arXiv:2003.00744v3 [cs.CL] 5 Oct 2020

PhoBERT: Pre-trained language models for Vietnamese

Dat Quoc Nguyen[1] and **Anh Tuan Nguyen**[2,*]
[1]VinAI Research, Vietnam; [2]NVIDIA, USA
v.datnq9@vinai.io, tuananhn@nvidia.com

Abstract

We present **PhoBERT** with two versions—PhoBERT$_{base}$ and PhoBERT$_{large}$—the *first* public large-scale monolingual language models pre-trained for Vietnamese. Experimental results show that PhoBERT consistently outperforms the recent best pre-trained multilingual model XLM-R (Conneau et al., 2020) and improves the state-of-the-art in multiple Vietnamese-specific NLP tasks including Part-of-speech tagging, Dependency parsing, Named-entity recognition and Natural language inference. We release PhoBERT to facilitate future research and downstream applications for Vietnamese NLP. Our PhoBERT models are available at: https://github.com/VinAIResearch/PhoBERT.

1 Introduction

Pre-trained language models, especially BERT (Devlin et al., 2019)—the Bidirectional Encoder Representations from Transformers (Vaswani et al., 2017), have recently become extremely popular and helped to produce significant improvement gains for various NLP tasks. The success of pre-trained BERT and its variants has largely been limited to the English language. For other languages, one could retrain a language-specific model using the BERT architecture (Cui et al., 2019; de Vries et al., 2019; Vu et al., 2019; Martin et al., 2020) or employ existing pre-trained multilingual BERT-based models (Devlin et al., 2019; Conneau and Lample, 2019; Conneau et al., 2020).

In terms of Vietnamese language modeling, to the best of our knowledge, there are two main concerns as follows:

- The Vietnamese Wikipedia corpus is the only data used to train monolingual language models (Vu et al., 2019), and it also is the only Vietnamese dataset which is included in the pre-training data used by all multilingual language models except XLM-R. It is worth noting that Wikipedia data is not representative of a general language use, and the Vietnamese Wikipedia data is relatively small (1GB in size uncompressed), while pre-trained language models can be significantly improved by using more pre-training data (Liu et al., 2019).
- All publicly released monolingual and multilingual BERT-based language models are not aware of the difference between Vietnamese syllables and word tokens. This ambiguity comes from the fact that the white space is also used to separate syllables that constitute words when written in Vietnamese.[1] For example, a 6-syllable written text "Tôi là một nghiên cứu viên" (I am a researcher) forms 4 words "Tôi$_{\text{I}}$ là$_{\text{am}}$ một$_{\text{a}}$ nghiên_cứu_viên$_{\text{researcher}}$". Without doing a pre-process step of Vietnamese word segmentation, those models directly apply Byte-Pair encoding (BPE) methods (Sennrich et al., 2016; Kudo and Richardson, 2018) to the syllable-level Vietnamese pre-training data.[2] Intuitively, for word-level Vietnamese NLP tasks, those models pre-trained on syllable-level data might not perform as good as language models pre-trained on word-level data.

To handle the two concerns above, we train the first large-scale monolingual BERT-based "base" and "large" models using a 20GB *word-level* Vietnamese corpus. We evaluate our models on four downstream Vietnamese NLP tasks: the common word-level ones of Part-of-speech (POS) tagging, Dependency parsing and Named-entity recogni-

[*]Work done during internship at VinAI Research.

[1]Thang et al. (2008) show that 85% of Vietnamese word types are composed of at least two syllables.

[2]Although performing word segmentation before applying BPE on the Vietnamese Wikipedia corpus, ETNLP (Vu et al., 2019) in fact does not publicly release any pre-trained BERT-based language model (https://github.com/vietnlp/etnlp). In particular, Vu et al. (2019) release a set of 15K BERT-based word embeddings specialized only for the Vietnamese NER task.

arXiv:2003.00744v3 [cs.CL] 5 Oct 2020

PhoBERT: Mô hình ngôn ngữ được huấn luyện trước cho tiếng Việt

Đạt Quốc Nguyễn[1] và Anh Tuấn Nguyễn[2,*1]
VinAI Research, Việt Nam; [2]NVIDIA, Mỹ
v.datnq9@vinai.io, tuananhn@nvidia.com

Tóm tắt

Chúng tôi giới thiệu PhoBERT với hai phiên bản—PhoBERT$_{base}$ và PhoBERT^{large}—là các mô hình ngôn ngữ đơn ngữ lớn đầu tiên được công khai và tiền huấn luyện cho tiếng Việt. Kết quả thí nghiệm cho thấy PhoBERT liên tục vượt trội hơn mô hình đa ngôn ngữ tiền huấn luyện mới nhất XLM-R (Conneau và cộng sự, 2020) và cải thiện trạng thái nghệ thuật trong nhiều nhiệm vụ NLP đặc thù tiếng Việt bao gồm gán nhãn từ loại, phân tích quan hệ phụ thuộc, nhận dạng thực thể có tên và suy luận ngôn ngữ tự nhiên. Chúng tôi phát hành PhoBERT để tạo điều kiện cho nghiên cứu trong tương lai và các ứng dụng hạ tầng cho NLP tiếng Việt. Các mô hình PhoBERT của chúng tôi có sẵn tại: https://github.com/VinAIResearch/PhoBERT.

1 Giới thiệu

Các mô hình ngôn ngữ được tiền huấn luyện, đặc biệt là BERT (Devlin et al., 2019)—Mô hình Biểu diễn Mã hóa Hai chiều từ Transformers (Vaswani et al., 2017), gần đây đã trở nên cực kỳ phổ biến và giúp tạo ra những cải thiện đáng kể cho các nhiệm vụ NLP khác nhau. Sự thành công của BERT được tiền huấn luyện và các biến thể của nó phần lớn chỉ giới hạn ở ngôn ngữ tiếng Anh. Đối với các ngôn ngữ khác, người ta có thể huấn luyện lại một mô hình ngôn ngữ cụ thể bằng cách sử dụng kiến trúc BERT (Cui et al., 2019; de Vries et al., 2019; Vu et al., 2019; Martin et al., 2020) hoặc sử dụng các mô hình dựa trên BERT đa ngôn ngữ đã được tiền huấn luyện sẵn (Devlin et al., 2019; Conneau và Lample, 2019; Conneau et al., 2020).

Về mô hình ngôn ngữ tiếng Việt, theo như chúng tôi biết, có hai mối quan tâm chính như sau:

• Tập dữ liệu Wikipedia tiếng Việt là dữ liệu duy nhất được sử dụng để huấn luyện các mô hình ngôn ngữ đơn ngữ (Vu et al., 2019), và nó cũng là tập dữ liệu tiếng Việt duy nhất được bao gồm trong dữ liệu tiền huấn luyện được sử dụng bởi tất cả các mô hình ngôn ngữ đa ngôn ngữ các mô hình ngoại trừ XLM-R. Cần lưu ý rằng dữ liệu Wikipedia không đại diện cho việc sử dụng ngôn ngữ chung, và dữ liệu Wikipedia tiếng Việt tương đối nhỏ (1GB chưa nén), t rong khi các mô hình ngôn ngữ được huấn luyện trước có thể được cải thiện đáng kể bằng cách sử dụng nhiều dữ liệu huấn luyện trước hơn (Liu et al., 2019).

•Tất cả các mô hình ngôn ngữ dựa trên BERT đơn ngữ và đa ngữ được phát hành công khai đều không nhận biết được sự khác biệt giữa â m tiết tiếng Việt và các từ. Sự mơ hồ này xuất phát từ thực tế rằng khoảng trắng cũng được sử dụng để tách các âm tiết tạo thành từ khi viết bằng tiếng Việt.[1] Ví dụ, một văn bản viết gồm 6 âm tiết "Tôi là một nghiên cứu viên" (I am a researcher) tạo thành 4 từ "TôiI làam mộta nghiên_cứu_viênresearcher".

Nếu không thực hiện bước tiền xử lý phân tách từ tiếng Việt, những mô hình này sẽ trực tiếp áp dụng các phương pháp mã hóa Byte-Pair (BPE) (Sennrich và cộng sự, 2016; Kudo và Richardson, 2018) cho dữ liệu tiền huấn luyện tiếng Việt ở cấp độ âm tiết. Một cách trực quan, đối với các tác vụ NLP tiếng Việt ở cấp độ từ, những mô hình được tiền huấn luyện trê n dữ liệu cấp độ âm tiết có thể không hoạt động tốt bằng các mô hình ngôn ngữ được tiền huấn luyện trên dữ liệu cấp độ từ.

Để xử lý hai vấn đề nêu trên, chúng tôi đào tạo các mô hình BERT đơn ngữ quy mô lớn 'cơ bản' và 'lớn' đầu tiên sử dụng một kho từ vựng tiếng Việt 20GB ở cấp độ từ. Chúng tôi đánh giá các mô hình của mình trên bốn nhiệm vụ NLP tiếng Việt hạ nguồn: các nhiệm vụ phổ biến ở cấp độ từ là Gắn nhãn từ loại (POS), Phân tích phụ thuộc và Nhận dạng thực thể đặt tên

[*]Công việc thực hiện trong thời gian thực tập tại VinAI Research.

[1]Thang và cộng sự (2008) chỉ ra rằng 85% các loại từ trong tiếng Việt được tạo thành từ ít nhất hai âm tiết. [2]Mặc dù thực hiện phân tách từ trước khi áp dụng BPE trên nguồn dữ liệu Wikipedia tiếng Việt, ETNLP (Vu và cộng sự, 2019) thực tế không công khai phát hành bất kỳ mô hình ngôn ngữ dựa trên BERT nào đã được huấn luyện trước (https://github.com/vietnlp/etnlp). Cụ thể, Vu và cộng sự (2019) phát hành một tập hợp 15 nghìn embeddings từ dựa trên BERT, chỉ chuyên biệt cho nhiệm vụ NER tiếng Việt.

tion (NER), and a language understanding task of Natural language inference (NLI) which can be formulated as either a syllable- or word-level task. Experimental results show that our models obtain state-of-the-art (SOTA) results on all these tasks. Our contributions are summarized as follows:

- We present the *first* large-scale monolingual language models pre-trained for Vietnamese.
- Our models help produce SOTA performances on four downstream tasks of POS tagging, Dependency parsing, NER and NLI, thus showing the effectiveness of large-scale BERT-based monolingual language models for Vietnamese.
- To the best of our knowledge, we also perform the *first* set of experiments to compare monolingual language models with the recent best multilingual model XLM-R in multiple (i.e. four) different language-specific tasks. The experiments show that our models outperform XLM-R on all these tasks, thus convincingly confirming that dedicated language-specific models still outperform multilingual ones.
- We publicly release our models under the name PhoBERT which can be used with `fairseq` (Ott et al., 2019) and `transformers` (Wolf et al., 2019). We hope that PhoBERT can serve as a strong baseline for future Vietnamese NLP research and applications.

2 PhoBERT

This section outlines the architecture and describes the pre-training data and optimization setup that we use for PhoBERT.

Architecture: Our PhoBERT has two versions, $\text{PhoBERT}_{\text{base}}$ and $\text{PhoBERT}_{\text{large}}$, using the same architectures of $\text{BERT}_{\text{base}}$ and $\text{BERT}_{\text{large}}$, respectively. PhoBERT pre-training approach is based on RoBERTa (Liu et al., 2019) which optimizes the BERT pre-training procedure for more robust performance.

Pre-training data: To handle the first concern mentioned in Section 1, we use a 20GB pre-training dataset of uncompressed texts. This dataset is a concatenation of two corpora: (i) the first one is the Vietnamese Wikipedia corpus (∼1GB), and (ii) the second corpus (∼19GB) is generated by removing similar articles and duplication from a 50GB Vietnamese news corpus.[3] To

[3] `https://github.com/binhvq/news-corpus`, crawled from a wide range of news websites and topics.

Task	#training	#valid	#test
POS tagging†	27,000	870	2,120
Dep. parsing†	8,977	200	1,020
NER†	14,861	2,000	2,831
NLI‡	392,702	2,490	5,010

Table 1: Statistics of the downstream task datasets. "#training", "#valid" and "#test" denote the size of the training, validation and test sets, respectively. † and ‡ refer to the dataset size as the numbers of sentences and sentence pairs, respectively.

solve the second concern, we employ RDRSegmenter (Nguyen et al., 2018) from VnCoreNLP (Vu et al., 2018) to perform word and sentence segmentation on the pre-training dataset, resulting in ∼145M word-segmented sentences (∼3B word tokens). Different from RoBERTa, we then apply `fastBPE` (Sennrich et al., 2016) to segment these sentences with subword units, using a vocabulary of 64K subword types. On average there are 24.4 subword tokens per sentence.

Optimization: We employ the RoBERTa implementation in `fairseq` (Ott et al., 2019). We set a maximum length at 256 subword tokens, thus generating 145M $\times$ 24.4 / 256 $\approx$ 13.8M sentence blocks. Following Liu et al. (2019), we optimize the models using Adam (Kingma and Ba, 2014). We use a batch size of 1024 across 4 V100 GPUs (16GB each) and a peak learning rate of 0.0004 for $\text{PhoBERT}_{\text{base}}$, and a batch size of 512 and a peak learning rate of 0.0002 for $\text{PhoBERT}_{\text{large}}$. We run for 40 epochs (here, the learning rate is warmed up for 2 epochs), thus resulting in 13.8M $\times$ 40 / 1024 $\approx$ 540K training steps for $\text{PhoBERT}_{\text{base}}$ and 1.08M training steps for $\text{PhoBERT}_{\text{large}}$. We pre-train $\text{PhoBERT}_{\text{base}}$ during 3 weeks, and then $\text{PhoBERT}_{\text{large}}$ during 5 weeks.

3 Experimental setup

We evaluate the performance of PhoBERT on four downstream Vietnamese NLP tasks: POS tagging, Dependency parsing, NER and NLI.

Downstream task datasets

Table 1 presents the statistics of the experimental datasets that we employ for downstream task evaluation. For POS tagging, Dependency parsing and NER, we follow the VnCoreNLP setup (Vu et al., 2018), using standard benchmarks of the VLSP 2013 POS tagging dataset,[4] the VnDT dependency

[4] `https://vlsp.org.vn/vlsp2013/eval`

tion (NER), và một nhiệm vụ hiểu ngôn ngữ của s uy luận ngôn ngữ tự nhiên (NLI) có thể được hình thành như một nhiệm vụ ở mức âm tiết hoặc từ. Kết quả thực nghiệm cho thấy các mô hình của chúng tôi đạt được kết quả tiên tiến nhất (SOTA) trên tất cả các nhiệm vụ này. Những đóng góp của chúng tôi được tóm tắt như sau:

• Chúng tôi giới thiệu các mô hình ngôn ngữ đơn ngữ quy mô lớn đầu tiên được tiền huấn luyện cho tiếng Việt.

• Các mô hình của chúng tôi giúp đạt được hiệu suất SOTA trên bốn tác vụ hạ nguồn gồm gán nhãn từ loại (POS tagging), phân tích phụ thuộc (Dependency parsing), nhận dạng thực thể có tên (NER) và suy luận ngôn ngữ tự nhiên (NLI), qua đó cho thấy hiệu quả của các mô hình ngôn ngữ đơn ngữ dựa trên BERT quy mô lớn đối với tiếng Việt.

Theo hiểu biết tốt nhất của chúng tôi, chúng tôi cũng thực hiện bộ thí nghiệm đầu tiên để so sánh các mô hình ngôn ngữ đơn với mô hình đa ngôn ngữ tốt nhất gần đây XLM-R trong nhiều (tức là bốn) nhiệm vụ cụ thể theo ngôn ngữ khác nhau. Các thí nghiệm cho thấy các mô hình của chúng tôi vượt trội hơn XLM-R trên tất cả các nhiệm vụ này, từ đó một cách thuyết phục xác nhận rằng các mô hình chuyên biệt theo ngôn ngữ vẫn vượt trội hơn các mô hình đa ngôn ngữ.

• Chúng tôi công khai phát hành các mô hình của mình dưới tên PhoBERT, có thể được sử dụng với `fairseq`(Ott et al., 2019) và `transformers` (Wolf et al., 2019). Chúng tôi hy vọng PhoBERT có thể trở thành một chuẩn mực mạnh mẽ cho nghiên cứu và ứng dụng NLP tiếng Việt trong tương lai.

2 PhoBERT

Phần này phác thảo kiến trúc và mô tả dữ liệu tiền huấn luyện cũng như thiết lập tối ưu hóa mà chúng tôi sử dụng cho PhoBERT.

Kiến trúc: PhoBERT của chúng tôi có hai phiên bản, $\text{PhoBERT}_{\text{base}}$ và $\text{PhoBERT}^{\text{large}}$, sử dụng cùng kiến trúc của $\text{BERT}_{\text{base}}$ và $\text{BERT}^{\text{large}}$, tương ứng. Phương pháp tiền huấn luyện của PhoBERT d ựa trên RoBERTa (Liu et al., 2019) nhằm tối ưu hóa quy trình tiền huấn luyện của BERT để đạt hiệu suất mạnh mẽ hơn.

Dữ liệu tiền huấn luyện: Để xử lý mối quan tâ m đầu tiên được đề cập trong Mục 1, chúng tôi sử dụng một bộ dữ liệu tiền huấn luyện 20GB các văn bản không nén. Bộ dữ liệu này là sự kết hợp của hai tập hợp văn bản: (i) tập đầu tiên là tập hợp Wikipedia tiếng Việt (∼1GB), và (ii) tập văn bản thứ hai (∼19GB) được tạo ra bằng cách loại bỏ các bài viết tương tự và trùng lặp từ một tập hợp tin tức tiếng Việt 50GB. [3] Để

[3] `https://github.com/binhvq/news-corpus`, được thu thập từ nhiều trang web tin tức và chủ đề khác nhau.

Task	#đào_tạo	#hợp lệ	#thử
Gắn nhãn từ loại†	27.000	870	Hai nghìn một trăm hai mươi
Phân tích cú pháp phụ thuộc†	Tám nghìn chín trăm bảy mươi bảy	200	Một nghìn hai mươi
NER†	14.861	Hai nghìn	Hai nghìn tám trăm ba mươi mốt
NLI‡	392.702	Hai nghìn bốn trăm chín mươi	Năm nghìn mười

Bảng 1: Thống kê các bộ dữ liệu của nhiệm vụ hạ nguồn. "#training", "#valid" và "#test" lần lượt chỉ kích thước của tập huấn luyện, tập xác thực và tập kiểm tra. † và ‡ lần lượt chỉ kích thước bộ dữ liệu theo số lượng câu và cặp câu.

Để giải quyết mối quan tâm thứ hai, chúng tôi sử dụng RDRSegmenter (Nguyen et al., 2018) từ VnCoreNLP (Vu et al., 2018) để thực hiện phân tách từ và câu trên bộ dữ liệu tiền huấn luyện, dẫn đến ∼145 triệu câu đã phân tách từ (∼3 tỷ từ). Khác với RoBERTa, chúng tôi sau đó áp dụng `fastBPE` (Sennrich et al., 2016) để phân tách các câu này thành các đơn vị phụ từ, sử dụng từ vựng gồm 64 nghìn loại đơn vị phụ từ. Trung bình có 24,4 token phụ từ mỗi câu.

Tối ưu hóa: Chúng tôi sử dụng cài đặt RoBERTa trong `fairseq` (Ott et al., 2019). Chúng tôi đặt độ dài tối đa là 256 token con, do đó tạo ra 145 M $\times$ 24.4 / 256 $\approx$ 13.8M khối câu. Theo Liu et al. (2019), chúng tôi tối ưu hóa các mô hình bằng Adam (Kingma và Ba, 2014). Chúng tôi sử dụng kích thước batch là 1024 trên 4 GPU V100 (mỗi GPU 16GB) và tốc độ học tối đa là 0.0004 cho $\text{PhoBERT}_{\text{base}}$, và kích thước batch là 512 và tốc độ học tối đa là 0.0002 cho $\text{PhoBERT}^{\text{large}}$. Chúng tôi chạy trong 40 epoch (ở đây, tốc độ học được làm nóng trong 2 epoch), dẫn đến 13.8M $\times$ 40/ 1024 $\approx$ 540K bước huấn luyện cho $\text{PhoBERT}_{\text{base}}$ và 1.08M bước huấn luyện cho $\text{PhoBERT}^{\text{large}}$. Chúng tôi tiền huấn luyện $\text{PhoBERT}_{\text{base}}$ trong 3 tuần, và sau đó $\text{PhoBERT}^{\text{large}}$ trong 5 tuần.

3 Thiết lập thí nghiệm

Chúng tôi đánh giá hiệu suất của PhoBERT trên bốn nhiệm vụ xử lý ngôn ngữ tự nhiên tiếng Việt: gán nhãn từ loại (POS tagging), phân tích phụ thuộc (Dependency parsing), nhận dạng thực thể đặt tên (NER) và suy luận ngôn ngữ tự nhiên (NLI).

Bộ dữ liệu cho tác vụ hạ nguồn

Bảng 1 trình bày số liệu thống kê của các bộ dữ li ệu thí nghiệm mà chúng tôi sử dụng để đánh giá các tác vụ hạ nguồn. Đối với gán nhãn POS, phân tích phụ thuộc và NER, chúng tôi tuân theo thiết l ập VnCoreNLP (Vu et al., 2018), sử dụng các chuẩn đánh giá tiêu chuẩn của bộ dữ liệu gán nhãn POS VLSP 2013, [4] bộ dữ liệu phụ thuộc VnDT

[4] `https://vlsp.org.vn/vlsp2013/eval`

POS tagging (word-level)		**Dependency parsing** (word-level)	
Model	Acc.	Model	LAS / UAS
RDRPOSTagger (Nguyen et al., 2014a) [♣]	95.1	_	_
BiLSTM-CNN-CRF (Ma and Hovy, 2016) [♣]	95.4	VnCoreNLP-DEP (Vu et al., 2018) [★]	71.38 / 77.35
VnCoreNLP-POS (Nguyen et al., 2017) [♣]	95.9	jPTDP-v2 [★]	73.12 / 79.63
jPTDP-v2 (Nguyen and Verspoor, 2018) [★]	95.7	jointWPD [★]	73.90 / 80.12
jointWPD (Nguyen, 2019) [★]	96.0	Biaffine (Dozat and Manning, 2017) [★]	74.99 / 81.19
XLM-R_{base} (our result)	96.2	Biaffine w/ XLM-R_{base} (our result)	76.46 / 83.10
XLM-R_{large} (our result)	96.3	Biaffine w/ XLM-R_{large} (our result)	75.87 / 82.70
$PhoBERT_{base}$	96.7	Biaffine w/ $PhoBERT_{base}$	**78.77 / 85.22**
$PhoBERT_{large}$	**96.8**	Biaffine w/ $PhoBERT_{large}$	77.85 / 84.32

Table 2: Performance scores (in %) on the POS tagging and Dependency parsing test sets. “Acc.”, “LAS” and “UAS” abbreviate the Accuracy, the Labeled Attachment Score and the Unlabeled Attachment Score, respectively (here, all these evaluation metrics are computed on all word tokens, including punctuation). [♣] and [★] denote results reported by Nguyen et al. (2017) and Nguyen (2019), respectively.

Gắn nhãn từ loại (cấp từ)		**Phân tích phụ thuộc (cấp từ)**	
Mô hình	Acc.	Mô hình	LAS / UAS
RDRPOSTagger (Nguyen và cộng sự, 2014a) [♣]	95.1	_	_
BiLSTM-CNN-CRF (Ma và Hovy, 2016) [♣]	95.4	VnCoreNLP-DEP (Vu và cộng sự, 2018) [★]	71,38 / 77,35
VnCoreNLP-POS (Nguyen và cộng sự, 2017) [♣]	95.9	jPTDP-v2 [★]	73,12 / 79,63
jPTDP-v2 (Nguyen và Verspoor, 2018) [★]	95.7	jointWPD [★]	73,90 / 80,12
jointWPD (Nguyen, 2019) [★]	96.0	Biaffine (Dozat và Manning, 2017) [★]	74,99 / 81,19
XLM-R_{base} (kết quả của chúng tôi)	96.2	Biaffine với XLM-R_{base} (kết quả của chúng tôi)	76,46 / 83,10
XLM-R^{large} (kết quả của chúng tôi)	96.3	Biaffine với XLM-R^{large} (kết quả của chúng tôi)	75,87 / 82,70
$PhoBERT_{base}$	96.7	Biaffine với $PhoBERT_{base}$	**78,77 / 85,22**
$PhoBERT^{large}$	**96.8**	Biaffine với $PhoBERT^{large}$	77,85 / 84,32

Bảng 2: Điểm hiệu suất (tính theo %) trên các bộ dữ liệu kiểm tra gán nhãn POS và phân tích phụ thuộc. “Acc.”, “LAS” và “UAS” lần lượt là viết tắt của Độ Chính Xác, Điểm Gắn Nhãn (Labeled Attachment Score) và Điểm Gắn Nhãn Không Nhãn (Unlabeled Attachment Score) (ở đây, tất cả các chỉ số đánh giá này được tính trên tất cả các từ, bao gồm cả dấu câu). [♣] và [★] lần lượt chỉ kết quả được báo cáo bởi Nguyen et al. (2017) và Nguyen (2019).

treebank v1.1 (Nguyen et al., 2014b) with POS tags predicted by VnCoreNLP and the VLSP 2016 NER dataset (Nguyen et al., 2019a).

For NLI, we use the manually-constructed Vietnamese validation and test sets from the cross-lingual NLI (XNLI) corpus v1.0 (Conneau et al., 2018) where the Vietnamese training set is released as a machine-translated version of the corresponding English training set (Williams et al., 2018). Unlike the POS tagging, Dependency parsing and NER datasets which provide the gold word segmentation, for NLI, we employ RDRSegmenter to segment the text into words before applying BPE to produce subwords from word tokens.

Fine-tuning

Following Devlin et al. (2019), for POS tagging and NER, we append a linear prediction layer on top of the PhoBERT architecture (i.e. to the last Transformer layer of PhoBERT) w.r.t. the first subword of each word token.[5] For dependency parsing, following Nguyen (2019), we employ a reimplementation of the state-of-the-art Biaffine dependency parser (Dozat and Manning, 2017) from Ma et al. (2018) with default optimal hyper-parameters. We then extend this parser by replacing the pre-trained word embedding of each word in an input sentence by the corresponding contextualized embedding (from the last layer) computed for the first subword token of the word.

For POS tagging, NER and NLI, we employ `transformers` (Wolf et al., 2019) to fine-tune PhoBERT for each task and each dataset independently. We use AdamW (Loshchilov and Hutter, 2019) with a fixed learning rate of 1.e-5 and a batch size of 32 (Liu et al., 2019). We fine-tune in 30 training epochs, evaluate the task performance after each epoch on the validation set (here, early stopping is applied when there is no improvement after 5 continuous epochs), and then select the best model checkpoint to report the final result on the test set (note that each of our scores is an average over 5 runs with different random seeds).

[5] In our preliminary experiments, using the average of contextualized embeddings of subword tokens of each word to represent the word produces slightly lower performance than using the contextualized embedding of the first subword.

4 Experimental results

Main results

Tables 2 and 3 compare PhoBERT scores with the previous highest reported results, using the same experimental setup. It is clear that our PhoBERT helps produce new SOTA performance results for all four downstream tasks.

For POS tagging, the neural model jointWPD for joint POS tagging and dependency parsing (Nguyen, 2019) and the feature-based model VnCoreNLP-POS (Nguyen et al., 2017) are the two previous SOTA models, obtaining accuracies at about 96.0%. PhoBERT obtains 0.8% absolute higher accuracy than these two models.

For Dependency parsing, the previous highest parsing scores LAS and UAS are obtained by the Biaffine parser at 75.0% and 81.2%, respectively. PhoBERT helps boost the Biaffine parser with about 4% absolute improvement, achieving a LAS at 78.8% and a UAS at 85.2%.

For NER, $PhoBERT_{large}$ produces 1.1 points higher F_1 than $PhoBERT_{base}$. In addition, $PhoBERT_{base}$ obtains 2+ points higher than the previous SOTA feature- and neural network-based models VnCoreNLP-NER (Vu et al., 2018) and BiLSTM-CNN-CRF (Ma and Hovy, 2016) which

treebank v1.1 (Nguyễn và cộng sự, 2014b) với các nhãn POS được dự đoán bởi VnCoreNLP và bộ dữ liệu NER VLSP 2016 (Nguyễn và cộng sự, 2019a).

Đối với NLI, chúng tôi sử dụng các tập xác th ực và kiểm tra tiếng Việt được xây dựng thủ công từ tập hợp dữ liệu NLI đa ngôn ngữ (XNLI) phiên bản 1.0 (Conneau et al., 2018), trong đó tập huấn luyện tiếng Việt được phát hành dưới dạng phiên bản dịch máy của tập huấn luyện tiếng Anh tương ứng (Williams et al., 2018). Khác với các tập dữ liệu gán nhãn POS, phân tích Dependency và NER cung cấp phân tách từ chuẩn, đối với NLI, chúng tôi sử dụng RDRSegmenter để phân tách văn bản thành các từ trước khi áp dụng BPE để tạo các tiểu từ từ các token từ.

Tinh chỉnh

Theo Devlin và cộng sự (2019), đối với gán nhãn POS và NER, chúng tôi thêm một lớp dự đoán t uyến tính lên trên kiến trúc PhoBERT (tức là trên lớp Transformer cuối cùng của PhoBERT) liên quan đến phân từ con đầu tiên của mỗi từ.Đối với phân tích phụ thuộc, theo Nguyen (2019), chúng tôi sử dụng một cài đặt lại bộ phân tích phụ thuộc Biaffine tiên tiến nhất (Dozat và Manning, 2017) từ Ma và cộng sự (2018) với các siêu tham số tối ưu mặc định. Sau đó, chúng tôi mở rộng bộ phân tích này bằng cách thay thế embedding từ được huấn luyện sẵn của mỗi từ trong câu đầu vào bằng embedding có ngữ cảnh tương ứng (từ lớp cuối cùng) được tính cho phân từ con đầu tiên của từ đó.

Đối với gán nhãn POS, NER và NLI, chúng tôi sử dụng `transformers` (Wolf và cộng sự, 2019) để tinh chỉnh PhoBERT cho từng nhiệm vụ và từng tập dữ liệu một cách độc lập. Chúng tôi sử dụng AdamW (Loshchilov và Hutter, 2019) với một tốc độ học cố định là 1.e-5 và kích thước lô là 32 (Liu et al., 2019). Chúng tôi tinh c hỉnh trong 30 epoch huấn luyện, đánh giá hiệu s uất nhiệm vụ sau mỗi epoch trên tập kiểm định (ở đây, áp dụng dừng sớm khi không có cải thiện sau 5 epoch liên tiếp), và sau đó chọn điểm kiểm tra mô hình tốt nhất để báo cáo kết quả cuối cùng trên tập kiểm tra (lưu ý rằng mỗi điểm số của chúng tôi là trung bình của 5 lần chạy với các hạt giống ngẫu nhiên khác nhau).

Trong các thí nghiệm sơ bộ của chúng tôi, việc sử dụng trung bình của các embedding ngữ cảnh hóa của các token phụ của mỗi từ để đại diện cho từ đó cho hiệu suất hơi thấp hơn so với việc sử dụng embedding ngữ cảnh hóa của token phụ đầu tiên.

4 Kết quả thí nghiệm

Kết quả chính

Bảng 2 và 3 so sánh điểm số PhoBERT với các kết quả cao nhất đã được báo cáo trước đó, sử dụng cùng một thiết lập thí nghiệm. Rõ ràng là PhoBERT của chúng tôi giúp tạo ra các kết quả hiệu suất SOTA mới cho tất cả bốn nhiệm vụ hạ nguồn.

Đối với việc gán nhãn từ loại (POStagging), mô hình neural jointWPD cho việc gán nhãn từ loại và phân tích phụ thuộc đồng thời (Nguyen, 2019) và mô hình dựa trên đặc trưng VnCoreNLP-POS (Nguyen et al., 2017) là hai mô hình SOTA trước đó, đạt độ chính xác khoảng 96,0%. PhoBERT đạt độ chính xác cao hơn tuyệt đối 0,8% so với hai mô hình này.

Đối với phân tích phụ thuộc, các điểm phân tích cao nhất trước đây LAS và UAS được đạt được bởi bộ phân tích Biaffine lần lượt là 75,0% và 81,2%. PhoBERT giúp tăng cường bộ phân tích Biaffine với khoảng 4% cải thiện tuyệt đối, đạt LAS ở mức 78,8% và UAS ở mức 85,2%.

Đối với NER, $PhoBERT^{large}$ cho điểm F_1 cao hơn 1,1 điểm so với $PhoBERT_{base}$. Ngoài ra, $PhoBERT_{base}$ đạt 2+ điểm cao hơn so với các mô hình dựa trên đặc trưng và mạng nơ-ron SOTA trước đó là VnCoreNLP-NER (Vu et al., 2018) và BiLSTM-CNN-CRF (Ma và Hovy, 2016) vốn

NER (word-level)		**NLI** (syllable- or word-level)	
Model	F_1	Model	Acc.
BiLSTM-CNN-CRF [♦]	88.3	_	_
VnCoreNLP-NER (Vu et al., 2018) [♦]	88.6	BiLSTM-max (Conneau et al., 2018)	66.4
VNER (Nguyen et al., 2019b)	89.6	mBiLSTM (Artetxe and Schwenk, 2019)	72.0
BiLSTM-CNN-CRF + ETNLP [♠]	91.1	multilingual BERT (Devlin et al., 2019) [■]	69.5
VnCoreNLP-NER + ETNLP [♠]	91.3	$XLM_{MLM+TLM}$ (Conneau and Lample, 2019)	76.6
$XLM\text{-}R_{base}$ (our result)	92.0	$XLM\text{-}R_{base}$ (Conneau et al., 2020)	75.4
$XLM\text{-}R_{large}$ (our result)	92.8	$XLM\text{-}R_{large}$ (Conneau et al., 2020)	79.7
$PhoBERT_{base}$	93.6	$PhoBERT_{base}$	78.5
$PhoBERT_{large}$	**94.7**	$PhoBERT_{large}$	**80.0**

Table 3: Performance scores (in %) on the NER and NLI test sets. [♦], [♠] and [■] denote results reported by Vu et al. (2018), Vu et al. (2019) and Wu and Dredze (2019), respectively. Note that there are higher Vietnamese NLI results reported for XLM-R when fine-tuning on the concatenation of all 15 training datasets from the XNLI corpus (i.e. TRANSLATE-TRAIN-ALL: 79.5% for $XLM\text{-}R_{base}$ and 83.4% $XLM\text{-}R_{large}$). However, those results might not be comparable as we only use the monolingual Vietnamese training data for fine-tuning.

are trained with the set of 15K BERT-based ETNLP word embeddings (Vu et al., 2019).

For NLI, PhoBERT outperforms the multilingual BERT (Devlin et al., 2019) and the BERT-based cross-lingual model with a new translation language modeling objective $XLM_{MLM+TLM}$ (Conneau and Lample, 2019) by large margins. PhoBERT also performs better than the recent best pre-trained multilingual model XLM-R but using far fewer parameters than XLM-R: 135M ($PhoBERT_{base}$) vs. 250M ($XLM\text{-}R_{base}$); 370M ($PhoBERT_{large}$) vs. 560M ($XLM\text{-}R_{large}$).

Discussion

We find that $PhoBERT_{large}$ achieves 0.9% lower dependency parsing scores than $PhoBERT_{base}$. One possible reason is that the last Transformer layer in the BERT architecture might not be the optimal one which encodes the richest information of syntactic structures (Hewitt and Manning, 2019; Jawahar et al., 2019). Future work will study which PhoBERT's Transformer layer contains richer syntactic information by evaluating the Vietnamese parsing performance from each layer.

Using more pre-training data can significantly improve the quality of the pre-trained language models (Liu et al., 2019). Thus it is not surprising that PhoBERT helps produce better performance than ETNLP on NER, and the multilingual BERT and $XLM_{MLM+TLM}$ on NLI (here, PhoBERT uses 20GB of Vietnamese texts while those models employ the 1GB Vietnamese Wikipedia corpus).

Following the fine-tuning approach that we use for PhoBERT, we carefully fine-tune XLM-R for the remaining Vietnamese POS tagging, Dependency parsing and NER tasks (here, it is applied to the first sub-syllable token of the first syllable of each word).[6] Tables 2 and 3 show that our PhoBERT also does better than XLM-R on these three word-level tasks. It is worth noting that XLM-R uses a 2.5TB pre-training corpus which contains 137GB of Vietnamese texts (i.e. about 137 / 20 ≈ 7 times bigger than our pre-training corpus). Recall that PhoBERT performs Vietnamese word segmentation to segment syllable-level sentences into word tokens before applying BPE to segment the word-segmented sentences into subword units, while XLM-R directly applies BPE to the syllable-level Vietnamese pre-training sentences. This reconfirms that the dedicated language-specific models still outperform the multilingual ones (Martin et al., 2020).[7]

5 Conclusion

In this paper, we have presented the first large-scale monolingual PhoBERT language models pre-trained for Vietnamese. We demonstrate the usefulness of PhoBERT by showing that PhoBERT performs better than the recent best multilingual model XLM-R and helps produce the SOTA performances for four downstream Vietnamese NLP tasks of POS tagging, Dependency parsing, NER and NLI. By publicly releasing PhoBERT models, we hope that they can foster future research and applications in Vietnamese NLP.

[6]For fine-tuning XLM-R, we use a grid search on the validation set to select the AdamW learning rate from {5e-6, 1e-5, 2e-5, 4e-5} and the batch size from {16, 32}.

[7]Note that Martin et al. (2020) only compare their model CamemBERT with XLM-R on the French NLI task.

NER (cấp từ)		NLI (cấp độ âm tiết hoặc từ)	
Mô hình	F_1	Mô hình	Acc.
BiLSTM-CNN-CRF [♦]	88.3	_	_
VnCoreNLP-NER (Vu et al., 2018) [♦]	88.6	BiLSTM-max (Conneau và cộng sự, 2018)	66.4
VNER (Nguyen và cộng sự, 2019b)	89.6	mBiLSTM (Artetxe và Schwenk, 2019)	72.0
BiLSTM-CNN-CRF + ETNLP [♠]	91.1	BERT đa ngôn ngữ (Devlin và cộng sự, 2019) [■]	69.5
VnCoreNLP-NER +ETNLP [♠]	91.3	$XLM_{MLM+TLM}$ (Conneau và Lample, 2019) 76,6	
$XLM\text{-}R_{base}$ (kết quả của chúng tôi)	92.0	$XLM\text{-}R_{base}$ (Conneau và cộng sự, 2020)	75.4
$XLM\text{-}R^{large}$ (kết quả của chúng tôi)	92.8	$XLM\text{-}R^{large}$ (Conneau và cộng sự, 2020)	79.7
$PhoBERT_{base}$	93.6	$PhoBERT_{base}$	78.5
$PhoBERT^{large}$	**94.7**	$PhoBERT^{large}$	**80.0**

Bảng 3: Điểm hiệu suất (tính theo %) trên các bộ kiểm tra NER và NLI. [♦], [♠] và [■] lần lượt chỉ ra kết quả được báo cáo bởi Vu et al. (2018), Vu et al. (2019) và Wu and Dredze (2019). Lưu ý rằng có những kết quả NLI tiếng Việt cao hơn được báo cáo cho XLM-R khi tinh chỉnh trên tập hợp nối tất cả 15 bộ dữ liệu huấn luyện từ tập XNLI (tức là TRANSLATE-TRAIN-ALL: 79,5% cho $XLM\text{-}R_{base}$ và 83,4% $XLM\text{-}R^{large}$). Tuy nhiên, những kết quả đó có thể không so sánh được vì chúng tôi chỉ sử dụng dữ liệu huấn luyện tiếng Việt đơn ngữ để tinh chỉnh.

được huấn luyện với tập hợp 15K từ nhúng BERT dựa trên ETNLP (Vụ et al., 2019).

Đối với NLI, PhoBERT vượt trội hơn BERT đa ngôn ngữ (Devlin et al., 2019) và mô hình đa ngôn ngữ dựa trên BERT với mục tiêu mô hình hóa ngôn ngữ dịch mới $XLM_{MLM+TLM}$(Conneau và Lample, 2019) với khoảng cách lớn. PhoBERT cũng hoạt động tốt hơn so với mô hình đa ngôn ngữ được huấn luyện trước tốt nhất gần đây XLM-R nhưng sử dụng ít tham số hơn nhiều so với XLM-R: 135M ($PhoBERT_{base}$) so với 250M ($XLM\text{-}R_{base}$); 370M ($PhoBERT^{large}$) so với 560M ($XLM\text{-}R^{large}$).

Thảo luận

Chúng tôi nhận thấy rằng $PhoBERT^{large}$ đạt điểm phân tích phụ thuộc thấp hơn 0,9% so với $PhoBERT_{base}$. Một lý do có thể là lớp Transformer cuối cùng trong kiến trúc BERT có thể không phải là lớp tối ưu chứa nhiều thông tin nhất về cấu trúc cú pháp (Hewitt và Manning, 2019; Jawahar et al., 2019). Công việc tương lai sẽ nghiên cứu lớp Transformer nào của PhoBERT chứa nhiều thông tin cú pháp hơn bằng cách đánh giá hiệu suất phân tích ngôn ngữ Việt Nam từ từng lớp.

Sử dụng nhiều dữ liệu tiền huấn luyện hơn có thể cải thiện đáng kể chất lượng của các mô hình ngôn ngữ đã được tiền huấn luyện (Liu và cộng sự, 2019). Do đó, không ngạc nhiên khi PhoBERT giúp tạo ra hiệu suất tốt hơn so với ETNLP trên NER, và BERT đa ngôn ngữ và XLM $_{MLM+TLM}$ trên NLI (ở đây, PhoBERT sử dụng 20GB văn bản tiếng Việt trong khi các mô hình đó sử dụng kho Wikipedia tiếng Việt 1GB).

Theo phương pháp tinh chỉnh mà chúng tôi sử dụng cho PhoBERT, chúng tôi cẩn thận tinh chỉnh XLM-R cho các nhãn POS còn lại của tiếng Việt, Depen- các nhiệm vụ phân tích cú pháp phụ thuộc và NER (ở đây, nó được áp dụng cho token phụ-âm tiết đầu tiên của âm tiết đầu tiên của mỗi từ).[6] Bảng 2 và 3 cho thấy PhoBERT của chúng tôi cũng làm tốt hơn XLM-R trên ba nhiệm vụ cấp từ này. Đáng chú ý là XLM-R sử dụng một tập hợp dữ liệu tiền huấn luyện 2,5TB, trong đó chứa 137GB văn bản tiếng Việt (tức là khoảng 137 / 20 ≈ 7 lần lớn hơn tập dữ liệu tiền huấn luyện của chúng tôi). Hãy nhớ rằng PhoBERT thực hiện phân tách từ tiếng Việt để phân tách các câu cấp âm tiết thành các token từ trước khi áp dụng BPE để phân tách các câu đã phân tách từ thành các đơn vị phụ từ, trong khi XLM-R trực tiếp áp dụng BPE cho các câu tiền huấn luyện cấp âm tiết tiếng Việt. Điều này xác nhận lại rằng các mô hình chuyên biệt cho từng ngôn ngữ vẫn vượt trội hơn các mô hình đa ngôn ngữ (Martin et al., 2020).[7]

5 Kết luận

Trong bài báo này, chúng tôi đã trình bày các mô hình ngôn ngữ PhoBERT đơn ngữ quy mô lớn đầu tiên được tiền huấn luyện cho tiếng Việt. Chúng tôi chứng minh tính hữu ích của PhoBERT bằng cách cho thấy PhoBERT hoạt động tốt hơn mô hình đa ngôn ngữ mới nhất XLM-R và giúp đạt được hiệu suất SOTA cho bốn nhiệm vụ NLP tiếng Việt hạ nguồn gồm gán nhãn từ loại (POS tagging), phân tích phụ thuộc (Dependency parsing), nhận dạng thực thể đặt tên (NER) và suy luận ngôn ngữ tự nhiên (NLI). Bằng cách công khai phát hành các mô hình PhoBERT, chúng tôi hy vọng rằng chúng có thể thúc đẩy nghiên cứu và ứng dụng trong NLP tiếng Việt trong tương lai.

[6]Đối với việc tinh chỉnh XLM-R, chúng tôi sử dụng tìm kiếm lưới trên tập xác thực để chọn tốc độ học AdamW từ {5 6, 1 5, 2 5, 4 5 16, 32 e- e- e- e- } và kích thước lô từ { }. [7]Lưu ý rằng Martin và cộng sự (2020) chỉ so sánh mô hình CamemBERT của họ với XLM-R trên nhiệm vụ NLI tiếng Pháp.

References

Mikel Artetxe and Holger Schwenk. 2019. Massively Multilingual Sentence Embeddings for Zero-Shot Cross-Lingual Transfer and Beyond. *TACL*, 7:597–610.

Alexis Conneau, Kartikay Khandelwal, Naman Goyal, Vishrav Chaudhary, Guillaume Wenzek, Francisco Guzmán, Edouard Grave, Myle Ott, Luke Zettlemoyer, and Veselin Stoyanov. 2020. Unsupervised Cross-lingual Representation Learning at Scale. In *Proceedings of ACL*, pages 8440–8451.

Alexis Conneau and Guillaume Lample. 2019. Cross-lingual Language Model Pretraining. In *Proceedings of NeurIPS*, pages 7059–7069.

Alexis Conneau, Ruty Rinott, Guillaume Lample, Holger Schwenk, Ves Stoyanov, Adina Williams, and Samuel R. Bowman. 2018. XNLI: Evaluating cross-lingual sentence representations. In *Proceedings of EMNLP*, pages 2475–2485.

Yiming Cui, Wanxiang Che, Ting Liu, Bing Qin, Ziqing Yang, Shijin Wang, and Guoping Hu. 2019. Pre-Training with Whole Word Masking for Chinese BERT. *arXiv preprint*, arXiv:1906.08101.

Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. 2019. BERT: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of NAACL*, pages 4171–4186.

Timothy Dozat and Christopher D. Manning. 2017. Deep Biaffine Attention for Neural Dependency Parsing. In *Proceedings of ICLR*.

John Hewitt and Christopher D. Manning. 2019. A structural probe for finding syntax in word representations. In *Proceedings of NAACL*, pages 4129–4138.

Ganesh Jawahar, Benoît Sagot, and Djamé Seddah. 2019. What does BERT learn about the structure of language? In *Proceedings of ACL*, pages 3651–3657.

Diederik P. Kingma and Jimmy Ba. 2014. Adam: A Method for Stochastic Optimization. *arXiv preprint*, arXiv:1412.6980.

Taku Kudo and John Richardson. 2018. SentencePiece: A simple and language independent subword tokenizer and detokenizer for Neural Text Processing. In *Proceedings of EMNLP: System Demonstrations*, pages 66–71.

Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, and Veselin Stoyanov. 2019. RoBERTa: A Robustly Optimized BERT Pretraining Approach. *arXiv preprint*, arXiv:1907.11692.

Ilya Loshchilov and Frank Hutter. 2019. Decoupled Weight Decay Regularization. In *Proceedings of ICLR*.

Xuezhe Ma and Eduard Hovy. 2016. End-to-end sequence labeling via bi-directional LSTM-CNNs-CRF. In *Proceedings of ACL*, pages 1064–1074.

Xuezhe Ma, Zecong Hu, Jingzhou Liu, Nanyun Peng, Graham Neubig, and Eduard Hovy. 2018. Stack-Pointer Networks for Dependency Parsing. In *Proceedings of ACL*, pages 1403–1414.

Louis Martin, Benjamin Muller, Pedro Javier Ortiz Suárez, Yoann Dupont, Laurent Romary, Éric Villemonte de la Clergerie, Djamé Seddah, and Benoît Sagot. 2020. CamemBERT: a Tasty French Language Model. In *Proceedings of ACL*, pages 7203–7219.

Dat Quoc Nguyen. 2019. A neural joint model for Vietnamese word segmentation, POS tagging and dependency parsing. In *Proceedings of ALTA*, pages 28–34.

Dat Quoc Nguyen, Dai Quoc Nguyen, Dang Duc Pham, and Son Bao Pham. 2014a. RDRPOSTagger: A Ripple Down Rules-based Part-Of-Speech Tagger. In *Proceedings of the Demonstrations at EACL*, pages 17–20.

Dat Quoc Nguyen, Dai Quoc Nguyen, Son Bao Pham, Phuong-Thai Nguyen, and Minh Le Nguyen. 2014b. From Treebank Conversion to Automatic Dependency Parsing for Vietnamese. In *Proceedings of NLDB*, pages 196–207.

Dat Quoc Nguyen, Dai Quoc Nguyen, Thanh Vu, Mark Dras, and Mark Johnson. 2018. A Fast and Accurate Vietnamese Word Segmenter. In *Proceedings of LREC*, pages 2582–2587.

Dat Quoc Nguyen and Karin Verspoor. 2018. An improved neural network model for joint POS tagging and dependency parsing. In *Proceedings of the CoNLL 2018 Shared Task*, pages 81–91.

Dat Quoc Nguyen, Thanh Vu, Dai Quoc Nguyen, Mark Dras, and Mark Johnson. 2017. From word segmentation to POS tagging for Vietnamese. In *Proceedings of ALTA*, pages 108–113.

Huyen Nguyen, Quyen Ngo, Luong Vu, Vu Tran, and Hien Nguyen. 2019a. VLSP Shared Task: Named Entity Recognition. *Journal of Computer Science and Cybernetics*, 34(4):283–294.

Kim Anh Nguyen, Ngan Dong, and Cam-Tu Nguyen. 2019b. Attentive Neural Network for Named Entity Recognition in Vietnamese. In *Proceedings of RIVF*.

Myle Ott, Sergey Edunov, Alexei Baevski, Angela Fan, Sam Gross, Nathan Ng, David Grangier, and Michael Auli. 2019. fairseq: A Fast, Extensible Toolkit for Sequence Modeling. In *Proceedings of NAACL-HLT 2019: Demonstrations*, pages 48–53.

Tài liệu tham khảo

Mikel Artetxe và Holger Schwenk. 2019. Nhúng Câu Đa Ngôn Ngữ Quy Mô Lớn cho Chuyển Giao Liên Ngôn Ngữ Zero-Shot và Hơn Nữa. TACL, 7:597–610.

Alexis Conneau, Kartikay Khandelwal, Naman Goyal, Vishrav Chaudhary, Guillaume Wenzek, Francisco Guzmán, Edouard Grave, Myle Ott, Luke Zettelmoyer và Veselin Stoyanov. 2020. Học Biểu Diễn Đa Ngôn Ngữ Không Giám Sát ở Quy Mô Lớn. Trong Kỷ yếu của ACL, các trang 8440–8451.

Alexis Conneau và Guillaume Lample. 2019. Huấn luyện trước Mô hình Ngôn ngữ Đa ngôn ngữ. Trong Kỷ yếu của NeurIPS, trang 7059–7069.

Alexis Conneau, Ruty Rinott, Guillaume Lample, Holger Schwenk, Ves Stoyanov, Adina Williams, và Samuel R. Bowman. 2018. XNLI: Đánh giá các đại diện câu đa ngôn ngữ. Trong Kỷ yếu của EMNLP, trang 2475–2485.

Yiming Cui, Wanxiang Che, Ting Liu, Bing Qin, Ziqing Yang, Shijin Wang, và Guoping Hu. 2019. Tiền huấn luyện với việc che toàn bộ từ cho BERT tiếng Trung. arXiv preprint, arXiv:1906.08101.

Jacob Devlin, Ming-Wei Chang, Kenton Lee, và Kristina Toutanova. 2019. BERT: Huấn luyện trước các bộ biến đổi hai chiều sâu cho hiểu biết ngôn ng ữ. Trong Kỷ yếu của NAACL, trang 4171–4186.

Timothy Dozat và Christopher D. Manning. 2017. Chú ý Biaffine Sâu cho Phân tích Phụ thuộc Thần kinh. Trong Kỷ yếu của ICLR.

John Hewitt và Christopher D. Manning. 2019. Một công cụ thăm dò cấu trúc để tìm cú pháp trong các biểu diễn từ. Trong Kỷ yếu của NAACL, trang 4129–4138.

Ganesh Jawahar, Benoît Sagot, và Djamé Seddah. 2019. BERT học được gì về cấu trúc của ngôn ngữ? Trong Kỷ yếu của ACL, trang 3651–3657.

Diederik P. Kingma và Jimmy Ba. 2014. Adam: Một Phương Pháp Tối Ưu Ngẫu Nhiên. Bản in trước trên arXiv, arXiv:1412.6980.

Taku Kudo và John Richardson. 2018. Sentence-Piece: Một bộ phân tách và gỡ tách từ con đơn giản và độc lập ngôn ngữ cho Xử lý Văn bản Bằng Mạng Nơ-ron. Trong Kỷ yếu của EMNLP: Trình diễn Hệ thống, trang 66–71.

Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, và Veselin Stoyanov. 2019. RoBERTa: Một Phương Pháp Huấn Luyện BERT Được Tối Ưu Hóa Mạnh Mẽ. Bản thảo arXiv, arXiv:1907.11692.

Ilya Loshchilov và Frank Hutter. 2019. Chuẩn hóa Tăng cường Trọng số Tách rời. Trong Kỷ yếu của ICLR. Xuezhe Ma và Eduard Hovy. 2016. Gán nhãn tuần tự đầu-cuối thông qua LSTM-CNN hai chiều - CRF. Trong Kỷ yếu của ACL, trang 1064–1074. Xuezhe Ma, Zecong Hu, Jingzhou Liu, Nanyun Peng, Graham Neubig, và Eduard Hovy. 2018. Mạng Ngón tay Chồng cho Phân tích Phụ thuộc. Trong Kỷ yếu của ACL, trang 1403–1414.

Louis Martin, Benjamin Muller, Pedro Javier Ortiz Suárez, Yoann Dupont, Laurent Romary, Éric Ville-monte de la Clergerie, Djamé Seddah, và Benoît Sagot. 2020. CamemBERT: Một Mô Hình Ngôn Ngữ Tiếng Pháp Ngon Lành. Trong Kỷ yếu của ACL, trang 7203–7219.

Dat Quoc Nguyen. 2019. Một mô hình kết hợp thần kinh cho phân đoạn từ, gán nhãn từ loại và phân tí ch phụ thuộc tiếng Việt. Trong Kỷ yếu của ALTA, trang 28–34.

Đạt Quốc Nguyễn, Đại Quốc Nguyễn, Đăng Đức Phạm, và Sơn Bảo Phạm. 2014a. RDRPOSTagger: Bộ gán nhãn từ loại dựa trên quy tắc Ripple Down. Trong Kỷ yếu các Bài trình diễn tại EACL, trang 17–20.

Dat Quoc Nguyen, Dai Quoc Nguyen, Son Bao Pham, Phuong-Thai Nguyen, và Minh Le Nguyen. 2014b. Từ Chuyển đổi Cây cú pháp đến Phân tích Phụ thuộc Tự động cho Tiếng Việt. Trong Kỷ yếu của NLDB, trang 196–207.

Đạt Quốc Nguyễn, Đại Quốc Nguyễn, Thanh Vũ, Mark Dras, và Mark Johnson. 2018. Một Bộ Phân Tách Từ Tiếng Việt Nhanh và Chính Xác. Trong Kỷ Yếu Hội Nghị LREC, trang 2582–2587.

Đạt Quốc Nguyễn và Karin Verspoor. 2018. Một mô hình mạng nơ-ron được cải thiện cho việc gán nhãn từ loại và phân tích phụ thuộc đồng thời. Trong Kỷ yếu Hội nghị CoNLL 2018 Shared Task, trang 81–91.

Đạt Quốc Nguyễn, Thành Vũ, Đại Quốc Nguyễn, Mark Dras, và Mark Johnson. 2017. Từ phân đoạn từ đến gán nhãn từ loại cho tiếng Việt. Trong Kỷ yếu ALTA, trang 108–113.

Huyền Nguyễn, Quyên Ngô, Lượng Vũ, Vũ Trần, và Hiền Nguyễn. 2019a. Nhiệm vụ chia sẻ VLSP: Nhận dạng thực thể có tên. Tạp chí Khoa học Máy tính và An ninh mạng, 34(4):283–294.

Kim Anh Nguyễn, Ngân Đông, và Cẩm-Tú Nguyễn. 2019b. Mạng Nơ-ron Chú Ý cho Nhận Diện Thực Thể Có Tên trong Tiếng Việt. Trong Kỷ yếu Hội nghị RIVF.

Myle Ott, Sergey Edunov, Alexei Baevski, Angela Fan, Sam Gross, Nathan Ng, David Grangier, và Michael Auli. 2019. fairseq: Một Bộ Công Cụ Nhanh, Mở Rộng Cho Mô Hình Hóa Chuỗi. Trong Kỷ yếu của NAACL-HLT 2019: Trình Diễn, trang 48–53.

Rico Sennrich, Barry Haddow, and Alexandra Birch. 2016. Neural Machine Translation of Rare Words with Subword Units. In *Proceedings of ACL*, pages 1715–1725.

Dinh Quang Thang, Le Hong Phuong, Nguyen Thi Minh Huyen, Nguyen Cam Tu, Mathias Rossignol, and Vu Xuan Luong. 2008. Word segmentation of Vietnamese texts: a comparison of approaches. In *Proceedings of LREC*, pages 1933–1936.

Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. 2017. Attention is All you Need. In *Advances in Neural Information Processing Systems 30*, pages 5998–6008.

Wietse de Vries, Andreas van Cranenburgh, Arianna Bisazza, Tommaso Caselli, Gertjan van Noord, and Malvina Nissim. 2019. BERTje: A Dutch BERT Model. *arXiv preprint*, arXiv:1912.09582.

Thanh Vu, Dat Quoc Nguyen, Dai Quoc Nguyen, Mark Dras, and Mark Johnson. 2018. VnCoreNLP: A Vietnamese Natural Language Processing Toolkit. In *Proceedings of NAACL: Demonstrations*, pages 56–60.

Xuan-Son Vu, Thanh Vu, Son Tran, and Lili Jiang. 2019. ETNLP: A visual-aided systematic approach to select pre-trained embeddings for a downstream task. In *Proceedings of RANLP*, pages 1285–1294.

Adina Williams, Nikita Nangia, and Samuel Bowman. 2018. A Broad-Coverage Challenge Corpus for Sentence Understanding through Inference. In *Proceedings of NAACL*, pages 1112–1122.

Thomas Wolf, Lysandre Debut, Victor Sanh, Julien Chaumond, Clement Delangue, Anthony Moi, Pierric Cistac, Tim Rault, R'emi Louf, Morgan Funtowicz, and Jamie Brew. 2019. HuggingFace's Transformers: State-of-the-art Natural Language Processing. *arXiv preprint*, arXiv:1910.03771.

Shijie Wu and Mark Dredze. 2019. Beto, bentz, becas: The surprising cross-lingual effectiveness of BERT. In *Proceedings of EMNLP-IJCNLP*, pages 833–844.

Rico Sennrich, Barry Haddow, và Alexandra Birch. 2016. Dịch Máy Thần Kinh của Từ Hiếm với Đơn Vị Phân Từ. Trong Kỷ yếu của ACL, trang 1715–1725.

Dinh Quang Thang, Le Hong Phuong, Nguyen Thi Minh Huyen, Nguyen Cam Tu, Mathias Rossignol, và Vu Xuan Luong. 2008. Phân đoạn từ của các văn bản tiếng Việt: một so sánh các phương pháp. Trong Kỷ yếu LREC, các trang 1933–1936.

Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, và Illia Polosukhin. 2017. Attention is All you Need. Trong Advances in Neural Information Processing Systems 30, trang 5998–6008.

Wietse de Vries, Andreas van Cranenburgh, Arianna Bisazza, Tommaso Caselli, Gertjan van Noord, và Malvina Nissim. 2019. BERTje: Một Mô Hình BERT Tiếng Hà Lan. Bản in trước arXiv, arXiv:1912.09582.

Thanh Vu, Dat Quoc Nguyen, Dai Quoc Nguyen, Mark Dras, và Mark Johnson. 2018. VnCoreNLP: Bộ công cụ Xử lý Ngôn ngữ Tự nhiên Tiếng Việt. Trong Kỷ yếu Hội nghị NAACL: Trình diễn, trang 56–60.

Xuan-Son Vu, Thanh Vu, Son Tran, và Lili Jiang. 2019. ETNLP: Một phương pháp hệ thống hỗ trợ trực quan để lựa chọn các biểu diễn nhúng đã được huấn luyện trước cho một nhiệm vụ hạ nguồn. Trong Kỷ yếu của RANLP, trang 1285–1294.

Adina Williams, Nikita Nangia, và Samuel Bowman. 2018. Một bộ câu hỏi thách thức có phạm vi bao quát rộng cho Hiểu câu thông qua Suy luận. Trong Kỷ yếu của NAACL, các trang 1112–1122.

Thomas Wolf, Lysandre Debut, Victor Sanh, Julien Chaumond, Clement Delangue, Anthony Moi, Pierric Cistac, Tim Rault, Rémi Louf, Morgan Funtowicz, và Jamie Brew. 2019. Transformers của HuggingFace: Xử lý Ngôn ngữ Tự nhiên tiên tiến nhất. Bản thảo arXiv, arXiv:1910.03771.

Shijie Wu và Mark Dredze. 2019. Beto, bentz, becas: Hiệu quả liên ngôn ngữ đáng ngạc nhiên của BERT. Trong Kỷ yếu của EMNLP-IJCNLP, trang 833–844.