PhoBERT: Mô hình ngôn ngữ được huấn luyện trước cho tiếng Việt

Đạt Quốc Nguyễn[1] và Anh Tuấn Nguyễn[2],[*1]
VinAI Research, Việt Nam; [2]NVIDIA, Mỹ
v.datnq9@vinai.io, tuananhn@nvidia.com

arXiv:2003.00744v3 [cs.CL] 5 Oct 2020

Tóm tắt

Chúng tôi giới thiệu PhoBERT với hai phiên bản—PhoBERT$_{base}$ và PhoBERT^{large}—là các mô hình ngôn ngữ đơn ngữ lớn đầu tiên được công khai và tiền huấn luyện cho tiếng Việt. Kết quả thí nghiệm cho thấy PhoBERT liên tục vượt trội hơn mô hình đa ngôn ngữ tiền huấn luyện mới nhất XLM-R (Conneau và cộng sự, 2020) và cải thiện trạng thái nghệ thuật trong nhiều nhiệm vụ NLP đặc thù tiếng Việt bao gồm gán nhãn từ loại, phân tích quan hệ phụ thuộc, nhận dạng thực thể có tên và suy luận ngôn ngữ tự nhiên. Chúng tôi phát hành PhoBERT để tạo điều kiện cho nghiên cứu trong tương lai và các ứng dụng hạ tầng cho NLP tiếng Việt. Các mô hình PhoBERT của chúng tôi có sẵn tại: https://github.com/VinAIResearch/PhoBERT.

1 Giới thiệu

Các mô hình ngôn ngữ được tiền huấn luyện, đặc biệt là BERT (Devlin et al., 2019)—Mô hình Biểu diễn Mã hóa Hai chiều từ Transformers (Vaswani et al., 2017), gần đây đã trở nên cực kỳ phổ biến và giúp tạo ra những cải thiện đáng kể cho các nhiệm vụ NLP khác nhau. Sự thành công của BERT được tiền huấn luyện và các biến thể của nó phần lớn chỉ giới hạn ở ngôn ngữ tiếng Anh. Đối với các ngôn ngữ khác, người ta có thể huấn luyện lại một mô hình ngôn ngữ cụ thể bằng cách sử dụng kiến trúc BERT (Cui et al., 2019; de Vries et al., 2019; Vu et al., 2019; Martin et al., 2020) hoặc sử dụng các mô hình dựa trên BERT đa ngôn ngữ đã được tiền huấn luyện sẵn (Devlin et al., 2019; Conneau và Lample, 2019; Conneau et al., 2020).

Về mô hình ngôn ngữ tiếng Việt, theo như chúng tôi biết, có hai mối quan tâm chính như sau:

• Tập dữ liệu Wikipedia tiếng Việt là dữ liệu duy nhất được sử dụng để huấn luyện các mô hình ngôn ngữ đơn ngữ (Vu et al., 2019), và nó cũng là tập dữ liệu tiếng Việt duy nhất được bao gồm trong dữ liệu tiền huấn luyện được sử dụng bởi tất cả các mô hình ngôn ngữ đa ngôn ngữ các mô hình ngoại trừ XLM-R. Cần lưu ý rằng dữ liệu Wikipedia không đại diện cho việc sử dụng ngôn ngữ chung, và dữ liệu Wikipedia tiếng Việt tương đối nhỏ (1GB chưa nén), t rong khi các mô hình ngôn ngữ được huấn luyện trước có thể được cải thiện đáng kể bằng cách sử dụng nhiều dữ liệu huấn luyện trước hơn (Liu et al., 2019).

•Tất cả các mô hình ngôn ngữ dựa trên BERT đơn ngữ và đa ngữ được phát hành công khai đều không nhận biết được sự khác biệt giữa â m tiết tiếng Việt và các từ. Sự mơ hồ này xuất phát từ thực tế rằng khoảng trắng cũng được sử dụng để tách các âm tiết tạo thành từ khi viết bằng tiếng Việt.[1] Ví dụ, một văn bản viết gồm 6 âm tiết "Tôi là một nghiên cứu viên" (I am a researcher) tạo thành 4 từ "TôiI làam mộta nghiên_cứu_viênresearcher".

Nếu không thực hiện bước tiền xử lý phân tách từ tiếng Việt, những mô hình này sẽ trực tiếp áp dụng các phương pháp mã hóa Byte-Pair (BPE) (Sennrich và cộng sự, 2016; Kudo và Richardson, 2018) cho dữ liệu tiền huấn luyện tiếng Việt ở cấp độ âm tiết. Một cách trực quan, đối với các tác vụ NLP tiếng Việt ở cấp độ từ, những mô hình được tiền huấn luyện trê n dữ liệu cấp độ âm tiết có thể không hoạt động tốt bằng các mô hình ngôn ngữ được tiền huấn luyện trên dữ liệu cấp độ từ.

Để xử lý hai vấn đề nêu trên, chúng tôi đào tạo các mô hình BERT đơn ngữ quy mô lớn 'cơ bản' và 'lớn' đầu tiên sử dụng một kho từ vựng tiếng Việt 20GB ở cấp độ từ. Chúng tôi đánh giá các mô hình của mình trên bốn nhiệm vụ NLP tiếng Việt hạ nguồn: các nhiệm vụ phổ biến ở cấp độ từ là Gắn nhãn từ loại (POS), Phân tích phụ thuộc và Nhận dạng thực thể đặt tên

[*] Công việc thực hiện trong thời gian thực tập tại VinAI Research.

[1] Thang và cộng sự (2008) chỉ ra rằng 85% các loại từ trong tiếng Việt được tạo thành từ ít nhất hai âm tiết. [2] Mặc dù thực hiện phân tách từ trước khi áp dụng BPE trên nguồn dữ liệu Wikipedia tiếng Việt, ETNLP (Vu và cộng sự, 2019) thực tế không công khai phát hành bất kỳ mô hình ngôn ngữ dựa trên BERT nào đã được huấn luyện trước (https://github.com/vietnlp/etnlp). Cụ thể, Vu và cộng sự (2019) phát hành một tập hợp 15 nghìn embeddings từ dựa trên BERT, chỉ chuyên biệt cho nhiệm vụ NER tiếng Việt.

tion (NER), và một nhiệm vụ hiểu ngôn ngữ của s uy luận ngôn ngữ tự nhiên (NLI) có thể được hình thành như một nhiệm vụ ở mức âm tiết hoặc từ. Kết quả thực nghiệm cho thấy các mô hình của chúng tôi đạt được kết quả tiên tiến nhất (SOTA) trên tất cả các nhiệm vụ này. Những đóng góp của chúng tôi được tóm tắt như sau:

• Chúng tôi giới thiệu các mô hình ngôn ngữ đơn ngữ quy mô lớn đầu tiên được tiền huấn luyện cho tiếng Việt.

• Các mô hình của chúng tôi giúp đạt được hiệu suất SOTA trên bốn tác vụ hạ nguồn gồm gán nhãn từ loại (POS tagging), phân tích phụ thuộc (Dependency parsing), nhận dạng thực thể có tên (NER) và suy luận ngôn ngữ tự nhiên (NLI), qua đó cho thấy hiệu quả của các mô hình ngôn ngữ đơn ngữ dựa trên BERT quy mô lớn đối với tiếng Việt.

Theo hiểu biết tốt nhất của chúng tôi, chúng tôi cũng thực hiện bộ thí nghiệm đầu tiên để so sánh các mô hình ngôn ngữ đơn với mô hình đa ngôn ngữ tốt nhất gần đây XLM-R trong nhiều (tức là bốn) nhiệm vụ cụ thể theo ngôn ngữ khác nhau. Các thí nghiệm cho thấy các mô hình của chúng tôi vượt trội hơn XLM-R trên tất cả các nhiệm vụ này, từ đó một cách thuyết phục xác nhận rằng các mô hình chuyên biệt theo ngôn ngữ vẫn vượt trội hơn các mô hình đa ngôn ngữ.

• Chúng tôi công khai phát hành các mô hình của mình dưới tên PhoBERT, có thể được sử dụng với `fairseq`(Ott et al., 2019) và `transformers` (Wolf et al., 2019). Chúng tôi hy vọng PhoBERT có thể trở thành một chuẩn mực mạnh mẽ cho nghiên cứu và ứng dụng NLP tiếng Việt trong tương lai.

2 PhoBERT

Phần này phác thảo kiến trúc và mô tả dữ liệu tiền huấn luyện cũng như thiết lập tối ưu hóa mà chúng tôi sử dụng cho PhoBERT.

Kiến trúc: PhoBERT của chúng tôi có hai phiên bản, $\text{PhoBERT}_{\text{base}}$ và $\text{PhoBERT}^{\text{large}}$, sử dụng cùng kiến trúc của $\text{BERT}_{\text{base}}$ và $\text{BERT}^{\text{large}}$, tương ứng. Phương pháp tiền huấn luyện của PhoBERT d ựa trên RoBERTa (Liu et al., 2019) nhằm tối ưu hóa quy trình tiền huấn luyện của BERT để đạt hiệu suất mạnh mẽ hơn.

Dữ liệu tiền huấn luyện: Để xử lý mối quan tâ m đầu tiên được đề cập trong Mục 1, chúng tôi sử dụng một bộ dữ liệu tiền huấn luyện 20GB các văn bản không nén. Bộ dữ liệu này là sự kết hợp của hai tập hợp văn bản: (i) tập đầu tiên là tập hợp Wikipedia tiếng Việt (∼1GB), và (ii) tập văn bản thứ hai (∼19GB) được tạo ra bằng cách loại bỏ các bài viết tương tự và trùng lặp từ một tập hợp tin tức tiếng Việt 50GB. [3] Để

[3] https://github.com/binhvq/news-corpus, được thu thập từ nhiều trang web tin tức và chủ đề khác nhau.

Task	#đào_tạo	#hợp lệ	#thử
Gắn nhãn từ loại†	27.000	870	Hai nghìn một trăm hai mươi
Phân tích cú pháp phụ thuộc†	Tám nghìn chín trăm bảy mươi bảy	200	Một nghìn hai mươi
NER†	14.861	Hai nghìn	Hai nghìn tám trăm ba mươi một
NLI‡	392.702	Hai nghìn bốn trăm chín mươi	Năm nghìn mười

Bảng 1: Thống kê các bộ dữ liệu của nhiệm vụ hạ nguồn. “#training”, “#valid” và “#test” lần lượt chỉ kích thước của tập huấn luyện, tập xác thực và tập kiểm tra. † và ‡ lần lượt chỉ kích thước bộ dữ liệu theo số lượng câu và cặp câu.

Để giải quyết mối quan tâm thứ hai, chúng tôi sử dụng RDRSegmenter (Nguyen et al., 2018) từ VnCoreNLP (Vu et al., 2018) để thực hiện phân tách từ và câu trên bộ dữ liệu tiền huấn luyện, dẫn đến ∼145 triệu câu đã phân tách từ (∼3 tỷ từ). Khác với RoBERTa, chúng tôi sau đó áp dụng `fastBPE` (Sennrich et al., 2016) để phân tách các câu này thành các đơn vị phụ từ, sử dụng từ vựng gồm 64 nghìn loại đơn vị phụ từ. Trung bình có 24,4 token phụ từ mỗi câu.

Tối ưu hóa: Chúng tôi sử dụng cài đặt RoBERTa trong `fairseq` (Ott et al., 2019). Chúng tôi đặt độ dài tối đa là 256 token con, do đó tạo ra 145 M $\times$ 24.4 / 256 $\approx$ 13.8M khối câu. Theo Liu et al. (2019), chúng tôi tối ưu hóa các mô hình bằng Adam (Kingma và Ba, 2014). Chúng tôi sử dụng kích thước batch là 1024 trên 4 GPU V100 (mỗi GPU 16GB) và tốc độ học tối đa là 0.0004 cho $\text{PhoBERT}_{\text{base}}$, và kích thước batch là 512 và tốc độ học tối đa là 0.0002 cho $\text{PhoBERT}^{\text{large}}$. Chúng tôi chạy trong 40 epoch (ở đây, tốc độ học được làm nóng trong 2 epoch), dẫn đến 13.8M $\times$ 40/ 1024 $\approx$ 540K bước huấn luyện cho $\text{PhoBERT}_{\text{base}}$ và 1.08M bước huấn luyện cho $\text{PhoBERT}^{\text{large}}$. Chúng tôi tiền huấn luyện $\text{PhoBERT}_{\text{base}}$ trong 3 tuần, và sau đó $\text{PhoBERT}^{\text{large}}$ trong 5 tuần.

3 Thiết lập thí nghiệm

Chúng tôi đánh giá hiệu suất của PhoBERT trên bốn nhiệm vụ xử lý ngôn ngữ tự nhiên tiếng Việt: gán nhãn từ loại (POS tagging), phân tích phụ thuộc (Dependency parsing), nhận dạng thực thể đặt tên (NER) và suy luận ngôn ngữ tự nhiên (NLI).

Bộ dữ liệu cho tác vụ hạ nguồn

Bảng 1 trình bày số liệu thống kê của các bộ dữ li ệu thí nghiệm mà chúng tôi sử dụng để đánh giá các tác vụ hạ nguồn. Đối với gán nhãn POS, phân tích phụ thuộc và NER, chúng tôi tuân theo thiết l ập VnCoreNLP (Vu et al., 2018), sử dụng các chuẩn đánh giá tiêu chuẩn của bộ dữ liệu gán nhãn POS VLSP 2013, [4] bộ dữ liệu phụ thuộc VnDT

[4] https://vlsp.org.vn/vlsp2013/eval

Gắn nhãn từ loại (cấp từ)		**Phân tích phụ thuộc (cấp từ)**	
Mô hình	Acc.	Mô hình	LAS / UAS
RDRPOSTagger (Nguyen và cộng sự, 2014a) [♣]	95.1	–	–
BiLSTM-CNN-CRF (Ma và Hovy, 2016) [♣]	95.4	VnCoreNLP-DEP (Vu và cộng sự, 2018) [★]	71,38 / 77,35
VnCoreNLP-POS (Nguyen và cộng sự, 2017) [♣]	95.9	jPTDP-v2 [★]	73,12 / 79,63
jPTDP-v2 (Nguyen và Verspoor, 2018) [★]	95.7	jointWPD [★]	73,90 / 80,12
jointWPD (Nguyen, 2019) [★]	96.0	Biaffine (Dozat và Manning, 2017) [★]	74,99 / 81,19
$XLM\text{-}R_{base}$ (kết quả của chúng tôi)	96.2	Biaffine với $XLM\text{-}R_{base}$ (kết quả của chúng tôi)	76,46 / 83,10
$XLM\text{-}R^{large}$ (kết quả của chúng tôi)	96.3	Biaffine với $XLM\text{-}R^{large}$ (kết quả của chúng tôi)	75,87 / 82,70
$PhoBERT_{base}$	96.7	Biaffine với $PhoBERT_{base}$	**78,77 / 85,22**
$PhoBERT^{large}$	**96.8**	Biaffine với $PhoBERT^{large}$	77,85 / 84,32

Bảng 2: Điểm hiệu suất (tính theo %) trên các bộ dữ liệu kiểm tra gán nhãn POS và phân tích phụ thuộc. “Acc.”, “LAS” và “UAS” lần lượt là viết tắt của Độ Chính Xác, Điểm Gắn Nhãn (Labeled Attachment Score) và Điểm Gắn Nhãn Không Nhãn (Unlabeled Attachment Score) (ở đây, tất cả các chỉ số đánh giá này được tính trên tất cả các từ, bao gồm cả dấu câu). [♣] và [★] lần lượt chỉ kết quả được báo cáo bởi Nguyen et al. (2017) và Nguyen (2019).

treebank v1.1 (Nguyễn và cộng sự, 2014b) với các nhãn POS được dự đoán bởi VnCoreNLP và bộ dữ liệu NER VLSP 2016 (Nguyễn và cộng sự, 2019a).

Đối với NLI, chúng tôi sử dụng các tập xác th ực và kiểm tra tiếng Việt được xây dựng thủ công từ tập hợp dữ liệu NLI đa ngôn ngữ (XNLI) phiên bản 1.0 (Conneau et al., 2018), trong đó tập huấn luyện tiếng Việt được phát hành dưới dạng phiên bản dịch máy của tập huấn luyện tiếng Anh tương ứng (Williams et al., 2018). Khác với các tập dữ liệu gán nhãn POS, phân tích Dependency và NER cung cấp phân tách từ chuẩn, đối với NLI, chúng tôi sử dụng RDRSegmenter để phân tách văn bản thành các từ trước khi áp dụng BPE để tạo các tiểu từ từ các token từ.

Tinh chỉnh

Theo Devlin và cộng sự (2019), đối với gán nhãn POS và NER, chúng tôi thêm một lớp dự đoán t uyến tính lên trên kiến trúc PhoBERT (tức là trên lớp Transformer cuối cùng của PhoBERT) liên quan đến phân từ con đầu tiên của mỗi từ.Đối với phân tích phụ thuộc, theo Nguyen (2019), chúng tôi sử dụng một cài đặt lại bộ phân tích phụ thuộc Biaffine tiên tiến nhất (Dozat và Manning, 2017) từ Ma và cộng sự (2018) với các siêu tham số tối ưu mặc định. Sau đó, chúng tôi mở rộng bộ phân tích này bằng cách thay thế embedding từ được huấn luyện sẵn của mỗi từ trong câu đầu vào bằng embedding có ngữ cảnh tương ứng (từ lớp cuối cùng) được tính cho phân từ con đầu tiên của từ đó.

Đối với gán nhãn POS, NER và NLI, chúng tôi sử dụng `transformers` (Wolf và cộng sự, 2019) để tinh chỉnh PhoBERT cho từng nhiệm vụ và từng tập dữ liệu một cách độc lập. Chúng tôi sử dụng AdamW (Loshchilov và Hutter, 2019) với một tốc độ học cố định là 1.e-5 và kích thước lô là 32 (Liu et al., 2019). Chúng tôi tinh c hỉnh trong 30 epoch huấn luyện, đánh giá hiệu s uất nhiệm vụ sau mỗi epoch trên tập kiểm định (ở đây, áp dụng dừng sớm khi không có cải thiện sau 5 epoch liên tiếp), và sau đó chọn điểm kiểm tra mô hình tốt nhất để báo cáo kết quả cuối cùng trên tập kiểm tra (lưu ý rằng mỗi điểm số của chúng tôi là trung bình của 5 lần chạy với các hạt giống ngẫu nhiên khác nhau).

4 Kết quả thí nghiệm

Kết quả chính

Bảng 2 và 3 so sánh điểm số PhoBERT với các kết quả cao nhất đã được báo cáo trước đó, sử dụng cùng một thiết lập thí nghiệm. Rõ ràng là PhoBERT của chúng tôi giúp tạo ra các kết quả hiệu suất SOTA mới cho tất cả bốn nhiệm vụ hạ nguồn.

Đối với việc gán nhãn từ loại (POStagging), mô hình neural jointWPD cho việc gán nhãn từ loại và phân tích phụ thuộc đồng thời (Nguyen, 2019) và mô hình dựa trên đặc trưng VnCoreNLP-POS (Nguyen et al., 2017) là hai mô hình SOTA trước đó, đạt độ chính xác khoảng 96,0%. PhoBERT đạt độ chính xác cao hơn tuyệt đối 0,8% so với hai mô hình này.

Đối với phân tích phụ thuộc, các điểm phân tích cao nhất trước đây LAS và UAS được đạt được bởi bộ phân tích Biaffine lần lượt là 75,0% và 81,2%. PhoBERT giúp tăng cường bộ phân tích Biaffine với khoảng 4% cải thiện tuyệt đối, đạt LAS ở mức 78,8% và UAS ở mức 85,2%.

Đối với NER, $PhoBERT^{large}$ cho điểm F_1 cao hơn 1,1 điểm so với $PhoBERT_{base}$. Ngoài ra, $PhoBERT_{base}$ đạt 2+ điểm cao hơn so với các mô hình dựa trên đặc trưng và mạng nơ-ron SOTA trước đó là VnCoreNLP-NER (Vu et al., 2018) và BiLSTM-CNN-CRF (Ma và Hovy, 2016) vốn

Trong các thí nghiệm sơ bộ của chúng tôi, việc sử dụng trung bình của các embedding ngữ cảnh hóa của các token phụ của mỗi từ để đại diện cho từ đó cho hiệu suất hơi thấp hơn so với việc sử dụng embedding ngữ cảnh hóa của token phụ đầu tiên.

NER (cấp từ)		NLI (cấp độ âm tiết hoặc từ)	
Mô hình	F_1	Mô hình	Acc.
BiLSTM-CNN-CRF [♦]	88.3	–	–
VnCoreNLP-NER (Vu et al., 2018) [♦]	88.6	BiLSTM-max (Conneau và cộng sự, 2018)	66.4
VNER (Nguyen và cộng sự, 2019b)	89.6	mBiLSTM (Artetxe và Schwenk, 2019)	72.0
BiLSTM-CNN-CRF + ETNLP [♠]	91.1	BERT đa ngôn ngữ (Devlin và cộng sự, 2019) [■]	69.5
VnCoreNLP-NER +ETNLP [♠]	91.3	$XLM_{MLM+TLM}$ (Conneau và Lample, 2019)	76,6
$XLM\text{-}R_{base}$ (kết quả của chúng tôi)	92.0	$XLM\text{-}R_{base}$ (Conneau và cộng sự, 2020)	75.4
$XLM\text{-}R^{large}$ (kết quả của chúng tôi)	92.8	$XLM\text{-}R^{large}$ (Conneau và cộng sự, 2020)	79.7
$PhoBERT_{base}$	93.6	$PhoBERT_{base}$	78.5
$PhoBERT^{large}$	**94.7**	$PhoBERT^{large}$	**80.0**

Bảng 3: Điểm hiệu suất (tính theo %) trên các bộ kiểm tra NER và NLI. [♦], [♠] và [■] lần lượt chỉ ra kết quả được báo cáo bởi Vu et al. (2018), Vu et al. (2019) và Wu and Dredze (2019). Lưu ý rằng có những kết quả NLI tiếng Việt cao hơn được báo cáo cho XLM-R khi tinh chỉnh trên tập hợp nối tất cả 15 bộ dữ liệu huấn luyện từ tập XNLI (tức là TRANSLATE-TRAIN-ALL: 79,5% cho $XLM\text{-}R_{base}$ và 83,4% $XLM\text{-}R^{large}$). Tuy nhiên, những kết quả đó có thể không so sánh được vì chúng tôi chỉ sử dụng dữ liệu huấn luyện tiếng Việt đơn ngữ để tinh chỉnh.

được huấn luyện với tập hợp 15K từ nhúng BERT dựa trên ETNLP (Vụ et al., 2019).

Đối với NLI, PhoBERT vượt trội hơn BERT đa ngôn ngữ (Devlin et al., 2019) và mô hình đa ngôn ngữ dựa trên BERT với mục tiêu mô hình hóa ngôn ngữ dịch mới $XLM_{MLM+TLM}$(Conneau và Lample, 2019) với khoảng cách lớn. PhoBERT cũng hoạt động tốt hơn so với mô hình đa ngôn ngữ được huấn luyện trước tốt nhất gần đây XLM-R nhưng sử dụng ít tham số hơn nhiều so với XLM-R: 135M ($PhoBERT_{base}$) so với 250M ($XLM\text{-}R_{base}$); 370M ($PhoBERT^{large}$) so với 560M ($XLM\text{-}R^{large}$).

Thảo luận

Chúng tôi nhận thấy rằng $PhoBERT^{large}$ đạt điểm phân tích phụ thuộc thấp hơn 0,9% so với $PhoBERT_{base}$. Một lý do có thể là lớp Transformer cuối cùng trong kiến trúc BERT có thể không phải là lớp tối ưu chứa nhiều thông tin nhất về cấu trúc cú pháp (Hewitt và Manning, 2019; Jawahar et al., 2019). Công việc tương lai sẽ nghiên cứu lớp Transformer nào của PhoBERT chứa nhiều thông tin cú pháp hơn bằng cách đánh giá hiệu suất phân tích ngôn ngữ Việt Nam từ từng lớp.

Sử dụng nhiều dữ liệu tiền huấn luyện hơn có thể cải thiện đáng kể chất lượng của các mô hình ngôn ngữ đã được tiền huấn luyện (Liu và cộng sự, 2019). Do đó, không ngạc nhiên khi PhoBERT giúp tạo ra hiệu suất tốt hơn so với ETNLP trên NER, và BERT đa ngôn ngữ và $XLM_{MLM+TLM}$ trên NLI (ở đây, PhoBERT sử dụng 20GB văn bản tiếng Việt trong khi các mô hình đó sử dụng kho Wikipedia tiếng Việt 1GB).

Theo phương pháp tinh chỉnh mà chúng tôi sử dụng cho PhoBERT, chúng tôi cẩn thận tinh chỉnh XLM-R cho các nhãn POS còn lại của tiếng Việt, Depen- các nhiệm vụ phân tích cú pháp phụ thuộc và NER (ở đây, nó được áp dụng cho token phụ-âm tiết đầu tiên của âm tiết đầu tiên của mỗi từ).[6] Bảng 2 và 3 cho thấy PhoBERT của chúng tôi cũng làm tốt hơn XLM-R trên ba nhiệm vụ cấp từ này. Đáng chú ý là XLM-R sử dụng một tập hợp dữ liệu tiền huấn luyện 2,5TB, trong đó chứa 137GB văn bản tiếng Việt (tức là khoảng $137 / 20 \approx 7$ lần lớn hơn tập dữ liệu tiền huấn luyện của chúng tôi). Hãy nhớ rằng PhoBERT thực hiện phân tách từ tiếng Việt để phân tách các câu cấp âm tiết thành các token từ trước khi áp dụng BPE để phân tách các câu đã phân tách từ thành các đơn vị phụ từ, trong khi XLM-R trực tiếp áp dụng BPE cho các câu tiền huấn luyện cấp âm tiết tiếng Việt. Điều này xác nhận lại rằng các mô hình chuyên biệt cho từng ngôn ngữ vẫn vượt trội hơn các mô hình đa ngôn ngữ (Martin et al., 2020).[7]

5 Kết luận

Trong bài báo này, chúng tôi đã trình bày các mô hình ngôn ngữ PhoBERT đơn ngữ quy mô lớn đầu tiên được tiền huấn luyện cho tiếng Việt. Chúng tôi chứng minh tính hữu ích của PhoBERT bằng cách cho thấy PhoBERT hoạt động tốt hơn mô hình đa ngôn ngữ mới nhất XLM-R và giúp đạt được hiệu suất SOTA cho bốn nhiệm vụ NLP tiếng Việt hạ nguồn gồm gán nhãn từ loại (POS tagging), phân tích phụ thuộc (Dependency parsing), nhận dạng thực thể đặt tên (NER) và suy luận ngôn ngữ tự nhiên (NLI). Bằng cách công khai phát hành các mô hình PhoBERT, chúng tôi hy vọng rằng chúng có thể thúc đẩy nghiên cứu và ứng dụng trong NLP tiếng Việt trong tương lai.

[6] Đối với việc tinh chỉnh XLM-R, chúng tôi sử dụng tìm kiếm lưới trên tập xác thực để chọn tốc độ học AdamW từ {5 6, 1 5, 2 5, 4 5 16, 32 e- e- e- e- } và kích thước lô từ { }. [7] Lưu ý rằng Martin và cộng sự (2020) chỉ so sánh mô hình CamemBERT của họ với XLM-R trên nhiệm vụ NLI tiếng Pháp.

Tài liệu tham khảo

Mikel Artetxe và Holger Schwenk. 2019. Nhúng Câu Đa Ngôn Ngữ Quy Mô Lớn cho Chuyển Giao Liên Ngôn Ngữ Zero-Shot và Hơn Nữa. TACL, 7:597–610.

Alexis Conneau, Kartikay Khandelwal, Naman Goyal, Vishrav Chaudhary, Guillaume Wenzek, Francisco Guzmán, Edouard Grave, Myle Ott, Luke Zettelmoyer và Veselin Stoyanov. 2020. Học Biểu Diễn Đa Ngôn Ngữ Không Giám Sát ở Quy Mô Lớn. Trong Kỷ yếu của ACL, các trang 8440–8451.

Alexis Conneau và Guillaume Lample. 2019. Huấn luyện trước Mô hình Ngôn ngữ Đa ngôn ngữ. Trong Kỷ yếu của NeurIPS, trang 7059–7069.

Alexis Conneau, Ruty Rinott, Guillaume Lample, Holger Schwenk, Ves Stoyanov, Adina Williams, và Samuel R. Bowman. 2018. XNLI: Đánh giá các đại diện câu đa ngôn ngữ. Trong Kỷ yếu của EMNLP, trang 2475–2485.

Yiming Cui, Wanxiang Che, Ting Liu, Bing Qin, Ziqing Yang, Shijin Wang, và Guoping Hu. 2019. Tiền huấn luyện với việc che toàn bộ từ cho BERT tiếng Trung. arXiv preprint, arXiv:1906.08101.

Jacob Devlin, Ming-Wei Chang, Kenton Lee, và Kristina Toutanova. 2019. BERT: Huấn luyện trước các bộ biến đổi hai chiều sâu cho hiểu biết ngôn ng ữ. Trong Kỷ yếu của NAACL, trang 4171–4186.

Timothy Dozat và Christopher D. Manning. 2017. Chú ý Biaffine Sâu cho Phân tích Phụ thuộc Thần kinh. Trong Kỷ yếu của ICLR.

John Hewitt và Christopher D. Manning. 2019. Một công cụ thăm dò cấu trúc để tìm cú pháp trong các biểu diễn từ. Trong Kỷ yếu của NAACL, trang 4129–4138.

Ganesh Jawahar, Benoît Sagot, và Djamé Seddah. 2019. BERT học được gì về cấu trúc của ngôn ngữ? Trong Kỷ yếu của ACL, trang 3651–3657.

Diederik P. Kingma và Jimmy Ba. 2014. Adam: Một Phương Pháp Tối Ưu Ngẫu Nhiên. Bản in trước trên arXiv, arXiv:1412.6980.

Taku Kudo và John Richardson. 2018. Sentence-Piece: Một bộ phân tách và gỡ tách từ con đơn giản và độc lập ngôn ngữ cho Xử lý Văn bản Bằng Mạng Nơ-ron. Trong Kỷ yếu của EMNLP: Trình diễn Hệ thống, trang 66–71.

Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, và Veselin Stoyanov. 2019. RoBERTa: Một Phương Pháp Huấn Luyện BERT Được Tối Ưu Hóa Mạnh Mẽ. Bản thảo arXiv, arXiv:1907.11692.

Ilya Loshchilov và Frank Hutter. 2019. Chuẩn hóa Tăng cường Trọng số Tách rời. Trong Kỷ yếu của ICLR. Xuezhe Ma và Eduard Hovy. 2016. Gán nhãn tuần tự đầu-cuối thông qua LSTM-CNN hai chiều - CRF. Trong Kỷ yếu của ACL, trang 1064–1074. Xuezhe Ma, Zecong Hu, Jingzhou Liu, Nanyun Peng, Graham Neubig, và Eduard Hovy. 2018. Mạng Ngón tay Chồng cho Phân tích Phụ thuộc. Trong Kỷ yếu của ACL, trang 1403–1414.

Louis Martin, Benjamin Muller, Pedro Javier Ortiz Suárez, Yoann Dupont, Laurent Romary, Éric Ville-monte de la Clergerie, Djamé Seddah, và Benoît Sagot. 2020. CamemBERT: Một Mô Hình Ngôn Ngữ Tiếng Pháp Ngon Lành. Trong Kỷ yếu của ACL, trang 7203–7219.

Dat Quoc Nguyen. 2019. Một mô hình kết hợp thần kinh cho phân đoạn từ, gán nhãn từ loại và phân tí ch phụ thuộc tiếng Việt. Trong Kỷ yếu của ALTA, trang 28–34.

Đạt Quốc Nguyễn, Đại Quốc Nguyễn, Đăng Đức Phạm, và Sơn Bảo Phạm. 2014a. RDRPOSTagger: Bộ gán nhãn từ loại dựa trên quy tắc Ripple Down. Trong Kỷ yếu các Bài trình diễn tại EACL, trang 17–20.

Dat Quoc Nguyen, Dai Quoc Nguyen, Son Bao Pham, Phuong-Thai Nguyen, và Minh Le Nguyen. 2014b. Từ Chuyển đổi Cây cú pháp đến Phân tích Phụ thuộc Tự động cho Tiếng Việt. Trong Kỷ yếu của NLDB, trang 196–207.

Đạt Quốc Nguyễn, Đại Quốc Nguyễn, Thanh Vũ, Mark Dras, và Mark Johnson. 2018. Một Bộ Phân Tách Từ Tiếng Việt Nhanh và Chính Xác. Trong Kỷ Yếu Hội Nghị LREC, trang 2582–2587.

Đạt Quốc Nguyễn và Karin Verspoor. 2018. Một mô hình mạng nơ-ron được cải thiện cho việc gán nhãn từ loại và phân tích phụ thuộc đồng thời. Trong Kỷ yếu Hội nghị CoNLL 2018 Shared Task, trang 81–91.

Đạt Quốc Nguyễn, Thành Vũ, Đại Quốc Nguyễn, Mark Dras, và Mark Johnson. 2017. Từ phân đoạn từ đến gán nhãn từ loại cho tiếng Việt. Trong Kỷ yếu ALTA, trang 108–113.

Huyền Nguyễn, Quyên Ngô, Lượng Vũ, Vũ Trần, và Hiền Nguyễn. 2019a. Nhiệm vụ chia sẻ VLSP: Nhận dạng thực thể có tên. Tạp chí Khoa học Máy tính và An ninh mạng, 34(4):283–294.

Kim Anh Nguyễn, Ngân Đông, và Cẩm-Tú Nguyễn. 2019b. Mạng Nơ-ron Chú Ý cho Nhận Diện Thực Thể Có Tên trong Tiếng Việt. Trong Kỷ yếu Hội nghị RIVF.

Myle Ott, Sergey Edunov, Alexei Baevski, Angela Fan, Sam Gross, Nathan Ng, David Grangier, và Michael Auli. 2019. fairseq: Một Bộ Công Cụ Nhanh, Mở Rộng Cho Mô Hình Hóa Chuỗi. Trong Kỷ yếu của NAACL-HLT 2019: Trình Diễn, trang 48–53.

Rico Sennrich, Barry Haddow, và Alexandra Birch. 2016. Dịch Máy Thần Kinh của Từ Hiếm với Đơn Vị Phân Từ. Trong Kỷ yếu của ACL, trang 1715–1725.

Dinh Quang Thang, Le Hong Phuong, Nguyen Thi Minh Huyen, Nguyen Cam Tu, Mathias Rossignol, và Vu Xuan Luong. 2008. Phân đoạn từ của các văn bản tiếng Việt: một so sánh các phương pháp. Trong Kỷ yếu LREC, các trang 1933–1936.

Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, và Illia Polosukhin. 2017. Attention is All you Need. Trong Advances in Neural Information Processing Systems 30, trang 5998–6008.

Wietse de Vries, Andreas van Cranenburgh, Arianna Bisazza, Tommaso Caselli, Gertjan van Noord, và Malvina Nissim. 2019. BERTje: Một Mô Hình BERT Tiếng Hà Lan. Bản in trước arXiv, arXiv:1912.09582.

Thanh Vu, Dat Quoc Nguyen, Dai Quoc Nguyen, Mark Dras, và Mark Johnson. 2018. VnCoreNLP: Bộ công cụ Xử lý Ngôn ngữ Tự nhiên Tiếng Việt. Trong Kỷ yếu Hội nghị NAACL: Trình diễn, trang 56–60.

Xuan-Son Vu, Thanh Vu, Son Tran, và Lili Jiang. 2019. ETNLP: Một phương pháp hệ thống hỗ trợ trực quan để lựa chọn các biểu diễn nhúng đã được huấn luyện trước cho một nhiệm vụ hạ nguồn. Trong Kỷ yếu của RANLP, trang 1285–1294.

Adina Williams, Nikita Nangia, và Samuel Bowman. 2018. Một bộ câu hỏi thách thức có phạm vi bao quát rộng cho Hiểu câu thông qua Suy luận. Trong Kỷ yếu của NAACL, các trang 1112–1122.

Thomas Wolf, Lysandre Debut, Victor Sanh, Julien Chaumond, Clement Delangue, Anthony Moi, Pierric Cistac, Tim Rault, Rémi Louf, Morgan Funtowicz, và Jamie Brew. 2019. Transformers của HuggingFace: Xử lý Ngôn ngữ Tự nhiên tiên tiến nhất. Bản thảo arXiv, arXiv:1910.03771.

Shijie Wu và Mark Dredze. 2019. Beto, bentz, becas: Hiệu quả liên ngôn ngữ đáng ngạc nhiên của BERT. Trong Kỷ yếu của EMNLP-IJCNLP, trang 833–844.