Hallucination Detection in LLM-enriched Product Listings

Ling Jiang, Keer Jiang, Xiaoyu Chu, Saaransh Gulati, Pulkit Garg
Amazon
Sunnyvale, CA, USA
{jiangll, kjiang, xiaoychu, saaransg, pulkitg}@amazon.com

Abstract

E-commerce faces persistent challenges with data quality issue of product listings. Recent advances in Large Language Models (LLMs) offer a promising avenue for automated product listing enrichment. However, LLMs are prone to hallucinations, which we define as the generation of content that is unfaithful to the source input. This poses significant risks in customer-facing applications. Hallucination detection is particularly challenging in the vast e-commerce domain, where billions of products are sold. In this paper, we propose a two-phase approach for detecting hallucinations in LLM-enriched product listings. The first phase prioritizes recall through cost-effective unsupervised techniques. The second phase maximizes precision by leveraging LLMs to validate candidate hallucinations detected in phase one. The first phase significantly reduces the inference space and enables the resource-intensive methods in the second phase to scale effectively. Experiments on two real-world datasets demonstrated that our approach achieved satisfactory recall on unstructured product attributes with suboptimal precision, primarily due to the inherent ambiguity of unstructured attributes and the presence of common sense reasoning. This highlights the necessity for a refined approach to distinguish between common sense and hallucination. On structured attributes with clearly defined hallucinations, our approach effectively detected hallucinations with precision and recall surpassing targeted level.

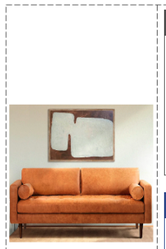
Keywords: large language model, hallucination, e-commerce, product listing enrichment

1. Introduction

In e-commerce, the significance of comprehensive product listings cannot be overstated, as it plays a pivotal role in facilitating informed purchase decisions by customers. However, real-world product listings often suffer from diverse quality issues, such as data incompleteness, information redundancy, and misinformation. These challenges impact customers' shopping experiences. Therefore, product listing enrichment is a critical task in e-commerce to generate compelling product listings.

The product listing enrichment task aims to create concise yet informative product listings given the source product data. Figure 1 illustrates this process. In the initial listing, several essential product attribute values are missing, and the product name contains redundant details. After enrichment, the product name is more succinct and user-friendly, and a correct value was populated for the attribute *Material*. Such enriched listings can help customer reduce cognitive load during product evaluation and improve sales conversion (Purnomo, 2023).

Product listing enrichment involves generating structured data and free text from the source input, which is an essential task in various natural language generation applications, such as summarization (Nenkova et al., 2011) and data-to-text generation (Wiseman et al., 2017). Traditional template-based approaches (Gatt and Reiter, 2009; Reiter et al., 2005) rely on manually crafted rules and lack scalability. Transformers and language models (Vaswani et al., 2017; Devlin et al., 2018;



Source product listing

Name	Leather Couch –Leather Sofa with Tufted Back – Leather Couch with Feather Down Topper On Seating Surfaces – Italian Leather
Material	NA
Color	NA
Size	NA

LLM-enriched product listing

Name	Italian Leather Sofa with Tufted Back and Feather Down Topper
Material	Leather
Color	Black
Size	88.5 Inch

Figure 1: Example of product listing enrichment and hallucination.

Yang et al., 2019; Liu et al., 2019; Radford et al., 2019) have demonstrated exceptional capabilities of generating fluent text. Recently, Large Language Models (LLMs) (Brown et al., 2020; Ouyang et al., 2022; Achiam et al., 2023; Touvron et al., 2023; Chowdhery et al., 2023) have pushed the boundaries of natural language generation to new heights (Bubeck et al., 2023). The remarkable language comprehension of LLMs offers an opportunity for automating the generation and enhancement of product listings (Westmoreland, 2023).

However, a concerning drawback of LLMs is its tendency to hallucinate, when LLMs generate texts that appear fluent and coherent but are nonfactual or unsupported by the input data (Varshney et al.,

The Seventh Workshop on e-Commerce and NLP (ECNLP 7), pages 29–39
21 May, 2024. © 2024 ELRA Language Resource Association: CC BY-NC 4.0

Phát hiện ảo giác trong danh sách sản phẩm được bổ sung bởi LLM

Ling Jiang, Keer Jiang, Xiaoyu Chu, Saaransh Gulati, Pulkit Garg Amazon Sunnyvale, CA, USA {jiangll,kjiang,xiaoychu, saaransg, pulkitg}@amazon.com

Tóm tắt

Thương mại điện tử đối mặt với những thách thức dai dẳng liên quan đến chất lượng dữ liệu của các danh sách sản phẩm. Những tiến bộ gần đây trong Mô hình Ngôn ngữ Lớn (LLMs) mở ra một hướng triển vọng cho việc tự động làm phong phú danh sách sản phẩm. Tuy nhiên, LLMs dễ gặp hiện tượng ảo tưởng, mà chúng tôi định nghĩa là việc tạo ra nội dung không trung thực với dữ liệu gốc. Điều này gây ra rủi ro đáng kể trong các ứng dụng hướng đến khách hàng. Việc phát hiện ảo tưởng đặc biệt khó khăn trong lĩnh vực thương mại điện tử rộng lớn, nơi hàng tỷ sản phẩm được bán ra. Trong bài báo này, chúng tôi đề xuất một phương pháp hai giai đoạn để phát hiện ảo tưởng trong các danh sách sản phẩm được làm phong phú bởi LLM. Giai đoạn đầu ưu tiên độ hồi hồi thông qua các kỹ thuật không giám sát tiết kiệm chi phí. Giai đoạn thứ hai tối đa hóa độ chính xác bằng cách tận dụng LLM để xác thực các ảo tưởng ứng viên được phát hiện trong giai đoạn một. Giai đoạn đầu làm giảm đáng kể không gian suy luận và cho phép các phương pháp tốn tài nguyên trong giai đoạn hai mở rộng hiệu quả. Các thí nghiệm trên hai bộ dữ liệu thực tế

Từ khóa: mô hình ngôn ngữ lớn, ảo giác, thương mại điện tử, bổ sung danh sách sản phẩm

1. Giới thiệu

Trong thương mại điện tử, tầm quan trọng của việc liệt kê sản phẩm một cách toàn diện không thể bị đánh giá thấp, vì nó đóng vai trò then chốt trong việc tạo điều kiện cho khách hàng đưa ra các quyết định mua hàng thông minh. Tuy nhiên, các danh sách sản phẩm trong thực tế thường gặp phải nhiều vấn đề về chất lượng, chẳng hạn như dữ liệu không đầy đủ, thông tin thừa thãi và thông tin sai lệch. Những thách thức này ảnh hưởng đến trải nghiệm mua sắ m của khách hàng. Do đó, việc làm phong phú danh sách sản phẩm là một nhiệm vụ quan trọng trong thương mại điện tử để tạo ra các danh sách sản phẩm hấp dẫn.

Nhiệm vụ làm phong phú danh sách sản phẩm nhằm tạo ra các danh sách sản phẩm ngắn gọn nhưng đầy đủ thông tin dựa trên dữ liệu sản phẩm gốc. Hình 1 minh họa quá trình này. Trong danh sách ban đầu, một số giá trị thuộc tính sản phẩm quan trọng bị thiếu, và t ên sản phẩm chứa các chi tiết dư thừa. Sau khi làm phong phú, tên sản phẩm trở nên ngắn gọn và thân thiện với người dùng hơn, và một giá trị chính xác đã được điền cho thuộc tính Chất liệu. Những danh sách sản phẩm được làm phong phú như vậy có thể giúp khách hàng giảm tải nhận thức khi đánh giá sản phẩm và cải thiện tỷ lệ chuyển đổi bán hàng (Purnomo, 2023).

Gia tăng danh sách sản phẩm liên quan đến việc tạo dữ liệu có cấu trúc và văn bản tự do từ đầu vào nguồn, đây là một nhiệm vụ thiết yếu trong nhiều ứng dụng tạo ngôn ngữ tự nhiên khác nhau, chẳng hạn như tóm tắt (Nenkova et al., 2011) và tạo dữ liệu thành văn bản (Wiseman et al., 2017). Các phương pháp dựa trên mẫu truyền thống (Gatt và Reiter, 2009; Reiter et al., 2005) dựa vào các quy tắc được tạ o thủ công và thiếu khả năng mở rộng. Các mô hình Transformers và ngôn ngữ (Vaswani et al., 2017; Devlin et al., 2018;



Source product listing

Name	Leather Couch –Leather Sofa with Tufted Back – Leather Couch with Feather Down Topper On Seating Surfaces – Italian Leather
Material	NA
Color	NA
Size	NA

LLM-enriched product listing

Name	Italian Leather Sofa with Tufted Back and Feather Down Topper
Material	Leather
Color	Black
Size	88.5 Inch

Hình 1: Ví dụ về việc làm phong phú và tưởng tượng danh sách sản phẩm.

Yang và cộng sự, 2019; Liu và cộng sự, 2019; Radford và cộng sự, 2019) đã chứng minh khả năng xuất sắc trong việc tạo ra văn bản mượt mà. Gần đây, các Mô hình Ngôn ngữ Lớn (LLMs) (Brown và cộng sự, 2020; Ouyang và cộng sự, 2022; Achiam và cộng sự, 2023; Touvron và cộng sự, 2023; Chowdhery và cộng sự, 2023) đã đưa ranh giới của việc tạo ngôn ngữ tự nhiên lên tầm cao mới (Bubeck và cộng sự, 2023). Khả năng hiểu ngôn ngữ đáng chú ý của LLMs mang đến cơ hội tự động hóa việc tạo và nâng cao danh sách sản phẩm (Westmoreland, 2023).

Tuy nhiên, một nhược điểm đáng lo ngại của các LLM là xu hướng ảo giác, khi các LLM tạo ra văn bản có vẻ trôi chảy và mạch lạc nhưng không đúng sự thật hoặc không được hỗ trợ bởi dữ liệu đầu vào (Varshney et al.,

Hội thảo thứ bảy về Thương mại điện tử và Xử lý ngôn ngữ tự nhiên (ECNLP 7), trang 29–39, ngày 21 tháng 5, 2024. © 2024 Hiệp hội Tài nguyên Ngôn ngữ ELRA: CC BY-NC 4.0

2023). In Figure 1, the LLM successfully improved the product *Name* and accurately generated value for *Material*. Conversely, the reliability of the generated values for *Color* and *Size* is questionable when examining the source data alone without additional information. Such hallucinations pose risks by potentially leading to negative user experiences and, more critically, misinformation-induced purchases. In safety-critical scenarios, such as the failure to generate warnings on toy choking hazards, hallucinations may result in legal consequences.

In this work, we address the hallucination problem in LLM-enriched product listings. We define hallucination as the generation of text that is unfaithful to the provided source input (Ji et al., 2023). Some works also consider factual inaccuracies in their definition (Varshney et al., 2023; Zhang et al., 2023). The primary function of product listings is to communicate descriptive details about the items. For example, the value of *Material* is product-specific, inherently contingent upon the source product information. Here, factual accuracy depends on faithfully reflecting the source input for each unique product, assuming the provided product information accurately describes the products. The source input data serves as the definitive reference for truth in this context.

Previous studies have employed the hidden layer activations or logit values of LLMs to detect hallucinated content (Azaria and Mitchell, 2023; Varshney et al., 2023). Yet, such methods require access to the internal states of LLMs, which is typically not available in state-of-the-art black-box LLMs (e.g. ChatGPT). Some have integrated external knowledge bases with LLMs (Guo et al., 2022; Martino et al., 2023; Peng et al., 2023a; Lee et al., 2022), but this introduces additional cost and complexities. Alternatively, LLMs have been used to autonomously verify their outputs (Wang et al., 2023; Manakul et al., 2023) or have been fine-tuned for specific tasks (Cao et al., 2021; Yu et al., 2023), though LLM-based methods can be costly without in-house models. In-house LLMs, while circumventing some expenses, still demand extensive training data and substantial resources for model development.

While akin to detecting hallucinations in summarization (Cao et al., 2021) or data-to-text generation (Tian et al., 2019), our task involves unique challenges due to the mixture of free text and structured data in both source input and generated text. The former is often noisy and poor-formatted, particularly when sourced from third-party sellers in e-commerce. Furthermore, LLM-generated values may be embedded in various product attribute fields, necessitating a comprehensive examination of all product information for potential evidence. Given that an e-commerce website can sell billions of products, addressing hallucination detection at such a scale requires careful consideration of both performance and cost factors.

In this paper, we present an approach for hallucination detection in LLM-enriched product listings without accessing internal LLM states or relying on external data sources. We propose to detect hallucinations in a two-phase fashion, prioritizing recall in the initial phase and enhancing precision in the subsequent phase. The motivation stems from the high cost associated with LLM-only approaches in massive-scale e-commerce applications. In the initial phase, which we call Lexical and Semantic Screening (LSS), we apply cost-effective unsupervised techniques to detect a broad range of hallucinations. While these methods are efficient, their accuracy may be compromised due to limitations in text comprehension. The second phase, LLM validation, utilizes LLMs to confirm potential hallucinations detected in the first phase. Leveraging the robust language understanding capabilities of LLMs, we optimize precision in the second phase. The initial LSS phase significantly reduces the inference space, allowing the more resource-intensive LLM validation to scale effectively. Experiments on two real-world e-commerce datasets demonstrate the effectiveness of our proposed approach. In addition, we discovered that our approach performs better on structured attributes with concise, deterministic values, as opposed to unstructured attributes presented in long-form free text. We identified directions for future work through analysis of the experimental results.

2. Related Work

2.1. Definition of Hallucination

Varshney et al. (2023) defined hallucination as the generation of text or responses that seem syntactically sound, fluent, and natural but are factually incorrect, nonsensical, or unfaithful to the provided source input. This definition aligns with the taxonomy proposed by Zhang et al. (2023). However, studies on hallucination in various natural language generation tasks (Tian et al., 2019; Maynez et al., 2020; Weng et al., 2023) may emphasize distinct aspects of the phenomenon. Consequently, the definition of hallucination may exhibit variability across tasks. In the product listing enrichment task, product listings primarily convey descriptive information about the products, and factual accuracy is contingent on faithfully representing the source input for each individual product. In this sense, our perception of hallucination aligns more closely with Ji et al. (2023)'s definition, which refers to the generation of text that is nonsensical, or unfaithful to the provided source input. It is further categorized into intrinsic and extrinsic hallucination. Intrinsic hallu-

2023). Trong Hình 1, LLM đã cải thiện thành công tê n sản phẩm và tạo ra giá trị chính xác cho vật liệu. Ngược lại, độ tin cậy của các giá trị được tạo ra cho màu sắc và kích thước trở nên nghi ngờ khi chỉ xem xét dữ liệu nguồn mà không có thông tin bổ sung. Những ảo giác như vậy gây rủi ro bằng cách có khả năng dẫn đến trải nghiệm người dùng tiêu cực và, nghiêm trọng hơn, các giao dịch mua bị gây ra do thông tin sai lệch. Trong các tình huống quan trọng liên quan đến an toàn, chẳng hạn như việc không tạo cảnh báo về nguy cơ nghẹt đối với đồ chơi, các ảo giác có thể dẫn đến hậu quả pháp lý.

Trong công trình này, chúng tôi giải quyết vấn đề ảo giác trong các danh sách sản phẩm được cải thiện bằng LLM. Chúng tôi định nghĩa ảo giác là việc tạo ra văn bản không trung thực với đầu vào nguồn được cung cấp (Ji et al., 2023). Một số công trình cũng xem xét các sai sót về thực tế trong định nghĩa của họ (Varshney et al., 2023; Zhang et al., 2023). Chức năng chính của danh sách sản phẩm là truyền đạt các chi tiết mô tả về các mặt hàng. Ví dụ, giá trị của Vật liệu phụ thuộc vào từng sản phẩm cụ thể, vốn dựa vào thông tin sản phẩm nguồn. Ở đây, độ chính xác về thực tế phụ thuộc vào việc phản ánh trung thực đầu vào nguồn cho từng sản phẩm riêng lẻ, với giả định rằng thông tin sản phẩm được cung cấp mô tả chính xác các sản phẩm. Dữ liệu đầu vào nguồn đóng vai trò là tham chiếu cuối cùng về sự thật trong bối cảnh này.

Các nghiên cứu trước đây đã sử dụng các kích hoạt của lớp ẩn hoặc giá trị logit của các LLM để phát hiện nội dung ảo tưởng (Azaria và Mitchell, 2023; Varshney và cộng sự, 2023). Tuy nhiên, các phương pháp này đòi hỏi quyền truy cập vào trạng thái nội bộ của các LLM, điều mà thường không có ở các LLM hiện đại dạng hộp đen (ví dụ: ChatGPT). Một số đã tích hợp cơ sở tri thức bên ngoài với các LLM (Guo và cộng sự, 2022; Martino và cộng sự, 2023; Peng và cộng sự, 2023a; Lee và cộng s ự, 2022), nhưng điều này làm phát sinh thêm chi phí và độ phức tạp. Ngoài ra, các LLM đã được sử dụng để tự động xác thực các đầu ra của chúng (Wang và cộng sự, 2023; Manakul và cộng sự, 2023) hoặc đã được tinh chỉnh cho các nhiệm vụ cụ thể (Cao và cộng sự, 2021; Yu và cộng sự, 2023), mặc dù các phương pháp dựa trên LLM có thể tốn kém nếu không có mô hình nội bộ. Các LLM nội bộ, mặc dù tránh được một số khoản chi phí, vẫn yêu cầu dữ liệu huấn luyện phong phú và nguồn lực đáng kể để phát triển mô hình.

Mặc dù tương tự như việc phát hiện ảo giác t rong tóm tắt (Cao et al., 2021) hoặc tạo dữ liệu thành văn bản (Tian et al., 2019), nhiệm vụ của chúng tôi bao gồm những thách thức độc đáo do sự kết hợp c ủa văn bản tự do và dữ liệu có cấu trúc trong cả đầu vào nguồn và văn bản được tạo ra. Phần đầu tiên thường bị nhiễu và định dạng kém, đặc biệt khi lấy t ừ các nhà bán hàng bên thứ ba trong thương mại điện tử. Hơn nữa, các giá trị do LLM tạo ra có thể được nhúng trong nhiều trường thuộc tính sản phẩ m khác nhau, đòi hỏi phải kiểm tra toàn diện tất cả thông tin sản phẩm để tìm bằng chứng có thể có. Với việc một trang web thương mại điện tử có thể bán hàng tỷ sản phẩm, việc giải quyết phát hiện ảo giác ở Một thang đo như vậy đòi hỏi phải xem xét cẩn thận cả các yếu tố về hiệu suất và chi phí.

Trong bài báo này, chúng tôi trình bày một phương pháp phát hiện ảo giác trong các danh sách sản phẩm được bổ sung bởi LLM mà không cần truy cập vào trạng thái nội bộ của LLM hoặc dựa vào các nguồn dữ liệu bên ngoài. Chúng tôi đề xuất phát hiện ảo giác theo hai giai đoạn, ưu tiên việc thu hồi ở giai đoạn đầu và nâng cao độ chính xác ở giai đoạn sau. Động lực xuất phát từ chi phí cao liên quan đến các phương pháp chỉ sử dụng LLM trong các ứng dụng thương mại điện tử quy mô lớn. Ở giai đoạn đầu, mà chúng tôi gọi là Sàng lọc Ngữ nghĩa và Từ vựng (LSS), chúng tôi áp dụng các kỹ thuật không giám sát, tiết kiệm chi phí để phát hiện một phạm vi rộng các ảo giác. Trong khi các phương pháp này hiệu quả, độ chính xác của chúng có thể bị ảnh hưởng do hạn chế trong khả năng hiểu văn bản. Giai đoạn thứ hai, xác nhận bằng LLM, sử dụng LLM để xác nhận các ảo giác tiềm năng được phát hiện trong giai đoạn đầu. Tận dụng khả năng hiểu ngôn ngữ mạnh mẽ của LLM, chúng tôi tối ưu hóa độ chính xác ở giai đoạn thứ hai. Giai đoạn LSS ban đầu giảm đáng kể sự inf

2. Công trình liên quan

2.1. Định nghĩa về ảo giác

Varshney et al. (2023) định nghĩa ảo giác là việc tạo ra văn bản hoặc các phản hồi có vẻ hợp lý về mặt cú pháp, trôi chảy và tự nhiên nhưng thực tế không chính xác, vô nghĩa hoặc không trung thành với đầu vào nguồn được cung cấp. Định nghĩa này phù hợp với phân loại được đề xuất bởi Zhang et al. (2023). Tuy nhiên, các nghiên cứu về ảo giác trong các nhiệm vụ tạo ngôn ngữ tự nhiên khác nhau (Tian et al., 2019; Maynez et al., 2020; Weng et al., 2023) có t hể nhấn mạnh các khía cạnh khác nhau của hiện tượng này. Do đó, định nghĩa về ảo giác có thể thay đổi theo từng nhiệm vụ. Trong nhiệm vụ làm phong phú danh sách sản phẩm, các danh sách sản phẩm chủ yếu truyền tải thông tin mô tả về sản phẩm, và độ chính xác về mặt thực tế phụ thuộc vào việc đại diện trung thành cho đầu vào nguồn của từng sản phẩm. Theo nghĩa này, nhận thức của chúng tôi về ảo giác phù hợp hơn với định nghĩa của Ji et al. (2023), trong đó chỉ việc tạo ra văn bản vô nghĩa hoặc không trung thành với nguồn được cung cấp

cination involves output contradicting the source, while extrinsic hallucination refers to output unverifiable against the source. We are concerned with both types, encompassing content that either contradicts or lacks support in the source input, emphasizing the unfaithfulness aspect. After we identify unfaithful hallucinations, we need to further determine the factual accuracy to serve the end business goal. However, we focus this work on the faithfulness aspect and leave the factual part for future work.

2.2. Hallucination Detection

Many recent studies have been focused on mitigating hallucinations in LLMs. Depending on the accessibility of LLM models, there are white-box, grey-box and black-box approaches. A white-box method (Azaria and Mitchell, 2023) used the LLM's hidden layer activations to train a classifier that predicts the probability of a statement being true. Grey-box approaches detect the parts of the output sequence that the LLM is least confident about by examining the logit output values in the response (Varshney et al., 2023). Both white-box and grey-box approaches require access to internal states or token probabilities that may not necessarily be available, e.g. when LLMs are accessed through limited API calls. Black-box approaches (Manakul et al., 2023) are suitable for a wider range of applications when only LLMs responses are available.

Approaches for mitigating hallucination can also be grouped into zero-resource and external knowledge based approaches depending on if an external knowledge base is involved. External knowledge based approaches try to mitigate hallucination through information augmentation from external knowledge sources (Guo et al., 2022; Moiseev et al., 2022; Martino et al., 2023; Peng et al., 2023a). However, knowledge augmented approaches usually come with the cost of additional complexity and resource overhead (Lee et al., 2022).

Zero-resource approaches do not rely on external knowledge to detect hallucinated responses. One line of studies leverage unsupervised metrics scores (Celikyilmaz et al., 2020; Forbes et al., 2023) such as ROUGE (Lin, 2004), BLEU (Papineni et al., 2002), and METEOR (Banerjee and Lavie, 2005) to measure the consistency between the generated text and the source text. While these metrics offer simplicity, they frequently fall short in accurately aligning texts. This leads to sub-optimal performance when semantically relevant text diverges from the reference's surface form. Additionally, these metrics struggle to capture distant dependencies and tend to penalize changes in semantic ordering. BERTScore (Zhang et al., 2019) leverages the pre-trained contextual embeddings from BERT (Devlin et al., 2018) and matches words in candidate and reference sentences by cosine similarity. BERTScore has been shown to correlate well with human judgments. Another approach is converting hallucination detection to classification problem (Chen et al., 2023). Recent studies showed that LLMs can be good evaluators themselves (Wang et al., 2023) and many studies leverage LLMs to detect hallucinations (Mündler et al., 2023; Manakul et al., 2023; Weng et al., 2023; Fu et al., 2023). Another way to mitigate hallucination is fine-tuning LLMs on task-specific data (Cao et al., 2021; Yu et al., 2023). Some of these approaches can complement each other. For example, Guan et al. (2023) combined LLM verification, instruction tuning and retrieval augmentation to verify facts for LLMs outputs. LLM-based approaches can entail significant expenses when utilizing commercially available LLMs, especially on large-scale e-commerce applications. Alternatively, the development of proprietary LLMs within an organization introduces a different set of costs.

In this work, we present a method for detecting hallucinations in LLMs-enriched product listings. Our approach utilizes zero-resource black-box hallucination detection techniques, eliminating the need for external knowledge base or access to LLMs' internal states. This independence allows our system to be agnostic of upstream LLMs and be generalizable to a wider range of LLMs applications. Moreover, our method enhances scalability compared to LLM-only approaches by markedly reducing the inference space prior to LLM validation.

3. Methodology

We propose a two-phase approach for hallucination detection (Figure 2), emphasizing recall in the initial phase and enhancing precision in the subsequent phase. In the first phase, termed Lexical and Semantic Screening (LSS), cost-effective unsupervised techniques are applied to detect a broad spectrum of hallucinations. Although these methods are efficient, their performance may be compromised by text comprehension limitations. In the second phase, LLM validation, we utilize LLMs to validate the candidate hallucinations identified in the first phase. We optimize precision in the second phase by leveraging the robust language understanding capabilities of LLMs. Given the critical need for scalability in hallucination detection, particularly in the context of e-commerce with a vast product inventory, the initial LSS phase significantly reduces the inference space. This reduction enables the more resource-intensive approach to scale effectively in the second phase, addressing the challenge of processing billions of products for product listing enrichment in e-commerce. Figure 3 depicts LLM-generated attribute values,

Ảo tưởng nội tại liên quan đến đầu ra mâu thuẫn với nguồn, trong khi ảo tưởng ngoại tại đề cập đến đầu ra không thể xác minh được so với nguồn. Chúng tôi quan tâm đến cả hai loại, bao gồm nội dung hoặc mâu thuẫn hoặc không có cơ sở trong dữ liệu nguồn, nhấn mạnh khía cạnh không trung thực. Sau khi xác định các ảo tưởng không trung thực, chúng ta cần tiếp tục xác định độ chính xác về mặt thực tế để phục vụ mục tiêu kinh doanh cuối cùng. Tuy nhiên, trong công trình này, chúng tôi tập trung vào khía cạnh trung thực và để phần thực tế cho công việc tương lai.

2.2. Phát hiện ảo giác

Nhiều nghiên cứu gần đây đã tập trung vào việc giảm ảo giác trong các mô hình ngôn ngữ lớn (LLM). Tùy thuộc vào khả năng truy cập của các mô hình LLM, có các phương pháp hộp trắng, hộp xám và hộp đen. Một phương pháp hộp trắng (Azaria và Mitchell, 2023) sử dụng các kích hoạt của lớp ẩn của LLM để đào tạo một bộ phân loại dự đoán xác suất một phát biểu là đúng. Các phương pháp hộp xám phát hiện các phần của chuỗi đầu ra mà LLM ít tự ti n nhất bằng cách kiểm tra các giá trị đầu ra logit trong phản hồi (Varshney và cộng sự, 2023). Cả phương pháp hộp trắng và hộp xám đều yêu cầu t ruy cập vào trạng thái nội bộ hoặc xác suất token mà có thể không có sẵn, ví dụ khi LLM được truy cập thông qua các cuộc gọi API giới hạn. Các phương pháp hộp đen (Manakul và cộng sự, 2023) phù hợp với một phạm vi ứng dụng rộng hơn khi chỉ có phản hồi từ LLM.

Các phương pháp giảm ảo giác cũng có thể được phân nhóm thành các phương pháp không sử dụng tài nguyên và dựa trên kiến thức bên ngoài tùy t huộc vào việc có sử dụng cơ sở kiến thức bên ngoài hay không. Các phương pháp dựa trên kiến thức bên ngoài cố gắng giảm ảo giác thông qua việc bổ sung thông tin từ các nguồn kiến thức bên ngoài (Guo et al., 2022; Moiseev et al., 2022; Martino et al., 2023; Peng et al., 2023a). Tuy nhiên, các phương pháp tăng cường kiến thức thường đi kèm với chi phí về sự phức tạp bổ sung và tài nguyên (Lee et al., 2022).

Các phương pháp không sử dụng tài nguyên không dựa vào kiến thức bên ngoài để phát hiện các phản hồi ảo tưởng. Một dòng nghiên cứu tận dụng điểm số các chỉ số không giám sát (Celikyilmaz et al., 2020; Forbes et al., 2023) như ROUGE (Lin, 2004), BLEU (Papineni et al., 2002), và METEOR (Banerjee và Lavie, 2005) để đo sự nhất quán giữa văn bản được tạo ra và văn bản gốc. Mặc dù các chỉ số này mang lại sự đơn giản, chúng thường không đánh giá chính xác sự phù hợp của văn bản. Điều này dẫn đến hiệu suất không tối ưu khi văn bản có ý nghĩa liên quan nhưng khác với hình thức bề mặt của tài liệu tham khảo. Ngoài ra, các chỉ số này gặp khó khăn trong việc nắm bắt các phụ thuộc xa và có xu hướng phạt những thay đổi trong thứ tự ngữ nghĩa. BERTScore (Zhang et al., 2019) tận dụng các nhúng ngữ cảnh đã được huấn luyện trước từ BERT (Devlin et al., 2018) và so khớp các từ trong các câu ứng viên và câu tham chiếu bằng độ tương đồng cosine. BERTScore đã được chứng minh là tương quan tốt với đánh giá của con người. Một phương pháp khác là chuyển việc phát hiện ảo giác thành vấn đề phân loại (Chen et al., 2023). Các nghiên cứu gần đây cho thấy rằng các LLM có thể tự là những đánh giá viên tốt (Wang et al., 2023) và nhiều nghiên cứu sử dụng LLM để phát hiện ảo giác (Mündler et al., 2023; Manakul et al., 2023; Weng et al., 2023; Fu et al., 2023). Một cách khác để giảm ảo giác là tinh chỉnh LLM trên dữ liệu theo nhiệm vụ cụ thể (Cao et al., 2021; Yu et al., 2023). Một số phương pháp này có thể bổ sung cho nhau. Ví dụ, Guan et al. (2023) đã kết hợp xác minh LLM, tinh chỉnh hướng dẫn và tăng cường truy xuất để xác minh các sự thật cho các đầu ra của LLM. Các phương pháp dựa trên LLM có thể tốn kém đáng kể khi sử dụng các LLM thương mại sẵn có, đặc biệt trong các ứng dụng thương mại điện tử quy mô lớn. Ngoài ra, việc phát triển LLM sở hữu riêng trong một tổ chức

Trong công trình này, chúng tôi trình bày một phương pháp để phát hiện các ảo giác trong danh sách sản phẩm được tăng cường bởi LLM. Phương pháp của chúng tôi sử dụng các kỹ thuật phát hiện ảo giác hộp đen không cần tài nguyên, loại bỏ nhu cầu về cơ sở dữ liệu kiến thức bên ngoài hoặc truy cập vào trạng thái nội bộ của LLM. Sự độc lập này cho phép hệ thống của chúng tôi không phụ thuộc vào các LLM đầu nguồn và có khả năng tổng quát hóa cho một phạm vi rộng hơn các ứng dụng của LLM. Hơn nữa, phương pháp của chúng tôi cải thiện khả năng mở rộng so với các phương pháp chỉ sử dụng LLM bằng cách giảm đáng kể không gian suy luận trước khi xác thực bởi LLM.

3. Phương pháp nghiên cứu

Chúng tôi đề xuất một phương pháp hai giai đoạn để phát hiện ảo giác (Hình 2), nhấn mạnh khả năng hồi tưởng trong giai đoạn đầu và cải thiện độ chính xác trong giai đoạn tiếp theo. Trong giai đoạn đầu, được gọi là Sàng lọc Từ vựng và Ngữ nghĩa (LSS), các kỹ thuật không giám sát tiết kiệm chi phí được áp dụng để phát hiện một phổ rộng các ảo giác. Mặc dù các phương pháp này hiệu quả, hiệu suất của chúng có thể bị ảnh hưởng bởi những hạn chế trong việc hiểu văn bản. Trong giai đoạn thứ hai, xác thực LLM, chúng tôi sử dụng các LLM để xác thực các ảo giác ứng viên được xác định trong giai đoạn đầu. Chúng tôi tối ưu hóa độ chính xác trong giai đoạn thứ hai bằng cách tận dụng khả năng hiểu ngôn ngữ mạnh mẽ của LLM. Do nhu cầu quan trọng về khả năng mở rộng trong việc phát hiện ảo giác, đặc biệt trong bối cảnh thương mại điện tử với kho sản phẩm khổng lồ, giai đoạn LSS ban đầu làm giảm đáng kể không gian suy luận. Sự giảm này cho phép phương pháp tốn nhiều tài nguyên hơn có thể mở rộng hiệu quả trong giai đoạn thứ hai, giải quyết

Brand: Lilly Pulitzer and *Size: 12inchx10inch*, for the given source product listing. Using LSS, we confirmed the legitimacy of *Brand: Lilly Pulitzer* by cross-referencing it with information in the source product name. Subsequently, we evaluated the *Size: 12inchx10inch* attribute and determined it to be hallucinated content employing LLM validation.

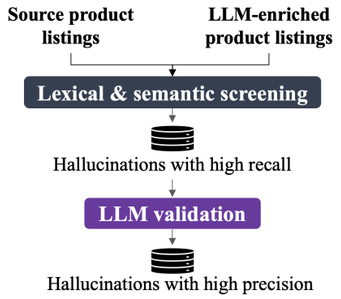


Figure 2: Two-phase hallucination detection.

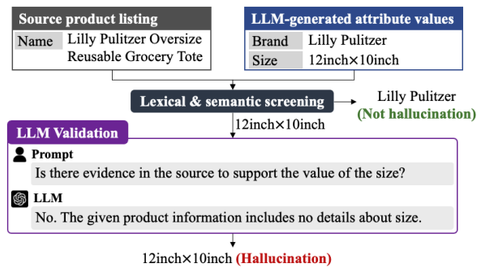


Figure 3: Example of hallucination detection.

3.1. Lexical and Semantic Screening (LSS)

In the initial phase, we employ unsupervised methods to flag all potential hallucinations by detecting information lacking supporting evidence in the source input. This support is traced through exact keywords or similar content, examined at either the token or the entire generated value level. We investigated techniques for locating supporting evidence from the source input:

3.1.1. Token-level LSS

Rebuffel et al. (2022) advocated addressing hallucinations at the word level rather than the instance level. They employed word-level alignment between candidate and inference text to control hallucinations. Their experiments demonstrated that word-level signals improved the fluency, factual accuracy, and relevance of LLM outputs. In our study, we similarly employ token-level alignment between the source input and LLM-enriched values to detect hallucinations.

Exact match. A direct method involves examining the presence of generated content in the source input. In Figure 2, the explicit mention of *Lilly Pulitzer* in the source input rules out hallucination. This method, denoted as T_{exact}, exhibits high recall but low precision in identifying hallucinations.

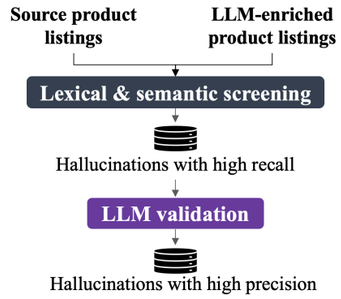
Exact matching often results in a large number false positive hallucinations, as LLMs may produce semantically similar but distinct words in enriched product listings. Fuzzy matching provides more flexibility, allowing LLMs to generate product information with enhanced fluency and coherence, leveraging advanced vocabulary. We assessed three fuzzy matching techniques:

Edit-distance. Token-level edit-distance (Levenshtein et al., 1966) between the source text and hallucinated text was used in generating synthetic data for hallucination detection and it was found that this approach provided sufficiently high quality training data in practice (Zhou et al., 2020). In our work, we adopt a similar approach by calculating the token-level edit distance between each token in the generated and source texts to pinpoint potential supporting evidence within the source data. This method is denoted as T_{edit}.

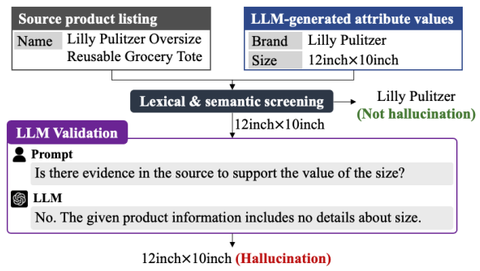
N-gram overlap metrics. N-gram matching metrics are commonly used for evaluating text generation by counting the number of n-grams that occur in the reference and candidate text. ROUGE (Lin, 2004) is often used for summarization evaluation, while BLEU is the most widely used metric in machine translation (Papineni et al., 2002). METEOR (Banerjee and Lavie, 2005) introduces flexibility by permitting a transition from strict unigram matching to encompassing word stems, synonyms, and paraphrases. These metrics provide a way to find the evidence for supporting the LLM-generated content from the source input. Therefore, we utilize three metrics: T_{rouge}, T_{bleu}, and T_{meteor}.

Embedding similarity. Token embeddings capture nuanced semantic and syntactic word relationships (Mikolov et al., 2013; Pennington et al., 2014; Bojanowski et al., 2016), and allow for a soft measure of similarity instead of strict string matching between the generated and source text. In this work, we experimented with three embedding models provided in Gensim (Rehurek and Sojka, 2011): *word2vec-google-news-300* (Mikolov et al., 2013) ($T_{word2vec}$), *glove-wiki-gigaword-300* (Pennington et al., 2014) (T_{glove}), and *fasttext-wiki-news-subwords-300* (Bojanowski et al., 2016) ($T_{fasttext}$).

Thương hiệu: Lilly Pulitzer và Kích thước: 12inchx10inch, cho danh sách sản phẩm nguồn đã cho. Sử dụng LSS, chúng tôi đã xác nhận tính hợp pháp của Thương hiệu: Lilly Pulitzer bằng cách đối chiếu với thông tin trong tên sản phẩm nguồn. Sau đó, chúng tôi đã đánh giá thuộc tính Kích thước: 12inchx10inch và xác định đây là nội dung ảo thông qua việc kiểm tra bằng LLM.



Hình 2: Phát hiện ảo giác hai pha.



Hình 3: Ví dụ về phát hiện ảo giác.

3.1. Sàng lọc Từ vựng và Ngữ nghĩa (LSS)

Trong giai đoạn đầu, chúng tôi sử dụng các phương pháp không giám sát để đánh dấu tất cả các ảo tưởng tiềm năng bằng cách phát hiện thông tin thiếu bằng chứng hỗ trợ trong dữ liệu đầu vào nguồn. Sự hỗ trợ này được truy xuất thông qua các từ khóa chính xác hoặc nội dung tương tự, được kiểm tra ở mức token hoặc toà n bộ giá trị được tạo ra. Chúng tôi đã nghiên cứu các kỹ thuật để tìm kiếm bằng chứng hỗ trợ từ dữ liệu đầu vào nguồn:

3.1.1. LSS cấp token

Rebuffel và cộng sự (2022) đã đề xuất giải quyết ảo giác ở cấp độ từ thay vì cấp độ thực thể. Họ đã sử dụng sự căn chỉnh cấp độ từ giữa văn bản ứng cử và văn bản suy luận để kiểm soát ảo giác. Các thí nghiệm của họ cho thấy rằng các tín hiệu cấp độ từ đã cải thiện tính trôi chảy, độ chính xác về mặt thực tế và sự liên quan của các kết quả đầu ra của LLM. Trong nghiên cứu của chúng tôi, chúng tôi cũng sử dụng sự căn chỉnh cấp độ token giữa nguồn đầu vào và các giá trị được LLM làm phong phú để phát hiện ảo tưởng.

Khớp chính xác. Một phương pháp trực tiếp liên quan đến việc kiểm tra sự hiện diện của nội dung được tạo ra trong nguồn đầu vào. Trong Hình 2, việc đề cập rõ ràng đến Lilly Pulitzer trong nguồn đầu vào loại trừ khả năng tưởng t ượng. Phương pháp này, được ký hiệu là T_{exact}, thể hiện độ hồi nhớ cao nhưng độ chính xác thấp trong việc xác định các ảo tưởng.

Đối sánh chính xác thường dẫn đến một số l ượng lớn các giả dương tính ảo, vì LLM có thể tạo ra các từ tương tự về ngữ nghĩa nhưng khác biệt trong các danh sách sản phẩm phong phú. Đối sánh mờ cung cấp nhiều sự linh hoạt hơn, cho phép LLM tạo ra thông tin sản phẩm với lưu loát và mạch lạc nâng cao, tận dụng từ vựng tiên tiến. Chúng tôi đã đánh giá ba kỹ thuật đối sánh mờ:

Khoảng cách chỉnh sửa. Khoảng cách chỉnh sửa ở mức token (Levenshtein et al., 1966) giữa văn bản nguồn và văn bản ảo tưởng đã được sử dụng trong việc tạo dữ liệu tổng hợp để phát hiện ảo tưởng và người ta nhận thấy rằng phương pháp này cung cấp dữ liệu huấn luyện có chất lượng đủ cao trong thực tế (Zhou et al., 2020). Trong công trình của chúng tôi, chúng tôi áp dụng một phương pháp tương tự bằng cách tính khoảng cách chỉnh sửa ở mức token giữa từng token trong văn bản được tạo ra và văn bản nguồn để xác định các bằng chứng hỗ trợ tiềm năng trong dữ liệu nguồn. Phương pháp này được ký hiệu là T_{edit}.

Các chỉ số chồng lấp N-gram. Các chỉ số so khớp N-gram thường được sử dụng để đánh giá việc tạo văn bản bằng cách đếm số lượng n-gram xuất hiện trong văn bản tham khảo và văn bản ứng viên. ROUGE (Lin, 2004) thường được sử dụng cho việc đánh giá tóm tắt, trong khi BLEU là chỉ số được sử dụng rộng rãi nhất trong dịch máy (Papineni et al., 2002). METEOR (Banerjee và Lavie, 2005) mang lại s ự linh hoạt bằng cách cho phép chuyển từ việc so khớp unigram nghiêm ngặt sang bao gồm thân từ, từ đồng nghĩa và các cách diễn đạt khác nhau. Những chỉ số này cung cấp một cách để tìm bằng chứng hỗ trợ nội dung do LLM tạo ra từ đầu vào gốc. Do đó, chúng tôi sử dụng ba chỉ số: T_{rouge}, T_{bleu}, và T_{meteor}.

Độ tương đồng embedding. Các embedding token nắm bắt mối quan hệ ngữ nghĩa và cú pháp tinh vi giữa các t ừ (Mikolov và cộng sự, 2013; Pennington và cộng sự, 2014; Bojanowski và cộng sự, 2016), và cho phép đo lường độ tương đồng mềm thay vì đối sánh chuỗi nghiêm ngặt giữa văn bản được sinh ra và văn bản gốc. Trong công trình này, chúng tôi đã thử nghiệm với ba mô hình embedding được cung cấp trong Gensim (Rehurek và Sojka, 2011): word2vec-google-news-300 (Mikolov và cộng sự, 2013) ($T_{word2vec}$), glove-wiki-gigaword-300 (Pennington và cộng sự, 2014) (T_{glove}), và fasttext-wiki-news-subwords-300 (Bojanowski và cộng sự, 2016) ($T_{fasttext}$).

3.1.2. Value-level LSS

Instead of checking evidence at the token level, we can evaluate the semantic similarity between the generated text and the source input as a whole. Significant deviations from the source text in the generated content can signal hallucination.

Sentence embedding. Sentence transformers convert sentences into semantically meaningful embeddings that can be compared using cosine-similarity (Reimers and Gurevych, 2019). In this work, we used four sentence-transformers (Reimers and Gurevych, 2019) models from HuggingFace (Wolf et al., 2019): *all-MiniLM-L6-v2*, *all-mpnet-base-v2*, *gtr-t5-large* (Ni et al., 2021), and *multi-qa-mpnet-base-dot-v1*, denoted as V_{miniLM}, V_{mpnet}, V_{gtr}, and V_{qa} respectively.

BERTScore. BERTScore has been shown to correlate well with human judgments for evaluating natural language generation tasks (Zhang et al., 2019). BERTScore calculates a similarity score between the candidate and reference text by aggregating the cosine similarities of their token embeddings. Unlike traditional metrics such as ROUGE, BLEU and METEOR that rely on string matching or heuristics, BERTScore uses contextualized token embeddings. It demonstrates a stronger capability of accommodating instances where semantically correct phrases deviate from the surface form of the reference. We abbreviate this approach as V_{bert}.

ALIGNSCORE. ALIGNSCORE (Zha et al., 2023) evaluates the factual consistency of generated text against a model input. It is applicable to various factual inconsistency scenarios, as it employs a unified training framework of the alignment function by integrating diverse data sources from seven well-established tasks. We denote this as V_{align}.

3.2. LLM Validation

Recent studies have explored the use of LLMs for evaluating their own generated text (Varshney et al., 2023), showing promising results. However, LLM validation typically incurs a significant expense due to associated API fees, presenting a challenge that impedes the scalability of LLM validation for e-commerce product listing enrichment. This challenge underscores the need to initially filter out a substantial portion of non-hallucinated content in the LSS step, which allows the subsequent LLM validation step to focus on a more manageable number of candidates. In this work, we used Claude 2 (Anthropic, 2023) from Anthropic for LLM validation.

Zero-shot. LLMs have shown great potential in evaluating the factual consistency between a document and its summary in the zero-shot setting (Luo et al., 2023). Thus, we directly prompt an LLM to verify the hallucinations detected in the LSS step.

Chain-of-thought (CoT). Chain-of-thought (CoT) prompting significantly enhances LLMs' complex reasoning abilities (Wei et al., 2022). CoT prompting, involving the presentation of intermediate reasoning steps, prove effective in both zero-shot (Kojima et al., 2022) or in-context learning (Wei et al., 2022) settings. Kojima et al. showed that LLMs demonstrated decent zero-shot reasoning capability by instructing them to think step by step (Kojima et al., 2022). In this work, we adopt a similar approach, instructing LLMs to provide step-by-step reasoning and identify supporting evidence when available. We only use the final decision from LLM as the prediction. Nonetheless, prompting the LLM to seek evidence initiates an underlying reasoning process, which can potentially improve the overall performance (Kojima et al., 2022).

In-context learning. LLMs demonstrate impressive ability to do in-context learning (Brown et al., 2020). They can generalize to unseen data by leveraging a limited set of training examples in the prompt, without explicit pre-training for the specific task (Xie et al., 2021). We asked domain experts to select examples of product listings with and without hallucinations and include them in prompts. By augmenting the context with these selected examples, it is anticipated that the LLM will discern the underlying pattern present in the demonstrations, thus enabling accurate predictions.

Many studies have investigated instruction-tuning for LLMs to enhance alignment with specific tasks (Ouyang et al., 2022; Peng et al., 2023b). In contrast to in-context learning, wherein examples are presented during inference without updating the LLMs' parameters, instruction tuning involves utilizing a set of examples to adjust the parameters during training. However, no demonstrations are employed during inference in instruction tuning (Duan et al., 2023). Although instruction tuning has shown promising results, it requires human-annotated prompts and feedback on a specific task. In our work, we do not experiment with instruction-tuning but consider it a potential future direction.

4. Experiments

In this section, we first introduce the dataset employed for evaluating hallucination detection in LLM-enriched product listings. We then compare the performance of different approaches, demonstrating the effectiveness of our proposed approach.

3.1.2. LSS cấp giá trị

Thay vì kiểm tra bằng chứng ở mức token, chúng ta có thể đánh giá độ tương đồng ngữ nghĩa giữa văn bản được tạo ra và đầu vào gốc như một tổng thể. Những sai lệch đáng kể so với văn bản gốc trong nội dung được tạo ra có thể báo hiệu ảo tưởng.

Nhúng câu. Bộ biến đổi câu chuyển đổi các câu t hành các nhúng có ý nghĩa ngữ nghĩa mà có thể được so sánh bằng cách sử dụng độ tương đồng cosi n (Reimers và Gurevych, 2019). Trong công trình này, chúng tôi đã sử dụng bốn mô hình bộ biến đổi câu (Reimers và Gurevych, 2019) từ HuggingFace (Wolf và cs., 2019): all-MiniLM-L6-v2, all-mpnet-base-v2, gtr-t5-large (Ni và cs., 2021), và multi-qa-mpnet-base-dot-v1, được ký hiệu lần lượt là V_{miniLM},V_{mpnet}, V_{gtr}, và V_{qa} .

BERTScore. BERTScore đã được chứng minh là có mối tương quan tốt với đánh giá của con người trong việc đánh giá các nhiệm vụ tạo ngôn ngữ tự nhiên (Zhang et al., 2019). BERTScore tính điểm tương đồng giữa văn bản ứng viên và văn bản tham chiếu bằng cách tổng hợp các độ tương đồng cosin của các embedding token của chúng. Khác với các chỉ số truyền thống như ROUGE, BLEU và METEOR dựa vào việc so khớp chuỗi hoặc các quy tắc kinh nghiệm, BERTScore sử dụng embedding token có ngữ cảnh. Nó thể hiện khả năng mạnh mẽ hơn trong việc xử lý các trường hợp mà các cụm từ về mặt ngữ nghĩa là đúng nhưng lệch khỏi hình thức bề mặt của tham chiếu. Chúng tôi viết tắt phương pháp này là V_{bert}.

ALIGNSCORE. ALIGNSCORE (Zha và cộng sự, 2023) đánh giá độ nhất quán thực tế của văn bản được tạo ra so với đầu vào của mô hình. Nó có thể áp dụng cho nhiều tình huống không nhất quán thực tế khác nhau, vì nó sử dụng một khuôn khổ đào tạo thống nhất của hàm căn chỉnh bằng cách tích hợp các nguồn dữ liệu đa dạng từ bảy nhiệm vụ đã được thiết lập. Chúng tôi gọi điều này l à V_{align}.

3.2. Xác thực LLM

Các nghiên cứu gần đây đã khám phá việc sử dụng LLM để đánh giá văn bản do chính chúng tạo ra (Varshney et al., 2023), cho thấy kết quả đầy hứa hẹn. Tuy nhiên, việc xác thực LLM thường phát sinh chi phí đáng kể do các khoản phí API liên quan, tạo ra một thách thức cản trở khả năng mở rộng của việc xác thực LLM cho việc làm giàu danh sách sản phẩ m thương mại điện tử. Thách thức này nhấn mạnh s ự cần thiết phải lọc ban đầu một phần đáng kể nội dung không ảo giác trong bước LSS, điều này cho phép bước xác thực LLM tiếp theo tập trung vào một số lượng ứng viên dễ quản lý hơn. Trong công trình này, chúng tôi đã sử dụng Claude 2 (Anthropic, 2023) từ Anthropic cho việc xác thực LLM.

Zero-shot. Các mô hình ngôn ngữ lớn (LLMs) đã cho thấy tiềm năng lớn trong việc đánh giá sự nhất quán thực tế giữa một tài liệu và tóm tắt của nó trong bối cảnh zero-shot (Luo et al., 2023). Do đó, chúng tôi trực tiếp yêu cầu một LLM xác minh các ảo tưởng được phát hiện trong bước LSS.

Chuỗi suy nghĩ (CoT). Phương pháp gợi ý chuỗi suy nghĩ (CoT) cải thiện đáng kể khả năng lập luận phức tạp của các mô hình ngôn ngữ lớn (LLMs) (Wei et al., 2022). Gợi ý CoT, bao gồm việc trình bày các bước s uy luận trung gian, chứng minh hiệu quả trong cả hai bối cảnh học zero-shot (Kojima et al., 2022) hoặc học theo ngữ cảnh (Wei et al., 2022). Kojima và cộng sự đã chỉ ra rằng các LLM thể hiện khả năng lập l uận zero-shot khá tốt khi được hướng dẫn suy nghĩ từng bước (Kojima et al., 2022). Trong nghiên cứu này, chúng tôi áp dụng một phương pháp tương tự, hướng dẫn các LLM cung cấp suy luận từng bước và xác định bằng chứng hỗ trợ khi có sẵn. Chúng tôi chỉ sử dụng kết quả cuối cùng từ LLM làm dự đoán. Tuy nhiên, việc gợi ý LLM tìm kiếm bằng chứng kích hoạt một quá trình suy luận tiềm ẩn, có thể cải thiện hiệu suất tổng thể (Kojima et al., 2022).

Học theo ngữ cảnh. Các LLM thể hiện khả năng ấn tượng trong việc học theo ngữ cảnh (Brown et al., 2020). Chúng có thể tổng quát hóa cho dữ liệu chưa thấy bằng cách tận dụng một tập hợp các ví dụ huấn luyện giới hạn trong prompt, mà không cần tiến huấn luyện rõ ràng cho nhiệm vụ cụ thể (Xie et al., 2021). Chúng tôi đã yêu cầu các chuyên gia trong lĩ nh vực chọn các ví dụ về danh sách sản phẩm có và không có ảo giác và đưa chúng vào trong prompt. Bằng cách bổ sung ngữ cảnh với những ví dụ đã chọn này, người ta dự kiến rằng LLM sẽ nhận ra mẫu ẩn trong các minh họa, từ đó cho phép dự đoán chính xác.

Nhiều nghiên cứu đã khảo sát việc tinh chỉnh theo hướng chỉ dẫn cho các Mô hình Ngôn ngữ Lớn (LLMs) nhằ m nâng cao sự phù hợp với các nhiệm vụ cụ thể (Ouyang et al., 2022; Peng et al., 2023b). Trái ngược với việc học theo ngữ cảnh, trong đó các ví dụ được trình bày trong quá trình suy luận mà không cập nhật các tham số của LLM, tinh chỉnh theo hướng chỉ dẫn liên quan đến việc sử dụng một tập hợp các ví dụ để điều chỉnh các tham số trong quá trình huấn luyện. Tuy nhiên, không có trình diễn nào được sử dụng trong quá trình suy luận khi tinh chỉnh theo hướng c hỉ dẫn (Duan et al., 2023). Mặc dù tinh chỉnh theo hướng chỉ dẫn đã cho thấy kết quả đầy hứa hẹn, nó đòi hỏi các gợi ý và phản hồi được chú thích bởi con người cho một nhiệm vụ c ụ thể. Trong công trình của chúng tôi, chúng tôi không thử nghiệm với tinh chỉnh theo hướng chỉ dẫn nhưng xem đây l à một hướng tiềm năng trong tương lai.

4. Thí nghiệm

Trong phần này, chúng tôi trước tiên giới thiệu bộ dữ liệu được sử dụng để đánh giá việc nhận diện ảo hoá trong các danh sách sản phẩm được tăng cường bởi LLM. Sau đó, chúng tôi so sánh hiệu suất của các phương pháp khác nhau, chứng minh hiệu quả của phương pháp mà chúng tôi đề xuất.

Finally, we discuss our findings, providing insights that guide our future research.

4.1. Dataset

We conducted experiments on two sets of human-annotated LLM-enriched product listings as described in Table 1. D_S exclusively contains structured product attributes, whereas D_U comprises only unstructured attributes. Structured attributes typically encompass product features characterized by enumerated, categorical, numerical, or keyword values, whereas unstructured attributes comprise long-form free-text values. In Table 1, we provide a summary of word counts for both structured and unstructured attributes. Given that the majority of product attributes are structured, we consolidate these into a single total count rather than listing each attribute individually. Conversely, we detail the three most prevalent unstructured attributes. Structured attributes normally contain 1-2 words, while unstructured attributes can include more than one hundred words. Additionally, attributes in D_S exhibits deterministic values, enabling annotators to identify hallucinations through a direct examination of the source input. In contrast, D_U introduces greater ambiguity. For instance, D_S primarily includes attributes such as *Color*, making it straightforward to assess the faithfulness of generated values to the source. On the contrary, D_U contains descriptive attributes, where values are less deterministic. Annotators' perceptions play a critical role in human judgments, contributing to increased uncertainty in hallucination detection.

Dataset	Attribute type	#Listings	#Entries
D_S	Structured	200	2,765
D_U	Unstructured	4,042	12,126

Table 1: Dataset description.

Type	Attribute	#Words		
		$Avg.$	$50p$	$75p$
Structured	-	2	1	2
Unstructured	U-Attribute 1	17	16	21
	U-Attribute 2	91	81	102
	U-Attribute 3	138	130	160

Table 2: Number of words by attribute type.

The datasets include original product listing alongside LLM-enriched values for one or multiple attributes in that listing. Our approach focuses on detecting hallucination at the attribute level. For instance, Figure 3 displays a listing with 2 LLM-enriched attributes: *Brand* and *Size*. We make independent decisions for each attribute. Domain experts audited the dataset to pinpoint hallucinations in LLM-generated values, and we use these human labels as the gold standard to evaluate our proposed approaches.

4.2. Experimental results

We utilize precision, recall, and F1 score to assess model performance. In e-commerce, distributing hallucinated product listings may lead to negative user experiences or legal issues in critical scenarios. Nevertheless, rejecting LLM-enriched product listings based on mistakenly identified hallucinations carries substantial costs. The precision-recall trade-off allows optimizing the balance between the consequences of false positive and false negative predictions in practice.

4.2.1. LSS

Table 3 and 4 detail the performance of various LSS models on D_S and D_U. In the results, P, R, and $F1$ represent precision, recall, and F1 score, respectively. Precision and recall targets, established by domain experts, are denoted as p and r. The target $f1$ is calculated with p and r. We present the performance of various approaches compared against the targets. As we optimize recall in the LSS phase to maximize the coverage of hallucinations, we choose the optimal model from each method with $recall >= min(recall_{max}, r)$.

LSS Model	P/p	R/r	$F1/f1$	$\%Inf$
T_{exact}	1.05	1.09	**1.07**	7.4
T_{edit}	1.05	1.09	**1.07**	7.4
T_{rouge}	0.88	1.06	0.95	9.0
T_{bleu}	1.05	1.07	1.06	6.8
T_{meteor}	0.68	1.06	0.82	11.6
$T_{word2vec}$	1.09	1.04	1.06	6.4
T_{glove}	1.09	1.03	1.06	6.4
$T_{fasttext}$	1.09	1.04	**1.07**	6.4
V_{miniLM}	0.85	1.06	0.94	9.8
V_{mpnet}	0.81	1.07	0.91	116
V_{gtr}	0.84	1.06	0.93	9.5
V_{qa}	0.81	1.06	0.91	10.6
V_{bert}	0.40	1.08	0.57	48.5
V_{align}	0.80	1.07	0.91	10.6

Table 3: Performances of LSS models on D_S.

The results indicate that LSS models exhibited promising abilities in detecting hallucinations within D_S. T_{exact}, T_{edit} and $T_{fasttext}$ yielded the highest F1 score at 1.07$f1$. While other LSS models demonstrated slightly lower performance, the majority maintained recall rates above 1.05r and precision within the range of 0.8p-1.05p. In contrast, these models exhibited a significant drop in performance when applied to D_U. While most maintained over 1.05r recall, precision struggled, falling below 0.25p. In e-commerce, ensuring high recall in hallucination detection is crucial, as false negatives

Cuối cùng, chúng tôi thảo luận về những phát hiện của mình, cung cấp những hiểu biết hướng dẫn nghiên cứu trong tương lai của chúng tôi.

4.1. Bộ dữ liệu

Chúng tôi đã tiến hành các thí nghiệm trên hai bộ danh sách sản phẩm được con người chú thích và bổ sung bởi LLM như mô tả trong Bảng 1. D_S chỉ chứa các thuộc tính sản phẩm có cấu trúc, trong khi D_U chỉ bao gồm các thuộc tính không có cấu trúc. Thuộc tính có cấu trúc thường bao gồm các đặc điểm sản phẩm được xác định bằng các giá trị liệt kê, phân loại, số hoặc từ khóa, trong khi các thuộc tính không có cấu trúc bao gồm các giá trị văn bản dài. Trong Bảng 1, chúng tôi cung cấp tóm tắt số lượng từ cho cả thuộc tính có cấu trúc và không có cấu trúc. Vì phần lớn các thuộc tính sản phẩm đều có cấu trúc, chúng tôi gộp chúng thành một tổng số duy nhất thay vì liệt kê từng thuộc tính một. Ngược lại, chúng tôi chi tiết ba thuộc tính không có cấu trúc phổ biến nhất. Các thuộc tính có cấu trúc thường chứa 1-2 từ, trong khi các thuộc tính không có cấu trúc có thể bao gồm hơn một trăm từ. Ngoài ra, các thuộc tính trong D_S hiển thị các giá trị xác định, cho phép người chú thích xác định các ảo giác thông qua một chuyến trực tiếp.

Bộ dữ liệu	Loại thuộc tính	#Danh sách	#Mục
D_S	Có cấu trúc	200	2,765
D_U	Không có cấu trúc	4,042	12,126

Bảng 1: Mô tả bộ dữ liệu.

Type	Thuộc tính	#Từ		
		$Avg.$	$50p$	$75p$
Có cấu trúc	-	2	1	2
Không có cấu trúc	Thuộc tính U 1	17	16	21
	Thuộc tính U 2	91	81	102
	Thuộc tính U 3	138	130	160

Bảng 2: Số lượng từ theo loại thuộc tính.

Các bộ dữ liệu bao gồm danh sách sản phẩm gốc cùng với các giá trị được LLM bổ sung cho một hoặc nhiều thuộc tính trong danh sách đó. Phương pháp của chúng tôi tập trung vào việc phát hiện ảo giác ở cấp thuộc tính. Ví dụ, Hình 3 hiển thị một danh sách với 2 thuộc tính được LLM bổ sung: Thương hiệu và Kích thước. Chúng tôi đưa ra quyết định độc lập cho mỗi thuộc tính. Lĩnh vực

Các chuyên gia đã kiểm tra bộ dữ liệu để xác định các ảo giác trong các giá trị do LLM tạo ra, và chúng tôi sử dụng những nhãn do con người này làm tiêu chuẩn vàng để đánh giá các phương pháp mà chúng tôi đề xuất.

4.2. Kết quả thí nghiệm

Chúng tôi sử dụng độ chính xác, độ nhạy, và điểm F1 để đánh giá hiệu suất của mô hình. Trong thương mại điện tử, việc phân phối các danh sách sản phẩm ảo có thể dẫn đến trải nghiệm người dùng tiêu cực hoặc các vấn đề pháp lý trong những tình huống quan trọng. Tuy nhiên, từ chối các danh sách sản phẩm được bổ sung bởi LLM dựa trên các ảo giác bị xác định nhầm có thể tốn kém đáng kể. Sự đánh đổi giữa độ chính xác và độ nhạy cho phép tối ưu hóa cân bằng giữa hậu quả của các dự đoán dương tính giả và âm tính giả trong thực tế.

4.2.1. LSS

Bảng 3 và 4 trình bày chi tiết hiệu suất của các mô hình LSS khác nhau trên D_S và D_U. Trong kết quả, P, R và $F1$ lần lượt đại diện cho độ chính xác, độ gọi lại và điểm F1. Mục tiêu về độ chính xác và độ gọi lại, được xác lập bởi các chuyên gia trong lĩnh vực, được ký hiệu là p và r. Mục tiêu $f1$ được tính bằng p và r. Chúng tôi trình bày hiệu suất của các phương pháp khác nhau so với các mục tiêu. Khi tối ưu độ gọi lại trong giai đoạn LSS để tối đa hóa phạm vi bao phủ các ảo tưởng, chúng tôi chọn mô hình tối ưu từ mỗi phương pháp với $recall >= min(recall_{max}, r)$.

Mô hình LSS	P/p	R/r	$F1/f1$	$\%Inf$
T_{exact}	1.05	1.09	**1.07**	7.4
T_{edit}	1.05	1.09	**1.07**	7.4
T_{rouge}	0.88	1.06	0.95	9.0
T_{bleu}	1.05	1.07	1.06	6.8
T_{meteor}	0.68	1.06	0.82	11.6
$T_{word2vec}$	1.09	1.04	1.06	6.4
T_{glove}	1.09	1.03	1.06	6.4
$T_{fasttext}$	1.09	1.04	**1.07**	6.4
V_{miniLM}	0.85	1.06	0.94	9.8
V_{mpnet}	0.81	1.07	0.91	116
V_{gtr}	0.84	1.06	0.93	9.5
V_{qa}	0.81	1.06	0.91	10.6
V_{bert}	0.40	1.08	0.57	48.5
V_{align}	0.80	1.07	0.91	10.6

Bảng 3: Hiệu suất của các mô hình LSS trên D_S.

Kết quả cho thấy các mô hình LSS thể hiện khả năng hứa hẹn trong việc phát hiện ảo giác trong D_S. T_{exact}, T_{edit} và $T_{fasttext}$ đạt điểm F1 cao nhất là 1.07$f1$. Trong khi một số mô hình LSS khác cho hiệu suất hơi thấp hơn, phần lớn vẫn duy trì tỷ lệ hồi tưởng trên 1.05r và độ chính xác trong khoảng 0.8p-1.05p. Ngược lại, các mô hình này gặp giảm hiệu suất đáng kể khi áp dụng cho D_U. Mặc dù hầu hết vẫn duy trì hồi tưởng trên 1.05r , độ chính xác gặp khó khăn, giảm xuống dưới 0.25p. Trong thương mại điện tử, đảm bảo hồi tưởng cao trong phát hiện ảo giác là rất quan trọng, vì các kết quả âm tính giả

LSS Model	P/p	R/r	$F1/f1$	$\%Inf$
T_{exact}	0.23	1.11	0.36	12.5
T_{edit}	0.23	1.11	0.36	12.5
T_{rouge}	0.23	1.11	0.37	13.2
T_{bleu}	0.23	1.11	0.36	12.5
T_{meteor}	0.26	1.08	**0.41**	7.2
$T_{word2vec}$	0.23	1.11	0.36	12.4
T_{glove}	0.23	1.11	0.36	12.4
$T_{fasttext}$	0.23	1.11	0.36	12.4
V_{miniLM}	0.27	0.96	**0.41**	2.9
V_{mpnet}	0.20	0.90	0.31	2.5
V_{gtr}	0.17	0.74	0.27	1.7
V_{qa}	0.24	1.06	0.37	6.0
V_{bert}	0.25	0.34	0.29	0.3
V_{align}	0.22	1.05	0.35	6.8

Table 4: Performances of LSS models on D_U.

directly affect customer experiences and can hurt brand reputation.

The $\%Inf$ column denotes the portion of the inference space identified by LSS as hallucination candidates, serving as input for LLM validation. LSS models effectively reduced the inference space to less than 12.5%, and some models further narrowed this down to below 10% for LLM validation.

V_{bert} is an anomalous case among the models for D_S, with a performance of only 0.4p. Our observations indicate that V_{bert} tends to give lower scores to generated values significantly shorter than the reference text, causing an increase in false positives. Conversely, it assigns high similarity scores to unstructured attribute values compared to the source text, which substantially reduces recall.

The primary difference between the datasets is their attribute types. The unstructured attributes in D_U contain substantial free-text content, differing significantly from the concise nature of structured attribute values in D_S. Detecting hallucination from unstructured attribute values poses a greater challenge compared to structured ones. Also, the difference between token-level and value-level approaches is larger on structured attributes than that on unstructured attributes. This indicates that word-to-word comparison approaches are more suitable when the LLM-generated values are a bag of keywords, rather than coherent paragraphs.

Combining LSS models improves performance on D_S through an AND operation on their predictions. We explored every possible pairing of two models, and Table 5 displays the top three combined LSS models for D_S, demonstrating notable enhancements. Intuitively, the combined models generated enhance precision but decreased recall. All the optimal combined models consist of a token-level and a text-level model. ALIGNSCORE significantly contributed to the top combined models D_S. On the contrary, combined LSS models demonstrated inferior performance compared to individual models on dataset D_U, as evidenced in Table 5. Notably, this combination led to a significant reduction in recall without improving precision, resulting in a decreased F1 score.

Dataset	Combined model	P/p	R/r	$F1/f1$
D_S	T_{exact}+V_{align}	1.12	1.06	1.09
	T_{edit}+V_{align}	1.12	1.06	1.09
	T_{bleu}+V_{align}	1.12	1.05	1.09
D_U	T_{bleu}+V_{bert}	0.23	0.31	0.26
	T_{edit}+V_{bert}	0.22	0.31	0.26
	T_{exact}+V_{bert}	0.22	0.31	0.26

Table 5: Combination of LSS models.

4.2.2. LLM validation

Table 6 presents the F1 scores of applying LLM validation to hallucination candidates identified by LSS models. Overall, LLM validation enhanced the performance on D_S, while yielding marginal improvement on D_U. On D_S, solely employing zero-shot LLM validation improved the performance for each LSS model. The CoT approach generally achieved higher F1 scores, with the exceptions of T_{bleu}, $T_{fasttext}$ and V_{bert}, where the zero-shot approach outperformed. For D_U, LLM validation with in-context examples consistently outperformed zero-shot and CoT. Optimal performance was achieved by combining LSS models with subsequent LLM validation for D_S, all models demonstrated comparable F1 scores for D_U post-LLM validation. Selection of models can be tailored based on specific business requirements for precision and recall.

It is known that LLM in-context learning faces a robustness challenge (Liu et al., 2021), with outcomes highly depend on the chosen in-context examples. We observed this dependence in our experiments. We asked domain experts to select examples of product listings with and without hallucinations. The selected examples aim to represent different situations where hallucinations may occur. Despite efforts to cover various scenarios, it remains challenging to encompass all possibilities within a limited set of examples. Our observation indicates that the LLM model tends to replicate the behavior of the provided examples during validation response generation. Consequently, it predominantly identifies semantically-close samples as hallucinations. A future direction would be strategically select examples based on their similarity to the query instance.

4.3. Discussions

Next, we discuss some key findings during the experiments and talk about a few open questions not covered by this work. This sheds lights on directions for future work.

Mô hình LSS	P/p	R/r	$F1/f1$	$\%Inf$
T_{exact}	0.23	1.11	0.36	12.5
T_{edit}	0.23	1.11	0.36	12.5
T_{rouge}	0.23	1.11	0.37	13.2
T_{bleu}	0.23	1.11	0.36	12.5
T_{meteor}	0.26	1.08	**0.41**	7.2
$T_{word2vec}$	0.23	1.11	0.36	12.4
T_{glove}	0.23	1.11	0.36	12.4
$T_{fasttext}$	0.23	1.11	0.36	12.4
V_{miniLM}	0.27	0.96	**0.41**	2.9
V_{mpnet}	0.20	0.90	0.31	2.5
V_{gtr}	0.17	0.74	0.27	1.7
V_{qa}	0.24	1.06	0.37	6.0
V_{bert}	0.25	0.34	0.29	0.3
V_{align}	0.22	1.05	0.35	6.8

Bảng 4: Hiệu suất của các mô hình LSS trên D_U.

ảnh hưởng trực tiếp đến trải nghiệm của khách hàng và có thể gây tổn hại đến uy tín thương hiệu.

Cột $\%Inf$ chỉ phần của không gian suy luận được LSS xác định là các ứng viên ảo tưởng, đóng vai trò như đầu vào cho việc xác thực LLM. Các mô hình LSS đã giảm hiệu quả không gian suy luận xuống dưới 12,5%, và một số mô hình còn thu hẹp hơn nữa xuống dưới 10% cho việc xác thực LLM.

V_{bert} là một trường hợp bất thường trong số các mô hình cho D_S, với hiệu suất chỉ đạt 0.4p. Quan sát của chúng tôi cho thấy V_{bert} có xu hướng đưa ra điểm số thấp hơn cho các giá trị được tạo ra ngắn hơn đáng kể so với văn bản tham chiếu, dẫn đến sự gia tăng các kết quả dương tính giả. Ngược lại, nó gán điểm tương đồng cao cho các giá trị thuộc tính không có cấu trúc so với văn bản nguồn, điều này làm giảm đáng kể độ truy hồi.

Sự khác biệt chính giữa các tập dữ liệu là loại thuộc tính của chúng. Các thuộc tính không có cấu trúc trong D_U chứa nội dung văn bản tự do đáng kể, khác biệt rõ rệt so với tính ngắn gọn của các giá trị thuộc tính có cấu trúc trong D_S. Việc phát hiện ảo giác từ các giá trị thuộc tính không có cấu trúc gây ra thách thức lớn hơn so với các giá trị có cấu trúc. Ngoài ra, sự khác biệt giữa các phương pháp ở mức token và mức giá trị lớn hơn đối với các thuộc tính có cấu trúc so với các thuộc tính không có cấu trúc. Điều này cho thấy các phương pháp so sánh từng từ một phù hợp hơn khi các giá trị do LLM tạo ra là một tập hợp từ khóa, thay vì các đoạn văn mạch lạc.

Việc kết hợp các mô hình LSS cải thiện hiệu suất trên D_S thông qua một phép toán AND trên các dự đoán của chúng. Chúng tôi đã khám phá mọi cặp hai mô hình có thể, và Bảng 5 hiển thị ba mô hình LSS kết hợp hàng đầu cho D_S, cho thấy sự cải thiện đáng kể. Trực quan, các mô hình kết hợp tạo ra tăng độ chính xác nhưng giảm độ nhạy. Tất cả các mô hình kết hợp tối ưu bao gồm một mô hình cấp token và một mô hình cấp văn bản. ALIGNSCORE đóng góp đáng kể vào các mô hình kết hợp hàng đầu D_S. Ngược lại, các mô hình LSS kết hợp thể hiện hiệu suất kém hơn so với các mô hình riêng lẻ trên bộ dữ liệu D_U, như được chứng minh trong Bảng 5. Đáng chú ý, sự kết hợp này dẫn đến việc giảm đáng kể khả năng gọi lại mà không cải thiện độ chính xác, dẫn đến điểm F1 giảm.

Bộ dữ liệu	Mô hình kết hợp	P/p	R/r	$F1/f1$
D_S	T_{exact}+V_{align}	1.12	1.06	1.09
	T_{edit}+V_{align}	1.12	1.06	1.09
	T_{bleu}+V_{align}	1.12	1.05	1.09
D_U	T_{bleu}+V_{bert}	0.23	0.31	0.26
	T_{edit}+V_{bert}	0.22	0.31	0.26
	T_{exact}+V_{bert}	0.22	0.31	0.26

Bảng 5: Sự kết hợp của các mô hình LSS.

4.2.2. Xác thực LLM

Bảng 6 trình bày các điểm F1 khi áp dụng xác thực LLM cho các ứng viên ảo tưởng được xác định bởi các mô hình LSS. Nhìn chung, xác thực LLM cải thiện hiệu suất trên D_S, trong khi chỉ mang lại cải thiện nhỏ trên D_U. Trên D_S, việc chỉ sử dụng xác thực zero-shot LLM đã cải thiện hiệu suất cho từng mô hình LSS. Phương pháp CoT nhìn chung đạt điểm F1 cao hơn, ngoại trừ T_{bleu}, $T_{fasttext}$ và V_{bert}, nơi phương pháp zero-shot vượt trội hơn. Đối với D_U, xác thực LLM với các ví dụ trong bối cảnh luôn vượt trội hơn zero-shot và CoT. Hiệu suất tối ưu đạt được bằng cách kết hợp các mô hình LSS với xác thực LL M tiếp theo cho D_S, và tất cả các mô hình đều cho thấy điểm F1 tương đương cho D_U sau xác thực LLM. Việc lựa chọn mô hình có thể được điều chỉnh dựa trên các yêu cầu kinh doanh cụ thể về độ chính xác và độ thu hồi.

Người ta biết rằng việc học theo ngữ cảnh của LLM gặp phải thách thức về độ ổn định (Liu et al., 2021), với kết quả phụ thuộc nhiều vào các ví dụ t heo ngữ cảnh được chọn. Chúng tôi đã quan sát thấy sự phụ thuộc này trong các thí nghiệm của mình. Chúng tôi đã yêu cầu các chuyên gia trong lĩnh vực chọn các ví dụ về danh sách sản phẩm có và không có ảo giác. Các ví dụ được chọn nhằm đại diện cho các tình huống khác nhau mà ảo giác có thể xảy ra. Mặc dù đã cố gắng bao quát nhiều kịch bản khác nhau, việc bao quát tất cả các khả năng trong một t ập hợp giới hạn các ví dụ vẫn là một thách thức. Quan sát của chúng tôi chỉ ra rằng mô hình LLM có xu hướng sao chép hành vi của các ví dụ được cung cấp trong quá trình tạo phản hồi kiểm tra. Do đó, nó chủ yếu nhận diện các mẫu gần về mặt ngữ nghĩa như những ảo giác. Một hướng đi trong tương lai là lựa chọn các ví dụ một cách chiến lược dựa trên độ tương đồng của chúng với trường hợp truy vấn.

4.3. Thảo luận

Tiếp theo, chúng tôi thảo luận một số phát hiện chính trong quá trình thí nghiệm và nói về một vài câu hỏi mở mà nghiên cứu này chưa đề cập. Điều này làm sáng tỏ hướng đi cho các công trình trong tương lai.

Model	D_S			D_U		
	Z	C	I	Z	C	I
T_{exact}	1.08	1.09	1.08	0.37	0.36	0.37
T_{edit}	1.08	1.09	1.08	0.37	0.36	0.37
T_{rouge}	1.01	1.05	1.00	0.36	0.36	0.37
T_{bleu}	1.08	1.07	1.05	0.36	0.36	0.37
T_{meteor}	0.97	0.99	0.99	0.36	0.35	0.39
$T_{word2vec}$	1.07	1.07	1.01	0.37	0.37	0.37
T_{glove}	1.07	1.07	1.01	0.37	0.37	0.37
$T_{fasttext}$	1.08	1.07	1.03	0.37	0.37	0.37
V_{miniLM}	1.01	1.01	1.02	0.37	0.37	0.37
V_{mpnet}	1.01	1.04	1.00	0.37	0.36	0.37
V_{gtr}	1.01	1.04	1.00	0.37	0.36	0.37
V_{qa}	1.00	1.04	1.00	0.37	0.36	0.37
V_{bert}	1.02	1.00	1.00	0.32	0.33	0.34
V_{align}	1.07	1.04	1.01	0.37	0.36	0.36
T_{exact}+V_{align}	1.10	1.07	1.04	-	-	-

Table 6: LLM validation performance. Z denotes zero-shot, C denotes CoT, and I denotes in-context learning.

Factual hallucination. This study focuses on identifying hallucinated product information that lack support from the source input. However, not all detected hallucinations are necessarily incorrect; some may align with factual information (Cao et al., 2021). As illustrated in Figure 4(a), the LLM-generated *Color* value lacks support in the source input, but aligns with the product image. It is worth noting that the product image was not part of the source input but included here for illustrative purposes. Conversely, the generated value of *Number of pocket* for the tote bag in Figure 4(b) is both unsupported and non-factual. In this study, we aim to identify hallucinated content based on the given source product listings. Distinguishing between factual and non-factual hallucinations could facilitate taking follow-up actions on the detected hallucinations. However, verifying the correctness of hallucinations necessitates external knowledge sources, like supplementary product details or images. We leave this for future work.



Source product listing	
Name	Big Scoop Dump Truck Toy with Sandbox
Gender	Unisex
Weight	1.96 LB
LLM-generated attribute values	
Color	Yellow, Green

(a) factual hallucination



Source product listing	
Name	Simply Cool Reusable bags
Size	14.5 X 14 X 6 inches
Color	Beige
LLM-generated attribute values	
Number of pockets	2

(b) non-factual hallucination

Figure 4: Factual and non-factual hallucination.

Common sense. We observed that annotators relied on common sense to evaluate hallucination in some cases. In Figure 5, LLM suggested *Walking* as the *Recommended use* for the sandal. Human annotators considered this non-hallucinatory, given the common understanding that sandals are suitable for walking rather than activities like running or jumping. However, our method flagged this as hallucination because there was no corresponding information in the source input supporting *Walking*, and the LLM validation step failed to capture it. Unlike the factual hallucination in Figure 4(a), which is clearly unfaithful to the source input even if factual, determining hallucination becomes challenging when common sense is a factor.



Source product listing	
Name	Women's Thong Sandal
Fabric	Polyester
Color	Light Brown Leopard
LLM-generated attribute values	
Recommended use	Walking

Figure 5: Common sense.

Common sense is a subjective and evolving concept, varying among individuals based on their experiences and knowledge. For instance, what is common knowledge today, such as Apple being the manufacturer of the iPhone, may not have been widely known several years ago. To distinguish common sense from hallucination in LLMs, we can leverage their hidden knowledge or external sources. However, a precise definition of common sense versus hallucination for different use cases is essential for effective hallucination detection.

Hallucination in LLM validation. The LLM validation phase, like other LLM applications, is prone to hallucinations. Instead of developing a new hallucination detection solution, a potential strategy to address this issue is to utilize multiple responses from one or more models. However, cost is a crucial consideration in real-world industrial applications, particularly in large-scale e-commerce settings. Another alternative is fine-tuning a task-specific LLM, but this necessitates high-quality training labels.

5. Conclusions

This paper introduces an effective approach for identifying hallucinations from LLM-enriched product listings. We proposed a two-phase approach, prioritizing recall in the initial phase and enhancing precision in the subsequent phase. Our experiments on two real-world e-commerce datasets demonstrate the efficacy of our proposed approach, with better performance observed on structured attributes compared to unstructured ones. We also highlight the challenge introduced by common sense when human annotators label the data, providing valuable insights for future work.

Mô hình	D_S			D_U		
	Z	C	I	Z	C	I
T_{exact}	1.08	1.09	1.08	0.37	0.36	0.37
T_{edit}	1.08	1.09	1.08	0.37	0.36	0.37
T_{rouge}	1.01	1.05	1.00	0.36	0.36	0.37
T_{bleu}	1.08	1.07	1.05	0.36	0.36	0.37
T_{meteor}	0.97	0.99	0.99	0.36	0.35	0.39
$T_{word2vec}$	1.07	1.07	1.01	0.37	0.37	0.37
T_{glove}	1.07	1.07	1.01	0.37	0.37	0.37
$T_{fasttext}$	1.08	1.07	1.03	0.37	0.37	0.37
V_{miniLM}	1.01	1.01	1.02	0.37	0.37	0.37
V_{mpnet}	1.01	1.04	1.00	0.37	0.36	0.37
V_{gtr}	1.01	1.04	1.00	0.37	0.36	0.37
V_{qa}	1.00	1.04	1.00	0.37	0.36	0.37
V_{bert}	1.02	1.00	1.00	0.32	0.33	0.34
V_{align}	1.07	1.04	1.01	0.37	0.36	0.36
T_{exact}+V_{align}	1.10	1.07	1.04	-	-	-

Bảng 6: Hiệu suất xác thực LLM. Z biểu thị zero-shot, C biểu thị CoT, và I biểu thị học theo ngữ cảnh.

Ảo giác thực tế. Nghiên cứu này tập trung vào việc xác định thông tin sản phẩm bị ảo giác mà thiếu sự hỗ trợ từ đầu vào nguồn. Tuy nhiên, không phải tất cả các ảo giác được phát hiện đều nhất thiết là sai; một số có thể phù hợp với thông tin thực tế (Cao et al., 2021). Như minh họa trong Hình 4(a), giá trị Màu sắc do LLM tạo ra thiếu sự hỗ trợ từ đầu vào nguồn, nhưng phù hợp với hình ảnh sản phẩm. Cần lưu ý rằng hình ảnh sản phẩm không phải là một phần c ủa đầu vào nguồn nhưng được đưa vào đây để minh họa. Ngược lại, giá trị được tạo của Số túi cho túi tote trong Hình 4(b) vừa không được hỗ trợ vừa không đúng với thực tế. Trong nghiên cứu này, chúng tôi nhằm mục tiêu xác định nội dung ảo giác dựa trên danh sách sản phẩm nguồn đã cho. Phân biệt giữa ảo giác thực tế và không thực tế có thể hỗ trợ thực hiện các hành động tiếp theo đối với các ảo giác được phát hiện. Tuy nhiên, việc xác minh độ chính xác c ủa các ảo giác đòi hỏi các nguồn kiến thức bên ngoài, như các sản phẩm bổ sung



Source product listing	
Name	Big Scoop Dump Truck Toy with Sandbox
Gender	Unisex
Weight	1.96 LB
LLM-generated attribute values	
Color	Yellow, Green

(a) factual hallucination



Source product listing	
Name	Simply Cool Reusable bags
Size	14.5 X 14 X 6 inches
Color	Beige
LLM-generated attribute values	
Number of pockets	2

(b) non-factual hallucination

Hình 4: Hoang tưởng có cơ sở thực tế và không có cơ sở thực tế.

Lẽ thường. Chúng tôi quan sát thấy rằng các người chú thích dựa vào lẽ thường để đánh giá sự ảo tưởng trong một số trường hợp. Trong Hình 5, LLM đề xuất Đi bộ là cách sử dụng được khuyến nghị cho đôi dép. Con người Các người chú thích coi đây là không ảo giác, dựa trên hiểu biết phổ biến rằng dép xăng-đan phù hợp để đi bộ hơn là các hoạt động như chạy hoặc nhảy. Tuy nhiên, phương pháp của chúng tôi đã đánh dấu đây là ảo giác vì không có thông tin tương ứng trong nguồn đầu vào hỗ trợ việc đi bộ, và bước xác thực LLM đã không nắm bắt được. Không giống như ảo giác thực tế trong Hình 4(a), rõ ràng không trung thực với nguồn đầu vào ngay cả khi đúng sự thật, việc xác định ảo giác trở nên khó khăn khi yếu tố kiến thức thông thường được đưa vào.



Source product listing	
Name	Women's Thong Sandal
Fabric	Polyester
Color	Light Brown Leopard
LLM-generated attribute values	
Recommended use	Walking

Hình 5: Lẽ thường

Lý lẽ thông thường là một khái niệm chủ quan và thay đổi theo thời gian, khác nhau giữa các cá nhân dựa trên kinh nghiệm và kiến thức của họ. Ví dụ, những gì là kiến thức phổ biến ngày nay, chẳng hạn như Apple là nhà sản xuất iPhone, có thể không được nhiều người biết đến vài năm trước. Để phân biệt lý lẽ thông thường với ảo giác trong các mô hình ngôn ngữ lớn (LLM), chúng ta có thể tận dụng kiến thức tiềm ẩn của chúng hoặc các nguồn bên ngoài. Tuy nhiên, việc xác định chính xác lý lẽ thông thường so với ảo giác cho các trường hợp sử dụng khác nhau là điều cần thiết để phát hiện ảo giác một cách hiệu quả.

Ảo tưởng trong việc xác thực LLM. Giai đoạn xác thực LLM, giống như các ứng dụng LLM khác, có xu hướng xảy ra ảo tưởng. Thay vì phát triển một giải pháp phát hiện ảo tưởng mới, một chiến lược tiềm năng để giải quyết vấn đề này là sử dụng nhiều phản hồi từ một hoặc nhiều mô hình. Tuy nhiên, chi phí là một yếu tố quan trọng cần xem xét trong các ứng dụng công nghiệp thực tế, đặc biệt là trong các thiết lập thương mại điện t ử quy mô lớn. Một lựa chọn khác là tinh chỉnh một LL M cho nhiệm vụ cụ thể, nhưng điều này đòi hỏi các nhãn đào tạo chất lượng cao.

5. Kết luận

Bài báo này giới thiệu một phương pháp hiệu quả để nhận diện các thông tin ảo từ các danh sách sản phẩm được cải thiện bằng LLM. Chúng tôi đề xuất một phương pháp hai giai đoạn, ưu tiên độ nhạy trong giai đoạn ban đầu và nâng cao độ chính xác trong giai đoạn tiếp theo. Các thí nghiệm của chúng tôi trên hai bộ dữ liệu thương mại điện tử thực tế cho thấy hiệu quả của phương pháp đề xuất, với hiệu suất tốt hơn được quan sát trên các thuộc tính có cấu trúc so với các thuộc tính không có cấu trúc. Chúng tôi cũng làm nổi bật thách thức do kiến thức phổ thông tạo ra khi các nhà chú thích con người gán nhãn dữ liệu, cung cấp những hiểu biết quý giá cho các công việc trong tương lai.

6. Bibliographical References

Josh Achiam, Steven Adler, Sandhini Agarwal, Lama Ahmad, Ilge Akkaya, Florencia Leoni Aleman, Diogo Almeida, Janko Altenschmidt, Sam Altman, Shyamal Anadkat, et al. 2023. Gpt-4 technical report. *arXiv preprint arXiv:2303.08774*.

Anthropic. 2023. *Claude 2*. https://www.anthropic.com/index/claude-2 [Accessed: 2024-01-08].

Amos Azaria and Tom Mitchell. 2023. The internal state of an llm knows when its lying. *arXiv preprint arXiv:2304.13734*.

Satanjeev Banerjee and Alon Lavie. 2005. Meteor: An automatic metric for mt evaluation with improved correlation with human judgments. In *Proceedings of the acl workshop on intrinsic and extrinsic evaluation measures for machine translation and/or summarization*, pages 65–72.

Piotr Bojanowski, Edouard Grave, Armand Joulin, and Tomas Mikolov. 2016. Enriching word vectors with subword information. *arXiv preprint arXiv:1607.04606*.

Tom Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared D Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, et al. 2020. Language models are few-shot learners. *Advances in neural information processing systems*, 33:1877–1901.

Sébastien Bubeck, Varun Chandrasekaran, Ronen Eldan, Johannes Gehrke, Eric Horvitz, Ece Kamar, Peter Lee, Yin Tat Lee, Yuanzhi Li, Scott Lundberg, et al. 2023. Sparks of artificial general intelligence: Early experiments with gpt-4. *arXiv preprint arXiv:2303.12712*.

Meng Cao, Yue Dong, and Jackie Chi Kit Cheung. 2021. Hallucinated but factual! inspecting the factuality of hallucinations in abstractive summarization. *arXiv preprint arXiv:2109.09784*.

Asli Celikyilmaz, Elizabeth Clark, and Jianfeng Gao. 2020. Evaluation of text generation: A survey. *arXiv preprint arXiv:2006.14799*.

Yuyan Chen, Qiang Fu, Yichen Yuan, Zhihao Wen, Ge Fan, Dayiheng Liu, Dongmei Zhang, Zhixu Li, and Yanghua Xiao. 2023. Hallucination detection: Robustly discerning reliable answers in large language models. In *Proceedings of the 32nd ACM International Conference on Information and Knowledge Management*, pages 245–255.

Aakanksha Chowdhery, Sharan Narang, Jacob Devlin, Maarten Bosma, Gaurav Mishra, Adam Roberts, Paul Barham, Hyung Won Chung, Charles Sutton, Sebastian Gehrmann, et al. 2023. Palm: Scaling language modeling with pathways. *Journal of Machine Learning Research*, 24(240):1–113.

Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. 2018. Bert: Pre-training of deep bidirectional transformers for language understanding. *arXiv preprint arXiv:1810.04805*.

Hanyu Duan, Yixuan Tang, Yi Yang, Ahmed Abbasi, and Kar Yan Tam. 2023. Exploring the relationship between in-context learning and instruction tuning. *arXiv preprint arXiv:2311.10367*.

Grant C. Forbes, Parth Katlana, and Zeydy Ortiz. 2023. Metric ensembles for hallucination detection.

Jinlan Fu, See-Kiong Ng, Zhengbao Jiang, and Pengfei Liu. 2023. Gptscore: Evaluate as you desire. *arXiv preprint arXiv:2302.04166*.

Albert Gatt and Ehud Reiter. 2009. Simplenlg: A realisation engine for practical applications. In *Proceedings of the 12th European workshop on natural language generation (ENLG 2009)*, pages 90–93.

Jian Guan, Jesse Dodge, David Wadden, Minlie Huang, and Hao Peng. 2023. Language models hallucinate, but may excel at fact verification. *arXiv preprint arXiv:2310.14564*.

Zhijiang Guo, Michael Schlichtkrull, and Andreas Vlachos. 2022. A survey on automated fact-checking. *Transactions of the Association for Computational Linguistics*, 10:178–206.

Ziwei Ji, Nayeon Lee, Rita Frieske, Tiezheng Yu, Dan Su, Yan Xu, Etsuko Ishii, Ye Jin Bang, Andrea Madotto, and Pascale Fung. 2023. Survey of hallucination in natural language generation. *ACM Computing Surveys*, 55(12):1–38.

Takeshi Kojima, Shixiang Shane Gu, Machel Reid, Yutaka Matsuo, and Yusuke Iwasawa. 2022. Large language models are zero-shot reasoners. *URL https://arxiv. org/abs/2205.11916*.

Nayeon Lee, Wei Ping, Peng Xu, Mostofa Patwary, Pascale N Fung, Mohammad Shoeybi, and Bryan Catanzaro. 2022. Factuality enhanced language models for open-ended text generation. *Advances in Neural Information Processing Systems*, 35:34586–34599.

Vladimir I Levenshtein et al. 1966. Binary codes capable of correcting deletions, insertions, and

6. Tài liệu tham khảo

Josh Achiam, Steven Adler, Sandhini Agarwal, Lama Ahmad, Ilge Akkaya, Florencia Leoni Aleman, Diogo Almeida, Janko Altenschmidt, Sam Altman, Shyamal Anadkat, et al. 2023. Báo cáo kỹ thuật GPT-4. Bản in trước trên arXiv arXiv:2303.08774.

Anthropic. 2023. Claude 2. https: // www.anthropic.com/index/claude-2[Truy cập: 2024-01-08].

Amos Azaria và Tom Mitchell. 2023. Trạng thái nội tại của một LLM biết khi nào nó đang nói dối. Bản in trước trên arXiv arXiv:2304.13734.

Satanjeev Banerjee và Alon Lavie. 2005. Meteor: Một chỉ số tự động để đánh giá dịch máy với sự t ương quan được cải thiện với đánh giá của con người. Trong Kỷ yếu hội thảo ACL về các phương pháp đánh giá nội tại và ngoại lai cho dịch máy và/hoặc tóm tắt, trang 65–72.

Piotr Bojanowski, Edouard Grave, Armand Joulin, và Tomas Mikolov. 2016. Làm giàu các vector từ với thông tin phân từ. Bản in trước trên arXiv arXiv:1607.04606.

Tom Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared D Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, và cộng sự. 2020. Mô hình ngôn ngữ là những người học ít mẫu. Tiến bộ trong hệ thống xử lý thông tin thần kinh, 33:1877–1901.

Sébastien Bubeck, Varun Chandrasekaran, Ronen Eldan, Johannes Gehrke, Eric Horvitz, Ece Ka-mar, Peter Lee, Yin Tat Lee, Yuanzhi Li, Scott Lundberg, và những người khác. 2023. Những tia lửa của trí tuệ nhân tạo tổng quát: Các thí nghiệm ban đầu với gpt-4. arXiv preprint arXiv:2303.12712.

Meng Cao, Yue Dong, và Jackie Chi Kit Cheung. 2021. Ảo hoá nhưng thực tế! Kiểm tra tính thực tế của những ảo tưởng trong tóm tắt trừu tượng. arXiv preprint arXiv:2109.09784.

Asli Celikyilmaz, Elizabeth Clark, và Jianfeng Gao. 2020. Đánh giá sinh văn bản: Một cuộc khảo sát. Bản in trước trên arXiv arXiv:2006.14799.

Yuyan Chen, Qiang Fu, Yichen Yuan, Zhihao Wen, Ge Fan, Dayiheng Liu, Dongmei Zhang, Zhixu Li, và Yanghua Xiao. 2023. Phát hiện ảo giác: Phân biệt một cách chắc chắn các câu trả lời đáng tin cậy trong các mô hình ngôn ngữ lớn. Trong Kỷ yếu Hội nghị Quốc tế ACM lần thứ 32 về Quản lý Thông tin và Kiến thức, trang 245–255.

Aakanksha Chowdhery, Sharan Narang, Jacob Devlin, Maarten Bosma, Gaurav Mishra, Adam Roberts, Paul Barham, Hyung Won Chung, Charles Sutton, Sebastian Gehrmann, và những người khác. 2023. Palm: Mở rộng mô hình hóa ngôn ngữ với các lộ trình. Tạp chí Nghiên cứu Học máy, 24(240):1–113.

Jacob Devlin, Ming-Wei Chang, Kenton Lee, và Kristina Toutanova. 2018. Bert: Tiền huấn luyện các bộ biến đổi hai chiều sâu cho hiểu ngôn ngữ. arXiv preprint arXiv:1810.04805.

Hanyu Duan, Yixuan Tang, Yi Yang, Ahmed Abbasi, và Kar Yan Tam. 2023. Khám phá mối quan hệ giữa học theo ngữ cảnh và tinh chỉnh hướng dẫn. Bản in trước trên arXiv arXiv:2311.10367.

Grant C. Forbes, Parth Katlana, và Zeydy Ortiz. 2023. Các tập hợp chỉ số cho phát hiện ảo tưởng.

Jinlan Fu, See-Kiong Ng, Zhengbao Jiang, và Pengfei Liu. 2023. Gptscore: Đánh giá theo ý bạn. Bản thảo lưu trữ arXiv arXiv:2302.04166.

Albert Gatt và Ehud Reiter. 2009. Simplenlg: Một công cụ hiện thực hóa cho các ứng dụng thực tiễn. Trong Kỷ yếu của Hội thảo châu Âu lần thứ 12 về tạo ngôn ngữ tự nhiên (ENLG 2009), trang 90–93.

Jian Guan, Jesse Dodge, David Wadden, Minlie Huang, và Hao Peng. 2023. Mô hình ngôn ngữ có ảo giác, nhưng có thể xuất sắc trong việc xác minh sự thật. Bản in trước trên arXiv arXiv:2310.14564.

Zhijiang Guo, Michael Schlichtkrull và Andreas Vlachos. 2022. Một khảo sát về kiểm tra sự thật tự động. Transactions of the Association for Computational Linguistics, 10:178–206.

Ziwei Ji, Nayeon Lee, Rita Frieske, Tiezheng Yu, Dan Su, Yan Xu, Etsuko Ishii, Ye Jin Bang, Andrea Madotto, và Pascale Fung. 2023. Khảo sát về ảo giác trong sinh ngôn ngữ tự nhiên. ACM Computing Surveys, 55(12):1–38.

Takeshi Kojima, Shixiang Shane Gu, Machel Reid, Yutaka Matsuo và Yusuke Iwasawa. 2022. Các mô hình ngôn ngữ l ớn là những trình suy luận không cần huấn luyện trước (zero-shot). URL https://arxiv.org/abs/2205.11916.

Nayeon Lee, Wei Ping, Peng Xu, Mostofa Patwary, Pascale N Fung, Mohammad Shoeybi, và Bryan Catanzaro. 2022. Các mô hình ngôn ngữ tăng cường tính xác thực cho việc tạo văn bản mở. Advances in Neural Information Processing Systems, 35:34586–34599.

Vladimir I Levenshtein và cộng sự. 1966. Mã nhị phân có khả năng sửa lỗi xoá, chèn, và

reversals. In *Soviet physics doklady*, volume 10, pages 707–710. Soviet Union.

Chin-Yew Lin. 2004. Rouge: A package for automatic evaluation of summaries. In *Text summarization branches out*, pages 74–81.

Jiachang Liu, Dinghan Shen, Yizhe Zhang, Bill Dolan, Lawrence Carin, and Weizhu Chen. 2021. What makes good in-context examples for gpt-3? *arXiv preprint arXiv:2101.06804*.

Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, and Veselin Stoyanov. 2019. Roberta: A robustly optimized bert pretraining approach. *arXiv preprint arXiv:1907.11692*.

Zheheng Luo, Qianqian Xie, and Sophia Ananiadou. 2023. Chatgpt as a factual inconsistency evaluator for abstractive text summarization. *arXiv preprint arXiv:2303.15621*.

Potsawee Manakul, Adian Liusie, and Mark JF Gales. 2023. Selfcheckgpt: Zero-resource black-box hallucination detection for generative large language models. *arXiv preprint arXiv:2303.08896*.

Ariana Martino, Michael Iannelli, and Coleen Truong. 2023. Knowledge injection to counter large language model (llm) hallucination. In *European Semantic Web Conference*, pages 182–185. Springer.

Joshua Maynez, Shashi Narayan, Bernd Bohnet, and Ryan McDonald. 2020. On faithfulness and factuality in abstractive summarization. *arXiv preprint arXiv:2005.00661*.

Tomas Mikolov, Ilya Sutskever, Kai Chen, Greg S Corrado, and Jeff Dean. 2013. Distributed representations of words and phrases and their compositionality. *Advances in neural information processing systems*, 26.

Fedor Moiseev, Zhe Dong, Enrique Alfonseca, and Martin Jaggi. 2022. Skill: structured knowledge infusion for large language models. *arXiv preprint arXiv:2205.08184*.

Niels Mündler, Jingxuan He, Slobodan Jenko, and Martin Vechev. 2023. Self-contradictory hallucinations of large language models: Evaluation, detection and mitigation. *arXiv preprint arXiv:2305.15852*.

Ani Nenkova, Kathleen McKeown, et al. 2011. Automatic summarization. *Foundations and Trends® in Information Retrieval*, 5(2–3):103–233.

Jianmo Ni, Chen Qu, Jing Lu, Zhuyun Dai, Gustavo Hernández Ábrego, Ji Ma, Vincent Y Zhao, Yi Luan, Keith B Hall, Ming-Wei Chang, et al. 2021. Large dual encoders are generalizable retrievers. *arXiv preprint arXiv:2112.07899*.

Long Ouyang, Jeffrey Wu, Xu Jiang, Diogo Almeida, Carroll Wainwright, Pamela Mishkin, Chong Zhang, Sandhini Agarwal, Katarina Slama, Alex Ray, et al. 2022. Training language models to follow instructions with human feedback. *Advances in Neural Information Processing Systems*, 35:27730–27744.

Kishore Papineni, Salim Roukos, Todd Ward, and Wei-Jing Zhu. 2002. Bleu: a method for automatic evaluation of machine translation. In *Proceedings of the 40th annual meeting of the Association for Computational Linguistics*, pages 311–318.

Baolin Peng, Michel Galley, Pengcheng He, Hao Cheng, Yujia Xie, Yu Hu, Qiuyuan Huang, Lars Liden, Zhou Yu, Weizhu Chen, et al. 2023a. Check your facts and try again: Improving large language models with external knowledge and automated feedback. *arXiv preprint arXiv:2302.12813*.

Baolin Peng, Chunyuan Li, Pengcheng He, Michel Galley, and Jianfeng Gao. 2023b. Instruction tuning with gpt-4. *arXiv preprint arXiv:2304.03277*.

Jeffrey Pennington, Richard Socher, and Christopher D Manning. 2014. Glove: Global vectors for word representation. In *Proceedings of the 2014 conference on empirical methods in natural language processing (EMNLP)*, pages 1532–1543.

Yudiyanto Joko Purnomo. 2023. Digital marketing strategy to increase sales conversion on e-commerce platforms. *Journal of Contemporary Administration and Management (ADMAN)*, 1(2):54–62.

Alec Radford, Karthik Narasimhan, Tim Salimans, Ilya Sutskever, et al. 2018. Improving language understanding by generative pre-training. *OpenAI*.

Alec Radford, Jeffrey Wu, Rewon Child, David Luan, Dario Amodei, Ilya Sutskever, et al. 2019. Language models are unsupervised multitask learners. *OpenAI blog*, 1(8):9.

Clément Rebuffel, Marco Roberti, Laure Soulier, Geoffrey Scoutheeten, Rossella Cancelliere, and Patrick Gallinari. 2022. Controlling hallucinations at word level in data-to-text generation. *Data Mining and Knowledge Discovery*, pages 1–37.

sự đảo ngược. Trong doklady vật lý Liên Xô, tập 10, các trang 707–710. Liên Xô.

Chin-Yew Lin. 2004. Rouge: Một gói phần mềm cho đánh giá tự động các bản tóm tắt. Trong Text summarization branches out, trang 74–81.

Jiachang Liu, Dinghan Shen, Yizhe Zhang, Bill Dolan, Lawrence Carin và Weizhu Chen. 2021. Điều gì tạo nên các ví dụ trong ngữ cảnh tốt cho GPT-3? Bản in trước arXiv arXiv:2101.06804.

Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, và Veselin Stoyanov. 2019. Roberta: Một phương pháp tiền huấn luyện BERT được tối ưu hóa mạnh mẽ. arXiv preprint arXiv:1907.11692.

Zheheng Luo, Qianqian Xie, và Sophia Anani-adou. 2023. Chatgpt như một công cụ đánh giá sự không nhất quán về thực tế cho tóm tắt văn bản trừu t ượng. Bài viết tiền in arXiv arXiv:2303.15621.

Potsawee Manakul, Adian Liusie, và Mark JF Gales. 2023. Selfcheckgpt: Phát hiện ảo tưởng hộp đen không cần tài nguyên cho các mô hình ngôn ngữ lớn sinh tạo. Bài in trước trên arXiv arXiv:2303.08896.

Ariana Martino, Michael Iannelli, và Coleen Truong. 2023. Tiêm kiến thức để chống lại ảo giác của mô hình ngôn ngữ lớn (LLM). Trong Hội nghị Web Ngữ nghĩa Châu Âu, trang 182–185. Springer.

Joshua Maynez, Shashi Narayan, Bernd Bohnet, và Ryan McDonald. 2020. Về độ trung thực và tính xác thực trong tóm tắt trừu tượng. arXiv preprint arXiv:2005.00661.

Tomas Mikolov, Ilya Sutskever, Kai Chen, Greg S Corrado, và Jeff Dean. 2013. Biểu diễn phân tán của từ và cụm từ cũng như tính hợp thành của chúng. Tiến bộ trong các hệ thống xử lý thông tin thần kinh, 26.

Fedor Moiseev, Zhe Dong, Enrique Alfonseca, và Martin Jaggi. 2022. Kỹ năng: tiêm kiến thức có cấu trúc cho các mô hình ngôn ngữ lớn. Bản in trước t rên arXiv arXiv:2205.08184.

Niels Mündler, Jingxuan He, Slobodan Jenko, và Martin Vechev. 2023. Những ảo tưởng tự mâu thuẫn của các mô hình ngôn ngữ lớn: Đánh giá, phát hiện và giảm thiểu. arXiv preprint arXiv:2305.15852.

Ani Nenkova, Kathleen McKeown, và những người khác. 2011. Tóm tắt tự động. Foundations and Trends® in Information Retrieval, 5(2–3):103–233.

Jianmo Ni, Chen Qu, Jing Lu, Zhuyun Dai, Gustavo Hernández Ábrego, Ji Ma, Vincent Y Zhao, Yi Luan, Keith B Hall, Ming-Wei Chang, và các cộng sự. 2021. Bộ mã hóa kép lớn là các bộ truy xuất có khả năng tổng quát hóa. arXiv preprint arXiv:2112.07899.

LongOuyang, Jeffrey Wu, Xu Jiang, Diogo Almeida, Carroll Wainwright, Pamela Mishkin, Chong Zhang, Sandhini Agarwal, Katarina Slama, Alex Ray, và cộng sự. 2022. Huấn luyện các mô hình ngôn ngữ để tuân theo hướng dẫn với phản hồi của con người. Tiến bộ trong Hệ thống Xử lý Thông tin Thần kinh, 35:27730–27744.

Kishore Papineni, Salim Roukos, Todd Ward, và Wei-Jing Zhu. 2002. Bleu: một phương pháp đánh giá tự động dịch máy. Trong Kỷ yếu hội nghị thường niên lần thứ 40 của Hiệp hội Ngôn ngữ học Máy tính, trang 311–318.

Baolin Peng, Michel Galley, Pengcheng He, Hao Cheng, Yujia Xie, Yu Hu, Qiuyuan Huang, Lars Liden, Zhou Yu, Weizhu Chen, và những người khác. 2023a. Kiểm tra các sự thật của bạn và thử lại: Cải thiện các mô hình ngôn ngữ lớn với kiến thức bên ngoài và phản hồi tự động. Bản thảo arXiv arXiv:2302.12813.

Baolin Peng, Chunyuan Li, Pengcheng He, Michel Galley, và Jianfeng Gao. 2023b. Tinh chỉnh hướng dẫn với gpt-4. Bản in trước trên arXiv arXiv:2304.03277.

Jeffrey Pennington, Richard Socher, và Christopher D Manning. 2014. GloVe: Véc-tơ toàn cục cho biểu diễn từ. Trong Kỷ yếu hội nghị năm 2014 về các phương pháp thực nghiệm trong xử lý ngôn ngữ tự nhiên (EMNLP), trang 1532–1543.

Yudiyanto Joko Purnomo. 2023. Chiến lược tiếp thị kỹ thuật số để tăng tỷ lệ chuyển đổi bán hàng trên các nền tảng thương mại điện tử. Tạp chí Quản trị và Quản lý Hiện đại (ADMAN), 1(2):54–62.

Alec Radford, Karthik Narasimhan, Tim Salimans, Ilya Sutskever, và các cộng sự. 2018. Cải thiện khả năng hiểu ngôn ngữ bằng cách huấn luyện trước tạo sinh. OpenAI.

Alec Radford, Jeffrey Wu, Rewon Child, David Luan, Dario Amodei, Ilya Sutskever, và cộng sự. 2019. Các mô hình ngôn ngữ là những người học đa nhiệm không giám sát. Blog OpenAI, 1(8):9.

Clément Rebuffel, Marco Roberti, Laure Soulier, Geoffrey Scoutheeten, Rossella Cancelliere, và Patrick Gallinari. 2022. Kiểm soát ảo giác ở mức từ trong sinh ra văn bản từ dữ liệu. Khai thác Dữ liệu và Khám phá Kiến thức, trang 1–37.

Radim Rehurek and Petr Sojka. 2011. Gensim–python framework for vector space modelling. *NLP Centre, Faculty of Informatics, Masaryk University, Brno, Czech Republic*, 3(2).

Nils Reimers and Iryna Gurevych. 2019. Sentence-bert: Sentence embeddings using siamese bert-networks. *arXiv preprint arXiv:1908.10084*.

Ehud Reiter, Somayajulu Sripada, Jim Hunter, Jin Yu, and Ian Davy. 2005. Choosing words in computer-generated weather forecasts. *Artificial Intelligence*, 167(1-2):137–169.

Ran Tian, Shashi Narayan, Thibault Sellam, and Ankur P Parikh. 2019. Sticking to the facts: Confident decoding for faithful data-to-text generation. *arXiv preprint arXiv:1910.08684*.

Hugo Touvron, Thibaut Lavril, Gautier Izacard, Xavier Martinet, Marie-Anne Lachaux, Timothée Lacroix, Baptiste Rozière, Naman Goyal, Eric Hambro, Faisal Azhar, et al. 2023. Llama: Open and efficient foundation language models. *arXiv preprint arXiv:2302.13971*.

Neeraj Varshney, Wenlin Yao, Hongming Zhang, Jianshu Chen, and Dong Yu. 2023. A stitch in time saves nine: Detecting and mitigating hallucinations of llms by validating low-confidence generation. *arXiv preprint arXiv:2307.03987*.

Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. 2017. Attention is all you need. *Advances in neural information processing systems*, 30.

Jiaan Wang, Yunlong Liang, Fandong Meng, Haoxiang Shi, Zhixu Li, Jinan Xu, Jianfeng Qu, and Jie Zhou. 2023. Is chatgpt a good nlg evaluator? a preliminary study. *arXiv preprint arXiv:2303.04048*.

Jason Wei, Maarten Bosma, Vincent Y Zhao, Kelvin Guu, Adams Wei Yu, Brian Lester, Nan Du, Andrew M Dai, and Quoc V Le. 2021. Finetuned language models are zero-shot learners. *arXiv preprint arXiv:2109.01652*.

Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Fei Xia, Ed Chi, Quoc V Le, Denny Zhou, et al. 2022. Chain-of-thought prompting elicits reasoning in large language models. *Advances in Neural Information Processing Systems*, 35:24824–24837.

Yixuan Weng, Minjun Zhu, Fei Xia, Bin Li, Shizhu He, Shengping Liu, Bin Sun, Kang Liu, and Jun Zhao. 2023. Large language models are better reasoners with self-verification.

Mary Beth Westmoreland. 2023. *Amazon launches generative AI to help sellers write product descriptions*. https://www.aboutamazon.com/news/small-business/amazon-sellers-generative-ai-tool [Accessed: 2023-12-07].

Sam Wiseman, Stuart M Shieber, and Alexander M Rush. 2017. Challenges in data-to-document generation. *arXiv preprint arXiv:1707.08052*.

Thomas Wolf, Lysandre Debut, Victor Sanh, Julien Chaumond, Clement Delangue, Anthony Moi, Pierric Cistac, Tim Rault, Rémi Louf, Morgan Funtowicz, et al. 2019. Huggingface's transformers: State-of-the-art natural language processing. *arXiv preprint arXiv:1910.03771*.

Sang Michael Xie, Aditi Raghunathan, Percy Liang, and Tengyu Ma. 2021. An explanation of in-context learning as implicit bayesian inference. *arXiv preprint arXiv:2111.02080*.

Zhilin Yang, Zihang Dai, Yiming Yang, Jaime Carbonell, Russ R Salakhutdinov, and Quoc V Le. 2019. Xlnet: Generalized autoregressive pretraining for language understanding. *Advances in neural information processing systems*, 32.

Zhang Ze Yu, Lau Jia Jaw, Wong Qin Jiang, and Zhang Hui. 2023. Fine-tuning language models with generative adversarial feedback. *arXiv preprint arXiv:2305.06176*.

Yuheng Zha, Yichi Yang, Ruichen Li, and Zhiting Hu. 2023. Alignscore: Evaluating factual consistency with a unified alignment function. *arXiv preprint arXiv:2305.16739*.

Tianyi Zhang, Varsha Kishore, Felix Wu, Kilian Q Weinberger, and Yoav Artzi. 2019. Bertscore: Evaluating text generation with bert. *arXiv preprint arXiv:1904.09675*.

Yue Zhang, Yafu Li, Leyang Cui, Deng Cai, Lemao Liu, Tingchen Fu, Xinting Huang, Enbo Zhao, Yu Zhang, Yulong Chen, et al. 2023. Siren's song in the ai ocean: A survey on hallucination in large language models. *arXiv preprint arXiv:2309.01219*.

Chunting Zhou, Graham Neubig, Jiatao Gu, Mona Diab, Paco Guzman, Luke Zettlemoyer, and Marjan Ghazvininejad. 2020. Detecting hallucinated content in conditional neural sequence generation. *arXiv preprint arXiv:2011.02593*.

Radim Rehurek và Petr Sojka. 2011. Gensim– khuôn khổ Python cho mô hình không gian vector. Trung tâm NLPCentre, Khoa Tin học, Đại học Masaryk, Brno, Cộng hòa Séc, 3(2).

Nils Reimers và Iryna Gurevych. 2019. Se ntence-bert: Nhúng câu sử dụng mạng bert hoán đôi. Bản in trước trên arXiv arXiv:1908.10084.

Ehud Reiter, Somayajulu Sripada, Jim Hunter, Jin Yu, và Ian Davy. 2005. Chọn từ trong dự báo thời tiết do máy tính tạo ra. Trí tuệ Nhân tạo, 167(1-2):137–169.

Ran Tian, Shashi Narayan, Thibault Sellam, và Ankur P Parikh. 2019. Bám vào sự thật: Giải mã tự ti n cho việc sinh dữ liệu-thành-văn bản trung thực. Bản in trước arXiv arXiv:1910.08684.

Hugo Touvron, Thibaut Lavril, Gautier Izacard, Xavier Martinet, Marie-Anne Lachaux, Timothée Lacroix, Baptiste Rozière, Naman Goyal, Eric Hambro, Faisal Azhar, và những người khác. 2023. Llama: Mô hình ngôn ngữ nền mở và hiệu quả. Bản in trước arXiv arXiv:2302.13971.

Neeraj Varshney, Wenlin Yao, Hongming Zhang, Jianshu Chen và Dong Yu. 2023. Một mũi khâu đúng lúc cứu chín lần: Phát hiện và giảm thiểu những ảo giác của LLM bằng cách xác thực các kết quả tạo ra với độ tự tin thấp. arXiv preprint arXiv:2307.03987.

Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, và Illia Polosukhin. 2017. Chú ý là tất cả những gì bạn cần. Tiến bộ trong các hệ thống xử lý thông tin thần kinh, 30.

Jiaan Wang, YunlongLiang, Fandong Meng, Haoxiang Shi, Zhixu Li, Jinan Xu, Jianfeng Qu, và Jie Zhou. 2023. Liệu ChatGPT có phải là một công cụ đánh giá NLG tốt? một nghiên cứu sơ bộ. bản thảo arXiv arXiv:2303.04048.

Jason Wei, Maarten Bosma, Vincent Y Zhao, Kelvin Guu, Adams Wei Yu, Brian Lester, Nan Du, Andrew M Dai, và Quoc V Le. 2021. Các mô hình ngôn ngữ được tinh chỉnh là người học không cần dữ liệu huấn luyện trước. arXiv preprint arXiv:2109.01652.

Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Fei Xia, Ed Chi, Quoc V Le, Denny Zhou, và những người khác. 2022. Kích thích chuỗi suy nghĩ gợi ra khả năng lý luận trong các mô hình ngôn ngữ lớn. Tiến bộ trong Hệ thống Xử lý Thông ti n Thần kinh, 35:24824–24837.

Yixuan Weng, Minjun Zhu, Fei Xia, Bin Li, Shizhu He, Shengping Liu, Bin Sun, Kang Liu và Jun Zhao. 2023. Các mô hình ngôn ngữ lớn là những nhà lý luận tốt hơn nhờ tự xác thực.

Mary Beth Westmoreland. 2023. Amazon ra mắt AI sinh tạo để giúp người bán viết mô tả sản phẩm. https://www.aboutamazon.com/news/small-business/amazon-sellers-generative-ai-tool [Truy cập: 2023-12-07].

Sam Wiseman, Stuart M Shieber, và Alexander M Rush. 2017. Những thách thức trong việc tạo tài liệu từ dữ liệu. Bản in trước trên arXiv arXiv:1707.08052.

Thomas Wolf, Lysandre Debut, Victor Sanh, Julien Chaumond, Clement Delangue, Anthony Moi, Pierric Cistac, Tim Rault, Rémi Louf, Morgan Funtowicz, và cộng sự. 2019. Transformers của Huggingface: Xử lý ngôn ngữ tự nhiên tiên tiến nhất. arXiv preprint arXiv:1910.03771.

Sang Michael Xie, Aditi Raghunathan, Percy Liang, và Tengyu Ma. 2021. Một giải thích về học theo ngữ cảnh như suy diễn Bayes tiềm ẩn. Bản in trước trên arXiv arXiv:2111.02080.

Zhilin Yang, Zihang Dai, Yiming Yang, Jaime Carbonell, Russ R Salakhutdinov và Quoc V Le. 2019. XLNet: Huấn luyện trước tự hồi quy tổng quát cho hiểu biết ngôn ngữ. Tạp chí tiến bộ trong các hệ thống xử lý thông tin thần kinh, 32.

Zhang Ze Yu, Lau Jia Jaw, Wong Qin Jiang, và Zhang Hui. 2023. Tinh chỉnh các mô hình ngôn ngữ với phản hồi đối kháng sinh ra. Bản in trước trên arXiv arXiv:2305.06176.

Yuheng Zha, Yichi Yang, Ruichen Li, và Zhiting Hu. 2023. Alignscore: Đánh giá tính nhất quán thực tế v ới một hàm căn chỉnh thống nhất. arXiv preprint arXiv:2305.16739.

Tianyi Zhang, Varsha Kishore, Felix Wu, Kilian Q Weinberger, và Yoav Artzi. 2019. Bertscore: Đánh giá sinh văn bản với BERT. arXiv preprint arXiv:1904.09675.

Yue Zhang, Yafu Li, Leyang Cui, Deng Cai, Lemao Liu, Tingchen Fu, Xinting Huang, Enbo Zhao, Yu Zhang, Yulong Chen, và cộng sự. 2023. Bài ca của Siren trong đại dương AI: Một khảo sát về ảo giác trong các mô hình ngôn ngữ lớn. arXiv preprint arXiv:2309.01219.

Chunting Zhou, Graham Neubig, Jiatao Gu, Mona Diab, Paco Guzman, Luke Zettlemoyer, và Marjan Ghazvininejad. 2020. Phát hiện nội dung ảo trong sinh chuỗi thần kinh có điều kiện. Bản in trước ar Xiv arXiv:2011.02593.