FEVER: a large-scale dataset for Fact Extraction and VERification

James Thorne[1], **Andreas Vlachos**[1], **Christos Christodoulopoulos**[2], and **Arpit Mittal**[2]

[1]Department of Computer Science, University of Sheffield
[2]Amazon Research Cambridge
{j.thorne, a.vlachos}@sheffield.ac.uk
{chrchrs, mitarpit}@amazon.co.uk

Abstract

In this paper we introduce a new publicly available dataset for verification against textual sources, FEVER: Fact Extraction and VERification. It consists of 185,445 claims generated by altering sentences extracted from Wikipedia and subsequently verified without knowledge of the sentence they were derived from. The claims are classified as SUPPORTED, REFUTED or NOTENOUGHINFO by annotators achieving 0.6841 in Fleiss κ. For the first two classes, the annotators also recorded the sentence(s) forming the necessary evidence for their judgment. To characterize the challenge of the dataset presented, we develop a pipeline approach and compare it to suitably designed oracles. The best accuracy we achieve on labeling a claim accompanied by the correct evidence is 31.87%, while if we ignore the evidence we achieve 50.91%. Thus we believe that FEVER is a challenging testbed that will help stimulate progress on claim verification against textual sources.

1 Introduction

The ever-increasing amounts of textual information available combined with the ease in sharing it through the web has increased the demand for verification, also referred to as fact checking. While it has received a lot of attention in the context of journalism, verification is important for other domains, e.g. information in scientific publications, product reviews, etc.

In this paper we focus on verification of textual claims against textual sources. When compared to textual entailment (TE)/natural language inference (Dagan et al., 2009; Bowman et al., 2015), the key difference is that in these tasks the passage to verify each claim is given, and in recent years it typically consists a single sentence, while in verification systems it is retrieved from a large set of documents in order to form the evidence. Another related task is question answering (QA), for which approaches have recently been extended to handle large-scale resources such as Wikipedia (Chen et al., 2017). However, questions typically provide the information needed to identify the answer, while information missing from a claim can often be crucial in retrieving refuting evidence. For example, a claim stating "Fiji's largest island is Kauai." can be refuted by retrieving "Kauai is the oldest Hawaiian Island." as evidence.

Progress on the aforementioned tasks has benefited from the availability of large-scale datasets (Bowman et al., 2015; Rajpurkar et al., 2016). However, despite the rising interest in verification and fact checking among researchers, the datasets currently used for this task are limited to a few hundred claims. Indicatively, the recently conducted Fake News Challenge (Pomerleau and Rao, 2017) with 50 participating teams used a dataset consisting of 300 claims verified against 2,595 associated news articles which is orders of magnitude smaller than those used for TE and QA.

In this paper we present a new dataset for claim verification, FEVER: Fact Extraction and VERification. It consists of 185,445 claims manually verified against the introductory sections of Wikipedia pages and classified as SUPPORTED, REFUTED or NOTENOUGHINFO. For the first two classes, systems and annotators need to also return the combination of sentences forming the necessary evidence supporting or refuting the claim (see Figure 1). The claims were generated by human annotators extracting claims from Wikipedia and mutating them in a variety of ways, some of which were meaning-altering. The verification of each

Proceedings of NAACL-HLT 2018, pages 809–819
New Orleans, Louisiana, June 1 - 6, 2018. ©2018 Association for Computational Linguistics

FEVER: một bộ dữ liệu quy mô lớn cho Trích xuất và Xác minh Sự thật

James Thorne[1], **Andreas Vlachos**[1], **Christos Christodoulopoulos**[2], **và Arpit Mittal**[2]

[1]Khoa Khoa học Máy tính, Đại học Sheffield[2]Nghiên cứu
Amazon Cambridge{j.thorne, a.vlachos}@sheffield.ac.uk{
chrchrs, mitarpit}@amazon.co.uk

Tóm tắt

Trong bài báo này, chúng tôi giới thiệu một tập dữ liệu mới có sẵn công khai để xác minh so với các nguồn văn bản, FEVER: Trích xuất sự thật và Xác minh. Nó bao gồm 185.445 tuyên bố được tạo ra bằng cách chỉnh sửa các câu trích xuất từ Wikipedia và sau đó được xác minh mà không có kiến thức về câu mà chúng được trích ra. Các tuyên bố được phân loại là HỖ TRỢ, BÁC BỎ hoặc KHÔNG ĐỦ THÔNG TIN bởi các người chú thích đạt 0.6841 t heo Fleiss κ. Đối với hai lớp đầu tiên, các người chú thích cũng ghi lại câu (hoặc các câu) tạo thành bằng chứng cần thiết cho đánh giá của họ. Để đặc trưng hóa thách thức của tập dữ liệu được giới thiệu, chúng tôi phát triển một phương pháp tiếp cận theo quy trình và so sánh nó với các oracle được thiết kế phù hợp. Độ chính xác tốt nhất mà chúng tôi đạt được khi gắn nhãn một tuyên bố kèm theo bằng chứng chính xác là 31,87%, trong khi nếu chúng tôi bỏ qua bằng chứng, độ chính xác đạt 50,91%. Do đó, chúng tôi tin rằng FEVER là một bài kiểm tra đầy thử thách sẽ giúp thúc đẩy tiến bộ trong việc xác minh các tuyên bố dựa trên các nguồn văn bản.

1 Giới thiệu

Lượng thông tin văn bản ngày càng tăng kết hợp với sự dễ dàng trong việc chia sẻ nó qua web đã l àm tăng nhu cầu xác minh, còn được gọi là kiểm tr a thực tế. Mặc dù nó đã nhận được nhiều sự chú ý trong bối cảnh báo chí, việc xác minh cũng quan trọng đối với các lĩnh vực khác, ví dụ như thông tin trong các ấn phẩm khoa học, đánh giá sản phẩm, v.v.

Trong bài báo này, chúng tôi tập trung vào việc xác minh các tuyên bố văn bản dựa trên các nguồn văn bản. Khi so sánh với suy luận văn bản (TE)/suy luận ngôn ngữ tự nhiên (Dagan et al., 2009; Bowman et al., 2015), Sự khác biệt chính là trong các nhiệm vụ này, đoạn văn để xác minh mỗi tuyên bố được cung cấp sẵn, và trong những năm gần đây nó thường chỉ gồm một câu đơn, trong khi trong các hệ thống xác minh, đoạn văn được truy xuất từ một tập hợp lớn các tài liệu để hình thành bằng chứng. Một nhiệm vụ liên quan khác là trả lời câu hỏi (QA), mà các phương pháp gần đây đã được mở rộng để xử lý các nguồn tài nguyên quy mô lớn như Wikipedia (Chen et al., 2017). Tuy nhiên, các câu hỏi thường cung cấp thông tin cần thiết để xác định câu trả lời, trong khi thông tin thiếu từ một tuyên bố thường có thể rất quan trọng trong việc truy xuất bằng chứng phản bác. Ví dụ, một tuyên bố nói "Đảo lớn nhất của Fiji là Kauai." có thể bị phản bác bằng cách truy xuất "Kauai là đảo lâu đời nhất của Hawaii." làm bằng chứng.

Tiến triển trong các nhiệm vụ nêu trên đã được hưởng lợi từ việc có sẵn các tập dữ liệu quy mô lớn (Bowman et al., 2015; Rajpurkar et al., 2016). Tuy nhiên, mặc dù sự quan tâm đến việc xác minh và kiểm tra sự thật đang gia tăng trong giới nghiên cứu, các tập dữ liệu hiện đang được sử dụng cho nhiệm vụ này vẫn chỉ giới hạn trong vài trăm tuyên bố. Cụ thể, cuộc thi FakeNewsChallenge gần đây (Pomerleau và Rao, 2017) với 50 đội tham gia đã sử dụng một tập dữ liệu bao gồm 300 tuyên bố được xác minh dựa trên 2.595 bài báo liên quan, con số này nhỏ hơn nhiều so với những gì được sử dụng cho TE và QA.

Trong bài báo này, chúng tôi giới thiệu một bộ dữ liệu mới cho việc xác minh tuyên bố, FEVER: Trích xuất Thực tế và Xác minh. Nó bao gồm 185.445 tuyên bố được xác minh thủ công dựa trên các phần giới thiệu của các trang Wikipedia và được phân loại thành HỖ TRỢ, BỊ PHỦ NHẬN hoặc KHÔNG ĐỦ THÔNG TIN. Đối với hai lớp đầu tiên, các hệ thống và người chú thích cũng cần phải trả về tổ hợp các câu tạo nên bằng chứng cần thiết để hỗ trợ hoặc bác bỏ tuyên bố (xem Hình 1). Các tuyên bố được tạo ra bởi các người chú thích con người bằng cách trích xuất tuyên bố từ Wikipedia và biến đổi chúng theo nhiều cách khác nhau, một số trong đó làm thay đổi ý nghĩa. Việc xác minh mỗi

Kỷ yếu NAACL-HLT 2018, trang 809–819 New Orleans, Louisiana, 1 - 6 tháng 6, 2018. c◯2018 Hiệp hội Ngôn ngữ học Máy tính

claim was conducted in a separate annotation process by annotators who were aware of the page but not the sentence from which original claim was extracted and thus in 31.75% of the claims more than one sentence was considered appropriate evidence. Claims require composition of evidence from multiple sentences in 16.82% of cases. Furthermore, in 12.15% of the claims, this evidence was taken from multiple pages.

To ensure annotation consistency, we developed suitable guidelines and user interfaces, resulting in inter-annotator agreement of 0.6841 in Fleiss κ (Fleiss, 1971) in claim verification classification, and 95.42% precision and 72.36% recall in evidence retrieval.

To characterize the challenges posed by FEVER we develop a pipeline approach which, given a claim, first identifies relevant documents, then selects sentences forming the evidence from the documents and finally classifies the claim w.r.t. evidence. The best performing version achieves 31.87% accuracy in verification when requiring correct evidence to be retrieved for claims SUPPORTED or REFUTED, and 50.91% if the correctness of the evidence is ignored, both indicating the difficulty but also the feasibility of the task. We also conducted oracle experiments in which components of the pipeline were replaced by the gold standard annotations, and observed that the most challenging part of the task is selecting the sentences containing the evidence. In addition to publishing the data via our website[1], we also publish the annotation interfaces[2] and the baseline system[3] to stimulate further research on verification.

2 Related Works

Vlachos and Riedel (2014) constructed a dataset for claim verification consisting of 106 claims, selecting data from fact-checking websites such as PolitiFact, taking advantage of the labelled claims available there. However, in order to develop claim verification components we typically require the justification for each verdict, including the sources used. While this information is usually available in justifications provided by the journalists, they are not in a machine-readable form. Thus, also considering the small number of claims, the task defined by the dataset proposed

[1] http://fever.ai
[2] https://github.com/awslabs/fever
[3] https://github.com/sheffieldnlp/fever-baselines

Claim: The Rodney King riots took place in the most populous county in the USA.

[wiki/Los_Angeles_Riots]

The 1992 Los Angeles riots, also known as the Rodney King riots were a series of riots, lootings, arsons, and civil disturbances that occurred in Los Angeles County, California in April and May 1992.

[wiki/Los_Angeles_County]

Los Angeles County, officially the County of Los Angeles, is the most populous county in the USA.

Verdict: Supported

Figure 1: Manually verified claim requiring evidence from multiple Wikipedia pages.

remains too challenging for the ML/NLP methods currently available. Wang (2017) extended this approach by including all 12.8K claims available by Politifact via its API, however the justification and the evidence contained in it was ignored in the experiments as it was not machine-readable. Instead, the claims were classified considering only the text and the metadata related to the person making the claim. While this rendered the task amenable to current NLP/ML methods, it does not allow for verification against any sources and no evidence needs to be returned to justify the verdicts.

The Fake News challenge (Pomerleau and Rao, 2017) modelled verification as stance classification: given a claim and an article, predict whether the article supports, refutes, observes (neutrally states the claim) or is irrelevant to the claim. It consists of 50K labelled claim-article pairs, combining 300 claims with 2,582 articles. The claims and the articles were curated and labeled by journalists in the context of the Emergent Project (Silverman, 2015), and the dataset was first proposed by Ferreira and Vlachos (2016), who only classified the claim w.r.t. the article headline instead of the whole article. Similar to recognizing textual entailment (RTE) (Dagan et al., 2009), the systems were provided with the sources to verify against, instead of having to retrieve them.

A differently motivated but closely related dataset is the one developed by Angeli and Manning (2014) to evaluate natural logic inference for common sense reasoning, as it evaluated sim-

Yêu cầu được thực hiện trong một quá trình chú thích riêng biệt bởi các người chú thích biết về trang nhưng không biết câu từ đó mà yêu cầu gốc được trích xuất và do đó trong 31,75% các yêu cầu, nhiều hơn một câu được coi là bằng chứng thích hợp. Các yêu cầu đòi hỏi việc tổng hợp bằng chứng từ nhiều câu trong 16,82% các trường hợp. Hơn nữa, trong 12,15% các yêu cầu, bằng chứng này được lấy từ nhiều trang.

Để đảm bảo tính nhất quán trong chú thích, chúng tôi đã phát triển các hướng dẫn và giao diện người dùng phù hợp, kết quả là mức độ đồng t huận giữa các chú thích viên đạt 0,6841 theo Fleiss κ (Fleiss, 1971) trong phân loại xác minh tuyên bố, và độ chính xác 95,42% cùng độ thu hồi 72,36% trong việc truy xuất bằng chứng.

Để đặc trưng hóa các thách thức do FEVER đặt ra, chúng tôi phát triển một phương pháp theo chuỗi các bước mà, khi nhận một tuyên bố, đầu tiên xác định các tài liệu liên quan, sau đó chọn các câu tạo thành bằng chứng từ các tài liệu và cuối cùng phân loại tuyên bố liên quan đến bằng c hứng. Phiên bản có hiệu suất tốt nhất đạt độ chính xác 31,87% trong việc xác minh khi yêu cầu phải truy xuất chính xác bằng chứng cho các tuyên bố ĐƯỢC HỖ TRỢ hoặc BỊ PHỦ NHẬN, và 50,91% nếu bỏ qua độ chính xác của bằng chứng, cả hai đều c hỉ ra sự khó khăn nhưng cũng khả năng thực hiện của nhiệm vụ. Chúng tôi cũng đã thực hiện các thí nghiệm oracle trong đó các thành phần của chuỗi bước được thay thế bằng các chú thích tiêu chuẩn vàng, và quan sát thấy phần khó khăn nhất của nhiệm vụ là chọn các câu chứa bằng chứng. Ngoài việc công bố dữ liệu qua trang web của chúng tôi[1], , chúng tôi cũng công bố các giao diện chú thích[2] và hệ thống cơ sở[3] để kích thích nghiên cứu thêm về việc xác minh.

2 Công trình liên quan

Vlachos và Riedel (2014) đã xây dựng một bộ dữ liệu để xác minh các tuyên bố gồm 106 tuyên bố, chọn dữ liệu từ các trang web kiểm chứng sự thật như PolitiFact, tận dụng các tuyên bố đã được gán nhãn có sẵn ở đó. Tuy nhiên, để phát triển các thành phần xác minh tuyên bố, chúng ta thường cần lý do cho mỗi phán quyết, bao gồm cả các nguồn được sử dụng. Mặc dù thông tin này thường có sẵn trong các lý do do các nhà báo cung cấp, nhưng chúng không ở dạng có thể đọc được bằng máy. Do đó, cũng xét đến số lượng tuyên bố nhỏ, nhiệm vụ được định nghĩa bởi bộ dữ liệu được đề xuất

[1] http://fever.ai[2]https://github.com/awslabs/fever[3] https://github.com/sheffieldnlp/fever-baselines

Khẳng định: Các cuộc bạo loạn Rodney King xảy ra ở quận đông dân nhất ở Hoa Kỳ.

[wiki/Bạo loạn Los Angeles]

Các vụ bạo loạn Los Angeles năm 1992, còn được biết đến với tên gọi là các vụ bạo l oạn ~~Rodney King, là một loạt các vụ bạo loạ~~n, cướp bóc, phóng hỏa và rối loạn dân sự xảy ra tại Quận Los Angeles, California vào tháng 4 và tháng 5 năm 1992. Quận Los Angeles, chính thức là Quận Los Angeles, là quận đông dân nhất ở Hoa Kỳ. Phán quyết: Hỗ trợ

Hình 1: Yêu cầu chứng cứ từ nhiều trang Wikipedia cho tuyên bố đã được xác minh thủ công.

vẫn quá thách thức đối với các phương pháp ML/NLP hiện có. Wang (2017) đã mở rộng phương pháp này bằng cách bao gồm tất cả 12,8 nghìn tuyên bố có sẵn từ Politifact thông qua API của nó, tuy nhiên, phần biện minh và bằng chứng chứa trong đó đã bị bỏ qua trong các thí nghiệm vì nó không thể đọc được bằng máy. Thay vào đó, các tuyên bố chỉ được phân loại dựa trên văn bản và siêu dữ liệu liên quan đến người đưa ra tuyên bố. Mặc dù điều này làm cho nhiệm vụ trở nên khả thi với các phương pháp NLP/ML hiện tại, nhưng nó không cho phép xác minh với bất kỳ nguồn nào và không cần phải cung cấp bằng chứng để lý giải cho các phán quyết.

Thách thức Tin tức giả mạo (Pomerleau và Rao, 2017) mô hình hóa việc xác minh như phân loại lập trường: cho một tuyên bố và một bài báo, dự đoán xem bài báo đó ủng hộ, bác bỏ, quan sát (nêu trung lập tuyên bố) hay không liên quan đến tuyên bố. Nó bao gồm 50 nghìn cặp tuyên bố-bài báo có nhãn, kết hợp 300 tuyên bố với 2.582 bài báo. Các tuyên bố và bài báo được các nhà báo chọn lọc và gán nhãn trong bối cảnh Dự án Emergent (Silverman, 2015), và bộ dữ liệu này lần đầu tiên được đề xuất bởi Ferreira và Vlachos (2016), những người chỉ phân loại tuyên bố liên quan đến tiêu đề bài báo thay vì toàn bộ bài báo. Tương tự như việc nhận diện hàm ý văn bản (RTE) (Dagan et al., 2009), các hệ thống được cung cấp các nguồn để xác minh, thay vì phải truy xuất chúng.

Một tập dữ liệu có động cơ khác nhưng liên quan chặt chẽ là tập dữ liệu được phát triển bởi Angeli và Manning (2014) để đánh giá suy luận logic tự nhiên cho lý luận thường thức, khi nó được đánh giá như

ple claims such as “not all birds can fly” against textual sources — including Wikipedia — which were processed with an Open Information Extraction system (Mausam et al., 2012). However, the claims were small in number (1,378) and limited in variety as they were derived from eight binary ConceptNet relations (Tandon et al., 2011).

Claim verification is also related to the multilingual Answer Validation Exercise (Rodrigo et al., 2009) conducted in the context of the TREC shared tasks. Apart from the difference in dataset size (1,000 instances per language), the key difference is that the claims being validated were answers returned to questions by QA systems. The questions and the QA systems themselves provide additional context to the claim, while in our task definition the claims are outside any particular context. In the same vein, Kobayashi et al. (2017) collected a dataset of 412 statements in context from high-school student exams that were validated against Wikipedia and history textbooks.

3 Fact extraction and verification dataset

The dataset was constructed in two stages[4] :

Claim Generation Extracting information from Wikipedia and generating claims from it.

Claim Labeling Classifying whether a claim is supported or refuted by Wikipedia and selecting the evidence for it, or deciding there’s not enough information to make a decision.

3.1 Task 1 - Claim Generation

The objective of this task was to generate claims from information extracted from Wikipedia. We used the June 2017 Wikipedia dump, processed it with Stanford CoreNLP (Manning et al., 2014), and sampled sentences from the introductory sections of approximately 50,000 popular pages.[5]

The annotators were given a sentence from the sample chosen at random, and were asked to generate a set of **claims** containing a single piece of information, focusing on the entity that its original Wikipedia page was about. We asked the annotators to generate claims about a single fact which could be arbitrarily complex and allowed for a variety of expressions for the entities.

If only the source sentences were used to generate claims then this would result in trivially verifiable claims, as the new claims would in essence be simplifications and paraphrases. At the other extreme, if we allowed world knowledge to be freely incorporated it would result in claims that would be hard to verify on Wikipedia alone. We address this issue by introducing a **dictionary**: a list of terms that were (hyper-)linked in the original sentence, along with the first sentence from their corresponding Wikipedia pages. Using this dictionary, we provide additional knowledge that can be used to increase the complexity of the generated claims in a controlled manner.

The annotators were also asked to generate **mutations** of the claims: altered versions of the original claims, which may or may not change whether they are supported by Wikipedia, or even if they can be verified against it. Inspired by the operators used in Natural Logic Inference (Angeli and Manning, 2014), we specified six types of mutation: paraphrasing, negation, substitution of an entity/relation with a similar/dissimilar one, and making the claim more general/specific.

During trials of the annotation task, we discovered that the majority of annotators had difficulty generating non-trivial negation mutations (e.g. mutations beyond adding “not” to the original). Besides providing numerous examples for each mutation, we also redesigned the annotation interface so that all mutation types were visible at once and highlighted mutations that contained “not” in order to discourage trivial negations. Finally, we provided the annotators with an ontology diagram to illustrate the different levels of entity similarity and class membership.

This process resulted in claims (both extracted and mutated) with a mean length of 9.4 tokens which is comparable to the average hypothesis length of 8.3 tokens in Bowman et al. (2015).

3.2 Task 2 - Claim Labeling

The annotators were asked to label each individual claim generated during Task 1 as SUPPORTED, REFUTED or NOTENOUGHINFO. For the first two cases, the annotators were asked to find the evidence from any page that supports or refutes the claim (see Figure 2 for a screenshot of the interface). In order to encourage inter-annotator consistency, we gave the following general guideline:

[4]The annotation guidelines for both stages are provided in the supplementary materials

[5]These consisted of 5,000 from a Wikipedia ‘most accessed pages’ list and the pages hyperlinked from them.

những tuyên bố như “không phải tất cả các loài chim đều có thể bay” đối chiếu với các nguồn văn bản — bao gồm Wikipedia — đã được xử lý bằng một hệ thống Trích xuất Thông tin Mở (Mausam et al., 2012). Tuy nhiên, các tuyên bố này có số lượng nhỏ (1.378) và hạn chế về đa dạng vì chúng được lấy từ tám mối quan hệ nhị phân của ConceptNet (Tandon et al., 2011).

Xác minh tuyên bố cũng liên quan đến Bài tập Xác thực Câu trả lời đa ngôn ngữ (Rodrigo et al., 2009) được thực hiện trong bối cảnh các nhiệm vụ chia sẻ TREC. Ngoài sự khác biệt về kích thước tập dữ liệu (1.000 mục một ngôn ngữ), điểm khác biệt chính là các tuyên bố được xác minh là câu trả lời trả về cho các câu hỏi bởi các hệ thống QA. Các câu hỏi và chính các hệ thống QA cung cấp bối cảnh bổ sung cho tuyên bố, trong khi trong định nghĩa nhiệm vụ của chúng tôi, các tuyên bố nằm ngoài bất kỳ bối cảnh cụ thể nào. Theo cùng một hướng, Kobayashi et al. (2017) đã thu thập một tập dữ liệu gồm 412 phát biểu trong bối cảnh từ các kỳ thi học sinh trung học được xác minh so với Wikipedia và sách giáo khoa lịch sử.

3 Dữ liệu trích xuất và xác minh sự thật et

Bộ dữ liệu được xây dựng trong hai giai đoạn:

Tạo tuyên bố Trích xuất thông tin từ Wikipedia và tạo các tuyên bố từ nó.

Gắn nhãn tuyên bố Phân loại xem một tuyên bố được Wikipedia ủng hộ hay bác bỏ và chọn bằng chứng cho nó, hoặc quyết định rằng không có đủ thông tin để đưa ra quyết định.

3.1 Nhiệm vụ 1 - Tạo Yêu cầu

Mục tiêu của nhiệm vụ này là tạo ra các phát biểu từ thông tin được trích xuất từ Wikipedia. Chúng tôi sử dụng bản sao Wikipedia vào tháng 6 năm 2017, xử lý nó bằng Stanford CoreNLP (Manning và cộng sự, 2014), và lấy mẫu các câu từ các phần giới thiệu của khoảng 50.000 trang phổ biến.

Các người chú thích được đưa một câu từ mẫu được chọn ngẫu nhiên, và được yêu cầu tạo ra một tập hợp các tuyên bố chứa một mẩu thông tin duy nhất, tập trung vào thực thể mà trang Wikipedia gốc của nó nói về. Chúng tôi yêu cầu các người chú thích tạo các tuyên bố về một sự thật duy nhất có thể phức tạp tùy ý và cho phép nhiều cách biểu đạt khác nhau cho các thực thể.

[4]Hướng dẫn chú thích cho cả hai giai đoạn được cung cấp trong tài liệu bổ sung[5]Chúng bao gồm 5.000 trang từ danh sách ‘ trang được truy cập nhiều nhất’ của Wikipedia và các trang được liên kết từ chúng.

Nếu chỉ sử dụng các câu gốc để tạo ra các t uyên bố thì điều này sẽ dẫn đến các tuyên bố dễ kiểm chứng một cách đơn giản, vì các tuyên bố mới về cơ bản sẽ là những sự đơn giản hóa và diễn giải lại. Ở cực khác, nếu chúng ta cho phép kiến thức về thế giới được tự do kết hợp thì sẽ dẫn đến các tuyên bố khó kiểm chứng chỉ dựa trên Wikipedia. Chúng tôi giải quyết vấn đề này bằng cách giới thiệu một từ điển: một danh sách các thuật ngữ đã được (siêu) liên kết trong câu gốc, cùng với câu đầu tiên từ các trang Wikipedia t ương ứng của chúng. Sử dụng từ điển này, chúng tôi cung cấp thêm kiến thức có thể được dùng để tăng độ phức tạp của các tuyên bố được tạo ra một cách có kiểm soát.

Các người chú thích cũng được yêu cầu tạo ra các biến thể của các tuyên bố: các phiên bản đã thay đổi của các tuyên bố gốc, có thể thay đổi hoặc không thay đổi việc chúng có được Wikipedia hỗ trợ hay thậm chí có thể được xác minh dựa trên đó hay không. Lấy cả m hứng từ các toán tử được sử dụng trong Suy luận Logic Tự nhiên (Angeli và Manning, 2014), chúng tôi đã chỉ định sáu loại biến thể: diễn giải lại, phủ định, thay thế một thực thể/mối quan hệ bằng một thực thể/mối quan hệ tương tự/khác, và làm cho tuyên bố chung hơn/cụ thể hơn.

Trong quá trình thử nghiệm nhiệm vụ chú thích, chúng tôi nhận ra rằng phần lớn những người chú thích gặp khó khăn trong việc tạo ra những biến đổi phủ định không tầm thường (ví dụ: các biến đổi vượt ra ngoài việc thêm “không” vào bản gốc). Bên cạnh việc cung cấp nhiều ví dụ cho mỗi loại biến đổi, chúng tôi cũng đã thiết kế lại giao diện chú thích để tất cả các loại biến đổi đều hiển thị cùng một lúc và làm nổi bật các biến đổi c ó chứa “không” nhằm ngăn chặn các phủ định tầ m thường. Cuối cùng, chúng tôi đã cung cấp cho những người chú thích một sơ đồ hệ thống từ để minh họa các mức độ tương đồng giữa các thực thể và sự thuộc lớp khác nhau.

Quá trình này dẫn đến các câu tuyên bố (cả trích xuất và biến đổi) có độ dài trung bình là 9,4 token, điều này tương đương với độ dài trung bình của giả thuyết là 8,3 token trong Bowman và cộng sự (2015).

3.2 Nhiệm vụ 2 - Gán nhãn yêu cầu

Các chú thích viên được yêu cầu gán nhãn cho t ừng tuyên bố riêng lẻ được tạo ra trong Nhiệm vụ 1 là HỖ TRỢ, PHỦ NHẬN hoặc KHÔNG ĐỦ THÔNG TIN. Đối với hai trường hợp đầu tiên, các chú thích viên được yêu cầu tìm bằng chứng từ bất kỳ trang nào hỗ trợ hoặc phản bác tuyên bố (xem Hình 2 để xem ảnh chụp giao diện). Nhằm khuyến khích sự nhất quán giữa các chú thích viên, chúng tôi đã đưa ra hướng dẫn chung sau:

> If I was given only the selected sentences, do I have strong reason to believe the claim is true (supported) or stronger reason to believe the claim is false (refuted). If I'm not certain, what additional information (dictionary) do I have to add to reach this conclusion.

In the annotation interface, all sentences from the introductory section of the page for the main entity of the claim and of every linked entity in those sentences were provided as a default source of evidence (left-hand side in Fig. 2). Using this interface the annotators recorded the sentences necessary to justify their classification decisions. In order to allow exploration beyond the main and linked pages, we also allowed annotators to add an arbitrary Wikipedia page by providing its URL and the system would add its introductory section as additional sentences that could be then selected as evidence (right-hand side in Fig. 2). The title of the page could also be used as evidence to resolve co-reference, but this decision was not explicitly recorded. We did not set a hard time limit for the task, but the annotators were advised not to spend more than 2-3 minutes per claim. The label NOTENOUGHINFO was used if the claim could not be supported or refuted by any amount of information in Wikipedia (either because it is too general, or too specific).

3.3 Annotators

The annotation team consisted of a total of 50 members, 25 of which were involved only in the first task. All annotators were native US English speakers and were trained either directly by the authors, or by experienced annotators. The interface for both tasks was developed by the authors in collaboration with an initial team of two annotators. Their notes and suggestions were incorporated into the annotation guidelines.

The majority of the feedback received from the annotators was very positive: they found the task engaging and challenging, and after the initial stages of annotation they had developed an understanding of the needs of the task which let them discuss solutions about edge cases as a group.

3.4 Data Validation

Given the complexity of the second task (claim labeling), we conducted three forms of data validation: 5-way inter-annotator agreement, agreement against *super-annotators* (defined in Section 3.4.2), and manual validation by the authors. The validation for claim generation was done implicitly during claim labeling. As a result 1.01% of claims were skipped, 2.11% contained typos and 6.63% of the generated claims were flagged as too vague/ambiguous and were excluded e.g. or "Sons of Anarchy premiered.".

3.4.1 5-way Agreement

We randomly selected 4% ($n = 7506$) of claims which were not skipped to be annotated by 5 annotators. We calculated the Fleiss κ score (Fleiss, 1971) to be 0.6841 which we consider encouraging given the complexity of the task. In comparison Bowman et al. (2015) reported a κ of 0.7 for a simpler task, since the annotators were given the premise/evidence to verify a hypothesis against without the additional task of finding it.

3.4.2 Agreement against *Super-Annotators*

We randomly selected 1% of the data to be annotated by *super-annotators*: expert annotators with no suggested time restrictions. The purpose of this exercise was to provide as much coverage of evidence as possible. We instructed the *super-annotators* to search over the whole Wikipedia for every possible sentence that could be used as evidence. We compared the regular annotations against this set of evidence and the precision/recall was 95.42% and 72.36% respectively.

3.4.3 Validation by the Authors

As a final quality control step, we chose 227 examples and annotated them for accuracy of the labels and the evidence provided. We found that 91.2% of the examples were annotated correctly. 3% of the claims were mistakes in claim generation that had not been flagged during labeling. We found a similar number of these claims which did not meet the guidelines during a manual error analysis of the baseline system (Section 5.8).

3.4.4 Findings

When compared against the *super-annotators*, all except two annotators achieved $> 90\%$ precision and all but 9 achieved recall $> 70\%$ in evidence retrieval. The majority of the low-recall cases are for claims such as "Akshay Kumar is an actor." where the *super-annotator* added 34 sentences as evidence, most of them being filmography listings (e.g. "In 2000, he starred in the Priyadarshan-directed comedy Hera Pheri").

> Nếu tôi chỉ được cung cấp những câu đã chọn, liệu tôi có lý do mạnh mẽ để tin rằng tuyên bố là đúng (được hỗ trợ) hay lý do mạnh hơn để tin rằng tuyên bố là sai (bị bác bỏ). Nếu tôi k hông chắc chắn, thì thông tin bổ sung (t ừ điển) nào tôi cần thêm để đạt được kết luận này.

Trong giao diện chú thích, tất cả các câu từ phần giới thiệu của trang cho thực thể chính của tuyên bố và của mọi thực thể liên kết trong những câu đó được cung cấp như nguồn bằng chứng mặc định (bên trái trong Hình 2). Sử dụng giao diện này, các annotator ghi lại các câu cần thiết để biện minh cho quyết định phân loại của họ. Để cho phép khám phá vượt ra ngoài các trang chính và liên kết, chúng tôi cũng cho phép các annotator thêm một trang Wikipedia tùy ý bằng cách cung cấp URL của nó và hệ thống sẽ thêm phần giới thiệu của nó như các câu bổ sung, sau đó có thể được chọn làm bằng chứng (bên phải trong Hình 2). Tiêu đề của trang cũng có thể được sử dụng là m bằng chứng để giải quyết đồng tham chiếu, nhưng quyết định này không được ghi lại một cách rõ ràng. Chúng tôi không đặt giới hạn thời gian cứng cho nhiệm vụ, nhưng các annotator được khuyên không nên dành quá 2-3 phút cho mỗi tuyên bố. Nhãn NOTENOUGHINFO được sử dụng nếu tuyên bố không thể được hỗ trợ hoặc bác bỏ bởi bất kỳ lượng thông tin nào.

3.3 Những người chú thích

Nhóm chú thích bao gồm tổng cộng 50 thành viên, trong đó 25 người chỉ tham gia vào nhiệm vụ đầu tiên. Tất cả những người chú thích đều là người bản ngữ tiếng Anh Mỹ và được đào tạo trực tiếp bởi các tác giả, hoặc bởi các annotator có kinh nghiệm. Giao diện cho cả hai nhiệm vụ được phát triển bởi các tác giả phối hợp với một nhóm ban đầu gồm hai annotator. Các ghi chú và đề xuất của họ đã được đưa vào hướng dẫn chú thích.

Phần lớn phản hồi nhận được từ những người chú thích là rất tích cực: họ thấy nhiệm vụ thú vị và đầy thử thách, và sau giai đoạn đầu của việc c hú thích, họ đã phát triển được sự hiểu biết về nhu cầu của nhiệm vụ, điều này cho phép họ thảo luận về các giải pháp cho các trường hợp đặc biệt theo nhóm.

3.4 Xác thực dữ liệu

Với độ phức tạp của nhiệm vụ thứ hai (gán nhãn yêu cầu), chúng tôi đã tiến hành ba hình thức xác thực dữ liệu: thỏa thuận giữa các người chú thích 5 chiều, thỏa thuận kiểm tra đối với các siêu chú thích (được định nghĩa trong Mục 3.4.2), và xác thực thủ công bởi các tác giả. Việc xác thực cho việc tạo lập tuyên bố đã được thực hiện một cách ngầm định trong quá trình gán nhãn tuyên bố. Kết quả là 1,01% các tuyên bố bị bỏ qua, 2,11% chứa lỗi chính tả và 6,63% các tuyên bố được tạo ra bị đánh dấu là quá mơ hồ/không rõ ràng và bị loại, ví dụ như "Sons of Anarchy phát sóng lần đầu.".

3.4.1 Thỏa thuận 5 bên

Chúng tôi đã chọn ngẫu nhiên 4% ($n = 7506$) các tuyên bố mà không bị bỏ qua để được chú thích bởi 5 người chú thích. Chúng tôi đã tính điểm Fleiss κ (Fleiss, 1971) là 0,6841, điều mà chúng tôi coi là đáng khích lệ với tính phức tạp của nhiệm vụ. So sánh, Bowman et al. (2015) báo cáo κ là 0,7 cho một nhiệm vụ đơn giản hơn, vì các người chú thích được cung cấp cơ sở/ bằng chứng để xác minh một giả thuyết mà không có nhiệm vụ bổ sung là tìm kiếm nó.

3.4.2 Thỏa thuận chống lại các Siêu Ghi Chú

Chúng tôi đã chọn ngẫu nhiên 1% dữ liệu để được chú thích bởi các siêu chú thích viên: những chuyên gia chú thích không bị giới hạn về thời gian. Mục đích của bài tập này là cung cấp càng nhiều bằng chứng càng tốt. Chúng tôi đã hướng dẫn các siêu chú thích viên tìm kiếm trên toàn bộ Wikipedia cho mọi câu có thể được sử dụng làm bằng chứng. Chúng tôi đã so sánh các chú thích thông thường với tập bằng chứng này và độ chính xác/độ bao phủ lần lượt là 95,42% và 72,36%.

3.4.3 Xác thực bởi các Tác giả

Như một bước kiểm soát chất lượng cuối cùng, chúng tôi đã chọn 227 ví dụ và chú thích chúng về độ chính xác của nhãn và bằng chứng được cung cấp. Chúng tôi nhận thấy rằng 91,2% các ví dụ đã được chú thích chính xác. 3% các tuyên bố là lỗi trong việc tạo tuyên bố mà không được phát hiện trong quá trình gán nhãn. Chúng tôi cũng tìm thấy một số lượng tương tự các tuyên bố này không đáp ứng các hướng dẫn trong quá trình phân tích lỗi thủ công của hệ thống cơ sở (Mục 5.8).

3.4.4 Kết quả

Khi so sánh với các siêu chú thích viên, tất cả ngoại trừ hai chú thích viên đạt độ chính xác $> 90\%$ và tất cả ngoại trừ 9 người đạt độ nhắc lại $> 70\%$ trong việc truy xuất bằng chứng. Phần lớn các trường hợp đạt độ nhắc lại thấp là đối với những tuyên bố như "Akshay Kumar là một diễn viên.", nơi siêu chú thích viên đã thêm 34 câu làm bằng chứng, hầu hết trong số đó là danh sách phim (ví dụ: "Năm 2000, anh đóng vai chính trong bộ phim hài Hera Pheri do Priyadarshan đạo diễn").

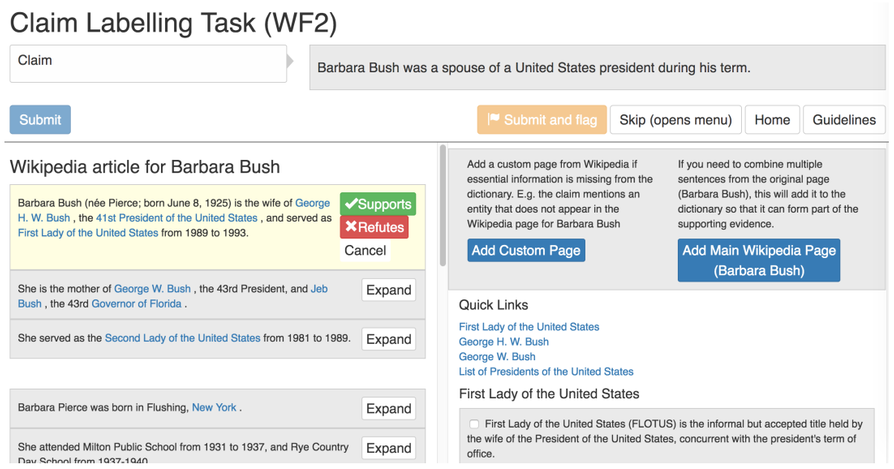


Figure 2: Screenshot of Task 2 - Claim Labeling

During the validation by the authors, we found that most of the examples that were annotated incorrectly were cases where the label was correct, but the evidence selected was not sufficient (only 4 out of 227 examples were labeled incorrectly according to the guidelines).

We tried to resolve this issue by asking our annotators to err on the side of caution. For example, while the claim "Shakira is Canadian" could be labeled as REFUTED by the sentence "Shakira is a Colombian singer, songwriter, dancer, and record producer", we advocated that unless more explicit evidence is provided (e.g. "She was denied Canadian citizenship"), the claim should be labeled as NOTENOUGHINFO, since dual citizenships are permitted, and the annotators' world knowledge should not be factored in.

A related issue is entity resolution. For a claim like "David Beckham was with United.", it might be trivial for an annotator to accept "David Beckham made his European League debut playing for Manchester United." as supporting evidence. This implicitly assumes that "United" refers to "Manchester United", however there are many Uniteds in Wikipedia and not just football clubs, e.g. United Airlines. The annotators knew the page of the main entity and thus it was relatively easy to resolve ambiguous entities. While we provide this information as part of the dataset, we argue that it should only be used for system training/development.

4 Baseline System Description

We construct a simple pipelined system comprising three components: document retrieval, sentence-level evidence selection and textual entailment. Each component is evaluated in isolation through oracle evaluations on the development set and we report the final accuracies on the test set.

Document Retrieval We use the document retrieval component from the DrQA system (Chen et al., 2017) which returns the k nearest documents for a query using cosine similarity between binned unigram and bigram Term Frequency-Inverse Document Frequency (TF-IDF) vectors.

Sentence Selection Our simple sentence selection method ranks sentences by TF-IDF similarity to the claim. We sort the most-similar sentences first and tune a cut-off using validation accuracy on the development set. We evaluate both DrQA and a simple unigram TF-IDF implementation to rank the sentences for selection. We further evaluate impact of sentence selection on the RTE module by predicting entailment given the original documents without sentence selection.

Recognizing Textual Entailment We compare two models for recognizing textual entailment. For a simple well-performing baseline, we selected Riedel et al. (2017)'s submission from the 2017 Fake News Challenge. It is a multi-layer perceptron (**MLP**) with a single hidden layer which uses term frequencies and TF-IDF cosine similarity between the claim and evidence as features.



Hình 2: Ảnh chụp màn hình của Nhiệm vụ 2 - Gán nhãn Yêu cầu

Trong quá trình xác thực bởi các tác giả, chúng tôi nhận thấy rằng hầu hết các ví dụ được chú t hích không chính xác là những trường hợp nhãn đúng, nhưng bằng chứng được chọn không đủ (chỉ có 4 trên 227 ví dụ được gán nhãn sai theo hướng dẫn).

Chúng tôi đã cố gắng giải quyết vấn đề này bằng cách yêu cầu những người chú thích của chúng tôi thận trọng hơn. Ví dụ, trong khi tuyên bố "Shakira là người Canada" có thể được gán nhãn là BỊ BÁC BỎ bởi câu "Shakira là một ca sĩ, nhạc sĩ, vũ công và nhà sản xuất thu âm người Colombia", chúng tôi cho rằng trừ khi có bằng chứng cụ thể hơn được cung cấp (ví dụ: "Cô ấy bị từ chối quốc tịch Canada"), tuyên bố đó nên được gán nhãn LƯỜNG THÔNG TIN KHÔNG ĐỦ, vì quyền công dân kép được phép, và kiến thức thế giới của ng ười chú thích không nên được xem xét.

Một vấn đề liên quan là phân giải thực thể. Đối với một tuyên bố như "David Beckham đã ở cùng United.", có thể rất đơn giản đối với một người chú thích khi chấp nhận "David Beckham đã ra mắt tại Giải đấu Châu Âu khi chơi cho Manchester United." như bằng chứng hỗ trợ. Điều này ngụ ý rằng "United" chỉ "Manchester United", tuy nhiên có nhiều United trên Wikipedia và không chỉ là các câu lạc bộ bóng đá, ví dụ như United Airlines. Những người chú thích biết trang của thực thể chính và do đó việc phân giải các thực thể mơ hồ trở nên tương đối dễ dàng. Mặc dù chúng tôi cung cấp thông tin này như một phần của tập dữ liệu, chúng tôi cho rằng nó chỉ nên được sử dụng cho việc huấn luyện/phát triển hệ thống.

4 Mô tả Hệ thống Cơ bản

Chúng tôi xây dựng một hệ thống theo đường ống đơn giản gồm ba thành phần: truy xuất tài liệu, lựa chọn bằng chứng ở cấp câu và suy diễn văn bản. Mỗi thành phần được đánh giá riêng thông qua các đánh giá oracle trên tập phát triển và chúng tôi báo cáo độ chính xác cuối cùng trên tập kiểm tra.

Truy xuất Tài liệu Chúng tôi sử dụng thành phần truy xuất tài liệu từ hệ thống DrQA (Chen và cộng sự, 2017) vốn trả về k tài liệu gần nhất cho một truy vấn bằng cách sử dụng độ tương đồng cosine giữa các vector TF-IDF (Tần suất Thuật ngữ - Tần suất Tài liệu Ngược) của unigram và bigram đã được phân chia vào các ô.

Lựa chọn câu Phương pháp lựa chọn câu đơn giản của chúng tôi xếp hạng các câu dựa trên sự tương đồng TF-IDF với tuyên bố. Chúng tôi sắp xếp các câu có độ tương đồng cao nhất trước và điều chỉnh ngưỡng cắt bằng cách sử dụng độ chính xác xác thực trên tập phát triển. Chúng tôi đánh giá cả DrQA và một cài đặt TF-IDF unigram đơn giản để xếp hạng các câu cho việc lựa chọn. Chúng tôi cũng đánh giá tác động của việc lựa chọn câu lên mô-đun RTE bằng cách dự đoán sự suy luận dựa trên các tài liệu gốc mà không có việc l ựa chọn câu.

Nhận diện Quan Hệ Ngữ Nghĩa Văn Bản Chúng tôi so sánh hai mô hình để nhận diện quan hệ ngữ nghĩa văn bản. Đối với một chuẩn mực đơn giản nhưng hiệu quả, chúng tôi chọn bài nộp của Riedel và cộng sự (2017) từ Fake News Challenge 2017. Đây là một mạng perceptron nhiều lớp (MLP) với một lớp ẩn duy nhất, sử dụng tần số từ và độ t ương tự cosine TF-IDF giữa tuyên bố và bằng chứng làm các đặc trưng.

Evaluating the state-of-the-art in RTE, we used a decomposable attention (**DA**) model between the claim and the evidence passage (Parikh et al., 2016). We selected it because at the time of development this model was the highest scoring system for the Stanford Natural Language Inference task (Bowman et al., 2015) with publicly available code that did not require the input text to be parsed syntactically, nor was an ensemble.

The RTE component must correctly classify a claim as NOTENOUGHINFO when the evidence retrieved is not relevant or informative. However, the instances labeled as NOTENOUGHINFO have no evidence annotated, thus cannot be used to train RTE for this class. To overcome this issue, we simulate training instances for the NOTENOUGHINFO through two methods: sampling a sentence from the nearest page (NEARESTP) to the claim as evidence using our document retrieval component and sampling a sentence from Wikipedia uniformly at random (RANDOMS).

5 Experiments

5.1 Dataset Statistics

We partitioned the annotated claims into training, development and test sets. We ensured that each Wikipedia page used to generate claims occurs in exactly one set. We reserved a further 19,998 examples for use as a test set for a shared task.

Split	SUPPORTED	REFUTED	NEI
Training	80,035	29,775	35,639
Dev	3,333	3,333	3,333
Test	3,333	3,333	3,333
Reserved	6,666	6,666	6,666

Table 1: Dataset split sizes for SUPPORTED, REFUTED and NOTENOUGHINFO (NEI) classes

5.2 Evaluation

Predicting whether a claim is SUPPORTED, REFUTED or NOTENOUGHINFO is a 3-way classification task that we evaluate using accuracy. In the case of the first two classes, appropriate evidence must be provided, at a sentence-level, to justify the classification. We consider an answer returned correct for the first two classes only if correct evidence is returned. Given that the development and test datasets have balanced class distributions, a random baseline will have $\sim 33\%$ accuracy if one ignores the requirement for evidence for SUPPORTED and REFUTED.

We evaluate the correctness of the evidence retrieved by computing the F_1-score of all the predicted sentences in comparison to the human-annotated sentences for those claims requiring evidence on our complete pipeline system (Section 5.7). As in Fig. 1, some claims require multi-hop inference involving sentences from more than one document to be correctly supported as SUPPORTED/REFUTED. In this case all sentences must be selected for the evidence to be marked as correct. We report this as the proportion of *fully supported claims*. Some claims may be equally supported by different pieces of evidence; in this case one complete set of sentences should be predicted.

Systems that select information that the annotators did not will be penalized in terms of precision. We recognize that it is not feasible to ensure that the evidence selection annotations are complete, nevertheless we argue that they are useful for automatic evaluation during system development. For a more reliable evaluation we advocate crowd-sourcing annotations of false-positive predictions at a later date in a similar manner to the TAC KBP Slot Filler Validation (Ellis et al., 2016).

5.3 Document Retrieval

The document retrieval component of the baseline system returns the k nearest documents to the claim using the DrQA (Chen et al., 2017) TF-IDF implementation to return the k-nearest documents. In the scenario where evidence from multiple documents is required, k must be greater than this figure. We simulate the upper bound in accuracy using an oracle 3-way RTE classifier that predicts SUPPORTED/REFUTED ones correctly only if the documents containing the supporting/refuting evidence are returned by document retrieval and always predicts NOTENOUGHINFO instances correctly independently of the evidence. Results are shown in Table 2.

5.4 Sentence Selection

Mirroring document retrieval, we extract the top l-most similar sentences from the k-most relevant documents using TF-IDF vector similarity. We modified document retrieval component of DrQA (Chen et al., 2017) to select sentences using bigram TF-IDF with binning and compared this to a simple unigram TF-IDF implementation using NLTK (Loper and Bird, 2002). Using the parameter

Đánh giá trạng thái hiện đại trong RTE, chúng tôi đã sử dụng một mô hình chú ý có thể phân rã (DA) giữa tuyên bố và đoạn chứng cứ (Parikh et al., 2016). Chúng tôi chọn nó vì tại thời điểm phát t riển, mô hình này là hệ thống đạt điểm cao nhất cho nhiệm vụ Suy diễn Ngôn ngữ Tự nhiên Stanford (Bowman et al., 2015) với mã nguồn công khai không yêu cầu văn bản đầu vào phải được phân tích cú pháp, cũng không phải là mô hình ghép.

Thành phần RTE phải phân loại chính xác một yêu cầu là NOTENOUGHINFO khi bằng chứng được truy xuất không liên quan hoặc không cung cấp thông tin. Tuy nhiên, các trường hợp được gán nhãn là NOTENOUGHINFO không có bằng chứng được chú thích, do đó không thể sử dụng để huấn luyện RTE cho lớp này. Để khắc phục vấn đề này, chúng tôi mô phỏng các trường hợp huấn luyện cho NOTENOUGHINFO thông qua hai phương pháp: lấy mẫu một câu từ trang gần nhất (NEARESTP) với yêu cầu làm bằng chứng bằng cách sử dụng thành phần truy xuất tài liệu của chúng tôi và lấy mẫu một câu từ Wikipedia một cách ngẫu nhiên (RANDOMS).

5 Thí nghiệm

5.1 Thống kê bộ dữ liệu

Chúng tôi đã phân chia các tuyên bố có chú thích thành các tập huấn luyện, phát triển và kiểm tra. Chúng tôi đảm bảo rằng mỗi trang Wikipedia được sử dụng để tạo các tuyên bố chỉ xuất hiện trong đúng một tập. Chúng tôi dành thêm 19.998 ví dụ để sử dụng làm tập kiểm tra cho một nhiệm vụ chung.

Chia	ĐƯỢC HỖ TRỢ	BỊ BẠC LẠI	NEI
Đào tạo	80.035	29.775	35.639
Dev	3,333	3,333	3,333
Test	3,333	3,333	3,333
Đã đặt trước	6,666	6,666	6,666

Bảng 1: Kích thước phân chia tập dữ liệu cho các lớp SUPPORTED, REFUTED và NOTENOUGHINFO (NEI)

5.2 Đánh giá

Dự đoán liệu một tuyên bố được HỖ TRỢ, BỊ PHỦ NHẬN hay KHÔNG ĐỦ THÔNG TIN là một nhiệm vụ phân loại ba lớp mà chúng tôi đánh giá bằng độ chính xác. Trong trường hợp hai lớp đầu tiên, bằng chứng thích hợp phải được cung cấp ở cấp câu để biện minh cho việc phân loại. Chúng tôi chỉ coi một câu trả lời là đúng cho hai lớp đầu tiên nếu bằng chứng chính xác được cung cấp. Vì các bộ dữ liệu phát triển và kiểm tra có phân bố lớp cân bằng, một chuẩn ngẫu nhiên sẽ có độ chính xác ~ 33 %.

sự chính xác nếu người ta bỏ qua yêu cầu về bằng chứng cho HỖ TRỢ và BẠI LUẬN.

Chúng tôi đánh giá độ đúng đắn của các bằng chứng được truy xuất bằng cách tính điểm F_1 của tất cả các câu được dự đoán so với các câu được gắn nhãn bởi con người cho những tuyên bố yêu cầu bằng chứng trên toàn bộ hệ thống đường ống của chúng tôi (Mục 5.7). Như trong Hình 1, một số tuyên bố yêu cầu suy luận nhiều bước liên quan đến các câu từ hơn một tài liệu để được hỗ trợ đúng cách là ĐƯỢC HỖ TRỢ/BỊ PHỦ NHẬN. Trong trường hợp này, tất cả các câu phải được chọn để bằng chứng được đánh dấu là đúng. Chúng tôi báo cáo điều này dưới dạng tỷ lệ các tuyên bố được hỗ trợ đầy đủ. Một số tuyên bố có thể được hỗ trợ bằng các mảnh bằng chứng khác nhau; trong trường hợp này, một tập hợp câu hoàn chỉnh nên được dự đoán.

Các hệ thống chọn thông tin mà người chú thích không chọn sẽ bị trừ điểm về độ chính xác. Chúng tôi nhận thấy rằng không khả thi để đảm bảo rằng các chú thích về lựa chọn bằng chứng là đầy đủ, tuy nhiên chúng tôi cho rằng chúng hữu í ch cho việc đánh giá tự động trong quá trình phát triển hệ thống. Để có đánh giá đáng tin cậy hơn, chúng tôi ủng hộ việc huy động cộng đồng để chú thích các dự đoán dương tính sai vào một thời điểm sau một cách tương tự như cách TAC KBP Slot Filler Validation (Ellis et al., 2016) thực hiện.

5.3 Truy xuất Tài liệu

Thành phần truy xuất tài liệu của hệ thống cơ sở trả về k tài liệu gần nhất với tuyên bố bằng cách sử dụng triển khai TF-IDF DrQA (Chen và cộng sự, 2017) để trả về k tài liệu gần nhất. Trong kịch bản yêu cầu bằng chứng từ nhiều tài liệu, k phải lớn hơn con số này. Chúng tôi mô phỏng giới hạn trên về độ chính xác bằng cách sử dụng một bộ phân loại RTE 3 chiều oracle, dự đoán chính xác các trường hợp ĐƯỢC HỖ TRỢ/BỊ PHỦ ĐỊNH chỉ khi các tài liệu chứa bằng chứng hỗ trợ/phủ định được truy xuất bởi thành phần truy xuất tài liệu và luôn dự đoán chính xác các trường hợp KHÔNG ĐỦ THÔNG TIN một cách độc lập với bằng chứng. Kết quả được trình bày trong Bảng 2.

5.4 Lựa chọn câu

Tương tự như việc truy xuất tài liệu, chúng tôi trích h xuất l câu có độ tương đồng cao nhất từ k tài li ệu có liên quan nhất bằng cách sử dụng độ tương đồng vectơ TF-IDF. Chúng tôi đã sửa đổi thành phần truy xuất tài liệu của DrQA (Chen et al., 2017) để chọn câu sử dụng TF-IDF hai từ với phân nhóm và so sánh điều này với việc triển khai TF-IDF một từ đơn giản sử dụng NLTK (Loper and Bird, 2002). Sử dụng tham số

k	Fully Supported (%)	Oracle Accuracy (%)
1	25.31	50.21
5	55.30	70.20
10	65.86	77.24
25	75.92	83.95
50	82.49	90.13
100	86.59	91.06

Table 2: Dev. set document retrieval evaluation.

eters $k = 5$ documents and $l = 5$ sentences, 55.30% of claims (excluding NOTENOUGHINFO) can be fully supported or refuted by the retrieved documents before sentence selection (see Table 2). After applying the sentence selection component, 44.22% of claims can be fully supported using the extracted sentences with DrQA and only 34.03% with NLTK. This would yield oracle accuracies of 62.81% and 56.02% respectively.

5.5 Recognizing Textual Entailment

The RTE component is trained on labeled claims paired with sentence-level. Where multiple sentences are required as evidence, the strings are concatenated. As discussed in Section 4, such data is not annotated for claims labeled NOTENOUGHINFO, thus we compare random sampling-based and similarity-based strategies for generating it. We evaluate classification accuracy on the development set in an oracle evaluation, assuming correct evidence sentences are selected (Table 3). Additionally, for the DA model, we predict entailment given evidence, using the AllenNLP (Gardner et al., 2017) pre-trained Stanford Natural Language Inference (SNLI) model for comparison.

Model	Accuracy (%)		
	NEARESTP	RANDOMS	SNLI
MLP	65.13	73.81	-
DA	80.82	88.00	38.54

Table 3: Oracle classification on claims in the development set using gold sentences as evidence

The random sampling (RANDOMS) approach (where a sentence is sampled at random from Wikipedia in place of evidence for claims labeled as NOTENOUGHINFO) yielded sentences that were not only semantically different to the claim, but also unrelated. While the the accuracy of models trained with sampling approach is higher in oracle evaluation setting, this may not yield a better system in the pipeline setting. In contrast, the nearest page (NEARESTP) method samples a sentence from the highest-ranked page returned by our document retrieval module. This simulates finding related information that may not be sufficient to support or refute a claim. We will evaluate both RANDOMS and NEARESTP in the full pipeline setting, but we will not pursue the SNLI-trained model further as it performed substantially worse.

5.6 Full Pipeline

The complete pipeline consists of the DrQA document retrieval module (Section 5.3), DrQA-based sentence retrieval module (Section 5.4), and the decomposable attention RTE model (Section 5.5). The two parameters: k, describing the number documents and l, describing the number sentences to return were found using grid-search optimizing the RTE accuracy with the DA model. For the pipeline, we set $k = 5$ and $l = 5$ and report the development set accuracy, both with and without the requirement to provide correct evidence for the SUPPORTED/REFUTED predictions (marked as **ScoreEv** and **NoScoreEv** respectively).

Model	Accuracy (%)	
	NoScoreEv	ScoreEv
MLP / NP	41.86	19.04
MLP / RS	40.63	19.42
DA / NP	52.09	**32.57**
DA / RS	50.37	23.53

Table 4: Full pipeline results on development set

The decomposable attention model trained with NEARESTP is the most accurate when evidence is considered. Inspection of the confusion matrices shows that the RANDOMS strategy harms recall for the NOTENOUGHINFO class. This is due to the difference between the sampled pages in the training set and the ones retrieved in the development set causing related but uninformative evidence to be misclassified as SUPPORTED and REFUTED.

Ablation of the sentence selection module We evaluate the impact of the sentence selection module on both the RTE accuracy by removing it.

k	Hoàn toàn Được hỗ trợ (%)	Tiên tri Độ chính xác (%)
1	25.31	50.21
5	55.30	70.20
10	65.86	77.24
25	75.92	83.95
50	82.49	90.13
100	86.59	91.06

Bảng 2: Đánh giá truy xuất tài liệu trên tập phát triển.

eters $k = 5$ tài liệu và $l = 5$ câu, 55,30% các tuyên bố (không bao gồm NOTENOUGHINFO) có thể được hoàn toàn hỗ trợ hoặc bác bỏ bởi các tài liệu được truy xuất trước khi chọn câu (xem Bảng 2). Sau khi áp dụng thành phần chọn câu, 44,22% các tuyên bố có thể được hoàn toàn hỗ trợ bằng các câu được trích xuất với DrQA và chỉ 34,03% với NLTK. Điều này sẽ tạo ra độ chính xác oracle lần lượt là 62,81% và 56,02%.

5.5 Nhận diện Sự Bao hàm Văn bản

Thành phần RTE được huấn luyện trên các tuyên bố có nhãn được ghép với cấp câu. Khi nhiều câu được yêu cầu làm bằng chứng, các chuỗi sẽ được nối lại với nhau. Như đã thảo luận trong Mục 4, dữ liệu như vậy không được chú thích cho các tuyên bố được gắn nhãn NOTE-NOUGHINFO, do đó c húng tôi so sánh các chiến lược dựa trên lấy mẫu ngẫu nhiên và dựa trên độ tương đồng để tạo dữ liệu này. Chúng tôi đánh giá độ chính xác phân loại trên tập phát triển trong một đánh giá tiên tri, giả sử rằng các câu bằng chứng được chọn đúng (Bảng 3). Ngoài ra, đối với mô hình DA, chúng tôi dự đoán sự kéo theo dựa trên bằng chứng, sử dụng mô hình Stanford Natural Language Inference (SNLI) đã được huấn luyện trước của AllenNLP (Gardner et al., 2017) để so sánh.

Mô hình	Độ chính xác (%)		
	GẦN NHẤT	NGẪU NHIÊN	SNLI
MLP	65.13	73.81	-
DA	80.82	88.00	38.54

Bảng 3: Phân loại Oracle trên các yêu cầu trong tập p hát triển sử dụng các câu vàng làm bằng chứng

Phương pháp lấy mẫu ngẫu nhiên (RANDO MS) (trong đó một câu được lấy ngẫu nhiên từ Wikipedia thay cho bằng chứng cho các tuyên bố được gắn nhãn là NOTENOUGHINFO) đã tạo ra các câu không chỉ khác về ngữ nghĩa so với khẳng định, nhưng cũng không liên quan. Trong khi độ chính xác của các mô hình được huấn luyện với phương pháp lấy mẫu cao hơn trong thiết lập đánh giá oracle, điều này có thể không mang lại một hệ thống tốt hơn trong thiết lập pipeline. Ngược lại, phương pháp trang gần nhất (NEARESTP) lấy mẫu một câu từ trang được xếp hạng cao nhất do mô-đun truy xuất tài liệu của chúng tôi trả về. Điều này mô phỏng việc tìm thông tin liên quan mà có thể không đủ để hỗ trợ hoặc bác bỏ một khẳng định. Chúng tôi sẽ đánh giá cả RANDOMS và NEARESTP trong thiết lập pipeline đầy đủ, nhưng chúng tôi sẽ không tiếp tục theo đuổi mô hình được huấn luyện SNLI vì nó hoạt động kém hơn đáng kể.

5.6 Toàn bộ Quy trình

Toàn bộ quy trình bao gồm mô-đun truy xuất tài liệu DrQA (Mục 5.3), mô-đun truy xuất câu dựa t rên DrQA (Mục 5.4), và mô hình RTE chú ý phân rã (Mục 5.5). Hai tham số: k, mô tả số lượng tài liệu và l, mô tả số lượng câu trả về, được tìm thấy bằng cách tối ưu hóa accuracy RTE với mô hình DA thông qua tìm kiếm theo lưới. Đối với quy trình, chúng tôi đặt $k = 5$ và $l = 5$ và báo cáo độ chính xác trên tập phát triển, cả trong trường hợp có và không có yêu cầu cung cấp bằng chứng chính xác cho các dự đoán SUPPORTED/REFUTED (được đánh dấu lần lượt là ScoreEv và NoScoreEv).

Mô hình	Độ chính xác (%)	
	Không điểm EV	ĐiểmEv
MLP / NP	41.86	19.04
MLP / RS	40.63	19.42
DA / NP	52.09	**32.57**
DA / RS	50.37	23.53

Bảng 4: Kết quả toàn bộ quy trình trên tập phát triển

Mô hình chú ý phân rã được huấn luyện với NEARESTP là chính xác nhất khi xem xét bằng chứng. Việc kiểm tra các ma trận nhầm lẫn cho thấy chiến lược RANDOMS làm giảm khả năng hồi tưởng đối với lớp NOTENOUGHINFO. Điều này là do sự khác biệt giữa các trang được lấy mẫu trong tập huấn luyện và những trang được truy xuất trong tập phát triển khiến bằng chứng liên quan nhưng không cung cấp thông tin bị phân loại sai thành SUPPORTED và REFUTED.

Loại bỏ mô-đun lựa chọn câu Chúng tôi đánh giá tác động của mô-đun lựa chọn câu đối với độ chính xác RTE bằng cách loại bỏ nó.

While the sentence selection module may improve accuracy in the RTE component, it is discarding sentences that are required as evidence to support claims, harming performance (see Section 5.4). We assess the accuracies in both oracle setting (similar to Section 5.5) (see Table 5) as well as in the full pipeline (see Table 6).

In the oracle setting, the decomposable attention models are worst affected by removal of the sentence selection module: exhibiting an substantial decrease in accuracy. The NEARESTP training regime exhibits a 17% decrease and the RANDOMS accuracy decreases by 19%, despite near-perfect recall of the NOTENOUGHINFO class.

Model	Oracle Accuracy (%)	
	NEARESTP	RANDOMS
MLP	57.16	73.36
DA	63.68	69.05

Table 5: Oracle accuracy on claims in the dev. set using gold documents as evidence (c.f. Table 3).

In the pipeline setting, we run the RTE component without sentence selection using $k = 5$ most similar predicted documents. The removal of the sentence selection component decreased the accuracy (NOSCOREEV) approximately 10% for both decomposable attention models.

Model	Accuracy (%)	
	NEARESTP	RANDOMS
MLP	38.85	40.45
DA	41.57	40.62

Table 6: Pipeline accuracy on the dev. set without the sentence selection module (c.f. Table 4).

5.7 Evaluating Full Pipeline on Test Set

We evaluate our pipeline approach on the test set based on the results observed in Section 5.6. First, we use DrQA to select select 5 documents nearest to the claim. Then, we select 5 sentences using our DrQA-based sentence retrieval component and concatenate them. Finally, we predict entailment using the Decomposable Attention model trained with the NEARESTP strategy. The classification accuracy is 31.87%. Ignoring the requirement for correct evidence (**NoScoreEv**) the accuracy is 50.91%, which highlights that while the systems were predicting the correct label, the evidence selected was different to that which the human annotators chose. The recall of the document and sentence retrieval modules for claims which required evidence on the test set was 45.89% (considering complete groups of evidence) and the precision 10.79%. The resulting F_1 score is 17.47%.

5.8 Manual Error Analysis

Using the predictions on the test set, we sampled 961 of the predictions with an incorrect label or incorrect evidence and performed a manual analysis. Of these, 28.51% ($n = 274$) had the correct predicted label but did not satisfy the requirements for evidence. The information retrieval component of the pipeline failed to identify any correct evidence in 58.27% ($n = 560$) of cases which accounted for the large disparity between accuracy of the system when evidence was and was not considered. Where suitable evidence was found, the RTE component incorrectly classified 13.84% ($n = 133$) of claims.

The pipeline retrieved new evidence that had not been identified by annotators in 21.85% ($n = 210$) of claims. This was in-line with our expectation given the measured recall rate of annotators (see Section 3.4.2), who achieved recall of 72.36% of evidence identified by the super-annotators.

We found that 4.05% ($n = 41$) of claims did not meet our guidelines. Of these, there were 11 claims which could be checked without evidence as these either tautologous or self-contradictory. Some correct claims appeared ungrammatical due to the mis-parsing of named entities (e.g. *Exotic Birds* is the name of a band but could be parsed as a type of animal). Annotator errors (where the wrong label was applied) were present in 1.35% ($n = 13$) of incorrectly classified claims.

Interestingly, our system found new evidence that contradicted the gold evidence in 0.52% ($n = 5$) of cases. This was caused either by entity resolution errors or by inconsistent information present in Wikipedia pages (e.g. Pakistan was described as having both the 41st and 42nd largest GDP in two different pages).

5.9 Ablation of Training Data

To evaluate whether the size of the dataset is suitable for training the RTE component of the pipeline, we plot the learning curves for the DA and MLP models (Fig. 3). For each model, we

Mặc dù mô-đun lựa chọn câu có thể cải thiện độ chính xác trong thành phần RTE, nó lại loại bỏ các câu cần thiết làm bằng chứng để hỗ trợ các tuyên bố, gây ảnh hưởng xấu đến hiệu suất (xem Mục 5.4). Chúng tôi đánh giá độ chính xác cả trong cài đặt oracle (tương tự như Mục 5.5) (xem Bảng 5) cũng như trong toàn bộ quy trình xử lý (xem Bảng 6).

Trong thiết lập oracle, các mô hình chú ý có t hể phân rã bị ảnh hưởng nặng nhất bởi việc loại bỏ mô-đun lựa chọn câu: thể hiện sự giảm đáng kể về độ chính xác. Chế độ huấn luyện NEARESTP giảm 17% và độ chính xác của RANDOMS giảm 19%, mặc dù khả năng hồi tưởng gần như hoàn hảo của lớp NOTENOUGHINFO.

Mô hình	Độ chính xác của Oracle (%)	
	GẦN NHẤT	NGẪU NHIÊN
MLP	57.16	73.36
DA	63.68	69.05

Bảng 5: Độ chính xác của Oracle trên các tuyên bố trong tập phát triển sử dụng các tài liệu chuẩn làm bằng chứng (xem Bảng 3).

Trong cài đặt theo quy trình, chúng tôi chạy thành phần RTE mà không sử dụng chọn câu bằng cách sử dụng $k = 5$ các tài liệu dự đoán tương tự nhất. Việc loại bỏ thành phần chọn câu đã làm giảm độ chính xác (NOSCOREEV) khoảng 10% đối với cả hai mô hình chú ý phân tách.

Mô hình	Độ chính xác (%)	
	GẦN NHẤT	NGẪU NHIÊN
MLP	38.85	40.45
DA	41.57	40.62

Bảng 6: Độ chính xác của quy trình trên tập phát triển mà không có mô-đun chọn câu (tham khảo Bảng 4).

5.7 Đánh giá Toàn bộ Quy trình trên Bộ dữ liệu Kiểm tra

Chúng tôi đánh giá phương pháp pipeline của mình trên tập kiểm tra dựa trên các kết quả quan sát được trong Mục 5.6. Trước tiên, chúng tôi sử dụng DrQA để chọn 5 tài liệu gần nhất với tuyên bố. Sau đó, chúng tôi chọn 5 câu sử dụng thành phần truy xuất câu dựa trên DrQA của mình và ghép chúng lại với nhau. Cuối cùng, chúng tôi dự đoán mối quan hệ một cách suy diễn sử dụng mô hình Decomposable Attention được huấn luyện với chiến lược NEARESTP. Độ chính xác phân loại là 31,87%. Bỏ qua yêu cầu về bằng chứng đúng (NoScoreEv), độ chính xác là 50,91%, điều này nhấn mạnh rằng mặc dù các hệ thống khi dự đoán nhãn chính xác, bằng chứng được chọn lại khác với những gì các chú thích viên con người đã chọn. Độ thu hồi của các mô-đun truy xuất tài liệu và câu cho các tuyên bố cần bằng chứng trên tập kiểm tra là 45,89% (xem xét các nhóm bằng chứng đầy đủ) và độ chính xác là 10,79 %. Điểm F_1 thu được là 17,47%.

5.8 Phân tích lỗi thủ công

Sử dụng các dự đoán trên tập kiểm tra, chúng tôi đã lấy mẫu 961 dự đoán với nhãn sai hoặc bằng chứng không chính xác và thực hiện phân tích thủ công. Trong số này, 28,51% ($n = 274$) có nhãn dự đoán đúng nhưng không đáp ứng các yêu cầu về bằng chứng. Thành phần truy xuất thông tin của quy trình chưa xác định được bất kỳ bằng chứng đúng nào trong 58,27% ($n = 560$) các trường hợp, chiếm phần lớn sự khác biệt về độ chính xác của hệ thống khi có và không có bằng chứng. Khi tìm thấy bằng chứng phù hợp, thành phần RTE đã phân loại sai 13,84% ($n = 133$) các tuyên bố.

Hệ thống đã thu thập được bằng chứng mới mà người chú thích chưa xác định trong 21,85% ($n = 210$) các tuyên bố. Điều này phù hợp với mong đợi của chúng tôi dựa trên tỷ lệ thu hồi được đo của các người chú thích (xem Mục 3.4.2), những người đã đạt được tỷ lệ thu hồi 72,36% bằng chứng được xác định bởi các siêu chú thích viên.

Chúng tôi phát hiện rằng 4,05% ($n = 41$) các tuyên bố không đáp ứng các hướng dẫn của chúng tôi. Trong số này, có 11 tuyên bố có thể kiểm tra mà không cần bằng chứng vì chúng hoặc là lặp nghĩa, hoặc mâu thuẫn với chính bản thân chúng. Một số tuyên bố đúng xuất hiện không đúng ngữ pháp do việc phân tích sai các thực thể tên riêng (ví dụ: Exotic Birds là t ên một ban nhạc nhưng có thể bị phân tích như một loại động vật). Sai sót của người ghi chú (khi nhãn sai được áp dụng) xuất hiện trong 1,35% ($n = 13$) các t uyên bố bị phân loại sai.

Thú vị thay, hệ thống của chúng tôi đã tìm t hấy bằng chứng mới mâu thuẫn với bằng chứng chuẩn ở 0,52% (n =5) các trường hợp. Nguyên nhân là do lỗi phân giải thực thể hoặc do thông tin không nhất quán có trong các trang Wikipedia (ví dụ: Pakistan được mô tả là có cả GDP lớn thứ 41 và 42 trên hai trang khác nhau).

5.9 Loại bỏ Dữ liệu Huấn luyện

Để đánh giá xem kích thước của tập dữ liệu có phù hợp để huấn luyện thành phần RTE của quy trình hay không, chúng tôi vẽ các đường cong học của các mô hình DA và MLP (Hình 3). Đối với mỗi mô hình, chúng tôi

trained 5 models with different random initializations using the NEARESTP method (see Section 5.5). We selected the highest performing model when evaluated on development set and report the oracle RTE accuracy on the test set. We observe that with fewer than 6000 training instances, the accuracy of DA is unstable. However, with more data, its accuracy increases with respect to the log of the number of training instances and exceeds that of MLP. While both learning curves exhibit the typical diminishing return trends, they indicate that the dataset is large enough to demonstrate the differences of models with different learning capabilities.



Figure 3: Learning curves for the RTE models.

6 Discussion

The pipeline presented and evaluated in the previous section is one possible approach to the task proposed in our dataset, but we envisage different ones to be equally valid and possibly better performing. For instance, it would be interesting to test how approaches similar to natural logic inference (Angeli and Manning, 2014) can be applied, where a knowledge base/graph is constructed by reading the textual sources and then a reasoning process over the claim is applied, possibly using recent advances in neural theorem proving (Rocktäschel and Riedel, 2017). A different approach could be to consider a combination of question generation (Heilman and Smith, 2010) followed by a question answering model such as BiDAF (Seo et al., 2016), possibly requiring modification as they are designed to select a single span of text from a document rather than return one or more sentences as per our scoring criteria. The sentence-level evidence annotation in our dataset will help develop models selecting and attending to the relevant information from multiple documents and non-contiguous passages. Not only will this enhance the interpretability of predictions, but also facilitate the development of new methods for reading comprehension.

Another use case for the FEVER dataset is claim extraction: generating short concise textual facts from longer encyclopedic texts. For sources like Wikipedia or news articles, the sentences can contain multiple individual claims, making them not only difficult to parse, but also hard to evaluate against evidence. During the construction on the FEVER dataset, we allowed for an extension of the task where simple claims can be extracted from multiple complex sentences.

Finally, we would like to note that while we chose Wikipedia as our textual source, we do not consider it to be the only source of information worth considering in verification, hence not using TRUE or FALSE in our classification scheme. We expect systems developed on the dataset presented to be portable to different textual sources.

7 Conclusions

In this paper we have introduced FEVER, a publicly available dataset for fact extraction and verification against textual sources. We discussed the data collection and annotation methods and shared some of the insights obtained during the annotation process that we hope will be useful to other large-scale annotation efforts.

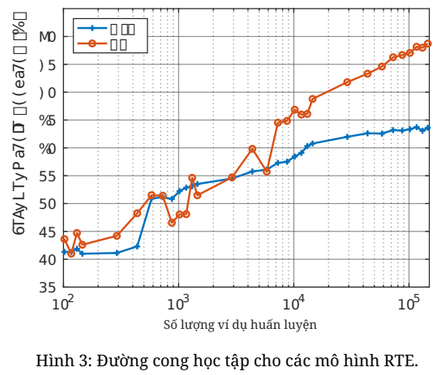
In order to evaluate the challenge this dataset presents, we developed a pipeline approach that comprises information retrieval and textual entailment components. We showed that the task is challenging yet feasible, with the best performing system achieving an accuracy of 31.87%.

We also discussed other uses for the FEVER dataset and presented some further extensions that we would like to work on in the future. We believe that FEVER will provide a stimulating challenge for claim extraction and verification systems.

Acknowledgments

The work reported was partly conducted while James Thorne was at Amazon Research Cambridge. Andreas Vlachos is supported by the EU H2020 SUMMA project (grant agreement number 688139). The authors would like to thank the team of annotators involved in preparing this dataset.

đã huấn luyện 5 mô hình với các khởi tạo ngẫu nhiên khác nhau bằng phương pháp NEARESTP (xem Mục 5.5). Chúng tôi chọn mô hình có hiệu suất cao nhất khi đánh giá trên tập phát triển và báo cáo độ chính xác RTE lý tưởng trên tập kiểm tra. Chúng tôi quan sát thấy rằng với ít hơn 6000 mẫu huấn luyện, độ chính xác của DA không ổn định. Tuy nhiên, với nhiều dữ liệu hơn, độ chính xác của nó tăng lên theo logarit của số mẫu huấn luyện và vượt qua độ chính xác của MLP. Mặc dù cả hai đường cong học đều thể hiện xu hướng lợi suất giảm đi điển hình, chúng chỉ ra rằng tập dữ liệu đủ lớn để chứng minh sự khác biệt của các mô hình với các khả năng học khác nhau.



Hình 3: Đường cong học tập cho các mô hình RTE.

6 Thảo luận

Hệ thống xử lý được trình bày và đánh giá trong phần trước là một cách tiếp cận có thể thực hiện cho nhiệm vụ được đề xuất trong tập dữ liệu của chúng tôi, nhưng chúng tôi dự đoán các cách tiếp cận khác cũng có thể hợp lệ và có thể cho hiệu suất tốt hơn. Ví dụ, sẽ thú vị khi thử nghiệm cách tiếp cận tương tự như suy luận logic tự nhiên (Angeli và Manning, 2014), nơi một cơ sở dữ liệu/đồ thị kiến thức được xây dựng bằng cách đọc các nguồn văn bản và sau đó một quy trình suy luận về tuyên bố được áp dụng, có thể sử dụng các tiến bộ gần đây trong chứng minh định lý bằng mạng nơ-ron (Rocktäschel và Riedel, 2017). Một cách tiếp cận khác có thể là kết hợp việc tạo câu hỏi (Heilman và Smith, 2010) theo sau bởi một mô hình trả lời câu hỏi như BiDAF (Seo et al., 2016), có thể cần điều chỉnh vì chúng được thiết kế để chọn một đoạn văn bản duy nhất từ một tài liệu thay vì trả lại một hoặc nhiều câu theo tiêu chí đánh giá của chúng tôi. Việc chú thích bằng chứng ở cấp độ câu trong tập dữ liệu của chúng tôi sẽ giúp phát triển các mô hình chọn lọc và chú ý đến thông tin liên quan từ nhiều tài liệu và các đoạn văn không liền kề. Điều này không chỉ nâng cao khả năng giải thích các dự đoán, mà còn thuận lợi cho việc phát triển các phương pháp mới cho việc đọc hiểu.

Một trường hợp sử dụng khác của tập dữ liệu FEVER là trích xuất tuyên bố: tạo ra các sự thật văn bản ngắn gọn từ các văn bản bách khoa dài hơn. Đối với các nguồn như Wikipedia hoặc các bài báo, các câu có thể chứa nhiều tuyên bố riêng lẻ, làm cho chúng không chỉ khó phân tích mà còn khó đánh giá so với bằng chứng. Trong quá trình xây dựng tập dữ liệu FEVER, chúng tôi đã cho phép mở rộng nhiệm vụ, nơi các tuyên bố đơn giản có thể được trích xuất từ nhiều câu phức tạp.

Cuối cùng, chúng tôi muốn lưu ý rằng mặc dù chúng tôi chọn Wikipedia làm nguồn văn bản, chúng tôi không coi nó là nguồn thông tin duy nhất đáng xem xét trong việc xác minh, do đó không sử dụng TRUE hoặc FALSE trong sơ đồ phân loại của chúng tôi. Chúng tôi kỳ vọng các hệ thống phát triển trên tập dữ liệu được trình bày có thể áp dụng cho các nguồn văn bản khác.

7 Kết luận

Trong bài báo này, chúng tôi đã giới thiệu FEVER, một bộ dữ liệu công khai dành cho việc trích xuất và xác minh sự thật dựa trên các nguồn văn bản. Chúng tôi đã thảo luận về các phương pháp thu thập và chú thích dữ liệu và chia sẻ một số hiểu biết thu được trong quá trình chú thích mà chúng tôi hy vọng sẽ hữu ích cho các nỗ lực chú thích quy mô lớn khác.

Để đánh giá thách thức mà tập dữ liệu này đưa ra, chúng tôi đã phát triển một phương pháp theo quy trình bao gồm các thành phần truy xuất thông tin và suy diễn văn bản. Chúng tôi đã chỉ ra rằng nhiệm vụ này vừa đầy thách thức vừa khả thi, với hệ thống hoạt động tốt nhất đạt độ chính xác 31,87%.

Chúng tôi cũng đã thảo luận về các ứng dụng khác của bộ dữ liệu FEVER và trình bày một số mở rộng thêm mà chúng tôi muốn thực hiện trong tương lai. Chúng tôi tin rằng FEVER sẽ cung cấp một thử thách kích thích đối với các hệ thống trích xuất và xác thực tuyên bố.

Lời cảm ơn

Công trình được báo cáo một phần được thực hiện trong khi James Thorne làm việc tại Amazon Research Cambridge. Andreas Vlachos được hỗ trợ bởi dự án EU H2020 SUMMA (số hợp đồng tài trợ 688139). Các tác giả xin gửi lời cảm ơn tới nhóm các nhà chú thích đã tham gia chuẩn bị bộ dữ liệu này.

References

Gabor Angeli and Christopher D. Manning. 2014. NaturalLI: Natural logic inference for common sense reasoning. In *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing*. pages 534–545.

Samuel R. Bowman, Gabor Angeli, Christopher Potts, and Christopher D. Manning. 2015. A large annotated corpus for learning natural language inference. In *Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing*.

Danqi Chen, Adam Fisch, Jason Weston, and Antoine Bordes. 2017. Reading wikipedia to answer open-domain questions. In *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Association for Computational Linguistics, pages 1870–1879. https://doi.org/10.18653/v1/P17-1171.

Ido Dagan, Bill Dolan, Bernardo Magnini, and Dan Roth. 2009. Recognizing textual entailment: Rational, evaluation and approaches. *Natural Language Engineering* 15(4):i–xvii. https://doi.org/10.1017/S1351324909990209.

Joe Ellis, Jeremy Getman, Dana Fore, Neil Kuster, Zhiyi Song, Ann Bies, and Stephanie Strassel. 2016. Overview of Linguistic Resources for the TAC KBP 2016 Evaluations : Methodologies and Results. *Proceedings of TAC KBP 2016 Workshop, National Institute of Standards and Technology, Maryland, USA* (Ldc).

William Ferreira and Andreas Vlachos. 2016. Emergent: a novel data-set for stance classification. In *Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*. San Diego, California, pages 1163–1168.

Joseph L Fleiss. 1971. Measuring nominal scale agreement among many raters. *Psychological bulletin* 76(5):378.

Matt Gardner, Joel Grus, Mark Neumann, Oyvind Tafjord, Pradeep Dasigi, Nelson Liu, Matthew Peters, Michael Schmitz, and Luke Zettlemoyer. 2017. AllenNLP: A Deep Semantic Natural Language Processing Platform .

Michael Heilman and Noah A. Smith. 2010. Good Question! statistical ranking for question generation. In *Proceedings of the 2010 Annual Conference of the North American Chapter of the Association for Computational Linguistics*. pages 609–617.

Mio Kobayashi, Ai Ishii, Chikara Hoshino, Hiroshi Miyashita, and Takuya Matsuzaki. 2017. Automated historical fact-checking by passage retrieval, word statistics, and virtual question-answering. In *Proceedings of the Eighth International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*. volume 1, pages 967–975.

Edward Loper and Steven Bird. 2002. Nltk: The natural language toolkit. In *Proceedings of the ACL-02 Workshop on Effective Tools and Methodologies for Teaching Natural Language Processing and Computational Linguistics - Volume 1*. Association for Computational Linguistics, Stroudsburg, PA, USA, ETMTNLP '02, pages 63–70. https://doi.org/10.3115/1118108.1118117.

Christopher D Manning, Mihai Surdeanu, John Bauer, Jenny Rose Finkel, Steven Bethard, and David McClosky. 2014. The Stanford CoreNLP natural language processing toolkit. In *ACL (System Demonstrations)*. pages 55–60.

Mausam, Michael Schmitz, Robert Bart, Stephen Soderland, and Oren Etzioni. 2012. Open language learning for information extraction. In *Proceedings of the 2012 Joint Conference on Empirical Methods in Natural Language Processing and Computational Natural Language Learning*. pages 523–534.

Ankur Parikh, Oscar Täckström, Dipanjan Das, and Jakob Uszkoreit. 2016. A decomposable attention model for natural language inference. In *Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, Austin, Texas, pages 2249–2255. https://aclweb.org/anthology/D16-1244.

Dean Pomerleau and Delip Rao. 2017. Fake news challenge. `http://fakenewschallenge.org/`.

P. Rajpurkar, J. Zhang, K. Lopyrev, and P. Liang. 2016. SQuAD: 100,000+ questions for machine comprehension of text. In *Empirical Methods in Natural Language Processing (EMNLP)*.

Benjamin Riedel, Isabelle Augenstein, George Spithourakis, and Sebastian Riedel. 2017. A simple but tough-to-beat baseline for the Fake News Challenge stance detection task. *CoRR* abs/1707.03264. http://arxiv.org/abs/1707.03264.

Tim Rocktäschel and Sebastian Riedel. 2017. End-to-end differentiable proving. In *Advances in Neural Information Processing Systems 31: Annual Conference on Neural Information Processing Systems 2017, December 4-9, 2017, Long Beach, California, United States*. volume abs/1705.11040. http://arxiv.org/abs/1705.11040.

Álvaro Rodrigo, Anselmo Peñas, and Felisa Verdejo. 2009. Overview of the answer validation exercise 2008. In Carol Peters, Thomas Deselaers, Nicola Ferro, Julio Gonzalo, Gareth J. F. Jones, Mikko Kurimo, Thomas Mandl, Anselmo Peñas, and Vivien Petras, editors, *Evaluating Systems for Multilingual and Multimodal Information Access: 9th Workshop of the Cross-Language Evaluation Forum*. pages 296–313.

Min Joon Seo, Aniruddha Kembhavi, Ali Farhadi, and Hannaneh Hajishirzi. 2016. Bidirectional attention flow for machine comprehension. *CoRR* abs/1611.01603. http://arxiv.org/abs/1611.01603.

Tài liệu tham khảo

Gabor Angeli và Christopher D. Manning. 2014. NaturalLI: Suy luận logic tự nhiên cho lý luận lẽ thường. Trong Kỷ yếu Hội nghị 2014 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên. trang 534–545.

Samuel R. Bowman, Gabor Angeli, Christopher Potts, và Christopher D. Manning. 2015. Một kho dữ liệu chú t hích lớn để học suy luận ngôn ngữ tự nhiên. Trong Kỷ yếu của Hội nghị về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên 2015.

Danqi Chen, Adam Fisch, Jason Weston, và Antoine Bordes. 2017. Đọc Wikipedia để trả lời các câu hỏi mở. Trong Kỷ yếu Hội nghị thường niên lần thứ 55 của Hiệp hội Ngôn ngữ học Máy tính (Tập 1: Bài báo dài). Hiệp hội Ngôn ngữ học Máy tính, các trang 1870–1879. https://doi.org/10.18653/v1/P17-1171.

Ido Dagan, Bill Dolan, Bernardo Magnini, và Dan Roth. 2009. Nhận dạng kết luận văn bản: Lý do, đánh giá và các phương pháp. Kỹ thuật Ngôn ngữ Tự nhiên 15(4):i–xvii. https://doi.org/10.1017/S1351324909990209.

Joe Ellis, Jeremy Getman, Dana Fore, Neil Kuster, Zhiyi Song, Ann Bies, và Stephanie Strassel. 2016. Tổng quan về các tài nguyên ngôn ngữ cho các đánh giá TAC KBP 2016: Phương pháp và Kết quả. Kỷ yếu Hội thảo TAC KBP 2016, Viện Tiêu chuẩn và Công nghệ Quốc gia, Maryland, Hoa Kỳ (Ldc). William Ferreira và Andreas Vlachos. 2016. Emergent: một bộ dữ liệu mới cho phân loại lập trường. Trong Kỷ yếu Hội nghị Chương Bắc Mỹ của Hiệp hội Ngôn ngữ Máy tính 2016: Công nghệ Ngôn ngữ Con người. San Diego, California, trang 1163–1168. Joseph L Fleiss. 1971. Đo lường sự đồng thuận trên t hang định danh giữa nhiều đánh giá viên. Tạp chí Tâm lý học 76(5):378. Matt Gardner, Joel Grus, Mark Neumann, Oyvind Tafjord, Pradeep Dasigi, Nelson Liu, Matthew Peters, Michael Schmitz, và Luke Zettlemoyer. 2017. AllenNLP: Một Nền tảng Xử lý Ngôn ngữ Tự nhiên Ngữ nghĩa Sâu. Michael Heilman và Noah A. Smith. 2010. Good Question! xếp hạng thống kê cho

Edward Loper và Steven Bird. 2002. Nltk: Bộ công cụ xử lý ngôn ngữ tự nhiên. Trong Kỷ yếu Hội thảo ACL-02 về Các Công cụ và Phương pháp Hiệu quả cho Giảng dạy Xử lý Ngôn ngữ Tự nhiên và Ngôn ngữ học Máy tính - Tập 1. Hiệp hội Ngôn ngữ học Máy tính, Stroudsburg, PA, USA, ETMTNLP '02, trang 63–70. https://doi.org/10.3115/1118108.1118117. Christopher D Manning, Mihai Surdeanu, John Bauer, Jenny Rose Finkel, Steven Bethard, và David McClosky. 2014. Bộ công cụ xử lý ngôn ngữ tự nhiên Stanford CoreNLP. Trong ACL (Trình diễn Hệ thống). trang 55–60. Mausam, Michael Schmitz, Robert Bart, Stephen Soderland, và Oren Etzioni. 2012. Học ngôn ngữ mở cho khai thác thông tin. Trong Kỷ yếu Hội nghị Liên hợp năm 2012 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên và Học Ngôn ngữ Tự nhiên Máy tính. trang 523–534. Ankur Parikh, Oscar T¨ackstr¨om, Dipanjan Das, và Jakob Uszkoreit. 2016. Mô hình chú ý có thể phân rã cho tự nhiên

Craig Silverman. 2015. Lies, Damn Lies and Viral Content. http://towcenter.org/research/lies-damn-lies-and-viral-content/.

Niket Tandon, Gerard de Melo, and Gerhard Weikum. 2011. Deriving a Web-scale common sense fact database. In *Proceedings of the 25th AAAI Conference on Artificial Intelligence (AAAI 2011)*. AAAI Press, Palo Alto, CA, USA, pages 152–157.

Andreas Vlachos and Sebastian Riedel. 2014. Fact checking: Task definition and dataset construction. In *Proceedings of the ACL 2014 Workshop on Language Technologies and Computational Social Science*. ACL. http://www.aclweb.org/anthology/W14-2508.

William Yang Wang. 2017. "Liar, Liar Pants on Fire": A new benchmark dataset for fake news detection. In *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers)*. http://aclweb.org/anthology/P17-2067.

Craig Silverman. 2015. Dối trá, Khốn nạn và Nội dung lan truyền.
http://towcenter.org/research/lies-damn-lies-and-viral-content/.

Niket Tandon, Gerard de Melo, và Gerhard Weikum. 2011. Khai thác cơ sở dữ liệu kiến thức thông thường ở quy mô web. Trong Kỷ yếu Hội nghị lần thứ 25 về Trí t uệ Nhân tạo AAAI (AAAI 2011). Nhà xuất bản AAAI, Palo Alto, CA, Mỹ, trang 152–157.

Andreas Vlachos và Sebastian Riedel. 2014. Kiểm tra thông tin: Định nghĩa nhiệm vụ và xây dựng tập dữ liệu. Trong Kỷ yếu hội thảo ACL 2014 về Công nghệ Ngôn ngữ và Khoa học Xã hội Tính toán. ACL.
http://www.aclweb.org/anthology/W14-2508.

William Yang Wang. 2017. "Liar, Liar Pants on Fire": Một bộ dữ liệu chuẩn mới cho việc phát hiện tin giả. Trong Kỷ yếu Hội nghị thường niên lần thứ 55 của Hiệp hội Ngôn ngữ học Máy tính (Tập 2: Bài viết ngắn).
http://aclweb.org/anthology/P17-2067.

819