

FactLens: Benchmarking Fine-Grained Fact Verification

Kushan Mitra
Megagon Labs, USA
kushan@megagon.ai

Sajjadur Rahman*
Adobe Inc.
sajjadurr@adobe.com

Dan Zhang
Megagon Labs, USA
dan_z@megagon.ai

Estevam Hruschka
Megagon Labs, USA
estevam@megagon.ai

Abstract

Large Language Models (LLMs) have shown impressive capability in language generation and understanding, but their tendency to hallucinate and produce factually incorrect information remains a key limitation. To verify LLM-generated contents and claims from other sources, traditional verification approaches often rely on holistic models that assign a single factuality label to complex claims, potentially obscuring nuanced errors. In this paper, we advocate for a shift towards fine-grained verification, where complex claims are broken down into smaller sub-claims for individual verification, allowing for more precise identification of inaccuracies, improved transparency, and reduced ambiguity in evidence retrieval. However, generating sub-claims poses challenges, such as maintaining context and ensuring semantic equivalence with respect to the original claim. We introduce FactLens¹, a benchmark for evaluating fine-grained fact verification, with metrics and automated evaluators of sub-claim quality. The benchmark data is manually curated to ensure high-quality ground truth. Our results show alignment between automated FactLens evaluators and human judgments, and we discuss the impact of sub-claim characteristics on the overall verification performance.

1 Introduction

Large Language Models (LLMs) have proven to be powerful tools, demonstrating impressive capabilities in language generation and understanding (Touvron et al., 2023; Brown et al., 2020). However, a well-known limitation of LLMs is their tendency to hallucinate, generating information that is factually incorrect or unsupported by evidence (Ji et al., 2022; Lin et al., 2022). As LLMs become more widespread, especially in applications where

factual accuracy is crucial, there has been increasing research on methods to verify the factuality of LLM-generated content as well as claims from other sources.

Previous works on building fact-checking benchmarks focus on generating claims with a ground truth label, and in some cases provide the evidence/context to verify the claim (Aly et al., 2021; Schlichtkrull et al., 2024). Claims are generated using human annotators (Aly et al., 2021), synthetic processes (Fatahi Bayat et al., 2023; Tang et al., 2024a), or considering LLM outputs on Question-Answering tasks (Wang et al., 2024). To increase the complexity of the fact-checking process, the claims are generated from source data of multiple domains & modalities, such as Wikipedia text and/or tables (Thorne et al., 2018; Chen et al., 2020; Aly et al., 2021), Web Pages (Schlichtkrull et al., 2024), Knowledge Graphs (Kim et al., 2023), online posts/chats (Wang et al., 2024; Li et al., 2024), and QA tasks from various domains such as statistics, finance, legal, etc (Jacovi et al., 2024).

These works also provide baseline fact-checking pipelines, which typically involves two main stages: (1) the retrieval of relevant evidence using Search APIs and multimodal data-lakes (Tang et al., 2024b; Schlichtkrull et al., 2024) and (2) the verification of claims based on that evidence using NLI-based, LLM-based and fine-tuned fact-verification models (Li et al., 2024). Some works also explore delegating these steps entirely to an LLM-based policy framework (Li et al., 2024; Peng et al., 2023).

Despite this structured pipeline, most existing methods rely on a holistic verification model, where complex claims are assigned a single factuality label, often obscuring the nuanced nature of the errors or inaccuracies in the claims. In this work, we echo the sentiments of Wang et al. (2024); Liu et al. (2020); Pan et al. (2023); Min et al. (2023); Si et al. (2024) for a shift towards fine-grained verification of complex claims, where claims are decom-

FactLens: Đánh giá Chuẩn Xác Xác Minh Thông Tin Chi Tiết

Kushan Mitra
Megagon Labs, Hoa Kỳ
kushan@megagon.ai

Sajjadur Rahman*
Adobe Inc.
sajjadurr@adobe.com

Dan Zhang
Megagon Labs, Mỹ
dan_z@megagon.ai

Estevam Hruschka
Megagon Labs, USA
estevam@megagon.ai

Tóm tắt

Các Mô Hình Ngôn Ngữ Lớn (LLMs) đã thể hiện khả năng ấn tượng trong việc tạo và hiểu ngôn ngữ, nhưng xu hướng ảo giác và sản xuất thông tin sai sự thật vẫn là một hạn chế quan trọng. Để kiểm chứng nội dung do LLM tạo ra và các tuyên bố từ các nguồn khác, các phương pháp xác minh truyền thống thường dựa vào các mô hình toàn diện gán một nhãn tính xác thực duy nhất cho các tuyên bố phức tạp, có thể che khuất các lỗi tinh vi. Trong bài báo này, chúng tôi ủng hộ việc chuyển sang kiểm chứng chi tiết, nơi các tuyên bố phức tạp được chia nhỏ thành các tuyên bố phụ để xác minh riêng, cho phép xác định chính xác hơn các sai sót, cải thiện tính minh bạch và giảm sự mơ hồ trong việc thu thập bằng chứng. Tuy nhiên, việc tạo ra các tuyên bố phụ đặt ra những thách thức, chẳng hạn như duy trì bối cảnh và đảm bảo sự tương đương về ngữ nghĩa so với tuyên bố gốc. Chúng tôi giới thiệu FactLens¹, một bộ chuẩn để đánh giá kiểm chứng sự thật chi tiết, với các chỉ số và tự động

Độ chính xác về thực tế là rất quan trọng, đã có nghiên cứu ngày càng tăng về các phương pháp xác minh tính xác thực của nội dung do LLM tạo ra cũng như các tuyên bố từ các nguồn khác.

Những công trình trước đây về xây dựng các chuẩn mực kiểm tra sự thật tập trung vào việc tạo ra các tuyên bố với nhân sự thật cơ sở, và trong một số trường hợp cung cấp bằng chứng/bối cảnh để xác minh tuyên bố (Aly et al., 2021; Schlichtkrull et al., 2024). Các tuyên bố được tạo ra bằng cách sử dụng người gán nhãn (Aly et al., 2021), các quy trình tổng hợp (Fatahi Bayat et al., 2023; Tang et al., 2024a), hoặc xem xét các kết quả đầu ra của LLM trong các nhiệm vụ Hỏi-Đáp (Wang et al., 2024). Để tăng độ phức tạp của quy trình kiểm tra sự thật, các tuyên bố được tạo từ dữ liệu nguồn thuộc nhiều miền và dạng thức khác nhau, chẳng hạn như văn bản và/hoặc bảng trên Wikipedia (Thorne et al., 2018; Chen et al., 2020; Aly et al., 2021), trang Web (Schlichtkrull et al., 2024), Đồ thị Kiến thức (Kim et al., 2023), các bài đăng/trò chuyện trực tuyến (Wang et al., 2024; Li et al., 2024), và các nhiệm vụ Hỏi-Đáp từ nhiều lĩnh vực khác nhau như thống kê, tài chính, pháp lý, v.v. (Jacovi et al., 2024).

Những công trình này cũng cung cấp các quy trình kiểm tra sự thật cơ bản, thường bao gồm hai giai đoạn chính: (1) truy xuất bằng chứng liên quan sử dụng các API Tìm kiếm và hồ dữ liệu đa phương thức (Tang et al., 2024b; Schlichtkrull et al., 2024) và (2) xác minh các tuyên bố dựa trên bằng chứng đó bằng các mô hình kiểm tra sự thật dựa trên NLI, dựa trên LLM và mô hình kiểm tra sự thật được tinh chỉnh (Li et al., 2024). Một số công trình cũng nghiên cứu việc ủy quyền hoàn toàn các bước này cho một khuôn khổ chính sách dựa trên LLM (Li et al., 2024; Peng et al., 2023).

Mặc dù có quy trình có cấu trúc này, hầu hết các phương pháp hiện có đều dựa vào mô hình xác minh toàn diện, trong đó các tuyên bố phức tạp được gán một nhãn thực tế duy nhất, thường làm lu mờ bản chất tinh tế của các lỗi hoặc sai sót trong các tuyên bố. Trong công trình này, chúng tôi đồng tình với quan điểm của Wang và cộng sự (2024); Liu và cộng sự (2020); Pan và cộng sự (2023); Min và cộng sự (2023); Si và cộng sự (2024) nhằm chuyển hướng sang xác minh chi tiết các tuyên bố phức tạp, nơi các tuyên bố được giải quyết-

1 Giới thiệu

Các Mô Hình Ngôn Ngữ Lớn (LLMs) đã được chứng minh là những công cụ mạnh mẽ, cho thấy khả năng ấn tượng trong việc tạo và hiểu ngôn ngữ (Touvron et al., 2023; Brown et al., 2020). Tuy nhiên, một hạn chế nổi tiếng của LLMs là xu hướng tạo ra thông tin ảo tưởng, tạo ra thông tin sai sự thật hoặc không được chứng minh bằng bằng chứng (Ji et al., 2022; Lin et al., 2022). Khi LLMs trở nên phổ biến hơn, đặc biệt trong các ứng dụng mà

¹Công việc thực hiện tại Megagon Labs.
<https://github.com/megagonlabs/factlens>

*Work done while at Megagon Labs.
¹<https://github.com/megagonlabs/factlens>

posed into smaller, more manageable sub-claims that can be individually verified. We additionally emphasise on the need to provide evaluation metrics to benchmark such fine-grained verification, and enrich existing benchmarks with fine-grained verification labels.

As shown in Figure 1, the benefits of fine-grained verification are substantial. By breaking down a complex claim into its constituent sub-claims, verification is more precise, allowing for pinpointing exact locations of factual inaccuracies. Additionally, this approach enables more transparent rationalizations and explanations, as each sub-claim can be linked directly to its corresponding evidence or lack thereof. Fine-grained decomposition also narrows the scope of evidence retrieval, making the subsequent verification process more focused and less prone to ambiguity.

Achieving fine-grained verification, however, presents its own challenges. Decomposing a raw, complex claim into smaller sub-claims is not simply a matter of splitting it into sentences. Poorly constructed sub-claims can introduce a variety of issues: they may lose the context necessary for proper verification, lack atomicity, or misrepresent the original information by either omitting key details or introducing new fabricated ones. Ensuring the quality and verifiability of these sub-claims is, therefore, critical for the overall success of the verification process.

To address these challenges, we introduce FactLens, a benchmark designed specifically for fine-grained fact verification. FactLens provides a novel suite of metrics for evaluating the quality of sub-claim generation and incorporates automated evaluators that combine LLM-based assessments with statistical metrics. The dataset has been manually curated to ensure high-quality sub-claims.

Through empirical evaluation, we demonstrate that our sub-claim evaluators align closely with human judgments. Moreover, our end-to-end evaluation shows that these fine-grained scores correlate strongly with improved downstream verification performance. We also present the results of state-of-the-art models on sub-claim generation, revealing the challenges inherent in this task and the need for further research in this area.

2 Evaluating Sub-claims with FactLens

At the core of fine-grained verification is the decomposition of complex claims into smaller, more




Figure 1: Examples of holistic fact verification (upper) failed to identify inaccuracies, whereas fine-grained verification (lower) clearly pinpointed the sources of error. In fine-grained verification, the FactLens Evaluator can be used to assess individual sub-claims and identify any alarming signals that may suggest the need for human intervention or regeneration of the sub-claims.

specific sub-claims when necessary. The accuracy of the overall verification process depends heavily on the quality of these sub-claims; errors (e.g. oversimplification, omission of important details, or incorrect contextualization) in their formulation can lead to flawed verification outcomes. To detect potential issues early on in the sub-claim generation process, we propose a set of metrics to quantitatively assess sub-claim quality across several dimensions.

2.1 Evaluation Metrics

The decomposed sub-claims should meet criteria below to fully realize benefits of fine-grained verification such as more precise identification of inaccuracies, enhanced transparency, and reduced ambiguity during evidence retrieval.

Atomicity Each sub-claim should refer to a single factual unit within the original claim. This ensures if an error occurs, the inaccuracy can be precisely traced back to one or more specific sub-claims. Atomicity measures whether a sub-claim is truly atomic i.e. it focuses on only one relation between a subject and an object. For example, the claim “*The International Olympic Committee (IOC) was established on June 23, 1895, in Paris, France*” is not atomic, as it makes assertions about both the time and location of the IOC’s establishment.

The decomposition process transforms a single claim into a list of sub-claims. It is crucial this

được chia thành các tuyên bố phụ nhỏ hơn, dễ quản lý hơn và có thể được xác minh riêng lẻ. Chúng tôi cũng nhấn mạnh nhu cầu cung cấp các chỉ số đánh giá để so sánh việc xác minh chi tiết như vậy, và bổ sung các bộ chuẩn hiện có với các nhân xác minh chi tiết.

Như được minh họa trong Hình 1, lợi ích của việc xác minh chi tiết là đáng kể. Bằng cách phân tách một tuyên bố phức tạp thành các tuyên bố phụ cấu thành của nó, việc xác minh trở nên chính xác hơn, cho phép xác định chính xác các vị trí sai sót về thực tế. Ngoài ra, phương pháp này cho phép các lý giải và giải thích minh bạch hơn, vì mỗi tuyên bố phụ có thể được liên kết trực tiếp với bằng chứng tương ứng của nó hoặc thiếu bằng chứng. Việc phân tách chi tiết cũng thu hẹp phạm vi thu thập bằng chứng, làm cho quá trình xác minh tiếp theo tập trung hơn và ít mơ hồ hơn.


Tuy nhiên, việc đạt được xác minh chi tiết lại đặt ra những thách thức riêng. Phân tách một tuyên bố phức tạp, thô thành các tuyên bố phụ nhỏ hơn không đơn giản chỉ là chia nó thành các câu. Các tuyên bố phụ được xây dựng kém có thể gây ra nhiều vấn đề: chúng có thể mất đi bối cảnh cần thiết để xác minh đúng, thiếu tính nguyên tử, hoặc trình bày sai thông tin gốc bằng cách bỏ sót các chi tiết quan trọng hoặc thêm các chi tiết giả mạo. Do đó, đảm bảo chất lượng và khả năng xác minh của các tuyên bố phụ này là rất quan trọng cho sự thành công tổng thể của quá trình xác minh.

Để giải quyết những thách thức này, chúng tôi giới thiệu FactLens, một chuẩn đánh giá được thiết kế đặc biệt cho việc xác minh sự thật chi tiết. FactLens cung cấp một bộ chỉ số mới để đánh giá chất lượng tạo ra các phụ đề cáo và tích hợp các công cụ đánh giá tự động kết hợp đánh giá dựa trên LLM với các chỉ số thống kê. Bộ dữ liệu đã được tuyển chọn thủ công để đảm bảo các phụ đề cáo có chất lượng cao.

Thông qua đánh giá thực nghiệm, chúng tôi chứng minh rằng các bộ đánh giá tiểu luận của chúng tôi phù hợp chặt chẽ với các đánh giá của con người. Hơn nữa, đánh giá đầu-cuối của chúng tôi cho thấy các điểm số chi tiết này có sự tương quan mạnh với hiệu suất xác minh hạ lưu được cải thiện. Chúng tôi cũng trình bày kết quả của các mô hình hiện đại nhất trong việc tạo tiểu luận, tiết lộ những thách thức vốn có trong nhiệm vụ này và nhu cầu nghiên cứu thêm trong lĩnh vực này.

2 Đánh giá các tiểu tuyên bố với FactLens

Cốt lõi của việc xác minh chi tiết là sự phân tách các tuyên bố phức tạp thành các phần nhỏ hơn, nhiều hơn



Hình 1: Các ví dụ về xác minh sự thật toàn diện (phía trên) không phát hiện được các sai sót, trong khi xác minh chi tiết (phía dưới) rõ ràng chỉ ra các nguồn lỗi. Trong xác minh chi tiết, Bộ đánh giá FactLens có thể được sử dụng để đánh giá từng tuyên bố phụ và xác định bất kỳ tín hiệu cảnh báo nào có thể gợi ý sự cần thiết phải can thiệp của con người hoặc tái tạo các tuyên bố phụ.

các tiểu khẳng định cụ thể khi cần thiết. Độ chính xác của toàn bộ quá trình xác minh phụ thuộc nhiều vào chất lượng của các tiểu khẳng định này; các lỗi (ví dụ như đơn giản hóa quá mức, bỏ sót chi tiết quan trọng, hoặc đặt sai bối cảnh) trong cách hình thành chúng có thể dẫn đến kết quả xác minh sai lệch. Để phát hiện các vấn đề tiềm ẩn ngay từ đầu trong quá trình tạo tiểu khẳng định, chúng tôi đề xuất một bộ các chỉ số để đánh giá định lượng chất lượng tiểu khẳng định theo nhiều khía cạnh.

2.1 Các chỉ số đánh giá

Các tiểu phẩm đã phân rã nên đáp ứng các tiêu chí dưới đây để thực sự hiện thực hóa các lợi ích của việc xác minh chi tiết như nhận diện chính xác hơn các lỗi không đúng, tăng cường tính minh bạch và giảm sự mơ hồ trong quá trình thu thập bằng chứng.

Tính nguyên tử Mỗi tiểu luận nên đề cập đến một đơn vị thực tế riêng biệt trong luận điểm gốc. Điều này đảm bảo rằng nếu có lỗi xảy ra, sự không chính xác có thể được truy xuất chính xác trở lại một hoặc nhiều tiểu luận cụ thể. Tính nguyên tử đo lường liệu một tiểu luận có thực sự nguyên tử hay không, tức là nó chỉ tập trung vào một mối quan hệ giữa một chủ thể và một đối tượng. Ví dụ, luận điểm “Ủy ban Olympic Quốc tế (IOC) được thành lập vào ngày 23 tháng 6 năm 1895, tại Paris, Pháp” không phải là nguyên tử, vì nó đưa ra các khẳng định về cả thời gian và địa điểm thành lập của IOC.

Quá trình phân rã biến một yêu cầu đơn thành một danh sách các yêu cầu phụ. Điều này là rất quan trọng

Correlation	<i>atomicity</i>		<i>sufficiency</i>		<i>fabrication</i>		<i>coverage</i>		redundancy	
	<i>r</i>	ρ	<i>r</i>	ρ	<i>r</i>	ρ	<i>r</i>	ρ	<i>r</i>	ρ
LLM	0.40	0.39	0.14	0.09	0.34	0.43	0.43	0.45	0.56	0.52
Statistical	0.58	0.59	—	—	0.04	0.05	0.61	0.58	0.10	0.12

Table 1: Correlation of FactLens Evaluator scores with Human annotations on synthetic data (Readability is omitted due to its high subjectivity). *r*: Pearson Correlation Score; ρ : Spearman Correlation Score.

transformation is semantically equivalent, ensuring the combined list of sub-claims faithfully represents the original claim and that each can be independently verified. To address this aspect, we propose the metrics *Sufficiency*, *Fabrication*, and *Coverage*.

Sufficiency To perform fine-grained verification, each sub-claim needs to be independently verifiable. This requires the sub-claims to be properly contextualized to avoid any added ambiguity. *Sufficiency* measures whether the sub-claim is unambiguous and sufficiently contextualized with respect to the original claim. For example, in the original claim “*Amanda Bauer attended the University of Cincinnati. The school’s nickname is Bearcats.*”, the sub-claim “*The school’s nickname is Bearcats*” would be considered low in sufficiency because the reference to the school was omitted in the decomposition, making it ambiguous.

Fabrication The decomposition process must not introduce additional information or attempt to correct factual errors. This metric is especially important when evaluating LLM decomposers, as LLMs are known to suffer from hallucination or the generation of made-up information. For example, in the original claim “*Sydney, the capital of Australia, is known for its Opera House and Harbour Bridge*”, a sub-claim “*Sydney is the capital of New South Wales, Australia*” is considered fabrication. Similarly, with the source claim “*Net sales will reach 30 million if the growth rate in 2024 is the same as in 2023*”, a sub-claim “*The growth rate of 2024 is the same as in 2023*” is considered fabrication because it treats a condition as a claim.

Coverage The list of sub-claims must cover all factual assertions in the original claims, leaving no sub-claims missing. For instance, with the claim “*Amanda Bauer attended the University of Cincinnati, whose nickname is Bearcats*”, if only one sub-claim is generated as “*Amanda Bauer attended the University of Cincinnati*”, the coverage will

be considered low because the assertion about the university’s nickname is missing.

Additionally, some dimensions might not directly affect downstream verifiability and accuracy but capture some nice-to-have characteristics of the sub-claims.

Redundancy This metric measures whether the sub-claims, as a whole, contain redundant facts. When some sub-claims are semantically repetitive, the distribution of the fact-check units might be skewed. For example, if one erroneous sub-claim is repeated three times, the final judgment could shift from “mostly correct except for one sub-claim” to “more than half of the sub-claims were wrong.” Furthermore, redundancy also introduces unnecessary costs in terms of time and computing resources.

Readability This metric assesses how readable the sub-claims are to the end-user and imposes a penalty on unnaturally formed sub-claims.

For each of these metrics, the sub claims are evaluated by assigning a score of ‘low’, ‘medium’ or ‘high’. For *coverage* and *redundancy*, the scores are assigned at the claim level as we consider the sub-claims as a whole. For all other metrics, scores are assigned to each sub-claim and then aggregated.

Ideal metric values: For an ideal claim decomposition, we expect the sub-claim to possess high *atomicity*, high *sufficiency*, high *coverage* and high *readability*, while having low *fabrication* and low *redundancy*.

2.2 FactLens Evaluator

FactLens evaluator utilizes an ensemble method of LLM-generated evaluation scores and statistically computed scores (more details in Appendix B.1 and B.2 respectively). We use LLMs as evaluators due to their ability to scale well compared to human evaluators, as well as their reliability and knowledge across diverse domains. However, acknowledging the limitations of LLMs (Bavaresco et al., 2024; Stureborg et al., 2024), our statistical

Tương quan	<i>tính nguyên tử</i>		<i>sự đủ</i>		<i>sản xuất</i>		<i>phạm vi</i>		dư thừa	
	<i>r</i>	ρ	<i>r</i>	ρ	<i>r</i>	ρ	<i>r</i>	ρ	<i>r</i>	ρ
LLM	0.40	0.39	0.14	0.09	0.34	0.43	0.43	0.45	0.56	0.52
Thống kê	0.58	0.59	—	—	0.04	0.05	0.61	0.58	0.10	0.12

Bảng 1: Mối tương quan giữa điểm số Evaluator của FactLens với các chú thích của con người trên dữ liệu tổng hợp (Độ dễ đọc bị bỏ qua do tính chủ quan cao). *r*: Điểm tương quan Pearson; ρ : Điểm tương quan Spearman.

sự biến đổi về mặt ngữ nghĩa là tương đương, đảm bảo danh sách kết hợp các yêu cầu phụ phản ánh trung thực yêu cầu gốc và rằng mỗi yêu cầu có thể được xác minh độc lập. Để giải quyết khía cạnh này, chúng tôi đề xuất các chỉ số Độ Đầy Đủ, Sự Tạo Ra, và Phạm Vi.

Đầy đủ Để thực hiện xác minh chi tiết, mỗi tuyên bố phụ cần phải có khả năng xác minh độc lập. Điều này yêu cầu các tuyên bố phụ được đặt trong bối cảnh phù hợp để tránh bất kỳ sự mơ hồ bổ sung nào. Đầy đủ đo lường xem tuyên bố phụ có rõ ràng và được đặt trong bối cảnh một cách đầy đủ so với tuyên bố gốc hay không. Ví dụ, trong tuyên bố gốc “Amanda Bauer đã theo học Đại học Cincinnati. Biệt danh của trường là Bearcats.”, tuyên bố phụ “Biệt danh của trường là Bearcats” sẽ được coi là có mức độ đầy đủ thấp vì việc tham chiếu đến trường đã bị bỏ qua trong quá trình phân tách, khiến nó trở nên mơ hồ.

Sáng tạo thông tin quá mức Quá trình phân rã không được phép thêm thông tin bổ sung hoặc cố gắng sửa các lỗi thực tế. Chỉ số này đặc biệt quan trọng khi đánh giá các bộ phân rã LLM, vì LLM được biết là gặp tình trạng ảo tưởng hoặc tạo ra thông tin bịa đặt. Ví dụ, trong tuyên bố gốc “Sydney, thủ đô của Úc, nổi tiếng với Nhà hát Opera và Cầu Cảng”, một tuyên bố phụ “Sydney là thủ phủ của New South Wales, Úc” được coi là sáng tạo thông tin quá mức. Tương tự, với tuyên bố gốc “Doanh số bán hàng ròng sẽ đạt 30 triệu nếu tỷ lệ tăng trưởng trong năm 2024 giống như năm 2023”, một tuyên bố phụ “Tỷ lệ tăng trưởng của năm 2024 giống như năm 2023” được coi là sáng tạo thông tin quá mức vì nó coi một điều kiện như một tuyên bố.

Phạm vi Danh sách các tiểu tuyên bố phải bao quát tất cả các khẳng định thực tế trong các tuyên bố gốc, không bỏ sót tiểu tuyên bố nào. Chẳng hạn, với tuyên bố “Amanda Bauer đã theo học tại Đại học Cincinnati, có biệt danh là Bearcats”, nếu chỉ tạo ra một tiểu tuyên bố là “Amanda Bauer đã theo học tại Đại học Cincinnati”, thì phạm vi sẽ

được coi là thấp vì tuyên bố về biệt danh của trường đại học bị thiếu.

Ngoài ra, một số khía cạnh có thể không ảnh hưởng trực tiếp đến khả năng xác minh và độ chính xác về sau nhưng lại nắm bắt được một số đặc điểm mong muốn của các tiểu yêu cầu.

Thừa Thông tin Chỉ số này đo lường liệu các tuyên bố phụ, nhìn chung, có chứa các sự thật thừa hay không. Khi một số tuyên bố phụ lặp lại về mặt ngữ nghĩa, sự phân bố của các đơn vị kiểm tra sự thật có thể bị lệch. Ví dụ, nếu một tuyên bố phụ sai lặp lại ba lần, đánh giá cuối cùng có thể chuyển từ “hầu hết đúng ngoại trừ một tuyên bố phụ” sang “hơn một nửa các tuyên bố phụ là sai.” Hơn nữa, thừa thông tin cũng gây ra chi phí không cần thiết về thời gian và tài nguyên tính toán.

Độ dễ đọc Chỉ số này đánh giá mức độ dễ đọc của các phụ khiếu nại đối với người dùng cuối và áp đặt một hình phạt đối với các phụ khiếu nại được hình thành một cách không tự nhiên.

Đối với mỗi chỉ số này, các tiểu tuyên bố được đánh giá bằng cách gán điểm 'thấp', 'trung bình' hoặc 'cao'. Đối với phạm vi và sự dư thừa, các điểm được gán ở cấp độ tuyên bố vì chúng tôi xem các tiểu tuyên bố như một tổng thể. Đối với tất cả các chỉ số khác, điểm được gán cho từng tiểu tuyên bố và sau đó được tổng hợp.

Giá trị chỉ số lý tưởng: Đối với việc phân tích lập luận lý tưởng, chúng ta kỳ vọng các tiểu luận nhận con có tính nguyên tử cao, tính đầy đủ cao, độ bao phủ cao và khả năng đọc cao, trong khi có độ bịa đặt thấp và độ dư thừa thấp.

2.2 Bộ Đánh Giá FactLens

Bộ đánh giá FactLens sử dụng một phương pháp tập hợp các điểm đánh giá do LLM tạo ra và các điểm được tính toán thống kê (chi tiết hơn trong Phụ lục B.1 và B.2 tương ứng). Chúng tôi sử dụng LLM làm người đánh giá nhờ khả năng mở rộng tốt so với người đánh giá, cũng như độ tin cậy và kiến thức của chúng trên nhiều lĩnh vực khác nhau. Tuy nhiên, thừa nhận những hạn chế của LLM (Bavaresco et al., 2024; Stureborg et al., 2024), chúng tôi

scores rely on entity and semantic-based computations.

In Table 1, we report the correlation scores of human annotators with the FactLens Evaluator scores, on a synthetic data (more details in Appendix B.4 and C) that has been carefully curated to cover various types of sub-claim errors. We observe fair to moderate agreement across all dimensions between human evaluations and FactLens Evaluator scores, except for *sufficiency*. The moderate correlation scores can be attributed to the subjectivity involved in judging such metrics. The dependency on contextual information and evidence for assessing the *sufficiency* of a sub-claim contributes to the lower correlation scores for this metric. Nevertheless, our results demonstrate that our computation methods for the FactLens Evaluator align moderately well with human judgments on a dataset with varying sub-claim quality.

3 FactLens: Benchmarking Fine-grained Verification

3.1 Dataset Creation

The FactLens benchmark contains a dataset with ground-truth sub-claims and fine-grained labels. We use 733 instances from *CoverBench* (Jacovi et al., 2024), a fact-checking benchmark focused on complex claim verification sampled from diverse sources and domains, as the original claims.

We utilize two state-of-the-art LLMs — GPT-4o (OpenAI, 2024) and LLaMA-3.1 (Meta, 2024) (details available in Appendix A) — to generate candidate sub-claims and measure the quality of these generations using the FactLens Evaluator. To ensure the high quality of the generated sub-claims, we engage human annotators (details provided in the Appendix C) to review all sub-claims and manually generate the ground-truth sub-claims, correcting any inaccuracies in the LLM-generated sub-claims (details in Appendix F).

To isolate the benefits of fine-grained verification, we do not perform the step of retrieving evidence or context for each sub-claim. Instead, we use the evidence and context provided in CoverBench, along with the generated sub-claims, to perform fact verification. This approach eliminates variability in the results that could arise from different methods and processes of evidence retrieval.

The next step in fine-grained verification involves using a ‘verifier’ model to fact-check each sub-claim against the provided evidence. In this




Figure 2: Impact of sub-claim quality metrics on verification performance. See Appendix E for details.

work, we use GPT-4o-mini as our verifier model across all experiments to maintain consistency.

This verification method enables an enriched fine-grained evaluation. To compare the performance of fine-grained verification labels (for each sub-claim) with the holistic verification label, we aggregate the fine-grained labels as false if at least one of the fine-grained labels is also false; otherwise, the claim is considered true.

3.2 Claim Decomposition: Model Performance

We utilize the prompt defined in Table 3 to decompose claims using GPT-4o and Llama-3.1 (405B). In Table 2, we tabulate the evaluation performance of both these models on the claim decomposition task using FactLens Evaluator.

For each instance, we map the ‘low’, ‘medium’, ‘high’ scores (‘non-atomic-2’, ‘non-atomic-1’, ‘atomic’ for *atomicity*) to numerical values (1, 2, 3 respectively), and report the average for each metric across all 733 instances in the *CoverBench* dataset.

Both models have similar performance and perform well on the task, as per expected results of having sub-claims which are highly sufficient, low in fabrication, high in coverage, low in redundancy and possess high readability. The *atomicity* scores are far lower, as we qualitatively observe several instances of the type having one subject but multiple objects (‘non-atomic-1’ which is mapped to a score of 2)

các điểm số dựa vào các phép tính dựa trên t hực thể và ngữ nghĩa.

Trong Bảng 1, chúng tôi báo cáo các điểm t ương quan của các nhà chủ thích con người với các điểm của Bộ đánh giá FactLens, trên một dữ liệu tổng hợp (chi tiết hơn trong Phụ lục B.4 và C) đã được tuyển chọn cẩn thận để bao phủ các loại lỗi tiểu khẳng định khác nhau. Chúng tôi quan sát t hấy sự đồng thuận từ vừa phải đến trung bình trên tất cả các khía cạnh giữa đánh giá của con người và các điểm của Bộ đánh giá FactLens, ngoại trừ khía cạnh đầy đủ. Các điểm tương quan vừa phải có thể được lý giải bởi tính chủ quan liên quan đến việc đánh giá các chỉ số như vậy. Sự phụ thuộc vào thông tin ngữ cảnh và bằng chứng để đánh giá độ đầy đủ của một tiểu khẳng định góp phần làm cho các điểm tương quan của chỉ số này thấp hơn. Tuy nhiên, kết quả của chúng tôi chứng minh rằng các phương pháp tính toán của chúng tôi cho Bộ đánh giá FactLens tương đồng vừa phải với đánh giá của con người trên một tập dữ liệu với chất lượng tiểu khẳng định khác nhau.

3 FactLens: Đánh giá kiểm chứng chi tiết


3.1 Tạo bộ dữ liệu

Bộ dữ liệu chuẩn FactLens chứa một tập dữ liệu với các tuyên bố phụ có sự thật và các nhãn chi tiết. Chúng tôi sử dụng 733 trường hợp từ CoverBench (Jacovi et al., 2024), một bộ dữ liệu chuẩn kiểm tra sự thật tập trung vào việc xác minh các tuyên bố phức tạp được lấy mẫu từ nhiều nguồn và lĩnh vực khác nhau, làm các tuyên bố gốc.

Chúng tôi sử dụng hai mô hình ngôn ngữ l ớn tiên tiến — GPT-4o (OpenAI, 2024) và LLaMA-3.1 (Meta, 2024) (chi tiết có trong Phụ lục A) — để tạo các giả định phụ ứng cử viên và đo lường chất lượng của các kết quả này bằng Bộ đánh giá FactLens. Để đảm bảo chất lượng cao của các giả định phụ được tạo ra, chúng tôi sử dụng các chú giải viên con người (chi tiết có trong Phụ lục C) để xem xét tất cả các giả định phụ và tự tay tạo ra các giả định phụ chuẩn xác, sửa chữa bất kỳ sai sót nào trong các giả định phụ do LLM tạo ra (chi tiết trong Phụ lục F).

Để tách riêng các lợi ích của việc xác minh chi tiết, chúng tôi không thực hiện bước thu thập bằng chứng hoặc ngữ cảnh cho từng tuyên bố phụ. Thay vào đó, chúng tôi sử dụng bằng chứng và ngữ cảnh được cung cấp trong CoverBench, cùng với các tuyên bố phụ được tạo ra, để thực hiện xác minh s ự thật. Phương pháp này loại bỏ sự biến đổi trong kết quả có thể phát sinh từ các phương pháp và quy trình thu thập bằng chứng khác nhau.

Bước tiếp theo trong việc kiểm tra chi tiết bao gồ m sử dụng một mô hình ‘người kiểm chứng’ để kiểm tra tính xác thực của từng tuyên bố phụ dựa trên bằng chứng được cung cấp. Trong điều này



Hình 2: Tác động của các chỉ số chất lượng phụ-tuyên đến hiệu suất xác minh. Xem Phụ lục E để biết chi tiết.

Trong công việc, chúng tôi sử dụng GPT-4o-mini làm mô hình kiểm chứng trong tất cả các thí nghiệm để duy trì sự nhất quán.

Phương pháp xác minh này cho phép đánh giá tinh vi và chi tiết hơn. Để so sánh hiệu suất của các nhãn xác minh chi tiết (cho từng tiểu yêu cầu) với nhãn xác minh tổng thể, chúng tôi tổng hợp các nhãn chi tiết là sai nếu ít nhất một trong các nhãn chi tiết cũng là sai; ngược lại, yêu cầu được coi là đúng.

3.2 Phân rã Yêu cầu: Hiệu suất Mô hình

Chúng tôi sử dụng gợi ý được định nghĩa trong Bảng 3 để phân tách các phát biểu bằng GPT-4o và Llama-3.1(405B). Trong Bảng 2, chúng tôi lập bảng hiệu suất đánh giá của cả hai mô hình này trên nhiệm vụ phân tách phát biểu bằng FactLens Evaluator.

Đối với mỗi trường hợp, chúng tôi ánh xạ các điểm ‘thấp’, ‘trung bình’, ‘cao’ (‘non-atomic-2’, ‘non-atomic-1’, ‘atomic’ đối với tính nguyên tử) thành các giá trị số (tương ứng là 1, 2, 3), và báo cáo giá trị trung bình cho mỗi chỉ số trên tất cả 733 trường hợp trong bộ dữ liệu CoverBench.

Cả hai mô hình đều có hiệu năng tương tự nhau và thực hiện tốt nhiệm vụ, như kết quả mong đợi khi các tuyên bố phụ có độ đầy đủ c ao, ít bịa đặt, bao phủ rộng, ít dư thừa và có khả năng đọc cao. Điểm nguyên tử thấp hơn nhiều, vì chúng tôi quan sát định tính một số trường hợp loại này có một chủ thể nhưng nhiều đối tượng (‘non-atomic-1’ được gán điểm 2)

Model	Atomicity $\uparrow$	Sufficiency $\uparrow$	Fabrication $\downarrow$	Coverage $\uparrow$	Redundancy $\downarrow$	Readability $\uparrow$
<i>Llama-3.1</i>	1.87	2.85	1.01	2.88	1.09	2.96
<i>GPT-4o</i>	1.82	2.85	1.02	2.89	1.15	2.95

Table 2: Measure of sub-claim quality using prompt-based contextualized decomposition. We report average scores on *CoverBench*. Up & down arrows indicate which metrics should ideally be high (~ 3) or low (~ 1) respectively.

3.3 Evaluation Results

In fine-grained verification, our FactLens evaluators can act as judges of generated sub-claims, providing early revision signals if the sub-claims might lead to problematic verifications. To illustrate this, we perform an end-to-end evaluation (as shown in Figure 2) to highlight how the final verification performance is affected by the quality of the sub-claims. For example, we expect high-quality sub-claims to exhibit low *fabrication* scores. We note that for claim decompositions with a *fabrication* score classified as ‘low,’ the downstream fact-checking performance i.e. F1-score, is higher compared to those with ‘medium’ or ‘high’ fabrication scores.

Similarly, we observe trends where sub-claims with higher *atomicity*, *sufficiency*, *coverage*, and *readability* scores demonstrate better verification performance. Although sub-claims with lower *redundancy* scores perform marginally better, the overall verification performance remains similar. This can be explained by the fact that highly redundant sub-claims may simply repeat claims without negatively impacting the final verification label.

4 Conclusion

In this paper, we introduce the benchmark FactLens to evaluate fine-grained claim verification, enriching existing benchmarks. We also identify important metrics for assessing the quality of fine-grained sub-claims and propose an automated evaluator to provide early signals of decomposition failures and evaluate claim decomposition approaches.

Limitations

Computation of Metrics We utilize two methods for computation of FactLens Evaluation metrics: LLM-based and statistically computed. Using LLMs as evaluators/judges is a research field being explored and improved continuously. However, existing works (Stureborg et al., 2024; Bavaresco et al., 2024) have highlighted the limitations of using LLMs in such evaluation tasks, with their scores being skewed and inconsistent.

To mitigate inconsistency, we provided specific instructions in the prompt (Table 4) to LLMs. We measured the agreement & correlation scores of LLMs with human judgement scores, observing fair-moderate agreement across most metrics. Furthermore, we propose our own definitions for computation of the FactLens Evaluator scores. However, we acknowledge the limitations in our computational approach as well, with it relying on the method for entity extraction, which may produce variable results. We aim to propose more concrete definitions for these metrics in future works.

Evidence Retrieval To ensure there is no variability in the fact-verification task, in this work we utilize the ground truth evidence which is present in the *CoverBench* dataset. This allows us to solely measure the dependency of fact-verification on the claim-decomposition and sub-claim quality. With our FactLens Benchmark, we provide motivation for fine-grained labels to soon be included across fact-verification benchmarks. In future works, we hope to show how claim decompositions may also improve the evidence search & retrieval process.

Fact Verification Models Previous works compared different verification models in the fact checking task. Tang et al. (2024a) contrast the performance of MNLI-based, LLM-based and their proposed fine-tuned models for fact-verification. In this work, we choose to use GPT-4o-mini as our only verifier model, as our aim is not to propose stronger models for verification; but to illustrate the benefits of fine-grained verification even using simpler off-the-shelf verifier models.

What are Facts? Fact extraction is a domain which still has a lot of room for improvement. Some previous works (Wang et al., 2024) also distinguish between factual claims, opinions and standard sentences. In this work, we utilize the *CoverBench* claims, which itself is obtained from benchmarks which rely on human or synthetic methods for claim generation. It can be noted that different types of factual claims may be generated with such a process, as some claims may center around

Mô hình	Tính nguyên t ỷ $\uparrow$	Đủ $\uparrow$	Sản xuất $\downarrow$	Phủ sóng $\uparrow$	Dư thừa $\downarrow$	Khả năng đọc $\uparrow$
<i>Llama-3.1</i>	1.87	2.85	1.01	2.88	1.09	2.96
<i>GPT-4o</i>	1.82	2.85	1.02	2.89	1.15	2.95

Bảng 2: Tôi đo lường chất lượng phụ-đề bằng cách phân tích bối cảnh dựa trên gợi ý. Chúng tôi báo cáo điểm trung bình es trên *CoverBe* mũn tên lên & xuống chỉ ra các chỉ số nên cao (~ 3) hoặc thấp (~ 1) tương ứng y.

3.3 Kết quả đánh giá

Trong việc xác minh chi tiết, các đánh giá viên FactLens của chúng tôi có thể đóng vai trò là trọng tài của các tiểu tuyên bố được tạo ra, cung cấp các tín hiệu sửa đổi sớm nếu các tiểu tuyên bố có thể dẫn đến việc xác minh gặp vấn đề. Để minh họa điều này, chúng tôi thực hiện một đánh giá đầu-cuối (như được trình bày trong Hình 2) để làm nổi bật cách hiệu suất xác minh cuối cùng bị ảnh hưởng bởi chất lượng của các tiểu tuyên bố. Ví dụ, chúng tôi kỳ vọng các tiểu tuyên bố chất lượng cao sẽ có điểm giả mạo thấp. Chúng tôi lưu ý rằng đối với các phân rã tuyên bố có điểm giả mạo được phân loại là 'thấp', hiệu suất kiểm chứng thông tin tiếp theo, tức là điểm F1, cao hơn so với những tuyên bố có điểm giả mạo 'trung bình' hoặc 'cao'.

Tương tự, chúng tôi quan sát thấy các xu hướng mà các tuyên bố phụ với mức độ nguyên tử, đầy đủ, bao phủ và khả năng đọc cao hơn thể hiện hiệu suất xác minh tốt hơn. Mặc dù các tuyên bố phụ với điểm dư thừa thấp hơn thực hiện hơi tốt hơn, hiệu suất xác minh tổng thể vẫn tương tự. Điều này có thể được giải thích bởi thực tế là các tuyên bố phụ có mức dư thừa cao có thể chỉ lặp lại các tuyên bố mà không ảnh hưởng tiêu cực đến nhận xác minh cuối cùng.

4 Kết luận

Trong bài báo này, chúng tôi giới thiệu chuẩn mực FactLens để đánh giá việc xác minh các tuyên bố chi tiết, làm phong phú các chuẩn mực hiện có. Chúng tôi cũng xác định các chỉ số quan trọng để đánh giá chất lượng của các tuyên bố phụ chi tiết và đề xuất một bộ đánh giá tự động để cung cấp tín hiệu sớm về các thất bại trong phân tách và đánh giá các phương pháp phân tách tuyên bố.

Hạn chế

Tính Toán Các Chỉ Số Chúng tôi sử dụng hai phương pháp để tính toán các chỉ số đánh giá FactLens: dựa trên LLM và tính toán theo thống kê. Việc sử dụng LLM như người đánh giá/trọng tài là một lĩnh vực nghiên cứu đang được khám phá và cải thiện liên tục. Tuy nhiên, các công trình hiện có (Stureborg et al., 2024; Bavaresco et al., 2024) đã c hỉ ra những hạn chế khi sử dụng LLM trong các nhiệm vụ đánh giá như vậy, với các điểm số của chúng bị lệch và không nhất quán.

Để giảm thiểu sự không nhất quán, chúng tôi đã cung cấp hướng dẫn cụ thể trong lời nhắc (Bảng 4) cho các mô hình ngôn ngữ lớn (LLM). Chúng tôi đã đo điểm đồng thuận và tương quan của các LL M với điểm đánh giá của con người, quan sát thấy sự đồng thuận từ vừa đến trung bình trên hầu hết các chỉ số. Hơn nữa, chúng tôi đề xuất các định nghĩa riêng cho việc tính toán điểm của Bộ đánh giá FactLens. Tuy nhiên, chúng tôi cũng thừa nhận những hạn chế trong phương pháp tính toán của mình, vì nó dựa vào phương pháp trích xuất thực thể, điều này có thể cho kết quả khác nhau. Chúng tôi dự định đề xuất các định nghĩa cụ thể hơn cho những chỉ số này trong các nghiên cứu tương lai.

Thu thập bằng chứng Để đảm bảo không có sự biến động trong nhiệm vụ xác minh sự thật, trong nghiên cứu này chúng tôi sử dụng bằng chứng th ực tế có sẵn trong bộ dữ liệu CoverBench. Điều này cho phép chúng tôi chỉ đo lường sự phụ thuộc của việc xác minh sự thật vào việc phân tách tuyên bố và chất lượng các tuyên bố phụ. Với Bộ chuẩn FactLens của chúng tôi, chúng tôi cung cấp động l ực để các nhà chi tiết sớm được bao gồm trong các bộ chuẩn xác minh sự thật. Trong các nghiên cứu tương lai, chúng tôi hy vọng sẽ chỉ ra cách mà việc phân tách tuyên bố cũng có thể cải thiện quá trình tìm kiếm & thu thập bằng chứng.

Mô Hình Xác Thực Sự Thật Các công trình trước đây đã so sánh các mô hình xác thực khác nhau trong nhiệm vụ kiểm tra sự thật. Tang và cộng sự (2024a) so sánh hiệu suất của các mô hình dựa trên MNLI, dựa trên LLM và các mô hình được tinh chỉnh mà họ đề xuất cho việc xác thực sự thật. Trong nghiên cứu này, chúng tôi chọn sử dụng GPT-4o-mini làm mô hình xác thực duy nhất, bởi vì mục tiêu của chúng tôi không phải là đề xuất các mô hình mạnh hơn cho việc xác thực; mà là để minh họa lợi ích của việc xác thực chi tiết ngay cả khi sử dụng các mô hình xác thực đơn giản có sẵn.

Sự thật là gì? Trích xuất sự thật là một lĩnh vực vẫn còn nhiều chỗ để cải thiện. Một số nghiên cứu trước đây (Wang và cộng sự, 2024) cũng phân biệt giữa các tuyên bố thực tế, ý kiến và câu chuẩn. Trong nghiên cứu này, chúng tôi sử dụng các tuyên bố CoverBench, vốn được lấy từ các chuẩn mực dựa vào phương pháp con người hoặc tổng hợp để tạo ra tuyên bố. Có thể nhận thấy rằng các loại tuyên bố thực tế khác nhau có thể được tạo ra bằng quy trình này, khi một số tuyên bố có thể tập trung vào

a claim that is universally true (eg. “Earth revolves around the Sun.”), while other claims are dependent heavily on the context/evidence (eg. “There are 3 players whose home state is Missouri”).

Moreover, factual claims in real world-scenarios can often be temporal and domain-dependent in nature. For example, a claim such as “*The legal drinking age is 18*” is false in a country such as the United States, however may be true in the United Kingdom, indicating domain dependence. Similarly, evidence retrieved for the claim “*Barack Obama is the President of the US*” is temporal in nature. We note that our results and experiments are also based on existing benchmarks, which do not account for all real-world scenarios.

References

Rami Aly, Zhijiang Guo, Michael Sejr Schlichtkrull, James Thorne, Andreas Vlachos, Christos Christodoulopoulos, Oana Cocarascu, and Arpit Mittal. 2021. [Feverous: Fact extraction and verification over unstructured and structured information](#). In [Thirty-fifth Conference on Neural Information Processing Systems Datasets and Benchmarks Track \(Round 1\)](#).

Anna Bavaresco, Raffaella Bernardi, Leonardo Bertolazzi, Desmond Elliott, Raquel Fern’andez, Albert Gatt, E. Ghaleb, Mario Giulianelli, Michael Hanna, Alexander Koller, Andr’e F. T. Martins, Philipp Mondorf, Vera Neplenbroek, Sandro Pezzelle, Barbara Plank, David Schlangen, Alessandro Suglia, Aditya K Surikuchi, Ece Takmaz, and Alberto Testoni. 2024. [Llms instead of human judges? a large scale empirical study across 20 nlp evaluation tasks](#). [ArXiv](#), abs/2406.18403.

Tom Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared D Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, Sandhini Agarwal, Ariel Herbert-Voss, Gretchen Krueger, Tom Henighan, Rewon Child, Aditya Ramesh, Daniel Ziegler, Jeffrey Wu, Clemens Winter, Chris Hesse, Mark Chen, Eric Sigler, Mateusz Litwin, Scott Gray, Benjamin Chess, Jack Clark, Christopher Berner, Sam McCandlish, Alec Radford, Ilya Sutskever, and Dario Amodei. 2020. [Language models are few-shot learners](#). In [Advances in Neural Information Processing Systems](#), volume 33, pages 1877–1901. Curran Associates, Inc.

Wenhu Chen, Hongmin Wang, Jianshu Chen, Yunkai Zhang, Hong Wang, Shiyang Li, Xiyou Zhou, and William Yang Wang. 2020. Tabfact : A large-scale dataset for table-based fact verification. In [International Conference on Learning Representations \(ICLR\)](#), Addis Ababa, Ethiopia.

Farima Fatahi Bayat, Kun Qian, Benjamin Han, Yisi Sang, Anton Belyy, Samira Khorshidi, Fei

Wu, Ihab Ilyas, and Yunyao Li. 2023. [FLEEK: Factual error detection and correction with evidence retrieved from external knowledge](#). In [Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing: System Demonstrations](#), pages 124–130, Singapore. Association for Computational Linguistics.

Alon Jacovi, Moran Ambar, Eyal Ben-David, Uri Shaham, Amir Feder, Mor Geva, Dror Marcus, and Avi Caciularu. 2024. Coverbench: A challenging benchmark for complex claim verification. [arXiv preprint arXiv:2408.03325](#).

Ziwei Ji, Nayeon Lee, Rita Frieske, Tiezheng Yu, Dan Su, Yan Xu, Etsuko Ishii, Yejin Bang, Delong Chen, Wenliang Dai, Andrea Madotto, and Pascale Fung. 2022. [Survey of hallucination in natural language generation](#). [ACM Computing Surveys](#), 55:1 – 38.

Jiho Kim, Sungjin Park, Yeonsu Kwon, Yohan Jo, James Thorne, and Edward Choi. 2023. [FactKG: Fact verification via reasoning on knowledge graphs](#). In [Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics \(Volume 1: Long Papers\)](#), pages 16190–16206, Toronto, Canada. Association for Computational Linguistics.

Miaoran Li, Baolin Peng, Michel Galley, Jianfeng Gao, and Zhu Zhang. 2024. [Self-checker: Plug-and-play modules for fact-checking with large language models](#). In [Findings of the Association for Computational Linguistics: NAACL 2024](#), pages 163–181, Mexico City, Mexico. Association for Computational Linguistics.

Stephanie Lin, Jacob Hilton, and Owain Evans. 2022. [TruthfulQA: Measuring how models mimic human falsehoods](#). In [Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics \(Volume 1: Long Papers\)](#), pages 3214–3252, Dublin, Ireland. Association for Computational Linguistics.

Zhenghao Liu, Chenyan Xiong, Maosong Sun, and Zhiyuan Liu. 2020. [Fine-grained fact verification with kernel graph attention network](#). In [Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics](#), pages 7342–7351, Online. Association for Computational Linguistics.

Meta. 2024. [Llama-3.1](#).

Sewon Min, Kalpesh Krishna, Xinxì Lyu, Mike Lewis, Wen-tau Yih, Pang Koh, Mohit Iyyer, Luke Zettlemoyer, and Hannaneh Hajishirzi. 2023. [FActScore: Fine-grained atomic evaluation of factual precision in long form text generation](#). In [Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing](#), pages 12076–12100, Singapore. Association for Computational Linguistics.

OpenAI. 2024. [Gpt-4o](#).

Liangming Pan, Xiaobao Wu, Xinyuan Lu, Anh Tuan Luu, William Yang Wang, Min-Yen Kan, and

một tuyên bố là đúng một cách phổ quát (ví dụ: “Trái Đất quay quanh Mặt Trời.”), trong khi các tuyên bố khác phụ thuộc nhiều vào bối cảnh/chứng cứ (ví dụ: “Có 3 cầu thủ có bang quê nhà là Missouri”).

Hơn nữa, các tuyên bố dựa trên sự thật trong các tình huống thực tế thường có tính chất theo thời gian và phụ thuộc vào lĩnh vực. Ví dụ, một tuyên bố như “Tuổi hợp pháp để uống rượu là 18” là sai ở một quốc gia như Hoa Kỳ, tuy nhiên có thể đúng ở Vương quốc Anh, cho thấy sự phụ thuộc vào lĩnh vực. Tương tự, bằng chứng thu thập cho tuyên bố “Barack Obama là Tổng thống Mỹ” có tính chất theo thời gian. Chúng tôi lưu ý rằng kết quả và thí nghiệm của chúng tôi cũng dựa trên các chuẩn mực hiện có, vốn không tính đến tất cả các tình huống trong thế giới thực.

Tài liệu tham khảo

Rami Aly, Zhijiang Guo, Michael Sejr Schlichtkrull, James Thorne, Andreas Vlachos, Christos Christodoulopoulos, Oana Cocarascu và Arpit Mittal. 2021. Feverous: Trích xuất dữ liệu và xác minh sự thật trên thông tin có cấu trúc và không có cấu trúc. Trong [Hội nghị lần thứ ba mươi lăm về Hệ thống Xử lý Thông tin Thần kinh, Phần Dữ liệu và Các Bài kiểm tra Chuẩn \(Vòng 1\)](#).

Anna Bavaresco, Raffaella Bernardi, Leonardo Bertolazzi, Desmond Elliott, Raquel Fernández, Albert Gatt, E. Ghaleb, Mario Giulianelli, Michael Hanna, Alexander Koller, André F. T. Martins, Philipp Mondorf, Vera Neplenbroek, Sandro Pezzelle, Barbara Plank, David Schlangen, Alessandro Suglia, Aditya K Surikuchi, Ece Takmaz, và Alberto Testoni. 2024. Các LLM thay vì thẩm phán con người? Một nghiên cứu thực nghiệm quy mô lớn trên 20 nhiệm vụ đánh giá NLP. [ArXiv](#), abs/2406.18403.

Tom Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared D Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, Sandhini Agarwal, Ariel Herbert-Voss, Gretchen Krueger, Tom Henighan, Rewon Child, Aditya Ramesh, Daniel Ziegler, Jeffrey Wu, Clemens Winter, Chris Hesse, Mark Chen, Eric Sigler, Mateusz Litwin, Scott Gray, Benjamin Chess, Jack Clark, Christopher Berner, Sam McCandlish, Alec Radford, Ilya Sutskever, và Dario Amodei. 2020. Mô hình ngôn ngữ là những người học ít mẫu. Trong [Advances in Neural Information Processing Systems](#), tập 33, trang 1877–1901. Curran Associates, Inc.

Wenhu Chen, Hongmin Wang, Jianshu Chen, Yunkai Zhang, Hong Wang, Shiyang Li, Xiyou Zhou, và William Yang Wang. 2020. Tabfact : Một tập dữ liệu quy mô lớn cho việc xác minh sự thật dựa trên bảng. Trong [Hội nghị Quốc tế về Đại diện Học tập \(ICLR\)](#), Addis Ababa, Ethiopia.

Farima Fatahi Bayat, Kun Qian, Benjamin Han, Yisi Sang, Anton Belyy, Samira Khorshidi, Fei

Wu, Ihab Ilyas, và Yunyao Li. 2023. FLEEK: Phát hiện và sửa lỗi thực tế với bằng chứng được truy xuất từ kiến thức bên ngoài. Trong [Kỷ yếu Hội nghị Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên 2023: Trình diễn Hệ thống](#), trang 124–130, Singapore. Hiệp hội Ngôn ngữ Học Máy Tính.

Alon Jacovi, Moran Ambar, Eyal Ben-David, Uri Shaham, Amir Feder, Mor Geva, Dror Marcus, và Avi Caciularu. 2024. Coverbench: Một chuẩn đánh giá đầy thử thách cho việc xác minh các tuyên bố phức tạp. [arXiv preprint arXiv:2408.03325](#).

Ziwei Ji, Nayeon Lee, Rita Frieske, Tiezheng Yu, Dan Su, Yan Xu, Etsuko Ishii, Yejin Bang, Delong Chen, Wenliang Dai, Andrea Madotto, và Pascale Fung. 2022. Khảo sát về ảo giác trong sinh ngôn ngữ tự nhiên. [Tập chí Khảo sát Máy tính ACM](#), 55:1 – 38.

Jiho Kim, Sungjin Park, Yeonsu Kwon, Yohan Jo, James Thorne, và Edward Choi. 2023. FactKG: Xác minh sự thật thông qua suy luận trên đồ thị tri thức. Trong [Kỷ yếu của Hội nghị thường niên lần thứ 61 của Hiệp hội Ngôn ngữ học Máy tính \(Tập 1: Bài báo dài\)](#), các trang 16190–16206, Toronto, Canada. Hiệp hội Ngôn ngữ học Máy tính.

Miaoran Li, Baolin Peng, Michel Galley, Jianfeng Gao, và Zhu Zhang. 2024. Self-checker: Các mô-đun cảm và chạy để kiểm tra sự thật với các mô hình ngôn ngữ lớn. Trong [Kết quả của Hiệp hội Ngôn ngữ học Máy tính: NAACL 2024](#), trang 163–181, Thành phố Mexico, Mexico. Hiệp hội Ngôn ngữ học Máy tính.

Stephanie Lin, Jacob Hilton, và Owain Evans. 2022. TruthfulQA: Đo lường cách các mô hình bắt chước những sai lầm của con người. Trong [Kỷ yếu Hội nghị thường niên lần thứ 60 của Hiệp hội Ngôn ngữ học Máy tính \(Tập 1: Bài báo dài\)](#), trang 3214–3252, Dublin, Ireland. Hiệp hội Ngôn ngữ học Máy tính.

Zhenghao Liu, Chenyan Xiong, Maosong Sun, và Zhiyuan Liu. 2020. Xác minh sự thật chi tiết với mạng chú ý đồ thị hạt nhân. Trong [Kỷ yếu của Hội nghị hàng năm lần thứ 58 của Hiệp hội Ngôn ngữ học Máy tính](#), trang 7342–7351, Trực tuyến. Hiệp hội Ngôn ngữ học Máy tính.

Meta. 2024. [Llama-3.1](#).

Sewon Min, Kalpesh Krishna, Xinxì Lyu, Mike Lewis, Wen-tau Yih, Pang Koh, Mohit Iyyer, Luke Zettlemoyer, và Hannaneh Hajishirzi. 2023. FActScore: Đánh giá nguyên tử chi tiết về độ chính xác thực tế trong việc tạo văn bản dạng dài. Trong [Kỷ yếu Hội nghị 2023 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên](#), trang 12076–12100, Singapore. Hiệp hội Ngôn ngữ Học Máy tính.

OpenAI. 2024. [Gpt-4o](#).

Liangming Pan, Xiaobao Wu, Xinyuan Lu, Anh Tuan Luu, William Yang Wang, Min-Yen Kan, và

Preslav Nakov. 2023. [Fact-checking complex claims with program-guided reasoning](#). In [Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics](#) (Volume 1: Long Papers), pages 6981–7004, Toronto, Canada. Association for Computational Linguistics.

Baolin Peng, Michel Galley, Pengcheng He, Hao Cheng, Yujia Xie, Yu Hu, Qiuyuan Huang, Lars Lidén, Zhou Yu, Weizhu Chen, and Jianfeng Gao. 2023. [Check your facts and try again: Improving large language models with external knowledge and automated feedback](#). [ArXiv](#), abs/2302.12813.

Michael Schlichtkrull, Yulong Chen, Chenxi Whitehouse, Zhenyun Deng, Mubashara Akhtar, Rami Aly, Zhijiang Guo, Christos Christodoulopoulos, Oana Cocarascu, Arpit Mittal, James Thorne, and Andreas Vlachos. 2024. [The automated verification of textual claims \(AVeriTeC\) shared task](#). In [Proceedings of the Seventh Fact Extraction and VERification Workshop \(FEVER\)](#), pages 1–26, Miami, Florida, USA. Association for Computational Linguistics.

Jiasheng Si, Yibo Zhao, Yingjie Zhu, Haiyang Zhu, Wenpeng Lu, and Deyu Zhou. 2024. [CHECK-WHY: Causal fact verification via argument structure](#). In [Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics](#) (Volume 1: Long Papers), pages 15636–15659, Bangkok, Thailand. Association for Computational Linguistics.

Rickard Stureborg, Dimitris Alikaniotis, and Yoshi Suhara. 2024. [Large language models are inconsistent and biased evaluators](#). [ArXiv](#), abs/2405.01724.

Liyan Tang, Philippe Laban, and Greg Durrett. 2024a. [MiniCheck: Efficient fact-checking of LLMs on grounding documents](#). In [Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing](#), pages 8818–8847, Miami, Florida, USA. Association for Computational Linguistics.

Nan Tang, Chenyu Yang, Ju Fan, Lei Cao, Yuyu Luo, and Alon Y. Halevy. 2024b. [Verifai: Verified generative ai](#). In [14th Conference on Innovative Data Systems Research \(CIDR 2024\)](#), Chaminade, HI, USA.

James Thorne, Andreas Vlachos, Christos Christodoulopoulos, and Arpit Mittal. 2018. [FEVER: a large-scale dataset for fact extraction and VERification](#). In [Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 \(Long Papers\)](#), pages 809–819, New Orleans, Louisiana. Association for Computational Linguistics.

Hugo Touvron, Thibaut Lavril, Gautier Izacard, Xavier Martinet, Marie-Anne Lachaux, Timothée Lacroix, Baptiste Rozière, Naman Goyal, Eric Hambro, Faisal Azhar, Aurelien Rodriguez, Armand Joulin, Edouard Grave, and Guillaume Lample. 2023. [Llama: Open](#)

[and efficient foundation language models](#). [ArXiv](#), abs/2302.13971.

Yuxia Wang, Revanth Gangi Reddy, Zain Muhammad Mujahid, Arnav Arora, Aleksandr Rubashevskii, Ji-ahui Geng, Osama Mohammed Afzal, Liangming Pan, Nadav Borenstein, Aditya Pillai, Isabelle Augenstein, Iryna Gurevych, and Preslav Nakov. 2024. [Factcheck-bench: Fine-grained evaluation benchmark for automatic fact-checkers](#). In [Findings of the Association for Computational Linguistics: EMNLP 2024](#), pages 14199–14230, Miami, Florida, USA. Association for Computational Linguistics.

Tianyi Zhang, Varsha Kishore, Felix Wu, Kilian Q. Weinberger, and Yoav Artzi. 2019. [Bertscore: Evaluating text generation with bert](#). [ArXiv](#), abs/1904.09675.

A Claim Decomposition

We utilize few-shot prompting to decompose a claim into sub-claims. Table 3 shows the prompt used to capture the objective of generating sub-claims which are atomic, yet contextualized with enough information preserved from the original claim.

For the few-shot demonstrations we sample 4 instances from the FEVEROUS dataset (Aly et al., 2021), ensuring no overlap with the *CoverBench* data. Finally in the prompt, we randomly select 3 of the 4 demonstrations and shuffle the order, to ensure there is no bias.

We utilize GPT-4o and Llama-3.1(405B) models for this task, with temperature = 0.

B Evaluating Claim Decomposition

To evaluate the sub-claims, our FactLens Evaluator utilizes LLM-generated as well as statistically computed scores.

B.1 Prompt for Evaluating Claim Decomposition

In Table 4, we provide the prompt to LLMs used for evaluating the claim decompositions across the 6 metrics defined in Section 2.1. We provide clear instructions using which LLMs can judge the claim decompositions across different dimensions. For all metrics except “coverage” and “redundancy”, the sub-claims are passed one at a time to obtain sub-claim level evaluation. “Coverage” and “redundancy” are used to judge the sub-claims as a whole, hence for these metrics, we provide the entire set of sub-claim decompositions for that instance. For “atomicity” we ask the LLM to output a label as

Preslav Nakov. 2023. Kiểm chứng các tuyên bố phức tạp bằng suy luận theo hướng chương trình. Trong [Kỷ yếu Hội nghị thường niên lần thứ 61 của Hiệp hội Ngôn ngữ học Máy tính](#) (Tập 1: Bài báo dài), trang 6981–7004, Toronto, Canada. Hiệp hội Ngôn ngữ học Máy tính.

Baolin Peng, Michel Galley, Pengcheng He, Hao Cheng, Yujia Xie, Yu Hu, Qiuyuan Huang, Lars Lidén, Zhou Yu, Weizhu Chen, và Jianfeng Gao. 2023. Kiểm tra các sự thật của bạn và thử lại: Cải thiện các mô hình ngôn ngữ lớn với kiến thức bên ngoài và phản hồi tự động. [ArXiv](#), abs/2302.12813.

Michael Schlichtkrull, Yulong Chen, Chenxi Whitehouse, Zhenyun Deng, Mubashara Akhtar, Rami Aly, Zhijiang Guo, Christos Christodoulopoulos, Oana Cocarascu, Arpit Mittal, James Thorne và Andreas Vlachos. 2024. Nhiệm vụ chia sẻ xác minh tự động các tuyên bố văn bản (AVeriTeC). Trong [Kỷ yếu của Hội thảo lần thứ bảy về Trích xuất Thực tế và Xác minh \(FEVER\)](#), trang 1–26, Miami, Florida, Mỹ. Hiệp hội Ngôn ngữ học Máy tính.

Jiasheng Si, Yibo Zhao, Yingjie Zhu, Haiyang Zhu, Wenpeng Lu, và Deyu Zhou. 2024. CHECK-WHY: Xác minh sự thật nguyên nhân thông qua cấu trúc lập luận. Trong [Kỷ yếu Hội nghị thường niên lần thứ 62 của Hiệp hội Ngôn ngữ học Máy tính](#) (Tập 1: Bài báo dài), các trang 15636–15659, Bangkok, Thái Lan. Hiệp hội Ngôn ngữ học Máy tính.

Rickard Stureborg, Dimitris Alikaniotis, và Yoshi Suhara. 2024. Các mô hình ngôn ngữ lớn là những người đánh giá không nhất quán và thiên vị. [ArXiv](#), abs/2405.01724.

LiyanTang, Philippe Laban và Greg Durrett. 2024a. MiniCheck: Kiểm tra sự thật hiệu quả của các LLM trên các tài liệu nền tảng. Trong [Kỷ yếu Hội nghị 2024 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên](#), trang 8818–8847, Miami, Florida, Hoa Kỳ. Hiệp hội Ngôn ngữ Học Máy Tính.

Nan Tang, Chenyu Yang, Ju Fan, Lei Cao, Yuyu Luo, và Alon Y. Halevy. 2024b. Verifai: Trí tuệ nhân tạo sinh tạo đã được xác minh. Trong [Hội nghị lần thứ 14 về Nghiên cứu Hệ thống Dữ liệu Sáng tạo \(CIDR 2024\)](#), Chaminade, HI, Mỹ.

James Thorne, Andreas Vlachos, Christos Christodoulopoulos, và Arpit Mittal. 2018. FEVER: một bộ dữ liệu quy mô lớn cho việc trích xuất và xác minh sự thật. Trong [Kỷ yếu Hội nghị 2018 của Chương Bắc Mỹ Hiệp hội Ngôn ngữ học Máy tính: Công nghệ Ngôn ngữ Con người, Tập 1 \(Bài báo Dài\)](#), trang 809–819, New Orleans, Louisiana. Hiệp hội Ngôn ngữ học Máy tính.

Hugo Touvron, Thibaut Lavril, Gautier Izacard, Xavier Martinet, Marie-Anne Lachaux, Timothée Lacroix, Baptiste Rozière, Naman Goyal, Eric Hambro, Faisal Azhar, Aurelien Rodriguez, Armand Joulin, Edouard Grave, và Guillaume Lample. 2023. Llama: Mở

và các mô hình ngôn ngữ nền tảng hiệu quả. [ArXiv](#), abs/2302.13971.

Yuxia Wang, Revanth Gangi Reddy, Zain Muhammad Mujahid, Arnav Arora, Aleksandr Rubashevskii, Ji-ahui Geng, Osama Mohammed Afzal, Liangming Pan, Nadav Borenstein, Aditya Pillai, Isabelle Augenstein, Iryna Gurevych và Preslav Nakov. 2024. Factcheck-bench: Bộ đánh giá chi tiết cho các công cụ kiểm tra sự thật tự động. Trong [Kết quả của Hiệp hội Ngôn ngữ Học Máy Tính: EMNLP 2024](#), trang 14199–14230, Miami, Florida, Mỹ. Hiệp hội Ngôn ngữ Học Máy Tính.

Tianyi Zhang, Varsha Kishore, Felix Wu, Kilian Q. Weinberger, và Yoav Artzi. 2019. Bertscore: Đánh giá sinh văn bản với BERT. [ArXiv](#), abs/1904.09675.

Phân rã Yêu cầu

Chúng tôi sử dụng phương pháp gợi ý ít ví dụ để phân tách một tuyên bố thành các tuyên bố phụ. Bảng 3 trình bày gợi ý được sử dụng để nắm bắt mục tiêu tạo ra các tuyên bố phụ mang tính nguyên tử, nhưng vẫn bối cảnh hóa với đủ thông tin được giữ lại từ tuyên bố gốc.

Đối với các minh họa few-shot, chúng tôi lấy mẫu 4 trường hợp từ bộ dữ liệu FEVEROUS (Aly et al., 2021), đảm bảo không trùng lặp với dữ liệu CoverBench. Cuối cùng trong lời nhắc, chúng tôi chọn ngẫu nhiên 3 trong 4 minh họa và xáo trộn thứ tự, để đảm bảo không có sự thiên vị.

Chúng tôi sử dụng các mô hình GPT-4o và Llama-3.1(405B) cho nhiệm vụ này, với nhiệt độ = 0.

B Đánh giá Phân tách Yêu cầu

Để đánh giá các tuyên bố phụ, Bộ đánh giá FactLens của chúng tôi sử dụng các điểm số do LLM tạo ra cũng như các điểm số được tính toán theo thống kê.

B.1 Lời nhắc để Đánh giá Phân rã Yêu cầu

Trong Bảng 4, chúng tôi cung cấp lời nhắc cho LLMs được sử dụng để đánh giá phân rã khẳng định qua 6 chỉ số được định nghĩa trong Mục 2.1. Chúng tôi cung cấp hướng dẫn rõ ràng mà theo đó LLMs có thể đánh giá phân rã khẳng định qua các khía cạnh khác nhau. Đối với tất cả các chỉ số ngoại trừ “coverage” và “redundancy”, các tiêu khẳng định được đưa vào từng cái một để thu được đánh giá ở cấp độ tiêu khẳng định. “Coverage” và “redundancy” được sử dụng để đánh giá các tiêu khẳng định như một tổng thể, do đó đối với các chỉ số này, chúng tôi cung cấp toàn bộ tập hợp các phân rã tiêu khẳng định cho trường hợp đó. Đối với “atomicity”, chúng tôi yêu cầu LLM đưa ra nhãn dưới dạng

We aim to fact-check a textual claim. To make the fact-checking task simpler, we break down a claim into simpler, atomic sub-claims to fact-check as needed. Note that atomic sub-claims refer to unit claims within the original claim, that refer to a single concept that can be independently verified without having to refer to the original claim. Verification of the sub-claims should not require aggregation of facts or multi-hop reasoning over concepts. However, the sub-claim should have all the contextual information preserved from the original claim. Your task is to break down a claim into atomic sub-claims for fact checking only if needed. If the original claim itself is a unit claim, do not break it down. For example: {demonstrations} Note how each sub claim contains atomic information to fact check and is brief, yet is contextualized with all the information needed from the original claim. Now find the sub claims from the following claim. Claim: {claim} Sub_Claims: < your output in form of a list > =====

Table 3: Claim Decomposition Prompt

A factual claim can be broken down into atomic, yet contextualized sub-claims which makes it easier to fact check. You will be provided a claim, and one of the sub-claims which have been extracted from it. Your job is to evaluate this sub-claim on the following metric: {metric} Your answer should either be “low”, “medium” or “high” based on the metric provided. Please be objective and fair in your evaluation. Claim: {claim} Sub-Claim: {sub_claim} ===== <i>The instructions to calculate each metric is passed one at a time as follows:</i> “atomicity”: If the sub-claim is atomic i.e. it is simple and centers around only one subject and one object, and the verification does not require aggregation of facts or multihop reasoning over concepts. Label the sub-claim as either “atomic” which denotes one subject and one object, or “non-atomic-1” which denotes one subject, multiple objects, or “non-atomic-2” which denotes multiple subjects “sufficiency”: If the sub-claim itself is sufficient to be fact-checked without the need of any additional contextual information i.e. the sub-claim contains all the required contextual information to be fact-checked independently and is not ambiguous. Your answer should indicate whether the sub-claim has “low”, “medium” or “high” sufficiency. “redundancy”: If the sub-claims contain redundant or repeated information among them, i.e. multiple semantically equivalent sub-claims. Your answer should indicate whether the sub-claims have “low”, “medium” or “high” redundancy. “coverage”: If the set of sub-claims cover all the facts and information made in the original claim. Your answer should indicate whether the sub-claims have “low”, “medium” or “high” coverage. “fabrication”: If the sub-claim shows a degree of fabrication with respect to the original claim i.e. how much new information is added which was not present in the original claim. Note this is not to be judged according to the factuality of the original claims or sub-claims. Your answer should indicate whether the sub-claim has “low”, “medium” or “high” fabrication. “readability”: If the sub-claim is readable to an end user. Your answer should indicate whether the sub-claim has “low”, “medium” or “high” readability.

Table 4: Prompt for Evaluating Claim Decompositions using LLMs

per specific instructions, while for each of the remaining metrics we prompt the LLM to judge the instance with a “low”, “medium” or “high” score.

We utilize the smaller and cheaper Ope-nAI model GPT-4o-mini for this task, with temperature = 0.

B.2 Statistically Computed Evaluation

To compute the FactLens Evaluation metrics using statistical methods we rely on entity-based and semantic-based calculations. Given one instance, with claim C , we extract all the (Subject,

Object) pairs present within it using gpt-4o-mini ; temperature = 0, and from there create a list of S = subjects, and O = objects. After decomposing the claim, we obtain sub-claims $c = \{c_1, c_2, ..., c_n\}$. For all i in [1, n], we extract the subjects s_i and object o_i lists in a similar manner. We next follow these definitions to calculate the following metrics:

Atomicity To measure atomicity, we use an entity-based computation method of comparing the number of subjects and objects involved in the sub-claim c_i . If c_i revolves around only one

Chúng tôi nhằm mục đích kiểm chứng tính xác thực của một tuyên bố bằng văn bản. Để làm cho nhiệm vụ kiểm chứng dễ dàng hơn, chúng tôi chia nhỏ một tuyên bố thành các tuyên bố phụ đơn giản, nguyên tử để kiểm chứng khi cần. Lưu ý rằng các tuyên bố phụ nguyên tử đề cập đến các tuyên bố đơn vị trong tuyên bố gốc, liên quan đến một khái niệm duy nhất có thể được xác minh độc lập mà không cần tham khảo tuyên bố gốc. Việc xác minh các tuyên bố phụ không nên yêu cầu tổng hợp các sự kiện hoặc suy luận đa bước về các khái niệm. Tuy nhiên, tuyên bố phụ nên giữ nguyên tất cả thông tin bối cảnh từ tuyên bố gốc. Nhiệm vụ của bạn là phân tích một tuyên bố thành các phần tử nguyên tử , yêu cầu kiểm chứng sự thật chỉ khi cần thiết . Nếu chính yêu cầu gốc là một yêu cầu đơn vị, thì không b reak nó xuống. Ví dụ: {cuộc biểu tình} Chú ý cách mỗi tiểu luận chứa thông tin nguyên tử để kiểm tra sự thật và ngắn gọn, nhưng được bối cảnh hóa với tất cả thông tin cần thiết từ luận điểm gốc. Bây giờ hãy tìm các tuyên bố phụ từ tuyên bố sau. Tuyên bố: {claim} Các tuyên bố phụ -: < kết quả của bạn dưới dạng danh sách > =====

Bảng 3: Yêu cầu Phân tích Yêu cầu

Một tuyên bố mang tính thực tế có thể được chia thành các tuyên bố con nguyên tử nhưng có bối cảnh, điều này giúp dễ dàng kiểm tra tính xác thực. Bạn sẽ được cung cấp một tuyên bố, và một trong các tuyên bố con đã được trích xuất từ nó. Nhiệm vụ của bạn là đánh giá tuyên bố con này theo tiêu chí sau: {metric} Câu trả lời của bạn nên là "thấp", "trung bình" hoặc "cao" dựa trên chỉ số được cung cấp. Hãy khách quan và công bằng trong đánh giá của bạn. Yêu cầu: {claim} Tiểu Yêu Cầu: {sub_claim} ===== <i>Các hướng dẫn để tính toán từng chỉ số được truyền từng bước một như sau:</i> “tính nguyên tử”: Nếu tuyên bố phụ là nguyên tử, tức là nó đơn giản và chỉ tập trung vào một chủ thể và một đối tượng, và việc xác minh không yêu cầu tổng hợp các sự kiện hoặc lập luận đa bước về các khái niệm. Gán nhãn cho tuyên bố phụ là “nguyên tử” để chỉ một chủ thể và một đối tượng, hoặc “phủ nguyên tử-1” để chỉ một chủ thể, nhiều đối tượng, hoặc “phủ nguyên tử-2” để chỉ nhiều chủ thể “đủ”: Nếu yêu cầu phụ đủ để kiểm tra mà không cần thêm thông tin ngữ cảnh, tức là yêu cầu phụ chứa đầy đủ thông tin ngữ cảnh cần thiết để kiểm tra độc lập và không gây mơ hồ. Câu trả lời của bạn nên chỉ rõ yêu cầu phụ có mức độ “thấp”, “trung bình” hay “cao”. “tính dư thừa”: Nếu các phụ khiếu nại chứa thông tin dư thừa hoặc bị lặp lại giữa chúng, tức là nhiều phụ khiếu nại có ý nghĩa tương đương. Câu trả lời của bạn nên chỉ ra liệu các phụ khiếu nại có “thấp”, “trung bình” hay “cao” mức độ dư thừa. “coverage”: Nếu tập hợp các tiểu tuyên bố bao phủ tất cả các sự kiện và thông tin được đưa ra trong tuyên bố gốc. Câu trả lời của bạn nên chỉ ra liệu các tiểu tuyên bố có mức độ bao phủ “thấp”, “trung bình” hay “cao”. “sự bịa đặt”: Nếu tuyên bố phụ thể hiện mức độ bịa đặt so với tuyên bố gốc, tức là có bao nhiêu thông tin mới được thêm vào mà không có trong tuyên bố gốc. Lưu ý rằng điều này không được đánh giá dựa trên tính xác thực của các tuyên bố gốc hoặc tuyên bố phụ. Câu trả lời của bạn nên chỉ ra liệu tuyên bố phụ có mức độ bịa đặt “thấp”, “trung bình” hay “cao”. “tính dễ đọc”: Nếu yêu cầu phụ có thể đọc được bởi người dùng cuối. Câu trả lời của bạn nên chỉ ra liệu yêu cầu phụ có “thấp”, “trung bình” hay “cao” về tính dễ đọc.

Bảng 4: Lời nhắc để Đánh giá Phân tích Yêu cầu sử dụng LLMs

theo hướng dẫn cụ thể, trong khi đối với từng chỉ số còn lại, chúng tôi yêu cầu LLM đánh giá trường hợp với điểm “thấp”, “trung bình” hoặc “cao”.

Chúng tôi sử dụng mô hình Ope-nAI nhỏ hơn và rẻ hơn GPT-4o-mini cho nhiệm vụ này, với nhiệt độ = 0.

B.2 Đánh giá Tính toán Thống kê

Để tính toán các chỉ số Đánh giá FactLens bằng cách sử dụng các phương pháp thống kê, chúng tôi dựa vào các phép tính dựa trên thực thể và dựa trên ngữ nghĩa. Với một ví dụ, với tuyên bố C , chúng tôi trích xuất tất cả các (Chủ đề,

Các cặp đối tượng) có mặt trong đó bằng cách sử dụng gpt-4o-mini; nhiệt độ = 0, và từ đó tạo danh sách S = chủ đề và O = đối tượng. Sau khi phân tích tuyên bố, chúng ta thu được các tuyên bố phụ $c = \{c_1, c_2, ..., c_n\}$. Đối với tất cả i trong [1, n], chúng tôi trích xuất danh sách chủ đề s_i và đối tượng o_i theo cách tương tự. Tiếp theo, chúng ta theo các định nghĩa này để tính các chỉ số sau:

Tính nguyên tử Để đo lường tính nguyên tử, chúng tôi sử dụng phương pháp tính toán dựa trên thực thể để so sánh số lượng chủ thể và đối tượng tham gia vào tuyên bố phụ c_i . Nếu c_i chỉ xoay quanh một

subject and one object eg. “*Kurt Cobain was a guitarist*”, it is labeled ‘atomic’.

if $len(s_i) = 1$ and $len(o_i) = 1$,
 $atomicity = \text{‘atomic’}$

If c_i revolves around one subject, but multiple objects eg. “*Kurt Cobain was a guitarist and a singer*”, it is labeled ‘non-atomic-1’.

if $len(s_i) = 1$ and $len(o_i) > 1$,
 $atomicity = \text{‘non-atomic-1’}$

However, if c_i revolves around multiple subjects eg. “*Kurt Cobain was a member of the band Nirvana, which was co-founded with Krist Novoselic*”, it is labeled ‘non-atomic-2’.

if $len(s_i) > 1$,
 $atomicity = \text{‘non-atomic-2’}$

Sufficiency As sufficiency is a tough metric to judge using semantic techniques, we rely on LLM evaluation scores.

Fabrication To calculate fabrication, we count all subjects in each s_i that do not appear in S i.e. subjects in the original claim, and all objects in each o_i that do not appear in O i.e. objects in the original claim.

If the count for fab is equal to 0, i.e. no new entities present in the sub-claims, the *fabrication* is ‘low’. Based on thresholding values, we assign scores of ‘medium’ or ‘high’ *fabrication*.

Coverage To measure *coverage*, we check if the entities (subjects and objects) in all sub-claims c_i include all the subjects S and objects O present in the original claim.

if $\cup(s_i) \forall i = S$ and $\cup(o_i) \forall i = O$,
 $coverage = \text{‘high’}$

In case there is no overlap, $coverage = \text{‘low’}$, and for all other cases $coverage = \text{‘medium’}$

Redundancy To calculate redundancy, we use semantic-based technique by measuring BertScore (Zhang et al., 2019) between each pair of sub-claims. If there is high similarity between two

$$red = \sum_{i=1}^n \sum_{j=1}^n \mathbb{I}(i \neq j, \text{BertScore}(c_i, c_j) > T)$$

, where T is a threshold value to find BertScore(.) similarity and n is the number of sub-claims generate for that instance.

Based on the number of redundant claims found, we assign scores of ‘low’, ‘medium’ and ‘high’.

Readability We rely on LLM generated evaluations to measure readability.

B.3 FactLens Evaluation using Ensemble Method

As previously mentioned, in Table 1 we tabulate the correlation between Human scores and our LLM-generated & statistically computed scores on the synthetic with varying claim decomposition quality. Based on the results across the metrics, we propose to utilize the statistically computed scores for *atomicity* and *coverage* (as they are better correlated than the LLM-generated scores), while using LLM-generated evaluations for the rest of the metrics in our experiment results in Section 3.3.

B.4 Agreement Scores on Synthetic Data

In Table 1 we observed fair to moderate correlation between humans and FactLens Evaluator scores through Pearson and Spearman correlation scores. We provide the corresponding *p-values* in Table 5, from which we conclude the correlation scores for *atomicity*, *coverage* (both LLM-Human and Statistical-Human), *fabrication*, and *redundancy* (LLM-Human) are statistically significant.

In addition to the correlation scores in Table 1, we also report agreement scores between Human annotators and FactLensEvaluator. We report the ordinal Krippendorff’s Alpha score to measure the agreement. We observe fair to moderate agreement across all dimensions except ‘sufficiency’, which can be attributed to the dependency on contextual information and evidence to judge *sufficiency* of a sub-claim.

The synthetic data is curated using 10 claims from the FEVEROUS benchmark and generating expert-annotated claim decompositions with perturbations. For each claim we generate 7 claim decompositions: one with perfect quality sub-claims, one LLM generated sub-claim, and others using perturbations resulting in lower quality sub-claims corresponding to each of the following 5 metrics: *atomicity*, *sufficiency*, *fabrication*, *coverage* and *redundancy*. We exclude *readability* in the agreement-scores, as it is an extremely subjective metric.

chủ ngữ và một tân ngữ ví dụ: “Kurt Cobain là một tay guitar”, nó được gán nhãn là ‘nguyên tử’.

nếu $len(s_i) = 1$ và $len(o_i) = 1$,
tính nguyên tử = ‘nguyên tử’

Nếu c_i xoay quanh một chủ đề, nhưng nhiều đối tượng ví dụ: “Kurt Cobain là một tay guitar và là một ca sĩ”, nó được gán nhãn ‘non-atomic-1’.

nếu $len(s_i) = 1$ và $len(o_i) > 1$,
tính nguyên tử = ‘phi-nguyên-tử-1’

Tuy nhiên, nếu c_i xoay quanh nhiều chủ đề ví dụ: “Kurt Cobain là thành viên của ban nhạc Nirvana, được sáng lập cùng với Krist Novoselic”, nó được gán nhãn là ‘không nguyên tử-2’.

nếu $len(s_i) > 1$, tính nguyên
tử = ‘không nguyên tử-2’

Đầy đủ Vì đầy đủ là một tiêu chí khó để đánh giá bằng các kỹ thuật ngữ nghĩa, chúng tôi dựa vào điểm đánh giá của LLM.

Chế tạo Để tính toán chế tạo, chúng tôi đếm tất cả các chủ thể trong mỗi s_i mà không xuất hiện trong S , tức là các chủ thể trong yêu cầu gốc, và tất cả các đối tượng trong mỗi o_i mà không xuất hiện trong O , tức là các đối tượng trong yêu cầu gốc.

Nếu số lượng cho fab bằng 0, tức là không có thực thể mới nào xuất hiện trong các tiểu tuyên bố, mức độ bịa đặt là ‘thấp’. Dựa trên các giá trị ngưỡng, chúng tôi gán điểm bịa đặt là ‘trung bình’ hoặc ‘cao’.

Phủ sóng Để đo lường phủ sóng, chúng tôi kiểm tra xem các thực thể (chủ thể và đối tượng) trong tất cả các tiểu tuyên bố c_i có bao gồm tất cả các chủ thể S và đối tượng O có trong tuyên bố gốc hay không.

if $\cup(s_i) \forall i = S$ and $\cup(o_i) \forall i = O$,
 $phủ\ sóng = \text{‘cao’}$

Trong trường hợp không có sự chồng chéo, độ bao phủ = ‘thấp’, và trong tất cả các trường hợp khác, độ bao phủ = ‘trung bình’

Dư thừa Để tính toán dư thừa, chúng tôi sử dụng kỹ thuật dựa trên ngữ nghĩa bằng cách đo BertScore (Zhang và cộng sự, 2019) giữa từng cặp các tuyên bố phụ. Nếu có sự tương đồng cao giữa hai

$$red = \sum_{i=1}^n \sum_{j=1}^n \mathbb{I}(i \neq j, \text{BertScore}(c_i, c_j) > T)$$

, trong đó T là giá trị ngưỡng để tìm độ tương đồng BertScore(.) và n là số lượng các luận phụ được tạo ra cho trường hợp đó.

Dựa trên số lượng các yêu cầu thừa được tìm thấy, chúng tôi gán điểm ‘thấp’, ‘trung bình’ và ‘cao’.

Khả năng đọc dựa vào các đánh giá được tạo ra bởi LLM để đo độ dễ đọc.

B.3 Đánh giá FactLens sử dụng phương pháp Tập hợp

Như đã đề cập trước đó, trong Bảng 1 trình bày mối tương quan giữa điểm số của con người và điểm số do LLM của chúng tôi tạo ra & tính toán thống kê trên dữ liệu tổng hợp với chất lượng phân tách luận điểm khác nhau. Dựa trên kết quả trên các chỉ số, chúng tôi đề xuất sử dụng các điểm số tính toán thống kê cho tính nguyên tử và độ bao phủ (vì chúng có sự tương quan tốt hơn so với điểm số do LLM tạo ra), trong khi sử dụng đánh giá do LLM tạo ra cho các chỉ số còn lại trong kết quả thí nghiệm của chúng tôi tại Mục 3.3.

B.4 Điểm Thỏa Thuận trên Dữ Liệu Tổng Hợp

Trong Bảng 1, chúng tôi quan sát thấy mối tương quan từ trung bình đến khá giữa con người và điểm số của Công cụ Đánh giá FactLens thông qua các chỉ số tương quan Pearson và Spearman. Chúng tôi cung cấp các giá trị p tương ứng trong Bảng 5, từ đó chúng tôi kết luận rằng các điểm số tương quan đối với tính nguyên tử, độ bao phủ (cả LLM-Con người và Thống kê-Con người), việc bịa đặt, và sự thừa thãi (LLM-Con người) là có ý nghĩa thống kê.

Bên cạnh các điểm tương quan trong Bảng 1, chúng tôi cũng báo cáo các điểm đồng thuận giữa các người chủ thích là con người và FactLensEvaluator. Chúng tôi báo cáo điểm Alpha của Krippendorff theo thứ tự để đo lường sự đồng thuận. Chúng tôi quan sát thấy sự đồng thuận từ công bằng đến trung bình trên tất cả các chiều trừ ‘độ đầy đủ’, điều này có thể được giải thích bởi việc phụ thuộc vào thông tin ngữ cảnh và bằng chứng để đánh giá độ đầy đủ của một tiểu tuyên bố.

Dữ liệu tổng hợp được tuyển chọn sử dụng 10 tuyên bố từ bộ chuẩn FEVEROUS và tạo ra các phân tách tuyên bố được chủ thích bởi chuyên gia với các biến đổi. Đối với mỗi tuyên bố, chúng tôi tạo 7 phân tách tuyên bố: một với các tuyên bố phụ chất lượng hoàn hảo, một tuyên bố phụ được tạo bởi LLM, và những cái khác sử dụng các biến đổi dẫn đến các tuyên bố phụ chất lượng thấp hơn tương ứng với từng chỉ số sau: tính nguyên tố, sự đầy đủ, sự bịa đặt, phạm vi và sự dư thừa. Chúng tôi loại trừ khả năng đọc trong các điểm thỏa thuận, vì đây là một chỉ số cực kỳ chủ quan.

P-values	<i>atomicity</i>		<i>sufficiency</i>		<i>fabrication</i>		<i>coverage</i>		redundancy	
	<i>r</i>	ρ	<i>r</i>	ρ	<i>r</i>	ρ	<i>r</i>	ρ	<i>r</i>	ρ
LLM	4e-10	5e-10	0.140	0.437	5.1e-4	2.63e-7	2.9e-4	2.4e-4	3.26e-6	7.78e-6
Statistical	1e-9	1e-9	—	—	0.166	0.176	7.7e-8	1.1e-6	0.404	0.332

Table 5: P-values from Table 1: Correlation of FactLens Evaluator scores with Human annotations on synthetic data

Metric	Krippendorff’s Alpha
Atomicity	0.4421
Sufficiency	0.0486
Fabrication	0.4085
Coverage	0.5300
Redundancy	0.4240

Table 6: Alignment of FactLens Evaluator scores with Human annotations on synthetic data

C Expert Annotations

For human annotations on the synthetic data (Section 2.2) and the creation for the benchmark, we recruited two in-house expert annotators. The annotators are proficient in English, currently based in the United States of America, with at least a graduate-level degree. For the task, they were provided the same instructions as the prompt to LLMs in Table 4. The annotators were clearly explained the objective of the task and how their annotations would be utilized.

The inter-annotator agreement score (Krippendorff Alpha) is high, as tabulated in Table 7.

Metric	Inter-Annotator Agreement
Atomicity	0.73
Sufficiency	0.53
Fabrication	0.54
Coverage	0.86
Redundancy	0.94
Readability	0.96

Table 7: Inter-Annotator Agreement score

To measure correlation between the FactLens Evaluator scores and human scores, we do an average of FactLens Evaluator score on a metric with both the annotators, and repeat for all metrics. The human annotators were also used to generate ground-truth sub-claims (Section 3.1).





Figure 3: As complexity (i.e. number of sub-claims) increases, the performance of sub-claim decomposition significantly improves.

D Fine-Grained Verification

We study the benefits of fine-grained fact verification compared to verifying the whole claim in Figure 3.

In order to perform verification, we utilize GPT-4o-mini to judge if a claim is true or false based on the evidence provided. We obtain the ground truth evidence present in the *CoverBench* dataset.

In order to show the benefits of fine-grained verification, we compare it with the method of holistically verifying the original claim without decompositions.

In the first case, we simply pass the original

Giá trị P	<i>tính nguyên tử</i>		<i>sự đủ</i>		<i>sản xuất</i>		<i>phạm vi</i>		dư thừa	
	<i>r</i>	ρ	<i>r</i>	ρ	<i>r</i>	ρ	<i>r</i>	ρ	<i>r</i>	ρ
LLM	4e-10	5e-10	0.140	0.437	5,1e-4	2,63e-7	2,9e-4	2,4e-4	3,26e-6	7,78e-6
Thống kê	1e-9	1e-9	—	—	0.166	0.176	7,7e-8	1,1e-6	0.404	0.332

Bảng 5: Giá trị P từ Bảng 1: Mối tương quan giữa điểm số của Người đánh giá FactLens với các chủ thích của con người trên dữ liệu tổng hợp

Hệ mét	Krippendorff Alpha
Tính nguyên tử	0.4421
Đầy đủ	0.0486
Sản xuất	0.4085
Phạm vi phủ sóng	0.5300
Dư thừa	0.4240

Bảng 6: Sự phù hợp của điểm số FactLensEvaluator với chủ thích của con người trên dữ liệu tổng hợp

Chú thích chuyên gia C



Để thực hiện chú thích của con người trên dữ liệu tổng hợp (Mục 2.2) và việc tạo ra chuẩn đánh giá, chúng tôi đã tuyển dụng hai chuyên gia chú thích nội bộ. Các chuyên gia chú thích này thành thạo tiếng Anh, hiện đang làm việc tại Hoa Kỳ, với ít nhất bằng cấp sau đại học. Cho nhiệm vụ này, họ được cung cấp cùng một hướng dẫn như lời nhắc đối với các mô hình ngôn ngữ lớn trong Bảng 4. Các chuyên gia chú thích đã được giải thích rõ ràng về mục tiêu của nhiệm vụ và cách các chú thích của họ sẽ được sử dụng.

Điểm đồng thuận giữa các người chú thích (Krippendorff Alpha) là cao, như được trình bày trong Bảng 7.

Hệ mét	Giữa các người chú thích
	Thỏa thuận
Tính nguyên tử	0.73
Đủ	0.53
Sản xuất	0.54
Phạm vi	0.86
Dư thừa	0.94
Độ dễ đọc	0.96

Bảng 7: Điểm đồng thuận giữa các người chú thích

Để đo lường mối tương quan giữa điểm số của Người đánh giá FactLens và điểm số của con người, chúng tôi thực hiện trung bình điểm số của Người đánh giá FactLens trên một chỉ số với cả hai người chú thích, và lặp lại cho tất cả các chỉ số. Các người chú thích con người cũng được sử dụng để tạo ra các tuyên bố phụ có tính thật (Mục 3.1).



Hình 3: Khi độ phức tạp (tức là số lượng các tuyên bố phụ) tăng lên, hiệu suất của việc phân tách các tuyên bố phụ cải thiện đáng kể.

D Xác minh chi tiết

Chúng tôi nghiên cứu lợi ích của việc xác minh sự thật chi tiết so với việc xác minh toàn bộ tuyên bố trong Hình 3.

Để thực hiện việc xác minh, chúng tôi sử dụng GPT-4o-mini để đánh giá xem một khẳng định là đúng hay sai dựa trên bằng chứng được cung cấp. Chúng tôi thu thập bằng chứng thực tế có trong tập dữ liệu CoverBench.

Để chứng minh lợi ích của việc xác minh chi tiết, chúng tôi so sánh nó với phương pháp xác minh toàn diện yêu cầu gốc mà không phân tách.

Trong trường hợp đầu tiên, chúng ta chỉ đơn giản truyền bản gốc

claim C along with the evidence to be verified. In the second case, we pass the claim’s decompositions $c = \{c_1, c_2, \dots, c_n\}$ one at a time. For each c_i we obtain a verification label, and then aggregate the labels for that instance. If any one sub-claim is judged false the whole instance is marked false, otherwise true.

We contrast the performance of the fine-grained verification with holistic verification in Figure 3. Here, we assume the number of sub-claims of an instance is indicative of how complex the claim is.

We observe that as the complexity (number of sub-claims) increase, the performance of the fine-grained verification method significantly increases compared to holistic verification.

E Impact of Sub Claim Quality on Verification




Figure 4: Fine-Grained Verification: Logistic Regression Coefficients for Metrics

In Figure 2, we showed how sub-claim quality impacts the end-to-end verification result. To truly understand the benefits of fine-grained decompositions and the FactLens metrics, we only consider those instances for which the number of sub-claims was greater than 1. Here, we illustrate further using

qualitative examples and weights of a logistic regression model to show the influence of FactLens Evaluator Metrics on fine-grained verification.

To deeper understand how each metric influences the final verification, we fit a logistic regression model on the FactLens Evaluator scores on *Cover-Bench*. We specifically study the impact of the metrics *atomicity*, *sufficiency*, *fabrication* and *coverage* as we expect them to influence the final verification more than the “nice-to-have” metrics: *redundancy* and *readability*.

We also conducted an analysis to understand how the scores can collectively predict the final verification accuracy by fitting a logistic regression model and examining the coefficients associated with each metric. Combining the four metrics—atomicity, fabrication, coverage, and sufficiency—we achieved a prediction F1 score of 0.71, despite potential noise in the retrieval and verification steps.




Figure 5: Distribution of Number of Sub Claims in FactLens Benchmark

From Figure 4, we observe that *fabrication* has the highest weight in magnitude, implying most influence in predicting whether the final label matches with ground truth. We see a negative weight for *fabrication* which is expected as lower *fabrication* indicates better quality sub-claims which in turn should have a positive effect on verification. *Atomicity*, *sufficiency* and *coverage* show a positive weight, as highly atomic, highly sufficient and high coverage sub-claims are expected to influence verification positively.


We also highlight some qualitative examples in Table 8 to show how sub-claim quality impacts

yêu cầu C cùng với bằng chứng để được xác minh. Trong trường hợp thứ hai, chúng tôi truyền các phân tích của yêu cầu $c = \{c_1, c_2, \dots, c_n\}$ từng cái một. Đối với mỗi c_i chúng tôi nhận được một nhãn xác minh, sau đó tổng hợp các nhãn cho trường hợp đó. Nếu bất kỳ một phụ yêu cầu nào bị đánh giá là sai thì toàn bộ trường hợp được đánh dấu là sai, nếu không thì đúng.

Chúng tôi so sánh hiệu suất của việc xác minh chi tiết với xác minh tổng thể trong Hình 3. Ở đây, chúng tôi giả định rằng số lượng các tiểu mục của một trường hợp cho thấy mức độ phức tạp của yêu cầu.

Chúng tôi nhận thấy rằng khi độ phức tạp (số lượng các phụ đề) tăng lên, hiệu suất của phương pháp xác minh chi tiết tăng đáng kể so với xác minh toàn diện.

Tác động của Chất lượng Tuyên bố Phụ lên Xác minh




Hình 4: Xác minh chi tiết: Hệ số hồi quy logistic cho các chỉ số

Trong Hình 2, chúng tôi đã chỉ ra cách mà chất lượng các tuyên bố phụ ảnh hưởng đến kết quả xác minh từ đầu đến cuối. Để thực sự hiểu được lợi ích của việc phân tách chi tiết và các chỉ số FactLens, chúng tôi chỉ xem xét những trường hợp mà số lượng tuyên bố phụ lớn hơn 1. Ở đây, chúng tôi minh họa thêm bằng cách sử dụng

các ví dụ định tính và trọng số của mô hình hồi quy logistic để chỉ ra ảnh hưởng của Các chỉ số Đánh giá FactLens đối với việc xác minh chi tiết.

Để hiểu sâu hơn về cách mỗi chỉ số ảnh hưởng đến việc xác minh cuối cùng, chúng tôi đã áp dụng một mô hình hồi quy logistic trên điểm số FactLens Evaluator trên Cover-Bench. Chúng tôi đặc biệt nghiên cứu tác động của các chỉ số tính nguyên tử, tính đầy đủ, sự bịa đặt và độ bao phủ vì chúng tôi dự đoán chúng sẽ ảnh hưởng đến việc xác minh cuối cùng nhiều hơn các chỉ số ‘tốt để có’: dư thừa và khả năng đọc.

Chúng tôi cũng tiến hành một phân tích để hiểu cách các điểm số có thể dự đoán tập thể độ chính xác xác minh cuối cùng bằng cách áp dụng một mô hình hồi quy logistic và kiểm tra các hệ số liên quan đến từng chỉ số. Khi kết hợp bốn chỉ số—tính nguyên tử, sự giả tạo, độ bao phủ và độ đầy đủ—chúng tôi đạt được điểm F1 dự đoán là 0,71, mặc dù có thể có nhiều trong các bước truy xuất và xác minh.



Hình 5: Phân bố Số lượng Yêu cầu Phụ trong Bộ Chuẩn FactLens

Từ Hình 4, chúng tôi quan sát thấy rằng yếu tố fabrication có trọng số lớn nhất về độ lớn, ngụ ý có ảnh hưởng nhiều nhất trong việc dự đoán liệu nhãn cuối cùng có khớp với thực tế hay không. Chúng tôi thấy một trọng số âm đối với fabrication, điều này là hợp lý vì mức fabrication thấp hơn cho thấy chất lượng các sub-claim tốt hơn, điều này sẽ có ảnh hưởng tích cực đến việc xác minh. Atomicity, sufficiency và coverage cho thấy trọng số dương, vì các sub-claim có tính nguyên tử cao, đầy đủ và độ bao phủ cao được dự đoán sẽ ảnh hưởng tích cực đến việc xác minh.

Chúng tôi cũng nhấn mạnh một số ví dụ định tính trong Bảng 8 để chỉ ra cách chất lượng phụ-đề ảnh hưởng

Claim: Fresh water crustaceans Aeglidae are classified as Malocostraca and Decapoda.
Gold Label: <u>False</u>
Evidence: [ground truth evidence from <i>CoverBench</i> ...]
Sub Claims: ['Fresh water crustaceans Aeglidae are classified as Malocostraca', 'Fresh water crustaceans Aeglidae are classified as Decapoda']
FactLens Evaluation:
• <i>Atomicity</i>: ['atomic', 'atomic'] • <i>Sufficiency</i>: ['high', 'high'] • <i>Fabrication</i>: ['low', 'low'] • <i>Coverage</i>: 'high' • <i>Redundancy</i>: 'low' • <i>Readability</i>: 'high'
Fine-Grained Verification Labels: [True, False] Aggregated Fine-Grained Verification Label: <u>False</u>
=====
Claim: In addition to co-starring in a Ken Ludwig musical, Jeffry Denman has worked with notables such as Mel Brooks, and has been called "a natural scene stealer" by The Houston Chronicle.
Gold Label: <u>False</u>
Evidence: [ground truth evidence from <i>CoverBench</i> ...]
Sub-Claims: ['Jeffry Denman co-starred in a Ken Ludwig musical', 'Jeffry Denman has worked with Mel Brooks', 'Jeffry Denman has been called a natural scene stealer by The Houston Chronicle']
FactLens Evaluation:
• <i>Atomicity</i>: ['atomic', 'atomic', 'non-atomic-2'] • <i>Sufficiency</i>: ['high', 'high', 'high'] • <i>Fabrication</i>: ['low', 'low', 'low'] • <i>Coverage</i>: 'medium' • <i>Redundancy</i>: 'low' • <i>Readability</i>: ['high', 'high', 'high']
Fine-Grained Verification Labels: [True, True, True] Aggregated Fine-Grained Verification Label: <u>True</u>

Table 8: Examples of how sub claim quality impacts verification performance

fine-grained verification. In the first instance, with perfect sub-claim quality, the fine-grained verification correctly predicts the ground truth label. In the second instance, we see *coverage* as ‘medium’ and imperfect *atomicity* score whereby the verifier eventually predicts an incorrect label.

F FactLens Dataset Characteristics

Our FactLens benchmarks consists of 733 instances from *CoverBench* with ground truth decompositions curated using LLMs and humans, and fine-grained labels as mentioned in Section 3.1. In Figure 5 we note the distribution of the number of sub-claims in the dataset.

Kháng định: Động vật giáp xác nước ngọt Aeglidae được phân loại là Malocostraca và Decapoda.
Nhãn Vàng: Sai
Bảng chứng: [bảng chứng thực tế từ CoverBench...]
Yêu cầu phụ: ['Giáp xác nước ngọt Aceans Aeglidae được phân loại là Malocostraca', 'Động vật giáp xác nước ngọt Aeglidae được phân loại vào Decapoda']
Đánh giá FactLens:
• Tính nguyên tử: ['nguyên tử', 'nguyên tử'] • Độ đầy đủ: ['cao', 'cao'] • Chế tạo: ['thấp', 'thấp'] • Phủ sóng: 'cao' • Dư thừa: 'thấp' • Độ dễ đọc: 'cao'
Nhãn Xác Minh Chi Tiết: [Đúng, Sai] Nhãn Xác Minh Chi Tiết Tổng Hợp: Sai
=====
Kháng định: Bên cạnh việc đóng chung trong một vở nhạc kịch của Ken Ludwig, Jeffry Denman đã làm việc với những người nổi tiếng như Mel Brooks, và đã được tờ The Houston Chronicle gọi là "một kẻ chiếm sóng hình tự nhiên".
Nhãn Vàng: Sai
Bảng chứng: [bảng chứng thực tế từ CoverBench...]
Phụ nhân vật MS: ['Jeffry Denman co _đảm nhận vai chính trong một vở nhạc kịch của Ken Ludwig', 'Jeffry Denman đã làm việc với Mel Brooks', 'Jeffry Denman đã được gọi là một na cảnh vật The Houston Chronicle']
Đánh giá FactLens:
• Tính nguyên tử: ['nguyên tử', 'nguyên tử', 'phi nguyên tử-2'] • Đầy đủ: ['cao', 'cao', 'cao'] • Chế tạo: ['thấp', 'thấp', 'thấp'] • Phủ sóng: 'trung bình' • Thừa: 'thấp' • Độ dễ đọc: ['cao', 'cao', 'cao']
Nhãn Xác Minh Chi Tiết: [Đúng, Đúng, Đúng] Nhãn Xác Minh Tinh Vi Tổng Hợp: Đúng

Bảng 8: Ví dụ về cách chất lượng yêu cầu phụ ảnh hưởng đến hiệu suất xác minh

xác minh chi tiết. Trong trường hợp đầu tiên, với chất lượng phụ-đề hoàn hảo, xác minh chi tiết dự đoán chính xác nhãn thực tế. Trong trường hợp t hứ hai, chúng ta thấy mức độ bao phủ là 'trung bình' và điểm nguyên tử không hoàn hảo, khiến người xác minh cuối cùng dự đoán nhãn sai.

F Bộ dữ liệu FactLens Đặc điểm

Bộ chuẩn đoán FactLens của chúng tôi bao gồm 733 trường hợp từ CoverBench với các phân tách sự thật cơ bản được biên soạn bằng LLMs và con người, cùng các nhãn chi tiết như đã đề cập trong Mục 3.1. Trong Hình 5, chúng tôi ghi nhận sự phân bố của số lượng các tuyên bố phụ trong tập dữ liệu.