

FactLens: Đánh giá Chuẩn Xác Xác Minh Thông Tin Chi Tiết

Kushan Mitra
Megagon Labs, Hoa Kỳ
kushan@megagon.ai

Dan Zhang
Megagon Labs, Mỹ
dan_z@megagon.ai

Sajjadur Rahman*
Adobe Inc.
sajjadur@adobe.com

Estevam Hruschka
Megagon Labs, USA
estevam@megagon.ai

Tóm tắt

Các Mô Hình Ngôn Ngữ Lớn (LLMs) đã thể hiện khả năng ấn tượng trong việc tạo và hiểu ngôn ngữ, nhưng xu hướng ảo giác và sản xuất thông tin sai sự thật vẫn là một hạn chế quan trọng. Để kiểm chứng nội dung do LLM tạo ra và các tuyên bố từ các nguồn khác, các phương pháp xác minh truyền thống thường dựa vào các mô hình toàn diện gán một nhãn tính xác thực duy nhất cho các tuyên bố phức tạp, có thể che khuất các lỗi tinh vi. Trong bài báo này, chúng tôi ủng hộ việc chuyển sang kiểm chứng chi tiết, nơi các tuyên bố phức tạp được chia nhỏ thành các tuyên bố phụ để xác minh riêng, cho phép xác định chính xác hơn các sai sót, cải thiện tính minh bạch và giảm sự mơ hồ trong việc thu thập bằng chứng. Tuy nhiên, việc tạo ra các tuyên bố phụ đặt ra những thách thức, chẳng hạn như duy trì bối cảnh và đảm bảo sự tương đương về ngữ nghĩa so với tuyên bố gốc. Chúng tôi giới thiệu FactLens¹, một bộ chuẩn để đánh giá kiểm chứng sự thật chi tiết, với các chỉ số và tự động

Độ chính xác về thực tế là rất quan trọng, đã có nghiên cứu ngày càng tăng về các phương pháp xác minh tính xác thực của nội dung do LLM tạo ra cũng như các tuyên bố từ các nguồn khác.

Những công trình trước đây về xây dựng các chuẩn mực kiểm tra sự thật tập trung vào việc tạo ra các tuyên bố với nhãn sự thật cơ sở, và trong một số trường hợp cung cấp bằng chứng/bối cảnh để xác minh tuyên bố (Aly et al., 2021; Schlichtkrull et al., 2024). Các tuyên bố được tạo ra bằng cách sử dụng người gán nhãn (Aly et al., 2021), các quy trình tổng hợp (Fatahi Bayat et al., 2023; Tang et al., 2024a), hoặc xem xét các kết quả đầu ra của LLM trong các nhiệm vụ Hỏi-Đáp (Wang et al., 2024). Để tăng độ phức tạp của quy trình kiểm tra sự thật, các tuyên bố được tạo từ dữ liệu nguồn thuộc nhiều miền và dạng thức khác nhau, chẳng hạn như văn bản và/hoặc bảng trên Wikipedia (Thorne et al., 2018; Chen et al., 2020; Aly et al., 2021), trang Web (Schlichtkrull et al., 2024), Đồ thị Kiến thức (Kim et al., 2023), các bài đăng/trò chuyện trực tuyến (Wang et al., 2024; Li et al., 2024), và các nhiệm vụ Hỏi-Đáp từ nhiều lĩnh vực khác nhau như thống kê, tài chính, pháp lý, v.v. (Jacovi et al., 2024).

Những công trình này cũng cung cấp các quy trình kiểm tra sự thật cơ bản, thường bao gồm hai giai đoạn chính: (1) truy xuất bằng chứng liên quan sử dụng các API Tìm kiếm và hồ dữ liệu đa phương thức (Tang et al., 2024b; Schlichtkrull et al., 2024) và (2) xác minh các tuyên bố dựa trên bằng chứng đó bằng các mô hình kiểm tra sự thật dựa trên NLI, dựa trên LLM và mô hình kiểm tra sự thật được tinh chỉnh (Li et al., 2024). Một số công trình cũng nghiên cứu việc ủy quyền hoàn toàn các bước này cho một khuôn khổ chính sách dựa trên LLM (Li et al., 2024; Peng et al., 2023).

Mặc dù có quy trình có cấu trúc này, hầu hết các phương pháp hiện có đều dựa vào mô hình xác minh toàn diện, trong đó các tuyên bố phức tạp được gán một nhãn thực tế duy nhất, thường làm lu mờ bản chất tinh tế của các lỗi hoặc sai sót trong các tuyên bố. Trong công trình này, chúng tôi đồng tình với quan điểm của Wang và cộng sự (2024); Liu và cộng sự (2020); Pan và cộng sự (2023); Min và cộng sự (2023); Si và cộng sự (2024) nhằm chuyển hướng sang xác minh chi tiết các tuyên bố phức tạp, nơi các tuyên bố được giải quyết-

1 Giới thiệu

Các Mô Hình Ngôn Ngữ Lớn (LLMs) đã được chứng minh là những công cụ mạnh mẽ, cho thấy khả năng ấn tượng trong việc tạo và hiểu ngôn ngữ (Touvron et al., 2023; Brown et al., 2020). Tuy nhiên, một hạn chế nổi tiếng của LLMs là xu hướng tạo ra thông tin ảo tưởng, tạo ra thông tin sai sự thật hoặc không được chứng minh bằng bằng chứng (Ji et al., 2022; Lin et al., 2022). Khi LLMs trở nên phổ biến hơn, đặc biệt trong các ứng dụng mà

¹Công việc thực hiện tại Megagon Labs.
<https://github.com/megagonlabs/factlens>

được chia thành các tuyên bố phụ nhỏ hơn, dễ quản lý hơn và có thể được xác minh riêng lẻ. Chúng tôi cũng nhấn mạnh nhu cầu cung cấp các chỉ số đánh giá để so sánh việc xác minh chi tiết như vậy, và bổ sung các bộ chuẩn hiện có với các nhân xác minh chi tiết.

Như được minh họa trong Hình 1, lợi ích của việc xác minh chi tiết là đáng kể. Bằng cách phân tách một tuyên bố phức tạp thành các tuyên bố phụ cấu thành của nó, việc xác minh trở nên chính xác hơn, cho phép xác định chính xác các vị trí sai sót về thực tế. Ngoài ra, phương pháp này cho phép các lý giải và giải thích minh bạch hơn, vì mỗi tuyên bố phụ có thể được liên kết trực tiếp với bằng chứng tương ứng của nó hoặc thiếu bằng chứng. Việc phân tách chi tiết cũng thu hẹp phạm vi thu thập bằng chứng, làm cho quá trình xác minh tiếp theo tập trung hơn và ít mơ hồ hơn.


Tuy nhiên, việc đạt được xác minh chi tiết lại đặt ra những thách thức riêng. Phân tách một tuyên bố phức tạp, thô thành các tuyên bố phụ nhỏ hơn không đơn giản chỉ là chia nó thành các câu. Các tuyên bố phụ được xây dựng kém có thể gây ra nhiều vấn đề: chúng có thể mất đi bối cảnh cần thiết để xác minh đúng, thiếu tính nguyên tử, hoặc trình bày sai thông tin gốc bằng cách bỏ sót các chi tiết quan trọng hoặc thêm các chi tiết giả mạo. Do đó, đảm bảo chất lượng và khả năng xác minh của các tuyên bố phụ này là rất quan trọng cho sự thành công tổng thể của quá trình xác minh.

Để giải quyết những thách thức này, chúng tôi giới thiệu FactLens, một chuẩn đánh giá được thiết kế đặc biệt cho việc xác minh sự thật chi tiết. FactLens cung cấp một bộ chỉ số mới để đánh giá chất lượng tạo ra các phụ đề cáo và tích hợp các công cụ đánh giá tự động kết hợp đánh giá dựa trên LLM với các chỉ số thống kê. Bộ dữ liệu đã được tuyển chọn thủ công để đảm bảo các phụ đề cáo có chất lượng cao.

Thông qua đánh giá thực nghiệm, chúng tôi chứng minh rằng các bộ đánh giá tiểu luận của chúng tôi phù hợp chặt chẽ với các đánh giá của con người. Hơn nữa, đánh giá đầu-cuối của chúng tôi cho thấy các điểm số chi tiết này có sự tương quan mạnh với hiệu suất xác minh hạ lưu được cải thiện. Chúng tôi cũng trình bày kết quả của các mô hình hiện đại nhất trong việc tạo tiểu luận, tiết lộ những thách thức vốn có trong nhiệm vụ này và nhu cầu nghiên cứu thêm trong lĩnh vực này.

2 Đánh giá các tiểu tuyên bố với FactLens

Cốt lõi của việc xác minh chi tiết là sự phân tách các tuyên bố phức tạp thành các phần nhỏ hơn, nhiều hơn



Hình 1: Các ví dụ về xác minh sự thật toàn diện (phía trên) không phát hiện được các sai sót, trong khi xác minh chi tiết (phía dưới) rõ ràng chỉ ra các nguồn lỗi. Trong xác minh chi tiết, Bộ đánh giá FactLens có thể được sử dụng để đánh giá từng tuyên bố phụ và xác định bất kỳ tín hiệu cảnh báo nào có thể gợi ý sự cần thiết phải can thiệp của con người hoặc tái tạo các tuyên bố phụ.

các tiểu khẳng định cụ thể khi cần thiết. Độ chính xác của toàn bộ quá trình xác minh phụ thuộc nhiều vào chất lượng của các tiểu khẳng định này; các lỗi (ví dụ như đơn giản hóa quá mức, bỏ sót chi tiết quan trọng, hoặc đặt sai bối cảnh) trong cách hình thành chúng có thể dẫn đến kết quả xác minh sai lệch. Để phát hiện các vấn đề tiềm ẩn ngay từ đầu trong quá trình tạo tiểu khẳng định, chúng tôi đề xuất một bộ các chỉ số để đánh giá định lượng chất lượng tiểu khẳng định theo nhiều khía cạnh.

2.1 Các chỉ số đánh giá

Các tiểu phẩm đã phân rã nên đáp ứng các tiêu chí dưới đây để thực sự hiện thực hóa các lợi ích của việc xác minh chi tiết như nhận diện chính xác hơn các lỗi không đúng, tăng cường tính minh bạch và giảm sự mơ hồ trong quá trình thu thập bằng chứng.

Tính nguyên tử Mỗi tiểu luận nên đề cập đến một đơn vị thực tế riêng biệt trong luận điểm gốc. Điều này đảm bảo rằng nếu có lỗi xảy ra, sự không chính xác có thể được truy xuất chính xác trở lại một hoặc nhiều tiểu luận cụ thể. Tính nguyên tử đo lường liệu một tiểu luận có thực sự nguyên tử hay không, tức là nó chỉ tập trung vào một mối quan hệ giữa một chủ thể và một đối tượng. Ví dụ, luận điểm “Ủy ban Olympic Quốc tế (IOC) được thành lập vào ngày 23 tháng 6 năm 1895, tại Paris, Pháp” không phải là nguyên tử, vì nó đưa ra các khẳng định về cả thời gian và địa điểm thành lập của IOC.

Quá trình phân rã biến một yêu cầu đơn thành một danh sách các yêu cầu phụ. Điều này là rất quan trọng

Tương quan	tính nguyên tử		sự đủ		sản xuất		phạm vi		dư thừa	
	r	ρ	r	ρ	r	ρ	r	ρ	r	ρ
LLM	0.40	0.39	0.14	0.09	0.34	0.43	0.43	0.45	0.56	0.52
Thông kê	0.58	0.59	—	—	0.04	0.05	0.61	0.58	0.10	0.12

Bảng 1: Mối tương quan giữa điểm số Evaluator của FactLens với các chủ thích của con người trên dữ liệu tổng hợp (Độ dễ đọc bị bỏ qua do tính chủ quan cao). r : Điểm tương quan Pearson; ρ : Điểm tương quan Spearman.

sự biến đổi về mặt ngữ nghĩa là tương đương, đảm bảo danh sách kết hợp các yêu cầu phụ phản ánh trung thực yêu cầu gốc và rằng mỗi yêu cầu có thể được xác minh độc lập. Để giải quyết khía cạnh này, chúng tôi đề xuất các chỉ số Độ Đầy Đủ, Sự Tạo Ra, và Phạm Vi.

Đầy đủ Để thực hiện xác minh chi tiết, mỗi tuyên bố phụ cần phải có khả năng xác minh độc lập. Điều này yêu cầu các tuyên bố phụ được đặt trong bối cảnh phù hợp để tránh bất kỳ sự mơ hồ bổ sung nào. Đầy đủ đo lường xem tuyên bố phụ có rõ ràng và được đặt trong bối cảnh một cách đầy đủ so với tuyên bố gốc hay không. Ví dụ, trong tuyên bố gốc “Amanda Bauer đã theo học Đại học Cincinnati. Biệt danh của trường là Bearcats.”, tuyên bố phụ “Biệt danh của trường là Bearcats” sẽ được coi là có mức độ đầy đủ thấp vì việc tham chiếu đến trường đã bị bỏ qua trong quá trình phân tách, khiến nó trở nên mơ hồ.

Sáng tạo thông tin quá mức Quá trình phân rã không được phép thêm thông tin bổ sung hoặc cố gắng sửa các lỗi thực tế. Chỉ số này đặc biệt quan trọng khi đánh giá các bộ phân rã LLM, vì LLM được biết là gặp tình trạng ảo tưởng hoặc tạo ra thông tin bịa đặt. Ví dụ, trong tuyên bố gốc “Sydney, thủ đô của Úc, nổi tiếng với Nhà hát Opera và Cầu Cảng”, một tuyên bố phụ “Sydney là thủ phủ của New South Wales, Úc” được coi là sáng tạo thông tin quá mức. Tương tự, với tuyên bố gốc “Doanh số bán hàng ròng sẽ đạt 30 triệu nếu tỷ lệ tăng trưởng trong năm 2024 giống như năm 2023”, một tuyên bố phụ “Tỷ lệ tăng trưởng của năm 2024 giống như năm 2023” được coi là sáng tạo thông tin quá mức vì nó coi một điều kiện như một tuyên bố.

Phạm vi Danh sách các tiểu tuyên bố phải bao quát tất cả các khẳng định thực tế trong các tuyên bố gốc, không bỏ sót tiểu tuyên bố nào. Chẳng hạn, với tuyên bố “Amanda Bauer đã theo học tại Đại học Cincinnati, có biệt danh là Bearcats”, nếu chỉ tạo ra một tiểu tuyên bố là “Amanda Bauer đã theo học tại Đại học Cincinnati”, thì phạm vi sẽ

được coi là thấp vì tuyên bố về biệt danh của trường đại học bị thiếu.

Ngoài ra, một số khía cạnh có thể không ảnh hưởng trực tiếp đến khả năng xác minh và độ chính xác về sau nhưng lại nắm bắt được một số đặc điểm mong muốn của các tiểu yêu cầu.

Thừa Thông tin Chỉ số này đo lường liệu các tuyên bố phụ, nhìn chung, có chứa các sự thật thừa hay không. Khi một số tuyên bố phụ lặp lại về mặt ngữ nghĩa, sự phân bố của các đơn vị kiểm tra sự thật có thể bị lệch. Ví dụ, nếu một tuyên bố phụ sai lặp lại ba lần, đánh giá cuối cùng có thể chuyển từ “hầu hết đúng ngoại trừ một tuyên bố phụ” sang “hơn một nửa các tuyên bố phụ là sai.” Hơn nữa, thừa thông tin cũng gây ra chi phí không cần thiết về thời gian và tài nguyên tính toán.

Độ dễ đọc Chỉ số này đánh giá mức độ dễ đọc của các phụ khiếu nại đối với người dùng cuối và áp đặt một hình phạt đối với các phụ khiếu nại được hình thành một cách không tự nhiên.

Đối với mỗi chỉ số này, các tiểu tuyên bố được đánh giá bằng cách gán điểm 'thấp', 'trung bình' hoặc 'cao'. Đối với phạm vi và sự dư thừa, các điểm được gán ở cấp độ tuyên bố vì chúng tôi xem các tiểu tuyên bố như một tổng thể. Đối với tất cả các chỉ số khác, điểm được gán cho từng tiểu tuyên bố và sau đó được tổng hợp.

Giá trị chỉ số lý tưởng: Đối với việc phân tích lập luận lý tưởng, chúng ta kỳ vọng các tiểu luận nhận con có tính nguyên tử cao, tính đầy đủ cao, độ bao phủ cao và khả năng đọc cao, trong khi có độ bịa đặt thấp và độ dư thừa thấp.

2.2 Bộ Đánh Giá FactLens

Bộ đánh giá FactLens sử dụng một phương pháp tập hợp các điểm đánh giá do LLM tạo ra và các điểm được tính toán thống kê (chi tiết hơn trong Phụ lục B.1 và B.2 tương ứng). Chúng tôi sử dụng LLM làm người đánh giá nhờ khả năng mở rộng tốt so với người đánh giá, cũng như độ tin cậy và kiến thức của chúng trên nhiều lĩnh vực khác nhau. Tuy nhiên, thừa nhận những hạn chế của LLM (Bavaresco et al., 2024; Stureborg et al., 2024), chúng tôi

các điểm số dựa vào các phép tính dựa trên t hực thể và ngữ nghĩa.

Trong Bảng 1, chúng tôi báo cáo các điểm t ương quan của các nhà chú thích con người với các điểm của Bộ đánh giá FactLens, trên một dữ liệu tổng hợp (chi tiết hơn trong Phụ lục B.4 và C) đã được tuyển chọn cẩn thận để bao phủ các loại lỗi tiểu khẳng định khác nhau. Chúng tôi quan sát t hấy sự đồng thuận từ vừa phải đến trung bình trên tất cả các khía cạnh giữa đánh giá của con người và các điểm của Bộ đánh giá FactLens, ngoại trừ khía cạnh đầy đủ. Các điểm tương quan vừa phải có thể được lý giải bởi tính chủ quan liên quan đến việc đánh giá các chỉ số như vậy. Sự phụ thuộc vào thông tin ngữ cảnh và bằng chứng để đánh giá độ đầy đủ của một tiểu khẳng định góp phần làm cho các điểm tương quan của chỉ số này thấp hơn. Tuy nhiên, kết quả của chúng tôi chứng minh rằng các phương pháp tính toán của chúng tôi cho Bộ đánh giá FactLens tương đồng vừa phải với đánh giá của con người trên một tập dữ liệu với chất lượng tiểu khẳng định khác nhau.

3 FactLens: Đánh giá kiểm chứng chi tiết


3.1 Tạo bộ dữ liệu

Bộ dữ liệu chuẩn FactLens chứa một tập dữ liệu với các tuyên bố phụ có sự thật và các nhân chi tiết. Chúng tôi sử dụng 733 trường hợp từ CoverBench (Jacovi et al., 2024), một bộ dữ liệu chuẩn kiểm tra sự thật tập trung vào việc xác minh các tuyên bố phức tạp được lấy mẫu từ nhiều nguồn và lĩnh vực khác nhau, làm các tuyên bố gốc.

Chúng tôi sử dụng hai mô hình ngôn ngữ l ớn tiên tiến — GPT-4o (OpenAI, 2024) và LLaMA-3.1 (Meta, 2024) (chi tiết có trong Phụ lục A) — để tạo các giả định phụ ứng cử viên và đo lường chất lượng của các kết quả này bằng Bộ đánh giá FactLens. Để đảm bảo chất lượng cao của các giả định phụ được tạo ra, chúng tôi sử dụng các chú giải viên con người (chi tiết có trong Phụ lục C) để xem xét tất cả các giả định phụ và tự tay tạo ra các giả định phụ chuẩn xác, sửa chữa bất kỳ sai sót nào trong các giả định phụ do LLM tạo ra (chi tiết trong Phụ lục F).

Để tách riêng các lợi ích của việc xác minh chi tiết, chúng tôi không thực hiện bước thu thập bằng chứng hoặc ngữ cảnh cho từng tuyên bố phụ. Thay vào đó, chúng tôi sử dụng bằng chứng và ngữ cảnh được cung cấp trong CoverBench, cùng với các tuyên bố phụ được tạo ra, để thực hiện xác minh s ự thật. Phương pháp này loại bỏ sự biến đổi trong kết quả có thể phát sinh từ các phương pháp và quy trình thu thập bằng chứng khác nhau.

Bước tiếp theo trong việc kiểm tra chi tiết bao gồ m sử dụng một mô hình 'người kiểm chứng' để kiểm tra tính xác thực của từng tuyên bố phụ dựa trên bằng chứng được cung cấp. Trong điều này



Hình 2: Tác động của các chỉ số chất lượng phụ-tuyên đến hiệu suất xác minh. Xem Phụ lục E để biết chi tiết.

Trong công việc, chúng tôi sử dụng GPT-4o-mini làm mô hình kiểm chứng trong tất cả các thí nghiệm để duy trì sự nhất quán.

Phương pháp xác minh này cho phép đánh giá tính vi và chi tiết hơn. Để so sánh hiệu suất của các nhân xác minh chi tiết (cho từng tiểu yêu cầu) với nhân xác minh tổng thể, chúng tôi tổng hợp các nhân chi tiết là sai nếu ít nhất một trong các nhân chi tiết cũng là sai; ngược lại, yêu cầu được coi là đúng.

3.2 Phân rã Yêu cầu: Hiệu suất Mô hình

Chúng tôi sử dụng gợi ý được định nghĩa trong Bảng 3 để phân tách các phát biểu bằng GPT-4o và Llama-3.1(405B). Trong Bảng 2, chúng tôi lập bảng hiệu suất đánh giá của cả hai mô hình này trên nhiệm vụ phân tách phát biểu bằng FactLens Evaluator.

Đối với mỗi trường hợp, chúng tôi ánh xạ các điểm 'thấp', 'trung bình', 'cao' ('non-atomic-2', 'non-atomic-1', 'atomic' đối với tính nguyên tử) thành các giá trị số (tương ứng là 1, 2, 3), và báo cáo giá trị trung bình cho mỗi chỉ số trên tất cả 733 trường hợp trong bộ dữ liệu CoverBench.

Cả hai mô hình đều có hiệu năng tương tự nhau và thực hiện tốt nhiệm vụ, như kết quả mong đợi khi các tuyên bố phụ có độ đầy đủ c ao, ít bịa đặt, bao phủ rộng, ít dư thừa và có khả năng đọc cao. Điểm nguyên tử thấp hơn nhiều, vì chúng tôi quan sát định tính một số trường hợp loại này có một chủ thể nhưng nhiều đối tượng ('non-atomic-1' được gán điểm 2)

Mô hình	Tính nguyên tử ↑	Đủ ↑	Sản xuất ↓	Phủ sóng ↑	Dư thừa ↓	Khả năng đọc ↑
Llama-3.1	1.87	2.85	1.01	2.88	1.09	2.96
GPT-4o	1.82	2.85	1.02	2.89	1.15	2.95

Bảng 2: Tôi đo lường chất lượng phụ-đề bằng cách phân tích bối cảnh dựa trên gợi ý. Chúng tôi báo cáo điểm trung bình trên CoverBe mũi tên lên & xuống chỉ ra các chỉ số nên cao (~ 3) hoặc thấp (~ 1) tương ứng.

3.3 Kết quả đánh giá

Trong việc xác minh chi tiết, các đánh giá viên FactLens của chúng tôi có thể đóng vai trò là trọng tài của các tiểu tuyên bố được tạo ra, cung cấp các tín hiệu sửa đổi sớm nếu các tiểu tuyên bố có thể dẫn đến việc xác minh gặp vấn đề. Để minh họa điều này, chúng tôi thực hiện một đánh giá đầu-cuối (như được trình bày trong Hình 2) để làm nổi bật cách hiệu suất xác minh cuối cùng bị ảnh hưởng bởi chất lượng của các tiểu tuyên bố. Ví dụ, chúng tôi kỳ vọng các tiểu tuyên bố chất lượng cao sẽ có điểm giả mạo thấp. Chúng tôi lưu ý rằng đối với các phân rã tuyên bố có điểm giả mạo được phân loại là 'thấp', hiệu suất kiểm chứng thông tin tiếp theo, tức là điểm F1, cao hơn so với những tuyên bố có điểm giả mạo 'trung bình' hoặc 'cao'.

Tương tự, chúng tôi quan sát thấy các xu hướng mà các tuyên bố phụ với mức độ nguyên tử, đầy đủ, bao phủ và khả năng đọc cao hơn thể hiện hiệu suất xác minh tốt hơn. Mặc dù các tuyên bố phụ với điểm dư thừa thấp hơn thực hiện hơi tốt hơn, hiệu suất xác minh tổng thể vẫn tương tự. Điều này có thể được giải thích bởi thực tế là các tuyên bố phụ có mức dư thừa cao có thể chỉ lặp lại các tuyên bố mà không ảnh hưởng tiêu cực đến nhận xét cuối cùng.

4 Kết luận

Trong bài báo này, chúng tôi giới thiệu chuẩn mực FactLens để đánh giá việc xác minh các tuyên bố chi tiết, làm phong phú các chuẩn mực hiện có. Chúng tôi cũng xác định các chỉ số quan trọng để đánh giá chất lượng của các tuyên bố phụ chi tiết và đề xuất một bộ đánh giá tự động để cung cấp tín hiệu sớm về các thất bại trong phân tích và đánh giá các phương pháp phân tích tuyên bố.

Hạn chế

Tính Toán Các Chỉ Số Chúng tôi sử dụng hai phương pháp để tính toán các chỉ số đánh giá FactLens: dựa trên LLM và tính toán theo thống kê. Việc sử dụng LLM như người đánh giá/trọng tài là một lĩnh vực nghiên cứu đang được khám phá và cải thiện liên tục. Tuy nhiên, các công trình hiện có (Stureborg et al., 2024; Bavaresco et al., 2024) đã chỉ ra những hạn chế khi sử dụng LLM trong các nhiệm vụ đánh giá như vậy, với các điểm số của chúng bị lệch và không nhất quán.

Để giảm thiểu sự không nhất quán, chúng tôi đã cung cấp hướng dẫn cụ thể trong lời nhắc (Bảng 4) cho các mô hình ngôn ngữ lớn (LLM). Chúng tôi đã đo điểm đồng thuận và tương quan của các LL M với điểm đánh giá của con người, quan sát thấy sự đồng thuận từ vừa đến trung bình trên hầu hết các chỉ số. Hơn nữa, chúng tôi đề xuất các định nghĩa riêng cho việc tính toán điểm của Bộ đánh giá FactLens. Tuy nhiên, chúng tôi cũng thừa nhận những hạn chế trong phương pháp tính toán của mình, vì nó dựa vào phương pháp trích xuất thực thể, điều này có thể cho kết quả khác nhau. Chúng tôi dự định đề xuất các định nghĩa cụ thể hơn cho những chỉ số này trong các nghiên cứu tương lai.

Thu thập bằng chứng Để đảm bảo không có sự biến động trong nhiệm vụ xác minh sự thật, trong nghiên cứu này chúng tôi sử dụng bằng chứng thực tế có sẵn trong bộ dữ liệu CoverBench. Điều này cho phép chúng tôi chỉ đo lường sự phụ thuộc của việc xác minh sự thật vào việc phân tích tuyên bố và chất lượng các tuyên bố phụ. Với Bộ chuẩn FactLens của chúng tôi, chúng tôi cung cấp động lực để các nhà chi tiết sớm được bao gồm trong các bộ chuẩn xác minh sự thật. Trong các nghiên cứu tương lai, chúng tôi hy vọng sẽ chỉ ra cách mà việc phân tích tuyên bố cũng có thể cải thiện quá trình tìm kiếm & thu thập bằng chứng.

Mô Hình Xác Thực Sự Thật Các công trình trước đây đã so sánh các mô hình xác thực khác nhau trong nhiệm vụ kiểm tra sự thật. Tang và cộng sự (2024a) so sánh hiệu suất của các mô hình dựa trên MNLI, dựa trên LLM và các mô hình được tinh chỉnh mà họ đề xuất cho việc xác thực sự thật. Trong nghiên cứu này, chúng tôi chọn sử dụng GPT-4o-mini làm mô hình xác thực duy nhất, bởi vì mục tiêu của chúng tôi không phải là đề xuất các mô hình mạnh hơn cho việc xác thực; mà là để minh họa lợi ích của việc xác thực chi tiết ngay cả khi sử dụng các mô hình xác thực đơn giản có sẵn.

Sự thật là gì? Trích xuất sự thật là một lĩnh vực vẫn còn nhiều chỗ để cải thiện. Một số nghiên cứu trước đây (Wang và cộng sự, 2024) cũng phân biệt giữa các tuyên bố thực tế, ý kiến và câu chuẩn. Trong nghiên cứu này, chúng tôi sử dụng các tuyên bố CoverBench, vốn được lấy từ các chuẩn mực dựa vào phương pháp con người hoặc tổng hợp để tạo ra tuyên bố. Có thể nhận thấy rằng các loại tuyên bố thực tế khác nhau có thể được tạo ra bằng quy trình này, khi một số tuyên bố có thể tập trung vào

một tuyên bố là đúng một cách phổ quát (ví dụ: “Trái Đất quay quanh Mặt Trời.”), trong khi các tuyên bố khác phụ thuộc nhiều vào bối cảnh/chứng cứ (ví dụ: “Có 3 câu thủ có bang quê nhà là Missouri”).

Hơn nữa, các tuyên bố dựa trên sự thật trong các tình huống thực tế thường có tính chất theo thời gian và phụ thuộc vào lĩnh vực. Ví dụ, một tuyên bố như “Tuổi hợp pháp để uống rượu là 18” là sai ở một quốc gia như Hoa Kỳ, tuy nhiên có thể đúng ở Vương quốc Anh, cho thấy sự phụ thuộc vào lĩnh vực. Tương tự, bằng chứng thu thập cho tuyên bố “Barack Obama là Tổng thống Mỹ” có tính chất theo thời gian. Chúng tôi lưu ý rằng kết quả và thí nghiệm của chúng tôi cũng dựa trên các chuẩn mực hiện có, vốn không tính đến tất cả các tình huống trong thế giới thực.

Tài liệu tham khảo

Rami Aly, Zhijiang Guo, Michael Sejr Schlichtkrull, James Thorne, Andreas Vlachos, Christos Christodoulopoulos, Oana Cocarascu và Arpit Mittal. 2021. Feverous: Trích xuất dữ liệu và xác minh sự thật trên thông tin có cấu trúc và không có cấu trúc. Trong Hội nghị lần thứ ba mươi lăm về Hệ thống Xử lý Thông tin Thần kinh, Phần Dữ liệu và Các Bài kiểm tra Chuẩn (Vòng 1).

Anna Bavaresco, Raffaella Bernardi, Leonardo Bertolazzi, Desmond Elliott, Raquel Fernández, Albert Gatt, E. Ghaleb, Mario Giulianelli, Michael Hanna, Alexander Koller, André F. T. Martins, Philipp Mondorf, Vera Neplenbroek, Sandro Pezzelle, Barbara Plank, David Schlangen, Alessandro Suglia, Aditya K Surikuchi, Ece Takmaz, và Alberto Testoni. 2024. Các LLM thay vì thẩm phán con người? Một nghiên cứu thực nghiệm quy mô lớn trên 20 nhiệm vụ đánh giá NLP. ArXiv, abs/2406.18403.

Tom Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared D Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, Sandhini Agarwal, Ariel Herbert-Voss, Gretchen Krueger, Tom Henighan, Rewon Child, Aditya Ramesh, Daniel Ziegler, Jeffrey Wu, Clemens Winter, Chris Hesse, Mark Chen, Eric Sigler, Mateusz Litwin, Scott Gray, Benjamin Chess, Jack Clark, Christopher Berner, Sam McCandlish, Alec Radford, Ilya Sutskever, và Dario Amodei. 2020. Mô hình ngôn ngữ là những người học ít mẫu. Trong Advances in Neural Information Processing Systems, tập 33, trang 1877–1901. Curran Associates, Inc.

Wenhu Chen, Hongmin Wang, Jianshu Chen, Yunkai Zhang, Hong Wang, Shiyang Li, Xiyu Zhou, và William Yang Wang. 2020. Tabfact: Một tập dữ liệu quy mô lớn cho việc xác minh sự thật dựa trên bảng. Trong Hội nghị Quốc tế về Đại diện Học tập (ICLR), Addis Ababa, Ethiopia.

Farima Fatahi Bayat, Kun Qian, Benjamin Han, Yisi Sang, Anton Belyy, Samira Khorshidi, Fei

Wu, Ihab Ilyas, và Yunyao Li. 2023. FLEEK: Phát hiện và sửa lỗi thực tế với bằng chứng được truy xuất từ kiến thức bên ngoài. Trong Kỷ yếu Hội nghị Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên 2023: Trình diễn Hệ thống, trang 124–130, Singapore. Hiệp hội Ngôn ngữ Học Máy Tính.

Alon Jacovi, Moran Ambar, Eyal Ben-David, Uri Sha-ham, Amir Feder, Mor Geva, Dror Marcus, và Avi Caciularu. 2024. Coverbench: Một chuẩn đánh giá đầy thử thách cho việc xác minh các tuyên bố phức tạp. arXiv preprint arXiv:2408.03325.

Ziwei Ji, Nayeon Lee, Rita Frieske, Tiezheng Yu, Dan Su, Yan Xu, Etsuko Ishii, Yejin Bang, Delong Chen, Wenliang Dai, Andrea Madotto, và Pascale Fung. 2022. Khảo sát về ảo giác trong sinh ngôn ngữ tự nhiên. Tạp chí Khảo sát Máy tính ACM, 55:1 – 38.

Jiho Kim, Sungjin Park, Yeonsu Kwon, Yohan Jo, James Thorne, và Edward Choi. 2023. FactKG: Xác minh sự thật thông qua suy luận trên đồ thị tri thức. Trong Kỷ yếu của Hội nghị thường niên lần thứ 61 của Hiệp hội Ngôn ngữ học Máy tính (Tập 1: Bài báo dài), các trang 16190–16206, Toronto, Canada. Hiệp hội Ngôn ngữ học Máy tính.

Miaoran Li, Baolin Peng, Michel Galley, Jianfeng Gao, và Zhu Zhang. 2024. Self-checker: Các mô-đun cầm và chạy để kiểm tra sự thật với các mô hình ngôn ngữ lớn. Trong Kết quả của Hiệp hội Ngôn ngữ học Máy tính: NAACL 2024, trang 163–181, Thành phố Mexico, Mexico. Hiệp hội Ngôn ngữ học Máy tính.

Stephanie Lin, Jacob Hilton, và Owain Evans. 2022. TruthfulQA: Đo lường cách các mô hình bắt chước những sai lầm của con người. Trong Kỷ yếu Hội nghị thường niên lần thứ 60 của Hiệp hội Ngôn ngữ học Máy tính (Tập 1: Bài báo dài), trang 3214–3252, Dublin, Ireland. Hiệp hội Ngôn ngữ học Máy tính.

Zhenghao Liu, Chenyan Xiong, Maosong Sun, và Zhiyuan Liu. 2020. Xác minh sự thật chi tiết với mạng chú ý đồ thị hạt nhân. Trong Kỷ yếu của Hội nghị hàng năm lần thứ 58 của Hiệp hội Ngôn ngữ học Máy tính, trang 7342–7351, Trực tuyến. Hiệp hội Ngôn ngữ học Máy tính.

Meta. 2024. Llama-3.1.

Sewon Min, Kalpesh Krishna, Xinxu Lyu, Mike Lewis, Wen-tau Yih, Pang Koh, Mohit Iyyer, Luke Zettlemoyer, và Hannaneh Hajishirzi. 2023. FActScore: Đánh giá nguyên tử chi tiết về độ chính xác thực tế trong việc tạo văn bản dạng dài. Trong Kỷ yếu Hội nghị 2023 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên, trang 12076–12100, Singapore. Hiệp hội Ngôn ngữ Học Máy tính.

OpenAI. 2024. Gpt-4o.

Liangming Pan, Xiaobao Wu, Xinyuan Lu, Anh Tuan Luu, William Yang Wang, Min-Yen Kan, và

Preslav Nakov. 2023. Kiểm chứng các tuyên bố phức tạp bằng suy luận theo hướng chương trình. Trong Kỷ yếu Hội nghị thường niên lần thứ 61 của Hiệp hội Ngôn ngữ học Máy tính (Tập 1: Bài báo dài), trang 6981–7004, Toronto, Canada. Hiệp hội Ngôn ngữ học Máy tính.

Baolin Peng, Michel Galley, Pengcheng He, Hao Cheng, Yujia Xie, Yu Hu, Qiuyuan Huang, Lars Liden, Zhou Yu, Weizhu Chen, và Jianfeng Gao. 2023. Kiểm tra các sự thật của bạn và thử lại: Cải thiện các mô hình ngôn ngữ lớn với kiến thức bên ngoài và phản hồi tự động. ArXiv, abs/2302.12813.

Michael Schlichtkrull, Yulong Chen, Chenxi Whitehouse, Zhenyun Deng, Mubashara Akhtar, Rami Aly, Zhijiang Guo, Christos Christodoulopoulos, Oana Cocarascu, Arpit Mittal, James Thorne và Andreas Vlachos. 2024. Nhiệm vụ chia sẻ xác minh tự động các tuyên bố văn bản (AVeriTeC). Trong Kỷ yếu của Hội thảo lần thứ bảy về Trích xuất Thực tế và Xác minh (FEVER), trang 1–26, Miami, Florida, Mỹ. Hiệp hội Ngôn ngữ học Máy tính.

Jiasheng Si, Yibo Zhao, Yingjie Zhu, Haiyang Zhu, Wenpeng Lu, và Deyu Zhou. 2024. CHECK-WHY: Xác minh sự thật nguyên nhân thông qua cấu trúc lập luận. Trong Kỷ yếu Hội nghị thường niên lần thứ 62 của Hiệp hội Ngôn ngữ học Máy tính (Tập 1: Bài báo dài), các trang 15636–15659, Bangkok, Thái Lan. Hiệp hội Ngôn ngữ học Máy tính.

Rickard Stureborg, Dimitris Alikaniotis, và Yoshi Suhara. 2024. Các mô hình ngôn ngữ lớn là những người đánh giá không nhất quán và thiên vị. ArXiv, abs/2405.01724.

LiyanTang, Philippe Laban và Greg Durrett. 2024a. MiniCheck: Kiểm tra sự thật hiệu quả của các LLM trên các tài liệu nền tảng. Trong Kỷ yếu Hội nghị 2024 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên, trang 8818–8847, Miami, Florida, Hoa Kỳ. Hiệp hội Ngôn ngữ Học Máy Tính.

Nan Tang, Chenyu Yang, Ju Fan, Lei Cao, Yuyu Luo, và Alon Y. Halevy. 2024b. Verifai: Trí tuệ nhân tạo sinh tạo đã được xác minh. Trong Hội nghị lần thứ 14 về Nghiên cứu Hệ thống Dữ liệu Sáng tạo (CIDR 2024), Chaminade, HI, Mỹ.

James Thorne, Andreas Vlachos, Christos Christodoulopoulos, và Arpit Mittal. 2018. FEVER: một bộ dữ liệu quy mô lớn cho việc trích xuất và xác minh sự thật. Trong Kỷ yếu Hội nghị 2018 của Chương Bắc Mỹ Hiệp hội Ngôn ngữ học Máy tính: Công nghệ Ngôn ngữ Con người, Tập 1 (Bài báo Dài), trang 809–819, New Orleans, Louisiana. Hiệp hội Ngôn ngữ học Máy tính.

Hugo Touvron, Thibaut Lavril, Gautier Izacard, Xavier Martinet, Marie-Anne Lachaux, Timothée Lacroix, Baptiste Rozière, Naman Goyal, Eric Hambro, Faisal Azhar, Aurelien Rodriguez, Armand Joulin, Edouard Grave, và Guillaume Lample. 2023. Llama: Mở

và các mô hình ngôn ngữ nền tảng hiệu quả. ArXiv, abs/2302.13971.

Yuxia Wang, Revanth Gangi Reddy, Zain Muhammad Mujahid, Arnav Arora, Aleksandr Rubashevskii, Ji-ahui Geng, Osama Mohammed Afzal, Liangming Pan, Nadav Borenstein, Aditya Pillai, Isabelle Augenstein, Iryna Gurevych và Preslav Nakov. 2024. Factcheck-bench: Bộ đánh giá chi tiết cho các công cụ kiểm tra sự thật tự động. Trong Kết quả của Hiệp hội Ngôn ngữ Học Máy Tính: EMNLP 2024, trang 14199–14230, Miami, Florida, Mỹ. Hiệp hội Ngôn ngữ Học Máy Tính.

Tianyi Zhang, Varsha Kishore, Felix Wu, Kilian Q. Weinberger, và Yoav Artzi. 2019. Bertscore: Đánh giá sinh văn bản với BERT. ArXiv, abs/1904.09675.

Phân rã Yêu cầu

Chúng tôi sử dụng phương pháp gợi ý ít ví dụ để phân tách một tuyên bố thành các tuyên bố phụ. Bảng 3 trình bày gợi ý được sử dụng để nắm bắt mục tiêu tạo ra các tuyên bố phụ mang tính nguyên tử, nhưng vẫn bối cảnh hóa với đủ t hông tin được giữ lại từ tuyên bố gốc.

Đối với các minh họa few-shot, chúng tôi lấy mẫu 4 trường hợp từ bộ dữ liệu FEVEROUS (Aly et al., 2021), đảm bảo không trùng lặp với dữ liệu CoverBench. Cuối cùng trong lời nhắc, chúng tôi chọn ngẫu nhiên 3 trong 4 minh họa và xáo trộn thứ tự, để đảm bảo không có sự thiên vị.

Chúng tôi sử dụng các mô hình GPT-4o và Llama-3.1(405B) cho nhiệm vụ này, với nhiệt độ = 0.

B Đánh giá Phân tách Yêu cầu

Để đánh giá các tuyên bố phụ, Bộ đánh giá FactLens của chúng tôi sử dụng các điểm số do LLM tạo ra cũng như các điểm số được tính toán theo thống kê.

B.1 Lời nhắc để Đánh giá Phân rã Yêu cầu

Trong Bảng 4, chúng tôi cung cấp lời nhắc cho LLMs được sử dụng để đánh giá phân rã khẳng định qua 6 chỉ số được định nghĩa trong Mục 2.1. Chúng tôi cung cấp hướng dẫn rõ ràng mà theo đó LLMs có thể đánh giá phân rã khẳng định qua các khía cạnh khác nhau. Đối với tất cả các chỉ số ngoại trừ “coverage” và “redundancy”, các tiêu khẳng định được đưa vào từng cái một để thu được đánh giá ở cấp độ tiêu khẳng định. “Coverage” và “redundancy” được sử dụng để đánh giá các tiêu khẳng định như một tổng thể, do đó đối với các chỉ số này, chúng tôi cung cấp toàn bộ tập hợp các phân rã tiêu khẳng định cho trường hợp đó. Đối với “atomicity”, chúng tôi yêu cầu LLM đưa ra nhãn dưới dạng

Chúng tôi nhằm mục đích kiểm chứng tính xác thực của một tuyên bố bằng văn bản. Để làm cho nhiệm vụ kiểm chứng dễ dàng hơn, chúng tôi chia nhỏ một tuyên bố thành các tuyên bố phụ đơn giản, nguyên tử để kiểm chứng khi cần. Lưu ý rằng các tuyên bố phụ nguyên tử đề cập đến các tuyên bố đơn vị trong tuyên bố gốc, liên quan đến một khái niệm duy nhất có thể được xác minh độc lập mà không cần tham khảo tuyên bố gốc. Việc xác minh các tuyên bố phụ không nên yêu cầu tổng hợp các sự kiện hoặc suy luận đa bước về các khái niệm. Tuy nhiên, tuyên bố phụ nên giữ nguyên tất cả thông tin bối cảnh từ tuyên bố gốc.	
Nhiệm vụ của bạn là phân tích một tuyên bố thành các phần tử nguyên tử	yêu cầu kiểm chứng sự thật chỉ khi cần thiết
nó xuống.	Nếu chính yêu cầu gốc là một yêu cầu đơn vị, thì không b reak
Ví dụ: {cuộc biểu tình}	
Chú ý cách mỗi tiểu luận chứa thông tin nguyên tử để kiểm tra sự thật và ngắn gọn, nhưng được bối cảnh hóa với tất cả thông tin cần thiết từ luận điểm gốc.	
Bây giờ hãy tìm các tuyên bố phụ từ tuyên bố sau. Tuyên bố: {claim} Các tuyên bố phụ ...: < kết quả của bạn dưới dạng danh sách >	
=====	

Bảng 3: Yêu cầu Phân tích Yêu cầu

Một tuyên bố mang tính thực tế có thể được chia thành các tuyên bố con nguyên tử nhưng có bối cảnh, điều này giúp dễ dàng kiểm tra tính xác thực. Bạn sẽ được cung cấp một tuyên bố, và một trong các tuyên bố con đã được trích xuất từ nó. Nhiệm vụ của bạn là đánh giá tuyên bố con này theo tiêu chí sau:	
{metric}	
Câu trả lời của bạn nên là "thấp", "trung bình" hoặc "cao" dựa trên chỉ số được cung cấp. Hãy khách quan và công bằng trong đánh giá của bạn.	
Yêu cầu: {claim}	
Tiểu Yêu Cầu: {sub_claim}	
=====	
<i>Các hướng dẫn để tính toán từng chỉ số được truyền từng bước một như sau:</i>	
“tính nguyên tử”: Nếu tuyên bố phụ là nguyên tử, tức là nó đơn giản và chỉ tập trung vào một chủ thể và một đối tượng, và việc xác minh không yêu cầu tổng hợp các sự kiện hoặc lập luận đa bước về các khái niệm. Gắn nhãn cho tuyên bố phụ là “nguyên tử” để chỉ một chủ thể và một đối tượng, hoặc “phi nguyên tử-1” để chỉ một chủ thể, nhiều đối tượng, hoặc “phi nguyên tử-2” để chỉ nhiều chủ thể	
"đủ": Nếu yêu cầu phụ đủ để kiểm tra mà không cần thêm thông tin ngữ cảnh, tức là yêu cầu phụ chứa đầy đủ thông tin ngữ cảnh cần thiết để kiểm tra độc lập và không gây mơ hồ. Câu trả lời của bạn nên chỉ rõ yêu cầu phụ có mức độ "thấp", "trung bình" hay "cao".	
"tính dư thừa": Nếu các phụ khiếu nại chứa thông tin dư thừa hoặc bị lặp lại giữa chúng, tức là nhiều phụ khiếu nại có ý nghĩa tương đương. Câu trả lời của bạn nên chỉ ra liệu các phụ khiếu nại có "thấp", "trung bình" hay "cao" mức độ dư thừa.	
“coverage”: Nếu tập hợp các tiểu tuyên bố bao phủ tất cả các sự kiện và thông tin được đưa ra trong tuyên bố gốc. Câu trả lời của bạn nên chỉ ra liệu các tiểu tuyên bố có mức độ bao phủ “thấp”, “trung bình” hay “cao”.	
“sự bịa đặt”: Nếu tuyên bố phụ thể hiện mức độ bịa đặt so với tuyên bố gốc, tức là có bao nhiêu thông tin mới được thêm vào mà không có trong tuyên bố gốc. Lưu ý rằng điều này không được đánh giá dựa trên tính xác thực của các tuyên bố gốc hoặc tuyên bố phụ. Câu trả lời của bạn nên chỉ ra liệu tuyên bố phụ có mức độ bịa đặt “thấp”, “trung bình” hay “cao”.	
“tính dễ đọc”: Nếu yêu cầu phụ có thể đọc được bởi người dùng cuối. Câu trả lời của bạn nên chỉ ra liệu yêu cầu phụ có “thấp”, “trung bình” hay “cao” về tính dễ đọc.	

Bảng 4: Lời nhắc để Đánh giá Phân tích Yêu cầu sử dụng LLMs

theo hướng dẫn cụ thể, trong khi đối với từng chỉ số còn lại, chúng tôi yêu cầu LLM đánh giá trường hợp với điểm “thấp”, “trung bình” hoặc “cao”.

Chúng tôi sử dụng mô hình Ope-nAI nhỏ hơn và rẻ hơn GPT-4o-mini cho nhiệm vụ này, với nhiệt độ = 0.

B.2 Đánh giá Tính toán Thống kê

Để tính toán các chỉ số Đánh giá FactLens bằng cách sử dụng các phương pháp thống kê, chúng tôi dựa vào các phép tính dựa trên thực thể và dựa trên ngữ nghĩa. Với một ví dụ, với tuyên bố C , chúng tôi trích xuất tất cả các (Chủ đề,

Các cặp đối tượng) có mặt trong đó bằng cách sử dụng gpt-4o-mini; nhiệt độ = 0, và từ đó tạo danh sách S = chủ đề và O = đối tượng. Sau khi phân tích tuyên bố, chúng ta thu được các tuyên bố phụ $c = \{c_1, c_2, ..., c_n\}$. Đối với tất cả i trong $[1, n]$, chúng tôi trích xuất danh sách chủ đề s_i và đối tượng o_i theo cách tương tự. Tiếp theo, chúng ta theo các định nghĩa này để tính các chỉ số sau:

Tính nguyên tử Để đo lường tính nguyên tử, chúng tôi sử dụng phương pháp tính toán dựa trên thực thể để so sánh số lượng chủ thể và đối tượng tham gia vào tuyên bố phụ c_i . Nếu c_i chỉ xoay quanh một

chủ ngữ và một tân ngữ ví dụ: “Kurt Cobain là một tay guitar”, nó được gắn nhãn là ‘nguyên tử’.

nếu $len(s_i) = 1$ và $len(o_i) = 1$,
tính nguyên tử = ‘nguyên tử’

Nếu c_i xoay quanh một chủ đề, nhưng nhiều đối tượng ví dụ: “Kurt Cobain là một tay guitar và là một ca sĩ”, nó được gắn nhãn ‘non-atomic-1’.

nếu $len(s_i) = 1$ và $len(o_i) > 1$,
tính nguyên tử = ‘phi-nguyên-tử-1’

Tuy nhiên, nếu c_i xoay quanh nhiều chủ đề ví dụ: “Kurt Cobain là thành viên của ban nhạc Nirvana, được sáng lập cùng với Krist Novoselic”, nó được gắn nhãn là ‘không nguyên tử-2’.

nếu $len(s_i) > 1$, tính nguyên tử = ‘không nguyên tử-2’

Đầy đủ Vì đầy đủ là một tiêu chí khó để đánh giá bằng các kỹ thuật ngữ nghĩa, chúng tôi dựa vào điểm đánh giá của LLM.

Chế tạo Để tính toán chế tạo, chúng tôi đếm tất cả các chủ thể trong mỗi s_i mà không xuất hiện trong S , tức là các chủ thể trong yêu cầu gốc, và tất cả các đối tượng trong mỗi o_i mà không xuất hiện trong O , tức là các đối tượng trong yêu cầu gốc.

Nếu số lượng cho fab bằng 0, tức là không có t hực thể mới nào xuất hiện trong các tiểu tuyên bố, mức độ bịa đặt là ‘thấp’. Dựa trên các giá trị ngưỡng, chúng tôi gán điểm bịa đặt là ‘trung bình’ hoặc ‘cao’.

Phủ sóng Để đo lường phủ sóng, chúng tôi kiểm tra xem các thực thể (chủ thể và đối tượng) trong tất cả các tiểu tuyên bố c_i có bao gồm tất cả các chủ thể S và đối tượng O có trong tuyên bố gốc hay không.

if $\cup(s_i) \forall i = S$ and $\cup(o_i) \forall i = O$,
phủ sóng = ‘cao’

Trong trường hợp không có sự chồng chéo, độ bao phủ = ‘thấp’, và trong tất cả các trường hợp khác, độ bao phủ = ‘trung bình’

Dư thừa Để tính toán dư thừa, chúng tôi sử dụng kỹ thuật dựa trên ngữ nghĩa bằng cách đo BertScore (Zhang và cộng sự, 2019) giữa từng cặp các tuyên bố phụ. Nếu có sự tương đồng cao giữa hai

$$red = \sum_{i=1}^n \sum_{j=1}^n \mathbb{I}(i \neq j, BertScore(c_i, c_j) > T)$$

, trong đó T là giá trị ngưỡng để tìm độ tương đồng BertScore(.) và n là số lượng các luận phụ được tạo ra cho trường hợp đó.

Dựa trên số lượng các yêu cầu thừa được tìm thấy, chúng tôi gán điểm ‘thấp’, ‘trung bình’ và ‘cao’.

Khả năng đọc dựa vào các đánh giá được tạo ra bởi LLM để đo độ dễ đọc.

B.3 Đánh giá FactLens sử dụng phương pháp Tập hợp

Như đã đề cập trước đó, trong Bảng 1 trình bày mối tương quan giữa điểm số của con người và điểm số do LLM của chúng tôi tạo ra & tính toán thống kê trên dữ liệu tổng hợp với chất lượng phân tách luận điểm khác nhau. Dựa trên kết quả trên các chỉ số, chúng tôi đề xuất sử dụng các điểm số tính toán thống kê cho tính nguyên tử và độ bao phủ (vì chúng có sự tương quan tốt hơn so với điểm số do LLM tạo ra), trong khi sử dụng đánh giá do LLM tạo ra cho các chỉ số còn lại trong kết quả thí nghiệm của chúng tôi tại Mục 3.3.

B.4 Điểm Thỏa Thuận trên Dữ Liệu Tổng Hợp

Trong Bảng 1, chúng tôi quan sát thấy mối tương quan từ trung bình đến khá giữa con người và điểm số của Công cụ Đánh giá FactLens thông qua các chỉ số tương quan Pearson và Spearman. Chúng tôi cung cấp các giá trị p tương ứng trong Bảng 5, từ đó chúng tôi kết luận rằng các điểm số tương quan đối với tính nguyên tử, độ bao phủ (cả LLM-Con người và Thống kê-Con người), việc bịa đặt, và sự thừa thãi (LLM-Con người) là có ý nghĩa thống kê.

Bên cạnh các điểm tương quan trong Bảng 1, chúng tôi cũng báo cáo các điểm đồng thuận giữa các người chú thích là con người và FactLensEvaluator. Chúng tôi báo cáo điểm Alpha của Krippendorff theo thứ tự để đo lường sự đồng thuận. Chúng tôi quan sát thấy sự đồng thuận từ công bằng đến trung bình trên tất cả các chiều trừ ‘độ đầy đủ’, điều này có thể được giải thích bởi việc phụ thuộc vào thông tin ngữ cảnh và bằng chứng để đánh giá độ đầy đủ của một tiểu tuyên bố.

Dữ liệu tổng hợp được tuyển chọn sử dụng 10 tuyên bố từ bộ chuẩn FEVEROUS và tạo ra các phân tách tuyên bố được chú thích bởi chuyên gia với các biến đổi. Đối với mỗi tuyên bố, chúng tôi tạo 7 phân tách tuyên bố: một với các tuyên bố phụ chất lượng hoàn hảo, một tuyên bố phụ được tạo bởi LLM, và những cái khác sử dụng các biến đổi dẫn đến các tuyên bố phụ chất lượng thấp hơn tương ứng với từng chỉ số sau: tính nguyên tử, sự đầy đủ, sự bịa đặt, phạm vi và sự dư thừa. Chúng tôi loại trừ khả năng đọc trong các điểm thỏa thuận, vì đây là một chỉ số cực kỳ chủ quan.

Giá trị P	tính nguyên tử		sự đủ		sản xuất		phạm vi		dư thừa	
	r	ρ	r	ρ	r	ρ	r	ρ	r	ρ
LLM	4e-10	5e-10	0.140	0.437	5,1e-4	2,63e-7	2,9e-4	2,4e-4	3,26e-6	7,78e-6
Thống kê	1e-9	1e-9	—	—	0.166	0.176	7,7e-8	1,1e-6	0.404	0.332

Bảng 5: Giá trị P từ Bảng 1: Mối tương quan giữa điểm số của Người đánh giá FactLens với các chú thích của con người trên dữ liệu tổng hợp

Krippendorff	
Hệ mét	Alpha
Tính nguyên tử	0.4421
Đầy đủ	0.0486
Sản xuất	0.4085
Phạm vi phủ sóng	0.5300
Dư thừa	0.4240

Bảng 6: Sự phù hợp của điểm số FactLensEvaluator với chú thích của con người trên dữ liệu tổng hợp

Chú thích chuyên gia C

Để thực hiện chú thích của con người trên dữ liệu tổng hợp (Mục 2.2) và việc tạo ra chuẩn đánh giá, chúng tôi đã tuyển dụng hai chuyên gia chú thích nội bộ. Các chuyên gia chú thích này thành thạo tiếng Anh, hiện đang làm việc tại Hoa Kỳ, với ít nhất bằng cấp sau đại học. Cho nhiệm vụ này, họ được cung cấp cùng một hướng dẫn như lời nhắc đối với các mô hình ngôn ngữ lớn trong Bảng 4. Các chuyên gia chú thích đã được giải thích rõ ràng về mục tiêu của nhiệm vụ và cách các chú thích của họ sẽ được sử dụng.


Điểm đồng thuận giữa các người chú thích (Krippendorff Alpha) là cao, như được trình bày trong Bảng 7.

Giữa các người chú thích	
Hệ mét	Thỏa thuận
Tính nguyên tử	0.73
Đủ	0.53
Sản xuất	0.54
Phạm vi	0.86
Dư thừa	0.94
Độ dễ đọc	0.96


Bảng 7: Điểm đồng thuận giữa các người chú thích

Để đo lường mối tương quan giữa điểm số của Người đánh giá FactLens và điểm số của con người, chúng tôi thực hiện trung bình điểm số của Người đánh giá FactLens trên một chỉ số với cả hai người chú thích, và lặp lại cho tất cả các chỉ số. Các người chú thích con người cũng được sử dụng để tạo ra các tuyên bố phụ có tính thật (Mục 3.1).

Fine-Grained vs Holistic Verification (Llama-3.1 Generated Sub Claims)



Fine-Grained vs Holistic Verification (GPT-4o Generated Sub Claims)



Hình 3: Khi độ phức tạp (tức là số lượng các tuyên bố phụ) tăng lên, hiệu suất của việc phân tích các tuyên bố phụ cải thiện đáng kể.

D Xác minh chi tiết

Chúng tôi nghiên cứu lợi ích của việc xác minh sự thật chi tiết so với việc xác minh toàn bộ tuyên bố trong Hình 3.

Để thực hiện việc xác minh, chúng tôi sử dụng GPT-4o-mini để đánh giá xem một khẳng định là đúng hay sai dựa trên bằng chứng được cung cấp. Chúng tôi thu thập bằng chứng thực tế có trong tập dữ liệu CoverBench.

Để chứng minh lợi ích của việc xác minh chi tiết, chúng tôi so sánh nó với phương pháp xác minh toàn diện yêu cầu gốc mà không phân tách.


Trong trường hợp đầu tiên, chúng ta chỉ đơn giản truyền bản gốc

yêu cầu C cùng với bằng chứng để được xác minh. Trong trường hợp thứ hai, chúng tôi truyền các phân tích của yêu cầu $c = \{c_1, c_2, \dots, c_n\}$ từng cái một. Đối với mỗi c_i chúng tôi nhận được một nhãn xác minh, sau đó tổng hợp các nhãn cho trường hợp đó. Nếu bất kỳ một phụ yêu cầu nào bị đánh giá là sai thì toàn bộ trường hợp được đánh dấu là sai, nếu không thì đúng.

Chúng tôi so sánh hiệu suất của việc xác minh chi tiết với xác minh tổng thể trong Hình 3. Ở đây, chúng tôi giả định rằng số lượng các tiểu mục của một trường hợp cho thấy mức độ phức tạp của yêu cầu.

Chúng tôi nhận thấy rằng khi độ phức tạp (số lượng các phụ đề) tăng lên, hiệu suất của phương pháp xác minh chi tiết tăng đáng kể so với xác minh toàn diện.

Tác động của Chất lượng Tuyên bố Phụ lên Xác minh




Hình 4: Xác minh chi tiết: Hệ số hồi quy logistic cho các chỉ số

Trong Hình 2, chúng tôi đã chỉ ra cách mà chất lượng các tuyên bố phụ ảnh hưởng đến kết quả xác minh từ đầu đến cuối. Để thực sự hiểu được lợi ích của việc phân tách chi tiết và các chỉ số FactLens, chúng tôi chỉ xem xét những trường hợp mà số lượng tuyên bố phụ lớn hơn 1. Ở đây, chúng tôi minh họa thêm bằng cách sử dụng

các ví dụ định tính và trọng số của mô hình hồi quy logistic để chỉ ra ảnh hưởng của Các chỉ số Đánh giá FactLens đối với việc xác minh chi tiết.

Để hiểu sâu hơn về cách mỗi chỉ số ảnh hưởng đến việc xác minh cuối cùng, chúng tôi đã áp dụng một mô hình hồi quy logistic trên điểm số FactLens Evaluator trên Cover-Bench. Chúng tôi đặc biệt nghiên cứu tác động của các chỉ số tính nguyên tử, tính đầy đủ, sự bịa đặt và độ bao phủ vì chúng tôi dự đoán chúng sẽ ảnh hưởng đến việc xác minh cuối cùng nhiều hơn các chỉ số 'tốt để có': dư thừa và khả năng đọc.

Chúng tôi cũng tiến hành một phân tích để hiểu cách các điểm số có thể dự đoán tập thể độ chính xác xác minh cuối cùng bằng cách áp dụng một mô hình hồi quy logistic và kiểm tra các hệ số liên quan đến từng chỉ số. Khi kết hợp bốn chỉ số—tính nguyên tử, sự giả tạo, độ bao phủ và độ đầy đủ—chúng tôi đạt được điểm F1 dự đoán là 0,71, mặc dù có thể có nhiều trong các bước truy xuất và xác minh.



Hình 5: Phân bố Số lượng Yêu cầu Phụ trong Bộ Chuẩn FactLens

Từ Hình 4, chúng tôi quan sát thấy rằng yếu tố fabrication có trọng số lớn nhất về độ lớn, ngụ ý có ảnh hưởng nhiều nhất trong việc dự đoán liệu nhãn cuối cùng có khớp với thực tế hay không. Chúng tôi thấy một trọng số âm đối với fabrication, điều này là hợp lý vì mức fabrication thấp hơn cho thấy chất lượng các sub-claim tốt hơn, điều này sẽ có ảnh hưởng tích cực đến việc xác minh. Atomicity, sufficiency và coverage cho thấy trọng số dương, vì các sub-claim có tính nguyên tử cao, đầy đủ và độ bao phủ cao được dự đoán sẽ ảnh hưởng tích cực đến việc xác minh.

Chúng tôi cũng nhấn mạnh một số ví dụ định tính trong Bảng 8 để chỉ ra cách chất lượng phụ-đề ảnh hưởng

Khẳng định: Động vật giáp xác nước ngọt Aeglidae được phân loại là Malacostraca và Decapoda.

Nhãn Vàng: Sai

Bảng chứng: [bảng chứng thực tế từ CoverBench. . .]

Yêu cầu phụ: [‘Giáp xác nước ngọt Aceans Aeglidae được phân loại là Malacostraca’, ‘Động vật giáp xác nước ngọt Aeglidae được phân loại vào Decapoda

Đánh giá FactLens:

- Tính nguyên tử: [‘nguyên tử’, ‘nguyên t
ử’]
- Độ đầy đủ: [‘cao’, ‘cao’]
- Chế tạo: [‘thấp’, ‘thấp’]
- Phủ sóng: ‘cao’
- Dư thừa: ‘thấp’
- Độ dễ đọc: ‘cao’

Nhãn Xác Minh Chi Tiết: [Đúng, Sai]Nhân Xác
Minh Chi Tiết Tổng Hợp: Sai

Khẳng định: Bên cạnh việc đóng chung trong một vở nhạc kịch của Ken Ludwig, Jeffry Denman đã làm việc với những người nổi tiếng như Mel Brooks, và đã được tờ The Houston Chronicle gọi là "một kẻ chiếm sóng hình tự nhiên".

Nhãn Vàng: Sai

Bảng chứng: [bảng chứng thực tế từ CoverBench...]

Phụ nhân vật ms: [‘Jeffry Denman co _đảm nhận vai chính trong một vở nhạc kịch của Ken Ludwig’, ‘Jeffry Denman đã làm việc với Mel Brooks’, ‘Jeffry Denman đã được gọi là một na
cảnh quan tự nhiên’]

Đánh giá FactLens:

- Tính nguyên tử: [‘nguyên tử’, ‘nguyên tử’, ‘phi nguyên tử-2’]
- Đầy đủ: [‘cao’, ‘cao’, ‘cao’]
- Chế tạo: [‘thấp’, ‘thấp’, ‘thấp’]
- Phủ sóng: ‘trung bình’
- Thừa: ‘thấp’
- Độ dễ đọc: [‘cao’, ‘cao’, ‘cao’]

Nhãn Xác Minh Chi Tiết: [Đúng, Đúng, Đúng]
Nhân Xác Minh Tinh Vi Tổng Hợp: Đúng

Bảng 8: Ví dụ về cách chất lượng yêu cầu phụ ảnh hưởng đến hiệu suất xác minh

xác minh chi tiết. Trong trường hợp đầu tiên, với chất lượng phụ-đề hoàn hảo, xác minh chi tiết dự đoán chính xác nhân thực tế. Trong trường hợp t hứ hai, chúng ta thấy mức độ bao phủ là 'trung bình' và điểm nguyên tử không hoàn hảo, khiến người xác minh cuối cùng dự đoán nhãn sai.

F Bộ dữ liệu FactLens Đặc điểm

Bộ chuẩn đoán FactLens của chúng tôi bao gồm 733 trường hợp từ CoverBench với các phân tách sự thật cơ bản được biên soạn bằng LLMs và con người, cùng các nhãn chi tiết như đã đề cập trong Mục 3.1. Trong Hình 5, chúng tôi ghi nhận sự phân bố của số lượng các tuyên bố phụ trong tập dữ liệu.