arXiv:2305.13117v2 [cs.CL] 8 Nov 2023

# AVERITEC: A Dataset for Real-world Claim Verification with Evidence from the Web

**Michael Schlichtkrull***, **Zhijiang Guo***, **Andreas Vlachos**
Department of Computer Science and Technology, University of Cambridge
{mss84,zg283,av308}@cam.ac.uk

## Abstract

Existing datasets for automated fact-checking have substantial limitations, such as relying on artificial claims, lacking annotations for evidence and intermediate reasoning, or including evidence published after the claim. In this paper, we introduce AVERITEC, a new dataset of 4,568 real-world claims covering fact-checks by 50 different organizations. Each claim is annotated with question-answer pairs supported by evidence available online, as well as textual justifications explaining how the evidence combines to produce a verdict. Through a multi-round annotation process, we avoid common pitfalls including context dependence, evidence insufficiency, and temporal leakage, and reach a substantial inter-annotator agreement of $\kappa = 0.619$ on verdicts. We develop a baseline as well as an evaluation scheme for verifying claims through question-answering against the open web.

## 1 Introduction

Fact-checking is considered crucial for limiting the impact of misinformation [Lewandowsky et al., 2020]. Unfortunately, not enough resources are available for manual fact-checking. Automated fact-checking (AFC) has been proposed as an assistive tool for fact-checkers, moderators, and citizen journalists to facilitate it [Cohen et al., 2011, Vlachos and Riedel, 2014], inspiring applications in journalism [Miranda et al., 2019, Dudfield, 2020, Nakov et al., 2021] and other domains, e.g. science [Wadden et al., 2020].

Substantial progress has been made on common benchmarks, such as FEVER [Thorne et al., 2018] and MultiFC [Augenstein et al., 2019]. Nevertheless, existing resources have recently come under criticism. Many datasets (for example, Thorne et al. [2018], Schuster et al. [2021], Aly et al. [2021]) contain purpose-made claims derived from sources such as Wikipedia, and are thus unlike real-world claims checked by journalists. Further, in these datasets, *refuted* claims are produced by corrupting existing sentences. Datasets that do contain real-world claims either lack evidence annotation [Wang, 2017], or annotate it superficially using automated means, resulting in issues such as including evidence published days or weeks *after* the investigated claims [Glockner et al., 2022].

To address these limitations we introduce AVERITEC (Automated VERIfication of TExtual Claims), which combines real-world claims with realistic evidence retrieved from the web, as well as justifications for veracity labels. We formulate retrieval as question generation and answering, providing a structured representation of the evidence and reasoning supporting or refuting the claim. The free-text justifications detail how the evidence is used to reach the verdict, including cases of conflicting evidence, matching best practises for human fact-checkers [Borel, 2016]. In constructing AVERITEC, we ameliorate three issues afflicting existing datasets with real-world claims:

1. **Context Dependence:** Ousidhoum et al. [2022] found that claims in some datasets based on fact-checking articles (e.g., Fan et al. [2020]) cannot be verified without additional

*Equal Contribution.

37th Conference on Neural Information Processing Systems (NeurIPS 2023).

arXiv:2305.13117v2 [cs.CL] 8 Nov 2023

# AVERITEC: Một Bộ Dữ liệu cho Việc Xác minh Yêu cầu Thực tế với Bằng chứng từ Web

Michael Schlichtkrull*, Zhijiang Guo*, Andreas Vlachos Khoa Khoa học Máy tính và Công nghệ, Đại học Cambridge {mss84,zg283,av308}@cam.ac.uk

## Tóm tắt

Các bộ dữ liệu hiện có cho việc kiểm tra sự thật tự động có những hạn chế đáng kể, chẳng hạn như dựa vào các tuyên bố nhân tạo, thiếu ghi chú về bằng chứng và lập luận trung gian, hoặc bao gồm bằng chứng được công bố sau tuyên bố. Trong bài báo này, chúng tôi giới thiệu AVERITEC, một bộ dữ liệu mới gồm 4.568 tuyên bố thực tế bao quát các kiểm tra sự thật bởi 50 tổ chức khác nhau. Mỗi tuyên bố được ghi chú với các cặp câu hỏi-trả lời được hỗ trợ bởi bằng chứng có sẵn trực tuyến, cũng như các lý giải bằng văn bản giải t hích cách bằng chứng kết hợp để đưa ra phán quyết. Thông qua quá trình ghi chú nhiều vòng, chúng tôi tránh được những sai lầm phổ biến bao gồm phụ thuộc vào ngữ cảnh, bằng chứng không đủ và rò rỉ theo thời gian, và đạt được sự đồng thuận đáng kể giữa các người ghi chú về phán quyết với $\kappa = 0.619$ . Chúng tôi phát triển một chuẩn cơ sở cũng như một sơ đồ đánh giá để xác minh các tuyên bố thông qua trả lời câu hỏi dựa trên web mở.

## 1 Giới thiệu

Kiểm tra sự thật được coi là rất quan trọng để hạn chế tác động của thông tin sai lệch [Lewandowsky et al.,2020]. Thật không may, không có đủ nguồn lực để kiểm tra sự thật thủ công. Kiểm tra sự thật tự động (AFC) đã được đề xuất như một công cụ hỗ trợ cho những người kiểm tra sự thật, các điều phối viên và nhà báo công dân để tạo điều kiện thuận lợi cho việc này [Cohen et al., 2011, Vlachos and Riedel, 2014], trong các ứng dụng truyền thông [Miranda et al., 2019, Dudfield, 2020, Nakov et al., 2021] và các lĩnh vực khác, ví dụ khoa học [Wadden et al., 2020].

Tiến bộ đáng kể đã được thực hiện trên các chuẩn chung, chẳng hạn như FEVER [ Thorne et al., 2018] và MultiFC [ Augenstein et al., 2019]. Tuy nhiên, các nguồn lực hiện có gần đây đã bị chỉ trích. Nhiều bộ dữ liệu (ví dụ, Thorne et al. [2018], Schuster et al. [2021], Aly et al. [2021]) chứa các tuyên bố được tạo ra có mục đích từ các nguồn như Wikipedia, do đó không giống như các tuyên bố thực tế được các nhà báo kiểm tra. Hơn nữa, trong các bộ dữ liệu này, các tuyên bố bị bác bỏ được tạo ra bằng cách làm sai lệch các câu hiện có. Các bộ dữ liệu có chứa các tuyên bố thực tế thì hoặc thiếu chú thích bằng chứng [ Wang, 2017], , hoặc chú thích một cách sơ sài bằng phương pháp tự động, dẫn đến các vấn đề như bao gồm bằng chứng được công bố vài ngày hoặc vài tuần sau các tuyên bố được điều tra [ Glockner et al., 2022].

Để giải quyết những hạn chế này, chúng tôi giới thiệu AVERITEC (Xác minh Tự động Các Yêu cầu Văn bản), kết hợp các tuyên bố thực tế với bằng chứng thực tế được truy xuất từ web, cũng như các lý do cho nhãn tính xác thực. Chúng tôi xây dựng việc truy xuất dưới dạng tạo câu hỏi và trả lời, cung cấp một cách biểu diễn có cấu trúc của bằng chứng và lý luận hỗ trợ hoặc bác bỏ tuyên bố. Các lý do dưới dạng văn bản tự do chi tiết cách thức sử dụng bằng chứng để đi đến kết luận, bao gồm các trường hợp bằng chứng mâu thuẫn, phù hợp với các phương pháp tốt nhất của những người kiểm tra sự thật [Borel, 2016]. Trong việc xây dựng AVERITEC, chúng tôi cải thiện ba vấn đề đang ảnh hưởng tới các bộ dữ liệu hiện có với các tuyên bố thực tế:

1. Phụ thuộc vào ngữ cảnh: Ousidhoum và cộng sự [2022] đã phát hiện rằng các tuyên bố trong một số bộ dữ liệu dựa trên các bài báo kiểm chứng sự thật (ví dụ, Fan và cộng sự [2020]) không thể được xác minh mà không có thêm

*Đóng góp bằng nhau.

Hội nghị lần thứ 37 về Hệ thống Xử lý Thông tin Thần kinh (NeurIPS 2023).

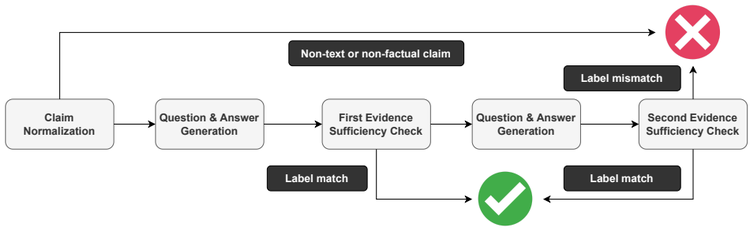



Figure 1: Diagram for our annotation process. Claims are first selected and normalized. Then, two rounds of question-answer pair generation and evidence sufficiency check ensure high-quality evidence annotation.

information from the articles they were extracted from. This could for example be due to unresolved coreference or ellipsis, e.g. in "unemployment is rising" it is unclear which geographical/temporal context is being considered.

2. **Evidence Insufficiency:** Glockner et al. [2022] found that labels in some datasets (e.g., Hanselowski et al. [2019]) often do not match the annotated evidence, because they rely on e.g., assumptions about the speaker of the claim. This is significantly different from *not enough evidence* verdicts, which is a label for claims where evidence could not be found.
3. **Temporal Leaks:** Glockner et al. [2022] found that annotations in some datasets (e.g., Augenstein et al. [2019]) contain leaks from the future. For example, a claim from January might be annotated with evidence from March that year. Leaks can also happen between splits, if e.g., evidence for a training claim from 2021 also pertains to a test claim from 2020.

We address (1) through an initial normalisation step, where annotators enrich claims with necessary information from the fact-checking article. We verify the adequacy of this, and address (2), by combining multiple rounds of annotation with a "blind" quality control step, re-annotating any claims with insufficient evidence. We address (3) by restricting annotators to evidence documents published before the claim, and by ordering our training, development, and test splits temporally. With the increasing reliance on large pretrained language models, temporal ordering provides an additional benefit: if the training data for the language model is cut off before the temporal start of the test set, leaks from pretraining cannot occur either.

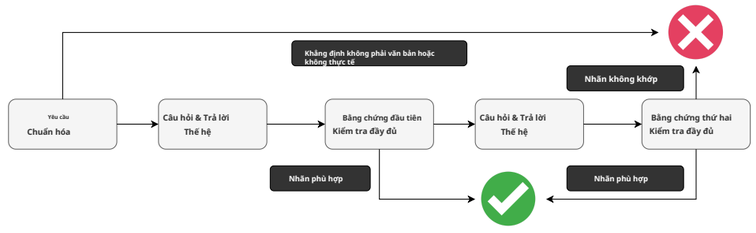
AVERITEC consists of 4,568 examples, collected from 50 fact-checking organizations using the Google FactCheck Claim Search API[2]; itself based on ClaimReview[3]. Our annotation, which involved up to five annotators per claim, resulted in substantial inter-annotator agreement, with a free-marginal $\kappa$ of 0.619 [Randolph, 2005]. We further develop a baseline to explore the feasibility of the task, relying on Google Search, BM25 [Robertson and Zaragoza, 2009], retrieved in-context prompts [Liu et al., 2022, Rubin et al., 2022], and a trained stance detection model. AVERITEC is the first AFC dataset to provide both question-answer decomposition and justifications, as well as avoid issues of context dependence, evidence insufficiency, and temporal leaks. Our dataset and baseline are available under a CC-BY-NC-4.0 license at `https://github.com/MichSchli/AVeriTeC`.

## 2 Related Work

Sourcing real-world claims from fact-checking articles is popular (e.g. Wang [2017]), as extracting claims from fact-checkers guarantees *checkworthiness*. That is, any claim included in the resulting dataset is deemed interesting enough to be worth the time of a professional journalist (see Hassan et al. [2015]). Previous real-world datasets either lack annotations for evidence, or suffer from context dependence, evidence insufficiency, or temporal leaks. Further, they do not provide annotations for intermediate steps, and only a minority (Alhindi et al. [2018], Kotonya and Toni [2020]) provide justifications. A comparison between AVeriTeC and prior datasets can be seen in Table 1.

[2] `https://toolbox.google.com/factcheck/apis`, available under a CC-BY-4.0 license.
[3] `https://www.claimreviewproject.com/`






Hình 1: Sơ đồ cho quy trình chú thích của chúng tôi. Các tuyên bố được chọn và chuẩn hóa trước. Sau đó, hai vòng tạo cặp câu hỏi-trả lời và kiểm tra tính đầy đủ của bằng chứng đảm bảo việc chú thích bằng chứng chất lượng cao.

thông tin từ các bài viết mà chúng được trích xuất. Điều này có thể, ví dụ, do tham chiếu chưa được giải quyết hoặc bỏ từ, ví dụ, trong "tỷ lệ thất nghiệp đang tăng" không rõ ngữ cảnh địa lý/thời gian nào đang được xem xét.

2. Thiếu bằng chứng: Glockner và cộng sự [2022] phát hiện rằng nhãn trong một số tập dữ liệu (ví dụ, Hanselowski và cộng sự [2019]) thường không khớp với bằng chứng được chú thích, vì chúng dựa vào, ví dụ, giả định về người nói của tuyên bố. Điều này khác biệt đáng kể so với các phán quyết không đủ bằng chứng, vốn là nhãn cho các tuyên bố mà bằng chứng không thể tìm thấy.

3. Rò rỉ theo thời gian: Glockner và cộng sự [2022] đã phát hiện rằng các chú thích trong một số tập dữ liệu (ví dụ, Augenstein và cộng sự [2019]) chứa rò rỉ từ tương lai. Ví dụ, một tuyên bố từ tháng Giêng có thể được chú thích với bằng chứng từ tháng Ba cùng năm. Rò rỉ cũng có thể xảy ra giữa các phân tách, nếu ví dụ, bằng chứng cho một tuyên bố trong tập huấn luyện từ năm 2021 cũng liên quan đến một tuyên bố trong tập kiểm tra từ năm 2020.

Chúng tôi giải quyết (1) thông qua bước chuẩn hóa ban đầu, nơi các người chú thích bổ sung các tuyên bố với thông tin cần thiết từ bài viết kiểm chứng sự thật. Chúng tôi xác minh sự đầy đủ của điều này, và giải quyết ( 2), bằng cách kết hợp nhiều vòng chú thích với bước kiểm soát chất lượng "ấn", chú thích lại bất kỳ tuyên bố nào có bằng chứng không đủ. Chúng tôi giải quyết (3) bằng cách giới hạn người chú thích với các tài liệu bằng chứng được xuất bản trước tuyên bố, và bằng cách sắp xếp các tập huấn luyện, phát triển và kiểm tra theo th ứ tự thời gian. Với việc ngày càng dựa vào các mô hình ngôn ngữ lớn đã được huấn luyện trước, việc sắp xếp theo thời gian cung cấp một lợi ích bổ sung: nếu dữ liệu huấn luyện cho mô hình ngôn ngữ bị cắt trước thời điểm bắt đầu theo thời gian của tập kiểm tra, việc rò rỉ từ huấn luyện trước cũng sẽ không xảy ra.

AVERITEC bao gồm 4.568 ví dụ, được thu thập từ 50 tổ chức kiểm tra sự thật sử dụng API Google FactCheck Claim Search[2]; chính nó dựa trên ClaimReview[3]. Công việc chú thích của chúng tôi, với sự tham gia của tối đa năm người chú thích cho mỗi tuyên bố, đã dẫn đến sự đồng thuận đáng kể giữa các người chú thích, với free-marginal$_\kappa$ of 0.619 [Randolph, 2005]. Chúng tôi còn phát triển một phương án cơ bản để khám phá khả năng thực hiện nhiệm vụ này, dựa vào Google Search, BM25 [Robertson và Zaragoza, 2009], , các gợi ý truy xuất theo ngữ cảnh [Liu et al., 2022, Rubin et al., 2022], và một mô hình phát hiện quan điểm đã được huấn luyện. AVERITEC là bộ dữ liệu AFC đầu tiên cung cấp cả phân rã câu hỏi-trả lời lẫn các lý do biện minh, cũng như tránh các vấn đề về phụ thuộc ngữ cảnh, thiếu bằng chứng và rò rỉ thời gian. Bộ dữ liệu và phương án cơ bản của chúng tôi có sẵn theo giấy phép CC-BY-NC-4.0 tại https://github.com/MichSchli/AVeriTeC.

## 2 Công trình liên quan

Việc lấy các tuyên bố từ các bài viết kiểm chứng sự thật trong thế giới thực là phổ biến (ví dụ, Wang [2017]), vì việc trích xuất tuyên bố từ những người kiểm chứng sự thật đảm bảo tính đáng kiểm tra. Tức là, bất kỳ tuyên bố nào được đưa vào bộ dữ liệu kết quả đều được coi là đủ thú vị để xứng đáng với thời gian của một nhà báo chuyên nghiệp (xem Hassan et al. [2015]). Các bộ dữ liệu thực tế trước đây hoặc thiếu chú thích cho bằng chứng, hoặc gặp phải vấn đề phụ thuộc ngữ cảnh, thiếu bằng chứng, hoặc rò rỉ thông tin theo thời gian. Hơn nữa, chúng không cung cấp chú thích cho các bước trung gian, và chỉ có một số ít (Alhindi et al. [2018], Kotonya và Toni [2020]) cung cấp lý do giải thích. Một bảng so sánh giữa AVeriTeC và các bộ dữ liệu trước có thể thấy trong Bảng 1.

[2] https://toolbox.google.com/factcheck/apis, có sẵn theo giấy phép CC-BY-4.0.[3]
https://www.claimreviewproject.com/

| Dataset | Claim | | | Evidence | | |
|---|---|---|---|---|---|---|
| | *Source* | *Type* | *Independence* | *Sufficient* | *Unleaked* | *Retrieved* |
| FEVER [Thorne et al., 2018] | Wikipedia | Synthetic | ✓ | ✓ | N/A | ✓ |
| VitaminC [Schuster et al., 2021] | Wikipedia | Synthetic | ✓ | ✓ | N/A | ✓ |
| FEVEROUS [Aly et al., 2021] | Wikipedia | Synthetic | ✓ | ✓ | N/A | ✓ |
| SciFact [Wadden et al., 2020] | Science | Synthetic | ✓ | ✓ | N/A | ✓ |
| FM2 [Saakyan et al., 2021] | Game | Synthetic | ✓ | ✓ | N/A | ✓ |
| Covid-Fact [Saakyan et al., 2021] | Reddit | Synthetic | ✓ | ✓ | N/A | ✓ |
| Liar-Plus [Alhindi et al., 2018] | Factcheck | Real | ✗ | ✓ | ✗ | ✗ |
| PolitiHop [Ostrowski et al., 2021] | Factcheck | Real | ✗ | ✓ | ✗ | ✗ |
| MultiFC [Augenstein et al., 2019] | Factcheck | Real | ✗ | ✗ | ✗ | ✓ |
| XFact [Gupta and Srikumar, 2021] | Factcheck | Real | ✗ | ✗ | ✗ | ✓ |
| PubHealth [Kotonya and Toni, 2020] | Factcheck | Real | ✗ | ✗ | ✓ | ✗ |
| WatClaimCheck [Khan et al., 2022] | Factcheck | Real | ✗ | ✗ | ✓ | ✗ |
| ClaimDecomp [Chen et al., 2022] | Factcheck | Real | ✗ | ✗ | ✓ | ✗ |
| Snopes [Hanselowski et al., 2019] | Factcheck | Real | ✗ | ✗ | ✓ | ✗ |
| QABrief [Fan et al., 2020] | Factcheck | Real | ✗ | ✗ | ✓ | ✗ |
| ClimateFEVER [Diggelmann et al., 2020] | Web | Real | ✗ | ✗ | ✓ | ✓ |
| HealthVer [Sarrouti et al., 2021] | Web | Real | ✗ | ✗ | ✓ | ✓ |
| CHEF [Hu et al., 2022] | Factcheck | Real | ✗ | ✓ | ✗ | ✓ |
| AVERITEC | Factcheck | Real | ✓ | ✓ | ✓ | ✓ |

Table 1: Comparison of fact-checking datasets. *Source* indicates where the claims are collected from, such as Wikipedia, or fact-checking articles (Factcheck). *Type* indicates whether the claims are synthetic or real-world. *Independence* indicates whether the claim is context independent. *Sufficient* indicates whether the evidence can provide sufficient information. *Unleaked* means whether the evidence contains leaks from the future and *retrieved* denotes whether the dataset involves evidence retrieval instead of relying on pre-retrieved passages e.g. the fact-checking article.

Beyond evidence insufficiency and temporal leakage, Glockner et al. [2022] also found that many examples require a *source guarantee* to refute, i.e. a guarantee that the claimant's underlying reason for making the claim is known to the debunker. For example, evidence against the claim *"COVID-19 vaccines may kill sharks"* can only be found when incorporating the underlying reasoning of the claimant, that the manufacturing of COVID-19 vaccines requires a chemical extracted from sharks. We do not explicitly provide such a guarantee; however, as each claim in AVERITEC is annotated with the original claimant, these underlying reasons can be recovered through question-answer pairs.

Question-answer decomposition is considered a promising strategy; Yang et al. [2022] proposed such a model even without a dataset of annotated question-answer pairs. Two recent datasets cast fact-checking as question-answering: Fan et al. [2020] and Chen et al. [2022]. However, Fan et al.'s [2020] question-answer pairs were only written to add relevant context, not to capture entire the fact-checking process, and thus lack evidence sufficiency. Ousidhoum et al. [2022] furthermore identified context dependence as a significant concern in Fan et al. [2020]: many questions are impossible to generate given only the claim, as they refer to entities and events only mentioned in the original fact-checking article. Chen et al. [2022] did – like us – attempt to ensure evidence sufficiency. However, they take no steps to verify their success. Furthermore, their evidence is taken directly from the fact-checking articles which are written after the claim, thus exhibiting temporal leakage.

## 3 Annotation Structure

Our dataset consists of 4,568 real-world claims annotated with question-answer pairs representing the evidence, a veracity label, and a textual justification describing how the evidence supports the label. An example can be seen in Figure 2.

Reasoning about evidence is represented through questions and answers. Questions may have multiple answers, a natural way to show potential disagreements in the evidence. Questions can refer to previous questions, allowing for multi-hop reasoning. Answers (other than *"No answer could be found."*) must be supported by a *source url* linking to a web document. To avoid sources disappearing from the web, we cache all pages used as evidence in the internet archive[4].

Claims in AFC datasets are typically *supported* or *refuted* by evidence, or there is *not enough evidence*. We add a fourth class: *conflicting evidence/cherry-picking*. This covers both conflicting evidence, and

[4]https://archive.org



| Bộ dữ liệu | Yêu cầu | | | Bằng chứng | | |
|---|---|---|---|---|---|---|
| | *Nguồn* | *Type* | *Độc lập* | *Đầy đủ* | *Chưa bị tiết lộ* | *Đã lấy lại* |
| FEVER [Thorne et al., 2018] | Wikipedia | Tổng hợp | ✓ | ✓ | N/A | ✓ |
| Vitamin C [Schuster et al., 2021] | Wikipedia | Tổng hợp | ✓ | ✓ | N/A | ✓ |
| FEVEROUS [Aly và cộng sự, 2021] | Wikipedia | Tổng hợp | ✓ | ✓ | N/A | ✓ |
| SciFact [Wadden và cộng sự, 2020] | Khoa học | Tổng hợp | ✓ | ✓ | N/A | ✓ |
| FM2 [Saakyan và cộng sự, 2021] | Game | Tổng hợp | ✓ | ✓ | N/A | ✓ |
| Covid-Fact [Saakyan et al., 2021] | Reddit | Tổng hợp | ✓ | ✓ | N/A | ✓ |
| Liar-Plus [Alhindi và cộng sự, 2018] | Kiểm tra sự thật | Real | ✗ | ✓ | ✗ | ✗ |
| PolitiHop [Ostrowski và cộng sự, 2021] | Kiểm tra sự thật | Real | ✗ | ✓ | ✗ | ✗ |
| MultiFC [ Augenstein et al., 2019] | Kiểm chứng sự thật | Real | ✗ | ✗ | ✗ | ✓ |
| XFact [ Gupta và Srikumar, 2021] | Kiểm chứng sự thật | Real | ✗ | ✗ | ✗ | ✓ |
| PubHealth [Kotonya và Toni, 2020] | Kiểm tra sự thật | Real | ✗ | ✗ | ✓ | ✗ |
| WatClaimCheck [Khan và cộng sự, 2022] | Kiểm tra sự thật | Real | ✗ | ✗ | ✓ | ✗ |
| ClaimDecomp [Chen et al., 2022] | Kiểm tra sự thật | Real | ✗ | ✗ | ✓ | ✗ |
| Snopes [Hanselowski và cộng sự, 2019] | Kiểm tra sự thật | Real | ✗ | ✗ | ✓ | ✗ |
| QABrief [Fan và cộng sự, 2020] | Kiểm tra sự thật | Real | ✗ | ✗ | ✓ | ✗ |
| ClimateFEVER [ Diggelmann et al., 2020] | Web | Real | ✗ | ✗ | ✓ | ✓ |
| HealthVer [ Sarrouti và cộng sự, 2021] | Web | Real | ✗ | ✗ | ✓ | ✓ |
| CHEF [Hu và cộng sự, 2022] | Kiểm tra sự thật | Real | ✗ | ✓ | ✗ | ✓ |
| AVERITEC | Kiểm tra s ự thật | Real | ✓ | ✓ | ✓ | ✓ |

Bảng 1: So sánh các tập dữ liệu kiểm chứng thông tin. Nguồn cho biết các tuyên bố được thu thập từ đâu, chẳng hạn như Wikipedia hoặc các bài viết kiểm chứng thông tin (Factcheck). Loại cho biết các tuyên bố là tổng hợp hay từ thế giới thực. Độc lập cho biết liệu tuyên bố có phụ thuộc vào ngữ cảnh hay không. Đủ cho biết liệu bằng chứng có thể cung cấp thông tin đầy đủ hay không. Chưa rò rỉ nghĩa là liệu bằng chứng có chứa thông tin rò rỉ từ tương lai hay không và truy xuất cho biết liệu tập dữ liệu có liên quan đến việc truy xuất bằng chứng thay vì dựa vào các đoạn văn đã được truy xuất trước, ví dụ như bài viết kiểm chứng thông tin.

Ngoài việc thiếu chứng cứ và rò rỉ theo thời gian, Glockner và cộng sự [2022] cũng phát hiện rằng nhiều ví dụ yêu cầu có đảm bảo từ nguồn để bác bỏ, tức là một đảm bảo rằng lý do cơ bản mà người đưa ra tuyên bố biết được với người bác bỏ. Ví dụ, bằng chứng chống lại tuyên bố "vắc-xin COVID-19 có thể giết cá mập" chỉ có thể được tìm thấy khi kết hợp lý luận cơ bản của người đưa ra tuyên bố, rằng việc sản xuất vắc-xin COVID-19 cần một hóa chất chiết xuất từ cá mập. Chúng tôi không cung cấp đảm bảo đó một cách rõ ràng; tuy nhiên, vì mỗi tuyên bố trong AVERITEC đều được chú thích với người đưa ra tuyên bố gốc, những lý do cơ bản này có thể được khôi phục thông qua các cặp câu hỏi-trả lời.

Phân tách câu hỏi-trả lời được coi là một chiến lược triển vọng; Yang và cộng sự [2022] đã đề xuất một mô hình như vậy ngay cả khi không có bộ dữ liệu các cặp câu hỏi-trả lời được chú thích. Hai bộ dữ liệu gần đây coi việc kiểm tra sự thật như là trả lời câu hỏi: Fan và cộng sự [2020] và Chen và cộng sự [2022]. Tuy nhiên, các cặp câu hỏi-trả lời của Fan và cộng sự [2020] chỉ được viết để thêm ngữ cảnh liên quan, không nhằm nắm bắt toàn bộ quá trình kiểm tra sự thật, và do đó thiếu tính đầy đủ về bằng chứng. Hơn nữa, Ousidhoum và cộng s ự [2022] đã xác định sự phụ thuộc vào ngữ cảnh là một mối quan tâm đáng kể trong Fan và cộng sự [2020]: nhiều câu hỏi là không thể tạo ra chỉ với tuyên bố, vì chúng đề cập đến các thực thể và sự kiện chỉ được nhắc đến trong bài viết kiểm tra sự thật gốc. Chen và cộng sự [2022] – giống như chúng tôi – đã cố gắng đảm bảo tính đầy đủ của bằng chứng. Tuy nhiên, họ không thực hiện bất kỳ bước nào để xác minh sự thành công của mình. Hơn nữa, bằng chứng của họ được lấy trực tiếp từ các bài viết kiểm tra sự thật được viết sau khi tuyên bố xuất hiện, do đó thể hiện sự rò rỉ về thời gian.

## 3 Cấu trúc Chú thích

Tập dữ liệu của chúng tôi bao gồm 4.568 tuyên bố thực tế được chú thích với các cặp câu hỏi-trả lời đại diện cho bằng chứng, nhãn xác thực và phần lý giải bằng văn bản mô tả cách bằng chứng hỗ trợ nhãn. Một ví dụ c ó thể được xem trong Hình 2.

Suy luận về bằng chứng được thể hiện thông qua các câu hỏi và câu trả lời. Các câu hỏi có thể có nhiều c âu trả lời, một cách tự nhiên để thể hiện những bất đồng tiềm ẩn trong bằng chứng. Các câu hỏi có thể tham chiếu đến các câu hỏi trước đó, cho phép suy luận nhiều bước. Các câu trả lời (ngoài câu "Không tìm thấy câu trả lời nào.") phải được hỗ trợ bởi một URL nguồn liên kết đến tài liệu web. Để tránh các nguồn biến mất khỏi web, chúng tôi lưu trữ tất cả các trang được sử dụng làm bằng chứng trong kho lưu trữ internet [4].

Các tuyên bố trong các bộ dữ liệu AFC thường được hỗ trợ hoặc bác bỏ bằng chứng, hoặc không có đủ bằng chứng. Chúng tôi thêm một lớp thứ tư: bằng chứng mâu thuẫn/cherry-picking. Điều này bao gồm cả bằng chứng mâu thuẫn, và

[4]https://archive.org

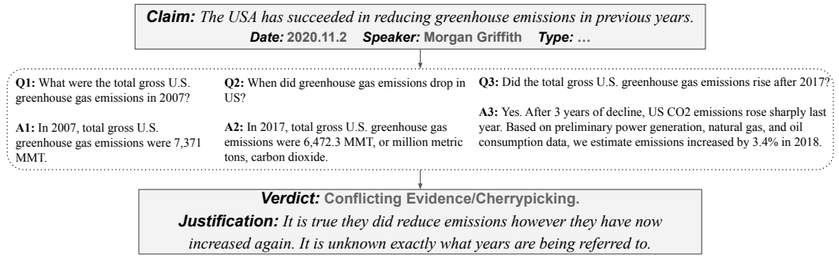



Figure 2: Example claim from AVERITEC. As opposed to previous datasets, ours naturally combines question-answer pairs that break down the evidence retrieval with justifications that show how evidence leads to verdicts.

technically true claims that mislead by excluding important context. For real-world claims, sources may interpret events differently, and therefore legitimately disagree. This differs from Schuster et al. [2021], which studies claims for which the evidence has been revised. Adding a fourth class has also recently been discussed in the context of natural language inference [Jiang and Marneffe, 2022], although there it is usually ambiguity in the premise or hypothesis leading to the conflict.

AVERITEC also provides textual justifications that explain how verdicts are reached from the evidence. Where sources disagree, best practices for established fact-checkers is to provide a textual explanation of *why* the claim misleads [Uscinski and Butler, 2013, Amazeen, 2015]. These justifications can be *substantial* [Toulmin, 1958], i.e. they may introduce logical leaps supported by commonsense or inductive reasoning beyond the retrieved evidence. For example, if a claim states that 50% of a population group were vaccinated by February 1st, and evidence shows only 33% had been vaccinated by January 31st, the justification may reason that a 50% rate one day later is unlikely.

We include several fields of metadata: the *speaker* of the claim, the *publisher* of the claim, the *date* the claim was published, and the *location* most relevant to the claim. These can be used to support questions, answers, and justifications. We also annotate the *claim type* and *fact-checking strategy* of each claim. Type represents common aspects, e.g., whether claims are about numerical facts; strategy represents the approach of the fact-checkers, e.g., whether they relied on expert testimony. Types and strategies should not be used as input to models (at inference time), but can provide useful data for analysis.

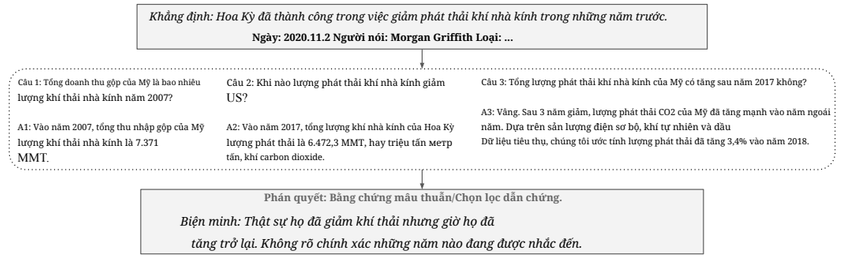
## 4 Annotation Process

Starting from 8,000 fact-checking articles, we first identified and discarded 537 duplicates and 802 paywalled or dead articles. We passed the remainder through a five-phase pipeline – see Figure 1. First, an annotator extracts claims and relevant metadata from each article, providing context independence. Second, an annotator generates questions and answers them using the web. These annotators also choose a temporary verdict. Third, a different annotator provides a justification and a verdict based *solely* on the annotated question-answer pairs; this serves as an evidence sufficiency check. Any claim for which the two verdicts do not match is passed through the last two phases again. If the verdicts still disagree, the claim is discarded. Different annotators were used for each claim in each phase – i.e., no annotator saw the same claim twice. Our annotation was performed by the company Appen[5]; details and annotation guidelines can be found in Appendices C and J.

**Claim Extraction & Normalisation** Annotators extracted the central claims from each fact-checking article, enriching them with the necessary context. This is necessary as many fact-checking articles cover multiple claims (e.g., several rumours circulating about an event). Further, some claims lack adequate contextualization [Ousidhoum et al., 2022]. For example, the claim *"we have 21 million unemployed"* requires coreference resolution. After claim extraction, we discarded *speculative* claims,

[5] https://appen.com/






Hình 2: Ví dụ về tuyên bố từ AVERITEC. Khác với các bộ dữ liệu trước đây, bộ dữ liệu của chúng tôi tự nhiên kết hợp các cặp câu hỏi-trả lời phân tách việc truy xuất bằng chứng với các lý do cho thấy cách bằng chứng dẫn đến phán quyết.

các tuyên bố về mặt kỹ thuật là đúng nhưng gây hiểu lầm bằng cách loại bỏ bối cảnh quan trọng. Đối với các tuyên bố trong thế giới thực, các nguồn có thể diễn giải sự kiện khác nhau, và do đó có thể bất đồng một cách hợp pháp. Điều này khác với Schuster et al. [2021], nghiên cứu các tuyên bố mà bằng chứng đã được chỉnh sửa. Việc thêm một lớp thứ tư cũng gần đây đã được thảo luận trong bối cảnh suy luận ngôn ngữ tự nhiên [Jiang và Marneffe, 2022], mặc dù ở đó thường là sự mơ hồ trong tiền đề hoặc giả thuyết dẫn đến xung đột.

AVERITEC cũng cung cấp các lý giải bằng văn bản giải thích cách các phán quyết được đưa ra từ bằng chứng. Khi các nguồn thông tin mâu thuẫn, các thực tiễn tốt nhất đối với những người kiểm tra sự thật đã được thiết lập là cung cấp một lời giải thích bằng văn bản về lý do tại sao tuyên bố đó gây hiểu lầm [Uscinski và Butler, 2013, Amazeen, 2015]. Những lý giải này có thể khá quan trọng [Toulmin, 1958], tức là chúng có thể đưa ra những bước nhảy logic được hỗ trợ bởi kiến thức thông thường hoặc suy luận quy nạp vượt ra ngoài bằng chứng có được. Ví dụ, nếu một tuyên bố nói rằng 50% một nhóm dân cư đã được tiêm chủng vào ngày 1 tháng 2, và bằng chứng cho thấy chỉ có 33% đã được tiêm chủng vào ngày 31 tháng 1, lý giải có thể suy luận rằng tỉ lệ 50% vào ngày hôm sau là không khả thi.

Chúng tôi bao gồm một số trường siêu dữ liệu: người phát ngôn của tuyên bố, nhà xuất bản của tuyên bố, ngày tuyên bố được công bố, và địa điểm liên quan nhất đến tuyên bố. Những thông tin này có thể được sử dụng để hỗ trợ các câu hỏi, câu trả lời và lý do giải thích. Chúng tôi cũng chú thích loại tuyên bố và chiến lược kiểm chứng một cách sự thật của từng tuyên bố. Loại đại diện cho các khía cạnh phổ biến, ví dụ, liệu các t uyên bố có liên quan đến các dữ liệu số hay không; chiến lược đại diện cho cách tiếp cận của các nhân viên kiểm chứng, ví dụ, liệu họ có dựa vào lời khai của chuyên gia hay không. Các loại và chiến lược không nên được sử dụng làm dữ liệu đầu vào cho các mô hình (tại thời điểm suy luận), nhưng có thể cung cấp dữ liệu hữu ích cho việc phân tích.

## 4 Quá trình Chú thích

Bắt đầu từ 8.000 bài viết kiểm chứng sự thật, trước tiên chúng tôi đã xác định và loại bỏ 537 bài trùng lặp và 802 bài bị trả phí hoặc không còn tồn tại. Chúng tôi đã đưa phần còn lại qua một quy trình năm giai đoạn – xem Hình 1. Đầu tiên, một người chú thích trích xuất các tuyên bố và siêu dữ liệu liên quan từ mỗi bài viết, đảm bảo tính độc lập về ngữ cảnh. Thứ hai, một người chú thích tạo các câu hỏi và trả lời chúng sử dụng web. Những người chú thích này cũng chọn một phán quyết tạm thời. Thứ ba, một người chú thích khác cung cấp lý do và phán quyết chỉ dựa trên các cặp câu hỏi-trả lời đã được chú thích; đây là bước kiểm tra độ đầy đủ của bằng chứng. Bất kỳ tuyên bố nào mà hai phán quyết không khớp được sẽ phải qua lại hai giai đoạn cuối cùng. Nếu các phán quyết vẫn không đồng ý, tuyên bố đó sẽ bị loại bỏ. Các người chú thích khác nhau được sử dụng cho mỗi tuyên bố trong mỗi giai đoạn – tức là, không ai chú thích cùng một tuyên bố hai lần. Việc chú thích c ủa chúng tôi được thực hiện bởi công ty Appen[5]; chi tiết và hướng dẫn chú thích có thể được tìm thấy trong Phụ lục C và J.

Các chú thích viên trích xuất và chuẩn hóa luận điểm đã trích xuất các luận điểm trung tâm từ mỗi bài viết kiểm chứng sự thật, đồng thời bổ sung cho chúng bối cảnh cần thiết. Điều này là cần thiết vì nhiều bài viết kiểm chứng sự thật bao gồm nhiều luận điểm (ví dụ, nhiều tin đồn lan truyền về một sự kiện). Hơn nữa, một số luận điểm thiếu sự định bối cảnh đầy đủ [Ousidhoum et al., 2022]. Ví dụ, luận điểm "chúng ta có 21 triệu người thất nghiệp" cần giải quyết sự tham chiếu. Sau khi trích xuất luận điểm, chúng tôi đã loại bỏ các luận điểm suy đoán.

[5] https://appen.com/

| Split | Train | Dev | Test |
|---|---|---|---|
| Claims | 3068 | 500 | 1000 |
| Questions / Claim | 2.60 | 2.57 | 2.57 |
| Reannotated (%) | 28.1 | 24.4 | 25.1 |
| End date | 25-08-2020 | 31-10-2020 | 22-12-2021 |
| Labels (S / R / C / N) (%) | 27.6 / 56.8 / 6.4 / 9.2 | 24.4 / 61.0 / 7.6 / 7.0 | 25.5 / 62.0 / 6.3 / 6.2 |

Table 2: Descriptive statistics for the dataset. Statistics for labels are split into supported (S), refuted (R), conflicting evidence/cherrypicking (C), and not enough evidence (N). For the dev and test splits, the start date is the end date of the previous split; the train set has no start date.

i.e. unverifiable statements about future events or personal opinions, and *multimodal* claims, i.e. claims where the type or the strategy inherently involves modalities beyond text.

**Question Generation & Answering** Annotators generate questions and answer them providing evidence about the claim. The aim is to "deconstruct" the reasoning of the fact-checker into a QA-structure, extracting question-answer pairs that match the content of their enquiries. This makes the process better amenable to annotators who are not trained journalists, and provides structured representations for model development and evaluation. Each question must be accompanied by an answer (or marked *unanswerable*), and answers must be backed by sources. We advise annotators that extractive answers are preferred, but abstractive answers are also allowed. Annotators in this phase are asked to provide a verdict based on their retrieved evidence, possibly different from the one in the fact-checking article.

As annotators follow the fact-checking articles, the ideal evidence sources for answer are the documents linked from the articles. For answers are not found in the linked documents, we provide access to a custom Google search bar. This search bar is restricted to show documents published only *before* the claim date, in contrast to prior work [Fan et al., 2020]. Furthermore, unlike Alhindi et al. [2018] and Hanselowski et al. [2019], the fact-checking article itself cannot be used as evidence.

We note that, where annotators could not find the publication date of the *claim*, their instructions were to use the publication date of the *fact-checking article* instead. As the process of fact-checking can take journalists several days, there is a window in which news about the claim can be published that we cannot prevent from being used as evidence. Further, the Google API does not always correctly infer the publication dates of articles. As such, our guarantee against temporal leakage is approximate (see Section 8). For the development set, we estimated that around 6% of answers are sourced from a fact-checking domain. This is primarily because of the earlier publication of an article about the same claim by a different fact-checking organization.

**Evidence Sufficiency Check** Once question-answer pairs have been generated, we present each claim along with its question-answer pairs to a new annotator. This annotator does *not* see the fact-checking article. They then produce a verdict and a textual justification for it. We compare this verdict to the one produced by the question and answer annotator, and if they disagree we repeat the question-&-answer generation and sufficiency check steps with new annotators to improve the evidence and the verdict.

## 5 Dataset Statistics

We split our dataset into training, validation, and test data temporally (see Table 2). Claims have on average 2.60 questions, and questions have on average 1.07 answers. Most answers (53%) are extractive, followed by abstractive (26%) and boolean (17%) answers. A few questions (4%) are marked unanswerable as no available evidence could be found by the annotators. Statistics for source document modality, fact-checker strategy, and claim type can be seen in Appendix F. We note that AVERITEC is somewhat unbalanced – the majority of claims are *refuted*. This is a consequence of our choice to rely on fact-checking articles, as journalists tend to pick false or misleading claims to work on. Our dataset includes all ClaimReview claims labeled *supported* (or any variation thereof, e.g. *true*) within our temporal limits (for more detail see Appendix I.1).



| Chia | Tàu | Dev | Test |
|---|---|---|---|
| Yêu cầu | 3068 | 500 | 1000 |
| Câu hỏi / Khiếu nại | 2.60 | 2.57 | 2.57 |
| Được chú thích lại (%) | 28.1 | 24.4 | 25.1 |
| Ngày kết thúc | 25-08-2020 | 31-10-2020 | 22-12-2021 |
| Nhãn (S / R / C / N) (%) | 27,6 / 56,8 / 6,4 / 9,2 | 24,4 / 61,0 / 7,6 / 7,0 | 25,5 / 62,0 / 6,3 / 6,2 |

Bảng 2: Thống kê mô tả cho tập dữ liệu. Thống kê cho các nhãn được chia thành hỗ trợ (S), phản bác (R), bằng chứng mâu thuẫn/chọn lọc (C), và không đủ bằng chứng (N). Đối với các phần dev và test, ngày bắt đầu là ngày kết thúc của phần trước; tập train không có ngày bắt đầu.

tức là, những phát biểu không thể kiểm chứng về các sự kiện trong tương lai hoặc ý kiến cá nhân, và những tuyên bố đa phương tiện, tức là những tuyên bố mà loại hình hoặc chiến lược vốn dĩ liên quan đến các phương thức vượt ra ngoài văn bản.

Các Nhân viên Chú thích Tạo Câu hỏi & Trả lời tạo ra các câu hỏi và trả lời chúng, đồng thời cung cấp bằng chứng về tuyên bố. Mục tiêu là "phân tích" lập luận của người kiểm tra sự thật thành một cấu trúc QA, trích xuất các cặp câu hỏi-trả lời phù hợp với nội dung của các truy vấn của họ. Điều này làm cho quá trình trở nên thích hợp hơn đối với các nhân viên chú thích không phải là nhà báo được đào tạo, và cung cấp các đại diện có cấu trúc cho phát triển và đánh giá mô hình. Mỗi câu hỏi phải kèm theo một câu trả lời (hoặc được đánh dấu là không thể trả lời), và các câu trả lời phải được hỗ trợ bởi các nguồn. Chúng tôi khuyên các nhân viên chú thích rằng câu trả lời trích xuất được ưu tiên, nhưng câu trả lời tóm tắt cũng được phép. Các nhân viên chú thích trong giai đoạn này được yêu cầu đưa ra phán quyết dựa trên bằng chứng mà họ thu thập được, có thể khác với phán quyết trong bài kiểm tra sự thật.

Khi các người chú thích theo dõi các bài báo kiểm chứng sự thật, các nguồn bằng chứng lý tưởng cho câu trả lời là các tài liệu được liên kết từ các bài báo. Đối với các câu trả lời không được tìm thấy trong các tài liệu liên kết, chúng tôi cung cấp quyền truy cập vào một thanh tìm kiếm Google tùy chỉnh. Thanh tìm kiếm này bị giới hạn chỉ hiển thị các tài liệu được xuất bản trước ngày tuyên bố, trái ngược với các công trình trước [Fan et al., 2020]. Hơn nữa, không giống như Alhindi et al. [2018] và Hanselowski et al. [2019]„ chính bài báo kiểm chứng sự thật không thể được sử dụng làm bằng chứng.

Chúng tôi lưu ý rằng, khi các người chú thích không thể tìm thấy ngày xuất bản của tuyên bố, hướng dẫn của họ là sử dụng ngày xuất bản của bài báo kiểm chứng sự thật thay thế. Vì quá trình kiểm chứng sự thật có thể mất vài ngày đối với các nhà báo, có một khoảng thời gian mà tin tức về tuyên bố có thể được xuất bản mà chúng tôi không thể ngăn nó bị sử dụng làm bằng chứng. Hơn nữa, API của Google không phải lúc nào cũng suy đoán chính xác ngày xuất bản của các bài báo. Do đó, đảm bảo của chúng tôi chống rò rỉ thời gian là t ương đối (xem Mục 8). Đối với tập phát triển, chúng tôi ước tính khoảng 6% câu trả lời được lấy từ một miền kiểm chứng sự thật. Nguyên nhân chính là do bài báo về cùng một tuyên bố đã được một tổ chức kiểm chứng sự thật khác xuất bản sớm hơn.

Kiểm tra Đủ Bằng Chứng Khi các cặp câu hỏi-trả lời đã được tạo ra, chúng tôi trình bày từng tuyên bố cùng v ới các cặp câu hỏi-trả lời đó cho một người gắn nhãn mới. Người gắn nhãn này không xem bài viết kiểm chứng sự thật. Sau đó, họ đưa ra phán quyết và một lý do bằng văn bản cho phán quyết đó. Chúng tôi so sánh phán quyết này với phán quyết do người gắn nhãn câu hỏi và trả lời đưa ra, và nếu họ không đồng ý, chúng tôi lặp lại các bước tạo câu hỏi-&-trả lời và kiểm tra tính đầy đủ với những người gắn nhãn mới để cải thiện bằng chứng và phán quyết.

## 5 Thống kê Bộ dữ liệu

Chúng tôi chia bộ dữ liệu của mình thành dữ liệu huấn luyện, dữ liệu xác thực và dữ liệu kiểm tra theo thời gian (xem Bảng 2). Trung bình mỗi tuyên bố có 2,60 câu hỏi, và mỗi câu hỏi có trung bình 1,07 câu trả lời. Phần lớn các câu trả lời (53%) là trích xuất, tiếp theo là tóm tắt (26%) và câu trả lời đúng/sai (17%). Một số câu hỏi (4%) được đánh dấu là không có câu trả lời vì không tìm thấy bằng chứng khả dụng bởi những người chú thích. Thống kê về loại tài liệu nguồn, chiến lược kiểm chứng sự thật và loại tuyên bố có thể được xem trong Phụ lục F. Chúng tôi lưu ý rằng AVERITEC hơi mất cân bằng – phần lớn các tuyên bố bị bác bỏ. Điều này là hệ quả của việc chúng tôi lựa chọn dựa vào các bài báo kiểm chứng sự thật, vì các nhà báo thường chọn những tuyên bố sai hoặc gây hiểu lầm để xử lý. Bộ dữ liệu của chúng tôi bao gồm tất cả các tuyên bố trong ClaimReview được gắn nhãn hỗ trợ (hoặc bất kỳ biến thể nào của nó, ví dụ như đúng) trong giới hạn thời gian của chúng tôi (để biết chi tiết hơn, xem Phụ lục I.1).

To measure the inter-annotator agreement of our annotation scheme, we had a second set of annotators re-annotate 100 claims from the dataset. In this we assumed the claim extraction and normalization step was done, and the annotators repeated the question and answer generation phase. Since we have an unbalanced dataset, following Kazemi et al. [2021], Ousidhoum et al. [2022], we therefore measure agreement using Randolph's [2005] free-marginal multirater $\kappa$, an alternative to Fleiss' $\kappa$ more suitable for unbalanced datasets [Warrens, 2010]. Our observed agreement score of $\kappa = 0.619$ is substantial, and compares well to those for other "hard" fact-checking annotation tasks, e.g. Kazemi et al. [2021], who got between $\kappa = .30$ and $\kappa = .63$ depending on the language. Using Fleiss' $\kappa$ [Fleiss, 1971], we get an agreement score of $0.503$.

## 6 Evaluation

To evaluate models on AVERITEC, we follow Thorne et al. [2018] and score retrieved evidence based on agreement with gold evidence, and give credit to veracity predictions (and justifications) only when correct evidence has been found. However, unlike in FEVER and other datasets using a closed source of evidence such as Wikipedia, AVERITEC is intended for use with evidence retrieved from the open web. Since the same evidence may be found in different sources, we cannot rely on exact matching to score retrieved evidence. As such, we instead rely on approximate matching.

To measure how well a set of generated questions and answers match the references, we rely on a pairwise scoring function $f : S \times S \rightarrow \mathbb{R}$, where $S$ is the set of sequences of tokens. We then use the Hungarian Algorithm [Kuhn, 1955] to find an optimal matching of generated sequences to reference sequences. Formally, let $X : \hat{Y} \times Y \rightarrow \{0, 1\}$ be a boolean function denoting the assignment between the generated sequences $\hat{Y}$ and the reference sequences $Y$. Then, the total score $u$ is calculated as:

$$u_f(\hat{Y}, Y) = \frac{1}{|Y|} \max \sum_{\hat{y} \in \hat{Y}} \sum_{y \in Y} f(\hat{y}, y) X(\hat{y}, y) \quad (1)$$

If $f$ is an exact match, we recover the evidence *recall* score from Thorne et al. [2018]. Our metric is as such a generalization of theirs to the approximate case. In our evaluation, we use the implementation of METEOR [Banerjee and Lavie, 2005] in NLTK [Bird et al., 2009] as the scoring function $f$ (and refer to our evidence scoring function as Hungarian METEOR hereafter), but any suitable pairwise metric could be used. We chose METEOR over other alternatives (e.g., ROUGE [Lin, 2004]) as it is known to correlate well with human judgments of similarity [Fomicheva and Specia, 2019]. We do not employ a precision metric, as we want to avoid penalizing systems for asking additional relevant information-seeking questions – however, all systems are limited to a maximum of $k = 10$ question-answer pairs.

We conduct the evaluation with Hungarian METEOR twice: once using only the questions as input sequences, and once using the concatenation of questions and answers. A subtask of AVERITEC is to *ask the right questions* – as we discuss in Section 7.2, good questions are very useful as search queries even if not accompanied by a good answer. Finding the right angle to criticize a claim is a substantial task by itself; it covers the creativity factor in retrieval discussed by Arnold [2020]. Including the question-only score allows comparison of systems along this axis as well. To evaluate veracity predictions and justifications, we use a cutoff of $f(\hat{y}, y) \geq \lambda$ to determine whether correct evidence has been retrieved (using concatenated questions and answers); any claim for which the evidence score is lower receives veracity and justification scores of $0$.

Many claims can be verified through alternative evidence formulations. Taking an example from the 100 claims annotated twice for Section 5, one annotator might produce the question-answer pair *"Where did South Africa rank in alcohol consumption? In 2016, South Africa ranked ninth out of 53 African countries."* while another produces *"What's the average alcohol consumption per person in South Africa? 7.1 litres."*. These may both be valid ways of establishing the relative levels of alcohol consumption between South Africa and other countries. We recognize that our evaluation approach can penalize systems for selecting an alternative evidence path; nevertheless, we argue that automatic evaluation on this task is helpful in model development. We note that a similar phenomenon was seen for the original FEVER dataset [Thorne et al., 2018], despite the artificial claims and the exclusive use of Wikipedia as an evidence source. There, the authors suggested crowd-sourced human evaluation as a more reliable alternative – we echo their recommendation. Our annotation process hints at a potential setup for human evaluation: judging if a body of evidence is sufficient for a verdict is exactly what our annotators did during the evidence sufficiency check phase.



Để đo lường sự đồng thuận giữa các người chú thích theo sơ đồ chú thích của chúng tôi, chúng tôi đã có một bộ người chú thích thứ hai thực hiện lại việc chú thích 100 tuyên bố từ bộ dữ liệu. Trong quá trình này, chúng tôi giả định rằng bước trích xuất và chuẩn hóa tuyên bố đã được thực hiện, và các người chú thích lặp lại giai đoạn tạo câu hỏi và trả lời. Vì chúng tôi có một bộ dữ liệu không cân bằng, theo Kazemi et al. [2021], Ousidhoum et al. [2022], do đó chúng tôi đo lường sự đồng thuận bằng phương pháp [2005] multirater miễn phí theo Randolph $\kappa$, một phương pháp thay thế cho Fleiss $\kappa$thích hợp hơn cho các bộ dữ liệu không cân bằng [ Warrens, 2010]. Điểm đồng thuận quan sát được của chúng tôi $\kappa = 0.619$ là đáng kể, và so sánh tốt với các tác vụ chú thích kiểm chứng thực tế "khó" khác, ví dụ Kazemi et al. [2021], người đã đạt được từ $\kappa = .30$ đến $\kappa = .63$ tùy thuộc vào ngôn ngữ. Sử dụng Fleiss' $\kappa$ [Fleiss, 1971], , chúng tôi nhận được điểm đồng thuận là 0,503.

## 6 Đánh giá

Để đánh giá các mô hình trên AVERITEC, chúng tôi tuân theo Thorne và cộng sự [2018] và chấm điểm bằng chứng được truy xuất dựa trên sự đồng thuận với bằng chứng chuẩn, và chỉ công nhận các dự đoán độ xác thực (và các lý do giải thích) khi bằng chứng đúng đã được tìm thấy. Tuy nhiên, không giống như trong FEVER và các tập dữ liệu khác sử dụng nguồn bằng chứng đóng như Wikipedia, AVERITEC được thiết kế để sử dụng với bằng chứng được truy xuất từ web mở. Vì cùng một bằng chứng có thể được tìm thấy ở các nguồn khác nhau, chúng tôi không thể dựa vào việc khớp chính xác để chấm điểm bằng chứng truy xuất. Do đó, thay vào đó, chúng tôi dựa vào việc khớp gần đúng.

Để đo lường mức độ phù hợp của một tập hợp các câu hỏi và câu trả lời được tạo với các tham chiếu, chúng t ôi dựa vào một hàm điểm cặp $f$: $S \times S \rightarrow \mathbb{R}$, trong đó $S$ là tập hợp các chuỗi token. Sau đó, chúng tôi sử dụng Thuật toán Hungary [ Kuhn, 1955] để tìm một phép ghép tối ưu giữa các chuỗi được tạo và các chuỗi tham chiếu. Một cách chính thức, cho $X$:ˆ $Y \times Y \rightarrow \{0, 1\}$ là một hàm boolean biểu thị việc gán giữa ˆ các chuỗi được tạo $Y$ và các chuỗi tham chiếu $Y$. Sau đó, tổng điểm $u$ được tính như sau:

$$u_f(\hat{Y}, Y) = \frac{1}{|Y|} \max \sum_{\hat{y} \in \hat{Y}} \sum_{y \in Y} f(\hat{y}, y) X(\hat{y}, y) \quad (1)$$

Nếu $f$ là một kết quả khớp chính xác, chúng tôi sẽ phục hồi điểm hồi nhớ bằng chứng từ Thorne và cộng sự [2018]. Thước đo của chúng tôi là một tổng quát hóa của họ đối với trường hợp xấp xỉ. Trong đánh giá của chúng tôi, chúng tôi sử dụng triển khai của METEOR [Banerjee và Lavie, 2005] trong NLTK [Bird và cộng sự, 2009] làm hàm chấm điểm $f$ (và từ đây sẽ gọi hàm chấm điểm bằng chứng của chúng tôi là Hungarian METEOR), nhưng bất kỳ thước đo cặp phù hợp nào cũng có thể được sử dụng. Chúng tôi chọn METEOR thay vì các lựa chọn khác (ví dụ: ROUGE [Lin, 2004]) vì nó được biết là có tương quan tốt với đánh giá giống của con người [Fomicheva và Specia, 2019]. Chúng tôi không sử dụng thước đo độ chính xác, vì chúng tôi muốn tránh việc trừng phạt các hệ thống khi hỏi thêm các câu hỏi tìm kiếm thông tin liên quan – tuy nhiên, tất cả các hệ thống đều bị giới hạn tối đa $k = 10$ cặp câu hỏi-trả lời.

Chúng tôi tiến hành đánh giá với METEOR của Hungary hai lần: một lần chỉ sử dụng các câu hỏi làm chuỗi đầu vào, và một lần sử dụng sự kết hợp của câu hỏi và câu trả lời. Một nhiệm vụ phụ của AVERITEC là đặt ra các câu hỏi đúng – như chúng tôi thảo luận ở Mục 7.2, các câu hỏi tốt rất hữu ích như các truy vấn tìm kiếm ngay cả khi không đi kèm với câu trả lời tốt. Tìm góc độ đúng để chỉ trích một tuyên bố là một nhiệm vụ đáng kể, nó bao gồm yếu tố sáng tạo trong việc truy xuất thông tin như Arnold [2020]đã thảo luận. Bao gồm điểm chỉ câu hỏi cho phép so sánh các hệ thống theo trục này. Để đánh giá dự đoán tính xác thực và các lý giải, chúng tôi sử dụng ngưỡng $f(\hat{y}, y) \geq \lambda$ để xác định xem bằng chứng có được truy xuất đúng hay không (sử dụng kết hợp câu hỏi và câu trả lời); bất kỳ tuyên bố nào có điểm bằng chứng thấp hơn sẽ nhận điểm tính xác thực và lý giải bằng 0.

Nhiều tuyên bố có thể được xác minh thông qua các công thức bằng chứng thay thế. Lấy một ví dụ từ 100 tuyên bố được chú thích hai lần cho Phần 5, một người chú thích có thể tạo ra cặp câu hỏi-trả lời "Nam Phi xếp hạng bao nhiêu về tiêu thụ rượu? Năm 2016, Nam Phi xếp thứ chín trong số 53 quốc gia châu Phi." trong khi người khác tạo ra "Mức tiêu thụ rượu trung bình trên mỗi người ở Nam Phi là bao nhiêu? 7,1 lít.". Cả hai đều có thể là những cách hợp lệ để xác định mức tiêu thụ rượu tương đối giữa Nam Phi và các quốc gia khác. Chúng tôi nhận thấy rằng phương pháp đánh giá của chúng tôi có thể phạt các hệ thống vì chọn một con đường bằng chứng thay thế; tuy nhiên, chúng tôi cho rằng đánh giá tự động trong nhiệm vụ này hữu ích trong việc phát triển mô hình. Chúng tôi lưu ý rằng một hiện tượng tương tự đã được thấy trong bộ dữ liệu FEVER gốc [ Thorne et al., 2018], mặc dù các tuyên bố là nhân tạo và chỉ sử dụng Wikipedia làm nguồn bằng chứng. Ở đó, các tác giả đã đề xuất đánh giá con người từ cộng đồng như một mo

| Model | Q only | Q + A | Veracity @ (.2/.25/.3) | | | Justifications @ (.2/.25/.3) | | |
|---|---|---|---|---|---|---|---|---|
| No search | 0.19 | 0.11 | 0.03 | 0.02 | 0.01 | 0.02 | 0.01 | 0.01 |
| Gold evidence | 1.00 | 1.00 | 0.49 | 0.49 | 0.49 | 0.28 | 0.28 | 0.28 |
| AVERITEC -BLOOM-7b | 0.26 | 0.21 | 0.23 | 0.15 | 0.00 | 0.11 | 0.07 | 0.05 |
| gpt-3.5-turbo | 0.29 | 0.16 | 0.17 | 0.10 | 0.06 | 0.06 | 0.04 | 0.02 |

Table 3: Results for the AVERITEC baseline and ChatGPT (gpt3.5-turbo). Retrieval scores both for questions and for questions + answers are given in terms of Hungarian METEOR score. Veracity and justifications are scored using accuracy and METEOR respectively, in both cases conditioned on correct evidence retrieved at $\lambda = \{0.2, 0.25, 0.3\}$ (see Section 6). We report results for three versions of the baseline, as discussed in Section 7.2: a version that uses no evidence (no search), a version that uses gold evidence (gold evidence), and the full pipeline described in Section 7.1 (AVERITEC). We also report results for gpt-3.5-turbo (ChatGPT).

We further note that our metric is straightforward to extend to cover evaluation with multiple reference sets. Given a set of sets of question-answer pairs $R$ representing different questioning strategies, a best-matching score could be computed as $\max_{Y \in R} u_f(\hat{Y}, Y)$. As such, if AVERITEC was expanded with annotations for alternative questioning strategies, our metric could score models on these as well.

To understand how our metric should be interpreted, we also computed Hungarian METEOR scores between the question-answer pairs generated during the two rounds of annotation used for inter-annotator agreement in Section 5. At $0.28$ for questions and $0.22$ for questions and answers, these results are quite low, highlighting the difficulty of automatic evaluation for this task. Investigating claims with low agreement scores, we see that these are actually often a result of different annotators using different evidence sources for the same verdict, or phrasing equivalent question-answer pairs differently. Based on our observations of human annotations, we recommend $\lambda = 0.25$ as an appropriate cutoff value for our metric. We refer to this metric (for veracity prediction) as AVERITEC score.

# 7 Experiments

## 7.1 Baseline Model

Our baseline is a pipeline consisting of several components: generation of search questions, search, generation of questions given retrieved evidence, reranking of retrieved evidence, veracity prediction, and generation of justifications. For each step in the pipeline, we carried out experiments with several models. Using our training set, we finetuned, respectively, BERT-large [Devlin et al., 2019] for classification (340M parameters) and BART-large [Lewis et al., 2020] for generation (406M parameters). We furthermore tried a few-shot setup, prompting a large language model (LLM) with retrieved in-context examples [Liu et al., 2022, Rubin et al., 2022] from our training set. Here, we tried the 7b parameter BLOOM model [Scao et al., 2022] and the 13b parameter Vicuna model [Chiang et al., 2023]. We limited ourselves to relatively small models, as we consider runnability crucial for a baseline: all our components can be run on a single Nvidia A100 GPU. As such, our baseline strikes a balance between performance and computational cost.

**Search** Given a claim, we retrieve evidence documents from the internet using the Google Search API. Following Karadzhov et al. [2017], we use a reduced version of the claim keeping only verbs, nouns, and adjectives as the search term. As we did during annotation, we limit the API to documents published *before* the estimated date of the claim. We keep all unique documents in the first 30 search results. Initial experiments showed that questions were very useful as additional search terms. As the model does not have access to gold questions during testing, we instead generate questions. We experimented with three models: BART-large, *bloom-7b*, and *Vicuna-13b*. Surprisingly, BLOOM performed the best, beating the newer and larger Vicuna; we attribute this primarily to greater topical diversity in the set of questions generated, and thus greater variety in the retrieved evidence pages. We rely on prompting with retrieved in-context examples [Liu et al., 2022, Rubin et al., 2022]. We use BM25 [Robertson and Zaragoza, 2009] to find the 10 most similar claims from the training set,



| Mô hình | Chỉ Q | Q +A | Độ xác thực @ (.2/.25/.3) | | | Căn chỉnh @ (.2/.25/.3) | | |
|---|---|---|---|---|---|---|---|---|
| Không tìm kiếm | 0.19 | 0.11 | 0.03 | 0.02 | 0.01 | 0.02 | 0.01 | 0.01 |
| Bằng chứng vàng | 1.00 | 1.00 | 0.49 | 0.49 | 0.49 | 0.28 | 0.28 | 0.28 |
| AVERITEC -BLOOM-7b | 0.26 | 0.21 | 0.23 | 0.15 | 0.00 | 0.11 | 0.07 | 0.05 |
| gpt-3.5-turbo | 0.29 | 0.16 | 0.17 | 0.10 | 0.06 | 0.06 | 0.04 | 0.02 |

Bảng 3: Kết quả cho AVERITEC cơ sở và ChatGPT (gpt3.5-turbo). Điểm truy xuất cho cả câu hỏi và cho câu hỏi + câu trả lời đều được đưa ra dưới dạng điểm METEOR Hungary. Tính xác thực và lý giải được đánh giá bằng độ chính xác và METEOR tương ứng, trong cả hai trường hợp đều dựa trên bằng chứng đúng được truy xuất tại $\lambda = \{0.2, 0.25, 0.3\}$ (xem Mục 6). Chúng tôi báo cáo kết quả cho ba phiên bản của cơ sở, như đã thảo luận trong Mục 7.2: một phiên bản không sử dụng bằng chứng (không tìm kiếm), một phiên bản sử dụng bằng chứng chuẩn (bằng chứng chuẩn), và cả pipeline đầy đủ được mô tả trong Mục 7.1 (AVERITEC). Chúng tôi cũng báo cáo kết quả cho gpt-3.5-turbo (ChatGPT).

Chúng tôi cũng lưu ý rằng chỉ số của chúng tôi rất dễ dàng mở rộng để đánh giá với nhiều bộ tham chiếu. Với một tập hợp các bộ câu hỏi-trả lời $R$ đại diện cho các chiến lược đặt câu hỏi khác nhau, một điểm số khớp tốt nhất ˆ có thể được tính là $\max_{Y \in R} u_f(Y, Y)$. Do đó, nếu AVERITEC được mở rộng với các chú thích cho các c hiến lược đặt câu hỏi thay thế, chỉ số của chúng tôi cũng có thể đánh giá các mô hình trên các chiến lược này.

Để hiểu cách mà chỉ số của chúng tôi nên được giải thích, chúng tôi cũng đã tính điểm METEOR của Hungary giữa các cặp câu hỏi-trả lời được tạo ra trong hai vòng chú thích được sử dụng để đánh giá sự đồng thuận giữa các người chú thích trong Mục 5. Với 0,28 cho các câu hỏi và 0,22 cho câu hỏi và câu trả lời, những kết quả này khá thấp, nhấn mạnh sự khó khăn của việc đánh giá tự động đối với nhiệm vụ này. Khi điều tra các tuyên bố có điểm đồng thuận thấp, chúng tôi thấy rằng thực ra điều này thường là kết quả của việc các người chú thích khác nhau sử dụng các nguồn chứng cứ khác nhau cho cùng một phán quyết, hoặc trình bày các cặp câu hỏi-trả lời tương đương khác nhau. Dựa trên các quan sát của chúng tôi về các chú thích của con người, chúng tôi đề xuất $\lambda = 0.25$ là giá trị giới hạn phù hợp cho chỉ số của chúng tôi. Chúng tôi gọi chỉ số này (cho dự đoán độ xác thực) là điểm AVERITEC.

# 7 Thí nghiệm

## 7.1 Mô hình cơ sở

Cơ sở của chúng tôi là một chuỗi xử lý gồm nhiều thành phần: tạo câu hỏi tìm kiếm, tìm kiếm, tạo câu hỏi dựa trên bằng chứng đã truy xuất, xếp lại bằng chứng đã truy xuất, dự đoán tính xác thực, và tạo lý giải. Đối với mỗi bước trong chuỗi xử lý, chúng tôi đã thực hiện thí nghiệm với nhiều mô hình. Sử dụng tập huấn luyện c ủa mình, chúng tôi lần lượt tinh chỉnh BERT-large [Devlin et al., 2019] cho phân loại (340 triệu tham số) và BART-large [Lewis et al., 2020] cho sinh văn bản (406 triệu tham số). Hơn nữa, chúng tôi đã thử thiết lập few-shot, sử dụng một mô hình ngôn ngữ lớn (LLM) với các ví dụ trong ngữ cảnh đã truy xuất [Liu et al., 2022, Rubin et al., 2022] từ tập huấn luyện của chúng tôi. Ở đây, chúng tôi thử mô hình BLOOM 7b tham số [Scao et al., 2022] và mô hình Vicuna 13b tham số [Chiang et al., 2023]. Chúng tôi giới hạn bản thân với các mô hình tương đối nhỏ, vì chúng tôi coi khả năng chạy là rất quan trọng cho một cơ sở: tất cả các thành phần của chúng tôi có thể được chạy trên một GPU Nvidia A100 duy nhất. Do đó, cơ sở của chúng tôi cân bằng

Tìm kiếm Khi có một tuyên bố, chúng tôi truy xuất các tài liệu chứng cứ từ internet bằng cách sử dụng Google Search API. Theo Karadzhov và cộng sự [2017]. , chúng tôi sử dụng phiên bản rút gọn của tuyên bố, chỉ giữ lại động từ, danh từ và tính từ làm từ khóa tìm kiếm. Như chúng tôi đã làm trong quá trình chú thích, chúng tôi giới hạn API cho các tài liệu được xuất bản trước ngày ước tính của tuyên bố. Chúng tôi giữ tất cả các tài liệu duy nhất trong 30 kết quả tìm kiếm đầu tiên. Các thử nghiệm ban đầu cho thấy các câu hỏi rất hữu ích như các từ khóa tìm kiếm bổ sung. Vì mô hình không có quyền truy cập vào các câu hỏi vàng trong quá trình kiểm tra, chúng tôi thay vào đó tạo ra các câu hỏi. Chúng tôi đã thử nghiệm với ba mô hình: BART-large, bloom-7b và Vicuna-13b. Đáng ngạc nhiên, BLOOM hoạt động tốt nhất, vượt qua Vicuna mới hơn và lớn hơn; chúng tôi cho rằng điều này chủ yếu do tính đa dạng chủ đề cao hơn trong tập hợp các câu hỏi được tạo ra, và do đó có sự đa dạng lớn hơn trong các trang chứng cứ được truy xuất. Chúng tôi dựa vào việc gợi ý với các ví dụ trong ngữ cảnh đã truy xuất [ Liu và cộng sự, 2022, Rubin và cộng sự, 2022]. Chúng tôi sử dụng BM 25 [ Robertson

and use their annotated questions to construct a prompt, with which we generate questions for the claim using BLOOM. We tested {1,3,5,10} in-context examples, finding 10 to perform the best. The full prompt can be seen in Appendix D.1. We add any new unique documents retrieved by searching for these generated questions. This can be seen as a form of query expansion [Mao et al., 2021].

**Evidence Selection** Once a set of evidence documents has been created for each claim, we pick $N = 3$ sentences from this set. We first apply a coarse filter to the evidence set, ranking evidence sentences by BM25 score computed against the claim, and discard those outside the top 100. Then, we generate a question for each sentence that is answerable *by* that sentence, again using BLOOM. We tested {1,3,5,10} in-context examples, finding 10 to perform the best. The full prompt can be seen in Appendix D.2. We then re-rank these question-answer pairs to find the ones most relevant for the claim, using a finetuned BERT-large model [Devlin et al., 2019] (for more details, see Appendix E.1). This somewhat counter-intuitive strategy of retrieving first and then generating questions can be seen as using the generated questions to bridge claims to distantly related evidence sentences. Our approach is similar to the document expansion strategy proposed for question answering in Nogueira et al. [2019], except applied for reranking rather than the initial retrieval step.

**Veracity Prediction** Once question-answer pairs have been generated, we produce verdicts through a stance detection strategy inspired by past work on filtering evidence [Hanselowski et al., 2019]. We use a finetuned BERT-large model to label each question-answer pair as supporting, refuting, or being irrelevant to the question (for more details, see Appendix E.2). We then deterministically label the claim as follows: 1) if the claim has both supporting and refuting evidence, label it *conflicting evidence/cherrypicking*. 2) If the claim has only supporting question-answer pairs, label it *supported*; similar for *refuted*. 3) Otherwise, label the claim *not enough evidence*. We tested three different models for veracity prediction: BERT-large, *bloom-7b1*, and *Vicuna-13b. We found BERT to perform better by a slight margin; using gold evidence, we obtained macro-F1 scores of .49, .43, and .48 for the three models respectively.*

**Justification Generation** The final step is to generate a textual justification for the verdict. Here, we rely on BART-large [Lewis et al., 2020] finetuned on our training set (for more details, see Appendix E.3). We use the concatenation of the claim and the retrieved evidence as input; we tried adding the predicted veracity as well, but saw no improvements to performance. We again tested three models: BART-large, *bloom-7b1*, and *Vicuna-13b*, respectively obtaining a METEOR score of .28, .23, and .25. Based on our qualitative analysis of 20 claims, the justifications generated by Vicuna are very good, but the model is penalized for being overly verbose – Vicuna generates 36 tokens on average, compared to 21 in the gold data.

### 7.2 Results

We evaluate as discussed in Section 6. We include results in Table 3 at three thresholds for comparison, although we encourage $\lambda = 0.25$. We compare our baseline to two other models: one without access to search, and one using gold question-answer pairs as evidence.

For the *no search* model, we use prompting to generate questions, following the approach described in Appendix D.1. We leave all answers as *"No answer could be found"*. Generating answers is not an option, as answers must be supported by sources. We use BERT-large finetuned on the training data to predict veracity labels (without any evidence), and the same prompting strategy as discussed in Section 7.1 to generate justifications. For the *gold evidence* model, we use the gold question-answer pairs provided by our annotators in the place of generated questions and retrieved evidence. That is, we test only the veracity prediction and justification production components.

Analysing retrieval results on the development set, we still find $\lambda = 0.25$ to be a good cutoff point for the AVERITEC veracity and justification metrics. For borderline question-answer pairs this threshold is high enough that all important information must be produced to meet it, but there is still some room for paraphrasing and partial evidence.

Our baseline has decent performance at $\lambda = 0.2$ and $\lambda = 0.25$, but does not perform well at higher evidence cutoff points. Because of the structure of our pipeline – generate search terms, retrieve and rerank evidence, generate questions to match the reranked evidence – our baseline struggles to match specific evidence sets. If the retrieved evidence paragraph is very short, e.g., a table cell reading



và sử dụng các câu hỏi đã được chú thích của họ để xây dựng một prompt, với nó chúng tôi tạo ra các câu hỏi cho tuyên bố bằng BLOOM. Chúng tôi đã thử {1,3,5,10} ví dụ trong ngữ cảnh, và thấy rằng 10 ví dụ cho hiệu suất tốt nhất. Toàn bộ prompt có thể được xem trong Phụ lục D.1. Chúng tôi thêm bất kỳ tài liệu mới độc đáo nào được truy xuất bằng cách tìm kiếm các câu hỏi được tạo ra này. Điều này có thể được coi như một hình thức mở rộng truy vấn [Mao et al., 2021].

Lựa chọn bằng chứng Một khi một bộ tài liệu bằng chứng đã được tạo cho mỗi tuyên bố, chúng tôi chọn N câu = 3 từ bộ này. Trước tiên, chúng tôi áp dụng một bộ lọc thô cho bộ bằng chứng, xếp hạng các câu bằng chứng theo điểm BM25 được tính dựa trên tuyên bố, và loại bỏ những câu nằm ngoài top 100. Sau đó, chúng tôi tạo r a một câu hỏi cho mỗi câu mà câu đó có thể trả lời được, một lần nữa sử dụng BLOOM. Chúng tôi đã thử {1,3,5,10} ví dụ trong bối cảnh, và nhận thấy 10 ví dụ có hiệu quả tốt nhất. Toàn bộ lời nhắc có thể thấy trong Phụ lục D.2. Sau đó, chúng tôi sắp xếp lại các cặp câu hỏi-trả lời này để tìm những cái phù hợp nhất với tuyên bố, sử dụng mô hình BERT-large được tinh chỉnh [Devlin et al., 2019] (chi tiết hơn, xem Phụ lục E.1). Chiến lược hơi phản trực giác này, đầu tiên là truy xuất rồi sau đó tạo câu hỏi, có thể được xem như việc sử dụng các câu hỏi được tạo ra để làm cầu nối giữa các tuyên bố và các câu bằng chứng có liên quan xa. Phương pháp của chúng tôi tương tự với chiến lược mở rộng tài liệu được đề xuất cho trả lời câu hỏi trong Nogueira et al. [2019], .

Dự đoán tính chân thực Khi các cặp câu hỏi-trả lời đã được tạo ra, chúng tôi đưa ra phán quyết thông qua một chiến lược phát hiện lập trường dựa trên các nghiên cứu trước đây về lọc bằng chứng [Hanselowski et al., 2019]. Chúng tôi sử dụng mô hình BERT-large được tinh chỉnh để gán nhãn từng cặp câu hỏi-trả lời là ủng hộ, bác bỏ, hoặc không liên quan đến câu hỏi (xem thêm chi tiết trong Phụ lục E.2). Sau đó, chúng tôi gán nhãn tuyên bố một cách quyết định như sau: 1) nếu tuyên bố có cả bằng chứng ủng hộ và bác bỏ, gán nhãn là bằng chứng mâu thuẫn/chọn lọc. 2) Nếu tuyên bố chỉ có các cặp câu hỏi-trả lời ủng hộ, gán nhãn là được ủng hộ; tương tự cho bác bỏ. 3) Ngược lại, gán nhãn tuyên bố là không đủ bằng chứng. Chúng tôi đã thử nghiệm ba mô hình khác nhau cho dự đoán tính chân thực: BERT-large, bloom-7b1 và Vicuna-13b. Chúng tôi nhận thấy BERT cho hiệu suất tốt hơn một chút; khi sử dụng bằng chứng vàng, chúng tôi thu được điểm macro-F1 lần lượt là 0,49, 0,43 và 0,48 cho ba mô hình.

Sinh Lời Biện Minh Bước cuối cùng là tạo ra một lời biện minh bằng văn bản cho phán quyết. Ở đây, chúng tôi dựa vào BART-large [Lewis et al., 2020] tinh chỉnh trên tập huấn luyện của chúng tôi (để biết thêm chi tiết, xem Phụ lục E.3). Chúng tôi sử dụng sự kết hợp của tuyên bố và bằng chứng thu thập được làm đầu vào; c húng tôi đã thử thêm độ xác thực dự đoán, nhưng không thấy cải thiện hiệu suất. Chúng tôi đã thử nghiệm ba mô hình: BART-large, bloom-7b1 và Vicuna-13b, lần lượt đạt điểm METEOR là 0,28, 0,23 và 0,25. Dựa trên phâ n tích định tính của chúng tôi về 20 tuyên bố, các lời biện minh do Vicuna tạo ra rất tốt, nhưng mô hình bị phạt vì quá dài dòng – Vicuna tạo ra trung bình 36 token, so với 21 token trong dữ liệu chuẩn.

### 7.2 Kết quả

Chúng tôi đánh giá như đã thảo luận trong Mục 6. Chúng tôi bao gồm kết quả trong Bảng 3 ở ba ngưỡng để so sánh, mặc dù chúng tôi khuyến khích $\lambda = 0.25$. Chúng tôi so sánh cơ sở của mình với hai mô hình khác: một mô hình không có quyền truy cập vào tìm kiếm, và một mô hình sử dụng các cặp câu hỏi-trả lời chuẩn làm bằng chứng.

Đối với mô hình không tìm kiếm, chúng tôi sử dụng phương pháp nhắc lệnh để tạo câu hỏi, theo cách được mô tả trong Phụ lục D.1. Chúng tôi để tất cả các câu trả lời là "Không tìm thấy câu trả lời". Việc tạo câu trả lời không phải là một lựa chọn, vì câu trả lời phải được hỗ trợ bởi các nguồn. Chúng tôi sử dụng BERT-large được tinh chỉnh trên dữ liệu huấn luyện để dự đoán nhãn độ xác thực (không cần bằng chứng nào), và cùng chiến lược nhắc lệnh như được thảo luận trong Mục 7.1 để tạo các lý do giải thích. Đối với mô hình bằng chứng vàng, chúng tôi sử dụng các cặp câu hỏi-trả lời vàng do các nhà chú thích cung cấp thay cho các câu hỏi được tạo và bằng chứng được truy xuất. Tức là, chúng tôi chỉ kiểm tra các thành phần dự đoán độ xác thực và tạo lý do giải thích.

Phân tích kết quả truy xuất trên tập phát triển, chúng tôi vẫn thấy $\lambda = 0.25$ là một điểm cắt tốt cho các chỉ số tính xác thực và biện minh của AVERITEC. Đối với các cặp câu hỏi-trả lời ở ranh giới, ngưỡng này đủ cao để t ất cả thông tin quan trọng phải được đưa ra để đạt được nó, nhưng vẫn còn một số khoảng trống cho việc diễn đạt lại và bằng chứng một phần.

Đường cơ sở của chúng tôi có hiệu suất khá tại $\lambda = 0.2$ và $\lambda = 0.25$, nhưng không hoạt động tốt ở các điểm cắt bằng chứng cao hơn. Vì cấu trúc của quy trình làm việc của chúng tôi – tạo từ khóa tìm kiếm, truy xuất và xếp hạng lại bằng chứng, tạo câu hỏi để phù hợp với bằng chứng đã được xếp hạng lại – đường cơ sở của chúng tôi gặp khó khăn trong việc phù hợp với các tập hợp bằng chứng cụ thể. Nếu đoạn văn bằng chứng được truy xuất rất ngắn, ví dụ, một ô bảng chứa nội dung

| Model | S | R | C | N | Macro |
|---|---|---|---|---|---|
| No evidence | .30 | .22 | .00 | .16 | .17 |
| Gold evidence | .48 | .74 | .15 | .59 | .49 |
| AVERITEC | .41 | .69 | .10 | .16 | .23 |
| gpt-3.5-turbo | .62 | .71 | .02 | .20 | .39 |

Table 4: *F1*-scores for veracity prediction split across labels: supported (S), refuted (R), conflicting evidence/cherrypicking (C), and not enough evidence (N). We also show the macro-average. Again, we report results for three versions of the baseline (see Section 7.2): a version that uses no evidence (no search), a version that uses gold evidence (gold evidence), and the full pipeline ( AVERITEC ). We also report results for gpt-3.5-turbo (ChatGPT).

"January 24th", the question generation model often lacks context to generate the right question. Further, the baseline cannot generate questions with highly abstractive answers, only questions that can be answered directly by sentences in the supporting sources.

We recognize that the retrieval scores of this baseline are quite close to those of the human annotators seen in Section 6. Nevertheless, for evidence retrieved by our baseline, low scores are much more frequently a result of reliance on *wrong* evidence, rather than *equivalent* evidence phrased differently and scored incorrectly. Further research is needed to develop an evaluation capable of recognizing this difference, e.g., a trained metric in the style of BLEURT [Sellam et al., 2020].

The gap between gold evidence and retrieved evidence highlights how retrieval remains challenging, also discussed in Arnold [2020]. Manually analysing 20 examples from the development set, we find that Google search results based on the claim and the generated questions contain useful evidence only in 9/20 cases. If the retrieval system had access to the gold questions for use as search queries, correct evidence would be found in 16/20 of these cases; this highlights the need for further development of retrieval and search systems, and especially query/question generation.

We also report individual *F1* scores for each veracity class (as well as a macro average) in Table 4. Our veracity prediction model fails to accurately predict *Conflicting Evidence/Cherrypicking* most of the time, even with gold evidence. Going through the predictions, we see that precision is very low (10% using gold evidence). Labelling claims as *Conflicting Evidence/Cherrypicking* if any evidence is classified as having different stance leads to many false positives – often, questions that simply add context to supported claims are (incorrectly) labelled as *refuting* by the stance detection model.

As a way to improve the stance detection component, we tried to generate additional training data using gpt-3.5-turbo (ChatGPT). We paraphrased each claim in the dataset, using the same evidence. We generated one paraphrase per claim. Then, we trained BERT-large on the concatenated original and paraphrased claims. Unfortunately, this failed to yield additional performance, producing a macro-*F1* score of .46 on gold data; slightly lower than the .49 obtained using only the original claims. The primary cause is a drop in performance for *refuted* and *not enough evidence*, which the model trained on paraphrased data conflates more often.

We further include results in Tables 3 and 4 using ChatGPT. As ChatGPT cannot produce sources to back up its answers, this is not directly comparable to our baseline. Nevertheless, it is an interesting point of comparison. We generate evidence and verdicts with ChatGPT, using the prompt described in Appendix G. We find that ChatGPT outperforms our baseline in terms of pure question generation, but nevertheless received a lower AVERITEC score (veracity prediction at $\lambda = 0.25$). This is a consequence of the missing retriever: generated answers often do not match gold answers (i.e., they are either alternative correct answers, or outright hallucinations).

ChatGPT performs well on veracity, especially for supported claims; but those verdicts are often not supported by valid evidence. For example, for the claim *"1 cup of dandelion greens = 535% of your daily recommended vitamin K and 112% of vitamin A."*, ChatGPT assigned the verdict *supported* and generated the evidence string *"According to the USDA, 1 cup of chopped dandelion greens provides 535% of your daily recommended vitamin K and 338% of vitamin A, which is higher than the claim"*. While the verdict is true, there is no such statement from the USDA, and the actual gold evidence relies on several question-answer pairs and a calculation to arrive at the verdict.



| Mô hình | S | R | C | N | Vĩ mô |
|---|---|---|---|---|---|
| Không có bằng chứng | .30 | .22 | .00 | .16 | .17 |
| Bằng chứng vàng | .48 | .74 | .15 | .59 | .49 |
| AVERITEC | .41 | .69 | .10 | .16 | .23 |
| gpt-3.5-turbo | .62 | .71 | .02 | .20 | .39 |

Bảng 4: Điểm F1 cho dự đoán tính xác thực được chia theo nhãn: được chứng thực (S), bị phủ nhận (R), bằng chứng mâu thuẫn/chọn lọc (C), và không đủ bằng chứng (N). Chúng tôi cũng hiển thị trung bình macro. Một l ần nữa, chúng tôi báo cáo kết quả cho ba phiên bản của mô hình cơ sở (xem Mục 7.2): một phiên bản không s ử dụng bằng chứng (không tìm kiếm), một phiên bản sử dụng bằng chứng vàng (bằng chứng vàng), và toàn bộ quy trình (AVERITEC). Chúng tôi cũng báo cáo kết quả cho gpt-3.5-turbo (ChatGPT).

"Ngày 24 tháng 1", mô hình tạo câu hỏi thường thiếu ngữ cảnh để tạo ra câu hỏi đúng. Hơn nữa, mô hình cơ sở không thể tạo ra các câu hỏi với câu trả lời mang tính trừu tượng cao, chỉ các câu hỏi có thể được trả lời trực tiếp bằng các câu trong các nguồn hỗ trợ.

Chúng tôi nhận thấy rằng các điểm truy xuất của phương pháp cơ bản này khá gần với các điểm của người chú giải như thấy trong Mục 6. Tuy nhiên, đối với bằng chứng được truy xuất bởi phương pháp cơ bản của chúng tôi, điểm thấp thường là kết quả của việc dựa vào bằng chứng sai, chứ không phải bằng chứng tương đương được diễn đạt khác đi và bị chấm điểm sai. Cần nghiên cứu thêm để phát triển một phương pháp đánh giá có khả năng nhận ra sự khác biệt này, ví dụ, một chỉ số được huấn luyện theo phong cách của BLEURT [ Sellam và cộng sự, 2020].

Khoảng cách giữa chứng cứ vàng và chứng cứ thu được làm nổi bật việc truy xuất vẫn còn nhiều thách thức, điều này cũng được thảo luận trong Arnold [2020]. Khi phân tích thủ công 20 ví dụ từ tập phát triển, chúng tôi nhận thấy kết quả tìm kiếm của Google dựa trên tuyên bố và các câu hỏi được tạo ra chỉ chứa chứng cứ hữu ích trong 9/20 trường hợp. Nếu hệ thống truy xuất có quyền truy cập vào các câu hỏi vàng để sử dụng làm tr uy vấn tìm kiếm, chứng cứ chính xác sẽ được tìm thấy trong 16/20 trường hợp này; điều này làm nổi bật nhu cầu phát triển thêm các hệ thống truy xuất và tìm kiếm, đặc biệt là tạo truy vấn/câu hỏi.

Chúng tôi cũng báo cáo các điểm F1 riêng lẻ cho từng lớp tính xác thực (cũng như điểm trung bình tổng quát) trong Bảng 4. Mô hình dự đoán tính xác thực của chúng tôi thường không dự đoán chính xác Evidence Mâu Thuẫn/Cherry-picking, ngay cả khi có bằng chứng vàng. Khi xem xét các dự đoán, chúng tôi thấy rằng độ c hính xác rất thấp (10% khi sử dụng bằng chứng vàng). Việc gán nhãn các tuyên bố là Evidence Mâu Thuẫn/Cherry-picking nếu bất kỳ bằng chứng nào được phân loại có quan điểm khác dẫn đến nhiều kết quả dương tính giả – thường thì, các câu hỏi chỉ thêm ngữ cảnh vào các tuyên bố được hỗ trợ lại bị mô hình phát hiện quan điểm gán nhãn sai là bác bỏ.

Như một cách để cải thiện thành phần phát hiện quan điểm, chúng tôi đã thử tạo thêm dữ liệu huấn luyện bằng cách sử dụng gpt-3.5-turbo (ChatGPT). Chúng tôi đã diễn giải lại từng tuyên bố trong tập dữ liệu, sử dụng cùng một bằng chứng. Chúng tôi tạo ra một câu diễn giải cho mỗi tuyên bố. Sau đó, chúng tôi huấn luyện BERT-large trên tập hợp các tuyên bố gốc và đã được diễn giải. Thật không may, điều này không giúp nâng cao hiệu suất, cho điểm macro-F1 là 0,46 trên dữ liệu chuẩn; thấp hơn một chút so với 0,49 thu được chỉ với các tuyên bố gốc. Nguyên nhân chính là sự giảm hiệu suất đối với các trường hợp bị bác bỏ và không có đủ bằng chứng, mà mô hình được huấn luyện trên dữ liệu diễn giải lại thường bị nhầm lẫn hơn.

Chúng tôi cũng đưa ra các kết quả trong Bảng 3 và 4 sử dụng ChatGPT. Vì ChatGPT không thể cung cấp các nguồn để chứng minh câu trả lời của nó, nên điều này không thể so sánh trực tiếp với cơ sở của chúng tôi. Tuy nhiên, đây là một điểm so sánh thú vị. Chúng tôi tạo ra bằng chứng và kết luận với ChatGPT, sử dụng câu lệnh mô tả trong Phụ lục G. Chúng tôi nhận thấy rằng ChatGPT vượt trội hơn cơ sở của chúng tôi về mặt tạo câu hỏi thuần túy, nhưng vẫn nhận được điểm AVERITEC thấp hơn (dự đoán độ xác thực tại $\lambda = 0.25$). Điều này là do thiếu bộ truy xuất: các câu trả lời được tạo ra thường không khớp với câu trả lời chuẩn (tức là chúng hoặc là các câu trả lời đúng thay thế, hoặc hoàn toàn tưởng tượng).

ChatGPT hoạt động tốt về độ xác thực, đặc biệt đối với những khẳng định được hỗ trợ; nhưng những phán quyết đó thường không có bằng chứng hợp lệ. Ví dụ, đối với khẳng định "1 cốc rau bồ công anh cung cấp = 535 % lượng vitamin K khuyến nghị hàng ngày và 112% vitamin A," ChatGPT đã gán phán quyết là được hỗ trợ và tạo ra chuỗi bằng chứng "Theo USDA, 1 cốc rau bồ công anh cắt nhỏ cung cấp 535% lượng vitamin K khuyến nghị hàng ngày và 338% vitamin A, cao hơn so với khẳng định." Mặc dù phán quyết này là đúng, nhưng không có tuyên bố nào như vậy từ USDA, và bằng chứng thực tế dựa trên một số cặp câu hỏi-trả lời và một phép tính để đưa ra phán quyết.

## 8 Limitations

The evaluation metric we have presented alongside AVERITEC contains a significant limitation: no efforts are made to ensure answers and source documents are consistent. As only 53% of gold answers are fully extractive, it is expected that abstractive models will be employed. Such models though can hallucinate, and can thus make up answers that are not supported by the underlying sources, which our evaluation metric cannot detect. Further research is needed on evaluation to counteract this, along with research on developing an evaluation strategy that better allows verifying claims correctly with different questioning strategies and evidence documents.

While claims geographically concern regions from all around the world, all fact-checking sources and consequently all claims used in our dataset are in English. Further, as we take claims directly from fact-checking articles, our dataset is subject to any biases present within those articles; notably, for internal fact-checking, Barnoy and Reich [2019] documented a selection bias resulting from journalists rating claims by male sources more credible than female sources.

Finally, we note that our reliance on Google Search to avoid temporal leakage is a noisy process. The dates we rely on are the best estimate computed by Google[6]. As such, while in general evidence documents were available when associated claims were published, there may be exceptions.

## 9 Ethics Statement

Fact-checking is often envisioned as an epistemic tool, limiting the spread and influence of misinformation. The datasets and models described in this paper are not intended for truth-telling, e.g. for the design of automated content moderation systems. The labels and justifications included with this dataset relate only to the evidence recovered by annotators, and as such are subject to the biases of annotators and journalists; furthermore, the machine learning models and search engine used for the baseline contain well-known biases [Noble, 2018, Bender et al., 2021]. Acting on veracity estimates arrived at through biased means, including automatically produced ranking decisions for evidence retrieval, risks causing epistemic harm [Schlichtkrull et al., 2023].

Annotators for our dataset had access to searching the entire web when finding evidence documents. We curated a list of common misinformative sources by combining several public documents[7], and flagged search results from these sources. Nevertheless, we did not prevent annotators from using them as evidence. Pointing out that a claim originates from an untrustworthy site is an important fact-checking strategy, and, indeed, our list may well contain false positives. A total of 85 answers in AVERITEC rely on a flagged source; moreover, our list is not complete. Our dataset may as such include misleading examples, and can potentially cause harm if relied on as an authoritative source.

We did not take any steps to anonymise the data. The claims discussed in our dataset are based on publicly available data from journalistic publications, and concern public figures and events – references to these are important to fact-check claims. We did not contact these public figures, or the journalists who published the original fact-checking articles. If any person included in our dataset as a speaker of a claim, as the subject of a claim, or as the author of a fact-checking article a claim is based on requests it, we will remove that claim from the dataset.

## 10 Conclusion

We have introduced AVERITEC, a new real-world fact-checking dataset consisting of 4,568 claims, each annotated with question-answer pairs decomposing the fact-checking process, as well as justifications. Our multi-step annotation process guarantees high-quality annotations, providing evidence sufficiency and avoiding temporal leakage; it also results in a substantial inter-annotator agreement of $\kappa = 0.619$. We have also introduced and analysed a baseline as well as an evaluation scheme, establishing AVERITEC as a new benchmark.

[6]See `https://developers.google.com/search/blog/2019/03/help-google-search-know-best-date-for`

[7]We combined the following: `https://libguides.castleton.edu/evaluating_news/fake_news`, `https://www.factcheck.org/2017/07/websites-post-fake-satirical-stories/`, and `https://en.wikipedia.org/wiki/List_of_fake_news_websites`



## 8 Hạn chế

Chỉ số đánh giá mà chúng tôi đã trình bày cùng với AVERITEC có một hạn chế đáng kể: không có nỗ lực nào được thực hiện để đảm bảo câu trả lời và tài liệu nguồn nhất quán. Vì chỉ có 53% câu trả lời chuẩn hoàn toàn có thể trích xuất, nên dự kiến các mô hình trừu tượng sẽ được sử dụng. Tuy nhiên, các mô hình như vậy có t hể tưởng tượng ra thông tin, và do đó có thể đưa ra các câu trả lời không được hỗ trợ bởi các nguồn cơ sở, điều mà chỉ số đánh giá của chúng tôi không thể phát hiện. Cần có thêm nghiên cứu về đánh giá để chống lại vấn đề này, cùng với việc nghiên cứu phát triển một chiến lược đánh giá cho phép xác minh các tuyên bố một các h chính xác hơn với các chiến lược đặt câu hỏi và các tài liệu bằng chứng khác nhau.

Mặc dù các tuyên bố về mặt địa lý liên quan đến các khu vực trên toàn thế giới, tất cả các nguồn kiểm chứng thông tin và do đó tất cả các tuyên bố được sử dụng trong bộ dữ liệu của chúng tôi đều bằng tiếng Anh. Hơn nữa, vì chúng tôi l ấy các tuyên bố trực tiếp từ các bài báo kiểm chứng thông tin, bộ dữ liệu của chúng tôi chịu ảnh hưởng từ bất kỳ thiên kiến nào có trong các bài báo đó; đáng chú ý, đối với việc kiểm chứng thông tin nội bộ, Barnoy và Reich [2019] đã ghi nhận một một thiên kiến lựa chọn do các nhà báo đánh giá các tuyên bố từ các nguồn nam đáng tin cậy hơn các nguồn nữ.

Cuối cùng, chúng tôi lưu ý rằng việc chúng tôi phụ thuộc vào Google Search để tránh rò rỉ theo thời gian là một quá trình nhiều nhiễu. Các ngày mà chúng tôi dựa vào là ước tính tốt nhất do Google [6] tính toán. Vì vậy, mặc dù nhìn chung các tài liệu bằng chứng có sẵn khi các tuyên bố liên quan được công bố, nhưng vẫn có thể có ngoại lệ.

## 9 Tuyên bố Đạo đức

Kiểm chứng sự thật thường được hình dung như một công cụ nhận thức, hạn chế sự lan truyền và ảnh hưởng của thông tin sai lệch. Các tập dữ liệu và mô hình được mô tả trong bài báo này không nhằm mục đích nói sự thật, ví dụ như để thiết kế các hệ thống kiểm duyệt nội dung tự động. Các nhãn và lý do đi kèm với tập dữ liệu này chỉ liên quan đến bằng chứng được các người chú thích thu thập, và do đó chịu ảnh hưởng của sự thiên lệch từ các người chú thích và nhà báo; hơn nữa, các mô hình học máy và công cụ tìm kiếm được sử dụng làm cơ sở chứa những thiên lệch đã được biết [Noble, 2018, Bender et al., 2021]. Việc hành động dựa trên các ước lượng tính xác thực được đưa ra thông qua các phương tiện có thiên lệch, bao gồm cả các quyết định xếp hạng tự động cho việc truy hồi bằng chứng, có nguy cơ gây hại về nhận thức [Schlichtkrull et al., 2023].

Những người chú thích cho tập dữ liệu của chúng tôi có quyền truy cập để tìm kiếm toàn bộ web khi tìm các tài liệu chứng cứ. Chúng tôi đã tuyển chọn một danh sách các nguồn thông tin sai lệch phổ biến bằng cách kết hợp một số tài liệu công khai và các kết quả tìm kiếm bị đánh dấu từ các nguồn này. Tuy nhiên, chúng tôi không ngăn cản những người chú thích sử dụng chúng làm bằng chứng. Việc chỉ ra rằng một tuyên bố xuất phát từ một trang web không đáng tin cậy là một chiến lược kiểm chứng quan trọng, và thực sự, danh sách của chúng tôi có thể chứa các kết quả dương tính giả. Tổng cộng có 85 câu trả lời trong AVERITEC dựa vào một nguồn bị đánh dấu; hơn nữa, danh sách của chúng tôi không đầy đủ. Do đó, tập dữ liệu của chúng tôi có thể bao gồm các ví dụ gây hiểu lầm, và có khả năng gây hại nếu được sử dụng làm nguồn đáng tin cậy.

Chúng tôi không thực hiện bất kỳ biện pháp nào để ẩn danh dữ liệu. Các tuyên bố được thảo luận trong bộ dữ liệu của chúng tôi dựa trên dữ liệu công khai từ các ấn phẩm báo chí, và liên quan đến các nhân vật công chúng và các sự kiện – việc tham chiếu đến những điều này là quan trọng để kiểm tra tính xác thực của các tuyên bố. Chúng tôi không liên hệ với các nhân vật công chúng này, hoặc các nhà báo đã xuất bản các bài báo kiểm chứng sự thật gốc. Nếu bất kỳ người nào được đưa vào bộ dữ liệu của chúng tôi như là người phát biểu một tuyên bố, là đối tượng của một tuyên bố, hoặc là tác giả của một bài kiểm chứng sự thật mà một tuyên bố dựa trên yêu cầu, chúng tôi sẽ xóa tuyên bố đó khỏi bộ dữ liệu.

## 10 Kết luận

Chúng tôi đã giới thiệu AVERITEC, một bộ dữ liệu kiểm tra sự thật thực tế mới gồm 4.568 tuyên bố, mỗi tuyên bố được chú thích với các cặp câu hỏi-trả lời phân tách quá trình kiểm tra sự thật, cũng như các lý do giải thích. Quy trình chú thích nhiều bước của chúng tôi đảm bảo các chú thích có chất lượng cao, cung cấp đầy đủ bằng chứng và tránh rò rỉ theo thời gian; đồng thời nó cũng dẫn đến sự đồng thuận đáng kể giữa các người chú thích đạt mức $\kappa = 0.619$. Chúng tôi cũng đã giới thiệu và phân tích một điểm chuẩn cơ sở cũng như một phương pháp đánh giá, thiết lập AVERITEC như một chuẩn mực mới.

[6]Xem https://developers.google.com/search/blog/2019/03/help-google-search-know-best-date-for[7]Chúng tôi đã kết hợp những điều sau: https://libguides.castleton.edu/evaluating_news/fake_news, https://www.factcheck.org/2017/07/websites-post-fake-satirical-stories/, và https://en.wikipedia.org/wiki/List_of_fake_news_websites

## Acknowledgements

We would like to thank Zhangdie Yuan, Pietro Lesci, Nedjma Ousidhoum, Ieva Staliunaite, and David Corney for their helpful comments, discussions, and feedback. This research was supported by the ERC grant AVeriTeC (GA 865958). Andreas Vlachos is further supported by the EU H2020 grant MONITIO (GA 965576).

## References

Tariq Alhindi, Savvas Petridis, and Smaranda Muresan. Where is your evidence: Improving fact-checking by justification modeling. In *Proceedings of the First Workshop on Fact Extraction and VERification (FEVER)*, pages 85–90, Brussels, Belgium, November 2018. Association for Computational Linguistics. doi: 10.18653/v1/W18-5513. URL https://aclanthology.org/W18-5513.

Rami Aly, Zhijiang Guo, Michael Sejr Schlichtkrull, James Thorne, Andreas Vlachos, Christos Christodoulopoulos, Oana Cocarascu, and Arpit Mittal. The fact extraction and VERification over unstructured and structured information (FEVEROUS) shared task. In *Proceedings of the Fourth Workshop on Fact Extraction and VERification (FEVER)*, pages 1–13, Dominican Republic, November 2021. Association for Computational Linguistics. doi: 10.18653/v1/2021.fever-1.1. URL https://aclanthology.org/2021.fever-1.1.

Michelle A. Amazeen. Revisiting the Epistemology of Fact-Checking. *Critical Review*, 27(1):1–22, January 2015. ISSN 0891-3811, 1933-8007. doi: 10.1080/08913811.2014.993890. URL http://www.tandfonline.com/doi/abs/10.1080/08913811.2014.993890.

Phoebe Arnold. The challenges of online fact checking. https://fullfact.org/media/uploads/coof-2020.pdf, 2020. Accessed: 2023-01-17.

Isabelle Augenstein, Christina Lioma, Dongsheng Wang, Lucas Chaves Lima, Casper Hansen, Christian Hansen, and Jakob Grue Simonsen. MultiFC: A real-world multi-domain dataset for evidence-based fact checking of claims. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 4685–4697, Hong Kong, China, November 2019. Association for Computational Linguistics. doi: 10.18653/v1/D19-1475. URL https://aclanthology.org/D19-1475.

Satanjeev Banerjee and Alon Lavie. METEOR: An automatic metric for MT evaluation with improved correlation with human judgments. In *Proceedings of the ACL Workshop on Intrinsic and Extrinsic Evaluation Measures for Machine Translation and/or Summarization*, pages 65–72, Ann Arbor, Michigan, June 2005. Association for Computational Linguistics. URL https://aclanthology.org/W05-0909.

Aviv Barnoy and Zvi Reich. The When, Why, How and So-What of Verifications. *Journalism Studies*, 20(16): 2312–2330, December 2019. ISSN 1461-670X, 1469-9699. doi: 10.1080/1461670X.2019.1593881. URL https://www.tandfonline.com/doi/full/10.1080/1461670X.2019.1593881.

Emily M. Bender and Batya Friedman. Data statements for natural language processing: Toward mitigating system bias and enabling better science. *Transactions of the Association for Computational Linguistics*, 6: 587–604, 2018. doi: 10.1162/tacl_a_00041. URL https://aclanthology.org/Q18-1041.

Emily M Bender, Timnit Gebru, Angelina McMillan-Major, and Shmargaret Shmitchell. On the dangers of stochastic parrots: Can language models be too big? . In *Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency*, pages 610–623, 2021.

Steven Bird, Ewan Klein, and Edward Loper. *Natural language processing with Python: analyzing text with the natural language toolkit*. " O'Reilly Media, Inc.", 2009.

Brooke Borel. *The Chicago Guide to Fact-checking*. University of Chicago Press, 2016.

Jifan Chen, Aniruddh Sriram, Eunsol Choi, and Greg Durrett. Generating literal and implied subquestions to fact-check complex claims. In *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*, pages 3495–3516, Abu Dhabi, United Arab Emirates, December 2022. Association for Computational Linguistics. URL https://aclanthology.org/2022.emnlp-main.229.

Wei-Lin Chiang, Zhuohan Li, Zi Lin, Ying Sheng, Zhanghao Wu, Hao Zhang, Lianmin Zheng, Siyuan Zhuang, Yonghao Zhuang, Joseph E. Gonzalez, Ion Stoica, and Eric P. Xing. Vicuna: An open-source chatbot impressing gpt-4 with 90%* chatgpt quality, March 2023. URL https://lmsys.org/blog/2023-03-30-vicuna/.



## Lời cảm ơn

Chúng tôi xin cảm ơn Zhangdie Yuan, Pietro Lesci, Nedjma Ousidhoum, Ieva Staliunaite và David Corney vì những nhận xét, thảo luận và góp ý hữu ích của họ. Nghiên cứu này được hỗ trợ bởi khoản tài trợ ERC AVeriTeC (GA 865958). Andreas Vlachos còn được hỗ trợ bởi khoản tài trợ EU H2020 MONITIO (GA 965576).

**Tài liệu tham khảo**

Tariq Alhindi, Savvas Petridis, và Smaranda Muresan. Bằng chứng của bạn ở đâu: Cải thiện việc kiểm tra sự thật bằng mô hình hóa biện minh. Trong Kỷ yếu Hội thảo Thứ nhất về Trích xuất Thực tế và XÁC minh (FEVER), trang 85–90, Brussels, Bỉ, tháng 11 năm 2018. Hiệp hội Ngôn ngữ Học Máy Tính. doi: 10.18653/v1/W18-5513. URL https://aclanthology.org/W18-5513.

Rami Aly, Zhijiang Guo, Michael Sejr Schlichtkrull, James Thorne, Andreas Vlachos, Christos Christodoulopoulos, Oana Cocarascu, và Arpit Mittal. Nhiệm vụ chia sẻ Trích xuất và Xác minh Sự kiện trên thông tin phi cấu trúc và cấu trúc (FEVEROUS). Trong Kỷ yếu Hội thảo lần thứ tư về Trích xuất và Xác minh Sự kiện (FEVER), trang 1–13, Cộng hòa Dominicana, tháng 11 năm 2021. Hiệp hội Ngôn ngữ Học Máy Tính. doi: 10.18653/v1/2021.fever-1.1. URL https://aclanthology.org/2021.fever-1.1.

Michelle A. Amazeen. Xem xét lại Nhận thức luận về Kiểm chứng sự kiện. Critical Review, 27(1):1–22, tháng 1 năm 2015. ISSN 0891-3811, 1933-8007. doi: 10.1080/08913811.2014.993890. URL http://www.tandfonline.com/doi/abs/10.1080/08913811.2014.993890.

Phoebe Arnold. Những thách thức của việc kiểm tra sự thật trực tuyến. https://fullfact.org/media/uploads/coof-2 020 2020 2023 01 17 .pdf, . Truy cập: - - .

Isabelle Augenstein, Christina Lioma, Dongsheng Wang, Lucas Chaves Lima, Casper Hansen, Christian Hansen, và Jakob Grue Simonsen. MultiFC: Một tập dữ liệu đa miền thực tế để kiểm chứng thông tin dựa trên bằng chứng. Trong Kỷ yếu Hội nghị Phương pháp Thực nghiệm về Xử lý Ngôn ngữ Tự nhiên 2019 và Hội nghị Liên hợp Quốc tế lần thứ 9 về Xử lý Ngôn ngữ Tự nhiên (EMNLP-IJCNLP), trang 4685–4697, Hồng Kông, Trung Quốc, tháng 11 năm 2019. Hiệp hội Ngôn ngữ học Máy tính. doi: 10.18653/v1/D19-1475. URL https://aclanthology.org/D19-1475.

Satanjeev Banerjee và Alon Lavie. METEOR: Một thước đo tự động cho đánh giá dịch máy với sự tương quan cải thiện với đánh giá của con người. Trong Kỷ yếu Hội thảo ACL về Các Biện pháp Đánh giá Nội tại và Ngoại tại cho Dịch máy và/hoặc Tóm tắt, trang 65–72, Ann Arbor, Michigan, tháng 6 năm 2005. Hiệp hội Ngôn ngữ học Máy tính. URL https://aclanthology.org/W05-0909.

Aviv Barnoy và Zvi Reich. Khi nào, Tại sao, Như thế nào và Vậy thì sao của việc Xác minh. Nghiên cứu Báo chí, 20(16): 2312–2330, tháng 12 năm 2019. ISSN 1461-670X, 1469-9699. doi: 10.1080/1461670X.2019.1593881. URL https://www.tandfonline.com/doi/full/10.1080/1461670X.2019.1593881.

Emily M. Bender và Batya Friedman. Tuyên bố dữ liệu cho xử lý ngôn ngữ tự nhiên: Hướng tới giảm thiểu thành kiến hệ thống và thúc đẩy khoa học tốt hơn. Transactions of the Association for Computational Linguistics, 6: 587–604, 2018. doi: 10.1162/tacl_a_00041. URL https://aclanthology.org/Q18-1041.

Emily M Bender, Timnit Gebru, Angelina McMillan-Major, và Shmargaret Shmitchell. Về những nguy hiểm của các con vẹt ngẫu nhiên: Liệu các mô hình ngôn ngữ có thể quá lớn không? Trong Kỷ yếu Hội nghị ACM 2021 về Công bằng, Trách nhiệm và Minh bạch, trang 610–623, 2021.

*Steven Bird, Ewan Klein, và Edward Loper. Xử lý ngôn ngữ tự nhiên với Python: phân tích văn bản bằng bộ công cụ ngôn ngữ tự nhiên. "O'Reilly Media, Inc.", 2009.*

Brooke Borel. The C *Hướng dẫn kiểm chứng sự thật của Chicago. Đại học Chicago* o Press, 2016.

Jifan Chen, Aniruddh Sriram, Eunsol Choi, và Greg Durrett. Tạo các câu hỏi phụ theo nghĩa đen và ngụ ý để kiểm chứng sự thật các tuyên bố phức tạp. Trong Kỷ yếu Hội nghị Phương pháp Thực nghiệm năm 2022 về Xử lý Ngôn ngữ Tự nhiên, các trang 3495–3516, Abu Dhabi, Các Tiểu vương quốc Ả Rập Thống nhất, tháng 12 năm 2022. Hiệp hội Ngôn ngữ Học Tính t oán. URLhttps://aclanthology.org/2022.emnlp-main.229.

Wei-Lin Chiang, Zhuohan Li, Zi Lin, Ying Sheng, Zhanghao Wu, Hao Zhang, Lianmin Zheng, Siyuan Zhuang, Yonghao Zhuang, Joseph E. Gonzalez, Ion Stoica, và Eric P. Xing. Vicuna: Một chatbot mã nguồn mở gây ấn tượng với gpt-4 3 0 90 2023 2023 03 với chất lượng chatgpt %, tháng 3. URL https://lmsys.org/blog/---vicuna/.

Sarah Cohen, Chengkai Li, Jun Yang, and Cong Yu. Computational journalism: A call to arms to database researchers. In *5th Biennial Conference on Innovative Data Systems Research (CIDR)*, 2011.

Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*, pages 4171–4186, Minneapolis, Minnesota, June 2019. Association for Computational Linguistics. doi: 10.18653/v1/N19-1423. URL https://aclanthology.org/N19-1423.

Thomas Diggelmann, Jordan Boyd-Graber, Jannis Bulian, Massimiliano Ciaramita, and Markus Leippold. Climate-fever: A dataset for verification of real-world climate claims, 2020.

Andy Dudfield. How we're using AI to scale up global fact checking. https://fullfact.org/blog/2020/jul/afc-global/, 2020. Accessed: 2023-01-17.

Angela Fan, Aleksandra Piktus, Fabio Petroni, Guillaume Wenzek, Marzieh Saeidi, Andreas Vlachos, Antoine Bordes, and Sebastian Riedel. Generating fact checking briefs. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 7147–7161, Online, November 2020. Association for Computational Linguistics. doi: 10.18653/v1/2020.emnlp-main.580. URL https://aclanthology.org/2020.emnlp-main.580.

Joseph L Fleiss. Measuring nominal scale agreement among many raters. *Psychological bulletin*, 76(5):378, 1971.

Marina Fomicheva and Lucia Specia. Taking MT Evaluation Metrics to Extremes: Beyond Correlation with Human Judgments. *Computational Linguistics*, 45(3):515–558, 09 2019. ISSN 0891-2017. doi: 10.1162/coli_a_00356. URL https://doi.org/10.1162/coli_a_00356.

Max Glockner, Yufang Hou, and Iryna Gurevych. Missing counter-evidence renders nlp fact-checking unrealistic for misinformation, 2022. URL https://arxiv.org/abs/2210.13865.

Ashim Gupta and Vivek Srikumar. X-fact: A new benchmark dataset for multilingual fact checking. In *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 2: Short Papers)*, pages 675–682, Online, August 2021. Association for Computational Linguistics. doi: 10.18653/v1/2021.acl-short.86. URL https://aclanthology.org/2021.acl-short.86.

Andreas Hanselowski, Christian Stab, Claudia Schulz, Zile Li, and Iryna Gurevych. A richly annotated corpus for different tasks in automated fact-checking. In *Proceedings of the 23rd Conference on Computational Natural Language Learning (CoNLL)*, pages 493–503, Hong Kong, China, November 2019. Association for Computational Linguistics. doi: 10.18653/v1/K19-1046. URL https://aclanthology.org/K19-1046.

Naeemul Hassan, Chengkai Li, and Mark Tremayne. Detecting check-worthy factual claims in presidential debates. In *Proceedings of the 24th ACM International on Conference on Information and Knowledge Management*, CIKM '15, page 1835–1838, New York, NY, USA, 2015. Association for Computing Machinery. ISBN 9781450337946. doi: 10.1145/2806416.2806652. URL https://doi.org/10.1145/2806416.2806652.

Xuming Hu, Zhijiang Guo, GuanYu Wu, Aiwei Liu, Lijie Wen, and Philip Yu. CHEF: A pilot Chinese dataset for evidence-based fact-checking. In *Proceedings of the 2022 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, pages 3362–3376, Seattle, United States, July 2022. Association for Computational Linguistics. doi: 10.18653/v1/2022.naacl-main.246. URL https://aclanthology.org/2022.naacl-main.246.

Nan-Jiang Jiang and Marie-Catherine de Marneffe. Investigating Reasons for Disagreement in Natural Language Inference. *Transactions of the Association for Computational Linguistics*, 10:1357–1374, 12 2022. ISSN 2307-387X. doi: 10.1162/tacl_a_00523. URL https://doi.org/10.1162/tacl_a_00523.

Georgi Karadzhov, Preslav Nakov, Lluís Màrquez, Alberto Barrón-Cedeño, and Ivan Koychev. Fully automated fact checking using external sources. In *Proceedings of the International Conference Recent Advances in Natural Language Processing, RANLP 2017*, pages 344–353, Varna, Bulgaria, September 2017. INCOMA Ltd. doi: 10.26615/978-954-452-049-6_046. URL https://doi.org/10.26615/978-954-452-049-6_046.

Ashkan Kazemi, Kiran Garimella, Devin Gaffney, and Scott Hale. Claim matching beyond English to scale global fact-checking. In *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*, pages 4504–4517, Online, August 2021. Association for Computational Linguistics. doi: 10.18653/v1/2021.acl-long.347. URL https://aclanthology.org/2021.acl-long.347.



Sarah Cohen, Chengkai Li, Jun Yang, và Cong Yu. Báo chí tính toán: Lời kêu gọi hành động đối với các nhà nghiên cứu cơ sở dữ liệu. Trong Hội nghị Hai năm một lần lần thứ 5 về Nghiên cứu Hệ thống Dữ liệu Sáng tạo (CIDR), 2011.

Jacob Devlin, Ming-Wei Chang, Kenton Lee, và Kristina Toutanova. BERT: Tiền huấn luyện các biến áp hai chiều sâu để hiểu ngôn ngữ. Trong Kỷ yếu hội nghị năm 2019 của Chương Bắc Mỹ của Hiệp hội Ngôn ngữ học Máy tính: Công nghệ Ngôn ngữ Con người, Tập 1 (Bài báo Dài và Ngắn), các trang 4171–4186, Minneapolis, Minnesota, tháng 6 năm 2019. Hiệp hội Ngôn ngữ học Máy tính. doi: 10.18653/v1/N19-1423. URL https://aclanthology.org/N19-1423.

Thomas Diggelmann, Jordan Boyd-Graber, Jannis Bulian, Massimiliano Ciaramita và Markus Leippold. Climate-fever: Bộ dữ liệu để xác minh các tuyên bố về khí hậu trong thế giới thực, 2020.

Andy Dudfield. Cách chúng tôi sử dụng AI để mở rộng việc kiểm chứng thông tin trên toàn cầu. https://fullfact.org/blog/2020/jul/afc-global/, 2020. Truy cập: 17-01-2023.

Angela Fan, Aleksandra Piktus, Fabio Petroni, Guillaume Wenzek, Marzieh Saeidi, Andreas Vlachos, Antoine Bordes, và Sebastian Riedel. Tạo các bản tóm tắt kiểm tra sự thật. Trong Kỷ yếu Hội nghị về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên 2020 (EMNLP), trang 7147–7161, Trực tuyến, tháng 11 năm 2020. Hiệp hội Ngôn ngữ Học Tính toán. doi: 10.18653/v1/2020.emnlp-main.580. URL https://aclanthology.org/2020.emnlp-main.580.

Joseph L Fleiss. Đo lường sự đồng ý quy mô danh nghĩa giữa nhiều người đánh giá. *Tâm lý học thông báo*, 76(5):378, 1971.

Marina Fomicheva và Lucia Specia. Đưa các Chỉ số Đánh giá MT đến Cực độ: Vượt ra ngoài Tương quan với Đánh giá của Con người. Ngôn ngữ học Tính toán, 45(3):515–558, 09 2019. ISSN 0891-2017. doi: 10.1162/coli_a_00356. URL https://doi.org/10.1162/coli_a_00356.

Max Glockner, Yufang Hou và Iryna Gurevych. Thiếu bằng chứng phản bác làm cho việc kiểm tra sự thật bằng NLP trở nên không thực tế thông tin sai lệch, 2022. URL https://arxiv.org/abs/2210.13865.

Ashim Gupta và Vivek Srikumar. X-fact: Một bộ dữ liệu chuẩn mới cho việc kiểm chứng sự thật đa ngôn ngữ. Trong Kỷ yếu Hội nghị thường niên lần thứ 59 của Hiệp hội Ngôn ngữ học Máy tính và Hội nghị Liên hợp Quốc tế lần thứ 11 về Xử lý Ngôn ngữ Tự nhiên (Tập 2: Bài viết ngắn), trang 675–682, Trực tuyến, Tháng 8, 2021. Hiệp hội Ngôn ngữ học Máy tính. doi: 10.18653/v1/2021.acl-short.86. URL https://aclanthology.org/2021.acl-short.86.

Andreas Hanselowski, Christian Stab, Claudia Schulz, Zile Li và Iryna Gurevych. Một tập hợp dữ liệu chú thích phong phú cho các nhiệm vụ khác nhau trong kiểm chứng sự thật tự động. Trong Kỷ yếu của Hội nghị lần thứ 23 về Học Máy Ngôn Ngữ Tự Nhiên (CoNLL), trang 493–503, Hồng Kông, Trung Quốc, Tháng 11 năm 2019. Hiệp hội Ngôn ngữ Học Tính Toán. doi: 10.18653/v1/K19-1046. URL https://aclanthology.org/K19-1046.

Naeemul Hassan, Chengkai Li, và Mark Tremayne. Phát hiện các tuyên bố thực tế đáng kiểm tra trong các cuộc tranh luận tổng thống. Trong Kỷ yếu Hội nghị Quốc tế ACM lần thứ 24 về Quản lý Thông tin và Kiến thức, CIKM '15, trang 1835–1838, New York, NY, USA, 2015. Hiệp hội Máy tính một cách Thủ công. ISBN 9781450337946 28 06652 10 1145 2806416 2806652 10 1145 2806416. doi: . / . . URL https://doi.org/ . / . .

Xuming Hu, Zhijiang Guo, GuanYu Wu, Aiwei Liu, Lijie Wen, và Philip Yu. CHEF: Một bộ dữ liệu thử nghiệm tiếng Trung c ho kiểm tra sự thật dựa trên bằng chứng. Trong Kỷ yếu Hội nghị 2022 của Chi nhánh Bắc Mỹ thuộc Hiệp hội Ngôn ngữ học Máy tính: Công nghệ Ngôn ngữ Con người, trang 3362–3376, Seattle, Hoa Kỳ, tháng 7 năm 2022. Hiệp hội Ngôn ngữ học Máy tính. doi: 10.18653/v1/2022.naacl-main.246. URL https://aclanthology.org/2022.naacl-main.246.

Nan-Jiang Jiang và Marie-Catherine de Marneffe. Điều tra các Lý do Bất đồng trong Suy luận ngôn ngữ tự nhiên. Transactions of the Association for Computational Linguistics, 10:1357–1374, 12 2022. ISSN 2307-387X. doi: 10.1162/tacl_a_00523. URL https://doi.org/10.1162/tacl_a_00523.

Georgi Karadzhov, Preslav Nakov, Lluís Màrquez, Alberto Barrón-Cedeño và Ivan Koychev. Kiểm chứng sự thật hoàn toàn tự động bằng cách sử dụng các nguồn bên ngoài. Trong Kỷ yếu Hội nghị Quốc tế về Những Tiến bộ Gần đây trong Xử lý Ngôn ngữ Tự nhiên, RANLP 2017, các trang 344–353, Varna, Bulgaria, tháng 9 năm 2017. INCOMA Ltd. doi: 10.26615/978-954-452-049-6_046. URL https://doi.org/10.26615/978-954-452-049-6_046.

Ashkan Kazemi, Kiran Garimella, Devin Gaffney, và Scott Hale. So khớp tuyên bố vượt ra ngoài tiếng Anh để mở rộng việc kiểm tra sự thật toàn cầu. Trong Kỷ yếu Hội nghị thường niên lần thứ 59 của Hiệp hội Ngôn ngữ Học Máy tính và Hội nghị Quốc tế Liên hợp lần thứ 11 về Xử lý Ngôn ngữ Tự nhiên (Tập 1: Bài báo dài), trang 4504–4517, Trực tuyến, Tháng 8 năm 2021. Hiệp hội Ngôn ngữ Học Máy tính. doi: 10.18653/v1/2021.acl-long.347. URL https://aclanthology.org/2021.acl-long.347.

Kashif Khan, Ruizhe Wang, and Pascal Poupart. Watclaimcheck: A new dataset for claim entailment and inference. In Smaranda Muresan, Preslav Nakov, and Aline Villavicencio, editors, *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), ACL 2022, Dublin, Ireland, May 22-27, 2022*, pages 1293–1304. Association for Computational Linguistics, 2022. doi: 10.18653/v1/2022.acl-long.92. URL https://doi.org/10.18653/v1/2022.acl-long.92.

Diederik P. Kingma and Jimmy Ba. Adam: A method for stochastic optimization. In Yoshua Bengio and Yann LeCun, editors, *3rd International Conference on Learning Representations, ICLR 2015, San Diego, CA, USA, May 7-9, 2015, Conference Track Proceedings*, 2015. URL http://arxiv.org/abs/1412.6980.

Neema Kotonya and Francesca Toni. Explainable automated fact-checking: A survey. In *Proceedings of the 28th International Conference on Computational Linguistics*, pages 5430–5443, Barcelona, Spain (Online), December 2020. International Committee on Computational Linguistics. doi: 10.18653/v1/2020.coling-main.474. URL https://aclanthology.org/2020.coling-main.474.

H. W. Kuhn. The hungarian method for the assignment problem. *Naval Research Logistics Quarterly*, 2(1-2): 83–97, 1955. doi: https://doi.org/10.1002/nav.3800020109. URL https://onlinelibrary.wiley.com/doi/abs/10.1002/nav.3800020109.

Stephan Lewandowsky, John Cook, Ullrich Ecker, Dolores Albarracin, Michelle Amazeen, Panayiota Kendeou, Doug Lombardi, Eryn Newman, Gordon Pennycook, Ethan Porter, David G. Rand, David N. Rapp, Jason Reifler, Jon Roozenbeek, Philipp Schmid, Colleen M. Seifert, Gale M. Sinatra, Briony Swire-Thompson, Sander van der Linden, Emily K. Vraga, Thomas J. Wood, and Maria S. Zaragoza. Debunking Handbook 2020. https://sks.to/db2020, 2020.

Mike Lewis, Yinhan Liu, Naman Goyal, Marjan Ghazvininejad, Abdelrahman Mohamed, Omer Levy, Veselin Stoyanov, and Luke Zettlemoyer. BART: Denoising sequence-to-sequence pre-training for natural language generation, translation, and comprehension. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 7871–7880, Online, July 2020. Association for Computational Linguistics. doi: 10.18653/v1/2020.acl-main.703. URL https://aclanthology.org/2020.acl-main.703.

Chin-Yew Lin. ROUGE: A package for automatic evaluation of summaries. In *Text Summarization Branches Out*, pages 74–81, Barcelona, Spain, July 2004. Association for Computational Linguistics. URL https://aclanthology.org/W04-1013.

Jiachang Liu, Dinghan Shen, Yizhe Zhang, Bill Dolan, Lawrence Carin, and Weizhu Chen. What makes good in-context examples for GPT-3? In *Proceedings of Deep Learning Inside Out (DeeLIO 2022): The 3rd Workshop on Knowledge Extraction and Integration for Deep Learning Architectures*, pages 100–114, Dublin, Ireland and Online, May 2022. Association for Computational Linguistics. doi: 10.18653/v1/2022.deelio-1.10. URL https://aclanthology.org/2022.deelio-1.10.

Yuning Mao, Pengcheng He, Xiaodong Liu, Yelong Shen, Jianfeng Gao, Jiawei Han, and Weizhu Chen. Generation-augmented retrieval for open-domain question answering. In *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*, pages 4089–4100, Online, August 2021. Association for Computational Linguistics. doi: 10.18653/v1/2021.acl-long.316. URL https://aclanthology.org/2021.acl-long.316.

Sebastião Miranda, Andreas Vlachos, David Nogueira, Andrew Secker, Afonso Mendes, Rebecca Garrett, Jeffrey J Mitchell, and Zita Marinho. Automated fact checking in the news room. In *The Web Conference 2019*, pages 3579–3583, United States, May 2019. Association for Computing Machinery (ACM). doi: 10.1145/3308558.3314135. 2019 World Wide Web Conference, WWW 2019 ; Conference date: 13-05-2019 Through 17-05-2019.

Preslav Nakov, David Corney, Maram Hasanain, Firoj Alam, Tamer Elsayed, Alberto Barrón-Cedeño, Paolo Papotti, Shaden Shaar, and Giovanni Da San Martino. Automated fact-checking for assisting human fact-checkers. In Zhi-Hua Zhou, editor, *Proceedings of the Thirtieth International Joint Conference on Artificial Intelligence, IJCAI-21*, pages 4551–4558. International Joint Conferences on Artificial Intelligence Organization, 8 2021. doi: 10.24963/ijcai.2021/619. URL https://doi.org/10.24963/ijcai.2021/619. Survey Track.

Safiya Umoja Noble. Algorithms of oppression. In *Algorithms of Oppression*. New York University Press, 2018.

Rodrigo Nogueira, Wei Yang, Jimmy Lin, and Kyunghyun Cho. Document expansion by query prediction. *arXiv preprint arXiv:1904.08375*, 2019.



Kashif Khan, Ruizhe Wang, và Pascal Poupart. Watclaimcheck: Một bộ dữ liệu mới cho việc suy diễn và xác nhận tuyên bố. Trong Smaranda Muresan, Preslav Nakov, và Aline Villavicencio, biên tập viên, Kỷ yếu của Hội nghị thường niên lần thứ 60 của Hiệp hội Ngôn ngữ học Máy tính (Tập 1: Bài báo dài), ACL 2022, Dublin, Ireland, từ ngày 22-27 tháng 5, 2022, trang 1293–1304. Hiệp hội Ngôn ngữ học Máy tính, 2022. doi: 10.18653/v1/2022.acl-long.92. URL https://doi.org/10.18653/v1/2022.acl-long.92.

*Diederik P. Kingma và Jimmy Ba. Adam: Một phương pháp tối ưu hóa ngẫu nhiên. Trong Yoshua Bengio và Yann LeCun, biên tập viên, Hội nghị Quốc tế lần thứ 3 về Học Biểu diễn, ICLR 2015, San Diego, CA, Mỹ, từ ngày 7-9 tháng 5, 2015, Kỷ yếu Hội nghị, 2015. URL http://arxiv.org/abs/1412.6980.*

Neema Kotonya và Francesca Toni. Kiểm tra sự thật tự động có thể giải thích: Một khảo sát. Trong Kỷ yếu Hội nghị Quốc tế lần thứ 28 về Ngôn ngữ Học Máy Tính, trang 5430–5443, Barcelona, Tây Ban Nha (Trực tuyến), Tháng 12 năm 2020. Ủy ban Quốc tế về Ngôn ngữ Học Máy Tính. doi: 10.18653/v1/2020.coling-main.474. URL https://aclanthology.org/2020.coling-main.474.

H. W. Kuhn. Phương pháp Hungary cho bài toán phân công. Naval Research Logistics Quarterly, 2(1-2): 83–97, 1955. doi: https://doi.org/10.1002/nav.3800020109. URL https://onlinelibrary.wiley.com/doi/abs/10.1002/nav.3800020109.

Stephan Lewandowsky, John Cook, Ullrich Ecker, Dolores Albarracin, Michelle Amazeen, Panayiota Kendeou, Doug Lombardi, Eryn Newman, Gordon Pennycook, Ethan Porter, David G. Rand, David N. Rapp, Jason Reifler, Jon Roozenbeek, Philipp Schmid, Colleen M. Seifert, Gale M. Sinatra, Briony Swire-Thompson, Sander van der Linden, Emily K. Vraga, Thomas J. Wood, và Maria S. Zaragoza. Sổ tay Phản bác 2020. https://sks.to/db2020, 2020.

Mike Lewis, Yinhan Liu, Naman Goyal, Marjan Ghazvininejad, Abdelrahman Mohamed, Omer Levy, Veselin Stoyanov, và Luke Zettlemoyer. BART: Tiền huấn luyện tuần tự-làm sạch cho sinh ngữ tự nhiên, dịch thuật và hiểu biết. Trong Kỷ yếu của Hội nghị thường niên lần thứ 58 Hiệp hội Ngôn ngữ học Máy tính, các trang 7871–7880, Trực tuyến, tháng 7 năm 2020. Hiệp hội Ngôn ngữ học Máy tính. doi: 10.18653/v1/2020.acl-main.703. URL https://aclanthology.org/2020.acl-main.703.

Chin-Yew Lin. ROUGE: Một gói cho đánh giá tự động các bản tóm tắt. Trong Text Summarization Branches Out, trang 74–81, Barcelona, Tây Ban Nha, tháng 7 năm 2004. Hiệp hội Ngôn ngữ học Máy tính. URL https://aclanthology.org/W04-1013.

Jiachang Liu, Dinghan Shen, Yizhe Zhang, Bill Dolan, Lawrence Carin, và Weizhu Chen. Điều gì tạo nên các ví dụ phù hợp trong ngữ cảnh cho GPT-3? Trong Kỷ yếu của Hội thảo Deep Learning Inside Out (DeeLIO 2022): Workshop lần thứ 3 về Trích xuất và Tích hợp Tri thức cho Kiến trúc Học Sâu, trang 100–114, Dublin, Ireland và Trực tuyến, tháng 5 năm 2022. Hiệp hội Ngôn ngữ Học Tính Toán. doi: 10.18653/v1/2022.deelio-1.10. URL https://aclanthology.org/2022.deelio-1.10.

Yuning Mao, Pengcheng He, Xiaodong Liu, Yelong Shen, Jianfeng Gao, Jiawei Han, và Weizhu Chen. Tăng cường sáng tạo trong truy xuất thông tin cho trả lời câu hỏi mở. Trong Kỷ yếu Hội nghị Thường niên lần thứ 59 của Hiệp hội Ngôn ngữ học Máy tính và Hội nghị Liên hợp Quốc tế lần thứ 11 về Xử lý Ngôn ngữ Tự nhiên (Tập 1: Bài báo dài), các trang 4089–4100, Trực tuyến, tháng 8 năm 2021. Hiệp hội Ngôn ngữ học Máy tính. doi: 10 2 021 18653 1 2021 316 316 ./v/.acl-long.. URL https://aclanthology.org/.acl-long..

Sebastião Miranda, Andreas Vlachos, David Nogueira, Andrew Secker, Afonso Mendes, Rebecca Garrett, Jeffrey J Mitchell và Zita Marinho. Kiểm tra sự thật tự động trong phòng tin tức. Trong Hội nghị Web 2019, trang 3579–3583, Hoa Kỳ, tháng 5 năm 2019. Hiệp hội Máy tính (ACM). doi: 10.1145/3308558.3314135. Hội nghị Thế giới Web 2019, WWW 2019; Ngày hội nghị: 13-05-2019 đến 17-05-2019.

Preslav Nakov, David Corney, Maram Hasanain, Firoj Alam, Tamer Elsayed, Alberto Barrón-Cedeño, Paolo Papotti, Shaden Shaar, và Giovanni Da San Martino. Kiểm tra sự thật tự động để hỗ trợ những người kiểm tra sự thật. Trong Zhi-Hua Zhou, biên tập, Kỷ yếu Hội nghị Liên hợp Quốc tế lần thứ Ba mươi về Trí tuệ Nhân tạo, IJCAI-21, trang 4551–4558. Tổ chức Hội nghị Liên hợp Quốc tế về Trí tuệ Nhân tạo, 8 2021. doi: 10.24963/ijcai.2021/619. URL https://doi.org/10.24963/ijcai.2021/619. Theo dõi Khảo sát.

Safiy a Umoja Noble. Thuật toán áp bức. Trong Thuật toán áp bức. Nhà xuất bản Đại học New York, 201 8.

Rodrigo Nogueira, Wei Yang, Jimmy Lin và Kyunghyun Cho. Mở rộng tài liệu bằng cách dự đoán truy vấn. Bản in trước tr ên arXiv arXiv:1904.08375, 2019.

Wojciech Ostrowski, Arnav Arora, Pepa Atanasova, and Isabelle Augenstein. Multi-hop fact checking of political claims. In Zhi-Hua Zhou, editor, *Proceedings of the Thirtieth International Joint Conference on Artificial Intelligence, IJCAI 2021, Virtual Event / Montreal, Canada, 19-27 August 2021*, pages 3892–3898. ijcai.org, 2021. doi: 10.24963/ijcai.2021/536. URL https://doi.org/10.24963/ijcai.2021/536.

Nedjma Ousidhoum, Zhangdie Yuan, and Andreas Vlachos. Varifocal question generation for fact-checking. In Yoav Goldberg, Zornitsa Kozareva, and Yue Zhang, editors, *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*, pages 2532–2544, Abu Dhabi, United Arab Emirates, December 2022. Association for Computational Linguistics. doi: 10.18653/v1/2022.emnlp-main.163. URL https://aclanthology.org/2022.emnlp-main.163.

Justus J Randolph. Free-marginal multirater kappa (multirater k [free]): An alternative to fleiss' fixed-marginal multirater kappa. *Online submission*, 2005.

Stephen Robertson and Hugo Zaragoza. The probabilistic relevance framework: Bm25 and beyond. *Foundations and Trends® in Information Retrieval*, 3(4):333–389, 2009. ISSN 1554-0669. doi: 10.1561/1500000019. URL http://dx.doi.org/10.1561/1500000019.

Ohad Rubin, Jonathan Herzig, and Jonathan Berant. Learning to retrieve prompts for in-context learning. In *Proceedings of the 2022 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, pages 2655–2671, Seattle, United States, July 2022. Association for Computational Linguistics. doi: 10.18653/v1/2022.naacl-main.191. URL https://aclanthology.org/2022.naacl-main.191.

Arkadiy Saakyan, Tuhin Chakrabarty, and Smaranda Muresan. COVID-fact: Fact extraction and verification of real-world claims on COVID-19 pandemic. In *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*, pages 2116–2129, Online, August 2021. Association for Computational Linguistics. doi: 10.18653/v1/2021.acl-long.165. URL https://aclanthology.org/2021.acl-long.165.

Mourad Sarrouti, Asma Ben Abacha, Yassine Mrabet, and Dina Demner-Fushman. Evidence-based fact-checking of health-related claims. In Marie-Francine Moens, Xuanjing Huang, Lucia Specia, and Scott Wen-tau Yih, editors, *Findings of the Association for Computational Linguistics: EMNLP 2021, Virtual Event / Punta Cana, Dominican Republic, 16-20 November, 2021*, pages 3499–3512. Association for Computational Linguistics, 2021. doi: 10.18653/v1/2021.findings-emnlp.297. URL https://doi.org/10.18653/v1/2021.findings-emnlp.297.

Teven Le Scao, Angela Fan, Christopher Akiki, Ellie Pavlick, Suzana Ilić, Daniel Hesslow, Roman Castagné, Alexandra Sasha Luccioni, François Yvon, Matthias Gallé, et al. Bloom: A 176b-parameter open-access multilingual language model. *arXiv preprint arXiv:2211.05100*, 2022.

Michael Schlichtkrull, Nedjma Ousidhoum, and Andreas Vlachos. The intended uses of automated fact-checking artefacts: Why, how and who, 2023.

Tal Schuster, Adam Fisch, and Regina Barzilay. Get your vitamin C! robust fact verification with contrastive evidence. In *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, pages 624–643, Online, June 2021. Association for Computational Linguistics. doi: 10.18653/v1/2021.naacl-main.52. URL https://aclanthology.org/2021.naacl-main.52.

Thibault Sellam, Dipanjan Das, and Ankur Parikh. BLEURT: Learning robust metrics for text generation. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 7881–7892, Online, July 2020. Association for Computational Linguistics. doi: 10.18653/v1/2020.acl-main.704. URL https://aclanthology.org/2020.acl-main.704.

James Thorne, Andreas Vlachos, Christos Christodoulopoulos, and Arpit Mittal. FEVER: a large-scale dataset for fact extraction and VERification. In *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long Papers)*, pages 809–819, New Orleans, Louisiana, June 2018. Association for Computational Linguistics. doi: 10.18653/v1/N18-1074. URL https://aclanthology.org/N18-1074.

Stephen E. Toulmin. *The Uses of Argument*. Cambridge University Press, 1958.

Joseph E. Uscinski and Ryden W. Butler. The Epistemology of Fact Checking. *Critical Review*, 25(2):162–180, June 2013. ISSN 0891-3811, 1933-8007. doi: 10.1080/08913811.2013.843872. URL http://www.tandfonline.com/doi/abs/10.1080/08913811.2013.843872.



Wojciech Ostrowski, Arnav Arora, Pepa Atanasova, và Isabelle Augenstein. Kiểm tra thực tế đa bước về các tuyên bố chính trị. Trong Zhi-Hua Zhou, biên tập, *Kỷ yếu Hội nghị Quốc tế Liên hợp lần thứ Ba mươi về Trí tuệ Nhân tạo, IJCAI 2021, Sự kiện Trực tuyến / Montreal, Canada, 19-27 tháng 8 năm 2021, trang 3892–3898*. ijcai.org, 2021. doi: 10.24963/ijcai.2021/536. URL https://doi.org/10.24963/ijcai.2021/536.

Nedjma Ousidhoum, Zhangdie Yuan, và Andreas Vlachos. Tạo câu hỏi đa tiêu điểm để kiểm chứng thông tin. Trong Yoav Goldberg, Zornitsa Kozareva và Yue Zhang, biên tập viên, *Kỷ yếu Hội nghị năm 2022 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên*, trang 2532–2544, Abu Dhabi, Các Tiểu vương quốc Ả Rập Thống nhất, tháng 12 năm 2022. Hiệp hội Ngôn ngữ Học Máy tính. doi: 10.18653/v1/2022.emnlp-main.163. URL https://aclanthology.org/2022.emnlp-main.163.

Justus J Randolph. Đánh giá viên biên tự do (đa đánh giá viên k [free]): Một phương án thay thế cho kappa đa đánh giá viên biên cố định của Fleiss. *Nộp trực tuyến*, 2005.

Stephen Robertson và Hugo Zaragoza. Khung liên quan xác suất: Bm25 và hơn thế nữa. *Foundations and Trends® in Information Retrieval*, 3(4):333–389, 2009. ISSN 1554-0669. doi: 10.1561/1500000019. URL http://dx.doi.org/10.1561/1500000019.

Ohad Rubin, Jonathan Herzig và Jonathan Berant. Học cách truy xuất các câu lệnh cho việc học theo ngữ cảnh. *Trong Kỷ yếu Hội nghị năm 2022 của Chi nhánh Bắc Mỹ của Hiệp hội Ngôn ngữ Học Máy tính: Công nghệ Ngôn ngữ Con người, trang 2655–2671, Seattle, Hoa Kỳ, tháng 7 năm 2022. Hiệp hội Ngôn ngữ Học Máy tính. doi: 10.18653/v1/2022.naacl-main.191. URL https://aclanthology.org/2022.naacl-main.191.*

Arkadiy Saakyan, Tuhin Chakrabarty và Smaranda Muresan. COVID-fact: Trích xuất và xác minh các tuyên bố thực tế về đại dịch COVID-19. Trong *Kỷ yếu Hội nghị thường niên lần thứ 59 của Hiệp hội Ngôn ngữ Học Máy tính và Hội nghị Liên hợp Quốc tế lần thứ 11 về Xử lý Ngôn ngữ Tự nhiên (Tập 1: Bài báo dài)*, trang 2116–2129, Trực tuyến, tháng 8 năm 2021. Hiệp hội Ngôn ngữ Học Máy tính. doi: 10.18653/v1/2021.acl-long.165. URL https://aclanthology.org/2021.acl-long.165.

Mourad Sarrouti, Asma Ben Abacha, Yassine Mrabet, và Dina Demner-Fushman. Kiểm chứng thông tin dựa trên bằng chứng về các tuyên bố liên quan đến sức khỏe. Trong Marie-Francine Moens, Xuanjing Huang, Lucia Specia, và Scott Wen-tau Yih, biên tập, *Kết quả của Hiệp hội Ngôn ngữ Học Máy Tính: EMNLP 2021, Sự kiện ảo / Punta Cana, Cộng hòa Dominican, 16-20 tháng 11, 2021*, trang 3499–3512. Hiệp hội Ngôn ngữ Học Máy Tính, 2021. doi: 10.18653/v1/2021.findings-emnlp.297. URL https://doi.org/10.18653/v1/2021.findings-emnlp.297.

Teven Le Scao, Angela Fan, Christopher Akiki, Ellie Pavlick, Suzana Ilić, Daniel Hesslow, Roman Castagné, Alexandra Sasha Luccioni, François Yvon, Matthias Gallé, và cộng sự. Bloom: Một mô hình ngôn ngữ đa ngôn ngữ truy cập mở với 176 tỷ tham số. *Bản in trước trên arXiv arXiv:2211.05100*, 2022.

Michael Schlichtkrull, Nedjma Ousidhoum, và Andreas Vlachos. Các mục đích sử dụng dự kiến của các hiện vật kiểm tra sự thật tự động: Tại sao, như thế nào và ai, 2023.

Tal Schuster, Adam Fisch, và Regina Barzilay. Lấy vitamin C của bạn! xác minh sự thật mạnh mẽ với bằng chứng đối chiếu. Trong *Kỷ yếu Hội nghị 2021 của Chương Bắc Mỹ của Hiệp hội Ngôn ngữ Học Tính Toán: Công nghệ Ngôn ngữ Con người, trang 624–643, Trực tuyến, tháng 6 năm 2021*. Hiệp hội Ngôn ngữ Học Tính Toán. doi: 10.18653/v1/2021.naacl-main.52. URL https://aclanthology.org/2021.naacl-main.52.

Thibault Sellam, Dipanjan Das và Ankur Parikh. BLEURT: Học các chỉ số bền vững cho việc tạo văn bản. Trong *Kỷ yếu của Hội nghị thường niên lần thứ 58 của Hiệp hội Ngôn ngữ học Máy tính, các trang 7881–7892, Trực tuyến, Tháng 7 năm 2020*. Hiệp hội Ngôn ngữ học Máy tính. doi: 10.18653/v1/2020.acl-main.704. URL https://aclanthology.org/2020.acl-main.704.

James Thorne, Andreas Vlachos, Christos Christodoulopoulos, và Arpit Mittal. FEVER: một tập dữ liệu quy mô lớn để trích xuất và xác minh thông tin. Trong *Kỷ yếu Hội nghị năm 2018 của Chương Bắc Mỹ của Hiệp hội Ngôn ngữ học Máy tính: Công nghệ Ngôn ngữ Con người, Tập 1 (Bài báo Dài), các trang 809–819, New Orleans, Louisiana, tháng 6 năm 2018*. Hiệp hội Ngôn ngữ học Máy tính. doi: 10.18653/v1/N18-1074. URL https://aclanthology.org/N18-1074.

Stephen E. Toulmin. *Những Công Dụng của Lập Luận*. Nhà xuất bản Đại học Cambridge, 1958.

Joseph E. Uscinski và Ryden W. Butler. Nhận thức luận của Kiểm tra thực tế. *Critical Review*, 25(2):162–180, tháng 6 năm 2013. ISSN 0891-3811, 1933-8007. doi: 10.1080/08913811.2013.843872. URL http://www.tandfonline.com/doi/abs/10.1080/08913811.2013.843872.

Andreas Vlachos and Sebastian Riedel. Fact checking: Task definition and dataset construction. In *Proceedings of the ACL 2014 Workshop on Language Technologies and Computational Social Science*, pages 18–22, Baltimore, MD, USA, June 2014. Association for Computational Linguistics. doi: 10.3115/v1/W14-2508. URL https://aclanthology.org/W14-2508.

David Wadden, Shanchuan Lin, Kyle Lo, Lucy Lu Wang, Madeleine van Zuylen, Arman Cohan, and Hannaneh Hajishirzi. Fact or fiction: Verifying scientific claims. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 7534–7550, Online, November 2020. Association for Computational Linguistics. doi: 10.18653/v1/2020.emnlp-main.609. URL https://aclanthology.org/2020.emnlp-main.609.

William Yang Wang. "liar, liar pants on fire": A new benchmark dataset for fake news detection. In *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers)*, pages 422–426, Vancouver, Canada, July 2017. Association for Computational Linguistics. doi: 10.18653/v1/P17-2067. URL https://aclanthology.org/P17-2067.

Matthijs J Warrens. Inequalities between multi-rater kappas. *Advances in data analysis and classification*, 4(4): 271–286, 2010.

Thomas Wolf, Lysandre Debut, Victor Sanh, Julien Chaumond, Clement Delangue, Anthony Moi, Pierric Cistac, Tim Rault, Remi Louf, Morgan Funtowicz, Joe Davison, Sam Shleifer, Patrick von Platen, Clara Ma, Yacine Jernite, Julien Plu, Canwen Xu, Teven Le Scao, Sylvain Gugger, Mariama Drame, Quentin Lhoest, and Alexander Rush. Transformers: State-of-the-art natural language processing. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, pages 38–45, Online, October 2020. Association for Computational Linguistics. doi: 10.18653/v1/2020.emnlp-demos.6. URL https://aclanthology.org/2020.emnlp-demos.6.

Jing Yang, Didier Vega-Oliveros, Taís Seibt, and Anderson Rocha. Explainable fact-checking through question answering. In *ICASSP 2022 - 2022 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pages 8952–8956, 2022. doi: 10.1109/ICASSP43922.2022.9747214.



Andreas Vlachos và Sebastian Riedel. Kiểm tra sự thật: Định nghĩa nhiệm vụ và xây dựng tập dữ liệu. Trong Kỷ yếu Hội t hảo ACL 2014 về Công nghệ Ngôn ngữ và Khoa học Xã hội Tính toán, trang 18–22, Baltimore, MD, USA, Tháng Sáu 2014. Hiệp hội Ngôn ngữ học Tính toán. doi: 10.3115/v1/W14-2508. URL https://aclanthology.org/W14-2508.

David Wadden, Shanchuan Lin, Kyle Lo, Lucy Lu Wang, Madeleine van Zuylen, Arman Cohan, và Hannaneh Hajishirzi. Thật hay giả: Xác minh các tuyên bố khoa học. Trong Kỷ yếu Hội nghị về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên 2020 (EMNLP), trang 7534–7550, Trực tuyến, tháng 11 năm 2020. Hiệp hội Ngôn ngữ Học Tính toán. doi: 10.18653/v1/2020.emnlp-main.609. URL https://aclanthology.o rg/2020.emnlp-main.609.

William Yang Wang. "kẻ nói dối, kẻ nói dối, quần đang cháy": Một bộ dữ liệu chuẩn mới cho phát hiện tin giả. Trong Kỷ yếu của Hội nghị thường niên lần thứ 55 của Hiệp hội Ngôn ngữ học Máy tính (Tập 2: Bài báo ngắn), trang 422–426, 2017, 10 18653 1 17 17 2067 – Vancouver, Canada, tháng 7. Hiệp hội Ngôn ngữ học Máy tính. doi: . /v /P - . URL https://aclanthology.org/P - .

Matthijs J Warrens. Bất bình đẳng giữa các chỉ số kappa đa đánh giá viên. Tiến bộ trong phân tích dữ liệu và phân loại, 4(4): 271–286, 2010.

Thomas Wolf, Lysandre Debut, Victor Sanh, Julien Chaumond, Clement Delangue, Anthony Moi, Pierric Cistac, Tim Rault, Remi Louf, Morgan Funtowicz, Joe Davison, Sam Shleifer, Patrick von Platen, Clara Ma, Yacine Jernite, Julien Plu, Canwen Xu, Teven Le Scao, Sylvain Gugger, Mariama Drame, Quentin Lhoest và Alexander Rush. Transformers: Xử lý ngôn ngữ tự nhiên tiên tiến nhất. Trong Kỷ yếu Hội nghị 2020 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên: Trình diễn Hệ thống, các trang 38–45, Trực tuyến, tháng 10 năm 2020. Hiệp hội Ngôn ngữ học Máy tính. doi: 10.18653/v1/2020.emnlp-demos.6. URL https://aclanthology.org/2020.emnlp-demos.6.

Jing Yang, Didier Vega-Oliveros, Taís Seibt, và Anderson Rocha. Kiểm tra sự thật có thể giải thích thông qua trả lời câu hỏi. Trong ICASSP 2022 - Hội nghị Quốc tế IEEE về Âm thanh, Lời nói và Xử lý Tín hiệu 2022 (ICASSP), trang 8952–8956, 2022. doi: 10.1109/ICASSP43922.2022.9747214.

# A Dataset Access

We release our dataset and baseline at `https://github.com/MichSchli/AVeriTeC`, and will maintain it there. As we anticipate using the dataset in a future shared task, we are as of submission time only releasing the training and development splits. We will make the test split available privately to reviewers upon request.

# B Author Statement

The authors of this paper bear all responsibility in case of violation of copyrights associated with the AVERITECdataset.

# C Annotation Details

We carried out our annotations with the help of Appen (`https://appen.com/`), an Australian private company delivering machine learning products. The annotations took place on a special-purpose platform developed by our team and supplied to Appen. We will make the code for this platform available upon request. Appen provides guarantees that annotators are paid fairly: see `https://success.appen.com/hc/en-us/articles/9557008940941-Guide-to-Fair-Pay`. We spent a total of €40,835 for crowdworkers in our annotation process.

# D Baseline Prompts

## D.1 Claim Question Generation

To enrich our search results, we generate additional questions for use as search queries. For each claim, we retrieve the 10 most similar claims from the training dataset (computed using BM25). We combine these into a prompt following the scheme shown in Figure 3. We incorporate both the speaker and the claim itself in a form of preliminary experiments found to be highly effective: "*Outrageously, SPEAKER claimed that CLAIM. Criticism includes questions like: "*. The adversarial tone encourages the model to generate questions useful for debunking – we found this to be crucial for finding additional useful search results beyond those returned using the claim itself.

## D.2 Passage Question Generation

Once search results have been found, we generate questions for each line of each searched document using the process described in Section 7.1. We retrieve the 10 most similar question-answer pairs from the training dataset (computed using BM25 between the answer and the evidence line). We combine these into a prompt following the scheme shown in Figure 3. We experimented also with including the claim when generating the questions, however, we found this to decrease performance by acting as a distractor; BLOOM would generate questions related only to the claim and unrelated to the evidence. Passage question generation was by far the most expensive part of our experiments. While we made sure the model fits in memory of an A100 GPU, we parallelized inference across several. Using eight GPUs, question generation took approximately 24 hours.

## D.3 Justification Generation

We use a further prompt to generate justifications given the claim and verdict for the no-evidence baseline. Again, for each claim, we retrieve the 10 most similar claims from the training dataset (computed using BM25). We experimented with the same adversarial form discussed for question generation in Appendix D.1, but did not see any improvements in performance.

# E Baseline Models

We finetuned models for several components of our baseline. The following sections list hyper-parameter settings for each of those models. All training took place on a single Nvidia A100 GPU.



# Truy cập Bộ dữ liệu

Chúng tôi phát hành bộ dữ liệu và chuẩn cơ sở tại https://github.com/MichSchli/AVeriTeC, và sẽ duy trì nó ở đó. Vì chúng tôi dự kiến sẽ sử dụng bộ dữ liệu này trong một nhiệm vụ chia sẻ trong tương lai, tại thời điểm nộp bài chúng tôi chỉ phát hành các phần chia huấn luyện và phát triển. Chúng tôi sẽ cung cấp phần chia kiểm tra riêng tư cho các nhà đánh giá khi có yêu cầu.

# Tuyên bố của tác giả B

Các tác giả của bài báo này chịu trách nhiệm hoàn toàn trong trường hợp vi phạm bản quyền liên quan đến bộ dữ liệu AVERITEC.

# Chi tiết chú thích C

Chúng tôi đã thực hiện việc chú thích của mình với sự trợ giúp của Appen (https://appen.com/), một công ty tư nhân của Úc cung cấp các sản phẩm học máy. Việc chú thích diễn ra trên một nền tảng chuyên dụng được phát triển bởi nhóm của chúng tôi và cung cấp cho Appen. Chúng tôi sẽ cung cấp mã cho nền tảng này khi có yêu cầu. Appen đảm bảo rằng các người chú thích được trả công công bằng: xem https://success.appen.com/hc/en-us/articles/9557008940941-Guide-to-Fair-Pay. Chúng tôi đã chi tổng cộng C40,835 cho các công nhân đám đông trong quá trình chú thích của mình.
=

# D Các Lời Nhắc Cơ Sở

## D.1 Tạo Câu Hỏi Tuyên Bố

Để làm phong phú kết quả tìm kiếm của chúng tôi, chúng tôi tạo ra các câu hỏi bổ sung để sử dụng như các truy vấn tìm kiếm. Đối với mỗi tuyên bố, chúng tôi truy xuất 10 tuyên bố tương tự nhất từ bộ dữ liệu huấn luyện (được tính t oán bằng BM25). Chúng tôi kết hợp chúng thành một lời nhắc theo sơ đồ được hiển thị trong Hình 3. Chúng tôi kết hợp cả người nói và chính tuyên bố vào một dạng thử nghiệm sơ bộ được xác định là rất hiệu quả:

" Một cách gây sốc, DIỄN GIẢ đã tuyên bố rằng YÊU CẦU. Các lời chỉ trích bao gồm các câu hỏi như: ". Giọng điệu đối kháng khuyến khích mô hình tạo ra các câu hỏi hữu ích để bác bỏ – chúng tôi nhận thấy điều này rất quan trọng để tìm các kết quả tìm kiếm bổ ích khác ngoài những gì được trả về khi chỉ sử dụng chính tuyên bố đó.

## D.2 Tạo câu hỏi từ đoạn văn

Khi các kết quả tìm kiếm đã được tìm thấy, chúng tôi tạo các câu hỏi cho mỗi dòng của từng tài liệu được tìm kiếm bằng quy trình được mô tả trong Mục 7.1. Chúng tôi truy xuất 10 cặp câu hỏi-trả lời tương tự nhất từ bộ dữ liệu huấn luyện (tính toán bằng BM25 giữa câu trả lời và dòng chứng cứ). Chúng tôi kết hợp những cặp này vào một gợi ý theo sơ đồ được hiển thị trong Hình 3. Chúng tôi cũng đã thử nghiệm việc bao gồm cả tuyên bố khi tạo câu hỏi, tuy nhiên, chúng tôi thấy điều này làm giảm hiệu suất vì nó gây phân tâm; BLOOM sẽ tạo các câu hỏi chỉ liên quan đến tuyên bố và không liên quan đến chứng cứ. Việc tạo câu hỏi từ đoạn văn là phần tốn kém nhất trong các thí nghiệm của chúng tôi. Trong khi chúng tôi đảm bảo mô hình vừa vặn trong bộ nhớ của GPU A100, chúng tôi đã chạy song song việc suy luận trên nhiều GPU. Sử dụng tám GPU, việc tạo câu hỏi mất khoảng 24 giờ.

## D.3 Tạo lập Lý do

Chúng tôi sử dụng một gợi ý bổ sung để tạo ra các lý do dựa trên tuyên bố và phán quyết cho cơ sở không có bằng chứng. Một lần nữa, đối với mỗi tuyên bố, chúng tôi truy xuất 10 tuyên bố tương tự nhất từ bộ dữ liệu huấn luyện (tính toán bằng BM25). Chúng tôi đã thử nghiệm với cùng một hình thức đối kháng được thảo l uận cho việc tạo câu hỏi trong Phụ lục D.1, nhưng không thấy cải thiện nào về hiệu suất.

# Mô Hình Cơ Sở E

Chúng tôi đã tinh chỉnh các mô hình cho một số thành phần của mô hình cơ sở của chúng tôi. Các phần sau liệt kê các cài đặt siêu tham số cho từng mô hình đó. Tất cả việc huấn luyện đều diễn ra trên một GPU Nvidia A100 duy nhất.

Outrageously, United We Win claimed that "As mayor, Cory Booker, US Democratic presidential candidate and US New Jersey Senator, passed criminal justice reform in a US Republican Senate.". Criticism includes questions like: Did U.S. Sen. Cory Booker pass criminal justice reform? What was the Republicans' majority in the Senate when the bill was signed into law?

Outrageously, Mokwele Kholofelo Banny claimed that "A married couple in Florida, Tito and Amanda Watts, was arrested for selling fake golden tickets to heaven to hundreds of people.". Criticism includes questions like: Did married couple Tito and Amanda Watts from Florida get arrested for selling fake golden tickets to heaven?

Outrageously, Muhammadu Buhari claimed that "It makes no sense for oil to be cheaper in Nigeria than in Saudi Arabia.". Criticism includes questions like: What was the price of petrol in Nigeria in Oct 2020? What was the price of petrol in Saudi Arabia in Oct 2020?

...

Outrageously, Tea talk and gossip claimed that "Microsoft cofounder Bill Gates said Be nice to nerds. Chances are you'll end up working for one.". Criticism includes questions like: Is Bill Gates quoted as saying "Be nice to nerds, chances are you'll end up working for one"?

Outrageously, Sen. Amy Klobuchar claimed that "US President Trump called for reduced funding for the Centre for Disease Control and Prevention.". Criticism includes questions like: Did US President Trump propose budget cuts in the funding for the Centre for Disease Control and Prevention?

Outrageously, US Democratic presidential candidate Wayne Messam claimed that "It is illegal for mayors to even bring up gun reform for discussion in Florida, US.". Criticism includes questions like:

Figure 3: Example prompt used to generate search questions for the claim *"It is illegal for mayors to even bring up gun reform for discussion in Florida, US."* with the speaker *"US Democratic presidential candidate Wayne Messam"*.

### E.1 Evidence Reranking

We used the BERT-large model [Devlin et al., 2019] with a text classification head, relying on the huggingface implementation [Wolf et al., 2020]. The model has 340 million parameters. We finetuned the model using Adam [Kingma and Ba, 2015] with a learning rate of $0.001$ and a batch size of 128. The evidence reranker is trained using negative sampling. For each triple of claim $c$, question $q$, and answer $a$, we construct three negatives by corrupting each of $c$, $q$, or $a$, for a total of 9 negative samples per positive. Corrupted elements are replaced with randomly selected others from the dataset.

### E.2 Stance Detection

The setup for the stance detection model is similar to the evidence reranker. We again used the BERT-large model [Devlin et al., 2019] with a text classification head, relying on the huggingface implementation [Wolf et al., 2020]. The model has 340 million parameters. We finetuned the model using Adam [Kingma and Ba, 2015] with a learning rate of $0.001$ and a batch size of 128. To train the stance detection model, we constructed examples from the training set. For claims with *supported* labels, we created one example per question for a positive stance. For claims with *refuted* labels, we created one example per question for negative stance. For claims with *not enough evidence* labels, we created one example per question for a neutral stance. Finally, we discarded all claims with *conflicting evidence/cherrypicking as the label*.



Một cách gây sốc, United We Win đã tuyên bố rằng "Là thị trưởng, Cory Booker, ứng cử viên tổng thống của Đảng Dân chủ Hoa Kỳ và Thượng nghị sĩ New Jersey của Hoa Kỳ, đã thông qua cải cách tư pháp hình sự tại Thượng viện Hoa Kỳ do Đảng Cộng hòa kiểm soát." Các phản biện bao gồm các câu hỏi như: Thượng nghị sĩ Hoa Kỳ Cory Booker có thông qua cải cách tư pháp hình sự không? Đa số của Đảng Cộng hòa trong Thượng viện khi dự luật được ký thành luật là bao nhiêu?

Một cách gây sốc, Mokwele Kholofelo Banny đã tuyên bố rằng "Một cặp vợ chồng ở Florida, Tito và Amanda Watts, đã bị bắt vì bán vé vàng giả lên thiên đường cho hàng trăm người." Lời chỉ trích bao gồm những câu hỏi như: Liệu cặp vợ chồng Tito và Amanda Watts từ Florida có bị bắt vì bán vé vàng giả lên thiên đường không?

Thật đáng phẫn nộ, Muhammadu Buhari đã tuyên bố rằng "Thật vô lý khi dầu lại rẻ hơn ở Nigeria hơn ở Saudi Arabia. Những lời chỉ trích bao gồm các câu hỏi như: Giá của xăng ở Nigeria vào tháng 10 năm 2020? Giá xăng ở Ả Rập Xê Út vào tháng 10 năm 2020 là bao nhiêu?

...

Thật tức giận, câu chuyện nhấm nháy và tin đồn cho rằng "Đồng sáng lập Microsoft Bill Gates đã nói: Hãy tử tế với những người mọt sách. Có khả năng bạn sẽ kết thúc làm việc cho một người trong số họ.". Những lời chỉ trích bao gồm các câu hỏi như: Bill Gates có được trích dẫn là nói "Hãy tử tế với những người mọt sách, có khả năng bạn sẽ kết thúc làm việc cho một người trong số họ" không?

Một cách gây sốc, Thượng nghị sĩ Amy Klobuchar tuyên bố rằng "Tổng thống Mỹ Trump kêu gọi giảm kinh phí cho Trung tâm Kiểm soát và Phòng ngừa Dịch bệnh." Những lời chỉ trích bao gồm các câu hỏi như: Liệu Tổng thống Mỹ Trump có đề xuất cắt giảm ngân sách cho Trung tâm Kiểm soát và Phòng ngừa Dịch bệnh không?

Một cách gây sốc, ứng cử viên tổng thống đảng Dân chủ Mỹ Wayne Messam đã tuyên bố rằng "Việc các thị trưởng thậm chí đề cập đến cải cách súng đạn để thảo luận ở Florida, Mỹ là bất hợp pháp." Những lời chỉ trích bao gồm những câu hỏi như:

*Hình 3: Ví dụ về gợi ý được sử dụng để tạo các câu hỏi tìm kiếm cho câu khẳng định "Ở Florida, Mỹ, việc các thị trưởng thậm chí đề cập đến cải cách súng là bất hợp pháp." với người phát ngôn "Ứng cử viên tổng thống Mỹ thuộc Đảng Dân chủ Wayne Messam".*

### E.1 Sắp xếp lại bằng chứng

Chúng tôi đã sử dụng mô hình BERT-large [Devlin et al., 2019] với một phần phân loại văn bản, dựa trên triển khai của huggingface [Wolf et al., 2020]. Mô hình có 340 triệu tham số. Chúng tôi đã tinh chỉnh mô hình sử dụng Adam [Kingma và Ba, 2015] với tốc độ học 0,001 và kích thước batch là 128. Trình xếp hạng lại bằng chứng được huấn luyện sử dụng phương pháp lấy mẫu âm. Đối với mỗi bộ ba gồm yêu cầu $c$, câu hỏi $q$, và câu trả lời $a$, chúng tôi tạo ra ba mẫu âm bằng cách làm hỏng từng phần $c$, $q$, hoặc $a$, tổng cộng có 9 mẫu âm cho mỗi mẫu dương. Các phần bị làm hỏng được thay bằng các phần khác được chọn ngẫu nhiên từ bộ dữ liệu.

### E.2 Phát hiện lập trường

Cài đặt cho mô hình phát hiện quan điểm tương tự như mô hình sắp xếp lại bằng chứng. Chúng tôi lại sử dụng mô hình BERT-large [Devlin et al., 2019] với đầu phân loại văn bản, dựa trên triển khai của huggingface [Wolf et al., 2020]. Mô hình có 340 triệu tham số. Chúng tôi tinh chỉnh mô hình sử dụng Adam [Kingma và Ba, 2015] với tốc độ học 0.001 và kích thước batch là 128. Để huấn luyện mô hình phát hiện quan điểm, chúng tôi xây dựng các ví dụ từ tập dữ liệu huấn luyện. Đối với những khẳng định có nhãn được hỗ trợ, chúng tôi tạo một ví dụ cho mỗi câu hỏi với quan điểm tích cực. Đối với những khẳng định có nhãn bị bác bỏ, chúng tôi tạo một ví dụ cho mỗi câu hỏi với quan điểm tiêu cực. Đối với những khẳng định có nhãn không đủ bằng chứng, chúng tôi tạo một ví dụ cho mỗi câu hỏi với quan điểm trung lập. Cuối cùng, chúng tôi loại bỏ tất cả các khẳng định có bằng chứng mâu thuẫn/lựa chọn có chọn lọc làm nhãn.

Evidence: The image of Time magazine cover with Rachel Levine as woman of the year was posted on Facebook by "The United Spot", which is labelled as a satire site. Question answered: Which website said that Rachel Levine was Time's Woman of the Year?

Evidence: Yes, because the wording was actually "complete 57 mega dams". Question answered: In 2017, did the Kenyan Government manifesto say they would construct 57 mega dams?

Evidence: No, because the blog text uses future terminology like "...the bill is being brought in..." and "...this nz food bill will pave the way...". Question answered: Does the blog post imply that this Food Bill is already legislation?

...

Evidence: China described the reports from Pakistan as "Baseless & fake". Question answered: Did China report any losses relating to this clash?

Evidence: After carrying a few boxes that appeared full of supplies, Pence was informed that the rest of the boxes in the van were empty and that his task was complete. "Well, can I carry the empty ones? Just for the cameras?" Pence joked. "Absolutely," an aide said as the group laughed. Pence then shuts the doors to the van and returns to talk to facility members from the nursing home. Question answered: Were the PPE boxes that Mike Pence delivered empty?

Evidence: Kris tells the magazine Caitlyn was "miserable" and "pissed off" during the last years of their marriage. Question answered:

Figure 4: Example prompt used to generate a question for the evidence line *"Kris tells the magazine Caitlyn was "miserable" and "pissed off" during the last years of their marriage."*.

### E.3 Justification Generation

For the justification generation model, we used the BART-large model [Lewis et al., 2020]. As previously we relied on the huggingface implementation [Wolf et al., 2020]. BART-large has 406M parameters. We finetuned the model using Adam [Kingma and Ba, 2015] with a learning rate of $0.001$ and a batch size of 128. When generating, we used beam search with 2 beams and a maximum generation length of $100$ tokens.

## F Dataset statistics

To analyse our dataset, we computed various statistics for each dataset split. An overview of modalities in which evidence was found can be seen in Table 5. Statistics for claim type and fact-checker strategy can be found in Tables and respectively.

Annotators rely on evidence from a wide variety of different sources, taking evidence from a total of 2989 different domains. Interestingly, the most frequent is twitter.com (3%), typically representing announcements from public officials. This is followed by africacheck.org (2.5%), as Africa Check relies to a greater extent on references to its own past articles. After this follow official sources (e.g. cdc.gov (1.5%), who.int (1.3%), gov.uk (0.7%), wikipedia.org (1.4%)) and news media (e.g. nytimes.com (1.1%), washingtonpost.com (0.7%), and reuters.com (0.6%). An interesting occurrence is a small number of non-textual sources, e.g. youtube.com (0.8%).

## G ChatGPT Prompts

For the prompt used for our gpt-3.5-turbo experiments, see Figure 6.



Bằng chứng: Hình ảnh bìa tạp chí Time với Rachel Levine là phụ nữ của năm đã được đăng trên Facebook bởi "The United Spot", được gắn nhãn là một trang web châm biếm. Câu hỏi được trả lời: Trang web nào nói rằng Rachel Levine là Phụ nữ của năm của Time?

Bằng chứng: Có, bởi vì cách diễn đạt thực sự là "hoàn thành 57 đập thủy điện khổng lồ". Câu hỏi được trả lời: Vào năm 2017, liệu bản tuyên ngôn của Chính phủ Kenya có nói họ sẽ xây dựng 57 đập thủy điện khổng lồ không?

Bằng chứng: Không, bởi vì bài blog sử dụng thuật ngữ về tương lai như '...the bill is being brought in...' và '...this NZ food bill will pave the way...'. Câu hỏi đã được trả lời: Bài blog có ngụ ý rằng Dự luật Thực phẩm này đã là luật không?

...

Bằng chứng: Trung Quốc mô tả các báo cáo từ Pakistan là "Vô căn cứ & giả mạo". Câu hỏi được trả lời: Trung Quốc có báo cáo bất kỳ tổn thất nào liên quan đến cuộc đụng độ này không?

Bằng chứng: Sau khi mang vài chiếc hộp trông có vẻ đầy vật tư, Pence được thông báo rằng phần còn lại của các hộp trong xe tải đều trống và nhiệm vụ của ông đã hoàn thành. "Vậy, tôi có thể mang những hộp trống không? Chỉ để cho máy quay thôi?" Pence đùa. "Chắc chắn rồi," một trợ lý nói khi cả nhóm cười. Sau đó, Pence đóng cửa xe tải và quay lại nói chuyện với các thành viên tại cơ sở chăm sóc người già. Câu hỏi được trả lời: Liệu các hộp PPE mà Mike Pence giao có trống không?

Bằng chứng: Kris nói với tạp chí rằng Caitlyn đã 'khổ sở' và 'tức giận' trong những năm cuối cùng của cuộc hôn nhân của họ. Câu hỏi đã được trả lời:

*Hình 4: Ví dụ về lời nhắc được sử dụng để tạo câu hỏi cho dòng chứng cứ "Kris nói với tạp chí rằng Caitlyn đã 'khổ sở' và 'tức giận' trong những năm cuối của cuộc hôn nhân của họ.".*

### E.3 Tạo lập Lý do

Đối với mô hình tạo lý do, chúng tôi đã sử dụng mô hình BART-large [Lewis và cộng sự, 2020]. Như trước đây, chúng tôi dựa vào triển khai của huggingface [Wolf và cộng sự, 2020]. BART-large có 406 triệu tham số. Chúng tôi đã tinh chỉnh mô hình sử dụng Adam [Kingma và Ba, 2015] với tốc độ học 0,001 và kích thước lô 128. Khi sinh, chúng tôi sử dụng tìm kiếm beam với 2 beam và độ dài sinh tối đa là 100 token.

## Thống kê bộ dữ liệu F

Để phân tích bộ dữ liệu của chúng tôi, chúng tôi đã tính toán các thống kê khác nhau cho mỗi phần dữ liệu. Một cái nhìn tổng quan về các phương thức mà bằng chứng được tìm thấy có thể được thấy trong Bảng 5. Thống kê về loại tuyên bố và chiến lược kiểm chứng sự thật có thể được tìm thấy trong các Bảng và tương ứng.

Các nhà chú giải dựa vào bằng chứng từ nhiều nguồn khác nhau, tổng cộng từ 2989 lĩnh vực khác nhau. Thú vị là nguồn phổ biến nhất là twitter.com (3%), thường đại diện cho các thông báo từ các quan chức công. Tiếp theo là africacheck.org (2,5%), vì Africa Check dựa nhiều hơn vào các tham chiếu đến các bài viết trước của chính họ. Sau đó là các nguồn chính thức (ví dụ: cdc.gov (1,5%), who.int (1,3%), gov.uk (0,7%), wikipedia.org (1,4%)) và các phương tiện truyền thông (ví dụ: nytimes.com (1,1%), washingtonpost.com (0,7%), và reuters.com (0,6%). Một hiện tượng thú vị là một số lượng nhỏ các nguồn phi văn bản, ví dụ: youtube.com (0,8%).

## G Các Lời Nhắc ChatGPT

Đối với lời nhắc được sử dụng trong các thí nghiệm gpt-3.5-turbo của chúng tôi, xem Hình 6.

Claim: A married couple in Florida, Tito and Amanda Watts, was arrested for selling fake golden tickets to heaven to hundreds of people.
Our verdict: Refuted.
Our reasoning: The answer and source clearly explain that it was an April Fool's joke so the claim is refuted.

Claim: North Korea blew up the office used for South Korea talks.
Our verdict: Supported.
Our reasoning: The building used was indeed destroyed.

...

Claim: US President Trump called for reduced funding for the Centre for Disease Control and Prevention.
Our verdict: Supported.
Our reasoning: From the source, I saw tangible evidence where it stated that there was a proposal by US President Trump to slash more than $1.2 billion of CDC's budget.

Claim: It is illegal for mayors to even bring up gun reform for discussion in Florida, US.
Our verdict: Conflicting Evidence/Cherrypicking.
Our reasoning:

Figure 5: Example prompt used to generate a justification for the claim *"It is illegal for mayors to even bring up gun reform for discussion in Florida, US."*. Evidence and verdict for the claim are produced in previous stages of the pipeline.

| | Train | Dev | Test |
|---|---|---|---|
| Web text: | 68.2 | 75.5 | 74.9 |
| PDF: | 11.9 | 7.7 | 9.7 |
| Metadata: | 6.1 | 5.9 | 5.0 |
| Web table: | 4.9 | 3.0 | 2.9 |
| Video: | 1.1 | 1.1 | 1.9 |
| Image/graphic: | 2.0 | 2.7 | 1.6 |
| Audio: | 0.1 | 0.0 | 0.8 |
| Other: | 1.3 | 1.4 | 0.2 |
| Unanswerable: | 4.5 | 2.8 | 3.0 |

Table 5: Evidence modalities (%)

Can you fact-check a claim for me? Classify the given claim into four labels: "true", "false", "not enough evidence" or "conflicting evidence/cherrypicking". Let's think step by step. Provide justification before giving the label. Given claim:

It is illegal for mayors to even bring up gun reform for discussion in Florida, US.

Figure 6: Prompt used to generate evidence and verdicts with ChatGPT for the example claim *"It is illegal for mayors to even bring up gun reform for discussion in Florida, US."*.



Khẳng định: Một cặp vợ chồng ở Florida, Tito và Amanda Watts, đã bị bắt vì bán hàng giả vé vàng lên thiên đường cho hàng trăm người.
Phán quyết của chúng tôi: Bị bác bỏ.
Lý do của chúng tôi: Câu trả lời và nguồn rõ ràng giải thích rằng đó là một trò đùa ngày Cá tháng Tư nên yêu cầu bị bác bỏ .

Khẳng định: Triều Tiên đã phá hủy văn phòng được sử dụng cho các cuộc đàm phán với Hàn Quốc.
Phán quyết của chúng tôi: Hỗ trợ.
Lập luận của chúng tôi: Tòa nhà đã được sử dụng thực sự đã bị phá hủy.

...

Yêu cầu: Tổng thống Mỹ Trump kêu gọi giảm kinh phí cho Trung tâm Kiểm soát Dịch bệnh và Phòng ngừa.
Phán quyết của chúng tôi: Hỗ trợ.
Lý luận của chúng tôi: Từ nguồn, tôi đã thấy bằng chứng cụ thể nơi nó ghi rằng đã có một đề xuất của Tổng thống Mỹ Trump cắt giảm hơn 1,2 tỷ đô la ngân sách của CDC.

Khẳng định: Ở Florida, Mỹ, việc các thị trưởng thậm chí đề cập đến cải cách súng để thảo luận là bất hợp pháp.
Phán quyết của chúng tôi: Bằng chứng mâu thuẫn/Chọn lọc thông tin.
Lý do của chúng tôi:

Hình 5: Ví dụ về lời nhắc được sử dụng để tạo lý do biện minh cho khẳng định "Ở Florida, Mỹ, các thị trưởng thậm chí còn không được phép đưa ra thảo luận về cải cách súng đạn." Bằng chứng và phán quyết cho khẳng định này đã được tạo ra trong các giai đoạn trước của quy trình.

| | Tàu | Dev | Test |
|---|---|---|---|
| Văn bản web: | 68.2 | 75.5 | 74.9 |
| PDF: | 11.9 | 7.7 | 9.7 |
| Siêu dữ liệu: | 6.1 | 5.9 | 5.0 |
| Bảng web: | 4.9 | 3.0 | 2.9 |
| Video: | 1.1 | 1.1 | 1.9 |
| Hình ảnh/đồ họa: | 2.0 | 2.7 | 1.6 |
| Âm thanh: | 0.1 | 0.0 | 0.8 |
| Khác: | 1.3 | 1.4 | 0.2 |
| Không thể trả lời: | 4.5 | 2.8 | 3.0 |

Bảng 5: Các phương thức bằng chứng (%)

Bạn có thể kiểm tra tính xác thực của một tuyên bố cho tôi không? Phân loại tuyên bố đã cho thành bốn nhãn: "đúng", "sai", "chưa đủ bằng chứng" hoặc "bằng chứng mâu thuẫn/chọn lọc". Hãy suy nghĩ từng bước. Cung cấp lý do trước khi đưa ra nhãn. Tuyên bố được đưa ra:

Ở Florida, Mỹ, việc các thị trưởng đề cập đến cải cách súng để thảo luận là bất hợp pháp.

Hình 6: Lời nhắc được sử dụng để tạo bằng chứng và phán quyết với ChatGPT cho ví dụ về tuyên bố "Ở Florida, Mỹ, các thị trưởng thậm chí không được phép đưa vấn đề cải cách súng đạn ra thảo luận."

| | Train | Dev | Test |
|---|---|---|---|
| Position Statement | 7.8 | 5.8 | 7.0 |
| Numerical Claim | 33.7 | 23.8 | 21.8 |
| Event/Property Claim | 57.8 | 61.4 | 69.8 |
| Quote Verification | 9.6 | 13.8 | 7.7 |
| Causal Claim | 11.5 | 10.8 | 11.9 |

Table 6: Claim types (%)

| | Train | Dev | Test |
|---|---|---|---|
| Written Evidence | 78.8 | 88.6 | 88.0 |
| Numerical Comparison | 30.6 | 19.0 | 19.2 |
| Fact-checker Reference | 6.6 | 7.4 | 7.7 |
| Expert Consultation | 29.9 | 27.4 | 29.6 |
| Satirical Source | 3.6 | 2.0 | 1.8 |

Table 7: Fact-checker strategies (%)

# H Additional Results

## H.1 Claim type

We computed baseline performance in terms of veracity at different evidence thresholds for each claim type. Results can be seen in Table 9 below:

# I Data Statement

Following Bender and Friedman [2018], we include a data statement describing the characteristics of AVERITEC.

## I.1 Curation Rationale

We processed a total of 8,000 texts from the Google FactCheck Claim Search API, which collects English-language articles from fact-checking organizations around the world. We selected claims in the two-year interval between 1/1/2022 and 1/1/2020. Within that span, we selected all claims marked *true* by fact-checking organizations, as well as a random selection of other claims; this was done to reduce the label imbalance as much as possible.

We discarded claims in several rounds. First, any duplicate claims were discarded using string matching. Then, annotators discarded paywalled claims, as well as claims about or requiring evidence from modalities beyond text. Finally, we discarded any claim for which agreement on a label could not be found after two rounds of annotation.

## I.2 Language variety

We include data from 50 different fact-checking organizations around the world. While our data is exclusively English, the editing standards used at different publications differ. As such, several varieties of news domain English should be expected; given the distribution of fact-checkers involved, these will be dominated by *en-US*, *en-IN*, *en-GB*, and *en-ZA*.

## I.3 Speaker demographics

We did not analyse the demographics of the individual speakers for each claim. However, we asked annotators to specify the location most relevant to the claims. The distribution can be seen in Table 10.



| | Tàu | Dev | Test |
|---|---|---|---|
| Tuyên bố quan điểm | 7.8 | 5.8 | 7.0 |
| Yêu cầu số | 33.7 | 23.8 | 21.8 |
| Yêu cầu sự kiện/tài sản | 57.8 | 61.4 | 69.8 |
| Xác minh trích dẫn | 9.6 | 13.8 | 7.7 |
| Khẳng định nhân quả | 11.5 | 10.8 | 11.9 |

Bảng 6: Các loại yêu cầu (%)

| | Tàu | Dev | Test |
|---|---|---|---|
| Bằng chứng viết | 78.8 | 88.6 | 88.0 |
| So sánh số học | 30.6 | 19.0 | 19.2 |
| Nguồn tham khảo kiểm chứng sự thật | 6.6 | 7.4 | 7.7 |
| Tư vấn chuyên gia | 29.9 | 27.4 | 29.6 |
| Nguồn châm biếm | 3.6 | 2.0 | 1.8 |

Bảng 7: Chiến lược của người kiểm tra sự t
hật (%)

# H Kết quả bổ sung

## H.1 Loại yêu cầu

Chúng tôi đã tính toán hiệu suất cơ bản về độ xác thực tại các ngưỡng bằng chứng khác nhau cho từng loại tuyên bố. Kết quả có thể được thấy trong Bảng 9 dưới đây:

**Tuyên bố dữ liệu của
tôi**

Theo Bender và Friedman [2018], , chúng tôi bao gồm một tuyên bố dữ liệu mô tả các đặc điểm của AVERITEC.

## I.1 Lý do chọn lọc

Chúng tôi đã xử lý tổng cộng 8.000 văn bản từ Google FactCheck Claim Search API, dịch vụ thu thập các bài viết bằng tiếng Anh từ các tổ chức kiểm tra thực tế trên toàn thế giới. Chúng tôi đã chọn các tuyên bố trong khoảng thời gian hai năm từ 1/1/2020 đến 1/1/2022. Trong khoảng thời gian đó, chúng tôi đã chọn tất cả các tuyên bố được các tổ chức kiểm tra thực tế đánh dấu là đúng, cũng như một lựa chọn ngẫu nhiên từ các tuyên bố khác; việc này được thực hiện để giảm thiểu sự mất cân bằng nhãn càng nhiều càng tốt.

Chúng tôi đã loại bỏ các tuyên bố trong nhiều vòng. Đầu tiên, bất kỳ tuyên bố trùng lặp nào được loại bỏ bằng cách so khớp chuỗi. Sau đó, các người chú thích đã loại bỏ các tuyên bố bị khóa bởi phí, cũng như các tuyên bố về hoặc yêu cầu bằng chứng từ các phương thức ngoài văn bản. Cuối cùng, chúng tôi loại bỏ bất kỳ tuyên bố nào mà không thể đạt được sự đồng thuận về nhãn sau hai vòng chú thích.

## I.2 Phong cách ngôn ngữ

Chúng tôi bao gồm dữ liệu từ 50 tổ chức kiểm chứng thông tin khác nhau trên toàn thế giới. Mặc dù dữ liệu của chúng tôi hoàn toàn bằng tiếng Anh, các tiêu chuẩn chỉnh sửa được sử dụng tại các ấn phẩm khác nhau có sự khác biệt. Do đó, nên mong đợi nhiều biến thể tiếng Anh trong lĩnh vực tin tức; với sự phân bố của các tổ chức kiểm chứng tham gia, những biến thể này sẽ chủ yếu là en-US, en-IN, en-GB và en-ZA.

**I.3 Thông tin nhân khẩu học của
người nói**

Chúng tôi đã không phân tích nhân khẩu học của từng người nói cho mỗi lập luận. Tuy nhiên, chúng tôi đã yêu cầu những người nhận xét chỉ định vị trí có liên quan nhất đến các lập luận. Phân bố có thể được thấy trong Bảng 10.

| | Fraction of claims |
|---|---|
| africacheck.org: | 0.154 |
| politifact.com: | 0.153 |
| leadstories.com: | 0.096 |
| fullfact.org: | 0.068 |
| factcheck.afp.com: | 0.062 |
| factcheck.org: | 0.050 |
| checkyourfact.com: | 0.041 |
| misbar.com: | 0.032 |
| washingtonpost.com: | 0.029 |
| boomlive.in: | 0.026 |
| dubawa.org: | 0.023 |
| polygraph.info: | 0.020 |
| usatoday.com: | 0.019 |
| altnews.in: | 0.019 |
| indiatoday.in: | 0.019 |
| newsmeter.in: | 0.018 |
| newsmobile.in: | 0.015 |
| factly.in: | 0.015 |
| vishvasnews.com: | 0.015 |
| aap.com.au: | 0.014 |
| thelogicalindian.com: | 0.013 |
| verafiles.org: | 0.011 |
| nytimes.com: | 0.011 |
| healthfeedback.org: | 0.011 |
| thequint.com: | 0.008 |
| newsweek.com: | 0.005 |
| icirnigeria.org: | 0.005 |
| bbc.co.uk: | 0.004 |
| factcheck.thedispatch.com: | 0.004 |
| ghanafact.com: | 0.003 |
| factcheckni.org: | 0.003 |
| theferret.scot: | 0.003 |
| rappler.com: | 0.003 |
| covid19facts.ca: | 0.003 |
| newsmobile.in:80: | 0.002 |
| thegazette.com: | 0.002 |
| abc.net.au: | 0.002 |
| ha-asia.com: | 0.002 |
| sciencefeedback.co: | 0.001 |
| cbsnews.com: | 0.001 |
| fit.thequint.com: | 0.001 |
| namibiafactcheck.org.na: | 0.001 |
| thejournal.ie: | 0.001 |
| poynter.org: | 0.001 |
| zimfact.org: | 0.001 |
| climatefeedback.org: | 0.001 |
| factchecker.in: | 0.001 |
| pesacheck.org: | 0.001 |
| ghana.dubawa.org: | 0.001 |
| scroll.in: | 0.001 |

Table 8: Fact-checking sites used

| | $\lambda = 0.2$ | $\lambda = 0.3$ |
|---|---|---|
| Quote Verification | .13 | 0.7 |
| Numerical Claim | .17 | .10 |
| Event/Property Claim | .13 | .06 |
| Causal Claim | .11 | .04 |
| Position Statement | .10 | .04 |

Table 9: Baseline performance on each claim type, computed with two different evidence standards.

### I.4 Annotator demographics

For this dataset, we relied on the company *Appen* to provide annotators. Although the company itself is headquartered in Australia, demographic details regarding location or nationality of the annotators



| | Phần các khiếu nại |
|---|---|
| africacheck.org: | 0.154 |
| politifact.com: | 0.153 |
| leadstories.com: | 0.096 |
| fullfact.org: | 0.068 |
| factcheck.afp.com: | 0.062 |
| factcheck.org: | 0.050 |
| checkyourfact.com: | 0.041 |
| misbar.com: | 0.032 |
| washingtonpost.com: | 0.029 |
| boomlive.in: | 0.026 |
| dubawa.org: | 0.023 |
| polygraph.info: | 0.020 |
| usatoday.com: | 0.019 |
| altnews.in: | 0.019 |
| indiatoday.in: | 0.019 |
| newsmeter.in: | 0.018 |
| newsmobile.in: | 0.015 |
| factly.in: | 0.015 |
| vishvasnews.com: | 0.015 |
| aap.com.au: | 0.014 |
| thelogicalindian.com: | 0.013 |
| verafiles.org: | 0.011 |
| nytimes.com: | 0.011 |
| healthfeedback.org: | 0.011 |
| thequint.com: | 0.008 |
| newsweek.com: | 0.005 |
| icirnigeria.org: | 0.005 |
| bbc.co.uk: | 0.004 |
| factcheck.thedispatch.com: | 0.004 |
| ghanafact.com: | 0.003 |
| factcheckni.org: | 0.003 |
| theferret.scot: | 0.003 |
| rappler.com: | 0.003 |
| covid19facts.ca: | 0.003 |
| newsmobile.in:80: | 0.002 |
| thegazette.com: | 0.002 |
| abc.net.au: | 0.002 |
| ha-asia.com: | 0.002 |
| sciencefeedback.co: | 0.001 |
| cbsnews.com: | 0.001 |
| fit.thequint.com: | 0.001 |
| namibiafactcheck.org.na: | 0.001 |
| thejournal.ie: | 0.001 |
| poynter.org: | 0.001 |
| zimfact.org: | 0.001 |
| climatefeedback.org: | 0.001 |
| factchecker.in: | 0.001 |
| pesacheck.org: | 0.001 |
| ghana.dubawa.org: | 0.001 |
| cuộn.in: | 0.001 |

Bảng 8: Các trang web kiểm chứng thông tin được sử dụng

| | $\lambda = 0.2$ | $\lambda = 0.3$ |
|---|---|---|
| Xác minh trích dẫn | .13 | 0.7 |
| Yêu cầu số | .17 | .10 |
| Yêu cầu sự kiện/tài sản | .13 | .06 |
| Khẳng định nhân quả | .11 | .04 |
| Tuyên bố quan điểm | .10 | .04 |

Tabl Hình 9: Hiệu suất cơ bản trên từng loại tuyên bố, được tính bằng hai tiêu chuẩn chứng cứ khác nhau s.

**I.4 Thống kê nhân khẩu học của người chú thích**

Đối với tập dữ liệu này, chúng tôi đã dựa vào công ty Appen để cung cấp những người chú thích. Mặc dù công ty này có trụ sở chính tại Úc, nhưng các chi tiết về nhân khẩu học liên quan đến vị trí hoặc quốc tịch của những người chú thích

| Country code | Count |
|---|---|
| US: | 1937 |
| IN: | 536 |
| GB: | 305 |
| KE: | 293 |
| NG: | 280 |
| ZA: | 191 |
| PH: | 73 |
| AU: | 56 |
| CN: | 55 |
| RU: | 38 |
| CA: | 31 |
| NZ: | 23 |
| GH: | 17 |
| IE: | 17 |
| LK: | 14 |
| TH: | 12 |
| FR: | 12 |
| PK: | 12 |
| IL: | 11 |
| IT: | 10 |
| DE: | 8 |
| ZW: | 7 |
| HK: | 7 |
| MM: | 6 |
| BR: | 6 |
| UA: | 6 |
| KR: | 5 |
| JP: | 5 |
| KP: | 5 |
| PL: | 5 |
| None: | 501 |

Table 10: Count of locations appearing in our dataset. All countries are listed using ISO country codes. Countries with fewer than five occurences are excluded – we will provide this data upon request.

were unfortunately not shared with us. We employed a total of 25 annotators with an average age of 42, and a gender split of 64% women and 36% men.

### I.5 Speech situation

The original claims were uttered in a variety of situations. We did not track this statistic for the entire dataset. However, analyzing a randomly selected 20 claims from our dataset, the majority (11) are social media posts. 4 originate from public speeches by politicians, 3 from newspaper articles, 1 from a political candidate's website, and 1 from a viral YouTube video.

The claims were all chosen by fact-checking organizations for analysis, and presented in a journalistic format on their websites.

### I.6 Text characteristics

We compute various statistics for the text included in this dataset; see Section 5 and Appendix F. The genre is a mix of political statements, social media posts, and news articles (see the previous subsection).



| Mã quốc gia | Đếm |
|---|---|
| US: | 1937 |
| IN: | 536 |
| GB: | 305 |
| KE: | 293 |
| NG: | 280 |
| ZA: | 191 |
| PH: | 73 |
| AU: | 56 |
| CN: | 55 |
| RU: | 38 |
| CA: | 31 |
| NZ: | 23 |
| GH: | 17 |
| IE: | 17 |
| LK: | 14 |
| TH: | 12 |
| FR: | 12 |
| PK: | 12 |
| IL: | 11 |
| IT: | 10 |
| DE: | 8 |
| ZW: | 7 |
| HK: | 7 |
| MM: | 6 |
| BR: | 6 |
| UA: | 6 |
| KR: | 5 |
| JP: | 5 |
| KP: | 5 |
| PL: | 5 |
| Không có: | 501 |

Bảng 10: Số lượng địa điểm xuất hiện trong bộ dữ liệu của chúng tôi. Tất cả các quốc gia được liệt kê theo mã quốc gia ISO. Các quốc gia có ít hơn năm lần xuất hiện sẽ bị loại trừ – chúng tôi sẽ cung cấp dữ liệu này khi được yêu cầu.

rất tiếc là không được chia sẻ với chúng tôi. Chúng tôi đã sử dụng tổng cộng 25 người chú thích với độ tuổi trung bình là 42, và tỉ lệ giới tính là 64% nữ và 36% nam.

#### I.5 Tình huống giao tiếp

Những tuyên bố gốc đã được phát ra trong nhiều tình huống khác nhau. Chúng tôi đã không theo dõi thống kê này c ho toàn bộ bộ dữ liệu. Tuy nhiên, khi phân tích 20 tuyên bố được chọn ngẫu nhiên từ bộ dữ liệu của chúng tôi, phần lớn (11) là các bài đăng trên mạng xã hội. 4 xuất phát từ các bài phát biểu công khai của các chính trị gia, 3 từ các bài báo, 1 từ trang web của một ứng cử viên chính trị, và 1 từ một video YouTube lan truyền.

Các tuyên bố đều được các tổ chức kiểm tra sự thật chọn để phân tích và được trình bày theo định dạng báo chí trên các trang web của họ.

#### I.6 Đặc điểm văn bản

Chúng tôi tính toán nhiều thống kê khác nhau cho văn bản được bao gồm trong bộ dữ liệu này; xem Mục 5 và Phụ lục F. Thể loại là sự kết hợp của các tuyên bố chính trị, bài đăng trên mạng xã hội và bài báo (xem phần trước).

# J Annotation Guidelines

## J.1 Introduction

We aim to construct a dataset for automated fact-checking with the following guiding principles. First, we intend to decompose the evidence retrieval process into multiple steps, annotating each individual step as a question-answer pair (see Figure 2). Second, our dataset will be constructed from real-world claims previously checked by journalistic organisations, rather than the artificially created claims used in prior work.

Decomposing claim verification into generations and answering questions allows us to break complex real-world claims down to their components, simplifying the task. For example, in Figure 2, verifying the claim requires knowing the salary of the health commissioner, the governor, the vice president, and Dr. Fauci, so that they can be compared. Four separate questions about salary need to be asked in order to reach a verdict (i.e. that the claim is *supported*).

By decomposing the evidence retrieval process in this way, we also produce a natural way for systems to justify their verdicts and explain their reasoning to users. In addition to this, we annotate claims with a final justification, providing a textual explanation of how to combine the retrieved answers to reach a verdict. This allows users to follow each step of the retrieval and verification processes, and so understand the reasoning employed by the system.

***Claim:*** **Biden lead disappears in NV, AZ, GA, PA on 11 November 2020.**

***Q1: Which media project Biden will win in Nevada?***
***A1:*** ABC News, CBS News, NBC News, CNN, Fox News, Decision Desk HQ, Associated Press, Reuters, and New York Times.

***Q2: Which media project Biden will win in Arizona?***
***A2:*** Fox News and Associated Pre.

***Q3: Which media project Biden will win in Georgia?***
***A3:*** None.

***Q4: Which media project Biden will win in Pennsylvania?***
***A4:*** ABC News, CBS News, NBC News, CNN, Fox News, Decision Desk HQ, Associated Press, Reuters, and New York Times.

***Verdict:*** **Refuted**
***Justification:*** **Many media organizations believe Biden will win in NV, AZ, and PA. As such, his lead has not disappeared.**

Figure 7: Example claim and question-answer pairs.

The annotation consists of the following three phases:

1. Claim Normalization.
2. Question Generation.
3. Quality Control.

Each claim should be annotated by different annotators in each phase. An annotator can participate *in* in all three phases, but they will be assigned different claims.



## Hướng dẫn chú thích J

### J.1 Giới thiệu

Chúng tôi nhằm mục đích xây dựng một bộ dữ liệu để kiểm tra sự thật tự động với các nguyên tắc hướng dẫn sau. Thứ nhất, chúng tôi dự định phân tách quá trình thu thập bằng chứng thành nhiều bước, chú thích từng bước riêng lẻ dưới dạng cặp câu hỏi-trả lời (xem Hình 2). Thứ hai, bộ dữ liệu của chúng tôi sẽ được xây dựng t ừ các tuyên bố thực tế đã được các tổ chức báo chí kiểm tra trước đây, thay vì các tuyên bố được tạo ra một cách nhân tạo như trong các công trình trước.

Phân rã việc xác minh tuyên bố thành các thế hệ và trả lời các câu hỏi cho phép chúng ta chia các tuyên bố phức tạp trong thế giới thực thành các thành phần của chúng, làm đơn giản hóa nhiệm vụ. Ví dụ, trong Hình 2, việc xác minh tuyên bố đòi hỏi phải biết mức lương của ủy viên y tế, thống đốc, phó tổng thống và Tiến sĩ Fauci, để có thể so sánh chúng. Cần đặt bốn câu hỏi riêng biệt về mức lương để đưa ra một phán quyết (tức là tuyên bố được hỗ trợ).

Bằng cách phân tách quá trình truy xuất bằng chứng theo cách này, chúng tôi cũng tạo ra một phương thức t ự nhiên để các hệ thống biện minh cho phán quyết của mình và giải thích lý luận của chúng cho người dùng. Ngoài ra, chúng tôi chú thích các khẳng định với một lý do cuối cùng, cung cấp giải thích bằng văn bản về cách kết hợp các câu trả lời đã truy xuất để đưa ra phán quyết. Điều này cho phép người dùng theo dõi từng bước của quá trình truy xuất và xác minh, từ đó hiểu được lý luận mà hệ thống đã sử dụng.

**Khẳng định: Lợi thế dẫn đầu của Biden biến mất ở NV, AZ, GA, PA vào ngày 11 tháng 11 năm 2020.**

***Q1: Phương tiện nào projBiden có sẽ thắng ở Nevada không?***
A1: ABC News, CBS News, NBC News, CNN, Fox News, Decision Desk HQ, Associated Press, Reuters và New York Times.

***Q2: Dự án truyền thông nào mà Biden sẽ thắng ở Arizona? A2: Fox News và Associated Press.***

***Câu 3: Dự án truyền thông nào mà Biden sẽ thắng ở Georgia? Câu 3: Không có.***

Q4: Biden sẽ thắng dự án truyền thông nào ở Pennsylvania? A4: ABC News, CBS News, NBC News, CNN, Fox News, Decision Desk HQ, Associated Press, Reuters, và New York Times.

***Phán quyết: Bác bỏ***
**Lý do: Nhiều tổ chức truyền thông tin rằng Biden sẽ thắng ở NV, AZ và PA. Do đó, vị trí dẫn đầu của ông chưa biến mất.**

Hình 7: Ví dụ về các cặp khẳng định và câu hỏi-trả lời.

Chú thích bao gồm ba giai đoạn sau:

1. Chuẩn hóa yêu cầu. 2.
Tạo câu hỏi. 3. Kiểm soát
chất lượng.

Mỗi tuyên bố nên được chú thích bởi các người chú thích khác nhau ở mỗi giai đoạn. Một người chú thích có thể tham gia vào cả ba giai đoạn, nhưng họ sẽ được giao các tuyên bố khác nhau.

**Warning!** Components of the AVeriTeC annotation tool may not render correctly in some browsers, specifically *Opera Mini*. If this is an issue we recommend trying another browser, e.g. Firefox, Chrome, Safari, or regular Opera.

### J.2 Sign In

Each annotator will have received an **ID** and a **Password** with the access link to the annotation server. The password can be changed after logging into the interface.

**Important!**

- Make sure to log out at the end of the session!
- Do not open multiple tabs/windows of the AVeriTeC annotation tool. Always use only one window during annotation! If you are logged into multiple sessions using the same account, the annotation tool may lose the data you enter.




Figure 8: Interface of the control panel. (1) Button for changing the password. (2) Button for logout. (3) Start the annotation for this phase. Here is Phase 1 Claim Normalization. (4) The left number shows how many claims have been annotated and the right number shows how many claims are assigned for the current annotator at this phase.

After clicking the **START NEXT** button, the annotation phase will start. If an annotator is new to the current phase, the interface will provide a guided tour as in Figure 9 for that phase. Please read the hints provided by the tour guide carefully before the annotation.

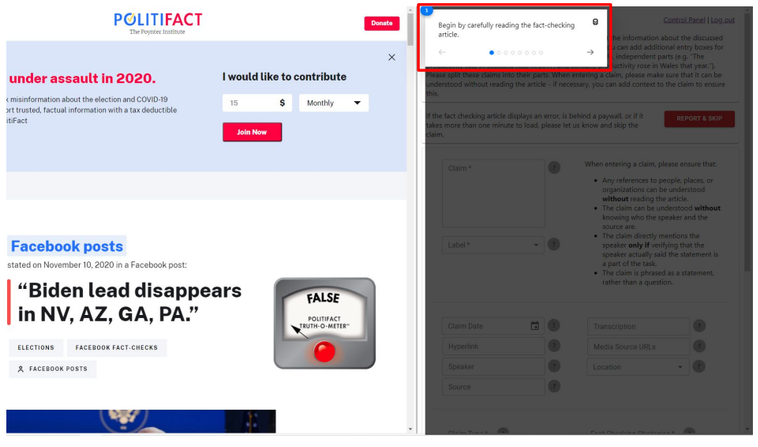



Figure 9: Interface of the tour guide.



Cảnh báo! Các thành phần của công cụ chú thích AVeriTeC có thể không hiển thị đúng trong một số trình duyệt, đặc biệt là Opera Mini. Nếu đây là một vấn đề, chúng tôi khuyên bạn nên thử một trình duyệt khác, ví dụ: Firefox, Chrome, Safari hoặc Opera thông thường.

**J.2 Đăng Nhập**

Mỗi người chú thích sẽ nhận được một ID và Mật khẩu cùng với liên kết truy cập vào máy chủ chú thích. Mật khẩu có thể được thay đổi sau khi đăng nhập vào giao diện.

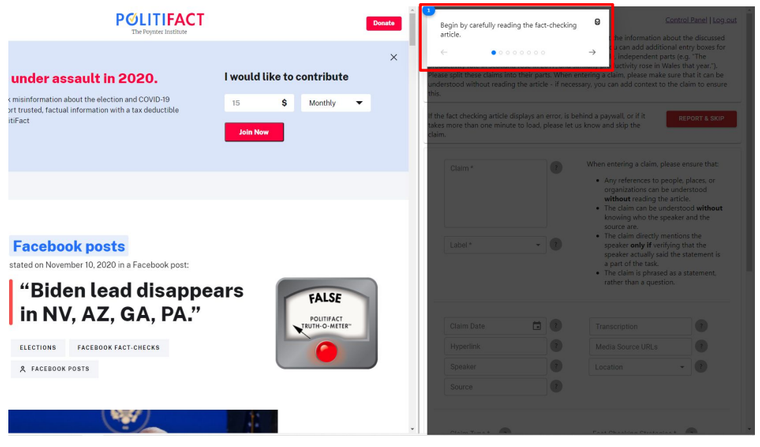
**Quan trọng!**

- Hãy chắc chắn đăng xuất vào cuối buổi làm việc!
- Không mở nhiều tab/cửa sổ của công cụ chú thích AVeriTeC. Luôn chỉ sử dụng một cửa sổ duy nhất trong quá trình chú thích! Nếu bạn đăng nhập vào nhiều phiên cùng một lúc bằng cùng một tài k hoản, công cụ chú thích có thể mất dữ liệu bạn đã nhập.




Hình 8: Giao diện bảng điều khiển. 1 Nút để đổi mật khẩu. 2 Nút để đăng xuất. 3 Bắt đầu chú thích cho giai đoạn này. Đây là Giai đoạn 1 Chuẩn hóa Yêu cầu. 4 Số bên trái hiển thị số yêu cầu đã được chú thích và số bên phải hiển thị số yêu cầu được phân công cho người chú thích hiện tại ở giai đoạn này.

Sau khi nhấp vào nút BẮT ĐẦU TIẾP THEO, giai đoạn chú thích sẽ bắt đầu. Nếu một người chú thích mới với giai đoạn hiện tại, giao diện sẽ cung cấp một hướng dẫn tham quan như trong Hình 9 cho giai đoạn đó. Vui lòng đọc kỹ các gợi ý do hướng dẫn viên cung cấp trước khi thực hiện chú thích.




Hình 9: Giao diện của hướng dẫn viên du lịc h.

## J.3 Phase 1: Claim Normalization

In the first phase, annotators collect metadata about the claims and produce a normalized version of each claim, as shown in Figure 10. The first step is to identify the claim(s) in the fact-checking article. Often, this can be found either in the headline or explicitly in some other place in the fact-checking article. In some cases, there may be a discrepancy between the article and the original claim (e.g. the original claim could be *"there are 30 days in March"*, while the fact-checking article might have the headline *"actually, there are 31 days in March"*). In those cases, it is important to use the *original* version of the claim. If there is ambiguity in the article over the exact wording of the claim, annotators should use their own judgment.

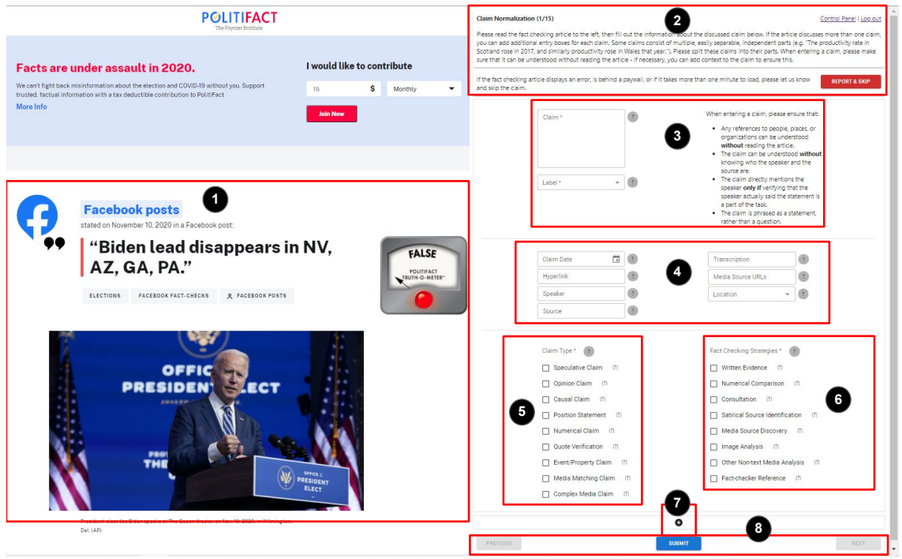



Figure 10: Interface of claim normalization. (1) The fact-checking article provided. (2) Guideline of annotation for this phase. Please read it before annotating. Notice that if the article displays a 404 page or another error, or if it takes more than one minute to load, please click the **REPORT & SKIP** button. (3) Fields for the normalized claim and the corresponding label. (4) General information of the claim. (5) Check-boxes for selecting the type of the claim. (6) Check-boxes for selecting the fact-checking strategy used. (7) Button for adding more claims. (8) Buttons for submitting the current claim, going to the previous claim, and the next claim.

### J.3.1 Overview

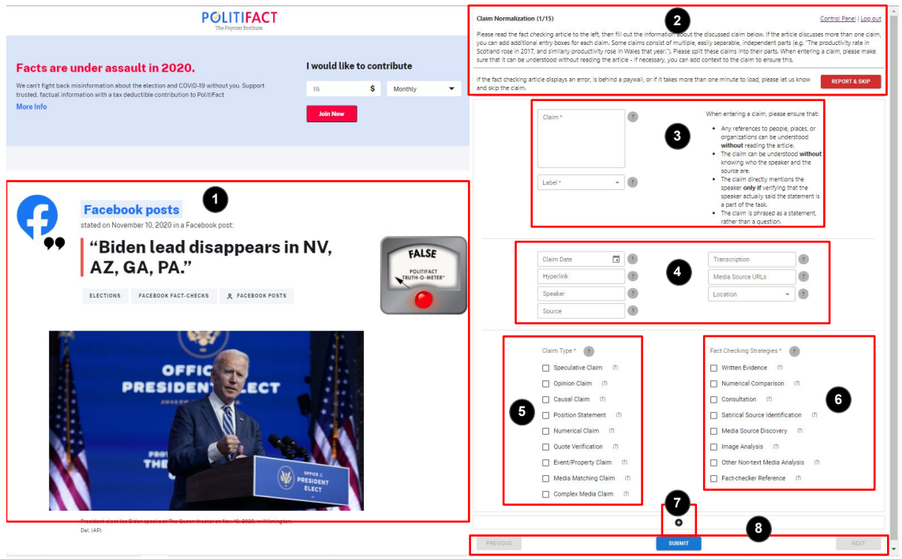
Here, we give a quick overview of the claim normalization task; an in-detail discussion can be found in subsequent sections. Further documentation can also be found on-the-fly using the tooltips in the annotation interface.

1. First, annotators should read the fact-checking article and identify which claims are being investigated.
2. If the fact-checking article is paywalled or inaccessible due to a 404-page or a similar error message, annotators should report this and skip the claim using the provided button. We warn that some fact-checking articles can take too long to load – as such, while fact-checking articles that do not load at all should be skipped, we ask annotators to wait for at least one minute before skipping an article while it is still trying to load.



## J.3 Giai đoạn 1: Chuẩn hóa Yêu cầu

Trong giai đoạn đầu tiên, các người chú thích thu thập siêu dữ liệu về các tuyên bố và tạo ra một phiên bản chuẩn hóa của mỗi tuyên bố, như được minh họa trong Hình 10. Bước đầu tiên là xác định tuyên bố trong bài viết kiểm chứng sự thật. Thường thì điều này có thể tìm thấy ở tiêu đề hoặc được nêu rõ ràng ở một vị trí khác trong bài viết kiểm chứng sự thật. Trong một số trường hợp, có thể có sự khác biệt giữa bài viết và tuyên bố gốc (ví dụ: tuyên bố gốc có thể là "tháng Ba có 30 ngày", trong khi bài viết kiểm chứng sự thật có tiêu đề "thực ra, tháng Ba có 31 ngày"). Trong những trường hợp đó, điều quan trọng là sử dụng phiên bản gốc của tuyên bố. Nếu có sự mơ hồ trong bài viết về cách diễn đạt chính xác của tuyên bố, các người chú thích nên sử dụng phán đoán của riêng họ.




Hình 10: Giao diện chuẩn hóa tuyên bố. 1 Bài báo kiểm chứng sự kiện được cung cấp. 2 Hướng dẫn chú thích cho giai đoạn này. Vui lòng đọc trước khi chú thích. Lưu ý rằng nếu bài báo hiển thị trang 404 hoặc lỗi khác, hoặc nếu mất hơn một phút để tải, vui lòng nhấn nút BÁO CÁO & BỎ QUA. 3 Các trường cho tuyên bố đã chuẩn hóa và nhãn tương ứng. 4 Thông tin chung về tuyên bố. 5 Hộp kiểm để chọn loại tuyên bố. 6 Hộp kiểm để chọn chiến lược kiểm chứng sự kiện được sử dụng. 7 Nút để thêm nhiều tuyên bố hơn. 8 Các nút để gửi tuyên bố hiện tại, đi tới tuyên bố trước và tuyên bố tiếp theo.

### J.3.1 Tổng quan

Ở đây, chúng tôi đưa ra tổng quan nhanh về nhiệm vụ chuẩn hóa tuyên bố; một cuộc thảo luận chi tiết có thể được tìm thấy trong các phần tiếp theo. Tài liệu bổ sung cũng có thể được tìm thấy ngay lập tức bằng cách sử dụng các chú giải công cụ trong giao diện chú thích.

1. Trước tiên, những người chú thích nên đọc bài viết kiểm chứng thông tin và xác định những tuyên bố nào đang được điều tra. 2. Nếu bài viết kiểm chứng thông tin bị trả phí hoặc không truy cập được do lỗi trang 404 hoặc thông báo lỗi tương tự, những người chú thích nên báo cáo việc này và bỏ qua tuyên bố bằng cách sử dụng nút được cung cấp. Chúng tôi cảnh báo rằng một số bài viết kiểm chứng thông ti n có thể mất quá nhiều thời gian để tải – do đó, trong khi những bài viết kiểm chứng thông tin không t ải được hoàn toàn nên được bỏ qua, chúng tôi yêu cầu những người chú thích chờ ít nhất một phút trước khi bỏ qua một bài viết trong khi nó vẫn đang cố gắng tải.

3. Most articles focus on one claim. However, some articles investigate multiple claims, or claims with multiple parts – in those cases, annotators should first split these into their parts (see Section J.3.2).
4. Some claims cannot be understood without the context of the fact-checking article, e.g. because they refer to entities not mentioned by name in the claim. In those cases, annotators should add context to the claims (see Section J.3.3).
5. Generally, we prefer claims to be as close as possible to their original form (i.e. the form originally said, *not* the form used in the fact-checking article). As such, contextualization should be done only when necessary, following the checklist in Section J.3.3.
6. Annotators should extract the verdict assigned to the claim in the article and translate it as closely as possible to one of our four labels – *supported*, *refuted*, *not enough evidence*, or *conflicting evidence/cherry picking* (see Section J.3.4). In phase one, annotators should give their own judgments – rather, they should match as closely as possible the judgments given by the fact-checking articles.
7. Claims will have associated metadata, i.e. the date the original claim was made, or the name of the person who made it. Annotators should identify and extract this metadata from the article (see Section J.3.6).
8. Annotators should identify the type of each claim, choosing from the options described in Section J.3.8. These are not mutually exclusive, and more than one claim type can be chosen.
9. Annotators should identify the strategies used in the fact-checking article to verify each claim, choosing from the options described in Section J.3.9. These are not mutually exclusive, and more than one claim type can be chosen.

### J.3.2 Claim Splitting

Some claims consist of multiple, easily separable, independent parts (e.g. *"The productivity rate in Scotland rose in 2017, and similarly productivity rose in Wales that year."*). The first step is to split these compound claims into individual claims. Metadata collection and normalization will then be done independently for each individual claim, and in subsequent phases, they will be treated as separate claims.

When splitting a claim, it is important to ensure that each part is understandable without requiring the others as context. This can be done either by adding metadata in the appropriate field, such as the claimed speaker or claim date, or through rewriting. For example, for the claim *"Amazon is doing great damage to tax paying retailers. Towns, cities, and states throughout the U.S. are being hurt - many jobs being lost!"*, it should be clear what is causing job loss in the second part. A possible split would be *"Amazon is doing great damage to tax paying retailers"* and *"Towns, cities and states throughout the U.S. are being hurt by Amazon - many jobs being lost"*. That is, it is necessary to rewrite the second part by adding *Amazon* a second time in order for the second part to be understandable without context.

### J.3.3 Claim Contextualization

Some claims are not complete, which means they lack adequate contextualization to be verified. For example, in the claim *"We have 21 million unemployed young men and women."*, there are unresolved pronouns without which the claim cannot be verified (e.g. *we* refers to Nigeria, as the speaker of the claim is the presidential candidate of Nigeria). Another example is *"Israel already had 50% of its population vaccinated."* We need to know when this claim was made to verify its veracity, as time is crucial for this verification. For the latter, metadata is enough to resolve ambiguities; the former needs to be rewritten as *"Nigeria has 21 million unemployed young men and women."*

Annotators are asked to contextualize claims to the original post by gathering the necessary information. Some information can be included simply as metadata, but this is not always enough – for information not captured by metadata, we ask that the claim itself is rewritten to include said information. Annotators need to follow this checklist:

1. Is the claim referring to entities that can only be identified by reading the associated fact-checking article, even if all metadata is taken into consideration? If so, add the names of the



3. Hầu hết các bài báo tập trung vào một tuyên bố. Tuy nhiên, một số bài báo điều tra nhiều tuyên bố, hoặc những tuyên bố có nhiều phần – trong những trường hợp đó, người chú thích nên tách chúng thành các phần của chúng trước (xem Mục J.3.2). 4. Một số tuyên bố không thể hiểu được nếu không có bối cảnh của bài báo kiểm chứng thông tin, ví dụ vì chúng đề cập đến các thực thể không được nhắc tên trong tuyên bố. Trong những trường hợp đó, người chú thích nên thêm bối cảnh cho các tuyên bố (xem Mục J.3.3). 5. Nói chung, chúng tôi ưu tiên các tuyên bố càng gần với hình thức gốc của chúng càng tốt (tức là hình thức được nói ra ban đầu, không phải hình thức được sử dụng trong bài báo kiểm chứng thông tin). Do đó, việc tạo bối cảnh nên chỉ thực hiện khi cần thiết, theo danh sách kiểm tra trong Mục J.3.3. 6. Người chú thích nên trích xuất phán quyết được gán cho tuyên bố trong bài báo và dịch nó càng sát với một trong bốn nhãn của chúng tôi – được hỗ trợ, bị phản bác, không đủ bằng chứng, hoặc bằng chứng mâu thuẫn/lựa chọn có chủ ý (xem Mục J.3.4). Trong giai đoạn một, người chú thích nên đưa ra

### J.3.2 Chia Tách Yêu Cầu

Một số tuyên bố bao gồm nhiều phần độc lập, dễ tách rời (ví dụ: "Tỷ lệ năng suất ở Scotland tăng vào năm 2017, và tương tự năng suất cũng tăng ở Wales trong năm đó."). Bước đầu tiên là tách những tuyên bố phức tạp này thành các tuyên bố riêng lẻ. Việc thu thập và chuẩn hóa siêu dữ liệu sau đó sẽ được thực hiện một cách độc lập cho mỗi tuyên bố, và trong các giai đoạn tiếp theo, chúng sẽ được xem như các tuyên bố riêng biệt.

Khi tách một tuyên bố, điều quan trọng là đảm bảo rằng mỗi phần đều dễ hiểu mà không cần đến các phần khác làm bối cảnh. Điều này có thể được thực hiện bằng cách thêm siêu dữ liệu vào trường phù hợp, chẳng hạn như người phát ngôn hoặc ngày của tuyên bố, hoặc thông qua việc viết lại. Ví dụ, đối với tuyên bố " Amazon đang gây thiệt hại lớn cho các nhà bán lẻ nộp thuế. Các thị trấn, thành phố và bang trên toàn nước Mỹ đang bị tổn hại - nhiều việc làm bị mất!", phải rõ ràng lý do gây mất việc làm trong phần thứ hai. Một cách tách có thể là "Amazon đang gây thiệt hại lớn cho các nhà bán lẻ nộp thuế" và "Các thị trấn, thành phố và bang trên toàn nước Mỹ đang bị ảnh hưởng bởi Amazon - nhiều việc làm bị mất". Tức là, cần viết lại phần thứ hai bằng cách thêm Amazon lần thứ hai để phần thứ hai có thể hiểu được mà không cần bối cảnh.

### J.3.3 Bối cảnh hóa Yêu cầu

Một số tuyên bố không đầy đủ, có nghĩa là chúng thiếu bối cảnh thích hợp để được xác minh. Ví dụ, trong tuyên bố "Chúng tôi có 21 triệu nam và nữ thanh niên thất nghiệp.", có các đại từ chưa được giải quyết mà không có chúng, tuyên bố không thể được xác minh (ví dụ, một từ 'chúng tôi' đề cập đến Nigeria, vì người nói tuyên bố là ứng cử viên tổng thống của Nigeria). Một ví dụ khác là "Israel đã tiêm chủng cho 50% dân số của họ." Chúng ta cần biết khi nào tuyên bố này được đưa ra để xác minh tính xác thực của nó, vì thời gian là yếu tố quan trọng cho việc xác minh này. Đối với trường hợp sau, siêu dữ liệu là đủ để giải quyết những mơ hồ; trường hợp trước cần được viết lại thành "Nigeria có 21 triệu nam và nữ thanh niên thất nghiệp."

Người chú thích được yêu cầu đặt các tuyên bố vào bối cảnh của bài đăng gốc bằng cách thu thập thông tin c ần thiết. Một số thông tin có thể được đưa vào chỉ dưới dạng siêu dữ liệu, nhưng điều này không phải lúc nào cũng đủ – đối với thông tin không được ghi lại bằng siêu dữ liệu, chúng tôi yêu cầu chính tuyên bố đó được viết lại để bao gồm thông tin nói trên. Người chú thích cần tuân theo danh sách kiểm tra này:

1. Liệu tuyên bố có đang đề cập đến các thực thể chỉ có thể được xác định bằng cách đọc bài kiểm tra s ự thật liên quan, ngay cả khi tất cả siêu dữ liệu được xem xét? Nếu có, hãy thêm tên của

entities (e.g. *"Former first lady said, 'White folks are what's wrong with America'."* becomes *"Former first lady Michelle Obama said, 'White folks are what's wrong with America'."*).

2. Does the claim have unnecessary quotation marks or references to a speaker (such as the word *says* in the example here)? If so, remove them (e.g. *"Says 'Monica Lewinsky Found Dead' in a burglary."* becomes *"Monica Lewinsky found dead in a burglary."*). Do NOT remove the reference to the speaker if the central problem is to determine if that person actually said the quote, e.g. in the case of quote verification.
3. Is the claim a question? If so, rephrase it as a statement (e.g. *"Did a Teamsters strike hinder aid efforts in Puerto Rico after Hurricane Maria?"* becomes *"A Teamsters strike hindered aid efforts in Puerto Rico after Hurricane Maria in 2017."*).
4. Does the claim contain pronominal references to entities only mentioned in the fact-checking article? If so, replace the pronoun with the name of that entity. (e.g. *"We have 21 million unemployed young men and women."* becomes *"Nigeria has 21 million unemployed young men and women."*).
5. For some fact-checking articles, the title used does not properly match the fact-checked claim. Find the original claim in the article, and use that for producing the normalized version. As shown in Figure 11, the claim should be the first sentence of the article rather than the title.
6. Is the claim too vague to be investigated through the use of evidence, and does the fact-checking article investigate a more specific version of the claim? If so, use the claim investigated in the fact-checking article (e.g. *"Towns, cities, and states throughout the U.S. are being hurt by Amazon"* might become *"Towns, cities, and states throughout the U.S. are losing state tax revenue because of Amazon"*).

Generally, try to make claims specific enough so that they can *be understood* and so that *appropriate evidence can be found* by a person who has not seen the fact-checking article.

**Important!** We recommend reading through the entire article and understanding the central problem before rewriting the claim. This makes it easier to identify the exact phrasing of the original claim and to make any minimal interventions necessary following our checklist above. When in doubt as to whether a claim should be modified, we recommend leaving it unchanged – we generally prefer claims to be as close as possible to their original form, subject to the constraints listed above.

### J.3.4 Labels

We ask annotators to produce a label for the claim relying *only* on the information on the fact-checking site (and assuming that everything reported it is accurate). For the dataset we are creating, we will be using four labels:

1. The claim is **supported**. The claim is supported by the arguments and evidence presented.
2. The claim is **refuted**. The claim is contradicted by the arguments and evidence presented.
3. There is **not enough evidence** to support or refute the claim. The evidence either directly argues that appropriate evidence cannot be found, or leaves some aspect of the claim neither supported nor refuted. We note that many fact-checking agencies mark claims as *refuted* (or similar), if supporting evidence does not exist, without giving any refuting evidence. We ask annotators to use *not enough evidence* for this category, regardless of the original label. In situations where evidence can be found that the claim is *unlikely*, even if the evidence is not conclusive, annotators may use *refuted*; here, annotators should use their own judgment. We give a few examples in Section J.3.5.
4. The claim is misleading due to **conflicting evidence/cherry-picking**, but not explicitly refuted. This includes cherry-picking (see `https://en.wikipedia.org/wiki/Cherry-picking`), true-but-misleading claims (e.g. the claim *"Alice has never lost an election"* with evidence showing Alice has only ever run unopposed), as well as cases where conflicting or internally contradictory evidence can be found.

   Conflicting evidence may also be relevant if a situation has recently changed, and the claim fails to mention this (e.g. *"Alice is a strong supporter of industrial subsidies"* with evidence showing that Alice currently supports industrial subsidies, but in the past opposed industrial



*các thực thể (ví dụ: "Cựu Đệ nhất phu nhân nói, 'Người da trắng là điều không ổn ở nước Mỹ'" trở thành*

"Cựu Đệ nhất Phu nhân Michelle Obama đã nói, 'Người da trắng là vấn đề của nước Mỹ'."). 2. Lời khẳng định có dấu ngoặc kép thừa hoặc tham chiếu đến người nói (chẳng hạn như từ says trong ví dụ này) không? Nếu có, hãy loại bỏ chúng (ví dụ "Says 'Monica Lewinsky Found Dead' in a burglary." trở thành "Monica Lewinsky found dead in a burglary."). KHÔNG loại bỏ tham chiếu đến người nói nếu vấn đề chính là xác định liệu người đó thực sự đã nói câu trích dẫn hay không, ví dụ trong trường hợp xác minh trích dẫn. 3. Lời khẳng định có phải là câu hỏi không? Nếu có, hãy diễn đạt lại thành câu khẳng định (ví dụ "Did a Teamsters strike hinder aid efforts in Puerto Rico after Hurricane Maria?" trở thành "A Teamsters strike hindered aid efforts in Puerto Rico after Hurricane Maria in 2017."). 4. Lời khẳng định có chứa đại từ chỉ các thực thể chỉ được nhắc đến trong bài viết kiểm chứng sự thật không? Nếu có, hãy thay thế đại từ bằng tên của thực thể đó. (ví dụ "We have 21 million unemployed young men and women." trở thành "Nigeria has 21 mill

Nói chung, hãy cố gắng đưa ra các tuyên bố đủ cụ thể để chúng có thể được hiểu và để người chưa đọc bài kiểm tra sự thật có thể tìm thấy bằng chứng phù hợp.

Quan trọng! Chúng tôi khuyến nghị đọc toàn bộ bài viết và hiểu vấn đề cốt lõi trước khi viết lại tuyên bố. Điều này sẽ giúp dễ dàng xác định chính xác cách diễn đạt của tuyên bố gốc và thực hiện bất kỳ can thiệp tối thiểu nào cần thiết theo danh sách kiểm tra của chúng tôi ở trên. Khi không chắc chắn liệu một tuyên bố có nên được sửa đổi hay không, chúng tôi khuyên nên để nguyên – chúng tôi thường ưu tiên các tuyên bố càng gần với hình thức gốc càng tốt, tuân theo các giới hạn đã nêu ở trên.

**J.3.4 Nhãn**

Chúng tôi yêu cầu những người chú thích tạo nhãn cho tuyên bố chỉ dựa trên thông tin trên trang kiểm chứng sự thật (và giả định rằng mọi thông tin được báo cáo đều chính xác). Đối với bộ dữ liệu mà chúng tôi đang tạo, chúng tôi sẽ sử dụng bốn nhãn:

1. Yêu cầu được hỗ trợ. Yêu cầu này được hỗ trợ bởi các lập luận và bằng chứng đã được trình bày. 2. Yêu cầu bị bác bỏ. Yêu cầu này bị mâu thuẫn bởi các lập luận và bằng chứng đã được trình bày. 3. Không có đủ bằng chứng để hỗ trợ hoặc bác bỏ yêu cầu. Bằng chứng hoặc trực tiếp lập luận rằng không thể tìm thấy bằng chứng thích hợp, hoặc để một số khía cạnh của yêu cầu không được hỗ trợ cũng không bị bác bỏ. Chúng tôi lưu ý rằng nhiều cơ quan xác minh sự thật đánh dấu các yêu cầu là bị bác bỏ (hoặc tương tự), nếu bằng chứng hỗ trợ không tồn tại, mà không đưa ra bất kỳ bằng chứng bác bỏ nào. Chúng tôi yêu cầu những người chú thích sử dụng "không có đủ bằng chứng" cho danh mục này, bất kể nhãn gốc. Trong các tình huống mà bằng chứng có thể được tìm thấy cho thấy yêu cầu là không có khả năng đúng, ngay cả khi bằng chứng đó không mang tính kết luận, người chú thích có thể sử dụng "bác bỏ"; ở đây, người chú thích nên sử dụng phán đoán của chính họ. Chúng tôi đưa một vài ví dụ trong Mục J.3.5. 4. Yêu cầu gây hiểu lầm do bằng chứng mâu thuẫn/chọn lọc, nhưng không bị bác bỏ rõ ràng. Điều này bao gồm việc chọn lọc

Bằng chứng mâu thuẫn cũng có thể có liên quan nếu một tình huống gần đây đã thay đổi, và tuyên bố không đề cập đến điều này (ví dụ: "Alice là một người ủng hộ mạnh mẽ các khoản trợ cấp công nghiệp" với bằng chứng cho thấy Alice hiện đang ủng hộ các khoản trợ cấp công nghiệp, nhưng trước đây đã phản đối công nghiệp)




Figure 11: An example of locating the claim.

subsidies). We note that if the claim covers a period of time, and evidence refutes the claim at some timepoints but not others, the whole claim is still *refuted* – for example, *"Alice has always been a strong supporter of industrial subsidies"* or *"Alice has never been a strong supporter of industrial subsidies"*. For a real example from our dataset, consider `https://fullfact.org/online/does-polands-migration-policy-explain-its-lack-terror-attacks/` – the claim is that *"Poland has had no terror attacks"*; evidence shows that Poland had no terror attacks before 2015, but some examples afterward, and should as such be marked *refuted*.

Despite the claim splitting subtask, some claims may contain multiple parts that are too interconnected to split. This could for example be a claim like *"Alice has never lost an election because she always supports cheese subsidies"*. In such cases, parts of the claim may have different truth values. We discuss a few cases below:

- The claim is implicature, i.e. *"X happens because Y"* or *"X leads to Y"*. In this case, annotators should find a label for the causal implication, and *not* for either of the component claims.
- The claim has too components, where one is *refuted* and the other is *not enough information*. In this case, the entire claim should be labeled *refuted*.
- The claim has too components, where one is *supported* and the other is *not enough information*. In this case, the entire claim should be labeled *not enough information*.

**Important!** The label was given in Phase 1 – and *only* in Phase 1 – should reflect the decision of the fact checker, not the interpretation of the annotator. In Phase 1, annotators should report the original judgment, as closely as possible, even if they disagree with it.






Hình 11: Một ví dụ về việc xác định yêu cầu.

trợ cấp). Chúng tôi lưu ý rằng nếu tuyên bố bao gồm một khoảng thời gian, và bằng chứng bác bỏ tuyên bố tại một số thời điểm nhưng không phải tất cả, toàn bộ tuyên bố vẫn bị bác bỏ – ví dụ, " Alice luôn luôn là người ủng hộ mạnh mẽ các trợ cấp công nghiệp" hoặc "Alice chưa bao giờ là người ủng hộ mạnh mẽ các trợ cấp công nghiệp". Để lấy một ví dụ thực tế từ bộ dữ liệu của chúng tôi, hãy xem https://fullfact.org/online/does-polands-migration-policy-explain-its-lack-terror-attacks/ – tuyên bố là "Ba Lan chưa từng có vụ tấn công khủng bố nào"; bằng chứng cho thấy Ba Lan chưa có vụ tấn công khủng bố nào trước năm 2015, nhưng có một số ví dụ sau đó, và do đó nên được đánh dấu là bị bác bỏ.

Mặc dù có nhiệm vụ tách các khẳng định, một số khẳng định có thể chứa nhiều phần quá gắn kết để tách ra. Ví dụ, điều này có thể là một khẳng định như "Alice chưa bao giờ thua trong một cuộc bầu cử vì cô ấy luôn ủng hộ trợ cấp cho phô mai". Trong những trường hợp như vậy, các phần của khẳng định có thể có các giá trị chân thực khác nhau. Chúng tôi thảo luận một vài trường hợp dưới đây:

• Yêu cầu này là suy luận ngụ ý, tức là "X xảy ra vì Y" hoặc "X dẫn đến Y". Trong trường hợp này, những người chú thích nên tìm một nhãn cho ý ngụ nhân quả, chứ không phải cho từng tuyên bố thành phần.

• Yêu cầu có hai thành phần, trong đó một thành phần bị bác bỏ và thành phần còn lại không đủ thông tin. Trong trường hợp này, toàn bộ yêu cầu nên được gắn nhãn là bị bác bỏ.

• Tuyên bố có hai thành phần, trong đó một được hỗ trợ và thành phần còn lại không đủ thông tin. Trong trường hợp này, toàn bộ tuyên bố nên được gán nhãn là không đủ thông tin.

Quan trọng! Nhãn được đưa ra trong Giai đoạn 1 – và chỉ trong Giai đoạn 1 – nên phản ánh quyết định của người kiểm tra thực tế, không phải là cách diễn giải của người chú thích. Trong Giai đoạn 1, người chú thích nên báo cáo đánh giá gốc, càng sát với thực tế càng tốt, ngay cả khi họ không đồng ý với nó.

### J.3.5 Deciding Between Refuted and NEE

As mentioned, the line between *refuted* and *not enough evidence* requires annotators to rely on their own judgment in cases where refuting evidence cannot be directly found, but the claim is extremely unlikely. As a guiding principle, if annotators would feel doubt regarding the truth value of the claim – given the presented evidence and/or lack of evidence – *not enough evidence* should be chosen. Below, we give several examples from our dataset:

- *"The Covid-19 dusk-to-dawn curfew is Kenya's first-ever nationwide curfew since independence."* No evidence can be found that Kenya has implemented a nationwide curfew before the Covid-19 pandemic. However, it is conceivable that evidence of such a curfew would simply not show up in documentation uploaded to the internet. As such, the annotator cannot rule out a prior curfew beyond a reasonable doubt, and such should select *not enough evidence* as the label.
- *"The government in India has announced that it will shut down the internet to avoid panic about the Coronavirus."* Evidence can be found that Indian law allows the government to do so as an emergency measure; however, the annotator finds no announcement from the government that the internet actually will be shut down. If other, regular, announcements from the same government body could be found, the claim should be labeled *refuted* – it would be extremely unlikely that a shutdown on the internet would not be announced via standard channels. However, in this case, standard channels do not make announcements in English, and therefore it is plausible that the announcement has not been found simply because it has not been translated; in this case, the annotator should select *not enough evidence* (with evidence that no English-language official channel exists).
- *"Shakira is Canadian."* Evidence can be found that Shakira is usually described as Colombian, was born in Colombia, and holds Colombian citizenship. Furthermore, evidence shows she now resides in Spain. As no evidence of any connection to Canada can be found despite the wealth of information available about her, it is extremely unlikely that she is secretly Canadian; as such, the annotator can select *refuted* as the label.

A special case of this kind of claim is quote verification, where it can be difficult to establish that someone did *not* say something. In many cases, evidence can be found that a quote is fictional (e.g. by finding evidence from a service like `https://quoteinvestigator.com/`), or that it originates from someone else. However, in some cases, there is no readily available evidence. In this case, we advise that annotators document the lack of evidence that the person said *the quote itself*, or *any paraphrase of the quote*. Further, annotators should document that *some* quotes by that person can be found, if possible what the person has said *on the same topic*, and if possible that the quote has not been said by *someone else*. This establishes that evidence for the quote should be available, and is not; in that case, annotators can pick *refuted* as the label. If annotators cannot find any claims by the person or any evidence for the quote (say an entirely fictional person with an entirely fictional quote), they should pick *not enough evidence*.

For a good example of how to handle these cases, consider the claim *"RBI has said that ₹2000 notes are banned and ₹1000 notes have been introduced"*. As this claim is false, no evidence can be found of RBI making any such announcement; nor that they did *not* make that particular announcement. Here, the annotator first established where official communication from RBI is published with the question *"how do the RBI/central bank make announcements on changes to currency?"* Then, after finding that all official communication is posted to the RBI website, they asked a follow-up question testing whether evidence for the claim can be found *on the official website*.

### J.3.6 Metadata Collection

Annotators need to collect metadata through the following three steps.

### J.3.7 General Information

- A hyperlink to the original claim, if that is provided by the fact-checking site. Examples of this include Facebook posts, the original article or blog post being fact-checked, and embedded video links. If the original claim has a hyperlink on the fact-checking site, but that hyperlink is dead, annotators should leave the field empty.



### J.3.5 Quyết định giữa Bị bác và NEE

Như đã đề cập, ranh giới giữa bị bác bỏ và thiếu bằng chứng đòi hỏi người chú thích phải dựa vào phán đoán của riêng họ trong những trường hợp không thể tìm thấy bằng chứng bác bỏ trực tiếp, nhưng tuyên bố là cực kỳ không khả thi. Như một nguyên tắc hướng dẫn, nếu người chú thích cảm thấy nghi ngờ về giá trị chân thật của tuyên bố – dựa trên bằng chứng được trình bày và/hoặc thiếu bằng chứng – thì nên chọn thiếu bằng chứng. Dưới đây, chúng tôi đưa ra một số ví dụ từ bộ dữ liệu của chúng tôi:

- "Lệnh giới nghiêm từ hoàng hôn đến bình minh vì Covid-19 là lệnh giới nghiêm toàn quốc đầu tiên của Kenya kể từ khi giành độc lập." Không có bằng chứng nào cho thấy Kenya đã thực hiện lệnh giới nghiêm toàn quốc trước đại dịch Covid-19. Tuy nhiên, có thể hình dung rằng bằng chứng về một lệnh giới nghiêm như vậy đơn giản là không xuất hiện trong các tài liệu được tải lên internet. Do đó, người chú thích không thể loại trừ một lệnh giới nghiêm trước đó một cách chắc chắn, và nên chọn 'không đủ bằng chứng' làm nhãn.
- "Chính phủ Ấn Độ đã thông báo rằng họ sẽ tắt Internet để tránh hoang mang về Virus Corona." Có thể tìm thấy bằng chứng rằng luật pháp Ấn Độ cho phép chính phủ làm như vậy một biện pháp khẩn cấp; tuy nhiên, người chú thích không tìm thấy thông báo nào từ chính phủ rằng Internet thực sự sẽ bị tắt. Nếu có thể tìm thấy các thông báo khác, thường xuyên từ cùng một cơ quan chính phủ, tuyên bố này nên được gắn nhãn là bị bác bỏ – sẽ cực kỳ khó xảy ra việc tắt Internet mà không được thông báo qua các kênh thông thường. Tuy nhiên, trong trường hợp này, các kênh thông thường không đưa ra thông báo bằng tiếng Anh, và do đó khả thi là thông báo chưa được tìm thấy chỉ vì nó chưa được dịch; trong trường hợp này, người chú thích nên chọn là không đủ bằng chứng (với bằng chứng rằng không tồn t ại kênh chính thức nào bằng tiếng Anh).
- "Shakira là người Canada." Bằng chứng có thể được tìm thấy là Shakira thường được mô tả là người Colombia, sinh ra ở Colombia và mang quốc tịch Colombia. Hơn nữa, bằng chứng cho thấy cô hiện đang sinh sống tại Tây Ban Nha. Vì không có bằng chứng nào cho thấy cô có liên hệ với Canada mặc dù có rất nhiều thông tin về cô, nên khả năng cô là người Canada một cách bí mật là cực kỳ thấp; do đó, người chú thích có thể chọn nhãn bị bác bỏ.

Một trường hợp đặc biệt của loại tuyên bố này là xác minh trích dẫn, nơi mà việc chứng minh rằng ai đó không nói một điều gì đó có thể gặp khó khăn. Trong nhiều trường hợp, có thể tìm thấy bằng chứng cho thấy một trích dẫn là hư cấu (ví dụ: bằng cách tìm bằng chứng từ một dịch vụ như https://quoteinvestigator.com/), hoặc rằng nó xuất phát từ người khác. Tuy nhiên, trong một số trường hợp, không có bằng chứng có sẵn. Trong trường hợp này, chúng tôi khuyên các người chú thích ghi nhận sự thiếu bằng chứng rằng người đó đã nói chính trích dẫn đó, hoặc bất kỳ sự diễn giải nào của trích dẫn. Hơn nữa, người chú thích nên ghi nhận r ằng một số trích dẫn của người đó có thể được tìm thấy, nếu có thể những gì người đó đã nói về cùng chủ đề, và nếu có thể rằng trích dẫn đó chưa được nói bởi người khác. Điều này xác lập rằng bằng chứng cho trích dẫn nên có sẵn, nhưng lại không có; trong trường hợp đó, người chú thích có thể chọn 'bác bỏ' làm nhãn. Nếu người chú thích không thể tìm thấy bất kỳ tuyên bố nào của người đó hoặc bất kỳ bằng chứng nào cho trích dẫn (ví dụ một người hoàn toàn hư cấu với một câu chuyện hoàn toàn hư cấu

Để có một ví dụ điển hình về cách xử lý các trường hợp này, hãy xem xét tuyên bố "RBI đã nói rằng các tờ ₹*2000* bị cấm và các tờ ₹*1000* đã được giới thiệu". Vì tuyên bố này là sai, nên không thể tìm thấy bằng chứng nào cho việc RBI đưa ra bất kỳ thông báo nào như vậy; cũng không có bằng chứng rằng họ không đưa ra thông báo cụ thể đó. Ở đây, người chú thích trước tiên xác định nơi mà các thông tin chính thức từ RBI được công bố với c âu hỏi "RBI/ngân hàng trung ương đưa ra thông báo về thay đổi tiền tệ như thế nào?" Sau đó, sau khi tìm thấy rằng tất cả thông tin chính thức đều được đăng trên trang web của RBI, họ đặt một câu hỏi tiếp theo kiểm tra xem bằng chứng cho tuyên bố đó có thể được tìm thấy trên trang web chính thức không.

### J.3.6 Thu thập siêu dữ liệu

Người chú thích cần thu thập siêu dữ liệu thông qua ba bước sau.

### J.3.7 Thông tin chung

- Một liên kết đến tuyên bố gốc, nếu điều đó được cung cấp bởi trang kiểm chứng thông tin. Ví dụ của điều này bao gồm các bài đăng trên Facebook, bài báo hoặc bài đăng blog gốc đang được kiểm chứng, và các liên kết video được nhúng. Nếu tuyên bố gốc có một liên kết trên trang kiểm chứng thông tin, nhưng liên kết đó đã chết, người chú thích nên để trống trường này.

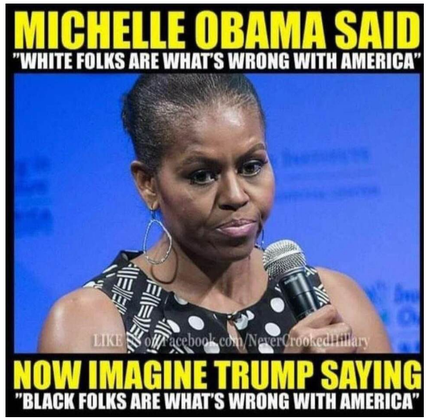



Figure 12: An example of an image claim requiring transcription.

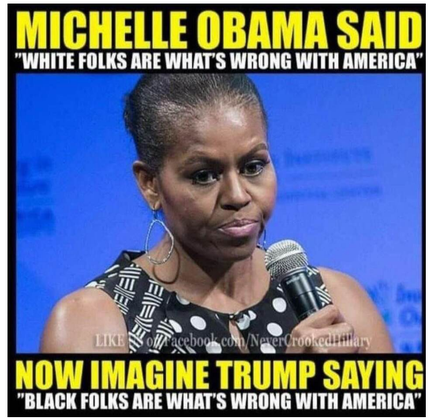
- The date of the original claim, regardless of whether it is necessary for verifying the claim. This date is often mentioned by the fact checker, but not in a standardized place where we could automatically retrieve it. Note that the date for the *original claim* and the *fact-checking article* (often its publication date) may be different and both are stated in the text. We specifically need the original claim date, as we intend to filter out evidence that appeared after that date. If multiple dates are mentioned, the earliest should be used. If an imprecise date is given (e.g. February 2017), the earliest possible interpretation should be used (i.e. February 1st, 2017).
- The speaker of the original claim, e.g. the person or organization who made the claim.
- The source of the original claim, e.g. the person or organization who published the claim. This is not necessarily the same as the speaker; a person might make a comment in a newspaper, in which case the person is the speaker and the newspaper is the source.
- If the original claim is or refers to an image, video, or audio file, annotators should add a link to that media file (or the page that contains the file, if the media file itself is inaccessible).
- If the original claim is an image that contains text – for example, Figure 12 shows a Facebook meme about Michelle Obama – annotators should transcribe the text that occurs in the image as metadata. In the example, it would be *"Michelle Obama said white folks are what's wrong with America."*
- If the fact-checking article is paywalled or inaccessible due to an error message, annotators should report this and skip the claim using the corresponding button.

### J.3.8 Claim Type

The type of the claim itself, independent of the approach taken by the fact checker to verify or refute it, should be chosen from the following list. This is not a mutually exclusive choice – a claim can be speculation about a numerical fact, for example. As such, annotators should choose one *or several* from the list.

- **Speculative Claim**: The primary task is to assess whether a prediction is plausible or realistic. For example *"the price of crude oil will rise next year."*
- **Opinion Claim**: The claim is a non-factual opinion, e.g. *"cannabis should be legalized"*. This contrasts with factual claims on the same topic, such as *"legalization of cannabis has helped reduce opioid deaths."*
- **Causal Claim**: The primary task is to assess whether one thing caused another. For example *"the price of crude oil rose because of the Suez blockage."*.






Hình 12: Một ví dụ về yêu cầu chuyển ngữ của hình ảnh.

Ngày của tuyên bố ban đầu, bất kể việc xác minh tuyên bố đó có cần thiết hay không. Ngày này t hường được người kiểm tra sự thật đề cập, nhưng không theo một định dạng chuẩn nào để chúng ta có thể tự động trích xuất. Lưu ý rằng ngày của tuyên bố ban đầu và bài viết kiểm tra sự thật (thường là ngày xuất bản) có thể khác nhau và cả hai đều được nêu trong văn bản. Chúng tôi đặc biệt cần ngày của tuyên bố ban đầu, vì chúng tôi dự định lọc ra các bằng chứng xuất hiện sau ngày đó. Nếu có nhiều ngày được đề cập, ngày sớm nhất nên được sử dụng. Nếu ngày được đưa ra không chính xác (ví dụ: tháng Hai năm 2017), cách hiểu có thể sớm nhất nên được sử dụng (tức là ngày 1 tháng 2 năm 2017).

• Người phát biểu của tuyên bố gốc, ví dụ như cá nhân hoặc tổ chức đã đưa ra tuyên bố đó.

• Nguồn gốc của tuyên bố ban đầu, ví dụ như người hoặc tổ chức đã công bố tuyên bố. Điều này không nhất thiết phải giống với người phát biểu; một người có thể đưa ra bình luận trên một tờ báo, trong trường hợp đó người đó là người phát biểu và tờ báo là nguồn.

• Nếu tuyên bố gốc là hình ảnh, video hoặc tệp âm thanh, hoặc đề cập đến chúng, người chú thích nên thêm liên kết đến tệp phương tiện đó (hoặc trang chứa tệp, nếu tệp phương tiện không thể truy cập).

• Nếu tuyên bố ban đầu là một hình ảnh chứa văn bản – ví dụ, Hình 12 cho thấy một meme trên Facebook về Michelle Obama – các nhân viên chú giải nên ghi lại văn bản xuất hiện trong hình ảnh dưới dạng metadata. Trong ví dụ đó, sẽ là "Michelle Obama nói người da trắng là nguyên nhân gây ra vấn đề với nước Mỹ."

• Nếu bài viết kiểm chứng sự thật bị khóa trả phí hoặc không thể truy cập do lỗi, người chú thích nên báo cáo điều này và bỏ qua tuyên bố bằng cách sử dụng nút tương ứng.

### J.3.8 Loại Yêu Cầu

Loại yêu cầu tự nó, độc lập với phương pháp mà người kiểm tra sự thật sử dụng để xác minh hoặc bác bỏ, nên được chọn từ danh sách sau. Đây không phải là một lựa chọn loại trừ lẫn nhau – một yêu cầu có thể là suy đoán về một sự kiện số, ví dụ. Do đó, người chú thích nên chọn một hoặc một số mục từ danh sách.

• Yêu cầu suy đoán: Nhiệm vụ chính là đánh giá xem một dự đoán có thể xảy ra hoặc thực tế hay không. Ví dụ "giá dầu thô sẽ tăng vào năm tới."

• Yêu cầu về Ý kiến: Yêu cầu này là một ý kiến không dựa trên sự thật, ví dụ: "cần hợp pháp hóa cần sa". Điều này tương phản với các yêu cầu dựa trên sự thật cùng chủ đề, chẳng hạn như "việc hợp pháp hóa cần sa đã giúp giảm số ca tử vong do opioid."

• Khẳng định nhân quả: Nhiệm vụ chính là đánh giá xem một sự việc có gây ra sự việc khác hay không. Ví dụ "giá dầu thô tăng lên vì tắc nghẽn ở kênh đào Suez."

- **Numerical claim**. The primary task is to verify whether a numerical fact is true, or to verify whether a comparison between several numerical facts hold, or to determine whether a numerical trend or correlation is supported by evidence.
- **Quote Verification**. The primary task is to identify whether a quote was actually said by the supposed speaker. Claims *only* fall under this category if the quote to be verified directly figures in the claim, e.g. *"Boris Johnson told journalists 'my favourite colour is red, because I love tomatoes' "*.
- **Position Statement**. The primary task is to identify whether a public figure has taken a certain position, e.g. supporting a particular policy or idea. For example, *"Edward Heath opposed privatisation"*. This also includes statements that opinions have changed, e.g. *"Edward Heath opposed privatisation before the election, but changed his mind after coming into office"*. Factual claims about the actions of people (e.g. *"Edward Heath nationalised Rolls-Royce"*) are not position statements (they are event or property claims); claims about the attitudes of people (e.g. *"Edward Heath supported the nationalisation of Rolls-Royce"*) are.
- **Event/Property Claim**. The primary task is to determine the veracity of a narrative about a particular event or series of events, or to identify whether a certain non-numerical property is true, e.g. a person attending a particular university. Some properties represent causal relationships, e.g. *"The prime minister never flies, because he has a fear of airplanes"*. In those cases, the claim should be interpreted as both a property claim and a causal claim.
- **Media Publishing Claim**. The primary task is to identify the original source for a (potentially doctored) image, video, or audio file. This covers both doctored media, and media that has been taken out of context (e.g. a politician is claimed to have shared a certain photo, and the task is to determine if they actually did). This also includes HTML-doctoring of social media posts. We will discard all claims in this category.
- **Media Analysis Claim**. The primary task is to perform complex reasoning about pieces of media, distinct from doctoring. This could for example be checking whether a geographical location is really where a video was taken, or determining whether a specific person is actually the speaker in an audio clip. The claim itself *must directly involve* media analysis; e.g. "the speaker of these two clips is the same". Claims where the original source is video, but which can be understood and verified without viewing the original source, do not fall under this category. An original video or audio file can feature as metadata in fact-checking articles, but claims are only *complex media claims* if analysis of the video or audio beyond just extracting a quote is necessary for verification.

Several claim types – speculative claims, opinion claims, media publishing claims, and media analysis claims – will not be included in later phases.

### J.3.9 Fact-checking Strategy

After identifying the claim type, we ask annotators to classify the approach taken by the fact checker according to the article. This is independent of the claim type, as a fact-checker might take any number of approaches to a given claim. Again, one *or several* options should be chosen from the following list:

- **Written Evidence**. The fact-checking process involved finding contradicting or supporting written evidence, e.g. a news article directly refuting or supporting the claim.
- **Numerical Comparison**. The fact-checking process involved numerical comparisons, such as verifying that one number is greater than another.
- **Consultation**. The fact checkers directly reached out to relevant experts or people involved with the story, reporting new information from such sources as part of the fact-checking article.
- **Satirical Source Identification**. The fact-checking process involved identifying the source of the claim as satire, e.g. The Onion.
- **Media Source Discovery**. The fact-checking process involved finding the original source of a (potentially doctored) image, video, or soundbite.



• Khẳng định bằng số. Nhiệm vụ chính là xác minh liệu một sự thật bằng số có đúng hay không, hoặc xác minh liệu một so sánh giữa nhiều sự thật bằng số có đúng hay không, hoặc xác định liệu một xu hướng hoặc mối tương quan bằng số có được chứng thực bằng bằng chứng hay không.

• Xác nhận câu trích dẫn. Nhiệm vụ chính là xác định liệu một câu trích dẫn có thực sự được nói bởi người được cho là người nói hay không. Các tuyên bố chỉ thuộc loại này nếu câu trích dẫn cần được xác minh trực tiếp xuất hiện trong tuyên bố, ví dụ: "Boris Johnson nói với các nhà báo 'màu yêu thích của tôi là màu đỏ, vì tôi thích cà chua' ".

• Tuyên bố quan điểm. Nhiệm vụ chính là xác định liệu một nhân vật công chúng có giữ một quan điểm nhất định hay không, ví dụ như ủng hộ một chính sách hoặc ý tưởng cụ thể. Ví dụ, "Edward Heath phản đối tư nhân hóa". Điều này cũng bao gồm các tuyên bố rằng quan điểm đã thay đổi, ví dụ, "Edward Heath phản đối tư nhân hóa trước cuộc bầu cử, nhưng thay đổi ý kiến sau khi nhậm chức". Các tuyên bố mang tính sự kiện về hành động của con người (ví dụ: "Edward Heath quốc hữu hóa Rolls-Royce") không phải là tuyên bố quan điểm (chúng là các tuyên bố về sự kiện hoặc thuộc tính); các tuyên bố về thái độ của con người (ví dụ: "Edward Heath ủng hộ quốc hữu hóa Rolls-Royce") thì là.

• Yêu cầu về Sự kiện/Tài sản. Nhiệm vụ chính là xác định tính xác thực của một câu chuyện về một sự kiện cụ thể hoặc một chuỗi sự kiện, hoặc xác định xem một thuộc tính không phải số liệu nào đó có đúng hay không, ví dụ: một người đang theo học một trường đại học cụ thể. Một số thuộc tính đại diện cho mối quan hệ nhân quả, ví dụ: "Thủ tướng không bao giờ bay, vì ông ấy sợ máy bay". Trong những trường hợp đó, một yêu cầu nên được hiểu vừa như một yêu cầu về thuộc tính vừa như một yêu cầu về nhân quả.

• Yêu cầu xuất bản truyền thông. Nhiệm vụ chính là xác định nguồn gốc ban đầu của một hình ảnh, video hoặc tệp âm thanh (có khả năng đã bị chỉnh sửa). Điều này bao gồm cả phương tiện bị chỉnh sửa và phương tiện bị lấy ra ngoài ngữ cảnh (ví dụ: một chính trị gia được cho là đã chia sẻ một bức ảnh nhất định, và nhiệm vụ là xác định xem họ có thực sự làm như vậy hay không). Điều này cũng bao gồm việc chỉnh sửa HTML của các bài đăng trên mạng xã hội. Chúng tôi sẽ loại bỏ tất cả các yêu cầu trong danh mục này.

• Yêu cầu Phân tích Truyền thông. Nhiệm vụ chính là thực hiện suy luận phức tạp về các đoạn phương tiện truyền thông, khác với việc chỉnh sửa. Ví dụ, điều này có thể là kiểm tra xem một địa điểm địa lý có thực sự là nơi một video được quay, hoặc xác định xem một người cụ thể có thực sự là người phát biểu trong một đoạn âm thanh hay không. Bản thân yêu cầu phải liên quan trực tiếp đến phân tích phương tiện truyền thông; ví dụ: "người phát biểu trong hai đoạn clip này là cùng một người". Những yêu cầu mà nguồn gốc ban đầu là video, nhưng có thể hiểu và xác minh mà không cần xem nguồn gốc ban đầu, không thuộc phạm vi này. Một video hoặc tệp âm thanh gốc có thể xuất hiện như siêu dữ liệu trong các bài viết xác minh sự thật, nhưng các yêu cầu chỉ được coi là yêu cầu phương tiện phức tạp nếu việc phân tích video hoặc âm thanh vượt ra ngoài việc chỉ trích xuất trích dẫn là cần thiết để xác minh.

Một số loại yêu cầu – yêu cầu mang tính suy đoán, yêu cầu ý kiến, yêu cầu xuất bản truyền thông và yêu cầu phân tích truyền thông – sẽ không được bao gồm trong các giai đoạn sau.

#### J.3.9 Chiến lược kiểm chứng sự thật

Sau khi xác định loại tuyên bố, chúng tôi yêu cầu người chú thích phân loại phương pháp mà người kiểm tra sự thật sử dụng theo bài viết. Điều này độc lập với loại tuyên bố, vì một người kiểm tra sự thật có thể áp dụng bất kỳ phương pháp nào đối với một tuyên bố nhất định. Một lần nữa, nên chọn một hoặc nhiều tùy chọn từ danh sách sau:

• BằngChứngViết. Quá trình kiểm chứng bao gồm việc tìm kiếm các bằng chứng viết mâu thuẫn hoặc hỗ trợ, ví dụ: một bài báo trực tiếp bác bỏ hoặc ủng hộ tuyên bố.

• So sánh số liệu. Quá trình kiểm chứng sự thật liên quan đến các so sánh số liệu, chẳng hạn như xác minh rằng một con số lớn hơn con số khác.

• Tham khảo ý kiến. Các nhà kiểm chứng thông tin đã trực tiếp liên hệ với các chuyên gia liên quan hoặc những người tham gia câu chuyện, báo cáo thông tin mới từ các nguồn này như một phần của bài viết kiểm chứng thông tin.

• Xác định Nguồn Châm Biếm. Quá trình kiểm chứng sự thật bao gồm việc xác định nguồn của tuyên bố là châm biếm, ví dụ: The Onion.

• Khám phá nguồn phương tiện truyền thông. Quá trình kiểm chứng sự thật bao gồm việc tìm kiếm nguồn gốc ban đầu của một hình ảnh, video hoặc đoạn âm thanh (có thể đã bị sửa).

- **Image analysis**. The fact-checking process involved image analysis, such as comparing two images.
- **Video Analysis**. The fact-checking process involved analysing video, such as identifying the people in a video clip.
- **Audio Analysis** The fact-checking process involved analysing audio, such as determining which song was played in the background of an audio recording.
- **Geolocation**. The fact-checking process involved determining the geographical location of an image or a video clip, through the comparison of landmarks to pictures from Google Streetview or similar.
- **Fact-checker Reference**. The fact-checking process involved a reference to a previous fact-check of the same claim, either by the same or a different organisation. Reasoning or evidence from the referenced article was necessary to verify the claim.

Claims *only* labelled as solved through Fact-checker Reference will not be included in later phases.

### J.4 Phase 2: Question Generation and Answering

The next round of annotation aims to produce pairs of questions and answers providing evidence to verify the claim. The primary sources of evidence are the URLs linked in the fact-checking article. We also provide access to a custom search bar to retrieve evidence.

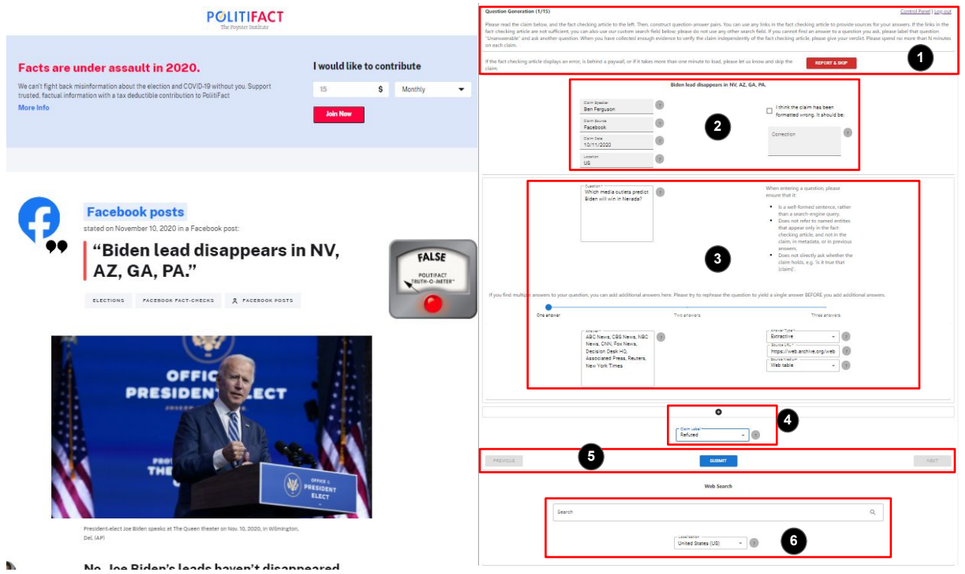



Figure 13: Interface of question generation. (1) Guideline of annotation for this phase. Please read it before annotating. Notice that if the article displays a 404 page or another error, or if it takes more than one minute to load, please click the **REPORT & SKIP** button. (2) The claim and the associated metadata. (3) Fields for the first question and its answers. Annotators can add up to 3 answers for each question if necessary. The text fields of metadata of question answer pairs are also provided. (4) Annotators can use the plus button to add as many questions as they want. Please select the label of this claim after finishing the question and answer generation. (5) Buttons for submitting the current claim, going to the previous claim, and next claim. (6) The custom search engine.

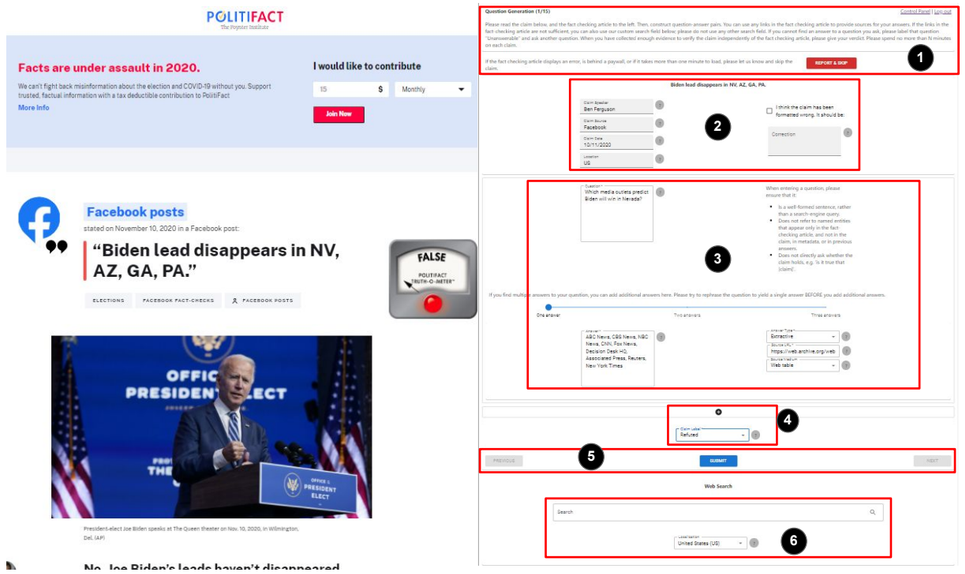


- Phân tích hình ảnh. Quá trình kiểm tra sự thật bao gồm phân tích hình ảnh, chẳng hạn như so sánh hai hình ảnh.
- Phân tích video. Quá trình kiểm chứng sự thật bao gồm phân tích video, chẳng hạn như xác định những người trong một đoạn video.
- Phân tích Âm thanh Quá trình kiểm chứng sự thật liên quan đến việc phân tích âm thanh, chẳng hạn như xác định bài hát nào được phát trong nền của bản ghi âm.
- Định vị địa lý. Quá trình kiểm chứng bao gồm việc xác định vị trí địa lý của một hình ảnh hoặc đoạn video, thông qua việc so sánh các địa danh với hình ảnh từ Google Streetview hoặc các nguồn tương tự.
- Tài liệu tham khảo kiểm chứng sự thật. Quá trình kiểm chứng sự thật liên quan đến việc tham khảo một kiểm chứng sự thật trước đó về cùng một tuyên bố, có thể bởi cùng một tổ chức hoặc một tổ chức khác. Lý do hoặc bằng chứng từ bài báo được tham khảo là cần thiết để xác minh tuyên bố.

Những tuyên bố chỉ được gắn nhãn là đã giải quyết thông qua Tham chiếu kiểm tra sự thật sẽ không được đưa vào các giai đoạn sau.

### J.4 Giai đoạn 2: Tạo câu hỏi và trả lời

Vòng chú thích tiếp theo nhằm tạo ra các cặp câu hỏi và câu trả lời cung cấp bằng chứng để xác minh tuyên bố. Các nguồn chính của bằng chứng là các URL được liên kết trong bài báo kiểm chứng sự thật. Chúng tôi cũng cung cấp quyền truy cập vào một thanh tìm kiếm tùy chỉnh để truy xuất bằng chứng.




Hình 13: Giao diện tạo câu hỏi. 1 Hướng dẫn ghi chú cho giai đoạn này. Vui lòng đọc trước khi ghi chú. Lưu ý rằng nếu bài viết hiển thị trang 404 hoặc lỗi khác, hoặc nếu mất hơn một phút để tải, vui lòng nhấn nút BÁO CÁO & BỎ QUA. 2 Yêu cầu và các siêu dữ liệu liên quan. 3 Các trường cho câu hỏi đầu tiên và câu trả lời của nó. Người ghi chú có thể thêm tối đa 3 câu trả lời cho mỗi câu hỏi nếu cần. Các trường văn bản của siêu dữ liệu cặp câu hỏi và câu trả lời cũng được cung cấp. 4 Người ghi chú có thể sử dụng nút cộng để thêm bao nhiêu câu hỏi tùy ý. Vui lòng chọn nhãn của yêu cầu này sau khi hoàn tất việc tạo câu hỏi và câu trả lời. 5 Nút để gửi yêu cầu hiện tại, chuyển đến yêu cầu trước và yêu cầu tiếp theo. 6 Công cụ tìm kiếm tùy chỉnh.

### J.4.1 Overview

Here, we give a quick overview of the question generation task; in-detail discussion can be found in subsequent sections. Further documentation can also be found on-the-fly using the tooltips in the annotation interface.

1. The annotator should first read the claim and metadata provided by the previous annotator, and the associated fact-checking article (including the verdict). We note that because phase-one annotators sometimes split decompose claims into parts, in some cases not all sections of the fact-checking article will be relevant.
2. The task is then to generation questions and answers about the claim such that a verdict can be given without knowledge of the fact-checking article. The sources and strategies used in the fact-checking article can serve as inspiration for questions and evidence for answers, but the fact-checking article should not be *directly* referenced as a source.
3. If an annotator believes a phase one claim has been extracted wrongly, they can correct it using the appropriate box. This is not necessary for most claims, but adds an extra layer of quality control. Guidance on correcting claims along with examples can be found in Section J.4.2.
4. We recommend constructing question-answer pairs iteratively, one at a time. That is, annotators should ask a question and attempt to answer it, and only then proceed to the next question.
5. Guidance on generating questions can be found in Section J.4.3.
6. Answers should be sought from the metadata, any of the sources listed on the fact-checking article (e.g. any hyperlinks to other sites), and when that is not possible (e.g. due to the hyperlinks being dead) from the internet using the search bar we provide.
7. Questions about metadata can be used to draw attention to aspects of the claim, in order to reason about publication date or publication source (see Section J.4.4).
8. WARNING: For persistence, we have stored all fact-checking articles on archive.org. Fact-checking articles may feature double-archivedlinks using both archive.org and archive.is, e.g. `https://web.archive.org/web/20201229212702/https://archive.md/28fMd`. Archive.org returns a 404 page for these. To view such a link, please just copy-paste the archive.is part (e.g. `https://archive.md/28fMd`) into your browser.
9. Answers should be accompanied by a hyperlink to the source, and the type of the source – e.g. web text, a pdf – should be specified. We note that if the source type is set as metadata, the source link will automatically be set to the word *metadata*.
10. Answers can be either *extraction*, e.g. copy-pasted directly from the source, *abstractive*, e.g. written in free-form based on the source, or *boolean*, e.g. written as yes/no with an explanation taken either extractively or abstractively from the source. Where possible, we strongly prefer extractive answers.
11. If an answer cannot be found, we also allow annotators to mark the question as unanswerable. We ask annotators to use this instead of deleting unanswerable questions.
12. Guidance on generating answers can be found in Section J.4.6.
13. If enough questions have been asked to support a verdict, or if at least ten minutes have passed without the annotator finding enough evidence, a verdict should be given from our for labels described in Section J.3.4.
14. Annotators in phase two should base their verdict on the question-answer pairs they have generated, and *not* on the fact-checking article. Depending on what information has been retrieved, they may therefore disagree with the article.
15. Before proceeding to the next hit, the annotator will be shown a warning with the QA-pairs they have generated. They will also be shown their assigned label. They will be asked to confirm that the collected evidence is sufficient to assign the label they have chosen to the claim.



### J.4.1 Tổng quan

Ở đây, chúng tôi cung cấp một tổng quan nhanh về nhiệm vụ tạo câu hỏi; thảo luận chi tiết có thể được tìm thấy trong các phần tiếp theo. Tài liệu bổ sung cũng có thể được tìm thấy ngay lập tức bằng cách sử dụng các chú giải công cụ trong giao diện chú thích.

1. Người chú thích nên đọc trước tuyên bố và siêu dữ liệu được cung cấp bởi người chú thích trước đó, cùng với bài viết kiểm tra thực tế liên quan (bao gồm cả phán quyết). Chúng tôi lưu ý rằng vì các người chú thích giai đoạn một đôi khi tách chia tuyên bố thành các phần, trong một số trường hợp không phải tất cả các phần của bài viết kiểm tra thực tế đều có liên quan. 2. Nhiệm vụ sau đó là tạo ra các câu hỏi và câu trả lời về tuyên bố sao cho có thể đưa ra phán quyết mà không cần biết bài viết kiểm tra thực tế. Các nguồn và chiến lược được sử dụng trong bài viết kiểm tra thực tế có thể phục vụ làm nguồn cảm hứng cho các câu hỏi và bằng chứng cho câu trả lời, nhưng bài viết kiểm tra thực tế không nên được t ham chiếu trực tiếp như một nguồn. 3. Nếu một người chú thích tin rằng một tuyên bố giai đoạn một đã được trích xuất sai, họ có thể chỉnh sửa nó bằng cách sử dụng hộp thích hợp. Điều này không cần thiết cho hầu hết các tuyên bố, nhưng thêm một lớp kiểm soát chất lượng. Hướng dẫn về việc chỉnh sửa tuyên bố cùng với các ví dụ có thể được tìm thấy trong Mục J.4.2. 4. Chúng tôi khuyến nghị xây dựng các câu

.

16. Sometimes, annotators may be in doubt as to whether an additional question should be added to further support the verdict. Generally speaking, we always prefer to have as many question-answer pairs as possible, so if in doubt annotators should veer on the side of adding that additional question.

**Important!** Annotators should not choose a label if the retrieved evidence does not support it; for example, if the label **conflicting evidence** is chosen, there should be evidence documenting the conflict. Labels in phase two can contradict the label of the fact-checker, if the annotator believes it is appropriate.

### J.4.2 Claim Correction

In addition to gathering question-answer pairs, Phase Two also acts as quality control for the claim contextualization in Phase One. This means if Phase Two annotators encounter a claim that is malformed or not properly contextualized, they can correct it. The guidelines for claim contextualization can be seen in Section J.3.3; the same criteria hold. Based on our initial review of the data entered in Phase One, Claim Correction is rarely necessary. Below are some examples from the data of claims that *should* be corrected in Phase Two:

1. The claim *"Nigerian vice presidential candidate Peter Obi claimed that Capital expenditure in 2016 was N1.2 trillion and 2017 was N1.5 trillion."*, given the article `https://africacheck.org/fact-checks/reports/battle-titans-fact-checking-arch-rivals-race-nigerias-presidency`. The article verifies the numerical value of capital expenditure in Nigeria, not whether Peter Obi has claimed anything about it. The original article is not quote verification, but the annotator has changed the claim to that. Here, the Phase Two annotator should correct the claim to simply *"Nigerian capital expenditure in 2016 was N1.2 trillion and 2017 was N1.5 trillion."*
2. The claim *"Abolish all charter schools"*, given the article `https://www.factcheck.org/2020/07/trump-twists-bidens-position-on-school-choice-charter-schools/`. This is a position statement about Joe Biden's stance on charter schools; however, the annotator has removed all reference to Joe Biden. The Phase Two annotator should correct the claim to *"Joe Biden wants to abolish all charter schools"*.
3. The claim *"Is Florida doing five times better than New Jersey?"*, given the article `https://leadstories.com/hoax-alert/2020/07/fact-check-florida-is-not-doing-five-times-better-in-deaths-than-new-york-and-new-jersey.html`. The claim has mistakenly been phrased as a question. It is also too vague. The Phase Two annotator should correct this, following the article: *"Florida is doing five times better than New Jersey in COVID-19 deaths per 1 million population"*.

### J.4.3 Question Generation

To ensure the quality of the generated questions, we ask the annotators to create their questions as follows:

- Questions should be well-formed, rather than search engine queries (e.g. "where is Cambridge?" rather than "Cambridge location").
- Questions should be standalone and understandable without any previous questions.
- Questions should be based on the version of the claim shown in the interface (i.e. the version extracted by phase one annotators), and not on the version in the fact-checking article. If an annotator believes a phase one claim has been extracted wrongly, they can correct it using the appropriate box.
- The annotators should avoid any question that directly asks whether or not the claim holds, e.g. *"is it true that [claim]"*.
- The annotators should ask all questions necessary to gather the evidence needed for the verdict, including world knowledge that might seem obvious, but could depend for example on where one is from. For example, Europeans might have better knowledge of European geography/history than Americans, and vice-versa.



16. Đôi khi, những người chú thích có thể nghi ngờ liệu có nên thêm một câu hỏi bổ sung để hỗ trợ thêm cho phán quyết hay không. Nói chung, chúng tôi luôn ưu tiên có càng nhiều cặp câu hỏi-trả lời càng tốt, vì vậy nếu còn nghi ngờ, những người chú thích nên nghiêng về việc thêm câu hỏi bổ sung đó.

Quan trọng! Người chú thích không nên chọn nhãn nếu bằng chứng tìm được không hỗ trợ cho nhãn đó; ví dụ, nếu nhãn 'bằng chứng mâu thuẫn' được chọn, nên có bằng chứng ghi lại mâu thuẫn. Các nhãn trong giai đoạn hai có thể mâu thuẫn với nhãn của người kiểm tra thực tế, nếu người chú thích cho rằng điều đó là phù hợp.

**J.4.2 Sửa đổi khiếu nại**

Bên cạnh việc thu thập các cặp câu hỏi-trả lời, Giai đoạn Hai cũng đóng vai trò kiểm soát chất lượng cho việc ngữ cảnh hóa các tuyên bố trong Giai đoạn Một. Điều này có nghĩa là nếu người chú thích ở Giai đoạn Hai gặp phải một tuyên bố bị sai cấu trúc hoặc không được ngữ cảnh hóa đúng cách, họ có thể sửa nó. Hướng dẫn về ngữ cảnh hóa tuyên bố có thể được xem ở Mục J.3.3; các tiêu chí như nhau vẫn áp dụng. Dựa trên đánh giá ban đầu của chúng tôi về dữ liệu đã nhập ở Giai đoạn Một, việc Sửa Tuyên Bố hiếm khi cần thiết. Dưới đây là một số ví dụ từ dữ liệu về các tuyên bố cần được sửa ở Giai đoạn Hai:

1. Khẳng định "Ứng cử viên phó tổng thống Nigeria Peter Obi tuyên bố rằng chi tiêu vốn năm 2016 là 1,2 nghìn tỷ Naira và năm 2017 là 1,5 nghìn tỷ Naira.", dựa trên bài báo
h
t
t
ps://africacheck.org/fact-checks/reports/battle-titans-fact-checking-arch-rivals-race-nigerias-presidency. Bài báo xác minh giá trị số học của chi tiêu vốn ở Nigeria, không xác minh liệu Peter Obi có tuyên bố gì về điều đó hay không. Bài báo gốc không phải là xác minh trích dẫn, nhưng người chú thích đã thay đổi khẳng định thành như vậy. Ở đây, người chú thích Giai đoạn Hai nên sửa khẳng định thành đơn giản " Chi tiêu vốn của Nigeria năm 2016 là 1,2 nghìn tỷ Naira và năm 2017 là 1,5 nghìn tỷ Naira." 2. Khẳng định "Bãi bỏ tất cả các trường thuộc quyền quản lý chuyển đổi", dựa trên bài báo https://www.factcheck.org/2020/07/trump-twists-bidens-position-on-school-choice-charter-schools/. Đây là một tuyên bố về quan điểm của Joe Biden đối với các trường thuộc quyền quản lý chuyển đổi; tuy nhiên, người chú thích đã loại bỏ tất cả các tham chiếu đến Joe Biden. Người chú thích Giai đoạn Hai nên sửa khẳng định...

**J.4.3 Tạo câu hỏi**

To e Để đảm bảo chất lượng của các câu hỏi được tạo ra, chúng tôi yêu cầu những người chú thích tạo câu hỏi của họ a s follows:

• Các câu hỏi nên được hình thành đầy đủ, thay vì là các truy vấn trên công cụ tìm kiếm (ví dụ: " Cambridge ở đâu?" thay vì "vị trí Cambridge").

• Câu hỏi nên độc lập và có thể hiểu được mà không cần các câu hỏi trước đó.

• Các câu hỏi nên dựa trên phiên bản của tuyên bố được hiển thị trong giao diện (tức là phiên bản được các chú thích viên giai đoạn một trích xuất), và không dựa trên phiên bản trong bài viết kiểm chứng sự kiện. Nếu một chú thích viên cho rằng một tuyên bố giai đoạn một đã bị trích xuất sai, họ có thể sửa nó bằng cách sử dụng ô thích hợp.

Các người chú thích nên tránh bất kỳ câu hỏi nào trực tiếp hỏi liệu tuyên bố có đúng hay không, ví dụ: "Có đúng rằng /tuyên bố/".

• Các người chú thích nên hỏi tất cả các câu hỏi cần thiết để thu thập bằng chứng cần thiết cho phán quyết, bao gồm cả kiến thức về thế giới mà có thể có vẻ hiển nhiên, nhưng có thể phụ thuộc ví dụ như vào nơi mà một người đến. Ví dụ, người châu Âu có thể có kiến thức về địa lý/lịch sử châu Âu tốt hơn người Mỹ, và ngược lại.

- As a guiding principle, at least 2 questions should be asked. This is not a hard limit, however, and the annotators can proceed with only one question asked if they do not feel more are needed.

The following are examples used to illustrate how questions should be asked. These are based on the real claim *"the US in 2017 has the largest percentage of immigrants, almost tied now with the historical high as a percentage of immigrants living in this country"*:

- Good: What was the population of the US in 2017?
- Good: How many immigrants live in the US in 2017?
- Bad: What was the population of the US? [No time specified to find a statistic]
- Bad: What was the population there in 2017? [What does *there* refer to?]
- Bad: Is it true that the US in 2017 has the largest percentage of immigrants, almost tied now with the historical high as a percentage of immigrants living in this country? [Directly paraphrases the claim]

### J.4.4 Metadata

Questions about metadata can be used to draw attention to aspects of the claim, in order to reason about publication date or publication source. If, for example, the claim *"aliens made contact with earth March 3rd, 2021"* was published on September 1st, 2020, the publication date can be used to refute the claim. In such cases, we ask annotators to first generate a question/answer pair – *"when was this claim made?" "September 1st, 2020"* – which can then be used to refute the claim. Similarly, questions about publication source can be used to refute satirical claims – *"where was this claim published?"*, *"www.theonion.com"*, *"what is The Onion?"*, *"The Onion is an American digital media company and newspaper organization that publishes satirical articles on international, national, and local news."*.

### J.4.5 Common sense assumptions and world knowledge

As a part of the question generation process, annotators may have to make assumptions and/or use world knowledge to interpret the claim. For example, for the claim *"Shakira is Canadian"*, it may be necessary to choose what it means to be Canadian. This is expressed in how questions are formulated, e.g. *"does Shakira have Canadian citizenship?"* or *"where does Shakira live?"*. This may also involve politically charged judgments. For example, some First Nations people are classed as Canadian by the Canadian government, but do not use that label for themselves.

In such cases, we ask annotators to follow – as closely as possible – the judgments made by the fact-checking websites. If the annotators feel that these are incomplete or misleading, they can add additional questions.

For example, for the claim *"Edward Heath opposed privatisation"*, a fact checker might provide his party manifesto as evidence. A corresponding question could then be *"what did the 1970 Conservative Party manifesto say about privatisation?"* An annotator could encounter evidence for the nationalisation of Rolls Royce during Heath's government, which the fact-checking article did not take into account. In that case, the annotator might want to add an additional question, such as *"did Heath's government nationalise any companies?"*. The annotators should ask *both* questions.

**Important!** As opposed to Phase 1, annotators in Phase 2 *should* use their own judgment to assign labels (although they should not ignore evidence used by the fact-checker). As such, if they disagree with the fact-checker about the label, they can select a different label.

### J.4.6 Answer Generation

To find answers to questions, the annotators can rely on metadata, or on any sources linked from the factchecking site. Where these fail to produce appropriate information – either because they are not relevant to an asked question or because they refer to sources which have been taken down – we provide search functionalities as an alternative. Note that the annotators are not allowed to use the fact-checking article itself as a source, only the pages *hyper-linked* in the fact-checking article (and



- Là một nguyên tắc chỉ dẫn, nên đặt ít nhất 2 câu hỏi. Tuy nhiên, đây không phải là giới hạn cứng, và những người chú thích có thể tiếp tục chỉ với một câu hỏi nếu họ cảm thấy không cần thêm câu hỏi nào khác.

*Các ví dụ sau được sử dụng để minh họa cách đặt câu hỏi. Đây dựa trên tuyên bố thực tế "Mỹ vào năm 2017 có tỷ lệ người nhập cư cao nhất, gần như sánh ngang với mức cao lịch sử về tỷ lệ người nhập cư sống ở quốc gia này":*

- Tốt: Dân số của Hoa Kỳ vào năm 2017 là bao nhiêu?
- Tốt: Có bao nhiêu người nhập cư sống ở Mỹ vào năm 2017?
- Tệ: Dân số của Hoa Kỳ là bao nhiêu? [Không có thời gian cụ thể để tìm số liệu thống kê]
- Tệ: Dân số ở đó là bao nhiêu vào năm 2017? [Từ 'đó' ám chỉ điều gì?]
- Tệ: Có đúng không rằng vào năm 2017, Mỹ có tỷ lệ người nhập cư lớn nhất, gần như ngang bằng với mức cao lịch sử về tỷ lệ người nhập cư sống ở quốc gia này? [Diễn giải trực tiếp lại tuyên bố ]

**J.4.4 Siêu dữ liệu**

Các câu hỏi về siêu dữ liệu có thể được sử dụng để thu hút sự chú ý đến các khía cạnh của tuyên bố, nhằm suy luận về ngày xuất bản hoặc nguồn xuất bản. Ví dụ, nếu tuyên bố "người ngoài hành tinh đã tiếp xúc với Trái đất vào ngày 3 tháng 3 năm 2021" được xuất bản vào ngày 1 tháng 9 năm 2020, ngày xuất bản có thể được sử dụng để bác bỏ tuyên bố này. Trong những trường hợp như vậy, chúng tôi yêu cầu người chú thích trước tiên tạo một cặp câu hỏi/trả lời – "khi nào tuyên bố này được đưa ra?" "Ngày 1 tháng 9 năm 2020" – mà sau đó có thể được sử dụng để bác bỏ tuyên bố. Tương tự, các câu hỏi về nguồn xuất bản có thể được sử dụng để bác bỏ các tuyên bố mang tính hài hước – "tuyên bố này được xuất bản ở đâu?", "www.theonion.com", "The Onion là gì?", "The Onion là một công ty truyền thông kỹ thuật số và tổ chức báo chí của Mỹ chuyên xuất bản các bài viết hài hước về tin tức quốc tế, quốc gia và địa phương."

**J.4.5 Giả định dựa trên lẽ thường và kiến thức về thế giới**

Như một phần của quá trình tạo câu hỏi, các người chú giải có thể phải đưa ra các giả định và/hoặc sử dụng kiến thức về thế giới để giải thích tuyên bố. Ví dụ, đối với tuyên bố "Shakira là người Canada", có thể cần phải chọn cách hiểu thế nào là người Canada. Điều này được thể hiện qua cách các câu hỏi được hình thành, ví dụ như "Shakira có quốc tịch Canada không?" hoặc "Shakira sống ở đâu?". Điều này cũng có thể liên quan đến những đánh giá mang tính chính trị. Ví dụ, một số người thuộc các dân tộc bản địa được chính phủ Canada xếp loại là người Canada, nhưng họ không tự gọi mình bằng nhãn đó.

Trong những trường hợp như vậy, chúng tôi yêu cầu người chú thích tuân theo – càng sát càng tốt – các đánh giá được thực hiện bởi các trang web kiểm chứng sự thật. Nếu người chú thích cảm thấy rằng những đánh giá này không đầy đủ hoặc gây hiểu lầm, họ có thể thêm các câu hỏi bổ sung.

Ví dụ, đối với tuyên bố "Edward Heath phản đối tư nhân hóa", một người kiểm chứng sự thật có thể cung cấp bản tuyên ngôn của đảng ông ấy như bằng chứng. Một câu hỏi tương ứng có thể là "bản tuyên ngôn của Đảng Bảo thủ năm 1970 nói gì về tư nhân hóa?" Một người chú thích có thể gặp bằng chứng về việc quốc hữu hóa Rolls Royce trong chính phủ của Heath, mà bài kiểm chứng sự thật không tính đến. Trong trường hợp đó, người chú thích có thể muốn thêm một câu hỏi bổ sung, chẳng hạn như "chính phủ của Heath có quốc hữu hóa công ty nào không?". Các người chú thích nên đặt cả hai câu hỏi.

Quan trọng! Khác với Giai đoạn 1, các người chú thích trong Giai đoạn 2 nên sử dụng sự đánh giá của riêng họ để gán nhãn (mặc dù họ không nên bỏ qua bằng chứng mà người kiểm tra thực tế đã sử dụng). Do đó, nếu họ không đồng ý với người kiểm tra thực tế về nhãn, họ có thể chọn một nhãn khác.

**J.4.6 Tạo câu trả lời**

Để tìm câu trả lời cho các câu hỏi, các người chú thích có thể dựa vào siêu dữ liệu hoặc bất kỳ nguồn nào được liên kết từ trang kiểm chứng sự thật. Khi những nguồn này không cung cấp được thông tin phù hợp – hoặc vì chúng không liên quan đến câu hỏi được đặt ra hoặc vì chúng tham chiếu đến các nguồn đã bị gỡ xuống – chúng tôi cung cấp các chức năng tìm kiếm như một phương án thay thế. Lưu ý rằng các người chú thích không được phép sử dụng bài viết kiểm chứng sự thật làm nguồn, chỉ được phép sử dụng các trang được liên kết trong bài viết kiểm chứng sự thật (và

only when they are not from fact-checking websites). Similarly, other fact-checking articles found through search should be avoided.

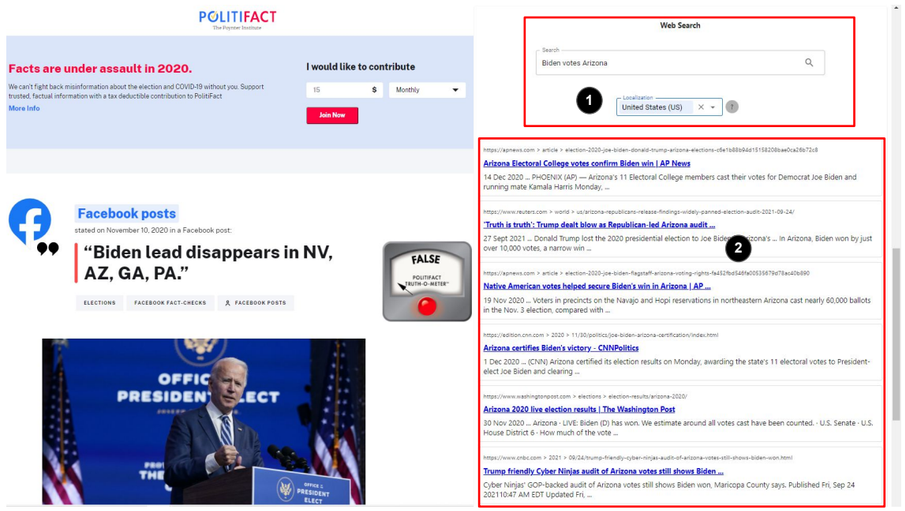



Figure 14: Interface of the search bar. (1) Search bar and the location option. Annotators can change the localization of the search engine by selecting the country code here. (2) Search results returned by the search engine.

Once an answer has been found, annotators can choose between the following four options to enter it:

- **Extractive:** The answer can be copied directly from the source. We ask the annotators to use their browser's copy-paste mechanism to enter it.
- **Abstractive:** A freeform answer can be constructed based on the source, but not directly copy-pasted.
- **Boolean:** This is a special case of abstractive answers, where a yes/no is sufficient to answer the question. A second box must be used to give an explanation for the verdict grounded in the source (e.g. "yes, because...").
- **Unanswerable:** No source can be found to answer the question.

For extractive, abstractive, and boolean answers, the annotators are also asked to copy-paste a link to the source URL they used to answer the question. Extractive answers are preferred to abstractive and boolean answers.

In some cases, annotators might find different answers from different sources. Our annotation tools allows adding additional answers, up to three. While we provide this functionality, we ask that annotators try to rephrase the question to yield a single answer before adding additional answers.

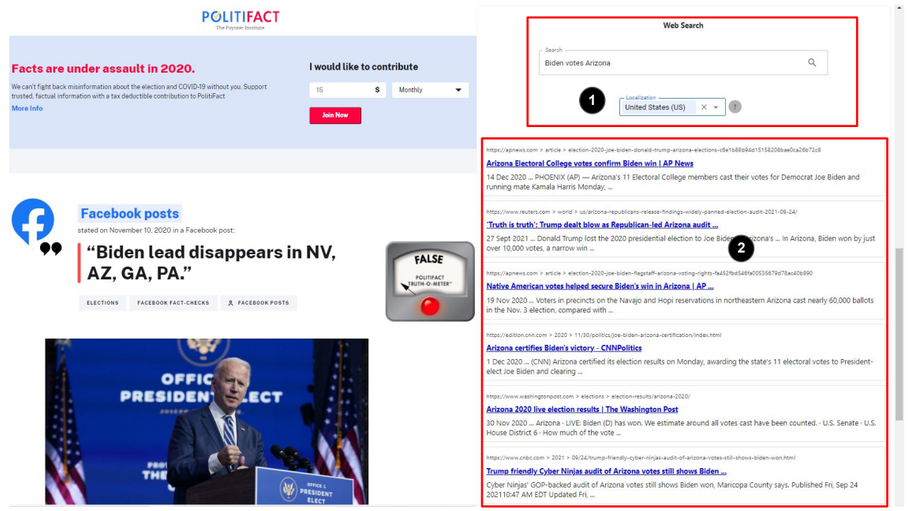
We note that if the annotators can only find a *partial* answer to a question, they can still use that. In such cases, please give the partial answer rather than marking the question as unanswerable.

Our search engine marks pages originating from known sources of misinformation and/or satire. We do not prevent annotators from using such sources, but we ask that annotators avoid them if at all possible. In the event that an annotator wishes to use information from such a source, we strongly prefer that the finds similar, corroborating information from an additional source in order to further substantiate the evidence.

While answering a question, we furthermore ask annotators to adhere to the following:



chỉ khi chúng không đến từ các trang web kiểm chứng thông tin). Tương tự, các bài viết kiểm chứng thông tin khác tìm thấy qua tìm kiếm cũng nên tránh.




Hình 14: Giao diện của thanh tìm kiếm. 1 Thanh tìm kiếm và tùy chọn vị trí. Người chú thích có thể thay đổi địa phương hóa của công cụ tìm kiếm bằng cách chọn mã quốc gia tại đây. 2 Kết quả tìm kiếm được trả về bởi công cụ tìm kiếm.

Onc Khi một câu trả lời đã được tìm thấy, những người chú thích có thể chọn giữa bốn tùy chọn sau để nhập t:

• Trích xuất: Câu trả lời có thể được sao chép trực tiếp từ nguồn. Chúng tôi yêu cầu những người chú thích sử dụng cơ chế sao chép-dán của trình duyệt để nhập nó.

Trừu tượng: Một câu trả lời tự do có thể được xây dựng dựa trên nguồn, nhưng không được sao chép trực tiếp.

• Boolean: Đây là một trường hợp đặc biệt của câu trả lời trừu tượng, nơi một câu có/không là đủ để trả lời câu hỏi. Một hộp thứ hai phải được sử dụng để đưa ra giải thích cho phán quyết dựa trên nguồn (ví dụ: "có, bởi vì...").

• Không trả lời được: Không thể tìm thấy nguồn nào để trả lời câu hỏi.

Đối với câu trả lời tóm trích, trừu tượng và đúng/sai, các người nhận xét cũng được yêu cầu sao chép-dán liên kết đến URL nguồn mà họ đã sử dụng để trả lời câu hỏi. Câu trả lời tóm trích được ưa thích hơn câu trả lời trừu tượng và đúng/sai.

Trong một số trường hợp, người chú thích có thể tìm thấy các câu trả lời khác nhau từ các nguồn khác nhau. Công cụ chú thích của chúng tôi cho phép thêm các câu trả lời bổ sung, tối đa ba câu. Khi chúng tôi cung cấp tính năng này, chúng tôi yêu cầu các người chú thích cố gắng diễn đạt lại câu hỏi để có một câu trả lời duy nhất trước khi thêm các câu trả lời bổ sung.

Chúng tôi lưu ý rằng nếu những người chú thích chỉ có thể tìm thấy một phần câu trả lời cho một câu hỏi, họ vẫn có thể sử dụng phần đó. Trong những trường hợp như vậy, vui lòng cung cấp phần câu trả lời thay vì đánh dấu câu hỏi là không thể trả lời.

Công cụ tìm kiếm của chúng tôi đánh dấu các trang xuất phát từ các nguồn thông tin sai lệch và/hoặc châm biếm đã biết. Chúng tôi không ngăn các người chú thích sử dụng những nguồn đó, nhưng chúng tôi yêu cầu các người chú thích tránh sử dụng chúng nếu có thể. Trong trường hợp một người chú thích muốn sử dụng thông tin từ nguồn như vậy, chúng tôi rất ủng hộ việc họ tìm kiếm thông tin tương tự, được xác nhận từ một nguồn bổ sung để củng cố thêm bằng chứng.

Khi trả lời một câu hỏi, chúng tôi còn yêu cầu những người chú thích tuân thủ các điều sau:

**Important!**

- DO NOT use any other browser window/search bar to find an answer. You MUST use the provided search bar only.
- DO NOT give a verdict for the claim until you have finished questions and answers.
- DO NOT use the fact-checking article itself, or any other version of it you find on the internet, as evidence to support an answer.
- DO NOT submit answers using other articles from fact-checking websites, such as politifact.com or factcheck.org, as evidence.
- DO NOT simply reference the source as an authority in abstractive answers (and boolean explanations), e.g. do not use answers like *"yes, because the Guardian says so"*. Rather, write out what the source says, e.g. *"yes, because £18.1 bn is 41% of the budget"*. If you consider it important to mention the source, write that the source says – e.g., *"yes, because according to the Guardian £18.1 bn was spent, which is 41% of the budget"*.

### J.4.7 Reasoning Chains of Claims

Annotators can build up reasoning chains across multiple questions, meaning that answers of one question can be used in the next question. For example, for the claim *"the fastest train in Japan drives at a top speed of 400 km/h"*, the first question is "What is the fastest Japanese train?". The answer is "The fastest Japanese train is Shinkansen ALFA-X". Based on the answer, we can further ask the second question to get more details, "What is the maximum operating speed of the Shinkansen ALFA-X". Note that while the *generation* of the second question assumes knowledge of the answer to the first, it is *understandable* without it.

### J.4.8 Confirmation

After submitting the question/answer pairs for a claim, annotators will be presented with a confirmation screen (see Figure 15). Annotators will be shown the question/answer pairs they have entered, along with the verdict, and asked to confirm a second time that the verdict is supported by the evidence.

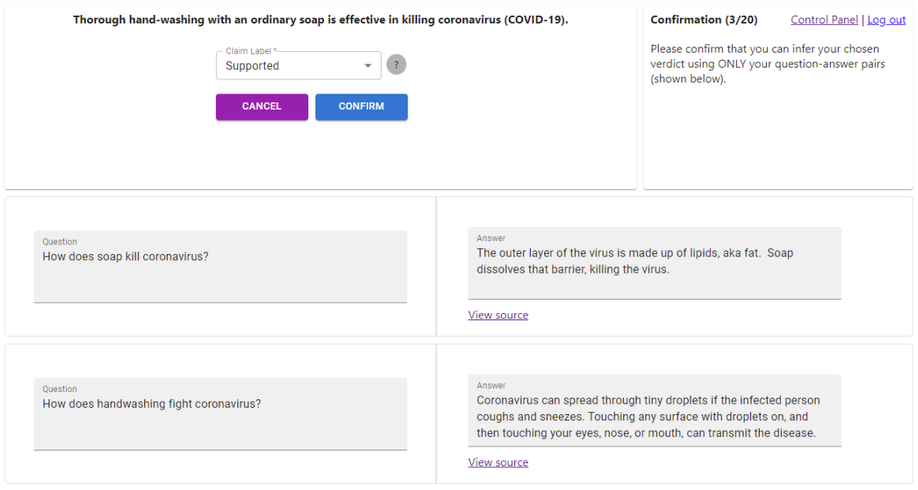



Figure 15: Before moving on to the next claim, phase two annotators will be shown a confirmation screen to make sure that their chosen verdict is correct.



**Quan trọng!**

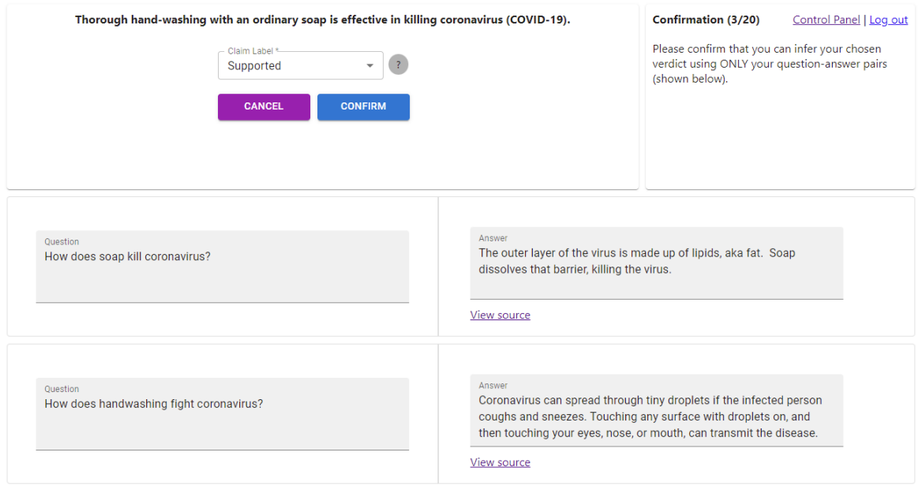
- KHÔNG sử dụng bất kỳ cửa sổ trình duyệt/thanh tìm kiếm nào khác để tìm câu trả lời. Bạn PHẢI chỉ sử dụng thanh tìm kiếm được cung cấp.
- KHÔNG đưa ra phán quyết cho yêu cầu cho đến khi bạn đã hoàn thành các câu hỏi và câu trả lời.
- KHÔNG sử dụng chính bài báo kiểm chứng sự thật, hoặc bất kỳ phiên bản nào khác của nó mà bạn tìm thấy trên internet, làm bằng chứng để hỗ trợ câu trả lời.
- KHÔNG gửi câu trả lời sử dụng các bài báo từ các trang web kiểm chứng thông tin khác, chẳng hạn như politifact.com hoặc factcheck.org, làm bằng chứng.
- KHÔNG chỉ đơn giản tham khảo nguồn như một thẩm quyền trong các câu trả lời trừu tượng (và giải thích kiểu boolean), ví dụ: không sử dụng các câu trả lời như "có, vì The Guardian nói vậy". Thay vào đó, hãy viết ra những gì nguồn nói, ví dụ: "có, vì £18,1 tỷ là 41% ngân sách". Nếu bạn cho rằng việc đề cập nguồn quan trọng, hãy viết rằng nguồn nói – ví dụ: "có, vì theo The Guardian £18,1 tỷ đã được chi, chiếm 41% ngân sách".

### J.4.7 Chuỗi Lập Luận của Các Yêu Cầu

Người chú giải có thể xây dựng chuỗi lập luận qua nhiều câu hỏi, nghĩa là câu trả lời của một câu hỏi có thể được sử dụng trong câu hỏi tiếp theo. Ví dụ, đối với tuyên bố "tàu nhanh nhất ở Nhật Bản chạy với vận tốc tối đa 400 km/h", câu hỏi đầu tiên là "Tàu nhanh nhất của Nhật Bản là gì?". Câu trả lời là "Tàu nhanh nhất của Nhật Bản là Shinkansen ALFA-X". Dựa trên câu trả lời này, chúng ta có thể tiếp tục đặt câu hỏi thứ hai để biết thêm chi tiết, "Vận tốc tối đa khi hoạt động của Shinkansen ALFA-X là bao nhiêu?". Lưu ý rằng mặc dù việc tạo câu hỏi thứ hai giả định có kiến thức về câu trả lời của câu hỏi đầu tiên, nhưng vẫn có thể hiểu được mà không cần nó.

### J.4.8 Xác nhận

Sau khi gửi các cặp câu hỏi/trả lời cho một tuyên bố, người chú thích sẽ được trình bày với một màn hình xác nhận (xem Hình 15). Người chú thích sẽ thấy các cặp câu hỏi/trả lời mà họ đã nhập, cùng với phán quyết, và được yêu cầu xác nhận lần thứ hai rằng phán quyết được hỗ trợ bởi bằng chứng.




Hình 15: Trước khi chuyển sang yêu cầu tiếp theo, các người đánh giá giai đoạn hai sẽ được hiển thị một màn hình xác nhận để đảm bảo rằng phán quyết mà họ chọn là chính xác.

## J.5 Phase 3: Quality Control

Once we have collected evidence in the form of generated questions and retrieved answers, we want to provide a measure of quality. Given a claim with associated evidence, we ask a third round of annotators to give a verdict for the claim. Crucially, the annotators at this round do not have access to the original fact-checking article, or to the claim label.

### J.5.1 Overview

Here, we give a quick overview of the quality control task; in-detail discussion can be found in the following sections. Further documentation can also be found on-the-fly using the tooltips in the annotation interface.

1. Annotators should first read the claim, the metadata, and the question-answer pairs. This is the only information which should be used during this phase
2. It is important that annotators in the quality control phase do not use web search to find additional information, or rely on background knowledge which an average English speaker might not have. Commonsense facts that are known to (almost) everyone can be used – see Section J.5.2.
3. If the claim, or any of the question-answer pairs lack context, they can be flagged. This helps us diagnose what is wrong with a set of question-answer pairs in the case annotators disagree over the label.
4. After reviewing the claim and the QA pairs, annotators should assign a label to the claim (see the four labels introduced in Section J.3.4).
5. Finally, annotators should write a short statement justifying the verdict. If any commonsense information (e.g. background knowledge which an average English speaker *is* likely to have) is used to give the verdict, but that information is not mentioned in any question-answer pair, it should be mentioned in the justification. For advice regarding justification production, see Section J.5.3.

### J.5.2 Commonsense Knowledge

When giving a verdict, annotators sometimes need to rely on commonsense knowledge. Here, we consider only basic facts which an average English speaker is likely to know – e.g. *"Earth is a planet"* or *"raindrops consist of water"*. No other information beyond the question-answer pairs can be used in this phase.

We ask annotators to be relatively strict with what they consider commonsense, but use their own judgment. For example, we would consider *"Canada is a country"* commonsense, but not *"Canada is the third-largest country in terms of land mass"*. If an annotator is in doubt as to whether something is considered commonsense, they should not consider it commonsense.

### J.5.3 Justification Production

In addition to the verdict, we as mentioned also ask annotators in Phase Three to write a short statement justifying their verdict. This justification should explain the reasoning process used to reach the verdict, along with any commonsense knowledge. If calculations or comparisons were used, e.g. *"6.3% is greater than 6.1%"* or *"10-4=6"*, they should be explicitly stated in the justification. Similarly, any rounding logic – e.g. *"4.3 million is approximately 4 million"* – should be explicitly stated here.

Other than commonsense knowledge, there should not be any new information presented in this statement. The justification should only describe how the annotators used the information present in the claim, the metadata, and the QA-pairs to reach their verdict. If a verdict cannot be reached, e.g. if the *not enough information*-label is chosen, annotators should instead describe what information is missing – e.g. *"I cannot determine if Canada is the third-largest country, because the questions do not specify how large any countries are."*

Similarly, in cases of conflicting evidence, annotators should describe which questions and answers lead to the conflict, and how they contradict – e.g. *"This claim is cherry-picked as it looks only at the*



### J.5 Giai đoạn 3: Kiểm soát chất lượng

Khi chúng tôi đã thu thập bằng chứng dưới dạng các câu hỏi được tạo ra và các câu trả lời được truy xuất, chúng tôi muốn cung cấp một thước đo chất lượng. Đối với một tuyên bố có kèm theo bằng chứng, chúng tôi yêu cầu một vòng thứ ba của các nhà chú thích đưa ra phán quyết cho tuyên bố đó. Quan trọng là, các nhà chú thích ở vòng này không được truy cập vào bài viết kiểm chứng sự thật gốc, cũng như nhãn của tuyên bố.

### J.5.1 Tổng quan

Ở đây, chúng tôi đưa ra tổng quan nhanh về nhiệm vụ kiểm soát chất lượng; phần thảo luận chi tiết có thể được tìm thấy trong các phần sau. Tài liệu bổ sung cũng có thể được tìm thấy ngay lập tức bằng cách sử dụng các gợi ý công cụ trong giao diện chú thích.

1. Người chú thích nên đọc trước tuyên bố, siêu dữ liệu và các cặp câu hỏi-trả lời. Đây là thông tin duy nhất nên được sử dụng trong giai đoạn này. 2. Điều quan trọng là các người chú thích trong giai đoạn kiểm soát chất lượng không sử dụng tìm kiếm web để tìm thêm thông tin, hoặc dựa vào kiến thức nền mà một người nói tiếng Anh bình thường có thể không có. Các sự thật phổ thông mà (gần như) mọi người đều biết có thể được sử dụng – xem Mục J.5.2. 3. Nếu tuyên bố, hoặc bất kỳ cặp câu hỏi-trả lời nào thiếu ngữ cảnh, chúng có thể được đánh dấu. Điều này giúp chúng tôi chẩn đoán những gì sai với một tập hợp các cặp câu hỏi-trả lời trong trường hợp các người chú thích không đồng ý về nhãn. 4. Sau khi xem xét tuyên bố và các cặp QA, các người chú thích nên gán một nhãn cho tuyên bố (xem bốn nhãn được giới thiệu trong Mục J.3.4). 5. Cuối cùng, các người chú thích nên viết một tuyên bố ngắn giải thích lý do cho phán quyết. Nếu bất kỳ thông tin phổ thông nào (ví dụ như kiến thức nền mà một người nói tiếng Anh bình thường có khả năng biết) được sử dụng để đưa ra

### J.5.2 Kiến thức Thường thức

Khi đưa ra phán quyết, người chú thích đôi khi cần dựa vào kiến thức phổ thông. Ở đây, chúng ta chỉ xem xét những sự thật cơ bản mà một người nói tiếng Anh trung bình có khả năng biết – ví dụ: "Trái Đất là một hành tinh" hoặc "giọt mưa bao gồm nước". Không được sử dụng bất kỳ thông tin nào khác ngoài các cặp câu hỏi-trả lời trong giai đoạn này.

Chúng tôi yêu cầu những người chú thích khá nghiêm ngặt với những gì họ coi là kiến thức thông thường, nhưng hãy sử dụng phán đoán của riêng họ. Ví dụ, chúng tôi sẽ coi "Canada là một quốc gia" là kiến thức thông thường, nhưng không phải "Canada là quốc gia lớn thứ ba về diện tích đất". Nếu một người chú thích nghi ngờ liệu điều gì đó được c oi là kiến thức thông thường hay không, họ không nên coi đó là kiến thức thông thường.

### J.5.3 Sản xuất Biện minh

Ngoài phán quyết, như đã đề cập, chúng tôi cũng yêu cầu các người chú thích trong Giai đoạn Ba viết một tuyên bố ngắn giải thích lý do cho phán quyết của họ. Lời giải thích này nên trình bày quá trình tư duy được sử dụng để đưa ra phán quyết, cùng với bất kỳ kiến thức thông thường nào. Nếu có sử dụng tính toán hoặc so sánh, ví dụ như "6,3% lớn hơn 6,1%" hoặc "10-*4=6*", chúng nên được nêu rõ ràng trong lời giải thích. Tương tự, bất kỳ logic làm tròn nào – ví dụ như "4,3 triệu xấp xỉ 4 triệu" – cũng nên được nêu rõ ở đây.

Ngoài kiến thức thông thường, không nên có bất kỳ thông tin mới nào được trình bày trong tuyên bố này. Lý do chỉ nên mô tả cách các người chú thích sử dụng thông tin có trong tuyên bố, siêu dữ liệu, và các cặp câu hỏi-trả lời để đưa ra phán quyết của họ. Nếu không thể đưa ra phán quyết, ví dụ, nếu nhãn 'không đủ thông tin' được chọn, các người chú thích nên mô tả thông tin nào đang thiếu – ví dụ: "Tôi không thể xác định liệu Canada có phải là quốc gia lớn thứ ba hay không, vì các câu hỏi không chỉ rõ kích thước của bất kỳ quốc gia nào."

Tương tự, trong các trường hợp có bằng chứng mâu thuẫn, người chú thích nên mô tả câu hỏi và câu trả lời nào dẫn đến mâu thuẫn, và cách chúng mâu thuẫn – ví dụ: "Yêu cầu này được chọn lọc một cách tùy tiện vì nó chỉ nhìn vào

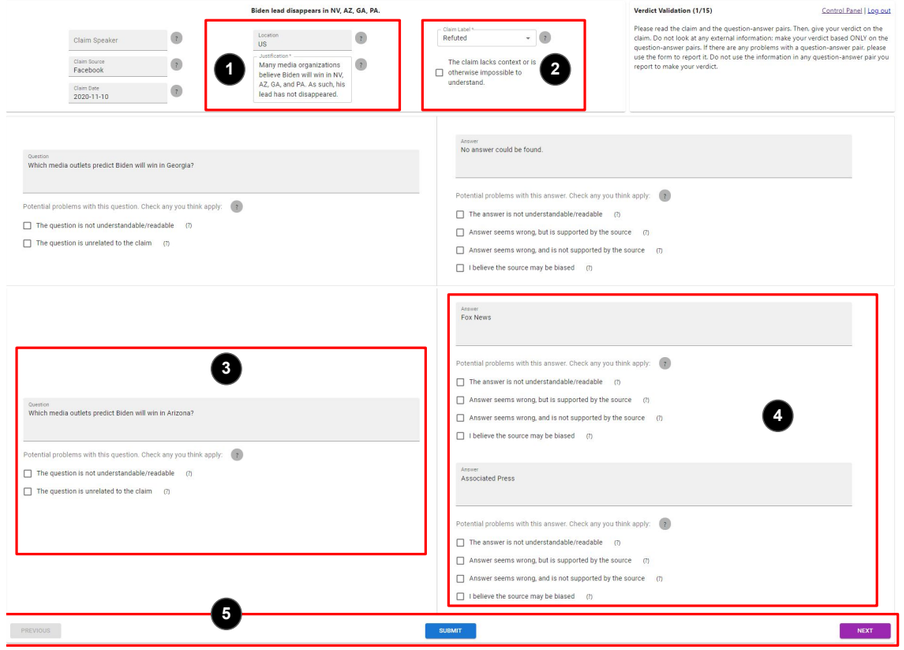



Figure 16: Interface of quality control. (1) Text field for entering the justification. (2) Label of the claim and the checkbox of unreadable. Notice that once the unreadable option is selected, annotators do not need to select the label for the claim. (3) The question corresponds to the current claim. Here we have two question-answer pairs. If the annotator think the there exist potential problems with this question, check any options applied. (4) The answers corresponds to the question on the left. If the annotator think the there exist potential problems with the answer, check any options applied. (5) Buttons for submitting the current claim, going to the previous claim, and next claim.

*price of vanilla icecream, for which an increase did take place, but leaves out other flavours, where no increase happened.*"

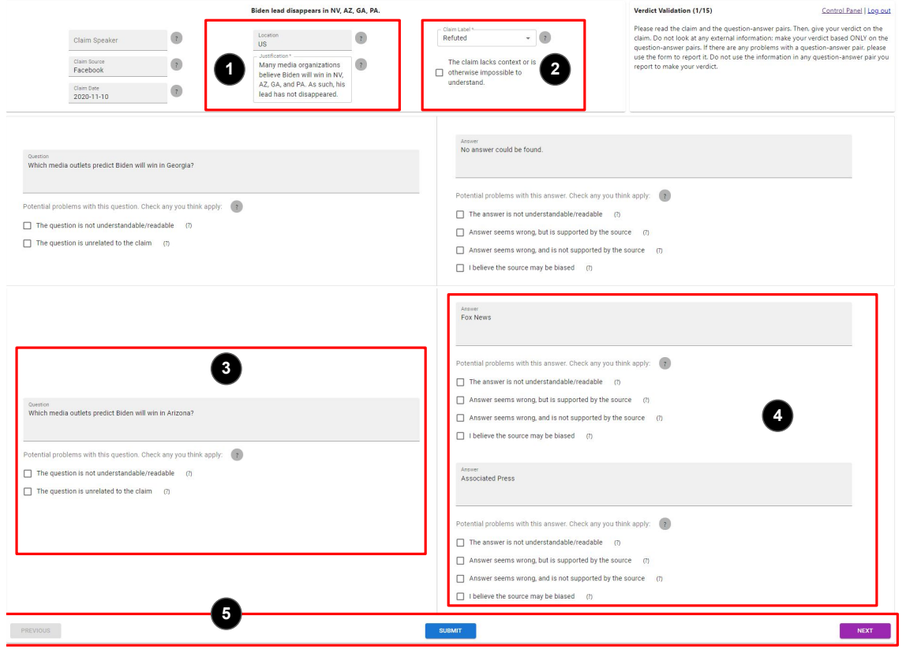
### J.6 Dispute Resolution

For some claims, there may be a disagreement between the labels produced by annotators in the question generation and quality control phases. In those cases, the claim will go through a second round of question generation and quality control. While the instructions given in Sections J.4.3 and J.5 still apply, we give a few extra recommendations specific to dispute resolution here.

#### J.6.1 Vague Claims

Some claims may pass to the dispute resolution phase because they are too vague for annotators in phases two and three to agree on the meaning. In order to catch these cases, the final step of dispute resolution – that is, the extra quality control step at the end – includes an additional label, *Claim Too Vague*. This should be select when and only when an annotator can understand the claim (e.g. it is readable), but there is too much doubt over how it is supposed to be interpreted. For example, the claim *"Ohio is the best state"* is too vague as it is not clear what "best" refers to.






Hình 16: Giao diện kiểm soát chất lượng. 1 Trường văn bản để nhập lý do biện minh. 2 Nhãn của yêu cầu và hộp kiểm không đọc được. Lưu ý rằng khi tùy chọn không đọc được được chọn, người chú thích không cần phải chọn nhãn cho yêu cầu. 3 Câu hỏi tương ứng với yêu cầu hiện tại. Ở đây chúng ta có hai cặp câu hỏi-trả lời. Nếu người chú thích nghĩ rằng có vấn đề tiềm ẩn với câu hỏi này, hãy đánh dấu bất kỳ tùy chọn nào áp dụng. 4 Các câu trả lời tương ứng với câu hỏi ở bên trái. Nếu người chú thích nghĩ rằng có vấn đề tiềm ẩn với câu trả lời này, hãy đánh dấu bất kỳ tùy chọn nào áp dụng. 5 Các nút để gửi yêu cầu hiện tại, chuyển đến yêu cầu trước và yêu cầu tiếp theo.

*giá của kem vani, mà giá đã tăng, nhưng bỏ qua các hương vị khác, nơi không có sự tăng giá nào xảy ra.*

### J.6 Giải quyết tranh chấp

Đối với một số tuyên bố, có thể có sự bất đồng giữa các nhãn do những người chú thích tạo ra trong các giai đoạn tạo câu hỏi và kiểm soát chất lượng. Trong những trường hợp đó, tuyên bố sẽ trải qua một vòng tạo câu hỏi và kiểm soát chất lượng thứ hai. Mặc dù các hướng dẫn được đưa ra trong Mục J.4.3 và J.5 vẫn áp dụng, chúng tôi đưa ra một vài khuyến nghị bổ sung cụ thể cho việc giải quyết tranh chấp ở đây.

#### J.6.1 Các Yêu Cầu Mơ Hồ

Một số tuyên bố có thể chuyển sang giai đoạn giải quyết tranh chấp vì chúng quá mơ hồ để các người gán nhãn ở giai đoạn hai và ba có thể đồng ý về ý nghĩa. Để phát hiện những trường hợp này, bước cuối cùng của giải quyết tranh chấp – tức là bước kiểm soát chất lượng bổ sung ở cuối – bao gồm một nhãn bổ sung, Tuyên Bố Quá Mơ Hồ. Nhãn này nên được chọn khi và chỉ khi một người gán nhãn có thể hiểu được tuyên bố (ví dụ: có thể đọc được), nhưng có quá nhiều nghi ngờ về cách nó nên được diễn giải. Ví dụ, tuyên bố "Ohio là bang tốt nhất" quá mơ hồ vì không rõ "tốt nhất" ám chỉ điều gì.

### J.6.2 Adding and Modifying Questions

The aim of dispute resolution is to resolve the conflict so that a potential new reader would come to a conclusive verdict. As such, the annotator should not necessarily agree with either the Phase Two or the Phase Three-verdict; they should attempt to make the fact-checking unambiguous. There may be cases where new questions must be added, and cases where existing questions should be changed but no new questions are necessary. There may also be cases where no change to the evidence is necessary at all, but where either the Phase Two or Phase Three-annotator has simply entered a wrong verdict. For this final category adding additional evidence to provide clarity can still be helpful, but it is not necessary; annotators should use their own judgment here.

### J.6.3 NEI-verdicts

A common case for dispute resolution is the situation where the Phase Two annotator has selected *Supported*, *Refuted*, or *Conflicting Evidence/Cherrypicking* as the verdict, but the Phase Three annotator has selected *Not Enough Evidence*. This can happen for example if Phase Two annotators forget to gather some of the evidence they use to reach the verdict, rely on aspects only stated in the fact-checking article without making it explicit through a question-answer pair, or overestimate the strength of the evidence they have gathered. In these cases, the aim of dispute resolution is to gather additional evidence and resolve the conflict that way; i.e. it is not sufficient to give a *Not Enough Information*-verdict without attempting to add evidence (although the same time limit as in P2 applies).



### J.6.2 Thêm và Sửa Đổi Câu Hỏi

Mục tiêu của việc giải quyết tranh chấp là để giải quyết xung đột sao cho một độc giả tiềm năng mới có thể đưa ra phán quyết cuối cùng. Do đó, người chú thích không nhất thiết phải đồng ý với phán quyết của Giai đoạn Hai hay Giai đoạn Ba; họ nên cố gắng làm cho việc kiểm tra sự thật trở nên rõ ràng. Có thể có những trường hợp cần phải thêm câu hỏi mới, và những trường hợp cần thay đổi các câu hỏi hiện có nhưng không cần thêm câu hỏi mới. Cũng có thể có những trường hợp không cần thay đổi bằng chứng gì cả, nhưng người chú thích của Giai đoạn Hai hoặc Giai đoạn Ba đã chỉ nhập một phán quyết sai. Đối với loại cuối cùng này, việc thêm bằng chứng bổ sung để làm rõ vẫn có thể hữu ích, nhưng không bắt buộc; người chú thích nên sử dụng sự đánh giá của riêng họ ở đây.

### J.6.3 Các phán quyết NEI

Một trường hợp phổ biến trong việc giải quyết tranh chấp là tình huống mà người chú thích Giai đoạn Hai đã chọn Chứng minh, Bác bỏ hoặc Bằng chứng Mâu thuẫn/Lựa chọn theo ý thích làm phán quyết, nhưng người chú thích Giai đoạn Ba đã chọn Không đủ bằng chứng. Điều này có thể xảy ra, ví dụ, nếu người chú thích Giai đoạn Hai quên thu thập một số bằng chứng mà họ sử dụng để đưa ra phán quyết, dựa vào các khía cạnh chỉ được nêu trong bài báo kiểm chứng mà không làm rõ thông qua một cặp câu hỏi-trả lời, hoặc đánh giá quá cao sức mạnh của bằng chứng mà họ đã thu thập. Trong những trường hợp này, mục tiêu của việc giải quyết tranh chấp là thu thập thêm bằng chứng và giải quyết xung đột theo cách đó; tức là chỉ đưa ra phán quyết Không đủ thông tin mà không cố gắng thêm bằng chứng là không đủ (mặc dù giới hạn thời gian giống như trong Giai đoạn Hai vẫn áp dụng).