

Think Right, Not More: Test-Time Scaling for Numerical Claim Verification

Primakov
Chungkham*
TU Delft
primakovch@gmail.com

Venktesh V*
Stockholm University
venktesh.viswanathan@dsv.su.se

Vinay Setty
University of Stavanger
vsetty@acm.org

Avishek Anand
TU Delft
avishek.anand@tudelft.nl

Abstract

Fact-checking real-world claims, particularly numerical claims, is inherently complex that require multistep reasoning and numerical reasoning for verifying diverse aspects of the claim. Although large language models (LLMs) including reasoning models have made tremendous advances, they still fall short on fact-checking real-world claims that require a combination of compositional and numerical reasoning. They are unable to understand nuance of numerical aspects, and are also susceptible to the *reasoning drift* issue, where the model is unable to contextualize diverse information resulting in misinterpretation and backtracking of reasoning process. In this work, we systematically explore scaling test-time compute (TTS) for LLMs on the task of fact-checking complex numerical claims, which entails eliciting multiple reasoning paths from an LLM. We train a verifier model (VERIFIERFC) to navigate this space of possible reasoning paths and select one that could lead to the correct verdict. We observe that TTS helps mitigate the *reasoning drift* issue, leading to significant performance gains for fact-checking numerical claims. To improve compute efficiency in TTS, we introduce an adaptive mechanism that performs TTS selectively based on the perceived complexity of the claim. This approach achieves $1.8\times$ higher efficiency than standard TTS, while delivering a notable **18.8%** performance improvement over single-shot claim verification methods. Our code and data can be found at <https://github.com/VenkteshV/VerifierFC>

1 Introduction

Automated verification of claims is critical to mitigate misinformation and disinformation. While many approaches focus on synthetically generated claims from Wikipedia (Jiang et al., 2020; Thorne

*Both authors **contributed equally** to this work

Mitigating Reasoning drift for Numerical FC

Claim: Diaspora remittances “now stand at an all-time high of over KSh400 billion in 2021”.

[Evidence 1]: diaspora remittances stand at an all-time-high at over ksh. 400 billion per annum as of 2021.

[Evidence2]: Diaspora remittances were robust in 2021, with total remittances in 2021 reaching a record USD 3,718 million. of daily users

[Verdict]: True

LLM reasoning without VERIFIERFC

[Reasoning]: The evidence provides conflicting information about the exact amount of diaspora remittances in 2021, and some sources mention figures that are not directly comparable to KSh400 billion.

[Prediction]: Conflicting

LLM reasoning with VERIFIERFC

[Reasoning]: The evidence supports the claim that diaspora remittances reached an all-time high of over KSh400 billion in 2021. However, there are minor variations in the wording and units used across different sources.

[Prediction]: True

Figure 1: Example numerical claim demonstrating *reasoning drift* issue and mitigation offered by VERIFIERFC

et al., 2018; Aly et al., 2021), recent works have focused on fact-checking real-world claims (Augenstein et al., 2019; Schlichtkrull et al., 2023; Chen et al., 2022; V et al., 2024).

Real-world claims contain numerical (quantitative and temporal) elements (V et al., 2024; Alam et al., 2025) and verifying such claims necessitates systematically comparing numerical aspects within the claim against corresponding evidence provided. Consider the example in Figure 1, where verifying the claim about diaspora remittances requires ensuring that the claimed amount (KSh400 billion) and the specified year (2021) align correctly with the evidence, even when the evidence presents the

Nghĩ Đúng, Không Nhiều Hơn: Điều Chỉnh Quy Mô Thời Gian Kiểm Tra cho Xác Thực Các Khẳng Định Số

Primakov
Chungkham*
TU Delft
primakovch@gmail.com

Venktesh V*Đại học Stockholm
venktesh.viswanatha@dsv.su.se

Vinay Setty
UĐại học Stavanger
vsetty@acm.org

Avishek Anand TU Delft
avishek.anand@tudelft.nl

Tóm tắt

Kiểm tra tính xác thực của các tuyên bố trong thế giới thực, đặc biệt là các tuyên bố về số liệu, vốn dĩ phức tạp và đòi hỏi suy luận nhiều bước cũng như lý luận số học để xác minh các khía cạnh đa dạng của tuyên bố. Mặc dù các mô hình ngôn ngữ lớn (LLM), bao gồm cả các mô hình suy luận, đã đạt được những tiến bộ to lớn, chúng vẫn còn hạn chế trong việc kiểm tra tính xác thực của các tuyên bố trong thế giới thực đòi hỏi sự kết hợp giữa suy luận tổng hợp và lý luận số học. Chúng không thể hiểu được sự tinh tế của các khía cạnh số học, và cũng dễ bị vấn đề trôi suy luận, nơi mà mô hình không thể đưa thông tin vào bối cảnh dẫn đến việc hiểu sai và phải quay lại quá trình suy luận. Trong công trình này, chúng tôi hệ thống khám phá việc mở rộng tính toán tại thời điểm thử nghiệm (TTS) cho LLM trong nhiệm vụ kiểm tra tính xác thực của các tuyên bố số phức tạp, điều này bao gồm việc khai thác nhiều con đường suy luận từ một LLM. Chúng tôi huấn luyện một mô hình xác minh (VERIFIERFC) để điều hướng trong không gian các con đường suy luận có thể có và chọn ra một con đường có thể dẫn đến

Giảm thiểu sai lệch lập luận cho FC số học

Yếu tố được nêu: Kiều hối từ cộng đồng người nước ngoài “hiện đứng ở mức cao kỷ lục hơn 400 tỷ KSh vào năm 2021”.

[Bằng chứng 1]: Kiều hối từ cộng đồng người di cư đạt mức cao nhất mọi thời đại với hơn 400 tỷ shilling Kenya mỗi năm tính đến năm 2021.

[Bằng chứng2]: Kiều hối từ cộng đồng người Việt ở nước ngoài tăng mạnh trong năm 2021, với tổng kiều hối trong năm 2021 đạt mức kỷ lục 3.718 triệu USD. của người dùng hàng ngày[Phán quyết]: Đúng

Lập luận LLM mà không có VERIFIERFC

[Lý giải]: Các bằng chứng ủng hộ cho khẳng định rằng kiều hối của cộng đồng người nhập cư đã đạt mức cao kỷ lục trên 400 tỷ KSh vào năm 2021. Tuy nhiên, có một số khác biệt nhỏ về cách diễn đạt và đơn vị được sử dụng ở các nguồn khác nhau.

[Dự đoán]: Đúng

Lập luận LLM với VERIFIERFC

[Lý giải]: Các bằng chứng ủng hộ cho khẳng định rằng kiều hối của cộng đồng người nhập cư đã đạt mức cao kỷ lục trên 400 tỷ KSh vào năm 2021. Tuy nhiên, có một số khác biệt nhỏ về cách diễn đạt và đơn vị được sử dụng ở các nguồn khác nhau.

[Dự đoán]: Đúng

Hình 1: Ví dụ về tuyên bố số học minh họa vấn đề lệch lý luận và biện pháp giảm thiểu do VERIFIERFC cung cấp

etal.,2018; Aly et al., 2021), các công trình gần đây đã tập trung vào việc kiểm chứng các tuyên bố trong thế giới thực (Augenstein et al., 2019; Schlichtkrull et al., 2023; Chen et al., 2022; V et al., 2024).

Các tuyên bố trong thực tế chứa các yếu tố số liệu (về lượng và thời gian) (V et al., 2024; Alam et al., 2025) và việc xác minh những tuyên bố này đòi hỏi phải so sánh có hệ thống các khía cạnh số liệu trong tuyên bố với bằng chứng tương ứng được cung cấp. Xem xét ví dụ trong Hình 1, việc xác minh tuyên bố về kiều hối của người di cư đòi hỏi phải đảm bảo rằng số tiền được tuyên bố (KSh400 tỷ) và năm được chỉ định (2021) khớp chính xác với bằng chứng, ngay cả khi bằng chứng trình bày

1 Giới thiệu

Xác minh tự động các tuyên bố là rất quan trọng để giảm thiểu thông tin sai lệch và thông tin bịa đặt. Trong khi nhiều phương pháp tập trung vào các tuyên bố được tạo ra tổng hợp từ Wikipedia (Jiang et al., 2020; Thorne

Cả hai tác giả đều đóng góp như nhau vào công trình này

amount in a different currency (USD). Unlike binary verification tasks, real-world claims often contain contradictory or partially correct components, making verification more complex.

Standard automated fact-checking approaches employ a multistage pipeline involving fine-tuned NLI models. Recently, Large Language Models (LLMs) have emerged as promising alternatives to NLI-based methods for claim verification (Li et al., 2024). However, these approaches have been evaluated mainly in synthetic claims, and recent studies highlight significant shortcomings when applied to complex claims in the real world that involve numerical data (V et al., 2024; Setty, 2024; Schlichtkrull et al., 2023; Augenstein et al., 2024). Although prior work has acknowledged these limitations, they have not thoroughly analyzed why LLMs fail in realistic scenarios.

To address this gap, we analyze failure modes in both open-source and proprietary models of different sizes. Beyond noise in retrieval, we identify a critical reasoning challenge even in the presence of relevant evidence introduced specifically due to multi-aspect or inability to contextualize diverse information from evidence sources, termed **reasoning drift** due to issues in its ability for accurate analysis of claims and evidence. This differs fundamentally from the “overthinking” phenomenon observed in simpler Q&A contexts, where models unnecessarily elaborate on obvious details (Sui et al., 2025). While it can impact simple claims, reasoning drift is especially pronounced in complex cases with multiple aspects and diverse evidences, leading to unfocused reasoning that strays from the core verification task. Our analysis reveals that approximately **34%** of claims in the QuanTemp dataset suffer from this reasoning problem.

In the context of fact-checking, *Reasoning drift* stems from LLMs focusing on unimportant aspects of the claim or misinterpretation of information in diverse evidences as part of its reasoning process. For instance, in the example in Figure 1 the claim mentions an amount of *400 billion Ksh* (kenyan shillings). While one of the evidences confirm this figure, the other evidence shown in the example quotes an amount of 3718 mil. USD. Though this is equivalent to 400 billion ksh, the LLM interprets this quantity as not being equivalent to the one mentioned in the claim and falls short by billions, predicting its verdict as “Conflicting”. To our knowledge, our work is the first to study the prob-

lem *reasoning drift* occurring due to **overanalysis** and explore test-time scaling as a solution to the same in the context of fact checking of real-world claims.

More formally reasoning drift due to overanalysis can be defined as the phenomenon in which:

“The LLM backtracks from it’s current accurate reasoning trajectory due to misinterpretation of diverse information which may also stem from multi-aspect nature of claims and inability to contextualize information.”

We introduce and investigate test-time scaling (TTS) (Zhang et al., 2025), an approach that allocates additional computational resources at inference time, enabling LLMs to explore multiple reasoning pathways to mitigate reasoning drift. To our knowledge, this is the first study to examine **test-time scaling** specifically for verifying complex factual claims. To effectively navigate and select from diverse reasoning paths, we train a dedicated verifier model (VERIFIERFC). Our experiments demonstrate that employing this verifier with a **best-of-N (BoN)** strategy significantly outperforms standard *majority-voting* (Wang et al., 2023) methods.

Since real-world claims are diverse, applying a fixed uniform computational effort across all claims is inefficient: simpler claims may consume unnecessary resources, and complex claims may not receive sufficient computational attention, resulting in suboptimal verification. To address this issue, we propose a novel *adaptive TTS* strategy that *dynamically* adjusts computational resources based on claim complexity, determined by analyzing *layerwise latent representations* within the LLMs. This adaptive method boosts verification performance by **18.8%** on complex numerical claims (QuanTemp) and **21.27%** on compositional claims (ClaimDecomp) compared to single-shot techniques, while also delivering **1.8x** greater computational efficiency than the standard TTS approach.

In this paper, we answer the following research questions through empirical validation:

RQ1: To what extent LLMs suffer from *reasoning drift* issue for complex numerical fact-checking tasks?

RQ2: How does test-time scaling impact the reasoning performance of LLMs for fact-checking complex numerical claims?

RQ3: How does test-time scaling compare

số tiền bằng một loại tiền tệ khác (USD). Không giống như các nhiệm vụ xác minh nhị phân, các tuyên bố trong thế giới thực thường chứa các thành phần mâu thuẫn hoặc chỉ đúng một phần, làm cho việc xác minh trở nên phức tạp hơn.

Các phương pháp kiểm tra sự thật tự động tiêu chuẩn sử dụng một quy trình đa giai đoạn liên quan đến các mô hình NLI được tinh chỉnh. Gần đây, các Mô Hình Ngôn Ngữ Lớn (LLMs) đã nổi lên như những lựa chọn thay thế đầy hứa hẹn cho các phương pháp dựa trên NLI trong việc xác minh các tuyên bố (Li và cộng sự, 2024). Tuy nhiên, các phương pháp này chủ yếu được đánh giá trên các tuyên bố tổng hợp, và các nghiên cứu gần đây nhấn mạnh những hạn chế đáng kể khi áp dụng vào các tuyên bố phức tạp trong thế giới thực có dữ liệu số (V và cộng sự, 2024; Setty, 2024; Schlichtkrull và cộng sự, 2023; Augenstein và cộng sự, 2024). Mặc dù các nghiên cứu trước đã thừa nhận những hạn chế này, nhưng chưa phân tích kỹ lý do tại sao LLMs thất bại trong các kịch bản thực tế.

Để giải quyết khoảng trống này, chúng tôi phân tích các chế độ thất bại trong cả các mô hình mã nguồn mở và mô hình sở hữu với các kích thước khác nhau. Ngoài nhiều trong quá trình truy xuất, chúng tôi xác định được một thách thức quan trọng về lý luận ngay cả khi có bằng chứng liên quan, được giới thiệu đặc biệt do nhiều khía cạnh hoặc không khả năng đặt thông tin đa dạng từ các nguồn bằng chứng vào ngữ cảnh, được gọi là sự lệch lý luận do vấn đề trong khả năng phân tích chính xác các tuyên bố và bằng chứng. Điều này khác cơ bản so với hiện tượng “suy nghĩ quá mức” được quan sát trong các bối cảnh Hỏi & Đáp đơn giản, nơi các mô hình giải thích không cần thiết các chi tiết rõ ràng (Sui et al., 2025). Mặc dù điều này có thể ảnh hưởng đến các tuyên bố đơn giản, nhưng sự lệch lý luận đặc biệt rõ rệt trong các trường hợp phức tạp với nhiều khía cạnh và bằng chứng đa dạng, dẫn đến lý luận thiếu tập trung và lệch khỏi nhiệm vụ xác minh cốt lõi. Phân tích của chúng tôi cho thấy khoảng 34% các tuyên bố trong bộ dữ liệu QuanTemp gặp vấn đề về lý luận này.

Trong bối cảnh kiểm chứng sự thật, sự lệch lạc trong lập luận xuất phát từ việc các mô hình ngôn ngữ lớn (LLMs) tập trung vào những khía cạnh không quan trọng của tuyên bố hoặc hiểu sai thông tin trong các bằng chứng khác nhau như một phần của quá trình lập luận của chúng. Ví dụ, trong ví dụ ở Hình 1, tuyên bố đề cập đến số tiền 400 tỷ Ksh (shilling Kenya). Trong khi một bằng chứng xác nhận con số này, bằng chứng khác được đưa ra trong ví dụ lại trích dẫn số tiền 3,718 tỷ USD. Mặc dù số tiền này tương đương với 400 tỷ Ksh, LLM lại hiểu số lượng này không tương đương với số được đề cập trong tuyên bố và thiếu hụt hàng tỷ, dự đoán phán quyết của nó là “Mâu thuẫn”. Theo hiểu biết của chúng tôi, công trình của chúng tôi là nghiên cứu đầu tiên khảo sát về prob-

suy luận lem xảy ra do phân tích quá mức và khám phá việc điều chỉnh quy mô trong thời gian thử nghiệm như một giải pháp cho vấn đề tương tự trong bối cảnh kiểm tra sự thật của các tuyên bố trong thế giới thực.

Một cách chính thức hơn, sự trôi dạt lý luận do phân tích quá mức có thể được định nghĩa là hiện tượng trong đó:

“Mô hình ngôn ngữ lớn (LLM) lui lại khỏi quỹ đạo lập luận chính xác hiện tại của nó do hiểu sai thông tin đa dạng, điều này cũng có thể bắt nguồn từ tính chất nhiều khía cạnh của các tuyên bố và khả năng không thể đặt thông tin vào bối cảnh.”

Chúng tôi giới thiệu và nghiên cứu phương pháp scaling thời gian kiểm tra (TTS) (Zhang et al., 2025), một phương pháp phân bổ thêm tài nguyên tính toán vào thời điểm suy diễn, cho phép các mô hình ngôn ngữ lớn (LLM) khám phá nhiều con đường lý luận để giảm thiểu sự sai lệch trong lý luận. Theo hiểu biết của chúng tôi, đây là nghiên cứu đầu tiên xem xét scaling thời gian kiểm tra đặc biệt để xác minh các khẳng định thực tế phức tạp. Để hiệu quả trong việc điều hướng và lựa chọn từ các con đường lý luận đa dạng, chúng tôi huấn luyện một mô hình xác minh chuyên dụng (VERIFIERFC). Các thí nghiệm của chúng tôi chứng minh rằng việc sử dụng mô hình xác minh này với chiến lược best-of-N (BoN) vượt trội đáng kể so với các phương pháp bỏ phiếu đa số tiêu chuẩn (Wang et al., 2023).

Vì các tuyên bố trong thế giới thực rất đa dạng, việc áp dụng cùng một mức độ nỗ lực tính toán cố định cho tất cả các tuyên bố là không hiệu quả: các tuyên bố đơn giản có thể tiêu tốn tài nguyên không cần thiết, trong khi các tuyên bố phức tạp có thể không nhận đủ sự chú ý về mặt tính toán, dẫn đến việc xác minh không tối ưu. Để giải quyết vấn đề này, chúng tôi đề xuất một chiến lược TTS thích ứng mới, điều chỉnh linh hoạt các nguồn lực tính toán dựa trên độ phức tạp của tuyên bố, được xác định bằng cách phân tích các biểu diễn tiềm ẩn theo từng lớp trong các LLM. Phương pháp thích ứng này nâng cao hiệu suất xác minh lên 18,8% đối với các tuyên bố số học phức tạp (QuanTemp) và 21,27% đối với các tuyên bố thành phần (ClaimDecomp) so với các kỹ thuật một lần thực hiện, đồng thời cung cấp hiệu quả tính toán cao hơn 1,8 lần so với phương pháp TTS tiêu chuẩn.

Trong bài báo này, chúng tôi trả lời các câu hỏi nghiên cứu sau thông qua xác thực thực nghiệm:

RQ1: Mức độ mà các LLM gặp phải vấn đề trôi lý luận trong các nhiệm vụ kiểm tra sự thật số liệu phức tạp là như thế nào?

RQ2: Việc điều chỉnh tỷ lệ tại thời điểm kiểm tra ảnh hưởng như thế nào đến hiệu suất lập luận của các LLM trong việc kiểm chứng các tuyên bố số liệu phức tạp?

RQ3: So sánh việc điều chỉnh kích thước vào thời gian kiểm tra như thế nào

to current strategies for fact-checking complex claims?

2 Related Work

2.1 Fact Checking Complex Real-World Claims

Automated fact-checking is key to mitigating growing misinformation and disinformation (Thorne et al., 2018; Aly et al., 2021; Guo et al., 2022). Existing works on automated fact-checking primarily focus on synthetic claims collected from Wikipedia (Thorne et al., 2018; Jiang et al., 2020; Aly et al., 2021; Nanekhan et al., 2025) that are not representative of real-world claims. More efforts have been made to build systems for real-world claims in domains like politics (Chen et al., 2022; Wang, 2017; Alhindi et al., 2018; Ostrowski et al., 2021; Nakov et al., 2025), science (Wadden et al., 2020; Vladika and Matthes, 2023; Wright et al., 2022), health (Kotonya and Toni, 2020) and climate (Diggelmann et al., 2021).

2.2 Reasoning drift due to overthinking in LLMs

LLMs with a large number of parameters are believed to exhibit emergent capabilities (Wei et al., 2022; Brown et al., 2020; OpenAI, 2023), including the ability to reason. Prior work shows that, when given few-shot examples, LLMs can produce step-by-step explanations (known as chains of thought or reasoning chains), resulting in improved performance on reasoning tasks (Wei et al., 2023; Huang and Chang, 2023; Yao et al., 2023b; Huang and Chang, 2023). However, there are known blindspots when used in few-shot and one-shot settings especially when numerical, temporal data is involved (Wallat et al., 2024a,b).

Moreover, recent studies show that large language models (LLMs) are prone to *overthinking* when they perform reasoning, a phenomenon where models generate unnecessarily long or elaborate reasoning chains that ultimately lead to incorrect conclusions (Sui et al., 2025; Chen et al., 2025). Overthinking has also been described as the tendency of LLMs to prioritize internal reasoning over external feedback (Cuadron et al., 2025). In knowledge-intensive tasks such as fact-checking, we observe that LLMs often backtrack or **overanalyze** their initial reasoning chain. This typically arises from the complexity of queries involving multiple aspects, or from misinterpreting conflict-

ing information in the evidence. Crucially, this reasoning gap can occur regardless of the actual length of the reasoning chain. We refer to this problem as **reasoning drift**. While prior work has explored the application of LLMs to fact-checking (Li et al., 2024), none have explicitly addressed the reasoning drift phenomenon. Our findings suggest that reasoning drift presents a significant challenge for verifying complex numerical claims.

2.3 Test Time Scaling

Test-Time Scaling is a technique to improve the reasoning performance of LLMs by allocating additional inference-time compute (Zhang et al., 2025; Venktesh et al., 2025). Early approaches primarily focused on generating multiple outputs per query in parallel and selecting an answer via majority voting (Wang et al., 2023) or search-based methods (Yao et al., 2023a; Feng et al., 2024; Xie et al., 2023). Recent developments can be broadly categorized into two lines of work: (i) modifying the proposal distribution of LLM by fine-tuning (DeepSeek-AI et al., 2025; OpenAI, 2024; Singh et al., 2024; Madaan et al., 2023; Zelikman et al., 2022; Jin et al., 2025), and (ii) training a reward / verifier model to select the preferred answer from multiple candidates (Snell et al., 2024; Wang et al., 2024; Nichols et al., 2020; Cobbe et al., 2021; Uesato et al., 2022; Lightman et al., 2023). Our methodology focuses on the latter, often referred to as *search against a verifier*. It involves sampling multiple outputs and using a trained verifier model to select the best final output or the reasoning path that led to it.

Verifiers used to select the best solution, are divided into Outcome reward models (ORM) (Cobbe et al., 2021) or Process Reward Models (PRM) (Uesato et al., 2022; Lightman et al., 2023). We adopt a PRM based verifier and while the majority of the approaches use rejection sampling training only on positive reasoning paths, we also include incorrect solutions to provide better discriminative capacity to the verifier. Existing works also apply TTS uniformly to all test sample, while some claims may not require TTS, wasting compute resources. We are the first to explore applying TTS adaptively based on complexity level of the claim, drawing inspiration from adaptive RAG (Jeong et al., 2024).

3 Methodology

In this section, we present a test-time scaling (TTS) strategy aimed at mitigating reasoning drift, a rea-

soning drift, a reasoning gap that occurs when the reasoning chain is too long or too complex, leading to incorrect conclusions.

2 Công trình liên quan

2.1 Kiểm tra thực tế các khẳng định phức tạp trong thế giới thực

Kiểm tra sự thật tự động là chìa khóa để giảm thiểu sự gia tăng thông tin sai lệch và thông tin sai lệch (Thorne và cộng sự, 2018; Aly và cộng sự, 2021; Guo và cộng sự, 2022). Các công trình hiện có về kiểm tra sự thật tự động chủ yếu tập trung vào các tuyên bố tổng hợp thu thập từ Wikipedia (Thorne và cộng sự, 2018; Jiang và cộng sự, 2020; Aly và cộng sự, 2021; Nanekhan và cộng sự, 2025) không đại diện cho các tuyên bố thực tế. Đã có nhiều nỗ lực hơn để xây dựng các hệ thống cho các tuyên bố thực tế trong các lĩnh vực như chính trị (Chen và cộng sự, 2022; Wang, 2017; Alhindi và cộng sự, 2018; Ostrowski và cộng sự, 2021; Nakov và cộng sự, 2025), khoa học (Wadden và cộng sự, 2020; Vladika và Matthes, 2023; Wright và cộng sự, 2022), sức khỏe (Kotonya và Toni, 2020) và khí hậu (Diggelmann và cộng sự, 2021).

2.2 Trôi dạt lập luận do suy nghĩ quá mức trong LLMs

Người ta tin rằng các mô hình ngôn ngữ lớn (LLM) với số lượng tham số lớn thể hiện các khả năng mới nổi (Wei et al., 2022; Brown et al., 2020; OpenAI, 2023), bao gồm khả năng lập luận. Các nghiên cứu trước đây cho thấy, khi được cung cấp các ví dụ ít ỏi, LLM có thể tạo ra các giải thích từng bước (được gọi là chuỗi tư duy hoặc chuỗi lập luận), dẫn đến cải thiện hiệu suất trong các nhiệm vụ lập luận (Wei et al., 2023; Huang và Chang, 2023; Yao et al., 2023b; Huang và Chang, 2023). Tuy nhiên, có những điểm mù đã được biết đến khi sử dụng trong các thiết lập ít ví dụ và một ví dụ, đặc biệt là khi liên quan đến dữ liệu số hoặc dữ liệu theo thời gian (Wallat et al., 2024a,b).

Hơn nữa, các nghiên cứu gần đây cho thấy các mô hình ngôn ngữ lớn (LLMs) có xu hướng suy nghĩ quá mức khi thực hiện suy luận, một hiện tượng mà các mô hình tạo ra các chuỗi suy luận dài hoặc phức tạp không cần thiết, cuối cùng dẫn đến các kết luận sai (Sui et al., 2025; Chen et al., 2025). Suy nghĩ quá mức cũng được mô tả là xu hướng của LLMs ưu tiên suy luận nội bộ hơn phản hồi bên ngoài (Cuadron et al., 2025). Trong các nhiệm vụ đòi hỏi nhiều kiến thức như kiểm tra sự thật, chúng tôi quan sát thấy rằng LLMs thường quay lại hoặc phân tích quá mức chuỗi suy luận ban đầu của chúng. Điều này thường xuất phát từ sự phức tạp của các truy vấn liên quan đến nhiều khía cạnh, hoặc từ việc hiểu sai xung đột

nhập thông tin trong bằng chứng. Quan trọng là, khoảng trống lý luận này có thể xảy ra bất kể độ dài thực tế của chuỗi lý luận. Chúng tôi gọi vấn đề này là trôi lý luận. Trong khi các nghiên cứu trước đây đã khám phá việc ứng dụng LLMs để kiểm tra sự thật (Li và cộng sự, 2024), chưa có nghiên cứu nào giải quyết rõ ràng hiện tượng trôi lý luận. Những phát hiện của chúng tôi cho thấy trôi lý luận là một thách thức đáng kể trong việc xác minh các tuyên bố số liệu phức tạp.

2.3 Thời gian kiểm tra

Test-Time Scaling là một kỹ thuật nhằm cải thiện hiệu suất suy luận của các LLM bằng cách phân bổ thêm khả năng tính toán vào thời gian suy luận (Zhang et al., 2025; Venktesh et al., 2025). Các phương pháp ban đầu chủ yếu tập trung vào việc tạo ra nhiều kết quả cho mỗi truy vấn song song và chọn ra câu trả lời thông qua bỏ phiếu đa số (Wang et al., 2023) hoặc các phương pháp dựa trên tìm kiếm (Yao et al., 2023a; Feng et al., 2024; Xie et al., 2023). Những phát triển gần đây có thể được chia thành hai hướng nghiên cứu chính: (i) điều chỉnh phân phối đề xuất của LLM bằng cách huấn luyện tinh chỉnh (DeepSeek-AI et al., 2025; OpenAI, 2024; Singh et al., 2024; Madaan et al., 2023; Zelikman et al., 2022; Jin et al., 2025), và (ii) huấn luyện một mô hình phần thưởng / kiểm chứng để chọn câu trả lời ưa thích từ nhiều ứng viên (Snell et al., 2024; Wang et al., 2024; Nichols et al., 2020; Cobbe et al., 2021; Uesato et al., 2022; Lightman et al., 2023). Phương pháp của chúng tôi tập trung vào hướng thứ hai, thường được gọi là tìm kiếm dựa vào kiểm chứng. Nó bao gồm sa

Các bộ xác minh được sử dụng để chọn giải pháp tốt nhất, được chia thành các mô hình thưởng Kết quả (ORM) (Cobbe et al., 2021) hoặc các Mô hình Thưởng Quá trình (PRM) (Uesato et al., 2022; Lightman et al., 2023). Chúng tôi áp dụng một bộ xác minh dựa trên PRM và trong khi phần lớn các phương pháp chỉ sử dụng huấn luyện theo mẫu từ chỗi trên các đường suy luận tích cực, chúng tôi cũng bao gồm các giải pháp sai để cung cấp khả năng phân biệt tốt hơn cho bộ xác minh. Các công trình hiện có cũng áp dụng TTS đồng đều cho tất cả các mẫu thử, trong khi một số yêu cầu có thể không cần TTS, gây lãng phí tài nguyên tính toán. Chúng tôi là những người đầu tiên khám phá việc áp dụng TTS một cách thích ứng dựa trên mức độ phức tạp của yêu cầu, lấy cảm hứng từ RAG thích ứng (Jeong et al., 2024).

3 Phương pháp luận

Trong phần này, chúng tôi trình bày một chiến lược điều chỉnh thời gian kiểm tra (TTS) nhằm giảm thiểu hiện tượng trôi suy luận, một rea-




Figure 2: Training and inference of complexity assignment pipeline using latent representation-based method for adaptive decomposition.

soning failure wherein the model fails to prioritize relevant information or misconstrues aspects of the claim during inference. Our approach involves training a process verifier (Section 3.1) to select more accurate reasoning chains from multiple candidates. To further reduce unnecessary compute on straightforward claims, we explore an adaptive TTS mechanism that predicts claim complexity using layer-wise latent representations from the base LLM (Section 3.2). We adopt a standard fact-checking pipeline of BM25 retrieval + re-ranking to extract evidences for claim and employ LLMs for claim verification instead of standard NLI models.

3.1 Verifier for best path selection in TTS

Test-time scaling using a best-of- N strategy, in the context of fact-checking, entails generating multiple candidate reasoning paths for verifying a claim c , followed by selecting the best verdict using a verifier $\mathcal{V}$. We propose training a *process-based verification model* that scores reasoning paths rather than just final verdicts for a given claim, enabling the selection of the most insightful path for verification.

More formally, given a training corpus D of claims (c_i) and corresponding expert fact-checker verdicts (y_i), where $D = \{(c_1, y_1), \dots, (c_n, y_n)\}$, we first sample m different reasoning paths $\{(e_{11}, \dots, e_{1m}), \dots, (e_{n1}, \dots, e_{nm})\}$ from a pre-trained LLM $\mathcal{F}_{LLM}$ for each claim during the claim verification phase, along with their corresponding predicted verdicts $\{(\hat{y}_{11}, \dots, \hat{y}_{1m}), \dots, (\hat{y}_{n1}, \dots, \hat{y}_{nm})\}$. We then generate training data for the verifier by labelling each $(c_i, e_{ij}, \hat{y}_{ij})$ pair as 1 (positive sample) if


the predicted verdict matches the ground-truth ($\hat{y}_{ij} == y_i$), and 0 otherwise (negative sample).

We use this constructed dataset of positive and negative reasoning paths to train the verifier model $\mathcal{V}(sc_i | (c_i, e_{ij}, \hat{y}_{ij}))$, which takes as input the original claim c_i , a reasoning path e_{ij} , and its corresponding predicted verdict $\hat{y}_{ij}$, and outputs a score based on the plausibility of the path leading to the correct verdict. The model is fine-tuned to assign higher scores to more appropriate reasoning paths by minimising a binary cross-entropy loss:

$$\mathcal{L}_{\mathcal{V}} = - [y_i \cdot \log \mathcal{V}(sc_i | (c_i, e_{ij}, \hat{y}_{ij})) + (1 - y_i) \cdot \log(1 - \mathcal{V}(sc_i | (c_i, e_{ij}, \hat{y}_{ij})))]$$

The existing process verification approaches for training verifier primarily focus on rejection sampling when generating training data where only positive samples are considered. However, the supervision from training data generated above, helps the verifier account for nuances in the claim verification process by learning the ability to distinguish better between plausible and incorrect paths.

During inference for a test claim c_i we generate m such reasoning paths $\{(e_{11}, \hat{y}_{11}), \dots, (e_{1m}, \hat{y}_{1m})\}$ and employ the verifier to score these reasoning paths by extracting logits score from output of the verifier $\mathcal{V}(sc_i | (c_i, e_{ij}, \hat{y}_{ij}))$. The path with highest score is given as outcome of claim verification process. However, this best of N (BoN) strategy applies TTS for all claims uniformly not accounting for a scenario where TTS might not be useful. This is not compute-optimal and we propose an adaptive BoN strategy to circumvent this issue.



Hình 2: Tr Đào tạo và suy luận của quy trình phân công độ phức tạp sử dụng phương pháp dựa trên biểu diễn tiềm ẩn cho dec thích ứng đại luận

sự thất bại trong lập luận, trong đó mô hình không ưu tiên các thông tin liên quan hoặc hiểu sai các khía cạnh của tuyên bố trong quá trình suy luận. Phương pháp của chúng tôi bao gồm việc đào tạo một bộ xác minh quy trình (Mục 3.1) để chọn các chuỗi lập luận chính xác hơn từ nhiều ứng viên. Để giảm thiểu việc tính toán không cần thiết trên các tuyên bố đơn giản, chúng tôi khám phá một cơ chế TTS thích ứng dự đoán độ phức tạp của tuyên bố sử dụng các biểu diễn tiềm ẩn theo lớp từ LLM cơ bản (Mục 3.2). Chúng tôi áp dụng một quy trình kiểm chứng sự thật tiêu chuẩn bao gồm tìm kiếm BM25 + và xếp hạng lại để trích xuất bằng chứng cho tuyên bố và sử dụng LLM cho việc xác minh tuyên bố t hay vì các mô hình NLI tiêu chuẩn.

3.1 Bộ xác minh cho việc chọn đường dẫn tốt nhất trong TTS

Tăng quy mô thời gian kiểm tra bằng cách sử dụng chiến lược best-of- N , trong bối cảnh kiểm tra sự thật, bao gồm việc tạo ra nhiều lộ trình lý luận ứng viên để xác minh một tuyên bố c , sau đó chọn phán quyết tốt nhất bằng cách sử dụng một bộ xác minh $\mathcal{V}$. Chúng tôi đề xuất đào tạo một mô hình xác minh dựa trên quy trình, đánh giá các lộ trình lý luận thay vì chỉ các phán quyết cuối cùng cho một tuyên bố nhất định, cho phép chọn lộ trình thấu đáo nhất để xác minh.

Một cách chính thức hơn, cho một tập hợp dữ liệu đào tạo D gồm các tuyên bố (c_i) và các phán quyết của chuyên gia kiểm tra sự thật tương ứng (y_i), nơi $D = \{(c_1, y_1), \dots, (c_n, y_n)\}$, trước tiên chúng ta lấy mẫu m con đường lập luận khác nhau $\{(e_{11}, \dots, e_{1m}), \dots, (e_{n1}, \dots, e_{nm})\}$ từ một mô hình ngôn ngữ lớn đã được huấn luyện trước $\mathcal{F}_{LLM}$ cho mỗi tuyên bố trong giai đoạn xác minh tuyên bố, cùng với các phán quyết dự đoán tương ứng của chúng $\{(\hat{y}_{11}, \dots, \hat{y}_{1m}), \dots, (\hat{y}_{n1}, \dots, \hat{y}_{nm})\}$. Sau đó, chúng tôi tạo dữ liệu đào tạo cho bộ xác minh bằng cách gán nhãn mỗi cặp $(c_i, e_{ij}, \hat{y}_{ij})$ là 1 (mẫu dương) nếu

phán quyết dự đoán khớp với kết quả thực tế ($\hat{y}_{ij} == y_i$), và 0 nếu không (mẫu âm).

Chúng tôi sử dụng bộ dữ liệu được xây dựng gồm các đường dẫn lý luận tích cực và tiêu cực này để huấn luyện mô hình kiểm chứng $\mathcal{V}(sc_i | (c_i, e_{ij}, \hat{y}_{ij}))$, lấy làm đầu vào là tuyên bố gốc c_i , một đường suy luận e_{ij} , và phán quyết dự đoán tương ứng $\hat{y}_{ij}$, và xuất ra điểm dựa trên tính hợp lý của đường dẫn đến phán quyết đúng. Mô hình được tinh chỉnh để gán điểm cao hơn cho các đường dẫn lý luận phù hợp hơn bằng cách giảm thiểu mất mát entropy chéo nhị phân:

$$\mathcal{L}_{\mathcal{V}} = - [y_i \cdot \log \mathcal{V}(sc_i | (c_i, e_{ij}, \hat{y}_{ij})) + (1 - y_i) \cdot \log(1 - \mathcal{V}(sc_i | (c_i, e_{ij}, \hat{y}_{ij})))]$$

Các phương pháp xác minh quy trình hiện có để huấn luyện bộ xác thực chủ yếu tập trung vào việc lấy mẫu từ chối khi tạo dữ liệu huấn luyện, nơi chỉ xem xét các mẫu tích cực. Tuy nhiên, việc giám sát từ dữ liệu huấn luyện được tạo ra ở trên giúp bộ xác thực cân nhắc những sắc thái trong quá trình xác minh tuyên bố bằng cách học khả năng phân biệt tốt hơn giữa các đường đi hợp lý và không chính xác.

Trong quá trình suy luận cho một yêu cầu kiểm tra c_i chúng tôi tạo ra m các đường đi lý luận như vậy $\{(e_{11}, \hat{y}_{11}), \dots, (e_{1m}, \hat{y}_{1m})\}$ và sử dụng bộ xác minh để chấm điểm các đường đi lý luận này bằng cách trích xuất điểm logits từ đầu ra của bộ xác minh $\mathcal{V}(sc_i | (c_i, e_{ij}, \hat{y}_{ij}))$. Đường đi có điểm cao nhất được đưa ra như kết quả của quá trình xác minh yêu cầu. Tuy nhiên, chiến lược tốt nhất trong số N (BoN) này áp dụng TTS cho tất cả các yêu cầu một cách đồng đều mà không tính đến trường hợp TTS có thể không hữu ích. Điều này không tối ưu về mặt tính toán và chúng tôi đề xuất một chiến lược BoN thích ứng để khắc phục vấn đề này.

3.2 Adaptive Test-Time Scaling (TTS)

We adopt a semi-supervised approach to estimate the *complexity* of a claim by leveraging sub-question decomposition and clustering in the latent representation space of a language model. Our method is inspired by recent work on Adaptive RAG (Jeong et al., 2024; Mallen et al., 2023), which uses query complexity annotations to guide inference-time control in retrieval-augmented generation. In our case, we define complexity whether the claim requires decomposition to correctly verify its veracity. This decomposition signal serves as a proxy for reasoning difficulty, which we use to determine whether a claim should *trigger TTS*.

We construct the training data for adaptive TTS by annotating claims with sub-questions and track the number required to resolve the claim’s veracity correctly. Claims are then categorized into two levels of complexity: level 0 includes claims that can be correctly verified without any decomposition; level 1 includes claims that require one or more sub-questions and are correctly verified after decomposition; and claims that remain misclassified even after decomposition are also assigned to level 1, reflecting unresolved ambiguity or model uncertainty.

Our adaptive decomposition decision algorithm draws inspiration from CTRLA (Liu et al., 2024), which posits that LLM latent representations encode semantically meaningful attributes. As shown in Figure 2, we extract latent representations and assign complexity labels accordingly.

We annotate a training set of claims $D_k = \{c_1, c_2, \dots, c_n\}$ with complexity level k . Each claim is passed through a pretrained LLM $\mathcal{F}_{\text{LLM}}$, with L layers and latent size h , to extract token-level latent representations, following prior work on semantic properties of latent representations (Sun et al., 2025; Chuang et al., 2024). For an input claim c_i with t tokens, its latent representation $\mathbf{r}^l$ for layer l is defined as:

$$\begin{aligned} \mathbf{r}^l &= \mathcal{F}_{\text{LLM}}^l(c_i) \\ &= [\mathbf{r}_{i,1}^{(l)}, \mathbf{r}_{i,2}^{(l)}, \dots, \mathbf{r}_{i,t}^{(l)}] \in \mathbb{R}^{t \times h} \end{aligned}$$

More generally, the set of token representations across all layers can be expressed as:

$$\mathcal{F}_{\text{LLM}}(c_i) = \left\{ \mathbf{r}_{i,j}^l \in \mathbb{R}^h \mid 1 \leq j \leq t, 1 \leq l \leq L \right\},$$

where $\mathbf{r}_{i,j}^l$ is the hidden representation of the j^{th} token at layer l . Then, we summarize this representation using the last token as a proxy for the entire

claim (following (Vaswani et al., 2023)). Formally, the pooled representation at layer l is defined as:

$$\mathbf{z}_i^l = \mathcal{P}(\{\mathbf{r}_{i,j}^l\}_{j=1}^t) = \mathbf{r}_{i,t}^l \quad \text{for } 1 \leq l \leq L,$$

where $\mathcal{P}$ denotes the pooling function over the token dimension. Generally, this can be represented as:

$$\mathcal{Z}_i = \left\{ \mathbf{z}_i^l \in \mathbb{R}^h \mid 1 \leq l \leq L \right\}.$$

We then apply Principal Component Analysis (PCA) to $\{\mathbf{z}_i^l\}_{i=1}^n$ for each layer l , and extract the first principal component:

$$\mathbf{u}_k^l = \text{PCA}_1 \left(\left\{ \mathbf{z}_i^l \right\}_{i=1}^n \right),$$

yielding complexity level representations:

$$\mathcal{U}_k = \left\{ \mathbf{u}_k^l \right\}_{l=1}^L,$$

For a test claim c , we extract its layerwise representations:

$$\mathcal{C} = \left\{ \mathbf{c}^l \in \mathbb{R}^h \mid 1 \leq l \leq L \right\}.$$

Cosine similarity is computed with each class prototype at each layer:

$$\begin{aligned} \mathcal{S} &= \left\{ \mathbf{s}^l \in \mathbb{R}^{|K|} \mid \mathbf{s}_k^l = \cos(\mathbf{c}^l, \mathbf{u}_k^l), \right. \\ &\quad \left. 1 \leq k \leq |K|, 1 \leq l \leq L \right\} \end{aligned}$$

where $\mathbf{s}_k^l$ is the similarity with class k at layer l . We assign:

$$\hat{k}^l = \arg \max_k \mathbf{s}_k^l$$

and the final predicted complexity class is determined via majority voting across $\{\hat{k}^l\}_{l=1}^L$. This approach is similar to prototypical classification in ML literature (Snell et al., 2017; Sourati et al., 2024) or nearest centroid / rocchio classifier (Rocchio, 1971). The approach primarily pre-computes and indexes latent representations for complexity classes. Then at inference time we extract latent representations for the test claim and assign the complexity class based on the representation that is closest as measured by cosine similarity, similar to Rocchio classifier in IR literature. Based on the inferred complexity, we apply adaptive test-time scaling: one-shot inference for level-0 claims, and expanded reasoning for level-1 (moderate or high complexity) claims. This yields a compute-efficient TTS strategy for complex fact-checking, as shown in Section 5.

3.2 Điều chỉnh Thời gian Kiểm tra Thích ứng (TTS)

Chúng tôi áp dụng một phương pháp bán giám sát để ước lượng mức độ phức tạp của một tuyên bố bằng cách tận dụng việc phân tách các câu hỏi phụ và phân cụm trong không gian đại diện tiềm ẩn của mô hình ngôn ngữ. Phương pháp của chúng tôi được lấy cảm hứng từ các nghiên cứu gần đây về Adaptive RAG (Jeong et al., 2024; Mallen et al., 2023), vốn sử dụng các ghi chú về độ phức tạp của truy vấn để hướng dẫn việc kiểm soát trong thời gian suy luận trong quá trình tạo được tăng cường truy xuất. Trong trường hợp của chúng tôi, chúng tôi xác định độ phức tạp dựa trên việc liệu tuyên bố có cần phân tách để xác minh đúng đắn tính xác thực của nó hay không. Tín hiệu phân tách này đóng vai trò như một thước đo cho độ khó về lý luận, mà chúng tôi sử dụng để xác định liệu một tuyên bố có nên kích hoạt TTS hay không.

Chúng tôi xây dựng dữ liệu huấn luyện cho TTS thích ứng bằng cách chú thích các tuyên bố với các câu hỏi phụ và theo dõi số lượng cần thiết để xác minh chính xác tính xác thực của tuyên bố. Các tuyên bố sau đó được phân loại thành hai mức độ phức tạp: mức 0 bao gồm các tuyên bố có thể được xác minh chính xác mà không cần bất kỳ sự phân rã nào; mức 1 bao gồm các tuyên bố yêu cầu một hoặc nhiều câu hỏi phụ và được xác minh chính xác sau khi phân rã; và các tuyên bố vẫn bị phân loại sai ngay cả sau khi phân rã cũng được gán vào mức 1, phản ánh sự mơ hồ chưa được giải quyết hoặc sự không chắc chắn của mô hình.

Thuật toán quyết định phân rã thích ứng của chúng tôi lấy cảm hứng từ CTRLA (Liu và cộng sự, 2024), cho rằng các biểu diễn tiềm ẩn của LLM mã hóa các thuộc tính mang ý nghĩa ngữ nghĩa. Như minh họa trong Hình 2, chúng tôi trích xuất các biểu diễn tiềm ẩn và gán nhãn độ phức tạp tương ứng.

Chúng tôi chú thích một tập huấn luyện các tuyên bố $D_k = \{c_1, c_2, \dots, c_n\}$ với mức độ phức tạp k . Mỗi tuyên bố được đưa qua một LLM đã được huấn luyện trước $\mathcal{F}_{\text{LLM}}$, với L lớp và kích thước tiềm ẩn h , để trích xuất các biểu diễn tiềm ẩn ở cấp token, theo các nghiên cứu trước về các thuộc tính ngữ nghĩa của các biểu diễn tiềm ẩn (Sun et al., 2025; Chuang et al., 2024). Đối với một tuyên bố đầu vào c_i với t token, biểu diễn tiềm ẩn $\mathbf{r}^l$ của nó cho lớp l được định nghĩa như sau:

$$\begin{aligned} \mathbf{r}^l &= \mathcal{F}_{\text{LLM}}^l(c_i) \\ &= [\mathbf{r}_{i,1}^{(l)}, \mathbf{r}_{i,2}^{(l)}, \dots, \mathbf{r}_{i,t}^{(l)}] \in \mathbb{R}^{t \times h} \end{aligned}$$

Nói chung hơn, tập hợp các biểu diễn token trên tất cả các lớp có thể được biểu diễn như sau:

$$\mathcal{F}_{\text{LLM}}(c_i) = \left\{ \mathbf{r}_{i,j}^l \in \mathbb{R}^h \mid 1 \leq j \leq t, 1 \leq l \leq L \right\},$$

nơi $\mathbf{r}_{i,j}^l$ là biểu diễn ẩn của token j^{th} tại lớp l . Sau đó, chúng tôi tóm tắt biểu diễn này sử dụng token cuối cùng làm đại diện cho toàn bộ

khẳng định (theo (Vaswani et al., 2023)). Về mặt hình thức, biểu diễn gộp ở lớp l được định nghĩa như sau:

$$\mathbf{z}_i^l = \mathcal{P}(\{\mathbf{r}_{i,j}^l\}_{j=1}^t) = \mathbf{r}_{i,t}^l \quad \text{for } 1 \leq l \leq L,$$

trong đó $\mathcal{P}$ biểu thị hàm gộp trên chiều token. Nói chung, điều này có thể được biểu diễn như sau:

$$\mathcal{Z}_i = \left\{ \mathbf{z}_i^l \in \mathbb{R}^h \mid 1 \leq l \leq L \right\}.$$

Sau đó chúng tôi áp dụng Phân tích Thành phần Chính (PCA) cho $\{\mathbf{z}_i^l\}_{i=1}^n$ cho mỗi lớp l , và trích xuất thành phần chính đầu tiên:

$$\mathbf{u}_k^l = \text{PCA}_1 \left(\left\{ \mathbf{z}_i^l \right\}_{i=1}^n \right),$$

tạo ra các biểu diễn mức độ phức tạp:

$$\mathcal{U}_k = \left\{ \mathbf{u}_k^l \right\}_{l=1}^L,$$

Đối với một yêu cầu kiểm tra c , chúng tôi trích xuất các biểu diễn theo từng lớp của nó:

$$\mathcal{C} = \left\{ \mathbf{c}^l \in \mathbb{R}^h \mid 1 \leq l \leq L \right\}.$$

Độ tương đồng cosine được tính với từng nguyên mẫu lớp ở mỗi tầng:

$$\begin{aligned} \mathcal{S} &= \left\{ \mathbf{s}^l \in \mathbb{R}^{|K|} \mid \mathbf{s}_k^l = \cos(\mathbf{c}^l, \mathbf{u}_k^l), \right. \\ &\quad \left. 1 \leq k \leq |K|, 1 \leq l \leq L \right\} \end{aligned}$$

trong đó $\mathbf{s}_k^l$ là độ tương đồng với lớp k tại tầng l . Chúng tôi gán:

$$\hat{k}^l = \arg \max_k \mathbf{s}_k^l$$

và lớp độ phức tạp dự đoán cuối cùng được xác định thông qua bỏ phiếu đa số trên $\{\hat{k}^l\}_{l=1}^L$. Cách tiếp cận này tương tự như phân loại nguyên mẫu trong tài liệu ML (Snell et al., 2017; Sourati et al., 2024) hoặc bộ phân loại gần tâm / Rocchio (Rocchio, 1971). Cách tiếp cận chủ yếu tính toán trước và lập chỉ mục các biểu diễn tiềm ẩn cho các lớp độ phức tạp. Sau đó, khi suy luận, chúng tôi trích xuất các biểu diễn tiềm ẩn cho yêu cầu kiểm thử và gán lớp độ phức tạp dựa trên biểu diễn gần nhất đo bằng độ tương đồng cosine, tương tự như bộ phân loại Rocchio trong tài liệu IR. Dựa trên độ phức tạp suy luận được, chúng tôi áp dụng điều chỉnh quy mô tại thời điểm kiểm thử thích ứng: suy luận một lần cho các yêu cầu cấp-0, và lập luận mở rộng cho các yêu cầu cấp-1 (độ phức tạp trung bình hoặc cao). Điều này tạo ra một chiến lược TTS tiết kiệm tính toán cho việc kiểm chứng sự thật phức tạp, như được thể hiện trong Mục 5.

4 Experimental Setup

Datasets. We evaluate our methods on **QuanTemp** (V et al., 2024), which is the first benchmark for complex numerical claims. It comprises 9935 training, 3084 validation and 2495 test claims. We employ their training set to train the verifier model and create representations for the complexity classes, which are used for adaptive TTS.

ClaimDecomp (Chen et al., 2022) is another benchmark dataset that focuses on compositional real-world claims. We use its evaluation set (200 claims) to test the generalization capabilities of our verifier (trained on QuanTemp) to other types of complex claims.

Fact-checking pipeline: We use a standard fact-checking pipeline as adopted in (V et al., 2024) which comprises an initial retrieval of top-100 results for each claim using BM25 (Elasticsearch). We then re-rank using paraphrase-MiniLM-L6-v2 (Reimers and Gurevych, 2019) to select top-3 evidence snippets for each claim.

Metrics: We use per-class F1 scores, macro and weighted F1 score as evaluation metrics.

LLMs used for claim verification: We use Llama 3.1 (8B) and gpt-4o-mini as LLMs for claim verification stage and Deepseek-r1 which internally does TTS as baseline. We employ a temperature of 0.45 for generating diverse reasoning paths in TTS setting. We use Few-shot Chain of Thought (COT) prompting (in **Figure 10**) for eliciting reasoning for all baselines and our approach. We experiment with different number of reasoning paths ($m=1,3,5,10$) as elaborated in Section 5.

Verifier model for TTS: The Verifier model used for Best-of-N in TTS setting is based on the Llama-3.2-3B model. It is fine-tuned for classification using LoRA adapters (Hu et al., 2021) with a rank of 8 and a scaling factor (α) of 16. The model is fine-tuned for 3 epochs with a batch size of 32, using the AdamW optimizer with $\epsilon = 1 \times 10^{-8}$ and an initial learning rate of 1×10^{-3} .

Prompts: All prompts for claim verification, decomposition and LLM based annotations can be found in Appendix C.

5 Experimental Results

5.1 LLM Reasoning Drift - Manual Analysis

To answer **RQ1**, we conduct a systematic study of *reasoning drift* in numerical claim verification using QuanTemp. From a stratified sample of 100

claims, we use a system prompt (Figure 8) and a few-shot prompt with annotated examples (Figure 9, Appendix C) to instruct an LLM judge (gpt-4o-mini) to label each reasoning path as exhibiting *reasoning drift* (1) or not (0).

Two human annotators (graduate volunteers) then independently verify whether the LLM’s label is correct, following the guidelines in Appendix A. We report a Cohen’s Kappa of **74.13** indicating substantial agreement and LLM judge is **69%** accurate. Based on this procedure, after correcting the LLM judge outcomes, we find that approximately **34%** of sampled claims exhibit *reasoning drift*, suggesting it is a common and non-trivial failure mode. Examples are shown in Figure 1, Table 3, and Figures 6, 7 (Appendix B).

5.2 Effectiveness of test-time scaling for Claim Verification

To address **RQ2**, we evaluate TTS as a mitigation strategy (Section 3) with results shown in Table 1. We first establish a theoretical upper bound, where a perfect verifier selects the correct reasoning path and verdict whenever present.

As shown in Table 1, the upper bound achievable via TTS—across different LLMs—surpasses the oracle performance of fine-tuned NLI models reported in V et al. (2024). The *Oracle fine-tuned* row reflects state-of-the-art NLI models (e.g., RoBERTa-large) trained on human-written justifications and provided those at inference. In contrast, the TTS upper bound relies entirely on LLM-generated reasoning, without any human-authored justifications. This highlights LLMs’ ability to elicit appropriate reasoning processes for complex fact-checking when guided by TTS.

Self-consistency (Wang et al., 2023), which aggregates multiple reasoning paths via majority voting, performs only marginally better than—or sometimes worse than—top-1 decoding. This is because it assumes the most frequent verdict is correct, overlooking the nuanced reasoning often required in fact-checking, especially for conflicting claims with diverse evidence.

As shown in Table 1, our trained verifier in both BoN and Adaptive BoN settings effectively selects the best reasoning path by leveraging task-specific signals. Adaptive BoN, which invokes TTS based on the predicted claim complexity, improves over top-1 decoding by **18.8%** and self-consistency by **16.69%** (Macro-F1 on QuanTemp). Adaptive BoN

4 Thiết lập Thí nghiệm

Bộ dữ liệu. Chúng tôi đánh giá các phương pháp của mình trên QuanTemp (V et al., 2024), đây là bộ chuẩn đầu tiên cho các khẳng định số phức tạp. Nó bao gồm 9935 khẳng định huấn luyện, 3084 khẳng định xác thực và 2495 khẳng định kiểm tra. Chúng tôi sử dụng bộ huấn luyện của họ để huấn luyện mô hình kiểm chứng và tạo các biểu diễn cho các lớp phức tạp, được sử dụng cho TTS thích ứng.

ClaimDecomp (Chen và cộng sự, 2022) là một bộ dữ liệu chuẩn khác tập trung vào các tuyên bố thực tế có tính cấu thành. Chúng tôi sử dụng tập đánh giá của nó (200 tuyên bố) để thử khả năng tổng quát hóa của bộ xác thực của chúng tôi (được huấn luyện trên QuanTemp) đối với các loại tuyên bố phức tạp khác.

Quy trình kiểm chứng sự thật: Chúng tôi sử dụng một quy trình kiểm chứng sự thật tiêu chuẩn theo phương pháp được áp dụng trong (V et al., 2024), bao gồm việc truy xuất ban đầu 100 kết quả hàng đầu cho mỗi tuyên bố bằng cách sử dụng BM25 (Elasticsearch). Sau đó, chúng tôi xếp lại thứ hạng bằng paraphrase-MiniLM-L6-v2 (Reimers và Gurevych, 2019) để chọn 3 đoạn bằng chứng hàng đầu cho mỗi tuyên bố.

Chỉ số: Chúng tôi sử dụng điểm F1 theo lớp, điểm F1 trung bình và điểm F1 có trọng số làm chỉ số đánh giá.

Các Mô hình Ngôn ngữ Lớn (LLMs) được sử dụng cho xác minh tuyên bố: Chúng tôi sử dụng Llama 3.1 (8B) và gpt-4o-mini làm LLMs cho giai đoạn xác minh tuyên bố và Deepseek-r1, vốn thực hiện TTS nội bộ, làm baseline. Chúng tôi áp dụng nhiệt độ 0,45 để tạo ra các đường suy luận đa dạng trong thiết lập TTS. Chúng tôi sử dụng kỹ thuật Few-shot Chain of Thought (COT) prompting (trong Hình 10) để khai thác suy luận cho tất cả các baseline và phương pháp của chúng tôi. Chúng tôi thử nghiệm với số lượng đường suy luận khác nhau ($m=1, 3, 5, 10$) như được trình bày chi tiết trong Mục 5.

Mô hình Verifier cho TTS: Mô hình Verifier được sử dụng cho Best-of-N trong cài đặt TTS dựa trên mô hình Llama-3.2-3B. Nó được tinh chỉnh cho việc phân loại sử dụng các bộ điều hợp LoRA (Hu et al., 2021) với bậc 8 và hệ số tỉ lệ (α) là 16. Mô hình được tinh chỉnh trong 3 epoch với kích thước batch là 32, sử dụng bộ tối ưu AdamW với $\epsilon = 1 \times 10^{-8}$ và tốc độ học ban đầu là 1×10^{-3} .

Các lời nhắc: Tất cả các lời nhắc để xác minh tuyên bố, phân tích và ghi chú dựa trên LLM có thể được tìm thấy trong Phụ lục C.

5 Kết quả Thử nghiệm

5.1 Sai lệch Lập luận của LLM - Phân tích Thủ công

Để trả lời RQ1, chúng tôi tiến hành một nghiên cứu có hệ thống về sự trôi dạt lý luận trong việc xác minh các tuyên bố số học sử dụng QuanTemp. Từ một mẫu phân tầng gồm 100

Các khẳng định, chúng tôi sử dụng một prompt hệ thống (Hình 8) và một prompt vài ví dụ với các ví dụ được chú thích (Hình 9, Phụ lục C) để hướng dẫn một LLM đánh giá (gpt-4o-mini) gán nhãn cho mỗi đường đi suy luận là có sự lệch suy luận (1) hay không (0).

Hai người chú giải con người (tinh nguyện viên cao học) sau đó độc lập xác minh liệu nhãn của LLM có đúng hay không, theo hướng dẫn trong Phụ lục A. Chúng tôi báo cáo chỉ số Cohen’s Kappa là 74,13, cho thấy sự đồng thuận đáng kể và đánh giá của LLM chính xác 69%. Dựa trên quy trình này, sau khi sửa kết quả đánh giá của LLM, chúng tôi nhận thấy rằng khoảng 34% các tuyên bố mẫu có biểu hiện lệch lý luận, gợi ý rằng đây là một chế độ lỗi phổ biến và không hề tầm thường. Ví dụ được trình bày trong Hình 1, Bảng 3 và Hình 6, 7 (Phụ lục B).

5.2 Hiệu quả của việc thay đổi tỉ lệ thời gian kiểm tra đối với Xác minh Yêu cầu

Để giải quyết RQ2, chúng tôi đánh giá TTS như một chiến lược giảm thiểu (Mục 3) với kết quả được trình bày trong Bảng 1. Trước tiên, chúng tôi thiết lập một giới hạn lý thuyết tối đa, nơi một người xác minh hoàn hảo sẽ chọn đúng lộ trình lý luận và phán quyết bất cứ khi nào có.

Như được thể hiện trong Bảng 1, giới hạn trên có thể đạt được thông qua TTS — trên các LLM khác nhau — vượt qua hiệu suất oracle của các mô hình NLI tinh chỉnh được báo cáo trong V et al. (2024). Hàng Oracle fine-tuned phản ánh các mô hình NLI hiện đại nhất (ví dụ, RoBERTa-large) được huấn luyện trên các lý do do con người viết và cung cấp chúng khi suy luận. Ngược lại, giới hạn trên của TTS hoàn toàn dựa trên quá trình lập luận do LLM tạo ra, không có bất kỳ lý do nào do con người viết. Điều này nhấn mạnh khả năng của LLM trong việc khơi gợi các quá trình lập luận phù hợp cho việc kiểm tra sự thật phức tạp khi được hướng dẫn bởi TTS.

Tính nhất quán tự thân (Wang và cs., 2023), tổng hợp nhiều đường đi suy luận thông qua bình chọn đa số, chỉ thực hiện tốt hơn một chút so với—hoặc đôi khi còn kém hơn—giải mã top-1. Điều này là vì phương pháp này giả định rằng phán quyết xuất hiện nhiều nhất là đúng, bỏ qua những lý luận tinh vi thường cần thiết trong việc kiểm chứng sự thật, đặc biệt đối với các tuyên bố mâu thuẫn có bằng chứng đa dạng.

Như được thể hiện trong Bảng 1, bộ xác minh đã được huấn luyện của chúng tôi trong cả hai thiết lập BoN và Adaptive BoN đã chọn hiệu quả con đường suy luận tốt nhất bằng cách tận dụng các tín hiệu cụ thể của nhiệm vụ. Adaptive BoN, sử dụng TTS dựa trên độ phức tạp dự đoán của tuyên bố, cải thiện so với giải mã top-1 lên 18,8% và tự nhất quán lên 16,69% (Macro-F1 trên QuanTemp). Adaptive BoN

Method	QuanTemp					ClaimDecomp				
	T-F1	F-F1	C-F1	M-F1	W-F1	T-F1	F-F1	C-F1	M-F1	W-F1
Other Baselines										
DeepSeek-R1 (7B) (DeepSeek-AI et al., 2025)	39.40	58.80	28.80	42.3	47.9	36.89	52.56	25.29	38.25	41.21
Llama-3.1 8B										
Top 1 Decoding (Wei et al., 2023)	33.5	66.4	34.7	44.8	52.5	19.75	44.03	44.44	36.07	37.15
Self-Consistency (Wang et al., 2023)	34.9	68.6	35.1	46.2	54.2	16.22	44.00	44.30	34.84	36.39
Best of N	44.20	75.30	40.30	53.20	61.0	22.22	48.00	46.91	39.05	40.22
Adaptive BoN (VERIFIERFC)	44.27	73.52	43.93	53.91	60.84	21.43	56.21	49.70	42.44	44.13
Upper bound	63.9	85.1	69.60	72.9	77.4	63.92	82.21	83.10	76.41	77.21
Gpt-4o-mini										
Top 1 decoding (Wei et al., 2023)	40.68	63.14	37.99	47.27	52.84	42.11	48.92	39.06	43.36	44.46
Self-Consistency (Wang et al., 2023)	29.70	63.20	42.33	45.07	51.83	47.41	50.00	34.19	43.87	45.35
Best of N	26.30	74.82	46.51	49.21	58.81	45.45	59.60	39.32	48.12	50.39
Adaptive BoN (VERIFIERFC)	36.16	72.61	44.22	51.00	58.88	49.18	57.93	46.62	51.24	52.53
Upper bound	45.34	85.37	67.19	65.97	73.41	58.21	66.67	61.68	62.19	62.91
Oracle (fine-tuned) (V et al., 2024)	56.86	82.92	48.79	62.85	69.79	66.67	66.67	45.76	59.69	60.50

Table 1: Claim verification performance of the models. The reward model is fine-tuned llama-3.2-3b and number of reasoning paths considered, m=10. The gains method is computed w.r.t the *top 1 Decoding* baseline.

Decomposition	T-F1	F-F1	C-F1	M-F1	W-F1
Majority Voting					
w/o decomp	34.89	68.63	35.09	46.20	54.18
with decomp	37.48	69.33	32.27	46.36	53.51
BoN					
w/o decomp	44.16	75.27	40.27	53.23	60.97
with decomp	43.77	76.32	35.21	51.77	60.29

Table 2: Analysis on impact of claim decomposition in test-time scaling setup on complex claim verification (using Llama-3.1 8B as base model).




Figure 3: (Left) Avg. runtime per query (in milliseconds) comparison and (Right) Total **Runtime** comparison: Adaptive BoN (VERIFIERFC) vs BoN (Best of N).

also outperforms **DeepSeek-R1** by **27.44%**, highlighting the importance of a trained verifier for TTS in complex fact-checking.

We observe similar improvements on Claimdecomp eval set where Adaptive BoN (VERIFIERFC) outperforms Top-1 decoding significantly, demonstrating that our verifier can also generalize to other types of complex claims apart from numerical claims. We observe that this is primarily because

the verifier used in BoN and adaptive versions is trained on data that considers positive and negative reasoning paths / process paths from the LLM for claim verification. This is unlike conventional Process or Outcome Reward Models which employ rejection sampling and only consider positive samples. This offers more discriminative capacity to the verifier that is able to distinguish the correct reasoning path among diverse paths even when their frequency is low. For instance, on second example in Table 3, the LLM is unable to reason that similar party manifesto was also adopted earlier in 1928 and was further expanded in 1956 and hence the claim is accurate. Instead, the model overanalyzes, backtracks from correct reasoning and passes the verdict as “Conflicting” due to mention of 1928 in one of the evidence not being in line with 1956 mentioned in claim. We observe that Self consistency also select “Conflicting” as verdict as 9/10 reasoning paths lead to this verdict. Rather BoN and adaptive BoN was able to rank the one correct reasoning path as the best solution leading to correct verdict.


We also observe that BoN and adaptive BoN with our trained process verifier helps mitigate the reasoning drift issue as evident from examples in Table 3. For instance, in the first example, one of the evidences exactly support the remittance value of 400 KSh and the second evidence quotes the equivalent value in US dollars. Under top-1-decoding, reasoning drift causes the LLM to classify the claim as "Conflicting" owing to the differing figures (ignoring the currency units) which

Phương pháp	QuanTemp					Phân tách yêu cầu				
	T-F1	F-F1	C-F1	M-F1	W-F1	T-F1	F-F1	C-F1	M-F1	W-F1
Các đường cơ sở khác										
DeepSeek-R1 (7B) (DeepSeek-AI và cộng sự, 2025)	39.40	58.80	28.80	42.3	47.9	36.89	52.56	25.29	38.25	41.21
Llama-3.1 8B										
Giải mã Hàng đầu 1 (Wei và cộng sự, 2023)	33.5	66.4	34.7	44.8	52.5	19.75	44.03	44.44	36.07	37.15
Tự Nhất Quán (Wang và cộng sự, 2023)	34.9	68.6	35.1	46.2	54.2	16.22	44.00	44.30	34.84	36.39
Tốt nhất của N	44.20	75.30	40.30	53.20	61.0	22.22	48.00	46.91	39.05	40.22
BoN Thích ứng (VERIFIERFC)	44.27	73.52	43.93	53.91	60.84	21.43	56.21	49.70	42.44	44.13
Giới hạn trên	63.9	85.1	69.60	72.9	77.4	63.92	82.21	83.10	76.41	77.21
Gpt-4o-mini										
Giải mã Top 1 (Wei và cộng sự, 2023)	40.68	63.14	37.99	47.27	52.84	42.11	48.92	39.06	43.36	44.46
Tự Nhất Quán (Wang và cộng sự, 2023)	29.70	63.20	42.33	45.07	51.83	47.41	50.00	34.19	43.87	45.35
Tốt nhất của N	26.30	74.82	46.51	49.21	58.81	45.45	59.60	39.32	48.12	50.39
BoN Thích ứng (VERIFIERFC)	36.16	72.61	44.22	51.00	58.88	49.18	57.93	46.62	51.24	52.53
Giới hạn trên	45.34	85.37	67.19	65.97	73.41	58.21	66.67	61.68	62.19	62.91
Oracle (tính chính) (V và cộng sự, 2024)	56.86	82.92	48.79	62.85	69.79	66.67	66.67	45.76	59.69	60.50

Bảng 1: Hiệu suất xác minh thông tin của các mô hình. Mô hình thường được tinh chỉnh từ llama-3.2-3b và số đường suy luận được xem xét, m=10. Phương pháp tính lợi ích được tính so với chuẩn giải mã hàng đầu 1.

Sự phân hủy	T-F1	F-F1	C-F1	M-F1	W-F1
Bổ phiếu đa số					
không phân hủy	34.89	68.63	35.09	46.20	54.18
với decomp	37.48	69.33	32.27	46.36	53.51
BoN					
không có phân hủy	44.16	75.27	40.27	53.23	60.97
với decomp	43.77	76.32	35.21	51.77	60.29

Bảng 2: Phân tích ảnh hưởng của việc phân tách yêu cầu trong thiết lập tỉ lệ thời gian kiểm tra đối với xác minh yêu cầu phức tạp (sử dụng Llama-3.1 8B làm mô hình cơ sở).



Hình 3: (Bên trái) So sánh thời gian chạy trung bình trên mỗi truy vấn (tính bằng mili giây) và (Bên phải) So sánh tổng thời gian chạy: Adaptive BoN (VERIFIERFC) so với BoN (Best of N).

cũng vượt trội hơn DeepSeek-R1 27,44%, nhấn mạnh tầm quan trọng của một bộ kiểm chứng được huấn luyện cho TTS trong kiểm tra thực tế phức tạp.

Chúng tôi quan sát thấy cải thiện tương tự trên tập đánh giá Claimde-comp, nơi Adaptive BoN (VERIFIERFC) vượt trội so với giải mã Top-1 một cách đáng kể, cho thấy rằng trình xác thực của chúng tôi cũng có thể tổng quát hóa sang các loại yêu cầu phức tạp khác ngoài các yêu cầu số. Chúng tôi nhận thấy rằng điều này chủ yếu là do

Trình xác minh được sử dụng trong các phiên bản BoN và adaptive được huấn luyện trên dữ liệu xem xét các đường dẫn lý luận tích cực và tiêu cực / các đường dẫn quá trình từ LLM để xác minh tuyên bố. Điều này khác với các Mô hình Thường Quá trình hoặc Kết quả thông thường, vốn sử dụng lấy mẫu từ chối và chỉ xem xét các mẫu tích cực. Điều này mang lại khả năng phân biệt cao hơn cho trình xác minh, có thể phân biệt được đường dẫn lý luận đúng giữa nhiều đường dẫn khác nhau ngay cả khi tần suất của chúng thấp. Ví dụ, trong ví dụ thứ hai ở Bảng 3, LLM không thể lý luận rằng bản tuyên ngôn của đảng tương tự cũng đã được áp dụng trước đó vào năm 1928 và sau đó được mở rộng vào năm 1956, và do đó tuyên bố là chính xác. Thay vào đó, mô hình phân tích quá sâu, lùì lại khỏi lý luận đúng và đưa ra phán quyết là “Mâu thuẫn” do việc nhắc đến năm 1928 trong một bằng chứng không phù hợp với năm 1956 được đề cập trong tuyên bố. Chúng tôi nhận thấy rằng Self consistency cũng chọn “Mâu thuẫn” làm phán quyết vì 9/10 đường dẫn lý luận dẫn đến phán quyết này. Thay vào đó B

Chúng tôi cũng nhận thấy rằng BoN và BoN thích ứng với bộ kiểm chứng quá trình đã được huấn luyện của chúng tôi giúp giảm thiểu vấn đề sai lệch lập luận như thấy rõ từ các ví dụ trong Bảng 3. Chẳng hạn, trong ví dụ đầu tiên, một bằng chứng hoàn toàn hỗ trợ giá trị chuyển tiền là 400 KSh và bằng chứng thứ hai trích dẫn giá trị tương đương bằng đô la Mỹ. Trong giải mã top-1, sai lệch lập luận khiến LLM phân loại tuyên bố là 'Mâu thuẫn' do các con số khác nhau (bỏ qua các đơn vị tiền tệ) mà

Method	Evidences
Claim	Diaspora remittances “now stand at an all-time high of over KSh400 billion in 2021”.
Top-1 decoding	[Evidence 1]: diaspora remittances have increased tenfold over the last decade; and they now stand at an all-time-high at over ksh. 400 billion per annum as of 2021. [Evidence 2]: diaspora remittances were robust in 2021, with total remittances in 2021 reaching a record usd3,718 million. of daily users.
Self Consistency	[Reasoning]: The evidence provides conflicting information about the exact amount of diaspora remittances in 2021, and some sources mention figures that are not directly comparable to KSh400 billion. [Verdict]: Conflicting [Final Verdict]: Conflicting
VERIFIERFC (ours)	[Reasoning]: The evidence supports the claim that diaspora remittances reached an all-time high of over KSh400 billion in 2021. However, there are minor variations in the wording and units used across different sources. [Final Verdict]: True
Claim	The 1956 Republican Party platform supported equal pay, the minimum wage, asylum for refugees, protections for unions and more.
Top-1 decoding	[Evidence 1]: 1928 the gop platform read: the party favors freedom in wage we support an equitable minimum wage for american workers one providing fair wages [Evidence 2]: the 1956 republican platform pledged to provide assistance; protect social security; provide asylum for refugees; extend the minimum wage; strengthen labor laws to support union; assure equal pay...
Self Consistency	[Reasoning]: The evidence provided supports many of the claims made in the original statement, but some quotes are from earlier years or mention specific policies, and not all points are explicitly stated in the 1956 platform. [Final Verdict]: Conflicting [Final Verdict]: Conflicting
VERIFIERFC (ours)	[Reasoning]: The claim is supported by quotes from the 1956 Republican platform, which mention equal pay, minimum wage, asylum for refugees, protections for unions,. While there are minor nuances it is supported [...] [Final Verdict]: True

Table 3: Qualitative analysis of reasoning process by Self consistency and VERIFIERFC

is resolved when inferenced using BoN strategy (VERIFIERFC).

5.3 Efficiency of Adaptive Test-Time Scaling

We evaluate the efficiency of Adaptive BoN based TTS strategy by measuring total runtime on QuanTemp evaluation set and also record the average per claim processing time. The efficiency results are shown in plots in Figure 3 and claim verification performance in Table 1. We observe that Adaptive Bon is less time intensive (1.8×) as it adaptively scales inference computation based on the complexity of the claims. We also observe from the plots that Adaptive scaling of test-time compute also reduces overall running time significantly, while achieving gains over plain TTS based BoN strategy, leading to judicious use of computational resources without sacrificing performance. We observe that on QuanTemp most of the claims assigned complexity level 0 belong to **statistical** category which are easy to verify as noted by authors in (V et al., 2024). We also independently

evaluate the complexity consistency on its agreement with human notion of complexity by asking two annotators to annotate complexity levels for 100 claims sampled in a stratified manner. We observe a Cohen’s kappa of **72.89** between annotators (Guidelines in Appendix A.2). Evaluating the classifier with annotations as ground truth, yields weighted precision of **71%**.

Method	QuanTemp		ClaimDecomp	
	M-F1	W-F1	M-F1	W-F1
Llama-3.1 8B				
m=3	50.60	57.47	37.96	39.71
m=5	51.49	58.39	39.64	41.25
m=10	53.91	60.84	42.44	44.13
Gpt-4o-mini				
m=3	47.98	54.82	44.15	45.28
m=5	49.26	56.82	48.24	49.24
m=10	51.00	58.88	51.24	52.53

Table 4: Performance with different number of reasoning paths m=3,5,10.

Phương pháp	Bảng chứng
Yêu cầu	Kiều hối từ cộng đồng người di cư "hiện đang ở mức cao kỷ lục trên 400 tỷ KSh vào năm 2021".
Giải mã Top-1	[Bảng chứng 1]: kiều hối đã tăng gấp mười lần trong thập kỷ qua; và hiện nay chúng đang ở mức đạt mức cao nhất mọi thời đại với hơn 400 tỷ Ksh mỗi năm tính đến năm 2021. [Bảng chứng 2]: kiều hối từ cộng đồng người Việt ở nước ngoài đã tăng mạnh vào năm 2021, với tổng kiều hối trong năm 2021 đạt mức kỷ lục 3.718 triệu USD. của người dùng hàng ngày.
Tự nhất quán	[Lý luận]: Bảng chứng cung cấp thông tin mâu thuẫn về số lượng chính xác của cộng đồng người Việt di cư kiều hối vào năm 2021, và một số nguồn đề cập đến các con số không thể so sánh trực tiếp với 400 KSh tỷ. [Phán quyết]: Mâu thuẫn
VERIFIERFC (của chúng tôi)	[Lập luận]: Bảng chứng cho thấy kiều hối từ cộng đồng người Việt ở nước ngoài đã đạt mức cao kỷ lục của hơn 400 tỷ KSh vào năm 2021. Tuy nhiên, có những biến thể nhỏ trong cách diễn đạt và đơn vị được sử dụng trên các nguồn khác nhau. [Phán quyết cuối cùng]: Đúng
Yêu cầu	Chương trình nghị sự của Đảng Cộng hòa năm 1956 ủng hộ quyền được trả lương bình đẳng, mức lương tối thiểu, nơi trú ẩn cho người tị nạn, bảo vệ cho công đoàn và nhiều hơn nữa.
Giải mã Top-1	[Bảng chứng 1]: Năm 1928, cương lĩnh của Đảng Cộng hòa viết: đảng ủng hộ tự do về tiền lương, chúng tôi ủng hộ một sự công bằng mức lương tối thiểu cho người lao động Mỹ một mức lương công bằng [Bảng chứng 2]: nền tảng đảng Cộng hòa năm 1956 cam kết cung cấp viện trợ; bảo vệ an sinh xã hội; cung cấp nơi tị nạn cho người tị nạn; tăng mức lương tối thiểu; củng cố luật lao động để hỗ trợ công đoàn; đảm bảo bình đẳng pay...
Tự nhất quán	[Lý luận]: Các bằng chứng được cung cấp hỗ trợ nhiều tuyên bố được đưa ra trong phát biểu gốc, nhưng một số trích dẫn là từ những năm trước hoặc đề cập đến các chính sách cụ thể, và không phải tất cả các điểm đều được nêu rõ ràng trong nền tảng năm 1956. [Phán quyết cuối cùng]: Mâu thuẫn
VERIFIERFC (của chúng tôi)	[Lập luận]: Lập luận này được hỗ trợ bởi các trích dẫn từ nền tảng của Đảng Cộng hòa năm 1956, đề cập đến sự bình đẳng tiền lương, mức lương tối thiểu, tị nạn cho người tị nạn, các biện pháp bảo vệ cho các công đoàn,. Mặc dù có những điểm khác biệt nhỏ, nó là hỗ trợ [...] [Phán quyết cuối cùng]: Đúng

Bảng 3: Phân tích định tính quá trình lý luận theo Tính nhất quán bản thân và VERIFIERFC

được giải quyết khi suy luận bằng chiến lược BoN (VERIFIERFC).

5.3 Hiệu quả của Điều Chỉnh Thời Gian Kiểm Tra Thích Ứng
Chúng tôi đánh giá hiệu quả của chiến lược TTS dựa trên Adaptive BoN bằng cách đo tổng thời gian chạy trên tập đánh giá Quan-Temp và cũng ghi lại thời gian xử lý trung bình cho mỗi tuyên bố. Kết quả hiệu quả được hiển thị trong các biểu đồ ở Hình 3 và hiệu suất xác minh tuyên bố trong Bảng 1. Chúng tôi quan sát thấy rằng Adaptive BoN tốn ít thời gian hơn (1.8×) vì nó điều chỉnh tính toán suy luận dựa trên độ phức tạp của các tuyên bố. Chúng tôi cũng quan sát từ các biểu đồ rằng việc điều chỉnh tính toán khi kiểm thử cũng giảm đáng kể tổng thời gian chạy, đồng thời đạt được lợi nhuận so với chiến lược BoN dựa trên TTS đơn giản, dẫn đến việc sử dụng tài nguyên tính toán một cách hợp lý mà không làm giảm hiệu suất. Chúng tôi quan sát thấy trên QuanTemp hầu hết các tuyên bố có mức độ phức tạp 0 thuộc về loại thống kê, vốn dễ xác minh như đã lưu ý bởi các tác giả trong (V et al., 2024). Chúng tôi cũng tự thực hiện độc lập

đánh giá sự nhất quán về độ phức tạp dựa trên sự đồng thuận của nó với khái niệm về độ phức tạp của con người bằng cách yêu cầu hai người chủ thích đánh dấu mức độ phức tạp cho 100 tuyên bố được lấy mẫu theo cách phân tầng. Chúng tôi quan sát thấy hệ số Cohen’s kappa là 72,89 giữa các người chủ thích (Hướng dẫn trong Phụ lục A.2). Việc đánh giá bộ phân loại với các chủ thích làm sự thật nền tảng, cho kết quả độ chính xác có trọng số là 71%.

Phương pháp	QuanTemp		Phân tách yêu cầu	
	M-F1	W-F1	M-F1	W-F1
Llama-3.1 8B				
m=3	50.60	57.47	37.96	39.71
m=5	51.49	58.39	39.64	41.25
m=10	53.91	60.84	42.44	44.13
Gpt-4o-mini				
m=3	47.98	54.82	44.15	45.28
m=5	49.26	56.82	48.24	49.24
m=10	51.00	58.88	51.24	52.53

Bảng 4: Hiệu suất với số lượng đường dẫn suy luận khác nhau m=3, 5, 10.

5.4 Impact of Decomposition on TTS

Claim decomposition is a popular approach for addressing complex claims with multiple aspects (V et al., 2024; Chen et al., 2022). Hence, to answer **RQ3** we analyze the impact of decomposing claim into sub-questions in combination with test-time scaling to understand the impact on final claim verification. We use ClaimDecomp (Chen et al., 2022) style yes/no sub-questions as they are found to have superior performance and easy to comprehend (V et al., 2024; Chen et al., 2022). The results are as shown in Table 2. We observe that claim decomposition surprisingly leads to negative effects on claim verification performance. On analysis, we observe this is primarily due to reasoning drift issue from LLM being elicited due to certain sub-questions focusing on aspects that are not central to facts being checked, causing drift.

Additionally, we observe that Adaptive BoN and BoN leads to diverse aspects of the claim being considered. Since this is the core objective of decomposition, TTS renders claim decomposition redundant, leading to diminishing returns (Tables 1, 2 and 3).

5.5 Ablations

We perform ablations by varying the scaling dimension of number of reasoning paths (m=3,5,10) using LLM. The results are as shown in Table 4. We observe that the performance increases with increase in number of reasoning paths, reaching the best performance at m=10. We do not scale beyond 10 due to computational and cost constraints.

6 Conclusion

We identify and study the *reasoning drift* issue in LLM reasoning for complex and numerical claims. To address this, we propose a Best-of-N (BoN) test-time scaling strategy, which outperforms Self-Consistency and Top-1 decoding. For improved compute-efficiency, we introduce Adaptive BoN (VERIFIERFC). VERIFIERFC achieves better performance than BoN while reducing computational cost. In future work, we aim to incorporate stronger verifier models and further optimize VERIFIERFC for performance and efficiency.

7 Limitations

While VERIFIERFC shows strong improvements over baselines, a notable gap remains compared to

the upper bound. This may be addressed by integrating stronger verifier models with deeper linguistic and numerical understanding. Another promising direction is training verifiers on higher-quality, human-annotated data, which has been shown to improve reasoning performance. Additionally, our current approach leverages existing state-of-the-art retrieval and ranking approaches. However, noisy evidence can introduce bias that may affect both the performance and the validity of our analysis. Future work could incorporate more robust retrieval and re-ranking pipelines (Rathee et al., 2024) to reduce this noise, enabling a fairer and more accurate evaluation of veracity prediction methods.

8 Ethical Considerations and Risks

This work focuses on improving factual consistency in language model outputs through test-time scaling and verifier-guided reasoning. While our methods aim to avoid reasoning drift, they are subject to several ethical considerations.

First, our reliance on LLM-generated reasoning paths introduces potential risks of reinforcing model biases or factual errors during verifier training. Although the verifier is trained to select plausible reasoning, it may inherit systematic flaws from the base LLM. Second, our approach does not currently include fairness or bias mitigation across demographic attributes, which may be relevant for politically or socially sensitive claims.

Our datasets (QuanTemp, ClaimDecomp) are drawn from public sources (with create commons license) and include no personally identifiable or sensitive information. The claims focus on public data and domain-specific knowledge rather than private individuals. Human annotators involved in evaluation were presented with reasoning paths and asked to assess model performance under clear, task-specific instructions (Appendix A). No potentially harmful or offensive content was encountered during the annotation process.

9 Acknowledgements

We would like to thank Sowmya AS for her help in evaluating quality of claim difficulty estimator. We would also like to acknowledge Factiveverse AI for contributing hardware for the experiments reported in this work.

5.4 Tác động của Phân rã lên TTS

Phân rã tuyên bố là một phương pháp phổ biến để giải quyết các tuyên bố phức tạp với nhiều khía cạnh (V et al., 2024; Chen et al., 2022). Do đó, để trả lời RQ3, chúng tôi phân tích tác động của việc phân rã tuyên bố thành các câu hỏi phụ kết hợp với việc điều chỉnh trong thời gian kiểm tra để hiểu tác động đối với việc xác minh cuối cùng của tuyên bố. Chúng tôi sử dụng các câu hỏi phụ kiểu đồng/không kiểu ClaimDecomp (Chen et al., 2022) vì chúng được phát hiện có hiệu suất vượt trội và dễ hiểu (V et al., 2024; Chen et al., 2022). Kết quả được trình bày trong Bảng 2. Chúng tôi quan sát thấy việc phân rã tuyên bố gây ra những tác động tiêu cực bất ngờ đối với hiệu suất xác minh tuyên bố. Qua phân tích, chúng tôi nhận thấy điều này chủ yếu là do vấn đề lệch suy luận từ LLM được kích hoạt vì một số câu hỏi phụ tập trung vào các khía cạnh không phải trọng tâm của các sự kiện đang được kiểm tra, gây ra sự lệch hướng.

Ngoài ra, chúng tôi nhận thấy rằng Adaptive BoN và BoN dẫn đến việc xem xét các khía cạnh đa dạng của yêu cầu. Vì đây là mục tiêu cốt lõi của việc phân rã, TTS làm cho việc phân rã yêu cầu trở nên thừa, dẫn đến hiệu quả giảm dần (Bảng 1, 2 và 3).

5.5 Cắt bỏ

Chúng tôi thực hiện các thí nghiệm loại bỏ bằng cách thay đổi kích thước tỉ lệ của số lượng đường dẫn suy luận (m=3,5,10) sử dụng LLM. Kết quả được trình bày trong Bảng 4. Chúng tôi quan sát thấy hiệu suất tăng khi số lượng đường dẫn suy luận tăng, đạt hiệu suất tốt nhất tại m=10. Chúng tôi không mở rộng vượt quá 10 do giới hạn về tính toán và chi phí.

6 Kết luận

Chúng tôi xác định và nghiên cứu vấn đề trôi lý luận trong khả năng suy luận của LLM đối với các khẳng định phức tạp và số liệu. Để giải quyết vấn đề này, chúng tôi đề xuất chiến lược mở rộng thời gian kiểm tra Best-of-N (BoN), vượt trội so với Self-Consistency và giải mã Top-1. Để cải thiện hiệu quả tính toán, chúng tôi giới thiệu Adaptive BoN (VERIFIERFC). VERIFIERFC đạt hiệu suất tốt hơn BoN đồng thời giảm chi phí tính toán. Trong công trình tương lai, chúng tôi dự định tích hợp các mô hình xác minh mạnh hơn và tối ưu hóa thêm VERIFIERFC về hiệu suất và hiệu quả.

7 Hạn chế

Trong khi VERIFIERFC cho thấy những cải tiến mạnh mẽ so với các cơ sở, một khoảng cách đáng kể vẫn còn so với

giới hạn trên. Điều này có thể được giải quyết bằng cách tích hợp các mô hình xác minh mạnh hơn với sự hiểu biết sâu hơn về ngôn ngữ và số học. Một hướng đi hứa hẹn khác là đào tạo các bộ xác minh trên dữ liệu được chú thích bởi con người chất lượng cao hơn, điều này đã được chứng minh là cải thiện hiệu suất suy luận. Ngoài ra, phương pháp hiện tại của chúng tôi tận dụng các phương pháp truy xuất và xếp hạng tiên tiến hiện có. Tuy nhiên, bằng chứng nhiều có thể gây ra thiên lệch, ảnh hưởng đến cả hiệu suất và tính hợp lệ của phân tích của chúng tôi. Công việc tương lai có thể kết hợp các quy trình truy xuất và xếp hạng lại mạnh mẽ hơn (Rathee và cộng sự, 2024) để giảm nhiễu này, cho phép đánh giá công bằng và chính xác hơn về các phương pháp dự đoán độ xác thực.

8 Cân nhắc và Rủi ro về Đạo đức

Công trình này tập trung vào việc cải thiện tính nhất quán về thực tế trong các kết quả đầu ra của mô hình ngôn ngữ thông qua mở rộng quy mô khi kiểm tra và suy luận có hướng dẫn bởi trình xác thực. Trong khi các phương pháp của chúng tôi nhằm tránh sự trôi đi của suy luận, chúng vẫn phải đối mặt với một số cân nhắc đạo đức.

Thứ nhất, sự phụ thuộc của chúng tôi vào các đường dẫn suy luận do LLM tạo ra có thể dẫn đến rủi ro tiềm ẩn trong việc củng cố các thiên lệch của mô hình hoặc các lỗi thực tế trong quá trình huấn luyện bộ xác minh. Mặc dù bộ xác minh được huấn luyện để chọn ra các lập luận hợp lý, nhưng nó có thể thừa hưởng những sai sót hệ thống từ LLM gốc. Thứ hai, phương pháp của chúng tôi hiện chưa bao gồm việc đảm bảo công bằng hay giảm thiên lệch theo các thuộc tính nhân khẩu học, điều này có thể có liên quan đối với các tuyên bố mang tính chính trị hoặc xã hội nhạy cảm.

Các bộ dữ liệu của chúng tôi (QuanTemp, ClaimDecomp) được lấy từ các nguồn công khai (với giấy phép Creative Commons) và không bao gồm thông tin nhận dạng cá nhân hoặc thông tin nhạy cảm. Các tuyên bố tập trung vào dữ liệu công khai và kiến thức chuyên ngành thay vì cá nhân riêng tư. Những người chú thích dữ liệu tham gia đánh giá đã được trình bày các đường lối suy luận và được yêu cầu đánh giá hiệu suất của mô hình theo hướng dẫn rõ ràng, cụ thể cho nhiệm vụ (Phụ lục A). Không có nội dung nào có thể gây hại hoặc xúc phạm được gặp trong quá trình chú thích.

9 Lời cảm ơn

Chúng tôi muốn cảm ơn SowmyaAS vì đã giúp đánh giá chất lượng của bộ ước lượng độ khó khiêu nại. Chúng tôi cũng muốn ghi nhận Factiveverse AI vì đã đóng góp phần cứng cho các thí nghiệm được báo cáo trong công trình này.

References

Firoj Alam, Julia Maria Struß, Tanmoy Chakraborty, Stefan Dietze, Salim Hafid, Katerina Korre, Arianna Muti, Preslav Nakov, Federico Ruggeri, Sebastian Schellhammer, et al. 2025. The clef-2025 checkthat! lab: Subjectivity, fact-checking, claim normalization, and retrieval. In *European Conference on Information Retrieval*, pages 467–478. Springer.

Tariq Alhindi, Savvas Petridis, and Smaranda Muresan. 2018. **Where is your evidence: Improving fact-checking by justification modeling**. In *Proceedings of the First Workshop on Fact Extraction and VERification (FEVER)*, pages 85–90, Brussels, Belgium. Association for Computational Linguistics.

Rami Aly, Zhijiang Guo, Michael Sejr Schlichtkrull, James Thorne, Andreas Vlachos, Christos Christodoulopoulos, Oana Cocarascu, and Arpit Mittal. 2021. **The fact extraction and VERification over unstructured and structured information (FEVEROUS) shared task**. In *Proceedings of the Fourth Workshop on Fact Extraction and VERification (FEVER)*, pages 1–13, Dominican Republic. Association for Computational Linguistics.

Isabelle Augenstein, Timothy Baldwin, Meeyoung Cha, et al. 2024. Factuality challenges in the era of large language models and opportunities for fact-checking. *Nature Machine Intelligence*, 6:852–863.

Isabelle Augenstein, Christina Lioma, Dongsheng Wang, Lucas Chaves Lima, Casper Hansen, Christian Hansen, and Jakob Grue Simonsen. 2019. **MultiFC: A real-world multi-domain dataset for evidence-based fact checking of claims**. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 4685–4697, Hong Kong, China. Association for Computational Linguistics.

Tom Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared D Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, et al. 2020. Language models are few-shot learners. *Advances in neural information processing systems*, 33:1877–1901.

Jifan Chen, Aniruddh Sriram, Eunsol Choi, and Greg Durrett. 2022. **Generating literal and implied sub-questions to fact-check complex claims**. In *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*, pages 3495–3516, Abu Dhabi, United Arab Emirates. Association for Computational Linguistics.

Xingyu Chen, Jiahao Xu, Tian Liang, Zhiwei He, Jianhui Pang, Dian Yu, Linfeng Song, Qiuzhi Liu, Mengfei Zhou, Zhuosheng Zhang, Rui Wang, Zhaopeng Tu, Haitao Mi, and Dong Yu. 2025. **Do not think that much for 2+3=? on the overthinking of o1-like llms**.

Yung-Sung Chuang, Yujia Xie, Hongyin Luo, Yoon Kim, James R. Glass, and Pengcheng He. 2024. **Dola: Decoding by contrasting layers improves factuality in large language models**. In *The Twelfth International Conference on Learning Representations*.

Karl Cobbe, Vineet Kosaraju, Mohammad Bavarian, Mark Chen, Heewoo Jun, Lukasz Kaiser, Matthias Plappert, Jerry Tworek, Jacob Hilton, Reiichiro Nakano, Christopher Hesse, and John Schulman. 2021. **Training verifiers to solve math word problems**.

Alejandro Cuadron, Dacheng Li, Wenjie Ma, Xingyao Wang, Yichuan Wang, Siyuan Zhuang, Shu Liu, Luis Gaspar Schroeder, Tian Xia, Huanzhi Mao, Nicholas Thumiger, Aditya Desai, Ion Stoica, Ana Klimovic, Graham Neubig, and Joseph E. Gonzalez. 2025. **The danger of overthinking: Examining the reasoning-action dilemma in agentic tasks**.

DeepSeek-AI, Daya Guo, Dejian Yang, Haowei Zhang, Junxiao Song, Ruoyu Zhang, Runxin Xu, Qihao Zhu, Shirong Ma, Peiyi Wang, Xiao Bi, Xiaokang Zhang, Xingkai Yu, Yu Wu, Z. F. Wu, Zhibin Gou, Zhihong Shao, Zhuoshu Li, Ziyi Gao, Aixin Liu, Bing Xue, Bingxuan Wang, Bochao Wu, Bei Feng, Chengda Lu, Chenggang Zhao, Chengqi Deng, Chenyu Zhang, Chong Ruan, Damai Dai, Deli Chen, Dongjie Ji, Erhang Li, Fangyun Lin, Fucong Dai, Fuli Luo, Guangbo Hao, Guanting Chen, Guowei Li, H. Zhang, Han Bao, Hanwei Xu, Haocheng Wang, Honghui Ding, Huajian Xin, Huazuo Gao, Hui Qu, Hui Li, Jianzhong Guo, Jiashi Li, Jiawei Wang, Jingchang Chen, Jingyang Yuan, Junjie Qiu, Junlong Li, J. L. Cai, Jiaqi Ni, Jian Liang, Jin Chen, Kai Dong, Kai Hu, Kaige Gao, Kang Guan, Kexin Huang, Kuai Yu, Lean Wang, Lecong Zhang, Liang Zhao, Litong Wang, Liyue Zhang, Lei Xu, Leyi Xia, Mingchuan Zhang, Minghua Zhang, Minghui Tang, Meng Li, Miaojun Wang, Mingming Li, Ning Tian, Panpan Huang, Peng Zhang, Qiancheng Wang, Qinyu Chen, Qiushi Du, Ruiqi Ge, Ruisong Zhang, Ruizhe Pan, Runji Wang, R. J. Chen, R. L. Jin, Ruyi Chen, Shanghao Lu, Shangyan Zhou, Shanhuang Chen, Shengfeng Ye, Shiyu Wang, Shuiping Yu, Shunfeng Zhou, Shuting Pan, S. S. Li, Shuang Zhou, Shaoqing Wu, Shengfeng Ye, Tao Yun, Tian Pei, Tianyu Sun, T. Wang, Wangding Zeng, Wanjia Zhao, Wen Liu, Wenfeng Liang, Wenjun Gao, Wenqin Yu, Wentao Zhang, W. L. Xiao, Wei An, Xiaodong Liu, Xiaohan Wang, Xiaokang Chen, Xiaotao Nie, Xin Cheng, Xin Liu, Xin Xie, Xingchao Liu, Xinyu Yang, Xinyuan Li, Xuecheng Su, Xuheng Lin, X. Q. Li, Xiangyue Jin, Xiaojin Shen, Xiaosha Chen, Xiaowen Sun, Xiaoxiang Wang, Xinnan Song, Xinyi Zhou, Xianzu Wang, Xinxia Shan, Y. K. Li, Y. Q. Wang, Y. X. Wei, Yang Zhang, Yanhong Xu, Yao Li, Yao Zhao, Yaofeng Sun, Yaohui Wang, Yi Yu, Yichao Zhang, Yifan Shi, Yiliang Xiong, Ying He, Yishi Piao, Yisong Wang, Yixuan Tan, Yiyang Ma, Yiyuan Liu, Yongqiang Guo, Yuan Ou, Yudian Wang, Yue Gong, Yuheng Zou, Yujia He, Yunfan Xiong, Yuxiang Luo, Yuxiang You, Yuxuan Liu, Yuyang Zhou, Y. X. Zhu, Yanhong Xu,

Tài liệu tham khảo

Firoj Alam, Julia Maria Struß, Tanmoy Chakraborty, Stefan Dietze, Salim Hafid, Katerina Korre, Arianna Muti, Preslav Nakov, Federico Ruggeri, Sebastian Schellhammer, và các tác giả khác. 2025. Phòng thí nghiệm clef-2025 checkthat!: Chủ quan, xác minh thông tin, chuẩn hóa tuyên bố và truy xuất. Trong Hội nghị Châu Âu về Truy xuất Thông tin, trang 467–478. Springer.

Tariq Alhindi, Savvas Petridis, và Smaranda Muresan. 2018. Bằng chứng của bạn ở đâu: Cải thiện việc kiểm tra sự thật bằng mô hình hóa lý lẽ. Trong Kỷ yếu Hội thảo Thường niên lần thứ nhất về Trích xuất và Xác minh Sự thật (FEVER), trang 85–90, Brussels, Bỉ. Hiệp hội Ngôn ngữ Học Máy Tính.

Rami Aly, Zhijiang Guo, Michael Sejr Schlichtkrull, James Thorne, Andreas Vlachos, Christos Christodoulopoulos, Oana Cocarascu, và Arpit Mittal. 2021. Nhiệm vụ chia sẻ Trích xuất sự thật và XÁC minh thông tin không cấu trúc và cấu trúc (FEVEROUS). Trong Kỷ yếu của Hội thảo lần thứ tư về Trích xuất sự thật và XÁC minh (FEVER), trang 1–13, Cộng hòa Dominican. Hiệp hội Ngôn ngữ Học Máy Tính.

Isabelle Augenstein, Timothy Baldwin, Meeyoung Cha, và cộng sự. 2024. Những thách thức về tính xác thực trong kỷ nguyên của các mô hình ngôn ngữ lớn và cơ hội cho việc kiểm chứng thông tin. *Nature Machine Intelligence*, 6:852–863.

Isabelle Augenstein, Christina Lioma, Dongsheng Wang, Lucas Chaves Lima, Casper Hansen, Christian Hansen, và Jakob Grue Simonsen. 2019. MultiFC: Một tập dữ liệu đa miền thực tiễn cho việc kiểm tra sự thật dựa trên bằng chứng của các tuyên bố. Trong Kỷ yếu Hội nghị Năm 2019 về Các Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên và Hội nghị Liên hợp Quốc tế lần thứ 9 về Xử lý Ngôn ngữ Tự nhiên (EMNLP-IJCNLP), trang 4685–4697, Hồng Kông, Trung Quốc. Hiệp hội Ngôn ngữ Học Máy Tính.

Tom Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared D Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, và các tác giả khác. 2020. Các mô hình ngôn ngữ là những người học ít dữ liệu. Tiến bộ trong hệ thống xử lý thông tin thần kinh, 33:1877–1901.

Jifan Chen, Aniruddh Sriram, Eunsol Choi, và Greg Durrett. 2022. Tạo các câu hỏi phụ theo nghĩa đen và ngụ ý để kiểm chứng sự thật các tuyên bố phức tạp. Trong Kỷ yếu Hội nghị Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên năm 2022, trang 3495–3516, Abu Dhabi, Các Tiểu vương quốc Ả Rập Thống nhất. Hiệp hội Ngôn ngữ học Tính toán.

Xingyu Chen, Jiahao Xu, Tian Liang, Zhiwei He, Jianhui Pang, Dian Yu, Linfeng Song, Qiuzhi Liu, Mengfei Zhou, Zhuosheng Zhang, Rui Wang, Zhaopeng Tu, Haitao Mi, và Dong Yu. 2025. Đừng suy nghĩ quá nhiều về 2+3=? về việc suy nghĩ quá mức của các mô hình ngôn ngữ giống o1.

Yung-Sung Chuang, Yujia Xie, Hongyin Luo, Yoon Kim, James R. Glass và Pengcheng He. 2024. Dola: Giải mã bằng cách đối chiếu các lớp cải thiện độ thực tế trong các mô hình ngôn ngữ lớn. Trong Hội nghị Quốc tế lần thứ Mười Hai về Biểu diễn Học Tập.

Karl Cobbe, Vineet Kosaraju, Mohammad Bavarian, MarkChen, HeewooJun, Lukasz Kaiser, Matthias Plappert, Jerry Tworek, Jacob Hilton, Reiichiro Nakano, Christopher Hesse, và John Schulman. 2021. Huấn luyện các bộ xác minh để giải các bài toán từ ngữ về toán học.

Alejandro Cuadron, Dacheng Li, Wenjie Ma, Xingyao Wang, Yichuan Wang, Siyuan Zhuang, Shu Liu, Luis Gaspar Schroeder, Tian Xia, Huanzhi Mao, Nicholas Thumiger, Aditya Desai, Ion Stoica, Ana Klimovic, Graham Neubig, và Joseph E. Gonzalez. 2025. Nguy cơ của việc suy nghĩ quá mức: Khảo sát mẫu thuẫn suy luận-hành động trong các nhiệm vụ tự chủ.

DeepSeek-AI, Daya Guo, Dejian Yang, Haowei Zhang, Junxiao Song, Ruoyu Zhang, Runxin Xu, Qihao Zhu, Shirong Ma, Peiyi Wang, Xiao Bi, Xiaokang Zhang, Xingkai Yu, Yu Wu, Z. F. Wu, Zhibin Gou, Zhihong Shao, Zhuoshu Li, Ziyi Gao, Aixin Liu, Bing Xue, Bingxuan Wang, Bochao Wu, Bei Feng, Chengda Lu, Chenggang Zhao, Chengqi Deng, Chenyu Zhang, Chong Ruan, Damai Dai, Deli Chen, Dongjie Ji, Erhang Li, Fangyun Lin, Fucong Dai, Fuli Luo, Guangbo Hao, Guanting Chen, Guowei Li, H. Zhang, Han Bao, Hanwei Xu, Haocheng Wang, Honghui Ding, Huajian Xin, Huazuo Gao, Hui Qu, Hui Li, Jianzhong Guo, Jiashi Li, Jiawei Wang, Jingchang Chen, Jingyang Yuan, Junjie Qiu, Junlong Li, J. L. Cai, Jiaqi Ni, Jian Liang, Jin Chen, Kai Dong, Kai Hu, Kaige Gao, Kang Guan, Kexin Huang, Kuai Yu, Lean Wang, Lecong Zhang, Liang Zhao, Litong Wang, Liyue Zhang, Lei Xu, Leyi Xia, Mingchuan Zhang, Minghua Zhang, Minghui Tang, Meng Li, Miaojun Wang, Mingming Li, Ning Tian, Panpan Huang, Peng Zhang, Qiancheng Wang, Qinyu Chen, Qius

Yanping Huang, Yaohui Li, Yi Zheng, Yuchen Zhu, Yunxian Ma, Ying Tang, Yukun Zha, Yuting Yan, Z. Z. Ren, Zehui Ren, Zhangli Sha, Zhe Fu, Zhean Xu, Zhenda Xie, Zhengyan Zhang, Zhewen Hao, Zhicheng Ma, Zhigang Yan, Zhiyu Wu, Zihui Gu, Zi-jia Zhu, Zijun Liu, Zilin Li, Ziwei Xie, Ziyang Song, Zizheng Pan, Zhen Huang, Zhipeng Xu, Zhongyu Zhang, and Zhen Zhang. 2025. Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning. Thomas Diggelmann, Jordan Boyd-Graber, Jannis Bu-lian, Massimiliano Ciaramita, and Markus Leippold. 2021. Climate-fever: A dataset for verification of real-world climate claims. Xidong Feng, Ziyu Wan, Muning Wen, Stephen Marcus McAleer, Ying Wen, Weinan Zhang, and Jun Wang. 2024. Alphazero-like tree-search can guide large language model decoding and training. Zhijiang Guo, Michael Schlichtkrull, and Andreas Vlachos. 2022. A survey on automated fact-checking. <i>Transactions of the Association for Computational Linguistics</i>, 10:178–206. Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. 2021. Lora: Low-rank adaptation of large language models. Jie Huang and Kevin Chen-Chuan Chang. 2023. Towards reasoning in large language models: A survey. In <i>Findings of the Association for Computational Linguistics: ACL 2023</i>, pages 1049–1065, Toronto, Canada. Association for Computational Linguistics. Soyeong Jeong, Jinheon Baek, Sukmin Cho, Sung Ju Hwang, and Jong C. Park. 2024. Adaptive-rag: Learning to adapt retrieval-augmented large language models through question complexity. Yichen Jiang, Shikha Bordia, Zheng Zhong, Charles Dognin, Maneesh Singh, and Mohit Bansal. 2020. HoVer: A dataset for many-hop fact extraction and claim verification. In <i>Findings of the Association for Computational Linguistics: EMNLP 2020</i>, pages 3441–3460, Online. Association for Computational Linguistics. Bowen Jin, Hansi Zeng, Zhenrui Yue, Jinsung Yoon, Sercan Arik, Dong Wang, Hamed Zamani, and Jiawei Han. 2025. Search-r1: Training llms to reason and leverage search engines with reinforcement learning. Neema Kotonya and Francesca Toni. 2020. Explainable automated fact-checking for public health claims. Miaoran Li, Baolin Peng, Michel Galley, Jianfeng Gao, and Zhu Zhang. 2024. Self-checker: Plug-and-play modules for fact-checking with large language models. In <i>Findings of the Association for Computational Linguistics: NAACL 2024</i>, pages 163–181, Mexico City, Mexico. Association for Computational Linguistics.	Hunter Lightman, Vineet Kosaraju, Yura Burda, Harri Edwards, Bowen Baker, Teddy Lee, Jan Leike, John Schulman, Ilya Sutskever, and Karl Cobbe. 2023. Let’s verify step by step. Huanshuo Liu, Hao Zhang, Zhijiang Guo, Jing Wang, Kuicai Dong, Xiangyang Li, Yi Quan Lee, Cong Zhang, and Yong Liu. 2024. Ctrla: Adaptive retrieval-augmented generation via inherent control. Aman Madaan, Niket Tandon, Prakhar Gupta, Skyler Hallinan, Luyu Gao, Sarah Wiegreffe, Uri Alon, Nouha Dziri, Shrimai Prabhumoye, Yiming Yang, Shashank Gupta, Bodhisattwa Prasad Majumder, Katherine Hermann, Sean Welleck, Amir Yazdanbakhsh, and Peter Clark. 2023. Self-refine: Iterative refinement with self-feedback. In <i>Advances in Neural Information Processing Systems</i>, volume 36, pages 46534–46594. Curran Associates, Inc. Alex Mallen, Akari Asai, Victor Zhong, Rajarshi Das, Daniel Khashabi, and Hannaneh Hajishirzi. 2023. When not to trust language models: Investigating effectiveness of parametric and non-parametric memories. Preslav Nakov, Federico Ruggeri, Sebastian Schellhammer, Vinay Setty, Megha Sundriyal10, Konstantin Todorov11, and V Venktesh. 2025. Overview of the clef-2025 checkthat! lab: Subjectivity, fact-checking, claim normalization, and retrieval. In <i>Experimental IR Meets Multilinguality, Multimodality, and Interaction: 16th International Conference of the CLEF Association, CLEF 2025, Madrid, Spain, September 9–12, 2025, Proceedings</i>, page 199. Springer Nature. Kevin Nanekhan, Erik Martin, Henrik Vatndal, Vinay Setty, and Avishek Anand. 2025. Flashcheck: Exploration of efficient evidence retrieval for fast fact-checking. In <i>European Conference on Information Retrieval</i>. Eric Nichols, Leo Gao, and Randy Gomez. 2020. Collaborative storytelling with large-scale neural language models. OpenAI. 2023. Gpt-4 technical report. OpenAI. 2024. Learning to reason with llms. https://openai.com/index/learning-to-reason-with-llms/. Accessed: 2025-04-26. Wojciech Ostrowski, Arnav Arora, Pepa Atanasova, and Isabelle Augenstein. 2021. Multi-hop fact checking of political claims. In <i>Proceedings of the Thirtieth International Joint Conference on Artificial Intelligence, IJCAI-21</i>, pages 3892–3898. International Joint Conferences on Artificial Intelligence Organization. Main Track. Mandeep Rathee, Sean MacAvaney, and Avishek Anand. 2024. Quam: Adaptive retrieval through query affinity modelling. <i>arXiv preprint arXiv:2410.20286</i>.	Yanping Huang, Yaohui Li, Yi Zheng, Yuchen Zhu, Yunxian Ma, Ying Tang, Yukun Zha, Yuting Yan, Z. Z. Ren, Zehui Ren, Zhangli Sha, Zhe Fu, Zhean Xu, Zhenda Xie, Zhengyan Zhang, Zhewen Hao, Zhicheng Ma, Zhigang Yan, Zhiyu Wu, Zihui Gu, Zi-jia Zhu, Zijun Liu, Zilin Li, Ziwei Xie, Ziyang Song, Zizheng Pan, Zhen Huang, Zhipeng Xu, Zhongyu Zhang, và Zhen Zhang. 2025. Deepseek-r1: Khuyến khích khả năng lý luận trong các mô hình ngôn ngữ lớn thông qua học tăng cường. Thomas Diggelmann, Jordan Boyd-Graber, Jannis Bu-lian, Massimiliano Ciaramita, và Markus Leippold. 2021. Climate-fever: Một tập dữ liệu để xác minh các tuyên bố về khí hậu trong thế giới thực. Xidong Feng, Ziyu Wan, Muning Wen, Stephen Marcus McAleer, Ying Wen, Weinan Zhang, và Jun Wang. 2024. Cây tìm kiếm giống Alphazero có thể hướng dẫn việc giải mã và huấn luyện mô hình ngôn ngữ lớn. Zhijiang Guo, Michael Schlichtkrull, và Andreas Vlachos. 2022. Một khảo sát về kiểm tra sự thật tự động. Transactions of the Association for Computational Linguistics, 10:178–206. Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, và Weizhu Chen. 2021. Lora: Thích ứng bậc thấp của các mô hình ngôn ngữ lớn. Jie Huang và Kevin Chen-Chuan Chang. 2023. Hướng tới suy luận trong các mô hình ngôn ngữ lớn: Một khảo sát. Trong Kết quả của Hiệp hội Ngôn ngữ học Máy tính: ACL 2023, trang 1049–1065, Toronto, Canada. Hiệp hội Ngôn ngữ học Máy tính. Soyeong Jeong, Jinheon Baek, Sukmin Cho, Sung Ju Hwang, và Jong C. Park. 2024. Adaptive-rag: Học cách thích nghi với các mô hình ngôn ngữ lớn được tăng cường truy xuất thông tin thông qua độ phức tạp của câu hỏi. Yichen Jiang, Shikha Bordia, Zheng Zhong, Charles Dognin, Maneesh Singh và Mohit Bansal. 2020. HoVer: Một tập dữ liệu cho trích xuất sự thật nhiều bước và xác minh tuyên bố. Trong Kết quả của Hiệp hội Ngôn ngữ học Máy tính: EMNLP2020, trang 3441–3460, Trục t uyển. Hiệp hội Ngôn ngữ học Máy tính. Bowen Jin, Hansi Zeng, Zhenrui Yue, Jinsung Yoon, Sercan Arik, Dong Wang, Hamed Zamani, và Jiawei Han. 2025. Search-r1: Huấn luyện LLMs để suy luận và tận dụng các công cụ tìm kiếm bằng học tăng cường. Neema Kotonya và Francesca Toni. 2020. Kiểm tra sự thật tự động có thể giải thích cho các tuyên bố về sức khỏe cộng đồng. Miaoran Li, Baolin Peng, Michel Galley, Jianfeng Gao, và Zhu Zhang. 2024. Self-checker: Các mô-đun cấm và chạy để kiểm tra sự thật với các mô hình ngôn ngữ lớn. Trong Kết quả của Hiệp hội Ngôn ngữ học Máy tính: NAACL 2024, trang 163–181, Thành phố Mexico, Mexico. Hiệp hội Ngôn ngữ học Máy tính.	Hunter Lightman, Vineet Kosaraju, Yura Burda, Harri Edwards, BowenBaker, TeddyLee, Jan Leike, John Schulman, Ilya Sutskever, và Karl Cobbe. 2023. Hãy xác minh từng bước một. Huanshuo Liu, Hao Zhang, Zhijiang Guo, Jing Wang, Kuicai Dong, Xiangyang Li, Yi Quan Lee, Cong Zhang, và Yong Liu. 2024. Ctrla: Sinh tạo tăng cường truy xuất thích ứng thông qua kiểm soát vốn có. Aman Madaan, Niket Tandon, Prakhar Gupta, Skyler Hallinan, Luyu Gao, Sarah Wiegreffe, Uri Alon, Nouha Dziri, Shrimai Prabhumoye, Yiming Yang, Shashank Gupta, Bodhisattwa Prasad Majumder, Katherine Hermann, Sean Welleck, Amir Yazdanbakhsh, và Peter Clark. 2023. Self-refine: Tinh chỉnh lặp đi lặp lại với phản hồi tự thân. Trong Tạp chí Advances in Neural Information Processing Systems, tập 36, các trang 46534–46594. Curran Associates, Inc. Alex Mallen, Akari Asai, Victor Zhong, Rajarshi Das, Daniel Khashabi, và Hannaneh Hajishirzi. 2023. Khi nào không nên tin vào các mô hình ngôn ngữ: Điều tra hiệu quả của bộ nhớ tham số và phi tham số. Preslav Nakov, Federico Ruggeri, Sebastian Schellhammer, Vinay Setty, Megha Sundriyal10, Konstantin Todorov11, và V Venktesh. 2025. Tổng quan về phòng thí nghiệm clef-2025 checkthat!: Chủ quan, kiểm tra sự thật, chuẩn hóa tuyên bố và truy xuất. Trong Triển khai IR Thí nghiệm Gặp Gỡ Đa ngôn ngữ, Đa phương tiện và Tương tác: Hội nghị Quốc tế lần thứ 16 của Hiệp hội CLEF, CLEF 2025, Madrid, Tây Ban Nha, từ 9–12 tháng 9, 2025, Kỷ yếu, trang 199. Springer Nature. Kevin Nanekhan, Erik Martin, Henrik Vatndal, Vinay Setty, và Avishek Anand. 2025. Flashcheck: Khám phá việc truy xuất bằng chứng hiệu quả cho kiểm tra sự thật nhanh. Trong Hội nghị Châu Âu về Truy xuất Thông tin. Eric Nichols, Leo Gao, và Randy Gomez. 2020. Kể chuyện hợp tác với các mô hình ngôn ngữ thần kinh quy mô l ớn. OpenAI. 2023. Báo cáo kỹ thuật GPT-4. OpenAI. 2024. Học cách lý luận với LLMs. https://openai.com/index/learning-to-reason-with-llms/. Truy cập: 26-04-2025. Wojciech Ostrowski, Arnav Arora, Pepa Atanasova, và Isabelle Augenstein. 2021. Kiểm tra sự thật nhiều bước đối với các tuyên bố chính trị. Trong Kỷ yếu của Hội nghị Liên hợp Quốc tế lần thứ ba mươi về Trí tuệ Nhân tạo, IJCAI-21, trang 3892–3898. Tổ chức Các Hội nghị Liên hợp Quốc tế về Trí tuệ Nhân tạo. Chương Chính. Mandeep Rathee, Sean MacAvaney, và Avishek Anand. 2024. Quam: Truy xuất thích ứng thông qua mô hình hóa sự t ương đồng truy vấn. arXiv preprint arXiv:2410.20286.
--	--	--	---

Nils Reimers and Iryna Gurevych. 2019. [Sentence-bert: Sentence embeddings using siamese bert-networks](#). In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics.

J. J. Rocchio. 1971. Relevance feedback in information retrieval. In G. Salton, editor, *The Smart retrieval system - experiments in automatic document processing*, pages 313–323. Englewood Cliffs, NJ: Prentice-Hall.

Michael Schlichtkrull, Zhijiang Guo, and Andreas Vlachos. 2023. [Averitec: A dataset for real-world claim verification with evidence from the web](#).

Vinay Setty. 2024. [Surprising efficacy of fine-tuned transformers for fact-checking over larger language models](#). In *Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval*, SIGIR ’24, page 2842–2846, New York, NY, USA. Association for Computing Machinery.

Avi Singh, John D. Co-Reyes, Rishabh Agarwal, Ankesh Anand, Piyush Patil, Xavier Garcia, Peter J. Liu, James Harrison, Jaehoon Lee, Kelvin Xu, Aaron Parisi, Abhishek Kumar, Alex Alemi, Alex Rizkowsky, Azade Nova, Ben Adlam, Bernd Bohnet, Gamaleldin Elsayed, Hanie Sedghi, Igor Mordatch, Isabelle Simpson, Izzeddin Gur, Jasper Snoek, Jeffrey Pennington, Jiri Hron, Kathleen Kenealy, Kevin Swersky, Kshiteej Mahajan, Laura Culp, Lechao Xiao, Maxwell L. Bileschi, Noah Constant, Roman Novak, Rosanne Liu, Tris Warkentin, Yundi Qian, Yamini Bansal, Ethan Dyer, Behnam Neyshabur, Jascha Sohl-Dickstein, and Noah Fiedel. 2024. [Beyond human data: Scaling self-training for problem-solving with language models](#).

Charlie Snell, Jaehoon Lee, Kelvin Xu, and Aviral Kumar. 2024. [Scaling llm test-time compute optimally can be more effective than scaling model parameters](#).

Jake Snell, Kevin Swersky, and Richard Zemel. 2017. Prototypical networks for few-shot learning. In *Proceedings of the 31st International Conference on Neural Information Processing Systems, NIPS’17*, page 4080–4090, Red Hook, NY, USA. Curran Associates Inc.

Zhivar Sourati, Darshan Girish Deshpande, Filip Ilievski, Kiril Gashteovski, and Sascha Saralajew. 2024. [Robust text classification: Analyzing prototype-based networks](#). In *Findings of the Association for Computational Linguistics: EMNLP 2024*, pages 12736–12757, Miami, Florida, USA. Association for Computational Linguistics.

Yang Sui, Yu-Neng Chuang, Guanchu Wang, Jiamu Zhang, Tianyi Zhang, Jiayi Yuan, Hongyi Liu, Andrew Wen, Shaochen Zhong, Hanjie Chen, and Xia Hu. 2025. [Stop overthinking: A survey on efficient reasoning for large language models](#).

Qi Sun, Marc Pickett, Aakash Kumar Nain, and Llion Jones. 2025. [Transformer layers as painters](#).

James Thorne, Andreas Vlachos, Christos Christodoulopoulos, and Arpit Mittal. 2018. [FEVER: a large-scale dataset for fact extraction and VERification](#). In *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long Papers)*, pages 809–819, New Orleans, Louisiana. Association for Computational Linguistics.

Jonathan Uesato, Nate Kushman, Ramana Kumar, Francis Song, Noah Siegel, Lisa Wang, Antonia Creswell, Geoffrey Irving, and Irina Higgins. 2022. [Solving math word problems with process- and outcome-based feedback](#).

Venktesh V, Abhijit Anand, Avishek Anand, and Vinay Setty. 2024. [Quantemp: A real-world open-domain benchmark for fact-checking numerical claims](#). In *Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval*, SIGIR ’24, page 650–660, New York, NY, USA. Association for Computing Machinery.

Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. 2023. [Attention is all you need](#).

V Venktesh, Avishek Anand, et al. 2025. Trust but verify! a survey on verification design for test-time scaling. *arXiv preprint arXiv:2508.16665*.

Juraj Vladika and Florian Matthes. 2023. [Scientific fact-checking: A survey of resources and approaches](#).

David Wadden, Shanchuan Lin, Kyle Lo, Lucy Lu Wang, Madeleine van Zuylen, Arman Cohan, and Hannaneh Hajishirzi. 2020. [Fact or fiction: Verifying scientific claims](#). In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 7534–7550, Online. Association for Computational Linguistics.

Jonas Wallat, Abdelrahman Abdallah, Adam Jatowt, and Avishek Anand. 2024a. A study into investigating temporal robustness of llms. *Findings of the Association for Computational Linguistics*.

Jonas Wallat, Adam Jatowt, and Avishek Anand. 2024b. Temporal blind spots in large language models. In *Proceedings of the 17th ACM International Conference on Web Search and Data Mining*, pages 683–692.

Peiyi Wang, Lei Li, Zhihong Shao, R. X. Xu, Damai Dai, Yifei Li, Deli Chen, Y. Wu, and Zhifang Sui. 2024. [Math-shepherd: Verify and reinforce llms step-by-step without human annotations](#).

William Yang Wang. 2017. [“liar, liar pants on fire”: A new benchmark dataset for fake news detection](#). In *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers)*, pages 422–426, Vancouver, Canada. Association for Computational Linguistics.

Nils Reimers và Iryna Gurevych. 2019. Sentence-bert: Những câu sử dụng mạng bert song sinh. Trong Kỷ yếu Hội nghị 2019 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên. Hiệp hội Ngôn ngữ học Máy tính. J. J. Rocchio. 1971. Phản hồi liên quan trong truy xuất thông tin. Trong G. Salton, biên tập, Hệ thống truy xuất thông minh - thí nghiệm trong xử lý tài liệu tự động, trang 313–323. Englewood Cliffs, NJ: Prentice-Hall. Michael Schlichtkrull, Zhijiang Guo, và Andreas Vlachos. 2023. Averitec: Một bộ dữ liệu cho xác minh tuyên bố thực tế với bằng chứng từ web. Vinay Setty. 2024. Hiệu quả bất ngờ của các transformer tinh chỉnh trong kiểm tra sự thật so với các mô hình ngôn ngữ lớn hơn. Trong Kỷ yếu Hội nghị Quốc tế ACM SIGIR lần thứ 47 về Nghiên cứu và Phát triển trong Truy xuất Thông tin, SIGIR ’24, trang 2842–2846, New York, NY, Hoa Kỳ. Hiệp hội Máy tính.

Avi Singh, John D. Co-Reyes, Rishabh Agarwal, Ankesh Anand, Piyush Patil, Xavier Garcia, Peter J. Liu, James Harrison, Jaehoon Lee, Kelvin Xu, Aaron Parisi, Abhishek Kumar, Alex Alemi, Alex Rizkowsky, Azade Nova, Ben Adlam, Bernd Bohnet, Gamaleldin Elsayed, Hanie Sedghi, Igor Mordatch, Isabelle Simpson, Izzeddin Gur, Jasper Snoek, Jeffrey Pennington, Jiri Hron, Kathleen Kenealy, Kevin Swersky, Kshiteej Mahajan, Laura Culp, Lechao Xiao, Maxwell L. Bileschi, Noah Constant, Roman Novak, Rosanne Liu, Tris Warkentin, Yundi Qian, Yamini Bansal, Ethan Dyer, Behnam Neyshabur, Jascha Sohl-Dickstein và Noah Fiedel. 2024. Vượt ra ngoài dữ liệu con người: Mở rộng tự huấn luyện để giải quyết vấn đề với các mô hình ngôn ngữ.

Charlie Snell, Jaehoon Lee, Kelvin Xu, và Aviral Kumar. 2024. Tăng cường tính toán thời gian kiểm tra của LLM một cách tối ưu có thể hiệu quả hơn so với việc tăng số lượng tham số của mô hình.

Jake Snell, Kevin Swersky, và Richard Zemel. 2017. Mạng nguyên mẫu cho học với số lượng mẫu ít. Trong Kỷ yếu của Hội nghị Quốc tế lần thứ 31 về Hệ thống Xử lý Thông tin Thần kinh, NIPS’17, trang 4080–4090, Red Hook, NY, Hoa Kỳ. Curran Associates Inc.

Zhivar Sourati, Darshan Girish Deshpande, Filip Ilievski, Kiril Gashteovski, và Sascha Saralajew. 2024. Phân loại văn bản vững chắc: Phân tích các mạng dựa trên nguyên mẫu. Trong Kết quả của Hiệp hội Ngôn ngữ học Máy tính: EMNLP 2024, trang 12736–12757, Miami, Florida, Hoa Kỳ. Hiệp hội Ngôn ngữ học Máy tính. Yang Sui, Yu-Neng Chuang, Guanchu Wang, Jiamu Zhang, Tianyi Zhang, Jiayi Yuan, Hongyi Liu, Andrew Wen, Shaochen Zhong, Hanjie Chen, và Xia Hu. 2025. Ngừng suy nghĩ quá nhiều: Một khảo sát về lý luận hiệu quả cho các mô hình ngôn ngữ lớn. Qi Sun, Marc Pickett, Aakash Kumar Nain, và Llion Jones. 2025. Các lớp Transformer như những họa sĩ.

James Thorne, Andreas Vlachos, Christos Christodoulopoulos, và Arpit Mittal. 2018. FEVER: một tập dữ liệu quy mô lớn cho việc trích xuất sự kiện và XÁC MINH. Trong Kỷ yếu Hội nghị 2018 của Chương Bắc Mỹ thuộc Hiệp hội Ngôn ngữ Học Máy tính: Công nghệ Ngôn ngữ Con người, Tập 1 (Bài báo dài), trang 809–819, New Orleans, Louisiana. Hiệp hội Ngôn ngữ Học Máy tính. Jonathan Uesato, Nate Kushman, Ramana Kumar, Francis Song, Noah Siegel, Lisa Wang, Antonia Creswell, Geoffrey Irving và Irina Higgins. 2022. Giải quyết các bài toán từ toán học với phản hồi dựa trên quá trình và kết quả. Venktesh V, Abhijit Anand, Avishek Anand và Vinay Setty. 2024. Quantemp: Một chuẩn đánh giá thực tế mở về xác minh các tuyên bố số. Trong Kỷ yếu Hội nghị Quốc tế ACM SIGIR lần thứ 47 về Nghiên cứu và Phát triển trong Truy hồi Thông tin, SIGIR ’24, trang 650–660, New York, NY, USA. Hiệp hội Máy tính.

Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, và Illia Polosukhin. 2023. Chỉ cần chú ý.

V Venktesh, Avishek Anand, và cộng sự. 2025. Tin nhưng kiểm chứng! một khảo sát về thiết kế xác minh cho việc mở rộng thời gian kiểm tra. Bản in trước arXiv arXiv:2508.16665.

Juraj Vladika và Florian Matthes. 2023. Kiểm tra sự thật khoa học: Một khảo sát về các nguồn lực và phương pháp tiếp cận.

David Wadden, Shanchuan Lin, Kyle Lo, Lucy Lu Wang, Madeleine van Zuylen, Arman Cohan và Hannaneh Hajishirzi. 2020. Thực hay hư: Xác thực các tuyên bố khoa học. Trong Kỷ yếu Hội nghị Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên 2020 (EMNLP), trang 7534–7550, Trục tuyến. Hiệp hội Ngôn ngữ học Tính toán.

Jonas Wallat, Abdelrahman Abdallah, Adam Jatowt và Avishek Anand. 2024a. Một nghiên cứu về điều tra độ bền theo thời gian của LLMs. Kết quả của Hiệp hội Ngôn ngữ học Máy tính.

Jonas Wallat, Adam Jatowt, và Avishek Anand. 2024b. Điểm mù về thời gian trong các mô hình ngôn ngữ lớn. Trong Kỷ yếu Hội nghị Quốc tế ACM lần thứ 17 về Tìm kiếm Web và Khai thác Dữ liệu, trang 683–692. Peiyi Wang, Lei Li, Zhihong Shao, R. X. Xu, Damai Dai, Yifei Li, Deli Chen, Y. Wu, và Zhifang Sui. 2024. Math-shepherd: Xác minh và củng cố các mô hình ngôn ngữ từng bước mà không cần chú thích của con người. William Yang Wang. 2017. “liar, liar pants on fire”: Bộ dữ liệu chuẩn mới cho phát hiện tin giả. Trong Kỷ yếu Cuộc họp Thường niên lần thứ 55 của Hiệp hội Ngôn ngữ học Máy tính (Tập 2: Bài báo ngắn), trang 422–426, Vancouver, Canada. Hiệp hội Ngôn ngữ học Máy tính.

Xuezhi Wang, Jason Wei, Dale Schuurmans, Quoc Le, Ed Chi, Sharan Narang, Aakanksha Chowdhery, and Denny Zhou. 2023. [Self-consistency improves chain of thought reasoning in language models](#).

Jason Wei, Yi Tay, Rishi Bommasani, Colin Raffel, Barret Zoph, Sebastian Borgeaud, Dani Yogatama, Maarten Bosma, Denny Zhou, Donald Metzler, Ed H. Chi, Tatsunori Hashimoto, Oriol Vinyals, Percy Liang, Jeff Dean, and William Fedus. 2022. [Emergent abilities of large language models](#).

Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Brian Ichter, Fei Xia, Ed Chi, Quoc Le, and Denny Zhou. 2023. [Chain-of-thought prompting elicits reasoning in large language models](#).

Dustin Wright, David Wadden, Kyle Lo, Bailey Kuehl, Arman Cohan, Isabelle Augenstein, and Lucy Lu Wang. 2022. [Generating scientific claims for zero-shot scientific fact checking](#).

Yuxi Xie, Kenji Kawaguchi, Yiran Zhao, Xu Zhao, Min-Yen Kan, Junxian He, and Qizhe Xie. 2023. [Self-evaluation guided beam search for reasoning](#).

Shunyu Yao, Dian Yu, Jeffrey Zhao, Izhak Shafran, Thomas L. Griffiths, Yuan Cao, and Karthik Narasimhan. 2023a. [Tree of thoughts: Deliberate problem solving with large language models](#).

Shunyu Yao, Jeffrey Zhao, Dian Yu, Nan Du, Izhak Shafran, Karthik R Narasimhan, and Yuan Cao. 2023b. [React: Synergizing reasoning and acting in language models](#). In *The Eleventh International Conference on Learning Representations*.

Eric Zelikman, Yuhuai Wu, Jesse Mu, and Noah D. Goodman. 2022. [Star: Bootstrapping reasoning with reasoning](#).

Qiyuan Zhang, Fuyuan Lyu, Zexu Sun, Lei Wang, Weixu Zhang, Wenyue Hua, Haolun Wu, Zhihan Guo, Yufei Wang, Niklas Muennighoff, et al. 2025. A survey on test-time scaling in large language models: What, how, where, and how well? *arXiv preprint arXiv:2503.24235*.

Xuezhi Wang, Jason Wei, Dale Schuurmans, Quoc Le, Ed Chi, Sharan Narang, Aakanksha Chowdhery, và Denny Zhou. 2023. Tính nhất quán tự thân cải thiện lập luận chuỗi suy nghĩ trong các mô hình ngôn ngữ.

Jason Wei, Yi Tay, Rishi Bommasani, Colin Raffel, Barret Zoph, Sebastian Borgeaud, Dani Yogatama, Maarten Bosma, Denny Zhou, Donald Metzler, Ed H. Chi, Tatsunori Hashimoto, Oriol Vinyals, Percy Liang, Jeff Dean, và William Fedus. 2022. Khả năng nổi bật của các mô hình ngôn ngữ lớn.

Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Brian Ichter, Fei Xia, Ed Chi, Quoc Le và Denny Zhou. 2023. Gợi ý theo chuỗi tư duy kích thích lý luận trong các mô hình ngôn ngữ lớn.

Dustin Wright, David Wadden, Kyle Lo, Bailey Kuehl, Arman Cohan, Isabelle Augenstein, và Lucy Lu Wang. 2022. Tạo ra các tuyên bố khoa học để kiểm tra sự thật khoa học theo phương pháp zero-shot.

Yuxi Xie, Kenji Kawaguchi, Yiran Zhao, Xu Zhao, Min-Yen Kan, Junxian He, và Qizhe Xie. 2023. Tìm kiếm chùm tia hướng dẫn tự đánh giá để suy luận.

Shunyu Yao, Dian Yu, Jeffrey Zhao, Izhak Shafran, Thomas L. Griffiths, Yuan Cao, và Karthik Narasimhan. 2023a. Cây suy nghĩ: Giải quyết vấn đề có suy xét với các mô hình ngôn ngữ lớn.

Shunyu Yao, Jeffrey Zhao, Dian Yu, Nan Du, Izhak Shafran, Karthik R Narasimhan, và Yuan Cao. 2023b. React: Tăng cường sự kết hợp giữa lập luận và hành động trong các mô hình ngôn ngữ. Trong Hội nghị Quốc tế lần thứ Mười một về Học các Biểu diễn.

Eric Zelikman, Yuhuai Wu, Jesse Mu, và Noah D. Goodman. 2022. Star: Khởi động tư duy với tư duy.

Qiyuan Zhang, Fuyuan Lyu, Zexu Sun, Lei Wang, Weixu Zhang, Wenyue Hua, Haolun Wu, Zhihan Guo, Yufei Wang, Niklas Muennighoff, và cộng sự. 2025. Một khảo sát về mở rộng thời gian kiểm tra trong các mô hình ngôn ngữ lớn: Cái gì, như thế nào, ở đâu, và hiệu quả ra sao? Bản in trước trên arXiv arXiv:2503.24235.

Annotator Guidelines for Claim Complexity Annotation

Annotation Instructions:
Please review the given claim in context of provided expert fact-checker justification and verdict. Trace the process of fact-checking by yourself and analyze how many aspects need to be verified in the claim. if the claim has more than one aspect that has to be verifier using multiple sources annotate it as 1 else annotate it as 0.

Figure 4: Annotator Guidelines for Claim Complexity Annotation.

A Annotation Guidelines

A.1 Guidelines for Manual analysis of reasoning drift issue

Figure 5 presents the guidelines to the annotator qualitatively evaluating the samples identified by judge LLMs for *reasoning drift*. Depending on the human judgements, they are instructed to assign a category 1 if they agree with the LLM’s judgement and 0 otherwise. This assignment is used to compute Cohen’s Kappa to evaluate inter-annotator agreements.

A.2 Annotation Guidelines for Claim Complexity

Figure 4 shows the guidelines for annotating complexity level for the claims.

B More examples exhibiting reasoning drift

Figure 6 and Figure 7 provides more qualitative examples where LLM exhibits *reasoning drift* during reasoning. This is mitigated by selecting the *best* reasoning sequence using VERIFIERFC.

C Prompts

This section describes the system and user prompts employed during different phases of our experiments. Figures 8 and 9 show the system prompt and a sample user prompt used to determine whether verifier-based reasoning reduces *reasoning drift* compared to its Top 1 Decoding counterpart. Figure 10 illustrates an example prompt designed to guide the fact-checking LLM in predicting a verdict and providing reasoning for a claim-evidence pair

Annotator Guidelines for Evaluating Reasoning Drift

Please review the LLM’s judgment regarding the presence or absence of reasoning drift, along with its justification. Then, annotate whether you believe the label is correct and whether it aligns with our definition of reasoning drift.

Definition of Reasoning Drift: Reasoning Drift is defined as a behavior inherent to LLMs, where—particularly in the context of fact-checking—the model overfits to an aspect of the claim that is not central to verifying its truth. This can be triggered by irrelevant details or by diverse contexts.

Examples:

- An LLM might fail to recognize that two quantities expressed in different units (e.g., KSh and dollars) represent the same value.
- It might not realize that the same political manifesto could have been adopted by a party in both 1928 and a later year, leading to unnecessary doubt.

Annotation Instructions: If the LLM judge has determined that reasoning drift is present (or absent), and you agree that this decision aligns with the definition above, mark it as **1** (i.e., correct). Otherwise, mark it as **0** (i.e., incorrect). We will use this to compute inter-annotator agreement.

Figure 5: Guidelines for human annotators evaluating the reasoning drift prediction made by the judge LLM.

Hướng dẫn Người chú thích về Chú thích Độ phức tạp của Yêu cầu

Hướng dẫn chú thích:
Vui lòng xem xét tuyên bố đã cho trong bối cảnh của lý do và phán quyết từ chuyên gia kiểm chứng thông tin được cung cấp. Tự theo dõi quá trình kiểm chứng thông tin và phân tích xem có bao nhiêu khía cạnh cần được xác minh trong tuyên bố. Nếu tuyên bố có nhiều hơn một khía cạnh cần được xác minh bằng nhiều nguồn, hãy chú thích nó là 1, nếu không hãy chú thích là 0.

Hình 4: Hướng dẫn Người chú thích cho Ghi chú Độ phức tạp của Yêu cầu.

Hướng dẫn chú thích

A.1 Hướng dẫn phân tích thủ công vấn đề trôi lý luận

Hình 5 trình bày hướng dẫn cho người chú thích đánh giá định tính các mẫu được xác định bởi các LLM thẩm phán về sự lệch lập luận. Tùy thuộc vào đánh giá của con người, họ được hướng dẫn gán một danh mục 1 nếu họ đồng ý với đánh giá của LLM và 0 nếu không. Việc gán này được sử dụng để tính toán Hệ số Kappa của Cohen nhằm đánh giá sự đồng thuận giữa các người chú thích.

A.2 Hướng Dẫn Chú Giải về Độ Phức Tạp của Yêu Cầu

Hình 4 cho thấy hướng dẫn về việc chú thích mức độ phức tạp cho các yêu cầu.

B Nhiều ví dụ hơn thể hiện sự trôi dạt trong lập luận

Hình 6 và Hình 7 cung cấp thêm các ví dụ định tính nơi LLM thể hiện sự trôi dạt trong lý luận trong quá trình suy luận. Điều này được giảm bớt bằng cách chọn chuỗi suy luận tốt nhất sử dụng VERIFIERFC.

C Lời nhắc

Phần này mô tả các lời nhắc của hệ thống và người dùng được sử dụng trong các giai đoạn khác nhau của các thí nghiệm của chúng tôi. Hình 8 và 9 cho thấy lời nhắc của hệ thống và một ví dụ về lời nhắc của người dùng được sử dụng để xác định liệu suy luận dựa trên người kiểm chứng có giảm sai lệch suy luận so với đối tác Giải mã Top 1 hay không. Hình 10 minh họa một ví dụ về lời nhắc được thiết kế để hướng dẫn LLM kiểm tra sự thật trong việc dự đoán một phán quyết và cung cấp lý luận cho một cặp tuyên bố-bằng chứng.

Hướng dẫn cho người chú thích để đánh giá sự lệch lạc trong lập luận

Vui lòng xem xét đánh giá của LLM về sự hiện diện hay vắng mặt của sự trôi luân lý, cùng với lý do của nó. Sau đó, ghi chú liệu bạn có tin rằng nhãn đó là chính xác và liệu nó có phù hợp với định nghĩa của chúng ta về sự trôi luân lý hay không.

Định nghĩa về Sai lệch Lý luận: Sai lệch Lý luận được định nghĩa là một hành vi vốn có ở các Mô hình Ngôn ngữ Lớn (LLM), trong đó—đặc biệt trong bối cảnh kiểm tra sự thật—mô hình quá khớp với một khía cạnh của tuyên bố không phải là trọng tâm để xác minh tính đúng đắn của nó. Điều này có thể bị kích hoạt bởi các chi tiết không liên quan hoặc bởi các bối cảnh đa dạng.

Ví dụ:

- Một mô hình ngôn ngữ lớn có thể không nhận ra rằng hai đại lượng được biểu thị bằng các đơn vị khác nhau (ví dụ: KSh và đô la) đại diện cho cùng một giá trị.
- Nó có thể không nhận ra rằng cùng một bản tuyên ngôn chính trị có thể đã được một đảng thông qua vào cả năm 1928 và một năm sau đó, dẫn đến những nghi ngờ không cần thiết.

Hướng dẫn chú thích: Nếu LLM judge đã xác định rằng có (hoặc không có) sự lệch lạc trong lập luận, và bạn đồng ý rằng quyết định này phù hợp với định nghĩa ở trên, đánh dấu nó là 1 (tức là đúng). Nếu không, đánh dấu nó là 0 (tức là sai). Chúng tôi sẽ sử dụng điều này để tính toán sự đồng thuận giữa các người chú thích.

Hình 5: Hướng dẫn cho những người chú thích đánh giá dự đoán lệch lý luận do judgeLLM thực hiện.

Mitigating *reasoning drift* for Numerical FC

Claim: There’s 100 million people that have preexisting conditions.

[Evidence]: a 2018 analysis by avalere, a health care consulting firm, **estimated that 102 million americans have preexisting conditions**. a 2019 analysis by the left-leaning center for american progress suggested **135 million people**.. also, it is unclear how many people with preexisting conditions would be at risk of losing their insurance entirely, or facing higher costs or having their conditions excluded from coverage. though bidens number is **certainly within this range**, he would need to provide more detail to support such a definitive number. the hhs issue brief, published in january 2017, estimated that between **61 million and 133 million** americans have a preexisting condition.

[Verdict]: True

LLM reasoning without VERIFIERFC
[Reasoning]: The evidence suggests a **range of estimates for the number of people with pre-existing conditions**, with Biden’s number being within this range but not universally accepted.
[Prediction]: **Conflicting**

LLM reasoning with VERIFIERFC
[Reasoning]: The claim is supported by multiple credible sources, including a former Vice President and health care consulting firms, with estimates **ranging from 61 to 135 million** Americans having pre-existing conditions. **Biden’s statement of 100 million falls within this range.**

[Prediction]: True

Figure 6: Example numerical claim demonstrating *reasoning drift* issue and mitigation offered by VERIFIERFC

within a few-shot learning framework. Lastly, Figure 11 presents the system prompt used to generate sub-questions by breaking down a claim, following the methodology detailed in the CLAIMDECOMP paper (Chen et al., 2022).

Mitigating *reasoning drift* for Numerical FC

Claim: Egas Moniz, the inventor of the controversial lobotomy technique for treating mentally ill patients (particularly people with schizophrenia), was awarded a Nobel Prize in 1949 for his work.

[Evidence]: antnio egas moniz (1874-1955) of portugal was an ambitious and multitalented person. ... **he had hoped and perhaps expected to receive the nobel prize for this work**, and **was disappointed when he realized he would not**. in 1935 at an international neurology conference he saw a ... loses something by this operation, some spontaneity, some sparkle, some flavor of the personality." in 1942 they published an influential book promoting the practice. in the united states the number of lobotomies performed per year went from 100 in 1946 to 5,000 in **1949**. **that year moniz won the nobel prize in physiology/medicine for his contribution** reduced the perceived need for most lobotomies.

[Verdict]: True

LLM reasoning without VERIFIERFC
[Reasoning]: The text states that Moniz was **disappointed when he realized he would not receive the Nobel Prize** for his work on visualizing blood vessels in the brain, but later won the Nobel Prize in Physiology or Medicine in 1949. This suggests that there is a **discrepancy between the information provided**.
[Prediction]: **Conflicting**

LLM reasoning with VERIFIERFC
[Reasoning]: The text states that Moniz was disappointed when he realized he would not receive the Nobel Prize for his work on visualizing blood vessels in the brain, but **later won the Nobel Prize in Physiology/Medicine in 1949** for his contribution to psychosurgery.

[Prediction]: True

Figure 7: Example numerical claim demonstrating *reasoning drift* issue and mitigation offered by VERIFIERFC

Giảm thiểu sự trôi dạt lập luận cho FC số học

Khẳng định: Có 100 triệu người có tình trạng bệnh lý từ trước.

[Bằng chứng]: một phân tích năm 2018 của Avalere, một công ty tư vấn chăm sóc sức khỏe, ước tính rằng 102 triệu người Mỹ có các tình trạng bệnh lý từ trước. Một phân tích năm 2019 của Trung tâm Tiến bộ Mỹ nghiêng về cánh tả gợi ý 135 triệu người. Ngoài ra, không rõ có bao nhiêu người có các tình trạng bệnh lý từ trước sẽ có nguy cơ mất hoàn toàn bảo hiểm, hoặc phải đối mặt với chi phí cao hơn hoặc tình trạng của họ không được bảo hiểm. Mặc dù con số của Biden chắc chắn nằm trong phạm vi này, ông sẽ cần cung cấp thêm chi tiết để chứng minh con số chắc chắn đó. Bản tóm tắt vấn đề của HHS, được công bố vào tháng 1 năm 2017, ước tính rằng từ 61 triệu đến 133 triệu người Mỹ có các tình trạng bệnh lý từ trước.

[Phán quyết]: True

Lập luận LLM mà không có VERIFIERFC
bằng chứng về một loạt các ước tính về số người có các tình trạng bệnh lý sẵn có, với con số của Biden nằm trong phạm vi này nhưng không được chấp nhận rộng rãi.[Dự đoán]: Mâu thuẫn

Lý luận LLM với VERIFIERFC
được cung cấp bởi nguồn đáng tin cậy, bao gồm một cựu Phó Tổng thống và các công ty tư vấn chăm sóc sức khỏe, với ước tính từ 61 đến 135 triệu người Mỹ có điều kiện bệnh lý tồn tại trước. Tuyên bố của Biden về 100 triệu nằm trong khoảng này.

[Dự đoán]: Đúng

Hình 6: Ví dụ về tuyên bố số học minh họa vấn đề lệch lý luận và biện pháp giảm thiểu do VERIFIERFC cung cấp

trong khuôn khổ học theo vài ví dụ. Cuối cùng, Hình 11 trình bày lời nhắc hệ thống được sử dụng để tạo các câu hỏi phụ bằng cách phân tách một tuyên bố, theo phương pháp được trình bày chi tiết trong bài báo CLAIMDECOMP (Chen et al., 2022).

Giảm thiểu sự lệch lập luận cho FC Số học

Khẳng định: Egas Moniz, người phát minh ra kỹ thuật cắt bỏ thùy não gây tranh cãi để điều trị bệnh nhân tâm thần (đặc biệt là những người mắc bệnh tâm thần phân liệt), đã được trao giải Nobel vào năm 1949 cho công trình của mình.

[Bằng chứng]: Antnio Egas Moniz (1874-1955) của Bồ Đào Nha là một người tham vọng và đa tài. ... Ông đã hy vọng và có lẽ mong đợi sẽ nhận giải Nobel cho công trình này, nhưng thất vọng khi nhận ra mình sẽ không được. Năm 1935 tại một hội nghị thần kinh quốc tế, ông nhận thấy một ... mất đi một phần nào đó từ ca phẫu thuật này, một chút tự nhiên, một chút lấp lánh, một chút hương vị của tính cách." Năm 1942, họ xuất bản một cuốn sách có ảnh hưởng quảng bá thực hành này. Tại Hoa Kỳ, số ca cắt bỏ thùy não được thực hiện mỗi năm tăng từ 100 ca năm 1946 lên 5.000 ca vào năm 1949. Năm đó, Moniz giành giải Nobel Sinh lý học/Y học cho những đóng góp của mình giảm nhu cầu được cho là về hầu hết các ca cắt thùy não.

[Phán quyết]: True

Lập luận LLM mà không có VERIFIERFC
[Lý luận]: Văn bản nêu rằng Moniz đã thất vọng khi nhận ra ông sẽ không nhận giải Nobel cho công trình của mình về việc hình dung các mạch máu trong não, nhưng sau đó ông đã giành giải Nobel về Sinh lý học hoặc Y học vào năm 1949. Điều này cho thấy có sự mâu thuẫn giữa các thông tin được cung cấp.[Dự đoán]: Mâu thuẫn

Lập luận LLM với VERIFIERFC
[Lý do]: Văn bản nêu rằng Moniz đã thất vọng khi nhận ra rằng ông sẽ không nhận Giải Nobel cho công trình của mình về hình dung các mạch máu trong não, nhưng sau đó đã giành Giải Nobel Y học/Sinh lý học năm 1949 vì đóng góp của mình trong phẫu thuật tâm thần.

[Dự đoán]: True e

Hình 7: Ví dụ về tuyên bố số học minh họa vấn đề trôi dạt lý luận và biện pháp giảm thiểu do VERIFIERFC cung cấp





Figure 8: System prompt provided to the judge LLM to evaluate and identify reasoning drift between reasoning with and without verifier support.



Hình 8: Lỗi nhắc hệ thống được cung cấp cho LLM trọng tài để đánh giá và xác định sự lệch lạc lập luận giữa việc lập luận có và không có sự hỗ trợ của bộ kiểm chứng.

An example user prompt to identify reasoning drift

Example:

[Claim]: Joe Biden says, “There’s 100 million people that have preexisting conditions.”

[Evidence]: a 2018 analysis by avalere, a health care consulting firm, estimated that 102 million americans have preexisting conditions. ... hhs issue brief, published in january 2017, estimated that between 61 million and 133 million americans have a preexisting condition.

[Verdict]: True

LLM reasoning without verifier

[Reasoning]: The evidence suggests a range of estimates for the number of people with pre-existing conditions, with Biden’s number being within this range but not universally accepted.

[Prediction]: Conflicting

LLM reasoning with verifier

[Reasoning]: The claim is supported by multiple credible sources, including a former Vice President and health care consulting firms, with estimates ranging from 61 to 135 million Americans having pre-existing conditions. Biden’s statement of 100 million falls within this range.

[Prediction]: True

LLM judgement

[Label]: 1

[Explanation]: The reward model-based reasoning effectively mitigates overthinking by focusing on the relevant evidence that supports the claim, specifically highlighting that Biden’s figure of 100 million falls within a credible range of estimates (61 to 135 million). In contrast, the reasoning without the reward model gets bogged down in the conflicting nature of the estimates without recognizing that Biden’s number is still valid within that context. The reward model reasoning arrives at the correct label (TRUE) more reliably by synthesizing the evidence holistically rather than getting lost in the details of conflicting statements.

Input:

[Claim]: Diaspora remittances “now stand at an all-time high of over KSh400 billion in 2021”.

[Evidence]: Diaspora remittances were robust in 2021, with total remittances in 2021 reaching a record USD 3,718 million.

[Verdict]: True

LLM reasoning without verifier

[Reasoning]: The evidence provides conflicting information about the exact amount of diaspora remittances in 2021, and some sources mention figures that are not directly comparable to KSh400 billion.

[Prediction]: Conflicting

LLM reasoning with verifier

[Reasoning]: The evidence supports the claim that diaspora remittances reached an all-time high of over KSh400 billion in 2021. However, there are minor variations in the wording and units used across different sources.

[Prediction]: True

Figure 9: An example user prompt to the judge LLM to identify reasoning driftbetween the reasoning without verifier and with verifier

24361

Một ví dụ về lời nhắc của người dùng để xác định sự trôi dạt trong lập luận

Ví dụ:

[Yêu cầu]: Joe Biden nói, “Có 100 triệu người có tình trạng bệnh lý từ trước.”

[Bằng chứng]: một phân tích năm 2018 do Avalere, một công ty tư vấn chăm sóc sức khỏe thực hiện, ước tính rằng 102 triệu người Mỹ có các điều kiện tiền sử. ... bản tóm tắt vấn đề của HHS, xuất bản vào tháng 1 năm 2017, ước tính rằng từ 61 triệu đến 133 triệu người Mỹ có một điều kiện tiền sử.

[Phán quyết]: Đúng

Suy luận LLM mà không có trình xác minh

[Reasoning]: Các bằng chứng gợi ý một phạm vi ước tính về số người có tình trạng bệnh lý từ trước, với Biden’s số của n nằm trong phạm vi này nhưng không được chấp nhận rộng rãi.

[Dự đoán]: Mâu thuẫn

Suy luận LLM với bộ kiểm chứng

[Lập luận]: Yêu cầu này được hỗ trợ bởi nhiều nguồn đáng tin cậy, bao gồm một cựu Phó Tổng thống và các công ty tư vấn chăm sóc sức khỏe, với ước tính từ 61 đến 135 triệu người Mỹ có bệnh nền. Phát biểu của Biden về con số 100 triệu nằm trong khoảng này.

[Dự đoán]: Đúng

Đánh giá LLM

[Nhân]: 1

[Giải thích]: Suy luận dựa trên mô hình phần thưởng hiệu quả trong việc giảm suy nghĩ quá mức bằng cách tập trung vào bằng chứng có liên quan hỗ trợ cho tuyên bố, đặc biệt nhấn mạnh rằng con số 100 triệu của Biden nằm trong phạm vi ước tính hợp lý (61 đến 135 triệu). Ngược lại, suy luận không dựa trên mô hình phần thưởng bị mắc kẹt trong tính mâu thuẫn của các ước tính mà không nhận ra rằng con số của Biden vẫn là hợp lệ trong bối cảnh đó. Suy luận dựa trên mô hình phần thưởng đạt nhãn đúng (ĐÚNG) một cách đáng tin cậy hơn bằng cách tổng hợp bằng chứng một cách toàn diện thay vì bị lạc vào chi tiết của các tuyên bố mâu thuẫn.

Nhập:

[Yêu cầu]: Kiềm hổi của cộng đồng người nước ngoài "hiện đang đạt mức cao kỷ lục vượt quá 400 tỷ KSh vào năm 2021". [Bằng chứng]: Khối tiền từ cộng đồng người ở nước ngoài rất mạnh mẽ trong năm 2021, với tổng số tiền khối-tiền năm 2021 đạt kỷ lục 3.718 triệu USD.

[Phán quyết]: Đúng

Suy luận LLM mà không có trình xác minh

[Lý do]: Các bằng chứng cung cấp thông tin mâu thuẫn về số tiền kiều hối chính xác trong năm 2021, và một số nguồn đề cập đến các con số không thể so sánh trực tiếp với 400 tỷ KSh.


[Dự đoán]: Mâu thuẫn

Suy luận LLM với bộ kiểm chứng

[Lý luận]: Bằng chứng cho thấy lời khẳng định rằng kiều hối của cộng đồng người hải ngoại đã đạt mức cao kỷ lục trên 400 tỷ KSh vào năm 2021 là đúng. Tuy nhiên, có một số khác biệt nhỏ về cách diễn đạt và đơn vị được sử dụng giữa các nguồn khác nhau.[Dự đoán]: Đúng

Hình 9: Ví dụ về lời nhắc của người dùng gửi cho LLM trọng tài để xác định sự lệch lạc trong suy luận giữa suy luận không có bộ xác minh và có bộ xác minh

24361







Figure 11: System prompt to generate sub-questions given a claim, adhering to the standards defined in the CLAIMDECOMP paper.



Hình 11: Lời nhắc hệ thống để tạo các câu hỏi phụ dựa trên một tuyên bố, tuân theo các tiêu chuẩn được định nghĩa trong bài báo CLAIMDECOMP.