

# Ngĩ Đúng, Không Nhiều Hơn: Điều Chỉnh Quy Mô Thời Gian Kiểm Tra cho Xác Thực Các Khẳng Định Số

Primakov  
Chungkham\*  
TU Delft  
primakovch@gmail.com

Venktesh V\*Đại học  
Stockholm  
venktesh.viswanatha@dsv.su.se

Vinay Setty  
Đại học Stavanger  
vsetty@acm.org

Avishek  
Anand TU Delft  
avishek.anand@tudelft.nl

## Tóm tắt

Kiểm tra tính xác thực của các tuyên bố trong thế giới thực, đặc biệt là các tuyên bố về số liệu, vốn dĩ phức tạp và đòi hỏi suy luận nhiều bước cũng như lý luận số học để xác minh các khía cạnh đa dạng của tuyên bố. Mặc dù các mô hình ngôn ngữ lớn (LLM), bao gồm cả các mô hình suy luận, đã đạt được những tiến bộ to lớn, chúng vẫn còn hạn chế trong việc kiểm tra tính xác thực của các tuyên bố trong thế giới thực đòi hỏi sự kết hợp giữa suy luận tổng hợp và lý luận số học. Chúng không thể hiểu được sự tinh tế của các khía cạnh số học, và cũng dễ bị vấn đề trôi suy luận, nơi mà mô hình không thể đưa thông tin vào bối cảnh dẫn đến việc hiểu sai và phải quay lại quá trình suy luận. Trong công trình này, chúng tôi hệ thống khám phá việc mở rộng tính toán tại thời điểm thử nghiệm (TTS) cho LLM trong nhiệm vụ kiểm tra tính xác thực của các tuyên bố số phức tạp, điều này bao gồm việc khai thác nhiều con đường suy luận từ một LLM. Chúng tôi huấn luyện một mô hình xác minh (VERIFIERFC) để điều hướng trong không gian các con đường suy luận có thể có và chọn ra một con đường có thể dẫn đến

### Giảm thiểu sai lệch lập luận cho FC số học

Yếu tố được nêu: Kiều hối từ cộng đồng người nước ngoài “hiện đứng ở mức cao kỷ lục hơn 400 tỷ KSh vào năm 2021”.

[Bằng chứng 1]: Kiều hối từ cộng đồng người di cư đạt mức cao nhất mọi thời đại với hơn 400 tỷ shilling Kenya mỗi năm tính đến năm 2021.

[Bằng chứng2]: Kiều hối từ cộng đồng người Việt ở nước ngoài tăng mạnh trong năm 2021, với tổng kiều hối trong năm 2021 đạt mức kỷ lục 3.718 triệu USD. của người dùng hàng ngày[Phán quyết]: Đúng

#### Lập luận LLM mà không có VERIFIERFC

có thông tin mâu thuẫn về số lượng kiều hối chính xác vào năm 2021, và một số nguồn đề cập đến các con số không thể so sánh trực tiếp với 400 tỷ KSh. Dự đoán: Mâu thuẫn

#### Lập luận LLM với VERIFIERFC

[Lý giải]: Các bằng chứng ủng hộ cho khẳng định rằng kiều hối của cộng đồng người nhập cư đã đạt mức cao kỷ lục trên 400 tỷ KSh vào năm 2021. Tuy nhiên, có một số khác biệt nhỏ về cách diễn đạt và đơn vị được sử dụng ở các nguồn khác nhau.

[Dự đoán]: Đúng

Hình 1: Ví dụ về tuyên bố số học minh họa vấn đề lệch lý luận và biện pháp giảm thiểu do VERIFIERFC cung cấp

## 1 Giới thiệu

Xác minh tự động các tuyên bố là rất quan trọng để giảm thiểu thông tin sai lệch và thông tin bịa đặt. Trong khi nhiều phương pháp tập trung vào các tuyên bố được tạo ra tổng hợp từ Wikipedia (Jiang et al., 2020; Thorne

etal., 2018; Aly et al., 2021), các công trình gần đây đã tập trung vào việc kiểm chứng các tuyên bố trong thế giới thực (Augenstein et al., 2019; Schlichtkrull et al., 2023; Chen et al., 2022; V et al., 2024).

Các tuyên bố trong thực tế chứa các yếu tố số liệu (về lượng và thời gian) (V et al., 2024; Alam et al., 2025) và việc xác minh những tuyên bố này đòi hỏi phải so sánh có hệ thống các khía cạnh số liệu trong tuyên bố với bằng chứng tương ứng được cung cấp. Xem xét ví dụ trong Hình 1, việc xác minh tuyên bố về kiều hối của người di cư đòi hỏi phải đảm bảo rằng số tiền được tuyên bố (KSh400 tỷ) và năm được chỉ định (2021) khớp chính xác với bằng chứng, ngay cả khi bằng chứng trình bày

Cả hai tác giả đều đóng góp như nhau vào công trình này

số tiền bằng một loại tiền tệ khác (USD). Không giống như các nhiệm vụ xác minh nhị phân, các tuyên bố trong thế giới thực thường chứa các thành phần mâu thuẫn hoặc chỉ đúng một phần, làm cho việc xác minh trở nên phức tạp hơn.

Các phương pháp kiểm tra sự thật tự động tiêu chuẩn sử dụng một quy trình đa giai đoạn liên quan đến các mô hình NLI được tinh chỉnh. Gần đây, các Mô Hình Ngôn Ngữ Lớn (LLMs) đã nổi lên như những lựa chọn thay thế đầy hứa hẹn cho các phương pháp dựa trên NLI trong việc xác minh các tuyên bố (Li và cộng sự, 2024). Tuy nhiên, các phương pháp này chủ yếu được đánh giá trên các tuyên bố tổng hợp, và các nghiên cứu gần đây nhấn mạnh những hạn chế đáng kể khi áp dụng vào các tuyên bố phức tạp trong thế giới thực có dữ liệu số (V và cộng sự, 2024; Setty, 2024; Schlichtkrull và cộng sự, 2023; Augenstein và cộng sự, 2024). Mặc dù các nghiên cứu trước đã thừa nhận những hạn chế này, nhưng chưa phân tích kỹ lý do tại sao LLMs thất bại trong các kịch bản thực tế.

Để giải quyết khoảng trống này, chúng tôi phân tích các chế độ thất bại trong cả các mô hình mã nguồn mở và mô hình sở hữu với các kích thước khác nhau. Ngoài nhiều trong quá trình truy xuất, chúng tôi xác định được một thách thức quan trọng về lý luận ngay cả khi có bằng chứng liên quan, được giới thiệu đặc biệt do nhiều khía cạnh hoặc không khả năng đặt thông tin đa dạng từ các nguồn bằng chứng vào ngữ cảnh, được gọi là sự lệch lý luận do vấn đề trong khả năng phân tích chính xác các tuyên bố và bằng chứng. Điều này khác cơ bản so với hiện tượng “suy nghĩ quá mức” được quan sát trong các bối cảnh Hỏi & Đáp đơn giản, nơi các mô hình giải thích không cần thiết các chi tiết rõ ràng (Sui et al., 2025). Mặc dù điều này có thể ảnh hưởng đến các tuyên bố đơn giản, nhưng sự lệch lý luận đặc biệt rõ rệt trong các trường hợp phức tạp với nhiều khía cạnh và bằng chứng đa dạng, dẫn đến lý luận thiếu tập trung và lệch khỏi nhiệm vụ xác minh cốt lõi. Phân tích của chúng tôi cho thấy khoảng 34% các tuyên bố trong bộ dữ liệu QuanTemp gặp vấn đề về lý luận này.

Trong bối cảnh kiểm chứng sự thật, sự lệch lạc trong lập luận xuất phát từ việc các mô hình ngôn ngữ lớn (LLMs) tập trung vào những khía cạnh không quan trọng của tuyên bố hoặc hiểu sai thông tin trong các bằng chứng khác nhau như một phần của quá trình lập luận của chúng. Ví dụ, trong ví dụ ở Hình 1, tuyên bố đề cập đến số tiền 400 tỷ Ksh (shilling Kenya). Trong khi một bằng chứng xác nhận con số này, bằng chứng khác được đưa ra trong ví dụ lại trích dẫn số tiền 3,718 tỷ USD. Mặc dù số tiền này tương đương với 400 tỷ Ksh, LLM lại hiểu số lượng này không tương đương với số được đề cập trong tuyên bố và thiếu hụt hàng tỷ, dự đoán phán quyết của nó là “Mâu thuẫn”. Theo hiểu biết của chúng tôi, công trình của chúng tôi là nghiên cứu đầu tiên khảo sát về prob-

suy luận lem xảy ra do phân tích quá mức và khám phá việc điều chỉnh quy mô trong thời gian thử nghiệm như một giải pháp cho vấn đề tương tự trong bối cảnh kiểm tra sự thật của các tuyên bố trong thế giới thực.

Một cách chính thức hơn, sự trôi dạt lý luận do phân tích quá mức có thể được định nghĩa là hiện tượng trong đó:

*“Mô hình ngôn ngữ lớn (LLM) lui lại khỏi quỹ đạo lập luận chính xác hiện tại của nó do hiểu sai thông tin đa dạng, điều này cũng có thể bắt nguồn từ tính chất nhiễu của các tuyên bố và khả năng không thể đặt thông tin vào bối cảnh.”*

Chúng tôi giới thiệu và nghiên cứu phương pháp scaling thời gian kiểm tra (TTS) (Zhang et al., 2025), một phương pháp phân bổ thêm tài nguyên tính toán vào thời điểm suy diễn, cho phép các mô hình ngôn ngữ lớn (LLM) khám phá nhiều con đường lý luận để giảm thiểu sự sai lệch trong lý luận. Theo hiểu biết của chúng tôi, đây là nghiên cứu đầu tiên xem xét scaling thời gian kiểm tra đặc biệt để xác minh các khẳng định thực tế phức tạp. Để hiệu quả trong việc điều hướng và lựa chọn từ các con đường lý luận đa dạng, chúng tôi huấn luyện một mô hình xác minh chuyên dụng (VERIFIERFC). Các thí nghiệm của chúng tôi chứng minh rằng việc sử dụng mô hình xác minh này với chiến lược best-of-N (BoN) vượt trội đáng kể so với các phương pháp bỏ phiếu đa số tiêu chuẩn (Wang et al., 2023).

Vì các tuyên bố trong thế giới thực rất đa dạng, việc áp dụng cùng một mức độ nỗ lực tính toán cố định cho tất cả các tuyên bố là không hiệu quả: các tuyên bố đơn giản có thể tiêu tốn tài nguyên không cần thiết, trong khi các tuyên bố phức tạp có thể không nhận đủ sự chú ý về mặt tính toán, dẫn đến việc xác minh không tối ưu. Để giải quyết vấn đề này, chúng tôi đề xuất một chiến lược TTS thích ứng mới, điều chỉnh linh hoạt các nguồn lực tính toán dựa trên độ phức tạp của tuyên bố, được xác định bằng cách phân tích các biểu diễn tiềm ẩn theo từng lớp trong các LLM. Phương pháp thích ứng này nâng cao hiệu suất xác minh lên 18,8% đối với các tuyên bố số học phức tạp (QuanTemp) và 21,27% đối với các tuyên bố thành phần (ClaimDecomp) so với các kỹ thuật một lần thực hiện, đồng thời cung cấp hiệu quả tính toán cao hơn 1,8 lần so với phương pháp TTS tiêu chuẩn.

Trong bài báo này, chúng tôi trả lời các câu hỏi nghiên cứu sau thông qua xác thực thực nghiệm:

RQ1: Mức độ mà các LLM gặp phải vấn đề trôi lý luận trong các nhiệm vụ kiểm tra sự thật số liệu phức tạp là như thế nào?

RQ2: Việc điều chỉnh tỷ lệ tại thời điểm kiểm tra ảnh hưởng như thế nào đến hiệu suất lập luận của các LLM trong việc kiểm chứng các tuyên bố số liệu phức tạp?

RQ3: So sánh việc điều chỉnh kích thước vào thời gian kiểm tra như thế nào

đối với các chiến lược hiện tại để kiểm tra tính xác thực của các tuyên bố phức tạp?

## 2 Công trình liên quan

### 2.1 Kiểm tra thực tế các khẳng định phức tạp trong thế giới thực

Kiểm tra sự thật tự động là chìa khóa để giảm thiểu sự gia tăng thông tin sai lệch và thông tin sai lệch (Thorne và cộng sự, 2018; Aly và cộng sự, 2021; Guo và cộng sự, 2022). Các công trình hiện có về kiểm tra sự thật tự động chủ yếu tập trung vào các tuyên bố tổng hợp thu thập từ Wikipedia (Thorne và cộng sự, 2018; Jiang và cộng sự, 2020; Aly và cộng sự, 2021; Nanekhan và cộng sự, 2025) không đại diện cho các tuyên bố thực tế. Đã có nhiều nỗ lực hơn để xây dựng các hệ thống cho các tuyên bố thực tế trong các lĩnh vực như chính trị (Chen và cộng sự, 2022; Wang, 2017; Alhindi và cộng sự, 2018; Ostrowski và cộng sự, 2021; Nakov và cộng sự, 2025), khoa học (Wadden và cộng sự, 2020; Vladika và Matthes, 2023; Wright và cộng sự, 2022), sức khỏe (Kotonya và Toni, 2020) và khí hậu (Diggelmann và cộng sự, 2021).

### 2.2 Trôi dạt lập luận do suy nghĩ quá mức trong LLMs

Người ta tin rằng các mô hình ngôn ngữ lớn (LLM) với số lượng tham số lớn thể hiện các khả năng mới nổi (Wei et al., 2022; Brown et al., 2020; OpenAI, 2023), bao gồm khả năng lập luận. Các nghiên cứu trước đây cho thấy, khi được cung cấp các ví dụ ít ỏi, LLM có thể tạo ra các giải thích từng bước (được gọi là chuỗi tư duy hoặc chuỗi lập luận), dẫn đến cải thiện hiệu suất trong các nhiệm vụ lập luận (Wei et al., 2023; Huang và Chang, 2023; Yao et al., 2023b; Huang và Chang, 2023). Tuy nhiên, có những điểm mù đã được biết đến khi sử dụng trong các thiết lập ít ví dụ và một ví dụ, đặc biệt là khi liên quan đến dữ liệu số hoặc dữ liệu theo thời gian (Wallat et al., 2024a,b).

Hơn nữa, các nghiên cứu gần đây cho thấy các mô hình ngôn ngữ lớn (LLMs) có xu hướng suy nghĩ quá mức khi thực hiện suy luận, một hiện tượng mà các mô hình tạo ra các chuỗi suy luận dài hoặc phức tạp không cần thiết, cuối cùng dẫn đến các kết luận sai (Sui et al., 2025; Chen et al., 2025). Suy nghĩ quá mức cũng được mô tả là xu hướng của LLMs ưu tiên suy luận nội bộ hơn phản hồi bên ngoài (Cuadron et al., 2025). Trong các nhiệm vụ đòi hỏi nhiều kiến thức như kiểm tra sự thật, chúng tôi quan sát thấy rằng LLMs thường quay lại hoặc phân tích quá mức chuỗi suy luận ban đầu của chúng. Điều này thường xuất phát từ sự phức tạp của các truy vấn liên quan đến nhiều khía cạnh, hoặc từ việc hiểu sai xung đột

nhập thông tin trong bằng chứng. Quan trọng là, khoảng trống lý luận này có thể xảy ra bất kể độ dài thực tế của chuỗi lý luận. Chúng tôi gọi vấn đề này là trôi lý luận. Trong khi các nghiên cứu trước đây đã khám phá việc ứng dụng LLMs để kiểm tra sự thật (Li và cộng sự, 2024), chưa có nghiên cứu nào giải quyết rõ ràng hiện tượng trôi lý luận. Những phát hiện của chúng tôi cho thấy trôi lý luận là một thách thức đáng kể trong việc xác minh các tuyên bố số liệu phức tạp.


### 2.3 Thời gian kiểm tra

Test-Time Scaling là một kỹ thuật nhằm cải thiện hiệu suất suy luận của các LLM bằng cách phân bổ thêm khả năng tính toán vào thời gian suy luận (Zhang et al., 2025; Venkatesh et al., 2025). Các phương pháp ban đầu chủ yếu tập trung vào việc tạo ra nhiều kết quả cho mỗi truy vấn song song và chọn ra câu trả lời thông qua bỏ phiếu đa số (Wang et al., 2023) hoặc các phương pháp dựa trên tìm kiếm (Yao et al., 2023a; Feng et al., 2024; Xie et al., 2023). Những phát triển gần đây có thể được chia thành hai hướng nghiên cứu chính: (i) điều chỉnh phân phối đề xuất của LLM bằng cách huấn luyện tinh chỉnh (DeepSeek-AI et al., 2025; OpenAI, 2024; Singh et al., 2024; Madaan et al., 2023; Zelikman et al., 2022; Jin et al., 2025), và (ii) huấn luyện một mô hình phần thưởng / kiểm chứng để chọn câu trả lời ưa thích từ nhiều ứng viên (Snell et al., 2024; Wang et al., 2024; Nichols et al., 2020; Cobbe et al., 2021; Uesato et al., 2022; Lightman et al., 2023). Phương pháp của chúng tôi tập trung vào hướng thứ hai, thường được gọi là tìm kiếm dựa vào kiểm chứng. Nó bao gồm sa

Các bộ xác minh được sử dụng để chọn giải pháp tốt nhất, được chia thành các mô hình thưởng Kết quả (ORM) (Cobbe et al., 2021) hoặc các Mô hình Thưởng Quá trình (PRM) (Uesato et al., 2022; Lightman et al., 2023). Chúng tôi áp dụng một bộ xác minh dựa trên PRM và trong khi phần lớn các phương pháp chỉ sử dụng huấn luyện theo mẫu từ chối trên các đường suy luận tích cực, chúng tôi cũng bao gồm các giải pháp sai để cung cấp khả năng phân biệt tốt hơn cho bộ xác minh. Các công trình hiện có cũng áp dụng TTS đồng đều cho tất cả các mẫu thử, trong khi một số yêu cầu có thể không cần TTS, gây lãng phí tài nguyên tính toán. Chúng tôi là những người đầu tiên khám phá việc áp dụng TTS một cách thích ứng dựa trên mức độ phức tạp của yêu cầu, lấy cảm hứng từ RAG thích ứng (Jeong et al., 2024).

## 3 Phương pháp luận

Trong phần này, chúng tôi trình bày một chiến lược điều chỉnh thời gian kiểm tra (TTS) nhằm giảm thiểu hiện tượng trôi suy luận, một rea-



Hình 2: Tr Đào tạo và suy luận của quy trình phân công độ phức tạp sử dụng phương pháp dựa trên biểu diễn tiềm ẩn cho các tuyên bố luận

sự thất bại trong lập luận, trong đó mô hình không ưu tiên các thông tin liên quan hoặc hiểu sai các khía cạnh của tuyên bố trong quá trình suy luận. Phương pháp của chúng tôi bao gồm việc đào tạo một bộ xác minh quy trình (Mục 3.1) để chọn các chuỗi lập luận chính xác hơn từ nhiều ứng viên. Để giảm thiểu việc tính toán không cần thiết trên các tuyên bố đơn giản, chúng tôi khám phá một cơ chế TTS thích ứng dự đoán độ phức tạp của tuyên bố sử dụng các biểu diễn tiềm ẩn theo lớp từ LLM cơ bản (Mục 3.2). Chúng tôi áp dụng một quy trình kiểm chứng sự thật tiêu chuẩn bao gồm tìm kiếm BM25 + và xếp hạng lại để trích xuất bằng chứng cho tuyên bố và sử dụng LLM cho việc xác minh tuyên bố t hay vì các mô hình NLI tiêu chuẩn.

### 3.1 Bộ xác minh cho việc chọn đường dẫn tốt nhất trong TTS

Tăng quy mô thời gian kiểm tra bằng cách sử dụng chiến lược best-of- $N$ , trong bối cảnh kiểm tra sự thật, bao gồm việc tạo ra nhiều lộ trình lý luận ứng viên để xác minh một tuyên bố  $c$ , sau đó chọn phán quyết tốt nhất bằng cách sử dụng một bộ xác minh  $\mathcal{V}$ . Chúng tôi đề xuất đào tạo một mô hình xác minh dựa trên quy trình, đánh giá các lộ trình lý luận thay vì chỉ các phán quyết cuối cùng cho một tuyên bố nhất định, cho phép chọn lộ trình thấu đáo nhất để xác minh.

Một cách chính thức hơn, cho một tập hợp dữ liệu đào tạo  $D$  gồm các tuyên bố ( $c_i$ ) và các phán quyết của chuyên gia kiểm tra sự thật tương ứng ( $y_i$ ), nơi  $D = \{(c_1, y_1), \dots, (c_n, y_n)\}$ , trước tiên chúng ta lấy mẫu  $m$  con đường lập luận khác nhau  $\{(e_{11}, \dots, e_{1m}), \dots, (e_{n1}, \dots, e_{nm})\}$  từ một mô hình ngôn ngữ lớn đã được huấn luyện trước  $\mathcal{F}_{LLM}$  cho mỗi tuyên bố trong giai đoạn xác minh tuyên bố, cùng với các phán quyết dự đoán tương ứng của chúng  $\{(\hat{y}_{11}, \dots, \hat{y}_{1m}), \dots, (\hat{y}_{n1}, \dots, \hat{y}_{nm})\}$ . Sau đó, chúng tôi tạo dữ liệu đào tạo cho bộ xác minh bằng cách gán nhãn mỗi cặp  $(c_i, e_{ij}, \hat{y}_{ij})$  là 1 (mẫu dương) nếu

phán quyết dự đoán khớp với kết quả thực tế ( $\hat{y}_{ij} == y_i$ ), và 0 nếu không (mẫu âm).

Chúng tôi sử dụng bộ dữ liệu được xây dựng gồm các đường dẫn lý luận tích cực và tiêu cực này để huấn luyện mô hình kiểm chứng  $\mathcal{V}(sc_i | (c_i, e_{ij}, \hat{y}_{ij}))$ , lấy làm đầu vào là tuyên bố gốc  $c_i$ , một đường suy luận  $e_{ij}$ , và phán quyết dự đoán tương ứng  $\hat{y}_{ij}$ , và xuất ra điểm dựa trên tính hợp lý của đường dẫn đến phán quyết đúng. Mô hình được tinh chỉnh để gán điểm cao hơn cho các đường dẫn lý luận phù hợp hơn bằng cách giảm thiểu mất mát entropy chéo nhị phân:

$$\mathcal{L}_{\mathcal{V}} = - [y_i \cdot \log \mathcal{V}(sc_i | (c_i, e_{ij}, \hat{y}_{ij})) + (1 - y_i) \cdot \log(1 - \mathcal{V}(sc_i | (c_i, e_{ij}, \hat{y}_{ij})))]$$

Các phương pháp xác minh quy trình hiện có để huấn luyện bộ xác thực chủ yếu tập trung vào việc lấy mẫu từ chối khi tạo dữ liệu huấn luyện, nơi chỉ xem xét các mẫu tích cực. Tuy nhiên, việc giám sát từ dữ liệu huấn luyện được tạo ra ở trên giúp bộ xác thực cân nhắc những sắc thái trong quá trình xác minh tuyên bố bằng cách học khả năng phân biệt tốt hơn giữa các đường đi hợp lý và không chính xác.

Trong quá trình suy luận cho một yêu cầu kiểm tra  $c_i$  chúng tôi tạo ra  $m$  các đường đi lý luận như vậy  $\{(e_{11}, \hat{y}_{11}), \dots, (e_{1m}, \hat{y}_{1m})\}$  và sử dụng bộ xác minh để chấm điểm các đường đi lý luận này bằng cách trích xuất điểm logits từ đầu ra của bộ xác minh  $\hat{\mathcal{V}}(sc_i | (c_i, e_{ij}, \hat{y}_{ij}))$ . Đường đi có điểm cao nhất được đưa ra như kết quả của quá trình xác minh yêu cầu. Tuy nhiên, chiến lược tốt nhất trong số  $N$  (BoN) này áp dụng TTS cho tất cả các yêu cầu một cách đồng đều mà không tính đến trường hợp TTS có thể không hữu ích. Điều này không tối ưu về mặt tính toán và chúng tôi đề xuất một chiến lược BoN thích ứng để khắc phục vấn đề này.

### 3.2 Điều chỉnh Thời gian Kiểm tra Thích ứng (TTS)

Chúng tôi áp dụng một phương pháp bán giám sát để ước lượng mức độ phức tạp của một tuyên bố bằng cách tận dụng việc phân tách các câu hỏi phụ và phân cụm trong không gian đại diện tiềm ẩn của mô hình ngôn ngữ. Phương pháp của chúng tôi được lấy cảm hứng từ các nghiên cứu gần đây về Adaptive RAG (Jeong et al., 2024; Mallen et al., 2023), vốn sử dụng các ghi chú về độ phức tạp của truy vấn để hướng dẫn việc kiểm soát trong thời gian suy luận trong quá trình tạo được tăng cường truy xuất. Trong trường hợp của chúng tôi, chúng tôi xác định độ phức tạp dựa trên việc liệu tuyên bố có cần phân tách để xác minh đúng đắn tính xác thực của nó hay không. Tín hiệu phân tách này đóng vai trò như một thước đo cho độ khó về lý luận, mà chúng tôi sử dụng để xác định liệu một tuyên bố có nên kích hoạt TTS hay không.

Chúng tôi xây dựng dữ liệu huấn luyện cho TTS thích ứng bằng cách chú thích các tuyên bố với các câu hỏi phụ và theo dõi số lượng cần thiết để xác minh chính xác tính xác thực của tuyên bố. Các tuyên bố sau đó được phân loại thành hai mức độ phức tạp: mức 0 bao gồm các tuyên bố có thể được xác minh chính xác mà không cần bất kỳ sự phân rã nào; mức 1 bao gồm các tuyên bố yêu cầu một hoặc nhiều câu hỏi phụ và được xác minh chính xác sau khi phân rã; và các tuyên bố vẫn bị phân loại sai ngay cả sau khi phân rã cũng được gán vào mức 1, phản ánh sự mơ hồ chưa được giải quyết hoặc sự không chắc chắn của mô hình.

Thuật toán quyết định phân rã thích ứng của chúng tôi lấy cảm hứng từ CTRLA (Liu và cộng sự, 2024), cho rằng các biểu diễn tiềm ẩn của LLM mã hóa các thuộc tính mang ý nghĩa ngữ nghĩa. Như minh họa trong Hình 2, chúng tôi trích xuất các biểu diễn tiềm ẩn và gán nhãn độ phức tạp tương ứng.

Chúng tôi chú thích một tập huấn luyện các tuyên bố  $D_k = \{c_1, c_2, \dots, c_n\}$  với mức độ phức tạp  $k$ . Mỗi tuyên bố được đưa qua một LLM đã được huấn luyện trước  $\mathcal{F}_{LLM}$ , với  $L$  lớp và kích thước tiềm ẩn  $h$ , để trích xuất các biểu diễn tiềm ẩn ở cấp token, theo các nghiên cứu trước về các thuộc tính ngữ nghĩa của các biểu diễn tiềm ẩn (Sun et al., 2025; Chuang et al., 2024). Đối với một tuyên bố đầu vào  $c_i$  với  $t$  token, biểu diễn tiềm ẩn  $\mathbf{r}^l$  của nó cho lớp  $l$  được định nghĩa như sau:

$$\begin{aligned} \mathbf{r}^l &= \mathcal{F}_{LLM}^l(c_i) \\ &= [\mathbf{r}_{i,1}^{(l)}, \mathbf{r}_{i,2}^{(l)}, \dots, \mathbf{r}_{i,t}^{(l)}] \in \mathbb{R}^{t \times h} \end{aligned}$$

Nói chung hơn, tập hợp các biểu diễn token trên tất cả các lớp có thể được biểu diễn như sau:

$$\mathcal{F}_{LLM}(c_i) = \left\{ \mathbf{r}_{i,j}^l \in \mathbb{R}^h \mid 1 \leq j \leq t, 1 \leq l \leq L \right\},$$

nơi  $\mathbf{r}_{i,j}^l$  là biểu diễn ẩn của token  $j^{\text{th}}$  tại lớp  $l$ . Sau đó, chúng tôi tóm tắt biểu diễn này sử dụng token cuối cùng làm đại diện cho toàn bộ

khẳng định (theo (Vaswani et al., 2023)). Về mặt hình thức, biểu diễn gộp ở lớp  $l$  được định nghĩa như sau:

$$\mathbf{z}_i^l = \mathcal{P}(\{\mathbf{r}_{i,j}^l\}_{j=1}^t) = \mathbf{r}_{i,t}^l \quad \text{for } 1 \leq l \leq L,$$

trong đó  $\mathcal{P}$  biểu thị hàm gộp trên chiều token. Nói chung, điều này có thể được biểu diễn như sau:

$$\mathcal{Z}_i = \left\{ \mathbf{z}_i^l \in \mathbb{R}^h \mid 1 \leq l \leq L \right\}.$$

Sau đó chúng tôi áp dụng Phân tích Thành phần Chính (PCA) cho  $\{\mathbf{z}_i^l\}_{i=1}^n$  cho mỗi lớp  $l$ , và trích xuất thành phần chính đầu tiên:

$$\mathbf{u}_k^l = \text{PCA}_1 \left( \left\{ \mathbf{z}_i^l \right\}_{i=1}^n \right),$$

tạo ra các biểu diễn mức độ phức tạp:

$$\mathcal{U}_k = \left\{ \mathbf{u}_k^l \right\}_{l=1}^L,$$

Đối với một yêu cầu kiểm tra  $c$ , chúng tôi trích xuất các biểu diễn theo từng lớp của nó:

$$\mathcal{C} = \left\{ \mathbf{c}^l \in \mathbb{R}^h \mid 1 \leq l \leq L \right\}.$$

Độ tương đồng cosine được tính với từng nguyên mẫu lớp ở mỗi tầng:

$$\begin{aligned} \mathcal{S} &= \left\{ \mathbf{s}^l \in \mathbb{R}^{|K|} \mid \mathbf{s}_k^l = \cos(\mathbf{c}^l, \mathbf{u}_k^l), \right. \\ &\quad \left. 1 \leq k \leq |K|, 1 \leq l \leq L \right\} \end{aligned}$$

trong đó  $\mathbf{s}_k^l$  là độ tương đồng với lớp  $k$  tại tầng  $l$ . Chúng tôi gán:

$$\hat{k}^l = \arg \max_k \mathbf{s}_k^l$$

và lớp độ phức tạp dự đoán cuối cùng được xác định thông qua bỏ phiếu đa số trên  $\{\hat{k}^l\}_{l=1}^L$ . Cách tiếp cận này tương tự như phân loại nguyên mẫu trong tài liệu ML (Snell et al., 2017; Sourati et al., 2024) hoặc bộ phân loại gần tâm / Rocchio (Rocchio, 1971). Cách tiếp cận chủ yếu tính toán trước và lập chỉ mục các biểu diễn tiềm ẩn cho các lớp độ phức tạp. Sau đó, khi suy luận, chúng tôi trích xuất các biểu diễn tiềm ẩn cho yêu cầu kiểm thử và gán lớp độ phức tạp dựa trên biểu diễn gần nhất đo bằng độ tương đồng cosine, tương tự như bộ phân loại Rocchio trong tài liệu IR. Dựa trên độ phức tạp suy luận được, chúng tôi áp dụng điều chỉnh quy mô tại thời điểm kiểm thử thích ứng: suy luận một lần cho các yêu cầu cấp-0, và lập luận mở rộng cho các yêu cầu cấp-1 (độ phức tạp trung bình hoặc cao). Điều này tạo ra một chiến lược TTS tiết kiệm tính toán cho việc kiểm chứng sự thật phức tạp, như được thể hiện trong Mục 5.

## 4 Thiết lập Thí nghiệm

Bộ dữ liệu. Chúng tôi đánh giá các phương pháp của mình trên QuanTemp (V et al., 2024), đây là bộ chuẩn đầu tiên cho các khẳng định số phức tạp. Nó bao gồm 9935 khẳng định huấn luyện, 3084 khẳng định xác thực và 2495 khẳng định kiểm tra. Chúng tôi sử dụng bộ huấn luyện của họ để huấn luyện mô hình kiểm chứng và tạo các biểu diễn cho các lớp phức tạp, được sử dụng cho TTS thích ứng.

ClaimDecomp (Chen và cộng sự, 2022) là một bộ dữ liệu chuẩn khác tập trung vào các tuyên bố thực tế có tính cấu thành. Chúng tôi sử dụng tập đánh giá của nó (200 tuyên bố) để thử khả năng tổng quát hóa của bộ xác thực của chúng tôi (được huấn luyện trên QuanTemp) đối với các loại tuyên bố phức tạp khác.

Quy trình kiểm chứng sự thật: Chúng tôi sử dụng một quy trình kiểm chứng sự thật tiêu chuẩn theo phương pháp được áp dụng trong (V et al., 2024), bao gồm việc truy xuất ban đầu 100 kết quả hàng đầu cho mỗi tuyên bố bằng cách sử dụng BM25 (Elasticsearch). Sau đó, chúng tôi xếp lại thứ hạng bằng paraphrase-MiniLM-L6-v2 (Reimers và Gurevych, 2019) để chọn 3 đoạn bằng chứng hàng đầu cho mỗi tuyên bố.

Chỉ số: Chúng tôi sử dụng điểm F1 theo lớp, điểm F1 trung bình và điểm F1 có trọng số làm chỉ số đánh giá.

Các Mô hình Ngôn ngữ Lớn (LLMs) được sử dụng cho xác minh tuyên bố: Chúng tôi sử dụng Llama 3.1 (8B) và gpt-4o-mini làm LLMs cho giai đoạn xác minh tuyên bố và Deepseek-r1, vốn thực hiện TTS nội bộ, làm baseline. Chúng tôi áp dụng nhiệt độ 0,45 để tạo ra các đường suy luận đa dạng trong thiết lập TTS. Chúng tôi sử dụng kỹ thuật Few-shot Chain of Thought (COT) prompting (trong Hình 10) để khai thác suy luận cho tất cả các baseline và phương pháp của chúng tôi. Chúng tôi thử nghiệm với số lượng đường suy luận khác nhau ( $m=1, 3, 5, 10$ ) như được trình bày chi tiết trong Mục 5.

Mô hình Verifier cho TTS: Mô hình Verifier được sử dụng cho Best-of-N trong cài đặt TTS dựa trên mô hình Llama-3.2-3B. Nó được tinh chỉnh cho việc phân loại sử dụng các bộ điều hợp LoRA (Hu et al., 2021) với bậc 8 và hệ số tỉ lệ ( $\alpha$ ) là 16. Mô hình được tinh chỉnh trong 3 epoch với kích thước batch là 32, sử dụng bộ tối ưu AdamW với  $\epsilon = 1 \times 10^{-8}$  và tốc độ học ban đầu là  $1 \times 10^{-3}$ .

Các lời nhắc: Tất cả các lời nhắc để xác minh tuyên bố, phân tích và ghi chú dựa trên LLM có thể được tìm thấy trong Phụ lục C.

## 5 Kết quả Thử nghiệm

### 5.1 Sai lệch Lập luận của LLM - Phân tích Thủ công

Để trả lời RQ1, chúng tôi tiến hành một nghiên cứu có hệ thống về sự trôi dạt lý luận trong việc xác minh các tuyên bố số học sử dụng QuanTemp. Từ một mẫu phân tầng gồm 100

Các khẳng định, chúng tôi sử dụng một prompt hệ thống (Hình 8) và một prompt vài ví dụ với các ví dụ được chú thích (Hình 9, Phụ lục C) để hướng dẫn một LLM đánh giá (gpt-4o-mini) gán nhãn cho mỗi đường đi suy luận là có sự lệch suy luận (1) hay không (0).

Hai người chú giải con người (tình nguyện viên cao học) sau đó độc lập xác minh liệu nhãn của LLM có đúng hay không, theo hướng dẫn trong Phụ lục A. Chúng tôi báo cáo chỉ số Cohen’s Kappa là 74,13, cho thấy sự đồng thuận đáng kể và đánh giá của LLM chính xác 69%. Dựa trên quy trình này, sau khi sửa kết quả đánh giá của LLM, chúng tôi nhận thấy rằng khoảng 34% các tuyên bố mẫu có biểu hiện lệch lý luận, gợi ý rằng đây là một chế độ lỗi phổ biến và không hề tầm thường. Ví dụ được trình bày trong Hình 1, Bảng 3 và Hình 6, 7 (Phụ lục B).

### 5.2 Hiệu quả của việc thay đổi tỉ lệ thời gian kiểm tra đối với Xác minh Yêu cầu

Để giải quyết RQ2, chúng tôi đánh giá TTS như một chiến lược giảm thiểu (Mục 3) với kết quả được trình bày trong Bảng 1. Trước tiên, chúng tôi thiết lập một giới hạn lý thuyết tối đa, nơi một người xác minh hoàn hảo sẽ chọn đúng lộ trình lý luận và phán quyết bất cứ khi nào có.

Như được thể hiện trong Bảng 1, giới hạn trên có thể đạt được thông qua TTS — trên các LLM khác nhau — vượt qua hiệu suất oracle của các mô hình NLI tinh chỉnh được báo cáo trong V et al. (2024). Hàng Oracle fine-tuned phản ánh các mô hình NLI hiện đại nhất (ví dụ, RoBERTa-large) được huấn luyện trên các lý do do con người viết và cung cấp chúng khi suy luận. Ngược lại, giới hạn trên của TTS hoàn toàn dựa trên quá trình lập luận do LLM tạo ra, không có bất kỳ lý do nào do con người viết. Điều này nhấn mạnh khả năng của LLM trong việc khơi gợi các quá trình lập luận phù hợp cho việc kiểm tra sự thật phức tạp khi được hướng dẫn bởi TTS.

Tính nhất quán tự thân (Wang và cs., 2023), tổng hợp nhiều đường đi suy luận thông qua bình chọn đa số, chỉ thực hiện tốt hơn một chút so với—hoặc đôi khi còn kém hơn—giải mã top-1. Điều này là vì phương pháp này giả định rằng phán quyết xuất hiện nhiều nhất là đúng, bỏ qua những lý luận tinh vi thường cần thiết trong việc kiểm chứng sự thật, đặc biệt đối với các tuyên bố mẫu thuẫn có bằng chứng đa dạng.


Như được thể hiện trong Bảng 1, bộ xác minh đã được huấn luyện của chúng tôi trong cả hai thiết lập BoN và Adaptive BoN đã chọn hiệu quả con đường suy luận tốt nhất bằng cách tận dụng các tín hiệu cụ thể của nhiệm vụ. Adaptive BoN, sử dụng TTS dựa trên độ phức tạp dự đoán của tuyên bố, cải thiện so với giải mã top-1 lên 18,8% và tự nhất quán lên 16,69% (Macro-F1 trên QuanTemp). Adaptive BoN

| Phương pháp                                     | QuanTemp     |       |              |              |              | Phân tách yêu cầu |       |              |              |              |
|-------------------------------------------------|--------------|-------|--------------|--------------|--------------|-------------------|-------|--------------|--------------|--------------|
|                                                 | T-F1         | F-F1  | C-F1         | M-F1         | W-F1         | T-F1              | F-F1  | C-F1         | M-F1         | W-F1         |
| <b>Các đường cơ sở khác</b>                     |              |       |              |              |              |                   |       |              |              |              |
| DeepSeek-R1 (7B) (DeepSeek-AI và cộng sự, 2025) | 39.40        | 58.80 | 28.80        | 42.3         | 47.9         | 36.89             | 52.56 | 25.29        | 38.25        | 41.21        |
| <b>Llama-3.1 8B</b>                             |              |       |              |              |              |                   |       |              |              |              |
| Giải mã Hàng đầu 1 (Wei và cộng sự, 2023)       | 33.5         | 66.4  | 34.7         | 44.8         | 52.5         | 19.75             | 44.03 | 44.44        | 36.07        | 37.15        |
| Tự Nhất Quán (Wang và cộng sự, 2023)            | 34.9         | 68.6  | 35.1         | 46.2         | 54.2         | 16.22             | 44.00 | 44.30        | 34.84        | 36.39        |
| Tốt nhất của N                                  | 44.20        | 75.30 | 40.30        | 53.20        | <b>61.0</b>  | 22.22             | 48.00 | 46.91        | 39.05        | 40.22        |
| BoN Thích ứng (VERIFIERFC)                      | 44.27        | 73.52 | <b>43.93</b> | <b>53.91</b> | 60.84        | 21.43             | 56.21 | <b>49.70</b> | <b>42.44</b> | <b>44.13</b> |
| Giới hạn trên                                   | 63.9         | 85.1  | 69.60        | 72.9         | 77.4         | 63.92             | 82.21 | 83.10        | 76.41        | 77.21        |
| <b>Gpt-4o-mini</b>                              |              |       |              |              |              |                   |       |              |              |              |
| Giải mã Top 1 (Wei và cộng sự, 2023)            | 40.68        | 63.14 | 37.99        | 47.27        | 52.84        | 42.11             | 48.92 | 39.06        | 43.36        | 44.46        |
| Tự Nhất Quán (Wang và cộng sự, 2023)            | 29.70        | 63.20 | 42.33        | 45.07        | 51.83        | 47.41             | 50.00 | 34.19        | 43.87        | 45.35        |
| Tốt nhất của N                                  | 26.30        | 74.82 | 46.51        | 49.21        | 58.81        | 45.45             | 59.60 | 39.32        | 48.12        | 50.39        |
| BoN Thích ứng (VERIFIERFC)                      | <b>36.16</b> | 72.61 | 44.22        | <b>51.00</b> | <b>58.88</b> | 49.18             | 57.93 | <b>46.62</b> | <b>51.24</b> | <b>52.53</b> |
| Giới hạn trên                                   | 45.34        | 85.37 | 67.19        | 65.97        | 73.41        | 58.21             | 66.67 | 61.68        | 62.19        | 62.91        |
| <b>Oracle (tính chính) (V và cộng sự, 2024)</b> | 56.86        | 82.92 | 48.79        | 62.85        | 69.79        | 66.67             | 66.67 | 45.76        | 59.69        | 60.50        |

Bảng 1: Hiệu suất xác minh thông tin của các mô hình. Mô hình thường được tinh chỉnh từ llama-3.2-3b và số đường suy luận được xem xét, m=10. Phương pháp tính lợi ích được tính so với chuẩn giải mã hàng đầu 1.

| Sự phân hủy           | T-F1         | F-F1         | C-F1         | M-F1         | W-F1         |
|-----------------------|--------------|--------------|--------------|--------------|--------------|
| <b>Bổ phiếu đa số</b> |              |              |              |              |              |
| không phân hủy        | 34.89        | 68.63        | 35.09        | 46.20        | 54.18        |
| với decomp            | 37.48        | 69.33        | 32.27        | 46.36        | 53.51        |
| <b>BoN</b>            |              |              |              |              |              |
| không có phân hủy     | <b>44.16</b> | 75.27        | <b>40.27</b> | <b>53.23</b> | <b>60.97</b> |
| với decomp            | 43.77        | <b>76.32</b> | 35.21        | 51.77        | 60.29        |

Bảng 2: Phân tích ảnh hưởng của việc phân tách yêu cầu trong thiết lập tỉ lệ thời gian kiểm tra đối với xác minh yêu cầu phức tạp (sử dụng Llama-3.1 8B làm mô hình cơ sở).



Hình 3: (Bên trái) So sánh thời gian chạy trung bình trên mỗi truy vấn (tính bằng mili giây) và (Bên phải) So sánh tổng thời gian chạy: Adaptive BoN (VERIFIERFC) so với BoN (Best of N).

cũng vượt trội hơn DeepSeek-R1 27,44%, nhấn mạnh tầm quan trọng của một bộ kiểm chứng được huấn luyện cho TTS trong kiểm tra thực tế phức tạp.

Chúng tôi quan sát thấy cải thiện tương tự trên tập đánh giá Claimde-comp, nơi Adaptive BoN (VERIFIERFC) vượt trội so với giải mã Top-1 một cách đáng kể, cho thấy rằng trình xác thực của chúng tôi cũng có thể tổng quát hóa sang các loại yêu cầu phức tạp khác ngoài các yêu cầu số. Chúng tôi nhận thấy rằng điều này chủ yếu là do

Trình xác minh được sử dụng trong các phiên bản BoN và adaptive được huấn luyện trên dữ liệu xem xét các đường dẫn lý luận tích cực và tiêu cực / các đường dẫn quá trình từ LLM để xác minh tuyên bố. Điều này khác với các Mô hình Thường Quá trình hoặc Kết quả thông thường, vốn sử dụng lấy mẫu từ chối và chỉ xem xét các mẫu tích cực. Điều này mang lại khả năng phân biệt cao hơn cho trình xác minh, có thể phân biệt được đường dẫn lý luận đúng giữa nhiều đường dẫn khác nhau ngay cả khi tần suất của chúng thấp. Ví dụ, trong ví dụ thứ hai ở Bảng 3, LLM không thể lý luận rằng bản tuyên ngôn của đảng tương tự cũng đã được áp dụng trước đó vào năm 1928 và sau đó được mở rộng vào năm 1956, và do đó tuyên bố là chính xác. Thay vào đó, mô hình phân tích quá sâu, lùi lại khỏi lý luận đúng và đưa ra phán quyết là “Mâu thuẫn” do việc nhắc đến năm 1928 trong một bằng chứng không phù hợp với năm 1956 được đề cập trong tuyên bố. Chúng tôi nhận thấy rằng Self consistency cũng chọn “Mâu thuẫn” làm phán quyết vì 9/10 đường dẫn lý luận dẫn đến phán quyết này. Thay vào đó B

Chúng tôi cũng nhận thấy rằng BoN và BoN thích ứng với bộ kiểm chứng quá trình đã được huấn luyện của chúng tôi giúp giảm thiểu vấn đề sai lệch lập luận như thấy rõ từ các ví dụ trong Bảng 3. Chẳng hạn, trong ví dụ đầu tiên, một bằng chứng hoàn toàn hỗ trợ giá trị chuyển tiền là 400 KSh và bằng chứng thứ hai trích dẫn giá trị tương đương bằng đô la Mỹ. Trong giải mã top-1, sai lệch lập luận khiến LLM phân loại tuyên bố là 'Mâu thuẫn' do các con số khác nhau (bỏ qua các đơn vị tiền tệ) mà

| Phương pháp                | Bảng chứng                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                           |
|----------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Yêu cầu                    | <b>Kiểu hối từ cộng đồng người di cư "hiện đang ở mức cao kỷ lục trên 400 tỷ KSh vào năm 2021".</b><br>[Bảng chứng 1]: kiểu hối đã tăng gấp mười lần trong thập kỷ qua; và hiện nay chúng đang ở mức đạt mức cao nhất mọi thời đại với hơn 400 tỷ Ksh mỗi năm tính đến năm 2021.<br>[Bảng chứng 2]: kiểu hối từ cộng đồng người Việt ở nước ngoài đã tăng mạnh vào năm 2021, với tổng kiểu hối trong năm 2021 đạt mức kỷ lục 3.718 triệu USD. của người dùng hàng ngày.                                                                                                                                                              |
| Giải mã Top-1              | [Lý luận]: Bảng chứng cung cấp thông tin mâu thuẫn về số lượng chính xác của cộng đồng người Việt di cư kiểu hối vào năm 2021, và một số nguồn đề cập đến các con số không thể so sánh trực tiếp với 400 KSh tỷ.<br>[Phán quyết]: Mâu thuẫn                                                                                                                                                                                                                                                                                                                                                                                          |
| Tự nhất quán               | [Phán quyết cuối cùng]: Mâu thuẫn                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                    |
| VERIFIERFC (của chúng tôi) | [Lập luận]: Bảng chứng cho thấy kiểu hối từ cộng đồng người Việt ở nước ngoài đã đạt mức cao kỷ lục của hơn 400 tỷ KSh vào năm 2021. Tuy nhiên, có những biến thể nhỏ trong cách diễn đạt và đơn vị được sử dụng trên các nguồn khác nhau.<br>[Phán quyết cuối cùng]: Đúng                                                                                                                                                                                                                                                                                                                                                           |
| Yêu cầu                    | <b>Chương trình nghị sự của Đảng Cộng hòa năm 1956 ủng hộ quyền được trả lương bình đẳng, mức lương tối thiểu, nơi trú ẩn cho người tị nạn, bảo vệ cho công đoàn và nhiều hơn nữa.</b><br>[Bảng chứng 1]: Năm 1928, cương lĩnh của Đảng Cộng hòa viết: đảng ủng hộ tự do về tiền lương, chúng tôi ủng hộ một sự công bằng mức lương tối thiểu cho người lao động Mỹ một mức lương công bằng<br>[Bảng chứng 2]: nền tảng đảng Cộng hòa năm 1956 cam kết cung cấp viện trợ; bảo vệ an sinh xã hội; cung cấp nơi tị nạn cho người tị nạn; tăng mức lương tối thiểu; củng cố luật lao động để hỗ trợ công đoàn; đảm bảo bình đẳng pay... |
| Giải mã Top-1              | [Lý luận]: Các bằng chứng được cung cấp hỗ trợ nhiều tuyên bố được đưa ra trong phát biểu gốc, nhưng một số trích dẫn là từ những năm trước hoặc đề cập đến các chính sách cụ thể, và không phải tất cả các điểm đều được nêu rõ ràng trong nền tảng năm 1956.<br>[Phán quyết cuối cùng]: Mâu thuẫn                                                                                                                                                                                                                                                                                                                                  |
| Tự nhất quán               | [Phán quyết cuối cùng]: Mâu thuẫn<br>[Lập luận]: Lập luận này được hỗ trợ bởi các trích dẫn từ nền tảng của Đảng Cộng hòa năm 1956, đề cập đến sự bình đẳng tiền lương, mức lương tối thiểu, tị nạn cho người tị nạn, các biện pháp bảo vệ cho các công đoàn,. Mặc dù có những điểm khác biệt nhỏ, nó là hỗ trợ [...]                                                                                                                                                                                                                                                                                                                |
| VERIFIERFC (của chúng tôi) | [Phán quyết cuối cùng]: Đúng                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                         |

Bảng 3: Phân tích định tính quá trình lý luận theo Tính nhất quán bản thân và VERIFIERFC

được giải quyết khi suy luận bằng chiến lược BoN (VERIFIERFC).

5.3 Hiệu quả của Điều Chỉnh Thời Gian Kiểm Tra Thích Ứng

Chúng tôi đánh giá hiệu quả của chiến lược TTS dựa trên Adaptive BoN bằng cách đo tổng thời gian chạy trên tập đánh giá Quan-Temp và cũng ghi lại thời gian xử lý trung bình cho mỗi tuyên bố. Kết quả hiệu quả được hiển thị trong các biểu đồ ở Hình 3 và hiệu suất xác minh tuyên bố trong Bảng 1. Chúng tôi quan sát thấy rằng Adaptive BoN tốn ít thời gian hơn (1.8×) vì nó điều chỉnh tính toán suy luận dựa trên độ phức tạp của các tuyên bố. Chúng tôi cũng quan sát từ các biểu đồ rằng việc điều chỉnh tính toán khi kiểm thử cũng giảm đáng kể tổng thời gian chạy, đồng thời đạt được lợi nhuận so với chiến lược BoN dựa trên TTS đơn giản, dẫn đến việc sử dụng tài nguyên tính toán một cách hợp lý mà không làm giảm hiệu suất. Chúng tôi quan sát thấy trên QuanTemp hầu hết các tuyên bố có mức độ phức tạp 0 thuộc về loại thống kê, vốn dễ xác minh như đã lưu ý bởi các tác giả trong (V et al., 2024). Chúng tôi cũng tự thực hiện độc lập

đánh giá sự nhất quán về độ phức tạp dựa trên sự đồng thuận của nó với khái niệm về độ phức tạp của con người bằng cách yêu cầu hai người chú thích đánh dấu mức độ phức tạp cho 100 tuyên bố được lấy mẫu theo cách phân tầng. Chúng tôi quan sát thấy hệ số Cohen's kappa là 72,89 giữa các người chú thích (Hướng dẫn trong Phụ lục A.2). Việc đánh giá bộ phân loại với các chú thích làm sự thật nền tảng, cho kết quả độ chính xác có trọng số là 71%.

| Phương pháp         | QuanTemp     |              | Phân tách yêu cầu |              |
|---------------------|--------------|--------------|-------------------|--------------|
|                     | M-F1         | W-F1         | M-F1              | W-F1         |
| <b>Llama-3.1 8B</b> |              |              |                   |              |
| m=3                 | 50.60        | 57.47        | 37.96             | 39.71        |
| m=5                 | 51.49        | 58.39        | 39.64             | 41.25        |
| m=10                | <b>53.91</b> | <b>60.84</b> | <b>42.44</b>      | <b>44.13</b> |
| <b>Gpt-4o-mini</b>  |              |              |                   |              |
| m=3                 | 47.98        | 54.82        | 44.15             | 45.28        |
| m=5                 | 49.26        | 56.82        | 48.24             | 49.24        |
| m=10                | <b>51.00</b> | <b>58.88</b> | <b>51.24</b>      | <b>52.53</b> |

Bảng 4: Hiệu suất với số lượng đường dẫn suy luận khác nhau m=3, 5, 10.

## 5.4 Tác động của Phân rã lên TTS

Phân rã tuyên bố là một phương pháp phổ biến để giải quyết các tuyên bố phức tạp với nhiều khía cạnh (V et al., 2024; Chen et al., 2022). Do đó, để trả lời RQ3, chúng tôi phân tích tác động của việc phân rã tuyên bố thành các câu hỏi phụ kết hợp với việc điều chỉnh trong thời gian kiểm tra để hiểu tác động đối với việc xác minh cuối cùng của tuyên bố. Chúng tôi sử dụng các câu hỏi phụ kiểu đồng/không kiểu ClaimDecomp (Chen et al., 2022) vì chúng được phát hiện có hiệu suất vượt trội và dễ hiểu (V et al., 2024; Chen et al., 2022). Kết quả được trình bày trong Bảng 2. Chúng tôi quan sát thấy việc phân rã tuyên bố gây ra những tác động tiêu cực bất ngờ đối với hiệu suất xác minh tuyên bố. Qua phân tích, chúng tôi nhận thấy điều này chủ yếu là do vấn đề lệch suy luận từ LLM được kích hoạt vì một số câu hỏi phụ tập trung vào các khía cạnh không phải trọng tâm của các sự kiện đang được kiểm tra, gây ra sự lệch hướng.

Ngoài ra, chúng tôi nhận thấy rằng Adaptive BoN và BoN dẫn đến việc xem xét các khía cạnh đa dạng của yêu cầu. Vì đây là mục tiêu cốt lõi của việc phân rã, TTS làm cho việc phân rã yêu cầu trở nên thừa, dẫn đến hiệu quả giảm dần (Bảng 1, 2 và 3).

## 5.5 Cắt bỏ

Chúng tôi thực hiện các thí nghiệm loại bỏ bằng cách thay đổi kích thước tỉ lệ của số lượng đường dẫn suy luận ( $m=3,5,10$ ) sử dụng LLM. Kết quả được trình bày trong Bảng 4. Chúng tôi quan sát thấy hiệu suất tăng khi số lượng đường dẫn suy luận tăng, đạt hiệu suất tốt nhất tại  $m=10$ . Chúng tôi không mở rộng vượt quá 10 do giới hạn về tính toán và chi phí.

## 6 Kết luận

Chúng tôi xác định và nghiên cứu vấn đề trôi lý luận trong khả năng suy luận của LLM đối với các khẳng định phức tạp và số liệu. Để giải quyết vấn đề này, chúng tôi đề xuất chiến lược mở rộng thời gian kiểm tra Best-of-N (BoN), vượt trội so với Self-Consistency và giải mã Top-1. Để cải thiện hiệu quả tính toán, chúng tôi giới thiệu Adaptive BoN (VERIFIERFC). VERIFIERFC đạt hiệu suất tốt hơn BoN đồng thời giảm chi phí tính toán. Trong công trình tương lai, chúng tôi dự định tích hợp các mô hình xác minh mạnh hơn và tối ưu hóa thêm VERIFIERFC về hiệu suất và hiệu quả.

## 7 Hạn chế

Trong khi VERIFIERFC cho thấy những cải tiến mạnh mẽ so với các cơ sở, một khoảng cách đáng kể vẫn còn so với

giới hạn trên. Điều này có thể được giải quyết bằng cách tích hợp các mô hình xác minh mạnh hơn với sự hiểu biết sâu hơn về ngôn ngữ và số học. Một hướng đi hứa hẹn khác là đào tạo các bộ xác minh trên dữ liệu được chú thích bởi con người chất lượng cao hơn, điều này đã được chứng minh là cải thiện hiệu suất suy luận. Ngoài ra, phương pháp hiện tại của chúng tôi tận dụng các phương pháp truy xuất và xếp hạng tiên tiến hiện có. Tuy nhiên, bằng chứng nhiều có thể gây ra thiên lệch, ảnh hưởng đến cả hiệu suất và tính hợp lệ của phân tích của chúng tôi. Công việc tương lai có thể kết hợp các quy trình truy xuất và xếp hạng lại mạnh mẽ hơn (Rathee và cộng sự, 2024) để giảm thiểu này, cho phép đánh giá công bằng và chính xác hơn về các phương pháp dự đoán độ xác thực.

## 8 Cân nhắc và Rủi ro về Đạo đức

Công trình này tập trung vào việc cải thiện tính nhất quán về thực tế trong các kết quả đầu ra của mô hình ngôn ngữ thông qua mở rộng quy mô khi kiểm tra và suy luận có hướng dẫn bởi trình xác thực. Trong khi các phương pháp của chúng tôi nhằm tránh sự trôi đi của suy luận, chúng vẫn phải đối mặt với một số cân nhắc đạo đức.

Thứ nhất, sự phụ thuộc của chúng tôi vào các đường lối suy luận do LLM tạo ra có thể dẫn đến rủi ro tiềm ẩn trong việc củng cố các thiên lệch của mô hình hoặc các lỗi thực tế trong quá trình huấn luyện bộ xác minh. Mặc dù bộ xác minh được huấn luyện để chọn ra các lập luận hợp lý, nhưng nó có thể thừa hưởng những sai sót hệ thống từ LLM gốc. Thứ hai, phương pháp của chúng tôi hiện chưa bao gồm việc đảm bảo công bằng hay giảm thiểu lệch theo các thuộc tính nhân khẩu học, điều này có thể có liên quan đối với các tuyên bố mang tính chính trị hoặc xã hội nhạy cảm.

Các bộ dữ liệu của chúng tôi (QuanTemp, ClaimDecomp) được lấy từ các nguồn công khai (với giấy phép Creative Commons) và không bao gồm thông tin nhận dạng cá nhân hoặc thông tin nhạy cảm. Các tuyên bố tập trung vào dữ liệu công khai và kiến thức chuyên ngành thay vì cá nhân riêng tư. Những người chú thích dữ liệu tham gia đánh giá đã được trình bày các đường lối suy luận và được yêu cầu đánh giá hiệu suất của mô hình theo hướng dẫn rõ ràng, cụ thể cho nhiệm vụ (Phụ lục A). Không có nội dung nào có thể gây hại hoặc xúc phạm được gặp trong quá trình chú thích.

## 9 Lời cảm ơn

Chúng tôi muốn cảm ơn SowmyaAS vì đã giúp đánh giá chất lượng của bộ ước lượng độ khó khiêu nại. Chúng tôi cũng muốn ghi nhận Factiveverse AI vì đã đóng góp phần cứng cho các thí nghiệm được báo cáo trong công trình này.

#### Tài liệu tham khảo

Firoj Alam, Julia Maria Struß, Tanmoy Chakraborty, Stefan Dietze, Salim Hafid, Katerina Korre, Arianna Muti, Preslav Nakov, Federico Ruggeri, Sebastian Schellhammer, và các tác giả khác. 2025. Phòng thí nghiệm clef-2025 checkthat!: Chủ quan, xác minh thông tin, chuẩn hóa tuyên bố và truy xuất. Trong Hội nghị Châu Âu về Truy xuất Thông tin, trang 467–478. Springer.

Tariq Alhindi, Savvas Petridis, và Smaranda Muresan. 2018. Bằng chứng của bạn ở đâu: Cải thiện việc kiểm tra sự thật bằng mô hình hóa lý lẽ. Trong Kỷ yếu Hội thảo Thường niên lần thứ nhất về Trích xuất và Xác minh Sự thật (FEVER), trang 85–90, Brussels, Bỉ. Hiệp hội Ngôn ngữ Học Máy Tính.

Rami Aly, Zhijiang Guo, Michael Sejr Schlichtkrull, James Thorne, Andreas Vlachos, Christos Christodoulopoulos, Oana Cocarascu, và Arpit Mittal. 2021. Nhiệm vụ chia sẻ Trích xuất sự thật và XÁC minh thông tin không cấu trúc và cấu trúc (FEVEROUS). Trong Kỷ yếu của Hội thảo lần thứ tư về Trích xuất sự thật và XÁC minh (FEVER), trang 1–13, Cộng hòa Dominican. Hiệp hội Ngôn ngữ Học Máy Tính.

Isabelle Augenstein, Timothy Baldwin, Meeyoung Cha, và cộng sự. 2024. Những thách thức về tính xác thực trong kỷ nguyên của các mô hình ngôn ngữ lớn và cơ hội cho việc kiểm chứng thông tin. *Nature Machine Intelligence*, 6:852–863.

Isabelle Augenstein, Christina Lioma, Dongsheng Wang, Lucas Chaves Lima, Casper Hansen, Christian Hansen, và Jakob Grue Simonsen. 2019. MultiFC: Một tập dữ liệu đa miền thực tiễn cho việc kiểm tra sự thật dựa trên bằng chứng của các tuyên bố. Trong Kỷ yếu Hội nghị Năm 2019 về Các Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên và Hội nghị Liên hợp Quốc tế lần thứ 9 về Xử lý Ngôn ngữ Tự nhiên (EMNLP-IJCNLP), trang 4685–4697, Hồng Kông, Trung Quốc. Hiệp hội Ngôn ngữ Học Máy Tính.

Tom Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared D Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, và các tác giả khác. 2020. Các mô hình ngôn ngữ là những người học ít dữ liệu. *Tiến bộ trong hệ thống xử lý thông tin thần kinh*, 33:1877–1901.

Jifan Chen, Aniruddh Sriram, Eunsol Choi, và Greg Durrett. 2022. Tạo các câu hỏi phụ theo nghĩa đen và ngụ ý để kiểm chứng sự thật các tuyên bố phức tạp. Trong Kỷ yếu Hội nghị Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên năm 2022, trang 3495–3516, Abu Dhabi, Các Tiểu vương quốc Ả Rập Thống nhất. Hiệp hội Ngôn ngữ học Tính toán.

Xingyu Chen, Jiahao Xu, Tian Liang, Zhiwei He, Jianhui Pang, Dian Yu, Linfeng Song, Qiuzhi Liu, Mengfei Zhou, Zhuosheng Zhang, Rui Wang, Zhaopeng Tu, Haitao Mi, và Dong Yu. 2025. Đừng suy nghĩ quá nhiều về  $2+3=?$  về việc suy nghĩ quá mức của các mô hình ngôn ngữ giống o1.

Yung-Sung Chuang, Yujia Xie, Hongyin Luo, Yoon Kim, James R. Glass và Pengcheng He. 2024. Dola: Giải mã bằng cách đối chiếu các lớp cải thiện độ thực tế trong các mô hình ngôn ngữ lớn. Trong Hội nghị Quốc tế lần thứ Mười Hai về Biểu diễn Học Tập.

Karl Cobbe, Vineet Kosaraju, Mohammad Bavarian, Mark Chen, Heewoo Jun, Lukasz Kaiser, Matthias Plappert, Jerry Tworek, Jacob Hilton, Reiichiro Nakano, Christopher Hesse, và John Schulman. 2021. Huấn luyện các bộ xác minh để giải các bài toán từ ngữ về toán học.

Alejandro Cuadron, Dacheng Li, Wenjie Ma, Xingyao Wang, Yichuan Wang, Siyuan Zhuang, Shu Liu, Luis Gaspar Schroeder, Tian Xia, Huanzhi Mao, Nicholas Thumiger, Aditya Desai, Ion Stoica, Ana Klimovic, Graham Neubig, và Joseph E. Gonzalez. 2025. Nguy cơ của việc suy nghĩ quá mức: Khảo sát mâu thuẫn suy luận-hành động trong các nhiệm vụ tự chủ.

DeepSeek-AI, Daya Guo, Dejian Yang, Haowei Zhang, Junxiao Song, Ruoyu Zhang, Runxin Xu, Qihao Zhu, Shirong Ma, Peiyi Wang, Xiao Bi, Xiaokang Zhang, Xingkai Yu, Yu Wu, Z. F. Wu, Zhibin Gou, Zhihong Shao, Zhuoshu Li, Ziyi Gao, Aixin Liu, Bing Xue, Bingxuan Wang, Bochao Wu, Bei Feng, Chengda Lu, Chenggang Zhao, Chengqi Deng, Chenyu Zhang, Chong Ruan, Da mai Dai, Deli Chen, Dongjie Ji, Erhang Li, Fangyun Lin, Fucong Dai, Fuli Luo, Guangbo Hao, Guanting Chen, Guowei Li, H. Zhang, Han Bao, Hanwei Xu, Haocheng Wang, Honghui Ding, Huajian Xin, Huazuo Gao, Hui Qu, Hui Li, Jianzhong Guo, Jiashi Li, Jiawei Wang, Jingchang Chen, Jingyang Yuan, Junjie Qiu, Junlong Li, J. L. Cai, Jiaqi Ni, Jian Liang, Jin Chen, Kai Dong, Kai Hu, Kaige Gao, Kang Guan, Kexin Huang, Kuai Yu, Lean Wang, Lecong Zhang, Liang Zhao, Litong Wang, Liyue Zhang, Lei Xu, Leyi Xia, Mingchuan Zhang, Minghua Zhang, Minghui Tang, Meng Li, Miaoqun Wang, Mingming Li, Ning Tian, Panpan Huang, Peng Zhang, Qiancheng Wang, Qinyu Chen, Qius

- Yanping Huang, Yaohui Li, Yi Zheng, Yuchen Zhu, Yunxian Ma, Ying Tang, Yukun Zha, Yuting Yan, Z. Z. Ren, Zehui Ren, Zhangli Sha, Zhe Fu, Zhean Xu, Zhenda Xie, Zhengyan Zhang, Zhewen Hao, Zhicheng Ma, Zhigang Yan, Zhiyu Wu, Zihui Gu, Zi-jia Zhu, Zijun Liu, Zilin Li, Ziwei Xie, Ziyang Song, Zizheng Pan, Zhen Huang, Zhipeng Xu, Zhongyu Zhang, và Zhen Zhang. 2025. Deepseek-r1: Khuyến khích khả năng lý luận trong các mô hình ngôn ngữ lớn thông qua học tăng cường.
- Thomas Diggelmann, Jordan Boyd-Graber, Jannis Bu-lian, Massimiliano Ciaramita, và Markus Leippold. 2021. Climate-fever: Một tập dữ liệu để xác minh các tuyên bố về khí hậu trong thế giới thực.
- Xidong Feng, Ziyu Wan, Muning Wen, Stephen Marcus McAleer, Ying Wen, Weinan Zhang, và Jun Wang. 2024. Cây tìm kiếm giống Alphazero có thể hướng dẫn việc giải mã và huấn luyện mô hình ngôn ngữ lớn.
- Zhijiang Guo, Michael Schlichtkrull, và Andreas Vlachos. 2022. Một khảo sát về kiểm tra sự thật tự động. *Transactions of the Association for Computational Linguistics*, 10:178–206.
- Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, và Weizhu Chen. 2021. Lora: Thích ứng bậc thấp của các mô hình ngôn ngữ lớn.
- Jie Huang và Kevin Chen-Chuan Chang. 2023. Hướng tới suy luận trong các mô hình ngôn ngữ lớn: Một khảo sát. Trong *Kết quả của Hiệp hội Ngôn ngữ học Máy tính: ACL 2023*, trang 1049–1065, Toronto, Canada. Hiệp hội Ngôn ngữ học Máy tính.
- Soyeong Jeong, Jinheon Baek, Sukmin Cho, Sung Ju Hwang, và Jong C. Park. 2024. Adaptive-rag: Học cách thích nghi với các mô hình ngôn ngữ lớn được tăng cường truy xuất thông tin thông qua độ phức tạp của câu hỏi.
- Yichen Jiang, Shikha Bordia, Zheng Zhong, Charles Dognin, Maneesh Singh và Mohit Bansal. 2020. HoVer: Một tập dữ liệu cho trích xuất sự thật nhiều bước và xác minh tuyên bố. Trong *Kết quả của Hiệp hội Ngôn ngữ học Máy tính: EMNLP2020*, trang 3441–3460, Trục t uyển. Hiệp hội Ngôn ngữ học Máy tính.
- Bowen Jin, Hansi Zeng, Zhenrui Yue, Jinsung Yoon, Sercan Arik, Dong Wang, Hamed Zamani, và Jiawei Han. 2025. Search-r1: Huấn luyện LLMs để suy luận và tận dụng các công cụ tìm kiếm bằng học tăng cường.
- Neema Kotonya và Francesca Toni. 2020. Kiểm tra sự thật tự động có thể giải thích cho các tuyên bố về sức khỏe cộng đồng.
- Miaoran Li, Baolin Peng, Michel Galley, Jianfeng Gao, và Zhu Zhang. 2024. Self-checker: Các mô-đun cắm và chạy để kiểm tra sự thật với các mô hình ngôn ngữ lớn. Trong *Kết quả của Hiệp hội Ngôn ngữ học Máy tính: NAACL 2024*, trang 163–181, Thành phố Mexico, Mexico. Hiệp hội Ngôn ngữ học Máy tính.
- Hunter Lightman, Vineet Kosaraju, Yura Burda, Harri Edwards, BowenBaker, TeddyLee, Jan Leike, John Schulman, Ilya Sutskever, và Karl Cobbe. 2023. Hãy xác minh từng bước một.
- Huanshuo Liu, Hao Zhang, Zhijiang Guo, Jing Wang, Kuicai Dong, Xiangyang Li, Yi Quan Lee, Cong Zhang, và Yong Liu. 2024. Ctrlr: Sinh tạo tăng cường truy xuất thích ứng thông qua kiểm soát vốn có.
- Aman Madaan, Niket Tandon, Prakhar Gupta, Skyler Hallinan, Luyu Gao, Sarah Wiegrefe, Uri Alon, Nouha Dziri, Shrimai Prabhumoye, Yiming Yang, Shashank Gupta, Bodhisattwa Prasad Majumder, Katherine Hermann, Sean Welleck, Amir Yazdan-bakhsh, và Peter Clark. 2023. Self-refine: Tinh chỉnh lặp đi lặp lại với phản hồi tự thân. Trong *Tạp chí Advances in Neural Information Processing Systems*, tập 36, các trang 46534–46594. Curran Associates, Inc.
- Alex Mallen, Akari Asai, Victor Zhong, Rajarshi Das, Daniel Khashabi, và Hannaneh Hajishirzi. 2023. Khi nào không nên tin vào các mô hình ngôn ngữ: Điều tra hiệu quả của bộ nhớ tham số và phi tham số.
- Preslav Nakov, Federico Ruggeri, Sebastian Schellhammer, Vinay Setty, Megha Sundriyal10, Konstantin Todorov11, và V Venkatesh. 2025. Tổng quan về phòng thí nghiệm clef-2025 checkthat!: Chủ quan, kiểm tra sự thật, chuẩn hóa tuyên bố và truy xuất. Trong *Triển khai IR Thí nghiệm Gặp Gỡ Đa ngôn ngữ, Đa phương tiện và Tương tác: Hội nghị Quốc tế lần thứ 16 của Hiệp hội CLEF, CLEF 2025*, Madrid, Tây Ban Nha, từ 9–12 tháng 9, 2025, Kỷ yếu, trang 199. Springer Nature.
- Kevin Nanekhan, Erik Martin, Henrik Vatndal, Vinay Setty, và Avishek Anand. 2025. Flashcheck: Khám phá việc truy xuất bằng chứng hiệu quả cho kiểm tra sự thật nhanh. Trong *Hội nghị Châu Âu về Truy xuất Thông tin*.
- Eric Nichols, Leo Gao, và Randy Gomez. 2020. Kể chuyện hợp tác với các mô hình ngôn ngữ thần kinh quy mô lớn.
- OpenAI. 2023. Báo cáo kỹ thuật GPT-4.
- OpenAI. 2024. Học cách lý luận với LLMs. <https://openai.com/index/learning-to-reason-with-llms/>. Truy cập: 26-04-2025.
- Wojciech Ostrowski, Arnav Arora, Pepa Atanasova, và Isabelle Augenstein. 2021. Kiểm tra sự thật nhiều bước đối với các tuyên bố chính trị. Trong *Kỷ yếu của Hội nghị Liên hợp Quốc tế lần thứ ba mươi về Trí tuệ Nhân tạo, IJCAI-21*, trang 3892–3898. Tổ chức Các Hội nghị Liên hợp Quốc tế về Trí tuệ Nhân tạo. Chương Chính.
- Mandeep Rathee, Sean MacAvaney, và Avishek Anand. 2024. Quam: Truy xuất thích ứng thông qua mô hình hóa sự tương đồng truy vấn. arXiv preprint arXiv:2410.20286.

Nils Reimers và Iryna Gurevych. 2019. Sentence-bert: Những câu sử dụng mạng bert song sinh. Trong Kỷ yếu Hội nghị 2019 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên. Hiệp hội Ngôn ngữ học Máy tính. J. J. Rocchio. 1971. Phản hồi liên quan trong truy xuất thông tin. Trong G. Salton, biên tập, Hệ thống truy xuất thông minh - thí nghiệm trong xử lý tài liệu tự động, trang 313–323. Englewood Cliffs, NJ: Prentice-Hall. Michael Schlichtkrull, Zhijiang Guo, và Andreas Vlachos. 2023. Averitec: Một bộ dữ liệu cho xác minh tuyên bố thực tế với bằng chứng từ web. Vinay Setty. 2024. Hiệu quả bất ngờ của các transformer tinh chỉnh trong kiểm tra sự thật so với các mô hình ngôn ngữ lớn hơn. Trong Kỷ yếu Hội nghị Quốc tế ACM SIGIR lần thứ 47 về Nghiên cứu và Phát triển trong Truy xuất Thông tin, SIGIR '24, trang 2842–2846, New York, NY, Hoa Kỳ. Hiệp hội Máy tính.

Avi Singh, John D. Co-Reyes, Rishabh Agarwal, Ankesh Anand, Piyush Patil, Xavier Garcia, Peter J. Liu, James Harrison, Jaehoon Lee, Kelvin Xu, Aaron Parisi, Abhishek Kumar, Alex Alemi, Alex Rizkowsky, Azade Nova, Ben Adlam, Bernd Bohnet, Gamaleldin Elsayed, Hanie Sedghi, Igor Mordatch, Isabelle Simpson, Izzeddin Gur, Jasper Snoek, Jeffrey Pennington, Jiri Hron, Kathleen Kenealy, Kevin Swersky, Kshiteej Mahajan, Laura Culp, Lechao Xiao, Maxwell L. Bileschi, Noah Constant, Roman Novak, Rosanne Liu, Tris Warkentin, Yundi Qian, Yamini Bansal, Ethan Dyer, Behnam Neyshabur, Jascha Sohl-Dickstein và Noah Fiedel. 2024. Vượt ra ngoài dữ liệu con người: Mở rộng tự huấn luyện để giải quyết vấn đề với các mô hình ngôn ngữ.

Charlie Snell, Jaehoon Lee, Kelvin Xu, và Aviral Kumar. 2024. Tăng cường tính toán thời gian kiểm tra của LLM một cách tối ưu có thể hiệu quả hơn so với việc tăng số lượng tham số của mô hình.

Jake Snell, Kevin Swersky, và Richard Zemel. 2017. Mạng nguyên mẫu cho học với số lượng mẫu ít. Trong Kỷ yếu của Hội nghị Quốc tế lần thứ 31 về Hệ thống Xử lý Thông tin Thần kinh, NIPS'17, trang 4080–4090, Red Hook, NY, Hoa Kỳ. Curran Associates Inc.

Zhivar Sourati, Darshan Girish Deshpande, Filip Ilievski, Kiril Gashtevski, và Sascha Sarala-jew. 2024. Phân loại văn bản vững chắc: Phân tích các mạng dựa trên nguyên mẫu. Trong Kết quả của Hiệp hội Ngôn ngữ học Máy tính: EMNLP 2024, trang 12736–12757, Miami, Florida, Hoa Kỳ. Hiệp hội Ngôn ngữ học Máy tính. Yang Sui, Yu-Neng Chuang, Guanchu Wang, Jiamu Zhang, Tianyi Zhang, Jiayi Yuan, Hongyi Liu, Andrew Wen, Shaochen Zhong, Hanjie Chen, và Xia Hu. 2025. Ngừng suy nghĩ quá nhiều: Một khảo sát về lý luận hiệu quả cho các mô hình ngôn ngữ lớn. Qi Sun, Marc Pickett, Aakash Kumar Nain, và Llion Jones. 2025. Các lớp Transformer như những họa sĩ.

James Thorne, Andreas Vlachos, Christos Christodoulopoulos, và Arpit Mittal. 2018. FEVER: một tập dữ liệu quy mô lớn cho việc trích xuất sự kiện và XÁC MINH. Trong Kỷ yếu Hội nghị 2018 của Chương Bắc Mỹ thuộc Hiệp hội Ngôn ngữ Học Máy tính: Công nghệ Ngôn ngữ Con người, Tập 1 (Bài báo dài), trang 809–819, New Orleans, Louisiana. Hiệp hội Ngôn ngữ Học Máy tính. Jonathan Uesato, Nate Kushman, Ramana Kumar, Francis Song, Noah Siegel, Lisa Wang, Antonia Creswell, Geoffrey Irving và Irina Higgins. 2022. Giải quyết các bài toán từ toán học với phản hồi dựa trên quá trình và kết quả. Venkatesh V, Abhijit Anand, Avishek Anand và Vinay Setty. 2024. Quantemp: Một chuẩn đánh giá thực tế mở về xác minh các tuyên bố số. Trong Kỷ yếu Hội nghị Quốc tế ACM SIGIR lần thứ 47 về Nghiên cứu và Phát triển trong Truy xuất Thông tin, SIGIR '24, trang 650–660, New York, NY, USA. Hiệp hội Máy tính.

Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, và Illia Polosukhin. 2023. Chỉ cần chú ý.

V Venkatesh, Avishek Anand, và cộng sự. 2025. Tin nhưng kiểm chứng! một khảo sát về thiết kế xác minh cho việc mở rộng thời gian kiểm tra. Bản in trước arXiv arXiv:2508.16665.

Juraj Vladika và Florian Matthes. 2023. Kiểm tra sự thật khoa học: Một khảo sát về các nguồn lực và phương pháp tiếp cận.

David Wadden, Shanchuan Lin, Kyle Lo, Lucy Lu Wang, Madeleine van Zuylen, Arman Cohan và Hannaneh Hajishirzi. 2020. Thực hay hư: Xác thực các tuyên bố khoa học. Trong Kỷ yếu Hội nghị Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên 2020 (EMNLP), trang 7534–7550, Trục tuyến. Hiệp hội Ngôn ngữ học Tính toán.

Jonas Wallat, Abdelrahman Abdallah, Adam Jatowt và Avishek Anand. 2024a. Một nghiên cứu về điều tra độ bền theo thời gian của LLMs. Kết quả của Hiệp hội Ngôn ngữ học Máy tính.

Jonas Wallat, Adam Jatowt, và Avishek Anand. 2024b. Điểm mù về thời gian trong các mô hình ngôn ngữ lớn. Trong Kỷ yếu Hội nghị Quốc tế ACM lần thứ 17 về Tìm kiếm Web và Khai thác Dữ liệu, trang 683–692. Peiyi Wang, Lei Li, Zhihong Shao, R. X. Xu, Damai Dai, Yifei Li, Deli Chen, Y. Wu, và Zhifang Sui. 2024. Math-shepherd: Xác minh và củng cố các mô hình ngôn ngữ từng bước mà không cần chú thích của con người. William Yang Wang. 2017. “liar, liar pants on fire”: Bộ dữ liệu chuẩn mới cho phát hiện tin giả. Trong Kỷ yếu Cuộc họp Thường niên lần thứ 55 của Hiệp hội Ngôn ngữ học Máy tính (Tập 2: Bài báo ngắn), trang 422–426, Vancouver, Canada. Hiệp hội Ngôn ngữ học Máy tính.

Xuezhi Wang, Jason Wei, Dale Schuurmans, Quoc Le, Ed Chi, Sharan Narang, Aakanksha Chowdhery, và Denny Zhou. 2023. Tính nhất quán tự thân cải thiện lập luận chuỗi suy nghĩ trong các mô hình ngôn ngữ.

Jason Wei, Yi Tay, Rishi Bommasani, Colin Raffel, Barret Zoph, Sebastian Borgeaud, Dani Yogatama, Maarten Bosma, Denny Zhou, Donald Metzler, Ed H. Chi, Tatsunori Hashimoto, Oriol Vinyals, Percy Liang, Jeff Dean, và William Fedus. 2022. Khả năng nổi bật của các mô hình ngôn ngữ lớn.

Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Brian Ichter, Fei Xia, Ed Chi, Quoc Le và Denny Zhou. 2023. Gợi ý theo chuỗi tư duy kích thích lý luận trong các mô hình ngôn ngữ lớn.

Dustin Wright, David Wadden, Kyle Lo, Bailey Kuehl, Arman Cohan, Isabelle Augenstein, và Lucy Lu Wang. 2022. Tạo ra các tuyên bố khoa học để kiểm tra sự thật khoa học theo phương pháp zero-shot.

Yuxi Xie, Kenji Kawaguchi, Yiran Zhao, Xu Zhao, Min-Yen Kan, Junxian He, và Qizhe Xie. 2023. Tìm kiếm chùm tia hướng dẫn tự đánh giá để suy luận.

Shunyu Yao, Dian Yu, Jeffrey Zhao, Izhak Shafran, Thomas L. Griffiths, Yuan Cao, và Karthik Narasimhan. 2023a. Cây suy nghĩ: Giải quyết vấn đề có suy xét với các mô hình ngôn ngữ lớn.

Shunyu Yao, Jeffrey Zhao, Dian Yu, Nan Du, Izhak Shafran, Karthik R Narasimhan, và Yuan Cao. 2023b. React: Tăng cường sự kết hợp giữa lập luận và hành động trong các mô hình ngôn ngữ. Trong Hội nghị Quốc tế lần thứ Mười về Học các Biểu diễn.

Eric Zelikman, Yuhuai Wu, Jesse Mu, và Noah D. Goodman. 2022. Star: Khởi động tư duy với tư duy.

Qiyuan Zhang, Fuyuan Lyu, Zexu Sun, Lei Wang, Weixu Zhang, Wenyue Hua, Haolun Wu, Zhihan Guo, Yufei Wang, Niklas Muennighoff, và cộng sự. 2025. Một khảo sát về mở rộng thời gian kiểm tra trong các mô hình ngôn ngữ lớn: Cái gì, như thế nào, ở đâu, và hiệu quả ra sao? Bản in trước trên arXiv arXiv:2503.24235.

#### Hướng dẫn Người chú thích về Chú thích Độ phức tạp của Yêu cầu

##### Hướng dẫn chú thích:

Vui lòng xem xét tuyên bố đã cho trong bối cảnh của lý do và phán quyết từ chuyên gia kiểm chứng thông tin được cung cấp. Tự theo dõi quá trình kiểm chứng thông tin và phân tích xem có bao nhiêu khía cạnh cần được xác minh trong tuyên bố. Nếu tuyên bố có nhiều hơn một khía cạnh cần được xác minh bằng nhiều nguồn, hãy chú thích nó là 1, nếu không hãy chú thích là 0.

Hình 4: Hướng dẫn Người chú thích cho Ghi chú Độ phức tạp của Yêu cầu.

## Hướng dẫn chú thích

### A.1 Hướng dẫn phân tích thủ công vấn đề trôi lý luận

Hình 5 trình bày hướng dẫn cho người chú thích đánh giá định tính các mẫu được xác định bởi các LLM thăm phán về sự lệch lập luận. Tùy thuộc vào đánh giá của con người, họ được hướng dẫn gán một danh mục 1 nếu họ đồng ý với đánh giá của LLM và 0 nếu không. Việc gán này được sử dụng để tính toán Hệ số Kappa của Cohen nhằm đánh giá sự đồng thuận giữa các người chú thích.

### A.2 Hướng Dẫn Chú Giải về Độ Phức Tạp của Yêu Cầu

Hình 4 cho thấy hướng dẫn về việc chú thích mức độ phức tạp cho các yêu cầu.

## B Nhiều ví dụ hơn thể hiện sự trôi dạt trong lập luận

Hình 6 và Hình 7 cung cấp thêm các ví dụ định tính nơi LLM thể hiện sự trôi dạt trong lý luận trong quá trình suy luận. Điều này được giảm bớt bằng cách chọn chuỗi suy luận tốt nhất sử dụng VERIFIERFC.

## C Lời nhắc

Phần này mô tả các lời nhắc của hệ thống và người dùng được sử dụng trong các giai đoạn khác nhau của các thí nghiệm của chúng tôi. Hình 8 và 9 cho thấy lời nhắc của hệ thống và một ví dụ về lời nhắc của người dùng được sử dụng để xác định liệu suy luận dựa trên người kiểm chứng có giảm sai lệch suy luận so với đối tác Giải mã Top 1 hay không. Hình 10 minh họa một ví dụ về lời nhắc được thiết kế để hướng dẫn LLM kiểm tra sự thật trong việc dự đoán một phán quyết và cung cấp lý luận cho một cặp tuyên bố-bằng chứng.

#### Hướng dẫn cho người chú thích để đánh giá sự lệch lạc trong lập luận

Vui lòng xem xét đánh giá của LLM về sự hiện diện hay vắng mặt của sự trôi luân lý, cùng với lý do của nó. Sau đó, ghi chú liệu bạn có tin rằng nhân đó là chính xác và liệu nó có phù hợp với định nghĩa của chúng ta về sự trôi luân lý hay không.

Định nghĩa về Sai lệch Lý luận: Sai lệch Lý luận được định nghĩa là một hành vi vốn có ở các Mô hình Ngôn ngữ Lớn (LLM), trong đó—đặc biệt trong bối cảnh kiểm tra sự thật—mô hình quá khớp với một khía cạnh của tuyên bố không phải là trọng tâm để xác minh tính đúng đắn của nó. Điều này có thể bị kích hoạt bởi các chi tiết không liên quan hoặc bởi các bối cảnh đa dạng.

##### Ví dụ:

- Một mô hình ngôn ngữ lớn có thể không nhận ra rằng hai đại lượng được biểu thị bằng các đơn vị khác nhau (ví dụ: KSh và đô la) đại diện cho cùng một giá trị.

- Nó có thể không nhận ra rằng cùng một bản tuyên ngôn chính trị có thể đã được một đảng thông qua vào cả năm 1928 và một năm sau đó, dẫn đến những nghi ngờ không cần thiết.

Hướng dẫn chú thích: Nếu LLM judge đã xác định rằng có (hoặc không có) sự lệch lạc trong lập luận, và bạn đồng ý rằng quyết định này phù hợp với định nghĩa ở trên, đánh dấu nó là 1 (tức là đúng). Nếu không, đánh dấu nó là 0 (tức là sai). Chúng tôi sẽ sử dụng điều này để tính toán sự đồng thuận giữa các người chú thích.

Hình 5: Hướng dẫn cho những người chú thích đánh giá dự đoán lệch lý luận do judgeLLM thực hiện.

#### Giảm thiểu sự trôi dạt lập luận cho FC số học

**Khẳng định:** Có 100 triệu người có tình trạng bệnh lý từ trước.

[Bằng chứng]: một phân tích năm 2018 của Avalere, một công ty tư vấn chăm sóc sức khỏe, ước tính rằng 102 triệu người Mỹ có các tình trạng bệnh lý từ trước. Một phân tích năm 2019 của Trung tâm Tiến bộ Mỹ nghiêng về cánh tả gợi ý 135 triệu người. Ngoài ra, không rõ có bao nhiêu người có các tình trạng bệnh lý từ trước sẽ có nguy cơ mất hoàn toàn bảo hiểm, hoặc phải đối mặt với chi phí cao hơn hoặc tình trạng của họ không được bảo hiểm. Mặc dù con số của Biden chắc chắn nằm trong phạm vi này, ông sẽ cần cung cấp thêm chi tiết để chứng minh con số chắc chắn đó. Bản tóm tắt vấn đề của HHS, được công bố vào tháng 1 năm 2017, ước tính rằng từ 61 triệu đến 133 triệu người Mỹ có các tình trạng bệnh lý từ trước.

[Phán quyết]: **True**

#### Lập luận LLM mà không có VERIFIERFCR

bằng chứng gợi ý rằng một loạt các ước tính về số người có các tình trạng bệnh lý sẵn có, với con số của Biden nằm trong phạm vi này nhưng không được chấp nhận rộng rãi.[Dự đoán]: Mâu thuẫn

#### Lý luận LLM với VERIFIERFCR

được hỗ trợ bởi điểm nguồn đáng tin cậy, bao gồm một cựu Phó Tổng thống và các công ty tư vấn chăm sóc sức khỏe, với ước tính từ 61 đến 135 triệu người Mỹ có điều kiện bệnh lý tồn tại trước. Tuyên bố của Biden về 100 triệu nằm trong khoảng này.

[Dự đoán]: **Đúng**

Hình 6: Ví dụ về tuyên bố số học minh họa vấn đề lệch lý luận và biện pháp giảm thiểu do VERIFIERFC cung cấp

trong khuôn khổ học theo vài ví dụ. Cuối cùng, Hình 11 trình bày lời nhắc hệ thống được sử dụng để tạo các câu hỏi phụ bằng cách phân tách một tuyên bố, theo phương pháp được trình bày chi tiết trong bài báo CLAIMDECOMP (Chen et al., 2022).

#### Giảm thiểu sự lệch lập luận cho FC Số học

**Khẳng định:** Egas Moniz, người phát minh ra kỹ thuật cắt bỏ thùy não gây tranh cãi để điều trị bệnh nhân tâm thần (đặc biệt là những người mắc bệnh tâm thần phân liệt), đã được trao giải Nobel vào năm 1949 cho công trình của mình.

[Bằng chứng]: Antnio Egas Moniz (1874-1955) của Bồ Đào Nha là một người tham vọng và đa tài. ... Ông đã hy vọng và có lẽ mong đợi sẽ nhận giải Nobel cho công trình này, nhưng thất vọng khi nhận ra mình sẽ không được. Năm 1935 tại một hội nghị thần kinh quốc tế, ông nhận thấy một ... mất đi một phần nào đó từ ca phẫu thuật này, một chút tự nhiên, một chút lấp lánh, một chút hương vị của tính cách." Năm 1942, họ xuất bản một cuốn sách có ảnh hưởng quảng bá thực hành này. Tại Hoa Kỳ, số ca cắt bỏ thùy não được thực hiện mỗi năm tăng từ 100 ca năm 1946 lên 5.000 ca vào năm 1949. Năm đó, Moniz giành giải Nobel Sinh lý học/Y học cho những đóng góp của mình .... giảm nhu cầu được cho là về hầu hết các ca cắt thùy não.

[Phán quyết]: **True**

#### Lập luận LLM mà không có VERIFIERFC

[Lý luận]: Văn bản nêu rằng Moniz đã thất vọng khi nhận ra ông sẽ không nhận giải Nobel cho công trình của mình về việc hình dung các mạch máu trong não, nhưng sau đó ông đã giành giải Nobel về Sinh lý học hoặc Y học vào năm 1949. Điều này cho thấy có sự mâu thuẫn giữa các thông tin được cung cấp.[Dự đoán]: Mâu thuẫn

#### Lập luận LLM với VERIFIERFC

[Lý do]: Văn bản nêu rằng Moniz đã thất vọng khi nhận ra rằng ông sẽ không nhận Giải Nobel cho công trình của mình về hình dung các mạch máu trong não, nhưng sau đó đã giành Giải Nobel Y học/Sinh lý học năm 1949 vì đóng góp của mình trong phẫu thuật tâm thần.

[Dự đoán]: **True** e

Hình 7: Ví dụ về tuyên bố số học minh họa vấn đề trôi dạt lý luận và biện pháp giảm thiểu do VERIFIERFC cung cấp

#### Lời nhắc Hệ thống để Xác định sự trôi dạt lý luận

Hướng dẫn: Bạn là một chuyên gia kiểm tra sự thật được giao nhiệm vụ đánh giá xem liệu việc lập luận được tạo ra bằng mô hình xác minh có giảm thiểu một vấn đề phổ biến trong suy luận của mô hình ngôn ngữ được gọi là lệch lối suy luận hay không. Bạn sẽ được cung cấp:

- Một tuyên bố
- Bảng chứng tương ứng của nó

Phán quyết cho yêu cầu

- Một lập luận và dự đoán được tạo ra mà không cần mô hình xác thực
- Một lập luận và dự đoán được tạo ra với mô hình xác minh

Mục tiêu: Xác định xem việc lý luận dựa trên người xác minh có giảm thiểu thành công sự lệch lạc trong lý luận hay không. Sự lệch lạc trong lý luận được định nghĩa là:

- Tập trung vào các chi tiết trong bảng chứng mà không liên quan đến tính xác thực của yêu cầu.
- Quá nghiêm khắc với độ chính xác về số liệu hoặc sự kiện, những điều có thể được hiểu một cách khoan dung hơn.
- Xác minh từng câu hỏi phụ một cách riêng lẻ nhưng không tổng hợp chúng thành một phán quyết cuối cùng mạch lạc và chính xác t.

**Về lý luận kiểm tra được xem là để giảm nhẹ suy luận d rifting:**

- Nó chỉ tập trung vào bảng chứng liên quan đến tuyên bố.
- Nó tránh việc kiểm tra không cần thiết các chi tiết nhỏ hoặc không liên quan.
- Nó cải thiện độ chính xác của nhân bằng cách lý giải một cách toàn diện về tuyên bố.

Nhiệm vụ của bạn: Trả về một nhãn nhị phân dựa trên đánh giá của bạn:

- 1— sự trôi dạt lý luận được giảm thiểu trong lý luận dựa trên bộ xác minh.
- 0 — suy luận bị lệch không được giảm thiểu (tức là, cả hai phương pháp đều chịu ảnh hưởng như nhau hoặc quá trình suy luận của người kiểm chứng cũng phân tích quá mức).

**Định dạng đầu ra:**

1. Nhãn: <0 hoặc 1> 2. Giải thích: < Lý do ngắn gọn tham chiếu các khác biệt chính trong cách lập luận và sử dụng bảng chứng >

Hình 8: Lời nhắc hệ thống được cung cấp cho LLM trọng tài để đánh giá và xác định sự lệch lạc lập luận giữa việc lập luận có và không có sự hỗ trợ của bộ kiểm chứng.

Một ví dụ về lời nhắc của người dùng để xác định sự trôi dạt trong lập luận

### Ví dụ:

[Yêu cầu]: Joe Biden nói, “Có 100 triệu người có tình trạng bệnh lý từ trước.”

[Bằng chứng]: một phân tích năm 2018 do Avalere, một công ty tư vấn chăm sóc sức khỏe thực hiện, ước tính rằng 102 triệu người Mỹ có các điều kiện tiền sử. ... bản tóm tắt vấn đề của HHS, xuất bản vào tháng 1 năm 2017, ước tính rằng từ 61 triệu đến 133 triệu người Mỹ có một điều kiện tiền sử.

[Phán quyết]: Đúng

#### Suy luận LLM mà không có trình xác minh

[Reasoning]: Các bằng chứng gợi ý một phạm vi ước tính về số người có tình trạng bệnh lý từ trước, với Biden của n nằm trong phạm vi này nhưng không được chấp nhận rộng rãi.

[Dự đoán]: Mâu thuẫn

#### Suy luận LLM với bộ kiểm chứng

[Lập luận]: Yêu cầu này được hỗ trợ bởi nhiều nguồn đáng tin cậy, bao gồm một cựu Phó Tổng thống và các công ty tư vấn chăm sóc sức khỏe, với ước tính từ 61 đến 135 triệu người Mỹ có bệnh nền. Phát biểu của Biden về con số 100 triệu nằm trong khoảng này.

[Dự đoán]: Đúng

#### Đánh giá LLM

[Nhận]: 1

[Giải thích]: Suy luận dựa trên mô hình phần thưởng hiệu quả trong việc giảm suy nghĩ quá mức bằng cách tập trung vào bằng chứng có liên quan hỗ trợ cho tuyên bố, đặc biệt nhấn mạnh rằng con số 100 triệu của Biden nằm trong phạm vi ước tính hợp lý (61 đến 135 triệu). Ngược lại, suy luận không dựa trên mô hình phần thưởng bị mắc kẹt trong tính mâu thuẫn của các ước tính mà không nhận ra rằng con số của Biden vẫn là hợp lệ trong bối cảnh đó. Suy luận dựa trên mô hình phần thưởng đạt nhãn đúng (ĐÚNG) một cách đáng tin cậy hơn bằng cách tổng hợp bằng chứng một cách toàn diện thay vì bị lạc vào chi tiết của các tuyên bố mâu thuẫn.

### Nhập:

[Yêu cầu]: Kiềm hổi của cộng đồng người nước ngoài "hiện đang đạt mức cao kỷ lục vượt quá 400 tỷ KSh vào năm 2021".

[Bằng chứng]: Khối tiền từ cộng đồng người ở nước ngoài rất mạnh mẽ trong năm 2021, với tổng số tiền khối-tiền năm 2021 đạt kỷ lục 3.718 triệu USD.

[Phán quyết]: Đúng

#### Suy luận LLM mà không có trình xác minh

[Lý do]: Các bằng chứng cung cấp thông tin mâu thuẫn về số tiền kiều hối chính xác trong năm 2021, và một số nguồn đề cập đến các con số không thể so sánh trực tiếp với 400 tỷ KSh.

[Dự đoán]: Mâu thuẫn

#### Suy luận LLM với bộ kiểm chứng

[Lý luận]: Bằng chứng cho thấy lời khẳng định rằng kiều hối của cộng đồng người hải ngoại đã đạt mức cao kỷ lục trên 400 tỷ KSh vào năm 2021 là đúng. Tuy nhiên, có một số khác biệt nhỏ về cách diễn đạt và đơn vị được sử dụng giữa các nguồn khác nhau.[Dự đoán]: Đúng

Hình 9: Ví dụ về lời nhắc của người dùng gửi cho LLM trọng tài để xác định sự lệch lạc trong suy luận giữa suy luận không có bộ xác minh và có bộ xác minh

Một câu lệnh ví dụ để tạo các chuỗi lập luận cho các cặp yêu cầu - bằng chứng

### Lời nhắc hệ thống:

Bạn là một trợ lý kiểm tra sự thật được giao nhiệm vụ đánh giá các tuyên bố dựa trên bằng chứng được cung cấp. Nhiệm vụ của bạn:

1. Phân tích cẩn thận các chi tiết quan trọng từ cả yêu cầu và bằng chứng được cung cấp.
2. Lý giải thông qua bằng chứng từng bước, tổng hợp các thông tin liên quan để đánh giá tính xác thực tổng thể của tuyên bố.
3. Cuối cùng, phân loại độ xác thực của tuyên bố vào một trong các danh mục sau:  
(a) Đúng: Bằng chứng hoàn toàn ủng hộ tuyên bố. (b) Sai: Bằng chứng trực tiếp mâu thuẫn với tuyên bố. (c) Mâu thuẫn: Bằng chứng chứa các yếu tố trái ngược hoặc không kết luận được.

**\*\*Định dạng phản hồi\*\*:**

- [Nhân]: (Đúng, Sai, hoặc Mâu thuẫn)
- [Lý do]: Các bước lập luận được sử dụng đã dẫn đến việc bạn phân loại tuyên bố đó.

### Lời nhắc của người dùng:

#### Ví dụ 1

[Yêu cầu]: Ngân hàng Trung ương Argentina đang xem xét đặt hình ảnh của Lionel Messi trên tờ tiền 1000 peso.

[Bằng chứng]: Các cơ quan tài chính đang xem xét việc đưa hình ảnh của người chiến thắng World Cup Lionel Messi bằng cách in hình của anh lên tờ tiền 1000 peso, theo các báo cáo.

[Phán quyết]: Sai

[Lý do]: Có thật không? Lời khẳng định đó là sai. Trang web của BCRA cũng không hiển thị hình ảnh của Messi trên bất kỳ tờ tiền nào khi nó đưa ra một thông báo như vậy.

#### Ví dụ 2

[Yêu cầu]: Politico đã không báo cáo rằng 20 triệu người Ukraine sẽ chết để giành chiến thắng trong chiến tranh.

[Bằng chứng]: Trong cuộc xung đột Nga-Ukraine đang diễn ra, tổn thất do các nguồn khác nhau báo cáo khác nhau theo cấp số lớn. Sergei Shoigu báo cáo 5.937 binh sĩ Nga ... binh sĩ Nga thiệt mạng, các nguồn Nga chỉ báo cáo tổn thất 0,3. Ngược lại, đối với mỗi binh sĩ Ukraine thiệt mạng, các nguồn Nga báo cáo 4,3 binh sĩ Ukraine thiệt mạng.

[Phán quyết]: Đúng

[Lý do]: Politico đã không xuất bản một bài báo nói rằng cái chết của 20 triệu người Ukraine là cần thiết để thắng Nga năm 2019.... Báo cáo này không thể được tìm thấy khi tìm kiếm qua các tài khoản mạng xã hội của Politico năm 2019.

### Nhập gợi ý Si

Dựa trên các ví dụ đã cho, kiểm chứng sự thật của tuyên bố sau bằng cách sử dụng bằng chứng. Chú ý đặc biệt đến các khoảng số trong tuyên bố và bằng chứng, kiểm chứng sự thật bằng cách suy nghĩ từng bước và đưa ra nhân bằng cách thực hiện suy luận hội nhập. Phân loại toàn bộ tuyên bố một cách nghiêm ngặt vào một trong các danh mục sau: ĐÚNG, SAI hoặc MÀU THUẦN.

[Khẳng định]: Kiều hối của người hải ngoại “hiện đang ở mức cao kỷ lục trên 400 tỷ KSH vào năm 2021”. [Bằng chứng]: Kiều hối của người hải ngoại đã mạnh mẽ trong năm 2021, với tổng kiều hối trong năm 2021 đạt kỷ lục 3.718 triệu USD. Trả lời ở định dạng sau: [Nhân]: (HỖ TRỢ, PHỦ NHẬN hoặc MÀU THUẦN). [Lý do]:

Hình 10: Một ví dụ về lời nhắc để tạo dự đoán tính xác thực và chuỗi lập luận tương ứng cho một cặp tuyên bố và bằng chứng.

**Lời nhắc hệ thống:**

Bạn được giao nhiệm vụ tạo ra một bộ câu hỏi để phân tích và đánh giá tính xác thực của một tuyên bố kiểm chứng sự thật đã cho. Hãy tuân thủ các hướng dẫn nghiêm ngặt này khi tạo các câu hỏi phụ:

1. Phạm vi toàn diện: Các câu hỏi phụ nên bao quát đầy đủ tất cả các khía cạnh liên quan của tuyên bố để có thể kiểm tra sự thật một cách kỹ lưỡng.
2. Không trùng lặp: Đảm bảo không có sự chồng chéo giữa các câu hỏi phụ. Mỗi câu hỏi phải độc đáo về ý nghĩa và không lặp lại về mặt ngữ nghĩa.
3. Tính liên quan: Mỗi câu hỏi đều phải liên quan trong việc xác định tính xác thực của tuyên bố. Tránh các câu hỏi không liên quan hoặc ngoài lề.
4. Rõ ràng và ngữ pháp: Viết các câu hỏi một cách rõ ràng, súc tích và đúng ngữ pháp để duy trì sự rõ ràng.
5. Định dạng Có/Không: Mỗi câu hỏi phải có thể trả lời nghiêm ngặt bằng câu trả lời đơn giản "Có" hoặc "Không".

Hình 11: Lời nhắc hệ thống để tạo các câu hỏi phụ dựa trên một tuyên bố, tuân theo các tiêu chuẩn được định nghĩa trong bài báo CLAIMDECOMP.