

Giải thích các nguồn không chắc chắn trong kiểm tra sự thật tự động


Jingyi Sun* Greta Warren* Irina Shklovski Isabelle Augenstein
Đại học Copenhagen {jisu, grwa, ias, augenstein}@di.ku.dk

Tóm tắt

Hợp tác giữa con người và AI trong các nhiệm vụ đòi hỏi nhiều kiến thức như kiểm tra sự thật yêu cầu hiểu biết sự không chắc chắn của mô hình trong suy luận đa tài liệu giữa các bằng chứng mâu thuẫn/đồng thuận. Tuy nhiên, các phương pháp hiện có chỉ biểu thị sự không chắc chắn dưới dạng số liệu hoặc cách diễn đạt chung mà không cho thấy bằng chứng nào mâu thuẫn gây ra sự không chắc chắn, khiến người dùng không thể giải quyết các bất đồng. Chúng tôi trình bày CLUE (Giải thích Sự Không Chắc Chắn của Mô Hình Nhận Thức Mâu Thuẫn & Đồng Thuận), một khung làm việc trắng-bảo đính-kèm và dễ sử dụng mà theo hiểu biết của chúng tôi, là lần đầu tiên tạo ra các giải thích bằng ngôn ngữ tự nhiên về sự không chắc chắn của mô hình dựa trên bằng chứng mâu thuẫn/đồng thuận. CLUE (i) xác định các mối quan hệ giữa khẳng định-bằng chứng cấp đoạn và giữa các bằng chứng để chỉ ra mâu thuẫn hoặc đồng thuận mà không cần giám sát, và (ii) sử dụng các mối quan hệ này để điều hướng quá trình tạo giải thích, trình bày cách chúng tác động đến sự không chắc chắn của mô hình. Trên ba mô hình ngôn ngữ và hai bộ dữ liệu kiểm tra sự thật, CLUE tạo ra các giải thích theo dõi sự không chắc chắn của mô hình một cách trung thực hơn

1 Giới thiệu

Các Mô Hình Ngôn Ngữ Lớn (LLMs) ngày càng phổ biến trong việc hỗ trợ các nhiệm vụ quan trọng liên quan đến việc lý luận về độ tin cậy của thông tin, chẳng hạn như kiểm tra sự thật (Wang et al., 2024; Fontana et al., 2025). Để thúc đẩy việc sử dụng hiệu quả các mô hình như vậy trong các nhiệm vụ kiểm tra sự thật, các mô hình này phải giải thích



Hình 1: Một ví dụ về kết quả đầu ra của CLUE cho một tuyên bố với hai đoạn bằng chứng: kết luận và độ tin cậy của mô hình, cùng với giải thích về sự không chắc chắn dựa trên tương tác giữa các đoạn xung đột/đồng ý.

cơ sở lý luận cho các dự đoán của họ (Atanasova et al., 2020; Kotonya và Toni, 2020).

Tuy nhiên, các phương pháp hiện tại trong việc kiểm tra sự thật tự động đã bị chỉ trích vì không phù hợp với nhu cầu thực tiễn của những người kiểm tra sự thật, những người phải đánh giá độ tin cậy của nguồn và hòa giải các bằng chứng mâu thuẫn, thay vì chỉ dự đoán nhãn phán quyết (Warren et al., 2025; Schlichtkrull et al., 2023). Các phương pháp hiện tại thường tạo ra các giải thích để biện minh cho dự đoán phán quyết (Atanasova et al., 2020; Stambach và Ash, 2020; Zeng và Gao, 2024), tuy nhiên, chúng không cung cấp hỗ trợ cho việc truyền đạt sự không chắc chắn của mô hình hoặc làm nổi bật các điểm đồng thuận và xung đột trong bằng chứng (Xem Hình 2). Các phương pháp biểu đạt sự không chắc chắn thì làm như vậy qua nu-

*Đóng góp ngang nhau.

Các điểm số meric (ví dụ: “Tôi tự tin 73%”) khó để đặt trong bối cảnh (Zimmer, 1983; Wallsten et al., 1993; van der Waa et al., 2020; Liu et al., 2020) hoặc thông qua các biểu thức ngôn ngữ tự nhiên (ví dụ: “Tôi không chắc chắn”) thường không phản ánh trung thực sự không chắc chắn của mô hình và có thể làm tăng cảm nhận về sự tự tin (Steyvers et al., 2025; Yona et al., 2024; Kim et al., 2024). Do đó, các hệ thống kiểm tra sự thật có thể giải thích hiện có thường thể hiện hai hạn chế: (1) bỏ qua việc truyền đạt sự không chắc chắn của mô hình thông qua các giải thích và (2) không làm nổi bật các mâu thuẫn và sự đồng thuận bằng chứng góp phần tạo ra sự không chắc chắn của mô hình. Điều này tạo thành một khoảng trống phương pháp cơ bản, vì kiểm tra sự thật hiệu quả đòi hỏi xác định chính xác các nguồn gây không chắc chắn, ví dụ, từ bằng chứng mâu thuẫn, để hướng dẫn việc xác minh mục tiêu (Graves, 2017; Micallef et al., 2022).

Để thu hẹp khoảng cách này, chúng tôi đề xuất CLUE, một quy trình tạo ra các giải thích ngôn ngữ tự nhiên (NLEs) về sự không chắc chắn của mô hình bằng cách nắm bắt rõ ràng các xung đột và sự đồng thuận trong đầu vào (ví dụ, một tuyên bố và các bằng chứng hỗ trợ hoặc phản bác nó), xem Hình 1. Quy trình này trước tiên xác định các tương tác cấp đoạn nổi bật, có vai trò quan trọng đối với dự đoán của mô hình thông qua một phương pháp không giám sát, cung cấp một giải thích về đặc trưng đầu vào nhấn mạnh các mối quan hệ chính giữa các đoạn đầu vào riêng biệt, ví dụ, tuyên bố và bằng chứng (Ray Choudhury et al., 2023). Các nghiên cứu trước đây đã chỉ ra rằng những tương tác này trung thực với mô hình và hợp lý đối với con người (Sun et al., 2025, 2026). CLUE sau đó chuyển các tín hiệu này thành các giải thích có nhận thức về sự không chắc chắn bằng cách trực tiếp tham chiếu đến các tương tác, các quan hệ xung đột/đồng thuận mà chúng biểu thị, và cách chúng đóng góp vào sự không chắc chắn liên quan đến phán quyết. CLUE không yêu cầu các giải thích gán nhãn vàng hay tinh chỉnh, và hoạt động một cách hiệu quả.

Trên ba mô hình ngôn ngữ (§3.2) và hai tập dữ liệu kiểm tra sự thật (§3.1), chúng tôi đánh giá hai biến thể của CLUE, vốn sử dụng các phương pháp khác nhau để hướng dẫn việc tạo NLE dựa trên các mâu thuẫn/đồng thuận chính được trích xuất (§2.4). Đánh giá tự động cho thấy cả hai biến thể đều tạo ra các giải thích trung thực hơn với sự không chắc chắn của từng mô hình và đồng thuận chặt chẽ hơn với các nhãn kiểm tra sự thật tiêu chuẩn so với một phương pháp nhắc nhở không có hướng dẫn về mâu thuẫn/đồng thuận (§4.5). Người tham gia nghiên cứu cũng đánh giá các giải thích của CLUE là hữu ích hơn, nhiều thông tin hơn, ít thừa lặp hơn và logic hơn so với dữ liệu đầu vào.

cũng quan sát thấy một sự đánh đổi giữa hai biến thể của khung ourCLUE của chúng tôi, một biến thể đạt được độ trung thực cao hơn, biến thể còn lại đạt được tính hợp lý cao hơn, làm nổi bật một hướng đi đầy hứa hẹn cho công việc trong tương lai để đạt được cả hai cùng lúc (§4.5).

2 Phương pháp

2.1 Các bước chuẩn bị và Khung tổng thể

Mục tiêu của chúng tôi là giải thích lý do tại sao một mô hình ngôn ngữ lớn (LLM) lại không chắc chắn về một trường hợp kiểm tra sự thật dựa trên nhiều bằng chứng bằng cách liên kết sự không chắc chắn đó với các sự đồng thuận hoặc mâu thuẫn cụ thể trong đầu vào.

Thiết lập vấn đề. Mỗi trường hợp đầu vào là một bộ ba $X = (C, E_1, E_2)$ gồm một tuyên bố C và hai bằng chứng E_1, E_2 . Trong nghiên cứu này, chúng tôi khám phá các kịch bản trong đó một tuyên bố và hai hoặc ba bằng chứng được trình bày.¹ Để rõ ràng, chúng tôi ký hiệu việc kết hợp của chúng là $X = [x_1, \dots, x_{|C|+|E_1|+|E_2|}]$. Nhãn nhiệm vụ được lấy từ tập $\mathcal{Y} = \{\text{HỖ TRỢ, PHỦ NHẬN, TRUNG LẬP}\}$.

Tổng quan về quy trình. Khung của chúng tôi bao gồm ba giai đoạn:

1. Đánh giá độ không chắc chắn. Chúng tôi tính toán entropy dự đoán từ các logit câu trả lời của mô hình để thu được một điểm số độ không chắc chắn dạng vô hướng $u(X)$ (§ 2.2). Biện pháp dựa trên logit này không phụ thuộc vào mô hình.
2. Trích xuất xung đột/đồng thuận. Chúng tôi nắm bắt các sự đồng thuận và xung đột có liên quan nhất đến lý luận của mô hình bằng cách xác định các tương tác khoảng văn bản giữa C, E_1 và E_2 đại diện cho các quan hệ này (§ 2.3).
3. Tạo giải thích. Mô hình nhận các khoảng trích xuất này như các ràng buộc mềm và tạo ra một giải thích ngôn ngữ tự nhiên $Y_R = [y'_1, \dots, y'_r]$ cùng với nhãn dự đoán $\hat{y}$ cho các tương tác đã xác định (§ 2.4).

Kết quả. Đối với mỗi trường hợp X , khung công tác trả về nhãn tác vụ dự đoán $\hat{y} \in \mathcal{Y}$; điểm không chắc chắn số $u(X)$; và giải thích bằng văn bản $Y_R = [y'_1, \dots, y'_r]$ giải thích nguồn gốc của sự không chắc chắn trong các sự thống nhất hoặc mâu thuẫn cụ thể giữa C, E_1, E_2 .

2.2 Tạo Điểm Không Chắc Chắn Dự Đoán

Để định lượng độ không chắc của mô hình trong việc tạo nhãn câu trả lời trên một chuỗi đầu vào cụ thể, chúng tôi theo dõi

¹ Vì khung của chúng tôi dựa trên tương tác phần đầu vào theo cặp, nó có thể dễ dàng áp dụng cho các kịch bản có nhiều yêu cầu và các mảnh bằng chứng hơn.

Công trình trước đây: giải thích hướng về phán quyết			Công trình này: giải thích hướng tới sự không chắc chắn	
Sắc diện tử	Giải thích-MT	JustiLM	CLUE	
Đầu vào Kháng định: Colin Kaepernick là một người chơi poker người chơi. Bằng chứng: Colin Kaepernick + Colin Rand Kaepernick là một cầu thủ bóng bầu dục Mỹ đội trưởng tấn công hiện đang là cầu thủ tự do đại lý.	Đầu vào Yêu cầu: Trong số hơn 1,3 triệu các sửa đổi tạm thời về thể chấp, trên một nửa đã vỡ nợ. Bằng chứng: Rubio nói "hơn một nửa đã bây giờ mặc định," đề cập đến tạm thời chương trình điều chỉnh khoản vay thể chấp	Đầu vào Kháng định: Biden: Các nhà sản xuất súng đang "ngăn cản công nghiệp duy nhất trong nước" đó được miễn trừ khỏi các vụ kiện Bằng chứng 1: Không, bạn không thể kiện Pfizer ... Bằng chứng 2: Nhận xét của Tổng thống Biden về Ngăn chặn Bảo lực Súng đạn ...	Đầu vào Kháng định: Các nê ở Nam Cực, nhưng vị trí và khí hậu của lục địa ối nhanh chóng do... Bằng chứng: Bằng chứng 1: Không chính xác về mặt thực tế: Không có của các nền văn minh cổ đại... Bằng chứng 2: Nam Cực từ đạt đến...	
Đầu ra Phán quyết: Sai Giải thích: Colin Kaepernick là một cầu thủ bóng đá, không phải người chơi poker.	Đầu ra Phán quyết: Một nửa đúng Giải thích: Rubio cũng nói "Hơn 1,3 triệu buổi tập tạm thời, hơn một nửa hiện đã vỡ nợ"	Đầu ra Phán quyết: Sai Giải thích: Biden nói rằng súng các nhà sản xuất đại diện cho duy nhất ngành công nghiệp ở Mỹ được miễn bị kiện.	Đầu ra Phán quyết: Sai Độ chắc chắn: 44% Giải thích: Bằng chứng 1, "không có i" nên văn minh..." không đồng ý với tuyên bố "các cư trú...". Điều này làm suy yếu ... Thỏa thuận giữa Bằng chứng 1 và Bằng chứng 2, "địa" "chuyển động" và ii", cũng có sự đồng thuận ...	
Trích dẫn bằng chứng cụ thể Nhiều tài liệu chứng cứ Phản ánh xung đột và sự đồng thuận Trung thành với lý luận theo mô hình Giải thích sự không chắc chắn	Trích dẫn bằng chứng cụ thể Nhiều tài liệu chứng cứ Phản ánh xung đột và sự đồng thuận Trung thành với lý luận theo mô hình Giải thích sự không chắc chắn	Trích dẫn bằng chứng cụ thể Nhiều tài liệu chứng cứ Phản ánh xung đột và sự đồng thuận Trung thành với lý luận theo mô hình Giải thích sự không chắc chắn	Trích dẫn bằng chứng cụ thể Nhiều tài liệu chứng cứ Phản ánh xung đột và sự đồng thuận Trung thành với lý luận theo mô hình Giải thích sự không chắc chắn	

Hình 2: So sánh minh họa các giải thích kiểm chứng sự thật theo hướng phán quyết (e-FEVER (Stammbach và Ash, 2020), Explain-MT (Atanasova và cộng sự, 2020), JustiLM (Zeng và Gao, 2024)) và các giải thích theo hướng không chắc chắn của CLUE. Trong so sánh này, CLUE là phương pháp duy nhất theo dõi rõ ràng sự không chắc chắn của dự đoán liên quan đến xung đột/đồng thuận giữa tuyên bố và bằng chứng cũng như giữa các bằng chứng qua nhiều đoạn bằng chứng.

Các công trình trước đây (Kadavath et al., 2022; Yang và cộng sự, 2025) và tính toán độ bất định dự đoán bằng lý thuyết ent-tropy, không yêu cầu chạy nhiều lần và được sử dụng rộng rãi trong các mô hình mã nguồn mở.

Cụ thể, chúng tôi định nghĩa điểm không chắc chắn số u là entropy của phân phối softmax trên các logits đầu ra của mô hình cho một tập hợp các câu trả lời ứng viên $\mathcal{Y} = \{\text{HỖ TRỢ, PHỦ NHẬN, TRUNG LẬP}\}$. Đối với mỗi nhãn ứng viên $y_i \in \mathcal{Y}$:

$$P(y_i | X) = \frac{\exp(\text{logit}(y_i))}{\sum_{j=1}^{|\mathcal{Y}|} \exp(\text{logit}(y_j))} \quad (1)$$

trong đó $\text{logit}(y_i)$ là logit đầu ra của mô hình đối với câu trả lời ứng viên y_i khi nhận đầu vào X .

$P(y_i | X)$ là điểm tự tin của mô hình khi chọn y_i làm câu trả lời cuối cùng trong tất cả các câu trả lời ứng viên trong $\mathcal{Y}$. Cuối cùng, độ không chắc chắn của mô hình đối với chuỗi đầu vào X là:

$$u(X) = - \sum_{y_i \in \mathcal{Y}} P(y_i | X) \log P(y_i | X) \quad (2)$$

2.3 Xác định Tương tác Phạm vi Mâu thuẫn và Thỏa thuận cho Sự không chắc chắn của Câu trả lời

Để làm nổi bật các xung đột và sự đồng thuận dẫn đến sự không chắc chắn của một mô hình, chúng tôi trích xuất và sau đó gán nhãn các tương tác đoạn văn nổi bật giữa tuyên bố C và hai đoạn chứng cứ, E_1 và E_2 .

Trích xuất tương tác khoảng. Đối với mỗi cặp phần đầu vào có thứ tự $(F, T) \in \{(C, E_1), (C, E_2), (E_1, E_2)\}$, chúng tôi theo công trình trước đây (Ray Choudhury et al., 2023; Sun et al.,

2025) để trích xuất các tương tác khoảng quan trọng và điểm quan trọng của chúng đối với câu trả lời của mô hình bằng cách (i) xác định đầu chú ý quan trọng nhất đối với dự đoán câu trả lời của mô hình từ lớp cuối cùng của nó, (ii) lấy ma trận chú ý của nó $A \in \mathbb{R}^{(|F|+|T|) \times (|F|+|T|)}$, và (iii) đối xứng hóa điểm chéo $a'_{p,q}$ cho mỗi tương tác token có thể (x_p, x_q) trong (F, T) :

$$a'_{p,q} = \frac{1}{2} (A_{p,q} + A_{q,p}), \quad x_p \in F, x_q \in T.$$

Dựa trên các tương tác token này, chúng tôi xem mỗi $a'_{p,q}$ như một trọng số cạnh trong một đồ thị token hai phía giữa hai phần đầu vào (F, T) . Sau đó, thuật toán Louvain (Blondel et al., 2008) được áp dụng để tìm kiếm các cộng đồng token với mối quan hệ mật độ cao bên trong cụm và thưa thớt giữa các cụm. Từ mỗi cộng đồng token được phát hiện, một tương tác span, (span_w , span_v), có thể được trích xuất bằng cách xem các token lân cận của cùng một phần đầu vào, F và T , tương ứng, như một span. Bằng cách lấy trung bình điểm quan trọng token $a'_{p,q}$ của mỗi tương tác token trong (span_w , span_v), điểm quan trọng của nó a_{wv} có thể được xác định bằng

$$a_{wv} = \frac{1}{|\text{span}_w| |\text{span}_v|} \sum_{x_p \in \text{span}_w} \sum_{x_q \in \text{span}_v} a'_{p,q}. \quad (3)$$

Các tương tác đã được ghi điểm cho (F, T) tạo thành $S^{(F,T)} = \{((\text{khoảng}_w, \text{khoảng}_v) a_{wv})\}$.

Gán nhãn quan hệ. Gán mỗi tương tác phạm vi như đồng ý, không đồng ý, hoặc không liên quan, chúng tôi sử dụng một bộ gán nhãn quan hệ L_{rel} có thể được khởi tạo với LLM trọng số mở hoặc đóng. L_{rel}

nhận toàn bộ ngữ cảnh (C, E_1, E_2) cùng với một cặp khoảng ứng viên và xuất ra một nhãn trong {đồng ý, không đồng ý, không liên quan}. Chúng tôi triển khai điều này bằng cách sử dụng một lệnh nhắc (xem Phụ lục C.1) và báo cáo mô hình gắn nhãn trong Phần 3.2.

Sau khi gán nhãn tất cả ba cặp, tập hợp tương tác đầy đủ cho ví dụ X là

$$S_R = S_R^{(C, E_1)} \cup S_R^{(C, E_2)} \cup S_R^{(E_1, E_2)}, \quad (4)$$

nơi mà, ví dụ, $S_R^{(C, E_1)} = \{(a_{wv}, r_{wv})\}_R$. Mỗi phần tử kết nối hai khoảng với một điểm quan trọng và một nhãn quan hệ, do đó cung cấp các tương tác khoảng xung đột hoặc đồng thuận được sử dụng trong các giai đoạn sau.

2.4 Tạo câu giải thích ngôn ngữ tự nhiên về sự không chắc chắn

Để chuyển đổi các tương tác khoảng cách xung đột và thỏa thuận đã được trích xuất thành các giải thích cho sự không chắc chắn của mô hình, chúng tôi dựa vào hai cơ chế bổ sung nhau. (i) Dẩy theo hướng dẫn những các khoảng cách t rục tiếp vào đầu vào để mô hình được chỉ dẫn đầu là các đoạn cần tham chiếu. (ii) Điều khiển chú ý nội tại hướng sự chú ý của mô hình về các đoạn tương tự trong khi nó đang tạo ra NLE. Cả hai cơ chế đều sử dụng tự biện minh: mô hình trước tiên đưa ra phán quyết $\hat{y}$ và sau đó giải thích Y_R , một trình tự được chứng minh là cải thiện sự trung thực so với các phương pháp theo pipeline (Wiegrefe et al., 2021; Marasovic et al., 2022; Siegel et al., 2025).

NLE theo hướng chỉ dẫn. Đối với mỗi trường hợp X , chúng tôi xếp hạng tất cả các tương tác đã gán nhãn theo điểm quan trọng giảm dần và giữ lại $k = 3$ hàng đầu, ký hiệu $S_R(k)$, để tránh giải thích quá dài. Ba cặp khoảng này được chèn vào một lời nhắc ba ví dụ (Xem Phụ lục G.1), hướng dẫn mô hình giải thích cách các thỏa thuận hoặc xung đột được đánh dấu ảnh hưởng đến mức độ tự tin của nó. Cuối cùng, quá trình giải mã chuẩn của transformer tạo ra cả nhãn dự đoán $\hat{y}$ và phần giải thích kèm theo Y_R .

Điều khiển chú ý. Thay vì các hướng dẫn rõ ràng, chúng ta có thể hướng dẫn việc tạo NLE bằng cách điều chỉnh chú ý ngay lập tức theo phương pháp điều khiển chú ý trong PASTA (Zhang et al., 2024b). Bắt đầu từ cùng một $S_R(k)$, chúng ta thu thập tất cả các chỉ số token nằm trong bất kỳ phạm vi nào được chọn,

$$\mathcal{I} = \{p : (\text{span}_w, \text{span}_v) \in S_R(k), p \in \text{span}_w \cup \text{span}_v\}. \quad (5)$$

Đối với mỗi đầu attention (ℓ, h) được coi là liên quan đến độ bất định của mô hình, hãy để A là ma trận attention của nó. Chúng tôi giảm trọng số các token không phải mục tiêu bằng β :

$$\tilde{A}_{ij} = \frac{A_{ij}}{Z_i} \begin{cases} 1 & \text{if } j \in \mathcal{I}, \\ \beta & \text{otherwise,} \end{cases} \quad (6)$$

$$Z_i = \sum_{j \in \mathcal{I}} A_{ij} + \beta \sum_{j \notin \mathcal{I}} A_{ij}. \quad (7)$$

Tất cả các đầu khác giữ nguyên. Theo Zhang và cộng sự (2024b), chúng tôi điều hướng $|H| = 100$ đầu và đặt $\beta = 0.01$ để cân bằng hiệu quả điều hướng và ngăn ngừa thoái hóa; xem Phụ lục B để biết quy trình chọn đầu. Với sự chú ý được điều hướng, bộ chuyển đổi sinh ra $\hat{y}$ tiếp theo là lý do Y_R , bây giờ tự nhiên tập trung vào các đoạn xung đột hoặc đồng thuận gây ra sự không chắc chắn của nó.

3 Thiết lập Thí nghiệm

3.1 Bộ dữ liệu

Chúng tôi chọn hai bộ dữ liệu kiểm chứng thông tin, một bộ dữ liệu cụ thể cho lĩnh vực y tế, HealthVer (Sarrouiti et al., 2021), và một bộ dữ liệu gần với kịch bản kiểm chứng thông tin trong thế giới thực hơn, DRUID (Hagström et al., 2024). Những bộ dữ liệu này được chọn vì chúng cung cấp nhiều bằng chứng cho mỗi tuyên bố, làm cho chúng phù hợp với mục tiêu của chúng tôi là giải thích sự không chắc chắn của mô hình phát sinh từ các xung đột và thỏa thuận giữa các bằng chứng. Trong các thí nghiệm, chúng tôi chọn sáu trăm trường hợp bao gồm một tuyên bố và nhiều bằng chứng, cùng với nhãn chuẩn $y \in \{\text{HỖ TRỢ, PHỦ NHẬN, TRUNG LẬP}\}$ từ mỗi bộ dữ liệu.²

3.2 Mô hình

Chúng tôi so sánh ba chiến lược sinh cho NLE của sự không chắc chắn mô hình:

- PromptBaseline: Một cơ sở gợi ý ba bước mở rộng các công trình NLE vài bước trước đó (Stammach và Ash, 2020; Zeng và Gao, 2024; Zhao et al., 2024) bằng cách yêu cầu mô hình xác định rõ các đoạn mâu thuẫn hoặc hỗ trợ ảnh hưởng đến sự không chắc chắn của nó (xem mẫu gợi ý trong Phụ lục G.1).
- CLUE-Span: Biến thể theo hướng dẫn của phương pháp CLUE của chúng tôi, trong đó các tương tác phạm vi được trích xuất sẽ được điền vào một prompt ba ví dụ để hướng dẫn việc sinh giải thích (§2.4; Phụ lục G.2).

²Trong khi DRUID có sáu nhãn kiểm tra sự thật chi tiết, chúng tôi hợp nhất các nhãn này thành ba loại trên để cân bằng các loại nhãn.

- CLUE-Span+Lái hướng: Biến thể lái hướng chú ý của phương pháp CLUE của chúng tôi, trong đó sử dụng cùng một lời nhắc như CLUE-Span. Lái hướng chú ý bổ sung được áp dụng để hướng dẫn một cách bản năng việc tạo giải thích của mô hình về các đoạn đã xác định (§2.4; Phụ lục G.2).

Chúng tôi tiến hành các thí nghiệm chính trên nhiều LLM trọng lượng mở gần đây có quy mô tương đương: Qwen2.5-14B-Instruct (Nhóm Qwen, 2024), Gemma-2-9B-IT (Nhóm Gemma, 2024), và OLMo-2-1124-13B-Instruct (Nhóm OLMo et al., 2025) và DeepSeek-R1-Distill-Qwen-14B (DeepSeek-AI) (thẻ mô hình trong Phụ lục D). Mỗi mô hình cơ sở được chạy qua CLUE trên một GPU NVIDIA A100-SXM 80GB duy nhất; chúng tôi chọn các mô hình này để cân bằng khả năng làm theo hướng dẫn/ lý luận với hiệu quả suy luận (xem báo cáo chi phí trong Phụ lục E).

Đối với việc gán nhãn quan hệ tương tác span, chúng tôi khởi tạo L_{rel} với GPT-4o (Nhóm OpenAI, 2024) để giảm nhiễu nhãn quan hệ (xem Phụ lục C.3 để phân tích lỗi lan truyền). Bước này là tùy chọn: thay L_{rel} bằng Qwen2.5-14B-Instruct có trọng số mở cho ra chất lượng NLE đầu ra tương đương với một mô hình giảm nhẹ (Phụ lục C.2); chúng tôi thảo luận về tính mô-đun này và các hướng đi tương lai trong phần Hạn chế.

4 Đánh giá Tự động

4.1 Lòng trung thành

Để đánh giá xem các NLE do CLUE tạo ra có phản ánh trung thực sự không chắc chắn của mô hình hay không, chúng tôi điều chỉnh Kiểm tra Phản Thực Tương Quan (CCT) (Siegel et al., 2024) và đề xuất Entropy-CCT. Entropy-CCT giữ lại thiết kế perturb-and-correlate của CCT, nhưng thay thế sự thay đổi xác suất câu trả lời của mô hình (ví dụ, TVD) bằng thay đổi entropy dự đoán để trực tiếp nhắm tới sự không chắc chắn, là đối tượng mà các NLE của chúng tôi nhằm giải thích (xem Phụ lục F.2 để so sánh).

Theo Siegel và cộng sự (2024), đối với mỗi trường hợp X chúng tôi xây dựng n các phép biến động X' bằng cách chèn một từ bổ nghĩa ngẫu nhiên (tính từ trước danh từ, hoặc trạng từ trước động từ; Phụ lục F.1). Gọi $u(X)$ là điểm không chắc chắn của mô hình được định nghĩa theo Phương trình 2. Chúng tôi đo ảnh hưởng của phép biến động lên độ không chắc chắn bằng Thay Đổi Entropy Tuyệt đối (AEC):

$$\Delta u(X) = |u(X) - u(X')|. \quad (8)$$

Đối với mỗi nhiễu loạn X' , chúng tôi cũng ghi lại liệu từ được chèn có xuất hiện trong NLE được tạo ra hay không, sử dụng sự xuất hiện của nó như một chỉ số thay thế cho tầm quan trọng. Điều này tạo ra một cờ nhắc nhở nhị phân $m \in \{0, 1\}$ (Siegel et al., 2024; Atanasova et al., 2023).

Gọi D_m là tập hợp các ví dụ bị thay đổi mà trong đó NLE đề cập đến từ được chèn và D_{-m} là tập hợp bổ sung mà trong đó nó không đề cập. Chúng tôi tính toán hệ số tương quan điểm-nhị phân r_{pb} (Tate, 1954) giữa biến liên tục Δu và cờ nhị phân m trên tất cả các thay đổi. Thống kê Entropy-CCT là:

$$CCT_{entropy} = r_{pb} = \frac{\mathbb{E}_m[\Delta u] - \mathbb{E}_{-m}[\Delta u]}{\text{Std}(\Delta u)} \cdot \sqrt{\frac{|D_m| \cdot |D_{-m}|}{(|D_m| + |D_{-m}|)^2}}. \quad (9)$$

Ở đây, $\mathbb{E}_m[\Delta u]$ và $\mathbb{E}_{-m}[\Delta u]$ là giá trị trung bình AEC của hai nhóm, và $\text{Std}(\Delta u)$ là độ lệch chuẩn trên tất cả các biến đổi. Entropy-CCT cao hơn cho thấy NLE thường nhắc đến các token mà việc chèn chúng gây ra những thay đổi lớn hơn trong độ không chắc chắn dự đoán, và do đó phản ánh chính xác hơn độ không chắc chắn của mô hình.

4.2 Phạm vi che phủ

Một giải thích về sự không chắc chắn nên hiển thị tất cả thông tin do các tương tác khoảng c họn lựa truyền đạt. Do đó, chúng tôi tính Phủ sóng Khoảng chọn: tỉ lệ các tương tác tham chiếu được nêu rõ ràng trong NLE được tạo ra. Gọi S_{NLE} là tập hợp các tương tác khoảng được trích xuất từ giải thích, và gọi $S_R(k)$ là tập hợp tham chiếu được cung cấp trong lời nhắc (Xem §2.4). Sau đó

$$\text{Span-Coverage} = \frac{|S_{NLE} \cap S_R(k)|}{|S_R(k)|}. \quad (10)$$

Một giá trị cao hơn cho thấy NLE bao phủ một tỷ lệ cao hơn của thông tin được cung cấp bởi các tương tác phạm vi đã trích xuất.

4.3 Phạm vi-Không liên quan

Lý tưởng nhất, phần giải thích chỉ nên đề cập đến các tương tác được cung cấp và tránh đưa vào các thông tin không liên quan. Chúng tôi đo tỉ lệ các tương tác được nhắc đến nhưng không thuộc tập tham chiếu, ký hiệu là Span-Extraneous:

$$\text{Span-Extraneous} = \frac{|S_{NLE} \setminus S_R(k)|}{|S_{NLE}|}. \quad (11)$$

Giá trị thấp hơn cho thấy sự phù hợp gần hơn với các tương tác khoảng cách dự kiến.

4.4 Liên hệ giữa Nhãn và Giải thích

Chúng tôi đánh giá mức độ mà lời giải thích về sự không chắc chắn đồng ý với nhãn dự đoán của mô hình bằng cách hình thành nhiệm vụ như một vấn đề suy luận ngôn ngữ tự nhiên (NLI). Trước tiên, chúng tôi chuyển nhãn dự đoán thành một giả thuyết bằng cách sử dụng mẫu

“Mệnh đề được chứng minh bởi / bị bác bỏ bởi / trung lập với bằng chứng.” Giải thích được tạo ra đóng vai trò làm tiền đề. Cặp tiền đề–giả thuyết kết quả được đưa vào mô hình suy luận ngôn ngữ có sẵn rộng rãi, DeBERTa-v3 (He et al., 2023). Điểm Label-Explanation Entailment (LEE) là tỉ lệ các ví dụ mà mô hình NLI dự đoán là ENTAILMENT.

4.5 Kết quả

Ở đây, chúng tôi trình bày kết quả đánh giá NLE tự động của chúng tôi cho kịch bản mà đầu vào bao gồm một Yêu cầu và hai mảnh Bằng chứng³. Để ngắn gọn, chúng tôi gọi Qwen2.5-14B-Instruct, OLMo-2-1124-13B-Instruct, và Gemma-2-9B- lần lượt là Qwen, OLMo và Gemma⁴.

Tính trung thành. Chúng tôi sử dụng Entropy-CCT, một tương quan điểm-nhị phân r_{pb} (Phương trình 9) bị giới hạn bởi $[-1, 1]$ để đo mức độ trung thành của NLEs với độ không chắc chắn của mô hình (§4.1). Khi $r_{pb} = 0$, phần giải thích đề cập đến các từ biến động có tác động cao và thấp một cách đều nhau; mỗi $+0.01$ sẽ tăng khoảng một điểm phần trăm (pp) khả năng phần giải thích nêu tên một token thực sự có ảnh hưởng đến độ không chắc chắn dự đoán của mô hình (Phụ lục F.3).

Bảng 1 cho thấy rằng Prompt_{Baseline} không đáng tin cậy trong tất cả sáu thiết lập với tất cả các giá trị r_{pb} đều âm, dao động từ -0.03 đến -0.13 . Do đó, các NLE của nó đề cập đến những token thực sự có ảnh hưởng ít hơn 3–13 điểm phần trăm so với các token không có ảnh hưởng — ngược lại với hành vi đáng tin cậy. Cả hai biến thể của CLUE của chúng tôi đều đảo ngược xu hướng này. Việc trình bày tương tác khoảng trong prompt (CLUE-Span) nâng mọi hệ số tương quan lên giá trị không âm và đạt đỉnh tại $r_{pb} = 0.089$ trong thiết lập DRUID–Qwen. Điều này có nghĩa là lời giải thích bây giờ được đề cập thường xuyên hơn khoảng 17 điểm phần trăm so với Prompt_{Baseline} ($r_{pb} = -0.080$). Thêm điều hướng attention (CLUE-Span+Steering) nâng các điểm r_{pb} lên 0,033 trên HEALTHVER và 0,102 trên DRUID với mô hình Qwen, tức là lợi ích ròng +6 điểm phần trăm và +18 điểm phần trăm so với Prompt_{Baseline}. Hơn nữa, bốn trong sáu hệ số tương quan dương do CLUE-Span+Steering tạo ra là đáng kể ở mức $p < 0.01$ (Bảng 7 trong Phụ lục F.3), xác nhận rằng những cải thiện này vừa đáng kể vừa có độ tin cậy thống kê. Những nhảy vọt đặc biệt lớn của OLMo trên bộ dữ liệu Druid (tối đa $\Delta r_{pb} = +0.23 \approx +23$ điểm phần trăm)

³Xem các thí nghiệm với ba mảnh bằng chứng trong Phụ lục H.1⁴Xem các thí nghiệm về mô hình lập luận DeepSeek-R1-Distill-Qwen-14B trong Phụ lục H.2

Khung công tác có lợi nhất cho các mô hình ban đầu gặp khó khăn trong việc điều chỉnh các giải thích với sự không chắc chắn của chúng.

Các Thuộc Tính Khác Chúng tôi đánh giá ba thuộc tính bổ sung của các NLE được tạo ra: (i) Span-Coverage: Độ bao phủ của các tương tác xung đột/thỏa thuận- đã được trích xuất (§4.2), (ii) Span-Extraneous: việc đề cập đến các span không được trích xuất (§4.3), và (iii)

Label-Explanation Entailment với nhãn kiểm tra sự thật được tạo ra (§4.4). Như Bảng 1 cho thấy, CLUE-Span+Steering vượt trội hơn CLUE-Span cả về Span-Coverage và Span-Extraneous, phù hợp với hiệu quả của phương pháp điều hướng chú ý trong việc hướng mô hình tập trung vào các span được cung cấp trong quá trình tạo ra (Zhang et al., 2024b). Tuy nhiên, các con số tuyệt đối vẫn còn khiêm tốn (đỉnh Span-Coverage: 0,44, Span-Extraneous: 0,20 với Qwen). Một Span-Coverage bằng 1 có nghĩa là NLE trích dẫn tất cả các tương tác đã được trích xuất, trong khi điểm Span-Extraneous bằng 0 có nghĩa là nó không thêm bất kỳ span nào ngoài chúng. Khoảng cách này nhấn mạnh khoảng trống đáng kể để tích hợp tốt hơn các tương tác span quan trọng vào giải thích. Trong ba khung xương, Qwen đạt được Span-Coverage cao nhất và

5 Đánh giá con người

5.1 Phương pháp

Chúng tôi đã tuyển dụng N=12 người tham gia từ Prolific (<https://www.prolific.com/>) để đánh giá 120 giải thích được tạo ra bởi Prompt_{Baseline}, CLUE-Span, CLUE-Span+Steering cho 40 tuyên bố độc đáo (20 từ DRUID, 20 từ HealthVer) (xem chi tiết về người tham gia và thiết lập trong Phụ lục I.1). Tham khảo Atanasova và cộng sự (2020), người tham gia xếp hạng các giải thích theo thứ tự giảm dần (1^{st} , 2^{nd} , 3^{rd}) theo năm tiêu chí, bổ sung cho các chỉ số đánh giá tự động của chúng tôi:

- Tính hữu ích. Phần giải thích cung cấp thông tin giúp người đọc kiểm tra tính xác thực của tuyên bố.
- Phạm vi. Giải thích nêu bật tất cả thông tin nổi bật trong đầu vào có liên quan đến

Mô hình	Phương pháp	HealthVer				TU SĨ RỪNG			
		Niềm tin ↑	Cov. ↑	Ngoại cảnh. ↓	LEE. ↑	Niềm tin. ↑	Cov. ↑	Ngoại cảnh. ↓	LEE. ↑
Qwen2.5-14B	Nhắc nhở _{Baseline}	-0.028	<i>n/a</i>	<i>n/a</i>	0.74	-0.080	<i>n/a</i>	<i>n/a</i>	0.60
	CLUE-Khoảng cách	0.006	0.33	0.68	0.75	0.089	0.20	0.38	0.78
	CLUE-Span+Lái	0.033	0.44	0.53	0.80	0.102	0.28	0.20	0.77
OLMo-2-1124-13B	Nhắc nhở _{Baseline}	-0.100	<i>n/a</i>	<i>n/a</i>	0.55	-0.130	<i>n/a</i>	<i>n/a</i>	0.53
	CLUE-Khoảng cách	0.005	0.10	0.83	0.61	0.014	0.08	0.79	0.65
	CLUE-Span+Lái	0.020	0.23	0.77	0.68	0.099	0.15	0.70	0.69
Gemma-2-9B-IT	Nhắc nhở _{Baseline}	-0.105	<i>n/a</i>	<i>n/a</i>	0.66	-0.120	<i>n/a</i>	<i>n/a</i>	0.57
	CLUE-Span	0.007	0.34	0.59	0.82	0.043	0.23	0.43	0.76
	CHỈ DẪN-Span+Lái	0.021	0.39	0.50	0.85	0.098	0.30	0.47	0.81

Bảng 1: Đánh giá NLE tự động theo độ không chắc chắn. Giá trị cao hơn là tốt hơn đối với Faith (§4.1)/Cov. (§4.2)/LEE (§4.4) và giá trị thấp hơn là tốt hơn đối với Ext. (§4.3). *n/a* chỉ ra rằng Cov./Ext. không xác định được cho Prompt_{Baseline} vì không có đoạn tham chiếu nào được cung cấp. Kết quả tốt nhất theo từng chỉ số cho mỗi cặp bộ dữ liệu-mô hình được in đậm.

- kiểm tra sự thật, khác với Phạm vi-Giải thích (§4.2), cái đếm sự trùng lặp với các đoạn đã được trích xuất trước.
- Không thừa. Giải thích không cung cấp thông tin không liên quan hoặc lặp lại với dữ liệu đầu vào, khác với Span-Extraneous (§4.3) đếm các đề cập ngoài các khoảng được trích xuất.
 - Tính nhất quán. Phần giải thích chứa các phát biểu logic nhất quán với đầu vào, khác với Sự phù hợp giữa nhân và giải thích (Label-Explanation Entailment (§4.4)), đo lường sự phù hợp giữa nhân và giải thích.
 - Chất lượng tổng thể. Xếp hạng các giải thích bằng cách xem xét tất cả các tiêu chí ở trên.

5.2 Kết quả

Đánh giá của chúng tôi cho thấy các giải thích được tạo ra bởi CLUE luôn được ưa thích hơn so với Prompt_{Baseline} (Bảng 2). Tương tự như các nghiên cứu trước đây đã đánh giá NLEs (Atanasova et al., 2020; Huang et al., 2024; Solano et al., 2024), mức độ đồng thuận giữa các người đánh dấu dao động từ vừa đến thấp (Phụ lục I.2.1), điều mà chúng tôi cho là do độ phức tạp của nhiệm vụ.

Các giải thích được tạo ra bởi khung CLUE của chúng tôi được xếp hạng là ưu tiên hàng đầu của người tham gia trong 67-78% thời gian, so với 24-34% thời gian đối với Prompt_{Baseline}. Các giải thích do CLUE tạo ra được đánh giá là hữu ích nhất, chứa ít thông tin thừa nhất, có độ bao phủ, tính nhất quán và chất lượng tổng thể cao nhất gần như gấp đôi so với những giải thích được tạo ra bằng Prompt_{Baseline}.

Mặc dù cả CLUE-Span và CLUE-Span+Steering đều vượt trội hơn Prompt_{Baseline} trong các chỉ số tự động (§4.5) và được xếp hạng cao hơn Prompt_{Baseline} trong nghiên cứu trên con người (Bảng 11 trong Phụ lục I.2.2), chúng tôi quan sát thấy một sự đánh đổi nhẹ giữa độ trung thực và tính hợp lý khi so sánh

hai biến thể CLUE. CLUE-Span+Steering đạt được độ trung thực tự động cao nhất, trong khi CLUE-Span được xếp hạng hơi cao hơn về chất lượng tổng thể theo đánh giá con người. Một lý do có thể là CLUE-Span+Steering tuân thủ chặt chẽ các tương tác của top- $k=3$ span (với độ bao phủ Span cao hơn và độ dư thừa Span thấp hơn), điều này cải thiện độ trung thực nhưng có thể giảm độ mượt mà/tự nhiên khi một số phạm vi trích xuất bị rời rạc. Ngược lại, CLUE-Span có thể nắm bắt thêm các điểm mà người tham gia cho là quan trọng, nhưng không được các tương tác phạm vi trích xuất ghi nhận (Ray Choudhury và cộng sự, 2023). Mô hình này phù hợp với sự đánh đổi đã được ghi nhận rõ giữa độ trung thực và khả năng tin cậy (Agarwal và cộng sự, 2024; Atanasova và cộng sự, 2023; Lu và Ma, 2024), và kêu gọi các nghiên cứu trong tương lai để cải thiện cả hai khía cạnh nhằm nâng cao việc tạo NLE, ví dụ, bằng cách cải thiện chất lượng các tương tác phạm vi trích xuất.

6 Công trình liên quan

6.1 Định lượng sự bất định trong các Mô hình Ngôn ngữ Lớn

Các nghiên cứu gần đây ước lượng sự không chắc chắn của LLM chủ yếu bằng các biện pháp hợp trảng, dựa trên logit: entropy dự đoán của các phân phối câu trả lời (Kadavath et al., 2022; Yang et al., 2025), tổng hợp qua các thể hệ khác nhau (Malinin và Gales, 2021), và độ nhất quán của phản hồi thông qua độ tương đồng ngữ nghĩa (Duan et al., 2024; Kuhn et al., 2023; Nikitin et al., 2024). Đối với các mô hình đóng, sự không chắc chắn thường được khai thác thông qua sự tự tin được diễn đạt bằng lời nói (Lin et al., 2022; Mielke et al., 2022), điều này thường quá tự tin và không đáng tin cậy (Yona et al., 2024; Tanneru et al., 2024), hoặc được xấp xỉ bằng sự đa dạng dưới các gợi ý diễn đạt lại (Zhang et al., 2024a; Chen và Mueller)

	Nhắc nhở _{Baseline}	CLUE
Sự giúp đỡ		
Tổng thể	0.281	0.73
TU SĨ RỪNG	0.312	0.688
HealthVer	0.25	0.772
Sự nhất quán		
Tổng thể	0.290	0.721
TU SĨ RỪNG	0.309	0.691
HealthVer	0.27	0.751
Không thừa		
Tổng thể	0.252	0.762
TU SĨ RỪNG	0.261	0.739
HealthVer	0.242	0.784
Phạm vi phù sổng		
Tổng thể	0.275	0.722
TU SĨ RỪNG	0.283	0.717
HealthVer	0.266	0.727
Chất lượng tổng thể		
Tổng thể	0.325	0.678
TU SĨ RỪNG	0.313	0.688
HealthVer	0.336	0.667

Bảng 2: Tỷ lệ các lần giải thích được xếp hạng là ưu tiên hàng đầu của người tham gia cho mỗi chỉ số đánh giá. Giải thích được tạo bởi Qwen2.5-14B-Instruct (được c họn vì tính trung thực cao; xem §4.5)

2024), vốn yêu cầu nhiều tính toán và gộp lẫn nhiều từ câu lệnh với sự không chắc chắn của mô hình. Theo đó, phương pháp của chúng tôi tập trung vào các mô hình mã nguồn mở và áp dụng entropy dự đoán, một chỉ số hộp trắng đơn giản, để giải thích và hiệu quả, được tính toán từ các logits của câu trả lời, tránh nhiều gây ra từ câu lệnh.

6.2 Biểu thức ngôn ngữ của sự không chắc chắn

Các ước lượng bất định theo con số khó để người dùng cuối có thể hành động vì chúng không giải quyết các nguồn gốc của sự bất định (Warren et al., 2025). Các biểu đạt ngôn ngữ về sự bất định, ví dụ, các cụm từ như “Tôi chắc chắn” (Mielke et al., 2022; Tian et al., 2023; Xiong et al., 2024; Ji et al., 2025; Farquhar et al., 2024; Kim et al., 2024), có thể trực quan hơn để hiểu so với các biểu đạt theo con số (Zimmer,1983; Wallsten et al., 1993; Windschitl and Wells, 1996). Tuy nhiên, chúng không nhất thiết phản ánh trung thực sự bất định của mô hình (Yona et al., 2024; Tanneru et al., 2024), có nguy cơ gây nhầm lẫn cho người dùng (Steyvers).

v.v., 2025). Hơn nữa, họ không giải thích lý do tại sao mô hình không chắc chắn, như phương pháp CLUE của chúng tôi làm.

6.3 Tạo giải thích bằng ngôn ngữ tự nhiên cho việc kiểm tra sự thật

Các giải thích bằng ngôn ngữ tự nhiên (NLEs) biện minh cho các dự đoán của mô hình đối với người đọc phổ thông trong việc kiểm chứng thông tin (Wei Jie và cộng sự, 2024), bổ sung cho các công việc tóm tắt và mạng xã hội cung cấp đồ thị, các đoạn được thao tác như các lý do (Ribeiro và cộng sự, 2022; Chan và cộng sự, 2023; Huang và cộng sự, 2025; Sun và cộng sự, 2026). Trong kiểm chứng thông tin, các hệ thống ban đầu trích xuất các câu chính từ các bài báo được cung cấp làm giải thích (Atanasova và cộng sự, 2020); các nghiên cứu sau này cải thiện độ lưu loát của NLE thông qua chỉnh sửa hậu kỳ (Jolly và cộng sự, 2022) và trên dữ liệu từ các trang web kiểm chứng thông tin (Feher và cộng sự, 2025; Raffel và cộng sự, 2020; Beltagy và cộng sự, 2020). Các phương pháp gần đây hơn sử dụng giải thích dựa trên điểm nổi bật như tín hiệu để nâng cao chất lượng NLE, áp dụng các kỹ thuật như mô hình hóa dựa trên đồ thị (Yuan và cộng sự, 2025) và tự tinh chỉnh (Wang và Atanasova, 2025). Một dòng công việc khác tập trung vào các phương pháp ít dữ liệu nhằm tránh giám sát mô hình, bao gồm việc gợi ý GPT-3 để tạo các bản tóm tắt bằng chứng (Brown và cộng sự, 2020; Stammbach và Ash,

7 Kết luận

Chúng tôi trình bày khuôn khổ đầu tiên, CLUE, để tạo ra NLEs về độ không chắc chắn của mô hình bằng cách tham chiếu đến các xung đột và sự đồng thuận giữa các tuyên bố và nhiều bằng chứng trong việc kiểm tra thông tin.

nhiệm vụ. Phương pháp của chúng tôi, được đánh giá trên ba mô hình ngôn ngữ và hai bộ dữ liệu, cho thấy những cải thiện đáng kể cả về độ trung thực với sự không chắc chắn của mô hình và tính nhất quán của nhãn so với việc gọi ý tiêu chuẩn. Các đánh giá bởi người tham gia còn cho thấy rằng các giải thích do CLUE tạo ra hữu ích hơn, cung cấp thông tin đầy đủ hơn, ít dư thừa hơn và logic hơn với dữ liệu đầu vào. Công trình này thiết lập nền tảng cho các hệ thống kiểm tra sự thật có thể giải thích, cung cấp cho người dùng cuối những giải thích có cơ sở và trung thực phản ánh sự không chắc chắn của mô hình. Hơn nữa, phương pháp của chúng tôi có thể hữu ích cho các công trình tương lai trong một loạt các nhiệm vụ tìm kiếm thông tin và tăng cường truy xuất (ví dụ, trả lời câu hỏi) trong đó việc giải thích sự không chắc chắn dựa trên bối cảnh mâu thuẫn là rất quan trọng.

Hạn chế

Bài báo của chúng tôi đề xuất một khuôn khổ mới để tạo ra các NLE hướng tới sự không chắc chắn của mô hình bằng cách trực tiếp chỉ ra các mâu thuẫn hoặc sự đồng thuận giữa tuyên bố và nhiều bằng chứng. Trong khi khuôn khổ của chúng tôi chứng minh chất lượng giải thích được cải thiện thông qua đánh giá nghiêm ngặt trên nhiều mô hình ngôn ngữ và tập dữ liệu, chúng tôi thừa nhận một số hạn chế.

Các thí nghiệm của chúng tôi bị giới hạn trong các mô hình cỡ trung bình (Qwen2.5-14B-Instruct, Gemma2-9B-It, OLMo-2-1124-13B-Instruct, và DeepSeek-R1-Distill-Qwen-14B), được lựa chọn dựa trên những hạn chế về tính toán. Mặc dù các mô hình này cho thấy sự cải thiện đáng kể so với hiệu suất cơ bản, kết quả của chúng tôi gợi ý rằng các mô hình lớn hơn (ví dụ, quy mô 70 tỷ tham số) có thể nâng cao chất lượng giải thích, đặc biệt về mặt bao phủ và dư thừa. Thiết kế mô-đun của khung làm việc của chúng tôi dễ dàng thích ứng với việc mở rộng như vậy.

CLUE bao gồm một bộ gán nhãn quan hệ phụ trợ L_{rel} gán cho mỗi tương tác đoạn trích một trong các nhãn {AGREE, DISAGREE, UNRELATED}. Trong các thí nghiệm chính, chúng tôi sử dụng GPT-4o cho bước này để giảm nhiễu nhãn quan hệ, nhưng bước này là tùy chọn: L_{rel} là mô-đun, và một phiên bản hoàn toàn mở trọng số (ví dụ, Qwen2.5-14B-Instruct) cho chất lượng NLE hạ lưu tương đương với chỉ một sự giảm nhỏ (Phụ lục C.2). Việc giảm khoảng cách còn lại này trong khi vẫn giữ hoàn toàn mở trọng số có thể yêu cầu cải thiện việc gọi ý nhãn quan hệ (nhiều ngữ cảnh cục bộ hơn, các ví dụ chất lượng cao hơn) hoặc tinh chỉnh nhẹ một mô hình mở trọng số trên một bộ đánh giá quan hệ gọn nhẹ.

(Phụ lục C.4).

Giống như hầu hết các quy trình nhiều giai đoạn, CLUE đôi khi có thể lan truyền lỗi ngược dòng: kiểm tra thủ công cho thấy các chế độ thất bại như các đoạn rời rạc và thỉnh thoảng nhãn quan hệ sai, điều này có thể làm giảm độ trung thực của NLE (Phụ lục C.3). Các vấn đề này có thể được giảm thiểu bằng cách khuyến khích một cách lấy các đoạn ngữ nghĩa đầy đủ hơn trong quá trình trích xuất (ví dụ, các hạn chế nhẹ trong phát hiện cộng đồng), cải thiện tính ổn định của nhãn quan hệ (sử dụng prompt hoặc tinh chỉnh nhẹ), và thêm các kiểm tra nhẹ trong thời gian sinh mà hạ trọng số các tương tác đoạn không đáng tin cậy trước khi tạo ra lời giải thích cuối cùng (Phụ lục C.4).

Trong nghiên cứu này, chúng tôi tập trung vào các bộ dữ liệu HealthVer và DRUID, kết hợp các tuyên bố với các mảnh bằng chứng riêng biệt, khiến chúng trở nên lý tưởng để nghiên cứu các kịch bản xung đột bằng chứng. Các thí nghiệm của chúng tôi chủ yếu tập trung vào các thiết lập nơi một tuyên bố và hai hoặc ba bằng chứng được trình bày. Mặc dù chúng tôi không khám phá các thiết lập có sự tương tác phức tạp hơn giữa tuyên bố và bằng chứng, khi nhiều luận điểm và/hoặc các mảnh bằng chứng được đưa vào, khung của chúng tôi, dựa trên các tương tác cặp đôi, có thể dễ dàng đáp ứng các bối cảnh phức tạp hơn chỉ bằng cách tăng số lượng các mảnh bằng chứng đầu vào; không cần thay đổi phương pháp luận.

CLUE nhắm vào các cài đặt mà người dùng cần hiểu tại sao mô hình lại không chắc chắn bằng cách cơ sở hóa sự không chắc chắn vào các mâu thuẫn/đồng thuận giữa bằng chứng và tuyên bố cụ thể. Sự tập trung này được thúc đẩy bởi các phát hiện định tính rằng các kiểm tra viên sự thật chuyên nghiệp muốn các hệ thống “hiển thị quá trình” đằng sau một quyết định, đặc biệt khi những căng thẳng dựa trên bằng chứng gây ra sự không chắc chắn, để người dùng có thể quyết định điều gì cần xác minh tiếp theo và khi nào nên tin tưởng kết quả (Warren et al., 2025). Trong khi trong bài báo này, chúng tôi tiến hành một nghiên cứu về con người và nhận thấy rằng các giải thích về sự không chắc chắn được tạo ra bởi khung CLUE mà chúng tôi đề xuất hữu ích hơn so với phương pháp nhắc nhở đơn giản, chúng tôi không nghiên cứu liệu những giải thích hướng tới sự không chắc chắn này có được ưa thích trong mọi bối cảnh so với các phương pháp thay thế để truyền đạt sự không chắc chắn (ví dụ, độ tin cậy số (Zimmer, 1983; Wallsten et al., 1993; van der Waa et al., 2020; Liu et al., 2020) hoặc các biện pháp diễn đạt bằng lời nói (Lin et al., 2022; Mielke et al., 2022; Yona et al., 2024).

các định dạng), sẽ cần thiết để nghiên cứu tác động của các giải thích về sự không chắc chắn đối với hiệu quả, việc phát hiện lỗi, và sự tin cậy được điều chỉnh trong các bối cảnh khác.

Công việc của chúng tôi giới hạn trong phạm vi giải thích sự không chắc chắn của mô hình phát sinh từ xung đột bằng chứng. Mặc dù điều này bao quát một tập hợp quan trọng của các trường hợp, sự không chắc chắn trong thế giới thực cũng có thể xuất phát từ các nguồn khác, bao gồm bằng chứng không đầy đủ, khoảng trống kiến thức trong mô hình và xung đột giữa bối cảnh và bộ nhớ. Chúng tôi coi công trình này là bước nền tảng hướng tới nghiên cứu rộng hơn về giải thích sự không chắc chắn của mô hình.

Cân nhắc đạo đức

Công trình này liên quan đến việc kiểm tra sự thật tự động, nhằm giảm thiểu tác hại và sự lan truyền của thông tin sai lệch, nhưng vẫn có khả năng gây hại hoặc bị lạm dụng thông qua sự không chính xác của mô hình, ảo tưởng, hoặc việc triển khai để kiểm duyệt. Công trình hiện tại của chúng tôi nhằm cung cấp các giải thích cho phép người dùng xem xét kết quả của các hệ thống này một cách phê phán hơn, và vì vậy chúng tôi không thấy có rủi ro ngay lập tức nào liên quan đến nó.

Công việc của chúng tôi chỉ giới hạn trong việc xem xét các tuyên bố, bằng chứng và giải thích bằng tiếng Anh, do đó kết quả của chúng tôi có thể không được tổng quát hóa cho các ngôn ngữ khác. Vì nhiệm vụ liên quan đến suy luận phức tạp về các chủ đề kỹ thuật, chúng tôi đã sàng lọc các người tham gia để đảm bảo họ là người bản ngữ tiếng Anh nhằm đảm bảo rằng họ có thể hiểu đầy đủ tài liệu và tăng khả năng nhận được các phản hồi chất lượng cao (xem mục I.1 để biết chi tiết). Tuy nhiên, tiêu chí này cũng có thể giới thiệu hoặc củng cố những thiên lệch hiện có và giới hạn khả năng tổng quát hóa của các phát hiện của chúng tôi. Người tham gia đã được thông báo về nghiên cứu và mục tiêu của nó trước khi đồng ý cung cấp sự đồng thuận thông tin. Không có dữ liệu cá nhân nào được thu thập từ các người tham gia và họ nhận được mức thù lao công bằng cho công việc của mình (khoảng 9 GBP/giờ).

Lời cảm ơn

 Nghiên cứu này được đồng tài trợ bởi Liên minh Châu Âu (ERC, ExplainYourself, 101077481), bởi Trung tâm Tiên phong về AI, số tiền tài trợ DNRFP1, cũng như bởi Chương trình Thông minh Villum. Tuy nhiên, những quan điểm và ý kiến được thể hiện chỉ là của tác giả và không nhất thiết phản ánh quan điểm của Liên minh Châu Âu hoặc Hội đồng Nghiên cứu Châu Âu. Cả Liên minh Châu Âu và cơ quan cấp vốn đều không chịu trách nhiệm về những ý kiến này.

Tài liệu tham khảo

Chirag Agarwal, Sree Harsha Tanneru, và Himabindu Lakkaraju. 2024. Độ trung thực so với Tính khả thi: Về Sự (Không) Đáng tin cậy của Các Giải thích từ Các Mô hình Ngôn ngữ Lớn.

Pepa Atanasova, Oana-Maria Camburu, Christina Lioma, Thomas Lukasiewicz, Jakob Grue Simonsen và Isabelle Augenstein. 2023. Các bài kiểm tra độ trung thực cho giải thích ngôn ngữ tự nhiên. Trong Kỷ yếu của Hội nghị thường niên lần thứ 61 của Hiệp hội Ngôn ngữ học Tính toán (Tập 2: Bài báo ngắn), trang 283–294, Toronto, Canada. Hiệp hội Ngôn ngữ học Tính toán.

Pepa Atanasova, Jakob Grue Simonsen, Christina Lioma, và Isabelle Augenstein. 2020. Tạo ra Giải thích Kiểm tra Sự thật. Trong Kỷ yếu Hội nghị thường niên lần thứ 58 của Hiệp hội Ngôn ngữ học Máy tính, trang 7352–7364, Trục tuyến. Hiệp hội Ngôn ngữ học Máy tính.

Iz Beltagy, Matthew E. Peters, và Arman Cohan. 2020. Longformer: Bộ Biến Đổi Tài Liệu Dài. Bản in trước trên ArXiv, abs/2004.05150.

Steven Bird, Ewan Klein, và Edward Loper. 2009. Xử lý Ngôn ngữ Tự nhiên với Python. O'Reilly Media.

Vincent D. Blondel, Jean-Loup Guillaume, Renaud Lambiotte và Etienne Lefebvre. 2008. Phân tách nhanh các cộng đồng trong các mạng lưới lớn. Tạp chí cơ học thống kê: lý thuyết và thực nghiệm, 2008(10):P10008.

Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, Sandhini Agarwal, Ariel Herbert-Voss, Gretchen Krueger, Tom Henighan, Rewon Child, Aditya Ramesh, Daniel M. Ziegler, Jeffrey Wu, Clemens Winter, Christopher Hesse, Mark Chen, Eric Sigler, Mateusz Litwin, Scott Gray, Benjamin Chess, Jack Clark, Christopher Berner, Sam McCandlish, Alec Radford, Ilya Sutskever, và Dario Amodei. 2020. Các mô hình ngôn ngữ là những người học ít mẫu. Trong Advances in Neural Information Processing Systems 33: Hội nghị thường niên về Hệ thống Xử lý Thông tin Thần kinh 2020, NeurIPS 2020, ngày 6-12 tháng 12, 2020, trục tuyến.

Hou Pong Chan, Qi Zeng, và Heng Ji. 2023. Phát hiện Sự Không Nhất Quán Tự Động Có Thể Giải Thích Chi Tiết trong Tóm Tắt Văn Bản. Trong Kết quả của Hiệp hội Ngôn ngữ Học Máy Tính: ACL 2023, trang 6433–6444, Toronto, Canada. Hiệp hội Ngôn ngữ Học Máy Tính.

Jiuhai Chen và Jonas Mueller. 2024. Định lượng Sự không chắc chắn trong các câu trả lời từ bất kỳ Mô hình Ngôn ngữ nào và Nâng cao độ tin cậy của chúng. Trong Kỷ yếu Hội nghị Thường niên lần thứ 62 của Hiệp hội Ngôn ngữ học Máy tính (Tập 1: Bài báo dài), trang 5186–5200, Bangkok, Thái Lan. Hiệp hội Ngôn ngữ học Máy tính.

Karl Cobbe, Vineet Kosaraju, Mohammad Bavarian, Mark Chen, Heewoo Jun, Lukasz Kaiser, Matthias Plappert, Jerry Tworek, Jacob Hilton, Reiichiro Nakano, và các tác giả khác. 2021. Đào tạo Người Kiểm chứng để Giải các Bài Toán Dạng Văn bản. Bản in trước ArXiv, abs/2110.14168.

DeepSeek-AI. DeepSeek-R1-Distill-Qwen-14B. <https://huggingface.co/deepseek-ai/DeepSeek-R1-Distill-Qwen-14B>. Hugging- Thử mô hình khuôn mặt; truy cập ngày 05-10-2025.

Jinhao Duan, Hao Cheng, Shiqi Wang, Alex Zavalny, Chenan Wang, Renjing Xu, Bhavya Kailkhura, và Kaidi Xu. 2024. Chuyển sự chú ý sang tính liên quan: Hướng tới định lượng độ không chắc chắn dự đoán của các mô hình ngôn ngữ lớn dạng tự do. Trong Kỷ yếu của Hội nghị thường niên lần thứ 62 của Hiệp hội Ngôn ngữ học Máy tính (Tập 1: Bài báo dài), t rang 5050–5063, Bangkok, Thái Lan. Hiệp hội Ngôn ngữ học Máy tính.

Sebastian Farquhar, Jannik Kossen, Lorenz Kuhn, và Yarin Gal. 2024. Phát hiện ảo tưởng trong các mô hình ngôn ngữ lớn bằng cách sử dụng entropy ngữ nghĩa. *Nature*, 630(8017):625–630.

Darius Feher, Abdullah Khered, Hao Zhang, Riza Batista-Navarro, và Viktor Schlegel. 2025. Học cách tạo ra và đánh giá các giải thích kiểm chứng sự thật với Transformers. Ứng dụng Kỹ thuật của Trí tuệ Nhân tạo, 139:109492.

Nicolo' Fontana, Francesco Corso, Enrico Zuccolotto và Francesco Pierri. 2025. Đánh giá các Mô hình Ngôn ngữ Lớn Mã nguồn mở cho Kiểm tra Thông tin Tự động. Bản in trước ArXiv, abs/2503.05565. Nhóm Gemma. 2024. Gemma: Mô hình Mở Dựa trên Nghiên cứu và Công nghệ Gemini. Bản in trước ArXiv, abs/2403.08295. Lucas Graves. 2017. Giải phẫu một kiểm tra thực tế: Thực hành khách quan và nhận thức luận tranh cãi của việc kiểm tra thực tế. *Communication, Culture & Critique*, 10(3):518–537. Lovisa Hagström, Sara Vera Marjanović, Haeun Yu, Arnav Arora, Christina Lioma, Maria Maistro, Pepa Atanasova, và Isabelle Augenstein. 2024. Kiểm tra Thực tế về Việc Sử dụng Ngữ cảnh cho Tạo nội dung Tăng cường Truy xuất. Pengcheng He, Jianfeng Gao và Weizhu Chen. 2023. DeBERTaV3: Cải thiện DeBERTa bằng cách Tiền huấn luyện theo Phong cách ELECTRA với Chia sẻ Nhúng Phân tách Gradient. Trong Hội nghị Quốc tế lần thứ mười một về Học Biểu diễn, ICLR 2023, Kigali, Rwanda, 1-5 tháng 5, 2023. OpenReview.net. Dan Hendrycks, Coll

Matthew Honnibal và Ines Montani. 2017. spaCy 2: Hiểu ngôn ngữ tự nhiên với các nhúng Bloom, Mạng nơ-ron tích chập và Phân tích tăng dần.

Fan Huang, Haewoon Kwak, Kunwoo Park, và Jisun An. 2024. ChatGPT Đánh Giá Chất Lượng Giải Thích Ngôn Ngữ Tự Nhiên Như Con Người: Nhưng Trên Những Thang Nào? Trong Kỷ yếu Hội nghị Quốc tế Thống nhất năm 2024 về Ngôn ngữ học Máy tính, Tài nguyên Ngôn ngữ và Đánh giá (LREC-COLING 2024), trang 3111–3132, Torino, Ý. ELRA và ICCL.

Kung-Hsiang Huang, Hou Pong Chan, Kathleen McKeown, và Heng Ji. 2025. ManiTweet: Một Chuẩn Mới để Nhận Diện Sự Thao Tung Tin Tức trên Mạng Xã Hội. Trong Kỷ yếu của Hội nghị Quốc tế lần thứ 31 về Ngôn ngữ học Máy tính, trang 11161–11180, Abu Dhabi, UAE. Hiệp hội Ngôn ngữ học Máy tính.

Ziwei Ji, Lei Yu, Yeskendir Koishekenov, Yejin Bang, Anthony Hartshorn, Alan Schelten, Cheng Zhang, Pascale Fung, và Nicola Cancedda. 2025. Hiệu chỉnh Sự Không Chắc Chắn Bằng Lời Nói như một Đặc Trưng Tuyến Tính để Giảm Ảo Giác. Bản in trước trên ArXiv, abs/2503.14477.

Shailza Jolly, Pepa Atanasova, và Isabelle Augenstein. 2022. Tạo các giải thích kiểm chứng sự thật trôi chảy với chỉnh sửa hậu kỳ không giám sát. *Information*, 13(10).

Saurav Kadavath, Tom Conerly, Amanda Askell, Tom Henighan, Dawn Drain, Ethan Perez, Nicholas Schiefer, Zac Hatfield-Dodds, Nova DasSarma, Eli Tran-Johnson, và cộng sự. 2022. Các Mô hình Ngôn ngữ (Phần lớn) Biết Những gì Chúng Biết. Bản in trước ArXiv, abs/2207.05221. Maurice G Kendall và B. Babington Smith. 1939. Vấn đề M Xếp hạng. *The annals of mathematical statistics*, 10(3):275–287. Sunnie S. Y. Kim, Q. Vera Liao, Mihaela Vorvoreanu, Stephanie Ballard, và Jennifer Wortman Vaughan. 2024. "Tôi Không Chắc, Nhưng...": Xem xét Tác động của Việc Mô hình Ngôn ngữ Lớn Thể hiện Sự Không chắc chắn đối với Sự Dựa vào và Niềm tin của Người dùng. Trong Kỷ yếu Hội nghị ACM 2024 về Công bằng, Trách nhiệm và Minh bạch, FAccT '24, trang 822–835, New York, NY, Hoa Kỳ. Hiệp hội Khoa học Máy tính. Neema Kotonya và Francesca Toni. 2020. Kiểm tra Sự thật Tự động Có thể Giải thích: Một Tổng quan. Trong Kỷ yếu Hội nghị Quốc tế lần thứ 28 về Ngôn ngữ Học Máy tính, trang 5430–5443, Barcelona, Tây Ban Nha (Trực tuyến). Intern

Stephanie C. Lin, Jacob Hilton, và Owain Evans. 2022. Dạy các mô hình để diễn đạt sự không chắc chắn của chúng bằng lời. *Transactions on Machine Learning Research*. <https://openreview.net/forum?id=s8K2UZGTZ>.

Dawn Liu, Marie Juanchich, Miroslav Sirota và Sheina Orbell. 2020. Việc Sử Dụng Trực Giác Thông Tin Ngữ Cảnh trong Các Quyết Định Được Thực Hiện với Các Đại Lượng Bằng Lời và Bằng Số. *Tạp chí Thử Nghiệm Tâm Lý Học Hàng Quý*, 73(4):481–494.

Xiaolei Lu và Jianghong Ma. 2024. Liệu Sự Trung Thành Có Mâu Thuẫn Với Sự Hợp Lý? Một Nghiên Cứu Thực Nghiệm về AI Giải Thích được trên các Nhiệm Vụ Xử Lý Ngôn Ngữ Tự Nhiên. Bản in trước trên ArXiv, abs/2404.00140.

Andrey Malinin và Mark J. F. Gales. 2021. Ước lượng Sự không chắc chắn trong Dự đoán Có cấu trúc Tự hồi quy. Trong *Hội nghị Quốc tế lần thứ 9 về Học Biểu diễn*, ICLR 2021, Sự kiện Áo, Áo, từ ngày 3-7 tháng 5, 2021. OpenReview.net.

Ana Marasovic, Iz Beltagy, Doug Downey, và Matthew Peters. 2022. Tự Lý Giải với Vài Ví Dụ bằng Các Gọi Ý Ngôn Ngữ Tự Nhiên. Trong *Kết Quả hội nghị Hiệp hội Ngôn ngữ Học Máy tính: NAACL 2022*, trang 410–424, Seattle, Hoa Kỳ. Hiệp hội Ngôn ngữ Học Máy tính.

Nicholas Micallef, Vivienne Armacost, Nasir Memon, và Sameer Patil. 2022. Đúng hay Sai: Nghiên cứu các Thực hành Công việc của Các Kiểm tra Sự thật Chuyên nghiệp. *Proc. ACM Hum.-Comput. Interact.*, 6(CSCW1).

Sabrina J. Mielke, Arthur Szlam, Emily Dinan và Y-Lan Boureau. 2022. Giảm Sự Quá Tự Tin Của Các Tác Nhân Đàm Thoại Thông Qua Hiệu Chuẩn Ngôn Ngữ. *Transactions of the Association for Computational Linguistics*, 10:857–872.

George A. Miller. 1992. *WordNet: Cơ sở dữ liệu Từ vựng cho Tiếng Anh*. Trong *Hội nghị và Ngôn ngữ Tự nhiên: Kỷ yếu của một Hội thảo được tổ chức tại Harriman, New York, từ ngày 23-26 tháng 2 năm 1992*.

Alexander Nikitin, Jannik Kossen, Yarin Gal, và Pekka Marttinen. 2024. *Độ Phức Tạp Ngôn Ngữ Hạt Nhân: Định lượng Không chắc chắn chi tiết cho LLM từ Các Độ Tương đồng Ngữ nghĩa*. Trong *Advances in Neural Information Processing Systems 38: Hội nghị thường niên về Hệ thống Xử lý Thông tin Thần kinh 2024, NeurIPS 2024, Vancouver, BC, Canada, từ ngày 10 đến 15 tháng 12 năm 2024*.

Đội ngũ OpenAI. 2024. Thẻ Hệ thống GPT-4o.

Nhóm Qwen. 2024. Qwen2.5: Một Bộ Mô Hình Nền Tảng.

Colin Raffel, Noam Shazeer, Adam Roberts, Katherine Lee, Sharan Narang, Michael Matena, Yanqi Zhou, Wei Li, và Peter J. Liu. 2020. Khám phá Giới hạn của Học Chuyển giao với Bộ Biến đổi Văn bản-đến-Văn bản Thống nhất. *J. Mach. Learn. Res.*, 21:140:1–140:67.

Sagnik Ray Choudhury, Pepa Atanasova, và Isabelle Augenstein. 2023. Giải thích các tương tác giữa các đoạn văn bản. Trong *Kỷ yếu Hội nghị Phương pháp Thực nghiệm về Xử lý Ngôn ngữ Tự nhiên 2023*, t rang 12709–12730, Singapore. Hiệp hội Ngôn ngữ học Máy tính.

Leonardo F. R. Ribeiro, Mengwen Liu, Iryna Gurevych, Markus Dreyer và Mohit Bansal. 2022. FactGraph: Đánh giá tính thực tế trong tóm tắt bằng biểu diễn đồ thị ngữ nghĩa. Trong *Kỷ yếu Hội nghị 2022 của Chi hội Bắc Mỹ thuộc Hiệp hội Ngôn ngữ học Tính toán: Công nghệ Ngôn ngữ Người*, trang 3238–3253, Seat-tle, Hoa Kỳ. Hiệp hội Ngôn ngữ học Tính toán.

Mourad Sarrouti, Asma Ben Abacha, Yassine Mrabet, và Dina Demner-Fushman. 2021. Kiểm chứng sự thật dựa trên bằng chứng của các tuyên bố liên quan đến sức khỏe. Trong *Kết quả của Hiệp hội Ngôn ngữ học Máy tính: EMNLP 2021*, trang 3499–3512, Punta Cana, Cộng hòa Dominica. Hiệp hội Ngôn ngữ học Máy tính.

Michael Schlichtkrull, Nedjma Ousidhoum, và Andreas Vlachos. 2023. Các Mục Đích Sử Dụng Của Các Hiện Vật Kiểm Tra Thực Tế Tự Động: Tại Sao, Như Thế Nào và Ai. Trong *Kết Quả của Hiệp Hội Ngôn Ngữ Học Máy Tính: EMNLP 2023*, trang 8618–8642, Singapore. Hiệp Hội Ngôn Ngữ Học Máy Tính.

Vera Schmitt, Luis-Felipe Villa-Arenas, Nils Feldhus, Joachim Meyer, Robert P. Spang, và Sebastian Möller. 2024. Vai trò của khả năng giải thích trong phát hiện thông tin sai lệch hợp tác giữa con người và AI. Trong *Kỷ yếu Hội nghị ACM 2024 về Công bằng, Trách nhiệm và Minh bạch, FAccT '24*, trang 2157–2174, New York, NY, Hoa Kỳ. Hiệp hội Máy tính ACM.

Noah Siegel, Oana-Maria Camburu, Nicolas Heess, và Maria Perez-Ortiz. 2024. Xác suất cũng quan trọng: Một thước đo trung thực hơn cho độ trung thực của các giải thích văn bản tự do trong các mô hình ngôn ngữ lớn. Trong *Kỷ yếu của Hội nghị thường niên lần thứ 62 của Hiệp hội Ngôn ngữ Học Máy Tính (Tập 2: Bài báo ngắn)*, trang 530–546, Bangkok, Thái Lan. Hiệp hội Ngôn ngữ Học Máy Tính.

Noah Y Siegel, Nicolas Heess, Maria Perez-Ortiz, và Oana-Maria Camburu. 2025. Độ trung thực của các giải thích tự tạo của LLM cho các nhiệm vụ kiến thức phổ thông: Lớn hơn thì tốt hơn, và điều chỉnh theo hướng dẫn cho phép đánh đổi nhưng không chiếm ưu thế Pareto. *ArXiv preprint*, abs/2503.13445.

Jesus Solano, Mardhiyah Sanni, Oana-Maria Camburu, và Pasquale Minervini. 2024. SparseFit: Prompting ít mẫu với tinh chỉnh thừa thớt để đồng thời tạo ra Dự đoán và Giải thích Ngôn ngữ Tự nhiên. Trong *Kỷ yếu Hội nghị thường niên lần thứ 62 của Hiệp hội Ngôn ngữ học Máy tính (Tập 1: Bài báo dài)*, các trang 2053–2077, Bangkok, Thái Lan. Hiệp hội Ngôn ngữ học Máy tính.

Dominik Stambach và Elliott Ash. 2020. e-FEVER: Giải thích và Tóm tắt cho Kiểm tra Thực tế Tự động. Kỷ yếu của Hội nghị Truth and Trust Online 2020 (TTO 2020), trang 32–43.

Mark Steyvers, Heliodoro Tejeda, Aakriti Kumar, Catarina Belem, Sheer Karny, Xinyue Hu, Lukas W Mayer, và Padhraic Smyth. 2025. Những gì các Mô hình Ngôn ngữ Lớn biết và những gì Con người nghĩ rằng họ biết. *Nature Machine Intelligence*, trang 1–11.

Jingyi Sun, Pepa Atanasova, và Isabelle Augenstein. 2025. Đánh giá Giải thích Tính năng Đầu vào thông qua Khung Đánh giá Chẩn đoán Thống nhất. Trong Kỷ yếu Hội nghị 2025 của Chương các nước châu Mỹ thuộc Hiệp hội Ngôn ngữ học Máy tính: Công nghệ Ngôn ngữ Con người (Tập 1: Bài báo dài), các trang 10559–10577, Albuquerque, New Mexico. Hiệp hội Ngôn ngữ học Máy tính.

Jingyi Sun, Pepa Atanasova, Sagnik Ray Choudhury, Sekh Mainul Islam và Isabelle Augenstein. 2026. Khung Đánh giá cho các giải thích nổi bật về việc sử dụng ngữ cảnh trong mô hình ngôn ngữ. *Ngôn ngữ học tính toán*, trang 1–33.

Sree Harsha Tanneru, Chirag Agarwal, và Himabindu Lakkaraju. 2024. Định lượng sự không chắc chắn trong các giải thích ngôn ngữ tự nhiên của các mô hình ngôn ngữ lớn. Trong Hội nghị Quốc tế về Trí tuệ Nhân tạo và Thống kê, 2-4 tháng 5 năm 2024, Palau de Congressos, Valencia, Tây Ban Nha, tập 238 của Kỷ yếu Nghiên cứu Máy học, các trang 1072–1080. PMLR.

Robert F Tate. 1954. Mối tương quan giữa một biến rời rạc và một biến liên tục. *Tương quan Điểm-Biserial. The Annals of Mathematical Statistics*, 25(3):603–607.

Nhóm OLMo, Pete Walsh, Luca Soldaini, Dirk Groen-eveld, Kyle Lo, Shane Arora, Akshita Bhagia, Yuling Gu, Shengyi Huang, Matt Jordan, Nathan Lambert, Dustin Schwenk, Oyvind Tafjord, Taira Anderson, David Atkinson, Faeze Brahman, Christopher Clark, Pradeep Dasigi, Nouha Dziri, Michal Guerquin, Hamish Ivison, Pang Wei Koh, Jiacheng Liu, Saumya Malik, William Merrill, Lester James V. Miranda, Jacob Morrison, Tyler Murray, Crystal Nam, Valentina Pyatkin, Aman Rangapur, Michael Schmitz, Sam Skjonsberg, David Wadden, Christopher Wilhelm, Michael Wilson, Luke Zettlemoyer, Ali Farhadi, Noah A. Smith, và Hannaneh Hajishirzi. 2025. 2 OLMo 2 Furious. Bản in sớm trên ArXiv, abs/2501.00656.

Katherine Tian, Eric Mitchell, Allan Zhou, Archit Sharma, Rafael Rafailov, Huaxiu Yao, Chelsea Finn, và Christopher Manning. 2023. Chỉ cần Yêu cầu Hiệu chuẩn: Các Chiến lược để Lấy được Điểm Tự tin Hiệu chuẩn từ Mô hình Ngôn ngữ được Tinh chỉnh với Phản hồi của Con người. Trong Kỷ yếu Hội nghị Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên 2023, trang 5433–5442, Singapore. Hiệp hội Ngôn ngữ học Máy tính.

Jasper van der Waa, Tjeerd Schoonderwoerd, Jurri-aan van Diggelen, và Mark Neerincx. 2020. Các Biện Pháp Niềm Tin Có Thể Giải Thích cho Hệ Thống Hỗ Trợ Ra Quyết Định. *Tạp chí Quốc tế về Nghiên cứu Người-Máy Tính*, 144:102493. Thomas S. Wallsten, David V. Budescu, Rami Zwick, và Steven M. Kemp. 1993. Sở Thích và Lý Do cho Việc Truyền Đạt Thông Tin Xác Suất Bằng Ngôn Từ hoặc Dạng Số. *Tạp chí Hội Tâm Lý học*, 31(2):135–138. Yingming Wang và Pepa Atanasova. 2025. Tự Phê Bình và Hoàn Thiện để Giải Thích Ngôn Ngữ Tự Nhiên Trung Thực. Trong Kỷ yếu Hội nghị 2025 về Phương Pháp Thực Nghiệm trong Xử Lý Ngôn Ngữ Tự Nhiên, trang 8481–8507, Tô Châu, Trung Quốc. Hiệp hội Ngôn ngữ Học Máy Tính.

Yuxia Wang, Revanth Gangi Reddy, Zain Muhammad Mujahid, Arnav Arora, Aleksandr Rubashevskii, Ji-ahui Geng, Osama Mohammed Afzal, Liangming Pan, Nadav Borenstein, Aditya Pillai, Isabelle Augenstein, Iryna Gurevych, và Preslav Nakov. 2024. Factcheck-Bench: Bộ đánh giá chi tiết cho các công cụ kiểm tra sự thật tự động. Trong Kết quả của Hiệp hội Ngôn ngữ học Máy tính: EMNLP 2024, trang 14199–14230, Miami, Florida, USA. Hiệp hội Ngôn ngữ học Máy tính.

Greta Warren, Irina Shklovski và Isabelle Augenstein. 2025. Cho Tôi Thấy Công Việc: Yêu Cầu của Người Kiểm Tra Sự Thật đối với Việc Kiểm Tra Sự Thật Tự Động Có Giải Thích. Trong Kỷ yếu Hội nghị CHI về Các Yếu Tố Con Người trong Hệ thống Máy tính, CHI '25, New York, NY, USA. Hiệp hội Máy tính.

Greta Warren, Jingyi Sun, Irina Shklovski và Isabelle Augenstein. 2026. Cho tôi thấy bằng chứng: Đánh giá vai trò của bằng chứng và các giải thích ngôn ngữ tự nhiên trong việc kiểm tra sự thật được hỗ trợ bởi AI. Bản in trước trên ArXiv, abs/2601.11387.

Yeo Wei Jie, Ranjan Satapathy, Rick Goh, và Erik Cambria. 2024. Các Giải Thích Lý Luận Có Dễ Hiểu Từ Việc Gọi Lệnh Các Mô Hình Ngôn Ngữ Lớn Như Thế Nào? Trong Kết Quả Hội nghị Hiệp hội Ngôn ngữ Học Máy Tính: NAACL 2024, các trang 2148–2164, Thành phố Mexico, Mexico. Hiệp hội Ngôn ngữ Học Máy tính.

Sarah Wiegrefe, Ana Marasović, và Noah A. Smith. 2021. Đo lường Mối quan hệ giữa Nhân và Giải thích Bằng Văn bản Tự do. Trong Kỷ yếu Hội nghị 2021 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên, các trang 10266–10284, Trại tuyến và Punta Cana, Cộng hòa Dominica. Hiệp hội Ngôn ngữ Học Máy Tính.

Paul D Windschitl và Gary L Wells. 1996. Đo lường Sự Không chắc chắn Về Tâm lý: Phương pháp Nói so với Phương pháp Số. *Tạp chí Tâm lý học Thí nghiệm*: Ứng dụng, 2(4):343.

Miao Xiong, Zhiyuan Hu, Xinyang Lu, Yifei Li, Jie Fu, Junxian He, và Bryan Hooi. 2024. Có thể LLMs

Thể hiện Sự Không chắc chắn của Họ? Một Đánh giá Thực nghiệm về Thu thập Độ tin cậy trong các Mô hình Ngôn ngữ Lớn. Trong Hội nghị Quốc tế lần thứ mười hai về Học các Biểu diễn, ICLR 2024, Vienna, Áo, ngày 7-11 tháng 5 năm 2024. OpenReview.net.

Yongjin Yang, Haneul Yoo, và Hwaran Lee. 2025. MAQA: Đánh giá Định lượng Sự không chắc chắn trong LLMs Liên quan đến Sự không chắc chắn Dữ liệu. Trong Kết quả của Hiệp hội Ngôn ngữ học Máy tính: NAACL 2025, trang 5846–5863, Albuquerque, New Mexico. Hiệp hội Ngôn ngữ học Máy tính.

Gal Yona, Roei Aharoni và Mor Geva. 2024. Liệu Các Mô Hình Ngôn Ngữ Lớn Có Thể Thể Hiện Trung Thực Sự Không Chắc Chắn Nội Tại Của Chúng Bằng Lời Nói Không? Trong Kỷ Yếu Hội nghị 2024 về Các Phương Pháp Thực Nghiệm trong Xử Lý Ngôn Ngữ Tự Nhiên, trang 7752–7764, Miami, Florida, Hoa Kỳ. Hiệp hội Ngôn ngữ học Tính toán.

Shuzhou Yuan, Jingyi Sun, Ran Zhang, Michael Färber, Steffen Eger, Pepa Atanasova, và Isabelle Augenstein. 2025. Khung Tạo Giải Thích Văn Bản Dựa Trên Đồ Thị. Trong Kỷ yếu Hội nghị Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên 2025, trang 29362–29386, Tô Châu, Trung Quốc. Hiệp hội Ngôn ngữ Học Tính toán.

Fengzhu Zeng và Wei Gao. 2024. JustiLM: Tạo Lập Lý Do Về Mấu Ít cho Kiểm Tra Sự Thật Có Giải Thích đối với Những Khẳng Định Thế Giới Thực. Transactions of the Association for Computational Linguistics, 12:334–354.

Caiqi Zhang, Fangyu Liu, Marco Basaldella, và Nigel Collier. 2024a. LUQ: Định lượng sự không chắc chắn trong văn bản dài cho LLMs. Trong Kỷ yếu của Hội nghị 2024 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên, trang 5244–5262, Miami, Florida, Hoa Kỳ. Hiệp hội Ngôn ngữ Học Máy Tính.

Qingru Zhang, Chandan Singh, Liyuan Liu, Xiaodong Liu, Bin Yu, Jianfeng Gao, và Tuo Zhao. 2024b. Hãy Nói với Mô Hình của Bạn Nơi Cần Tập Trung: Điều chỉnh Chú Ý Hậu Tế cho các LLM. Trong Hội nghị Quốc tế lần thứ mười hai về Biểu diễn Học, ICLR 2024, Vienna, Áo, từ 7 đến 11 tháng 5, 2024. OpenReview.net.

Xiaoyan Zhao, Lingzhi Wang, Zhanghao Wang, Hong Cheng, Rui Zhang, và Kam-Fai Wong. 2024. PACAR: Kiểm tra sự thật tự động với lập kế hoạch và lý luận hành động tùy chỉnh sử dụng các mô hình ngôn ngữ lớn. Trong Kỷ yếu Hội nghị Quốc tế Liên hợp về Ngôn ngữ học Máy tính, Tài nguyên Ngôn ngữ và Đánh giá 2024 (LREC-COLING 2024), trang 12564–12573, Torino, Italia. ELRA và ICCL.

Alf C Zimmer. 1983. Xử lý Bằng Lời so với Bằng Số của Xác Suất Chủ Quan. Trong Advances in psychology, tập 16, trang 159–182. Elsevier.

Hiệu suất của mô hình Backbone trên các tiêu chuẩn công khai

Bảng 3 tóm tắt kết quả năm lần thử được công bố công khai trên hai bộ chuẩn đánh giá khả năng lập luận. Tất cả các số liệu được lấy nguyên văn từ thể mô hình chính thức hoặc các báo cáo kỹ thuật đi kèm. Các số liệu được sao chép từ thể mô hình chính thức.

Những con số này xác nhận lập luận của chúng tôi rằng Qwen2.5-14B-Instruct là mạnh nhất trong ba cái về khả năng theo hướng dẫn và lập luận.

Phương pháp B: Chọn đầu chú ý để điều hướng

Theo Zhang và cộng sự (2024b), chúng tôi chỉ điều khiển một tập con các đầu chú ý được chọn thay vì tất cả, vì việc điều khiển có mục tiêu mang lại cải thiện lớn hơn về chất lượng đầu ra. Tuy nhiên, tiêu chí lựa chọn của chúng tôi khác với họ: thay vì xếp hạng các đầu dựa trên ảnh hưởng của chúng đến độ chính xác của nhiệm vụ, chúng tôi xếp hạng chúng dựa trên mức độ mà chúng ảnh hưởng đến sự không chắc chắn dự đoán của mô hình trong quá trình kiểm chứng sự thật.

Cụ thể, đối với mỗi bộ dữ liệu kiểm chứng sự thật được chọn trong công trình này (xem chi tiết ở §3.1), D , chúng tôi lấy một tập hợp con để xác thực D_d với $|D_d| = 300$ ví dụ. Đối với mỗi đầu vào $X \in D_d$, chúng tôi tính điểm không chắc chắn cơ bản của mô hình $u(X)$ khi nó dự đoán nhãn kiểm chứng sự thật như đã nêu ở §2.2. Sau đó, đối với từng đầu chú ý được xác định bởi lớp ℓ và chỉ số h , chúng tôi đặt đầu đó về 0, chạy lại mô hình và đo sự thay đổi tuyệt đối trong độ không chắc chắn

$$\Delta u(X, \ell, h) = |u(X) - u_{o(\ell, h)}(X)|.$$

Lấy trung bình $\Delta u(X, \ell, h)$ trên tất cả $X \in D_d$ tạo ra một điểm quan trọng duy nhất cho head (ℓ, h) . Chúng tôi xếp hạng các head theo điểm này và giữ lại top t head cho mỗi bộ dữ liệu và mỗi mô hình. Lưu ý rằng chúng tôi thiết lập $t = 100$ theo khuyến nghị của Zhang et al. (2024b) và để cân bằng hiệu quả điều hướng với rủi ro suy thoái.

C Chi tiết nhận dạng xung đột và thỏa thuận

C.1 Ví dụ gợi ý để gắn nhãn quan hệ cho các tương tác khoảng văn bản được ghi lại

Để xác định các thỏa thuận và mâu thuẫn giữa tuyên bố và hai đoạn bằng chứng, chúng tôi sử dụng lời nhắc trong Hình 3 để gắn nhãn cho từng tương tác khoảng trích xuất (xem §2.3).

Mô hình	Tham số MMLU GSM8K		
Qwen2.5-14B-Hướng dẫn (Nhóm Qwen, 2024)	14,7 B	79.7	90.2
Gemma-2-9B-IT (Đội Gemma, 2024)	9.0 B	71.3	68.6
OLMo-2-1124-13B-Hướng dẫn (Nhóm OLMo và cộng sự, 2025)	13 B	67.5	54.2

Bảng 3: Là Điểm chuẩn trên MMLU (Hendrycks et al., 2021) và GSM8K (Cobbe et al., 2021) được sử dụng để đo lường khả năng tuân theo hướng dẫn và lập luận.

Bạn là một trợ lý hữu ích. Nhiệm vụ của bạn:	
1. Đọc tuyên bố và hai đoạn chứng cứ của nó (E1 , E2) .	
2. Đối với mỗi tương tác phạm vi được cung cấp , quyết định liệu hai nhịp cầu ĐỒNG Ý, KHÔNG ĐỒNG Ý, hoặc KHÔNG LIÊN QUAN, lấy tổng thể ngữ cảnh.	
3. Xuất các cặp khoảng cách chính xác như đã cho, theo sau bởi quan hệ: đồng ý /không đồng ý /không liên quan	
Định dạng trả về:	
1. "SPAN A" - "SPAN B" mối quan hệ: <đồng ý /không đồng ý /không liên quan >	
2. ...	
3. ...	
### CẢNH 1 (có chủ thích ví dụ)	
Yêu cầu: [...]	
Bảng chứng 1: [...]	
Bảng chứng 2: [...]	
Span tương tác (to be được gán nhãn):	
1. "[...]" - "[...]"	
2. "[...]" - "[...]"	
3. "[...]" - "[...]"	
Được mong đợi đầu ra:	
1. "[...]" - "[...]" mối quan hệ: ...	
2. "[...]" - "[...]" mối quan hệ: ...	
3. "[...]" - "[...]" mối quan hệ: ...	
### CẢNH 2 % bị bỏ qua để ngắn gọn	
### CẢNH 3 % bị bỏ qua để ngắn gọn	
### THỂ HIỆN MỚI (được điền sẵn cho mỗi ví dụ mới)	
Yêu cầu: {CLAIM}	
Bảng chứng 1: {E1 }	
Bảng chứng 2: {E2}	
Span tương tác:	
1. "{SPAN1-A}" - "{SPAN1-B}"	
2. "{SPAN2-A}" - "{SPAN2-B}"	
3. "{SPAN3-A}" - "{SPAN3-B}"	

Hình 3: Mẫu gợi ý cho nhãn quan hệ tương tác khoảng.

C.2 Phương pháp thay thế trọng số mở c ho Nhãn quan hệ Tương tác Khoảng cách

Phần này nghiên cứu cách lựa chọn bộ gán nhãn quan hệ ảnh hưởng đến chất lượng NLE xuống dòng trong CLUE. Trong khi chúng tôi sử dụng GPT-4 làm bộ gán nhãn quan hệ mặc định để giảm nhiễu nhãn, chúng tôi chỉ ra rằng một lựa chọn thay thế mở mạnh cũng khả thi, với chỉ một sự giảm hiệu suất nhỏ.

Như đã thảo luận trong Mục 2.3, CLUE sử dụng một bộ gán nhãn quan hệ L_{rel} để gán cho mỗi tương tác đoạn trích được một trong các nhãn {ĐỒNG Ý, KHÔNG ĐỒNG Ý, KHÔNG LIÊN QUAN}.

Chúng tôi đã xem xét hai tùy chọn gán nhãn: (i) một mô hình API đóng, có thể giảm nhiễu nhãn với chi phí sử dụng API, và (ii) một mô hình trọng số mở, hoàn toàn cục bộ nhưng có thể tạo ra nhiễu ồn hơn và do đó gây thêm nhiễu trong việc tạo NLE hạ nguồn.

Để định lượng tác động của việc lựa chọn người gán nhãn, chúng tôi đã chạy lại luồng xử lý với một lựa chọn thay thế có trọng số mở cho L_{rel} : Qwen2.5-14B-Instruct, giữ nguyên tất cả các thành phần khác. Bảng 4 báo cáo kết quả.

Nhìn chung, Qwen2.5-14B-Instruct cho chất lượng NLE hạ nguồn tương tự, mặc dù hơi yếu hơn, so với GPT-4o trên cả hai bộ dữ liệu. Ví dụ, trên HealthVer, Faithfulness giảm từ 0.033 xuống 0.025 và LEE từ 0.80 xuống 0.78; trên DRUID, Faithfulness giảm từ 0.102 xuống 0.076 và LEE từ 0.77 xuống 0.75.

Những kết quả này cho thấy rằng việc gán nhãn trọng số mở là khả thi trong CLUE, và khung này không bị ràng buộc với một thành phần độc quyền. Trong nghiên cứu này, chúng tôi sử dụng GPT-4o trong các thí nghiệm chính vì nó cung cấp việc gán nhãn quan hệ mạnh mẽ hơn một cách liên tục và giảm nguy cơ lan truyền lỗi từ các nhãn quan hệ có nhiễu đến các giải thích cuối cùng. Chúng tôi cũng thảo luận thêm về cách mà lỗi gán nhãn ở giai đoạn đầu có thể lan truyền và các chiến lược giảm thiểu trong Phụ lục C.3.

Một mối quan tâm tự nhiên là việc sử dụng trình gán nhãn API đóng có làm suy giảm tính minh bạch hay không. Chúng tôi nhấn mạnh rằng CLUE là dạng hộp trắng đối với mô hình nền tảng: việc đánh giá độ không chắc chắn, trích xuất tương tác khoảng, và điều hướng chú ý đều yêu cầu truy cập vào các nội bộ của mô hình nền tảng, điều mà các API đóng không cung cấp. Do đó, chạy toàn bộ quy trình với GPT-4o sẽ bỏ qua những tín hiệu hộp trắng này và giảm phương pháp xuống mức gợi ý bề mặt; các công trình trước đây cho thấy sự không chắc chắn được diễn đạt bằng lời như vậy có thể không đáng tin cậy, và thực hành kiểm tra sự thật yêu cầu các hệ thống phải “thể hiện công việc” đằng sau một quyết định (Yona et al., 2024; Tanneru et al., 2024; Warren et al., 2025).

GPT-4o chỉ được sử dụng cho nhiệm vụ hẹp là đánh giá mối quan hệ theo cặp sau khi các tương tác khoảng đã được trích xuất từ các phần nội bộ chính;

Trình gán nhãn quan hệ	HealthVer				TU SĨ RỪNG			
	Đức tin. (↑)	Span-Cov. (↑)	Mở rộng khoảng cách-(↓)	LEE (↑)	Đức tin. (↑)	Span-Cov. (↑)	Mở rộng khoảng cách-(↓)	LEE (↑)
GPT-4o	0.033	0.44	0.53	0.80	0.102	0.28	0.20	0.77
Qwen2.5-14B-Hướng dẫn	0.025	0.41	0.58	0.78	0.076	0.25	0.25	0.75

Bảng 4: Ảnh hưởng của việc lựa chọn bộ gán nhãn quan hệ tương tác liên đoạn. Chúng tôi chạy lại CLUE trong khi chỉ hoán đổi L_{rel} (GPT-4o vs. Qwen2.5-14B-Instruct) và giữ tất cả các thành phần khác cố định (cốt lõi: Qwen2.5-14B-Instruct; biến thể: CLUE-Span+Steering; $k=3$). Một bộ gán nhãn mở cân nặng là khả thi với chỉ một sự giảm nhỏ về chất lượng NLE hạ nguồn. In đậm chỉ kết quả tốt hơn theo mỗi chỉ số trong mỗi bộ dữ liệu.

do đó, nó không ảnh hưởng đến tính minh bạch của khung lỗi.

C.3 Phân tích sự lan truyền lỗi

Chúng tôi đã kiểm tra thủ công 50 trường hợp HealthVer (3 cặp đoạn văn hàng đầu cho mỗi trường hợp; $N=150$ cặp đoạn văn) để đánh giá (i) chất lượng trích xuất đoạn văn và (ii) độ chính xác gán nhãn mỗi quan hệ khi sử dụng GPT-4o làm L_{rel} .

Chất lượng trích xuất khoảng. Hầu hết các khoảng được trích xuất rất ngắn: 105/150 cặp khoảng chứa các khoảng hai từ (thường là các danh từ nổi bật như chủ ngữ/đối tượng). Trong 35/150 trường hợp, ít nhất một khoảng không hoàn chỉnh (ví dụ, “D” thay vì “vitamin D”) hoặc thiếu chỉ định ngữ nghĩa (ví dụ, “is not”). Nhìn chung, bộ trích xuất có xu hướng ưu tiên các từ ngắn, nổi bật, cho thấy tiềm năng cho các nghiên cứu trong tương lai nhằm khuyến khích các đơn vị ngữ nghĩa hoàn chỉnh hơn.

Độ chính xác gán nhãn quan hệ. Trên 150 cặp đoạn này, GPT-4o đạt độ chính xác 86% (129/150 đúng). Trong số 21 lỗi, 12 trường hợp là khi một quan hệ AGREE bị gán nhãn sai thành UNRELATED, thường xảy ra khi một đoạn không đầy đủ (ví dụ, “D” so với “vitamin D”), cho thấy rằng độ đầy đủ của đoạn là một nguyên nhân thất bại chính.

Lan truyền đến các NLE hạ nguồn. Sử dụng Qwen2.5-14B-Instruct với CLUE-Span+Steering, 13/21 tương tác bị gán nhãn sai được đề cập rõ ràng trong các NLE được tạo ra, cho thấy rằng lỗi từ nguồn có thể lan truyền vào các giải thích. Hơn nữa, tập con các trường hợp có tương tác bị gán nhãn sai thể hiện độ trung thực thấp hơn (Entropy-CCT trung bình 0,020) so với mức trung bình tổng thể của HealthVer–Qwen CLUE-Span+Steering (0,033; Bảng 1), cho thấy rằng các nhãn quan hệ không chính xác có thể làm giảm độ trung thực của giải thích.

Phân tích này gợi ý rằng các khoảng mảnh vụn và nhiễu nhãn quan hệ có thể là nguồn lỗi từ đầu và tiếp tục ảnh hưởng đến các NLE cuối cùng, thúc đẩy các chiến lược giảm thiểu được thảo luận trong Phụ lục C.4 cho công việc trong tương lai.

C.4 Giảm thiểu Sự Truyền Sai Sót

Chúng tôi đề ra một số hướng để giảm thiểu sự lan truyền lỗi trong công việc tương lai: (1) Cải thiện việc trích xuất khoảng: thêm các ràng buộc nhẹ trong quá trình phát hiện cộng đồng để các khoảng được trích xuất nhất quán hơn trong việc nắm bắt các đơn vị ngữ nghĩa hoàn chỉnh thay vì các token bị cắt cụt. (2) Cải thiện độ bền nhãn quan hệ: sử dụng gợi ý mạnh hơn (ngữ cảnh cục bộ rộng hơn, ví dụ minh họa chất lượng cao hơn) hoặc tinh chỉnh nhẹ một mô hình mở trên một bộ đánh giá quan hệ gọn. (3) Kiểm tra hợp lý tại thời gian sinh: thêm một kiểm tra nhất quán nhẹ nhàng để đánh dấu hoặc giảm trọng số các cặp khoảng được đánh giá nội bộ là không nhất quán với tuyên bố/bảng c hứng trước khi tạo ra NLE cuối cùng.

D Tài nguyên và Thẻ Mô hình

Thẻ mô hình: Qwen2.5-14B-Instruct (Hugging Face); Gemma-2-9B-IT (Hugging Face); OLMo-2-1124-13B-Instruct (Hugging Face); DeepSeek-R1-Distill-Qwen-14B (Hugging Face); DeBERTa-v3 NLI (Hugging Face); GPT-4o (OpenAI).

Chi phí Tính toán và Yêu cầu Tài nguyên

Cài đặt. Chúng tôi báo cáo chi phí tính toán của CLUE so với Prompt_{Baseline}. Trừ khi được nêu khác, các phép đo được thu thập sử dụng Qwen2.5-14B-Instruct trên bộ dữ liệu HealthVer với một GPU NVIDIA A100 80GB. Tất cả các giá trị được báo cáo cho mỗi trường hợp (trung bình trên toàn bộ tập đánh giá).

E.1 Độ trễ

Bảng 5 báo cáo thời gian thực trung bình trên mỗi trường hợp cho ba phương pháp. Cả CLUE-Span và CLUE-Span+Steering đều chậm hơn khoảng 2 giây trên mỗi trường hợp so với Prompt_{Baseline}, và chi phí thêm này hoàn toàn là do giai đoạn trích xuất tương tác span bổ sung và gán nhãn quan hệ.

Tiếp cận	Đánh giá Không chắc chắn (s)	Trích xuất Phạm vi +Gán nhãn (s)	Thế hệ NLE	Tổng (giây)
Nhắc nhở _{baseline}	0.364	—	14.8969	15.2609
CLUE-Span	0.364	2.0452	14.7730	17.1822
CHỈ DẪN-Span+Lái	0.364	2.0452	14.7874	17.1966

Bảng 5: Thời gian trung bình cho mỗi trường hợp đối với ba phương pháp sinh NLE trên HealthVer sử dụng Qwen2.5-14B-Instruct trên một GPU NVIDIA A100 80GB. “—” chỉ ra rằng trích xuất/đánh nhãn đoạn văn không được Prompt_{baseline} sử dụng.

E.2 Sử dụng bộ nhớ GPU

Bảng 6 báo cáo việc sử dụng bộ nhớ GPU (VRAM). Trong quá trình tạo NLE, việc sử dụng VRAM tương tự ở tất cả các phương pháp. CLUE-Span+Steering yêu cầu khoảng 0,32 GiB VRAM nhiều hơn Prompt_{baseline}, chủ yếu vì prompt dài hơn (nó bao gồm các tương tác span được trích xuất; xem Phụ lục G.2). Đáng chú ý, CLUE-Span+Steering không yêu cầu VRAM nhiều hơn CLUE-Span, vì trong quá trình sinh, bộ nhớ chính được chiếm bởi KV-cache và các activations, và steering không thêm một dấu chân bộ nhớ riêng ngoài quá trình forward pass cơ bản.

E.3 Yêu cầu bộ nhớ để điều khiển 100 đầu

Đối với việc chọn 100 đầu chú ý quan trọng nhất (Phụ lục B), đỉnh VRAM là 29,8 GiB. Đối với việc điều khiển các đầu này trong quá trình sinh NLE (CLUE-Span+Steering), đỉnh VRAM trung bình trên mỗi phiên bản là 30,84 GiB. Do đó, một GPU với 40GB bộ nhớ đáp ứng yêu cầu cho việc điều khiển chú ý trên 100 đầu.

E.4 Chi phí API GPT-4o cho gán nhãn mối quan hệ

Khi sử dụng GPT-4o như L_{rel} , tổng chi phí gán nhãn quan hệ tăng tỷ lệ thuận với số lượng các mẫu đã gán nhãn. Trong các thí nghiệm chính của chúng tôi, chi phí tích lũy trên các bộ dữ liệu và các nền tảng là khoảng 30 USD (khoảng 0,003 USD cho mỗi mẫu), với độ dài đầu vào trung bình là ~ 1 nghìn từ và độ dài đầu ra trung bình là ~ 50 từ cho mỗi lần gọi.

Phụ lục Phương pháp F: Chi tiết Đánh giá Độ trung thực

Phần bổ sung này cung cấp các chi tiết về triển khai và thống kê cho thước đo độ trung thực Entropy-CCT được giới thiệu ở §4.1. Chúng tôi mô tả (i) cách các biến động phản thực được tạo ra, (ii) cách Entropy-CCT liên quan đến CCT gốc, và (iii) cách chúng tôi kiểm tra ý nghĩa thống kê và báo cáo kết quả.

F.1 Tạo Nhiều Entropy-CCT

Để đánh giá mức độ phản ánh đúng đắn sự không chắc chắn của mô hình trong mỗi NLE, chúng tôi tạo ra nhiều phản thực cho mỗi trường hợp, theo Atanasova và cộng sự (2020) và Siegel và cộng sự (2024) (xem §4.1). Đối với mỗi đầu vào, bao gồm một tuyên bố và hai đoạn bằng chứng, trước tiên chúng tôi gán nhãn loại từ với spaCy (Honnibal và Montani, 2017) (en_core_web_sm), sau đó chọn bốn vị trí chèn ngẫu nhiên (đồng đều giữa các từ được gán nhãn là DANH TỪ hoặc ĐỘNG TỪ). Ở mỗi vị trí, chúng tôi chèn hoặc (i) một tính từ ngẫu nhiên trước danh từ hoặc (ii) một trạng từ ngẫu nhiên trước động từ. Các từ bổ nghĩa ứng viên được lấy đồng đều từ WordNet (Miller, 1992) sử dụng NLTK (Bird và cộng sự, 2009): chúng tôi xây dựng danh sách các tính từ/trạng từ ứng viên bằng cách thu thập tất cả tên gốc từ tất cả các synset tính từ/trạng từ trong WordNet, tương ứng. Bởi vì chúng tôi chọn ba ứng viên ngẫu nhiên cho mỗi bốn vị trí, thủ tục này tạo ra $4 \times 3 = 12$ biến thể cho mỗi trường hợp, cung cấp một tập đủ cho đánh giá Entropy-CCT tiếp theo, trong đó chúng tôi ch

F.2 Entropy-CCT so với OriginalCCT

CCT (Siegel et al., 2024) đánh giá độ trung thực bằng cách làm nhiều đầu vào và đo lường sự thay đổi kết quả trong phân phối nhãn dự đoán của mô hình. Cụ thể, nó sử dụng Khoảng Cách Biến Thiên Tổng (TVD) giữa phân phối trước và sau khi bị làm nhiễu $P(\cdot | X)$ và $P(\cdot | X')$:

$$\text{TVD}(P, Q) = \frac{1}{2} \sum_i |P_i - Q_i|. \quad (12)$$

Entropy-CCT là một sự điều chỉnh tối thiểu của CCT mà vẫn giữ nguyên quy trình nhiễu loạn và bài kiểm tra tương quan giống nhau: chúng tôi tương quan tác động của nhiễu loạn với việc liệu token được chèn có được đề cập trong NLE hay không. Thay đổi duy nhất là tín hiệu mà chúng tôi tương quan. Thay vì TVD (thay đổi xác suất), chúng tôi sử dụng Thay đổi Entropy Tuyệt đối (AEC).

Tiếp cận	Đánh giá Mức độ Không chắc chắn (GiB)	Trích xuất Tương tác Khoảng thời gian (GiB)	Thế hệ NLE (GiB)
Nhắc nhở _{Baseline}	29.71	—	30.52
CLUE-Span	29.71	29.72	30.84
CHỈ DẪN-Span+Lái	29.71	29.72	30.84

Bảng 6: Trung bình đỉnh VRAM mỗi phiên bản cho ba phương pháp tạo NLE (HealthVer, Qwen2.5-14B-Instruct, NVIDIA A100 80GB).

tức là, sự thay đổi trong entropy dự đoán, để trực tiếp nhằm vào sự bất định (mục tiêu giải thích của chúng tôi).

F.3 Kiểm định thống kê & Ý nghĩa

Chúng tôi kiểm tra ý nghĩa thống kê của r_{pb} bằng phép kiểm tra t Pearson tiêu chuẩn. Mỗi sự thay đổi cấu thành một quan sát: đối với mỗi bộ dữ liệu, chúng tôi đánh giá 600 trường hợp với 12 sự thay đổi cho mỗi trường hợp, tạo ra $n = 600 \times 12 = 7,200$ quan sát (Phụ lục F.1). Vì tương quan điểm-nhị thức về mặt đại số tương đương với tương quan Pearson giữa một biến liên tục và một biến nhị thức, chúng tôi sử dụng phép kiểm tra t Pearson tiêu chuẩn cho $H_0: r_{pb} = 0$.

Diễn giải r_{pb} và Δr_{pb} . Điểm Entropy-CCT là hệ số tương quan điểm-biserial (Tate, 1954) giữa sự thay đổi entropy tuyệt đối $|\Delta u|$ và cờ nhắc nhở nhị phân m . Bởi vì nó về mặt toán học giống hệt với Pearson r được tính giữa một biến liên tục và một biến nhị phân, nên nó tuân theo $-1 \leq r_{pb} \leq 1$. Khi $r_{pb} = 0$, điều đó có nghĩa là các biến động tác động cao và thấp được nhắc đến với tần suất như nhau. Nếu hai tầng xấp xỉ cân bằng, mỗi $+0.01$ trong r_{pb} làm tăng xác suất một token thực sự có ảnh hưởng đến bất định được nhắc đến khoảng một điểm phần trăm (pp). Một lợi ích Δr_{pb} do đó chuyển thành sự cải thiện tuyệt đối $\approx |\Delta r_{pb}| \times 100$ pp trong tỉ lệ nhắc đến. Ví dụ, chuyển từ -0.08 sang $+0.06$ là một sự dao động 0,14, tương ứng khoảng 14 pp.

Kiểm định ý nghĩa. Vì hệ số tương quan điểm-biserial là một tương quan Pearson, nên kiểm định t quen thuộc được áp dụng:

$$t = r_{pb} \sqrt{\frac{n-2}{1-r_{pb}^2}}, \quad (13)$$

$$t \sim t_{(n-2)} \quad \text{under } H_0: r_{pb} = 0. \quad (14)$$

Với $n = 7,200$ chúng ta có $df = 7,198$; các giá trị hai phía quan trọng là $|t| > 1.96$ cho $p < 0.05$ và $|t| > 2.58$ cho $p < 0.01$.

Sự trung thành với kết quả có ý nghĩa. Bảng 7 cho thấy các hệ số điểm-biserial r_{pb} , đây là thước đo sự trung thành của chúng tôi đối với độ không chắc chắn của mô hình (Xem, Eq.9), các thống kê t liên quan, và

giá trị p hai chiều cho mỗi cặp mô hình-phương pháp. Các giá trị đáp ứng tiêu chí $p < 0.01$ nghiêm ngặt hơn được in đậm.

Trên cả hai tập dữ liệu và cả ba nền tảng, Prompt_{Baseline} cho thấy mối tương quan âm, ám c hỉ xu hướng không trung thực khi làm nổi bật các token ít ảnh hưởng trong các NLE được tạo ra, với trung bình -0.094 . Biến thể chỉ sử dụng prompt của framework CLUE của chúng tôi, CLUE-Span, loại bỏ sự thiên lệch này và biến giá trị trung bình thành $+0.027$; hai hệ số của nó rõ ràng là $p < 0.01$, cho thấy một cải thiện khiêm tốn nhưng đáng kể về mức độ trung thực.

Biến thể đầy đủ CLUE-Span+Steering đẩy giá trị trung bình lên $+0.062$ và đạt được $p < 0.01$ trong bốn trên sáu thiết lập. Diễn giải những con số này theo thảo luận nêu trên, việc chuyển từ -0.094 sang $+0.062$ mang lại sự tăng tuyệt đối $(0.062 - (-0.094)) \times 100! \approx 16$, phần trăm trong xác suất mà một token thực sự ảnh hưởng đến sự không chắc chắn được đề cập trong NLE, điều này dễ nhận thấy khi kiểm tra định tính.

Do những cải thiện tích cực liên tục và có ý nghĩa thống kê, điều này do đó củng cố tuyên bố được nêu trong văn bản chính: CLUE tạo ra các NLE trung thực đáng kể hơn đối với sự không chắc chắn của mô hình so với Prompt_{Baseline}, và biến thể thesteer đặc biệt có lợi cho các mô hình ban đầu gặp khó khăn với việc phân bổ không chắc chắn.

Mẫu gợi ý cho Prompt_{Baseline}, CLUE-Span và CLUE-Span+ Điều khiển trên bộ dữ liệu Healthver và Druid

Chúng tôi đã thiết kế hai mẫu gợi ý cho các thí nghiệm của mình. Mẫu gợi ý cơ bản (Hình 4) không cung cấp cho mô hình bất kỳ tương tác khoảng nào; thay vào đó, mô hình phải xác định trước các thỏa thuận hoặc xung đột liên quan và sau đó thảo luận về chúng trong phần giải thích của mình. Ngược lại, mẫu gợi ý được sử dụng bởi khuôn khổ CLUE của chúng tôi (Hình 5) cung cấp ba tương tác khoảng đã được trích xuất trước (§2.3). Mô hình được hướng dẫn rõ ràng dựa trên các khoảng này để đưa ra giải thích, đảm bảo rằng lý do vẫn dựa trên chứng cứ được cung cấp.

Mô hình	Phương pháp	r_{pb}	t	p
HealthVer				
Qwen2.5-14B-Hướng dẫn	Nhắc nhở _{Baseline}	-0.028	-2.38	1.7×10^{-2}
	CLUE-Span	+0.006	+0.51	6.1×10^{-1}
	CHỈ DẪN-Span+Lái	+0.033	+2.80	5.1×10^{-3}
OLMo-2-1124-13B-Hướng dẫn	Nhắc nhở _{Baseline}	-0.100	-8.53	$< 10^{-15}$
	CLUE-Span	+0.005	+0.42	6.7×10^{-1}
	CHỈ DẪN-Span+Lái	+0.020	+1.70	9.0×10^{-2}
Gemma-2-9B-IT	Nhắc nhở _{Baseline}	-0.105	-8.96	$< 10^{-15}$
	CLUE-Span	+0.007	+0.59	5.5×10^{-1}
	CHỈ DẪN-Span+Lái	+0.021	+1.78	7.5×10^{-2}
TU SĨ RỪNG				
Qwen2.5-14B-Hướng dẫn	Nhắc nhở _{Baseline}	-0.080	-6.81	9.8×10^{-12}
	CLUE-Span	+0.089	+7.58	3.4×10^{-14}
	CHỈ DẪN-Span+Lái	+0.102	+8.70	$< 10^{-15}$
OLMo-2-1124-13B-Hướng dẫn	Nhắc nhở _{Baseline}	-0.130	-11.12	$< 10^{-15}$
	CLUE-Span	+0.014	+1.19	2.3×10^{-1}
	CHỈ DẪN-Span+Lái	+0.099	+8.44	$< 10^{-15}$
Gemma-2-9B-IT	Nhắc nhở _{Baseline}	-0.120	-10.26	$< 10^{-15}$
	CLUE-Span	+0.043	+3.65	2.6×10^{-4}
	CHỈ DẪN-Span+Lái	+0.098	+8.35	$< 10^{-15}$

Bảng 7: Kết quả đánh giá chi tiết về độ trung thực cho phương pháp cơ sở Prompt_{Baseline}, và hai biến thể của khung CLUE của chúng tôi là CLUE-Span và CLUE-Span+Steering trên bộ dữ liệu Healthver và Druid dựa trên Qwen2.5-14B-Instruct (Nhóm Qwen (2024)), OLMo-2-1124-13B-Instruct (Nhóm OLMo et al. (2025)) và Gemma-2-9B-IT (Nhóm Gemma (2024)). Tương quan bán nhị phân r_{pb} là phép đo Entropy-CCT của chúng tôi (§4.1), cùng với thống kê t và giá trị hai phía p cho từng cặp mô hình-phương pháp ($n = 7,200$, $df = 7,198$). Các mục có $p < 0.01$ được in đậm.

G.1 Mẫu nhắc choPrompt_{Baseline}

Để tạo NLEs về sự không chắc chắn của mô hình mà không có hướng dẫn tương tác khoảng, chúng tôi tạo một lời nhắc ba lần mẫu hướng dẫn mô hình xác định các tương tác có khả năng ảnh hưởng đến sự không chắc chắn của nó nhất và giải thích cách mà các mối quan hệ mà chúng đại diện ảnh hưởng đến điều đó. (Xem Hình 4).

G.2 Mẫu gợi ý cho CLUE-Span và CLUE-Span+ Điều hướng

Để tạo NLE về độ không chắc chắn của mô hình với hướng dẫn tương tác khoảng, chúng tôi tạo một lời nhắc ba ví dụ hướng dẫn mô hình thảo luận về cách những tương tác này, cùng với các quan hệ mà chúng đại diện, ảnh hưởng đến sự không chắc chắn của nó. (Xem Hình 5).

Kết quả đánh giá mở rộng H

H.1 Kết quả Đánh giá Mở rộng cho các Tình huống Liên quan đến Ba Bảng chứng

Để xác minh khả năng khái quát hóa của khung làm việc của chúng tôi trong các tình huống liên quan đến nhiều bảng chứng, chúng tôi thực hiện một thí nghiệm trên bộ dữ liệu Healthver sử dụng mô hình Qwen2.5-14B-Instruct, kết hợp mỗi tuyên bố với ba mảnh bằng chứng thay vì

Chỉ số	Nhắc nhở _{Base}	CLUE-S	CLUE-Lái
Đức tin. (↑)	0.08	0.10	0.13
Span-Cov. (↑)	—	0.25	0.41
Mở rộng khoảng cách-(↓)	—	0.23	0.27
LEE (↑)	0.80	0.86	0.86

Bảng 8: Đánh giá tự động cho ba loại NLE trên HealthVer sử dụng Qwen2.5-14B-Instruct khi một tuyên bố và ba bằng chứng liên quan: Prompt_{Base} (Prompt_{Baseline}) là phương pháp cơ bản, CLUE-S (CLUE-Span) và CLUE-Steer(CLUE-Span+Steering) là hai biến thể của khung CLUE của chúng tôi.

hai (như được hiển thị trong Bảng 8). Lưu ý rằng chúng tôi chọn $k = 6$ tương tác hàng đầu để tạo NLE, lấy tương tác hàng đầu-1 từ mỗi kết hợp theo cặp giữa C , E_1 , E_2 , và E_3 phần đầu vào.

Nhìn chung, chúng tôi quan sát thấy một xu hướng tương tự với ba bằng chứng như với hai bằng chứng (xem §4.5): CLUE- Span+Steering và CLUE-Span cho thấy độ trung thực và sự phù hợp giữa nhãn và giải thích tốt hơn so với Prompt_{Baseline}. Điều thú vị là độ trung thực của cả ba loại giải thích đều tăng so với thiết lập hai bằng chứng, từ -0,028 lên

Bạn là một hữu ích trợ lý.		Nhiệm vụ của bạn:			
1. Xác định mối quan hệ giữa yêu cầu và hai đoạn bằng chứng.					
2. Giải thích your sự không chắc chắn của dự đoán by xác định the ba nhất có ảnh hưởng span tương tác from Kháng định - Bảng c 1, Kháng định - Bảng chứng 2, và Bảng chứng 1-Bảng chứng 2, và mô tả how each tương tác của mối quan hệ (đồng ý, không đồng ý, hoặc không liên quan) ảnh hưởng your tổng thể sự tự tin.					
Trở về định dạng: [Dự đoán] [Giải thích]					
### CẢNH 1					
Đầu vào					
Yêu cầu: [...]					
Bảng chứng 1: [...]					
Bảng chứng 2: [...]					
Đầu ra					
[Dự đoán: ...] [Giải thích: ...]					
### CẢNH 2 % bỏ qua for sự ngắn gọn					
### CẢNH 3 % bị bỏ qua để ngắn gọn					
### THỂ HIỆN MỚI					
Yêu cầu: {CLAIM}					
Bảng chứng 1: {E1}					
Bảng chứng 2: {E2}					
Câu trả lời của bạn:					

Hình 4: Lời nhắc ba lần cho Prompt_{Baseline} (Bỏ qua Lần 2-3) trên các bộ dữ liệu HealthVer và DRUID.

0,08 cho Prompt_{Baseline}, từ 0,006 đến 0,10 cho CLUE-Span, và từ 0,033 đến 0,13 cho CLUE-Span+Steering. Điều này có thể là vì, khi NLEs được căn cứ trên bằng chứng phong phú hơn, chúng nắm bắt được nhiều sắc thái hơn trong cả tương tác giữa tuyên bố và bằng chứng, cũng như giữa các bằng chứng với nhau, từ đó phản ánh trung thực hơn quyết định kiểm tra sự thật của mô hình.

Đáng chú ý là CLUE-Span+Steering bao gồm nhiều tương tác phạm vi mục tiêu hơn (Phủ sóng phạm vi cao hơn: $0.41 > 0.27$) cũng như nhiều tương tác phạm vi dư thừa hơn (Phạm vi thừa cao hơn: $0.27 > 0.23$) so với CLUE-Span. Điều này gợi ý rằng, mặc dù CLUE-Span+Steering tập trung tốt hơn vào các tương tác mục tiêu, nó vẫn gặp phải sự dư thừa do việc bao gồm nhiều tương tác không liên quan hơn, điều mà chúng tôi kêu gọi nghiên cứu tương lai giải quyết.

H.2 Kết quả Đánh giá Mở rộng trên Mô hình Lý luận

Để chứng minh rằng khung của chúng tôi có khả năng tổng quát hóa cho các mô hình suy luận được huấn luyện chủ yếu thông qua học tăng cường quy mô lớn, và được thiết kế để khuyến khích khám phá chuỗi suy nghĩ, chúng tôi chọn DeepSeek-R1-Distill-Qwen-14B⁵ (DeepSeek-AI) làm mô hình cơ sở và đánh giá nó trên bộ dữ liệu HealthVer trong bối cảnh với một tuyên bố và hai bằng chứng (xem Bảng 9).

⁵<https://huggingface.co/deepseek-ai/DeepSeek-R1-Distill-Qwen-14B>

Bạn là một hữu ích trợ lý.		Nhiệm vụ của bạn:	
1.	Xác định mối quan hệ giữa yêu cầu và hai đoạn bằng chứng.		
2.	Giải thích your sự không chắc chắn của dự đoán by tham khảo đến ba nhịp tương tác cung cấp dưới đây (Yêu cầu - Bảng chứng 1, Kháng định - Bảng chứng 2, Bảng chứng 1-Bảng chứng 2) và mô tả như thế nào tương tác của mối quan hệ (đồng ý, không đồng ý, hoặc không liên quan) ảnh hưởng your tổng thể sự tự tin.		
Trở về định dạng:		[Dự đoán] [Giải thích]	
### CẢNH 1			
Nhập:			
Yêu cầu: [...]			
Bảng chứng 1: [...]			
Bảng chứng 2: [...]			
Span tương tác:			
1.	"[...]" - "[...]"	(C-E1)	mối quan hệ:
2.	"[...]" - "[...]"	(C-E2)	mối quan hệ:
3.	"[...]" - "[...]"	(E1 -E2)	mối quan hệ:
Đầu ra:			
[Dự đoán: ...] [Giải thích: ...]			
### CẢNH 2 % bị bỏ qua để ngắn gọn			
### CẢNH 3 % bị bỏ qua để ngắn gọn			
### THỂ HIỆN MỚI			
Yêu cầu: {CLAIM}			
Bảng chứng 1: {E1}			
Bảng chứng 2: {E2}			
Span tương tác (đã điền trước):			
1.	"{SPAN1 -A}" - "{SPAN1 -B}"	(C-E1)	
mối quan hệ: {REL1}			
2.	"{SPAN2-A}" - "{SPAN2 -B}"	(C-E2)	
mối quan hệ: {REL2}			
3.	"{SPAN3-A}" - "{SPAN3 -B}"	(E1 - E2)	
mối quan hệ: {REL3}			
Câu trả lời của bạn:			

Hình 5: Prompt ba lần bắn cho CLUE-Span và CLUE-Span+Steering (Bỏ qua các lần bắn 2-3) trên các bộ dữ liệu HealthVer and DRUID.

Tổng thể, cả hai biến thể của mô hình CLUE của chúng tôi, CLUE-Span và CLUE-Span+Steering, đều cho thấy độ Chính xác và Sự đồng thuận giữa Nhận và Giải thích cao hơn so với phương pháp cơ sở Prompt_{Baseline}, xác nhận hiệu quả của khung làm việc của chúng tôi. Cũng đáng chú ý rằng, so với các kết quả đánh giá trên các mô hình khác trong Bảng 1, cả ba loại giải thích được tạo ra bằng mô hình DeepSeek-R1-Distill-Qwen-14B đều đạt hiệu suất tốt nhất trên tất cả các chỉ số, đặc biệt là độ Chính xác và Độ bao phủ Phạm vi cao nhất. Điều đầu tiên ngụ ý rằng các mô hình lý luận được huấn luyện bằng học tăng cường có thể có khả năng tạo ra các giải thích rất chính xác với từng bước suy nghĩ; điều thứ hai gợi ý rằng loại mô hình này tuân theo các hướng dẫn tương tác của chúng tôi hiệu quả hơn. Do đó, cả CLUE-Span và CLUE-Span+Steering đều bao gồm nhiều tương tác với phạm vi mục tiêu hơn, dẫn đến Độ bao phủ Phạm vi cao hơn.

So sánh the two các biến thể,

Chỉ số	Nhắc nhở _{Base}	CLUE-S	CLUE-Lái
Đức tin. (↑)	0.12	0.16	0.18
Span-Cov. (↑)	—	0.58	0.67
Mở rộng khoảng cách-(↓)	—	0.59	0.64
LEE (↑)	0.88	0.90	0.89

Bảng 9: Đánh giá tự động cho ba loại NLE trên HEALTHVER sử dụng DeepSeek-R1-Distill-Qwen-14B khi có một tuyên bố và hai bằng chứng: Prompt_{Base} (Prompt_{Baseline}) là phương pháp cơ bản, CLUE-S (CLUE-Span) và CLUE-Steer(CLUE-Span+Steering) là hai biến thể của khung CLUE của chúng tôi.

CLUE-Span+Steering thể hiện Bao phủ Phạm vi (Span-Coverage) cao hơn (0.67 > 0.58) so với CLUE-Span, nhưng cũng có nhiều Phạm vi Thừa (Span-Extraneous) hơn (0.64 > 0.59), gợi ý rằng CLUE-Span+Steering có xu hướng bao gồm các tương tác dư thừa trong khi tập trung vào các tương tác mục tiêu. CLUE-Span+Steering cũng đạt được Độ Tin cậy (Faithfulness) cao nhất (0.18 > 0.16), phù hợp với Bao phủ Phạm vi cao hơn của nó, nhưng mang lại Tương quan Giải thích-Nhân (Label-Explanation Entailment) tương tự với CLUE-Span (0.89 so với 0.90), có khả năng do sự tăng của Phạm vi Thừa. Việc giải quyết sự đánh đổi này được để lại cho các nghiên cứu trong tương lai.

Tôi Chi tiết Đánh giá Con người

I.1 Người tham gia và Vật liệu

Người tham gia Chúng tôi đã tuyển N=12 người tham gia từ Prolific, được sàng lọc để là người nói tiếng Anh bản ngữ từ Úc, Canada, Ireland, New Zealand, Vương quốc Anh và Hoa Kỳ. Nghiên cứu đã được Ủy ban Đạo đức Nghiên cứu của tổ chức chúng tôi phê duyệt (số tham chiếu ẩn danh).

Vật liệu: Bốn mươi tuyên bố (20 từ DRUID, 20 từ HealthVer) được chọn ngẫu nhiên để đánh giá, trong khi tổng cộng 120 lời giải thích đã được đánh giá. Đối với mỗi trường hợp, người tham gia được cung cấp một tuyên bố, hai tài liệu chứng cứ, phán quyết của mô hình, độ chắc chắn số của mô hình, và ba lời giải thích thay thế (xem Hình 6 trong I.6). Các lời giải thích được trình bày cho người tham gia là những lời giải thích được tạo ra bằng Qwen2.5-14b-instruct (Nhóm Qwen, 2024) dựa trên hiệu suất đánh giá tự động của nó.

Mỗi người tham gia đánh giá các giải thích cho 10 trường hợp (5 trường hợp được gắn nhãn 'Đúng', 5 trường hợp được gắn nhãn 'Sai'), bên cạnh hai trường hợp kiểm tra sự chú ý được sử dụng để sàng lọc các câu trả lời về chất lượng. Để giảm bớt độ khó và yêu cầu về nhận thức của nhiệm vụ, chúng tôi đã giữ số lượng trường hợp cho mỗi người tham gia

	TU SĨ RỪNG		HealthVer	
	Tập A	Bộ B	Bộ A	Bộ B
Sự giúp đỡ	.016	.079	.003	.013
Sự nhất quán	.44	.058	.017	.016
Không thừa	.005	.084	.005	.019
Phạm vi phủ sóng	.494	.113	.018	.027
Chất lượng tổng thể	.005	.158	.01	.002

Bảng 10: Thỏa thuận giữa các đánh giá viên (W của Kendall) cho đánh giá của con người

hạ quần, và loại bỏ những người tham gia không vượt qua kiểm tra chú ý khởi dữ liệu. Để giảm thiểu rủi ro thiên vị, mỗi lời giải thích được trình bày cho người tham gia đều được gán nhãn trung lập: ‘Lời Giải Thích A’, ‘Lời Giải Thích B’, ‘Lời Giải Thích C’, để người tham gia không thể suy đoán gì về cách các lời giải thích được tạo ra hoặc cho rằng một lời giải thích nào đó nên được ưu tiên hơn những lời giải thích khác. Mỗi lời giải thích cũng được trình bày theo một thứ tự khác nhau và ngẫu nhiên cho từng trường hợp (ví dụ: ABC cho Yêu Cầu 1, CAB cho Yêu Cầu 2, v.v.) để giảm thiểu các hiệu ứng thứ tự như thiên lệch ưu tiên hoặc thiên lệch gần đây. Thứ tự hiển thị các tùy chọn phản hồi ‘Lời Giải Thích A’, ‘Lời Giải Thích B’, ‘Lời Giải Thích C’ cũng xuất hiện theo cùng một thứ tự ngẫu nhiên.

Quy trình Người tham gia đọc thông tin về nghiên cứu (xem I.3) và cung cấp sự đồng ý thông tin (xem I.4) trước khi đọc hướng dẫn chi tiết về nhiệm vụ và thực hiện một ví dụ thực hành của nhiệm vụ (xem I.5). Sau đó, người tham gia tiến hành nghiên cứu theo tốc độ của riêng họ. Nhiệm vụ mất khoảng 20 phút, và người tham gia được trả 3 bảng Anh cho công việc của mình.

I.2 Kết quả Đánh giá của Con người

I.2.1 Sự đồng thuận giữa các đánh giá viên

Phù hợp với các đánh giá NLE tương tự được thực hiện bởi các nghiên cứu trước đây (ví dụ, (Atanasova et al., 2020)), sự đồng thuận giữa các đánh giá viên (Kendall’s W (Kendall và Smith, 1939)) từ mức trung bình đến thấp (xem Bảng 10). Chúng tôi cho rằng điều này là do tính phức tạp tương đối của nhiệm vụ và sự khác biệt cá nhân trong cách mà thông tin được nhận thức.

I.2.2 Ưu tiên biến thể CLUE

Bảng 11 cho thấy thứ hạng trung bình được người tham gia gán cho từng biến thể giải thích. Các giải thích được tạo ra bởi CLUE đã được người tham gia của chúng tôi ưa thích hơn so với những giải thích được tạo ra bằng Prompt_{Baseline}: các giải thích được tạo ra bởi CLUE-Span+Steering được đánh giá là hữu ích nhất

	Nhắc nhở _{Base}	CLUE-S	CLUE-Lái
Sự giúp đỡ			
Tổng thể	2.025	1.892	1.867
TU SĨ RỪNG	1.9	1.917	1.767
HealthVer	2.15	1.867	1.967
Sự nhất quán			
Tổng thể	1.875	1.783	1.817
TU SĨ RỪNG	1.717	1.75	1.617
HealthVer	2.033	1.817	2.017
Không thừa			
Tổng thể	2.05	1.908	1.833
TU SĨ RỪNG	1.983	1.983	1.683
HealthVer	2.117	1.833	1.983
Phạm vi phù sổng			
Tổng thể	1.967	1.775	1.758
TU SĨ RỪNG	1.767	1.75	1.617
HealthVer	2.167	1.8	1.9
Chất lượng tổng thể			
Tổng thể	1.967	1.908	1.925
TU SĨ RỪNG	1.9	1.9	1.817
HealthVer	2.033	1.917	2.033

Bảng 11: Xếp hạng Trung bình Trung bình (MAR) cho năm tiêu chí đánh giá con người áp dụng cho các giải thích từ Qwen2.5-14B-Instruct trên các tập dữ liệu HEALTHVER và DRUID (được chọn vì độ trung thực cao; xem §4.5). So sánh Prompt_{BaseLine}, CLUE-Span (CLUE-S), và CLUE-Span+Steering (CLUE-Steer). MAR thấp hơn nghĩa là xếp hạng trung bình tốt hơn (cao hơn); điểm tốt nhất trong mỗi hàng được in đậm.

đầy đủ, có phạm vi bao phủ cao nhất và chứa ít thông tin thừa nhất, trong khi những thông tin từ CLUE-Span được đánh giá là có mức độ nhất quán và chất lượng tổng thể cao nhất.

Cuối cùng, chúng tôi nhận thấy sự khác biệt nhẹ giữa các tập dữ liệu: CLUE-Span+Steering có xu hướng được đánh giá cao hơn CLUE-Span đối với DRUID, và ngược lại đối với HealthVer. Điều này có thể xuất phát từ sự khác nhau về độ dài và độ phức tạp của đầu vào: các tài liệu chứng cứ của DRUID, được lấy từ các nguồn trực tuyến đa dạng và thường bao gồm các bài báo dài, có thể được hưởng lợi nhiều hơn từ một phương pháp điều hướng chú ý so với các tài liệu chứng cứ của HealthVer, vốn bao gồm các đoạn trích ngắn và tập trung từ các bài tóm tắt khoa học.

I.3 Màn hình Thông tin Đánh giá Con người

Cảm ơn bạn đã tình nguyện tham gia nghiên cứu này! Trước khi bạn quyết định có muốn tham gia hay không, vui lòng đọc kỹ màn hình thông tin này. 1. Dự án này về vấn đề gì?

Mục tiêu của chúng tôi là đảm bảo rằng các hệ thống kiểm chứng sự thật bằng AI có thể giải thích các quyết định mà chúng tạo ra theo những cách mà con người có thể hiểu và hữu ích. Khảo sát này là một phần của dự án giúp chúng tôi hiểu [ẩn danh]

2. Sự tham gia bao gồm những gì?

Bạn được mời giúp chúng tôi khám phá những loại giải thích nào hoạt động hiệu quả hơn trong việc kiểm tra thông tin. Trong nhiệm vụ này, bạn sẽ thấy các tuyên bố, dự đoán của hệ thống AI về việc tuyên bố đó đúng hay sai và các bằng chứng tương ứng được sử dụng để đưa ra dự đoán. Bạn cũng sẽ thấy một giải thích về lý do tại sao hệ thống AI chắc chắn hoặc không chắc chắn về dự đoán của nó để giúp bạn quyết định cách diễn giải dự đoán đúng/sai. Chúng tôi yêu cầu bạn đánh giá các giải thích theo 5 khía cạnh khác nhau (giải thích chi tiết về nhiệm vụ sẽ có ở trang tiếp theo). Tất cả những người tham gia hoàn thành khảo sát sẽ nhận được khoản thanh toán 3 bảng Anh. Bạn không phải trả bất kỳ chi phí nào để tham gia. Bạn có thể từ chối tham gia hoặc ngừng tham gia bất cứ lúc nào mà không bị phạt.

3. Nguồn tài trợ

Dự án này đã nhận được tài trợ từ [anonymised]

4. Đồng ý tham gia dự án và rút khỏi nghiên cứu

Bạn có thể đồng ý tham gia nghiên cứu này bằng cách đánh dấu vào ô ở trang tiếp theo của nghiên cứu. Việc tham gia nghiên cứu hoàn toàn tự nguyện. Quyết định không đồng ý của bạn sẽ không có hậu quả tiêu cực nào. Nếu bạn muốn rút lui trong quá trình thí nghiệm, bạn chỉ cần thoát khỏi trang web. Tất cả các câu trả lời chưa hoàn thành sẽ bị xóa. Sau khi bạn hoàn thành nghiên cứu và gửi câu trả lời của mình, sẽ không còn khả năng rút lui khỏi nghiên cứu nữa, vì dữ liệu của bạn sẽ không thể nhận diện và không thể liên kết với bạn.

5. Những lợi ích và rủi ro có thể đối với người tham gia

Bằng cách tham gia vào nghiên cứu này, bạn sẽ góp phần vào các nghiên cứu liên quan đến việc hiểu những loại giải thích nào hữu ích cho những người sử dụng hoặc bị ảnh hưởng bởi các hệ thống kiểm tra sự thật tự động. Đây là một dự án nghiên cứu dài hạn, vì vậy các lợi ích của nghiên cứu có thể sẽ không được thấy trong vài năm tới. Không mong đợi rằng việc tham gia sẽ gây ra bất kỳ rủi ro, bất tiện hay khó chịu nào cho bạn hoặc người khác.

6. Quy trình dự án xử lý dữ liệu cá nhân nào? Dự án không xử lý bất kỳ dữ liệu cá nhân nào.

7. Quyền của người tham gia theo Quy định Bảo vệ Dữ liệu Chung (GDPR)

Là người tham gia một dự án nghiên cứu, bạn có một số quyền theo GDPR. Quyền của bạn bao gồm

được chỉ định trong [ẩn danh]

8. Người chịu trách nhiệm lưu trữ và xử lý dữ liệu

[ẩn danh]

Vui lòng nhấp 'Tiếp theo' để đọc thêm về việc đồng ý tham gia nghiên cứu.

1.4 Biểu mẫu đồng ý Đánh giá Con người

Chúng tôi xin được yêu cầu sự đồng ý của bạn để xử lý dữ liệu của bạn. Chúng tôi thực hiện việc này tuân thủ Quy định Bảo vệ Dữ liệu Chung (GDPR). Xem bảng thông tin trên màn hình trước để biết thêm chi tiết về dự án và việc xử lý dữ liệu của bạn.

- Tôi xác nhận rằng tôi đã đọc bảng thông tin và rằng đây là cơ sở để tôi đồng ý cho việc xử lý dữ liệu của mình bởi dự án.
- Tôi xin đồng ý rằng [với dữ liệu ẩn danh] có thể đăng ký và xử lý dữ liệu của tôi
- Tôi hiểu rằng bất kỳ dữ liệu nào tôi cung cấp sẽ được giữ ẩn danh và không thể xác định được với tôi.
- Tôi hiểu rằng dữ liệu phản hồi ẩn danh của tôi sẽ được nhóm nghiên cứu lưu giữ.
- Tôi hiểu rằng sau khi tôi nộp câu trả lời của mình vào cuối nghiên cứu, chúng không thể bị hủy, rút lại hoặc thu hồi, vì chúng không thể được liên kết với tôi.
- Tôi hiểu rằng việc tham gia nghiên cứu này sẽ không mang lại lợi ích trực tiếp nào cho tôi
- Tôi hiểu rằng dữ liệu ẩn danh được chia sẻ qua các ấn phẩm hoặc bài trình bày sẽ có thể truy cập được bởi các nhà nghiên cứu và công chúng ở bất kỳ nơi nào trên thế giới, không chỉ riêng EU.
- Tôi đồng ý rằng dữ liệu ẩn danh mà tôi cung cấp có thể được lưu trữ trong cơ sở dữ liệu cho các dự án nghiên cứu mới sau khi dự án này kết thúc.
- Tôi cho phép dữ liệu ẩn danh của mình được lưu trữ cho các nghiên cứu tiềm năng trong tương lai liên quan đến nghiên cứu hiện tại mà không cần sự đồng ý thêm.
- Tôi hiểu rằng tôi sẽ không được trả tiền cho bất kỳ việc sử dụng nào trong tương lai đối với dữ liệu của tôi hoặc các sản phẩm được tạo ra từ đó.

Bằng cách đánh dấu vào ô này, tôi xác nhận rằng tôi đồng ý với những điều trên và đồng ý tham gia nghiên cứu này.

☐ Tôi đồng ý

1.5 Hướng dẫn nhiệm vụ đánh giá

Tôi phải làm gì?

Trong nghiên cứu này, bạn sẽ thấy các tuyên bố, dự đoán của hệ thống AI về việc tuyên bố này đúng hay sai, mức độ chắc chắn của hệ thống về nhân của nó, và bằng chứng tương ứng được sử dụng để đưa ra dự đoán. Bạn cũng sẽ thấy ba giải thích khác nhau về lý do tại sao hệ thống AI lại chắc chắn hoặc không chắc chắn về dự đoán của nó. Những giải thích này nhằm giúp bạn quyết định cách diễn giải dự đoán đúng/sai.

Nhiệm vụ của bạn là đánh giá chất lượng của các lời giải thích được cung cấp, không phải độ tin cậy của các tuyên bố và bằng chứng.

Tôi sẽ được hiển thị những thông tin gì?

Bạn sẽ được thấy các ví dụ về các yêu cầu, tài liệu bằng chứng, phán quyết và giải thích.

- Một tuyên bố là một phát biểu nào đó về thế giới. Nó có thể đúng, sai, hoặc nằm ở đâu đó giữa hai trạng thái đó.
- Thông tin bổ sung thường cần thiết để xác minh tính trung thực của một tuyên bố - điều này được gọi là bằng chứng hoặc tài liệu bằng chứng. Một tài liệu bằng chứng bao gồm một hoặc nhiều câu được trích xuất từ một nguồn bên ngoài cho tuyên bố cụ thể. Trong nghiên cứu này, bạn sẽ thấy hai tài liệu bằng chứng đã được thu thập cho một tuyên bố. Những tài liệu bằng chứng này có thể đồng ý hoặc không đồng ý với nhau.
- Dựa trên các bằng chứng có sẵn, một phán quyết được đưa ra về việc một yêu cầu là đúng hay sai.
- Sự không chắc chắn thường phát sinh khi đánh giá khẳng định và bằng chứng để đưa ra phán quyết. Mỗi phán quyết đi kèm với một điểm số không chắc chắn bằng số, biểu thị mức độ tin cậy của hệ thống AI rằng phán quyết mà nó dự đoán là đúng.
- Bạn sẽ thấy 3 giải thích thay thế về nơi mà sự không chắc chắn phát sinh liên quan đến phán quyết. Lưu ý rằng những giải thích này tập trung vào sự không chắc chắn của hệ thống AI, không phải bản thân phán quyết.
- Bạn được yêu cầu đánh giá các lời giải thích theo 5 thuộc tính khác nhau. Các thuộc tính như sau:

Tính hữu ích. Phần giải thích chứa thông tin hữu ích để đánh giá tuyên bố và kiểm tra sự thật.

Phạm vi. Phần giải thích chứa thông tin quan trọng, nổi bật và không bỏ sót bất kỳ điểm quan trọng nào góp phần vào việc kiểm tra sự thật.

Không thừa. Lời giải thích không chứa bất kỳ thông tin nào thừa/lặp lại/không liên quan đến lập luận và việc kiểm tra sự thật.

Tính nhất quán. Phần giải thích không chứa bất kỳ thông tin nào mâu thuẫn với tuyên bố và kiểm tra sự thật.

Chất lượng tổng thể. Xếp hạng các giải thích theo chất lượng tổng thể của chúng.

- Vui lòng xếp hạng các giải thích theo thứ tự giảm dần. Ví dụ, bạn nên xếp giải thích mà bạn cho là hữu ích nhất là '1', và giải thích mà bạn cho là ít hữu ích nhất là '3'. Nếu hai giải thích có vẻ gần như giống nhau, bạn có thể gán cho chúng cùng một thứ hạng, nhưng theo quy tắc chung, bạn nên cố gắng xếp chúng theo thứ tự có cấp bậc.

- Ba lời giải thích, Lời giải thích A, Lời giải thích B và Lời giải thích C, sẽ xuất hiện theo thứ tự khác nhau trong suốt nghiên cứu, vì vậy bạn có thể cần chú ý một chút để biết cái nào là cái nào.

Quan trọng: Vui lòng chỉ xem xét thông tin được cung cấp (yêu cầu, tài liệu bằng chứng và các giải thích) khi đánh giá các giải thích. Đôi khi bạn sẽ quen thuộc với tuyên bố, nhưng chúng tôi yêu cầu bạn tiếp cận mỗi tuyên bố như mới, dù bạn đã từng thấy trước đây hay chưa. Không quan trọng bạn đồng ý hay không đồng ý với tuyên bố hoặc bằng chứng - chúng tôi yêu cầu bạn đánh giá những gì AI tạo ra: nếu bạn lần đầu tiên nhìn thấy tuyên bố này, bạn có thấy lời giải thích do AI cung cấp hữu ích không? Ở trang tiếp theo, bạn sẽ thấy ví dụ về nhiệm vụ.

I.6 Ví dụ về thiết lập bộ đánh giá con người

Đây là một ví dụ về những gì bạn sẽ thấy trong quá trình nghiên cứu. Trước tiên, bạn sẽ thấy một Yêu cầu, và hai bằng chứng, cùng với Phán quyết dự đoán của hệ thống AI và Mức độ chắc chắn của hệ thống về việc dự đoán của nó là đúng.

Các phần của luận điểm và bằng chứng quan trọng nhất đối với độ chắc chắn của hệ thống AI được tô sáng. Các phần của Luận điểm được tô màu Đỏ, các phần của Bằng chứng 1 được tô màu Xanh dương, và các phần của Bằng chứng 2 được tô màu Xanh lá.

Phía dưới, bạn sẽ thấy ba giải thích thay thế cho độ chắc chắn của hệ thống AI, Giải thích A, Giải thích B và Giải thích C. Các phần của mỗi giải thích tham chiếu đến tuyên bố và bằng chứng được mã màu theo cùng một cách (Tuyên bố = Đỏ, Bằng chứng 1 = Xanh dương, Bằng chứng 3 = Xanh lá cây).

Nhiệm vụ của bạn là đọc yêu cầu, bằng chứng và các giải thích, và xếp hạng từng giải thích dựa trên năm đặc tính.

Bây giờ, bạn có thể thử ví dụ dưới đây!

