Những Phần Thiếu: Tăng Cường Xác Thực Thực Tế với Phát Hiện Nửa Sự Thật

Yixuan Tang Jincheng Wang Anthony K.H. Tung

Trường Máy tính, Đại học Quốc gia Singapore yixuan@comp.nus.edu.sg, bertrand.wongjc@gmail.com, atung@comp.nus.edu.sg

Tóm tắt

Các hệ thống xác minh sự thật thường đánh giá xem một tuyên bố có được hỗ trợ bởi bằng chứng thu thập hay không, giả sử rằng tính chính xác chỉ phụ thuộc vào những gì được nêu ra. Tuy nhiên, nhiều tuyên bố trong thế giới thực là nửa sự thật, đúng về mặt thực tế nhưng gây hiểu nhầm do bỏ sót ngữ cảnh quan trọng. Các mô hình hiện có gặp khó khăn với những trường hợp như vậy, vì chúng không được thiết kế để suy luận về thông tin bị bỏ sót. Chúng tôi giới thiệu nhiệm vụ phát hiện nửa sự thật, và đề xuất POLITIFACT-HIDDEN, một chuẩn đánh giá mới với 15 nghìn tuyên bố chính trị được chú thích với sự phù hợp bằng chứng ở mức câu và suy luận về ý định của tuyên bố. Để giải quyết thách thức này, chúng tôi giới thiệu TRACER, một khuôn khổ đánh giá lại theo mô-đun giúp xác định thông tin sai lệch dựa trên sự bỏ sót bằng cách căn chỉnh bằng chứng, suy luận ý định ngụ ý, và ước tính tác động nhân quả của nội dung bị ẩn. TRACER có thể được tích hợp vào các quy trình xác minh sự thật hiện có và liên tục cải thiện hiệu suất trên nhiều cơ sở mạnh. Đáng chú ý, nó tăng chỉ số F1 của phân loại Nửa Sự Thật.

1 Giới thiệu

Sự lan truyền nhanh chóng của nội dung số đã khiến việc xác minh sự thật trở thành một yếu tố quan trọng trong cuộc chiến chống lại thông tin sai lệch và thúc đẩy diễn đàn công cộng đáng tin cậy. Các hệ thống kiểm tra sự thật truyền thống theo một mô hình tiêu chuẩn: với một tuyên bố và một bộ bằng chứng, hệ thống phân loại tuyên bố là đúng, sai, hoặc không đủ thông tin (Chen và Shu, 2024). Những hệ thống này hiệu quả trong việc xác định các tuyên bố rõ ràng sai và tiếp tục đóng vai trò là xương sống của các quy trình xác minh tự động.

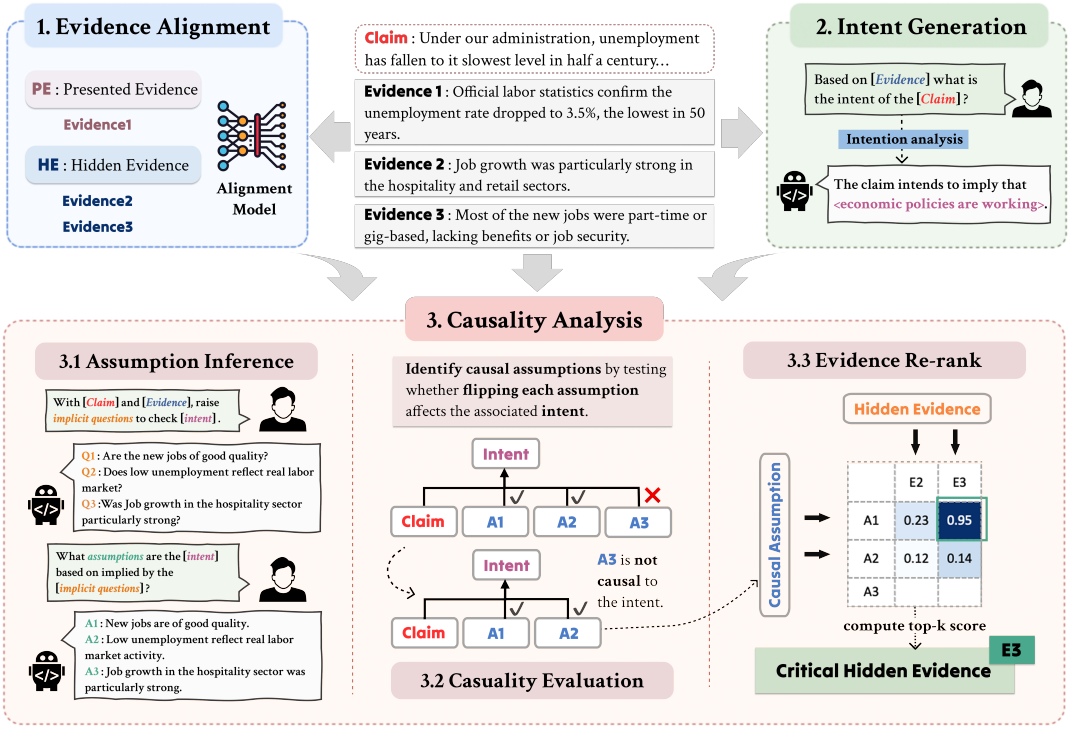
Tuy nhiên, nhiều tuyên bố trong thế giới thực không hoàn toàn sai nhưng vẫn gây hiểu lầm do bỏ sót bối cảnh quan trọng. Thông tin sai lệch có thể phát triển dynamically khi được lan truyền dưới các quan điểm chính trị khác nhau (Chong et al., 2025), những điều này thường được gọi là nửa sự thật, tức là những t uyên bố về mặt sự thật là đúng nhưng chiến lược thì chưa đầy đủ (Singamsetty et al., 2023; Jaradat et al., 2024). Xem ví dụ trong Bảng 1, nơi một chính trị gia tuyên bố rằng tỷ lệ thất nghiệp đã xuống mức thấp nhất trong 50 năm. Mặc dù số liệu này về mặt thực tế l à chính xác, nhưng nó bỏ qua các thông tin quan tr ọng, chẳng hạn như sự gia tăng các công việc bán thời gian và tình trạng lực lượng lao động trì trệ, điều này làm suy yếu câu chuyện ngụ ý về thành công kinh tế rộng rãi. Các mô hình xác minh sự thật (FV) tiêu chuẩn, vốn tập trung vào việc xác thực tính đúng đắn ở bề mặt, đánh dấu những tuyên bố như vậy là đúng, nhưng không nắm bắt được bản chất gây hiểu lầm của việc bỏ sót chọn lọc.

Khẳng định: Dưới sự quản lý của chúng tôi, tình trạng thất nghiệp đã giảm xuống mức thấp nhất trong nửa thế kỷ, chứng tỏ rằng chúng ta các chính sách kinh tế đang có hiệu quả.
Bằng chứng được trình bày (PE):
• Các thống kê lao động chính thức xác nhận tỷ lệ thất nghiệp giảm xuống còn 3,5%, mức thấp nhất trong 50 năm.
Bằng chứng ẩn (HE):
• Hầu hết các công việc mới đều là bán thời gian hoặc dựa trên công việc tạm, thiếu lợi ích hoặc an ninh công việc. →CHE • Tỷ lệ tham gia lực lượng lao động vẫn thấp, với nhiều người bị nản lòng người lao động cao tuổi không còn được tính. • Tăng trưởng việc làm đặc biệt mạnh trong ngành khách sạn và các ngành bán lẻ.
Phán quyết bởi Mô hình FV Chuẩn:
Đúng: Tuyên bố này được hỗ trợ về mặt thực tế bởi các số liệu thống kê chính thức.
Phán quyết Đánh giá lại TRACER:
Một nửa sự thật: Mặc dù con số thất nghiệp là chính xác, sự bỏ qua chất lượng công việc và bối cảnh tham gia gây sai lệch thành công kinh tế ngầm ý

Bảng 1: Một tuyên bố chính trị đúng sự thật được TRACER đánh giá lại là gây hiểu lầm (Một phần đúng) thông qua phân tích Bằng chứng Ẩn Quan trọng (CHE).

Thách thức này làm nổi bật một hạn chế cơ bản trong các quy trình FV hiện có: chúng không được thiết kế để suy luận về những gì còn thiếu. Các mô hình hiện tại thường đánh giá những gì được nêu ra, coi tính xác thực như một thuộc tính rời rạc dựa trên sự suy diễn văn bản

Kỷ yếu Hội nghị năm 2025 về Các Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên, các trang 33979–33996, ngày 4-9 tháng 11, 2025 ©2025 Hiệp hội Ngôn ngữ Học Máy Tính



Hình 1: Tổng quan về khung TRACER để phát hiện nửa sự thật. Hệ thống xác định Bằng chứng Ẩn Quan trọng (CHE) thông qua việc căn chỉnh bằng chứng, tạo ý định, và phân tích nhân quả, đồng thời đánh giá lại các tuyên bố về thông tin sai lệch dựa trên sự thiếu sót.

ment (Molina et al., 2019; Estornell et al., 2020). Tuy nhiên, trên thực tế, tính chân thực thường được định hình bởi cả những gì được nói và những gì không được nói. Thông tin sai lệch dựa trên việc bỏ sót khai thác khoảng trống này, chiếm một khu vực xám giữa sự thật và giả dối mà các hệ thống tiêu chuẩn khó có thể xử lý.

Trong bài báo này, chúng tôi giới thiệu nhiệm vụ phát hiện nửa sự thật, bổ sung cho việc xác minh sự thật truyền thống bằng cách mô hình hóa tính đầy đủ. Chúng tôi định nghĩa nửa sự thật là những tuyên bố đúng về mặt thực tế nhưng bỏ sót Bằng chứng Ẩn Quan trọng (CHE) — thông tin mà nếu được đưa vào, s ẽ thay đổi đáng kể mức độ có thể tin được của ý nghĩa ngụ ý của tuyên bố. Mục tiêu của chúng tôi là xác định những thiếu sót như vậy và đánh giá tác động của chúng đối với ý định suy luận từ tuyên bố.

Để giải quyết nhiệm vụ này, chúng tôi đề xuất TRACER (Đánh giá lại Sự thật với Lý luận về Bằng chứng Ẩn Quan trọng), một khung làm việc nhằm tăng cường các hệ thống kiểm tra sự thật bằng cách đưa vào lý luận nhận biết thiếu sót. TRACER hoạt động theo ba giai đoạn: (1) căn chỉnh bằng chứng, để phân loại bằng chứng thu thập được là một phần đã được trình bày hay bị ẩn giấu; (2) tạo ý định, để khôi phục thông điệp ngầm của tuyên bố; và (3) phân tích quan hệ nhân q uả, để xác định xem Bằng chứng Ẩn có làm suy yếu ý định suy luận hay không. Những thành phần này cung cấp dữ liệu cho một mô-đun đánh giá lại nhẹ, nhằm xem xét lại các tuyên bố, đặc biệt là những tuyên bố ban đầu được gán nhãn là đúng.

và xác định những thiếu sót gây hiểu lầm. TRACER không phụ thuộc mô hình và có thể được tích hợp vào cả quy trình FV dựa trên tác nhân và dựa trên câu lệnh hoán dụ.

Để hỗ trợ nhiệm vụ này, chúng tôi xây dựng POLITIFACT-HIDDEN, một tập dữ liệu chuẩn dựa trên tập hợp dữ liệu PolitiFact. Nó chứa khoảng 15 nghìn tuyên bố được chú thích với nhãn ở cấp câu cho Thông tin và Bằng chứng Ẩn, cùng với các mục đích của tuyê n bố được suy luận và xác thực thông qua sự kết hợp giữa việc tạo prompt với mô hình ngôn ngữ lớn (LLM) và kiểm soát chất lượng bởi con người. Theo như chúng tôi biết, đây là tập dữ liệu đầu tiên chú thích rõ ràng cả sự bỏ sót và mục đích, cho phép nghiên cứu hệ thống về những nửa sự thật ở quy mô lớn.

Các đóng góp của chúng tôi như sau:

1. Chúng tôi định hình việc phát hiện nửa sự t hật như một nhiệm vụ mới trong xác minh t hông tin, nhắm vào những tuyên bố bỏ qua bối cảnh quan trọng trong khi vẫn đúng sự thật.

2. Chúng tôi giới thiệu POLITIFACT-HIDDEN, một bộ chuẩn quy mô lớn với các chú thích chi tiết cho Bằng chứng được Trình bày / Ẩn và ý định khẳng định suy luận.

3. Chúng tôi đề xuất TRACER, một khuôn khổ ba giai đoạn xác định thông tin sai lệch dựa trên bỏ sót thông qua việc căn chỉnh bằng chứng, ý định

mô hình hóa, và lý luận nhân quả. TRACER có t hể được triển khai như một mô-đun đánh giá lại và mang lại những cải thiện đáng kể trong việc phát hiện nửa sự thật trên nhiều cơ sở mạnh.

Bằng cách mô hình hóa tính đầy đủ cùng với tính chính xác, công trình này thúc đẩy ranh giới của việc xác minh sự thật. Nó giải quyết một điểm mù trong các hệ thống hiện tại và cung cấp một khuôn khổ có thể tổng quát hóa để phát hiện các hình thức thông tin sai lệch tinh vi hơn, hoạt động thông qua việc bỏ sót thay vì xuyên tạc.

2 Công trình liên quan

Xác minh sự thật. Xác minh sự thật thường được trình bày như một quy trình ba giai đoạn bao gồm phát hiện tuyên bố, truy xuất bằng chứng và phân loại tuyên bố thành Hỗ trợ, Bác bỏ, hoặc Không đủ Thông tin (Thorne et al., 2018; Guo et al., 2022). Các chuẩn mực như FEVER (Thorne et al., 2018) và LIAR (Wang, 2017) đã tạo điều kiện cho tiến bộ đáng kể trong lĩnh vực này. Hầu hết các hệ thống hiện có tập trung vào độ chính xác bề mặt của thông tin, nhằm mục đích so khớp các tuyên bố với các sự kiện đã được truy xuất. Mặc dù có hiệu quả đối với những thông tin hoàn toàn sai, những phương pháp này kém phù hợp trong việc xử lý các thao túng dựa trên việc bỏ sót thông tin.

Bỏ sót và Nửa sự thật. Thông tin sai lệch dựa trên việc bỏ sót, bao gồm nửa sự thật, đã nhận được sự chú ý ngày càng tăng. Singamsetty và cộng sự (2023) giới thiệu việc chỉnh sửa tuyên bố có kiểm soát để phơi bày nội dung bị bỏ sót, và Chen và cộng sự (2022) đề xuất tạo ra các câu hỏi ngụ ý để phục hồi ngữ cảnh bị thiếu. Các bộ dữ liệu khác đã tích hợp các chú thích liên quan, chẳng hạn như Cherry-picking (Schlichtkrull và cộng sự, 2023) và Mixture (Yang và cộng sự, 2022), vốn chủ yếu ghi l ại bằng chứng mâu thuẫn hơn là các bỏ sót thực sự. Các sơ đồ này tập trung vào sự không nhất quán về thực tế (tức là sự tồn tại cả bằng chứng ủng hộ và bác bỏ), thay vì sự thiếu hoàn chỉnh về ngữ nghĩa hay thao túng dựa trên ý định. Ngược lại, công t rình của chúng tôi nhắm đến nửa sự thật, những tuyên bố về thực tế là chính xác nhưng chiến lược bỏ qua Bằng chứng Ẩn quan trọng (CHE) có ảnh hưởng đáng kể đến cách diễn giải. Các nỗ lực liên quan chặt chẽ là các nghiên cứu khám phá vai trò của ý định trong thông tin sai lệch, chẳng hạn như phân biệt thông tin sai sự thật thông qua việc che giấu mô hình hóa rõ ràng tác động nhân quả của Bằng chứng Ẩn đối với ý định suy luận mà không làm thay đổi tuyên bố gốc.

Kiểm tra sự thật dựa trên tư duy lập luận. Các phương pháp gần đây kết hợp tư duy có cấu trúc để cải thiện việc đánh giá tính xác thực. Các mô hình theo hướng chương trình như QACheck và ProgramFC (Pan et al., 2023b) tạo ra các bước trung gian để hỗ trợ việc xác minh (Tang et al., 2021). Các phương pháp dựa trên lập luận, chẳng hạn như CHECKWHY (Si et al., 2024), mô hình hóa các liên kết nhân quả trong chuỗi bằng chứng. Trong khi đó, các phương pháp dựa trên prompt như HiSS (Zhang và Gao, 2023) và Flan-T5 (Chung et al., 2022) tận dụng các mô hình ngôn ngữ lớn để xác minh từng bước. Các công trình khác khám phá mô hình hóa ý định bằng cách học đối lập (Yang et al., 2024) hoặc truy xuất tinh chỉnh (Wang et al., 2024). Công trình của chúng tôi bổ sung cho các nỗ lực này bằng cách giới thiệu tư duy nhận biết bỏ sót và cung cấp một khung mô-đun có thể tích hợp vào cả các quy trình có cấu trúc và tạo sinh.

3 Hình thành Nhiệm vụ

Chúng tôi định nghĩa việc phát hiện nửa sự thật như một sự mở rộng của việc xác minh sự thật, tập trung vào tính đầy đủ của thông tin thực tế. Một tuyên bố có thể chính xác về mặt thực tế khi được tách riêng, nhưng vẫn tạo ra ấn tượng sai lệch bằng cách bỏ qua thông tin liên quan có ảnh hưởng đến cách giải thích của nó. Mục tiêu là xác định những thiếu sót này và đánh giá xem chúng có ảnh hưởng đáng kể đến mức độ hợp lý của thông điệp ẩn ý trong tuyên bố hay không.

Một cách chính thức, đối với một khẳng định C và một tập hợp các câu chứng cứ thu thập được $E = \{e_1, e_2, \ldots, e_n\}$ liên quan đến C, mục tiêu là phân loại khẳng định đó vào một trong ba danh mục: Đúng, Một nửa đúng hoặc Sai. Việc phân loại này được xác định không chỉ dựa trên hỗ trợ thực tế mà còn dựa vào sự hiện diện hoặc vắng mặt của Chứng Cứ Ẩn Quan Trọng (CHE) $\subseteq E$, mà cả hai điều kiện sau đều thỏa mãn: (1) không được trình bày trong khẳng định, và (2) cần thiết để hiểu hoặc thách thức kết luận ngầm của khẳng định.

Để hỗ trợ điều này, chúng tôi định nghĩa các thành phần sau:

- Bằng Chứng Trình Bày (PE): Các câu trong E được nêu rõ ràng hoặc ngụ ý rõ ràng trong tuyên bố.

- Bằng chứng ẩn (HE): Các câu trong E có liên quan đến luận điểm nhưng không được đề cập đến.

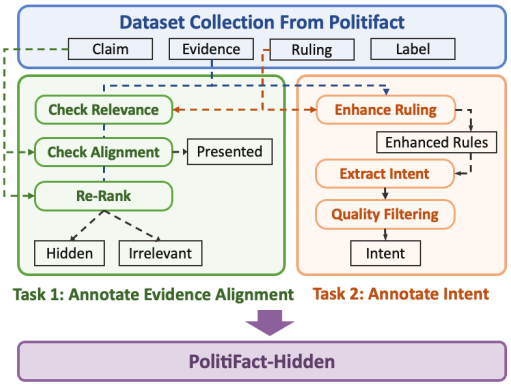
- Ý định: Kết luận hoặc thông điệp ngầm mà lập luận có khả năng truyền đạt đến người đọc.

Nhãn hợp nhất	Xếp hạng gốc
True	True
Nửa đúng	Phần lớn đúng, một nửa đúng
Sai	Hầu hết sai, Sai, Nói dối trơ trẽn

Bảng 2: Bản đồ từ các đánh giá gốc của PolitiFact sang các nhãn hợp nhất.

Chia	True	Nửa đúng	Sai	Tổng cộng
Tàu	1,352	4,564	6,078	11,994
Dev	64	195	741	1,000
Test	93	406	1,501	2,000

Bảng 3: Phân bố nhãn trong tập dữ liệu POLITIFACT-HIDDEN theo các phần train/dev/test.



Hình 2: Minh họa quy trình gán nhãn bán tự động để xây dựng PolitiFact-HIDDEN, kết hợp việc gợi ý GPT-4o-mini với kiểm soát chất lượng của con người.

• Bằng chứng ẩn quan trọng (CHE): Một tập hợp nhỏ của HE mà, nếu được tiết lộ, sẽ ảnh hưởng đáng kể đến tính xác thực của ý định nhận định.

Công thức này có liên kết chặt chẽ với quy t rình FV truyền thống nhưng thêm một lớp suy luận mới: hệ thống không chỉ phải xác minh những gì được nói, mà còn phải suy luận về những gì bị bỏ qua. Bằng cách tập trung vào những thiếu sót làm thay đổi ý nghĩa của một tuyên bố, việc phát hiện nửa sự thật hỗ trợ hiểu biết tinh tế hơn về thông ti n sai lệch và giúp phát hiện những hình thức thao túng tinh vi mà các hệ thống FV thông thường có thể bỏ qua.

4 Bộ dữ liệu: POLITIFACT-HIDDEN

Như minh họa trong Hình 2, chúng tôi phát triển một quy trình chú thích bán tự động (Hình 2) kết hợp việc gợi ý GPT-4o-mini và tinh chỉnh hỗ trợ bởi mô hình để gán nhãn mỗi tuyên bố với sự phù hợp bằng chứng và Ý định.

Chúng tôi giới thiệu POLITIFACT-HIDDEN, một chuẩn mực cho việc xác minh thông tin nhận thức về bỏ sót. Nó mở rộng tập dữ liệu PolitiFact gốc với các chú thích chi tiết ghi lại cả Bằng chứng được Trình bày và Bằng chứng Ẩn, cũng như Ý định đằng sau mỗi tuyên bố. Những chú thích này cho phép đánh giá có hệ thống liệu nội dung bị bỏ sót, tức là Bằng chứng Ẩn Quan trọng (CHE), có làm thay đổi ý nghĩa ngụ ý của tuyên bố hay không.

4.1 Nguồn dữ liệu và Sơ đồ nhãn

Bộ dữ liệu được xây dựng dựa trên các bài viết kiểm chứng sự thật từ PolitiFact, bao gồm cả một tuyên bố ngắn gọn và một bài viết phán quyết kèm theo. Khác với nhiều nguồn kiểm chứng sự thật khác, PolitiFact coi trọng tính đầy đủ trong các tiêu chí đánh giá của mình: một tuyên bố được đánh giá là Đúng phải vừa chính xác vừa đầy đủ, trong khi Đa phần Đúng và Một nửa Đúng chỉ ra đúng sự thật nhưng thiếu bối cảnh (Holan, 2018). Ngược lại, Phần lớn sai phản ánh sự tồn tại của các bằng chứng mâu thuẫn.

Chúng tôi hợp nhất sáu mức đánh giá gốc của PolitiFact thành ba nhãn thô để phù hợp với nhiệ m vụ phát hiện nửa sự thật của chúng tôi:

Mỗi bài báo được chia thành các đoạn chứng cứ, cung cấp bối cảnh thực tế, và các đoạn phán quyết, giải thích cho bản án cuối cùng. Để ngăn chặn rò rỉ nhãn, chúng tôi phân tách các phân đoạn này bằng các dấu hiệu cấu trúc (ví dụ: “Phán quyết của chúng tôi”) và loại bỏ nội dung phán quyết khỏi đầu vào của mô hình.

Để cải thiện khả năng tổng quát hóa và kiểm tra độ bền về mặt thời gian, chúng tôi thu thập thêm 2.000 tuyên bố từ năm 2020–2025 để tạo thành một bộ kiểm tra tách biệt về mặt thời gian. Các tuyên bố có trùng ngày được loại bỏ khỏi tập huấn luyện. Bộ dữ liệu kết quả chứa 14.994 tuyên bố. Thống kê chi tiết được trình bày trong Bảng 3.

4.2 Quy trình Chú thích

Ghi chú bằng chứng: Đối với mỗi câu bằng chứng, chúng tôi xác định liệu nó đã được phản ánh trong tuyên bố hay chưa. Điều này bao gồm:

1. Kiểm tra mức độ liên quan: Lọc ra nội dung không liên quan bằng cách sử dụng gợi ý suy l uận dựa trên LLM. 2. Kiểm tra trình bày: Đánh giá xem nội dung được nêu rõ ràng hay ngụ ý trong tuyên bố. 3. Tinh chỉnh độ tương đồng: Sử dụng độ tương đồng cosin với embeddings XLM-RoBERTa (Nils Reimers, 2019) để tinh chỉnh các trường hợp khó và giảm thiểu ảo tưởng.

Kích thước	yêu cầu	LLM-Tích cực	Đã xác nhận con ng ười	Thỏa thuận
Khả tín	Ý định suy ra không được mâu thuẫn với tuyên bố.	95	94	98,9%
Ngầm định	Ý định nên được ngụ ý, không nên nói ra một cách rõ ràng.	94	93	98,9%
Đầy đủ	Mô tả phải cụ thể và nhiều thông tin.	81	80	98,8%
Độ dễ đọc	Ý định phải được diễn đạt một cách rõ ràng và trôi chảy.	76	70	92,1%

Bảng 4: Sự đồng thuận giữa LLM và các chú thích của con người trên các khía cạnh chất lượng ý định.

Bằng chứng được gắn nhãn là PE hoặc HE. Kiểm tra thủ công 50 mẫu cho thấy sự đồng thuận 88% giữa các dự đoán của LLM và đánh giá của co n người, xác nhận quá trình căn chỉnh.

Chú thích Ý định. Một yếu tố quan trọng trong việc phát hiện nửa sự thật là Ý định của lời khẳng định, tức là thông điệp hoặc đánh giá ngầm mà nó cố gắng truyền tải. Ý định được trích xuất qua 3 bước:

1. Cải thiện phán quyết: Cải thiện văn bản phán quyết bằng cách thêm bằng chứng hỗ trợ để làm rõ ý.

2. Trích xuất Ý định: Sử dụng gợi ý được tinh chỉnh theo hướng dẫn để trích xuất kết luận dự định của tuyên bố.

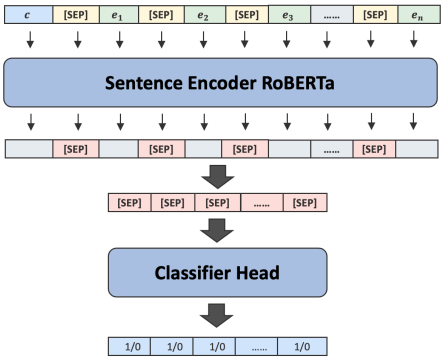
3. Lọc Chất Lượng: Lọc các ý định đã trích xuất bằng bốn tiêu chí, cụ thể là tính hợp lý, tính ngụ ý, tính đầy đủ và khả năng đọc.

Để xác thực chất lượng của việc lọc dựa trên LLM, chúng tôi đã có hai người chú thích độc lập đánh giá 100 mẫu theo cùng bốn chiều đánh giá. Sự đồng thuận giữa LLM và cả hai người chú thích là cao (92,1-98,9% theo các chiều), cho thấy phương pháp hỗ trợ bởi LLM ghi lại một cách đáng tin cậy các mục đích có chất lượng cao cho việc suy luận tiếp theo. Toàn bộ các lời nhắc đánh giá mục đích được cung cấp trong Phụ lục A.

5 Khung TRACER

Chúng tôi đề xuất TRACER, một khuôn khổ mô-đun để phát hiện những nửa sự thật bằng cách xác định và đánh giá bối cảnh bị bỏ sót. TRACER được thiết kế để tích hợp với các hệ thống kiểm chứng sự thật (FV) hiện có bằng cách đánh giá lại các tuyên bố, đặc biệt là những tuyên bố ban đầu được gắn nhãn là Đúng, để xác định xem việc bỏ sót có làm thay đổi quan trọng thông điệp mà tuyên bố muốn truyền tải hay không.

TRACER hoạt động theo ba giai đoạn: (1) căn chỉnh bằng chứng, (2) tạo ý định, và (3) ước lượng nguyên nhân của nội dung bị bỏ sót. Các thành phần này hỗ trợ một mô-đun đánh giá lại cuối cùng nhằm tinh chỉnh đầu ra của các mô hình FV cơ sở.



Hình 3: Kiến trúc của mô-đun căn chỉnh bằng chứng, phân loại mỗi câu bằng chứng là được trình bày hay ẩn so với khẳng định.

5.1 Căn chỉnh bằng chứng

Giai đoạn đầu tiên xác định liệu mỗi câu bằng chứng $e_i \in E$ có được phản ánh rõ ràng hay ngầm hiểu trong tuyên bố C. Chúng tôi hình thành đây là một nhiệm vụ phân loại nhị phân, gán mỗi e_i vào một trong hai loại: Bằng chứng được trình bày (PE) hoặc Bằng chứng ẩn (HE). Chỉ HE mới được chuyển tiếp để phân tích thêm.

Như thể hiện trong Hình 3, một mô hình đối sánh dựa trên transformer được áp dụng. Mỗi cặp (C, e_i) được kết hợp và mã hóa bằng RoBERTa-large (Liu et al., 2019). Một đầu phân loại dự đoán liệu nội dung bằng chứng có xuất hiện trong tuyên bố hay không. Bước đối sánh này cho phép TRACER tách ra các thông tin có khả năng bị bỏ qua nhưng có liên quan cho việc suy luận ý định và nhân quả ở các bước tiếp theo.

5.2 Tạo Ý định

Hiểu được ý định tiềm ẩn này là cần thiết để xác định liệu nội dung bị bỏ sót có gây hiểu lầm hay không. Như đã mô tả trong Mục 4.2, chúng tôi tinh chỉnh LLM bằng cách sử dụng đầu vào bao gồm tuyên bố và bối cảnh bằng chứng liên quan để suy luận ý định. Cách trình bày dựa trên gợi ý này khuyến khích mô hình trích xuất các kết luận ngầm mà không dựa vào các mẫu được định nghĩa thủ công. Những ý định thu được này phục vụ như các mỏ neo ngữ nghĩa cho một phân tích nhân quả tiếp theo.

5.3 Phân tích nhân quả

Mặc dù các giả định được suy ra từ HE, không phải tất cả các câu HE đều ảnh hưởng trực tiếp đến tính hợp lý của ý định. Nhiều câu là gián tiếp hoặc trung lập. Để phân biệt Bằng chứng Ẩn Quan trọng (CHE) với các bỏ sót trung lập, chúng tôi ước tính ảnh hưởng nhân quả của từng câu HE đối với ý định s uy ra.

Lấy cảm hứng từ các khung lý luận quy nạp (Chen et al., 2022), chúng tôi tạo ra các giả định ứng viên A_i mà phải đúng để ý định Z là hợp lệ. Những giả định này được suy ra từ bằng chứng thông qua việc tạo câu hỏi nhị phân và trừu tượng hóa.

Sau đó, chúng tôi đánh giá tác động của từng A_i bằng cách sử dụng phương pháp gợi ý phản thực: với $do\,(A_i = \neg A_i)$, liệu ý định Z có vẫn giữ nguyên không? Nếu không, A_i được đánh dấu là quan trọng về mặt nguyên nhân. Với mỗi giả định đã được xác nhận, chúng tôi truy xuất CHE tương ứng từ hồ bơi HE bằng cách chọn các câu vừa ủng hộ vừa mâu thuẫn với nó, dựa trên sự tương đồng ngữ nghĩa và mô hình NLI xác minh sự suy diễn logic. Quá trình tinh chỉnh hai bước này ngăn không cho các bằng chứng không liên quan hoặc liên quan yếu bị phân loại sai là CHE.

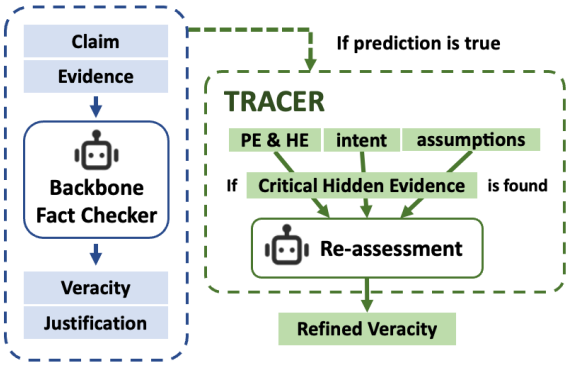
5.4 Mô-đun Đánh giá Lại Cuối cùng

Để xác định nhãn cuối cùng (Đúng, Nửa đúng hoặc Sai), chúng tôi kết hợp ý định suy luận, các giả định và CHE đã chọn vào một mô-đun đánh giá lại (RA). Mô-đun này đánh giá lại dự đoán FV ban đầu, đặc biệt khi tuyên bố ban đầu được phân loại là Đúng.

Nếu không tìm thấy CHE, nhãn gốc sẽ được giữ nguyên. Nếu CHE làm thay đổi tính hợp lý của ý định, hệ thống sẽ phân loại lại tuyên bố là Một phần đúng hoặc Sai, tùy thuộc vào tính chất của mâu thuẫn. Giai đoạn tái đánh giá này được triển khai như một mô-đun dựa trên prompt. Nó được thiết kế để không phụ thuộc vào mô hình và có thể tích hợp vào các quy trình FV hiện có để nâng cao khả năng phát hiện thao túng dựa trên sự bỏ sót. Chúng tôi cung cấp các ví dụ prompt đầy đủ được sử dụng trong từng thành phần của TRACER ở Phụ lục B.

6 Thí nghiệm

Chúng tôi đánh giá TRACER bằng cách tích hợp nó vào các mô hình xác thực thông tin (FV) hiện có và đo lường hiệu quả của nó trong việc nhận diện thông tin sai lệch dựa trên việc bỏ sót. Cụ thể, chúng tôi so sánh các mô hình được tăng cường TRACER với các hệ thống FV mạnh và tiến hành các nghiên cứu Ablation để đánh giá tác động của từng thành phần riêng lẻ. Các chỉ số đánh giá bao gồm Độ chính xác tổng thể, macro-F1 và F1 trên Half-



Hình 4: TRACER được tích hợp vào một quy trình xác minh sự thật như một mô-đun đánh giá lại.

Lớp thực (F1(H)), phản ánh khả năng của hệ thống trong việc nắm bắt các hiểu lầm do bỏ sót.

6.1 Căn chỉnh bằng chứng

Chúng tôi đào tạo mô hình căn chỉnh bằng chứng của mình sử dụng RoBERTa-large[1], với chiến lược lấy mẫu theo lô có nhận thức ngữ cảnh. Ở mỗi b ước huấn luyện, các đoạn bằng chứng liên tiếp được nhóm lại thành một lô để giúp mô hình tận dụng các tín hiệu ngữ cảnh trong lô. Chúng tôi so sánh thiết lập này với một cơ sở nơi mỗi cặp yêu cầu-bằng chứng được xử lý độc lập (tức là không nhận thức ngữ cảnh). Cả hai mô hình đều được huấn luyện trong 5 epoch với kích thước lô là 8 và tốc độ học là 1e-5.

Phương pháp	Độ chính xác	F1
RoBERTa-lớn	93.2	90.3
TRACER (nhận thức ngữ cảnh)	**94.0**	**91.6**

Bảng 5: Hiệu suất căn chỉnh chứng cứ.

Như được trình bày trong Bảng 5, việc huấn luyện nhận biết ngữ cảnh cải thiện điểm F1 lên 1,3 và độ chính xác lên 0,8, cho thấy khả năng phát hiện bằng chứng bỏ sót được nâng cao.

6.2 Tạo Ý định

Chúng tôi điều chỉnh tinh chỉnh GPT-4o-mini thông qua API của OpenAI để tạo ra các câu tuyên bố ý định ngầm. Mỗi đầu vào huấn luyện bao gồm tuyê n bố và các đoạn chứng cứ liên quan. Chúng tôi so sánh phương pháp này với một cơ sở 4-shot trong ngữ cảnh gợi ý. Mô hình tinh chỉnh được huấn luyện trong 3 epoch với kích thước lô là 4.

Như được thể hiện trong Bảng 6, việc tinh chỉnh liên tục vượt trội hơn việc gợi ý trên tất cả các chỉ số, ủng hộ quyết định của chúng tôi sử d ụng trích xuất ý định có giám sát trong TRACER.

[1]https://huggingface.co/FacebookAI/roberta-large

Phương pháp	ROUGE-L	BLEU	Điểm BERT
Vài ví dụ	37.7	6.1	91.2
Tinh chỉnh	**46.2**	**8.0**	**91.5**

Bảng 6: Hiệu suất của các phương pháp tạo ý định.

Phương pháp	Độ chính xác		F1	
	Dev	Test	Dev	Test
Kiểm tra chất lượng	48.5	48.8	38.0	38.6
Chương trình FC	55.4	56.9	32.9	34.2
KIỂM TRA TẠI SAO	74.8	65.9	64.2	54.6
Flan-T5	69.7	70.0	50.8	50.4
CoT	76.6	76.3	68.5	64.3
CoT +RA	77.3	78.5	**68.7**	**68.0**
Cải thiện	*↑ 0.7*	*↑ 2.2*	*↑ 0.2*	*↑ 3.7*
HiSS	76.3	78.3	60.3	59.4
HiSS +RA	**78.1**	**81.9**	64.3	65.7
Cải thiện	*↑ 1.8*	*↑ 3.6*	*↑ 4.1*	*↑ 6.3*

Bảng 7: Độ chính xác tổng thể và macro-F1 trong xác minh sự thật. RA biểu thị sự tích hợp của mô-đun đánh giá lại TRACER.

6.3 Các đường cơ sở

TRACER yêu cầu phương pháp kiểm chứng sự thật để đưa ra các lý do biện minh cho độ chính xác của tuyên bố. Điều này là vì TRACER đánh giá tính chân thực bằng cách xem xét đồng thời độ chính xác về mặt thực tế của tuyên bố và tính khả thi của ý định của nó, trong đó phần đầu tiên nên được hỗ trợ bởi các bước lý luận rõ ràng. Chúng tôi đánh giá TRACER dựa trên hai mô hình kiểm chứng sự thật hàng đầu phù hợp để tích hợp:

•Chuỗi suy nghĩ (CoT) (Kojima et al., 2022): một cơ sở khởi đầu zero-shot, nơi mô hình được hướng dẫn tạo ra các bước suy luận trung gian trước khi đưa ra phán quyết kiểm tra sự thật cuối cùng.

•HiSS (Zhang và Gao, 2023): một công cụ xác minh theo hướng dẫn tiên tiến sử dụng lập luận có cấu trúc bằng cách phân tách tuyên bố thành nhiều tuyên bố phụ có thể xác minh được và đánh giá chúng từng bước một.

Chúng tôi cũng báo cáo kết quả cho bốn đường cơ sở sau:

•QACheck (Pan et al., 2023a) và ProgramFC (Pan et al., 2023b): những công cụ kiểm tra sự thật dựa trê n tác nhân. QACheck phân tách các tuyên bố thành các câu hỏi phụ và xác thực chúng bằng bằng chứng. ProgramFC coi việc xác thực như một chương trình có cấu trúc gồm các nhiệm vụ phụ được tạo ra thông qua học theo ngữ cảnh và được thực hiện bởi các tác nhân mô-đun.

• CHECKWHY (Si và cộng sự, 2024) và Flan-T5 (Chung và cộng sự, 2022): các LLM dựa trên phương pháp prompting. CHECKWHY mô hình hóa lập luận nhân quả thông qua các cấu trúc lập luận. Flan-T5 được xác định là một công cụ kiểm chứng sự thật mạnh trong các đánh giá về ảo tưởng.

Để đảm bảo tính công bằng, chúng tôi đánh giá tất cả các đường cơ sở sử dụng GPT-4o-mini, ngoại trừ trong những trường hợp công trình trước đó cho thấy một mô hình nền khác mang lại hiệu suất mạnh hơn. Đối với HiSS, chúng tôi nhận thấy GPT-3.5-turbo luôn vượt trội so với GPT-4o-mini.

6.4 Kết quả chính

Chúng tôi trình bày hiệu suất tổng thể của các mô hình tích hợp TRACER và các mô hình cơ sở trong Bảng 7 (Độ chính xác và macro-F1) và Bảng 8 (Độ chính xác, Độ thu hồi và F1 trên danh mục Half-True). Kết quả nhấn mạnh sự cải thiện nhất quán của TRACER cả trong việc xác minh sự thật tổng quát và các trường hợp nhạy cảm với việc bỏ sót khó khăn hơn.

Hiệu suất tổng thể. Bảng 7 cho thấy TRACER cải thiện cả độ chính xác và macro-F1 khi được thêm vào các mô hình cơ sở dựa trên suy luận mạnh. Ví dụ, tích hợp TRACER với HiSS cải thiện độ chính xác kiểm tra từ 78,3% lên 81,9%, và macro-F1 từ 59,4 lên 65,7. Tương tự, CoT cũng hưởng lợi từ TRACER với mức tăng 2,2 điểm về độ chính xác kiểm tra và tăng 3,7 điểm về macro-F1. Những cải thiện này được quan sát trên cả tập phát triển và tập kiểm tra, cho thấy TRACER là một mô-đun đánh giá lại đa dụng và bền vững.

Phát hiện Nửa-Sự Thật. Như được trình bày trong Bảng 8, TRACER cải thiện đáng kể hiệu suất trên l ớp Nửa-Sự Thật. Khi áp dụng vào HiSS, TRACER l àm tăng F1 lên 16,1 điểm trên tập kiểm tra (từ 44,4 lên 60,5) và hồi tưởng lên 28,9 điểm (từ 37,9 lên 66,8), chứng tỏ hiệu quả của nó trong việc nhận diện sự thao túng dựa trên bỏ sót. Những cải thiện tương tự cũng được thấy cho CoT, với F1 tăng từ 52,8 lên 60,2 và hồi tưởng tăng 15,5 điểm (từ 63,8 lên 79,3).

Các phương pháp cơ sở dựa trên tác nhân như QACheck và ProgramFC đạt điểm recall và F1 thấp, l àm nổi bật sự thiếu khả năng của chúng trong việc nắm bắt bối cảnh ẩn. Ngược lại, các phương pháp dựa trên gợi ý cạnh tranh hơn, nhưng vẫn hưởng lợi đáng kể từ việc đánh giá lại của TRACER. Những kết quả này xác nhận giả thuyết của chúng tôi rằng lập luận nhận thức thiếu sót, dựa trên việc căn cứ vào bằng chứng, mô hình hóa ý định và nhân quả

Phương pháp	Dev			Test		
	Độ chính xác	Nhắc lại	F1	Độ chính xác	Nhắc lại	F1
Kiểm tra chất lượng	24.0	55.1	33.4	24.3	54.4	33.6
Chương trình FC	11.8	2.0	3.5	18.2	6.9	10.0
KIỂM TRA TẠI SAO	43.2	76.5	55.3	34.3	58.1	43.1
Flan-T5	37.7	33.7	35.6	44.1	27.3	33.7
CoT	44.6	71.8	55.0	45.0	63.8	52.8
CoT +RA	45.5 ↑ *0.9*	**83.6** ↑ *11.8*	**59.0** ↑ *4.0*	48.5 ↑ *3.5*	**79.3** ↑ *15.5*	60.2 ↑ *7.4*
HiSS	34.9	47.6	40.2	53.7	37.9	44.4
HiSS +RA	**46.3** ↑ *11.4*	54.4 ↑ *6.8*	50.0 ↑ *9.8*	**55.3** ↑ *1.6*	66.8 ↑ *28.9*	**60.5** ↑ *16.1*

Bảng 8: Độ chính xác, Độ thu hồi và F1 trên danh mục Nửa Đúng. TRACER liên tục cải thiện việc nhận diện thao túng dựa trên bỏ sót trên tất cả các bộ nền tảng.

Phương pháp	True	Nửa đúng	Sai
CoT	52.9	52.8	**87.1**
CoT +RA	**56.7** ↑ *3.8*	**60.2** ↑ *7.4*	**87,1 (–)**
HiSS	44.7	44.4	88.9
HiSS +RA	**46.6** ↑ *1.9*	**60.5** ↑ *16.1*	**90.1** ↑ *1.2*

Bảng 9: Điểm F1 theo từng lớp trên tập kiểm tra.

Cfg	Ý định	Giả định	Nguyên nhân.	F1 (H)	F1
①	–	–	–	44.4	59.4
②	✓	–	–	50.9	64.7
③	✓	✓	–	**61.2**	61.7
④	✓	✓	✓	60.5	**65.7**

Bảng 10: Kết quả tháo rời các thành phần của TRACER.

phân tích, cải thiện đáng kể khả năng của mô hình trong việc phát hiện nửa sự thật.

Hiệu suất theo từng lớp. Để kiểm tra kỹ hơn tác động của TRACER đối với việc xác minh sự thật, chúng tôi báo cáo hiệu suất theo từng lớp cho các mô hình có hiệu suất tốt nhất. Như được trình bày trong Bảng 9, TRACER cải thiện đáng kể việc phân loại các tuyên bố Nửa đúng đồng thời duy trì hoặc nâng nhẹ hiệu suất trên các tuyên bố Đúng và Sai. Điều này xác nhận rằng những cải thiện quan sát được không đạt được với chi phí của các lớp khác.

Khái quát hóa. Để kiểm tra khả năng khái quát hóa của TRACER, chúng tôi đánh giá nó với mô hình mã nguồn mở LLaMA2-7B làm trình xác minh cơ bản trên khuôn khổ HiSS có hiệu suất cao nhất. Với TRACER, độ chính xác tăng từ 78,2 lên 82,3 và Macro-F1 từ 59,1 lên 65,4. Bảng phân tích hiệu suất theo lớp và phân tích kết quả theo độ dài câu khẳng định khác nhau được cung cấp trong Phụ l ục C.

6.5 Phân tích định tính

Để minh họa cách TRACER phát hiện thao túng dựa trên việc bỏ sót thông tin, chúng tôi trình bày các ví dụ đại diện từ bộ dữ liệu kiểm tra POLITIFACT-HIDDEN. Những trường hợp này cho thấy cách các tuyên bố chính xác về mặt thực tế vẫn có thể gây hiểu lầm t hông qua trình bày có chọn lọc, và cách TRACER sửa các phân loại sai như vậy bằng cách xác định Bằng chứng Ẩn Quan Trọng (Critical Hidden Evidence - C HE) và lý luận về ý định.

Ví dụ: Quy kết chi phí tăng gây hiểu lầm. Lời khẳng định: "Dưới thời kinh tế Obama, hóa đơn tiện ích cao hơn." Lời khẳng định này được HiSS đánh dấu là Đúng, vì nó phù hợp với dữ liệu cho thấy chi phí tiện ích tăng trong nhiệm kỳ của Tổng thống Obama. Tuy nhiên, TRACER suy luận một ý định quy lỗi cho các chính sách kinh tế của Obama về việc giá cả tăng. Sau đó, nó truy xuất CHE cho thấy giá điện thậm chí đã tăng nhanh hơn dưới chính quyền trước và theo một mô hình tương tự qua các nhiệm kỳ tổng thống. Điều này làm suy yếu việc quy kết nguyên nhân ngụ ý và dẫn đến việc TRACER sửa nhãn thành Một phần đúng.

Trích dẫn CHE: "Tỷ lệ tăng nhanh hơn đáng kể dưới thời Bush so với dưới thời Obama." "Xu hướng không khác biệt quá lớn giữa chính quyền Bush và Obama."

6.6 Nghiên cứu Ablation

Chúng tôi tiến hành một nghiên cứu ablation để đánh giá đóng góp của từng thành phần trong khung TRACER. Sử dụng HiSS làm trình xác minh cơ bản, chúng tôi lần lượt giới thiệu mô hình hóa ý định, suy đoán giả định và ước tính nhân quả. Kết quả được hiển thị trong Bảng 10.

Tác động của Mô hình Hành vi. Cài đặt ① đại diệ n cho mô hình HiSS cơ bản mà không có bất kỳ thành phần TRACER nào. Trong Cài đặt ②, chúng tôi giới thiệu việc tạo dự định nhưng bỏ qua suy luận giả định và ước lượng nhân quả. CHE được truy xuất trực tiếp dựa trên dự định suy luận được. Cấu hình này mang lại một kết quả phụ-

cải thiện đáng kể cả F1(H) và macro-F1, tăng từ 44,4 lên 50,9 và từ 59,4 lên 64,7, lần lượt, cho thấy rằng mô hình hóa ý định riêng lẻ cung cấp tín hiệu có ý nghĩa để xác định sự sai lệch dựa trên bỏ sót.

Suy luận Giả định. Cấu hình ③ mở rộng cấu hình trước đó bằng cách kết hợp suy luận giả định, nơi ý định được suy luận được phân tách thành các giả định có thể kiểm tra chi tiết hơn. Tuy nhiên, ước lượng quan hệ nhân quả vẫn bị vô hiệu hóa trong cấu hình này, có nghĩa là tất cả các giả định được tạo ra đều được xử lý ngang nhau trong quá trình truy xuất CHE. Điều này dẫn đến việc tăng thêm điểm F1(H) lên 61,2, xác nhận tính hữu ích của việc phân tách ý định thành các đơn vị lập luận cụ thể hơn. Tuy nhiên, macro-F1 giảm nhẹ xuống 61,7 do sự gia tăng các kết quả dương tính giả, cho thấy không phải tất cả các giả định đều đóng góp một cách có ích.

Lọc nhân quả. Trong Cài đặt ④, toàn bộ khung TRACER của chúng tôi được áp dụng, với tất cả các thành phần được bật, bao gồm ước lượng nhân quả để lọc ra các giả định không nhân quả hoặc giả mạo. Trong khi F1(H) giảm nhẹ xuống 60,5, macro-F1 cải thiện đáng kể lên 65,7. Điều này cho thấy việc kiểm tra nhân quả hiệu quả trong việc loại bỏ các giả định nhiễu hoặc không liên quan, dẫn đến một hệ thống cân bằng và mạnh mẽ hơn.

7 Kết luận

Công trình này giới thiệu nhiệm vụ phát hiện nửa sự thật, nhằm giải quyết các tuyên bố đúng về mặt thực tế nhưng gây hiểu lầm do bỏ sót bối cảnh. Để hỗ trợ điều này, chúng tôi giới thiệu POLITIFACT-HIDDEN, một chuẩn mới với một bộ dữ liệu được chú thích về sự phù hợp của bằng chứng và mục đích. Chúng tôi đề xuất TRACER, một khung mới phát hiện thông tin sai lệch dựa trên bỏ sót thông qua mô hình hóa mục đích và lý luận nhân quả trên nội dung bị ẩn. Khi tích hợp với các mô hình xác minh sự thật hiện có, TRACER liên tục cải thiện hiệu suất, đặc biệt đối với nửa sự thật, minh chứng cho tầm quan trọng của việc lý luận về thông tin bị bỏ sót. Công trình này nhấn mạnh việc xác minh có nhận thức về bỏ sót là bước tiếp theo quan trọng để xây dựng các hệ thống kiểm tra sự thật đáng tin cậy, và thiết lập TRACER như một khung tổng quát để giải quyết thử thách chưa được khai thác nhưng thiết yếu này.

Hạn chế

Trong khi TRACER thể hiện hiệu suất mạnh mẽ trong việc xác định thông tin sai lệch dựa trên việc bỏ sót, vẫn còn một số hạn chế. Thứ nhất, đánh giá của chúng tôi tập trung vào diễn ngôn chính trị, vì POLITIFACT-HIDDEN được xây dựng từ tập dữ liệu PolitiFact. Mặc dù TRACER được thiết kế để không phụ thuộc vào mô hình và độc lập với lĩnh vực, hiệu quả của nó trong các lĩnh vực khác, chẳng hạn như y tế hoặc tài chính, vẫn cần được xác thực, đặc biệt là trong những trường hợp mẫu bỏ sót có thể khác nhau. Thứ hai, TRACER giả định rằng mỗi tuyên bố thể hiện một ý định mạch lạc và có thể s uy luận được. Tuy nhiên, các tuyên bố trong thực tế có thể mơ hồ, không rõ ràng, hoặc truyền đạt nhiều ý định chồng chéo, điều này có thể tạo ra nhiễu trong quá trình suy luận tiếp theo. Các nghiên cứu trong tương lai có thể khám phá việc mô hình hóa ngữ dụng của tuyên bố và sự không chắc chắn về ý định một cách mạnh mẽ hơn để mở rộng khả năng áp dụng của TRACER cho các kịch bản rộng hơn.

Lời cảm ơn

Nghiên cứu này được Bộ Giáo dục Singapore hỗ tr ợ, theo khoản tài trợ MOE-AcRF TIER 3 (MOE-MOET32022-0001).

Tài liệu tham khảo

Canyu Chen và Kai Shu. 2024. Chống lại thông tin sai l ệch trong thời đại của các mô hình ngôn ngữ lớn: Cơ hội và thách thức. Tạp chí AI, 45(3):354–368.

Jifan Chen, Aniruddh Sriram, Eunsol Choi, và Greg Durrett. 2022. Tạo các câu hỏi phụ bề mặt và ngụ ý để kiểm chứng các tuyên bố phức tạp. Trong Kỷ yếu của Hội nghị về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên 2022, trang 3495–3516. Hiệp hội Ngôn ngữ Học Tính Toán.

Brian Jun Rong Chong, Yixuan Tang, và Anthony Kum Hoe Tung. 2025. Mpcg: Sinh tạo điều kiện theo nhiều vòng dựa trên cá nhân để mô hình hóa sự tiến hóa của thông tin sai lệch với llms. Trong EMNLP. Hiệp hội Ngôn ngữ học Máy tính.

Hyung Won Chung, Le Hou, Shayne Longpre, Barret Zoph, và những người khác. 2022. Mở rộng các mô hình ngôn ngữ được tinh chỉnh theo hướng dẫn. Bản in sẵn, arXiv:2210.11416.

Andrew Estornell, Sanmay Das, và Yevgeniy Vorobey-chik. 2020. Lừa dối thông qua những nửa sự thật. Kỷ yếu Hội nghị AAAI về Trí tuệ Nhân tạo, 34(06):10110–10117.

Zhijiang Guo, Michael Schlichtkrull, và Andreas Vlachos. 2022. Một khảo sát về kiểm tra sự thật tự động. Transactions of the Association for Computational Linguistics, 10:178–206.

Angie Drobnic Holan. 2018. Các nguyên tắc của truth-o-meter: Phương pháp luận kiểm tra sự thật độc lập của Politifact. Cập nhật lần cuối ngày 12 tháng 1 năm 2024.

Israa Jaradat, Haiqi Zhang, và Chengkai Li. 2024. Về việc phát hiện cherry-picking trong đưa tin tức sử dụng các mô hình ngôn ngữ lớn. CoRR, abs/2401.05650.

Takeshi Kojima, Shixiang Shane Gu, Machel Reid, Yu-taka Matsuo và Yusuke Iwasawa. 2022. Các mô hình ngôn ngữ lớn là những lý luận viên zero-shot. Trong Kỷ yếu của Hội nghị Quốc tế lần thứ 36 về Hệ thống Xử lý Thông tin Thần kinh, NIPS '22, Red Hook, NY, USA. Curran Associates Inc.

Jiyoung Lee và Keeheon Lee. 2024. Đo lường tính sai l ệch trong các bài báo dựa trên việc che giấu và phóng đại. Bản in trước, arXiv:2408.00156.

Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, và Veselin Stoyanov. 2019. Roberta: Một phương pháp tiền huấn luyện BERT được tối ưu hóa mạnh mẽ. CoRR, abs/1907.11692.

Maria D. Molina, S. Shyam Sundar, Thai Le, và Dong-won Lee. 2019. "tin giả" không chỉ đơn thuần là thông tin sai: Một giải thích khái niệm và phân loại nội dung trực tuyến. American Behavioral Scientist, 65(2):180–212. Công trình gốc xuất bản 2021. Iryna Gurevych Nils Reimers. 2019. Sentence-bert: Nhúng câu sử dụng mạng bert song sinh. https://arxiv.org/abs/1908.10084. Liangming Pan, Xinyuan Lu, Min-Yen Kan, và Preslav Nakov. 2023a. QACheck: Hệ thống minh họa kiểm tra sự thật dựa trên câu hỏi đa bước. Trong Kỷ yếu của Hội nghị Phương pháp Thực nghiệm về Xử lý Ngôn ngữ Tự nhiên 2023: Trình diễn Hệ thống, trang 264–273, Singapore. Hiệp hội Ngôn ngữ Học Máy Tính. Liangming Pan, Xiaobao Wu, Xinyuan Lu, Anh Tuan Luu, William Yang Wang, Min-Yen Kan, và Preslav Nakov. 2023b. Kiểm tra sự thật các khẳng định phức tạp với lập luận hướng dẫn bằng chương trình. Trong Kỷ yếu của Cuộc họp thường niên lần thứ 61 của Hiệp hội Ngôn ngữ Học Máy Tính (Tập 1: Bài dài), trang

Kỷ yếu Hội nghị thường niên lần thứ 62 của Hiệp hội Ngôn ngữ học Máy tính (Tập 1: Bài báo dài), trang 15636–15659. Hiệp hội Ngôn ngữ học Máy tính.

Sandeep Singamsetty, Nishtha Madaan, Sameep Mehta, Varad Bhatnagar, và Pushpak Bhattacharyya. 2023. "hãy cẩn thận với sự lừa dối": Phát hiện sự thật một nửa và bác bỏ nó thông qua chỉnh sửa tuyên bố có kiểm soát. Bản in trước, arXiv:2308.07973.

Yixuan Tang, Hwee Tou Ng, và Anthony K.H. Tung. 2021. Các hệ thống trả lời câu hỏi đa bước có biết cách trả lời các câu hỏi phụ một bước không? Trong EACL, trang 3244–3249. Hiệp hội Ngôn ngữ học Máy tính.

Yixuan Tang, Yuanyuan Shi, Yiqun Sun, và Anthony Kum Hoe Tung. 2025. Khám phá bức tranh toàn cảnh: Hiểu biết toàn diện về sự kiện thông qua truy xuất tin tức đa dạng. Trong EMNLP. Hiệp hội Ngôn ngữ Học Máy Tính.

James Thorne, Andreas Vlachos, Christos Christodoulopoulos, và Arpit Mittal. 2018. FEVER: một tập dữ liệu quy mô lớn cho trích xuất và xác minh sự thật. Trong Kỷ yếu Hội nghị năm 2018 của Chương Bắc Mỹ thuộc Hiệp hội Ngôn ngữ Học Máy Tính: Công nghệ Ngôn ngữ Con người, các trang 809–819.

Bing Wang, Ximing Li, Changchun Li, Bo Fu, Song-wen Pei, và Shengsheng Wang. 2024. Tại sao thông tin sai l ệch được tạo ra? Phát hiện chúng bằng cách tích hợp các đặc trưng ý định. Trong Kỷ yếu Hội nghị Quốc tế ACM lần thứ 33 về Quản lý Thông tin và Kiến thức, CIKM '24, trang 2304–2314, New York, NY, USA. Hiệp hội Máy tính. William Yang Wang. 2017. "Kẻ nói dối, kẻ nói dối quần đang cháy": Một bộ dữ liệu chuẩn mới cho việc phát hiện tin giả. Trong Kỷ yếu Hội nghị Hàng năm lần thứ 55 của Hiệp hội Ngôn ngữ học Máy tính (Tập 2: Bài báo ngắn), trang 422–426. Chang Yang, Peng Zhang, Hui Gao, và Jing Zhang. 2024. Giải mã tin đồn: Một phương pháp học đa nhiệm với học đối chiếu theo thứ bậc nhận thức ý định. Trong Kỷ yếu Hội nghị 2024 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên, trang 4471–4483. Hiệp hội Ngôn ngữ học Máy tính. Zhiwei Yang, Ji ng Ma, Hechang Chen, Hongzhan Lin, Ziyang Luo, và Yi Chang. 2022. Một mô hình thác từ tổng quát đến chi tiết

Xử lý Ngôn ngữ và Hội nghị lần thứ 3 của Chương Châu Á - Thái Bình Dương của Hiệp hội Ngôn ngữ Học Máy Tính (Tập 1: Bài báo Dài), trang 996–1011, Nusa Dua, Bali. Hiệp hội Ngôn ngữ Học Máy Tính.

Một lời nhắc để xây dựng POLITIFACT-HIDDEN

Cái này se Phần trình bày các mẫu nhắc được sử dụng trong việc xây dựng bộ dữ liệu POLITIFACT-HIDDEN.

Nhắc nhở: Phân loại mức độ liên quan của bằng c hứng

Bạn được giao nhiệm vụ xác định mức độ liên quan của một bằng chứng đối với một sự kiện. Bạn sẽ được cung cấp một tuyên bố, lý do kiểm chứng sự thật của tuyên bố này, và một bằng chứng. Liệu bằng chứng đó có liên quan gì đến sự kiện không?

Không liên quan: Bằng chứng không nói về một khía cạnh của sự kiện. Liên quan: Bằng chứng nói về một khía cạnh của sự kiện ngay cả khi nó không trực tiếp đề cập đến yêu cầu hoặc chỉ chia sẻ các chủ đề chung của sự kiện hoặc đơn giản tham chiếu đến yêu cầu ban đầu.

Bạn không cần phải tập trung vào việc bằng chứng có ủng hộ hay bác bỏ tuyên bố.

Bằng chứng: {evidence}

Lý do: {ruling}

Yêu cầu: {claim}

Bằng chứng có liên quan đến sự kiện không?

A. Vâng

B. Không

Chỉ trả lời một chữ cái:

Nhắc nhở: Phân loại Sự hiện diện của Bằng chứng

Bạn được giao nhiệm vụ xác định liệu bằng chứng có được trình bày trong một tuyên bố hay không. Bạn sẽ được cung cấp một tuyên bố và bằng chứng. Liệu bằng chứng có được trình bày trong tuyên bố không?

Được trình bày nên thỏa mãn các điều kiện sau:

1. Bằng chứng phần nào hoặc hoàn toàn ủng hộ tuyên bố. Không tìm thấy mâu thuẫn.

2. Bằng chứng hỗ trợ cho tuyên bố mà không cần lý luận thêm, vì thông tin được nêu trực tiếp và rõ ràng trong tuyên bố.

Bằng chứng: {evidence}

Yêu cầu: {claim}

Bằng chứng có được trình bày trong yêu cầu không?

A. Vâng

B. Không

Chỉ trả lời một chữ cái:

Lời nhắc: Làm phong phú phán quyết kiểm chứng sự thật với các bằng chứng đã cho.

Bạn sẽ được cung cấp phán quyết và bằng chứng từ một bài viết kiểm tra sự thật. Nhiệm vụ của bạn là nâng cao sự rõ ràng và chiều sâu của phán quyết.

Định nghĩa:

• Phán quyết: Một bản tóm tắt ngắn gọn của bài viết kiểm chứng sự thật bao gồm đánh giá độ chính xác của tuyên bố.

• Bằng chứng: Các chi tiết hỗ trợ và dữ liệu thu thập được liên quan đến khẳng định.

Yêu cầu:

• Xác định Sự Mơ Hồ: Xem xét bản phán quyết và bằng chứng để xác định bất kỳ thông tin nào không rõ ràng hoặc chưa đầy đủ trong bản phán quyết.

• Làm phong phú bằng bằng chứng: Tham khảo các phần liên quan của bằng chứng để mở rộng phán quyết. Đảm bảo phán quyết được làm phong phú giải thích rõ ràng cách bằng chứng hỗ trợ hoặc mâu thuẫn với tuyên bố và liên kết trực tiếp với mức độ xác thực của nó.

• Tạo một bản phán quyết toàn diện: Bản phán quyết được nâng cao nên trình bày độc lập toàn bộ bối cảnh của quá trình kiểm chứng sự thật và lý do cho đánh giá được đưa ra.

Bằng chứng: {evidence}
Phán quyết: {ruling}

Không xuất ra điều gì khác ngoài phán quyết được cải thiện của bạn.

Nhắc nhở: Phân tích ý định

Một tuyên bố sẽ truyền đạt những ý định ngầm. Bạn được yêu cầu xác định ý định của một tuyên bố dựa trên bối cảnh trong Phán quyết.

Định nghĩa:

• Yêu cầu: Yêu cầu được kiểm tra.

• Phán quyết: Văn bản để xác định tính xác thực và giải thích cách tuyên bố đó sẽ định hình sự hiểu biết của con người.

• Ý định: Sự hiểu biết về sự kiện mà người nói muốn định hình, điều này không được trình bày trực tiếp trong lập luận.

(3 ví dụ bị bỏ qua)

Yêu cầu:

1. Ý định phải có thể kiểm tra được. Ví dụ, “mọi người nên làm điều gì đó” không thể kiểm tra được vì nó chưa xảy ra. 2. Xuất ý định trong <>. 3. Vui lòng suy nghĩ từng bước. Trước tiên hãy viết lý do, sau đó là ý định.

Yêu cầu: {claim}
Phán quyết: {ruling}

Để tránh lặp lại, chúng tôi sử dụng màu sắc trong các gợi ý để chỉ các chiều đánh giá khác nhau, được đánh giá một cách độc lập trong thực tế.

Đánh giá Ý định Tạo ra (4 chiều)

Bạn được yêu cầu xác định xem kết luận dự định có phải là một ý định hợp lý của tuyên bố / truyền đạt ý nghĩa ngầm của tuyên bố / dễ đọc / đủ ý, có nghĩa là có thể hiểu được trong phạm vi kiến thức chung.

Vui lòng đánh giá theo thang sau:

- **0** (không khả thi): Mệnh đề này mâu thuẫn với kết luận dự định.
- **1** (có vẻ hợp lý): Lời khẳng định này không mâu thuẫn với kết luận dự định.
- **0** (không ngụ ý): Kết luận dự định chỉ đơn giản là diễn đạt lại một phần của tuyên bố. Nó không truyền đạt bất kỳ ý nghĩa ngụ ý nào của tuyên bố.
- **1** (ngầm định): Kết luận dự định tiết lộ thông tin ngầm không được nêu rõ trong tuyên bố.
- **0** (không đọc được): Kết luận dự định không đọc được và quá phức tạp.
- **1**(dễ đọc): Kết luận dự định có thể đọc được và dễ hiểu.
- **0** (không đủ): Kết luận dự định có những tham chiếu rõ ràng gây mơ hồ và không thể hiểu được. Ví dụ, nó sử dụng các thuật ngữ không rõ ràng như “the claim”.
- **1** (đầy đủ): Kết luận dự định được tham chiếu rõ ràng và có thể hiểu được một cách độc lập.

Yêu cầu: {claim} Kết luận dự định: {intent}

Chỉ xuất ra một chữ số.

B Mẫu nhắc lệnh Được sử dụng trong TRACER

Phụ lục này cung cấp các mẫu lệnh đầy đủ được sử dụng ở mỗi giai đoạn của khung TRACER. Chúng tôi bao gồm các lệnh cho việc tạo câu hỏi ngầm, suy luận giả định, đánh giá nhân quả và đánh giá lại cuối cùng.

Đề bài: Tạo các câu hỏi ngầm hiểu.

Một tuyên bố có thể chính xác theo nghĩa đen nhưng vẫn gây hiểu lầm theo cách ngầm định.
Nhiệm vụ của bạn là xác định những câu hỏi ngầm quan trọng mà bằng chứng đề cập.

Các bước:

1. Đọc kỹ các bằng chứng dưới đây để hiểu đầy đủ bối cảnh và các chủ đề mà nó bao quát .
2. Giả sử rằng tuyên bố là đúng. Những câu hỏi ngầm quan trọng kiểu có-không nào nên được đặt ra để xác minh kết luận dự định, thay vì chỉ sự chính xác theo nghĩa đen của tuyên bố?
3. Tạo 1–3 câu hỏi ngầm như vậy.
4. Mỗi câu hỏi nên được đặt trong dấu ngoặc nhọn riêng của nó <>.
5. Tất cả các câu hỏi ngụ ý phải là câu hỏi có/không.

(Các ví dụ bị bỏ qua.)
Khẳng định: {claim} Kết luận dự định: {intent} Bằng chứng: {evidence}

Gợi ý: Tạo giả định

Một tuyên bố có thể chính xác theo nghĩa đen nhưng vẫn gây hiểu lầm vì kết luận dự định của nó. Nhiệm vụ của bạn là xác định những giả định mà kết luận dự định dựa trên, ngoài tuyên bố đó.

Định nghĩa:

- Khẳng định: Một tuyên bố được cho là đúng.
- Kết luận dự định: Kết luận dự định của tuyên bố, cần được kiểm tra.
- Câu hỏi: Một số câu hỏi quan trọng khi kiểm tra yêu cầu.
- Giả định: Những giả định mà kết luận dự định dựa trên, ngoài tuyên bố .

Các bước:

1. Đọc tuyên bố, kết luận dự định và các câu hỏi. 2. Giả sử tuyên bố là đúng, những giả định nào mà câu hỏi ngụ ý nên được dùng làm cơ sở cho kết luận dự định? 3. Đưa ra lý do trong 1–3 câu, sau đó liệt kê 1–{assumption_max_number} giả định. Mỗi giả định nên được đặt trong dấu ngoặc nhọn < <> > và được phân tách bằng ||.

Yêu cầu:

1. Đảm bảo rằng mỗi giả định có thể truyền đạt ý nghĩa của nó một cách độc lập. Ví dụ, không bao giờ sử dụng các tham chiếu mơ hồ như “khẳng định,” “bằng chứng,” hoặc “ý định”; thay vào đó, hãy đề cập đến thông tin cụ thể.

2. Chỉ bao gồm những giả định mà bạn tự tin và chúng có thể làm cơ sở vững chắc cho kết luận dự định.

(Các ví dụ bị bỏ qua.) Khẳng định: {claim} Kết luận dự định: {intention} Câu hỏi: {questions}

Phân tích nhân quả

Bạn được yêu cầu thực hiện suy luận nhân quả phản thực tế trên một đồ thị nhân quả đã cho.

Lập luận: { "Z": ý định, "linked_by": { "X": tuyên bố, "Y_1": giả định_1, "Y_2": giả định_2} } Đánh giá ΔP (Z | làm({chữ} = ¬{chữ})). Cụ thể hơn, xác suất của Z thay đổi như thế nào khi chúng ta đặt {chữ} t ừ {chữ} thành¬{chữ}?

Tùy chọn:
A. Xác suất của Z không thay đổi. B. Xác suất của Z tăng lên (Z trở nên có khả năng đúng hơn). C. Xác suất của Z giảm xuống (Z trở nên ít có khả năng đúng hơn).

Vui lòng trả lời chỉ bằng một chữ cái.

Nhắc nhở: Đánh giá lại

Một tuyên bố có thể chính xác về mặt thực tế nhưng vẫn gây hiểu lầm do kết luận ngụ ý của nó. Nhiệm vụ của bạn là tinh chỉnh việc đánh giá tính xác thực của tuyên bố đó bằng cách xem xét thê m các thông tin ẩn. Bạn được cung cấp một lý do kiểm chứng thực tế đã được tạo trước đó, cùng với bằng chứng mới và một lập luận ủng hộ kết luận dự kiến của tuyên bố. Vui lòng xác định xem lý do đó đã giải quyết thông tin ẩn hay chưa. Sau đó, hãy tinh chỉnh tính xác thực của tuyên bố một cách phù hợp.

Nhập:

Bằng chứng: [BẰNG CHỨNG]Lập luận: [LẬP LUẬN]Biện minh: [BIỆN MINH]

Hướng dẫn: Đánh giá lại tính xác thực của tuyên bố dựa trên những thông tin trên. Chọn một trong các tùy chọn sau (chỉ xuất ra chữ cái): A. Đúng // B. Nửa đúng // C. Sai // D. Không thể xác minh (ví dụ, giả định ẩn không hỗ trợ kết luận, hoặc thông tin không đầy đủ) Câu trả lời của bạn (chỉ một chữ cái):

C Tổng quát hóa với LLaMA2-7B

Kết quả trong Bảng 11 cho thấy TRACER mang lại những cải thiện nhất quán trên các chỉ số khi được áp dụng cho LLaMA2-7B mã nguồn mở, với những cải thiện đặc biệt đáng chú ý trong phân loại Nửa-Đúng.

Mô hình	Độ chính xác	Macro-F1	F1(Đúng)	F1(Đúng một nửa)	F1(Sai)
HiSS	78.3	59.4	44.7	44.4	88.9
HiSS + RA (GPT-3.5-turbo)	81.9	**65.7**	**46.6**	60.5	90.1
HiSS + RA (LLaMA2-7B)	**82.3**	65.4	43.6	**61.3**	**91.2**

Bảng 11: Khả năng tổng quát hóa của TRACER với các nền tảng khác nhau.

Chúng tôi tiếp tục phân tích hiệu suất của TRACER theo độ dài khác nhau của các tuyên bố. Sử dụng mô hình nền tảng mã nguồn mở LLaMA2-7B, chúng tôi chia các tuyên bố kiểm tra thành bốn khoảng độ dài theo số từ. Bảng 12 cho thấy sự cải thiện nhất quán ở tất cả các khoảng, với mức tăng lớn hơn quan sát được ở các tuyên bố dài hơn, điều này có khả năng cung cấp ngữ cảnh phong phú hơn cho việc suy luận ý định và tạo ra giả định.

Mô hình	4–13 (755)	14–23 (893)	24–34 (308)	≥35 (44)
HiSS	80.3	78.5	73.1	75.0
HiSS +RA	**83.7**	**81.8**	**80.5**	**81.8**
Cải thiện	↑3.4	↑3.3	↑7.5	↑6.8

Bảng 12: Hiệu suất của TRACER theo độ dài các khẳng định khác nhau (điểm F1) sử dụng LLaMA2-7B. Các số trong dấu ngoặc cho biết số lượng ví dụ theo từng khoảng độ dài. Các khẳng định dài hơn cung cấp bối cảnh phong phú hơn, dẫn đến cải thiện lớn hơn.