arXiv:2412.15308v1 [cs.CL] 19 Dec 2024

ViFactCheck: A New Benchmark Dataset and Methods for Multi-domain News Fact-Checking in Vietnamese

Thai-Hoa Tran[1,2], **Quang-Duy Tran**[1,2], **Khanh Quoc Tran**[1,2],**Kiet Van Nguyen**[1,2]*

[1] Faculty of Information Science and Engineering, University of Information Technology
[2] Vietnam National University, Ho Chi Minh City, Vietnam
{21522082,20512013}@gm.uit.edu.vn, {khanhtq,kietnv}@uit.edu.vn

Abstract

The rapid spread of information in the digital age highlights the critical need for effective fact-checking tools, particularly for languages with limited resources, such as Vietnamese. In response to this challenge, we introduce ViFactCheck, the first publicly available benchmark dataset designed specifically for Vietnamese fact-checking across multiple online news domains. This dataset contains 7,232 human-annotated pairs of claim-evidence combinations sourced from reputable Vietnamese online news, covering 12 diverse topics. It has been subjected to a meticulous annotation process to ensure high quality and reliability, achieving a Fleiss Kappa inter-annotator agreement score of 0.83. Our evaluation leverages state-of-the-art pre-trained and large language models, employing fine-tuning and prompting techniques to assess performance. Notably, the Gemma model demonstrated superior effectiveness, with an impressive macro F1 score of 89.90%, thereby establishing a new standard for fact-checking benchmarks. This result highlights the robust capabilities of Gemma in accurately identifying and verifying facts in Vietnamese. To further promote advances in fact-checking technology and improve the reliability of digital media, we have made the ViFactCheck dataset, model checkpoints, fact-checking pipelines, and source code freely available on GitHub. This initiative aims to inspire further research and enhance the accuracy of information in low-resource languages[1].

1 Introduction

The rapid proliferation of digital information has created significant challenges in distinguishing between accurate and false information. The spread of disinformation, rumors, and fake news has become a global concern with far-reaching consequences for individuals, societies, and public discourse. As noted by Lazer et al. (2018), the extensive spread of fake news can have severe negative impacts on individuals and society. It can cause confusion and misunderstanding, disrupt social order, and even threaten national security.

Fact-checking, a rigorous process to verify the accuracy of claims in specific contexts, relies on informed individuals using evidence, reasoning, and available information to make well-founded judgements. Figure 1 provides a specific illustration for Vietnamese fact-checking. Although substantial efforts have been devoted to fact-checking in English (Thorne et al. 2018; Aly et al. 2021; Schuster, Fisch, and Barzilay 2021), resources for fact-checking in low-resource languages like Vietnamese are limited. This scarcity primarily stems from the limited availability of guidance resources to analyze the structure and semantics of Vietnamese.

To bridge this gap, this study presents the development of ViFactCheck, the first publicly available human-curated fact-checking benchmark tailored to multiple domains Vietnamese news. Our main contributions are described as follows:

Claim:
Các công dân trẻ tiêu biểu cũng tham gia vào giải chạy bộ "Bước chân xanh" nhằm hưởng ứng chiến dịch Giờ Trái đất năm 2023.
English: Exemplary young citizens also participate in the "Green Steps" running event to support the Earth Hour campaign in 2023.

Support ✔

Context:
TPO-Sáng 25/3, Thành Đoàn, Hội LHTN Việt Nam TPHCM , Hội Sinh viên Việt Nam TPHCM tổ chức Giải chạy bộ "Bước chân xanh" lần thứ 2. Giải chạy thu hút hơn 1.000 người tham gia hưởng ứng chiến dịch Giờ Trái đất năm 2023. Bên cạnh đông đảo đoàn viên, thanh niên, sinh viên, giải chạy bộ "Bước chân xanh" còn thu hút các gương công dân trẻ tiêu biểu TPHCM, các hoa hậu, á hậu, văn nghệ sĩ trẻ... cùng tham gia.
English: TPO-March 25th, the HCM Youth Union and the Vietnam National Union of Students in HCM City organized the 2nd "Green Steps" running event. The race attracted over 1,000 participants in response to the Earth Hour campaign in 2023. In addition to a large number of union members, youth, and students, the "Green Steps" running event also attracted notable young citizens of HCM City, beauty queens, runners-up, young artists, and others to participate.

Figure 1: An example of the Vietnamese fact-checking task. Words highlighted in blue represent key evidence used to support the classification of the claim as "Supported".

*Corresponding author.
Copyright © 2025, Association for the Advancement of Artificial Intelligence (www.aaai.org). All rights reserved.
[1]https://github.com/QuangDiy/ViFactCheck

arXiv:2412.15308v1 [cs.CL] 19 Dec 2024

ViFactCheck: Bộ Dữ Liệu Chuẩn Mới và Phương Pháp Kiểm Tra Thực Tế Tin Tức Đa Lĩnh Vực bằng Tiếng Việt

Thai-Hoa Tran[1,2], Quang-Duy Tran[1,2],Khanh Quoc Tran[1,2],Kiet Van Nguyen[1,2]*[1] Khoa Khoa Học và Kỹ Thuật Thông Tin, Trường Đại Học Công Nghệ Thông Tin[2] Đại Học Quốc Gia Việt Nam, Thành phố Hồ Chí Minh, Việt Nam {21522082,20512013}@gm.uit.edu.vn, {khanhtq,kietnv}@uit.edu.vn

Tóm tắt

Sự lan truyền nhanh chóng của thông tin trong kỷ nguyên kỹ thuật số làm nổi bật nhu cầu cấp thiết về các công cụ kiểm chứng thông tin hiệu quả, đặc biệt đối với các ngôn ngữ có tài nguyên hạn chế, chẳng hạn như tiếng Việt. Để đáp ứng thách thức này, chúng tôi giới thiệu ViFactCheck, bộ dữ liệu chuẩn đánh giá công khai đầu tiên được thiết kế đặc biệt cho việc kiểm chứng thông tin tiếng Việt trên nhiều lĩnh vực tin tức trực tuyến. Bộ dữ liệu này chứa 7.232 cặp kết hợp giữa tuyên bố và bằng chứng được chú thích bởi con người, được lấy từ các nguồn tin tức trực tuyến uy tín của Việt Nam, bao phủ 12 chủ đề đa dạng. Nó đã trải qua một quy trình chú thích tỉ mỉ để đảm bảo chất lượng và độ tin cậy cao, đạt điểm đồng thuận giữa những người chú thích theo hệ số Fleiss Kappa là 0,83. Việc đánh giá của chúng tôi tận dụng các mô hình ngôn ngữ lớn và mô hình đã được huấn luyện sẵn tiên tiến, sử dụng các kỹ thuật tinh chỉnh và gợi ý để đánh giá hiệu suất. Đáng chú ý, mô hình Gemma đã thể hiện hiệu quả vượt trội, với điểm macro F1 ấn t ượng đạt 89,90%, qua đó thiết lập một tiêu chuẩn mới

1 Giới thiệu

Sự lan truyền nhanh chóng của thông tin số đã tạo ra những thách thức đáng kể trong việc phân biệt giữa thông tin chính xác và thông tin sai lệch. Sự lan rộng của tin giả, tin đồn và tin tức sai sự thật đã trở thành một mối quan tâm toàn cầu với những hậu quả sâu rộng đối với cá nhân, xã hội và diễn ngôn công cộng. Như Lazer và cộng sự (2018) đã ghi nhận, việc lan truyền rộng rãi tin tức giả có thể có tác động tiêu cực nghiêm trọng đối với cá nhân và xã hội. Nó có thể gây ra sự nhầm lẫn và hiểu lầm, làm rối trật tự xã hội và thậm chí đe dọa an ninh quốc gia.

Kiểm chứng sự thật, một quy trình nghiêm ngặt để xác minh độ chính xác của các tuyên bố trong những bối cảnh cụ thể, dựa vào các cá nhân có hiểu biết sử dụng bằng chứng, lý luận và thông tin sẵn có để đưa ra các đánh giá có cơ sở. Hình 1 cung cấp một ví dụ cụ thể

Yêu cầu:
Typical young citizens also participated in the 'Green Steps' race to respond to the Earth Hour 2023 campaign.

Tiếng Việt: Các công dân trẻ gương mẫu cũng tham gia sự kiện chạy "Bước Chân Xanh" để ủng hộ chiến dịch Giờ Trái Đất năm 2023.

Hỗ trợ ✔

Ngữ cảnh:
TPO - On the morning of March 25, the Ho Chi Minh City Youth Union, the Ho Chi Minh City Vietnamese Youth Federation, and the Ho Chi Minh City Vietnamese Student Association organized the 2nd 'Green Steps' running race. The race attracted more than 1,000 participants joining the Earth Hour 2023 campaign. In addition to a large number of union members, youth, and students, the 'Green Steps' running race also attracted outstanding young citizens of Ho Chi Minh City, beauty queens, runners-up, and young artists to participate.

Tiếng Việt: Ngày 25 tháng 3, Thành Đoàn TP.HCM và Hội Sinh viên Việt Nam tại TP.HCM đã tổ chức sự kiện chạy bộ " Bước Chân Xanh" lần thứ 2. Cuộc đua thu hút hơn 1.000 người tham gia hưởng ứng chiến dịch Giờ Trái đất năm 2023. Bên cạnh đông đảo đoàn viên, thanh niên và sinh viên, sự kiện chạy bộ "Bước Chân Xanh" còn thu hút các công dân trẻ nổi bật của TP.HCM, các hoa hậu, á hậu, các nghệ sĩ trẻ và nhiều người khác tham gia.

Hình 1: Một ví dụ về nhiệm vụ kiểm chứng thông tin tại Việt Nam. Những từ được tô màu xanh biểu thị bằng chứng chính được sử dụng để hỗ trợ việc phân loại tuyên bố là "Được hỗ trợ".

Minh họa cho việc kiểm tra thông tin tại Việt Nam. Mặc dù đã có những nỗ lực đáng kể dành cho việc kiểm tra thông tin bằng ti ếng Anh (Thorne et al. 2018; Aly et al. 2021; Schuster, Fisch, and Barzilay 2021), nhưng các nguồn lực để kiểm tra thông tin bằng các ngôn ngữ ít có tài nguyên như tiếng Việt vẫn còn hạn chế. Sự khan hiếm này chủ yếu xuất phát từ việc thiếu hụt các tài liệu hướng dẫn để phân tích cấu trúc và ngữ nghĩa của tiếng Việt.

Để thu hẹp khoảng cách này, nghiên cứu này giới thiệu sự phát triển của ViFactCheck, chuẩn kiểm tra sự thật do con người hiệu chỉnh công khai đầu tiên được thiết kế cho nhiều lĩnh vực tin tức Việt Nam. Những đóng góp chính của chúng tôi được mô tả như sau:

*Tác giả liên hệ. Bản quyền © 2025, Hiệp hội Thúc đẩy Trí tuệ Nhân tạo (www.aaai.org). Mọi quyền được bảo lưu. [1] https://github.com/QuangDiy/ViFactCheck

1. **Dataset Construction:** We developed ViFactCheck, a comprehensive dataset encompassing 12 critical domains of Vietnamese online news. This dataset contains 7,232 rigorously vetted human-annotated claims, thereby ensuring a robust foundation for both research and practical applications.
2. **Model Experimentation:** We utilized fine-tuning and prompting techniques to several state-of-the-art language models using the ViFactCheck dataset to assess their effectiveness in verifying information within the Vietnamese context. Our study includes fine-tuning and zero-shot in-context learning on both pre-trained and large language models, specifically adapted to this linguistic framework, to evaluate their efficacy.
3. **In-depth Analysis**: Through detailed examinations of the challenges faced during the creation of the dataset and subsequent experimentation, this study offers profound insights into the hurdles of developing fact-checking systems for low-resource languages, guiding future advancements in the field.

The remainder of this paper is structured as follows. Section 2 delves into the fundamentals of fact-checking tasks. Section 3 describes the process of constructing the ViFactCheck benchmark dataset. Section 4 discusses the results of our experiments and identifies key challenges encountered. Section 5 concludes with a summary of our findings and suggests directions for future research.

2 Fundamental of Fact-Checking

2.1 Foundational Benchmark Datasets

Benchmark datasets are crucial in the development and evaluation of fact-checking algorithms, serving as the foundation upon which these systems are tested and fine-tuned. The FEVER (Thorne et al. 2018) is particularly notable, containing more than 185,000 claims sourced from Wikipedia, each meticulously annotated with evidence to support or refute the claims. Following FEVER, the FEVEROUS dataset (Aly et al. 2021) extends these capabilities by incorporating not only text but also structured data such as tables and lists, presenting a more comprehensive dataset that challenges algorithms to parse and verify information across different formats. Another significant dataset, MultiFC (Augenstein et al. 2019), compiles claims from 26 different fact-checking websites, covering various topics and offering a rich environment to test the adaptability of verification systems to different contexts and types of misinformation. These benchmark datasets play a critical role in advancing the field of fact-checking, providing a diverse set of challenges and inspiring the development of diverse open-domain fact-checking datasets in many languages (Schuster, Fisch, and Barzilay 2021; Wang 2017; Hu et al. 2022; Nørregaard and Derczynski 2021; Khouja 2020). The comparison of multi-domain fact-checking datasets is summarized in Table 1.

2.2 Advanced Methods in Fact-Checking

The evolution of fact-checking methods has significantly advanced through the adoption of sophisticated machine learning technologies. Notably, the use of Pre-trained Language Models (PLMs) and Large Language Models (LLMs) like BERT and other transformer-based architectures (Devlin et al. 2019) has been instrumental. These models, leveraging deep learning, are highly effective in processing and analyzing the context within texts based on patterns in data, making them exceptionally effective for tasks such as evidence retrieval and claim verification (Nie, Chen, and Bansal 2019; Soleimani, Monz, and Worring 2020; Liu et al. 2020). By fine-tuning these models on specific fact-checking datasets, researchers can adapt their capabilities to better recognize and interpret the nuances of misinformation. Furthermore, researchers have explored prompting techniques with these models to direct their focus without extensive retraining, enhancing their utility in diverse applications (Huang, Chan, and Ji 2023; Pan et al. 2023). The synergy of language models with traditional retrieval and verification methods has also given rise to hybrid models, which combine the depth and adaptability of machine learning with the precision of rule-based systems (Vlachos and Riedel 2014), graph modeling (Zhong et al. 2020), leading to more robust and accurate fact-checking solutions.

2.3 Vietnamese Research on Fact-Checking

Research within Vietnam on fact-checking has been making significant strides, particularly with the development of customized datasets that address the unique linguistic characteristics of Vietnamese (Duong, Ho, and Do 2023; Le et al. 2024). A notable study by Duong, Ho, and Do (2023) has produced a dataset with more than 129K triples checked for fact, specifically designed to evaluate the effectiveness of fact-checking algorithms under Vietnamese linguistic constraints. This approach not only enhances the precision of fact-checking in Vietnam but also contributes significantly to the global body of knowledge. It showcases how fact-checking technologies can be adapted to different linguistic and cultural contexts, providing a model for similar adaptations in other regions.

3 Dataset Creation Process

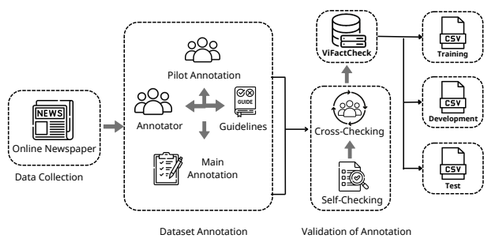


Figure 2: The ViFactCheck dataset contruction process.

Figure 2 shows the development of ViFactCheck, the first multi-domain Vietnamese news fact-checking benchmark. The dataset construction included three phases: data collection, dataset annotation, and annotation validation, each rigorously monitored by experts to ensure dataset quality.

1. Xây dựng Bộ dữ liệu: Chúng tôi đã phát triển ViFactCheck, một bộ dữ liệu toàn diện bao gồm 12 lĩnh vực quan trọng của tin tức trực tuyến Việt Nam. Bộ dữ liệu này chứa 7.232 tuyên bố được chú thích bởi con người và kiểm tra kỹ lưỡng, từ đó đảm bảo một nền tảng vững chắc cho cả nghiên cứu và ứng dụng th ực tiễn.

2. Thử nghiệm Mô hình: Chúng tôi đã sử dụng các kỹ thuật tinh chỉnh và gợi ý cho một số mô hình ngôn ngữ tiên tiến nhất sử dụng tập dữ liệu ViFactCheck để đánh giá hiệu quả của chúng trong việc xác minh thông tin trong bối cảnh Việt Nam. Nghiên cứu của chúng tôi bao gồm tinh chỉnh và học ngữ cảnh không c ần huấn luyện trước trên cả các mô hình ngôn ngữ đã được huấn luyện trước và các mô hình ngôn ngữ lớn, được điều chỉnh cụ thể cho khung ngôn ngữ này, nhằm đánh giá hiệu quả của chúng.

3. PhânTíchSâu: Thông qua các cuộc kiểm tra chi tiết về những thách thức gặp phải trong quá trình tạo bộ dữ liệu và thí nghiệm tiếp theo, nghiên cứu này cung cấp những hiểu biết sâu sắc về những trở ngại trong việc phát triển các hệ thống kiểm tra thông tin cho các ngôn ngữ thiếu tài nguyên, hướng dẫn những tiến bộ tương lai trong lĩnh vực này.

Phần còn lại của bài báo này được cấu trúc như sau. Mục 2 đi sâu vào các nguyên tắc cơ bản của các nhiệm vụ kiểm chứng thông tin. Mục 3 mô tả quá trình xây dựng bộ dữ liệu Vi-FactCheckbenchmark. Mục 4 thảo luận về kết quả của các thí nghiệm của chúng tôi và xác định các thách thức chính đã gặp phải. Mục 5 kết luận bằng một tóm tắt các phát hiện của chúng t ôi và đề xuất hướng nghiên cứu trong tương lai.

2 Nguyên tắc cơ bản của Kiểm chứng sự thật.1 Bộ dữ liệu chuẩn nền tảng

Các tập dữ liệu chuẩn là yếu tố quan trọng trong việc phát triển và đánh giá các thuật toán kiểm chứng thông tin, đóng vai trò là nền tảng mà các hệ thống này được thử nghiệm và điều chỉnh. FEVER (Thorne và cộng sự, 2018) đặc biệt nổi bật, chứa hơn 185.000 tuyên bố lấy từ Wikipedia, mỗi tuyên bố đều được chú thích cẩn thận với bằng chứng để ủng hộ hoặc bác bỏ các tuyên bố đó. Tiếp theo FEVER, tập dữ liệu FEVEROUS (Aly và cộng sự, 2021) mở rộng các khả năng này bằng cách kết hợp không chỉ vă n bản mà còn dữ liệu có cấu trúc như bảng và danh sách, tạo ra một tập dữ liệu toàn diện hơn, thách thức các thuật toán phân tích và xác minh thông tin trên các định dạng khác nhau. Một tập dữ liệu quan trọng khác, MultiFC (Augenstein và cộng sự, 2019), tổng hợp các tuyên bố từ 26 trang web kiểm chứng thông tin khác nhau, bao quát nhiều chủ đề và cung cấp một môi trường phong phú để kiểm tra khả năng thích ứng của các hệ thống xác minh trước các bối cảnh và loại thông tin sai lệch khác nhau. Các tập dữ liệu chuẩn này đóng vai trò then chốt trong việc thúc đẩy

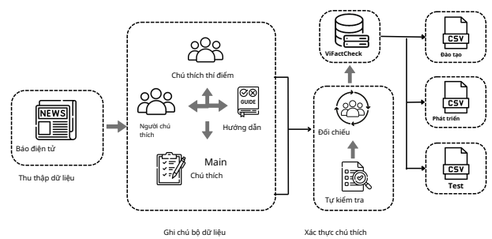
2.2 Các Phương Pháp Nâng Cao trong Kiểm Chứng Thông Tin

Sự phát triển của các phương pháp kiểm tra sự thật đã tiến bộ đáng kể thông qua việc áp dụng các công nghệ học máy tinh vi. Đáng chú ý, việc sử dụng Ngôn ngữ Được Huấn luyện Trước Các mô hình ngôn ngữ tiền huấn luyện (PLMs) và các mô hình ngôn ngữ lớn (LLMs) như BERT và các kiến trúc dựa trên transformer khác (Devlin et al. 2019) đã đóng vai trò quan trọng. Những mô hình này, tận dụng học sâu, rất hiệu quả trong việc xử lý và phân tích ngữ cảnh trong văn bản dựa trên các mẫu trong dữ liệu, làm cho chúng đặc biệt hiệu quả cho các nhiệm vụ như truy xuất bằng chứng và xác minh thông tin (Nie, Chen, và Bansal 2019; Soleimani, Monz, và Worring 2020; Liu et al. 2020). Bằng cách tinh chỉnh các mô hình này trên các bộ dữ liệu kiểm tra sự thật cụ thể, các nhà nghiên cứu có thể điều chỉnh khả năng của chúng để nhận biết và diễn giải rõ hơn những sắc thái của thông tin sai lệch. Hơn nữa, các nhà nghiên cứu đã khám phá các kỹ thuật gợi ý với các mô hình này để định hướng sự tập trung của chúng mà không cần huấn luyện lại nhiều, nâng cao tính hữu ích của chúng trong các ứng dụng đa dạng (Huang, Chan, và Ji 2023; Pan et al. 2023). Sự kết hợp của các mô hình ngôn ngữ với các phương pháp truy xuất và xác minh truyền thống cũng đã tạo ra các mô hình lai, kết hợp d

2.3 Nghiên cứu của Việt Nam về kiểm tra sự thật

Nghiên cứu tại Việt Nam về kiểm tra sự thật đã đạt được những tiến bộ đáng kể, đặc biệt với việc phát triển các bộ dữ liệu tùy chỉnh nhằm giải quyết những đặc điểm ngôn ngữ độc đáo của tiếng Việt (Dương, Hồ, và Đỗ 2023; Lê và cs. 2024). Một nghiên c ứu nổi bật của Dương, Hồ, và Đỗ (2023) đã tạo ra một bộ dữ liệu với hơn 129 nghìn bộ ba được kiểm tra tính đúng sự thật, được thiết kế đặc biệt để đánh giá hiệu quả của các thuật toán kiểm tra sự thật trong bối cảnh ngôn ngữ tiếng Việt. Cách tiếp cận này không chỉ nâng cao độ chính xác của việc kiểm tra sự thật tại Việt Nam mà còn đóng góp đáng kể vào kho tàng tri thức toàn cầu. Nó cho thấy cách công nghệ kiểm tra sự thật có thể được điều chỉnh phù hợp với các ngữ cảnh ngôn ngữ và văn hóa khác nhau, đồng thời cung cấp một mô hình cho các điều chỉnh tương tự ở các khu vực khác.

3 Quá trình Tạo Dữ liệu



Hình 2: Quy trình xây dựng bộ dữ liệu ViFactCheck.

Hình 2 cho thấy sự phát triển của ViFactCheck, bộ chuẩn nhận diện sự thật cho tin tức tiếng Việt đa miền đầu tiên. Việc xây dựng bộ dữ liệu bao gồm ba giai đoạn: thu thập dữ liệu, chú thích bộ dữ liệu và xác thực chú thích, mỗi giai đoạn đều được các chuyên gia giám sát nghiêm ngặt để đảm bảo chất lượng bộ dữ liệu.

	Dataset	Labels	# Claims	Annotated Evidence	Language	Source	#RS
English	FEVER (2018)	3	185,445	✔	English	Wikipedia	Multi
	FEVEROUS (2021)	3	87,026	✔	English	Wikipedia	Multi
	VitaminC (2021)	3	488,904	✗	English	Wikipedia	Single
	MultiFC (2019)	2-40	36,534	✔	English	Fact-check	Multi
	LIAR (2017)	6	12,836	✗	English	Fact-check	W/O
Non-English	CHEF (2022)	3	10,000	✔	Chinese	News/Fact-check	Multi
	DANFEVER (2021)	3	6,407	✔	Danish	Wikipedia	Multi
	ANT (2020)	2	4,547	✗	Arabic	News	Multi
	ViWikiFC (2024)	3	20,976	✗	Vietnamese	Wikipedia	Single
	ViFactCheck (Ours)	3	7,232	✔	Vietnamese	News	Multi

Table 1: Comparative overview of typical open-domain fact-checking datasets. The type of Reasoning Steps (#RS) column reflects the complexity involved in verifying the claims in each dataset.

	Bộ dữ liệu	Nhãn	# Khiếu nại	Bằng chứng có chú thích	Ngôn ngữ	Nguồn	#RS
English	SỐT (2018)	3	185.445	✔	Tiếng Anh	Wikipedia	Đa
	FEVEROUS (2021)	3	87.026	✔	Tiếng Anh	Wikipedia	Đa
	VitaminC (2021)	3	488.904	✗	Tiếng Anh	Wikipedia	Độc thân
	MultiFC (2019)	2-40	36.534	✔	Tiếng Anh	Kiểm tra sự thật	Đa
	KẺ NÓI DỐI (2017)	6	12.836	✗	Tiếng Anh	Kiểm tra sự thật	W/O
Non-English	ĐẦU BẾP (2022)	3	Mười nghìn	✔	Tiếng Trung	Tin tức/Kiểm chứng sự thật	Đa
	DANFEVER (2021)	3	Sáu nghìn bốn trăm bảy	✔	Tiếng Đan Mạch	Wikipedia	Đa
	ANT (2020)	2	Bốn nghìn năm trăm bốn mươi bảy	✗	Tiếng Ả Rập	News	Đa
	ViWikiFC (2024)	3	20.976	✗	Tiếng Việt	Wikipedia	Độc thân
	ViFactCheck (Của Chúng Tôi)	3	Bảy nghìn hai trăm ba mươi hai	✔	Tiếng Việt	News	Đa

Bảng 1: Tổng quan so sánh về các bộ dữ liệu kiểm chứng sự thật mở điển hình. Cột Loại các bước lý luận (#RS) phản ánh mức độ phức tạp liên quan đến việc xác minh các tuyên bố trong mỗi bộ dữ liệu.

3.1 Data Collection

This research constructs a dataset from articles sourced from nine licensed and widely-read Vietnamese online newspapers, detailed in the Appendix B. These sources were chosen for their comprehensive and timely news coverage, ensuring the relevance and reliability of the dataset. We extracted datasets that included titles, content, topics, lead descriptions, and URLs of articles published between February and March 2023. The selection of this period aims to capture the current dynamics of news reporting, providing a contemporary snapshot of media trends.

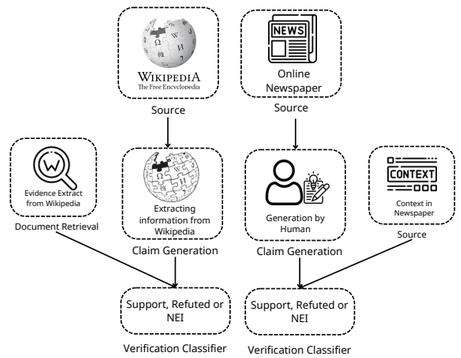
The initial corpus contained 1,000 articles covering 12 topics. Notably, news leads were merged with their respective contents to form a "Full Context" field, thereby enriching the dataset with a more comprehensive narrative view. This methodological rigor ensure the utility of dataset in advancing research on media analysis and computational linguistics.

3.2 Dataset Annotation

The construction methodology proposed for Vietnamese news differs from the conventional methods in previous datasets (Khouja 2020; Nørregaard and Derczynski 2021), which mimic the FEVER approach (Figure 3a). Recognizing the nuanced and dynamic nature of online news, our method employs human annotators to extract and interpret contextual nuances and factual details from news articles (Figure 3b). This human-centered approach enhances the naturalness and relevance of the data, enabling the dataset to better represent complex real-world information scenarios.

By assigning labels that reflect the context of each article, our methodology supports intricate inference tasks that require analysis across multiple pieces of evidence. This refined approach ensures that our dataset is exceptionally well-suited for advanced fact-verification systems, significantly contributing to the accuracy and effectiveness of misinformation detection in the digital media landscape.

Pilot Annotation is used to familiarize the annotators with the claim generation and verification process described above. Seven native Vietnamese-speaking university students



(a) Thorne et al. (2018). (b) Our proposed process.

Figure 3: Comparison of the labeling pipelines in the FEVER and ViFactCheck datasets.

were involved as annotators. We conducted a pilot annotation with each annotator annotating 120 claims corresponding to 20 random articles. Annotators were instructed to proofread each claim carefully and rigorously in accordance with the annotation guidelines. Details of the annotators recruitment and guidelines can be found in Appendices C and D.

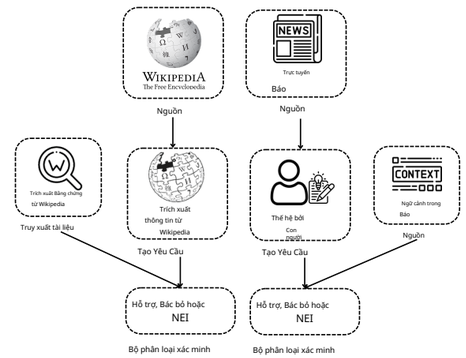
To verify the integrity of the pilot annotation process, we conducted thorough reviews of both the claims and their corresponding labels. The expert provided detailed feedback and asked the annotators to review any details or labels that did not meet the requirements of the annotation guidelines.

Main Annotation Following a pilot phase that familiarized the annotators with the tasks, each was assigned a specific subset to ensure focused and deep engagement. Throughout this phase, strict adherence to established guidelines was paramount to ensure consistency and enhance the overall quality of the dataset.

3.1 Thu thập dữ liệu

Nghiên cứu này xây dựng một bộ dữ liệu từ các bài báo được lấy từ chín tờ báo điện tử Việt Nam có giấy phép và được đọc rộng rãi, chi tiết trong Phụ lục B. Những nguồn này được chọn vì khả năng bao quát thông tin toàn diện và cập nhật kịp thời, đảm bảo tính liên quan và độ tin cậy của bộ dữ liệu. Chúng tôi đã trích xuất các bộ dữ liệu bao gồm tiêu đề, nội dung, chủ đề, mô tả dẫn một đoạn, và URL của các bài báo được xuất bản từ tháng Hai đến tháng Ba năm 2023. Việc lựa chọn khoảng thời gian này nhằm nắm bắt các động thái hiện tại của việc đưa tin, cung cấp một góc nhìn hiện đại về xu hướng truyền thông.

Tập hợp dữ liệu ban đầu chứa 1.000 bài báo bao quát 12 chủ đề. Đáng chú ý, phần dẫn tin tức được hợp nhất với nội dung tương ứng của chúng để tạo thành một trường "Bối cảnh đầy đủ", từ đó làm giàu bộ dữ liệu với một cái nhìn toàn diện hơn về câu chuyện. Sự nghiêm ngặt trong phương pháp này đảm bảo tính hữu ích của bộ dữ liệu trong việc thúc đẩy nghiên cứu về phân tích truyền thông và ngôn ngữ học máy tính.



(a) Thorne và cộng sự (2018). (b) Quy trình mà chúng tôi đề xuất.

Hình 3: So sánh các quy trình gán nhãn trong các bộ dữ liệu FEVER và ViFactCheck.

3.2 Ghi chú bộ dữ liệu

Phương pháp xây dựng được đề xuất cho tin tức Việt Nam khác với các phương pháp truyền thống trong các bộ dữ liệu trước đây (Khouja 2020; Nørregaard và Derczynski 2021), vốn mô phỏng cách tiếp cận FEVER (Hình 3a). Nhận thức được tính tinh vi và động của tin tức trực tuyến, phương pháp của chúng tôi sử dụng các biên tập viên con người để trích xuất và giải thích các sắc thái ngữ cảnh và chi tiết thực tế từ các bài báo (Hình 3b). Cách tiếp cận lấy con người làm trung tâm này tăng tính tự nhiên và liên quan của dữ liệu, cho phép bộ dữ liệu đại diện tốt hơn cho các tình huống thông tin phức tạp trong thế giới thực.

Bằng cách gán nhãn phản ánh ngữ cảnh của từng bài báo, phương pháp của chúng tôi hỗ trợ các nhiệm vụ suy luận phức tạp yêu cầu phân tích trên nhiều mảnh bằng chứng. Cách tiếp cậ n tinh chỉnh này đảm bảo rằng bộ dữ liệu của chúng tôi đặc biệt phù hợp với các hệ thống xác minh sự thật nâng cao, đóng góp đáng kể vào độ chính xác và hiệu quả của việc phát hiện thông ti n sai lệch trong môi trường truyền thông kỹ thuật số.

Ghi chú thí điểm được sử dụng để làm quen cho các người chú thích với quy trình tạo và xác minh tuyên bố được mô tả ở trên. Bảy sinh viên đại học nói tiếng Việt bản ngữ

đã tham gia với vai trò là người chú thích. Chúng tôi đã tiến hành thử nghiệm chú thích với mỗi người chú thích thực hiện chú thích 120 tuyên bố tương ứng với 20 bài báo ngẫu nhiên. Người chú thích được hướng dẫn đọc lại từng tuyên bố một cách cẩn thận và nghiêm ngặt theo hướng dẫn chú thích. Chi tiết về việc tuyển dụng người chú thích và hướng dẫn có thể được tìm thấy trong Phụ lục C và D.

Để xác minh tính toàn vẹn của quy trình chú thích thử nghiệm, chúng tôi đã tiến hành các đánh giá kỹ lưỡng cả về các yêu cầu và nhãn tương ứng của chúng. Chuyên gia đã cung cấp phản hồi chi tiết và yêu cầu những người chú thích xem xét lại bất kỳ chi tiết hoặc nhãn nào không đáp ứng yêu cầu của hướng dẫn chú thích.

Chú thích chính Sau một giai đoạn thử nghiệm nhằm làm quen các người chú thích với các nhiệm vụ, mỗi người được giao một tập con cụ thể để đảm bảo sự tập trung và tham gia sâu sắc. Trong suốt giai đoạn này, việc tuân thủ nghiêm ngặt các hướng dẫn đã thiết lập là cực kỳ quan trọng để đảm bảo sự nhất quán và nâng cao chất lượng tổng thể của bộ dữ liệu.

Claim Generation: Before generating any claims, annotators conducted a thorough review of the article. This meticulous process ensures a deep understanding of the multiple facets of the article, facilitating an accurate interpretation of the information. Annotators then employed their expertise to construct claims that align with the predefined labels: Support, Refute, and NEI (Not Enough Information). Such rigorous adherence to these guidelines is essential for generating contextually relevant claims, thereby enhancing the reliability of the dataset and its utility in advancing fact-checking.

Evidence Annotation: In terms of evidence annotation, the task extends beyond simple identification. Annotators are required to meticulously annotate the supporting evidence for each claim derived from the phrases previously collected from the articles. To enhance the complexity of the dataset and the challenge it presents, annotators are instructed not to limit their claims to single pieces of evidence. Instead, they are required to craft intricate claims that amalgamate multiple pieces of evidence (Appendix F). This process involves breaking down the claim, collating diverse evidences, and performing multi-step reasoning. The ability to synthesize complex evidence not only enriches the data but also crucially underpins more sophisticated analyses.

3.3 Validation of Annotation

After completing the main annotation phases, we implemented several strategies to ensure the quality and consistency of the dataset: **(1)** Self-checking: Annotators review their own claims and labels, checking for grammatical errors and typographical mistakes. **(2)** Cross-checking: Annotators verify the work of their peers. Any identified errors are collaboratively discussed and corrected.

Metric For Inter-Annotator Agreement: Fleiss Kappa is widely used to evaluate inter-annotator agreement (IAA) in several tasks and is considered a benchmark for such measurements (McHugh 2012; Thorne et al. 2018). Consequently, we utilized the Fleiss Kappa metric (Fleiss 1971) to assess inter-annotator agreement, thus ensuring quality assurance in human annotation.

We randomly selected 10% of the claims (n = 726) from the labeled dataset, assigning them to a group of three annotators. These claims, originally authored by different individuals, were relabeled without revealing the existing annotations. The inter-rater agreement was then calculated using the Fleiss Kappa measure. We achieved an agreement level of 0.83, indicative of a very high level of agreement among annotators, which confirms the high quality and reliability of our dataset.

3.4 Words overlap and Semantic similarity analysis

To evaluate the complexity of inference within our dataset, we employed two principal metrics: word overlap and semantic similarity. For word overlap, we used metrics including Longest Common Sequence (LCS), New Word Ratio (%) (NWR), Jaccard Similarity (%) (JS), and Lexical Overlap. For semantic similarity, we utilized the concept of Related Words, generating embeddings with SBERT (2019) and calculating correlations using cosine similarity. The results are summarized in Table 2.

		LSC	NWR	JS	LO	RW
Context	Support	20.60	6.54	11.46	20.13	36.24
	Refute	18.10	11.50	10.06	17.90	34.00
	NEI	19.89	11.81	10.96	18.50	32.85
Evidence	Support	17.70	17.13	63.52	73.87	86.89
	Refute	15.46	25.47	54.63	66.69	81.41
	NEI	16.71	26.84	57.56	64.39	81.13

Table 2: Relationship between claim-context and claim-evidence in the ViFactCheck dataset.

McCoy, Pavlick, and Linzen (2019) demonstrated that models face difficulties with low overlap ratios, necessitating advanced inference capabilities. Our dataset features claim-context pairs with minimal word overlap and semantic similarity, complicating model inference. In contrast, a strong correlation between claim-evidence pairs significantly enhances the performance of models when the appropriate evidence is retrieved. Further detailed analysis can be found in the Appendix G.

4 Experiment and Results

4.1 Baseline models

Drawing on the transformative impact of transformer-based models in prior fact-checking studies (Thorne et al. 2018; Hu et al. 2022; Nørregaard and Derczynski 2021), our research employs pre-trained language models (PLMs) that utilize the BERT (Devlin et al. 2019) and RoBERTa (Liu et al. 2019) architectures. Our study incorporates four specific models to address the fact-checking task, including two multilingual models mBERT (2019) and XLM-R (2020) and two monolingual models PhoBERT (2020) and ViBERT (2020) tailored to handle linguistic nuances effectively.

Moreover, the recent strides in large language models (LLMs) have solidified their utility in demonstrating robust contextual comprehension and reasoning capabilities, particularly in tasks that require deep understanding, such as fact-checking. Accordingly, our experimental framework includes four SOTA open-source LLMs designed for optimized performance in low-resource settings: Llama (2023), Gemma (2024), and Mistral (2023). These models are pivotal in our methodology, providing a comprehensive approach to evaluating their effectiveness across diverse linguistic contexts.

4.2 Software and Hardware Configurations

We employed the AdamW optimizer for fine-tuning pre-trained language models, as detailed by Loshchilov and Hutter (2019). The settings for these models included a learning rate of 5e-06, a dropout rate of 0.3, a batch size of 16, and a training duration of 10 epochs. Additionally, for PhoBERT, we segmented the text data using VnCoreNLP (Vu et al. 2018), adhering to the recommendations by Nguyen and Tuan Nguyen (2020). The dataset was partitioned into training, development, and test sets with a split ratio of 6:2:2, ensuring a balanced evaluation across all stages of model development.

Tạo Yêu Cầu: Trước khi tạo bất kỳ yêu cầu nào, các người chú thích đã tiến hành xem xét kỹ lưỡng bài báo. Quá trình tỉ mỉ này đảm bảo hiểu biết sâu sắc về nhiều khía cạnh của bài báo, tạo điều kiện cho việc giải thích thông tin một cách chính xác. Sau đó, các người chú thích đã sử dụng chuyên môn của mình để xây dựng các yêu cầu phù hợp với các nhãn đã được định trước: Hỗ trợ, Bác bỏ và NEI (Không đủ Thông tin). Việc tuân thủ nghiêm ngặt các hướng dẫn này là thiết yếu để tạo ra các yêu cầu có liên quan trong bối cảnh, từ đó nâng cao độ tin cậy của bộ dữ liệu và tính hữu ích của nó trong việc thúc đẩy kiểm tra sự thật.

Chú thích bằng chứng: Về mặt chú thích bằng chứng, nhiệm vụ này vượt ra ngoài việc nhận diện đơn giản. Người chú thích được yêu cầu phải tỉ mỉ chú thích các bằng chứng hỗ trợ cho từng tuyên bố được rút ra từ các cụm từ đã thu thập trước đó từ các bài báo. Để tăng độ phức tạp của bộ dữ liệu và thử thách mà nó mang lại, người chú thích được hướng dẫn không giới hạn các tuyên bố của họ vào một mảnh bằng chứng duy nhất. Thay vào đó, họ được yêu cầu tạo ra các tuyên bố phức tạp kết hợp nhiều bằng chứng khác nhau (Phụ lục F). Quá trình này bao gồm việc phân tích tuyên bố, tập hợp các bằng chứng đa dạng và thực hiện suy luận nhiều bước. Khả năng tổng hợp các bằng chứng phức t ạp không chỉ làm phong phú dữ liệu mà còn quan trọng trong việc cơ sở cho các phân tích tinh vi hơn.

3.3 Xác nhận Chú thích

Sau khi hoàn thành các giai đoạn chú thích chính, chúng tôi đã triển khai một số chiến lược để đảm bảo chất lượng và sự nhất quán của tập dữ liệu: (1) Tự kiểm tra: Người chú thích xem lại các tuyên bố và nhãn của chính họ, kiểm tra lỗi ngữ pháp và lỗi đánh máy. (2) Kiểm tra chéo: Người chú thích xác minh công việc của đồng nghiệp. Bất kỳ lỗi nào được phát hiện sẽ được thảo luận và sửa chữa cùng nhau.

Chỉ số Đo lường Sự đồng thuận giữa các Người chú thích: Fleiss Kappa được sử dụng rộng rãi để đánh giá sự đồng thuận giữa các người chú thích (IAA) trong nhiều nhiệm vụ và được coi là tiêu chuẩn cho các phép đo như vậy (McHugh 2012; Thorne et al. 2018). Do đó, chúng tôi đã sử dụng chỉ số Fleiss Kappa (Fleiss 1971) để đánh giá sự đồng thuận giữa các người chú thích, qua đó đảm bảo chất lượng trong việc chú thích của con người.

Chúng tôi đã chọn ngẫu nhiên 10% các yêu cầu (n = 726) từ bộ dữ liệu đã gán nhãn, phân công chúng cho một nhóm gồm ba người gán nhãn. Những yêu cầu này, vốn được viết bởi các cá nhân khác nhau, đã được gán nhãn lại mà không tiết lộ các nhãn hiện có. Sau đó, mức độ đồng thuận giữa các người gán nhãn được tính bằng chỉ số Fleiss Kappa. Chúng tôi đạt được mức đồng thuận là 0,83, cho thấy mức độ đồng thuận rất cao giữa các người gán nhãn, điều này xác nhận chất lượng và độ tin cậy cao của bộ dữ liệu của chúng tôi.

3.4 Phân tích trùng lặp từ và độ tương đồng ngữ nghĩa

Để đánh giá độ phức tạp của suy luận trong tập dữ liệu của chú ng tôi, chúng tôi đã sử dụng hai chỉ số chính: sự trùng lặp từ và s ự tương đồng ngữ nghĩa. Đối với sự trùng lặp từ, chúng tôi đã sử dụng các chỉ số bao gồm Dãy Con Chung Dài Nhất (LCS), Tỷ lệ Từ Mới (%) (NWR), Độ Tương Đồng Jaccard (%) (JS) và Sự Trùng Lặp Từ Vựng. Đối với sự tương đồng ngữ nghĩa, chúng tôi đã sử dụng khái niệm Từ Liên Quan, tạo embedding với SBERT (2019) và tính toán tương quan bằng cách sử dụng độ tương đồng cosine. Kết quả được tóm tắt trong Bảng 2.

		LSC	NWR	JS	LO	RW
Bối cả nh	Hỗ trợ	20.60	6.54	11.46	20.13	36.24
	Bác bỏ	18.10	11.50	10.06	17.90	34.00
	NEI	19.89	11.81	10.96	18.50	32.85
Bằng chứng	Hỗ trợ	17.70	17.13	63.52	73.87	86.89
	Bác bỏ	15.46	25.47	54.63	66.69	81.41
	NEI	16.71	26.84	57.56	64.39	81.13

Bảng 2: Mối quan hệ giữa ngữ cảnh khẳng định và bằng chứng khẳng định trong bộ dữ liệu ViFactCheck.

McCoy, Pavlick và Linzen (2019) đã chứng minh rằng các mô hình gặp khó khăn với tỷ lệ chồng lấp thấp, đòi hỏi khả năng suy diễn nâng cao. Bộ dữ liệu của chúng tôi có các cặp yêu cầu-ngữ cảnh với sự chồng lấp từ và sự tương đồng ngữ nghĩa tối thiểu, làm phức tạp việc suy diễn của mô hình. Ngược lại, một mối tương quan mạnh mẽ giữa các cặp yêu cầu-bằng chứng cải thiện đáng kể hiệu suất của mô hình khi bằng chứng thích hợp được truy xuất. Phân tích chi tiết hơn có thể được tìm thấy trong Phụ lục G.

4 Thí nghiệm và Kết quả

4.1 Mô hình cơ sở

Dựa trên tác động biến đổi của các mô hình dựa trên transfor mer trong các nghiên cứu kiểm tra sự thật trước đây (Thorne et al. 2018; Hu et al. 2022; Nørregaard và Derczynski 2021), nghiên cứu của chúng tôi sử dụng các mô hình ngôn ngữ được huấn luyện trước (PLMs) sử dụng kiến trúc BERT (Devlin et al. 2019) và RoBERTa (Liu et al. 2019). Nghiên cứu của chúng tôi bao gồm bốn mô hình cụ thể để giải quyết nhiệm vụ kiểm tra sự thật, bao gồm hai mô hình đa ngôn ngữ mBERT (2019) và XLM-R (2020) và hai mô hình đơn ngữ PhoBERT (2020) và ViBERT (2020) được thiết kế để xử lý hiệu quả các sắc thái ngôn ngữ.

Hơn nữa, những bước tiến gần đây trong các mô hình ngôn ngữ lớn (LLMs) đã củng cố tính hữu ích của chúng trong việc thể hiện khả năng hiểu ngữ cảnh và lập luận mạnh mẽ, đặc biệt tr ong các nhiệm vụ đòi hỏi sự hiểu biết sâu sắc, chẳng hạn như kiểm tra sự thật. Theo đó, khung thí nghiệm của chúng tôi bao gồm bốn LLM mã nguồn mở SOTA được thiết kế để tối ưu hóa hiệu suất trong các môi trường tài nguyên thấp: Llama (2023), Gemma (2024) và Mistral (2023). Những mô hình này là then chốt trong phương pháp của chúng tôi, cung cấp một cách tiếp cận toàn diện để đánh giá hiệu quả của chúng trong các bối cảnh ngôn ngữ đa dạng.

4.2 Cấu hình Phần mềm và Phần cứng

Chúng tôi sử dụng bộ tối ưu AdamW để tinh chỉnh các mô hình ngôn ngữ đã được đào tạo trước, như được trình bày bởi Loshchilov và Hutter (2019). Các cài đặt cho những mô hình này bao gồm tốc độ học 5e-06, tỷ lệ dropout 0,3, kích thước lô 16 và thời gian huấn luyện 10 lần lặp (epoch). Ngoài ra, đối với PhoBERT, chúng tôi phân đoạn dữ liệu văn bản bằng VnCoreNLP (Vu et al. 2018), tuân thủ các khuyến nghị của Nguyen và Tuan Nguyen (2020). Bộ dữ liệu được chia thành các tập huấn luyện, phát triển và kiểm tra với tỷ lệ phân chia 6:2:2, đảm bảo đánh giá cân bằng ở tất cả các giai đoạn phát triển mô hình.

For LLMs, we utilized the Unsloth framework with supervised fine-tuning using LoRA adaptation. The hyperparameters were configured with a Lora rank of 16, Lora alpha of 16, a learning rate of 2e-04, a batch size of 16, and 5 epochs. All experiments were conducted on a RTX 4090 GPU with 24GB of memory, utilizing PyTorch version 2.2.1 and Transformers version 4.41.2, and took a total of five days to complete. Details of the models, prompt templates and parameters can be found in Appendices H, I and J.

4.3 Main Results

Table 3 presents a detailed comparison of language models in fact-checking, examining their performance across different methods such as fine-tuning and prompting, and their efficiency in using Full Context versus Gold Evidence. Using the macro-average F1 score (%), the analysis provides insights into the capabilities of the models, highlighting the strengths and limitations of each approach in processing complex information sets.

Model	Full Context	Gold Evidence	Δ
Fine-tuning PLMs			
PhoBERT$_{base}$	68.55	77.76	↑9.21
PhoBERT$_{large}$	62.93	79.76	↑16.83
ViBERT	59.95	72.18	↑12.23
mBERT	58.07	69.94	↑11.87
XLM-R$_{base}$	65.40	81.10	↑15.70
XLM-R$_{large}$	75.42	88.02	↑12.60
Fine-tuning LLMs			
Gemma	**85.94**	**89.90**	↑3.96
Mistral	70.13	88.63	↑18.50
Llama2	41.47	79.53	↑**38.06**
Llama3	79.65	88.67	↑9.02
Prompting LLMs			
Gemini	76.26	74.88	↓1.38
Gemma	45.05	39.47	↓5.58
Mistral	61.02	57.31	↓3.71
Llama2	63.54	51.64	↓11.90
Llama3	65.21	63.10	↓2.11

Table 3: Performance comparison of baseline models on the ViFactCheck test set. Context and Evidence indicate the use of Full Context and Gold Evidence, respectively, for Claim Verification. The best scores are highlighted in bold; models that outperform other peers are underlined. Performance differences (Δ) are statistically significant ($p < 0.01$), confirming robust gains or reductions when Full Context is employed compared to Gold Evidence.

Fine-tuning Pre-trained Language Models Among the PLMs, XLM-R$_{large}$ stands out with exemplary performance, scoring 75.42% in Context and 88.02% in Evidence. These results suggest that the scale and design of XLM-R$_{large}$ provide a robust model capable of handling the complexities inherent in determining the veracity of claims based on the provided contexts and evidence. Additionally, variants of BERT-based models also demonstrate considerable gains, with PhoBERT$_{large}$ in particular showing a significant leap in context understanding compared to its peers.

Fine-tuning Large Language Models The LLMs, particularly Gemma, display remarkable effectiveness, outperforming other models in both Context (85.94%) and Evidence (89.90%) scores. This superior performance is likely due to the deeper learning capabilities and broader contextual understanding inherent in larger models. Variations in performance within this category also highlight the potential for specific architectural enhancements and targeted training strategies, as evidenced by the disparity between Llama2 and Llama3.

Fine-tuning PLMs and LLMs Fine-tuning both PLMs and LLMs consistently produces better results than prompting methods. Fine-tuning, which involves specific adjustments to model weights for the task, enables the models to directly learn detailed and nuanced patterns within the training data. The effectiveness of fine-tuning is particularly evident in scenarios involving Gold Evidence, where the fine-tuned model can precisely assess the validity of claims based on key information.

Performance with Gold Evidence versus Full Context The use of Gold Evidence typically results in higher accuracy scores across models compared to when the Full Context is provided. Gold evidence, being directly relevant to the claims, allows models to focus their computational power on a smaller, more pertinent dataset, thereby reducing the noise associated with broader contexts. This targeted approach leads to more precise verifications but does not necessarily prepare models for real-world scenarios where they must extract relevant information from extensive, unstructured data.

Prompting and Handling Full Context Models designed to handle extensive and complex contexts, such as Gemini, benefit from prompting techniques that leverage pre-trained knowledge to interpret new data without extensive re-training. This approach enables efficient navigation and processing of large datasets, making it especially suitable for applications that require the processing of generalized information. However, despite its capability to manage broader data, prompting generally falls short of achieving the accuracy delivered by fine-tuning, particularly when detailed specificity and deep data understanding are necessary.

Influence of Model Architecture and Size The results consistently reveal that larger models such as XLM-R$_{large}$ and Gemma surpass their smaller counterparts in both context and evidence metrics. The enhanced performance of these models is attributed to their expanded capacity, which is essential for addressing the intricacies associated with verifying claims. Equipped with extensive neural networks and deeper layers, these models possess greater computational power, enabling them to effectively model complex relationships and dependencies in the data. This allows for more effective information extraction and synthesis, providing a significant advantage in fact-checking tasks.

4.4 Analysis and Discussion

How does the Evidences Retrieval help? Our analysis of retrieval models in fact-checking sheds light on the operational dynamics of SBERT (Reimers and Gurevych 2019), BM25 (Robertson, Zaragoza et al. 2009), and their hybrid configurations under various conditions, with a focus on how well these models understand the semantic complexities of

Đối với các LLM, chúng tôi đã sử dụng khung Unsloth với việc tinh chỉnh có giám sát sử dụng thích ứng LoRA. Các siêu tham số được cấu hình với hạng Lora là 16, Lora alpha là 16, tốc độ học là 2e-04, kích thước lô là 16, và 5 epoch. Tất cả các thí nghiệm được tiến hành trên GPU RTX 4090 với 24GB bộ nhớ, sử dụng PyTorch phiên bản 2.2.1 và Transformers phiên bản 4.41.2, và mất tổng cộng năm ngày để hoàn thành. Chi tiết về các mô hình, mẫu prompt và các tham số có thể được tìm thấy trong Phụ lục H, I và J.

4.3 Kết quả chính

Bảng 3 trình bày một so sánh chi tiết các mô hình ngôn ngữ trong việc kiểm chứng sự thật, xem xét hiệu suất của chúng theo các phương pháp khác nhau như tinh chỉnh và gợi ý, cũng như hiệu quả của chúng khi sử dụng Toàn bộ Ngữ cảnh so với Bằng chứng Vàng. Sử dụng điểm F1 trung bình tổng thể (%), phân tích cung cấp những hiểu biết về khả năng của các mô hình, nhấn mạnh điểm mạnh và hạn chế của từng phương pháp trong việc xử lý các bộ thông tin phức tạp.

Mô hình	Toàn bộ bối cảnh	Bằng chứng vàng	Δ
Tinh chỉnh các PLM			
PhoBERT$_{base}$	68.55	77.76	↑9.21
PhoBERT^{large}	62.93	79.76	↑16.83
ViBERT	59.95	72.18	↑12.23
mBERT	58.07	69.94	↑11.87
XLM-R$_{base}$	65.40	81.10	↑15.70
XLM-R^{large}	75.42	88.02	↑12.60
Tinh chỉnh LLMs			
Gemma	**85.94**	**89.90**	↑3.96
Gió Mistral	70.13	88.63	↑18.50
Llama2	41.47	79.53	↑**38.06**
Llama3	79.65	88.67	↑9.02
Gợi ý cho LLMs			
Song Tử	76.26	74.88	↓1.38
Gemma	45.05	39.47	↓5.58
Gió Mistral	61.02	57.31	↓3.71
Llama2	63.54	51.64	↓11.90
Llama3	65.21	63.10	↓2.11

Bảng 3: So sánh hiệu suất của các mô hình cơ bản trên tập kiểm tra ViFactCheck. Context và Evidence lần lượt chỉ việc sử dụng Toàn bộ bối cảnh và Bằng chứng vàng cho Xác thực Yêu cầu. Các điểm số tốt nhất được in đậm; các mô hình vượt trội hơn các mô hình khác được gạch chân. Sự khác biệt hiệu suất (Δ) có ý nghĩa thống kê ($p < 0.01$), xác nhận các cải thiện hoặc giảm mạnh khi sử dụng Toàn bộ bối cảnh so với Bằng chứng vàng.

Tinh chỉnh các Mô hình Ngôn ngữ Đã được Huấn luyện Tr ước Trong số các PLM, XLM-R^{large} nổi bật với hiệu suất xuất sắc, đạt 75,42% về Ngữ cảnh và 88,02% về Bằng chứng. Những kết quả này cho thấy quy mô và thiết kế của XLM-R^{large} cung cấp một mô hình vững chắc có khả năng xử lý các phức tạp vốn có trong việc xác định tính xác thực của các tuyên bố dựa trên ngữ cảnh và bằng chứng được cung cấp. Ngoài ra, các biến thể của các mô hình dựa trên BERT cũng cho thấy sự cải thiện đáng kể, trong đó PhoBERT^{large} đặc biệt thể hiện một bước nhảy vọt quan trọng trong việc hiểu ngữ cảnh so với các mô hình cùng loại.

Tinh chỉnh Mô hình Ngôn ngữ Lớn Các LLM, đặc biệt là Gemma, cho thấy hiệu quả đáng kể, vượt trội hơn các mô hình khác về cả điểm Cảnh cảnh (85,94%) và Bằng chứng (89,90%). Hiệu suất vượt trội này có khả năng nhờ vào khả năng học sâu hơn và hiểu biết bối cảnh rộng hơn vốn có ở các mô hình lớn hơn. Sự khác biệt về hiệu suất trong cùng loại này cũng làm nổi bật tiềm năng cho các cải tiến kiến trúc cụ thể và các chiến lược đào tạo tập trung, như được chứng minh bởi sự chênh lệch giữa Llama2 và Llama3.

Tinh chỉnh PLM và LLM Tinh chỉnh cả PLM và LLM thường xuyên mang lại kết quả tốt hơn so với các phương pháp gợi ý. Tinh chỉnh, bao gồm các điều chỉnh cụ thể đối với trọng số của mô hình cho nhiệm vụ, cho phép mô hình trực tiếp học các mô hình chi tiết và tinh vi trong dữ liệu huấn luyện. Hiệu quả của việc tinh chỉnh đặc biệt rõ rệt trong các tình huống liên quan đến Bằng chứng Vàng, nơi mô hình được tinh chỉnh có thể đánh giá chính xác tính hợp lệ của các tuyên bố dựa trên thông tin quan trọng.

Hiệu suất với Bằng chứng Vàng so với Toàn bộ Ngữ cảnh Việc sử dụng Bằng chứng Vàng thường dẫn đến điểm chính xác cao hơn trên các mô hình so với khi Toàn bộ Ngữ cảnh được cung c ấp. Bằng chứng vàng, vì có liên quan trực tiếp đến các tuyên bố, cho phép các mô hình tập trung sức mạnh tính toán của chúng vào một tập dữ liệu nhỏ hơn, liên quan hơn, từ đó giảm thiểu nhiễu liên quan đến các ngữ cảnh rộng hơn. Cách tiếp cận có mục tiêu này dẫn đến việc xác minh chính xác hơn nhưng không nhất thiết chuẩn bị các mô hình cho các tình huống thực tế, nơi chúng phải trích xuất thông tin liên quan từ dữ liệu rộng lớn, không có cấu trúc.

Những mô hình ngữ cảnh đầy đủ được thiết kế để xử lý các ngữ cảnh rộng và phức tạp, chẳng hạn như Gemini, được hưởng lợi từ các kỹ thuật gợi ý tận dụng kiến thức đã được đào tạo trước để giải thích dữ liệu mới mà không cần huấn luyện lại nhiều. Cách tiếp cận này cho phép điều hướng và xử lý dữ liệu lớn một cách hiệu quả, khiến nó đặc biệt phù hợp cho các ứng dụng yêu cầu xử lý thông tin tổng quát. Tuy nhiên, mặc dù có khả năng quản lý dữ liệu rộng hơn, việc gợi ý nói chung vẫn chưa đạt được độ chính xác mà việc tinh chỉnh mang lại, đặc biệt khi cần tính cụ thể chi tiết và hiểu biết sâu về dữ liệu.

Ảnh hưởng của Kiến trúc và Kích thước Mô hình Các kết quả cho thấy nhất quán rằng các mô hình lớn hơn như XLM-R^{large} và Gemma vượt trội hơn các mô hình nhỏ hơn của chúng về cả hai chỉ số ngữ cảnh và bằng chứng. Hiệu suất nâng cao của những mô hình này được quy cho khả năng mở rộng của chúng, điều này thiết yếu để xử lý các phức tạp liên quan đến việc xác minh các tuyên bố. Được trang bị mạng nơ-ron rộng lớn và các lớp sâu hơn, những mô hình này có sức mạnh tính toán lớn hơn, cho phép chúng mô hình hoá hiệu quả các mối quan hệ và sự phụ thuộc phức tạp trong dữ liệu. Điều này giúp trích xuất và tổng hợp thông tin hiệu quả hơn, mang lại lợi thế đáng kể trong các nhiệm vụ kiểm chứng thông tin.

4.4 Phân tích và Thảo luận

Việc Truy xuất Bằng chứng giúp như thế nào? Phân tích của chúng tôi về các mô hình truy xuất trong kiểm chứng sự thật thực ra làm sáng tỏ các động lực vận hành của SBERT (Reimers và Gurevych 2019), BM25 (Robertson, Zaragoza et al. 2009), và các cấu hình lai của chúng dưới các điều kiện khác nhau, với trọng tâm là mức độ các mô hình này hiểu được sự phức tạp ngữ nghĩa của

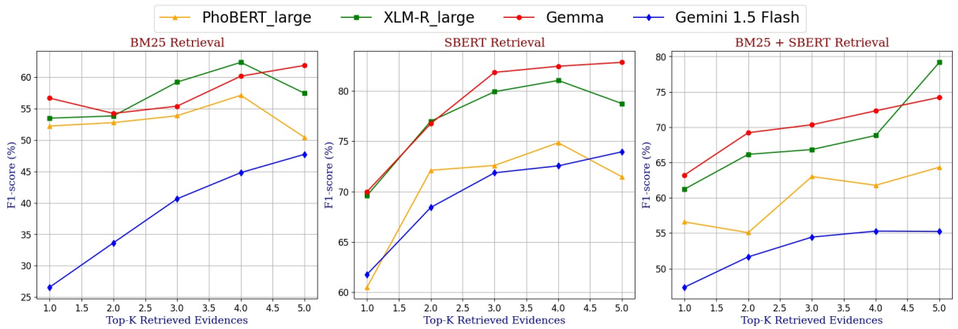


Figure 4: Comparative performance of various text retrieval models across different Top-K settings.

language processing (see Figure 4). The choice of these models for a more detailed evaluation is based on their superior performance across experiments, as discussed in Section 4.3.

A deeper dive into the results reveals that increasing the number of top-K retrieved evidences universally benefits all models by expanding the pool of potentially relevant information. However, the relationship between the number of documents retrieved (K) and the improvement in F1-score is not linear and varies significantly between different models and configurations. SBERT, in particular, shows a strong positive correlation between increased K and performance gains, indicating its effective use of broader contextual data.

Interestingly, performance improvements begin to plateau at higher K values in certain configurations, including Gemma within the SBERT model, suggesting an optimal K threshold of 5. This threshold represents the balance point where the benefits of additional document retrieval begin to decline relative to the computational costs. This insight is crucial for optimizing retrieval systems, emphasizing the need to balance data comprehensiveness with resource efficiency.

Furthermore, the distinct behavior of configurations like Gemini 1.5 Flash under SBERT, which scales effectively with an increase in K, underscores the potential for tailored approaches based on specific system capabilities and task requirements. Such adaptability is crucial in cases where the volume and variety of information vary dramatically.

How Multi-evidence Impacts Model Reasoning? The comparative performance of language models shows significant variations, particularly when comparing their ability to handle single-evidence versus multiple-evidence inputs, as depicted in Table 4. Gemma stands out for its robust capability in both of scenarios, benefitting significantly from training on a diverse, multilingual dataset. This extensive training enhances its adaptability and accuracy by enabling it to effectively manage complex contexts. Additionally, Gemma excels in data sufficiency assessments, effectively classifying the Not Enough Information (NEI) category across different scenarios, which is crucial for ensuring the reliability of fact-checking systems and preventing misinformation.

In single-evidence scenarios, the simplicity of the data allows models such as Llama3 to achieve higher accuracy. This straightforwardness typically presents less ambiguity, enabling the models to apply their verification capabilities more effectively. However, when multiple evidence sources are introduced, the added complexity significantly challenges all models. The noticeable decline in performance metrics in these scenarios highlights a gap in the ability of models to synthesize and integrate information from various sources, revealing a critical area for future enhancements.

4.5 Qualitative Error Analysis

Based on the macro F1 scores, we selected the Gemma model as our baseline to perform a detailed error analysis. As illustrated in Figure 5 and further detailed in Appendix K, we evaluated 100 random incorrect predictions from the development set to identify and categorize error types.

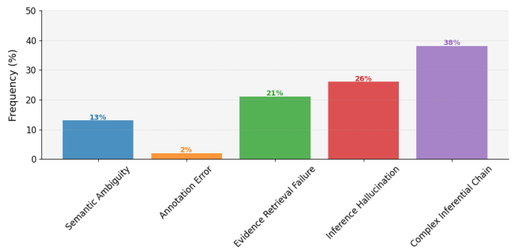
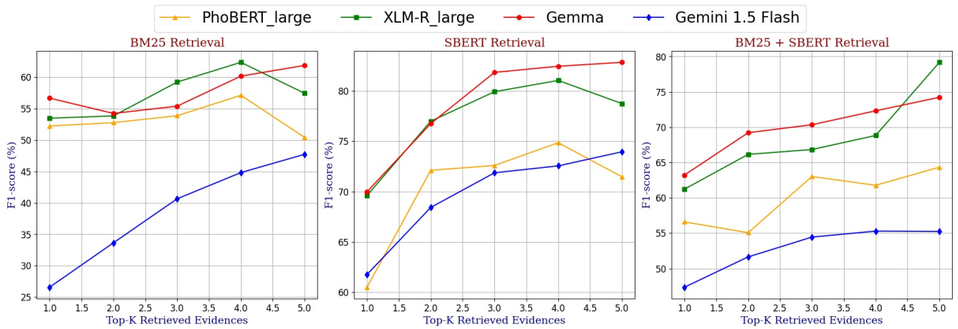


Figure 5: Distributions of errors.

The analysis revealed significant challenges in handling Semantic Ambiguity and Complex Inferential Chains, both of which are pivotal for refining NLP technologies. Semantic Ambiguity issues particularly highlight the necessity for context-aware processing (Wang et al. 2022; Wu et al. 2023). By integrating transformer-based models, the ability of the Gemma model to interpret complex linguistic contexts could be substantially improved, enhancing its accuracy in environments where nuance is critical.



Figu Hình 4: Hiệu suất so sánh của các mô hình truy xuất văn bản khác nhau trên các thiết lập Top-K khác nhau s.

xử lý ngôn ngữ (xem Hình 4). Việc lựa chọn các mô hình này để đánh giá chi tiết hơn dựa trên hiệu suất vượt trội của chúng tro ng các thí nghiệm, như đã thảo luận trong Mục 4.3.

Một phân tích sâu hơn về kết quả cho thấy việc tăng số lượng bằng chứng top-K được truy xuất mang lại lợi ích chung cho tất cả các mô hình bằng cách mở rộng nguồn thông tin có khả năng liên quan. Tuy nhiên, mối quan hệ giữa số lượng tài liệu được truy xuất (K) và sự cải thiện điểm F1 không tuyến tính và thay đổi đáng kể giữa các mô hình và cấu hình khác nhau. SBERT, cụ thể, cho thấy mối tương quan tích cực mạnh mẽ giữa việc tăng K và mức tăng hiệu suất, chỉ ra một cách sử dụng hiệu quả dữ liệu ngữ cảnh rộng hơn của nó.

Thú vị là, hiệu suất cải thiện bắt đầu đạt điểm bão hòa ở các giá trị K cao hơn trong một số cấu hình nhất định, bao gồm Gemma trong mô hình SBERT, gợi ý một ngưỡng K tối ưu là 5. Ngưỡng này đại diện cho điểm cân bằng nơi lợi ích của việc truy xuất thêm tài liệu bắt đầu giảm so với chi phí tính toán. Nhận thức này là rất quan trọng cho việc tối ưu hóa các hệ thống truy xuất, nhấn mạnh sự cần thiết phải cân bằng giữa sự toàn diện c ủa dữ liệu và hiệu quả sử dụng tài nguyên.

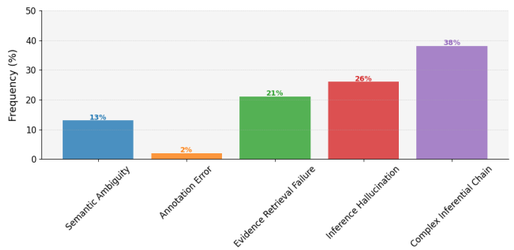
Hơn nữa, hành vi đặc biệt của các cấu hình như Gemini 1.5 Flash dưới SBERT, vốn tăng hiệu quả khi K tăng, nhấn mạnh tiề m năng của các phương pháp tùy chỉnh dựa trên khả năng cụ thể của hệ thống và yêu cầu nhiệm vụ. Khả năng thích ứng như vậy l à rất quan trọng trong những trường hợp khối lượng và đa dạng thông tin thay đổi đáng kể.

Sự tác động của nhiều bằng chứng đối với lập luận của mô hình như thế nào? Hiệu suất so sánh của các mô hình ngôn ngữ cho thấy sự biến động đáng kể, đặc biệt khi so sánh khả năng của chúng trong việc xử lý đầu vào với một bằng chứng so với nhiều bằng chứng, như được minh họa trong Bảng 4. Gemma nổi bật với khả năng vững chắc trong cả hai tình huống, được hưởng lợi đáng kể từ việc đào tạo trên một bộ dữ liệu đa dạng, đa ngôn ngữ. Việc đào tạo rộng rãi này nâng cao khả năng thích ứng và độ chính xác của nó bằng cách cho phép quản lý hiệu quả các ngữ cảnh phức tạp. Ngoài ra, Gemma xuất sắc trong các đánh giá về đủ dữ liệu, phân loại hiệu quả hạng mục Thông tin Không Đủ (NEI) trong các tình huống khác nhau, điều này rất quan trọng để đảm bảo độ tin cậy của các hệ thống kiểm tra sự thật và ngăn chặn thông tin sai lệch.

Trong các tình huống chỉ có một bằng chứng, sự đơn giản của dữ liệu cho phép các mô hình như Llama3 đạt được độ chính xác cao hơn. Sự đơn giản này thường tạo ra ít mơ hồ hơn, giúp các mô hình áp dụng khả năng xác minh của chúng hiệu quả hơn. Tuy nhiên, khi nhiều nguồn chứng cứ được đưa vào, sự phức tạp tăng thêm sẽ thách thức đáng kể tất cả các mô hình. Sự suy giảm rõ rệt trong các chỉ số hiệu suất trong các kịch bản này làm nổi bật một khoảng cách trong khả năng của các mô hình trong việc tổng hợp và tích hợp thông tin từ nhiều nguồn khác nhau, tiết lộ một lĩnh vực quan trọng cần cải tiến trong tương lai.

4.5 Phân Tích Lỗi Định Tính

Dựa trên các điểm số F1 macro, chúng tôi đã chọn mô hình Gemma làm cơ sở để thực hiện phân tích lỗi chi tiết. Như minh họa trong Hình 5 và được trình bày chi tiết hơn trong Phụ lục K, chúng tôi đã đánh giá 100 dự đoán sai ngẫu nhiên từ tập phát triển để xác định và phân loại các loại lỗi.



Hình 5: Phân bố lỗi.

Phân tích cho thấy những thách thức đáng kể trong việc xử lý Sự mơ hồ ngữ nghĩa và Chuỗi suy luận phức tạp, cả hai đều đóng vai trò then chốt trong việc tinh chỉnh công nghệ NLP. Vấn đề Sự mơ hồ ngữ nghĩa đặc biệt nhấn mạnh sự cần thiết phải xử lý có nhận thức ngữ cảnh (Wang và cộng sự, 2022; Wu và cộng sự, 2023). Bằng cách tích hợp các mô hình dựa trên transformer, khả năng của mô hình Gemma trong việc diễn giải các ngữ cảnh ngôn ngữ phức tạp có thể được cải thiện đáng kể, nâng cao độ chính xác của nó trong những môi trường mà sự tinh tế là quan trọng.

	Single-evidence				Multiple-evidence				Overall			
	Avg. F1	Support	Refute	NEI	Avg. F1	Support	Refute	NEI	Avg. F1	Support	Refute	NEI
Fine-tuning PLMs												
PhoBERT$_{base}$	69.79	71.04	65.53	72.80	64.92	66.89	67.10	60.77	68.47	69.75	69.75	69.75
PhoBERT$_{large}$	75.01	76.27	70.81	77.95	62.72	64.44	67.12	56.58	71.47	72.64	69.59	72.18
ViBERT	56.42	61.38	46.31	61.59	58.11	63.64	56.23	54.46	57.16	62.08	49.57	59.81
mBERT	71.92	70.45	67.17	78.13	61.72	62.19	60.57	62.41	68.97	67.80	65.03	74.08
XLM-R$_{base}$	71.52	74.96	64.75	74.86	67.46	67.35	69.49	65.56	70.48	72.57	66.33	72.54
XLM-R$_{large}$	80.06	81.38	78.00	80.80	74.97	78.96	77.82	68.14	78.75	80.60	77.94	77.72
Fine-tuning LLMs												
Gemma	**83.99**	84.77	82.33	**84.87**	**79.52**	81.71	**81.96**	**74.88**	**82.85**	83.75	**82.21**	**82.59**
Mistral	83.62	85.26	**83.01**	82.60	77.35	**82.99**	78.11	70.94	81.89	84.52	81.41	79.75
Llama2	38.99	38.77	33.62	44.59	38.05	45.02	33.09	36.04	38.81	40.73	33.45	42.27
Llama3	83.45	**85.88**	80.64	83.82	75.02	82.01	77.51	65.55	81.18	**84.59**	79.65	79.29
Prompting LLMs												
Gemini	73.96	80.85	71.58	69.46	75.33	80.55	72.70	72.75	69.96	81.46	69.29	59.13
Gemma	49.53	53.33	54.16	41.09	52.08	55.67	56.19	46.55	49.76	61.26	52.31	35.71
Mistral	51.54	68.79	53.38	32.45	53.97	68.20	53.01	40.69	49.99	68.06	50.14	31.78
Llama2	36.12	65.43	11.95	30.99	43.58	64.08	30.83	35.83	33.16	67.14	19.68	22.66
Llama3	48.65	61.16	50.41	34.37	52.31	55.31	59.56	42.06	43.71	48.21	46.25	36.67

Table 4: Performance comparison of language models across Single and Multiple evidence scenarios.

Moreover, the frequent errors associated with Complex Inferential Chains expose the limitations of the model in synthesizing and reasoning across diverse informational inputs. The adoption of memory networks and knowledge graphs could markedly improve its capacity to process and link extended data sequences, thereby enhancing its reasoning and inference capabilities (Kim et al. 2023; Pan et al. 2023).

4.6 Human Performance

Table 5 presents an evaluation of fine-tuned models, offering crucial insights into their varied performances in the Support, Refute, and NEI compared to human performance. Models such as Gemma and Llama3 demonstrate strong capabilities in the Support and NEI categories, indicating their robustness in handling both direct and ambiguous information. However, their performance declines in the Refute category, highlighting a critical gap in the ability of AI to effectively process and analyze contradictory information.

Model	F1 score	Support	Refute	NEI
Fine-tuning PLMs				
PhoBERT$_{base}$	71.29	75.19	63.89	74.80
PhoBERT$_{large}$	73.08	79.70	62.30	77.24
ViBERT	55.66	68.70	48.28	50.00
mBERT	66.94	71.79	61.84	67.18
XLM-R$_{base}$	66.33	71.64	64.97	62.39
XLM-R$_{large}$	74.95	76.47	73.02	75.36
Fine-tuning LLMs				
Gemma	83.95	91.73	77.52	82.61
Mistral	66.61	77.46	62.69	59.68
Llama2	46.10	50.45	40.94	46.91
Llama3	84.24	91.97	77.05	83.69
Human Evaluating				
Human	**84.93**	**81.25**	**80.95**	**82.38**

Table 5: Evaluation results of human performance compared to the models on the test set of 200 samples. Models that outperform human evaluators are marked in gray.

This pattern is not isolated but is evident across various models, suggesting that current AI architectures and training paradigms may lack the sophisticated reasoning required to handle complex linguistic challenges that humans manage more adeptly. The comparative underperformance of AI in the Refute category underscores the need for integrating deeper contextual understanding and advanced reasoning mechanisms into AI systems to better mimic human cognitive abilities in processing contradictions and complex arguments.

5 Conclusion & Future Work

The development of the ViFactCheck dataset marks a transformative advancement in fact-checking for Vietnamese. This dataset comprises 7,232 entries across 12 topics, providing a substantial resource to assess various SOTA baseline models. Our work demonstrates the potential of using advanced language models, fine-tuned on this dataset, to achieve high levels of accuracy, as evidenced by a macro F1 score of 89.90%. This validates the efficacy of our dataset and methodologies in a real-world context, setting a new benchmark for fact-checking performance in low-resource languages. The challenges identified through our in-depth analysis, such as semantic ambiguity and evidence retrieval failures, not only underscore the complexity of fact-checking in such environments but also pave the way for targeted improvements.

Future research will focus on addressing the identified challenges to further enhance model performance. Efforts will include refining semantic understanding and evidence retrieval capabilities to handle ambiguous and complex datasets more effectively (Wang et al. 2022; Wu et al. 2023). In addition, we plan to develop methods to mitigate inference hallucinations and improve reasoning across complex inferential chains (Kim et al. 2023; Pan et al. 2023). Expanding the dataset to incorporate a wider range of misinformation types and correcting labeling errors will also be crucial (Gupta and Srikumar 2021; Augenstein et al. 2019).

	Đơn bằng chứng				Đa bằng chứng				Tổng thể			
	F1 trung bình	Hỗ trợ	Bác bỏ	NEI	F1 trung bình	Hỗ trợ	Bác bỏ	NEI	F1 trung bình	Hỗ trợ	Bác bỏ	NEI
Tinh chỉnh các PLM												
PhoBERT$_{base}$	69.79	71.04	65.53	72.80	64.92	66.89	67.10	60.77	68.47	69.75	69.75	69.75
PhoBERT$_{large}$	75.01	76.27	70.81	77.95	62.72	64.44	67.12	56.58	71.47	72.64	69.59	72.18
ViBERT	56.42	61.38	46.31	61.59	58.11	63.64	56.23	54.46	57.16	62.08	49.57	59.81
mBERT	71.92	70.45	67.17	78.13	61.72	62.19	60.57	62.41	68.97	67.80	65.03	74.08
XLM-R$_{base}$	71.52	74.96	64.75	74.86	67.46	67.35	69.49	65.56	70.48	72.57	66.33	72.54
XLM-R$_{large}$	80.06	81.38	78.00	80.80	74.97	78.96	77.82	68.14	78.75	80.60	77.94	77.72
Tinh chỉnh LLMs												
Gemma	**83.99**	84.77	82.33	**84.87**	**79.52**	81.71	**81.96**	**74.88**	**82.85**	83.75	**82.21**	**82.59**
Gió Mistral	83.62	85.26	**83.01**	82.60	77.35	**82.99**	78.11	70.94	81.89	84.52	81.41	79.75
Llama2	38.99	38.77	33.62	44.59	38.05	45.02	33.09	36.04	38.81	40.73	33.45	42.27
Llama3	83.45	**85.88**	80.64	83.82	75.02	82.01	77.51	65.55	81.18	**84.59**	79.65	79.29
Gợi ý cho LLM												
Song Tử	73.96	80.85	71.58	69.46	75.33	80.55	72.70	72.75	69.96	81.46	69.29	59.13
Gemma	49.53	53.33	54.16	41.09	52.08	55.67	56.19	46.55	49.76	61.26	52.31	35.71
Gió Mistral	51.54	68.79	53.38	32.45	53.97	68.20	53.01	40.69	49.99	68.06	50.14	31.78
Llama2	36.12	65.43	11.95	30.99	43.58	64.08	30.83	35.83	33.16	67.14	19.68	22.66
Llama3	48.65	61.16	50.41	34.37	52.31	55.31	59.56	42.06	43.71	48.21	46.25	36.67

Tabl Hình 4: So sánh hiệu suất của các mô hình ngôn ngữ trong bối cảnh bằng chứng đơn và nhiều s.

Hơn nữa, những lỗi thường xuyên liên quan đến Chuỗi Suy Luận Phức Tạp đã phơi bày những hạn chế của mô hình trong việc tổng hợp và suy luận trên các thông tin đầu vào đa dạng. Việc áp dụng các mạng bộ nhớ và đồ thị tri thức có thể cải thiện đáng kể khả năng xử lý và liên kết chuỗi dữ liệu mở rộng của nó, từ đó nâng cao khả năng suy luận và suy diễn của nó (Kim et al. 2023; Pan et al. 2023).

4.6 Hiệu suất con người

Bảng 5 trình bày đánh giá các mô hình được tinh chỉnh, cung cấp những thông tin quan trọng về hiệu suất khác nhau của chúng trong các mục Hỗ trợ, Phủ nhận và NEI so với hiệu suất của con người. Các mô hình như Gemma và Llama3 thể hiện khả năng mạnh mẽ trong các mục Hỗ trợ và NEI, cho thấy sự vững chắc c ủa chúng trong việc xử lý cả thông tin trực tiếp và mơ hồ. Tuy nhiên, hiệu suất của chúng giảm ở mục Phủ nhận, làm nổi bật một khoảng trống quan trọng trong khả năng của AI xử lý và phân tích thông tin mâu thuẫn một cách hiệu quả.

Mô hình	Điểm F1	Hỗ trợ	Bác bỏ	NEI
Tinh chỉnh các PLM				
PhoBERT$_{base}$	71.29	75.19	63.89	74.80
PhoBERT$_{large}$	73.08	79.70	62.30	77.24
ViBERT	55.66	68.70	48.28	50.00
mBERT	66.94	71.79	61.84	67.18
XLM-R$_{base}$	66.33	71.64	64.97	62.39
XLM-R$_{large}$	74.95	76.47	73.02	75.36
Tinh chỉnh LLMs				
Gemma	83.95	91.73	77.52	82.61
Gió Mistral	66.61	77.46	62.69	59.68
Llama2	46.10	50.45	40.94	46.91
Llama3	84.24	91.97	77.05	83.69
Đang đánh giá bởi con người				
Con người	**84.93**	**81.25**	**80.95**	**82.38**

Bảng 5: Kết quả đánh giá hiệu suất của con người được so sánh đối với các mô hình trên tập kiểm tra gồm 200 mẫu. Các mô hình mà những đánh giá vượt trội hơn so với con người được đánh dấu bằng màu xám.

Mô hình này không phải là hiện tượng riêng lẻ mà xuất hiện ở nhiều mô hình khác nhau, gợi ý rằng kiến trúc AI hiện tại và các phương pháp huấn luyện có thể thiếu khả năng lý luận tinh vi cần thiết để xử lý những thách thức ngôn ngữ phức tạp mà con người quản lý một cách thành thạo hơn. Hiệu suất tương đối ké m của AI trong danh mục Phản bác nhấn mạnh nhu cầu tích hợp sự hiểu biết bối cảnh sâu hơn và các cơ chế lý luận tiên tiến vào các hệ thống AI để mô phỏng tốt hơn khả năng nhận thức của con người trong việc xử lý các mâu thuẫn và lập luận phức tạp.

5 Kết luận & Công việc Tương lai

Việc phát triển bộ dữ liệu ViFactCheck đánh dấu một bước tiến mang tính chuyển đổi trong việc kiểm chứng thông tin cho tiếng Việt. Bộ dữ liệu này bao gồm 7.232 mục trên 12 chủ đề, cung cấp một nguồn tài nguyên đáng kể để đánh giá các mô hình chuẩn SOTA khác nhau. Công trình của chúng tôi cho thấy tiềm năng của việc sử dụng các mô hình ngôn ngữ tiên tiến, tinh chỉnh trên bộ dữ liệu này, để đạt được mức độ chính xác cao, được chứng minh bằng điểm F1 macro là 89,90%. Điều này xác nhận hiệu quả của bộ dữ liệu và phương pháp của chúng tôi trong bối cảnh thực tế, thiết lập một tiêu chuẩn mới cho hiệu suất kiểm chứng thông tin trong các ngôn ngữ ít tài nguyên. Những thách thức được xác định thông qua phân tích chuyên sâu của chúng tôi, chẳng hạn như sự mơ hồ về ngữ nghĩa và thất bại trong truy xuất bằng chứng, không chỉ nhấn mạnh độ phức tạp của việc kiểm chứng thông tin trong những môi trường như vậy mà còn mở đường cho những cải tiến có mục tiêu.

Nghiên cứu trong tương lai sẽ tập trung vào việc giải quyết các thách thức đã được xác định để nâng cao hiệu suất của mô hình. Các nỗ lực sẽ bao gồm việc hoàn thiện khả năng hiểu ngữ nghĩa và truy xuất bằng chứng để xử lý các bộ dữ liệu mơ hồ và phức tạp hiệu quả hơn (Wang et al. 2022; Wu et al. 2023). Ngoài ra, chúng tôi dự định phát triển các phương pháp để giảm thiểu hiện tượng tạo thông tin sai lệch trong suy luận và cải thiện khả năng lý luận qua các chuỗi suy diễn phức tạp (Kim et al. 2023; Pan et al. 2023). Mở rộng bộ dữ liệu để bao gồm nhiều loại thông tin sai lệch hơn và sửa lỗi gán nhãn cũng sẽ rất quan trọng (Gupta và Srikumar 2021; Augenstein et al. 2019).

Acknowledgments

This research was supported by The VNUHCM-University of Information Technology's Scientific Research Support Fund of the VNUHCM University of Information Technology.

References

Aly, R.; Guo, Z.; Schlichtkrull, M.; Thorne, J.; Vlachos, A.; Christodoulopoulos, C.; Cocarascu, O.; and Mittal, A. 2021. FEVEROUS: Fact Extraction and VERification Over Unstructured and Structured information. In Vanschoren, J.; and Yeung, S., eds., *Proceedings of the Neural Information Processing Systems Track on Datasets and Benchmarks*, volume 1. Curran.

Augenstein, I.; Lioma, C.; Wang, D.; Chaves Lima, L.; Hansen, C.; Hansen, C.; and Simonsen, J. G. 2019. MultiFC: A Real-World Multi-Domain Dataset for Evidence-Based Fact Checking of Claims. In Inui, K.; Jiang, J.; Ng, V.; and Wan, X., eds., *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, 4685–4697. Hong Kong, China: Association for Computational Linguistics.

Bui, T. V.; Tran, T. O.; and Le-Hong, P. 2020. Improving Sequence Tagging for Vietnamese Text using Transformer-based Neural Models. In Nguyen, M. L.; Luong, M. C.; and Song, S., eds., *Proceedings of the 34th Pacific Asia Conference on Language, Information and Computation*, 13–20. Hanoi, Vietnam: Association for Computational Linguistics.

Conneau, A.; Khandelwal, K.; Goyal, N.; Chaudhary, V.; Wenzek, G.; Guzmán, F.; Grave, E.; Ott, M.; Zettlemoyer, L.; and Stoyanov, V. 2020. Unsupervised Cross-lingual Representation Learning at Scale. In Jurafsky, D.; Chai, J.; Schluter, N.; and Tetreault, J., eds., *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, 8440–8451. Online: Association for Computational Linguistics.

Devlin, J.; Chang, M.-W.; Lee, K.; and Toutanova, K. 2019. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*, 4171–4186. Minneapolis, Minnesota: Association for Computational Linguistics.

Duong, H. T.; Ho, V. H.; and Do, P. 2023. Fact-checking Vietnamese Information Using Knowledge Graph, Datalog, and KG-BERT. *ACM Transactions on Asian and Low-Resource Language Information Processing*, 22(10): 1–23.

Fleiss, J. L. 1971. Measuring nominal scale agreement among many raters. *Psychological bulletin*, 76(5): 378.

Gupta, A.; and Srikumar, V. 2021. X-Fact: A New Benchmark Dataset for Multilingual Fact Checking. In *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 2: Short Papers)*, 675–682. Online: Association for Computational Linguistics.

Hu, X.; Guo, Z.; Wu, G.; Liu, A.; Wen, L.; and Yu, P. 2022. CHEF: A Pilot Chinese Dataset for Evidence-Based Fact-Checking. In *Proceedings of the 2022 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, 3362–3376. Seattle, United States: Association for Computational Linguistics.

Huang, K.-H.; Chan, H. P.; and Ji, H. 2023. Zero-shot Faithful Factual Error Correction. In Rogers, A.; Boyd-Graber, J.; and Okazaki, N., eds., *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 5660–5676. Toronto, Canada: Association for Computational Linguistics.

Jiang, A. Q.; Sablayrolles, A.; Mensch, A.; Bamford, C.; Chaplot, D. S.; Casas, D. d. l.; Bressand, F.; Lengyel, G.; Lample, G.; Saulnier, L.; et al. 2023. Mistral 7B. *arXiv preprint arXiv:2310.06825*.

Khouja, J. 2020. Stance Prediction and Claim Verification: An Arabic Perspective. In Christodoulopoulos, C.; Thorne, J.; Vlachos, A.; Cocarascu, O.; and Mittal, A., eds., *Proceedings of the Third Workshop on Fact Extraction and VERification (FEVER)*, 8–17. Online: Association for Computational Linguistics.

Kim, J.; Park, S.; Kwon, Y.; Jo, Y.; Thorne, J.; and Choi, E. 2023. FactKG: Fact Verification via Reasoning on Knowledge Graphs. In Rogers, A.; Boyd-Graber, J.; and Okazaki, N., eds., *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 16190–16206. Toronto, Canada: Association for Computational Linguistics.

Lazer, D. M.; Baum, M. A.; Benkler, Y.; Berinsky, A. J.; Greenhill, K. M.; Menczer, F.; Metzger, M. J.; Nyhan, B.; Pennycook, G.; Rothschild, D.; et al. 2018. The science of fake news. *Science*, 359(6380): 1094–1096.

Le, H. T.; To, L. T.; Nguyen, M. T.; and Van Nguyen, K. 2024. ViWikiFC: Fact-Checking for Vietnamese Wikipedia-Based Textual Knowledge Source. *arXiv preprint arXiv:2405.07615*.

Liu, Y.; Ott, M.; Goyal, N.; Du, J.; Joshi, M.; Chen, D.; Levy, O.; Lewis, M.; Zettlemoyer, L.; and Stoyanov, V. 2019. RoBERTa: A Robustly Optimized BERT Pretraining Approach. arXiv:1907.11692.

Liu, Z.; Xiong, C.; Sun, M.; and Liu, Z. 2020. Fine-grained Fact Verification with Kernel Graph Attention Network. In Jurafsky, D.; Chai, J.; Schluter, N.; and Tetreault, J., eds., *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, 7342–7351. Online: Association for Computational Linguistics.

Loshchilov, I.; and Hutter, F. 2019. Decoupled Weight Decay Regularization. In *7th International Conference on Learning Representations, ICLR 2019, New Orleans, LA, USA, May 6-9, 2019*. OpenReview.net.

McCoy, T.; Pavlick, E.; and Linzen, T. 2019. Right for the Wrong Reasons: Diagnosing Syntactic Heuristics in Natural Language Inference. In Korhonen, A.; Traum, D.; and Màrquez, L., eds., *Proceedings of the 57th Annual Meeting of*

Lời cảm ơn

Nghiên cứu này được hỗ trợ bởi Quỹ Hỗ trợ Nghiên cứu Khoa học của Trường Đại học Công nghệ Thông tin, Đại học Quốc gia TP.HCM.

Tài liệu tham khảo

Aly, R.; Guo, Z.; Schlichtkrull, M.; Thorne, J.; Vlachos, A.; Christodoulopoulos, C.; Cocarascu, O.; và Mittal, A. 2021. FEVEROUS: Trích xuất và Xác minh Thông tin từ dữ liệu Phi cấu trúc và Cấu trúc. Trong Vanschoren, J.; và Yeung, S., biên tập, Kỷ yếu của Hội nghị Hệ thống Thông tin Thần kinh về Các bộ dữ liệu và Chuẩn đo lường, tập 1. Curran.

Augenstein, I.; Lioma, C.; Wang, D.; Chaves Lima, L.; Hansen, C.; Hansen, C.; và Simonsen, J. G. 2019. MultiFC: Một Bộ Dữ liệu Đa Miền Thực Tế cho Kiểm Tra Sự Thật Dựa trên Bằng Chứng của Các Yêu Cầu. Trong Inui, K.; Jiang, J.; Ng, V.; và Wan, X., chủ biên, Kỷ yếu Hội nghị năm 2019 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên và Hội nghị Liên hợp Quốc tế lần thứ 9 về Xử lý Ngôn ngữ Tự nhiên (EMNLP-IJCNLP), 4685–4697. Hồng Kông, Trung Quốc: Hiệp hội Ngôn ngữ Học Máy Tính.

Bùi, T. V.; Trần, T. O.; và Lê-Hồng, P. 2020. Cải thiện đánh dấu chuỗi cho văn bản tiếng Việt sử dụng mô hình thần kinh dựa trên Transformer. Trong Nguyễn, M. L.; Lương, M. C.; và Song, S., biên tập, Kỷ yếu Hội nghị Châu Á Thái Bình Dương lần thứ 34 về Ngôn ngữ, Thông tin và Tính toán, 13–20. Hà Nội, Việt Nam: Hiệp hội Ngôn ngữ Học Máy.

Conneau, A.; Khandelwal, K.; Goyal, N.; Chaudhary, V.; Wenzek, G.; Guzmán, F.; Grave, E.; Ott, M.; Zettlemoyer, L.; và Stoyanov, V. 2020. Học Biểu Diễn Liên Ngôn Ngữ Không Giám Sát ở Quy Mô Lớn. Trong Jurafsky, D.; Chai, J.; Schluter, N.; và Tetreault, J., biên tập, Kỷ yếu Hội nghị thường niên lần thứ 58 của Hiệp hội Ngôn ngữ học Tính toán, 8440–8451. Trực tuyến: Hiệp hội Ngôn ngữ học Tính toán.

Devlin, J.; Chang, M.-W.; Lee, K.; và Toutanova, K. 2019. BERT: Tiền huấn luyện các Transformer Hai Chiều Sâu cho Hiểu Ngôn ngữ. Trong Kỷ yếu Hội nghị 2019 của Chi hội Bắc Mỹ thuộc Hiệp hội Ngôn ngữ học Máy tính: Công nghệ Ngôn ngữ Con người, Tập 1 (Bài báo Dài và Ngắn), 4171–4186. Minneapolis, Minnesota: Hiệp hội Ngôn ngữ học Máy tính.

Dương, H. T.; Hồ, V. H.; và Đỗ, P. 2023. Kiểm chứng thông tin tiếng Việt sử dụng Đồ thị tri thức, Datalog, và KG-BERT. ACM Transactions on Asian and Low-Resource Language Information Processing, 22(10): 1–23.

Fleiss, J. L. 1971. Đo lường sự đồng thuận trên thang đo danh nghĩa giữa nhiều người đánh giá. Tạp chí Tâm lý học, 76(5): 378.

Gupta, A.; và Srikumar, V. 2021. X-Fact: Bộ dữ liệu chuẩn mới cho việc kiểm chứng thông tin đa ngôn ngữ. Trong Kỷ yếu Hội nghị Thường niên lần thứ 59 của Hiệp hội Ngôn ngữ học Máy tính và Hội nghị Liên hợp Quốc tế lần thứ 11 về Xử lý Ngôn ngữ Tự nhiên (Tập 2: Bài báo ngắn), 675–682. Trực tuyến: Hiệp hội Ngôn ngữ học Máy tính.

Hu, X.; Guo, Z.; Wu, G.; Liu, A.; Wen, L.; và Yu, P. 2022. CHEF: Một bộ dữ liệu thí điểm của Trung Quốc cho kiểm tra sự thật dựa trên bằng chứng. Trong Kỷ yếu Hội nghị 2022 của Chi nhánh Bắc Mỹ của Hiệp hội Ngôn ngữ Học Máy Tính: Công nghệ Ngôn ngữ Con người, 3362–3376. Seattle, Hoa Kỳ: Hiệp hội Ngôn ngữ Học Máy Tính.

Huang, K.-H.; Chan, H. P.; và Ji, H. 2023. Sửa lỗi thực tế trung thực không cần huấn luyện trước. Trong Rogers, A.; Boyd-Graber, J.; và Okazaki, N., biên tập, Kỷ yếu Hội nghị thường niên lần thứ 61 của Hiệp hội Ngôn ngữ học Máy tính (Tập 1: Bài báo dài), 5660–5676. Toronto, Canada: Hiệp hội Ngôn ngữ học Máy tính.

Jiang, A. Q.; Sablayrolles, A.; Mensch, A.; Bamford, C.; Chaplot, D. S.; Casas, D. d. l.; Bressand, F.; Lengyel, G.; Lample, G.; Saulnier, L.; et al. 2023. Mistral 7B. arXiv preprint arXiv:2310.06825. Khouja, J. 2020. Dự đoán lập trường và xác minh tuyên bố: Góc nhìn tiếng Ả Rập. Trong Christodoulopoulos, C.; Thorne, J.; Vlachos, A.; Cocarascu, O.; và Mittal, A., biên tập, Kỷ yếu hội thảo thứ ba về Trích xuất và Xác minh Sự kiện (FEVER), 8–17. Trực tuyến: Hiệp hội Ngôn ngữ học Máy tính. Kim, J.; Park, S.; Kwon, Y.; Jo, Y.; Thorne, J.; và Choi, E. 2023. FactKG: Xác minh sự kiện thông qua lý luận trên đồ thị tri thức. Trong Rogers, A.; Boyd-Graber, J.; và Okazaki, N., biên tập, Kỷ yếu Hội nghị thường niên lần thứ 61 của Hiệp hội Ngôn ngữ học Máy tính (Tập 1: Bài báo dài), 16190–16206. Toronto, Canada: Hiệp hội Ngôn ngữ học Máy tính. Lazer, D. M.; Baum, M. A.; Benkler, Y.; Berinsky, A. J.; Greenhill, K. M.; Menczer, F.; Metzger, M. J.; Nyhan, B.; P

the Association for Computational Linguistics, 3428–3448. Florence, Italy: Association for Computational Linguistics.

McHugh, M. 2012. Interrater reliability: the kappa statistic. *Biochem Med (Zagreb)*, 22(3): 276–282.

Nguyen, D. Q.; and Tuan Nguyen, A. 2020. PhoBERT: Pre-trained language models for Vietnamese. In *Findings of the Association for Computational Linguistics: EMNLP 2020*, 1037–1042. Association for Computational Linguistics.

Nie, Y.; Chen, H.; and Bansal, M. 2019. Combining fact extraction and verification with neural semantic matching networks. In *Proceedings of the AAAI conference on artificial intelligence*, volume 33, 6859–6866.

Nørregaard, J.; and Derczynski, L. 2021. DanFEVER: claim verification dataset for Danish. In Dobnik, S.; and Øvrelid, L., eds., *Proceedings of the 23rd Nordic Conference on Computational Linguistics (NoDaLiDa)*, 422–428. Reykjavik, Iceland (Online): Linköping University Electronic Press, Sweden.

Pan, L.; Wu, X.; Lu, X.; Luu, A. T.; Wang, W. Y.; Kan, M.-Y.; and Nakov, P. 2023. Fact-Checking Complex Claims with Program-Guided Reasoning. In Rogers, A.; Boyd-Graber, J.; and Okazaki, N., eds., *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 6981–7004. Toronto, Canada: Association for Computational Linguistics.

Reid, M.; Savinov, N.; Teplyashin, D.; Lepikhin, D.; Lillicrap, T.; Alayrac, J.-b.; Soricut, R.; Lazaridou, A.; Firat, O.; Schrittwieser, J.; et al. 2024. Gemini 1.5: Unlocking multimodal understanding across millions of tokens of context. *arXiv preprint arXiv:2403.05530*.

Reimers, N.; and Gurevych, I. 2019. Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. In Inui, K.; Jiang, J.; Ng, V.; and Wan, X., eds., *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, 3982–3992. Hong Kong, China: Association for Computational Linguistics.

Robertson, S.; Zaragoza, H.; et al. 2009. The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends® in Information Retrieval*, 3(4): 333–389.

Schuster, T.; Fisch, A.; and Barzilay, R. 2021. Get Your Vitamin C! Robust Fact Verification with Contrastive Evidence. In *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, 624–643. Online: Association for Computational Linguistics.

Soleimani, A.; Monz, C.; and Worring, M. 2020. BERT for Evidence Retrieval and Claim Verification. In Jose, J. M.; Yilmaz, E.; Magalhães, J.; Castells, P.; Ferro, N.; Silva, M. J.; and Martins, F., eds., *Advances in Information Retrieval*, 359–366. Cham: Springer International Publishing. ISBN 978-3-030-45442-5.

Team, G.; Mesnard, T.; Hardin, C.; Dadashi, R.; Bhupatiraju, S.; Pathak, S.; Sifre, L.; Rivière, M.; Kale, M. S.; Love, J.; et al. 2024. Gemma: Open models based on gemini research and technology. *arXiv preprint arXiv:2403.08295*.

Thorne, J.; Vlachos, A.; Christodoulopoulos, C.; and Mittal, A. 2018. FEVER: a Large-scale Dataset for Fact Extraction and VERification. In Walker, M.; Ji, H.; and Stent, A., eds., *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long Papers)*, 809–819. New Orleans, Louisiana: Association for Computational Linguistics.

Touvron, H.; Lavril, T.; Izacard, G.; Martinet, X.; Lachaux, M.-A.; Lacroix, T.; Rozière, B.; Goyal, N.; Hambro, E.; Azhar, F.; et al. 2023. Llama: Open and efficient foundation language models. *arXiv preprint arXiv:2302.13971*.

Vlachos, A.; and Riedel, S. 2014. Fact Checking: Task definition and dataset construction. In Danescu-Niculescu-Mizil, C.; Eisenstein, J.; McKeown, K.; and Smith, N. A., eds., *Proceedings of the ACL 2014 Workshop on Language Technologies and Computational Social Science*, 18–22. Baltimore, MD, USA: Association for Computational Linguistics.

Vu, T.; Nguyen, D. Q.; Nguyen, D. Q.; Dras, M.; and Johnson, M. 2018. VnCoreNLP: A Vietnamese Natural Language Processing Toolkit. In Liu, Y.; Paek, T.; and Patwardhan, M., eds., *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Demonstrations*, 56–60. New Orleans, Louisiana: Association for Computational Linguistics.

Wang, W. Y. 2017. "Liar, Liar Pants on Fire": A New Benchmark Dataset for Fake News Detection. In *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers)*, 422–426. Vancouver, Canada: Association for Computational Linguistics.

Wang, Y.; Li, Y.; Wang, Y.; Mi, F.; Zhou, P.; Wang, X.; Liu, J.; Jiang, X.; and Liu, Q. 2022. Pan More Gold from the Sand: Refining Open-domain Dialogue Training with Noisy Self-Retrieval Generation. In Calzolari, N.; Huang, C.-R.; Kim, H.; Pustejovsky, J.; Wanner, L.; Choi, K.-S.; Ryu, P.-M.; Chen, H.-H.; Donatelli, L.; Ji, H.; Kurohashi, S.; Paggio, P.; Xue, N.; Kim, S.; Hahm, Y.; He, Z.; Lee, T. K.; Santus, E.; Bond, F.; and Na, S.-H., eds., *Proceedings of the 29th International Conference on Computational Linguistics*, 636–647. Gyeongju, Republic of Korea: International Committee on Computational Linguistics.

Wu, S.; Xin, C.; Lin, H.; Han, X.; Liu, C.; Chen, J.; Yang, F.; Wan, G.; and Sun, L. 2023. Ambiguous Learning from Retrieval: Towards Zero-shot Semantic Parsing. In Rogers, A.; Boyd-Graber, J.; and Okazaki, N., eds., *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 14081–14094. Toronto, Canada: Association for Computational Linguistics.

Zhong, W.; Xu, J.; Tang, D.; Xu, Z.; Duan, N.; Zhou, M.; Wang, J.; and Yin, J. 2020. Reasoning Over Semantic-Level Graph for Fact Checking. In Jurafsky, D.; Chai, J.; Schluter, N.; and Tetreault, J., eds., *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, 6170–6180. Association for Computational Linguistics.

Hiệp hội Ngôn ngữ học Máy tính, 3428–3448. Florence, Ý: Hiệp hội Ngôn ngữ học Máy tính. McHugh, M. 2012. Độ tin cậy giữa các đánh giá viên: thống kê kappa. Biochem Med (Zagreb), 22(3): 276–282. Nguyen, D. Q.; và Tuan Nguyen, A. 2020. PhoBERT: Mô hình ngôn ngữ được tiền huấn luyện cho tiếng Việt. Trong Kết quả của Hiệp hội Ngôn ngữ học Máy tính: EMNLP 2020, 1037–1042. Hiệp hội Ngôn ngữ học Máy tính. Nie, Y.; Chen, H.; và Bansal, M. 2019. Kết hợp trích xuất sự thật và xác minh với các mạng khớp ngữ nghĩa thần kinh. Trong Kỷ yếu hội nghị AAAI về trí tuệ nhân tạo, tập 33, 6859–6866. Nørregaard, J.; và Derczynski, L. 2021. DanFEVER: tập dữ liệu xác minh tuyên bố cho tiếng Đan Mạch. Trong Dobnik, S.; và Øvrelid, L., biên tập, Kỷ yếu Hội nghị Ngôn ngữ học Máy tính Bắc Âu lần thứ 23 (NoDaLiDa), 422–428. Reykjavik, Iceland (Trực tuyến): Link¨oping University Electronic Press, Thụy Điển. Pan, L.; Wu, X.; Lu, X.; Luu, A. T.; Wang,

Thorne, J.; Vlachos, A.; Christodoulopoulos, C.; và Mittal, A. 2018. FEVER: một Bộ Dữ liệu Quy mô Lớn cho Trích xuất và Xác minh Thực tế. Trong Walker, M.; Ji, H.; và Stent, A., biên tập, Kỷ yếu Hội nghị 2018 của Chương Bắc Mỹ Hiệp hội Ngôn ngữ học Máy tính: Công nghệ Ngôn ngữ Con người, Tập 1 (Bài báo Dài), 809–819. New Orleans, Louisiana: Hiệp hội Ngôn ngữ học Máy tính.

Touvron, H.; Lavril, T.; Izacard, G.; Martinet, X.; Lachaux, M.-A.; Lacroix, T.; Rozière, B.; Goyal, N.; Hambro, E.; Azhar, F.; và cộng sự. 2023. Llama: Mô hình ngôn ngữ nền tảng mở và hiệu quả. arXiv preprint arXiv:2302.13971.

Vlachos, A.; và Riedel, S. 2014. Kiểm tra sự thật: Định nghĩa nhiệ m vụ và xây dựng bộ dữ liệu. Trong Danescu-Niculescu-Mizil, C.; Eisenstein, J.; McKeown, K.; và Smith, N. A., biên tập, Kỷ yếu Hội thảo ACL 2014 về Công nghệ Ngôn ngữ và Khoa học Xã hội Tính toán, 18–22. Baltimore, MD, Mỹ: Hiệp hội Ngôn ngữ Tính toán. Vu, T.; Nguyễn, D. Q.; Nguyễn, D. Q.; Dras, M.; và Johnson, M. 2018. VnCoreNLP: Bộ công cụ Xử lý Ngôn ngữ Tự nhiên tiếng Việt. Tro ng Liu, Y.; Paek, T.; và Patwardhan, M., biên tập, Kỷ yếu Hội nghị 2018 của Chương Bắc Mỹ thuộc Hiệp hội Ngôn ngữ Tính toán: Minh họa, 56–60. New Orleans, Louisiana: Hiệp hội Ngôn ngữ Tính toán. Wang, W. Y. 2017. "Liar, Liar Pants on Fire": Bộ dữ liệu chuẩn mới cho Phát hiện Tin giả. Trong Kỷ yếu Hội nghị thường niên lần thứ 55 của Hiệp hội Ngôn ngữ Tính toán (Tập 2: Bài báo ngắn), 422–426. Vancouver, Canada: Hiệp hội Ngôn ngữ Tính toán.

A Task Definition

Fact-checking can be defined as the task of automatically assessing the veracity of a given claim based on available evidence. This task typically involves two main steps: **1) Evidence Retrieval (Fact Extraction):** This step aims to find relevant evidence from a given corpus to support or refute the claim. **2) Claim Verification (Fact Verification):** This step determines the truthfulness of the claim based on the retrieved evidence.

The proposed system is designed to assign labels to the claims, categorizing them as follows:

- **Support:** The claim is confirmed to be correct according to the available evidence.
- **Refute:** The claim is determined to be inaccurate compared to the available evidence.
- **Not Enough Info (NEI):** The claim is not sufficiently supported by the evidence within the corresponding news, making it impossible to definitively verify or refute.

The goal of fact-checking systems is to assist human fact-checkers in their efforts to combat the spread of disinformation and false news. These systems provide automated tools that assess the credibility of claims in various sources, including news articles, social media, and political speeches.

B Data Collection Source

The data for this study was collected from reliable, government-licensed online newspaper websites in Vietnam, which boast significant visitor counts and provide up-to-date news. The sources included Bao Chinh Phu, VnExpress, Dan Tri, Nguoi Lao Dong, Tuoi Tre, Tin Tuc, Phap Luat HCM, Thanh Nien, and Tien Phong. To extract news articles from these online newspaper websites, we utilized two Python libraries, BeautifulSoup and Selenium. These libraries are well-known for their robust capabilities in extracting data from websites.

Website	Organization	URL
Bao Chinh Phu	Government of Vietnam	https://baochinhphu.vn
VnExpress	MOST Vietnam	https://vnexpress.net
Dan Tri	MOLISA Vietnam	https://dantri.com.vn
Nguoi Lao Dong	HCM City Committee	https://nld.com.vn
Tuoi Tre	HCM Communist Youth Union	https://tuoitre.vn
Tin Tuc	Vietnam News Agency	https://baotintuc.vn
Phap Luat HCM	HCM City People's Committee	https://plo.vn
Thanh Nien	Vietnam Youth Union	https://thanhnien.vn

Table 6: Details of the sources and organizations of the online news sites in the ViFactCheck dataset.

C Data Annotation Tool and Guideline

Data annotation tool During the annotation phases of the dataset, we utilized Label Studio, an open-source platform that provides an intuitive interface and supports various labeling tasks across different types of data. Our annotation interface is shown in Figure 6.

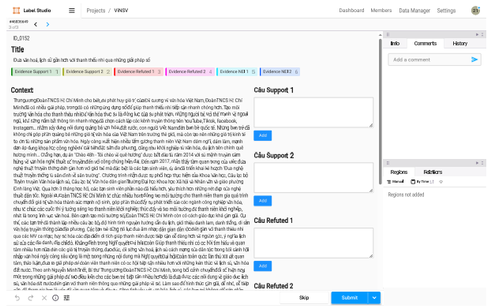


Figure 6: Label Studio UI for our annotation task.

Data annotation guideline Comprehensive guidelines were provided to the annotators to ensure a cohesive and systematic approach.

(1) The annotation process required the generation of six claim pairs for each article in the dataset, resulting in two pairs for each designated label: **Support, Refute, and NEI (Not Enough Information). (2)** For the **Support** and **Refute** labels, annotations were grounded in the intrinsic information and contextual evidence derived directly from the corresponding news articles. The **NEI** label required a more nuanced approach, involving the addition of external information and context, which could either align with or deviate from the truth. **(3)** The generated claims must adhere to certain rules: paraphrasing sentences from the article, inferring claims by combining multiple pieces of information, and meticulously avoiding spelling and abbreviation errors that could compromise the quality of the dataset. **(4)** To enrich the dataset with diverse perspectives and challenges, annotators were encouraged to leverage their broad vocabulary and skilled sentence-writing techniques, thereby introducing valuable nuances into the annotations.

D Human Recruitment

Annotation Recruitment In our study, we recruited seven university students as annotators, all native Vietnamese speakers aged 20 to 22, representing a diverse range of academic disciplines. These disciplines included social sciences, natural sciences, and Vietnamese studies. Their selection was based on exceptional linguistic skills, demonstrated by high scores in Vietnamese literature exams, and a deep familiarity with various media platforms, ensuring annotations that accurately reflect current linguistic trends.

To ensure the reliability and accuracy of our annotation process, we engaged two linguistic experts with a solid background in Vietnamese grammar and syntax. These experts, also native speakers, were tasked with developing the guidelines and continuously monitoring the annotation process. Their expertise is grounded in extensive academic achievements and a critical ability to evaluate news content across various media platforms, adding a significant layer of scientific rigor and depth to our data creation methodology.

Định nghĩa nhiệm vụ

Kiểm chứng sự thật có thể được định nghĩa là nhiệm vụ đánh giá tự động độ chính xác của một tuyên bố dựa trên các bằng chứng sẵn có. Nhiệm vụ này thường bao gồm hai bước chính: 1) Truy xuất bằng chứng (Trích xuất sự thật): Bước này nhằm tìm kiếm bằng chứng liên quan từ một tập hợp dữ liệu cho trước để hỗ trợ hoặc bác bỏ tuyên bố. 2) Xác minh tuyên bố (Kiểm chứng sự thật): Bước này xác định mức độ đúng sự thật của tuyên bố dựa trên các bằng chứng đã được truy xuất.

Hệ thống được đề xuất được thiết kế để gán nhãn cho các tuyên bố, phân loại chúng như sau:

• Hỗ trợ: Yêu cầu được xác nhận là đúng theo các bằng chứng hiện có.

• Phản bác: Yêu cầu này được xác định là không chính xác so với các bằng chứng có sẵn.

• Không đủ thông tin (NEI): Yêu cầu không được bằng chứng trong bản tin tương ứng hỗ trợ đầy đủ, khiến việc xác minh hoặc bác bỏ một cách chắc chắn là không thể.

Mục tiêu của các hệ thống kiểm tra sự thật là hỗ trợ các nhà kiểm tra sự thật con người trong nỗ lực của họ để chống lại sự lan truyền thông tin sai lệch và tin tức giả. Các hệ thống này cung cấp các công cụ tự động đánh giá độ tin cậy của các tuyên bố từ nhiều nguồn khác nhau, bao gồm bài báo, mạng xã hội và các bài phát biểu chính trị.

Nguồn Thu Thập Dữ Liệu B

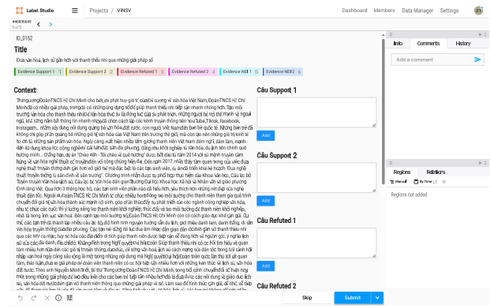
Dữ liệu cho nghiên cứu này được thu thập từ các trang web báo điện tử đáng tin cậy, được cấp phép bởi chính phủ tại Việt Nam, có lượng truy cập lớn và cung cấp tin tức cập nhật. Các nguồn bao gồm Báo Chính Phủ, VnExpress, Dân Trí, Người Lao Động, Tuổi Trẻ, Tin Tức, Pháp Luật TP.HCM, Thanh Niên và Tiền Phong. Để trích xuất các bài báo từ các trang web báo điện tử này, chúng tôi đã sử dụng hai thư viện Python, BeautifulSoup và Selenium. Các thư viện này nổi tiếng với khả năng mạnh mẽ trong việc trích xuất dữ liệu từ các trang web.

Trang web	Tổ chức	URL
Government Bao	Chính phủ Việt Nam	https://baochinhphu.vn
VnExpress	PHẦN LỚN Việt Nam	https://vnexpress.net
Dân Trí	Bộ Lao động - Thương binh và Xã hội Việt Nam	https://dantri.com.vn
Laborer	Ủy ban Thành phố Hồ Chí Minh	https://nld.com.vn
Tuổi Trẻ	Đoàn Thanh niên Cộng sản Hồ Chí Minh	https://tuoitre.vn
Tin Tức	Thông tấn xã Việt Nam	https://baotintuc.vn
HCM Law	Ủy ban Nhân dân Thành phố Hồ Chí Minh	https://plo.vn
Young Man	Đoàn Thanh niên Việt Nam	https://thanhnien.vn

Bảng 6: Chi tiết về các nguồn và tổ chức của các trang tin tức trực tuyến trong bộ dữ liệu ViFactCheck.

C Công cụ và Hướng dẫn Chú thích Dữ liệu

Công cụ chú thích dữ liệu Trong các giai đoạn chú thích của bộ dữ liệu, chúng tôi đã sử dụng Label Studio, một nền tảng mã nguồn mở cung cấp giao diện thân thiện và hỗ trợ các nhiệm vụ chú thích khác nhau trên các loại dữ liệu khác nhau. Giao diện chú thích của chúng tôi được hiển thị trong Hình 6.



Hình 6: Giao diện người dùng Label Studio cho bộ gán nhãn của chúng tôi sk.

Hướng dẫn chú thích dữ liệu: Các hướng dẫn toàn diện đã được cung cấp cho những người chú thích để đảm bảo một phương pháp tiếp cận thống nhất và có hệ thống:

(1) Quá trình chú thích yêu cầu tạo ra sáu cặp tuyên bố cho mỗi bài báo trong bộ dữ liệu, dẫn đến hai cặp cho mỗi nhãn được chỉ định: Hỗ trợ, Phủ nhận và NEI (Không đủ thông tin). (2) Đối với các nhãn Hỗ trợ và Phủ nhận, các chú thích được dựa trên thông tin nội tại và bằng chứng ngữ cảnh lấy trực tiếp từ các bài báo tương ứng. Nhãn NEI yêu cầu một phương pháp tinh vi hơn, liên quan đến việc bổ sung thông tin và ngữ cảnh bên ngoài, có thể phù hợp hoặc lệch so với sự thật. (3) Các tuyên bố được tạo ra phải tuân theo những quy tắc nhất định: diễn giải lại các câu từ bài báo, suy luận các tuyên bố bằng cách kết hợp nhiều thông tin khác nhau, và cẩn thận tránh các lỗi chính tả và viết tắt có thể làm giảm chất lượng của bộ dữ liệu. (4) Để làm phong phú bộ dữ liệu với các quan điểm và thách thức đa dạng, các nhà chú thích được khuyến khích tận dụng vốn từ vựng rộng lớn và kỹ năng viết câu điêu luyện của họ, từ đó int

Tuyển dụng nhân sự D

Tuyển dụng người chú thích Trong nghiên cứu của chúng tôi, chúng tôi đã tuyển bảy sinh viên đại học làm người chú thích, tất cả đều là người Việt bản xứ, trong độ tuổi từ 20 đến 22, đại diện cho nhiều ngành học khác nhau. Các ngành học này bao gồm khoa học xã hội, khoa học tự nhiên và nghiên cứu Việt Nam. Việc lựa chọn họ dựa trên kỹ năng ngôn ngữ xuất sắc, được chứng minh qua điểm số cao trong các kỳ thi văn học Việt Nam, và sự am hiểu sâu sắc về các nền tảng truyền thông khác nhau, đảm bảo các chú thích phản ánh chính xác các xu hướng ngôn ngữ hiện nay.

Để đảm bảo độ tin cậy và chính xác của quy trình chú thích của chúng tôi, chúng tôi đã thuê hai chuyên gia ngôn ngữ có nền tảng vững chắc về ngữ pháp và cú pháp tiếng Việt. Những chuyên gia này, đồng thời cũng là người bản ngữ, được giao nhiệm vụ phát triển các hướng dẫn và liên tục giám sát quá trình chú thích. Chuyên môn của họ dựa trên những thành tựu học thuật rộng l ớn và khả năng phân tích quan trọng để đánh giá nội dung tin t ức trên nhiều nền tảng truyền thông khác nhau, bổ sung một lớp độ chính xác và chiều sâu khoa học đáng kể cho phương pháp tạo dữ liệu của chúng tôi.

Context	TPO - Tổng Công ty Cảng Hàng không Việt Nam (ACV) vừa chính thức gia hạn thời gian mời thầu thêm 1 tháng, kéo dài thời gian thực hiện gói thầu thi công nhà ga sân bay Long Thành từ 33 tháng lên 39 tháng. Như vậy, "siêu sân bay" Long Thành sẽ chỉ có thể đưa vào khai thác từ năm 2026 thay vì mục tiêu năm 2025 như trước đó. Tin từ ACV cho hay, đơn vị chính thức điều chỉnh kế hoạch và hồ sơ mời thầu gói thầu thi công xây dựng và lắp đặt thiết bị nhà ga hành khách sân bay Long Thành giai đoạn 1 (do ACV làm chủ đầu tư). Cụ thể, thời gian mời thầu được gia hạn thêm 1 tháng, kéo dài tới sáng ngày 28/4, thay vì tới ngày 28/3 như trước đó. ... Gói thầu thi công nhà ga hành khách sân bay Long Thành trị giá hơn 35 nghìn tỷ đồng do ACV làm chủ đầu tư. Đây là gói thầu lớn nhất dự án sân bay Long Thành... (**English:** TPO - Vietnam Airport Corporation (ACV) has officially extended the bidding period by an additional month, prolonging the implementation time for the construction contract of the Long Thanh Airport passenger terminal from 33 to 39 months. Consequently, the "mega airport" Long Thanh will only be operational by 2026 instead of the previous target of 2025. According to ACV, the organization has formally adjusted the plan and tender documents for the construction and installation of the passenger terminal at Long Thanh Airport Phase 1 (with ACV as the main investor). Specifically, the bidding period has been extended by one month, now ending on the morning of April 28, instead of the previous deadline of March 28. ... The construction contract for Long Thanh Airport's passenger terminal, valued at over 35 trillion VND is being managed by ACV. This is the largest contract within the Long Thanh Airport project.)
Support	Việc nhà thầu thi công xây dựng và lắp đặt thiết bị nhà ga hành khách sân bay Long Thành giai đoạn 1 bị điều chỉnh, thời gian bị kéo dài tới sáng ngày 28/4 thay vì tới ngày 28/3 như dự kiến. **English:** *The construction and installation contract for the Long Thanh Airport Phase 1 passenger terminal has been adjusted, with the timeline extended to the morning of April 28 instead of the originally anticipated March 28.*
Refute	Tổng Công ty Cảng Hàng không Việt Nam (ACV) vừa gia hạn thời gian mời thầu thêm thời gian 2 tháng, tức "siêu sân bay" Long Thành sẽ chỉ có thể đưa vào sử dụng từ năm 2026 thay vì năm 2025 như dự kiến ban đầu. **English:** *Vietnam Airport Corporation (ACV) has recently extended the bidding period by an additional 2 months, meaning that the "mega airport" Long Thanh will only be operational by 2026 instead of the originally planned year 2025.*
NEI	Gói thầu lớn nhất dự án sân bay Long Thành là gói thầu thi công nhà ga hành khách với trị giá hơn 35 nghìn tỷ đồng, được tài trợ bởi công ty Hàn Quốc. **English:** *The largest contract within the Long Thanh Airport project is the construction of the passenger terminal, valued at over 35 trillion VND, and it is sponsored by a South Korean company.*

Table 7: Typical samples from the **ViFactCheck** dataset with three labels **Support**, **Refute**, and **NEI**. The highlighted words is the evidence of the claim.

Ngữ cảnh	TPO - Tổng Công ty Cảng Hàng không Việt Nam (ACV) vừa chính thức gia hạn thời gian mời thầu thêm 1 month, extend the implementation period of the Long Thanh airport terminal construction package from 33 months to 39 months. Thus, the Long Thanh 'super airport' will only be able to be put into operation from 2026 instead of the target year 2025 như trước đó. Tin từ ACV cho hay, đơn vị chính thức điều chỉnh kế hoạch và hồ sơ mời thầu gói thầu Construction and installation of equipment at Long Thanh Airport passenger terminal phase 1 (managed by ACV) investment). Specifically, the bidding period has been extended by 1 month, lasting until the morning of April 28, instead of until the day 28/3 như trước đó. ... Gói thầu thi công nhà ga hành khách sân bay Long Thành trị giá hơn 35 nghìn tỷ funded by ACV as the investor. This is the largest package of the Long Thanh airport project... (Tiếng Việt: TPO - Tổng công ty Cảng hàng không Việt Nam (ACV) chính thức gia hạn thời gian đấu thầu bởi một tháng bổ sung, kéo dài thời gian thực hiện hợp đồng xây dựng của Long Thành Nhà ga hành khách sân bay từ 33 đến 39 tháng. Do đó, "siêu sân bay" Long Thành chỉ hoạt động vào năm 2026 thay vì mục tiêu trước đó là năm 2025. Theo ACV, tổ chức này đã chính thức điều chỉnh kế hoạch và tài liệu đấu thầu cho việc xây dựng và lắp đặt cho hành khách nhà ga tại Sân bay Long Thành Giai đoạn 1 (với ACV là nhà đầu tư chính). Cụ thể, giai đoạn đấu thầu đã được gia hạn thêm một tháng, bây giờ kết thúc vào sáng ngày 28 tháng 4, thay vì hạn chót trước đó vào ngày 28 tháng 3. ... Hợp đồng xây dựng nhà ga hành khách của Sân bay Long Thành, có giá trị hơn 35 nghìn tỷ VND đang được ACV quản lý. Đây là hợp đồng lớn nhất tại Sân bay Long Thành dự án.)
Hỗ trợ	The contractor for construction and installation of equipment at Long Thanh Airport passenger terminal phase 1 was adjust, the period is extended until the morning of April 28 instead of March 28 as planned. *Hợp đồng xây dựng và lắp đặt cho nhà ga hành khách Giai đoạn 1 của Sân bay Long Thành đã được điều chỉnh, với thời gian kéo dài đến sáng ngày 28 tháng 4 thay vì dự kiến ban đầu Ngày 28 tháng 3.*
Bác bỏ	Vietnam Airport Corporation (ACV) has just extended the bidding invitation period by an additional 2 months, that is, the 'super airport' Long Thanh will only be able to be put into use from 2026 instead of 2025 as planned initially . *Tiếng Việt: Tổng công ty Cảng hàng không Việt Nam (ACV) gần đây đã gia hạn thời gian đấu thầu thêm 2 tháng, có nghĩa là "siêu cảng hàng không" Long Thành sẽ chỉ đi vào hoạt động vào năm 2026 thay vì ban đầu dự kiến vào năm 2025.*
NEI	The largest contract of the Long Thanh airport project is the passenger terminal construction package with a value of more than 35 nghìn tỷ đồng, được tài trợ bởi công ty Hàn Quốc. *Tiếng Việt: Hợp đồng lớn nhất trong dự án Sân bay Long Thành là xây dựng nhà ga hành khách ga, trị giá hơn 35 nghìn tỷ VND, và nó được tài trợ bởi một công ty Hàn Quốc.*

Bảng 7: Mẫu điển hình từ bộ dữ liệu ViFactCheck với ba nhãn Hỗ trợ, Phủ nhận và NEI. Các từ được đánh dấu là bằng chứng của tuyên bố.

Human Evaluation Recruitment To evaluate human performance in the fact-checking process, we engaged three native Vietnamese-speaking students who had no prior exposure to the task of fact-checking. They were tasked with annotating a representative subset consisting of 200 samples. Comprehensive instructions were provided to ensure their understanding of the task, including clarifications on the significance of each label and additional information to assist them in determining the appropriate labels for each sample. The final label for each claim was determined through a majority consensus among the assessors.

E Data Examples

The ViFactCheck dataset includes various examples of written claims, as illustrated in Table 7. To create a challenging and realistic context, annotators were tasked with generating claims based on multiple evidences, which are highlighted within the textual context provided. This approach not only enhances the complexity and challenge of the annotation task but also contributes significantly to the reliability and practical value of the dataset for fact-checking tasks in the Vietnamese language. By ensuring that claims are grounded in verifiable pieces of evidence, the dataset fosters a robust environment for training and evaluating language models specifically tailored to the nuances of fact verification.

F Human-Generated Rules

In the ViFactCheck datasets, annotators were encouraged to leverage their broad vocabulary and skilled sentence-writing techniques, thus introducing valuable nuances into the annotations. The basic rules for the use of the generation by annotators are summarized in Table 8.

	Rules	Ratio (%)
Support	Restructuring the evidences	73.68
	Eliminating or adding words	44.21
	Substituting numbers, time, or mathematical inferences	7.34
	Altering the word order in a sentence	8.42
Refute	Employing Negation	8.16
	Replacing Words with Antonyms	17.35
	Misrepresenting quantity	22.45
	Misrepresenting Temporal Logic	16.37
	Misinterpreting Entity Relationships	5.11
	Misjudging Event Dynamics	47.96
NEI	Inferring sentences with unspecified information	90.20
	Utilizing external knowledge	10.78

Table 8: Approaches and rules for generating claims by humans in the ViFactCheck dataset. Note that a claim could involve multiple rules

Annotators are required to follow guidelines to create diverse and challenging data. The distribution of data-generating rule usage for claims related to Support, Refute, and Not Enough Information (NEI) is shown in Figure 7. To understand how annotators behave in creating ViFactCheck, we analyzed the number of rules used to generate claims. We randomly selected 100 context-claim pairs for Support, Refute, and NEI categories.

The primary trend in this dataset reveals an obvious bias towards using 1-2 rules, reflecting a standardized annotation process. However, some annotators deviated from this trend, opting for four or more rules, demonstrating an awareness of the complexity and diversity of data. This underscores the importance of judiciously combining rules for reliable and accurate annotation.

The use of multiple rules presents challenges for language model development, introducing complexity into inference and decision-making processes dependent on rule combinations. However, it also offers an opportunity to improve more adaptable language models, ensuring greater accuracy in making inferences.

G Additional Dataset Analysis

Dataset basic statistic. The ViFactCheck dataset contains 7,232 samples divided into three subsets: training, development, and test with a ratio of 7:1:2. The basic statistics of the three subsets are shown in Table 9. We observed that the average length of a context in the dataset is approximately 700 words, with the longest context extending to 3,602 words. Such richness in context proves highly beneficial for models with large parameter sets, such as Gemma, as they can effectively capture the maximum features of the data. On average, each claim sentence contains about 36 words, with the longest reaching 165 words.

		Training	Development	Test
Context	Total samples	1035	496	758
	Avg length	693.2	670.2	690.5
	Max length	3602	2534	3602
	Min length	71	71	71
	Total vocab size	25,382	16,522	21,263
claim	Total samples	5062	723	1447
	Avg length	35.9	35.6	35.8
	Max length	165	145	135
	Min length	7	10	7
	Total vocab size	12,189	4,555	6,711

Table 9: Basic statistic of ViFactCheck dataset. The size and length of the vocab are computed at word level.

Topic Distribution Analysis The ViFactCheck dataset covers 12 popular topics frequently found in Vietnamese news, which are often subjected to misinformation. These topics, summarized in Figure 8, include “Headlines”, “World”, “Education”, and “Economics”, among others. “Headlines”, covering updates on social issues and events, appears most frequently, demonstrating a significant presence in the dataset. The other notable topics, “World", “Education”, and “Economics”, contribute 12.4%, 12.9%, and 10.9% respectively. In contrast, “National Security” accounts for the lowest percentage at 2.0%. This lower representation is attributed to

Tuyển Dụng Đánh Giá Nhân Sự Để đánh giá hiệu suất của con người trong quá trình kiểm chứng thông tin, chúng tôi đã mời ba sinh viên nói tiếng Việt bản địa, những người chưa từng tiếp xúc với nhiệm vụ kiểm chứng thông tin trước đó. Họ có nhiệm vụ gán nhãn cho một tập con đại diện gồm 200 mẫu. Hướng dẫn toàn diện đã được cung cấp để đảm bảo họ hiểu nhiệm vụ, bao gồm làm rõ ý nghĩa của từng nhãn và thông tin bổ sung để giúp họ xác định nhãn thích hợp cho mỗi mẫu. Nhãn cuối cùng cho mỗi tuyê n bố được xác định thông qua sự đồng thuận đa số giữa các người đánh giá.

Ví dụ về dữ liệu E

Bộ dữ liệu ViFactCheck bao gồm nhiều ví dụ về các tuyên bố bằng văn bản, như minh họa trong Bảng 7. Để tạo ra một bối cảnh thách thức và thực tế, các người chú thích đã được giao nhiệm vụ tạo ra các tuyên bố dựa trên nhiều bằng chứng, được làm nổi bật trong bối cảnh văn bản được cung cấp. Cách tiếp cận này không chỉ nâng cao độ phức tạp và tính thách thức của nhiệm vụ chú thích mà còn đóng góp đáng kể vào độ tin cậy và giá trị thực tiễn của bộ dữ liệu cho các nhiệm vụ kiểm chứng thông tin bằng tiếng Việt. Bằng cách đảm bảo rằng các tuyên bố được dựa trên các bằng chứng có thể kiểm chứng, bộ dữ liệu tạo ra một môi trường vững chắc để đào tạo và đánh giá các mô hình ngôn ngữ được thiết kế đặc biệt cho những sắc thái của việc xác minh sự thật.

F Các Quy Tắc do Con Người Tạo Ra

Trong các bộ dữ liệu ViFactCheck, những người chú thích được khuyến khích tận dụng vốn từ rộng và kỹ năng viết câu của họ, t ừ đó đưa những sắc thái giá trị vào các chú thích. Các quy tắc cơ bản về việc sử dụng sự tạo ra của người chú thích được tóm tắt trong Bảng 8.

	Quy tắc	Tỷ lệ (%)
Support	Tái cấu trúc các bằng chứng	73.68
	Loại bỏ hoặc thêm từ	44.21
	Thay thế các con số, thời gian hoặc suy luận toán học	7.34
	Thay đổi trật tự từ trong một câu	8.42
Refute	Sử dụng phủ định	8.16
	Thay Thế Từ Bằng Từ Trái Nghĩa	17.35
	Trình bày sai số lượng	22.45
	Trình bày sai Logic Thời gian	16.37
	Hiểu sai các mối quan hệ thực thể	5.11
	Đánh giá sai động lực sự kiện	47.96
NEI	Suy luận câu với thông tin chưa được xác định	90.20
	Sử dụng kiến thức bên ngoài	10.78

Bảng 8: Các phương pháp và quy tắc để con người tạo ra các t uyên bố trong tập dữ liệu ViFactCheck. Lưu ý rằng một tuyên bố có thể liên quan đến nhiều quy tắc

Những người chú thích được yêu cầu tuân theo hướng dẫn để tạo ra dữ liệu đa dạng và thách thức. Phân bố việc sử dụng các quy tắc tạo dữ liệu cho các tuyên bố liên quan đến Hỗ trợ, Phủ nhận, và Thông tin không đủ (NEI) được hiển thị trong Hình 7. Để hiểu cách những người chú thích hành xử khi tạo ViFactCheck, chúng tôi đã phân tích số lượng quy tắc được sử dụng để tạo các tuyên bố.

Chúng tôi đã chọn ngẫu nhiên 100 cặp ngữ cảnh-lời khẳng định cho các danh mục Hỗ trợ, Phủ nhận và NEI.

Xu hướng chính trong bộ dữ liệu này cho thấy một sự thiên vị rõ ràng trong việc sử dụng 1-2 quy tắc, phản ánh một quy trình chú thích tiêu chuẩn hóa. Tuy nhiên, một số người chú thích đã lệch khỏi xu hướng này, chọn bốn quy tắc trở lên, cho thấy nhận thức về sự phức tạp và đa dạng của dữ liệu. Điều này nhấn mạnh tầm quan trọng của việc kết hợp các quy tắc một cách thận trọng để có chú thích đáng tin cậy và chính xác.

Việc sử dụng nhiều quy tắc đặt ra những thách thức cho việc phát triển mô hình ngôn ngữ, đưa ra sự phức tạp trong các quá trình suy luận và ra quyết định phụ thuộc vào sự kết hợp của các quy tắc. Tuy nhiên, nó cũng mang lại cơ hội để cải thiện các mô hình ngôn ngữ linh hoạt hơn, đảm bảo độ chính xác cao hơn trong việc đưa ra suy luận.

G Phân tích Bộ dữ liệu Bổ sung

Thống kê cơ bản của tập dữ liệu. Tập dữ liệu ViFactCheck chứa 7.232 mẫu, được chia thành ba tập con: huấn luyện, phát triển và kiểm tra với tỉ lệ 7:1:2. Thống kê cơ bản của ba tập con được trình bày trong Bảng 9. Chúng tôi quan sát thấy rằng độ dài trung bình của một ngữ cảnh trong tập dữ liệu khoảng 700 từ, với ngữ cảnh dài nhất kéo dài tới 3.602 từ. Sự phong phú về ngữ cảnh này chứng tỏ rất có lợi cho các mô hình có số lượng tham số lớn, chẳng hạn như Gemma, vì chúng có thể nắm bắt hiệu quả tối đa các đặc trưng của dữ liệu. Trung bình, mỗi câu khẳng định chứa khoảng 36 từ, với câu dài nhất đạt 165 từ.

		Đào tạo	Phát triển	Test
Context	Tổng số mẫu	1035	496	758
	Độ dài trung bình	693.2	670.2	690.5
	Chiều dài tối đa	3602	2534	3602
	Độ dài tối thiểu	71	71	71
	Tổng kích thước từ vựng	25,382	16,522	21,263
claim	Tổng số mẫu	5062	723	1447
	Độ dài trung bình	35.9	35.6	35.8
	Chiều dài tối đa	165	145	135
	Độ dài tối thiểu	7	10	7
	Tổng kích thước từ vựng	12,189	4,555	6,711

Bảng 9: Thống kê cơ bản của bộ dữ liệu ViFactCheck. Kích thước và độ dài của từ vựng được tính ở cấp độ từ.

Phân tích Phân bố Chủ đề Bộ dữ liệu ViFactCheck bao gồm 12 chủ đề phổ biến thường xuất hiện trong tin tức Việt Nam, thường bị thông tin sai lệch tác động. Những chủ đề này, được tóm tắt trong Hình 8, bao gồm “Tiêu đề”, “Thế giới”, “Giáo dục” và “Kinh tế”, cùng nhiều chủ đề khác. “Tiêu đề”, bao gồm cập nhật về các vấn đề xã hội và sự kiện, xuất hiện thường xuyên nhất, cho thấy sự hiện diện đáng kể trong bộ dữ liệu. Các chủ đề đáng chú ý khác, “ Thế giới”, “Giáo dục” và “Kinh tế”, lần lượt chiếm 12,4%, 12,9% và 10,9%. Ngược lại, “An ninh Quốc gia” chiếm tỷ lệ thấp nhất với 2,0 %. Sự đại diện thấp hơn này được lý giải bởi

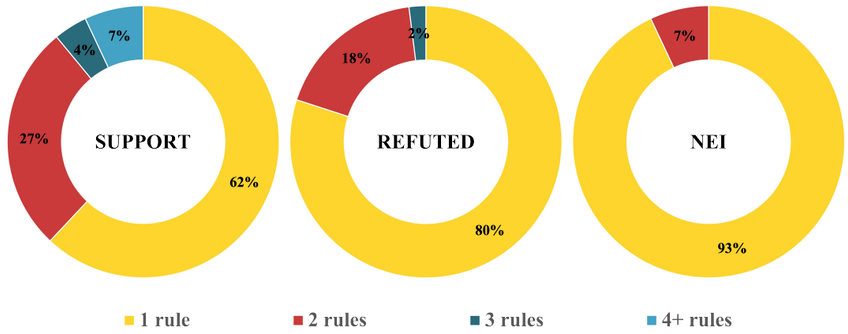


Figure 7: The ratio of combining different rules to create claims in ViFactCheck.

the relatively few news on this topic in real life. Despite its smaller volume, due to the critical need for accuracy in information pertaining to national security, a concerted effort was made to include news related to this topic.

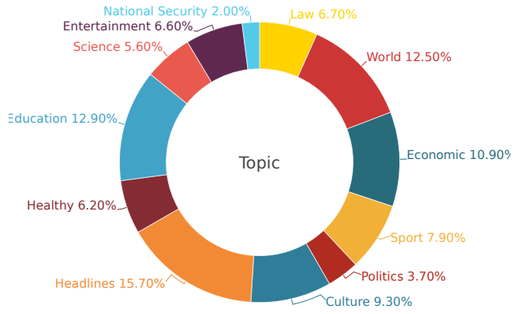


Figure 8: Topic distribution on ViFactCheck dataset.

Evidence Distribution Analysis Figure 9 from the ViFactCheck dataset shows the distribution of samples with varying numbers of evidence per claim. Single evidence refers to using only one piece of information to verify a claim, while multi-evidence involves integrating findings from multiple sources, necessitating advanced analytical skills to synthesize and validate information.

The distribution reveals a predominant reliance on single pieces of evidence, where claims are supported by one source, reflecting simpler verification tasks. Multi-evidence scenarios, where claims are substantiated by two or more sources, demonstrate a steep decline to 1,765 and 293 samples for two and three evidences, respectively. This indicates the increasing complexity and computational demand of integrating diverse evidences. Notably, the rise to 130 samples for claims with more than five evidences suggests some scenarios necessitate extensive, complex reasoning, highlighting the capability of the dataset to train models for robust, multi-faceted fact verification.

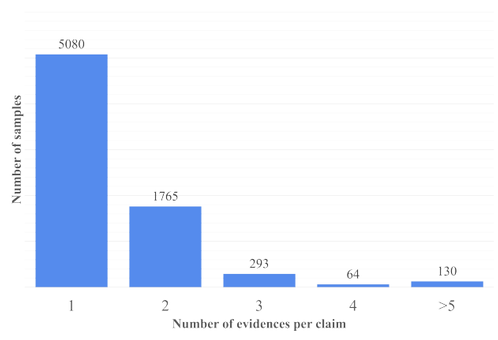
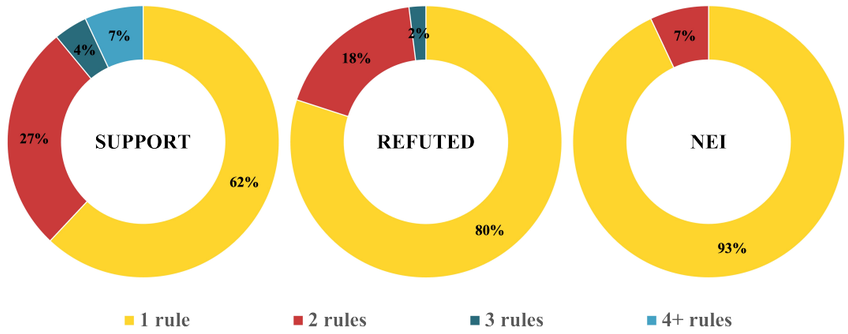


Figure 9: The distribution of single and multiple evidences samples in the ViFactCheck dataset.

H Details about the Baselines

H.1 Pre-trained Language Models

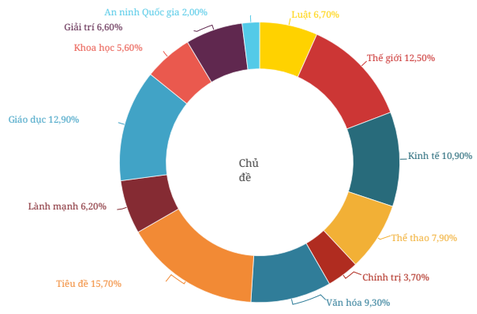
Based on the significant performance of transformer-based in prior fact-checking tasks (Thorne et al. 2018; Hu et al. 2022; Nørregaard and Derczynski 2021), we employ pre-trained language models, specifically BERT (Devlin et al. 2019) and RoBERTa (Liu et al. 2019) architectures, for the fact-checking task. This study includes four models, comprising two multilingual models and two monolingual models (the details of each model are shown in Table 10).



Hình 7: Tỷ lệ kết hợp các quy tắc khác nhau để tạo ra các khẳng định trong ViFactCheck.

tương đối ít tin tức về chủ đề này trong đời thực. Mặc dù khối lượng nhỏ hơn, nhưng do nhu cầu cấp thiết về độ chính xác t hông tin liên quan đến an ninh quốc gia, một nỗ lực chung đã được thực hiện để bao gồm các tin tức liên quan đến chủ đề này.

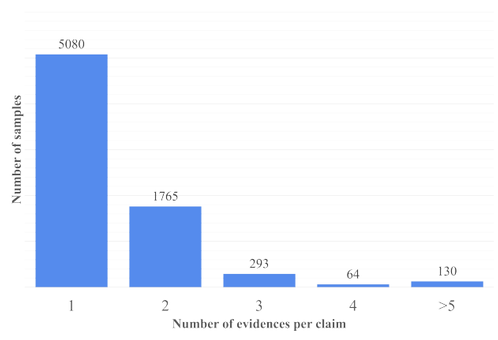
sự phức tạp ngày càng tăng và nhu cầu tính toán khi tích hợp các bằng chứng đa dạng. Đáng chú ý, việc tăng lên 130 mẫu cho các tuyên bố có hơn năm bằng chứng cho thấy một số kịch bản đòi hỏi lý luận phức tạp, rộng lớn, nhấn mạnh khả năng của bộ dữ liệu để đào tạo các mô hình nhằm xác minh sự thật mạnh mẽ, nhiều khía cạnh.



Hình 8: Phân bố chủ đề trên tập dữ liệu ViFactCheck.

Phân tích phân bố bằng chứng Hình 9 từ bộ dữ liệu Vi-FactCheck cho thấy phân bố các mẫu với số lượng bằng chứng khác nhau cho mỗi tuyên bố. Bằng chứng đơn đề cập đến việc chỉ sử dụng một thông tin để xác minh một tuyên bố, trong khi bằng chứng đa dạng liên quan đến việc tích hợp các phát hiện từ nhiều nguồn, đòi hỏi kỹ năng phân tích nâng cao để tổng hợp và xác thực thông tin.

Phân phối cho thấy sự phụ thuộc chủ yếu vào từng mẩu bằng chứng riêng lẻ, nơi các tuyên bố được hỗ trợ bởi một nguồn duy nhất, phản ánh các nhiệm vụ xác minh đơn giản hơn. Các tình huống sử dụng nhiều bằng chứng, nơi các tuyên bố được chứng minh bằng hai hoặc nhiều nguồn, cho thấy sự giảm mạnh xuống còn 1.765 và 293 mẫu cho hai và ba bằng chứng, tương ứng. Điều này chỉ ra



Hình 9: Phân bố các mẫu chứng cứ đơn và nhiều chứng cứ trong tập dữ liệu ViFactCheck.

H Chi tiết về các đường cơ sở

H.1 Mô hình ngôn ngữ đã được huấn luyện trước

Dựa trên hiệu suất đáng kể của các mô hình dựa trên tr ansformer trong các nhiệm vụ kiểm tra thực tế trước đây (T horne et al. 2018; Hu et al. 2022; Nørregaard và Derczynski 2021), chúng tôi sử dụng các mô hình ngôn ngữ được huấn luyện trước, cụ thể là kiến trúc BERT (Devlin et al. 2019) và RoBERTa (Liu et al. 2019), cho nhiệm vụ kiểm tra thực tế. Nghiên cứu này bao gồm bốn mô hình, gồm hai mô hình đa ngôn ngữ và hai mô hình đơn ngôn ngữ (chi tiết về từng mô hình được trình bày trong Bảng 10).

mBERT (Devlin et al. 2019) is a transformer-based model trained on an extensive corpus of 104 languages, including Vietnamese. Its linguistic versatility makes mBERT invaluable for fact-checking tasks. As a multilingual model, mBERT enables comprehensive analysis and serves as an excellent tool for ensuring the credibility of data within the Vietnamese fact-checking framework.

Cross-lingual Language Model - RoBERTa (XLM-R) (Conneau et al. 2020) is a transformer-based model trained on 100 languages. This vast linguistic scope means XLM-R can understand and compare information across different languages, an advantage for fact-checking that offers a broader context beyond the Vietnamese language. The ability of XLM-R to process information from multilingual sources or across language barriers is especially valuable when dealing with content that transcends linguistic boundaries.

PhoBERT (Nguyen and Tuan Nguyen 2020), leveraging the powerful Transformer architecture of RoBERTa (Liu et al. 2019), exhibits a profound understanding of the nuances and context of the Vietnamese language. This linguistic precision is highly beneficial for the Vietnamese fact-checking dataset, as it can discern subtle language nuances that general models might overlook. With its focus on Vietnamese, PhoBERT delivers exceptional efficiency and accuracy when applied to a corpus of the same language, facilitating high-quality fact-checking within the Vietnamese context.

ViBERT, based on the BERT architecture and specifically designed for Vietnamese, was introduced by Bui, Tran, and Le-Hong (2020). Unlike mBERT, which is trained on a multi-language corpus, ViBERT is pre-trained on a substantial corpus of 10GB of uncompressed Vietnamese text, focusing solely on Vietnamese to achieve optimal performance.

By investigating the effectiveness of these BERT variants in Vietnamese fact-checking, we aim to enhance the field's ability to combat disinformation. The diversity of these models in terms of monolingual understanding, linguistic precision, and cross-lingual capabilities promises to make a contribution to the fact-checking landscape, advancing a more credible and precise information ecosystem.

H.2 Fine-Tuning Large Language Models

Recent advances in large language models (LLMs), which exhibit strong contextual understanding, have demonstrated their effectiveness in tasks such as contextual comprehension and reasoning, including fact-checking. Consequently, we employ several primary models that are suitable for low-resource configurations. Specifically, we utilize the open-source models Llama2 7B, Llama3 8B, Gemma 7B, and Mistral 7B.

LLaMA (Touvron et al. 2023), or Large Language Model Meta AI, represents a significant leap in the development of foundational models for natural language inference (NLI) tasks. Introduced by Meta AI, LLaMA is designed to create a more accessible and efficient framework for researchers and developers. Available in various sizes including 7B, 13B, 33B, 65B, and 70B parameters, LLaMA caters to different computational needs and research objectives. It is trained on a diverse dataset comprising 1.4 trillion tokens from 20 languages, enabling it to perform a wide range of NLP tasks with high accuracy and efficiency. Innovations in its architecture, such as the SwiGLU activation function and rotary positional embeddings, contribute to its superior performance on NLP benchmarks.

Mistral (Jiang et al. 2023), developed by Mistral AI, stands out for its innovative approach to structured content generation and instruction-based modeling. Designed to generate high-quality, structured content similar to the functionalities offered by OpenAI models, Mistral achieves enhanced efficiency and lower resource requirements. The Mistral model utilizes mechanisms like Grouped-query Attention (GQA) and Sliding Window Attention (SWA) to achieve faster inference times and handle longer text sequences. Its ability to parse and extract information using a JSON Schema makes it particularly suited for tasks requiring structured output.

Gemma (Team et al. 2024), developed by Google DeepMind, leverages technology from the Gemini model to offer state-of-the-art, open models. It includes a 7B parameter model for GPU/TPU use and a 2B parameter model for CPU and on-device applications, both trained on up to 6 billion tokens. These models excel in language understanding, reasoning, and safety benchmarks, outperforming similarly sized open models in 11 out of 18 tasks. Key enhancements in the Gemma models include multi-query attention, RoPE embeddings, GeGLU activations, and RMSNorm for stable training. The models are rigorously evaluated through automated and human benchmarks to ensure robustness and reliability, with a strong emphasis on responsible AI practices.

The LLMs were fine-tuned using the LoRA through the Unsloth library. Detailed configuration specifics and prompting procedures are described in Section 4.2 and Appendix I, respectively.

H.3 In-Context Learning Models

In addition to fine-tuning large language models (LLMs), we rigorously assessed the in-context learning capabilities of these models through zero-shot evaluations, where models are tasked with generating accurate responses without prior specific training on examples.

Beyond the models detailed in Appendix H.2, we employed Gemini 1.5 Flash (Reid et al. 2024), a recent addition to the LLMs developed by Google AI. Introduced in May 2024, Gemini 1.5 Flash, part of the broader Gemini family, excels in handling multimodal tasks. Notable for its high-speed, large-scale information processing capabilities, Gemini 1.5 Flash is particularly suitable for real-time applications and environments requiring frequent updates. Despite its focus on efficiency, this model maintains robust reasoning capabilities across multiple modalities, including text, image, and audio, and supports an extensive context window of up to one million tokens. This feature is crucial for tasks that require a deep comprehension of prior information.

Furthermore, we conducted experiments on the Vi-FactCheck dataset using the prompt described in Appendix I, following a zero-shot approach. These experiments aimed to evaluate the ability of models to integrate and reason with various types of information without preliminary fine-tuning, showcasing its potential in real-world applications where training data may be sparse or unavailable.

mBERT (Devlin et al. 2019) là một mô hình dựa trên transformer được huấn luyện trên một tập hợp lớn gồm 104 ngôn ngữ, bao gồm cả tiếng Việt. Sự đa dạng ngôn ngữ của nó khiến mBERT trở nên vô giá cho các nhiệm vụ kiểm tra sự thật. Là một mô hình đa ngôn ngữ, mBERT cho phép phân tích toàn diện và là một công cụ xuất sắc để đảm bảo độ tin cậy của dữ liệu trong khuôn khổ kiểm tra sự thật tại Việt Nam.

Mô hình Ngôn ngữ Đa ngôn ngữ - RoBERTa (XLM-R) (Conneau và cộng sự, 2020) là một mô hình dựa trên transformer được đào tạo trên 100 ngôn ngữ. Phạm vi ngôn ngữ rộng lớn này có nghĩa là XLM-R có thể hiểu và so sánh thông tin giữa các ngôn ngữ khác nhau, một lợi thế cho việc kiểm chứng thông tin, mang lại bối cảnh rộng hơn ngoài ngôn ngữ tiếng Việt. Khả năng của XLM-R trong việc xử lý thông tin từ các nguồn đa ngôn ngữ hoặc vượt qua rào cản ngôn ngữ đặc biệt có giá trị khi xử lý nội dung vượt ra ngoài giới hạn ngôn ngữ.

PhoBERT (Nguyen và Tuan Nguyen 2020), tận dụng kiến trúc Transformer mạnh mẽ của RoBERTa (Liu và cộng sự 2019), thể hiện sự hiểu biết sâu sắc về các sắc thái và ngữ cảnh của ngôn ngữ Việt Nam. Sự chính xác về ngôn ngữ này rất có lợi cho tập dữ liệu xác minh thông tin tiếng Việt, vì nó có thể phân biệt các sắc thái ngôn ngữ tinh tế mà các mô hình tổng quát có thể bỏ qua. Với việc tập trung vào tiếng Việt, PhoBERT mang lại hiệu quả và độ chính xác đặc biệt khi áp dụng vào một tập hợp dữ liệu cùng ngôn ngữ, hỗ trợ việc xác minh thông tin chất lượng cao trong bối cảnh Việt Nam.

ViBERT, dựa trên kiến trúc BERT và được thiết kế đặc biệt c ho tiếng Việt, đã được Bùi, Trần và Lê-Hong (2020) giới thiệu. Khác với mBERT, được đào tạo trên một tập hợp dữ liệu đa ngôn ngữ, ViBERT được tiền huấn luyện trên một tập hợp dữ liệu lớn gồm 10GB văn bản tiếng Việt chưa nén, tập trung hoàn toàn vào tiếng Việt để đạt hiệu suất tối ưu.

Bằng cách nghiên cứu hiệu quả của các biến thể BERT này trong việc kiểm chứng thông tin tại Việt Nam, chúng tôi nhằm mục đích nâng cao khả năng của lĩnh vực này trong việc chống l ại thông tin sai lệch. Sự đa dạng của các mô hình này về hiểu biết đơn ngôn ngữ, độ chính xác ngôn ngữ và khả năng xuyên ngôn ngữ hứa hẹn sẽ đóng góp vào bức tranh kiểm chứng thông tin, tiến tới một hệ sinh thái thông tin đáng tin cậy và chính xác hơn.

H.2 Tinh Chỉnh Mô Hình Ngôn Ngữ Lớn

Những tiến bộ gần đây trong các mô hình ngôn ngữ lớn (LLMs), vốn thể hiện khả năng hiểu ngữ cảnh mạnh mẽ, đã chứng minh hiệu quả của chúng trong các nhiệm vụ như hiểu ngữ cảnh và lập luận, bao gồm việc kiểm tra sự thật. Do đó, chúng tôi sử dụng một số mô hình chính phù hợp với các cấu hình hạn chế tài nguyên. Cụ thể, chúng tôi sử dụng các mô hình nguồn mở Lla ma2 7B, Llama3 8B, Gemma 7B và Mistral 7B.

LLaMA (Touvron et al. 2023), hay Large Language Model Meta AI, đại diện cho một bước tiến quan trọng trong phát triển các mô hình nền tảng cho các nhiệm vụ suy luận ngôn ngữ tự nhiên (NLI). Được giới thiệu bởi Meta AI, LLaMA được thiết kế để tạo ra một khuôn khổ dễ tiếp cận và hiệu quả hơn cho các nhà nghiên cứu và phát triển. Có sẵn với nhiều kích thước khác nhau bao gồm 7B, 13B, 33B, 65B và 70B tham số, LLaMA đáp ứng các nhu cầu tính toán và mục tiêu nghiên cứu khác nhau. Nó được đào tạo trên một bộ dữ liệu đa dạng bao gồm 1,4 nghìn tỷ token t ừ 20 ngôn ngữ, cho phép nó thực hiện một loạt các nhiệm vụ xử l ý ngôn ngữ tự nhiên (NLP) với độ chính xác và hiệu quả cao. Các đổi mới trong kiến trúc của nó, chẳng hạn như hàm kích hoạt SwiGLU và nhúng vị trí xoay, góp phần vào hiệu suất vượt trội của nó trên các chuẩn đánh giá NLP.

Mistral (Jiang et al. 2023), được phát triển bởi Mistral AI, nổi bật với phương pháp đổi mới trong việc tạo nội dung có cấu trúc và mô hình hóa dựa trên hướng dẫn. Được thiết kế để tạo ra nội dung có chất lượng cao và có cấu trúc tương tự như các chức năng mà các mô hình của OpenAI cung cấp, Mistral đạt được hiệu quả cao hơn và yêu cầu t ài nguyên thấp hơn. Mô hình Mistral sử dụng các cơ chế như Attention theo nhóm truy vấn (Grouped-query Attention - GQA) và Attention cửa sổ trượt (Sliding Window Attention - SWA) để đạt được thời gian suy luận nhanh hơn và xử lý các chuỗi văn bản dài hơn. Khả năng phân tích và trích xuất thông tin của nó bằng cách sử dụng JSON Schema khiến nó đặc biệt phù hợp cho các nhiệm vụ yêu cầu đầu ra c ó cấu trúc.

Gemma (Team et al. 2024), được phát triển bởi Google DeepMind, sử dụng công nghệ từ mô hình Gemini để cung cấp c ác mô hình mở hiện đại. Nó bao gồm một mô hình 7 tỷ tham số dành cho GPU/TPU và một mô hình 2 tỷ tham số dành cho CPU và các ứng dụng trên thiết bị, đều được đào tạo trên tối đa 6 tỷ t oken. Các mô hình này xuất sắc trong việc hiểu ngôn ngữ, lập l uận và đánh giá an toàn, vượt trội hơn các mô hình mở có kích thước tương đương trong 11 trên 18 nhiệm vụ. Các cải tiến chính trong các mô hình Gemma bao gồm chú ý đa truy vấn (multi-query attention), nhúng RoPE, hoạt hóa GeGLU và RMSNorm để đào tạo ổn định. Các mô hình được đánh giá nghiêm ngặt thông qua các chuẩn mực tự động và con người để đảm bảo tính chắc chắn và đáng tin cậy, với sự nhấn mạnh mạnh mẽ vào các thực hành AI có trách nhiệm.

Các mô hình ngôn ngữ lớn (LLM) đã được tinh chỉnh sử dụng LoRA thông qua thư viện Unsloth. Các chi tiết cấu hình cụ thể và quy trình nhắc lệnh được mô tả trong Mục 4.2 và Phụ lục I, tương ứng.

H.3 Mô hình học theo ngữ cảnh

Ngoài việc tinh chỉnh các mô hình ngôn ngữ lớn (LLM), chúng tôi còn đánh giá một cách nghiêm ngặt khả năng học theo ngữ cảnh của các mô hình này thông qua các đánh giá zero-shot, trong đó các mô hình được giao nhiệm vụ tạo ra các phản hồi chính xác mà không cần huấn luyện cụ thể trước về các ví dụ.

Ngoài các mô hình được trình bày chi tiết trong Phụ lục H.2, chúng tôi đã sử dụng Gemini 1.5 Flash (Reid và cộng sự, 2024), một bổ sung gần đây vào các LLM được phát triển bởi Google AI. Được giới thiệu vào tháng 5 năm 2024, Gemini 1.5 Flash, thuộc họ Gemini rộng hơn, nổi trội trong việc xử lý các nhiệm vụ đa phương thức. Đáng chú ý với khả năng xử lý thông tin ở quy mô lớn và tốc độ cao, Gemini 1.5 Flash đặc biệt phù hợp cho các ứng dụng thời gian thực và môi trường yêu cầu cập nhật thường xuyên. Mặc dù tập trung vào hiệu quả, mô hình này vẫn duy trì khả năng suy luận mạnh mẽ trên nhiều phương thức, bao gồm văn bản, hình ảnh và âm thanh, và hỗ trợ cửa sổ ngữ cảnh rộng tới một triệu token. Tính năng này rất quan trọng cho các nhiệm vụ đòi hỏi hiểu biết sâu sắc về thông tin trước đó.

Hơn nữa, chúng tôi đã tiến hành các thí nghiệm trên bộ dữ liệu Vi-FactCheck bằng cách sử dụng lời nhắc được mô tả trong Phụ lục I, theo phương pháp zero-shot. Các thí nghiệm này nhằm đánh giá khả năng của các mô hình trong việc tích hợp và suy luận với các loại thông tin khác nhau mà không cần tinh chỉnh trước, thể hiện tiềm năng của chúng trong các ứng dụng thực tế nơi dữ liệu huấn luyện có thể khan hiếm hoặc không có sẵn.

Model	#Layer	#Head	#Params	#Vocab	#MSL	Domain data	Language support
PhoBERT$_{base}$ (Nguyen and Tuan Nguyen 2020)	12	12	135M	64K	256	ViWiki + ViNews	Vietnamese
PhoBERT$_{large}$ (Nguyen and Tuan Nguyen 2020)	24	16	370M	64K	256	ViWiki + ViNews	Vietnamese
ViBERT (Bui, Tran, and Le-Hong 2020)	12	12	-	30K	256	Vietnamese News	Vietnamese
mBERT (Devlin et al. 2019)	12	12	110M	30K	512	Wikipedia + BookCorpus	Multilingual
XLM-R$_{base}$ (Conneau et al. 2020)	12	12	270M	250K	512	CommonCrawl	100+ languages
XLM-R$_{large}$ (Conneau et al. 2020)	24	16	550M	250K	512	CommonCrawl	100+ languages
Gemini (Reid et al. 2024)	-	-	-	-	1,048,576	Mixed large datasets	Multilingual
Gemma (Team et al. 2024)	28	16	7B	256K	8,192	Mixed large datasets	Multilingual
Mistral (Jiang et al. 2023)	32	32	7B	32K	32,768	Mixed large datasets	Multilingual
Llama2 (Touvron et al. 2023)	32	32	7B	32K	4,096	Mixture of datasets	Primarily English
Llama3 (Touvron et al. 2023)	32	32	8B	128K	8,192	Mixture of datasets	Primarily English

Table 10: Detailed specifications of our baseline models. Abbreviations used are: #Layers (Number of Hidden Layers), #Heads (Number of Attention Heads), #Params (Total Number of Parameters), #Vocab (Vocabulary Size), and #MSL (Maximum Sequence Length).

Mô hình	#Lớp	#Đầu	#ThamSố	# Từvựng	#MSL	Dữ liệu miền	Hỗ trợ ngôn ngữ
PhoBERT$_{base}$ (Nguyen và Tuan Nguyen 2020)	12	12	135M	64K	256	ViWiki + ViNews	Tiếng Việt
PhoBERT$_{large}$ (Nguyen và Tuan Nguyen 2020)	24	16	370M	64K	256	ViWiki + ViNews	Tiếng Việt
ViBERT (Bui, Tran và Le-Hong 2020)	12	12	-	30K	256	Tin tức Việt Nam	Tiếng Việt
mBERT (Devlin và cộng sự, 2019)	12	12	110M	30K	512	Wikipedia + BookCorpus	Đa ngôn ngữ
XLM-R$_{base}$ (Conneau và cộng sự 2020)	12	12	270M	250K	512	CommonCrawl	100+ ngôn ngữ
XLM-R$_{large}$ (Conneau và cộng sự 2020)	24	16	550M	250K	512	CommonCrawl	100+ ngôn ngữ
Gemini (Reid và cộng sự 2024)	-	-	-	-	1.048.576	Tập dữ liệu lớn hỗn hợp	Đa ngôn ngữ
Gemma (Nhóm và cộng sự 2024)	28	16	7B	256K	Tám nghìn một trăm chín mươi hai	Tập dữ liệu lớn hỗn hợp	Đa ngôn ngữ
Mistral (Jiang và cộng sự, 2023)	32	32	7B	32K	32.768	Tập dữ liệu lớn hỗn hợp	Đa ngôn ngữ
Llama2 (Touvron và cộng sự, 2023)	32	32	7B	32K	Bốn nghìn không trăm chín mươi sáu	Hỗn hợp các tập dữ liệu	Chủ yếu là tiếng Anh
Llama3 (Touvron và cộng sự, 2023)	32	32	8B	128K	Tám nghìn một trăm chín mươi hai	Hỗn hợp các bộ dữ liệu	Chủ yếu là tiếng Anh

Bảng 10: Thông số chi tiết của các mô hình cơ sở của chúng tôi. Các chữ viết tắt sử dụng là: #Layers (Số Lượng Lớp Ẩn), #Heads (Số Lượng Đầu Attention), #Params (Tổng Số Tham Số), #Vocab (Kích Thước Từ Vựng), và #MSL (Độ Dài Chuỗi Tối Đa).

I Prompts for Vietnames Fact-Checking

In this section, we outline the templates for the prompting methods used for fine-tuning and zero-shot evaluations with LLMs in the fact-checking task. The prompt structure is designed to test the ability of models to assess the veracity of a claim based on the given context or evidence.

Fine-Tune Instruction Prompting

You will be presented with a long context, followed by a claim. Your task is to fact-check the claim based on the provided context. You must categorize the claim into one of three categories:
- **Support:** Choose this if the claim is true and fully supported by the context.
- **Refute:** Choose this if the claim is false and contradicted by the context.
- **Not Enough Information:** Choose this if the claim contains content that is not covered by the context, making it impossible to determine its accuracy.
Context:
Claim:
Response:

Zeroshot Prompting

Return only the label in the format: Label: Support(0), Label: Refute(1), or Label: Not Enough Information(2).
Instructions:
1. Fact check the claim based on the provided evidence.
2. Use the following labels:
- **Support:** The claim is true and supported by the evidence.
- **Refute:** The claim is false and contradicted by the evidence.
- **Not Enough Information:** The claim contains content that is not covered by the evidence, making it impossible to determine its accuracy.
Example:
Label: Support

J Number of Parameters

To establish the main baseline models, we utilized several state-of-the-art methods, including a pre-trained and large language model, to support the Vietnamese Fact-Checking task. The details of each model are shown in Table 10.

K Definition and Examples of Error Analysis

We introduce the error definition as follows and illustrate some error cases for Vietnamese fact-checking in Figure 5:

- **Evidence Retrieval Failure:** Failures due to the inability of model to accurately and fully extract essential evidence from data sources (as shown in Figure 10).

Evidence Retrieval Failure

Context: … Cuộc đua xe đạp Cúp Truyền hình TP.HCM 2023 với slogan "Non sông liền một dải - Niềm tin chiến thắng" quy tụ tất cả đội đua mạnh trên cả nước, vốn quen thuộc với làng xe đạp chuyên nghiệp gồm: TP.HCM - Vinama, Tập đoàn Lộc Trời, Dược Domesco Đồng Tháp, Quân khu 7, Hà Nội, Kenda Đồng Nai, Bình Dương…
(…The 2023 Ho Chi Minh City Television Cup cycling race with the slogan "United Nation, Victory Belief" brings together all the strong teams across the country who are familiar with the professional cycling scene, including: Ho Chi Minh City - Vinama, Loc Troi Group, Domesco Dong Thap Pharmaceutical, Military Zone 7, Hanoi, Kenda Dong Nai, Binh Duong...)

Claim: Cuộc đua xe đạp quy tụ 100 đội đua xe chuyên nghiệp trong nước tham gia.
(The cycling race brought together 100 professional cycling teams from across the country.)

Retrieved Evidence: Chặng đua đồng đội tính giờ sẽ diễn ra tại Quảng Ngãi. Nét đặc biệt của giải đua năm nay là ngoài lộ trình lên Tây Nguyên và vòng xuống các tỉnh miền Đông Nam Bộ còn là chuyến tải nhiều thông điệp như quảng bá du lịch, giới thiệu văn hóa vùng miền, bảo vệ môi trường, góp phần cổ vũ, động viên phong trào đạp xe đạp trong cả nước và các hoạt động thiện nguyện, lan tỏa công tác đền ơn đáp nghĩa.
(The team time trial stage will take place in Quang Ngai. A special feature of this year's race is that in addition to the route up to the Central Highlands and down to the provinces of the Southeast, it also conveys many messages such as promoting tourism, introducing regional culture, protecting the environment, contributing to encouraging and motivating the cycling movement nationwide, and charitable activities, spreading gratitude and repayment.)

Gold labels: NEI **Gemma Prediction:** Refute

Figure 10: Examples of Evidence Retrieval Failure.

Tôi đưa ra câu hỏi để kiểm chứng sự thật bằng tiếng Việt

Trong phần này, chúng tôi trình bày các mẫu cho các phương pháp nhắc nhở được sử dụng cho việc tinh chỉnh và đánh giá zero-shot với các mô hình ngôn ngữ lớn (LLM) trong nhiệm vụ kiểm tra sự thật. Cấu trúc lời nhắc được thiết kế để kiểm tra khả năng của các mô hình t rong việc đánh giá tính xác thực của một tuyên bố dựa trên bối cảnh hoặc bằng chứng được cung cấp.

Tinh chỉnh hướng dẫn nhắc

Bạn sẽ được trình bày với một bối cảnh dài, sau đó là một tuyên bố. Nhiệm vụ của bạn là kiểm tra tính xác thực của tuyên bố dựa trên bối cảnh được cung cấp. Bạn phải phân loại tuyên bố thành một trong ba loại: - Hỗ trợ: Chọn mục này nếu tuyên bố là đúng và được bối cảnh hoàn toàn xác nhận. - Bác bỏ: Chọn mục này nếu tuyên bố là sai và mâu thuẫn với bối cảnh. - Thông tin không đủ: Chọn mục này nếu tuyên bố chứa nội dung không được đề cập trong bối cảnh, làm cho việc xác định độ chính xác của nó trở nên không thể. ### Bối cảnh: ### Tuyên bố: ### Phản hồi:

Gợi ý không cần huấn luyện trước

Chỉ trả về nhãn theo định dạng: Nhãn: Hỗ trợ(0), Nhãn: Phản bác(1), hoặc Nhãn: Không đủ thông tin(2).

Hướng dẫn: .
1
Kiểm tra tính xác thực của tuyên bố dựa trên bằng chứng đã c ung cấp. 2. Sử dụng các nhãn sau: - Hỗ trợ: Tuyên bố là đúng và được chứng minh bởi bằng chứng. - Bác bỏ: Tuyên bố là sai và mâu thuẫn với bằng chứng. - Thông tin không đủ: Tuyên bố chứa nội dung không được bao phủ bởi bằng chứng, làm cho việc xác định độ chính xác c ủa nó là không thể.

Ví dụ:
Nhãn: Hỗ trợ

J Số lượng tham số

Để thiết lập các mô hình cơ sở chính, chúng tôi đã sử dụng một số phương pháp tiên tiến nhất, bao gồm một mô hình được huấn luyện trước và lớn mô hình ngôn ngữ, để hỗ trợ nhiệm vụ Kiểm chứng Thông tin tại Việt Nam. Chi tiết của từng mô hình được trình bày trong Bảng 10.

Định nghĩa K và Ví dụ về Phân tích Lỗi

Chúng tôi giới thiệu định nghĩa lỗi như sau và minh họa một số trường hợp lỗi cho việc kiểm chứng sự thật bằng tiếng Việt trong Hình 5:

- Thất bại trong thu hồi bằng chứng: Thất bại do mô hình không thể trích xuất chính xác và đầy đủ các bằng chứng cần thiết từ các nguồn dữ liệu (như minh họa trong Hình 10).

Lỗi truy xuất bằng chứng

Ngữ cảnh: ... Cuộc đua xe đạp Cúp Truyền hình TP.HCM 2023 với khẩu hiệu "Non sông liền một dải - Niềm tin chiến thắng" quy tụ tất cả các đội mạnh trên cả nước, vốn quen thuộc với làng xe đạp chuyên nghiệp, bao gồm: TP.HCM - Vinama, Tập đoàn Lộc Trời, Dược Domesco Đồng Tháp, Quân khu 7, Hà Nội, Kenda Đồng Nai, Bình Dương... Yêu cầu: Cuộc đua xe đạp đã quy tụ 100 đội xe đạp chuyên nghiệp trên cả nước tham gia. Bằng chứng đã thu thập: Chặng đua đồng đội tính giờ sẽ diễn ra tại Quảng Ngãi. Điểm đặc biệt của giải đua năm nay là ngoài lộ trình lên Tây Nguyên và vòng xuống

Hình 10: Ví dụ về thất bại trong việc truy xuất bằng chứng.

- **Semantic Ambiguity:** Issues arising from context with ambiguous, verbose, or complex data, leading to interpretive difficulties (as shown in Figure 11).

Semantic Ambiguity

Context: ...Bên cạnh đó, Sở cũng yêu cầu các cơ sở giáo dục phối hợp với lực lượng chức năng tại địa phương đảm bảo trật tự, an toàn cho học sinh, sinh viên tại khu vực cổng trường.
(In addition, the Department also requested educational institutions to collaborate with local authorities to ensure order and safety for students in the school gate area.)

Claim: Sở cũng yêu cầu các cơ sở giáo dục phối hợp với lực lượng chức năng tại địa phương đảm bảo trật tự, an toàn cho học sinh, sinh viên tại những khu vực đông đúc gần trường.
(The department also requested educational institutions to collaborate with local authorities to ensure order and safety for students in crowded areas near schools.)

Gold labels: NEI **Gemma Prediction:** Refute

Figure 11: Examples of Semantic Ambiguity.

- **Inference Hallucination:** Incorrect classifications produced by the model, despite the correct extraction and availability of relevant evidence (as shown in Figure 12).

Inference Hallucination

Context: (Chinhphu.vn) – Việt Nam và Trung Quốc sẽ tiếp tục hợp tác chặt chẽ cùng nhau thúc đẩy du lịch hai nước phục hồi và phát triển lành mạnh….
((Chinhphu.vn) - Vietnam and China will continue to work closely together to promote the recovery and healthy development of tourism in both countries.)

Claim: Việt Nam và Trung Quốc sẽ tiếp tục hợp tác chặt chẽ trong lĩnh vực nông nghiệp.
(Vietnam and China will continue to strengthen cooperation in agriculture.)

Retrieved Evidence: (Chinhphu.vn) – Việt Nam và Trung Quốc sẽ tiếp tục hợp tác chặt chẽ cùng nhau thúc đẩy du lịch hai nước phục hồi và phát triển lành mạnh….
((Chinhphu.vn) - Vietnam and China will continue to work closely together to promote the recovery and healthy development of tourism in both countries.)

Gold labels: Refute **Gemma Prediction:** NEI

Figure 12: Examples of Inference Hallucination.

- **Complex Inferential Chain:** Errors resulting from the necessity to synthesize insights across multiple sources or evidences through sequential reasoning (as shown in Figure 13).
- **Labeling Error:** Issues stemming from inaccuracies or inconsistencies introduced during the manual data labeling process.

L Additional Qualitative Analysis

To obtain insights into the performance of language models, we conducted an in-depth analysis considering various factors such as the length of the context, the topic of discussion, the volume of training data, and the duration of model training.

Effects of Context Length We initiated our investigation by analyzing the test results with respect to the length of the context (see Figure 14). Notably, PhoBERT$_{large}$ and XLM-R$_{large}$ perform well when analyzing shorter texts (0-100

Complex Inferential Chain

Context: ...Rạng sáng 6/2, trận động đất độ lớn 7,8 có tâm chấn tại Thổ Nhĩ Kỳ đã gây thiệt hạilớn tại nước này và nước láng giềng Syria. Tính đến 16h ngày 12/2 (giờ Việt Nam), trận động đất này đã cướp đi sinh mạng của hơn 29.000 người tại cả hai nước, trong đó có 24.617 người tại Thổ Nhĩ Kỳ và hơn 4.500 người tại Syria, trong khi có hàng chục nghìn người bị thương.
(Early morning on February 6th, a 7.8 magnitude earthquake centered in Turkey struck, causing widespread devastation in both Turkey and neighboring Syria. As of 4 PM on February 12th (Vietnam time), the earthquake has claimed the lives of over 29,000 people in both countries, including 24,617 in Turkey and over 4,500 in Syria, while tens of thousands have been injured)

Claim: Trận động đất độ lớn 7,8 có tâm chấn tại Thổ Nhĩ Kỳ đã gây thiệt hại lớn tại nước này và hai nước láng giềng là Bulgaria và Syria, có hàng chục nghìn người bị thương, cướp đi sinh mạng của hơn 29.000 người.
(The 7.8 magnitude earthquake centered in Turkey has caused widespread devastation in the country and its neighboring nations, Bulgaria and Syria. The disaster has left tens of thousands injured and tragically claimed the lives of over 29,000 people.)

Gold labels: NEI **Gemma Prediction:** Refute

Figure 13: Examples of Complex Inferential Chain.

words). However, their performance declines as text length increases, particularly in the 400-500 and 500-600 word ranges, suggesting that longer texts may pose challenges for these models. In contrast, Gemma and Gemini exhibit more consistent performance across different text lengths, showing only minor fluctuations. This stability suggests their potential suitability for tasks involving a wide range of text lengths, where maintaining accuracy is crucial. The consistent performance of Gemma and Gemini across various text lengths is particularly advantageous for fact-checking, which often involves analyzing claims of different lengths, from short social media posts to longer articles.

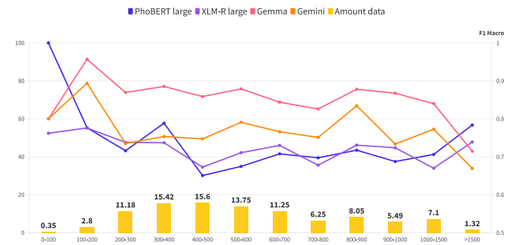


Figure 14: The effect of the length context on test set.

Effects of Topic Further analysis focused on the impact of topics on model performance, as illustrated in Figure 15. Gemma consistently outperforms other models across most topics, excelling particularly in the “Science”, “National Security”, and "Culture" categories. Gemini generally performs the second best, closely following Gemma in most areas but showing a slight dip in “National security” and “Entertainment”. While not as strong overall, PhoBERT$_{large}$ and XLM-R$_{large}$ have their strengths: PhoBERT$_{large}$ performs notably well in “Politics”, benefiting from being pre-trained on a large Vietnamese dataset that provides an advantage in

• Mơ hồ ngữ nghĩa: Các vấn đề phát sinh từ bối cảnh với dữ liệu mơ hồ, dài dòng hoặc phức tạp, dẫn đến khó khăn trong việc diễn giải (như được minh họa trong Hình 11).

viên tại khu vực cổng trường. (Ngoài ra, Sở cũng yêu cầu các cơ sở giáo dục phối hợp với chính quyền địa phương để đảm bảo trật tự và an toàn cho học sinh trong khu vực cổng trường.) Yêu cầu: Sở cũng yêu cầu các cơ sở giáo dục phối hợp với lực lượng chức năng tại địa phương đảm bảo trật tự, an toàn cho học sinh, sinh viên tại những khu vực đông đúc gần trường. (Sở cũng yêu cầu các cơ sở giáo dục phối hợp với chính quyền địa phương để đảm bảo trật tự và an toàn cho học sinh ở những khu vực đông đúc gần trường.) Nhãn vàng: NEI Dự đoán của Gemma: Bác bỏ

Hình 11: Ví dụ về mơ hồ ngữ nghĩa.

• Ảo giác suy diễn: Các phân loại sai do mô hình tạo ra, mặc dù việc trích xuất chính xác và sẵn có bằng chứng liên quan (như được minh họa trong Hình 12).

((Chinhphu.vn) - Vietnam and China will continue to work closely together to promote the recovery and healthy development of tourism in both countries.) Khẳng định: Việt Nam và Trung Quốc sẽ tiếp tục hợp tác chặt chẽ trong lĩnh vực nông nghiệp. (Vietnam and China will continue to strengthen cooperation in agriculture.) Bằng chứng trích dẫn: (Chinhphu.vn) – Việt Nam và Trung Quốc sẽ tiếp tục hợp tác chặt chẽ cùng nhau thúc đẩy du lịch hai nước phục hồi và phát triển lành mạnh…. ((Chinhphu.vn) - Vietnam and China will continue to work closely together to promote the recovery and healthy development of tourism in both countries.) Nhãn vàng: Bác bỏ Dự đoán của Gemma: NEI

Hình 12: Ví dụ về Ảo tưởng Suy luận.

• Chuỗi Suy Luận Phức Tạp: Các lỗi phát sinh từ sự cần thiết phải tổng hợp các hiểu biết từ nhiều nguồn hoặc bằng chứng thông qua lập luận tuần tự (như được thể hiện trong Hình 13).

• Lỗi Gán Nhãn: Các vấn đề phát sinh từ những sai sót hoặc không nhất quán được tạo ra trong quá trình gán nhãn dữ liệu thủ công.

L Phân tích định tính bổ sung

Để có được những hiểu biết về hiệu suất của các mô hình ngôn ngữ, chúng tôi đã tiến hành một phân tích sâu sắc xem xét các yếu tố khác nhau như độ dài của bối cảnh, chủ đề thảo luận, khối lượng dữ liệu huấn luyện và thời gian huấn luyện mô hình.

Ảnh hưởng của độ dài ngữ cảnh Chúng tôi bắt đầu cuộc nghiên cứu của mình bằng cách phân tích kết quả kiểm tra liên quan đến độ dài của ngữ cảnh (xem Hình 14). Đặc biệt, PhoBERT^{large} và XLM-R^{large} hoạt động tốt khi phân tích các văn bản ngắn hơn (0-100

Chuỗi suy luận phức tạp

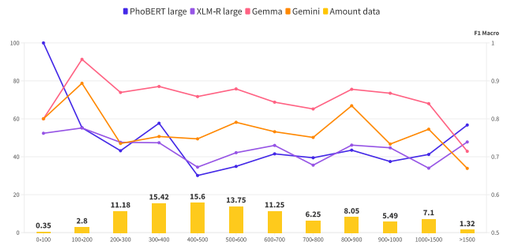
Bối cảnh: ...Rạng sáng 6/2, trận động đất có cường độ 7,8 với tâm chấn ở Thổ Nhĩ Kỳ has caused great damage in this country and neighboring Syria. As of 4 PM on 12/2 (giờ Việt Nam), trận động đất này đã cướp đi sinh mạng của hơn 29.000 people in both countries, including 24,617 people in Turkey and more than 4,500 People in Syria, while tens of thousands are injured.
(Sáng sớm ngày 6 tháng 2, một trận động đất mạnh 7,8 độ Richter xảy ra tại Thổ Nhĩ Kỳ tấn công, gây ra sự tàn phá rộng rãi ở cả Thổ Nhĩ Kỳ và Syria láng giềng. Khi vào lúc 4 giờ chiều ngày 12 tháng 2 (theo giờ Việt Nam), trận động đất đã cướp đi sinh mạng của hơn 29.000 người ở cả hai quốc gia, bao gồm 24.617 ở Thổ Nhĩ Kỳ và hơn 4.500 tại Syria, trong khi hàng chục nghìn người đã bị thương)

Yêu cầu: Trận động đất có độ lớn 7,8 với tâm chấn tại Thổ Nhĩ Kỳ đã gây thiệt hại lớn in this country and the two neighboring countries, Bulgaria and Syria, there are tens of thousands the injured, taking the lives of over 29,000 people.
(Trận động đất có cường độ 7,8 độ Richter xảy ra tại Thổ Nhĩ Kỳ đã gây ra hậu quả rộng khắp sự tàn phá ở đất nước này và các quốc gia láng giềng của nó, Bulgaria và Syria. The thảm họa đã khiến hàng chục nghìn người bị thương và đáng tiếc đã cướp đi sinh mạng của hơn 29.000 người.)

Nhãn vàng: NEI **Dự đoán của Gemma: Phản bác**

Hình 13: Ví dụ về chuỗi suy luận phức tạp.

từ). Tuy nhiên, hiệu suất của chúng giảm khi độ dài văn bản tăng, đặc biệt trong khoảng 400-500 và 500-600 từ, cho thấy các văn bản dài hơn có thể gây khó khăn cho các mô hình này. Ngược lại, Gemma và Gemini thể hiện hiệu suất ổn định hơn trên các độ dài văn bản khác nhau, chỉ có những biến động nhỏ. Sự ổn định này gợi ý khả năng phù hợp của chúng cho các nhiệm vụ liên quan đến nhiều độ dài văn bản khác nhau, nơi việc duy trì độ chính xác là rất quan trọng. Hiệu suất nhất quán của Gemma và Gemini trên các độ dài văn bản khác nhau đặc biệt có lợi cho việc kiểm tra sự thật, vốn thường liên quan đến việc phân tích các tuyên bố có độ dài khác nhau, từ các bài đăng ngắn trên mạng xã hội đến các bài báo dài hơn.



Hình 14: Ảnh hưởng của ngữ cảnh độ dài đến tập kiểm tra.

Tác động của Chủ đề Phân tích sâu hơn tập trung vào ảnh hưởng của các chủ đề đối với hiệu suất mô hình, như minh họa trong Hình 15. Gemma liên tục vượt trội hơn các mô hình khác trên hầu hết các chủ đề, đặc biệt xuất sắc ở các mục “Khoa học”, “An ninh quốc gia” và “Văn hóa”. Gemini thường có hiệu suất thứ hai tốt nhất, chỉ sau Gemma trong hầu hết các lĩnh vực nhưng có một chút giảm sút ở “An ninh quốc gia” và “Giải trí”. Mặc dù không mạnh mẽ tổng thể, PhoBERT^{large} và XLM-R^{large} vẫn có những điểm mạnh riêng: PhoBERT^{large} hoạt động nổi bật trong “ Chính trị”, nhờ được tiền huấn luyện trên một tập dữ liệu tiếng Việt lớn mang lại lợi thế trong

this domain due to the specific vocabulary required. Conversely, XLM-R$_{large}$ shows a relative peak in the "World" category, leveraging its multilingual training data to gain an advantage over monolingual models like PhoBERT$_{large}$.

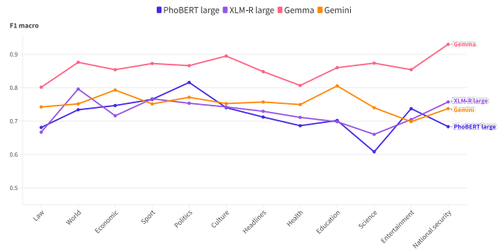


Figure 15: The effect of the topic on the test set.

Interestingly, except for Gemma, the remaining models seem to struggle with the "Science", "Law", and "Health" categories, indicating a potential area for improvement in Vietnamese fact-checking models. These categories require high accuracy and specialized vocabulary, which may explain the suboptimal performance of the other models. Additionally, there is a noticeable performance gap between Gemma and the other models in several topics, suggesting that the architecture or training data of Gemma might be better suited for fact-checking Vietnamese across diverse topics.

Effects of Training Data Size To investigate the effect of training data size on model performance, we conducted experiments with various data subsets, including those containing 1000, 2000, 3000, 4000, and 5062 data points. Figure 16 visually represents the evaluation performance across these subsets. Note that all models demonstrated improved performance as the dataset size increased. Given that Gemini is an API-based model and cannot be trained on custom datasets, it was excluded from this analysis.

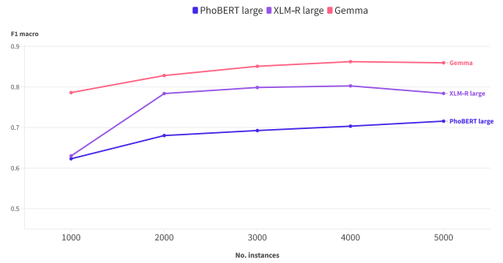


Figure 16: The impact of training data size on test set.

Our comprehensive analysis highlights the multifaceted factors influencing model performance. Gemma consistently outperforms both PhoBERT$_{large}$ and XLM-R$_{large}$ across all training sizes. While all models exhibit improved performance with increased data, F1-score of Gemma starts higher and increases at a steeper rate, especially up to 2,000 instances. Beyond this point, the rate of improvement for all models slows, indicating diminishing returns from additional training data. This consistent superiority demonstrates effectiveness of Gemma regardless of the available training data amount.

Moreover, our findings show that increasing the size of the training data improves the performance of Vietnamese models such as PhoBERT$_{large}$, highlighting the need for a robust and diverse training dataset to achieve optimal fact-checking results.

Analysis of Training Time Efficiency Finally, Figure 17 illustrates the training times of various models per epoch, measured in hours. The Mistral model has the longest training time at 1.1 hours for processing Full Context (FC), indicative of its complexity and computational demands. Gemma and Llama2 each require approximately 1.0 hour, while Llama3 requires significant time as well, at 0.94 hours. These durations illustrate the intricate computations these models undertake for handling detailed and extensive contexts.

In contrast, the XLM-R$_{large}$ model, though still demanding, is more time-efficient at only 0.1 hours, likely due to its optimized large-scale architecture. The PhoBERT$_{large}$ and XLM-R$_{base}$ models show moderate training times, striking a balance between computational efficiency and performance capabilities.

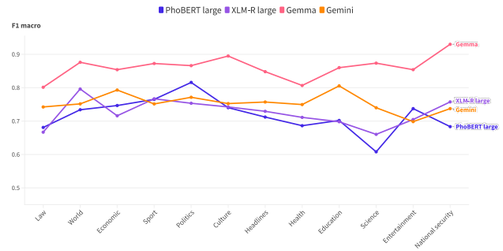
Models such as mBERT, ViBERT, and PhoBERT$_{base}$ demonstrate shorter training times, ranging from 0.0083 to 0.0139 hours. These reduced durations suggest higher operational efficiency but may also indicate a lower capacity for managing complex tasks requiring extensive contextual data.

When trained with Gold Evidence, which comprises shorter and more directly relevant sentences, Gemma still requires the most time at 0.6467 hours, although this is significantly less than with Full Context. Mistral, Llama2, and Llama3 also exhibit reduced training times at 0.32, 0.29, and 0.20 hours, respectively. This indicates that models can achieve greater efficiency when provided with concise and pertinent training data.

This analysis underscores the trade-offs between training time, model complexity, and performance, highlighting the substantial computational demands placed on advanced models to achieve high performance in Vietnamese fact-checking tasks. The reduced training times with Gold Evidence further emphasize the potential efficiency gains from using relevant training inputs.

In conclusion, our analysis elucidates the multifaceted effects of dataset characteristics and training time on the performance of language models. Larger and more diverse datasets generally improve model accuracy, particularly in specialized applications like fact-checking. However, the efficiency of model training also plays a critical role, as faster training can lead to quicker deployment and adaptation in dynamic environments. The results underscore the importance of optimizing both the data input and model architecture to achieve the best balance between performance and efficiency, which is crucial to develop robust AI systems capable of handling the intricacies of language-based tasks.

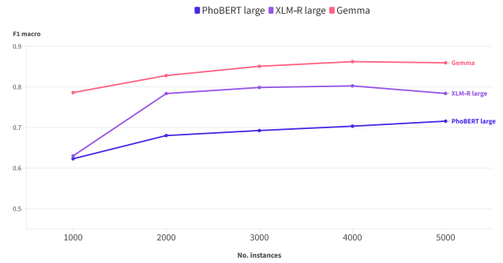
miền này do cần từ vựng cụ thể. Ngược lại, XLM-R^{large} cho thấy đỉnh tương đối trong danh mục "Thế giới", tận dụng dữ liệu đào tạo đa ngôn ngữ của nó để có lợi thế so với các mô hình đơn ngữ như PhoBERT^{large}.



Hình 15: Tác động của chủ đề đến bộ kiểm tra se t.

Thú vị thay, ngoại trừ Gemma, các mô hình còn lại dường như gặp khó khăn với các danh mục "Khoa học", "Luật" và "Sức khỏe", cho thấy đây có thể là một lĩnh vực cần cải thiện trong các mô hình kiểm chứng sự thật bằng tiếng Việt. Những danh mục này đòi hỏi độ chính xác cao và từ vựng chuyên ngành, điều này có thể giải thích tại sao hiệu suất của các mô hình khác không tối ưu. Thêm vào đó, có một khoảng cách hiệu suất rõ rệt giữa Gemma và các mô hình khác ở một số chủ đề, gợi ý rằng kiến tr úc hoặc dữ liệu huấn luyện của Gemma có thể phù hợp hơn cho việc kiểm chứng sự thật bằng tiếng Việt trên các chủ đề đa dạng.

Ảnh hưởng của Kích thước Dữ liệu Huấn luyện Để nghiên cứu ảnh hưởng của kích thước dữ liệu huấn luyện đến hiệu suất mô hình, chúng tôi đã tiến hành các thí nghiệm với nhiều tập con dữ liệu khác nhau, bao gồm các tập có 1000, 2000, 3000, 4000 và 5062 điểm dữ liệu. Hình 16 minh họa trực quan hiệu suất đánh giá trê n các tập con này. Lưu ý rằng tất cả các mô hình đều cho thấy hiệu suất được cải thiện khi kích thước tập dữ liệu tăng lên. Vì Gemini là một mô hình dựa trên API và không thể được huấn luyện trên các tập dữ liệu tùy chỉnh, nên nó đã bị loại khỏi phân tích này.



Hình 16: Tác động của kích thước dữ liệu huấn luyện lên tập kiểm tra.

Phân tích toàn diện của chúng tôi làm nổi bật các yếu tố đa diện ảnh hưởng đến hiệu suất của mô hình. Gemma liên tục vượt trội hơn cả PhoBERT^{large} và XLM-R^{large} trên tất cả các kích thước dữ liệu huấn luyện. Trong khi tất cả các mô hình đều thể hiện hiệu suất cải thiện khi tăng dữ liệu, điểm F1 của Gemma bắt đầu ở mức cao hơn và tăng với tốc độ dốc hơn, đặc biệt là lên đến 2.000 trường hợp. Vượt quá điểm này, tốc độ cải thiện của tất cả các mô hình chậm lại, cho thấy lợi nhuận giảm dần từ dữ liệu huấn luyện bổ sung. Sự vượt trội nhất quán này chứng tỏ hiệu quả của Gemma bất kể lượng dữ liệu huấn luyện có sẵn.

Hơn nữa, các phát hiện của chúng tôi cho thấy việc tăng kích thước dữ liệu huấn luyện cải thiện hiệu suất của các mô hình tiếng Việt như PhoBERT^{large}, nhấn mạnh nhu cầu về một bộ dữ liệu huấn luyện đa dạng và vững chắc để đạt được kết quả kiểm tra sự thật tối ưu.

Phân tích Hiệu quả Thời gian Đào tạo Cuối cùng, Hình 17 minh họa thời gian đào tạo của các mô hình khác nhau cho mỗi epoch, được đo bằng giờ. Model Mistral có thời gian đào tạo lâu nhất là 1,1 giờ để xử lý Full Context (FC), cho thấy độ phức tạp và yêu cầu tính toán của nó. Gemma và Llama2 mỗi mô hình cần khoảng 1,0 giờ, trong khi Llama3 cũng mất thời gian đáng kể, ở mức 0,94 giờ. Những khoảng thời gian này minh họa các phép tính phức tạp mà các mô hình này thực hiện để xử lý các ngữ cảnh chi tiết và rộng.

Ngược lại, mô hình XLM-R^{large} , mặc dù vẫn đòi hỏi nhiều, nhưng lại tiết kiệm thời gian hơn chỉ với 0,1 giờ, có khả năng là do kiến trúc quy mô lớn được tối ưu hóa của nó. Các mô hình PhoBERT^{large} và XLM-R$_{base}$ cho thấy thời gian huấn luyện vừa phải, tạo ra sự cân bằng giữa hiệu quả tính toán và khả năng t hực thi.

Các mô hình như mBERT, ViBERT và PhoBERT$_{base}$ cho thấy thời gian đào tạo ngắn hơn, dao động từ 0,0083 đến 0,0139 giờ. Những khoảng thời gian giảm này cho thấy hiệu quả hoạt động cao hơn nhưng cũng có thể chỉ ra khả năng xử lý các tác vụ phức tạp yêu cầu dữ liệu ngữ cảnh lớn thấp hơn.

Khi được đào tạo với Bằng Chứng Vàng, bao gồm các câu ngắn hơn và liên quan trực tiếp hơn, Gemma vẫn cần nhiều thời gian nhất với 0,6467 giờ, mặc dù điều này ít hơn đáng kể so với khi sử dụng Toàn bộ Bối cảnh. Mistral, Llama2 và Llama3 cũng cho thấy thời gian đào tạo giảm, lần lượt là 0,32, 0,29 và 0,20 giờ. Điều này cho thấy các mô hình có thể đạt được hiệu quả cao hơn khi được cung cấp dữ liệu đào tạo ngắn gọn và phù hợp.

Phân tích này nhấn mạnh những đánh đổi giữa thời gian đào tạo, độ phức tạp của mô hình và hiệu suất, làm nổi bật những yêu cầu tính toán đáng kể đặt ra cho các mô hình tiên tiến để đạt hiệu suất cao trong các nhiệm vụ kiểm tra sự thật bằng tiếng Việt. T hời gian đào tạo giảm khi sử dụng Bằng chứng Vàng càng nhấn mạnh những khả năng cải thiện hiệu quả từ việc sử dụng các đầu vào đào tạo có liên quan.

Tóm lại, phân tích của chúng tôi làm sáng tỏ các tác động đa diện của các đặc điểm tập dữ liệu và thời gian huấn luyện lên hiệu suất của các mô hình ngôn ngữ. Các tập dữ liệu lớn hơn và đa dạng hơn nhìn chung cải thiện độ chính xác của mô hình, đặc biệt trong các ứng dụng chuyên biệt như kiểm tra sự thật. Tuy nhiên, hiệu quả của việc huấn luyện mô hình cũng đóng một vai trò quan trọng, vì huấn luyện nhanh hơn có thể dẫn đến việc t riển khai và thích ứng nhanh hơn trong các môi trường năng động. Các kết quả nhấn mạnh tầm quan trọng của việc tối ưu hóa cả đầu vào dữ liệu lẫn kiến trúc mô hình để đạt được sự cân bằng tốt nhất giữa hiệu suất và hiệu quả, điều này rất quan trọng để phát triển các hệ thống AI mạnh mẽ có khả năng xử lý các sự phức tạp của các nhiệm vụ dựa trên ngôn ngữ.

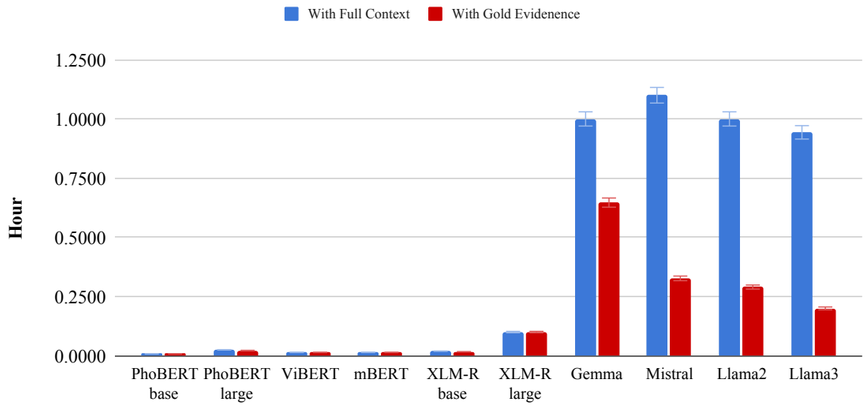
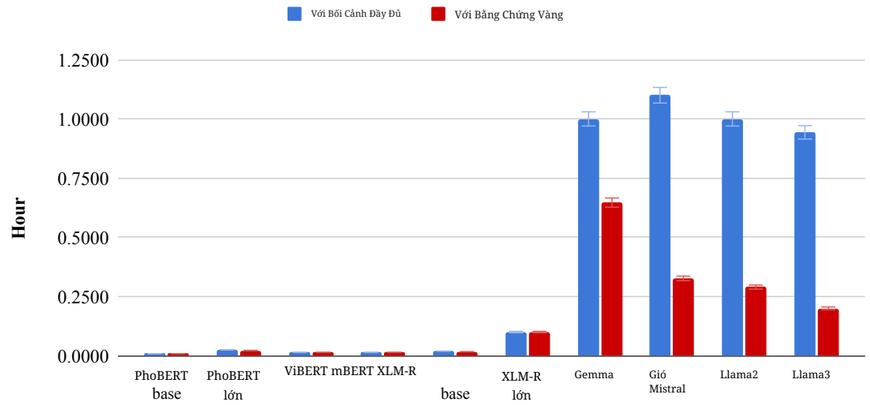


Figure 17: The comparison of training times per epoch for various baseline models.

M Scientific Artifacts

The licenses for all the models and software used in this paper are listed in parentheses: Beautiful Soup 4 (MIT License), Selenium (Apache License 2.0), Fleiss Kappa (BSD License), mBERT (Apache License 2.0), ViBERT (Apache License 2.0), PhoBERT (MIT License), XLM-R (Apache License 2.0), VnCoreNLP (Apache License 2.0), Unsloth (Apache License 2.0), LoRa (Apache License 2.0), F1-score (BSD License), BM25 (MIT License), SBERT (Apache License 2.0), Gemma (Apache License 2.0), Mistral (Apache License 2.0), Llama3 (Apache License 2.0), Llama2 (Apache License 2.0) Gemini 1.5 Flash (Proprietary License), Label Studio (Apache License 2.0)



Hình 17: So sánh thời gian huấn luyện mỗi epoch cho các mô hình cơ sở khác nhau.

Hiện vật Khoa học M

Các giấy phép cho tất cả các mô hình và phần mềm được sử dụng trong bài báo này được liệt kê trong ngoặc: Beautiful Soup 4 (Giấy phép MIT), Selenium (Giấy phép Apache 2.0), Fleiss Kappa (Giấy phép BSD), mBERT (Giấy phép Apache 2.0), ViBERT (Giấy phép Apache 2.0), PhoBERT (Giấy phép MIT), XLM-R (Giấy phép Apache 2.0), VnCoreNLP (Giấy phép Apache 2.0), Unsloth (Giấy phép Apache 2.0), LoRa (Giấy phép Apache 2.0), F1-score (Giấy phép BSD), BM25 (Giấy phép MIT), SBERT (Giấy phép Apache 2.0), Gemma (Giấy phép Apache 2.0), Mistral (Giấy phép Apache 2.0), Llama3 (Giấy phép Apache 2.0), Llama2 (Giấy phép Apache 2.0), Gemini 1.5 Flash (Giấy phép độc quyền), Label Studio (Giấy phép Apache 2.0)