

CoVer: Conflict-Aware Claim Verification

Shuning Zhang^{1,*}, Dai Shi^{2,*}, Bohao Chu³, Hui Wang³, Yuwei Chuai^{4,†},
Yifan Wang⁵, Jingruo Chen⁶, Simin Li⁷, Xin Yi^{1,8,†}, Hewu Li¹

¹Tsinghua University, ²Tongji University, ³University of Duisburg-Essen,

⁴University of Luxembourg, ⁵University of Washington, ⁶Cornell University, ⁷Beihang University,

⁸Beijing Academy of Artificial Intelligence

yuwei.chuai@uni.lu, yixin@tsinghua.edu.cn

*Equal contribution. †Corresponding authors.

Abstract

Social media fact-checking has long been challenged by evidence-level and aggregation-level conflicts, where erroneous evidence mimics authoritative news sources. To capture this challenge and support conflict verification tasks, we present *ContraNote*, a large-scale real-world dataset curated from X’s Community Notes system. It includes 33,686 posts for evaluating evidence-level conflict resolution, and 54,474 instances for evaluating aggregation-level prioritization. Additionally, we propose *CoVer*, a factual adjudication framework with three-stage pipelines: evidence schema normalization, factual consensus and support verification. This prioritizes evidence over noise to prevent it from compromising the final verdict. Technical evaluations show that CoVer achieves strong performance compared with state-of-the-art baselines across ContraNote (86.0% Acc., 68.0% mac. F1, 64.5 bal. Acc. on Conflict; and 88.5% Acc., 88.5 mac. F1 and 89.2 bal. Acc. on Prioritization), CONFACT-HumC (88.4% Acc.) and CONFACT-ModC (89.4% Acc.).

1 Introduction

Developing effective automated fact-checking methods is increasingly important to mitigate the spread of misinformation on social media platforms at scale (Choi and Ferrara, 2024; Augenstein et al., 2024). Modern systems commonly adopt a decomposition-aggregation pipeline, which breaks complex claims into atomic sub-claims, verifies each subclaim against external knowledge sources, and synthesizes verdicts to determine overall veracity (Wang et al., 2024). Retrieval-Augmented Generation (RAG) plays an important role in this pipeline by enabling Large Language Models (LLMs) to ground their reasoning in external evidence retrieved from the open web (Lewis et al., 2020).

However, this pipeline frequently encounters conflicts that compromise verdict accuracy. We

categorize these conflicts into two distinct levels: (i) **evidence-level conflict**, where retrieved documents from different sources take opposing stances on the same fact, (ii) **aggregation-level conflict**, where sub-claims within a single complex claim provide contradictory signals that must be prioritized and reconciled.




Figure 1: An illustration of conflicting evidence.

These challenges are exemplified in a social media claim asserting that a newly published public-health study links COVID-19 vaccines to a rise in excess deaths (Figure 1). During verification, retrieval may surface an evidence-level conflict: a widely shared headline interprets the study as “vindicating” prior anti-vaccine claims, while statements from the publishing journal and epidemiologists clarify that the study has no such causal relationship. Besides, an aggregation-level conflict arises when the claim is decomposed into sub-claims (e.g., trends in excess mortality vs. implied causality), yielding contradictory signals that must be weighed against one another. Here, aggregation-level conflict does not necessarily mean that sub-

CoVer: Xác Minh Yêu Cầu Nhận Thức Mâu Thuẫn

Shuning Zhang^{1,*}, Dai Shi^{2,*}, Bohao Chu³, Hui Wang³, Yuwei Chuai^{4,†}, Yifan Wang⁵, Jingruo Chen⁶,
Simin Li⁷, Xin Yi^{1,8,†}, Hewu Li¹ Đại học Tsinghua, ²Đại học Tongji, ³Đại học Duisburg-Essen, ⁴Đại học Luxembourg, ⁵Đại học Washington, ⁶Đại học Cornell, ⁷Đại học Beihang, ⁸Học viện Trí tuệ Nhân tạo Bắc Kinh yuwei.chuai@uni.lu, yixin@tsinghua.edu.cn*Đóng góp như nhau. †Tác giả liên hệ.

Tóm tắt


Việc kiểm tra sự thật trên mạng xã hội từ lâu đã gặp phải những thách thức liên quan đến xung đột ở mức bằng chứng và mức tổng hợp, nơi các bằng chứng sai lệch bắt chước các nguồn tin uy tín. Để nắm bắt thách thức này và hỗ trợ các nhiệm vụ xác minh xung đột, chúng tôi giới thiệu ContraNote, một tập dữ liệu thực tế quy mô lớn được chọn lọc từ hệ thống Ghi chú Cộng đồng của X. Nó bao gồm 33.686 bài đăng để đánh giá giải quyết xung đột ở mức bằng chứng, và 54.474 trường hợp để đánh giá ưu tiên ở mức tổng hợp. Ngoài ra, chúng tôi đề xuất CoVer, một khuôn khổ phán quyết thực tế với ba giai đoạn: chuẩn hóa sơ đồ bằng chứng, đồng thuận thực tế và xác minh sự hỗ trợ. Điều này ưu tiên bằng chứng hơn tiếng ồn để ngăn chặn việc làm ảnh hưởng đến phán quyết cuối cùng. Các đánh giá kỹ thuật cho thấy CoVer đạt hiệu suất mạnh so với các phương pháp cơ sở tiên tiến trên ContraNote (86,0% chính xác, 68,0 % F1 trung bình, 64,5% chính xác cân bằng trên Xung đột; và 88,5% chính xác, 88,5% F1 trung bình và 89,2% chính xác cân bằng trên Ưu tiên), CONFACT-

1 Giới thiệu

Phát triển các phương pháp kiểm tra sự thật tự động hiệu quả ngày càng trở nên quan trọng để giảm thiểu sự lan truyền thông tin sai lệch trên các nền tảng mạng xã hội với quy mô lớn (Choi và Ferrara, 2024; Augenstein và cộng sự, 2024). Các hệ thống hiện đại thường áp dụng một chuỗi xử lý phân rã-tổng hợp, chia các tuyên bố phức tạp thành các tuyên bố con nguyên tử, kiểm tra từng tuyên bố con dựa trên các nguồn kiến thức bên ngoài, và tổng hợp kết quả để xác định độ xác thực tổng thể (Wang và cộng sự, 2024). Kỹ thuật Tạo nội dung Tăng cường Truy xuất (RAG) đóng vai trò quan trọng trong chuỗi này bằng cách cho phép các Mô hình Ngôn ngữ Lớn (LLMs) căn cứ lập luận của mình trên bằng chứng bên ngoài được truy xuất từ web mở (Lewis và cộng sự, 2020).

Tuy nhiên, quy trình này thường xuyên gặp phải xung đột làm ảnh hưởng đến độ chính xác của phán quyết. Chúng tôi

phân loại những xung đột này thành hai cấp độ rõ rệt: (i) xung đột cấp độ bằng chứng, nơi các tài liệu được truy xuất từ các nguồn khác nhau đưa ra quan điểm đối lập về cùng một sự kiện, (ii) xung đột cấp độ tổng hợp, nơi các tiểu tuyên bố trong một tuyên bố phức tạp duy nhất đưa ra các tín hiệu mâu thuẫn cần được ưu tiên và hòa giải.



Hình 1: Minh họa về những bằng chứng mâu thuẫn.

Những thách thức này được minh họa trong một tuyên bố trên mạng xã hội cho rằng một nghiên cứu y tế công cộng mới được công bố liên kết vắc-xin COVID-19 với sự gia tăng các ca tử vong vượt mức (Hình 1). Trong quá trình xác minh, việc thu thập thông tin có thể phát hiện ra một xung đột về mức độ bằng chứng: một tiêu đề được chia sẻ rộng rãi diễn giải nghiên cứu này là “chứng minh” các tuyên bố phản đối vắc-xin trước đó, trong khi các phát ngôn từ tạp chí công bố nghiên cứu và các nhà dịch tễ học làm rõ rằng nghiên cứu này không có mối quan hệ nhân quả như vậy. Bên cạnh đó, một xung đột ở mức tổng hợp xuất hiện khi tuyên bố được phân tách thành các tuyên bố phụ (ví dụ, xu hướng tử vong vượt mức so với nguyên nhân gây ý), tạo ra các tín hiệu mâu thuẫn cần được cân nhắc lẫn nhau. Ở đây, xung đột ở mức tổng hợp không nhất thiết có nghĩa là các tuyên bố phụ

claims contradict one another. Different subclaims may receive local verdicts whose logical implications conflict with the overall claim. For instance, evidence may support the observation that excess mortality increased while refuting the implied causal attribution to COVID-19 vaccination. The conflict therefore arises when local verdicts are aggregated.

Resolving such contradictions is crucial, yet evidence conflict on social media differs from general conflicts in two aspects: (i) *Intentionality*: Unlike general search conflicts that often stem from outdated data, social media conflicts are frequently adversarial, with misinformation crafted to mimic authoritative style. (ii) *Popularity bias*: False narratives on social media may circulate faster than factual corrections. Methods relying on frequency-based aggregation struggle around these issues.

To bridge this gap, we introduce *ContraNote*, a real-world dataset derived from X’s Community Notes system. ContraNote captures real-world conflicts by identifying posts that received opposed debunking statements from crowdsourced contributors. We filtered over two million notes to construct two tasks: a conflict task comprising 33,686 posts to evaluate support/refutation, and a prioritization task comprising 54,474 posts to evaluate the identification of high-quality evidence.

We further propose *CoVer*, a framework to parse and adjudicate conflicting evidence by prioritizing evidence over noise. Unlike algorithms that aggregate all evidence at once, CoVer uses a structured pipeline with three modules: evidence schema normalization, factual consensus, and support verification. This facilitates individual scrutinization and filters out noise such as quoted rumors, headlines, or weakly relevant statements.

Technical evaluations show that CoVer outperforms state-of-the-art (SOTA) baselines across various datasets. On ContraNote Conflict and Prioritization, CoVer achieves accuracies of 86.0% and 88.5%, with corresponding bal. Acc. of 64.5% and 89.2%. It also achieves 88.4% accuracy on CONFACT-HumC and 89.4% on -ModC. Ablation studies further confirm the contribution of each module in our proposed framework. Together, this paper makes three contributions:

- We propose the CoVer framework, an algorithm featuring evidence schema normalization, factual consensus, and support verification modules to effectively resolve evidence conflicts.
- We construct ContraNote dataset, comprising

33,686 conflicting instances and 54,474 prioritization instances derived from X, providing testbeds for evaluating real-world conflicts.

- We provide empirical evidence that CoVer performs strongly relative to SOTA baselines across evidence conflict datasets.

2 Background and Related Work

2.1 Automatic Fact-checking

Traditional expert-based fact-checking faces significant challenges regarding scalability, selection bias, and public trust (Pennycook and Rand, 2019; Straub and Spradling, 2022; Chuai et al., 2025, 2026b). In response, community-based and automated alternatives have emerged as viable solutions (Kim and Walker, 2020; Quelle and Bovet, 2024; Zhang et al., 2026). Community-based fact-checking, exemplified by X’s Community Notes (X Corp., 2026), can achieve accuracy comparable to expert judgments (Allen et al., 2021), resist motivated reasoning (Epstein et al., 2020), and reach broader online communities (Micallef et al., 2020). However, it remains too slow to curb misinformation at an early stage and is subject to coordinated rating manipulation (Chuai et al., 2024, 2026a,b).

Given recent advances in LLMs, automated fact-checking frameworks show promises in identifying suspicious multimodal claims (Qi et al., 2024; Zhou et al., 2024), verifying their veracity (Wang and Shu, 2023), and generating explanations (Yue et al., 2024; He et al., 2023; Zeng and Gao, 2024) immediately after publication. Notably, De et al. (2025) explored synthesizing community notes, while we focus on evidence conflict resolution.

Beyond verification, LLMs can enhance collective decision-making (Yang et al., 2024) by aggregating diverse perspectives (Burton et al., 2024) and mapping complex opinions to consensus statements (Bakker et al., 2022). For instance, Fish et al. (2024) integrated LLMs with social choice theory to generate multiple summaries than a singular consensus. Our work differs by focusing on evidence conflict resolution.

2.2 Conflict Resolution in Fact-Checking

Truth discovery. Early conflict resolution focused on truth discovery, aiming to identify accurate information among conflicting sources by estimating source reliability (Li et al., 2016). Traditional methods used iterative probabilistic models to infer trustworthiness (Li et al., 2016; Lyu et al., 2017),

Các tuyên bố mâu thuẫn lẫn nhau. Các tuyên bố phụ khác nhau có thể nhận được những phán quyết cục bộ mà hàm ý logic của chúng mâu thuẫn với tuyên bố tổng thể. Ví dụ, bằng chứng có thể ủng hộ quan sát rằng tỷ lệ tử vong vượt mức tăng lên trong khi bác bỏ sự gán nguyên nhân ngụ ý cho việc tiêm chủng COVID-19. Do đó, xung đột phát sinh khi các phán quyết cục bộ được tổng hợp lại.

Giải quyết những mâu thuẫn như vậy là rất quan trọng, tuy nhiên xung đột thông tin trên mạng xã hội khác với xung đột chung ở hai khía cạnh: (i) Cố ý: Khác với xung đột tìm kiếm chung thường xuất phát từ dữ liệu lỗi thời, xung đột trên mạng xã hội thường mang tính đối kháng, với thông tin sai lệch được tạo ra để bắt chước phong cách chính thống. (ii) Thiên vị phổ biến: Các câu chuyện sai lệch trên mạng xã hội có thể lan truyền nhanh hơn các chỉnh sửa dựa trên sự thật. Các phương pháp dựa trên tập hợp theo tần suất gặp khó khăn với những vấn đề này.

Để thu hẹp khoảng cách này, chúng tôi giới thiệu ContraNote, một bộ dữ liệu thực tế được tạo ra từ hệ thống Ghi chú Cộng đồng của X. ContraNote nắm bắt các xung đột trong thế giới thực bằng cách xác định các bài đăng nhận được các tuyên bố bác bỏ đối lập từ những người đóng góp từ cộng đồng. Chúng tôi đã lọc hơn hai triệu ghi chú để xây dựng hai nhiệm vụ: một nhiệm vụ xung đột gồm 33.686 bài đăng để đánh giá việc ủng hộ/bác bỏ, và một nhiệm vụ ưu tiên gồm 54.474 bài đăng để đánh giá việc xác định các bằng chứng chất lượng cao.

Chúng tôi đề xuất thêm CoVer, một khuôn khổ để phân tích và xử lý xung đột bằng cách ưu tiên bằng chứng hơn là nhiễu. Khác với các thuật toán tổng hợp tất cả bằng chứng cùng một lúc, CoVer sử dụng một quy trình có cấu trúc với ba mô-đun: chuẩn hóa lược đồ bằng chứng, đồng thuận thực tế và xác minh hỗ trợ. Điều này tạo thuận lợi cho việc kiểm tra từng phần riêng lẻ và loại bỏ những nhiễu như tin đồn trích dẫn, tiêu đề, hoặc các tuyên bố có liên quan yếu.

Các đánh giá kỹ thuật cho thấy CoVer vượt trội hơn các mô hình cơ sở tiên tiến (SOTA) trên nhiều tập dữ liệu khác nhau. Trên ContraNote Conflict và Prioritization, CoVer đạt độ chính xác lần lượt là 86,0% và 88,5%, với độ chính xác cân bằng tương ứng là 64,5% và 89,2%. Nó cũng đạt độ chính xác 88,4% trên CONFACT-HumC và 89,4% trên -ModC. Các nghiên cứu loại bỏ lần nữa xác nhận sự đóng góp của từng mô-đun trong khuôn khổ đề xuất của chúng tôi. Nhìn chung, bài báo này đưa ra ba đóng góp:

- Chúng tôi đề xuất khung CoVer, một thuật toán có các mô-đun chuẩn hóa sơ đồ bằng chứng, đồng thuận thực tế và xác minh hỗ trợ để giải quyết hiệu quả các xung đột bằng chứng.
- Chúng tôi xây dựng bộ dữ liệu ContraNote, bao gồm

33.686 trường hợp mâu thuẫn và 54.474 trường hợp ưu tiên được tạo ra từ X, cung cấp các môi trường thử nghiệm để đánh giá các xung đột trong thế giới thực.

- Chúng tôi cung cấp bằng chứng thực nghiệm rằng CoVer hoạt động mạnh mẽ so với các chuẩn mực SOTA trên các tập dữ liệu xung đột bằng chứng.

2 Bối cảnh và Công trình Liên quan

2.1 Kiểm tra sự thật tự động

Việc kiểm tra sự thật dựa trên chuyên gia truyền thống phải đối mặt với những thách thức đáng kể về khả năng mở rộng, thiên lệch trong việc lựa chọn và niềm tin của công chúng (Pennycook và Rand, 2019; Straub và Spradling, 2022; Chuai et al., 2025, 2026b). Đáp lại, các phương án dựa trên cộng đồng và tự động đã xuất hiện như những giải pháp khả thi (Kim và Walker, 2020; Quelle và Bovet, 2024; Zhang et al., 2026). Kiểm tra sự thật dựa trên cộng đồng, được minh họa bởi Ghi chú Cộng đồng của X (X Corp., 2026), có thể đạt độ chính xác tương đương với đánh giá của chuyên gia (Allen et al., 2021), chống lại lý luận theo động cơ (Epstein et al., 2020), và tiếp cận các cộng đồng trực tuyến rộng hơn (Micallef et al., 2020). Tuy nhiên, phương pháp này vẫn quá chậm để ngăn chặn thông tin sai lệch ở giai đoạn đầu và có thể bị thao túng đánh giá có kế hoạch (Chuai et al., 2024, 2026a,b).

Trước những tiến bộ gần đây trong các mô hình ngôn ngữ lớn (LLMs), các khung kiểm tra sự thật tự động cho thấy tiềm năng trong việc xác định các tuyên bố đa phương tiện đáng ngờ (Qi và cộng sự, 2024; Zhou và cộng sự, 2024), xác minh tính xác thực của chúng (Wang và Shu, 2023), và tạo ra các lời giải thích (Yue và cộng sự, 2024; He và cộng sự, 2023; Zeng và Gao, 2024) ngay sau khi xuất bản. Đáng chú ý, De và cộng sự (2025) đã nghiên cứu việc tổng hợp các ghi chú cộng đồng, trong khi chúng tôi tập trung vào việc giải quyết xung đột bằng chứng.

Ngoài việc xác minh, LLMs có thể nâng cao khả năng ra quyết định tập thể (Yang et al., 2024) bằng cách tổng hợp các quan điểm đa dạng (Burton et al., 2024) và chuyển đổi các ý kiến phức tạp thành các tuyên bố đồng thuận (Bakker et al., 2022). Chẳng hạn, Fish et al. (2024) đã tích hợp LLMs với lý thuyết lựa chọn xã hội để tạo ra nhiều bản tóm tắt thay vì một sự đồng thuận duy nhất. Công trình của chúng tôi khác ở chỗ tập trung vào giải quyết xung đột bằng chứng.

2.2 Giải quyết xung đột trong kiểm tra sự thật

Khám phá sự thật. Giải quyết xung đột sớm tập trung vào việc khám phá sự thật, nhằm xác định thông tin chính xác giữa các nguồn mâu thuẫn bằng cách ước lượng độ tin cậy của nguồn (Li và cộng sự, 2016). Các phương pháp truyền thống sử dụng các mô hình xác suất lặp đi lặp lại để suy luận độ tin cậy (Li và cộng sự, 2016; Lyu và cộng sự, 2017)

later evolving into neural frameworks, such as De-ClarE, which aggregates external evidence and source credibility via attention mechanisms (Popat et al., 2018). Unlike these methods that focus on source credibility, our approach models consensus among conflicting evidence items.

Taxonomy and biases in knowledge conflicts. With the adoption of LLMs, the focus shifted to knowledge conflicts, which can be classified as intra-context, inter-context and parametric discrepancies (Su et al., 2024; Xie et al., 2023; Ming et al., 2024). When resolving these conflicts, LLMs exhibit notable biases: confirmation bias toward internal parametric memory (Xie et al., 2023; Su et al., 2024; Özer and Yıldız, 2025), self-generation bias favoring erroneous self-derived context over retrieved facts (Tan et al., 2024), and selection bias where LLMs detect inconsistencies via Natural Language Inference (NLI) (Jiayang et al., 2024) but arbitrarily select single evidence items without holistic synthesis (Jiayang et al., 2024). To mitigate these biases, we ground conflict resolution in recognizing evidence’s stances and resolving based on stance conflicts.

Detection and resolution frameworks. To counter LLM biases, research proposed factual consistency models for detection (Jiayang et al., 2024), and employ iterative multi-agent debates (e.g., MADAM-RAG) (Wang et al., 2025), or contrastive argument synthesis for resolution (Yue et al., 2024). Furthermore, robust resolution requires calibration and uncertainty estimation to merge conflicting and evolving evidence in temporal contexts (Wan et al., 2024; Chen et al., 2022a; Özer and Yıldız, 2025; Burton et al., 2024). Unlike frameworks designed for document retrieval and verification, we focused on reconciling contradictory evidence.

3 Problem Definition

In automated fact-checking, conflicting evidence primarily exist at two stages: the *evidence* level and the *aggregation* level. *Evidence*-level conflict occurs when retrieved documents present contradictory stances on a single fact. *Aggregation*-level conflict arises when a complex claim is decomposed into sub-claims that yield divergent verdicts. For example, a correct attribution alongside false causality requires the system to synthesize these mixed signals into a coherent conclusion.

Formally, let a claim C be decomposed into

subclaims $S = \{s_1, ..., s_n\}$. For each s_i , the system retrieves a set of evidence documents $E_i = \{e_{i,1}, ..., e_{i,m}\}$. An evidence-level conflict exists if E_i contains contradictory stance labels that simultaneously support and refute s_i . An aggregation-level conflict occurs when the set of local verdicts $V_S = \{v(s_1), ..., v(s_n)\}$ has opposing logical implications for the overall veracity of C . The objective is to learn a verification function $\mathcal{F}(C, \bigcup E_i) \rightarrow y$ that maps the claim and conflicting evidence to a final verdict $y \in \{\text{Supported, Refuted, Not Enough Information}\}$ by prioritizing evidence over noise.

4 ContraNote Dataset

We constructed the ContraNote dataset using the open-source Community Notes repository published by X (X Corp., 2025). Community Notes is a crowd-sourced misinformation debunking mechanism where qualified contributors provide additional context to evaluate the veracity of posts. The longitudinal data used in this study span from June 2021 to May 2026.

Individual posts on the platform frequently elicit multiple community notes with divergent viewpoints. Some contributors may flag a post as potentially misleading, while others may argue that it is not misleading because it is factually correct, satirical, or containing personal opinion. These conflicting perspectives on a single post create a complex environment of evidentiary contradictions. Final note selection is determined by user helpfulness ratings and algorithmic prioritization. This inherent complexity provides a unique opportunity for LLMs to learn from real-world conflicts and develop mechanisms for information prioritization.

Our initial corpus comprised 2,276,724 community notes corresponding to 1,502,486 unique posts. To isolate instances of conflict, we first identified 443,148 posts that received more than one community note. We then focused on posts containing stance contrast, defined by the two Community Notes classifications: MISINFORMED_OR_POTENTIALLY_MISLEADING and NOT_MISLEADING.

We constructed two benchmark tasks from this filtered corpus. The first, **ContraNote Conflict**, evaluates whether an original post should be supported or refuted given conflicting notes. Refuted instances are posts satisfying three conditions: (1) the notes have stance contrast, (2) it has at least one

sau này phát triển thành các khuôn khổ thần kinh, chẳng hạn như De-ClarE, tổng hợp bằng chứng bên ngoài và độ tin cậy của nguồn thông qua cơ chế chú ý (Popat et al., 2018). Không giống như các phương pháp này tập trung vào độ tin cậy của nguồn, phương pháp của chúng tôi mô hình hóa sự đồng thuận giữa các mục bằng chứng mâu thuẫn.

Phân loại và thiên lệch trong xung đột kiến thức. Với việc áp dụng LLMs, tập trung đã chuyển sang xung đột kiến thức, có thể được phân loại thành xung đột trong cùng một bối cảnh, giữa các bối cảnh và sự khác biệt tham số (Su et al., 2024; Xie et al., 2023; Ming et al., 2024). Khi giải quyết những xung đột này, LLMs thể hiện các thiên lệch đáng kể: thiên lệch xác nhận đối với bộ nhớ tham số nội bộ (Xie et al., 2023; Su et al., 2024; Özer và Yıldız, 2025), thiên lệch tự sinh ưu tiên bối cảnh do chính chúng tạo ra nhưng sai lệch so với các dữ kiện được truy xuất (Tan et al., 2024), và thiên lệch lựa chọn khi LLMs phát hiện mâu thuẫn thông qua Suy luận Ngôn ngữ Tự nhiên (NLI) (Jiayang et al., 2024) nhưng tùy ý chọn các mục chứng cứ đơn lẻ mà không tổng hợp toàn diện (Jiayang et al., 2024). Để giảm bớt các thiên lệch này, chúng tôi căn cứ giải quyết xung đột vào việc nhận diện lập trường của chứng cứ và giải quyết dựa trên xung đột lập trường.

Các khuôn khổ phát hiện và giải quyết. Để chống lại thiên kiến của LLM, các nghiên cứu đã đề xuất các mô hình nhất quán thực tế để phát hiện (Jiayang et al., 2024), và sử dụng các cuộc tranh luận lặp đi lặp lại giữa nhiều tác nhân (ví dụ, MADAM-RAG) (Wang et al., 2025), hoặc tổng hợp lập luận đối lập để giải quyết (Yue et al., 2024). Hơn nữa, việc giải quyết chắc chắn yêu cầu hiệu chuẩn và ước lượng sự không chắc chắn để hợp nhất bằng chứng mâu thuẫn và đang phát triển trong các bối cảnh thời gian (Wan et al., 2024; Chen et al., 2022a; Özer và Yıldız, 2025; Burton et al., 2024). Khác với các khuôn khổ được thiết kế cho việc truy xuất và kiểm chứng tài liệu, chúng tôi tập trung vào việc hòa giải các bằng chứng mâu thuẫn.

3 Định nghĩa vấn đề

Trong việc kiểm tra sự thật tự động, bằng chứng mâu thuẫn chủ yếu tồn tại ở hai cấp độ: cấp độ bằng chứng và cấp độ tổng hợp. Mâu thuẫn cấp độ bằng chứng xảy ra khi các tài liệu được truy xuất trình bày các quan điểm đối lập về một sự kiện duy nhất. Mâu thuẫn cấp độ tổng hợp phát sinh khi một tuyên bố phức tạp được phân tách thành các tuyên bố phụ dẫn đến những kết luận khác nhau. Ví dụ, một sự gán đúng kèm theo nguyên nhân sai yêu cầu hệ thống tổng hợp những tín hiệu lẫn lộn này thành một kết luận mạch lạc.

Một cách chính thức, hãy để một khẳng định C được phân tích thành

subclaims $S = \{s_1, ..., s_n\}$. Đối với mỗi s_i , hệ thống truy xuất một tập hợp các tài liệu chứng cứ $E_i = \{e_{i,1}, ..., e_{i,m}\}$. Một xung đột cấp bằng chứng tồn tại nếu E_i chứa các quan điểm mâu thuẫn đồng thời ủng hộ và phản bác s_i . Một xung đột cấp tổng hợp xảy ra khi tập hợp các phán quyết địa phương $V_S = \{v(s_1), ..., v(s_n)\}$ có các hệ quả logic trái ngược đối với độ chính xác tổng thể của C . Mục tiêu là học một hàm xác minh $F(C, \bigcup E_i) \rightarrow y$ ánh xạ tuyên bố và chứng cứ mâu thuẫn thành phán quyết cuối cùng $y \in \{\text{Hỗ trợ, Phản bác, Không đủ thông tin bằng cách ưu tiên chứng cứ hơn nhiều}\}$.

Bộ dữ liệu 4 ContraNote

Chúng tôi đã xây dựng bộ dữ liệu ContraNote bằng cách sử dụng kho lưu trữ Community Notes mã nguồn mở được xuất bản bởi X (X Corp., 2025). Community Notes là một cơ chế kiểm chứng thông tin sai lệch dựa trên sự đóng góp của cộng đồng, nơi các cộng tác viên đủ điều kiện cung cấp bối cảnh bổ sung để đánh giá độ xác thực của các bài đăng. Dữ liệu dài hạn được sử dụng trong nghiên cứu này kéo dài từ tháng 6 năm 2021 đến tháng 5 năm 2026.

Các bài đăng cá nhân trên nền tảng thường xuyên gọi ra nhiều ghi chú cộng đồng với các quan điểm trái ngược nhau. Một số người đóng góp có thể đánh dấu một bài đăng là có khả năng gây hiểu lầm, trong khi những người khác có thể tranh luận rằng bài đăng đó không gây hiểu lầm vì nó đúng về mặt thực tế, mang tính châm biếm, hoặc chứa quan điểm cá nhân. Những quan điểm mâu thuẫn này về một bài đăng duy nhất tạo ra một môi trường phức tạp của các mâu thuẫn bằng chứng. Việc lựa chọn ghi chú cuối cùng được xác định bởi đánh giá hữu ích của người dùng và sự ưu tiên thuật toán. Sự phức tạp vốn có này cung cấp một cơ hội độc đáo cho các mô hình ngôn ngữ lớn để học hỏi từ các xung đột trong thế giới thực và phát triển các cơ chế ưu tiên thông tin.

Tập hợp dữ liệu ban đầu của chúng tôi bao gồm 2.276.724 ghi chú cộng đồng tương ứng với 1.502.486 bài viết duy nhất. Để tách các trường hợp xung đột, trước tiên chúng tôi đã xác định 443.148 bài viết nhận được nhiều hơn một ghi chú cộng đồng. Sau đó, chúng tôi tập trung vào các bài viết chứa sự đối lập lập trường, được định nghĩa bởi hai phân loại Ghi chú Cộng đồng: MISINFORMED_OR_POTENTIALLY_MISLEADING và KHÔNG_MISLEADING.

Chúng tôi đã xây dựng hai nhiệm vụ chuẩn từ tập hợp dữ liệu đã được lọc này. Nhiệm vụ đầu tiên, ContraNote Conflict, đánh giá liệu một bài đăng gốc nên được ủng hộ hay bác bỏ dựa trên các ghi chú mâu thuẫn. Các trường hợp bị bác bỏ là những bài đăng đáp ứng ba điều kiện: (1) các ghi chú có quan điểm trái ngược, (2) nó có ít nhất một




Figure 2: Distributions in ContraNote, (a) distribution of misleading reasons, (b) note length by stance, (c) percentage of notes with cited sources.

note rated as CURRENTLY_RATED_HELPFUL, and (3) at least one helpful note is labeled MISINFORMED_OR_POTENTIALLY_MISLEADING. These instances correspond to claims for which the crowd-rated consensus supports active correction or refutation. This yields 27,445 *Refuted* instances. Supported instances should satisfy: (1) the notes have stance contrast, (2) it contain no helpful misleading note, and all misleading notes are rated CURRENTLY_RATED_NOT_HELPFUL, (3) the majority of its notes are labeled NOT_MISLEADING. We apply different criteria as our dataset from Community Notes have no non-misleading notes with helpful status. This process yields 6,241 *Supported* instances. **ContraNote Conflict** contains 33,686 posts, including 27,445 *Refuted* and 6,241 *Supported* instances.

The second task, **ContraNote prioritization**, evaluates whether a model can identify potentially conflicting high-quality evidence among notes. We selected posts with stance contrast that contain at least one helpful note and one non-helpful note, where non-helpful candidates include notes rated as CURRENTLY_RATED_NOT_HELPFUL or NEEDS_MORE_RATINGS. Given the post context and its set of notes, the model needs to predict which note should be prioritized. This produces a balanced benchmark of 54,474 instances over 27,237 posts, with 27,237 *Supported* target notes and 27,237 *Refuted* target notes.

As shown in Figure 2, missing context (22,615 instances) and factual errors (20,918 instances) are primary drivers of misleading claim. Refuting notes exhibit greater detail (1.77 per post) and length (289.08 characters) compared to supporting ones. Evidence link analysis reveals that news (49.1%) and social media platforms (24.6%) are major cited sources, while encyclopedic references remain secondary. This indicates that ContraNote primarily relies on heterogeneous evidence that


require provenance assessment. Qualitative coding reveals that relations between contradictory notes extend beyond direct contrasts, which include contextual, scoping and aggregation-level disagreements. Notably, *note-necessity disagreement* is the primary conflict pattern (33%), where contributors contest the necessity of moderation. Language distribution analysis shows that English constitutes the majority language (13,776, 62.98%), followed by Spanish (1,758, 8.04%) and Portuguese (1,368, 6.25%).

As shown in Table 4, ContraNote extends prior benchmarks (Augenstein et al., 2019; Schlichtkrull et al., 2023; Chen et al., 2022b) by capturing naturally occurring evidence conflicts within single posts. To evaluate label reliability, three trained annotators independently annotated on randomly sampled 500 instances, which yield high inter-rater reliability (Fleiss’ κ =0.82). Majority-vote human annotations aligned with dataset labels in 94.2% cases, validating labels’ accuracy. To account for potential bias, we analyzed using PoliticalBiasBERT, and found the dataset covered broad political orientations (18.6% left, 47.0% center, 34.4% right) and topic domains (e.g., 26.0% political/governance, 20.6% science/technology, 29.8% media/entertainment/sports). This indicates that ContraNote reflects the consensus signal generated by Community Notes mechanism. Details are all shown in Appendix B.2.

5 CoVer

5.1 Algorithm Overview

As shown in Figure 3, given a claim q and an evidence set $\mathcal{E} = \{e_i\}_{i=1}^N$, CoVer predicts a label $y \in \{\text{Supported}, \text{Refuted}\}$. This algorithm has three modules: evidence schema normalization, factual consensus, and support verification.



Hình 2: Distributions in ContraNote, (a) phân phối các lý do gây hiểu lầm, (b) độ dài ghi chú theo lập trường, (c) phân trăm của các ghi chú với nguồn.

ghi chú được đánh giá là HIỆN TẠI ĐƯỢC ĐÁNH GIÁ HỮU ÍCH, và (3) ít nhất một ghi chú hữu ích được dán nhãn SAI SỰ THẬT HOẶC CÓ THỂ GÂY HIỂU LẦM. Những trường hợp này tương ứng với các tuyên bố mà sự đồng thuận do đám đông đánh giá ủng hộ việc sửa chữa hoặc bác bỏ tích cực. Điều này tạo ra 27,445 trường hợp Bị Bác Bỏ. Các trường hợp được Hỗ Trợ nên thỏa mãn: (1) các ghi chú có sự đối lập về lập trường, (2) không chứa ghi chú hữu ích gây hiểu lầm, và tất cả các ghi chú gây hiểu lầm đều được đánh giá HIỆN TẠI ĐƯỢC ĐÁNH GIÁ KHÔNG HỮU ÍCH, (3) phần lớn các ghi chú của nó được dán nhãn KHÔNG GÂY HIỂU LẦM. Chúng tôi áp dụng các tiêu chí khác vì bộ dữ liệu của chúng tôi từ Community Notes không có ghi chú không gây hiểu lầm nào ở trạng thái hữu ích. Quá trình này tạo ra 6.241 trường hợp được Hỗ Trợ. ContraNote Conflict chứa 33.686 bài viết, bao gồm 27.445 trường hợp Bị Bác Bỏ và 6.241 trường hợp được Hỗ Trợ.

Nhiệm vụ thứ hai, ưu tiên ContraNote, đánh giá xem liệu một mô hình có thể xác định bằng chứng chất lượng cao có khả năng mâu thuẫn giữa các ghi chú hay không. Chúng tôi chọn các bài đăng có quan điểm đối lập chứa ít nhất một ghi chú hữu ích và một ghi chú không hữu ích, trong đó các ứng viên không hữu ích bao gồm các ghi chú được đánh giá là CURRENTLY_RATED_NOT_HELPFUL hoặc NEEDS_MORE_RATINGS. Dựa trên ngữ cảnh của bài đăng và tập hợp các ghi chú của nó, mô hình cần dự đoán ghi chú nào nên được ưu tiên. Điều này tạo ra một chuẩn mực cân bằng gồm 54.474 trường hợp trên 27.237 bài đăng, với 27.237 ghi chú mục tiêu được Hỗ trợ và 27.237 ghi chú mục tiêu bị Bác bỏ.

Như được thể hiện trong Hình 2, thiếu bối cảnh (22.615 trường hợp) và sai sự thật (20.918 trường hợp) là những nguyên nhân chính gây ra các tuyên bố gây hiểu lầm. Các ghi chú bác bỏ có chi tiết nhiều hơn (1,77 mỗi bài đăng) và độ dài lớn hơn (289,08 ký tự) so với các ghi chú ủng hộ. Phân tích liên kết bằng chứng cho thấy tin tức (49,1%) và các nền tảng mạng xã hội (24,6%) là các nguồn trích dẫn chính, trong khi các tài liệu bách khoa toàn thư vẫn là thứ yếu. Điều này cho thấy ContraNote chủ yếu dựa vào các bằng chứng đa dạng mà

yêu cầu đánh giá nguồn gốc. Việc mã hóa định tính cho thấy rằng các mối quan hệ giữa các chủ thích mâu thuẫn vượt ra ngoài sự đối lập trực tiếp, bao gồm các bất đồng về bối cảnh, phạm vi và mức độ đồng hợp. Đáng chú ý, bất đồng về sự cần thiết của chủ thích là mô hình xung đột chính (33%), nơi các cộng tác viên tranh cãi về sự cần thiết của việc kiểm duyệt. Phân tích phân phối ngôn ngữ cho thấy tiếng Anh chiếm phần lớn (13.776, 62,98%), tiếp theo là tiếng Tây Ban Nha (1.758, 8,04%) và tiếng Bồ Đào Nha (1.368, 6,25%).

Như được hiển thị trong Bảng 4, ContraNote mở rộng các chuẩn mực trước đó (Augenstein et al., 2019; Schlichtkrull et al., 2023; Chen et al., 2022b) bằng cách nắm bắt các mâu thuẫn bằng chứng tự nhiên xảy ra trong các bài đăng đơn lẻ. Để đánh giá độ tin cậy của nhãn, ba nhà chủ thích được đào tạo đã độc lập chủ thích trên 500 mục lấy mẫu ngẫu nhiên, cho kết quả độ tin cậy giữa các đánh giá viên cao (Fleiss’ κ =0.82). Các chủ thích của con người theo phiếu đa số phù hợp với nhãn của bộ dữ liệu trong 94,2% trường hợp, xác thực độ chính xác của nhãn. Để tính đến khả năng thiên lệch, chúng tôi đã phân tích sử dụng PoliticalBiasBERT và nhận thấy bộ dữ liệu bao phủ nhiều quan điểm chính trị khác nhau (18,6% cánh tả, 47,0% trung lập, 34,4% cánh hữu) và các lĩnh vực chủ đề (ví dụ: 26,0% chính trị/quản trị, 20,6% khoa học/công nghệ, 29,8% truyền thông/giải trí/thể thao). Điều này cho thấy ContraNote phản ánh tín hiệu đồng thuận được tạo ra bởi cơ chế Community Notes. Chi tiết được hiển thị đầy đủ trong Phụ lục B.2.

5 Bìa

5.1 Tổng quan về thuật toán

Như được thể hiện trong Hình 3, với một tuyên bố q và một tập hợp bằng chứng $E = \{e_i\}_{i=1}^N$, CoVer dự đoán một nhãn $y \in \{\text{Hỗ trợ}, \text{Phủ nhận}\}$. Thuật toán này có ba mô-đun: chuẩn hóa sơ đồ bằng chứng, đồng thuận thực tế và xác minh hỗ trợ.




Figure 3: The CoVer framework.

5.2 Evidence Schema Normalization

Each evidence item e_i may contain free text and structured metadata $e_i = (t_i, m_i)$, where t_i is textual content and m_i contains optional fields such as source URL. We normalize each item into a canonical representation: $z_i = \phi(e_i) = \phi(t_i, m_i)$. The normalized item z_i preserves both text and schema-level cues. For QA evidence, we retained proposed answer fields. For source-pointer evidence, we retained page and line identifiers. For candidate-note evidence, status, label, stance, and helpfulness fields are kept. For plain fact-checking evidence, article text and snippets are kept. This gives a unified evidence set $\mathcal{Z} = \{z_i\}_{i=1}^N$.

5.3 Factual Consensus

The second stage performs factual adjudication over the normalized evidence via a three-step pipeline: individual evidence adjudication, consensus aggregation, and final verdict generation.

For each normalized evidence item $z_i \in \mathcal{Z}$ associated with the claim q , CoVer estimates its stance toward the claim and evaluates its evidential quality. Instead of using separate prompts, we use a single LLM call with structured output constraints to jointly predict the stance s_i and four fine-grained quality components. These constraints require a valid stance from the predefined label set, numeric quality scores in $[0, 1]$, and the presence of all fields needed by deterministic aggregation:

$$(s_i, d_i, a_i, l_i, u_i) = \text{LLM}_{\text{adj}}(q, z_i, m_i), \quad (1)$$

where $s_i \in \{\text{support, refute, irrelevant}\}$, and m_i denotes the preserved metadata schema (e.g., source URL, helpfulness signals). The quality com-

ponents are scored on a normalized scale $[0, 1]$ according to the following rubrics:


- **Directness** (d_i) measures whether z_i directly addresses the central proposition of q , penalizing items that merely share superficial entities.
- **Attribute alignment** (a_i) evaluates factual compatibility across key dimensions, including entity identity, temporal scope, location, and numerical arguments.
- **Schema reliability** (l_i) includes metadata cues m_i (e.g., source authority and community helpfulness ratings) to assess the trustworthiness of the evidence channel.
- **Informativeness** (u_i) quantifies the substantive factual content, assigning low scores to repetitive rumor quotes, headlines, or text that merely reports the existence of a claim.

The overall quality score q_i is deterministically computed as a weighted linear combination of these components: $q_i = \lambda_d d_i + \lambda_a a_i + \lambda_l l_i + \lambda_u u_i$, where weights are tuned as $\lambda_d = \lambda_a = \lambda_l = \lambda_u = 0.25$ to balance each dimension (see Appendix D.2). Given (s_i, q_i) for all evidence items, CoVer aggregates the evidence deterministically to resolve conflicts. We first compute quality-weighted cumulative scores for the supporting and refuting stances:

$$A_{\text{sup}} = \sum_{i=1}^{|\mathcal{Z}|} q_i \cdot \mathbb{I}[s_i = \text{support}], \quad (2)$$

$$A_{\text{ref}} = \sum_{i=1}^{|\mathcal{Z}|} q_i \cdot \mathbb{I}[s_i = \text{refute}], \quad (3)$$

where $\mathbb{I}[\cdot]$ is the indicator function. The dominant factual stance s^* is selected by comparing the cumulative strengths:



Hình 3: Khung CoVer.

5.2 Chuẩn hóa Sơ đồ Bằng chứng

Mỗi mục bằng chứng e_i có thể chứa văn bản tự do và siêu dữ liệu có cấu trúc $e_i = (t_i, m_i)$, trong đó t_i là nội dung văn bản và m_i chứa các trường tùy chọn như URL nguồn. Chúng tôi chuẩn hóa mỗi mục thành một biểu diễn chuẩn: $z_i = \phi(e_i) = \phi(t_i, m_i)$. Mục chuẩn hóa z_i giữ lại cả văn bản và các dấu hiệu ở cấp độ lược đồ. Đối với bằng chứng QA, chúng tôi giữ các trường câu trả lời được đề xuất. Đối với bằng chứng chỉ nguồn, chúng tôi giữ các định danh trang và dòng. Đối với bằng chứng ghi chú ứng viên, các trường trạng thái, nhãn, lập trường và độ hữu ích được giữ lại. Đối với bằng chứng kiểm tra thực tế đơn giản, văn bản bài báo và các trích đoạn được giữ lại. Điều này tạo ra một tập hợp bằng chứng thống nhất $\mathcal{Z} = \{z_i\}_{i=1}^N$.

5.3 Sự đồng thuận về sự thật

Giai đoạn thứ hai thực hiện việc phán quyết dựa trên các bằng chứng đã chuẩn hóa thông qua một quy trình ba bước: phán quyết từng bằng chứng riêng lẻ, tổng hợp đồng thuận và tạo ra phán quyết cuối cùng.

Đối với mỗi mục bằng chứng đã được chuẩn hóa $z_i \in \mathcal{Z}$ liên quan đến tuyên bố q , CoVer ước lượng lập trường của nó đối với tuyên bố và đánh giá chất lượng bằng chứng của nó. Thay vì sử dụng các lệnh riêng biệt, chúng tôi sử dụng một lần gọi LLM duy nhất với các ràng buộc đầu ra có cấu trúc để dự đoán đồng thời lập trường s_i và bốn thành phần chất lượng chi tiết. Các ràng buộc này yêu cầu một lập trường hợp lệ từ tập nhân đã xác định trước, các điểm chất lượng số trong $[0, 1]$, và sự có mặt của tất cả các trường cần thiết cho tổng hợp xác định:

$$(s_i, d_i, a_i, l_i, u_i) = \text{LLM}_{\text{adj}}(q, z_i, m_i), \quad (1)$$

nơi $s_i \in \{\text{hỗ trợ, bác bỏ, không liên quan}\}$, và m_i biểu thị sơ đồ siêu dữ liệu được bảo lưu (ví dụ: URL nguồn, các tín hiệu hữu ích). Chất lượng com-

Các thành phần được chấm điểm trên một thang điểm chuẩn hóa $[0, 1]$ theo các tiêu chí sau:

- **Tính thẳng thắn** (d_i) đo lường việc z_i có trực tiếp đề cập đến đề xuất trung tâm của q hay không, đồng thời trừ điểm những mục chỉ chia sẻ các thực thể bề ngoài.
- **Căn chỉnh thuộc tính** (a_i) đánh giá sự tương thích thực tế trên các chiều quan trọng, bao gồm danh tính thực thể, phạm vi thời gian, vị trí và các tham số số học.
- **Độ tin cậy của sơ đồ** (l_i) bao gồm các chỉ báo siêu dữ liệu m_i (ví dụ: uy tín nguồn và đánh giá hữu ích từ cộng đồng) để đánh giá độ tin cậy của kênh bằng chứng.
- **Tính thông tin** (u_i) định lượng nội dung thực tế trọng yếu, gán điểm thấp cho các trích dẫn tin đồn lặp đi lặp lại, tiêu đề, hoặc văn bản chỉ đơn giản báo cáo sự tồn tại của một tuyên bố.

Điểm chất lượng tổng thể q_i được tính toán một cách xác định như là tổ hợp tuyến tính có trọng số của các thành phần này: $q_i = \lambda_d d_i + \lambda_a a_i + \lambda_l l_i + \lambda_u u_i$, trong đó các trọng số được điều chỉnh như $\lambda_d = \lambda_a = \lambda_l = \lambda_u = 0.25$ để cân bằng mỗi chiều (xem Phụ lục D.2). Cho (s_i, q_i) cho tất cả các mục bằng chứng, CoVer tổng hợp các bằng chứng một cách xác định để giải quyết các mâu thuẫn. Trước tiên, chúng tôi tính điểm tích lũy có trọng số chất lượng cho các quan điểm ủng hộ và phản đối:

$$A_{\text{sup}} = \sum_{i=1}^{|\mathcal{Z}|} q_i \cdot \mathbb{I}[s_i = \text{support}], \quad (2)$$

$$A_{\text{ref}} = \sum_{i=1}^{|\mathcal{Z}|} q_i \cdot \mathbb{I}[s_i = \text{refute}], \quad (3)$$

nơi $\mathbb{I}[\cdot]$ là hàm chỉ báo. Quan điểm thực tế chiếm ưu thế s^* được chọn bằng cách so sánh độ mạnh tích lũy:

$$s^* = \begin{cases} \text{support}, & \text{if } A_{\text{sup}} > A_{\text{ref}}, \\ \text{refute}, & \text{if } A_{\text{ref}} \geq A_{\text{sup}}. \end{cases} \quad (4)$$

We use Refute as the tie-breaker, which follows the conservative goal of avoiding unsupported positive predictions. To assess potential biases, we evaluate a variant in which ties are assigned to Support. Corresponding results are reported in Appendix D.3. To remove irrelevant noise and low-quality assertions, the final consensus evidence set G^* is filtered using a quality threshold τ_q :

$$G^* = \{z_i \in \mathcal{Z} \mid s_i = s^* \wedge q_i \geq \tau_q\}. \quad (5)$$

The factual correlation between the aggregated consensus set G^* and claim q is adjudicated by an additional LLM call, yielding $r = \text{LLM}_{\text{ver}}(q, G^*) \in \{\text{entails}, \text{contradicts}, \text{insufficient}\}$. entails is mapped to Supported, while others are mapped to Refuted, as neither outcome suggests that the original post is supported under the Community Notes labeling protocol. To test the effect of this strategy, we evaluate a Supported/Partially Supported/Refuted setting in Appendix C.4.

5.4 Support Verification

Given the factual consensus output y_{strict} , CoVer applies support verification only when factual consensus predicts Supported. If $y_{\text{strict}} = \text{Refuted}$, the algorithm terminates and returns Refuted. We use this as a conservative filter for positive predictions. When $y_{\text{strict}} = \text{Supported}$, CoVer constructs the candidate support set

$$\mathcal{Z}_{\text{sup}} = \{z_i \in \mathcal{Z} : s_i = \text{support}, q_i \geq \tau_q\}.$$

It then performs a final verification call: $v = g_{\theta}(q, \mathcal{Z}_{\text{sup}}) \in \{\text{valid}, \text{invalid}\}$. This verifier checks whether the selected supporting evidence directly and independently validates the claim’s central proposition. It rejects support if the evidence merely quotes a claim or rumor, a headline or fact-check setup, about a different entity, time, answer, or scope, or is merely related without factual statement. The final prediction $\hat{y}$ is labeled as Supported if $y_{\text{strict}} = \text{Supported} \wedge v = \text{valid}$, and Refuted otherwise.

6 Experiments

6.1 Datasets

We choose various datasets representing different conflict levels. Specifically, we examine conflicting evidence in social media fact-checking and other scenarios to test CoVer’s generalizability:

CONFACT (Ge et al., 2025). Unlike traditional benchmarks where evidence is often consistent, CONFACT is specifically curated to include claims with opposed evidence on the web (e.g., conflicting reports on political events or scientific debates). It serves as the primary testbed for measuring agents’ ability to resolve evidence conflicts.

ConflictBank (Su et al., 2024). This benchmark analyzes model behavior by simulating knowledge conflicts. It includes 553,117 QA pairs derived from 2,863,205 Wikidata claims, covering three main conflict causes: misinformation, temporal change, and semantic variation. Using the original QA pairs, we construct refutation examples by treating the modified evidence as conflicting evidence groups, yielding 1,659,351 data items.

ECON (Jiayang et al., 2024). The dataset is based on two public datasets: Natural Questions and Complex Web Questions, where they constructed alternative answers as conflicting evidence, producing different types of answer and factoid conflicts: degree, entity, negation, number, temporal, verb, and other types. ECON contains 4,995 data items.

ContraNote. We use the version described in Sec. 4. The primary binary labels follow the Community Notes labeling scheme. We also provide a three-way pilot analysis in Appendix C.4.

FEVER (Thorne et al., 2018). It is a most widely used fact-check dataset (Min et al., 2023; Chen et al., 2023), featuring fact extraction and verification. It contains claims generated by altering sentences extracted from Wikipedia and subsequently verified without access to the source sentences. Claims are labeled supported, refuted and not enough information. We used the shared claim subset, containing 19,998 claims.

6.2 Baselines

We compare CoVer with eight representative baselines for conflict resolution or social media fact-checking. To ensure a controlled evaluation, we decouple verification from retrieval. By providing all methods with identical sets of conflicting evidence, we isolate retrieval variance as a confounding variable. Therefore, while some baselines originally

$$s^* = \begin{cases} \text{support}, & \text{if } A_{\text{sup}} > A_{\text{ref}}, \\ \text{refute}, & \text{if } A_{\text{ref}} \geq A_{\text{sup}}. \end{cases} \quad (4)$$

Chúng tôi sử dụng Refute làm tiêu chí quyết định khi hòa, điều này tuân theo mục tiêu thận trọng là tránh các dự đoán tích cực không có cơ sở. Để đánh giá các thiên lệch tiềm ẩn, chúng tôi đánh giá một biến thể trong đó các trường hợp hòa được gán cho Support. Các kết quả tương ứng được báo cáo trong Phụ lục D.3. Để loại bỏ nhiễu không liên quan và các khẳng định chất lượng thấp, bộ bằng chứng đồng thuận cuối cùng G^* được lọc sử dụng ngưỡng chất lượng τ_q .

$$G^* = \{z_i \in \mathcal{Z} \mid s_i = s^* \wedge q_i \geq \tau_q\}. \quad (5)$$

Mối tương quan thực tế giữa tập hợp đồng thuận tổng hợp G^* và tuyên bố q được phân xử bởi một lần gọi LLM bổ sung, cho ra $r = \text{LLM}_{\text{ver}}(q, G^*) \in \{\text{xác nhận}, \text{mâu thuẫn}, \text{không đủ}\}$. 'xác nhận' được ánh xạ thành Hỗ trợ, trong khi các kết quả khác được ánh xạ thành Bác bỏ, vì không có kết quả nào cho thấy bài đăng gốc được hỗ trợ theo giao thức gắn nhãn Community Notes. Để kiểm tra tác động của chiến lược này, chúng tôi đánh giá thiết lập Hỗ trợ/Một phần Hỗ trợ/Bác bỏ trong Phụ lục C.4.

5.4 Xác minh Hỗ trợ

Với đầu ra đồng thuận thực tế y_{strict} , CoVer chỉ áp dụng việc xác minh hỗ trợ khi đồng thuận thực tế dự đoán được Hỗ trợ. Nếu $y_{\text{strict}} = \text{Bị Bác bỏ}$, thuật toán kết thúc và trả về Bị Bác bỏ. Chúng tôi sử dụng điều này như một bộ lọc thận trọng cho các dự đoán dương tính. Khi $y_{\text{strict}} = \text{Được Hỗ trợ}$, CoVer xây dựng tập hợp hỗ trợ ứng viên

$$\mathcal{Z}_{\text{sup}} = \{z_i \in \mathcal{Z} : s_i = \text{support}, q_i \geq \tau_q\}.$$

Nó sau đó thực hiện một cuộc gọi xác minh cuối cùng: $v = g_{\theta}(q, \mathcal{Z}_{\text{sup}}) \in \{\text{hợp lệ}, \text{không hợp lệ}\}$. Trình xác minh này kiểm tra xem bằng chứng hỗ trợ được chọn có xác thực trực tiếp và độc lập mệnh đề trung tâm của tuyên bố hay không. Nó bác bỏ sự hỗ trợ nếu bằng chứng chỉ trích dẫn một tuyên bố hoặc tin đồn, tiêu đề hoặc thiết lập kiểm tra sự thật, về một thực thể, thời gian, câu trả lời hoặc phạm vi khác, hoặc chỉ đơn giản liên quan mà không có tuyên bố thực tế. Dự đoán cuối cùng $\hat{y}$ được gán nhãn là Hỗ trợ nếu $y_{\text{strict}} = \text{Hỗ trợ} \wedge v = \text{hợp lệ}$, và Ngược lại nếu không.

6 Thí nghiệm

6.1 Bộ dữ liệu

Chúng tôi chọn nhiều bộ dữ liệu khác nhau đại diện cho các mức độ xung đột khác nhau. Cụ thể, chúng tôi kiểm tra các bằng chứng mâu thuẫn trong việc kiểm chứng thông tin trên mạng xã hội và các tình huống khác để đánh giá khả năng tổng quát hóa của CoVer: CONFACT (Ge và cộng sự, 2025). Khác với các chuẩn mực truyền thống nơi bằng chứng thường nhất quán, CONFACT được tuyển chọn đặc biệt để bao gồm các tuyên bố có bằng chứng mâu thuẫn trên web (ví dụ, các báo cáo trái chiều về sự kiện chính trị hoặc tranh luận khoa học). Nó phục vụ như một bộ thử nghiệm chính để đo khả năng của các tác nhân trong việc giải quyết xung đột bằng chứng.

ConflictBank (Su et al., 2024). Bộ chuẩn này phân tích hành vi của mô hình bằng cách mô phỏng các xung đột kiến thức. Nó bao gồm 553.117 cặp hỏi đáp được trích từ 2.863.205 khẳng định của Wikidata, bao phủ ba nguyên nhân xung đột chính: thông tin sai lệch, thay đổi theo thời gian và biến thể ngữ nghĩa. Sử dụng các cặp hỏi đáp gốc, chúng tôi xây dựng các ví dụ phản bác bằng cách coi bằng chứng đã được chỉnh sửa là các nhóm bằng chứng mâu thuẫn, tạo ra 1.659.351 mục dữ liệu.

ECON (Jiayang et al., 2024). Bộ dữ liệu dựa trên hai bộ dữ liệu công khai: Câu hỏi tự nhiên (Natural Questions) và Câu hỏi web phức tạp (Complex Web Questions), trong đó họ xây dựng các câu trả lời thay thế như các bằng chứng mâu thuẫn, tạo ra các loại mâu thuẫn câu trả lời và sự thật khác nhau: cấp độ, thực thể, phủ định, số, thời gian, động từ và các loại khác. ECON chứa 4.995 mục dữ liệu. ContraNote. Chúng tôi sử dụng phiên bản được mô tả trong Mục 4. Các nhãn nhị phân chính tuân theo sơ đồ gán nhãn của Community Notes. Chúng tôi cũng cung cấp một phân tích thử nghiệm m ba hướng trong Phụ lục C.4.

FEVER (Thorne et al., 2018). Đây là một bộ dữ liệu kiểm tra sự thật được sử dụng rộng rãi nhất (Min et al., 2023; Chen et al., 2023), bao gồm việc trích xuất và xác minh thông tin. Nó chứa các tuyên bố được tạo ra bằng cách thay đổi các câu trích xuất từ Wikipedia và sau đó được xác minh mà không truy cập vào các câu nguồn. Các tuyên bố được gán nhãn là được hỗ trợ, bị bác bỏ và thông tin không đủ. Chúng tôi đã sử dụng tập con tuyên bố được chia sẻ, bao gồm 19.998 tuyên bố.

6.2 Đường cơ sở

Chúng tôi so sánh CoVer với tám phương pháp cơ sở đại diện cho giải quyết xung đột hoặc kiểm tra sự thật trên mạng xã hội. Để đảm bảo đánh giá có kiểm soát, chúng tôi tách việc xác minh ra khỏi việc truy xuất. Bằng cách cung cấp cho tất cả các phương pháp cùng một tập hợp bằng chứng mâu thuẫn, chúng tôi cô lập sự biến thiên trong truy xuất như một biến gây nhiễu. Do đó, trong khi một số phương pháp cơ sở ban đầu

Dataset	Subset	Number	Positive	Negative
CONFACT	HumC	287	51	236
	ModC	611	125	486
ConflictBank	–	1,659,351	553,117	1,106,234
ECON	–	4,995	2,043	2,952
ContraNote	Conflict	33,686	6,241	27,445
	Prioritization	54,474	27,237	27,237
FEVER	–	13,332	6,666	6,666

Table 1: Dataset distribution (Positive: Support, Negative: Refute).

included retrieval components, we adapt them to focus on evidence adjudication.

FacTool (Chern et al., 2023): A method that performs a single-pass verification based on retrieved evidence, representing a basic fact-check flow.

FactCheckGPT (Wang et al., 2024): A decomposition-based method, which breaks a claim into atomic sub-claims, retrieves evidence for each sub-claim individually, and aggregates the results, thereby serving a standard automated fact-checking pipeline.

FIRE (Xie et al., 2025): An iterative reasoning agent. Unlike FacTool, FIRE operates as a loop. It assesses whether the current context is sufficient to answer the claim. If not, it considers new evidence. Through this process, it implicitly models conflict.

Confact (Ge et al., 2025): A source-aware RAG framework designed to resolve evidentiary conflicts by integrating media background metadata (e.g., source credibility ratings and bias information) directly into the answer generation stage. It uses structured reasoning (e.g., Chain-of-Thought) to evaluate and prioritize evidence from trustworthy sources, thereby mitigating the influence of misleading information from unreliable origins.

ECON (Jiayang et al., 2024) (i.e., ConflictRes): A framework focusing on evidence conflicts, especially those occurring between different retrieved context. ECON addresses the gap between LLMs’ detection and their unreliable resolution behaviors, such as arbitrary evidence selection or over-reliance on internal priors.

Additional baselines: We also compare an AVeriTeC-style verifier, MADAM-RAG, and ClaimDecomp. The AVeriTeC-style verifier uses question-guided evidence verification for real-world claims, while MADAM-RAG represents a multi-agent retrieval-augmented verification pipeline. ClaimDecomp decomposes a complex claim into literal and implied subclaims, verifies them individually, and aggregates their local ver-

dicts. Under our fixed-evidence setting, these methods receive the same claim and evidence pool as the other baselines, isolating differences in verification and aggregation rather than retrieval coverage.

6.3 Study Settings

Implementation details

All agents in our evaluation use gpt-4o as the backbone LLMs. Baselines are implemented with the following configurations to ensure reproducibility: **FacTool** generates two search queries and retrieves the top-10 results per query using a CoT verification process. **FactCheckGPT** decomposes claims into 2–3 queries and verifies results through NLI. The iterative **FIRE** agent is restricted to a maximum of 10 steps. **CONFACT** retrieves the top-10 results and augments them with claim background descriptions of under 50 words each, while **ConflictRes** focuses on resolving discrepancies between the top-10 retrieved snippets. Similarly, we limit CoVer to a maximum of 10 evidence items to maintain processing efficiency. Each method receives the same query and evidence. We repeat each experiment five times and report the average results.

Ablation Settings

We evaluate the contribution of each CoVer component by removing modules.

Without evidence *schema* normalization: we remove the schema normalization module and provide evidence to the adjudicator only as unstructured text. We omit structured cues such as proposed answers, source pointers, line identifiers, candidate-note stances, and target-candidate markers. This tests whether task-relevant evidence structures are necessary for conflict resolution.

Without factual *consensus*: the system no longer selects direct, internally consistent, and claim-aligned evidence group before making a decision. This evaluates whether factual consensus with evidence group is helpful.

Without *support* verification: the model accepts support decisions without additional check for direct entailment, target-candidate validity, or contradiction by stronger evidence.

Pairwise removals: we further evaluate all pairwise removals: w/o Schema + Consensus, w/o Schema + Support, and w/o Consensus + Support. These settings measure whether the modules provide complementary benefits or whether performance is driven by a single component.

Without all: we remove all three modules to create

Bộ dữ liệu	Tập con	Số	Tích cực	Tiêu cực
CONFACT	HumC	287	51	236
	ModC	611	125	486
Ngân hàng Xung đột	–	1,659,351	553,117	1,106,234
ECON	–	4,995	2,043	2,952
ContraNote	Xung đột	33,686	6,241	27,445
	Ưu tiên	54,474	27,237	27,237
SỐT	–	13,332	6,666	6,666

Bảng 1: Phân phối bộ dữ liệu (Dương: Hỗ trợ, Âm: Phủ nhận).

bao gồm các thành phần truy xuất, chúng tôi điều chỉnh chúng để tập trung vào việc xét xử bằng chứng.

FacTool (Chern et al., 2023): Một phương pháp thực hiện xác minh một lần dựa trên bằng chứng được truy xuất, đại diện cho một luồng kiểm tra sự thật cơ bản.

FactCheckGPT (Wang và cộng sự, 2024): Một phương pháp dựa trên phân rã, phá vỡ một tuyên bố thành các tuyên bố con cơ bản, truy xuất bằng chứng cho từng tuyên bố con một cách riêng lẻ, và tổng hợp kết quả, do đó phục vụ như một quy trình kiểm tra thực tế tự động tiêu chuẩn.

FIRE (Xie et al., 2025): Một tác nhân suy luận lặp đi lặp lại. Khác với FacTool, FIRE hoạt động theo dạng vòng lặp. Nó đánh giá xem bối cảnh hiện tại có đủ để trả lời khẳng định hay không. Nếu không, nó xem xét các bằng chứng mới. Thông qua quá trình này, nó mô phỏng ngẫm xung đột. Confact (Ge et al., 2025): Một khung RAG nhận biết nguồn được thiết kế để giải quyết xung đột bằng chứng bằng cách tích hợp siêu dữ liệu nền của phương tiện truyền thông (ví dụ, đánh giá độ tin cậy của nguồn và thông tin thiên lệch) trực tiếp vào giai đoạn tạo câu trả lời. Nó sử dụng suy luận có cấu trúc (ví dụ, Chuỗi Suy Nghi) để đánh giá và ưu tiên bằng chứng từ các nguồn đáng tin cậy, từ đó giảm thiểu ảnh hưởng của thông tin gây hiểu lầm từ các nguồn không đáng tin cậy.

ECON (Jiayang et al., 2024) (tức là ConflictRes): Một khuôn khổ tập trung vào các xung đột bằng chứng, đặc biệt là những xung đột xảy ra giữa các ngữ cảnh được truy xuất khác nhau. ECON giải quyết khoảng cách giữa việc phát hiện của các mô hình ngôn ngữ lớn (LLM) và hành vi giải quyết không đáng tin cậy của chúng, chẳng hạn như lựa chọn bằng chứng tùy ý hoặc phụ thuộc quá mức vào các tiên kiến nội bộ.

Các cơ sở so sánh bổ sung: Chúng tôi cũng so sánh một trình xác minh theo phong cách AVeriTeC, MADAM-RAG, và ClaimDecomp. Trình xác minh theo phong cách AVeriTeC sử dụng xác minh bằng chứng hướng dẫn theo câu hỏi cho các tuyên bố thực tế, trong khi MADAM-RAG đại diện cho một quy trình xác minh tăng cường truy xuất đa tác nhân. ClaimDecomp phân rã một tuyên bố phức tạp thành các tuyên bố con theo nghĩa đen và ngụ ý, xác minh chúng từng một, và tổng hợp các giá trị cục bộ của chúng

dicts. Trong thiết lập bằng chứng cố định của chúng tôi, các phương pháp này nhận được cùng một tập hợp yêu cầu và bằng chứng như các phương pháp cơ sở khác, tách biệt sự khác biệt về xác minh và tổng hợp thay vì phạm vi truy xuất.

6.3 Cài đặt học tập

Chi tiết triển khai

Tất cả các đại lý trong đánh giá của chúng tôi sử dụng gpt-4o làm LLMs nền tảng. Các phương pháp cơ bản được triển khai với các cấu hình sau để đảm bảo khả năng tái lập: FacTool tạo hai truy vấn tìm kiếm và truy xuất 10 kết quả hàng đầu cho mỗi truy vấn bằng quy trình xác minh CoT. FactCheckGPT phân tách các tuyên bố thành 2–3 truy vấn và xác minh kết quả thông qua NLI. Đại lý FIRE theo vòng lặp bị giới hạn tối đa 10 bước. CONFACT truy xuất 10 kết quả hàng đầu và bổ sung chúng bằng mô tả nền của tuyên bố dưới 50 từ mỗi mô tả, trong khi ConflictRes tập trung vào việc giải quyết các mâu thuẫn giữa 10 đoạn trích được truy xuất hàng đầu. Tương tự, chúng tôi giới hạn CoVer tối đa 10 bằng chứng để duy trì hiệu quả xử lý. Mỗi phương pháp nhận cùng một truy vấn và bằng chứng. Chúng tôi lặp lại mỗi thí nghiệm năm lần và báo cáo kết quả trung bình.

Cài đặt khử

Chúng tôi đánh giá đóng góp của từng thành phần CoVer bằng cách loại bỏ các mô-đun.

Không có chuẩn hóa lược đồ bằng chứng: chúng tôi loại bỏ mô-đun chuẩn hóa lược đồ và chỉ cung cấp bằng chứng cho người phân xử dưới dạng văn bản không có cấu trúc. Chúng tôi bỏ qua các dấu hiệu có cấu trúc như câu trả lời được đề xuất, chỉ số nguồn, định danh dòng, quan điểm ghi chú ứng viên và các dấu hiệu ứng viên-mục tiêu. Điều này kiểm tra xem các cấu trúc bằng chứng liên quan đến nhiệm vụ có cần thiết cho việc giải quyết xung đột hay không.

Không có sự đồng thuận về thực tế: hệ thống không còn chọn nhóm chứng cứ trực tiếp, nhất quán nội bộ và phù hợp với tuyên bố trước khi đưa ra quyết định. Điều này đánh giá liệu sự đồng thuận về thực tế với nhóm chứng cứ có hữu ích hay không.

Không có xác minh hỗ trợ: mô hình chấp nhận các quyết định hỗ trợ mà không kiểm tra thêm về sự suy diễn trực tiếp, tính hợp lệ của mục tiêu-ứng viên, hoặc mâu thuẫn bởi bằng chứng mạnh hơn.

Loại bỏ theo cặp: chúng tôi tiếp tục đánh giá tất cả các loại bỏ theo cặp: không có Schema + Consensus, không có Schema + Support, và không có Consensus +Support. Các thiết lập này đo lường xem các mô-đun có cung cấp lợi ích bổ sung hay hiệu suất chỉ được thúc đẩy bởi một thành phần duy nhất.

Không có tất cả: chúng tôi loại bỏ cả ba mô-đun để tạo

the minimal setting.

6.4 Main Results

Table 2 compares CoVer with the baselines across all datasets.

CoVer performs strongly on tasks involving complex contradictions and ambiguity. As shown in Table 2, CoVer surpasses all baselines on CON-FACT, achieving 88.4% accuracy on HumC and 89.4% on ModC. On ContraNote Conflict, it attains a leading accuracy of 86.0%, compared with 82.8% for Confact and 81.3% for ConflictRes. These results show CoVer’s ability to synthesize conflicting information and adjudicate claims involving nuanced inconsistencies.

CoVer is effective at evidence prioritization and domain-specific conflict resolution. On ContraNote Prioritization, CoVer achieves 88.5% accuracy, exceeding baselines such as FIRE (64.5%). Similarly, on ConflictBank, CoVer achieves 73.5% accuracy, showing marked improvement over FactCheckGPT (63.5%). This highlights CoVer’s capacity to process structured conflicting scenarios and prioritize reliable signals.

Beyond conflict arbitration, CoVer exhibits high accuracy on fact-check datasets. It achieved 93.4% accuracy on FEVER, surpassing Confact (87.0%) and FactCheckGPT (81.5%). On ECON, it achieves the highest accuracy (77.5%) versus Confact (74.0%). This confirms CoVer’s generalizability to fact-check datasets.

Additional baseline comparisons: The AVeriTeC-style verifier obtains 65.6 and 80.5 mac. F1 on ContraNote Conflict and Prioritization, respectively, while MADAM-RAG obtains 47.7 and 70.3; CoVer obtains 68.0 and 88.5 on the same two tasks. ClaimDecomp obtains accuracies of 82.23, 84.58, 80.00, and 66.00, with corresponding mac. F1 scores of 67.28, 76.21, 54.29, and 65.58 on CONFACT-HumC, CONFACT-ModC, ContraNote Conflict, and ContraNote Prioritization, respectively. Under the same dataset order, CoVer obtains mac. F1 scores of 77.10, 83.10, 68.00, and 88.50. These results show that CoVer remains competitive with retrieval-oriented and claim-decomposition baselines, with the largest gains appearing on evidence prioritization and conflict aggregation.

Retrieval: Beyond gold evidence setting, which isolates evidence adjudication and prevents confounding effects from retrieval quality, we assess whether the framework remains useful with end-

to-end evidence retrieval. We pair each method with upstream retriever and evaluate the resulting claim-level predictions. On retrieval-enabled ContraNote Conflict setting, CoVer obtains 69.6 mac. F1, compared with 59.2 mac. F1 for strongest baseline. These suggests that CoVer complements retrieval, adjudicating evidence with varied stances, reliability and claim alignment.

Shortcut baseline

To test whether ContraNote labels are recoverable from inputted metadata, we evaluate a shortcut baseline, with rules that predict Refuted if and only if at least one note is marked both helpful and misleading. On ContraNote Conflict, this obtains 81.5% accuracy, 44.9 mac. F1 and 50.0 bal. Acc. On ContraNote Prioritization, this obtains 50.0% accuracy, 33.3 mac. F1 and 50.0 bal. Acc. Its high accuracy is explained by class imbalance, where mac. F1 and bal. Acc. are by chance.

Metadata-suppressed evaluation

We further test conditions of CoVer by removing note-status fields that could expose construction-time signals, i.e., target note’s helpfulness, status, classification, and label fields. In this setting, CoVer obtains 87.5% mac. F1 and 86.5% bal. Acc. This shows that CoVer retains strong performance without access to metadata fields.

Statistical testing

We assess pairwise differences using McNemar’s test with $\alpha = 0.05$. CoVer’s improvements are significant on all evaluated datasets except for comparisons on ContraNote Conflict with CONFACT and ConflictRes. Accordingly, the results on ContraNote Conflict indicate a positive performance trend but are not significant. Appendix E.2 complements these tests with error analysis.

6.5 Ablation Study

Factual consensus module is critical for resolving complex contradictions. As shown in Table 3, removing this module (w/o Consensus) degrades performance in tasks requiring nuanced arbitration, where accuracy on ContraNote Prioritization drops from 88.5% to 42.5%. Similarly, accuracy on ContraNote Conflict drops from 86.0% to 69.0%.

Evidence schema normalization is essential for parsing factual information. While removing this module leaves performance on CONFACT unaffected, it causes degradation on ECON, failing from 77.5% to 45.5%. We also observe substan-

cài đặt tối thiểu.

6.4 Kết quả chính

Bảng 2 so sánh CoVer với các phương pháp cơ sở trên tất cả các bộ dữ liệu.

CoVer hoạt động mạnh mẽ trên các nhiệm vụ liên quan đến mâu thuẫn phức tạp và sự mơ hồ. Như thể hiện trong Bảng 2, CoVer vượt qua tất cả các tiêu chuẩn về CON-FACT, đạt độ chính xác 88,4 % trên HumC và 89,4% trên ModC. Trên ContraNote Conflict, nó đạt độ chính xác dẫn đầu là 86,0%, so với 82,8% của Confact và 81,3% của ConflictRes. Những kết quả này cho thấy khả năng tổng hợp thông tin mâu thuẫn của CoVer và giải quyết các yêu cầu liên quan đến sự không nhất quán có tính tinh tế.

CoVer hiệu quả trong việc ưu tiên chứng cứ và giải quyết xung đột theo lĩnh vực cụ thể. Về Ưu tiên Ghi chú Trái chiều, CoVer đạt độ chính xác 88,5%, vượt qua các chuẩn mực như FIRE (64,5%). Tương tự, trên ConflictBank, CoVer đạt độ chính xác 73,5%, cho thấy sự cải thiện rõ rệt so với FactCheckGPT (63,5%). Điều này nhấn mạnh khả năng của CoVer trong việc xử lý các tình huống xung đột có cấu trúc và ưu tiên các tín hiệu đáng tin cậy.

Ngoài việc trọng tài xung đột, CoVer thể hiện độ chính xác cao trên các bộ dữ liệu kiểm tra sự thật. Nó đạt độ chính xác 93,4% trên FEVER, vượt qua Confact (87,0%) và FactCheckGPT (81,5%). Trên ECON, nó đạt độ chính xác cao nhất (77,5%) so với Confact (74,0%). Điều này xác nhận khả năng tổng quát của CoVer trong việc kiểm tra sự thật trên các bộ dữ liệu.

So sánh cơ sở bổ sung: Trình xác minh kiểu AVeriTeC đạt F1 trung bình 65,6 và 80,5 trên ContraNote Conflict và Prioritization, tương ứng, trong khi MADAM-RAG đạt 47,7 và 70,3; CoVer đạt 68,0 và 88,5 trên cùng hai nhiệm vụ. ClaimDecomp đạt độ chính xác lần lượt là 82,23, 84,58, 80,00 và 66,00, với các điểm F1 trung bình tương ứng là 67,28, 76,21, 54,29 và 65,58 trên CONFACT-HumC, CONFACT-ModC, ContraNote Conflict và ContraNote Prioritization, tương ứng. Theo cùng thứ tự dữ liệu, CoVer đạt các điểm F1 trung bình lần lượt là 77,10, 83,10, 68,00 và 88,50. Những kết quả này cho thấy CoVer vẫn cạnh tranh với các cơ sở hướng truy xuất và phân tách yêu cầu, với những cải thiện lớn nhất xuất hiện ở việc ưu tiên bằng chứng và tổng hợp xung đột.

Truy xuất: Vượt ra ngoài cài đặt bằng chứng vàng, vốn tách biệt việc xét xử bằng chứng và ngăn ngừa các hiệu ứng gây nhiễu từ chất lượng truy xuất, chúng tôi đánh giá xem liệu khung này vẫn hữu ích với việc kết thúc

truy xuất bằng chứng toàn bộ. Chúng tôi kết hợp mỗi phương pháp với bộ truy xuất dữ liệu phía trên và đánh giá các dự đoán cấp độ tuyên bố thu được. Trong thiết lập Conflict ContraNote được hỗ trợ truy xuất, CoVer đạt 69,6 mac. F1, so với 59,2 mac. F1 cho phương pháp cơ sở mạnh nhất. Điều này cho thấy CoVer bổ sung cho việc truy xuất, phân xử bằng chứng với các quan điểm, độ tin cậy và sự phù hợp với tuyên bố khác nhau.

Đường cơ sở phím tắt

Để kiểm tra xem nhãn ContraNote có thể được khôi phục từ siêu dữ liệu đã nhập hay không, chúng tôi đánh giá một phương pháp cơ bản nhanh, với các quy tắc dự đoán Refuted nếu và chỉ nếu ít nhất một ghi chú được đánh dấu vừa hữu ích vừa gây hiểu nhầm. Trên ContraNote Conflict, phương pháp này đạt 81,5% độ chính xác, mac. F1 44,9 và bal. Acc. 50,0. Trên ContraNote Prioritization, phương pháp này đạt 50,0% độ chính xác, mac. F1 33,3 và bal. Acc. 50,0. Độ chính xác cao của nó được giải thích bởi sự mất cân bằng lớp, trong đó mac. F1 và bal. Acc. mang tính ngẫu nhiên.

Đánh giá bị ẩn siêu dữ liệu

Chúng tôi tiến hành thử nghiệm thêm các điều kiện của CoVer bằng cách loại bỏ các trường trạng thái ghi chú có thể tiết lộ các tín hiệu thời gian xây dựng, tức là mức độ hữu ích, trạng thái, phân loại và nhãn của ghi chú mục tiêu. Trong bối cảnh này, CoVer đạt 87,5% F1 trung bình và 86,5% độ chính xác cân bằng. Điều này cho thấy CoVer duy trì hiệu suất mạnh mẽ không cần truy cập vào các trường siêu dữ liệu.

Kiểm định thống kê

Chúng tôi đánh giá sự khác biệt theo cặp sử dụng kiểm định McNemar với $\alpha = 0.05$. Những cải tiến của CoVer là đáng kể trên tất cả các tập dữ liệu được đánh giá ngoại trừ các so sánh trên ContraNote Conflict với CONFACT và ConflictRes. Do đó, các kết quả trên ContraNote Conflict chỉ ra xu hướng hiệu suất tích cực nhưng không đáng kể. Phụ lục E.2 bổ sung cho các kiểm định này bằng phân tích lỗi.

6.5 Nghiên cứu loại bỏ

Mô-đun đồng thuận thực tế là rất quan trọng để giải quyết các mâu thuẫn phức tạp. Như được trình bày trong Bảng 3, việc loại bỏ mô-đun này (không có Đồng thuận) làm giảm hiệu suất trong các nhiệm vụ yêu cầu phân xử tinh vi, nơi độ chính xác trên ContraNotePrioritization giảm từ 88,5% xuống 42,5%. Tương tự, độ chính xác trên ContraNote Conflict giảm từ 86,0% xuống 69,0%.

Chuẩn hóa sơ đồ bằng chứng là rất cần thiết để phân tích thông tin thực tế. Trong khi việc loại bỏ mô-đun này không ảnh hưởng đến hiệu suất trên CONFACT, nó gây suy giảm trên ECON, giảm từ 77,5% xuống 45,5%. Chúng tôi cũng quan sát thấy đáng kể

Method	CONFACT HumC			CONFACT ModC			ConflictBank			ECON			FEVER			ContraNote Conflict			ContraNote Prioritization		
FacTool	80.0	60.8	59.9	81.5	69.6	68.2	57.8	52.0	52.5	70.0	69.2	69.2	51.0	50.3	61.7	71.1	63.4	71.2	59.8	59.8	60.0
FactCheckGPT	84.0	67.7	65.8	80.5	68.0	66.7	63.5	57.5	58.0	67.5	66.6	66.6	81.5	80.9	85.0	72.2	60.1	62.9	55.8	55.7	56.3
FIRE	79.0	55.0	54.6	78.4	66.0	65.4	54.8	48.2	48.3	63.0	61.9	62.0	72.0	71.7	76.7	72.2	63.0	68.5	64.5	63.8	63.9
Confact	75.9	62.5	64.4	80.8	74.2	77.4	60.5	56.4	57.9	74.0	74.0	74.4	87.0	85.1	84.3	82.8	73.4	76.1	62.8	62.8	62.9
ConflictRes	81.5	64.2	63.1	77.5	68.5	70.0	57.0	44.1	44.7	68.5	67.8	67.8	74.5	73.4	76.0	81.3	70.2	71.8	61.5	60.1	60.6
CoVer	88.4	77.1	74.3	89.4	83.1	81.6	73.5	63.4	62.5	77.5	77.5	77.7	93.4	92.9	94.3	86.0	68.0	64.5	88.5	88.5	89.2

Table 2: Baseline comparison across various evaluation datasets. Metrics in each cell are formatted as Accuracy | mac. F1 | bal. Acc..

Setting	CONFACT HumC			CONFACT ModC			ConflictBank			ECON			FEVER			ContraNote Conflict			ContraNote Prioritization		
Full	88.4	77.1	74.3	89.4	83.1	81.6	73.5	63.4	62.5	77.5	77.5	77.7	93.4	92.9	94.3	86.0	68.0	64.5	88.5	88.5	89.2
w/o Schema	88.4	77.1	74.3	89.4	83.1	81.6	68.8	56.8	56.7	45.5	40.7	47.0	82.4	81.6	84.5	84.0	71.7	71.2	76.9	76.9	77.0
w/o Consensus	84.4	74.0	75.4	81.1	73.9	76.4	63.3	60.8	64.0	77.5	77.5	77.7	88.5	87.6	89.5	69.0	58.0	49.7	42.5	31.9	40.2
w/o Support	85.8	73.2	71.6	88.4	81.5	80.1	70.0	60.0	59.5	77.5	77.5	77.7	88.5	87.6	89.5	85.5	66.3	63.1	68.5	68.3	68.3
w/o Schema + Consensus	80.6	67.0	67.4	78.9	70.3	72.3	63.8	61.3	64.3	76.5	76.5	77.0	88.0	86.8	87.6	60.0	55.7	65.6	54.0	59.8	53.5
w/o Schema + Support	82.7	62.3	60.5	86.3	76.3	73.4	69.3	60.0	59.6	59.5	55.0	57.3	86.5	85.5	87.3	84.0	71.7	71.2	79.4	79.4	79.5
w/o Consensus + Support	84.4	74.0	75.4	81.1	73.9	76.4	63.3	60.8	64.0	77.5	77.5	77.7	88.5	87.6	89.5	72.0	60.9	52.6	40.5	30.1	38.3
w/o All	80.6	67.0	67.4	78.9	70.3	72.3	63.8	61.3	64.3	76.5	76.5	77.0	88.0	86.8	87.6	61.0	56.4	67.4	49.7	54.8	49.3

Table 3: Ablation results on different components of CoVer, formatted as Accuracy | mac. F1 | bal. Acc.. Schema=Evidence Schema Normalization, Consensus=Factual Consensus, Support=Support Verification.

tial degradations on FEVER (93.4% to 82.4%) and ConflictBank (73.5% to 68.8%).

Support verification ensures reasoning stability, and CoVer exhibits strong synergistic effects when integrating all modules. Removing support verification degrades performance across multiple datasets, most notably on ContraNote Prioritization (dropping from 88.5% to 68.5%). Furthermore, w/o all configuration produces the most substantial degradation on complex tasks, reducing CONFACT-HumC accuracy to 80.6% and ContraNote Prioritization to 49.7%.

6.6 Temporal and Paraphrase Robustness

As GPT-4o may be trained on publicly available Community Notes, we evaluate whether CoVer relies on memorization. We construct a temporally held-out slice from January 2026 and paraphrase the claims while preserving their semantics. On this test, CoVer obtains 68.8 mac. F1, compared with 66.5 for the strongest baseline.

6.7 Computational Cost Analysis

Based on results from all evaluation datasets, the average per-call generation, and end-to-end fact-checking time are 5.8s. Average token usage is 1546.1 tokens per request (1274.9 input / 271.2 output), corresponding to an estimated cost of \$0.0059 per request. These results suggest that resolving conflicting evidence with CoVer remains computationally and economically feasible. To control for inference budget, we evaluate both single-call baseline configurations and multi-call configura-

tions matched to the number of LLM calls used by CoVer. Multi-call versions improve some baselines, but CoVer remains competitive under matched call budgets. Call counts and token usage are reported in Appendix E.1.

7 Conclusion

This paper addresses evidence-level and aggregation-level conflicts in automated social media fact-checking. We propose CoVer, a framework that resolves these contradictions through structuring evidence schema normalization, factual consensus, and support verification, effectively prioritizing evidence over noise. We then construct ContraNote, a real-world dataset derived from $\mathbb{X}$ for conflict resolution (33,686 items) and evidence prioritization (54,474 items). Extensive experiments show that CoVer achieved strong performance compared with SOTA baselines, achieving accuracies of 86.0% and 88.5% on the Conflict and Prioritization tasks (bal. Acc.: 64.5% and 89.2%) respectively.

Acknowledgments

This work was supported by Beijing Major Science and Technology Project under Contract no. Z251100008125024, Beijing Academy of Artificial Intelligence (BAAI), and the Luxembourg National Research Fund (ref. C25/IS-SAS/19599536).

Phương pháp	CONFACT HumC			CONFACT ModC			Ngân hàng Xung đột			ECON			SỐT			Ghi chú đối lập Xung đột			Ghi chú đối lập Ưu tiên		
FacTool	80.0	60.8	59.9	81.5	69.6	68.2	57.8	52.0	52.5	70.0	69.2	69.2	51.0	50.3	61.7	71.1	63.4	71.2	59.8	59.8	60.0
KiểmTraSửThậtGPT	84.0	67.7	65.8	80.5	68.0	66.7	63.5	57.5	58.0	67.5	66.6	66.6	81.5	80.9	85.0	72.2	60.1	62.9	55.8	55.7	56.3
FIRE	79.0	55.0	54.6	78.4	66.0	65.4	54.8	48.2	48.3	63.0	61.9	62.0	72.0	71.7	76.7	72.2	63.0	68.5	64.5	63.8	63.9
Liên hệ	75.9	62.5	64.4	80.8	74.2	77.4	60.5	56.4	57.9	74.0	74.0	74.4	87.0	85.1	84.3	82.8	73.4	76.1	62.8	62.8	62.9
Xung đột	81.5	64.2	63.1	77.5	68.5	70.0	57.0	44.1	44.7	68.5	67.8	67.8	74.5	73.4	76.0	81.3	70.2	71.8	61.5	60.1	60.6
Bĩa	88.4	77.1	74.3	89.4	83.1	81.6	73.5	63.4	62.5	77.5	77.5	77.7	93.4	92.9	94.3	86.0	68.0	64.5	88.5	88.5	89.2

Bảng 2: So sánh cơ sở giữa các bộ dữ liệu đánh giá khác nhau. Các chỉ số trong mỗi ô được định dạng dưới dạng Accuracy |mac. F1 | bal. Acc.

Cài đặt	CONFACT HumC			CONFACT ModC			Ngân hàng Xung đột			ECON			SỐT			Ghi chú đối lập Xung đột			Ghi chú đối lập Ưu tiên		
Full	88.4	77.1	74.3	89.4	83.1	81.6	73.5	63.4	62.5	77.5	77.5	77.7	93.4	92.9	94.3	86.0	68.0	64.5	88.5	88.5	89.2
không có Sơ đồ	88.4	77.1	74.3	89.4	83.1	81.6	68.8	56.8	56.7	45.5	40.7	47.0	82.4	81.6	84.5	84.0	71.7	71.2	76.9	76.9	77.0
không có sự đồng thuận	84.4	74.0	75.4	81.1	73.9	76.4	63.3	60.8	64.0	77.5	77.5	77.7	88.5	87.6	89.5	69.0	58.0	49.7	42.5	31.9	40.2
không có hỗ trợ	85.8	73.2	71.6	88.4	81.5	80.1	70.0	60.0	59.5	77.5	77.5	77.7	88.5	87.6	89.5	85.5	66.3	63.1	68.5	68.3	68.3
không có Schema + Consensus	80.6	67.0	67.4	78.9	70.3	72.3	63.8	61.3	64.3	76.5	76.5	77.0	88.0	86.8	87.6	60.0	55.7	65.6	54.0	59.8	53.5
không có Hỗ trợ Schema +	82.7	62.3	60.5	86.3	76.3	73.4	69.3	60.0	59.6	59.5	55.0	57.3	86.5	85.5	87.3	84.0	71.7	71.2	79.4	79.4	79.5
không có Hỗ trợ Đồng thuận +	84.4	74.0	75.4	81.1	73.9	76.4	63.3	60.8	64.0	77.5	77.5	77.7	88.5	87.6	89.5	72.0	60.9	52.6	40.5	30.1	38.3
không có tất cả	80.6	67.0	67.4	78.9	70.3	72.3	63.8	61.3	64.3	76.5	76.5	77.0	88.0	86.8	87.6	61.0	56.4	67.4	49.7	54.8	49.3

Bảng 3: Kết quả ablation trên các thành phần khác nhau của CoVer, được định dạng dưới dạng Accuracy | mac. F1 | bal. Acc.. Schema=Chuẩn hóa Lược đồ Bảng chứng, Consensus=Thống nhất Thực tế, Support=Xác minh Hỗ trợ.

suy giảm đáng kể trên FEVER (93,4% xuống 82,4%) và ConflictBank (73,5% xuống 68,8%).

Xác minh hỗ trợ đảm bảo tính ổn định của suy luận, và CoVer thể hiện hiệu ứng hiệp lực mạnh k hi tích hợp tất cả các mô-đun. Việc loại bỏ xác minh hỗ trợ làm giảm hiệu suất trên nhiều tập dữ liệu, đặc biệt là trên ContraNote Prioritization (giảm từ 88,5% xuống 68,5%). Hơn nữa, cấu hình không có tất cả các yếu tố tạo ra sự suy giảm đáng kể nhất trong các nhiệm vụ phức tạp, giảm độ chính xác của CONFACT-HumC xuống 80,6% và ContraNote Prioritization xuống 49,7%.

6.6 Tính vững chắc của Diễn giải theo Thời gian

Vì GPT-4o có thể được đào tạo trên các Ghi chú Cộng đồng có sẵn công khai, chúng tôi đánh giá xem CoVer có dựa vào việc ghi nhớ hay không. Chúng tôi xây dựng một phần dữ liệu bị giữ lại theo thời gian từ tháng 1 năm 2026 và diễn giải lại các tuyên bố trong khi vẫn giữ nguyên ý nghĩa của chúng. Trong bài kiểm tra này, CoVer đạt 68,8 điểm mac. F1, so với 66,5 của phương pháp cơ sở mạnh nhất.

6.7 Phân tích Chi phí Tính toán

Dựa trên kết quả từ tất cả các bộ dữ liệu đánh giá, thời gian sinh trung bình cho mỗi lần gọi và thời gian kiểm tra sự thật từ đầu đến cuối là 5,8 giây. Số lượng token trung bình sử dụng là 1546,1 token c ho mỗi yêu cầu (1274,9 input / 271,2 output), tương ứng với chi phí ước tính là 0,0059 USD cho mỗi yêu cầu. Những kết quả này gợi ý rằng việc giải quyết bằng chứng mâu thuẫn với CoVer vẫn khả thi về mặt tính toán và kinh tế. Để kiểm soát ngân sách suy diễn, chúng tôi đánh giá cả các cấu hình cơ bản gọi một lần và các cấu hình gọi nhiều lần.

các tác vụ được khớp với số lần gọi LLM được CoVer sử dụng. Các phiên bản nhiều lần gọi cải thiện một số cơ sở, nhưng CoVer vẫn giữ được tính cạnh tranh khi số lần gọi được cân bằng. Số lần gọi và việc sử dụng token được báo cáo trong Phụ lục E.1.

7 Kết luận

Bài báo này đề cập đến các xung đột ở cấp độ bằng chứng và cấp độ tổng hợp trong việc kiểm tra sự thật tự động trên mạng xã hội. Chúng tôi đề xuất CoVer, một khuôn khổ giải quyết những mâu thuẫn này thông qua việc cấu trúc hóa chuẩn hóa lược đồ bằng chứng, đồng thuận về sự thật và xác minh hỗ trợ, hiệu quả trong việc ưu tiên bằng chứng so với nhiều. Sau đó, chúng tôi xây dựng ContraNote, một bộ dữ liệu thực tế được rút ra từ X để giải quyết xung đột (33.686 mục) và ưu tiên bằng chứng (54.474 mục). Các thí nghiệm mở rộng cho thấy CoVer đạt hiệu suất mạnh so với các phương pháp cơ sở SOTA, đạt độ chính xác 86,0% và 88,5% trong các nhiệm vụ Xung đột và Ưu tiên (độ chính xác cân bằng: 64,5% và 89,2%) tương ứng.

Lời cảm ơn

Công trình này được hỗ trợ bởi Dự án Khoa học và Công nghệ Lớn Bắc Kinh theo Hợp đồng số Z251100008125024, Học viện Trí tuệ Nhân tạo Bắc Kinh (BAAI), và Quỹ Nghiên cứu Quốc gia Luxembourg (tham chiếu C25/IS-SAS/19599536).

8 Limitations

We acknowledge several limitations in this paper that highlight directions for future research.

First, the proposed framework and the Contra-Note dataset focus exclusively on textual claims and metadata, predominantly in English. Although we diversify the language coverage, the current coverage remains insufficient for comprehensive real-world deployment. Furthermore, modern social media misinformation is multimodal. Our current setting excludes conflict adjudication involving manipulated images, deepfakes, or out-of-context videos, which frequently drive real-world evidence contradictions. Additionally, the efficacy of the framework in low-resource languages or highly specialized domains (e.g., legal or medical texts) requires further validation.

Second, the ground-truth definition in the ContraNote dataset relies on crowdsourced consensus and algorithmic helpfulness scores. While this approach reflects practical social consensus under algorithmic quality control, it is not strictly equivalent to absolute factual truth and remains susceptible to coordinated rating manipulation. Moreover, trained annotators may share some of the same cultural or ideological assumptions as Community Notes contributors.

Third, our primary experiments use a gold-evidence setting to isolate adjudication from retrieval. We additionally conduct an end-to-end retrieval-enabled experiment, but the experiment is limited in scale. CoVer should therefore be viewed as complementary to retrieval systems.

Finally, some pairwise improvements on ContraNote Conflict benchmark do not reach significance. A power analysis suggests that approximately 4.9 times more sample are needed to detect the observed accuracy difference between CoVer and CONFACT at 80% power, and approximately 2.4 times more samples for the comparison with ConflictRes. The current test set size limits the strength of our claims.

9 Ethical Considerations

The deployment of automated fact-checking systems involves potential ethical risks regarding information integrity. No automated system is infallible, and the risk of misclassification remains a primary concern. Incorrectly labeling a true claim as “Refuted” or a false claim as “Supported” can lead to the suppression of accurate information or the

inadvertent spread of misinformation. Therefore, currently the CoVer framework should be treated as a decision-support tool for maintaining information integrity rather than an authority.

Regarding data privacy, ContraNote dataset is derived from the public ✕ Community Notes and acquired via the official ✕ API. We highlighted that reproduction or further use could be conducted with an ✕ API, so as to follow the official data usage terms. Furthermore, we emphasize that all research using such datasets must comply with the platform’s terms of service, and respect the privacy and intent of the original content creators.

References

Jennifer Allen, Antonio A Arechar, Gordon Pennycook, and David G Rand. 2021. Scaling up fact-checking using the wisdom of crowds. *Science Advances*, 7(36):eabf4393.

Isabelle Augenstein, Timothy Baldwin, Meeyoung Cha, Tanmoy Chakraborty, Giovanni Luca Ciampaglia, David Corney, Renee DiResta, Emilio Ferrara, Scott Hale, Alon Halevy, Eduard Hovy, Heng Ji, Filippo Menczer, Ruben Miguez, Preslav Nakov, Dietram Scheufele, Shivam Sharma, and Giovanni Zagni. 2024. Factuality challenges in the era of large language models and opportunities for fact-checking. *Nat. Mach. Intell.*, 6(8):852–863.

Isabelle Augenstein, Christina Lioma, Dongsheng Wang, Lucas Chaves Lima, Casper Hansen, Christian Hansen, and Jakob Grue Simonsen. 2019. Multifc: A real-world multi-domain dataset for evidence-based fact checking of claims. In *Proceedings of the 2019 conference on empirical methods in natural language processing and the 9th international joint conference on natural language processing (EMNLP-IJCNLP)*, pages 4685–4697.

Michiel Bakker, Martin Chadwick, Hannah Sheahan, Michael Tessler, Lucy Campbell-Gillingham, Jan Balaguer, Nat McAleese, Amelia Glaese, John Aslanides, Matt Botvinick, and Christopher Summerfield. 2022. Fine-tuning language models to find agreement among humans with diverse preferences. In *Advances in Neural Information Processing Systems*, volume 35, pages 38176–38189. Curran Associates, Inc.

Jason W Burton, Ezequiel Lopez-Lopez, Shahar Hechtlinger, Zoe Rahwan, Samuel Aeschbach, Michiel A Bakker, Joshua A Becker, Aleks Berditchevskaia, Julian Berger, Levin Brinkmann, Lucie Flek, Stefan M Herzog, Saffron Huang, Sayash Kapoor, Arvind Narayanan, Anne-Marie Nussberger, Taha Yasseri, Pietro Nickl, Abdullah Almaatouq, and 9 others. 2024. How large language models can reshape collective intelligence. *Nat. Hum. Behav.*, 8(9):1643–1655.

8 Hạn chế

Chúng tôi nhận ra một hạn chế trong bài báo này, điều này làm nổi bật các hướng nghiên cứu trong tương lai.

Đầu tiên, khung đề xuất và bộ dữ liệu Contra-Note tập trung hoàn toàn vào các tuyên bố văn bản và siêu dữ liệu, chủ yếu bằng tiếng Anh. Mặc dù chúng tôi đa dạng hóa phạm vi ngôn ngữ, nhưng phạm vi hiện tại vẫn chưa đủ cho việc triển khai toàn diện trong thực tế. Hơn nữa, thông tin sai lệch trên mạng xã hội hiện đại là đa phương tiện. Cài đặt hiện tại của chúng tôi loại trừ việc giải quyết xung đột liên quan đến hình ảnh bị thao túng, deepfake hoặc video ngoài ngữ cảnh, vốn thường gây ra mâu thuẫn bằng chứng thực tế. Ngoài ra, hiệu quả của khung này trong các ngôn ngữ tài nguyên thấp hoặc các lĩnh vực chuyên biệt cao (ví dụ: văn bản pháp lý hoặc y tế) cần được kiểm chứng thêm.

Thứ hai, định nghĩa thực tế trong bộ dữ liệu Con- traNote dựa vào sự đồng thuận từ đám đông và các điểm hữu ích theo thuật toán. Trong khi phương pháp này phản ánh sự đồng thuận xã hội thực tiễn dưới sự kiểm soát chất lượng thuật toán, nó không hoàn toàn tương đương với sự thật tuyệt đối và vẫn dễ bị thao túng đánh giá có phối hợp. Hơn nữa, các chuyên gia gán nhãn được đào tạo có thể chia sẻ một số giả định văn hóa hoặc ý thức hệ giống như các đóng góp viên của Community Notes.

Thứ ba, các thí nghiệm chính của chúng tôi sử dụng một môi trường bằng chứng vàng để tách biệt việc xét xử khỏi việc truy xuất. Chúng tôi cũng tiến hành một thí nghiệm có khả năng truy xuất đầu-cuối, nhưng thí nghiệm này có quy mô hạn chế. Do đó, CoVer nên được xem như là bổ sung cho các hệ thống truy xuất.

Cuối cùng, một số cải tiến theo cặp trên chuẩn mực ContraNote Conflict không đạt được sự khác biệt có ý nghĩa. Phân tích công suất cho thấy cần khoảng 4,9 lần mẫu nhiều hơn để phát hiện sự khác biệt về độ chính xác quan sát được giữa CoVer và CONFACT với công suất 80%, và khoảng 2,4 lần mẫu nhiều hơn cho so sánh với ConflictRes. Kích thước bộ kiểm tra hiện tại giới hạn độ mạnh của các khẳng định của chúng tôi.

9 Cân nhắc đạo đức

Việc triển khai các hệ thống kiểm tra sự thật tự động liên quan đến các rủi ro đạo đức tiềm ẩn về tính toàn vẹn của thông tin. Không hệ thống tự động nào là không thể sai, và rủi ro phân loại sai vẫn là mối quan tâm chính. Việc gán nhãn sai một tuyên bố đúng là “Bị bác bỏ” hoặc một tuyên bố sai là “Được hỗ trợ” có thể dẫn đến việc ngăn chặn thông tin chính xác hoặc

sự lan truyền thông tin sai lệch một cách không cố ý. Vì vậy, hiện tại khung CoVer nên được coi như một công cụ hỗ trợ quyết định để duy trì tính toàn vẹn thông tin thay vì là một cơ quan có thẩm quyền.

Về quyền riêng tư dữ liệu, tập dữ liệu ContraNote được lấy từ X Community Notes công khai và được thu thập thông qua API chính thức của X. Chúng tôi nhấn mạnh rằng việc sao chép hoặc sử dụng tiếp có thể được thực hiện thông qua API của X, nhằm tuân theo các điều khoản sử dụng dữ liệu chính thức. Hơn nữa, chúng tôi nhấn mạnh rằng tất cả các nghiên cứu sử dụng các tập dữ liệu như vậy phải tuân thủ các điều khoản dịch vụ của nền tảng và tôn trọng quyền riêng tư cũng như mục đích của các tác giả nội dung gốc.

Tài liệu tham khảo

Jennifer Allen, Antonio A Arechar, Gordon Pennycook và David G Rand. 2021. Mở rộng kiểm chứng sự thật bằng cách sử dụng trí tuệ của đám đông. *Science Advances*, 7(36):eabf4393.

Isabelle Augenstein, Timothy Baldwin, Meeyoung Cha, Tanmoy Chakraborty, Giovanni Luca Ciampaglia, David Corney, Renee DiResta, Emilio Ferrara, Scott Hale, Alon Halevy, Eduard Hovy, Heng Ji, Filippo Menczer, Ruben Miguez, Preslav Nakov, Dietram Scheufele, Shivam Sharma, và Giovanni Zagni. 2024. Những thách thức về tính xác thực trong kỷ nguyên của các mô hình ngôn ngữ lớn và cơ hội cho việc kiểm tra sự thật. *Nat. Mach. Intell.*, 6(8):852–863.

Isabelle Augenstein, Christina Lioma, Dongsheng Wang, Lucas Chaves Lima, Casper Hansen, Christian Hansen, và Jakob Grue Simonsen. 2019. Multifc: Một tập dữ liệu đa miền thực tế cho việc kiểm tra sự thật dựa trên bằng chứng của các tuyên bố. Trong Kỷ yếu hội nghị năm 2019 về các phương pháp thực nghiệm trong xử lý ngôn ngữ tự nhiên và hội nghị liên hợp quốc tế lần thứ 9 về xử lý ngôn ngữ tự nhiên (EMNLP-IJCNLP), tra ng 4685–4697.

Michiel Bakker, Martin Chadwick, Hannah Sheahan, Michael Tessler, Lucy Campbell-Gillingham, Jan Balaguer, Nat McAleese, Amelia Glaese, John Aslanides, Matt Botvinick và Christopher Summerfield. 2022. Tinh chỉnh các mô hình ngôn ngữ để tìm sự đồng thuận giữa con người với các sở thích đa dạng. Trong *Advances in Neural Information Processing Systems*, tập 35, trang 38176–38189. Curran Associates, Inc.

Jason W Burton, Ezequiel Lopez-Lopez, Shahar Hechtlinger, Zoe Rahwan, Samuel Aeschbach, Michiel A Bakker, Joshua A Becker, Aleks Berditchevskaia, Julian Berger, Levin Brinkmann, Lucie Flek, Stefan M Herzog, Saffron Huang, Sayash Kapoor, Arvind Narayanan, Anne-Marie Nussberger, Taha Yasseri, Pietro Nickl, Abdullah Almaatouq và 9 người khác. 2024. Các mô hình ngôn ngữ lớn có thể tái định hình trí tuệ tập thể như thế nào. *Nat. Hum. Behav.*, 8(9):1643–1655.

Hung-Ting Chen, Michael Zhang, and Eunsol Choi. 2022a. Rich knowledge sources bring complex knowledge conflicts: Recalibrating models to reflect conflicting evidence. In *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*, pages 2292–2307.

Jifan Chen, Aniruddh Sriram, Eunsol Choi, and Greg Durrett. 2022b. Generating literal and implied sub-questions to fact-check complex claims. In *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*, pages 3495–3516.

Shiqi Chen, Yiran Zhao, Jinghan Zhang, I-Chun Chern, Siyang Gao, Pengfei Liu, and Junxian He. 2023. Felm: Benchmarking factuality evaluation of large language models. In *Advances in Neural Information Processing Systems*, volume 36, pages 44502–44523. Curran Associates, Inc.

I-Chun Chern, Steffi Chern, Shiqi Chen, Weizhe Yuan, Kehua Feng, Chunting Zhou, Junxian He, Graham Neubig, and Pengfei Liu. 2023. Factool: Factuality detection in generative ai-a tool augmented framework for multi-task and multi-domain scenarios.

Eun Cheol Choi and Emilio Ferrara. 2024. Automated claim matching with large language models: Empowering fact-checkers in the fight against misinformation. In *Companion Proceedings of the ACM Web Conference 2024*, pages 1441–1449.

Yuwei Chuai, Gabriele Lenzini, and Nicolas Pröllochs. 2026a. Consensus stability of community notes on X. In *Proceedings of the ACM Web Conference 2026*, pages 8885–8896.

Yuwei Chuai, Moritz Pilarski, Thomas Renault, David Restrepo-Amariles, Aurore Troussel-Clément, Gabriele Lenzini, and Nicolas Pröllochs. 2026b. Community-based fact-checking reduces the spread of misleading posts on X (formerly Twitter). *Nature Communications*, 17(1):4070.

Yuwei Chuai, Haoye Tian, Nicolas Pröllochs, and Gabriele Lenzini. 2024. Did the roll-out of community notes reduce engagement with misinformation on x/twitter? *Proceedings of the ACM on Human-Computer Interaction*, 8(CSCW2):1–52.

Yuwei Chuai, Jichang Zhao, Nicolas Pröllochs, and Gabriele Lenzini. 2025. Is fact-checking politically neutral? asymmetries in how us fact-checking organizations pick up false statements mentioning political elites. In *Proceedings of the International AAAI Conference on Web and Social Media*, volume 19, pages 403–429.

Soham De, Michiel A. Bakker, Jay Baxter, and Martin Saveski. 2025. Supernotes: Driving consensus in crowd-sourced fact-checking. In *Proceedings of the ACM Web Conference 2025*, pages 3751–3761.

Ziv Epstein, Gordon Pennycook, and David Rand. 2020. Will the crowd game the algorithm? using layperson judgments to combat misinformation on social media

by downranking distrusted sources. In *Proceedings of the 2020 CHI Conference on Human Factors in Computing Systems*, pages 1–11.

Sara Fish, Paul Gözl, David C Parkes, Ariel D Procaccia, Gili Rusak, Itai Shapira, and Manuel Wüthrich. 2024. Generative social choice. In *Proceedings of the 25th ACM Conference on Economics and Computation*, pages 985–985.

Ziyu Ge, Yuhao Wu, Daniel Wai Kit Chin, Roy Ka-Wei Lee, and Rui Cao. 2025. Resolving conflicting evidence in automated fact-checking: A study on retrieval-augmented llms. *arXiv preprint arXiv:2505.17762*.

Bing He, Mustaque Ahamad, and Srijan Kumar. 2023. Reinforcement learning-based counter-misinformation response generation: A case study of covid-19 vaccine misinformation. In *Proceedings of the ACM Web Conference 2023*, pages 2698–2709.

Cheng Jiayang, Chunkit Chan, Qianqian Zhuang, Lin Qiu, Tianhang Zhang, Tengxiao Liu, Yangqiu Song, Yue Zhang, Pengfei Liu, and Zheng Zhang. 2024. Econ: On the detection and resolution of evidence conflicts. In *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*, pages 7816–7844.

Hyunuk Kim and Dylan Walker. 2020. Leveraging volunteer fact checking to identify misinformation about covid-19 in social media. *Harvard Kennedy School Misinformation Review*, 1(3).

Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, Sebastian Riedel, and Douwe Kiela. 2020. Retrieval-augmented generation for knowledge-intensive nlp tasks. In *Advances in Neural Information Processing Systems*, volume 33, pages 9459–9474. Curran Associates, Inc.

Yaliang Li, Jing Gao, Chuishi Meng, Qi Li, Lu Su, Bo Zhao, Wei Fan, and Jiawei Han. 2016. A survey on truth discovery. *ACM Sigkdd Explorations Newsletter*, 17(2):1–16.

Shanshan Lyu, Wentao Ouyang, Huawei Shen, and Xueqi Cheng. 2017. Truth discovery by claim and source embedding. In *Proceedings of the 2017 ACM on Conference on Information and Knowledge Management*, pages 2183–2186.

Nicholas Micallef, Bing He, Srijan Kumar, Mustaque Ahamad, and Nasir Memon. 2020. The role of the crowd in countering misinformation: A case study of the covid-19 infodemic. In *2020 IEEE International Conference on Big Data (big data)*, pages 748–757. IEEE.

Sewon Min, Kalpesh Krishna, Xinxì Lyu, Mike Lewis, Wen-tau Yih, Pang Koh, Mohit Iyyer, Luke Zettlemoyer, and Hannaneh Hajishirzi. 2023. Factscore: Fine-grained atomic evaluation of factual precision

Hung-Ting Chen, Michael Zhang, and Eunsol Choi. 2022a. Nguồn tri thức phong phú mang lại xung đột kiến thức phức tạp: Điều chỉnh lại các mô hình để phản ánh bằng chứng mâu thuẫn. Trong Kỷ yếu của Hội nghị 2022 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên, trang 2292–2307.

Jifan Chen, Aniruddh Sriram, Eunsol Choi, và Greg Durrett. 2022b. Tạo các câu hỏi phụ theo nghĩa đen và ngụ ý để kiểm tra tính xác thực của các khẳng định phức tạp. Trong Kỷ yếu Hội nghị về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên 2022, trang 3495–3516.

Shiqi Chen, Yiran Zhao, Jinghan Zhang, I-Chun Chern, Siyang Gao, Pengfei Liu, và Junxian He. 2023. Felm: Đánh giá chuẩn về tính xác thực của các mô hình ngôn ngữ lớn. Trong Advances in Neural Information Processing Systems, tập 36, trang 44502–44523. Curran Associates, Inc.

I-Chun Chern, Steffi Chern, Shiqi Chen, Weizhe Yuan, Kehua Feng, Chunting Zhou, Junxian He, Graham Neubig và Pengfei Liu. 2023. Factool: Phát hiện tính t hực tế trong AI tạo sinh - một khung công cụ tăng cường cho nhiều nhiệm vụ và nhiều miền.

Eun Cheol Choi và Emilio Ferrara. 2024. Tự động so khớp tuyên bố với các mô hình ngôn ngữ lớn: Trao quyền cho các nhà kiểm chứng sự thật trong cuộc chiến chống lại thông tin sai lệch. Trong Kỷ yếu Phụ trợ hội nghị Web ACM 2024, trang 1441–1449.

Yuwei Chuai, Gabriele Lenzini, và Nicolas Pröllochs. 2026a. Ổn định đồng thuận của các ghi chú cộng đồng trên X. Trong Kỷ yếu Hội nghị Web ACM 2026, trang 8885–8896.

Yuwei Chuai, Moritz Pilarski, Thomas Renault, David Restrepo-Amariles, Aurore Troussel-Clément, Gabriele Lenzini, và Nicolas Pröllochs. 2026b. Kiểm tra sự thật dựa trên cộng đồng giảm sự lan truyền của các bài đăng gây hiểu nhầm trên X (trước đây là Twitter). Nature Communications, 17(1):4070.

Yuwei Chuai, Haoye Tian, Nicolas Pröllochs, và Gabriele Lenzini. 2024. Việc triển khai các ghi chú cộng đồng có làm giảm sự tương tác với thông tin sai lệch trên x/twitter không? Kỷ yếu của ACM về Tương tác Người-Máy tính, 8(CSCW2):1–52.

Yuwei Chuai, Jichang Zhao, Nicolas Pröllochs, và Gabriele Lenzini. 2025. Việc kiểm chứng sự kiện có t rung lập về chính trị không? Sự bất đối xứng trong cách các tổ chức kiểm chứng sự kiện ở Mỹ phát hiện các phát biểu sai lệch liên quan đến các nhân vật chính trị cấp cao. Trong Kỷ yếu Hội nghị AAAI Quốc tế về Web và Mạng xã hội, tập 19, trang 403–429.

Soham De, Michiel A. Bakker, Jay Baxter, và Martin Saveski. 2025. Supernotes: Thúc đẩy sự đồng thuận trong kiểm tra thực tế dựa vào đám đông. Trong Kỷ yếu Hội nghị Web ACM 2025, trang 3751–3761.

Ziv Epstein, Gordon Pennycook và David Rand. 2020. Liệu đám đông có thao túng thuật toán? Sử dụng đánh giá của người không chuyên để chống lại thông tin sai lệch trên mạng xã hội

bằng cách hạ thứ hạng các nguồn không đáng tin cậy. Trong Kỷ yếu Hội nghị CHI 2020 về các Yếu tố Con người trong Hệ thống Máy tính, trang 1–11. Sara Fish, Paul Gözl, David C Parkes, Ariel D Procaccia, Gili Rusak, Itai Shapira, và Manuel Wüthrich. 2024. Lựa chọn xã hội sinh sinh. Trong Kỷ yếu Hội nghị lần thứ 25 của ACM về Kinh tế và Tính toán, trang 985–985. Ziyu Ge, Yuhao Wu, Daniel Wai Kit Chin, Roy Ka-Wei Lee, và Rui Cao. 2025. Giải quyết bằng chứng mâu thuẫn trong kiểm chứng sự thật tự động: Một nghiên cứu về mô hình ngôn ngữ lớn hỗ trợ truy xuất. arXiv preprint arXiv:2505.17762.

Bing He, Mustaque Ahamad, và Srijan Kumar. 2023. Tạo phản hồi chống sai lệch thông tin dựa trên học tăng cường: Một nghiên cứu trường hợp về thông tin sai lệch về vaccine covid-19. Trong Kỷ yếu Hội nghị Web ACM 2023, trang 2698–2709.

Cheng Jiayang, Chunkit Chan, Qianqian Zhuang, Lin Qiu, Tianhang Zhang, Tengxiao Liu, Yangqiu Song, Yue Zhang, Pengfei Liu, và Zheng Zhang. 2024. Econ: Về việc phát hiện và giải quyết xung đột bằng chứng. Trong Kỷ yếu Hội nghị Năm 2024 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên, trang 7816–7844.

Hyunuk Kim và Dylan Walker. 2020. Tận dụng kiểm tra sự thật tình nguyện để xác định thông tin sai lệch về covid-19 trên mạng xã hội. Harvard Kennedy School Misinformation Review, 1(3).

Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, Sebastian Riedel, và Douwe Kiela. 2020. Tăng cường truy xuất dữ liệu cho các tác vụ NLP đòi hỏi nhiều kiến thức. Trong Advances in Neural Information Processing Systems, tập 33, trang 9459–9474. Curran Associates, Inc.

Yaliang Li, Jing Gao, Chuishi Meng, Qi Li, Lu Su, Bo Zhao, Wei Fan, và Jiawei Han. 2016. Một khảo sát về khám phá sự thật. Thư tin ACM Sigkdd Explorations, 17(2):1–16.

Shanshan Lyu, Wentao Ouyang, Huawei Shen, và Xueqi Cheng. 2017. Khám phá sự thật bằng cách nhúng tuyên bố và nguồn. Trong Kỷ yếu Hội nghị ACM 2017 về Quản lý Thông tin và Kiến thức, trang 2183–2186.

Nicholas Micallef, Bing He, Srijan Kumar, Mustaque Ahamad, và Nasir Memon. 2020. Vai trò của đám đông trong việc chống lại thông tin sai lệch: Một nghiên cứu tình huống về dịch tin tức sai lệch covid-19. Trong Hội nghị Quốc tế IEEE về Dữ liệu Lớn 2020 (big data), trang 748–757. IEEE.

Sewon Min, Kalpesh Krishna, Xinxì Lyu, Mike Lewis, Wen-tau Yih, Pang Koh, Mohit Iyyer, Luke Zettlemoyer, và Hannaneh Hajishirzi. 2023. Factscore: Đánh giá chi tiết cấp nguyên tử về độ chính xác của các sự kiện

in long form text generation. In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, pages 12076–12100.

Yifei Ming, Senthil Purushwalkam, Shrey Pandit, Zixuan Ke, Xuan-Phi Nguyen, Caiming Xiong, and Shafiq Joty. 2024. Faitheval: Can your language model stay faithful to context, even if" the moon is made of marshmallows". In *The Thirteenth International Conference on Learning Representations*.

Atahan Özer and Çağatay Yıldız. 2025. Question answering under temporal conflict: Evaluating and organizing evolving knowledge with llms. *arXiv preprint arXiv:2506.07270*.

Gordon Pennycook and David G Rand. 2019. Fighting misinformation on social media using crowdsourced judgments of news source quality. *Proceedings of the National Academy of Sciences*, 116(7):2521–2526.

Kashyap Papat, Subhabrata Mukherjee, Andrew Yates, and Gerhard Weikum. 2018. Declare: Debunking fake news and false claims using evidence-aware deep learning. In *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing*, pages 22–32.

Peng Qi, Zehong Yan, Wynne Hsu, and Mong Li Lee. 2024. Sniffer: Multimodal large language model for explainable out-of-context misinformation detection. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 13052–13062.

Dorian Quelle and Alexandre Bovet. 2024. The perils and promises of fact-checking with large language models. *Frontiers in Artificial Intelligence*, 7:1341697.

Michael Schlichtkrull, Zhijiang Guo, and Andreas Vlachos. 2023. Averitec: A dataset for real-world claim verification with evidence from the web. *Advances in Neural Information Processing Systems*, 36:65128–65167.

Jeremy Straub and Matthew Spradling. 2022. Americans’ perspectives on online media warning labels. *Behavioral Sciences*, 12(3):59.

Zhaochen Su, Jun Zhang, Xiaoye Qu, Tong Zhu, Yanshu Li, Jiashuo Sun, Juntao Li, Min Zhang, and Yu Cheng. 2024. Conflictbank: A benchmark for evaluating knowledge conflicts in large language models. In *Proceedings of the 38th International Conference on Neural Information Processing Systems*, pages 103242–103268.

Hexiang Tan, Fei Sun, Wanli Yang, Yuanzhuo Wang, Qi Cao, and Xueqi Cheng. 2024. Blinded by generated contexts: How language models merge generated and retrieved contexts when knowledge conflicts? In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 6207–6227.

James Thorne, Andreas Vlachos, Christos Christodoulopoulos, and Arpit Mittal. 2018. Fever: A large-scale dataset for fact extraction and verification. In *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long Papers)*, pages 809–819.

Alexander Wan, Eric Wallace, and Dan Klein. 2024. What evidence do language models find convincing? In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 7468–7484.

Han Wang, Archiki Prasad, Elias Stengel-Eskin, and Mohit Bansal. 2025. Retrieval-augmented generation with conflicting evidence. *arXiv preprint arXiv:2504.13079*.

Haoran Wang and Kai Shu. 2023. Explainable claim verification via knowledge-grounded reasoning with large language models. In *Findings of the Association for Computational Linguistics: EMNLP 2023*, pages 6288–6304.

Yuxia Wang, Revanth Gangi Reddy, Zain Muhammad Mujahid, Arnav Arora, Aleksandr Rubashevskii, Jiahui Geng, Osama Mohammed Afzal, Liangming Pan, Nadav Borenstein, Aditya Pillai, Isabelle Augenstein, Iryna Gurevych, and Preslav Nakov. 2024. Factcheck-bench: Fine-grained evaluation benchmark for automatic fact-checkers. In *Findings of the Association for Computational Linguistics: EMNLP 2024*, pages 14199–14230, Miami, Florida, USA. Association for Computational Linguistics.

X Corp. 2025. Community notes guide: Downloading data. <https://communitynotes.x.com/guide/en/under-the-hood/download-data>. [Accessed: 2026-02-09].

X Corp. 2026. About community notes on x. <https://help.x.com/en/using-x/community-notes>. [Accessed: 2026-02-09].

Jian Xie, Kai Zhang, Jiangjie Chen, Renze Lou, and Yu Su. 2023. Adaptive chameleon or stubborn sloth: Revealing the behavior of large language models in knowledge conflicts. In *The Twelfth International Conference on Learning Representations*.

Zhuohan Xie, Rui Xing, Yuxia Wang, Jiahui Geng, Hasan Iqbal, Dhruv Sahnan, Iryna Gurevych, and Preslav Nakov. 2025. Fire: Fact-checking with iterative retrieval and verification. In *Findings of the Association for Computational Linguistics: NAACL 2025*, pages 2901–2914.

Joshua C Yang, Damian Dalisan, Marcin Korecki, Carina I Hausladen, and Dirk Helbing. 2024. Llm voting: Human choices and ai collective decision-making. In *Proceedings of the AAAI/ACM Conference on AI, Ethics, and Society*, volume 7, pages 1696–1708.

trong việc tạo văn bản dài. Trong *Kỷ yếu Hội nghị Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên 2023*, các trang 12076–12100.

Yifei Ming, Senthil Purushwalkam, Shrey Pandit, Zixuan Ke, Xuan-Phi Nguyen, Caiming Xiong, và Shafiq Joty. 2024. Faitheval: Liệu mô hình ngôn ngữ của bạn có thể giữ trung thực với ngữ cảnh, ngay cả khi “mặt trăng được làm từ kẹo dẻo”? Trong Hội nghị Quốc tế lần thứ mười ba về Học đại diện.

Atahan Özer và Çağatay Yıldız. 2025. Trả lời câu hỏi dưới xung đột thời gian: Đánh giá và tổ chức kiến thức đang phát triển với các mô hình ngôn ngữ lớn. Bản thảo arXiv arXiv:2506.07270.

Gordon Pennycook và David G Rand. 2019. Chống lại thông tin sai lệch trên mạng xã hội bằng cách sử dụng đánh giá từ cộng đồng về chất lượng nguồn tin. Kỷ yếu của Viện Hàn lâm Khoa học Quốc gia, 116(7):2521–2526.

Kashyap Papat, Subhabrata Mukherjee, Andrew Yates, và Gerhard Weikum. 2018. Declare: Vạch trần tin giả và những tuyên bố sai bằng cách sử dụng học sâu nhận thức bằng chứng. Trong Kỷ yếu của Hội nghị năm 2018 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên, trang 22–32.

Peng Qi, Zehong Yan, Wynne Hsu, và Mong Li Lee. 2024. Sniffer: Mô hình ngôn ngữ lớn đa phương thức cho phát hiện thông tin sai lệch ngoài ngữ cảnh có thể giải thích. Trong Kỷ yếu Hội nghị IEEE/CVF về Thị giác Máy tính và Nhận dạng Mẫu, trang 13052–13062.

Dorian Quelle và Alexandre Bovet. 2024. Những hiểm họa và hứa hẹn của việc kiểm chứng thông tin với các mô hình ngôn ngữ lớn. Frontiers in Artificial Intelligence, 7:1341697.

Michael Schlichtkrull, Zhijiang Guo, và Andreas Vlachos. 2023. Averitec: Một bộ dữ liệu cho việc xác minh tuyên bố trong thế giới thực với bằng chứng từ web. Advances in Neural Information Processing Systems, 36:65128–65167.

Jeremy Straub và Matthew Spradling. 2022. Quan điểm của người Mỹ về nhãn cảnh báo trên phương tiện trực tuyến. Khoa học Hành vi, 12(3):59.

Zhaochen Su, Jun Zhang, Xiaoye Qu, Tong Zhu, Yanshu Li, Jiashuo Sun, Juntao Li, Min Zhang, và Yu Cheng. 2024. Conflictbank: Một chuẩn mực để đánh giá xung đột kiến thức trong các mô hình ngôn ngữ lớn. Trong Kỷ yếu Hội nghị Quốc tế lần thứ 38 về Hệ thống Xử lý Thông tin Thần kinh, các trang 103242–103268.

Hexiang Tan, Fei Sun, Wanli Yang, Yuanzhuo Wang, Qi Cao, và Xueqi Cheng. 2024. Bị mù trước các ngữ cảnh được tạo ra: Các mô hình ngôn ngữ kết hợp ngữ cảnh được tạo ra và được truy xuất như thế nào khi kiến thức mâu thuẫn? Trong Kỷ yếu Hội nghị thường niên lần thứ 62 của Hiệp hội Ngôn ngữ học Máy tính (Tập 1: Bài báo dài), các trang 6207–6227.

James Thorne, Andreas Vlachos, Christos Christodoulopoulos, và Arpit Mittal. 2018. Fever: Một tập dữ liệu quy mô lớn cho việc trích xuất và xác minh thông tin. Trong Kỷ yếu Hội nghị 2018 của Chương Bắc Mỹ thuộc Hiệp hội Ngôn ngữ học Máy tính: Công nghệ Ngôn ngữ Con người, Tập 1 (Bài báo Dài), trang 809–819.

Alexander Wan, Eric Wallace, và Dan Klein. 2024. Ngôn ngữ mô hình tìm thấy bằng chứng nào thuyết phục? Trong Kỷ yếu của Hội nghị thường niên lần thứ 62 của Hiệp hội Ngôn ngữ học Máy tính (Tập 1: Bài báo dài), trang 7468–7484.

HanWang, ArchikiPrasad, EliasStengel-Eskin, và Mohit Bansal. 2025. Tạo sinh tăng cường truy xuất với bằng chứng mâu thuẫn. arXiv preprint arXiv:2504.13079.

Haoran Wang và Kai Shu. 2023. Xác minh tuyên bố có thể giải thích thông qua lập luận dựa trên tri thức với các mô hình ngôn ngữ lớn. Trong Kết quả của Hiệp hội Ngôn ngữ Học Máy tính: EMNLP 2023, trang 6288–6304.

Yuxia Wang, Revanth Gangi Reddy, Zain Muhammad Mujahid, Arnav Arora, Aleksandr Rubashevskii, Jiahui Geng, Osama Mohammed Afzal, Liangming Pan, Nadav Borenstein, Aditya Pillai, Isabelle Augenstein, Iryna Gurevych, và Preslav Nakov. 2024. Factcheck-bench: Bộ đánh giá chi tiết cho các công cụ kiểm tra sự thật tự động. Trong Kết quả của Hiệp hội Ngôn ngữ học Máy tính: EMNLP 2024, trang 14199–14230, Miami, Florida, USA. Hiệp hội Ngôn ngữ học Máy tính.

X Corp. 2025. Hướng dẫn ghi chú cộng đồng: Tải dữ liệu. <https://communitynotes.x.com/guide/en/under-the-hood/download-data>. [Truy cập: 2026-02-09].

X Corp. 2026. Về các ghi chú cộng đồng trên x. <https://help.x.com/en/using-x/community-notes>[Truy cập: 2026-02-09].

Jian Xie, Kai Zhang, Jiangjie Chen, Renze Lou, và Yu Su. 2023. Tác kè thích nghi hay lười biếng bướng bỉnh: Tiết lộ hành vi của các mô hình ngôn ngữ lớn trong xung đột kiến thức. Trong Hội nghị Quốc tế lần thứ mười hai về Biểu diễn Học tập.

Zhuohan Xie, Rui Xing, Yuxia Wang, Jiahui Geng, Hasan Iqbal, Dhruv Sahnan, Iryna Gurevych, và Preslav Nakov. 2025. Fire: Kiểm chứng sự thật với truy xuất và xác minh lặp đi lặp lại. Trong Kết quả của Hiệp hội Ngôn ngữ học Máy tính: NAACL 2025, trang 2901–2914.

Joshua C Yang, Damian Dalisan, Marcin Korecki, Carina I Hausladen, và Dirk Helbing. 2024. Bỏ phiếu LLM: Lựa chọn của con người và quyết định tập thể của AI. Trong Kỷ yếu Hội nghị AAAI/ACM về AI, Đạo đức và Xã hội, tập 7, trang 1696–1708.

Zhenrui Yue, Huimin Zeng, Yimeng Lu, Lanyu Shang, Yang Zhang, and Dong Wang. 2024. Evidence-driven retrieval augmented response generation for online misinformation. In *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers)*, pages 5628–5643.

Fengzhu Zeng and Wei Gao. 2024. Justilm: Few-shot justification generation for explainable fact-checking of real-world claims. *Transactions of the Association for Computational Linguistics*, 12:334–354.

Shuning Zhang, Linzhi Wang, Shixuan Li, Yuanyuan Wu, Yuwei Chuai, Luoxi Chen, Xin Yi, and Hewu Li. 2026. Collab: Fostering critical identification of deepfake videos on social media via synergistic annotation. In *Proceedings of the 2026 CHI Conference on Human Factors in Computing Systems*, pages 1–21.

Xinyi Zhou, Ashish Sharma, Amy X Zhang, and Tim Althoff. 2024. Correcting misinformation on social media with a large language model. *arXiv preprint arXiv:2403.11169*.

A Generative AI Usage

In accordance with generative AI usage policies, we disclose the use of Generative AI tools. We used generative AI as the base model for the experiment. Besides, we utilized Google’s Gemini 3 Pro and ChatGPT (i.e., GPT-5.2) as writing assistants. Except for Figure 3, which was edited by Gemini Nano Banana, the Generative AI tool was used only for the purpose of improving the quality of writing. Its functions were limited to proofreading, language and clarity enhancement, conciseness, and word choice, and was not used to generate any core scientific content. The tool was applied to refine the final manuscript, after the content of each section was completed by the authors.

B Dataset Details

B.1 Comparisons of Datasets

Table 4 contains the comparisons of datasets, where NEI denotes Not Enough Information.

B.2 Dataset Analysis

As shown in Figure 2, we provide an analysis of the **ContraNote** dataset. The primary reasons for flagging claims as misleading are missing important context (22,615 instances) and factual errors (20,918 instances). Other categories include unverified claims presented as facts (13,087 instances), outdated information (9,508 instances),

satire (5,381 instances), manipulated media (5,124 instances), and other reasons (6,461 instances). Statistical analysis indicates that refuting notes are generally more detailed than supporting ones. Specifically, refuting notes average 1.77 per post and 289.08 characters in length, whereas supporting notes average 1.61 per post and 163.64 characters.

We grouped the cited evidence links in ContraNote into six source categories. Web and news pages constitute 49.1% of the links, followed by social-media and video platforms (24.6%), Wikipedia (8.6%), government or other official sources (7.9%), dedicated fact-checking sites (7.3%), and other sources (2.5%). The result shows that ContraNote is not dominated by short encyclopedic passages. A large share of its evidence comes from heterogeneous, socially situated sources for which authority and provenance need to be assessed.

Two researchers manually examined the semantic relation among a post, its strongest corrective note, and the competing note. The most frequent pattern is *note-necessity disagreement*, accounting for 33% of the manually coded cases. In these cases, the competing note does not necessarily establish that the post is factually true; instead, it argues that no Community Note is needed because the post is satire, opinion, or a platform-policy issue. The analysis also identifies *evidential-authority disagreement*, in which notes rely on sources with different authority; *scope or definition mismatch*, in which the same statement is evaluated under different temporal or definitional scopes; and *entity/event attribution conflict*, in which evidence is attached to a different person, event, or provenance. For example, evidence may support a statement about a historical policy but fail to support the same statement when applied to current policy. These categories show that ContraNote contains contextual and aggregation-level disagreement in addition to direct factual negation. Because aggregate frequencies were not retained for remaining categories, we describe them qualitatively.

Furthermore, we analyzed the language distribution of posts with successfully retrieved text. Of these posts, 13,776 are in English, accounting for 62.98%; 1,758 are in Spanish, accounting for 8.04%; and 1,368 are in Portuguese, accounting for 6.25%. Other posts are written in French, Japanese, German, Chinese, and other languages.

As compared in Table 4, ContraNote extends MultiFC (Augenstein et al., 2019), AVeriTeC (Schlichtkrull et al., 2023), and

Zhenrui Yue, Huimin Zeng, Yimeng Lu, Lanyu Shang, Yang Zhang và Dong Wang. 2024. Tạo phản hồi tăng cường truy xuất dựa trên bằng chứng cho thông tin sai lệch trực tuyến. Trong Kỷ yếu Hội nghị 2024 của Chi nhánh Bắc Mỹ Hiệp hội Ngôn ngữ Học Máy Tính: Công nghệ Ngôn ngữ Con người (Tập 1: Bài báo dài), trang 5628–5643.

Fengzhu Zeng và Wei Gao. 2024. Justilm: Tạo lập biện minh theo vài ví dụ cho việc kiểm chứng sự thật có thể giải thích được của các tuyên bố trong thế giới thực. Transactions of the Association for Computational Linguistics, 12:334–354.

Shuning Zhang, Linzhi Wang, Shixuan Li, Yuanyuan Wu, Yuwei Chuai, Luoxi Chen, Xin Yi và Hewu Li. 2026. Collab: Thúc đẩy việc nhận diện quan trọng các video deepfake trên mạng xã hội thông qua chú thích hợp lực. Trong Kỷ yếu Hội nghị CHI 2026 về Các Yếu tố Con người trong Hệ thống Tính toán, trang 1–21.

Xinyi Zhou, Ashish Sharma, Amy X Zhang, và Tim Althoff. 2024. Chỉnh sửa thông tin sai lệch trên mạng xã hội bằng mô hình ngôn ngữ lớn. bản in trước arXiv arXiv:2403.11169.

Một Sử Dụng GenerativeAI

Theo các chính sách sử dụng AI tạo sinh, chúng tôi công khai việc sử dụng các công cụ AI tạo sinh. Chúng tôi đã sử dụng AI tạo sinh làm mô hình cơ sở cho thí nghiệm. Bên cạnh đó, chúng tôi đã sử dụng Google Gemini 3 Pro và ChatGPT (tức GPT-5.2) như các trợ lý viết. Ngoại trừ Hình 3, được chỉnh sửa bởi Gemini Nano Banana, công cụ AI tạo sinh chỉ được sử dụng với mục đích cải thiện chất lượng viết. Các chức năng của nó chỉ giới hạn ở việc hiệu đính, nâng cao ngôn ngữ và độ rõ ràng, rút gọn và lựa chọn từ, và không được dùng để tạo bất kỳ nội dung khoa học cốt lõi nào. Công cụ này được áp dụng để hoàn thiện bản thảo cuối cùng, sau khi nội dung của từng phần đã được các tác giả hoàn thành.

Chi tiết bộ dữ liệu B

B.1 So sánh các tập dữ liệu

Bảng 4 chứa các so sánh của các bộ dữ liệu, trong đó NEI nghĩa là Không đủ thông tin.

B.2 Phân Tích Bộ Dữ Liệu

Như được trình bày trong Hình 2, chúng tôi cung cấp một phân tích về bộ dữ liệu ContraNote. Những lý do chính để gắn cờ các tuyên bố là gây hiểu lầm bao gồm thiếu bối cảnh quan trọng (22.615 trường hợp) và sai sự thật (20.918 trường hợp). Các loại khác bao gồm các tuyên bố chưa được xác minh được trình bày như sự thật (13.087 trường hợp), thông tin lỗi thời (9.508 trường hợp),

châm biếm (5.381 trường hợp), truyền thông bị t hao túng (5.124 trường hợp) và các lý do khác (6.461 trường hợp). Phân tích thống kê cho thấy các ghi chú phản bác thường chi tiết hơn các ghi chú ủng hộ. Cụ thể, ghi chú phản bác trung bình 1,77 ghi chú mỗi bài đăng và dài 289,08 ký tự, trong khi ghi chú ủng hộ trung bình 1,61 ghi chú mỗi bài đăng và dài 163,64 ký tự.

Chúng tôi đã nhóm các liên kết bằng chứng được trích dẫn trong ContraNote thành sáu loại nguồn. Các trang web và trang tin tức chiếm 49,1% các liên kết, tiếp theo là các nền tảng mạng xã hội và video (24,6%), Wikipedia (8,6%), các nguồn chính phủ hoặc nguồn chính thức khác (7,9%), các trang web kiểm tra sự thật chuyên dụng (7,3%), và các nguồn khác (2,5%). Kết quả cho thấy ContraNote không bị chi phối bởi các đoạn trích khoa ngắn. Một phần lớn bằng chứng của nó đến từ các nguồn đa dạng, có bối cảnh xã hội mà quyền hạn và xuất xứ cần được đánh giá.

Hai nhà nghiên cứu đã kiểm tra thủ công mối quan hệ ngữ nghĩa giữa một bài đăng, ghi chú một cách chỉnh sửa mạnh nhất của nó và ghi chú cạnh tranh. Mẫu phổ biến nhất là bất đồng về tính cần thiết của ghi chú, chiếm 33% các trường hợp được mã hóa thủ công. Trong những trường hợp này, ghi chú cạnh tranh không nhất thiết xác nhận rằng bài đăng là đúng sự thật; thay vào đó, nó lập luận rằng không cần Ghi chú Cộng đồng vì bài đăng là châm biếm, ý kiến hoặc vấn đề chính sách của nền tảng. Phân tích cũng xác định bất đồng về thẩm quyền chứng cứ, trong đó các ghi chú dựa vào các nguồn có thẩm quyền khác nhau; sự không khớp về phạm vi hoặc định nghĩa, trong đó cùng một tuyên bố được đánh giá theo các phạm vi thời gian hoặc định nghĩa khác nhau; và xung đột về gán thực thể/sự kiện, trong đó bằng chứng được gán cho một người, sự kiện hoặc nguồn gốc khác. Ví dụ, bằng chứng có thể hỗ trợ một tuyên bố về chính sách lịch sử nhưng không hỗ trợ cùng tuyên bố khi áp dụng cho chính sách hiện tại. Những danh mục này cho thấy ContraNote chứa

Hơn nữa, chúng tôi đã phân tích phân bố ngôn ngữ của các bài đăng có văn bản được truy xuất thành công. Trong số các bài đăng này, 13.776 bài bằng tiếng Anh, chiếm 62,98%; 1.758 bài bằng tiếng Tây Ban Nha, chiếm 8,04%; và 1.368 bài bằng tiếng Bồ Đào Nha, chiếm 6,25%. Các bài đăng khác được viết bằng tiếng Pháp, tiếng Nhật, tiếng Đức, tiếng Trung Quốc và các ngôn ngữ khác.

Như so sánh trong Bảng 4, ContraNote mở rộng MultiFC (Augenstein và cộng sự, 2019), AVeriTeC (Schlichtkrull và cộng sự, 2023), và

Dataset	Source domain	Claim type	Evidence type	Heterogeneous sources	Explicit evidence conflict	Subclaim decomposition	Evidence-prioritization labels	Social-media origin	Claim-level labels
FEVER	Wikipedia	Factoid	Wikipedia sentences	No	No	No	No	No	Supported / Refuted / NEI
MultiFC	Fact-checking websites	Real-world claims	Heterogeneous web documents	Yes	No	No	No	Partly	Claim-level veracity
AVeriTeC	Web and fact-checking sources	Real-world claims	Retrieved web evidence	Yes	No	No	No	Partly	Supported / Refuted
ClaimDecomp	Web fact-checking	Complex claims	Claim-linked evidence	Yes	No	Yes	No	Partly	Claim- and subclaim-level veracity
WikiContradict	Wikipedia	Contradictory claims	Wikipedia passages	Limited	Yes	No	No	No	Contradiction labels
AmbiFC	Real-world fact-checking	Ambiguous claims	Claim-linked evidence	Yes	Partly	Partly	No	Partly	Ambiguous / non-ambiguous
ContraNote Conflict	% Community Notes	Social-media claims	Multiple user-generated notes	Yes	Yes	Yes	No	Yes	Supported / Refuted
ContraNote Prioritization	% Community Notes	Social-media claims	Competing candidate notes	Yes	Yes	Yes	Yes	Yes	Supported-note / Refuted-note target

Table 4: Comparison of ContraNote with representative fact-checking datasets. ContraNote Conflict provides claim-level verification labels, whereas ContraNote Prioritization additionally labels which competing evidence item should be prioritized.

ClaimDecomp (Chen et al., 2022b), which introduced real-world contrasting evidence into fact-checking. ContraNote specifically annotates naturally occurring evidence conflicts within the same post, and separates two forms of conflict (i.e., evidence- and aggregation-level).

To assess the reliability of automatically derived labels, we randomly sampled 500 instances from ContraNote and recruited three trained annotators. They independently judged each post’s veracity using the post content, the associated notes, and their cited evidence, achieving substantial inter-annotator agreement (Fleiss’ $\kappa = 0.82$). Majority vote human labels agreed with ContraNote labels on 94.2% of instances. This validates labels’ accuracy.

As Community Notes contributors may not represent all demographics, ContraNote may have population and ideological skew. We characterize its stance and topic distributions. Using PoliticalBiasBERT, we classify the notes into left, center, and right categories, with proportions of 18.6%, 47.0% and 34.4% respectively. On the human-annotated subset, the topic distribution is politics/governance (26.0%), health/medicine (4.0%), science/technology (20.6%), media/entertainment/sports (29.8%), economy/finance (5.8%), public safety/crime (6.8%), and other/ general (10.4%). Topic annotations by three annotators achieved Fleiss’ $\kappa = 0.84$. These indicate that ContraNote reflects the consensus signal generated by Community Notes mechanism.

C Extended Evaluation

C.1 Class-wise Results for the Baseline Conditions

We reported the class-wise results for the baseline conditions in Tables 5 and 6. Table 5 showed the performance on the supported class, while Table 6 showed the performance on the refuted class.

C.2 Additional Results on Baselines

We additionally evaluate ClaimDecomp, MADAM-RAG, and an AVeriTeC-style verification baseline in Table 7. ClaimDecomp obtains mac. F1 scores of 67.28, 76.21, 54.29, and 65.58 on CONFACT-HumC, CONFACT-ModC, ContraNote Conflict, and ContraNote Prioritization, respectively. MADAM-RAG obtains 47.70 and 70.30 on the two ContraNote benchmarks, while the AVeriTeC-style baseline obtains 65.60 and 80.50. These results provide additional comparisons with methods designed for claim decomposition, retrieval-augmented verification, and conflict resolution.

On the additional datasets, CoVer obtains mac. F1 scores of 92.60 on AVeriTeC, 84.00 on WikiContradict, and 92.20 on AmbiFC. These experiments indicate that the framework is applicable beyond ContraNote, although the datasets differ in task formulation and evidence structure.

C.3 Multi-Call Baseline

Table 8 reports the shortcut and multi-call baselines. The metadata shortcut baseline achieves 81.5% accuracy on ContraNote Conflict, but only 44.9 macro-F1 and 50.0 balanced accuracy. Its high accuracy is attributable to strong class imbalance rather than reliable verification. On ContraNote Prioritization, the same rule obtains 50.0% accuracy, 33.3 macro-F1, and 50.0 balanced accuracy, which is close to chance. Thus, the benchmark cannot be adequately solved by the metadata rule alone.

For the matched-call control, we use fixed evidence for all four baselines within each task. We aggregate predictions by majority vote, breaking ties as Refuted, with results shown in Table 8.

C.4 Three-way Verification

To examine whether CoVer can represent partial correctness, we construct a three-way setting with the labels Supported, Partially Supported, and Refuted. An instance is labeled Partially Supported

Bộ dữ liệu	Miền nguồn	Loại yêu cầu	Loại minh chứng	Đa dạng nguồn	Bảng chứng rõ ràng xung đột	Yêu cầu phụ sự phản hủy	Ưu tiên bằng chứng nhân	Mạng xã hội nguồn gốc	Cấp độ yêu cầu nhân
SỐT	Wikipedia	Sự thật nhỏ	Các câu trên Wikipedia	No	No	No	No	No	Được hỗ trợ / Bị phản bác / Không kết luận được
MultiFC	Trang web kiểm chứng sự thật	Các yêu cầu kiểm chứng sự thật	Tài liệu web không đồng nhất	Yes	No	No	No	Một phần	Tình xác thực ở mức từng tuyên bố
AVeriTeC	Các nguồn web và kiểm chứng sự thật	Các tuyên bố trong đó giải thích	Bảng chứng web đã được truy xuất	Yes	No	No	No	Một phần	Được hỗ trợ / Bị phản bác
Phân tách yêu cầu	Kiểm chứng sự thật trên web	Các yêu cầu phức tạp	Bảng chứng liên quan đến yêu cầu	Yes	No	Yes	No	Một phần	Tình xác thực ở cấp độ tuyên bố và phụ tuyên bố
WikiTeC-Ngược	Wikipedia	Những tuyên bố mâu thuẫn	Các đoạn văn trên Wikipedia	Giới hạn	Yes	No	No	No	Nhân mâu thuẫn
AmbiFC	Kiểm chứng sự thật trong đó giải thích	Những tuyên bố mơ hồ	Bảng chứng liên quan đến yêu cầu	Yes	Một phần	Một phần	No	Một phần	Mơ hồ / không mơ hồ
Xung đột ContraNote	Ghi chú Cộng đồng X	Những tuyên bố trên mạng xã hội	Nhiều ghi chú do người dùng tạo	Yes	Yes	Yes	No	Yes	Được hỗ trợ / Bị phản bác
Ưu tiên ContraNote	Ghi chú Cộng đồng X	Những tuyên bố trên mạng xã hội	Ghi chú của ứng viên cạnh tranh	Yes	Yes	Yes	Yes	Yes	Ghi chú được hỗ trợ / Ghi chú bị bác bỏ mục tiêu

Bảng 4: So sánh ContraNote với các bộ dữ liệu kiểm chứng sự thật tiêu biểu. ContraNote Conflict cung cấp nhãn xác minh ở cấp độ tuyên bố, trong khi ContraNote Prioritization bổ sung nhãn xác định mục bằng chứng cạnh tranh nào nên được ưu tiên.

ClaimDecomp (Chen et al., 2022b), đã đưa bằng chứng đối chiếu từ thế giới thực vào việc kiểm tra sự thật. ContraNote đặc biệt chú thích các xung đột bằng chứng tự nhiên xảy ra trong cùng một bài đăng, và phân tách hai hình thức xung đột (tức là mức bằng chứng và mức tổng hợp).

Để đánh giá độ tin cậy của các nhãn được tạo t ự động, chúng tôi đã lấy mẫu ngẫu nhiên 500 trường hợp từ ContraNote và tuyển ba người chú thích đã được đào tạo. Họ đánh giá độc lập tính xác thực của từng bài đăng dựa trên nội dung bài đăng, các ghi chú liên quan và bằng chứng được trích dẫn, đạt được sự đồng thuận đáng kể giữa các người chú thích (Fleiss’ $\kappa = 0.82$). Các nhãn của con người theo phiếu đa số đồng ý với các nhãn của ContraNote ở 94,2% các trường hợp. Điều này xác nhận độ chính xác của các nhãn.

Vì những cộng tác viên của Community Notes có thể không đại diện cho tất cả các nhóm nhân khẩu học, ContraNote có thể có sự thiên lệch về dân số và ý thức hệ. Chúng tôi đặc trưng quan điể m và phân bố chủ đề của nó. Sử dụng PoliticalBiasBERT, chúng tôi phân loại các ghi chú thành các loại trái, trung tâm và phải, với tỉ lệ lần lượt là 18,6%, 47,0% và 34,4%. Trên tập con được chú thích bởi con người, phân bố chủ đề là chính trị/quản trị (26,0%), y tế/thuốc (4,0%), khoa học/công nghệ (20,6%), truyền thông/giải trí/thể thao (29,8%), kinh tế/tài chính (5,8%), an toàn cộng cộng/tội phạm (6,8%) và khác/chung (10,4%). Các chú thích chủ đề bởi ba người chú thích đạt Fleiss’ $\kappa = 0.84$. Điều này cho thấy rằng ContraNote phản ánh tín hiệu đồng thuận được tạo ra bởi cơ chế Community Notes.

Đánh giá mở rộng C

C.1 Kết quả theo lớp cho các điều kiện cơ bản

Chúng tôi đã báo cáo kết quả theo từng lớp cho các điều kiện cơ sở trong Bảng 5 và Bảng 6. Bảng 5 cho thấy hiệu suất trên lớp được hỗ trợ, trong khi Bảng 6 cho thấy hiệu suất trên lớp bị bác bỏ.

C.2 Kết quả bổ sung trên các đường cơ sở

Chúng tôi cũng đánh giá ClaimDecomp, MADAM-RAG, và một nền tảng kiểm chứng kiểu AVeriTeC trong Bảng 7. ClaimDecomp đạt điểm mac. F1 lần lượt là 67,28, 76,21, 54,29 và 65,58 trên CONFACT-HumC, CONFACT-ModC, ContraNote Conflict và ContraNote Prioritization. MADAM-RAG đạt 47,70 và 70,30 trên hai đánh giá chuẩn ContraNote, trong khi nền tảng kiểu AVeriTeC đạt 65,60 và 80,50. Những kết quả này cung cấp các so sánh bổ sung với các phương pháp được thiết kế cho phân tích chi tiết tuyên bố, kiểm chứng tăng cường truy xuất và giải quyết xung đột.

Trên các bộ dữ liệu bổ sung, CoVer đạt điểm F1 trung bình (mac. F1) lần lượt là 92,60 trên AVeriTeC, 84,00 trên WikiContradict và 92,20 trên AmbiFC. Các thí nghiệm này chỉ ra rằng khung phương pháp này có thể áp dụng ngoài Co ntraNote, mặc dù các bộ dữ liệu khác nhau về cách đặt bài toán và cấu trúc bằng chứng.

C.3 Đường cơ sở gọi nhiều lần

Bảng 8 báo cáo các đường cơ sở lỗi tắt và đa cuộc gọi. Đường cơ sở lỗi tắt metadata đạt 81,5% độ chính xác trên ContraNote Conflict, nhưng chỉ đạt 44,9 macro-F1 và 50,0 độ chính xác cân bằng. Độ chính xác cao của nó là nhờ sự mất cân bằng lớp mạnh chứ không phải do kiểm chứng đáng tin cậy. Trên ContraNote Prioritization, cùng một quy tắc đạt 50,0% độ chính xác, 33,3 macro-F1 và 50,0 độ chính xác cân bằng, gần như giống với may rủi. Do đó, điểm chuẩn không thể được giải quyết đầy đủ chỉ bằng quy tắc metadata.

Đối với kiểm soát cuộc gọi được khớp, chúng tôi sử dụng bằng chứng cố định cho tất cả bốn cơ sở trong mỗi nhiệm vụ. Chúng tôi tổng hợp các dự đoán bằng cách bỏ phiếu đa số, giải quyết các trường hợp hòa bằng cách cho l à Bị bác bỏ, với kết quả được trình bày trong Bảng 8.

C.4 Xác minh ba chiều

Để kiểm tra xem CoVer có thể đại diện cho độ chính xác một phần hay không, chúng tôi xây dựng một thiết lập ba chiều với các nhãn Hỗ trợ, Hỗ trợ một phần và Bị bác bỏ. Một trường hợp được gán nhãn Hỗ trợ một phần

Method	CONFACT HumC			CONFACT ModC			ConflictBank			ECON			FEVER			ContraNote Conflict			ContraNote Prioritization		
FacTool	38.5	29.4	33.3	57.6	45.2	50.7	31.9	39.7	35.4	71.1	58.7	64.3	90.7	29.3	44.3	34.7	71.4	46.7	56.6	63.8	60.0
FactCheckGPT	54.2	38.2	44.8	54.5	42.9	48.0	38.8	44.8	41.6	68.0	55.4	61.1	97.1	74.4	84.3	31.5	48.6	38.2	52.2	64.5	57.7
FIRE	30.0	17.6	22.2	48.6	42.9	45.6	27.1	32.8	29.7	62.2	50.0	55.4	93.3	62.4	74.8	34.4	62.9	44.4	64.6	54.3	59.0
Confact	34.8	47.1	40.0	53.6	71.4	61.2	37.0	51.7	43.2	68.9	79.3	73.7	88.5	92.5	90.4	51.1	65.7	57.5	59.4	64.5	61.9
ConflictRes	44.4	35.3	39.3	47.1	57.1	51.6	19.6	15.5	17.3	68.4	58.7	63.2	88.0	71.4	78.8	47.6	57.1	51.9	62.3	45.7	52.8

Table 5: Detailed performance comparing different techniques, on the **Supported** class. Metrics are formatted as Precision | Recall | F1-score.

Method	CONFACT HumC			CONFACT ModC			ConflictBank			ECON			FEVER			ContraNote Conflict			ContraNote Prioritization		
FacTool	86.2	90.4	88.2	86.2	91.1	88.6	72.4	65.2	68.7	69.4	79.6	74.1	40.1	94.0	56.3	92.0	71.0	80.1	63.4	56.2	59.6
FactCheckGPT	88.1	93.4	90.6	85.6	90.5	88.0	75.9	71.1	73.5	67.2	77.8	72.1	65.3	95.5	77.6	87.5	77.3	82.1	60.7	48.1	53.7
FIRE	84.4	91.6	87.9	85.2	87.9	86.5	69.8	63.8	66.7	63.5	74.1	68.4	55.0	91.0	68.5	90.3	74.2	81.5	64.5	73.6	68.7
Confact	88.2	81.8	84.9	91.5	83.3	87.2	76.5	64.1	69.7	79.8	69.4	74.3	83.6	76.1	79.7	92.2	86.5	89.2	66.3	61.3	63.7
ConflictRes	87.3	91.0	89.1	87.9	82.9	85.3	68.2	73.9	70.9	68.6	76.9	72.5	58.7	80.6	67.9	90.4	86.5	88.4	61.1	75.5	67.5

Table 6: Detailed performance comparing different techniques, on the **Refuted** class. Metrics are formatted as Precision | Recall | F1-score.

Method	CONFACT HumC	CONFACT ModC	ContraNote Conflict	ContraNote Prioritization
MADAM-RAG	65.0	68.0	47.70	70.30
AVeriTeC-style	65.8	77.4	65.60	80.50
ClaimDecomp	67.28	76.21	54.29	65.58
CoVer	77.10	83.10	68.00	88.50

Table 7: Additional baseline comparisons using mac. F1 (%). The AVeriTeC-style and MADAM-RAG results were reported for the ContraNote benchmarks, whereas ClaimDecomp was additionally evaluated on CONFACT. A dash denotes that the corresponding result was not reported.

Method	Accuracy	Mac. F1	Bal. Acc.
<i>ContraNote Conflict</i>			
Helpful+misleading	81.5	44.9	50.0
CoVer	86.0	68.0	64.5
FactCheckGPT	83.0	63.6	61.4
CONFACT	85.5	69.4	66.0
FIRE	85.5	67.4	63.9
FacTool	84.0	67.7	65.1
<i>ContraNote Prioritization</i>			
Helpful+misleading	50.0	33.3	50.0
CoVer	88.5	88.5	89.2
FactCheckGPT	69.5	68.9	69.5
CONFACT	63.5	61.2	63.5
FIRE	61.0	58.4	61.0
FacTool	78.0	77.9	78.0

Table 8: Shortcut and inference-budget controls on ContraNote. The shortcut rule predicts Refuted if and only if a candidate note is both helpful and misleading.

when its subclaims contain both supported and unsupported or refuted components. Under this setting, CoVer obtains 80.6% accuracy and 68.0 mac. F1, compared with 66.5 mac. F1 for the strongest baseline. This pilot experiment suggests that the framework can be extended beyond the binary formulation used by the primary ContraNote task.

C.5 Factuality of Generated Rationales

We evaluate the factuality of generated rationales using an adapted FActScore-style procedure. Atomic claims in the rationales are checked against the Community Notes and the associated evidence. We manually annotate 100 instances and use these annotations to validate the automatic procedure. GPT-5.5 agrees with the human annotations on 97% of the cases. Under automatic annotation, CoVer achieves support rates of 85.2% on ContraNote Conflict and 82.3% on ContraNote Prioritization, compared with 76.9% and 72.6% for the strongest competing baselines, respectively.

Phương pháp	CONFACT HumC	CONFACT ModC	Ngân hàng Xung đột	ECON	SỐT	Ghi chú đối lập Xung đột	Ghi chú đối lập Ưu tiên
FacTool	38.5 29.4 33.3	57.6 45.2 50.7	31.9 39.7 35.4	71.1 58.7 64.3	90.7 29.3 44.3	34.7 71.4 46.7	56.6 63.8 60.0
KiểmTraSựThậtGPT	54.2 38.2 44.8	54.5 42.9 48.0	38.8 44.8 41.6	68.0 55.4 61.1	97.1 74.4 84.3	31.5 48.6 38.2	52.2 64.5 57.7
FIRE	30.0 17.6 22.2	48.6 42.9 45.6	27.1 32.8 29.7	62.2 50.0 55.4	93.3 62.4 74.8	34.4 62.9 44.4	64.6 54.3 59.0
Liên hệ	34.8 47.1 40.0	53.6 71.4 61.2	37.0 51.7 43.2	68.9 79.3 73.7	88.5 92.5 90.4	51.1 65.7 57.5	59.4 64.5 61.9
Xung đột	44.4 35.3 39.3	47.1 57.1 51.6	19.6 15.5 17.3	68.4 58.7 63.2	88.0 71.4 78.8	47.6 57.1 51.9	62.3 45.7 52.8

Bảng 5: Hiệu suất chi tiết so sánh các kỹ thuật khác nhau, trên lớp Supported. Các chỉ số được định dạng dưới dạng Precision | Recall | F1-score.

Phương pháp	CONFACT HumC	CONFACT ModC	Ngân hàng Xung đột	ECON	SỐT	Ghi chú đối lập Xung đột	Ghi chú đối lập Ưu tiên
FacTool	86.2 90.4 88.2	86.2 91.1 88.6	72.4 65.2 68.7	69.4 79.6 74.1	40.1 94.0 56.3	92.0 71.0 80.1	63.4 56.2 59.6
KiểmTraSựThậtGPT	88.1 93.4 90.6	85.6 90.5 88.0	75.9 71.1 73.5	67.2 77.8 72.1	65.3 95.5 77.6	87.5 77.3 82.1	60.7 48.1 53.7
FIRE	84.4 91.6 87.9	85.2 87.9 86.5	69.8 63.8 66.7	63.5 74.1 68.4	55.0 91.0 68.5	90.3 74.2 81.5	64.5 73.6 68.7
Liên hệ	88.2 81.8 84.9	91.5 83.3 87.2	76.5 64.1 69.7	79.8 69.4 74.3	83.6 76.1 79.7	92.2 86.5 89.2	66.3 61.3 63.7
Xung đột	87.3 91.0 89.1	87.9 82.9 85.3	68.2 73.9 70.9	68.6 76.9 72.5	58.7 80.6 67.9	90.4 86.5 88.4	61.1 75.5 67.5

Bảng 6: Hiệu quả chi tiết so sánh các kỹ thuật khác nhau, trên lớp Bị bác bỏ. Các chỉ số được định dạng là Độ chính xác | Nhớ Điểm F1.

Phương pháp	CONFACT HumC	CONFACT ModC	Ghi chú đối lập Xung đột	Ghi chú đối lập Ưu tiên
BÀ-TẾ	65.0	68.0	47.70	70.30
Phong cách AVeriTeC	65.8	77.4	65.60	80.50
Phân tách yêu cầu	67.28	76.21	54.29	65.58
Bia	77.10	83.10	68.00	88.50

Bảng 7: So sánh cơ sở bổ sung sử dụng mac. F1 (%). Kết quả theo kiểu AVeriTeC và MADAM-RAG được báo cáo cho các chuẩn mực ContraNote, trong khi ClaimDecomp còn được đánh giá thêm trên CONFACT. Dấu gạch ngang biểu thị rằng kết quả tương ứng không được báo cáo.

Phương pháp	Độ chính xác	Mac. F1	Số dư TK
<i>Xung đột ContraNote</i>			
Hữu ích+gây hiểu lầm	81.5	44.9	50.0
Bia	86.0	68.0	64.5
KiểmTraSựThậtGPT	83.0	63.6	61.4
CONFACT	85.5	69.4	66.0
FIRE	85.5	67.4	63.9
FacTool	84.0	67.7	65.1
<i>Ưu tiên ContraNote</i>			
Hữu ích+gây hiểu lầm	50.0	33.3	50.0
Bia	88.5	88.5	89.2
KiểmTraSựThậtGPT	69.5	68.9	69.5
CONFACT	63.5	61.2	63.5
FIRE	61.0	58.4	61.0
FacTool	78.0	77.9	78.0

Bảng 8: Kiểm soát đường tắt và ngăn sách suy luận trên Con-traNote. Quy tắc đường tắt chỉ dự đoán là Bị phản bác nếu và chỉ nếu một ghi chú ứng viên vừa hữu ích vừa gây hiểu lầm.

khí các tuyên bố phụ của nó chứa cả các thành phần được hỗ trợ và không được hỗ trợ hoặc bị bác bỏ. Trong bối cảnh này, CoVer đạt độ chính xác 80,6% và F1 trung bình 68,0, so với F1 trung bình 66,5 của điểm cơ sở mạnh nhất. Thí nghiệm thử nghiệm này cho thấy khung có thể được mở rộng vượt ra ngoài công thức nhị phân được sử dụng bởi nhiệm vụ ContraNote chính.

C.5 Tính xác thực của các lý do được tạo ra

Chúng tôi đánh giá tính xác thực của các lý giải được tạo ra bằng cách sử dụng một quy trình theo kiểu FActScore được điều chỉnh. Các khẳng định nguyên tử trong các lý giải được kiểm tra đối chiếu với Community Notes và các bằng chứng liên quan. Chúng tôi ghi chú thủ công 100 trường hợp và sử dụng các ghi chú này để xác thực quy trình tự động. GPT-5.5 đồng ý với các ghi chú của con người trong 97% các trường hợp. Dưới hình thức ghi chú tự động, CoVer đạt tỷ lệ hỗ trợ 85,2% trên ContraNote Conflict và 82,3% trên ContraNote Prioritization, so với 76,9% và 72,6% của các phương pháp cơ sở cạnh tranh mạnh nhất, tương ứng.

D Ablation and Sensitivity Analysis

D.1 Class-wise Results for the Ablation Study

We reported the class-wise results for the ablation study in Tables 9 and 10. Note that Table 9 contains the detailed performance for the supported class, while Table 10 contains the detailed performance for the refuted class.

D.2 Sensitivity to Quality Weights

We evaluate the sensitivity of CoVer to the quality-weight vector $\lambda = (\lambda_d, \lambda_a, \lambda_l, \lambda_u)$, corresponding to directness, attribute alignment, schema reliability, and informativeness, respectively. Each weight is varied over $\{0, 0.05, 0.10, \dots, 1.0\}$ subject to $\lambda_d + \lambda_a + \lambda_l + \lambda_u = 1$. The uniform configuration $\lambda_{\text{uni}} = (0.25, 0.25, 0.25, 0.25)$ is fixed before evaluation and is not tuned on any test set; we compare it with the best- and worst-performing configurations identified on the development split. All reported values are mac. F1 scores averaged over five runs. Across the evaluated datasets, mac. F1 varies within 1.3 percentage points, indicating that CoVer is not dependent on a narrowly tuned weighting configuration.

D.3 Tie-breaking Sensitivity

We compare the primary Refute-default rule in Eq. 4 with a Support-default variant. Changing the tie default decreases performance by 2.15 percentage points on ContraNote Prioritization but improves it by 4.19 percentage points on CONFACT-HumC. Thus, the effect of the tie-breaking rule is dataset-dependent rather than uniformly beneficial.

D.4 Structured-Output Constraint Ablation

The factual-consensus call normally requires a complete structured record containing a stance from the valid label set and four quality scores bounded to $[0, 1]$. We ablate these validity constraints while keeping the backbone model, evidence, and downstream decision rule unchanged; free-form outputs are parsed into the same intermediate fields whenever possible. Removing the structured-output constraints reduces accuracy by 1.57 percentage points relative to the constrained configuration. Thus, the constraints improve the stability of intermediate decisions, but the modest change indicates that CoVer’s performance is not explained solely by output formatting.

E Efficiency and Error Analysis

E.1 Comparisons Controlling Inference Budget

Table 12 showed the comparisons controlling inference budget.

E.2 Error Analysis

We qualitatively inspect CoVer’s incorrect predictions to identify recurring failure modes. The analysis reveals three principal categories.

Temporal ambiguity. Some claims and notes refer to different stages of an evolving event or omit the relevant time frame. In such cases, evidence that was correct at one point can conflict with a later update, and the model may select an outdated interpretation or fail to restrict the verdict to the claim’s intended period.

Evidence requiring domain expertise. Some cases depend on specialized legal, medical, scientific, or policy knowledge that is not stated explicitly in the supplied evidence. CoVer can identify the competing stances but may assign excessive weight to a fluent explanation when resolving the technical distinction requires expert interpretation.

True event with an unsupported implication. A claim may mention a real event and then attach an unsupported causal, intentional, or generalized implication. The model sometimes treats evidence for the underlying event as support for the entire claim, even when the implication is not entailed. This failure mode motivates the conservative support-verification stage, but difficult cases remain when the factual and implied components are tightly coupled.

These errors suggest three corresponding directions for improvement: explicit temporal normalization, routing of specialized cases to domain-aware evidence or experts, and finer-grained decomposition of event facts from causal or intentional implications. This analysis is qualitative; we do not assign category percentages because the available coding record does not contain a frequency table.

D Phân tích Ablation và Độ nhạy

D.1 Kết quả theo lớp cho Nghiên cứu Loại bỏ

Chúng tôi đã báo cáo kết quả theo từng lớp cho nghiên cứu loại bỏ trong Bảng 9 và Bảng 10. Lưu ý rằng Bảng 9 chứa hiệu suất chi tiết cho lớp được hỗ trợ, trong khi Bảng 10 chứa hiệu suất chi tiết cho lớp bị bác bỏ.

D.2 Độ nhạy với Trọng số Chất lượng

Chúng tôi đánh giá độ nhạy của CoVer đối với vector trọng số chất lượng $\lambda = (\lambda_d, \lambda_a, \lambda_l, \lambda_u)$, tương ứng với tính trực tiếp, sự phù hợp thuộc tính, độ tin cậy của sơ đồ, và tính hữu ích thông tin. Mỗi trọng số được thay đổi trong khoảng $\{0, 0.05, 0.10, \dots, 1.0\}$ dưới điều kiện $\lambda_d + \lambda_a + \lambda_l + \lambda_u = 1$. Cấu hình đồng đều $\lambda_{\text{uni}} = (0.25, 0.25, 0.25, 0.25)$ được cố định trước khi đánh giá và không được điều chỉnh trên bất kỳ tập kiểm tra nào; chúng tôi so sánh nó với các cấu hình hoạt động tốt nhất và kém nhất được xác định trên tập phát triển. Tất cả các giá trị báo cáo là điểm F1 trung bình (mac. F1) trung bình trên năm lần chạy. Trên các tập dữ liệu được đánh giá, mac. F1 dao động trong khoảng 1,3 điểm phần trăm, cho thấy CoVer không phụ thuộc vào một cấu hình trọng số được tinh chỉnh hẹp.

D.3 Độ nhạy khi hòa điểm

Chúng tôi so sánh quy tắc Refute-mặc định chính trong Phương trình 4 với một biến thể Support-mặc định. Thay đổi mặc định khi hòa làm giảm hiệu suất 2,15 điểm phần trăm trên ContraNotePrioritization nhưng lại cải thiện 4,19 điểm phần trăm trên CONFACT-HumC. Do đó, tác động của quy tắc giải quyết hòa phụ thuộc vào tập dữ liệu thay vì có lợi một cách đồng đều.

D.4 Thí nghiệm loại bỏ ràng buộc đầu ra có cấu trúc

Cuộc gọi đồng thuận thực tế thường yêu cầu một bản ghi có cấu trúc đầy đủ chứa quan điểm từ tập nhân hợp lệ và bốn điểm chất lượng giới hạn trong $[0, 1]$. Chúng tôi loại bỏ các ràng buộc hợp lệ này trong khi giữ nguyên mô hình nền tảng, bằng chứng và quy tắc quyết định hạ nguồn; các kết quả đầu ra tự do được phân tích thành các trường trung gian giống nhau bất cứ khi nào có thể. Việc loại bỏ các ràng buộc đầu ra có cấu trúc làm giảm độ chính xác 1,57 điểm phần trăm so với cấu hình bị ràng buộc. Do đó, các ràng buộc cải thiện tính ổn định của các quyết định trung gian, nhưng sự thay đổi khiêm tốn cho thấy hiệu suất của CoVer không được giải thích chỉ bằng cách định dạng đầu ra.

E Hiệu suất và Phân tích lỗi

E.1 So sánh Kiểm soát Ngân sách Suy luận

Bảng 12 cho thấy các so sánh kiểm soát ngân sách suy luận.

E.2 Phân Tích Lỗi

Chúng tôi kiểm tra định tính các dự đoán sai của CoVer để xác định các chế độ thất bại lặp lại. Phân tích cho thấy ba loại chính.

Mơ hồ về thời gian. Một số câu khẳng định và ghi chú đề cập đến các giai đoạn khác nhau của một sự kiện đang diễn ra hoặc bỏ qua khung thời gian liên quan. Trong những trường hợp như vậy, bằng chứng đúng tại một thời điểm có thể mâu thuẫn với một bản cập nhật sau đó, và mô hình có thể chọn một cách diễn giải lỗi thời hoặc không giới hạn phán quyết trong khoảng thời gian mà câu khẳng định đề cập.

Bằng chứng đòi hỏi chuyên môn trong lĩnh vực. Một số trường hợp phụ thuộc vào kiến thức pháp lý, y tế, khoa học hoặc chính sách chuyên biệt mà không được nêu rõ trong bằng chứng cung cấp. CoVer có thể xác định các quan điểm đối lập nhưng có thể đánh giá quá cao một giải thích trôi chảy khi việc giải quyết sự khác biệt kỹ thuật đòi hỏi sự giải thích của chuyên gia.

Sự kiện thật với một hàm ý không được hỗ trợ. Một tuyên bố có thể đề cập đến một sự kiện thực sự và sau đó gán một hàm ý nguyên nhân, cố ý, hoặc tổng quát không được hỗ trợ. Mô hình đôi khi coi bằng chứng cho sự kiện cơ bản là sự hỗ trợ cho toàn bộ tuyên bố, ngay cả khi hàm ý không được suy ra. Chế độ thất bại này thúc đẩy giai đoạn xác minh hỗ trợ thận trọng, nhưng những trường hợp khó vẫn còn khi các thành phần thực tế và hàm ý được gắn chặt với nhau.

Những lỗi này gợi ý ba hướng cải tiến tương ứng: chuẩn hóa thời gian một cách rõ ràng, chuyển các trường hợp chuyên biệt đến bằng chứng hoặc chuyên gia am hiểu lĩnh vực, và phân tách chi tiết hơn các sự kiện từ các hàm ý nhân quả hoặc có chủ đích. Phân tích này mang tính định tính; chúng tôi không gán tỉ lệ phần trăm danh mục vì hồ sơ mã hóa hiện có không chứa bằng tần suất.

Setting	CONFACT HumC			CONFACT ModC			ConflictBank			ECON			FEVER			ContraNote Conflict			ContraNote Prioritization		
Full	72.0	52.9	61.0	77.8	68.3	72.7	56.8	36.2	44.2	73.3	80.4	76.7	98.4	91.6	94.9	73.3	31.4	44.0	80.3	100.0	89.1
w/o Schema	72.0	52.9	61.0	77.8	68.3	72.7	44.4	27.6	34.0	44.7	16.3	23.9	94.5	78.0	85.5	54.5	51.4	52.9	73.5	79.8	76.5
w/o Consensus	53.8	61.8	57.5	53.8	68.3	60.2	41.8	65.5	51.0	73.3	80.4	76.7	95.8	86.5	90.9	43.8	20.0	27.5	9.1	2.1	3.4
w/o Support	60.7	50.0	54.8	75.0	65.9	70.1	47.6	34.5	40.0	73.3	80.4	76.7	95.8	86.5	90.9	71.4	28.6	40.8	67.0	64.9	65.9
w/o Schema + Consensus	44.4	47.1	45.7	49.0	61.0	54.3	42.2	65.5	51.4	71.0	82.6	76.4	92.9	88.7	90.8	28.3	74.3	40.9	72.9	45.7	56.2
w/o Schema + Support	50.0	26.5	34.6	75.0	51.2	60.9	46.7	36.2	40.8	62.2	30.4	40.9	94.2	85.0	89.3	54.5	51.4	52.9	76.2	81.9	79.0
w/o Consensus + Support	53.8	61.8	57.5	53.8	68.3	60.2	41.8	65.5	51.0	73.3	80.4	76.7	95.8	86.5	90.9	53.3	22.9	32.0	4.0	1.1	1.7
w/o All Three	44.4	47.1	45.7	49.0	61.0	54.3	42.2	65.5	51.4	71.0	82.6	76.4	92.9	88.7	90.8	28.7	77.1	41.9	66.7	40.4	50.3

Table 9: Detailed performance of the ablation study, on the **Supported** class. Metrics are formatted as Precision | Recall | F1-score.

Setting	CONFACT HumC			CONFACT ModC			ConflictBank			ECON			FEVER			ContraNote Conflict			ContraNote Prioritization		
Full	90.8	95.8	93.2	92.0	94.9	93.5	77.3	88.7	82.6	81.8	75.0	78.3	85.5	97.0	90.9	87.0	97.6	92.0	100.0	78.3	87.8
w/o Schema	90.8	95.8	93.2	92.0	94.9	93.5	74.2	85.8	79.6	45.6	77.7	57.5	67.8	91.0	77.7	89.8	90.9	90.4	80.4	74.3	77.2
w/o Consensus	91.9	89.1	90.5	91.0	84.5	87.6	81.5	62.4	70.7	81.8	75.0	78.3	77.5	92.5	84.4	100.0	79.4	88.5	49.1	78.3	60.4
w/o Support	89.9	93.3	91.6	91.4	94.3	92.8	75.9	84.5	80.0	81.8	75.0	78.3	77.5	92.5	84.4	86.6	97.6	91.7	69.7	71.7	70.7
w/o Schema + Consensus	88.8	87.7	88.2	89.2	83.5	86.3	81.7	63.1	71.2	82.8	71.3	76.6	79.5	86.6	82.9	92.2	57.0	70.4	65.7	61.3	63.4
w/o Schema + Support	86.0	94.4	90.0	88.2	95.5	91.7	76.0	83.0	79.3	58.7	84.3	69.2	75.0	89.6	81.6	89.8	90.9	90.4	82.7	77.1	79.8
w/o Consensus + Support	91.9	89.1	90.5	91.0	84.5	87.6	81.5	62.4	70.7	81.8	75.0	78.3	77.5	92.5	84.4	98.6	82.4	89.8	47.9	75.5	58.6
w/o All Three	88.8	87.7	88.2	89.2	83.5	86.3	81.7	63.1	71.2	82.8	71.3	76.6	79.5	86.6	82.9	92.2	57.6	70.9	60.4	58.1	59.2

Table 10: Detailed performance of the ablation study, on the **Refuted** class. Metrics are formatted as Precision | Recall | F1-score.

Dataset	Uniform λ	Best λ	Worst λ	Best mac. F1	Worst mac. F1
CONFACT-HumC	0.25,0.25,0.25,0.25	0.25,0.25,0.25,0.25	0.40,0.30,0.20,0.10	78.0	76.7
CONFACT-ModC	0.25,0.25,0.25,0.25	0.25,0.25,0.25,0.25	0.10,0.20,0.30,0.40	84.0	82.7
ConflictBank	0.25,0.25,0.25,0.25	0.25,0.25,0.25,0.25	0.40,0.30,0.20,0.10	64.3	63.0
ECON	0.25,0.25,0.25,0.25	0.25,0.25,0.25,0.25	0.10,0.20,0.30,0.40	78.4	77.1
FEVER	0.25,0.25,0.25,0.25	0.25,0.25,0.25,0.25	0.40,0.30,0.20,0.10	93.8	92.5
ContraNote-Conflict	0.25,0.25,0.25,0.25	0.25,0.25,0.25,0.25	0.10,0.20,0.30,0.40	68.9	67.6
ContraNote-Prioritization	0.25,0.25,0.25,0.25	0.25,0.25,0.25,0.25	0.40,0.30,0.20,0.10	89.4	88.1

Table 11: Sensitivity of CoVer to the quality-weight vector. Each weight vector is ordered as $(\lambda_d, \lambda_a, \lambda_l, \lambda_u)$. Mac. F1 values are reported in percentage points. The best and worst configurations are selected from the development split and evaluated without further tuning on the test set.

Method	Configuration	Avg. LLM calls	Avg. input tokens	Avg. output tokens	Estimated cost/request
CoVer	Primary	5.34	1274.9	271.2	0.0059
FacTool	Single-call	1.00	628.4	180.3	0.0034
FacTool	Matched multi-call	5.34	3261.5	852.2	0.0167
FactCheckGPT	Single-call	1.00	635.4	357.1	0.0052
FactCheckGPT	Matched multi-call	5.34	3298.2	1461.2	0.0229
FIRE	Single-call	1.00	633.4	275.1	0.0043
FIRE	Matched multi-call	5.34	3288.0	1530.4	0.0235
CONFACT	Single-call	1.00	632.4	196.0	0.0035
CONFACT	Matched multi-call	5.34	3282.7	938.0	0.0176
ConflictRes	Single-call	1.00	632.4	188.5	0.0035
MADAM-RAG	Single-call	1.00	571.4	173.8	0.0032
AVeriTeC-style	Single-call	1.00	572.4	155.1	0.0030
ClaimDecomp	Single-call	1.00	635.4	341.6	0.0050

Table 12: Inference budget and computational cost under the original and matched-call configurations. Reported values are averages per instance over all evaluation examples. Input and output tokens include all LLM requests made by a method. The estimated cost is calculated using the API prices corresponding to the reported backbone model and evaluation date.

Cài đặt	CONFACT HumC	CONFACT ModC	Ngân hàng Xung đột	ECON	SỐT	Ghi chú đối lập Xung đột	Ghi chú đối lập Ưu tiên
Full	72.0 52.9 61.0	77.8 68.3 72.7	56.8 36.2 44.2	73.3 80.4 76.7	98.4 91.6 94.9	73.3 31.4 44.0	80.3 100.0 89.1
không có Sơ đồ	72.0 52.9 61.0	77.8 68.3 72.7	44.4 27.6 34.0	44.7 16.3 23.9	94.5 78.0 85.5	54.5 51.4 52.9	73.5 79.8 76.5
không có sự đồng thuận	53.8 61.8 57.5	53.8 68.3 60.2	41.8 65.5 51.0	73.3 80.4 76.7	95.8 86.5 90.9	43.8 20.0 27.5	9.1 2.1 3.4
không có hỗ trợ	60.7 50.0 54.8	75.0 65.9 70.1	47.6 34.5 40.0	73.3 80.4 76.7	95.8 86.5 90.9	71.4 28.6 40.8	67.0 64.9 65.9
không có Lược đồ +Thỏa thuận	44.4 47.1 45.7	49.0 61.0 54.3	42.2 65.5 51.4	71.0 82.6 76.4	92.9 88.7 90.8	28.3 74.3 40.9	72.9 45.7 56.2
không có Hỗ trợ Schema +	50.0 26.5 34.6	75.0 51.2 60.9	46.7 36.2 40.8	62.2 30.4 40.9	94.2 85.0 89.3	54.5 51.4 52.9	76.2 81.9 79.0
không có sự đồng thuận + Hỗ trợ	53.8 61.8 57.5	53.8 68.3 60.2	41.8 65.5 51.0	73.3 80.4 76.7	95.8 86.5 90.9	53.3 22.9 32.0	4.0 1.1 1.7
không có cả ba	44.4 47.1 45.7	49.0 61.0 54.3	42.2 65.5 51.4	71.0 82.6 76.4	92.9 88.7 90.8	28.7 77.1 41.9	66.7 40.4 50.3

Bảng 9: Hiệu suất chi tiết của nghiên cứu loại bỏ yếu tố, trên lớp Hỗ trợ. Các chỉ số được định dạng theo Precision | Recall | F1-score.

Cài đặt	CONFACT HumC	CONFACT ModC	Ngân hàng Xung đột	ECON	SỐT	Ghi chú đối lập Xung đột	Ghi chú đối lập Ưu tiên
Full	90.8 95.8 93.2	92.0 94.9 93.5	77.3 88.7 82.6	81.8 75.0 78.3	85.5 97.0 90.9	87.0 97.6 92.0	100.0 78.3 87.8
không có Sơ đồ	90.8 95.8 93.2	92.0 94.9 93.5	74.2 85.8 79.6	45.6 77.7 57.5	67.8 91.0 77.7	89.8 90.9 90.4	80.4 74.3 77.2
không có sự đồng thuận	91.9 89.1 90.5	91.0 84.5 87.6	81.5 62.4 70.7	81.8 75.0 78.3	77.5 92.5 84.4	100.0 79.4 88.5	49.1 78.3 60.4
không có hỗ trợ	89.9 93.3 91.6	91.4 94.3 92.8	75.9 84.5 80.0	81.8 75.0 78.3	77.5 92.5 84.4	86.6 97.6 91.7	69.7 71.7 70.7
không có Lược đồ + Thỏa thuận	88.8 87.7 88.2	89.2 83.5 86.3	81.7 63.1 71.2	82.8 71.3 76.6	79.5 86.6 82.9	92.2 57.0 70.4	65.7 61.3 63.4
không có Hỗ trợ Schema +	86.0 94.4 90.0	88.2 95.5 91.7	76.0 83.0 79.3	58.7 84.3 69.2	75.0 89.6 81.6	89.8 90.9 90.4	82.7 77.1 79.8
không có sự đồng thuận + Hỗ trợ	91.9 89.1 90.5	91.0 84.5 87.6	81.5 62.4 70.7	81.8 75.0 78.3	77.5 92.5 84.4	98.6 82.4 89.8	47.9 75.5 58.6
không có cả ba	88.8 87.7 88.2	89.2 83.5 86.3	81.7 63.1 71.2	82.8 71.3 76.6	79.5 86.6 82.9	92.2 57.6 70.9	60.4 58.1 59.2

Bảng 10: Hiệu suất chi tiết của nghiên cứu loại bỏ, trên lớp Bị bác bỏ. Các chỉ số được định dạng dưới dạng Độ chính xác | Độ hồi tưởng | Điểm F1.

Bộ dữ liệu	Đồng phục λ	Best λ	Tệ nhất λ	Best mac. F1	Tệ nhất mac. F1
CONFACT-HumC	0.25,0.25,0.25,0.25 0,25	0.25,0.25,0.25 0,25 0,40	0.30,0.20,0.10	78.0	76.7
CONFACT-ModC	0.25,0.25,0.25,0.25 0,25	0.25,0.25,0.25 0,10	0.20,0.30,0.40	84.0	82.7
Ngân hàng Xung đột	0.25,0.25,0.25,0.25 0,25	0.25,0.25,0.25 0,40	0.30,0.20,0.10	64.3	63.0
ECON	0.25,0.25,0.25,0.25 0,25	0.25,0.25,0.25 0,10	0.20,0.30,0.40	78.4	77.1
SỐT	0.25,0.25,0.25,0.25 0,25	0.25,0.25,0.25 0,40	0.30,0.20,0.10	93.8	92.5
ContraNote-Xung đột	0.25,0.25,0.25,0.25 0,25	0.25,0.25,0.25 0,10	0.20,0.30,0.40	68.9	67.6
ContraNote-Ưu tiên	0.25,0.25,0.25 0,25	0.25,0.25,0.25 0,40	0.30,0.20,0.10	89.4	88.1

Bảng 11: Độ nhạy của CoVer đối với vectơ trọng số chất lượng. Mỗi vectơ trọng số được sắp xếp theo $(\lambda_{ds}, \lambda_{as}, \lambda_{ls}, \lambda_{us})$. Giá trị Mac. F1 được báo cáo theo điểm phần trăm. Cấu hình tốt nhất và tệ nhất được chọn từ tập phát triển và đánh giá mà không tinh chỉnh thêm trên tập kiểm tra.

Phương pháp	Cấu hình	Avg. Cuộc gọi LLM	Đầu vào trung bình thẻ	Công suất trung bình thẻ	Ước tính chi phí/yêu cầu
Bìa	Chính	5.34	1274.9	271.2	0.0059
FacTool	Gọi một lần	1.00	628.4	180.3	0.0034
FacTool	Đa cuộc gọi khớp	5.34	3261.5	852.2	0.0167
KiểmTraSựThậtGPT	Gọi một lần	1.00	635.4	357.1	0.0052
KiểmTraSựThậtGPT	Đa cuộc gọi khớp	5.34	3298.2	1461.2	0.0229
FIRE	Gọi một lần	1.00	633.4	275.1	0.0043
FIRE	Đa cuộc gọi khớp	5.34	3288.0	1530.4	0.0235
CONFACT	Gọi đơn	1.00	632.4	196.0	0.0035
CONFACT	Đa cuộc gọi khớp	5.34	3282.7	938.0	0.0176
Xung đột	Gọi một lần	1.00	632.4	188.5	0.0035
BÀ-TẾ	Gọi một lần	1.00	571.4	173.8	0.0032
Phong cách AVeriTeC	Gọi một lần	1.00	572.4	155.1	0.0030
Phân tách yêu cầu	Gọi một lần	1.00	635.4	341.6	0.0050

Bảng 12: Ngân sách suy luận và chi phí tính toán dưới các cấu hình gốc và gọi khớp. Các giá trị báo cáo là trung bình trên mỗi trường hợp đối với tất cả các ví dụ đánh giá. Các token đầu vào và đầu ra bao gồm tất cả các yêu cầu LLM được thực hiện bởi một phương pháp. Chi phí ước tính được tính dựa trên giá API tương ứng với mô hình nền báo cáo và ngày đánh giá.