

CoVer: Xác Minh Yêu Cầu Nhận Thức Mâu Thuẫn

Shuning Zhang^{1,*}, Dai Shi^{2,*}, Bohao Chu³, Hui Wang³, Yuwei Chuai^{4,†}, Yifan Wang⁵, Jingruo Chen⁶, Simin Li⁷, Xin Yi^{1,8,†}, Hewu Li¹ Đại học Tsinghua, ²Đại học Tongji, ³Đại học Duisburg-Essen, ⁴Đại học Luxembourg, ⁵Đại học Washington, ⁶Đại học Cornell, ⁷Đại học Beihang, ⁸Học viện Trí tuệ Nhân tạo Bắc Kinh yuwei.chuai@uni.lu, yixin@tsinghua.edu.cn *Đóng góp như nhau. †Tác giả liên hệ.

Tóm tắt


Việc kiểm tra sự thật trên mạng xã hội từ lâu đã gặp phải những thách thức liên quan đến xung đột ở mức bằng chứng và mức tổng hợp, nơi các bằng chứng sai lệch bắt chước các nguồn tin uy tín. Để nắm bắt thách thức này và hỗ trợ các nhiệm vụ xác minh xung đột, chúng tôi giới thiệu ContraNote, một tập dữ liệu thực tế quy mô lớn được chọn lọc từ hệ thống Ghi chú Cộng đồng của X. Nó bao gồm 33.686 bài đăng để đánh giá giải quyết xung đột ở mức bằng chứng, và 54.474 trường hợp để đánh giá ưu tiên ở mức tổng hợp. Ngoài ra, chúng tôi đề xuất CoVer, một khuôn khổ phân quyết thực tế với ba giai đoạn: chuẩn hóa sơ đồ bằng chứng, đồng thuận thực tế và xác minh sự hỗ trợ. Điều này ưu tiên bằng chứng hơn tiếng ồn để ngăn chặn việc làm ảnh hưởng đến phân quyết cuối cùng. Các đánh giá kỹ thuật cho thấy CoVer đạt hiệu suất mạnh so với các phương pháp cơ sở tiên tiến trên ContraNote (86,0% chính xác, 68,0% F1 trung bình, 64,5% chính xác cân bằng trên n Xung đột; và 88,5% chính xác, 88,5% F1 trung bình và 89,2% chính xác cân bằng trên Ưu tiên), CONFACT-

1 Giới thiệu

Phát triển các phương pháp kiểm tra sự thật tự động hiệu quả ngày càng trở nên quan trọng để giảm thiểu sự lan truyền thông tin sai lệch trên các nền tảng mạng xã hội với quy mô lớn (Choi và Ferrara, 2024; Augenstein và cộng sự, 2024). Các hệ thống hiện đại thường áp dụng một chuỗi xử lý phân rã-tổng hợp, chia các tuyên bố phức tạp thành các tuyên bố con nguyên tử, kiểm tra từng tuyên bố con dựa trên các nguồn kiến thức bên ngoài, và tổng hợp kết quả để xác định độ xác thực tổng thể (Wang và cộng sự, 2024). Kỹ thuật Tạo nội dung Tăng cường Truy xuất (RAG) đóng vai trò quan trọng trong chuỗi này bằng cách cho phép các Mô hình Ngôn ngữ Lớn (LLMs) căn cứ lập luận của mình trên bằng chứng bên ngoài được truy xuất từ web mở (Lewis và cộng sự, 2020).

Tuy nhiên, quy trình này thường xuyên gặp phải xung đột làm ảnh hưởng đến độ chính xác của phân quyết. Chúng tôi

phân loại những xung đột này thành hai cấp độ rõ rệt: (i) xung đột cấp độ bằng chứng, nơi các tài liệu được truy xuất từ các nguồn khác nhau đưa ra quan điểm đối lập về cùng một sự kiện, (ii) xung đột cấp độ tổng hợp, nơi các tiểu tuyên bố trong một tuyên bố phức tạp duy nhất đưa ra các tín hiệu mâu thuẫn cần được ưu tiên và hòa giải.



Hình 1: Minh họa về những bằng chứng mâu thuẫn.

Những thách thức này được minh họa trong một tuyên bố trên mạng xã hội cho rằng một nghiên cứu y tế công cộng mới được công bố liên kết vắc-xin COVID-19 với sự gia tăng các ca tử vong vượt mức (Hình 1). Trong quá trình xác minh, việc thu thập thông tin có thể phát hiện ra một xung đột về mức độ bằng chứng: một tiêu đề được chia sẻ rộng rãi diễn giải nghiên cứu này là “chứng minh” các tuyên bố phản đối vắc-xin trước đó, trong khi các phát ngôn từ tạp chí công bố nghiên cứu và các nhà dịch tễ học làm rõ rằng nghiên cứu này không có mối quan hệ nhân quả như vậy. Bên cạnh đó, một xung đột ở mức tổng hợp xuất hiện khi tuyên bố được phân tách thành các tuyên bố phụ (ví dụ, xu hướng tử vong vượt mức so với nguyên nhân gợi ý), tạo ra các tín hiệu mâu thuẫn cần được cân nhắc lẫn nhau. Ở đây, xung đột ở mức tổng hợp không nhất thiết có nghĩa là các tuyên bố phụ

Các tuyên bố mâu thuẫn lẫn nhau. Các tuyên bố phụ khác nhau có thể nhận được những phán quyết cục bộ mà hàm ý logic của chúng mâu thuẫn với tuyên bố tổng thể. Ví dụ, bằng chứng có thể ủng hộ quan sát rằng tỷ lệ tử vong vượt mức tăng lên trong khi bác bỏ sự gán nguyên nhân ngụ ý cho việc tiêm chủng COVID-19. Do đó, xung đột phát sinh khi các phán quyết cục bộ được tổng hợp lại.

Giải quyết những mâu thuẫn như vậy là rất quan trọng, tuy nhiên xung đột thông tin trên mạng xã hội khác với xung đột chung ở hai khía cạnh: (i) Cố ý: Khác với xung đột tìm kiếm chung thường xuất phát từ dữ liệu lỗi thời, xung đột trên mạng xã hội thường mang tính đối kháng, với thông tin sai lệch được tạo ra để bắt chước phong cách chính thống. (ii) Thiên vị phổ biến: Các câu chuyện sai lệch trên mạng xã hội có thể lan truyền nhanh hơn các chỉnh sửa dựa trên sự thật. Các phương pháp dựa trên tập hợp theo tần suất gặp khó khăn với những vấn đề này.

Để thu hẹp khoảng cách này, chúng tôi giới thiệu ContraNote, một bộ dữ liệu thực tế được tạo ra từ hệ thống Ghi chú Cộng đồng của X. ContraNote nắm bắt các xung đột trong thế giới thực bằng cách xác định các bài đăng nhận được các tuyên bố bác bỏ đối lập từ những người đóng góp từ cộng đồng. Chúng tôi đã lọc hơn hai triệu ghi chú để xây dựng hai nhiệm vụ: một nhiệm vụ xung đột gồm 33.686 bài đăng để đánh giá việc ủng hộ/bác bỏ, và một nhiệm vụ ưu tiên gồm 54.474 bài đăng để đánh giá việc xác định các bằng chứng chất lượng cao.

Chúng tôi đề xuất thêm CoVer, một khuôn khổ để phân tích và xử lý xung đột bằng cách ưu tiên bằng chứng hơn là nhiễu. Khác với các thuật toán tổng hợp tất cả bằng chứng cùng một lúc, CoVer sử dụng một quy trình có cấu trúc với ba mô-đun: chuẩn hóa lược đồ bằng chứng, đồng thuận thực tế và xác minh hỗ trợ. Điều này tạo thuận lợi cho việc kiểm tra từng phần riêng lẻ và loại bỏ những nhiễu như tin đồn trích dẫn, tiêu đề, hoặc các tuyên bố có liên quan yếu.

Các đánh giá kỹ thuật cho thấy CoVer vượt trội hơn các mô hình cơ sở tiên tiến (SOTA) trên nhiều tập dữ liệu khác nhau. Trên ContraNote Conflict và Prioritization, CoVer đạt độ chính xác lần lượt là 86,0% và 88,5%, với độ chính xác cân bằng tương ứng là 64,5% và 89,2%. Nó cũng đạt độ chính xác 88,4% trên CONFACT-HumC và 89,4% trên -ModC. Các nghiên cứu loại bỏ lần nữa xác nhận sự đóng góp của từng mô-đun trong khuôn khổ đề xuất của chúng tôi. Nhìn chung, bài báo này đưa ra ba đóng góp:

- Chúng tôi đề xuất khung CoVer, một thuật toán có các mô-đun chuẩn hóa sơ đồ bằng chứng, đồng thuận thực tế và xác minh hỗ trợ để giải quyết hiệu quả các xung đột bằng chứng.
- Chúng tôi xây dựng bộ dữ liệu ContraNote, bao gồm

33.686 trường hợp mâu thuẫn và 54.474 trường hợp ưu tiên được tạo ra từ X, cung cấp các môi trường thử nghiệm để đánh giá các xung đột trong thế giới thực.

- Chúng tôi cung cấp bằng chứng thực nghiệm rằng CoVer hoạt động mạnh mẽ so với các chuẩn mực SOTA trên các tập dữ liệu xung đột bằng chứng.

2 Bối cảnh và Công trình Liên quan

2.1 Kiểm tra sự thật tự động

Việc kiểm tra sự thật dựa trên chuyên gia truyền thống phải đối mặt với những thách thức đáng kể về khả năng mở rộng, thiên lệch trong việc lựa chọn và niềm tin của công chúng (Pennycook và Rand, 2019; Straub và Spradling, 2022; Chuai et al., 2025, 2026b). Đáp lại, các phương án dựa trên cộng đồng và tự động đã xuất hiện như những giải pháp khả thi (Kim và Walker, 2020; Quelle và Bovet, 2024; Zhang et al., 2026). Kiểm tra sự thật dựa trên cộng đồng, được minh họa bởi Ghi chú Cộng đồng của X (X Corp., 2026), có thể đạt độ chính xác tương đương với đánh giá của chuyên gia (Allen et al., 2021), chống lại lý luận theo động cơ (Epstein et al., 2020), và tiếp cận các cộng đồng trực tuyến rộng hơn (Micallef et al., 2020). Tuy nhiên, phương pháp này vẫn quá chậm để ngăn chặn thông tin sai lệch ở giai đoạn đầu và có thể bị thao túng đánh giá có kế hoạch (Chuai et al., 2024, 2026a,b).

Trước những tiến bộ gần đây trong các mô hình ngôn ngữ lớn (LLMs), các khung kiểm tra sự thật tự động cho thấy tiềm năng trong việc xác định các tuyên bố đa phương tiện đáng ngờ (Qi và cộng sự, 2024; Zhou và cộng sự, 2024), xác minh tính xác thực của chúng (Wang và Shu, 2023), và tạo ra các lời giải thích (Yue và cộng sự, 2024; He và cộng sự, 2023; Zeng và Gao, 2024) ngay sau khi xuất bản. Đáng chú ý, De và cộng sự (2025) đã nghiên cứu việc tổng hợp các ghi chú cộng đồng, trong khi chúng tôi tập trung vào việc giải quyết xung đột bằng chứng.

Ngoài việc xác minh, LLMs có thể nâng cao khả năng ra quyết định tập thể (Yang et al., 2024) bằng cách tổng hợp các quan điểm đa dạng (Burton et al., 2024) và chuyển đổi các ý kiến phức tạp thành các tuyên bố đồng thuận (Bakker et al., 2022). Chẳng hạn, Fish et al. (2024) đã tích hợp LLMs với lý thuyết lựa chọn xã hội để tạo ra nhiều bản tóm tắt thay vì một sự đồng thuận duy nhất. Công trình của chúng tôi khác ở chỗ tập trung vào giải quyết xung đột bằng chứng.

2.2 Giải quyết xung đột trong kiểm tra sự thật

Khám phá sự thật. Giải quyết xung đột sớm tập trung vào việc khám phá sự thật, nhằm xác định thông tin chính xác giữa các nguồn mâu thuẫn bằng cách ước lượng độ tin cậy của nguồn (Li và cộng sự, 2016). Các phương pháp truyền thống sử dụng các mô hình xác suất lặp đi lặp lại để suy luận độ tin cậy (Li và cộng sự, 2016; Lyu và cộng sự, 2017)

sau này phát triển thành các khuôn khổ thần kinh, chẳng hạn như De-ClarE, tổng hợp bằng chứng bên ngoài và độ tin cậy của nguồn thông qua cơ chế chú ý (Popat et al., 2018). Không giống như các phương pháp này tập trung vào độ tin cậy của nguồn, phương pháp của chúng tôi mô hình hóa sự đồng thuận giữa các mục bằng chứng mâu thuẫn.

Phân loại và thiên lệch trong xung đột kiến thức. Với việc áp dụng LLMs, tập trung đã chuyển sang xung đột kiến thức, có thể được phân loại thành xung đột trong cùng một bối cảnh, giữa các bối cảnh và sự khác biệt tham số (Su et al., 2024; Xie et al., 2023; Ming et al., 2024). Khi giải quyết những xung đột này, LLMs thể hiện các thiên lệch đáng kể: thiên lệch xác nhận đối với bộ nhớ tham số nội bộ (Xie et al., 2023; Su et al., 2024; Özer và Yıldız, 2025), thiên lệch tự sinh ưu tiên bối cảnh do chính chúng tạo ra nhưng sai lệch so với các dữ kiện được truy xuất (Tan et al., 2024), và thiên lệch lựa chọn khi LLMs phát hiện mâu thuẫn thông qua Suy luận Ngôn ngữ Tự nhiên (NLI) (Jiayang et al., 2024) nhưng tùy ý chọn các mục chứng cứ đơn lẻ mà không tổng hợp toàn diện (Jiayang et al., 2024). Để giảm bớt các thiên lệch này, chúng tôi căn cứ giải quyết xung đột vào việc nhận diện lập trường của chứng cứ và giải quyết dựa trên xung đột lập trường.

Các khuôn khổ phát hiện và giải quyết. Để chống lại thiên kiến của LLM, các nghiên cứu đã đề xuất các mô hình nhất quán thực tế để phát hiện (Jiayang et al., 2024), và sử dụng các cuộc tranh luận lặp đi lặp lại giữa nhiều tác nhân (ví dụ, MADAM-RAG) (Wang et al., 2025), hoặc tổng hợp lập luận đối lập để giải quyết (Yue et al., 2024). Hơn nữa, việc giải quyết chắc chắn yêu cầu hiệu chuẩn và ước lượng sự không chắc chắn để hợp nhất bằng chứng mâu thuẫn và đang phát triển trong các bối cảnh thời gian (Wan et al., 2024; Chen et al., 2022a; Özer và Yıldız, 2025; Burton et al., 2024). Khác với các khuôn khổ được thiết kế cho việc truy xuất và kiểm chứng tài liệu, chúng tôi tập trung vào việc hòa giải các bằng chứng mâu thuẫn.

3 Định nghĩa vấn đề

Trong việc kiểm tra sự thật tự động, bằng chứng mâu thuẫn chủ yếu tồn tại ở hai cấp độ: cấp độ bằng chứng và cấp độ tổng hợp. Mâu thuẫn cấp độ bằng chứng xảy ra khi các tài liệu được truy xuất trình bày các quan điểm đối lập về một sự kiện duy nhất. Mâu thuẫn cấp độ tổng hợp phát sinh khi một tuyên bố phức tạp được phân tách thành các tuyên bố phụ dẫn đến những kết luận khác nhau. Ví dụ, một sự gán đúng kèm theo nguyên nhân sai yêu cầu hệ thống tổng hợp những tín hiệu lẫn lộn này thành một kết luận mạch lạc.

Một cách chính thức, hãy để một khẳng định C được phân tích thành

subclaims $S = \{s_1, \dots, s_n\}$. Đối với mỗi s_i , hệ thống truy xuất một tập hợp các tài liệu chứng cứ $E_i = \{e_{i,1}, \dots, e_{i,m}\}$. Một xung đột cấp bằng chứng tồn tại nếu E_i chứa các nhân quan điểm mâu thuẫn đồng thời ủng hộ và phản bác s_i . Một xung đột cấp tổng hợp xảy ra khi tập hợp các phán quyết địa phương $V_S = \{v(s_1) \dots, v(s_n)\}$ có các hệ quả logic trái ngược đối với độ chính xác tổng thể của C . Mục tiêu là học một hàm xác minh $F(C, \bigcup E_i) \rightarrow y$ ánh xạ tuyên bố và chứng cứ mâu thuẫn thành phán quyết cuối cùng $y \in \{\text{Hỗ trợ, Phản bác, Không đủ thông tin bằng cách ưu tiên chứng cứ hơn nhiều}\}$.


Bộ dữ liệu 4 ContraNote

Chúng tôi đã xây dựng bộ dữ liệu ContraNote bằng cách sử dụng kho lưu trữ Community Notes mã nguồn mở được xuất bản bởi X (X Corp., 2025). Community Notes là một cơ chế kiểm chứng thông tin sai lệch dựa trên sự đóng góp của cộng đồng, nơi các cộng tác viên đủ điều kiện cung cấp bối cảnh bổ sung để đánh giá độ xác thực của các bài đăng. Dữ liệu dài hạn được sử dụng trong nghiên cứu này kéo dài từ tháng 6 năm 2021 đến tháng 5 năm 2026.

Các bài đăng cá nhân trên nền tảng thường xuyên gọi ra nhiều ghi chú cộng đồng với các quan điểm trái ngược nhau. Một số người đóng góp có thể đánh dấu một bài đăng là có khả năng gây hiểu lầm, trong khi những người khác có thể tranh luận rằng bài đăng đó không gây hiểu lầm vì nó đúng về mặt thực tế, mang tính châm biếm, hoặc chứa quan điểm cá nhân. Những quan điểm mâu thuẫn này về một bài đăng duy nhất tạo ra một môi trường phức tạp của các mâu thuẫn bằng chứng. Việc lựa chọn ghi chú cuối cùng được xác định bởi đánh giá hữu ích của người dùng và sự ưu tiên thuật toán. Sự phức tạp vốn có này cung cấp một cơ hội độc đáo cho các mô hình ngôn ngữ lớn để học hỏi từ các xung đột trong thế giới thực và phát triển các cơ chế ưu tiên thông tin.

Tập hợp dữ liệu ban đầu của chúng tôi bao gồm 2.276.724 ghi chú cộng đồng tương ứng với 1.502.486 bài viết duy nhất. Để tách các trường hợp xung đột, trước tiên chúng tôi đã xác định 443.148 bài viết nhận được nhiều hơn một ghi chú cộng đồng. Sau đó, chúng tôi tập trung vào các bài viết chứa sự đối lập lập trường, được định nghĩa bởi hai phân loại Ghi chú Cộng đồng: MISINFORMED_ HOẶC POTENTIALLY_MISLEADING và KHÔNG_MISLEADING.

Chúng tôi đã xây dựng hai nhiệm vụ chuẩn từ tập hợp dữ liệu đã được lọc này. Nhiệm vụ đầu tiên, ContraNote Conflict, đánh giá liệu một bài đăng gốc nên được ủng hộ hay bác bỏ dựa trên các ghi chú mâu thuẫn. Các trường hợp bị bác bỏ là những bài đăng đáp ứng ba điều kiện: (1) các ghi chú có quan điểm trái ngược, (2) nó có ít nhất một



Hình 2: Di phân phối trong ContraNote, (a) phân phối các lý do gây hiểu lầm, (b) độ dài ghi chú theo lập trường, (c) phân trăm của các ghi h đã trích dẫn các chú với nguồn.

ghi chú được đánh giá là HIỆN TẠI ĐƯỢC ĐÁNH GIÁ HỮU ÍCH, và (3) ít nhất một ghi chú hữu ích được dán nhãn SAI SỰ THẬT HOẶC CÓ THỂ GÂY HIỂU LẦM. Những trường hợp này tương ứng với các tuyên bố mà sự đồng thuận do đám đông đánh giá ủng hộ việc sửa chữa hoặc bác bỏ tích cực. Điều này tạo ra 27.445 trường hợp Bị Bác Bỏ. Các trường hợp được Hỗ Trợ nên thỏa mãn: (1) các ghi chú có sự đối lập về lập trường, (2) không chứa ghi chú hữu ích gây hiểu lầm, và tất cả các ghi chú gây hiểu lầm đều được đánh giá HIỆN TẠI ĐƯỢC ĐÁNH GIÁ KHÔNG HỮU ÍCH, (3) phần lớn các ghi chú của nó được dán nhãn KHÔNG GÂY HIỂU LẦM. Chúng tôi áp dụng các tiêu chí khác vì bộ dữ liệu của chúng tôi từ Community Notes không có ghi chú không gây hiểu lầm nào ở trạng thái hữu ích. Quá trình này tạo ra 6.241 trường hợp được Hỗ Trợ. ContraNote Conflict chứa 33.686 bài viết, bao gồm 27.445 trường hợp Bị Bác Bỏ và 6.241 trường hợp được Hỗ Trợ.

Nhiệm vụ thứ hai, ưu tiên ContraNote, đánh giá xem liệu một mô hình có thể xác định bằng chứng chất lượng cao có khả năng mâu thuẫn giữa các ghi chú hay không. Chúng tôi chọn các bài đăng có quan điểm đối lập chứa ít nhất một ghi chú hữu ích và một ghi chú không hữu ích, trong đó các ứng viên không hữu ích bao gồm các ghi chú được đánh giá là CURRENTLY_RATED_NOT_HELPFUL hoặc NEEDS_MORE_RATINGS. Dựa trên ngữ cảnh của bài đăng và tập hợp các ghi chú của nó, mô hình cần dự đoán ghi chú nào nên được ưu tiên. Điều này tạo ra một chuẩn mực cân bằng gồm 54.474 trường hợp trên 27.237 bài đăng, với 27.237 ghi chú mục tiêu được Hỗ trợ và 27.237 ghi chú mục tiêu bị Bác bỏ.

Như được thể hiện trong Hình 2, thiếu bối cảnh (22.615 trường hợp) và sai sự thật (20.918 trường hợp) là những nguyên nhân chính gây ra các tuyên bố gây hiểu lầm. Các ghi chú bác bỏ có chi tiết nhiều hơn (1,77 mỗi bài đăng) và độ dài lớn hơn (289,08 ký tự) so với các ghi chú ủng hộ. Phân tích liên kết bằng chứng cho thấy tin tức (49,1%) và các nền tảng mạng xã hội (24,6%) là các nguồn trích dẫn chính, trong khi các tài liệu bách khoa toàn thư vẫn là thứ yếu. Điều này cho thấy ContraNote chủ yếu dựa vào các bằng chứng đa dạng mà


yêu cầu đánh giá nguồn gốc. Việc mã hóa định tính cho thấy rằng các mối quan hệ giữa các chú thích mâu thuẫn vượt ra ngoài sự đối lập trực tiếp, bao gồm các bất đồng về bối cảnh, phạm vi và mức độ đồng hợp. Đáng chú ý, bất đồng về sự cần thiết của chú thích là mô hình xung đột chính (33%), nơi các cộng tác viên tranh cãi về sự cần thiết của việc kiểm duyệt. Phân tích phân phối ngôn ngữ cho thấy tiếng Anh chiếm phần lớn (13.776, 62,98%), tiếp theo là tiếng Tây Ban Nha (1.758, 8,04%) và tiếng Bồ Đào Nha (1.368, 6,25%).

Như được hiển thị trong Bảng 4, ContraNote mở rộng các chuẩn mực trước đó (Augenstein et al., 2019; Schlichtkrull et al., 2023; Chen et al., 2022b) bằng cách nắm bắt các mâu thuẫn bằng chứng tự nhiên xảy ra trong các bài đăng đơn lẻ. Để đánh giá độ tin cậy của nhãn, ba nhà chú thích được đào tạo đã độc lập chú thích trên 500 mục lấy mẫu ngẫu nhiên, cho kết quả độ tin cậy giữa các đánh giá viên cao (Fleiss' $\kappa = 0.82$). Các chú thích của con người theo phiếu đa số phù hợp với nhãn của bộ dữ liệu trong 94,2% trường hợp, xác thực độ chính xác của nhãn. Để tính đến khả năng thiên lệch, chúng tôi đã phân tích sử dụng PoliticalBiasBERT và nhận thấy bộ dữ liệu bao phủ nhiều quan điểm chính trị khác nhau (18,6% cánh tả, 47,0% trung lập, 34,4% cánh hữu) và các lĩnh vực chủ đề (ví dụ: 26,0% chính trị/quản trị, 20,6% khoa học/công nghệ, 29,8% truyền thông/giải trí/thể thao). Điều này cho thấy ContraNote phản ánh tín hiệu đồng thuận được tạo ra bởi cơ chế Community Notes. Chi tiết được hiển thị đầy đủ trong Phụ lục B.2.

5 Bài

5.1 Tổng quan về thuật toán

Như được thể hiện trong Hình 3, với một tuyên bố q và một tập hợp bằng chứng $E = \{e_i\}_{i=1}^N$, CoVer dự đoán một nhãn $y \in \{\text{Hỗ trợ}, \text{Phủ nhận}\}$. Thuật toán này có ba mô-đun: chuẩn hóa sơ đồ bằng chứng, đồng thuận thực tế và xác minh hỗ trợ.



Hình 3: Khung CoVer.

5.2 Chuẩn hóa Sơ đồ Bằng chứng

Mỗi mục bằng chứng e_i có thể chứa văn bản tự do và siêu dữ liệu có cấu trúc $e_i = (t_i, m_i)$, trong đó t_i là nội dung văn bản và m_i chứa các trường tùy chọn như URL nguồn. Chúng tôi chuẩn hóa mỗi mục thành một biểu diễn chuẩn: $z_i = \phi(e_i) = \phi(t_i, m_i)$. Mục chuẩn hóa z_i giữ lại cả văn bản và các dấu hiệu ở cấp độ lược đồ. Đối với bằng chứng QA, chúng tôi giữ các trường câu trả lời được đề xuất. Đối với bằng chứng chỉ nguồn, chúng tôi giữ các định danh trang và dòng. Đối với bằng chứng ghi chú ứng viên, các trường trạng thái, nhãn, lập trường và độ hữu ích được giữ lại. Đối với bằng chứng kiểm tra thực tế đơn giản, văn bản bài báo và các trích đoạn được giữ lại. Điều này tạo ra một tập hợp bằng chứng thống nhất $Z = \{z_i\}_{i=1}^N$.

5.3 Sự đồng thuận về sự thật

Giai đoạn thứ hai thực hiện việc phán quyết dựa trên các bằng chứng đã chuẩn hóa thông qua một quy trình ba bước: phán quyết từng bằng chứng riêng lẻ, tổng hợp đồng thuận và tạo ra phán quyết cuối cùng.

Đối với mỗi mục bằng chứng đã được chuẩn hóa $z_i \in$ liên quan đến tuyên bố q , CoVer ước lượng lập trường của nó đối với tuyên bố và đánh giá chất lượng bằng chứng của nó. Thay vì sử dụng các lệnh riêng biệt, chúng tôi sử dụng một lần gọi LLM duy nhất với các ràng buộc đầu ra có cấu trúc để dự đoán đồng thời lập trường s_i và bốn thành phần chất lượng chi tiết. Các ràng buộc này yêu cầu một lập trường hợp lệ từ tập nhân đã xác định trước, các điểm chất lượng số trong $[0, 1]$, và sự có mặt của tất cả các trường cần thiết cho tổng hợp xác định:

$$(s_i, d_i, a_i, l_i, u_i) = \text{LLM}_{\text{adj}}(q, z_i, m_i), \quad (1)$$

nơi $s_i \in \{\text{hỗ trợ, bác bỏ, không liên quan}\}$, và m_i biểu thị sơ đồ siêu dữ liệu được bảo lưu (ví dụ: URL nguồn, các tín hiệu hữu ích). Chất lượng com-

Các thành phần được chấm điểm trên một thang điểm chuẩn hóa $[0, 1]$ theo các tiêu chí sau:

- Tính thẳng thắn (d_i) đo lường việc z_i có trực tiếp đề cập đến đề xuất trung tâm của q hay không, đồng thời trừ điểm những mục chỉ chia sẻ các thực thể bên ngoài.
- Căn chỉnh thuộc tính (a_i) đánh giá sự tương thích thực tế trên các chiều quan trọng, bao gồm danh tính thực thể, phạm vi thời gian, vị trí và các tham số số học.
- Độ tin cậy của sơ đồ (l_i) bao gồm các chỉ báo siêu dữ liệu m_i (ví dụ: uy tín nguồn và đánh giá hữu ích từ cộng đồng) để đánh giá độ tin cậy của kênh bằng chứng.
- Tính thông tin (u_i) định lượng nội dung thực tế trọng yếu, gán điểm thấp cho các trích dẫn tin đồn lặp đi lặp lại, tiêu đề, hoặc văn bản chỉ đơn giản báo cáo sự tồn tại của một tuyên bố.

Điểm chất lượng tổng thể q_i được tính toán một cách xác định như là tổ hợp tuyến tính có trọng số của các thành phần này: $q_i = \lambda_d d_i + \lambda_a a_i + \lambda_l l_i + \lambda_u u_i$, trong đó các trọng số được điều chỉnh như $\lambda_d = \lambda_a = \lambda_l = \lambda_u = 0.25$ để cân bằng mỗi chiều (xem Phụ lục D.2). Cho (s_i, q_i) cho tất cả các mục bằng chứng, CoVer tổng hợp các bằng chứng một cách xác định để giải quyết các mâu thuẫn. Trước tiên, chúng tôi tính điểm tích lũy có trọng số chất lượng cho các quan điểm ủng hộ và phản đối:

$$A_{\text{sup}} = \sum_{i=1}^{|Z|} q_i \cdot \mathbb{I}[s_i = \text{support}], \quad (2)$$

$$A_{\text{ref}} = \sum_{i=1}^{|Z|} q_i \cdot \mathbb{I}[s_i = \text{refute}], \quad (3)$$

nơi $\mathbb{I}[\cdot]$ là hàm chỉ báo. Quan điểm thực tế chiếm ưu thế s^* được chọn bằng cách so sánh độ mạnh tích lũy:

$$s^* = \begin{cases} \text{support}, & \text{if } A_{\text{sup}} > A_{\text{ref}}, \\ \text{refute}, & \text{if } A_{\text{ref}} \geq A_{\text{sup}}. \end{cases} \quad (4)$$

Chúng tôi sử dụng Refute làm tiêu chí quyết định khi hòa, điều này tuân theo mục tiêu thận trọng là tránh các dự đoán tích cực không có cơ sở. Để đánh giá các thiên lệch tiềm ẩn, chúng tôi đánh giá một biến thể trong đó các trường hợp hòa được gán cho Support. Các kết quả tương ứng được báo cáo trong Phụ lục D.3. Để loại bỏ nhiễu không liên quan và các khẳng định chất lượng thấp, bộ bằng chứng đồng thuận cuối cùng G^* được lọc sử dụng ngưỡng chất lượng τ_q :

$$G^* = \{z_i \in \mathcal{Z} \mid s_i = s^* \wedge q_i \geq \tau_q\}. \quad (5)$$

Mối tương quan thực tế giữa tập hợp đồng thuận tổng hợp G^* và tuyên bố q được phân xử bởi một lần gọi LLM bổ sung, cho ra $r = \text{LLM}_{\text{ver}}(q, G^*) \in \{\text{xác nhận}, \text{mâu thuẫn}, \text{không đủ}\}$. 'xác nhận' được ánh xạ thành Hỗ trợ, trong khi các kết quả khác được ánh xạ thành Bác bỏ, vì không có kết quả nào cho thấy bài đăng gốc được hỗ trợ theo giao thức gắn nhãn Community Notes. Để kiểm tra tác động của chiến lược này, chúng tôi đánh giá thiết lập Hỗ trợ/Một phần Hỗ trợ/Bác bỏ trong Phụ lục C.4.

5.4 Xác minh Hỗ trợ

Với đầu ra đồng thuận thực tế y_{strict} , CoVer chỉ áp dụng việc xác minh hỗ trợ khi đồng thuận thực tế dự đoán được Hỗ trợ. Nếu $y_{\text{strict}} = \text{Bị Bác bỏ}$, thuật toán kết thúc và trả về Bị Bác bỏ. Chúng tôi sử dụng điều này như một bộ lọc thận trọng cho các dự đoán dương tính. Khi $y_{\text{strict}} = \text{Được Hỗ trợ}$, CoVer xây dựng tập hợp hỗ trợ ứng viên

$$\mathcal{Z}_{\text{sup}} = \{z_i \in \mathcal{Z} : s_i = \text{support}, q_i \geq \tau_q\}.$$

Nó sau đó thực hiện một cuộc gọi xác minh cuối cùng: $v = g_\theta(q, \mathcal{Z}_{\text{sup}}) \in \{\text{hợp lệ}, \text{không hợp lệ}\}$. Trình xác minh này kiểm tra xem bằng chứng hỗ trợ được chọn có xác thực trực tiếp và độc lập mệnh đề trung tâm của tuyên bố hay không. Nó bác bỏ sự hỗ trợ nếu bằng chứng chỉ trích dẫn một tuyên bố hoặc tin đồn, tiêu đề hoặc thiết lập kiểm tra sự thật, về một thực thể, thời gian, câu trả lời hoặc phạm vi khác, hoặc chỉ đơn giản liên quan mà không có tuyên bố thực tế. Dự đoán cuối cùng $\hat{y}$ được gán nhãn là Hỗ trợ nếu $y_{\text{strict}} = \text{Hỗ trợ} \wedge v = \text{hợp lệ}$, và Ngược lại nếu không.

6 Thí nghiệm

6.1 Bộ dữ liệu

Chúng tôi chọn nhiều bộ dữ liệu khác nhau đại diện cho các mức độ xung đột khác nhau. Cụ thể, chúng tôi kiểm tra các bằng chứng mâu thuẫn trong việc kiểm chứng thông tin trên mạng xã hội và các tình huống khác để đánh giá khả năng tổng quát hóa của CoVer: CONFACT (Ge và cộng sự, 2025). Khác với các chuẩn mực truyền thống nơi bằng chứng thường nhất quán, CONFACT được tuyển chọn đặc biệt để bao gồm các tuyên bố có bằng chứng mâu thuẫn trên web (ví dụ, các báo cáo trái chiều về sự kiện chính trị hoặc tranh luận khoa học). Nó phục vụ như một bộ thử nghiệm chính để đo khả năng của các tác nhân trong việc giải quyết xung đột bằng chứng.

ConflictBank (Su et al., 2024). Bộ chuẩn này phân tích hành vi của mô hình bằng cách mô phỏng các xung đột kiến thức. Nó bao gồm 553.117 cặp hỏi đáp được trích từ 2.863.205 khẳng định của Wikidata, bao phủ ba nguyên nhân xung đột chính: thông tin sai lệch, thay đổi theo thời gian và biến thể ngữ nghĩa. Sử dụng các cặp hỏi đáp gốc, chúng tôi xây dựng các ví dụ phản bác bằng cách coi bằng chứng đã được chỉnh sửa là các nhóm bằng chứng mâu thuẫn, tạo ra 1.659.351 mục dữ liệu.

ECON (Jiayang et al., 2024). Bộ dữ liệu dựa trên hai bộ dữ liệu công khai: Câu hỏi tự nhiên (Natural Questions) và Câu hỏi web phức tạp (Complex Web Questions), trong đó họ xây dựng các câu trả lời thay thế như các bằng chứng mâu thuẫn, tạo ra các loại mâu thuẫn câu trả lời và sự thật khác nhau: cấp độ, thực thể, phủ định, số, thời gian, động từ và các loại khác. ECON chứa 4.995 mục dữ liệu. ContraNote. Chúng tôi sử dụng phiên bản được mô tả trong Mục 4. Các nhân nhị phân chính tuân theo sơ đồ gắn nhãn của Community Notes. Chúng tôi cũng cung cấp một phân tích thử nghiệm m ba hướng trong Phụ lục C.4.

FEVER (Thorne et al., 2018). Đây là một bộ dữ liệu kiểm tra sự thật được sử dụng rộng rãi nhất (Min et al., 2023; Chen et al., 2023), bao gồm việc trích xuất và xác minh thông tin. Nó chứa các tuyên bố được tạo ra bằng cách thay đổi các câu trích xuất từ Wikipedia và sau đó được xác minh mà không truy cập vào các câu nguồn. Các tuyên bố được gán nhãn là được hỗ trợ, bị bác bỏ và thông tin không đủ. Chúng tôi đã sử dụng tập con tuyên bố được chia sẻ, bao gồm 19.998 tuyên bố.

6.2 Đường cơ sở

Chúng tôi so sánh CoVer với tám phương pháp cơ sở đại diện cho giải quyết xung đột hoặc kiểm tra sự thật trên mạng xã hội. Để đảm bảo đánh giá có kiểm soát, chúng tôi tách việc xác minh ra khỏi việc truy xuất. Bằng cách cung cấp cho tất cả các phương pháp cùng một tập hợp bằng chứng mâu thuẫn, chúng tôi cô lập sự biến thiên trong truy xuất như một biến gây nhiễu. Do đó, trong khi một số phương pháp cơ sở ban đầu

Bộ dữ liệu	Tập con	Số	Tích cực	Tiêu cực
CONFACT	HumC	287	51	236
	ModC	611	125	486
Ngân hàng Xung đột	—	1,659,351	553,117	1,106,234
ECON	—	4,995	2,043	2,952
ContraNote	Xung đột	33,686	6,241	27,445
	Ưu tiên	54,474	27,237	27,237
SỐT	—	13,332	6,666	6,666

Bảng 1: Phân phối bộ dữ liệu (Dương: Hỗ trợ, Âm: Phủ nhận).

bao gồm các thành phần truy xuất, chúng tôi điều chỉnh chúng để tập trung vào việc xét xử bằng chứng.

FactTool (Chern et al., 2023): Một phương pháp thực hiện xác minh một lần dựa trên bằng chứng được truy xuất, đại diện cho một luồng kiểm tra sự thật cơ bản.

FactCheckGPT (Wang và cộng sự, 2024): Một phương pháp dựa trên phân rã, phá vỡ một tuyên bố thành các tuyên bố con cơ bản, truy xuất bằng chứng cho từng tuyên bố con một cách riêng lẻ, và tổng hợp kết quả, do đó phục vụ như một quy trình kiểm tra thực tế tự động tiêu chuẩn.

FIRE (Xie et al., 2025): Một tác nhân suy luận lặp đi lặp lại. Khác với FactTool, FIRE hoạt động theo dạng vòng lặp. Nó đánh giá xem bối cảnh hiện tại có đủ để trả lời khẳng định hay không. Nếu không, nó xem xét các bằng chứng mới. Thông qua quá trình này, nó mô phỏng ngấm xung đột. Confact (Ge et al., 2025): Một khung RAG nhận biết nguồn được thiết kế để giải quyết xung đột bằng chứng bằng cách tích hợp siêu dữ liệu nền của phương tiện truyền thông (ví dụ, đánh giá độ tin cậy của nguồn và thông tin thiên lệch) trực tiếp vào giai đoạn tạo câu trả lời. Nó sử dụng suy luận có cấu trúc (ví dụ, Chuỗi Suy Nghi) để đánh giá và ưu tiên bằng chứng từ các nguồn đáng tin cậy, từ đó giảm thiểu ảnh hưởng của thông tin gây hiểu lầm từ các nguồn không đáng tin cậy.

ECON (Jiayang et al., 2024) (tức là ConflictRes): Một khuôn khổ tập trung vào các xung đột bằng chứng, đặc biệt là những xung đột xảy ra giữa các ngữ cảnh được truy xuất khác nhau. ECON giải quyết khoảng cách giữa việc phát hiện của các mô hình ngôn ngữ lớn (LLM) và hành vi giải quyết không đáng tin cậy của chúng, chẳng hạn như lựa chọn bằng chứng tùy ý hoặc phụ thuộc quá mức vào các tiên kiến nội bộ.

Các cơ sở so sánh bổ sung: Chúng tôi cũng so sánh một trình xác minh theo phong cách AVeriTeC, MADAM-RAG, và ClaimDecomp. Trình xác minh theo phong cách AVeriTeC sử dụng xác minh bằng chứng hướng dẫn theo câu hỏi cho các tuyên bố thực tế, trong khi MADAM-RAG đại diện cho một quy trình xác minh tăng cường truy xuất đa tác nhân. ClaimDecomp phân rã một tuyên bố phức tạp thành các tuyên bố con theo nghĩa đen và ngụ ý, xác minh chúng từng một, và tổng hợp các giá trị cục bộ của chúng

dicts. Trong thiết lập bằng chứng cố định của chúng tôi, các phương pháp này nhận được cùng một tập hợp yêu cầu và bằng chứng như các phương pháp cơ sở khác, tách biệt sự khác biệt về xác minh và tổng hợp thay vì phạm vi truy xuất.

6.3 Cài đặt học tập

Chi tiết triển khai

Tất cả các đại lý trong đánh giá của chúng tôi sử dụng gpt-4o làm LLMs nền tảng. Các phương pháp cơ bản được triển khai với các cấu hình sau để đảm bảo khả năng tái lập: FactTool tạo hai truy vấn tìm kiếm và truy xuất 10 kết quả hàng đầu cho mỗi truy vấn bằng quy trình xác minh CoT. FactCheckGPT phân tách các tuyên bố thành 2–3 truy vấn và xác minh kết quả thông qua NLI. Đại lý FIRE theo vòng lặp bị giới hạn tối đa 10 bước. CONFACT truy xuất 10 kết quả hàng đầu và bổ sung chúng bằng mô tả nền của tuyên bố dưới 50 từ mỗi mô tả, trong khi ConflictRes tập trung vào việc giải quyết các mâu thuẫn giữa 10 đoạn trích được truy xuất hàng đầu. Tương tự, chúng tôi giới hạn CoVer tối đa 10 bằng chứng để duy trì hiệu quả xử lý. Mỗi phương pháp nhận cùng một truy vấn và bằng chứng. Chúng tôi lặp lại mỗi thí nghiệm năm lần và báo cáo kết quả trung bình.

Cài đặt khởi

Chúng tôi đánh giá đóng góp của từng thành phần CoVer bằng cách loại bỏ các mô-đun.

Không có chuẩn hóa lược đồ bằng chứng: chúng tôi loại bỏ mô-đun chuẩn hóa lược đồ và chỉ cung cấp bằng chứng cho người phân xử dưới dạng văn bản không có cấu trúc. Chúng tôi bỏ qua các dấu hiệu có cấu trúc như câu trả lời được đề xuất, chỉ số nguồn, định danh dòng, quan điểm ghi chú ứng viên và các dấu hiệu ứng viên-mục tiêu. Điều này kiểm tra xem các cấu trúc bằng chứng liên quan đến nhiệm vụ có cần thiết cho việc giải quyết xung đột hay không.

Không có sự đồng thuận về thực tế: hệ thống không còn chọn nhóm chứng cứ trực tiếp, nhất quán nội bộ và phù hợp với tuyên bố trước khi đưa ra quyết định. Điều này đánh giá liệu sự đồng thuận về thực tế với nhóm chứng cứ có hữu ích hay không.

Không có xác minh hỗ trợ: mô hình chấp nhận các quyết định hỗ trợ mà không kiểm tra thêm về sự suy diễn trực tiếp, tính hợp lệ của mục tiêu-ứng viên, hoặc mâu thuẫn bởi bằng chứng mạnh hơn.

Loại bỏ theo cặp: chúng tôi tiếp tục đánh giá tất cả các loại bỏ theo cặp: không có Schema + Consensus, không có Schema + Support, và không có Consensus +Support. Các thiết lập này đo lường xem các mô-đun có cung cấp lợi ích bổ sung hay hiệu suất chỉ được thúc đẩy bởi một thành phần duy nhất.

Không có tất cả: chúng tôi loại bỏ cả ba mô-đun để tạo

cài đặt tối thiểu.

6.4 Kết quả chính

Bảng 2 so sánh CoVer với các phương pháp cơ sở trên tất cả các bộ dữ liệu.

CoVer hoạt động mạnh mẽ trên các nhiệm vụ liên quan đến mâu thuẫn phức tạp và sự mơ hồ. Như thể hiện trong Bảng 2, CoVer vượt qua tất cả các tiêu chuẩn về CON- FACT, đạt độ chính xác 88,4% trên HumC và 89,4% trên ModC. Trên ContraNote Conflict, nó đạt độ chính xác dẫn đầu là 86,0%, so với 82,8% của ConFact và 81,3% của ConflictRes. Những kết quả này cho thấy khả năng tổng hợp thông tin mâu thuẫn của CoVer và giải quyết các yêu cầu liên quan đến sự không nhất quán có tính tình tế.

CoVer hiệu quả trong việc ưu tiên chứng cứ và giải quyết xung đột theo lĩnh vực cụ thể. Về Ưu tiên Ghi chú Trái chiều, CoVer đạt độ chính xác 88,5%, vượt qua các chuẩn mực như FIRE (64,5%). Tương tự, trên ConflictBank, CoVer đạt độ chính xác 73,5%, cho thấy sự cải thiện rõ rệt so với FactCheckGPT (63,5%). Điều này nhấn mạnh khả năng của CoVer trong việc xử lý các tình huống xung đột có cấu trúc và ưu tiên các tín hiệu đáng tin cậy.

Ngoài việc trọng tài xung đột, CoVer thể hiện độ chính xác cao trên các bộ dữ liệu kiểm tra sự thật. Nó đạt độ chính xác 93,4% trên FEVER, vượt qua ConFact (87,0%) và FactCheckGPT (81,5%). Trên ECON, nó đạt độ chính xác cao nhất (77,5%) so với ConFact (74,0%). Điều này xác nhận khả năng tổng quát của CoVer trong việc kiểm tra sự thật trên các bộ dữ liệu.

So sánh cơ sở bổ sung: Trình xác minh kiểu AVeriTeC đạt F1 trung bình 65,6 và 80,5 trên ContraNote Conflict và Prioritization, tương ứng, trong khi MADAM-RAG đạt 47,7 và 70,3; CoVer đạt 68,0 và 88,5 trên cùng hai nhiệm vụ. ClaimDecomp đạt độ chính xác lần lượt là 82,23, 84,58, 80,00 và 66,00, với các điểm F1 trung bình tương ứng là 67,28, 76,21, 54,29 và 65,58 trên CONFACT-HumC, CONFACT-ModC, ContraNote Conflict và ContraNote Prioritization, tương ứng. Theo cùng thứ tự dữ liệu, CoVer đạt các điểm F1 trung bình lần lượt là 77,10, 83,10, 68,00 và 88,50. Những kết quả này cho thấy CoVer vẫn cạnh tranh với các cơ sở hướng truy xuất và phân tách yêu cầu, với những cải thiện lớn nhất xuất hiện ở việc ưu tiên bằng chứng và tổng hợp xung đột.

Truy xuất: Vượt ra ngoài cài đặt bằng chứng vàng, vốn tách biệt việc xét xử bằng chứng và ngăn ngừa các hiệu ứng gây nhiễu từ chất lượng truy xuất, chúng tôi đánh giá xem liệu khung này vẫn hữu ích với việc kết thúc

truy xuất bằng chứng toàn bộ. Chúng tôi kết hợp mỗi phương pháp với bộ truy xuất dữ liệu phía trên và đánh giá các dự đoán cấp độ tuyên bố thu được. Trong thiết lập Conflict ContraNote được hỗ trợ truy xuất, CoVer đạt 69,6 mac. F1, so với 59,2 mac. F1 cho phương pháp cơ sở mạnh nhất. Điều này cho thấy CoVer bổ sung cho việc truy xuất, phân xử bằng chứng với các quan điểm, độ tin cậy và sự phù hợp với tuyên bố khác nhau.

Đường cơ sở phẩm tât

Để kiểm tra xem nhãn ContraNote có thể được khôi phục từ siêu dữ liệu đã nhập hay không, chúng tôi đánh giá một phương pháp cơ bản nhanh, với các quy tắc dự đoán Refuted nếu và chỉ nếu ít nhất một ghi chú được đánh dấu vừa hữu ích vừa gây hiểu nhầm. Trên ContraNote Conflict, phương pháp này đạt 81,5% độ chính xác, mac. F1 44,9 và bal. Acc. 50,0. Trên ContraNote Prioritization, phương pháp này đạt 50,0% độ chính xác, mac. F1 33,3 và bal. Acc. 50,0. Độ chính xác cao của nó được giải thích bởi sự mất cân bằng lớp, trong đó mac. F1 và bal. Acc. mang tính ngẫu nhiên.

Đánh giá bị ẩn siêu dữ liệu

Chúng tôi tiến hành thử nghiệm thêm các điều kiện của CoVer bằng cách loại bỏ các trường trạng thái ghi chú có thể tiết lộ các tín hiệu thời gian xây dựng, tức là mức độ hữu ích, trạng thái, phân loại và nhãn của ghi chú mục tiêu. Trong bối cảnh này, CoVer đạt 87,5% F1 trung bình và 86,5% độ chính xác cân bằng. Điều này cho thấy CoVer duy trì hiệu suất mạnh mẽ mà không cần truy cập vào các trường siêu dữ liệu.

Kiểm định thống kê

Chúng tôi đánh giá sự khác biệt theo cặp sử dụng kiểm định McNemar với $\alpha = 0.05$. Những cải tiến của CoVer là đáng kể trên tất cả các tập dữ liệu được đánh giá ngoại trừ các so sánh trên ContraNote Conflict với CONFACT và ConflictRes. Do đó, các kết quả trên ContraNote Conflict chỉ ra xu hướng hiệu suất tích cực nhưng không đáng kể. Phụ lục E.2 bổ sung cho các kiểm định này bằng phân tích lỗi.

6.5 Nghiên cứu loại bỏ

Mô-đun đồng thuận thực tế là rất quan trọng để giải quyết các mâu thuẫn phức tạp. Như được trình bày trong Bảng 3, việc loại bỏ mô-đun này (không có Đồng thuận) làm giảm hiệu suất trong các nhiệm vụ yêu cầu phân xử tình vi, nơi độ chính xác trên ContraNotePrioritization giảm từ 88,5% xuống 42,5%. Tương tự, độ chính xác trên ContraNote Conflict giảm từ 86,0% xuống 69,0%.

Chuẩn hóa sơ đồ bằng chứng là rất cần thiết để phân tích thông tin thực tế. Trong khi việc loại bỏ mô-đun này không ảnh hưởng đến hiệu suất trên CONFACT, nó gây suy giảm trên ECON, giảm từ 77,5% xuống 45,5%. Chúng tôi cũng quan sát thấy đáng kể

Phương pháp	CONFACT HumC	CONFACT ModC	Ngân hàng Xung đột	ECON	SỐT	Ghi chú đối lập Xung đột	Ghi chú đối lập Ưu tiên
FacTool	80.0 60.8 59.9	81.5 69.6 68.2	57.8 52.0 52.5	70.0 69.2 69.2	51.0 50.3 61.7	71.1 63.4 71.2	59.8 59.8 60.0
KiểmTraSưTháiGPT	84.0 67.7 65.8	80.5 68.0 66.7	63.5 57.5 58.0	67.5 66.6 66.6	81.5 80.9 85.0	72.2 60.1 62.9	55.8 55.7 56.3
FIRE	79.0 55.0 54.6	78.4 66.0 65.4	54.8 48.2 48.3	63.0 61.9 62.0	72.0 71.7 76.7	72.2 63.0 68.5	64.5 63.8 63.9
Liên hệ	75.9 62.5 64.4	80.8 74.2 77.4	60.5 56.4 57.9	74.0 74.0 74.4	87.0 85.1 84.3	82.8 73.4 76.1	62.8 62.8 62.9
Xung đột	81.5 64.2 63.1	77.5 68.5 70.0	57.0 44.1 44.7	68.5 67.8 67.8	74.5 73.4 76.0	81.3 70.2 71.8	61.5 60.1 60.6
Bìa	88.4 77.1 74.3	89.4 83.1 81.6	73.5 63.4 62.5	77.5 77.5 77.7	93.4 92.9 94.3	86.0 68.0 64.5	88.5 88.5 89.2

Bảng 2: So sánh cơ sở giữa các bộ dữ liệu đánh giá khác nhau. Các chỉ số trong mỗi ô được định dạng dưới dạng Accuracy | mac. F1 | bal. Acc.

Cài đặt	CONFACT HumC	CONFACT ModC	Ngân hàng Xung đột	ECON	SỐT	Ghi chú đối lập Xung đột	Ghi chú đối lập Ưu tiên
Full	88.4 77.1 74.3	89.4 83.1 81.6	73.5 63.4 62.5	77.5 77.5 77.7	93.4 92.9 94.3	86.0 68.0 64.5	88.5 88.5 89.2
không có Sơ đồ	88.4 77.1 74.3	89.4 83.1 81.6	68.8 56.8 56.7	45.5 40.7 47.0	82.4 81.6 84.5	84.0 71.7 71.2	76.9 76.9 77.0
không có sự đồng thuận	84.4 74.0 75.4	81.1 73.9 76.4	63.3 60.8 64.0	77.5 77.5 77.7	88.5 87.6 89.5	69.0 58.0 49.7	42.5 31.9 40.2
không có hỗ trợ	85.8 73.2 71.6	88.4 81.5 80.1	70.0 60.0 59.5	77.5 77.5 77.7	88.5 87.6 89.5	85.5 66.3 63.1	68.5 68.3 68.3
không có Schema + Consensus	80.6 67.0 67.4	78.9 70.3 72.3	63.8 61.3 64.3	76.5 76.5 77.0	88.0 86.8 87.6	60.0 55.7 65.6	54.0 59.8 53.5
không có Hỗ trợ Schema +	82.7 62.3 60.5	86.3 76.3 73.4	69.3 60.0 59.6	59.5 55.0 57.3	86.5 85.5 87.3	84.0 71.7 71.2	79.4 79.4 79.5
không có Hỗ trợ Đồng thuận +	84.4 74.0 75.4	81.1 73.9 76.4	63.3 60.8 64.0	77.5 77.5 77.7	88.5 87.6 89.5	72.0 60.9 52.6	40.5 30.1 38.3
không có tất cả	80.6 67.0 67.4	78.9 70.3 72.3	63.8 61.3 64.3	76.5 76.5 77.0	88.0 86.8 87.6	61.0 56.4 67.4	49.7 54.8 49.3

Bảng 3: Kết quả ablation trên các thành phần khác nhau của CoVer, được định dạng dưới dạng Accuracy | mac. F1 | bal. Acc.. Schema=Chuẩn hóa Lược đồ Bằng chứng, Consensus=Thống nhất Thực tế, Support=Xác minh Hỗ trợ.

suy giảm đáng kể trên FEVER (93,4% xuống 82,4%) và ConflictBank (73,5% xuống 68,8%).

Xác minh hỗ trợ đảm bảo tính ổn định của suy luận, và CoVer thể hiện hiệu ứng hiệp lực mạnh k hi tích hợp tất cả các mô-đun. Việc loại bỏ xác minh hỗ trợ làm giảm hiệu suất trên nhiều tập dữ liệu, đặc biệt là trên ContraNote Prioritization (giảm từ 88,5% xuống 68,5%). Hơn nữa, cấu hình không có tất cả các yếu tố tạo ra sự suy giảm đáng kể nhất trong các nhiệm vụ phức tạp, giảm độ chính xác của CONFACT-HumC xuống 80,6% và ContraNote Prioritization xuống 49,7%.

6.6 Tính vững chắc của Diễn giải theo Thời gian

Vì GPT-4o có thể được đào tạo trên các Ghi chú Cộng đồng có sẵn công khai, chúng tôi đánh giá xem CoVer có dựa vào việc ghi nhớ hay không. Chúng tôi xây dựng một phần dữ liệu bị giữ lại theo thời gian từ tháng 1 năm 2026 và diễn giải lại các tuyên bố trong khi vẫn giữ nguyên ý nghĩa của chúng. Trong bài kiểm tra này, CoVer đạt 68,8 điểm mac. F1, so với 66,5 của phương pháp cơ sở mạnh nhất.

6.7 Phân tích Chi phí Tính toán

Dựa trên kết quả từ tất cả các bộ dữ liệu đánh giá, thời gian sinh trung bình cho mỗi lần gọi và thời gian kiểm tra sự thật từ đầu đến cuối là 5,8 giây. Số lượng token trung bình sử dụng là 1546,1 token c ho mỗi yêu cầu (1274,9 input / 271,2 output), tương ứng với chi phí ước tính là 0,0059 USD cho mỗi yêu cầu. Những kết quả này gợi ý rằng việc giải quyết bằng chứng mâu thuẫn với CoVer vẫn khả thi về mặt tính toán và kinh tế. Để kiểm soát ngân sách suy diễn, chúng tôi đánh giá cả các cấu hình cơ bản gọi một lần và các cấu hình gọi nhiều lần.

các tác vụ được khớp với số lần gọi LLM được CoVer sử dụng. Các phiên bản nhiều lần gọi cải thiện một số cơ sở, nhưng CoVer vẫn giữ được tính cạnh tranh khi số lần gọi được cân bằng. Số lần gọi và việc sử dụng token được báo cáo trong Phụ lục E.1.

7 Kết luận

Bài báo này đề cập đến các xung đột ở cấp độ bằng chứng và cấp độ tổng hợp trong việc kiểm tra sự thật tự động trên mạng xã hội. Chúng tôi đề xuất CoVer, một khuôn khổ giải quyết những mâu thuẫn này thông qua việc cấu trúc hóa chuẩn hóa lược đồ bằng chứng, đồng thuận về sự thật và xác minh hỗ trợ, hiệu quả trong việc ưu tiên bằng chứng so với nhiều. Sau đó, chúng tôi xây dựng ContraNote, một bộ dữ liệu thực tế được rút ra từ X để giải quyết xung đột (33.686 mục) và ưu tiên bằng chứng (54.474 mục). Các thí nghiệm mở rộng cho thấy CoVer đạt hiệu suất mạnh so với các phương pháp cơ sở SOTA, đạt độ chính xác 86,0% và 88,5% trong các nhiệm vụ Xung đột và Ưu tiên (độ chính xác cân bằng: 64,5% và 89,2%) tương ứng.

Lời cảm ơn

Công trình này được hỗ trợ bởi Dự án Khoa học và Công nghệ Lớn Bắc Kinh theo Hợp đồng số Z251100008125024, Học viện Trí tuệ Nhân tạo Bắc Kinh (BAAI), và Quỹ Nghiên cứu Quốc gia Luxembourg (tham chiếu C25/IS-SAS/19599536).

8 Hạn chế

Chúng tôi nhận ra một số hạn chế trong bài báo này, điều này làm nổi bật các hướng nghiên cứu trong tương lai.

Đầu tiên, khung đề xuất và bộ dữ liệu Contra-Note tập trung hoàn toàn vào các tuyên bố văn bản và siêu dữ liệu, chủ yếu bằng tiếng Anh. Mặc dù chúng tôi đa dạng hóa phạm vi ngôn ngữ, nhưng phạm vi hiện tại vẫn chưa đủ cho việc triển khai toàn diện trong thực tế. Hơn nữa, thông tin sai lệch trên mạng xã hội hiện đại là đa phương tiện. Cài đặt hiện tại của chúng tôi loại trừ việc giải quyết xung đột liên quan đến hình ảnh bị thao túng, deepfake hoặc video ngoài ngữ cảnh, vốn thường gây ra mâu thuẫn bằng chứng thực tế. Ngoài ra, hiệu quả của khung này trong các ngôn ngữ tài nguyên thấp hoặc các lĩnh vực chuyên biệt cao (ví dụ: văn bản pháp lý hoặc y tế) cần được kiểm chứng thêm.

Thứ hai, định nghĩa thực tế trong bộ dữ liệu Con- traNote dựa vào sự đồng thuận từ đám đông và các điểm hữu ích theo thuật toán. Trong khi phương pháp này phản ánh sự đồng thuận xã hội thực tiễn dưới sự kiểm soát chất lượng thuật toán, nó không hoàn toàn tương đương với sự thật tuyệt đối và vẫn dễ bị thao túng đánh giá có phối hợp. Hơn nữa, các chuyên gia gắn nhãn được đào tạo có thể chia sẻ một số giả định văn hóa hoặc ý thức hệ giống như các đóng góp viên của Community Notes.

Thứ ba, các thí nghiệm chính của chúng tôi sử dụng một môi trường bằng chứng vàng để tách biệt việc xét xử khỏi việc truy xuất. Chúng tôi cũng tiến hành một thí nghiệm có khả năng truy xuất đầu-cuối, nhưng thí nghiệm này có quy mô hạn chế. Do đó, CoVer nên được xem như là bổ sung cho các hệ thống truy xuất.

Cuối cùng, một số cải tiến theo cặp trên chuẩn mực ContraNote Conflict không đạt được sự khác biệt có ý nghĩa. Phân tích công suất cho thấy cần khoảng 4,9 lần mẫu nhiều hơn để phát hiện sự khác biệt về độ chính xác quan sát được giữa CoVer và CONFACT với công suất 80%, và khoảng 2,4 lần mẫu nhiều hơn cho so sánh với ConflictRes. Kích thước bộ kiểm tra hiện tại giới hạn độ mạnh của các khẳng định của chúng tôi.

9 Cân nhắc đạo đức

Việc triển khai các hệ thống kiểm tra sự thật tự động liên quan đến các rủi ro đạo đức tiềm ẩn về tính toàn vẹn của thông tin. Không hệ thống tự động nào là không thể sai, và rủi ro phân loại sai vẫn là mối quan tâm chính. Việc gắn nhãn sai một tuyên bố đúng là “Bị bác bỏ” hoặc một tuyên bố sai là “Được hỗ trợ” có thể dẫn đến việc ngăn chặn thông tin chính xác hoặc

sự lan truyền thông tin sai lệch một cách không cố ý. Vì vậy, hiện tại khung CoVer nên được coi như một công cụ hỗ trợ quyết định để duy trì tính toàn vẹn thông tin thay vì là một cơ quan có thẩm quyền.

Về quyền riêng tư dữ liệu, tập dữ liệu ContraNote được lấy từ X Community Notes công khai và được thu thập thông qua API chính thức của X. Chúng tôi nhấn mạnh rằng việc sao chép hoặc sử dụng tiếp có thể được thực hiện thông qua API của X, nhằm tuân theo các điều khoản sử dụng dữ liệu chính thức. Hơn nữa, chúng tôi nhấn mạnh rằng tất cả các nghiên cứu sử dụng các tập dữ liệu như vậy phải tuân thủ các điều khoản dịch vụ của nền tảng và tôn trọng quyền riêng tư cũng như mục đích của các tác giả nội dung gốc.

Tài liệu tham khảo

Jennifer Allen, Antonio A Arechar, Gordon Pennycook và David G Rand. 2021. Mở rộng kiểm chứng sự thật bằng cách sử dụng trí tuệ của đám đông. *Science Advances*, 7(36):eabf4393.

Isabelle Augenstein, Timothy Baldwin, Meeyoung Cha, Tanmoy Chakraborty, Giovanni Luca Ciampaglia, David Corney, Renee DiResta, Emilio Ferrara, Scott Hale, Alon Halevy, Eduard Hovy, Heng Ji, Filippo Menczer, Ruben Míguez, Preslav Nakov, Dietram Scheufele, Shivam Sharma, và Giovanni Zagni. 2024. Những thách thức về tính xác thực trong kỷ nguyên của các mô hình ngôn ngữ lớn và cơ hội cho việc kiểm tra sự thật. *Nat. Mach. Intell.*, 6(8):852–863.

Isabelle Augenstein, Christina Lioma, Dongsheng Wang, Lucas Chaves Lima, Casper Hansen, Christian Hansen, và Jakob Grue Simonsen. 2019. Multifc: Một tập dữ liệu đa miền thực tế cho việc kiểm tra sự thật dựa trên bằng chứng của các tuyên bố. Trong *Kỷ yếu hội nghị năm 2019 về các phương pháp thực nghiệm trong xử lý ngôn ngữ tự nhiên và hội nghị liên hợp quốc tế lần thứ 9 về xử lý ngôn ngữ tự nhiên (EMNLP-IJCNLP)*, trang 4685–4697.

Michiel Bakker, Martin Chadwick, Hannah Sheahan, Michael Tessler, Lucy Campbell-Gillingham, Jan Balaguer, Nat McAleese, Amelia Glaese, John Aslanides, Matt Botvinick và Christopher Summerfield. 2022. Tinh chỉnh các mô hình ngôn ngữ để tìm sự đồng thuận giữa con người với các sở thích đa dạng. Trong *Advances in Neural Information Processing Systems*, tập 35, trang 38176–38189. Curran Associates, Inc.

Jason W Burton, Ezequiel Lopez-Lopez, Shahar Hechtlinger, Zoe Rahwan, Samuel Aeschbach, Michiel A Bakker, Joshua A Becker, Aleks Berditshevskaya, Julian Berger, Levin Brinkmann, Lucie Flek, Stefan M Herzog, Saffron Huang, Sayash Kapoor, Arvind Narayanan, Anne-Marie Nussberger, Taha Yasseri, Pietro Nickl, Abdullah Almaatouq và 9 người khác. 2024. Các mô hình ngôn ngữ lớn có thể tái định hình trí tuệ tập thể như thế nào. *Nat. Hum. Behav.*, 8(9):1643–1655.

Hung-Ting Chen, Michael Zhang, và Eunsol Choi. 2022a. Nguồn tri thức phong phú mang lại xung đột kiến thức phức tạp: Điều chỉnh lại các mô hình để phản ánh bằng chứng mâu thuẫn. Trong Kỷ yếu của Hội nghị 2022 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên, trang 2292–2307.

Jifan Chen, Aniruddh Sriram, Eunsol Choi, và Greg Durrett. 2022b. Tạo các câu hỏi phụ theo nghĩa đen và ngụ ý để kiểm tra tính xác thực của các khẳng định phức tạp. Trong Kỷ yếu Hội nghị về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên 2022, trang 3495–3516.

Shiqi Chen, Yiran Zhao, Jinghan Zhang, I-Chun Chern, Siyang Gao, Pengfei Liu, và Junxian He. 2023. Felm: Đánh giá chuẩn về tính xác thực của các mô hình ngôn ngữ lớn. Trong *Advances in Neural Information Processing Systems*, tập 36, trang 44502–44523. Curran Associates, Inc.

I-Chun Chern, Steffi Chern, Shiqi Chen, Weizhe Yuan, Kehua Feng, Chunting Zhou, Junxian He, Graham Neubig và Pengfei Liu. 2023. Factool: Phát hiện tính thực tế trong AI tạo sinh - một khung công cụ tăng cường cho nhiều nhiệm vụ và nhiều miền.

Eun Cheol Choi và Emilio Ferrara. 2024. Tự động so khớp tuyên bố với các mô hình ngôn ngữ lớn: Trao quyền cho các nhà kiểm chứng sự thật trong cuộc chiến chống lại thông tin sai lệch. Trong Kỷ yếu Phụ trợ hội nghị Web ACM 2024, trang 1441–1449.

Yuwei Chuai, Gabriele Lenzini, và Nicolas Pröllochs. 2026a. Ổn định đồng thuận của các ghi chú cộng đồng trên X. Trong Kỷ yếu Hội nghị Web ACM 2026, trang 8885–8896.

Yuwei Chuai, Moritz Pilarski, Thomas Renault, David Restrepo-Amariles, Aurore Troussel-Clément, Gabriele Lenzini, và Nicolas Pröllochs. 2026b. Kiểm tra sự thật dựa trên cộng đồng giảm sự lan truyền của các bài đăng gây hiểu nhầm trên X (trước đây là Twitter). *Nature Communications*, 17(1):4070.

Yuwei Chuai, Haoye Tian, Nicolas Pröllochs, và Gabriele Lenzini. 2024. Việc triển khai các ghi chú cộng đồng có làm giảm sự tương tác với thông tin sai lệch trên x/twitter không? Kỷ yếu của ACM về Tương tác Người-Máy tính, 8(CSCW2):1–52.

Yuwei Chuai, Jichang Zhao, Nicolas Pröllochs, và Gabriele Lenzini. 2025. Việc kiểm chứng sự kiện có tung lập về chính trị không? Sự bất đối xứng trong cách các tổ chức kiểm chứng sự kiện ở Mỹ phát hiện các phát biểu sai lệch liên quan đến các nhân vật chính trị cấp cao. Trong Kỷ yếu Hội nghị AAAI Quốc tế về Web và Mạng xã hội, tập 19, trang 403–429.

Soham De, Michiel A. Bakker, Jay Baxter, và Martin Saveski. 2025. Supernotes: Thúc đẩy sự đồng thuận trong kiểm tra thực tế dựa vào đám đông. Trong Kỷ yếu Hội nghị Web ACM 2025, trang 3751–3761.

Ziv Epstein, Gordon Pennycook và David Rand. 2020. Liệu đám đông có thao túng thuật toán? Sử dụng đánh giá của người không chuyên để chống lại thông tin sai lệch trên mạng xã hội

bằng cách hạ thứ hạng các nguồn không đáng tin cậy. Trong Kỷ yếu Hội nghị CHI 2020 về các Yếu tố Con người trong Hệ thống Máy tính, trang 1–11. Sara Fish, Paul Gözl, David C Parkes, Ariel D Procaccia, Gili Rusak, Itai Shapira, và Manuel Wüthrich. 2024. Lựa chọn xã hội sinh sinh. Trong Kỷ yếu Hội nghị lần thứ 25 của ACM về Kinh tế và Tính toán, trang 985–985. Ziyu Ge, Yuhao Wu, Daniel Wai Kit Chin, Roy Ka-Wei Lee, và Rui Cao. 2025. Giải quyết bằng chứng mâu thuẫn trong kiểm chứng sự thật tự động: Một nghiên cứu về mô hình ngôn ngữ lớn hỗ trợ truy xuất. arXiv preprint arXiv:2505.17762.

Bing He, Mustaque Ahamad, và Srijan Kumar. 2023. Tạo phản hồi chống sai lệch thông tin dựa trên học tăng cường: Một nghiên cứu trường hợp về thông tin sai lệch về vaccine covid-19. Trong Kỷ yếu Hội nghị Web ACM 2023, trang 2698–2709.

Cheng Jiayang, Chunkit Chan, Qianqian Zhuang, Lin Qiu, Tianhang Zhang, Tengxiao Liu, Yangqiu Song, Yue Zhang, Pengfei Liu, và Zheng Zhang. 2024. Econ: Về việc phát hiện và giải quyết xung đột bằng chứng. Trong Kỷ yếu Hội nghị Năm 2024 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên, trang 7816–7844.

Hyunuk Kim và Dylan Walker. 2020. Tận dụng kiểm tra sự thật tình nguyện để xác định thông tin sai lệch về covid-19 trên mạng xã hội. *Harvard Kennedy School Misinformation Review*, 1(3).

Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, Sebastian Riedel, và Douwe Kiela. 2020. Tăng cường truy xuất dữ liệu cho các tác vụ NLP đòi hỏi nhiều kiến thức. Trong *Advances in Neural Information Processing Systems*, tập 33, trang 9459–9474. Curran Associates, Inc.

Yaliang Li, Jing Gao, Chuishi Meng, Qi Li, Lu Su, Bo Z hao, Wei Fan, và Jiawei Han. 2016. Một khảo sát về khám phá sự thật. *Thư tin ACM Sigkdd Explorations*, 17(2):1–16.

Shanshan Lyu, Wentao Ouyang, Huawei Shen, và Xueqi Cheng. 2017. Khám phá sự thật bằng cách nhúng tuyên bố và nguồn. Trong Kỷ yếu Hội nghị ACM 2017 về Quản lý Thông tin và Kiến thức, trang 2183–2186.

Nicholas Micallef, Bing He, Srijan Kumar, Mustaque Ahamad, và Nasir Memon. 2020. Vai trò của đám đông trong việc chống lại thông tin sai lệch: Một nghiên cứu tình huống về dịch tin tức sai lệch covid-19. Trong Hội nghị Quốc tế IEEE về Dữ liệu Lớn 2020 (big data), trang 748–757. IEEE.

Sewon Min, Kalpesh Krishna, Xinxi Lyu, Mike Lewis, Wen-tau Yih, Pang Koh, Mohit Iyyer, Luke Zettlemoyer, và Hannaneh Hajishirzi. 2023. Factscore: Đánh giá chi tiết cấp nguyên tử về độ chính xác của các sự kiện

trong việc tạo văn bản dài. Trong Kỷ yếu Hội nghị Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên 2023, các trang 12076–12100.

Yifei Ming, Senthil Purushwalkam, Shrey Pandit, Zixuan Ke, Xuan-Phi Nguyen, Caiming Xiong, và Shafiq Joty. 2024. Faitheval: Liều mô hình ngôn ngữ của bạn có thể giữ trung thực với ngữ cảnh, ngay cả khi “mặt trắng được làm từ kẹo dẻo”? Trong Hội nghị Quốc tế lần thứ mười ba về Học đại diện.

Atahan Özer và Çağatay Yıldız. 2025. Trả lời câu hỏi dưới xung đột thời gian: Đánh giá và tổ chức kiến thức đang phát triển với các mô hình ngôn ngữ lớn. Bản thảo arXiv arXiv:2506.07270.

Gordon Pennycook và David G Rand. 2019. Chống lại thông tin sai lệch trên mạng xã hội bằng cách sử dụng đánh giá từ cộng đồng về chất lượng nguồn tin. Kỷ yếu của Viện Hàn lâm Khoa học Quốc gia, 116(7):2521–2526.

Kashyap Papat, Subhabrata Mukherjee, Andrew Yates, và Gerhard Weikum. 2018. Declare: Vạch trần tin giả và những tuyên bố sai bằng cách sử dụng học sâu nhận thức bằng chứng. Trong Kỷ yếu của Hội nghị năm 2018 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên, trang 22–32.

Peng Qi, Zehong Yan, Wynne Hsu, và Mong Li Lee. 2024. Sniffer: Mô hình ngôn ngữ lớn đa phương thức cho phát hiện thông tin sai lệch ngoài ngữ cảnh có thể giải thích. Trong Kỷ yếu Hội nghị IEEE/CVF về Thị giác Máy tính và Nhận dạng Mẫu, trang 13052–13062.

Dorian Quelle và Alexandre Bovet. 2024. Những hiểm họa và hứa hẹn của việc kiểm chứng thông tin với các mô hình ngôn ngữ lớn. *Frontiers in Artificial Intelligence*, 7:1341697.

Michael Schlichtkrull, Zhijiang Guo, và Andreas Vlachos. 2023. Averitec: Một bộ dữ liệu cho việc xác minh tuyên bố trong thế giới thực với bằng chứng từ web. *Advances in Neural Information Processing Systems*, 36:65128–65167.

Jeremy Straub và Matthew Spradling. 2022. Quan điểm của người Mỹ về nhãn cảnh báo trên phương tiện trực tuyến. *Khoa học Hành vi*, 12(3):59.

Zhaochen Su, Jun Zhang, Xiaoye Qu, Tong Zhu, Yanshu Li, Jiashuo Sun, Juntao Li, Min Zhang, và Yu Cheng. 2024. Conflictbank: Một chuẩn mực để đánh giá xung đột kiến thức trong các mô hình ngôn ngữ lớn. Trong Kỷ yếu Hội nghị Quốc tế lần thứ 38 về Hệ thống Xử lý Thông tin Thần kinh, các trang 103242–103268.

Hexiang Tan, Fei Sun, Wanli Yang, Yuanzhuo Wang, Qi Cao, và Xueqi Cheng. 2024. Bị mù trước các ngữ cảnh được tạo ra: Các mô hình ngôn ngữ kết hợp ngữ cảnh được tạo ra và được truy xuất như thế nào khi kiến thức mâu thuẫn? Trong Kỷ yếu Hội nghị thường niên lần thứ 62 của Hiệp hội Ngôn ngữ học Máy tính (Tập 1: Bài báo dài), các trang 6207–6227.

James Thorne, Andreas Vlachos, Christos Christodoulopoulos, và Arpit Mittal. 2018. Fever: Một tập dữ liệu quy mô lớn cho việc trích xuất và xác minh thông tin. Trong Kỷ yếu Hội nghị 2018 của Chương Bắc Mỹ thuộc Hiệp hội Ngôn ngữ học Máy tính: Công nghệ Ngôn ngữ Con người, Tập 1 (Bài báo dài), trang 809–819.

Alexander Wan, Eric Wallace, và Dan Klein. 2024. Ngôn ngữ mô hình tìm thấy bằng chứng nào thuyết phục? Trong Kỷ yếu của Hội nghị thường niên lần thứ 62 của Hiệp hội Ngôn ngữ học Máy tính (Tập 1: Bài báo dài), trang 7468–7484.

HanWang, ArchikiPrasad, EliasStengel-Eskin, và Mohit Bansal. 2025. Tạo sinh tăng cường truy xuất với bằng chứng mâu thuẫn. arXiv preprint arXiv:2504.13079.

Haoran Wang và Kai Shu. 2023. Xác minh tuyên bố có thể giải thích thông qua lập luận dựa trên tri thức với các mô hình ngôn ngữ lớn. Trong Kết quả của Hiệp hội Ngôn ngữ Học Máy tính: EMNLP 2023, trang 6288–6304.

Yuxia Wang, Revanth Gangi Reddy, Zain Muhammad Mujahid, Arnav Arora, Aleksandr Rubashevskii, Ji-ahui Geng, Osama Mohammed Afzal, Liangming Pan, Nadav Borenstein, Aditya Pillai, Isabelle Augenstein, Iryna Gurevych, và Preslav Nakov. 2024. Factcheck-bench: Bộ đánh giá chi tiết cho các công cụ kiểm tra sự thật tự động. Trong Kết quả của Hiệp hội Ngôn ngữ học Máy tính: EMNLP 2024, trang 14199–14230, Miami, Florida, USA. Hiệp hội Ngôn ngữ học Máy tính.

X Corp. 2025. Hướng dẫn ghi chú cộng đồng: Tải dữ liệu. <https://communitynotes.x.com/guide/en/under-the-hood/download-data>. [Truy cập: 2026-02-09].

X Corp. 2026. Về các ghi chú cộng đồng trên x. <https://help.x.com/en/using-x/community-notes>. [Truy cập: 2026-02-09].

Jian Xie, Kai Zhang, Jiangjie Chen, Renze Lou, và Yu Su. 2023. Tắc kè thích nghi hay lừa dối biếng lười: Tiết lộ hành vi của các mô hình ngôn ngữ lớn trong xung đột kiến thức. Trong Hội nghị Quốc tế lần thứ mười hai về Biểu diễn Học tập.

Zhuohan Xie, Rui Xing, Yuxia Wang, Jiahui Geng, Hasan Iqbal, Dhruv Sahnan, Iryna Gurevych, và Preslav Nakov. 2025. Fire: Kiểm chứng sự thật với truy xuất và xác minh lặp đi lặp lại. Trong Kết quả của Hiệp hội Ngôn ngữ học Máy tính: NAACL 2025, trang 2901–2914.

Joshua C Yang, Damian Dalisan, Marcin Korecki, Carina I Hausladen, và Dirk Helbing. 2024. Bộ phiếu LLM: Lựa chọn của con người và quyết định tập thể của AI. Trong Kỷ yếu Hội nghị AAAI/ACM về AI, Đạo đức và Xã hội, tập 7, trang 1696–1708.

Zhenrui Yue, Huimin Zeng, Yimeng Lu, Lanyu Shang, Yang Zhang và Dong Wang. 2024. Tạo phản hồi tăng cường truy xuất dựa trên bằng chứng cho thông tin sai lệch trực tuyến. Trong Kỷ yếu Hội nghị 2024 của Chi nhánh Bắc Mỹ Hiệp hội Ngôn ngữ Học Máy Tính: Công nghệ Ngôn ngữ Con người (Tập 1: Bài báo dài), trang 5628–5643.

Fengzhu Zeng và Wei Gao. 2024. Justilm: Tạo lập biện minh theo vài ví dụ cho việc kiểm chứng sự thật có thể giải thích được của các tuyên bố trong thế giới thực. Transactions of the Association for Computational Linguistics, 12:334–354.

Shuning Zhang, Linzhi Wang, Shixuan Li, Yuanyuan Wu, Yuwei Chuai, Luoxi Chen, Xin Yi và Hewu Li. 2026. Collab: Thúc đẩy việc nhận diện quan trọng các video deepfake trên mạng xã hội thông qua chú thích hợp lực. Trong Kỷ yếu Hội nghị CHI 2026 về Các Yếu tố Con người trong Hệ thống Tính toán, trang 1–21.

Xinyi Zhou, Ashish Sharma, Amy X Zhang, và Tim Althoff. 2024. Chỉnh sửa thông tin sai lệch trên mạng xã hội bằng mô hình ngôn ngữ lớn. bản in trước arXiv arXiv:2403.11169.

Một Sử Dụng GenerativeAI

Theo các chính sách sử dụng AI tạo sinh, chúng tôi công khai việc sử dụng các công cụ AI tạo sinh. Chúng tôi đã sử dụng AI tạo sinh làm mô hình cơ sở cho thí nghiệm. Bên cạnh đó, chúng tôi đã sử dụng Google Gemini 3 Pro và ChatGPT (tức GPT-5.2) như các trợ lý viết. Ngoại trừ Hình 3, được chỉnh sửa bởi Gemini Nano Banana, công cụ AI tạo sinh chỉ được sử dụng với mục đích cải thiện chất lượng viết. Các chức năng của nó chỉ giới hạn ở việc hiệu đính, nâng cao ngôn ngữ và độ rõ ràng, rút gọn và lựa chọn từ, và không được dùng để tạo bất kỳ nội dung khoa học cốt lõi nào. Công cụ này được áp dụng để hoàn thiện bản thảo cuối cùng, sau khi nội dung của từng phần đã được các tác giả hoàn thành.

Chi tiết bộ dữ liệu B

B.1 So sánh các tập dữ liệu

Bảng 4 chứa các so sánh của các bộ dữ liệu, trong đó NEI nghĩa là Không đủ thông tin.

B.2 Phân Tích Bộ Dữ Liệu

Như được trình bày trong Hình 2, chúng tôi cung cấp một phân tích về bộ dữ liệu ContraNote. Những lý do chính để gắn cờ các tuyên bố là gây hiểu lầm bao gồm thiếu bối cảnh quan trọng (22.615 trường hợp) và sai sự thật (20.918 trường hợp). Các loại khác bao gồm các tuyên bố chưa được xác minh được trình bày như sự thật (13.087 trường hợp), thông tin lỗi thời (9.508 trường hợp),

châm biếm (5.381 trường hợp), truyền thông bị t hao túng (5.124 trường hợp) và các lý do khác (6.461 trường hợp). Phân tích thống kê cho thấy các ghi chú phản bác thường chi tiết hơn các ghi chú ủng hộ. Cụ thể, ghi chú phản bác trung bình 1,77 ghi chú mỗi bài đăng và dài 289,08 ký tự, trong khi ghi chú ủng hộ trung bình 1,61 ghi chú mỗi bài đăng và dài 163,64 ký tự.

Chúng tôi đã nhóm các liên kết bằng chứng được trích dẫn trong ContraNote thành sáu loại nguồn. Các trang web và trang tin tức chiếm 49,1% các liên kết, tiếp theo là các nền tảng mạng xã hội và video (24,6%), Wikipedia (8,6%), các nguồn chính phủ hoặc nguồn chính thức khác (7,9%), các trang web kiểm tra sự thật chuyên dụng (7,3%), và các nguồn khác (2,5%). Kết quả cho thấy ContraNote không bị chi phối bởi các đoạn trích khoa ngắn. Một phần lớn bằng chứng của nó đến từ các nguồn đa dạng, có bối cảnh xã hội mà quyền hạn và xuất xứ cần được đánh giá.

Hai nhà nghiên cứu đã kiểm tra thủ công mối quan hệ ngữ nghĩa giữa một bài đăng, ghi chú một cách chỉnh sửa mạnh nhất của nó và ghi chú cạnh tranh. Mẫu phổ biến nhất là bất đồng về tính cần thiết của ghi chú, chiếm 33% các trường hợp được mã hóa thủ công. Trong những trường hợp này, ghi chú cạnh tranh không nhất thiết xác nhận rằng bài đăng là đúng sự thật; thay vào đó, nó lập luận rằng không cần Ghi chú Cộng đồng vì bài đăng là châm biếm, ý kiến hoặc vấn đề chính sách của nền tảng. Phân tích cũng xác định bất đồng về thẩm quyền chứng cứ, trong đó các ghi chú dựa vào các nguồn có thẩm quyền khác nhau; sự không khớp về phạm vi hoặc định nghĩa, trong đó cùng một tuyên bố được đánh giá theo các phạm vi thời gian hoặc định nghĩa khác nhau; và xung đột về gán thực thể/sự kiện, trong đó bằng chứng được gán cho một người, sự kiện hoặc nguồn gốc khác. Ví dụ, bằng chứng có thể hỗ trợ một tuyên bố về chính sách lịch sử nhưng không hỗ trợ cùng tuyên bố khi áp dụng cho chính sách hiện tại. Những danh mục này cho thấy ContraNote chứa

Hơn nữa, chúng tôi đã phân tích phân bố ngôn ngữ của các bài đăng có văn bản được truy xuất thành công. Trong số các bài đăng này, 13.776 bài bằng tiếng Anh, chiếm 62,98%; 1.758 bài bằng tiếng Tây Ban Nha, chiếm 8,04%; và 1.368 bài bằng tiếng Bồ Đào Nha, chiếm 6,25%. Các bài đăng khác được viết bằng tiếng Pháp, tiếng Nhật, tiếng Đức, tiếng Trung Quốc và các ngôn ngữ khác.

Như so sánh trong Bảng 4, ContraNote mở rộng MultiFC (Augenstein và cộng sự, 2019), AVeriTeC (Schlichtkrull và cộng sự, 2023), và

Bộ dữ liệu	Miền nguồn	Loại yêu cầu	Loại bằng chứng	Đa dạng nguồn	Bằng chứng rõ ràng xung đột	Yêu cầu phụ sự phản hồi	Ưu tiên bằng chứng nhân	Mạng xã hội nguồn gốc	Cấp độ yêu cầu nhân
SỐT	Wikipedia	Sự thật nhỏ	Các câu trên Wikipedia	No	No	No	No	No	Được hỗ trợ / Bị phản bác / Không kết luận được
MultiFC	Trang web kiểm chứng sự thật	Các tuyên bố trong thế giới thực	Tài liệu web không đồng nhất	Yes	No	No	No	Một phần	Tính xác thực ở mức từng tuyên bố
AVeriTeC	Các nguồn web và kiểm chứng sự thật	Các yêu cầu phức tạp	Bằng chứng web đã được truy xuất	Yes	No	No	No	Một phần	Được hỗ trợ / Bị phản bác
Phân tách yêu cầu	Kiểm chứng sự thật trên web	Wikipedia	Bằng chứng liên quan đến yêu cầu	Yes	No	Yes	No	Một phần	Tính xác thực ở cấp độ tuyên bố và phụ tuyên bố
WikiTrái-Ngược	Wikipedia	Những tuyên bố mâu thuẫn	Các đoạn văn trên Wikipedia	Giới hạn	Yes	No	No	No	Nhân mẫu thuận
AmbiFC	Kiểm chứng sự thật trong thế giới thực	Những tuyên bố mơ hồ	Bằng chứng liên quan đến yêu cầu	Yes	Một phần	Một phần	No	Một phần	Mơ hồ / không mơ hồ
Xung đột ContraNote	Ghi chú Cộng đồng X	Những tuyên bố trên mạng xã hội	Nhiều ghi chú do người dùng tạo	Yes	Yes	Yes	No	Yes	Được hỗ trợ / Bị phản bác
Ưu tiên ContraNote	Ghi chú Cộng đồng X	Những tuyên bố trên mạng xã hội	Ghi chú của ứng viên cạnh tranh	Yes	Yes	Yes	Yes	Yes	Ghi chú được hỗ trợ / Ghi chú bị bác bỏ mục tiêu

Bảng 4: So sánh ContraNote với các bộ dữ liệu kiểm chứng sự thật tiêu biểu. ContraNote Conflict cung cấp nhãn xác minh ở cấp độ tuyên bố, trong khi ContraNote Prioritization bổ sung nhãn xác định mục bằng chứng cạnh tranh nào nên được ưu tiên.

ClaimDecomp (Chen et al., 2022b), đã đưa bằng chứng đối chiếu từ thế giới thực vào việc kiểm tra sự thật. ContraNote đặc biệt chú thích các xung đột bằng chứng tự nhiên xảy ra trong cùng một bài đăng, và phân tách hai hình thức xung đột (tức là mức bằng chứng và mức tổng hợp).

Để đánh giá độ tin cậy của các nhãn được tạo tự động, chúng tôi đã lấy mẫu ngẫu nhiên 500 trường hợp từ ContraNote và tuyển ba người chú thích đã được đào tạo. Họ đánh giá độc lập tính xác thực của từng bài đăng dựa trên nội dung bài đăng, các ghi chú liên quan và bằng chứng được trích dẫn, đạt được sự đồng thuận đáng kể giữa các người chú thích (Fleiss’ $\kappa = 0.82$). Các nhãn của con người theo phiếu đa số đồng ý với các nhãn của ContraNote ở 94,2% các trường hợp. Điều này xác nhận độ chính xác của các nhãn.

Vì những cộng tác viên của Community Notes có thể không đại diện cho tất cả các nhóm nhân khẩu học, ContraNote có thể có sự thiên lệch về dân số và ý thức hệ. Chúng tôi đặc trưng quan điểm và phân bố chủ đề của nó. Sử dụng PoliticalBiasBERT, chúng tôi phân loại các ghi chú thành các loại trái, trung tâm và phải, với tỉ lệ lần lượt là 18,6%, 47,0% và 34,4%. Trên tập con được chú thích bởi con người, phân bố chủ đề là chính trị/quản trị (26,0%), y tế/thuốc (4,0%), khoa học/công nghệ (20,6%), truyền thông/giải trí/thể thao (29,8%), kinh tế/tài chính (5,8%), an toàn công cộng/tội phạm (6,8%) và khác/chung (10,4%). Các chú thích chủ đề bởi ba người chú thích đạt Fleiss’ $\kappa = 0.84$. Điều này cho thấy rằng ContraNote phản ánh tín hiệu đồng thuận được tạo ra bởi cơ chế Community Notes.

Đánh giá mở rộng C

C.1 Kết quả theo lớp cho các điều kiện cơ bản

Chúng tôi đã báo cáo kết quả theo từng lớp cho các điều kiện cơ sở trong Bảng 5 và Bảng 6. Bảng 5 cho thấy hiệu suất trên lớp được hỗ trợ, trong khi Bảng 6 cho thấy hiệu suất trên lớp bị bác bỏ.

C.2 Kết quả bổ sung trên các đường cơ sở

Chúng tôi cũng đánh giá ClaimDecomp, MADAM-RAG, và một nền tảng kiểm chứng kiểu AVeriTeC trong Bảng 7. ClaimDecomp đạt điểm mac. F1 lần lượt là 67,28, 76,21, 54,29 và 65,58 trên CONFACT-HumC, CONFACT-ModC, ContraNote Conflict và ContraNote Prioritization. MADAM-RAG đạt 47,70 và 70,30 trên hai đánh giá chuẩn ContraNote, trong khi nền tảng kiểu AVeriTeC đạt 65,60 và 80,50. Những kết quả này cung cấp các so sánh bổ sung với các phương pháp được thiết kế cho phân tích chi tiết tuyên bố, kiểm chứng tăng cường truy xuất và giải quyết xung đột.

Trên các bộ dữ liệu bổ sung, CoVer đạt điểm F1 trung bình (mac. F1) lần lượt là 92,60 trên AVeriTeC, 84,00 trên WikiContradict và 92,20 trên AmbiFC. Các thí nghiệm này chỉ ra rằng khung phương pháp này có thể áp dụng ngoài ContraNote, mặc dù các bộ dữ liệu khác nhau về cách đặt bài toán và cấu trúc bằng chứng.

C.3 Đường cơ sở gọi nhiều lần

Bảng 8 báo cáo các đường cơ sở lỗi tắt và đa cuộc gọi. Đường cơ sở lỗi tắt metadata đạt 81,5% độ chính xác trên ContraNote Conflict, nhưng chỉ đạt 44,9 macro-F1 và 50,0 độ chính xác cân bằng. Độ chính xác cao của nó là nhờ sự mất cân bằng lớp mạnh chứ không phải do kiểm chứng đáng tin cậy. Trên ContraNote Prioritization, cùng một quy tắc đạt 50,0% độ chính xác, 33,3 macro-F1 và 50,0 độ chính xác cân bằng, gần như giống với may rủi. Do đó, điểm chuẩn không thể được giải quyết đầy đủ chỉ bằng quy tắc metadata.

Đối với kiểm soát cuộc gọi được khớp, chúng tôi sử dụng bằng chứng cố định cho tất cả bốn cơ sở trong mỗi nhiệm vụ. Chúng tôi tổng hợp các dự đoán bằng cách bỏ phiếu đa số, giải quyết các trường hợp hòa bằng cách cho 1 à Bị bác bỏ, với kết quả được trình bày trong Bảng 8.

C.4 Xác minh ba chiều

Để kiểm tra xem CoVer có thể đại diện cho độ chính xác một phần hay không, chúng tôi xây dựng một thiết lập ba chiều với các nhãn Hỗ trợ, Hỗ trợ một phần và Bị bác bỏ. Một trường hợp được gán nhãn Hỗ trợ một phần

Phương pháp	CONFACT HumC	CONFACT ModC	Ngân hàng Xung đột	ECON	SỐT	Ghi chú đối lập Xung đột	Ghi chú đối lập Ưu tiên
FacTool	38.5 29.4 33.3	57.6 45.2 50.7	31.9 39.7 35.4	71.1 58.7 64.3	90.7 29.3 44.3	34.7 71.4 46.7	56.6 63.8 60.0
KiểmTraSỰThậtGPT	54.2 38.2 44.8	54.5 42.9 48.0	38.8 44.8 41.6	68.0 55.4 61.1	97.1 74.4 84.3	31.5 48.6 38.2	52.2 64.5 57.7
FIRE	30.0 17.6 22.2	48.6 42.9 45.6	27.1 32.8 29.7	62.2 50.0 55.4	93.3 62.4 74.8	34.4 62.9 44.4	64.6 54.3 59.0
Liên hệ	34.8 47.1 40.0	53.6 71.4 61.2	37.0 51.7 43.2	68.9 79.3 73.7	88.5 92.5 90.4	51.1 65.7 57.5	59.4 64.5 61.9
Xung đột	44.4 35.3 39.3	47.1 57.1 51.6	19.6 15.5 17.3	68.4 58.7 63.2	88.0 71.4 78.8	47.6 57.1 51.9	62.3 45.7 52.8

Bảng 5: Hiệu suất chi tiết so sánh các kỹ thuật khác nhau, trên lớp Supported. Các chỉ số được định dạng dưới dạng Precision | Recall |F1-score.

Phương pháp	CONFACT HumC	CONFACT ModC	Ngân hàng Xung đột	ECON	SỐT	Ghi chú đối lập Xung đột	Ghi chú đối lập Ưu tiên
FacTool	86.2 90.4 88.2	86.2 91.1 88.6	72.4 65.2 68.7	69.4 79.6 74.1	40.1 94.0 56.3	92.0 71.0 80.1	63.4 56.2 59.6
KiểmTraSỰThậtGPT	88.1 93.4 90.6	85.6 90.5 88.0	75.9 71.1 73.5	67.2 77.8 72.1	65.3 95.5 77.6	87.5 77.3 82.1	60.7 48.1 53.7
FIRE	84.4 91.6 87.9	85.2 87.9 86.5	69.8 63.8 66.7	63.5 74.1 68.4	55.0 91.0 68.5	90.3 74.2 81.5	64.5 73.6 68.7
Liên hệ	88.2 81.8 84.9	91.5 83.3 87.2	76.5 64.1 69.7	79.8 69.4 74.3	83.6 76.1 79.7	92.2 86.5 89.2	66.3 61.3 63.7
Xung đột	87.3 91.0 89.1	87.9 82.9 85.3	68.2 73.9 70.9	68.6 76.9 72.5	58.7 80.6 67.9	90.4 86.5 88.4	61.1 75.5 67.5

Bảng 6: Hiệu quả chi tiết so sánh các kỹ thuật khác nhau, trên lớp Bị bác bỏ. Các chỉ số được định dạng là Độ chính xác | Nhớ |Điểm F1.

Phương pháp	CONFACT HumC	CONFACT ModC	Ghi chú đối lập Xung đột	Ghi chú đối lập Ưu tiên
BÀ-TẾ	65.0	68.0	47.70	70.30
Phong cách AVeriTeC	65.8	77.4	65.60	80.50
Phân tách yêu cầu	67.28	76.21	54.29	65.58
Bìa	77.10	83.10	68.00	88.50

Bảng 7: So sánh cơ sở bổ sung sử dụng mac. F1 (%). Kết quả theo kiểu AVeriTeC và MADAM-RAG được báo cáo cho các chuẩn mực ContraNote, trong khi ClaimDecomp còn được đánh giá thêm trên CONFACT. Dấu gạch ngang biểu thị rằng kết quả tương ứng không được báo cáo.

Phương pháp	Độ chính xác	Mac. F1	Số dư TK
<i>Xung đột ContraNote</i>			
Hữu ích+gây hiểu lầm	81.5	44.9	50.0
Bìa	86.0	68.0	64.5
KiểmTraSỰThậtGPT	83.0	63.6	61.4
CONFACT	85.5	69.4	66.0
FIRE	85.5	67.4	63.9
FacTool	84.0	67.7	65.1
<i>Ưu tiên ContraNote</i>			
Hữu ích+gây hiểu lầm	50.0	33.3	50.0
Bìa	88.5	88.5	89.2
KiểmTraSỰThậtGPT	69.5	68.9	69.5
CONFACT	63.5	61.2	63.5
FIRE	61.0	58.4	61.0
FacTool	78.0	77.9	78.0

Bảng 8: Kiểm soát đường tắt và ngân sách suy luận trên Con-traNote. Quy tắc đường tắt chỉ dự đoán là Bị phản bác nếu và chỉ nếu một ghi chú ứng viên vừa hữu ích vừa gây hiểu lầm.

khi các tuyên bố phụ của nó chứa cả các thành phần được hỗ trợ và không được hỗ trợ hoặc bị bác bỏ. Trong bối cảnh này, CoVer đạt độ chính xác 80,6% và F1 trung bình 68,0, so với F1 trung bình 66,5 của điểm cơ sở mạnh nhất. Thử nghiệm thử nghiệm này cho thấy khung có thể được mở rộng vượt ra ngoài công thức nhị phân được sử dụng bởi nhiệm vụ ContraNote chính.

C.5 Tính xác thực của các lý do được tạo ra

Chúng tôi đánh giá tính xác thực của các lý giải được tạo ra bằng cách sử dụng một quy trình theo kiểu FActScore được điều chỉnh. Các khẳng định nguyên tử trong các lý giải được kiểm tra đối chiếu với Community Notes và các bằng chứng liên quan. Chúng tôi ghi chú thủ công 100 trường hợp và sử dụng các ghi chú này để xác thực quy trình tự động. GPT-5.5 đồng ý với các ghi chú của con người trong 97% các trường hợp. Dưới hình thức ghi chú tự động, CoVer đạt tỷ lệ hỗ trợ 85,2% trên ContraNote Conflict và 82,3% trên ContraNote Prioritization, so với 76,9% và 72,6% của các phương pháp cơ sở cạnh tranh mạnh nhất, tương ứng.

D Phân tích Ablation và Độ nhạy

D.1 Kết quả theo lớp cho Nghiên cứu Loại bỏ

Chúng tôi đã báo cáo kết quả theo từng lớp cho nghiên cứu loại bỏ trong Bảng 9 và Bảng 10. Lưu ý rằng Bảng 9 chứa hiệu suất chi tiết cho lớp được hỗ trợ, trong khi Bảng 10 chứa hiệu suất chi tiết cho lớp bị bác bỏ.

D.2 Độ nhạy với Trọng số Chất lượng

Chúng tôi đánh giá độ nhạy của CoVer đối với vector trọng số chất lượng $\lambda = (\lambda_d, \lambda_a, \lambda_l, \lambda_u)$, tương ứng với tính trực tiếp, sự phù hợp thuộc tính, độ tin cậy của sơ đồ, và tính hữu ích thông tin. Mỗi trọng số được thay đổi trong khoảng $\{0, 0.05, 0.10, \dots, 1.0\}$ dưới điều kiện $\lambda_d + \lambda_a + \lambda_l + \lambda_u = 1$. Cấu hình đồng đều $\lambda_{\text{uni}} = (0.25, 0.25, 0.25, 0.25)$ được cố định trước khi đánh giá và không được điều chỉnh trên bất kỳ tập kiểm tra nào; chúng tôi so sánh nó với các cấu hình hoạt động tốt nhất và kém nhất được xác định trên tập phát triển. Tất cả các giá trị báo cáo là điểm F1 trung bình (mac. F1) trung bình trên năm lần chạy. Trên các tập dữ liệu được đánh giá, mac. F1 dao động trong khoảng 1,3 điểm phần trăm, cho thấy CoVer không phụ thuộc vào một cấu hình trọng số được tinh chỉnh hẹp.

D.3 Độ nhạy khi hòa điểm

Chúng tôi so sánh quy tắc Refute-mặc định chính trong Phương trình 4 với một biến thể Support-mặc định. Thay đổi mặc định khi hòa làm giảm hiệu suất 2,15 điểm phần trăm trên ContraNotePrioritization nhưng lại cải thiện 4,19 điểm phần trăm trên CONFACT-HumC. Do đó, tác động của quy tắc giải quyết hòa phụ thuộc vào tập dữ liệu thay vì có lợi một cách đồng đều.

D.4 Thí nghiệm loại bỏ ràng buộc đầu ra có cấu trúc

Cuộc gọi đồng thuận thực tế thường yêu cầu một bản ghi có cấu trúc đầy đủ chứa quan điểm từ tập nhân hợp lệ và bốn điểm chất lượng giới hạn trong $[0, 1]$. Chúng tôi loại bỏ các ràng buộc hợp lệ này trong khi giữ nguyên mô hình nền tảng, bằng chứng và quy tắc quyết định hạ nguồn; các kết quả đầu ra tự do được phân tích thành các trường trung gian giống nhau bất cứ khi nào có thể. Việc loại bỏ các ràng buộc đầu ra có cấu trúc làm giảm độ chính xác 1,57 điểm phần trăm so với cấu hình bị ràng buộc. Do đó, các ràng buộc cải thiện tính ổn định của các quyết định trung gian, nhưng sự thay đổi khiêm tốn cho thấy hiệu suất của CoVer không được giải thích chỉ bằng cách định dạng đầu ra.

E Hiệu suất và Phân tích lỗi

E.1 So sánh Kiểm soát Ngân sách Suy luận

Bảng 12 cho thấy các so sánh kiểm soát ngân sách suy luận.

E.2 Phân Tích Lỗi

Chúng tôi kiểm tra định tính các dự đoán sai của CoVer để xác định các chế độ thất bại lặp lại. Phân tích cho thấy ba loại chính.

Mơ hồ về thời gian. Một số câu khẳng định và ghi chú đề cập đến các giai đoạn khác nhau của một sự kiện đang diễn ra hoặc bỏ qua khung thời gian liên quan. Trong những trường hợp như vậy, bằng chứng đúng tại một thời điểm có thể mâu thuẫn với một bản cập nhật sau đó, và mô hình có thể chọn một cách diễn giải lỗi thời hoặc không giới hạn phán quyết trong khoảng thời gian mà câu khẳng định đề cập.

Bằng chứng đòi hỏi chuyên môn trong lĩnh vực. Một số trường hợp phụ thuộc vào kiến thức pháp lý, y tế, khoa học hoặc chính sách chuyên biệt mà không được nêu rõ trong bằng chứng cung cấp. CoVer có thể xác định các quan điểm đối lập nhưng có thể đánh giá quá cao một giải thích trôi chảy khi việc giải quyết sự khác biệt kỹ thuật đòi hỏi sự giải thích của chuyên gia.

Sự kiện thật với một hàm ý không được hỗ trợ. Một tuyên bố có thể đề cập đến một sự kiện thực sự và sau đó gắn một hàm ý nguyên nhân, cố ý, hoặc tổng quát không được hỗ trợ. Mô hình đôi khi coi bằng chứng cho sự kiện cơ bản là sự hỗ trợ cho toàn bộ tuyên bố, ngay cả khi hàm ý không được suy ra. Chế độ thất bại này thúc đẩy giai đoạn xác minh hỗ trợ thận trọng, nhưng những trường hợp khó vẫn còn khi các thành phần thực tế và hàm ý được gắn chặt với nhau.

Những lỗi này gợi ý ba hướng cải tiến tương ứng: chuẩn hóa thời gian một cách rõ ràng, chuyển các trường hợp chuyên biệt đến bằng chứng hoặc chuyên gia am hiểu lĩnh vực, và phân tách chi tiết hơn các sự kiện từ các hàm ý nhân quả hoặc có chủ đích. Phân tích này mang tính định tính; chúng tôi không gán tỉ lệ phần trăm danh mục vì hồ sơ mã hóa hiện có không chứa bảng tần suất.

Cài đặt	CONFACT HumC	CONFACT ModC	Ngân hàng Xung đột	ECON	SỐT	Ghi chú đối lập Xung đột	Ghi chú đối lập Ưu tiên
Full	72.0 52.9 61.0	77.8 68.3 72.7	56.8 36.2 44.2	73.3 80.4 76.7	98.4 91.6 94.9	73.3 31.4 44.0	80.3 100.0 89.1
không có Sơ đồ	72.0 52.9 61.0	77.8 68.3 72.7	44.4 27.6 34.0	44.7 16.3 23.9	94.5 78.0 85.5	54.5 51.4 52.9	73.5 79.8 76.5
không có sự đồng thuận	53.8 61.8 57.5	53.8 68.3 60.2	41.8 65.5 51.0	73.3 80.4 76.7	95.8 86.5 90.9	43.8 20.0 27.5	9.1 2.1 3.4
không có hỗ trợ	60.7 50.0 54.8	75.0 65.9 70.1	47.6 34.5 40.0	73.3 80.4 76.7	95.8 86.5 90.9	71.4 28.6 40.8	67.0 64.9 65.9
không có Lược đồ +Thỏa thuận	44.4 47.1 45.7	49.0 61.0 54.3	42.2 65.5 51.4	71.0 82.6 76.4	92.9 88.7 90.8	28.3 74.3 40.9	72.9 45.7 56.2
không có Hỗ trợ Schema +	50.0 26.5 34.6	75.0 51.2 60.9	46.7 36.2 40.8	62.2 30.4 40.9	94.2 85.0 89.3	54.5 51.4 52.9	76.2 81.9 79.0
không có sự đồng thuận + Hỗ trợ	53.8 61.8 57.5	53.8 68.3 60.2	41.8 65.5 51.0	73.3 80.4 76.7	95.8 86.5 90.9	53.3 22.9 32.0	4.0 1.1 1.7
không có cả ba	44.4 47.1 45.7	49.0 61.0 54.3	42.2 65.5 51.4	71.0 82.6 76.4	92.9 88.7 90.8	28.7 77.1 41.9	66.7 40.4 50.3

Bảng 9: Hiệu suất chi tiết của nghiên cứu loại bỏ yếu tố, trên lớp Hỗ trợ. Các chỉ số được định dạng theo Precision | Recall | F1-score.

Cài đặt	CONFACT HumC	CONFACT ModC	Ngân hàng Xung đột	ECON	SỐT	Ghi chú đối lập Xung đột	Ghi chú đối lập Ưu tiên
Full	90.8 95.8 93.2	92.0 94.9 93.5	77.3 88.7 82.6	81.8 75.0 78.3	85.5 97.0 90.9	87.0 97.6 92.0	100.0 78.3 87.8
không có Sơ đồ	90.8 95.8 93.2	92.0 94.9 93.5	74.2 85.8 79.6	45.6 77.7 57.5	67.8 91.0 77.7	89.8 90.9 90.4	80.4 74.3 77.2
không có sự đồng thuận	91.9 89.1 90.5	91.0 84.5 87.6	81.5 62.4 70.7	81.8 75.0 78.3	77.5 92.5 84.4	100.0 79.4 88.5	49.1 78.3 60.4
không có hỗ trợ	89.9 93.3 91.6	91.4 94.3 92.8	75.9 84.5 80.0	81.8 75.0 78.3	77.5 92.5 84.4	86.6 97.6 91.7	69.7 71.7 70.7
không có Lược đồ + Thỏa thuận	88.8 87.7 88.2	89.2 83.5 86.3	81.7 63.1 71.2	82.8 71.3 76.6	79.5 86.6 82.9	92.2 57.0 70.4	65.7 61.3 63.4
không có Hỗ trợ Schema +	86.0 94.4 90.0	88.2 95.5 91.7	76.0 83.0 79.3	58.7 84.3 69.2	75.0 89.6 81.6	89.8 90.9 90.4	82.7 77.1 79.8
không có sự đồng thuận + Hỗ trợ	91.9 89.1 90.5	91.0 84.5 87.6	81.5 62.4 70.7	81.8 75.0 78.3	77.5 92.5 84.4	98.6 82.4 89.8	47.9 75.5 58.6
không có cả ba	88.8 87.7 88.2	89.2 83.5 86.3	81.7 63.1 71.2	82.8 71.3 76.6	79.5 86.6 82.9	92.2 57.6 70.9	60.4 58.1 59.2

Bảng 10: Hiệu suất chi tiết của nghiên cứu loại bỏ, trên lớp Bị bác bỏ. Các chỉ số được định dạng dưới dạng Độ chính xác | Độ hồi tưởng | Điểm F1.

Bộ dữ liệu	Đồng phục λ	Best λ	Tệ nhất λ	Best mac. F1	Tệ nhất mac. F1
CONFACT-HumC	0.25,0.25,0.25,0.25 0.25	0.25,0.25,0.25,0.25 0.40	0.30,0.20,0.10	78.0	76.7
CONFACT-ModC	0.25,0.25,0.25,0.25 0.25	0.25,0.25,0.25 0.10	0.20,0.30,0.40	84.0	82.7
Ngân hàng Xung đột	0.25,0.25,0.25,0.25 0.25	0.25,0.25,0.25 0.40	0.30,0.20,0.10	64.3	63.0
ECON	0.25,0.25,0.25,0.25 0.25	0.25,0.25,0.25 0.10	0.20,0.30,0.40	78.4	77.1
SỐT	0.25,0.25,0.25,0.25 0.25	0.25,0.25,0.25 0.40	0.30,0.20,0.10	93.8	92.5
ContraNote-Xung đột	0.25,0.25,0.25,0.25 0.25	0.25,0.25,0.25 0.10	0.20,0.30,0.40	68.9	67.6
ContraNote-Ưu tiên 0,25	0.25,0.25,0.25,0.25 0.25	0.25,0.25,0.25 0.40	0.30,0.20,0.10	89.4	88.1

Bảng 11: Độ nhảy của CoVer đối với vector trọng số chất lượng. Mỗi vector trọng số được sắp xếp theo ($\lambda_d, \lambda_a, \lambda_t, \lambda_u$). Giá trị Mac. F1 được báo cáo theo điểm phần trăm. Cấu hình tốt nhất và tệ nhất được chọn từ tập phát triển và đánh giá mà không tinh chỉnh thêm trên tập kiểm tra.

Phương pháp	Cấu hình	Avg. Cuộc gọi LLM	Đầu vào trung bình thẻ	Công suất trung bình thẻ	Ước tính chi phí/yêu cầu
Bia	Chính	5.34	1274.9	271.2	0.0059
FacTool	Gọi một lần	1.00	628.4	180.3	0.0034
FacTool	Đa cuộc gọi khớp	5.34	3261.5	852.2	0.0167
KiểmTraSựThậtGPT	Gọi một lần	1.00	635.4	357.1	0.0052
KiểmTraSựThậtGPT	Đa cuộc gọi khớp	5.34	3298.2	1461.2	0.0229
FIRE	Gọi một lần	1.00	633.4	275.1	0.0043
FIRE	Đa cuộc gọi khớp	5.34	3288.0	1530.4	0.0235
CONFACT	Gọi đơn	1.00	632.4	196.0	0.0035
CONFACT	Đa cuộc gọi khớp	5.34	3282.7	938.0	0.0176
Xung đột	Gọi một lần	1.00	632.4	188.5	0.0035
BÀ-TẾ	Gọi một lần	1.00	571.4	173.8	0.0032
Phong cách AVeriTeC	Gọi một lần	1.00	572.4	155.1	0.0030
Phân tách yêu cầu	Gọi một lần	1.00	635.4	341.6	0.0050

Bảng 12: Ngân sách suy luận và chi phí tính toán dưới các cấu hình gốc và gọi khớp. Các giá trị báo cáo là trung bình trên môi trường hợp đối với tất cả các ví dụ đánh giá. Các token đầu vào và đầu ra bao gồm tất cả các yêu cầu LLM được thực hiện bởi một phương pháp. Chi phí ước tính được tính dựa trên giá API tương ứng với mô hình nền báo cáo và ngày đánh giá.