ViNumFCR: A Novel Vietnamese Benchmark for Numerical Reasoning Fact Checking on Social Media News

Nhi Ngoc-Phuong Luong, Anh Thi-Lan Le, Tin Van Huynh*, Kiet Van Nguyen, Ngan Luu-Thuy Nguyen
Faculty of Information Science and Engineering, University of Information Technology,
Ho Chi Minh City, Vietnam
Vietnam National University, Ho Chi Minh City, Vietnam
{20520263, 20521067}@gm.uit.edu.vn
{tinhv, kietnv, ngannlt}@uit.edu.vn

Abstract

In the digital era, the internet provides rapid and convenient access to vast amounts of information. However, much of this information remains unverified, particularly with the increasing prevalence of falsified numerical data, leading to public confusion and negative societal impacts. To address this issue, we developed ViNumFCR, a first dataset dedicated to fact-checking numerical information in Vietnamese. Comprising over 10,000 samples collected and constructed from online newspaper across 12 different topics. We assessed the performance of various fact-checking models, including Pre-trained Language Models and Large Language Models, alongside retrieval techniques for gathering supporting evidence. Experimental results demonstrate that the XLM-R$_{Large}$ model achieved the highest accuracy of 90.05% on the fact-checking task, while the combined SBERT + BM25 model attained a precision of over 97% on the evidence retrieval task. Additionally, we conducted an in-depth analysis of the linguistic features of the dataset to understand the factors influencing the performance models. The ViNumFCR dataset is available to support further research.

1 Introduction

With the rapid growth of the Internet, information is shared widely and instantly, keeping users updated on many topics. However, this also enables the spread of unverified content, which poses significant risks. In Vietnam, fake news and misinformation have harmed people's health, finances, families, and reputations. As a result, fact-checking has become essential in fields like journalism and social media. While there has been extensive research for languages such as English and Chinese, Vietnamese remains underexplored. In particular, previous studies have rarely focused on verifying numerical information — an important yet overlooked aspect. Motivated by this, we design and develop a Vietnamese fact-checking task centered on numerical verification, aiming to help bridge this gap and enhance the reliability of digital information.

The fact checking task (Ünal and Çiçeklioğlu, 2019) is a process of verifying the accuracy of information, data, or events before they are published to the public. The goal of fact checking (Ünal and Çiçeklioğlu, 2019) is to determine the correctness of information based on verifiable evidence, such as official documents, reliable sources, or accurately recorded events.

In this paper, we describe our task as follows: Given a Vietnamese sentence containing numerical data A and a Vietnamese text passage containing numerical data B, the objective is to develop a system that can verify the accuracy of sentence A by identifying supporting evidence in text B.

Input: Given a text passage (called B) and a sentence (called A) that is related to the content of B.

Output: A label X indicating the veracity of sentence A based on text B, where X belongs to the label set Supported, Refuted, NotenoughInfo, along with evidence to demonstrate whether "Text B contains sufficient evidence to verify sentence A.". Figure 1 shows an illustration of the task.

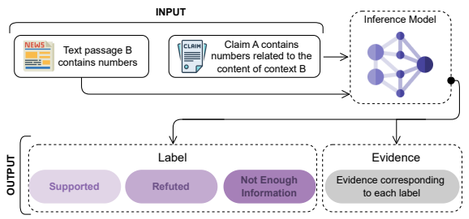


Figure 1: A Visual Diagram Illustrating the Numerical Reasoning Fact Checking Task.

*Corresponding author.

ViNumFCR: Một bộ chuẩn mới của Việt Nam cho kiểm tra sự thật lý luận số học trên tin tức mạng xã hội

Nhi Ngoc-Phuong Luong, Anh Thi-Lan Le, Tin Van Huynh*, Kiet Van Nguyen, Ngan Luu-Thuy Nguyen Khoa Khoa học Thông tin và Kỹ thuật, Đại học Công nghệ Thông tin, Thành phố Hồ Chí Minh, Việt Nam Đại học Quốc gia Việt Nam, Thành phố Hồ Chí Minh, Việt Nam {20520263, 20521067}@gm.uit.edu.vn {tinhv, kietnv, ngannlt}@uit.edu.vn

Tóm tắt

Trong thời đại kỹ thuật số, internet cung cấ p quyền truy cập nhanh chóng và tiện lợi đến một lượng lớn thông tin. Tuy nhiên, nhiều thông tin trong số này vẫn chưa được xác minh, đặc biệt với sự gia tăng phổ biến của dữ liệu số bị làm giả, dẫn đến sự nhầm lẫn của công chúng và tác động tiêu cực đến xã hội. Để giải quyết vấn đề này, chúng tôi đã phát triển ViNumFCR, bộ dữ liệu đầu tiê n dành riêng cho việc kiểm tra sự thật t hông tin số bằng tiếng Việt. Bộ dữ liệu gồm hơn 10.000 mẫu được thu thập và xây dựng từ các tờ báo trực tuyến về 12 chủ đề khác nhau. Chúng tôi đánh giá hiệu suất của nhiều mô hình kiểm tra sự thật khác nhau, bao gồm Mô hình Ngôn ngữ Được Huấn luyện Trước và Mô hình Ngôn ngữ Lớn, cùng với các kỹ thuật truy xuất để thu thập bằng chứng hỗ trợ. Kết quả thực nghiệm c ho thấy mô hình XLM-R^{Large} đạt độ chính xác cao nhất 90,05% trong nhiệm vụ kiểm tra sự thật, trong khi mô hình kết hợp SBERT+ BM25 đạt độ chính xác trên 97% trong nhiệm vụ truy xuất bằng chứng. Ngoài ra, chúng tôi đã tiến hành một phân tích sâu sắc

1 Giới thiệu

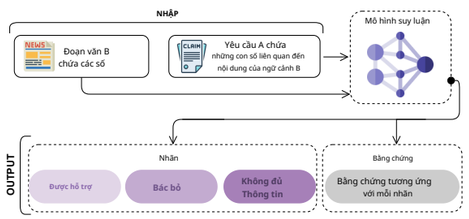
Với sự phát triển nhanh chóng của Internet, thông tin được chia sẻ rộng rãi và ngay lập tức, giúp người dùng cập nhật nhiều chủ đề. Tuy nhiên, điều này cũng tạo điều kiện cho việc lan truyền các nội dung chưa được xác minh, gây ra những rủi ro đáng kể. Ở Việt Nam, tin giả và thông tin sai lệch đã làm tổn hại đến sức khỏe, tài chính, gia đình và danh tiếng của người dân. Do đó, việc kiểm chứng thông tin đã trở nên thiết yếu trong các lĩnh vực như báo chí và mạng xã hội. Mặc dù đã có nhiều nghiên cứu về các ngôn ngữ như tiếng Anh và ti ếng Trung, tiếng Việt vẫn chưa được khai thác đầy đủ. Cụ thể, các nghiên cứu trước đây hiếm khi tập trung vào việc xác minh thông tin số — một khía cạnh quan trọng nhưng bị bỏ qua. Được thúc đẩy bởi điều này, chúng tôi thiết kế và phát triển một nhiệm vụ kiểm chứng sự thật tiếng Việt tập trung vào việc xác minh số liệu, nhằm giúp thu hẹp khoảng cách này và nâng cao độ tin cậy của thông tin kỹ thuật số.

Nhiệm vụ kiểm tra sự thật (¨Unal và C.ic.eklio ˘glu, 2019) là một quá trình xác minh độ chính xác của thông tin, dữ liệu hoặc sự kiện trước khi chúng được công bố ¨cho công chúng. Mục tiêu của kiểm tra sự thật (Unal và C.ic.eklio ˘glu, 2019) là xác định tính đúng đắn của thông tin dựa trên bằng chứng có thể kiểm chứng, chẳng hạn như các tài liệu chính thức, nguồn đáng tin cậy hoặc các sự kiện được ghi chép chính xác.

Trong bài báo này, chúng tôi mô tả nhiệm vụ của mình như sau: Cho một câu tiếng Việt chứa dữ liệu số A và một đoạn văn tiếng Việt chứa dữ liệu số B, mục tiêu là phát triển một hệ thống có thể xác minh độ chính xác của câu A bằng cách xác định bằng chứng hỗ trợ trong đoạn văn B.

Đầu vào: Cho một đoạn văn bản (gọi là B) và một câu (gọi là A) có liên quan đến nội dung của B.

Đầu ra: Một nhãn X chỉ ra tính xác thực của câu A dựa trên văn bản B, trong đó X thuộc tập nhãn Supported, Refuted, NotenoughInfo, cùng với bằng chứng để chứng minh liệu "Văn bản B có chứa đủ bằng chứng để xác minh câu A hay không." Hình 1 minh họa cho nhiệm vụ này.



Hình 1: Sơ đồ trực quan minh họa nhiệm vụ kiểm t ra sự thật về suy luận số học.

*Tác giả liên hệ.

We evaluated multiple models for Vietnamese fact verification, with BERT (Devlin et al., 2019) achieving 83.48% accuracy. Other models such as PhoBERT (Nguyen and Tuan Nguyen, 2020), XLM-R (Conneau et al., 2020), InfoXLM (Chi et al., 2021), ViSoBERT (Nguyen et al., 2023), CaFeBERT (Do et al., 2024), and BARTpho-word (Tran et al., 2022) achieved 85.27%, 84.68%, 85.07%, 56.11%, 89.35%, and 85.67%, respectively. We also analyzed the influence of sentence length, syntactic complexity, and semantic ambiguity, which revealed their impact on model performance.

The key contributions of this project are as follows:

- We introduce ViNumFCR, a high-quality dataset for fact verification based on logical inference, consisting of over 10,000 samples of paragraph-claim-evidence with human-generated inference labels for fact-checking tasks.
- We conducted experiments on neural network-based models, pre-trained transformer models, and large language models.
- We analyzed linguistic features in ViNumFCR to understand factors influencing the performance of pre-trained models, providing insights into both the models and the ViNumFCR dataset.

2 Related Works

2.1 Related datasets

Several datasets have been developed to support fact-checking research. FEVER (Thorne et al., 2018) is a widely used benchmark containing over 185,000 claims labeled as Supported, Refuted, or NotEnoughInfo, based on evidence from Wikipedia. LIAR (Wang, 2017), proposed by Wang, includes over 12,800 political statements from politifact.com with six truthfulness levels, enabling fine-grained fake news detection. FEVEROUS(Aly et al., 2021) extends FEVER by including structured and unstructured data, with 87,026 labeled claims. VITAMINC (Schuster et al., 2021) offers 400,000 claim-evidence pairs, promoting contrastive reasoning for claim verification. In the Vietnamese context, ViFactCheck (Hoa et al., 2025) and ViWikiFC (Le et al., 2024) are the first manually annotated datasets with three labels—SUPPORTED, REFUTED, or NOT ENOUGH INFORMATION—contributing significantly to fact-checking research for Vietnamese. However, no dataset has been specifically designed to study numerical reasoning fact-checking on Vietnamese social media text.

Table 1 provides a brief summary of various datasets used for the fact-checking task.

2.2 Related models

The evolution of artificial intelligence has driven significant advancements in NLP for fact-checking tasks. Early approaches utilized classical machine learning models like Random Forest (Rigatti, 2017) and Support Vector Machines (SVM) (Mammone et al., 2009), which classified claims using syntactic and semantic features. While stable, these models struggled with contextual nuances critical for fact-checking. Recurrent neural networks such as LSTM (Hochreiter and Schmidhuber, 1997) improved performance by modeling sequential dependencies, capturing textual context more effectively. However, their limitations in handling long-range dependencies led to the adoption of transformer-based models. Models like BERT (Devlin et al., 2019), RoBERTa (Liu et al., 2019), XLM-R (Conneau et al., 2020), and PhoBERT (Nguyen and Tuan Nguyen, 2020) revolutionized NLP by leveraging self-attention to capture bidirectional semantics, making them ideal for fact-checking tasks requiring nuanced understanding.

Recent large language models (LLMs), such as Qwen (Bai et al., 2023), Gemma (Mesnard et al., 2024), GPT (Achiam et al., 2023), and Llama (Touvron et al., 2023), have further advanced fact-checking by offering superior reasoning and text generation capabilities (Hoa et al., 2025; Le et al., 2024). These models excel in verifying complex claims but face challenges like computational cost. Evidence retrieval techniques, including BM25 (Robertson et al., 2009) and SBERT (Reimers and Gurevych, 2019), complement these models by retrieving relevant evidence to enhace the accuracy and reliability of fact verification models.

3 Corpus Creation

We conducted the data construction following a rigorous process to ensure the accuracy, reliability, and quality of the dataset. The process was referenced from the ViNLI and FEVER dataset

Chúng tôi đã đánh giá nhiều mô hình cho việc xác minh sự thật tiếng Việt, với BERT (Devlin và cộng sự, 2019) đạt độ chính xác 83,48 %. Các mô hình khác như PhoBERT (Nguyễn và Tuấn Nguyễn, 2020), XLM-R (Conneau và cộng sự, 2020), InfoXLM (Chi và cộng sự, 2021), ViSoBERT (Nguyễn và cộng sự, 2023), CaFeBERT (Đỗ và cộng sự, 2024), và BARTpho-word (Trần và cộng sự, 2022) đạt lần lượt 85,27%, 84,68%, 85,07%, 56,11%, 89,35% và 85,67%. Chúng tôi cũng đã phân tích ảnh hưởng của độ dài câu, độ phức tạp cú pháp, và sự mơ hồ ngữ nghĩa, và điều này đã tiết lộ tác động của chúng đến hiệu suất của các mô hình.

Những đóng góp chính của dự án này như sau:

•Chúng tôi giới thiệu ViNumFCR, một tập dữ liệu chất lượng cao để xác minh sự thật dựa trên suy luận logic, bao gồm hơn 10.000 mẫu đoạn văn - tuyên bố - bằng chứng với các nhãn suy luận do con người tạo ra cho các nhiệm vụ kiểm tra sự thật.

Chúng tôi đã thực hiện các thí nghiệm trên các mô hình dựa trên mạng nơ-ron, các mô hình transformer được huấn luyện trước, và các mô hình ngôn ngữ lớn.

• Chúng tôi đã phân tích các đặc điểm ngôn ngữ trong ViNumFCR để hiểu các yếu tố ảnh hưởng đến hiệu suất của các mô hình đã được huấn luyện trước, cung cấp những hiểu biết về cả các mô hình và bộ dữ liệu ViNumFCR.

2 Công trình liên quan

2.1 Các bộ dữ liệu liên quan

Một số bộ dữ liệu đã được phát triển để hỗ trợ nghiên cứu kiểm tra sự thật. FEVER (Thorne và cộng sự, 2018) là một chuẩn đánh giá được sử dụng rộng rãi, chứa hơn 185.000 tuyên bố được gắn nhãn là Hỗ trợ, Bác bỏ hoặc Thông tin không đủ, dựa trên bằng chứng từ Wikipedia. LIAR (Wang, 2017), do Wang đề xuất, bao gồm hơn 12.800 tuyên bố chính trị từ politifact.com với sáu mức độ chân thực, cho phép phát hiện tin giả tinh vi. FEVER-OUS (Aly và cộng sự, 2021) mở rộng FEVER bằng cách bao gồm dữ liệu có cấu trúc và không có cấu trúc, với 87.026 tuyên bố đã được gắn nhãn. VITAMINC (Schuster và cộng sự, 2021) cung cấp 400.000 cặp tuyên bố-bằng chứng, thúc đẩy suy luận đối chiếu cho việc xác minh tuyên bố. Trong bối cảnh Việt Nam, ViFactCheck (Hoa và cộng sự, 2025) và ViWikiFC (Lê và cộng sự, 2024) là các bộ dữ liệu được chú thích thủ công đầu tiên với ba nhãn—HỖ TRỢ, BÁC BỎ, hoặc KHÔNG ĐỦ THÔNG TIN—đóng góp đáng kể cho nghiên cứu kiểm chứng sự thật cho tiếng Việt. Tuy nhiên, chưa có bộ dữ liệu nào được thiết kế đặc biệt để nghiên cứu kiểm chứng tính toán số liệu trên văn bản mạng xã hội tiếng Việt.

Bảng 1 cung cấp một tóm tắt ngắn gọn về các tập dữ liệu khác nhau được sử dụng cho nhiệm vụ kiểm chứng sự thật.

2.2 Các mô hình liên quan

Sự phát triển của trí tuệ nhân tạo đã thúc đẩy những tiến bộ đáng kể trong xử lý ngôn ngữ tự nhiên (NLP) cho các nhiệm vụ kiểm tra sự thật. Các phương pháp ban đầu sử dụng các mô hình học máy cổ điển như Random Forest (Rigatti, 2017) và Support Vector Machines (SVM) (Mammone et al., 2009), phân loại các tuyên bố bằng cách sử dụng các đặc trưng cú pháp và ngữ nghĩa. Mặc dù ổn định, các mô hình này gặp khó khăn với những sắc thái bối cảnh quan trọng cho việc kiểm tra sự thật. Các mạng nơ-ron hồi tiếp như LSTM (Hochreiter và Schmidhuber, 1997) cải thiện hiệu suất bằng cách mô hình hóa các phụ thuộc theo trình tự, nắm bắt bối cảnh văn bản một cách hiệu quả hơn. Tuy nhiên, hạn chế của chúng trong việc xử lý các phụ thuộc dài hạn đã dẫn đến việc áp dụng các mô hình dựa trên transformer. Các mô hình như BERT (Devlin et al., 2019), RoBERTa (Liu et al., 2019), XLM-R (Conneau et al., 2020) và PhoBERT (Nguyen và Tuan Nguyen, 2020) đã cách mạng hóa NLP bằng việc tận dụng cơ chế tự chú ý (self-attention) để nắm bắt ngữ nghĩa hai chiều, khiến chúng trở nên lý tưởng cho các nhiệm vụ kiểm tra sự thật yêu cầu sự tinh tế.

Các mô hình ngôn ngữ lớn (LLM) gần đây, chẳng hạn như Qwen (Bai và cộng sự, 2023), Gemma (Mesnard và cộng sự, 2024), GPT (Achiam và cộng sự, 2023), và Llama (Touvron và cộng sự, 2023), đã nâng cao hơn nữa việc kiểm tra tính xác thực bằng cách cung cấp khả năng lập luận và tạo văn bản vượt trội (Hoa và cộng sự, 2025; Lê và cộng sự, 2024). Những mô hình này xuất sắc trong việc xác minh các tuyên bố phức tạp nhưng gặp phải những thách thức như chi phí tính toán. Các kỹ thuật truy xuất bằng chứng, bao gồm BM25 (Robertson và cộng sự, 2009) và SBERT (Reimers và Gurevych, 2019), bổ sung cho những mô hình này bằng cách truy xuất các bằng chứng liên quan để nâng cao độ chính xác và độ tin cậy của các mô hình xác minh tính xác thực.

3 Tạo Tập Văn Bản

Chúng tôi đã tiến hành xây dựng dữ liệu theo một quy trình nghiêm ngặt để đảm bảo tính chính xác, độ tin cậy và chất lượng của bộ dữ liệu. Quy trình này được tham khảo từ bộ dữ liệu ViNLI và FEVER

Dataset	Text genre	Quantity	Language	3+ labels agree	4+ labels agree	Numerical Focus
FEVER	Wikipedia	∼185,000	English	–	–	No
LIAR	Newswire	∼12,800	English	–	–	No
FEVEROUS	Wikipedia	87,026	English	–	–	No
VITAMINC	Wikipedia	∼400,000	English	–	–	No
ViFactCheck	Wikipedia	∼7,200	Vietnamese	–	–	No
ViWikiFC	Newswire	∼20,000	Vietnamese	–	–	No
ViNumFCR (Our dataset)	**Newswire**	**∼10,000**	**Vietnamese**	**94%**	**85%**	**Yes**

Table 1: Overview of Fact-Checking Datasets

construction methodologies, as illustrated in Figure 2, and includes four main stages: (3.1) Collecting premise paragraphs; (3.2) Annotator recruitment and training; (3.3) Generating claims and finding evidence; and (3.4) Data validation. Additionally, we analyzed the dataset from various perspectives, as presented in Section 3.5

3.1 Collecting premise paragraphs

We collected over 10,000 articles from the highly reputable Vietnamese online newspaper VnExpress[1], covering 12 diverse topics including: digitalization, tourism, education, entertainment, science, business, law, health, world news, sports, current events and automobiles. Subsequently, we conducted preliminary data processing to extract text segments containing solely numerical data.

3.2 Annotator recruitment and training

The annotator recruitment and training process was based on the methodology used in the FEVER dataset (Thorne et al., 2018) and followed the steps outlined in Figure 3. The annotators, consisting of 17 university students in Vietnam with strong language proficiency and effective communication skills, underwent a training session to fully understand the annotation guidelines and evaluation criteria. They were compensated at a rate of $0.019 per annotated pattern. As part of the training phase, each annotator was required to write 20 claims using our custom-built annotation tool. The labels (Supported, Refuted, and NotenoughInfo) for the corresponding paragraph–claim pairs were then hidden, and the annotators proceeded to assign labels to these claims. Inter-annotator agreement was evaluated using Cohen's Kappa coefficient (Cohen, 1960). Annotators achieving an agreement rate above 0.95 were deemed eligible to participate in the official data construction. In cases of lower agreement rates, annotators were required to review their errors and repeat the training process with a new dataset. During training, any disagreements in labeling were reviewed, and, if necessary, adjustments were made to the sentence-writing rules to ensure the quality and accuracy of the dataset.

3.3 Generate Claims and Find Evidence

The annotators are required to generate claims that include numerical data and content mentioned in the original paragraph but rephrased creatively using their own vocabulary, avoiding the reuse of words or phrases that appeared in the premise paragraph. The creators will generate three claims for the three labels according to the following guidelines:

Supported: The claim is correct with respect to the information and numerical data provided in the original paragraph.

Refuted: The claim is incorrect with respect to the information and numerical data provided in the original paragraph.

NotenoughInfo: It cannot be determined whether the claim is correct or incorrect based on the information and numerical data available in the original paragraph.

Additionally, the creators are required to find evidence for the two labels, Supported and Refuted. The evidence is provided by selecting specific sentences from the premise paragraph that relate to the claim the creator just wrote. To create these claims, annotators may refer to the sentence writing rules provided in the guidelines. Tables 2 and 3 summarize these rules, which were referenced from the ViNLI dataset (Huynh et al., 2022). The illustrative examples of rules for creating premise paragraph - claim pairs for the Supported and Refuted Labels are presented in Appendix A. The annotators must write three claims and find evidence (for the Supported and Refuted labels) for each premise

[1]https://vnexpress.net

Bộ dữ liệu	Thể loại văn bản	Số lượng	Ngôn ngữ	3+ nhãn đồng ý	4+ nhãn đồng ý	Số học Tập trung
SỐT	Wikipedia	∼185,000	Tiếng Anh	–	–	No
LIAR	Bản tin	∼12,800	Tiếng Anh	–	–	No
Sốt	Wikipedia	87.026	Tiếng Anh	–	–	No
VITAMINC	Wikipedia	∼400,000	Tiếng Anh	–	–	No
ViFactCheck	Wikipedia	∼7,200	Tiếng Việt	–	–	No
ViWikiFC	Bản tin	∼20,000	Tiếng Việt	–	–	No
ViNumFCR (Bộ dữ liệu của chúng tôi)	**Bản tin**	**∼10,000**	**Tiếng Việt**	**94%**	**85%**	**Yes**

Bảng 1: Tổng quan về các bộ dữ liệu kiểm chứng sự thật

các phương pháp xây dựng, như được minh họa trong Hình 2, và bao gồm bốn giai đoạn chính: (3.1) Thu thập các đoạn văn tiền đề; (3.2) Tuyển dụng và đào tạo người chú giải; (3.3) Tạo các tuyên bố và tìm kiếm bằng chứng; và (3.4) Xác thực dữ liệu. Ngoài ra, chúng tôi đã phân tích bộ dữ liệu từ nhiều góc độ khác nhau, như được trình bày trong Mục 3.5

3.1 Thu thập các đoạn văn tiền đề

Chúng tôi đã thu thập hơn 10.000 bài viết từ tờ báo điện tử Việt Nam có uy tín VnExpress [1], bao phủ 12 chủ đề đa dạng bao gồm: số hóa, du lịch, giáo dục, giải trí, khoa học, kinh doanh, pháp luật, y tế, tin tức thế giới, thể thao, sự kiện hiện tại và ô tô. Sau đó, chúng tôi tiến hành xử lý dữ liệu sơ bộ để trích xuất các đoạn văn bản chỉ chứa dữ liệu số.

3.2 Tuyển dụng và đào tạo người gán nhãn

Quy trình tuyển dụng và đào tạo người chú giải dựa trên phương pháp được sử dụng trong bộ dữ liệu FEVER (Thorne và cộng sự, 2018) và tuân theo các bước được minh họa trong Hình 3. Các người chú giải, gồm 17 sinh viên đại học tại Việt Nam với khả năng ngôn ngữ tốt và kỹ năng giao tiếp hiệu quả, đã tham gia một buổi đào tạo để hiểu đầy đủ các hướng dẫn chú giải và tiêu chí đánh giá. Họ được trả thù lao với mức $0,019 cho mỗi mẫu được chú giải. Như một phần của giai đoạn đào tạo, mỗi người chú giải được yêu cầu viết 20 tuyên bố sử dụng công cụ chú giải do chúng tôi tự phát triển. Nhãn (Supported, Refuted, và NotenoughInfo) cho từng cặp đoạn văn–tuyên bố tương ứng sau đó được ẩn đi, và các người chú giải tiến hành gán nhãn cho những tuyên bố này. Sự đồng thuận giữa các người chú giải được đánh giá bằng hệ số Kappa của Cohen (Cohen, 1960). Những người chú giải đạt tỷ lệ đồng thuận trên 0,95 được coi là đủ điều kiện tham gia vào việc xây dựng dữ liệu chính thức. Trong các trường hợp thấp hơn tỷ lệ đồng thuận, các chú giải viên được yêu cầu xem lại các lỗi của họ và lặp lại quá trình đào tạo với một bộ dữ liệu mới. Trong quá trình đào tạo, bất kỳ sự bất đồng nào về việc gán nhãn đều được xem xét, và nếu cần, các quy tắc viết câu đã được điều chỉnh để đảm bảo chất lượng và độ chính xác của bộ dữ liệu.

3.3 Tạo Yêu Cầu và Tìm Bằng Chứng

Những người chú thích được yêu cầu tạo ra các khẳng định bao gồm dữ liệu số và nội dung được đề cập trong đoạn văn gốc nhưng được diễn đạt lại một cách sáng tạo bằng từ vựng của riêng họ, tránh tái sử dụng các từ hoặc cụm từ đã xuất hiện trong đoạn văn cơ sở. Những người tạo sẽ tạo ra ba khẳng định cho ba nhãn theo các hướng dẫn sau:

Hỗ trợ: Mệnh đề là chính xác liên quan đến thông tin và dữ liệu số được cung cấp trong đoạn văn gốc.

Bác bỏ: Yêu cầu này không chính xác liên quan đến thông tin và dữ liệu số đã được cung cấp trong đoạn văn gốc.

Chưa đủ thông tin: Không thể xác định liệu tuyên bố là đúng hay sai dựa trên thông tin và dữ liệu số có sẵn trong đoạn gốc.

Ngoài ra, các tác giả được yêu cầu tìm bằng chứng cho hai nhãn, Hỗ trợ và Bác bỏ. Bằng chứng được cung cấp bằng cách chọn các câu c ụ thể từ đoạn tiền đề có liên quan đến tuyên bố mà tác giả vừa viết. Để tạo ra các tuyên bố này, người chú thích có thể tham khảo các quy tắc viết câu được cung cấp trong hướng dẫn. Bảng 2 và 3 tóm tắt các quy tắc này, được tham chiếu t ừ bộ dữ liệu ViNLI (Huỳnh et al., 2022). Các ví dụ minh họa về quy tắc tạo cặp đoạn tiền đề - tuyên bố cho các nhãn Hỗ trợ và Bác bỏ được trình bày trong Phụ lục A. Người chú thích phải viết ba tuyên bố và tìm bằng chứng (cho các nhãn Hỗ trợ và Bác bỏ) cho mỗi đoạn tiền đề

[1]https://vnexpress.net

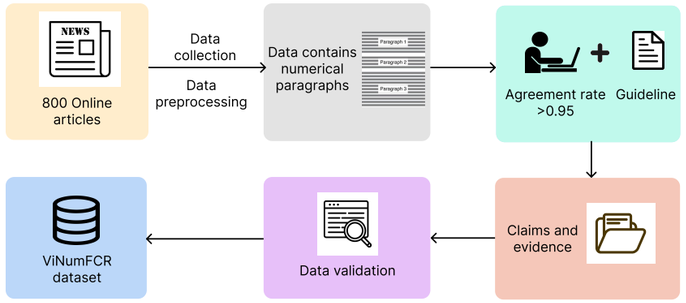


Figure 2: The Process of Building the Vinumfcr Dataset.

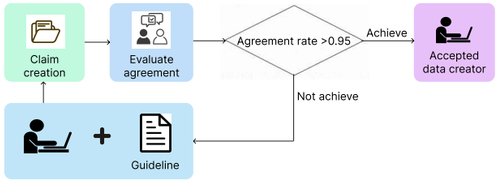


Figure 3: The Process of Selecting Data Annotators for the Vinumfcr Dataset.

No.	Rule	Ratio
1	Use negative words.	6%
2	Replace with antonyms.	14.5%
3	Incorrect entity inference structure.	18.5%
4	Incorrect event inference structure.	2%
5	Create a sentence with a meaning opposite to the presupposition paragraph.	38%
6	Others.	21%

Table 3: Rules for Creating Refuted Claims Sentences.

paragraph.

No.	Rule	Ratio
1	Change the sentence structure from active to passive and vice versa.	7%
2	Replace with synonyms or similar words.	38%
3	Add or remove modifiers while retaining the original meaning of the sentence.	26%
4	Replace representative nouns with relative clauses.	1%
5	Replace the object with a relative clause.	1%
6	Replace the adjective with a relative clause.	1%
7	Replace the quantity terms with equivalent ones.	9%
8	Generate a presupposition sentence.	11.5%
9	Others.	13.5%

Table 2: Rules for Creating Supported Claims Sentences.

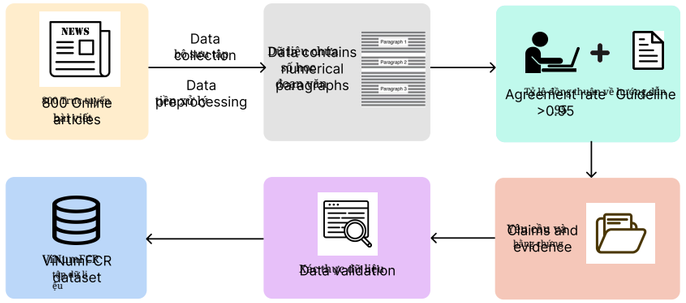
3.4 Data validation

We conducted a round of data validation by cross-labeling premise paragraph-claim pairs by multiple annotators. We selected five different annotators, who had participated in the claim-writing phase, to label the premise paragraph-claim pairs. The data samples to be labeled were not from the dataset originally written by the assigned labelers. If a premise paragraph-claim pair does not receive at least three out of five identical labels, it will be excluded from the dataset. This new method provides a fresh perspective on an issue that the original FEVER paper did not address, with the results presented in Table 1. Statistics show that the rate of premise paragraph-claim pairs achieving four identical labels is 85%, while the rate of premise paragraph-claim pairs achieving three identical labels is 94%.

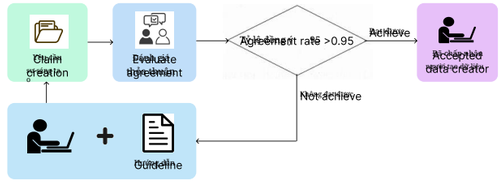
3.5 Corpus Analysis

To train and evaluate the model, we randomly divided the data into three parts with the following proportions: 80% for the training set (train), 10% for the development set (dev) and 10% for the test set. Table 4 shows the preliminary statistics, including the number of premise paragraph-claim pairs across 12 different topics and the average length (in words) of the premise paragraphs and claims. The average length of the premise paragraphs and claims in the Train, Dev and Test sets is 58.3 words for premise paragraphs and 20.5 words for claims. The average lengths of the premise paragraphs and claims across the three sets are relatively consistent, contributing to the dataset's consistency and helping the model learn more effectively.

Word Overlap: We calculated the word overlap between the premise paragraphs and claims in the ViNumFCR dataset. We chose to use the Jaccard index to assess lexical overlap based on the frequency of words appearing, regardless of or-



Hình 2: Quá trình xây dựng bộ dữ liệu Vinumfcr.



Hình 3: Quá trình lựa chọn người chú thích dữ liệu cho tập dữ liệu Vinumfcr.

No.	Rule	Tỷ lệ
1	Sử dụng những từ mang nghĩa tiêu cực.	6%
2	Thay thế bằng từ trái nghĩa.	14,5%
3	Cấu trúc suy luận thực thể không chính xác.	18,5%
4	Cấu trúc suy luận sự kiện không chính xác.	2%
5	Tạo một câu có nghĩa ngược lại đến đoạn giả định.	38%
6	Những người khác.	21%

Bảng 3: Quy tắc để tạo câu khẳng định bị bác bỏ.

đoạn văn.

No.	Rule	Tỷ lệ
1	Thay đổi cấu trúc câu từ chủ động sang bị động và ngược lại.	7%
2	Thay thế bằng các từ đồng nghĩa hoặc từ có nghĩa tương tự.	38%
3	Thêm hoặc bớt các bộ điều biến trong khi vẫn giữ nghĩa gốc của câu.	26%
4	Thay thế danh từ đại diện bằng đại từ quan hệ các mệnh đề.	1%
5	Thay thế đối tượng bằng một mệnh đề quan hệ.	1%
6	Thay tính từ bằng một mệnh đề quan hệ.	1%
7	Thay thế các thuật ngữ về số lượng bằng tương đương ones.	9%
8	Tạo một câu giả định.	11,5%
9	Những người khác.	13,5%

Bảng 2: Quy tắc để tạo câu khẳng định được hỗ trợ.

3.4 Xác thực dữ liệu

Chúng tôi đã tiến hành một vòng xác thực dữ liệu bằng cách đối chiếu gán nhãn các cặp đoạn văn luận điểm-đề xuất bởi nhiều người chú thích. Chúng tôi đã chọn năm người chú thích khác nhau, những người đã tham gia vào giai đoạn viết đề xuất, để gán nhãn các cặp đoạn văn luận điểm-đề xuất. Các mẫu dữ liệu cần được gán nhãn không thuộc tập dữ liệu ban đầu do các người gán nhãn được phân công viết. Nếu một cặp đoạn văn luận điểm-đề xuất không nhận được ít nhất ba trong năm nhãn giống nhau, nó sẽ bị loại khỏi tập dữ liệu. Phương pháp mới này cung cấp một góc nhìn mới về một vấn đề mà bài báo FEVER gốc chưa đề cập, với kết quả được trình bày trong Bảng 1. Thống kê cho thấy tỉ lệ các cặp đoạn văn tiền đề - khẳng định đạt bốn nhãn giống nhau là 85%, trong khi tỉ lệ các cặp đoạn văn tiền đề - khẳng định đạt ba nhãn giống nhau là 94%.

3.5 Phân tích tập hợp văn bản

Để huấn luyện và đánh giá mô hình, chúng tôi đã chia ngẫu nhiên dữ liệu thành ba phần với tỷ lệ sau: 80% cho tập huấn luyện (train), 10% cho tập phát triển (dev) và 10% cho tập kiểm tra. Bảng 4 trình bày các thống kê sơ bộ, bao gồm số cặp đoạn văn tiền đề và luận cứ theo 12 chủ đề khác nhau và độ dài trung bình (tính bằng từ) của các đoạn văn tiền đề và các luận cứ. Độ dài trung bình của các đoạn văn tiền đề và luận cứ trong các tập Train, Dev và Test lần lượt là 58,3 từ cho đoạn văn tiền đề và 20,5 từ cho luận cứ. Độ dài trung bình của các đoạn văn tiền đề và luận cứ ở cả ba tập tương đối đồng đều, góp phần vào tính nhất quán của bộ dữ liệu và giúp mô hình học hiệu quả hơn.

Chồng chéo từ: Chúng tôi đã tính toán sự chồng chéo từ giữa các đoạn tiền đề và các tuyên bố trong bộ dữ liệu ViNumFCR. Chúng tôi đã chọn sử dụng chỉ số Jaccard để đánh giá sự trùng lặp từ vựng dựa trên tần suất xuất hiện của các từ, bất kể

Topic/Label	Train	Dev	Test	Total
Digital	742	80	90	912
Tourism	523	76	79	678
Education	479	57	58	594
Entertainment	323	41	59	423
Science	574	61	73	708
Business	700	90	89	882
Law	1,662	201	189	2,052
Health	729	88	80	897
World	594	82	80	756
Sports	622	64	73	759
News	643	105	71	819
Cars	413	54	64	531
Supported	2,668	333	335	3,336
Refuted	2,668	333	335	3,336
NotenoughInfo	2,668	333	335	3,336
Total (pairs)	8,004	999	1,005	10,008
MPL (words)	58.6	57.5	58.8	58.3
MCL (words)	20.4	20.4	20.6	20.5

Table 4: Overview Statistics of the ViNumFCR Dataset. MPL: Mean Premise Paragraph Length. MCL: Mean Claim Length.

der, between the premise paragraph and the claim. Additionally, we used LCS (Longest Common Subsequence) to evaluate the structural similarity between the premise paragraph and the claim by focusing on finding the longest common subsequence between the two strings. To better suit the analysis in Vietnamese, we first used VnCoreNLP(Vu et al., 2018) for word segmentation before applying Jaccard and LCS. The analysis results are shown in Table 5. Based on the analysis, we found that the Supported label has the highest lexical overlap when measured by the Jaccard index, as well as the highest sequence overlap when measured by the LCS index. Conversely, the NotenoughInfo label has the lowest lexical overlap according to both the Jaccard and LCS indices.

New Word Rate: We analyzed the usage of new words in the dataset to evaluate the diversity in the creators' use of language. To perform this effectively, we also used VnCoreNLP(Vu et al., 2018) for word segmentation. Then, we used PhoNLP(Nguyen and Nguyen, 2021) to classify the new words by word class. The results shown in Table 5 indicate that the NotenoughInfo label has the highest number of new words at 54.27%. Additionally, nouns and verbs are the most frequently used word classes in the claims created by the annotators.

Data-Generation Rules Analysis: annotators may flexibly use one or more rules to construct claims. We analyzed how these rules were combined by selecting 200 random premise paragraph-claim pairs from the dataset, focusing on the Supported and Refuted labels for analysis. According to Figure 4, 57% of the supported claims were created using one rule, 41% were created using two rules and using three rules to create supported claims was less common, accounting for only 2%. For the refuted claims, the trend of using one rule to create a claim was predominant, and combining two rules accounting for only 3%.

Next, we analyzed the claim creation rules to better understand the tendencies and standards applied by the annotators during data construction. The results from Table 2 show that, for supported claims, annotators most frequently used the "Replace with synonyms or similar words." rule, accounting for 38%. Conversely, the rule "Replace representative nouns/objects/adjectives with relative clauses." was used the least, at only 3%. For refuted claims, Table 3 shows that the most applied rule was "Create a sentence with a meaning opposite to the presupposition paragraph." with a rate of 38%, as this rule best aligns with the primary purpose of refuted claims, which is to negate the premise paragraph content. On the other hand, the least used rule was "Incorrect event inference structure." accounting for only 2%.

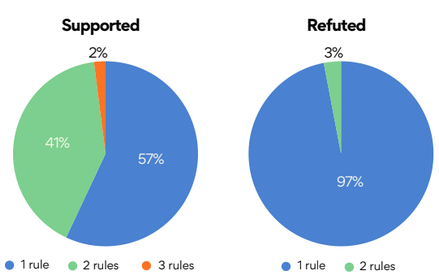


Figure 4: Percentage of Combined Rules for Generating Supported and Refuted Label Claims.

Syntax tree: To evaluate the complexity of affirmative sentences, we conducted a syntactic tree analysis. We used PhoNLP to analyze the dependency relationships between words in the sentences, thereby constructing a tree structure that represents the connections between the words. The level of the tree was calculated as the maximum depth from a leaf node (a word with no child dependencies) to the root of the sentence. The results shown in Figure 5 indicate that syntactic trees with a level of 3 accounted for the highest proportion, at

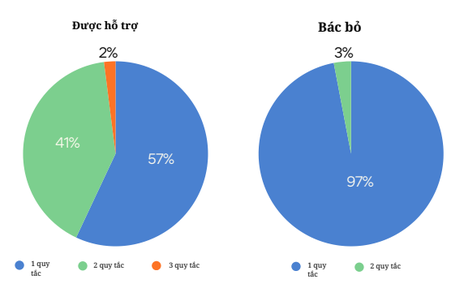
Chủ đề/Nhãn	Tàu	Dev	Test	Tổng cộng
Kỹ thuật số	742	80	90	912
Du lịch	523	76	79	678
Giáo dục	479	57	58	594
Giải trí	323	41	59	423
Khoa học	574	61	73	708
Kinh doanh	700	90	89	882
Law	1,662	201	189	2,052
Sức khỏe	729	88	80	897
Thế giới	594	82	80	756
Thể thao	622	64	73	759
News	643	105	71	819
Cars	413	54	64	531
Được hỗ trợ	Hai nghìn sáu trăm năm mươi tám	333	335	Ba nghìn ba trăm ba mươi sáu
Bác bỏ	Hai nghìn sáu trăm năm mươi tám	333	335	Ba nghìn ba trăm ba mươi sáu
Không đủ thông tin	Hai nghìn sáu trăm năm mươi tám	333	335	Ba nghìn ba trăm ba mươi sáu
Tổng số (cặp)	Tám nghìn bốn	999	Một nghìn năm trăm	10.008
MPL (từ)	58.6	57.5	58.8	58.3
MCL (từ)	20.4	20.4	20.6	20.5

Bảng 4: Thống kê tổng quan của bộ dữ liệu ViNumFCR. MPL: Độ dài trung bình của đoạn tiền đề. MCL: Độ dài trung bình của nhận định.

der, giữa đoạn tiền đề và tuyên bố. Ngoài ra, chúng tôi đã sử dụng LCS (Chuỗi Con Chung Dài Nhất) để đánh giá sự tương đồng về cấu trúc giữa đoạn tiền đề và tuyên bố bằng cách tập trung vào việc tìm chuỗi con chung dài nhất giữa hai chuỗi. Để phù hợp hơn với phân tích bằng tiếng Việt, chúng tôi trước tiên đã sử dụng VnCoreNLP (Vu et al., 2018) để phân tách từ trước khi áp dụng Jaccard và LCS. Kết quả phân tích được thể hiện trong Bảng 5. Dựa trên phân tích, chúng tôi nhận thấy nhãn Supported có sự trùng khớp từ vựng cao nhất khi đo bằng chỉ số Jaccard, cũng như sự trùng khớp chuỗi cao nhất khi đo bằng chỉ số LCS. Ngược lại, nhãn NotenoughInfo có sự trùng khớp từ vựng thấp nhất theo cả hai chỉ số Jaccard và LCS.

Tỷ lệ từ mới: Chúng tôi đã phân tích việc sử dụng từ mới trong tập dữ liệu để đánh giá sự đa dạng trong cách sử dụng ngôn ngữ của các nhà sáng tạo. Để thực hiện điều này một cách hiệu quả, chúng tôi cũng đã sử dụng VnCoreNLP (Vu et al., 2018) cho việc tách từ. Sau đó, chúng tôi sử dụng PhoNLP (Nguyen và Nguyen, 2021) để phân loại các từ mới theo loại từ. Kết quả được trình bày trong Bảng 5 cho thấy nhãn NotenoughInfo có số lượng từ mới cao nhất với 54,27%. Ngoài ra, danh từ và động từ là những loại từ được sử dụng nhiều nhất trong các tuyên bố do các người gán nhãn tạo ra.

Phân tích Quy tắc Sinh dữ liệu: những người chú thích có thể linh hoạt sử dụng một hoặc nhiều quy tắc để xây dựng các tuyên bố. Chúng tôi đã phân tích cách những quy tắc này được com-



Hình 4: Tỷ lệ phần trăm các Quy tắc Kết hợp để Tạo các Nhãn Yêu cầu được Hỗ trợ và Bác bỏ.

được tổng hợp bằng cách chọn 200 cặp đoạn văn tiền đề và khẳng định ngẫu nhiên từ bộ dữ liệu, tập trung vào các nhãn Hỗ trợ và Bác bỏ để phân tích. Theo Hình 4, 57% các khẳng định được hỗ trợ được tạo bằng cách sử dụng một quy tắc, 41% được tạo bằng cách sử dụng hai quy tắc và việc sử dụng ba quy tắc để tạo các khẳng định được hỗ trợ ít phổ biến hơn, chỉ chiếm 2%. Đối với các khẳng định bị bác bỏ, xu hướng sử dụng một quy tắc để tạo khẳng định chiếm ưu thế, và kết hợp hai quy tắc chỉ chiếm 3%.

Tiếp theo, chúng tôi phân tích các quy tắc tạo lập tuyên bố để hiểu rõ hơn về xu hướng và tiêu chuẩn mà các người gán nhãn áp dụng trong quá trình xây dựng dữ liệu. Kết quả từ Bảng 2 cho thấy, đối với các tuyên bố được hỗ trợ, người gán nhãn thường sử dụng nhất quy tắc "Thay thế bằng từ đồng nghĩa hoặc từ có nghĩa tương tự", chiếm 38%. Ngược lại, quy tắc " Thay thế danh từ/đối tượng/tính từ đại diện bằng mệnh đề quan hệ" được sử dụng ít nhất, chỉ chiếm 3%. Đối với các tuyên bố bị phản bác, Bảng 3 cho thấy quy tắc được áp dụng nhiều nhất là "Tạo câu có nghĩa trái ngược với đoạn giả định", với tỷ lệ 38%, vì quy tắc này phù hợp nhất với mục đích chính của các tuyên bố bị phản bác, đó là phủ định nội dung đoạn giả định. Mặt khác, quy tắc ít được sử dụng nhất là " Cấu trúc suy diễn sự kiện sai", chỉ chiếm 2%.

Cây cú pháp: Để đánh giá độ phức tạp của các câu khẳng định, chúng tôi đã tiến hành phân tích cây cú pháp. Chúng tôi sử dụng PhoNLP để phân tích các mối quan hệ phụ thuộc giữa các từ trong câu, từ đó xây dựng một cấu trúc cây thể hiện các kết nối giữa các từ. Cấp độ của cây được tính bằng chiều sâu tối đa từ một nút lá (một từ không có từ con phụ thuộc) đến gốc của câu. Kết quả được trình bày trong Hình 5 cho thấy các cây cú pháp có cấp độ 3 chiếm tỷ lệ cao nhất, ở mức

Label	Jaccard (%)	LSC (%)	New word rate	Part-Of-Speech (%)					
				Noun	Verb	Adjective	Preposition	Adjunct	Other
Supported	23.72	72.92	35.58	28.35	30.16	6.93	9.04	9.61	15.91
Refuted	19.76	70.12	43.99	25.62	25.92	7.27	9.36	8.41	23.42
NotenoughInfo	15.74	67.41	54.27	31.11	26.31	7.47	8.73	9.48	16.90

Table 5: Word Overlap and New Word Rate Between Premise Paragraph and Claim.

39.11%.

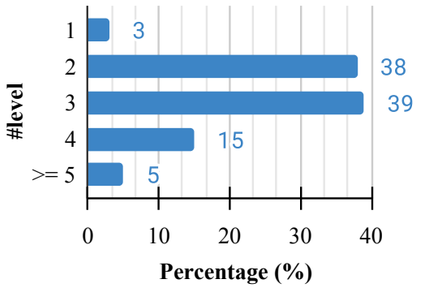


Figure 5: Distribution of Syntax Tree Depth Levels.

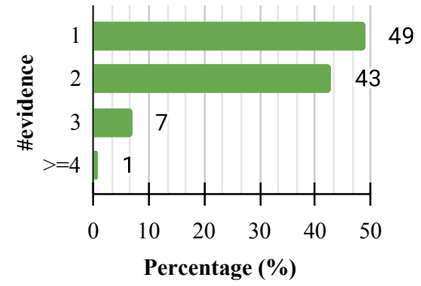


Figure 6: The Proportion of Combined Sentences Forming Evidence.

Evidence: During the data construction phase, after completing the claims, annotators search for evidence to support the claims for the Supported and Refuted labels. Figure 6 illustrates the proportion of sentences used to form evidence. Accordingly, 49% of the evidence consists of only one sentence, indicating that this is the most commonly applied method by annotators. Additionally, the proportion of using two sentences as evidence is 43%, while evidence using three or more sentences accounts for 8%.

4 Experiments and Evaluation

4.1 Baseline Model and Experimental Setup

To evaluate ViNumFCR, we experimented with a range of models, including multilingual PLMs such as mBERT (Devlin et al., 2019), SBERT (Reimers and Gurevych, 2019), and XLM-R (Conneau et al., 2020); Vietnamese-specific PLMs like PhoBERT (Nguyen and Tuan Nguyen, 2020), BARTpho-word (Tran et al., 2022), and CafeBERT (Do et al., 2024). For large language models we performed zero-shot and few-shot technical experiments with the Qwen-2.5-7b-instruct (Bai et al., 2023), Gemma-3-12b-it (Mesnard et al., 2024), and Llama-4-Scout-17B (Touvron et al., 2023) models (Appendix B presents our prompt templates). In addition, we also fine tuning with the Gemma-2-2b model to evaluate and compare with the above experiments.

All were fine-tuned on Google Colab[2] (Tesla P100) using the same hyperparameters when fine-tuning PLMs with learning_rate = 1e-5, epoch = 7, batch_size = 16. For fine-tuned LLMs, we applied 4-bit quantization and LoRA to train Gemma-2-2b with learning_rate = 1e-5, epoch =5 , batch_size = 8, lora_rank = 8, and lora_alpha = 16.

For evidence retrieval, we applied BM25 (Robertson et al., 2009) and SBERT (Reimers and Gurevych, 2019) to rank sentences by relevance and compared the top results with gold-standard evidence.

4.2 Evaluation Metrics

We use Accuracy, Precision and F1-score as the main evaluation metrics. High values of these metrics indicate that the model has a high prediction accuracy.

4.3 Experimental Results

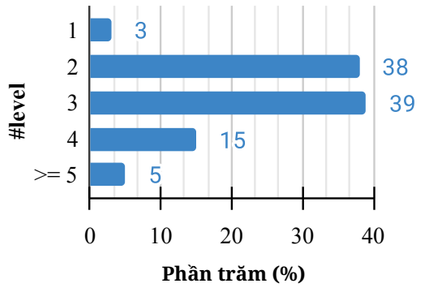
Table 6 presents the results of PLM and LLM models on the dev and test sets of the ViNum-FCR dataset. Overall, PLM models achieve high and stable performance. Among them, CafeBERT and XLM-R$_{Large}$ lead with test Accuracy and F1-score around 89–90%. Models like PhoBERT$_{Large}$ and InfoXLM also exceed 85%, demonstrating the advantage of multilingual training or specialization for Vietnamese. In contrast, SBERT$_{Base}$ and

[2]https://colab.research.google.com/

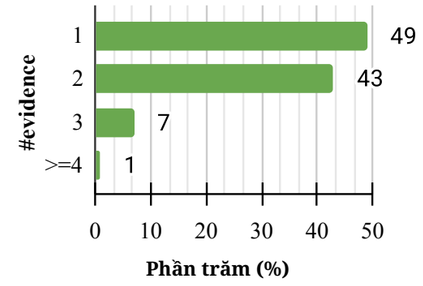
Nhãn	Jaccard (%)	LSC (%)	Tỉ lệ từ mới	Phân của lời (%)					
				Noun	Verb	Tính từ	Giới từ	Phụ trợ	Khác
Được hỗ trợ	23.72	72.92	35.58	28.35	30.16	6.93	9.04	9.61	15.91
Bác bỏ	19.76	70.12	43.99	25.62	25.92	7.27	9.36	8.41	23.42
Không đủ thông tin	15.74	67.41	54.27	31.11	26.31	7.47	8.73	9.48	16.90

Bảng 5: Sự trùng lặp từ và tỷ lệ từ mới giữa đoạn tiền đề và tuyên bố.

39,11%.



Hình 5: Phân bố các mức độ sâu của cây cú pháp.



Hình 6: Tỷ lệ các câu kết hợp hình thành bằng chứng.

Bằng chứng: Trong giai đoạn xây dựng dữ liệu, sau khi hoàn thành các tuyên bố, các người chú thích sẽ tìm kiếm bằng chứng để hỗ trợ các tuyên bố cho các nhãn Hỗ trợ và Phủ định. Hình 6 minh họa tỷ lệ câu được sử dụng để hình thành bằng chứng. Theo đó, 49% bằng chứng chỉ bao gồm một câu, cho thấy đây là phương pháp phổ biến nhất được các người chú thích áp dụng. Ngoài ra, tỷ lệ sử dụng hai câu làm bằng chứng là 43%, trong khi bằng chứng sử dụng ba câu trở lên chiếm 8%.

4 Thí nghiệm và Đánh giá

4.1 Mô hình cơ sở và Thiết lập Thí nghiệm

Để đánh giá ViNumFCR, chúng tôi đã thử nghiệm với một loạt các mô hình, bao gồm cả đa ngôn ngữ Các PLM như mBERT (Devlin và cộng sự, 2019), SBERT (Reimers và Gurevych, 2019), và XLM-R (Conneau và cộng sự, 2020); các PLM đặc thù cho tiếng Việt như PhoBERT (Nguyen và Tuan Nguyen, 2020), BARTpho-word (Tran và cộng sự, 2022), và CafeBERT (Do và cộng sự, 2024). Đối với các mô hình ngôn ngữ lớn, chúng tôi đã thực hiện các thí nghiệm kỹ thuật zero-shot và few-shot với các mô hình Qwen-2.5-7b-instruct (Bai và cộng sự, 2023), Gemma-3-12b-it (Mesnard và cộng sự, 2024), và Llama-4-Scout-17B (Touvron và cộng sự, 2023) (Phụ lục B trình bày các mẫu prompt của chúng t ôi). Ngoài ra, chúng tôi cũng tiến hành fine-tuning với mô hình Gemma-2-2b để đánh giá và so sánh với các thí nghiệm trên.

Tất cả đều được tinh chỉnh trên Google Colab[2] (Tesla P100) sử dụng cùng một siêu tha m số khi tinh chỉnh PLM với tốc độ học_ = 1e-5, số vòng lặp = 7, kích thước lô_ = 16. Đối với các LLM được tinh chỉnh, chúng tôi áp dụng lượng tử hóa 4-bit và LoRA để đào tạo Gemma-2-2b với tốc độ học_ = 1e-5, số vòng lặp =5, kích t hước lô _ =8, hạng lora_ = 8, và alpha lora_ = 16.

Đối với việc truy xuất bằng chứng, chúng tôi đã áp dụng BM25 (Robertson và cộng sự, 2009) và SBERT (Reimers và Gurevych, 2019) để xếp hạng các câu theo mức độ liên quan và so sánh các kết quả hàng đầu với bằng chứng tiêu chuẩn vàng.

4.2 Các chỉ số đánh giá

Chúng tôi sử dụng Độ chính xác, Độ tinh và chỉ số F1 làm các chỉ số đánh giá chính. Các giá trị cao của những chỉ số này cho thấy mô hình có độ chính xác dự đoán cao.

4.3 Kết quả thí nghiệm

Bảng 6 trình bày kết quả của các mô hình PLM và LLM trên tập phát triển (dev) và tập kiểm tra (test) của bộ dữ liệu ViNum-FCR. Nhìn chung, các mô hình PLM đạt được hiệu suất cao và ổn định. Tro ng số đó, CafeBERT và XLM-R$_{Large}$ dẫn đầu với độ chính xác (Accuracy) và điểm F1 (F1-score) trên t ập test khoảng 89–90%. Các mô hình như PhoBERT $_{Large}$ và InfoXLM cũng vượt quá 85%, cho thấy lợi thế của việc đào tạo đa ngôn ngữ hoặc chuyên biệt hóa cho tiếng Việt. Ngược lại, SBERT$_{Base}$ và

[2]https://colab.research.google.com/

	Models	Dev		Test	
		Acc	F1-score	Acc	F1-score
	Fine-tuning				
PLM	mBERT	84.78	84.78	83.48	83.43
	SBERT$_{Base}$	76.68	76.64	75.82	75.67
	SBERT$_{Large}$	78.98	78.99	77.41	77.40
	InfoXLM	86.09	86.07	85.07	85.00
	PhoBERT$_{Base}$	85.39	85.38	85.27	85.26
	PhoBERT$_{Large}$	88.69	88.70	87.56	87.56
	XLM-R$_{Base}$	84.88	84.85	84.68	84.67
	XLM-R$_{Large}$	90.09	90.09	**90.05**	**90.06**
	CafeBERT	**90.89**	**90.89**	89.35	89.35
	BARTpho	85.59	85.57	85.67	85.65
	Zero-shot Prompting				
LLM	**Qwen-2.5**	**44.84**	**42.41**	**45.87**	**43.96**
	Gemma-3	42.74	38.52	43.68	40.25
	Llama-4	43.14	41.6	42.59	40.78
	Few-shot Prompting				
	Qwen-2.5	36.84	37.88	37.71	38.72
	Gemma-3	**42.84**	**41.23**	**41.79**	**40.54**
	Llama-4	41.24	39.96	40.52	38.84
	Fine-tuning				
	Gemma-2	90.69	90.69	88.96	88.95

Table 6: The Performance of Models on the Dev and Test Set of the ViNumFCR Dataset.

Models	Dynamic k		
	Precision	Recall	F1-score
SBERT	92.20	78.78	84.96
BM25	**97.40**	**90.47**	**99.80**
TFIDF	94.27	77.86	85.28
SBERT + BM25	**97.40**	**88.89**	**92.95**

Table 7: Evidence Retrieval Performance on the ViNumFCR Dataset.

Models	Precision@k			
	K=1	K=2	K=3	K=4
SBERT	79.86	86.26	89.47	92.18
BM25	**93.40**	**94.08**	**95.30**	**95.88**
TFIDF	68.32	79.04	84.62	94.81
SBERT + BM25	**93.34**	**94.07**	**95.29**	**95.88**

Table 8: Precision@K on ViNumFCR for K=1–4 Evidence Sentences.

5 Result Analysis

SBERT$_{Large}$ only achieve about 75–78%, reflecting the limitations of non-specialized models.

The performance of LLMs is noticeably lower. In the zero-shot setting, the best model (Qwen-2.5-7b-instruct) reaches only around 45% Accuracy; other models range around 40–43%. In the few-shot setting, the results improve slightly but remain low, with the highest Accuracy around 41.79%.

In summary, PLMs – especially those trained specifically for Vietnamese or multilingual tasks – outperform LLMs on this task.

For the prediction of evidence, we evaluated the data set using a dynamically selected k (ranging from 1 to 4), where k represents the number of relevant top sentences automatically recovered based on each instance. Table 7 shows that SBERT + BM25 achieved strong performance (precision 97.4%, recall 88.89%, F1-score 92.95%). BM25 individually also performed well, with very high F1-score (99.8%). SBERT and TFIDF had lower recall but still maintained good precision.

Finally, Table 8 reports precision@k on the dataset for fixed values of K = 1–4. SBERT + BM25 and BM25 consistently achieved high precision (above 93% up to 95.88%), showing stable performance. SBERT started lower at K=1 (79.86%) but improved as k increased. TFIDF had the lowest precision at K=1 (68.32%) but increased significantly to 94.81% at K=4.

To better understand the impact of various aspects on performance outcomes, we conducted an analysis on the three models with the highest performance results: PhoBERT$_{Large}$, CafeBERT, mBERT, Gemma and XLM-R$_{Large}$.

Length affects model performance: The impact of text length on model performance on the Dev set for CafeBERT, PhoBERT$_{Large}$, mBERT, Gemma and XLM-R$_{Large}$ is illustrated in Figure 7. When analyzing the combined length of the premise paragraph and the claim, the XLM-R$_{Large}$ and CafeBERT models achieve the best performance when the total length exceeds 150 words. In contrast, the performance of mBERT and Gemma drops significantly when the total length exceeds 150 words. Meanwhile, PhoBERT$_{Large}$ maintains relatively stable accuracy across different length ranges.

Word overlap affects model performance: We analyzed the impact of the Jaccard index on model accuracy similarly to that on the ViNLI dataset (Van Huynh et al., 2022). The performance analysis on the Dev set, as shown in Figure 8, indicates that the mBERT model achieves the lowest accuracy when the Jaccard index falls within the 20% to

Mô hình	Dev		Test	
	Acc	Điểm F1	Acc	Điểm F1
	Tinh chỉnh			
PLM	mBERT	84.78	84.78	83.48	83.43
	SBERT$_{Base}$	76.68	76.64	75.82	75.67
	SBERT$_{Large}$	78.98	78.99	77.41	77.40
	InfoXLM	86.09	86.07	85.07	85.00
	PhoBERT$_{Base}$	85.39	85.38	85.27	85.26
	PhoBERT$_{Large}$	88.69	88.70	87.56	87.56
	XLM-R$_{Base}$	84.88	84.85	84.68	84.67
	XLM-R$_{Large}$	90.09	90.09	**90.05**	**90.06**
	CafeBERT	**90.89**	**90.89**	89.35	89.35
	BARTpho	85.59	85.57	85.67	85.65
	Gợi ý không cần huấn luyện trước				
LLM	**Qwen-2.5**	**44.84**	**42.41**	**45.87**	**43.96**
	Gemma-3	42.74	38.52	43.68	40.25
	Llama-4	43.14	41.6	42.59	40.78
	Gợi ý ít ví dụ				
	Qwen-2.5	36.84	37.88	37.71	38.72
	Gemma-3	**42.84**	**41.23**	**41.79**	**40.54**
	Llama-4	41.24	39.96	40.52	38.84
	Tinh chỉnh				
	Gemma-2	90.69	90.69	88.96	88.95

Bảng 6: Hiệu suất của các mô hình trên tập Dev và Test của bộ dữ liệu ViNumFCR.

Mô hình	Động k		
	Độ chính xác	Nhắc lại	Điểm F1
SBERT	92.20	78.78	84.96
BM25	**97.40**	**90.47**	**99.80**
TFIDF	94.27	77.86	85.28
SBERT + BM25	**97.40**	**88.89**	**92.95**

Bảng 7: Hiệu suất Truy xuất Bằng chứng trên Bộ dữ liệu ViNumFCR.

Mô hình	Độ chính xác@k			
	K=1	K=2	K=3	K=4
SBERT	79.86	86.26	89.47	92.18
BM25	**93.40**	**94.08**	**95.30**	**95.88**
TFIDF	68.32	79.04	84.62	94.81
SBERT + BM25	**93.34**	**94.07**	**95.29**	**95.88**

Bảng 8: Độ chính xác@K trên ViNumFCR cho K =1–4 Câu chứng cứ.

5 Phân Tích Kết Quả

SBERT$_{Large}$ chỉ đạt khoảng 75–78%, phản ánh những hạn chế của các mô hình không chuyên dụng.

Hiệu suất của các mô hình ngôn ngữ lớn (LLMs) thấp hơn đáng kể. Trong bối cảnh zero-shot, mô hình tốt nhất (Qwen-2.5-7b-instruct) chỉ đạt khoảng 45% độ chính xác; các mô hình khác dao động khoảng 40–43%. Trong bối cảnh few-shot, kết quả cải thiện chút ít nhưng vẫn thấp, với độ chính xác cao nhất khoảng 41,79%.

Tóm lại, PLM – đặc biệt là những mô hình được huấn luyện riêng cho các nhiệm vụ tiếng Việt hoặc đa ngôn ngữ – vượt trội hơn LLM trong nhiệm vụ này.

Đối với việc dự đoán bằng chứng, chúng tôi đã đánh giá bộ dữ liệu bằng cách sử dụng một k được chọn động (dao động từ 1 đến 4), trong đó k đại diện cho số lượng câu chính liên quan được tự động phục hồi dựa trên từng trường hợp. Bảng 7 cho thấy SBERT+ BM25 đạt hiệu suất cao (độ chính xác 97,4%, độ thu hồi 88,89%, điểm F1 92,95%). BM25 riêng lẻ cũng hoạt động tốt, với điểm F1 rất cao (99,8%). SBERT và TFIDF có độ thu hồi thấp hơn nhưng vẫn duy trì độ chính xác tốt.

Cuối cùng, Bảng 8 báo cáo độ chính xác@k trên tập dữ liệu cho các giá trị cố định của K = 1–4. SBERT +BM25 và BM25 liên tục đạt độ chính xác cao (trên 93% đến 95,88%), cho thấy sự ổn định

Để hiểu rõ hơn về tác động của các khía cạnh khác nhau đối với kết quả hiệu suất, chúng tôi đã tiến hành phân tích trên ba mô hình có kết quả hiệu suất cao nhất: PhoBERT$_{Large}$, CafeBERT, mBERT, Gemma và XLM-R$_{Large}$.

Độ dài ảnh hưởng đến hiệu suất mô hình: Ảnh hưởng của độ dài văn bản đến hiệu suất mô hình trên tập Dev đối với CafeBERT, PhoBERT$_{Large}$, mBERT, Gemma và XLM-R$_{Large}$ được minh họa trong Hình 7. Khi phân tích tổng độ dài của đoạn mở đầu và tuyên bố, các mô hình XLM-R$_{Large}$ và CafeBERT đạt hiệu suất tốt nhất khi tổng độ dài vượt quá 150 từ. Ngược lại, hiệu suất của mBERT và Gemma giảm đáng kể khi tổng độ dài vượt quá 150 từ. Trong khi đó, PhoBERT$_{Large}$ duy trì độ chính xác tương đối ổn định trên các khoảng độ dài khác nhau.

Sự trùng lặp từ ảnh hưởng đến hiệu suất mô hình: Chúng tôi đã phân tích tác động của chỉ số Jaccard đối với độ chính xác của mô hình tương tự như trên bộ dữ liệu ViNLI (Van Huynh et al., 2022). Phân tích hiệu suất trên tập Dev, như được thể hiện trong Hình 8, cho thấy mô hình mBERT đạt độ chính xác thấp nhất khi chỉ số Jaccard nằm trong khoảng 20% đến

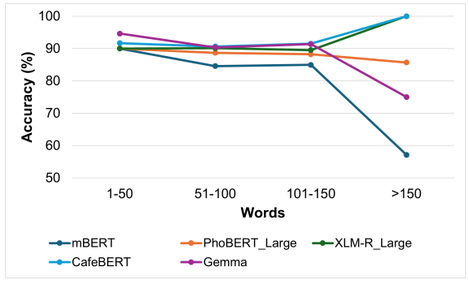


Figure 7: Model Performance by Length on the Dev Set.

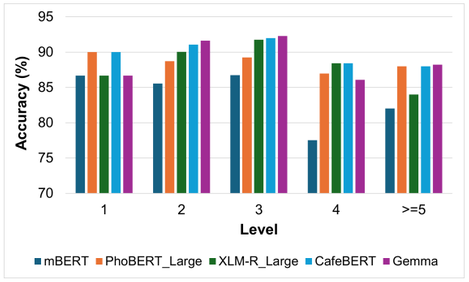


Figure 9: Model Performance by Syntax Tree Index on the Dev Set.

30% range. When the Jaccard index exceeds 50%, the performance of mBERT continues to decline, with an even more pronounced drop observed in the PhoBERT$_{Large}$ model. In contrast, within the same Jaccard range, the XLM-R$_{Large}$, CafeBERT, and Gemma models achieve the highest accuracy.

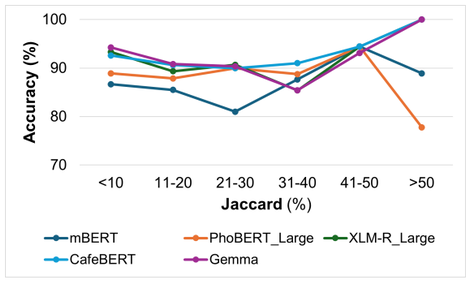


Figure 8: Model Performance by Jaccard Index on the Dev Set.

Syntax tree affects model performance: The impact of the syntactic tree level on model performance on the Dev set is illustrated in Figure 9. The mBERT, CafeBERT, Gemma, and XLM-R$_{Large}$ models achieve the highest performance when the syntactic tree level is 3. However, the PhoBERT$_{Large}$ model performs best when the tree level is only 1. Furthermore, as the tree level increases from 4 onward, the performance of all models tends to decline, with the most noticeable drop observed in the mBERT model when the level reaches 4.

Topic affects model performance: The analysis of topic influence on model performance, as shown in Table 9, indicates that the Education and Entertainment topics pose significant challenges for the models, with generally lower accuracy compared to other topics. In contrast, topics such as Business and News yield high and consistent performance across most models. Additionally, both CafeBERT and Gemma demonstrate relatively high performance across all topics.

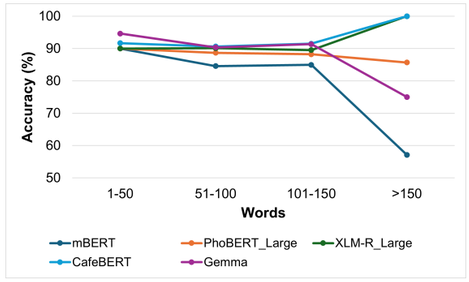
Topic / Model	XLM-R$_{Large}$	mBERT	CafeBERT	PhoBERT$_{Large}$	Gemma
Digital	93.68	84.21	93.68	**93.68**	88.75
Tourism	91.89	87.84	91.89	90.54	88.16
Education	78.95	75.44	82.46	85.96	91.23
Entertainment	76.92	74.36	82.05	79.49	90.24
Science	80.36	78.57	89.29	85.71	86.89
Business	**94.05**	84.52	**94.05**	90.48	91.11
Law	93.33	88.57	92.38	87.62	91.54
Health	90.72	85.57	89.69	88.66	90.91
World	88.89	83.95	90.12	86.42	**95.12**
Sports	91.89	83.78	91.89	89.19	93.75
News	90.28	**88.89**	90.28	91.67	91.43
Cars	91.67	86.67	93.33	90.00	85.19

Table 9: Model performance across different topics.

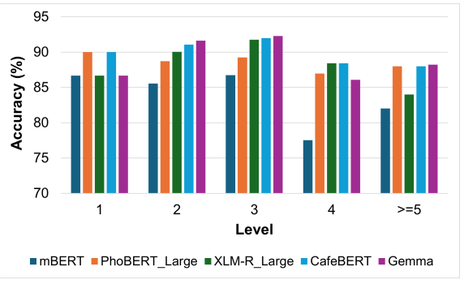
6 Conclusion and Future Work

This paper introduces the ViNumFCR dataset, a pioneering benchmark for numerical reasoning fact-checking in Vietnamese, comprising over 10,000 claims by a rigorous annotation process. We assessed advanced language models including PLMs, LLMs, revealing that models such as XLM-R$_{Large}$ and CafeBERT achieved significant accuracy. However, we observed that zero-shot and few-shot techniques with Qwen, LLama, and Gemma models for reasoning and generating predictions proved ineffective, highlighting the unique challenges posed by this dataset. These findings emphasize ViNumFCR's role as a robust resource for real-world applications and the advancement of Vietnamese NLP research, particularly in managing numerical data on social media.

Looking ahead, we intend to enrich the dataset by increasing its scale and diversity through expanded data collection and thorough cleaning procedures. We plan to explore fine-tuning techniques on alternative machine learning models, especially large language models, to further enhance perfor-

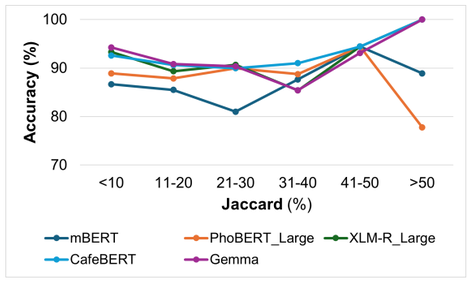


Hình 7: Hiệu suất mô hình theo độ dài trên tập Dev.



Hình 9: Hiệu suất mô hình theo chỉ số cây cú pháp trên tập phát triển.

Phạm vi 30%. Khi chỉ số Jaccard vượt quá 50%, hiệu suất của mBERT tiếp tục giảm, với mức giảm rõ rệt hơn quan sát thấy ở mô hình PhoBERT^{Large} . Ngược lại, trong cùng phạm vi Jaccard, các mô hình XLM-R^{Large}, CafeBERT và Gemma đạt được độ chính xác cao nhất.



Hình 8: Hiệu suất Mô hình theo Chỉ số Jaccard trên Bộ Dữ liệu Dev.

Cây cú pháp ảnh hưởng đến hiệu suất mô hình: Ảnh hưởng của mức độ cây cú pháp đến hiệu suất của mô hình trên tập Dev được minh họa trong Hình 9. Các mô hình mBERT, CafeBERT, Gemma và XLM-R^{Large} đạt hiệu suất cao nhất khi mức độ cây cú pháp là 3. Tuy nhiên, mô hình PhoBERT^{Large} lại đạt hiệu suất tốt nhất khi mức độ cây chỉ là 1. Hơn nữa, khi mức độ cây tăng từ 4 trở đi, hiệu suất của tất cả các mô hình có xu hướng giảm, với sự giảm đáng chú ý nhất được quan sát ở mô hình mBERT khi mức độ đạt 4.

Chủ đề ảnh hưởng đến hiệu suất mô hình: Phân tích ảnh hưởng của chủ đề đối với hiệu suất mô hình, như được trình bày trong Bảng 9, cho thấy các chủ đề Giáo dục và Giải trí gây ra những thách thức đáng kể đối với các mô hình, với độ chính xác nói chung thấp hơn so với các chủ đề khác. Ngược lại, các chủ đề như Kinh doanh và Tin tức mang lại hiệu suất cao và ổn định.

hiệu suất trên hầu hết các mô hình. Ngoài ra, cả CafeBERT và Gemma đều thể hiện hiệu suất tương đối cao trên tất cả các chủ đề.

Chủ đề / Mô hình	XLM-R^{Large}	mBERT	CafeBERT	PhoBERT^{Large}	Gemma
Kỹ thuật số	93.68	84,21	93,68	93,68	88.75
Du lịch	91.89	87.84	91.89	90.54	88.16
Giáo dục	78.95	75.44	82.46	85.96	91.23
Giải trí	76.92	74.36	82.05	79.49	90.24
Khoa học	80.36	78.57	89.29	85.71	86.89
Kinh doanh	**94.05**	84.52	**94.05**	90.48	91.11
Law	93.33	88.57	92.38	87.62	91.54
Sức khỏe	90.72	85.57	89.69	88.66	90.91
Thế giới	88.89	83.95	90.12	86.42	**95.12**
Thể thao	91.89	83.78	91.89	89.19	93.75
News	90.28	**88.89**	90.28	91.67	91.43
Cars	91.67	86.67	93.33	90.00	85.19

Bảng 9: Hiệu suất mô hình trên các chủ đề khác nhau.

6 Kết luận và Công việc Tương lai

Bài báo này giới thiệu bộ dữ liệu ViNumFCR, một chuẩn mực tiên phong cho việc kiểm tra sự thật dựa trên lý luận số liệu bằng tiếng Việt, bao gồm hơn 10.000 tuyên bố thông qua một quy trình chú thích nghiêm ngặt. Chúng tôi đã đánh giá các mô hình ngôn ngữ tiên tiến bao gồm PLMs, LLMs, cho thấy các mô hình như XLM-R^{Large} và CafeBERT đạt được độ chính xác đáng kể. Tuy nhiên, chúng tôi quan sát thấy rằng các kỹ thuật zero-shot và few-shot với các mô hình Qwen, LLama và Gemma để lập luận và tạo dự đoán tỏ ra không hiệu quả, nhấn mạnh những thách thức đặc thù mà bộ dữ liệu này đặt ra. Những phát hiện này nhấn mạnh vai trò của ViNumFCR như một nguồn tài nguyên mạnh mẽ cho các ứng dụng thực tiễn và sự phát triển của nghiên cứu NLP tiếng Việt, đặc biệt trong việc quản lý dữ liệu số trên mạng xã hội.

Nhìn về phía trước, chúng tôi dự định làm phong phú bộ dữ liệu bằng cách tăng quy mô và sự đa dạng thông qua việc mở rộng thu thập dữ liệu và các quy trình làm sạch kỹ lưỡng. Chúng tôi dự định khám phá các kỹ thuật tinh chỉnh trên các mô hình học máy thay thế, đặc biệt là các mô hình ngôn ngữ lớn, nhằm nâng cao hiệu suất hơn nữa.

mance, particularly for complex fact-checking samples. Moreover, we will tackle current limitations by improving models' ability to process longer and more intricate text passages, thereby boosting the system's reliability for real-world news verification deployments.

Acknowledgements

This research is funded by Vietnam National University HoChiMinh City (VNU-HCM) under grant number DS.C2025-26-10.

References

Josh Achiam, Steven Adler, Sandhini Agarwal, Lama Ahmad, Ilge Akkaya, Florencia Leoni Aleman, Diogo Almeida, Janko Altenschmidt, Sam Altman, Shyamal Anadkat, et al. 2023. Gpt-4 technical report. *arXiv preprint arXiv:2303.08774*.

Rami Aly, Zhijiang Guo, Michael Sejr Schlichtkrull, James Thorne, Andreas Vlachos, Christos Christodoulopoulos, Oana Cocarascu, and Arpit Mittal. 2021. The fact extraction and VERification over unstructured and structured information (FEVEROUS) shared task. In *Proceedings of the Fourth Workshop on Fact Extraction and VERification (FEVER)*, pages 1–13, Dominican Republic. Association for Computational Linguistics.

Jinze Bai, Shuai Bai, Yunfei Chu, Zeyu Cui, Kai Dang, Xiaodong Deng, Yang Fan, Wenbin Ge, Yu Han, Fei Huang, et al. 2023. Qwen technical report. *arXiv preprint arXiv:2309.16609*.

Zewen Chi, Li Dong, Furu Wei, Nan Yang, Saksham Singhal, Wenhui Wang, Xia Song, Xian-Ling Mao, Heyan Huang, and Ming Zhou. 2021. InfoXLM: An information-theoretic framework for cross-lingual language model pre-training. In *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, pages 3576–3588, Online. Association for Computational Linguistics.

Jacob Cohen. 1960. A coefficient of agreement for nominal scales. *Educational and psychological measurement*, 20(1):37–46.

Alexis Conneau, Kartikay Khandelwal, Naman Goyal, Vishrav Chaudhary, Guillaume Wenzek, Francisco Guzmán, Edouard Grave, Myle Ott, Luke Zettlemoyer, and Veselin Stoyanov. 2020. Unsupervised cross-lingual representation learning at scale. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 8440–8451, Online. Association for Computational Linguistics.

Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. 2019. BERT: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*, pages 4171–4186, Minneapolis, Minnesota. Association for Computational Linguistics.

Phong Nguyen-Thuan Do, Son Quoc Tran, Phu Gia Hoang, Kiet Van Nguyen, and Ngan Luu-Thuy Nguyen. 2024. VLUE: A new benchmark and multi-task knowledge transfer learning for Vietnamese natural language understanding. In *Findings of the Association for Computational Linguistics: NAACL 2024*, pages 211–222, Mexico City, Mexico. Association for Computational Linguistics.

Tran Thai Hoa, Tran Quang Duy, Khanh Quoc Tran, and Kiet Van Nguyen. 2025. Vifactcheck: A new benchmark dataset and methods for multi-domain news fact-checking in vietnamese. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 39, pages 308–316.

Sepp Hochreiter and Jürgen Schmidhuber. 1997. Long short-term memory. *Neural Computation*, 9(8):1735–1780.

Tin Van Huynh, Kiet Van Nguyen, and Ngan Luu-Thuy Nguyen. 2022. ViNLI: A Vietnamese corpus for studies on open-domain natural language inference. In *Proceedings of the 29th International Conference on Computational Linguistics*, pages 3858–3872, Gyeongju, Republic of Korea. International Committee on Computational Linguistics.

Hung Tuan Le, Long Truong To, Manh Trong Nguyen, and Kiet Van Nguyen. 2024. Viwikifc: Fact-checking for vietnamese wikipedia-based textual knowledge source. *arXiv preprint arXiv:2405.07615*.

Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, and Veselin Stoyanov. 2019. Roberta: A robustly optimized bert pretraining approach. *arXiv preprint arXiv:1907.11692*.

Alessia Mammone, Marco Turchi, and Nello Cristianini. 2009. Support vector machines. *Wiley Interdisciplinary Reviews: Computational Statistics*, 1(3):283–289.

Thomas Mesnard, Cassidy Hardin, Robert Dadashi, Surya Bhupatiraju, Shreya Pathak, Laurent Sifre, Morgane Rivière, Mihir Sanjay Kale, Juliette Love, Pouya Tafti, et al. 2024. Gemma: Open models based on gemini research and technology. *CoRR*.

Dat Quoc Nguyen and Anh Tuan Nguyen. 2020. PhoBERT: Pre-trained language models for Vietnamese. In *Findings of the Association for Computational Linguistics: EMNLP 2020*, pages 1037–1042, Online. Association for Computational Linguistics.

hiệu suất, đặc biệt là đối với các mẫu kiểm tra sự thật phức tạp. Hơn nữa, chúng tôi sẽ giải quyết các hạn chế hiện tại bằng cách cải thiện khả năng của các mô hình trong việc xử lý các đoạn văn bản dài và phức tạp hơn, từ đó tăng độ tin cậy của hệ t hống cho việc triển khai xác minh tin tức trong thực tế.

Lời cảm ơn

Nghiên cứu này được tài trợ bởi Đại học Quốc gia Việt Nam Thành phố Hồ Chí Minh (VNU-HCM) theo số tài trợ DS.C2025-26-10.

Tài liệu tham khảo

Josh Achiam, Steven Adler, Sandhini Agarwal, Lama Ahmad, Ilge Akkaya, Florencia Leoni Aleman, Diogo Almeida, Janko Altenschmidt, Sam Altman, Shyamal Anadkat, và những người khác. 2023. Báo cáo kỹ thuật Gpt-4. Bản in trước arXiv arXiv:2303.08774.

Rami Aly, Zhijiang Guo, Michael Sejr Schlichtkrull, James Thorne, Andreas Vlachos, Christos Christodoulopoulos, Oana Cocarascu và Arpit Mittal. 2021. Bài toán chia sẻ Trích xuất sự kiện và XÁC minh thông tin từ thông tin không cấu trúc và có cấu trúc (FEVEROUS). Trong Kỷ yếu của Hội thảo lần thứ tư về Trích xuất sự kiện và Xác minh (FEVER), trang 1–13, Cộng hòa Dominican. Hiệp hội Ngôn ngữ học Máy tính.

Jinze Bai, Shuai Bai, Yunfei Chu, Zeyu Cui, Kai Dang, Xiaodong Deng, Yang Fan, Wenbin Ge, YuHan, Fei Huang, và cộng sự. 2023. Báo cáo kỹ thuật Qwen. arXiv preprint arXiv:2309.16609.

Zewen Chi, Li Dong, Furu Wei, Nan Yang, Saksham Singhal, Wenhui Wang, Xia Song, Xian-Ling Mao, Heyan Huang, và Ming Zhou. 2021. InfoXLM: Một khuôn khổ lý thuyết thông tin cho việc tiền huấn luyện mô hình ngôn ngữ đa ngôn ngữ. Trong Kỷ yếu Hội nghị 2021 của Chi nhánh Bắc Mỹ Hiệp hội Ngôn ngữ học Máy tính: Công nghệ Ngôn ngữ Con người, trang 3576–3588, Trực tuyến. Hiệp hội Ngôn ngữ học Máy tính.

Jacob Cohen. 1960. Hệ số thoả thuận cho thang đo danh nghĩa. Đo lường giáo dục và tâm lý học, 20(1):37–46.

Alexis Conneau, Kartikay Khandelwal, Naman Goyal, Vishrav Chaudhary, Guillaume Wenzek, Francisco Guzmán, Edouard Grave, Myle Ott, Luke Zettlemoyer, và Veselin Stoyanov. 2020. Học biểu diễn liên ngôn ngữ không giám sát ở quy mô lớn. Trong Kỷ yếu Hội nghị lần thứ 58 của Hiệp hội Ngôn ngữ Học Máy Tính, trang 8440–8451, Trực tuyến. Hiệp hội Ngôn ngữ Học Máy Tính.

Jacob Devlin, Ming-Wei Chang, Kenton Lee, và Kristina Toutanova. 2019. BERT: Huấn luyện trước của *các bộ biến áp hai chiều sâu cho hiểu ngôn ngữ. Trong Kỷ yếu Hội nghị năm 2019 của Chương Bắc Mỹ của Hiệp hội Ngôn ngữ học Máy tính: Công nghệ Ngôn ngữ Con người, Tập 1 (Bài báo Dài và Ngắn), các trang 4171–4186, Minneapolis, Minnesota. Hiệp hội Ngôn ngữ học Máy tính.*

Phong Nguyễn-Thuận Đỗ, Sơn Quốc Trần, Phú Gia Hoàng, Kiệt Văn Nguyễn, và Ngân Lưu-Thùy Nguyễn. 2024. VLUE: Một chuẩn mới và học chuyển giao kiến thức đa nhiệm cho hiểu ngôn ngữ tự nhiên tiếng Việt. Trong Kết quả của Hiệp hội Ngôn ngữ học Máy tính: NAACL 2024, trang 211–222, Thành phố Mexico, Mexico. Hiệp hội Ngôn ngữ học Máy tính.

Trần Thái Hòa, Trần Quang Duy, Khánh Quốc Trần và Kiệt Văn Nguyễn. 2025. Vifactcheck: Một bộ dữ liệu đánh dấu chuẩn mới và các phương pháp cho việc kiểm tra sự thật tin tức đa miền bằng tiếng Việt. Trong Kỷ yếu Hội nghị AAAI về Trí tuệ Nhân tạo, tập 39, trang 308–316.

Sepp Hochreiter và Jürgen Schmidhuber. 1997. Bộ nhớ dài ngắn hạn. Tính toán thần kinh, 9(8):1735–1780.

Tin Văn Huỳnh, Kiệt Văn Nguyễn, và Ngân Lưu-Thúy Nguyễn. 2022. ViNLI: Một tập dữ liệu tiếng Việt cho các nghiên cứu về suy luận ngôn ngữ tự nhiên miền mở. Trong Kỷ yếu Hội nghị Quốc tế lần thứ 29 về Ngôn ngữ học Tính toán, trang 3858–3872, Gyeongju, Hàn Quốc. Ủy ban Quốc tế về Ngôn ngữ học Tính toán.

Hung Tuấn Lê, Long Trường Tô, Mạnh Trọng Nguyễn, và Kiệt Văn Nguyễn. 2024. Viwikifc: Kiểm tra sự thật c ho nguồn kiến thức văn bản dựa trên Wikipedia tiếng Việt. Bản thảo arXiv arXiv:2405.07615.

Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Man-dar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer và Veselin Stoyanov. 2019. Roberta: Một phương pháp tiền huấn luyện BERT được tối ưu hóa mạnh mẽ. arXiv preprint arXiv:1907.11692.

Alessia Mammone, Marco Turchi, và Nello Cristianini. 2009. Máy vectơ hỗ trợ. Wiley Interdisciplinary Reviews: Thống kê Tính toán, 1(3):283–289.

Thomas Mesnard, Cassidy Hardin, Robert Dadashi, Surya Bhupatiraju, Shreya Pathak, Laurent Sifre, Morgane Rivière, Mihir Sanjay Kale, Juliette Love, Pouya Tafti, và cộng sự. 2024. Gemma: Mô hình mở dựa trên nghiên cứu và công nghệ Gemini. CoRR.

Đạt Quốc Nguyễn và Anh Tuấn Nguyễn. 2020. PhoBERT: Mô hình ngôn ngữ được huấn luyện trước cho tiếng Việt. Trong Kết quả của Hiệp hội Ngôn ngữ học Tính toán: EMNLP 2020, trang 1037–1042, Trực tuyến. Hiệp hội Ngôn ngữ học Tính toán.

Linh The Nguyen and Dat Quoc Nguyen. 2021. PhoNLP: A joint multi-task learning model for Vietnamese part-of-speech tagging, named entity recognition and dependency parsing. In *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies: Demonstrations*, pages 1–7, Online. Association for Computational Linguistics.

Nam Nguyen, Thang Phan, Duc-Vu Nguyen, and Kiet Nguyen. 2023. ViSoBERT: A pre-trained language model for Vietnamese social media text processing. In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, pages 5191–5207, Singapore. Association for Computational Linguistics.

Nils Reimers and Iryna Gurevych. 2019. Sentence-BERT: Sentence embeddings using Siamese BERT-networks. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 3982–3992, Hong Kong, China. Association for Computational Linguistics.

S. J. Rigatti. 2017. Random forest. *Journal of Insurance Medicine*, 47(1):31–39.

Stephen Robertson, Hugo Zaragoza, et al. 2009. The probabilistic relevance framework: Bm25 and beyond. *Foundations and Trends® in Information Retrieval*, 3(4):333–389.

Tal Schuster, Adam Fisch, and Regina Barzilay. 2021. Get your vitamin C! robust fact verification with contrastive evidence. In *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, pages 624–643, Online. Association for Computational Linguistics.

James Thorne, Andreas Vlachos, Christos Christodoulopoulos, and Arpit Mittal. 2018. FEVER: a large-scale dataset for fact extraction and VERification. In *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long Papers)*, pages 809–819, New Orleans, Louisiana. Association for Computational Linguistics.

Hugo Touvron, Thibaut Lavril, Gautier Izacard, Xavier Martinet, Marie-Anne Lachaux, Timothée Lacroix, Baptiste Rozière, Naman Goyal, Eric Hambro, Faisal Azhar, et al. 2023. Llama: Open and efficient foundation language models. *arXiv preprint arXiv:2302.13971*.

Nguyen Luong Tran, Duong Minh Le, and Dat Quoc Nguyen. 2022. BARTpho: Pre-trained Sequence-to-Sequence Models for Vietnamese. In *Proceedings of the 23rd Annual Conference of the International Speech Communication Association*.

Tin Van Huynh, Huy Quoc To, Kiet Van Nguyen, and Ngan Luu-Thuy Nguyen. 2022. Error investigation of pre-trained bertology models on vietnamese natural language inference. In *Asian Conference on Intelligent Information and Database Systems*, pages 176–188. Springer.

Thanh Vu, Dat Quoc Nguyen, Dai Quoc Nguyen, Mark Dras, and Mark Johnson. 2018. VnCoreNLP: A Vietnamese natural language processing toolkit. In *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Demonstrations*, pages 56–60, New Orleans, Louisiana. Association for Computational Linguistics.

William Yang Wang. 2017. "liar, liar pants on fire": A new benchmark dataset for fake news detection. In *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers)*, pages 422–426, Vancouver, Canada. Association for Computational Linguistics.

R. Ünal and A. Ş. Çiçeklioğlu. 2019. The function and importance of fact-checking organizations in the era of fake news: Teyit. org, an example from turkey. *Media Studies*, 10(19):140–160.

Linh Thế Nguyễn và Đạt Quốc Nguyễn. 2021. PhoNLP: Một mô hình học đa nhiệm kết hợp cho việc gán nhãn từ loại, nhận dạng thực thể có tên và phân tích phụ thuộc trong tiếng Việt. Trong Kỷ yếu Hội nghị 2021 của Hội Bắc Mỹ thuộc Hiệp hội Ngôn ngữ học Máy tính: Công nghệ Ngôn ngữ Con người: Minh họa, trang 1–7, Trực tuyến. Hiệp hội Ngôn ngữ học Máy tính.

Nam Nguyen, Thang Phan, Duc-Vu Nguyen, và Kiet Nguyen. 2023. ViSoBERT: Một mô hình ngôn ngữ được huấn luyện trước cho xử lý văn bản mạng xã hội tiếng Việt. Trong Kỷ yếu Hội nghị về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên 2023, trang 5191–5207, Singapore. Hiệp hội Ngôn ngữ Học Máy Tính.

Nils Reimers và Iryna Gurevych. 2019. Sentence-BERT: Nhúng câu sử dụng mạng BERT Siamese. Trong Kỷ yếu Hội nghị 2019 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên và Hội nghị Chung Quốc tế lần thứ 9 về Xử lý Ngôn ngữ Tự nhiên (EMNLP-IJCNLP), trang 3982–3992, Hồng Kông, Trung Quốc. Hiệp hội Ngôn ngữ học Máy tính.

S. J. Rigatti. 2017. Rừng ngẫu nhiên. Tạp chí Y học Bảo hiểm, 47(1):31–39.

Stephen Robertson, Hugo Zaragoza, và cộng sự. 2009. Khung xác suất liên quan: Bm25 và hơn thế nữa. Foundations and Trends® in Information Retrieval, 3(4):333–389.

Tal Schuster, Adam Fisch và Regina Barzilay. 2021. Hãy lấy vitamin C của bạn! Xác minh sự thật mạnh mẽ với bằng chứng đối chiếu. Trong Kỷ yếu Hội nghị 2021 của Chương Bắc Mỹ thuộc Hiệp hội Ngôn ngữ học Máy tính: Công nghệ Ngôn ngữ Con người, trang 624–643, Trực tuyến. Hiệp hội Ngôn ngữ học Máy tính.

James Thorne, Andreas Vlachos, Christos Christodoulopoulos, và Arpit Mittal. 2018. FEVER: một bộ dữ liệu quy mô lớn cho việc trích xuất và xác minh sự thật. Trong Kỷ yếu Hội nghị 2018 của Chương Bắc Mỹ Hiệp hội Ngôn ngữ học Máy tính: Công nghệ Ngôn ngữ Con người, Tập 1 (Bài báo Dài), trang 809–819, New Orleans, Louisiana. Hiệp hội Ngôn ngữ học Máy tính.

Hugo Touvron, Thibaut Lavril, Gautier Izacard, Xavier Martinet, Marie-Anne Lachaux, Timothée Lacroix, Baptiste Rozière, Naman Goyal, Eric Hambro, Faisal Azhar, và cộng sự. 2023. Llama: Mô hình ngôn ngữ nền tảng mở và hiệu quả. Bản in trước arXiv arXiv:2302.13971.

Nguyễn Lương Trần, Dương Minh Lê, và Đạt Quốc Nguyễn. 2022. BARTpho: Mô hình Chuỗi-đến-Chuỗi được Tiền huấn luyện cho tiếng Việt. Trong Kỷ yếu Hội nghị thường niên lần thứ 23 của Hiệp hội Giao tiếp Ngôn ngữ Quốc tế.

Tin Van Huynh, Huy Quoc To, Kiet Van Nguyen, và Ngan Luu-Thuy Nguyen. 2022. Điều tra lỗi của các mô hình bertology được tiền huấn luyện trên suy diễn ngôn ngữ tự nhiên tiếng Việt. Trong Hội nghị Châu Á về Hệ thống Thông tin và Cơ sở Dữ liệu Thông minh, trang 176–188. Springer.

Thanh Vũ, Đạt Quốc Nguyễn, Đại Quốc Nguyễn, Mark Dras, và Mark Johnson. 2018. VnCoreNLP: Bộ công cụ xử lý ngôn ngữ tự nhiên tiếng Việt. Trong Kỷ yếu Hội nghị 2018 của Hiệp hội Ngôn ngữ học Máy tính Bắc Mỹ: Trình diễn, trang 56–60, New Orleans, Louisiana. Hiệp hội Ngôn ngữ học Máy tí nh.

William Yang Wang. 2017. "Kẻ nói dối, kẻ nói dối quần đang cháy": Một bộ dữ liệu chuẩn mới cho phát hiện tin giả. Trong Kỷ yếu cuộc họp thường niên lần thứ 55 của Hiệp hội Ngôn ngữ học Máy tính (Tập 2: Bài báo ngắn), trang 422–426, Vancouver, Canada. Hiệp hội Ngôn ngữ học Máy tính.

R. Unal và A. S. Cicekliogl u. 2019. Chức năng và tầm quan trọng của các tổ chức kiểm chứng sự thật trong thời đại tin giả: Teyit.org, một ví dụ từ Thổ Nhĩ Kỳ. Nghiên cứu Truyền thông, 10(19):140–160.

A Data-Generation Rules

No.	Rule	Example
1	Change the sentence structure from active to passive and vice versa.	P: Một con mèo đang chơi với cuộn len. (A cat is playing with a ball of yarn.) C: Cuộn len đang bị một con mèo chơi. (The ball of yarn is being played with by a cat.)
2	Replace with synonyms or similar words.	P: Tôi đi siêu thị mua thực phẩm. (I went to the supermarket to buy groceries.) C: Tôi đi siêu thị mua đồ ăn. (I went to the supermarket to buy food.)
3	Add or remove modifiers while retaining the original meaning of the sentence.	P: Cô giáo 23 tuổi xinh đẹp đang dạy tiếng Anh. (The beautiful 23-year-old teacher is teaching English.) C: Cô giáo 23 tuổi đang dạy tiếng Anh. (The 23-year-old teacher is teaching English.)
4	Replace representative nouns with relative clauses.	P: Một cầu thủ đá bóng nam đang sút bóng vào khung thành. (A male soccer player is kicking the ball into the goal.) C: Người đàn ông, cái người mà chơi bóng đá đang sút một quả bóng vào khung thành. (The man, who plays soccer, is kicking a ball into the goal.)
5	Replace the object with a relative clause.	P: Người phụ nữ đang dùng một chiếc máy may. (The woman is using a sewing machine.) C: Người phụ nữ đang sử dụng một chiếc máy được sản xuất để may. (The woman is using a machine made for sewing.)
6	Replace the adjective with a relative clause.	P: Hai người đàn ông đang nghỉ ngơi sau một chuyến đi trên con đường tuyết. (Two men are resting after a trip on a snowy road.) C: Hai người đàn ông đang nghỉ ngơi sau một chuyến đi trên con đường mà nó được phủ đầy tuyết. (Two men are resting after a trip on a road that is covered with snow.)
7	Replace the quantity terms with equivalent ones.	P: Vài người đang lướt sóng trên một con sóng lớn. (Several people are surfing on a big wave.) C: Một số người đang lướt sóng trên một con sóng lớn. (Some people are surfing on a big wave.)
8	Generate a presupposition sentence.	P: Tôi đã lạc mất con mèo duy nhất của tôi vào sáng nay. (I lost my only cat this morning.) C: Tôi có một con mèo. (I have a cat.)
9	Others.	

Table 10: Examples of Rules for Creating Premise Paragraph (P) - Claim (C) Pairs for the Supported Label.

Các Quy tắc Tạo Dữ liệu

No.	Rule	Ví dụ
1	Thay đổi câu- câu cấu trúc from hoạt động to thụ động và tệ nạn ngược lại.	P: Một con mèo đang chơi với một cuộn len. C: Cuộn len đang được một con mèo chơi. bởi một con mèo.)
2	Thay bằng syn- từ đồng nghĩa hoặc tương t ự từ.	P: Tôi đi siêu thị mua thực phẩm. C: Tôi đi siêu thị để mua thực phẩm.
3	Thêm hoặc xóa bộ điều chỉnh trong khi giữ nguyên bản gốc ý nghĩa cuối cùng của câu .	P: Cô giáo 23 tuổi xinh đẹp đang dạy tiếng Anh. (Cô gái đẹp 23 tuổi giáo viên đang dạy tiếng Anh.) C: Cô giáo 23 tuổi đang dạy tiếng Anh. Tiếng Anh.)
4	Thay thế đại diện danh từ tative với mệnh đề quan hệ	P: Một cầu thủ bóng đá nam đang sút bóng vào khung thành. cầu thủ đang đá bóng vào khung thành. C: The man, the one who is playing football, is kicking a ball into the goal người đàn ông, người chơi bóng đá, đang đá một quả bóng vào khung thành.
5	Thay thế ob- ản với một rela- mệnh đề phụ thuộc.	P: Người phụ nữ đang dùng một chiếc máy may. máy. C: Người phụ nữ đang sử dụng một chiếc máy được sản xuất để may. người phụ nữ đang sử dụng một chiếc máy được làm để may.
6	Thay thế quảng cáo- jective với một rel- mệnh đề quan hệ	P: Two men are resting after a trip on the snowy road. (Hai người đàn ông đang nghỉ ngơi sau một chuyến đi trên con đường đầy tuyết.) C: Two men are resting after a trip on the road that it được phủ đầy tuyết. (Hai người đàn ông đang nghỉ ngơi sau một chuyến đi trên con đường được phủ đầy tuyết với tuyết.)
7	Thay thế quan- điều khoản về tính hợp pháp với những cái tương đương.	P: Vài người đang lướt sóng trên một con sóng lớn. (Một vài người đang lướt sóng) trên một con sóng lớn.) C: Một số người đang lướt sóng trên một con sóng lớn. (Some people are) lướt sóng trên một con sóng lớn.)
8	Tạo trước giả định sen- câu.	P: Tôi đã lạc mất con mèo duy nhất của mình vào sáng nay. sáng nay.) C: Tôi có một con mèo.
9	Những người khác.	

Bàn 10: Ví dụ về Quy tắc Tạo Cặp Đoạn Luận (P) - Khẳng định (C) cho Nhãn được Hỗ trợ l.

No.	Rule	Example
1	Use negative words.	P: Mặc dù đã có vacxin phòng ngừa bệnh cúm, nhưng mỗi năm nước ta vẫn có tới 800.000 người mắc bệnh.(Although there is a flu vaccine, our country still has up to 800,000 cases each year.) C: Số ca mắc bệnh cúm ở nước ta mỗi năm là 200 người, và vẫn chưa có loại vacxin phòng bệnh.(The number of flu cases in our country each year is 200 and there is still no vaccine available.)
2	Replace with antonyms.	P: Một chiếc máy bay đang cất cánh. (An airplane is taking off.) C: Một chiếc máy bay đang hạ cánh. (An airplane is landing.)
3	Incorrect entity inference structure.	P: Với chiều dài 50,45 km, nối liền Folkestone ở Anh với Coquelles ở Pháp, Channel là đường hầm đường sắt dài thứ ba trên thế giới. (At 50.45 km in length, connecting Folkestone in the UK with Coquelles in France, the Channel Tunnel is the third longest railway tunnel in the world.) C: Đường hầm Channel nối Pháp và Nhật Bản, lập kỉ lục là đường sắt dài thứ 4 thế giới. (The Channel Tunnel connects France and Japan, setting a record as the fourth longest railway tunnel in the world.")
4	Incorrect event inference structure.	P: Ông Santer kế nhiệm ông Delors làm việc tại Ủy ban ở Châu Âu vào năm 1995. (Mr. Santer succeeded Mr. Delors at the European Commission in 1995.) C: Năm 1990 ông Delors kế nhiệm ông Santer làm việc tại Ủy ban ở Thái Bình Dương. (In 1990, Mr. Delors succeeded Mr. Santer at the Pacific Commission.)
5	Create a sentence with a meaning opposite to the presupposition paragraph.	P: Năm 2009, Rose kết hôn và cùng chồng mua căn nhà ở vùng ngoại ô London chưa tới 1 triệu bảng. (In 2009, Rose got married and, together with her husband, bought a house in the suburbs of London for less than 1 million pounds.) C: Cho đến tận năm 2010, Rose vẫn chưa từng thử yêu đương một lần. (Up until 2010, Rose had never tried dating even once.)
6	Others.	

Table 11: Examples of Rules for Creating Premise Paragraph (P) - Claim (C) Pairs for the Refuted Label.

No.	Rule	Ví dụ
1	Use tiêu cực từ.	P: Mặc dù đã có vắc-xin phòng ngừa bệnh cúm, nhưng mỗi năm nước ta vẫn có tới 800.000 người mắc bệnh. (Mặc dù có vắc-xin cúm, nước ta vẫn có tới 800.000 trường hợp mỗi năm.) C: The number of flu cases in our country each year is 200 people, and there is still no type vắc xin phòng bệnh. (Số ca cúm ở nước ta mỗi năm là 200 và vẫn chưa có vắc-xin nào có sẵn.)
2	Thay thế with từ trái nghĩa.	P: Một chiếc máy bay đang cất cánh. C: Một chiếc máy bay đang hạ cánh.
3	Sai entity suy luận cấu trúc.	P: With a length of 50.45 km, connecting Folkestone in England with Coquelles in France, Kênh là đường hầm đường sắt dài thứ ba trên thế giới. (Dài 50,45 km) chiều dài, nối Folkestone ở Vương quốc Anh với Coquelles ở Pháp, Kênh Đường hầm là đường hầm xe lửa dài thứ ba trên thế giới.) C: The Channel Tunnel connecting France and Japan, setting the record as the 4th longest railway thế giới. (Đường hầm Kênh kết nối Pháp và Nhật Bản, thiết lập kỷ lục như đường hầm railway dài thứ tư trên thế giới.
4	Sai sự kiện cấu trúc suy luận sự thật.	P: Ông Santer succeeded ông Delors in working at the European Commission in the year 1995. (Ông Santer kế nhiệm ông Delors tại Ủy ban Châu Âu vào năm 1995.) C: In 1990, Mr. Delors succeeded Mr. Santer working at the Commission in the Pacific Dương. (Vào năm 1990, ông Delors kế nhiệm ông Santer tại Ủy ban Thái Bình Dương.)
5	Tạo một câu với một ý nghĩa đối diện với giả định trước đoạn văn.	P: In 2009, Rose got married and bought a house in the suburbs of London with her husband chưa tới 1 triệu bảng. (Vào năm 2009, Rose đã kết hôn và, cùng với chồng cô, mua một ngôi nhà ở ngoại ô London với giá chưa đến 1 triệu bảng. C: Cho đến tận năm 2010, Rose vẫn chưa từng thử yêu đương một lần. Năm 2010, Rose chưa bao giờ thử hẹn hò dù chỉ một lần.
6	Những người khác.	

Tabl Hình 11: Ví dụ về các quy tắc tạo cặp Đoạn giả thuyết (P) - Khẳng định (C) cho nhãn bị phản bác .

B LLM Prompts

This section presents the prompts (zero-shot and few-shot prompting) used in experiments with LLMs (Qwen, Gemma, Llama) on our ViNumFCR dataset.

Zero-shot Prompting

SYSTEM PROMPT:

You are a fact checking classifier. Your task is to classify the relationship between the paragraph and claim into exactly one of the following labels: Supported, Refuted, or NotenoughInfo. Your classification should be precise.

Instructions

- Read the given paragraph and claim.
- Decide the relationship between them based strictly on semantic meaning.
- You must follow these definitions:

  - **Supported**: The claim is correct with respect to the information and numerical data provided in the original paragraph.
  - **Refuted**: The claim is incorrect with respect to the information and numerical data provided in the original paragraph.
  - **NotenoughInfo**: It cannot be determined whether the claim is correct or incorrect based on the information and numerical data available in the original paragraph.

- Do not provide any explanations or extra words.

Output Format:

You should ONLY return one word from the set: Supported | Refuted | NotenoughInfo

---

USER PROMPT:

`Paragraph`: `...`
`Claim`: `...`

Few-shot Prompting

SYSTEM PROMPT:

You are a fact checking classifier. Your task is to classify the relationship between the paragraph and claim into exactly one of the following labels: Supported, Refuted, or NotenoughInfo. Your classification should be precise.

Instructions

- Read the given paragraph and claim.
- Decide the relationship between them based strictly on semantic meaning.
- You must follow these definitions:

  - **Supported**: The claim is correct with respect to the information and numerical data provided in the original paragraph.
  - **Refuted**: The claim is incorrect with respect to the information and numerical data provided in the original paragraph.
  - **NotenoughInfo**: It cannot be determined whether the claim is correct or incorrect based on the information and numerical data available in the original paragraph.

- Learn from the provided examples.

B LLM Lời nhắc

Phần này n trình bày các lời nhắc (lời nhắc zero-shot và few-shot) được sử dụng trong các thí nghiệm với LLM s (Qwen, Ge mma, Llama) trên tập dữ liệu ViNumFCR của chúng tôi.

Gợi ý không cần huấn luyện trước

LỜI NHẮC HỆ THỐNG:

Bạn là một bộ phân loại kiểm tra sự thật. Nhiệm vụ của bạn là phân loại mối quan hệ giữa đoạn văn và tuyên bố thành đúng một trong các nhãn sau: Hỗ trợ, Bác bỏ, hoặc Thiếu thông tin. Việc phân loại của bạn nên chính xác.

Hướng dẫn

- Đọc đoạn văn và tuyên bố đã cho. - Xác định mối quan hệ giữa chúng dựa hoàn toàn trên ý nghĩa ngữ nghĩa. - Bạn phải tuân theo các định nghĩa này:

  • Hỗ trợ: Yêu cầu này là chính xác liên quan đến thông tin và dữ liệu số được cung cấp trong đoạn văn gốc.

  • Bác bỏ: Yêu cầu này không chính xác đối với thông tin và dữ liệu số được cung cấp trong đoạn văn gốc.

  • Không đủ thông tin: Không thể xác định liệu yêu cầu có đúng hay sai dựa trên thông tin và dữ liệu số có sẵn trong đoạn văn gốc.

- Không cung cấp bất kỳ giải thích hoặc từ ngữ bổ sung nào.

Định dạng đầu ra:

Bạn chỉ nên trả về một từ duy nhất từ tập hợp: Hỗ trợ | Bác bỏ | Không đủ thông tin

---

LỜI NHẮC NGƯỜI DÙNG:

`Đoạn văn`: `...`
Yêu cầu`: `.. .`

Gợi ý ít ví dụ

LỜI NHẮC HỆ THỐNG:

Bạn là một bộ phân loại kiểm tra sự thật. Nhiệm vụ của bạn là phân loại mối quan hệ giữa đoạn văn và tuyên bố thành đúng một trong các nhãn sau: Hỗ trợ, Bác bỏ, hoặc Thiếu thông tin. Việc phân loại của bạn nên chính xác.

Hướng dẫn

- Đọc đoạn văn và tuyên bố đã cho. - Xác định mối quan hệ giữa chúng dựa hoàn toàn trên ý nghĩa ngữ nghĩa. - Bạn phải tuân theo các định nghĩa này:

  • Hỗ trợ: Yêu cầu này là chính xác liên quan đến thông tin và dữ liệu số được cung cấp trong đoạn văn gốc.

  • Bác bỏ: Yêu cầu này không chính xác đối với thông tin và dữ liệu số được cung cấp trong đoạn văn gốc.

  • Không đủ thông tin: Không thể xác định liệu tuyên bố là đúng hay sai dựa trên thông tin và dữ liệu số có sẵn trong đoạn gốc.

- Học từ các ví dụ được cung cấp.

Example 1
+ Paragraph: Việt Nam có 33 cơ sở giáo dục liên cấp có vốn đầu tư nước ngoài, thường được gọi là trường quốc tế, trong đó Hà Nội có 13 cơ sở, TP HCM có 20 cơ sở. Các trường này thu học phí hàng trăm triệu đồng một năm, tăng dần từ mầm non đến cấp trung học. *(Vietnam has 33 inter-level educational institutions with foreign investment, commonly referred to as international schools, of which Hanoi has 13 and Ho Chi Minh City has 20. These schools charge tuition fees of hundreds of millions of VND per year, increasing from kindergarten to secondary level.)*
+ Claim: Trong tổng số trường quốc tế liên cấp tại Việt Nam, TP.HCM chiếm hơn 50%. *(Ho Chi Minh City accounts for more than 50% of the total number of international inter-level schools in Vietnam.)*
+ True Label: Supported

Example 2
+ Paragraph: Từng là tuyển thủ hạt giống của đội bắn súng, Vạn Quang Húc gần đây bỏ bê tập luyện, mâu thuẫn với huấn luyện viên, cố tình khiêu khích gây rối, đánh nhau. Húc từng được đội thể thao nhiều lần bỏ qua lỗi lầm vì luyến tiếc tài năng, nhưng hành động đánh đập ác ý vận động viên khác đã vượt quá giới hạn. Húc bị công an bắt tạm giam một tháng, khai trừ khỏi đội. *(Once a seeded athlete of the shooting team, Van Quang Huc has recently neglected training, clashed with his coach, deliberately provoked disturbances, and engaged in fights. He had been repeatedly forgiven by the team out of regard for his talent, but his malicious assault on another athlete crossed the line. Huc was detained by the police for one month and expelled from the team.)*
+ Claim: Sau khi bị tạm giam chỉ 20 ngày, anh ấy đã được ân xá để trở lại đội tuyển vì tài năng của mình. *(After being detained for only 20 days, he was pardoned and allowed to return to the national team because of his talent.)*
+ True Label: Refuted

Example 3
+ Paragraph: Một hệ lụy khác mà cơn bão sa thải mang đến là môi trường làm việc trở nên "vô cùng áp lực" khi có đến 31% người lao động thường xuyên stress. Ngoài ra, một trạng thái đáng báo động mà báo cáo nêu cứ 10 người đi làm có 4 người rơi vào trạng thái burn out – hội chứng kiệt quệ về thể chất, tinh thần do stress quá nhiều. *(Another consequence brought about by the wave of layoffs is that the work environment has become "extremely stressful," with up to 31% of employees frequently experiencing stress. In addition, the report highlights an alarming state: 4 out of every 10 workers suffer from burnout – a syndrome of physical and mental exhaustion caused by excessive stress.)*
+ Claim: Một nữa trong số 31% người lao động thường xuyên stress có nguy cơ cơ cao mắc các bệnh liên quan đến tim mạch do kiệt quệ về thể chất, tinh thần. *(Half of the 31% of employees who are frequently stressed face a high risk of cardiovascular diseases due to physical and mental exhaustion.)*
+ True Label: NotenoughInfo

- Do not provide any explanations or extra words.

Output Format:
You should ONLY return one word from the set: Supported | Refuted | NotenoughInfo

---

USER PROMPT:

`Paragraph`: `...`
`Claim`: `...`

Ví dụ 1
Việt Nam có 33 cơ sở giáo dục liên cấp có vốn đầu tư nước ngoài, thường được gọi là trường quốc tế, trong đó Hà Nội có 13 cơ sở và TP HCM có 20 cơ sở. Các trường này thu học phí hàng trăm triệu đồng một năm, tăng dần từ mầm non đến cấp trung học.

+ Khẳng định: Trong tổng số trường quốc tế liên cấp tại Việt Nam, TP.HCM chiếm hơn 50%. (Ho Chi Minh City accounts for more than 50% of the total number of international inter-level schools in Vietnam.)+Nhãn đúng: Được hỗ trợ

Ví dụ 2
Đã từng là tuyển thủ hạt giống của đội bắn súng, Vạn Quang Húc gần đây bỏ bê tập luyện, mâu thuẫn với huấn luyện viên, cố tình gây rối và tham gia đánh nhau. Anh ta từng nhiều lần được đội tha thứ vì tài năng, nhưng hành động tấn công ác ý đối với vận động viên khác đã vượt quá giới hạn. Húc bị công an tạm giam một tháng và bị khai trừ khỏi đội.

+ Claim: Sau khi bị tạm giam chỉ 20 ngày, anh ấy đã được ân xá và được phép trở lại đội tuyển quốc gia vì tài năng của mình.

+ Nhãn thật: Bị bác bỏ

Ví dụ 3
Một hệ lụy khác mà làn sóng sa thải mang đến là môi trường làm việc trở nên "vô cùng áp lực," với tới 31% nhân viên thường xuyên trải qua stress. Ngoài ra, một trạng thái đáng báo động mà báo cáo nêu ra: cứ 10 người đi làm thì có 4 người rơi vào tình trạng kiệt sức – một hội chứng kiệt quệ về thể chất và tinh thần do stress quá mức gây ra.

+ Yêu cầu: Một nửa trong số 31% nhân viên thường xuyên căng thẳng có nguy cơ cao mắc các bệnh tim mạch do kiệt sức về thể chất và tinh thần.+Nhãn đúng: Chưa đủ thông tin

- Không cung cấp bất kỳ giải thích hoặc từ ngữ bổ sung nào.

Định dạng đầu ra:
Bạn chỉ nên trả về một từ duy nhất từ tập hợp: Hỗ trợ | Bác bỏ | Không đủ thông tin

---

LỜI NHẮC NGƯỜI DÙNG:

`Đoạn văn`: `...`
Yêu cầu`: `...`