

Fathom: A Fast and Modular RAG Pipeline for Fact-Checking

Farrukh Bin Rashid
farrukh.rashid@unb.ca

Saqib Hakak
saqib.hakak@unb.ca

Abstract

We present Fathom, a Retrieval-Augmented Generation (RAG) pipeline for automated fact-checking, built entirely using lightweight open-source language models. The system begins with HyDE-style question generation to expand the context around each claim, followed by a dual-stage retrieval process using BM25 and semantic similarity to gather relevant evidence. Finally, a lightweight LLM performs veracity prediction, producing both a verdict and supporting rationale. Despite relying on smaller models, our system achieved a new AVeriTeC score of 0.2043 on the test set, a 0.99% absolute improvement over the baseline and 0.378 on the dev set, marking a 27.7% absolute improvement.

1 Introduction

Misinformation and disinformation continue to pose serious challenges in today’s social media landscape. Research from 2018 shows that false claims spread up to six times faster than truthful ones on platforms like Twitter (Vosoughi et al., 2018). Although manual fact-checking has played a critical role in addressing false claims, it struggles to match the speed and volume at which mis/disinformation proliferates online. As a result, automated fact-checking (AFC) has been proposed as a valuable tool to support journalists and professional fact-checkers (Vlachos and Riedel, 2014). AFC refers to the task of predicting the veracity of a claim by leveraging relevant pieces of evidence (Guo et al., 2022).

The field of automated fact-checking has progressed significantly in recent years, supported by the development of benchmark datasets such as FEVER (Thorne et al., 2018) and, more recently, AVeriTeC (Schlichtkrull et al., 2023). While FEVER introduced large-scale fact verification using synthetic claims derived from Wikipedia, it and similar datasets often suffered from limitations like

shallow context, limited evidence, and temporal leakage, reducing their effectiveness on real-world claims. AVeriTeC addresses these challenges by using real claims from professional fact-checkers, annotated with fine-grained, crowdsourced evidence and question-answer pairs drawn from noisy, open-web sources.

In this paper, we present Fathom, a Retrieval-Augmented Generation (RAG) pipeline for automated fact-checking that leverages open-source, lightweight language models, using the AVeriTeC dataset. The system processes each claim in 22 seconds. First, it enriches the claim using a HyDE-style approach by generating hypothetical question-answer pairs. These are then used to retrieve candidate evidence via BM25. To refine the retrieved set, we apply semantic re-ranking using a dense embedding model. Finally, a lightweight LLM reasons over the selected evidence and QA pairs to classify the claim as Supported, Refuted, Not Enough Evidence, or Conflicting Evidence/Cherrypicking. The full implementation of our system is publicly available at github.com/farrukhrashid1997/Fathom.

2 Related Works

Schlichtkrull et al. (2024) features and discusses top-performing systems that combined large language models (LLMs) with hybrid retrieval pipelines for automated fact-checking on the AVeriTeC dataset. Rothermel et al. (2024) was the most notable with a GPT-4o-based pipeline and semantic search. Yoon et al. (2024) integrated BM25 with dense retrieval, using LLaMA-3 models for both question generation and veracity prediction. Ullrich et al. (2024) and Park et al. (2024) both relied on GPT-4, with the latter achieving the highest performance by enhancing retrieval through PDF and video text extraction.

A common pattern among top systems using

Fathom: Một Pipeline RAG Nhanh và Mô-đun cho Kiểm tra Thực tế

Farrukh Bin Rashid
farrukh.rashid@unb.ca

Saqib Hakak
saqib.hakak@unb.ca

Tóm tắt

Chúng tôi giới thiệu Fathom, một quy trình Tạo Sinh Bổ Sung Truy Xuất (RAG) để kiểm tra sự thật tự động, được xây dựng hoàn toàn bằng các mô hình ngôn ngữ mã nguồn mở nhẹ. Hệ thống bắt đầu với việc tạo câu hỏi theo kiểu HyDE để mở rộng bối cảnh xung quanh mỗi tuyên bố, sau đó là quá trình truy xuất hai giai đoạn sử dụng BM25 và độ tương đồng ngữ nghĩa để thu thập bằng chứng liên quan. Cuối cùng, một mô hình ngôn ngữ nhẹ thực hiện dự đoán tính xác thực, tạo ra cả phán quyết và cơ sở lập luận hỗ trợ. Mặc dù dựa vào các mô hình nhỏ hơn, hệ thống của chúng tôi đã đạt được điểm AVeriTeC mới là 0.2043 trên tập kiểm tra, cải thiện tuyệt đối 0,99% so với mức cơ bản và 0.378 trên tập phát triển, đánh dấu sự cải thiện tuyệt đối 27,7%.

1 Giới thiệu

Thông tin sai lệch và tin tức giả mạo tiếp tục gây ra những thách thức nghiêm trọng trong bối cảnh mạng xã hội hiện nay. Nghiên cứu từ năm 2018 cho thấy các tuyên bố sai lan truyền nhanh gấp sáu lần so với các tuyên bố đúng trên các nền tảng như Twitter (Vosoughi và cộng sự, 2018). Mặc dù việc kiểm tra sự thật thủ công đã đóng vai trò quan trọng trong việc xử lý các tuyên bố sai, nó gặp khó khăn trong việc theo kịp tốc độ và khối lượng mà thông tin sai lệch/tin giả lan truyền trực tuyến. Do đó, kiểm tra sự thật tự động (AFC) đã được đề xuất như một công cụ quan trọng để hỗ trợ các nhà báo và những người kiểm tra sự thật chuyên nghiệp (Vlachos và Riedel, 2014). AFC đề cập đến nhiệm vụ dự đoán tính chân thực của một tuyên bố bằng cách tận dụng các mảnh bằng chứng liên quan (Guo và cộng sự, 2022).

Lĩnh vực kiểm tra sự thật tự động đã tiến triển đáng kể trong những năm gần đây, được hỗ trợ bởi sự phát triển của các bộ dữ liệu chuẩn như FEVER (Thorne và cộng sự, 2018) và, gần đây hơn, AVeriTeC (Schlichtkrull và cộng sự, 2023). Trong khi FEVER giới thiệu việc xác minh sự thật quy mô lớn sử dụng các tuyên bố tổng hợp lấy từ Wikipedia, nó và các bộ dữ liệu tương tự thường gặp phải các hạn chế như

ngữ cảnh nông cạn, bằng chứng hạn chế và rò rỉ theo thời gian, làm giảm hiệu quả của chúng đối với các tuyên bố trong thế giới thực. AVeriTeC giải quyết những thách thức này bằng cách sử dụng các tuyên bố thực tế từ các chuyên gia kiểm tra sự thật, được chú thích với bằng chứng chi tiết, do cộng đồng cung cấp và các cặp câu hỏi-trả lời được lấy từ các nguồn mở trên web có độ nhiễu cao.

Trong bài báo này, chúng tôi giới thiệu Fathom, một quy trình Tạo Sinh Tăng cường Truy xuất (RAG) cho việc kiểm tra sự thật tự động, tận dụng các mô hình ngôn ngữ mã nguồn mở, nhẹ, sử dụng tập dữ liệu AVeriTeC. Hệ thống xử lý mỗi tuyên bố trong 22 giây. Đầu tiên, nó làm phong phú tuyên bố bằng cách sử dụng phương pháp kiểu HyDE bằng cách tạo các cặp câu hỏi-trả lời giả định. Những cặp này sau đó được sử dụng để truy xuất bằng chứng ứng viên thông qua BM25. Để tinh chỉnh tập hợp truy xuất được, chúng tôi áp dụng xếp hạng lại ngữ nghĩa bằng mô hình nhúng đặc. Cuối cùng, một LLM nhẹ lý giải dựa trên các bằng chứng và cặp QA đã chọn để phân loại tuyên bố là Hỗ trợ, Bác bỏ, Không đủ bằng chứng, hoặc Bằng chứng mâu thuẫn/Chọn lọc. Toàn bộ triển khai hệ thống của chúng tôi có sẵn công khai tại github.com/farrukhrashid1997/Fathom.

2 Công trình liên quan

Schlichtkrull và cộng sự (2024) giới thiệu và thảo luận về các hệ thống hàng đầu kết hợp các mô hình ngôn ngữ lớn (LLM) với các pipeline truy hồi kết hợp cho việc kiểm tra sự thật tự động trên tập dữ liệu AVeriTeC. Rothermel và cộng sự (2024) là nổi bật nhất với một pipeline dựa trên GPT-4o và tìm kiếm ngữ nghĩa. Yoon và cộng sự (2024) tích hợp BM25 với truy hồi đậm đặc, sử dụng các mô hình LLaMA-3 cho cả việc tạo câu hỏi và dự đoán tính xác thực. Ullrich và cộng sự (2024) cũng như Park và cộng sự (2024) đều dựa vào GPT-4, với nhóm sau đạt hiệu suất cao nhất nhờ cải thiện truy hồi thông qua trích xuất văn bản từ PDF và video.

Một mô hình phổ biến trong số các hệ thống hàng đầu sử dụng

the AVeriTeC dataset is the initial generation of questions or decomposition of claims into self-contained queries to guide retrieval. This step was typically powered by large LLMs such as GPT-4o or LLaMA-3.1-70B. However, several competitive systems, such as HerO (Yoon et al., 2024) with LLaMA-3-8B and Data-Wizards (Singhal et al., 2024) with Phi-3-medium, demonstrated that smaller models can also be effective for query generation.

Similarly, in the veracity prediction stage, most top-performing systems relied on powerful LLMs like GPT-4o, LLaMA-3.1-70B, and Mixtral-8x7B to reason over retrieved evidence and generate final verdicts. Notably, some systems like HerO (Yoon et al., 2024) and SynApSe (Churina et al., 2024) observed further gains by fine-tuning these LLMs for the task, suggesting that adapting large language models to the specific reasoning requirements of the AVeriTeC task can lead to measurable performance improvements.

More broadly, recent work has explored variations of RAG to improve fact verification through better evidence grounding. Khaliq et al. (2024) combines multimodal retrieval with structured reasoning via Chain of RAG and Tree of RAG, enabling step-by-step reasoning by retrieving and integrating evidence across multiple sub-questions.

Another notable use RAG is by CrAM (Deng et al., 2025), it improves fact-checking by teaching the model to focus more on reliable evidence. Instead of treating all retrieved documents equally, it adjusts how much attention the LLM gives to each one based on how credible it is.

Inspired by these developments, our system adopts a RAG-based architecture with lightweight open-source LLMs, combining efficient retrieval and reasoning to tackle the challenges of automated fact-checking.

3 Data

We evaluate our system on the AVeriTeC dataset (Schlichtkrull et al., 2023), a resource for automated fact-checking containing 4,568 real-world claims collected from 50 professional fact-checking organizations. Each claim is annotated with a veracity label *Supported*, *Refuted*, *Not Enough Evidence*, or *Conflicting Evidence/Cherry-picking* along with question-answer (QA) pairs grounded in web-based evidence, and a justification explaining how the evidence supports the verdict.

The distribution of labels across the training and development splits is summarized in Table 1.

The AVeriTeC dataset uses a multi-step annotation process to make each claim easier to verify. First, the claims are cleaned and simplified for clarity. Then, annotators generate questions that reflect the core factual components of the claim. For each question, they retrieve supporting or refuting information from the web and record multiple answers along with the source URLs.

In the 2024 AVeriTeC shared task (Schlichtkrull et al., 2024) introduced a knowledge store, a curated collection of pre-retrieved web documents, to assist people using the dataset in evidence retrieval, eliminating the need for independent web scraping.

Class	Train	Dev
Supported	847	122
Refuted	1743	305
Conflicting evidence/Cherry-picking	196	38
Not enough evidence	282	35
Total	3068	500

Table 1: Class-wise distribution of train and dev sets of the AVeriTeC dataset.

4 Methodology

In this section, we present our system and describe its four key components within the RAG pipeline.

4.1 Claim Decomposition via HyDE-QA Generation

Several fact-checking pipelines (Park et al., 2024; Rothermel et al., 2024; Ullrich et al., 2024) have shown that generating explicit questions from claims and subsequently answering them using retrieved evidence significantly improves fact verification performance. These question-answer pairs not only guide the retrieval process but also organize the information in a way that supports LLM reasoning during classification. In parallel, the HyDE approach (Gao et al., 2023; Wang et al., 2023) has gained traction in RAG pipelines by generating hypothetical answers to queries using an LLM. These synthetic answers, when used as enriched search queries, improve semantic retrieval performance by injecting latent contextual cues. Inspired by prior work, we generate multiple plausible HyDE-style QA pairs for each claim to guide evidence retrieval.

In order to generate the question answer pairs, the model is prompted with the claim along with

Bộ dữ liệu AVeriTeC là thể hệ ban đầu của các câu hỏi hoặc sự phân rã các tuyên bố thành các truy vấn tự-contained để hướng dẫn việc truy xuất. Bước này thường được hỗ trợ bởi các mô hình ngôn ngữ lớn như GPT-4o hoặc LLaMA-3.1-70B. Tuy nhiên, một số hệ thống cạnh tranh, như HerO (Yoon et al., 2024) với LLaMA-3-8B và Data-Wizards (Singhal et al., 2024) với Phi-3-medium, đã chứng minh rằng các mô hình nhỏ hơn cũng có thể hiệu quả cho việc tạo truy vấn.

Tương tự, trong giai đoạn dự đoán độ xác thực, hầu hết các hệ thống có hiệu suất hàng đầu dựa vào các mô hình ngôn ngữ lớn mạnh mẽ như GPT-4o, LLaMA-3.1-70B và Mixtral-8x7B để lý luận dựa trên bằng chứng truy xuất được và đưa ra phán quyết cuối cùng. Đáng chú ý, một số hệ thống như HerO (Yoon et al., 2024) và SynApSe (Churina et al., 2024) quan sát thấy những cải thiện hơn nữa khi tinh chỉnh các mô hình ngôn ngữ lớn này cho nhiệm vụ, gợi ý rằng việc điều chỉnh các mô hình ngôn ngữ lớn theo các yêu cầu lý luận cụ thể của nhiệm vụ AVeriTeC có thể dẫn đến những cải thiện hiệu suất đo lường được.

Nói rộng hơn, các nghiên cứu gần đây đã khám phá các biến thể của RAG để cải thiện việc xác minh sự thật thông qua nền tảng bằng chứng tốt hơn. Khaliq và cộng sự (2024) kết hợp truy xuất đa phương tiện với lập luận có cấu trúc thông qua Chuỗi RAG và Cây RAG, cho phép suy luận từng bước bằng cách truy xuất và tích hợp bằng chứng từ nhiều câu hỏi phụ.

Một ứng dụng đáng chú ý khác của RAG là bởi CrAM (Deng và cộng sự, 2025), nó cải thiện việc kiểm tra sự thật bằng cách dạy mô hình tập trung nhiều hơn vào bằng chứng đáng tin cậy. Thay vì đối xử với tất cả các tài liệu được truy xuất như nhau, nó điều chỉnh mức độ chú ý mà LLM dành cho từng tài liệu dựa trên mức độ đáng tin cậy của chúng.

Lấy cảm hứng từ những phát triển này, hệ thống của chúng tôi áp dụng kiến trúc dựa trên RAG với các LLM mã nguồn mở nhẹ, kết hợp việc truy xuất và lập luận hiệu quả để giải quyết các thách thức của việc kiểm tra sự thật tự động.

3 Dữ liệu

Chúng tôi đánh giá hệ thống của mình trên bộ dữ liệu AVeriTeC (Schlichtkrull et al., 2023), một nguồn tài nguyên cho việc kiểm tra sự thật tự động chứa 4.568 tuyên bố thực tế được thu thập từ 50 tổ chức kiểm tra sự thật chuyên nghiệp. Mỗi tuyên bố được gán nhãn độ xác thực là Hỗ trợ, Bác bỏ, Không đủ bằng chứng, hoặc Bằng chứng mâu thuẫn/Lựa chọn có chọn lọc cùng với các cặp câu hỏi-trả lời (QA) dựa trên bằng chứng từ web, và một lý giải giải thích cách bằng chứng hỗ trợ phán quyết.

Sự phân bố nhãn trên các tập huấn luyện và phát triển được tóm tắt trong Bảng 1.

Bộ dữ liệu AVeriTeC sử dụng một quy trình chú thích nhiều bước để làm cho mỗi tuyên bố dễ xác minh hơn. Đầu tiên, các tuyên bố được làm sạch và đơn giản hóa để rõ ràng. Sau đó, các người chủ thích tạo ra các câu hỏi phản ánh các thành phần thực tế cốt lõi của tuyên bố. Đối với mỗi câu hỏi, họ truy xuất thông tin hỗ trợ hoặc phản bác từ web và ghi lại nhiều câu trả lời cùng với các URL nguồn.

Trong nhiệm vụ chia sẻ AVeriTeC 2024 (Schlichtkrull et al., 2024) đã giới thiệu một kho tri thức, một bộ sưu tập được chọn lọc các tài liệu web đã được truy xuất trước, để hỗ trợ người dùng sử dụng bộ dữ liệu trong việc truy xuất bằng chứng, loại bỏ nhu cầu tự thu thập dữ liệu web một cách độc lập.

Lớp	Tàu	Dev
Được hỗ trợ	847	122
Bác bỏ	1743	305
Bằng chứng mâu thuẫn/Lựa chọn thông tin có chọn lọc	196	38
Không đủ bằng chứng	282	35
Tổng cộng	3068	500

Bảng 1: Phân bố theo lớp của tập huấn luyện và tập phát triển của bộ dữ liệu AVeriTeC.

4 Phương pháp luận

Trong phần này, chúng tôi trình bày hệ thống của mình và mô tả bốn thành phần chính của nó trong quy trình RAG.

4.1 Phân rã Yêu cầu thông qua Tạo HyDE-QA

Một số quy trình kiểm tra sự thật (Park và cộng sự, 2024; Rothermel và cộng sự, 2024; Ullrich và cộng sự, 2024) đã cho thấy việc tạo ra các câu hỏi rõ ràng từ các tuyên bố và sau đó trả lời chúng bằng bằng chứng thu thập được giúp cải thiện đáng kể hiệu suất xác minh sự thật. Các cặp câu hỏi-trả lời này không chỉ hướng dẫn quá trình thu thập thông tin mà còn sắp xếp thông tin theo cách hỗ trợ suy luận của LLM trong quá trình phân loại. Đồng thời, phương pháp HyDE (Gao và cộng sự, 2023; Wang và cộng sự, 2023) đã trở nên phổ biến trong các quy trình RAG bằng cách tạo ra các câu trả lời giả định cho các truy vấn bằng LLM. Khi các câu trả lời tổng hợp này được sử dụng làm truy vấn tìm kiếm được bổ sung, chúng cải thiện hiệu suất tìm kiếm ngữ nghĩa bằng cách cung cấp các gợi ý ngữ cảnh tiềm ẩn. Lấy cảm hứng từ các công trình trước, chúng tôi tạo ra nhiều cặp QA kiểu HyDE khả thi cho mỗi tuyên bố để hướng dẫn việc thu thập bằng chứng.

Để tạo các cặp câu hỏi và câu trả lời, mô hình được thúc đẩy với tuyên bố cùng với




Figure 1: Overview of the Fathom system architecture.

optional metadata (speaker, date, location) and instructed to output multiple detailed QA pairs. To steer generation quality, we include handpicked few-shot examples that emphasize explicit and well-reasoned question-answer pairs. Six of the eight examples represent claims labeled as Conflicting Evidence/Cherry-picking. We chose this label primarily because such claims often involve both supporting and refuting information, which leads to more diverse and informative questions, covering multiple angles of the claim. These richer question answer pairs, in turn, guide better retrieval and support the LLM’s reasoning in downstream prediction. The remaining few-shot examples include one Supported and one Refuted case. An example generation output is shown in Figure 2.

4.2 Evidence Retrieval

In order to retrieve relevant evidence for the claim, we adopt a hybrid retrieval strategy, combining keyword-based sparse retrieval with semantic dense re-ranking.

4.2.1 Sparse Retrieval (BM25)

As in most RAG systems (Lewis et al., 2020; Ullrich et al., 2024), we perform document chunk re-

Claim: In a letter to Steve Jobs, Sean Connery refused to appear in an Apple commercial.

Q1: Did Sean Connery refuse to appear in an Apple commercial?

A1: No, because in 1998, Steve Jobs reached out to Sean Connery to star in a commercial for Apple’s iMac G3. Connery agreed and filmed the commercial.

Q2: Was there a letter from Sean Connery refusing to appear in an Apple commercial?

A2: No, there is no record of such a letter. Instead, Connery accepted the invitation and starred in the commercial.


Q3: Did Steve Jobs request Sean Connery for a commercial?

A3: Yes, in 1998, Steve Jobs, the CEO of Apple, personally wrote to Sean Connery, asking him to star in a commercial for the iMac G3.

Figure 2: Example of generated QA pairs for a Refuted claim.

trieval by splitting each document into smaller passages. Consecutive sentences are grouped until the combined character length reaches a threshold of N . Each chunk is annotated with metadata referencing its preceding and following chunks to maintain contextual continuity when later presented to the LLM.

Given that each claim has its own associated



Hình 1: Tổng quan về kiến trúc hệ thống Fathom.

metadata tùy chọn (người nói, ngày, địa điểm) và được chỉ dẫn để tạo nhiều cặp câu hỏi-trả lời chi tiết. Để điều hướng chất lượng tạo ra, chúng tôi bao gồm các ví dụ ít-lần tay chọn lựa nhấn mạnh các cặp câu hỏi-trả lời rõ ràng và có lý luận tốt. Sáu trong tám ví dụ đại diện cho các tuyên bố được gắn nhãn như Bằng chứng Mâu thuẫn/Lựa chọn dữ liệu. Chúng tôi chọn nhãn này chủ yếu vì các tuyên bố như vậy thường liên quan đến cả thông tin hỗ trợ và phản bác, điều này dẫn đến các câu hỏi đa dạng và nhiều thông tin hơn, bao quát nhiều góc độ của tuyên bố. Các cặp câu hỏi-trả lời phong phú này, lần lượt, hướng dẫn truy xuất tốt hơn và hỗ trợ lý luận của LLM trong dự đoán tiếp theo. Các ví dụ ít-lần còn lại bao gồm một trường hợp Được Hỗ trợ và một trường hợp Bị Phản bác. Một ví dụ về đầu ra tạo ra được hiển thị trong Hình 2.

4.2 Thu thập bằng chứng

Để truy xuất bằng chứng liên quan cho tuyên bố, chúng tôi áp dụng một chiến lược truy xuất lai, kết hợp truy xuất thưa dựa trên từ khóa với xếp hạng lại ngữ nghĩa đậm đặc.

4.2.1 Truy xuất thưa thớt (BM25)

Như trong hầu hết các hệ thống RAG (Lewis et al., 2020; Ullrich et al., 2024), chúng tôi thực hiện chia nhỏ tài liệu

Yêu cầu: Trong một bức thư gửi Steve Jobs, Sean Connery từ chối xuất hiện trong một quảng cáo của Apple. Q1: Sean Connery có từ chối xuất hiện trong một quảng cáo của Apple không? A1: Không, vì vào năm 1998, Steve Jobs đã liên hệ với Sean Connery để tham gia một quảng cáo cho iMac G3 của Apple. Connery đã đồng ý và quay quảng cáo. Q2: Có bức thư nào từ Sean Connery từ chối xuất hiện trong quảng cáo của Apple không? A2: Không, không có ghi chép nào về bức thư đó. Thay vào đó, Connery đã nhận lời mời và xuất hiện trong quảng cáo. Q3: Steve Jobs có yêu cầu Sean Connery tham gia quảng cáo không? A3: Có, vào năm 1998, Steve Jobs, giám đốc điều hành của Apple, đã tự mình viết thư cho Sean Connery, mời ông tham gia một quảng cáo cho iMac G3.

Hình 2: Ví dụ về các cặp hỏi đáp được tạo ra cho một khẳng định bị bác bỏ.

thu hồi bằng cách chia từng tài liệu thành các đoạn nhỏ hơn. Các câu liên tiếp được nhóm lại cho đến khi tổng chiều dài ký tự đạt đến ngưỡng N . Mỗi đoạn được chú thích với siêu dữ liệu tham chiếu đến các đoạn trước và sau để duy trì tính liên tục ngữ cảnh khi sau này được trình bày cho LLM.

Với việc mỗi yêu cầu đều có liên quan riêng của nó

knowledge store, often comprising hundreds or thousands of web pages, the search space is prohibitively large for direct dense retrieval. To address this, we first apply BM25 (Harman, 1995) to narrow the candidate pool: for each generated question-answer pair, we form a query and retrieve the top $k = 250$ chunks. Results are then deduplicated across all QA pairs linked to the claim. This high-recall filtering step enables efficient downstream semantic re-ranking.

This design also ensures that the system operates within the time constraints of fact-checking a claim under one minute. BM25 acts as a lightweight and effective first-pass filter, helping balance retrieval quality with system speed.

4.2.2 Semantic Re-ranking

Following the sparse BM25 stage, we employ semantic re-ranking to identify the most relevant passages from the candidate pool. To select an embedding model, we explore the MTEB benchmark (Muennighoff et al., 2022), prioritizing models under 500M parameters to meet runtime and memory constraints. We choose Snowflake/snowflake-arctic-embed-m-v2.0 (Merrick et al., 2024), a compact model that ranks among the top performers on retrieval tasks in the MTEB leaderboard, making it well-suited for our space and time constrained setting.

Each candidate chunk is embedded into a dense vector representation that captures its semantic content. Similarly, each query is formed by concatenating the question and answer from the QA pair and encoded using the same model. We compute cosine similarity between each query and all candidate chunk embeddings, and select the top 10 highest-scoring chunks per query. The output of this step is a ranked list of 10 evidence passages for each QA pair, optimized for semantic relevance.

4.3 Veracity Prediction

In the final stage, the system assigns one of four veracity labels (Supported, Refuted, Not Enough Evidence, or Conflicting/Cherry-picking) based on the structured evidence retrieved earlier, along with a clear rationale for its decision.

We prompt the LLM using a structured prompt that includes:

- the original claim
- a set of generated questions (from the QA generation step)

- For each question, up to $N = 8$ top-ranked evidence passages (ranked by the similarity score)

Through our preliminary testing, we found that $N = 8$ strikes a balance between sufficient context and avoiding prompt length limitations or information overload. To encourage structured reasoning, we adopt a Chain-of-Thought (CoT) prompting strategy as shown in Figure 3. The prompt explicitly instructs the LLM to analyze the claim by reasoning step-by-step through multiple question-answer evidence pairs. Essentially, instead of making an immediate judgment, the model is guided to sequentially evaluate evidence associated with each question, reflect on its implications for the claim, and then generate an overall conclusion. This encourages the model to simulate a fact-checker’s reasoning process, improving interpretability and alignment with complex veracity categories. We draw inspiration from prior work demonstrating that CoT enhances the reasoning capabilities of large language models across various tasks. (Wei et al., 2022)

After prompting the LLM, we get the final output which consists of:

- A detailed, natural-language reasoning which is grounded in the evidence
- A single veracity label, justified by the reasoning above

An excerpt of the final-stage output is shown in Figure 4, where the LLM can be seen reasoning through the provided questions and their corresponding evidence passages.

5 Experiments and Results

5.1 Experimental Details

All experiments were conducted using the **NVIDIA Quadro RTX 8000** GPU, which provided sufficient capacity for both dense retrieval and large language model inference. To ensure generalization and prevent overfitting to the dev set, final evaluation was performed on the AVeriTeC test set, an unseen split with hidden labels. For this stage, our system was deployed on an **NVIDIA A10G** GPU, as provided by the AVeriTeC shared task organizers, under standardized evaluation constraints.

Throughout the pipeline, we make design choices aimed at maximizing time efficiency without compromising output quality. In the first

kho tri thức, thường bao gồm hàng trăm hoặc hàng nghìn trang web, không gian tìm kiếm quá lớn để truy xuất trực tiếp bằng phương pháp dense. Để giải quyết vấn đề này, trước tiên chúng tôi áp dụng BM25 (Harman, 1995) để thu hẹp tập ứng viên: đối với mỗi cặp câu hỏi-trả lời được tạo ra, chúng tôi hình thành một truy vấn và truy xuất $k = 250$ đoạn hàng đầu. Kết quả sau đó được loại bỏ trùng lặp trên tất cả các cặp QA liên kết với tuyên bố. Bước lọc có độ nhớ cao này cho phép sắp xếp lại ngữ nghĩa hiệu quả ở các bước tiếp theo.

Thiết kế này cũng đảm bảo rằng hệ thống hoạt động trong giới hạn thời gian kiểm chứng một tuyên bố dưới một phút. BM25 hoạt động như một bộ lọc bước đầu nhẹ và hiệu quả, giúp cân bằng chất lượng truy xuất với tốc độ của hệ thống.

4.2.2 Sắp xếp lại theo ngữ nghĩa

Sau giai đoạn BM25 thưa thớt, chúng tôi sử dụng sắp xếp lại theo ngữ nghĩa để xác định các đoạn văn có liên quan nhất từ tập hợp các ứng viên. Để lựa chọn một mô hình nhúng, chúng tôi khám phá chuẩn MTEB (Muennighoff và cộng sự, 2022), ưu tiên các mô hình dưới 500 triệu tham số để đáp ứng các hạn chế về thời gian chạy và bộ nhớ. Chúng tôi chọn

Snowflake/snowflake-arctic-embed-m-v2.0 (Merrick và cộng sự, 2024), một mô hình gọn nhẹ nằm trong số các mô hình có hiệu suất hàng đầu trong các nhiệm vụ truy xuất trên bảng xếp hạng MTEB, làm cho nó phù hợp với bối cảnh hạn chế về không gian và thời gian của chúng tôi.

Mỗi đoạn ứng viên được nhúng vào một biểu diễn vector dày đặc nhằm nắm bắt nội dung ngữ nghĩa của nó. Tương tự, mỗi truy vấn được hình thành bằng cách nối câu hỏi và câu trả lời từ cặp QA và được mã hóa bằng cùng một mô hình. Chúng tôi tính toán độ tương đồng cosine giữa mỗi truy vấn và tất cả các biểu diễn đoạn ứng viên, và chọn 10 đoạn có điểm cao nhất cho mỗi truy vấn. Kết quả của bước này là một danh sách xếp hạng gồm 10 đoạn bằng chứng cho mỗi cặp QA, được tối ưu hóa về mức độ liên quan ngữ nghĩa.

4.3 Dự đoán độ chính xác

Trong giai đoạn cuối cùng, hệ thống gán một trong bốn nhãn độ xác thực (Được Hỗ Trợ, Bị Phủ Nhận, Không Đủ Bằng Chứng, hoặc Mâu Thuẫn/Lựa Chọn Có Chủ Định) dựa trên các chứng cứ có cấu trúc được truy xuất trước đó, cùng với một lý do rõ ràng cho quyết định của nó.

Chúng tôi đưa ra yêu cầu cho LLM bằng một yêu cầu có cấu trúc bao gồm:

- yêu cầu ban đầu
- một tập hợp các câu hỏi được tạo ra (từ bước tạo câu hỏi và trả lời)

- Đối với mỗi câu hỏi, tối đa $N = 8$ đoạn bằng chứng xếp hạng cao nhất (xếp hạng theo điểm tương đồng)

Qua các thử nghiệm sơ bộ của chúng tôi, chúng tôi nhận thấy rằng $N = 8$ tạo ra sự cân bằng giữa việc cung cấp đủ ngữ cảnh và tránh các giới hạn về độ dài gợi ý hoặc quá tải thông tin. Để khuyến khích tư duy có cấu trúc, chúng tôi áp dụng chiến lược gợi ý Chuỗi Tư duy (Chain-of-Thought, CoT) như được minh họa trong Hình 3. Gợi ý này yêu cầu rõ ràng mô hình ngôn ngữ lớn (LLM) phân tích tuyên bố bằng cách lý luận từng bước thông qua nhiều cặp câu hỏi-trả lời làm bằng chứng. Về cơ bản, thay vì đưa ra đánh giá ngay lập tức, mô hình được hướng dẫn đánh giá tuần tự các bằng chứng liên quan đến từng câu hỏi, suy ngẫm về ý nghĩa của chúng đối với tuyên bố, và sau đó đưa ra kết luận tổng thể. Điều này khuyến khích mô hình mô phỏng quy trình lý luận của một người kiểm tra sự thật, cải thiện khả năng giải thích và sự phù hợp với các loại tính xác thực phức tạp. Chúng tôi lấy cảm hứng từ các nghiên cứu trước đây cho thấy rằng CoT nâng cao khả năng lý luận của các mô hình ngôn ngữ lớn trong nhiều nhiệm vụ khác nhau. (Wei et al., 2022)

Sau khi nhắc LLM, chúng ta nhận được đầu ra cuối cùng bao gồm:

- Một lập luận chi tiết bằng ngôn ngữ tự nhiên được dựa trên bằng chứng
- Một nhãn tính xác thực duy nhất, được chứng minh bởi lý do nêu trên

Một trích đoạn của kết quả giai đoạn cuối được hiển thị trong Hình 4, nơi có thể thấy LLM đang lý luận qua các câu hỏi được cung cấp và các đoạn bằng chứng tương ứng.

5 Thí nghiệm và Kết quả

5.1 Chi tiết thí nghiệm

Tất cả các thí nghiệm được tiến hành sử dụng GPU NVIDIA Quadro RTX 8000, cung cấp đủ khả năng cho cả truy xuất dày đặc và suy diễn mô hình ngôn ngữ lớn. Để đảm bảo khả năng tổng quát hóa và ngăn ngừa hiện tượng overfitting vào tập dev, đánh giá cuối cùng được thực hiện trên tập kiểm tra AVeriTeC, một phân tách chưa được thấy với nhãn ẩn. Trong giai đoạn này, hệ thống của chúng tôi được triển khai trên GPU NVIDIA A10G, được cung cấp bởi các tổ chức của bài toán chia sẻ AVeriTeC, dưới các ràng buộc đánh giá tiêu chuẩn hóa.

Trong suốt quy trình, chúng tôi thực hiện các lựa chọn thiết kế nhằm tối đa hóa hiệu quả thời gian mà không làm giảm chất lượng đầu ra. Ở phần đầu tiên

	Q (Ev2R)	Q + A (Ev2R)	New (Ev2R)	Time/claim (s)
Fathom	0.2488	0.5137	0.3780	20
Baseline	0.3392	0.4404	0.2960	50

Table 2: AVeriTeC score on the **dev set**

Class	F1 Score
Supported (S)	0.6877
Refuted (R)	0.8436
Not Enough Evidence (NEI)	0.1455
Conflicting/Cherry-Picking (CP/CE)	0.0000
Accuracy	0.7200
Macro Avg F1	0.4192

Table 3: Per-class F1 scores, overall accuracy, and macro-averaged F1 score on the development set.

Claim: You are a fact-checking helpful assistant. Task: Your task is to evaluate the truthfulness of a claim using associated question–answer (QA) evidence pairs, where each question has several pieces of evidence (answers). You must analyze the claim and reason step-by-step through the evidence provided. Use a chain-of-thought reasoning approach to determine the final label. The given claim falls into one of the following four categories: - Supported - Refuted - Not Enough Evidence - Conflicting Evidence/Cherry-picking Input Format: Claim: <claim> QA: <Question answer pairs> Output: Reasoning: [Use chain-of-thought reasoning on the claim based on the evidence. Incorporate evaluation of the content and optionally consider the trustworthiness or context of the source URLs.] Label: <Supported, Refuted, Not Enough Evidence, Conflicting Evidence/Cherry-picking>
--

Figure 3: Prompt for the final veracity prediction step.

stage, the HyDE-QA step, we employ the open-source **Qwen2.5-7B-Instruct** model, running at half precision (dtype=“float16”) to reduce memory usage and accelerate inference. We use temperature=1.2 and top_p=0.3 to balance output diversity and relevance where the high temperature encourages variability while the low top_p keeps sampling focused on plausible tokens to maintain coherence. To reduce latency and GPU memory load, claims are processed with a batch size of 2. These settings offer a practical trade-off between response quality and runtime performance.

In the second stage, we apply parallelism to the BM25-based sparse retrieval step. Claims are

distributed across multiple CPU processes, and queries within each claim are further parallelized using multi-threading. This dual-level parallelism allows the system to retrieve evidence for many claims simultaneously, significantly reducing total time.

For semantic re-ranking, we use the **Snowflake/snowflake-arctic-embed-m-v2.0** embedding model. All candidate evidence chunks are encoded in batches of 128 for efficiency.

In the final veracity prediction step, we process claims in **batches of 4** using a 4-bit quantized version of Microsoft’s Phi-4 model (jakiAJK/microsoft-phi4_GPTQ-int4) to ensure faster inference and reduced memory usage. We select Phi-4 for its advanced reasoning capabilities, as it outperforms much larger models including LLaMA-3.3 70B and GPT-4o-mini on several reasoning-focused benchmarks such as MATH, GPQA, and HumanEval (Abdin et al., 2024). For generation, we use temperature=0.9, top_p=0.7, and top_k=1, a conservative setup that limits randomness while maintaining output quality. This configuration promotes stable, deterministic responses suitable for factual judgment.

5.2 Evaluation metrics

The evaluations metrics ensure that a correct veracity prediction is recorded only when the right evidence is retrieved to support the label.

In 2024, the AVeriTeC score was measured using the Hungarian METEOR approach (Kuhn, 1955; Banerjee and Lavie, 2005), wherein each generated QA pair is optimally matched to a reference using the Hungarian algorithm, and scored using METEOR similarity.

In 2025, the *AVeriTeC score* transitioned from Hungarian METEOR to the Ev2R atomic reference

	Q (Ev2R)	Q + A (Ev2R)	Mới (Ev2R)	Thời gian/đơn yêu cầu
Hiệu suất	0.2488	0.5137	0.3780	20
Đường cơ sở	0.3392	0.4404	0.2960	50

Bảng 2: Điểm AVeriTeC trên tập phát triển

Lớp	Điểm F1
Được hỗ trợ (S)	0.6877
Bác bỏ (R)	0.8436
Không đủ bằng chứng (NEI)	0.1455
Mâu thuẫn/Lựa chọn theo ý thích (CP/CE)	0.0000
Độ chính xác F1 Trung bình Macro	0.7200
	0.4192

Bảng 3: Điểm F1 theo từng lớp, độ chính xác tổng thể và điểm F1 trung bình theo macro trên tập phát triển t.

Yêu cầu: Bạn là một trợ lý hữu ích kiểm chứng thông tin. Nhiệm vụ: Nhiệm vụ của bạn là đánh giá độ chính xác của một tuyên bố bằng cách sử dụng các cặp bằng chứng câu hỏi–trả lời (QA) liên quan, trong đó mỗi câu hỏi có nhiều mảnh bằng chứng (câu trả lời). Bạn phải phân tích tuyên bố và lập luận từng bước thông qua các bằng chứng được cung cấp. Sử dụng phương pháp lập luận theo chuỗi suy nghĩ để xác định nhân cuối cùng. Yêu cầu được đưa ra thuộc vào một trong bốn loại sau: 1. Được hỗ trợ 2. Bị bác bỏ 3. Không đủ bằng chứng 4. Bằng chứng mâu thuẫn/Chọn lọc Định dạng đầu vào: Khẳng định: <khẳng định>Hỏi & Đáp: <Cặp câu hỏi và trả lời> Đầu ra: Lý luận: [Sử dụng lý luận theo chuỗi suy nghĩ trên tuyên bố dựa trên bằng chứng. Kết hợp đánh giá nội dung và tùy chọn xem xét độ tin cậy hoặc bối cảnh của các URL nguồn.] Nhân: <Được hỗ trợ, Bị bác bỏ, Không đủ bằng chứng, Bằng chứng mâu thuẫn/Lựa chọn thông tin có chủ ý>

Hình 3: Lời nhắc cho bước dự đoán độ xác thực cuối cùng.

giai đoạn, bước HyDE-QA, chúng tôi sử dụng mô hình mã nguồn mở Qwen2.5-7B-Instruct, chạy ở độ chính xác nửa (dtype=“float16”) để giảm việc sử dụng bộ nhớ và tăng tốc suy luận. Chúng tôi sử dụng temperature 0.2 và topp 0.3 để cân bằng sự đa dạng và tính liên quan của đầu ra, trong đó nhiệt độ cao khuyến khích tính biến đổi trong khi topp thấp giữ việc lấy mẫu tập trung vào các token khả thi để duy trì tính mạch lạc. Để giảm độ trễ và tải bộ nhớ GPU, các tuyên bố được xử lý với kích thước lô là 2. Các cài đặt này mang lại một sự đánh đổi hợp lý giữa chất lượng phản hồi và hiệu năng thời gian chạy.

Ở giai đoạn thứ hai, chúng tôi áp dụng song song hóa cho bước truy xuất thưa thớt dựa trên BM25. Các tuyên bố được

được phân bổ trên nhiều tiến trình CPU, và các truy vấn trong mỗi tuyên bố được song song hóa thêm bằng cách sử dụng đa luồng. Sự song song hai cấp độ này cho phép hệ thống truy xuất bằng chứng cho nhiều tuyên bố cùng lúc, giảm đáng kể tổng thời gian.

Đối với việc sắp xếp lại theo ngữ nghĩa, chúng tôi sử dụng mô hình nhúng Snowflake/snowflake-arctic-embed-m-v2.0. Tất cả các đoạn bằng chứng ứng viên được mã hóa theo từng lô 128 để tăng hiệu quả.

Trong bước dự đoán tính xác thực cuối cùng, chúng tôi xử lý các tuyên bố theo từng lô gồm 4 mục bằng phiên bản lượng tử 4-bit của mô hình Phi-4 của Microsoft (jakiAJK/microsoft-phi4_GPTQ-int4) để đảm bảo suy luận nhanh hơn và giảm sử dụng bộ nhớ. Chúng tôi chọn Phi-4 vì khả năng suy luận tiên tiến của nó, vượt trội hơn nhiều mô hình lớn hơn bao gồm LLaMA-3.3 70B và GPT-4o-mini trên một số bài kiểm tra tập trung vào suy luận như MATH, GPQA và HumanEval (Abdin và cộng sự, 2024). Đối với sinh văn bản, chúng tôi sử dụng temperature=0.9, top_p=0.7 và top_k=1, một thiết lập thận trọng giới hạn tính ngẫu nhiên trong khi vẫn duy trì chất lượng đầu ra. Cấu hình này thúc đẩy các phản hồi ổn định, có tính xác định, phù hợp với việc đánh giá thông tin thực tế.

5.2 Các chỉ số đánh giá

Các chỉ số đánh giá đảm bảo rằng một dự đoán độ xác thực đúng chỉ được ghi nhận khi bằng chứng đúng được truy xuất để hỗ trợ nhân.

Vào năm 2024, điểm theAVeriTeC được đo bằng phương pháp METEOR của Hungary (Kuhn, 1955; Banerjee và Lavie, 2005), trong đó mỗi cặp QA tạo ra được đối chiếu tối ưu với một tham chiếu bằng thuật toán Hungary, và được chấm điểm bằng độ tương đồng METEOR.

Vào năm 2025, điểm AVeriTeC đã chuyển từ HungarianMETEOR sang Ev2R atomicreference




Figure 4: Example of LLM-generated chain-of-thought reasoning with partial QA evidence (Q1–Q2 shown).

scorer (Akhtar et al., 2024). This approach uses an LLM to decompose both the predicted and reference question–answer (Q+A) pairs into sets of atomic facts. The metric then computes **Q + A (Ev2R Recall)** by measuring how many reference atomic facts are matched by those in the retrieved evidence. The predicted veracity label is only evaluated if the **Q+A (Ev2R) Recall exceeds 0.50**, which then contributes to the final AVeriTeC score.

5.3 Results

We conduct all development and initial evaluation on the AVeriTeC development set. As shown in Table 2, our system achieves a higher **New (Ev2R) AVeriTeC score of 0.3780**, outperforming the baseline. This gain is primarily driven by stronger semantic evidence retrieval, as reflected in the higher **Q+A (Ev2R) recall score of 0.5137**. In terms of veracity classification, Table 3 presents the F1 scores across all four classes. Our

final model using the 4-bit quantized Phi-4 performs well on the **Refuted** (0.8436) and **Supported** (0.6877) categories, which are also the most represented in the dev set. However, it struggles on the low-resource labels: **Not Enough Evidence (0.1455)** and especially **Conflicting/Cherry-picking**, where it fails to correctly classify any instance. This highlights a limitation in the veracity prediction stage, particularly for underrepresented classes that require more nuanced reasoning.


We hypothesize that one reason for this shortfall is the use of a zero-shot prompting strategy at the veracity prediction step. Incorporating a few-shot approach, especially with examples from NEI and CP/CE may help the model generalize better. Despite these challenges, the system achieves a strong overall **accuracy of 72%**, showing its reliability on majority classes while pointing to clear directions for future improvement.

To evaluate the generalization of our system, we submit predictions on the unseen AVeriTeC test set, where ground-truth labels are hidden. As shown in Table 4, our system slightly outperforming the baseline while maintaining significantly lower average runtime per claim. However, in contrast to the substantial improvement observed on the dev set, the margin over the baseline on the test set is noticeably smaller.

We hypothesize that this difference is because of our fixed chunking strategy (in step 2 of the pipeline), which segments documents using a constant token size without adopting to the semantic boundaries of the document. While this approach proved effective on the dev set, it may fail to generalize across more diverse or structurally varied claims in the test set. This is another direction for future work, to explore semantic aware chunking methods, potentially improving retrieval precision and final veracity scores.

6 Conclusion and Future Work

In this paper, we presented **Fathom**, our lightweight and time-efficient pipeline for evidence-based automated fact-checking, built entirely using open-source LLMs. Despite strong accuracy on majority classes such as *Refuted* and *Supported*, our results indicate notable performance gaps on underrepresented labels especially *Conflicting Evidence/Cherry-picking* and *Not Enough Evidence*. These shortcomings highlight ongoing challenges in reasoning over evidence, especially when the



Hình 4: Ví dụ về lập luận chuỗi suy nghĩ do LLM tạo ra với bằng chứng QA một phần (hiển thị Q1–Q2).

người chấm điểm (Akhtar và cộng sự, 2024). Cách tiếp cận này sử dụng một LLM để phân tích cả cặp câu hỏi–trả lời (Q+A) dự đoán và tham chiếu thành các tập hợp sự kiện nguyên tử. Sau đó, chỉ số này tính **Q + A (Ev2R Recall)** bằng cách đo lường bao nhiêu sự kiện nguyên tử tham chiếu được khớp bởi những sự kiện trong bằng chứng được truy xuất.

Nhân độ xác thực dự đoán chỉ được đánh giá nếu **Q+A (Ev2R)Recall vượt quá 0,50**, điều này sau đó đóng góp vào điểm AVeriTeC cuối cùng.

5.3 Kết quả

Chúng tôi tiến hành tất cả các phát triển và đánh giá ban đầu trên tập phát triển AVeriTeC. Như đ ược thể hiện trong Bảng 2, hệ thống của chúng tôi đạt được điểm AVeriTeC Mới (Ev2R) cao hơn là 0,3780, vượt trội so với đường cơ sở. Sự cải thiện này chủ yếu nhờ vào việc truy xuất bằng chứng ngữ nghĩa mạnh mẽ hơn, được phản ánh qua điểm hồi tưởng Q+A (Ev2R) cao hơn là 0,5137.

Về phân loại độ xác thực, Bảng 3 trình bày các điểm F1 cho cả bốn lớp.

mô hình cuối cùng sử dụng Phi-4 lượng tử hóa 4-bit thực hiện tốt trên các danh mục Bị Phủ nhận (0,8436) và Hỗ trợ (0,6877), cũng là những danh mục chiếm đại đa số trong tập phát triển. Tuy nhiên, nó gặp khó khăn với các nhãn ít dữ liệu: Không đủ bằng chứng (0,1455) và đặc biệt là Mâu thuẫn/Chọn lọc (Conflicting/Cherry-picking), nơi nó không phân loại chính xác được bất kỳ trường hợp nào. Điều này làm nổi bật một hạn chế trong giai đoạn dự đoán độ chính xác, đặc biệt đối với các lớp đại diện ít, những lớp cần suy luận tinh vi hơn.

Chúng tôi giả thuyết rằng một lý do cho sự thiếu hụt này là việc sử dụng chiến lược gợi ý không có dữ liệu huấn luyện ở bước dự đoán tính xác thực. Việc kết hợp phương pháp vài ví dụ, đặc biệt với các ví dụ từ NEI và CP/CE, có thể giúp mô hình tổng quát hóa tốt hơn. Mặc dù có những thách thức này, hệ thống đạt được độ chính xác tổng thể mạnh mẽ 72%, cho thấy sự đáng tin cậy của nó trên các lớp chiếm đa số đồng thời chỉ ra những hướng cải thiện rõ ràng trong tương lai.

Để đánh giá khả năng tổng quát hóa của hệ thống, chúng tôi gửi các dự đoán trên tập kiểm tra AVeriTeC chưa thấy trước, nơi các nhãn thực được ẩn. Như được trình bày trong Bảng 4, hệ thống của chúng tôi hơi vượt trội hơn so với phương pháp cơ sở trong khi vẫn duy trì thời gian chạy trung bình trên mỗi khẳng định thấp hơn đáng kể. Tuy nhiên, trái ngược với sự cải thiện đáng kể quan sát được trên tập phát triển, mức chênh lệch so với phương pháp cơ sở trên tập kiểm tra rõ ràng nhỏ hơn.

Chúng tôi giả thuyết rằng sự khác biệt này là do chiến lược chia nhỏ cố định của chúng tôi (ở bước 2 của pipeline), phân đoạn tài liệu bằng kích thước token nhất quán mà không tuân thủ ranh giới ngữ nghĩa của tài liệu. Mặc dù cách tiếp cận này đã chứng minh hiệu quả trên tập hợp dev, nó có thể không thể tổng hợp trên các yêu cầu đa dạng hoặc cấu trúc khác nhau trong tập kiểm thử. Đây là một hướng đi khác cho công việc tương lai, nhằm khám phá các phương pháp chia nhỏ nhận thức ngữ nghĩa, có thể cải thiện độ chính xác truy xuất và điểm số xác thực cuối cùng.

6 Kết luận và công việc tương lai

Trong bài báo này, chúng tôi đã giới thiệu Fathom, một quy trình nhẹ và tiết kiệm thời gian cho việc kiểm tra sự thật tự động dựa trên bằng chứng, được xây dựng hoàn toàn bằng các mô hình ngôn ngữ lớn nguồn mở. Mặc dù có độ chính xác cao đối với các lớp chiếm đa số như Bác bỏ và Hỗ trợ, kết quả của chúng tôi cho thấy khoảng cách hiệu suất đáng kể đối với các nhãn bị đại diện yếu, đặc biệt là Bằng chứng Mâu thuẫn/Chọn lọc và Không đủ bằng chứng. Những hạn chế này nêu bật những thách thức hiện tại trong việc suy luận dựa trên bằng chứng, đặc biệt khi

	Q (Ev2R)	Q + A (Ev2R)	New (Ev2R)	Time/claim (s)
Fathom	0.1848	0.3368	0.2043	22.73
Baseline	0.2723	0.3362	0.2023	33.88

Table 4: AVeriTeC Scores on the **test set**

claim is unclear or has both supporting and opposing information.

Looking forward, we identify several key directions for improving performance. First, enhancing retrieval with *semantic-aware chunking* could help the system adapt more flexibly to diverse document structures, especially on unseen data. Second, integrating *few-shot prompting* for veracity prediction may improve the model’s reasoning capabilities. Finally, fine-tuning small LLMs on curated QA-veracity datasets could enable better discrimination between nuanced veracity types. Together, these enhancements may help build more robust, efficient, and interpretable fact-checking systems.

Acknowledgment

This research is supported by NSERC RGPIN-2025-04608 and DGECR-2025-00153.

References

Marah Abdin, Jyoti Aneja, Harkirat Behl, Sébastien Bubeck, Ronen Eldan, Suriya Gunasekar, Michael Harrison, Russell J Hewett, Mojan Javaheripi, Piero Kauffmann, and 1 others. 2024. Phi-4 technical report. *arXiv preprint arXiv:2412.08905*.

Mubashara Akhtar, Michael Schlichtkrull, and Andreas Vlachos. 2024. Ev2r: Evaluating evidence retrieval in automated fact-checking. *arXiv preprint arXiv:2411.05375*.

Satanjeev Banerjee and Alon Lavie. 2005. Meteor: An automatic metric for mt evaluation with improved correlation with human judgments. In *Proceedings of the acl workshop on intrinsic and extrinsic evaluation measures for machine translation and/or summarization*, pages 65–72.

Svetlana Churina, Anab Barik, and Saisamarth Phaye. 2024. Improving evidence retrieval on claim verification pipeline through question enrichment. In *Proceedings of the Seventh Fact Extraction and VERification Workshop (FEVER)*, pages 64–70.

Boyi Deng, Wenjie Wang, Fengbin Zhu, Qifan Wang, and Fuli Feng. 2025. Cram: Credibility-aware attention modification in llms for combating misinformation in rag. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 39, pages 23760–23768.

Luyu Gao, Xueguang Ma, Jimmy Lin, and Jamie Callan. 2023. [Precise zero-shot dense retrieval without relevance labels](#). In *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 1762–1777, Toronto, Canada. Association for Computational Linguistics.

Zhijiang Guo, Michael Schlichtkrull, and Andreas Vlachos. 2022. [A survey on automated fact-checking](#). *Transactions of the Association for Computational Linguistics*, 10:178–206.

Donna K Harman. 1995. *Overview of the third text retrieval conference (TREC-3)*. 500. DIANE Publishing.

M Abdul Khaliq, Paul Chang, Mingyang Ma, Bernhard Pflugfelder, and Filip Miletic. 2024. Ragar, your falsehood radar: Rag-augmented reasoning for political fact-checking using multimodal large language models. *arXiv preprint arXiv:2404.12065*.

Harold W Kuhn. 1955. The hungarian method for the assignment problem. *Naval research logistics quarterly*, 2(1-2):83–97.

Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, and 1 others. 2020. Retrieval-augmented generation for knowledge-intensive nlp tasks. *Advances in neural information processing systems*, 33:9459–9474.

Luke Merrick, Danmei Xu, Gaurav Nuti, and Daniel Campos. 2024. [Arctic-embed 2.0: Multilingual retrieval without compromise](#). *Preprint*, arXiv:2412.04506.

Niklas Muennighoff, Nouamane Tazi, Loïc Magne, and Nils Reimers. 2022. Mteb: Massive text embedding benchmark. *arXiv preprint arXiv:2210.07316*.

Heesoo Park, Dongjun Lee, Jaehyuk Kim, ChoongWon Park, and Changhwa Park. 2024. Dunamu-ml’s submissions on averitec shared task. In *Proceedings of the Seventh Fact Extraction and VERification Workshop (FEVER)*, pages 71–76.

Mark Rothermel, Tobias Braun, Marcus Rohrbach, and Anna Rohrbach. 2024. Infact: A strong baseline for automated fact-checking. In *Proceedings of the Seventh Fact Extraction and VERification Workshop (FEVER)*, pages 108–112.

Michael Schlichtkrull, Yulong Chen, Chenxi Whitehouse, Zhenyun Deng, Mubashara Akhtar, Rami Aly, Zhijiang Guo, Christos Christodoulopoulos, Oana

	Q (Ev2R)	Q + A (Ev2R)	Mới (Ev2R)	Thời gian/đơn yêu cầu
Hiệu suất	0.1848	0.3368	0.2043	22.73
Đường cơ sở	0.2723	0.3362	0.2023	33.88

Bảng 4: Điểm số AVeriTeC trên tập kiểm tra

lời khẳng định không rõ ràng hoặc có cả thông tin ủng hộ và phản đối.

Nhìn về tương lai, chúng tôi xác định một số hướng chính để cải thiện hiệu suất. Thứ nhất, tăng cường truy xuất với phân mảnh nhận thức ngữ nghĩa có thể giúp hệ thống thích nghi linh hoạt hơn với các cấu trúc tài liệu đa dạng, đặc biệt trên dữ liệu chưa nhìn thấy. Thứ hai, tích hợp khả năng kích hoạt ít mẫu cho dự đoán tính xác thực có thể cải thiện khả năng lập luận của mô hình. Cuối cùng, tinh chỉnh các mô hình ngôn ngữ lớn nhỏ trên các tập dữ liệu QA-veracity được chọn lọc có thể giúp phân biệt tốt hơn giữa các loại tính xác thực tinh vi. Tất cả những cải tiến này cùng nhau có thể giúp xây dựng các hệ thống kiểm tra sự thật vững chắc, hiệu quả và dễ diễn giải hơn.

Lời cảm ơn

Nghiên cứu này được hỗ trợ bởi NSERC RGPIN-2025-04608 và DGECR-2025-00153.

Tài liệu tham khảo

Marah Abdin, Jyoti Aneja, Harkirat Behl, Sébastien Bubeck, Ronen Eldan, Suriya Gunasekar, Michael Harrison, Russell J Hewett, Mojan Javaheripi, Piero Kauffmann, và 1 người khác. 2024. Báo cáo kỹ thuật Phi-4. Bản in trước arXiv arXiv:2412.08905.

Mubashara Akhtar, Michael Schlichtkrull, và Andreas Vlachos. 2024. Ev2r: Đánh giá truy xuất bằng chứng trong kiểm tra thực tế tự động. Bản in trước arXiv arXiv:2411.05375.

Satanjeev Banerjee và Alon Lavie. 2005. Meteor: Một thước đo tự động cho đánh giá dịch máy với sự tương quan được cải thiện với đánh giá của con người. Trong Kỷ yếu hội thảo ACL về các phương pháp đánh giá nội tại và ngoại lai cho dịch máy và/hoặc tóm tắt, trang 65–72.

Svetlana Churina, Anab Barik, và Saisamarth Phaye. 2024. Cải thiện việc truy xuất bằng chứng trên quy trình xác minh tuyên bố thông qua mở rộng câu hỏi. Trong Kỷ yếu Hội thảo lần thứ Bảy về Trích xuất và Xác minh Thực tế (FEVER), trang 64–70.

Boyi Deng, Wenjie Wang, Fengbin Zhu, Qifan Wang, và Fuli Feng. 2025. Cram: Sửa đổi chú ý nhận thức độ tin cậy trong LLMs để chống thông tin sai lệch trong RAG. Trong Kỷ yếu Hội nghị AAAI về Trí tuệ Nhân tạo, tập 39, trang 23760–23768.

Luyu Gao, Xueguang Ma, Jimmy Lin và Jamie Callan. 2023. Truy xuất mật độ chính xác không cần nhân liên quan. Trong Kỷ yếu Hội nghị thường niên lần thứ 61 của Hiệp hội Ngôn ngữ học Máy tính (Tập 1: Bài báo dài), trang 1762–1777, Toronto, Canada. Hiệp hội Ngôn ngữ học Máy tính. Zhijiang Guo, Michael Schlichtkrull và Andreas Vlachos. 2022. Một khảo sát về kiểm tra sự thật tự động. Transactions của Hiệp hội Ngôn ngữ học Máy tính, 10:178–206. Donna K Harman. 1995. Tổng quan về hội nghị tìm kiếm văn bản lần thứ ba (TREC-3). 500. DIANE Publishing. M Abdul Khaliq, Paul Chang, Mingyang Ma, Bernhard Pflugfelder và Filip Miletic. 2024. Ragar, radar nhận diện sai sự thật của bạn: Lý l uận tăng cường RAG cho kiểm tra sự thật chính trị bằng mô hình ngôn ngữ lớn đa phương tiện. Bản in trước arXiv arXiv:2404.12065. Harold W Kuhn. 1955. Phương pháp Hungary cho bài toán phân công. Naval research logistics quarterly, 2(1-2):83–97. Patrick Lewis, Ethan Perez, Al

Cocarascu, Arpit Mittal, and 1 others. 2024. The automated verification of textual claims (averitec) shared task. <i>arXiv preprint arXiv:2410.23850</i>. Michael Schlichtkrull, Zhijiang Guo, and Andreas Vlachos. 2023. Averitec: A dataset for real-world claim verification with evidence from the web. <i>Advances in Neural Information Processing Systems</i>, 36:65128–65167. Ronit Singhal, Pransh Patwa, Parth Patwa, Aman Chadha, and Amitava Das. 2024. Evidence-backed fact checking using rag and few-shot in-context learning with llms. <i>arXiv preprint arXiv:2408.12060</i>. James Thorne, Andreas Vlachos, Christos Christodoulopoulos, and Arpit Mittal. 2018. Fever: a large-scale dataset for fact extraction and verification. <i>arXiv preprint arXiv:1803.05355</i>. Herbert Ullrich, Tomáš Mlynář, and Jan Drchal. 2024. Aic ctu system at averitec: Re-framing automated fact-checking as a simple rag task. <i>arXiv preprint arXiv:2410.11446</i>. Andreas Vlachos and Sebastian Riedel. 2014. Fact checking: Task definition and dataset construction. In <i>Proceedings of the ACL 2014 Workshop on Language Technologies and Computational Social Science</i>, pages 18–22, Baltimore, MD, USA. Association for Computational Linguistics. Soroush Vosoughi, Deb Roy, and Sinan Aral. 2018. The spread of true and false news online. <i>science</i>, 359(6380):1146–1151. Liang Wang, Nan Yang, and Furu Wei. 2023. Query2doc: Query expansion with large language models. <i>arXiv preprint arXiv:2303.07678</i>. Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Fei Xia, Ed Chi, Quoc V Le, Denny Zhou, and 1 others. 2022. Chain-of-thought prompting elicits reasoning in large language models. <i>Advances in neural information processing systems</i>, 35:24824–24837. Yejun Yoon, Jaeyoon Jung, Seunghyun Yoon, and Kun-woo Park. 2024. Hero at averitec: The herd of open large language models for verifying real-world claims. <i>arXiv preprint arXiv:2410.12377</i>.	Cocarascu, Arpit Mittal và 1 người khác. 2024. Nhiệm vụ chia sẻ xác minh tự động các tuyên bố văn bản (averitec). Bản in trước arXiv arXiv:2410.23850. Michael Schlichtkrull, Zhijiang Guo, và Andreas Vlachos. 2023. Averitec: Một bộ dữ liệu cho việc xác minh tuyên bố trong thế giới thực với bằng chứng từ web. <i>Advances in Neural Information Processing Systems</i>, 36:65128–65167. Ronit Singhal, Pransh Patwa, Parth Patwa, Aman Chadha và Amitava Das. 2024. Kiểm tra sự thật dựa trên bằng chứng sử dụng RAG và học ngữ cảnh ít ví dụ với LLMs. Bản in trước trên arXiv arXiv:2408.12060. James Thorne, Andreas Vlachos, Christos Christodoulopoulos, và Arpit Mittal. 2018. Fever: một bộ dữ liệu quy mô lớn để trích xuất và xác minh sự thật. <i>arXiv preprint arXiv:1803.05355</i>. Herbert Ullrich, Tomáš Mlynář, và Jan Drchal. 2024. Hệ thống Aic ctu tại Averitec: Định hình lại kiểm chứng sự thật tự động như một nhiệm vụ RAG đơn giản. Bản in trước arXiv arXiv:2410.11446. Andreas Vlachos và Sebastian Riedel. 2014. Kiểm tra sự thật: Định nghĩa nhiệm vụ và xây dựng bộ dữ liệu. Trong Kỷ yếu Hội thảo ACL 2014 về Công nghệ Ngôn ngữ và Khoa học Xã hội Tính toán, trang 18–22, Baltimore, MD, USA. Hiệp hội Ngôn ngữ Học Tính toán. Soroush Vosoughi, Deb Roy, và Sinan Aral. 2018. Sự lan truyền của tin tức đúng và sai trên mạng. <i>Science</i>, 359(6380):1146–1151. Liang Wang, Nan Yang, và Furu Wei. 2023. Query2doc: Mở rộng truy vấn với các mô hình ngôn ngữ lớn. Bản in trước trên arXiv arXiv:2303.07678. Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Fei Xia, Ed Chi, Quoc V Le, Denny Zhou, và 1 người khác. 2022. Chain-of-thought prompting kích thích khả năng lý luận trong các mô hình ngôn ngữ lớn. Tạp chí Nâng cao trong hệ thống xử lý thông tin thần kinh, 35:24824–24837. Yejun Yoon, Jaeyoon Jung, Seunghyun Yoon, và Kun-woo Park. 2024. Hero tại averitec: Bầy các mô hình ngôn ngữ lớn mở để xác minh các tuyên bố trong thế giới thực. <i>arXiv preprint arXiv:2410.12377</i>.
---	---