# NumPert: Numerical Perturbations to Probe Language Models for Veracity Prediction

**Peter Røysland Aarnes** **Vinay Setty**
University of Stavanger
peter.r.aarnes@uis.no, vsetty@acm.org

## Abstract

Large language models show strong performance on knowledge intensive tasks such as fact-checking and question answering, yet they often struggle with numerical reasoning. We present a systematic evaluation of state-of-the-art models for veracity prediction on numerical claims and evidence pairs using controlled perturbations, including label-flipping probes, to test robustness. Our results indicate that even leading proprietary systems experience accuracy drops of up to 62% under certain perturbations. No model proves to be robust across all conditions. We further find that increasing context length generally reduces accuracy, but when extended context is enriched with perturbed demonstrations, most models substantially recover. These findings highlight critical limitations in numerical fact-checking and suggest that robustness remains an open challenge for current language models.

## 1 Introduction

Verifying claims in social media, political debates, and press releases has become essential. While platforms such as Politifact, Snopes, and FullFact support manual fact-checking, their scalability is limited. Numerical claims, in particular, are tedious and error prone for human annotators (Aly et al., 2021). Neural language models provide a promising alternative for evidence retrieval and preliminary veracity assessment (Guo et al., 2022; Dmonte et al., 2024; Setty, 2024). Yet, recent studies show that both transformer models fine-tuned for numerical claim verification and general purpose large language models struggle with numerical reasoning (Wallat et al., 2024; V et al., 2024; Akhtar et al., 2023), and the reasons remain unclear.

Although prior work has studied LLM fragility in numerical reasoning for QA (Xu et al., 2022) and tabular NLI (Akhtar et al., 2023), no systematic analysis exists for veracity prediction in long-context fact-checking. Our results indicate that models are prone to errors with longer context and reasoning chains. To address this gap, we evaluate state-of-the-art models of different sizes and architectures

**Numerical Perturbation Example**

**Original Claim:** *"In 2020, the company's revenue was 5,000,000 dollars, making a significant growth from the previous year".*
[**Label:** TRUE, **Model Prediction:** TRUE ✓]

**Perturbed Claim:** *"In 2020, the company's revenue was fifty million dollars making a significant growth from the previous year."*
[**Label**: FALSE, **Model Prediction:** TRUE ✗]

**Evidence:** *"A market analysis by MNO Research Group, published in 2021, states: 'PQR Innovations experienced significant growth (...). The revenue for the year 2020 reached 5,000,000 dollars."*[1em]

Figure 1: Example illustrating how the original 'TRUE' claim is perturbed into a 'FALSE' claim, yet the model predicts 'TRUE'.



*Proceedings of the IJCNLP-AACL 2025 Student Research Workshop*, pages 78–95
December 20-24, 2025 ©2025 Association for Computational Linguistics

# NumPert: Biến Đổi Số Học Để Khám Phá Mô Hình Ngôn Ngữ Nhằm Dự Đoán Độ Chính Xác

Peter Røysland Aarnes VinaySetty Đại
học Stavanger peter.r.aarnes@uis.no,
vsetty@acm.org

## Tóm tắt

Các mô hình ngôn ngữ lớn cho thấy hiệu suất mạnh mẽ trong các nhiệm vụ yêu cầu nhiều kiến thức như kiểm tra sự thật và trả lời câu hỏi, tuy nhiên chúng thường gặp khó khăn với lý luận số học. Chúng tôi trình bày một đánh giá hệ thống các mô hình tiên tiến nhất về dự đoán tính chính xác trên các tuyên bố số và cặp bằng chứng bằng cách sử dụng các biến đổi có kiểm soát, bao gồm cả các probe đảo nhãn, để kiểm tra độ bền. Kết quả của chúng tôi chỉ ra rằng ngay cả các hệ thống độc quyền hàng đầu cũng trải qua mức giảm độ chính xác lên đến 62% dưới một số biến đổi nhất định. Không có mô hình nào chứng tỏ được độ bền trên tất cả các điều kiện. Chúng tôi cũng nhận thấy rằng việc tăng độ dài ngữ cảnh thường làm giảm độ chính xác, nhưng khi ngữ cảnh mở rộng được bổ sung bằng các minh chứng đã biến đổi, hầu hết các mô hình phục hồi đáng kể. Những phát hiện này làm nổi bật những hạn chế quan trọng trong việc kiểm tra sự thật số học và gợi ý rằng độ bền vẫn là một thách thức mở đối với các mô hình ngôn ngữ hiện tại.

## 1 Giới thiệu

Việc xác minh các tuyên bố trên mạng xã hội, các cuộc tranh luận chính trị và thông cáo báo chí đã trở nên cần thiết. Trong khi các nền tảng như Politifact, Snopes và FullFact hỗ trợ việc kiểm tra sự thật thủ công, khả năng mở rộng của chúng vẫn bị hạn chế. Các tuyên bố về con số, đặc biệt, là tẻ nhạt và dễ sai sót đối với người gán nhãn thủ công (Aly et al., 2021). Mô hình ngôn ngữ thần kinh cung cấp một lựa chọn hứa hẹn cho việc truy xuất bằng chứng và kiểm tra độ xác thực sơ bộ đánh giá (Guo et al., 2022; Dmonte et al., 2024; Setty, 2024). Tuy nhiên, các nghiên cứu gần đây cho thấy cả các mô hình transformer được tinh chỉnh để xác minh các tuyên bố số và các mô hình ngôn ngữ l ớn đa năng đều gặp khó khăn với lý luận số học (Wallat et al., 2024; V et al., 2024; Akhtar et al., 2023), và các lý do vẫn chưa rõ ràng.

Mặc dù các nghiên cứu trước đây đã nghiên cứu về độ dễ vỡ của LLM trong suy luận số học cho QA (Xu et al., 2022) và NLI dạng bảng (Akhtar et al., 2023), nhưng không có phân tích hệ thống nào tồn tại cho dự đoán độ xác thực trong kiểm t ra sự thật dài hạn. Kết quả của chúng tôi chỉ ra rằng các mô hình có xu hướng mắc lỗi khi bối cảnh và chuỗi suy luận dài hơn. Để giải quyết khoảng trống này, chúng tôi đánh giá các mô hình tiên tiến với các kích thước và kiến trúc khác nhau.

**Ví dụ về nhiễu loạn số**

*Yêu cầu gốc: "Vào năm 2020, doanh thu của công ty là 5.000.000 đô la, tạo ra mức tăng t rưởng đáng kể so với năm trước."*
[**Nhãn: ĐÚNG, Dự đoán của mô hình: ĐÚNG** ✓]

*Yêu cầu gây bối rối: "Vào năm 2020, doanh thu của công ty là năm mươi triệu đô la, tạo ra sự tăng trưởng đáng kể so với năm trước."*
[**Nhãn: SAI, Dự đoán của mô hình: ĐÚNG** ]

*Bằng chứng: "Một phân tích thị trường của Nhóm Nghiên cứu MNO, được công bố vào năm 2021, cho biết: 'PQR Innova- tions đã trải qua sự tăng trưởng đáng kể (...). Doanh thu trong năm 2020 đạt 5.000.000 đô la."*[1em]

Hình 1: Ví dụ minh họa cách tuyên bố 'ĐÚNG' ban đầu bị làm sai lệch thành tuyên bố 'SAI', nhưng mô hình vẫn dự đoán là 'ĐÚNG'.



Kỷ yếu Hội thảo Nghiên cứu Sinh viên IJCNLP-AACL 2025, các trang 78–95, ngày 20-24 tháng 12, 2025 ©2025 Hiệp hội Ngôn ngữ học Máy tính

under varied prompting settings with systematically perturbed numerical claims and evidence.

Manipulating numerical values in unstructured text requires care to ensure that perturbations remain meaningful. We define six probe types: Numeration (*Num*), Approximation (*Approx*), *Range*, Masking (*Mask*), Random Replacement (*Rand-Repl*), and Negative Number (*Neg-Num*) (see Table 1) to systematically modify numbers while preserving claim intent. In some cases, these perturbations also flip the factual label (e.g., changing $5,000,000 to fifty million; see Figure 1). All perturbations are manually verified to ensure correctness and relevance. This study addresses three research questions:

**RQ1** : *Which models in our selection of diverse sizes are most and least robust?*

**RQ2** : *Which numerical perturbations most affect performance?*

**RQ3** : *How do context length and reasoning chains influence robustness?*

To answer this, we test models on claim–evidence pairs, comparing baseline predictions with those on numerically perturbed claims. Larger gaps reflect weaker robustness. We use truthful probes that keep the original label and label-flipping probes that contradict the evidence, under zero-shot, two-shot, and perturbation aware prompts (PAP).

Our results show that all state-of-the-art models are highly vulnerable to numerical perturbations, particularly under *Mask* and *Neg-Num*. We also notice that zero-shot settings outperform two-shot, while providing a few perturbed examples (PAP prompt) helps models recover in most cases. These findings reveal weaknesses in LLM veracity prediction.

## 2 Related work

The interpretability of LLMs is critical for knowledge-intensive tasks like question answering and fact-checking. Probing studies have revealed their opaque decision processes (Belinkov, 2022). For instance, Yang et al. (2024); Lu et al. (2023); Frieder et al. (2024) showed that while LLMs can perform complex reasoning, they often struggle with basic numeracy.

Several works have examined numerical reasoning in LLMs. Wallace et al. (2019) probed embeddings from BERT and GloVe, finding inherent but inconsistent numeracy. Akhtar et al. (2023) evaluated models on tabular data with a hierarchical taxonomy, showing no model excels across all tasks. Xu et al. (2022); Zhou et al. (2024) demonstrated that numerical perturbations in QA often mislead LLMs, while Paruchuri et al. (2024); Chen et al. (2024) highlighted weaknesses in numerical reasoning. Several studies also reveal that LLMs for fact-checking are brittle to textual perturbations, and adversarial edits (Mamta and Cocarascu, 2025; Przybyła et al., 2024; Liu et al., 2025).

Despite prior advances, key gaps remain. Most work does not examine numerical reasoning in *open-domain fact-checking* with real-world, long-context data, and reproducibility is often limited. For instance, Akhtar et al. (2023) rely on synthetic tabular inputs with short context, provide incomplete perturbation details, and lack an accessible repository. In contrast, we evaluate numerical reasoning in realistic, unstructured settings, introduce perturbations that preserve semantic validity, and release full code and data to ensure reproducibility.

## 3 Methodology

Our study examines veracity prediction models by systematically perturbing numerical values in claims to assess their impact on label prediction. The methodology involves (1) curating



dưới các cài đặt nhắc khác nhau với các tuyên bố và bằng chứng số bị làm nhiễu một cách có hệ thống.

Việc thao túng các giá trị số trong văn bản không cấu trúc đòi hỏi sự cẩn thận để đảm bảo rằng các thay đổi vẫn có ý nghĩa. Chúng tôi xác định sáu loại thăm dò: Đánh số (Num), Xấp xỉ (Approx), Khoảng, Che giấu (Mask), Thay thế ngẫu nhiên (Rand-Repl), và Số âm (Neg-Num) (xem Bảng 1) để sửa đổi số một cách có hệ thống trong khi vẫn giữ nguyên ý định của tuyên bố. Trong một số trường hợp, các thay đổi này cũng làm thay đổi nhãn thực tế (ví dụ: thay đổi $5,000,000 thành năm mươi triệu; xem Hình 1). Tất cả các thay đổi đều được kiể m tra thủ công để đảm bảo tính đúng đắn và liên quan. Nghiên cứu này giải quyết ba câu hỏi nghiên cứu:

*RQ1: Mẫu nào trong lựa chọn các kích thước đa dạng của chúng tôi là mạnh mẽ nhất và kém mạnh mẽ nhất?*

*RQ2: Những nhiễu số nào ảnh hưởng nhiều nhất đến hiệu suất?*

*RQ3: Chiều dài ngữ cảnh và chuỗi lập luận ảnh hưởng đến độ bền như thế nào?*

Để trả lời điều này, chúng tôi kiểm tra các mô hình trên các cặp tuyên bố–bằng chứng, so sánh các dự đoán cơ bản với các dự đoán trên các tuyên bố bị thay đổi số liệu. Khoảng cách lớn hơn phản ánh độ bền yếu hơn. Chúng tôi sử dụng các khảo sát trung thực giữ nhãn gốc và các khảo sát đảo nhãn mâu thuẫn với bằng chứng, dưới các lệnh zero-shot, two-shot và lệnh có nhận thức về thay đổi (PAP).

Kết quả của chúng tôi cho thấy tất cả các mô hình tiên tiến nhất đều dễ bị tổn thương bởi các perturbation số học, đặc biệt là dưới Mask và Neg-Num. Chúng tôi cũng nhận thấy rằng các thiết lập zero-shot hoạt động tốt hơn hai-shot, trong khi việc cung cấp một vài ví dụ bị perturb (prompt PAP) giúp các mô hình phục hồi trong hầu hết các trường hợp. Những phát hiện này tiết lộ những điểm yếu trong việc dự đoán độ xác thực của LLM.

**2 Công trình liên quan**

Khả năng giải thích của các mô hình ngôn ngữ lớn (LLM) là rất quan trọng đối với các nhiệm vụ yêu cầu nhiều kiến thức như trả lời câu hỏi và kiểm chứng thông tin. Các nghiên cứu thăm dò đã tiết lộ các quá trình ra quyết định mờ ám của chúng (Belinkov, 2022). Ví dụ, Yang và cộng sự (2024); Lu và cộng sự (2023); Frieder và cộng sự (2024) đã chỉ ra rằng mặc dù LLM có thể thực hiện suy luận phức tạp, nhưng chúng thường gặp khó khăn với các phép tính cơ bản.

Một số nghiên cứu đã khảo sát khả năng lý luận số học trong các LLM. Wallace và cộng sự (2019) khảo sát các embeddings từ BERT và GloVe, phát hiện ra khả năng số học vốn có nh ưng không nhất quán. Akhtar và cộng sự (2023) đánh giá các mô hình trên dữ liệu bảng với một hệ thống phân loại phân cấp, cho thấy không có mô hình nào vượt trội trong tất cả các nhiệm vụ. Xu và cộng sự (2022); Zhou và cộng sự (2024) chứng minh rằng các biến động số trong QA thường làm LLM bị nhầm lẫn, trong khi Par uchuri và cộng sự (2024); Chen và cộng sự (2024) nhấn mạnh những điểm yếu trong khả năng lý luận số học. Một số nghiên cứu cũng chỉ ra rằng các LLM dùng để kiểm tra thông tin có tính giòn trước các biến động văn bản và các chỉnh sửa đối kháng (Mamta và Cocarascu, 2025; Przybyła và cộng sự, 2024; Liu và cộng sự, 2025).

Mặc dù đã có những tiến bộ trước đó, vẫn còn những khoảng trống quan trọng. Hầu hết các nghiên cứu không xem xét lý luận số trong việc kiểm tra sự thật mở với dữ liệu thực tế có bối cảnh dài, và khả năng tái lập thường hạn chế. Chẳng hạn, Akhtar và cộng sự (2023) dựa vào các đầu vào bảng tổng hợp với bối cảnh ngắn, cung cấp chi tiết biến đổi không đầy đủ và thiếu kho lưu trữ có thể truy cập. Ngược lại, chúng tôi đánh giá lý luận số trong các môi trường thực tế, không cấu trúc, giới thiệu các biến đổi giữ nguyên tính hợp lệ về ngữ nghĩa, và phát hành đầy đủ mã cùng dữ liệu để đảm bảo khả năng tái lập.

**3 Phương pháp luận**

Nghiên cứu của chúng tôi xem xét các mô hình dự đoán tính xác thực bằng cách có hệ thống làm xáo trộn các giá trị số trong các nhận định để đánh giá tác động của chúng đến việc dự đoán nhãn. Phương pháp luận bao gồm (1) tuyển chọn

a dataset with diverse numerical expressions (e.g., statistics), (2) applying controlled perturbations (e.g., scaling, replacements, masking). (3) Extensive error analysis leveraging the reasoning tokens.

Table 1: The number of claims per perturbation type that remain 'True' (T→T), remain 'False' (F→F), or switch from 'True' to 'False' (T→F). Unperturbed baseline has 260 `True` claims and 604 `False` claims.

| Category | T → T | F → F | T → F |
|---|---|---|---|
| ***Num*** | 213 | 490 | 213 |
| ***Approx*** | 170 | 404 | 170 |
| ***Range*** | 188 | 411 | 188 |
| ***Mask*** | ✗ | 490 | 213 |
| ***Rand-Repl*** | ✗ | 490 | 213 |
| ***Neg-Num*** | ✗ | 89 | 51 |

### 3.1 Dataset and Preprocessing

We use the *QuanTemp* dataset (V et al., 2024), which contains real world claim-evidence pairs with numerical focus from reputable fact checking sources. Each pair is labeled as `True`, `False`, or `Conflicting`. For our evaluation, we exclude the *Conflicting* class due to its inherent ambiguity. To prevent shortcut learning, we remove summaries from all pairs, requiring models to assess veracity solely from evidence.

Each claim is processed with the spaCy NER tagger (covering *Cardinal*, *Money*, *Percent*, *Time*, *Date*, and *Ordinal*), and numerical values are normalized to digits using the *Word2Number* library (similar to (Akhtar et al., 2023; Wallace et al., 2019; Xu et al., 2022)). Perturbed claims are *manually verified* for validity, and invalid cases are removed.

### 3.2 Perturbation Techniques

We adopt the numerical reasoning taxonomy of Akhtar et al. (2023) (see Table 1). The *Num*, *Approx*, and *Range* settings perturb numbers while remaining consistent with the evidence, so `True` claims stay `True`. Conversely, *Mask*, *Rand-Repl*, and *Neg-Num* modify values such that `True` claims flip to `False`, while `False` claims remain unchanged. We do not perturb `False` to `True`, since falsity can stem from multiple factors and counterfactual claims are often infeasible. Exploring this direction is left for future work. Now we explain the different perturbation techniques:

***Num*:** Tests whether models recognize equivalence between digits and words (e.g., "12" vs. "twelve"), preserving the original label for non-flipping probes. Perturbation applies to `Cardinal`, `Percent`, and `Money`, but not to `Ordinal`, `Time`, or `Date`, except for cardinal numbers within `Time` (e.g., "24 hours" to "twenty four hours"). For the label-flipping probes, the original number is modified (e.g., "12" could be perturbed to "fifteen").

***Approx*:** Non-flipping probes reduces precision by rounding and adding *about* (e.g., "1,025 dollars" to "about 1000 dollars"), retaining truth when close to the evidence. For the label-flipping probes, the original value is altered so that it is no longer reflective of the true amount (e.g., original"1,025 dollars" to "about 1200 dollars").

***Range*:** Non-flipping probes replaces exact values with spans (e.g., "25 percent" to "between 20 and 30 percent"), testing reasoning over intervals. The label-flipping probes modifies the span such that the original number is not within it (e.g., the original "25 percent" is perturbed to "between 30 and 40 percent").

***Rand-Repl*:** Replaces numbers with random values of equal digit length (e.g., "100,000" to "423,823"), mismatching the evidence.

***Mask*:** Hides numbers with "#" tokens according to digit length, including delimiters (e.g., "100,000" to "#######"), requiring inference from evidence.

***Neg-Num*:** Converts values to negatives (e.g., "4%" to "-4%"), applied only to percentages since other entities (money, time, dates) typically use linguistic cues like "decrease."



một tập dữ liệu với các biểu thức số đa dạng (ví dụ, thống kê), (2) áp dụng các biến đổi có kiểm soát (ví dụ, tỉ lệ, thay thế, che dấu). (3) Phân tích lỗi rộng rãi tận dụng các token lý luận.

Bảng 1: Số lượng tuyên bố theo loại nhiễu vẫn giữ 'Đúng' (T→T), vẫn giữ 'Sai' (F→F), hoặc chuyển từ 'Đúng' sang 'Sai' (T→F). Dữ liệu cơ sở không nhiễu có 260 tuyên bố Đúng và 604 tuyên bố Sai.

| Thể loại | T → T | F →F | T →F |
|---|---|---|---|
| ***Num*** | 213 | 490 | 213 |
| ***Khoảng*** | 170 | 404 | 170 |
| ***Phạm vi*** | 188 | 411 | 188 |
| ***Mask*** | ✗ | 490 | 213 |
| ***Rand-Repl*** | ✗ | 490 | 213 |
| ***Số âm*** | ✗ | 89 | 51 |

### 3.1 Bộ dữ liệu và Tiền xử lý

Chúng tôi sử dụng tập dữ liệu QuanTemp (V và cộng sự, 2024), chứa các cặp tuyên bố - bằng chứng thực tế với trọng tâm số liệu từ các nguồn kiểm chứng sự thật uy tín. Mỗi cặp được gắn nhãn là Đúng, Sai hoặc Mâu thuẫn. Trong đánh giá của chúng tôi, chúng tôi loại bỏ lớp Mâu thuẫn do sự mơ hồ vốn có của nó. Để ngăn việc học tắt, chúng tôi loại bỏ các bản tóm tắt khỏi tất cả các cặp, yêu cầu các mô hình đánh giá tính xác thực chỉ dựa trên bằng chứng.

Mỗi tuyên bố được xử lý với trình gắn thẻ NER của spaCy (bao gồm Cardinal, Money, Percent, Time, Date và Ordinal), và các giá trị số được chuẩn hóa thành chữ số bằng cách sử dụng thư viện Word2Number (tương tự như (Akhtar et al., 2023; Wallace et al., 2019; Xu et al., 2022)). Các tuyên bố bị thay đổi được xác minh thủ công để đảm bảo hợp lệ, và các trường hợp không hợp lệ sẽ bị loại bỏ.

### 3.2 Kỹ thuật nhiễu loạn

Chúng tôi áp dụng phân loại suy luận số học của Akhtar và cộng sự (2023) (xem Bảng 1). Các cài đặt Num, Approx, và Range làm nhiễu số liệu trong khi vẫn phù hợp với bằng chứng, nên các khẳng định đúng vẫn giữ đúng. Ngược lại, Mask, Rand-Repl, và Neg-Num thay đổi các giá trị như

rằng các tuyên bố đúng chuyển thành sai, trong khi các tuyên bố sai vẫn giữ nguyên. Chúng tôi không làm sai thành đúng, vì tính sai có thể xuất phát từ nhiều yếu tố và các tuyên bố phản thực tế thường không khả thi. Khám phá hướng này sẽ được để lại cho công việc tương lai. Bây giờ chúng tôi giải thích các kỹ thuật làm nhiễu khác nhau:

Num: Kiểm tra xem các mô hình có nhận ra sự tương đương giữa chữ số và từ viết (ví dụ, "12" và "twelve") hay không, đồng thời giữ nguyên nhãn gốc cho các câu hỏi không đổi nhãn. Sự biến động áp dụng cho các số Cardinal, Percent và Money, nhưng không áp dụng cho Ordinal, Time hoặc Date, trừ trường hợp số cardinal trong Time (ví dụ, "24 hours" thành "twenty four hours"). Đối với các câu hỏi đổi nhãn, số gốc sẽ được sửa đổi (ví dụ, "12" có thể bị thay đổi thành "fifteen").

Xấp xỉ: Các phép đo không lật nhãn làm giảm độ chính xác bằng cách làm tròn và cộng thêm khoảng (ví dụ, "1.025 đô la" t hành "khoảng 1000 đô la"), vẫn giữ đúng khi gần với bằng chứng. Đối với các phép đo lật nhãn, giá trị ban đầu được thay đổi để không còn phản ánh số tiền thực sự (ví dụ, ban đầu "1.025 đô la" thành "khoảng 1200 đô la").

Phạm vi: Các kiểm tra không lật thay thế các giá trị chính xác bằng các khoảng (ví dụ, "25 phần trăm" thành "từ 20 đến 30 phần trăm"), kiểm tra khả năng lý luận trên các khoảng. Các kiểm tra lật nhãn thay đổi khoảng sao cho số ban đầu không nằm trong đó (ví dụ, số ban đầu "25 phần trăm" bị thay đổi thành "từ 30 đến 40 phần trăm").

Rand-Repl: Thay thế các con số bằng các giá trị ngẫu nhiên có cùng độ dài chữ số (ví dụ, "100.000" thành " 423.823"), làm cho bằng chứng không khớp.

Mặt nạ: Che các con số bằng các ký tự "#" theo độ dài chữ số, bao gồm cả dấu phân cách (ví dụ, "100,000" thành "#######"), yêu cầu suy luận từ bằng chứng.

Neg-Num: Chuyển các giá trị thành số âm (ví dụ: " 4%" thành "-4%"), chỉ áp dụng cho phần trăm vì các thực thể khác (tiền, thời gian, ngày tháng) thường sử dụng các dấu hiệu ngôn ngữ như "giả m."

### 3.3 Prompting Strategy

All models use identical instructions under three prompting strategies: (1) **Zero-shot** with only instructions and no demonstrations (see Appendix B), (2) **Two-shot** prompt that extends the zero-shot prompt with one `True` and one `False` demonstration from training data with evidence and rationale (Brown et al., 2020). (3) We also test models with a perturbation aware prompt **(PAP)**, which pairs a perturbed claim with one sentence evidence for each perturbation type and flipped label. A similar approach is used by (Hu et al., 2024) in a RAG setting. Full prompts are provided in Appendix B.

## 4 Experimental Setup

This section describes our experimental framework, including the language models used, and evaluation methods.

### 4.1 Model Selection

***Open-weight LLMs:*** *DeepSeek-R1-32B*, *Qwen3-32B*, *Llama3.3-70B*, *Llama 3.2-1B*, and *Mistral-7B* (All models are from Ollama framework[1] with Q4_K_M quantization).

***Proprietary LLMs:*** *GPT-4o (v2024-08-06)*, *GPT-4o-mini (v2024-07-18)*, *GPT-5 (v2025-08-07)*, *GPT-o3 (v2025-04-16)*, and *Gemini 2.5 Flash (v2025-06)* (All models are accessed via their respective official APIs)

Models with thinking are marked with superscript $T$. All models ran with temperature 0 and JSON output; open-weight and OpenAI models used default (medium) reasoning effort. For Gemini 2.5 Flash$^T$, we fixed the thinking budget to 8192 (vs. the default 1) for cost efficiency. Other settings followed defaults. We exclude *Llama 3.2-1B* and *Mistral-7B* from the main results due to limited robustness; details are in Appendix A.2. Invalid predictions are rare, except for DeepSeek-R1$^T$, which yields 6.8% invalid outputs under zero-shot. Thinking variants generally produce more invalid outputs than their non-thinking counterparts (see Appendix C). Code and data can be accessed though our GitHub repository[2].

### 4.2 Evaluation

Robustness is assessed by comparing baseline performance on non-perturbed claims with performance on perturbed ones. We use per-class accuracy metric. We use accuracy as the primary metric for $T \rightarrow F$ evaluations. To gain greater insight into model errors, we manually analyze reasoning tokens of zero-shot vs. PAP for `T` $\rightarrow$ `F` claims to look for common patterns that models fall into while evaluating a claim.

## 5 Results

We report results across models and perturbation settings. We first describe performance on unperturbed claims, then analyze changes under non-flipped and flipped label conditions. Results for `False` $\rightarrow$ `False` cases are omitted here for brevity (see Appendix A.2). Models are evaluated under three prompting regimes defined in Section 3.3 (see Appendix B for full prompts).

### 5.1 `True` $\rightarrow$ `False`

We start with the most challenging case: label-flipping perturbations (`True` $\rightarrow$ `False`), shown in Table 2. Since the claim and ground-truth label are flipped, all reported results reflect the flipped label. A drop in performance means models still predict `True` instead of the expected `False` and less robust. Performance on unperturbed `True` claims is given in the "Original" column as the baseline for each prompting regime.

[1] https://ollama.com/search

[2] https://github.com/iai-group/adversarial_attack_numerical_claims/



#### 3.3 Chiến lược đưa ra gợi ý

Tất cả các mô hình sử dụng các hướng dẫn giống nhau dưới ba chiến lược gợi ý: (1) Zero-shot chỉ với hướng dẫn mà không có minh họa (xem Phụ lục B), (2) Gợi ý hai bước mở rộng gợi ý zero-shot với một minh họa True và một minh họa False từ dữ liệu huấn luyện kèm bằng chứng và lý giải (Brown et al., 2020). (3) Chúng tôi cũng kiể m tra các mô hình với gợi ý nhận biết biến đổi (PAP), kết hợp một tuyên bố bị biến đổi với một câu bằng chứng cho mỗi loại biến đổi và nhãn bị đảo ngược. Một phương pháp tương tự được sử dụng bởi (Hu et al., 2024) trong bối cảnh aRAG. Toàn bộ các gợi ý được cung cấp trong Phụ lục B.

## 4 Thiết lập Thí nghiệm

Phần này mô tả khung thí nghiệm của chúng tôi, bao gồm các mô hình ngôn ngữ sử dụng và phương pháp đánh giá.

#### 4.1 Lựa chọn mô hình

***LLM trọng lượng mở: DeepSeek-R1-32B,***

Qwen3-32B, Llama3.3-70B, Llama 3.2-1B, và Mistral-7B (Tất cả các mô hình đều từ framework Ollama [1] với lượng tử hóa Q 4_ K _ M).

*Các LLM độc quyền: GPT-4o (v2024-08-06), GPT-4o-mini (v2024-07-18), GPT-5 (v2025-08-07), GPT-o3 (v2025-04-16), và Gemini 2.5 Flash (v2025-06) (Tất cả các mô hình đều được truy cập thông qua API chính thức của chúng)*

Các mô hình có khả năng suy nghĩ được đánh dấu bằng số mũ $T$. Tất cả các mô hình chạy với nhiệt độ 0 và đầu ra JSON; các mô hình open-weight và OpenAI sử dụng mức nỗ lực suy luận mặc định (trung bình). Đối với Gemini 2.5 Flash$^T$, chúng tôi đã cố định ngân sách suy nghĩ là 8192 (so với mặc định là 1) để hiệu quả về chi phí. Các thiết lập khác theo mặc định. Chúng tôi loại trừ Llama 3.2-1B và Mistral-7B khỏi kết quả chính do độ ổn định hạn chế; chi tiết có trong Phụ lục A.2. Các dự đoán không hợp lệ là hiếm, ngoại trừ DeepSeek-R1$^T$, vốn tạo ra 6,8% kết quả không hợp lệ trong trường hợp zero-shot. Các biến thể Thinking nói chung tạo ra nhiều kết quả không hợp lệ hơn so với các đối tác không Thinking của chúng (xem Phụ l ục C). Mã và dữ liệu có thể truy cập qua kho l ưu trữ GitHub của chúng tôi[2].

#### 4.2 Đánh giá

Độ bền được đánh giá bằng cách so sánh hiệu suất cơ bản trên các tuyên bố không bị xáo trộn với hiệu suất trên các tuyên bố bị xáo trộn. Chúng tôi sử dụng chỉ số độ chính xác theo từng lớp. Chúng tôi sử dụng độ chính xác làm chỉ số chính cho đánh giá $T \rightarrow F$. Để hiểu rõ hơn về lỗi của mô hình, chúng tôi tự tay phân tích các token suy l uận của zero-shot so với PAP cho các tuyên bố T $\rightarrow$ F để tìm các mẫu chung mà mô hình mắc phải khi đánh giá một tuyên bố.

## 5 kết quả

Chúng tôi báo cáo kết quả trên các mô hình và các thiết lập nhiễu. Trước tiên, chúng tôi mô tả hiệu suất trên các tuyên bố không bị nhiễu, sau đó phân tích các thay đổi dưới các điều kiện nhãn không đảo và đảo. Kết quả cho các trường hợp False $\rightarrow$False được bỏ qua tại đây để ngắn gọn (xem Phụ lục A.2). Các mô hình được đánh giá dưới ba c hế độ gợi ý được định nghĩa trong Mục 3.3 (xem Phụ lục B để biết đầy đủ các gợi ý).

### 5.1 Đúng $\rightarrow$Sai

Chúng tôi bắt đầu với trường hợp thách t hức nhất: nhiễu lật nhãn (True $\rightarrow$ False), được hiển thị trong Bảng 2. Do khẳng định và nhãn thực tế bị lật, tất cả các kết quả được báo cáo phản ánh nhãn đã bị lật. Sự giảm hiệu suất có nghĩa là các mô hình vẫn dự đoán True thay vì False như mong đợi và kém bền vững hơn. Hiệu suất trên các khẳng định True không bị nhiễu được đưa ra trong cột "Original" như là cơ sở cho mỗi chế độ gợi ý.

[1] https://ollama.com/search

[2] https://github.com/iai-group/tấn công_gây nhiễu_số liệu_yêu cầu/

Table 2: Accuracy (reported in %) for 'True' dataset split for label flips perturbations (True → False), and comparing accuracy variance between the flipped probes to model performance on unaltered *original* claims accuracy (-x indicates a drop; +x indicates an increase). Values in bold denote the highest accuracy within each perturbation setting, separated by open-weight and proprietary models.

| Model | Original | Approx | Neg-num | Num | Rand-repl | Range | Mask |
|---|---|---|---|---|---|---|---|
| **Zero-shot** | | | | | | | |
| Llama3.3-70B | 87.32 | 87.65$^{+0.32}$ | **62.75**$^{-24.58}$ | 68.54$^{-18.78}$ | **91.08**$^{+3.76}$ | 82.45$^{-4.88}$ | 10.80$^{-76.53}$ |
| DeepSeek-R1-32B | 81.69 | **89.41**$^{+7.72}$ | 39.22$^{-42.47}$ | 56.34$^{-25.35}$ | 88.73$^{+7.04}$ | 81.91$^{+0.22}$ | **23.47**$^{-58.22}$ |
| DeepSeek-R1-32B$^{T}$ | **87.44** | 85.06$^{-2.37}$ | 31.91$^{-55.52}$ | 69.43$^{-18.01}$ | 84.73$^{-2.71}$ | 86.98$^{-0.46}$ | 10.63$^{-76.81}$ |
| Qwen3-32B | 84.35 | 78.24$^{-6.12}$ | 43.14$^{-41.21}$ | 58.78$^{-25.57}$ | 84.51$^{+0.16}$ | 80.32$^{-4.03}$ | 16.43$^{-67.92}$ |
| Qwen3-32B$^{T}$ | 85.99 | 89.38$^{+3.38}$ | 34.04$^{-51.95}$ | **78.24**$^{-7.75}$ | 87.88$^{+1.89}$ | **87.64**$^{+1.65}$ | 12.38$^{-73.61}$ |
| GPT-4o | 80.00 | 88.82$^{+8.82}$ | 47.06$^{-32.94}$ | 73.24$^{-6.76}$ | 90.61$^{+10.61}$ | 91.49$^{+11.49}$ | 19.25$^{-60.75}$ |
| GPT-4o-Mini | **85.38** | 68.24$^{-17.15}$ | 25.49$^{-59.89}$ | 56.81$^{-28.58}$ | 78.87$^{-6.51}$ | 75.00$^{-10.38}$ | 11.27$^{-74.12}$ |
| GPT-5$^{T}$ | 76.15 | 93.53$^{+17.38}$ | 33.33$^{-42.82}$ | **86.38**$^{+10.23}$ | 89.20$^{+13.05}$ | 92.02$^{+15.87}$ | 19.72$^{-56.44}$ |
| GPT-o3$^{T}$ | 75.77 | 89.41$^{+13.64}$ | 25.49$^{-50.28}$ | 84.98$^{+9.21}$ | 88.73$^{+12.96}$ | 90.96$^{+15.19}$ | 21.60$^{-54.17}$ |
| Gemini 2.5F | 82.69 | **95.29**-$^{+12.60}$ | 54.90$^{-27.79}$ | 83.57$^{+0.88}$ | **96.71**$^{+14.02}$ | **93.09**$^{+10.39}$ | **25.82**$^{-56.87}$ |
| Gemini 2.5F$^{T}$ | 71.54 | 88.82$^{+17.29}$ | **58.82**$^{-12.71}$ | 82.63$^{+11.09}$ | 89.67$^{+18.13}$ | 90.43$^{+18.89}$ | 16.90$^{-54.64}$ |
| **Two-shot** | | | | | | | |
| Llama3.3-70B | **91.55** | 72.35$^{-19.20}$ | **33.33**$^{-58.22}$ | 46.48$^{-45.07}$ | 78.26$^{-13.29}$ | 57.98$^{-33.57}$ | 8.92$^{-82.63}$ |
| DeepSeek-R1-32B | 89.67 | 65.29$^{-24.38}$ | 21.57$^{-68.10}$ | 37.09$^{-52.58}$ | 74.70$^{-14.97}$ | 58.51$^{-31.16}$ | 12.21$^{-77.46}$ |
| DeepSeek-R1-32B$^{T}$ | 86.32 | 88.55$^{+2.23}$ | 22.00$^{-64.32}$ | 71.15$^{-15.17}$ | 88.49$^{+2.17}$ | 87.17$^{+0.85}$ | 9.43$^{-76.89}$ |
| Qwen3-32B | 79.81 | 70.59$^{-9.22}$ | 37.25$^{-42.56}$ | 49.77$^{-30.05}$ | 66.40$^{-13.41}$ | 72.87$^{-6.94}$ | **20.66**$^{-59.15}$ |
| Qwen3-32B$^{T}$ | 83.49 | **86.98**$^{+3.49}$ | 27.45$^{-56.04}$ | **78.20**$^{-5.29}$ | **88.76**$^{+5.26}$ | **87.23**$^{+3.74}$ | 12.74$^{-70.75}$ |
| GPT-4o | 86.54 | 82.35$^{-4.19}$ | 33.33$^{-53.21}$ | 68.54$^{-17.99}$ | 87.32$^{+0.79}$ | 85.64$^{-0.90}$ | 13.62$^{-72.92}$ |
| GPT-4o-Mini | **89.62** | 67.06$^{-22.56}$ | 27.45$^{-62.16}$ | 50.70$^{-38.91}$ | 77.46$^{-12.15}$ | 73.94$^{-15.68}$ | 20.19$^{-69.43}$ |
| GPT-5$^{T}$ | 77.69 | **91.18**$^{+13.48}$ | 29.41$^{-48.28}$ | 84.04$^{+6.35}$ | 88.26$^{+10.57}$ | 88.83$^{+11.14}$ | 18.78$^{-58.91}$ |
| GPT-o3$^{T}$ | 75.77 | 89.41$^{+13.64}$ | 23.53$^{-52.24}$ | **85.45**$^{+9.68}$ | 89.67$^{+13.90}$ | **90.43**$^{+14.66}$ | 22.07$^{-53.70}$ |
| Gemini 2.5F | 85.00 | 87.06$^{+2.06}$ | 35.29$^{-49.71}$ | 70.89$^{-14.11}$ | **94.37**$^{+9.37}$ | 85.64$^{+0.64}$ | **22.90**$^{-62.10}$ |
| Gemini 2.5F$^{T}$ | 74.23 | 90.00$^{+15.77}$ | **52.94**$^{-21.29}$ | 82.16$^{+7.93}$ | 92.02$^{+17.79}$ | 88.83$^{+14.60}$ | 15.96$^{-58.27}$ |
| **Perturbation Aware Prompt (PAP)** | | | | | | | |
| Qwen3-32B | 79.34 | 89.41$^{+10.07}$ | 76.47$^{-2.87}$ | 73.71$^{-5.63}$ | 90.61$^{+11.27}$ | 89.36$^{+10.02}$ | **67.61**$^{-11.74}$ |
| Qwen3-32B$^{T}$ | 71.23 | **95.27**$^{+24.04}$ | 74.00$^{+2.77}$ | **90.14**$^{+18.91}$ | **94.37**$^{+23.14}$ | **94.62**$^{+23.40}$ | 44.85$^{-26.38}$ |
| Gemini 2.5F | **81.92** | **97.06**$^{+15.14}$ | 74.51$^{-7.41}$ | 84.98$^{+3.05}$ | **97.18**$^{+15.26}$ | **94.68**$^{+12.76}$ | 29.11$^{-52.82}$ |
| Gemini 2.5F$^{T}$ | 63.08 | 91.76$^{+28.69}$ | **88.24**$^{+25.16}$ | **86.85**$^{+23.78}$ | 92.02$^{+28.94}$ | 90.96$^{+27.88}$ | 26.29$^{-36.79}$ |

### 5.1.1 Performance on Unperturbed Claims

In zero-shot, most models cluster in the low to high eighties, with Llama 3.3-70B performing best at about 87% and Qwen3-32B$^{T}$is close behind at 86%. Proprietary models are slightly lower, with GPT-4o-Mini reaching about 85% as the strongest performer. This suggests that larger models may require more specified prompts to achieve higher accuracy.

With two-shot prompting, baselines increase for Llama 3.3-70B, the GPT variants, and DeepSeek-R1. Llama 3.3-70B surpasses 91%. In contrast, Qwen3-32B variants decline, Gemini 2.5F drops slightly, and its thinking variant shows a modest improvement. Under PAP, both Qwen and Gemini models exhibit performance declines. Models get confused by PAP since it contains counterfactual examples.

Overall, adding few-shot examples improves baselines for Llama and GPT models but tends to reduce them for Qwen and Gemini. No-



Bảng 2: Độ chính xác (được báo cáo theo %) cho tập dữ liệu 'True' phân tách cho các nhiễu lật nhãn (True → False), và so sánh biến thiên độ chính xác giữa các thăm dò bị lật với hiệu suất mô hình trên độ chính xác của các tuyên bố gốc không thay đổi (-x cho biết giảm; +x cho biết tăng). Các giá trị in đậm biểu thị độ chính xác cao nhất trong từng cài đặt nhiễu, được phân tách theo mô hình mở và mô hình độc quyền.

| Mô hình | Nguyên bản | Khoảng | Số âm | Num | Rand-repl | Phạm vi | Mask |
|---|---|---|---|---|---|---|---|
| **Không cần huấn luyện trước** | | | | | | | |
| Llama3.3-70B | 87.32 | 87.65$^{+0.32}$ | **62.75**$^{-24.58}$ | 68.54$^{-18.78}$ | **91.08**$^{+3.76}$ | 82.45$^{-4.88}$ | 10.80$^{-76.53}$ |
| DeepSeek-R1-32B | 81.69 | **89.41**$^{+7.72}$ | 39.22$^{-42.47}$ | 56.34$^{-25.35}$ | 88.73$^{+7.04}$ | 81.91$^{+0.22}$ | **23.47**$^{-58.22}$ |
| DeepSeek-R1-32B$^{T}$ | **87.44** | 85.06$^{-2.37}$ | 31.91$^{-55.52}$ | 69.43$^{-18.01}$ | 84.73$^{-2.71}$ | 86.98$^{-0.46}$ | 10.63$^{-76.81}$ |
| Qwen3-32B | 84.35 | 78.24$^{-6.12}$ | 43.14$^{-41.21}$ | 58.78$^{-25.57}$ | 84.51$^{+0.16}$ | 80.32$^{-4.03}$ | 16.43$^{-67.92}$ |
| Qwen3-32B$^{T}$ | 85.99 | 89.38$^{+3.38}$ | 34.04$^{-51.95}$ | **78.24**$^{-7.75}$ | 87.88$^{+1.89}$ | **87.64**$^{+1.65}$ | 12.38$^{-73.61}$ |
| GPT-4o | 80.00 | 88.82$^{+8.82}$ | 47.06$^{-32.94}$ | 73.24$^{-6.76}$ | 90.61$^{+10.61}$ | 91.49$^{+11.49}$ | 19.25$^{-60.75}$ |
| GPT-4o-Mini | **85.38** | 68.24$^{-17.15}$ | 25.49$^{-59.89}$ | 56.81$^{-28.58}$ | 78.87$^{-6.51}$ | 75.00$^{-10.38}$ | 11.27$^{-74.12}$ |
| GPT-5$^{T}$ | 76.15 | 93.53$^{+17.38}$ | 33.33$^{-42.82}$ | **86.38**$^{+10.23}$ | 89.20$^{+13.05}$ | 92.02$^{+15.87}$ | 19.72$^{-56.44}$ |
| GPT-o3$^{T}$ | 75.77 | 89.41$^{+13.64}$ | 25.49$^{-50.28}$ | 84.98$^{+9.21}$ | 88.73$^{+12.96}$ | 90.96$^{+15.19}$ | 21.60$^{-54.17}$ |
| Gemini 2.5F | 82.69 | **95.29**-$^{+12.60}$ | 54.90$^{-27.79}$ | 83.57$^{+0.88}$ | **96.71**$^{+14.02}$ | **93.09**$^{+10.39}$ | **25.82**$^{-56.87}$ |
| Gemini 2.5F$^{T}$ | 71.54 | 88.82$^{+17.29}$ | **58.82**$^{-12.71}$ | 82.63$^{+11.09}$ | 89.67$^{+18.13}$ | 90.43$^{+18.89}$ | 16.90$^{-54.64}$ |
| **Cảnh hai nhân vật** | | | | | | | |
| Llama3.3-70B | **91.55** | 72.35$^{-19.20}$ | **33.33**$^{-58.22}$ | 46.48$^{-45.07}$ | 78.26$^{-13.29}$ | 57.98$^{-33.57}$ | 8.92$^{-82.63}$ |
| DeepSeek-R1-32B | 89.67 | 65.29$^{-24.38}$ | 21.57$^{-68.10}$ | 37.09$^{-52.58}$ | 74.70$^{-14.97}$ | 58.51$^{-31.16}$ | 12.21$^{-77.46}$ |
| DeepSeek-R1-32B$^{T}$ | 86.32 | 88.55$^{+2.23}$ | 22.00$^{-64.32}$ | 71.15$^{-15.17}$ | 88.49$^{+2.17}$ | 87.17$^{+0.85}$ | 9.43$^{-76.89}$ |
| Qwen3-32B | 79.81 | 70.59$^{-9.22}$ | 37.25$^{-42.56}$ | 49.77$^{-30.05}$ | 66.40$^{-13.41}$ | 72.87$^{-6.94}$ | **20.66**$^{-59.15}$ |
| Qwen3-32B$^{T}$ | 83.49 | **86.98**$^{+3.49}$ | 27.45$^{-56.04}$ | **78.20**$^{-5.29}$ | **88.76**$^{+5.26}$ | **87.23**$^{+3.74}$ | 12.74$^{-70.75}$ |
| GPT-4o | 86.54 | 82.35$^{-4.19}$ | 33.33$^{-53.21}$ | 68.54$^{-17.99}$ | 87.32$^{+0.79}$ | 85.64$^{-0.90}$ | 13.62$^{-72.92}$ |
| GPT-4o-Mini | **89.62** | 67.06$^{-22.56}$ | 27.45$^{-62.16}$ | 50.70$^{-38.91}$ | 77.46$^{-12.15}$ | 73.94$^{-15.68}$ | 20.19$^{-69.43}$ |
| GPT-5$^{T}$ | 77.69 | **91.18**$^{+13.48}$ | 29.41$^{-48.28}$ | 84.04$^{+6.35}$ | 88.26$^{+10.57}$ | 88.83$^{+11.14}$ | 18.78$^{-58.91}$ |
| GPT-o3$^{T}$ | 75.77 | 89.41$^{+13.64}$ | 23.53$^{-52.24}$ | **85.45**$^{+9.68}$ | 89.67$^{+13.90}$ | **90.43**$^{+14.66}$ | 22.07$^{-53.70}$ |
| Gemini 2.5F | 85.00 | 87.06$^{+2.06}$ | 35.29$^{-49.71}$ | 70.89$^{-14.11}$ | **94.37**$^{+9.37}$ | 85.64$^{+0.64}$ | **22.90**$^{-62.10}$ |
| Gemini 2.5F$^{T}$ | 74.23 | 90.00$^{+15.77}$ | **52.94**$^{-21.29}$ | 82.16$^{+7.93}$ | 92.02$^{+17.79}$ | 88.83$^{+14.60}$ | 15.96$^{-58.27}$ |
| **Gợi ý Nhận Thức Sự Nhiễu (PAP)** | | | | | | | |
| Qwen3-32B | 79.34 | 89.41$^{+10.07}$ | 76.47$^{-2.87}$ | 73.71$^{-5.63}$ | 90.61$^{+11.27}$ | 89.36$^{+10.02}$ | **67.61**$^{-11.74}$ |
| Qwen3-32B$^{T}$ | 71.23 | **95.27**$^{+24.04}$ | 74.00$^{+2.77}$ | **90.14**$^{+18.91}$ | **94.37**$^{+23.14}$ | **94.62**$^{+23.40}$ | 44.85$^{-26.38}$ |
| Gemini 2.5F | **81.92** | **97.06**$^{+15.14}$ | 74.51$^{-7.41}$ | 84.98$^{+3.05}$ | **97.18**$^{+15.26}$ | **94.68**$^{+12.76}$ | 29.11$^{-52.82}$ |
| Gemini 2.5F$^{T}$ | 63.08 | 91.76$^{+28.69}$ | **88.24**$^{+25.16}$ | **86.85**$^{+23.78}$ | 92.02$^{+28.94}$ | 90.96$^{+27.88}$ | 26.29$^{-36.79}$ |

### 5.1.1 Hiệu suất trên các yêu cầu không bị xáo trộn

Trong zero-shot, hầu hết các mô hình tập trung trong khoảng từ thấp đến cao của thập phân tám mươi, với Llama 3.3-70B hoạt động tốt nhất khoảng 87% và Qwen3-32B$^{T}$ đứng ngay sau với 86 %. Các mô hình sở hữu độc quyền thấp hơn một chút, với GPT-4o-Mini đạt khoảng 85% là hiệu s uất mạnh nhất. Điều này cho thấy các mô hình l ớn hơn có thể cần các prompt được chỉ định cụ t hể hơn để đạt độ chính xác cao hơn.

Với việc gợi ý hai bước, các đường cơ sở tăng lên đối với Llama 3.3-70B, các biến thể GPT và DeepSeek-R1. Llama 3.3-70B vượt qua 91%. Ngược lại, các biến thể Qwen3-32B giảm, Gemini 2.5F giảm nhẹ, và biến thể tư duy của nó cho thấy cải thiện khiêm tốn. Dưới PAP, cả mô hình Qwen và Gemini đều thể hiện sự giảm hiệu suất. Các mô hình bị nhầm lẫn bởi PAP vì nó chứa các ví dụ phản một cách giả định.

Tổng thể, việc thêm một vài ví dụ mẫu cải thiện các chuẩn cơ sở cho các mô hình Llama và GPT nhưng có xu hướng làm giảm hiệu quả cho Qwen và Gemini. Không-

Table 3: Accuracy (reported in %) on the 'True' dataset split under non label-flipping perturbations (True → True). The table compares perturbed accuracy to unaltered *original* claim accuracy (-x indicates a drop; +x indicates an increase). Values in bold denote the highest accuracy within each perturbation setting, separated by open-weight and proprietary models.

| Model | Approx | Num | Range |
|---|---|---|---|
| **Zero-shot** | | | |
| Llama3.3-70B | 71.76$^{-15.56}$ | **86.38**$^{-0.94}$ | 70.21$^{-17.11}$ |
| DeepSeek-R1 | 75.29$^{-6.40}$ | 82.63$^{+0.94}$ | 67.55$^{-14.14}$ |
| DeepSeek-R1$^{T}$ | **81.44**$^{-6.00}$ | 84.62$^{-2.82}$ | **79.23**$^{-8.20}$ |
| Qwen3 | 73.53$^{-10.82}$ | 85.88$^{+1.53}$ | 62.23$^{-22.12}$ |
| Qwen3-32B$^{T}$ | 79.39$^{-6.60}$ | 85.02$^{-0.97}$ | 78.24$^{-7.76}$ |
| GPT-4o | 68.82$^{-11.18}$ | 80.28$^{+0.28}$ | 55.32$^{-24.68}$ |
| GPT-4o-Mini | **81.18**$^{-4.21}$ | **92.96**$^{+7.57}$ | **79.79**$^{-5.60}$ |
| GPT-5$^{T}$ | 75.29$^{-0.86}$ | 77.00$^{+0.84}$ | 73.40$^{-2.75}$ |
| GPT-o3$^{T}$ | 74.71$^{-1.06}$ | 77.46$^{+1.70}$ | 77.66$^{+1.89}$ |
| Gemini 2.5F | 60.69$^{-22.00}$ | 79.81$^{-2.88}$ | 43.92$^{-38.78}$ |
| Gemini 2.5F$^{T}$ | 68.24$^{-3.30}$ | 71.76$^{+0.22}$ | 61.70$^{-9.84}$ |
| **Two-shot** | | | |
| Llama3.3-70B | 84.71$^{-6.84}$ | 90.14$^{-1.41}$ | 85.64$^{-5.91}$ |
| DeepSeek-R1 | **88.82**$^{-0.85}$ | **90.61**$^{+0.94}$ | **86.70**$^{-2.97}$ |
| DeepSeek-R1$^{T}$ | 82.25$^{-4.07}$ | 87.50$^{+1.18}$ | 77.13$^{-9.19}$ |
| Qwen3-32B | 72.94$^{-6.87}$ | 81.69$^{+1.88}$ | 67.02$^{-12.79}$ |
| Qwen3-32B$^{T}$ | 81.66$^{-1.83}$ | 84.43$^{+0.94}$ | 77.72$^{-5.77}$ |
| GPT-4o | 77.06$^{-9.48}$ | 85.92$^{-0.62}$ | 63.83$^{-22.71}$ |
| GPT-4o-Mini | **81.18**$^{-8.44}$ | **89.67**$^{+0.06}$ | **76.06**$^{-13.55}$ |
| GPT-5$^{T}$ | 78.82$^{+1.13}$ | 80.28$^{+2.59}$ | 73.94$^{-3.76}$ |
| GPT-o3$^{T}$ | 75.29$^{-0.48}$ | 79.34$^{+3.57}$ | 74.47$^{-1.30}$ |
| Gemini 2.5F | 75.88$^{-9.12}$ | 87.79$^{+2.79}$ | 70.74$^{-14.26}$ |
| Gemini 2.5F$^{T}$ | 74.12$^{-0.11}$ | 76.53$^{+2.30}$ | 71.28$^{-2.95}$ |
| **PAP** | | | |
| Qwen3-32B | 58.82$^{-14.39}$ | 72.74$^{-0.47}$ | 44.41$^{-28.79}$ |
| Qwen3-32B$^{T}$ | **62.13**$^{-15.46}$ | **77.60**$^{+0.02}$ | **66.94**$^{-10.65}$ |
| Gemini 2.5F | **60.00**$^{-21.92}$ | **81.69**$^{-0.23}$ | 53.19$^{-28.73}$ |
| Gemini 2.5F$^{T}$ | 57.65$^{-5.43}$ | 63.38$^{+0.30}$ | **54.79**$^{-8.29}$ |

tably, the thinking variants consistently perform slightly worse than their non-thinking counterparts, possibly due to the "overthinking" phenomenon as defined by (Sui et al., 2025), in which reasoning models produce unnecessarily long and elaborate chains of reasoning that ultimately reduce problem-solving efficiency – a pattern confirmed by our error analysis (see Section 6.1). Among open-weight LLMs, performance is stronger in zero-shot and two-shot prompts, but when label-flipping examples are included, Gemini 2.5F outperforms Qwen3-32B.

Performance on unperturbed false claims is generally higher, reflecting the fact that fact-checking tasks predominantly target false claims. Consistent with earlier observations, open-weight models exhibit slightly stronger results than proprietary counterparts. A comprehensive analysis is presented in Appendix A.2.

### 5.1.2 Performance on Perturbed Claims

Now we summarize the change in performance under numerical perturbation. The Table 2 shows the change in accuracy values in red or green superscript depending on if the accuracy deceases or increases to the corresponding baseline with unperturbed original claims.

Masking and negative number perturbations are consistently the most challenging across prompting regimes. Masking yields very low accuracy in zero-shot setting (max 26%), as models often treat masked tokens as placeholders and predict `True`. With negative numbers, accuracy typically falls below 20% for masking and 30–50% overall, except Llama 3.3-70B, which maintains 63%; many models dismiss negatives as typos. Range and approximation perturbations raise accuracy for Qwen, DeepSeek, GPTs (not Mini), and Gemini, showing a preference for approximate over exact values. Numeration perturbations hurt open-weight models (Qwen3-32B, Llama 3.3-70B) but help proprietary systems (GPT-5$^{T}$, GPT-o3$^{T}$, Gemini 2.5F), reflecting stronger handling of surface forms.

In two-shot settings, similar trend to zero-shot is observed with slight drop in performance overall. With notable exceptions being DeepSeek-R1, Llama 3.3-70B, and Qwen3-32B drop sharply on approximation, while thinking models, GPT-5$^{T}$, GPT-o3$^{T}$, and Gemini 2.5F$^{T}$, gain on approximate perturbations.



Bảng 3: Độ chính xác (báo cáo theo %) trên tập dữ liệu 'True' phân chia dưới các nhiễu không l ật nhãn (True → True). Bảng so sánh độ chính xác bị nhiễu với độ chính xác của tuyên bố gốc không thay đổi (-x biểu thị giảm; +x biểu thị tăng). Các giá trị in đậm cho thấy độ chính xác cao nhất trong từng thiết lập nhiễu, được phân tách theo các mô hình mở và mô hình sở hữu.

| Mô hình | Khoảng | Num | Phạm vi |
|---|---|---|---|
| **Không cần huấn luyện trước** | | | |
| Llama3.3-70B | 71.76$^{-15.56}$ | **86.38**$^{-0.94}$ | 70.21$^{-17.11}$ |
| DeepSeek-R1 | 75.29$^{-6.40}$ | 82.63$^{+0.94}$ | 67.55$^{-14.14}$ |
| DeepSeek-R1$^{T}$ | **81.44**$^{-6.00}$ | 84.62$^{-2.82}$ | **79.23**$^{-8.20}$ |
| Qwen3 | 73.53$^{-10.82}$ | 85.88$^{+1.53}$ | 62.23$^{-22.12}$ |
| Qwen3-32B$^{T}$ | 79.39$^{-6.60}$ | 85.02$^{-0.97}$ | 78.24$^{-7.76}$ |
| GPT-4o | 68.82$^{-11.18}$ | 80.28$^{+0.28}$ | 55.32$^{-24.68}$ |
| GPT-4o-Mini | **81.18**$^{-4.21}$ | **92.96**$^{+7.57}$ | **79.79**$^{-5.60}$ |
| GPT-5$^{T}$ | 75.29$^{-0.86}$ | 77.00$^{+0.84}$ | 73.40$^{-2.75}$ |
| GPT-o3$^{T}$ | 74.71$^{-1.06}$ | 77.46$^{+1.70}$ | 77.66$^{+1.89}$ |
| Gemini 2.5F | 60.69$^{-22.00}$ | 79.81$^{-2.88}$ | 43.92$^{-38.78}$ |
| Gemini 2.5F$^{T}$ | 68.24$^{-3.30}$ | 71.76$^{+0.22}$ | 61.70$^{-9.84}$ |
| **Cảnh hai nhân vật** | | | |
| Llama3.3-70B | 84.71$^{-6.84}$ | 90.14$^{-1.41}$ | 85.64$^{-5.91}$ |
| DeepSeek-R1 | **88.82**$^{-0.85}$ | **90.61**$^{+0.94}$ | **86.70**$^{-2.97}$ |
| DeepSeek-R1$^{T}$ | 82.25$^{-4.07}$ | 87.50$^{+1.18}$ | 77.13$^{-9.19}$ |
| Qwen3-32B | 72.94$^{-6.87}$ | 81.69$^{+1.88}$ | 67.02$^{-12.79}$ |
| Qwen3-32B$^{T}$ | 81.66$^{-1.83}$ | 84.43$^{+0.94}$ | 77.72$^{-5.77}$ |
| GPT-4o | 77.06$^{-9.48}$ | 85.92$^{-0.62}$ | 63.83$^{-22.71}$ |
| GPT-4o-Mini | **81.18**$^{-8.44}$ | **89.67**$^{+0.06}$ | **76.06**$^{-13.55}$ |
| GPT-5$^{T}$ | 78.82$^{+1.13}$ | 80.28$^{+2.59}$ | 73.94$^{-3.76}$ |
| GPT-o3$^{T}$ | 75.29$^{-0.48}$ | 79.34$^{+3.57}$ | 74.47$^{-1.30}$ |
| Gemini 2.5F | 75.88$^{-9.12}$ | 87.79$^{+2.79}$ | 70.74$^{-14.26}$ |
| Gemini 2.5F$^{T}$ | 74.12$^{-0.11}$ | 76.53$^{+2.30}$ | 71.28$^{-2.95}$ |
| **PAP** | | | |
| Qwen3-32B | 58.82$^{-14.39}$ | 72.74$^{-0.47}$ | 44.41$^{-28.79}$ |
| Qwen3-32B$^{T}$ | **62.13**$^{-15.46}$ | **77.60**$^{+0.02}$ | **66.94**$^{-10.65}$ |
| Gemini 2.5F | **60.00**$^{-21.92}$ | **81.69**$^{-0.23}$ | 53.19$^{-28.73}$ |
| Gemini 2.5F$^{T}$ | 57.65$^{-5.43}$ | 63.38$^{+0.30}$ | **54.79**$^{-8.29}$ |

Một cách tổng quát, các biến thể suy nghĩ luôn thực hiện kém hơn một chút so với các biến t hể không suy nghĩ của chúng, có thể do hiện tượng "quá suy nghĩ" được định nghĩa bởi (Sui et al., 2025), trong đó các mô hình lý luận tạo ra các chuỗi lý luận dài và phức tạp không cần thiết, cuối cùng làm giảm hiệu quả giải quyết vấn đề – một mô hình được xác nhận bởi phân tích lỗi của chúng tôi (xem Mục 6.1). Trong số các LLM có trọng số mở, hiệu suất mạnh hơn ở zero-shot và two-shot.

các lời nhắc, nhưng khi bao gồm các ví dụ đảo nhãn, Gemini 2.5F vượt trội hơn Qwen3-32B.

Hiệu suất trên các khẳng định sai không bị ảnh hưởng thường cao hơn, phản ánh thực tế rằng các nhiệm vụ kiểm tra sự thật chủ yếu nhắm vào các khẳng định sai. Phù hợp với các quan sát trước đó, các mô hình mở trọng số thể hiện kết quả hơi mạnh hơn so với các mô hình độc quyền. Một phân tích toàn diện được trình bày trong Phụ lục A.2.

#### 5.1.2 Hiệu suất trên các Yêu cầu Bị Thay đổi

Bây giờ chúng tôi tóm tắt sự thay đổi về hiệu suất dưới tác động nhiễu số. Bảng 2 hiển thị sự thay đổi về giá trị độ chính xác bằng chỉ số tr ên màu đỏ hoặc xanh tùy thuộc vào việc độ chính xác giảm hay tăng so với mức cơ sở tương ứng với các tuyên bố gốc chưa bị nhiễu.

Việc che dấu và biến đổi số âm luôn là những thách thức lớn nhất trên các chế độ gợi ý. Việc che dấu mang lại độ chính xác r ất thấp trong thiết lập zero-shot (tối đa 26%), vì các mô hình thường coi các token bị che dấu như các chỗ giữ chỗ và dự đoán True. Với các số âm, độ chính xác thường giảm xuống dưới 20% đối với việc che dấu và 30–50% tổng thể, ngoại trừ Llama 3.3-70B, duy trì 63%; nhiều mô hình bỏ qua số âm như l ỗi chính tả. Việc biến đổi phạm vi và xấp xỉ nâng cao độ chính xác cho Qwen, DeepSeek, GPTs (không bao gồm Mini) và Gemini, cho thấy sự ưu tiên các giá trị xấp xỉ hơn là giá trị chính xác. Việc biến đổi số thứ tự làm giảm hiệu quả các mô hình mở (Qwen3-32B, Llama 3.3-70B) nhưng giúp các hệ thống độc quyền (GPT-5$^{T}$, GPT-o3$^{T}$, Gemini 2.5F), phản ánh khả năng xử lý hình thức bề mặt mạnh hơn.

Trong các thiết lập hai bước, xu hướng tương tự như zero-shot được quan sát với hiệu suất tổng thể giảm nhẹ. Ngoại lệ đáng chú ý là DeepSeek-R1, Llama 3.3-70B và Qwen3-32B giảm mạnh về xấp xỉ, trong khi các mô hình suy nghĩ, GPT-5$^{T}$, GPT-o3$^{T}$, và Gemini 2.5F$^{T}$, cải thiện về các nhiễu xấp xỉ.

For the rest of the perturbations, a similar trend to that of zero-shot is observed.

Finally, we find that introducing a single label-flipping demonstration for each perturbation type (PAP, shown in Appendix B) substantially boosts performance across all perturbations. The most striking gains appear in reasoning-oriented models, which display far greater robustness than their non-thinking counterparts. In the case of *Neg-Num*, these models not only surpass their baselines but also achieve strong improvements on perturbations such as simple numeration and ranged replacements. Notably, Qwen3-32B recovers to over 67%, underscoring the effectiveness of this model to leverage perturbed demonstrations, although masking remains a persistent challenge for Gemini. For Qwen, enabling the thinking variant consistently strengthens performance in most cases, whereas for Gemini the benefits are more uneven—showing improvements in certain perturbations but minimal change in others.

### 5.2 `True` → `True`

Table 3 shows the results for `True` → `True` perturbations. *Neg-Num*, *Rand-Repl* and *Mask* are not relevant when preserving labels.

With few exceptions, most models struggle on *Approx* and *Range* perturbations, though the drop is modest compared to `True` → `False` setting. This suggests that replacing numerical values with approximations or ranges, while preserving truth, can still mislead models into predicting `False`. In contrast, performance under *Num* perturbations remains relatively robust. Unlike label-flipping cases, perturbed PAP does not improve performance; instead, they often confuse models into misclassifying `True` claims as `False`. Surprisingly, GPT-4o-Mini, despite being smaller performs the best under this setting.

## 6 Discussion

**RQ1**: Across all experiments, *no single model emerges as universally the most robust*, though Gemini 2.5F and Qwen3-32B models come closest. Our results show that models are generally more robust on `False` claims (Tables 5 and 4) than on `True` claims (Tables 2 and 3). With perturbed false demonstrations, Gemini 2.5F$^T$ achieves near-ceiling accuracy on *Approx*, *Range*, and *Rand-Repl*, and shows the largest recovery on *Neg-Num*; without such calibration, Gemini 2.5F offers the best default balance, consistently leading on *Rand-Repl* and *Range*.

Among open-weight systems, Qwen3-32B$^T$ is the most stable across regimes and uniquely strong on *Mask* when provided perturbed examples, while Llama 3.3-70B excels on zero-shot *Neg-Num* but becomes brittle under two-shot. By contrast, DeepSeek-R1 is the least stable, showing sharp two-shot degradations on *Approx* and *Num*, indicative of harmful anchoring effects.

**RQ2**: *Neg-Num* and *Mask* appear to be the hardest perturbations among all prompt settings. With perturbation aware prompt (PAP), there is modest recovery and even then the gains are model-dependent (e.g., Gemini 2.5F$^T$). The *Rand-Repl* and *Range* perturbations are the most straightforward, consistently improving accuracy across models and prompting regimes. The *Num* and *Approx* perturbations fall in the middle: "thinking" models such as GPT-5$^T$, GPT-o3$^T$, and Gemini 2.5F$^T$ often gain from these perturbations, while many open-weight base models lose accuracy under two-shot prompts, likely because demonstrations with different numerical notation confuse the models—suggesting that these rely more heavily on superficial formatting cues, making them more sensitive to inconsistencies in numeric representation.

**RQ3**: Across both Gemini 2.5F$^T$ and



Đối với phần còn lại của các nhiễu loạn, một xu hướng tương tự như zero-shot đã được quan sát.

Cuối cùng, chúng tôi nhận thấy rằng việc giới thiệu một ví dụ lật nhãn duy nhất cho mỗi loại nhiễu (PAP, được trình bày trong Phụ lục B) cải thiện đáng kể hiệu suất trên tất cả các loại nhiễu. Những cải thiện nổi bật nhất xuất hiện ở các mô hình hướng tới tư duy, vốn thể hiện độ bền cao hơn rất nhiều so với các mô hình không tư duy. Trong trường hợp Neg-Num, các mô hình này không chỉ vượt qua các mức cơ sở của chúng mà còn đạt được những cải thiện mạnh mẽ trên các loại nhiễu như đánh số đơn giản và thay thế theo khoảng. Đáng chú ý, Qwen3-32B phục hồi lên trên 67%, nhấn mạnh hiệu quả của mô hình này trong việc tận dụng các ví dụ nhiễu, mặc dù việc che giấu vẫn là một thách thức dai dẳng đối với Gemini. Đối với Qwen, việc bật biến thể tư duy liên tục củng cố hiệu suất trong hầu hết các trường hợp, trong khi đối với Gemini lợi ích thì không đồng đều—cho thấy cải thiện ở một số loại nhiễu nhưng thay đổi rất ít ở các loại khác.

### 5.2 Đúng →Đúng

Bảng 3 cho thấy kết quả cho các nhiễu True → True. Neg-Num, Rand-Repl và Mask không liên quan khi giữ nguyên nhãn.

Ngoại trừ một vài trường hợp, hầu hết các mô hình gặp khó khăn với các nhiễu Approx và Range, mặc dù mức giảm là khiêm tốn so với thiết lập True → False. Điều này gợi ý rằng việc thay thế các giá trị số bằng các giá trị xấp xỉ hoặc khoảng, trong khi vẫn giữ nguyên tính đúng, vẫn có thể khiến các mô hình dự đoán sai thành False. Ngược lại, hiệu suất dưới các nhiễu Num vẫn tương đối ổn định. Không giống như các trường hợp lật nhãn, PAP bị nhiễu không cải thiện hiệu suất; thay vào đó, chúng thường khiến các mô hình nhầm lẫn và phân loại sai các khẳng định True thành False. Thật bất ngờ, GPT-4o-Mini, mặc dù nhỏ hơn, lại hoạt động tốt nhất trong thiết lập này.

## 6 Thảo luận

RQ1: Trong tất cả các thí nghiệm, không có mô hình nào xuất hiện là mô hình mạnh mẽ nhất một cách toàn cầu, mặc dù các mô hình Gemini 2.5F và Qwen3-32B là gần nhất. Kết quả của chúng tôi cho thấy các mô hình nói chung mạnh mẽ hơn đối với các tuyên bố sai (Bảng 5 và 4) so với các tuyên bố đúng (Bảng 2 và 3). Với các minh họa sai bị perturb, Gemini 2.5F$^T$ đạt được độ chính xác gần như tối đa trên Approx, Range và Rand-Repl, và cho thấy khả năng phục hồi lớn nhất trên Neg-Num; nếu không có sự hiệu chỉnh này, Gemini 2.5F cung cấp sự cân bằng mặc định tốt nhất, liên tục dẫn đầu trên Rand-Repl và Range.

Trong số các hệ thống trọng lượng mở, Qwen3-32B$^T$ là ổn định nhất trên các chế độ và đặc biệt mạnh trên Mask khi được cung cấp các ví dụ bị nhiễu, trong khi Llama 3.3-70B xuất sắc ở zero-shot Neg-Num nhưng trở nên yếu đuối dưới hai lần thử nghiệm. Ngược lại, DeepSeek-R1 là kém ổn định nhất, thể hiện sự suy giảm rõ rệt khi hai lần thử nghiệm trên Approx và Num, cho thấy các hiệu ứng neo có hại.

RQ2: Neg-Num và Mask dường như là những sự biến đổi khó nhất trong tất cả các cài đặt prompt. Với prompt nhận thức sự biến đổi (PAP), có sự phục hồi khiêm tốn và ngay cả như vậy, những cải thiện này phụ thuộc vào mô hình (ví dụ, Gemini 2.5F$^T$). Các sự biến đổi Rand-Repl và Range là dễ hiểu nhất, liên tục cải thiện độ chính xác trên các mô hình và chế độ prompt. Các sự biến đổi Num và Approx nằm ở mức trung bình: các mô hình "suy nghĩ" như GPT-5$^T$, GPT-o3$^T$, và Gemini 2.5F$^T$ thường có lợi từ các sự biến đổi này, trong khi nhiều mô hình cơ bản mở trọng số lại giảm độ chính xác dưới prompt hai-shot, có thể do các ví dụ minh họa với ký hiệu số khác nhau gây nhầm lẫn cho mô hình — điều này cho thấy chúng dựa nhiều hơn vào các dấu hiệu định dạng bề ngoài, khiến chúng nhạy cảm hơn với sự không nhất quán trong biểu diễn số.

RQ3: Trên cả Gemini 2.5F$^T$ và

Qwen3-32B$^T$, misclassified instances consistently involve longer inputs than correct predictions. For Gemini 2.5F$^T$, misclassifications show ∼15% more total tokens than correct cases, largely driven by a ∼38% increase in reasoning tokens (877 vs. 635 on average). For Qwen, the effect is even stronger: misclassified examples carry ∼41% more total tokens, with reasoning length nearly doubling (∼876 vs. 397, a ∼120% increase). Prompt tokens also inflate in misclassifications, albeit more modestly (e.g., ∼3–10% increases across models). Taken together, these findings suggest that models tend to fail when they have longer prompt and reasoning tokens (*overthinking* (Sui et al., 2025)), with inflated reasoning chains being a strong marker of misclassification. While PAP prompts introduce longer inputs overall, they provide targeted demonstrations that help mitigate these failures by guiding models toward more stable reasoning. Detailed breakdowns are presented in Appendix B.5.

### 6.1 Error Analysis

To better understand model errors, we analyze thinking tokens under the $T \rightarrow F$ setting for Qwen3-32B$^T$ and Gemini 2.5F$^T$, focusing on zero-shot errors that recover in PAP. Appendix C, Table 10 shows specific samples. Our analysis reveals the following reasoning patterns:

**Numerical strictness:** In PAP reasoning, models tend to interpret numbers more rigidly than in zero-shot. For instance, a claim citing $330,000 against evidence of $300,000 was treated as a minor discrepancy in zero-shot, but as a significant mismatch in PAP, predicting `False`.

**Masking fallacies:** In the zero-shot setting, masked numbers were often treated as placeholders, leading the model to "complete" the claim from evidence rather than verify it. Under PAP reasoning, the model more frequently flagged missing values as critical, aligning with the masked prompt examples and rejecting unverifiable claims. In some cases, however, it ignored the masking and reached the correct verdict, but for spurious reasons such as assuming small discrepancies in the evidence.

**Typo interpretation:** In the negative-number perturbation setting, under zero-shot, models often interpreted the negative sign (–) as a typo, treating it as a misplaced hyphen and discarding it during evaluation, which led to misclassifications. Under PAP prompting, however, the model highlighted the negative sign as a crucial discrepancy, correctly identifying it as evidence that invalidated the claim.

**Overthinking:** In some cases, models generate unnecessarily elaborate reasoning that obscures straightforward evidence. For example, for the claim *"Of the [more than 2 million] work opportunities created, more than 1 million have been taken up by the youth"*, the evidence clearly shows 2.5 million created and 1.1 million taken by youth (45%). Instead of rejecting the claim directly, the model speculated about time windows and approximation thresholds, leading to a wrong verdict. This illustrates how excessive reasoning can derail simple numerical checks.

## 7 Conclusion and Future Work

We introduced a framework for systematically perturbing numerical claims in claim–evidence pairs to evaluate the robustness of state-of-the-art LLMs in veracity prediction. Our results show that even leading systems suffer sharp performance drops under controlled numerical edits, providing the first comprehensive evidence that *numerical robustness in long-context fact-checking remains an open challenge*. Beyond prior work on textual or adversarial perturbations, our study is novel in designing semantically valid numerical perturbations and demonstrating that perturbation-



Qwen3-32B$^T$, các trường hợp phân loại nhầm thường liên quan đến các đầu vào dài hơn so với các dự đoán chính xác. Đối với Gemini 2.5F$^T$, các trường hợp phân loại nhầm hiển thị ∼15% tổng số token nhiều hơn so với các trường hợp đúng, chủ yếu do sự tăng ∼38% số token lý luận (trung bình 877 so với 635). Đối với Qwen, hiệu ứng còn mạnh hơn: các ví dụ bị phân loại nhầm mang ∼41% tổng số token nhiều hơn, với độ dài lý luận gần như tăng gấp đôi (∼876 so với 397, tăng ∼120%). Các token gợi ý cũng tăng trong các trường hợp phân loại nhầm, mặc dù mức độ khiêm tốn hơn (ví dụ, tăng ∼3–10% trên các mô hình). Tổng thể, các phát hiện này cho thấy các mô hình có xu hướng thất bại khi chúng có nhiều token gợi ý và lý luận hơn (suy nghĩ quá mức (Sui et al., 2025)), với chuỗi lý luận mở rộng là một dấu hiệu mạnh của việc phân loại nhầm. Trong khi các gợi ý PAP giới thiệu đầu vào dài hơn tổng thể, chúng cung cấp các minh họa có mục tiêu giúp giảm thiểu những thất bại này bằng cách hướng dẫn các mô hình đi theo một hướng lý luận ổn định hơn. Bảng phân tích chi tiết được trình bày trong Ap-p

### 6.1 Phân Tích Lỗi

Để hiểu rõ hơn về lỗi của mô hình, chúng tôi phân tích các token suy nghĩ dưới thiết lập $T \rightarrow F$ cho Qwen3-32B $^T$ và Gemini 2.5F $^T$, tập trung vào các lỗi zero-shot mà có thể khôi phục trong PAP. Phụ lục C, Bảng 10 cho thấy các mẫu cụ thể. Phân tích của chúng tôi tiết lộ các mô hình lập luận sau:

Độ nghiêm ngặt về số liệu: Trong lập luận PAP, các mô hình có xu hướng diễn giải các con số một cách nghiêm ngặt hơn so với trong zero-shot. Ví dụ, một tuyên bố trích dẫn $ 330,000 đối với bằng chứng $300,000 được coi là một sự khác biệt nhỏ trong zero-shot, nh ưng lại là một sự không khớp đáng kể trong PAP, dự đoán Sai.

Che giấu những nguy biện: Trong bối cảnh zero-shot, các con số bị che thường được coi là chỗ trống, dẫn đến việc mô hình "hoàn thành" tuyên bố từ bằng chứng thay vì xác minh nó. Theo lý luận PAP, mô hình thường xuyên hơn đã đánh dấu các giá trị thiếu là quan trọng, phù hợp với các ví dụ lời nhắc được che đi và từ chối các tuyên bố không thể kiểm chứng. Tuy nhiên, trong một số trường hợp, nó đã bỏ qua việc che đi và đưa ra phán quyết đúng, nhưng vì những lý do không chính xác như giả định sự khác biệt nhỏ trong bằng chứng.

Giải thích lỗi chính tả: Trong bối cảnh perturbation số âm, dưới hình thức zero-shot, các mô hình thường giải thích dấu âm (–) như một lỗi chính tả, xem nó như một dấu gạch ngang bị đặt sai chỗ và loại bỏ nó trong quá trình đánh giá, điều này dẫn đến phân loại sai. Tuy nhiên, dưới sự gợi ý PAP, mô hình đã nhấn mạnh dấu âm như một sự khác biệt quan trọng, xác định chính xác nó là bằng chứng để bác bỏ khẳng định.

Suy nghĩ quá mức: Trong một số trường hợp, các mô hình tạo ra những lập luận phức tạp không cần thiết làm che khuất bằng chứng rõ ràng. Ví dụ, đối với tuyên bố "Trong số /hơn 2 triệu/ cơ hội việc làm được tạo ra, hơn 1 triệu đã được giới trẻ đảm nhận", bằng chứng rõ ràng cho thấy có 2,5 triệu cơ hội được tạo ra và 1,1 triệu đ ược giới trẻ đảm nhận (45%). Thay vì bác bỏ trực tiếp tuyên bố này, mô hình lại suy đoán về các khoảng thời gian và ngưỡng gần đúng, dẫn đến kết luận sai. Điều này minh họa cách mà việc lập luận quá mức có thể làm lệch các kiểm tra số liệu đơn giản.

## 7 Kết luận và Công việc Tương lai

Chúng tôi đã giới thiệu một khuôn khổ để làm biến động có hệ thống các tuyên bố số trong các cặp tuyên bố–bằng chứng nhằm đánh giá độ bền vững của các mô hình ngôn ngữ lớn tiên tiến tr ong việc dự đoán tính xác thực. Kết quả của chú ng tôi cho thấy ngay cả các hệ thống hàng đầu cũng gặp phải sự suy giảm hiệu suất đáng kể dưới các chỉnh sửa số được kiểm soát, cung cấp bằng chứng toàn diện đầu tiên rằng độ bền số trong việc kiểm chứng sự thật dài hạn vẫn là một thách thức chưa được giải quyết. Vượt ra ngoài các nghiên cứu trước về biến động văn bản hoặc tấn công đối nghịch, nghiên cứu của chúng tôi mới mẻ trong việc thiết kế các biến động số có ý nghĩa về mặt ngữ nghĩa và chứng minh rằng biến động

aware prompting can partially recover performance.

As a preliminary step, this work opens several directions: perturbing the evidence side of claim–evidence pairs, designing fine-grained probes that target sub-claims, and extending the framework to multi-hop reasoning and counterfactual scenarios.

## 8 Limitations

Our experiments are constrained by the selection of models tested. Additionally, they were conducted in a black-box environment, restricting access to model weights, parameters, and other internal insights. Some perturbation datasets are also limited in size; a larger and more diverse sample would enhance the robustness of our findings. For reasons discussed in previous sections, our experiments focus exclusively on binary veracity classification ('True' and 'False'), omitting more granular classifications and False-to-True perturbations. Expanding the scope to include these aspects could offer a more comprehensive understanding of model performance under different conditions. Lastly, as with most classification tasks involving LLMs, there is a potential risk of data leakage from training data, which could influence the final evaluation and affect the results.

## 9 Ethical Considerations

Our research highlights the strengths and weaknesses of various models in binary veracity and counterfactual classification. While this type of research presents valuable opportunities to enhance model security and resilience. However, it also necessitates a thoughtful approach to ethical concerns. For our experiments, some models outperform others, yet we do not endorse any specific model for fact-checking tasks. Fact-checking itself is a nuanced and complex issue. Journalists, fact-checkers, and researchers alike risk introducing inadvertent bias into their work, a concern that also extends to the use of LLMs.

Additionally, while the goal of our experiments is to bring greater attention to LLM performance in specific tasks, these findings also highlight vulnerabilities and encourage the development of more robust models. However, these techniques have multipurpose potential and could be exploited for harmful purposes if misapplied.

## Acknowledgements

This research is funded by SFI MediaFutures partners and the Research Council of Norway (grant number 309339).

## References

Mubashara Akhtar, Abhilash Shankarampeta, Vivek Gupta, Arpit Patil, Oana Cocarascu, and Elena Simperl. 2023. Exploring the numerical reasoning capabilities of language models: A comprehensive analysis on tabular data. In *Findings of the Association for Computational Linguistics: EMNLP 2023*, ACL '23, pages 15391–15405.

Rami Aly, Zhijiang Guo, Michael Sejr Schlichtkrull, James Thorne, Andreas Vlachos, Christos Christodoulopoulos, Oana Cocarascu, and Arpit Mittal. 2021. Feverous: Fact extraction and verification over unstructured and structured information. In *Thirty-fifth Conference on Neural Information Processing Systems Datasets and Benchmarks Track*.

Yonatan Belinkov. 2022. Probing classifiers: Promises, shortcomings, and advances. *Computational Linguistics*, 48(1):207–219.

Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, et al. 2020. Language models are few-shot learners. In *Advances in Neural Information Processing Systems*.

Kejie Chen, Lin Wang, Qinghai Zhang, and Renjun Xu. 2024. Metarulegpt: Recursive numerical reasoning of language models trained with simple rules. *arXiv preprint arXiv:2412.13536*.



gợi ý có nhận thức có thể phục hồi một phần hiệu suất.

Như một bước sơ bộ, công trình này mở ra nhiều hướng: làm nhiễu bên bằng chứng của các cặp luận điểm–bằng chứng, thiết kế các phép kiểm tra tinh vi nhắm vào các luận điểm phụ, và mở rộng khung phân tích sang suy l uận nhiều bước và các tình huống phản thực.

## 8 Hạn chế

Các thí nghiệm của chúng tôi bị giới hạn bởi việc lựa chọn các mô hình được thử nghiệm. Thêm vào đó, chúng được tiến hành trong một môi trường hộp đen, hạn chế quyền truy cập vào trọng số mô hình, các tham số và các hiểu biết nội bộ khác. Một số tập dữ liệu biến đổi cũng bị hạn chế về kích thước; một mẫu lớn hơn và đa dạng hơn sẽ tăng cường độ bền vững của các phát hiện của chúng tôi. Vì những lý do đã được thảo luận trong các phần trước, các thí nghiệm của chúng tôi tập trung hoàn toàn vào phân loại độ xác thực nhị phân (' True' và 'False'), bỏ qua các phân loại chi tiết hơn và các biến đổi từ False sang True. Mở rộng phạm vi để bao gồm những khía cạnh này có thể cung cấp một hiểu biết toàn diện hơn về hiệu suất của mô hình trong các điều kiện khác nhau. Cuối cùng, cũng như hầu hết các nhiệm vụ phân loại liên quan đến LLM, có nguy cơ rò rỉ dữ liệu từ dữ liệu huấn luyện, điều này có thể ảnh hưởng đến đánh giá cuối cùng và tác động đến kết quả.

## 9 Cân nhắc đạo đức

Nghiên cứu của chúng tôi làm nổi bật những điể m mạnh và điểm yếu của các mô hình khác nhau trong việc phân loại tính xác thực nhị phân và phản thực. Trong khi loại nghiên cứu này mang l ại cơ hội quý giá để nâng cao bảo mật và khả năng chống chịu của mô hình, nó cũng đòi hỏi một cách tiếp cận cẩn trọng đối với các mối quan tâm đạo đức. Trong các thí nghiệm của chúng tôi, một số mô hình hoạt động tốt hơn các mô hình khác, nhưng chúng tôi không ủng hộ bất kỳ mô hình cụ thể nào cho các nhiệm vụ kiểm tra thông tin. Tự việc kiểm tra thông tin là một vấn đề tinh vi và phức tạp. Các nhà báo, người kiểm tra thông tin và các nhà nghiên cứu đều có nguy cơ giới thiệu những thiên kiến vào công việc của họ, một mối quan ngại cũng mở rộng đến việc sử dụng LLMs.

Ngoài ra, trong khi mục tiêu của các thí nghiệm của chúng tôi là thu hút sự chú ý nhiều hơn đến hiệu suất của các LLM trong các nhiệm vụ cụ thể, những phát hiện này cũng làm nổi bật các lỗ hổng và khuyến khích việc phát triển các mô hình mạnh mẽ hơn. Tuy nhiên, những kỹ thuật này có tiề m năng đa mục đích và có thể bị khai thác cho các mục đích gây hại nếu sử dụng sai.

## Lời cảm ơn

Nghiên cứu này được tài trợ bởi các đối tác SFIMediaFutures và Hội đồng Nghiên cứu Na Uy (mã số tài trợ 309339).

### Tài liệu tham khảo

Mubashara Akhtar, Abhilash Shankarampeta, Vivek Gupta, Arpit Patil, Oana Cocarascu, và Elena Simperl. 2023. Khám phá khả năng lý luận số học của các mô hình ngôn ngữ: Phân tích t oàn diện về dữ liệu bảng. Trong Kết quả của Hiệp hội Ngôn ngữ Học Máy Tính: EMNLP 2023, ACL '23, trang 15391–15405.

Rami Aly, Zhijiang Guo, Michael Sejr Schlichtkrull, James Thorne, Andreas Vlachos, Christos Christodoulopoulos, Oana Cocarascu, và Arpit Mittal. 2021. Feverous: Trích xuất và xác minh sự thật từ thông tin không cấu trúc và có cấu trúc. Trong Hội nghị lần thứ ba mươi lă m về Hệ thống Xử lý Thông tin Thần kinh, Chương trình Dữ liệu và Bộ chuẩn.

Yonatan Belinkov. 2022. Thăm dò bộ phân loại: Những hứa hẹn, thiếu sót và tiến bộ. Ngôn ngữ học tính toán, 48(1):207–219.

Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, và cộng sự. 2020. Các mô hình ngôn ngữ là những người học ít ví dụ. Trong Kỷ yếu Hội nghị Hệ thống Xử lý Thông tin Thần kinh Tiến bộ.

Kejie Chen, Lin Wang, Qinghai Zhang, và Renjun Xu. 2024. Metarulegpt: Lý luận số học đệ quy của các mô hình ngôn ngữ được huấn luyện với các quy tắc đơn giản. Bản in trước arXiv arXiv:2412.13536.

Alphaeus Dmonte, Roland Oruche, Marcos Zampieri, Prasad Calyam, and Isabelle Augenstein. 2024. Claim verification in the age of large language models: A survey. *arXiv preprint arXiv:2408.14317*.

Simon Frieder, Luca Pinchetti, Ryan-Rhys Griffiths, Tommaso Salvatori, Thomas Lukasiewicz, Philipp Petersen, and Julius Berner. 2024. Mathematical capabilities of chatgpt. *Advances in neural information processing systems*, 36.

Zhijiang Guo, Michael Sejr Schlichtkrull, and Andreas Vlachos. 2022. A survey on automated fact-checking. *Transactions of the Association for Computational Linguistics*, 10:178–206.

Zhibo Hu, Chen Wang, Yanfeng Shu, Hye-Young Paik, and Liming Zhu. 2024. Prompt perturbation in retrieval-augmented generation based large language models. In *Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, pages 1119–1130.

Fanzhen Liu, Alsharif Abuadbba, Kristen Moore, Surya Nepal, Cecile Paris, Jia Wu, Jian Yang, and Quan Z Sheng. 2025. Adversarial attacks against automated fact-checking: A survey. *arXiv preprint arXiv:2509.08463*.

Pan Lu, Liang Qiu, Wenhao Yu, Sean Welleck, and Kai-Wei Chang. 2023. A survey of deep learning for mathematical reasoning. In *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 14605–14631.

Mamta and Oana Cocarascu. 2025. Facteval: Evaluating the robustness of fact verification systems in the era of large language models. In *Proceedings of the 2025 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL)*.

Akshay Paruchuri, Jake Garrison, Shun Liao, John B. Hernandez, Jacob Sunshine, Tim Althoff, Xin Liu, and Daniel McDuff. 2024. What are the odds? language models are capable of probabilistic reasoning. In *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*, pages 11712–11733, Miami, Florida, USA. Association for Computational Linguistics.

Piotr Przybyła, Alexander Shvets, and Horacio Saggion. 2024. Verifying the robustness of automatic credibility assessment. *Natural Language Processing Journal*.

Vinay Setty. 2024. Surprising efficacy of fine-tuned transformers for fact-checking over larger language models. In *Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR '24)*, pages 2842–2846.

Yang Sui, Yu-Neng Chuang, Guanchu Wang, Jiamu Zhang, Tianyi Zhang, Jiayi Yuan, Hongyi Liu, Andrew Wen, Shaochen Zhong, Na Zou, Hanjie Chen, and Xia Hu. 2025. Stop overthinking: A survey on efficient reasoning for large language models. *Preprint*, arXiv:2503.16419.

Venktesh V, Abhijit Anand, Avishek Anand, and Vinay Setty. 2024. Quantemp: A real-world open-domain benchmark for fact-checking numerical claims. In *Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval*, Sigir '24, pages 650–660.

Eric Wallace, Yizhong Wang, Sujian Li, Sameer Singh, and Matt Gardner. 2019. Do nlp models know numbers? probing numeracy in embeddings. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 5307–5315, Hong Kong, China. Association for Computational Linguistics.

Jonas Wallat, Adam Jatowt, and Avishek Anand. 2024. Temporal blind spots in large language models. In *Proceedings of the 17th ACM International Conference on Web Search and Data Mining*, WSDM '24, page 683–692.

Jialiang Xu, Mengyu Zhou, Xinyi He, Shi Han, and Dongmei Zhang. 2022. Towards Robust Numerical Question Answering: Diagnosing Numerical Capabilities of NLP Systems. In *Proceedings of the 2022 conference on empirical methods in natural language processing*, EMNLP '22, pages 7950–7966.

Haotong Yang, Yi Hu, Shijia Kang, Zhouchen Lin, and Muhan Zhang. 2024. Number cookbook: Number understanding of language models and how to improve it. *arXiv preprint arXiv:2411.03766*.



Alphaeus Dmonte, Roland Oruche, Marcos Zampieri, Prasad Calyam, và Isabelle Augenstein. 2024. Xác minh các tuyên bố trong thời đại của các mô hình ngôn ngữ lớn: Một cuộc khảo sát. Bản in trước arXiv arXiv:2408.14317.

Simon Frieder, Luca Pinchetti, Ryan-Rhys Griffiths, Tommaso Salvatori, Thomas Lukasiewicz, Philipp Petersen, và Julius Berner. 2024. Khả năng toán học của chatgpt. Tiến bộ trong hệ thống xử lý thông tin thần kinh, 36.

Zhijiang Guo, Michael Sejr Schlichtkrull, và Andreas Vlachos. 2022. Một khảo sát về kiểm tra sự thật tự động. Transactions of the Association for Computational Linguistics, 10:178–206.

Zhibo Hu, Chen Wang, Yanfeng Shu, Hye-Young Paik, và Liming Zhu. 2024. Nhiễu cảnh báo tro ng các mô hình ngôn ngữ lớn dựa trên tạo sinh tăng cường truy xuất. Trong Kỷ yếu Hội nghị SIGKDD lần thứ 30 của ACM về Khám phá Kiến thức và Khai thác Dữ liệu, trang 1119–1130.

Fanzhen Liu, Alsharif Abuadbba, Kristen Moore, Surya Nepal, Cecile Paris, Jia Wu, Jian Yang, và Quan Z Sheng. 2025. Các cuộc tấn công đối kháng chống lại kiểm tra sự thật tự động: Một khảo sát. bản thảo arXiv arXiv:2509.08463.

Pan Lu, Liang Qiu, Wenhao Yu, Sean Welleck, và Kai-Wei Chang. 2023. Một khảo sát về học sâu cho suy luận toán học. Trong Kỷ yếu của Cuộc họp thường niên lần thứ 61 của Hiệp hội Ngôn ngữ học Máy tính (Tập 1: Bài báo Dài), trang 14605–14631.

Mamta và Oana Cocarascu. 2025. Facteval: Đánh giá độ bền vững của các hệ thống xác minh thông tin trong kỷ nguyên của các mô hình ngôn ngữ lớn. Trong Kỷ yếu Hội nghị 2025 của Chi hội Bắc Mỹ của Hiệp hội Ngôn ngữ Học Máy Tính (NAACL).

Akshay Paruchuri, Jake Garrison, Shun Liao, John B. Hernandez, Jacob Sunshine, Tim Al-thoff, Xin Liu, và Daniel McDuff. 2024. Tỷ lệ là bao nhiêu? các mô hình ngôn ngữ có khả năng suy luận xác suất. Trong Kỷ yếu Hội nghị 2024 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên, các trang 11712–11733, Miami, Florida, Hoa Kỳ. Hiệp hội Ngôn ngữ học Máy tính.

Piotr Przybyła, Alexander Shvets, và Horacio Saggion. 2024. Xác minh độ tin cậy của việc đánh giá tự động. Tạp chí Xử lý Ngôn ngữ Tự nhiên.

Vinay Setty. 2024. Hiệu quả đáng ngạc nhiên của các transformer được tinh chỉnh cho việc kiểm chứng sự thật so với các mô hình ngôn ngữ lớn hơn. Trong Kỷ yếu của Hội nghị Quốc tế ACM SIGIR lần thứ 47 về Nghiên cứu và Phát triển trong Truy xuất Thông tin (SIGIR '24), trang 2842–2846.

Yang Sui, Yu-Neng Chuang, Guanchu Wang, Jiamu Zhang, Tianyi Zhang, Jiayi Yuan, Hongyi Liu, Andrew Wen, Shaochen Zhong, Na Zou, Hanjie Chen và Xia Hu. 2025. Ngừng suy nghĩ quá nhiều: Khảo sát về lý luận hiệu quả cho các mô hình ngôn ngữ lớn. Tiền in, arXiv:2503.16419.

Venktesh V, Abhijit Anand, Avishek Anand, và Vinay Setty. 2024. Quantemp: Một chuẩn thực tiễn thực tế mở cho việc kiểm chứng các tuyên bố số học. Trong Kỷ yếu của Hội nghị Quốc tế ACM SIGIR lần thứ 47 về Nghiên cứu và Phát triển trong Truy xuất Thông tin, Sigir '24, các trang 650–660.

Eric Wallace, Yizhong Wang, Sujian Li, Sameer Singh, và Matt Gardner. 2019. Các mô hình NLP có hiểu số không? Khám phá khả năng số học trong các embedding. Trong Kỷ yếu Hội nghị 2019 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên và Hội nghị Liên hợp Quốc t ế lần thứ 9 về Xử lý Ngôn ngữ Tự nhiên (EMNLP-IJCNLP), trang 5307–5315, Hồng Kông, Trung Quốc. Hiệp hội Ngôn ngữ Học Máy tính.

Jonas Wallat, Adam Jatowt, và Avishek Anand. 2024. Các điểm mù về thời gian trong các mô hình ngôn ngữ lớn. Trong Kỷ yếu của Hội nghị Quốc tế ACM lần thứ 17 về Tìm kiếm Web và Khai thác Dữ liệu, WSDM '24, trang 683–692.

Jialiang Xu, Mengyu Zhou, Xinyi He, Shi Han, và Dongmei Zhang. 2022. Hướng tới Trả lời Câu hỏi Số liệu Mạnh mẽ: Chẩn đoán Khả năng Xử lý Số liệu của các Hệ thống NLP. Trong Kỷ yếu hội nghị năm 2022 về các phương pháp thực nghiệm trong xử lý ngôn ngữ tự nhiên, EMNLP '22, trang 7950–7966.

Haotong Yang, Yi Hu, Shijia Kang, Zhouchen Li n, và Muhan Zhang. 2024. Sách nấu số: Hiểu số của các mô hình ngôn ngữ và cách cải thiện nó. Bản in trước arXiv arXiv:2411.03766.

Wei Zhou, Mohsen Mesgar, Heike Adel, and Annemarie Friedrich. 2024. Freb-tqa: A fine-grained robustness evaluation benchmark for table question answering. In *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers)*, pages 2479–2497.

# A Appendix

The appendix includes additional details of the perturbation methods used, a summary of the False → False evaluation, and the evidence document and evaluation for the two-shot examples.

## A.1 Perturbation Details

This section provides a brief description of additional details regarding the perturbation methods. For full script details, refer to the GitHub repository[3].

### A.1.1 Numeration

For numbers that should not match the original numerical value in the unperturbed claim, the value is increased by 10%, then converted from digits to words.

### A.1.2 Approximation

Each type applies context-specific rounding to create conversational approximations rounding, and adds "about" as an approximation prefix. If all numbers, if it is less than 10 and a decimal number, the number gets round to the nearest .5.

- *Cardinal*: Rounds to tens, hundreds, thousands, or hundred-thousands based on magnitude.
- *Percentage*: Rounds to tens or hundreds, preserving exact values for small percentages.
- *Money*: Similar to Cardinal—with a currency symbol and preserves decimal detail for small amounts.
- *Date*: Rounds to the nearest decade.
- *Time*: Rounds to tens or hundreds depending on magnitude.

For the label-flipping probes, the original numerical value is multiplied randomly by a factor 0.5, 0.6, 1.4, or 1.5, and then rounded as described above.

[3] https://github.com/iai-group/adversarial_attack_numerical_claims/



Wei Zhou, Mohsen Mesgar, Heike Adel, và Annemarie Friedrich. 2024. Freb-tqa: Một chuẩn đánh giá độ bền chi tiết cho trả lời câu hỏi bảng. Trong Kỷ yếu Hội nghị 2024 của Chương Bắc Mỹ thuộc Hiệp hội Ngôn ngữ học Máy tính: Công nghệ Ngôn ngữ Con người (Tập 1: Bài báo dài), các trang 2479–2497.

# Phụ lục A

Phụ lục bao gồm các chi tiết bổ sung về các phương pháp nhiễu đã sử dụng, tóm tắt đánh giá False → False, và tài liệu bằng chứng cũng như đánh giá cho các ví dụ hai lần thử.

## A.1 Chi tiết sự nhiễu

Phần này cung cấp mô tả ngắn gọn về các chi tiết bổ sung liên quan đến các phương pháp nhiễu loạn. Để biết chi tiết đầy đủ về kịch bản, hãy tham khảo kho lưu trữ GitHub[3].

### A.1.1 Đánh số

Đối với các số không nên khớp với giá trị số gốc trong yêu cầu chưa bị thay đổi, giá trị được tăng thêm 10%, sau đó được chuyển từ chữ số sang chữ viết.

### A.1.2 Xấp xỉ

Mỗi loại áp dụng làm tròn theo ngữ cảnh cụ thể để tạo ra các xấp xỉ trong cuộc trò chuyện và thêm "khoảng" như một tiền tố xấp xỉ. Nếu tất cả các số, nếu nhỏ hơn 10 và là số thập phân, số đó sẽ được làm tròn đến 0,5 gần nhất.

• Số chính: Làm tròn đến chục, trăm, nghìn hoặc trăm nghìn dựa trên độ lớn.

• Phần trăm: Làm tròn đến hàng trăm của tensor, giữ nguyên giá trị chính xác cho các phần trăm nhỏ.

• Tiền: Tương tự như Số đếm — với ký hiệu tiền tệ và giữ nguyên chi tiết thập phân cho các khoản nhỏ.

• Ngày: Làm tròn đến thập kỷ gần nhất.

• Thời gian: Làm tròn đến chục hoặc trăm tùy thuộc vào độ lớn.

Đối với các đầu dò lật nhãn, giá trị số ban đầu được nhân ngẫu nhiên với các hệ số 0,5, 0,6, 1,4 hoặc 1,5, sau đó được làm tròn như đã mô tả ở trên.

[3] https://github.com/iai-group/tấn công_gây nhiễu_số liệu_khẳng định/

Table 4: Accuracy performance for the ‘False’ class, in the‘False’ dataset split with perturbations where numerical values have been adjusted to remain similar to the original false claim while maintaining the label, i.e., False → False (-x indicates a drop; +x indicates an increase). Values in bold denote the highest accuracy within each perturbation setting, separated by open-weight and proprietary models.

| Model | Original | Approx | Num | Range |
|---|---|---|---|---|
| **One-shot** | | | | |
| Llama 3.2-1B | 5.71 | 5.45$^{-0.27}$ | 6.53$^{+0.82}$ | 6.81$^{+1.10}$ |
| Llama 3.3-70B | 93.67 | 94.06$^{+0.39}$ | 93.47$^{-0.20}$ | 92.21$^{-1.46}$ |
| Mistral-7B | 96.53 | 95.79$^{-0.74}$ | 96.33$^{-0.20}$ | 95.62$^{-0.91}$ |
| DeepSeek-R1 | **97.14** | **97.28**$^{+0.13}$ | **96.94**$^{-0.20}$ | 96.84$^{-0.31}$ |
| DeepSeek-R1$^{T}$ | 95.86 | 95.56$^{-0.31}$ | 96.13$^{+0.27}$ | 94.56$^{-1.30}$ |
| Qwen3-32B | 96.12 | 96.29$^{+0.16}$ | 96.12 | **97.32**$^{+1.20}$ |
| Qwen3-32B$^{T}$ | 95.92 | 94.99$^{-0.93}$ | 95.90$^{-0.01}$ | 95.15$^{-0.76}$ |
| GPT-4o | **96.52** | **97.28**$^{+0.75}$ | **97.14**$^{+0.62}$ | **97.08**$^{+0.56}$ |
| GPT-4o-Mini | 93.05 | 93.32$^{+0.27}$ | 92.45$^{-0.60}$ | 93.19$^{+0.14}$ |
| GPT-5 | 95.20 | 95.05$^{-0.15}$ | 96.12$^{+0.92}$ | 95.13$^{-0.06}$ |
| GPT-o3 | 95.36 | 94.06$^{-1.30}$ | 95.92$^{+0.55}$ | 94.40$^{-0.96}$ |
| Gemini 2.5F | 93.21 | 95.05$^{+1.84}$ | 93.88$^{+0.67}$ | 96.11$^{+2.90}$ |
| Gemini 2.5F$^{T}$ | 92.05 | 90.84$^{-1.21}$ | 90.69$^{-1.36}$ | 90.02$^{-2.03}$ |
| **Two-shot** | | | | |
| Llama 3.2-1B | 10.00 | 6.93$^{-3.07}$ | 10.20$^{+0.20}$ | 9.73$^{-0.27}$ |
| Llama 3.3-70B | 95.92 | 96.04$^{+0.12}$ | 95.51$^{-0.41}$ | 93.19$^{-2.73}$ |
| Mistral-7B | 87.76 | 88.12$^{+0.36}$ | 88.78$^{+1.02}$ | 87.10$^{-0.65}$ |
| DeepSeek-R1 | 95.92 | 95.79$^{-0.13}$ | 95.71$^{-0.20}$ | 96.84$^{+0.92}$ |
| DeepSeek-R1$^{T}$ | 96.07 | 95.73$^{-0.34}$ | 96.27$^{+0.20}$ | 94.35$^{-1.72}$ |
| Qwen3-32B | **97.76** | **97.28**$^{-0.48}$ | **97.76** | **97.32**$^{-0.43}$ |
| Qwen3-32B$^{T}$ | 95.91 | 96.04$^{+0.13}$ | 96.33$^{+0.42}$ | 94.88$^{-1.03}$ |
| GPT-4o | **96.36** | **97.28**$^{+0.92}$ | **96.12**$^{-0.24}$ | **97.32**$^{+0.97}$ |
| GPT-4o-Mini | 92.38 | 95.79$^{+3.41}$ | 93.88$^{+1.49}$ | 95.38$^{+2.99}$ |
| GPT-5 | 95.20 | 94.55$^{-0.64}$ | 96.12$^{+0.92}$ | 95.13$^{-0.06}$ |
| GPT-o3 | 94.87 | 94.55$^{-0.31}$ | 95.10$^{+0.23}$ | 94.89$^{+0.02}$ |
| Gemini 2.5F | 92.72 | 95.54$^{+2.83}$ | 94.49$^{+1.77}$ | 95.62$^{+2.91}$ |
| Gemini 2.5F$^{T}$ | 92.38 | 91.58$^{-0.80}$ | 94.08$^{+1.70}$ | 90.27$^{-2.12}$ |
| **PAP** | | | | |
| Qwen3-32B | 96.12 | **96.78**$^{+0.66}$ | **96.53**$^{+0.41}$ | **97.20**$^{+1.08}$ |
| Qwen3-32B$^{T}$ | **96.72** | 96.40$^{-0.32}$ | 96.39$^{-0.33}$ | 95.84$^{-0.89}$ |
| Gemini 2.5F | 92.88 | **95.30**$^{+2.42}$ | 92.24$^{-0.64}$ | **95.13**$^{+2.25}$ |
| Gemini 2.5F$^{T}$ | **93.54** | 90.84$^{-2.70}$ | **92.65**$^{-0.89}$ | 90.02$^{-3.52}$ |

### A.1.3 Range

In the range perturb setting, for when the numerical values should be within the span of the original, the lower bounds we perturb the number by $\pm 10\%$. For *ordinal*, we subtract and add 1 to the original value to create the range bound.

In instances where the labels are flipped, the numerical span will be outside of the range of the original number.



Bảng 4: Hiệu suất độ chính xác cho lớp 'Sai', trong tập dữ liệu phân tách 'Sai' với các nhiễu, nơi các giá trị số đã được điều chỉnh để giữ gần giống với tuyên bố sai ban đầu trong khi vẫn giữ nhãn, tức là, Sai → Sai (-x biểu thị giảm; +x biểu thị tăng). Các giá trị in đậm thể hiện độ chính xác cao nhất trong t ừng thiết lập nhiễu, được phân tách theo mô hình mở và mô hình sở hữu riêng.

| Mô hình | Nguyên bản | Khoảng | Num | Phạm vi |
|---|---|---|---|---|
| **Một lần** | | | | |
| Llama 3.2-1B | 5.71 | 5.45$^{-0.27}$ | 6.53$^{+0.82}$ | 6.81$^{+1.10}$ |
| Llama 3.3-70B | 93.67 | 94.06$^{+0.39}$ | 93.47$^{-0.20}$ | 92.21$^{-1.46}$ |
| Mistral-7B | 96.53 | 95.79$^{-0.74}$ | 96.33$^{-0.20}$ | 95.62$^{-0.91}$ |
| DeepSeek-R1 | **97.14** | **97.28**$^{+0.13}$ | **96.94**$^{-0.20}$ | 96.84$^{-0.31}$ |
| DeepSeek-R1$^{T}$ | 95.86 | 95.56$^{-0.31}$ | 96.13$^{+0.27}$ | 94.56$^{-1.30}$ |
| Qwen3-32B | 96.12 | 96.29$^{+0.16}$ | 96.12 | **97.32**$^{+1.20}$ |
| Qwen3-32B$^{T}$ | 95.92 | 94.99$^{-0.93}$ | 95.90$^{-0.01}$ | 95.15$^{-0.76}$ |
| GPT-4o | **96.52** | **97.28**$^{+0.75}$ | **97.14**$^{+0.62}$ | **97.08**$^{+0.56}$ |
| GPT-4o-Mini | 93.05 | 93.32$^{+0.27}$ | 92.45$^{-0.60}$ | 93.19$^{+0.14}$ |
| GPT-5 | 95.20 | 95.05$^{-0.15}$ | 96.12$^{+0.92}$ | 95.13$^{-0.06}$ |
| GPT-o3 | 95.36 | 94.06$^{-1.30}$ | 95.92$^{+0.55}$ | 94.40$^{-0.96}$ |
| Gemini 2.5F | 93.21 | 95.05$^{+1.84}$ | 93.88$^{+0.67}$ | 96.11$^{+2.90}$ |
| Gemini 2.5F$^{T}$ | 92.05 | 90.84$^{-1.21}$ | 90.69$^{-1.36}$ | 90.02$^{-2.03}$ |
| **Cảnh hai nhân vật** | | | | |
| Llama 3.2-1B | 10.00 | 6.93$^{-3.07}$ | 10.20$^{+0.20}$ | 9.73$^{-0.27}$ |
| Llama 3.3-70B | 95.92 | 96.04$^{+0.12}$ | 95.51$^{-0.41}$ | 93.19$^{-2.73}$ |
| Mistral-7B | 87.76 | 88.12$^{+0.36}$ | 88.78$^{+1.02}$ | 87.10$^{-0.65}$ |
| DeepSeek-R1 | 95.92 | 95.79$^{-0.13}$ | 95.71$^{-0.20}$ | 96.84$^{+0.92}$ |
| DeepSeek-R1$^{T}$ | 96.07 | 95.73$^{-0.34}$ | 96.27$^{+0.20}$ | 94.35$^{-1.72}$ |
| Qwen3-32B | **97.76** | **97.28**$^{-0.48}$ | **97.76** | **97.32**$^{-0.43}$ |
| Qwen3-32B$^{T}$ | 95.91 | 96.04$^{+0.13}$ | 96.33$^{+0.42}$ | 94.88$^{-1.03}$ |
| GPT-4o | **96.36** | **97.28**$^{+0.92}$ | **96.12**$^{-0.24}$ | **97.32**$^{+0.97}$ |
| GPT-4o-Mini | 92.38 | 95.79$^{+3.41}$ | 93.88$^{+1.49}$ | 95.38$^{+2.99}$ |
| GPT-5 | 95.20 | 94.55$^{-0.64}$ | 96.12$^{+0.92}$ | 95.13$^{-0.06}$ |
| GPT-o3 | 94.87 | 94.55$^{-0.31}$ | 95.10$^{+0.23}$ | 94.89$^{+0.02}$ |
| Gemini 2.5F | 92.72 | 95.54$^{+2.83}$ | 94.49$^{+1.77}$ | 95.62$^{+2.91}$ |
| Gemini 2.5F$^{T}$ | 92.38 | 91.58$^{-0.80}$ | 94.08$^{+1.70}$ | 90.27$^{-2.12}$ |
| **PAP** | | | | |
| Qwen3-32B | 96.12 | **96.78**$^{+0.66}$ | **96.53**$^{+0.41}$ | **97.20**$^{+1.08}$ |
| Qwen3-32B$^{T}$ | **96.72** | 96.40$^{-0.32}$ | 96.39$^{-0.33}$ | 95.84$^{-0.89}$ |
| Gemini 2.5F | 92.88 | **95.30**$^{+2.42}$ | 92.24$^{-0.64}$ | **95.13**$^{+2.25}$ |
| Gemini 2.5F$^{T}$ | **93.54** | 90.84$^{-2.70}$ | **92.65**$^{-0.89}$ | 90.02$^{-3.52}$ |

### A.1.3 Phạm vi

Trong cài đặt nhiễu phạm vi, khi các giá trị số nên nằm trong phạm vi của giá trị gốc, chúng tôi làm nhiễu số theo $\pm 10\%$ ở ranh giới dưới. Đối với giá trị thứ tự, chúng tôi tr ừ và cộng 1 vào giá trị gốc để tạo giới hạn phạm vi.

Trong những trường hợp nhãn bị đảo lộn, phạm vi số sẽ nằm ngoài phạm vi của số gốc.

Table 5: Accuracy performance for the `False` class, in the'False' dataset split with perturbations where numerical values have been modified to differ from the original false claim while preserving the label, i.e., `False` → `False` (-x indicates a drop; +x indicates an increase). Values in bold denote the highest accuracy within each perturbation setting, separated by open-weight and proprietary models.

| Model | Original | Approx | Neg-num | Num | Rand-repl | Range | Mask |
|---|---|---|---|---|---|---|---|
| **Zero-shot** | | | | | | | |
| Llama2-1B | 5.71 | 5.45$^{-0.27}$ | 5.62$^{-0.10}$ | 6.33$^{+0.61}$ | 4.90$^{-0.82}$ | 5.35$^{-0.36}$ | 5.92$^{+0.20}$ |
| Llama3.3-70B | 93.67 | 96.53$^{+2.86}$ | 93.26$^{-0.42}$ | 96.12$^{+2.45}$ | 96.73$^{+3.06}$ | 95.62$^{+1.95}$ | 92.86$^{-0.82}$ |
| Mistral-7B | 96.53 | 97.28$^{+0.75}$ | 95.51$^{-1.02}$ | 96.33$^{-0.20}$ | 96.73$^{+0.20}$ | 96.35$^{-0.18}$ | 95.31$^{-1.22}$ |
| DeepSeek-R1 | **97.14** | **98.51**$^{+1.37}$ | **96.63**$^{-0.51}$ | 97.96$^{+0.82}$ | **98.16**$^{+1.02}$ | **98.30**$^{+1.15}$ | **97.55**$^{+0.41}$ |
| DeepSeek-R1$^{T}$ | 95.86 | 96.57$^{+0.71}$ | 91.57$^{-4.30}$ | 97.42$^{+1.56}$ | 97.61$^{+1.75}$ | 97.44$^{+1.58}$ | 93.74$^{-2.13}$ |
| Qwen3-32B | 96.12 | 98.27$^{+2.14}$ | 95.51$^{-0.62}$ | 97.96$^{+1.84}$ | 97.96$^{+1.84}$ | 98.30$^{+2.17}$ | 95.31$^{-0.82}$ |
| Qwen3-32B$^{T}$ | 95.92 | 96.74$^{+0.83}$ | 94.32$^{-1.60}$ | **98.22**$^{+2.30}$ | 97.74$^{+1.82}$ | 98.03$^{+2.11}$ | 94.01$^{-1.91}$ |
| GPT-4o | **96.52** | **97.77**$^{+1.25}$ | **96.63**$^{+0.11}$ | **98.16**$^{+1.64}$ | **98.16**$^{+1.64}$ | **97.81**$^{+1.29}$ | **96.53**$^{+0.01}$ |
| GPT-4o-Mini | 93.05 | 96.04$^{+2.99}$ | 92.13$^{-0.91}$ | 95.71$^{+2.67}$ | 95.92$^{+2.87}$ | 96.84$^{+3.79}$ | 93.27$^{+0.22}$ |
| GPT-5 | 95.20 | 96.29$^{+1.09}$ | 91.01$^{-4.19}$ | 97.55$^{+2.35}$ | 97.35$^{+2.15}$ | 96.84$^{+1.64}$ | 95.51$^{+0.31}$ |
| GPT-o3 | 95.36 | 96.04$^{+0.68}$ | 91.01$^{-4.35}$ | 96.94$^{+1.57}$ | 96.94$^{+1.57}$ | 96.84$^{+1.47}$ | 95.51$^{+0.15}$ |
| Gemini 2.5F | 93.21 | 97.28$^{+4.07}$ | 94.38$^{+1.17}$ | 96.94$^{+3.73}$ | 97.96$^{+4.75}$ | 97.08$^{+3.87}$ | 93.88$^{+0.67}$ |
| Gemini 2.5F$^{T}$ | 92.05 | 93.30$^{+1.25}$ | 87.64$^{-4.41}$ | 95.31$^{+3.25}$ | 94.90$^{+2.84}$ | 96.09$^{+4.04}$ | 88.98$^{-3.07}$ |
| **2-S** | | | | | | | |
| Llama2-1B | 10.00 | 7.92$^{-2.08}$ | 7.87$^{-2.13}$ | 7.76$^{-2.24}$ | 9.18$^{-0.82}$ | 9.25$^{-0.75}$ | 7.76$^{-2.24}$ |
| Llama3.3-70B | 95.92 | 97.52$^{+1.61}$ | 95.51$^{-0.41}$ | 96.73$^{+0.82}$ | 97.87$^{+1.95}$ | 95.38$^{-0.54}$ | 95.10$^{-0.82}$ |
| Mistral-7B | 87.76 | 87.38$^{-0.38}$ | 87.64$^{-0.11}$ | 88.57$^{+0.82}$ | 88.78$^{+1.02}$ | 87.35$^{-0.41}$ | 87.35$^{-0.41}$ |
| DeepSeek-R1 | 95.92 | 98.27$^{+2.35}$ | 93.26$^{-2.66}$ | 96.73$^{+0.82}$ | 85.26$^{-10.66}$ | 98.05$^{+2.14}$ | 95.51$^{-0.41}$ |
| DeepSeek-R1$^{T}$ | 96.07 | 96.50$^{+0.43}$ | 94.25$^{-1.81}$ | 97.32$^{+1.25}$ | 96.79$^{+0.73}$ | 98.03$^{+1.97}$ | 94.61$^{-1.46}$ |
| Qwen3-32B | **97.76** | **99.01**$^{+1.25}$ | **97.75**$^{-0.00}$ | **98.98**$^{+1.22}$ | **98.93**$^{+1.18}$ | **98.54**$^{+0.79}$ | **97.55**$^{-0.20}$ |
| Qwen3-32B$^{T}$ | 95.91 | 97.52$^{+1.61}$ | 94.38$^{-1.53}$ | 97.96$^{+2.05}$ | 98.04$^{+2.13}$ | 97.57$^{+1.66}$ | 96.11$^{+0.20}$ |
| GPT-4o | **96.36** | **98.51**$^{+2.16}$ | **98.88**$^{+2.52}$ | **97.55**$^{+1.19}$ | **97.96**$^{+1.60}$ | **98.05**$^{+1.70}$ | 95.51$^{-0.85}$ |
| GPT-4o-Mini | 92.38 | 96.29$^{+3.90}$ | 94.38$^{+2.00}$ | 95.92$^{+3.53}$ | 96.94$^{+4.55}$ | 97.08$^{+4.70}$ | 95.31$^{+2.92}$ |
| GPT-5 | 95.20 | 96.04$^{+0.84}$ | 92.13$^{-3.06}$ | 97.55$^{+2.35}$ | 97.35$^{+2.15}$ | 97.08$^{+1.88}$ | **96.12**$^{+0.92}$ |
| GPT-o3 | 94.87 | 96.53$^{+1.67}$ | 91.01$^{-3.86}$ | 97.35$^{+2.48}$ | 96.94$^{+2.07}$ | 97.08$^{+2.21}$ | 95.31$^{+0.44}$ |
| Gemini 2.5F | 92.72 | 97.03$^{+4.31}$ | 95.51$^{+2.79}$ | 96.94$^{+4.22}$ | 96.73$^{+4.02}$ | 96.36$^{+3.64}$ | 93.88$^{+1.16}$ |
| Gemini 2.5F$^{T}$ | 92.38 | 94.31$^{+1.92}$ | 89.89$^{-2.50}$ | 95.94$^{+3.56}$ | 96.13$^{+3.75}$ | 96.11$^{+3.72}$ | 90.82$^{-1.57}$ |
| **PAP** | | | | | | | |
| Qwen3-32B | 95.10 | **98.51**$^{+3.41}$ | **95.51**$^{+0.40}$ | 98.16$^{+3.06}$ | 98.57$^{+3.47}$ | 98.54$^{+3.44}$ | **97.55**$^{+2.45}$ |
| Qwen3-32B$^{T}$ | **97.13** | 97.77$^{+0.65}$ | 95.51$^{-1.62}$ | **98.98**$^{+1.85}$ | **98.57**$^{+1.44}$ | **98.54**$^{+1.41}$ | 95.88$^{-1.25}$ |
| Gemini 2.5F | 92.88 | **97.52**$^{+4.64}$ | **96.63**$^{+3.75}$ | **97.14**$^{+4.26}$ | **98.16**$^{+5.28}$ | **97.81**$^{+4.93}$ | **94.29**$^{+1.40}$ |
| Gemini 2.5F$^{T}$ | **93.54** | 94.31$^{+0.76}$ | 92.13$^{-1.41}$ | 96.94$^{+3.40}$ | 96.94$^{+3.40}$ | 95.62$^{+2.08}$ | 89.39$^{-4.16}$ |

## A.2 Summary of Model Behavior Under Numerical Perturbations for False Dataset Split (False → False)

Table 5 presents False → False perturbations where numerical values are modified while preserving the false label. Our experiments reveal that large models (e.g., GPT-4o, GPT-4o-Mini, Gemini 2.5F) and open-weight DeepSeek-R1$^{T}$ maintain high robustness across perturbations, with accuracies typically above 90%. Smaller models such as Llama 3.2-1B and Mistral-7B degrade sharply, especially under *Approx* and *Range*. Qwen3-32B$^{T}$ performs consistently well across shots, rivaling proprietary systems. Notable anomalies include Gemini



Bảng 5: Hiệu suất độ chính xác cho lớp False, trong tập dữ liệu 'False' được chia cùng với các nhiễu, nơi các giá trị số đã được chỉnh sửa để khác với tuyên bố sai ban đầu trong khi vẫn giữ nguyên nhãn, tức là False → False (-x cho thấy giảm; +x cho thấy tăng). Các giá trị in đậm biểu thị độ chính xác cao nhất trong mỗi cài đặt nhiễu, được phân tách theo mô hình open-weight và mô hình độc quyền.

| Mô hình | Nguyên bản | Khoảng | Số âm | Num | Rand-repl | Phạm vi | Mask |
|---|---|---|---|---|---|---|---|
| **Không cần huấn luyện trước** | | | | | | | |
| Llama2-1B | 5.71 | 5.45$^{-0.27}$ | 5.62$^{-0.10}$ | 6.33$^{+0.61}$ | 4.90$^{-0.82}$ | 5.35$^{-0.36}$ | 5.92$^{+0.20}$ |
| Llama3.3-70B | 93.67 | 96.53$^{+2.86}$ | 93.26$^{-0.42}$ | 96.12$^{+2.45}$ | 96.73$^{+3.06}$ | 95.62$^{+1.95}$ | 92.86$^{-0.82}$ |
| Mistral-7B | 96.53 | 97.28$^{+0.75}$ | 95.51$^{-1.02}$ | 96.33$^{-0.20}$ | 96.73$^{+0.20}$ | 96.35$^{-0.18}$ | 95.31$^{-1.22}$ |
| DeepSeek-R1 | **97.14** | **98.51**$^{+1.37}$ | **96.63**$^{-0.51}$ | 97.96$^{+0.82}$ | **98.16**$^{+1.02}$ | **98.30**$^{+1.15}$ | **97.55**$^{+0.41}$ |
| DeepSeek-R1$^{T}$ | 95.86 | 96.57$^{+0.71}$ | 91.57$^{-4.30}$ | 97.42$^{+1.56}$ | 97.61$^{+1.75}$ | 97.44$^{+1.58}$ | 93.74$^{-2.13}$ |
| Qwen3-32B | 96.12 | 98.27$^{+2.14}$ | 95.51$^{-0.62}$ | 97.96$^{+1.84}$ | 97.96$^{+1.84}$ | 98.30$^{+2.17}$ | 95.31$^{-0.82}$ |
| Qwen3-32B$^{T}$ | 95.92 | 96.74$^{+0.83}$ | 94.32$^{-1.60}$ | **98.22**$^{+2.30}$ | 97.74$^{+1.82}$ | 98.03$^{+2.11}$ | 94.01$^{-1.91}$ |
| GPT-4o | **96.52** | **97.77**$^{+1.25}$ | **96.63**$^{+0.11}$ | **98.16**$^{+1.64}$ | **98.16**$^{+1.64}$ | **97.81**$^{+1.29}$ | **96.53**$^{+0.01}$ |
| GPT-4o-Mini | 93.05 | 96.04$^{+2.99}$ | 92.13$^{-0.91}$ | 95.71$^{+2.67}$ | 95.92$^{+2.87}$ | 96.84$^{+3.79}$ | 93.27$^{+0.22}$ |
| GPT-5 | 95.20 | 96.29$^{+1.09}$ | 91.01$^{-4.19}$ | 97.55$^{+2.35}$ | 97.35$^{+2.15}$ | 96.84$^{+1.64}$ | 95.51$^{+0.31}$ |
| GPT-o3 | 95.36 | 96.04$^{+0.68}$ | 91.01$^{-4.35}$ | 96.94$^{+1.57}$ | 96.94$^{+1.57}$ | 96.84$^{+1.47}$ | 95.51$^{+0.15}$ |
| Gemini 2.5F | 93.21 | 97.28$^{+4.07}$ | 94.38$^{+1.17}$ | 96.94$^{+3.73}$ | 97.96$^{+4.75}$ | 97.08$^{+3.87}$ | 93.88$^{+0.67}$ |
| Gemini 2.5F$^{T}$ | 92.05 | 93.30$^{+1.25}$ | 87.64$^{-4.41}$ | 95.31$^{+3.25}$ | 94.90$^{+2.84}$ | 96.09$^{+4.04}$ | 88.98$^{-3.07}$ |
| **2-S** | | | | | | | |
| Llama2-1B | 10.00 | 7.92$^{-2.08}$ | 7.87$^{-2.13}$ | 7.76$^{-2.24}$ | 9.18$^{-0.82}$ | 9.25$^{-0.75}$ | 7.76$^{-2.24}$ |
| Llama3.3-70B | 95.92 | 97.52$^{+1.61}$ | 95.51$^{-0.41}$ | 96.73$^{+0.82}$ | 97.87$^{+1.95}$ | 95.38$^{-0.54}$ | 95.10$^{-0.82}$ |
| Mistral-7B | 87.76 | 87.38$^{-0.38}$ | 87.64$^{-0.11}$ | 88.57$^{+0.82}$ | 88.78$^{+1.02}$ | 87.35$^{-0.41}$ | 87.35$^{-0.41}$ |
| DeepSeek-R1 | 95.92 | 98.27$^{+2.35}$ | 93.26$^{-2.66}$ | 96.73$^{+0.82}$ | 85.26$^{-10.66}$ | 98.05$^{+2.14}$ | 95.51$^{-0.41}$ |
| DeepSeek-R1$^{T}$ | 96.07 | 96.50$^{+0.43}$ | 94.25$^{-1.81}$ | 97.32$^{+1.25}$ | 96.79$^{+0.73}$ | 98.03$^{+1.97}$ | 94.61$^{-1.46}$ |
| Qwen3-32B | **97.76** | **99.01**$^{+1.25}$ | **97.75**$^{-0.00}$ | **98.98**$^{+1.22}$ | **98.93**$^{+1.18}$ | **98.54**$^{+0.79}$ | **97.55**$^{-0.20}$ |
| Qwen3-32B$^{T}$ | 95.91 | 97.52$^{+1.61}$ | 94.38$^{-1.53}$ | 97.96$^{+2.05}$ | 98.04$^{+2.13}$ | 97.57$^{+1.66}$ | 96.11$^{+0.20}$ |
| GPT-4o | **96.36** | **98.51**$^{+2.16}$ | **98.88**$^{+2.52}$ | **97.55**$^{+1.19}$ | **97.96**$^{+1.60}$ | **98.05**$^{+1.70}$ | 95.51$^{-0.85}$ |
| GPT-4o-Mini | 92.38 | 96.29$^{+3.90}$ | 94.38$^{+2.00}$ | 95.92$^{+3.53}$ | 96.94$^{+4.55}$ | 97.08$^{+4.70}$ | 95.31$^{+2.92}$ |
| GPT-5 | 95.20 | 96.04$^{+0.84}$ | 92.13$^{-3.06}$ | 97.55$^{+2.35}$ | 97.35$^{+2.15}$ | 97.08$^{+1.88}$ | **96.12**$^{+0.92}$ |
| GPT-o3 | 94.87 | 96.53$^{+1.67}$ | 91.01$^{-3.86}$ | 97.35$^{+2.48}$ | 96.94$^{+2.07}$ | 97.08$^{+2.21}$ | 95.31$^{+0.44}$ |
| Gemini 2.5F | 92.72 | 97.03$^{+4.31}$ | 95.51$^{+2.79}$ | 96.94$^{+4.22}$ | 96.73$^{+4.02}$ | 96.36$^{+3.64}$ | 93.88$^{+1.16}$ |
| Gemini 2.5F$^{T}$ | 92.38 | 94.31$^{+1.92}$ | 89.89$^{-2.50}$ | 95.94$^{+3.56}$ | 96.13$^{+3.75}$ | 96.11$^{+3.72}$ | 90.82$^{-1.57}$ |
| **PAP** | | | | | | | |
| Qwen3-32B | 95.10 | **98.51**$^{+3.41}$ | **95.51**$^{+0.40}$ | 98.16$^{+3.06}$ | 98.57$^{+3.47}$ | 98.54$^{+3.44}$ | **97.55**$^{+2.45}$ |
| Qwen3-32B$^{T}$ | **97.13** | 97.77$^{+0.65}$ | 95.51$^{-1.62}$ | **98.98**$^{+1.85}$ | **98.57**$^{+1.44}$ | **98.54**$^{+1.41}$ | 95.88$^{-1.25}$ |
| Gemini 2.5F | 92.88 | **97.52**$^{+4.64}$ | **96.63**$^{+3.75}$ | **97.14**$^{+4.26}$ | **98.16**$^{+5.28}$ | **97.81**$^{+4.93}$ | **94.29**$^{+1.40}$ |
| Gemini 2.5F$^{T}$ | **93.54** | 94.31$^{+0.76}$ | 92.13$^{-1.41}$ | 96.94$^{+3.40}$ | 96.94$^{+3.40}$ | 95.62$^{+2.08}$ | 89.39$^{-4.16}$ |

## A.2 Tóm tắt Hành vi Mô hình Dưới Sự Nhiễu Số học cho Phân tách Dữ liệu Sai (Sai → Sai)

Bảng 5 trình bày các nhiễu → Sai, nơi các giá trị số được chỉnh sửa trong khi vẫn giữ nhãn sai. Các thí nghiệm của chúng tôi tiết lộ rằng các mô hình lớn (ví dụ, GPT-4o, GPT-4o-Mini, Gemini 2.5F) và DeepSeek-R1$^{T}$ với trọng lượng mở duy trì độ bền cao trước các biến động, với độ chính xác thường trên 90%. Các mô hình nhỏ hơn như Llama 3.2-1B và Mistral-7B giảm mạnh, đặc biệt dưới các điều kiện Approx và Range. Qwen3-32B$^{T}$ hoạt động ổn định trên nhiều lần thử, cạnh tranh với các hệ thống độc quyền. Những bất thường đáng chú ý bao gồm Gemini

| Example 1 | Example 2 |
|---|---|
| **Claim:**<br>As Republicans try to repeal the Affordable Care Act, they should be reminded every day that **36,000** people will die yearly as a result. | **Claim:**<br>We see a quarter-billion dollars in a pension fund that needs to be funded at **$1.2 billion**. |
| **Evidence:**<br>*Gift Article Share*<br>"As Republicans try to repeal the Affordable Care Act, they should be reminded every day that **36,000 people** will die yearly as a result." **— Sen. Bernie Sanders (D-Vt.)**, in a tweet, Jan. 12, 2017. | **Evidence:**<br>Providence Mayor Angel Taveras had to deal with near bankruptcy in the capital city after he took office in 2011. As the city struggled to fix its budget problems, he won union concessions to reduce pension costs. The most recent figures show the plan is only **31.4-percent funded**. |
| **Evaluation: False** | **Evaluation: True** |

Table 6: True and False examples of claims and their labels based on evidence used in the prompt.

2.5F's drop under *Approx* ($-5$ to $-6$ points) despite strong overall performance, and GPT-4o-Mini's unexpected gains in two-shot ($+3$ points). Reasoning-enabled ($^T$) variants generally improve robustness, though Gemini's thinking variant remains more variable.

The table 4, reports accuracy metric for the False class in the False dataset split with perturbations. Perturbations significantly modify numerical values while preserving the label (False $\rightarrow$ False). Results are presented for multiple LLMs including Llama, Mistral, DeepSeek, GPT, Gemini, and Qwen across three evaluation setups: Zero-shot, two-shot, and Perturbation-Aware Prompt (PAP). The columns indicate different perturbation types: Original (baseline), Approx, Neg-num, Num, Rand-repl, Range, and Mask. Superscripts with negative values denote drops relative to the baseline, and positive values denote improvements.

In the zero-shot setting, DeepSeek-R1, GPT-4o, and Qwen3-32B$^T$ achieve the highest and most stable performance, maintaining accuracies between 96% and 98% across perturbations. Gemini 2.5F is also stable with scores in the range of 93% to 97%. In contrast, smaller models such as Llama 3.2-1B perform poorly with accuracies around 5–6%. Mid-sized models like Llama 3.3-70B and Mistral-7B perform well but remain slightly below the frontier models.

In the two-shot setting, accuracy improves slightly compared to Zero-shot, especially for the smaller models. DeepSeek-R1 remains strong with scores around 96–97%, GPT-4o reaches 95–98%, Qwen3-32B$^T$ achieves 94–98%, and Gemini 2.5F$^T$ remains consistent with 90–96%. Llama 3.2-1B, however, continues to perform poorly with accuracies only between 7% and 10%.

Perturbation-Aware Prompt (PAP) delivers the highest overall accuracies. Qwen3-32B$^T$ and DeepSeek-R1$^T$ achieve 95–99% across all perturbations, while Gemini 2.5F$^T$ also shows strong performance with accuracies between 89% and 97%. PAP consistently improves the already strong models by about 1–2 percentage points compared to zero-shot and two-shot.

In general, model scale is critical. Small



| Ví dụ 1 | Ví dụ 2 |
|---|---|
| **Yêu cầu:**<br>Khi các chính trị gia Cộng hòa cố gắng bãi bỏ Đạo luật Chăm sóc Giá cả phải chăng<br>Luật Chăm sóc, họ nên được nhắc nhở mỗi ngày mà 36.000 người sẽ chết hàng năm như một kết quả . | **Yêu cầu:**<br>Chúng tôi thấy một phần tư tỷ đô la trong quỹ hưu trí quỹ cần được cấp vốn với 1,2 tỷ đô la. |
| **Bằng chứng:**<br>*Chia sẻ bài viết quà tặng*<br>"Khi các nghị sĩ Cộng hòa cố gắng bãi bỏ Đạo luật Chăm sóc Sức khỏe Hợp túi tiền (Affordable)"<br>Đạo luật Chăm sóc Khả năng, họ nên được nhắc nhở<br>Mỗi ngày sẽ có 36.000 người chết hàng năm vì **một kết quả." — Thượng nghị sĩ Bernie Sanders (D-Vt.),**<br>trong một tweet, ngày 12 t<br>háng 1 năm 2017. | **Bằng chứng:**<br>Thị trưởng Providence Angel Taveras đã phải đối phó với gần như phá sản ở thủ đô<br>sau khi ông nhậm chức vào năm 2011. Như thành phố<br>đã gặp khó khăn trong việc giải quyết các vấn đề ngân sách của mình, ông đã chiến thắng<br>nhượng bộ của công đoàn để giảm chi phí lương hưu.<br>Các số liệu gần đây nhất cho thấy kế hoạch là **chỉ được cấp vốn 31,4 phần trăm.** |
| **Đánh giá: Sai** | **Đánh giá: Đúng** |

Bảng 6: Ví dụ đúng và sai về các khẳng định và nhãn của chúng dựa trên bằng chứng được sử dụng trong lời nhắc.

2.5F giảm khoảng ($-5$ đến $-6$ điểm) mặc dù hiệu suất tổng thể mạnh, và GPT-4o-Mini có những tăng bất ngờ trong thử nghiệm hai cú ($+3$ điểm). Các biến thể có khả năng suy luận ($^T$) nói chung cải thiện độ ổn định, mặc dù biến t hể tư duy của Gemini vẫn biến động hơn.

Bảng 4 báo cáo chỉ số độ chính xác cho lớp False trong phân tách bộ dữ liệu False với các nhiễu. Các nhiễu làm thay đổi đáng kể các giá trị số trong khi vẫn giữ nguyên nhãn (False $\rightarrow$ False). Kết quả được trình bày cho nhiều mô hình ngôn ngữ lớn (LLM) bao gồm Llama, Mistral, DeepSeek, GPT, Gemini và Qwen qua ba thiết lập đánh giá: Zero-shot, two-shot và Perturbation-Aware Prompt (PAP). Các cột cho biết các loại nhiễu khác nhau: Original (cơ sở), Approx, Neg-num, Num, Rand-repl, Range và Mask. Các chỉ số mũ với giá trị âm biểu thị sự giả m so với cơ sở, và giá trị dương biểu thị sự cải thiện.

Trong bối cảnh zero-shot, DeepSeek-R1, GPT-4o và Qwen3-32B$^T$ đạt được hiệu suất cao nhất và ổn định nhất, duy trì độ chính xác trong khoảng từ 96% đến 98% trên các biến đổi tions. Gemini 2.5F cũng ổn định với điểm số nằm trong khoảng 93% đến 97%. Ngược lại, các mô hình nhỏ hơn như Llama 3.2-1B hoạt động kém với độ chính xác khoảng 5–6 %. Các mô hình cỡ trung như Llama 3.3-70B và Mistral-7B hoạt động tốt nhưng vẫn hơi thấp hơn các mô hình tiên tiến nhất.

Trong cài đặt hai lần thử, độ chính xác cải thiện nhẹ so với Zero-shot, đặc biệt là đối với các mô hình nhỏ hơn. DeepSeek-R1 vẫn mạnh với điểm số khoảng 96–97%, GPT-4o đạt 95–98%, Qwen3-32B$^T$ đạt 94–98%, và Gemini 2.5F$^T$ duy trì ổn định với 90–96%. Tuy nhiên, Llama 3.2-1B tiếp tục hoạt động kém với độ chính xác chỉ từ 7% đến 10%.

Lời nhắc Nhận thức Rối loạn (PAP) mang lại độ chính xác tổng thể cao nhất. Qwen3-32B$^T$ và DeepSeek-R1$^T$ đạt từ 95–99% trên tất cả các rối loạn, trong khi Gemini 2.5F$^T$ cũng thể hiện hiệu suất mạnh với độ chính xác từ 89% đến 97%. PAP liên tục cải thiện các mô hình vốn đã mạnh khoảng 1–2 điểm phần trăm so với phương pháp zero-shot và two-shot.

Nói chung, tỷ lệ mô hình là rất quan trọng. Nhỏ

models such as Llama 3.2-1B collapse under this evaluation, while large-scale and frontier models like DeepSeek, GPT-4o, Qwen, and Gemini perform near ceiling. Prompting with two-shot increases stability across most models, and PAP proves to be the most robust method, yielding the best and most consistent results overall.

# B Prompt

For the LLMs we use the same instruction and two-shot examples. The zero-shot only includes the instruction, whereas the two-shot includes the instruction and the sample data. The following two-shot examples are snippets of the examples used. For the full prompt, refer to our GitHub repository.

## B.1 System Prompt

The following prompt was used as the model system prompt:

*You are a professional fact checker, your task is to classify whether the given claim is true or false based on the evidence text provided.*

## B.2 Instruction

The following prompt was used along with two examples from Table 6:

*Given the claim and evidence provided, classify the claim as "label": true if it is true, and "label": false if it is false.*

## B.3 Two-shot Examples

Table 6 presents two examples of fact-checking claims used in the prompt for LLMs along with their corresponding evidence and veracity evaluations. The two examples are used for all LLMs and all perturbation inputs to be consistent. And each of the two example represents the two distinct labels in the dataset.

## B.4 Perturbation Aware Prompt

The following prompt was added to the instruction prompt for the negative example experiments:

*The numbers in the evidence may not match the claim. For example:*

*Claim: The Eiffel Tower is three hundred and fifty-one meters tall. Evidence: The Eiffel Tower is 330 meters tall. "label": false*

*Claim: The year-over-year U.S. inflation rate at the end of 2024 was -2.9%. Evidence: The year-over-year U.S. inflation rate at the end of 2024 was 2.9"label": false*

*Claim: The birth rate in Japan in 2023 was between 2 to 2.5. Evidence: The birth rate in Japan in 2023 was 1.2. "label": false*

*Claim: The population of Canada in 2023 was about 45 million. Evidence: The population of Canada in 2023 was 40.5 million by October 2023. "label": false*

*Claim: Saturn has 789 moons. Evidence: Discoveries bring Saturn's total moon count to 274, nearly triple Jupiter's and more than the total number of known moons around the other planets. "label": false*

*Claim: The Wembley Stadium in London has a seating capacity of ######. Evidence: The Wembley Stadium in London has a seating capacity of 90,000. "label": false*

## B.5 Prompt Length Analysis

We perform prompt length analysis for misclassified instances compared to correct classifications for the two most stable models–Gemini 2.5F$^T$ and Qwen3-32B$^T$.

**Gemini 2.5F$^T$** In misclassified instances, Gemini 2.5-Flash tends to have longer reasoning token length overall, with average total token length increasing by 15% compared to correct predictions (2103 vs. 1822 tokens). Prompt tokens show only a modest difference (+3%). The distribution further suggests that



Các mô hình như Llama 3.2-1B thất bại dưới đánh giá này, trong khi các mô hình quy mô lớn và tiên tiến như DeepSeek, GPT-4o, Qwen và Gemini hoạt động gần mức tối đa. Việc đưa ra lệnh với hai ví dụ tăng sự ổn định ở hầu hết các mô hình, và PAP được chứng minh là phương pháp bền vững nhất, mang lại kết quả tốt nhất và nhất quán nhất tổng thể.

# Lời nhắc B

Đối với các LLM, chúng tôi sử dụng cùng một hướng dẫn và ví dụ hai lần thử. Zero-shot chỉ bao gồm hướng dẫn, trong khi hai-shot bao gồm hướng dẫn và dữ liệu mẫu. Hai ví dụ hai-shot sau đây là các đoạn trích của các ví dụ đã sử dụng. Để xem toàn bộ lời nhắc, vui lòng tham khảo kho lưu trữ GitHub của chúng tôi.

### B.1 Lời nhắc Hệ thống

Câu lệnh sau đây đã được sử dụng làm câu lệnh hệ thống của mô hình:

*Bạn là một chuyên gia kiểm tra sự thật, nhiệm vụ của bạn là phân loại xem tuyên bố được đưa ra là đúng hay sai dựa trên văn bản bằng chứng được cung cấp.*

### B.2 Hướng dẫn

Lời nhắc sau đây đã được sử dụng cùng với hai ví dụ từ Bảng 6:

*Dựa trên tuyên bố và bằng chứng được cung cấp, phân loại tuyên bố là "label": true nếu nó đúng, và "label": false nếu nó sai.*

### B.3 Ví dụ hai lần thử

Bảng 6 trình bày hai ví dụ về kiểm tra sự thật của các tuyên bố được sử dụng trong lời nhắc cho LLM cùng với bằng chứng tương ứng và đánh giá tính xác thực. Hai ví dụ này được sử dụng cho tất cả các LLM và tất cả các đầu vào biến đổi để đảm bảo tính nhất quán. Và mỗi trong hai ví dụ này đại diện cho hai nhãn khác nhau trong bộ dữ liệu.

### B.4 Lời nhắc Nhận thức Nhiễu loạn

Lời nhắc sau đây đã được thêm vào lời nhắc hướng dẫn cho các thí nghiệm ví dụ tiêu cực:

*Các con số trong bằng chứng có thể không khớp với tuyên bố. Ví dụ:*

*Khẳng định: Tháp Eiffel cao ba trăm năm mươi mốt mét. Bằng chứng: Tháp Eiffel cao 330 mét. "nhãn": sai*

*Yêu cầu: Tỷ lệ lạm phát hàng năm của Hoa Kỳ vào cuối năm 2024 là -2,9%. Bằng chứng: Tỷ lệ lạm phát hàng năm của Hoa Kỳ vào cuối năm 2024 là 2,9. "nhãn": sai*

*Khẳng định: Tỷ lệ sinh ở Nhật Bản vào nă m 2023 là từ 2 đến 2,5. Bằng chứng: Tỷ lệ sinh ở Nhật Bản vào năm 2023 là 1,2. "nhãn": sai*

*Khẳng định: Dân số Canada vào năm 2023 khoảng 45 triệu. Bằng chứng: Dân số Canada vào năm 2023 là 40,5 triệu vào tháng 10 năm 2023. "nhãn": sai*

*Khẳng định: Sao Thổ có 789 vệ tinh. Bằng chứng: Các phát hiện đưa tổng số vệ tinh của Sao Thổ lên 274, gần gấp ba so với Sao Mộc và nhiều hơn tổng số vệ tinh đã biết quanh các hành tinh khác. "nhãn": sai*

*Khẳng định: Sân vận động Wembley ở London có sức chứa ###### chỗ ngồi. Bằng chứng: Sân vận động Wembley ở London có sức chứa 90.000 chỗ ngồi. "nhãn": sai*

### B.5 Phân tích độ dài câu lệnh

Chúng tôi thực hiện phân tích độ dài prompt đối với các trường hợp bị phân loại sai so với các phân loại đúng cho hai mô hình ổn định nhất – Gemini 2.5F$^T$ và Qwen3-32B$^T$.

Gemini 2.5F$^T$ Trong các trường hợp bị phân loại sai, Gemini 2.5-Flash có xu hướng có độ dài token lí giải tổng thể dài hơn, với độ dài token trung bình tổng tăng 15% so với các dự đoán đúng (2103 so với 1822 token). Token gợi ý chỉ cho thấy sự khác biệt khiê m tốn (+3%). Phân bố này còn gợi ý rằng

| Perturbation | Prompt Tokens | | Reasoning Tokens | |
|---|---|---|---|---|
| | Misclassified | Correct | Misclassified | Correct |
| Approximation | 2158.7 | 1303.9 | 1265.1 | 371.2 |
| Negative Number | 1214.5 | 1073.2 | 846.5 | 339.0 |
| Numeration | 1648.2 | 1239.6 | 796.1 | 378.4 |
| Random Replacement | 1576.4 | 1323.8 | 713.2 | 363.8 |
| Range | 1963.4 | 1315.1 | 698.4 | 401.1 |
| Masking | 1234.7 | 1017.8 | 717.1 | 427.7 |

Table 7: Comparison of average prompt and reasoning token lengths for Qwen3-32B$^T$ between **misclassifications** and **correct classifications** in the Zero-shot setting.

errors are associated with longer and more variable reasoning chains (max reasoning length over 6k tokens), whereas correct predictions are achieved with more compact reasoning. In other words, misclassifications correlate strongly with *overthinking*.

**Qwen3-32B$^T$** For Qwen3-32B$^T$, misclassified cases consistently exhibit inflated reasoning lengths compared to correctly classified instances in the Zero-shot setting (Table 7). For example, reasoning tokens nearly triple in *Approx* (1265 vs. 371) and more than double in *Num* (796 vs. 378) and *Range* (698 vs. 401). Prompt lengths are also consistently higher for misclassifications, with the most pronounced gap in *Approx*, where prompts expand by over 65% (2159 vs. 1304). The anomaly occurs with *Mask*, where reasoning remains high even in misclassifications (717 vs. 428), indicating that masked inputs elicit extended elaboration regardless of correctness. Overall, Qwen3-32B$^T$ tends to over-reason when it misclassifies, while correct predictions are characterized by shorter, more efficient reasoning chains and more compact prompts. All token lengths for Qwen3-32B$^T$ zero-shot settings are shown in Table 7.

## C Invalid Output Analysis

As shown in Table 8, across the open-weight models, invalid outputs are virtually absent

| Model | Total Instances | Invalid | % Invalid |
|---|---|---|---|
| | Zero-shot | | |
| DeepSeek-R1:32B | 8841 | 0 | 0.00 |
| DeepSeek-R1:32B$^T$ | 6837 | 477 | 6.98 |
| LLaMA-3.2 1B-Instruct | 6837 | 0 | 0.00 |
| LLaMA-3.3 70B | 6837 | 0 | 0.00 |
| Mistral-7B | 6837 | 0 | 0.00 |
| Qwen-3 32B | 7041 | 0 | 0.00 |
| Qwen-3 32B$^T$ | 6553 | 165 | 2.52 |
| | Two-shot | | |
| DeepSeek-R1:32B | 6951 | 0 | 0.00 |
| DeepSeek-R1:32B$^T$ | 6951 | 78 | 1.12 |
| LLaMA-3.2 1B-Instruct | 6837 | 0 | 0.00 |
| LLaMA-3.3 70B | 6951 | 0 | 0.00 |
| Mistral-7B | 6837 | 0 | 0.00 |
| Qwen-3 32B | 6951 | 0 | 0.00 |
| Qwen-3 32B$^T$ | 6951 | 23 | 0.33 |
| | PAP | | |
| DeepSeek-R1:32B | 6837 | 0 | 0.00 |
| DeepSeek-R1:32B$^T$ | 6837 | 92 | 1.35 |
| LLaMA-3.2 1B-Instruct | 6837 | 0 | 0.00 |
| LLaMA-3.3 70B | 6837 | 0 | 0.00 |
| Mistral-7B | 6837 | 0 | 0.00 |
| Qwen-3 32B | 6837 | 0 | 0.00 |
| Qwen-3 32B$^T$ | 6837 | 55 | 0.80 |

Table 8: Invalid outputs across open-weight models, grouped by shot setting. Thinking-enhanced variants are marked with $^T$. Percentages are calculated as invalid/total $\times$ 100.

in the non-thinking variants: Llama 3.3-70B, Llama-3.2 1B instruct, Mistral-7B, Qwen3-32B, and DeepSeek-R1 consistently produce $0.00\%$ invalidity across all shot settings. By contrast, enabling thinking introduces instability. For instance, DeepSeek-R1$^T$ exhibits a sharp rise in invalid generations under zero-shot ($6.98\%$), which decreases under two-shot ($1.12\%$) and PAP ($1.35\%$), indicating some recovery with examples. Similarly, Qwen3-



| Sự nhiễu loạn | Mã thông báo nhắc | | Mã Lý luận | |
|---|---|---|---|---|
| | Phân loại sai | Đúng | Phân loại sai | Đúng |
| Sự xấp xỉ | 2158.7 | 1303.9 | 1265.1 | 371.2 |
| Số âm | 1214.5 | 1073.2 | 846.5 | 339.0 |
| Sự đánh số | 1648.2 | 1239.6 | 796.1 | 378.4 |
| Thay thế ngẫu nhiên | 1576.4 | 1323.8 | 713.2 | 363.8 |
| Phạm vi | 1963.4 | 1315.1 | 698.4 | 401.1 |
| Che mặt | 1234.7 | 1017.8 | 717.1 | 427.7 |

Bảng 7: So sánh độ dài trung bình của token gợi ý và token lý luận cho Qwen3-32B$^T$ giữa các phân loại sai và phân loại đúng trong thiết lập Zero-shot.

các lỗi liên quan đến các chuỗi suy luận dài hơn và biến đổi hơn (độ dài suy luận tối đa trên 6k token), trong khi các dự đoán chính xác được thực hiện với suy luận gọn hơn. Nói cách khác, việc phân loại sai có mối liên hệ chặt chẽ với việc suy nghĩ quá mức.

Qwen3-32B$^T$ Đối với Qwen3-32B$^T$, các trường hợp phân loại sai thường cho thấy độ dài lập luận bị thổi phồng so với các trường hợp phân loại đúng trong chế độ Zero-shot (Bảng 7). Ví dụ, số lượng token lập luận gần như tăng gấp ba lần trong Approx (1265 so với 371) và hơn gấp đôi trong Num (796 so với 378) và Range (698 so với 401). Độ dài prompt cũng luôn cao hơn đối với các trường hợp phân loại sai, với khoảng cách rõ rệt nhất trong Approx, nơi các prompt mở rộng hơn 65% (2159 so với 1304). Ngoại lệ xảy ra với Mask, nơi độ dài lập luận vẫn cao ngay cả trong các trường hợp phân loại sai (717 so với 428), cho thấy rằng các đầu vào bị ẩn (masked) kích thích sự trình bày dài hơn bất kể đúng hay sai. Nhìn chung, Qwen3-32B$^T$ có xu hướng suy nghĩ quá mức khi phân loại sai, trong khi các dự đoán đúng được đặc trưng bởi chuỗi lập luận ngắn hơn, hiệu quả hơn và các prompt gọn gàng hơn. Tất cả độ dài token cho Qwen3-32B$^T$ trong chế độ zero-shot được trình bày trong Bảng 7.

| Mô hình | Tổng số trường hợp | Không hợp lệ | % Không hợp lệ |
|---|---|---|---|
| | Không cần huấn luyện trước | | |
| DeepSeek-R1:32B | 8841 | 0 | 0.00 |
| DeepSeek-R1:32B$^T$ | 6837 | 477 | 6.98 |
| LLaMA-3.2 1B-Hướng dẫn | 6837 | 0 | 0.00 |
| LLaMA-3.3 70B | 6837 | 0 | 0.00 |
| Mistral-7B | 6837 | 0 | 0.00 |
| Qwen-3 32B | 7041 | 0 | 0.00 |
| Qwen-3 32B$^T$ | 6553 | 165 | 2.52 |
| | Cảnh hai nhân vật | | |
| DeepSeek-R1:32B | 6951 | 0 | 0.00 |
| DeepSeek-R1:32B$^T$ | 6951 | 78 | 1.12 |
| LLaMA-3.2 1B-Hướng dẫn | 6837 | 0 | 0.00 |
| LLaMA-3.3 70B | 6951 | 0 | 0.00 |
| Mistral-7B | 6837 | 0 | 0.00 |
| Qwen-3 32B | 6951 | 0 | 0.00 |
| Qwen-3 32B$^T$ | 6951 | 23 | 0.33 |
| | PAP | | |
| DeepSeek-R1:32B | 6837 | 0 | 0.00 |
| DeepSeek-R1:32B$^T$ | 6837 | 92 | 1.35 |
| LLaMA-3.2 1B-Hướng dẫn | 6837 | 0 | 0.00 |
| LLaMA-3.3 70B | 6837 | 0 | 0.00 |
| Mistral-7B | 6837 | 0 | 0.00 |
| Qwen-3 32B | 6837 | 0 | 0.00 |
| Qwen-3 32B$^T$ | 6837 | 55 | 0.80 |

Bảng 8: Các kết quả không hợp lệ trên các mô hình trọng lượng mở, được nhóm theo cài đặt số lần bắn. Các biến thể tăng cường tư duy được đánh dấu bằng $^T$. Tỷ lệ phần trăm được tính là không hợp lệ / tổng $\times$ 100.

**Phân tích Kết quả Không hợp lệ C**

Như được trình bày trong Bảng 8, trong các mô hình t rọng lượng mở, các kết quả đầu ra không hợp lệ hầu như không xuất hiện

Trong các biến thể không suy nghĩ: Llama 3.3-70B, Llama-3.2 1B instruct, Mistral-7B, Qwen3-32B, và DeepSeek-R1 luôn tạo ra 0,00% khả năng không hợp lệ ở tất cả các thiết lập shot. Ngược lại, việc kích hoạt suy nghĩ gây ra sự không ổn định. Chẳng hạn, DeepSeek-R1$^T$ cho thấy sự tăng mạnh các kết quả không hợp lệ ở zero-shot (6,98%), giảm xuống ở two-shot (1,12%) và PAP (1,35%), cho thấy có một sự phục hồi nào đó khi có ví dụ. Tương tự, Qwen3-

| Model | Total Instances | Invalid | % Invalid |
|---|---|---|---|
| | Zero-shot | | |
| GPT-4o | 5298 | 0 | 0.00 |
| GPT-4o-mini | 5298 | 0 | 0.00 |
| GPT-5 | 5298 | 0 | 0.00 |
| GPT-o3 | 5298 | 1 | 0.02 |
| Gemini-2.5$^{T}$ | 5295 | 174 | 3.29 |
| Gemini-2.5 | 5298 | 1 | 0.02 |
| | Two-shot | | |
| GPT-4o | 5298 | 0 | 0.00 |
| GPT-4o-mini | 5298 | 0 | 0.00 |
| GPT-5 | 5298 | 0 | 0.00 |
| GPT-o3 | 5298 | 2 | 0.04 |
| Gemini-2.5$^{T}$ | 5298 | 82 | 1.55 |
| Gemini-2.5 | 5298 | 42 | 0.79 |
| | PAP | | |
| Gemini-2.5$^{T}$ | 5298 | 231 | 4.36 |
| Gemini-2.5 | 5298 | 0 | 0.00 |

Table 9: Invalid outputs across proprietary models and Gemini variants, grouped by shot setting. Percentages are calculated as invalid/total $\times$ 100.

32B$^{T}$ yields $2.52\%$ invalidity in zero-shot, reduced to $0.33\%$ under two-shot, but climbing again to around $0.80$–$1.33\%$ with perturbation-aware prompts.

These findings reveal a clear pattern: while open-weight models without reasoning remain robust against invalid outputs, their reasoning-enabled counterparts are consistently more error-prone. Zero-shot is the most unstable regime, two-shot offers stabilizing effects, and PAP shows mixed outcomes depending on the model.

As shown in Table 9, for proprietary systems, invalid outputs are exceedingly rare except in the Gemini family. GPT-4o, GPT-4o-Mini, GPT-5$^{T}$, and GPT-o3$^{T}$ maintain near-perfect robustness across all shot settings, with invalid rates between $0.00$–$0.04\%$. By contrast, Gemini 2.5F demonstrates a higher susceptibility to invalid generations. In particular, Gemini 2.5F$^{T}$ reaches $3.29\%$ invalidity under zero-shot, improves to $1.55\%$ with two-shot calibration, but rises again to $4.36\%$ under PAP. Its non-thinking counterpart is much more stable, remaining below $1\%$ invalidity in all cases.

Overall, proprietary models without reasoning capabilities (GPT family and Gemini 2.5F) are extremely stable, while reasoning-enabled variants of Gemini incur significantly higher invalid rates, especially in zero-shot and PAP settings.



| Mô hình | Tổng số trường hợp | Không hợp lệ | % Không hợp lệ |
|---|---|---|---|
| | Không cần huấn luyện trước | | |
| GPT-4o | 5298 | 0 | 0.00 |
| GPT-4o-mini | 5298 | 0 | 0.00 |
| GPT-5 | 5298 | 0 | 0.00 |
| GPT-o3 | 5298 | 1 | 0.02 |
| Gemini-2.5$^{T}$ | 5295 | 174 | 3.29 |
| Gemini-2.5 | 5298 | 1 | 0.02 |
| | Cảnh hai nhân vật | | |
| GPT-4o | 5298 | 0 | 0.00 |
| GPT-4o-mini | 5298 | 0 | 0.00 |
| GPT-5 | 5298 | 0 | 0.00 |
| GPT-o3 | 5298 | 2 | 0.04 |
| Gemini-2.5$^{T}$ | 5298 | 82 | 1.55 |
| Gemini-2.5 | 5298 | 42 | 0.79 |
| | PAP | | |
| Gemini-2.5$^{T}$ | 5298 | 231 | 4.36 |
| Gemini-2.5 | 5298 | 0 | 0.00 |

Bảng 9: Kết quả không hợp lệ trên các mô hình độc quyền và các biến thể của Gemini, được nhóm theo cài đặt số lần thử. Phần trăm được tính bằng invalid/total $\times$ 100.

32B$^{T}$ cho ra 2,52% lỗi trong chế độ zero-shot, giảm xuống 0,33% trong chế độ two-shot, nhưng lại tăng lên khoảng 0,80–1,33% với các lời nhắc nhận thức nhiễu.

Những phát hiện này tiết lộ một mô hình rõ ràng: trong khi các mô hình trọng số mở mà không có khả năng suy luận vẫn giữ vững trước các kết quả không hợp lệ, các mô hình có khả năng suy luận tương ứng của chúng thường dễ mắc lỗi hơn. Chế độ không cần huấn luyện trước l à không ổn định nhất, chế độ hai bước mang lại hiệu ứng ổn định, và PAP cho thấy kết quả đa dạng tùy thuộc vào mô hình.

Như được thể hiện trong Bảng 9, đối với các hệ thống độc quyền, các kết quả đầu ra không hợp lệ là cực kỳ hiếm ngoại trừ trong dòng Gemini. GPT-4o, GPT-4o-Mini, GPT-5$^{T}$, và GPT-o3$^{T}$ duy trì độ bền gần như hoàn hảo trên tất cả các thiết lập shot, với tỷ lệ không hợp lệ từ 0,00–0,04%. Ngược lại, Gemini 2.5F cho thấy mức độ nhạy cảm cao hơn với các kết quả tạo ra không hợp lệ. Cụ thể, Gemini 2.5F$^{T}$ đạt 3,29% không hợp lệ ở zero-shot, cải thiện xuống 1,55% với hiệu chỉnh hai-shot, nhưng lại tăng lên 4,36 % theo PAP. Phiên bản không suy nghĩ của nó ổn định hơn nhiều, duy trì dưới 1% không hợp lệ trong tất cả các trường hợp.

Nhìn chung, các mô hình độc quyền không có khả năng lý luận (gia đình GPT và Gemini 2.5F) cực kỳ ổn định, trong khi các biến thể của Gemini có khả năng lý luận lại gặp tỷ lệ không hợp lệ cao hơn đáng kể, đặc biệt trong các thiết lập zero-shot và PAP.

| **True → False Perturbed Claims** | **Reasoning Output Snippets** | **Analysis Summary** |
|---|---|---|
| The various offices of state government have purchased more than $########## in vehicles, not counting leases, for use from the Governor on down during the last two years. | **Gemini 2.5F**$^T$ zero-shot: "(...)While the claim uses a placeholder, the evidence substantiates the 'more than $11 million figure with precision. I will now mark the claim as true." **Gemini 2.5F**$^T$ PAP:"(...)I'm now certain the claim is false. The instruction's emphasis on placeholders makes the 'more than' condition irrelevant. The claim is inherently un-verifiable (...)" | In the zero-shot evaluation the model assumes that the model needs to find the missing value. PAP nudges the model in the correct direction, predicting the claim as false for the correct reasons. |
| Some states, like Montana and Nebraska, are getting more than three hundred and thirty thousand dollars in federal stimulus money per reported COVID-19 case. New York is the hardest-hit state and yet we are getting only about thirteen thousand, two hundred dollars per case. | **Gemini 2.5F**$^T$ zero-shot: "(...) I am also considering whether the small discrepancy in the funding figures makes the overall claim inaccurate (...) The claim is essentially true, even with minor discrepancies" **Gemini 2.5F**$^T$ PAP: "(...) claim states '$13,200' per case for New York, whereas the evidence consistently states '$12,000'. Since the numbers don't align, I must classify the claim as false." | PAP highlights that the 10% difference in the claim's numerical values, compared to the evidence as "significant numerical discrepancies". Zero-shot evaluation is more forgiving with regarding the discrepancies. |
| My opponent, Rick Gunn, blocked the expansion of Medicaid — costing half a million people health insurance, including about 34,000 veterans. | **Qwen3-32B**$^T$ zero-shot: "(...)The claim states 34,000 veterans, but the evidence only supports up to 23,000 or 14,000. The user's claim says 34,000, which is higher than both estimates (...)" *(starts to overthink)*. **Qwen3-32B**$^T$ PAP: "(...) The 34,000 figure isn't present in the evidence; the highest is 23,000. Therefore, the claim is false because the specific number provided doesn't match the evidence." | During zero-shot, the model starts to overthink, going in circles–outputting nearly 7000 reasoning tokens, citing the number in the evidence "23,000", 198 times, and the claim number "34,000", 135 times. During PAP, the model does correctly identify the discrapancy effectively, and keeps the reasoning token output of around 200. |

Table 10: Examples of claims, reasoning, and analysis for Gemini 2.5F$^T$ and Qwen3-32B$^T$ where reasoning improves for PAP, compared to zero-shot.



| **Đúng → Sai Bối rối** **Yêu cầu** | **Các đoạn trích kết quả lập luận** | **Tóm tắt phân tích** |
|---|---|---|
| Các văn phòng khác nhau của chính phủ bang có mua nhiều hơn $########## trong phương tiện giao thông, không tính hợp đồng thuê, cho sử dụng từ Thống đốc trở đi xuống trong hai cái cuối cùng năm. | Gemini 2.5F$^T$ zero-shot: "(...)Trong khi đòi hỏi sử dụng một chỗ giữ chỗ, cái bằng chứng chứng minh 'hơn 11 triệu đô la tính toán với độ chính xác. Tôi sẽ đánh dấu tuyên bố này là đúng. Gemini 2.5F$^T$ PAP:"(...)Tôi bây giờ chắc chắn rằng tuyên bố đó là sai. The sự nhấn mạnh của hướng dẫn về chỗ giữ chỗ tạo điều kiện 'nhiều hơn' không liên quan. Yêu cầu này vốn dĩ không thể kiểm chứng (...) | Trong trường hợp không có dữ liệu huấn luyện trước đánh giá mô hình giả định rằng mô hình cần tìm cái còn thiếu giá trị. PAP thúc đẩy mô hình đúng hướng, dự đoán khẳng định là sai cho lý do chính xác . |
| Một số bang, chẳng hạn như Montana và Nebraska, đang nhận được nhiều hơn ba trăm ba mươi nghìn đô la trong tiền kích thích liên bang theo báo cáo COVID-19 trường hợp. New York là bang bị ảnh hưởng nặng nề nhất và vẫn chúng tôi chỉ nhận được khoảng mười ba nghìn, hai một trăm đô la mỗi thùng. | Gemini 2.5F$^T$ zero-shot: "(...) Tôi là cũng xem xét liệu cái nhỏ sự chênh lệch trong các con số tài trợ làm cho tuyên bố tổng thể trở nên không chính xác (...) Yêu cầu đó về cơ bản là đúng, ngay cả với những sai lệch nhỏ Gemini 2.5F$^T$ PAP: "(...) trạng thái yêu cầu '13.200 USD' mỗi trường hợp cho New York, trong khi bằng chứng liên tục nêu '12.000 đô la'. Vì các con số đừng căn chỉnh, tôi phải phân loại yêu cầu như sai. | PAP nhấn mạnh rằng khác biệt 10% trong giá trị số của yêu cầu, so với bằng chứng như "số liệu đáng kể sự khác biệt". Zero-shot đánh giá nhiều hơn tha thứ với liên quan những sự khác biệt. |
| Đối thủ của tôi, Rick Gunn, chặn sự mở rộng của Medicaid — chi phí một nửa sức khỏe của một triệu người bảo hiểm, bao gồm khoảng 34.000 cựu chiến binh. | Qwen3-32B$^T$ zero-shot: "(...)The tuyên bố rằng có 34.000 cựu chiến binh, nhưng bằng chứng chỉ ủng hộ tới 23.000 hoặc 14.000. Yêu cầu của người dùng nói 34.000, cao hơn cả hai ước tính *(...)" (bắt đầu suy nghĩ quá nhiều).* Qwen3-32B$^T$ PAP: "(...) 34.000 con số không có trong bằng chứng; cao nhất là 23.000. Do đó, tuyên bố là sai vì số cụ thể được cung cấp không phù hợp với bằng chứng. | Trong quá trình zero-shot, cái mô hình bắt đầu suy nghĩ quá nhiều, đang đi vào vòng tròn–xuất gần như 7000 token lý luận, trích dẫn con số trong bằng chứng "23.000", 198 lần, và tuyên bố số "34.000", 135 lần. Trong thời gian PAP, mô hình hoạt động đúng xác định sự khác biệt một cách hiệu quả, và giữ đầu ra mã thông báo lập luận của khoảng 200. |

Bảng 10: Ví dụ về các tuyên bố, lập luận và phân tích cho Gemini 2.5F$^T$ và Qwen3-32B$^T$ nơi lập luận cải thiện đối với PAP, so với zero-shot.