NumPert: Biến Đổi Số Học Để Khám Phá Mô Hình Ngôn Ngữ Nhằm Dự Đoán Độ Chính Xác

Peter Røysland Aarnes VinaySetty Đại học Stavanger peter.r.aarnes@uis.no, vsetty@acm.org

Tóm tắt

Các mô hình ngôn ngữ lớn cho thấy hiệu suất mạnh mẽ trong các nhiệm vụ yêu cầu nhiều kiến thức như kiểm tra sự thật và trả lời câu hỏi, tuy nhiên chúng thường gặp khó khăn với lý luận số học. Chúng tôi trình bày một đánh giá hệ thống các mô hình tiên tiến nhất về dự đoán tính chính xác trên các tuyên bố số và cặp bằng chứng bằng cách sử dụng các biến đổi có kiểm soát, bao gồm cả các probe đảo nhãn, để kiểm tra độ bền. Kết quả của chúng tôi chỉ ra rằng ngay cả các hệ thống độc quyền hàng đầu cũng trải qua mức giảm độ chính xác lên đến 62% dưới một số biến đổi nhất định. Không có mô hình nào chứng tỏ được độ bền trên tất cả các điều kiện. Chúng tôi cũng nhận thấy rằng việc tăng độ dài ngữ cảnh thường làm giảm độ chính xác, nhưng khi ngữ cảnh mở rộng được bổ sung bằng các minh chứng đã biến đổi, hầu hết các mô hình phục hồi đáng kể. Những phát hiện này làm nổi bật những hạn chế quan trọng trong việc kiểm tra sự thật số học và gợi ý rằng độ bền vẫn là một thách thức mở đối với các mô hình ngôn ngữ hiện tại.

1 Giới thiệu

Việc xác minh các tuyên bố trên mạng xã hội, các cuộc tranh luận chính trị và thông cáo báo chí đã trở nên cần thiết. Trong khi các nền tảng như Politifact, Snopes và FullFact hỗ trợ việc kiểm tra sự thật thủ công, khả năng mở rộng của chúng vẫn bị hạn chế. Các tuyên bố về con số, đặc biệt, là tẻ nhạt và dễ sai sót đối với người gán nhãn thủ công (Aly et al., 2021). Mô hình ngôn ngữ thần kinh cung cấp một lựa chọn hứa hẹn cho việc truy xuất bằng chứng và kiểm tra độ xác thực sơ bộ

Ví dụ về nhiễu loạn số

Yêu cầu gốc: "Vào năm 2020, doanh thu của công ty là 5.000.000 đô la, tạo ra mức tăng t rưởng đáng kể so với năm trước."

[**Nhãn: ĐÚNG, Dự đoán của mô hình: ĐÚNG** ✓]

Yêu cầu gây bối rối: "Vào năm 2020, doanh thu của công ty là năm mươi triệu đô la, tạo ra sự tăng trưởng đáng kể so với năm trước."

[**Nhãn: SAI, Dự đoán của mô hình: ĐÚNG**]

Bằng chứng: "Một phân tích thị trường của Nhóm Nghiên cứu MNO, được công bố vào năm 2021, cho biết: 'PQR Innova- tions đã trải qua sự tăng trưởng đáng kể (...). Doanh thu trong năm 2020 đạt 5.000.000 đô la."[1em]

Hình 1: Ví dụ minh họa cách tuyên bố 'ĐÚNG' ban đầu bị làm sai lệch thành tuyên bố 'SAI', nhưng mô hình vẫn dự đoán là 'ĐÚNG'.

đánh giá (Guo et al., 2022; Dmonte et al., 2024; Setty, 2024). Tuy nhiên, các nghiên cứu gần đây cho thấy cả các mô hình transformer được tinh chỉnh để xác minh các tuyên bố số và các mô hình ngôn ngữ l ớn đa năng đều gặp khó khăn với lý luận số học (Wallat et al., 2024; V et al., 2024; Akhtar et al., 2023), và các lý do vẫn chưa rõ ràng.

Mặc dù các nghiên cứu trước đây đã nghiên cứu về độ dễ vỡ của LLM trong suy luận số học cho QA (Xu et al., 2022) và NLI dạng bảng (Akhtar et al., 2023), nhưng không có phân tích hệ thống nào tồn tại cho dự đoán độ xác thực trong kiểm t ra sự thật dài hạn. Kết quả của chúng tôi chỉ ra rằng các mô hình có xu hướng mắc lỗi khi bối cảnh và chuỗi suy luận dài hơn. Để giải quyết khoảng trống này, chúng tôi đánh giá các mô hình tiên tiến với các kích thước và kiến trúc khác nhau.

Kỷ yếu Hội thảo Nghiên cứu Sinh viên IJCNLP-AACL 2025, các trang 78–95, ngày 20-24 tháng 12, 2025 ©2025 Hiệp hội Ngôn ngữ học Máy tính

dưới các cài đặt nhắc khác nhau với các tuyên bố và bằng chứng số bị làm nhiễu một cách có hệ thống.

Việc thao túng các giá trị số trong văn bản không cấu trúc đòi hỏi sự cẩn thận để đảm bảo rằng các thay đổi vẫn có ý nghĩa. Chúng tôi xác định sáu loại thăm dò: Đánh số (Num), Xấp xỉ (Approx), Khoảng, Che giấu (Mask), Thay thế ngẫu nhiên (Rand-Repl), và Số âm (Neg-Num) (xem Bảng 1) để sửa đổi số một cách có hệ thống trong khi vẫn giữ nguyên ý định của tuyên bố. Trong một số trường hợp, các thay đổi này cũng làm thay đổi nhãn thực tế (ví dụ: thay đổi $5,000,000 thành năm mươi triệu; xem Hình 1). Tất cả các thay đổi đều được kiể m tra thủ công để đảm bảo tính đúng đắn và liên quan. Nghiên cứu này giải quyết ba câu hỏi nghiên cứu:

RQ1: Mẫu nào trong lựa chọn các kích thước đa dạng của chúng tôi là mạnh mẽ nhất và kém mạnh mẽ nhất?

RQ2: Những nhiễu số nào ảnh hưởng nhiều nhất đến hiệu suất?

RQ3: Chiều dài ngữ cảnh và chuỗi lập luận ảnh hưởng đến độ bền như thế nào?

Để trả lời điều này, chúng tôi kiểm tra các mô hình trên các cặp tuyên bố–bằng chứng, so sánh các dự đoán cơ bản với các dự đoán trên các tuyên bố bị thay đổi số liệu. Khoảng cách lớn hơn phản ánh độ bền yếu hơn. Chúng tôi sử dụng các khảo sát trung thực giữ nhãn gốc và các khảo sát đảo nhãn mâu thuẫn với bằng chứng, dưới các lệnh zero-shot, two-shot và lệnh có nhận thức về thay đổi (PAP).

Kết quả của chúng tôi cho thấy tất cả các mô hình tiên tiến nhất đều dễ bị tổn thương bởi các perturbation số học, đặc biệt là dưới Mask và Neg-Num. Chúng tôi cũng nhận thấy rằng các thiết lập zero-shot hoạt động tốt hơn hai-shot, trong khi việc cung cấp một vài ví dụ bị perturb (prompt PAP) giúp các mô hình phục hồi trong hầu hết các trường hợp. Những phát hiện này tiết lộ những điểm yếu trong việc dự đoán độ xác thực của LLM.

2 Công trình liên quan

Khả năng giải thích của các mô hình ngôn ngữ lớn (LLM) là rất quan trọng đối với các nhiệm vụ yêu cầu nhiều kiến thức như trả lời câu hỏi và kiểm chứng thông tin. Các nghiên cứu thăm dò đã tiết lộ các quá trình ra quyết định mờ ám của chúng (Belinkov, 2022). Ví dụ, Yang và cộng sự (2024); Lu và cộng sự (2023); Frieder và cộng sự (2024) đã chỉ ra rằng mặc dù LLM có thể thực hiện suy luận phức tạp, nhưng chúng thường gặp khó khăn với các phép tính cơ bản.

Một số nghiên cứu đã khảo sát khả năng lý luận số học trong các LLM. Wallace và cộng sự (2019) khảo sát các embeddings từ BERT và GloVe, phát hiện ra khả năng số học vốn có nh ưng không nhất quán. Akhtar và cộng sự (2023) đánh giá các mô hình trên dữ liệu bảng với một hệ thống phân loại phân cấp, cho thấy không có mô hình nào vượt trội trong tất cả các nhiệm vụ. Xu và cộng sự (2022); Zhou và cộng sự (2024) chứng minh rằng các biến động số trong QA thường làm LLM bị nhầm lẫn, trong khi Par uchuri và cộng sự (2024); Chen và cộng sự (2024) nhấn mạnh những điểm yếu trong khả năng lý luận số học. Một số nghiên cứu cũng chỉ ra rằng các LLM dùng để kiểm tra thông tin có tính giòn trước các biến động văn bản và các chỉnh sửa đối kháng (Mamta và Cocarascu, 2025; Przybyła và cộng sự, 2024; Liu và cộng sự, 2025).

Mặc dù đã có những tiến bộ trước đó, vẫn còn những khoảng trống quan trọng. Hầu hết các nghiên cứu không xem xét lý luận số trong việc kiểm tra sự thật mở với dữ liệu thực tế có bối cảnh dài, và khả năng tái lập thường hạn chế. Chẳng hạn, Akhtar và cộng sự (2023) dựa vào các đầu vào bảng tổng hợp với bối cảnh ngắn, cung cấp chi tiết biến đổi không đầy đủ và thiếu kho lưu trữ có thể truy cập. Ngược lại, chúng tôi đánh giá lý luận số trong các môi trường thực tế, không cấu trúc, giới thiệu các biến đổi giữ nguyên tính hợp lệ về ngữ nghĩa, và phát hành đầy đủ mã cùng dữ liệu để đảm bảo khả năng tái lập.

3 Phương pháp luận

Nghiên cứu của chúng tôi xem xét các mô hình dự đoán tính xác thực bằng cách có hệ thống làm xáo trộn các giá trị số trong các nhận định để đánh giá tác động của chúng đến việc dự đoán nhãn. Phương pháp luận bao gồm (1) tuyển chọn

một tập dữ liệu với các biểu thức số đa dạng (ví dụ, thống kê), (2) áp dụng các biến đổi có kiểm soát (ví dụ, tỉ lệ, thay thế, che dấu). (3) Phân tích lỗi rộng rãi tận dụng các token lý luận.

Bảng 1: Số lượng tuyên bố theo loại nhiễu vẫn giữ 'Đúng' (T→T), vẫn giữ 'Sai' (F→F), hoặc chuyển từ 'Đúng' sang 'Sai' (T→F). Dữ liệu cơ sở không nhiễu có 260 tuyên bố Đúng và 604 tuyên bố Sai.

Thể loại	T → T	F →F	T →F
Num	213	490	213
Khoảng	170	404	170
Phạm vi	188	411	188
Mask	✗	490	213
Rand-Repl	✗	490	213
Số âm	✗	89	51

3.1 Bộ dữ liệu và Tiền xử lý

Chúng tôi sử dụng tập dữ liệu QuanTemp (V và cộng sự, 2024), chứa các cặp tuyên bố - bằng chứng thực tế với trọng tâm số liệu từ các nguồn kiểm chứng sự thật uy tín. Mỗi cặp được gắn nhãn là Đúng, Sai hoặc Mâu thuẫn. Trong đánh giá của chúng tôi, chúng tôi loại bỏ lớp Mâu thuẫn do sự mơ hồ vốn có của nó. Để ngăn việc học tắt, chúng tôi loại bỏ các bản tóm tắt khỏi tất cả các cặp, yêu cầu các mô hình đánh giá tính xác thực chỉ dựa trên bằng chứng.

Mỗi tuyên bố được xử lý với trình gắn thẻ NER của spaCy (bao gồm Cardinal, Money, Percent, Time, Date và Ordinal), và các giá trị số được chuẩn hóa thành chữ số bằng cách sử dụng thư viện Word2Number (tương tự như (Akhtar et al., 2023; Wallace et al., 2019; Xu et al., 2022)). Các tuyên bố bị thay đổi được xác minh thủ công để đảm bảo hợp lệ, và các trường hợp không hợp lệ sẽ bị loại bỏ.

3.2 Kỹ thuật nhiễu loạn

Chúng tôi áp dụng phân loại suy luận số học của Akhtar và cộng sự (2023) (xem Bảng 1). Các cài đặt Num, Approx, và Range làm nhiễu số liệu trong khi vẫn phù hợp với bằng chứng, nên các khẳng định đúng vẫn giữ đúng. Ngược lại, Mask, Rand-Repl, và Neg-Num thay đổi các giá trị như rằng các tuyên bố đúng chuyển thành sai, trong khi các tuyên bố sai vẫn giữ nguyên. Chúng tôi không làm sai thành đúng, vì tính sai có thể xuất phát từ nhiều yếu tố và các tuyên bố phản thực tế thường không khả thi. Khám phá hướng này sẽ được để lại cho công việc tương lai. Bây giờ chúng tôi giải thích các kỹ thuật làm nhiễu khác nhau:

Num: Kiểm tra xem các mô hình có nhận ra sự tương đương giữa chữ số và từ viết (ví dụ, “12” và “twelve”) hay không, đồng thời giữ nguyên nhãn gốc cho các câu hỏi không đổi nhãn. Sự biến động áp dụng cho các số Cardinal, Percent và Money, nhưng không áp dụng cho Ordinal, Time hoặc Date, trừ trường hợp số cardinal trong Time (ví dụ, “24 hours” thành “twenty four hours”). Đối với các câu hỏi đổi nhãn, số gốc sẽ được sửa đổi (ví dụ, “12” có thể bị thay đổi thành “fifteen”).

Xấp xỉ: Các phép đo không lật nhãn làm giảm độ chính xác bằng cách làm tròn và cộng thêm khoảng (ví dụ, “1.025 đô la” t hành “khoảng 1000 đô la”), vẫn giữ đúng khi gần với bằng chứng. Đối với các phép đo lật nhãn, giá trị ban đầu được thay đổi để không còn phản ánh số tiền thực sự (ví dụ, ban đầu “1.025 đô la” thành “khoảng 1200 đô la”).

Phạm vi: Các kiểm tra không lật thay thế các giá trị chính xác bằng các khoảng (ví dụ, “25 phần trăm” thành “từ 20 đến 30 phần trăm”), kiểm tra khả năng lý luận trên các khoảng. Các kiểm tra lật nhãn thay đổi khoảng sao cho số ban đầu không nằm trong đó (ví dụ, số ban đầu “25 phần trăm” bị thay đổi thành “từ 30 đến 40 phần trăm”).

Rand-Repl: Thay thế các con số bằng các giá trị ngẫu nhiên có cùng độ dài chữ số (ví dụ, “100.000” thành “ 423.823”), làm cho bằng chứng không khớp.

Mặt nạ: Che các con số bằng các ký tự “#” theo độ dài chữ số, bao gồm cả dấu phân cách (ví dụ, “100,000” thành “#######”), yêu cầu suy luận từ bằng chứng.

Neg-Num: Chuyển các giá trị thành số âm (ví dụ: “ 4%” thành “-4%”), chỉ áp dụng cho phần trăm vì các thực thể khác (tiền, thời gian, ngày tháng) thường sử dụng các dấu hiệu ngôn ngữ như “giả m.”

3.3 Chiến lược đưa ra gợi ý

Tất cả các mô hình sử dụng các hướng dẫn giống nhau dưới ba chiến lược gợi ý: (1) Zero-shot chỉ với hướng dẫn mà không có minh họa (xem Phụ lục B), (2) Gợi ý hai bước mở rộng gợi ý zero-shot với một minh họa True và một minh họa False từ dữ liệu huấn luyện kèm bằng chứng và lý giải (Brown et al., 2020). (3) Chúng tôi cũng kiểm tra các mô hình với gợi ý nhận biết biến đổi (PAP), kết hợp một tuyên bố bị biến đổi với một câu bằng chứng cho mỗi loại biến đổi và nhãn bị đảo ngược. Một phương pháp tương tự được sử dụng bởi (Hu et al., 2024) trong bối cảnh aRAG. Toàn bộ các gợi ý được cung cấp trong Phụ lục B.

4 Thiết lập Thí nghiệm

Phần này mô tả khung thí nghiệm của chúng tôi, bao gồm các mô hình ngôn ngữ sử dụng và phương pháp đánh giá.

4.1 Lựa chọn mô hình

LLM trọng lượng mở: DeepSeek-R1-32B,

Qwen3-32B, Llama3.3-70B, Llama 3.2-1B, và Mistral-7B (Tất cả các mô hình đều từ framework Ollama [1] với lượng tử hóa Q 4_ K _ M).

Các LLM độc quyền: GPT-4o (v2024-08-06), GPT-4o-mini (v2024-07-18), GPT-5 (v2025-08-07), GPT-o3 (v2025-04-16), và Gemini 2.5 Flash (v2025-06) (Tất cả các mô hình đều được truy cập thông qua API chính thức của chúng)

Các mô hình có khả năng suy nghĩ được đánh dấu bằng số mũ T. Tất cả các mô hình chạy với nhiệt độ 0 và đầu ra JSON; các mô hình open-weight và OpenAI sử dụng mức nỗ lực suy luận mặc định (trung bình). Đối với Gemini 2.5 Flash^T, chúng tôi đã cố định ngân sách suy nghĩ là 8192 (so với mặc định là 1) để hiệu quả về chi phí. Các thiết lập khác theo mặc định. Chúng tôi loại trừ Llama 3.2-1B và Mistral-7B khỏi kết quả chính do độ ổn định hạn chế; chi tiết có trong Phụ lục A.2. Các dự đoán không hợp lệ là hiếm, ngoại trừ DeepSeek-R1^T, vốn tạo ra 6,8% kết quả không hợp lệ trong trường hợp zero-shot. Các biến thể Thinking nói chung tạo ra nhiều kết quả không hợp lệ hơn so với các đối tác không Thinking của chúng (xem Phụ lục C). Mã và dữ liệu có thể truy cập qua kho lưu trữ GitHub của chúng tôi[2].

[1] https://ollama.com/search

4.2 Đánh giá

Độ bền được đánh giá bằng cách so sánh hiệu suất cơ bản trên các tuyên bố không bị xáo trộn với hiệu suất trên các tuyên bố bị xáo trộn. Chúng tôi sử dụng chỉ số độ chính xác theo từng lớp. Chúng tôi sử dụng độ chính xác làm chỉ số chính cho đánh giá $T \rightarrow F$. Để hiểu rõ hơn về lỗi của mô hình, chúng tôi tự tay phân tích các token suy luận của zero-shot so với PAP cho các tuyên bố T $\rightarrow$ F để tìm các mẫu chung mà mô hình mắc phải khi đánh giá một tuyên bố.

5 kết quả

Chúng tôi báo cáo kết quả trên các mô hình và các thiết lập nhiễu. Trước tiên, chúng tôi mô tả hiệu suất trên các tuyên bố không bị nhiễu, sau đó phân tích các thay đổi dưới các điều kiện nhãn không đảo và đảo. Kết quả cho các trường hợp False $\rightarrow$False được bỏ qua tại đây để ngắn gọn (xem Phụ lục A.2). Các mô hình được đánh giá dưới ba chế độ gợi ý được định nghĩa trong Mục 3.3 (xem Phụ lục B để biết đầy đủ các gợi ý).

5.1 Đúng $\rightarrow$Sai

Chúng tôi bắt đầu với trường hợp thách thức nhất: nhiễu lật nhãn (True $\rightarrow$ False), được hiển thị trong Bảng 2. Do khẳng định và nhãn thực tế bị lật, tất cả các kết quả được báo cáo phản ánh nhãn đã bị lật. Sự giảm hiệu suất có nghĩa là các mô hình vẫn dự đoán True thay vì False như mong đợi và kém bền vững hơn. Hiệu suất trên các khẳng định True không bị nhiễu được đưa ra trong cột "Original" như là cơ sở cho mỗi chế độ gợi ý.

[2] https://github.com/iai-group/tấn công_gây nhiễu_số liệu_yêu cầu/

Bảng 2: Độ chính xác (được báo cáo theo %) cho tập dữ liệu 'True' phân tách cho các nhiễu lật nhãn (True → False), và so sánh biến thiên độ chính xác giữa các thăm dò bị lật với hiệu suất mô hình trên độ chính xác của các tuyên bố gốc không thay đổi (-x cho biết giảm; +x cho biết tăng). Các giá trị in đậm biểu thị độ chính xác cao nhất trong từng cài đặt nhiễu, được phân tách theo mô hình mở và mô hình độc quyền.

Mô hình	Nguyên bản	Khoảng	Số âm	Num	Rand-repl	Phạm vi	Mask
Không cần huấn luyện trước							
Llama3.3-70B	87.32	87.65$^{+0.32}$	**62.75**$^{-24.58}$	68.54$^{-18.78}$	**91.08**$^{+3.76}$	82.45$^{-4.88}$	10.80$^{-76.53}$
DeepSeek-R1-32B	81.69	**89.41**$^{+7.72}$	39.22$^{-42.47}$	56.34$^{-25.35}$	88.73$^{+7.04}$	81.91$^{+0.22}$	**23.47**$^{-58.22}$
DeepSeek-R1-32B^{T}	**87.44**	85.06$^{-2.37}$	31.91$^{-55.52}$	69.43$^{-18.01}$	84.73$^{-2.71}$	86.98$^{-0.46}$	10.63$^{-76.81}$
Qwen3-32B	84.35	78.24$^{-6.12}$	43.14$^{-41.21}$	58.78$^{-25.57}$	84.51$^{+0.16}$	80.32$^{-4.03}$	16.43$^{-67.92}$
Qwen3-32B^{T}	85.99	89.38$^{+3.38}$	34.04$^{-51.95}$	**78.24**$^{-7.75}$	87.88$^{+1.89}$	**87.64**$^{+1.65}$	12.38$^{-73.61}$
GPT-4o	80.00	88.82$^{+8.82}$	47.06$^{-32.94}$	73.24$^{-6.76}$	90.61$^{+10.61}$	91.49$^{+11.49}$	19.25$^{-60.75}$
GPT-4o-Mini	**85.38**	68.24$^{-17.15}$	25.49$^{-59.89}$	56.81$^{-28.58}$	78.87$^{-6.51}$	75.00$^{-10.38}$	11.27$^{-74.12}$
GPT-5^{T}	76.15	93.53$^{+17.38}$	33.33$^{-42.82}$	**86.38**$^{+10.23}$	89.20$^{+13.05}$	92.02$^{+15.87}$	19.72$^{-56.44}$
GPT-o3^{T}	75.77	89.41$^{+13.64}$	25.49$^{-50.28}$	84.98$^{+9.21}$	88.73$^{+12.96}$	90.96$^{+15.19}$	21.60$^{-54.17}$
Gemini 2.5F	82.69	**95.29-**$^{+12.60}$	54.90$^{-27.79}$	83.57$^{+0.88}$	**96.71**$^{+14.02}$	**93.09**$^{+10.39}$	**25.82**$^{-56.87}$
Gemini 2.5F^{T}	71.54	88.82$^{+17.29}$	**58.82**$^{-12.71}$	82.63$^{+11.09}$	89.67$^{+18.13}$	90.43$^{+18.89}$	16.90$^{-54.64}$
Cảnh hai nhân vật							
Llama3.3-70B	**91.55**	72.35$^{-19.20}$	**33.33**$^{-58.22}$	46.48$^{-45.07}$	78.26$^{-13.29}$	57.98$^{-33.57}$	8.92$^{-82.63}$
DeepSeek-R1-32B	89.67	65.29$^{-24.38}$	21.57$^{-68.10}$	37.09$^{-52.58}$	74.70$^{-14.97}$	58.51$^{-31.16}$	12.21$^{-77.46}$
DeepSeek-R1-32B^{T}	86.32	88.55$^{+2.23}$	22.00$^{-64.32}$	71.15$^{-15.17}$	88.49$^{+2.17}$	87.17$^{+0.85}$	9.43$^{-76.89}$
Qwen3-32B	79.81	70.59$^{-9.22}$	37.25$^{-42.56}$	49.77$^{-30.05}$	66.40$^{-13.41}$	72.87$^{-6.94}$	**20.66**$^{-59.15}$
Qwen3-32B^{T}	83.49	**86.98**$^{+3.49}$	27.45$^{-56.04}$	**78.20**$^{-5.29}$	**88.76**$^{+5.26}$	**87.23**$^{+3.74}$	12.74$^{-70.75}$
GPT-4o	86.54	82.35$^{-4.19}$	33.33$^{-53.21}$	68.54$^{-17.99}$	87.32$^{+0.79}$	85.64$^{-0.90}$	13.62$^{-72.92}$
GPT-4o-Mini	**89.62**	67.06$^{-22.56}$	27.45$^{-62.16}$	50.70$^{-38.91}$	77.46$^{-12.15}$	73.94$^{-15.68}$	20.19$^{-69.43}$
GPT-5^{T}	77.69	**91.18**$^{+13.48}$	29.41$^{-48.28}$	84.04$^{+6.35}$	88.26$^{+10.57}$	88.83$^{+11.14}$	18.78$^{-58.91}$
GPT-o3^{T}	75.77	89.41$^{+13.64}$	23.53$^{-52.24}$	**85.45**$^{+9.68}$	89.67$^{+13.90}$	**90.43**$^{+14.66}$	22.07$^{-53.70}$
Gemini 2.5F	85.00	87.06$^{+2.06}$	35.29$^{-49.71}$	70.89$^{-14.11}$	**94.37**$^{+9.37}$	85.64$^{+0.64}$	**22.90**$^{-62.10}$
Gemini 2.5F^{T}	74.23	90.00$^{+15.77}$	**52.94**$^{-21.29}$	82.16$^{+7.93}$	92.02$^{+17.79}$	88.83$^{+14.60}$	15.96$^{-58.27}$
Gợi ý Nhận Thức Sự Nhiễu (PAP)							
Qwen3-32B	79.34	89.41$^{+10.07}$	76.47$^{-2.87}$	73.71$^{-5.63}$	90.61$^{+11.27}$	89.36$^{+10.02}$	**67.61**$^{-11.74}$
Qwen3-32B^{T}	71.23	**95.27**$^{+24.04}$	74.00$^{+2.77}$	**90.14**$^{+18.91}$	**94.37**$^{+23.14}$	**94.62**$^{+23.40}$	44.85$^{-26.38}$
Gemini 2.5F	**81.92**	**97.06**$^{+15.14}$	74.51$^{-7.41}$	84.98$^{+3.05}$	**97.18**$^{+15.26}$	**94.68**$^{+12.76}$	29.11$^{-52.82}$
Gemini 2.5F^{T}	63.08	91.76$^{+28.69}$	**88.24**$^{+25.16}$	**86.85**$^{+23.78}$	92.02$^{+28.94}$	90.96$^{+27.88}$	26.29$^{-36.79}$

5.1.1 Hiệu suất trên các yêu cầu không bị xáo trộn

Trong zero-shot, hầu hết các mô hình tập trung trong khoảng từ thấp đến cao của thập phân tám mươi, với Llama 3.3-70B hoạt động tốt nhất khoảng 87% và Qwen3-32B^{T} đứng ngay sau với 86 %. Các mô hình sở hữu độc quyền thấp hơn một chút, với GPT-4o-Mini đạt khoảng 85% là hiệu s uất mạnh nhất. Điều này cho thấy các mô hình l ớn hơn có thể cần các prompt được chỉ định cụ t hể hơn để đạt độ chính xác cao hơn.

Với việc gợi ý hai bước, các đường cơ sở tăng lên đối với Llama 3.3-70B, các biến thể GPT và DeepSeek-R1. Llama 3.3-70B vượt qua 91%. Ngược lại, các biến thể Qwen3-32B giảm, Gemini 2.5F giảm nhẹ, và biến thể tư duy của nó cho thấy cải thiện khiêm tốn. Dưới PAP, cả mô hình Qwen và Gemini đều thể hiện sự giảm hiệu suất. Các mô hình bị nhầm lẫn bởi PAP vì nó chứa các ví dụ phản một cách giả định.

Tổng thể, việc thêm một vài ví dụ mẫu cải thiện các chuẩn cơ sở cho các mô hình Llama và GPT nhưng có xu hướng làm giảm hiệu quả cho Qwen và Gemini. Không-

Bảng 3: Độ chính xác (báo cáo theo %) trên tập dữ liệu 'True' phân chia dưới các nhiễu không l ật nhãn (True → True). Bảng so sánh độ chính xác bị nhiễu với độ chính xác của tuyên bố gốc không thay đổi (-x biểu thị giảm; +x biểu thị tăng). Các giá trị in đậm cho thấy độ chính xác cao nhất trong từng thiết lập nhiễu, được phân tách theo các mô hình mở và mô hình sở hữu.

Mô hình	Khoảng	Num	Phạm vi
Không cần huấn luyện trước			
Llama3.3-70B	71.76$^{-15.56}$	**86.38**$^{-0.94}$	70.21$^{-17.11}$
DeepSeek-R1	75.29$^{-6.40}$	82.63$^{+0.94}$	67.55$^{-14.14}$
DeepSeek-R1^{T}	**81.44**$^{-6.00}$	84.62$^{-2.82}$	**79.23**$^{-8.20}$
Qwen3	73.53$^{-10.82}$	85.88$^{+1.53}$	62.23$^{-22.12}$
Qwen3-32B^{T}	79.39$^{-6.60}$	85.02$^{-0.97}$	78.24$^{-7.76}$
GPT-4o	68.82$^{-11.18}$	80.28$^{+0.28}$	55.32$^{-24.68}$
GPT-4o-Mini	**81.18**$^{-4.21}$	**92.96**$^{+7.57}$	**79.79**$^{-5.60}$
GPT-5^{T}	75.29$^{-0.86}$	77.00$^{+0.84}$	73.40$^{-2.75}$
GPT-o3^{T}	74.71$^{-1.06}$	77.46$^{+1.70}$	77.66$^{+1.89}$
Gemini 2.5F	60.69$^{-22.00}$	79.81$^{-2.88}$	43.92$^{-38.78}$
Gemini 2.5F^{T}	68.24$^{-3.30}$	71.76$^{+0.22}$	61.70$^{-9.84}$
Cảnh hai nhân vật			
Llama3.3-70B	84.71$^{-6.84}$	90.14$^{-1.41}$	85.64$^{-5.91}$
DeepSeek-R1	**88.82**$^{-0.85}$	**90.61**$^{+0.94}$	**86.70**$^{-2.97}$
DeepSeek-R1^{T}	82.25$^{-4.07}$	87.50$^{+1.18}$	77.13$^{-9.19}$
Qwen3-32B	72.94$^{-6.87}$	81.69$^{+1.88}$	67.02$^{-12.79}$
Qwen3-32B^{T}	81.66$^{-1.83}$	84.43$^{+0.94}$	77.72$^{-5.77}$
GPT-4o	77.06$^{-9.48}$	85.92$^{-0.62}$	63.83$^{-22.71}$
GPT-4o-Mini	**81.18**$^{-8.44}$	**89.67**$^{+0.06}$	**76.06**$^{-13.55}$
GPT-5^{T}	78.82$^{+1.13}$	80.28$^{+2.59}$	73.94$^{-3.76}$
GPT-o3^{T}	75.29$^{-0.48}$	79.34$^{+3.57}$	74.47$^{-1.30}$
Gemini 2.5F	75.88$^{-9.12}$	87.79$^{+2.79}$	70.74$^{-14.26}$
Gemini 2.5F^{T}	74.12$^{-0.11}$	76.53$^{+2.30}$	71.28$^{-2.95}$
PAP			
Qwen3-32B	58.82$^{-14.39}$	72.74$^{-0.47}$	44.41$^{-28.79}$
Qwen3-32B^{T}	**62.13**$^{-15.46}$	**77.60**$^{+0.02}$	**66.94**$^{-10.65}$
Gemini 2.5F	**60.00**$^{-21.92}$	**81.69**$^{-0.23}$	53.19$^{-28.73}$
Gemini 2.5F^{T}	57.65$^{-5.43}$	63.38$^{+0.30}$	**54.79**$^{-8.29}$

Một cách tổng quát, các biến thể suy nghĩ luôn thực hiện kém hơn một chút so với các biến t hể không suy nghĩ của chúng, có thể do hiện tượng "quá suy nghĩ" được định nghĩa bởi (Sui et al., 2025), trong đó các mô hình lý luận tạo ra các chuỗi lý luận dài và phức tạp không cần thiết, cuối cùng làm giảm hiệu quả giải quyết vấn đề – một mô hình được xác nhận bởi phân tích lỗi của chúng tôi (xem Mục 6.1). Trong số các LLM có trọng số mở, hiệu suất mạnh hơn ở zero-shot và two-shot.

các lời nhắc, nhưng khi bao gồm các ví dụ đảo nhãn, Gemini 2.5F vượt trội hơn Qwen3-32B.

Hiệu suất trên các khẳng định sai không bị ảnh hưởng thường cao hơn, phản ánh thực tế rằng các nhiệm vụ kiểm tra sự thật chủ yếu nhắm vào các khẳng định sai. Phù hợp với các quan sát trước đó, các mô hình mở trọng số thể hiện kết quả hơi mạnh hơn so với các mô hình độc quyền. Một phân tích toàn diện được trình bày trong Phụ lục A.2.

5.1.2 Hiệu suất trên các Yêu cầu Bị Thay đổi

Bây giờ chúng tôi tóm tắt sự thay đổi về hiệu suất dưới tác động nhiễu số. Bảng 2 hiển thị sự thay đổi về giá trị độ chính xác bằng chỉ số tr ên màu đỏ hoặc xanh tùy thuộc vào việc độ chính xác giảm hay tăng so với mức cơ sở tương ứng với các tuyên bố gốc chưa bị nhiễu.

Việc che dấu và biến đổi số âm luôn là những thách thức lớn nhất trên các chế độ gợi ý. Việc che dấu mang lại độ chính xác r ất thấp trong thiết lập zero-shot (tối đa 26%), vì các mô hình thường coi các token bị che dấu như các chỗ giữ chỗ và dự đoán True. Với các số âm, độ chính xác thường giảm xuống dưới 20% đối với việc che dấu và 30–50% tổng thể, ngoại trừ Llama 3.3-70B, duy trì 63%; nhiều mô hình bỏ qua số âm như l ỗi chính tả. Việc biến đổi phạm vi và xấp xỉ nâng cao độ chính xác cho Qwen, DeepSeek, GPTs (không bao gồm Mini) và Gemini, cho thấy sự ưu tiên các giá trị xấp xỉ hơn là giá trị chính xác. Việc biến đổi số thứ tự làm giảm hiệu quả các mô hình mở (Qwen3-32B, Llama 3.3-70B) nhưng giúp các hệ thống độc quyền (GPT-5^{T}, GPT-o3^{T}, Gemini 2.5F), phản ánh khả năng xử lý hình thức bề mặt mạnh hơn.

Trong các thiết lập hai bước, xu hướng tương tự như zero-shot được quan sát với hiệu suất tổng thể giảm nhẹ. Ngoại lệ đáng chú ý là DeepSeek-R1, Llama 3.3-70B và Qwen3-32B giảm mạnh về xấp xỉ, trong khi các mô hình suy nghĩ, GPT-5^{T}, GPT-o3^{T}, và Gemini 2.5F^{T}, cải thiện về các nhiễu xấp xỉ.

Đối với phần còn lại của các nhiễu loạn, một xu hướng tương tự như zero-shot đã được quan sát.

Cuối cùng, chúng tôi nhận thấy rằng việc giới thiệu một ví dụ lật nhãn duy nhất cho mỗi loại nhiễu (PAP, được trình bày trong Phụ lục B) cải thiện đáng kể hiệu suất trên tất cả các loại nhiễu. Những cải thiện nổi bật nhất xuất hiện ở các mô hình hướng tới tư duy, vốn thể hiện độ bền cao hơn rất nhiều so với các mô hình không tư duy. Trong trường hợp Neg-Num, các mô hình này không chỉ vượt qua các mức cơ sở của chúng mà còn đạt được những cải thiện mạnh mẽ trên các loại nhiễu như đánh số đơn giản và thay thế theo khoảng. Đáng chú ý, Qwen3-32B phục hồi lên trên 67%, nhấn mạnh hiệu quả của mô hình này trong việc tận dụng các ví dụ nhiễu, mặc dù việc che giấu vẫn là một thách thức dai dẳng đối với Gemini. Đối với Qwen, việc bật biến thể tư duy liên tục củng cố hiệu suất trong hầu hết các trường hợp, trong khi đối với Gemini lợi ích thì không đồng đều—cho thấy cải thiện ở một số loại nhiễu nhưng thay đổi rất ít ở các loại khác.

5.2 Đúng →Đúng

Bảng 3 cho thấy kết quả cho các nhiễu True $\rightarrow$ True. Neg-Num, Rand-Repl và Mask không liên quan khi giữ nguyên nhãn.

Ngoại trừ một vài trường hợp, hầu hết các mô hình gặp khó khăn với các nhiễu Approx và Range, mặc dù mức giảm là khiêm tốn so với thiết lập True $\rightarrow$ False. Điều này gợi ý rằng việc thay thế các giá trị số bằng các giá trị xấp xỉ hoặc khoảng, trong khi vẫn giữ nguyên tính đúng, vẫn có thể khiến các mô hình dự đoán sai thành False. Ngược lại, hiệu suất dưới các nhiễu Num vẫn tương đối ổn định. Không giống như các trường hợp lật nhãn, PAP bị nhiễu không cải thiện hiệu suất; thay vào đó, chúng thường khiến các mô hình nhầm lẫn và phân loại sai các khẳng định True thành False. Thật bất ngờ, GPT-4o-Mini, mặc dù nhỏ hơn, lại hoạt động tốt nhất trong thiết lập này.

6 Thảo luận

RQ1: Trong tất cả các thí nghiệm, không có mô hình nào xuất hiện là mô hình mạnh mẽ nhất một cách toàn cầu, mặc dù các mô hình Gemini 2.5F và Qwen3-32B là gần nhất. Kết quả của chúng tôi cho thấy các mô hình nói chung mạnh mẽ hơn đối với các tuyên bố sai (Bảng 5 và 4) so với các tuyên bố đúng (Bảng 2 và 3). Với các minh họa sai bị perturb, Gemini 2.5F^T đạt được độ chính xác gần như tối đa trên Approx, Range và Rand-Repl, và cho thấy khả năng phục hồi lớn nhất trên Neg-Num; nếu không có sự hiệu chỉnh này, Gemini 2.5F cung cấp sự cân bằng mặc định tốt nhất, liên tục dẫn đầu trên Rand-Repl và Range.

Trong số các hệ thống trọng lượng mở, Qwen3-32B^T là ổn định nhất trên các chế độ và đặc biệt mạnh trên Mask khi được cung cấp các ví dụ bị nhiễu, trong khi Llama 3.3-70B xuất sắc ở zero-shot Neg-Num nhưng trở nên yếu đuối dưới hai lần thử nghiệm. Ngược lại, DeepSeek-R1 là kém ổn định nhất, thể hiện sự suy giảm rõ rệt khi hai lần thử nghiệm trên Approx và Num, cho thấy các hiệu ứng neo có hại.

RQ2: Neg-Num và Mask dường như là những sự biến đổi khó nhất trong tất cả các cài đặt prompt. Với prompt nhận thức sự biến đổi (PAP), có sự phục hồi khiêm tốn và ngay cả như vậy, những cải thiện này phụ thuộc vào mô hình (ví dụ, Gemini 2.5F^T). Các sự biến đổi Rand-Repl và Range là dễ hiểu nhất, liên tục cải thiện độ chính xác trên các mô hình và chế độ prompt. Các sự biến đổi Num và Approx nằm ở mức trung bình: các mô hình "suy nghĩ" như GPT-5^T, GPT-o3^T, và Gemini 2.5F^T thường có lợi từ các sự biến đổi này, trong khi nhiều mô hình cơ bản mở trọng số lại giảm độ chính xác dưới prompt hai-shot, có thể do các ví dụ minh họa với ký hiệu số khác nhau gây nhầm lẫn cho mô hình — điều này cho thấy chúng dựa nhiều hơn vào các dấu hiệu định dạng bề ngoài, khiến chúng nhạy cảm hơn với sự không nhất quán trong biểu diễn số.

RQ3: Trên cả Gemini 2.5F^T và

Qwen3-32B^T, các trường hợp phân loại nhầm thường liên quan đến các đầu vào dài hơn so với các dự đoán chính xác. Đối với Gemini 2.5F^T, các trường hợp phân loại nhầm hiển thị $\sim$15% tổng số token nhiều hơn so với các trường hợp đúng, chủ yếu do sự tăng $\sim$38% số token lý luận (trung bình 877 so với 635). Đối với Qwen, hiệu ứng còn mạnh hơn: các ví dụ bị phân loại nhầm mang $\sim$41% tổng số token nhiều hơn, với độ dài lý luận gần như tăng gấp đôi ($\sim$876 so với 397, tăng $\sim$120%). Các token gợi ý cũng tăng trong các trường hợp phân loại nhầm, mặc dù mức độ khiêm tốn hơn (ví dụ, tăng $\sim$3–10% trên các mô hình). Tổng thể, các phát hiện này cho thấy các mô hình có xu hướng thất bại khi chúng có nhiều token gợi ý và lý luận hơn (suy nghĩ quá mức (Sui et al., 2025)), với chuỗi lý luận mở rộng là một dấu hiệu mạnh của việc phân loại nhầm. Trong khi các gợi ý PAP giới thiệu đầu vào dài hơn tổng thể, chúng cung cấp các minh họa có mục tiêu giúp giảm thiểu những thất bại này bằng cách hướng dẫn các mô hình đi theo một hướng lý luận ổn định hơn. Bảng phân tích chi tiết được trình bày trong Ap-p

6.1 Phân Tích Lỗi

Để hiểu rõ hơn về lỗi của mô hình, chúng tôi phân tích các token suy nghĩ dưới thiết lập $T \rightarrow F$ cho Qwen3-32B ^{T} và Gemini 2.5F ^{T}, tập trung vào các lỗi zero-shot mà có thể khôi phục trong PAP. Phụ lục C, Bảng 10 cho thấy các mẫu cụ thể. Phân tích của chúng tôi tiết lộ các mô hình lập luận sau:

Độ nghiêm ngặt về số liệu: Trong lập luận PAP, các mô hình có xu hướng diễn giải các con số một cách nghiêm ngặt hơn so với trong zero-shot. Ví dụ, một tuyên bố trích dẫn $ 330,000 đối với bằng chứng $300,000 được coi là một sự khác biệt nhỏ trong zero-shot, nh ưng lại là một sự không khớp đáng kể trong PAP, dự đoán Sai.

Che giấu những ngụy biện: Trong bối cảnh zero-shot, các con số bị che thường được coi là chỗ trống, dẫn đến việc mô hình “hoàn thành” tuyên bố từ bằng chứng thay vì xác minh nó. Theo lý luận PAP, mô hình thường xuyên hơn đã đánh dấu các giá trị thiếu là quan trọng, phù hợp với các ví dụ lời nhắc được che đi và từ chối các tuyên bố không thể kiểm chứng. Tuy nhiên, trong một số trường hợp, nó đã bỏ qua việc che đi và đưa ra phán quyết đúng, nhưng vì những lý do không chính xác như giả định sự khác biệt nhỏ trong bằng chứng.

Giải thích lỗi chính tả: Trong bối cảnh perturbation số âm, dưới hình thức zero-shot, các mô hình thường giải thích dấu âm (–) như một lỗi chính tả, xem nó như một dấu gạch ngang bị đặt sai chỗ và loại bỏ nó trong quá trình đánh giá, điều này dẫn đến phân loại sai. Tuy nhiên, dưới sự gợi ý PAP, mô hình đã nhấn mạnh dấu âm như một sự khác biệt quan trọng, xác định chính xác nó là bằng chứng để bác bỏ khẳng định.

Suy nghĩ quá mức: Trong một số trường hợp, các mô hình tạo ra những lập luận phức tạp không cần thiết làm che khuất bằng chứng rõ ràng. Ví dụ, đối với tuyên bố “Trong số /hơn 2 triệu/ cơ hội việc làm được tạo ra, hơn 1 triệu đã được giới trẻ đảm nhận”, bằng chứng rõ ràng cho thấy có 2,5 triệu cơ hội được tạo ra và 1,1 triệu đ ược giới trẻ đảm nhận (45%). Thay vì bác bỏ trực tiếp tuyên bố này, mô hình lại suy đoán về các khoảng thời gian và ngưỡng gần đúng, dẫn đến kết luận sai. Điều này minh họa cách mà việc lập luận quá mức có thể làm lệch các kiểm tra số liệu đơn giản.

7 Kết luận và Công việc Tương lai

Chúng tôi đã giới thiệu một khuôn khổ để làm biến động có hệ thống các tuyên bố số trong các cặp tuyên bố–bằng chứng nhằm đánh giá độ bền vững của các mô hình ngôn ngữ lớn tiên tiến tr ong việc dự đoán tính xác thực. Kết quả của chú ng tôi cho thấy ngay cả các hệ thống hàng đầu cũng gặp phải sự suy giảm hiệu suất đáng kể dưới các chỉnh sửa số được kiểm soát, cung cấp bằng chứng toàn diện đầu tiên rằng độ bền số trong việc kiểm chứng sự thật dài hạn vẫn là một thách thức chưa được giải quyết. Vượt ra ngoài các nghiên cứu trước về biến động văn bản hoặc tấn công đối nghịch, nghiên cứu của chúng tôi mới mẻ trong việc thiết kế các biến động số có ý nghĩa về mặt ngữ nghĩa và chứng minh rằng biến động

gợi ý có nhận thức có thể phục hồi một phần hiệu suất.

Như một bước sơ bộ, công trình này mở ra nhiều hướng: làm nhiễu bên bằng chứng của các cặp luận điểm–bằng chứng, thiết kế các phép kiểm tra tinh vi nhắm vào các luận điểm phụ, và mở rộng khung phân tích sang suy l uận nhiều bước và các tình huống phản thực.

8 Hạn chế

Các thí nghiệm của chúng tôi bị giới hạn bởi việc lựa chọn các mô hình được thử nghiệm. Thêm vào đó, chúng được tiến hành trong một môi trường hộp đen, hạn chế quyền truy cập vào trọng số mô hình, các tham số và các hiểu biết nội bộ khác. Một số tập dữ liệu biến đổi cũng bị hạn chế về kích thước; một mẫu lớn hơn và đa dạng hơn sẽ tăng cường độ bền vững của các phát hiện của chúng tôi. Vì những lý do đã được thảo luận trong các phần trước, các thí nghiệm của chúng tôi tập trung hoàn toàn vào phân loại độ xác thực nhị phân (‘ True’ và ‘False’), bỏ qua các phân loại chi tiết hơn và các biến đổi từ False sang True. Mở rộng phạm vi để bao gồm những khía cạnh này có thể cung cấp một hiểu biết toàn diện hơn về hiệu suất của mô hình trong các điều kiện khác nhau. Cuối cùng, cũng như hầu hết các nhiệm vụ phân loại liên quan đến LLM, có nguy cơ rò rỉ dữ liệu từ dữ liệu huấn luyện, điều này có thể ảnh hưởng đến đánh giá cuối cùng và tác động đến kết quả.

9 Cân nhắc đạo đức

Nghiên cứu của chúng tôi làm nổi bật những điể m mạnh và điểm yếu của các mô hình khác nhau trong việc phân loại tính xác thực nhị phân và phản thực. Trong khi loại nghiên cứu này mang l ại cơ hội quý giá để nâng cao bảo mật và khả năng chống chịu của mô hình, nó cũng đòi hỏi một cách tiếp cận cẩn trọng đối với các mối quan tâm đạo đức. Trong các thí nghiệm của chúng tôi, một số mô hình hoạt động tốt hơn các mô hình khác, nhưng chúng tôi không ủng hộ bất kỳ mô hình cụ thể nào cho các nhiệm vụ kiểm tra thông tin. Tự việc kiểm tra thông tin là một vấn đề tinh vi và phức tạp. Các nhà báo, người kiểm tra thông tin và các nhà nghiên cứu đều có nguy cơ giới thiệu những thiên kiến vào công việc của họ, một mối quan ngại cũng mở rộng đến việc sử dụng LLMs.

Ngoài ra, trong khi mục tiêu của các thí nghiệm của chúng tôi là thu hút sự chú ý nhiều hơn đến hiệu suất của các LLM trong các nhiệm vụ cụ thể, những phát hiện này cũng làm nổi bật các lỗ hổng và khuyến khích việc phát triển các mô hình mạnh mẽ hơn. Tuy nhiên, những kỹ thuật này có tiề m năng đa mục đích và có thể bị khai thác cho các mục đích gây hại nếu sử dụng sai.

Lời cảm ơn

Nghiên cứu này được tài trợ bởi các đối tác SFIMediaFutures và Hội đồng Nghiên cứu Na Uy (mã số tài trợ 309339).

Tài liệu tham khảo

Mubashara Akhtar, Abhilash Shankarampeta, Vivek Gupta, Arpit Patil, Oana Cocarascu, và Elena Simperl. 2023. Khám phá khả năng lý luận số học của các mô hình ngôn ngữ: Phân tích t oàn diện về dữ liệu bảng. Trong Kết quả của Hiệp hội Ngôn ngữ Học Máy Tính: EMNLP 2023, ACL ’23, trang 15391–15405.

Rami Aly, Zhijiang Guo, Michael Sejr Schlichtkrull, James Thorne, Andreas Vlachos, Christos Christodoulopoulos, Oana Cocarascu, và Arpit Mittal. 2021. Feverous: Trích xuất và xác minh sự thật từ thông tin không cấu trúc và có cấu trúc. Trong Hội nghị lần thứ ba mươi lă m về Hệ thống Xử lý Thông tin Thần kinh, Chương trình Dữ liệu và Bộ chuẩn.

Yonatan Belinkov. 2022. Thăm dò bộ phân loại: Những hứa hẹn, thiếu sót và tiến bộ. Ngôn ngữ học tính toán, 48(1):207–219.

Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, và cộng sự. 2020. Các mô hình ngôn ngữ là những người học ít ví dụ. Trong Kỷ yếu Hội nghị Hệ thống Xử lý Thông tin Thần kinh Tiến bộ.

Kejie Chen, Lin Wang, Qinghai Zhang, và Renjun Xu. 2024. Metarulegpt: Lý luận số học đệ quy của các mô hình ngôn ngữ được huấn luyện với các quy tắc đơn giản. Bản in trước arXiv arXiv:2412.13536.

Alphaeus Dmonte, Roland Oruche, Marcos Zampieri, Prasad Calyam, và Isabelle Augenstein. 2024. Xác minh các tuyên bố trong thời đại của các mô hình ngôn ngữ lớn: Một cuộc khảo sát. Bản in trước arXiv arXiv:2408.14317.

Simon Frieder, Luca Pinchetti, Ryan-Rhys Griffiths, Tommaso Salvatori, Thomas Lukasiewicz, Philipp Petersen, và Julius Berner. 2024. Khả năng toán học của chatgpt. Tiến bộ trong hệ thống xử lý thông tin thần kinh, 36.

Zhijiang Guo, Michael Sejr Schlichtkrull, và Andreas Vlachos. 2022. Một khảo sát về kiểm tra sự thật tự động. Transactions of the Association for Computational Linguistics, 10:178–206.

Zhibo Hu, Chen Wang, Yanfeng Shu, Hye-Young Paik, và Liming Zhu. 2024. Nhiễu cảnh báo tro ng các mô hình ngôn ngữ lớn dựa trên tạo sinh tăng cường truy xuất. Trong Kỷ yếu Hội nghị SIGKDD lần thứ 30 của ACM về Khám phá Kiến thức và Khai thác Dữ liệu, trang 1119–1130.

Fanzhen Liu, Alsharif Abuadbba, Kristen Moore, Surya Nepal, Cecile Paris, Jia Wu, Jian Yang, và Quan Z Sheng. 2025. Các cuộc tấn công đối kháng chống lại kiểm tra sự thật tự động: Một khảo sát. bản thảo arXiv arXiv:2509.08463.

Pan Lu, Liang Qiu, Wenhao Yu, Sean Welleck, và Kai-Wei Chang. 2023. Một khảo sát về học sâu cho suy luận toán học. Trong Kỷ yếu của Cuộc họp thường niên lần thứ 61 của Hiệp hội Ngôn ngữ học Máy tính (Tập 1: Bài báo Dài), trang 14605–14631.

Mamta và Oana Cocarascu. 2025. Facteval: Đánh giá độ bền vững của các hệ thống xác minh thông tin trong kỷ nguyên của các mô hình ngôn ngữ lớn. Trong Kỷ yếu Hội nghị 2025 của Chi hội Bắc Mỹ của Hiệp hội Ngôn ngữ Học Máy Tính (NAACL).

Akshay Paruchuri, Jake Garrison, Shun Liao, John B. Hernandez, Jacob Sunshine, Tim Al-thoff, Xin Liu, và Daniel McDuff. 2024. Tỷ lệ là bao nhiêu? các mô hình ngôn ngữ có khả năng suy luận xác suất. Trong Kỷ yếu Hội nghị 2024 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên, các trang 11712–11733, Miami, Florida, Hoa Kỳ. Hiệp hội Ngôn ngữ học Máy tính.

Piotr Przybyła, Alexander Shvets, và Horacio Saggion. 2024. Xác minh độ tin cậy của việc đánh giá tự động. Tạp chí Xử lý Ngôn ngữ Tự nhiên.

Vinay Setty. 2024. Hiệu quả đáng ngạc nhiên của các transformer được tinh chỉnh cho việc kiểm chứng sự thật so với các mô hình ngôn ngữ lớn hơn. Trong Kỷ yếu của Hội nghị Quốc tế ACM SIGIR lần thứ 47 về Nghiên cứu và Phát triển trong Truy xuất Thông tin (SIGIR '24), trang 2842–2846.

Yang Sui, Yu-Neng Chuang, Guanchu Wang, Jiamu Zhang, Tianyi Zhang, Jiayi Yuan, Hongyi Liu, Andrew Wen, Shaochen Zhong, Na Zou, Hanjie Chen và Xia Hu. 2025. Ngừng suy nghĩ quá nhiều: Khảo sát về lý luận hiệu quả cho các mô hình ngôn ngữ lớn. Tiền in, arXiv:2503.16419.

Venktesh V, Abhijit Anand, Avishek Anand, và Vinay Setty. 2024. Quantemp: Một chuẩn thực tiễn thực tế mở cho việc kiểm chứng các tuyên bố số học. Trong Kỷ yếu của Hội nghị Quốc tế ACM SIGIR lần thứ 47 về Nghiên cứu và Phát triển trong Truy xuất Thông tin, Sigir '24, các trang 650–660.

Eric Wallace, Yizhong Wang, Sujian Li, Sameer Singh, và Matt Gardner. 2019. Các mô hình NLP có hiểu số không? Khám phá khả năng số học trong các embedding. Trong Kỷ yếu Hội nghị 2019 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên và Hội nghị Liên hợp Quốc t ế lần thứ 9 về Xử lý Ngôn ngữ Tự nhiên (EMNLP-IJCNLP), trang 5307–5315, Hồng Kông, Trung Quốc. Hiệp hội Ngôn ngữ Học Máy tính.

Jonas Wallat, Adam Jatowt, và Avishek Anand. 2024. Các điểm mù về thời gian trong các mô hình ngôn ngữ lớn. Trong Kỷ yếu của Hội nghị Quốc tế ACM lần thứ 17 về Tìm kiếm Web và Khai thác Dữ liệu, WSDM '24, trang 683–692.

Jialiang Xu, Mengyu Zhou, Xinyi He, Shi Han, và Dongmei Zhang. 2022. Hướng tới Trả lời Câu hỏi Số liệu Mạnh mẽ: Chẩn đoán Khả năng Xử lý Số liệu của các Hệ thống NLP. Trong Kỷ yếu hội nghị năm 2022 về các phương pháp thực nghiệm trong xử lý ngôn ngữ tự nhiên, EMNLP '22, trang 7950–7966.

Haotong Yang, Yi Hu, Shijia Kang, Zhouchen Li n, và Muhan Zhang. 2024. Sách nấu số: Hiểu số của các mô hình ngôn ngữ và cách cải thiện nó. Bản in trước arXiv arXiv:2411.03766.

Wei Zhou, Mohsen Mesgar, Heike Adel, và Annemarie Friedrich. 2024. Freb-tqa: Một chuẩn đánh giá độ bền chi tiết cho trả lời câu hỏi bảng. Trong Kỷ yếu Hội nghị 2024 của Chương Bắc Mỹ thuộc Hiệp hội Ngôn ngữ học Máy tính: Cô ng nghệ Ngôn ngữ Con người (Tập 1: Bài báo dài), các trang 2479–2497.

Phụ lục A

Phụ lục bao gồm các chi tiết bổ sung về các phương pháp nhiễu đã sử dụng, tóm tắt đánh giá False → False, và tài liệu bằng chứng cũng như đánh giá cho các ví dụ hai lần thử.

A.1 Chi tiết sự nhiễu

Phần này cung cấp mô tả ngắn gọn về các chi tiết bổ sung liên quan đến các phương pháp nhiễu loạn. Để biết chi tiết đầy đủ về kịch bản, hãy tham khảo kho lưu trữ GitHub[3].

A.1.1 Đánh số

Đối với các số không nên khớp với giá trị số gốc trong yêu cầu chưa bị thay đổi, giá trị được tăng thêm 10%, sau đó được chuyển t ừ chữ số sang chữ viết.

A.1.2 Xấp xỉ

Mỗi loại áp dụng làm tròn theo ngữ cảnh cụ thể để tạo ra các xấp xỉ trong cuộc trò chuyện và thêm “khoảng” như một tiền tố xấp xỉ. Nếu tất cả các số, nếu nhỏ hơn 10 và là số thập phân, số đó sẽ được làm tròn đến 0,5 gần nhất.

• Số chính: Làm tròn đến chục, trăm, nghìn hoặc trăm nghìn dựa trên độ lớn.

• Phần trăm: Làm tròn đến hàng trăm của tensor, giữ nguyên giá trị chính xác cho các phần trăm nhỏ.

• Tiền: Tương tự như Số đếm — với ký hiệu tiền tệ và giữ nguyên chi tiết thập phân cho các khoản nhỏ.

• Ngày: Làm tròn đến thập kỷ gần nhất.

• Thời gian: Làm tròn đến chục hoặc trăm tùy thuộc vào độ lớn.

Đối với các đầu dò lật nhãn, giá trị số ban đầu được nhân ngẫu nhiên với các hệ số 0,5, 0,6, 1,4 hoặc 1,5, sau đó được làm tròn như đã mô tả ở trên.

[3] https://github.com/iai-group/tấn công_gây nhiễu_số liệu_khẳng định/

Bảng 4: Hiệu suất độ chính xác cho lớp 'Sai', trong tập dữ liệu phân tách 'Sai' với các nhiễu, nơi các giá trị số đã được điều chỉnh để giữ gần giống với tuyên bố sai ban đầu trong khi vẫn giữ nhãn, tức là, Sai → Sai (-x biểu thị giảm; +x biểu thị tăng). Các giá trị in đậm thể hiện độ chính xác cao nhất trong t ừng thiết lập nhiễu, được phân tách theo mô hình mở và mô hình sở hữu riêng.

Mô hình	Nguyên bản	Khoảng	Num	Phạm vi
		Một lần		
Llama 3.2-1B	5.71	5.45$^{-0.27}$	6.53$^{+0.82}$	6.81$^{+1.10}$
Llama 3.3-70B	93.67	94.06$^{+0.39}$	93.47$^{-0.20}$	92.21$^{-1.46}$
Mistral-7B	96.53	95.79$^{-0.74}$	96.33$^{-0.20}$	95.62$^{-0.91}$
DeepSeek-R1	**97.14**	**97.28**$^{+0.13}$	**96.94**$^{-0.20}$	96.84$^{-0.31}$
DeepSeek-R1^{T}	95.86	95.56$^{-0.31}$	96.13$^{+0.27}$	94.56$^{-1.30}$
Qwen3-32B	96.12	96.29$^{+0.16}$	96.12	**97.32**$^{+1.20}$
Qwen3-32B^{T}	95.92	94.99$^{-0.93}$	95.90$^{-0.01}$	95.15$^{-0.76}$
GPT-4o	**96.52**	**97.28**$^{+0.75}$	**97.14**$^{+0.62}$	**97.08**$^{+0.56}$
GPT-4o-Mini	93.05	93.32$^{+0.27}$	92.45$^{-0.60}$	93.19$^{+0.14}$
GPT-5	95.20	95.05$^{-0.15}$	96.12$^{+0.92}$	95.13$^{-0.06}$
GPT-o3	95.36	94.06$^{-1.30}$	95.92$^{+0.55}$	94.40$^{-0.96}$
Gemini 2.5F	93.21	95.05$^{+1.84}$	93.88$^{+0.67}$	96.11$^{+2.90}$
Gemini 2.5F^{T}	92.05	90.84$^{-1.21}$	90.69$^{-1.36}$	90.02$^{-2.03}$
		Cảnh hai nhân vật		
Llama 3.2-1B	10.00	6.93$^{-3.07}$	10.20$^{+0.20}$	9.73$^{-0.27}$
Llama 3.3-70B	95.92	96.04$^{+0.12}$	95.51$^{-0.41}$	93.19$^{-2.73}$
Mistral-7B	87.76	88.12$^{+0.36}$	88.78$^{+1.02}$	87.10$^{-0.65}$
DeepSeek-R1	95.92	95.79$^{-0.13}$	95.71$^{-0.20}$	96.84$^{+0.92}$
DeepSeek-R1^{T}	96.07	95.73$^{-0.34}$	96.27$^{+0.20}$	94.35$^{-1.72}$
Qwen3-32B	**97.76**	**97.28**$^{-0.48}$	**97.76**	**97.32**$^{-0.43}$
Qwen3-32B^{T}	95.91	96.04$^{+0.13}$	96.33$^{+0.42}$	94.88$^{-1.03}$
GPT-4o	**96.36**	**97.28**$^{+0.92}$	**96.12**$^{-0.24}$	**97.32**$^{+0.97}$
GPT-4o-Mini	92.38	95.79$^{+3.41}$	93.88$^{+1.49}$	95.38$^{+2.99}$
GPT-5	95.20	94.55$^{-0.64}$	96.12$^{+0.92}$	95.13$^{-0.06}$
GPT-o3	94.87	94.55$^{-0.31}$	95.10$^{+0.23}$	94.89$^{+0.02}$
Gemini 2.5F	92.72	95.54$^{+2.83}$	94.49$^{+1.77}$	95.62$^{+2.91}$
Gemini 2.5F^{T}	92.38	91.58$^{-0.80}$	94.08$^{+1.70}$	90.27$^{-2.12}$
		PAP		
Qwen3-32B	96.12	**96.78**$^{+0.66}$	**96.53**$^{+0.41}$	**97.20**$^{+1.08}$
Qwen3-32B^{T}	**96.72**	96.40$^{-0.32}$	96.39$^{-0.33}$	95.84$^{-0.89}$
Gemini 2.5F	92.88	**95.30**$^{+2.42}$	92.24$^{-0.64}$	**95.13**$^{+2.25}$
Gemini 2.5F^{T}	**93.54**	90.84$^{-2.70}$	**92.65**$^{-0.89}$	90.02$^{-3.52}$

A.1.3 Phạm vi

Trong cài đặt nhiễu phạm vi, khi các giá trị số nên nằm trong phạm vi của giá trị gốc, chúng tôi làm nhiễu số theo $\pm 10\%$ ở ranh giới dưới. Đối với giá trị thứ tự, chúng tôi tr ừ và cộng 1 vào giá trị gốc để tạo giới hạn phạm vi.

Trong những trường hợp nhãn bị đảo lộn, phạm vi số sẽ nằm ngoài phạm vi của số gốc.

Bảng 5: Hiệu suất độ chính xác cho lớp False, trong tập dữ liệu 'False' được chia cùng với các nhiễu, nơi các giá trị số đã được chỉnh sửa để khác với tuyên bố sai ban đầu trong khi vẫn giữ nguyên nhãn, tức là False → False (-x cho thấy giảm; +x cho thấy tăng). Các giá trị in đậm biểu thị độ chính xác cao nhất trong mỗi cài đặt nhiễu, được phân tách theo mô hình open-weight và mô hình độc quyền.

Mô hình	Nguyên bản	Khoảng	Số âm	Num	Rand-repl	Phạm vi	Mask
			Không cần huấn luyện trước				
Llama2-1B	5.71	5.45$^{-0.27}$	5.62$^{-0.10}$	6.33$^{+0.61}$	4.90$^{-0.82}$	5.35$^{-0.36}$	5.92$^{+0.20}$
Llama3.3-70B	93.67	96.53$^{+2.86}$	93.26$^{-0.42}$	96.12$^{+2.45}$	96.73$^{+3.06}$	95.62$^{+1.95}$	92.86$^{-0.82}$
Mistral-7B	96.53	97.28$^{+0.75}$	95.51$^{-1.02}$	96.33$^{-0.20}$	96.73$^{+0.20}$	96.35$^{-0.18}$	95.31$^{-1.22}$
DeepSeek-R1	**97.14**	**98.51**$^{+1.37}$	**96.63**$^{-0.51}$	97.96$^{+0.82}$	**98.16**$^{+1.02}$	**98.30**$^{+1.15}$	**97.55**$^{+0.41}$
DeepSeek-R1^{T}	95.86	96.57$^{+0.71}$	91.57$^{-4.30}$	97.42$^{+1.56}$	97.61$^{+1.75}$	97.44$^{+1.58}$	93.74$^{-2.13}$
Qwen3-32B	96.12	98.27$^{+2.14}$	95.51$^{-0.62}$	97.96$^{+1.84}$	97.96$^{+1.84}$	98.30$^{+2.17}$	95.31$^{-0.82}$
Qwen3-32B^{T}	95.92	96.74$^{+0.83}$	94.32$^{-1.60}$	**98.22**$^{+2.30}$	97.74$^{+1.82}$	98.03$^{+2.11}$	94.01$^{-1.91}$
GPT-4o	**96.52**	**97.77**$^{+1.25}$	**96.63**$^{+0.11}$	**98.16**$^{+1.64}$	**98.16**$^{+1.64}$	**97.81**$^{+1.29}$	**96.53**$^{+0.01}$
GPT-4o-Mini	93.05	96.04$^{+2.99}$	92.13$^{-0.91}$	95.71$^{+2.67}$	95.92$^{+2.87}$	96.84$^{+3.79}$	93.27$^{+0.22}$
GPT-5	95.20	96.29$^{+1.09}$	91.01$^{-4.19}$	97.55$^{+2.35}$	97.35$^{+2.15}$	96.84$^{+1.64}$	95.51$^{+0.31}$
GPT-o3	95.36	96.04$^{+0.68}$	91.01$^{-4.35}$	96.94$^{+1.57}$	96.94$^{+1.57}$	96.84$^{+1.47}$	95.51$^{+0.15}$
Gemini 2.5F	93.21	97.28$^{+4.07}$	94.38$^{+1.17}$	96.94$^{+3.73}$	97.96$^{+4.75}$	97.08$^{+3.87}$	93.88$^{+0.67}$
Gemini 2.5F^{T}	92.05	93.30$^{+1.25}$	87.64$^{-4.41}$	95.31$^{+3.25}$	94.90$^{+2.84}$	96.09$^{+4.04}$	88.98$^{-3.07}$
			2-S				
Llama2-1B	10.00	7.92$^{-2.08}$	7.87$^{-2.13}$	7.76$^{-2.24}$	9.18$^{-0.82}$	9.25$^{-0.75}$	7.76$^{-2.24}$
Llama3.3-70B	95.92	97.52$^{+1.61}$	95.51$^{-0.41}$	96.73$^{+0.82}$	97.87$^{+1.95}$	95.38$^{-0.54}$	95.10$^{-0.82}$
Mistral-7B	87.76	87.38$^{-0.38}$	87.64$^{-0.11}$	88.57$^{+0.82}$	88.78$^{+1.02}$	87.35$^{-0.41}$	87.35$^{-0.41}$
DeepSeek-R1	95.92	98.27$^{+2.35}$	93.26$^{-2.66}$	96.73$^{+0.82}$	85.26$^{-10.66}$	98.05$^{+2.14}$	95.51$^{-0.41}$
DeepSeek-R1^{T}	96.07	96.50$^{+0.43}$	94.25$^{-1.81}$	97.32$^{+1.25}$	96.79$^{+0.73}$	98.03$^{+1.97}$	94.61$^{-1.46}$
Qwen3-32B	**97.76**	**99.01**$^{+1.25}$	**97.75**$^{-0.00}$	**98.98**$^{+1.22}$	**98.93**$^{+1.18}$	**98.54**$^{+0.79}$	**97.55**$^{-0.20}$
Qwen3-32B^{T}	95.91	97.52$^{+1.61}$	94.38$^{-1.53}$	97.96$^{+2.05}$	98.04$^{+2.13}$	97.57$^{+1.66}$	96.11$^{+0.20}$
GPT-4o	**96.36**	**98.51**$^{+2.16}$	**98.88**$^{+2.52}$	**97.55**$^{+1.19}$	**97.96**$^{+1.60}$	**98.05**$^{+1.70}$	95.51$^{-0.85}$
GPT-4o-Mini	92.38	96.29$^{+3.90}$	94.38$^{+2.00}$	95.92$^{+3.53}$	96.94$^{+4.55}$	97.08$^{+4.70}$	95.31$^{+2.92}$
GPT-5	95.20	96.04$^{+0.84}$	92.13$^{-3.06}$	97.55$^{+2.35}$	97.35$^{+2.15}$	97.08$^{+1.88}$	**96.12**$^{+0.92}$
GPT-o3	94.87	96.53$^{+1.67}$	91.01$^{-3.86}$	97.35$^{+2.48}$	96.94$^{+2.07}$	97.08$^{+2.21}$	95.31$^{+0.44}$
Gemini 2.5F	92.72	97.03$^{+4.31}$	95.51$^{+2.79}$	96.94$^{+4.22}$	96.73$^{+4.02}$	96.36$^{+3.64}$	93.88$^{+1.16}$
Gemini 2.5F^{T}	92.38	94.31$^{+1.92}$	89.89$^{-2.50}$	95.94$^{+3.56}$	96.13$^{+3.75}$	96.11$^{+3.72}$	90.82$^{-1.57}$
			PAP				
Qwen3-32B	95.10	**98.51**$^{+3.41}$	**95.51**$^{+0.40}$	98.16$^{+3.06}$	98.57$^{+3.47}$	98.54$^{+3.44}$	**97.55**$^{+2.45}$
Qwen3-32B^{T}	**97.13**	97.77$^{+0.65}$	95.51$^{-1.62}$	**98.98**$^{+1.85}$	**98.57**$^{+1.44}$	**98.54**$^{+1.41}$	95.88$^{-1.25}$
Gemini 2.5F	92.88	**97.52**$^{+4.64}$	**96.63**$^{+3.75}$	**97.14**$^{+4.26}$	**98.16**$^{+5.28}$	**97.81**$^{+4.93}$	**94.29**$^{+1.40}$
Gemini 2.5F^{T}	**93.54**	94.31$^{+0.76}$	92.13$^{-1.41}$	96.94$^{+3.40}$	96.94$^{+3.40}$	95.62$^{+2.08}$	89.39$^{-4.16}$

A.2 Tóm tắt Hành vi Mô hình Dưới Sự Nhiễu Số học cho Phân tách Dữ liệu Sai (Sai → Sai)

Bảng 5 trình bày các nhiễu → Sai, nơi các giá trị số được chỉnh sửa trong khi vẫn giữ nhãn sai. Các thí nghiệm của chúng tôi tiết lộ rằng các mô hình lớn (ví dụ, GPT-4o, GPT-4o-Mini, Gemini 2.5F) và DeepSeek-R1^{T} với trọng lượng mở duy trì độ bền cao trước các biến động, với độ chính xác thường trên 90%. Các mô hình nhỏ hơn như Llama 3.2-1B và Mistral-7B giảm mạnh, đặc biệt dưới các điều kiện Approx và Range. Qwen3-32B^{T} hoạt động ổn định trên nhiều lần thử, cạnh tranh với các hệ thống độc quyền. Những bất thường đáng chú ý bao gồm Gemini

Ví dụ 1	Ví dụ 2
Yêu cầu: Khi các chính trị gia Cộng hòa cố gắng bãi bỏ Đạo luật Chăm sóc Giá cả phải chăng Luật Chăm sóc, họ nên được nhắc nhở mỗi ngày mà 36.000 người sẽ chết hàng năm như một kết quả .	**Yêu cầu:** Chúng tôi thấy một phần tư tỷ đô la trong quỹ hưu trí quỹ cần được cấp vốn với 1,2 tỷ đô la.
Bằng chứng: *Chia sẻ bài viết quà tặng* "Khi các nghị sĩ Cộng hòa cố gắng bãi bỏ Đạo luật Chăm sóc Sức khỏe Hợp túi tiền (Affordable)" Đạo luật Chăm sóc Khả năng, họ nên được nhắc nhở Mỗi ngày sẽ có 36.000 người chết hàng năm vì **một kết quả." — Thượng nghị sĩ Bernie Sanders (D-Vt.),** trong một tweet, ngày 12 t háng 1 năm 2017.	**Bằng chứng:** Thị trưởng Providence Angel Taveras đã phải đối phó với gần như phá sản ở thủ đô sau khi ông nhậm chức vào năm 2011. Như thành phố đã gặp khó khăn trong việc giải quyết các vấn đề ngân sách của mình, ông đã chiến thắng nhượng bộ của công đoàn để giảm chi phí lương hưu. Các số liệu gần đây nhất cho thấy kế hoạch là **chỉ được cấp vốn 31,4 phần trăm.**
Đánh giá: Sai	**Đánh giá: Đúng**

Bảng 6: Ví dụ đúng và sai về các khẳng định và nhãn của chúng dựa trên bằng chứng được sử dụng trong lời nhắc.

2.5F giảm khoảng (-5 đến -6 điểm) mặc dù hiệu suất tổng thể mạnh, và GPT-4o-Mini có những tăng bất ngờ trong thử nghiệm hai cú ($+3$ điểm). Các biến thể có khả năng suy luận (^{T}) nói chung cải thiện độ ổn định, mặc dù biến t hể tư duy của Gemini vẫn biến động hơn.

Bảng 4 báo cáo chỉ số độ chính xác cho lớp False trong phân tách bộ dữ liệu False với các nhiễu. Các nhiễu làm thay đổi đáng kể các giá trị số trong khi vẫn giữ nguyên nhãn (False $\rightarrow$ False). Kết quả được trình bày cho nhiều mô hình ngôn ngữ lớn (LLM) bao gồm Llama, Mistral, DeepSeek, GPT, Gemini và Qwen qua ba thiết lập đánh giá: Zero-shot, two-shot và Perturbation-Aware Prompt (PAP). Các cột cho biết các loại nhiễu khác nhau: Original (cơ sở), Approx, Neg-num, Num, Rand-repl, Range và Mask. Các chỉ số mũ với giá trị âm biểu thị sự giả m so với cơ sở, và giá trị dương biểu thị sự cải thiện.

Trong bối cảnh zero-shot, DeepSeek-R1, GPT-4o và Qwen3-32B^T đạt được hiệu suất cao nhất và ổn định nhất, duy trì độ chính xác trong khoảng từ 96% đến 98% trên các biến đổi tions. Gemini 2.5F cũng ổn định với điểm số nằm trong khoảng 93% đến 97%. Ngược lại, các mô hình nhỏ hơn như Llama 3.2-1B hoạt động kém với độ chính xác khoảng 5–6 %. Các mô hình cỡ trung như Llama 3.3-70B và Mistral-7B hoạt động tốt nhưng vẫn hơi thấp hơn các mô hình tiên tiến nhất.

Trong cài đặt hai lần thử, độ chính xác cải thiện nhẹ so với Zero-shot, đặc biệt là đối với các mô hình nhỏ hơn. DeepSeek-R1 vẫn mạnh với điểm số khoảng 96–97%, GPT-4o đạt 95–98%, Qwen3-32B^T đạt 94–98%, và Gemini 2.5F^T duy trì ổn định với 90–96%. Tuy nhiên, Llama 3.2-1B tiếp tục hoạt động kém với độ chính xác chỉ từ 7% đến 10%.

Lời nhắc Nhận thức Rối loạn (PAP) mang lại độ chính xác tổng thể cao nhất. Qwen3-32B^T và DeepSeek-R1^T đạt từ 95–99% trên tất cả các rối loạn, trong khi Gemini 2.5F^T cũng thể hiện hiệu suất mạnh với độ chính xác từ 89% đến 97%. PAP liên tục cải thiện các mô hình vốn đã mạnh khoảng 1–2 điểm phần trăm so với phương pháp zero-shot và two-shot.

Nói chung, tỷ lệ mô hình là rất quan trọng. Nhỏ

Các mô hình như Llama 3.2-1B thất bại dưới đánh giá này, trong khi các mô hình quy mô lớn và tiên tiến như DeepSeek, GPT-4o, Qwen và Gemini hoạt động gần mức tối đa. Việc đưa ra lệnh với hai ví dụ tăng sự ổn định ở hầu hết các mô hình, và PAP được chứng minh là phương pháp bền vững nhất, mang lại kết quả tốt nhất và nhất quán nhất tổng thể.

Lời nhắc B

Đối với các LLM, chúng tôi sử dụng cùng một hướng dẫn và ví dụ hai lần thử. Zero-shot chỉ bao gồm hướng dẫn, trong khi hai-shot bao gồm hướng dẫn và dữ liệu mẫu. Hai ví dụ hai-shot sau đây là các đoạn trích của các ví dụ đã sử dụng. Để xem toàn bộ lời nhắc, vui lòng tham khảo kho lưu trữ GitHub của chúng tôi.

B.1 Lời nhắc Hệ thống

Câu lệnh sau đây đã được sử dụng làm câu lệnh hệ thống của mô hình:

Bạn là một chuyên gia kiểm tra sự thật, nhiệm vụ của bạn là phân loại xem tuyên bố được đưa ra là đúng hay sai dựa trên văn bản bằng chứng được cung cấp.

B.2 Hướng dẫn

Lời nhắc sau đây đã được sử dụng cùng với hai ví dụ từ Bảng 6:

Dựa trên tuyên bố và bằng chứng được cung cấp, phân loại tuyên bố là "label": true nếu nó đúng, và "label": false nếu nó sai.

B.3 Ví dụ hai lần thử

Bảng 6 trình bày hai ví dụ về kiểm tra sự thật của các tuyên bố được sử dụng trong lời nhắc cho LLM cùng với bằng chứng tương ứng và đánh giá tính xác thực. Hai ví dụ này được sử dụng cho tất cả các LLM và tất cả các đầu vào biến đổi để đảm bảo tính nhất quán. Và mỗi trong hai ví dụ này đại diện cho hai nhãn khác nhau trong bộ dữ liệu.

B.4 Lời nhắc Nhận thức Nhiễu loạn

Lời nhắc sau đây đã được thêm vào lời nhắc hướng dẫn cho các thí nghiệm ví dụ tiêu cực:

Các con số trong bằng chứng có thể không khớp với tuyên bố. Ví dụ:

Khẳng định: Tháp Eiffel cao ba trăm năm mươi mốt mét. Bằng chứng: Tháp Eiffel cao 330 mét. "nhãn": sai

Yêu cầu: Tỷ lệ lạm phát hàng năm của Hoa Kỳ vào cuối năm 2024 là -2,9%. Bằng chứng: Tỷ lệ lạm phát hàng năm của Hoa Kỳ vào cuối năm 2024 là 2,9. "nhãn": sai

Khẳng định: Tỷ lệ sinh ở Nhật Bản vào nă m 2023 là từ 2 đến 2,5. Bằng chứng: Tỷ lệ sinh ở Nhật Bản vào năm 2023 là 1,2. "nhãn": sai

Khẳng định: Dân số Canada vào năm 2023 khoảng 45 triệu. Bằng chứng: Dân số Canada vào năm 2023 là 40,5 triệu vào tháng 10 năm 2023. "nhãn": sai

Khẳng định: Sao Thổ có 789 vệ tinh. Bằng chứng: Các phát hiện đưa tổng số vệ tinh của Sao Thổ lên 274, gần gấp ba so với Sao Mộc và nhiều hơn tổng số vệ tinh đã biết quanh các hành tinh khác. "nhãn": sai

Khẳng định: Sân vận động Wembley ở London có sức chứa ###### chỗ ngồi. Bằng chứng: Sân vận động Wembley ở London có sức chứa 90.000 chỗ ngồi. "nhãn": sai

B.5 Phân tích độ dài câu lệnh

Chúng tôi thực hiện phân tích độ dài prompt đối với các trường hợp bị phân loại sai so với các phân loại đúng cho hai mô hình ổn định nhất – Gemini 2.5F^T và Qwen3-32B^T.

Gemini 2.5F^T Trong các trường hợp bị phân loại sai, Gemini 2.5-Flash có xu hướng có độ dài token lí giải tổng thể dài hơn, với độ dài token trung bình tổng tăng 15% so với các dự đoán đúng (2103 so với 1822 token). Token gợi ý chỉ cho thấy sự khác biệt khiê m tốn (+3%). Phân bố này còn gợi ý rằng

Sự nhiễu loạn	Mã thông báo nhắc		Mã Lý luận	
	Phân loại sai	Đúng	Phân loại sai	Đúng
Sự xấp xỉ	2158.7	1303.9	1265.1	371.2
Số âm	1214.5	1073.2	846.5	339.0
Sự đánh số	1648.2	1239.6	796.1	378.4
Thay thế ngẫu nhiên	1576.4	1323.8	713.2	363.8
Phạm vi	1963.4	1315.1	698.4	401.1
Che mặt	1234.7	1017.8	717.1	427.7

Bảng 7: So sánh độ dài trung bình của token gợi ý và token lý luận cho Qwen3-32B^T giữa các phân loại sai và phân loại đúng trong thiết lập Zero-shot.

các lỗi liên quan đến các chuỗi suy luận dài hơn và biến đổi hơn (độ dài suy luận tối đa trên 6k token), trong khi các dự đoán chính xác được thực hiện với suy luận gọn hơn. Nói cách khác, việc phân loại sai có mối liên hệ chặt chẽ với việc suy nghĩ quá mức.

Qwen3-32B^T Đối với Qwen3-32B^T, các trường hợp phân loại sai thường cho thấy độ dài lập luận bị thổi phồng so với các trường hợp phân loại đúng trong chế độ Zero-shot (Bảng 7). Ví dụ, số lượng token lập luận gần như tăng gấp ba lần trong Approx (1265 so với 371) và hơn gấp đôi trong Num (796 so với 378) và Range (698 so với 401). Độ dài prompt cũng luôn cao hơn đối với các trường hợp phân loại sai, với khoảng cách rõ rệt nhất trong Approx, nơi các prompt mở rộng hơn 65% (2159 so với 1304). Ngoại lệ xảy ra với Mask, nơi độ dài lập luận vẫn cao ngay cả trong các trường hợp phân loại sai (717 so với 428), cho thấy rằng các đầu vào bị ẩn (masked) kích thích sự trình bày dài hơn bất kể đúng hay sai. Nhìn chung, Qwen3-32B^T có xu hướng suy nghĩ quá mức khi phân loại sai, trong khi các dự đoán đúng được đặc trưng bởi chuỗi lập luận ngắn hơn, hiệu quả hơn và các prompt gọn gàng hơn. Tất cả độ dài token cho Qwen3-32B^T trong chế độ zero-shot được trình bày trong Bảng 7.

Phân tích Kết quả Không hợp lệ C

Như được trình bày trong Bảng 8, trong các mô hình t rọng lượng mở, các kết quả đầu ra không hợp lệ hầu như không xuất hiện

Mô hình	Tổng số trường hợp	Không hợp lệ	% Không hợp lệ
	Không cần huấn luyện trước		
DeepSeek-R1:32B	8841	0	0.00
DeepSeek-R1:32B^T	6837	477	6.98
LLaMA-3.2 1B-Hướng dẫn	6837	0	0.00
LLaMA-3.3 70B	6837	0	0.00
Mistral-7B	6837	0	0.00
Qwen-3 32B	7041	0	0.00
Qwen-3 32B^T	6553	165	2.52
	Cảnh hai nhân vật		
DeepSeek-R1:32B	6951	0	0.00
DeepSeek-R1:32B^T	6951	78	1.12
LLaMA-3.2 1B-Hướng dẫn	6837	0	0.00
LLaMA-3.3 70B	6951	0	0.00
Mistral-7B	6837	0	0.00
Qwen-3 32B	6951	0	0.00
Qwen-3 32B^T	6951	23	0.33
	PAP		
DeepSeek-R1:32B	6837	0	0.00
DeepSeek-R1:32B^T	6837	92	1.35
LLaMA-3.2 1B-Hướng dẫn	6837	0	0.00
LLaMA-3.3 70B	6837	0	0.00
Mistral-7B	6837	0	0.00
Qwen-3 32B	6837	0	0.00
Qwen-3 32B^T	6837	55	0.80

Bảng 8: Các kết quả không hợp lệ trên các mô hình trọng lượng mở, được nhóm theo cài đặt số lần bắn. Các biến thể tăng cường tư duy được đánh dấu bằng ^{T}. Tỷ lệ phần trăm được tính là không hợp lệ / tổng $\times 100$.

Trong các biến thể không suy nghĩ: Llama 3.3-70B, Llama-3.2 1B instruct, Mistral-7B, Qwen3-32B, và DeepSeek-R1 luôn tạo ra 0,00% khả năng không hợp lệ ở tất cả các thiết lập shot. Ngược lại, việc kích hoạt suy nghĩ gây ra sự không ổn định. Chẳng hạn, DeepSeek-R1^T cho thấy sự tăng mạnh các kết quả không hợp lệ ở zero-shot (6,98%), giảm xuống ở two-shot (1,12%) và PAP (1,35%), cho thấy có một sự phục hồi nào đó khi có ví dụ. Tương tự, Qwen3-

Mô hình	Tổng số trường hợp	Không hợp lệ	% Không hợp lệ
	Không cần huấn luyện trước		
GPT-4o	5298	0	0.00
GPT-4o-mini	5298	0	0.00
GPT-5	5298	0	0.00
GPT-o3	5298	1	0.02
Gemini-2.5^{T}	5295	174	3.29
Gemini-2.5	5298	1	0.02
	Cảnh hai nhân vật		
GPT-4o	5298	0	0.00
GPT-4o-mini	5298	0	0.00
GPT-5	5298	0	0.00
GPT-o3	5298	2	0.04
Gemini-2.5^{T}	5298	82	1.55
Gemini-2.5	5298	42	0.79
	PAP		
Gemini-2.5^{T}	5298	231	4.36
Gemini-2.5	5298	0	0.00

Bảng 9: Kết quả không hợp lệ trên các mô hình độc quyền và các biến thể của Gemini, được nhóm theo cài đặt số lần thử. Phần trăm được tính bằng invalid/total $\times$ 100.

32B^{T} cho ra 2,52% lỗi trong chế độ zero-shot, giảm xuống 0,33% trong chế độ two-shot, nhưng lại tăng lên khoảng 0,80–1,33% với các lời nhắc nhận thức nhiễu.

Những phát hiện này tiết lộ một mô hình rõ ràng: trong khi các mô hình trọng số mở mà không có khả năng suy luận vẫn giữ vững trước các kết quả không hợp lệ, các mô hình có khả năng suy luận tương ứng của chúng thường dễ mắc lỗi hơn. Chế độ không cần huấn luyện trước l à không ổn định nhất, chế độ hai bước mang lại hiệu ứng ổn định, và PAP cho thấy kết quả đa dạng tùy thuộc vào mô hình.

Như được thể hiện trong Bảng 9, đối với các hệ thống độc quyền, các kết quả đầu ra không hợp lệ là cực kỳ hiếm ngoại trừ trong dòng Gemini. GPT-4o, GPT-4o-Mini, GPT-5^{T}, và GPT-o3^{T} duy trì độ bền gần như hoàn hảo trên tất cả các thiết lập shot, với tỷ lệ không hợp lệ từ 0,00–0,04%. Ngược lại, Gemini 2.5F cho thấy mức độ nhạy cảm cao hơn với các kết quả tạo ra không hợp lệ. Cụ thể, Gemini 2.5F^{T} đạt 3,29% không hợp lệ ở zero-shot, cải thiện xuống 1,55% với hiệu chỉnh hai-shot, nhưng lại tăng lên 4,36 % theo PAP. Phiên bản không suy nghĩ của nó ổn định hơn nhiều, duy trì dưới 1% không hợp lệ trong tất cả các trường hợp.

Nhìn chung, các mô hình độc quyền không có khả năng lý luận (gia đình GPT và Gemini 2.5F) cực kỳ ổn định, trong khi các biến thể của Gemini có khả năng lý luận lại gặp tỷ lệ không hợp lệ cao hơn đáng kể, đặc biệt trong các thiết lập zero-shot và PAP.

Đúng → Sai Bối rối **Yêu cầu**	**Các đoạn trích kết quả lập luận**	**Tóm tắt phân tích**
Các văn phòng khác nhau của chính phủ bang có mua nhiều hơn $########## trong phương tiện giao thông, không tính hợp đồng thuê, cho sử dụng từ Thống đốc trở đi xuống trong hai cái cuối cùng năm.	Gemini 2.5F^{T} zero-shot: “(...)Trong khi đòi hỏi sử dụng một chỗ giữ chỗ, cái bằng chứng chứng minh 'hơn 11 triệu đô la tính toán với độ chính xác. Tôi sẽ đánh dấu tuyên bố này là đúng. Gemini 2.5F^{T} PAP:“(...)Tôi bây giờ chắc chắn rằng tuyên bố đó là sai. The sự nhấn mạnh của hướng dẫn về chỗ giữ chỗ tạo điều kiện 'nhiều hơn' không liên quan. Yêu cầu này vốn dĩ không thể kiểm chứng (...)	Trong trường hợp không có dữ liệu huấn luyện trước đánh giá mô hình giả định rằng mô hình cần tìm cái còn thiếu giá trị. PAP thúc đẩy mô hình đúng hướng, dự đoán khẳng định là sai cho lý do chính xác .
Một số bang, chẳng hạn như Montana và Nebraska, đang nhận được nhiều hơn ba trăm ba mươi nghìn đô la trong tiền kích thích liên bang theo báo cáo COVID-19 trường hợp. New York là bang bị ảnh hưởng nặng nề nhất và vẫn chúng tôi chỉ nhận được khoảng mười ba nghìn, hai một trăm đô la mỗi thùng.	Gemini 2.5F^{T} zero-shot: “(...) Tôi là cũng xem xét liệu cái nhỏ sự chênh lệch trong các con số tài trợ làm cho tuyên bố tổng thể trở nên không chính xác (...) Yêu cầu đó về cơ bản là đúng, ngay cả với những sai lệch nhỏ Gemini 2.5F^{T} PAP: “(...) trạng thái yêu cầu ‘13.200 USD’ mỗi trường hợp cho New York, trong khi bằng chứng liên tục nêu ‘12.000 đô la’. Vì các con số đừng căn chỉnh, tôi phải phân loại yêu cầu như sai.	PAP nhấn mạnh rằng khác biệt 10% trong giá trị số của yêu cầu, so với bằng chứng như “số liệu đáng kể sự khác biệt”. Zero-shot đánh giá nhiều hơn tha thứ với liên quan những sự khác biệt.
Đối thủ của tôi, Rick Gunn, chặn sự mở rộng của Medicaid — chi phí một nửa sức khỏe của một triệu người bảo hiểm, bao gồm khoảng 34.000 cựu chiến binh.	Qwen3-32B^{T} zero-shot: “(...)The tuyên bố rằng có 34.000 cựu chiến binh, nhưng bằng chứng chỉ ủng hộ tới 23.000 hoặc 14.000. Yêu cầu của người dùng nói 34.000, cao hơn cả hai ước tính *(...)” (bắt đầu suy nghĩ quá nhiều).* Qwen3-32B^{T} PAP: “(...) 34.000 con số không có trong bằng chứng; cao nhất là 23.000. Do đó, tuyên bố là sai vì số cụ thể được cung cấp không phù hợp với bằng chứng.	Trong quá trình zero-shot, cái mô hình bắt đầu suy nghĩ quá nhiều, đang đi vào vòng tròn–xuất gần như 7000 token lý luận, trích dẫn con số trong bằng chứng “23.000”, 198 lần, và tuyên bố số “34.000”, 135 lần. Trong thời gian PAP, mô hình hoạt động đúng xác định sự khác biệt một cách hiệu quả, và giữ đầu ra mã thông báo lập luận của khoảng 200.

Bảng 10: Ví dụ về các tuyên bố, lập luận và phân tích cho Gemini 2.5F^{T} và Qwen3-32B^{T} nơi lập luận cải thiện đối với PAP, so với zero-shot.