arXiv:2608.10213v1 [cs.CE] 10 Aug 2026

VeriFin: A Neurosymbolic Framework for Verifying LLM-Generated Financial Claims

Bethel Hall
bhall2@stevens.edu
Stevens Institute of Technology
Hoboken, New Jersey, USA

Sachi Shome
sshome@stevens.edu
Stevens Institute of Technology
Hoboken, New Jersey, USA

William Eiers
weiers@stevens.edu
Stevens Institute of Technology
Hoboken, New Jersey, USA

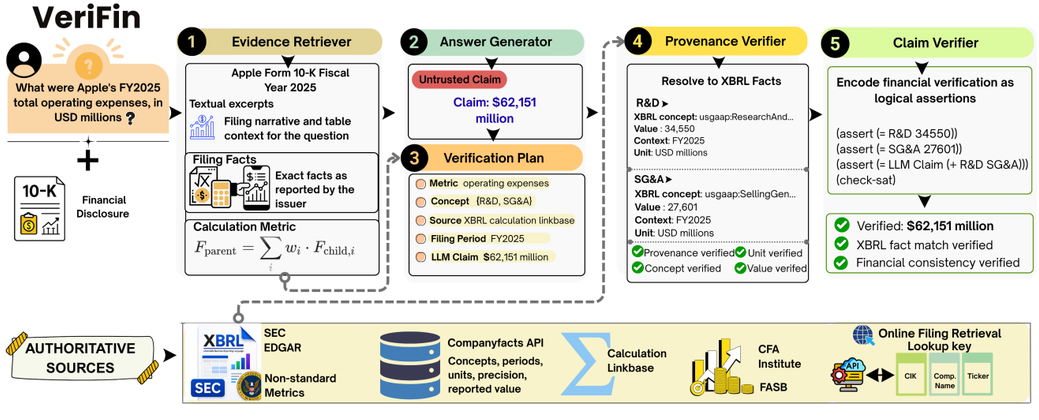


Figure 1: VeriFin applies formal verification to numerical claims generated by LLMs. For an Apple FY2025 operating-expense query, it retrieves filing evidence and obtains an untrusted candidate claim. A Verification Planner specifies the metric, period, unit, operands, and computation. The Provenance Verifier independently grounds the operands in XBRL facts and authorizes the formula from candidate-independent sources. The Claim Verifier then checks the resulting constraints and returns Verified, Violated, or Abstain with traceable evidence.

Abstract

Large language models often produce plausible numerical claims from financial filings while using the wrong reporting period, unit, line item, or formula. Verifying such claims requires more than rechecking arithmetic: a verifier must ground the relevant facts, establish the authorized calculation, and determine whether the candidate value follows from both. We propose VeriFin, a neurosymbolic verification framework for numerical financial question answering that grounds operands in filed XBRL facts, derives calculations from the question, filing linkbases, or documented metric definitions, and checks claims using Z3. When a claim is inconsistent, solver-derived unsatisfiable cores identify the conflicting facts, formula, and candidate value, enabling targeted repair. We evaluate VeriFin on XBRLFiling, a new 600-question benchmark constructed from 10-K filings of 28 U.S. companies, and on FinanceBench. On fixed candidate pools shared by all verification methods, VeriFin accepts none of the incorrect claims, whereas the baselines accept 6 to 92 incorrect claims on XBRLFiling's 600 claims and 4 to 21 incorrect claims on FinanceBench's 67 claims. The zero-false-accept result persists across multiple answer-generator models. Solver-derived feedback further improves repair, achieving up to 69.9% recovery among true catches. These results show that source-grounded symbolic verification can provide a reliable and auditable acceptance control for LLM-generated financial claims.

Keywords

Large Language Models, SMT Solvers, Formal Verification, XBRL, Financial Question Answering, Neurosymbolic Reasoning

1 Introduction

Financial professionals increasingly use large language models to answer numerical questions over public-company filings. These questions often require identifying the correct line items, reporting period, unit, and computation from 10-K and 10-Q disclosures. Yet a fluent answer may rely on the wrong year, scale, sign, metric definition, or source fact while remaining entirely plausible. Once incorporated into a spreadsheet, valuation model, risk report, compliance assessment, or investment memo, such an error may be difficult to detect and trace. The central reliability problem is therefore not only whether an LLM can generate an answer, but whether that answer should be accepted into a financial workflow or used in financial decision-making. For practical use, a plausible numerical answer is not enough; it must be independently verified before acceptance.

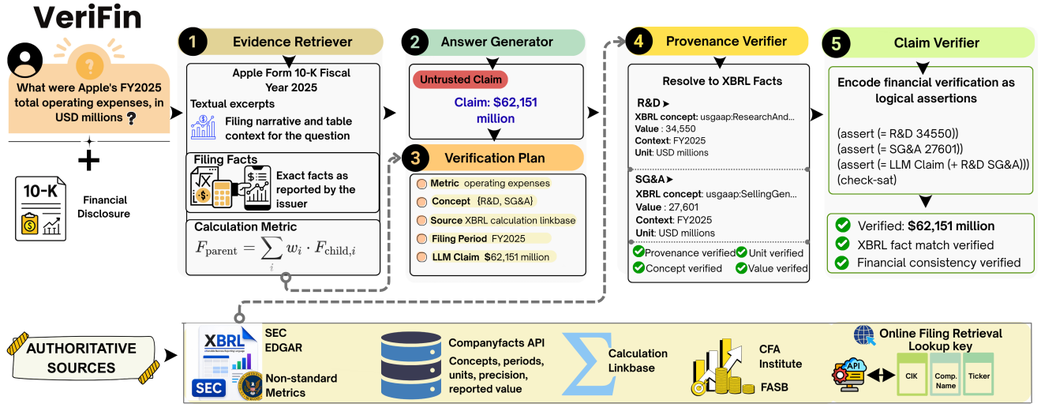
arXiv:2608.10213v1 [cs.CE] 10 Aug 2026

VeriFin: Một Khung Khoa Học Biểu Tượng Thần Kinh để Xác Minh Các Yêu Cầu Tài Chính Do LLM Tạo Ra

Bethel Hall
bhall2@stevens.edu Viện Công nghệ Stevens Hoboken, New Jersey, Hoa Kỳ

Sachi Shome
sshome@stevens.edu Viện Công nghệ Stevens Hoboken, New Jersey, Hoa Kỳ

William Eiers
weiers@stevens.edu Viện Công nghệ Stevens Hoboken, New Jersey, Hoa Kỳ



Hình 1: VeriFin áp dụng xác minh chính thức đối với các tuyên bố số liệu do LLM tạo ra. Đối với một truy vấn về chi phí hoạt động của Apple trong năm tài chính 2025, nó truy xuất bằng chứng hồ sơ và nhận được một tuyên bố ứng viên không đáng tin cậy. Một Bộ lập kế hoạch Xác minh xác định chỉ số, kỳ báo cáo, đơn vị, các toán hạng và phép tính. Bộ Xác minh Nguồn gốc độc lập xác thực các toán hạng trong XBRLfacts và xác nhận công thức từ các nguồn không phụ thuộc vào ứng viên. Sau đó, Bộ Xác minh Tuyên bố kiểm tra các ràng b uộc kết quả và trả về Đã Xác minh, Vi phạm, hoặc Tránh né kèm bằng chứng có thể truy xuất.

Tóm tắt

Các mô hình ngôn ngữ lớn thường tạo ra các tuyên bố số khả thi từ báo cáo tài chính trong khi sử dụng sai kỳ báo cáo, đơn vị, mục dòng hoặc công thức. Việc xác minh những tuyên bố này đòi hỏi hơn cả việc kiểm tra lại phép tính: người xác minh phải dựa vào các sự kiện liên quan, thiết lập phép tính được ủy quyền, và xác định xem giá trị ứng viên có phù hợp với cả hai không. Chúng tôi đề xuất VeriFin, một khuôn khổ xác minh thần kinh-biểu tượng cho việc trả lời các câu hỏi tài chính số học, mà trong đó các toán hạng được dựa trên các sự kiện XBRL đã nộp, các phép tính được suy ra từ câu hỏi, cơ sở liên kết báo cáo, hoặc định nghĩa các chỉ số đã được ghi chép, và kiểm tra các tuyên bố bằng Z3. Khi một tuyên bố không nhất quán, các lõi không thể thỏa mãn do bộ giải tạo ra sẽ xác định các sự kiện, công thức và giá trị ứng viên mâu thuẫn, cho phép sửa chữa có mục tiêu. Chúng tôi đánh giá VeriFin trên XBRLFiling, một chuẩn mới gồm 600 câu hỏi được xây dựng từ các báo cáo 10-K của 28 công ty Mỹ, và trên FinanceBench. Trên các nhóm ứng viên cố định được chia sẻ bởi tất cả các phương pháp xác minh, VeriFin chấp nhận không trong số những phát hiện thực sự. Những kết quả này cho thấy rằng việc xác minh biểu tượng dựa trên nguồn có thể cung cấp một kiểm soát chấp nhận đáng tin cậy và có thể kiểm tra được cho các yêu cầu tài chính do LLM tạo ra.

Từ khóa

Mô hình Ngôn ngữ Lớn, Bộ giải SMT, Xác minh Chính thức, XBRL, Trả lời Câu hỏi Tài chính, Lập luận Thần kinh Biểu tượng

1 Giới thiệu

Các chuyên gia tài chính ngày càng sử dụng các mô hình ngôn ngữ lớn để trả lời các câu hỏi về số liệu từ các báo cáo của các công ty đại chúng. Những câu hỏi này thường yêu cầu xác định đúng các mục dòng, kỳ báo cáo, đơn vị, và phép tính từ các báo cáo 10-K và 10-Q. Tuy nhiên, một câu trả lời trôi chảy có thể dựa trên năm, quy mô, dấu, định nghĩa chỉ số hoặc dữ kiện nguồn không chính xác nhưng vẫn hoàn toàn có vẻ hợp lý. Khi được đưa vào bảng tính, mô hình định giá, báo cáo rủi ro, đánh giá tuân thủ hoặc bản ghi nhớ đầu tư, lỗi như vậy có thể khó phát hiện và truy nguyên. Vấn đề trung tâm về độ tin cậy do đó không chỉ là liệu một LLM có thể tạo ra câu trả lời hay không, mà còn là liệu câu trả lời đó có nên được chấp nhận trong quy trình tài chính hay sử dụng trong việc ra quyết định tài chính hay không. Đối với việc sử dụng thực tiễn, một câu trả lời số có vẻ hợp lý là chưa đủ; nó phải được kiểm chứng độc lập trước khi chấp nhận.

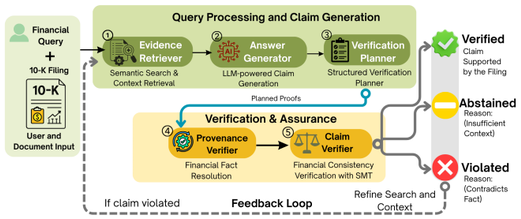


Figure 2: Overview of VeriFin

Recent work has improved financial question answering through retrieval, structured XBRL access, calculation tools, and executable programs [7, 8, 10, 17], yet numerical reliability remains a challenge. FinanceBench, XBRL-Agent, and Fin-RATE show that errors continue even when models have access to filings and external tools, particularly when questions require the correct entity, reporting period, line item, or computation [7–9]. The problem is therefore not merely retrieving relevant evidence or executing arithmetic, but establishing whether the selected facts, units, periods, and formula actually support a candidate answer. Complementary work on atomic claim grounding, financial-statement consistency, and XBRL-based audit verification addresses parts of this problem [6, 15, 18]; however, a model-generated program may execute the wrong computation, retrieved evidence may be insufficient, and an LLM judge may still approve a claim that does not follow from the filing. We call the acceptance of such an incorrect numerical claim a *false accept*. This motivates the operational question at the center of our work: **given a fixed numerical claim produced by an LLM, should a financial workflow accept it?**

To address this question, we introduce VeriFin, a filing-grounded neurosymbolic framework that separates claim generation from verification and determines whether numerical claims produced by LLMs should be accepted (Figure 2). VeriFin treats each candidate claim as an untrusted claim. First, it grounds the required financial values in filed XBRL facts, preserving their concepts, reporting periods, units, and contexts. Second, it establishes the required calculation independently of the candidate claim. The calculation is obtained from an operation stated in the question, the filing's XBRL calculation relationships, a documented financial metric definition, or a filing-specific definition. Third, VeriFin compiles the grounded values, calculation, and candidate claim into arithmetic constraints checked by the Satisfiability Modulo Theories (SMT) solver Z3 [5]. The framework returns Verified when the candidate is consistent with the established facts and calculation, Violated when it is inconsistent, and Abstain when the necessary facts or a source-backed calculation cannot be established unambiguously. Once the facts and calculation are fixed, the solver decision is deterministic and traceable to the filing evidence. Abstention is therefore an explicit financial-control decision: when support for a number cannot be established, VeriFin declines to approve it rather than substituting a model-generated assumption.

We evaluate VeriFin on XBRLFiling, a new benchmark of 600 numerical questions constructed from calculations in 10-K filings of 28 U.S. companies, and on a numerical subset of FinanceBench. On XBRLFiling, VeriFin records zero observed false accepts, whereas the four baselines accept between 6 and 92 of the same 92 incorrect claims. VeriFin achieves 92.2% accuracy among decided cases with 1.2% abstention. On FinanceBench, VeriFin again records zero observed false accepts, whereas the baselines accept between 4 and 21 of the same 21 incorrect claims. The zero false-accept result persists across multiple answer-generator models. These findings shift the reliability question in LLM-based financial analysis from whether a claim sounds plausible to whether filed facts and an independently established calculation support its acceptance.

Our contributions are:

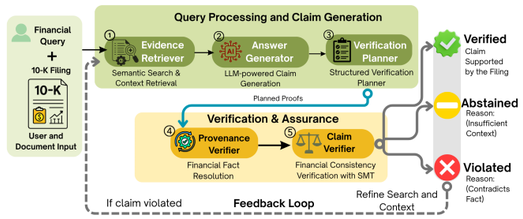
- We formulate verification of numerical financial claims as an acceptance-control problem centered on false-accept risk and explicit abstention, preventing unsupported numerical claims from entering downstream financial workflows.
- We develop VeriFin, which grounds required values in filed XBRL facts, establishes the financial calculation independently of the candidate claim, and checks the resulting claim using a symbolic solver.
- We introduce XBRLFiling, a 600-question benchmark from real corporate filings, and evaluate VeriFin against same-candidate verification baselines on XBRLFiling and FinanceBench. Code and data are available publicly.[1]

2 Related Work

Financial claim verification. LLM-as-a-judge methods use one model to evaluate another, but their decisions can exhibit systematic biases and reasoning failures [20]. Program-of-Thoughts instead delegates arithmetic to executable model-generated code [3]; SEC-QA applies this approach to questions over SEC filings [10]. Execution reduces arithmetic errors, but the model still selects the operands and computation. Large-scale pretraining and instruction tuning give language models broad linguistic and semantic competence [11, 12], but neither provides a guarantee that generated claims are factually supported. These findings motivate VeriFin's division of labor: language models propose candidate answers and semantic interpretations, while candidate-independent provenance checks and symbolic constraints determine whether a numerical claim should be accepted.

Recent financial systems address reliability more directly. Fin-Ground decomposes generated claims into atomic claims and recomputes numerical claims, while using learned models for evidence alignment and final verdicts [6]. VERAFI uses formalized financial policies as guidance during agentic generation [1]. FinVerBench evaluates deterministic consistency checks over complete financial statements [15], while AuditFlow combines XBRL graphs with deterministic tools for audit-rule verification [18]. VeriFin instead verifies a fixed numerical QA claim: the candidate claim does not determine the filed facts or source-backed calculation used to check it. Its same-candidate evaluation directly measures false accepts, false rejects, and abstentions.

[1] https://github.com/verifiedfinance/anon



Hình 2: Tổng quan về VeriFin

Các nghiên cứu gần đây đã cải thiện khả năng trả lời câu hỏi tài chính thông qua việc truy xuất, truy cập XBRL có cấu trúc, công cụ tính toán và chương trình thực thi [7, 8, 10, 17], nhưng độ tin cậy về số liệu vẫn là một thách thức. FinanceBench, XBRL-Agent và Fin-RATE cho thấy lỗi vẫn tiếp tục xảy ra ngay cả khi các mô hình có quyền truy cập vào hồ sơ và các công cụ bên ngoài, đặc biệt khi các câu hỏi yêu cầu thực thể, kỳ báo cáo, mục dòng hoặc phép tính đúng [7–9]. Do đó, vấn đề không chỉ là truy xuất bằng chứng có liên quan hoặc thực hiện các phép tính số học, mà còn là xác định liệu các dữ kiện, đơn vị, kỳ báo cáo và công thức được chọn có thực sự hỗ trợ cho một câu trả lời dự kiến hay không. Các nghiên cứu bổ sung về xác thực tuyên bố đơn lẻ, độ nhất quán của báo cáo tài chính, và xác minh kiểm toán dựa trên XBRL giải quyết một phần vấn đề này [6, 15, 18]; tuy nhiên, một chương trình do mô hình tạo ra có thể thực hiện phép tính sai, bằng chứng truy xuất có thể không đủ, và một giám khảo LLM vẫn có thể phê duyệt một tuyên bố mà không tuân theo hồ sơ. Chúng tôi gọi việc chấp nhận như vậy là

Để giải quyết câu hỏi này, chúng tôi giới thiệu VeriFin, một khuôn khổ neurosymbolic dựa trên hồ sơ, tách biệt việc tạo lập yêu cầu và việc xác minh, và xác định liệu các yêu cầu số liệu do LLM tạo ra có nên được chấp nhận hay không (Hình 2). VeriFin xem mỗi yêu cầu ứng viên như một yêu cầu chưa được tin cậy. Đầu tiên, nó gắn các giá trị tài chính cần thiết vào các dữ liệu XBRL đã được nộp, bảo lưu các khái niệm, kỳ báo cáo, đơn vị và bối cảnh của chúng. Thứ hai, nó thiết lập phép tính cần thiết độc lập với yêu cầu ứng viên. Phép tính này được lấy từ một phép toán được nêu trong câu hỏi, các mối quan hệ tính toán XBRL của hồ sơ, một định nghĩa chỉ số tài chính được tài liệ u hóa, hoặc một định nghĩa đặc thù theo hồ sơ. Thứ ba, VeriFin biên soạn các giá trị đã gắn, phép tính và yêu cầu ứng viên thành các ràng buộc số học được kiểm tra bởi bộ giải Satisfiability Modulo Theories (SMT) Z3 [5]. Khuôn khổ trả về Verified khi yêu cầu ứng viên nhất quán với các dữ liệu và phép tính đã thiết lập, Violated khi nó

Chúng tôi đánh giá VeriFin trên XBRLFiling, một bộ chuẩn mới gồm 600 câu hỏi số học được tạo ra từ các phép tính trong các báo cáo 10-K của 28 công ty tại Hoa Kỳ, và trên một tập hợp con số học của FinanceBench. Trên XBRLFiling, VeriFin ghi nhận không quan sát thấy trường hợp chấp nhận sai nào, trong khi bốn phương pháp cơ sở chấp nhận từ 6 đến 92 trong số 92 tuyên bố sai tương tự. VeriFin đạt độ chính xác 92,2% trong c ác trường hợp đã quyết định với tỷ lệ từ chối 1,2%. Trên FinanceBench, VeriFin một lần nữa ghi nhận không có trường hợp chấp nhận sai nào, trong khi các phương pháp cơ sở chấp nhận từ 4 đến 21 trong số 21 tuyên bố sai tương tự. Kết quả không chấp nhận sai này vẫn duy trì trên nhiều mô hình tạo câu trả lời khác nhau. Những phát hiện này đã chuyển câu hỏi về độ tin cậy trong phân tích tài chính dựa trên LLM từ việc liệu một tuyên bố có nghe có vẻ hợp lý hay không sang việc liệu các dữ kiện đã nộp và một phép tính được thiết lập độc lập có hỗ trợ việc chấp nhận nó hay không.

Những đóng góp của chúng tôi là:

- Chúng tôi hình thành việc xác minh các yêu cầu tài chính số học như một vấn đề kiểm soát chấp nhận tập trung vào rủi ro chấp nhận sai và từ chối rõ ràng, ngăn chặn các yêu cầu số học không được hỗ trợ đi vào các quy trình tài chính hạ nguồn.
- Chúng tôi phát triển VeriFin, giao các giá trị yêu cầu trên các dữ kiện XBRL đã nộp, thiết lập phép tính tài chính độc lập với yêu cầu của ứng viên, và kiểm tra yêu cầu kết quả bằng bộ giải biểu tượng.
- Chúng tôi giới thiệu XBRLFiling, một bộ chuẩn 600 câu hỏi từ các hồ sơ doanh nghiệp thực tế, và đánh giá VeriFin so với các chuẩn xác minh ứng viên tương tự trên XBRLFiling và FinanceBench. Mã và dữ liệu có sẵn công khai.[1]

2 Công trình liên quan

Xác minh yêu cầu tài chính. Các phương pháp LLM như thẩm phán sử dụng một mô hình để đánh giá mô hình khác, nhưng các quyết định của chúng có thể thể hiện sự thiên lệch hệ thống và sai sót trong lập luận [20]. Program-of-Thoughts thay vào đó giao việc tính toán số học cho mã do mô hình tạo ra có thể thực thi [3]; SEC-QA áp dụng phương pháp này cho các câu hỏi về báo cáo của SEC [10]. Việc thực thi giảm các lỗi số học, nhưng mô hình vẫn chọn các toán hạng và phép tính. Huấn luyện quy mô lớn và tinh chỉnh hướng dẫn mang lại cho các mô hình ngôn ngữ năng lực ngôn ngữ và ngữ nghĩa rộng [11, 12]„ nhưng không phương pháp nào đảm bảo rằng các yêu cầu được tạo ra có cơ sở thực tế. Những phát hiện này thúc đẩy sự phân công công việc của VeriFin: các mô hình ngôn ngữ đề xuất các câu trả lời và giải thích ngữ nghĩa tiềm năng, trong khi kiểm tra nguồn gốc độc lập với các ứng cử viên và các ràng buộc biểu tượng xác định liệu một yêu cầu số liệu có nên được chấp nhận hay không.

Các hệ thống tài chính gần đây giải quyết vấn đề độ tin cậy một cách trực tiếp hơn. Fin-Ground phân tách các yêu cầu được tạo thành các yêu cầu nguyên tử và tái tính toán các yêu cầu số, đồng thời sử dụng các mô hình học được để căn chỉnh bằng chứng và đưa ra phán quyết cuối cùng [6]. VERAFI sử dụng các chính sách tài chính được chính thức hóa làm hướng dẫn trong quá trình tạo tác nhân [1]. FinVerBench đánh giá các kiểm tra nhất quán xác định trên các báo cáo tài chính đầy đủ [15], trong khi AuditFlow kết hợp các đồ thị XBRL với các công cụ xác định để xác minh quy tắc kiểm toán [18]. VeriFin thay vào đó xác minh một yêu cầu QA số cố định: yêu cầu ứng viên không xác định các dữ kiện đã nộp hoặc phép tính dựa trên nguồn được sử dụng để kiểm tra nó. Việc đánh giá cùng ứng viên của nó đo lường trực tiếp các trường hợp chấp nhận sai, từ chối sai và từ chối tr ả lời.

[1] https://github.com/verifiedfinance/anon

Neurosymbolic Verification. Logic-LM, LINC, and SatLM translate natural-language problems into formal representations and delegate inference to symbolic solvers [13, 14, 19]. Similarly, ARc uses inference-time autoformalization to verify natural-language policy rules with automated reasoning tools [2]. Although inference is deterministic with respect to the generated formal representation, semantic-parsing errors can still lead to incorrect conclusions. VeriFin reduces reliance on unconstrained free-form translation by grounding numerical values in XBRL facts and restricting computations to operations specified in the question, filing calculation relationships, or documented financial definitions. Given a complete and correctly grounded verification plan, VeriFin uses Z3 [5] to deterministically check whether the candidate claim satisfies the resulting arithmetic constraints.

3 Methodology

VeriFin evaluates whether an LLM-generated numerical claim should be accepted into a financial workflow by replacing nondeterministic evaluation with formal verification. Rather than asking a secondary model to judge correctness—which remains vulnerable to plausible hallucinations—VeriFin decouples candidate proposal from claim validation. We leverage language models solely for semantic parsing and retrieval planning, while delegating arithmetic enforcement, context binding, and consistency checking to deterministic XBRL linkbases and an SMT solver.

3.1 Neurosymbolic Verification Paradigm

Financial question answering requires two distinct capabilities: *semantic understanding* (identifying relevant concepts from unstructured filing narrative) and *symbolic rigor* (ensuring mathematical and context-level consistency). Standard LLM-as-a-judge or Program-of-Thought (PoT) baselines are unreliable because they allow the model to select its own evaluation criteria and operand definitions without formal constraints. VeriFin resolves this by establishing an asymmetric workflow grounded in the intuition that *checking a solution to a problem is generally easier than finding one.* As illustrated in Figure 2, an LLM acts purely as a proposal engine to extract candidate claims and structure verification plans. Crucially, the candidate claim never influences the authoritative filing facts or formulas used to check it. Acceptance is decided exclusively by whether the grounded facts and formula form a satisfiable constraint system in the SMT solver Z3. We next describe the five components of the framework.

3.2 Evidence Retriever

Given a query q and filing document D, the Evidence Retriever selects a bounded set of K evidence chunks $E = \{e_1, \ldots, e_K\} \subseteq D$ to ground claim generation and verification. To prevent cross-filing contamination, candidates are strictly restricted to D by document identifier. Rather than searching with q alone, the retriever identifies required line-item facts $R = \{r_1, \ldots, r_m\}$ and constructs expanded queries $q_i = [q \,||\, r_i \,||\, \text{period} \,||\, \text{statement}]$. Chunks $c \in D$ are scored using a hybrid function:

$$S(q_i, c) = \cos\left(\mathbf{e}(q_i), \mathbf{e}(c)\right) + \lambda \cdot S_{\text{lex}}(q_i, c) \tag{1}$$

combining dense cosine similarity with a lexical score S_{lex} that rewards exact label matches in table rows. Top candidate chunks are reranked via a cross-encoder model. The selected passages and table rows are concatenated to form the evidence text supplied to the subsequent claim-generation and verification stages.

3.3 Answer Generator

Given the retrieved evidence context E, a language model drafts a candidate claim a to query q. This stage is intentionally decoupled from decision-making: a is treated as an untrusted claim. To prevent circular evaluation, candidate a is passed forward strictly as a target for formal verification and exerts no influence on the authoritative facts, linkbases, or solver constraints used to check it.

3.4 Verification Planner

The Verification Planner uses an LLM to parse question q and evidence E into a candidate verification plan $C = (M, F, R, \boldsymbol{u}, \boldsymbol{\rho}, S)$. Defining target metrics M, authorized formulas F, operand roles R, expected units $\boldsymbol{u}$, reporting periods $\boldsymbol{\rho}$, and formula sources S as sets enables a single plan to naturally support multi-metric and multi-step computational queries.

Formula authority follows a strict hierarchy over non-generative sources (§3.5): explicit operations in q, the filing's calculation linkbase, the curated metric registry, or disclosure text. If any formula in F lacks complete and unambiguous authority, VeriFin abstains.

3.5 Provenance Verifier

Grounding Operands in XBRL Facts. For each required operand role r_i, the Provenance Verifier independently establishes four properties: the referenced taxonomy concept, the reporting period, the reported unit, and the filed value.

Concept. The role is resolved to a taxonomy concept in three stages. If the filing's calculation linkbase identifies a child concept for the role under the requested subtotal, that concept is bound directly. Otherwise the role is matched against a curated concept registry that maps normalized financial concepts to candidate taxonomy elements (e.g., `us-gaap:AccountsPayableCurrent`). If neither stage resolves the role, a symbolic label-matching heuristic tokenizes the filing row label and candidate concept labels, accepts a concept only when the row's tokens are a subset of the concept label, and breaks ties by selecting the candidate with the fewest surplus tokens.

Period and unit. A concept alone does not uniquely identify a fact: the same concept is reported for multiple fiscal periods and may be presented at different display scales (e.g., thousands or millions of USD). A role therefore binds only to a fact whose reporting period matches the question and whose unit matches the expected measure, after normalizing the reported value to the requested scale. A concept that exists in the filing but has no fact at the required period and unit does not bind.

Value and provenance. The operand value is taken exclusively from the filed fact. Registry-resolved concepts are therefore bound *value-blind*: the filed value overrides whatever figure the model extracted. Consequently, structural mismatches (e.g., binding `ProfitLoss` where the authorized policy requires `NetIncomeLoss`) are not filtered during grounding but instead surface later as solver constraint

Xác minh thần kinh-biểu tượng. Logic-LM, LINC và SatLM chuyển các vấn đề ngôn ngữ tự nhiên thành các biểu diễn chính thức và ủy quyền suy luận cho các bộ giải biểu tượng [13, 14, 19]. Tương tự, ARc s ử dụng tự hình thức hóa trong thời gian suy luận để xác minh các quy tắc chính sách ngôn ngữ tự nhiên với các công cụ lý luận tự động [2]. Mặc dù việc suy luận là xác định đối với biểu diễn chính thức được t ạo ra, các lỗi phân tích ngữ nghĩa vẫn có thể dẫn đến những kết luận sai. VeriFin giảm sự phụ thuộc vào dịch tự do không giới hạn bằng cách đặt các giá trị số dựa trên dữ kiện XBRL và giới hạn các phép tí nh chỉ trong các phép toán được chỉ định trong câu hỏi, các mối quan hệ tính toán hoặc các định nghĩa tài chính đã được ghi nhận. Với một kế hoạch xác minh đầy đủ và được định hướng đúng, VeriFin sử dụng Z 3 [5] để kiểm tra một cách xác định xem yêu cầu ứng viên có thỏa mãn các ràng buộc số học kết quả hay không.

3 Phương pháp luận

VeriFin đánh giá xem một tuyên bố số do LLM tạo ra có nên được chấp nhận vào quy trình tài chính hay không bằng cách thay thế đánh giá phi xác định bằng xác minh chính thức. Thay vì yêu cầu một mô hình phụ đánh giá tính chính xác — điều này vẫn có thể bị ảnh hưởng bởi những ảo tưởng có vẻ hợp lý — VeriFin tách rời việc đề xuất ứng viên khỏi việc xác nhận tuyên bố. Chúng tôi sử dụng các mô hình ngôn ngữ chỉ để phân tích cú pháp ngữ nghĩa và lập kế hoạch truy xuất, trong khi việc thực thi phép toán, liên kết ngữ cảnh và kiểm tra tính nhất quán được giao cho các liên kết cơ sở dữ liệu XBRL xác định và trình giải SMT.

3.1 Mô hình Xác minh Thần kinh-biểu tượng

Trả lời các câu hỏi tài chính đòi hỏi hai khả năng khác nhau: hiểu ngữ nghĩa (xác định các khái niệm liên quan từ bản tường thuật hỗ sơ không cấu trúc) và độ chính xác mang tính biểu tượng (đảm bảo tính nhất quán về mặt toán học và bối cảnh). Các phương pháp chuẩn như LLM-với-vai-trò-thẩm-phán hoặc Program-of-Thought (PoT) là không đáng tin cậy vì chúng cho phép mô hình tự chọn tiêu chí đánh giá và định nghĩa toán tử mà không có giới hạn chính thức. VeriFin giải quyết vấn đề này bằng cách thiết lập một quy trình làm việc bất đối xứng dựa trên trực giác rằng việc kiểm tra một giải pháp cho một vấn đề thường dễ hơn việc tìm ra nó. Như minh họa trong Hình 2, một LLM chỉ hoạt động như một công cụ đề xuất để trích xuất các tuyên bố ứng viên và cấu trúc các kế hoạch xác minh. Quan trọng là, các tuyên bố ứng viên không bao giờ ảnh hưởng đến các sự kiện hoặc công thức có thẩm quyền từ hồ sơ được sử dụng để kiểm tra chúng. Việc chấp nhận hoàn toàn được quyết định dựa trên việc các sự kiện và công thức đã cơ sở hóa có tạo thành một hệ thống ràng buộc khả t hi trong bộ giải SMT Z3 hay không. Tiếp theo, chúng tôi mô tả năm thành phần

3.2 Trình Tìm Kiếm Bằng Chứng

Với một truy vấn q và tài liệu nộp D, Bộ Truy xuất Bằng chứng chọn một tập hợp giới hạn các đoạn bằng chứng K $E = \{e_1, \ldots, e_K\} \subseteq D$ để làm cơ sở cho việc tạo và xác minh tuyên bố. Để ngăn ngừa sự lẫn lộn giữa các tài liệu, các ứng viên bị hạn chế nghiêm ngặt theo D bởi định danh tài liệu. Thay vì tìm kiếm chỉ với q, bộ truy xuất xác định các thông tin chi tiết theo mục cần thiết $R = \{r_1, \ldots, r_m\}$ và xây dựng các truy vấn mở rộng $q_i = [q \,||\, r_i \,||$ khoảng. Các đoạn $c \in D$ được chấ m điểm bằng một hàm lai:

$$S(q_i, c) = \cos\left(\mathbf{e}(q_i), \mathbf{e}(c)\right) + \lambda \cdot S_{\text{lex}}(q_i, c) \tag{1}$$

kết hợp độ tương đồng cosin dày đặc với điểm số từ vựng S_{lex} thưởng cho các nhãn khớp chính xác trong các hàng bảng. Các đoạn ứng viên hàng đầu được xếp hạng thông qua một mô hình mã hóa chéo. Các đoạn và hàng bảng được chọn được nối lại để tạo thành văn bản bằng chứng cung cấp cho các giai đoạn tạo và xác minh khẳng định tiếp theo.

3.3 Trình tạo câu trả lời

Dựa trên bối cảnh bằng chứng được truy xuất E, một mô hình ngôn ngữ soạn thảo một yêu cầu ứng viên a cho truy vấn q. Giai đoạn này được tách rời một cách có chủ ý khỏi quá trình ra quyết định: a được coi là một yêu cầu không đáng tin cậy. Để ngăn chặn đánh giá vòng lặp, yêu cầu ứng viên a được chuyển tiếp một cách nghiêm ngặt như một mục tiêu để xác minh chính thức và không ảnh hưởng đến các sự kiện chính thức, cơ sở liên kết, hoặc các ràng buộc của trình giải được sử dụng để kiểm tra nó.

3.4 Kế hoạch kiểm tra

Trình lập kế hoạch Xác minh sử dụng một LLM để phân tích câu hỏi q và bằng chứng E thành một kế hoạch xác minh ứng viên $C = (M, F, R, \boldsymbol{u}, \boldsymbol{\rho}, S)$. Việc định nghĩa các chỉ số mục tiêu M, công thức được phép F, vai trò của toán hạng R, đơn vị dự kiến $\boldsymbol{u}$, các khoảng thời gian báo cáo $\boldsymbol{\rho}$, và nguồn công thức S dưới dạng các tập hợp cho phép một kế hoạch duy nhất hỗ trợ tự nhiên các truy vấn tính toán đa chỉ số và nhiều bước.

Quyền hạn công thức tuân theo một hệ thống cấp bậc nghiêm ngặt đối với các nguồn không sinh tạo (§3.5): các phép toán rõ ràng trong q, liên kết tính toán của hồ sơ, đăng ký chỉ số được lựa chọn kỹ lưỡng, hoặc văn bản công bố. Nếu bất kỳ công thức nào trong F thiếu quyền hạn đầy đủ và rõ ràng, VeriFin sẽ kiềm chế.

3.5 Trình kiểm tra nguồn gốc

Căn cứ các toán hạng trong các sự kiện XBRL. Đối với mỗi vai trò toán hạng bắt buộc r_i, Bộ Kiểm tra Nguồn gốc độc lập thiết lập bốn thuộc tính: khái niệm phân loại tham chiếu, kỳ báo cáo, đơn vị báo cáo và giá trị đã nộp.

Khái niệm. Vai trò được xác định thành một khái niệm phân loại trong ba giai đoạn. Nếu cơ sở liên kết tính toán của hồ sơ xác định một khái niệm con cho vai trò dưới tổng số phụ được yêu cầu, khái niệm đó sẽ được liên kết trực tiếp. Nếu không, vai trò sẽ được so sánh với một đăng ký khái niệm được tuyển chọn, đăng ký này ánh xạ các khái niệm tài chính chuẩn hóa với các phần tử phân loại ứng cử viên (ví dụ: us-gaap:AccountsPayableCurrent). Nếu không giai đoạn nào xác định được vai trò, một thủ thuật so khớp nhãn biểu tượng sẽ phân tách nhãn hàng của hồ sơ và nhãn khái niệm ứng cử viên, chấp nhận một khái niệm chỉ khi các token của hàng là một tập con của nhãn khái niệm, và giải quyết sự trùng lặp bằng cách chọn ứng cử viên có số token dư thừa ít nhất.

Kỳ và đơn vị. Một khái niệm riêng lẻ không xác định duy nhất một sự kiện: cùng một khái niệm có thể được báo cáo cho nhiều kỳ tài chính khác nhau và có thể được trình bày ở các quy mô hiển thị khác nhau (ví dụ: nghìn hoặc triệu USD). Do đó, một vai trò chỉ gắn với một sự kiện có kỳ báo cáo phù hợp với câu hỏi và đơn vị phù hợp với thước đo mong đợi, sau khi chuẩn hóa giá trị báo cáo theo quy mô yêu cầu. Một khái niệm tồn tại trong hồ sơ nhưng không có sự kiện ở kỳ và đơn vị được yêu cầu sẽ không được gắn.

Giá trị và nguồn gốc. Giá trị toán hạng được lấy hoàn toàn từ thực tế đã ghi. Do đó, các khái niệm được phân giải từ sổ đăng ký là bị ràng buộc không quan tâm đến giá trị: giá trị đã ghi sẽ ghi đè bất kỳ con số nào mà mô hình trích xuất. Do đó, sự không khớp về cấu trúc (ví dụ, bindingProfitLoss trong khi chính sách được ủy quyền yêu cầu NetIncomeLoss) không được lọc trong quá trình nền tảng hóa mà thay vào đó xuất hiện sau đó như một ràng buộc của bộ giải.

violations. Only the heuristic third stage is guarded by a plausibility check against the extracted value. Every binding records the concept, reporting period, unit, accession number, and source fact identifier, so each admitted operand is fully traceable to a specific reported filing fact. If any required role cannot be grounded, no verification plan is admitted and VeriFin abstains.

Establishing Formula Provenance. For linkbase-derived subtotals, issuer-declared child concepts and arc weights $w_i \in \{-1, +1\}$ define the formula directly as $f(x_1, \ldots, x_n) = \sum_{i=1}^{n} w_i x_i$. Where no linkbase relationship applies, formula authority is derived from an explicit question template, a curated metric registry,[2] or an explicit definition in the filing text. If no authority yields a complete and unambiguous formula, VeriFin abstains.

Admitted plans record the formula provenance, source identifier, authorized equation f, and grounded operand roles, providing downstream verification with an independently established computational baseline.

3.6 Claim Verifier

Given a validated verification plan and grounded XBRL facts, the Claim Verifier binds each operand x_i to its filed value $m_i^\star$, computes the expected value $\hat{v}$ using formula f, and compares it with the candidate value v_c:

$$\Phi = \bigwedge_i (x_i = m_i^\star) \wedge (\hat{v} = f(x)) \wedge (|\hat{v} - v_c| \leq \tau),$$

where τ is the reporting precision. The constraints are compiled into quantifier-free real arithmetic and evaluated by Z3 [5]. The tolerance τ is half a unit in the last place reported by the filing, so it admits rounding at the disclosed precision. For a figure stated to the nearest million, $\tau = 0.5$ million; for a percentage stated to one decimal, $\tau = 0.05$ percentage points.

A satisfiable constraint system yields Verified; an unsatisfiable constraint system yields Violated; the system returns Abstain when a required operand or authorized formula cannot be established or when the solver returns unknown. Constraints are named so that a violation can be accompanied by an unsatisfiable core identifying conflicting filing, formula, or claim constraints. The final solver decision is deterministic conditional on the grounded facts and authorized computation.

Verifier feedback. Each constraint is named so that a failed verification can be traced to the relevant filing value, formula condition, or claim bound. For a Verified claim, the Z3 SMT Solver returns logically grounded evidence supporting the result. For a Violated claim, it identifies a conflicting subset of named filing, formula, and claim constraints that cannot all hold together, thereby pinpointing the source of the error. The violated claim bound further indicates whether the claim overstates or understates the correct value. For Abstain, the verifier provides the exact requirement it could not establish, such as a missing formula or facts that cannot be grounded in the filing. This provides the language model with a concrete target for repair.

[2]The registry compiles derived financial-metric definitions from CFA Institute curriculum materials.

XBRLFiling Example
Income statement

Question. What were Apple's FY2025 total operating expenses?

APPLE INC.
CONSOLIDATED STATEMENTS OF OPERATIONS
(USD millions)

	Fiscal years ended		
	2025	**2024**	**2023**
Revenue	416,161	391,035	383,285
Cost of goods sold	220,960	210,352	214,137
Gross profit	**195,201**	**180,683**	**169,148**
Operating expenses:			
Research and development	**34,550**	31,370	29,915
Selling, general and administrative	**27,601**	26,097	24,932
Total operating expenses	***[redacted]***	**57,467**	**54,847**
Operating income	**133,050**	**123,216**	**114,301**
Nonoperating income (expense)	321	269	565
Income before taxes	132,729	123,485	113,736
Income tax expense	20,719	29,749	16,741
Net income	**112,010**	**93,736**	**96,995**

gold answer: 34,550 + 27,601 = **62,151** million

Figure 3: An XBRLFiling income-statement numerical question: the target subtotal is redacted, and the complete filing table is reorganized into a compact listing while preserving all line items and reporting periods.

4 Experimental Setup

To isolate differences in verification performance, all methods evaluate the same fixed candidate claims and retrieved evidence. Candidate generation is performed once using Claude Haiku 4.5, and the resulting candidate answers are reused unchanged across Direct LLM, LLM Judge, Judge+Formula, Program-of-Thought, and VeriFin.

Consequently, differences in false accepts, false rejects, precision, accuracy, and abstention reflect the behavior of the verification method rather than differences in candidate generation.

4.1 Datasets

XBRLFiling. Inspired by FinQA's use of financial-report evidence and executable reasoning programs [4], XBRLFiling is built in reverse: instead of writing a question and then annotating how to answer it, we start from a calculation the company itself declared in its filing and generate a question that the calculation answers. We collect 86 10-K submissions from EDGAR [16] across 28 U.S. companies (including Apple, Microsoft, Amazon, Nvidia, and Exxon Mobil) for fiscal years 2021–2026.

Alongside its financial statements, every XBRL filing publishes a *calculation linkbase*: a machine-readable record stating which line items sum to which subtotals, and with what sign. We fix a target set of 15 reported subtotals spanning the three primary statements (net income, current assets, operating income, and so on). For each filing we take every target subtotal p the calculation linkbase declares, read off the line items $\{c_1, \ldots, c_n\}$ it says compose p and their signs $w_i \in \{-1, +1\}$, and record the identity $p = \sum_{i=1}^{n} w_i c_i$ as ground truth. Only then do we generate the question, from a template

vi phạm. Chỉ giai đoạn thứ ba theo phương pháp heuristic được bảo vệ bởi một kiểm tra tính hợp lý đối với giá trị đã trích xuất. Mỗi liên kết ghi lại khái niệm, kỳ báo cáo, đơn vị, số truy cập và định danh sự kiện nguồn, vì vậy mỗi toán hạng được chấp nhận đều có thể truy nguyên đầy đủ đến một sự kiện báo cáo cụ thể. Nếu bất kỳ vai trò bắt buộc nào không thể được xác định, không có kế hoạch xác minh nào được chấp nhận và VeriFin sẽ từ chối.

Thiết lập Nguồn Gốc Công Thức. Đối với các tổng phụ có nguồn gốc từ linkbase, các khái niệm con do người phát hành khai báo và trọng số cung $w_i \in \{-1, +1\}$ xác định công thức trực tiếp là $f(x_1, \ldots, x_n) = \sum_{i=1}^{n} w_i x_i$. Khi không có mối quan hệ linkbase áp dụng, thẩm quyền công thức được xác định từ một mẫu câu hỏi rõ ràng, một đăng ký chỉ số được tuyển chọn,[2] hoặc một định nghĩa rõ ràng trong văn bản nộp hồ sơ. Nếu không thẩm quyền nào cung cấp một công thức đầy đủ và rõ ràng, VeriFin sẽ không thực hiện.

Các bản ghi kế hoạch đã được chấp nhận ghi lại nguồn gốc công thức, định danh nguồn, phương trình được ủy quyền f, và vai trò toán hạng cơ sở, cung cấp khả năng xác minh tiếp theo với một cơ sở tính toán được thiết lập độc lập.

3.6 Bộ xác minh tuyên bố

Với một kế hoạch xác minh đã được xác nhận và các dữ kiện XBRL cơ sở, Người Kiểm Tra Yêu Cầu liên kết mỗi toán hạng x_i với giá trị đã nộp của nó $m_i^\star$, tính giá trị dự kiến $\hat{v}$ sử dụng công thức f, và so sánh nó với giá trị ứng viên v_c:

$$\Phi = \bigwedge_i (x_i = m_i^\star) \wedge (\hat{v} = f(x)) \wedge (|\hat{v} - v_c| \leq \tau),$$

where τ là độ chính xác báo cáo. Các ràng buộc được biên soạn thành số học thực không chứa lượng tử và được đánh giá bởi Z3 [5]. Sai số τl à một nửa đơn vị ở vị trí cuối cùng được báo cáo bởi hồ sơ, vì vậy nó cho phép làm tròn ở độ chính xác đã công bố. Đối với một con số được nêu gần nhất triệu, $\tau = 0.5$ triệu; đối với một phần trăm được nêu với một chữ số thập phân, $\tau = 0.05$ điểm phần trăm.

Một hệ thống ràng buộc có thể thỏa mãn sẽ cho kết quả Đã Xác Minh; một hệ thống ràng buộc không thể thỏa mãn sẽ cho kết quả Bị Vi Phạm; hệ thống trả về Từ Chối khi một toán hạng yêu cầu hoặc công thức được ủy quyền không thể được thiết lập hoặc khi bộ giải trả về không biết. Các ràng buộc được đặt tên sao cho một vi phạm có thể đi kèm với một lõi không thể thỏa mãn xác định các ràng buộc nộp, công thức hoặc yêu cầu mâu thuẫn. Quyết định cuối cùng của bộ giải là xác định dựa trên các sự kiện đã được ghi nhận và tính toán được ủy quyền.

Phản hồi của người xác minh. Mỗi ràng buộc được đặt tên để việc kiểm tra không thành công có thể được truy nguyên đến giá trị nộp, điều kiện công thức hoặc giới hạn yêu cầu liên quan. Đối với một yêu cầu đã được xác minh, Bộ giải Z3 SMT trả về bằng chứng một cách logic để hỗ trợ kết quả. Đối với một yêu cầu bị vi phạm, nó xác định một tập hợp con mâu thuẫn của các ràng buộc về nộp, công thức và yêu cầu đã được đặt tên mà không thể tồn tại đồng thời, từ đó xác định nguồn gốc của lỗi. Giới hạn yêu cầu bị vi phạm còn cho biết liệu yêu cầu đó có làm quá hay làm thiếu giá trị đúng. Đối với Tránh, người xác minh cung cấp yêu cầu chính xác mà nó không thể xác lập, chẳng hạn như một công thức thiếu hoặc các sự kiện không thể được căn cứ trên việc nộp. Điều này cung cấp cho mô hình ngôn ngữ một mục tiêu cụ thể để sửa chữa.

[2]Sổ đăng ký tổng hợp các định nghĩa chỉ số tài chính suy ra từ tài liệu giảng dạy của Viện CFA.

Ví dụ khai báo XBRL. Báo cáo t
hu nhập

Câu hỏi. Tổng chi phí hoạt động của Apple trong năm tài chính 2025 là bao nhiêu?

CÔNG TY APPLE
BÁO CÁO TỔNG HỢP HOẠT ĐỘNG KINH DOANH
(triệu USD)

	Các năm tài chính kết thúc		
	2025	**2024**	**2023**
Doanh thu	416.161	391.035	383.285
Giá vốn hàng bán	220,960	210,352	214,137
Lợi nhuận gộp	**195,201**	**180,683**	**169,148**
Chi phí hoạt động:			
Nghiên cứu và phát triển	**34.550**	31.370	29.915
Bán hàng, chung và quản lý	**27.601**	26.097	24.932
Tổng chi phí hoạt động	***[đã bị che]***	**57.467**	**54.847**
Thu nhập từ hoạt động	**133.050**	**123,216**	**114,301**
Thu nhập (chi phí) phi hoạt động	321	269	565
Thu nhập trước thuế	132.729	123.485	113.736
Chi phí thuế thu nhập	20.719	29.749	16.741
Thu nhập ròng	**112,010**	**93,736**	**96,995**

đáp án vàng: 34,550 + 27,601 = 62,151 triệu

Hình 3: Một câu hỏi số liệu về báo cáo thu nhập trong hồ sơ XBRL: tổng phụ mục tiêu bị che mờ, và bảng hồ sơ hoàn chỉnh được sắp xếp lại thành một danh sách gọn gàng trong khi vẫn gi ữ nguyên tất cả các mục dòng và kỳ báo cáo.

4 Thiết lập Thí nghiệm

Để tách biệt sự khác nhau trong hiệu suất kiểm chứng, tất cả các phương pháp đều đánh giá cùng một tập các tuyên bố ứng viên cố định và bằng chứng được truy xuất. Việc tạo ứng viên được thực hiện một lần bằng Claude Haiku 4.5, và các câu trả lời ứng viên thu được được tái sử dụng mà không thay đổi cho Direct LLM, LLM Judge, J udge+Formula, Program-of-Thought, và VeriFin.

Do đó, sự khác biệt về việc chấp nhận sai, từ chối sai, độ chính xác, độ đúng và việc từ chối phản ánh hành vi của phương pháp xác minh hơn là sự khác biệt trong việc tạo ra ứng viên.

4.1 Bộ dữ liệu

XBRLFiling. Lấy cảm hứng từ việc FinQA sử dụng bằng chứng báo cáo tài chính và các chương trình suy luận có thể thực thi [4], XBRLFiling được xây dựng theo hướng ngược lại: thay vì viết câu hỏi rồi sau đó chú thích cách trả lời, chúng tôi bắt đầu từ một phép tính mà công ty tự khai báo trong hồ sơ của mình và tạo ra một câu hỏi mà phép tính đó trả lời. Chúng tôi thu thập 86 hồ sơ 10-K từ EDGAR [16] trên 28 công ty của Hoa Kỳ (bao gồm Apple, Microsoft, Amazon, Nvidia và Exxon Mobil) cho các năm tài chính 2021–2026.

Cùng với báo cáo tài chính của mình, mỗi hồ sơ XBRL đều công bố một liên kết cơ sở tính toán: một bản ghi có thể đọc bằng máy, nêu rõ dòng mục nào cộng với những dòng phụ nào, và với dấu hiệu nào. Chúng tôi cố định một bộ mục tiêu gồm 15 tổng phụ được báo cáo bao trùm ba báo cáo chính (lợi nhuận ròng, tài sản hiện tại, lợi nhuận từ hoạt động, v.v.). Đối với mỗi hồ sơ, chúng tôi lấy từng tổng phụ mục tiêu p mà cơ sở liên kết tính toán khai báo, đọc các dòng mục $\{c_1, \ldots, c_n\}$ mà nó nói là cấu thành p và dấu hiệu của chúng $w_i \in \{-1, +1\}$, và ghi nhận danh tính $p = \sum_{i=1}^{n} w_i c_i$ như sự thật cơ bản. Chỉ sau đó chúng tôi mới tạo ra câu hỏi, dựa trên một mẫu.

Statement	M	N	Metrics
Income	5	226	Net, pretax, and operating income; gross profit; operating expenses
Balance	7	279	Current/non-current assets and liabilities; total liabilities; shareholders' equity; net PP&E
Cash flow	3	95	Operating, investing, and financing cash flows

Table 1: XBRLFiling composition (N=600; 15 metrics). M denotes the number of metrics.

naming the company, fiscal year ρ, the subtotal's reported label, and the unit (e.g., *"What were Apple's FY2025 total operating expenses, in USD millions? Round to the nearest million."*). The gold answer is p's value as filed.

Evidence is the statement in which p is reported, rendered from the filing's own data: every line item the linkbase groups with p appears, in filed order, across three fiscal-year columns—the target year ρ and the two preceding it (see Figure 3). Each excerpt is headed by the company name, CIK, form, accession number, and unit scale. We blank out only p's cell for the target year, marking it `[redacted]` and leaving its components and all neighboring line items visible, so the answer must be computed rather than read off. Prior-year values are left intact: the figure directly beside the redaction is a plausible but wrong claim, so a model must select the right period as well as compute correctly.

Because each question is derived from a declared calculation rather than inferred from prose, every example carries signed operands and a gold value traceable to the filing itself—a machine-checkable link from evidence to claim. XBRLFiling comprises 600 questions across the 15 subtotals (Table 1).

FinanceBench. To test generality beyond our construction, we also evaluate on FinanceBench, a public benchmark of open-ended questions over real 10-K and 10-Q filings with human-annotated claims. We use its numeric subset of 67 questions[8].

4.2 Evaluated Models and Baselines

Answer Models. To evaluate verification robustness across diverse model capabilities, candidate claims are generated using six language models spanning different scales and architectures: frontier closed models (`GPT-5.5`, `Claude Haiku-4.5`), open-weight reasoning models (`Qwen3-30B`, `Llama-3.1-8B`, `Qwen2.5-7B`), and domain-specialized financial models (`Fin-o1-8B`). Evaluating across this spectrum ensures our results reflect verifier performance rather than specific generator biases. We served the open-weight claim models with vLLM, calling them through its OpenAI-compatible endpoint; weights were downloaded from HuggingFace. Claude Haiku 4.5 and GPT-5.5 were called through their respective APIs. All calls use temperature 0 and a 2048-token response limit.

Verification Baselines. For the verification baselines, we use Claude Haiku 4.5 as the verifier backbone. All methods evaluate the same fixed candidate claims and retrieved evidence; the candidate claim is not regenerated for any method.

- **Direct LLM.** Accepts every candidate claim without verification. This no-verification baseline quantifies the incorrect candidates that would enter the workflow in the absence of an acceptance control.
- **LLM judge.** The model receives the question, retrieved evidence, and fixed candidate claim, and predicts whether the claim should be accepted as correct.
- **Judge+formula.** The same judge additionally receives the authoritative formula and grounded operand values used by VeriFin. This baseline tests whether access to the correct computation is sufficient for an LLM to enforce it reliably.
- **Program-of-Thought (PoT).** The model generates a Python program intended to compute the requested quantity from the supplied evidence. The program is executed, and its numerical output is compared using the baseline numerical-matching rule defined below

Inference and numerical matching. Program-of-Thought returns Abstain when its generated program fails to execute or does not produce numerical values. For numerical comparison, the baselines accept a candidate value y when $|y-\hat{y}| \le \max(0.01|\hat{y}|,\ 1.0)$, where $\hat{y}$ is the value computed by the baseline. We use this tolerance to avoid treating minor rounding and numerical-formatting differences as substantive verification errors. VeriFin uses the tolerance defined in §3.6.

Metrics. Each claim is correct or incorrect, and each verifier accepts, rejects, or abstains, yielding true accepts (TA), false accepts (FA), true rejects (TR), false rejects (FR), and abstentions (Abs) over n questions. We report FA; accepted claim precision $\mathrm{TA}/(\mathrm{TA}+\mathrm{FA})$; accuracy $(\mathrm{TA}+\mathrm{TR})/(\mathrm{TA}+\mathrm{FA}+\mathrm{TR}+\mathrm{FR})$; abstention Abs/n; and coverage $(\mathrm{TA}+\mathrm{FA}+\mathrm{TR}+\mathrm{FR})/n = 1-\mathrm{Abs}/n$, the fraction receiving a non-abstaining verdict. For repair, we report recovery among true catches of wrong claims generated by the LLM: naive repair uses one generic retry, pass@1 evaluates the first verifier-guided recovery, and pass@3 counts recovery by at least one of up to three guided attempts. We report both recovery rates and recovered/scored counts.

4.3 Repair Setup

Beyond binary acceptance filtering, we evaluate whether verifier diagnostic feedback enables an answer generator to correct a rejected numerical claim. Critically, automated repair requires pinpointing the exact logical source of failure—a diagnostic capability unique to symbolic verification. Standard evaluation paradigms cannot produce targeted repair signals: an LLM judge emits unconstrained natural-language critiques vulnerable to hallucinated error causes, while Program-of-Thought (PoT) yields only binary execution checks or numerical mismatches without isolating which operand, unit, period, or formula caused the failure.

In contrast, when VeriFin identifies a Violated claim, the SMT solver Z3 extracts an *unsatisfiable core* (UNSAT core): the set of logical constraints that cannot hold simultaneously. This mathematically isolates the explicit conflict between filed XBRL values, authorized arithmetic relations, and candidate claim bounds.

We evaluate repair performance exclusively on *true catches*—cases where the initial candidate claim is incorrect and VeriFin returns Violated. Gold answers are used solely offline to identify

Tuyên bố M		Chỉ số N	
Thu nhập	5	226	Thu nhập ròng, trước thuế và hoạt động; lợi nhuận gộp; chi phí hoạt động
Cân bằng	7	279	Tài sản và nợ phải trả ngắn hạn/dài hạn; tổng nợ phải trả; vốn cổ đông; tài sản cố định ròng
Dòng tiền	3	95	Dòng tiền từ hoạt động kinh doanh, đầu tư và tài chính

Bảng 1: Thành phần nộp XBRL (N=600; 15 chỉ số). M biểu thị số lượng chỉ số.

đặt tên công ty, năm tài chính ρ, nhãn báo cáo của tổng phụ, và đơn vị (ví dụ: "Chi phí hoạt động tổng cộng của Apple trong năm tài chính 2025 là bao nhiêu, tính bằng triệu USD? Làm tròn đến triệu gần nhất."). Câu trả lời chính xác là giá trị của p theo hồ sơ nộp.

Bằng chứng là tuyên bố trong đó p được báo cáo, được trình bày từ dữ liệu của hồ sơ: mọi mục dòng mà liên kết cơ sở nhóm với p x uất hiện, theo thứ tự đã nộp, trên ba cột năm tài chính — năm mục tiêu ρ và hai năm trước đó (xem Hình 3). Mỗi trích đoạn được đặt tiêu đề bằng tên công ty, CIK, mẫu, số đăng ký và đơn vị đo lường. Chúng tôi chỉ làm trống ô của p cho năm mục tiêu, đánh dấu nó là `[` được biên tập`]` và để các thành phần của nó cùng tất cả các mục dòng lân cận hiển thị, vì vậy câu trả lời phải được tính toán thay vì đọc trực tiếp. Các giá trị của năm trước được giữ nguyên: con số ngay bên cạnh chỗ biên tập là một tuyên bố hợp lý nhưng sai, vì vậy mô hình phải chọn đúng kỳ cũng như tính toán chính xác.

Bởi vì mỗi câu hỏi được nhận từ một phép tính đã được khai báo thay vì suy ra từ văn bản, mỗi ví dụ đều mang các toán hạng có dấu và một giá trị vàng có thể truy nguyên đến chính hồ sơ — một liên kết có thể kiểm tra bằng máy từ bằng chứng đến yêu cầu. Hồ sơ XBRL bao gồm 600 câu hỏi trên 15 tổng phụ (Bảng 1).

FinanceBench. Để kiểm tra tính tổng quát vượt ra ngoài cách xây dựng của chúng tôi, chúng tôi cũng đánh giá trên FinanceBench, một chuẩn công khai gồm các câu hỏi mở dựa trên các hồ sơ 10-K và 10-Q thực tế với các khẳng định được chú thích bởi con người. Chúng tôi sử dụng tập hợp số học của nó gồm 67 câu hỏi[8].

4.2 Các Mô Hình và Tiêu Chuẩn Đánh Giá

Mô hình trả lời. Để đánh giá độ bền xác minh trên các khả năng mô hình khác nhau, các tuyên bố ứng viên được tạo ra bằng sáu mô hình ngôn ngữ có quy mô và kiến trúc khác nhau: các mô hình đóng cao cấp (GPT-5.5, Claude Haiku-4.5), các mô hình suy luận mở (Qwen3-30B, Llama-3.1-8B, Qwen2.5-7B), và các mô hình chuyên môn tài chính (Fin-o1-8B). Việc đánh giá trên toàn bộ phổ này đảm bảo kết quả của chúng tôi phản ánh hiệu suất của bộ xác minh thay vì thiên lệch của người tạo cụ thể. Chúng tôi phục vụ các mô hình tuyên bố mở bằng vLLM, gọi chúng thông qua điểm cuối tương thích với OpenAI; các trọng số được tải xuống từ HuggingFace. Claude Haiku 4.5 và GPT-5.5 được gọi thông qua API tương ứng của chúng. Tất cả c ác lần gọi đều sử dụng nhiệt độ 0 và giới hạn phản hồi 2048 token.

Các đường cơ sở xác minh. Đối với các đường cơ sở xác minh, chúng tôi sử dụng Claude Haiku 4.5 làm lõi xác minh. Tất cả các phương pháp đánh giá cùng các yêu cầu ứng viên cố định và bằng chứng được truy xuất; yêu cầu ứng viên không được tạo lại cho bất kỳ phương pháp nào.

• LLM Trực tiếp. Chấp nhận mọi tuyên bố ứng viên mà không kiểm tra. Cơ sở không kiểm tra này định lượng các sai sót các ứng viên sẽ vào quy trình làm việc nếu không có kiểm soát chấp nhận.

Trọng tài LLM. Mô hình nhận câu hỏi, bằng chứng được truy xuất và tuyên bố ứng viên cố định, và dự đoán liệu tuyên bố đó có nên được chấp nhận là chính xác hay không.

Công thức • Judge+. Vị thẩm phán cùng lúc nhận được công thức có thẩ m quyền và các giá trị toán hạng cơ sở được VeriFin sử dụng. Thử nghiệm cơ bản này kiểm tra xem việc truy cập vào phép tính chính xác có đủ để một LLM thực thi nó một cách đáng tin cậy hay không.

• Chương trình-Suy nghĩ (PoT). Mô hình tạo ra một chương trình Python nhằm tính toán lượng được yêu cầu từ bằng chứng cung cấp. Chương trình được thực thi, và kết quả số của nó được so sánh bằng cách sử dụng quy tắc so khớp số cơ bản được định nghĩa dưới đây

Suy luận và so khớp số. Chương trình-nhận thức sẽ trả về Từ chối khi chương trình được tạo không thể thực thi hoặc không tạo ra giá t rị số. Đối với so sánh số, các đường cơ sở chấp nhận một giá trị ứng viên y khi $|y-\hat{y}| \le \max(0.01|\hat{y}|, 1.0)$, trong đó $\hat{y}$ là giá trị tính toán bởi đường cơ sở. Chúng tôi sử dụng độ dung sai này để tránh việc coi những khác biệt nhỏ về làm tròn và định dạng số là lỗi xác minh quan trọng. VeriFin sử dụng độ dung sai được định nghĩa trong §3.6.

Các chỉ số. Mỗi một tuyên bố là đúng hoặc sai, và mỗi người xác minh có thể chấp nhận, từ chối hoặc không quyết định, tạo ra các chấp nhận đúng (TA), chấp nhận sai (FA), từ chối đúng (TR), từ chối sai (FR) và không quyết định (Abs) trên n câu hỏi. Chúng tôi báo cáo FA; độ chính xác của các tuyên bố được chấp nhận TA/(TA +FA); độ chính xác tổng thể (TA + TR)/(TA + FA + TR + FR); tỷ lệ không quyết định Abs/n; và độ bao phủ (TA + FA + TR + FR)/n = 1 − Abs/n, phần nhận được một phán quyết không phải là không quyết định. Đối với việc sửa chữa, chúng tôi báo cáo việc phục hồi trong số các lỗi tuyên bố thực sự được phát hiện bởi LLM: sửa chữa đơn giản sử dụng một lần thử lại chung, pass@1 đánh giá lần phục hồi đầu tiên do người xác minh hướng dẫn, và pass@3 tính số lượng phục hồi bởi ít nhất một trong tối đa ba lần thử được hướng dẫn. Chúng tôi báo cáo cả tỷ l ệ phục hồi và số lượng được phục hồi/đánh giá.

4.3 Cài đặt sửa chữa

Ngoài việc lọc chấp nhận nhị phân, chúng tôi đánh giá liệu phản hồi chẩn đoán của bộ xác minh có giúp một bộ tạo câu trả lời sửa chữa một tuyên bố số bị từ chối hay không. Quan trọng là, việc sửa chữa tự động đòi hỏi xác định chính xác nguồn gốc logic của sự thất bại—một khả năng chẩn đoán độc đáo của xác minh biểu tượng. Các mô hình đánh giá tiêu chuẩn không thể cung cấp tín hiệu sửa chữa cụ thể: một trọng tài LLM phát ra các nhận xét bằng ngôn ngữ tự nhiên không bị ràng buộc, dễ bị các nguyên nhân lỗi tưởng tượng, trong khi Chương trình Tư duy (PoT) chỉ cung cấp kiểm tra thực thi nhị phân hoặc sai lệch số học mà không xác định được toán hạng, đơn vị, kỳ hạn, hay công thức nào gây ra lỗi đó.

Ngược lại, khi VeriFin phát hiện một yêu cầu bị vi phạm, trình giải SMT Z3 trích xuất một lõi không thể thỏa mãn (lõi UNSAT): tập hợp các ràng buộc logic không thể đồng thời tồn tại. Điều này về mặt toán học cô lập xung đột rõ ràng giữa các giá trị XBRL đã nộp, các quan hệ số học được ủy quyền và các giới hạn của yêu cầu ứng viên.

Chúng tôi đánh giá hiệu suất sửa chữa chỉ trên các lần phát hiện đúng — những trường hợp mà yêu cầu ứng viên ban đầu là sai và VeriFin trả về Violated. Các câu trả lời chuẩn chỉ được sử dụng ngoại tuyến để xác định

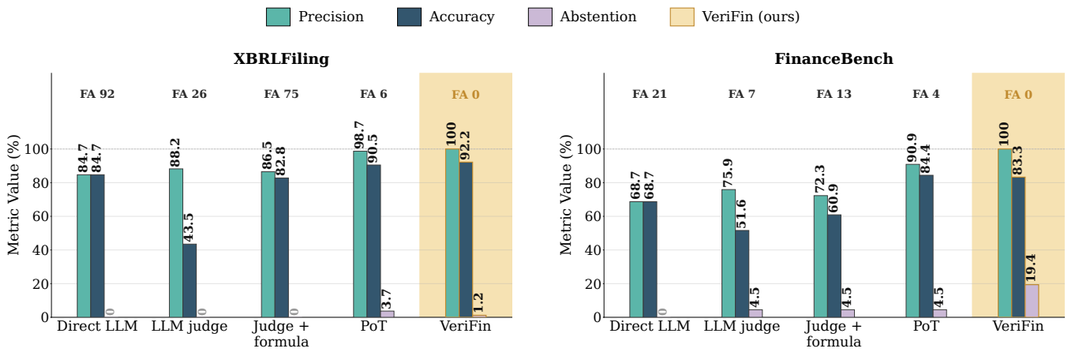


Figure 4: Verification performance on XBRLFiling (n=600) and FinanceBench (n=67) for a fixed set of candidate claims generated by Claude Haiku 4.5. Bars report accepted-claim precision, accuracy, and abstention rate; labels above the bars report false-accept counts. VeriFin is the only evaluated method with zero false accepts on both datasets. On XBRLFiling, this result is achieved at 98.8% coverage; on FinanceBench, coverage falls to 80.6%, exposing the trade-off between false-accept control and verification coverage.

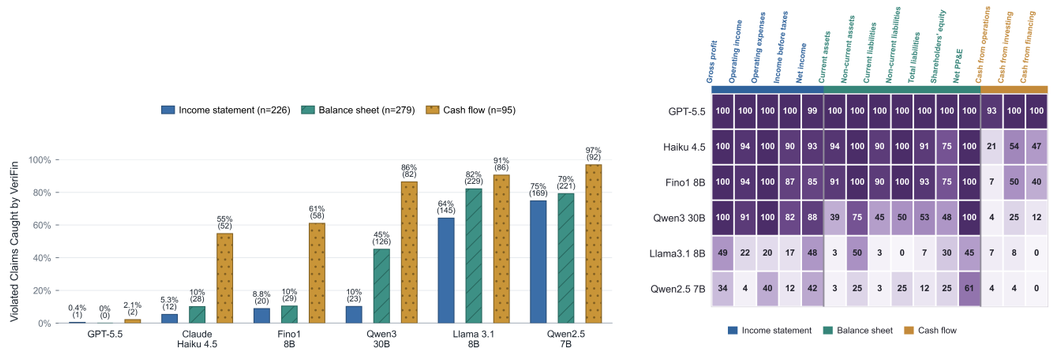


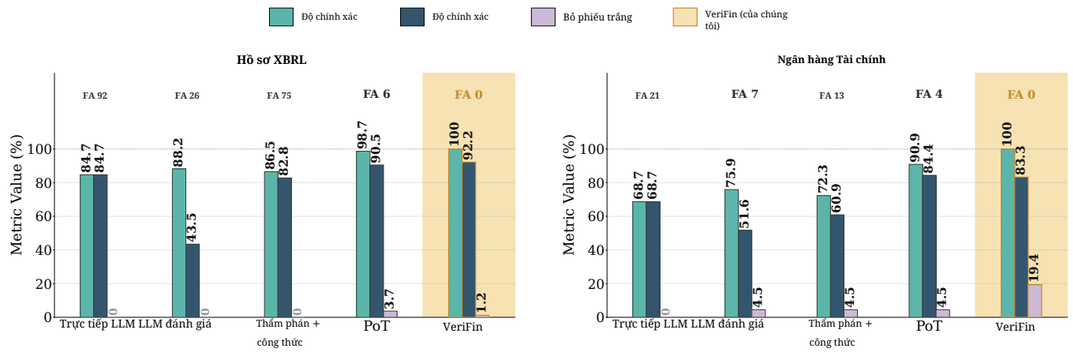
Figure 5: Left: Percentage of incorrect claims generated by each LLM and rejected by VeriFin. Right: Candidate-answer accuracy by requested line item on XBRLFiling. Generator errors are strongly metric-dependent. Cash-flow subtotals remain difficult for most evaluated models, while every incorrect candidate represented in the left panel is rejected by VeriFin.

true catches and score revised claims. Within each model-dataset setting, we compare two repair conditions:

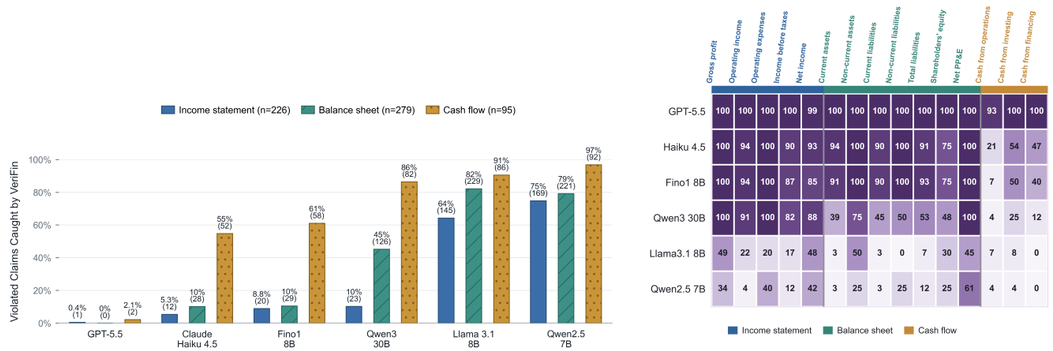
- **Naive Repair.** The model receives the original question, filing evidence, and previous candidate, together with generic feedback stating that the claim is incorrect and requesting a revised calculation.
- **Verifier-Guided Repair.** The model receives the same inputs together with structured diagnostic feedback derived from the named constraints in the solver's unsatisfiable core. The feedback identifies the filed values, financial line-item roles, authorized arithmetic relation, and claim constraint that cannot hold simultaneously.

Within each model–dataset setting, both conditions use the same repair backbone and filing evidence.

A revised candidate is never accepted directly from the repair model. Each repaired claim is submitted to the same verification pipeline as the original candidate, using the same grounded facts, authorized computation, and reporting tolerance. A case is counted as recovered only when the revised numerical claim matches the gold answer and receives a Verified verdict. A repaired output



Hình 4: Hiệu suất xác minh trên XBRLFiling (n=600) và FinanceBench (n=67) đối với một tập cố định các tuyên bố ứng viên được tạo bởi Claude Haiku 4.5. Các cột báo cáo độ chính xác của các tuyên bố được chấp nhận, độ chính xác tổng thể và tỷ lệ từ chối; các nhãn phía tr ên các cột báo cáo số lượng chấp nhận sai. VeriFin là phương pháp duy nhất được đánh giá có số lần chấp nhận sai bằng không trên cả hai bộ dữ liệu. Trên XBRLFiling, kết quả này đạt được ở mức bao phủ 98,8%; trên FinanceBench, mức bao phủ giảm xuống còn 80,6%, cho t hấy sự đánh đổi giữa kiểm soát chấp nhận sai và độ bao phủ xác minh.



Hình 5: Bên trái: Tỷ lệ các tuyên bố sai được tạo ra bởi mỗi LLM và bị VeriFin từ chối. Bên phải: Độ chính xác của câu trả lời ứng viên theo mục yêu cầu trên XBRLFiling. Lỗi của bộ tạo phụ thuộc mạnh vào chỉ số. Các tổng phụ dòng tiền vẫn khó đối với hầu hết các mô hình đ ược đánh giá, trong khi mọi ứng viên sai được thể hiện ở bảng bên trái đều bị VeriFin từ chối.

bất thực và sửa các yêu cầu đã được điều chỉnh. Trong mỗi thiết lập mô hình-dữ liệu, chúng tôi so sánh hai điều kiện sửa chữa:

- Sửa chữa ngây thơ. Mô hình nhận câu hỏi gốc, fil
  bằng chứng, và ứng viên trước đó, cùng với phản hồi chung nêu rằng tuyên bố là không chính xác và yêu cầu tính toán lại.
- Sửa chữa do Người kiểm tra hướng dẫn. Mô hình nhận cùng một đầu vào cùng với phản hồi chẩn đoán có cấu trúc được lấy từ các ràng buộc đã đặt tên trong lõi không thể thỏa mãn của bộ giải. Phản hồi xác định các giá trị đã nộp, mục dòng tài chính vai trò, quan hệ số học được ủy quyền, và ràng buộc yêu cầu không thể cùng tồn tại đồng thời.

Trong mỗi cài đặt mô hình–dữ liệu, cả hai điều kiện đều sử dụng cùng một xương sống sửa chữa và bằng chứng hỗ sơ.

Một ứng viên được sửa đổi không bao giờ được chấp nhận trực tiếp từ mô hình sửa chữa. Mỗi yêu cầu đã được sửa chữa đều được gửi đến cùng một quy trình xác minh như ứng viên gốc, sử dụng cùng các dữ kiện cơ sở, tính toán được ủy quyền và dung sai báo cáo. Một trường hợp chỉ được tính là phục hồi khi yêu cầu số đã sửa khớp với câu trả lời chuẩn và nhận được phán quyết Đã Xác Minh. Một kết quả đã được sửa chữa

that remains inconsistent, produces an ABSTAIN verdict, or does not contain a checkable numerical claim is counted as unsuccessful.

Because the repair conditions were run end-to-end, the number of scored true catches varies slightly across conditions due to generation nondeterminism. We therefore report both recovery rates and recovered/scored counts in Table 3; differences between conditions are interpreted descriptively rather than as paired estimates.

5 Results and Discussion

All verification methods evaluate the same fixed candidate claims and retrieved evidence. False-accept counts, false rejects, precision, accuracy, and abstention are therefore directly comparable across Direct LLM, LLM Judge, Judge+Formula, Program-of-Thought, and VERIFIN. For VERIFIN, verification requires 4–6 LLM calls and 12k–17k tokens per question, taking 3–9 seconds on average. Symbolic checking adds negligible overhead: Z3 takes a median of 5 ms, less than 0.2% of total processing time.

5.1 Verification Performance

Symbolic enforcement changes the model's error profile. On XBRL-FILING, VERIFIN rejects all 92 incorrect candidates in this evaluation, while returning a decision on 593 of 600 cases. Its zero observed false accepts are therefore not explained by blanket abstention: coverage remains 98.8%. PoT substantially reduces false acceptance relative to the LLM-based judges, but still admits six incorrect claims. This residual error shows that executable arithmetic alone does not guarantee conformance to the intended financial specification.

XBRLFILING. Figure 4 reports verification performance on the fixed Claude Haiku 4.5 candidate pool shared by all methods. Of the 600 candidate claims, 92 are incorrect. VERIFIN returns a decision on 593 questions. Among these decided cases, it accepts 455 correct claims, rejects 46 correct claims, and correctly rejects all 92 incorrect claims; it abstains on the remaining 7 questions. Thus, VERIFIN accepts none of the incorrect claims on which it returns a decision. VERIFIN achieves 100% accepted-claim precision, 92.2% accuracy, and 98.8% coverage.

FinanceBench. FinanceBench evaluates VERIFIN on a broader set of financial calculations that are not constructed from XBRL calculation-linkbase relationships. VERIFIN returns a decision on 54 of the 67 questions. Among these decided cases, it accepts 28 correct claims, rejects 9 correct claims, and correctly rejects 17 incorrect claims. VERIFIN abstains on the remaining 13 questions.

VERIFIN therefore achieves 100% accepted-claim precision, 83.3% accuracy, and 80.6% coverage. The lower coverage reflects the intended safety–coverage trade-off: when the required facts or computation cannot be established unambiguously, the system declines to verify the claim rather than relying on a model-generated interpretation. Z3 returns UNKNOWN on none of the evaluated instances; every constructed constraint system is decided as satisfiable or unsatisfiable. Abstentions arise before the solver is reached, when a required operand cannot be grounded, or no source authorizes a formula, rather than from an inability to decide the generated constraints.

We also observe a larger coverage cost on this broader benchmark. Four of the 67 generator outputs do not contain a valid numerical claim, causing VERIFIN to abstain before verification. Among the remaining 63 checkable claims, VERIFIN abstains on nine because it cannot establish a complete and unambiguous verification plan. The verifier's abstention rate is therefore 14.3% over checkable claims, while end-to-end coverage is 80.6% over all 67 questions. This illustrates the intended FA–abstention trade-off: when the required facts or computation cannot be authorized, VERIFIN declines to verify the claim rather than relying on a model-generated interpretation.

We observe that providing financial context during prompting as linguistic context is not equivalent to enforcing it. Judge+Formula receives the supported formula used by VERIFIN, yet accepts 75 of the 92 incorrect XBRLFILING claims. VERIFIN instead encodes that information as hard constraints and accepts none.

5.2 Robustness Across Models

Table 2 evaluates VERIFIN on candidate numerical claims produced by six answer models with different error profiles. Across all twelve model–dataset settings, we observe zero false accepts and 100% accepted-claim precision. On XBRLFILING, coverage ranges from 97.3% to 100.0%; on FinanceBench, it ranges from 49.3% to 82.1%.

The difficulty of financial question answering is strongly metric-dependent. Figure 5 shows that several models perform well on common income-statement subtotals but fail frequently on cash-flow calculations. Claude Haiku reaches 21% accuracy on operating cash flow and Fin-o1-8B reaches 7%, despite both exceeding 85% on several income-statement metrics. Qwen3 shows a similar gap, with 4% accuracy on operating cash flow but 82–100% on several income-statement measures. We find that the principal remaining cost is the conservative handling of correct claims. Depending on the answer-generating model, VERIFIN rejects between 37 and 73 correct claims. A correct numerical claim may therefore still be declined when the Claim Verifier cannot establish that it follows from the grounded filing facts and authorized computation. Improving correct-claim retention without weakening false-accept control remains the main coverage challenge we will address in future work.

Overall, we find that whenever VERIFIN establishes the required computation, none of the incorrect candidate claims in our evaluations are accepted. The results support deterministic verification as a practical control for LLM-based financial analysis, while also making its coverage cost explicit.

5.3 Verifier-Guided Repair

Table 3 reports recovery metrics among true catches. Generic retry repairs only a small fraction of rejected claims across all models, indicating that most financial reasoning failures are structural rather than simple slips that resolve upon re-prompting. Verifier-guided feedback substantially improves recovery by providing the model with explicit context regarding the logical conflict. On XBRL-FILING, pass@1 repair increases recovery from 6.5% to 46.3% for Qwen3-30B, from 26.1% to 57.0% for Fin-o1-8B, and from 23.1% to 40.5% for Claude Haiku. Allowing three independent attempts (pass@3) yields further recovery gains, reaching 69.9% for Fin-o1-8B on XBRLFILING and 50.0% for Qwen3-30B on FinanceBench.

điều đó vẫn không nhất quán, đưa ra phán quyết Bỏ phiếu hoặc không chứa tuyên bố số có thể kiểm tra được sẽ được tính là không thành công.

Bởi vì các điều kiện sửa chữa được thực hiện từ đầu đến cuối, số lượng các lần bắt đúng được ghi điểm thay đổi nhẹ giữa các điều kiện do tính không xác định khi tạo. Do đó, chúng tôi báo cáo cả tỷ lệ phục hồi và số liệu phục hồi/được ghi điểm trong Bảng 3; sự khác biệt giữa các điều kiện được diễn giải theo cách mô tả hơn là như các ước l ượng ghép đôi.

5 Kết quả và Thảo luận

Tất cả các phương pháp xác minh đánh giá cùng một các yêu cầu ứng viên và chứng cứ truy xuất được cố định. Các số liệu chấp nhận sai, từ chối sai, độ chính xác, hiệu quả và việc từ chối trả lời do đó có thể so sánh trực tiếp giữa Direct LLM, LLM Judge, Judge+Formula, Program-of-Thought và VeriFin. Đối với VeriFin, việc xác minh yêu cầu 4–6 lần gọi LLM và 12k–17k token cho mỗi câu hỏi, mất trung bình 3–9 giây. Kiểm tra theo phương pháp ký hiệu thêm một chi phí không đáng kể: Z3 mất trung vị 5ms, chiếm dưới 0,2% tổng thời gian xử lý.

5.1 Hiệu suất xác minh

Việc thực thi theo ký hiệu thay đổi hồ sơ lỗi của mô hình. Trên XBRL-Filing, VeriFin từ chối tất cả 92 ứng viên không chính xác trong đánh giá này, đồng thời đưa ra quyết định cho 593 trên 600 trường hợp. Do đó, việc không quan sát thấy bất kỳ chấp nhận sai nào của nó không thể giải thích bằng việc từ chối tổng quát: độ bao phủ vẫn đạt 98,8%. PoT giảm đáng kể việc chấp nhận sai so với các trọng tài dựa trên LLM, nhưng vẫn chấp nhận sáu tuyên bố không chính xác. Lỗi tồn dư này cho thấy rằng việc tính toán số học có thể thực thi một mình không đảm bảo tuân thủ các đặc tả tài chính dự kiến.

Lập hồ sơ XBRL. Hình 4 báo cáo hiệu quả xác minh trên tập hợp ứng viên Claude Haiku 4.5 cố định được tất cả các phương pháp chia sẻ. Trong số 600 tuyên bố ứng viên, có 92 tuyên bố là không chính xác. VeriFin đưa ra quyết định về 593 câu hỏi. Trong số các trường hợp đã được quyết định này, nó chấp nhận 455 tuyên bố đúng, từ chối 46 tuyên bố đúng, và từ chối chính xác tất cả 92 tuyên bố không đúng; nó không đưa ra quyết định cho 7 câu hỏi còn lại. Do đó, VeriFin không chấp nhận bất kỳ tuyên bố không đúng nào mà nó đã ra quyết định. VeriFin đạt độ chính xác 100% cho các tuyên bố được chấp nhận, độ chính xác tổng thể 92,2% và độ bao phủ 98,8%.

FinanceBench. FinanceBench đánh giá VeriFin trên một tập hợp rộng hơn các phép tính tài chính mà không được xây dựng từ các mối quan hệ calculation-linkbase XBRL. VeriFin đưa ra quyết định cho 54 trong số 67 câu hỏi. Trong số các trường hợp đã được quyết định này, nó chấp nhận 28 yêu cầu đúng, từ chối 9 yêu cầu đúng, và từ chối chính xác 17 yêu cầu sai. VeriFin không đưa ra quyết định về 13 câu hỏi còn lại.

Do đó, VeriFin đạt được độ chính xác 100% đối với các tuyên bố được chấp nhận, 83,3% độ chính xác và 80,6% độ bao phủ. Độ bao phủ thấp hơn phản ánh sự đánh đổi an toàn–bao phủ như dự kiến: khi các sự kiện hoặc phép tính cần thiết không thể được xác lập một cách rõ ràng, hệ thống từ chối xác minh tuyên bố thay vì dựa vào một diễn giải do mô hình tạo ra. Z3 không trả về 'không biết' đối với bất kỳ trường hợp nào đã được đánh giá; mọi hệ thống ràng buộc được tạo ra đều được quyết định là có thể thỏa mãn hoặc không thể thỏa mãn. Việc từ chối xảy ra trước khi trình giải được tiếp cận, khi một toán hạng cần thiết không thể được xác lập, hoặc không có nguồn nào cho phép một công thức, thay vì từ sự không khả năng quyết định các ràng buộc được tạo ra.

Chúng tôi cũng quan sát thấy chi phí bao phủ lớn hơn trên bộ chuẩn rộng này. Bốn trong số 67 đầu ra của máy phát điện không chứa một tuyên bố số hợp lệ, khiến VeriFin phải từ chối trước khi xác minh. Trong số 63 tuyên bố có thể kiểm tra còn lại, VeriFin từ chối chín trường hợp vì nó không thể thiết lập một kế hoạch xác minh hoàn chỉnh và rõ ràng. Do đó, tỷ lệ từ chối của hệ thống kiểm chứng là 14,3% trên các tuyên bố có thể kiểm tra, trong khi mức bao phủ đầu cuối là 80,6% trên tất cả 67 câu hỏi. Điều này minh họa sự cân bằng FA–từ chối mà hệ thống hướng tới: khi các dữ kiện hoặc phép tính cầ n thiết không thể được chấp thuận, VeriFin từ chối xác minh tuyên bố thay vì dựa vào một diễn giải do mô hình tạo ra.

Chúng tôi quan sát thấy rằng việc cung cấp bối cảnh tài chính trong khi gợi ý như bối cảnh ngôn ngữ không tương đương với việc áp đặt nó. Công thức Judge+ nhận công thức hỗ trợ được VeriFin sử dụng, nhưng vẫn chấp nhận 75 trong số 92 tuyên bố XBRL Filing sai. Thay vào đó, VeriFin mã hóa thông tin đó như các ràng buộc cứng và không chấp nhận tuyên bố nào.

5.2 Độ bền vững giữa các mô hình

Bảng 2 đánh giá VeriFin trên các tuyên bố số liệu ứng viên được tạo ra bởi sáu mô hình trả lời với các hồ sơ lỗi khác nhau. Trong tất cả mười hai cài đặt mô hình–bộ dữ liệu, chúng tôi quan sát thấy không có chấp nhận sai nào và độ chính xác của các tuyên bố được chấp nhận là 100%. Trên XBRLFiling, phạm vi bao phủ từ 97,3% đến 100,0%; trên FinanceBench, nó dao động từ 49,3% đến 82,1%.

Độ khó của việc trả lời các câu hỏi tài chính phụ thuộc mạnh mẽ vào chỉ số đo lường. Hình 5 cho thấy một số mô hình hoạt động tốt trên các tổng phụ phổ biến của báo cáo thu nhập nhưng thường thất bại trong các tính toán dòng tiền. Claude Haiku đạt độ chính xác 21% trên dòng tiền hoạt động và Fin-o1-8B đạt 7%, mặc dù cả hai đều vượt quá 85% trên một số chỉ số báo cáo thu nhập. Qwen3 cho thấy một khoảng cách tương tự, với độ chính xác 4% trên dòng tiền hoạt động nhưng 82–100% trên một số chỉ số báo cáo thu nhập. Chúng tôi thấy rằng chi phí chính còn lại là việc xử lý thận trọng các tuyên bố đúng. Tùy thuộc vào mô hình tạo câu trả lời, VeriFin từ chối từ 37 đến 73 tuyên bố đúng. Do đó, một tuyên bố số đúng vẫn có thể bị từ chối khi Bộ xác minh Tuyên bố không thể xác nhận rằng nó dựa trên các dữ kiện nộp hồ sơ có cơ sở và tính toán được phép. Cải thiện việc giữ lại các tuyên bố đúng mà không làm suy yếu kiểm soát chấp nhận sai vẫn là thách thức phủ sóng chính mà chúng tôi sẽ giải quyết trong công việc tương lai.

Nhìn chung, chúng tôi nhận thấy rằng bất cứ khi nào VeriFin t hiết lập phép tính cần thiết, không có bất kỳ tuyên bố ứng viên sai nào trong các đánh giá của chúng tôi được chấp nhận. Các kết quả này ủng hộ việc xác minh xác định như một biện pháp kiểm soát thực tiễn cho phân tích tài chính dựa trên LLM, đồng thời cũng làm rõ chi phí bao phủ của nó.

5.3 Sửa chữa theo hướng kiểm chứng

Bảng 3 báo cáo các chỉ số hồi phục trong số các kết quả bắt đúng. Việc sửa lỗi bằng cách thử lại chung chỉ khắc phục một phần nhỏ các yêu cầu bị từ chối trên tất cả các mô hình, cho thấy hầu hết các thất bại trong lý luận tài chính là do cấu trúc chứ không phải là các lỗi đơn giản có thể được giải quyết khi yêu cầu lại. Phản hồi hướng dẫn bởi trình xác minh cải thiện đáng kể khả năng hồi phục bằng cách cung cấp cho mô hình bối cảnh rõ ràng liên quan đến mâu thuẫn logic. Trên XBRL-Filing, sửa lỗi pass@1 làm tăng khả năng hồi phục từ 6,5% lên 46,3% cho Qwen3-30B, từ 26,1% lên 57,0% cho Fin-o1-8B, và từ 23,1% lên 40,5% cho Claude Haiku. Cho phép ba lần thử độc lập (pass@3) mang lại mức hồi phục cao hơn nữa, đạt 69,9% cho Fin-o1-8B trên XBRL-Filing và 50,0% cho Qwen3-30B trên FinanceBench.

	XBRLFiling (n=600)							FinanceBench (n=67)						
Claim model	TA	FA ↓	FR	Abs	Prec.	Acc.	Cov.	TA	FA ↓	FR	Abs	Prec.	Acc.	Cov.
Qwen2.5-7B	35	0	73	10	100.0	87.6	98.3	10	0	7	34	100.0	78.8	49.3
Llama-3.1-8B	74	0	50	16	100.0	91.4	97.3	10	0	13	28	100.0	66.7	58.2
Qwen3-30B	245	0	69	0	100.0	88.5	100.0	24	0	10	15	100.0	80.8	77.6
Fin-o1-8B	436	0	49	8	100.0	91.7	98.7	32	0	9	12	100.0	83.6	82.1
Claude Haiku 4.5	455	0	46	7	100.0	92.2	98.8	28	0	9	13	100.0	83.3	80.6
GPT-5.5	560	0	37	0	100.0	93.8	100.0	35	0	10	12	100.0	81.8	82.1

Table 2: VeriFin performance across six answer-generator models. TA/FA/FR/Abs are counts; Prec./Acc./Cov. are percentages. True rejects are omitted for space and recoverable as $n -$ (TA + FA + FR + Abs).

Backbone	Naive Repair Recovery	Verifier-Guided Repair			
		pass@1		pass@3	
		Recovery	Δ	Recovery	Δ
XBRLFiling					
Qwen3-30B	6.5 (15/230)	46.3 (107/231)	+39.8	47.7 (113/237)	+1.4
Fin-o1-8B	26.1 (29/111)	57.0 (61/107)	+30.9	69.9 (79/113)	+12.9
Claude Haiku 4.5	23.1 (9/39)	40.5 (17/42)	+17.4	55.6 (25/45)	+15.1
FinanceBench					
Qwen3-30B	0.0 (0/16)	37.5 (6/16)	+37.5	50.0 (9/18)	+12.5
Fin-o1-8B	0.0 (0/11)	0.0 (0/12)	+0.0	9.1 (1/11)	+9.1
Claude Haiku 4.5	0.0 (0/11)	10.0 (1/10)	+10.0	20.0 (2/10)	+10.0

Table 3: Recovery rate (%) among true catches, with recovered/scored counts shown in parentheses. *Naive Repair* uses one generic retry. Verifier-guided pass@1 uses one attempt with solver-derived diagnostic feedback, while pass@3 allows up to three independent guided attempts.

The benefit of verifier feedback lies in identifying what must change, rather than merely reporting that the claim is wrong. Generic retries recover few true catches, whereas named conflicts identify the relevant filed values, line-item roles, formula, and candidate bound. This structured feedback improves pass@1 recovery by as much as 39.8%. These findings highlight the diagnostic utility of SMT-based verification in financial workflows. Beyond binary filtering, the verifier uses UNSAT cores as targeted repair signals to recover otherwise rejected claims.

6 Conclusion

In this work, we introduced VeriFin, a neurosymbolic framework for verifying numerical claims generated by LLMs. VeriFin separates claim generation from verification: language models propose answers and verification plans, while filed XBRL facts, source-backed formulas, and an SMT solver determine whether a claim should be accepted. Experiments on XBRLFiling and FinanceBench show that this design produced zero observed false accepts in our evaluations across multiple answer models, while maintaining high coverage on the structured benchmark. Comparisons with LLM judges and Program-of-Thought further show that access to the correct operands and formula is not sufficient unless they are enforced as hard constraints. Solver-derived diagnostics also improve repair of rejected claims. These results suggest that reliable financial question-answering systems should be built around independently grounded, executable verification rather than model-based plausibility judgments.

References

[1] Adewale Akinfaderin and Shreyas Subramanian. 2025. VERAFI: Verified Agentic Financial Intelligence through Neurosymbolic Policy Generation. *arXiv preprint arXiv:2512.14744* (2025).

[2] Sam Bayless, Stefano Buliani, Darion Cassel, Byron Cook, Duncan Clough, Rémi Delmas, Nafi Diallo, Ferhat Erata, Nick Feng, Dimitra Giannakopoulou, et al. 2025. A neurosymbolic approach to natural language formalization and verification. *arXiv preprint arXiv:2511.09008* (2025).

[3] Wenhu Chen, Xueguang Ma, Xinyi Wang, and William W Cohen. 2022. Program of thoughts prompting: Disentangling computation from reasoning for numerical reasoning tasks. *arXiv preprint arXiv:2211.12588* (2022).

[4] Zhiyu Chen, Wenhu Chen, Charese Smiley, Sameena Shah, Iana Borova, Dylan Langdon, Reema Moussa, Matt Beane, Ting-Hao Huang, Bryan R Routledge, et al. 2021. Finqa: A dataset of numerical reasoning over financial data. In *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*. 3697–3711.

[5] Leonardo De Moura and Nikolaj Bjørner. 2008. Z3: An efficient SMT solver. In *International conference on Tools and Algorithms for the Construction and Analysis of Systems*. Springer, 337–340.

[6] Dongxin Guo, Jikun Wu, and Siu Ming Yiu. 2026. FinGround: Detecting and Grounding Financial Hallucinations via Atomic Claim Verification. *arXiv preprint arXiv:2604.23588* (2026).

[7] Shijie Han, Haoqiang Kang, Bo Jin, Xiao-Yang Liu, and Steve Y Yang. 2024. Xbrl agent: Leveraging large language models for financial report analysis. In *Proceedings of the 5th ACM International Conference on AI in Finance*. 856–864.

[8] Pranab Islam, Anand Kannappan, Douwe Kiela, Rebecca Qian, Nino Scherrer, and Bertie Vidgen. 2023. Financebench: A new benchmark for financial question answering. *arXiv preprint arXiv:2311.11944* (2023).

[9] Yidong Jiang, Junrong Chen, Eftychia Makri, Jialin Chen, Peiwen Li, Ali Maatouk, Leandros Tassiulas, Eliot Brenner, Bing Xiang, and Rex Ying. 2026. Fin-rate: A real-world financial analytics and tracking evaluation benchmark for llms on sec filings. *arXiv preprint arXiv:2602.07294* (2026).

[10] Viet Lai, Michael Krumdick, Charles Lovering, Varshini Reddy, Craig Schmidt, and Chris Tanner. 2025. Sec-qa: A systematic evaluation corpus for financial qa. In *Proceedings of The 10th Workshop on Financial Technology and Natural Language Processing*. 221–236.

[11] Stephanie Lin, Jacob Hilton, and Owain Evans. 2022. Truthfulqa: Measuring how models mimic human falsehoods. In *Proceedings of the 60th annual meeting of the association for computational linguistics (volume 1: long papers)*. 3214–3252.

[12] Sewon Min, Kalpesh Krishna, Xinxi Lyu, Mike Lewis, Wen-tau Yih, Pang Koh, Mohit Iyyer, Luke Zettlemoyer, and Hannaneh Hajishirzi. 2023. FActScore: Fine-grained atomic evaluation of factual precision in long form text generation. In *Proceedings of the 2023 conference on empirical methods in natural language processing*. 12076–12100.

[13] Theo Olausson, Alex Gu, Ben Lipkin, Cedegao Zhang, Armando Solar-Lezama, Joshua Tenenbaum, and Roger Levy. 2023. LINC: A neurosymbolic approach for logical reasoning by combining language models with first-order logic provers. In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. 5153–5176.

[14] Liangming Pan, Alon Albalak, Xinyi Wang, and William Wang. 2023. Logic-lm: Empowering large language models with symbolic solvers for faithful logical reasoning. In *Findings of the Association for Computational Linguistics: EMNLP 2023*. 3806–3824.

	Nộp XBRL (n=600)							FinanceBench (n=67)						
Mô hình yêu cầu	TA	FA ↓	FR	Abs	Tối hôm trước	Acc.	Cov.	TA	FA ↓	FR	Abs	Tối	Acc.	Cov.
Qwen2.5-7B	35	0	73	10	100.0	87.6	98.3	10	0	7	34	100.0	78.8	49.3
Llama-3.1-8B	74	0	50	16	100.0	91.4	97.3	10	0	13	28	100.0	66.7	58.2
Qwen3-30B	245	0	69	0	100.0	88.5	100.0	24	0	10	15	100.0	80.8	77.6
Fin-o1-8B	436	0	49	8	100.0	91.7	98.7	32	0	9	12	100.0	83.6	82.1
Claude Haiku 4.5	455	0	46	7	100.0	92.2	98.8	28	0	9	13	100.0	83.3	80.6
GPT-5.5	560	0	37	0	100.0	93.8	100.0	35	0	10	12	100.0	81.8	82.1

Bảng 2: Hiệu suất của VeriFin trên sáu mô hình tạo câu trả lời. TA/FA/FR/Abs là số lượng; Prec./Acc./Cov. là tỷ lệ phần trăm. Các từ chối đúng bị bỏ qua để tiết kiệm không gian và có thể phục hồi dưới dạng $n -$ (TA + FA + FR + Abs).

Xương sống	Sửa chữa ngây thơ	Sửa chữa được hướng dẫn bởi kiểm chứng			
	Phục hồi	pass@1		pass@3	
		Phục hồi	Δ	Phục hồi	Δ
Hồ sơ XBRL					
Qwen3-30B	6,5 (15/230)	46,3 (107/231)	+39.8	47,7 (113/237)	+1.4
Fin-o1-8B	26,1 (29/111)	57,0 (61/107)	+30.9	69,9 (79/113)	+12.9
Claude Haiku 4.5	23,1 (9/39)	40,5 (17/42)	+17.4	55,6 (25/45)	+15.1
Ngân hàng Tài chính					
Qwen3-30B	0.0 (0/16)	37,5 (6/16)	+37.5	50,0 (9/18)	+12.5
Fin-o1-8B	0.0 (0/11)	0.0 (0/12)	+0.0	9.1 (1/11)	+9.1
Claude Haiku 4.5	0.0 (0/11)	10.0 (1/10)	+10.0	20.0 (2/10)	+10.0

Bảng 3: Tỷ lệ phục hồi (%) trong số các trường hợp bắt chính xác, với số lượng phục hồi/điểm được hiển thị trong ngoặc. Naive Repair sử dụng một lần thử chung. pass@1 được hướng dẫn bởi Verifier sử dụng một lần cố gắng với phản hồi chẩn đoán từ trình giải, trong khi pass@3 cho phép lên đến ba lần cố gắng độc lập được hướng dẫn.

Lợi ích của phản hồi từ người kiểm chứng nằm ở việc xác định những gì cần thay đổi, thay vì chỉ đơn thuần báo cáo rằng yêu cầu là sai. Việc thử lại chung chung chỉ phục hồi được ít lỗi thực sự, trong khi các xung đột được đặt tên giúp xác định các giá trị đã nộp liên quan, vai trò từng mục, công thức và giới hạn ứng viên. Phản hồi có cấu trúc này cải thiện khả năng phục hồi pass@1 lên đến 39,8%. Những phát hiện này làm nổi bật tiện ích chẩn đoán của việc xác minh dựa trên SMT trong các quy trình tài chính. Ngoài việc lọc nhị phân, người kiểm chứng sử dụng các lõi UNSAT như các tín hiệu sửa chữa nhằm mục tiêu để phục hồi các yêu cầu bị từ chối.

6 Kết luận

Trong công trình này, chúng tôi giới thiệu VeriFin, một khung neurosymbolic để xác minh các tuyên bố số được tạo ra bởi LLMs. VeriFin tách riêng việc tạo tuyên bố khỏi việc xác minh: các mô hình ngôn ngữ đề xuất câu trả lời và kế hoạch xác minh, trong khi các dữ liệu XBRL đã nộp, các công thức có nguồn gốc, và một bộ giải SMT xác định liệu một tuyên bố có nên được chấp nhận hay không. Thí nghiệm trên XBRLFiling và FinanceBench cho thấy thiết kế này không ghi nhận trường hợp chấp nhận sai nào trong các đánh giá của chúng tôi trên nhiều mô hình trả lời, đồng thời duy trì độ bao phủ cao trên chuẩn cấu trúc. So sánh với các trọng tài LLM và Progra
m-of-Thought còn cho thấy việc truy cập các toán hạng và công thức chính xác là không đủ trừ khi chúng được thực thi như các ràng buộc cứng. Các chẩn đoán do bộ giải đưa ra cũng cải thiện việc sửa chữa các tuyên bố bị từ chối. Những kết quả này gợi ý rằng các hệ thống trả lời câu hỏi tài chính đáng tin cậy nên được xây dựng xoay quanh việc độc lập xác minh thực tế, có thể thực thi thay vì đánh giá tính hợp lý dựa trên mô hình.

Tài liệu tham khảo

[1] Adewale Akinfaderin và Shreyas Subramanian. 2025. VERAFI: Trí tuệ tài chính có tác nhân được xác minh thông qua tạo chính sách thần kinh-ký hiệu. arXiv preprint arXiv:2512.14744 (2025).[2] Sam Bayless, Stefano Buliani, Darion Cassel, Byron Cook, Duncan Clough, Rémi Delmas, Nafi Diallo, Ferhat Erata, Nick Feng, Dimitra Giannakopoulou, et al. 2025. Một phương pháp thần kinh-ký hiệu cho việc hình thức hóa và xác minh ngôn ngữ tự nhiên. arXiv preprint arXiv:2511.09008 (2025). [3] Wenhu Chen, Xueguang Ma, Xinyi Wang, và William W Cohen. 2022. Gợi ý Chương trình suy nghĩ: Tách riêng tính toán khỏi lý luận cho các nhiệm vụ lý luận số. arXiv preprint arXiv:2211.12588 (2022).[4] Zhiyu Chen, Wenhu Chen, Charese Smiley, Sameena Shah, Iana Borova, Dylan Langdon, Reema Moussa, Matt Beane, Ting-Hao Huang, Bryan R Routledge, et al. 2021. Finqa: Một tập dữ liệu về lý luận số trên dữ liệu tài chính. Trong Kỷ yếu Hội nghị 2021 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên. 3697–3711.[5]

[15] Silu Panda. 2026. FinVerBench: Benchmark Validity and Calibration in Large Language Model Financial Statement Verification. *arXiv preprint arXiv:2605.29586* (2026).
[16] U.S. Securities and Exchange Commission. [n. d.]. EDGAR Company Filings. https://sec.gov. Accessed: 2026-07-30.
[17] Xinyu Wang, Jijun Chi, Zhenghan Tai, Tung Sum Thomas Kwok, Hailin He, Zhuhong Li, Yuchen Hua, Muzhi Li, Peng Lu, Suyucheng Wang, et al. 2025. Finsage: A multi-aspect rag system for financial filings question answering. In *Proceedings of the 34th ACM International Conference on Information and Knowledge Management*. 6144–6152.
[18] Yan Wang, Xuguang Ai, Jaisal Patel, Xueqing Peng, Fengran Mo, Yupeng Cao, Haohang Li, Mingyu Cao, Lingfei Qian, and Víctor Gutiérrez-Basulto. 2026. AUDITFLOW: Executable Symbolic Environments for Structured Financial Reporting Verification. *arXiv preprint arXiv:2606.03031* (2026).
[19] Xi Ye, Qiaochu Chen, Isil Dillig, and Greg Durrett. 2023. Satlm: Satisfiability-aided language models using declarative prompting. *Advances in Neural Information Processing Systems* 36 (2023), 45548–45580.
[20] Lianmin Zheng, Wei-Lin Chiang, Ying Sheng, Siyuan Zhuang, Zhanghao Wu, Yonghao Zhuang, Zi Lin, Zhuohan Li, Dacheng Li, Eric Xing, et al. 2023. Judging llm-as-a-judge with mt-bench and chatbot arena. *Advances in neural information processing systems* 36 (2023), 46595–46623.

[15] Silu Panda. 2026. FinVerBench: Tính hợp lệ và hiệu chuẩn chuẩn mực trong việc xác minh báo cáo tài chính bằng mô hình ngôn ngữ lớn. Bản in trước arXiv arXiv:2605.29586 (2026). [16] Ủy ban Chứng khoán và Giao dịch Hoa Kỳ. [không xác định]. Hồ sơ Công ty EDGAR. https://sec.gov. Truy cập: 30-07-2026. [17] Xinyu Wang, Jijun Chi, Zhenghan Tai, Tung Sum Thomas Kwok, Hailin He, Zhuhong Li, Yuchen Hua, Muzhi Li, Peng Lu, Suyucheng Wang, và cộng sự. 2025. Finsage: Hệ thống RAG đa khía cạnh cho trả lời câu hỏi về hồ sơ tài chính. Trong Kỷ yếu Hội nghị Quốc tế ACM lần thứ 34 về Thông tin và Quản lý Kiến thức. 6144–6152.
[18] Yan Wang, Xuguang Ai, Jaisal Patel, Xueqing Peng, Fengran Mo, Yupeng Cao, Haohang Li, Mingyu Cao, Lingfei Qian, và Víctor Gutiérrez-Basulto. 2026. AUDITFLOW: Môi trường Biểu tượng Có thể Thực thi để Kiểm tra Báo cáo Tài chính Có cấu trúc. Bản in trước trên arXiv arXiv:2606.03031 (2026). [19] Xi Ye, Qiaochu Chen, Isil Dillig, và Greg Durrett. 2023. Satlm: Mô hình ngôn ngữ hỗ trợ độ thỏa mãn sử dụng gợi ý khai báo. Tiến bộ trong Hệ thống Xử lý Thông tin Thần kinh 36 (2023), 45548–45580. [20] Lianmin Zheng, Wei-Lin Chiang, Ying Sheng, Siyuan Zhuang, Zhanghao Wu, Yonghao Zhuang, Zi Lin, Zhuohan Li, Dacheng Li, Eric Xing, và những người khác. 2023. Đánh giá LLM- như một thẩm phán với MT-Bench và Chatbot Arena. Tiến bộ trong hệ thống xử lý thông tin thần kinh 36 (2023), 46595–46623.