MiniCheck: Efficient Fact-Checking of LLMs on Grounding Documents

Liyan Tang[♢] **Philippe Laban**[♠] **Greg Durrett**[♢]
[♢]The University of Texas at Austin [♠]Salesforce AI Research
lytang@utexas.edu

Abstract

Recognizing if LLM output can be grounded in evidence is central to many tasks in NLP: retrieval-augmented generation, summarization, document-grounded dialogue, and more. Current approaches to this kind of fact-checking are based on verifying each piece of a model generation against potential evidence using an LLM. However, this process can be very computationally expensive, requiring many calls to a model to check a single response. In this work, we show how to build small fact-checking models that have GPT-4-level performance but for 400x lower cost. We do this by constructing synthetic training data with GPT-4, which involves creating realistic yet challenging instances of factual errors via a structured generation procedure. Training on this data teaches models to check each fact in the claim and recognize synthesis of information across sentences. For evaluation, we unify datasets from recent work on fact-checking and grounding LLM generations into a new benchmark, LLM-AGGREFACT. Our best system MiniCheck-FT5 (770M parameters) outperforms all systems of comparable size and reaches GPT-4 accuracy. We release LLM-AGGREFACT, code for data synthesis, and models.[1]

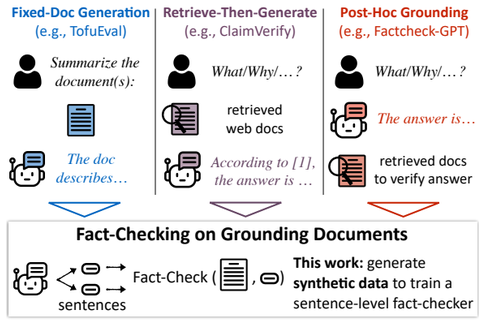


Figure 1: We unify the task of fact-checking across various settings that rely on grounding documents. We train a small sentence-level fact-checker by leveraging new synthetically generated data, which demonstrates strong performance on a new unified benchmark LLM-AGGREFACT, comparable to GPT-4 but 400x cheaper.

1 Introduction

Freeform generation of responses is a flexible way to employ large language models (LLMs) for question answering, summarization, and beyond. However, this kind of generation can lead to factual errors, the "hallucination" problem in LLMs (Falke et al., 2019; Maynez et al., 2020; McKenna et al., 2023; Zhang et al., 2023a). Such errors arise in generation settings where an LLM is prompted closed-book, but its parametric knowledge may be insufficient to produce the right facts (Min et al., 2023; Mallen et al., 2023; Zhou et al., 2023; Chen et al., 2023). Different but related errors occur in grounded generation settings where evidence is already available, like summarization of input documents or retrieval-augmented question answering, where an LLM can blend information incorrectly (Liu et al., 2023; Tang et al., 2024).

Past work has largely dealt with these problems separately. We can post-hoc verify closed-book generated answers by retrieving supporting documents and checking the answer against them (Gao et al., 2023; Malaviya et al., 2024; Jacovi et al., 2024), which requires precise checking as many statements are not exactly supported or may have conflicting information available (Wang et al., 2023; Glockner et al., 2024). When the grounding is known in settings like summarization, the attribution problem can be cleanly framed as document-level textual entailment (Nie et al., 2020a; Yin et al., 2021) and has been studied extensively for smaller language models (Falke et al., 2019; Goyal and Durrett, 2020, 2021; Laban et al., 2022; Tang et al.,

[1]https://github.com/Liyan06/MiniCheck; see latest leaderboard at llm-aggrefact.github.io.

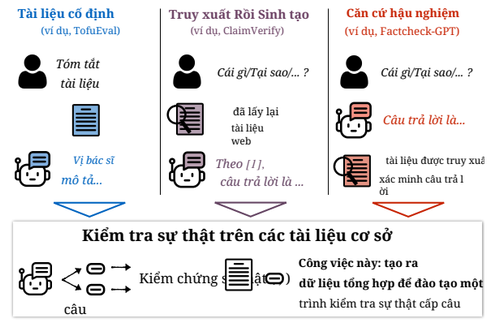
Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing, pages 8818–8847
November 12-16, 2024 ©2024 Association for Computational Linguistics

MiniCheck: Kiểm tra sự thật hiệu quả của LLM trên các tài liệu cơ sở

Liyan Tang[♢] Philippe Laban[♠] Greg Durrett[♢♢]Trường Đại học
Texas tại Austin [♠]Nghiên cứu AI Salesforce lytang@utexas.edu

Tóm tắt

Nhận biết liệu đầu ra của LLM có thể được dựa trên bằng chứng hay không là trung tâm của nhiều nhiệm vụ trong NLP: tạo ra nội dung kết hợp truy xuất thông tin, tóm tắt, đối thoại dựa trên tài liệu, và nhiều hơn nữa. Các phương pháp hiện tại để kiểm tra sự thật kiểu này dựa trên việc xác minh từng phần của kết quả mô hình với bằng chứng tiềm năng sử dụng LLM. Tuy nhiên, quá trình này có thể rất tốn kém về mặt tính toán, yêu cầu nhiều lần gọi tới mô hình để kiểm tra một phản hồi duy nhất. Trong công trình này, chúng tôi trình bày cách xây dựng các mô hình kiểm tra sự thật nhỏ có hiệu suất tương đương GPT-4 nhưng chi phí thấp hơn 400 lần. Chúng tôi làm điều này bằng cách tạo dữ liệu huấn luyện tổng hợp với GPT-4, bao gồm việc tạo ra các tình huống lỗi thực tế nhưng đầy thách thức thông qua một quy trình tạo có cấu trúc. Huấn luyện trên dữ liệu này dạy các mô hình kiểm tra từng thông tin trong tuyên bố và nhận biết sự tổng hợp thông tin giữa các câu. Để đánh giá, chúng tôi hợp nhất các tập dữ liệu từ các công trình gần đây về kiểm tra sự thật và nền tảng đầu ra LLM thành một chuẩn mới, L



Hình 1: Chúng tôi thống nhất nhiệm vụ kiểm tra sự thật trên nhiều bối cảnh khác nhau phụ thuộc vào các tài li ệu cơ sở. Chúng tôi đào tạo một trình kiểm tra sự thật ở cấp câu nhỏ bằng cách tận dụng dữ liệu mới được tạo ra tổng hợp, điều này chứng minh hiệu suất mạnh trên một chuẩn mực thống nhất mới LLM-AGGREFACT, t ương đương với GPT-4 nhưng rẻ hơn 400 lần.

1 Giới thiệu

Việc tạo phản hồi theo dạng tự do là một cách linh hoạt để sử dụng các mô hình ngôn ngữ lớn (LLMs) cho trả lời câu hỏi, tóm tắt, và nhiều ứng dụng khác. Tuy nhiên, loại sáng tạo này có thể dẫn đến các lỗi thực tế, vấn đề "ảo tưởng" trong LLMs (Falke et al., 2019; Maynez et al., 2020; McKenna et al., 2023; Zhang et al., 2023a). Những lỗi như vậy xuất hiện trong các bối cảnh tạo ra dữ liệu khi một LLM được gợi ý mà không sử dụng tài liệu tham khảo, nhưng kiến thức tham số của nó có thể không đủ để đưa ra các dữ kiện chính xác (Min et al., 2023; Mallen và cộng sự, 2023; Zhou và cộng sự, 2023; Chen và cộng sự, 2023). Các lỗi khác nhưng có liên quan xảy ra trong các thiết lập tạo nội dung dựa trên bằng chứng khi bằng chứng đã có sẵn, như tóm tắt các tài liệu đầu vào hoặc trả lời câu hỏi được tăng cường truy xuất, nơi một LLM có thể t rộn thông tin một cách không chính xác (Liu và cộng sự, 2023; Tang và cộng sự, 2024).

Các công trình trước đây phần lớn đã xử lý những vấn đề này một cách riêng lẻ. Chúng ta có thể kiểm tra lại các câu trả lời được tạo ra từ bộ nhớ đóng hậu kỳ bằng cách truy xuất các tài liệu hỗ trợ và kiểm tra câu trả lời dựa trên chúng (Gao et al., 2023; Malaviya et al., 2024; Jacovi et al., 2024), điều này đòi hỏi việc kiểm tra chính xác vì nhiều phát biểu không được hỗ trợ chính xác hoặc có thể có thông tin mâu thuẫn (Wang et al., 2023; Glockner et al., 2024). Khi nguồn dữ liệu cơ sở được biết trong các bối cảnh như tóm tắt, vấn đề xác định nguồn có thể được trình bày rõ ràng dưới dạng suy diễn văn bản cấp tài liệu (Nie et al., 2020a; Yin et al., 2021) và đã được nghiên cứu rộng rãi đối với các mô hình ngôn ngữ nhỏ hơn (Falke et al., 2019; Goyal và Durrett, 2020, 2021; Laban et al., 2022; Tang et al.,

[1]https://github.com/Liyan06/MiniCheck; xem bảng xếp hạng mới nhất tại llm-aggrefact.github.io.

Kỷ yếu Hội nghị năm 2024 về Các Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên, các trang 8818–8847,
ngày 12-16 tháng 11, 2024 ©2024 Hiệp hội Ngôn ngữ Học Máy Tính

2023a).

The problems in this space have a shared primitive operation: the need to check a statement against grounding documents, either retrieval-augmented content or post-hoc retrieved evidence. We call this primitive **fact-checking on grounding documents**, shown in Figure 1. Implementations of this primitive need to be accurate, spotting subtle errors while maintaining a low false positive rate, as most generated statements are correct. They also need to be efficient: a single LLM response may contain dozens of facts to verify, and self-verification with an LLM may increase cost by an order of magnitude (Weng et al., 2023; Gero et al., 2023). For instance, the 110-150 word biographies in FActScore (Min et al., 2023) contain 26-41 atomic facts that are checked against 5 documents each, resulting in 130-205 entailment checks.

In this work, we build an efficient system for fact-checking on grounding documents. Our key insight is to develop a new synthetic training dataset which is tailored to the complexities of the fact-checking task. Unlike standard distillation from LLMs (Taori et al., 2023; Hsieh et al., 2023), this setting differs in that we do not necessary have access to task instances that we can label with strong LLMs. For instance, in datasets like ExpertQA (Malaviya et al., 2024), even the inputs to the LLM are expert-written questions. As a result, we synthesize challenging fact-checking instances from the ground up, as a scalable way to teach a small model how to simultaneously verify multiple facts in a sentence against multiple sentences in grounding documents. Our system, MiniCheck, is an instance of Flan-T5 (Chung et al., 2022) fine-tuned on this data plus standard entailment data (Nie et al., 2020a).

For our experiments, we introduce a new unified benchmark, LLM-AGGREFACT, which aggregates 10 existing datasets for both closed-book and grounded generation settings. In each constituent dataset, sentence-level factual errors are labeled by human annotators. We show that MiniCheck can perform as well as GPT-4 in aggregate and substantially outperform past fine-tuned systems like AlignScore (Zha et al., 2023). Moreover, we find that decomposition of sentences into atomic facts, which has been explored in past work (Kamoi et al., 2023; Gao et al., 2023; Wang et al., 2023), is not necessary to achieve this high performance.

Our contributions are as follows: (1) Two synthetic data generation methods to address the challenges of fact-checking on grounding documents. (2) A new benchmark unifying factual evaluation on closed-book and grounded generation settings. (3) Evaluation shows that our MiniCheck system can beat previous specialized systems by 4% to 10% in absolute values, despite using less fine-tuning data, and is on par with GPT-4 with a much smaller model size, faster inference speed, and 400 times less cost. Furthermore, we can do this without a separate claim decomposition step.

2 Background and Motivation

Problem Setup: Claim Verification We assume a collection of statements to be checked consisting of sentences $\mathbf{c} = [c_1, \ldots, c_{|\mathbf{c}|}]$. Typically, this will be a sequence of sentences produced by an LLM. Each sentence c_i has an associated set of grounding documents $\mathcal{D}_i = \{D_{i,1}, \ldots, D_{i,|\mathcal{D}_i|}\}$. These different $\mathcal{D}_i$ per sentence accommodate post-hoc retrieval settings where each sentence has different retrieved evidence; however, some settings may use shared evidence across all sentences or even a single grounding document for tasks like single-document summarization (i.e., all $\mathcal{D}_i$ only contain the document being summarized).

We view these sentences as *claims*. Our goal in this work is to build a system that can validate each claim against the documents. Following Laban et al. (2022), we define a discriminator

$$M(D_{i,j}, c_i) \in \{0, 1\},$$

that classifies each claim c_i into `unsupported`, 0, or `supported`, 1, according to a provided document $D_{i,j}$.[2]

This process makes two assumptions. First, we assume that **each supported claim can be validated against a single document**; that is, claims are "atomic enough". Our methodology can be generalized to handle claims supported by multiple documents by simply appending multiple documents in the context of M, but we did not find it necessary in any of the datasets we studied.

Second, we assume that **we can perform our entailment checks on each sentence c_i on its own, without context $c_{<i}$.** In general, sentences do need context to be understood (e.g., most sentences starting with pronouns), but this can be resolved through the use of a *decontextualization* step (Choi et al., 2021). Section 7 examines whether such a step improves performance of our system.

[2]Following past work (Kamoi et al., 2023; Sanyal et al., 2024), we disregard the usual "contradiction" class from textual entailment, as contradictions are rare in our benchmark.

2023a).

Các vấn đề trong lĩnh vực này có một thao tác sơ khai chung: cần phải kiểm tra một tuyên bố dựa trên các tài liệu nền tảng, hoặc là nội dung được tăng cường truy xuất, hoặc là bằng chứng được tr uy xuất hậu kỳ. Chúng tôi gọi thao tác sơ khai này l à kiểm tra sự thật dựa trên tài liệu nền tảng, như minh họa trong Hình 1. Các triển khai của thao tác sơ khai này cần phải chính xác, phát hiện ra những lỗi tinh vi trong khi vẫn duy trì tỷ lệ dương tính giả thấp, vì hầu hết các tuyên bố được tạo ra đều đúng. Chúng cũng cần phải hiệu quả: một phản hồi từ LLM duy nhất có thể chứa hàng chục sự thật cần xác minh, và việc tự xác minh với LLM có thể làm tăng chi phí lên một bậc (Weng et al., 2023; Gero et al., 2023). Ví dụ, những tiểu sử dài 110-150 từ trong FActScore (Min et al., 2023) chứa 26-41 dữ kiện nguyên tử được kiểm tra dựa trên 5 tài liệu mỗi ti ểu sử, dẫn đến 130-205 lần kiểm tra sự suy luận.

Trong công trình này, chúng tôi xây dựng một hệ thống hiệu quả để kiểm tra sự thật dựa trên các tài liệu nền tảng. Nhận thức chính của chúng tôi là phát triển một bộ dữ liệu huấn luyện tổng hợp mới được thiết kế phù hợp với sự phức tạp của nhiệm vụ kiểm tra sự t hật. Khác với việc chưng cất tiêu chuẩn từ các mô hình ngôn ngữ lớn (LLM) (Taori et al., 2023; Hsieh et al., 2023), thiết lập này khác ở chỗ chúng tôi không nhất thiết có quyền truy cập vào các trường hợp nhiệm vụ mà chúng tôi có thể gán nhãn bằng các LLM mạnh. Ví dụ, trong các bộ dữ liệu như ExpertQA (Malaviya et al., 2024), ngay cả các đầu vào cho LLM cũng là các câu hỏi được viết bởi chuyên gia. Do đó, chúng tôi tổng hợp các trường hợp kiểm tra sự thật khó từ đầu, như một cách mở rộng để dạy một mô hình nhỏ cách cùng lúc xác minh nhiều sự thật trong một câu với nhiều câu trong các tài liệu nền tảng. Hệ thống của chúng tôi, MiniCheck, là một ví dụ của Flan-T5 (Chung et al., 2022) được tinh chỉnh trên dữ liệu này cộng với dữ liệu suy diễn tiêu chuẩn (Nie et al., 2020a).

Đối với các thí nghiệm của chúng tôi, chúng tôi gi ới thiệu một chuẩn mới thống nhất, LLM-AGGREFACT, tổng hợp 10 bộ dữ liệu hiện có cho cả hai thiết lập tạo nội dung đóng sách và nội dung có cơ sở. Trong mỗi bộ dữ liệu thành phần, các lỗi một câu ở mức sự thật đ ược đánh dấu bởi các người chú thích con người. Chúng tôi chỉ ra rằng MiniCheck có thể hoạt động tốt như GPT-4 ở mức tổng hợp và vượt trội đáng kể so với các hệ thống đã được tinh chỉnh trước đây như AlignScore (Zha et al., 2023). Hơn nữa, chúng tôi nhận thấy rằng việc phân tách các câu thành các sự kiện cơ bản, vốn đã được nghiên cứu trong các công trình trước (Kamoi et al., 2023; Gao et al., 2023; Wang et al., 2023), không cần thiết để đạt được hiệu suất cao này.

Những đóng góp của chúng tôi như sau: (1) Hai phương pháp tạo dữ liệu tổng hợp để giải quyết những thách thức trong việc kiểm tra tính xác thực dựa trên các tài liệu nền tảng. (2) Một chuẩn mực mới hợp nhất đánh giá thực tế trên các bối cảnh tạo dữ liệu đóng và có cơ sở. (3) Đánh giá cho thấy hệ thống MiniCheck của chúng tôi có thể vượt qua các hệ thống chuyên biệt trước đây từ 4% đến 10% về giá trị tuyệt đối, mặc dù sử dụng ít dữ liệu tinh chỉnh hơn, và ngang bằng với GPT-4 với kích thước mô hình nhỏ hơn nhiều, tốc độ suy luận nhanh hơn, và chi phí thấp hơn 400 l ần. Hơn nữa, chúng tôi có thể làm điều này mà không cần bước phân tách tuyên bố riêng biệt.

2 Bối cảnh và Động lực

Thiết lập vấn đề: Xác minh tuyên bố Chúng tôi giả định một tập hợp các tuyên bố cần được kiểm tra bao gồm các câu c $= [c_1, \ldots, c_{|\mathbf{c}|}]$. Thông thường, đây sẽ là một chuỗi các câu do một Mô hình Ngôn ngữ Lớn (LLM) tạo ra. Mỗi câu c_i có một tập hợp các tài liệu làm cơ sở $\mathcal{D}_i = \{D_{i,1}, \ldots, D_{i,|\mathcal{D}_i|}\}$ liên quan. Những $\mathcal{D}_i$ khác nhau cho mỗi câu này phù hợp với các bối cảnh truy xuất ngược hậu kỳ, nơi mỗi câu có các bằng chứng được truy xuất khác nhau; tuy nhiên, một số bối cảnh có thể sử dụng cùng một bằng chứng cho tất cả các câu hoặc thậm chí một t ài liệu cơ sở duy nhất cho các nhiệm vụ như tóm t ắt một tài liệu duy nhất (tức là tất cả các $\mathcal{D}_i$ chỉ chứa tài liệu đang được tóm tắt).

Chúng tôi xem những câu này như các tuyên bố. Mục tiêu của chúng tôi trong công việc này là xây dựng một hệ thống có thể xác thực từng tuyên bố dựa trên các tài liệu. Theo Laban và cộng sự (2022), chúng tôi định nghĩa một bộ phân biệt

$$M(D_{i,j}, c_i) \in \{0, 1\},$$

xếp loại mỗi tuyên bố c_i thành không được hỗ trợ, 0, hoặc được hỗ trợ, 1, theo một tài liệu được cung cấp $D_{i,j}$.[2]

Quy trình này đưa ra hai giả định. Thứ nhất, chúng tôi giả định rằng mỗi tuyên bố được hỗ trợ có thể được xác thực dựa trên một tài liệu duy nhất; nghĩa là, các tuyên bố đủ "nguyên tử". Phương pháp của chúng tôi có thể được tổng quát hóa để xử lý các tuyên bố được hỗ trợ bởi nhiều tài liệu bằng cách đơn giản là thêm nhiều tài liệu vào bối cảnh của M, nhưng chúng tôi không thấy cần thiết làm điều này trong bất kỳ tập dữ liệu nào mà chúng tôi đã nghiên cứu.

Thứ hai, chúng tôi giả định rằng chúng tôi có thể thực hiện các kiểm tra suy luận của mình trên từng câu c_i một cách độc lập, mà không cần ngữ cảnh $c_{<i}$. Nói chung, các câu cần ngữ cảnh để được hiểu (ví dụ, hầu hết các câu bắt đầu bằng đại từ), nhưng điều này có thể được giải quyết thông qua việc sử dụng bước tách ngữ cảnh (Choi et al., 2021). Mục 7 xem xét liệu bước này có cải thiện hiệu suất của hệ thống của chúng tôi hay không.

[2]Theo các nghiên cứu trước đây (Kamoi và cộng sự, 2023; Sanyal và cộng sự, 2024), chúng tôi bỏ qua lớp "mâu thuẫn" thông thường từ suy luận ngữ nghĩa, vì các mâu thuẫn hiếm gặp trong bộ chuẩn của chúng tôi.

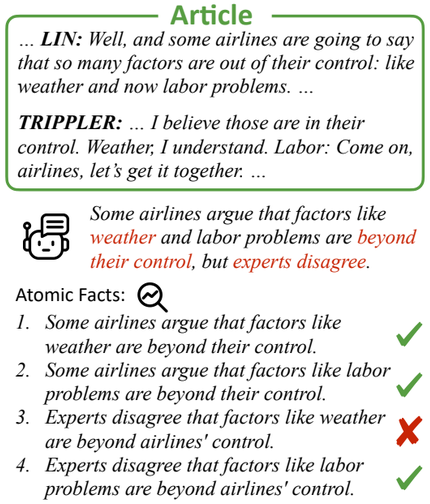


Figure 2: An example dialogue snippet with an LLM-generated summary sentence, from the TofuEval dataset.

We judge a sentence c_i by taking $\max_j M(D_{i,j}, c_i)$: it is supported if and only if there exists some document that supports it.

Challenges of verification Two aspects of the task make this process challenging. First, there may be several individual facts in $D_{i,j}$ which are necessary to validate a claim c_i. For example, the LLM-generated sentence in Figure 2 can be broken down into four atomic facts. Each fact must be checked *even if they are not explicitly materialized.*

Second, and relatedly, the claim, or a fact in the claim, may require making inferences that span multiple sentences within $D_{i,j}$. In Figure 2, Lin initially argues that airlines have no control over either weather or labor issues. However, Trippler's later statement, *"Weather, I understand. Labor: Come on, airlines, let's get it together,"*, implies agreement that weather is uncontrollable but suggests that labor problems are within the airlines' control. This indicates that the third atomic fact is unsupported by the document.

We argue that existing specialized fact-checkers fall short in effectively considering all atomic facts within a claim to be verified and struggle with reasoning across multiple sentences. Results in Appendix A.1 support this characterization. To address this issue, we come up with two synthetic data generation methods (Section 3) to enhance the models' ability in these areas. We discuss the relation to prior work in Section 8.

3 Methodology: Training Data Synthesis

To address these challenges, new data is required. Existing datasets like MNLI (Williams et al., 2018) and ANLI (Nie et al., 2020a) do not feature instances that reflect the complexity of LLM fact-checking. Annotation of real errors is challenging to scale; datasets of such errors (including those in LLM-AGGREFACT) are largely test-only.

Our goal is to construct a dataset $\{(D_i, c_i, y_i)\}_{i=1}^N$ of N instances of documents D_i paired with claims c_i with label $y_i \in \{0, 1\}$, using two novel synthetic data generation methods (Figure 3). Statistics about our final synthetic training data can be found in Table 1. A small-scale human evaluation of the synthetic data quality can be found in Appendix A.3. Additional details, including the sources of claims and documents and examples of generated data, can be found in Appendix D. We provide all prompts and quality assurance details in Appendix H.

3.1 Claim to Doc (C2D) Generation

In the C2D method, we assume that we have access to a set of human-written claim statements. The goal is to generate synthetic documents that require models be able to check multiple facts in the claim against multiple sentences each.

Step 1: Claim decomposition Given a claim c, we first decompose it into a set of atomic facts $\mathbf{a}$ with GPT-3.5: $\texttt{Decomp}(c) = \{a_1, \ldots, a_l\}$.

Step 2: Atomic fact expansion For the claim c, we ask GPT-4 to generate a pair of sentences for each of its atomic facts with a 4-shot prompt:

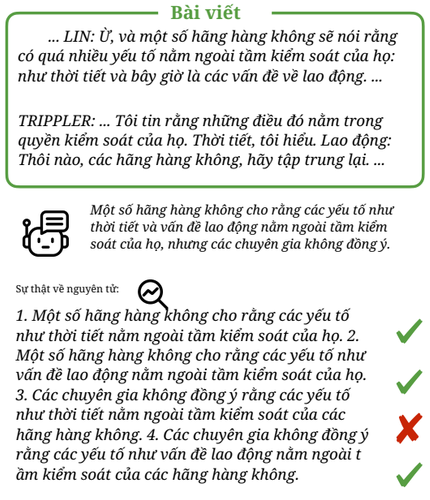
$$\texttt{SentPair}(a_i) = (s_{i,1}, s_{i,2}), \forall i \in \{1, \ldots, l\}.$$

The generated sentence pairs are designed such that the atomic fact is supported if and only if the information from both sentences is combined.

Step 3: Supporting document generation After expanding atomic facts $\mathbf{a}$ into sentences $\mathbf{s} = \{s_{1,1}, s_{1,2}, \ldots, s_{l,1}, s_{l,2}\}$, we ask GPT-4 to generate a document D that mentions all sentences from the generated sentence pairs in its own words $D = \texttt{PassageGen}(\mathbf{s})$ with a zero-shot prompt.[3]

By following these steps, we create a triplet $(D, c, y = 1)$. This procedure increases the diffi-

[3]We ask GPT-4 to not state deduced facts or conclusions based on the provided sentences, and we find that GPT-4 can follow this instruction well.



Hình 2: Một đoạn hội thoại ví dụ với câu tóm tắt được tạo bởi LLM, từ bộ dữ liệu TofuEval.

Chúng tôi đánh giá một câu c_i bằng cách lấy $\max_j M(D_{i,j}, c_i)$: nó được hỗ trợ nếu và chỉ nếu tồn tại một tài liệu nào đó hỗ trợ nó.

Những thách thức của việc xác minh Hai khía cạnh của nhiệm vụ làm cho quá trình này trở nên khó khăn. Trước tiên, có thể có một số sự kiện riêng lẻ trong $D_{i,j}$ cần thiết để xác thực một tuyên bố c_i. Ví dụ, câu được tạo ra bởi LLM trong Hình 2 có thể được chia thành bốn sự kiện cơ bản. Mỗi sự kiện phải được kiểm tra ngay cả khi chúng không được thể hiện một cách rõ ràng.

Thứ hai, và liên quan, tuyên bố, hoặc một sự thật trong tuyên bố, có thể yêu cầu việc rút ra suy luận trải dài qua nhiều câu trong $D_{i,j}$. Trong Hình 2, Lin ban đầu lập luận rằng các hãng hàng không không kiểm soát được thời tiết hay vấn đề lao động. Tuy nhiên, phát biểu sau này của Trippler, " Thời tiết, tôi hiểu. Lao động: Nào, các hãng hàng không, hãy gắng lên,", ám chỉ sự đồng ý rằng thời tiết là không kiểm soát được nhưng gợi ý rằng các vấn đề về lao động nằm trong khả năng kiểm soát của các hãng hàng không. Điều này cho thấy rằng sự thật nguyên tử thứ ba không được tài liệu hỗ tr ợ.

Chúng tôi cho rằng các bộ kiểm tra sự thật chuyên biệt hiện có chưa hiệu quả trong việc cân nhắc tất cả các sự thật nguyên tử trong một tuyên bố cần được xác minh và gặp khó khăn trong việc l ý luận qua nhiều câu. Kết quả trong Phụ lục A.1 hỗ trợ cho mô tả này. Để giải quyết vấn đề này, chúng tôi đưa ra hai phương pháp tạo dữ liệu tổng hợp (Mục 3) để nâng cao khả năng của các mô hình trong các lĩnh vực này. Chúng tôi thảo luận mối quan hệ với các công trình trước đó trong Mục 8.

3 Phương pháp luận: Tổng hợp Dữ liệu Đào tạo

Để giải quyết những thách thức này, cần có dữ liệu mới. Các tập dữ liệu hiện có như MNLI (Williams et al., 2018) và ANLI (Nie et al., 2020a) không bao gồ m các ví dụ phản ánh độ phức tạp của việc kiểm tra sự thật bằng LLM. Việc chú thích các lỗi thực tế khó có thể mở rộng; các tập dữ liệu về những lỗi như vậy (bao gồm cả những lỗi trong LL M-AGGREFACT) phần lớn chỉ dùng để kiểm tra.

Mục tiêu của chúng tôi là xây dựng một bộ dữ liệu$\{(D_i, c_i, y_i)\}_{i=1}^N$ gồm N bản ghi tài liệuD_i được ghép nối với các tuyên bố c_i với nhãn $y_i \in \{0, 1\}$, sử dụng hai phương pháp tạo dữ liệu tổng hợp mới (Hình 3). Thống kê về dữ liệu huấn luyện tổng hợp cuối cùng của chúng tôi có thể được tìm thấy trong Bảng 1. Một đánh giá nhỏ về chất lượng dữ liệu tổng hợp bởi con người có thể được tìm thấy trong Phụ lục A.3. Các chi tiết bổ sung, bao gồm nguồn gốc của các tuyên bố và tài liệu cũng như các ví dụ về dữ liệu được tạo ra, có thể được tìm thấy trong Phụ lục D. Chúng tôi cung cấp tất cả các lệnh nhắc và chi tiết đảm bảo chất lượng trong Phụ lục H.

3.1 Yêu cầu tạo toDoc(C2D)

Trong phương pháp C2D, chúng tôi giả sử rằng chúng tôi có quyền truy cập vào một tập hợp các tuyên bố khẳng định được viết bởi con người. Mục tiêu là tạo ra các tài liệu tổng hợp mà yêu cầu các mô hình có thể kiểm tra nhiều sự thật trong tuyên bố so với nhiều câu trong từng tài liệu.

Bước 1: Phân rã tuyên bố Cho một tuyên bố c, trước tiên chúng ta phân rã nó thành một tập hợp các sự kiện nguyên tử a với GPT-3.5: Decomp(c) $= \{a_1, \ldots, a_l\}$.

Bước 2: Mở rộng sự thật nguyên tử Đối với tuyên bố c, chúng tôi yêu cầu GPT-4 tạo ra một cặp câu cho mỗi sự thật nguyên tử của nó bằng một lệnh 4 ví dụ:

$$\texttt{SentPair}(a_i) = (s_{i,1}, s_{i,2}), \forall i \in \{1, \ldots, l\}.$$

Các cặp câu được tạo ra được thiết kế sao cho sự kiện nguyên tử chỉ được hỗ trợ nếu và chỉ nếu thông tin từ cả hai câu được kết hợp.

Bước 3: Tạo tài liệu hỗ trợ Sau khi mở rộng các sự kiện nguyên tử a thành các câu s $=$ $\{s_{1,1}, s_{1,2}, \ldots, s_{l,1}, s_{l,2}\}$, chúng tôi yêu cầu GPT-4 tạo một tài liệu D nhắc đến tất cả các câu từ các cặp câu đã tạo bằng chính từ ngữ của nó $D =$ PassageGen(s) với một prompt zero-shot.[3]

Bằng cách thực hiện các bước này, chúng ta tạo ra một bộ ba $(D, c, y = 1)$. Quy trình này làm tăng độ khó-

[3]Chúng tôi yêu cầu GPT-4 không nêu các sự thật suy luận hoặc kết luận dựa trên các câu được cung cấp, và chúng tôi nhận thấy rằng GPT-4 có thể tuân theo hướng dẫn này tốt.

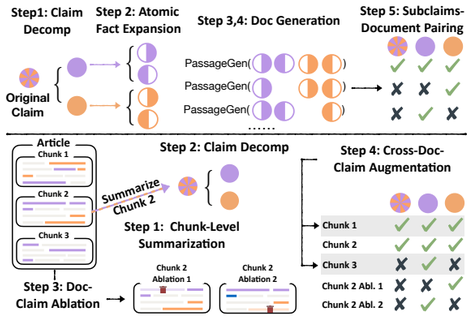


Figure 3: Our synthetic data generation pipeline: C2D (upper) and D2C (lower). We illustrate with a claim that contains two atomic facts. Examples of generated data can be found in Appendix D.

culty of the task by ensuring that multiple-sentence reasoning is required to correctly classify a claim.

Step 4: Nonsupporting document generation By construction, an atomic fact a_i in the claim c is supported by the sentence pair $(s_{i,1}, s_{i,2})$ mentioned in the generated document D. Therefore, by omitting one of the sentences from the pair in a newly generated document D', it is likely that a_i, and consequently c, is no longer supported by D' (except in cases of redundancy in the sentences $\mathbf{s}$). More formally, we can construct a document $D'_{a_{i\setminus j}}$ that *probably* cannot support fact a_i in c (and hence c) by removing sentence $s_{i,j}$ from its sentence pair:

$$D'_{a_{i\setminus j}} = \texttt{PassageGen}(\mathbf{s} \setminus s_{i,j}),$$

for all $i \in \{1, \ldots, l\}$ and $j \in \{1, 2\}$ (Figure 3; top right). To collect documents that do not support the claim c, we retain $D'_{a_{i\setminus j}}$ if a_i cannot be supported by the information combined from the remaining sentence from its sentence pair and other atomic facts ($s_{i,3-j} \cup \{\mathbf{a} \setminus a_i\}$) via an entailment check by GPT-4. Note that this entailment check is again more accurate than directly checking a_i against $D'_{a_{i\setminus j}}$ due to the shorter context.

Step 5: Pairing subclaims and generated documents We have collected tuples $(D, c, 1)$ and $(D'_{a_{i\setminus j}}, c, 0)$ for some i and j. We can further augment this data to produce more examples. We first generate a power set $\texttt{Power}(\mathbf{a})$, that consists of all possible subsets of atomic facts $\mathbf{a}$ in c, but excludes the empty set. We then create a set of augmented subclaims $\mathrm{Aug}(c)$ by merging atomic facts from each subset:

$$\mathrm{Aug}(c) = \{\texttt{Merge}(\mathbf{a}') : \forall \mathbf{a}' \in \texttt{Power}(\mathbf{a})\}.$$

It follows that we obtain tuples $(D, c', 1)$ for every $c' \in \mathrm{Aug}(c)$. Similarly, for each $D'_{a_{i\setminus j}}$, we generate tuples $(D'_{a_{i\setminus j}}, \texttt{Merge}(\mathbf{a}'), 1)$ if $a_i \notin \mathbf{a}'$, indicating that the document still supports the subclaim absent the atomic fact a_i. Conversely, we have $(D'_{a_{i\setminus j}}, \texttt{Merge}(\mathbf{a}'), 0)$ if $a_i \in \mathbf{a}'$, suggesting that the document does not support the subclaim due to the absence of a_i.

Because the same subclaim is supported by certain documents and unsupported by others depending on the presence or absence of specific atomic facts, we achieve the same benefits that training on contrast sets provides (Cao and Wang, 2021; Liu et al., 2022; Tang et al., 2023b), namely making the model more sensitive to the specifics of the decision boundary and encouraging it to consider all atomic facts within a claim during prediction.

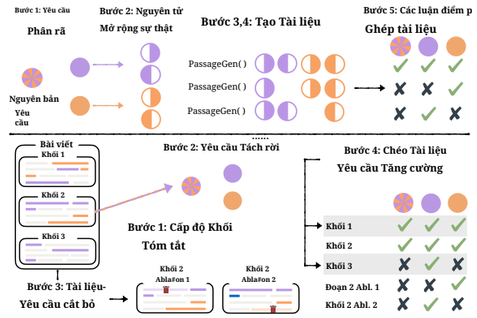
3.2 Doc to Claim (D2C) Generation

In the D2C method, our objective is to enhance the diversity of documents and ensure that the documents are more realistic than those in C2D, thereby reducing the distribution shift between synthetic documents used during training and real documents at test time. To achieve this, we assume that we have access to a set of human-written documents to start with. The goal is to generate claims and pair them with portions of these human written documents, which, once again, require multi-sentence, multi-fact reasoning to check the claims.

Step 1: Chunk-level summarization We first divide a human written document into three chunks $\{D_1, D_2, D_3\}$ with approximately equal length. We then use GPT-4 to generate a summary sentence for each chunk, resulting in a set of summary sentences $\mathbf{c} = \{c_1, c_2, c_3\}$. We assume these generated summary sentences are factually consistent with respect to their corresponding chunks, *i.e.* $(D_i, c_i, 1)$ for all i, as each chunk is short and LLMs can almost always generate factual summaries in this setting (Zhang et al., 2024).

Step 2: Claim decomposition and subclaim augmentation Similar to the C2D method, for a summary sentence c_i in $\mathbf{c}$, we decompose it into atomic facts $\mathbf{a_i} = \{a_{i,1}, \ldots, a_{i,l}\}$, and create a set of augmented subclaims $\mathrm{Aug}(c_i) = \{\texttt{Merge}(\mathbf{a}'_i) : \forall \mathbf{a}'_i \in \texttt{Power}(\mathbf{a}_i)\}$.

Step 3: Document-claim augmentation This step aims to do data augmentation on a (D_i, c_i) pair. Given a chunk $D_i = \texttt{Concat}(\mathbf{s})$, which is the



Hình 3: Quy trình tạo dữ liệu tổng hợp của chúng tôi: C2D (phía trên) và D2C (phía dưới). Chúng tôi minh họa với một tuyên bố chứa hai sự kiện cơ bản. Ví dụ về dữ liệu được tạo có thể được tìm thấy trong Phụ lục D.

độ khó của nhiệm vụ bằng cách đảm bảo rằng cần có lập luận nhiều câu để phân loại chính xác một tuyên bố.

Bước 4: Tạo tài liệu không hỗ trợ Theo cách xây dựng, một sự thật nguyên tử a_i trong tuyên bố c được hỗ trợ bởi cặp câu (s_i,1,s_i,2) được đề cập trong tài liệu D đã tạo ra. Do đó, bằng cách bỏ một trong các câu của cặp trong một tài liệu mới tạo D', có khả năng a_i, và do đó c, không còn được D' hỗ trợ (trừ các trường hợp trùng lặp trong các câu s). Một cách chính thức hơn, chúng ta có thể xây dựng một tài liệu $D'_{a_{i\setminus j}}$ mà có lẽ không thể hỗ trợ sự thật a_i trong c (và do đó c) bằng cách loại bỏ câu $s_{i,j}$ khỏi cặp câu của nó:

$$D'_{a_{i\setminus j}} = \texttt{PassageGen}(\mathbf{s} \setminus s_{i,j}),$$

đối với tất cả $i \in \{1, \ldots, l\}$ và $j \in \{1, 2\}$ (Hình 3; góc trên bên phải). Để thu thập các tài liệu không ủng hộ cho luận điểm c, chúng tôi giữ lại $D'_{a_{i\setminus j}}$ nếu a_i không thể được hỗ trợ bởi thông tin kết hợp từ các câu còn lại trong cặp câu của nó và các sự kiện cơ bản khác ($s_{i,\,3-j} \cup \{a \setminus a_i\}$) thông qua việc kiểm tra mô phỏng suy luận bởi GPT-4. Lưu ý rằng việc kiểm tra suy luận này lần nữa chính xác hơn so với việc kiểm tra trực tiếp a_i đối với $D'_{a_{i\setminus j}}$ do ngữ cảnh ngắn hơn.

Bước 5: Ghép cặp các tuyên bố phụ và các tài liệu đã tạo Chúng tôi đã thu thập các bộ đôi (D, c, 1) và ($D'_{a_{i\setminus j}}$, c, 0) cho một số i và j. Chúng tôi có thể tăng cường dữ liệu này để tạo ra nhiều ví dụ hơn. Trước tiên, chúng tôi tạo tập hợp lũy thừa Power(a), bao gồm t ất cả các tập hợp con có thể có của các sự kiện nguyên tử a trong c, nhưng loại trừ tập rỗng. Sau đó, chúng tôi tạo một tập hợp các tuyên bố phụ đã được tăng cường Aug(c) bằng cách kết hợp các sự kiện nguyên tử từ mỗi tập con:

$$\mathrm{Aug}(c) = \{\texttt{Merge}(\mathbf{a}') : \forall \mathbf{a}' \in \texttt{Power}(\mathbf{a})\}.$$

Theo đó, chúng ta thu được các bộ (D, c', 1) cho mỗi $c' \in$ Aug(c). Tương tự, đối với mỗi $D'_{a_{i\setminus j}}$, chúng ta tạo các bộ ($D'_{a_{i\setminus j}}$, Merge(a′), 1) nếu $a_i \notin$ a′, chỉ ra rằng tài liệu vẫn hỗ trợ tuyên bố phụ khi không có sự kiện nguyên tử a_i. Ngược lại, chúng ta có ($D'_{a_{i\setminus j}}$, Merge(a′), 0) nếu $a_i \in$ a′, gợi ý rằng tài liệu không hỗ trợ tuyên bố phụ do thiếu a_i.

Bởi vì cùng một phụ đề được hỗ trợ bởi một số tài liệu và không được hỗ trợ bởi những tài liệu khác tùy thuộc vào việc có hay không có các sự kiện nguyên tử cụ thể, chúng ta đạt được cùng những lợi ích mà việc huấn luyện trên các bộ đối chiếu mang lại (Cao và Wang, 2021; Liu et al., 2022; Tang et al., 2023b), cụ thể là làm cho mô hình nhạy cảm hơn với các chi tiết của ranh giới quyết định và khuyến khích nó xem xét tất cả các sự kiện nguyên tử trong một tuyên bố khi dự đoán.

3.2 Tạo DoctoClaim (D2C)

Trong phương pháp D2C, mục tiêu của chúng tôi là tăng tính đa dạng của các tài liệu và đảm bảo rằng các tài liệu thực tế hơn so với những tài liệu trong C2D, từ đó giảm sự chênh lệch phân phối giữa các tài liệu tổng hợp được sử dụng trong quá trình huấn luyện và các tài liệu thực tế khi kiểm tra. Để đạt được điều này, chúng tôi giả sử rằng chúng tôi có quyền truy cập vào một tập hợp các tài liệu viết bởi con người để bắt đầu. Mục tiêu là tạo ra các tuyên bố và ghép chúng với các phần của những tài liệu viết bởi con người này, điều này, một lần nữa, đòi hỏi khả năng lập luận nhiều câu, nhiều sự kiện để kiểm tra các tuyên bố.

Bước 1: Tóm tắt ở cấp độ đoạn Chúng tôi trước tiên chia một tài liệu do con người viết thành ba đoạn $\{D_1, D_2, D_3\}$ có độ dài xấp xỉ bằng nhau. Sau đó, chúng tôi sử dụng GPT-4 để tạo một câu tóm tắt cho mỗi đoạn, dẫn đến một tập hợp các câu tóm tắt c $= \{c_1, c_2, c_3\}$. Chúng tôi giả định rằng các câu tóm tắt được tạo ra này là nhất quán về mặt thực tế so với các đoạn tương ứng của chúng, tức là (D_i, c_i, 1) cho tất cả i, vì mỗi đoạn khá ngắn và các mô hình ngôn ngữ lớn (LLMs) hầu như luôn có thể tạo ra các bản tóm tắt chính xác trong bối cảnh này (Zhang et al., 2024).

Bước 2: Phân rã tuyên bố và tăng cường các tuyên bố phụ Tương tự phương pháp C2D, đối với một câu tóm tắt c_i trong c, chúng tôi phân rã nó thành các sự kiện nguyên tử $\mathbf{a_i} = \{a_{i,1}, \ldots, a_{i,l}\}$, và tạo ra một tập hợp các tuyên bố phụ được tăng cường Aug(c_i) = {Hợp nhất(a′$_i$) : ∀a′$_i$ ∈Công suất(a$_i$)}.

Bước 3: Tăng cường tài liệu-đề xuất Bước này nhằm thực hiện tăng cường dữ liệu trên một cặp (D_i, c_i). Cho một đoạn D_i = Concat(s), đó là

Data	Size	Uniq. Claim	Uniq. Doc	Doc Len	Claim Len	% of Neg
C2D	7076	2004	1188	189	19	42%
D2C	7319	1392	4967	164	12	65%

Table 1: **Statistics of synthetic training data.** Amount of synthetic data for training, the number of unique claims and documents, the average number of words in documents and claims, and the proportion of unsupported claims.

concatenation of n sentences $\mathbf{s} = \{s_{i,1}, ..., s_{i,n}\}$, we construct new documents by iteratively removing each sentence $s_{i,j}$ from $\mathbf{s}$:

$$D'_{i\setminus j} = \texttt{Concat}(\mathbf{s} \setminus \{s_{i,j}\}).$$

We then determine the entailment label for each atomic fact $a_{i,k}$ in c_i, where $k \in \{1, \ldots, l\}$:

$$L^{-j}(a_{i,k}) = \text{Ent}(D'_{i\setminus j}, a_{i,k}) \in \{0, 1\}.$$

Similar to step 5 in C2D, if $L^{-j}(a_{i,k}) = 1$ for all $a_{i,k} \in \mathbf{a}'_i$, we create tuples $(D'_{i\setminus j}, \texttt{Merge}(\mathbf{a}'_i), 1)$. Conversely, if there exists any $a_{i,k} \in \mathbf{a}'_i$ such that $L^{-j}(a_{i,k}) = 0$, we then create tuples $(D'_{i\setminus j}, \texttt{Merge}(\mathbf{a}'_i), 0)$.

Step 4: Cross-document-claim augmentation The objective of this step is to perform data augmentation on a (D_j, c_i) pair, where $j \neq i$. The rationale behind this is that the important information in a document can be conveyed multiple times in various ways. Given that each chunk D_i has an associated summary c_i, it is probable that the summary c_i conveys some information that can be indirectly supported by other chunks D_j within the document, even if D_j are not used to generate c_i. Therefore, we consider chunks D_j, where $j \neq i$, as more challenging chunks to either support or refute the claim c_i or its atomic facts $\mathbf{a}_i$.

More formally, we determine the entailment label for each atomic fact $a_{i,k}$ in c_i, using the document chunk D_j, where $k \in \{1, \ldots, l\}$, and $j \neq i$:

$$L^{D_j}(a_{i,k}) = \text{Ent}(D_j, a_{i,k}) \in \{0, 1\}.$$

If $L^{D_j}(a_{i,k}) = 1$ for all $a_{i,k} \in \mathbf{a}'_i$, we create tuples $(D_j, \texttt{Merge}(\mathbf{a}'_i), 1)$. Conversely, if there exists any $a_{i,k} \in \mathbf{a}'_i$ such that $L^{D_j}(a_{i,k}) = 0$, we then create tuples $(D_j, \texttt{Merge}(\mathbf{a}'_i), 0)$.

3.3 MINICHECK Models

We fine-tune three models with various model architectures by leveraging our synthetic data. We use the standard cross-entropy loss for all models. See Appendix G for training details.

MiniCheck-DBTA and MiniCheck-FT5 As models trained on the ANLI dataset (Nie et al., 2020a) have demonstrated strong performance (Kamoi et al., 2023; Honovich et al., 2022), we integrate our data with the ANLI dataset for fine-tuning `deberta-v3-large` (He et al., 2021) and `flan-t5-large` (Chung et al., 2022). We take a subset (21K) of the ANLI training data, selecting examples where their trained entailment models made incorrect predictions during dataset construction. Training on more of ANLI was not effective.

Combining these 21K datapoints with our 14K-sized dataset, we have 35K training datapoints in total. We map the labels `contradiction` and `neutral` from ANLI to `unsupported`.

MiniCheck-RBTA We also explore whether it is possible to improve upon the previous AlignScore (Zha et al., 2023) system, the existing SOTA specialized fact-checking model. We fine-tune the tuned `roberta-large` (Liu et al., 2019) model from AlignScore with a binary classification head, on our 14K synthetic datapoints.

Producing classification decisions Although our task is framed as binary classification, in reality the models we have are of the form $M(D_i, c_i) \rightarrow z \in \mathbb{R}$, mapping each (document, claim) pair to a score in the range $z \in [v_{\min}, v_{\max}]$. Following Laban et al. (2022); Zha et al. (2023); Tang et al. (2023a), we convert each method into a binary classifier $M(D_i, c_i) \rightarrow \{0, 1\}$ by picking a threshold t such that we predict 1 if $M(D_i, c_i) > t$ and 0 otherwise. Unless otherwise specified, we set $t = 0.5$.

4 LLM-AGGREFACT Benchmark

We construct a fact verification benchmark, LLM-AGGREFACT, by aggregating 10 of the most up-to-date publicly available datasets on factual consistency evaluation across both closed-book and grounded generation settings.

Characteristics In LLM-AGGREFACT, all datasets contain human-annotated `(document, claim, label)` tuples. The documents come from diverse sources, including Wikipedia paragraphs, interviews, web text, covering domains such as news, dialogue, science, and healthcare. The claims to be verified are mostly generated from recent generative models (except for one dataset

Data	Size	Độc nhất Yêu cầu	Độc nhất Doc	Doc Len	Yêu cầu Len	% of Neg
C2D	7076	2004	1188	189	19	42%
D2C	7319	1392	4967	164	12	65%

Bảng 1: Thống kê dữ liệu huấn luyện tổng hợp. Lượng dữ liệu tổng hợp để huấn luyện, số lượng tuyên bố và tài liệu duy nhất, số lượng từ trung bình trong các tài liệu và tuyên bố, và tỷ lệ các tuyên bố không được hỗ trợ.

nối các câu n s $= \{s_{i,1}, ..., s_{i,n}\}$, chúng tôi xây dựng các tài liệu mới bằng cách lặp đi lặp lại loại bỏ từng câu $s_{i,j}$ từ s:

$$D'_{i\setminus j} = \texttt{Concat}(\mathbf{s} \setminus \{s_{i,j}\}).$$

Chúng tôi sau đó xác định nhãn suy diễn cho mỗi sự kiện nguyên tử $a_{i,k}$ trong c_i, nơi $k \in \{1, \ldots, l\}$:

$$L^{-j}(a_{i,k}) = \text{Ent}(D'_{i\setminus j}, a_{i,k}) \in \{0, 1\}.$$

Tương tự như bước 5 trong C2D, nếu $L^{-j}(a_{i,k}) = 1$ cho tất cả $a_{i,k} \in$ a$'_i$, chúng ta tạo các bộ ($D'_{i\setminus j}$, Merge(a$'_i$), 1). Ngược lại, nếu tồn tại bất kỳ $a_{i,k} \in$ a$'_i$ nào sao cho $L^{-j}(a_{i,k}) = 0$, chúng ta sẽ tạo các bộ ($D'_{i\setminus j}$, Merge(a$'_i$), 0).

Bước 4: Tăng cường tuyên bố xuyên tài liệu Mục tiêu của bước này là thực hiện tăng cường dữ liệu trên một cặp (D_j, c_i), nơi $j \neq i$. Lý do đằng sau việc này là thông tin quan trọng trong một tài liệu có t hể được truyền đạt nhiều lần theo nhiều cách khác nhau. Vì mỗi đoạn D_i đều có một bản tóm tắt liên quan c_i, có khả năng bản tóm tắt c_i truyền đạt một số thông tin có thể được hỗ trợ gián tiếp bởi c ác đoạn khác D_j trong tài liệu, ngay cả khi D_j không được sử dụng để tạo ra c_i. Do đó, chúng tôi xem các đoạn D_j, nơi $j \neq i$, là những đoạn khó hơn để hỗ trợ hoặc phản bác tuyên bố c_i hoặc các sự kiện nguyên tử của nó a$_i$.

Một cách trang trọng hơn, chúng tôi xác định nhãn bao hàm cho mỗi sự kiện nguyên tử $a_{i,k}$ trong c_i, sử dụng đoạn tài liệu D_j, nơi $k \in \{1, \ldots, l\}$, và $j \neq i$:

$$L^{D_j}(a_{i,k}) = \text{Ent}(D_j, a_{i,k}) \in \{0, 1\}.$$

Nếu $L^{D_j}(a_{i,k}) = 1$ đối với tất cả $a_{i,k} \in$ a$'_i$, chúng ta tạo các bộ (D_j, Hợp nhất(a$'_i$), 1). Ngược lại, nếu tồn tại bất kỳ $a_{i,k} \in$ a$'_i$ nào mà $L^{D_j}(a_{i,k}) = 0$, thì chúng t a tạo các bộ (D_j, Hợp nhất(a$'_i$), 0).

3.3 Mô hình MINICHECK

Chúng tôi tinh chỉnh ba mô hình với các kiến trúc mô hình k hác nhau bằng cách tận dụng dữ liệu tổng hợp của mình. Chúng tôi sử dụng hàm mất mát chéo chuẩn cho tất cả các mô hình. Xem Phụ lục G để biết chi tiết huấn luyện.

MiniCheck-DBTA và MiniCheck-FT5 Là các mô hình được huấn luyện trên tập dữ liệu ANLI (Nie et al., 2020a) đã thể hiện hiệu suất mạnh (Kamoi et al., 2023; Honovich et al., 2022), chúng tôi tích hợp dữ liệu của mình với tập dữ liệu ANLI để tinh chỉnh deberta-v3-large (He et al., 2021) và flan-t5-large (Chung et al., 2022). Chúng tôi lấy một tập con (21 K) của dữ liệu huấn luyện ANLI, chọn các ví dụ mà mô hình suy diễn được huấn luyện của họ đã đưa ra dự đoán sai trong quá trình xây dựng tập dữ li ệu. Việc huấn luyện trên nhiều dữ liệu ANLI hơn không mang lại hiệu quả.

Kết hợp 21 nghìn điểm dữ liệu này với bộ dữ liệu kích thước 14 nghìn của chúng tôi, chúng tôi có tổng cộng 35 nghìn điểm dữ liệu để huấn luyện. Chúng tôi ánh xạ nhãn mâu thuẫn và trung lập từ ANLI sang không được hỗ trợ.

MiniCheck-RBTA Chúng tôi cũng khám phá xem liệu có thể cải thiện so với hệ thống AlignScore trước đó (Zha et al., 2023), mô hình kiểm tra sự thật chuyên biệt SOTA hiện có hay không. Chúng tôi ti nh chỉnh mô hình roberta-large đã được tinh chỉnh (Liu et al., 2019) từ AlignScore với một đầu phân loại nhị phân, trên 14 nghìn điểm dữ liệu tổng hợp của chúng tôi.

Ra quyết định phân loại Mặc dù nhiệm vụ của chúng tôi được định hình như phân loại nhị phân, trên thực tế các mô hình chúng tôi có là dạng $M(D_i, c_i) \rightarrow z \in \mathbb{R}$, ánh xạ mỗi cặp (tài liệu, tuyên bố) thành một điểm số trong phạm vi $z \in [v_{\min}, v_{\max}]$. Theo Laban et al. (2022); Zha et al. (2023); Tang et al. (2023a), chúng tôi chuyển đổi mỗi phương pháp thành một bộ phân loại nhị phân $M(D_i, c_i) \rightarrow \{0, 1\}$ bằng cách chọn một ngưỡng t sao cho chúng tôi dự đoán 1 nếu $M(D_i, c_i) > t$ và 0 trong các trường hợp khác. Trừ khi có chỉ định khác, chúng tôi đặt $t = 0.5$.

4 Tiêu chuẩn LLM-AGGREFACT

Chúng tôi xây dựng một chuẩn kiểm tra xác minh sự thật, LLM-AGGREFACT, bằng cách tổng hợp 10 bộ dữ liệu công khai mới nhất về đánh giá độ nhất quán thực tế trong cả hai thiết lập sinh văn bản theo cơ sở dữ liệu đóng và có nền tảng thực tế.

Đặc điểm Trong LLM-AGGREFACT, tất cả các bộ dữ liệu đều chứa các bộ ba (tài liệu, tuyên bố, nhãn) được chú thích bởi con người. Các tài liệu đến từ nhiều nguồn khác nhau, bao gồm các đoạn văn Wikipedia, phỏng vấn, văn bản web, bao phủ các lĩnh vực như tin tức, đối thoại, khoa học và chăm sóc sức khỏe. Các tuyên bố cần được xác minh chủ yếu được tạo ra từ các mô hình sinh gần đây (ngoại trừ một bộ dữ liệu).

Type	Dataset	Feature
Fixed-Doc Generation	AGGREFACT (CNN/XSum)	Summaries from SOTA fine-tuned summarizers
	TOFUEVAL (MediaS/MeetB)	Topic-focused dialogue summaries from LLMs
Retrieve-then Generate	CLAIMVERIFY	(Check-worthy) sentences from LLMs/ search engines' responses to search queries
	LFQA	
	EXPERTQA	
Post-Hoc Grounding	EXPERTQA	
	REVEAL	
	FACTCHECK-GPT	
Written Claims	WICE	Wikipedia claims with citations

Figure 4: 10 datasets in LLM-AGGREFACT. Details of these datasets as well as related but excluded datasets can be found in Appendix C.

of human-written claims), without any human intervention in any format, such as injecting certain error types into model-generated claims. An overview of the LLM-AGGREFACT is shown in Figure 4, with statistics and detailed dataset descriptions in Appendix C.

4.1 Benchmark Details

Validation/Test set split For the datasets from AGGREFACT and TOFUEVAL, as well as WICE and CLAIMVERIFY, we directly use the existing validation and test splits from the original work. For REVEAL, FACTCHECK-GPT, EXPERTQA and LFQA, we randomly divide each of them into validation and test sets (50%/50%), assuring that responses to unique queries do not appear in both sets.

One potential use of the validation data is to allow for **per-dataset threshold tuning**. This setting is used in substantial past work (Laban et al., 2022; Luo et al., 2023; Zha et al., 2023; Tang et al., 2023a, 2024). However, we do not follow this trend in order to focus on building systems that can be deployed zero-shot across multiple downstream tasks, without any additional hyperparameter tuning. Instead, for $M(d, c) \rightarrow z \in [v_{\min}, v_{\max}]$, the threshold is set as the midpoint of the output score range $t = (v_{\min} + v_{\max})/2$, which is 0.5 for most fact-checkers. In practice, most fact-checkers return scores at the extremes of the range, so small tweaks on this procedure have little effect. See Appendix B.1 for the results of the threshold tuning setting, which yields qualitatively similar results.

Evaluation Metric Following Laban et al. (2022); Fabbri et al. (2022); Tang et al. (2023a), we evaluate the performance of fact-checkers using balanced accuracy (BAcc): $\text{BAcc} = \frac{1}{2}\left(\frac{\text{TP}}{\text{TP+FN}} + \frac{\text{TN}}{\text{TN+FP}}\right)$, where TP, TN, FP, and FN represent true/false positives/negatives.

5 Experimental Setup

We include the following specialized fact-checkers: **T5-NLI-Mixed** (Honovich et al., 2022), **DAE** (Goyal and Durrett, 2021), **QAFactEval** (Fabbri et al., 2022), **SummaC-ZS** and **SummaC-CV** (Laban et al., 2022), **AlignScore** (Zha et al., 2023), and **FT5-ANLI-L** that fine-tunes `flan-t5-large` on the full ANLI training set. A meta-comparison of those specialized fact-checkers and our models can be found in Table 3. More inference details can be found in Appendix E.2.

We also include the following LLMs as fact-checkers: **Gemini-Pro** (Team et al., 2023), **PaLM2-Bison** (Thoppilan et al., 2022), **Mistral-8x7B**, **Mistral-Large** (Jiang et al., 2024), **Claude 2.1**, **Claude 3 Opus** (Bai et al., 2022), **GPT-3.5** and **GPT-4** (OpenAI, 2023). More details about the models can be found in Appendix E.1. For the LLM-based fact-checkers, we adapt a prompt from Luo et al. (2023) for zero-shot prediction, which can be found in Appendix H.

6 Results

6.1 Main Results

Our synthetic data improves performance across diverse model architectures. Table 2 demonstrates that our synthetic data gives strong performance when used in three different backbone models: RoBERTa, DeBERTa, and Flan-T5. These models outperform prior models of a similar scale. Notably, MiniCheck-FT5 achieves a 4.3% overall improvement over AlignScore, outperforming it on 6 out of 10 datasets and matching its performance on the remaining 4. We attribute its additional 2% gain over MiniCheck-RBTA and -DBTA to its larger model size. However, model size alone does not guarantee superior performance, as evidenced by T5-NLI-Mixed and FT5-ANLI-L, which, despite being trained on NLI datasets, underperform on most of the benchmark settings. This underscores the importance of training data selection in addition to model capacity.

Our models achieve performance on par with the most capable LLM-based fact-checkers. In

Type	Bộ dữ liệu	Tính năng
Tài liệu cố định Thế hệ	AGGREFACT (CNN/XSum)	Tóm tắt từ SOTA bộ tóm tắt được điều chỉnh tinh chỉnh
	TOFUEVAL (MediaS/GặpB)	Đối thoại tập trung vào chủ đề tóm tắt từ LLM
Truy xuất-rồi Tạo	CLAIMVERIFY	(Đáng kiểm tra) các câu từ LLMs/ các công cụ tìm kiếm phản hồi với tìm kiếm các tr uy vấn
	LFQA	
	EXPERTQA	
Hậu nghiệm Tiếp đất	EXPERTQA	
	REVEAL	
	FACTCHECK-GPT	
Yêu cầu Bằng văn bản	WICE	Wikipedia cho rằng với trích dẫn

Hình 4: 10 bộ dữ liệu trong LLM-AGGREFACT. Chi tiết của các bộ dữ liệu này cũng như các bộ dữ liệu liên quan nhưng bị loại trừ có thể được tìm thấy trong Phụ lục C.

của các tuyên bố do con người viết), mà không có bất kỳ sự can thiệp nào của con người dưới bất kỳ hình thức nào, chẳng hạn như chèn một số loại lỗi nhất định vào các tuyên bố do mô hình tạo ra. Một tổng quan về LLM-AGGREFACT được hiển thị trong Hình 4, với các thống kê và mô tả chi tiết về bộ dữ liệu trong Phụ lục C.

4.1 Chi tiết chuẩn đối chiếu

Phân chia tập Validation/Test Đối với các bộ dữ liệu từ AGGREFACT và TOFUEVAL, cũng như WICE và CLAIMVERIFY, chúng tôi trực tiếp sử dụng các phân chia validation và test hiện có từ công trình gốc. Đối với REVEAL, FACTCHECK-GPT, EXPERTQA và LFQA, chúng tôi chia ngẫu nhiên mỗi bộ thành tập validation và test (50%/50%), đảm bảo rằng các phản hồi cho các truy vấn duy nhất không xuất hiện trong cả hai tập.

Một ứng dụng tiềm năng của dữ liệu xác thực l à cho phép điều chỉnh ngưỡng theo từng tập dữ liệu. Cài đặt này đã được sử dụng trong nhiều công trình trước đây (Laban et al., 2022; Luo et al., 2023; Zha et al., 2023; Tang et al., 2023a, 2024). Tuy nhiên, chúng tôi không theo xu hướng này nhằm tập tr ung vào việc xây dựng hệ thống có thể triển khai zero-shot trên nhiều nhiệm vụ hạ nguồn khác nhau, mà không cần điều chỉnh siêu tham số bổ sung nào. Thay vào đó, đối với $M(d, c) \rightarrow z \in [v_{\min}, v_{\max}]$, ngưỡng được đặt là điểm giữa của khoảng điểm đầu ra $t = (v_{\min} + v_{\max})/2$, là 0.5 đối với hầu hết các công cụ kiểm tra sự thật. Trong thực tế, hầu hết các công cụ kiểm tra sự thật trả về điểm ở các cực của khoảng, vì vậy các điều chỉnh nhỏ trên thủ tục này có tác động rất ít. Xem Phụ lục B.1 để biết kết quả của cài đặt điều chỉnh ngưỡng, cho kết quả tương tự về mặt chất lượng.

Thước đo đánh giá Theo Laban et al. (2022); Fabbri et al. (2022); Tang et al. (2023a),

chúng tôi đánh giá hiệu suất của các nhà kiểm chứng sự thật bằng cách sử dụng độ chính xác cân bằng (BAcc): $\text{BAcc} = \frac{1}{2}\left(\frac{\text{TP}}{\text{TP+FN}} + \frac{\text{TN}}{\text{TN+FP}}\right)$, trong đó TP, TN, FP và FN đại diện cho các giá trị dương/âm đúng/sai.

5 Thiết lập Thí nghiệm

Chúng tôi bao gồm các trình kiểm tra sự thật chuyên biệt sau: T5-NLI-Mixed (Honovich et al., 2022), DAE (Goyal và Durrett, 2021), QAFactEval (Fabbri et al., 2022), SummaC-ZS và SummaC-CV (Laban et al., 2022), AlignScore (Zha et al., 2023), và FT5-ANLI-L, tinh chỉnh flan-t5-large trên toàn bộ tập huấn luyện ANLI. Một so sánh tổng hợp các trình kiểm tra sự thật chuyên biệt đó và các mô hình của chúng tôi có thể được tìm thấy trong Bảng 3. Thêm chi tiết suy luận có thể được tìm thấy trong Phụ lục E.2.

Chúng tôi cũng bao gồm các mô hình LLM sau đây như những người kiểm tra sự thật: Ge mini-Pro (Team et al., 2023), PaLM2-Bison (Thoppilan et al., 2022), Mistral-8x7B, Mistral-Large (Jiang et al., 2024), Claude 2.1, Claude 3 Opus (Bai et al., 2022), GPT-3.5 và GPT-4 (OpenAI, 2023). Thêm chi tiết về các mô hình có thể được tì m thấy trong Phụ lục E.1. Đối với những người kiểm tra sự thật dựa trên LLM, chúng tôi điều chỉnh một lời nhắc từ Luo et al. (2023) để dự đoán zero-shot, mà có thể được tìm thấy trong Phụ lục H.

6 kết quả

6.1 Kết quả chính

Dữ liệu tổng hợp của chúng tôi cải thiện hiệu suất trên nhiều kiến trúc mô hình khác nhau. Bảng 2 cho thấy dữ liệu tổng hợp của chúng tôi mang lại hiệu suất mạnh khi được sử dụng trong ba mô hì nh nền tảng khác nhau: RoBERTa, DeBERTa và Flan-T5. Những mô hình này vượt trội hơn các mô hình trước đó có quy mô tương tự. Đáng chú ý, MiniCheck-FT5 đạt được cải thiện tổng thể 4,3% so với AlignScore, vượt trội hơn nó ở 6 trên 10 bộ dữ liệu và tương đương hiệu suất ở 4 bộ dữ liệu còn l ại. Chúng tôi cho rằng mức tăng thêm 2% so với MiniCheck-RBTA và -DBTA là nhờ kích thước mô hình lớn hơn. Tuy nhiên, chỉ riêng kích thước mô hình không đảm bảo hiệu suất vượt trội, như được chứng minh bởi T5-NLI-Mixed và FT5-ANLI-L, mặc dù được đào tạo trên các bộ dữ liệu NLI, nhưng hiệu suất kém hơn trên hầu hết các cài đặt đánh giá chuẩn. Điều này nhấn mạnh tầm quan trọng của việc lựa chọn dữ liệu đào tạo bên cạnh khả năng của mô hình.

Các mô hình của chúng tôi đạt hiệu suất tương đương với các công cụ kiểm tra sự thật dựa trên LLM có khả năng cao nhất. Trong

Model Name	LLM-AGGREFACT (*without* threshold tuning)										
	AGGREFACT		TOFUEVAL		WICE	REVEAL	CLAIM VERIFY	FACT CHECK	EXPERT QA	LFQA	Avg
	CNN	XSum	MediaS	MeetB							
Gemini-Pro	49.4	60.6	63.8	65.8	65.8	85.5	61.8	76.8	56.8	75.9	66.2
PaLM2-Bison	52.4	59.0	68.3	73.6	63.4	84.2	60.5	76.4	56.6	71.4	66.6
Mistral-8x7B	55.0	65.5	68.5	73.3	63.8	80.8	64.3	75.1	56.3	70.8	67.3
GPT-3.5	63.2	72.4	66.8	73.4	68.5	84.7	65.2	70.8	57.2	73.8	69.6
Claude-2.1	59.9	66.4	69.2	72.3	64.3	88.2	69.7	79.3	59.8	78.2	70.7
Mistral-Large	58.4	76.3	67.3	78.9	76.6	88.4	67.6	79.0	60.0	81.7	73.4
Claude-3 Opus	65.2	72.4	74.1	82.4	75.0	83.8	69.3	78.8	58.8	81.6	74.1
GPT-4	66.7	76.5	71.4	79.9	80.4	87.8	67.6	79.9	59.2	83.1	75.3
SummaC-CV	65.2	54.5	63.7	62.8	54.3	67.7	70.9	53.4	54.9	62.1	62.1
T5-NLI-Mixed	54.6	52.3	59.1	55.3	55.3	87.2	59.5	69.0	55.6	61.8	61.0
FT5-ANLI-L	51.2	60.0	57.4	60.1	67.0	77.5	58.3	67.7	52.2	63.0	61.4
DAE	50.8	59.1	65.1	69.5	58.5	81.3	64.0	72.5	56.2	72.2	64.9
QAFactEval	54.3	62.1	61.3	65.7	62.5	83.2	73.2	66.1	56.0	80.6	66.5
SummaC-ZS	51.1	61.5	69.5	71.0	62.8	85.3	69.7	75.2	55.2	77.6	67.9
AlignScore	52.4	71.4	69.2	72.6	66.0	85.3	69.6	74.3	58.3	84.5	70.4
MiniCheck-DBTA	64.2	71.0	69.3	72.7	69.4	87.3	75.6	73.0	58.9	83.9	72.6
MiniCheck-RBTA	63.7	70.8	71.9	75.9	67.6	88.8	77.4	73.3	57.4	84.4	72.7
MiniCheck-FT5	69.9	74.3	73.6	77.3	72.2	86.2	74.6	74.7	59.0	85.2	74.7

Table 2: Performance (BAcc) of models on the test set of LLM-AGGREFACT without per-dataset threshold tuning. Models are split into *LLM-based fact-checkers* | *specialized fact-checkers* | *Ours*. We highlight the best performance for each dataset, where multiple green highlights indicate systems indistinguishable from the best according to a paired bootstrap test with 1000 runs and p-value < 0.05. Details for -Dectx and -Decmp are in Section 7. Our MiniCheck models outperform other specialized evaluators and MiniCheck-FT5 reaches the performance of GPT-4.

Model Name	Backbone Model	Model Size	# FT Data	Cost ($)
T5-NLI-Mixed	T5-XXL	11B	1,697K	7.39
FT5-ANLI-L	Flan-T5-L	770M	163K	0.24
DAE	ELECTRA-B	110M	95K	0.26
QAFactEval	multiple*	1.4B	-	1.87
SummaC-ZS	ALBERT-XL	60M	371K	0.85
SummaC-CV	ALBERT-XL	60M	381K	0.85
AlignScore	RoBERTa-L	355M	4,700K	0.20
MiniCheck-RBTA	AlignScore	355M	14K	0.20
MiniCheck-DBTA	DeBERTa-L	355M	35K	0.20
MiniCheck-FT5	Flan-T5-L	770M	35K	0.24

Table 3: Comparison of specialized fact-checkers on model sizes, training data sizes, and the inference cost ($0.8/GPU-hr) on the 13K LLM-AGGREFACT test set. *QAFactEval contains several model components, which sum up to 1.4B in size.

the top rows of Table 2, we present the performance of strong LLM-based fact-checkers. We observe that existing specialized fact-checkers achieve similar performance to non-frontier LLM-based fact-checkers like Mistral-8x7B and GPT-3.5. MiniCheck-RBTA and MiniCheck-DBTA can surpass these non-frontier LLM-based fact-checkers by a large margin. MiniCheck-FT5 achieves the same performance as Claude-3 Opus and is close to GPT-4, but with a much smaller model size.

Extended Analysis See Appendix A for an intrinsic evaluation on our synthethic data and an ablation study on our best model MiniCheck-FT5.

6.2 Computational Cost Comparison

We compare the computational cost of specialized fact-checkers and LLMs on the test set of LLM-AGGREFACT. For specialized fact-checkers, we use our own hardware and convert the prediction time on our GPUs to the equivalent cost of using cloud computing services (see Appendix E.2.1 for details). For LLM-based fact-checkers, we compute the costs of corresponding API calls. Results are shown in Table 3 and 4. We see that specialized models in general have much lower inference costs. In particular, our most capable model MiniCheck-FT5 has almost the same performance as GPT-4 but is more than 400 times cheaper.

7 Rethinking LLM Fact-Checking

We now revisit two other stages of the typical LLM fact-checking pipeline: claim decomposition and decontextualization. Surprisingly, we find that claim decomposition is not needed in our settings, contradicting prior work (Yang and Zhu, 2021; Kamoi et al., 2023). Furthermore, we find that decontextualization doesn't help on our benchmark,

Mô hình Name	LLM-AGGREFACT (không điều chỉnh ngưỡng)										
	AGGREFACT		ĐÁNH GIÁ TOFU		WICE TIẾT LỘ		YÊU CẦU XÁC MINH	FACT KIỂM TRA	CHUYÊN GIA QA	LFQA Trung bình	
	CNN	XSum	MediaS	MeetB							
Gemini-Pro	49.4	60.6	63.8	65.8	65.8	85.5	61.8	76.8	56.8	75.9	66.2
PaLM2-Bison	52.4	59.0	68.3	73.6	63.4	84.2	60.5	76.4	56.6	71.4	66.6
Mistral-8x7B	55.0	65.5	68.5	73.3	63.8	80.8	64.3	75.1	56.3	70.8	67.3
GPT-3.5	63.2	72.4	66.8	73.4	68.5	84.7	65.2	70.8	57.2	73.8	69.6
Claude-2.1	59.9	66.4	69.2	72.3	64.3	88.2	69.7	79.3	59.8	78.2	70.7
Mistral-Large	58.4	76.3	67.3	78.9	76.6	88.4	67.6	79.0	60.0	81.7	73.4
Claude-3 Opus	65.2	72.4	74.1	82.4	75.0	83.8	69.3	78.8	58.8	81.6	74.1
GPT-4	66.7	76.5	71.4	79.9	80.4	87.8	67.6	79.9	59.2	83.1	75.3
SummaC-CV	65.2	54.5	63.7	62.8	54.3	67.7	70.9	53.4	54.9	62.1	62.1
T5-NLI-Pha trộn	54.6	52.3	59.1	55.3	55.3	87.2	59.5	69.0	55.6	61.8	61.0
FT5-ANLI-L	51.2	60.0	57.4	60.1	67.0	77.5	58.3	67.7	52.2	63.0	61.4
DAE	50.8	59.1	65.1	69.5	58.5	81.3	64.0	72.5	56.2	72.2	64.9
Đánh giá sự thật QA	54.3	62.1	61.3	65.7	62.5	83.2	73.2	66.1	56.0	80.6	66.5
SummaC-ZS	51.1	61.5	69.5	71.0	62.8	85.3	69.7	75.2	55.2	77.6	67.9
ĐiểmCânChỉnh	52.4	71.4	69.2	72.6	66.0	85.3	69.6	74.3	58.3	84.5	70.4
MiniCheck-DBTA	64.2	71.0	69.3	72.7	69.4	87.3	75.6	73.0	58.9	83.9	72.6
MiniCheck-RBTA	63.7	70.8	71.9	75.9	67.6	88.8	77.4	73.3	57.4	84.4	72.7
MiniCheck-FT5	69.9	74.3	73.6	77.3	72.2	86.2	74.6	74.7	59.0	85.2	74.7

Bảng 2: Hiệu suất (BAcc) của các mô hình trên tập kiểm tra của LLM-AGGREFACT mà không điều chỉnh ngưỡng theo từng tập dữ liệu. Các mô hình được chia thành các bộ kiểm tra sự thật dựa trên LLM |, các bộ kiểm tra sự thật chuyên biệt | và mô hình của chúng tôi. Chúng tôi làm nổi bật hiệu suất tốt nhất cho mỗi tập dữ liệu, trong đó nhiều điểm nhấn màu xanh lá chỉ ra các hệ thống không thể phân biệt với hệ thống tốt nhất theo kiểm định bootstrap ghép cặp với 1000 lượt chạy và giá trị p < 0.05. Chi tiết về -Dectx và -Decmp được trình bày trong Mục 7. Các mô hình MiniCheck của chúng tôi vượt trội hơn các bộ đánh giá chuyên biệt khác và MiniCheck-FT5 đạt được hiệu suất tương đương GPT-4.

Mô hình Name	Xương sống Mô hình	Mô hình Size	# FT Data	Cost ($)
T5-NLI-Pha trộn	T5-XXL	11B	1.697K	7,39
FT5-ANLI-L	Flan-T5-L	770M	163K	0.24
DAE	ELECTRA-B	110M	95K	0.26
Đánh giá sự thật QA	nhiều*	1.4B	-	1.87
SummaC-ZS	ALBERT-XL	60M	371K	0.85
SummaC-CV	ALBERT-XL	60M	381K	0.85
ĐiểmCânChỉnh	RoBERTa-L	355 triệu	4.700 nghìn	0,20
MiniCheck-RBTA	ĐiểmCânChỉnh	355M	14K	0.20
MiniCheck-DBTA	DeBERTa-L	355M	35K	0.20
MiniCheck-FT5	Flan-T5-L	770M	35K	0.24

Bảng 3: So sánh các bộ kiểm tra sự thật chuyên biệt về kích thước mô hình, kích thước dữ liệu huấn luyện và chi phí suy luận (0,8 đô la/GPU-giờ) trên bộ kiểm tra 13K LLM-AGGREFACT. *QAFactEval bao gồm một số thành phần mô hình, tổng cộng có kích thước 1,4 tỷ.

Ở các hàng đầu của Bảng 2, chúng tôi trình bày hiệu suất của các bộ kiểm tra sự thật mạnh mẽ dựa trên LLM. Chúng tôi nhận thấy rằng các bộ kiểm tr a sự thật chuyên biệt hiện có đạt hiệu suất tương t ự như các bộ kiểm tra sự thật dựa trên LLM không tiên tiến như Mistral-8x7B và GPT-3.5. MiniCheck-RBTA và MiniCheck-DBTA có thể vượt xa các bộ kiểm tra sự thật dựa trên LLM không tiên tiến này. MiniCheck-FT5 đạt cùng hiệu suất với Claude-3 Opus và gần bằng GPT-4, nhưng với kích thước mô hình nhỏ hơn nhiều.

Phân tích mở rộng Xem Phụ lục A để đánh giá nội tại về dữ liệu tổng hợp của chúng tôi và một nghiên cứu loại bỏ trên mô hình tốt nhất của chúng tôi MiniCheck-FT5.

6.2 So sánh Chi phí Tính toán

Chúng tôi so sánh chi phí tính toán của các bộ kiểm tra sự thật chuyên dụng và các mô hình ngôn ngữ lớn (LLM) trên tập kiểm tra của LLM-AGGREFACT. Đối với các bộ kiểm tra sự thật chuyên dụng, chúng tôi sử dụng phần cứng của riêng mình và quy đổi thời gian dự đoán trên GPU sang chi phí tương đương khi sử dụng dịch vụ điện toán đám mây (xem Phụ lục E.2.1 để biết chi tiết). Đối với các bộ kiểm tra sự thật dựa trên LLM, chúng tôi tính toán chi phí của các lần gọi API tương ứng. Kết quả được trình bày trong Bảng 3 và 4. Chúng tôi thấy rằng các mô hình chuyên dụng nói chung có chi phí suy luận thấp hơn nhiều. Cụ thể, mô hình có khả năng cao nhất của chúng tôi, MiniCheck-FT5, có hiệu suất gần như tương đương với GPT-4 nhưng rẻ hơn hơn 400 lần.

7 Suy nghĩ lại về việc kiểm tra sự thật của LLM

Chúng tôi bây giờ xem xét lại hai giai đoạn khác của quy trình kiểm tra sự thật điển hình của LLM: phân tách tuyên bố và phá bối cảnh. Thật ngạc nhiên, chúng tôi nhận thấy rằng phân tách tuyên bố không cần thiết trong các thiết lập của chúng tôi, mâu thuẫn với các công trình trước đây (Yang và Zhu, 2021; Kamoi et al., 2023). Hơn nữa, chúng tôi nhận thấy rằng phá bối cả nh không giúp gì trên bộ chuẩn của chúng tôi.

Model Name	Cost ($)	Model Name	Cost ($)
Gemini-Pro	5.24	Claude-2.1	89.9
PaLM2-Bison	10.9	Claude-3 Opus	165
Mistral-8x7B	7.78	GPT-3.5	4.75
Mistral-Large	90.2	GPT-4	107
GPT-4-Dectx	161	GPT-4-Decmp	212

Table 4: Inference cost comparison for API models on the 13K LLM-AGGREFACT test set. Both decontextualization and decomposition add cost to GPT-4. Overall, decoding our test set with the most capable models incurs significant cost.

Model	Decomposition	Decontextualization
GPT-4	75.6 (↑ **0.3**)	75.3 (+**0.0**)
SummaC-CV	58.8 (↓ **3.3**)	60.8 (↓ **1.3**)
QAFactEval	64.6 (↓ **1.9**)	66.4 (↓ **0.1**)
SummaC-ZS	69.1 (↑ **1.2**)	67.7 (↓ **0.2**)
AlignScore	71.5 (↑ **1.1**)	70.4 (+**0.0**)
MiniCheck-RBTA	73.2 (↑ **0.5**)	72.4 (↓ **0.3**)
MiniCheck-DBTA	72.7 (↑ **0.1**)	71.2 (↓ **1.4**)
MiniCheck-FT5	73.3 (↓ **1.4**)	74.1 (↓ **0.6**)

Table 5: Average performance on the test set of LLM-AGGREFACT by aggregating predictions on decomposed claims (left); doing claim decontextualization where it is applicable (right). We show the performance change compared to predicting using original claims from Table 2. Full results in Appendix Tables 8 and 9.

although we believe that it is needed in general.

7.1 Claim Decomposition

We also experiment with a setting using claim decomposition. In this setting, we decompose each claim c_i into atomic facts $\mathbf{a}_i$ with the prompt from Kamoi et al. (2023) and use a fact-checker to predict the factuality label for each $(D_i, a_{i,k})$ pair, $k \in \{1, \ldots, l\}$. If all atomic facts are supported by the document, then the claim is supported, and unsupported otherwise. We do this for every dataset except FactCheck-GPT which is already atomic facts. There are typically 2-4 atomic facts per claim across datasets.

We show the results from GPT-4 and a subset of specialized fact-checkers in Table 5. We observe near-zero performance change for GPT-4 and mixed changes for specialized fact-checkers. **Overall, there is no clear indication that decomposing claims into atomic facts can consistently improve models' performance.** Because this approach increases the inference time and costs by a factor of 2-4 for different datasets, depending on the average number of atomic facts per claim, we believe it should not be used until it provides a clear accuracy benefit.[4]

7.2 Claim Decontextualization

As mentioned in Section 2, our approach relies on being able to check each sentence in isolation. However, phenomena like coreference and ellipsis may make sentences difficult to ground out of context. We can address this with an explicit *decontextualization* step (Choi et al., 2021; Wang et al., 2023; Jacovi et al., 2024). We experiment with TOFUEVAL-MediaS, TOFUEVAL-MeetB, WICE, REVEAL, CLAIMVERIFY, EXPERTQA and LFQA, which are the datasets in our benchmark where sentences need to be interpreted in context (FACTCHECK is already decontextualizaed). We prompt GPT-4 for decontextualization as shown in Appendix H, using the previous claims or response sentences as context to expand the claim. Respectively, 33%, 33%, 39%, 11%, 35%, 47%, and 57% of the claims from those datasets are changed after decontextualization.

In Table 5, we show the average fact-checking performance when using this decontextualization step (see the prompt in Table 24). **These results suggest that models may make decent guesses about context-dependent content, particularly when the retrieval stage already implicitly enforces shared context between the claim and the grounding documents.** However, for tasks such as retrieval-augmented generation, we believe decontextualization still plays a crucial role in ensuring meaningful document retrieval. Furthermore, as LLMs scale further and their responses get more complex, the level of contextualization they feature may be higher, making this step more necessary.

8 Related Work

Hallucinations in LLMs LLMs are prone to hallucinations across various settings (Huang et al., 2023; Zhang et al., 2023b; Rawte et al., 2023), generating information that cannot be supported by any source. For example, in the closed-book setting, where LLMs rely solely on their parametric knowledge, they may fabricate details when describing biographies or providing Wikipedia entity information (Min et al., 2023; Guan et al., 2023; Mallen

[4]Note that for Factcheck-GPT, retrieval operates over individual atomic facts. Decomposition may still be necessary to *retrieve* the relevant information, but our results show that it may not be necessary for *entailment checks*.

Mô hình Name	Cost ($)	Mô hình Name	Cost ($)
Gemini-Pro	5.24	Claude-2.1	89.9
PaLM2-Bison	10.9	Claude-3 Opus	165
Mistral-8x7B	7.78	GPT-3.5	4.75
Mistral-Large	90.2	GPT-4	107
GPT-4-Dectx	161	GPT-4-Decmp	212

Bảng 4: So sánh chi phí suy luận cho các mô hình API trên bộ dữ liệu kiểm tra 13K LLM-AGGREFACT. Cả hai decontextu- phân mảnh và phân hủy làm tăng chi phí cho GPT-4. Nhìn chung, giải mã bộ dữ liệu thử nghiệm của chúng tôi với các mô hình có khả năng cao nhất trong- chi phí đáng kể

Mô hình	Phân rã	Tách ngữ cảnh
GPT-4	75,6 (↑ **0.3**)	75.3 (+**0.0**)
SummaC-CV	58.8 (↓ **3.3**)	60,8 (↓ **1.3**)
Đánh giá Sự thật QA	64,6 (↓ **1.9**)	66.4 (↓ **0.1**)
SummaC-ZS	69.1 (↑ **1.2**)	67,7 (↓ **0.2**)
ĐiểmCânChỉnh	71,5 (↑ **1.1**)	70,4 (+**0.0**)
MiniCheck-RBTA	73.2 (↑ **0.5**)	72,4 (↓ **0.3**)
MiniCheck-DBTA	72,7 (↑ **0.1**)	71,2 (↓ **1.4**)
MiniCheck-FT5	73,3 (↓ **1.4**)	74.1 (↓ **0.6**)

Bảng 5: Hiệu suất trung bình trên tập kiểm tra của LLM-AGGREFACT bằng cách tổng hợp các dự đoán trên các tuyên bố đã được phân tích (bên trái); thực hiện phi ngữ cảnh hóa tuyên bố khi áp dụng được (bên phải). Chúng tôi cho thấy sự thay đổi hiệu suất so với việc dự đoán sử dụng các tuyên bố gốc từ Bảng 2. Kết quả đầy đủ trong Bảng 8 và 9 của Phụ lục.

mặc dù chúng tôi tin rằng điều đó là cần thiết nói chung.

7.1 Phân tích Yêu cầu

Chúng tôi cũng thử nghiệm với một cài đặt sử dụng phân tách tuyên bố. Trong cài đặt này, chúng tôi phân tách mỗi tuyên bố c_i thành các sự kiện nguyên tử $\mathbf{a}_i$ với lời nhắc từ Kamoi et al. (2023) và sử dụng một công cụ kiểm tra sự thật để dự đoán nhãn tính xác thực cho mỗi cặp $(D_i, a_{i,k})$, $k \in \{1, \ldots, l\}$. Nếu tất cả các sự kiện nguyên tử được tài liệu hỗ trợ, thì tuyên bố được hỗ trợ, và nếu không thì bị không hỗ trợ. Chúng tôi thực hiện điều này cho mọi bộ dữ liệu ngoại trừ FactCheck-GPT vốn đã là các sự kiện nguyên tử. Thông thường có 2-4 sự kiện nguyên tử cho mỗi tuyên bố trên các bộ dữ liệu.

Chúng tôi trình bày kết quả từ GPT-4 và một tập hợp con của các nhà kiểm chứng sự thật chuyên môn trong Bảng 5. Chúng tôi quan sát thấy gần như không có thay đổi về hiệu suất đối với GPT-4 và những thay đổi hỗn hợp đối với các nhà kiểm chứng sự thật chuyên môn. Nhìn chung, không có dấu hiệu rõ ràng nào cho thấy việc phân rã các tuyên bố thành các sự kiện nguyên tử có thể cải thiện hiệu suất của mô hình một cách nhất quán. Bởi vì phương pháp này làm tăng thời gian suy luận và chi phí lên gấp 2-4 lần đối với các bộ dữ liệu khác nhau, tùy thuộc vào số lượng trung bình các sự kiện nguyên tử trên mỗi tuyên bố, chúng tôi cho rằng không nên sử dụng cho đến khi nó mang lại lợi ích rõ ràng về độ chính xác.

Thực nghiệm với TOFUEVAL-MediaS, TOFUEVAL-MeetB, WICE, REVEAL, CLAIMVERIFY, EXPERTQA và LFQA, là các bộ dữ liệu trong điểm chuẩn của chúng tôi, nơi các câu cần được diễn giải theo ngữ cảnh (FACTCHECK đã được phi ngữ cảnh hóa). Chúng tôi yêu cầu GPT-4 thực hiện phi ngữ cảnh hóa như minh họa trong Phụ lục H, sử dụng các tuyên bố trước đó hoặc các câu trả lời làm ngữ cảnh để mở rộng tuyên bố. Tương ứng, 33%, 33%, 39%, 11%, 35%, 47%, và 57% các tuyên bố từ các bộ dữ liệu đó bị thay đổi sau khi phi ngữ cảnh hóa.

Trong Bảng 5, chúng tôi trình bày hiệu suất kiểm chứng sự thật trung bình khi sử dụng bước tách bối cảnh này (xem hướng dẫn trong Bảng 24). Những kết quả này gợi ý rằng các mô hình có thể đưa ra phỏng đoán khá chính xác về nội dung phụ thuộc vào bối cảnh, đặc biệt khi giai đoạn truy xuất đã ngầm thực thi việc chia sẻ bối cảnh giữa tuyên bố và các tài liệu nền tảng. Tuy nhiên, đối với các nhiệm vụ như sinh dữ liệu được tăng cường truy xuất, chúng tôi tin rằng việc tách bối cảnh vẫn đóng vai trò quan trọng trong việc đảm bảo truy xuất tài liệu có ý nghĩa. Hơn nữa, khi các LLM mở rộng hơn và phản hồi của chúng trở nên phức tạp hơn, mức độ có bối cảnh mà chúng hiển thị có thể cao hơn, làm cho bước này trở nên cần thiết hơn.

7.2 Tách rời ngữ cảnh của khẳng định

Như đã đề cập trong Mục 2, phương pháp của chúng tôi dựa vào khả năng kiểm tra từng câu một cách độc lập. Tuy nhiên, các hiện tượng như hội chiếu và lược từ có thể làm cho các câu khó được xác định ngoài ngữ cảnh. Chúng tôi có thể giải quyết vấn đề này bằng một bước tách bối cảnh rõ ràng (Choi et al., 2021; Wang et al., 2023; Jacovi et al., 2024). Chúng tôi...

[4]Lưu ý rằng đối với Factcheck-GPT, việc truy xuất hoạt động trên các sự kiện nguyên tử riêng lẻ. Việc phân tách vẫn có thể cần thiết để truy xuất thông tin liên quan, nhưng kết quả của chúng tôi cho thấy nó có thể không cần thiết cho các kiểm tra suy diễn.

8 Công trình liên quan

Ảo giác trong các mô hình ngôn ngữ lớn (LLMs) Các LLM dễ gặp phải ảo giác trong nhiều bối cảnh khác nhau (Huang và cộng sự, 2023; Zhang và cộng sự, 2023b; Rawte và cộng sự, 2023), tạo ra thông tin không thể được xác nhận bởi bất kỳ nguồn nào. Ví dụ, trong bối cảnh sách đóng, nơi LLM chỉ dựa vào kiến thức tham số của mình, chúng có thể bịa ra c hi tiết khi mô tả tiểu sử hoặc cung cấp thông tin về thực thể trên Wikipedia (Min và cộng sự, 2023; Guan và cộng sự, 2023; Mallen

et al., 2023). In retrieval-augmented settings, where models have access to external documents to provide responses to user queries, they may generate supplementary information that is not faithful to the provided documents (Chiesurin et al., 2023; Adlakha et al., 2023; Chen et al., 2024). Even when LLMs are provided with gold documents, such as in text summarization and simplification tasks, they still generate factually inconsistent outputs with diverse error types across different domains (Joseph et al., 2023; Shaib et al., 2023; Tang et al., 2024, 2023c). In this work, we construct a new benchmark dataset, LLM-AGGREFACT, which unifies human-annotated model responses across all settings, and evaluate the performance of existing fact-checkers and our proposed ones on the benchmark in detecting such errors.

Methods in Detecting Hallucinations When documents are directly available for model-generated sentences, such as in text summarization (Falke et al., 2019; Kryscinski et al., 2020; Maynez et al., 2020; Fabbri et al., 2021; Tang et al., 2023a) or retrieval-augmented generation (Liu et al., 2023; Malaviya et al., 2024), the entire claims are directly verified against the source documents. However, in cases where such documents are not readily available, such as in close-book generation, Gao et al. (2023); Min et al. (2023); Wang et al. (2023) decompose each generated sentence into atomic facts and then search for relevant documents to support each atomic fact. Alternatively, Malaviya et al. (2024) directly search for relevant documents for each sentence as a whole.

There are two main approaches to verifying sentences against documents. The first involves training specialized fact-checkers specifically designed for factual consistency evaluation, which are primarily evaluated in the context of summarization (Kryscinski et al., 2020; Fabbri et al., 2022; Goyal and Durrett, 2020; Laban et al., 2022). The second approach leverages LLMs as fact-checkers, particularly for evaluating LLM-generated responses from retrieval-augmented generation and closed-book generation (Min et al., 2023; Wang et al., 2023; Malaviya et al., 2024; Gao et al., 2023). In this work, we bridge the gap between these two approaches by evaluating both specialized fact-checkers and LLM-based fact-checkers across all these settings using our new benchmark, LLM-AGGREFACT. We show that our best model can match GPT-4 performance and perform well in all settings without doing sentence decomposition.

Entailment Datasets Our work contributes a new dataset for training textual entailment models over documents or document-chunks. Most prior entailment datasets have been human-authored (Bowman et al., 2015; Williams et al., 2018), which is known to introduce artifacts (Gururangan et al., 2018), or collected in the wild (Kamoi et al., 2023), which is challenging to scale. Past work has automatically generated contrast sets for NLI (Li et al., 2020). DocNLI (Yin et al., 2021) is a restructure of existing datasets where the length of most training examples cannot fit into the input limit of small models. Our work differs from these in its hand-built, synthetic nature to encourage multi-sentence and multi-fact reasoning, which is important to the task of fact-checking on grounding documents.

9 Conclusion

In this work, we introduce two synthetic data generation methods that address key limitations of specialized fact-checkers by encouraging models to verify each atomic fact within a claim and reason across multiple sentences. We also present LLM-AGGREFACT, a new factual consistency evaluation dataset covering both closed-book and grounded generation settings. A model fine-tuned on our synthetic data outperforms all prior specialized fact-checkers on LLM-AGGREFACT, while being much cheaper than LLM-based fact-checkers.

Limitations

Interpretation Like many other specialized fact-checking models, our models do not reveal their internal decision-making processes, making it challenging to localize errors to particular mismatched spans of a claim or document. There are two ways to alleviate this issue. The first is to perform claim decomposition and check the models' prediction labels on each atomic fact, thereby localizing the error from the original claim. Our models show better performance compared to other specialized fact-checkers when using this claim decomposition method (Table 5), but this method can give greater interpretability. The second approach, which can be a future research direction, is to enable our best model, MiniCheck-FT5, or generative models in general, to provide reliable explanations in addition to the binary predictions. We believe a model can provide reliable explanations only if it can first cor-

et al., 2023). Trong các thiết lập tăng cường truy xuất, nơi các mô hình có quyền truy cập vào các tài liệu bên ngoài để cung cấp các phản hồi cho các truy vấn của người dùng, chúng có thể tạo ra các thông tin bổ sung không trung thực với các tài liệu được cung cấp (Chiesurin et al., 2023; Adlakha et al., 2023; Chen et al., 2024). Ngay cả khi các LLM được cung cấp các tài liệu chuẩn, chẳng hạn như trong các nhiệm vụ tóm tắt và đơn giản hóa văn bản, chúng vẫn tạo ra các kết quả không nhất quán về mặt thực tế với nhiều loại lỗi khác nhau trên các lĩnh vực khác nhau (Joseph et al., 2023; Shaib et al., 2023; Tang et al., 2024, 2023c). Trong công trình này, chúng tôi xây dựng một bộ dữ liệu đánh giá mới, LLM-AGGREFACT, thống nhất các phản hồi mô hình có chú thích bởi con người trên tất cả các thiết lập, và đánh giá hiệu suất của các công cụ kiểm chứng thực tế hiện có cũng như các công cụ mà chúng tôi đề xuất trên bộ đánh giá này trong việc phát hiện các lỗi như vậy.

Các phương pháp phát hiện ảo giác Khi các tài liệu có sẵn trực tiếp cho các câu do mô hình tạo ra, chẳng hạn như trong tóm tắt văn bản (Falke et al., 2019; Kryscinski et al., 2020; Maynez et al., 2020; Fabbri et al., 2021; Tang et al., 2023a) hoặc sinh dữ liệu được tăng cường truy xuất (Liu et al., 2023; Malaviya et al., 2024), tất cả các tuyên bố đều được xác minh trực tiếp với các tài liệu nguồn. Tuy nhiên, trong những trường hợp tài liệu như vậy không có sẵn, chẳng hạn như trong sinh dữ liệu đóng sách, Gao et al. (2023); Min et al. (2023); Wang et al. (2023) phân tách từng câu được tạo thành các sự kiện cơ bản và sau đó tìm kiếm các tài liệu liên quan để hỗ trợ từng sự kiện cơ bản. Ngoài ra, Malaviya et al. (2024) trực tiếp tìm kiếm các tài liệu liên quan cho từng câu như một tổng thể.

Có hai phương pháp chính để xác minh các câu so với các tài liệu. Phương pháp đầu tiên liên quan đến việc đào tạo các bộ kiểm tra sự thật chuyên biệt được thiết kế riêng để đánh giá độ nhất quán về thực tế, chủ yếu được đánh giá trong bối cảnh tóm tắt (Kryscinski et al., 2020; Fabbri et al., 2022; Goyal và Durrett, 2020; Laban et al., 2022). Phương pháp thứ hai sử dụng các mô hình ngôn ngữ lớn (LLM) làm bộ kiểm tra sự thật, đặc biệt để đánh giá các phản hồi do LLM tạo ra từ việc kết hợp truy xuất dữ liệu và tạo nội dung độc lập (Min et al., 2023; Wang et al., 2023; Malaviya et al., 2024; Gao et al., 2023). Trong công trình này, chúng tôi nối khoảng cách giữa hai phương pháp này bằng cách đánh giá cả các bộ kiểm tra sự thật chuyên biệt và bộ kiểm tra sự thật dựa trên LLM trên tất cả các thiết lập này bằng cách sử dụng chuẩn đánh giá mới của chúng tôi, LLM-AGGREFACT. Chúng tôi cho thấy rằng mô hình tốt nhất của chúng tôi có thể đạt hiệu suất tương đương với GPT-4 và hoạt động tốt trong tất cả

cài đặt mà không thực hiện phân tách câu on.

Bộ dữ liệu Suy diễn Công trình của chúng tôi đóng góp một bộ dữ liệu mới để huấn luyện các mô hình suy diễn văn bản trên các tài liệu hoặc đoạn tài li ệu. Hầu hết các bộ dữ liệu suy diễn trước đây đều do con người tạo ra (Bowman et al., 2015; Williams et al., 2018), điều này được biết là gây ra các hiện tượng không mong muốn (Gururangan et al., 2018), hoặc được thu thập từ thực tế (Kamoi et al., 2023), điều này khó mở rộng. Các công trình trước đây đã tự động tạo ra các bộ đối lập cho NLI (Li et al., 2020). DocNLI (Yin et al., 2021) là một sự tái cấu trúc các bộ dữ liệu hiện có, nơi độ dài của hầu hết các ví dụ huấn luyện không thể phù hợp với giới hạn đầu vào của các mô hình nhỏ. Công trình của chúng tôi khác với những công trình này ở tính chất tổng hợp thủ công, nhằm khuyến khích suy luận đa câu và đa sự kiện, điều quan trọng đối với nhiệm vụ kiểm tra tính xác thực của thông tin dựa trên các tài liệu nền.

9 Kết luận

Trong công trình này, chúng tôi giới thiệu hai phương pháp tạo dữ liệu tổng hợp nhằm giải quyết những hạn chế chính của các bộ kiểm tra sự thật chuyên biệt bằng cách khuyến khích các mô hình xác minh từng sự thật nguyên tử trong một tuyên bố và suy luận qua nhiều câu. Chúng tôi cũng giới thiệu LLM-AGGREFACT, một tập dữ liệu đánh giá tính nhất quán thực tế mới bao gồm cả thiết lập tạo văn bản không dựa vào tài liệu và một cách có cơ sở. Một mô hình được tinh chỉnh trên dữ liệu tổng hợp của chúng tôi vượt trội hơn tất cả các bộ kiểm tra sự thật chuyên biệt trước đó trên LLM-AGGREFACT, đồng thời rẻ hơn nhiều so với các bộ kiểm tra sự thật dựa trên LLM.

Hạn chế

Diễn giải Giống như nhiều mô hình kiểm tra sự t hật chuyên biệt khác, các mô hình của chúng tôi không tiết lộ quá trình ra quyết định nội bộ của chúng, khiến việc xác định lỗi một cách cụ thể tại các khoảng không tương ứng với tuyên bố hoặc tài liệu trở nên khó khăn. Có hai cách để giảm bớt vấn đề này. Cách đầu tiên là thực hiện phân tách tuyên bố và kiểm tra nhãn dự đoán của mô hình trên t ừng sự thật nguyên tử, từ đó xác định vị trí lỗi từ tuyên bố gốc. Các mô hình của chúng tôi cho thấy hiệu suất tốt hơn so với các mô hình kiểm tra sự thật chuyên biệt khác khi sử dụng phương pháp phân tách tuyên bố này (Bảng 5), nhưng phương pháp này có thể mang lại khả năng diễn giải cao hơn. Cách tiếp cận thứ hai, có thể là hướng nghiên cứu tương lai, là cho phép mô hình tốt nhất của chúng tôi, MiniCheck-FT5, hoặc các mô hình tạo sinh nói chung, cung cấp các giải thích đáng tin cậy bên cạnh các dự đoán nhị phân. Chúng tôi tin rằng một mô hình chỉ có thể cung cấp các giải thích đáng tin cậy nếu nó có thể trước tiên tạo ra

rectly identify errors in our binary setting, which was the focus of this work.

Multi-Document Reasoning While our benchmark includes instances that evaluate models' ability to reason across multiple sentences, these datasets do not necessitate reasoning over evidence that is significantly separated or spread across various documents. Future research could focus on evaluating the performance of existing models in such scenarios, creating new labeled datasets of errors to expand our benchmark, and developing better fact-checking models to handle these challenges.

Synthetic Data The effectiveness of our synthetic data is demonstrated by the improved performance when training on it across various model architectures. We find that using a pair of sentences to support a fact is a simple method that yields useful training data for our models. However, there are other possible strategies for how atomic facts or claims could be expanded into multiple sentences. We believe that constructing more complex and higher-quality data could be a future direction not only for this work but also for other related tasks. As LLMs continue to advance, the quality of the synthetic data generated using our approach is also expected to improve.

Language Our models are trained exclusively on English data. Although the backbone model, Flan-T5, is trained on multilingual data, we have not systematically assessed how well our model's performance extends to other languages due to the absence of a human-annotated factual consistency evaluation dataset for LLM-generated outputs in non-English languages. We believe that developing a fact-checker that can perform well across multiple languages is important for future work.

Acknowledgments

We would like to thank Jessy Li for comments on a draft of this work. This work was principally supported by a gift from Amazon as part of the UT-Amazon Science Hub. It was partially supported by NSF CAREER Award IIS-2145280, the NSF AI Institute for Foundations of Machine Learning (IFML), a grant from Open Philanthropy, a grant from the UT Austin Office of the Vice President for Research through the "Creating Connections for National Security Research Grants" program, and Good Systems,[5] a UT Austin Grand Challenge to develop responsible AI technologies.

References

Vaibhav Adlakha, Parishad BehnamGhader, Xing Han Lu, Nicholas Meade, and Siva Reddy. 2023. Evaluating correctness and faithfulness of instruction-following models for question answering. *arXiv preprint arXiv:2307.16877*.

Yuntao Bai, Saurav Kadavath, Sandipan Kundu, Amanda Askell, Jackson Kernion, Andy Jones, Anna Chen, Anna Goldie, Azalia Mirhoseini, Cameron McKinnon, Carol Chen, Catherine Olsson, Christopher Olah, Danny Hernandez, Dawn Drain, Deep Ganguli, Dustin Li, Eli Tran-Johnson, Ethan Perez, Jamie Kerr, Jared Mueller, Jeffrey Ladish, Joshua Landau, Kamal Ndousse, Kamile Lukosuite, Liane Lovitt, Michael Sellitto, Nelson Elhage, Nicholas Schiefer, Noemi Mercado, Nova DasSarma, Robert Lasenby, Robin Larson, Sam Ringer, Scott Johnston, Shauna Kravec, Sheer El Showk, Stanislav Fort, Tamera Lanham, Timothy Telleen-Lawton, Tom Conerly, Tom Henighan, Tristan Hume, Samuel R. Bowman, Zac Hatfield-Dodds, Ben Mann, Dario Amodei, Nicholas Joseph, Sam McCandlish, Tom Brown, and Jared Kaplan. 2022. Constitutional ai: Harmlessness from ai feedback.

Samuel R. Bowman, Gabor Angeli, Christopher Potts, and Christopher D. Manning. 2015. A large annotated corpus for learning natural language inference. In *Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing*, pages 632–642, Lisbon, Portugal. Association for Computational Linguistics.

Meng Cao, Yue Dong, and Jackie Cheung. 2022. Hallucinated but factual! inspecting the factuality of hallucinations in abstractive summarization. In *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 3340–3354, Dublin, Ireland. Association for Computational Linguistics.

Shuyang Cao and Lu Wang. 2021. CLIFF: Contrastive learning for improving faithfulness and factuality in abstractive summarization. In *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*, pages 6633–6649, Online and Punta Cana, Dominican Republic. Association for Computational Linguistics.

Hung-Ting Chen, Fangyuan Xu, Shane A Arora, and Eunsol Choi. 2023. Understanding retrieval augmentation for long-form question answering. *arXiv preprint arXiv:2310.12150*.

Jiawei Chen, Hongyu Lin, Xianpei Han, and Le Sun. 2024. Benchmarking large language models in retrieval-augmented generation. In *Thirty-Eighth*

[5] https://goodsystems.utexas.edu/

xác định chính xác các lỗi trong môi trường nhị phân của chúng tôi, đây là trọng tâm của công trình này.

Lý luận đa tài liệu Trong khi bộ chuẩn của chúng tôi bao gồm các trường hợp đánh giá khả năng lý luận của các mô hình trên nhiều câu, các tập dữ liệu này không yêu cầu lý luận dựa trên các bằng chứng bị tách rời đáng kể hoặc trải rộng trên nhiều tài liệu khác nhau. Nghiên cứu trong tương lai có thể tập trung vào việc đánh giá hiệu suất của các mô hình hiện có trong những kịch bản như vậy, tạo ra các tập dữ liệu lỗi mới có nhãn để mở rộng bộ chuẩn của chúng tôi, và phát triển các mô hình kiểm tra sự thật tốt hơn để xử lý những thách thức này.

Dữ liệu tổng hợp Hiệu quả của dữ liệu tổng hợp của chúng tôi được chứng minh qua việc cải thiện hiệu s uất khi đào tạo trên nó qua nhiều kiến trúc mô hình khác nhau. Chúng tôi nhận thấy rằng việc sử dụng một cặp câu để hỗ trợ một sự thật là một phương pháp đơn giản nhưng tạo ra dữ liệu đào tạo hữu ích cho các mô hình của chúng tôi. Tuy nhiên, cũng có những chiến lược khác về cách các sự thật hoặc khẳng định đơn lẻ có thể được mở rộng thành nhiều câu. Chúng tôi tin rằng việc xây dựng dữ liệu phức tạp hơn và chất lượng cao hơn có thể là một hướng đi trong tương lai không chỉ cho công việc này mà còn cho các nhiệm vụ liên quan khác. Khi các mô hình ngôn ngữ lớn (LLM) tiếp tục phát triển, chất lượng dữ liệu tổng hợp được tạo ra bằng phương pháp của chúng tôi cũng được kỳ vọng sẽ cải thiện.

Ngôn ngữ Các mô hình của chúng tôi được huấn luyện hoàn toàn trên dữ liệu tiếng Anh. Mặc dù mô hình nền tảng, Flan-T5, được huấn luyện trên dữ liệu đa ngôn ngữ, chúng tôi chưa đánh giá một cách có hệ thống mức độ hiệu quả của mô hình đối với các ngôn ngữ khác do thiếu bộ dữ liệu đánh giá độ nhất quán thực tế được chú thích bởi con người cho các đầu ra do LLM tạo ra bằng các ngôn ngữ không phải tiếng Anh. Chúng tôi tin rằng việc phát triển một công cụ kiểm tra tính chính xác có thể hoạt động tốt trên nhiều ngôn ngữ là quan trọng cho các công việc trong tương lai.

Lời cảm ơn

Chúng tôi xin cảm ơn Jessy Li về những nhận xét đối với bản thảo của công trình này. Công trình này chủ yếu được hỗ trợ bởi một khoản tài trợ từ Amazon như một phần của Trung tâm Khoa học UT-Amazon. Nó được hỗ trợ một phần bởi Giải thưởng CAREER của NSF IIS-2145280, Viện AI của NSF về Cơ sở của Học máy (IFML), một khoản tài t rợ từ Open Philanthropy, một khoản tài trợ từ Văn phòng Phó Chủ tịch Nghiên cứu của UT Austin thông qua chương trình "Tạo Kết nối cho Các k hoản Nghiên cứu An ninh Quốc gia".

và Good Systems,[5] một Thách thức Lớn tại UT Austin để phát triển các công nghệ AI có trách nhiệm.

Tài liệu tham khảo

Vaibhav Adlakha, Parishad BehnamGhader, Xing Han Lu, Nicholas Meade, và Siva Reddy. 2023. Đánh giá độ chính xác và tính trung thực của các mô hình theo hướng dẫn trong việc trả lời câu hỏi. Bản in trước arXiv arXiv:2307.16877.

Yuntao Bai, Saurav Kadavath, Sandipan Kundu, Amanda Askell, Jackson Kernion, Andy Jones, Anna Chen, Anna Goldie, Azalia Mirhoseini, Cameron McKinnon, Carol Chen, Catherine Olsson, Christopher Olah, Danny Hernandez, Dawn Drain, Deep Ganguli, Dustin Li, Eli Tran-Johnson, Ethan Perez, Jamie Kerr, Jared Mueller, Jeffrey Ladish, Joshua Landau, Kamal Ndousse, Kamile Lukosuite, Liane Lovitt, Michael Sellitto, Nelson Elhage, Nicholas Schiefer, Noemi Mercado, Nova DasSarma, Robert Lasenby, Robin Larson, Sam Ringer, Scott Johnston, Shauna Kravec, Sheer El Showk, Stanislav Fort, Tamera Lanham, Timothy Telleen-Lawton, Tom Conerly, Tom Henighan, Tristan Hume, Samuel R. Bowman, Zac Hatfield-Dodds, Ben Mann, Dario Amodei, Nicholas Joseph, Sam McCandlish, Tom Brown, và Jared Kaplan. 2022. Trí tuệ nhân tạo theo hiến pháp: Tính vô hại từ phản hồi của AI.

Samuel R. Bowman, Gabor Angeli, Christopher Potts, và Christopher D. Manning. 2015. Một tập hợp dữ liệu lớn có chú thích để học suy luận ngôn ngữ tự nhiên. Trong Kỷ yếu hội nghị năm 2015 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên, trang 632–642, Lisbon, Bồ Đào Nha. Hiệp hội Ngôn ngữ Học Tính toán.

Meng Cao, Yue Dong, và Jackie Cheung. 2022. Ảo tưởng nhưng thực tế! Kiểm tra tính xác thực của các ảo tưởng trong tóm tắt trừu tượng. Trong Kỷ yếu của Hội nghị thường niên lần thứ 60 của Hiệp hội Ngôn ngữ học Máy tính (Tập 1: Bài báo dài), trang 3340–3354, Dublin, Ireland. Hiệp hội Ngôn ngữ học Máy tính.

Shuyang Cao và Lu Wang. 2021. CLIFF: Học đối chiếu để cải thiện độ trung thực và tính xác thực trong tóm tắt trừu tượng. Trong Kỷ yếu Hội nghị Phương pháp Thực nghiệm về Xử lý Ngôn ngữ Tự nhiên 2021, trang 6633–6649, Trực tuyến và Punta Cana, Cộng hòa Dominicana. Hiệp hội Ngôn ngữ Học Máy Tính.

Hung-Ting Chen, Fangyuan Xu, Shane A Arora, và Eunsol Choi. 2023. Hiểu về tăng cường truy xuất cho trả lời câu hỏi dạng dài. Bản in trước arXiv arXiv:2310.12150.

Jiawei Chen, Hongyu Lin, Xianpei Han, và Le Sun. 2024. Định chuẩn các mô hình ngôn ngữ lớn trong tạo sinh được tăng cường truy xuất. Trong Hội nghị lần thứ ba mươi tám

[5] https://goodsystems.utexas.edu/

AAAI Conference on Artificial Intelligence, AAAI 2024, Thirty-Sixth Conference on Innovative Applications of Artificial Intelligence, IAAI 2024, Fourteenth Symposium on Educational Advances in Artificial Intelligence, EAAI 2014, February 20-27, 2024, Vancouver, Canada, pages 17754–17762. AAAI Press.

Tongfei Chen, Zhengping Jiang, Adam Poliak, Keisuke Sakaguchi, and Benjamin Van Durme. 2020. Uncertain natural language inference. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 8772–8779, Online. Association for Computational Linguistics.

Sabrina Chiesurin, Dimitris Dimakopoulos, Marco Antonio Sobrevilla Cabezudo, Arash Eshghi, Ioannis Papaioannou, Verena Rieser, and Ioannis Konstas. 2023. The dangers of trusting stochastic parrots: Faithfulness and trust in open-domain conversational question answering. In *Findings of the Association for Computational Linguistics: ACL 2023*, pages 947–959, Toronto, Canada. Association for Computational Linguistics.

Eunsol Choi, Jennimaria Palomaki, Matthew Lamm, Tom Kwiatkowski, Dipanjan Das, and Michael Collins. 2021. Decontextualization: Making sentences stand-alone. *Transactions of the Association for Computational Linguistics*, 9:447–461.

Hyung Won Chung, Le Hou, Shayne Longpre, Barret Zoph, Yi Tay, William Fedus, Yunxuan Li, Xuezhi Wang, Mostafa Dehghani, Siddhartha Brahma, et al. 2022. Scaling instruction-finetuned language models. *arXiv preprint arXiv:2210.11416*.

Alexander Fabbri, Chien-Sheng Wu, Wenhao Liu, and Caiming Xiong. 2022. QAFactEval: Improved QA-based factual consistency evaluation for summarization. In *Proceedings of the 2022 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, pages 2587–2601, Seattle, United States. Association for Computational Linguistics.

Alexander R. Fabbri, Wojciech Kryściński, Bryan McCann, Caiming Xiong, Richard Socher, and Dragomir Radev. 2021. SummEval: Re-evaluating Summarization Evaluation. *Transactions of the Association for Computational Linguistics*, 9:391–409.

Tobias Falke, Leonardo F. R. Ribeiro, Prasetya Ajie Utama, Ido Dagan, and Iryna Gurevych. 2019. Ranking generated summaries by correctness: An interesting but challenging application for natural language inference. In *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*, pages 2214–2220, Florence, Italy. Association for Computational Linguistics.

Angela Fan, Yacine Jernite, Ethan Perez, David Grangier, Jason Weston, and Michael Auli. 2019. ELI5: Long form question answering. In *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*, pages 3558–3567, Florence, Italy. Association for Computational Linguistics.

Luyu Gao, Zhuyun Dai, Panupong Pasupat, Anthony Chen, Arun Tejasvi Chaganty, Yicheng Fan, Vincent Zhao, Ni Lao, Hongrae Lee, Da-Cheng Juan, and Kelvin Guu. 2023. RARR: Researching and revising what language models say, using language models. In *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 16477–16508, Toronto, Canada. Association for Computational Linguistics.

Zelalem Gero, Chandan Singh, Hao Cheng, Tristan Naumann, Michel Galley, Jianfeng Gao, and Hoifung Poon. 2023. Self-verification improves few-shot clinical information extraction. In *ICML 3rd Workshop on Interpretable Machine Learning in Healthcare (IMLH)*.

Max Glockner, Ieva Staliūnaitė, James Thorne, Gisela Vallejo, Andreas Vlachos, and Iryna Gurevych. 2024. AmbiFC: Fact-Checking Ambiguous Claims with Evidence. *Transactions of the Association for Computational Linguistics*, 12:1–18.

Tanya Goyal and Greg Durrett. 2020. Evaluating factuality in generation with dependency-level entailment. In *Findings of the Association for Computational Linguistics: EMNLP 2020*, pages 3592–3603, Online. Association for Computational Linguistics.

Tanya Goyal and Greg Durrett. 2021. Annotating and modeling fine-grained factuality in summarization. In *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, pages 1449–1462, Online. Association for Computational Linguistics.

Jian Guan, Jesse Dodge, David Wadden, Minlie Huang, and Hao Peng. 2023. Language models hallucinate, but may excel at fact verification. *arXiv preprint arXiv:2310.14564*.

Suchin Gururangan, Swabha Swayamdipta, Omer Levy, Roy Schwartz, Samuel Bowman, and Noah A. Smith. 2018. Annotation artifacts in natural language inference data. In *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 2 (Short Papers)*, pages 107–112, New Orleans, Louisiana. Association for Computational Linguistics.

Pengcheng He, Jianfeng Gao, and Weizhu Chen. 2021. DeBERTaV3: Improving DeBERTa using electra-style pre-training with gradient-disentangled embedding sharing. *arXiv preprint arXiv:2111.09543*.

Or Honovich, Roee Aharoni, Jonathan Herzig, Hagai Taitelbaum, Doron Kukliansy, Vered Cohen, Thomas Scialom, Idan Szpektor, Avinatan Hassidim, and Yossi Matias. 2022. TRUE: Re-evaluating factual consistency evaluation. In *Proceedings of the Second DialDoc Workshop on Document-grounded Dialogue and Conversational Question Answering*, pages 161–175, Dublin, Ireland. Association for Computational Linguistics.

Hội nghị AAAI về Trí tuệ Nhân tạo, AAAI 2024, Hội nghị lần thứ ba mươi sáu về Ứng dụng Sáng tạo của Trí tuệ Nhân tạo, IAAI 2024, Hội thảo lần thứ mười bốn về Tiến bộ Giáo dục trong Trí tuệ Nhân tạo, EAAI 2014, ngày 20-27 tháng 2 năm 2024, Vancouver, Canada, trang 17754–17762. Nhà xuất bản AAAI.

Tongfei Chen, Zhengping Jiang, Adam Poliak, Keisuke Sakaguchi, và Benjamin Van Durme. 2020. Suy luận ngôn ngữ tự nhiên không chắc chắn. Trong Kỷ yếu Hội nghị lần thứ 58 thường niên của Hiệp hội Ngôn ngữ học Máy tính, trang 8772–8779, Trực tuyến. Hiệp hội Ngôn ngữ học Máy tính.

Sabrina Chiesurin, Dimitris Dimakopoulos, Marco Antonio Sobrevilla Cabezudo, Arash Eshghi, Ioannis Papaioannou, Verena Rieser, và Ioannis Konstas. 2023. Những nguy hiểm khi tin tưởng vào những con vẹt ngẫu nhiên: Sự trung thực và lòng tin trong trả lời câu hỏi hội thoại mở. Trong Kết quả của Hiệp hội Ngôn ngữ Học Máy tính: ACL 2023, trang 947–959, Toronto, Canada. Hiệp hội Ngôn ngữ Học Máy tính.

Eunsol Choi, Jennimaria Palomaki, Matthew Lamm, Tom Kwiatkowski, Dipanjan Das, và Michael Collins. 2021. Decontextualization: Làm cho các câu trở nên độc lập. Transactions of the Association for Computational Linguistics, 9:447–461.

Hyung Won Chung, Le Hou, Shayne Longpre, Barret Zoph, Yi Tay, William Fedus, Yunxuan Li, Xuezhi Wang, Mostafa Dehghani, Siddhartha Brahma, và cộng sự. 2022. Mở rộng các mô hình ngôn ngữ được tinh chỉnh theo chỉ dẫn. Bản in trước trên arXiv arXiv:2210.11416.

Alexander Fabbri, Chien-Sheng Wu, Wenhao Liu, và Caiming Xiong. 2022. QAFactEval: Cải thiện đánh giá độ nhất quán thực tế dựa trên QA cho tóm tắt. Trong Kỷ yếu Hội nghị 2022 của Chương Bắc Mỹ thuộc Hiệp hội Ngôn ngữ Tính toán: Công nghệ Ngôn ngữ Con người, trang 2587–2601, Seattle, Hoa Kỳ. Hiệp hội Ngôn ngữ Tính toán.

Alexander R. Fabbri, Wojciech Kry´sci´nski, Bryan McCann, Caiming Xiong, Richard Socher, và Dragomir Radev. 2021. SummEval: Đánh giá lại việc đánh giá tóm tắt. Transactions of the Association for Computational Linguistics, 9:391–409.

Tobias Falke, Leonardo F. R. Ribeiro, Prasetya Ajie Utama, Ido Dagan, và Iryna Gurevych. 2019. Xếp hạng các bản tóm tắt được tạo ra theo độ chính xác: Một ứng dụng thú vị nhưng đầy thách thức cho suy luận ngôn ngữ tự nhiên. Trong Kỷ yếu Hội nghị thường niên lần thứ 57 của Hiệp hội Ngôn ngữ học Máy tính, trang 2214–2220, Florence, Ý. Hiệp hội Ngôn ngữ học Máy tính.

Angela Fan, Yacine Jernite, Ethan Perez, David Grangier, Jason Weston, và Michael Auli. 2019. ELI5: Trả lời câu hỏi dạng dài. Trong Kỷ yếu Hội nghị thường niên lần thứ 57 của Hiệp hội Ngôn ngữ học Máy tính, trang 3558–3567, Florence, Ý. Hiệp hội Ngôn ngữ học Máy tính.

Luyu Gao, Zhuyun Dai, Panupong Pasupat, Anthony Chen, Arun Tejasvi Chaganty, Yicheng Fan, Vincent Zhao, Ni Lao, Hongrae Lee, Da-Cheng Juan, và Kelvin Guu. 2023. RARR: Nghiên cứu và sửa đổi những gì các mô hình ngôn ngữ nói, sử dụng các mô hình ngôn ngữ. Trong Kỷ yếu của Hội nghị thường niên lần thứ 61 của Hiệp hội Ngôn ngữ Học Máy Tính (Tập 1: Bài báo dài), trang 16477–16508, Toronto, Canada. Hiệp hội Ngôn ngữ Học Máy Tính.

Zelalem Gero, Chandan Singh, Hao Cheng, Tristan Naumann, Michel Galley, Jianfeng Gao, và Hoifung Poon. 2023. Tự xác minh cải thiện việc trích xuất thông tin lâm sàng ít mẫu. Trong Hội thảo lần thứ 3 ICML về Học Máy Có Thể Giải Thích trong Chăm Sóc Sức Khỏe (IMLH).

Max Glockner, Ieva Stali¯unait˙e, James Thorne, Gisela Vallejo, Andreas Vlachos, và Iryna Gurevych. 2024. AmbiFC: Kiểm tra sự thật các khẳng định mơ hồ với bằng chứng. Transactions of the Association for Computational Linguistics, 12:1–18.

Tanya Goyal và Greg Durrett. 2020. Đánh giá tính xác thực trong sinh văn bản với sự phụ thuộc cấp độ hàm ý. Trong Kết quả của Hiệp hội Ngôn ngữ học Máy tính: EMNLP 2020, trang 3592–3603, Trực tuyến. Hiệp hội Ngôn ngữ học Máy tính.

Tanya Goyal và Greg Durrett. 2021. Chú thích và mô hình hóa tính xác thực chi tiết trong tóm tắt. Trong Kỷ yếu Hội nghị 2021 của Chương Bắc Mỹ Hiệp hội Ngôn ngữ học Máy tính: Công nghệ Ngôn ngữ Con người, tr ang 1449–1462, Trực tuyến. Hiệp hội Ngôn ngữ học Máy tính.

Jian Guan, Jesse Dodge, David Wadden, Minlie Huang, và Hao Peng. 2023. Mô hình ngôn ngữ ảo tưởng, nhưng có thể xuất sắc trong việc xác minh sự thật. Bản in trước trên arXiv arXiv:2310.14564.

Suchin Gururangan, Swabha Swayamdipta, Omer Levy, Roy Schwartz, Samuel Bowman, và Noah A. Smith. 2018. Các hiện tượng phụ chú trong dữ liệu suy diễn ngôn ngữ tự nhiên. Trong Kỷ yếu Hội nghị 2018 của Chương Bắc Mỹ thuộc Hiệp hội Ngôn ngữ Học Tính Toán: Công nghệ Ngôn ngữ Con Người, Tập 2 (Bài báo Ngắn), trang 107–112, New Orleans, Louisiana. Hiệp hội Ngôn ngữ Học Tính Toán.

Pengcheng He, Jianfeng Gao, và Weizhu Chen. 2021. DeBERTaV3: Cải thiện DeBERTa bằng cách sử dụng tiền huấn luyện kiểu electra với chia sẻ nhúng phân tách gradient. Bản in trước arXiv arXiv:2111.09543.

Or Honovich, Roee Aharoni, Jonathan Herzig, Hagai Taitelbaum, Doron Kukliansy, Vered Cohen, Thomas Scialom, Idan Szpektor, Avinatan Hassidim, và Yossi Matias. 2022. TRUE: Đánh giá lại việc đánh giá tính nhất quán thực tế. Trong Kỷ yếu Hội thảo Thứ hai DialDoc về Đối thoại dựa trên Tài liệu và Trả lời Câu hỏi Hội thoại, trang 161–175, Dublin, Ireland. Hiệp hội Ngôn ngữ học Máy tính.

Cheng-Yu Hsieh, Chun-Liang Li, Chih-kuan Yeh, Hootan Nakhost, Yasuhisa Fujii, Alex Ratner, Ranjay Krishna, Chen-Yu Lee, and Tomas Pfister. 2023. Distilling step-by-step! outperforming larger language models with less training data and smaller model sizes. In *Findings of the Association for Computational Linguistics: ACL 2023*, pages 8003–8017, Toronto, Canada. Association for Computational Linguistics.

Yebowen Hu, Timothy Ganter, Hanieh Deilamsalehy, Franck Dernoncourt, Hassan Foroosh, and Fei Liu. 2023. MeetingBank: A benchmark dataset for meeting summarization. In *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 16409–16423, Toronto, Canada. Association for Computational Linguistics.

Dandan Huang, Leyang Cui, Sen Yang, Guangsheng Bao, Kun Wang, Jun Xie, and Yue Zhang. 2020. What have we achieved on text summarization? In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 446–469, Online. Association for Computational Linguistics.

Lei Huang, Weijiang Yu, Weitao Ma, Weihong Zhong, Zhangyin Feng, Haotian Wang, Qianglong Chen, Weihua Peng, Xiaocheng Feng, Bing Qin, et al. 2023. A survey on hallucination in large language models: Principles, taxonomy, challenges, and open questions. *arXiv preprint arXiv:2311.05232*.

Alon Jacovi, Yonatan Bitton, Bernd Bohnet, Jonathan Herzig, Or Honovich, Michael Tseng, Michael Collins, Roee Aharoni, and Mor Geva. 2024. A chain-of-thought is as strong as its weakest link: A benchmark for verifiers of reasoning chains.

Albert Q. Jiang, Alexandre Sablayrolles, Antoine Roux, Arthur Mensch, Blanche Savary, Chris Bamford, Devendra Singh Chaplot, Diego de las Casas, Emma Bou Hanna, Florian Bressand, Gianna Lengyel, Guillaume Bour, Guillaume Lample, Lélio Renard Lavaud, Lucile Saulnier, Marie-Anne Lachaux, Pierre Stock, Sandeep Subramanian, Sophia Yang, Szymon Antoniak, Teven Le Scao, Théophile Gervet, Thibaut Lavril, Thomas Wang, Timothée Lacroix, and William El Sayed. 2024. Mixtral of experts.

Sebastian Joseph, Kathryn Kazanas, Keziah Reina, Vishnesh Ramanathan, Wei Xu, Byron Wallace, and Junyi Jessy Li. 2023. Multilingual simplification of medical texts. In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, pages 16662–16692, Singapore. Association for Computational Linguistics.

Ryo Kamoi, Tanya Goyal, Juan Diego Rodriguez, and Greg Durrett. 2023. WiCE: Real-world entailment for claims in Wikipedia. In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, pages 7561–7583, Singapore. Association for Computational Linguistics.

Wojciech Kryscinski, Bryan McCann, Caiming Xiong, and Richard Socher. 2020. Evaluating the factual consistency of abstractive text summarization. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 9332–9346, Online. Association for Computational Linguistics.

Philippe Laban, Wojciech Kryscinski, Divyansh Agarwal, Alexander Fabbri, Caiming Xiong, Shafiq Joty, and Chien-Sheng Wu. 2023. SummEdits: Measuring LLM ability at factual reasoning through the lens of summarization. In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, pages 9662–9676, Singapore. Association for Computational Linguistics.

Philippe Laban, Tobias Schnabel, Paul N. Bennett, and Marti A. Hearst. 2022. SummaC: Re-visiting NLI-based models for inconsistency detection in summarization. *Transactions of the Association for Computational Linguistics*, 10:163–177.

Chuanrong Li, Lin Shengshuo, Zeyu Liu, Xinyi Wu, Xuhui Zhou, and Shane Steinert-Threlkeld. 2020. Linguistically-informed transformations (LIT): A method for automatically generating contrast sets. In *Proceedings of the Third BlackboxNLP Workshop on Analyzing and Interpreting Neural Networks for NLP*, pages 126–135, Online. Association for Computational Linguistics.

Junyi Li, Xiaoxue Cheng, Xin Zhao, Jian-Yun Nie, and Ji-Rong Wen. 2023. HaluEval: A large-scale hallucination evaluation benchmark for large language models. In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, pages 6449–6464, Singapore. Association for Computational Linguistics.

Nelson Liu, Tianyi Zhang, and Percy Liang. 2023. Evaluating verifiability in generative search engines. In *Findings of the Association for Computational Linguistics: EMNLP 2023*, pages 7001–7025, Singapore. Association for Computational Linguistics.

Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, and Veselin Stoyanov. 2019. RoBERTa: A robustly optimized bert pretraining approach. *arXiv preprint arXiv:1907.11692*.

Yixin Liu, Pengfei Liu, Dragomir Radev, and Graham Neubig. 2022. BRIO: Bringing order to abstractive summarization. In *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 2890–2903, Dublin, Ireland. Association for Computational Linguistics.

Zheheng Luo, Qianqian Xie, and Sophia Ananiadou. 2023. ChatGPT as a Factual Inconsistency Evaluator for Text Summarization.

Cheng-Yu Hsieh, Chun-Liang Li, Chih-kuan Yeh, Hootan Nakhost, Yasuhisa Fujii, Alex Ratner, Ranjay Krishna, Chen-Yu Lee, và Tomas Pfister. 2023. Chưng cất từng bước! Vượt trội hơn các mô hình ngôn ngữ lớn hơn với ít dữ liệu huấn luyện hơn và kích thước mô hình nhỏ hơn. Trong Kết quả của Hiệp hội Ngôn ngữ học Máy tính: ACL 2023, trang 8003–8017, Toronto, Canada. Hiệp hội Ngôn ngữ học Máy tính.

Yebowen Hu, Timothy Ganter, Hanieh Deilamsalehy, Franck Dernoncourt, Hassan Foroosh, và Fei Liu. 2023. MeetingBank: Một bộ dữ liệu chuẩn cho tóm tắt cuộc họp. Trong Kỷ yếu của Hội nghị thường niên lần thứ 61 của Hiệp hội Ngôn ngữ học Máy tính (Tập 1: Bài báo dài), trang 16409–16423, Toronto, Canada. Hiệp hội Ngôn ngữ học Máy tính.

Dandan Huang, Leyang Cui, Sen Yang, Guangsheng Bao, Kun Wang, Jun Xie, và Yue Zhang. 2020. Chúng ta đã đạt được gì trong việc tóm tắt văn bản? Trong Kỷ yếu Hội nghị 2020 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên (EMNLP), trang 446–469, Trực t uyến. Hiệp hội Ngôn ngữ Học Máy tính.

Lei Huang, Weijiang Yu, Weitao Ma, Weihong Zhong, Zhangyin Feng, Haotian Wang, Qianglong Chen, Weihua Peng, Xiaocheng Feng, Bing Qin, và những người khác. 2023. Một khảo sát về ảo giác trong các mô hình ngôn ngữ lớn: Nguyên tắc, phân loại, thách thức và các câu hỏi mở. arXiv preprint arXiv:2311.05232.

Alon Jacovi, Yonatan Bitton, Bernd Bohnet, Jonathan Herzig, Or Honovich, Michael Tseng, Michael Collins, Roee Aharoni, và Mor Geva. 2024. Một chuỗi tư duy mạnh mẽ được quyết định bởi mắt xích yếu nhất của nó: Một chuẩn đánh giá cho các trình xác minh chuỗi lý luận.

Albert Q. Jiang, Alexandre Sablayrolles, Antoine Roux, Arthur Mensch, Blanche Savary, Chris Bamford, Devendra Singh Chaplot, Diego de las Casas, Emma Bou Hanna, Florian Bressand, Gi- anna Lengyel, Guillaume Bour, Guillaume Lam- ple, Lélio Renard Lavaud, Lucile Saulnier, Marie- Anne Lachaux, Pierre Stock, Sandeep Subramanian, Sophia Yang, Szymon Antoniak, Teven Le Scao, Théophile Gervet, Thibaut Lavril, Thomas Wang, Timothée Lacroix, và William El Sayed. 2024. Mix- tral of experts.

Sebastian Joseph, Kathryn Kazanas, Keziah Reina, Vishnesh Ramanathan, Wei Xu, Byron Wallace, và Junyi Jessy Li. 2023. Đơn giản hóa đa ngôn ngữ các văn bản y học. Trong Kỷ yếu Hội nghị Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên 2023, trang 16662–16692, Singapore. Hiệp hội Ngôn ngữ Học Máy.

Ryo Kamoi, Tanya Goyal, Juan Diego Rodriguez, và Greg Durrett. 2023. WiCE: Suy diễn thực tế cho các tuyên bố trong Wikipedia. Trong Kỷ yếu Hội nghị Phương pháp Thực nghiệm về Xử lý Ngôn ngữ Tự nhiên 2023, trang 7561–7583, Singapore. Hiệp hội Ngôn ngữ học Máy tính.

Wojciech Kryscinski, Bryan McCann, Caiming Xiong và Richard Socher. 2020. Đánh giá sự nhất quán thực tế của tóm tắt văn bản trừu tượng. Trong Kỷ yếu của Hội nghị 2020 về Phương pháp Cộng tác Kinh nghiệm trong Xử lý Ngôn ngữ Tự nhiên (EMNLP), trang 9332–9346, Trực tuyến. Hiệp hội Ngôn ngữ Học Tính toán.

Philippe Laban, Wojciech Kryscinski, Divyansh Agarwal, Alexander Fabbri, Caiming Xiong, Shafiq Joty, và Chien-Sheng Wu. 2023. SummEdits: Đo khả năng lý luận thực tế của LLM thông qua lăng kính tóm tắt. Trong Kỷ yếu Hội nghị 2023 về Các Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên, trang 9662–9676, Singapore. Hiệp hội Ngôn ngữ học Máy tính.

Philippe Laban, Tobias Schnabel, Paul N. Bennett và Marti A. Hearst. 2022. SummaC: Xem lại các mô hình dựa trên NLI để phát hiện sự mâu thuẫn trong tóm tắt. Tạp chí Hiệp hội Ngôn ngữ học Máy tính, 10:163–177.

Chuanrong Li, Lin Shengshuo, Zeyu Liu, Xinyi Wu, Xuhui Zhou và Shane Steinert-Threlkeld. 2020. Biến đổi theo thông tin ngôn ngữ (LIT): Một phương pháp tạo tự động các tập đối lập. Trong Kỷ yếu Hội thảo lần thứ ba BlackboxNLP về Phân tích và Giải thích Mạng thần kinh cho NLP, trang 126–135, Trực tuyến. Hiệp hội Ngôn ngữ học Máy tính.

Junyi Li, Xiaoxue Cheng, Xin Zhao, Jian-Yun Nie, và Ji-Rong Wen. 2023. HaluEval: Một bộ chuẩn đánh giá ảo hóa quy mô lớn cho các mô hình ngôn ngữ lớn. Trong Kỷ yếu Hội nghị 2023 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên, trang 6449–6464, Singapore. Hiệp hội Ngôn ngữ Học Máy Tính.

Nelson Liu, Tianyi Zhang, và Percy Liang. 2023. Đánh giá khả năng kiểm chứng trong các công cụ tìm kiếm sinh tạo. Trong Kết quả của Hiệp hội Ngôn ngữ học Máy tính: EMNLP 2023, trang 7001–7025, Singapore. Hiệp hội Ngôn ngữ học Máy tính.

Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, và Veselin Stoyanov. 2019. RoBERTa: Một phương pháp huấn luyện trước BERT được tối ưu hóa một cách mạnh mẽ. arXiv preprint arXiv:1907.11692.

Yixin Liu, Pengfei Liu, Dragomir Radev, và Graham Neubig. 2022. BRIO: Đưa trật tự vào tóm tắt trừu tượng. Trong Kỷ yếu Hội nghị thường niên lần thứ 60 của Hiệp hội Ngôn ngữ học Máy tính (Tập 1: Bài báo dài), trang 2890–2903, Dublin, Ireland. Hiệp hội Ngôn ngữ học Máy tính.

Zheheng Luo, Qianqian Xie, và Sophia Ananiadou. 2023. ChatGPT như một công cụ đánh giá sự không nhất quán về thực tế cho tóm tắt văn bản.

Chaitanya Malaviya, Subin Lee, Sihao Chen, Elizabeth Sieber, Mark Yatskar, and Dan Roth. 2024. ExpertQA: Expert-curated questions and attributed answers. In *2024 Annual Conference of the North American Chapter of the Association for Computational Linguistics*.

Alex Mallen, Akari Asai, Victor Zhong, Rajarshi Das, Daniel Khashabi, and Hannaneh Hajishirzi. 2023. When not to trust language models: Investigating effectiveness of parametric and non-parametric memories. In *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 9802–9822, Toronto, Canada. Association for Computational Linguistics.

Joshua Maynez, Shashi Narayan, Bernd Bohnet, and Ryan McDonald. 2020. On faithfulness and factuality in abstractive summarization. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 1906–1919, Online. Association for Computational Linguistics.

Nick McKenna, Tianyi Li, Liang Cheng, Mohammad Hosseini, Mark Johnson, and Mark Steedman. 2023. Sources of hallucination by large language models on inference tasks. In *Findings of the Association for Computational Linguistics: EMNLP 2023*, pages 2758–2774, Singapore. Association for Computational Linguistics.

Sewon Min, Kalpesh Krishna, Xinxi Lyu, Mike Lewis, Wen-tau Yih, Pang Koh, Mohit Iyyer, Luke Zettlemoyer, and Hannaneh Hajishirzi. 2023. FActScore: Fine-grained atomic evaluation of factual precision in long form text generation. In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, pages 12076–12100, Singapore. Association for Computational Linguistics.

Ramesh Nallapati, Bowen Zhou, Cicero dos Santos, Caglar Gulcehre, and Bing Xiang. 2016. Abstractive text summarization using sequence-to-sequence rnns and beyond. In *Proceedings of The 20th SIGNLL Conference on Computational Natural Language Learning*. Association for Computational Linguistics.

Shashi Narayan, Shay B. Cohen, and Mirella Lapata. 2018. Don't give me the details, just the summary! topic-aware convolutional neural networks for extreme summarization. In *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing*, pages 1797–1807, Brussels, Belgium. Association for Computational Linguistics.

Yixin Nie, Adina Williams, Emily Dinan, Mohit Bansal, Jason Weston, and Douwe Kiela. 2020a. Adversarial NLI: A new benchmark for natural language understanding. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 4885–4901, Online. Association for Computational Linguistics.

Yixin Nie, Xiang Zhou, and Mohit Bansal. 2020b. What can we learn from collective human opinions on natural language inference data? In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 9131–9143, Online. Association for Computational Linguistics.

OpenAI. 2023. GPT-4 technical report. *ArXiv*, abs/2303.08774.

Artidoro Pagnoni, Vidhisha Balachandran, and Yulia Tsvetkov. 2021. Understanding factuality in abstractive summarization with FRANK: A benchmark for factuality metrics. In *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, pages 4812–4829, Online. Association for Computational Linguistics.

Ellie Pavlick and Tom Kwiatkowski. 2019. Inherent disagreements in human textual inferences. *Transactions of the Association for Computational Linguistics*, 7:677–694.

Fabio Petroni, Samuel Broscheit, Aleksandra Piktus, Patrick Lewis, Gautier Izacard, Lucas Hosseini, Jane Dwivedi-Yu, Maria Lomeli, Timo Schick, Michele Bevilacqua, Pierre-Emmanuel Mazaré, Armand Joulin, Edouard Grave, and Sebastian Riedel. 2023. Improving Wikipedia verifiability with AI. *Nature Machine Intelligence*, 5(10):1142–1148.

Vipula Rawte, Amit Sheth, and Amitava Das. 2023. A survey of hallucination in large foundation models. *arXiv preprint arXiv:2309.05922*.

Soumya Sanyal, Tianyi Xiao, Jiacheng Liu, Wenya Wang, and Xiang Ren. 2024. Minds versus machines: Rethinking entailment verification with language models. *arXiv preprint arXiv:2402.03686*.

Chantal Shaib, Millicent Li, Sebastian Joseph, Iain Marshall, Junyi Jessy Li, and Byron Wallace. 2023. Summarizing, simplifying, and synthesizing medical evidence using GPT-3 (with varying success). In *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers)*, pages 1387–1407, Toronto, Canada. Association for Computational Linguistics.

Liyan Tang, Tanya Goyal, Alex Fabbri, Philippe Laban, Jiacheng Xu, Semih Yavuz, Wojciech Kryscinski, Justin Rousseau, and Greg Durrett. 2023a. Understanding factual errors in summarization: Errors, summarizers, datasets, error detectors. In *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 11626–11644, Toronto, Canada. Association for Computational Linguistics.

Liyan Tang, Yifan Peng, Yanshan Wang, Ying Ding, Greg Durrett, and Justin Rousseau. 2023b. Less likely brainstorming: Using language models to generate alternative hypotheses. In *Findings of the Association for Computational Linguistics: ACL 2023*, pages 12532–12555, Toronto, Canada. Association for Computational Linguistics.

Chaitanya Malaviya, Subin Lee, Sihao Chen, Elizabeth Sieber, Mark Yatskar, và Dan Roth. 2024. ExpertQA: Câu hỏi do chuyên gia biên soạn và câu trả lời được ghi c ông. Trong hội nghị thường niên năm 2024 của Chi nhánh Bắc Mỹ thuộc Hiệp hội Ngôn ngữ học Máy tính.

Alex Mallen, Akari Asai, Victor Zhong, Rajarshi Das, Daniel Khashabi, và Hannaneh Hajishirzi. 2023. Khi nào không nên tin tưởng các mô hình ngôn ngữ: Điều tra hiệu quả của bộ nhớ tham số và phi tham số. Trong Kỷ yếu Hội nghị thường niên lần thứ 61 của Hiệp hội Ngôn ngữ học Máy tính (Tập 1: Bài báo dài), trang 9802–9822, Toronto, Canada. Hiệp hội Ngôn ngữ học Máy tính.

Joshua Maynez, Shashi Narayan, Bernd Bohnet, và Ryan McDonald. 2020. Về độ trung thực và tính thực tế trong tóm tắt trừu tượng. Trong Kỷ yếu Hội nghị thường niên lần thứ 58 của Hiệp hội Ngôn ngữ học Máy tính, trang 1906–1919, Trực tuyến. Hiệp hội Ngôn ngữ học Máy tí nh.

Nick McKenna, Tianyi Li, Liang Cheng, Mohammad Hosseini, Mark Johnson, và Mark Steedman. 2023. Nguồn gốc của ảo giác do các mô hình ngôn ngữ lớn gây ra trong các nhiệm vụ suy luận. Trong Kết quả của Hiệp hội Ngôn ngữ học Máy tính: EMNLP 2023, trang 2758–2774, Singapore. Hiệp hội Ngôn ngữ học Máy tính.

Sewon Min, Kalpesh Krishna, Xinxi Lyu, Mike Lewis, Wen-tau Yih, Pang Koh, Mohit Iyyer, Luke Zettlemoyer, và Hannaneh Hajishirzi. 2023. FActScore: Đánh giá nguyên tử chi tiết về độ chính xác thực tế trong việc tạo văn bản dạng dài. Trong Kỷ yếu Hội nghị 2023 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên, trang 12076–12100, Singapore. Hiệp hội Ngôn ngữ Học Máy tính.

Ramesh Nallapati, Bowen Zhou, Cicero dos Santos, Caglar Gulcehre, và Bing Xiang. 2016. Tóm tắt văn bản trừu tượng sử dụng mạng nơ-ron tuần tự và hơn thế nữa. Trong Kỷ yếu của Hội nghị SIGNLL lần thứ 20 về Học máy ngôn ngữ tự nhiên. Hiệp hội Ngôn ngữ học Máy tính.

Shashi Narayan, Shay B. Cohen, và Mirella Lapata. 2018. Đừng cho tôi chi tiết, chỉ là tóm tắt thôi! mạng nơ-ron tích chập nhận biết chủ đề cho tóm tắt cực đoan. Trong Kỷ yếu Hội nghị Phương pháp Thực nghiệm về Xử lý Ngôn ngữ Tự nhiên 2018, trang 1797–1807, Brussels, Bỉ. Hiệp hội Ngôn ngữ Học Máy Tính.

Yixin Nie, Adina Williams, Emily Dinan, Mohit Bansal, Jason Weston, và Douwe Kiela. 2020a. Adversarial NLI: Một chuẩn mực mới cho việc hiểu ngôn ngữ tự nhiên. Trong Kỷ yếu của Hội nghị thường niên lần thứ 58 của Hiệp hội Ngôn ngữ Học Máy Tính, trang 4885–4901, trực tuyến. Hiệp hội Ngôn ngữ Học Máy Tính.

Yixin Nie, Xiang Zhou, và Mohit Bansal. 2020b. Chúng ta có thể học được gì từ các ý kiến tập thể của con người về dữ liệu suy diễn ngôn ngữ tự nhiên? Trong Kỷ yếu Hội nghị Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên 2020 (EMNLP), các trang 9131–9143, Trực tuyến. Hiệp hội Ngôn ngữ học Máy tính. OpenAI. 2023. Báo cáo kỹ thuật GPT-4. ArXiv, abs/2303.08774. Artidoro Pagnoni, Vidhisha Balachandran, và Yulia Tsvetkov. 2021. Hiểu tính xác thực trong tóm tắt trừu tượng với FRANK: Một chuẩn mực cho các chỉ số tính xác thực. Trong Kỷ yếu Hội nghị Hiệp hội Ngôn ngữ học Máy tính Bắc Mỹ 2021: Công nghệ Ngôn ngữ Con người, các trang 4812–4829, Trực tuyến. Hiệp hội Ngôn ngữ học Máy tí nh. Ellie Pavlick và Tom Kwiatkowski. 2019. Những bất đồng vốn có trong suy luận văn bản của con người. Giao dịch của Hiệp hội Ngôn ngữ học Máy tính, 7:677–694. Fabio Petroni, Samuel Broscheit, Aleksandra Piktus, Patrick Lewis, Gau

Liyan Tang, Igor Shalyminov, Amy Wing mei Wong, Jon Burnsky, Jake W. Vincent, Yu'an Yang, Siffi Singh, Song Feng, Hwanjun Song, Hang Su, Lijia Sun, Yi Zhang, Saab Mansour, and Kathleen McKeown. 2024. TofuEval: Evaluating Hallucinations of LLMs on Topic-Focused Dialogue Summarization.

Liyan Tang, Zhaoyi Sun, Betina Idnay, Jordan G. Nestor, Ali Soroush, Pierre A. Elias, Ziyang Xu, Ying Ding, Greg Durrett, Justin F. Rousseau, Chunhua Weng, and Yifan Peng. 2023c. Evaluating large language models on medical evidence summarization. *npj Digital Medicine*, 6(1).

Rohan Taori, Ishaan Gulrajani, Tianyi Zhang, Yann Dubois, Xuechen Li, Carlos Guestrin, Percy Liang, and Tatsunori B. Hashimoto. 2023. Stanford Alpaca: An Instruction-following LLaMA model. `https://github.com/tatsu-lab/stanford_alpaca`.

Gemini Team, Rohan Anil, Sebastian Borgeaud, Yonghui Wu, Jean-Baptiste Alayrac, Jiahui Yu, Radu Soricut, Johan Schalkwyk, Andrew M. Dai, Anja Hauth, and et al. 2023. Gemini: A family of highly capable multimodal models.

Romal Thoppilan, Daniel De Freitas, Jamie Hall, Noam M. Shazeer, Apoorv Kulshreshtha, Heng-Tze Cheng, Alicia Jin, Taylor Bos, Leslie Baker, Yu Du, Yaguang Li, Hongrae Lee, Huaixiu Steven Zheng, Amin Ghafouri, Marcelo Menegali, Yanping Huang, Maxim Krikun, Dmitry Lepikhin, James Qin, Dehao Chen, Yuanzhong Xu, Zhifeng Chen, Adam Roberts, Maarten Bosma, Yanqi Zhou, Chung-Ching Chang, I. A. Krivokon, Willard James Rusch, Marc Pickett, Kathleen S. Meier-Hellstern, Meredith Ringel Morris, Tulsee Doshi, Renelito Delos Santos, Toju Duke, Johnny Hartz Søraker, Ben Zevenbergen, Vinodkumar Prabhakaran, Mark Díaz, Ben Hutchinson, Kristen Olson, Alejandra Molina, Erin Hoffman-John, Josh Lee, Lora Aroyo, Ravi Rajakumar, Alena Butryna, Matthew Lamm, V. O. Kuzmina, Joseph Fenton, Aaron Cohen, Rachel Bernstein, Ray Kurzweil, Blaise Aguera-Arcas, Claire Cui, Marian Rogers Croak, Ed Huai hsin Chi, and Quoc Le. 2022. LaMDA: Language Models for Dialog Applications. *ArXiv*, abs/2201.08239.

Alex Wang, Kyunghyun Cho, and Mike Lewis. 2020. Asking and answering questions to evaluate the factual consistency of summaries. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 5008–5020, Online. Association for Computational Linguistics.

Yuxia Wang, Revanth Gangi Reddy, Zain Muhammad Mujahid, Arnav Arora, Aleksandr Rubashevskii, Jiahui Geng, Osama Mohammed Afzal, Liangming Pan, Nadav Borenstein, Aditya Pillai, Isabelle Augenstein, Iryna Gurevych, and Preslav Nakov. 2023. Factcheck-GPT: End-to-End Fine-Grained Document-Level Fact-Checking and Correction of LLM Output. *ArXiv*, abs/2311.09000.

Yixuan Weng, Minjun Zhu, Fei Xia, Bin Li, Shizhu He, Shengping Liu, Bin Sun, Kang Liu, and Jun Zhao. 2023. Large language models are better reasoners with self-verification. In *Findings of the Association for Computational Linguistics: EMNLP 2023*, pages 2550–2575, Singapore. Association for Computational Linguistics.

Adina Williams, Nikita Nangia, and Samuel Bowman. 2018. A broad-coverage challenge corpus for sentence understanding through inference. In *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long Papers)*, pages 1112–1122, New Orleans, Louisiana. Association for Computational Linguistics.

Xiaoyu Yang and Xiaodan Zhu. 2021. Exploring decomposition for table-based fact verification. In *Findings of the Association for Computational Linguistics: EMNLP 2021*, pages 1045–1052, Punta Cana, Dominican Republic. Association for Computational Linguistics.

Wenpeng Yin, Dragomir Radev, and Caiming Xiong. 2021. DocNLI: A large-scale dataset for document-level natural language inference. In *Findings of the Association for Computational Linguistics: ACL-IJCNLP 2021*, pages 4913–4922, Online. Association for Computational Linguistics.

Yuheng Zha, Yichi Yang, Ruichen Li, and Zhiting Hu. 2023. AlignScore: Evaluating factual consistency with a unified alignment function. In *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 11328–11348, Toronto, Canada. Association for Computational Linguistics.

Muru Zhang, Ofir Press, William Merrill, Alisa Liu, and Noah A Smith. 2023a. How language model hallucinations can snowball. *arXiv preprint arXiv:2305.13534*.

Tianyi Zhang, Faisal Ladhak, Esin Durmus, Percy Liang, Kathleen McKeown, and Tatsunori B. Hashimoto. 2024. Benchmarking large language models for news summarization. *Transactions of the Association for Computational Linguistics*, 12:39–57.

Yue Zhang, Yafu Li, Leyang Cui, Deng Cai, Lemao Liu, Tingchen Fu, Xinting Huang, Enbo Zhao, Yu Zhang, Yulong Chen, et al. 2023b. Siren's song in the AI ocean: a survey on hallucination in large language models. *arXiv preprint arXiv:2309.01219*.

Wenxuan Zhou, Sheng Zhang, Hoifung Poon, and Muhao Chen. 2023. Context-faithful prompting for large language models. In *Findings of the Association for Computational Linguistics: EMNLP 2023*, pages 14544–14556, Singapore. Association for Computational Linguistics.

Chenguang Zhu, Yang Liu, Jie Mei, and Michael Zeng. 2021. MediaSum: A large-scale media interview dataset for dialogue summarization. In *Proceedings*

Liyan Tang, Igor Shalyminov, Amy Wing mei Wong, Jon Burnsky, Jake W. Vincent, Yu'an Yang, Siffi Singh, Song Feng, Hwanjun Song, Hang Su, Lijia Sun, Yi Zhang, Saab Mansour, và Kathleen McKeown. 2024. TofuEval: Đánh giá các ảo giác của LLMs trong Tóm tắt Đối thoại Tập trung vào Chủ đề.

Liyan Tang, Zhaoyi Sun, Betina Idnay, Jordan G. Nestor, Ali Soroush, Pierre A. Elias, Ziyang Xu, Ying Ding, Greg Durrett, Justin F. Rousseau, Chunhua Weng và Yifan Peng. 2023c. Đánh giá các mô hình ngôn ngữ lớn về tổng hợp bằng chứng y tế. npj Digital Medicine, 6(1).

Rohan Taori, Ishaan Gulrajani, Tianyi Zhang, Yann Dubois, Xuechen Li, Carlos Guestrin, Percy Liang, và Tatsunori B. Hashimoto. 2023. Stanford Alpaca: Một mô hình LLaMA theo sát hướng dẫn. https://github.com/tatsu-lab/stanford_alpaca.

Nhóm Gemini, Rohan Anil, Sebastian Borgeaud, Yonghui Wu, Jean-Baptiste Alayrac, Jiahui Yu, Radu Soricut, Johan Schalkwyk, Andrew M. Dai, Anja Hauth, và những người khác. 2023. Gemini: Một họ các mô hình đa phương tiện có khả năng cao.

Romal Thoppilan, Daniel De Freitas, Jamie Hall, Noam M. Shazeer, Apoorv Kulshreshtha, Heng-Tze Cheng, Alicia Jin, Taylor Bos, Leslie Baker, Yu Du, Yaguang Li, Hongrae Lee, Huaixiu Steven Zheng, Amin Ghafouri, Marcelo Menegali, Yanping Huang, Maxim Krikun, Dmitry Lepikhin, James Qin, Dehao Chen, Yuanzhong Xu, Zhifeng Chen, Adam Roberts, Maarten Bosma, Yanqi Zhou, Chung-Ching Chang, I. A. Krivokon, Willard Ja mes Rusch, Marc Pickett, Kathleen S. Meier-Hellstern, Meredith Ringel Morris, Tulsee Doshi, Renelito Delos Santos, Toju Duke, Johnny Hartz Søraker, Ben Zevenbergen, Vinodkumar Prabhakaran, Mark Díaz, Ben Hutchinson, Kristen Olson, Alejandra Molina, Erin Hoffman-John, Josh Lee, Lora Aroyo, Ravi Rajakumar, Alena Butryna, Matthew Lamm, V. O. Kuzmina, Joseph Fenton, Aaron Cohen, Rachel Bernstein, Ray Kurzweil, Blaise Aguera-Arcas, Claire Cui, Marian Rogers Croak, Ed Huai hsin Chi, và Quoc Le. 2022. LaMDA: Mô hình ngôn ngữ cho các ứng dụng hội thoại. ArXiv, abs/2201.08239.

Alex Wang, Kyunghyun Cho và Mike Lewis. 2020. Hỏi và trả lời các câu hỏi để đánh giá tính nhất quán thực tế của các bản tóm tắt. Trong Kỷ yếu Hội nghị hàng năm lần thứ 58 của Hiệp hội Ngôn ngữ học Máy tính, trang 5008–5020, Trực tuyến. Hiệp hội Ngôn ngữ học Máy tính.

Yuxia Wang, Revanth Gangi Reddy, Zain Muhammad Mujahid, Arnav Arora, Aleksandr Rubashevskii, Jiahui Geng, Osama Mohammed Afzal, Liangming Pan, Nadav Borenstein, Aditya Pillai, Isabelle Augenstein, Iryna Gurevych, và Preslav Nakov. 2023. Factcheck-GPT: Kiểm tra sự thật cấp tài liệu từ đầu đến cuối và sửa lỗi đầu ra của LLM. ArXiv, abs/2311.09000.

Yixuan Weng, Minjun Zhu, Fei Xia, Bin Li, Shizhu He, Shengping Liu, Bin Sun, Kang Liu và Jun Zhao. 2023. Các mô hình ngôn ngữ lớn có khả năng lập luận tốt hơn nhờ tự xác minh. Trong Kết quả của Hiệp hội Ngôn ngữ học Tính toán: EMNLP 2023, trang 2550–2575, Singapore. Hiệp hội Ngôn ngữ học Tính toán.

Adina Williams, Nikita Nangia, và Samuel Bowman. 2018. Một tập hợp thách thức bao quát cho việc hiểu câu thông qua suy luận. Trong Kỷ yếu Hội nghị 2018 của Chương Bắc Mỹ thuộc Hiệp hội Ngôn ngữ học Máy tính: Công nghệ Ngôn ngữ Con người, Tập 1 (Bài dài), các trang 1112–1122, New Orleans, Louisiana. Hiệp hội Ngôn ngữ học Máy tính.

Xiaoyu Yang và Xiaodan Zhu. 2021. Khám phá phân rã cho xác minh sự thật dựa trên bảng. Trong Kết quả của Hiệp hội Ngôn ngữ học Máy tính: EMNLP 2021, trang 1045–1052, Punta Cana, Cộng hòa Dominica. Hiệp hội Ngôn ngữ học Máy tính.

Wenpeng Yin, Dragomir Radev, và Caiming Xiong. 2021. DocNLI: Một bộ dữ liệu quy mô lớn cho suy luận ngôn ngữ tự nhiên ở cấp độ tài liệu. Trong Kết quả của Hiệp hội Ngôn ngữ học Máy tính: ACL-IJCNLP 2021, trang 4913–4922, Trực tuyến. Hiệp hội Ngôn ngữ học Máy tính.

Yuheng Zha, Yichi Yang, Ruichen Li, và Zhiting Hu. 2023. AlignScore: Đánh giá tính nhất quán về thực tế với một hàm căn chỉnh thống nhất. Trong Kỷ yếu của Hội nghị thường niên lần thứ 61 của Hiệp hội Ngôn ngữ học Máy tính (Tập 1: Bài báo dài), trang 11328–11348, Toronto, Canada. Hiệp hội Ngôn ngữ học Máy tính.

Muru Zhang, Ofir Press, William Merrill, Alisa Liu, và Noah A Smith. 2023a. Cách các ảo tưởng của mô hình ngôn ngữ có thể tăng lên. Bản in trước trên arXiv arXiv:2305.13534.

Tianyi Zhang, Faisal Ladhak, Esin Durmus, Percy Liang, Kathleen McKeown, và Tatsunori B. Hashimoto. 2024. Đánh giá hiệu năng các mô hình ngôn ngữ lớn cho việc tóm tắt tin tức. Tạp chí Hiệp hội Ngôn ngữ Học Máy Tính, 12:39–57.

Yue Zhang, Yafu Li, Leyang Cui, Deng Cai, Lemao Liu, Tingchen Fu, Xinting Huang, Enbo Zhao, Yu Zhang, Yulong Chen, và cộng sự. 2023b. Bài ca của Siren trong đại dương AI: một khảo sát về ảo tưởng trong các mô hình ngôn ngữ lớn. arXiv preprint arXiv:2309.01219.

Wenxuan Zhou, Sheng Zhang, Hoifung Poon, và Muhao Chen. 2023. Gợi ý trung thành với ngữ cảnh cho các mô hình ngôn ngữ lớn. Trong Kết quả của Hiệp hội Ngôn ngữ Học Máy Tính: EMNLP 2023, trang 14544–14556, Singapore. Hiệp hội Ngôn ngữ Học Máy Tính.

Chenguang Zhu, Yang Liu, Jie Mei, và Michael Zeng. 2021. MediaSum: Một tập dữ liệu cuộc phỏng vấn truyền thông quy mô lớn cho việc tóm tắt đối thoại. Trong Kỷ yếu

of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, pages 5927–5934, Online. Association for Computational Linguistics.

A Additional Analysis and Ablations

A.1 Intrinsic Evaluation on C2D/D2C

Our model achieves strong overall performance, but we would like to have more insight as to whether it actually does well at the types of instances in D2C and C2D. We evaluate the performance of QAFactEval, SummaC-ZS, SummaC-CV, AlignScore, FT5-ANLI-L on our held-out synthetic data of C2D and D2C as a way to understand their ability to reason over multiple sentences and consider multiple atomic facts within a claim. There are 2K held-out instances from C2D and D2C, respectively, in the format of `(document, claim, label)` tuples. Performance is measured by BAcc.

Synthetic data ablations Beside those specialized models, we fine-tune `flan-t5-large` on the training set of C2D (**FT5-C2D**) and D2C (**FT5-D2C**), respectively. We evaluate FT5-C2D on D2C as an out-of-distribution (OOD) evaluation set, and evaluate FT5-D2C on C2D.

To demonstrate the necessity of steps in creating our synthetic data, we also create simplified versions of the synthetic data for both methods, denoted as C2D-SIMP and D2C-SIMP, each comprising 7K training examples, same as in C2D and D2C. For the C2D-SIMP method, we ask GPT-4 to directly generate documents that support and not support a provided claim, with the requirement mentioned in the prompt that the inference on the claim should require reasoning over multiple sentences from a document. For the D2C-SIMP method, we ask GPT-4 to generate summary sentences for Google News articles and come up with unsupported summaries by injecting errors into those summary sentences following the method in SummEdit (Laban et al., 2023). We denote models trained on those simplified synthetic data as **FT5-C2D-S** and **FT5-D2C-S**. More details for creating these synthetic datasets can be found in Appendix F.

Synthetic data needs to be carefully constructed for an fact-checker to work well. Figure 5 shows the in-distribution performance of FT5-C2D and FT5-D2C as optimal performance in each sub-figure, represented by the black dashed lines. We observe that models trained on synthetic data

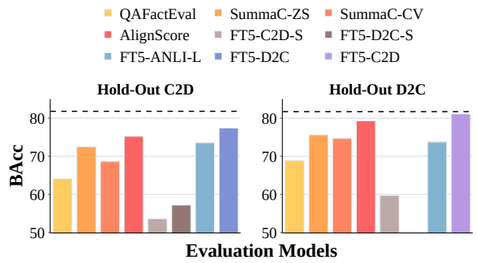


Figure 5: Performance of fact-checkers on the held-outs sets of C2D (left) and D2C (right). The black dashed line shows the in-distribution performance of FT5-C2D (left) and FT5-D2C (right).

with simplified construction steps (C2D-SIMP and D2C-SIMP) fail to develop the desired properties we expect. FT5-D2C-S performs even worse than random chance on the held-out set of C2D. In contrast, models trained on C2D and D2C outperform all other fact-checkers on the OOD held-out set of D2C and C2D, respectively. Additionally, we note that the model trained on 163K ANLI data points fail to reach the performance of models trained solely on 7K synthetic data. Our synthetic data generation methods can effectively encourage models to pay more attention to multiple atomic facts and reason over multiple sentences, even with a limited amount of training data.

A.2 Ablation of D2C/C2D

We observe that there are still gaps between the optimal performance and that achieved by other specialized fact-checkers in Figure 5. Notably, AlignScore demonstrates the best performance among the four specialized metrics, but its performance can still be outperformed by FT5-C2D and FT5-D2C. As shown in Table 2, we can improve AlignScore's performance on the benchmark by fine-tuning it on this small amount of data, effectively equipping it with the desired properties.

To further investigate, we conducted an ablation study on our top-performing model, MiniCheck-FT5, by removing our synthetic data from the training set. The results, presented in Table 6, reveal that the two types of synthetic data complement each other. Notably, the model performs poorly when trained solely on the ANLI subset, with a performance drop of nearly 10% in the absence of threshold tuning. However, the addition of either 7K C2D or 7K D2C to the training data significantly enhances the model's performance and

của Hội nghị năm 2021 của Chi nhánh Bắc Mỹ của Hiệp hội Ngôn ngữ học Máy tính: Công nghệ Ngôn ngữ Con người, trang 5927–5934, Trực tuyến. Hiệp hội Ngôn ngữ học Máy tính.

Phân tích bổ sung và loại bỏ

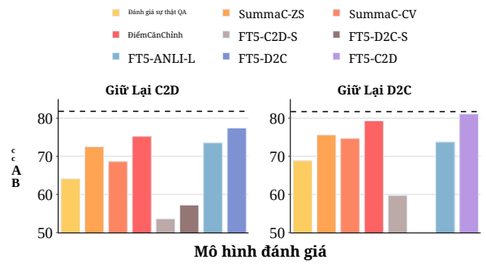
A.1 Đánh giá nội tại trên C2D/D2C

Mô hình của chúng tôi đạt hiệu suất tổng thể mạnh, nhưng chúng tôi muốn hiểu rõ hơn liệu nó thực sự hoạt động tốt với các loại trường hợp trong D2C và C2D hay không. Chúng tôi đánh giá hiệu suất của QAFactEval, SummaC-ZS, SummaC-CV, AlignScore, FT5-ANLI-L trên dữ liệu tổng hợp giữ l ại của chúng tôi từ C2D và D2C như một cách để hiểu khả năng suy luận qua nhiều câu và xem xét nhiều sự kiện nguyên tử trong một khẳng định. Có 2.000 trường hợp giữ lại từ C2D và D2C, tương ứng, ở định dạng bộ ba (tài liệu, khẳng định, nhãn). Hiệu suất được đo bằng BAcc.

Loại bỏ dữ liệu tổng hợp Bên cạnh những mô hình chuyên biệt đó, chúng tôi tinh chỉnh flan-t5-large trên tập huấn luyện của C2D (FT5-C2D) và D2C (FT5-D2C), tương ứng. Chúng tôi đánh giá FT5-C2D trên D2C như một tập đánh giá ngoài phân phối (OOD), và đánh giá FT5-D2C trên C2D.

Để chứng minh sự cần thiết của các bước trong việc tạo dữ liệu tổng hợp của chúng tôi, chúng tôi cũng tạo các phiên bản đơn giản hóa của dữ liệu tổng hợp cho cả hai phương pháp, được ký hiệu là C2D-SIMP và D2C-SIMP, mỗi phiên bản bao gồm 7 nghìn ví dụ huấn luyện, giống như trong C2D và D2C. Đối với phương pháp C2D-SIMP, chúng tôi yêu cầu GPT-4 trực tiếp tạo các tài liệu ủng hộ và không ủng hộ một tuyên bố được cung cấp, với yêu cầu được nêu trong lời nhắc rằng việc suy luận về t uyên bố này cần phải dựa trên lý luận qua nhiều câu trong một tài liệu. Đối với phương pháp D2C-SIMP, chúng tôi yêu cầu GPT-4 tạo các câu tó m tắt cho các bài báo của Google News và tạo ra các bản tóm tắt không được hỗ trợ bằng cách chèn lỗi vào các câu tóm tắt đó theo phương pháp trong SummEdit (Laban và cộng sự, 2023). Chúng tôi ký hiệu các mô hình được huấn luyện trên những dữ liệu tổng hợp đơn giản này là FT5-C2D-S và FT5-D2C-S. Thêm chi tiết về việc tạo các bộ dữ liệu tổng hợp này có thể được tìm thấy trong Phụ lục F.

Dữ liệu tổng hợp cần được xây dựng cẩn thận để một công cụ kiểm tra sự thật hoạt động tốt. Hình 5 cho thấy hiệu suất trong phân phối của FT5-C2D và FT5-D2C như hiệu suất tối ưu trong mỗi tiểu hình, được biểu diễn bằng các đường đứt nét màu đen. Chúng tôi quan sát thấy các mô hình được huấn luyện trên dữ liệu tổng hợp



Hình 5: Hiệu suất của các bộ kiểm tra sự thật trên các tập giữ lại của C2D (bên trái) và D2C (bên phải). Đường nét đen ngang cho thấy hiệu suất trong phân phối của FT5-C2D (bên trái) và FT5-D2C (bên phải).

với các bước xây dựng được đơn giản hóa (C2D-SIMP và D2C-SIMP) không thể phát triển các thuộc tính mong muốn mà chúng tôi kỳ vọng. FT5-D2C-S thậm chí còn hoạt động kém hơn so với ngẫu nhiên trên tập giữ ngoài (held-out set) của C2D. Ngược lại, các mô hình được huấn luyện trên C2D và D2C vượt trội hơn tất cả các bộ kiểm tra thực tế khác trên tập giữ ngoài OOD của D2C và C2D, tương ứng. Thêm vào đó, chúng tôi nhận thấy rằng mô hình được huấn luyện trên 163K điểm dữ liệu ANLI không thể đạt được hiệu suất của các mô hình được huấn luyện chỉ trên 7K dữ liệu tổng hợp. Các phương pháp tạo dữ liệu tổng hợp của chúng tôi có thể khuyến khích các mô hình chú ý nhiều hơn đến nhiều sự kiện nguyên tử và suy luận qua nhiều câu, ngay cả với lượng dữ liệu huấn luyện hạn chế.

A.2 Cắt bỏ D2C/C2D

Chúng tôi quan sát thấy vẫn còn tồn tại khoảng cách giữa hiệu suất tối ưu và hiệu suất đạt được bởi các công cụ kiểm chứng chuyên biệt khác trong Hình 5. Đáng chú ý, AlignScore cho thấy hiệu suất tốt nhất trong số bốn chỉ số chuyên biệt, nhưng hiệu suất của nó vẫn có thể bị vượt trội bởi FT5-C2D và FT5-D2C. Như được thể hiện trong Bảng 2, chúng ta có thể cải thiện hiệu suất của AlignScore trên bảng chuẩn bằng cách tinh chỉnh nó trên một lượng dữ liệu nhỏ này, hiệu quả là trang bị cho nó các thuộc tính mong muốn.

Để điều tra kỹ hơn, chúng tôi đã tiến hành một nghiên cứu ablation trên mô hình có hiệu quả cao nhất của mình, MiniCheck-FT5, bằng cách loại bỏ dữ liệu tổng hợp của chúng tôi khỏi tập huấn l uyện. Các kết quả, được trình bày trong Bảng 6, cho thấy hai loại dữ liệu tổng hợp bổ sung cho nhau. Đáng chú ý, mô hình hoạt động kém khi chỉ được huấn luyện trên tập con ANLI, với mức giảm hiệu suất gần 10% khi không thực hiện điều chỉnh ngưỡng. Tuy nhiên, việc bổ sung bất kỳ dữ liệu 7K C2D hoặc 7K D2C nào vào dữ liệu huấn luyện đều cải thiện đáng kể hiệu suất của mô hình và

Model Name	LLM-AGGREFACT (*without* threshold tuning)										
	AGGREFACT		TOFUEVAL		WICE	REVEAL	CLAIM VERIFY	FACT CHECK	EXPERT QA	LFQA	Avg
	CNN	XSum	MediaS	MeetB							
MiniCheck-FT5	69.9	74.3	73.6	77.3	72.2	86.2	74.6	74.7	59.0	85.2	74.7
- C2D	64.7	68.6	70.7	76.6	75.5	85.4	70.4	75.1	58.6	82.0	72.7 (↓ **2.0**)
- D2C	62.9	70.6	70.1	75.9	74.0	83.1	67.1	75.5	58.0	77.9	71.5 (↓ **3.2**)
- BOTH	54.7	59.4	54.1	55.6	61.5	77.1	57.4	65.0	51.9	63.0	59.9 (↓ **14.8**)

Table 6: **Ablation study on the training data.** Models are evaluated on the test set of LLM-AGGREFACT without threshold tuning. We show the average performance downgrade in red. -BOTH drops from 69.1 to 59.9 without threshold tuning.

Model Name	LLM-AGGREFACT (*with* threshold tuning)										
	AGGREFACT		TOFUEVAL		WICE	REVEAL	CLAIM VERIFY	FACT CHECK	EXPERT QA	LFQA	Avg
	CNN	XSum	MediaS	MeetB							
T5-NLI-Mixed	59.9	56.1	60.6	55.9	58.0	87.6	61.5	69.3	56.8	62.8	62.9
DAE	58.6	67.1	67.6	63.2	57.1	83.8	71.1	72.6	58.6	68.5	68.5
QAFactEval	63.9	63.7	64.0	66.8	65.8	85.3	73.3	72.1	57.6	81.5	69.4
SummaC-ZS	63.0	67.2	69.5	70.0	61.8	86.4	69.9	75.7	57.5	82.0	70.4
SummaC-CV	67.6	69.7	68.2	71.0	66.1	87.3	71.3	74.3	59.3	71.3	71.3
AlignScore	62.6	69.6	71.6	71.8	66.8	85.3	72.9	76.5	59.2	85.6	72.2
MiniCheck-RBTA	64.6	70.2	71.1	75.2	73.7	88.0	77.1	77.3	58.4	84.2	73.7
MiniCheck-DBTA	63.4	74.7	69.1	72.8	76.3	87.4	75.5	76.0	58.8	84.1	73.8
MiniCheck-FT5	71.5	74.8	73.7	76.7	75.0	86.4	73.8	76.4	58.6	84.4	75.1

Table 7: **Performance of models on the test set of LLM-AGGREFACT *with* threshold tuning on the validation set.** Balanced accuracy is computed for each model on the 10 datasets in LLM-AGGREFACT, and the average is computed. In each dataset, a factuality metric selects a threshold based on the performance on the corresponding validation set.

robustness.

A.3 Human Evaluation of Synthetic Data

While we use automatic entailment checks to ensure label quality in the training data construction pipeline, we conduct a small scale human evaluation to measure the quality of the generated data.

We randomly chose 40 (document, claim) pairs from each of the C2D and D2C training data. Three authors of the work independently annotated these 40×2 datapoints as supported or not supported (without seeing the gold label), with an average annotation time of around 1 min and 40 seconds per example. Among the three annotators, we computed an annotation agreement using Fleiss' Kappa, obtaining a score of 0.51 for the C2D samples and 0.70 on the D2C samples, indicating moderate to substantial agreement. The annotators adjudicated cases with disagreement to reach a consensus on the final factuality of the labels. We refer to these as the ground truth labels.

Compared to these ground truth labels, the labels given to our training samples have an accuracy of 80% on C2D and 78% on D2C, respectively. We calculated similar accuracy values for the human annotators, and the average across the three annotators' accuracies was 85% on C2D and 88% on D2C. These accuracies demonstrate that the automatic labels are a bit lower-quality than single-annotator labels on D2C, but close on C2D.

Many of the disagreement cases are classic cases of subjectivity in NLI (Pavlick and Kwiatkowski, 2019; Chen et al., 2020; Nie et al., 2020b). For example, for the C2D claim "*Located in the Scottish Highlands, she lived with and later married James Ballard in Spean Bridge.*", the generated passage only references the couple living in the town of Spean Bridge after the marriage, making it unclear whether or not they got married there. However, this is a reasonable supposition to make. Our results show that our data is useful for training in spite of these subjective examples.

B Additional Results

B.1 Results using Threshold Tuning

As shown in Table 7, AlignScore achieves the highest overall performance (72.2%) on LLM-

Mô hình Name	LLM-AGGREFACT (không điều chỉnh ngưỡng)										
	AGGREFACT		ĐÁNH GIÁ TOFU		WICE TIẾT LỘ		YÊU CẦU XÁC MINH	FACT KIỂM TRA	CHUYÊN GIA QA	LFQA	Avg
	CNN	XSum	MediaS	MeetB							
MiniCheck-FT5	69.9	74.3	73.6	77.3	72.2	86.2	74.6	74.7	59.0	85.2	74.7
- C2D	64.7	68.6	70.7	76.6	75.5	85.4	70.4	75.1	58.6	82.0	72,7 (↓ **2.0**)
- D2C	62.9	70.6	70.1	75.9	74.0	83.1	67.1	75.5	58.0	77.9	71,5 (↓ **3.2**)
- CẢ HAI	54.7	59.4	54.1	55.6	61.5	77.1	57.4	65.0	51.9	63.0	59.9 (↓ **14.8**)

Bảng 6: Nghiên cứu loại bỏ trên dữ liệu huấn luyện. Các mô hình được đánh giá trên tập kiểm tra của LLM-AGGREFACT mà không tinh chỉnh ngưỡng. Chúng tôi hiển thị sự suy giảm hiệu suất trung bình bằng màu đỏ. -BOTH giảm từ 69,1 xuống 59,9 mà không cần tinh chỉnh ngưỡng.

Mô hình Name	LLM-AGGREFACT (với điều chỉnh ngưỡng)										
	AGGREFACT		ĐÁNH GIÁ TOFU		WICE TIẾT LỘ		YÊU CẦU XÁC MINH	FACT KIỂM TRA	CHUYÊN GIA QA	LFQA Trung bình	
	CNN	XSum	MediaS	MeetB							
T5-NLI-Pha trộn	59.9	56.1	60.6	55.9	58.0	87.6	61.5	69.3	56.8	62.8	62.9
DAE	58.6	67.1	67.6	63.2	57.1	83.8	71.1	72.6	58.6	68.5	68.5
Đánh giá sự thật QA	63.9	63.7	64.0	66.8	65.8	85.3	73.3	72.1	57.6	81.5	69.4
SummaC-ZS	63.0	67.2	69.5	70.0	61.8	86.4	69.9	75.7	57.5	82.0	70.4
SummaC-CV	67.6	69.7	68.2	71.0	66.1	87.3	71.3	74.3	59.3	71.3	71.3
ĐiểmCânChỉnh	62.6	69.6	71.6	71.8	66.8	85.3	72.9	76.5	59.2	85.6	72.2
MiniCheck-RBTA	64.6	70.2	71.1	75.2	73.7	88.0	77.1	77.3	58.4	84.2	73.7
MiniCheck-DBTA	63.4	74.7	69.1	72.8	76.3	87.4	75.5	76.0	58.8	84.1	73.8
MiniCheck-FT5	71.5	74.8	73.7	76.7	75.0	86.4	73.8	76.4	58.6	84.4	75.1

Bảng 7: Hiệu suất của các mô hình trên tập kiểm tra của LLM-AGGREFACT với việc điều chỉnh ngưỡng trên tập xác nhận. Độ chính xác cân bằng được tính cho mỗi mô hình trên 10 bộ dữ liệu trong LLM-AGGREFACT, và giá trị trung bình được tính. Trong mỗi bộ dữ liệu, một chỉ số thực tế chọn ngưỡng dựa trên hiệu suất trên tập xác nhận tương ứng.

sự mạnh mẽ.

A.3 Đánh giá con người về dữ liệu tổng hợp

Trong khi chúng tôi sử dụng các kiểm tra suy luận tự động để đảm bảo chất lượng nhãn trong quy trình xây dựng dữ liệu huấn luyện, chúng tôi tiến hành đánh giá con người quy mô nhỏ để đo lường chất lượng của dữ liệu được tạo ra.

Chúng tôi đã chọn ngẫu nhiên 40 cặp (tài liệu, tuyên bố) từ mỗi tập dữ liệu huấn luyện C2D và D2C. Ba tác giả của nghiên cứu này đã độc lập chú thích các điểm dữ liệu này là được hỗ trợ hay không được hỗ trợ (mà không nhìn thấy nhãn chuẩn), với thời gian chú thích trung bình khoảng 1 phút 40 giây cho mỗi ví dụ. Trong ba người chú thích, chúng tôi đã tính toán sự đồng thuận chú thích sử dụng Fleiss' Kappa, đạt được điểm 0,51 cho các mẫu C2D và 0,70 cho các mẫu D2C, cho thấy đồng thuận từ mức trung bình đến đáng kể. Các người chú thích đã xử lý các trường hợp không đồng thuận để đạt được sự đồng thuận về tính đúng sự thật cuối cùng của các nhãn. Chúng tôi gọi những nhãn này là nhãn chuẩn.

So với những nhãn chuẩn này, các nhãn được gán cho các mẫu huấn luyện của chúng tôi có độ chính xác lần lượt là 80% trên C2D và 78% trên D2C. Chúng tôi tính toán các giá trị độ chính xác tương tự cho những người chú thích con người, và trung bình trên độ chính xác của ba người chú thích là 85% trên C2D và 88% trên D2C. Những độ chính xác này cho thấy rằng các nhãn tự động có chất lượng thấp hơn một chút so với nhãn của người chú thích đơn lẻ trên D2C, nhưng gần bằng trên C2D.

Nhiều trường hợp bất đồng là những trường hợp điển hình của tính chủ quan trong NLI (Pavlick và Kwiatkowski, 2019; Chen và cộng sự, 2020; Nie và cộng sự, 2020b). Ví dụ, đối với tuyên bố C2D " Located in the Scottish Highlands, she lived with and later married James Ballard in Spean Bridge.", đoạn văn được tạo ra chỉ đề cập đến việc cặp đôi sống ở thị trấn Spean Bridge sau khi kết hôn, khiến không rõ liệu họ có kết hôn ở đó hay không. Tuy nhiên, đây là một giả định hợp lý để đưa ra. Kết quả của chúng tôi cho thấy dữ liệu của chúng tôi vẫn hữu ích cho việc huấn luyện mặc dù có những ví dụ mang tính chủ quan này.

B Kết quả bổ sung

B.1 Kết quả sử dụng Điều chỉnh Ngưỡng

Như được thể hiện trong Bảng 7, AlignScore đạt hiệu suất tổng thể cao nhất (72,2%) trên LLM-

Model Name	AGGREFACT CNN	AGGREFACT XSum	TOFUEVAL MediaS	TOFUEVAL MeetB	WICE	REVEAL	CLAIM VERIFY	FACT CHECK	EXPERT QA	LFQA	Avg
LLM-AGGREFACT (decomposition - *without* threshold tuning)											
GPT-4	70.1	74.3	70.9	79.4	77.6	87.4	73.2	79.9	59.6	84.9	75.6 (↑ **0.3**)
SummaC-CV	65.2	51.2	58.0	55.2	50.9	66.2	69.6	53.4	53.5	65.0	58.8 (↓ **3.3**)
QAFactEval	61.7	60.4	65.0	60.2	59.1	81.7	68.6	66.1	54.6	73.0	64.6 (↓ **1.9**)
SummaC-ZS	62.4	64.5	64.5	70.0	64.8	85.6	70.0	75.2	56.3	77.2	69.1 (↑ **1.2**)
AlignScore	65.6	68.3	71.2	73.2	63.9	86.2	73.7	74.3	57.6	82.6	71.5 (↑ **1.1**)
MiniCheck-RBTA	65.0	72.1	72.6	75.1	66.9	88.5	76.1	73.3	58.0	84.3	73.2 (↑ **0.5**)
MiniCheck-DBTA	59.9	73.3	67.9	74.5	75.0	88.2	72.5	73.0	57.9	84.5	72.7 (↑ **0.1**)
MiniCheck-FT5	65.9	71.7	69.2	77.4	72.9	87.0	73.5	74.7	57.5	83.2	73.3 (↓ **1.4**)

Table 8: Performance of models on the test set of LLM-AGGREFACT by aggregating predictions on decomposed claims. We include the performance change compared to predicting using original claims from Table 2 (red for worse performance and green for better performance).

Model Name	AGGREFACT CNN	AGGREFACT XSum	TOFUEVAL MediaS	TOFUEVAL MeetB	WICE	REVEAL	CLAIM VERIFY	FACT CHECK	EXPERT QA	LFQA	Avg
LLM-AGGREFACT (decontextualization - *without* threshold tuning)											
GPT-4	66.7	76.5	71.5	79.2	80.3	87.0	66.2	79.9	60.1	86.4	75.3 (+**0.0**)
SummaC-CV	65.2	54.5	62.6	62.1	52.5	67.8	69.0	53.4	54.7	66.5	60.8 (↓ **1.3**)
QAFactEval	54.3	62.1	62.8	64.5	62.7	82.8	71.7	66.9	56.5	80.3	66.4 (↓ **0.1**)
SummaC-ZS	51.1	61.5	67.5	71.4	63.0	85.8	69.0	75.2	56.4	76.1	67.7 (↓ **0.2**)
AlignScore	52.4	71.4	68.8	72.2	65.1	85.5	69.1	74.3	59.6	85.2	70.4 (+**0.0**)
MiniCheck-RBTA	63.7	70.8	70.9	75.6	64.3	88.9	76.0	73.3	57.5	83.2	72.4 (↓ **0.3**)
MiniCheck-DBTA	64.2	71.0	69.6	69.1	63.3	87.5	73.6	73.0	57.8	83.2	71.2 (↓ **1.4**)
MiniCheck-FT5	69.9	74.3	74.0	75.6	69.7	86.2	73.0	74.7	58.4	85.2	74.1 (↓ **0.6**)

Table 9: Performance of models on the test set of LLM-AGGREFACT by doing claim decontextualization where it is applicable. We include the performance change compared to predicting using original claims from Table 2.

AGGREFACT among fact-checkers from prior work. However, by fine-tuning AlignScore's backbone RoBERTa model on our 14K synthetic data (MiniCheck-RBTA), we surpass AlignScore's performance by 1.5%. This improvement is more significant in the setting without threshold tuning (Section 6). Remarkably, this boost in performance is attained using a dataset that constitutes less than 0.3% of the total data on which AlignScore was initially trained (Table 3). This finding highlights the potential of curated synthetic data in enhancing the performance of state-of-the-art fact-checkers. Overall, our models achieve new state-of-the-art among specialized models under the threshold tuning setting.

Our synthetic data enhances model robustness and performance in the absence of threshold tuning. Comparing Table 2 with Table 7, we see that the performance of specialized fact-checkers decreases without threshold tuning. However, *MiniCheck-FT5 only drops by 0.4%* compared to larger drops for other systems, such as 9.2% for SummaC-CV. These results suggest that our synthetic data not only improves overall performance but also enhances the robustness of models across the domains of our benchmark, enabling them to maintain strong performance even without threshold tuning.

B.2 Full Results Using Claim Decomposition

In Table 8, we show the performance (and performance changes) of GPT-4 and a subset of specialized fact-checkers across all datasets from LLM-AGGREFACT, using claim decomposition to determine the factuality label for each claim.

B.3 Full Results Using Claim Decontextualization

In Table 9, we show the performance (and performance changes) of GPT-4 and a subset of specialized fact-checkers across all datasets from LLM-AGGREFACT, using claim decontextualization when applicable. In particular, we perform claim decontextualization on TOFUEVAL-MediaS,

Mô hình Name	AGGREFACT CNN	AGGREFACT XSum	ĐÁNH GIÁ TOFU MediaS	ĐÁNH GIÁ TOFU MeetB	WICE TIẾT LỘ	YÊU CẦU XÁC MINH	FACT KIỂM TRA	CHUYÊN GIA QA	LFQA	Avg
LLM-AGGREFACT (phân rã - không điều chỉnh ngưỡng)										
GPT-4	70.1	74.3	70.9	79.4	77.6	87.4	73.2	79.9	59.6	84.9	75,6 (↑ **0.3**)
SummaC-CV	65.2	51.2	58.0	55.2	50.9	66.2	69.6	53.4	53.5	65.0	58.8 (↓ **3.3**)
Đánh giá Sự thật QA	61.7	60.4	65.0	60.2	59.1	81.7	68.6	66.1	54.6	73.0	64,6 (↓ **1.9**)
SummaC-ZS	62.4	64.5	64.5	70.0	64.8	85.6	70.0	75.2	56.3	77.2	69.1 (↑ **1.2**)
ĐiểmCânChỉnh	65.6	68.3	71.2	73.2	63.9	86.2	73.7	74.3	57.6	82.6	71,5 (↑ **1.1**)
MiniCheck-RBTA	65.0	72.1	72.6	75.1	66.9	88.5	76.1	73.3	58.0	84.3	73.2 (↑ **0.5**)
MiniCheck-DBTA	59.9	73.3	67.9	74.5	75.0	88.2	72.5	73.0	57.9	84.5	72,7 (↑ **0.1**)
MiniCheck-FT5	65.9	71.7	69.2	77.4	72.9	87.0	73.5	74.7	57.5	83.2	73,3 (↓ **1.4**)

Bảng 8: Hiệu suất của các mô hình trên tập kiểm tra của LLM-AGGREFACT bằng cách tổng hợp các dự đoán trên các tuyên bố đã được phân tích. Chúng tôi bao gồm sự thay đổi về hiệu suất so với việc dự đoán bằng các tuyên bố gốc từ Bảng 2 (màu đỏ cho hiệu suất kém hơn và màu xanh lá cho hiệu suất tốt hơn).

Mô hình Name	AGGREFACT CNN	AGGREFACT XSum	ĐÁNH GIÁ TOFU MediaS	ĐÁNH GIÁ TOFU MeetB	WICE TIẾT LỘ	YÊU CẦU XÁC MINH	FACT KIỂM TRA	CHUYÊN GIA QA	LFQA	Avg
LLM-AGGREFACT (phi ngữ cảnh hóa - không điều chỉnh ngưỡng)										
GPT-4	66.7	76.5	71.5	79.2	80.3	87.0	66.2	79.9	60.1	86.4	75.3 (+**0.0**)
SummaC-CV	65.2	54.5	62.6	62.1	52.5	67.8	69.0	53.4	54.7	66.5	60,8 (↓ **1.3**)
Đánh giá Sự thật QA	54.3	62.1	62.8	64.5	62.7	82.8	71.7	66.9	56.5	80.3	66.4 (↓ **0.1**)
SummaC-ZS	51.1	61.5	67.5	71.4	63.0	85.8	69.0	75.2	56.4	76.1	67,7 (↓ **0.2**)
ĐiểmCânChỉnh	52.4	71.4	68.8	72.2	65.1	85.5	69.1	74.3	59.6	85.2	70,4 (+**0.0**)
MiniCheck-RBTA	63.7	70.8	70.9	75.6	64.3	88.9	76.0	73.3	57.5	83.2	72,4 (↓ **0.3**)
MiniCheck-DBTA	64.2	71.0	69.6	69.1	63.3	87.5	73.6	73.0	57.8	83.2	71,2 (↓ **1.4**)
MiniCheck-FT5	69.9	74.3	74.0	75.6	69.7	86.2	73.0	74.7	58.4	85.2	74.1 (↓ **0.6**)

Bảng 9: Hiệu suất của các mô hình trên tập kiểm tra của LLM-AGGREFACT bằng cách thực hiện tách bối cảnh tuyên bố khi có thể áp dụng. Chúng tôi bao gồm sự thay đổi hiệu suất so với việc dự đoán sử dụng các tuyên bố gốc từ Bảng 2.

AGGREFACT đứng đầu trong số các nhà kiểm tra sự thật từ các công trình trước đây. Tuy nhiên, bằng cách tinh chỉnh mô hình cốt lõi RoBERTa của AlignScore trên 14 nghìn dữ liệu tổng hợp của chúng tôi (MiniCheck-RBTA), chúng tôi vượt qua hiệu suất của AlignScore 1,5%. Cải tiến này nổi bật hơn trong môi trường không điều chỉnh ngưỡng (Mục 6). Đáng chú ý, sự gia tăng hiệu suất này đạt được khi sử dụng một bộ dữ liệu chỉ chiếm chưa đến 0,3% tổng dữ liệu ban đầu mà AlignScore được đào tạo (Bảng 3). Phát hiện này nhấn mạnh tiềm năng của dữ liệu tổng hợp được chọn lọc trong việc nâng cao hiệu suất của các công cụ kiểm tra sự thật tiên tiến. Nhìn chung, các mô hình của chúng tôi đạt được cấp trạng thái nghệ thuật mới trong số các mô hình chuyên biệt dưới môi trường điều chỉnh ngưỡng.

Dữ liệu tổng hợp của chúng tôi cải thiện độ bền và hiệu suất của mô hình khi không điều chỉnh ngưỡng. So sánh Bảng 2 với Bảng 7, chúng ta thấy hiệu suất của các bộ kiểm tra sự thật chuyên biệt giảm khi không điều chỉnh ngưỡng. Tuy nhiên, MiniCheck-FT5 chỉ giảm 0,4% so với mức giảm lớn hơn của các hệ thống khác, chẳng hạn như 9,2% cho SummaC-CV. Những kết quả này gợi ý rằng dữ liệu tổng hợp của chúng tôi không chỉ cải thiện hiệu suất tổng thể mà còn tăng cường tính ổn định của các mô hình trên các miền trong bộ chuẩn của chúng tôi, cho phép chúng duy trì hiệu suất mạnh ngay cả khi không điều chỉnh ngưỡng.

B.2 Kết Quả Đầy Đủ Sử Dụng Phân Rã Yêu Cầu

Trong Bảng 8, chúng tôi trình bày hiệu suất (và sự thay đổi hiệu suất) của GPT-4 và một tập hợp con của các công cụ kiểm chứng chuyên biệt trên tất cả các bộ dữ liệu từ LLM-AGGREFACT, sử dụng phân rã tuyên bố để xác định nhãn thực tế cho mỗi t uyên bố.

B.3 Kết quả đầy đủ Sử dụng Khai thác Độc lập ngữ cảnh

Trong Bảng 9, chúng tôi trình bày hiệu suất (và những thay đổi về hiệu suất) của GPT-4 và một tập hợp con các công cụ kiểm tra thực tế chuyên biệt trên tất cả các tập dữ liệu từ LLM-AGGREFACT, sử dụng việc tách ngữ cảnh của tuyên bố khi có thể. Cụ thể, chúng tôi thực hiện tách ngữ cảnh tuyên bố trên TOFUEVAL-MediaS,

Model Name	TofuEval	
	MediaS	MeetB
GPT-4	71.4	79.9
GPT-4-Full	72.3	79.7

Table 10: Comparison of GPT-4 and GPT-4-Full on TofuEval, a dataset where sentences from an LLM-generated response share the same grounding document.

TofuEval-MeetB, Wice, Reveal, ClaimVerify, ExpertQA, and Lfqa. Note that the claim decontextualization step add a non-negligible amount of cost, as shown in Table 4.

B.4 Results Predicting All Errors

When a grounding document is relevant to multiple sentences in a response, it becomes feasible to ask an LLM-based fact-checker to simultaneously predict the factuality labels for all sentences, thereby reducing cost. We investigate this approach using GPT-4 on the TofuEval datasets, where we provide GPT-4 with a document and the entire summary, asking the model to predict the factuality labels for all summary sentences at once, denoted as **GPT4-Full**. The prompt is shown in Table 28. Table 10 shows that GPT4-Full achieves performance similar to predicting the factual label for each summary sentence individually. The inference cost on the TofuEval test set can be reduced from $16.7 to $6.72 with this method.

However, in retrieve-then-generate and post-hoc grounding settings, evidence is typically retrieved for each claim separately, meaning no document can be shared across claims in a single response, and thus the inference cost is barely reduced.

C LLM-AggreFact Details

C.1 Dataset Descriptions

AggreFact (Tang et al., 2023a) is a factual consistency evaluation benchmark for new summarization, targeting **CNN(/DM)** (Nallapati et al., 2016) and **XSum** (Narayan et al., 2018). Our focus is on the SOTA sets within AggreFact, where summaries are generated from SOTA fine-tuned summarizers, since their analysis suggests that summaries are more challenging to evaluate for factual consistency compared to summaries generated by pre-SOTA summarizers. Data in AggreFact comes from 9 factual consistency evaluation datasets on CNN or XSum, including widely used ones such as SummaC (Laban et al., 2022), FRANK (Pagnoni et al., 2021), and SummEval (Fabbri et al., 2021). Check Appendix C for a complete set of evaluation datasets in AggreFact. Because CNN/DM and XSum feature quite different styles of summaries, we report these numbers separately in our benchmark. However, we do not otherwise report results on the smaller datasets within the AggreFact SOTA subset.

TofuEval (Tang et al., 2024) is a factual consistency evaluation benchmark for dialogue summarization, targeting **MediaS**um (interviews, Zhu et al. (2021)) and **Meet**ing**B**ank (city council meetings, Hu et al. (2023)). It includes topic-focused dialogue summaries generated by 6 LLMs, with sentence-level factual consistency annotations by linguists.

Wice (Kamoi et al., 2023) is a textual entailment dataset that consists of naturally occurring claims from Wikipedia and their cited documents. Based on its cited documents, each claim is labeled as `supported`, `partially-supported`, or `non-supported`.

Reveal (Jacovi et al., 2024) is a benchmark dataset that evaluates the correctness of reasoning chains generated by LLMs in the context of open-domain question-answering. The dataset includes annotations at the sentence level, covering various aspects of response correctness. For our dataset, we focus on the subset of sentences that have *attribution* annotations, which indicate whether a sentence in a reasoning chain can be attributed to information retrieved from Wikipedia paragraphs with three label categories: `fully attributable`, `partially attributable`, or `contradictory`.

ClaimVerify (Liu et al., 2023) evaluates the correctness of responses from four generative search engines in answering user queries. Similar to Wice, the dataset contains annotations on whether check-worthy sentences from the engines' responses can be fully supported by their associated cited documents. The dataset contains binary-level factual consistency annotations for each citeworthy sentence.

FactCheck-GPT (Wang et al., 2023) contains factual consistency annotations for LLMs' responses to search queries. In this dataset, each sentence from LLMs' responses is first decomposed into atomic facts and those atomic facts are then fur-

Mô hình Name	ĐÁNH GIÁ TOFU	
	MediaS	GặpB
GPT-4	71.4	79.9
GPT-4-Full	72.3	79.7

Bảng 10: So sánh giữa GPT-4 và GPT-4-Full trên TOFUEVAL, một tập dữ liệu mà các câu từ câu trả lời do LLM tạo ra có cùng tài liệu cơ sở.

TOFUEVAL-MeetB, WICE, REVEAL, CLAIMVER-IFY, EXPERTQA, và LFQA. Lưu ý rằng bước phi ngữ cảnh hóa tuyên bố thêm một lượng chi phí không thể xem nhẹ, như được trình bày trong Bảng 4.

B.4 Kết quả Dự đoán Tất cả Lỗi

Khi một tài liệu cơ sở liên quan đến nhiều câu tr ong một phản hồi, việc yêu cầu một bộ kiểm tra sự thật dựa trên LLM đồng thời dự đoán nhãn tính xác thực cho tất cả các câu một cách khả thi, từ đó giả m chi phí. Chúng tôi nghiên cứu phương pháp này sử dụng GPT-4 trên bộ dữ liệu TOFUEVAL, nơi chúng tôi cung cấp cho GPT-4 một tài liệu và toàn bộ bản tóm tắt, yêu cầu mô hình dự đoán nhãn tí nh xác thực cho tất cả các câu trong bản tóm tắt cùng lúc, được ký hiệu là GPT4-Full. Lời nhắc được hiển thị trong Bảng 28. Bảng 10 cho thấy GPT4-Full đạt hiệu suất tương tự như dự đoán nhãn tính xác thực cho từng câu trong bản tóm tắt một cách riêng lẻ. Chi phí suy luận trên tập kiểm tra TOFUEVAL có thể giảm từ 16,7 đô la xuống 6,72 đô la với phương pháp này.

Tuy nhiên, trong các thiết lập truy xuất-rồi-tạo và cơ sở hóa hậu kỳ, bằng chứng thường được truy xuất cho từng tuyên bố riêng lẻ, có nghĩa là không tài liệu nào có thể được chia sẻ giữa các tuyên bố trong một phản hồi duy nhất, do đó chi phí suy luận hầu như không giảm.

Chi tiết C LLM-AGGREFACT

C.1 Mô tả bộ dữ liệu

AGGREFACT (Tang et al., 2023a) là một chuẩn đánh giá tính nhất quán thực tế cho tóm tắt mới, hướng đến CNN(/DM) (Nallapati et al., 2016) và XSum (Narayan et al., 2018). Chúng tôi tập trung vào các tập SOTA trong AGGREFACT, nơi các bản tóm tắt được tạo ra từ các bộ tóm tắt tinh chỉnh SOTA, vì phân tích của họ cho thấy các bản tóm tắt này khó đánh giá về tính nhất quán thực tế hơn so với các bản tóm tắt được tạo ra bởi các bộ tóm tắt trước SOTA. Dữ liệu trong AGGREFACT đến từ 9 bộ dữ li ệu đánh giá tính nhất quán thực tế trên CNN hoặc XSum, bao gồm rộng rãi những cái đã sử dụng như SummaC (Laban et al., 2022), FRANK (Pagnoni et al., 2021), và SummEval (Fabbri et al., 2021). Kiểm tra Phụ lục C để có bộ dữ liệu đánh giá đầy đủ trong AGGREFACT. Vì CNN/DM và XSum có phong cách tóm tắt khá khác nhau, chúng tôi báo cáo những con số này riêng biệt trong chuẩn đánh giá của chúng tôi. Tuy nhiên, chúng tôi không báo cáo kết quả trên các bộ dữ liệu nhỏ hơn trong tập con AGGREFACT SOTA.

TOFUEVAL (Tang et al., 2024) là một chuẩn đánh giá tính nhất quán thực tế cho việc tóm tắt hội thoại, nhắm vào MediaSum (các cuộc phỏng vấn, Zhu et al. (2021)) và MeetingBank (các cuộc họp hội đồng thành phố, Hu et al. (2023)). Nó bao gồm các bản tóm tắt hội thoại tập trung vào chủ đề được tạo bởi 6 mô hình ngôn ngữ lớn, với các chú thích về tính nhất quán thực tế ở cấp câu bởi các nhà ngôn ngữ học.

WICE (Kamoi và cộng sự, 2023) là một tập dữ liệu suy diễn văn bản bao gồm các tuyên bố tự nhiên từ Wikipedia và các tài liệu được trích dẫn của chúng. Dựa trên các tài liệu được trích dẫn, mỗi tuyên bố được gán nhãn là được hỗ trợ, được hỗ trợ một phần, hoặc không được hỗ trợ.

REVEAL (Jacovi et al., 2024) là một bộ dữ liệu c huẩn dùng để đánh giá tính đúng đắn của các c huỗi lập luận do các LLM tạo ra trong bối cảnh hỏi-đáp mở. Bộ dữ liệu bao gồm các chú thích ở cấp câu, bao quát nhiều khía cạnh của tính đúng đắn của phản hồi. Đối với bộ dữ liệu của chúng tôi, chúng tôi tập trung vào tập hợp các câu có chú thích về nguồn gốc, chỉ ra một câu trong chuỗi lập luận có thể được gán cho thông tin lấy từ các đoạn Wikipedia với ba nhãn: hoàn toàn có thể gán, một phần có thể gán, hoặc mâu thuẫn.

CLAIMVERIFY (Liu et al., 2023) đánh giá độ chính xác của các phản hồi từ bốn công cụ tìm kiếm tạo sinh trong việc trả lời các truy vấn của người dùng. Tương tự như WICE, tập dữ liệu chứa các chú thích về việc liệu các câu đáng kiểm tra từ phản hồi của các công cụ có thể được hỗ trợ đầy đủ bởi các tài liệu tham khảo liên kết của chúng hay không. Tập dữ liệu có các chú thích về tính nhất quán thực tế ở mức nhị phân cho mỗi câu đáng trích dẫn.

FACTCHECK-GPT (Wang và cộng sự, 2023) chứa các chú thích về tính nhất quán thực tế cho các phản hồi của LLM đối với các truy vấn tìm kiếm. Trong tập dữ liệu này, mỗi câu từ phản hồi của LLM trước tiên được phân tách thành các sự thật nguyên tử và sau đó các s ự thật nguyên tử đó được

ther decontextualized so that they can stand alone. Finally, each worth-checking and decontextualized atomic fact is labeled as `completely support`, `partially support`, `refute`, or `irrelevant`. We include those decontextualized atomic facts and their corresponding documents in the benchmark.

EXPERTQA (Malaviya et al., 2024) contains responses from 6 different systems to queries curated by experts from 32 fields. These systems answer queries either in a close-book fashion with/without in-line citations, or based on retrieved document(s). For each sentence in the response, the sentence is verified against the concatenation of cited or retrieved document(s), if any. We include examples where documents are judged as `complete`, `partial`, or `incomplete` in supporting the corresponding sentences. We do not include human edited claims and evidence in our benchmark.

LFQA (Chen et al., 2023) contains LLM-generated responses to questions from the ELI5 ("Explain Like I'm Five") dataset (Fan et al., 2019). LLMs generate responses based on documents that are either retrieved by humans, models, or randomly selected. Human annotators then evaluate each sentence in the LLM-generated responses against the corresponding document set, classifying them into `supported`, `partially supported`, or `not supported`.

C.2 Label Unification

For AGGREFACT, TOFUEVAL, and CLAIMVERIFY, we keep using the binary label from the original work. For the remaining datasets, we map `supported`, `fully attributable`, `completely support`, and `complete` to `supported`, and `unsupported` otherwise.

C.3 Excluded Datasets

We excluded **HALUEVAL** (Li et al., 2023) and **SUMMEDITS** (Laban et al., 2023) from our benchmark since they are synthetic, with errors in summaries generated via instruction prompts that guide the model to intentionally make errors in summaries. These errors are unnatural and do not fit with our goal of detecting true LLM generation errors. **FACTSCORE** (Min et al., 2023) contains naturally generated biographies from LLMs and has human-annotated labels of individual atomic facts. However, humans could potentially search different articles to verify the correctness of those sentences than the ones that models retrieve. As a result, a non-negligible fraction of the claims in the dataset appear mislabeled from the standpoint of the fact-checking on grounded documents task.

Dataset		Split	Size	Doc Len	Claim Len	% of Neg
AGGREFACT	CNN	dev	459	558	56	13%
		test	558	563	58	10%
	XSum	dev	777	374	26	49%
		test	558	370	25	49%
TOFUEVAL	Media	dev	1800	990	21	20%
		test	726	922	21	24%
	MeetB	dev	1607	930	22	18%
		test	772	915	22	19%
WICE		dev	349	1622	27	67%
		test	358	1683	28	69%
REVEAL		dev	1656	104	11	77%
		test	1710	103	11	77%
CLAIM VERIFY		dev	1093	1874	21	25%
		test	1088	1841	22	27%
FACT CHECK		dev	1537	100	14	83%
		test	1566	100	13	76%
EXPERT QA		dev	3773	491	29	22%
		test	3702	506	29	20%
LFQA		dev	2029	383	25	43%
		test	1911	380	25	41%

Table 11: **Statistics of datasets in LLM-AGGREFACT.** We show the size of datasets, the average length of documents and claims, and the proportion of unsupported claims.

C.4 Statistics

The statistics of LLM-AGGREFACT can be found in Table 11. Our use of these datasets is for research purposes only, which is consistent with their intended use.

AGGREFACT contains the following 9 factual consistency evaluation datasets on CNN or XSum: FactCC (Kryscinski et al., 2020), Wang'20 (Wang et al., 2020), SummEval (Fabbri et al., 2021), Polytope (Huang et al., 2020), Cao'22 (Cao et al., 2022), XSumFaith (Maynez et al., 2020), FRANK (Pagnoni et al., 2021), Goyal'21 (Goyal and Durrett, 2021), and CLIFF (Cao and Wang, 2021).

D Synthetic Data Details

Source of Data In our C2D method, we choose around 400 claims from Wikipedia that have cited web articles (Kamoi et al., 2023; Petroni et al., 2023) to generate synthetic documents. In our D2C method, we scraped around 300 Google News articles since November 2023 from diverse topic cate-

được tách ra khỏi ngữ cảnh để chúng có thể tồn tại độc lập. Cuối cùng, mỗi sự kiện nguyên tử đã được kiểm tra giá trị và tách ra khỏi ngữ cảnh được gán nhãn là hoàn toàn ủng hộ, ủng hộ một phần, bác bỏ, hoặc không liên quan. Chúng tôi bao gồm những sự kiện nguyên tử đã tách ra khỏi ngữ cảnh đó và các tài liệu tương ứng của chúng trong bộ chuẩn.

EXPERTQA (Malaviya và cộng sự, 2024) chứa các phản hồi từ 6 hệ thống khác nhau đối với các truy vấn được tuyển chọn bởi các chuyên gia từ 32 lĩnh vực. Các hệ thống này trả lời các truy vấn theo cách đóng sách có hoặc không có trích dẫn trực tiếp, hoặc dựa trên tài liệu được truy xuất. Đối với mỗi câu trong phản hồi, câu đó được xác minh dựa trên sự kết hợp của các tài liệu được trích dẫn hoặc truy xuất, nếu có. Chúng tôi bao gồm các ví dụ trong đó các tài liệu được đánh giá là đầy đủ, một phần hoặc không đầy đủ trong việc hỗ trợ các câu tương ứng. Chúng tôi không bao gồm các tuyên bố và bằng chứng được chỉnh sửa bởi con người trong bộ dữ liệu chuẩn của mình.

LFQA (Chen và cộng sự, 2023) chứa các phản hồi do LLM tạo ra đối với các câu hỏi từ bộ dữ liệu ELI5 (" Giải thích như thể tôi năm tuổi") (Fan và cộng sự, 2019). LLM tạo ra các phản hồi dựa trên các tài liệu được con người, mô hình hoặc ngẫu nhiên lựa chọn. Các chú thích viên con người sau đó đánh giá từng câu trong các phản hồi do LLM tạo ra dựa tr ên tập tài liệu tương ứng, phân loại chúng thành được hỗ trợ, được hỗ trợ một phần, hoặc không được hỗ trợ.

Bộ dữ liệu		Kích thước phân tách		Doc Len	Yêu cầu Len	% of Neg
AGGREFACT	CNN	dev	459	558	56	13%
		test	558	563	58	10%
	XSum	dev	777	374	26	49%
		test	558	370	25	49%
ĐÁNH GIÁ TOFU	Truyền thông	dev	1800	990	21	20%
		test	726	922	21	24%
	GặpB	dev	1607	930	22	18%
		test	772	915	22	19%
WICE		dev	349	1622	27	67%
		test	358	1683	28	69%
TIẾT LỘ		dev	1656	104	11	77%
		test	1710	103	11	77%
YÊU CẦU XÁC MINH		dev	1093	1874	21	25%
		test	1088	1841	22	27%
FACT KIỂM TRA		dev	1537	100	14	83%
		kiểm tra	1566	100	13	76%
CHUYÊN GIA QA		dev	3773	491	29	22%
		kiểm tra	3702	506	29	20%
LFQA		dev	2029	383	25	43%
		test	1911	380	25	41%

Bảng 11: Thống kê các tập dữ liệu trong LLM-AGGREFACT. Chúng tôi hiển thị kích thước của các tập dữ liệu, độ dài trung bình của các tài liệu và các tuyên bố, cũng như tỷ lệ các tuyên bố không được hỗ trợ.

Kết quả, một phần không nhỏ các tuyên bố trong tập dữ liệu dường như bị gán nhãn sai từ quan điểm kiểm tra sự thật dựa trên nhiệm vụ tài liệu cơ sở.

C.2 Thống nhất nhãn

Đối với AGGREFACT, TOFUEVAL và CLAI MVER-IFY, chúng tôi tiếp tục sử dụng nhãn nhị phân từ công trình gốc. Đối với các tập dữ liệu còn lại, chúng tôi ánh xạ 'supported', 'fully attri butable', 'completely support' và 'complete' thành 'supported', và các trường hợp khác thành 'unsupported'.

C.3 Bộ dữ liệu bị loại trừ

Chúng tôi đã loại trừ HALUEVAL (Li et al., 2023) và SUMMEDITS (Laban et al., 2023) khỏi chuẩn đánh giá của mình vì chúng là tổng hợp, với các lỗi trong các bản tóm tắt được tạo ra thông qua các lệnh hướng dẫn mô hình cố tình gây ra lỗi trong các bản tóm tắt. Những lỗi này không tự nhiên và không phù hợp với mục tiêu của chúng tôi là phát hiện các lỗi thực sự do LLM tạo ra. FACTSCORE (Min et al., 2023) chứa các tiểu sử được tạo ra một cách tự nhiên từ LLM và có nhãn do con người chú thích các sự thật riêng lẻ. Tuy nhiên, con người có thể tì m kiếm các bài báo khác để xác minh tính đúng đắn của các câu đó so với những gì các mô hình truy xuất.

C.4 Thống kê

Thống kê của LLM-AGGREFACT có thể được tìm thấy trong Bảng 11. Việc chúng tôi sử dụng các bộ dữ liệu này chỉ nhằm mục đích nghiên cứu, điều này phù hợp với mục đích sử dụng ban đầu của chúng.

AGGREFACT chứa 9 tập dữ liệu đánh giá tính nhất quán thực tế sau trên CNN hoặc XSum: FactCC (Kryscinski et al., 2020), Wang'20 (Wang et al., 2020), SummEval (Fabbri et al., 2021), Polytope (Huang et al., 2020), Cao'22 (Cao et al., 2022), XSumFaith (Maynez et al., 2020), FRANK (Pagnoni et al., 2021), Goyal'21 (Goyal và Durrett, 2021), và CLIFF (Cao và Wang, 2021).

D Chi tiết Dữ liệu Tổng hợp

Nguồn dữ liệu Trong phương pháp C2D của chúng tôi, chúng tôi chọn khoảng 400 tuyên bố từ Wikipedia có trích dẫn các bài báo trên web (Kamoi et al., 2023; Petroni et al., 2023) để tạo các tài liệu tổng hợp. Trong phương pháp D2C của chúng tôi, chúng tôi đã thu thập khoảng 300 bài báo của Google News từ tháng 11 năm 2023 từ các danh mục chủ đề đa dạng

	Label	Min.	25%	50%	75%	Max.
C2D	1	72	147	182	242	359
	0	66	136	171	234	359
D2C	1	85	139	162	186	427
	0	84	138	161	186	493

Table 12: Length distribution of generated documents. We use the NLTK package for word tokenizatiopn.

Model	Checkpoint
Gemini-Pro	`gemini-1.0-pro`
PaLM2-Bison	`chat-bison@001`
Mistral-8x7B	`open-mixtral-8x7b`
Mistral-Large	`mistral-large-2402`
Claude-2.1	`claude-2.1`
Claude-3 Opus	`claude-3-opus-20240229`
GPT-3.5	`gpt-3.5-turbo-0125`
GPT-4	`gpt-4-0125-preview`

Table 13: LLM checkpoints

gories, including science, politics, world, entertainment, business, and technology. Each document is approximately 500 words. Statistics of our generated data can be found in Table 1 and 12. See Appendix H.1 for how we maintain the quality of our synthetic data.

Characteristics of Synthetic Data It is worth noting that constructing our synthetic dataset involves using human-written or naturally generated claims, which sets it apart from prior synthetic data generation methods used to train fact-checkers for text summarization. These methods, such as entity swapping and sentence negation (Kryscinski et al., 2020; Goyal and Durrett, 2021), were designed to target specific error types that occurred in claims from earlier summarization models. However, as errors from generative models progress (Tang et al., 2023a) and new error types emerge from LLMs, focusing on specific error types may not generalize well to unseen datasets with potentially novel errors.

Examples of synthetic data for C2D and D2C can be found in Table 15 and 16.

Data Rejection Rate Since we use GPT-4 for filtering out low-quality examples in our C2D method, we report the rejection rate at different steps that require entailment checks.

During the *atomic fact expansion* step (step 2), 6% of the final generated sentence pairs, when combined, could not support the original atomic fact. In the *supporting document generation* step (step 3), 5% of the final documents failed the entailment check. For the *non-supporting document generation* step (step 4), 53% of the final documents still supported the claim, and these documents were not included in our constructed data. These filtering steps are crucial for improving the training dataset's quality.

E Fact-Checking Model Details

E.1 LLM-Based Fact-Checkers

We use the official APIs for LLM-based fact-checkers. The checkpoints we use for LLMs can be found in Table 13. The inference prompt is the same for all LLMs and can be found in Table 23. We use a temperature of zero to collect deterministic outputs, which is typical from previous work.

E.2 Specialized Fact-Checkers

QAFactEval (Fabbri et al., 2022) is a QA-based fact-checker with optimized components for answer selection, question answering, question generation, and answer overlap calculation. It selects spans as answers from a summary sentence, generates questions based on these answers, and then answers these questions using the source document. Finally, it computes an overall overlap score for the summary sentence by comparing the selected spans from the summary sentence with the answers derived from the source document, given the generated questions. QAFactEval produces scores on a continuous scale ranging from 0 to 5. In our experiments, we use the default model and hyperparameters as provided by the authors.

DAE (Goyal and Durrett, 2020, 2021) is an entailment-based fact-checker that evaluates the factual consistency of each dependency arc in a summary sentence. It independently verifies whether the semantic relationship of each dependency arc is factually supported by the source document. Finally, it aggregates the scores for all dependency arcs to compute an overall sentence-level factuality score ranging from 0 to 1. In our experiments, we use the default model and hyperparameters as provided by the authors in Goyal and Durrett (2021).

	Nhãn	Tối thiểu	25%	50%	75%	Max.
C2D	1	72	147	182	242	359
	0	66	136	171	234	359
D2C	1	85	139	162	186	427
	0	84	138	161	186	493

Bảng 12: Phân bố độ dài của các tài liệu được tạo. Chúng tôi sử dụng gói NLTK để tách từ.

Mô hình	Trạm kiểm soát
Gemini-Pro	gemini-1.0-pro
PaLM2-Bison	chat-bison@001
Mistral-8x7B	mở-mixtral-8x7b
Mistral-Large	mistral-large-2402
Claude-2.1	claude-2.1
Claude-3 Opus	claude-3-opus-20240229
GPT-3.5	gpt-3.5-turbo-0125
GPT-4	gpt-4-0125-preview

Bảng 13: Các điểm kiểm tra LLM

Các thể loại, bao gồm khoa học, chính trị, thế giới, giải trí, kinh doanh và công nghệ. Mỗi tài liệu khoảng 500 từ. Thống kê về dữ liệu do chúng tôi tạo ra có thể được tìm thấy trong Bảng 1 và 12. Xem Phụ lục H.1 để biết cách chúng tôi duy trì chất lượng dữ liệu tổng hợp của mình.

Đặc điểm của Dữ liệu Tổng hợp Cần lưu ý rằng việc xây dựng bộ dữ liệu tổng hợp của chúng tôi liên quan đến việc sử dụng các tuyên bố do con người viết hoặc được tạo ra tự nhiên, điều này khiến nó khác biệt so với các phương pháp tạo dữ liệu tổng hợp trước đây được sử dụng để huấn luyện các bộ kiểm tra sự thật cho việc tóm tắt văn bản. Các phương pháp này, chẳng hạn như hoán đổi thực t hể và phủ định câu (Kryscinski et al., 2020; Goyal và Durrett, 2021), được thiết kế để nhắm vào các loại lỗi cụ thể xuất hiện trong các tuyên bố từ các mô hình tóm tắt trước đó. Tuy nhiên, khi lỗi từ các mô hình sinh tiến triển (Tang et al., 2023a) và các loại lỗi mới xuất hiện từ các LLM, việc tập trung vào các loại lỗi cụ thể có thể không tổng quát tốt cho các bộ dữ liệu chưa thấy với các lỗi có thể mới.

Các ví dụ về dữ liệu tổng hợp cho C2D và D2C có thể được tìm thấy trong Bảng 15 và 16.

Tỷ lệ từ chối dữ liệu Vì chúng tôi sử dụng GPT-4 để lọc các ví dụ chất lượng thấp trong phương pháp C2D của mình, chúng tôi báo cáo tỷ lệ từ chối ở các bước khác nhau mà yêu cầu kiểm tra sự liên kết.

Trong bước mở rộng sự kiện nguyên tử (bước 2), 6% các cặp câu cuối cùng được tạo ra, khi kết hợp, không thể hỗ trợ sự kiện nguyên tử ban đầu. Trong bước tạo tài liệu hỗ trợ (bước 3), 5% các tài liệu cuối cùng không vượt qua kiểm tra suy luận. Đối với bước tạo tài liệu không hỗ trợ (bước 4), 53% các tài liệu cuối cùng vẫn hỗ trợ tuyên bố, và những tài liệu này không được bao gồm trong dữ liệu mà chúng tôi xây dựng. Những bước lọc này rất quan trọng để nâng cao chất lượng bộ dữ liệu đào tạo.

Chi tiết Mô hình Kiểm tra sự thật E

E.1 Trình kiểm tra sự thật dựa trên Mô hình Ngôn ngữ Lớn

Chúng tôi sử dụng các API chính thức cho các công cụ kiểm tra sự thật dựa trên LLM. Các điểm kiểm tra mà chúng tôi sử dụng cho LLM có thể được tìm thấy trong Bảng 13. Lời nhắc suy luận giống nhau cho tất cả các LLM và có thể được tìm thấy trong Bảng 23. Chúng tôi sử dụng nhiệt độ bằng không để thu thập các đầu ra xác định, điều này là điển hình từ các công trình trước đây.

E.2 Các kiểm chứng viên chuyên môn

QAFactEval (Fabbri et al., 2022) là một công cụ kiểm tra sự thật dựa trên QA với các thành phần được tối ưu hóa cho việc lựa chọn câu trả lời, trả l ời câu hỏi, tạo câu hỏi và tính toán độ trùng lặp câu trả lời. Nó chọn các đoạn văn làm câu trả lời từ một câu tóm tắt, tạo câu hỏi dựa trên các câu trả lời này, và sau đó trả lời các câu hỏi này bằng cách sử dụng tài liệu gốc. Cuối cùng, nó tính toán điểm trùng lặp tổng thể cho câu tóm tắt bằng cách so sánh các đoạn đã chọn từ câu tóm tắt với các câu trả lời được rút ra từ tài liệu gốc, dựa trên các câu hỏi đã tạo. QAFactEval đưa ra điểm trên thang liên tục từ 0 đến 5. Trong các thí nghiệm của chúng tôi, chúng tôi sử dụng mô hình và các siêu tham số mặc định như được các tác giả cung cấp.

DAE (Goyal và Durrett, 2020, 2021) là một công cụ kiểm tra sự thật dựa trên mối quan hệ suy diễn, đánh giá tính nhất quán về sự thật của từng cung phụ thuộc trong một câu tóm tắt. Nó xác minh độc lập xem mối quan hệ ngữ nghĩa của từng cung phụ thuộc có được hỗ trợ thực tế bởi tài liệu gốc hay không. Cuối cùng, nó tổng hợp các điểm số của tất cả các cung phụ thuộc để tính điểm tính xác thực tổng thể ở cấp câu, dao động từ 0 đến 1. Trong các thí nghiệm của chúng tôi, chúng tôi sử dụng mô hình mặc định và các siêu tham số như được cung cấp bởi các tác giả trong Goyal và Durrett (2021).

SummaC-ZS (Laban et al., 2022) is an entailment-based fact-checker. To evaluate a summary sentence c_i, it divides the source document D_i into a set of sentences or paragraphs $D_i = \{d_{i,1}, \ldots, d_{i,|d|}\}$, and the score for c_i is determined by the highest score among all $(d_{i,j}, c_i)$ pairs, i.e., $\text{score}(c_i) = \max_j M(di, j, c_i)$. For a multi-sentence summary, the final score is calculated as the average of the individual sentence scores. In our experiments, we do not use the authors' default setting of splitting the document D_i into sentences and instead choose paragraph-level segmentation, as most datapoints in LLM-AGGREFACT require reasoning across multiple sentences. We find this change not only improves the overall performance but also accelerates inference speed. Apart from this adjustment, we adhere to the default model and hyperparameters provided by the authors. SummaC-ZS returns a score between -1 and 1.

SummaC-CV (Laban et al., 2022) extends SummaC-ZS by considering all entailment scores for each summary sentence c_i. Similar to SummaC-ZS, SummaC-Conv evaluates a summary sentence c_i by dividing the source document D_i into $D_i = \{d_{i,1}, \ldots, d_{i,|d|}\}$. However, instead of selecting the maximum score among all $(d_{i,j}, c_i)$ pairs, SummaC-Conv uses a learned convolutional layer to transform the distribution of entailment scores $\{M(d_{i,j}, c_i) : \forall j\}$ into a single score. The final summary score is computed by averaging the scores of individual sentences. As with SummaC-ZS, we use paragraph-level segmentation in our experiments and keep other settings as default. SummaC-Conv outputs a score between 0 and 1.

AlignScore (Zha et al., 2023) is an entailment-based model that has been trained on data from a wide range of tasks such as NLI, QA, fact verification, and summarization. It works similarly to SummaC-ZS, with the only difference being that it splits a document $D_i = \{d_{i,1}, \ldots, d_{i,|d|}\}$ into sequential chunks at sentence boundaries. Each chunk contains approximately 350 tokens, determined by white space splitting. In our experiments, we use the default model and hyperparameters as provided by the authors. AlignScore outputs a score between 0 and 1.

T5-NLI-Mixed (Honovich et al., 2022) is an entailment-based fact-checker built on T5-XXL. It has been trained on a diverse set of NLI datasets and predicts whether a given claim is supported by a document, outputting "1" for supported claims and "0" for unsupported ones. The final entailment score is calculated as the probability of the model predicting the token "1". To optimize its performance on 2 GPUs from our hardware setup, we select a chunk size of 350 tokens according to the T5 tokenizer. T5-NLI-Mixed outputs a score between 0 and 1.

MINICHECK-RBTA, MINICHECK-DBTA also split a document into chunks at sentence boundaries, with a chunk size of approximately 400 tokens according to RoBERTA and DeBERTa tokenizers. This results in approximately the same chunk size as in AlignScore, which has a chunk size of 350 tokens using white space splitting. The output scores fall within the range of 0 to 1.

FT5-ANLI-L, MiniCheck-FT5 work the same way as T5-NLI-Mixed, but using only one GPU and setting the chunk size to 500 tokens using white space splitting. The output scores fall within the range of 0 to 1.

E.2.1 Machine Configuration for Specialized Fact-Chekers

We use two `NVIDIA RTX A6000` GPUs for T5-NLI-Mixed, given its model size, and one GPU for the remaining models, all on our own hardware. According to Lambda,[6] a single `NVIDIA RTX A6000` GPU costs $0.8 per hour and has 48 GB VRAM.

F Baseline Synthetic Data Generation Methods

We describe the simplified methods in generating C2D and D2C datasets, denoted as C2D-SIMP and D2C-Simp. Performance on models trained on those simplified synthetic datasets can be found in Section A.1.

The motivation for these models is to capture the performance of a more basic prompting approach, where we simply ask GPT-4 to generate a data instance in one shot. Comparing the performance of this with C2D/D2C helps validate our more sophisticated prompting strategy.

C2D-SIMP To generate the C2D-SIMP dataset, we begin by providing GPT-4 with a claim c and asking it to create a supporting document D that requires multiple sentences together to support the

[6]Detailed price specifications are available at `https://lambdalabs.com/service/gpu-cloud##pricing`.

SummaC-ZS (Laban và cộng sự, 2022) là một công cụ kiểm tra sự thật dựa trên sự suy diễn. Để đánh giá một câu tóm tắt c_i, nó chia tài liệu gốc D_i t hành một tập các câu hoặc đoạn $D_i = \{d_{i,1}, \ldots, d_{i,|d|}\}$, và điểm số cho c_i được xác định bởi điểm cao nhất trong tất cả các cặp $(d_{i,j}, c_i)$, tức là, score(c_i) $= \max_j M(di, j, c_i)$. Đối với một bản tóm tắt gồm nhiều câu, điểm cuối cùng được tính bằng trung bình của điểm số từng câu. Trong các thí nghiệm của chúng tôi, chúng tôi không sử dụng cài đặt mặc định của tác giả là chia tài liệu D_i thành các câu mà thay vào đó chọn phân đoạn theo đoạn, vì hầu hết các điểm dữ liệu trong LLM-AGGREFACT yêu cầu suy luận qua nhiều câu. Chúng tôi nhận thấy sự thay đổi này không chỉ cải thiện hiệu suất tổng thể mà còn tăng tốc độ suy luận. Ngoài điều chỉnh này, chúng tôi tuân thủ mô hình và các siêu tham số mặc định do tác giả cung cấp. SummaC-ZS trả về một điểm số trong khoảng từ -1 đến 1.

SummaC-CV (Laban et al., 2022) mở rộng SummaC-ZS bằng cách xem xét tất cả các điểm liên quan cho mỗi câu tóm tắt c_i. Tương tự như SummaC-ZS, SummaC-Conv đánh giá một câu tóm tắt c_i bằng cách chia tài liệu nguồn D_i thành $D_i = \{d_{i,1}, \ldots, d_{i,|d|}\}$. Tuy nhiên, thay vì chọn điểm tối đa trong tất cả các cặp $(d_{i,j}, c_i)$, SummaC-Conv sử dụng một lớp chập học được để biến đổi phân phối các điểm liên quan $\{M(d_{i,j}, c_i): \forall j\}$ thành một điểm duy nhất. Điểm tóm tắt cuối cùng được tính bằng cách lấy trung bình các điểm của từng câu. Giống như SummaC-ZS, chúng tôi sử dụng phân đoạn cấp đoạn văn trong các thí nghiệm của mình và giữ các thiết lập khác ở chế độ mặc định. SummaC-Conv xuất ra một điểm từ 0 đến 1.

AlignScore (Zha et al., 2023) là một mô hình dựa trên suy luận (entailment) được đào tạo trên dữ li ệu từ nhiều nhiệm vụ khác nhau như NLI, QA, kiểm chứng sự thật và tóm tắt. Nó hoạt động tương tự như SummaC-ZS, với điểm khác biệt duy nhất là nó chia tài liệu $D_i = \{d_{i,1}, \ldots, d_{i,|d|}\}$ thành các đoạn liên tiếp tại các ranh giới câu. Mỗi đoạn chứa khoảng 350 từ, được xác định bằng cách tách theo khoảng trắng. Trong các thí nghiệm của chúng tôi, chúng tôi sử dụng mô hình và siêu tham số mặc định như được các tác giả cung cấp. AlignScore xuất điểm trong khoảng từ 0 đến 1.

T5-NLI-Mixed (Honovich et al., 2022) là một công cụ kiểm tra sự thật dựa trên suy diễn được xây dựng trên T5-XXL. Nó đã được đào tạo trên một tập hợp các bộ dữ liệu NLI đa dạng và dự đoán liệu một tuyên bố nhất định có được một tài liệu hỗ trợ hay không, xuất ra "1" cho các tuyên bố được hỗ trợ và "0" cho các tuyên bố k hông được hỗ trợ. Điểm xác nhận cuối cùng được tính bằng xác suất mô hình dự đoán token "1". Để tối ưu hiệu suất trên 2 GPU từ thiết lập phần cứng của chúng tôi, chúng tôi chọn kích thước khối là 350 token theo bộ mã hóa T5. T5-NLI-Mixed xuất ra một điểm nằm giữa 0 và 1.

MINICHECK-RBTA, MINICHECK-DBTA cũng chia một tài liệu thành các đoạn tại các ranh giới câu, với kích thước đoạn xấp xỉ 400 token theo bộ mã hóa RoBERTA và DeBERTa. Điều này dẫn đến kích thước đoạn xấp xỉ giống như trong AlignScore, có kích thước đoạn là 350 token sử dụng phương pháp tách theo khoảng trắng. Các điểm đầu ra nằm tro ng khoảng từ 0 đến 1.

FT5-ANLI-L, MiniCheck-FT5 hoạt động giống như T5-NLI-Mixed, nhưng chỉ sử dụng một GPU và đặt kích thước chunk thành 500 token bằng cách tách theo khoảng trắng. Điểm đầu ra nằm trong khoảng từ 0 đến 1.

E.2.1 Cấu hình máy cho những người kiểm tra sự thật chuyên biệt

Chúng tôi sử dụng hai GPU NVIDIA RTX A6000 cho T5-NLI-Mixed, do kích thước mô hình của nó, và một GPU cho các mô hình còn lại, tất cả trên phần cứng của riêng chúng tôi. Theo Lambda, [6] một GPU NVIDIA RTX A6000 có giá 0,8 USD mỗi giờ và có 48 GB VRAM.

F Phương pháp tạo dữ liệu tổng hợp cơ bản

Chúng tôi mô tả các phương pháp đơn giản hóa trong việc tạo ra các bộ dữ liệu C2D và D2C, được ký hiệu là C2D-SIMP và D2C-Simp. Hiệu năng trên các mô hình được đào tạo trên các bộ dữ liệu tổng hợp đơn giản này có thể được tìm thấy trong Mục A.1.

Động cơ cho các mô hình này là để nắm bắt hiệu suất của một phương pháp gợi ý cơ bản hơn, nơi chúng tôi chỉ đơn giản yêu cầu GPT-4 tạo một ví dụ dữ liệu trong một lần. So sánh hiệu suất của điều này với C2D/D2C giúp xác nhận chiến lược gợi ý tinh vi hơn của chúng tôi.

C2D-SIMP Để tạo ra bộ dữ liệu C2D-SIMP, chúng tôi bắt đầu bằng cách cung cấp cho GPT-4 một tuyên bố c và yêu cầu nó tạo ra một tài liệu hỗ trợ D đòi hỏi nhiều câu cùng nhau để hỗ trợ

[6]Thông tin chi tiết về giá có sẵn tại https://lambdalabs.com/service/gpu-cloud##pricing.

claim (see Table 25 for the generation prompt). We then ask GPT-4 to minimally modify D to create a new document D', which can support some atomic facts mentioned in c but not all of them. Inspired by the error type definitions from Tang et al. (2023a), we provide four different revision types to help GPT-4 generate diverse non-supporting documents, covering various reasons for not supporting the claim (see Table 26 for the prompt). As the generated supporting documents for a given claim tend to be similar despite adjusting the model temperature, we do not generate multiple supporting documents for c. Instead, for each claim, we generate one supporting and pair it with one non-supporting document. To enhance the diversity of the training data and maintain a comparable dataset size to our C2D method, we randomly select 3,500 claims from Wikipedia with cited web articles, resulting in the C2D-SIMP dataset containing 7K datapoints.

D2C-SIMP We start by directly using the summary sentences generated using the chunk-level summarization step of our D2C method (Section 3.2). That is, for each human written document, we have three document chunks $\{D_1, D_2, D_3\}$ and corresponding supporting summary sentences $\{c_1, c_2, c_3\}$ generated by GPT-4. For each $(D_i, c_i, 1)$ tuple, we ask GPT-4 to modify the summary sentence c_i such that the edited summary sentence c_i' is no longer supported by the document chunk D_i. We leverage the editing method from Laban et al. (2023), which is used to construct their SummEdit factual consistency evaluation benchmark. The editing prompt is provided in Table 27. We sample 7K datapoints from the generated data to construct D2C-SIMP.

G Training Details

We include the training details and hyperparemater details in the section. Unless otherwise specified, we use the default hyperparematers of the backbone models. All models are trained using the standard cross-entropy loss function.

For our baseline models: FT5-C2D, FT5-D2C, FT5-ANLI-L, FT5-C2D-S, and FT5-D2C-S, we fine-tune `flan-t5-large`[7] for 2 epochs on prepared data described in Section 5 and A, using a batch size of 4 and a learning rate of 5e-5.

For MiniCheck-RBTA, MiniCheck-DBTA and MiniCheck-FT5, we begin by fine-tuning the tuned RoBERTa-Large model from AlignScore, `deberta-v3-large`[8], and `flan-t5-large` on their respective training data (Section 3.3) for 2 epochs, while excluding 7K D2C synthetic data. We use a batch size of 4 with an accumulation step of 2 and a learning rate of 1e-5 for RoBERTa and 5e-5 for the other two models. We then fine-tune these models on 7K D2C synthetic data for 1 epoch, with a batch size of 4 and learning rate of 1e-5.

We observe that following this training pipeline consistently yields higher performance across all three backbone models compared to training on all data simultaneously. We hypothesize that this improvement stems from the fact that the source documents in the D2C dataset are human-written documents, in contrast to the synthetically generated source documents in the C2D dataset. Fine-tuning on these realistic documents at the end helps the models adapt back to a realistic distribution, preventing them from overfitting to synthetic documents and allowing them to perform well on real documents in the benchmark.

H Prompts

In Table 14, we present the full list of the prompts used throughout our work. We use GPT-3.5 for sentence decomposition and merging atomic facts, and GPT-4 for the remaining prompts. We next elaborate on how we ensure the labeling quality of our synthetically generated data.

H.1 Quality Assurance for Generations

Sentence decomposition We adapt a few-shot sentence decomposition prompt from (Kamoi et al.,

Prompt Functionality	**Ref.**
Sentence decomposition	Table 17
Atomic fact expansion (C2D)	Table 18
Document generation (C2D)	Table 19
Supporting doc. generation (C2D-SIMP)	Table 25
Non-supporting doc. generation (C2D-SIMP)	Table 26
Merging atomic facts (C2D, D2C)	Table 22
Chunk-level summarization (D2C, D2C-Simp)	Table 21
Non-supporting doc. generation (D2C-SIMP)	Table 27
Entailment check for data construction	Table 20
Zero-shot factual consistency evaluation	Tabel 23
Sentence decontextualization	Table 24

Table 14: References to prompts. Upper: prompts for our synthetic data generation methods, and simplified synthetic data generation methods. Lower: Prompts for evaluation on LLM-AGGREFACT.

[7] huggingface.co/google/flan-t5-large

[8] huggingface.co/microsoft/deberta-v3-large

yêu cầu (xem Bảng 25 để biết lệnh tạo). Sau đó, chúng tôi yêu cầu GPT-4 chỉnh sửa tối thiểu D để tạo một tài liệu mới D', có thể hỗ trợ một số sự kiện nguyên tử được đề cập trong c nhưng không phải tất cả. Lấy cảm hứng từ các định nghĩa loại lỗi của Tang và cộng sự (2023a), chúng tôi cung cấp bốn loại chỉnh sửa khác nhau để giúp GPT-4 tạo ra các tài liệu không hỗ trợ đa dạng, bao gồm nhiều lý do khác nhau không hỗ trợ yêu cầu (xem Bảng 26 để biết lệnh). Vì các tài liệu hỗ trợ được tạo ra cho một yêu cầu nhất định có xu hướng giống nhau mặc dù điều chỉnh nhiệt độ mô hình, chúng tôi không tạo nhiều tài liệu hỗ trợ cho c. Thay vào đó, đối với mỗi yêu cầu, chúng tôi tạo một tài liệu hỗ trợ và ghép nó với một tài liệu không hỗ trợ. Để tăng tính đa dạng của dữ liệu huấn luyện và duy trì kích thước bộ dữ liệu tương đương với phương pháp C2D của chúng tôi, chúng tôi chọn ngẫu nhiên 3.500 yêu cầu từ Wikipedia có các bài báo trên web được trích dẫn, dẫn đến bộ dữ liệu C2D-SIMP chứa 7.000 điểm dữ liệu.

D2C-SIMP Chúng tôi bắt đầu bằng cách sử dụng t rực tiếp các câu tóm tắt được tạo ra bằng cách sử dụng bước tóm tắt theo từng đoạn của phương pháp D2C của chúng tôi (Mục 3.2). Tức là, đối với mỗi tài liệu do con người viết, chúng tôi có ba đoạn tài liệu $\{D_1, D_2, D_3\}$ và các câu tóm tắt hỗ trợ tương ứng $\{c_1, c_2, c_3\}$ được tạo bởi GPT-4. Đối với mỗi bộ (D_i, c_i, 1), chúng tôi yêu cầu GPT-4 chỉnh sửa câu tó m tắt c_i sao cho câu tóm tắt đã chỉnh sửa c_i' không còn được hỗ trợ bởi đoạn tài liệu D_i. Chúng tôi tận dụng phương pháp chỉnh sửa từ Laban et al. (2023), được sử dụng để xây dựng bộ đánh giá tính nhất quán thực tế SummEdit của họ. Lời nhắc chỉnh sửa được cung cấp trong Bảng 27. Chúng tôi lấy mẫu 7.000 điểm dữ liệu từ dữ liệu đã tạo để xây dựng D2C-SIMP.

Chi tiết đào tạo G

Chúng tôi bao gồm chi tiết huấn luyện và chi tiết siêu tham số trong phần này. Trừ khi được chỉ định khác, chúng tôi sử dụng các siêu tham số mặc định của các mô hình nền tảng. Tất cả các mô hình được huấn l uyện bằng cách sử dụng hàm mất mát entropi chéo tiêu chuẩn.

Đối với các mô hình cơ sở của chúng tôi: FT5-C2D, FT5-D2C, FT5-ANLI-L, FT5-C2D-S và FT5-D2C-S, chúng tôi tinh chỉnh flan-t5-large[7] trong 2 epoch trên dữ liệu được chuẩn bị như mô tả trong Mục 5 và A, sử dụng kích thước batch là 4 và tốc độ học 5e-5.

Đối với MiniCheck-RBTA, MiniCheck-DBTA và MiniCheck-FT5, chúng tôi bắt đầu bằng cách tinh chỉnh điều chỉnh mô hình RoBERTa-Large từ AlignScore, deberta-v3-large[8], và flan-t5-large trên dữ liệu huấn luyện tương ứng của chúng (Mục 3.3) trong 2 epoch, đồng thời loại trừ 7K dữ liệu tổng hợp D2C. Chúng tôi sử dụng kích thước lô là 4 với bước tích lũy là 2 và tốc độ học là 1e-5 cho RoBERTa và 5e-5 cho hai mô hình còn lại. Sau đó, chúng tôi tinh chỉnh các mô hình này trên 7K dữ liệu tổng hợp D2C trong 1 epoch, với kích thước lô là 4 và tốc độ học là 1e-5.

Chúng tôi quan sát thấy rằng việc theo dõi quy trình huấn luyện này liên tục mang lại hiệu suất cao hơn trên cả ba mô hình backbone so với việc huấn luyện trên tất cả dữ liệu cùng một lúc. Chúng tôi giả thuyết rằng sự cải thiện này bắt nguồn từ thực tế là các tài liệu nguồn trong bộ dữ liệu D2C là các tài liệu do con người viết, trái ngược với các tài liệu nguồn được tạo ra tổng hợp trong bộ dữ liệu C2D. Việc tinh chỉnh trên các tài liệu thực tế này vào cuối quá trình giúp các mô hình thích nghi trở lại với phân phối thực tế, ngăn chúng khỏi việc quá khớp với các tài liệu tổng hợp và cho phép chúng hoạt động tốt trên các tài liệu thực trong chuẩn đánh giá.

Lời nhắc H

Trong Bảng 14, chúng tôi trình bày danh sách đầy đủ các lời nhắc được sử dụng trong toàn bộ công trình của chúng tôi. Chúng tôi sử dụng GPT-3.5 để phân tích câu và hợp nhất các sự kiện cơ bản, và GPT-4 cho các lời nhắc còn lại. Tiếp theo, chúng tôi sẽ giải thích cách chúng tôi đảm bảo chất lượng gán nhãn của dữ liệu được tạo ra tổng hợp.

H.1 Đảm bảo chất lượng cho các thế hệ

Phân tách câu Chúng tôi áp dụng một hướng dẫn phân tách câu theo phương pháp few-shot từ (Kamoi et al.,

Chức năng nhắc	**Ref.**
Phân tích câu	Bảng 17
Mở rộng sự kiện nguyên tử (C2D)	Bảng 18
Tạo tài liệu (C2D)	Bảng 19
Hỗ trợ tạo tài liệu (C2D-SIMP)	Bảng 25
Tạo tài liệu không hỗ trợ (C2D-SIMP)	Bảng 26
Hợp nhất các sự kiện nguyên tử (C2D, D2C)	Bảng 22
Tóm tắt ở cấp độ khối (D2C, D2C-Simp)	Bảng 21
Tạo tài liệu không hỗ trợ (D2C-SIMP)	Bảng 27
Kiểm tra hàm chứa cho việc xây dựng dữ liệu	Bảng 20
Đánh giá tính nhất quán thực tế không cần huấn luyện trước	Bảng 23
Phi ngữ cảnh câu	Bảng 24

Bảng 14: Tham chiếu đến các lời nhắc. Phần trên: lời nhắc cho các phương pháp tạo dữ liệu tổng hợp của chúng tôi, và các phương pháp tạo dữ liệu tổng hợp đơn giản hóa. Phần dưới: lời nhắc cho đánh giá trên LLM-AGGREFACT.

[7] huggingface.co/google/flan-t5-large

[8] huggingface.co/microsoft/deberta-v3-large

2023), which can generate complete and correct atomic facts most of the time according to their human evaluation. The prompt (Table 17) is used for both of our synthetic data generation methods and the claim decomposition experiment in Section 7.1.

C2D: Atomic fact expansion We use a 4-shot prompt (Table 18) for this step, where we ask GPT-4 to produce a sentence pair where the atomic fact is supported if and only if the information from both sentences is combined. To ensure the quality of the generation, we verify the correctness of this condition after generation via an entailment check by GPT-4 (Table 20). If the correctness is not met, we iterate the process and regenerate a new sentence pair up to a specified number of attempts. In cases where the correctness criterion remains unmet after the specified attempts, we remove the datapoint from the dataset.

C2D: Supporting document generation We ensure that all sentences $\mathbf{s}$ from the generated sentence pairs are mentioned in (and hence are entailed by) the generated document D by using the entailment check by GPT-4. Same as above, if the document fails to mention all sentences from the sentence pairs, we iteratively generate new documents until a specified number of attempts is reached. It is important to note that we only verify whether sentences $\mathbf{s}$ are mentioned in D, as we believe GPT-4 can perform well on this simple task. By construction, if all sentences are mentioned in D, then c is supported by D. However, directly performing an entailment check on the (D, c) pair with GPT-4 may introduce many labeling errors, which can negatively impact the performance of the trained models.

2023), vốn có thể tạo ra các sự thật nguyên tử đầy đủ và chính xác hầu hết thời gian theo đánh giá c ủa con người. Lời nhắc (Bảng 17) được sử dụng cho cả hai phương pháp tạo dữ liệu tổng hợp của chúng tôi và thí nghiệm phân tách tuyên bố trong Mục 7.1.

C2D: Mở rộng sự kiện nguyên tử Chúng tôi sử dụng một lời nhắc 4 mẫu (Bảng 18) cho bước này, trong đó chúng tôi yêu cầu GPT-4 tạo một cặp câu mà sự kiện nguyên tử chỉ được xác nhận nếu và chỉ nếu thông tin từ cả hai câu được kết hợp. Để đảm bảo chất lượng của việc tạo một cách, chúng tôi kiểm t ra tính đúng đắn của điều kiện này sau khi tạo thông qua kiểm tra suy diễn bởi GPT-4 (Bảng 20). Nếu điều kiện đúng đắn không được đáp ứng, chúng tôi lặp lại quy trình và tạo lại một cặp câu mới lên đến số lần thử nhất định. Trong những trường hợp tiêu chí đúng đắn vẫn không được đáp ứng sau số lần thử đã định, chúng tôi loại bỏ điểm dữ liệu khỏi bộ dữ liệu.

C2D: Hỗ trợ tạo tài liệu Chúng tôi đảm bảo rằng tất cả các câu s từ các cặp câu được tạo ra đều được đề cập trong (và do đó được suy ra từ) tài liệu được tạo ra D bằng cách sử dụng kiểm tra suy diễn bởi GPT-4. Giống như trên, nếu tài liệu không đề cập đến tất cả các câu từ các cặp câu, chúng tôi sẽ lặp đi lặp lại việc tạo tài liệu mới cho đến khi đạt số lần thử quy định. Cần lưu ý rằng chúng tôi chỉ xác minh liệu các câu s có được đề cập trong D hay không, vì chúng tôi tin rằng GPT-4 có thể thực hiện tốt nhiệm vụ đơn giản này. Theo cấu trúc, nếu tất cả các câu được đề cập trong D, thì c được hỗ trợ bởi D. Tuy nhiên, việc trực tiếp thực hiện kiểm tra suy diễn trên cặp (D, c) với GPT-4 có thể dẫn đến nhiều lỗi gán nhãn, điều này có thể ảnh hưởng tiêu cực đến hiệu suất của các mô hình đã được huấn luyện.

Document	Claim	Label
More than 5,000 individuals, part of a caravan that crossed into Mexico last month, are now seeking asylum and have established a temporary encampment at the Tijuana Stadium as of today. The Tijuana Stadium, known for hosting sporting events, recently underwent renovations that doubled its seating capacity. Prior to these changes, the stadium had a capacity to accommodate 1,500 spectators.	By this date, over 5,000 members of the caravan were staying at the Tijuana Stadium — a structure with a capacity of 3,000.	S
	By this date, over 5,000 members of the caravan were staying at the Tijuana Stadium.	S
	The Tijuana Stadium has a capacity of 3,000.	S
More than 5,000 individuals who are part of a caravan that crossed into Mexico last month have now established a temporary encampment at the Tijuana Stadium, where they are reportedly seeking asylum. The stadium, known for hosting sporting events, could originally accommodate 1,500 spectators before it became the site of the makeshift settlement. As of today, the facility is being repurposed to provide the asylum seekers with temporary shelter as they await the processing of their claims.	By this date, over 5,000 members of the caravan were staying at the Tijuana Stadium — a structure with a capacity of 3,000.	U
	By this date, over 5,000 members of the caravan were staying at the Tijuana Stadium.	S
	The Tijuana Stadium has a capacity of 3,000.	U
As of today, a group of individuals has established a temporary encampment within the premises of the Tijuana Stadium, according to officials. The stadium, which has recently undergone extensive renovations that included an expansion to double its original capacity, can now welcome a significantly larger audience. Prior to the upgrade, the Tijuana Stadium was known to have a seating capacity for 1,500 spectators; the recent improvements are expected to enhance its utility for various events and gatherings.	By this date, over 5,000 members of the caravan were staying at the Tijuana Stadium — a structure with a capacity of 3,000.	U
	By this date, over 5,000 members of the caravan were staying at the Tijuana Stadium.	U
	The Tijuana Stadium has a capacity of 3,000.	S
In a significant movement at the border, a caravan comprising over 5,000 asylum seekers penetrated Mexico's boundaries last month, bringing to the forefront the ongoing challenges faced by migrants from multiple origins. The group has today established a makeshift camp within the confines of the Tijuana Stadium, a venue known for its recent renovation that doubled its seating capacity. The temporal shift marks a new chapter for the individuals on their quest for safety and stability, with the stadium offering a transient sanctuary as they navigate their next steps.	By this date, over 5,000 members of the caravan were staying at the Tijuana Stadium — a structure with a capacity of 3,000.	U
	By this date, over 5,000 members of the caravan were staying at the Tijuana Stadium.	S
	The Tijuana Stadium has a capacity of 3,000.	U

Table 15: **Examples using the C2D method.** Documents are generated from the claim (from Wikipedia): *By this date, over 5,000 members of the caravan were staying at the Tijuana Stadium — a structure with a capacity of 3,000.* The same claim can be both supported (S) and unsupported (U) by documents, which encourage models to pay attention to multiple atomic facts in a sentence. Determining the factuality labels of claims requires models to reason over multiple sentences. Unsupporting facts are highlighted.

Tài liệu	Yêu cầu	Nhãn
Hơn 5.000 cá nhân, là một phần của đoàn lữ hành đã vượt biên vào Mexico tháng trước, hiện đang xin tị nạn và đã thành lập một khu trại tạm thời tại Sân vận động Tijuana tính đến hôm nay. Cái Sân vận động Tijuana, nổi tiếng với việc tổ chức các sự kiện thể thao, gần đây đã trải qua cải tạo làm tăng gấp đôi sức chứa chỗ ngồi của nó. Trước đó trước những thay đổi này, sân vận động có sức chứa để tiếp nhận 1.500 khán giả.	Tính đến ngày này, có hơn 5.000 thành viên của đoàn lữ hành đang ở tại Sân vận động Tijuana — một kết cấu với sức chứa 3.000.	S
	Tính đến ngày này, có hơn 5.000 thành viên của đoàn lữ hành đang ở tại Sân vận động Tijuana.	S
	Sân vận động Tijuana có sức chứa 3.000 người.	S
Hơn 5.000 cá nhân là một phần của đoàn caravan mà đã vượt qua vào Mexico tháng trước hiện đã thiết lập một tạm thời trại đóng quân tại Sân vận động Tijuana, nơi mà theo báo cáo xin tị nạn. Sân vận động, nổi tiếng với việc tổ chức các sự kiện thể thao, ban đầu có thể chứa 1.500 khán giả trước khi nó trở thành nơi của khu định cư tạm thời. Tính đến ngày hôm nay, cơ sở này là đang được tái sử dụng để cung cấp cho những người xin tị nạn tạm thời nơi trú ẩn trong khi họ chờ xử lý yêu cầu của mình.	Tính đến ngày này, có hơn 5.000 thành viên của đoàn lữ hành đang ở tại Sân vận động Tijuana — một kết cấu với sức chứa 3.000.	U
	Tính đến ngày này, có hơn 5.000 thành viên của đoàn lữ hành đang ở tại Sân vận động Tijuana.	S
	Sân vận động Tijuana có sức chứa 3.000 người.	U
Tính đến hôm nay, một nhóm cá nhân đã thành lập một tạm thời trại tạm trong khuôn viên Sân vận động Tijuana, according theo các quan chức. Sân vận động, gần đây đã trải qua các cải tạo rộng rãi bao gồm việc mở rộng để gấp đôi sức chứa ban đầu, giờ đây có thể chào đón một lượng khán giả lớn hơn đáng kể trước. Trước khi nâng cấp, Sân vận động Tijuana được biết đến là có sức chứa chỗ ngồi cho 1.500 khán giả; cải thiện gần đây các cải tiến được kỳ vọng sẽ nâng cao tính hữu ích của nó cho các sự kiện khác nhau và cuộc tụ họp.	Tính đến ngày này, có hơn 5.000 thành viên của đoàn lữ hành đang ở tại Sân vận động Tijuana — một kết cấu với sức chứa 3.000.	U
	Tính đến ngày này, có hơn 5.000 thành viên của đoàn lữ hành đang ở tại Sân vận động Tijuana.	U
	Sân vận động Tijuana có sức chứa 3.000 người.	S
Trong một động thái quan trọng tại biên giới, một đoàn người bao gồm hơn 5.000 người xin tị nạn đã xâm nhập vào biên giới của Mexico vào năm ngoái tháng, đưa ra ánh sáng những thách thức đang diễn ra mà những người di cư từ nhiều nguồn gốc. Nhóm này ngày nay đã thành lập một trại tạm bên trong khuôn viên của Sân vận động Tijuana, một địa điểm nổi tiếng với việc cải tạo gần đây đã tăng gấp đôi số chỗ ngồi năng lực. Sự thay đổi về thời gian đánh dấu một chương mới cho các nghệ sĩ độc lập cá nhân trên hành trình tìm kiếm an toàn và ổn định, với sân vận động cung cấp một nơi trú ẩn tạm thời khi họ tìm hướng đi tiếp theo.	Tính đến ngày này, có hơn 5.000 thành viên của đoàn lữ hành đang ở tại Sân vận động Tijuana — một kết cấu với sức chứa 3.000.	U
	Tính đến ngày này, có hơn 5.000 thành viên của đoàn lữ hành đang ở tại Sân vận động Tijuana.	S
	Sân vận động Tijuana có sức chứa 3.000 người.	U

Bảng 15: Ví dụ sử dụng phương pháp C2D. Các tài liệu được tạo từ tuyên bố (từ Wikipedia): Tính đến ngày này, hơn 5.000 thành viên của đoàn lữ hành đang lưu trú tại Sân vận động Tijuana — một công trình có sức chứa 3.000 người. Cùng một tuyên bố có thể vừa được hỗ trợ (S) vừa không được hỗ trợ (U) bởi các tài liệu, điều này khuyến khích các mô hình chú ý đến nhiều sự kiện nguyên tử trong một câu. Việc xác định nhãn tính xác thực của các tuyên bố đòi hỏi các mô hình phải suy luận qua nhiều câu. Những sự kiện không hỗ trợ được đánh dấu nổi bật.

Document	Claim	Label
(Doc Chunk 1) With the SAG-AFTRA strike settled, the six-month, multi-guild Hollywood labor disruption has finally ended, but the theatrical damage has only begun to surface. Reviewing the films delayed until next year, a rough estimate suggests that the stoppage cost theaters around $400 million- $600 million in gross – more, when including lost concession revenue. "Barbie," "Oppenheimer," "Sound of Freedom," and "Taylor Swift: The Eras Tours" kept the damage from being worse. Immediately following the SAG-AFTRA settlement, Disney announced wholesale delays in its upcoming release schedule. Their revived plans includes only one Marvel title for 2024 ("Deadpool 3," moved to July 26 from May 3), down from the customary three per year from MCU. Disney was among the first studios to announce delays, with Sony already out Wednesday evening with word the third "Venom" film would move from July to November. Related Stories The good news for theaters is despite it all, 2023 should still reach the $9 billion in domestic gross hoped for this year.	2024 box-office hopes dashed by production delays and major title postponements, costing potentially $500 million.	S
(Doc Chunk 2; corresponding chunk) However, any hopes that 2024 might return to 2019 box-office parity are dashed. Grosses from rescheduled titles will help, but production delays will leave substantial gaps. Even so: It could have been worse. "Dune: Part 2" (Warner Bros.) and "Kraven the Hunter" and "Ghostbusters: Frozen Empire" (Sony) will cost this year's total the most – perhaps $400 million ("Ghostbusters" would have had only 12 days of 2023 play). Figure other films, mostly limited/specialized entries like Luca Guadagnino's "Challengers" and Jeff Nichols "The Bikeriders" (Disney), Ethan Coen's "Drive Away Dolls" (Focus), and "The Book of Clarence" (Sony) could have contributed $100 million or more while riding the awards wave. The biggest unknown is how much the lack of promotion hurt the films released during the strikes. By the time the SAG-AFTRA strike began July 11, most of the summer's top titles had already been released or were about to be, which meant their promotional pushes were all but complete.	2024 box-office hopes dashed by production delays and major title postponements, costing potentially $500 million.	S
(Doc Chunk 2; corresponding chunk) ~~However, any hopes that 2024 might return to 2019 box-office parity are dashed.~~ Grosses from rescheduled titles will help, but production delays will leave substantial gaps. Even so: It could have been worse. "Dune: Part 2" (Warner Bros.) and "Kraven the Hunter" and "Ghostbusters: Frozen Empire" (Sony) will cost this year's total the most – perhaps $400 million ("Ghostbusters" would have had only 12 days of 2023 play). Figure other films, mostly limited/specialized entries like Luca Guadagnino's "Challengers" and Jeff Nichols "The Bikeriders" (Disney), Ethan Coen's "Drive Away Dolls" (Focus), and "The Book of Clarence" (Sony) could have contributed $100 million or more while riding the awards wave. The biggest unknown is how much the lack of promotion hurt the films released during the strikes. By the time the SAG-AFTRA strike began July 11, most of the summer's top titles had already been released or were about to be, which meant their promotional pushes were all but complete.	2024 box-office hopes dashed by production delays and major title postponements, costing potentially $500 million.	U
(Doc Chunk 2; corresponding chunk) However, any hopes that 2024 might return to 2019 box-office parity are dashed. Grosses from rescheduled titles will help, but production delays will leave substantial gaps. Even so: It could have been worse. "Dune: Part 2" (Warner Bros.) and "Kraven the Hunter" and "Ghostbusters: Frozen Empire" (Sony) will cost this year's total the most – perhaps $400 million ("Ghostbusters" would have had only 12 days of 2023 play). ~~Figure other films, mostly limited/specialized entries like Luca Guadagnino's "Challengers" and Jeff Nichols "The Bikeriders" (Disney), Ethan Coen's "Drive Away Dolls" (Focus), and "The Book of Clarence" (Sony) could have contributed $100 million or more while riding the awards wave.~~ The biggest unknown is how much the lack of promotion hurt the films released during the strikes. By the time the SAG-AFTRA strike began July 11, most of the summer's top titles had already been released or were about to be, which meant their promotional pushes were all but complete.	2024 box-office hopes dashed by production delays and major title postponements, costing potentially $500 million.	U
(Doc Chunk 3) Some, like DC Comics' "Blue Beetle" (WB) and "The Equalizer 3" (Sony), may have suffered more. Would promotion for all strike-period releases have total $100 million? Maybe. Theaters were fortunate that both "Barbie" and "Oppenheimer" already had enormous publicity before actors struck, and both had major, Oscar-nominated directors to carry the ball. Their $950 million combined domestic gross more than doubled expectations. Add the mid-summer sleeper success of "Sound of Freedom" and July and August both were strong months. A wild card, unknown when the strike began, was Taylor Swift's concert film. It certainly filled an October void that existed before the strike and its SAG-AFTRA waver meant she could promote it. The outside-studio success of "Sound of Freedom" and "The Eras Tour" were not only welcome for their grosses, but also because they show it's possible to find releases outside the studios.	2024 box-office hopes dashed by production delays and major title postponements, costing potentially $500 million.	U

Table 16: **Examples using the D2C method.** The full document is from this website. The same claim (summary sentence) can be supported by both its directly associated document chunk (chunk 2) and a separate chunk (chunk 1) originating from the same document, which has been divided into three distinct chunks. Some ~~sentences~~ are removed from the chunk to make the claim unsupported. Unsupporting facts are highlighted.

Tài liệu	Yêu cầu	Nhãn
(Đoạn tài liệu 1) Với cuộc đình công của SAG-AFTRA đã được giải quyết, cuộc đình công kéo dài sáu tháng của nhiều liên đoàn ở Hollywood- Cuộc đình công lao động tại Hollywood cuối cùng đã kết thúc, nhưng thiệt hại về mặt sân khấu mới chỉ bắt đầu bề mặt. Việc xem xét các bộ phim bị trì hoãn đến năm sau, một ước lượng sơ bộ cho thấy rằng chi phí dừng hoạt động làm các rạp khoảng 400 triệu - 600 triệu đô la tổng doanh thu – hơn nữa, khi tính cả mất doanh thu nhượng quyền. "Barbie," "Oppenheimer," "Sound of Freedom," và "Taylor" Swift: The Eras Tours đã ngăn thiệt hại trở nên tồi tệ hơn. Ngay sau đó Thỏa thuận SAG-AFTRA, Disney thông báo hoãn toàn bộ việc phát hành sắp tới của mình lịch trình. Kế hoạch tái khởi động của họ chỉ bao gồm một tựa phim Marvel cho năm 2024 ("Deadpool 3", được dời sang ngày 26 tháng 7 từ ngày 3 tháng 5), giảm so với ba lần mỗi năm theo thông lệ từ MCU. Disney là một trong những studio đầu tiên thông báo trì hoãn, với Sony đã ra mắt từ thứ Tư buổi tối với tờ bộ phim thứ ba "Venom" sẽ chuyển từ tháng Bảy sang tháng Mười Một. Liên quan Câu chuyện Tin tốt cho các rạp chiếu phim là mặc dù tất cả, năm 2023 vẫn nên đạt 9 tỷ đô la trong tổng sản phẩm trong nước kỳ vọng cho năm nay.	Hy vọng phòng vé năm 2024 bị sản xuất đánh dấu bằng dấu gạch ngang trình bày và bài đăng tiêu đề chính hoãn lại, chi phí tiềm năng tially 500 triệu đô la.	S
(Tài liệu Phân đoạn 2; phân đoạn tương ứng) Tuy nhiên, bất kỳ hy vọng nào rằng năm 2024 có thể quay trở lại Sự cân bằng doanh thu phòng vé năm 2019 bị phá vỡ. Doanh thu từ các tựa phim được dời lịch sẽ giúp ích, nhưng sản xuất sự chậm trễ sẽ để lại những khoảng trống đáng kể. Dù vậy: Có thể đã tệ hơn. "Dune: Phần 2" (Warner Bros.) và "Kraven the Hunter" và "Ghostbusters: Frozen Empire" (Sony) sẽ chi phí tổng của năm nay nhiều nhất – có lẽ 400 triệu đô la ("Ghostbusters" sẽ chỉ có 12 ngày của năm 2023 chơi). Xem các phim khác, phần lớn là các bản giới hạn/chuyên biệt như Luca Guadagnino's "Challengers" và Jeff Nichols "The Bikeriders" (Disney), Ethan Coen's "Drive Away Dolls" (Focus) và "The Book of Clarence" (Sony) có thể đã đóng góp 100 triệu đô la hoặc hơn trong khi tận dụng làn sóng giải thưởng. Điều chưa biết lớn nhất là bao nhiêu việc thiếu quảng bá đã làm tổn hại đến các bộ phim phát hành trong thời gian đình công. Đến khi SAG-AFTRA cuộc đình công bắt đầu vào ngày 11 tháng 7, hầu hết các tựa game hàng đầu của mùa hè đã được phát hành hoặc đã sắp xảy ra, điều đó có nghĩa là các đợt quảng bá của họ gần như đã hoàn tất.	Hy vọng phòng vé năm 2024 bị sản xuất đánh dấu bằng dấu gạch ngang trình bày và bài đăng tiêu đề chính hoãn lại, chi phí tiềm ẩn tially 500 triệu đô la.	S
(Đoạn Tài liệu 2; đoạn tương ứng) Tuy nhiên, ~~bất cứ hy vọng nào rằng năm 2024 có thể trở lại sự bình đẳng phòng vé đến năm 2019 bị phá vỡ.~~ Doanh thu từ các đầu phim được dời lịch sẽ giúp, nhưng những trì hoãn trong sản xuất sẽ để lại những khoảng trống đáng kể. Dù vậy: Nó có thể đã tệ hơn. "Dune:" Phần 2 (Warner Bros.) và Kraven the Hunter và Ghostbusters: Frozen Empire (Sony) sẽ chi phí tổng trong năm nay nhiều nhất – có thể là 400 triệu đô la ("Ghostbusters" sẽ chỉ có 12 ngày chiếu trong năm 2023). Hình dung các phim khác, chủ yếu là các suất chiếu hạn chế/đặc biệt như "Challengers" của Luca Guadagnino và "The Bikeriders" của Jeff Nichols (Disney), Ethan 'Drive Away Dolls' của Coen (Focus) và 'The Book of Clarence' (Sony) có thể đã đã đóng góp 100 triệu đô la hoặc hơn trong khi tận dụng cơn sốt giải thưởng. Điều chưa biết lớn nhất là mức độ thiếu quảng bá đã ảnh hưởng đến các bộ phim được phát hành trong thời gian đình công. Vào thời điểm cuộc đình công của SAG-AFTRA bắt đầu vào ngày 11 tháng 7, hầu hết các phim bom tấn mùa hè đã được đã được phát hành hoặc sắp được phát hành, điều này có nghĩa là các chiến dịch quảng bá của họ gần như đã hoàn tất.	Hy vọng phòng vé năm 2024 bị sản xuất đánh dấu bằng dấu gạch ngang trình bày và bài đăng tiêu đề chính hoãn lại, chi phí tiềm ẩn tially 500 triệu đô la.	U
(Tài liệu Phân đoạn 2; phân đoạn tương ứng) Tuy nhiên, bất kỳ hy vọng nào rằng năm 2024 có thể quay trở lại Sự cân bằng doanh thu phòng vé năm 2019 bị phá vỡ. Doanh thu từ các tựa phim được dời lịch sẽ giúp ích, nhưng sản xuất sự chậm trễ sẽ để lại những khoảng trống đáng kể. Dù vậy: Có thể đã tệ hơn. "Dune: Phần 2" (Warner Bros.) và "Kraven the Hunter" và "Ghostbusters: Frozen Empire" (Sony) sẽ chi phí tổng cộng của năm nay là cao nhất – có lẽ 400 triệu đô la ("Ghostbusters" chỉ có 12 ngày của năm 2023 chơi). ~~Xem các phim khác, phần lớn là các bản giới hạn/chuyên biệt như Luca Guadagnino's "Challengers" và Jeff Nichols "The Bikeriders" (Disney), Ethan Coen's "Drive Away Dolls" (Focus) và "The Book of Clarence" (Sony) có thể đã đã đóng góp 100 triệu đô la hoặc hơn trong khi tận dụng làn sóng giải thưởng~~. Điều chưa biết lớn nhất là bao nhiêu thiếu quảng bá đã ảnh hưởng đến các bộ phim được phát hành trong thời gian đình công. Khi SAG-Cuộc đình công của AFTRA bắt đầu vào ngày 11 tháng 7, hầu hết các tựa phim hàng đầu mùa hè đã được phát hành hoặc sắp sửa hoàn thành, điều này có nghĩa là các chiến dịch quảng bá của họ gần như đã xong.	Hy vọng phòng vé năm 2024 bị sản xuất đánh dấu bằng dấu gạch ngang trình bày và bài đăng tiêu đề chính hoãn lại, chi phí tiềm ẩn tially 500 triệu đô la.	U
(Tài liệu phần 3) Một số, như 'Blue Beetle' của DC Comics (WB) và 'The Equalizer 3' (Sony) có thể đã chịu tổn thất nhiều hơn. Liệu việc quảng bá cho tất cả các sản phẩm phát hành trong thời gian đình công có tổng cộng 100 triệu đô la? Có thể. Các rạp may mắn khi cả "Barbie" và "Oppenheimer" đã có sự quảng bá lớn trước khi các diễn viên đình công, và cả hai đều có vai trò quan trọng, được đề cử Oscar các đạo diễn cầm bóng. Tổng doanh thu nội địa kết hợp 950 triệu đô la của họ đã tăng hơn gấp đôi những kỳ vọng. Thêm vào thành công bất ngờ giữa mùa hè của "Sound of Freedom" và tháng Bảy và Tháng Tám cả hai đều là những tháng mạnh mẽ. Một yếu tố bất ngờ, không ai biết khi cuộc đình công bắt đầu, là Taylor Phim buổi hòa nhạc của Swift. Nó chắc chắn đã lấp đầy một khoảng trống vào tháng Mười vốn tồn tại trước cuộc đình công và nó Việc SAG-AFTRA miễn trừ có nghĩa là cô ấy có thể quảng bá nó. Thành công ngoài phòng thu của "Sound of "Freedom" và "The Eras Tour" không chỉ được chào đón vì doanh thu, mà còn bởi vì Họ cho thấy rằng có thể tìm thấy các bản phát hành bên ngoài các studio.	Hy vọng phòng vé năm 2024 bị sản xuất đánh dấu bằng dấu gạch ngang trình bày và bài đăng tiêu đề chính hoãn lại, chi phí tiềm ẩn tially 500 triệu đô la.	U

Bảng 16: Ví dụ sử dụng phương pháp D2C. Toàn bộ tài liệu có từ trang web này. Cùng một tuyên bố (câu tóm tắt) có thể được hỗ trợ bởi cả phần tài liệu trực tiếp liên quan của nó (khối 2) và một khối riêng biệt (khối 1) xuất phát từ cùng một tài liệu, đã được chia thành ba khối riêng biệt. Một số câu được loại bỏ khỏi khối để làm cho tuyên bố không được hỗ trợ. Các sự kiện không hỗ trợ được đánh dấu nổi bật.

Segment the following sentence into individual facts:

Sentence: Other title changes included Lord Steven Regal and The Nasty Boys winning the World Television Championship and the World Tag Team Championship respectively.
Facts:
- Lord Steven Regal won the World Television Championship.
- The Nasty Boys won the World Tag Team Championship.

Sentence: The parkway was opened in 2001 after just under a year of construction and almost two decades of community requests.
Facts:
- The parkway was opened in 2001.
- The parkway was opened after just under a year of construction.
- The parkway was opened after two decades of community requests.

Sentence: Touring began in Europe in April-June with guitarist Paul Gilbert as the opening act, followed by Australia and New Zealand in July, Mexico and South America in late July-August, and concluding in North America in October-November.
Facts:
- Touring began in Europe in April-June.
- The opening act of the tour was guitarist Paul Gilbert.
- The tour was in Australia and New Zealand in July.
- The tour was in Mexico and South America in late July-August.
- The tour was concluded in North America in October-November.

Sentence: In March 2018, the company partnered With Amazon Web Services (AWS) to offer Al-enabled conversational solutions to customers in India.
Facts:
- The company partnered with Amazon Web Services (AWS) in March 2018.
- The two companies partnered to offer Al-enabled conversational solutions to customers in India.

Sentence: The most significant of these is in Germany, which now has a Yazidi community of more than 200,000 living primarily in Hannover, Bielefeld, Celle, Bremen, Bad Oeynhausen, Pforzheim and Oldenburg.
Facts:
- The most significant of these is in Germany.
- Germany now has a Yazidi community of more than 200,000.
- Yazidi community in Germany lives primarily in Hannover, Bielefeld, Celle, Bremen, Bad Oeynhausen, Pforzheim and Oldenburg.

Sentence: A previous six-time winner of the Nations' Cup, Sebastian Vettel became Champion of Champions for the first time, defeating Tom Kristensen, who made the final for the fourth time, 2-0.
Facts:
- Sebastian Vettel is a previous six-time winner of the Nations' Cup.
- Sebastian Vettel became Champion of Champions for the first time, defeating Tom Kristensen, 2-0.
- Tom Kristensen made the final for the fourth time.

Sentence: [SENTENCE]
Facts:

Table 17: Sentence decomposition prompt adapted from (Kamoi et al., 2023).

Phân tách câu sau thành các sự thật riêng lẻ:

Câu: Các thay đổi danh hiệu khác bao gồm Lord Steven Regal và The Nasty Boys lần lượt giành chức vô địch World Television và chức vô địch World Tag Team. Sự kiện: - Lord Steven Regal giành chức vô địch World Television. - The Nasty Boys giành chức vô địch World Tag Team.

Câu: Đường công viên được mở vào năm 2001 sau chưa đầy một năm xây dựng và gần hai thập kỷ yêu cầu của cộng đồng.

Sự thật:
- Tuyến đường công viên đã được mở vào năm 2001. - Tuyến đường công viên đã được mở sau chưa đầy một năm xây dựng. - Tuyến đường công viên đã được mở sau hai thập kỷ yêu cầu từ cộng đồng.

Câu: Chuyến lưu diễn bắt đầu ở châu Âu vào tháng 4-6 với tay guitar Paul Gilbert là phần mở màn, tiếp theo là Australia và New Zealand vào tháng 7, Mexico và Nam Mỹ vào cuối tháng 7-8, và kết thúc ở Bắc Mỹ vào tháng 10-11. Sự kiện:

- Chuyến lưu diễn bắt đầu ở châu Âu vào tháng Tư-Tháng Sáu. - Màn trình diễn mở đầu của chuyến lưu diễn là tay guitar Paul Gilbert. - Chuyến lưu diễn diễn ra ở Úc và New Zealand vào tháng Bảy. - Chuyến lưu diễn diễn ra ở Mexico và Nam Mỹ vào cuối tháng Bảy- Tháng Tám. - Chuyến lưu diễn kết thúc ở Bắc Mỹ vào tháng Mười-Tháng Mười Một.

Câu: Vào tháng 3 năm 2018, công ty đã hợp tác với Amazon Web Services (AWS) để cung cấp các giải pháp trò chuyện được hỗ trợ bởi AI cho khách hàng tại Ấn Độ.

Sự thật:
- Công ty đã hợp tác với Amazon Web Services (AWS) vào tháng 3 năm 2018. - Hai công ty đã hợp tác để cung cấp các giải pháp trò chuyện được hỗ trợ bởi AI cho khách hàng tại Ấn Độ.

Câu: Quan trọng nhất trong số này là ở Đức, nơi hiện có một cộng đồng Yazidi hơn 200.000 người chủ yếu sinh sống tại Hannover, Bielefeld, Celle, Bremen, Bad Oeynhausen, Pforzheim và Oldenburg. Sự kiện:

- Quan trọng nhất trong số này là ở Đức. - Hiện nay, Đức có một cộng đồng Yazidi hơn 200.000 người. - Cộng đồng Yazidi ở Đức chủ yếu sinh sống tại Hannover, Bielefeld, Celle, Bremen, Bad Oeynhausen, Pforzheim và Oldenburg.

Câu: Một cựu vô địch sáu lần của Nations' Cup, Sebastian Vettel lần đầu tiên trở thành Nhà Vô Địch của các Nhà Vô Địch, đánh bại Tom Kristensen, người đã vào chung kết lần thứ tư, với tỉ số 2-0. Sự kiện:

- Sebastian Vettel là người chiến thắng trước đây của Cúp các Quốc gia sáu lần. - Sebastian Vettel lần đầu tiên trở thành Nhà vô địch của các nhà vô địch, đánh bại Tom Kristensen với tỷ số 2-0. - Tom Kristensen đã vào chung kết lần thứ tư.

Câu: [CÂU]Sự kiện:

Bảng 17: Phân tích câu, được điều chỉnh từ (Kamoi et al., 2023).

8843

Your task is to generate a pair of sentences so that the provided claim can be entailed by the sentence pair. You must make sure that the claim can only be deduced by combining the information from the two sentences that contain unique information.

Examples:
Provided Claim: The investigation is into allegations that his mayoral campaign received illegal foreign funds.
Sentence 1: During the period leading up to the mayoral election, there was a notable increase in his campaign's financial resources.
Sentence 2: Investigation shows the funds having origins beyond national boundaries, a detail raising questions under current campaign laws.

Provided Claim: Approximately 1,000 fans fainted at the concert.
Sentence 1: Emergency services reported an unusually high number of calls for medical assistance during the concert with an attendance of 20,000.
Sentence 2: Venue officials estimated that approximately 5% of the audience required medical attention for fainting.

Provided Claim: The interest rate hikes were intended to manage inflation and moderate economic growth.
Sentence 1: Central bank officials expressed concern over the rising consumer price index and the overheating of the economy.
Sentence 2: The monetary policy committee decided to adjust the interest rates as a response to these economic indicators.

Provided Claim: Several advertisers are considering halting their ads on social media platform X.
Sentence 1: Some companies are re-evaluating their marketing strategies to avoid association with platforms that fail to address misinformation.
Sentence 2: Recent reports show that platform X has received criticism for its handling of false information spreading unchecked.

Please make sure that NEITHER sentence alone supports the claim.

Your turn:
Provided Claim: [CLAIM]

Table 18: Prompt for *Step 2: Atomic fact expansion* for the C2D method (Section 3.1).

Nhiệm vụ của bạn là tạo ra một cặp câu sao cho khẳng định được cung cấp có thể được suy ra từ cặp câu đó. Bạn phải đảm bảo rằng khẳng định chỉ có thể được suy ra bằng cách kết hợp thông tin từ hai câu chứa thông tin duy nhất.

Ví dụ:
Yêu cầu được cung cấp: Cuộc điều tra liên quan đến các cáo buộc rằng chiến dịch tranh cử thị trưởng của ông ấy đã nhận được quỹ nước ngoài bất hợp pháp.
Câu 1: Trong giai đoạn trước cuộc bầu cử thị trưởng, đã có một sự tăng đáng kể về tài chính của chiến dịch của ông ấy tài nguyên .
Câu 2: Cuộc điều tra cho thấy các khoản quỹ có nguồn gốc vượt ra ngoài biên giới quốc gia, một chi tiết gây ra những câu hỏi theo các quy định hiện hành luật chiến dịch.

Yêu cầu đã cung cấp: A pproximatel y 1.000 người hâm mộ ngất xỉu tại buổi hòa nhạc.
Câu 1: Các dịch vụ khẩn cấp báo cáo đã có một số lượng cuộc gọi yêu cầu trợ giúp y tế bất thường cao trong suốt buổi hòa nhạc với 20.000 người tham dự.
Câu 2: Các quan chức địa điểm ước tính rằng khoảng 5% khán giả cần chăm sóc y tế vì bị ngất .

Yêu cầu đã được cung cấp: Việc tăng lãi suất nhằm mục đích kiểm soát lạm phát và điều tiết tăng trưởng kinh tế. Câu 1: Các quan chức ngân hàng trung ương bày tỏ mối quan ngại về chỉ số giá tiêu dùng tăng và sự quá nhiệt của nền kinh tế. Câu 2: Ủy ban chính sách tiền tệ quyết định điều chỉnh lãi suất nhằm đáp ứng với các chỉ số kinh tế này.

Yêu cầu đã nêu: Một số nhà quảng cáo đang cân nhắc việc ngưng quảng cáo trên nền tảng mạng xã hội X.
Câu 1: Một số công ty đang xem xét lại chiến lược tiếp thị của họ để tránh liên kết với các nền tảng không giải quyết được thông tin sai lệch.
Câu 2: Các báo cáo gần đây cho thấy nền tảng X đã nhận phải chỉ trích vì cách xử lý thông tin sai lệch lan truyền mà không được kiểm soát.

Hãy chắc chắn rằng KHÔNG câu nào riêng lẻ hỗ trợ cho tuyên bố đó.

Lượt của bạn: Yêu cầu đã cung cấp: [YÊU CẦU]

Bảng 18: Lời nhắc cho Bước 2: Mở rộng sự thật nguyên tử cho phương pháp C2D (Mục 3.1).

We are creating a news article (one paragraph) in the style of The New York Times. We will give you a list of facts to use when writing your article. You must include all the facts in the list. Never state deduced facts or conclusions. The article should stick to the fact list pretty closely. Include as many sentences as needed to write each fact from the list of facts.

Facts you must include:
-{FACT1}
-{FACT2}
...

Table 19: Prompt for *Step 3: Document generation* for the C2D method (Section 3.1).

Chúng tôi đang tạo một bài báo tin tức (một đoạn) theo phong cách của The New York Times. Chúng tôi sẽ cung cấp cho bạn một danh sách các sự kiện để sử dụng khi viết bài báo của mình. Bạn phải bao gồm tất cả các sự kiện trong danh sách. Không được nêu những sự kiện hay kết luận suy đoán. Bài báo nên bám sát danh sách các sự kiện. Bao gồm càng nhiều câu càng cần thiết để viết mỗi sự kiện từ danh sách.

Những sự thật bạn phải bao gồm:
-{FACT1}
-{FACT2}
...

Bảng 19: Lời nhắc cho Bước 3: Tạo tài liệu cho phương pháp C2D (Mục 3.1).

Source: [SOURCE]
Claim: [CLAIM]

Is the claim fully entailed, or implied, by the source? Please answer with "yes" or "no".

Table 20: Prompt for all steps in our methods that require entailment check.

Nguồn: [NGUỒN]
Khai báo: [KHAI BÁO]
Liệu khẳng định này có hoàn toàn được viện dẫn, hay được ngụ ý, từ nguồn không? Vui lòng trả lời bằng 'có' hoặc 'không'.

Bảng 20: Lời nhắc cho tất cả các bước trong phương pháp của chúng tôi yêu cầu kiểm tra suy luận.

Document:
[DOCUMENT]

Please generate a summary for the document with the following requirements:
1. The summary should be a fluent and grammatical sentence.
2. The summary should be no more than 15 words.
3. The summary should cover information across the document.
Summary:

Table 21: Summarization prompt for *Step 1: Chunk-level summarization* for the D2C method (Section 3.2) and D2C-SIMP method.

Tài liệu:
[TÀI LIỆU]

Vui lòng tạo một bản tóm tắt cho tài liệu với các yêu cầu sau:
1. Bản tóm tắt nên là một câu trôi chảy và ngữ pháp đúng.
2. Tóm tắt không nên vượt quá 15 từ.
3. Bản tóm tắt nên bao quát thông tin trên toàn bộ tài liệu.
Tóm tắt:

Bảng 21: Lời nhắc tóm tắt cho Bước 1: Tóm tắt theo phần nhỏ cho phương pháp D2C (Mục 3.2) và phương pháp D2C-SIMP.

Merge the following individual facts into a single sentence:

Facts:
- Lord Steven Regal wan the World Television Championship.
- The Nasty Boys wan and the World Tag Team Championship.
Sentence: Other title changes included Lord Steven Regal and The Nasty Boys winning the World Television Championship and the World Tag Team Championship respectively.

Facts:
- The parkway was opened in 2001.
- The parkway was opened after just under a year of construction.
- The parkway was opened after two decades of community requests.
Sentence: The parkway was opened in 2001 after just under a year of construction and almost two decades of community requests.

Facts:
- Touring began in Europe in April-June.
- The opening act was guitarist Paul Gilbert.
- There was a tour in Australia in July.
- There was a tour in New Zealand in July.
- There was a tour in Mexico in late July-August.
- There was a tour in South America in late July-August
- The tour was concluded in North America in October-November.
Sentence: Touring began in Europe in April-June with guitarist Paul Gilbert as the opening act, followed by Australia and New Zealand in July, Mexico and South America in late July-August, and concluding in North America in October-November.

Facts:
- The company partnered with Amazon Web Services (AWS) in March 2018.
- The two companies partnered to offer Al-enabled conversational solutions to customers in India.
Sentence: In March 2018, the company partnered With Amazon Web Services (AWS) to offer Al-enabled conversational solutions to customers in India.

Facts:
- The most significant of these is in Germany.
- Germany now has a Yazidi community of more than 200,000.
- Yazidi community in Germany lives primarily in Hannover.
- Yazidi community in Germany lives primarily in Bielefeld.
- Yazidi community in Germany lives primarily in Celle.
- Yazidi community in Germany lives primarily in Bremen.
- Yazidi community in Germany lives primarily in Bad Oeynhausen.
- Yazidi community in Germany lives primarily in Pforzheim.
- Yazidi community in Germany lives primarily in Oldenburg.
Sentence: The most significant of these is in Germany, which now has a Yazidi community of more than 200,000 living primarily in Hannover, Bielefeld, Celle, Bremen, Bad Oeynhausen, Pforzheim and Oldenburg.

Facts:
- Sebastian Vettel is a previous six-time winner of the Nations' Cup.
- Sebastian Vettel became Champion of Champions for the first time.
- Sebastian Vettel defeated Tom Kristensen.
- Tom Kristensen made the final for the fourth time.
- The score was 2-0.
Sentence: A previous six-time winner of the Nations' Cup, Sebastian Vettel became Champion of Champions for the first time, defeating Tom Kristensen, who made the final for the fourth time, 2-0.

Facts:
-{FACT1}
-{FACT2}
...
Sentence:

Table 22: Merging prompt for *Step 5: Pairing subclaims and generated documents* for the C2D method (Section 3.1) and *Step 2: Claim decomposition and subclaim augmentation* for the D2C method (Section 3.2).

Hợp nhất các sự thật riêng lẻ sau đây thành một câu duy nhất:

Sự thật:
Các thay đổi danh hiệu khác bao gồm Lord Steven Regal và The Nasty Boys giành được World Television Championship và World Tag Team Championship tương ứng.

Sự thật:
Con đường công viên đã được khai trương vào năm 2001 sau chưa đầy một năm xây dựng và gần hai thập kỷ yêu cầu từ cộng đồng.

Sự thật:
Việc lưu diễn bắt đầu ở châu Âu từ tháng Tư đến tháng Sáu với tay guitar Paul Gilbert là phần mở màn, tiếp theo là Úc và New Zealand vào tháng Bảy, Mexico và Nam Mỹ vào cuối tháng Bảy đến tháng Tám, và kết thúc ở Bắc Mỹ vào tháng Mười đến tháng Mười Một.

Sự thật:
Vào tháng 3 năm 2018, công ty đã hợp tác với Amazon Web Services (AWS) để cung cấp các giải pháp tương tác được hỗ trợ bởi AI cho khách hàng tại Ấn Độ.

Sự thật:
Điều quan trọng nhất trong số này là ở Đức, nơi hiện có cộng đồng Yazidi hơn 200.000 người, chủ yếu sinh sống tại Hannover, Bielefeld, Celle, Bremen, Bad Oeynhausen, Pforzheim và Oldenburg.

Sự thật:
- Sebastian Vettel là người từng sáu lần giành chiến thắng tại Cúp Các Quốc gia. - Sebastian Vettel trở thành Nhà vô địch của các nhà vô địch lần đầu tiên. - Sebastian Vettel đã đánh bại Tom Kristensen. - Tom Kristensen lọt vào chung kết lần thứ tư. - Tỷ số là 2-0.

câu: A preNhà vô địch sáu lần trước đó của Cúp Các Quốc gia, Sebastian Vettel đã lần đầu tiên trở thành Nhà vô địch của các nhà vô địch, đánh bại Tom Kristensen, người đã lọt vào trận chung kết lần thứ tư, 2-0.

Sự thật: -
{FACT1} -
{FACT2} ...
Câu:

Bảng 22: Hợp nhất lời nhắc cho Bước 5: Ghép nối các tuyên bố phụ và tài liệu được tạo ra cho phương pháp C2D (Mục 3.1) và Bước 2: Phân tích tuyên bố và bổ sung tuyên bố phụ cho phương pháp D2C (Mục 3.2).

8845

Determine whether the provided claim is consistent with the corresponding document. Consistency in this context implies that all information presented in the claim is substantiated by the document. If not, it should be considered inconsistent.
Document: [DOCUMENT]
Claim: [CLAIM]
Please assess the claim's consistency with the document by responding with either "yes" or "no".
Answer:

Table 23: Zero-shot factual consistency evaluation prompt for all LLMs.

Xác định xem tuyên bố được cung cấp có nhất quán với tài liệu tương ứng hay không. Sự nhất quán trong bối cảnh này ngụ ý rằng tất cả thông tin được trình bày trong tuyên bố đều được chứng thực bởi tài liệu. Nếu không, nó nên được coi là không nhất quán. Tài liệu: [TÀI LIỆU]Tuyên bố: [TUYÊN BỐ] Vui lòng đánh giá sự nhất quán của tuyên bố với tài liệu bằng cách trả lời 'có' hoặc 'không'.
Trả lời:

Bảng 23: Lời nhắc đánh giá độ nhất quán thực tế không cần huấn luyện trước cho tất cả các LLM.

You are provied with a context and a claim. Please first determine if the claim can stand alone whitout the conext. If not, provide a decontextualzied version of the claim that incorporates necessary information from the context to make it self-contained. The revision should be as minimum as possible. Please respond with a JSON format: {"label": "yes"/"no", "decontext": "NA"/decontextualized claim}.

Example 1:
Context: There are many reasons why poetry is important for children. Poetry can help children build confidence through memorizing and reciting poems. It can also provide an easy way for children to remember a lesson or value.
Claim: It can also provide an easy way for children to remember a lesson or value.
Answer: {"label": "no", "decontext": "Poetry can provide an easy way for children to remember a lesson or value."}

Example 2:
Context: Yes, ancient societies had concepts of rights. The concept of rights first appeared in the theory of natural law which existed in the state of nature. In this state, people enjoyed certain rights sanctioned by natural law.
Claim: In this state, people enjoyed certain rights sanctioned by natural law.
Answer: {"label": "no", "decontext": "In the state of nature, people enjoyed certain rights sanctioned by natural law"}

Example 3:
Context: The ancient Greeks had some concept of human rights, although there is no single word in classical Greek that captures the sense of "rights" as it is used in modern political thought. However, Greek customs and institutions provided protection to private property unique in the ancient world, instilling a strong sense of equality. The idea of human rights spread quickly from Babylon to Greece and eventually Rome, where the concept of "natural law" arose.
Claim: The idea of human rights spread quickly from Babylon to Greece and eventually Rome, where the concept of "natural law" arose.
Answer: {"label": "yes", "decontext": "NA"}

Your Turn:
Context: [CONTEXT]
Claim: [CLAIM]
Answer:

Table 24: Decontextualization prompt for GPT-4.

Bạn được cung cấp một ngữ cảnh và một tuyên bố. Vui lòng xác định trước xem tuyên bố có thể đứng một mình mà không cần ngữ cảnh hay không. Nếu không, hãy cung cấp một phiên bản tuyên bố đã được tách khỏi ngữ cảnh, bao gồm các thông tin cần thiết từ ngữ cảnh để làm cho nó đầy đủ. Việc chỉnh sửa nên tối thiểu nhất có thể. Vui lòng trả lời theo định dạng JSON: {"label": "yes"/"no", "decontext": "NA"/tuyên bố đã tách khỏi ngữ cảnh}.

Ví dụ 1:
Bối cảnh: Có nhiều lý do tại sao thơ ca quan trọng đối với trẻ em. Thơ ca có thể giúp trẻ xây dựng sự tự tin thông qua việc ghi nhớ và đọc thuộc lòng thơ. Nó cũng có thể cung cấp một cách dễ dàng để trẻ ghi nhớ một bài học hoặc giá trị. Luận điểm: Nó cũng có thể cung cấp một cách dễ dàng để trẻ ghi nhớ một bài học hoặc giá trị. Trả lời: {"nhãn": "không", "tách bối cảnh": "Thơ ca có thể cung c ấp một cách dễ dàng để trẻ ghi nhớ một bài học hoặc giá trị."}

Ví dụ 2:
Bối cảnh: Vâng, các xã hội cổ đại đã có khái niệm về quyền. Khái niệm về quyền xuất hiện lần đầu trong lý thuyết về luật tự nhiên tồn tại trong trạng thái tự nhiên. Trong trạng thái này, con người được hưởng một số quyền được luật tự nhiên cho phép. Khẳng định: Trong trạng thái này, con người được hưởng một số quyền được luật tự nhiên cho phép. Trả lời: {"nhãn": "không", "tách bối cảnh": "Trong trạng thái tự nhiên, con người được hưởng một số quyền được luật tự nhiên cho phép"}

Ví dụ 3:
Bối cảnh: Người Hy Lạp cổ đại có một số khái niệm về quyền con người, mặc dù không có một từ đơn nào trong tiếng Hy Lạp cổ điển có thể diễn tả đúng nghĩa của "quyền" như cách nó được sử dụng trong tư tưởng chính trị hiện đại. Tuy nhiên, phong tục và thể chế của Hy Lạp đã bảo vệ quyền sở hữu tư nhân, điều mà trong thế giới cổ đại là độc nhất, đồng thời tạo nên một cảm giác bình đẳng mạnh mẽ. Ý tưởng về quyền con người lan truyền nhanh chóng từ Babylon đến Hy Lạp và cuối cùng đến La Mã, nơi mà khái niệm "luật tự nhiên" xuất hiện.

Khẳng định: Ý tưởng về nhân quyền lan truyền nhanh chóng từ Babylon đến Hy Lạp và cuối cùng là Rome, nơi khái niệm 'luật tự nhiên' xuất hiện.
Trả lời: {"nhãn": "có", "bối cảnh": "NA"}

Lượt của bạn: Ngữ
cảnh: [NGỮ CẢNH]
Yêu cầu: [YÊU CẦU]
Trả lời:

Bảng 24: Lời nhắc tách bối cảnh cho GPT-4.

We are creating a news article (one paragraph) in the style of The New York Times. We will give you a claim that must be covered when writing your article. All information in the claim must be supported by weaving together various pieces of evidence within the text. That is, the claim should not be directly supported by using one sentence from the article. The generated article should be around 140 words.

Claim: [CLAIM]
Article:

Table 25: Supporting document generation prompt for the simplified data generation method C2D-SIMP.

Chúng tôi đang tạo một bài báo tin tức (một đoạn) theo phong cách của The New York Times. Chúng tôi sẽ cung cấp cho bạn một tuyên bố mà bạn phải đề cập khi viết bài báo của mình. Tất cả thông tin trong tuyên bố phải được chứng minh bằng cách kết hợp nhiều bằng chứng khác nhau trong văn bản. Tức là, tuyên bố không nên chỉ được hỗ trợ trực tiếp bằng một câu duy nhất trong bài báo. Bài báo được tạo ra nên dài khoảng 140 từ.

Yêu cầu: [YÊU
CẦU]Bài viết:

Table 25: Hướng dẫn tạo tài liệu hỗ trợ cho phương pháp tạo dữ liệu đơn giản C2D-SIMP .

You are presented with a claim and an article that fully support the claim. You task is to minimally modify the article with the following requirements:

1. The modified article no longer fully supports the claim. Some (but not all) statements in the claim should be supported by the modified article.
2. The edited article looks close to the original claim.
3. The edited claim article should have the similar length with the original article.

The followings are the type of revisions you can use to revise the article:
- Entity revision: An entity (like a person, place, organization, etc.) from a claim is being edited or not mentioned in the revised article.
- Number revision: A number from a claim is being edited or not mentioned in the revised article.
- Attribute revision: A syntax unit (either a word, phrase or clause) that modifies a noun is being edited or not mentioned in the revised article.
- Predicate revision: A main content verb or content like adverbs that closely relate to the verb is being edited or not mentioned in the revised article.

Claim: [CLAIM]
Article: [ARTICLE]

Please respond in a JSON format: {"revision_type": ..., "revised_article": ...}.

Table 26: Nonsupporting document generation prompt for the simplified data generation method C2D-SIMP.

Document:
[DOCUMENT]

Consistent Summary:
[CONSISTENT_SUMMARY]

Given the document and consistent summary above, generate 10 slightly modified versions of the summary such that the modifications introduce a factual inconsistency. For example, you can modify a number, date, or entity, and negate or modify a statement. Here are some rules to follow:
- Each modification should change at most 3-4 words from the original summary, and keep the rest the same.
- Each modification should change a different part of the original summary.
- Your modifications should be challenging to detect: modify minimally while still introducing a factual inconsistency.
- The factual inconsistency you introduce should be subtle. For example, if you replace an entity, make sure you replace it with another entity from the document.
- Each modification should start with "[FIRST_THREE_WORDS] [...]", and end with "[LAST_THREE_WORDS]"

Please respond in a JSON format with the following structure:
{"inconsistent_summaries": ["First inconsistent summary", "Second inconsistent summary", ...]}

Table 27: Nonsupporting document generation prompt for the simplified data generation method D2C-SIMP. The prompt is adapted from SummEdit (Laban et al., 2023).

Determine whether each of the provided claims are consistent with the corresponding document. Consistency in this context implies that all information presented in a claim is substantiated by the document. If not, it should be considered inconsistent.
Document: [DOCUMENT]
Claims: [CLAIM]

Claims are displayed with sentence indices. Please evaluate each claim's consistency with the document by responding with either "yes" or "no" in the JSON format: {"[1]": ..., "[2]": ..., ...}.
Answer:

Table 28: Prompt for predicting the factuality labels of all claims in a response for a provided document. This is used mainly for text summarization where multiple summary sentences share the same document.

Bạn có mặt với một tuyên bố và một bài viết hoàn toàn hỗ trợ cho tuyên bố đó. Nhiệm vụ của bạn là chỉnh sửa tối thiểu bài viết với yêu cầu sau yêu cầu:

1. Bài báo đã chỉnh sửa không còn hoàn toàn hỗ trợ cho tuyên bố. Một số (nhưng không phải tất cả) lập luận trong tuyên bố nên được hỗ trợ bởi bài viết đã chỉnh sửa.
2. Bài viết đã chỉnh sửa trông gần giống với tuyên bố gốc.
3. Bài viết yêu cầu sửa đổi nên có độ dài tương tự với bài viết gốc.

Các loại sửa đổi sau đây là các loại bạn có thể sử dụng để chỉnh sửa bài viết: - Sửa đổi thực thể: Một thực thể (như người, địa điểm, tổ chức, v.v.) từ một tuyên bố được chỉnh sửa hoặc không được đề cập trong bài viết đã được chỉnh sửa. - Sửa đổi số: Một con số từ một tuyên bố được chỉnh sửa hoặc không được đề cập trong bài viết đã được chỉnh sửa. - Sửa đổi thuộc tính: Một đơn vị cú pháp (có thể là từ, cụm từ hoặc mệnh đề) sửa đổi một danh từ đang được chỉnh sửa hoặc không được đề cập trong bài viết đã được chỉnh sửa. - Sửa đổi vị ngữ: Một động từ chính hoặc nội dung như trạng từ có liên quan mật thiết đến động từ đang được chỉnh sửa hoặc không được đề cập trong bài viết đã được chỉnh sửa.

Yêu cầu: [YÊU CẦU]
Bài viết: [BÀI VIẾT]

Vui lòng trả lời dưới định dạng JSON: {"revision_type": ..., "revised_article": ...}.

Bảng 26: Lời nhắc tạo tài liệu không hỗ trợ cho phương pháp tạo dữ liệu đơn giản C2D-SIMP.

Tài liệu:[TÀI LIỆU]

Tóm tắt nhất quán:[NHẤT QUÁN_TÓM TẮT]

Dựa trên tài liệu và bản tóm tắt nhất quán ở trên, hãy tạo 10 phiên bản thay đổi nhẹ của bản tóm tắt sao cho các thay đổi này gây ra mâu thuẫn thực tế. Ví dụ, bạn có thể thay đổi một con số, ngày tháng, hoặc thực thể, và phủ định hoặc sửa đổi một tuyên bố. Dưới đây là một số quy tắc cần tuân theo:
- Mỗi sửa đổi chỉ nên thay đổi tối đa 3-4 từ từ tóm tắt gốc, và giữ nguyên phần còn lại. - Mỗi sửa đổi nên thay đổi một phần khác của tóm tắt gốc. - Các sửa đổi của bạn nên khó phát hiện: chỉnh sửa tối thiểu nhưng vẫn tạo một sự không nhất quán về mặt thực tế. - Sự không nhất quán về mặt thực tế mà bạn tạo nên nên tinh vi. Ví dụ, nếu bạn thay thế một thực thể, hãy chắc chắn thay thế bằng một thực thể khác từ tài liệu. - Mỗi sửa đổi nên bắt đầu với "[FIRST_THREE_WORDS] [...]", và kết thúc với "[LAST_THREE_WORDS]"

Vui lòng phản hồi ở định dạng JSON với cấu trúc sau: {"inconsistent_summaries": ["Bản tóm tắt không nhất quán đầu tiên", "Bản tóm tắt không nhất quán thứ hai", ...]}

Bảng 27: N về lời nhắc tạo tài liệu hỗ trợ cho phương pháp tạo dữ liệu đơn giản D2C-SIMP. Th e prompt là một được điều chỉnh từ SummEdit (Laban và cộng sự, 2023).

Xác định xem mỗi tuyên bố được cung cấp có nhất quán với tài liệu tương ứng hay không. Sự nhất quán trong ngữ cảnh này ngụ ý rằng tất cả thông tin được trình bày trong một tuyên bố đều được tài liệu chứng minh. Nếu không, nó nên được coi là không nhất quán. Tài liệu: [DOCUMENT]Tuyên bố: [CLAIM]

Các tuyên bố được hiển thị kèm chỉ số câu. Vui lòng đánh giá tính nhất quán của từng tuyên bố với tài liệu bằng cách trả lời "có" hoặc "không" theo định dạng JSON: {"[1]": ..., "[2]": ..., ...}. Trả lời:

Bảng 28: Lời nhắc để dự đoán nhãn tính xác thực của tất cả các tuyên bố trong một phản hồi cho một tài liệu được cung cấp. Điều này chủ yếu được sử dụng cho tóm tắt văn bản, nơi nhiều câu tóm tắt chia sẻ cùng một tài liệu.

8847