# SemEval-2021 Task 8: MeasEval – Extracting Counts and Measurements and their Related Contexts

**Corey A Harper**[1,2], **Jessica Cox**[1], **Curt Kohler**[1], **Antony Scerri**[1], **Ron Daniel, Jr.**[1] and **Paul Groth**[2]

[1]Elsevier Labs, Suite 800, 230 Park Avenue, New York, NY 10169, USA
[1]{*c.harper, j.cox, c.kohler, a.scerri, r.daniel*}*@elsevier.com*
[2]University of Amsterdam, Postbus 94323 / 1090 GH, Amsterdam
[2]{*c.a.harper, p.t.groth*}*@uva.nl*

## Abstract

We describe MeasEval, a SemEval task of extracting counts, measurements, and related context from scientific documents, which is of significant importance to the creation of Knowledge Graphs that distill information from the scientific literature. This is a new task in 2021, for which over 75 submissions from 25 participants were received. We expect the data developed for this task and the findings reported to be valuable to the scientific knowledge extraction, metrology, and automated knowledge base construction communities.

## 1 Introduction

Counts and measurements are an important part of scientific discourse (Rijgersberg et al., 2011). It is relatively easy to find measurements in text (Foppiano et al., 2019a), but a bare measurement like 17mg is not informative without knowing what it is referring to. For example, it is important to know whether a quantity is 17mg of a medicine dosage or 17mg of concrete additive. Only recently have attempts been made to identify the named entity and property being measured (Hundman and Maamann, 2017). Extracting such information is challenging because the way scientists write can be ambiguous and inconsistent. Furthermore, the location of this information relative to the measurement can vary greatly, and might even be in a different sentence.

Being able to extract measurement information automatically can enable the construction of databases of measured properties. Such databases are important in biomedicine (Hao et al., 2016), engineering (Foppiano et al., 2019a), and other scientific disciplines (Bergmann et al., 2017), but the approaches used for populating these databases do not generalize widely. Furthermore, knowledge graphs (Hogan et al., 2021) frequently aggregate quantitative data reported in the literature and are often built through a largely manual curation process. Examples include: LITTERBASE[1] (Bergmann et al., 2017), which aggregates observations of marine litter distribution; NeuroElectro[2] (Tripathy et al., 2014), which collects information on electrophysiological properties of neurons; and various model organism databases like the Zebrafish Information Network[3] (Sprague, 2006), which provide summaries of gene information.

Beyond knowledge graphs and curated databases, clinical health contexts often require extraction of measured values for lab results and patient observations. Moreover, scientific research frequently relies on precise measurements for reproducibility of experimental methods (Kaiser, 2018). Measured property extraction could be of value in many other contexts, such as fact checking and news validation or in statistical analysis for public policy (Einav and Levin, 2014).

Research in information extraction and knowledge graph creation has concentrated on forming triples by extracting entities and relations (Konstantinova, 2014). Little attention has been paid to the extraction of measured properties, entities, and conditions or contexts, yet these elements are needed to place measurements into a database and for their subsequent use in comparison and calculation. Units and measures are an important part of the semantic web, though research has largely been focused on ontology design (Rijgersberg et al., 2013). There is, thus, a need for understanding the state of the art on this important task.

The aim of this paper is to introduce the MeasEval shared task for the extraction of counts, measurements, and related context from English-language scientific documents, as well as to present an analysis of the results of participant systems on

[1]https://litterbase.awi.de/
[2]https://neuroelectro.org/
[3]http://zfin.org/



*Proceedings of the 15th International Workshop on Semantic Evaluation (SemEval-2021)*, pages 306–316
Bangkok, Thailand (online), August 5–6, 2021. ©2021 Association for Computational Linguistics

# SemEval-2021 Nhiệm vụ 8: MeasEval – Trích xuất Số lượng và Đo lường cùng với Ngữ cảnh Liên quan của Chúng

**Corey A Harper**[1,2], **Jessica Cox**[1], **Curt Kohler**[1],**Antony Scerri**[1], **Ron Daniel, Jr.**[1] **và Paul Groth**[2]

[1]Phòng thí nghiệm Elsevier, Suite 800, 230 Đại lộ Park, New York, NY 10169, Hoa Kỳ[1]{c.harper, j.cox, c.kohler, a.scerri, r.daniel}@elsevier.com[2]Đại học Amsterdam, Hộp thư 94323 / 1090 GH, Amsterdam[2]{c.a.harper, p.t.groth}@uva.nl

## Tóm tắt

Chúng tôi mô tả MeasEval, một nhiệm vụ SemEval về việc trích xuất các số lượng, phép đo và bối cảnh liên quan từ các tài liệu khoa học, điều này có tầm quan trọng đáng kể đối với việc tạo ra các Đồ thị Kiến thức nhằm chắt lọc thông tin từ văn học khoa học. Đây là một nhiệm vụ mới vào năm 2021, với hơn 75 bài nộp từ 25 người tham gia đã được nhận. Chúng tôi kỳ vọng dữ liệu phát triển cho nhiệm vụ này và các phát hiện được báo cáo sẽ có giá trị đối với việc trích xuất kiến thức khoa học, đo lường, và cộng đồng xây dựng cơ sở tri thức tự động.

## 1 Giới thiệu

Số lượng và các phép đo là một phần quan trọng của diễn ngôn khoa học (Rijgersberg và cộng sự, 2011). Việc tìm các phép đo trong văn bản tương đối dễ dàng (Fop-piano và cộng sự, 2019a), nhưng một phép đo trần như 17mg sẽ không cung cấp thông tin nếu không biết nó đang đề cập đến gì. Ví dụ, việc biết liệu một lượng là 17mg liều thuốc hay 17mg phụ gia bê tông là rất quan trọng. Chỉ gần đây, những nỗ lực mới được thực hiện để xác định thực thể được đặt tên và đặc tính đang được đo (Hundman và Maamann, 2017). Việc trích xuất thông tin như vậy là thách thức vì cách viết của các nhà khoa học có thể mơ hồ và không nhất quán. Hơn nữa, vị trí của thông tin này so với phép đo có thể khác nhau rất nhiều, và thậm chí có thể nằm ở câu khác.

Khả năng tự động trích xuất thông tin đo lường có thể cho phép xây dựng các cơ sở dữ li ệu về các đặc tính đã được đo. Các cơ sở dữ liệu như vậy rất quan trọng trong y sinh (Hao et al., 2016), kỹ thuật (Foppiano et al., 2019a) và các ngành khoa học khác (Bergmann et al., 2017), nhưng các phương pháp được sử dụng để điền đầy các cơ sở dữ liệu này không phổ quát. Hơn nữa, các biểu đồ tri thức (Hogan et al., 2021) thường tổng hợp dữ liệu định lượng được báo cáo trong các tài liệu và thường được xây dựng thông qua một quy trình biên t ập chủ yếu thủ công. Ví dụ bao gồm: LITTERBASE[1] (Bergmann et al., 2017), tổng hợp các quan sát về phân bố rác thải biển; NeuroElectro[2] (Tripathy et al., 2014), thu thập thông tin về các đặc tính điện sinh lý của nơ-ron; và các cơ sở dữ liệu sinh vật mô hình khác như Zebrafish Information Network[3] (Sprague, 2006), cung cấp các tóm tắt thông tin gen.

Ngoài các đồ thị tri thức và cơ sở dữ liệu được tuyển chọn, các bối cảnh y tế lâm sàng thường yêu cầu việc trích xuất các giá trị đo được từ kết quả xét nghiệm và quan sát của bệnh nhân. Hơn nữa, nghiên cứu khoa học thường dựa vào các phép đo chính xác để tái lập các phương pháp thí nghiệm (Kaiser, 2018). Việc trích xuất các đặc tính đo lường có thể có giá trị trong nhiều bối cảnh khác, chẳng hạn như kiểm tra sự thật và xác thực tin tức hoặc trong phân tích thống kê cho chính sách công (Einav và Levin, 2014).

Nghiên cứu về trích xuất thông tin và tạo đồ thị tri thức đã tập trung vào việc hình thành các bộ ba bằng cách trích xuất các thực thể và quan hệ (Konstantinova, 2014). Ít chú ý đã được dành cho việc trích xuất các thuộc tính đo lường, thực thể và các điều kiện hoặc ngữ cảnh, tuy nhiên những yếu tố này là cần thiết để đặt các phép đo vào cơ sở dữ liệu và cho việc sử dụng tiếp theo trong so sánh và tính toán. Đơn vị và phép đo là một phần quan trọng của web ngữ nghĩa, mặc dù nghiên cứu chủ yếu tập trung vào thiết kế ontology (Rijgersberg et al., 2013). Do đó, có một nhu cầu phải hiểu trạng thái hiện đại của nhiệm vụ quan trọng này.

Mục đích của bài báo này là giới thiệu nhiệm vụ chia sẻ Mea-sEval để trích xuất số liệu, các phép đo và bối cảnh liên quan từ các tài liệu khoa học bằng tiếng Anh, cũng như trình bày một phân tích về kết quả của các hệ thống tham gia trên

[1]https://litterbase.awi.de/[2]
https://neuroelectro.org/[3]
http://zfin.org/



Tài liệu hội thảo lần thứ 15 về Đánh giá Ngữ nghĩa Quốc tế (SemEval-2021), trang 306–316, Bangkok,
Thái Lan (trực tuyến), ngày 5–6 tháng 8, 2021. ©2021 Hiệp hội Ngôn ngữ Học Máy

the task.

The rest of this paper is organized as follows. We begin with a description of related work. This is followed by the description of the task itself (Section 3) and the associated data and annotation procedure (Section 4). The evaluation regime is detailed in Section 5 including baselines. Subsequently, we present an analysis of the results of the systems on the task. Finally, we summarize the various participating systems approaches and conclude.

## 2 Related Work

There is a substantial body of work discussing units of measurement, ontologies to describe them, systems designed to extract them, as well as related work on knowledge graphs of numerical attributes. Automated extraction of measured quantities, such as 520 +/- 8 items/kg, is straightforward and many tools exist to perform this task (Foppiano et al., 2019b; Deus et al., 2017; Hao et al., 2016). To build a knowledge graph, we must put these measurements in context. We need to determine the properties being measured (e.g. abundances), the entities that exhibit those properties (e.g. the Maowei Sea), and possible qualifying conditions under which measurements are obtained (e.g. the date and depth of the sampling). These properties, entities, and conditions can then be mapped to those that are used in the knowledge graph, so that the measurements can be normalized into a common system.

There are a number of ontologies that cover units of measurement, such as Quantities, Units, Dimensions, and Types Ontologies (QUDT)[4] and the Ontology of Units of Measure and Related Concepts (OM) (Rijgersberg et al., 2013). These and others are discussed in a survey paper by (Steinberg et al., 2017). Most of these ontologies focus on conversion between different systems of measurement, and on classifying types of measurement or domain of application, but do not necessarily address the "thing" being measured. The Joint Committee for Guides in Metrology's (JCGM) International Vocabulary of Metrology covers this in slightly more depth, discussing measurement units and quantity values, then talking about quantities themselves, which it defines as a "property of a phenomenon, body, or substance" (Joint Committee for Guides in Metrology, 2012). We find that this nomenclature, while precise, is likely to be confusing to non-metrologists from both an evaluation and annotation perspective, so to support the data annotation process for this task we use a simplified nomenclature.

Metrology research in the Semantic Web community is often focused on ontology alignment for Units of Measurement ontologies. Kaladevi et al. (2016) look at aligning unit ontologies to support merging data across many weather information systems, while Do and Pauwels (2013) more generally look at using MathML for aligning unit ontologies. Efforts around designing linked data models for semantic sensor streams for the Internet of Things also utilize the Units of Measurement ontology for representing measurement information (Barnaghi et al., 2013). None of this work addresses extraction of measurements and their contexts nor building knowledge graphs from such information.

Other research explores creating databases of numeric attributes. Kotnis and Garcıa-Duran (2019) infer new values using linear regression for neighboring entities in a knowledge graph. Gupta et al. (2015) use a logistic regression with distributional vectors. Davidov and Rappoport (2010) use a system of averages and boundary values to infer an estimated numeric attribute value. Rather than imputing new values from related entities, MeasEval starts from a value and puts it into the context of measured entities and measured properties, working toward a knowledge representation of numeric data.

## 3 Task Description

MeasEval is an entity recognition and semantic relation extraction task focused on finding counts and measurements, attributes of those quantities, and additional information including measured entities, properties, and measurement contexts.

MeasEval is composed of five sub-tasks that cover span extraction, classification, and relation extraction, including cross-sentence relations. Given a paragraph from a scientific text:

- For each paragraph of text, identify all spans containing quantities (e.g. 12 kg). Quantities are treated as strings, and are not converted or normalized.
- For each identified Quantity, identify the Unit of Measurement (e.g. kg), if one exists. For each Quantity classify additional value Modifiers (e.g. count, range, approximate, mean,

[4] http://www.qudt.org/



nhiệm vụ.

Phần còn lại của bài báo này được tổ chức như sau. Chúng tôi bắt đầu với phần mô tả các công trình liên quan. Tiếp theo là phần mô tả nhiệm vụ chính (Phần 3) và dữ liệu cùng quy trình gắn nhãn liên quan (Phần 4). Chế độ đánh giá được trình bày chi tiết trong Phần 5 bao gồ m các phương pháp cơ sở. Sau đó, chúng tôi trình bày phân tích kết quả của các hệ thống trên nhiệm vụ. Cuối cùng, chúng tôi tóm tắt các phương pháp của các hệ thống tham gia và kết luận.

**2 Công trình liên quan**

Có một lượng lớn công trình bàn về các đơn vị đo lường, các ontology để mô tả chúng, các hệ thống được thiết kế để trích xuất chúng, cũng như các công trình liên quan về đồ thị tri thức của các thuộc tính số. Việc trích xuất tự động các đại lượng đo lường, chẳng hạn như 520 +/- 8 items/kg, là khá đơn giản và có nhiều công cụ tồn tại để thực hiện nhiệm vụ này (Foppiano et al., 2019b; Deus et al., 2017; Hao et al., 2016). Để xây dựng một đồ thị tri thức, chúng ta phải đặt các đo lường này vào ngữ cảnh. Chúng ta cần xác định các thuộc tính đang được đo (ví dụ: lượng tồn tại), các thực thể thể hiện những t huộc tính đó (ví dụ: Biển Maowei), và các điều kiện có thể xảy ra khi các đo lường được thực hiện (ví dụ: ngày và độ sâu của việc lấy mẫu). Những thuộc tính, thực thể và điều kiện này sau đó có thể được ánh xạ tới những gì đang được s ử dụng trong đồ thị tri thức, để các đo lường có thể được chuẩn hóa thành một hệ thống chung.

Có một số ontology bao gồm các đơn vị đo lường, chẳng hạn như Quantities, Units, Dimensions, and Types Ontologies (QUDT)[4] và Ontology of Units of Measure and Related Concepts (OM) (Rijgersberg et al., 2013). Những ontology này và những ontology khác được thảo luận trong một bài khảo sát bởi (Steinberg et al., 2017). Hầu hết các ontology này tập trung vào việc chuyển đổi giữa các hệ thống đo lường khác nhau và phân loại các loại đo lường hoặc lĩnh vực ứng dụng, nhưng không nhất thiết đề cập đến "đối tượng" được đo. Từ vựng Quốc tế về Đo lường của Ủy ban Chung về Hướng dẫn trong Đo lường (JCGM) đề cập đến vấn đề này chi tiết hơn một chút, thảo luận về các đơn vị đo và giá trị lượng, sau đó nói về chính các đại lượng, mà họ định nghĩa là "một tính chất của hiện tượng, vật thể hoặc chất" (Ủy ban Chung về Hướng dẫn trong Đo lường, 2012). Chúng tôi nhận thấy rằng thuật ngữ này, mặc dù chính xác, có khả năng là hợp nhất với những người không chuyên về đo lường từ cả góc độ đánh giá và chú thích, vì vậy để hỗ trợ quá trình chú thích dữ liệu cho nhiệm vụ này, chúng tôi sử dụng một hệ thống danh pháp đơn giản.

Nghiên cứu đo lường trong cộng đồng Web Ngữ nghĩa thường tập trung vào việc căn chỉnh ontology cho các ontology Đơn vị Đo lường. Kaladevi và cộng sự (2016) xem xét việc căn chỉnh các ontology đơn vị để hỗ trợ hợp nhất dữ liệu từ nhiều hệ thống thông tin thời tiết, trong khi Do và Pauwels (2013) một cách tổng quát hơn xem xét việc sử dụng MathML để căn chỉnh các ontology đơn vị. Các nỗ lực xung quanh việc thiết kế các mô hình dữ liệu liên kết cho luồng cảm biến ngữ nghĩa trong Internet of Things cũng sử dụng ontology Đơn vị Đo lường để đại diện thông tin đo lường (Barnaghi và cộng sự, 2013). Không có công trình nào trong số này đề cập đến việc trích xuất các phép đo và bối cảnh của chúng cũng như xây dựng các đồ thị tri thức từ những thông tin đó.

Các nghiên cứu khác khám phá việc tạo cơ sở dữ liệu các thuộc tính số. Kotnis và Garcıa-Duran (2019) suy ra các giá trị mới bằng cách sử dụng hồi quy tuyến tính cho các thực t hể lân cận trong đồ thị tri thức. Gupta và cộng sự (2015) sử dụng hồi quy logistic với các vectơ phân phối. Davidov và Rappoport (2010) sử dụng một hệ thống các giá trị trung bình và giá trị biên để suy ra giá trị thuộc tính số ước tính. Thay vì bổ sung các giá trị mới từ các thực thể liên quan, MeasEval bắt đầu từ một giá trị và đặt nó vào bối cảnh của các thực thể và thuộc tính được đo, hướng tới biểu diễn tri thức của dữ liệu số.

## 3 Mô tả nhiệm vụ

MeasEval là một nhiệm vụ nhận dạng thực thể và trích xuất quan hệ ngữ nghĩa tập trung vào việc tìm kiếm các số lượng và phép đo, các thuộc tính của những lượng đó, và thông tin bổ sung bao gồm các thực thể được đo, các đặc tính và bối cảnh đo lường.

MeasEval bao gồm năm nhiệm vụ phụ bao gồm trích xuất phạm vi, phân loại và trích xuất quan hệ, bao gồm cả các quan hệ giữa các câu. Cho một đoạn văn từ văn bản khoa học:

- Đối với mỗi đoạn văn bản, xác định tất cả các phần chứa các lượng số (ví dụ: 12 kg). Các lượng số được coi là chuỗi, và không được chuyển đổi hoặc chuẩn hóa.
- Đối với mỗi Giá trị được xác định, xác định Đơn vị Đo lường (ví dụ: kg), nếu có. Đối với mỗi Giá trị, phân loại các Bộ sửa đổi giá trị bổ sung (ví dụ: số lượng, phạm vi, xấp xỉ, trung bình,

[4] http://www.qudt.org/

etc.) that apply to the Quantity.

- For each identified Quantity, identify the Measured Entity (e.g. bed inventory) it applies to (if one exists) and mark its span. If an associated Measured Property (e.g. concentration) also exists, identify it and mark its span.
- Identify and mark the span of any Qualifier (e.g. after incubation) that is needed to record additional related context to either validate or understand each identified Quantity.
- Identify relationships between Quantity, Measured Entity, Measured Property, and Qualifier spans using the HasQuantity, HasProperty, and Qualifies relation types.

More detailed definitions can be found be reviewing the MeasEval Annotation Guidelines.[5] We describe each of the elements to be extracted in more detail in the next section.

## 4 Annotated Data

### 4.1 Data Model

As shown in Figure 1, the MeasEval annotation model consists of Quantities, MeasuredEntities, MeasuredProperties, and Qualifiers. A Quantity can be either a count or a measurement, with measurements being composed of a Unit and a Value. Values also can have additional attributes such as "isMean", "isApproximate", or "isRange". Quantities can be directly related to a MeasuredEntity, or can be indirectly related to a MeasuredEntity via a MeasuredProperty. Qualifiers provide additional information that is required to interpret the measurement. These include things like the pressure at which a boiling point was observed, or the depth and location where an ocean sample was taken. Since texts may contain different parts of this information, all relationships are optional. A MeasuredEntity can be related to a MeasuredProperty or a Quantity, a MeasuredProperty can be related a Quantity, and a Qualifier can have a relationship to any span.

### 4.2 Corpus and Annotations

Annotations are drawn from 110 CC-BY licensed articles that have been made previously available by Elsevier Labs. [6] These articles were the basis of a previous SemEval task for SemEval 2017 (Augenstein et al., 2017). These 110 articles are distributed evenly across 10 subject areas.

From these 110 articles, the MeasEval dataset includes 428 paragraphs containing 1663 Quantities. These are split into a training data set of 1164 Quantities (313 paragraphs) and an evaluation set of 499 Quantities (135 paragraphs).

All paragraphs were annotated by at least two annotators, then reviewed and reconciled during an adjudication meeting, often including a third annotator. The MeasEval data release included training data, as well as original annotations from multiple annotators for a 248 Quantity subset of the training data. This was to provide deep information on inter-annotator agreement, and also to allow participants to do their own analysis on how their algorithms perform relative to humans.

The inter-annotator agreement (IAA) shows some variation in interpretation when humans are performing this task. The review process serves to resolve much of the disagreement and to ensure that the data is as consistent as possible given the challenging nature of the task. For this subset of data in this IAA set, Table 1 shows Krippendorff's Alpha values for each class.

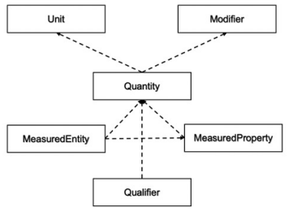



Figure 1: Annotation Model. All relationships are optional.

| Annotation Class | Krippendorff's Alpha |
|---|---|
| Quantity | 0.943 |
| MeasuredProperty | 0.641 |
| MeasuredEntity | 0.546 |
| Qualifier | 0.334 |
| Unit | 0.866 |

Table 1: Krippendorf's Alpha scores for subset of data included in Inter-Annotator Agreement dataset.

### 4.3 Data Formats

To increase the usability of the data, multiple formats are provided. The MeasEval data includes a

[5] https://github.com/harperco/MeasEval/tree/main/annotationGuidelines

[6] https://github.com/elsevierlabs/OA-STM-Corpus



v.v.) áp dụng cho Số lượng.

• Đối với mỗi số lượng đã xác định, xác định Thực thể được Đo lường (ví dụ: số giường trong kho) mà nó áp dụng (nếu có) và đánh dấu phạ m vi của nó. Nếu một Thuộc tính Đo lường liên quan (ví dụ: nồng độ) cũng tồn tại, hãy xác định nó và đánh dấu phạm vi của nó.

• Xác định và đánh dấu phạm vi của bất kỳ Phần bổ nghĩa nào (ví dụ: sau khi ủ) cần thiết để ghi lại bối cảnh liên quan bổ sung nhằm xác thực hoặc hiểu từng Số lượng đã xác định.

• Xác định mối quan hệ giữa Số lượng, Thực thể được đo, Thuộc tính được đo và Khoảng nhận xét bằng cách sử dụng các loại quan hệ HasQuantity, HasProperty và Qualifies.

Các định nghĩa chi tiết hơn có thể được tìm t hấy bằng cách xem lại Hướng dẫn Ghi chú Đánh giá Đo lường. [5] Chúng tôi mô tả chi tiết hơn từng yếu tố sẽ được trích xuất trong phần tiếp theo.

## 4 Dữ liệu có chú thích

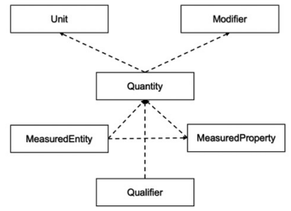
### 4.1 Mô hình dữ liệu

Như được hiển thị trong Hình 1, mô hình chú thích MeasEval gồm có Các Đại lượng, Thực thể được đo, Thuộc tính được đo và Các Phần bổ nghĩa. Một Đại lượng có thể là số lượng hoặc một phép đo, trong đó các phép đo được cấu thành từ một Đơn vị và một Giá trị. Giá trị cũng có thể có các thuộc tính bổ sung như "isMean" (là trung bình), "isApproximate" (là xấp xỉ) hoặc "isRange" (là phạm vi). Các Đại lượng có thể liên quan trực tiếp đến một Thực thể được đo, hoặc có thể liên quan gián tiếp đến một Thực t hể được đo thông qua một Thuộc tính được đo. Các Phần bổ nghĩa cung cấp thông tin bổ sung cần thiết để diễn giải phép đo. Điều này bao gồm các yếu tố như áp suất tại đó điểm sôi được quan sát, hoặc độ sâu và vị trí nơi mẫu đại dương được lấy. Vì văn bản có thể chứa các phần khác nhau của thông tin này, tất cả các mối quan hệ đều là tùy chọn. Một Thực thể được đo có thể liên quan đến một Thuộc tính được đo hoặc một Đại lượng, một Thuộc tính được đo có thể liên quan đến một Đại lượng, và một Phần bổ nghĩa có thể có mối quan hệ với bất kỳ đoạn nào.

### 4.2 Tập hợp dữ liệu và chú thích

Các chú thích được rút ra từ 110 bài báo được cấp phép CC-BY mà trước đây đã được Elsevier Labs cung cấp. [6] Các bài báo này là cơ sở-

[5] https://github.com/harperco/MeasEval/tree/main/annotationGuidelines[6] https://github.com/elsevierlabs/ OA-STM-Corpus




Hình 1: Mô hình chú thích. Tất cả các mối quan hệ đều tùy chọn.

sis của một nhiệm vụ SemEval trước đó cho SemEval 2017 (Augenstein et al., 2017). 110 bài báo này được phân bố đều trên 10 lĩnh vực chủ đề.

Từ 110 bài báo này, bộ dữ liệu MeasEval bao gồm 428 đoạn văn chứa 1663 số lượng. Chúng được chia thành một bộ dữ liệu huấn luyện gồm 1164 số lượng (313 đoạn văn) và một bộ dữ liệu đánh giá gồm 499 số lượng (135 đoạn văn).

Tất cả các đoạn văn đều được chú thích bởi ít nhất hai người chú thích, sau đó được xem xét và hòa giải trong một cuộc họp phân xử, thường bao gồm một người chú thích thứ ba. Bản phát hành d ữ liệu MeasEval bao gồm dữ liệu đào tạo, cũng như các chú thích gốc từ nhiều người chú thích cho một tập con 248Lượng của dữ liệu đào tạo. Điều này nhằm cung cấp thông tin chi tiết về sự đồng thuận giữa các người chú thích, cũng như cho phép người tham gia tự phân tích cách các thuật toán của họ hoạt động so với con người.

Sự đồng thuận giữa các chú thích viên (IAA) cho thấy một số biến thể trong cách diễn giải khi con người thực hiện nhiệm vụ này. Quá trình xem xét nhằm giải quyết phần lớn sự bất đồng và đảm bảo rằng dữ liệu nhất quán nhất có thể, xét đến bản chất khó khăn của nhiệm v ụ. Đối với tập con dữ liệu trong tập IAA này, Bảng 1 cho thấy các giá trị Alpha của Krippendorff cho từng lớp.

| Lớp Chú Thích | Alpha của Krippendorff |
|---|---|
| Số lượng | 0.943 |
| Thuộc tính đo lường | 0.641 |
| Thực thể được đo | 0.546 |
| Vòng loại | 0.334 |
| Unit | 0.866 |

Bảng 1: Điểm Alpha của Krippendorf cho tập hợp con dữ liệu được bao gồm trong bộ dữ liệu Thỏa thuận Giữa Các Người Ghi chú.

### 4.3 Định Dạng Dữ Liệu

Để tăng tính sử dụng của dữ liệu, nhiều định dạng được cung cấp. Dữ liệu MeasEval bao gồm một

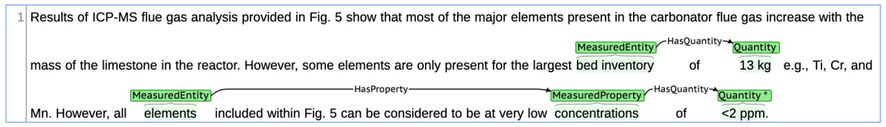



Figure 2: BRAT Example of a Quantity with related annotations.

text file and a set of annotations for each paragraph of scientific text. Annotations are provided in a tab-separated value (.tsv) file format, and in the BRAT annotation format. The BRAT format is for the purpose of visualization and review, but the official data format for the task is the .tsv, which is used for submissions and evaluation. For .tsv and .txt files, there is one file per paragraph of annotated text, and the .tsv file contains all annotations. For the BRAT files, there are one .ann and one .txt file per annotated Quantity.

For example, given the BRAT annotations illustrated in Figure 2, the data will have a raw text file (S0016236113008041-3153.txt), a BRAT annotation file *per Quantity* (S0016236113008041-3153-1.ann, and S0016236113008041-3153-2.ann), and a tab-separated file containing all annotations from each Quantity (S0016236113008041-3153.tsv).

More detail on each of these formats, including examples, as well as all MeasEval training and evaluation data, inter-annotator agreement annotations, and annotation guidelines can be found on the MeasEval Github repository. [7]

## 5 Evaluation

Evaluation is scored by providing a single SQuAD-style (Rajpurkar et al., 2016) F1 (Overlap) score for each submission, averaged across all nine components of the five subtasks. The 9 components are the Quantity, MeasuredProperty, MeasuredEntity, and Qualifier spans; the Modifier and Unit extensions to Quantity, and the HasQuantity, HasProperty, and Qualifies relationships. The evaluation script also provides a number of other metrics, described below.

In order to effectively evaluate all 9 components of the sub-tasks, it is necessary to first pin all Quantities in a submission to the corresponding Quantities in the gold data. As an example, consider the sentence "The dog weighed 25 pounds, while the average weight of the cats was 9 lbs." We want to avoid crediting correct MeasuredEntities if associated with the wrong Quantity. For example, if a submission listed "dog" as the MeasuredEntity associated with the average weight of 9 lbs, this would be incorrect.

The first pass matches each submission "annotSet" ID to a corresponding Gold Set annotationId, and propagates this matched identifier across all of the data.

From there, the script calculates Precision, Recall, F-measure, and an Exact Match and SQuAD-style F1 (overlap) score. Exact Match and F1 are averaged across the entire submission. Exact Match is a binary value of 0 or 1, while F1 is a token level overlap ratio of submission to gold spans, where tokenization is done using simple white space delimiters. For components that do not include a span, Exact Match and F1 scores are the same. Relations are also scored with a binary Exact Match and F1 score if the relation types match and both endpoints match either exactly or with some overlap.

Any span, unit, modifier, or relationship found in the gold data, but not the submission, or found in the submission, but not the gold data is included as a "penalty row" with a score of 0 in order to sufficiently penalize both false positives and false negatives when averaging scores. This calculation leads to very fine-grained differences in the distribution of scores in the results tables.

Although not used for calculating leaderboard rankings, the evaluation code can also provide all the same scores micro-averaged by scoring component, by subject area, or by paragraph for further analysis of error. Additional documentation as well as the evaluation code itself can be found on the MeasEval GitHub repository. [8]

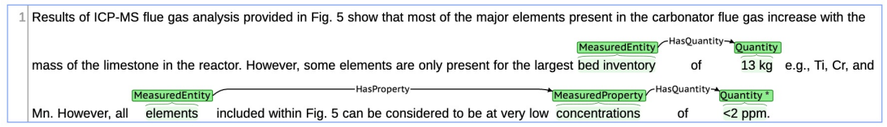
### 5.1 Baseline Models

MeasEval also includes two very similar baseline models. Baseline 1 is the best-performing of these, and scores an overall F1 (Overlap) of 0.239 in the evaluation as reported in Tables 2 and 3. Base-

[7] https://github.com/harperco/MeasEval

[8] https://github.com/harperco/MeasEval/tree/main/eval






Hình 2: Ví dụ BRAT về một Lượng với các chú thích liên quan.

tệp văn bản và một tập hợp các chú thích cho mỗi đoạn văn bản khoa học. Các chú thích được cung cấp dưới định dạng tệp giá trị tách bằng tab (.tsv), và dưới định dạng chú thích BRAT. Định dạng BRAT nhằm mục đích trực quan hóa và xem xét, nhưng định dạng dữ liệu chính thức cho nhiệm vụ là .tsv, được sử dụng cho việc nộp và đánh giá. Đối với các tệp .tsv và .txt, có một tệp cho mỗi đoạn văn bản được chú thích, và tệ p .tsv chứa tất cả các chú thích. Đối với các tệp BRAT, có một tệp .ann và một tệp .txt cho mỗi Quantity được chú thích.

Ví dụ, với các chú thích BRAT được minh họa trong Hình 2, dữ liệu sẽ có một tệp văn bản thô (S0016236113008041-3153.txt), một tệp chú thích BRAT cho mỗi Quantity (S0016236113008041-3153-1.ann, và S0016236113008041-3153-2.ann), và một tệp phân tách bằng tab chứa tất cả các chú thích từ mỗi Quantity (S0016236113008041-3153.tsv).

Chi tiết hơn về từng định dạng này, bao gồm cả ví dụ, cũng như tất cả dữ liệu đào tạo và đánh giá MeasEval, các chú thích thỏa thuận giữa người chú thích, và hướng dẫn chú thích có thể được tìm thấy trên kho lưu trữ Github của MeasEval. [7]

## 5 Đánh giá

Đánh giá được tính điểm bằng cách cung cấp một điểm F1 (Overlap) kiểu SQuAD (Rajpurkar et al., 2016) duy nhất cho mỗi bài nộp, trung bình trên tất cả chín thành phần của năm phân nhiệm vụ. Chín thành phần bao gồm các khoảng Quantity, MeasuredProperty, MeasuredEntity và Qualifier; các phần mở rộng Modifier và Unit cho Quantity, và các mối quan hệ HasQuantity, HasProperty, và Qualifies. Script đánh giá cũng cung cấp một số chỉ số khác, được mô tả dưới đây.

Để đánh giá hiệu quả tất cả 9 thành phần của các nhiệm vụ phụ, trước tiên cần ghim tất c ả các Lượng trong một bài nộp với các Lượng tương ứng trong dữ liệu chuẩn. Ví dụ, hãy xem xét câu "Con chó nặng 25 pound, trong khi trọ ng lượng trung bình của những con mèo là 9 l bs." Chúng ta muốn tránh ghi công các Thực thể Được Đo lường đúng nếu như liên quan-liên quan đến Số lượng sai. Ví dụ, nếu một bài nộp liệt kê "chó" là Thực thể được đo liên quan đến trọng lượng trung bình 9 lbs, điều này sẽ không đúng.

Lần xử lý đầu tiên khớp mỗi ID "annot-Set" của từng bản nộp với một annotationId của Bộ Vàng tương ứng, và lan truyền định danh đã khớp này trên toàn bộ dữ liệu.

Từ đó, kịch bản tính toán Độ chính xác (Precision), Độ hồi tưởng (Recall), F-measure, và một Điểm khớp chính xác (Exact Match) cũng như điểm F1 kiểu SQuAD (overlap). Điểm Exact Match và F1 được trung bình trên toàn bộ bài nộp. Exact Match là một giá trị nhị phân 0 hoặc 1, trong khi F1 là tỷ lệ chồng lấp cấp token giữa bài nộp và các đoạn chuẩn, trong đó việc phân tách token được thực hiện bằng cách sử dụng dấu cách đơn giản. Đối với các thành phần không bao gồm một đoạn, điểm Exact Match và F1 là giống nhau. Các quan hệ cũng được đánh giá với điểm Exact Match nhị phân và điểm F1 nếu loại quan hệ khớp và cả hai điểm đầu khớp chính xác hoặc có một số chồng lấp.

Bất kỳ phạm vi, đơn vị, bộ điều chỉnh hoặc mối quan hệ nào được tìm thấy trong dữ liệu vàng nhưng không có trong bản nộp, hoặc được tìm thấy trong bản nộp nhưng không có trong dữ liệu vàng, được bao gồm như một "hàng phạt" với điểm số là 0 nhằm đủ để trừng phạt cả các kết quả dương tính sai và âm tính sai khi trung bình điểm số. Việc tính toán này dẫn đến những khác biệt rất tinh vi trong phân bố điểm số trong các bảng kết quả.

Mặc dù không được sử dụng để tính bảng xếp hạng, mã đánh giá cũng có thể cung cấp tất cả các điểm số giống nhau được tính trung bình vi mô theo thành phần chấm điểm, theo lĩnh vực chủ đề, hoặc theo đoạn văn để phân tích thêm lỗi. Tài liệu bổ sung cũng như mã đánh giá có thể được tìm thấy trên kho GitHub MeasEval. [8]

### 5.1 Mô hình cơ sở

MeasEval cũng bao gồm hai mô hình cơ sở rất giống nhau. Mô hình cơ sở 1 là mô hình hoạt động tốt nhất trong số này, và đạt điểm F1 tổng thể (Overlap) là 0,239 trong đánh giá như được báo cáo trong Bảng 2 và 3. Cơ sở-

[7] https://github.com/harperco/MeasEval

[8] https://github.com/harperco/MeasEval/tree/main/eval

| Team Name | Overall | Quantity | Unit | Modifier | MeasuredEntity | MeasuredProperty | Qualifier |
|---|---|---|---|---|---|---|---|
| LIORI* | **0.519** | **0.861** | 0.722 | **0.642** | **0.437** | **0.467** | **0.163** |
| jarvis@tencent* | 0.473 | 0.855 | 0.719 | 0.523 | *0.398* | 0.437 | 0.000 |
| zyy_77 | *0.448* | 0.842 | 0.697 | 0.507 | 0.383 | *0.385* | 0.000 |
| zz362 | 0.433 | 0.821 | 0.720 | 0.498 | 0.344 | 0.365 | 0.000 |
| Counts@IITK* | 0.432 | **0.861** | 0.406 | 0.245 | *0.077* | **0.804** | 0.614 |
| yorkey | 0.399 | 0.745 | 0.661 | 0.314 | 0.344 | 0.365 | 0.000 |
| XMSHI | 0.392 | 0.736 | 0.624 | 0.313 | 0.348 | 0.353 | 0.000 |
| CLaC-BP* | 0.389 | 0.855 | 0.677 | *0.546* | 0.251 | 0.318 | 0.107 |
| clockwise9* | 0.369 | *0.850* | 0.618 | 0.000 | 0.327 | 0.350 | 0.000 |
| UPB* | 0.369 | 0.742 | 0.533 | 0.277 | 0.331 | 0.374 | 0.040 |
| *Baseline* | 0.239 | 0.827 | 0.561 | 0.000 | 0.053 | 0.064 | 0.005 |
| KGP* | 0.278 | 0.787 | *0.748* | 0.309 | 0.113 | 0.012 | 0.005 |
| Stanford MLab* | 0.272 | 0.818 | 0.760 | 0.408 | 0.000 | 0.000 | 0.000 |
| BuckschJ | 0.263 | 0.825 | 0.695 | 0.375 | 0.000 | 0.000 | 0.000 |
| CLaC-np* | 0.241 | 0.756 | 0.495 | 0.408 | 0.056 | 0.006 | 0.000 |
| FabianW | 0.238 | 0.826 | 0.624 | 0.438 | 0.060 | 0.045 | 0.006 |
| ugeijtsv | 0.229 | 0.759 | 0.582 | 0.210 | 0.000 | 0.000 | 0.000 |
| Jo | 0.212 | 0.754 | 0.377 | 0.291 | 0.000 | 0.000 | 0.000 |
| joe_o123 | 0.185 | 0.376 | 0.383 | 0.242 | 0.000 | 0.000 | 0.000 |
| SU-NLP | 0.001 | 0.007 | 0.002 | 0.000 | 0.000 | 0.000 | 0.000 |

Table 2: Top result for each team/user, ordered by Overall F1 along with micro-averages for each annotation span, for units, and for modifiers. Team Names marked with * have submitted system information for further analysis and discussion. Top, second, and third place scores per category represented by **bold**, underline, and *italics* respectively.

line 1 use spaCy Named Entity Recognition (NER) models for each of the four classes independently. Unfortunately, some training examples need to be thrown away because spaCy's NER functionality does not support overlapping spans in the same model. Since there is frequently an overlap between MeasEval spans of different types, this necessitates training each annotation type separately, and stripping out edge cases where multiple annotations of the same type intersect.

Baseline 1 generates a deduplicated list of all units in the training data, and checks each Quantity against this list. If there are one or more matches in this comparison, the system returns the "longest last matching" unit, ensuring that cm would be preferred to m in "22 cm" and that s would be preferred to m in "approximately 22 s". The baseline does not attempt the Modifier component, though could be augmented with a set of regular expressions that search the Quantity string for key phrases and symbols, including "approximately", "between", ">", and "~".

Once the NER models and unit matching are completed, baseline 1 matches Quantities to MeasuredEntities, MeasuredProperties, and Qualifiers using a knockout match algorithm based on proximity. So each MeasuredProperty matches the nearest Quantity, each MeasuredEntity matches the nearest MeasuredProperty or Quantity, and each Qualifier matches the nearest span of any type. Baseline 2 is a variant that does much simpler matching, taking each span in the order they appear in the data. Baseline 2 does not appear in the results tables, but scores an overall F1 (Overlap) of 0.223. The code for both baselines is available in a Jupyter notebook on the MeasEval Github repository. [9]

## 6 Results and Discussion

During the 21-day evaluation period (January 10 through 31, 2021), 26 CodaLab users submitted a total of 89 submissions, of which 77 passed validation and were successfully scored by the evaluation script. Given the complexity of the task, we opted to allow for five submissions total during the evaluation, although some collaboration between users meant that some teams were able to effectively submit more than five times. We note that submissions did not calculate scores on sub-tasks, thus making it difficult to overly optimize models using just the overall score. The relatively generous submission allowance does not seem to have presented too much of an over-fitting problem, as scores remain relatively low on all tasks, although the collaboration could have given some participants a slight advantage in the rankings.

Table 2 shows the top submission from each of

[9] https://github.com/harperco/MeasEval/blob/main/baselines/first-baseline.ipynb



| Tên đội | Tổng thể | Số lượng | Unit | Bộ sửa đổi | Thực thể được đo | Thuộc tính đo lường | Vòng loại |
|---|---|---|---|---|---|---|---|
| LIORI* | **0.519** | **0.861** | 0.722 | **0.642** | **0.437** | **0.467** | **0.163** |
| jarvis@tencent* | 0.473 | 0.855 | 0.719 | 0.523 | *0.398* | 0.437 | 0.000 |
| zyy 77 | *0.448* | 0.842 | 0.697 | 0.507 | 0.383 | *0.385* | 0.000 |
| zz362 | 0.433 | 0.821 | 0.720 | 0.498 | 0.344 | 0.365 | 0.000 |
| Counts@IITK* | 0.432 | **0.861** | 0.406 | 0.245 | *0.077* | **0.804** | 0.614 |
| yorkey | 0.399 | 0.745 | 0.661 | 0.314 | 0.344 | 0.365 | 0.000 |
| XMSHI | 0.392 | 0.736 | 0.624 | 0.313 | 0.348 | 0.353 | 0.000 |
| CLaC-BP* | 0.389 | 0.855 | 0.677 | *0.546* | 0.251 | 0.318 | 0.107 |
| theo chiều kim đồng hồ* | 0.369 | *0.850* | 0.618 | 0.000 | 0.327 | 0.350 | 0.000 |
| UPB* | 0.369 | 0.742 | 0.533 | 0.277 | 0.331 | 0.374 | 0.040 |
| *Đường cơ sở* | 0.239 | 0.827 | 0.561 | 0.000 | 0.053 | 0.064 | 0.005 |
| KGP* | 0.278 | 0.787 | *0.748* | 0.309 | 0.113 | 0.012 | 0.005 |
| Phòng Thí nghiệm Stanford MLab* | 0.272 | 0.818 | 0.760 | 0.408 | 0.000 | 0.000 | 0.000 |
| BuckschJ | 0.263 | 0.825 | 0.695 | 0.375 | 0.000 | 0.000 | 0.000 |
| CLaC-np* | 0.241 | 0.756 | 0.495 | 0.408 | 0.056 | 0.006 | 0.000 |
| FabianW | 0.238 | 0.826 | 0.624 | 0.438 | 0.060 | 0.045 | 0.006 |
| ugeijtsv | 0.229 | 0.759 | 0.582 | 0.210 | 0.000 | 0.000 | 0.000 |
| Jo | 0.212 | 0.754 | 0.377 | 0.291 | 0.000 | 0.000 | 0.000 |
| joe o123 | 0.185 | 0.376 | 0.383 | 0.242 | 0.000 | 0.000 | 0.000 |
| SU-NLP | 0.001 | 0.007 | 0.002 | 0.000 | 0.000 | 0.000 | 0.000 |

Bảng 2: Kết quả hàng đầu cho mỗi đội/người dùng, được sắp xếp theo F1 tổng thể cùng với trung bình vi mô c ho mỗi phạm vi chú thích, cho các đơn vị và cho các bộ điều chỉnh. Tên đội được đánh dấu * đã gửi thông tin hệ thống cho phân tích và thảo luận thêm. Điểm xếp hạng nhất, nhì và ba theo từng hạng mục được biểu thị bằng chữ in đậm, gạch dưới và chữ nghiêng tương ứng.

dòng 1 Sử dụng các mô hình Nhận dạng Thực thể có tên (NER) của spaCy cho từng lớp trong bốn lớp một cách độc lập. Thật không may, một số ví dụ đào tạo cần được loại bỏ vì chức năng NER của spaCy không hỗ trợ các phạm vi chồng lấp trong cùng một mô hình. Vì thường có sự chồng lấp giữa các phạm vi MeasEval của các loại khác nhau, điều này đòi hỏi phải đào tạo từng loại chú thích riêng lẻ và loại bỏ các tr ường hợp biên một nơi mà nhiều chú thích cùng loại giao nhau.

Baseline 1 tạo ra một danh sách các đơn vị không trùng lặp của tất cả các đơn vị trong dữ liệu huấn luyện, và kiểm tra từng Quantity so với danh sách này. Nếu có một hoặc nhiều kết quả khớp trong so sánh này, hệ thống sẽ trả về đơn vị "khớp cuối cùng dài nhất", đảm bảo rằng cm sẽ được ưu tiên so với m trong "22 cm" và s sẽ được ưu tiên so với m trong "khoảng 22 s". Baseline này không cố gắng xử lý thành phần Modifier, mặc dù có thể được bổ sung bằng một tập hợp các biểu thức chính quy để tìm kiếm chuỗi Quantity cho các cụm từ và ký hiệu chính, bao gồm "khoảng", "giữa", ">" và "~".

Khi các mô hình NER và việc ghép đơn vị đã hoàn tất, baseline 1 sẽ ghép các Giá trị với các Thực thể được Đo, Các Thuộc tính được Đo và Các Bộ chỉ tiêu bằng cách sử dụng một thuật toán ghép loại knockout dựa trên khoảng cách gần. Vì vậy, mỗi Thuộc tính được Đo sẽ ghép với Giá trị gần nhất, mỗi Thực thể được Đo sẽ ghép với Thuộc tính được Đo hoặc Giá trị gần nhất, và mỗi Bộ chỉ tiêu khớp với khoảng gần nhất của bất kỳ loại nào. Baseline 2 là một biến thể thực hiện việc khớp đơn giản hơn nhiều, lấy mỗi khoảng theo thứ tự xuất hiện trong dữ liệu. Baseline 2 không xuất hiện trong các bảng kết quả, nhưng đạt điểm F1 tổng thể (Overlap) là 0,223. Mã cho cả hai baseline có sẵn trong một sổ tay Jupyter trên kho Github MeasEval. [9]

## 6 Kết quả và Thảo luận

Trong giai đoạn đánh giá 21 ngày (từ ngày 10 đến 31 tháng 1 năm 2021), 26 người dùng CodaLab đã gửi tổng cộng 89 bài nộp, trong đó 77 bài vượt qua xác thực và được kịch bản đánh giá ghi điểm thành công. Do độ phức tạp của nhiệm vụ, chúng tôi đã chọn cho phép tổng cộ ng năm bài nộp trong suốt quá trình đánh giá, mặc dù một số sự hợp tác giữa các người dùng có nghĩa là một số nhóm đã có thể nộp hiệu quả nhiều hơn năm lần. Chúng tôi lưu ý rằng các bài nộp không tính điểm cho các nhiệm vụ phụ, do đó làm cho việc tối ưu hóa quá mức các mô hình chỉ dựa trên điểm tổng thể trở nên khó khăn. Việc cho phép nộp bài tương đối rộng rãi dường như không gây ra quá nhiều vấn đề về việc học quá mức, vì điểm số vẫn tương đối thấp ở tất cả các nhiệm vụ, mặc dù sự hợp tác có thể đã mang lại một lợi thế nhỏ cho một số người tham gia trong bảng xếp hạng.

Bảng 2 cho thấy bài nộp đứng đầu từ mỗi

[9] https://github.com/harperco/MeasEval/blob/main/baselines/first-baseline.ipynb

the 19 teams that submitted successfully, as well as the top performing baseline. 10 of the 19 exceed the benchmark of the baseline spaCy model. In addition to the overall F1 scores, Table 2 shows micro-averaged F1 across the four annotation spans as well as Units and Modifiers. Table 3 provides this same breakdown for each of the three relationship types. Team names marked with an asterisk (*) represent teams which have either submitted system description papers or responded to a request for system information.

The overall top-performing model was at least tied for top performance in five out of 6 of the component scores in Table 2, but interestingly, the second best and third best performing models varied across scoring component. Models that did particularly well at Quantities, Units, or Modifiers, may have had their overall performance reduced by lower performance at the MeasuredEntity and MeasuredProperty spans.

Table 3 shows the scores for the Relation Extraction subtasks: HasQuantity, HasProperty, and Qualifies. These largely align with the annotation span components of the scoring which they are dependent on. In both Table 2 and Table 3 it is worth noting that only 7 teams attempted extraction of Qualifiers and the Qualifies relation, as these were the most difficult aspects of the task.

| Team Name | HasQuantity | HasProperty | Qualifies |
|---|---|---|---|
| LIORI* | **0.482** | **0.318** | **0.092** |
| jarvis@tencent* | 0.424 | 0.257 | 0.000 |
| zyy_77 | *0.387* | 0.229 | 0.000 |
| zz362 | 0.375 | 0.203 | 0.000 |
| Counts@IITK* | 0.311 | 0.183 | 0.064 |
| yorkey | 0.375 | 0.203 | 0.000 |
| XMSHI | 0.373 | 0.199 | 0.000 |
| CLaC-BP* | 0.308 | 0.147 | *0.058* |
| clockwise9* | 0.366 | 0.167 | 0.000 |
| UPB* | 0.350 | *0.242* | 0.019 |
| *Baseline* | 0.075 | 0.007 | 0.000 |
| KGP* | 0.076 | 0.006 | 0.000 |
| Stanford MLab* | 0.000 | 0.000 | 0.000 |
| BuckschJ | 0.000 | 0.000 | 0.000 |
| CLaC-np* | 0.028 | 0.000 | 0.000 |
| FabianW | 0.037 | 0.007 | 0.000 |
| ugeijtsv | 0.000 | 0.000 | 0.000 |
| Jo | 0.000 | 0.000 | 0.000 |
| joe_o123 | 0.000 | 0.000 | 0.000 |
| SU-NLP | 0.000 | 0.000 | 0.000 |

Table 3: Top result for each team/user for the Relation Extraction components of the score. Team Names marked with * have submitted system information for further analysis and discussion. Top, second, and third place scores per category represented by **bold**, underline, and *italics* respectively.

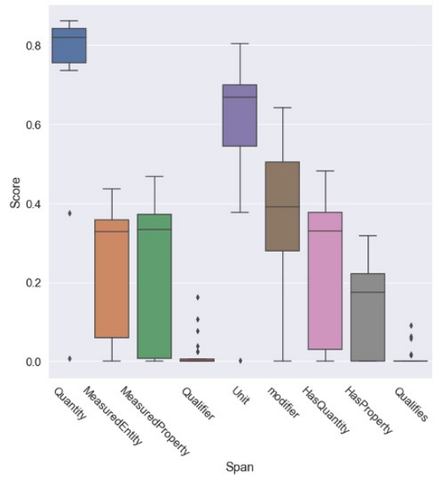



Figure 3: Visualization of average scores for each scoring component across top score for all participants.

Figure 3 provides a visualization of the distribution of scores for each scoring component from Tables 2 and 3. From this, it is clear that Quantity and Unit are the easiest aspects of the shared task, which makes intuitive sense. The relatively high scores for Modifier is also of interest, as these are the components of the extraction that capture uncertainty and variance in value, which is an important part of the task and not one that we expected to see handled as well as it was. This clearly demonstrates that the various Quantity contextualization subtasks are far more difficult and more work is needed in how best to handle the extraction of related MeasuredEntities, MeasuredProperties, and Qualifiers.

Figure 4 provides a visualization of the distribution of scores for 9 of the 10 subject areas in the corpus. The mathematics subject area has been omitted from this graphic due to under-representation in both the training and evaluation datasets.

### 6.1 Impact of Duplicates

As noted previously, the MeasEval evaluation algorithm was designed toward lenience, and as a result sometimes inflates scores if multiple submission annotations match a single entry in the gold data. This was done to allow submissions to get credit for submitting multiple Quantity annotations that partially matched a single gold data span as well as to generally not penalize systems that might make multiple predictions pinned to the same numeric



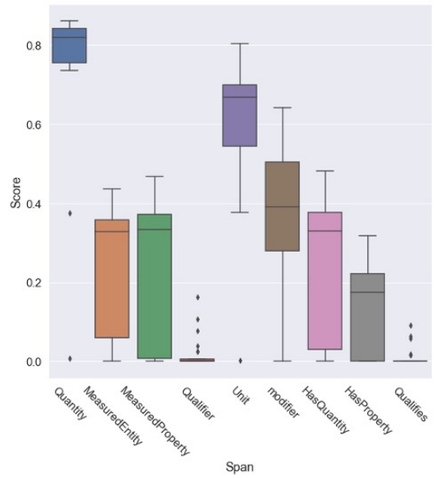
19 đội đã nộp thành công, cũng như điểm chuẩn thực hiện tốt nhất. 10 trong số 19 đội vượt qua ngưỡng của mô hình spaCy cơ bản. Ngoài điểm F1 tổng thể, Bảng 2 cho thấy điểm F1 trung bình vi mô trên bốn phạm vi chú thích cũng như Đơn vị và Bộ điều chỉnh. Bảng 3 cung cấp phân tích tương tự cho từng loại quan hệ ba. Tên các đội được đánh dấu bằng một dấu sao (*) đại diện cho các đội đã nộp bài báo mô tả hệ thống hoặc đã phản hồi yêu cầu thông tin về hệ thống.

Mô hình có hiệu suất tổng thể cao nhất đã ít nhất bằng nhau về hiệu suất hàng đầu ở năm trong số sáu điểm thành phần trong Bảng 2, nhưng thú vị là, mô hình có hiệu suất cao thứ hai và thứ ba lại thay đổi tùy theo thành phần chấm điểm. Những mô hình thực sự làm tốt tại các mục Số lượng, Đơn vị, hoặc Bộ chỉnh, có thể đã bị giảm hiệu suất tổng thể do hiệu suất thấp hơn ở các đoạn Thực thể Được Đo lường và Thuộc tính Được Đo lường.

Bảng 3 hiển thị các điểm số cho các nhiệm vụ phụ Trích xuất Quan hệ: HasQuantity, HasProperty và Qualifies. Chúng phần lớn phù hợp với các thành phần phạm vi chú giải của việc chấm điểm mà chúng phụ thuộc vào. Cả trong Bảng 2 và Bảng 3, đáng chú ý là chỉ có 7 đội thử trích xuất Qualifiers và mối quan hệ Qualifies, vì đây là những khía cạnh khó nhất của nhiệm vụ.

| Tên đội | CóSốLượng | CóThuộcTính | Đủ điều kiện |
|---|---|---|---|
| LIORI* | **0.482** | **0.318** | **0.092** |
| jarvis@tencent* | 0.424 | 0.257 | 0.000 |
| zyy 77 | *0.387* | 0.229 | 0.000 |
| zz362 | 0.375 | 0.203 | 0.000 |
| Counts@IITK* | 0.311 | 0.183 | 0.064 |
| yorkey | 0.375 | 0.203 | 0.000 |
| XMSHI | 0.373 | 0.199 | 0.000 |
| CLaC-BP* | 0.308 | 0.147 | *0.058* |
| theo chiều kim đồng hồ9* | 0.366 | 0.167 | 0.000 |
| UPB* | 0.350 | *0.242* | 0.019 |
| *Đường cơ sở* | 0.075 | 0.007 | 0.000 |
| KGP* | 0.076 | 0.006 | 0.000 |
| Phòng Thí nghiệm Stanford MLab* | 0.000 | 0.000 | 0.000 |
| BuckschJ | 0.000 | 0.000 | 0.000 |
| CLaC-np* | 0.028 | 0.000 | 0.000 |
| FabianW | 0.037 | 0.007 | 0.000 |
| ugeijtsv | 0.000 | 0.000 | 0.000 |
| Jo | 0.000 | 0.000 | 0.000 |
| joe o123 | 0.000 | 0.000 | 0.000 |
| SU-NLP | 0.000 | 0.000 | 0.000 |

Bảng 3: Kết quả hàng đầu cho mỗi đội/người dùng cho các thành phần Trích xuất Quan hệ của điểm số. Tên đội được đánh dấu * đã gửi thông tin hệ thống để phân tích và thảo luận thêm. Điểm xếp hạng nhất, nhì và ba cho mỗi danh mục được biểu thị bằng chữ in đậm, gạch chân và chữ in nghiêng tương ứng.




Hình 3: Minh họa điểm trung bình cho từng thành phần chấm điểm trên điểm cao nhất của tất cả người tham gia.

Hình 3 cung cấp một trực quan hóa về phân phối điểm số cho từng thành phần đánh giá từ Bảng 2 và 3. Từ đó, có thể thấy rằng Số lượng và Đơn vị là những khía cạnh dễ nhất của nhiệm vụ chia sẻ, điều này hợp lý theo trực giác. Điểm số tương đối cao cho Thành phần bổ nghĩa cũng đáng chú ý, vì đây là những thành phần của việc trích xuất nắm bắt sự không chắc chắn và biến thiên trong giá trị, đây là một phần quan trọng của nhiệm vụ và không phải là điều mà chúng tôi mong đợi sẽ được xử lý tốt như vậy. Điều này rõ ràng chứng tỏ rằng các nhiệm vụ phụ về bối cảnh hóa Số lượng khác nhau khó khăn hơn nhiều và cần nhiều công việc hơn về cách xử lý tốt nhất việc trích xuất các Thực thể đo lường, Thuộc tính đo lường và Các yếu tố bổ nghĩa liên quan.

Hình 4 cung cấp một hình ảnh trực quan về phân bố các điểm số cho 9 trong số 10 lĩnh vực môn học trong tập dữ liệu. Lĩnh vực môn Toán đã bị loại khỏi biểu đồ này do bị thiếu đại diện trong cả tập dữ liệu huấn luyện và đánh giá.

#### 6.1 Tác động của các bản sao

Như đã lưu ý trước đó, thuật toán đánh giá MeasEval được thiết kế theo hướng khoan dung, và do đó đôi khi làm tăng điểm số nếu nhiều c hú thích gửi lên khớp với một mục duy nhất trong dữ liệu vàng. Việc này được thực hiện để cho phép các bài nộp được công nhận khi gửi nhiều chú thích về Số lượng mà khớp một phần với một đoạn dữ liệu vàng duy nhất cũng như nhìn chung không phạt các hệ thống có thể đưa ra nhiều dự đoán gần với cùng một giá trị số.

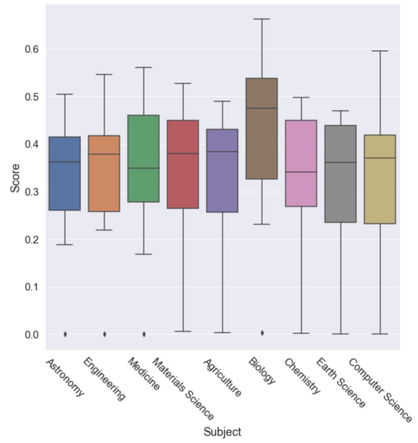



Figure 4: Visualization of average scores for each subject area across top score for all participants.

value.

However, allowing duplicates can in some cases result in inflated scores. This is especially evident in cases where submissions contained entries that duplicated entire annotations sets. For a small number of submissions that exhibited annotation set level duplicates, a post-processing routine removed all set level duplicates before final evaluation, resulting in the scores in Table 2 and Table 3.

Additionally, Quantity-level duplicates can also potentially inflate Quantity scores, but should have a neutral impact on other components of scoring. For example, if a system identified the same Quantity two times, but found a different MeasuredEntity for each occurrence, the submission will score extra points associated with the Quantity, and potentially the Unit and Modifiers if those are also correct, but will only get points for the correct MeasuredEntity while being penalized for the incorrect MeasuredEntity. An ablation analysis was performed for the eight submissions covered by system papers, assessing the impact of these duplicates on the Overall F1 (Overlap) metric.

Table 4 gives the extent of duplication for these submissions, the initial overall score from Table 3, the overall score with exact quantity duplicates removed, and the overall score with both exact and overlapping duplicates removed. For example, if the gold data includes the Quantity “approximately 23 mm”, and a submissions included annotation sets with both “23 mm” and “approximately 23 mm”, the exact match duplicate removal would not drop either score, whereas the overlapping match score would drop whichever occurred last in the submission, whether or not it is the correct answer.

| Team Name | F1 | Count Exact / Overlap | F1 w/out Exact | F1 w/out Any Duplicates |
|---|---|---|---|---|
| LIORI | 0.519 | 125 / 32 | 0.499 | 0.487 |
| jarvis@tencent | 0.473 | 0 / 11 | 0.473 | 0.470 |
| Counts@IITK | 0.432 | 0 / 0 | 0.432 | 0.432 |
| CLaC-BP | 0.389 | 0 / 0 | 0.389 | 0.389 |
| UPB | 0.369 | 0 / 1 | 0.369 | 0.369 |
| KGP | 0.278 | 0 / 0 | 0.278 | 0.278 |
| Stanford MLab | 0.272 | 0 / 0 | 0.272 | 0.272 |
| CLaC-np | 0.241 | 55 / 0 | 0.231 | 0.231 |

Table 4: Ablation analysis of duplicates and Overall F1 (Overlap) score for each of the eight Teams with System Papers.

The general downward trajectory seen while removing duplicates that are not at the set level is informative. Partly this is due to declining Quantity score from duplicate removal, but some effect is attributable to the possibility that deduplication deletes a correct MeasuredProperty or MeasuredEntity and leaves an incorrect one, given that they may include different values. The ablation analysis simply removes all but the first occurrence, so there is no control over whether removed values are a closer match to the gold data.

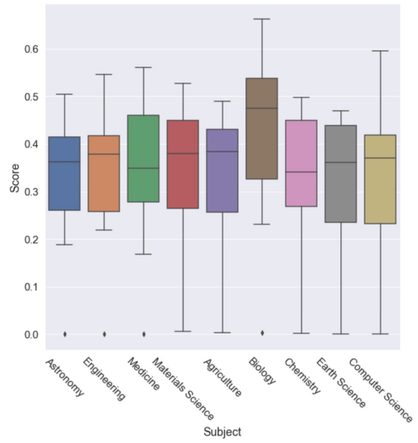
### 6.2 Multiple Hypotheses Hypothesis

The results of de-duplication analysis, the relatively low inter-annotator agreement scores, and deeper consideration of the annotation guidelines present an interesting hypothesis. It could be that the different interpretations of the context of a measurement are not automatically right or wrong. It could be that different interpretations are useful in different downstream applications. While it is out of scope in for this task description, future work may look more closely at categorization of the areas where annotators disagreed and systems produced multiple interpretations, to see if there is alignment in the differences and whether there are patterns to the variance.

## 7 Summary of Participating Systems

The MeasEval track at SemEval-2021 received nine system description paper submissions, eight of which are represented in the analysis in Table 4. A ninth paper formulated a new task from the MeasEval dataset focusing on just the relation extraction






Hình 4: Minh họa điểm trung bình cho từng lĩnh vực môn học trên tổng điểm cao nhất của tất cả người tham gia.

giá trị.

Tuy nhiên, việc cho phép bản sao có thể trong một số trường hợp dẫn đến điểm số bị phóng đại. Điều này đặc biệt rõ ràng trong các trường hợp mà các bài nộp chứa các mục sao chép toàn bộ bộ chú thích. Đối với một số ít bài nộp mà có các bản sao ở cấp độ bộ chú thích, một quy trình xử lý hậu kỳ đã loại bỏ tất cả các bản sao ở cấp độ bộ trước khi đánh giá cuối cùng, dẫn đến điểm số trong Bảng 2 và Bảng 3.

Ngoài ra, các bản sao ở mức Số lượng cũng có thể làm tăng điểm Số lượng, nhưng nên có tác động trung lập đối với các thành phần khác của việc chấm điểm. Ví dụ, nếu một hệ thống nhận diện cùng một Số lượng hai lần, nhưng tìm thấy một Thực thể Được Đo lường khác nhau cho mỗi lần xuất hiện, bản nộp sẽ được cộng thêm điểm liên quan đến Số lượng, và có thể là Đơn vị và Biến thể nếu những yếu tố này cũng đúng, nhưng chỉ nhận điểm cho Thực thể Được Đo lường đúng trong khi bị trừ điểm cho Thực thể Được Đo lường sai. Một phân tích loại bỏ đã được thực hiện cho tám bản nộp được đề cập trong các bài báo hệ thống, đánh giá tác động của các bản sao này đối với chỉ số F1 Tổng thể (Chồng lặp).

Bảng 4 đưa ra mức độ trùng lặp của các bài nộp này, điểm tổng thể ban đầu từ Bảng 3, điểm tổng thể khi loại bỏ các bản sao số lượng chính xác, và điểm tổng thể khi loại bỏ cả bản sao chính xác và trùng lặp. Ví dụ, nếu dữ liệu chuẩn bao gồm Số lượng “xấp xỉ 23 mm”, và một bài nộp bao gồm các bộ chú thích với cả “23 mm” và “xấp xỉ 23 mm”, việc loại bỏ bản sao khớp chính xác sẽ không bỏ bất kỳ điểm nào, trong khi điểm khớp chồng sẽ bỏ điểm nào xảy ra sau cùng trong bài nộp, bất kể liệu nó có phải là câu trả lời đúng hay không.

| Tên đội | F1 | Đếm Chính xác / Chồng lên nhau | F1 không có Chính xác | F1 không có Any Bản sao |
|---|---|---|---|---|
| LIORI | 0,519 | 125/ 32 | 0.499 | 0.487 |
| jarvis@tencent | 0.473 | 0 / 11 | 0.473 | 0.470 |
| Counts@IITK | 0.432 | 0 / 0 | 0.432 | 0.432 |
| CLaC-BP | 0.389 | 0 / 0 | 0.389 | 0.389 |
| UPB | 0.369 | 0 / 1 | 0.369 | 0.369 |
| KGP | 0.278 | 0 / 0 | 0.278 | 0.278 |
| Stanford MLab | 0.272 | 0 / 0 | 0.272 | 0.272 |
| CLaC-np | 0.241 | 55 / 0 | 0.231 | 0.231 |

Bảng 4: Phân tích loại bỏ các bản trùng lặp và điểm F1 tổng thể (Overlap) cho từng tám Đội với Bài báo Hệ thống.

Xu hướng giảm tổng thể được quan sát khi loại bỏ các bản sao không ở mức được thiết lập là thông tin hữu ích. Một phần điều này là do điểm Quantity giảm khi loại bỏ bản sao, nhưng một số tác động có thể là do khả năng rằng việc loại bỏ trùng lặp xóa một MeasuredProperty hoặc MeasuredEntity đúng và để lại một cái sai, vì chúng có thể bao gồm các giá trị khác nhau. Phân tích ablation chỉ đơn giản loại bỏ tất cả trừ lần xuất hiện đầu tiên, nên không có kiểm soát về việc các giá trị bị loại có khớp gần đúng với dữ liệu chuẩn hay không.

### 6.2 Giả thuyết Nhiều Giả thuyết

Kết quả của phân tích loại bỏ trùng lặp, điểm đồng thuận giữa những người chú thích tương đối thấp, và việc xem xét kỹ hơn các hướng dẫn chú thích nêu ra một giả thuyết thú vị. Có thể là những cách hiểu khác nhau về ngữ cảnh của một phép đo không phải lúc nào cũng đúng hoặc sai. Có thể là những cách hiểu khác nhau lại hữu ích trong các ứng dụng hạ nguồn khác nhau. Mặc dù điều này nằm ngoài phạm vi mô tả nhiệm vụ này, các nghiên cứu trong tương lai có thể xem xét kỹ hơn việc phân loại các lĩnh vực mà người chú thích không đồng ý và các hệ thống tạo ra nhiều cách hiểu khác nhau, để xem liệu có sự phù hợp trong những khác biệt đó hay không và liệu có những mẫu hình trong sự biến thiên này hay không.

## 7 Tóm tắt các Hệ thống Tham gia

Hạng mục MeasEval tại SemEval-2021 đã nhận được chín bài báo mô tả hệ thống, tám trong số đó được thể hiện trong phân tích ở Bảng 4. Một bài báo thứ chín đã xây dựng một nhiệm vụ mới từ tập dữ liệu MeasEval tập trung chỉ vào việc trích xuất quan hệ.

part of the problem. One system only attempted the Quantity, Unit, and Modifier parts of the task, while another did not submit any Qualifier spans or Qualifies relationships. Four of the nine systems have released code or models.

There are several points of similarity between the eight main submissions. All but one of the systems are based on the BERT architecture (Devlin et al., 2018) or a derivative, such as SciBERT (Beltagy et al., 2019), BioBERT (Lee et al., 2019), or RoBERTa (Liu et al., 2019). All but one used a pipeline architecture, starting with Quantity extraction. All but one used sequence tagging with a BIO encoding scheme, and four followed the sequence tagger by a Conditional Random Fields (CRF) model to assemble tokens into spans and improve accuracy over simple token-level classifiers. Unit and Modifier extraction was either done using a character-level BiLSTMs, another BERT model, or a rule-based approach. Finally, it was common to see MeasuredEntity, MeasuredProperty, and Qualifier, and sometimes the relation extraction components, stacked together in a multi-task sequence tagging model as a final stage, taking both the original sentences and Quantity spans as input. One system diverged from the sequence tagging tagging approach and used templated question answering techniques to handle the relation extraction along with related spans. Table 5 provides a high-level summary of frequency of architectures and techniques in use by more than one system.

| Technique / Model | Submission Count |
|---|---|
| BERT | 3 |
| BioBERT | 1 |
| SciBERT | 3 |
| RoBERTa | 1 |
| CRF | 4 |
| BiLSTM Units / Mods | 3 |
| Rule-based Units / Mods | 3 |
| Dict-based Units / Mods | 2 |
| Question Answering | 1 |
| Sequence Tagging | 7 |

Table 5: Summary of techniques and architectures used in MeasEval System Description Submissions.

### 7.1 System Specifics

Davletov et al. (2021) (LIORI), achieve their state-of-the-art performance using pre-trained models RoBERTa (Liu et al., 2019) and LUKE (Yamada et al., 2020). They use LUKE to fine-tune an NER model for Quantity extraction, and a RoBERTa-based multi-task model for all other spans. Modifiers are predicted as Quantity-types. All other spans, including units, are extracted using Question Answering style sequence tagging (start/end logits) without question prompts for each annotation type queried for each extracted Quantity.

This sequential ensemble approach of Quantity-detection followed by either "all-in-one-multi-task" extraction or a staged approach to one or more of the other subtasks proved very common among the top-performing systems.

Cao et al. (2021) (jarvis@tencent), do initial Quantity extraction with an ensemble of a Pointer Net (Vinyals et al., 2015) and a CRF. They use a BERT-based classifier for Modifier tagging and a rule-based system for Units, and then use relation-specific taggers with the same architecgure as the Quantity-tagger for all other task components.

Gangwar et al. (2021) (Counts@IITK) similarly tag Quantities witha SciBERT sequence tagger and a CRF model and SciBERT for Modifiers, but use a Character based bidirectional LSTM for Unit tagging. They then encode the Quantity into SciBERT input when tagging MeasuredEntity and HasQuantity, and iteratively mark new spans in the input when tagging then next sub-task, using a rule-base for assembling the necessary relationships. Their performance on Quantity, Unit, and Modifier was near the top performing, but they struggled with MeasuredProperty and HasProperty.

Therien et al. (2021) (CLaC-BP) use SciBERT in a token-level multi-class classifier across all span classes. This is an interesting approach, given the opportunity for joint inference between the various types of spans. However, it penalizes them in that each token in their model can only be one class, while there are cases when a Quantity and MeasuredEntity from one set may be part of, e.g. a Qualifier in another. Quantity spans are then fed to another SciBERT model for Modifier typing, and rule-based systems are used for Units and for the Relations between spans.

Avram et al. (2021) (UPB) use RoBERTa along with a CRF for Quantity extraction. They also tested SciBERT and BERT. They achieved their best results on their dev subset with SciBERT, but their best results on evaluation set came from RoBERTa. They use a BiLSTM to extract Units and classifier Modifiers, and then use a templated Question Answering system as a joint entity and relation extraction system for the remaining subtasks. Unlike LIORI, who did not use prefixes or



một phần của vấn đề. Một hệ thống chỉ thử nghiệm các phần Số lượng, Đơn vị và Bộ điều chỉnh của nhiệm vụ, trong khi một hệ thống khác không gửi bất kỳ phạm vi Chất lượng hay mối quan hệ Chất lượng nào. Bốn tro ng chín hệ thống đã phát hành mã hoặc mô hình.

Có một số điểm tương đồng giữa tám bài nộp chính. Tất cả ngoại trừ một hệ thống đều dựa trên kiến trúc BERT (Devlin et al., 2018) hoặc một biến thể của nó, chẳng hạn như SciBERT (Beltagy et al., 2019), BioBERT (Lee et al., 2019), hoặc RoBERTa (Liu et al., 2019). Tất cả ngoại trừ một hệ thống đều sử dụng kiến trúc theo quy trình, bắt đầu với việc trích xuất Số lượng. Tất cả ngoại trừ một hệ thống đều sử dụng gắn thẻ chuỗi với sơ đồ mã hóa BIO, và bốn hệ thống tiếp theo gắn thẻ chuỗi bằng một mô hình Mạng Xác suất Có Điều kiện (CRF) để ghép các token thành các khoảng và cải thiện độ chính xác so với các bộ phân loại mức token đơn giản. Việc trích xuất Đơn vị và Bộ điều chỉnh được thực hiện bằng BiLSTMs cấp ký tự, một mô hình BERT khác, hoặc phương pháp d ựa trên quy tắc. Cuối cùng, thường thấy rằng MeasuredEntity, MeasuredProperty và Qualifier, và đôi khi các thành phần trích xuất quan hệ, được xếp chồng cùng nhau trong một mô hình gắn thẻ chuỗi đa nhiệm như giai đoạn cuối cùng, lấy cả câu gốc và các khoảng Số l ượng làm đầu vào. Một hệ thống khác biệt

| Kỹ thuật / Mô hình | Số lần nộp |
|---|---|
| BERT | 3 |
| BioBERT | 1 |
| SciBERT | 3 |
| RoBERTa | 1 |
| CRF | 4 |
| Các đơn vị / mô-đun BiLSTM | 3 |
| Đơn vị / Mod dựa trên quy tắc | 3 |
| Đơn vị / Mod dựa trên từ điển | 2 |
| Trả lời câu hỏi | 1 |
| Đánh dấu chuỗi | 7 |

Bảng 5: Tóm tắt các kỹ thuật và kiến trúc được sử dụng trong các bài nộp Mô tả Hệ thống MeasEval.

### 7.1 Chi tiết Hệ thống

Davletov và cộng sự (2021) (LIORI), đạt được hiệu suất tiên tiến nhất của họ bằng cách sử dụng các mô hình đã được huấn luyện trước RoBERTa (Liu và cộng sự, 2019) và LUKE (Yamada và cộng sự, 2020). Họ sử dụng LUKE để tinh chỉnh một mô hình NER cho việc trích xuất Số lượng, và một mô hình đa nhiệm dựa trên RoBERTa cho tất cả các phạm vi khác. Mod-

Các chỉ số được dự đoán là loại Số lượng. Tất cả các đoạn khác, bao gồm cả đơn vị, được trích xuất bằng cách sử dụng gắn thẻ tuần tự theo kiểu Hỏi đáp (logits bắt đầu/kết thúc) mà không cần câu hỏi cho từng loại chú thích được truy vấn cho mỗi Số lượng được trích xuất.

Phương pháp tổ hợp theo trình tự này bao gồm việc phát hiện số lượng, sau đó là trích xuất theo kiểu " tất cả-trong-một-nhiều-nhiệm vụ" hoặc phương pháp theo giai đoạn đối với một hoặc nhiều nhiệm vụ phụ khác đã được chứng minh là rất phổ biến trong số các hệ thống có hiệu suất cao nhất.

Cao và cộng sự (2021) (jarvis@tencent), thực hiện trích xuất Số lượng ban đầu với một tổ hợp của Pointer Net (Vinyals và cộng sự, 2015) và CRF. Họ sử dụng một bộ phân loại dựa trên BERT cho việc gắn thẻ Bộ điều chỉnh và một hệ thống dựa trên quy tắc cho Đơn vị, s au đó sử dụng các bộ gắn thẻ theo quan hệ với kiến trúc giống như bộ gắn thẻ Số lượng cho tất cả các t hành phần nhiệm vụ khác.

Gangwar và cộng sự (2021) (Counts@IITK) tương tự đánh dấu các Đại lượng với bộ gắn nhãn chuỗi SciBERT và mô hình CRF và SciBERT cho các Bộ sửa đổi, nhưng sử dụng LSTM hai chiều dựa tr ên ký tự cho việc đánh dấu Đơn vị. Sau đó, họ mã hóa Đại lượng vào đầu vào SciBERT khi gắn nhãn Thực thể đo lường và Có đại lượng, và lặp đi lặp lại đánh dấu các khoảng mới trong đầu vào khi gắn nhãn cho tác vụ con tiếp theo, sử dụng một quy tắc cơ sở để lắp ráp các mối quan hệ cần thiết. Hiệu suất của họ trên Đại lượng, Đơn vị và Bộ sửa đổi gần đạt mức cao nhất, nhưng họ gặp khó khăn với Thuộc tính đo lường và Có thuộc tính.

Therien và cộng sự (2021) (CLaC-BP) sử dụng SciBERT trong một bộ phân loại đa lớp ở cấp token trên tất cả các lớp span. Đây là một phương pháp thú vị, khi xem xét cơ hội suy luận đồng thời giữa các loại span khác nhau. Tuy nhiên, phương pháp này gây bất lợi cho họ vì mỗi token trong mô hình của họ chỉ có thể thuộc một lớp, trong khi có những trường hợp một Quantity và MeasuredEntity từ một bộ có thể là một phần của, ví dụ, một Qualifier trong bộ khác. Các span Quantity sau đó được đưa vào một mô hình SciBERT khác để xác định loại Modifier, và các hệ thống dựa trên quy tắc được sử dụng cho Units và cho các mối quan hệ giữa các span.

Avram và cộng sự (2021) (UPB) sử dụng RoBERTa cùng với CRF để trích xuất Số lượng. Họ cũng đã thử nghiệm SciBERT và BERT. Họ đạt được kết quả tốt nhất trên tập con phát triển của mình với SciBERT, nhưng kết quả tốt nhất trên tập đánh giá lại đến từ RoBERTa. Họ sử dụng BiLSTM để trích xuất Đơn vị và phân loại Bộ một cách, và sau đó sử dụng hệ thống Hỏi đáp theo mẫu như một hệ thống trích xuất thực thể và quan hệ chung cho các tác vụ con còn lại. Không giống như LIORI, người đã không sử dụng các tiền tố hoặc

suffixes in their question templates, UPB asks more natural language questions of the form “What is the measured property of the quantity ___?”

Karia et al. (2021) (KGP) also use BioBERT after testing various BERT-based pre-trained models, but depart from many of the other submissions by using a binary classifier rather than BIO tags and CRF layers for Quantity sequence tagging. Modifiers and Units are handled using keywords and dictionary matching, while they use a multi-task BERT model for the remaining components, first finding MeasuredEntity based on the Quantity predictions, then fusing these results for the remaining spans and relations. They also continued refining their approach into the post-evaluation phase, and reported improving their score from an Overall F1 (Overlap) of 0.278 to 0.456.

Liu et al. (2021) (Stanford MLab) only tackle the Quantity, Unit, and Modifier subtasks. Notably, they report building their system for these components from inception to submission in under 48 hours. They use BERT-large for IOB sequence tagging for Quantities, use a similar IO sequence tagging scheme on Quantities to tag Units, and a multi-class classifier to classify Quantities to the appropriate Modifiers. Their system performs well on all subtasks they attempted, even scoring second place overall for Units.

Lathiff et al. (2021) (CLaC-np) diverge from other submissions in their approach. They preprocess their text using GATE and ANNIE, and use custom rules to further clean up tokenization. They treated Stanford Core Dependency Parse trees as graphs to extract subgraphs starting each path query from the CD tokens to identify MeasureEntities, MeasuredProperties and Qualifiers with the use of Graph CNN. They relied on the models from CLaC-BP to map from their tokens to annotation spans for each type in assembling their final submission.

Finally, not shown in Table 1 is Veyseh et al. (2021). They formulated their own task based on the MeasEval data. Although they did not submit a solution during the evaluation period, they have submitted a system description paper describing a novel approach to relation extraction, which they have evaluated on MeasEval sub-task 5. Using our Gold Quantity, MeasuredEntity, MeasuredProperty, and Qualifier spans as input (without annotation sets), they compared their approach to two other baseline models. They encode contextual embeddings, positional embeddings, and entity types for each annotation span, and perform dependency path reasoning along with an “Information Bottleneck” regularization technique to complete their Relation Extraction task.

## 8 Conclusion

In this paper, we present the design, the data, the evaluation the process, the results, and the systems for MeasEval at SemEval 2021. The shared task is challenging, partly due to the relatively small training data, and partly due to the inter-relationships between many different components of the task. Quantity and Unit identification, and to a lesser extent Modifier typing, appear to be the simplest parts of the task based on average performance, with one participating system building their end-to-end pipeline for these components in under 48 hours. The contextual elements MeasuredEntity, MeasuredProperty, and Qualifier, and their relationships, are far more difficult, which is not surprising given that these are subject to more human annotator disagreement. The challenge of context is especially pronounced in the Qualifier span and Qualifies relationship.

Common components shown in Table 5 include the BERT family of pre-trained neural language models, CRF models, BiLSTMs, and rule-based components. In general, the task does not appear to require whole new novel models and architectures, but rather pipelines and cascading ensembles stitching together various existing methods. There is still room for improvement on this task, and whether progress will come from novel models or creative applications of existing techniques remains to be seen. Work also remains to be done in applying the entities and relationships extracted for this task to the larger end goal of scientific knowledge graph construction and related downstream applications. Future work could be done to further analyze areas of error and disagreement in these annotations, and to investigate entity linking across Quantity, MeasuredEntity, and MeasuredProperty annotation spans to various measurement ontologies and to domain-specific entity and property ontologies.

## Acknowledgments

The authors would like to thank Darin McBeath and Pierre-Yves Vandenbussche for help with annotations and annotation rules. We also thank Elsevier’s Discovery Lab team for their feedback on this work.



hậu tố trong các mẫu câu hỏi của họ, UPB hỏi các câu hỏi ngôn ngữ tự nhiên hơn theo dạng “ Đặc tính đo được của đại lượng là gì?”___

Karia và cộng sự (2021) (KGP) cũng sử dụng BioBERT sau khi thử nghiệm nhiều mô hình BERT có sẵn khác, nhưng khác với nhiều bài nộp khác ở chỗ họ sử dụng bộ phân loại nhị phân thay vì các thẻ BIO và lớp CRF cho việc gắ n nhãn chuỗi Quantity. Các Modifiers và Units được xử lý bằng cách sử dụng từ khóa và đối chiếu từ điển, trong khi họ sử dụng mô hình BERT đa nhiệm cho các thành phần còn lại, trước tiên tìm MeasuredEntity dựa trên dự đoán Quantity, sau đó kết hợp các kết quả này cho các phạm vi và mối quan hệ còn lại. Họ cũng tiếp t ục tinh chỉnh phương pháp của mình trong giai đoạn sau đánh giá, và báo cáo đã cải thiện điể m số từ F1 tổng thể (Overlap) 0,278 lên 0,456.

Liu và cộng sự (2021) (Stanford MLab) chỉ giải quyết các nhiệm vụ phụ về Số lượng, Đơn vị và Bộ điều chỉnh. Đáng chú ý, họ báo cáo đã xây dựng hệ thống của mình cho những thành phần này từ khi bắt đầu đến khi nộp trong chưa đầy 48 giờ. Họ sử dụng BERT-large để gắn nhãn trình tự IOB cho Số lượng, sử dụng một sơ đồ gắn nhãn trình tự IO tương tự trên Số lượng để gắn nhãn Đơn vị, và một bộ phân loại đa lớp để phân loại Số lượng thành c ác Bộ điều chỉnh thích hợp. Hệ thống của họ hoạt động tốt trên tất cả các nhiệm vụ phụ mà họ đã t hử, thậm chí đạt vị trí thứ hai chung cuộc cho Đơn vị.

Lathiff et al. (2021) (CLaC-np) khác với các bài nộp khác về cách tiếp cận của họ. Họ tiền xử lý văn bản của mình bằng GATE và ANNIE, và sử dụng các quy tắc tùy chỉnh để làm sạch thêm việc phân tách từ. Họ coi các cây Phân tích Phụ thuộc Stanford Core như các đồ thị để trích xuất các đồ thị con, bắt đầu mỗi truy vấn đường đi từ các token CD để xác định MeasureEntities, MeasuredProperties và Qualifiers bằng cách sử dụng Graph CNN. Họ dựa vào các mô hình từ CLaC-BP để ánh xạ từ các token của họ sang các khoảng chú thích cho mỗi loại trong việc lắp ráp bài nộp cuối cùng của họ.

Cuối cùng, không được trình bày trong Bảng 1 là Veyseh và cộng sự (2021). Họ đã xây dựng nhiệ m vụ riêng dựa trên dữ liệu MeasEval. Mặc dù họ không nộp một giải pháp trong thời gian đánh giá, họ đã nộp một bài báo mô tả hệ thống mô tả một phương pháp mới để trích xuất quan hệ, mà họ đã đánh giá trên nhiệm vụ phụ số 5 của MeasEval. Sử dụng các khoảng GoldQuantity, MeasuredEntity, MeasuredProperty và Qualifier của chúng tôi làm đầu vào (không kèm theo bộ chú thích), họ đã so sánh phương pháp của mình với hai mô hình cơ sở khác. Họ mã hóa nhúng ngữ cảnh, nhúng vị trí và loại thực thể

cho mỗi đoạn chú thích, và thực hiện suy luận đường dẫn phụ thuộc cùng với kỹ thuật điều chuẩn “Cổ chai Thông tin” để hoàn thành nhiệ m vụ Trích xuất Quan hệ của họ.

## 8 Kết luận

Trong bài báo này, chúng tôi trình bày thiết kế, dữ liệu, quy trình đánh giá, kết quả và các hệ thống cho MeasEval tại SemEval 2021. Nhiệm vụ chung này đầy thách thức, một phần là do dữ liệu huấn luyện tương đối ít, và một phần là do các mối quan hệ giữa nhiều thành phần khác nhau của nhiệm vụ. Việc nhận dạng Số lượng và Đơn vị, và ở mức độ thấp hơn là phân loại Bộ điều chỉnh, có vẻ là những phần đơn giản nhất của nhiệm vụ dựa trên hiệu suất trung bình, với một hệ thống tham gia xây dựng đường ống đầu-cuối cho các thành phần này trong chưa đầy 48 giờ. Các yếu tố ngữ cảnh MeasuredEntity, MeasuredProperty và Qualifier, cùng các mối quan hệ của chúng, khó khăn hơn nhiều, điều này không có gì ngạc nhiên vì chúng dễ gây tranh cãi hơn đối với những người chú thích. Thách thức về ngữ cảnh đặc biệt rõ ràng ở phạm vi Qualifier và mối quan hệ Qualifies.

Các thành phần phổ biến được trình bày trong Bảng 5 bao gồm họ BERT của các mô hình ngôn ngữ nơ-ron đã được huấn luyện trước, các mô hình CRF, BiLSTM và các thành phần dựa trên quy tắc. Nói chung, nhiệm vụ dường như không yêu cầu các mô hình và kiến trúc hoàn toàn mới mẻ, mà thay vào đó là các pipeline và các tập hợp ghép nối dọc theo chuỗi kết hợp các phương pháp hiện có. Vẫn còn dư địa để cải thiện trong nhiệm vụ này, và việc tiến triển sẽ đến từ các mô hình mới hay từ việc ứng dụng sáng tạo các kỹ thuật hiện có vẫn còn phải chờ xem. Công việc cũng còn phải được thực hiện trong việc áp dụng các thực thể và mối quan hệ được trích xuất cho nhiệm vụ này vào mục tiêu lớn hơn là xây dựng đồ thị tri thức khoa học và các ứng dụng hạ nguồn liên quan. Các công việc tương lai có thể được tiến hành để phân tích thêm các khu vực lỗi và bất đồng trong các chú thích này, và để nghiên cứu việc liên kết thực thể giữa các khoảng chú thích Quantity, MeasuredEntity và MeasuredProperty đến các hệ thống đo lường khác nhau cũng như đến các hệ thống thực thể và thuộc tính chuyên ngành.

## Lời cảm ơn

Các tác giả muốn cảm ơn Darin McBeath và Pierre-Yves Vandenbussche vì đã giúp với các chú thích và quy tắc chú thích. Chúng tôi cũng cảm ơn đội ngũ Discovery Lab của Elsevier vì phản hồi của họ về công trình này.

## References


Isabelle Augenstein, Mrinal Das, Sebastian Riedel, Lakshmi Vikraman, and Andrew McCallum. 2017. SemEval 2017 task 10: ScienceIE - extracting keyphrases and relations from scientific publications. In *Proceedings of the 11th International Workshop on Semantic Evaluation (SemEval-2017)*, pages 546–555, Vancouver, Canada. Association for Computational Linguistics.

Andrei-marius Avram, George-eduard Zaharia, Dumitru-clementin Cercel, and Mihai Dascalu. 2021. UPB at SemEval-2021 Task 8 : Extracting Semantic Information on Measurements as Multi-Turn Question Answering. In *Proceedings of the Fifteenth Workshop on Semantic Evaluation (SemEval-2021)*, 2.

Payam Barnaghi, Wei Wang, Lijun Dong, and Chonggang Wang. 2013. A linked-data model for semantic sensor streams. *Proceedings - 2013 IEEE International Conference on Green Computing and Communications and IEEE Internet of Things and IEEE Cyber, Physical and Social Computing, GreenCom-iThings-CPSCom 2013*, pages 468–475.

Iz Beltagy, Kyle Lo, and Arman Cohan. 2019. SciBERT: A Pretrained Language Model for Scientific Text. pages 3613–3618.

Melanie Bergmann, Mine B Tekman, and L. Gutow. 2017. *LITTERBASE: An Online Portal for Marine Litter and Microplastics and Their Implications for Marine Life*, pages 106–107.

Jiarun Cao, Yuejia Xiang, Yunyan Zhang, Zhiyuan Qi, and Xi Chen. 2021. CONNER : A Cascade Count and Measurement Extraction Tool for Scientific Discourse. In *Proceedings of the Fifteenth Workshop on Semantic Evaluation (SemEval-2021)*.

Dmitry Davidov and Ari Rappoport. 2010. Extraction and approximation of numerical attributes from the Web. *ACL 2010 - 48th Annual Meeting of the Association for Computational Linguistics, Proceedings of the Conference*, (July):1308–1317.

Adis Davletov, Denis Gordeev, Nikolay Arefyev, and Emil Davletov. 2021. LIORI at SemEval-2021 Task 8: Ask Transformer for measurements. In *Proceedings of the Fifteenth Workshop on Semantic Evaluation (SemEval-2021)*.

Helena F. Deus, Corey A. Harper, Darin McBeath, and Ron Daniel. 2017. Combining pattern matching with word embeddings for the extraction of experimental variables from scientific literature. *2017 IEEE International Conference on Big Data (Big Data)*, pages 4287–4292.

Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. 2018. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding.

Chau Do and Eric J. Pauwels. 2013. Using MathML to represent units of measurement for improved ontology alignment. *Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, 7961 LNAI:310–325.

Liran Einav and Jonathan Levin. 2014. The data revolution and economic analysis. *Innovation Policy and the Economy*, 14:1–24.

Luca Foppiano, Thaer M Dieb, Akira Suzuki, and Masashi Ishii. 2019a. Proposal for Automatic Extraction Framework of Superconductors Related Information from Scientific Literature Proposal for Automatic Extraction Framework of Superconductors Related Information from Scientific Literature. (June):0–5.

Luca Foppiano, Laurent Romary, Masashi Ishii, and Mikiko Tanifuji. 2019b. Automatic identification and normalisation of physical measurements in scientific literature. *Proceedings of the ACM Symposium on Document Engineering, DocEng 2019*, pages 0–4.

Akash Gangwar, Sabhay Jain, Shubham Sourav, and Ashutosh Modi. 2021. Counts @ IITK at SemEval-2021 Task 8 : SciBERT Based Entity And Semantic Relation Extraction For Scientific Data. In *Proceedings of the Fifteenth Workshop on Semantic Evaluation (SemEval-2021)*.

Abhijeet Gupta, Gemma Boleda, Marco Baroni, and Sebastian Padó. 2015. Distributional vectors encode referential attributes. *Conference Proceedings - EMNLP 2015: Conference on Empirical Methods in Natural Language Processing*, (September):12–21.

Tianyong Hao, Hongfang Liu, and Chunhua Weng. 2016. Valx: A system for extracting and structuring numeric lab test comparison statements from text. *Methods of information in medicine*, 55.

Aidan Hogan, Eva Blomqvist, Michael Cochez, Claudia d'Amato, Gerard de Melo, Claudio Gutierrez, José Emilio Labra Gayo, Sabrina Kirrane, Sebastian Neumaier, Axel Polleres, Roberto Navigli, Axel-Cyrille Ngonga Ngomo, Sabbir M. Rashid, Anisa Rula, Lukas Schmelzeisen, Juan Sequeda, Steffen Staab, and Antoine Zimmermann. 2021. Knowledge graphs.

Kyle Hundman and Chris A Maamann. 2017. Measurement Context Ex-traction from Text: Discovering Opportunities and Gaps in Earth Science. 8:pages.

Joint Committee for Guides in Metrology. 2012. *International vocabulary of metrology. Basic and general concepts and associated terms.*, 3rd ed edition.

Jocelyn Kaiser. 2018. Plan to replicate 50 high-impact cancer papers shrinks to just 18. *Science*.




**Tài liệu tham khảo**


Isabelle Augenstein, Mrinal Das, Sebastian Riedel, Lakshmi Vikraman, và Andrew McCallum. 2017. SemEval 2017 nhiệm vụ 10: ScienceIE - trích xuất các cụm từ khóa và quan hệ từ các ấn phẩm khoa học. Trong Kỷ yếu của Hội thảo Quốc tế lần thứ 11 về Đánh giá Ngữ nghĩa (SemEval-2017), trang 546–555, Vancouver, Canada. Hiệp hội Ngôn ngữ Học Máy Tính.

Andrei-marius Avram, George-eduard Zaharia, Dumitru-clementin Cercel, và Mihai Dascalu. 2021. UPB tại SemEval-2021 Nhiệm vụ 8: Trích xuất Thông tin Ngữ nghĩa về Đo lường dưới dạng Hỏi đáp Nhiều lượt. Trong Kỷ yếu của Hội thảo Lần thứ Mười lăm về Đánh giá Ngữ nghĩa (SemEval-2021), 2.

*Payam Barnaghi, Wei Wang, Lijun Dong và Chong-gang Wang. 2013. Một mô hình dữ liệu liên kết cho các luồng cảm biến ngữ nghĩa. Kỷ yếu - Hội nghị Quốc tế IEEE năm 2013 về Điện toán và Truyền thông Xanh và IEEE Internet of Things và IEEE Điện toán Vật lý và Xã hội, GreenCom-iThings-CPSCom 2013, trang 468–475.*

Iz Beltagy, Kyle Lo, và Arman Cohan. 2019. SciBERT: Một Mô Hình Ngôn Ngữ Được Tiền Huấn Luyện cho Văn Bản Khoa Học. trang 3613–3618.

*Melanie Bergmann, Mine B Tekman, và L. Gutow. 2017. LITTERBASE: Cổng trực tuyến về rác thải biển và vi nhựa cùng những tác động của chúng đối với đời sống biển, trang 106–107.*

Jiarun Cao, Yuejia Xiang, Yunyan Zhang, Zhiyuan Qi, và Xi Chen. 2021. CONNER: Một công cụ chiếu đếm và trích xuất đo lường cho diễn ngôn khoa học. Trong Kỷ yếu của Hội thảo lần thứ mười lăm về Đánh giá Ngữ nghĩa (SemEval-2021).

Dmitry Davidov và Ari Rappoport. 2010. Trích xuất và xấp xỉ các thuộc tính số từ Web. ACL 2010 - Hội nghị thường niên lần thứ 48 của Hiệp hội Ngôn ngữ học Máy tính, Kỷ yếu Hội nghị, (Tháng 7):1308–1317.

Adis Davletov, Denis Gordeev, Nikolay Arefyev, và Emil Davletov. 2021. LIORI tại SemEval-2021 Nhiệm vụ 8: Hỏi Transformer về các phép đo. Trong Kỷ yếu của Hội thảo thứ Mười lăm về Đánh giá Ngữ nghĩa (SemEval-2021).

Helena F. Deus, Corey A. Harper, Darin McBeath và Ron Daniel. 2017. Kết hợp so khớp mẫu với nhúng từ để trích xuất các biến thí nghiệm từ văn liệu khoa học. Hội nghị Quốc tế IEEE về Dữ liệu Lớn 2017 (Big Data), trang 4287–4292.

Jacob Devlin, Ming-Wei Chang, Kenton Lee, và Kristina Toutanova. 2018. BERT: Tiền huấn luyện các Transformer Hai Chiều Sâu để Hiểu Ngôn ngữ.

Chau Đỗ và Eric J. Pauwels. 2013. Sử dụng MathML để biểu diễn các đơn vị đo lường nhằm cải thiện sự căn chỉnh ontology. Lecture Notes in Computer Science (bao gồm các phân loạt Lecture Notes in Artificial Intelligence và Lecture Notes in Bioinformatics), 7961 LNAI:310–325.

Liran Einav và Jonathan Levin. 2014. Cuộc cách mạng dữ liệu và phân tích kinh tế. Chính sách Đổi mới và Kinh tế, 14:1–24.

Luca Foppiano, Thaer M Dieb, Akira Suzuki, và Masashi Ishii. 2019a. Đề xuất Khung Trích xuất Tự động Thông tin Liên quan đến Siêu dẫn từ Văn học Khoa học Đề xuất Khung Trích xuất Tự động Thông tin Liên quan đến Siêu dẫn từ Văn học Khoa học. (Tháng Sáu):0–5.

Luca Foppiano, Laurent Romary, Masashi Ishii và Mikiko Tanifuji. 2019b. Nhận dạng tự động và chuẩn hóa các đo lường vật lý trong tài liệu khoa học. Kỷ yếu Hội nghị chuyên đề ACM về Kỹ thuật Tài liệu, DocEng 2019, trang 0–4.

Akash Gangwar, Sabhay Jain, Shubham Sourav, và Ashutosh Modi. 2021. Counts @ IITK tại SemEval-2021 Task 8: Trích xuất Thực thể và Quan hệ Ngữ nghĩa dựa trên SciBERT cho Dữ liệu Khoa học. Trong Kỷ yếu của Hội thảo lần thứ mười lăm về Đánh giá Ngữ nghĩa (SemEval-2021).

Abhijeet Gupta, Gemma Boleda, Marco Baroni và Sebastian Pad´o. 2015. Các vectơ phân phối mã hóa thuộc tính tham chiếu. Kỷ yếu Hội nghị - EMNLP 2015: Hội nghị về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên, (Tháng Chín):12–21.

Tianyong Hao, Hongfang Liu, và Chunhua Weng. 2016. Valx: Một hệ thống để trích xuất và cấu trúc các câu so sánh kết quả xét nghiệm số từ văn bản. Phương pháp thông tin trong y học, 55.

Aidan Hogan, Eva Blomqvist, Michael Cochez, Claudia d'Amato, Gerard de Melo, Claudio Gutierrez, José Emilio Labra Gayo, Sabrina Kirrane, Sebastian Neumaier, Axel Polleres, Roberto Navigli, Axel-Cyrille Ngonga Ngomo, Sabbir M. Rashid, Anisa Rula, Lukas Schmelzeisen, Juan Sequeda, Steffen Staab, và Antoine Zimmermann. 2021. Đồ thị tri t hức.

Kyle Hundman và Chris A Maamann. 2017. Trích xuất Ngữ cảnh Đo lường từ Văn bản: Khám phá Cơ hội và Khoảng trống trong Khoa học Trái đất. 8:trang.

*Ủy ban Chung về Hướng dẫn trong Đo lường. 2012. Từ vựng quốc tế về đo lường. Các khái niệm cơ bản và chung và các thuật ngữ liên quan., ấn bản thứ 3.*

Jocelyn Kaiser. 2018. Kế hoạch tái hiện 50 bài báo về ung thư có tác động lớn giảm xuống chỉ còn 18. Science.

Ramar Kaladevi, Gurunathan Geetha, and P. Narayanasamy. 2016. Ontological based interoperability and integration framework for heterogeneous weather systems. *Revista Tecnica de la Facultad de Ingenieria Universidad del Zulia*, 39(1):185–192.

Neel Karia, Ayush Kaushal, and Faraaz Rahman Mallick. 2021. KGP at SemEval-2021 Task 8 : Leveraging Multi-Staged Language Models for Extracting Measurements, their Attributes and Relations. In *Proceedings of the Fifteenth Workshop on Semantic Evaluation (SemEval-2021)*.

Natalia Konstantinova. 2014. Review of relation extraction methods: What is new out there? *Communications in Computer and Information Science*, 436:15–28.

Bhushan Kotnis and Alberto Garcıa-Duran. 2019. Learning Numerical Attributes in Knowledge Bases. *Automated Knowledge Base Construction (2019)*.

Nihatha Lathiff, Pavel Khloponin, and Sabine Bergler. 2021. CLaC-np at SemEval-2021 Task 8 : Dependency DGCNN. In *Proceedings of the Fifteenth Workshop on Semantic Evaluation (SemEval-2021)*.

Jinhyuk Lee, Wonjin Yoon, Sungdong Kim, Donghyeon Kim, Sunkyu Kim, Chan Ho So, and Jaewoo Kang. 2019. BioBERT: a pre-trained biomedical language representation model for biomedical text mining. pages 1–8.

Patrick Liu, Niveditha S Iyer, Erik Rozi, and Ethan A Chi. 2021. Stanford MLab at SemEval-2021 Task 8 : 48 Hours Is All You Need. In *Proceedings of the Fifteenth Workshop on Semantic Evaluation (SemEval-2021)*.

Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, and Veselin Stoyanov. 2019. RoBERTa: A robustly optimized BERT pretraining approach. *arXiv*, (1).

Pranav Rajpurkar, Jian Zhang, Konstantin Lopyrev, and Percy Liang. 2016. SQuAD: 100,000+ Questions for Machine Comprehension of Text. (ii).

H. Rijgersberg, M. Wigham, and J. L. Top. 2011. How semantics can improve engineering processes: A case of units of measure and quantities. *Advanced Engineering Informatics*, 25(2):276–287.

Hajo Rijgersberg, Mark Van Assem, and Jan Top. 2013. Ontology of units of measure and related concepts. *Semantic Web*, 4(1):3–13.

J. Sprague. 2006. The Zebrafish Information Network: the zebrafish model organism database. *Nucleic Acids Research*, 34(90001):D581–D585.

Markus D. Steinberg, Sirko Schindler, and Jan Martin Keil. 2017. Use cases and suitability metrics for unit ontologies. *Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, 10161 LNCS:40–54.

Benjamin Therien, Parsa Bagherzadeh, and Sabine Bergler. 2021. CLaC-BP at SemEval-2021 Task 8 : SciBERT Plus Rules for MeasEval. In *Proceedings of the Fifteenth Workshop on Semantic Evaluation (SemEval-2021)*.

Shreejoy J. Tripathy, Judith Savitskaya, Shawn D. Burton, Nathaniel N. Urban, and Richard C. Gerkin. 2014. NeuroElectro: A window to the world's neuron electrophysiology data. *Frontiers in Neuroinformatics*, 8(APR):1–11.

Amir Pouran Ben Veyseh, Franck Dernoncourt, and Thien Huu Nguyen. 2021. DPR at SemEval-2021 Task 8: Dynamic Path Reasoning for Measurement Relation Extraction. In *Proceedings of the Fifteenth Workshop on Semantic Evaluation (SemEval-2021)*.

Oriol Vinyals, Meire Fortunato, and Navdeep Jaitly. 2015. Pointer networks. *Advances in Neural Information Processing Systems*, 2015-January:2692–2700.

Ikuya Yamada, Akari Asai, Hiroyuki Shindo, Hideaki Takeda, and Yuji Matsumoto. 2020. LUKE: Deep contextualized entity representations with entity-aware self-attention. *arXiv*, pages 6442–6454.



Ramar Kaladevi, Gurunathan Geetha, và P. Narayanasamy. 2016. Khung tương tác và tích hợp dựa trên ontology cho các hệ thống thời tiết đa dạng. Revista Tecnica de la Facultad de Ingenieria Universidad del Zulia, 39(1):185–192.

Neel Karia, Ayush Kaushal, và Faraaz Rahman Mallick. 2021. KGP tại SemEval-2021 Task 8: Tận dụng các mô hình ngôn ngữ đa giai đoạn để trích xuất các phép đo, thuộc tính của chúng và các quan hệ. Trong Kỷ yếu của Hội thảo lần thứ mười lăm về Đánh giá Ngữ nghĩa (SemEval-2021). Natalia Konstantinova. 2014. Tổng quan về các phương pháp trích xuất quan hệ: Có gì mới ngoài kia? Communications in Computer and Information Science, 436:15–28. Bhushan Kotnis và Alberto García-Durán. 2019. Học các thuộc tính số trong cơ s ở tri thức. Xây dựng cơ sở tri thức tự động (2019). Nihatha Lathiff, Pavel Khloponin, và Sabine Bergler. 2021. CLaC-np tại SemEval-2021 Task 8: Dependency DGCNN. Trong Kỷ yếu của Hội thảo lần thứ mười lă m về Đánh giá Ngữ nghĩa (SemEval-2021). Jinhyuk Lee, Wonjin Yoon, Sungdong Kim, Donghyeon Kim, Sunkyu Kim, Chan Ho So, và Jaewoo Kang. 2019. BioBERT: một mô hình đại diện ngôn ngữ y sinh đã được tiền huấn luyện cho khai thác văn bản y sinh. trang 1–8. Patrick Liu, Niveditha S Iy

*các hệ thống tri thức. Giáo trình về Khoa học Máy tính (bao gồm các tiểu loạt Giáo trình về Trí tuệ Nhân tạo và Giáo trình về Tin sinh học), 10161 LNCS:40–54.*

Benjamin Therien, Parsa Bagherzadeh, và Sabine Bergler. 2021. CLaC-BP tại SemEval-2021 Task 8: SciBERT Cộng Quy tắc cho MeasEval. Trong Kỷ yếu Hội thảo thứ Mười lăm về Đánh giá Ngữ nghĩa (SemEval-2021).

Shreejoy J. Tripathy, Judith Savitskaya, Shawn D. Burton, Nathaniel N. Urban, và Richard C. Gerkin. 2014. NeuroElectro: Một cửa sổ đến dữ liệu điện sinh học neuron trên thế giới. Frontiers in Neuroinformatics, 8(APR):1–11. Amir Pouran Ben Veyseh, Franck Dernoncourt, và Thien Huu Nguyen. 2021. DPR tại SemEval-2021 Task 8: Lý luận đường dẫn động cho trích xuất mối quan hệ đo lường. Trong Kỷ yếu của Hội thảo thứ mười lăm về Đánh giá Ngữ nghĩa (SemEval-2021). Oriol Vinyals, Meire Fortunato, và Navdeep Jaitly. 2015. Mạng con trỏ. Advances in Neural Information Processing Syste ms, 2015-January:2692–2700. Ikuya Yamada, Akari Asai, Hiroyuki Shindo, Hideaki Takeda, và Yuji Matsumoto. 2020. LUKE: Biểu diễn thực thể ngữ cảnh sâu với chú ý tự nhận biết thực thể. arXiv, trang 6442–6454.