Get Your Vitamin C!
Robust Fact Verification with Contrastive Evidence

Tal Schuster **Adam Fisch** **Regina Barzilay**
Computer Science and Artificial Intelligence Laboratory
Massachusetts Institute of Technology
{tals,fisch,regina}@csail.mit.edu

Abstract

Typical fact verification models use retrieved written evidence to verify claims. Evidence sources, however, often change over time as more information is gathered and revised. In order to adapt, models must be sensitive to subtle differences in supporting evidence. We present VITAMINC, a benchmark infused with challenging cases that require fact verification models to discern and adjust to slight factual changes. We collect over 100,000 Wikipedia revisions that modify an underlying fact, and leverage these revisions, together with additional synthetically constructed ones, to create a total of over 400,000 claim-evidence pairs. Unlike previous resources, the examples in VITAMINC are *contrastive*, i.e., they contain evidence pairs that are nearly identical in language and content, with the exception that one supports a given claim while the other does not. We show that training using this design increases robustness—improving accuracy by 10% on adversarial fact verification and 6% on adversarial natural language inference (NLI). Moreover, the structure of VITAMINC leads us to define additional tasks for fact-checking resources: tagging relevant words in the evidence for verifying the claim, identifying factual revisions, and providing automatic edits via factually consistent text generation.[1]

1 Introduction

Determining the truthfulness of factual claims by comparing them to textual sources of evidence has received intense research interest in recent years. An underlying, but often overlooked, challenge for this paradigm, however, is the dynamic nature of today's written resources. An extraordinary amount of new information becomes available daily; as a result, many consequential facts are established, changed, or added to over time. We argue that the quality of fact verification systems should be measured by how well they adjust to new evidence. In this way, we seek to advance fact verification by requiring that models remain reliable and robust to the change present in practical settings.

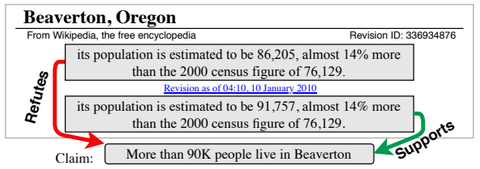


Figure 1: In VITAMINC, we focus on Wikipedia revisions in which the *factual content* changes. This example revision now *supports* an initially *refuted* claim.

To this end, we focus on fact verification with *contrastive evidence*. That is, we infuse the standard fact verification paradigm with challenging cases that require models to be sensitive to factual changes in their presented evidence (hereon referred to interchangeably as "context"). We present VITAMINC,[2] a new large-scale fact verification dataset that is based on factual revisions to Wikipedia. The key concept is exemplified in Figure 1: there a factual revision yields a contrastive pair of contexts that are nearly identical in language and content—except that one context refutes the given claim, while the other supports it.

This type of contrastive structure exposes existing deficiencies in model behavior. To illustrate this, we train a classifier on the popular FEVER fact verification dataset (Thorne et al., 2018) and evaluate it on contrastive claim-evidence pairs. We find that the model flips its prediction from the original verdict on only 56% of the contrastive cases. When examples from VITAMINC are included during training, however, the model's sensitivity increases, flipping on 86% of contrastive cases.

Such context-sensitive inference has two main benefits. First, it ensures that the model consid-

[1]The VITAMINC dataset and our models are available at: https://github.com/TalSchuster/VitaminC

[2]Etymology of VITAMINC: *Contrastive* evidence keeps fact verification models robust and healthy, hence "Vitamin C."

Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, pages 624–643
June 6–11, 2021. ©2021 Association for Computational Linguistics

Hãy Nhận Vitamin C Của Bạn! Xác Minh Thông Tin Vững Chắc với Bằng Chứng Đối Chiếu

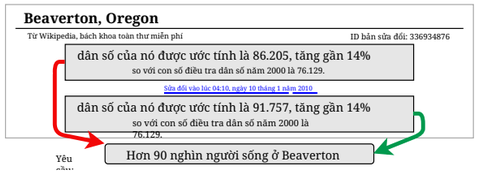
Tal Schuster AdamFisch ReginaBarzilay Phòng
Thí nghiệm Khoa học Máy tính và Trí tuệ Nhân tạo
Viện Công nghệ Massachusetts
{tals,fisch,regina}@csail.mit.edu

Tóm tắt

Các mô hình xác minh sự thật điển hình sử dụng bằng chứng viết được truy xuất để xác minh các tuyên bố. Tuy nhiên, các nguồn bằng chứng thường thay đổi theo thời gian khi có thêm thông tin được thu thập và chỉnh sửa. Để thích nghi, các mô hình phải nhạy cảm với những khác biệt tinh tế trong bằng chứng hỗ trợ. Chúng tôi giới thiệu VITAMINC, một chuẩn thử nghiệm chứa các trường hợp thách thức yêu cầu các mô hình xác minh sự thật phân biệt và điều chỉnh theo những thay đổi thực tế nhỏ. Chúng tôi thu thập hơn 100.000 lần chỉnh sửa Wikipedia làm thay đổi một thực tế cơ bản, và sử dụng các lần chỉnh sửa này, cùng với các lần được tạo ra một cách tổng hợp bổ sung, để tạo tổng cộng hơn 400.000 cặp t uyên bố-bằng chứng. Khác với các nguồn tài nguyên trước đây, các ví dụ trong VITAMINC mang tính tương phản, tức là chúng chứa các cặp bằng chứng gần như giống hệt về ngôn ngữ và nội dung, ngoại tr ừ việc một cặp hỗ trợ một tuyên bố cụ thể trong khi cặp còn lại không. Chúng tôi cho thấy rằng việc huấn luyện sử dụng thiết kế này tăng cường độ bền—nâng cao độ chính xác lên 10% trong xác minh sự thật đối kháng và 6%

1 Giới thiệu

Xác định tính chân thực của các tuyên bố thực tế bằng cách so sánh chúng với các nguồn văn bản làm chứng đã nhận được sự quan tâm nghiên cứu sâu sắc trong những năm gần đây. Tuy nhiên, một thách thức cơ bản nhưng thường bị bỏ qua đối với mô hình này là bản chất động của các nguồn tài nguyên viết hiện nay. Một lượng thông tin mới khổng lồ được cung cấp hàng ngày; kết quả là, nhiều sự kiện quan trọng được thiết lập, thay đổi hoặc bổ sung theo thời gian. Chúng tôi cho rằng chất lượng của các hệ thống xác minh sự kiện nên được



Hình 1: Trong VITAMINC, chúng tôi tập trung vào các lần sửa đổi Wikipedia mà trong đó nội dung thực tế thay đổi. Ví dụ về lần sửa đổi này bây giờ hỗ trợ một tuyên bố ban đầu bị bác bỏ.

được đo bằng mức độ họ điều chỉnh tốt như thế nào trước bằng chứng mới. Bằng cách này, chúng tôi tìm cách thúc đẩy việc xác minh sự thật bằng cách yêu cầu các mô hình duy trì độ tin cậy và vững chắc trước những thay đổi hiện diện trong các bối cảnh thực tiễn.

Để đạt được mục tiêu này, chúng tôi tập trung vào việc xác minh sự thật với bằng chứng đối c hiếu. Nghĩa là, chúng tôi kết hợp mô hình xác minh sự thật tiêu chuẩn với các trường hợp thách thức đòi hỏi các mô hình phải nhạy cảm với các thay đổi về sự thật trong bằng chứng được trình bày (sau đây được gọi thay thế cho nhau là "ngữ cảnh"). Chúng tôi giới thiệu VITAMINC,[2] —một tập dữ liệu xác minh sự thật quy mô lớn mới, dựa trên các sửa đổi sự thật trên Wikipedia. Khái niệm c hính được minh họa trong Hình 1: tại đó, một sửa đổi sự thật tạo ra một cặp ngữ cảnh đối chiếu gần như giống hệt về ngôn ngữ và nội dung—ngoại trừ việc một ngữ cảnh phản bác tuyên bố đã đưa ra, trong khi ngữ cảnh kia ủng hộ nó.

Loại cấu trúc so sánh này làm lộ ra những thiếu s ót hiện có trong hành vi của mô hình. Để minh họa điều này, chúng tôi đào tạo một bộ phân loại trên tập dữ liệu xác minh sự thật phổ biến FEVER (Thorne et al., 2018) và đánh giá nó trên các cặp tuyên bố-bằng chứng đối chiếu. Chúng tôi nhận thấy rằng mô hình c hỉ thay đổi dự đoán từ phán quyết gốc trong 56% các trường hợp đối chiếu. Tuy nhiên, khi các ví dụ từ VITAMINC được bao gồm trong quá trình đào tạo, độ nhạy của mô hình tăng lên, thay đổi dự đoán ở 86% các trường hợp đối chiếu.

Suy luận nhạy cảm với ngữ cảnh như vậy có hai lợi ích chính. Thứ nhất, nó đảm bảo rằng mô hình xem xét

[1]Bộ dữ liệu VITAMINC và các mô hình của chúng tôi có sẵn tại: https://github.com/TalSchuster/VitaminC

[2]Nguồn gốc từ VITAMINC: Bằng chứng đối chiếu giữ cho các mô hình xác minh sự thật vững chắc và khỏe mạnh, do đó gọi là "Vitamin C."

Tài liệu hội nghị của Hội nghị năm 2021 của Chi nhánh Bắc Mỹ thuộc Hiệp hội Ngôn ngữ học Máy tính: Công nghệ Ngôn ngữ Con người, trang 624–643, từ ngày 6–11 tháng 6 năm 2021. *©2021 Hiệp hội Ngôn ngữ học Máy tính*

ers the provided evidence rather than relying on built-in static knowledge, such as that obtained via language model pre-training (Petroni et al., 2019; Roberts et al., 2020). This is particularly important for scenarios in which the source of truth is mutable (e.g., the current US president, or new declarations as in Figure 1). Second, this setting discourages certain biases and idiosyncrasies—such as exploiting differences in how true vs. false claims are posed—that are common in similar crowd-sourced datasets (Poliak et al., 2018; Schuster et al., 2019). Indeed, we show that augmenting both fact verification models and NLI models with VITAMINC data improves their robustness to adversarial inputs.

Furthermore, our emphasis on contrastive contexts allows us to expand on the scope of commonly considered tasks. Most of the fact verification literature focuses on resolving claims to be true or false (Popat et al., 2018; Thorne and Vlachos, 2018; Wang, 2017). The surrounding ecosystem, however, includes additional challenges, some of which we explore here: Documents such as Wikipedia articles are updated frequently; which edits represent factual changes? For a given claim and (refuting or supporting) evidence pair, which words or phrases in the evidence are most relevant? If we know that a certain claim is true, can we modify an out-dated document to be consistent with it? We show that the unique structure of our VITAMINC dataset can be leveraged to provide both supervised and distantly supervised data for these new questions.

Our key contributions are as follows:

1. We pose a contrastive fact verification paradigm that requires sensitivity to changes in data;
2. We introduce VITAMINC, a new large-scale dataset that supports this paradigm;
3. We demonstrate that training on VITAMINC leads to better performance on standard tasks;
4. We show how VITAMINC opens the door to additional research directions in fact verification.

2 Related Work

Fact Verification. The FEVER dataset (Thorne et al., 2018) fueled the development of many fact-checking models (e.g., see Hanselowski et al., 2018; Nie et al., 2019a,b; Yoneda et al., 2018, *inter alia*). The claim creation process, however, required crowd-workers to write claims related to Wikipedia articles, and was found to engender biases that allow an evidence-agnostic model to achieve unexpectedly high performance (Schuster et al., 2019). Other recent datasets cover verification against tables (Chen et al., 2020), relational databases (Jo et al., 2019), Wikipedia references (Sathe et al., 2020), multiple articles (Jiang et al., 2020), and search snippets (Augenstein et al., 2019). These resources all assume static ground truths. In contrast, VITAMINC compares objective claims to a dynamic source of truth, and requires models to change their verdicts accordingly.

Annotation Bias. Annotation artifacts are common in many NLP datasets, and affect performance on adversarial and contrastive examples (Gardner et al., 2020; Ribeiro et al., 2020; Ross et al., 2020). Sentence-pair inference tasks such as fact verification (Paul Panenghat et al., 2020; Schuster et al., 2019) and NLI (Gururangan et al., 2018; McCoy et al., 2019; Poliak et al., 2018; Tsuchiya, 2018) are no exception. Alleviating this bias requires either modeling solutions (Karimi Mahabadi et al., 2020; Pratapa et al., 2020; Shah et al., 2020; Thorne and Vlachos, 2020; Utama et al., 2020b), which have limited effectiveness (Utama et al., 2020a), or adversarially removing troublesome training examples (Bras et al., 2020) or manually collecting new ones (Nie et al., 2020; Thorne et al., 2019a), which is model specific. Instead, our dataset design avoids single-sentence artifacts and provides model-agnostic challenging examples that increase the robustness of trained models.

Explainability. Current fact verification datasets provide sentence-level rationales (DeYoung et al., 2020; Petroni et al., 2020) but do not enforce the model's verdict to rely on them—leading to a potential discrepancy. VITAMINC ensures the verdict is conditioned on the retrieved evidence. Moreover, we use the revision history as distant supervision for word-level rationales, allowing for finer-grained explanations (Camburu et al., 2018; Lei et al., 2016; Portelli et al., 2020; Thorne et al., 2019b).

Factually Consistent Generation. Generating texts that match given facts is a known challenge (Fan et al., 2020; Kryscinski et al., 2020; Lewis et al., 2020b; Parikh et al., 2020; Shah et al., 2020; Tian et al., 2020) as language models tend to degenerate and hallucinate (Holtzman et al., 2020; Schuster et al., 2020; Zhou et al., 2020). Moreover, evaluation is non-trivial, and usually manual. VITAMINC includes supervised data for training sequence-to-sequence models, and provides auto-

dựa trên bằng chứng được cung cấp thay vì dựa vào kiến thức tĩnh tích hợp sẵn, chẳng hạn như kiến thức thu được qua huấn luyện trước mô hình ngôn ngữ (Petroni et al., 2019; Roberts et al., 2020). Điều này đặc biệt quan trọng cho các tình huống mà nguồn sự thật có thể thay đổi (ví dụ, tổng thống Mỹ hiện tại, hoặc các tuyên bố mới như trong Hình 1). Thứ hai, thiết lập này ngăn chặn một số thiên kiến và đặc thù nhất định—chẳng hạn như khai thác sự khác biệt trong cách các khẳng định đúng và sai được đưa ra—mà thường gặp trong các tập dữ liệu được tạo bởi đám đông tương tự (Poliak et al., 2018; Schuster et al., 2019). Thực sự, chúng tôi cho thấy rằng việc bổ sung cả mô hình xác minh sự thật và mô hình NLI với dữ liệu VITAMINC cải thiện độ bền của chúng đối với các đầu vào mang tính đối kháng.

Hơn nữa, việc nhấn mạnh của chúng tôi vào các ngữ cảnh tương phản cho phép chúng tôi mở rộng phạm vi các nhiệm vụ thường được xem xét. Hầu hết các nghiên cứu về xác minh sự thật tập trung vào việc giải quyết các tuyên bố là đúng hay sai (Popat et al., 2018; Thorne và Vlachos, 2018; Wang, 2017). Tuy nhiên, hệ sinh thái xung quanh bao gồm các thách thức bổ sung, một số trong đó chúng tôi khám phá ở đây: Các tài liệu như các bài viết trên Wikipedia thường được cập nhật; những chỉnh sửa nào đại diện cho các thay đổi thực tế? Đối với một cặp tuyên bố và bằng chứng (bác bỏ hoặc hỗ trợ) nhất định, những từ hoặc cụm từ nào trong bằng chứng là có liên quan nhất? Nếu chúng ta biết rằng một tuyên bố nhất định là đúng, chúng ta có thể chỉnh sửa một tài liệu lỗi thời để phù hợp với nó không? Chúng tôi chỉ ra rằng cấu trúc độc đáo của bộ dữ liệu VITAMINC có thể được tận dụng để cung cấp cả dữ liệu có giám sát và dữ liệu có giám sát xa cho các câu hỏi mới này.

Những đóng góp chính của chúng tôi như sa
u:

1. Chúng tôi đề xuất một phương pháp kiểm chứng sự thật đối chiếu yêu cầu nhạy cảm với các thay đổi trong dữ liệu; 2. Chúng tôi giới thiệu VITAMINC, một bộ dữ liệu quy mô lớn mới hỗ trợ phương pháp này; 3. Chúng tôi chứng minh rằng việc huấn luyện trên VITAMINC dẫn đến hiệu suất tốt hơn trên các nhiệm vụ tiêu chuẩn; 4. Chúng tôi chỉ ra cách VITAMINC mở ra cánh cửa cho các hướng nghiên cứu bổ sung trong kiểm chứng sự thật.

2 Công trình liên quan

Xác minh sự thật. Bộ dữ liệu FEVER (Thorne et al., 2018) đã thúc đẩy sự phát triển của nhiều mô hình kiểm tra sự thật (ví dụ, xem Hanselowski et al., 2018; Nie et al., 2019a,b; Yoneda et al., 2018, và các nguồn khác). Tuy nhiên, quá trình tạo lập các tuyên bố yêu cầu người lao động từ đám đông viết các tuyên bố liên quan đến các bài viết trên Wikipedia, và đã được phát hiện là tạo ra các thiên kiến khiến một mô hình không dựa vào bằng chứng có thể

đạt hiệu suất cao bất ngờ (Schuster và cộng sự, 2019). Các bộ dữ liệu gần đây khác bao gồm xác minh chống lại bảng (Chen và cộng sự, 2020), cơ sở dữ liệu quan hệ (Jo và cộng sự, 2019), tham chiếu Wikipedia (Sathe và cộng sự, 2020), nhiều bài viết (Jiang và cộng sự, 2020), và các đoạn trích tìm kiếm (Augenstein và cộng sự, 2019). Tất cả các nguồn tài nguyên này đều giả định sự thật cơ bản là tĩnh. Ngược lại, VITAMINC so sánh các tuyên bố khách quan với một nguồn sự thật động, và yêu cầu các mô hình thay đổi phán quyết của chúng tương ứng.

Thiên vị chú thích. Các hiện tượng sai lệch do chú thích phổ biến trong nhiều tập dữ liệu NLP và ảnh hưởng đến hiệu suất trên các ví dụ đối kháng và tương phản (Gardner et al., 2020; Ribeiro et al., 2020; Ross et al., 2020). Các nhiệm vụ suy luận cặp câu như xác minh sự thật (Paul Panenghat et al., 2020; Schuster et al., 2019) và NLI (Gururangan et al., 2018; McCoy et al., 2019; Poliak et al., 2018; Tsuchiya, 2018) cũng không phải là ngoại lệ. Giảm thiểu thiên vị này đòi hỏi các giải pháp mô hình hóa (Karimi Mahabadi et al., 2020; Pratapa et al., 2020; Shah et al., 2020; Thorne và Vlachos, 2020; Utama et al., 2020b), nhưng hiệu quả có hạn (Utama et al., 2020a), hoặc loại bỏ một cách đối kháng các ví dụ huấn luyện gây rắc rối (Bras et al., 2020) hoặc tự thu thập các ví dụ mới (Nie et al., 2020; Thorne et al., 2019a), điều này phụ thuộc vào mô hình. Thay vào đó, thiết kế tập dữ liệu của chúng tôi tránh các sai lệch từ câu đơn và cung cấp các ví dụ thử thách không phụ thuộc mô hình, giúp tăng độ bền vững của các mô hình đã được huấn luyện.

Khả năng giải thích. Các bộ dữ liệu xác thực thực tế hiện tại cung cấp lý do ở mức câu (DeYoung et al., 2020; Petroni et al., 2020) nhưng không bắt buộc phán quyết của mô hình phải dựa vào chúng—dẫn đến khả năng có sự không nhất quán. VITAMINC đảm bảo rằng phán quyết được điều kiện dựa trên bằng chứng được truy xuất. Hơn nữa, chúng tôi sử dụng lịch sử chỉnh sửa như một hình thức giám sát gián tiếp cho lý do ở mức từ, cho phép các giải t hích tinh vi hơn (Camburu et al., 2018; Lei et al., 2016; Portelli et al., 2020; Thorne et al., 2019b).

Sinh văn bản phù hợp với thực tế. Việc tạo ra các văn bản phù hợp với các sự kiện đã cho là một thách thức đã được biết đến (Fan et al., 2020; Kryscinski et al., 2020; Lewis et al., 2020b; Parikh et al., 2020; Shah et al., 2020; Tian et al., 2020) vì các mô hình ngôn ngữ có xu hướng suy thoái và tạo ra các thông tin sai lệch (Holtzman et al., 2020; Schuster et al., 2020; Zhou et al., 2020). Hơn nữa, việc đánh giá không phải là điều đơn giản, và thường được thực hiện thủ công. VITAMINC bao gồm dữ liệu có giám sát để huấn luyện các mô hình chuỗi-thành-chuỗi, và cung cấp tự động-

matic evaluation via the fact verification classifier.

3 The VITAMINC Dataset

VITAMINC (abbreviated VitC) is based on revisions to English Wikipedia. Wikipedia has become a comprehensive online resource that is rigorously maintained by a large and active community (Benjakob and Harrison, 2019). While adversaries do try to insert disinformation, popular pages are usually quickly corrected (Kumar et al., 2016). Furthermore, Wikipedia's policies dictate that its content should be written from a neutral perspective—or should otherwise objectively state all points of view.[3] These properties make Wikipedia a suitable source of evidence for fact verification models. In the following section, we outline our process for mining factual revisions from Wikipedia.

3.1 Collecting Factual Revisions

We collected the 5K most-viewed English Wikipedia articles[4] as of January 2020, along with any additional articles referred from them (on average 100 per article). We also included all articles from the FEVER dataset (Thorne et al., 2018). For each article, we retrieved up to 500 of its most recent revisions. In May 2020, we added all COVID-19 related articles[5] and all of their 41K revisions at the time. Combined together, this resulted in a total of ∼200 million revisions. For each revision, we identified all of the modified sentences and stored two versions: (1) before, and (2) after the edit.

In our task, we are only interested in edits made with an intent to introduce a *factual* modification—i.e., a change for which one can make a claim that is supported by one sentence, but not by the other.[6] To expedite annotation, we trained a BERT classifier (Devlin et al., 2019) on a small labeled set of revised sentences determined to be factual (Yang et al., 2017), and used this model to select the top 305K edited sentences from the corpus for manual annotation. Trained human annotators were then presented with the sentence pairs, and were asked to mark the ones that indeed represented a factual change. Sentences lacking self-contained context were filtered (e.g., short expressions from tables or bulleted lists). Example annotations are presented in Table 1. Note that these annotations can also be recursively recycled for re-training the automated BERT classifier in the future to expand the corpus further (we also introduce this as a task, see §4.1).

3.2 Writing Claims

The factual Wikipedia revisions guide us in creating challenging claims for fact verification. For each revision, annotators were asked to write two symmetric claims related to the same edit:

1. The first should be supported by the *original* sentence and refuted by the *revised* sentence;
2. The second should be supported by the *revised* sentence and refuted by the *original* sentence.

When an explicit contradiction was not possible, a *not enough information* (NEI) relation was used. A group of 70 native English speakers[7] wrote and reviewed claims. During the annotation period, annotations were delivered in weekly batches, from which we examined random samples to provide feedback and request corrections. Annotators were instructed to write short and self-contained claims. Furthermore, annotators were instructed to avoid copying exact phrases and values when possible, in order to avoid a bias for substantially higher word overlap in supporting pairs over refuting pairs. For example, rather than stating, "*there are $\underline{x}$ confirmed cases of coronavirus in the US*", one can write "*there are $\underline{\text{more than } z}$ confirmed cases of coronavirus in the US*", which is supported if $x > z$ and refuted otherwise. For revisions that only add new information or that remove outdated facts without replacing them, annotators wrote a single claim.

3.3 Adding Synthetic Revisions

Naturally, the real Wikipedia revisions we collect mostly describe facts that frequently change over time, or that are prone to mistakes and corrections (such as quantitative values, see Appendix A.1) (Faruqui et al., 2018; Yang et al., 2017). Sensitivity to contrastive contexts, however, is desirable behavior for any claim. This can both ensure consistency with external sources of truth, and improve the model's faithfulness via connecting the verdict with a specific evidence (Jacovi and Goldberg, 2020; Ross et al., 2020). For example, we require the model to not only classify the claim "*Tom Hanks was honored by a president*" as true, but to also change its verdict to false if paired with a (fictional) contrasting evidence. As a result, we can verify that the model prioritizes sentence-pair inference over

[3] https://bit.ly/Wiki_Neutral_POV
[4] https://bit.ly/Wiki_popular_pages
[5] https://wikimediafoundation.org/covid19
[6] Many edits only reflect grammatical corrections, paraphrasing, or "Wikification" (text formatting/page linking).
[7] We sourced our annotators through TransPerfect.

đánh giá matic thông qua phân loại kiểm chứng sự thật er.

3 Bộ dữ liệu VITAMINC

VITAMINC (viết tắt là VitC) dựa trên các sửa đổi từ Wikipedia tiếng Anh. Wikipedia đã trở thành một nguồn tài nguyên trực tuyến toàn diện được duy trì nghiêm ngặt bởi một cộng đồng lớn và năng động (Benjakob và Harrison, 2019). Trong khi các đối thủ cố gắng chèn thông tin sai lệch, các trang phổ biến thường được sửa chữa nhanh chóng (Kumar và cộng sự, 2016). Hơn nữa, các chính sách của Wikipedia quy định rằng nội dung của nó nên được viết từ quan điểm trung lập—hoặc phải nêu khách quan tất cả các quan điểm. Các đặc điểm này làm cho Wikipedia trở thành một nguồn bằng chứng phù hợp cho các mô hình xác minh sự thật. Trong phần sau, chúng tôi sẽ trình bày quy trình khai thác các sửa đổi thực tế từ Wikipedia.

3.1 Thu thập các Sửa đổi Thực tế

Chúng tôi đã thu thập 5.000 bài viết tiếng Anh được xem nhiều nhất trên Wikipedia[4] tính đến tháng 1 nă m 2020, cùng với bất kỳ bài viết bổ sung nào được t ham chiếu từ chúng (trung bình 100 bài viết một bài). Chúng tôi cũng bao gồm tất cả các bài viết từ tập dữ liệu FEVER (Thorne và cộng sự, 2018). Đối với mỗi bài viết, chúng tôi đã truy xuất tối đa 500 lần chỉnh sửa gần đây nhất của nó. Vào tháng 5 năm 2020, chúng tôi đã thêm tất cả các bài viết liên quan đến COVID-19[5] và tất cả 41.000 lần chỉnh sửa của chúng vào thời điểm đó. Kết hợp lại, điều này dẫn đến tổng cộng ∼200 triệu lần chỉnh sửa. Đối với mỗi lần chỉnh sửa, chúng tôi xác định tất cả các câu đã được chỉnh sửa và lưu trữ hai phiên bản: (1) trước khi chỉnh sửa, và (2) sau khi chỉnh sửa.

Trong nhiệm vụ của chúng tôi, chúng tôi chỉ quan tâm đến các chỉnh sửa được thực hiện với ý định giới thiệu một sự thay đổi thực tế — tức là, một thay đổi mà người ta có thể đưa ra lập luận rằng nó được hỗ trợ bởi một câu, nhưng không p hải bởi câu kia. Để tăng tốc việc chú thích, chúng tôi đã huấn luyện một bộ phân loại BERT (Devlin et al., 2019) trên một tập nhỏ các câu đã được gán nhãn là thực tế (Yang et al., 2017), và sử dụng mô hình này để chọn ra 305.000 câu đã chỉnh sửa hàng đầu từ tập dữ liệu cho việc chú thích thủ công. Các nhà c hú thích người được huấn luyện sau đó được trình bày với các cặp câu, và được yêu cầu đánh dấu những cặp câu thực sự đại diện cho sự thay đổi t hực tế. Các câu thiếu ngữ cảnh tự chứa đã bị lọc bỏ (ví dụ: các biểu thức ngắn từ bảng hoặc danh sách gạch đầu dòng). Ví dụ về chú thích được trình bày trong Bảng 1. Lưu ý rằng các chú thích này cũng có thể được được tái chế theo đệ quy để huấn luyện lại bộ phân loại BERT tự động trong tương lai nhằm mở rộng thêm kho ngữ liệu (chúng tôi cũng giới thiệu điều này như một nhiệm vụ, xem §4.1).

3.2 Viết các yêu cầu

Các bản chỉnh sửa thực tế trên Wikipedia hướng dẫn chúng tôi trong việc tạo ra các tuyên bố thách thức để xác minh sự thật. Đối với mỗi lần chỉnh sửa, các người chú thích được yêu cầu viết hai tuyên bố đối xứng liên quan đến cùng một chỉnh sửa:

1. Câu đầu tiên nên được hỗ trợ bởi câu gốc và bị bác bỏ bởi câu sửa đổi; 2. Câu thứ hai nên được hỗ trợ bởi câu sửa đổi và bị bác bỏ bởi câu gốc.

Khi một mâu thuẫn rõ ràng không khả thi, một mối quan hệ không đủ thông tin (NEI) đã được sử dụng. Một nhóm gồm 70 người bản ngữ tiếng Anh[7] đã viết và xem xét các tuyên bố. Trong t hời gian chú thích, các chú thích được gửi theo l ô hàng tuần, từ đó chúng tôi kiểm tra các mẫu ngẫu nhiên để cung cấp phản hồi và yêu cầu chỉnh sửa. Người chú thích được hướng dẫn viết các tuyên bố ngắn gọn và độc lập. Hơn nữa, người chú thích được hướng dẫn tránh sao chép chính xác các cụm từ và giá trị khi có thể, nhằm tránh thiên vị cho việc trùng lặp từ cao hơn đáng kể trong các cặp ủng hộ so với các cặp phản bác. Ví dụ, thay vì nói, "có x ca mắc coronavirus đã được xác nhận ở Mỹ", ~~người~~ ta có thể viết "có hơn z ca mắc coronavirus đã được xác nhận $\underline{\text{ở Mỹ}}$", điều này được ủng hộ nếu $x > z$ và bị phản bác nếu ngược lại. Đối với các chỉnh sửa chỉ thêm thông tin mới hoặc loại bỏ các thông tin lỗi thời mà không thay thế chúng, người chú thích sẽ viết một tuyên bố duy nhất.

3.3 Thêm Các Sửa Đổi Tổng Hợp

Tự nhiên, các phiên bản sửa đổi thực tế của Wikipedia mà chúng tôi thu thập chủ yếu mô tả các sự kiện thường xuyên thay đổi theo thời gian, hoặc dễ bị sai sót và cần sửa chữa (chẳng hạn như các giá trị định lượng, xem Phụ lục A.1) (Faruqui et al., 2018; Yang et al., 2017). Tuy nhiên, nhạy cảm với các ngữ cảnh trái ngược là hành vi đáng mong đợi đối với bất kỳ tuyên bố nào. Điều này vừa đảm bảo tính nhất quán với các nguồn sự thật bên ngoài, vừa cải thiện độ trung thực của mô hình thông qua việc kết nối phán quyết với bằng chứng cụ thể (Jacovi và Goldberg, 2020; Ross et al., 2020). Ví dụ, chúng tôi yêu cầu mô hình không chỉ phân loại tuyên bố "Tom Hanks được một tổng thống vinh danh" là đúng, mà còn thay đổi phán quyết của nó thành sai nếu đi kèm với một bằng chứng đối lập (hư cấu). Do đó, chúng tôi có thể xác minh rằng mô hình ưu tiên suy luận dựa trên cặp câu hơn

[3] https://bit.ly/Wiki_Trung lập_Quan điểm [4] https://bit.ly/Wiki_phổ biến_trang [5] https://wikimediafoundation.org/covid19 [6] Nhiều chỉnh sửa chỉ phản ánh việc sửa ngữ pháp, diễn đạt lại, hoặc " Wikification" (định dạng văn bản/liên kết trang).
[7] Chúng tôi đã tìm nguồn các người chú thích của mình thông qua TransPerfect.

Factual		
	Wikipedia sentences *before* and *after* a revision, presented with VITAMINC claims if the revision is factual.	
✗	Before	More stringent actions were taken in China once the seriousness of the outbreak became apparent, such as quarantining entire cities affecting 60 million individuals in Hubei, and strict travel bans.
	After	More drastic actions were taken in China once the severity of the outbreak became apparent, such as quarantining entire cities affecting 60 million individuals in Hubei, and strict travel bans.
✓	Before	In animals, spaying involves an invasive removal of the ovaries, but rarely has major complications other than that spayed animals tend to gain weight.
	After	In animals, spaying involves an invasive removal of the ovaries, but rarely has major complications; the superstition that it causes weight gain is not based on fact.
	Claim 1	Spayed animals gain weight.
	Claim 2	Weight gain in spayed animals is a superstitious myth.
✗	Before	As of 16 March, more than 182,000 cases of the disease have been reported in over 160 countries and territories, resulting in around 79,000 recoveries and more than 7,100 deaths.
	After	As of 16 March, more than 182,000 cases of the disease have been reported in over 160 countries and territories, resulting in more than 7,100 deaths and around 79,000 recoveries.
✓	Before	Global hybrid sales are led by the Prius family, with sales of 4.7 million units representing 66.8% of TMC worldwide sales of 7.053 million Lexus and Toyota units through September 2014.
	After	Global hybrid sales are led by the Prius family, with sales of 5.264 million units representing 65.4% of TMC worldwide sales of 8.048 million Lexus and Toyota units delivered through July 2014.
	Claim 1	Prius sold less than 5 million units, representing over 65.5% of TMC worldwide sales.
	Claim 2	Prius sold more than 5 million units, representing less than 65.5% of TMC worldwide sales.

Table 1: Examples of *non-factual* revisions vs. *factual* revisions, and the claims associated with the later. Factual updates change the outcome (i.e., true or false) of a claim that might be in question. Accordingly, the verdict of a classifier should change based on the version presented. Modified words are underlined and colored.

memorization, which can help it generalize better. Therefore, we use the FEVER dataset to augment VITAMINC with *synthetic* revisions to Wikipedia sentences.

We follow the setting of Schuster et al. (2019) to expand claim-evidence pairs from FEVER (Thorne et al., 2018). Specifically, given a false claim from FEVER, we ask annotators to edit the sentence that refutes it so that it will then support the originally false claim. Additionally, we ask them to write a new claim that is refuted by the new, modified sentence, but that is supported by the original version. Following this method, we obtain two claims where each can be supported or refuted by the original, or the synthetically revised, sentence. We follow the same process for constructing synthetic examples using true claims, but with flipped labels.

3.4 Dataset Statistics

In total, 304,671 revised Wikipedia sentences were examined by annotators, of which 107,056 (35%) were found to express a factual modification and were passed to the group of expert annotators for claim writing. As two symmetric claims with opposing facts were created (when possible) for each revision, this resulted in a total of 325,724 total claim-evidence pairs. We collected 163,180 additional pairs following the synthetic process. The data was partitioned as shown in Table 2. The assignment was done randomly by article, and is consistent with FEVER for overlapping articles. Appendix A contains additional details.

	Supports		Refutes		NEI	
Split	Real	Syn	Real	Syn	Real	Syn
Train	124,864	60,850	71,108	60,850	52,981	-
Dev	21,102	10,382	12,146	10,382	9,042	-
Test	17,306	10,358	9,907	10,358	7,268	-

Table 2: Number of claim-evidence pairs in VITAMINC. Breakdowns of real vs. synthetic revisions are presented on the left and right of each cell, respectively.

4 VITAMINC Tasks

The unique structure of VITAMINC allows us to derive annotations that provide a novel source of supervision for several fact-verification-related tasks. We describe the four main tasks we consider in this work, along with baseline models: (1) factual revision flagging, (2) fact verification, (3) word-level rationales, and (4) factually consistent generation. Figure 2 illustrates an example from VITAMINC. We use the following notations:

- $\mathcal{C}$ is the space of short sentences that express an arbitrary factual statement that can potentially be verified or debunked by external sources.

Thực tế		
	Các câu trên Wikipedia trước và sau khi chỉnh sửa, được trình bày kèm theo các tuyên bố VITAMINC nếu bản chỉnh sửa là thực tế.	
✗	Trước	Các biện pháp nghiêm ngặt hơn đã được thực hiện ở Trung Quốc một khi mức độ nghiêm trọng của dịch bùng phát trở nên rõ ràng, chẳng hạn như việc cách ly toàn bộ các thành phố ảnh hưởng đến 60 triệu người ở Hồ Bắc, và lệnh cấm đi lại nghiêm ngặt.
	Sau	Những biện pháp quyết liệt hơn đã được thực hiện ở Trung Quốc khi mức độ nghiêm trọng của dịch bùng phát trở nên rõ ràng, chẳng hạn như cách ly toàn bộ thành phố ảnh hưởng đến 60 triệu người ở Hồ Bắc, và lệnh cấm đi lại nghiêm ngặt.
✓	Trước	Ở động vật, việc triệt sản ở cái liên quan đến việc loại bỏ buồng trứng một cách xâm lấn, nhưng hiếm khi gây ra các biến chứng nghiêm trọng khác so với điều đó, những con vật đã được triệt sản có xu hướng tăng cân.
	Sau	Ở động vật, việc triệt sản ở cái liên quan đến việc loại bỏ buồng trứng một cách xâm lấn, nhưng hiếm khi gặp các biến chứng nghiêm trọng; Sự mê tín rằng nó gây tăng cân không dựa trên sự thật.
	Yêu cầu 1	Các động vật đã bị triệt sản tăng cân.
	Yêu cầu 2	Tăng cân ở động vật đã được triệt sản là một quan niệm mê tín.
✗	Trước	Tính đến ngày 16 tháng 3, đã có hơn 182.000 ca bệnh được báo cáo tại hơn 160 quốc gia và các vùng lãnh thổ, dẫn đến khoảng 79.000 ca hồi phục và hơn 7.100 ca tử vong.
	Sau	Tính đến ngày 16 tháng 3, đã có hơn 182.000 ca bệnh được báo cáo tại hơn 160 quốc gia và các vùng lãnh thổ, dẫn đến hơn 7.100 ca tử vong và khoảng 79.000 ca hồi phục.
✓	Trước	Doanh số xe hybrid toàn cầu được dẫn đầu bởi gia đình Prius, với doanh số 4,7 triệu chiếc chiếm 66,8% của Doanh số bán hàng toàn cầu của TMC đạt 7,053 triệu đơn vị Lexus và Toyota tính đến tháng 9 năm 2014.
	Sau	Doanh số xe hybrid toàn cầu do dòng Prius dẫn đầu, với doanh số 5,264 triệu chiếc chiếm 65,4% của Doanh số bán toàn cầu của TMC đạt 8,048 triệu đơn vị Lexus và Toyota đã giao đến tháng 7 năm 2014.
	Yêu cầu 1	Prius đã bán được chưa đến 5 triệu chiếc, chiếm hơn 65,5% doanh số bán hàng toàn cầu của TMC.
	Yêu cầu 2	Prius đã bán được hơn 5 triệu chiếc, chiếm chưa đến 65,5% tổng doanh số bán hàng toàn cầu của TMC.

Bảng 1: Ví dụ về các chỉnh sửa không thực tế so với các chỉnh sửa thực tế, và các khẳng định liên quan đến các chỉnh sửa sau. Các cập nhật thực tế thay đổi kết quả (tức là đúng hay sai) của một khẳng định có thể đang bị nghi ngờ. Theo đó, phán quyết của một bộ phân loại nên thay đổi dựa trên phiên bản được trình bày. Các từ đã được chỉnh sửa được gạch chân và đánh màu.

việc ghi nhớ, điều này có thể giúp nó tổng quát hóa tốt hơn. Do đó, chúng tôi sử dụng bộ dữ liệu FEVER để tăng cường VITAMINC với các sửa đổi tổng hợp đối với các câu trên Wikipedia.

Chúng tôi tuân theo phương pháp của Schuster và cộng sự (2019) để mở rộng các cặp luận điểm-bằng chứng từ FEVER (Thorne và cộng sự, 2018). Cụ thể, với một luận điểm sai từ FEVER, chúng tôi yêu cầu người gán nhãn chỉnh sửa câu một cách bác bỏ nó sao cho câu này sau đó sẽ ủng hộ luận điểm ban đầu là sai. Thêm vào đó, chúng tôi yêu cầu họ viết một luận điểm mới bị bác bỏ bởi câu đã được chỉnh sửa mới này, nhưng được ủng hộ bởi phiên bản gốc. Theo phương pháp này, chúng tôi thu được hai luận điểm mà mỗi luận điểm có thể được ủng hộ hoặc bác bỏ bởi câu gốc, hoặc câu đã được chỉnh sửa tổng hợp. Chúng tôi theo cùng một quy trình để xây dựng các ví dụ tổng hợp sử dụng các luận điểm đúng, nhưng với nhãn bị đảo ngược.

3.4 Thống kê bộ dữ liệu

Tổng cộng, 304.671 câu Wikipedia đã được chỉnh sửa đã được các người chú thích kiểm tra, trong đó 107.056 câu (35%) được phát hiện thể hiện một sự sửa đổi theo thực tế và được chuyển cho nhóm các chuyên gia chú thích để viết tuyên bố. Khi có thể, hai tuyên bố đối xứng với các sự thật đối nghịch đã được tạo ra cho mỗi lần chỉnh sửa, điều này dẫn đến tổng cộng 325.724 cặp tuyên bố-bằng chứng. Chúng tôi đã thu thập 163.180 thêm

Chia	Hỗ trợ		Bác bỏ		NEI	
	Real	Syn	Real	Syn	Thực	Syn
Tàu	124.864	60.850	71.108	60.850	52.981	-
Dev	21,102	10,382	12,146	10,382	9,042	-
Test	17,306	10,358	9,907	10,358	7,268	-

Bảng 2: Số lượng cặp lập luận-bằng chứng trong VITAM-INC. Phân tích các bản sửa đổi thực và tổng hợp được trình bày lần lượt ở bên trái và bên phải mỗi ô.

các cặp tional theo quy trình tổng hợp. Dữ liệu được phân chia như được trình bày trong Bảng 2. Việc phân công được thực hiện ngẫu nhiên theo bài viết, và nhất quán với FEVER đối với các bài viết trùng lặp. Phụ lục A chứa thêm chi tiết.

4 Nhiệm vụ VITAMINC

Cấu trúc độc đáo của VITAMINC cho phép chúng tôi tạo ra các chú thích cung cấp một nguồn giám sát mới cho một số tác vụ liên quan đến xác minh sự thật. Chúng tôi mô tả bốn tác vụ chính mà chúng tôi xem xét trong nghiên cứu này, cùng với các mô hình cơ sở: (1) đánh dấu điều chỉnh thực tế, (2) xác minh sự thật, (3) lý do ở cấp từ, và (4) tạo nội dung nhất quán với thực tế. Hình 2 minh họa một ví dụ từ VITAMINC. Chúng tôi sử dụng các ký hiệu sau:

- $\mathcal{C}$ là không gian của các câu ngắn diễn đạt một tuyên bố thực tế tùy ý có thể được xác minh hoặc bác bỏ bởi các nguồn bên ngoài.

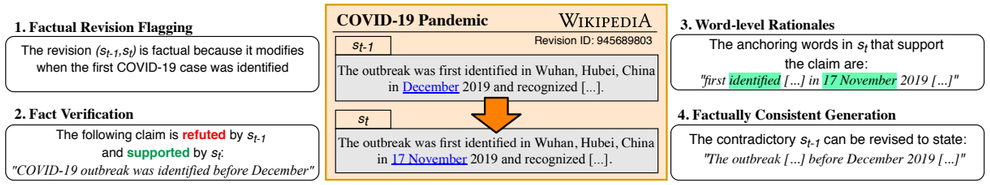


Figure 2: The VITAMINC dataset uses Wikipedia revisions to motivate four central fact verification tasks. Revision source: https://en.wikipedia.org/wiki/?diff=945689803.

- $\mathcal{S}$ is the space of sentences that can be found in a trusted online resource (Wikipedia in this study).
- (s_{t-1}, s_t) denotes the two versions of a sentence that was revised from s_{t-1} to $s_t \in \mathcal{S}$.
- $\text{rel}(c, s)$ denotes the relation between the claim $c \in \mathcal{C}$ and observed evidence $s \in \mathcal{S}$—which can either support c (SUP), refute it (REF), or not contain enough information (NEI).

4.1 Factual Revision Flagging

Online resources like Wikipedia are continuously changing. In order to remain a reliable and neutral source for recent information, its active community of users must constantly verify and correct the revisions of others. We define *factual revision flagging* as the task of identifying revisions that introduce a *factual* change—e.g., by either modifying a certain fact, adding a new one, or removing an existing one. Such an automated detection process can help the community moderate important articles by serving as a watchdog for factual revisions. Furthermore, tracking factual revisions to certain articles can potentially help keep reliant articles consistent (e.g., citing articles, or non-English versions).

We pose factual revision flagging as a binary classification function $f_{\text{flag}}: \mathcal{S} \times \mathcal{S} \rightarrow \{0, 1\}$, where for a revision $(s_{t-1}, s_t)_i$, we set $y_i = 1$ iff there exists a claim in $\mathcal{C}$ whose label (SUP or REF) changes as a result of the edit (i.e., SUP $\rightarrow$ $\{\text{REF}, \text{NEI}\}$ or REF $\rightarrow$ $\{\text{SUP}, \text{NEI}\}$). Table 1 provides example factual and non-factual revisions. We evaluate the following baseline models:

Edit Distance. We measure the edit distance between s_{t-1} and s_t, assuming that larger edits are more likely to represent substantive changes. We tune a decision threshold on the validation set.

BOW. We use an MLP on top of a bag-of-words representation. Each sentence is encoded as e_*, the average *fast*Text (Bojanowski et al., 2017) word embedding of its edited words (i.e., that were removed or modified in the revision). The MLP input is then taken as $[e_{t-1}; e_t; |e_t - e_{t-1}|; e_t \cdot e_{t-1}]$.

ALBERT. We train the ALBERT transformer (Lan et al., 2020) using either only the edited words (diff), or the full sentence pair (full).

4.2 Fact Verification

Our basic setting is similar to the inference task of the FEVER dataset.[8] We predict the verdict for a claim given an observed evidence, $f_{\text{verdict}}: \mathcal{C} \times \mathcal{S} \rightarrow \{\text{SUP}, \text{REF}, \text{NEI}\}$. The FEVER dataset, however, contains independent claim-evidence pairs. In our setting, we have claims paired with revisions such that $\text{rel}(c_i, s_{t-1}) \neq \text{rel}(c_i, s_t)$, creating contrastive triplets. For example, the claim in Figure 2 states that the COVID-19 outbreak was identified before December. VITAMINC matches it with two different contexts (before and after the presented revision), that can either support or refute that claim.

Our baseline model is an ALBERT sentence-pair classifier that predicts $\text{rel}(c, s)$. Compared to BERT (Devlin et al., 2019), it uses fewer parameters by shrinking the embedding size and sharing layers, which we find to improve robustness.

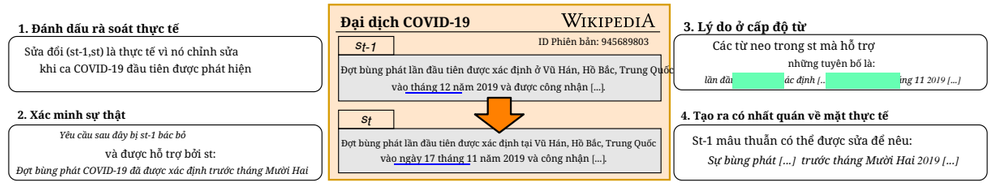
4.3 Word-level Rationales

Word-level rationales provide useful explanations for predictions of neural models (Lei et al., 2016). Such explanations can be particularly useful for semi-automated fact verification, since they allow users to quickly interpret and trust the model's verdict.[9] In Figure 2, for example, the date of the first identified case can explain the verdict for the claim.

As first proposed by Lei et al. (2016), the standard definition of extractive rationales asks for selecting the minimal set of input tokens that is sufficient for preserving the model's prediction. Here we use a slightly modified definition following Shah et al. (2020), where we identify the minimal set of evidence tokens where removing them

[8] To focus on the inference task, as opposed to a full end-to-end system, we assume that we have access to an oracle retriever.

[9] Roitero et al. (2020) showed that explanations can increase the agreement between users and expert fact-checkers.



Hình 2: Bộ dữ liệu VITAMINC sử dụng các bản sửa đổi của Wikipedia để thúc đẩy bốn nhiệm vụ xác minh sự thật trung tâm. Nguồn bản sửa đổi: https://en.wikipedia.org/wiki/?diff=945689803.

• $\mathcal{S}$ là không gian các câu có thể tìm thấy trong một nguồn trực tuyến đáng tin cậy (Wikipedia trong nghiên cứu này).

• (s_{t-1}, s_t) chỉ hai phiên bản của một câu đã được chỉnh sửa từ s_{t-1} thành $s_t \in \mathcal{S}$.

• rel(c, s) chỉ mối quan hệ giữa tuyên bố $c \in \mathcal{C}$ và bằng chứng quan sát được $s \in \mathcal{S}$ — có thể ủng hộ nó (SUP), phản bác nó (REF), hoặc không chứa đủ thông tin (NEI).

4.1 Đánh dấu sửa đổi thực tế

Các nguồn trực tuyến như Wikipedia liên tục thay đổi. Để duy trì vai trò là một nguồn tin cậy và trung lập cho thông tin mới nhất, cộng đồng người dùng tích cực của nó phải liên tục xác minh và sửa các bản chỉnh sửa của người khác. Chúng tôi định nghĩa việc đánh dấu chỉnh sửa thực tế là nhiệm vụ xác định các chỉnh sửa đưa ra sự thay đổi thực tế—ví dụ, bằng cách sửa đổi một sự thật nhất định, thêm một sự thật mới hoặc loại bỏ một sự thật hiện có. Quá trình phát hiện tự động như vậy có thể giúp cộng đồng quản lý các bài viết quan trọng bằng cách đóng vai trò như một người giá m sát các chỉnh sửa thực tế. Hơn nữa, theo dõi các chỉnh sửa thực tế cho các bài viết nhất định có thể giúp duy trì sự nhất quán cho các bài viết phụ thuộc (ví dụ, các bài viết trích dẫn, hoặc các phiên bản không phải tiếng Anh).

Chúng tôi đặt việc đánh dấu sửa đổi thực tế như một hàm phân loại nhị phân f_{flag}: $\mathcal{S} \times \mathcal{S} \rightarrow \{0, 1\}$, trong đó đối với một sửa đổi $(s_{t-1}, s_t)_i$, chúng tôi đặt $y_i = 1$ nếu tồn tại một tuyên bố trong $\mathcal{C}$ mà nhãn của nó (SUP hoặc REF) thay đổi do chỉnh sửa (tức là, SUP $\rightarrow$ { REF, NEI } hoặc REF $\rightarrow$ { SUP, NEI }). Bảng 1 cung cấp các ví dụ về các sửa đổi thực tế và không thực tế. Chúng tôi đánh giá các mô hình cơ bản sau:

Khoảng cách chỉnh sửa. Chúng tôi đo khoảng cách chỉnh sửa giữa s_{t-1} và s_t, giả sử rằng những chỉnh sửa lớn hơn có khả năng đại diện cho những thay đổi thực chất. Chúng tôi điều chỉnh ngưỡng quyết định trên tập dữ liệu xác thực.

BẢNG. Chúng tôi sử dụng một MLP trên đỉnh của biểu diễn túi từ. Mỗi câu được mã hóa thành e_*, là trung bình của nhúng từ fastText (Bojanowski et al., 2017) của các từ đã chỉnh sửa của nó (tức là, những từ đã bị xóa hoặc sửa đổi trong bản chỉnh sửa). Đầu vào của MLP sau đó được lấy là $[e_{t-1}; e_t; |e_t - e_{t-1}|; e_t \cdot e_{t-1}]$.

ALBERT. Chúng tôi huấn luyện bộ biến đổi ALBERT (Lan et al., 2020) sử dụng hoặc chỉ các từ được chỉnh sửa (diff), hoặc toàn bộ cặp câu (full).

4.2 Xác minh sự thật

Cài đặt cơ bản của chúng tôi tương tự như nhiệm vụ suy luận của bộ dữ liệu FEVER. Chúng tôi dự đoán phán quyết cho một tuyên bố dựa trên bằng chứng quan sát được: SUP, REF, NEI. Tuy nhiên, bộ dữ liệu FEVER chứa các cặp tuyên bố-bằng chứng độc lập. Trong cài đặt của chúng tôi, chúng tôi có các tuyên bố được ghép với các bản sửa đổi sao cho rel(c_i, s_{t-1}) khác rel(c_i, s_t), tạo ra các bộ ba đối lập. Ví dụ, tuyên bố trong Hình 2 nêu rõ rằng đợt bùng phát COVID-19 đã được xác định trước tháng Mười Hai. VITAMINC ghép nó với hai ngữ cảnh khác nhau (trước và sau bản sửa đổi được trình bày), có thể hỗ trợ hoặc bác bỏ tuyên bố đó.

Mô hình cơ sở của chúng tôi là một bộ phân l oại cặp câu ALBERT dự đoán rel(c, s). So với BERT (Devlin và cộng sự, 2019), nó sử dụng ít tham số hơn bằng cách thu nhỏ kích thước nhúng và chia sẻ các lớp, điều mà chúng tôi nhận thấy cải thiện độ bền.

4.3 Lập luận ở cấp từ

Các lý giải ở cấp độ từ cung cấp những giải thích hữu ích cho các dự đoán của các mô hình mạng nơ-ron (Lei và cộng sự, 2016). Những giải thích như vậy có thể đặc biệt hữu ích cho việc xác minh sự thật bán tự động, vì chúng cho phép người dùng nhanh chóng diễn giải và tin tưởng vào phán quyết của mô hình. Ví dụ, trong Hình 2, ngày của ca bệnh được xác định đầu tiên có t hể giải thích phán quyết cho tuyên bố đó.

Như lần đầu tiên được đề xuất bởi Lei và cộng sự (2016), định nghĩa chuẩn về các lý do trích xuất yêu cầu chọn tập hợp tối thiểu các từ đầu vào đủ để giữ dự đoán của mô hình. Ở đây chúng tôi sử dụng một định nghĩa được chỉnh sửa một chút theo Shah và cộng sự (2020), nơi chúng tôi xác định tập hợp tối thiểu các từ chứng cứ mà khi loại bỏ chúng

[8] Để tập trung vào nhiệm vụ suy luận, thay vì một hệ thống đầ u-cuối đầy đủ, chúng tôi giả sử rằng chúng tôi có quyền truy cập vào một công cụ truy xuất oracle. [9] Roitero và cộng sự (2020) đã chỉ ra rằng các giải thích có thể tăng sự đồng thuận giữa người dùng và các chuyên gia kiểm chứng sự thật.

will change the input's label to NEI.

We pose this task as conditional masking, where we learn a function $f_{\text{rationale}}: \mathcal{C} \times \mathcal{S} \rightarrow \{0,1\}^n$, where n is the length of an evidence $s \in \mathcal{S}$. Given an evidence $s = (x_1, \ldots, x_n)$ and a claim c, where $\text{rel}(c, s) \in \{\text{SUP}, \text{REF}\}$, we want to find a mask m such that $\text{rel}(c, s \odot m) = \text{NEI}$, where

$$s \odot m = \begin{cases} x_i & \text{if } m[i] = 0; \\ \texttt{<mask>} & \text{if } m[i] = 1. \end{cases}$$

Moreover, we want m to be as sparse as possible. Intuitively, $s \odot m$ could be viewed as an incomplete revision in which the masked words that have not yet been filled in will determine the relation with the claim. We say that m reveals the most responsible words in s for resolving c. Following Shah et al. (2020), we formulate an unsupervised objective as

$$\min \sum_{i=1}^{n} m_i \;\; \text{s.t.} \;\; \text{rel}(c, s \odot m) = \text{NEI}\,. \qquad (1)$$

We evaluate the quality of m by comparing it in terms of F1 to both (1) m_{edit}, the non-stopwords removed or replaced in the true revision (i.e., *edit prediction*), and (2) m_{manual}, a manually annotated "human" reference, (i.e., *rationale prediction*). We implement the following two baselines:

Unsupervised. As in Shah et al. (2020), we optimize a Lagrangian relaxation of Eq. 1, where

$$\mathcal{L}_{\text{us}} := -\log p(\text{rel}(c, s \odot m) = \text{NEI}) + \frac{\lambda}{n} \sum_{i=1}^{n} m_i.$$

We keep the rel classifier (from §4.2) fixed, and train a separate ALBERT model to predict the mask m using a Gumbel softmax (Jang et al., 2017).

Distantly Supervised. By leveraging opposing claims present in VITAMINC, we are able to identify $m_{\text{edit}} = \texttt{diff}(s_{t-1}, s_t)$—i.e., the non-stopwords that are deleted or replaced in s_{t-1} when compared to s_t. We then use m_{edit} as distant supervision for m, where $\mathcal{L}_{\text{ds}} = -\frac{\gamma}{n} \sum_{i=1}^{n} \log p(m_i = m_{\text{edit}_i})$. We combine both the $\mathcal{L}_{\text{us}}$ and $\mathcal{L}_{\text{ds}}$ losses.

4.4 Factually Consistent Generation

As facts change, the sources reporting them must change as well to reflect the most recent information. In VITAMINC, this is reflected via the active revisions to Wikipedia. We simulate *automating* this process by considering two generation tasks:

Automatic Revisions. Given an outdated context s_{t-1} and an updated claim c, we learn $f_{\text{revise}}: \mathcal{S} \times \mathcal{C} \rightarrow \mathcal{S}$ to produce a new context s_t that minimally modifies s_{t-1} to agree with c. For example, one can change s_{t-1} in Figure 2 to state "*before December*" in order to agree with the claim.

Claim Extraction. Given a revision (s_{t-1}, s_t), we learn $f_{\text{extract}}: \mathcal{S} \times \mathcal{S} \rightarrow \mathcal{C}$ to produce a short claim c that expresses the factual change.

In both tasks, the output should satisfy $\text{rel}(c, s_t) = \text{SUP}$, while $\text{rel}(c, s_{t-1}) = \text{REF}$. We use f_{verdict} (§4.2) to evaluate this requirement. We experiment with both BART-base (Lewis et al., 2020a) and T5-base (Raffel et al., 2020) sequence-to-sequence transformer-based generators. For the revision task, we concatenate s_{t-1} and c with a separator and train the model to predict s_t. For the claim extraction task, we combine the input pair (s_{t-1}, s_t) into a single sentence that visualizes the revision (e.g., *"sales of {4.7 → 5.4} million"*).

5 Experiments

We present and analyze results for the models described in Section 4. Our analysis attempts to evaluate several questions: (1) How well can the current state-of-the-art models perform on the VITAMINC tasks? (2) Does VITAMINC increases the robustness of models against adversarial examples? (3) Can VITAMINC improve interpretability by providing supervision for anchoring words?

5.1 Related Datasets

In addition to VITAMINC, we train and evaluate on several related datasets, which we briefly describe:

FEVER (Thorne et al., 2018): A popular fact verification dataset based on Wikipedia. We use the provided SUP and REF claim-evidence pairs. For NEI claims, we randomly sample neutral evidence from the article with the highest BM25 score (Fisch et al., 2021).

MNLI (Williams et al., 2018): A large and diverse dataset for natural language inference. The three-way sentence-pair entailment prediction is similar to fact verification. We use the hypothesis as the claim and the premise as the evidence and evaluate on the "mismatched" evaluation set.

Symmetric (Schuster et al., 2019): A set of challenging symmetric, synthetic extensions to FEVER's evaluation set that avoid claim-only bias.

Adversarial (Thorne et al., 2019c): Adversarial examples created by participants of the FEVER 2.0 shared task. Teams were asked to create claims that

sẽ thay đổi nhãn của đầu vào thành NEI.

Chúng tôi đặt nhiệm vụ này dưới dạng che điều kiện, nơi chúng tôi học một hàm $f_{\text{rationale}}$: $\mathcal{C} \times \mathcal{S} \rightarrow \{0,1\}^n$, trong đó n là độ dài của một bằng chứng $s \in \mathcal{S}$. Cho một bằng chứng $s = (x_1, \ldots, x_n)$ và một tuyên bố c, nơi $\text{rel}(c, s) \in \{\text{SUP}, \text{REF}\}$, chúng tôi muốn tìm một mặt nạ m sao cho $\text{rel}(c, s \odot m) = \text{NEI}$, nơi

$$s \odot m = \begin{cases} x_i & \text{if } m[i] = 0; \\ \texttt{<mask>} & \text{if } m[i] = 1. \end{cases}$$

Hơn nữa, chúng tôi muốn m trở nên thưa thớt nhất có thể. Trực giác cho thấy, $s \odot m$ có thể được coi như một bản chỉnh sửa chưa hoàn thiện mà trong đó các từ bị che mà chưa được điền sẽ quyết định mối quan hệ với tuyên bố. Chúng tôi nói rằng m tiết lộ các từ có trách nhiệm nhất trong s để giải quyết c. Theo Shah et al. (2020), chúng tôi xây dựng một mục tiêu không giám sát như một

$$\min \sum_{i=1}^{n} m_i \;\; \text{s.t.} \;\; \text{rel}(c, s \odot m) = \text{NEI}\,. \qquad (1)$$

Chúng tôi đánh giá chất lượng của m bằng cách so sánh nó về mặt F1 với cả (1) m_{edit}, các từ không phải stopwords được bỏ hoặc thay thế trong phiên bản true revision (tức là dự đoán chỉnh sửa), và (2) m_{manual}, một tham chiếu "con người" được chú thích thủ công (tức là dự đoán lý do). Chúng tôi triển khai hai phương pháp cơ bản sau:

Không giám sát. Như trong Shah và cộng sự (2020), chúng tôi t ối ưu hóa một sự thư giãn Lagrange của Phương trình 1, trong đó

$$\mathcal{L}_{\text{us}} := -\log p(\text{rel}(c, s \odot m) = \text{NEI}) + \frac{\lambda}{n} \sum_{i=1}^{n} m_i.$$

Chúng tôi giữ cố định bộ phân loại rel (từ §4.2), và huấn luyện một mô hình ALBERT riêng biệt để dự đoán the mask$m$ bằng cách sử dụng Gumbel softmax (Jang et al., 2017).

Giám sát từ xa. Bằng cách tận dụng các tuyên bố trái ngược có trong VITAMINC, chúng tôi có thể xác định $m_{\text{edit}} = \text{diff}(s_{t-1}, s_t)$—tức là các từ không phải danh từ dừng bị xóa hoặc thay thế trong s_{t-1} khi so sánh với s_t. Sau đó, chúng tôi sử dụng m_{edit} làm giám sát từ xa cho m, nơi $\mathcal{L}_{\text{ds}} = -\frac{\gamma}{n} \sum_{i=1}^{n} \log p(m_i = m_{\text{edit}_i})$. Chúng tôi kết hợp cả $\mathcal{L}_{\text{us}}$ và $\mathcal{L}_{\text{ds}}$ mất mát.

4.4 Sinh ra nhất quán về mặt thực tế

Khi các sự kiện thay đổi, các nguồn báo cáo chúng cũng phải thay đổi để phản ánh thông tin mới nhất. Trong VITAMINC, điều này được thể hiện thông qua việc chỉnh sửa tích cực trên Wikipedia. Chúng tôi mô phỏng việc tự động hóa quá trình này bằng cách xem xét hai nhiệm vụ tạo nội dung:

Sửa đổi tự động. Cho một ngữ cảnh lỗi thời s_{t-1} và một tuyên bố được cập nhật c, chúng tôi học $f_{\text{revise}}: \mathcal{S} \times \mathcal{C} \rightarrow \mathcal{S}$ để tạo ra một ngữ cảnh mới s_t mà thay đổi tối thiểu s_{t-1} để phù hợp với c. Ví dụ, người ta có thể thay đổi s_{t-1} trong Hình 2 để ghi " trước tháng Mười Hai" nhằm phù hợp với tuyên bố.

Trích xuất Yêu cầu. Cho một bản chỉnh sửa (s_{t-1}, s_t), chúng tôi học $f_{\text{extract}}: \mathcal{S} \times \mathcal{S} \rightarrow \mathcal{C}$ để tạo ra một yêu cầu ngắn c thể hiện sự thay đổi thực tế.

Trong cả hai nhiệm vụ, đầu ra nên thỏa mãn $\text{rel}(c, s_t) = \text{SUP}$, trong khi $\text{rel}(c, s_{t-1}) = \text{REF}$. Chúng tôi sử dụng f_{verdict} (§4.2) để đánh giá yêu cầu này. Chúng tôi thử nghiệm cả hai bộ sinh dựa trên transformer theo chuỗi-to-chuỗi là BART-base (Lewis et al., 2020a) và T5-base (Raffel et al., 2020). Đối với nhiệm vụ chỉnh sửa, chúng tôi kết hợp s_{t-1} và c với một ký tự phân tách và huấn luyện mô hình để dự đoán s_t. Đối với nhiệm vụ trích xuất khẳng định, chúng tôi kết hợp cặp đầu vào (s_{t-1}, s_t) thành một câu duy nhất hiển thị bản chỉnh sửa (ví dụ: "doanh số của {4.7 → 5.4} triệu").

5 Thí nghiệm

Chúng tôi trình bày và phân tích kết quả cho các mô hình được mô tả trong Mục 4. Phân tích của chúng tôi cố gắng đánh giá một số câu hỏi: (1) Các mô hình hiện đại nhất có thể thực hiện tốt các nhiệm vụ của VITAMINC đến mức nào? (2) Liệu VITAMINC có làm tăng độ bền vững của các mô hình trước các ví dụ thù địch hay không? (3) Liệu VITAMINC có thể cải thiện khả năng giải thích bằng cách cung cấp giám sát cho các từ mấu chốt không?

5.1 Bộ Dữ Liệu Liên Quan

Ngoài VITAMINC, chúng tôi đào tạo và đánh giá trên một số tập dữ liệu liên quan, mà chúng tôi sẽ mô tả ngắn gọn:

SỐT (Thorne và cộng sự, 2018): Một bộ dữ liệu xác thực sự thật phổ biến dựa trên Wikipedia. Chúng tôi sử dụng các cặp tuyên bố-bằng chứng SUP và REF được cung cấp. Đối với các tuyên bố NEI, c húng tôi chọn ngẫu nhiên bằng chứng trung lập từ bài viết có điểm BM25 cao nhất (Fisch và cộng sự, 2021).

MNLI (Williams và cộng sự, 2018): Một tập dữ liệu lớn và đa dạng cho suy luận ngôn ngữ tự nhiên. Dự đoán quan hệ ba chiều giữa các cặp câu tương tự như xác minh sự thật. Chúng tôi sử dụng giả thuyết như là tuyên bố và tiền đề như là bằng chứng và đánh giá trên tập đánh giá "không khớp".

Đối xứng (Schuster và cộng sự, 2019): Một tập hợp các phần mở rộng tổng hợp đối xứng đầy thách thức cho bộ đánh giá FEVER mà tránh thiên vị chỉ dựa trên phát biểu.

Đối kháng (Thorne et al., 2019c): Các ví dụ đối kháng được tạo ra bởi các thành viên tham gia nhiệm vụ chia sẻ F EVER 2.0. Các đội được yêu cầu tạo ra các tuyên bố mà

Model	Train data	AUC	Prec.	Rec.	F1
Edit dist.	-	71.34	64.90	63.18	63.56
ALBERT	PAWS-full	72.20	65.27	60.61	60.48
BOW	VitC-diff	79.87	70.85	67.84	68.55
ALBERT	VitC-diff	89.87	80.69	82.06	81.18
ALBERT	VitC-full	**91.97**	82.63	84.49	**83.18**

Table 3: Factual revision flagging scores for models aware of the full sentence-pair (full) and aware only of the modified words (diff). We use ALBERT-base.

break FEVER-trained models. We take all SUP and REF claims and their gold evidence sentences.

Triggers (Atanasova et al., 2020): A set of 186 FEVER claims paraphrased adversarially to contain universal adversarial triggers (Wallace et al., 2019). Its small size leads to high variance results.

ANLI (Nie et al., 2020): An adversarial dataset for MNLI- and FEVER-based models. The creation was performed in three iterative rounds in which a model was trained, and then crowdworkers devised adversarial inputs, and the process repeated.

PAWS (Zhang et al., 2019): A dataset of altered Wikipedia sentences using word swapping and back-translation. Human annotators labeled whether the modified sentence is a paraphrase or not. We evaluate whether a PAWS-trained classifier can be used for our factual revision flagging task.

5.2 Factual Revision Flagging

Table 3 shows the results of our baseline models on the factual revision flagging task. First, we notice that a model trained on the PAWS dataset (reaching 93.42 F1 score on PAWS test) does *not* transfer well to the flagging task, and performs on par with a simple edit distance heuristic. We hypothesize that this is a result of the entity scrambling technique used to synthetically revise sentences in PAWS, which is different from the edits introduced by real, factual Wikipedia revisions in practice.

Second, we see that the performance of neural models trained on the VITAMINC flagging task increases with richer inputs and more advanced models—demonstrating the complexity of the task. The ALBERT (diff) model that uses only the modified word sequences from each sentence (i.e., contextual within a subspan) improves the AUC by 10 points over a BOW model that gets a similar input. The ALBERT (full) model that receives the full sentences as input (i.e., has access to even more context), further improves the AUC by 2 points. Nevertheless, the best model still only reaches 83

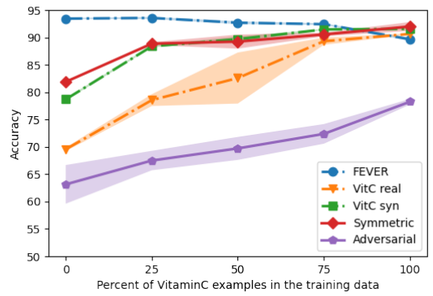


Figure 3: Test accuracy of models trained on a dataset of 100K combined SUP and REF examples from VITAMINC and FEVER. The higher the ratio of VITAMINC in the training data, the better the performance on adversarial evaluation sets (solid lines). The shaded areas represent standard error across three runs.

macro-F1, indicating the difficulty of this task.

5.3 Fact Verification

Table 4 summarizes the results for classifiers trained on fact verification and NLI datasets. Verifying claims against real revisions proves to be the hardest. The best model achieves 89% accuracy, lower than that on either VITAMINC's synthetic cases or the original FEVER examples. Including VITAMINC examples in the training data drastically increases models' sensitivity to contrastive examples (rightmost column)—while preserving the in-domain accuracy (only -0.42% for FEVER and $+0.12\%$ for MNLI with ALBERT-xlarge). Another evidence for the generalization properties conferred by VITAMINC is its zero-shot performance to both other datsets. An ALBERT-xlarge model trained only on VITAMINC reaches 76% and 79% accuracy on FEVER and MNLI, respectively. In contrast, the transfer accuracy for MNLI→FEVER is 70% and for FEVER→MNLI is only 38%.

Most importantly, models trained with VITAMINC perform better on challenging adversarial datasets. On the otherhand, simply augmenting FEVER data with MNLI data has a limited effect on adversarial examples.[10] We conjecture that the contrastive nature of VITAMINC helps models better learn the relations between the claims and evidences—and to avoid relying on certain artifacts that do not generalize well.

To further probe the value of VITAMINC examples compared to FEVER ones (SUP and REF

[10]We've also tried augmenting FEVER with ANLI for an ALBERT-xlarge model and find it to achieve only 73%, 91%, and 34% on Adver., Sym., and Triggers, respectively.

Mô hình	Dữ liệu huấn luyện	AUC	Tối	Rec.	F1
Chỉnh sửa dist.	-	71.34	64.90	63.18	63.56
ALBERT	Đầy BÀN CHÂN	72.20	65.27	60.61	60.48
BOW	VitC-diff	79.87	70.85	67.84	68.55
ALBERT	VitC-diff	89.87	80.69	82.06	81.18
ALBERT	VitC-đầy đủ	**91.97**	82.63	84.49	**83.18**

Bảng 3: Điểm đánh dấu hiệu chỉnh thực tế cho các mô hình nhận biết toàn bộ cặp câu (full) và chỉ nhận biết các từ được sửa đổi (diff). Chúng tôi sử dụng ALBERT-base.

phá vỡ các mô hình được huấn luyện FEVER. Chúng tôi lấy tất cả các tuyên bố SUP và REF cùng với các câu bằng chứng vàng của chúng.

Các trình kích hoạt (Atanasova et al., 2020): Một tập hợp gồm 186 tuyên bố FEVER được diễn giải lại theo cách đối kháng để chứa các trình kích hoạt đối kháng phổ quát (Wallace et al., 2019). Kích thước nhỏ của nó dẫn đến kết quả có độ biến thiên cao.

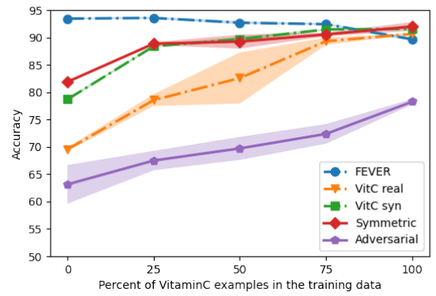
ANLI (Nie và cộng sự, 2020): Một tập dữ liệu đối kháng cho các mô hình dựa trên MNLI và FEVER. Việc tạo ra được thực hiện qua ba vòng lặp, trong đó một mô hình được huấn luyện, sau đó các lao động đám đông tạo ra các đầu vào đối kháng, và quá trình được lặp lại.

PAWS (Zhang và cộng sự, 2019): Một bộ dữ liệu các câu t rên Wikipedia đã bị thay đổi sử dụng phương pháp hoán đổi từ và dịch ngược. Các chú thích viên con người đã gắn nhãn liệu câu đã chỉnh sửa có phải là câu diễn giải lại hay không. Chúng tôi đánh giá xem liệu một bộ phân loại được huấn luyện trên PAWS có thể được sử dụng cho nhiệm vụ đánh dấu sửa đổi thực tế của chúng tôi hay không.

5.2 Đánh dấu sửa đổi thực tế

Bảng 3 cho thấy kết quả của các mô hình cơ sở của chúng tôi trên nhiệm vụ đánh dấu sửa đổi thực tế. Đầu tiên, chúng tôi nhận thấy rằng một mô hình được huấn luyện trên bộ dữ liệu PAWS (đạt 93,42 điểm F1 trên bài kiểm tra PAWS) không chuyển giao tốt sang nhiệm vụ đánh dấu, và hoạt động ngang bằng với một thuật toán khoảng cách chỉnh sửa đơn giản. Chúng tôi giả thuyết rằng điều này là kết quả của kỹ thuật tráo đổi thực thể được sử dụng để chỉnh sửa câu một cách tổng hợp trong PAWS, điều này khác với các chỉnh sửa được thực hiện bởi các phiên bản thực tế, có thực tế trên Wikipedia.

Thứ hai, chúng ta thấy rằng hiệu suất của các mô hình thần kinh được huấn luyện trên nhiệm vụ đánh dấu VITAMINC tăng lên với các đầu vào phong phú hơn và các mô hình tiên tiến hơn—cho thấy sự phức tạp của nhiệm vụ. Mô hình ALBERT(diff) chỉ sử dụng các chuỗi từ đã được chỉnh sửa từ mỗi câu (tức là theo ngữ cảnh trong một khoảng con) cải thiện AUC lên 10 điểm so với mô hình BOW nhận cùng một đầu vào tương tự. Mô hình ALBERT (full) nhận toàn bộ câu làm đầu vào (tức là có quyền truy cập vào nhiều ngữ cảnh hơn), cải thiện AUC thêm 2 điểm. Tuy nhiên, mô hình tốt nhất vẫn chỉ đạt 83



Hình 3: Độ chính xác kiểm tra của các mô hình được huấn luyện trên một tập dữ liệu gồm 100K ví dụ kết hợp SUP và REF từ VITAMINC và FEVER. Tỷ lệ VITAMINC trong dữ liệu huấn luyện càng cao, hiệu suất trên các bộ đánh giá đối kháng càng tốt (đường liền). Các vùng được tô màu biểu thị sai số chuẩn trên ba lần chạy.

macro-F1, cho thấy độ khó của nhiệm vụ này.

5.3 Xác minh sự thật

Bảng 4 tóm tắt kết quả cho các bộ phân loại được huấn luyện trên các tập dữ liệu xác minh sự thật và NLI. Việc xác minh các tuyên bố dựa trên các sửa đổi thực tế được chứng minh là khó nhất. Mô hình tốt nhất đạt độ chính xác 89%, thấp hơn so với trên cả các trường hợp tổng hợp của VITAMINC hoặc các ví dụ gốc của FEVER. Việc đưa các ví dụ VITAMINC vào dữ liệu huấn luyện làm tăng đáng kể độ nhạy của các mô hình đối với các ví dụ đối chiếu (cột ngoài cùng bên phải) — trong khi vẫn duy trì độ chính xác trong miền (chỉ -0.42% cho FEVER và $+0.12$% cho MNLI với ALBERT-xlarge). Một bằng chứng khác về các đặc tính tổng quát được cung cấp bởi VITAMINC là hiệu suất zero-shot trên cả hai tập dữ liệu khác. Một mô hình ALBERT-xlarge chỉ được huấn luyện trên VITAMINC đạt 76% và 79% độ chính xác trên FEVER và MNLI, tương ứng. Ngược lại, độ chính xác chuyển giao cho MNLI→ FEVER là 70% và cho FEVER→MNLI chỉ là 38%.

Quan trọng nhất, các mô hình được huấn luyện với VITA-MINC hoạt động tốt hơn trên các tập dữ liệu đối kháng khó. Ngược lại, việc đơn giản bổ sung dữ liệu FEVER bằng dữ liệu MNLI có ảnh hưởng hạn chế đến các ví dụ đối kháng. Chúng tôi suy đoán rằng bản chất đối chiếu của VITA-MINC giúp các mô hình học tốt hơn các mối quan hệ giữa các khẳng định và bằng c hứng—và tránh dựa vào một số hiện vật nhất định mà không tổng quát tốt.

Để điều tra thêm giá trị của các ví dụ VITAMIN C so với các ví dụ FEVER (SUP và REF

[10]Chúng tôi cũng đã thử tăng cường FEVER với ANLI cho mô hình ALBERT-xlarge và thấy rằng nó chỉ đạt 73%, 91% và 34% trên Adver., Sym. và Triggers, tương ứng.

Model	Train dataset	VitC real	VitC syn	FEVER	MNLI	Adver.	Sym.	Triggers	ANLI	Contrast
ALBERT-base	FEVER	54.78	79.18	95.07	58.45	62.01	81.18	3.33	32.94	55.53
	MNLI	44.93	69.67	65.70	85.22	49.61	72.89	68.82	30.63	56.67
	FEVER + MNLI	55.93	82.26	95.62	85.58	63.97	85.67	38.71	30.59	61.90
	VitC	86.16	89.78	74.56	69.18	71.41	90.17	**86.67**	37.25	84.11
	VitC + MNLI	86.68	91.18	77.70	85.95	69.58	91.15	70.97	34.31	85.61
	VitC + FEVER	86.26	91.05	94.24	68.90	68.80	91.57	72.04	38.50	85.89
ALBERT-xlarge	FEVER	58.56	84.22	96.47	38.33	72.58	87.08	32.80	36.03	64.59
	MNLI	49.26	74.58	70.47	88.91	53.52	78.65	72.58	36.38	63.41
	FEVER + MNLI	61.21	86.81	**96.81**	**89.04**	69.97	89.75	43.55	37.66	70.44
	VitC	88.64	93.84	75.99	78.89	**82.51**	**94.80**	67.20	**42.66**	89.57
	VitC + MNLI	88.69	93.92	76.80	89.03	80.81	**94.80**	67.20	40.09	89.80
	VitC + FEVER	**88.87**	**94.01**	96.05	62.30	80.94	**94.80**	65.59	40.31	**90.94**

Table 4: Test accuracy of fact verification and NLI models. VITAMINC-trained models are more robust to adversarial examples and more sensitive to contrastive contexts. The rightmost column shows the percent of FEVER claims in which the prediction flipped when presented with contrastive contexts.

Token labels	Edit prediction			Word-level rationales		
	Prec.	Rec.	F1	Prec.	Rec.	F1
-	31.93	30.56	31.23	31.11	46.64	37.33
✓	55.93	62.68	**59.11**	36.92	66.03	**47.36**

Table 5: The distant token-level supervision of VITAMINC improves the edit prediction, and as result identifies the anchoring words (rationales) more accurately.

only), we compose training sets of 100K examples using different ratios of the two datasets. As shown in Figure 3, including more VITAMINC pairs continuously improves the performance on the challenging adversarial and symmetric evaluation sets.

As an additional qualitative experiment, given the recent successes of huge language models such as GPT-3 (Brown et al., 2020), we explore whether such models develop sufficient context sensitivity on their own. Appendix C shows the results of classifying several claims using a few-shot GPT-3 model. We find that GPT-3 still largely underperforms our VITAMINC-trained models in terms of sensitivity—demonstrating the importance of using VITAMINC's unique structure during training.

5.4 Word-level Rationales

Table 5 shows the results of our baseline models for identifying word-level rationales (i.e., anchoring words in the evidence). While our unsupervised model is able to uncover some patterns, directly leveraging the structure of VITAMINC to obtain distant supervision for likely anchoring words (i.e., token labels) improves both the edit prediction and the word-level rationale prediction performance.[11] Example predictions are provided in Appendix E.

[11] We evaluate rationales using a manually annotated test set of 300 examples (150 each from VitC real and VitC synthetic).

5.5 Factually Consistent Generation

Table 6 presents the results on factually consistent generation. We find BART to perform better in both of our generation tasks (though we only tried the default setting). The BLEU score (Papineni et al., 2002) is lower in the claim extraction task since there is freedom in how to phrase the claims, which can result in greater differences between the outputs and the references. The BERT-based BLEURT score (Sellam et al., 2020) shows a similar trend. Still, the claim extraction model succeeds in updating the facts that reflect the true revision 86% of the time, as measured by the fact verification model's verdict (f_{verdict}).

The revision generator aims to modify sentences so that they agree with a given claim. According to our fact verification model's verdict, it succeeds in doing so 76% of the time. Furthermore, revisions should resemble real ones, and preserve the remaining content that is unrelated to the claim. The SARI KEEP F1 (Xu et al., 2016) of 75 shows that the model and the reference mostly agree on parts of the sentence that should be kept unchanged.

We find that the token-based measures and our f_{verdict} metric agree well with human (manual) evaluation scores. We randomly sampled 100 generated and human-written sentences per task, and asked workers on Amazon MTurk to rate their grammaticality and whether the evidence s_t supports the claim. The scores of the generated sentences were on par with the human-written ones, indicating the high-quality of our outputs.

Table 7 presents two example generations for the claim extraction task (we provide additional qualitative examples in Appendix E). Our model is able to efficiently extract a self-contained claim that expresses the correct fact after the edit. As in §5.3,

Mô hình	Tập dữ liệu huấn luyện	VitC thật	VitC syn	SỐT	MNLI	Trạng từ	Sym.	Kích hoạt	ANLI	Tương phản
ALBERT-base	SỐT	54.78	79.18	95.07	58.45	62.01	81.18	3.33	32.94	55.53
	MNLI	44.93	69.67	65.70	85.22	49.61	72.89	68.82	30.63	56.67
	SỐT + MNLI	55.93	82.26	95.62	85.58	63.97	85.67	38.71	30.59	61.90
	VitC	86.16	89.78	74.56	69.18	71.41	90.17	**86.67**	37.25	84.11
	VitC +MNLI	86.68	91.18	77.70	85.95	69.58	91.15	70.97	34.31	85.61
	VitC +SỐT	86.26	91.05	94.24	68.90	68.80	91.57	72.04	38.50	85.89
ALBERT-rất l ớn	SỐT	58.56	84.22	96.47	38.33	72.58	87.08	32.80	36.03	64.59
	MNLI	49.26	74.58	70.47	88.91	53.52	78.65	72.58	36.38	63.41
	SỐT + MNLI	61.21	86.81	**96.81**	**89.04**	69.97	89.75	43.55	37.66	70.44
	VitC	88.64	93.84	75.99	78.89	**82.51**	**94.80**	67.20	**42.66**	89.57
	VitC +MNLI	88.69	93.92	76.80	89.03	80.81	**94.80**	67.20	40.09	89.80
	VitC +SỐT	**88.87**	**94.01**	96.05	62.30	80.94	**94.80**	65.59	40.31	**90.94**

Bảng 4: Độ chính xác kiểm tra của các mô hình xác minh sự thật và NLI. Các mô hình được huấn luyện VITAMINC có độ bền cao hơn với các tấn công đối kháng-

ví dụ sarial và nhạy cảm hơn với các ngữ cảnh tương phản. Cột bên phải cùng cho thấy tỷ lệ phần trăm của FEVER những tuyên bố trong đó dự đoán bị đảo ngược khi được trình bày với các bối cảnh tương phản.

Mã thông báo nhãn	Chỉnh sửa dự đoán			Lý do ở cấp từ		
	Tối	Rec.	F1	Tối	Rec.	F1
-	31.93	30.56	31.23	31.11	46.64	37.33
✓	55.93	62.68	**59.11**	36.92	66.03	**47.36**

Bảng 5: Việc giám sát ở mức token xa của VITA M-INC cải thiện dự đoán chỉnh sửa, và kết quả là xác định các từ mấu chốt (lý lẽ) chính xác hơn.

chỉ), chúng tôi tạo ra các tập huấn luyện gồm 100.000 ví dụ sử dụng các tỉ lệ khác nhau của hai bộ dữ liệu. Như được trình bày trong Hình 3, việc bao gồm nhiều cặp VITAMINC hơn liên tục cải t hiện hiệu suất trên các bộ đánh giá đối kháng và đối xứng đầy thách thức.

Như một thí nghiệm định tính bổ sung, trước những thành công gần đây của các mô hình ngôn ngữ khổng lồ như GPT-3 (Brown et al., 2020), chúng tôi khám phá xem liệu các mô hình này có tự phát triển đủ khả năng nhạy cảm với ngữ cảnh hay không. Phụ lục C trình bày kết quả phân loại một số tuyên bố bằng mô hình GPT-3 với phương pháp vài mẫu. Chúng tôi nhận thấy GPT-3 vẫn còn kém một phần lớn so với các mô hình được huấn luyện bằng VITAMINC của chúng tôi về mặt nhạy cảm—điều này chứng minh tầm quan trọng của việc sử dụng cấu trúc độc đáo của VITAMINC trong quá trình huấn luyện.

5.4 Lập luận ở cấp từ

Bảng 5 cho thấy kết quả của các mô hình cơ sở của chúng tôi trong việc xác định các lý do ở mức từ (tức là các từ làm điểm neo trong bằng chứng). Trong khi mô hình không giám sát của chúng tôi có thể phát hiện một số mẫu, việc tận dụng trực tiếp cấu trúc của VITAMINC để đạt được giám sát từ xa cho các từ có khả năng làm điểm neo (tức là nhãn token) cải thiện cả hiệu suất dự đoán chỉnh sửa và dự đoán lý do ở mức từ. Ví dụ về các dự đoán được cung cấp trong Phụ lục E.

[11] Chúng tôi đánh giá các lý do bằng cách sử dụng một bộ dữ liệu kiểm tra được chú thích thủ công gồm 300 ví dụ (mỗi loại 150 ví dụ từ VitC thực và VitC tổng hợp).

5.5 Tạo nội dung nhất quán theo thực tế

Bảng 6 trình bày kết quả về việc tạo ra nội dung nhất quán với thực tế. Chúng tôi nhận thấy BART hoạt động tốt hơn trong cả hai nhiệm vụ tạo văn bản của chúng tôi (mặc dù chúng tôi chỉ thử cài đặt mặc định). Điểm BLEU (Papineni et al., 2002) thấp hơn trong nhiệm vụ trích xuất tuyên bố vì có sự tự do trong cách diễn đạt các tuyên bố, điều này có t hể dẫn đến khác biệt lớn hơn giữa kết quả đầu ra và các tài liệu tham khảo. Điểm BLEURT dựa trên BERT (Sellam et al., 2020) cũng cho thấy xu hướng tương tự. Tuy nhiên, mô hình trích xuất tuyên bố vẫn thành công trong việc cập nhật các sự kiện phản ánh đúng chỉnh sửa thực tế 86% thời gian, được đo bằng phán quyết của mô hình xác minh sự thật (f_{verdict}).

Bộ tạo chỉnh sửa nhằm mục đích thay đổi câu sao cho chúng đồng ý với một tuyên bố đã cho. Theo phán quyết của mô hình xác minh sự thật của chúng tôi, nó thành công trong việc này 76% thời gian. Hơn nữa, các chỉnh sửa nên giống với các chỉnh sửa thực tế, và giữ lại phần nội dung còn lại không liên quan đến tuyên bố. Chỉ số SARI KEEP F1 (Xu et al., 2016) là 75 cho thấy mô hình và tham chiếu phần lớn đồng ý về các phần của câu nên được giữ nguyên.

Chúng tôi nhận thấy rằng các thước đo dựa trên token và chỉ số f_{verdict} của chúng tôi tương đồng tốt với các điểm đánh giá của con người (thủ công). Chúng tôi đã ngẫu nhiên chọn mẫu 100 câu được tạo ra và viết bởi con người cho mỗi nhiệm vụ, và yêu cầu các công nhân trên Amazon MTurk đánh giá tính ngữ pháp của chúng và liệu bằng chứng s_t có hỗ trợ cho khẳng định hay không. Điểm số của các câu được tạo ra tương đương với các câu viết bởi con người, cho thấy chất lượng cao của các kết quả đầu ra của chúng tôi.

Bảng 7 trình bày hai ví dụ sinh ra cho nhiệm vụ trích xuất khẳng định (chúng tôi cung cấp thêm các ví dụ định tính trong Phụ lục E). Mô hình của chúng tôi có khả năng trích xuất hiệu quả một khẳng định độc lập thể hiện đúng sự thật sau khi chỉnh sửa. Như trong §5.3,

Target	Model	ROUGE$_2$	BLEU	SARI scores KEEP	ADD	DEL	AVG	BLEURT	f_{verdict}	Manual evaluation Grammar	SUP
Revision	T5	77.63	47.46	72.61	13.32	43.04	42.99	0.38	64.52	81.00	71.80
	BART	85.23	54.86	75.36	18.31	47.95	47.21	0.67	76.26	84.80	83.20
Claim	T5	35.19	13.95	44.36	20.59	87.54	50.83	-0.12	75.39	71.33	72.22
	BART	40.38	16.14	52.91	23.62	91.37	55.97	0.16	85.83	75.78	74.22

Table 6: Factually consistent generation results. Higher is better for all scores and the max value is 100 (except for BLEURT). f_{verdict} is the score of our VITAMINC-trained ALBERT-base model on the outputs. For manual evaluation, outputs were rated by their grammaticality and by how much the evidence supports the claim (SUP). For reference, human-written pairs received 75.75 and 76.0 average scores for Grammar and SUP, respectively.

(s_{t-1}, s_t)	2020 coronavirus pandemic in Germany: there have been{*| 349 -> 444 |}confirmed cases and 16 recoveries.		
BART (VitC)	More than 400 people have tested positive for COVID-19 in Germany.	$f_{\text{verdict}}(c, s_t) =$	SUP
GPT-3 $\mathcal{T}$=0	As of 14 March, there have been more than 350 confirmed cases of the virus in Germany		SUP
GPT-3 $\mathcal{T}$=0.7	As of March 12, there have been more than 400 confirmed cases and 20 reported deaths		NEI
Reference	There have been more than 400 confirmed coronavirus cases in Germany .		SUP
(s_{t-1}, s_t)	Diego Corrales: Corrales was born to a{*| Puerto Rican -> African American |}father and a {*| Dominican -> Mexican |}mother .		
BART (VitC)	Diego Corrales'father is African American and his mother is Mexican.		SUP
GPT-3 $\mathcal{T}$=0	Corrales was born to a Puerto Rican father and a Mexican mother		REF
GPT-3 $\mathcal{T}$=0.7	Corrales was born to a father from Puerto Rico and a mother from the Dominican Republic		REF
Reference	Diego Corrales´ father was African American and his mother Mexican .		SUP

Table 7: Example outputs for expressing claims that reflect the factual changes in a single Wikipedia revision. The BART-base model is trained on VITAMINC data, while GPT-3 is applied in a 2-shot setting with a temperature of 0 or 0.7 (see Appendix C). The revision (s_{t-1}, s_t) is given to the model as a single sentence, where the edits are between curly brackets. The human-written claim is provided for reference. The rightmost column contains the prediction of our ALBERT-xlarge $f_{\text{verdict}}(c, s_t)$ model (trained on VITAMINC) when using the generated claim.

we also explore how GPT-3 handles this task (we provide two demonstrations in the prompt). Compared to the BART model trained on VITAMINC, GPT-3 appears to make more factually inconsistent or unsupported generations (see Appendix C for more details). Encouragingly, our f_{verdict} classifier is still able to pick up on this—as demonstrated by the predictions in the rightmost column of Table 7. For example, classifying the report about 20 deaths as NEI since it is not part of the source. Once again, this serves to qualitatively demonstrate the effectiveness of leveraging VITAMINC.

6 Conclusion

We presented VITAMINC, a large-scale dataset for training and evaluating fact verification models using contrastive contexts. Our novel method of leveraging factual revisions to Wikipedia enabled us to create challenging examples in which a claim is paired with contexts that are lexically similar, yet factually opposing. Our results illustrated that training on VITAMINC improves classifier sensitivity to subtle changes in evidence, and increases their robustness to adversarial examples.

Furthermore, we formulated several new, important tasks for fact verification that VITAMINC allows us to test. We showed how the dataset's unique "before and after" structure lends itself to training classifiers to flag factual revisions. In addition, for factual revisions, the edits reveal which words in the evidence are the most critical—which helps supervise word-level rationale models for better interpretability. Finally, we demonstrated that VITAMINC can help with factually consistent text generation. We hope that this work and the range of tasks it presents will motivate and support the fact verification field in developing reliable models that can adapt to dynamically changing evidence.

Acknowledgements

We thank the TransPerfect team, Darsh J Shah and Enrico Santus for helpful discussions, as well as the members of the MIT NLP group and Andreas Vlachos for valuable feedback. This work is supported in part by the Facebook Online Safety Benchmark Award. TS is supported in part by DSO grant DSOCL18002. AF is supported in part by a NSF Graduate Research Fellowship.

Mục tiêu	Mô hình	ĐỎ	BLEU	Điểm SARI KEEP	ADD	DEL	AVG	BLEURT	f_{verdict}	Đánh giá thủ công Ngữ pháp	SUP
Sửa đổi	T5	77.63	47.46	72.61	13.32	43.04	42.99	0.38	64.52	81.00	71.80
	BART	85.23	54.86	75.36	18.31	47.95	47.21	0.67	76.26	84.80	83.20
Yêu cầu	T5	35.19	13.95	44.36	20.59	87.54	50.83	-0.12	75.39	71.33	72.22
	BART	40.38	16.14	52.91	23.62	91.37	55.97	0.16	85.83	75.78	74.22

Bảng 6: Kết quả tạo ra nhất quán về mặt thực tế. Điểm cao hơn là tốt hơn cho tất cả các chỉ số và giá trị tối đa là 100 (trừ BLEURT). f_{verdict} là điểm của mô hình ALBERT-base được huấn luyện VITAMINC của chúng tôi trên các đầu ra. Đối với đánh giá thủ công, các đầu ra được đánh giá dựa trên ngữ pháp và mức độ bằng chứng hỗ trợ cho tuyên bố (SUP). Tham khảo một cặp viết bởi con người đạt trung bình 75,75 và 76,0 điểm cho Ngữ pháp và SUP, tương ứng.

(s_{t-1}, s_t)	Đại dịch coronavirus 2020 tại Đức: đã có {*| 349 -> 444 |} ca được xác nhận và 16 ca khỏi bệnh.		
BART (VitC)	Hơn 400 người đã có kết quả xét nghiệm dương tính với COVID-19 ở Đức.	$f_{\text{verdict}}(c, s_t) =$	SUP
GPT-3 $\mathcal{T}$=0	Tính đến ngày 14 tháng 3, đã có hơn 350 ca nhiễm virus được xác nhận ở Đức		SUP
GPT-3 $\mathcal{T}$=0.7	Tính đến ngày 12 tháng 3, đã có hơn 400 ca được xác nhận và 20 ca tử vong được báo cáo		NEI
Tham khảo	Đã có hơn 400 ca nhiễm coronavirus được xác nhận ở Đức.		SUP
(s_{t-1}, s_t)	Diego Corrales: Corrales sinh ra trong một gia đình với cha là người {Puerto Rico - người Mỹ gốc Phi} và một mẹ Dominican-Mexican.		
BART (VitC)	Cha của Diego Corrales là người Mỹ gốc Phi và mẹ của anh ấy là người Mexico.		SUP
GPT-3 $\mathcal{T}$=0	Corrales sinh ra trong một gia đình có cha người Puerto Rico và mẹ người Mexico		REF
GPT-3 $\mathcal{T}$=0.7	Corrales sinh ra trong một gia đình có cha là người Puerto Rico và mẹ là người Cộng hòa Dominica		REF
Tham khảo	Cha của Diego Corrales là người Mỹ gốc Phi và mẹ của anh là người Mexico.		SUP

Bảng 7: Ví dụ về kết quả đầu ra để diễn đạt các tuyên bố phản ánh những thay đổi thực tế trong một lần chỉnh sửa Wikipedia. Mô hình BART-base được huấn luyện trên dữ liệu VITAMINC, trong khi GPT-3 được áp dụng trong trường hợp 2-shot với nhiệt độ 0 hoặc 0,7 (xem Phụ lục C). Lần chỉnh sửa (s_{t-1}, s_t) được đưa cho mô hình dưới dạng một câu duy nhất, nơi các chỉnh sửa nằm giữa các dấu ngoặc nhọn. Tuyên bố được viết bởi con người được cung cấp để tham khảo. Cột cuối cùng bên phải chứa dự đoán của mô hình ALBERT-xlarge $f_{\text{verdict}}(c, s_t)$ của chúng tôi (được huấn luyện trên VITAMINC) khi sử dụng tuyên bố được sinh ra.

chúng tôi cũng khám phá cách GPT-3 xử lý nhiệm vụ này (chúng tôi cung cấp hai minh họa trong phần prompt). So với mô hình BART được huấn luyện trên VITAMINC, GPT-3 dường như tạo ra nhiều thông tin không nhất quán về mặt thực tế hoặc không được hỗ trợ hơn (xem Phụ lục C để biết thêm chi tiết). một cách khích lệ, bộ phân loại f_{verdict} của chúng tôi vẫn có thể nhận ra điều này — như được minh họa bởi các dự đoán ở cột ngoài cùng bên phải của Bảng 7. Ví dụ, phân loại báo cáo về khoảng 20 ca tử vong là NEI vì nó không thuộc phần nguồn. Một lần nữa, điều này phục vụ để chứng minh một cách định tính hiệu quả của việc tận dụng VITAMINC.

6 Kết luận

Chúng tôi đã giới thiệu VITAMINC, một tập dữ liệu quy mô lớn để huấn luyện và đánh giá các mô hình xác minh sự thật sử dụng các ngữ cảnh đối lập. Phương pháp mới của chúng tôi trong việc tận dụng các sửa đổi thực tế trên Wikipedia đã cho phép chúng tôi tạo ra các ví dụ thách thức, trong đó một khẳng định được ghép với các ngữ cảnh có từ vựng tương tự nhưng mâu thuẫn về mặt thực tế. Kết quả của chúng tôi minh họa rằng việc huấn luyện trên VITAMINC cải thiện độ nhạy của bộ phân loại đối với những thay đổi tinh tế trong bằng chứng và tăng cường độ bền của chúng trước các ví dụ đối kháng.

Hơn nữa, chúng tôi đã đề xuất một số nhiệm vụ mới quan trọng cho việc xác minh thông tin mà VITAMINC cho phép chúng tôi thử nghiệm. Chúng tôi đã chỉ ra cách cấu trúc độc đáo "trước và sau" của tập dữ liệu giúp huấn luyện các bộ phân loại để đánh dấu các chỉnh sửa dựa trên sự thật. Ngoài ra, đối với các chỉnh sửa dựa trên sự thật, các sửa đổi tiết lộ các từ trong bằng chứng quan trọng nhất — điều này giúp giám sát các mô hình lý giải ở mức từ để cải thiện khả năng giải thích. Cuối cùng, chúng tôi đã chứng minh rằng VITAMINC có thể hỗ trợ việc tạo văn bản phù hợp với sự thật. Chúng tôi hy vọng rằng công trình này và loạt nhiệm vụ mà nó mang lại sẽ thúc đẩy và hỗ trợ lĩnh vực xác minh thông tin trong việc phát triển các mô hình đáng tin cậy có thể thích ứng với các bằng chứng thay đổi động.

Lời cảm ơn

Chúng tôi cảm ơn đội ngũ TransPerfect, Darsh J Shah và Enrico Santus về những cuộc thảo luận hữu ích, cũng như các thành viên của nhóm MIT NLP và Andreas Vlachos về phản hồi quý giá. Công trình này được hỗ trợ một phần bởi Giải thưởng Chuẩn An toàn Trực tuyến Facebook. TS được hỗ trợ một phần bởi khoản tài trợ DSO DSOCL18002. AF được hỗ trợ một phần bởi Học bổng Nghiên cứu Sau đại học NSF.

References

Pepa Atanasova, Jakob Grue Simonsen, Christina Lioma, and Isabelle Augenstein. 2020. Generating fact checking explanations. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 7352–7364, Online. Association for Computational Linguistics.

Isabelle Augenstein, Christina Lioma, Dongsheng Wang, Lucas Chaves Lima, Casper Hansen, Christian Hansen, and Jakob Grue Simonsen. 2019. MultiFC: A real-world multi-domain dataset for evidence-based fact checking of claims. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 4685–4697, Hong Kong, China. Association for Computational Linguistics.

Omer Benjakob and Stephen Harrison. 2019. From anarchy to wikiality, glaring bias to good cop: Press coverage of wikipedia's first two decades. *Wikipedia @ 20*. Https://wikipedia20.pubpub.org/pub/tw83imoy.

Piotr Bojanowski, Edouard Grave, Armand Joulin, and Tomas Mikolov. 2017. Enriching word vectors with subword information. *Transactions of the Association for Computational Linguistics*, 5:135–146.

Samuel R. Bowman, Gabor Angeli, Christopher Potts, and Christopher D. Manning. 2015. A large annotated corpus for learning natural language inference. In *Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing*, pages 632–642, Lisbon, Portugal. Association for Computational Linguistics.

Ronan Le Bras, Swabha Swayamdipta, Chandra Bhagavatula, Rowan Zellers, Matthew Peters, Ashish Sabharwal, and Yejin Choi. 2020. Adversarial filters of dataset biases.

Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, Sandhini Agarwal, Ariel Herbert-Voss, Gretchen Krueger, Tom Henighan, Rewon Child, Aditya Ramesh, Daniel M. Ziegler, Jeffrey Wu, Clemens Winter, Christopher Hesse, Mark Chen, Eric Sigler, Mateusz Litwin, Scott Gray, Benjamin Chess, Jack Clark, Christopher Berner, Sam McCandlish, Alec Radford, Ilya Sutskever, and Dario Amodei. 2020. Language models are few-shot learners.

Oana-Maria Camburu, Tim Rocktäschel, Thomas Lukasiewicz, and Phil Blunsom. 2018. e-snli: Natural language inference with natural language explanations. In *Advances in Neural Information Processing Systems*, volume 31. Curran Associates, Inc.

Wenhu Chen, Hongmin Wang, Jianshu Chen, Yunkai Zhang, Hong Wang, Shiyang Li, Xiyou Zhou, and William Yang Wang. 2020. Tabfact: A large-scale dataset for table-based fact verification. In *International Conference on Learning Representations*.

Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. 2019. BERT: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*, pages 4171–4186, Minneapolis, Minnesota. Association for Computational Linguistics.

Jay DeYoung, Sarthak Jain, Nazneen Fatema Rajani, Eric Lehman, Caiming Xiong, Richard Socher, and Byron C. Wallace. 2020. ERASER: A benchmark to evaluate rationalized NLP models. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 4443–4458, Online. Association for Computational Linguistics.

Angela Fan, Aleksandra Piktus, Fabio Petroni, Guillaume Wenzek, Marzieh Saeidi, Andreas Vlachos, Antoine Bordes, and Sebastian Riedel. 2020. Generating fact checking briefs. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 7147–7161, Online. Association for Computational Linguistics.

Manaal Faruqui, Ellie Pavlick, Ian Tenney, and Dipanjan Das. 2018. WikiAtomicEdits: A multilingual corpus of Wikipedia edits for modeling language and discourse. In *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing*, pages 305–315, Brussels, Belgium. Association for Computational Linguistics.

Adam Fisch, Tal Schuster, Tommi S. Jaakkola, and Regina Barzilay. 2021. Efficient conformal prediction via cascaded inference with expanded admission. In *International Conference on Learning Representations*.

JL Fleiss. 1971. Measuring nominal scale agreement among many raters. *Psychological bulletin*, 76(5):378—382.

Matt Gardner, Yoav Artzi, Victoria Basmov, Jonathan Berant, Ben Bogin, Sihao Chen, Pradeep Dasigi, Dheeru Dua, Yanai Elazar, Ananth Gottumukkala, Nitish Gupta, Hannaneh Hajishirzi, Gabriel Ilharco, Daniel Khashabi, Kevin Lin, Jiangming Liu, Nelson F. Liu, Phoebe Mulcaire, Qiang Ning, Sameer Singh, Noah A. Smith, Sanjay Subramanian, Reut Tsarfaty, Eric Wallace, Ally Zhang, and Ben Zhou. 2020. Evaluating models' local decision boundaries via contrast sets. In *Findings of the Association for Computational Linguistics: EMNLP 2020*, pages 1307–1323, Online. Association for Computational Linguistics.

Suchin Gururangan, Swabha Swayamdipta, Omer Levy, Roy Schwartz, Samuel Bowman, and Noah A. Smith. 2018. Annotation artifacts in natural language inference data. In *Proceedings of the 2018*

Tài liệu tham khảo

Pepa Atanasova, Jakob Grue Simonsen, Christina Lioma, và Isabelle Augenstein. 2020. Tạo ra các giải thích kiểm chứng sự thật. Trong Kỷ yếu Hội nghị thường niên lần thứ 58 của Hiệp hội Ngôn ngữ học Máy tính, trang 7352–7364, Trực tuyến. Hiệp hội Ngôn ngữ học Máy tính.

Isabelle Augenstein, Christina Lioma, Dongsheng Wang, Lucas Chaves Lima, Casper Hansen, Christian Hansen, và Jakob Grue Simonsen. 2019. MultiFC: Một tập dữ liệu đa miền thực tế cho kiểm tra sự thật dựa trên bằng chứng của các tuyên bố. Trong Kỷ yếu Hội nghị năm 2019 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên và Hội nghị Liên hợp Quốc tế lần thứ 9 về Xử lý Ngôn ngữ Tự nhiên (EMNLP-IJCNLP), trang 4685–4697, Hồng Kông, Trung Quốc. Hiệp hội Ngôn ngữ Học Máy Tính.

Omer Benjakob và Stephen Harrison. 2019. Từ vô chính phủ đến wikiality, thiên vị rõ ràng đến viên cảnh sát tốt: Phủ sóng báo chí về hai thập kỷ đầu của Wikipedia. Wikipedia @ 20. Https://wikipedia20.pubpub.org/pub/tw83imoy.

Piotr Bojanowski, Edouard Grave, Armand Joulin, và Tomas Mikolov. 2017. Làm phong phú vectơ từ với thông tin tiểu từ. Transactions of the Association for Computational Linguistics, 5:135–146.

Samuel R. Bowman, Gabor Angeli, Christopher Potts, và Christopher D. Manning. 2015. Một tập hợp dữ liệu lớn có chú thích để học suy luận ngôn ngữ tự nhiên. Trong Kỷ yếu hội nghị năm 2015 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên, trang 632–642, Lisbon, Bồ Đào Nha. Hiệp hội Ngôn ngữ Học Tính Toán.

Ronan Le Bras, Swabha Swayamdipta, Chandra Bhagavatula, Rowan Zellers, Matthew Peters, Ashish Sabharwal, và Yejin Choi. 2020. Các bộ lọc đối kháng của thiên vị tập dữ liệu.

Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, Sandhini Agarwal, Ariel Herbert-Voss, Gretchen Krueger, Tom Henighan, Rewon Child, Aditya Ramesh, Daniel M. Ziegler, Jeffrey Wu, Clemens Winter, Christopher Hesse, Mark Chen, Eric Sigler, Mateusz Litwin, Scott Gray, Benjamin Chess, Jack Clark, Christopher Berner, Sa m Mc- Candlish, Alec Radford, Ilya Sutskever, và Dario Amodei. 2020. Mô hình ngôn ngữ là những người học ít ví dụ.

Oana-Maria Camburu, Tim Rocktäschel, Thomas Lukasiewicz và Phil Blunsom. 2018. e-snli: Suy luận ngôn ngữ tự nhiên với các giải thích bằng ngôn ngữ tự nhiên. Trong Advances in Neural Information Processing Systems, tập 31. Curran Associates, Inc.

Wenhu Chen, Hongmin Wang, Jianshu Chen, Yunkai Zhang, Hong Wang, Shiyang Li, Xiyou Zhou, và William Yang Wang. 2020. Tabfact: Một bộ dữ liệu quy mô lớn để xác minh sự thật dựa trên bảng. Trong Hội nghị Quốc tế về Học Biểu diễn.

Jacob Devlin, Ming-Wei Chang, Kenton Lee, và Kristina Toutanova. 2019. BERT: Tiền huấn luyện các biến đổi chiều sâu hai chiều cho hiểu ngôn ngữ. Trong Kỷ yếu Hội nghị 2019 của Hiệp hội Ngôn ngữ Học Tính Toán Bắc Mỹ: Công nghệ Ngôn ngữ Con người, Tập 1 (Bài báo dài và ngắn), trang 4171–4186, Minneapolis, Minnesota. Hiệp hội Ngôn ngữ Học Tính Toán.

Jay DeYoung, Sarthak Jain, Nazneen Fatema Rajani, Eric Lehman, Caiming Xiong, Richard Socher, và Byron C. Wallace. 2020. ERASER: Một chuẩn đánh giá để đánh giá các mô hình NLP có lý giải. Trong Kỷ yếu của Hội nghị thường niên lần thứ 58 của Hiệp hội Ngôn ngữ học Máy tính, trang 4443–4458, Trực t uyến. Hiệp hội Ngôn ngữ học Máy tính.

Angela Fan, Aleksandra Piktus, Fabio Petroni, Guillaume Wenzek, Marzieh Saeidi, Andreas Vlachos, Antoine Bordes, và Sebastian Riedel. 2020. Tạo các bản tóm tắt kiểm tra sự thật. Trong Kỷ yếu Hội nghị Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên 2020 (EMNLP), trang 7147–7161, Trực tuyến. Hiệp hội Ngôn ngữ Học Máy Tính.

Manaal Faruqui, Ellie Pavlick, Ian Tenney, và Dipanjan Das. 2018. WikiAtomicEdits: Một tập dữ liệu đa ngôn ngữ về các chỉnh sửa trên Wikipedia để mô hình hóa ngôn ngữ và diễn ngôn. Trong Kỷ yếu của Hội nghị Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên 2018, trang 305–315, Brussels, Bỉ. Hiệp hội Ngôn ngữ Học Máy Tính.

Adam Fisch, Tal Schuster, Tommi S. Jaakkola, và Regina Barzilay. 2021. Dự đoán tuân thủ hiệu quả thông qua suy luận theo cấp bậc với việc mở rộng chấp nhận. Trong Hội nghị Quốc tế về Học các Biểu diễn.

JL Fleiss. 1971. Đo lường sự đồng ý theo thang đo danh nghĩa giữa nhiều người đánh giá. Tạp chí Tâm lý học, 76(5):378—382.

Matt Gardner, Yoav Artzi, Victoria Basmov, Jonathan Berant, Ben Bogin, Sihao Chen, Pradeep Dasigi, Dheeru Dua, Yanai Elazar, Ananth Gottumukkala, Nitish Gupta, Hannaneh Hajishirzi, Gabriel Ilharco, Daniel Khashabi, Kevin Lin, Jiangming Liu, Nelson F. Liu, Phoebe Mulcaire, Qiang Ning, Sameer Singh, Noah A. Smith, Sanjay Subramanian, Reut Tsarfaty, Eric Wallace, Ally Zhang, và Ben Zhou. 2020. Đánh giá các ranh giới quyết định cục bộ của mô hình thông qua bộ đối chiếu. Trong Kết quả của Hiệp hội Ngôn ngữ học Máy tính: EMNLP 2020, các trang 1307–1323, Trực tuyến. Hiệp hội Ngôn ngữ học Máy tính.

Suchin Gururangan, Swabha Swayamdipta, Omer Levy, Roy Schwartz, Samuel Bowman, và Noah A. Smith. 2018. Các hiện vật chú thích trong dữ liệu suy diễn ngôn ngữ tự nhiên. Trong Kỷ yếu của năm 2018

Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 2 (Short Papers), pages 107–112, New Orleans, Louisiana. Association for Computational Linguistics.

Andreas Hanselowski, Hao Zhang, Zile Li, Daniil Sorokin, Benjamin Schiller, Claudia Schulz, and Iryna Gurevych. 2018. UKP-athene: Multi-sentence textual entailment for claim verification. In *Proceedings of the First Workshop on Fact Extraction and VERification (FEVER)*, pages 103–108, Brussels, Belgium. Association for Computational Linguistics.

Ari Holtzman, Jan Buys, Li Du, Maxwell Forbes, and Yejin Choi. 2020. The curious case of neural text degeneration. In *International Conference on Learning Representations*.

Alon Jacovi and Yoav Goldberg. 2020. Towards faithfully interpretable NLP systems: How should we define and evaluate faithfulness? In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 4198–4205, Online. Association for Computational Linguistics.

Eric Jang, Shixiang Gu, and Ben Poole. 2017. Categorical reparameterization with gumbel-softmax. In *International Conference on Learning Representations*.

Yichen Jiang, Shikha Bordia, Zheng Zhong, Charles Dognin, Maneesh Singh, and Mohit Bansal. 2020. HoVer: A dataset for many-hop fact extraction and claim verification. In *Findings of the Association for Computational Linguistics: EMNLP 2020*, pages 3441–3460, Online. Association for Computational Linguistics.

Saehan Jo, Immanuel Trummer, Weicheng Yu, Xuezhi Wang, Cong Yu, Daniel Liu, and Niyati Mehta. 2019. Aggchecker: A fact-checking system for text summaries of relational data sets. *Proc. VLDB Endow.*, 12(12):1938–1941.

Rabeeh Karimi Mahabadi, Yonatan Belinkov, and James Henderson. 2020. End-to-end bias mitigation by modelling biases in corpora. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 8706–8716, Online. Association for Computational Linguistics.

Wojciech Kryscinski, Bryan McCann, Caiming Xiong, and Richard Socher. 2020. Evaluating the factual consistency of abstractive text summarization. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 9332–9346, Online. Association for Computational Linguistics.

Srijan Kumar, Robert West, and Jure Leskovec. 2016. Disinformation on the web: Impact, characteristics, and detection of wikipedia hoaxes. In *WWW*, pages 591–602.

Ouyu Lan, Xiao Huang, Bill Yuchen Lin, He Jiang, Liyuan Liu, and Xiang Ren. 2020. Learning to contextually aggregate multi-source supervision for sequence labeling. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 2134–2146, Online. Association for Computational Linguistics.

Tao Lei, Regina Barzilay, and Tommi Jaakkola. 2016. Rationalizing neural predictions. In *Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing*, pages 107–117, Austin, Texas. Association for Computational Linguistics.

Mike Lewis, Yinhan Liu, Naman Goyal, Marjan Ghazvininejad, Abdelrahman Mohamed, Omer Levy, Veselin Stoyanov, and Luke Zettlemoyer. 2020a. BART: Denoising sequence-to-sequence pre-training for natural language generation, translation, and comprehension. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 7871–7880, Online. Association for Computational Linguistics.

Patrick Lewis, Ethan Perez, Aleksandara Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen tau Yih, Tim Rocktäschel, Sebastian Riedel, and Douwe Kiela. 2020b. Retrieval-augmented generation for knowledge-intensive nlp tasks.

Tom McCoy, Ellie Pavlick, and Tal Linzen. 2019. Right for the wrong reasons: Diagnosing syntactic heuristics in natural language inference. In *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*, pages 3428–3448, Florence, Italy. Association for Computational Linguistics.

Feng Nie, Jin-Ge Yao, Jinpeng Wang, Rong Pan, and Chin-Yew Lin. 2019a. A simple recipe towards reducing hallucination in neural surface realisation. In *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*, pages 2673–2679, Florence, Italy. Association for Computational Linguistics.

Yixin Nie, Haonan Chen, and Mohit Bansal. 2019b. Combining fact extraction and verification with neural semantic matching networks. *Proceedings of the AAAI Conference on Artificial Intelligence*, 33(01):6859–6866.

Yixin Nie, Adina Williams, Emily Dinan, Mohit Bansal, Jason Weston, and Douwe Kiela. 2020. Adversarial NLI: A new benchmark for natural language understanding. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 4885–4901, Online. Association for Computational Linguistics.

Kishore Papineni, Salim Roukos, Todd Ward, and Wei-Jing Zhu. 2002. Bleu: a method for automatic evaluation of machine translation. In *Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics*, pages 311–318, Philadelphia,

Hội nghị của Chi hội Bắc Mỹ của Hiệp hội Ngôn ngữ học Máy tính: Công nghệ Ngôn ngữ Con người, Tập 2 (Bài báo ngắn), trang 107–112, New Orleans, Louisiana. Hiệp hội Ngôn ngữ học Máy tính.

Andreas Hanselowski, Hao Zhang, Zile Li, Daniil Sorokin, Benjamin Schiller, Claudia Schulz và Iryna Gurevych. 2018. UKP-athene: Suy diễn ngôn từ nhiều câu cho xác minh tuyên bố. Trong Kỷ yếu của Hội thảo lần thứ nhất về Trích xuất Sự thật và Xác minh (FEVER), trang 103–108, Brussels, Bỉ. Hiệp hội Ngôn ngữ học Máy tính.

Ari Holtzman, Jan Buys, Li Du, Maxwell Forbes, và Yejin Choi. 2020. Trường hợp kỳ lạ của sự suy thoái văn bản thần kinh. Trong Hội nghị Quốc tế về Đại diện Học Tập.

Alon Jacovi và Yoav Goldberg. 2020. Hướng tới các hệ thống NLP có thể giải thích trung thực: Chúng ta nên định nghĩa và đánh giá sự trung thực như thế nào? Trong Kỷ yếu Hội nghị thường niên lần thứ 58 của Hiệp hội Ngôn ngữ học Máy tính, trang 4198–4205, Trực tuyến. Hiệp hội Ngôn ngữ học Máy tính.

Eric Jang, Shixiang Gu, và Ben Poole. 2017. Tái tham số hóa phân loại với gumbel-softmax. Trong Hội nghị Quốc tế về Học Các Biểu Diễn.

Yichen Jiang, Shikha Bordia, Zheng Zhong, Charles Dognin, Maneesh Singh, và Mohit Bansal. 2020. HoVer: Một bộ dữ liệu cho việc trích xuất sự kiện nhiều bước và xác minh tuyên bố. Trong Kết quả của Hiệp hội Ngôn ngữ học Máy tính: EMNLP 2020, trang 3441–3460, Trực tuyến. Hiệp hội Ngôn ngữ học Máy tính.

Saehan Jo, Immanuel Trummer, Weicheng Yu, Xuezhi Wang, Cong Yu, Daniel Liu, và Niyati Mehta. 2019. Aggchecker: Hệ thống kiểm tra sự thật cho các tóm tắt văn bản của các bộ dữ liệu quan hệ. Proc. VLDB Endow., 12(12):1938–1941.

Rabeeh Karimi Mahabadi, Yonatan Belinkov, và James Henderson. 2020. Giảm thiên lệch đầu-cuối bằng cách mô hình hóa các thiên lệch trong tập hợp ngôn ngữ. Trong Kỷ yếu Hội nghị thường niên lần thứ 58 của Hiệp hội Ngôn ngữ học Máy tính, trang 8706–8716, Trực tuyến. Hiệp hội Ngôn ngữ học Máy tính.

Wojciech Kryscinski, Bryan McCann, Caiming Xiong, và Richard Socher. 2020. Đánh giá sự nhất quán thực tế của tóm tắt văn bản trừu tượng. Trong Kỷ yếu của Hội nghị 2020 về Phương pháp Cực đoán trong Xử lý Ngôn ngữ Tự nhiên (EMNLP), trang 9332–9346, Trực tuyến. Hiệp hội Ngôn ngữ Học Máy tính.

Srijan Kumar, Robert West, và Jure Leskovec. 2016. Thông tin sai lệch trên web: Tác động, đặc điểm và phát hiện các trò lừa Wikipedia. Trong WWW, trang 591–602.

Ouyu Lan, Xiao Huang, Bill Yuchen Lin, He Jiang, Liyuan Liu, và Xiang Ren. 2020. Học cách tổng hợp có ngữ cảnh giám sát từ nhiều nguồn cho việc gán nhãn chuỗi. Trong Kỷ yếu của Hội nghị Thường niên lần thứ 58 của Hiệp hội Ngôn ngữ học Máy tính, trang 2134–2146, Trực tuyến. Hiệp hội Ngôn ngữ học Máy tính. Tao Lei, Regina Barzilay, và Tommi Jaakkola. 2016. Lý giải các dự đoán của mạng nơ-ron. Trong Kỷ yếu Hội nghị Năm 2016 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên, trang 107–117, Austin, Texas. Hiệp hội Ngôn ngữ học Máy tính.

Mike Lewis, Yinhan Liu, Naman Goyal, Marjan Ghazvininejad, Abdelrahman Mohamed, Omer Levy, Veselin Stoyanov, và Luke Zettlemoyer. 2020a. BART: Huấn luyện trước chuỗi-thành-chuỗi làm sạch nhiễu cho sinh ngôn ngữ tự nhiên, dịch thuật, và hiểu biết. Trong Kỷ yếu Hội nghị Thường niên lần thứ 58 của Hiệp hội Ngôn ngữ học Máy tính, trang 7871–7880, Trực tuyến. Hiệp hội Ngôn ngữ học Máy tính.

Patrick Lewis, Ethan Perez, Aleksandara Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen tau Yih, Tim Rocktäschel, Sebastian Riedel, và Douwe Kiela. 2020b. Tạo sinh được tăng cường truy xuất cho các nhiệm vụ NLP đòi hỏi nhiều kiến thức.

Tom McCoy, Ellie Pavlick và Tal Linzen. 2019. Đúng vì lý do sai: Chẩn đoán các mẹo cú pháp trong suy luận ngôn ngữ tự nhiên. Trong Kỷ yếu Hội nghị thường niên lần thứ 57 của Hiệp hội Ngôn ngữ học Máy tính, trang 3428–3448, Florence, Ý. Hiệp hội Ngôn ngữ học Máy tính.

Feng Nie, Jin-Ge Yao, Jinpeng Wang, Rong Pan, và Chin-Yew Lin. 2019a. Một công thức đơn giản hướng tới việc giảm ảo giác trong hiện thực hóa bề mặt t hần kinh. Trong Kỷ yếu Hội nghị thường niên lần t hứ 57 của Hiệp hội Ngôn ngữ học Tính toán, các trang 2673–2679, Florence, Ý. Hiệp hội Ngôn ngữ học Tính toán.

Yixin Nie, Haonan Chen, và Mohit Bansal. 2019b. Kết hợp trích xuất sự kiện và xác minh với mạng đối sánh ngữ nghĩa thần kinh. Kỷ yếu Hội nghị AAAI về Trí tuệ Nhân tạo, 33(01):6859–6866.

Yixin Nie, Adina Williams, Emily Dinan, Mohit Bansal, Jason Weston, và Douwe Kiela. 2020. Adversarial NLI: Một chuẩn mực mới cho hiểu ngôn ngữ tự nhiên. Trong Kỷ yếu của Hội nghị hàng năm lần thứ 58 Hiệp hội Ngôn ngữ Học Tính Toán, trang 4885–4901, Trực tuyến. Hiệp hội Ngôn ngữ Học Tính Toán.

Kishore Papineni, Salim Roukos, Todd Ward và Wei-Jing Zhu. 2002. Bleu: một phương pháp đánh giá tự động dịch máy. Trong Kỷ yếu Hội nghị thường niên lần thứ 40 của Hiệp hội Ngôn ngữ học Tính t oán, trang 311–318, Philadelphia,

Pennsylvania, USA. Association for Computational Linguistics.

Ankur Parikh, Xuezhi Wang, Sebastian Gehrmann, Manaal Faruqui, Bhuwan Dhingra, Diyi Yang, and Dipanjan Das. 2020. ToTTo: A controlled table-to-text generation dataset. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 1173–1186, Online. Association for Computational Linguistics.

Mithun Paul Panenghat, Sandeep Suntwal, Faiz Rafique, Rebecca Sharp, and Mihai Surdeanu. 2020. Towards the necessity for debiasing natural language inference datasets. In *Proceedings of the 12th Language Resources and Evaluation Conference*, pages 6883–6888, Marseille, France. European Language Resources Association.

Fabio Petroni, Aleksandra Piktus, Angela Fan, Patrick Lewis, Majid Yazdani, Nicola De Cao, James Thorne, Yacine Jernite, Vassilis Plachouras, Tim Rocktäschel, and Sebastian Riedel. 2020. Kilt: a benchmark for knowledge intensive language tasks.

Fabio Petroni, Tim Rocktäschel, Sebastian Riedel, Patrick Lewis, Anton Bakhtin, Yuxiang Wu, and Alexander Miller. 2019. Language models as knowledge bases? In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 2463–2473, Hong Kong, China. Association for Computational Linguistics.

Adam Poliak, Jason Naradowsky, Aparajita Haldar, Rachel Rudinger, and Benjamin Van Durme. 2018. Hypothesis only baselines in natural language inference. In *Proceedings of the Seventh Joint Conference on Lexical and Computational Semantics*, pages 180–191, New Orleans, Louisiana. Association for Computational Linguistics.

Kashyap Popat, Subhabrata Mukherjee, Andrew Yates, and Gerhard Weikum. 2018. DeClarE: Debunking fake news and false claims using evidence-aware deep learning. In *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing*, pages 22–32, Brussels, Belgium. Association for Computational Linguistics.

Beatrice Portelli, Jason Zhao, Tal Schuster, Giuseppe Serra, and Enrico Santus. 2020. Distilling the evidence to augment fact verification models. In *Proceedings of the Third Workshop on Fact Extraction and VERification (FEVER)*, pages 47–51, Online. Association for Computational Linguistics.

Adithya Pratapa, Sai Muralidhar Jayanthi, and Kavya Nerella. 2020. Constrained Fact Verification for FEVER. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 7826–7832, Online. Association for Computational Linguistics.

Colin Raffel, Noam Shazeer, Adam Roberts, Katherine Lee, Sharan Narang, Michael Matena, Yanqi Zhou, W. Li, and Peter J. Liu. 2020. Exploring the limits of transfer learning with a unified text-to-text transformer. *J. Mach. Learn. Res.*, 21:140:1–140:67.

Marco Tulio Ribeiro, Tongshuang Wu, Carlos Guestrin, and Sameer Singh. 2020. Beyond accuracy: Behavioral testing of NLP models with CheckList. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 4902–4912, Online. Association for Computational Linguistics.

Adam Roberts, Colin Raffel, and Noam Shazeer. 2020. How much knowledge can you pack into the parameters of a language model? In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 5418–5426, Online. Association for Computational Linguistics.

Kevin Roitero, Michael Soprano, Beatrice Portelli, Damiano Spina, Vincenzo Della Mea, Giuseppe Serra, Stefano Mizzaro, and Gianluca Demartini. 2020. The covid-19 infodemic: Can the crowd judge recent misinformation objectively? CIKM '20, page 1305–1314, New York, NY, USA. Association for Computing Machinery.

Alexis Ross, Ana Marasović, and Matthew E. Peters. 2020. Explaining nlp models via minimal contrastive editing (mice).

Aalok Sathe, Salar Ather, Tuan Manh Le, Nathan Perry, and Joonsuk Park. 2020. Automated fact-checking of claims from Wikipedia. In *Proceedings of the 12th Language Resources and Evaluation Conference*, pages 6874–6882, Marseille, France. European Language Resources Association.

Tal Schuster, Roei Schuster, Darsh J. Shah, and Regina Barzilay. 2020. The limitations of stylometry for detecting machine-generated fake news. *Computational Linguistics*, 46(2):499–510.

Tal Schuster, Darsh Shah, Yun Jie Serene Yeo, Daniel Roberto Filizzola Ortiz, Enrico Santus, and Regina Barzilay. 2019. Towards debiasing fact verification models. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 3419–3425, Hong Kong, China. Association for Computational Linguistics.

Thibault Sellam, Dipanjan Das, and Ankur Parikh. 2020. BLEURT: Learning robust metrics for text generation. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 7881–7892, Online. Association for Computational Linguistics.

Darsh J Shah, Tal Schuster, and Regina Barzilay. 2020. Automatic fact-guided sentence modification. In *Association for the Advancement of Artificial Intelligence (AAAI)*.

Pennsylvania, Hoa Kỳ. Hiệp hội Ngôn ngữ học Tính toán.

Ankur Parikh, Xuezhi Wang, Sebastian Gehrmann, Manaal Faruqui, Bhuwan Dhingra, Diyi Yang, và Dipanjan Das. 2020. ToTTo: Một bộ dữ liệu tạo văn bản từ bảng có kiểm soát. Trong Kỷ yếu của Hội nghị Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên 2020 (EMNLP), trang 1173–1186, Trực tuyến. Hiệp hội Ngôn ngữ Học Máy Tính.

Mithun Paul Panenghat, Sandeep Suntwal, Faiz Rafique, Rebecca Sharp, và Mihai Surdeanu. 2020. Hướng tới sự cần thiết của việc loại bỏ thành kiến trong các tập dữ liệu suy luận ngôn ngữ tự nhiên. Trong Kỷ yếu của Hội nghị Đánh giá và Tài nguyên Ngôn ngữ lần thứ 12, trang 6883–6888, Marseille, Pháp. Hiệp hội Tài nguyên Ngôn ngữ Châu Âu.

Fabio Petroni, Aleksandra Piktus, Angela Fan, Patrick Lewis, Majid Yazdani, Nicola De Cao, James Thorne, Yacine Jernite, Vassilis Plachouras, Tim Rocktäschel, và Sebastian Riedel. 2020. Kilt: một chuẩn đánh giá cho các nhiệm vụ ngôn ngữ đòi hỏi nhiều kiến thức.

Fabio Petroni, Tim Rocktäschel, Sebastian Riedel, Patrick Lewis, Anton Bakhtin, Yuxiang Wu, và Alexander Miller. 2019. Các mô hình ngôn ngữ như các cơ sở tri thức? Trong Kỷ yếu Hội nghị năm 2019 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên và Hội nghị Liên hợp Quốc tế lần thứ 9 về Xử lý Ngôn ngữ Tự nhiên (EMNLP-IJCNLP), trang 2463–2473, Hồng Kông, Trung Quốc. Hiệp hội Ngôn ngữ học Máy tính.

Adam Poliak, Jason Naradowsky, Aparajita Haldar, Rachel Rudinger và Benjamin Van Durme. 2018. Các đường cơ sở chỉ dựa trên giả thuyết trong suy luận ngôn ngữ tự nhiên. Trong Kỷ yếu Hội nghị Liên hợp lần thứ bảy về Ngữ nghĩa Từ vựng và Tính toán, trang 180–191, New Orleans, Louisiana. Hiệp hội Ngôn ngữ Học Tính toán.

Kashyap Popat, Subhabrata Mukherjee, Andrew Yates, và Gerhard Weikum. 2018. DeClarE: Phá vỡ ti n giả và các tuyên bố sai bằng cách sử dụng học sâu nhận thức bằng chứng. Trong Kỷ yếu của Hội nghị 2018 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên, trang 22–32, Brussels, Bỉ. Hiệp hội Ngôn ngữ Học Máy Tính.

Beatrice Portelli, Jason Zhao, Tal Schuster, Giuseppe Serra, và Enrico Santus. 2020. Chưng cất bằng chứng để tăng cường các mô hình xác minh sự thật. Trong Kỷ yếu của Hội thảo Thứ ba về Trích xuất và Xác minh Sự thật (FEVER), trang 47–51, Trực tuyến. Hiệp hội Ngôn ngữ học Máy tính.

Adithya Pratapa, Sai Muralidhar Jayanthi, và Kavya Nerella. 2020. Xác minh sự thật có ràng buộc cho FEVER. Trong Kỷ yếu Hội nghị năm 2020 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên (EMNLP), trang 7826–7832, Trực tuyến. Hiệp hội Ngôn ngữ Học Máy Tính.

Colin Raffel, Noam Shazeer, Adam Roberts, Katherine Lee, Sharan Narang, Michael Matena, Yanqi Zhou, W. Li, và Peter J. Liu. 2020. Khám phá giới hạn của học chuyển giao với một bộ biến đổi văn bản-thành-văn bản thống nhất. J. Mach. Learn. Res., 21:140:1–140:67.

MarcoTulio Ribeiro, Tongshuang Wu, Carlos Guestrin, và Sameer Singh. 2020. Vượt ra ngoài độ chính xác: Kiểm tra hành vi của các mô hình NLP với CheckList. Trong Kỷ yếu Hội nghị thường niên lần thứ 58 của Hiệp hội Ngôn ngữ học Máy tính, trang 4902–4912, Trực tuyến. Hiệp hội Ngôn ngữ học Máy tính.

AdamRoberts, Colin Raffel và Noam Shazeer. 2020. Bạn có thể nhồi nhét bao nhiêu kiến thức vào các tham số của một mô hình ngôn ngữ? Trong Kỷ yếu Hội nghị 2020 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên (EMNLP), trang 5418–5426, Trực tuyến. Hiệp hội Ngôn ngữ Học Máy tính.

Kevin Roitero, Michael Soprano, Beatrice Portelli, Damiano Spina, Vincenzo Della Mea, Giuseppe Serra, Stefano Mizzaro, và Gianluca Demartini. 2020. Cuộc khủng hoảng thông tin covid-19: Liệu đám đông có thể đánh giá thông tin sai lệch gần đây một cách khách quan? CIKM '20, trang 1305–1314, New York, NY, Mỹ. Hiệp hội Máy tính.

Alexis Ross, Ana Marasović, và Matthew E. Peters. 2020. Giải thích các mô hình xử lý ngôn ngữ tự nhiên thông qua chỉnh sửa đối lập tối thiểu (MICE).

Aalok Sathe, Salar Ather, TuanManh Le, Nathan Perry, và Joonsuk Park. 2020. Kiểm chứng tự động các tuyên bố từ Wikipedia. Trong Kỷ yếu Hội nghị Đánh giá và Tài nguyên Ngôn ngữ lần thứ 12, trang 6874–6882, Marseille, Pháp. Hiệp hội Tài nguyên Ngôn ngữ Châu Âu.

Tal Schuster, Roei Schuster, Darsh J. Shah, và Regina Barzilay. 2020. Những hạn chế của phong cách học (stylometry) trong việc phát hiện tin tức giả được tạo bởi máy. Ngôn ngữ học Máy tính, 46(2):499–510.

Tal Schuster, Darsh Shah, Yun Jie Serene Yeo, Daniel Roberto Filizzola Ortiz, Enrico Santus và Regina Barzilay. 2019. Hướng tới việc loại bỏ thiên lệch t rong các mô hình xác minh sự thật. Trong Kỷ yếu Hội nghị 2019 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên và Hội nghị Liên hợp Quốc tế lần thứ 9 về Xử lý Ngôn ngữ Tự nhiên (EMNLP-IJCNLP), trang 3419–3425, Hồng Kông, Trung Quốc. Hiệp hội Ngôn ngữ Học Máy tính.

Thibault Sellam, Dipanjan Das và Ankur Parikh. 2020. BLEURT: Học các chỉ số mạnh mẽ cho tạo văn bản. Trong Kỷ yếu Hội nghị thường niên lần thứ 58 của Hiệp hội Ngôn ngữ học Máy tính, trang 7881–7892, Trực tuyến. Hiệp hội Ngôn ngữ học Máy tính.

Darsh J Shah, Tal Schuster, và Regina Barzilay. 2020. Tự động chỉnh sửa câu theo hướng dẫn thực tế. Trong Hiệp hội Thúc đẩy Trí tuệ Nhân tạo (AAAI).

James Thorne and Andreas Vlachos. 2018. Automated fact checking: Task formulations, methods and future directions. In *Proceedings of the 27th International Conference on Computational Linguistics*, pages 3346–3359, Santa Fe, New Mexico, USA. Association for Computational Linguistics.

James Thorne and Andreas Vlachos. 2020. Avoiding catastrophic forgetting in mitigating model biases in sentence-pair classification with elastic weight consolidation.

James Thorne, Andreas Vlachos, Christos Christodoulopoulos, and Arpit Mittal. 2018. FEVER: a large-scale dataset for fact extraction and VERification. In *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long Papers)*, pages 809–819, New Orleans, Louisiana. Association for Computational Linguistics.

James Thorne, Andreas Vlachos, Christos Christodoulopoulos, and Arpit Mittal. 2019a. Evaluating adversarial attacks against multiple fact verification systems. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 2944–2953, Hong Kong, China. Association for Computational Linguistics.

James Thorne, Andreas Vlachos, Christos Christodoulopoulos, and Arpit Mittal. 2019b. Generating token-level explanations for natural language inference. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*, pages 963–969, Minneapolis, Minnesota. Association for Computational Linguistics.

James Thorne, Andreas Vlachos, Oana Cocarascu, Christos Christodoulopoulos, and Arpit Mittal. 2019c. The FEVER2.0 shared task. In *Proceedings of the Second Workshop on Fact Extraction and VERification (FEVER)*, pages 1–6, Hong Kong, China. Association for Computational Linguistics.

Ran Tian, Shashi Narayan, Thibault Sellam, and Ankur P. Parikh. 2020. Sticking to the facts: Confident decoding for faithful data-to-text generation.

Masatoshi Tsuchiya. 2018. Performance impact caused by hidden bias of training data for recognizing textual entailment. In *Proceedings of the Eleventh International Conference on Language Resources and Evaluation (LREC 2018)*, Miyazaki, Japan. European Language Resources Association (ELRA).

Prasetya Ajie Utama, Nafise Sadat Moosavi, and Iryna Gurevych. 2020a. Mind the trade-off: Debiasing NLU models without degrading the in-distribution performance. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 8717–8729, Online. Association for Computational Linguistics.

Prasetya Ajie Utama, Nafise Sadat Moosavi, and Iryna Gurevych. 2020b. Towards debiasing NLU models from unknown biases. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 7597–7610, Online. Association for Computational Linguistics.

Eric Wallace, Shi Feng, Nikhil Kandpal, Matt Gardner, and Sameer Singh. 2019. Universal adversarial triggers for attacking and analyzing NLP. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 2153–2162, Hong Kong, China. Association for Computational Linguistics.

William Yang Wang. 2017. "liar, liar pants on fire": A new benchmark dataset for fake news detection. In *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers)*, pages 422–426, Vancouver, Canada. Association for Computational Linguistics.

Adina Williams, Nikita Nangia, and Samuel Bowman. 2018. A broad-coverage challenge corpus for sentence understanding through inference. In *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long Papers)*, pages 1112–1122, New Orleans, Louisiana. Association for Computational Linguistics.

Thomas Wolf, Lysandre Debut, Victor Sanh, Julien Chaumond, Clement Delangue, Anthony Moi, Pierric Cistac, Tim Rault, Rémi Louf, Morgan Funtowicz, Joe Davison, Sam Shleifer, Patrick von Platen, Clara Ma, Yacine Jernite, Julien Plu, Canwen Xu, Teven Le Scao, Sylvain Gugger, Mariama Drame, Quentin Lhoest, and Alexander M. Rush. 2019. Huggingface's transformers: State-of-the-art natural language processing. *ArXiv*, abs/1910.03771.

Wei Xu, Courtney Napoles, Ellie Pavlick, Quanze Chen, and Chris Callison-Burch. 2016. Optimizing statistical machine translation for text simplification. *Transactions of the Association for Computational Linguistics*, 4:401–415.

Diyi Yang, Aaron Halfaker, Robert Kraut, and Eduard Hovy. 2017. Identifying semantic edit intentions from revisions in Wikipedia. In *Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing*, pages 2000–2010, Copenhagen, Denmark. Association for Computational Linguistics.

Takuma Yoneda, Jeff Mitchell, Johannes Welbl, Pontus Stenetorp, and Sebastian Riedel. 2018. UCL machine reading group: Four factor framework for fact

James Thorne và Andreas Vlachos. 2018. Kiểm tra sự thật tự động: Các công thức nhiệm vụ, phương pháp và hướng đi tương lai. Trong Kỷ yếu Hội nghị Quốc tế lần thứ 27 về Ngôn ngữ học Máy tính, trang 3346–3359, Santa Fe, New Mexico, Hoa Kỳ. Hiệp hội Ngôn ngữ học Máy tính.

James Thorne và Andreas Vlachos. 2020. Tránh quên dữ dội trong việc giảm thiểu thiên vị mô hình trong phân loại cặp câu với việc hoán tịnh trọng số đàn hồi.

James Thorne, Andreas Vlachos, Christos Christodoulopoulos, và Arpit Mittal. 2018. FEVER: một bộ dữ liệu quy mô lớn cho việc trích xuất và xác minh sự thật. Trong Kỷ yếu Hội nghị 2018 của Chương Bắc Mỹ Hiệp hội Ngôn ngữ học Máy tính: Công nghệ Ngôn ngữ Con người, Tập 1 (Bài báo Dài), trang 809–819, New Orleans, Louisiana. Hiệp hội Ngôn ngữ học Máy tính.

James Thorne, Andreas Vlachos, Christos Christodoulopoulos và Arpit Mittal. 2019a. Đánh giá các cuộc tấn công đối kháng chống lại nhiều hệ t hống xác minh sự thật. Trong Kỷ yếu của Hội nghị 2019 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên và Hội nghị Liên hợp Quốc tế lần thứ 9 về Xử lý Ngôn ngữ Tự nhiên (EMNLP-IJCNLP), các trang 2944–2953, Hồng Kông, Trung Quốc. Hiệp hội Ngôn ngữ Học Máy Tính.

James Thorne, Andreas Vlachos, Christos Christodoulopoulos, và Arpit Mittal. 2019b. Tạo giải thích mức token cho suy luận ngôn ngữ tự nhiên. Trong Kỷ yếu Hội nghị năm 2019 của Chương Bắc Mỹ thuộc Hiệp hội Ngôn ngữ học Máy tính: Công nghệ Ngôn ngữ Con người, Tập 1 (Bài báo Dài và Ngắn), các trang 963–969, Minneapolis, Minnesota. Hiệp hội Ngôn ngữ học Máy tính.

James Thorne, Andreas Vlachos, Oana Cocarascu, Christos Christodoulopoulos, và Arpit Mittal. 2019c. Nhiệm vụ chia sẻ FEVER2.0. Trong Kỷ yếu của Hội thảo thứ hai về Trích xuất và Xác minh Thực tế (FEVER), trang 1–6, Hồng Kông, Trung Quốc. Hiệp hội Ngôn ngữ Học Tính toán.

Ran Tian, Shashi Narayan, Thibault Sellam và Ankur P. Parikh. 2020. Bám sát sự thật: Giải mã tự tin để tạo dữ liệu-thành-văn bản trung thực.

Masatoshi Tsuchiya. 2018. Tác động hiệu suất gây ra bởi sự thiên vị ẩn trong dữ liệu huấn luyện để nhận dạng suy diễn văn bản. Trong Kỷ yếu Hội nghị Quốc tế lần thứ Mười Một về Tài nguyên Ngôn ngữ và Đánh giá (LREC 2018), Miyazaki, Nhật Bản. Hiệp hội Tài nguyên Ngôn ngữ Châu Âu (ELRA).

Prasetya Ajie Utama, Nafise Sadat Moosavi, và Iryna Gurevych. 2020a. Lưu ý đến sự đánh đổi: Loại bỏ thiên kiến trong các mô hình NLU mà không làm giảm hiệu suất trong phân phối. Trong Kỷ yếu Hội nghị thường niên lần thứ 58 Hội nghị Hiệp hội Ngôn ngữ học Máy tính, trang 8717–8729, Trực tuyến. Hiệp hội Ngôn ngữ học Máy tính.

Prasetya Ajie Utama, Nafise Sadat Moosavi, và Iryna Gurevych. 2020b. Hướng tới việc loại bỏ thiên vị khỏi các mô hình NLU từ những thiên vị chưa biết. Trong Kỷ yếu Hội nghị Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên 2020 (EMNLP), trang 7597–7610, Trực tuyến. Hiệp hội Ngôn ngữ Tính toán.

Eric Wallace, Shi Feng, Nikhil Kandpal, Matt Gardner, và Sameer Singh. 2019. Các kích hoạt đối kháng phổ quát để tấn công và phân tích NLP. Trong Kỷ yếu Hội nghị 2019 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên và Hội nghị Liên hợp Quốc tế lần thứ 9 về Xử lý Ngôn ngữ Tự nhiên (EMNLP-IJCNLP), trang 2153–2162, Hồng Kông, Trung Quốc. Hiệp hội Ngôn ngữ Học Tính toán.

William Yang Wang. 2017. "Kẻ nói dối, kẻ nói dối quần đang cháy": Một bộ dữ liệu chuẩn mới cho phát hiện tin giả. Trong Kỷ yếu cuộc họp thường niên lần thứ 55 của Hiệp hội Ngôn ngữ học Máy tính (Tập 2: Bài báo ngắn), trang 422–426, Vancouver, Canada. Hiệp hội Ngôn ngữ học Máy tính.

Adina Williams, Nikita Nangia, và Samuel Bowman. 2018. Một tập hợp thách thức bao quát cho việc hiểu câu thông qua suy luận. Trong Kỷ yếu Hội nghị 2018 của Chương Bắc Mỹ thuộc Hiệp hội Ngôn ngữ học Máy tính: Công nghệ Ngôn ngữ Con người, Tập 1 (Bài dài), các trang 1112–1122, New Orleans, Louisiana. Hiệp hội Ngôn ngữ học Máy tính.

Thomas Wolf, Lysandre Debut, Victor Sanh, Julien Chaumond, Clement Delangue, Anthony Moi, Pierric Cistac, Tim Rault, Rémi Louf, Morgan Funtowicz, Joe Davison, Sam Shleifer, Patrick von Platen, Clara Ma, Yacine Jernite, Julien Plu, Canwen Xu, Teven Le Scao, Sylvain Gugger, Mariama Drame, Quentin Lhoest, và Alexander M. Rush. 2019. Huggingface's transformers: Xử lý ngôn ngữ tự nhiên tiên tiến nhất. ArXiv, abs/1910.03771.

Wei Xu, Courtney Napoles, Ellie Pavlick, Quanze Chen, và Chris Callison-Burch. 2016. Tối ưu hóa dịch máy thống kê cho việc đơn giản hóa văn bản. Transactions of the Association for Computational Linguistics, 4:401–415.

Diyi Yang, Aaron Halfaker, Robert Kraut và Eduard Hovy. 2017. Xác định ý định chỉnh sửa ngữ nghĩa từ các sửa đổi trong Wikipedia. Trong Kỷ yếu Hội nghị Phương pháp Thực nghiệm về Xử lý Ngôn ngữ Tự nhiên 2017, các trang 2000–2010, Copenhagen, Đan Mạch. Hiệp hội Ngôn ngữ Học Tính Toán.

Takuma Yoneda, Jeff Mitchell, Johannes Welbl, Pontus Stenetorp, và Sebastian Riedel. 2018. Nhóm đọc máy UCL: Khung bốn yếu tố cho sự thật

finding (HexaF). In *Proceedings of the First Workshop on Fact Extraction and VERification (FEVER)*, pages 97–102, Brussels, Belgium. Association for Computational Linguistics.

Yuan Zhang, Jason Baldridge, and Luheng He. 2019. PAWS: Paraphrase adversaries from word scrambling. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*, pages 1298–1308, Minneapolis, Minnesota. Association for Computational Linguistics.

Chunting Zhou, Jiatao Gu, Mona Diab, Paco Guzman, Luke Zettlemoyer, and Marjan Ghazvininejad. 2020. Detecting hallucinated content in conditional neural sequence generation.

A VITAMINC: Complementary details

We provide additional details about the VITAMINC dataset.

A.1 Claim Statistics

Topic Distribution. Figure A.1 shows the distribution of claims in the VITAMINC dataset by the topic of the Wikipedia article they are based on. The information was collected from DBpedia,[12] retrieving the parent class of the pages. Labels for about 25% of the articles were missing, and left blank in the diagram.

The "synthetic" part of VITAMINC, which is based on the claims of the FEVER dataset, contains many claims about specific human entities. About 15% of the claims in VITAMINC real are about COVID-19.

Category Distribution. We sample 100 examples from the "real" and "synthetic" subsets of VITAMINC and manually categorize their claims. The results are presented in Table A.1. Due to the creation methodology of VITAMINC real, its claims mostly describe frequently updating facts, or facts that tend to be corrected. We find about half of these claims to describe changes in numerical values (e.g., number of COVID-19 cases, earnings or ratings of movies, number of awards etc.). In contrast, VITAMINC synthetic mostly covers general facts about specific entities, (e.g., place of birth, date of birth, occupation, etc.). This is a result of the synthetic claims being based on the FEVER dataset, where annotators were asked to come up with claims on popular Wikipedia pages. Combined, the VITAMINC dataset holds a diverse set of claims about various topics.

[12] http://dbpedia.org/ontology/

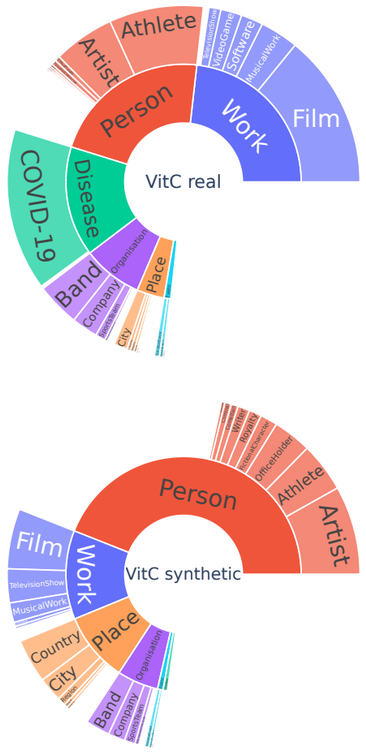


Figure A.1: Distribution of claims in the VITAMINC dataset by the topic of the originated Wikipedia article.

A.2 Inter-annotator Agreement

We ask three additional annotators to independently annotate a random set of two thousand claim-evidence pairs, evenly distributed between the development and test splits of the real and synthetic sets. The Fleiss κ score (Fleiss, 1971) between the four annotations is 0.7065, which means substantial agreement. Similar agreement scores of 0.6841 and 0.7 were reported for fact verification (Thorne et al., 2018) and NLI datasets (Bowman et al., 2015), respectively.

A.3 Claim-only Classification

Annotation artifacts are common in crowd-sourced sentence-pair inference datasets such as fact verification and NLI. Models can leverage these idiosyncrasies to achieve unexpectedly high performance when given only one sentence of the pair. For example, Schuster et al. (2019) showed that a claim-only classifier can obtain 61.7% accuracy. The VITAMINC dataset avoids this bias by pairing each claim with two contrastive contexts.

finding (HexaF). Trong Kỷ yếu của Hội thảo đầu tiên về Trích xuất và Xác minh Thực tế (FEVER), trang 97–102, Brussels, Bỉ. Hiệp hội Ngôn ngữ Học Máy.

Yuan Zhang, Jason Baldridge, và Luheng He. 2019. PAWS: Đối thủ paraphrase từ việc xáo trộn từ. Trong Kỷ yếu của Hội nghị 2019 của Chi nhánh Bắc Mỹ thuộc Hiệp hội Ngôn ngữ học Máy tính: Công nghệ Ngôn ngữ Con người, Tập 1 (Bài dài và bài ngắn), trang 1298–1308, Minneapolis, Minnesota. Hiệp hội Ngôn ngữ học Máy tính.

Chunting Zhou, Jiatao Gu, Mona Diab, Paco Guzman, Luke Zettlemoyer, và Marjan Ghazvininejad. 2020. Phát hiện nội dung ảo tưởng trong sinh chuỗi thần kinh có điều kiện.

A VITAMINC: Chi tiết bổ sung

Chúng tôi cung cấp thêm chi tiết về bộ dữ liệu VITAMINC.

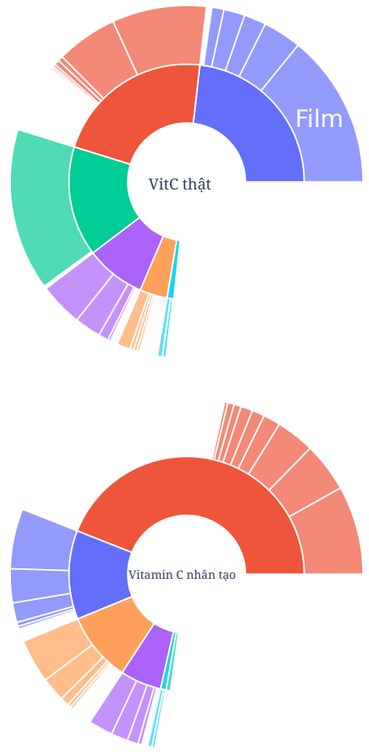
A.1 Thống kê yêu cầu

Phân bố Chủ đề. Hình A.1 cho thấy phân bố các tuyên bố trong bộ dữ liệu VITAMINC theo chủ đề của bài viết Wikipedia mà chúng dựa trên. Thông tin được thu thập từ DBpedia,[12]truy xuất lớp cha của các trang. Nhãn cho khoảng 25% các bài viết bị thiếu và được để trống trong sơ đồ.

Phần "tổng hợp" của VITAMINC, dựa trên các tuyên bố của bộ dữ liệu FEVER, chứa nhiều tuyên bố về các thực thể con người cụ thể. Khoảng 15% các tuyên bố trong VITAMINC thực sự liên quan đến COVID-19.

Phân bố theo danh mục. Chúng tôi lấy mẫu 100 ví dụ từ các tập con "thực" và "nhân tạo" của VITAMINC và phân loại các tuyên bố của chúng theo cách thủ công. Kết quả được trình bày t rong Bảng A.1. Do phương pháp tạo ra VITAMINC thực, các tuyên bố của nó chủ yếu mô tả các sự kiện thường xuyên được cập nhật, hoặc các sự kiện có xu hướng được sửa đổi. Chúng tôi nhận thấy khoảng một nửa các tuyên bố này mô tả sự thay đổi về giá trị số (ví dụ: số ca COVID-19, doanh thu hoặc xếp hạng phim, số giải thưởng, v.v.). Ngược lại, VITAMINC nhân tạo chủ yếu bao gồm các sự kiện tổng quát về các thực thể cụ thể (ví dụ: nơi sinh, ngày sinh, nghề nghiệp, v.v.). Điều này là kết quả của việc các tuyên bố nhân tạo dựa trên bộ dữ liệu FEVER, nơi các người gán nhãn được yêu cầu tạo ra các tuyên bố về các trang Wikipedia phổ biến. Tổng thể, bộ dữ liệu VITAMINC chứa một tập hợp đa dạng các tuyên bố về nhiều chủ đề khác nhau.

[12] http://dbpedia.org/ontology/



Hình A.1: Phân bố các tuyên bố trong tập dữ liệu VITAMINC theo chủ đề của bài viết Wikipedia gốc.

A.2 Thỏa thuận giữa các người chú thích

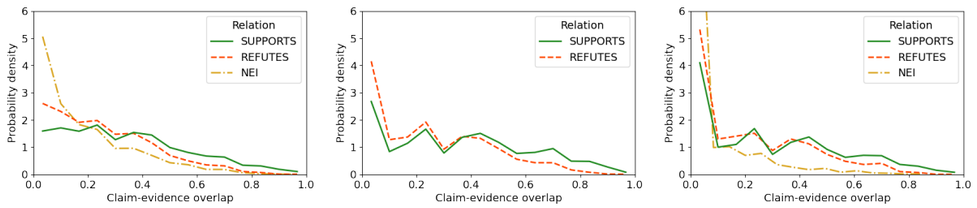
Chúng tôi yêu cầu ba người chú thích bổ sung để độc lập chú thích một tập hợp ngẫu nhiên gồm hai nghìn cặp khẳng định - bằng chứng, phân bổ đều giữa các phân tách phát triển và kiểm tra của các bộ dữ liệu thực và tổng hợp. Điểm Fleiss κ (Fleiss, 1971) giữa bốn chú thích là 0,7065, có nghĩa là có sự đồng thuận đáng kể. Các điểm đồng thuận tương tự là 0,6841 và 0,7 đã được báo cáo cho việc xác minh sự thật (Thorne et al., 2018) và các bộ dữ liệu NLI (Bowman et al., 2015), tương ứng.

A.3 Phân loại chỉ dựa trên tuyên bố

Các hiện vật chú thích là phổ biến trong các bộ dữ liệu suy luận cặp câu dựa trên đám đông như xác minh sự thật và NLI. Các mô hình có t hể tận dụng những đặc điểm kỳ quặc này để đạt hiệu suất cao bất ngờ khi chỉ được cung cấp một câu trong cặp. Ví dụ, Schuster và cộng sự (2019) đã chỉ ra rằng một bộ phân loại chỉ dựa trên tuyên bố có thể đạt độ chính xác 61,7%. Bộ dữ liệu VITAMINC tránh thiên lệch này bằng cách ghép mỗi tuyên bố với hai bối cảnh đối lập.

Claim category	real	synthetic	Example
Quantitative	48%	9%	The COVID-19 pathogen may last less than 10 days on some surfaces.
Calendrical	9%	15%	Italy surpassed the 10,000 coronavirus-related deaths on a Saturday.
Entity	23%	58%	Mary of Teck was queen-consort.
Event	14%	14%	In the last EFL Cup, Manchester defeated Chelsea.
Other	6%	4%	Most genes need further research to better understand the function of their RNA products.

Table A.1: Estimated distribution of claims in the VITAMINC, based on manual annotations of 100 randomly sampled claims from the development split of the real and synthetic subsets. An example claim from each category is provided for reference.



(a) VITAMINC real (b) VITAMINC synthetic (c) FEVER

Figure A.2: Probability density function of claim-evidence overlap for different labels in the dataset. The overlap is computed as the ratio of mutual bigrams in the two sentences.

All claims in the VITAMINC-synthetic are paired with one refuting and one supporting evidence, making it impossible for a claim-only to perform better than random. Each claim in the VITAMINC-real is paired with one refuting or neutral evidence, in addition to a supporting one. To evaluate whether models can utilize lexical cues in claims, we train a claim-only classifier on VITAMINC-real and find it to achieve 50% accuracy—the same as always predicting SUP.

A.4 Claim-evidence Word Overlap

Naturally, when pairing claims to evidence sentences, the overlapping words will be higher on average for claims with their supporting evidence. In VITAMINC dataset, we want to minimize this bias in order to create challenging examples that require sentence-pair inference and cannot be solved by simple word matching techniques. Therefore, we asked annotators, when possible, to avoid copying exact phrases from the evidence to the claim (see §3.2).

Figure A.2 shows the probability density function of bigram overlaps between the claim and evidence for each relation. Similar to FEVER, the overlap ratio of supporting pairs in the VITAMINC dataset is only slightly higher than the one of refuting pairs. Also, the overlap ratio of the NEI pairs of the VITAMINC real dataset is on average higher than FEVER.

B Experimental Setting

We implement all our models with the Hugging-Face Transformers library (Wolf et al., 2019). When comparing across training datasets of different sizes, we train the model for the same amount of update steps, upsampling the smaller datasets. We pick the checkpoint with the highest accuracy on the development set of the training task and report performance on the test set. More details are available at https://github.com/TalSchuster/VitaminC

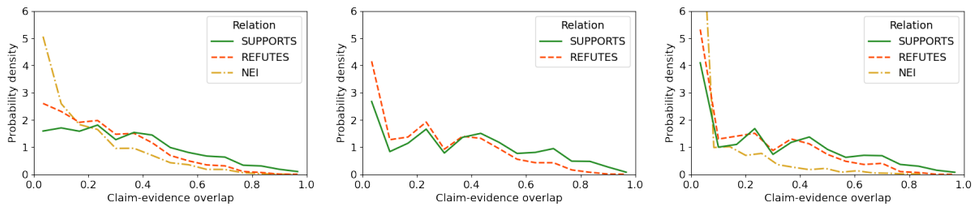
C GPT-3 Evaluation

The GPT-3 model has recently demonstrated impressive results in zero-shot and few-shot generation and classification tasks (Brown et al., 2020). This 175B parameters language model was trained on billions of words from online sources, including the English Wikipedia. As result, it can be applied on many tasks without any further fine-tuning—instead, one need only provide a task-specific prefix (i.e., "prompt") with a few examples that direct the language model towards the desired output format. For example, GPT-3 achieves better than random results on ANLI with only a single example in the prompt, and over 40% accuracy with 50 examples (Brown et al., 2020).

We used OpenAI's beta API to query GPT-3. Due to our limited quota, we could not perform

Loại yêu cầu	real	tổng hợp	Ví dụ
Định lượng	48%	9%	Tác nhân gây bệnh COVID-19 có thể tồn tại dưới 10 ngày trên một số bề mặt.
Liên quan đến lịch	9%	15%	Italy đã vượt qua 10.000 ca tử vong liên quan đến coronavirus vào một ngày thứ Bảy.
Thực thể	23%	58%	Mary của Teck là hoàng hậu.
Sự kiện	14%	14%	Trong trận EFL Cup gần đây, Manchester đã đánh bại Chelsea.
Khác	6%	4%	Hầu hết các gen cần được nghiên cứu thêm để hiểu rõ hơn về chức năng của các sản phẩm RNA của chúng.

Bảng A.1: Phân phối ước tính các yêu cầu trong VITAMINC, dựa trên các chú thích thủ công của 100 yêu cầu được chọn ngẫu nhiên từ phần phát triển của các tập con thực và nhân tạo. Một ví dụ về yêu cầu từ mỗi loại được cung cấp để tham khảo.



(a) VITAMINC thật (b) VITAMINC tổng hợp (c) SỐT

Hình A.2: Hàm mật độ xác suất của sự chồng chéo giữa lập luận và bằng chứng cho các nhãn khác nhau trong tập dữ liệu. Sự chồng chéo được tính toán như tỉ lệ các cặp từ hai từ chung trong hai câu.

Tất cả các tuyên bố trong VITAMINC-tổng hợp đều được ghép với một bằng chứng phản bác và một bằng chứng ủng hộ, khiến cho một mô hình c hỉ dựa vào tuyên bố không thể hoạt động tốt hơn ngẫu nhiên. Mỗi tuyên bố trong VITAMINC-thực tế được ghép với một bằng chứng phản bác hoặc t rung lập, bên cạnh một bằng chứng ủng hộ. Để đánh giá liệu các mô hình có thể sử dụng gợi ý từ vựng trong các tuyên bố hay không, chúng tôi huấn luyện một bộ phân loại chỉ dựa trên tuyên bố trên VITAMINC-thực tế và nhận thấy nó đạt độ chính xác 50%—tương đương với việc luôn dự đoán SUP.

A.4 Chứng cứ-điểm trùng từ

Tự nhiên, khi ghép các câu khẳng định với các câu bằng chứng, các từ trùng lặp sẽ cao hơn trung bình đối với các khẳng định cùng bằng chứng hỗ trợ của chúng. Trong bộ dữ liệu VITAMINC, chúng tôi muốn giảm thiểu sự thiên lệch này để tạo ra các ví dụ thử thách, đòi hỏi suy luận theo cặp câu và không thể giải quyết chỉ bằng các kỹ thuật so khớp từ đơn giản. Do đó, chúng tôi đã yêu cầu các người chú thích, khi có thể, tránh sao chép chính xác các cụm từ từ bằng chứng sang khẳng định (xem §3.2).

Hình A.2 cho thấy hàm mật độ xác suất của các sự chồng lấp bigram giữa luận điểm và bằng chứng đối với từng quan hệ. Tương tự như FEVER, tỷ lệ chồng lấp của các cặp chứng thực trong bộ dữ liệu VITAMINC chỉ cao hơn một chút so với các cặp phản bác. Ngoài ra, tỷ lệ chồng lấp của các cặp NEI trong bộ dữ liệu thực VITAMINC trung bình cao hơn FEVER.

B Thiết lập Thí nghiệm

Chúng tôi triển khai tất cả các mô hình của mình bằng thư viện Hugging-Face Transfor mers (Wolf và cộng sự, 2019). Khi so sánh giữa các tập dữ liệu huấn luyện có kích thước khác nhau, chúng tôi huấn luyện mô hình với cùng số bước cập nhật, tăng tần suất mẫu của các tập dữ liệu nhỏ hơn. Chúng tôi chọn điểm kiểm tra có độ chính xác cao nhất trên tập phát triển của nhiệm vụ huấn luyện và báo cáo hiệu suất trên tập kiểm tra. Thêm chi tiết có tại https://github.com/TalSchuster/VitaminC

Đánh giá C GPT-3

Mô hình GPT-3 gần đây đã thể hiện kết quả ấn tượng trong các nhiệm vụ sinh và phân loại zero-shot và few-shot (Brown và cộng sự, 2020). Mô hình ngôn ngữ 175 tỷ tham số này được huấn luyện trên hàng tỷ từ từ các nguồn trực tuyến, bao gồm Wikipedia tiếng Anh. Do đó, nó có thể được áp dụng cho nhiều nhiệm vụ mà không cần tinh chỉnh thêm—thay vào đó, chỉ cần cung cấp một tiền tố cụ thể cho nhiệm vụ (tức là "prompt") với một vài ví dụ hướng dẫn mô hình ngôn ngữ về định dạng đầu ra mong muốn. Ví dụ, GPT-3 đạt được kết quả tốt hơn ngẫu nhiên trên ANLI chỉ với một ví dụ trong prompt, và đạt độ chính xác hơn 40% với 50 ví dụ (Brown và cộng sự, 2020).

Chúng tôi đã sử dụng API thử nghiệm của OpenAI để truy vấn GPT-3. Do hạn mức có giới hạn, chúng tôi không thể thực hiện

extensive experiments. Instead, we performed a qualitative evaluation using several examples from VITAMINC test set for the claim extraction (factually consistent generation) and the fact verification tasks. Therefore, these results should be viewed as exploratory only.

GPT-3 for Claim Extraction. We examine a two-shot setting for the claim extraction task. The model is asked to convert a revision into a short claim that expresses the fact that is true after the edit. To guide the model for this task, we provide a prompt with two random examples from the VITAMINC training set (see Figure C.1). One of the main concerns regarding large language models is the limited control it allows for ensuring that the facts in the generated output align with the source (Schuster et al., 2020). The generation tasks of VITAMINC provide a useful test-bed for evaluating the factual consistency with the input. Importantly, our VITAMINC-trained fact verification classifiers (f_{verdict}) allow strong automatic evaluation for the factual agreement of the generation with the source.

We use GPT-3 to extract claims for four revisions with a sampling temperature value ($\mathcal{T}$) set to either 0 or 0.7. The zero value is recommended for maximizing the factual consistency as the model follows its most certain predictions. Using low temperature, however, can result in less fluent generations (Holtzman et al., 2020). Therefore, high values of $\mathcal{T}$ are also commonly used.

The results are reported in Tables 7 and E.3. With only two guiding examples, GPT-3 is able to follow the desired format and create a short claim. Yet, some of its generations follow s_{t-1} instead of s_t or add new, unsupported facts. f_{verdict} provides an indication for the factual correctness of the output. For example, it correctly classifies the output of the $\mathcal{T} = 0.7$ setting for the top example in Table 7 as "Not Enough Information" since GPT-3 reported about 20 deaths even though the input doesn't mention death numbers at all.

We expect GPT-3 to improve with longer prompts or fine-tuning and leave this to future research due to our limited quota.

GPT-3 for Fact Verification. We also experiment with using GPT-3 few-shot classification capabilities for the fact verification task. We follow the ANLI few-shot format of Brown et al. (2020) and compose prompts with 6 examples (2 from each class) with random examples from VITAMINC training set. We use only numerical examples to evaluate numerical claims (Figure C.3), and mixed examples for other claims (Figure C.2). We set $\mathcal{T} = 0$ as recommended for classification.

Table C.1 summarizes the results. Even with only six examples, GPT-3 seems to perform significantly better than random. Yet, its verdict is wrong in several cases that can be easily classified by humans. For example, we find it to refrain from predicting a True/False verdict even when the evidence is clear. We observe this both for a date-based (line 3.2 in Table C.1), numerical (lines 4.1-4.2), and entity-focused claims (line 5.2).

To experiment with the sensitivity of the model to the provided context, we manually modified some of the examples to provide even stronger evidence. For example, while GPT-3's prediction for line 5.2 is acceptable as actually, Turner Broadcasting System merged with WarnerMedia in 1996, changing the evidence to another disconnected entity (The Walt Disney Company) did not change the prediction (line 5.3) as expected. Even when explicitly stating that there is no other owner GPT-3 didn't modify its verdict (line 5.4). Similarly, when evaluating the claim about the population of Beaverton being less than 90K, GPT-3 ignores the supporting evidence and outputs a false verdict (lines 1.4-1.5). Changing the claim to state "approximately 86K" instead of "less than 90,000" modified the prediction to "Neither" (line 1.6). Only repeating the exact same number as the evidence led to a true verdict (line 1.7).

D Complementary Experiments

We report fact verification results with a fine-tuned BERT-base (Devlin et al., 2019) model in Table D.1. We find ALBERT-base to outperform BERT-base on most of the evaluated datasets. ALBERT-xlarge performed better than the two base models in all datasets except for Triggers. The Triggers dataset is very small (186 examples) and contains some unnaturally looking claims, which could explain the high variance across models.

E Example Outputs

We provide examples of predicted word-level rationales in Table E.1 and of outputs for the two generation tasks in Tables E.2 and E.3.

các thí nghiệm mở rộng. Thay vào đó, chúng tôi đã thực hiện một đánh giá định tính sử dụng một số ví dụ từ bộ kiểm tra VITAMINC cho việc trích xuất tuyên bố (tạo ra nhất quán về mặt thực tế) và các nhiệm vụ xác minh sự thật. Do đó, những kết quả này chỉ nên được xem là mang tính khám phá.

GPT-3 cho Việc Trích Xuất Khẳng Định. Chúng tôi nghiên cứu một thiết lập hai ví dụ cho nhiệm vụ trích xuất khẳng định. Mô hình được yêu cầu chuyển một bản sửa đổi thành một khẳng định ngắn diễn đạt sự thật đúng sau khi chỉnh sửa. Để hướng dẫn mô hình cho nhiệm vụ này, chúng tôi cung cấp một prompt với hai ví dụ ngẫu nhiên từ bộ dữ liệu huấn luyện VI-TAMINC (xem Hình C.1). Một trong những mối quan tâm chính liên quan đến các mô hình ngôn ngữ lớn là việc kiểm soát hạn chế mà chúng cho phép để đảm bảo rằng các sự thật trong đầu ra được sinh ra phù hợp với nguồn (Schuster và cộng sự, 2020). Các nhiệm vụ sinh dữ liệu của VITAMINC cung cấp một môi trường thử nghiệm hữu ích để đánh giá tính nhất quán thực tế với đầu vào. Quan trọng, các bộ phân loại xác minh sự thật được huấn luyện từ VITAMINC của chúng tôi (f_{verdict}) cho phép đánh giá tự động mạnh mẽ về sự phù hợp thực tế của các sinh dữ liệu với nguồn.

Chúng tôi sử dụng GPT-3 để trích xuất các tuyên bố cho bốn bản chỉnh sửa với giá trị nhiệt độ mẫu ($\mathcal{T}$) được đặt là 0 hoặc 0,7. Giá trị bằng không được khuyến nghị để tối đa hóa tính nhất quán về mặt thực tế vì mô hình sẽ theo các dự đoán chắc chắn nhất của nó. Tuy nhiên, việc sử dụng nhiệt độ thấp có thể dẫn đến các kết quả tạo ra kém trôi chảy hơn (Holtzman et al., 2020). Do đó, các giá trị cao của $\mathcal{T}$ cũng thường được sử dụng.

Kết quả được báo cáo trong Bảng 7 và E.3. Chỉ với hai ví dụ hướng dẫn, GPT-3 có thể làm theo định dạng mong muốn và tạo ra một tuyên bố ngắn. Tuy nhiên, một số kết quả sinh ra của nó theo s_{t-1} thay vì s_t hoặc thêm các thông tin mới không được hỗ trợ. f_{verdict} cung cấp một chỉ dẫn về độ chính xác thực tế của đầu ra. Ví dụ, nó phân loại chính xác đầu ra của cài đặt $\mathcal{T} = 0.7$ cho ví dụ đầu tiên trong Bảng 7 là " Thông tin không đủ" vì GPT-3 đã báo cáo k hoảng 20 ca tử vong mặc dù đầu vào không đề cập đến số lượng tử vong nào.

Chúng tôi mong đợi GPT-3 sẽ cải thiện với các gợi ý dài hơn hoặc tinh chỉnh và để điều này cho các nghiên cứu trong tương lai do hạn ngạch có hạn của chúng tôi.

GPT-3 cho Xác minh Thông tin. Chúng tôi cũng thử nghiệm việc sử dụng khả năng phân loại vài ví dụ của GPT-3 cho nhiệm vụ xác minh thông tin. Chúng tôi tuân theo định dạng vài ví dụ của ANLI theo Brown và cộng sự (2020) và soạn các lời nhắc với 6 ví dụ (2 từ mỗi lớp) với các ví dụ ngẫu nhiên từ VITAMINC tập huấn luyện. Chúng tôi chỉ sử dụng các ví dụ số để đánh giá các tuyên bố số (Hình C.3), và các ví dụ hỗn hợp cho các tuyên bố khác (Hình C.2). Chúng tôi thiết lập $\mathcal{T} = 0$ như được khuyến nghị cho phân loại.

Bảng C.1 tóm tắt các kết quả. Ngay cả với chỉ sáu ví dụ, GPT-3 dường như hoạt động tốt hơn đáng kể so với ngẫu nhiên. Tuy nhiên, kết luận của nó s ai trong một số trường hợp mà con người có thể dễ dàng phân loại. Ví dụ, chúng tôi nhận thấy nó tr ánh dự đoán một kết luận Đúng/Sai ngay cả khi bằng chứng rõ ràng. Chúng tôi quan sát điều này cả với các tuyên bố dựa trên ngày tháng (dòng 3.2 trong Bảng C.1), số liệu (dòng 4.1-4.2), và các tuyên bố tập trung vào thực thể (dòng 5.2).

Để thử nghiệm độ nhạy của mô hình đối với bối cảnh được cung cấp, chúng tôi đã tự tay chỉnh sửa một số ví dụ để cung cấp bằng chứng mạnh mẽ hơn. Ví dụ, trong khi dự đoán của GPT-3 cho dòng 5.2 là chấp nhận được vì thực tế, Turner Broadcasting System đã sáp nhập với WarnerMedia vào năm 1996, việc thay đổi bằng chứng sang một thực thể khác không liên quan (The Walt Disney Company) không làm thay đổi dự đoán (dòng 5.3) như mong đợi. Ngay cả khi nêu rõ rằng không có chủ sở hữu khác, GPT-3 vẫn không thay đổi phán quyết của mình (dòng 5.4). Tương tự, khi đánh giá tuyên bố về dân số của Beaverton là dưới 90K, GPT-3 bỏ qua bằng chứng hỗ trợ và đưa ra phán quyết sai (dòng 1.4-1.5). Việc thay đổi tuyên bố thành "khoảng 86K" thay vì "dưới 90.000" đã làm thay đổi dự đoán thành "Không ai cả" (dòng 1.6). Chỉ khi lặp lại chính xác cùng một con số như bằng chứng mới dẫn đến kết quả đúng (dòng 1.7).

D Thí nghiệm bổ sung

Chúng tôi báo cáo kết quả xác minh sự thật với mô hình BERT-base được tinh chỉnh (Devlin và cộng s ự, 2019) trong Bảng D.1. Chúng tôi nhận thấy ALBERT-base vượt trội hơn BERT-base trên hầu hết các tập dữ liệu được đánh giá. ALBERT-xlarge hoạt động tốt hơn hai mô hình cơ bản trên tất cả các tập dữ liệu ngoại trừ Triggers. Tập dữ liệu Triggers rất nhỏ (186 ví dụ) và chứa một số tuyên bố có vẻ phi tự nhiên, điều này có thể giải thích sự biến động cao giữa các mô hình.

E Ví dụ đầu ra

Chúng tôi cung cấp các ví dụ về các lý do dự đoán ở cấp độ từ trong Bảng E.1 và các kết quả cho hai nhiệm vụ tạo trong Bảng E.2 và E.3.

```
Life Is Peachy:  Life Is Peachy is the{*| first -> second |}studio album by the
American nu metal band Korn, released on October 15, 1996 through both Immortal
Records and Epic Records.
Claim:  Life Is Peachy is Korn's second studio album.
###
2020 coronavirus pandemic in Kerala:  As of 14 March 2020, there are{*| 19 -> 22
|}confirmed cases of the virus and more than 4000 people are under surveillance in
Kerala.
Claim:  As of 14 March, there have been more than 20 confirmed COVID-19 cases in
Kerala.
###
<Visualized edit>
Calim:  <prediction>
```

Figure C.1: The prompt used for GPT-3 few-shot claim extraction.

Cuộc Sống Thật Tuyệt Vời: Cuộc Sống Thật Tuyệt Vời là {*| album studio đầu tiên -> thứ hai |} của ban nhạc nu metal người Mỹ Korn, được phát hành vào ngày 15 tháng 10 năm 1996 thông qua cả Immortal Records và Epic Records. Khẳng định: Cuộc Sống Thật Tuyệt Vời là album studio thứ hai của Korn. ### Đại dịch coronavirus 2020 tại Kerala: Tính đến ngày 14 tháng 3 năm 2020, có {*| 19-> 22} ca nhiễm virus được xác nhận và hơn 4000 người đang được giám sát tại Kerala. Khẳng định: Tính đến ngày 14 tháng 3, đã có hơn 20 ca COVID-19 được xác nhận tại Kerala. ###<Chỉnh sửa trực quan>Khẳng định: <dự đoán>

Hình C.1: Lời nhắc được sử dụng cho việc trích xuất tuyên bố theo phương pháp few-shot của GPT-3.

```
Manchester is a major city and metropolitan borough in Greater Manchester,
England, with a population of 545,500 as of 2017 (5th most populous English
district).
Question:  Manchester had a population of more than 540,000 in 2017 and was the
5th most populous English district.  True, False, or Neither?  True
###
As of March 2018, the apps have achieved more than 8 billion downloads.
Question:  Talking Tom and Friends apps have less than 8 billion downloads.  True,
False, or Neither?  False
###
He won the Premier League in 2018.
John Stones won both the Premier League and EFL Cup in 2018.  True, False, or
Neither?  Neither
###
Neck Deep are a emo band.
Question:  Neck deep is an emo band.  True, False, or Neither?  True
###
Critics generally gave The Final Frontier mixed to poor reviews.
Question:  The film Star Trek V: The Final Frontier got negative reviews only.
True, False, or Neither?  False
###
The series was favorably compared to the HBO series The Jinx and the podcast
Serial.
Question:  The follow-up of the series Making a Murderer, was released in 2018.
True, False, or Neither?  Neither
###
<Examined evidence>
Question:  <Examined claim>.  True, False, or Neither?  <prediction>
```

Figure C.2: The prompt used for GPT-3 few-shot fact verification predictions on **non-numerical** claims (examples 2 and 4 in Table C.1. We follow the few-shot setting of Brown et al. (2020) for ANLI.

Manchester là một thành phố lớn và quận đô thị tại Greater Manchester, Anh, với dân số 545.500 vào năm 2017 (quận đông dân đứng thứ 5 của Anh). Câu hỏi: Manchester có dân số hơn 540.000 vào năm 2017 và là quận đông dân đứng t hứ 5 ở Anh. Đúng, Sai, hay Không cái nào? Đúng ### Tính đến tháng 3 năm 2018, các ứng dụng đã đạt hơn 8 tỷ lượt tải xuống. Câu hỏi: Ứng dụng Talking Tom and Friends có ít hơn 8 tỷ lượt tải xuống. Đúng, Sai, hay Không cái nào? Sai ### Anh ấy đã giành Premier League vào năm 2018. John Stones đã giành cả Premier League và EFL Cup vào năm 2018. Đúng, Sai, hay Không cái nào? Không cái nào ### Neck Deep là một ban nhạc emo. Câu hỏi: Neck Deep là một ban nhạc emo. Đúng, Sai, hay Không cái nào? Đúng ### Các nhà phê bình thường đánh giá The Final Frontier với nhận xét từ trung bình đến kém. Câu hỏi: Bộ phim Star Trek V: The Final Frontier chỉ nhận được nhận xét tiêu cực. Đúng, Sai, hay Không cái nào? Sai ### Loạt phim này được so sánh tích cực với loạt phim HBO The Jinx và podcast Serial. Câu hỏi: The fo

Hình C.2: Lời nhắc được sử dụng cho các dự đoán xác minh sự thật theo phương pháp few-shot của GPT-3 trên các tuyên bố phi số học (ví dụ 2 và 4 trong Bảng C.1. Chúng tôi theo thiết lập few-shot của Brown et al. (2020) cho ANLI.

#	Claim	Evidence	GPT-3	Ours	Gold
1.1	**Less than 90,000** people live in Beaverton , Oregon	its population is estimated to be **91,757**, almost 14% more than the 2000 census figure of 76,129	False	False	False
1.2	**More than 90K** people live in Beaverton	its population is estimated to be **91,757**, almost 14% more than the 2000 census figure of 76,129	True	True	True
1.3	**More than 90K** people live in Beaverton	its population is estimated to be **86,205**, almost 14% more than the 2000 census figure of 76,129	Neither	False	False
1.4	**Less than 90,000** people live in Beaverton, Oregon	its population is estimated to be **86,205**, almost 14% more than the 2000 census figure of 76,129	False	True	True
1.5	**Less than 90,000** people live in Beaverton, Oregon	**Beaverton's** population is estimated to be **86,205**	False	True	True
1.6	**Approximately 86k** people live in Beaverto, Oregon	**Beaverton's** population is estimated to be **86,205**	Neither	True	True
1.7	**Approximately 86,205** people live in Beaverton, Oregon	**Beaverton's** population is estimated to be **86,205**	True	True	True
2.1	Diego Corrales' father was Puerto Rican and his mother Dominican	Corrales was born to a African American father and a Mexican mother	False	False	False
2.2	Diego Corrales' father was Puerto Rican and his mother Dominican	Corrales was born to a Puerto Rican father and a Dominican mother	True	True	True
3.1	COVID-19 outbreak was identified **before December**	The outbreak was first identified in Wuhan, Hubei, China **in December** 2019 and recognized as a pandemic	False	False	False
3.2	COVID-19 outbreak was identified **before December**	The outbreak was first identified in Wuhan, Hubei, China **in 17 November** 2019 and recognized as a pandemic	Neither	True	True
4.1	There have been **more than 400** confirmed coronavirus cases in Germany	There have been **444** confirmed cases and 16 recoveries of coronavirus in Germany	Neither	True	True
4.2	There have been **more than 400** confirmed coronavirus cases in Germany	There have been **less than 349** confirmed cases and 16 recoveries of coronavirus in Germany	Neither	False	False
5.1	Cartoon Network is owned by **Turner Broadcasting System**	Cartoon Network is an American pay television channel owned by **Turner Broadcasting System**, a subsidiary of AT&T's WarnerMedia	True	True	True
5.2	Cartoon Network is owned by **Turner Broadcasting System**	Cartoon Network is an American pay television channel owned by **Warner Bros. Entertainment**, a subsidiary of AT&T's WarnerMedia	Neither	False	False
5.3	Cartoon Network is owned by **Turner Broadcasting System**	Cartoon Network is an American pay television channel owned by **The Walt Disney Company**	Neither	False	False
5.4	Cartoon Network is owned by **Turner Broadcasting System**	**The Walt Disney Company is the only owner** of Cartoon Network	Neither	False	False

Table C.1: GPT-3 fact verification predictions on examples from the VITAMINC test dataset (examples 1.5-1.7 and 5.3-5.4 were manually modified to examine the model's behavior). We follow the few-shot setting of Brown et al. (2020) for ANLI (see Figures C.2 and C.3). The bold spans are for presentation and are not part of the input. Our VITAMINC-trained ALBERT classifiers predicted correctly on all these examples (though they weren't picked this way). The GPT-3 few-shot succeeds on some examples and even expresses sensitivity to evidence in lines 2.1-2.2. In several cases, however, GPT-3 abstains from a True/False verdict, even when provided with strong evidence (see "Neither" predictions). Line 1.4 shows an example where GPT-3's verdict is opposite of the provided evidence. Only when rephrasing the claim to exactly overlap with the evidence, it predicts an agreement.

#	Yêu cầu	Bằng chứng	GPT-3	Ours	Gold
1.1	**Ít hơn 90.000 người sống ở** Beaverton, Oregon	dân số của nó ước tính là 91.757, gần 14% nhiều hơn con số điều tra dân số năm 2000 là 76.129	Sai	Sai	Sai
1.2	**Hơn 90 nghìn** người sống ở Beaverton	dân số của nó ước tính là 91.757, gần 14% nhiều hơn con số điều tra dân số năm 2000 là 76.129	True	True	True
1.3	**Hơn 90 nghìn** mọi người sống ở Beaverton	dân số của nó ước tính là 86.205, gần 14% nhiều hơn con số điều tra dân số năm 2000 là 76.129	Cả hai đều không	Sai	Sai
1.4	**Ít hơn 90.000 người sống ở** Beaverton, Oregon	dân số của nó ước tính là 86.205, gần 14% nhiều hơn con số điều tra dân số năm 2000 là 76.129	Sai	True	True
1.5	**Ít hơn 90.000 người sống ở** Beaverton, Oregon	Dân số của Beaverton ước tính là **86.205**	Sai	True	True
1.6	**Khoảng 86 nghìn người sống ở** Beaverto, Oregon	Dân số của Beaverton ước tính là **86.205**	Cả hai đều không	True	True
1.7	**Khoảng 86.205 người sinh sống** tại Beaverton, Oregon	Dân số của Beaverton ước tính là **86.205**	True	True	True
2.1	Cha của Diego Corrales là người Puerto Ri- có thể và mẹ của anh ấy người Dominica	Corrales sinh ra trong một gia đình có cha là người Mỹ gốc Phi và một người mẹ người Mexico	Sai	Sai	Sai
2.2	Cha của Diego Corrales là người Puerto Ri- có thể và mẹ của anh ấy người Dominica	Corrales sinh ra với người cha gốc Puerto Rico và một Mẹ người Dominica	True	True	True
3.1	Đợt bùng phát COVID-19 đã được xác định **trước tháng mười hai**	Đợt bùng phát lần đầu tiên được xác định ở Vũ Hán , Hubei , Trung Quốc vào tháng 12 năm 2019 và nhận ra- được công nhận là một đại dịch	Sai	Sai	Sai
3.2	Đợt bùng phát COVID-19 đã được xác định **trước tháng mười hai**	Đợt bùng phát lần đầu tiên được xác định ở Vũ Hán , Hubei , Trung Quốc vào ngày 17 tháng 11 năm 2019 và rec- được công nhận là một đại dịch	Cả hai đều không	True	True
4.1	Đã có hơn 400 con- các trường hợp coronavirus được xác nhận ở Đức	Đã có 444 ca được xác nhận và 16 số ca hồi phục của virus corona ở Đức	Cả hai đều không	True	True
4.2	Đã có hơn 400 con- các trường hợp coronavirus được xác nhận ở Đức	Đã có ít hơn 349 ca được xác nhận và 16 trường hợp hồi phục coronavirus ở Đức	Cả hai đều không	Sai	Sai
5.1	Hoạt hình Mạng được sở hữu bởi **Hệ thống Phát sóng Turner**	Cartoon Network là một kênh truyền hình trả tiền của Mỹ **kênh do Hệ thống Phát sóng Turner sở hữu** tem, một công ty con của WarnerMedia thuộc AT&T	True	True	True
5.2	Hoạt hình Mạng được sở hữu bởi **Hệ thống Phát sóng Turner**	Cartoon Network là một kênh truyền hình trả tiền của Mỹ kênh sion thuộc sở hữu của Warner Bros. Enter- tainment, một công ty con của WarnerMedia thuộc AT&T	Cả hai đều không	Sai	Sai
5.3	Hoạt hình Mạng được sở hữu bởi **Hệ thống Phát sóng Turner**	Cartoon Network là một kênh truyền hình trả tiền của Mỹ **kênh do Công ty Walt Disney sở hữu**	Cả hai đều không	Sai	Sai
5.4	Hoạt hình Mạng được sở hữu bởi **Hệ thống Phát sóng Turner**	**Công ty Walt Disney là chủ sở hữu duy nhất** của Cartoon Network	Cả hai đều không	Sai	Sai

Bảng C.1: Các dự đoán xác minh sự thật của GPT-3 trên các ví dụ từ bộ dữ liệu kiểm tra VITAMINC (các ví dụ 1.5-1.7 và 5.3-5.4 đã được chỉnh sửa thủ công để kiểm tra hành vi của mô hình). Chúng tôi theo thiết lập few-shot của Brown và cộng sự (2020) cho ANLI (xem Hình C.2 và C.3). Các đoạn in đậm chỉ để trình bày và không phải là một phần của dữ liệu đầu vào. Các bộ phân loại ALBERT được huấn luyện trên VITAMINC của chúng tôi dự đoán đúng tất cả các ví dụ này (mặc dù chúng không được chọn theo cách này). GPT-3 trong thiết lập few-shot thành công ở một số ví dụ và thậ m chí thể hiện sự nhạy cảm với bằng chứng ở các dòng 2.1-2.2. Tuy nhiên, trong một số trường hợp, GPT-3 từ chối đưa ra phán quyết True/False, ngay cả khi được cung cấp bằng chứng mạnh (xem các dự đoán "Neither"). Dòng 1.4 cho thấy một ví dụ nơi phán quyết của GPT-3 trái ngược với bằng chứng được cung cấp. Chỉ khi diễn đạt lại tuyên bố sao cho hoàn toàn trùng khớp với bằng chứng, nó mới dự đoán sự đồng ý.

```
Manchester is a major city and metropolitan borough in Greater Manchester,
England, with a population of 545,500 as of 2017 (5th most populous English
district).
Question:  Manchester had a population of more than 540,000 in 2017 and was the
5th most populous English district.  True, False, or Neither?  True
###
As of March 2018, the apps have achieved more than 8 billion downloads.
Question:  Talking Tom and Friends apps have less than 8 billion downloads.  True,
False, or Neither?  False
###
As of January 2015, JFC had a total of more than 3,000 stores worldwide, with
system-wide retail sales totaling 82.1 billion pesos for the fiscal year 2011.
Question:  Jollibee had a total of more than 20,000 stores worldwide after January
2016.  True, False, or Neither?  Neither
###
As of March 2018, the apps have achieved more than 8 billiobn downloads.
Question:  Talking Tom and Friends apps have over 8 billion downloads.  True,
False, or Neither?  True
###
Bet365 has more than 35 million customers globally.
Question:  Bet365 has less than 30 million customers worldwide.  True, False, or
Neither?  False
###
The series was favorably compared to the HBO series The Jinx and the podcast
Serial.
Question:  The follow-up of the series Making a Murderer, was released in 2018.
True, False, or Neither?  Neither
###
<Examined evidence>
Question:  <Examined claim>.  True, False, or Neither?  <prediction>
```

Figure C.3: The prompt used for GPT-3 few-shot fact verification predictions on **numerical** claims (examples 1 and 3 in Table C.1.

Model	Train dataset	VitC real	VitC syn	FEVER	MNLI	Adversarial	Symmetric	Triggers	ANLI	Contrast
BERT-base	FEVER	60.55	71.35	87.16	61.90	52.09	73.60	69.89	**34.53**	54.05
	MNLI	46.31	69.01	70.06	83.80	50.13	73.88	65.05	26.88	51.92
	FEVER + MNLI	56.24	81.80	**95.59**	**85.06**	63.05	85.11	37.63	29.63	60.63
	VitC	**85.80**	90.63	74.21	66.66	**76.24**	90.17	63.98	33.19	72.49
	VitC + MNLI	84.47	**91.00**	74.88	83.70	63.05	84.55	66.13	31.00	84.88
	VitC + FEVER	84.72	89.16	87.55	69.28	64.75	**90.73**	**72.58**	34.06	84.01

Table D.1: Fact verifcation Complementrary results for Table 4 with a BERT-base model.

Claim	the youtube channel chuchu tv is placed 42nd and has more than 25 million subscribers .
Evidence	chuchu tv is the 43rd most subscribed youtube channel in the world , with over 20 million subscribers .
Claim	the ramus has sold less than 4.5 million albums worldwide .
Evidence	the rasmus has sold 5 million albums worldwide , 310,000 copies in their native finland alone .
Claim	darren randolph is spanish .
Evidence	humes dated irish footballer darren randolph in 2005 .
Claim	astravyets is near vilnius .
Evidence	his father may have migrated to the us in the 1860s from astravyets near vilnius .
Claim	the pace controlling stamina meter is a new feature in the game series .
Evidence	new to the series is a three-tier stamina meter which controls the pace of a match .
Claim	the movie will be released on 25 november 2015 .
Evidence	[...] are producing the film which columbia pictures will release on november 25 , 2015 .

Table E.1: Example masks produced by the word-level rationale model for identifying anchoring words in the evidence that are responsible for the classifiers verdict regarding the claim. Masking these words leads the classifier to predict NEI instead of what would have been SUP or REF.

Manchester là một thành phố lớn và là quận đô thị ở Greater Manchester, Anh, với dân số 545.500 người tính đến năm 2017 (quận đông dân thứ 5 ở Anh). Câu hỏi: Manchester có dân số hơn 540.000 người vào năm 2017 và là quận đông dân thứ 5 ở Anh. Đúng, Sai, hay Không rõ? Đúng ### Tính đến tháng 3 năm 2018, các ứng dụng đã đạt hơn 8 tỷ lượt tải xuống. Câu hỏi: Ứng dụng Talking Tom and Friends có ít hơn 8 tỷ lượt tải xuống. Đúng, Sai, hay Không rõ? Sai ### Tính đến tháng 1 năm 2015, JFC có tổng cộng hơn 3.000 cửa hàng trên toàn thế giới, với doanh số bán lẻ toàn hệ thống đạt 82,1 tỷ peso cho năm tài chính 2011. Câu hỏi: Jollibee có tổng cộng hơn 20.000 cửa hàng trên toàn thế giới sau tháng 1 năm 2016. Đúng, Sai, hay Không rõ? Không rõ ### Tính đến tháng 3 năm 2018, các ứng dụng đã đạt hơn 8 tỷ lượt tải xuống. Câu hỏi: Ứng dụng Talking Tom and Friends có hơn 8 tỷ lượt tải xuống. Đúng, Sai, hay Không rõ? Đúng ### Bet365 có hơn 35 triệu khách hàng trên toàn cầu

Hình C.3: Lời nhắc sử dụng cho dự đoán xác minh sự thật theo vài ví dụ của GPT-3 về các khẳng định số học (ví dụ 1 và 3 trong Bảng C.1).

Mô hình	Tập dữ liệu huấn luyện	VitC thật	VitC syn	SỐT	MNLI	Đối kháng Đối xứng		Kích hoạt	ANLI	Tương phản
BERT-cơ bản	SỐT	60.55	71.35	87.16	61.90	52.09	73.60	69.89	**34.53**	54.05
	MNLI	46.31	69.01	70.06	83.80	50.13	73.88	65.05	26.88	51.92
	SỐT +MNLI	56.24	81.80	**95.59**	**85.06**	63.05	85.11	37.63	29.63	60.63
	VitC	**85.80**	90.63	74.21	66.66	**76.24**	90.17	63.98	33.19	72.49
	VitC + MNLI	84.47	**91.00**	74.88	83.70	63.05	84.55	66.13	31.00	84.88
	VitC + SỐT	84.72	89.16	87.55	69.28	64.75	**90.73**	**72.58**	34.06	84.01

Bảng D.1: Kết quả bổ sung xác minh sự thật cho Bảng 4 với mô hình BERT-base.

Yêu cầu	Kênh YouTube Chuchu TV được xếp hạng 42 và có hơn 25 triệu người đăng ký.
Bằng chứng	chuchu tv là kên[redacted]tube c[redacted]ứ 43 trên thế giới, với hơn 20 triệ[redacted]
Yêu cầu	Ramus đã bán chưa đến 4,5 triệu album trên toàn thế giới.
Bằng chứng	The Rasmus đã bán[redacted]ng tại quê nhà Phần Lan đã bán được 310.000 bản.
Yêu cầu	Darren Randolph là người Tây Ban Nha.
Bằng chứng	Humes hẹn hò cầu[redacted]g đá Ireland Darren Randolph vào năm 2005.
Yêu cầu	Astravyets gần Vilnius.
Bằng chứng	Cha của ông có thể đã di cư sang Mỹ vào những năm 1860 từ một làn[redacted]
Yêu cầu	Thanh đo thể lực điều khiển nhịp độ là một tính năng mới trong loạt trò chơi.
Bằng chứng	Mới trong lo[redacted] là một thanh [redacted]điều khi[redacted]ộ cù[redacted] trận đấu.
Yêu cầu	Bộ phim sẽ được phát hành vào ngày 25 tháng 11 năm 2015.
Bằng chứng	[...] đang sản xuất bộ phim mà Columbia Pictures sẽ phát hành [redacted]

Bảng E.1: Ví dụ về các mặt nạ được tạo bởi mô hình lý giải ở cấp từ để xác định các từ mô[redacted] hứng chịu trách nhiệm cho phán quyết của bộ phân loại về tuyên bố. Việc che các từ này khiến bộ phân loại dự đoán NEI thay vì SUP hoặc REF như lẽ ra.

Claim	Stephen Bruner was born on October 19 , 1984 .
s_{t-1}	Stephen Bruner (born October 18 , 1984) , better known by his stage name Thundercat , is an American multi-genre bass player , producer and singer fr om Los Angeles , California .
Output	Stephen Bruner (born October 19, 1984), better known by his stage name Thundercat, is an American multi-genre bass player, producer and singer from Los Angeles, California.
s_t	Stephen Bruner (born October 19 , 1984) , better known by his stage name Thundercat , is an American multi-genre bass player , producer and singer from Los Angeles , California .
Claim	The House that Jack Built has an approval rate of over 45 % and over 13 critics .
s_{t-1}	On Rotten Tomatoes , the film has an approval rating of 42 % , based on 12 critics , and an average rating of 5.9/10
Output	On Rotten Tomatoes, the film has an approval rating of 47 %, based on 14 critics, and an average rating of 5.9/10.
s_t	On Rotten Tomatoes , the film has an approval rating of 47 % , based on 15 critics , and an average rating of 6.3/10.
Claim	Cartoon Network is owned by Warner Bros. Entertainment .
s_{t-1}	Cartoon Network is an American pay television channel owned by Turner Broadcasting System , a subsidiary of AT & T 's WarnerMedia .
Output	Cartoon Network is an American pay television channel owned by Warner Bros. Entertainment, a subsidiary of AT & T's WarnerMedia.
s_t	Cartoon Network is an American pay television channel owned by Warner Bros. Entertainment , a subsidiary of AT & T 's WarnerMedia .
Claim	The New York Times reviewed the film Mad Max : Fury Road .
s_{t-1}	Lindsay Bahr of The Associated Press wrote , " Miller has reminded us that blockbusters have the potential to not only be art , but radically visionary – even the fourth in a series .
Output	Lindsay Bahr of The New York Times wrote, " Miller has reminded us that blockbusters have the potential to not only be art, but radically visionary – even the fourth in a series.
s_t	The New York Times wrote , " Miller has reminded us that blockbusters have the potential to not only be art , but radically visionary – even the fourth in a series .

Table E.2: Example outputs of the BART-base used for generating factually consistent revisions given the old version s_{t-1} and the updated claim we wish to support. The "ground-truth" s_t is provided for reference.

(s_{t-1}, s_t)	WWE 2K15: As of August 2015 , WWE 2K15 has shipped over{*| six -> 7.5 |}million units.		
BART (VitC)	WWE 2K15 sold more than 7 million units.	$f_{\text{verdict}}(c, s_t) =$	SUP
GPT-3 $\mathcal{T}$=0	As of August 2015, WWE 2K15 has shipped over seven million units		SUP
GPT-3 $\mathcal{T}$=0.7	As of August 2015, WWE 2K15 has shipped over seven million units		SUP
Reference	By August 2015 , WWE 2K15 shipped over 7.5 million units .		SUP
(s_{t-1}, s_t)	Pat Jennings: He has played for League of Ireland clubs UCDDerry and is now at {*| Shamrock Rovers -> Dublin |}.		
BART (VitC)	Pat Jennings is currently playing for Dublin club UCDDerry.		SUP
GPT-3 $\mathcal{T}$=0	He has played for League of Ireland clubs UCD and is now at Shamrock Rovers		REF
GPT-3 $\mathcal{T}$=0.7	He played for Shamrock Rovers and is now at Dublin		REF
Reference	Pat Jennings currently plays for the Dublin club .		SUP

Table E.3: Additional examples for Table 7. Example outputs for extracting claims that express the factual change in a Wikipedia revision. The BART-base model is trained on VITAMINC data and GPT-3 is applied in a 2-shot setting with a temperature of 0 or 0.7. The revision (s_{t-1}, s_t) is given to the model as a single sentence visualization where the edits are between curly brackets, preceded by the article's title. The human-written claim is provided for reference. The prediction of our ALBERT-xlarge VITAMINC-trained model $f_{\text{verdict}}(c, s_t)$ on the generated claim against s_t is also reported in the rightmost column.

Yêu cầu	Stephen Bruner sinh ngày 19 tháng 10 năm 1984.
s_{t-1}	Stephen Bruner (sinh ngày 18 tháng 10 năm 1984), được biết đến nhiều hơn với nghệ danh Thundercat, là một người Mỹ người chơi bass đa thể loại, nhà sản xuất và ca sĩ từ Los Angeles, California.
Đầu ra	Stephen Bruner (sinh ngày 19 tháng 10 năm 1984), được biết đến nhiều hơn với nghệ danh Thundercat, là một người Mỹ người chơi bass đa thể loại, nhà sản xuất và ca sĩ đến từ Los Angeles, California.
s_t	Stephen Bruner (sinh ngày 19 tháng 10 năm 1984), được biết đến nhiều hơn với nghệ danh Thundercat, là một người Mỹ người chơi bass đa thể loại, nhà sản xuất và ca sĩ đến từ Los Angeles, California.
Yêu cầu	Bộ phim The House that Jack Built có tỷ lệ đánh giá đồng thuận trên 45% và hơn 13 nhà phê bình.
s_{t-1}	Trên Rotten Tomatoes, bộ phim có tỷ lệ chấp thuận 42%, dựa trên 12 nhà phê bình, và điểm đánh giá trung bình điểm 5,9/10
Đầu ra	Trên Rotten Tomatoes, bộ phim có tỷ lệ chấp thuận 47 %, dựa trên 14 nhà phê bình, và điểm đánh giá trung bình 5,9/10.
s_t	Trên Rotten Tomatoes, bộ phim có tỷ lệ chấp thuận 47%, dựa trên 15 nhà phê bình, và điểm đánh giá trung bình được 6,3/10.
Yêu cầu	Cartoon Network thuộc sở hữu của Warner Bros. Entertainment.
s_{t-1}	Cartoon Network là một kênh truyền hình trả tiền của Mỹ thuộc sở hữu của Turner Broadcasting System, một công ty con của WarnerMedia thuộc AT & T.
Đầu ra	Cartoon Network là một kênh truyền hình trả tiền của Mỹ, thuộc sở hữu của Warner Bros. Entertainment, một công ty con của WarnerMedia thuộc AT & T.
s_t	Cartoon Network là một kênh truyền hình trả tiền của Mỹ, thuộc sở hữu của Warner Bros. Entertainment, một công ty con của WarnerMedia thuộc AT & T.
Yêu cầu	Tờ New York Times đã đánh giá bộ phim Mad Max: Fury Road.
s_{t-1}	Lindsay Bahr của The Associated Press đã viết, "Miller đã nhắc nhở chúng ta rằng những bộ phim bom tấn có tiềm năng không chỉ để trở thành nghệ thuật, mà còn mang tính tiên phong – thậm chí là phần thứ tư trong một loạt.
Đầu ra	Lindsay Bahr của The New York Times đã viết, "Miller đã nhắc chúng ta rằng những bộ phim bom tấn có tiềm năng không chỉ để trở thành nghệ thuật, mà còn mang tính cách tân – thậm chí là tác phẩm thứ tư trong một loạt.
s_t	The New York Times đã viết, "Miller đã nhắc chúng ta rằng những bộ phim bom tấn có tiềm năng không chỉ để nghệ thuật, nhưng mang tầm nhìn cấp tiến – thậm chí là phần thứ tư trong một loạt.

Bảng E.2: Ví dụ về các kết quả đầu ra của BART-base được sử dụng để tạo các chỉnh sửa nhất quán về mặt thực tế dựa trên phiên bản cũ s_{t-1} và tuyên bố cập nhật mà chúng ta muốn hỗ trợ. "Sự thật nền tảng" s_t được cung cấp để tham khảo.

(s_{t-1}, s_t)	WWE 2K15: Tính đến tháng 8 năm 2015, WWE 2K15 đã được xuất xưởng hơn sáu triệu đơn vị.		
BART (VitC)	WWE 2K15 đã bán được hơn 7 triệu bản.	$f_{\text{verdict}}(c, s_t) =$	SUP
GPT-3 $\mathcal{T}$=0	Tính đến tháng 8 năm 2015, WWE 2K15 đã được xuất xưởng hơn bảy triệu đơn vị		SUP
GPT-3 $\mathcal{T}$=0.7	Tính đến tháng 8 năm 2015, WWE 2K15 đã được xuất xưởng hơn bảy triệu đơn vị		SUP
Tham khảo	Đến tháng 8 năm 2015, WWE 2K15 đã bán được hơn 7,5 triệu bản.		SUP
(s_{t-1}, s_t)	Pat Jennings: Anh ấy đã từng thi đấu cho các câu lạc bộ của Giải bóng đá Ireland UCD và Derry và hiện nay đang ở {*| Shamrock Rovers -> Dublin |}.		
BART (VitC)	Pat Jennings hiện đang chơi cho câu lạc bộ Dublin UCD Derry.		SUP
GPT-3 $\mathcal{T}$=0	Anh ấy đã chơi cho các câu lạc bộ ở Giải bóng đá Ireland UCD và hiện đang thi đấu cho Shamrock Rovers		REF
GPT-3 $\mathcal{T}$=0.7	Anh ấy đã chơi cho Shamrock Rovers và hiện đang ở Dublin		REF
Tham khảo	Pat Jennings hiện đang chơi cho câu lạc bộ Dublin.		SUP

Bảng E.3: Các ví dụ bổ sung cho Bảng 7. Các kết quả ví dụ cho việc trích xuất các tuyên bố thể hiện sự thay đổi thực tế trong một phiên bản Wikipedia. Mô hình BART-base được huấn luyện trên dữ liệu VITAMINC và GPT-3 được áp dụng trong thiết lập 2-shot với nhiệt độ 0 hoặc 0,7. Phiên bản (s_{t-1}, s_t) được cung cấp cho mô hình dưới dạng một câu trực quan duy nhất, trong đó các chỉnh sửa được đặt giữa các dấu ngoặc nhọn, đứng sau tiêu đề bài viết. Tuyên bố do con người viết được cung cấp để tham khảo. Dự đoán của mô hình ALBERT-xlarge được huấn luyện trên VITAMINC f_{verdict} (c, s_t) về tuyên bố được tạo ra đối với s_t cũng được báo cáo trong cột ngoài cùng bên phải.