Hãy Nhận Vitamin C Của Bạn! Xác Minh Thông Tin Vững Chắc với Bằng Chứng Đối Chiếu

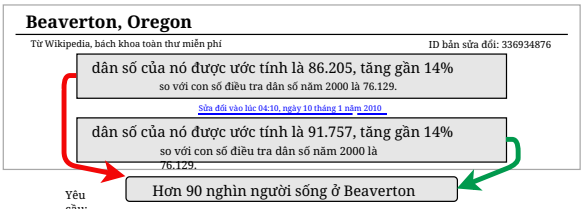
Tal Schuster AdamFisch ReginaBarzilay Phòng
Thí nghiệm Khoa học Máy tính và Trí tuệ Nhân tạo
Viện Công nghệ Massachusetts
{tals,fisch,regina}@csail.mit.edu

Tóm tắt

Các mô hình xác minh sự thật điển hình sử dụng bằng chứng viết được truy xuất để xác minh các tuyên bố. Tuy nhiên, các nguồn bằng chứng thường thay đổi theo thời gian khi có thêm thông tin được thu thập và chỉnh sửa. Để thích nghi, các mô hình phải nhạy cảm với những khác biệt tinh tế trong bằng chứng hỗ trợ. Chúng tôi giới thiệu VITAMINC, một chuẩn thử nghiệm chứa các trường hợp thách thức yêu cầu các mô hình xác minh sự thật phân biệt và điều chỉnh theo những thay đổi thực tế nhỏ. Chúng tôi thu thập hơn 100.000 lần chỉnh sửa Wikipedia làm thay đổi một thực tế cơ bản, và sử dụng các lần chỉnh sửa này, cùng với các lần được tạo ra một cách tổng hợp bổ sung, để tạo tổng cộng hơn 400.000 cặp t uyên bố-bằng chứng. Khác với các nguồn tài nguyên trước đây, các ví dụ trong VITAMINC mang tính tương phản, tức là chúng chứa các cặp bằng chứng gần như giống hệt về ngôn ngữ và nội dung, ngoại tr ừ việc một cặp hỗ trợ một tuyên bố cụ thể trong khi cặp còn lại không. Chúng tôi cho thấy rằng việc huấn luyện sử dụng thiết kế này tăng cường độ bền—nâng cao độ chính xác lên 10% trong xác minh sự thật đối kháng và 6%

1 Giới thiệu

Xác định tính chân thực của các tuyên bố thực tế bằng cách so sánh chúng với các nguồn văn bản làm chứng đã nhận được sự quan tâm nghiên cứu sâu sắc trong những năm gần đây. Tuy nhiên, một thách thức cơ bản nhưng thường bị bỏ qua đối với mô hình này là bản chất động của các nguồn tài nguyên viết hiện nay. Một lượng thông tin mới khổng lồ được cung cấp hàng ngày; kết quả là, nhiều sự kiện quan trọng được thiết lập, thay đổi hoặc bổ sung theo thời gian. Chúng tôi cho rằng chất lượng của các hệ thống xác minh sự kiện nên được



Hình 1: Trong VITAMINC, chúng tôi tập trung vào các lần sửa đổi Wikipedia mà trong đó nội dung thực tế thay đổi. Ví dụ về lần sửa đổi này bây giờ hỗ trợ một tuyên bố ban đầu bị bác bỏ.

được đo bằng mức độ họ điều chỉnh tốt như thế nào trước bằng chứng mới. Bằng cách này, chúng tôi tìm cách thúc đẩy việc xác minh sự thật bằng cách yêu cầu các mô hình duy trì độ tin cậy và vững chắc trước những thay đổi hiện diện trong các bối cảnh thực tiễn.

Để đạt được mục tiêu này, chúng tôi tập trung vào việc xác minh sự thật với bằng chứng đối c hiếu. Nghĩa là, chúng tôi kết hợp mô hình xác minh sự thật tiêu chuẩn với các trường hợp thách thức đòi hỏi các mô hình phải nhạy cảm với các thay đổi về sự thật trong bằng chứng được trình bày (sau đây được gọi thay thế cho nhau là "ngữ cảnh"). Chúng tôi giới thiệu VITAMINC,[2] —một tập dữ liệu xác minh sự thật quy mô lớn mới, dựa trên các sửa đổi sự thật trên Wikipedia. Khái niệm c hính được minh họa trong Hình 1: tại đó, một sửa đổi sự thật tạo ra một cặp ngữ cảnh đối chiếu gần như giống hệt về ngôn ngữ và nội dung—ngoại trừ việc một ngữ cảnh phản bác tuyên bố đã đưa ra, trong khi ngữ cảnh kia ủng hộ nó.

Loại cấu trúc so sánh này làm lộ ra những thiếu s ót hiện có trong hành vi của mô hình. Để minh họa điều này, chúng tôi đào tạo một bộ phân loại trên tập dữ liệu xác minh sự thật phổ biến FEVER (Thorne et al., 2018) và đánh giá nó trên các cặp tuyên bố-bằng chứng đối chiếu. Chúng tôi nhận thấy rằng mô hình c hỉ thay đổi dự đoán từ phán quyết gốc trong 56% các trường hợp đối chiếu. Tuy nhiên, khi các ví dụ từ VITAMINC được bao gồm trong quá trình đào tạo, độ nhạy của mô hình tăng lên, thay đổi dự đoán ở 86% các trường hợp đối chiếu.

Suy luận nhạy cảm với ngữ cảnh như vậy có hai lợi ích chính. Thứ nhất, nó đảm bảo rằng mô hình xem xét

[1]Bộ dữ liệu VITAMINC và các mô hình của chúng tôi có sẵn tại: https://github.com/TalSchuster/VitaminC

[2]Nguồn gốc từ VITAMINC: Bằng chứng đối chiếu giữ cho các mô hình xác minh sự thật vững chắc và khỏe mạnh, do đó gọi là "Vitamin C."

Tài liệu hội nghị của Hội nghị năm 2021 của Chi nhánh Bắc Mỹ thuộc Hiệp hội Ngôn ngữ học Máy tính: Công nghệ Ngôn ngữ Con người, trang 624–643, từ ngày 6–11 tháng 6 năm 2021. *©2021 Hiệp hội Ngôn ngữ học Máy tính*

dựa trên bằng chứng được cung cấp thay vì dựa vào kiến thức tĩnh tích hợp sẵn, chẳng hạn như kiến thức thu được qua huấn luyện trước mô hình ngôn ngữ (Petroni et al., 2019; Roberts et al., 2020). Điều này đặc biệt quan trọng cho các tình huống mà nguồn sự thật có thể thay đổi (ví dụ, tổng thống Mỹ hiện tại, hoặc các tuyên bố mới như trong Hình 1). Thứ hai, thiết lập này ngăn chặn một số thiên kiến và đặc thù nhất định—chẳng hạn như khai thác sự khác biệt trong cách các khẳng định đúng và sai được đưa ra—mà thường gặp trong các tập dữ liệu được tạo bởi đám đông tương tự (Poliak et al., 2018; Schuster et al., 2019). Thực sự, chúng tôi cho thấy rằng việc bổ sung cả mô hình xác minh sự thật và mô hình NLI với dữ liệu VITAMINC cải thiện độ bền của chúng đối với các đầu vào mang tính đối kháng.

Hơn nữa, việc nhấn mạnh của chúng tôi vào các ngữ cảnh tương phản cho phép chúng tôi mở rộng phạm vi các nhiệm vụ thường được xem xét. Hầu hết các nghiên cứu về xác minh sự thật tập trung vào việc giải quyết các tuyên bố là đúng hay sai (Popat et al., 2018; Thorne và Vlachos, 2018; Wang, 2017). Tuy nhiên, hệ sinh thái xung quanh bao gồm các thách thức bổ sung, một số trong đó chúng tôi khám phá ở đây: Các tài liệu như các bài viết trên Wikipedia thường được cập nhật; những chỉnh sửa nào đại diện cho các thay đổi thực tế? Đối với một cặp tuyên bố và bằng chứng (bác bỏ hoặc hỗ trợ) nhất định, những từ hoặc cụm từ nào trong bằng chứng là có liên quan nhất? Nếu chúng ta biết rằng một tuyên bố nhất định là đúng, chúng ta có thể chỉnh sửa một tài liệu lỗi thời để phù hợp với nó không? Chúng tôi chỉ ra rằng cấu trúc độc đáo của bộ dữ liệu VITAMINC có thể được tận dụng để cung cấp cả dữ liệu có giám sát và dữ liệu có giám sát xa cho các câu hỏi mới này.

Những đóng góp chính của chúng tôi như sa u:

1. Chúng tôi đề xuất một phương pháp kiểm chứng sự thật đối chiếu yêu cầu nhạy cảm với các thay đổi trong dữ liệu; 2. Chúng tôi giới thiệu VITAMINC, một bộ dữ liệu quy mô lớn mới hỗ trợ phương pháp này; 3. Chúng tôi chứng minh rằng việc huấn luyện trên VITAMINC dẫn đến hiệu suất tốt hơn trên các nhiệm vụ tiêu chuẩn; 4. Chúng tôi chỉ ra cách VITAMINC mở ra cánh cửa cho các hướng nghiên cứu bổ sung trong kiểm chứng sự thật.

2 Công trình liên quan

Xác minh sự thật. Bộ dữ liệu FEVER (Thorne et al., 2018) đã thúc đẩy sự phát triển của nhiều mô hình kiểm tra sự thật (ví dụ, xem Hanselowski et al., 2018; Nie et al., 2019a,b; Yoneda et al., 2018, và các nguồn khác). Tuy nhiên, quá trình tạo lập các tuyên bố yêu cầu người lao động từ đám đông viết các tuyên bố liên quan đến các bài viết trên Wikipedia, và đã được phát hiện là tạo ra các thiên kiến khiến một mô hình không dựa vào bằng chứng có thể đạt hiệu suất cao bất ngờ (Schuster và cộng sự, 2019). Các bộ dữ liệu gần đây khác bao gồm xác minh chống lại bảng (Chen và cộng sự, 2020), cơ sở dữ liệu quan hệ (Jo và cộng sự, 2019), tham chiếu Wikipedia (Sathe và cộng sự, 2020), nhiều bài viết (Jiang và cộng sự, 2020), và các đoạn trích tìm kiếm (Augenstein và cộng sự, 2019). Tất cả các nguồn tài nguyên này đều giả định sự thật cơ bản là tĩnh. Ngược lại, VITAMINC so sánh các tuyên bố khách quan với một nguồn sự thật động, và yêu cầu các mô hình thay đổi phán quyết của chúng tương ứng.

Thiên vị chú thích. Các hiện tượng sai lệch do chú thích phổ biến trong nhiều tập dữ liệu NLP và ảnh hưởng đến hiệu suất trên các ví dụ đối kháng và tương phản (Gardner et al., 2020; Ribeiro et al., 2020; Ross et al., 2020). Các nhiệm vụ suy luận cặp câu như xác minh sự thật (Paul Panenghat et al., 2020; Schuster et al., 2019) và NLI (Gururangan et al., 2018; McCoy et al., 2019; Poliak et al., 2018; Tsuchiya, 2018) cũng không phải là ngoại lệ. Giảm thiểu thiên vị này đòi hỏi các giải pháp mô hình hóa (Karimi Mahabadi et al., 2020; Pratapa et al., 2020; Shah et al., 2020; Thorne và Vlachos, 2020; Utama et al., 2020b), nhưng hiệu quả có hạn (Utama et al., 2020a), hoặc loại bỏ một cách đối kháng các ví dụ huấn luyện gây rắc rối (Bras et al., 2020) hoặc tự thu thập các ví dụ mới (Nie et al., 2020; Thorne et al., 2019a), điều này phụ thuộc vào mô hình. Thay vào đó, thiết kế tập dữ liệu của chúng tôi tránh các sai lệch từ câu đơn và cung cấp các ví dụ thử thách không phụ thuộc mô hình, giúp tăng độ bền vững của các mô hình đã được huấn luyện.

Khả năng giải thích. Các bộ dữ liệu xác thực thực tế hiện tại cung cấp lý do ở mức câu (DeYoung et al., 2020; Petroni et al., 2020) nhưng không bắt buộc phán quyết của mô hình phải dựa vào chúng—dẫn đến khả năng có sự không nhất quán. VITAMINC đảm bảo rằng phán quyết được điều kiện dựa trên bằng chứng được truy xuất. Hơn nữa, chúng tôi sử dụng lịch sử chỉnh sửa như một hình thức giám sát gián tiếp cho lý do ở mức từ, cho phép các giải thích tinh vi hơn (Camburu et al., 2018; Lei et al., 2016; Portelli et al., 2020; Thorne et al., 2019b).

Sinh văn bản phù hợp với thực tế. Việc tạo ra các văn bản phù hợp với các sự kiện đã cho là một thách thức đã được biết đến (Fan et al., 2020; Kryscinski et al., 2020; Lewis et al., 2020b; Parikh et al., 2020; Shah et al., 2020; Tian et al., 2020) vì các mô hình ngôn ngữ có xu hướng suy thoái và tạo ra các thông tin sai lệch (Holtzman et al., 2020; Schuster et al., 2020; Zhou et al., 2020). Hơn nữa, việc đánh giá không phải là điều đơn giản, và thường được thực hiện thủ công. VITAMINC bao gồm dữ liệu có giám sát để huấn luyện các mô hình chuỗi-thành-chuỗi, và cung cấp tự động-

đánh giá matic thông qua phân loại kiểm chứng sự thật er.

3 Bộ dữ liệu VITAMINC

VITAMINC (viết tắt là VitC) dựa trên các sửa đổi từ Wikipedia tiếng Anh. Wikipedia đã trở thành một nguồn tài nguyên trực tuyến toàn diện được duy trì nghiêm ngặt bởi một cộng đồng lớn và năng động (Benjakob và Harrison, 2019). Trong khi các đối thủ cố gắng chèn thông tin sai lệch, các trang phổ biến thường được sửa chữa nhanh chóng (Kumar và cộng sự, 2016). Hơn nữa, các chính sách của Wikipedia quy định rằng nội dung của nó nên được viết từ quan điểm trung lập—hoặc phải nêu khách quan tất cả các quan điểm. Các đặc điểm này làm cho Wikipedia trở thành một nguồn bằng chứng phù hợp cho các mô hình xác minh sự thật. Trong phần sau, chúng tôi sẽ trình bày quy trình khai thác các sửa đổi thực tế từ Wikipedia.

3.1 Thu thập các Sửa đổi Thực tế

Chúng tôi đã thu thập 5.000 bài viết tiếng Anh được xem nhiều nhất trên Wikipedia[4] tính đến tháng 1 nă m 2020, cùng với bất kỳ bài viết bổ sung nào được t ham chiếu từ chúng (trung bình 100 bài viết một bài). Chúng tôi cũng bao gồm tất cả các bài viết từ tập dữ liệu FEVER (Thorne và cộng sự, 2018). Đối với mỗi bài viết, chúng tôi đã truy xuất tối đa 500 lần chỉnh sửa gần đây nhất của nó. Vào tháng 5 năm 2020, chúng tôi đã thêm tất cả các bài viết liên quan đến COVID-19[5] và tất cả 41.000 lần chỉnh sửa của chúng vào thời điểm đó. Kết hợp lại, điều này dẫn đến tổng cộng $\sim$200 triệu lần chỉnh sửa. Đối với mỗi lần chỉnh sửa, chúng tôi xác định tất cả các câu đã được chỉnh sửa và lưu trữ hai phiên bản: (1) trước khi chỉnh sửa, và (2) sau khi chỉnh sửa.

Trong nhiệm vụ của chúng tôi, chúng tôi chỉ quan tâm đến các chỉnh sửa được thực hiện với ý định giới thiệu một sự thay đổi thực tế — tức là, một thay đổi mà người ta có thể đưa ra lập luận rằng nó được hỗ trợ bởi một câu, nhưng không p hải bởi câu kia. Để tăng tốc việc chú thích, chúng tôi đã huấn luyện một bộ phân loại BERT (Devlin et al., 2019) trên một tập nhỏ các câu đã được gán nhãn là thực tế (Yang et al., 2017), và sử dụng mô hình này để chọn ra 305.000 câu đã chỉnh sửa hàng đầu từ tập dữ liệu cho việc chú thích thủ công. Các nhà c hú thích người được huấn luyện sau đó được trình bày với các cặp câu, và được yêu cầu đánh dấu những cặp câu thực sự đại diện cho sự thay đổi t hực tế. Các câu thiếu ngữ cảnh tự chứa đã bị lọc bỏ (ví dụ: các biểu thức ngắn từ bảng hoặc danh sách gạch đầu dòng). Ví dụ về chú thích được trình bày trong Bảng 1. Lưu ý rằng các chú thích này cũng có thể được được tái chế theo đệ quy để huấn luyện lại bộ phân loại BERT tự động trong tương lai nhằm mở rộng thêm kho ngữ liệu (chúng tôi cũng giới thiệu điều này như một nhiệm vụ, xem §4.1).

3.2 Viết các yêu cầu

Các bản chỉnh sửa thực tế trên Wikipedia hướng dẫn chúng tôi trong việc tạo ra các tuyên bố thách thức để xác minh sự thật. Đối với mỗi lần chỉnh sửa, các người chú thích được yêu cầu viết hai tuyên bố đối xứng liên quan đến cùng một chỉnh sửa:

1. Câu đầu tiên nên được hỗ trợ bởi câu gốc và bị bác bỏ bởi câu sửa đổi; 2. Câu thứ hai nên được hỗ trợ bởi câu sửa đổi và bị bác bỏ bởi câu gốc.

Khi một mâu thuẫn rõ ràng không khả thi, một mối quan hệ không đủ thông tin (NEI) đã được sử dụng. Một nhóm gồm 70 người bản ngữ tiếng Anh[7] đã viết và xem xét các tuyên bố. Trong t hời gian chú thích, các chú thích được gửi theo l ô hàng tuần, từ đó chúng tôi kiểm tra các mẫu ngẫu nhiên để cung cấp phản hồi và yêu cầu chỉnh sửa. Người chú thích được hướng dẫn viết các tuyên bố ngắn gọn và độc lập. Hơn nữa, người chú thích được hướng dẫn tránh sao chép chính xác các cụm từ và giá trị khi có thể, nhằm tránh thiên vị cho việc trùng lặp từ cao hơn đáng kể trong các cặp ủng hộ so với các cặp phản bác. Ví dụ, thay vì nói, "có x ca mắc coronavirus đã được xác nhận ở Mỹ", ~~n~~người ta có thể viết "có hơn z ca mắc coronavirus đã được xác nhận ở Mỹ", điều này được ủng hộ nếu $x > z$ và bị phản bác nếu ngược lại. Đối với các chỉnh sửa chỉ thêm thông tin mới hoặc loại bỏ các thông tin lỗi thời mà không thay thế chúng, người chú thích sẽ viết một tuyên bố duy nhất.

3.3 Thêm Các Sửa Đổi Tổng Hợp

Tự nhiên, các phiên bản sửa đổi thực tế của Wikipedia mà chúng tôi thu thập chủ yếu mô tả các sự kiện thường xuyên thay đổi theo thời gian, hoặc dễ bị sai sót và cần sửa chữa (chẳng hạn như các giá trị định lượng, xem Phụ lục A.1) (Faruqui et al., 2018; Yang et al., 2017). Tuy nhiên, nhạy cảm với các ngữ cảnh trái ngược là hành vi đáng mong đợi đối với bất kỳ tuyên bố nào. Điều này vừa đảm bảo tính nhất quán với các nguồn sự thật bên ngoài, vừa cải thiện độ trung thực của mô hình thông qua việc kết nối phán quyết với bằng chứng cụ thể (Jacovi và Goldberg, 2020; Ross et al., 2020). Ví dụ, chúng tôi yêu cầu mô hình không chỉ phân loại tuyên bố "Tom Hanks được một tổng thống vinh danh" là đúng, mà còn thay đổi phán quyết của nó thành sai nếu đi kèm với một bằng chứng đối lập (hư cấu). Do đó, chúng tôi có thể xác minh rằng mô hình ưu tiên suy luận dựa trên cặp câu hơn

[3]https://bit.ly/Wiki_Trung lập_Quan điểm[4]https://bit.ly/Wiki_phổ biến_trang[5]https://wikimediafoundation.org/covid19[6]Nhiều chỉnh sửa chỉ phản ánh việc sửa ngữ pháp, diễn đạt lại, hoặc " Wikification" (định dạng văn bản/liên kết trang).

[7]Chúng tôi đã tìm nguồn các người chú thích của mình thông qua TransPerfect.

Thực tế		Các câu trên Wikipedia trước và sau khi chỉnh sửa, được trình bày kèm theo các tuyên bố VITAMINC nếu bản chỉnh sửa là thực tế.
✗	Trước	Các biện pháp nghiêm ngặt hơn đã được thực hiện ở Trung Quốc một khi mức độ nghiêm trọng của dịch bùng phát trở nên rõ ràng, chẳng hạn như việc cách ly toàn bộ các thành phố ảnh hưởng đến 60 triệu người ở Hồ Bắc, và lệnh cấm đi lại nghiêm ngặt.
	Sau	Những biện pháp quyết liệt hơn đã được thực hiện ở Trung Quốc khi mức độ nghiêm trọng của dịch bùng phát trở nên rõ ràng, chẳng hạn như cách ly toàn bộ thành phố ảnh hưởng đến 60 triệu người ở Hồ Bắc, và lệnh cấm đi lại nghiêm ngặt.
✓	Trước	Ở động vật, việc triệt sản ở cái liên quan đến việc loại bỏ buồng trứng một cách xâm lấn, nhưng hiếm khi gây ra các biến chứng nghiêm trọng khác so với điều đó, những con vật đã được triệt sản có xu hướng tăng cân.
	Sau	Ở động vật, việc triệt sản ở cái liên quan đến việc loại bỏ buồng trứng một cách xâm lấn, nhưng hiếm khi gặp các biến chứng nghiêm trọng; Sự mê tín rằng nó gây tăng cân không dựa trên sự thật.
	Yêu cầu 1	Các động vật đã bị triệt sản tăng cân.
	Yêu cầu 2	Tăng cân ở động vật đã được triệt sản là một quan niệm mê tín.
✗	Trước	Tính đến ngày 16 tháng 3, đã có hơn 182.000 ca bệnh được báo cáo tại hơn 160 quốc gia và các vùng lãnh thổ, dẫn đến khoảng 79.000 ca hồi phục và hơn 7.100 ca tử vong.
	Sau	Tính đến ngày 16 tháng 3, đã có hơn 182.000 ca bệnh được báo cáo tại hơn 160 quốc gia và các vùng lãnh thổ, dẫn đến hơn 7.100 ca tử vong và khoảng 79.000 ca hồi phục.
✓	Trước	Doanh số xe hybrid toàn cầu được dẫn đầu bởi gia đình Prius, với doanh số 4,7 triệu chiếc chiếm 66,8% của Doanh số bán hàng toàn cầu của TMC đạt 7,053 triệu đơn vị Lexus và Toyota tính đến tháng 9 năm 2014.
	Sau	Doanh số xe hybrid toàn cầu do dòng Prius dẫn đầu, với doanh số 5,264 triệu chiếc chiếm 65,4% của Doanh số bán toàn cầu của TMC đạt 8,048 triệu đơn vị Lexus và Toyota đã giao đến tháng 7 năm 2014.
	Yêu cầu 1	Prius đã bán được chưa đến 5 triệu chiếc, chiếm hơn 65,5% doanh số bán hàng toàn cầu của TMC.
	Yêu cầu 2	Prius đã bán được hơn 5 triệu chiếc, chiếm chưa đến 65,5% tổng doanh số bán hàng toàn cầu của TMC.

Bảng 1: Ví dụ về các chỉnh sửa không thực tế so với các chỉnh sửa thực tế, và các khẳng định liên quan đến các chỉnh sửa sau. Các cập nhật thực tế thay đổi kết quả (tức là đúng hay sai) của một khẳng định có thể đang bị nghi ngờ. Theo đó, phán quyết của một bộ phân loại nên thay đổi dựa trên phiên bản được trình bày. Các từ đã được chỉnh sửa được gạch chân và đánh màu.

việc ghi nhớ, điều này có thể giúp nó tổng quát hóa tốt hơn. Do đó, chúng tôi sử dụng bộ dữ liệu FEVER để tăng cường VITAMINC với các sửa đổi tổng hợp đối với các câu trên Wikipedia.

Chúng tôi tuân theo phương pháp của Schuster và cộng sự (2019) để mở rộng các cặp luận điểm-bằng chứng từ FEVER (Thorne và cộng sự, 2018). Cụ thể, với một luận điểm sai từ FEVER, chúng tôi yêu cầu người gán nhãn chỉnh sửa câu một cách bác bỏ nó sao cho câu này sau đó sẽ ủng hộ luận điểm ban đầu là sai. Thêm vào đó, chúng tôi yêu cầu họ viết một luận điểm mới bị bác bỏ bởi câu đã được chỉnh sửa mới này, nhưng được ủng hộ bởi phiên bản gốc. Theo phương pháp này, chúng tôi thu được hai luận điểm mà mỗi luận điểm có thể được ủng hộ hoặc bác bỏ bởi câu gốc, hoặc câu đã được chỉnh sửa tổng hợp. Chúng tôi theo cùng một quy trình để xây dựng các ví dụ tổng hợp sử dụng các luận điểm đúng, nhưng với nhãn bị đảo ngược.

3.4 Thống kê bộ dữ liệu

Tổng cộng, 304.671 câu Wikipedia đã được chỉnh sửa đã được các người chú thích kiểm tra, trong đó 107.056 câu (35%) được phát hiện thể hiện một sự sửa đổi theo thực tế và được chuyển cho nhóm các chuyên gia chú thích để viết tuyên bố. Khi có thể, hai tuyên bố đối xứng với các sự thật đối nghịch đã được tạo ra cho mỗi lần chỉnh sửa, điều này dẫn đến tổng cộng 325.724 cặp tuyên bố-bằng chứng. Chúng tôi đã thu thập 163.180 thêm

Chia	Hỗ trợ Real	Hỗ trợ Syn	Bác bỏ Real	Bác bỏ Syn	NEI Thực Syn	NEI
Tàu	124.864	60.850	71.108	60.850	52.981	-
Dev	21,102	10,382	12,146	10,382	9,042	-
Test	17,306	10,358	9,907	10,358	7,268	-

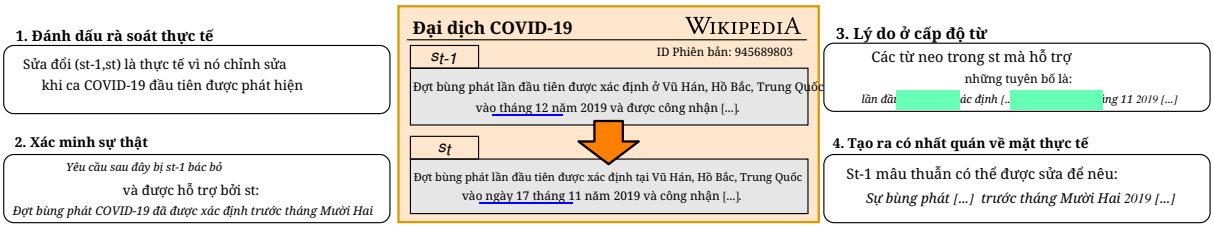
Bảng 2: Số lượng cặp lập luận-bằng chứng trong VITAM-INC. Phân tích các bản sửa đổi thực và tổng hợp được trình bày lần lượt ở bên trái và bên phải mỗi ô.

các cặp tional theo quy trình tổng hợp. Dữ liệu được phân chia như được trình bày trong Bảng 2. Việc phân công được thực hiện ngẫu nhiên theo bài viết, và nhất quán với FEVER đối với các bài viết trùng lặp. Phụ lục A chứa thêm chi tiết.

4 Nhiệm vụ VITAMINC

Cấu trúc độc đáo của VITAMINC cho phép chúng tôi tạo ra các chú thích cung cấp một nguồn giám sát mới cho một số tác vụ liên quan đến xác minh sự thật. Chúng tôi mô tả bốn tác vụ chính mà chúng tôi xem xét trong nghiên cứu này, cùng với các mô hình cơ sở: (1) đánh dấu điều chỉnh thực tế, (2) xác minh sự thật, (3) lý do ở cấp từ, và (4) tạo nội dung nhất quán với thực tế. Hình 2 minh họa một ví dụ từ VITAMINC. Chúng tôi sử dụng các ký hiệu sau:

• $\mathcal{C}$ là không gian của các câu ngắn diễn đạt một tuyên bố thực tế tùy ý có thể được xác minh hoặc bác bỏ bởi các nguồn bên ngoài.



Hình 2: Bộ dữ liệu VITAMINC sử dụng các bản sửa đổi của Wikipedia để thúc đẩy bốn nhiệm vụ xác minh sự thật trung tâm. Nguồn bản sửa đổi: https://en.wikipedia.org/wiki/?diff=945689803.

• $\mathcal{S}$ là không gian các câu có thể tìm thấy trong một nguồn trực tuyến đáng tin cậy (Wikipedia trong nghiên cứu này).

• (s_{t-1}, s_t) chỉ hai phiên bản của một câu đã được chỉnh sửa từ s_{t-1} thành $s_t \in \mathcal{S}$.

• rel(c, s) chỉ mối quan hệ giữa tuyên bố $c \in \mathcal{C}$ và bằng chứng quan sát được $s \in \mathcal{S}$ — có thể ủng hộ nó (SUP), phản bác nó (REF), hoặc không chứa đủ thông tin (NEI).

4.1 Đánh dấu sửa đổi thực tế

Các nguồn trực tuyến như Wikipedia liên tục thay đổi. Để duy trì vai trò là một nguồn tin cậy và trung lập cho thông tin mới nhất, cộng đồng người dùng tích cực của nó phải liên tục xác minh và sửa các bản chỉnh sửa của người khác. Chúng tôi định nghĩa việc đánh dấu chỉnh sửa thực tế là nhiệm vụ xác định các chỉnh sửa đưa ra sự thay đổi thực tế—ví dụ, bằng cách sửa đổi một sự thật nhất định, thêm một sự thật mới hoặc loại bỏ một sự thật hiện có. Quá trình phát hiện tự động như vậy có thể giúp cộng đồng quản lý các bài viết quan trọng bằng cách đóng vai trò như một người giá m sát các chỉnh sửa thực tế. Hơn nữa, theo dõi các chỉnh sửa thực tế cho các bài viết nhất định có thể giúp duy trì sự nhất quán cho các bài viết phụ thuộc (ví dụ, các bài viết trích dẫn, hoặc các phiên bản không phải tiếng Anh).

Chúng tôi đặt việc đánh dấu sửa đổi thực tế như một hàm phân loại nhị phân f_{flag}: $\mathcal{S} \times \mathcal{S} \rightarrow \{0, 1\}$, trong đó đối với một sửa đổi (s_{t-1}, s_t) $_i$, chúng tôi đặt $y_i = 1$ nếu tồn tại một tuyên bố trong $\mathcal{C}$ mà nhãn của nó (SUP hoặc REF) thay đổi do chỉnh sửa (tức là, SUP $\rightarrow$ { REF, NEI } hoặc REF $\rightarrow$ { SUP, NEI }). Bảng 1 cung cấp các ví dụ về các sửa đổi thực tế và không thực tế. Chúng tôi đánh giá các mô hình cơ bản sau:

Khoảng cách chỉnh sửa. Chúng tôi đo khoảng cách chỉnh sửa giữa s_{t-1} và s_t, giả sử rằng những chỉnh sửa lớn hơn có khả năng đại diện cho những thay đổi thực chất. Chúng tôi điều chỉnh ngưỡng quyết định trên tập dữ liệu xác thực.

BẢNG. Chúng tôi sử dụng một MLP trên đỉnh của biểu diễn túi từ. Mỗi câu được mã hóa thành e_*, là trung bình của nhúng từ fastText (Bojanowski et al., 2017) của các từ đã chỉnh sửa của nó (tức là, những từ đã bị xóa hoặc sửa đổi trong bản chỉnh sửa). Đầu vào của MLP sau đó được lấy là $[e_{t-1}; e_t; |e_t - e_{t-1}|; e_t \cdot e_{t-1}]$.

ALBERT. Chúng tôi huấn luyện bộ biến đổi ALBERT (Lan et al., 2020) sử dụng hoặc chỉ các từ được chỉnh sửa (diff), hoặc toàn bộ cặp câu (full).

4.2 Xác minh sự thật

Cài đặt cơ bản của chúng tôi tương tự như nhiệm vụ suy luận của bộ dữ liệu FEVER. Chúng tôi dự đoán phán quyết cho một tuyên bố dựa trên bằng chứng quan sát được: SUP, REF, NEI. Tuy nhiên, bộ dữ liệu FEVER chứa các cặp tuyên bố-bằng chứng độc lập. Trong cài đặt của chúng tôi, chúng tôi có các tuyên bố được ghép với các bản sửa đổi sao cho rel(c_i, s_{t-1}) khác rel(c_i, s_t), tạo ra các bộ ba đối lập. Ví dụ, tuyên bố trong Hình 2 nêu rõ rằng đợt bùng phát COVID-19 đã được xác định trước tháng Mười Hai. VITAMINC ghép nó với hai ngữ cảnh khác nhau (trước và sau bản sửa đổi được trình bày), có thể hỗ trợ hoặc bác bỏ tuyên bố đó.

Mô hình cơ sở của chúng tôi là một bộ phân l oại cặp câu ALBERT dự đoán rel(c, s). So với BERT (Devlin và cộng sự, 2019), nó sử dụng ít tham số hơn bằng cách thu nhỏ kích thước nhúng và chia sẻ các lớp, điều mà chúng tôi nhận thấy cải thiện độ bền.

4.3 Lập luận ở cấp từ

Các lý giải ở cấp độ từ cung cấp những giải thích hữu ích cho các dự đoán của các mô hình mạng nơ-ron (Lei và cộng sự, 2016). Những giải thích như vậy có thể đặc biệt hữu ích cho việc xác minh sự thật bán tự động, vì chúng cho phép người dùng nhanh chóng diễn giải và tin tưởng vào phán quyết của mô hình. Ví dụ, trong Hình 2, ngày của ca bệnh được xác định đầu tiên có t hể giải thích phán quyết cho tuyên bố đó.

Như lần đầu tiên được đề xuất bởi Lei và cộng sự (2016), định nghĩa chuẩn về các lý do trích xuất yêu cầu chọn tập hợp tối thiểu các từ đầu vào đủ để giữ dự đoán của mô hình. Ở đây chúng tôi sử dụng một định nghĩa được chỉnh sửa một chút theo Shah và cộng sự (2020), nơi chúng tôi xác định tập hợp tối thiểu các từ chứng cứ mà khi loại bỏ chúng

[8]Để tập trung vào nhiệm vụ suy luận, thay vì một hệ thống đầ u-cuối đầy đủ, chúng tôi giả sử rằng chúng tôi có quyền truy cập vào một công cụ truy xuất oracle. [9]Roitero và cộng sự (2020) đã chỉ ra rằng các giải thích có thể tăng sự đồng thuận giữa người dùng và các chuyên gia kiểm chứng sự thật.

sẽ thay đổi nhãn của đầu vào thành NEI.

Chúng tôi đặt nhiệm vụ này dưới dạng che điều kiện, nơi chúng tôi học một hàm $f_{\text{rationale}}$: $\mathcal{C} \times \mathcal{S} \rightarrow \{0,1\}^n$, trong đó n là độ dài của một bằng chứng $s \in \mathcal{S}$. Cho một bằng chứng $s = (x_1, \ldots, x_n)$ và một tuyên bố c, nơi rel(c, s) $\in$ {SUP, REF}, chúng tôi muốn tìm một mặt nạ m sao cho rel(c, $s \odot m$) = NEI, nơi

$$s \odot m = \begin{cases} x_i & \text{if } m[i] = 0; \\ \texttt{<mask>} & \text{if } m[i] = 1. \end{cases}$$

Hơn nữa, chúng tôi muốn m trở nên thưa thớt nhất có thể. Trực giác cho thấy, $s \odot m$ có thể được coi như một bản chỉnh sửa chưa hoàn thiện mà trong đó các từ bị che mà chưa được điền sẽ quyết định mối quan hệ với tuyên bố. Chúng tôi nói rằng m tiết lộ các từ có trách nhiệm nhất trong s để giải quyết c. Theo Shah et al. (2020), chúng tôi xây dựng một mục tiêu không giám sát như một

$$\min \sum_{i=1}^{n} m_i \;\; \text{s.t.} \;\; \text{rel}(c, s \odot m) = \text{NEI}\,. \qquad (1)$$

Chúng tôi đánh giá chất lượng của m bằng cách so sánh nó về mặt F1 với cả (1) m_{edit}, các từ không phải stopwords được bỏ hoặc thay thế trong phiên bản true revision (tức là dự đoán chỉnh sửa), và (2) m_{manual}, một tham chiếu "con người" được chú thích thủ công (tức là dự đoán lý do). Chúng tôi triển khai hai phương pháp cơ bản sau:

Không giám sát. Như trong Shah và cộng sự (2020), chúng tôi t ối ưu hóa một sự thư giãn Lagrange của Phương trình 1, trong đó

$$\mathcal{L}_{\text{us}} := -\log p(\text{rel}(c, s \odot m) = \text{NEI}) + \frac{\lambda}{n} \sum_{i=1}^{n} m_i.$$

Chúng tôi giữ cố định bộ phân loại rel (từ §4.2), và huấn luyện một mô hình ALBERT riêng biệt để dự đoán the mask$m$ bằng cách sử dụng Gumbel softmax (Jang et al., 2017).

Giám sát từ xa. Bằng cách tận dụng các tuyên bố trái ngược có trong VITAMINC, chúng tôi có thể xác định m_{edit} = diff(s_{t-1}, s_t)—tức là các từ không phải danh từ dừng bị xóa hoặc thay thế trong s_{t-1} khi so sánh với s_t. Sau đó, chúng tôi sử dụng m_{edit} làm giám sát từ xa cho m, nơi $\mathcal{L}_{\text{ds}} = -\frac{\gamma}{n} \sum_{i=1}^{n} \log p(m_i = m_{\text{edit}_i})$. Chúng tôi kết hợp cả $\mathcal{L}_{\text{us}}$ và $\mathcal{L}_{\text{ds}}$ mất mát.

4.4 Sinh ra nhất quán về mặt thực tế

Khi các sự kiện thay đổi, các nguồn báo cáo chúng cũng phải thay đổi để phản ánh thông tin mới nhất. Trong VITAMINC, điều này được thể hiện thông qua việc chỉnh sửa tích cực trên Wikipedia. Chúng tôi mô phỏng việc tự động hóa quá trình này bằng cách xem xét hai nhiệm vụ tạo nội dung:

Sửa đổi tự động. Cho một ngữ cảnh lỗi thời s_{t-1} và một tuyên bố được cập nhật c, chúng tôi học f_{revise}: $\mathcal{S} \times \mathcal{C} \rightarrow \mathcal{S}$ để tạo ra một ngữ cảnh mới s_t mà thay đổi tối thiểu s_{t-1} để phù hợp với c. Ví dụ, người ta có thể thay đổi s_{t-1} trong Hình 2 để ghi " trước tháng Mười Hai" nhằm phù hợp với tuyên bố.

Trích xuất Yêu cầu. Cho một bản chỉnh sửa (s_{t-1}, s_t), chúng tôi học f_{extract}: $\mathcal{S} \times \mathcal{S} \rightarrow \mathcal{C}$ để tạo ra một yêu cầu ngắn c thể hiện sự thay đổi thực tế.

Trong cả hai nhiệm vụ, đầu ra nên thỏa mãn rel(c, s_t) = SUP, trong khi rel(c, s_{t-1}) = REF. Chúng tôi sử dụng f_{verdict} (§4.2) để đánh giá yêu cầu này. Chúng tôi thử nghiệm cả hai bộ sinh dựa trên transformer theo chuỗi-to-chuỗi là BART-base (Lewis et al., 2020a) và T5-base (Raffel et al., 2020). Đối với nhiệm vụ chỉnh sửa, chúng tôi kết hợp s_{t-1} và c với một ký tự phân tách và huấn luyện mô hình để dự đoán s_t. Đối với nhiệm vụ trích xuất khẳng định, chúng tôi kết hợp cặp đầu vào (s_{t-1}, s_t) thành một câu duy nhất hiển thị bản chỉnh sửa (ví dụ: "doanh số của {4.*7* → *5.*4} triệu").

5 Thí nghiệm

Chúng tôi trình bày và phân tích kết quả cho các mô hình được mô tả trong Mục 4. Phân tích của chúng tôi cố gắng đánh giá một số câu hỏi: (1) Các mô hình hiện đại nhất có thể thực hiện tốt các nhiệm vụ của VITAMINC đến mức nào? (2) Liệu VITAMINC có làm tăng độ bền vững của các mô hình trước các ví dụ thù địch hay không? (3) Liệu VITAMINC có thể cải thiện khả năng giải thích bằng cách cung cấp giám sát cho các từ mấu chốt không?

5.1 Bộ Dữ Liệu Liên Quan

Ngoài VITAMINC, chúng tôi đào tạo và đánh giá trên một số tập dữ liệu liên quan, mà chúng tôi sẽ mô tả ngắn gọn:

SỐT (Thorne và cộng sự, 2018): Một bộ dữ liệu xác thực sự thật phổ biến dựa trên Wikipedia. Chúng tôi sử dụng các cặp tuyên bố-bằng chứng SUP và REF được cung cấp. Đối với các tuyên bố NEI, c húng tôi chọn ngẫu nhiên bằng chứng trung lập từ bài viết có điểm BM25 cao nhất (Fisch và cộng sự, 2021).

MNLI (Williams và cộng sự, 2018): Một tập dữ liệu lớn và đa dạng cho suy luận ngôn ngữ tự nhiên. Dự đoán quan hệ ba chiều giữa các cặp câu tương tự như xác minh sự thật. Chúng tôi sử dụng giả thuyết như là tuyên bố và tiền đề như là bằng chứng và đánh giá trên tập đánh giá "không khớp".

Đối xứng (Schuster và cộng sự, 2019): Một tập hợp các phần mở rộng tổng hợp đối xứng đầy thách thức cho bộ đánh giá FEVER mà tránh thiên vị chỉ dựa trên phát biểu.

Đối kháng (Thorne et al., 2019c): Các ví dụ đối kháng được tạo ra bởi các thành viên tham gia nhiệm vụ chia sẻ F EVER 2.0. Các đội được yêu cầu tạo ra các tuyên bố mà

Mô hình	Dữ liệu huấn luyện	AUC	Tối	Rec.	F1
Chỉnh sửa dist.	-	71.34	64.90	63.18	63.56
ALBERT	Đầy BÀN CHÂN	72.20	65.27	60.61	60.48
BOW	VitC-diff	79.87	70.85	67.84	68.55
ALBERT	VitC-diff	89.87	80.69	82.06	81.18
ALBERT	VitC-đầy đủ	**91.97**	82.63	84.49	**83.18**

Bảng 3: Điểm đánh dấu hiệu chỉnh thực tế cho các mô hình nhận biết toàn bộ cặp câu (full) và chỉ nhận biết các từ được sửa đổi (diff). Chúng tôi sử dụng ALBERT-base.

phá vỡ các mô hình được huấn luyện FEVER. Chúng tôi lấy tất cả các tuyên bố SUP và REF cùng với các câu bằng chứng vàng của chúng.

Các trình kích hoạt (Atanasova et al., 2020): Một tập hợp gồm 186 tuyên bố FEVER được diễn giải lại theo cách đối kháng để chứa các trình kích hoạt đối kháng phổ quát (Wallace et al., 2019). Kích thước nhỏ của nó dẫn đến kết quả có độ biến thiên cao.

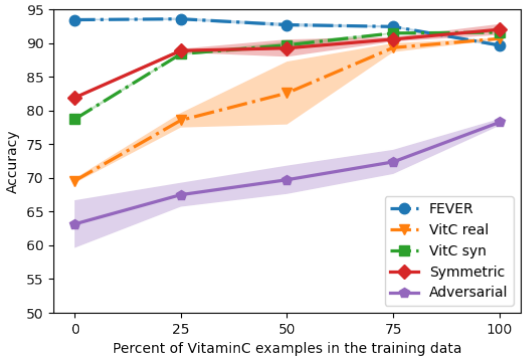
ANLI (Nie và cộng sự, 2020): Một tập dữ liệu đối kháng cho các mô hình dựa trên MNLI và FEVER. Việc tạo ra được thực hiện qua ba vòng lặp, trong đó một mô hình được huấn luyện, sau đó các lao động đám đông tạo ra các đầu vào đối kháng, và quá trình được lặp lại.

PAWS (Zhang và cộng sự, 2019): Một bộ dữ liệu các câu t rên Wikipedia đã bị thay đổi sử dụng phương pháp hoán đổi từ và dịch ngược. Các chú thích viên con người đã gắn nhãn liệu câu đã chỉnh sửa có phải là câu diễn giải lại hay không. Chúng tôi đánh giá xem liệu một bộ phân loại được huấn luyện trên PAWS có thể được sử dụng cho nhiệm vụ đánh dấu sửa đổi thực tế của chúng tôi hay không.

5.2 Đánh dấu sửa đổi thực tế

Bảng 3 cho thấy kết quả của các mô hình cơ sở của chúng tôi trên nhiệm vụ đánh dấu sửa đổi thực tế. Đầu tiên, chúng tôi nhận thấy rằng một mô hình được huấn luyện trên bộ dữ liệu PAWS (đạt 93,42 điểm F1 trên bài kiểm tra PAWS) không chuyển giao tốt sang nhiệm vụ đánh dấu, và hoạt động ngang bằng với một thuật toán khoảng cách chỉnh sửa đơn giản. Chúng tôi giả thuyết rằng điều này là kết quả của kỹ thuật tráo đổi thực thể được sử dụng để chỉnh sửa câu một cách tổng hợp trong PAWS, điều này khác với các chỉnh sửa được thực hiện bởi các phiên bản thực tế, có thực tế trên Wikipedia.

Thứ hai, chúng ta thấy rằng hiệu suất của các mô hình thần kinh được huấn luyện trên nhiệm vụ đánh dấu VITAMINC tăng lên với các đầu vào phong phú hơn và các mô hình tiên tiến hơn—cho thấy sự phức tạp của nhiệm vụ. Mô hình ALBERT(diff) chỉ sử dụng các chuỗi từ đã được chỉnh sửa từ mỗi câu (tức là theo ngữ cảnh trong một khoảng con) cải thiện AUC lên 10 điểm so với mô hình BOW nhận cùng một đầu vào tương tự. Mô hình ALBERT (full) nhận toàn bộ câu làm đầu vào (tức là có quyền truy cập vào nhiều ngữ cảnh hơn), cải thiện AUC thêm 2 điểm. Tuy nhiên, mô hình tốt nhất vẫn chỉ đạt 83



Hình 3: Độ chính xác kiểm tra của các mô hình được huấn luyện trên một tập dữ liệu gồm 100K ví dụ kết hợp SUP và REF từ VITAMINC và FEVER. Tỷ lệ VITAMINC trong dữ liệu huấn luyện càng cao, hiệu suất trên các bộ đánh giá đối kháng càng tốt (đường liền). Các vùng được tô màu biểu thị sai số chuẩn trên ba lần chạy.

macro-F1, cho thấy độ khó của nhiệm vụ này.

5.3 Xác minh sự thật

Bảng 4 tóm tắt kết quả cho các bộ phân loại được huấn luyện trên các tập dữ liệu xác minh sự thật và NLI. Việc xác minh các tuyên bố dựa trên các sửa đổi thực tế được chứng minh là khó nhất. Mô hình tốt nhất đạt độ chính xác 89%, thấp hơn so với trên cả các trường hợp tổng hợp của VITAMINC hoặc các ví dụ gốc của FEVER. Việc đưa các ví dụ VITAMINC vào dữ liệu huấn luyện làm tăng đáng kể độ nhạy của các mô hình đối với các ví dụ đối chiếu (cột ngoài cùng bên phải) — trong khi vẫn duy trì độ chính xác trong miền (chỉ -0.42% cho FEVER và $+0.12$% cho MNLI với ALBERT-xlarge). Một bằng chứng khác về các đặc tính tổng quát được cung cấp bởi VITAMINC là hiệu suất zero-shot trên cả hai tập dữ liệu khác. Một mô hình ALBERT-xlarge chỉ được huấn luyện trên VITAMINC đạt 76% và 79% độ chính xác trên FEVER và MNLI, tương ứng. Ngược lại, độ chính xác chuyển giao cho MNLI→ FEVER là 70% và cho FEVER→MNLI chỉ là 38%.

Quan trọng nhất, các mô hình được huấn luyện với VITA-MINC hoạt động tốt hơn trên các tập dữ liệu đối kháng khó. Ngược lại, việc đơn giản bổ sung dữ liệu FEVER bằng dữ liệu MNLI có ảnh hưởng hạn chế đến các ví dụ đối kháng. Chúng tôi suy đoán rằng bản chất đối chiếu của VITA-MINC giúp các mô hình học tốt hơn các mối quan hệ giữa các khẳng định và bằng c hứng—và tránh dựa vào một số hiện vật nhất định mà không tổng quát tốt.

Để điều tra thêm giá trị của các ví dụ VITAMIN C so với các ví dụ FEVER (SUP và REF

[10]Chúng tôi cũng đã thử tăng cường FEVER với ANLI cho mô hình ALBERT-xlarge và thấy rằng nó chỉ đạt 73%, 91% và 34% trên Adver., Sym. và Triggers, tương ứng.

Mô hình	Tập dữ liệu huấn luyện	VitC thật	VitC syn	SỐT	MNLI	Trạng từ	Sym.	Kích hoạt	ANLI	Tương phản
ALBERT-base	SỐT	54.78	79.18	95.07	58.45	62.01	81.18	3.33	32.94	55.53
	MNLI	44.93	69.67	65.70	85.22	49.61	72.89	68.82	30.63	56.67
	SỐT + MNLI	55.93	82.26	95.62	85.58	63.97	85.67	38.71	30.59	61.90
	VitC	86.16	89.78	74.56	69.18	71.41	90.17	**86.67**	37.25	84.11
	VitC +MNLI	86.68	91.18	77.70	85.95	69.58	91.15	70.97	34.31	85.61
	VitC +SỐT	86.26	91.05	94.24	68.90	68.80	91.57	72.04	38.50	85.89
ALBERT-rất lớn	SỐT	58.56	84.22	96.47	38.33	72.58	87.08	32.80	36.03	64.59
	MNLI	49.26	74.58	70.47	88.91	53.52	78.65	72.58	36.38	63.41
	SỐT + MNLI	61.21	86.81	**96.81**	**89.04**	69.97	89.75	43.55	37.66	70.44
	VitC	88.64	93.84	75.99	78.89	**82.51**	**94.80**	67.20	**42.66**	89.57
	VitC +MNLI	88.69	93.92	76.80	89.03	80.81	**94.80**	67.20	40.09	89.80
	VitC +SỐT	**88.87**	**94.01**	96.05	62.30	80.94	**94.80**	65.59	40.31	**90.94**

Bảng 4: Độ chính xác kiểm tra của các mô hình xác minh sự thật và NLI. Các mô hình được huấn luyện VITAMINC có độ bền cao hơn với các tấn công đối kháng-

ví dụ sarial và nhạy cảm hơn với các ngữ cảnh tương phản. Cột bên phải cùng cho thấy tỷ lệ phần trăm của FEVER những tuyên bố trong đó dự đoán bị đảo ngược khi được trình bày với các bối cảnh tương phản.

Mã thông báo nhãn	Chỉnh sửa dự đoán			Lý do ở cấp từ		
	Tối	Rec.	F1	Tối	Rec.	F1
-	31.93	30.56	31.23	31.11	46.64	37.33
✓	55.93	62.68	**59.11**	36.92	66.03	**47.36**

Bảng 5: Việc giám sát ở mức token xa của VITA M-INC cải thiện dự đoán chỉnh sửa, và kết quả là xác định các từ mấu chốt (lý lẽ) chính xác hơn.

chỉ), chúng tôi tạo ra các tập huấn luyện gồm 100.000 ví dụ sử dụng các tỉ lệ khác nhau của hai bộ dữ liệu. Như được trình bày trong Hình 3, việc bao gồm nhiều cặp VITAMINC hơn liên tục cải t hiện hiệu suất trên các bộ đánh giá đối kháng và đối xứng đầy thách thức.

Như một thí nghiệm định tính bổ sung, trước những thành công gần đây của các mô hình ngôn ngữ khổng lồ như GPT-3 (Brown et al., 2020), chúng tôi khám phá xem liệu các mô hình này có tự phát triển đủ khả năng nhạy cảm với ngữ cảnh hay không. Phụ lục C trình bày kết quả phân loại một số tuyên bố bằng mô hình GPT-3 với phương pháp vài mẫu. Chúng tôi nhận thấy GPT-3 vẫn còn kém một phần lớn so với các mô hình được huấn luyện bằng VITAMINC của chúng tôi về mặt nhạy cảm—điều này chứng minh tầm quan trọng của việc sử dụng cấu trúc độc đáo của VITAMINC trong quá trình huấn luyện.

5.4 Lập luận ở cấp từ

Bảng 5 cho thấy kết quả của các mô hình cơ sở của chúng tôi trong việc xác định các lý do ở mức từ (tức là các từ làm điểm neo trong bằng chứng). Trong khi mô hình không giám sát của chúng tôi có thể phát hiện một số mẫu, việc tận dụng trực tiếp cấu trúc của VITAMINC để đạt được giám sát từ xa cho các từ có khả năng làm điểm neo (tức là nhãn token) cải thiện cả hiệu suất dự đoán chỉnh sửa và dự đoán lý do ở mức từ. Ví dụ về các dự đoán được cung cấp trong Phụ lục E.

[11]Chúng tôi đánh giá các lý do bằng cách sử dụng một bộ dữ liệu kiểm tra được chú thích thủ công gồm 300 ví dụ (mỗi loại 150 ví dụ từ VitC thực và VitC tổng hợp).

5.5 Tạo nội dung nhất quán theo thực tế

Bảng 6 trình bày kết quả về việc tạo ra nội dung nhất quán với thực tế. Chúng tôi nhận thấy BART hoạt động tốt hơn trong cả hai nhiệm vụ tạo văn bản của chúng tôi (mặc dù chúng tôi chỉ thử cài đặt mặc định). Điểm BLEU (Papineni et al., 2002) thấp hơn trong nhiệm vụ trích xuất tuyên bố vì có sự tự do trong cách diễn đạt các tuyên bố, điều này có t hể dẫn đến khác biệt lớn hơn giữa kết quả đầu ra và các tài liệu tham khảo. Điểm BLEURT dựa trên BERT (Sellam et al., 2020) cũng cho thấy xu hướng tương tự. Tuy nhiên, mô hình trích xuất tuyên bố vẫn thành công trong việc cập nhật các sự kiện phản ánh đúng chỉnh sửa thực tế 86% thời gian, được đo bằng phán quyết của mô hình xác minh sự thật (f_{verdict}).

Bộ tạo chỉnh sửa nhằm mục đích thay đổi câu sao cho chúng đồng ý với một tuyên bố đã cho. Theo phán quyết của mô hình xác minh sự thật của chúng tôi, nó thành công trong việc này 76% thời gian. Hơn nữa, các chỉnh sửa nên giống với các chỉnh sửa thực tế, và giữ lại phần nội dung còn lại không liên quan đến tuyên bố. Chỉ số SARI KEEP F1 (Xu et al., 2016) là 75 cho thấy mô hình và tham chiếu phần lớn đồng ý về các phần của câu nên được giữ nguyên.

Chúng tôi nhận thấy rằng các thước đo dựa trên token và chỉ số f_{verdict} của chúng tôi tương đồng tốt với các điểm đánh giá của con người (thủ công). Chúng tôi đã ngẫu nhiên chọn mẫu 100 câu được tạo ra và viết bởi con người cho mỗi nhiệm vụ, và yêu cầu các công nhân trên Amazon MTurk đánh giá tính ngữ pháp của chúng và liệu bằng chứng s_t có hỗ trợ cho khẳng định hay không. Điểm số của các câu được tạo ra tương đương với các câu viết bởi con người, cho thấy chất lượng cao của các kết quả đầu ra của chúng tôi.

Bảng 7 trình bày hai ví dụ sinh ra cho nhiệm vụ trích xuất khẳng định (chúng tôi cung cấp thêm các ví dụ định tính trong Phụ lục E). Mô hình của chúng tôi có khả năng trích xuất hiệu quả một khẳng định độc lập thể hiện đúng sự thật sau khi chỉnh sửa. Như trong §5.3,

Mục tiêu	Mô hình	ĐỎ	BLEU	Điểm SARI KEEP	ADD	DEL	AVG	BLEURT	f_{verdict}	Đánh giá thủ công Ngữ pháp	SUP
Sửa đổi	T5	77.63	47.46	72.61	13.32	43.04	42.99	0.38	64.52	81.00	71.80
	BART	85.23	54.86	75.36	18.31	47.95	47.21	0.67	76.26	84.80	83.20
Yêu cầu	T5	35.19	13.95	44.36	20.59	87.54	50.83	-0.12	75.39	71.33	72.22
	BART	40.38	16.14	52.91	23.62	91.37	55.97	0.16	85.83	75.78	74.22

Bảng 6: Kết quả tạo ra nhất quán về mặt thực tế. Điểm cao hơn là tốt hơn cho tất cả các chỉ số và giá trị tối đa là 100 (trừ BLEURT). f_{verdict} là điểm của mô hình ALBERT-base được huấn luyện VITAMINC của chúng tôi trên các đầu ra. Đối với đánh giá thủ công, các đầu ra được đánh giá dựa trên ngữ pháp và mức độ bằng chứng hỗ trợ cho tuyên bố (SUP). Tham khảo một cặp viết bởi con người đạt trung bình 75,75 và 76,0 điểm cho Ngữ pháp và SUP, tương ứng.

(s_{t-1}, s_t)	Đại dịch coronavirus 2020 tại Đức: đã có {*| 349 -> 444 |} ca được xác nhận và 16 ca khỏi bệnh.		
BART (VitC)	Hơn 400 người đã có kết quả xét nghiệm dương tính với COVID-19 ở Đức.	$f_{\text{verdict}}(c, s_t) =$	SUP
GPT-3 $\mathcal{T}$=0	Tính đến ngày 14 tháng 3, đã có hơn 350 ca nhiễm virus được xác nhận ở Đức		SUP
GPT-3 $\mathcal{T}$=0.7	Tính đến ngày 12 tháng 3, đã có hơn 400 ca được xác nhận và 20 ca tử vong được báo cáo		NEI
Tham khảo	Đã có hơn 400 ca nhiễm coronavirus được xác nhận ở Đức.		SUP
(s_{t-1}, s_t)	Diego Corrales: Corrales sinh ra trong một gia đình với cha là người {Puerto Rico - người Mỹ gốc Phi} và một mẹ Dominican-Mexican.		
BART (VitC)	Cha của Diego Corrales là người Mỹ gốc Phi và mẹ của anh ấy là người Mexico.		SUP
GPT-3 $\mathcal{T}$=0	Corrales sinh ra trong một gia đình có cha người Puerto Rico và mẹ người Mexico		REF
GPT-3 $\mathcal{T}$=0.7	Corrales sinh ra trong một gia đình có cha là người Puerto Rico và mẹ là người Cộng hòa Dominica		REF
Tham khảo	Cha của Diego Corrales là người Mỹ gốc Phi và mẹ của anh là người Mexico.		SUP

Bảng 7: Ví dụ về kết quả đầu ra để diễn đạt các tuyên bố phản ánh những thay đổi thực tế trong một lần chỉnh sửa Wikipedia. Mô hình BART-base được huấn luyện trên dữ liệu VITAMINC, trong khi GPT-3 được áp dụng trong trường hợp 2-shot với nhiệt độ 0 hoặc 0,7 (xem Phụ lục C). Lần chỉnh sửa (s_{t-1}, s_t) được đưa cho mô hình dưới dạng một câu duy nhất, nơi các chỉnh sửa nằm giữa các dấu ngoặc nhọn. Tuyên bố được viết bởi con người được cung cấp để tham khảo. Cột cuối cùng bên phải chứa dự đoán của mô hình ALBERT-xlarge $f_{\text{verdict}}(c, s_t)$ của chúng tôi (được huấn luyện trên VITAMINC) khi sử dụng tuyên bố được sinh ra.

chúng tôi cũng khám phá cách GPT-3 xử lý nhiệm vụ này (chúng tôi cung cấp hai minh họa trong phần prompt). So với mô hình BART được huấn luyện trên VITAMINC, GPT-3 dường như tạo ra nhiều thông tin không nhất quán về mặt thực tế hoặc không được hỗ trợ hơn (xem Phụ lục C để biết thêm chi tiết). một cách khích lệ, bộ phân loại f_{verdict} của chúng tôi vẫn có thể nhận ra điều này — như được minh họa bởi các dự đoán ở cột ngoài cùng bên phải của Bảng 7. Ví dụ, phân loại báo cáo về khoảng 20 ca tử vong là NEI vì nó không thuộc phần nguồn. Một lần nữa, điều này phục vụ để chứng minh một cách định tính hiệu quả của việc tận dụng VITAMINC.

6 Kết luận

Chúng tôi đã giới thiệu VITAMINC, một tập dữ liệu quy mô lớn để huấn luyện và đánh giá các mô hình xác minh sự thật sử dụng các ngữ cảnh đối lập. Phương pháp mới của chúng tôi trong việc tận dụng các sửa đổi thực tế trên Wikipedia đã cho phép chúng tôi tạo ra các ví dụ thách thức, trong đó một khẳng định được ghép với các ngữ cảnh có từ vựng tương tự nhưng mâu thuẫn về mặt thực tế. Kết quả của chúng tôi minh họa rằng việc huấn luyện trên VITAMINC cải thiện độ nhạy của bộ phân loại đối với những thay đổi tinh tế trong bằng chứng và tăng cường độ bền của chúng trước các ví dụ đối kháng.

Hơn nữa, chúng tôi đã đề xuất một số nhiệm vụ mới quan trọng cho việc xác minh thông tin mà VITAMINC cho phép chúng tôi thử nghiệm. Chúng tôi đã chỉ ra cách cấu trúc độc đáo "trước và sau" của tập dữ liệu giúp huấn luyện các bộ phân loại để đánh dấu các chỉnh sửa dựa trên sự thật. Ngoài ra, đối với các chỉnh sửa dựa trên sự thật, các sửa đổi tiết lộ các từ trong bằng chứng quan trọng nhất — điều này giúp giám sát các mô hình lý giải ở mức từ để cải thiện khả năng giải thích. Cuối cùng, chúng tôi đã chứng minh rằng VITAMINC có thể hỗ trợ việc tạo văn bản phù hợp với sự thật. Chúng tôi hy vọng rằng công trình này và loạt nhiệm vụ mà nó mang lại sẽ thúc đẩy và hỗ trợ lĩnh vực xác minh thông tin trong việc phát triển các mô hình đáng tin cậy có thể thích ứng với các bằng chứng thay đổi động.

Lời cảm ơn

Chúng tôi cảm ơn đội ngũ TransPerfect, Darsh J Shah và Enrico Santus về những cuộc thảo luận hữu ích, cũng như các thành viên của nhóm MIT NLP và Andreas Vlachos về phản hồi quý giá. Công trình này được hỗ trợ một phần bởi Giải thưởng Chuẩn An toàn Trực tuyến Facebook. TS được hỗ trợ một phần bởi khoản tài trợ DSO DSOCL18002. AF được hỗ trợ một phần bởi Học bổng Nghiên cứu Sau đại học NSF.

Pepa Atanasova, Jakob Grue Simonsen, Christina Li-oma, và Isabelle Augenstein. 2020. Tạo ra các giải thích kiểm chứng sự thật. Trong Kỷ yếu Hội nghị thường niên lần thứ 58 của Hiệp hội Ngôn ngữ học Máy tính, trang 7352–7364, Trực tuyến. Hiệp hội Ngôn ngữ học Máy tính.

Isabelle Augenstein, Christina Lioma, Dongsheng Wang, Lucas Chaves Lima, Casper Hansen, Christian Hansen, và Jakob Grue Simonsen. 2019. MultiFC: Một tập dữ liệu đa miền thực tế cho kiểm tra sự thật dựa trên bằng chứng của các tuyên bố. Trong Kỷ yếu Hội nghị năm 2019 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên và Hội nghị Liên hợp Quốc tế lần thứ 9 về Xử lý Ngôn ngữ Tự nhiên (EMNLP-IJCNLP), trang 4685–4697, Hồng Kông, Trung Quốc. Hiệp hội Ngôn ngữ Học Máy Tính.

Omer Benjakob và Stephen Harrison. 2019. Từ vô chính phủ đến wikiality, thiên vị rõ ràng đến viên cảnh sát tốt: Phủ sóng báo chí về hai thập kỷ đầu của Wikipedia. Wikipedia @ 20. Https://wikipedia20.pubpub.org/pub/tw83imoy.

Piotr Bojanowski, Edouard Grave, Armand Joulin, và Tomas Mikolov. 2017. Làm phong phú vectơ từ với thông tin tiểu từ. Transactions of the Association for Computational Linguistics, 5:135–146.

Samuel R. Bowman, Gabor Angeli, Christopher Potts, và Christopher D. Manning. 2015. Một tập hợp dữ liệu lớn có chú thích để học suy luận ngôn ngữ tự nhiên. Trong Kỷ yếu hội nghị năm 2015 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên, trang 632–642, Lisbon, Bồ Đào Nha. Hiệp hội Ngôn ngữ Học Tính Toán.

Ronan Le Bras, Swabha Swayamdipta, Chandra Bhagavatula, Rowan Zellers, Matthew Peters, Ashish Sabharwal, và Yejin Choi. 2020. Các bộ lọc đối kháng của thiên vị tập dữ liệu.

Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, Sandhini Agarwal, Ariel Herbert-Voss, Gretchen Krueger, Tom Henighan, Rewon Child, Aditya Ramesh, Daniel M. Ziegler, Jeffrey Wu, Clemens Winter, Christopher Hesse, Mark Chen, Eric Sigler, Mateusz Litwin, Scott Gray, Benjamin Chess, Jack Clark, Christopher Berner, Sa m Mc- Candlish, Alec Radford, Ilya Sutskever, và Dario Amodei. 2020. Mô hình ngôn ngữ là những người học ít ví dụ.

Oana-Maria Camburu, Tim Rocktäschel, Thomas Lukasiewicz và Phil Blunsom. 2018. e-snli: Suy luận ngôn ngữ tự nhiên với các giải thích bằng ngôn ngữ tự nhiên. Trong Advances in Neural Information Processing Systems, tập 31. Curran Associates, Inc.

Wenhu Chen, Hongmin Wang, Jianshu Chen, Yunkai Zhang, Hong Wang, Shiyang Li, Xiyou Zhou, và William Yang Wang. 2020. Tabfact: Một bộ dữ liệu quy mô lớn để xác minh sự thật dựa trên bảng. Trong Hội nghị Quốc tế về Học Biểu diễn.

Jacob Devlin, Ming-Wei Chang, Kenton Lee, và Kristina Toutanova. 2019. BERT: Tiền huấn luyện các biến đổi chiều sâu hai chiều cho hiểu ngôn ngữ. Trong Kỷ yếu Hội nghị 2019 của Hiệp hội Ngôn ngữ Học Tính Toán Bắc Mỹ: Công nghệ Ngôn ngữ Con người, Tập 1 (Bài báo dài và ngắn), trang 4171–4186, Minneapolis, Minnesota. Hiệp hội Ngôn ngữ Học Tính Toán.

Jay DeYoung, Sarthak Jain, Nazneen Fatema Rajani, Eric Lehman, Caiming Xiong, Richard Socher, và Byron C. Wallace. 2020. ERASER: Một chuẩn đánh giá để đánh giá các mô hình NLP có lý giải. Trong Kỷ yếu của Hội nghị thường niên lần thứ 58 của Hiệp hội Ngôn ngữ học Máy tính, trang 4443–4458, Trực t uyến. Hiệp hội Ngôn ngữ học Máy tính.

Angela Fan, Aleksandra Piktus, Fabio Petroni, Guillaume Wenzek, Marzieh Saeidi, Andreas Vlachos, Antoine Bordes, và Sebastian Riedel. 2020. Tạo các bản tóm tắt kiểm tra sự thật. Trong Kỷ yếu Hội nghị Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên 2020 (EMNLP), trang 7147–7161, Trực tuyến. Hiệp hội Ngôn ngữ Học Máy Tính.

Manaal Faruqui, Ellie Pavlick, Ian Tenney, và Dipanjan Das. 2018. WikiAtomicEdits: Một tập dữ li ệu đa ngôn ngữ về các chỉnh sửa trên Wikipedia để mô hình hóa ngôn ngữ và diễn ngôn. Trong Kỷ yếu của Hội nghị Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên 2018, trang 305–315, Brussels, Bỉ. Hiệp hội Ngôn ngữ Học Máy Tính.

Adam Fisch, Tal Schuster, Tommi S. Jaakkola, và Regina Barzilay. 2021. Dự đoán tuân thủ hiệu quả thông qua suy luận theo cấp bậc với việc mở rộng chấp nhận. Trong Hội nghị Quốc tế về Học các Biểu diễn.

JL Fleiss. 1971. Đo lường sự đồng ý theo thang đo danh nghĩa giữa nhiều người đánh giá. Tạp chí Tâm lý học, 76(5):378—382.

Matt Gardner, Yoav Artzi, Victoria Basmov, Jonathan Berant, Ben Bogin, Sihao Chen, Pradeep Dasigi, Dheeru Dua, Yanai Elazar, Ananth Gottumukkala, Nitish Gupta, Hannaneh Hajishirzi, Gabriel Ilharco, Daniel Khashabi, Kevin Lin, Jiangming Liu, Nelson F. Liu, Phoebe Mulcaire, Qiang Ning, Sameer Singh, Noah A. Smith, Sanjay Subramanian, Reut Tsarfaty, Eric Wallace, Ally Zhang, và Ben Zhou. 2020. Đánh giá các ranh giới quyết định cục bộ của mô hình thông qua bộ đối chiếu. Trong Kết quả của Hiệp hội Ngôn ngữ học Máy tính: EMNLP 2020, các trang 1307–1323, Trực tuyến. Hiệp hội Ngôn ngữ học Máy tính.

Suchin Gururangan, Swabha Swayamdipta, Omer Levy, Roy Schwartz, Samuel Bowman, và Noah A. Smith. 2018. Các hiện vật chú thích trong dữ liệu suy diễn ngôn ngữ tự nhiên. Trong Kỷ yếu của năm 2018

Hội nghị của Chi hội Bắc Mỹ của Hiệp hội Ngôn ngữ học Máy tính: Công nghệ Ngôn ngữ Con người, Tập 2 (Bài báo ngắn), trang 107–112, New Orleans, Louisiana. Hiệp hội Ngôn ngữ học Máy tính.

Andreas Hanselowski, Hao Zhang, Zile Li, Daniil Sorokin, Benjamin Schiller, Claudia Schulz và Iryna Gurevych. 2018. UKP-athene: Suy diễn ngôn từ nhiều câu cho xác minh tuyên bố. Trong Kỷ yếu của Hội thảo lần thứ nhất về Trích xuất Sự thật và Xác minh (FEVER), trang 103–108, Brussels, Bỉ. Hiệp hội Ngôn ngữ học Máy tính.

Ari Holtzman, Jan Buys, Li Du, Maxwell Forbes, và Yejin Choi. 2020. Trường hợp kỳ lạ của sự suy thoái văn bản thần kinh. Trong Hội nghị Quốc tế về Đại diện Học Tập.

Alon Jacovi và Yoav Goldberg. 2020. Hướng tới các hệ thống NLP có thể giải thích trung thực: Chúng ta nên định nghĩa và đánh giá sự trung thực như thế nào? Trong Kỷ yếu Hội nghị thường niên lần thứ 58 của Hiệp hội Ngôn ngữ học Máy tính, trang 4198–4205, Trực tuyến. Hiệp hội Ngôn ngữ học Máy tính.

Eric Jang, Shixiang Gu, và Ben Poole. 2017. Tái tham số hóa phân loại với gumbel-softmax. Trong Hội nghị Quốc tế về Học Các Biểu Diễn.

Yichen Jiang, Shikha Bordia, Zheng Zhong, Charles Dognin, Maneesh Singh, và Mohit Bansal. 2020. HoVer: Một bộ dữ liệu cho việc trích xuất sự kiện nhiều bước và xác minh tuyên bố. Trong Kết quả của Hiệp hội Ngôn ngữ học Máy tính: EMNLP 2020, trang 3441–3460, Trực tuyến. Hiệp hội Ngôn ngữ học Máy tính.

Saehan Jo, Immanuel Trummer, Weicheng Yu, Xuezhi Wang, Cong Yu, Daniel Liu, và Niyati Mehta. 2019. Aggchecker: Hệ thống kiểm tra sự thật cho các tóm tắt văn bản của các bộ dữ liệu quan hệ. Proc. VLDB Endow., 12(12):1938–1941.

Rabeeh Karimi Mahabadi, Yonatan Belinkov, và James Henderson. 2020. Giảm thiên lệch đầu-cuối bằng cách mô hình hóa các thiên lệch trong tập hợp ngôn ngữ. Trong Kỷ yếu Hội nghị thường niên lần thứ 58 của Hiệp hội Ngôn ngữ học Máy tính, trang 8706–8716, Trực tuyến. Hiệp hội Ngôn ngữ học Máy tính.

Wojciech Kryscinski, Bryan McCann, Caiming Xiong, và Richard Socher. 2020. Đánh giá sự nhất quán thực tế của tóm tắt văn bản trừu tượng. Trong Kỷ yếu của Hội nghị 2020 về Phương pháp Cực đoán trong Xử lý Ngôn ngữ Tự nhiên (EMNLP), trang 9332–9346, Trực tuyến. Hiệp hội Ngôn ngữ Học Máy tính.

Srijan Kumar, Robert West, và Jure Leskovec. 2016. Thông tin sai lệch trên web: Tác động, đặc điểm và phát hiện các trò lừa Wikipedia. Trong WWW, trang 591–602.

Ouyu Lan, Xiao Huang, Bill Yuchen Lin, He Jiang, Liyuan Liu, và Xiang Ren. 2020. Học cách tổng hợp có ngữ cảnh giám sát từ nhiều nguồn cho việc gán nhãn chuỗi. Trong Kỷ yếu của Hội nghị Thường niên lần thứ 58 của Hiệp hội Ngôn ngữ học Máy tính, trang 2134–2146, Trực tuyến. Hiệp hội Ngôn ngữ học Máy tính. Tao Lei, Regina Barzilay, và Tommi Jaakkola. 2016. Lý giải các dự đoán của mạng nơ-ron. Trong Kỷ yếu Hội nghị Năm 2016 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên, trang 107–117, Austin, Texas. Hiệp hội Ngôn ngữ học Máy tính.

Mike Lewis, Yinhan Liu, Naman Goyal, Marjan Ghazvininejad, Abdelrahman Mohamed, Omer Levy, Veselin Stoyanov, và Luke Zettlemoyer. 2020a. BART: Huấn luyện trước chuỗi-thành-chuỗi làm sạch nhiễu cho sinh ngôn ngữ tự nhiên, dịch thuật, và hiểu biết. Trong Kỷ yếu Hội nghị Thường niên lần thứ 58 của Hiệp hội Ngôn ngữ học Máy tính, trang 7871–7880, Trực tuyến. Hiệp hội Ngôn ngữ học Máy tính.

Patrick Lewis, Ethan Perez, Aleksandara Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen tau Yih, Tim Rocktäschel, Sebastian Riedel, và Douwe Kiela. 2020b. Tạo sinh được tăng cường truy xuất cho các nhiệm vụ NLP đòi hỏi nhiều kiến thức.

Tom McCoy, Ellie Pavlick và Tal Linzen. 2019. Đúng vì lý do sai: Chẩn đoán các mẹo cú pháp trong suy luận ngôn ngữ tự nhiên. Trong Kỷ yếu Hội nghị thường niên lần thứ 57 của Hiệp hội Ngôn ngữ học Máy tính, trang 3428–3448, Florence, Ý. Hiệp hội Ngôn ngữ học Máy tính.

Feng Nie, Jin-Ge Yao, Jinpeng Wang, Rong Pan, và Chin-Yew Lin. 2019a. Một công thức đơn giản hướng tới việc giảm ảo giác trong hiện thực hóa bề mặt t hần kinh. Trong Kỷ yếu Hội nghị thường niên lần t hứ 57 của Hiệp hội Ngôn ngữ học Tính toán, các trang 2673–2679, Florence, Ý. Hiệp hội Ngôn ngữ học Tính toán.

Yixin Nie, Haonan Chen, và Mohit Bansal. 2019b. Kết hợp trích xuất sự kiện và xác minh với mạng đối sánh ngữ nghĩa thần kinh. Kỷ yếu Hội nghị AAAI về Trí tuệ Nhân tạo, 33(01):6859–6866.

Yixin Nie, Adina Williams, Emily Dinan, Mohit Bansal, Jason Weston, và Douwe Kiela. 2020. Adversarial NLI: Một chuẩn mực mới cho hiểu ngôn ngữ tự nhiên. Trong Kỷ yếu của Hội nghị hàng năm lần thứ 58 Hiệp hội Ngôn ngữ Học Tính Toán, trang 4885–4901, Trực tuyến. Hiệp hội Ngôn ngữ Học Tính Toán.

Kishore Papineni, Salim Roukos, Todd Ward và Wei-Jing Zhu. 2002. Bleu: một phương pháp đánh giá tự động dịch máy. Trong Kỷ yếu Hội nghị thường niên lần thứ 40 của Hiệp hội Ngôn ngữ học Tính t oán, trang 311–318, Philadelphia,

Pennsylvania, Hoa Kỳ. Hiệp hội Ngôn ngữ học Tính toán.

Ankur Parikh, Xuezhi Wang, Sebastian Gehrmann, Manaal Faruqui, Bhuwan Dhingra, Diyi Yang, và Dipanjan Das. 2020. ToTTo: Một bộ dữ liệu tạo văn bản từ bảng có kiểm soát. Trong Kỷ yếu của Hội nghị Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên 2020 (EMNLP), trang 1173–1186, Trực tuyến. Hiệp hội Ngôn ngữ Học Máy Tính.

Mithun Paul Panenghat, Sandeep Suntwal, Faiz Rafique, Rebecca Sharp, và Mihai Surdeanu. 2020. Hướng tới sự cần thiết của việc loại bỏ thành kiến trong các tập dữ liệu suy luận ngôn ngữ tự nhiên. Trong Kỷ yếu của Hội nghị Đánh giá và Tài nguyên Ngôn ngữ lần thứ 12, trang 6883–6888, Marseille, Pháp. Hiệp hội Tài nguyên Ngôn ngữ Châu Âu.

Fabio Petroni, Aleksandra Piktus, Angela Fan, Patrick Lewis, Majid Yazdani, Nicola De Cao, James Thorne, Yacine Jernite, Vassilis Plachouras, Tim Rocktäschel, và Sebastian Riedel. 2020. Kilt: một chuẩn đánh giá cho các nhiệm vụ ngôn ngữ đòi hỏi nhiều kiến thức.

Fabio Petroni, Tim Rocktäschel, Sebastian Riedel, Patrick Lewis, Anton Bakhtin, Yuxiang Wu, và Alexander Miller. 2019. Các mô hình ngôn ngữ như các cơ sở tri thức? Trong Kỷ yếu Hội nghị năm 2019 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên và Hội nghị Liên hợp Quốc tế lần thứ 9 về Xử lý Ngôn ngữ Tự nhiên (EMNLP-IJCNLP), trang 2463–2473, Hồng Kông, Trung Quốc. Hiệp hội Ngôn ngữ học Máy tính.

Adam Poliak, Jason Naradowsky, Aparajita Haldar, Rachel Rudinger và Benjamin Van Durme. 2018. Các đường cơ sở chỉ dựa trên giả thuyết trong suy luận ngôn ngữ tự nhiên. Trong Kỷ yếu Hội nghị Liên hợp lần thứ bảy về Ngữ nghĩa Từ vựng và Tính toán, trang 180–191, New Orleans, Louisiana. Hiệp hội Ngôn ngữ Học Tính toán.

Kashyap Popat, Subhabrata Mukherjee, Andrew Yates, và Gerhard Weikum. 2018. DeClarE: Phá vỡ ti n giả và các tuyên bố sai bằng cách sử dụng học sâu nhận thức bằng chứng. Trong Kỷ yếu của Hội nghị 2018 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên, trang 22–32, Brussels, Bỉ. Hiệp hội Ngôn ngữ Học Máy Tính.

Beatrice Portelli, Jason Zhao, Tal Schuster, Giuseppe Serra, và Enrico Santus. 2020. Chưng cất bằng chứng để tăng cường các mô hình xác minh sự thật. Trong Kỷ yếu của Hội thảo Thứ ba về Trích xuất và Xác minh Sự thật (FEVER), trang 47–51, Trực tuyến. Hiệp hội Ngôn ngữ học Máy tính.

Adithya Pratapa, Sai Muralidhar Jayanthi, và Kavya Nerella. 2020. Xác minh sự thật có ràng buộc cho FEVER. Trong Kỷ yếu Hội nghị năm 2020 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên (EMNLP), trang 7826–7832, Trực tuyến. Hiệp hội Ngôn ngữ Học Máy Tính.

Colin Raffel, Noam Shazeer, Adam Roberts, Katherine Lee, Sharan Narang, Michael Matena, Yanqi Zhou, W. Li, và Peter J. Liu. 2020. Khám phá giới hạn của học chuyển giao với một bộ biến đổi văn bản-thành-văn bản thống nhất. J. Mach. Learn. Res., 21:140:1–140:67.

MarcoTulio Ribeiro, Tongshuang Wu, Carlos Guestrin, và Sameer Singh. 2020. Vượt ra ngoài độ chính xác: Kiểm tra hành vi của các mô hình NLP với CheckList. Trong Kỷ yếu Hội nghị thường niên lần thứ 58 của Hiệp hội Ngôn ngữ học Máy tính, trang 4902–4912, Trực tuyến. Hiệp hội Ngôn ngữ học Máy tính.

AdamRoberts, Colin Raffel và Noam Shazeer. 2020. Bạn có thể nhồi nhét bao nhiêu kiến thức vào các tham số của một mô hình ngôn ngữ? Trong Kỷ yếu Hội nghị 2020 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên (EMNLP), trang 5418–5426, Trực tuyến. Hiệp hội Ngôn ngữ Học Máy tính.

Kevin Roitero, Michael Soprano, Beatrice Portelli, Damiano Spina, Vincenzo Della Mea, Giuseppe Serra, Stefano Mizzaro, và Gianluca Demartini. 2020. Cuộc khủng hoảng thông tin covid-19: Liệu đám đông có thể đánh giá thông tin sai lệch gần đây một cách khách quan? CIKM '20, trang 1305–1314, New York, NY, Mỹ. Hiệp hội Máy tính.

Alexis Ross, Ana Marasović, và Matthew E. Peters. 2020. Giải thích các mô hình xử lý ngôn ngữ tự nhiên thông qua chỉnh sửa đối lập tối thiểu (MICE).

Aalok Sathe, Salar Ather, TuanManh Le, Nathan Perry, và Joonsuk Park. 2020. Kiểm chứng tự động các tuyên bố từ Wikipedia. Trong Kỷ yếu Hội nghị Đánh giá và Tài nguyên Ngôn ngữ lần thứ 12, trang 6874–6882, Marseille, Pháp. Hiệp hội Tài nguyên Ngôn ngữ Châu Âu.

Tal Schuster, Roei Schuster, Darsh J. Shah, và Regina Barzilay. 2020. Những hạn chế của phong cách học (stylometry) trong việc phát hiện tin tức giả được tạo bởi máy. Ngôn ngữ học Máy tính, 46(2):499–510.

Tal Schuster, Darsh Shah, Yun Jie Serene Yeo, Daniel Roberto Filizzola Ortiz, Enrico Santus và Regina Barzilay. 2019. Hướng tới việc loại bỏ thiên lệch t rong các mô hình xác minh sự thật. Trong Kỷ yếu Hội nghị 2019 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên và Hội nghị Liên hợp Quốc tế lần thứ 9 về Xử lý Ngôn ngữ Tự nhiên (EMNLP-IJCNLP), trang 3419–3425, Hồng Kông, Trung Quốc. Hiệp hội Ngôn ngữ Học Máy tính.

Thibault Sellam, Dipanjan Das và Ankur Parikh. 2020. BLEURT: Học các chỉ số mạnh mẽ cho tạo văn bản. Trong Kỷ yếu Hội nghị thường niên lần thứ 58 của Hiệp hội Ngôn ngữ học Máy tính, trang 7881–7892, Trực tuyến. Hiệp hội Ngôn ngữ học Máy tính.

Darsh J Shah, Tal Schuster, và Regina Barzilay. 2020. Tự động chỉnh sửa câu theo hướng dẫn thực tế. Trong Hiệp hội Thúc đẩy Trí tuệ Nhân tạo (AAAI).

James Thorne và Andreas Vlachos. 2018. Kiểm tra sự thật tự động: Các công thức nhiệm vụ, phương pháp và hướng đi tương lai. Trong Kỷ yếu Hội nghị Quốc tế lần thứ 27 về Ngôn ngữ học Máy tính, trang 3346–3359, Santa Fe, New Mexico, Hoa Kỳ. Hiệp hội Ngôn ngữ học Máy tính.

James Thorne và Andreas Vlachos. 2020. Tránh quên dữ dội trong việc giảm thiểu thiên vị mô hình trong phân loại cặp câu với việc hoán tịnh trọng số đàn hồi.

James Thorne, Andreas Vlachos, Christos Christodoulopoulos, và Arpit Mittal. 2018. FEVER: một bộ dữ liệu quy mô lớn cho việc trích xuất và xác minh sự thật. Trong Kỷ yếu Hội nghị 2018 của Chương Bắc Mỹ Hiệp hội Ngôn ngữ học Máy tính: Công nghệ Ngôn ngữ Con người, Tập 1 (Bài báo Dài), trang 809–819, New Orleans, Louisiana. Hiệp hội Ngôn ngữ học Máy tính.

James Thorne, Andreas Vlachos, Christos Christodoulopoulos và Arpit Mittal. 2019a. Đánh giá các cuộc tấn công đối kháng chống lại nhiều hệ t hống xác minh sự thật. Trong Kỷ yếu của Hội nghị 2019 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên và Hội nghị Liên hợp Quốc tế lần thứ 9 về Xử lý Ngôn ngữ Tự nhiên (EMNLP-IJCNLP), các trang 2944–2953, Hồng Kông, Trung Quốc. Hiệp hội Ngôn ngữ Học Máy Tính.

James Thorne, Andreas Vlachos, Christos Christodoulopoulos, và Arpit Mittal. 2019b. Tạo giải thích mức token cho suy luận ngôn ngữ tự nhiên. Trong Kỷ yếu Hội nghị năm 2019 của Chương Bắc Mỹ thuộc Hiệp hội Ngôn ngữ học Máy tính: Công nghệ Ngôn ngữ Con người, Tập 1 (Bài báo Dài và Ngắn), các trang 963–969, Minneapolis, Minnesota. Hiệp hội Ngôn ngữ học Máy tính.

James Thorne, Andreas Vlachos, Oana Cocarascu, Christos Christodoulopoulos, và Arpit Mittal. 2019c. Nhiệm vụ chia sẻ FEVER2.0. Trong Kỷ yếu của Hội thảo thứ hai về Trích xuất và Xác minh Thực tế (FEVER), trang 1–6, Hồng Kông, Trung Quốc. Hiệp hội Ngôn ngữ Học Tính toán.

Ran Tian, Shashi Narayan, Thibault Sellam và Ankur P. Parikh. 2020. Bám sát sự thật: Giải mã tự tin để tạo dữ liệu-thành-văn bản trung thực.

Masatoshi Tsuchiya. 2018. Tác động hiệu suất gây ra bởi sự thiên vị ẩn trong dữ liệu huấn luyện để nhận dạng suy diễn văn bản. Trong Kỷ yếu Hội nghị Quốc tế lần thứ Mười Một về Tài nguyên Ngôn ngữ và Đánh giá (LREC 2018), Miyazaki, Nhật Bản. Hiệp hội Tài nguyên Ngôn ngữ Châu Âu (ELRA).

Prasetya Ajie Utama, Nafise Sadat Moosavi, và Iryna Gurevych. 2020a. Lưu ý đến sự đánh đổi: Loại bỏ thiên kiến trong các mô hình NLU mà không làm giảm hiệu suất trong phân phối. Trong Kỷ yếu Hội nghị thường niên lần thứ 58 Hội nghị Hiệp hội Ngôn ngữ học Máy tính, trang 8717–8729, Trực tuyến. Hiệp hội Ngôn ngữ học Máy tính.

Prasetya Ajie Utama, Nafise Sadat Moosavi, và Iryna Gurevych. 2020b. Hướng tới việc loại bỏ thiên vị khỏi các mô hình NLU từ những thiên vị chưa biết. Trong Kỷ yếu Hội nghị Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên 2020 (EMNLP), trang 7597–7610, Trực tuyến. Hiệp hội Ngôn ngữ Tính toán.

Eric Wallace, Shi Feng, Nikhil Kandpal, Matt Gardner, và Sameer Singh. 2019. Các kích hoạt đối kháng phổ quát để tấn công và phân tích NLP. Trong Kỷ yếu Hội nghị 2019 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên và Hội nghị Liên hợp Quốc tế lần thứ 9 về Xử lý Ngôn ngữ Tự nhiên (EMNLP-IJCNLP), trang 2153–2162, Hồng Kông, Trung Quốc. Hiệp hội Ngôn ngữ Học Tính toán.

William Yang Wang. 2017. “Kẻ nói dối, kẻ nói dối quần đang cháy”: Một bộ dữ liệu chuẩn mới cho phát hiện tin giả. Trong Kỷ yếu cuộc họp thường niên lần thứ 55 của Hiệp hội Ngôn ngữ học Máy tính (Tập 2: Bài báo ngắn), trang 422–426, Vancouver, Canada. Hiệp hội Ngôn ngữ học Máy tính.

Adina Williams, Nikita Nangia, và Samuel Bowman. 2018. Một tập hợp thách thức bao quát cho việc hiểu câu thông qua suy luận. Trong Kỷ yếu Hội nghị 2018 của Chương Bắc Mỹ thuộc Hiệp hội Ngôn ngữ học Máy tính: Công nghệ Ngôn ngữ Con người, Tập 1 (Bài dài), các trang 1112–1122, New Orleans, Louisiana. Hiệp hội Ngôn ngữ học Máy tính.

Thomas Wolf, Lysandre Debut, Victor Sanh, Julien Chaumond, Clement Delangue, Anthony Moi, Pierric Cistac, Tim Rault, Rémi Louf, Morgan Funtowicz, Joe Davison, Sam Shleifer, Patrick von Platen, Clara Ma, Yacine Jernite, Julien Plu, Canwen Xu, Teven Le Scao, Sylvain Gugger, Mariama Drame, Quentin Lhoest, và Alexander M. Rush. 2019. Huggingface’s transformers: Xử lý ngôn ngữ tự nhiên tiên tiến nhất. ArXiv, abs/1910.03771.

Wei Xu, Courtney Napoles, Ellie Pavlick, Quanze Chen, và Chris Callison-Burch. 2016. Tối ưu hóa dịch máy thống kê cho việc đơn giản hóa văn bản. Transactions of the Association for Computational Linguistics, 4:401–415.

Diyi Yang, Aaron Halfaker, Robert Kraut và Eduard Hovy. 2017. Xác định ý định chỉnh sửa ngữ nghĩa từ các sửa đổi trong Wikipedia. Trong Kỷ yếu Hội nghị Phương pháp Thực nghiệm về Xử lý Ngôn ngữ Tự nhiên 2017, các trang 2000–2010, Copenhagen, Đan Mạch. Hiệp hội Ngôn ngữ Học Tính Toán.

Takuma Yoneda, Jeff Mitchell, Johannes Welbl, Pontus Stenetorp, và Sebastian Riedel. 2018. Nhóm đọc máy UCL: Khung bốn yếu tố cho sự thật

finding (HexaF). Trong Kỷ yếu của Hội thảo đầu tiên về Trích xuất và Xác minh Thực tế (FEVER), trang 97–102, Brussels, Bỉ. Hiệp hội Ngôn ngữ Học Máy.

Yuan Zhang, Jason Baldridge, và Luheng He. 2019. PAWS: Đối thủ paraphrase từ việc xáo trộn từ. Trong Kỷ yếu của Hội nghị 2019 của Chi nhánh Bắc Mỹ thuộc Hiệp hội Ngôn ngữ học Máy tính: Công nghệ Ngôn ngữ Con người, Tập 1 (Bài dài và bài ngắn), trang 1298–1308, Minneapolis, Minnesota. Hiệp hội Ngôn ngữ học Máy tính.

Chunting Zhou, Jiatao Gu, Mona Diab, Paco Guzman, Luke Zettlemoyer, và Marjan Ghazvininejad. 2020. Phát hiện nội dung ảo tưởng trong sinh chuỗi thần kinh có điều kiện.

A VITAMINC: Chi tiết bổ sung

Chúng tôi cung cấp thêm chi tiết về bộ dữ liệu VITAMINC.

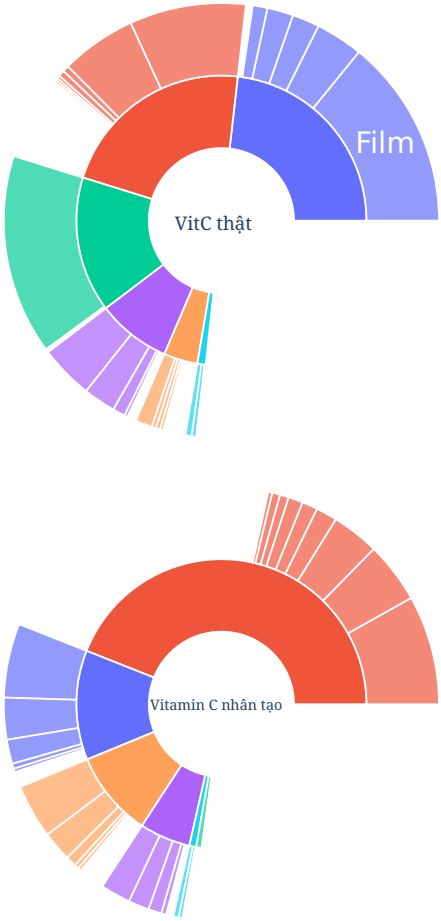
A.1 Thống kê yêu cầu

Phân bố Chủ đề. Hình A.1 cho thấy phân bố các tuyên bố trong bộ dữ liệu VITAMINC theo chủ đề của bài viết Wikipedia mà chúng dựa trên. Thông tin được thu thập từ DBpedia,[12]truy xuất lớp cha của các trang. Nhãn cho khoảng 25% các bài viết bị thiếu và được để trống trong sơ đồ.

Phần "tổng hợp" của VITAMINC, dựa trên các tuyên bố của bộ dữ liệu FEVER, chứa nhiều tuyên bố về các thực thể con người cụ thể. Khoảng 15% các tuyên bố trong VITAMINC thực sự liên quan đến COVID-19.

Phân bố theo danh mục. Chúng tôi lấy mẫu 100 ví dụ từ các tập con "thực" và "nhân tạo" của VITAMINC và phân loại các tuyên bố của chúng theo cách thủ công. Kết quả được trình bày t rong Bảng A.1. Do phương pháp tạo ra VITAMINC thực, các tuyên bố của nó chủ yếu mô tả các sự kiện thường xuyên được cập nhật, hoặc các sự kiện có xu hướng được sửa đổi. Chúng tôi nhận thấy khoảng một nửa các tuyên bố này mô tả sự thay đổi về giá trị số (ví dụ: số ca COVID-19, doanh thu hoặc xếp hạng phim, số giải thưởng, v.v.). Ngược lại, VITAMINC nhân tạo chủ yếu bao gồm các sự kiện tổng quát về các thực thể cụ thể (ví dụ: nơi sinh, ngày sinh, nghề nghiệp, v.v.). Điều này là kết quả của việc các tuyên bố nhân tạo dựa trên bộ dữ liệu FEVER, nơi các người gán nhãn được yêu cầu tạo ra các tuyên bố về các trang Wikipedia phổ biến. Tổng thể, bộ dữ liệu VITAMINC chứa một tập hợp đa dạng các tuyên bố về nhiều chủ đề khác nhau.

[12]http://dbpedia.org/ontology/



Hình A.1: Phân bố các tuyên bố trong tập dữ liệu VITAMINC theo chủ đề của bài viết Wikipedia gốc.

A.2 Thỏa thuận giữa các người chú thích

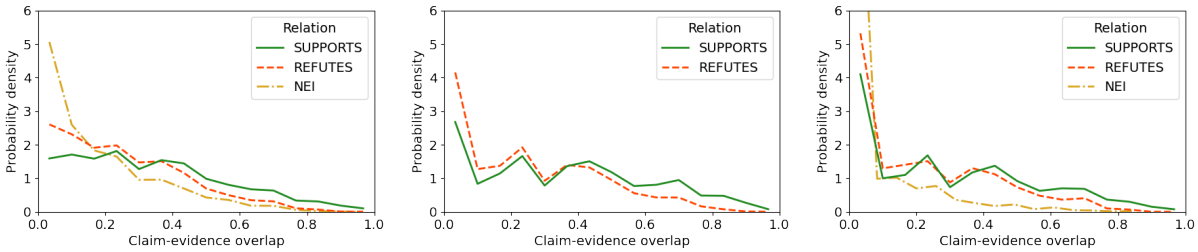
Chúng tôi yêu cầu ba người chú thích bổ sung để độc lập chú thích một tập hợp ngẫu nhiên gồm hai nghìn cặp khẳng định - bằng chứng, phân bổ đều giữa các phân tách phát triển và kiểm tra của các bộ dữ liệu thực và tổng hợp. Điểm Fleiss κ (Fleiss, 1971) giữa bốn chú thích là 0,7065, có nghĩa là có sự đồng thuận đáng kể. Các điểm đồng thuận tương tự là 0,6841 và 0,7 đã được báo cáo cho việc xác minh sự thật (Thorne et al., 2018) và các bộ dữ liệu NLI (Bowman et al., 2015), tương ứng.

A.3 Phân loại chỉ dựa trên tuyên bố

Các hiện vật chú thích là phổ biến trong các bộ dữ liệu suy luận cặp câu dựa trên đám đông như xác minh sự thật và NLI. Các mô hình có t hể tận dụng những đặc điểm kỳ quặc này để đạt hiệu suất cao bất ngờ khi chỉ được cung cấp một câu trong cặp. Ví dụ, Schuster và cộng sự (2019) đã chỉ ra rằng một bộ phân loại chỉ dựa trên tuyên bố có thể đạt độ chính xác 61,7%. Bộ dữ liệu VITAMINC tránh thiên lệch này bằng cách ghép mỗi tuyên bố với hai bối cảnh đối lập.

Loại yêu cầu	real	tổng hợp	Ví dụ
Định lượng	48%	9%	Tác nhân gây bệnh COVID-19 có thể tồn tại dưới 10 ngày trên một số bề mặt.
Liên quan đến lịch	9%	15%	Italy đã vượt qua 10.000 ca tử vong liên quan đến coronavirus vào một ngày thứ Bảy.
Thực thể	23%	58%	Mary của Teck là hoàng hậu.
Sự kiện	14%	14%	Trong trận EFL Cup gần đây, Manchester đã đánh bại Chelsea.
Khác	6%	4%	Hầu hết các gen cần được nghiên cứu thêm để hiểu rõ hơn về chức năng của các sản phẩm RNA của chúng.

Bảng A.1: Phân phối ước tính các yêu cầu trong VITAMINC, dựa trên các chú thích thủ công của 100 yêu cầu được chọn ngẫu nhiên từ phần phát triển của các tập con thực và nhân tạo. Một ví dụ về yêu cầu từ mỗi loại được cung cấp để tham khảo.



(a) VITAMINC thật (b) VITAMINC tổng hợp (c) SỐT

Hình A.2: Hàm mật độ xác suất của sự chồng chéo giữa lập luận và bằng chứng cho các nhãn khác nhau trong tập dữ liệu. Sự chồng chéo được tính toán như tỉ lệ các cặp từ hai từ chung trong hai câu.

Tất cả các tuyên bố trong VITAMINC-tổng hợp đều được ghép với một bằng chứng phản bác và một bằng chứng ủng hộ, khiến cho một mô hình c hỉ dựa vào tuyên bố không thể hoạt động tốt hơn ngẫu nhiên. Mỗi tuyên bố trong VITAMINC-thực tế được ghép với một bằng chứng phản bác hoặc t rung lập, bên cạnh một bằng chứng ủng hộ. Để đánh giá liệu các mô hình có thể sử dụng gợi ý từ vựng trong các tuyên bố hay không, chúng tôi huấn luyện một bộ phân loại chỉ dựa trên tuyên bố trên VITAMINC-thực tế và nhận thấy nó đạt độ chính xác 50%—tương đương với việc luôn dự đoán SUP.

A.4 Chứng cứ-điểm trùng từ

Tự nhiên, khi ghép các câu khẳng định với các câu bằng chứng, các từ trùng lặp sẽ cao hơn trung bình đối với các khẳng định cùng bằng chứng hỗ trợ của chúng. Trong bộ dữ liệu VITAMINC, chúng tôi muốn giảm thiểu sự thiên lệch này để tạo ra các ví dụ thử thách, đòi hỏi suy luận theo cặp câu và không thể giải quyết chỉ bằng các kỹ thuật so khớp từ đơn giản. Do đó, chúng tôi đã yêu cầu các người chú thích, khi có thể, tránh sao chép chính xác các cụm từ từ bằng chứng sang khẳng định (xem §3.2).

Hình A.2 cho thấy hàm mật độ xác suất của các sự chồng lấp bigram giữa luận điểm và bằng chứng đối với từng quan hệ. Tương tự như FEVER, tỷ lệ chồng lấp của các cặp chứng thực trong bộ dữ liệu VITAMINC chỉ cao hơn một chút so với các cặp phản bác. Ngoài ra, tỷ lệ chồng lấp của các cặp NEI trong bộ dữ liệu thực VITAMINC trung bình cao hơn FEVER.

B Thiết lập Thí nghiệm

Chúng tôi triển khai tất cả các mô hình của mình bằng thư viện Hugging-Face Transfor mers (Wolf và cộng sự, 2019). Khi so sánh giữa các tập dữ liệu huấn luyện có kích thước khác nhau, chúng tôi huấn luyện mô hình với cùng số bước cập nhật, tăng tần suất mẫu của các tập dữ liệu nhỏ hơn. Chúng tôi chọn điểm kiểm tra có độ chính xác cao nhất trên tập phát triển của nhiệm vụ huấn luyện và báo cáo hiệu suất trên tập kiểm tra. Thêm chi tiết có tại https://github.com/TalSchuster/VitaminC

Đánh giá C GPT-3

Mô hình GPT-3 gần đây đã thể hiện kết quả ấn tượng trong các nhiệm vụ sinh và phân loại zero-shot và few-shot (Brown và cộng sự, 2020). Mô hình ngôn ngữ 175 tỷ tham số này được huấn luyện trên hàng tỷ từ từ các nguồn trực tuyến, bao gồm Wikipedia tiếng Anh. Do đó, nó có thể được áp dụng cho nhiều nhiệm vụ mà không cần tinh chỉnh thêm—thay vào đó, chỉ cần cung cấp một tiền tố cụ thể cho nhiệm vụ (tức là “prompt”) với một vài ví dụ hướng dẫn mô hình ngôn ngữ về định dạng đầu ra mong muốn. Ví dụ, GPT-3 đạt được kết quả tốt hơn ngẫu nhiên trên ANLI chỉ với một ví dụ trong prompt, và đạt độ chính xác hơn 40% với 50 ví dụ (Brown và cộng sự, 2020).

Chúng tôi đã sử dụng API thử nghiệm của OpenAI để truy vấn GPT-3. Do hạn mức có giới hạn, chúng tôi không thể thực hiện

các thí nghiệm mở rộng. Thay vào đó, chúng tôi đã thực hiện một đánh giá định tính sử dụng một số ví dụ từ bộ kiểm tra VITAMINC cho việc trích xuất tuyên bố (tạo ra nhất quán về mặt thực tế) và các nhiệm vụ xác minh sự thật. Do đó, những kết quả này chỉ nên được xem là mang tính khám phá.

GPT-3 cho Việc Trích Xuất Khẳng Định. Chúng tôi nghiên cứu một thiết lập hai ví dụ cho nhiệm vụ trích xuất khẳng định. Mô hình được yêu cầu chuyển một bản sửa đổi thành một khẳng định ngắn diễn đạt sự thật đúng sau khi chỉnh sửa. Để hướng dẫn mô hình cho nhiệm vụ này, chúng tôi cung cấp một prompt với hai ví dụ ngẫu nhiên từ bộ dữ liệu huấn luyện VI-TAMINC (xem Hình C.1). Một trong những mối quan tâm chính liên quan đến các mô hình ngôn ngữ lớn là việc kiểm soát hạn chế mà chúng cho phép để đảm bảo rằng các sự thật trong đầu ra được sinh ra phù hợp với nguồn (Schuster và cộng sự, 2020). Các nhiệm vụ sinh dữ liệu của VITAMINC cung cấp một môi trường thử nghiệm hữu ích để đánh giá tính nhất quán thực tế với đầu vào. Quan trọng, các bộ phân loại xác minh sự thật được huấn luyện từ VITAMINC của chúng tôi (f_{verdict}) cho phép đánh giá tự động mạnh mẽ về sự phù hợp thực tế của các sinh dữ liệu với nguồn.

Chúng tôi sử dụng GPT-3 để trích xuất các tuyên bố cho bốn bản chỉnh sửa với giá trị nhiệt độ mẫu ($\mathcal{T}$) được đặt là 0 hoặc 0,7. Giá trị bằng không được khuyến nghị để tối đa hóa tính nhất quán về mặt thực tế vì mô hình sẽ theo các dự đoán chắc chắn nhất của nó. Tuy nhiên, việc sử dụng nhiệt độ thấp có thể dẫn đến các kết quả tạo ra kém trôi chảy hơn (Holtzman et al., 2020). Do đó, các giá trị cao của $\mathcal{T}$ cũng thường được sử dụng.

Kết quả được báo cáo trong Bảng 7 và E.3. Chỉ với hai ví dụ hướng dẫn, GPT-3 có thể làm theo định dạng mong muốn và tạo ra một tuyên bố ngắn. Tuy nhiên, một số kết quả sinh ra của nó theo s_{t-1} thay vì s_t hoặc thêm các thông tin mới không được hỗ trợ. f_{verdict} cung cấp một chỉ dẫn về độ chính xác thực tế của đầu ra. Ví dụ, nó phân loại chính xác đầu ra của cài đặt $\mathcal{T} = 0.7$ cho ví dụ đầu tiên trong Bảng 7 là " Thông tin không đủ" vì GPT-3 đã báo cáo k hoảng 20 ca tử vong mặc dù đầu vào không đề cập đến số lượng tử vong nào.

Chúng tôi mong đợi GPT-3 sẽ cải thiện với các gợi ý dài hơn hoặc tinh chỉnh và để điều này cho các nghiên cứu trong tương lai do hạn ngạch có hạn của chúng tôi.

GPT-3 cho Xác minh Thông tin. Chúng tôi cũng thử nghiệm việc sử dụng khả năng phân loại vài ví dụ của GPT-3 cho nhiệm vụ xác minh thông tin. Chúng tôi tuân theo định dạng vài ví dụ của ANLI theo Brown và cộng sự (2020) và soạn các lời nhắc với 6 ví dụ (2 từ mỗi lớp) với các ví dụ ngẫu nhiên từ VITAMINC tập huấn luyện. Chúng tôi chỉ sử dụng các ví dụ số để đánh giá các tuyên bố số (Hình C.3), và các ví dụ hỗn hợp cho các tuyên bố khác (Hình C.2). Chúng tôi thiết lập $\mathcal{T} = 0$ như được khuyến nghị cho phân loại.

Bảng C.1 tóm tắt các kết quả. Ngay cả với chỉ sáu ví dụ, GPT-3 dường như hoạt động tốt hơn đáng kể so với ngẫu nhiên. Tuy nhiên, kết luận của nó s ai trong một số trường hợp mà con người có thể dễ dàng phân loại. Ví dụ, chúng tôi nhận thấy nó tr ánh dự đoán một kết luận Đúng/Sai ngay cả khi bằng chứng rõ ràng. Chúng tôi quan sát điều này cả với các tuyên bố dựa trên ngày tháng (dòng 3.2 trong Bảng C.1), số liệu (dòng 4.1-4.2), và các tuyên bố tập trung vào thực thể (dòng 5.2).

Để thử nghiệm độ nhạy của mô hình đối với bối cảnh được cung cấp, chúng tôi đã tự tay chỉnh sửa một số ví dụ để cung cấp bằng chứng mạnh mẽ hơn. Ví dụ, trong khi dự đoán của GPT-3 cho dòng 5.2 là chấp nhận được vì thực tế, Turner Broadcasting System đã sáp nhập với WarnerMedia vào năm 1996, việc thay đổi bằng chứng sang một thực thể khác không liên quan (The Walt Disney Company) không làm thay đổi dự đoán (dòng 5.3) như mong đợi. Ngay cả khi nêu rõ rằng không có chủ sở hữu khác, GPT-3 vẫn không thay đổi phán quyết của mình (dòng 5.4). Tương tự, khi đánh giá tuyên bố về dân số của Beaverton là dưới 90K, GPT-3 bỏ qua bằng chứng hỗ trợ và đưa ra phán quyết sai (dòng 1.4-1.5). Việc thay đổi tuyên bố thành "khoảng 86K" thay vì "dưới 90.000" đã làm thay đổi dự đoán thành "Không ai cả" (dòng 1.6). Chỉ khi lặp lại chính xác cùng một con số như bằng chứng mới dẫn đến kết quả đúng (dòng 1.7).

D Thí nghiệm bổ sung

Chúng tôi báo cáo kết quả xác minh sự thật với mô hình BERT-base được tinh chỉnh (Devlin và cộng s ự, 2019) trong Bảng D.1. Chúng tôi nhận thấy ALBERT-base vượt trội hơn BERT-base trên hầu hết các tập dữ liệu được đánh giá. ALBERT-xlarge hoạt động tốt hơn hai mô hình cơ bản trên tất cả các tập dữ liệu ngoại trừ Triggers. Tập dữ liệu Triggers rất nhỏ (186 ví dụ) và chứa một số tuyên bố có vẻ phi tự nhiên, điều này có thể giải thích sự biến động cao giữa các mô hình.

E Ví dụ đầu ra

Chúng tôi cung cấp các ví dụ về các lý do dự đoán ở cấp độ từ trong Bảng E.1 và các kết quả cho hai nhiệm vụ tạo trong Bảng E.2 và E.3.

Cuộc Sống Thật Tuyệt Vời: Cuộc Sống Thật Tuyệt Vời là {*| album studio đầu tiên -> thứ hai |} của ban nhạc nu metal người Mỹ Korn, được phát hành vào ngày 15 tháng 10 năm 1996 thông qua cả Immortal Records và Epic Records. Khẳng định: Cuộc Sống Thật Tuyệt Vời là album studio thứ hai của Korn. ### Đại dịch coronavirus 2020 tại Kerala: Tính đến ngày 14 tháng 3 năm 2020, có {*| 19-> 22|} ca nhiễm virus được xác nhận và hơn 4000 người đang được giám sát tại Kerala. Khẳng định: Tính đến ngày 14 tháng 3, đã có hơn 20 ca COVID-19 được xác nhận tại Kerala. ###<Chỉnh sửa trực quan>Khẳng định: <dự đoán>

Hình C.1: Lời nhắc được sử dụng cho việc trích xuất tuyên bố theo phương pháp few-shot của GPT-3.

Manchester là một thành phố lớn và quận đô thị tại Greater Manchester, Anh, với dân số 545.500 vào năm 2017 (quận đông dân đứng thứ 5 của Anh). Câu hỏi: Manchester có dân số hơn 540.000 vào năm 2017 và là quận đông dân đứng t hứ 5 ở Anh. Đúng, Sai, hay Không cái nào? Đúng ### Tính đến tháng 3 năm 2018, các ứng dụng đã đạt hơn 8 tỷ lượt tải xuống. Câu hỏi: Ứng dụng Talking Tom and Friends có ít hơn 8 tỷ lượt tải xuống. Đúng, Sai, hay Không cái nào? Sai ### Anh ấy đã giành Premier League vào năm 2018. John Stones đã giành cả Premier League và EFL Cup vào năm 2018. Đúng, Sai, hay Không cái nào? Không cái nào ### Neck Deep là một ban nhạc emo. Câu hỏi: Neck Deep là một ban nhạc emo. Đúng, Sai, hay Không cái nào? Đúng ### Các nhà phê bình thường đánh giá The Final Frontier với nhận xét từ trung bình đến kém. Câu hỏi: Bộ phim Star Trek V: The Final Frontier chỉ nhận được nhận xét tiêu cực. Đúng, Sai, hay Không cái nào? Sai ### Loạt phim này được so sánh tích cực với loạt phim HBO The Jinx và podcast Serial. Câu hỏi: The fo

Hình C.2: Lời nhắc được sử dụng cho các dự đoán xác minh sự thật theo phương pháp few-shot của GPT-3 trên các tuyên bố phi số học (ví dụ 2 và 4 trong Bảng C.1. Chúng tôi theo thiết lập few-shot của Brown et al. (2020) cho ANLI.

#	Yêu cầu	Bằng chứng	GPT-3	Ours	Gold
1.1	**Ít hơn 90.000 người sống ở** Beaverton, Oregon	dân số của nó ước tính là 91.757, gần 14% nhiều hơn con số điều tra dân số năm 2000 là 76.129	Sai	Sai	Sai
1.2	**Hơn 90 nghìn** người sống ở Beaverton	dân số của nó ước tính là 91.757, gần 14% nhiều hơn con số điều tra dân số năm 2000 là 76.129	True	True	True
1.3	**Hơn 90 nghìn** mọi người sống ở Beaverton	dân số của nó ước tính là 86.205, gần 14% nhiều hơn con số điều tra dân số năm 2000 là 76.129	Cả hai đều không	Sai	Sai
1.4	**Ít hơn 90.000 người sống ở** Beaverton, Oregon	dân số của nó ước tính là 86.205, gần 14% nhiều hơn con số điều tra dân số năm 2000 là 76.129	Sai	True	True
1.5	**Ít hơn 90.000 người sống ở** Beaverton, Oregon	Dân số của Beaverton ước tính là **86.205**	Sai	True	True
1.6	**Khoảng 86 nghìn người sống ở** Beaverto, Oregon	Dân số của Beaverton ước tính là **86.205**	Cả hai đều không	True	True
1.7	**Khoảng 86.205 người sinh sống** tại Beaverton, Oregon	Dân số của Beaverton ước tính là **86.205**	True	True	True
2.1	Cha của Diego Corrales là người Puerto Ri- có thể và mẹ của anh ấy người Dominica	Corrales sinh ra trong một gia đình có cha là người Mỹ gốc Phi và một người mẹ người Mexico	Sai	Sai	Sai
2.2	Cha của Diego Corrales là người Puerto Ri- có thể và mẹ của anh ấy người Dominica	Corrales sinh ra với người cha gốc Puerto Rico và một Mẹ người Dominica	True	True	True
3.1	Đợt bùng phát COVID-19 đã được xác định **trước tháng mười hai**	Đợt bùng phát lần đầu tiên được xác định ở Vũ Hán , Hubei, Trung Quốc vào tháng 12 năm 2019 và nhận ra- được công nhận là một đại dịch	Sai	Sai	Sai
3.2	Đợt bùng phát COVID-19 đã được xác định **trước tháng mười hai**	Đợt bùng phát lần đầu tiên được xác định ở Vũ Hán , Hubei , Trung Quốc vào ngày 17 tháng 11 năm 2019 và rec- được công nhận là một đại dịch	Cả hai đều không	True	True
4.1	Đã có hơn 400 con- các trường hợp coronavirus được xác nhận ở Đức	Đã có 444 ca được xác nhận và 16 số ca hồi phục của virus corona ở Đức	Cả hai đều không	True	True
4.2	Đã có hơn 400 con- các trường hợp coronavirus được xác nhận ở Đức	Đã có ít hơn 349 ca được xác nhận và 16 trường hợp hồi phục coronavirus ở Đức	Cả hai đều không	Sai	Sai
5.1	Hoạt hình Mạng được sở hữu bởi **Hệ thống Phát sóng Turner**	Cartoon Network là một kênh truyền hình trả tiền của Mỹ **kênh do Hệ thống Phát sóng Turner sở hữu** tem, một công ty con của WarnerMedia thuộc AT&T	True	True	True
5.2	Hoạt hình Mạng được sở hữu bởi **Hệ thống Phát sóng Turner**	Cartoon Network là một kênh truyền hình trả tiền của Mỹ kênh sion thuộc sở hữu của Warner Bros. Enter- tainment, một công ty con của WarnerMedia thuộc AT&T	Cả hai đều không	Sai	Sai
5.3	Hoạt hình Mạng được sở hữu bởi **Hệ thống Phát sóng Turner**	Cartoon Network là một kênh truyền hình trả tiền của Mỹ **kênh do Công ty Walt Disney sở hữu**	Cả hai đều không	Sai	Sai
5.4	Hoạt hình Mạng được sở hữu bởi **Hệ thống Phát sóng Turner**	**Công ty Walt Disney là chủ sở hữu duy nhất** của Cartoon Network	Cả hai đều không	Sai	Sai

Bảng C.1: Các dự đoán xác minh sự thật của GPT-3 trên các ví dụ từ bộ dữ liệu kiểm tra VITAMINC (các ví dụ 1.5-1.7 và 5.3-5.4 đã được chỉnh sửa thủ công để kiểm tra hành vi của mô hình). Chúng tôi theo thiết lập few-shot của Brown và cộng sự (2020) cho ANLI (xem Hình C.2 và C.3). Các đoạn in đậm chỉ để trình bày và không phải là một phần của dữ liệu đầu vào. Các bộ phân loại ALBERT được huấn luyện trên VITAMINC của chúng tôi dự đoán đúng tất cả các ví dụ này (mặc dù chúng không được chọn theo cách này). GPT-3 trong thiết lập few-shot thành công ở một số ví dụ và thậ m chí thể hiện sự nhạy cảm với bằng chứng ở các dòng 2.1-2.2. Tuy nhiên, trong một số trường hợp, GPT-3 từ chối đưa ra phán quyết True/False, ngay cả khi được cung cấp bằng chứng mạnh (xem các dự đoán “Neither”). Dòng 1.4 cho thấy một ví dụ nơi phán quyết của GPT-3 trái ngược với bằng chứng được cung cấp. Chỉ khi diễn đạt lại tuyên bố sao cho hoàn toàn trùng khớp với bằng chứng, nó mới dự đoán sự đồng ý.

Manchester là một thành phố lớn và là quận đô thị ở Greater Manchester, Anh, với dân số 545.500 người tính đến năm 2017 (quận đông dân thứ 5 ở Anh). Câu hỏi: Manchester có dân số hơn 540.000 người vào năm 2017 và là quận đông dân thứ 5 ở Anh. Đúng, Sai, hay Không rõ? Đúng ### Tính đến tháng 3 năm 2018, các ứng dụng đã đạt hơn 8 tỷ lượt tải xuống. Câu hỏi: Ứng dụng Talking Tom and Friends có ít hơn 8 tỷ lượt tải xuống. Đúng, Sai, hay Không rõ? Sai ### Tính đến tháng 1 năm 2015, JFC có tổng cộng hơn 3.000 cửa hàng trên toàn thế giới, với doanh số bán lẻ toàn hệ thống đạt 82,1 tỷ peso cho năm tài chính 2011. Câu hỏi: Jollibee có tổng cộng hơn 20.000 cửa hàng trên toàn thế giới sau tháng 1 năm 2016. Đúng, Sai, hay Không rõ? Không rõ ### Tính đến tháng 3 năm 2018, các ứng dụng đã đạt hơn 8 tỷ lượt tải xuống. Câu hỏi: Ứng dụng Talking Tom and Friends có hơn 8 tỷ lượt tải xuống. Đúng, Sai, hay Không rõ? Đúng ### Bet365 có hơn 35 triệu khách hàng trên toàn cầu

Hình C.3: Lời nhắc sử dụng cho dự đoán xác minh sự thật theo vài ví dụ của GPT-3 về các khẳng định số học (ví dụ 1 và 3 trong Bảng C.1).

Mô hình	Tập dữ liệu huấn luyện	VitC thật	VitC syn	SỐT	MNLI	Đối kháng Đối xứng		Kích hoạt	ANLI	Tương phản
BERT-cơ bản	SỐT	60.55	71.35	87.16	61.90	52.09	73.60	69.89	**34.53**	54.05
	MNLI	46.31	69.01	70.06	83.80	50.13	73.88	65.05	26.88	51.92
	SỐT +MNLI	56.24	81.80	**95.59**	**85.06**	63.05	85.11	37.63	29.63	60.63
	VitC	**85.80**	90.63	74.21	66.66	**76.24**	90.17	63.98	33.19	72.49
	VitC + MNLI	84.47	**91.00**	74.88	83.70	63.05	84.55	66.13	31.00	84.88
	VitC + SỐT	84.72	89.16	87.55	69.28	64.75	**90.73**	**72.58**	34.06	84.01

Bảng D.1: Kết quả bổ sung xác minh sự thật cho Bảng 4 với mô hình BERT-base.

Yêu cầu	Kênh YouTube Chuchu TV được xếp hạng 42 và có hơn 25 triệu người đăng ký.
Bằng chứng	chuchu tv là kên[redacted]tube c[redacted]ứ 43 trên thế giới, với hơn 20 triệ[redacted]
Yêu cầu	Ramus đã bán chưa đến 4,5 triệu album trên toàn thế giới.
Bằng chứng	The Rasmus đã bán [redacted]ng tại quê nhà Phần Lan đã bán được 310.000 bản.
Yêu cầu	Darren Randolph là người Tây Ban Nha.
Bằng chứng	Humes hẹn hò cầu[redacted]g đá Ireland Darren Randolph vào năm 2005.
Yêu cầu	Astravyets gần Vilnius.
Bằng chứng	Cha của ông có thể đã di cư sang Mỹ vào những năm 1860 từ một làn[redacted]
Yêu cầu	Thanh đo thể lực điều khiển nhịp độ là một tính năng mới trong loạt trò chơi.
Bằng chứng	Mới trong l[redacted] là một thanh [redacted]điều kh[redacted]ộ củ[redacted] trận đấu.
Yêu cầu	Bộ phim sẽ được phát hành vào ngày 25 tháng 11 năm 2015.
Bằng chứng	[...] đang sản xuất bộ phim mà Columbia Pictures sẽ phát hành [redacted]

Bảng E.1: Ví dụ về các mặt nạ được tạo bởi mô hình lý giải ở cấp từ để xác định các từ mô[redacted] hứng chịu trách nhiệm cho phán quyết của bộ phân loại về tuyên bố. Việc che các từ này khiến bộ phân loại dự đoán NEI thay vì SUP hoặc REF như lẽ ra.

Yêu cầu s_{t-1}	Stephen Bruner sinh ngày 19 tháng 10 năm 1984.
	Stephen Bruner (sinh ngày 18 tháng 10 năm 1984), được biết đến nhiều hơn với nghệ danh Thundercat, là một người Mỹ người chơi bass đa thể loại, nhà sản xuất và ca sĩ từ Los Angeles, California.
Đầu ra	Stephen Bruner (sinh ngày 19 tháng 10 năm 1984), được biết đến nhiều hơn với nghệ danh Thundercat, là một người Mỹ người chơi bass đa thể loại, nhà sản xuất và ca sĩ đến từ Los Angeles, California.
s_t	Stephen Bruner (sinh ngày 19 tháng 10 năm 1984), được biết đến nhiều hơn với nghệ danh Thundercat, là một người Mỹ người chơi bass đa thể loại, nhà sản xuất và ca sĩ đến từ Los Angeles, California.
Yêu cầu s_{t-1}	Bộ phim The House that Jack Built có tỷ lệ đánh giá đồng thuận trên 45% và hơn 13 nhà phê bình.
	Trên Rotten Tomatoes, bộ phim có tỷ lệ chấp thuận 42%, dựa trên 12 nhà phê bình, và điểm đánh giá trung bình điểm 5,9/10
Đầu ra	Trên Rotten Tomatoes, bộ phim có tỷ lệ chấp thuận 47 %, dựa trên 14 nhà phê bình, và điểm đánh giá trung bình 5,9/10.
s_t	Trên Rotten Tomatoes, bộ phim có tỷ lệ chấp thuận 47%, dựa trên 15 nhà phê bình, và điểm đánh giá trung bình được 6,3/10.
Yêu cầu s_{t-1}	Cartoon Network thuộc sở hữu của Warner Bros. Entertainment.
	Cartoon Network là một kênh truyền hình trả tiền của Mỹ thuộc sở hữu của Turner Broadcasting System, một công ty con của WarnerMedia thuộc AT & T.
Đầu ra	Cartoon Network là một kênh truyền hình trả tiền của Mỹ, thuộc sở hữu của Warner Bros. Entertainment, một công ty con của WarnerMedia thuộc AT & T.
s_t	Cartoon Network là một kênh truyền hình trả tiền của Mỹ, thuộc sở hữu của Warner Bros. Entertainment, một công ty con của WarnerMedia thuộc AT & T.
Yêu cầu s_{t-1}	Tờ New York Times đã đánh giá bộ phim Mad Max: Fury Road.
	Lindsay Bahr của The Associated Press đã viết, "Miller đã nhắc nhở chúng ta rằng những bộ phim bom tấn có tiềm năng không chỉ để trở thành nghệ thuật, mà còn mang tính tiên phong – thậm chí là phần thứ tư trong một loạt.
Đầu ra	Lindsay Bahr của The New York Times đã viết, "Miller đã nhắc chúng ta rằng những bộ phim bom tấn có tiềm năng không chỉ để trở thành nghệ thuật, mà còn mang tính cách tân – thậm chí là tác phẩm thứ tư trong một loạt.
s_t	The New York Times đã viết, "Miller đã nhắc chúng ta rằng những bộ phim bom tấn có tiềm năng không chỉ để nghệ thuật, nhưng mang tầm nhìn cấp tiến – thậm chí là phần thứ tư trong một loạt.

Bảng E.2: Ví dụ về các kết quả đầu ra của BART-base được sử dụng để tạo các chỉnh sửa nhất quán về mặt thực tế dựa trên phiên bản cũ s_{t-1} và tuyên bố cập nhật mà chúng ta muốn hỗ trợ. "Sự thật nền tảng" s_t được cung cấp để tham khảo.

(s_{t-1}, s_t)	WWE 2K15: Tính đến tháng 8 năm 2015, WWE 2K15 đã được xuất xưởng hơn sáu triệu đơn vị.		
BART (VitC)	WWE 2K15 đã bán được hơn 7 triệu bản.	$f_{\text{verdict}}(c, s_t) =$	SUP
GPT-3 $\mathcal{T}$=0	Tính đến tháng 8 năm 2015, WWE 2K15 đã được xuất xưởng hơn bảy triệu đơn vị		SUP
GPT-3 $\mathcal{T}$=0.7	Tính đến tháng 8 năm 2015, WWE 2K15 đã được xuất xưởng hơn bảy triệu đơn vị		SUP
Tham khảo	Đến tháng 8 năm 2015, WWE 2K15 đã bán được hơn 7,5 triệu bản.		SUP
(s_{t-1}, s_t)	Pat Jennings: Anh ấy đã từng thi đấu cho các câu lạc bộ của Giải bóng đá Ireland UCD và Derry và hiện nay đang ở {*| Shamrock Rovers -> Dublin |}.		
BART (VitC)	Pat Jennings hiện đang chơi cho câu lạc bộ Dublin UCD Derry.		SUP
GPT-3 $\mathcal{T}$=0	Anh ấy đã chơi cho các câu lạc bộ ở Giải bóng đá Ireland UCD và hiện đang thi đấu cho Shamrock Rovers		REF
GPT-3 $\mathcal{T}$=0.7	Anh ấy đã chơi cho Shamrock Rovers và hiện đang ở Dublin		REF
Tham khảo	Pat Jennings hiện đang chơi cho câu lạc bộ Dublin.		SUP

Bảng E.3: Các ví dụ bổ sung cho Bảng 7. Các kết quả ví dụ cho việc trích xuất các tuyên bố thể hiện sự thay đổi thực tế trong một phiên bản Wikipedia. Mô hình BART-base được huấn luyện trên dữ liệu VITAMINC và GPT-3 được áp dụng trong thiết lập 2-shot với nhiệt độ 0 hoặc 0,7. Phiên bản (s_{t-1}, s_t) được cung cấp cho mô hình dưới dạng một câu trực quan duy nhất, trong đó các chỉnh sửa được đặt giữa các dấu ngoặc nhọn, đứng sau tiêu đề bài viết. Tuyên bố do con người viết được cung cấp để tham khảo. Dự đoán của mô hình ALBERT-xlarge được huấn luyện trên VITAMINC f_{verdict} (c, s_t) về tuyên bố được tạo ra đối với s_t cũng được báo cáo trong cột ngoài cùng bên phải.