Foundations and Trends® in
Information Retrieval
Vol. 3, No. 4 (2009) 333–389
© 2009 S. Robertson and H. Zaragoza
DOI: 10.1561/1500000019

Foundations and Trends® trong Truy
xuất Thông tin Tập 3, Số 4 (2009) 333–
389 c◯ 2009 S. Robertson và H.
Zaragoza DOI: 10.1561/1500000019

The Probabilistic Relevance Framework: BM25 and Beyond

By Stephen Robertson and Hugo Zaragoza

Khung Liên Quan Xác Suất: BM25 và Hơn Thế Nữa

Bởi Stephen Robertson và Hugo Zaragoza

Contents

Nội dung

1 Introduction **334**

2 Development of the Basic Model **336**

2.1 Information Needs and Queries 336
2.2 Binary Relevance 337
2.3 The Probability Ranking Principle 337
2.4 Some Notation 338
2.5 A Note on Probabilities and Rank Equivalence 345

3 Derived Models **347**

3.1 The Binary Independence Model 347
3.2 Relevance Feedback and Query Expansion 349
3.3 Blind Feedback 351
3.4 The Eliteness Model and BM25 352
3.5 Uses of BM25 360
3.6 Multiple Streams and BM25F 361
3.7 Non-Textual Relevance Features 365
3.8 Positional Information 367
3.9 Open Source Implementations of BM25 and BM25F 369

1 Giới thiệu 334

2 Phát triển Mô hình Cơ bản 336

2.1 Nhu cầu và truy vấn thông tin 336 2.2 Độ liên quan nhị phân 337 2.3 Nguyên tắc xếp hạng xác suất 337 2.4 Một số ký hiệu 338 2.5 Ghi chú về xác suất và tương đương xếp hạng 345

3 Mô Hình Phái Sinh **347**

3.1 Mô hình Độc lập Nhị phân 347 3.2 Phản hồi Liên quan và Mở rộng Truy vấn 349 3.3 Phản hồi Mù 351 3.4 Mô hình Ưu tú và BM25 352 3.5 Các ứng dụng của BM25 360

3.6 Nhiều Luồng và BM25F 361
3.7 Tính năng Liên quan Phi văn bản 365
3.8 Thông tin vị trí 367
3.9 Triển khai mã nguồn mở của BM25 và BM25F 369

4 Comparison with Other Models **371**

4.1 Maron and Kuhns 371
4.2 The Unified Model 372
4.3 The Simple Language Model 374
4.4 The Relevance (Language) Model 375
4.5 Topic Models 375
4.6 Divergence from Randomness 376

5 Parameter Optimisation **377**

5.1 Greedy Optimisation 378
5.2 Multidimensional Optimisation 380
5.3 Gradient Optimisation 382

6 Conclusions **384**

References **385**

4 So sánh với các Mô hình Khác **371**

4.1 Maron và Kuhns 371 4.2 Mô hình Thống nhất 372 4.3 Mô hình Ngôn ngữ Đơn giản 374 4.4 Mô hình Liên quan (Ngôn ngữ) 375 4.5 Mô hình Chủ đề 375 4.6 Sai khác so với Ngẫu nhiên 376

5 Tối ưu hóa tham số 377

5.1 Tối ưu tham lam 378 5.2 Tối ưu đa chiều 380 5.3 Tối ưu gradient 382

6 Kết luận 384

Tài liệu tham khảo 385

Foundations and Trends® in
Information Retrieval
Vol. 3, No. 4 (2009) 333–389
© 2009 S. Robertson and H. Zaragoza
DOI: 10.1561/1500000019

now
the essence of knowledge

The Probabilistic Relevance Framework: BM25 and Beyond

Stephen Robertson[1] and Hugo Zaragoza[2]

[1] *Microsoft Research, 7 J J Thomson Avenue, Cambridge CB3 0FB, UK ser@microsoft.com*
[2] *Yahoo! Research, Av. Diagonal 177, Barcelona 08028, Spain hugoz@yahoo-inc.com*

Abstract

The Probabilistic Relevance Framework (PRF) is a formal framework for document retrieval, grounded in work done in the 1970–1980s, which led to the development of one of the most successful text-retrieval algorithms, BM25. In recent years, research in the PRF has yielded new retrieval models capable of taking into account document meta-data (especially structure and link-graph information). Again, this has led to one of the most successful Web-search and corporate-search algorithms, BM25F. This work presents the PRF from a conceptual point of view, describing the probabilistic modelling assumptions behind the framework and the different ranking algorithms that result from its application: the binary independence model, relevance feedback models, BM25 and BM25F. It also discusses the relation between the PRF and other statistical models for IR, and covers some related topics, such as the use of non-textual features, and parameter optimisation for models with free parameters.

Foundations and Trends® trong Truy
xuất Thông tin Tập 3, Số 4 (2009) 333–389
c◯ 2009 S. Robertson và H. Zaragoza
DOI: 10.1561/1500000019

now
the essence of knowledge

Khuôn khổ Liên quan Xác suất: BM25 và hơn thế nữa

Stephen Robertson[1] và Hugo Zaragoza[2]

[1] *Microsoft Research, 7 J JThomson Avenue, Cambridge CB3 0FB, Vương quốc Anh ser@microsoft.com*[2] *Yahoo! Research, Av. Diagonal 177, Barcelona 08028, Tây Ban Nha hugoz@yahoo-inc.com*

Tóm tắt

Khung Tính Liên Quan Xác Suất (PRF) là một khung chính thức cho việc truy xuất tài liệu, dựa trên các công trình thực hiện vào những năm 1970–1980, dẫn đến sự phát triển của một trong những thuật t oán truy xuất văn bản thành công nhất, BM25. Trong những năm gần đây, nghiên cứu về PRF đã tạo ra các mô hình truy xuất mới có khả năng tính đến siêu dữ liệu của tài liệu (đặc biệt là thông tin cấu trúc và đồ thị liên kết). Một lần nữa, điều này đã dẫn đến một trong những thuật toán tìm kiếm Web và tìm kiếm doanh nghiệp thành công nhất, BM25F. Công trình này trình bày PRF từ góc nhìn khái niệm, mô tả các giả định mô hình xác suất đứng sau khung và các thuật toán xếp hạng khác nhau phát sinh từ việc áp dụng nó: mô hình độc lập nhị phân, các mô hình phản hồi liên quan, BM25 và BM25F. Nó cũng thảo luận về mối quan hệ giữa PRF và các mô hình thống kê khác cho IR, và đề cập đến một số chủ đề liên quan, chẳng hạn như việc sử dụng các đặc trưng phi văn bản, và tối ưu hóa tham số cho các mô hình có tham số tự do.

1

Introduction

This monograph addresses the *classical* probabilistic model of information retrieval. The model is characterised by including a specific notion of relevance, an explicit variable associated with a query–document pair, normally hidden in the sense of *not observable*. The model revolves around the notion of estimating a probability of relevance for each pair, and ranking documents in relation to a given query in descending order of probability of relevance. The best-known instantiation of the model is the BM25 term-weighting and document-scoring function.

The model has been developed in stages over a period of about 30 years, with a precursor in 1960. A few of the main references are as follows: [30, 44, 46, 50, 52, 53, 58]; other surveys of a range of probabilistic approaches include [14, 17]. Some more detailed references are given below.

There are a number of later developments of IR models which are also probabilistic but which differ considerably from the models developed here — specifically and notably the *language model* (LM) approach [24, 26, 33] and the *divergence from randomness* (DFR) models [2]. For this reason we refer to the family of models developed here as the *Probabilistic Relevance Framework* (PRF), emphasising the

1

Giới thiệu

Bài đơn khảo này đề cập đến mô hình xác suất kinh điển của việc truy xuất thông tin. Mô hình này đặc trưng bởi việc bao gồm một khái niệm cụ thể về sự liên quan, một biến rõ ràng liên quan đến cặp truy vấn–tài liệu, thường ẩn theo nghĩa không thể quan sát được. Mô hình xoay quanh khái niệm ước lượng xác suất liên quan cho mỗi cặp, và xếp hạng các tài liệu liên quan đến một truy vấn nhất định theo thứ t ự giảm dần của xác suất liên quan. Biểu hiện nổi tiếng nhất của mô hình là hàm tính điểm tài liệu và trọng số từ BM25.

Mô hình đã được phát triển theo các giai đoạn trong khoảng thời gian khoảng 30 năm, với một tiền thân vào năm 1960. Một vài tài liệu tham khảo chính như sau: [30, 44, 46, 50, 52, 53, 58]; các khảo sát khác về một loạt các phương pháp xác suất bao gồm [14, 17]. Một số tài liệu tham khảo chi tiết hơn được đưa ra dưới đây.

Có một số phát triển sau này của các mô hình IR cũng mang tính xác suất nhưng khác biệt đáng kể so với các mô hình được phát triển ở đây — cụ thể và đặc biệt là phương pháp mô hình ngôn ngữ (LM) [24, 26, 33] và các mô hình sai lệch so với ngẫu nhiên (DFR) [2]. Vì lý do này, chúng tôi gọi tập hợp các mô hình được phát triển ở đây là Khung Liên quan Xác suất (PRF), nhấn mạnh

importance of the relevance variable in the development of the models. We do not cover the development of other probabilistic models in the present survey, but some points of comparison are made.

This is not primarily an experimental survey; throughout, assertions will be made about techniques which are said to work well. In general such statements derive from experimental results, many experiments by many people over a long period, which will not in general be fully referenced. The emphasis is on the theoretical development of the methods, the logic and assumptions behind the models.

The survey is organised as follows. In Section 2 we develop the most generic retrieval model, which subsumes a number of specific instantiations developed in Section 3. In Section 4 we discuss the similarities and differences with other retrieval frameworks. Finally in Section 5 we give an overview of optimisation techniques we have used to tune the different parameters in the models and Section 6 concludes the survey.

tầm quan trọng của biến liên quan trong việc phát triển các mô hình. Chúng tôi không đề cập đến việc phát triển các mô hình xác suất khác trong khảo sát hiện tại, nhưng một số điểm so sánh đã được thực hiện.

Đây không chủ yếu là một khảo sát thực nghiệm; xuyên suốt, các khẳng định sẽ được đưa ra về các kỹ thuật được cho là hiệu quả. Nói chung, những tuyên bố như vậy dựa trên kết quả thực nghiệm, nhiều thí nghiệm của nhiều người trong một khoảng thời gian dài, mà nói chung sẽ không được trích dẫn đầy đủ. Trọng tâm là phát triển lý thuyết của các phương pháp, logic và các giả định đằng sau các mô hình.

Khảo sát được tổ chức như sau. Trong Phần 2, chúng tôi phát triển mô hình truy xuất tổng quát nhất, bao quát một số hiện thực cụ thể được phát triển trong Phần 3. Trong Phần 4, chúng tôi thảo luận về những điểm giống và khác với các khung truy xuất khác. Cuối cùng, trong Phần 5, chúng tôi cung cấp tổng quan về các kỹ thuật tối ưu hóa mà chúng tôi đã sử dụng để điều chỉnh các tham số khác nhau trong các mô hình và Phần 6 kết luận khảo sát.

2

Development of the Basic Model

2.1 Information Needs and Queries

We start from a notion of information need. We take a query to be a representation (not necessarily very good or very complete) of an individual user's information need or perhaps search intent. We take *relevance* to mean the relevance of a document to the information need, as judged by the user. We make no specific assumption about the conceptual nature of relevance; in particular, we do *not* assume relevance to be topical in nature.[1] We do, however, makes some assumptions about the formal status of the relevance variable, given below, which might be taken to imply some assumptions about its conceptual nature.

[1] The notion of *topic*, as used in TREC, is somewhat akin to *information need*, or at least to a more detailed and complete representation and specification of an information need. The use of the term 'topic' for this purpose is a little unfortunate, as it seems to imply some kind of topical nature of relevance. However, we also note that the widespread use of the term following TREC also includes some examples of non-topical 'topics', for example the home-page topics used in the TREC Web track [59].

2

Phát triển Mô hình Cơ bản

2.1 Nhu cầu thông tin và các truy vấn

Chúng tôi bắt đầu từ khái niệm nhu cầu thông tin. Chúng tôi coi một truy vấn là một đại diện (không nhất thiết phải tốt hoặc đầy đủ) của nhu cầu thông tin của một người dùng cá nhân hoặc có thể là ý định tìm kiếm. Chúng tôi coi tính liên quan là mức độ liên quan của một tài liệu đối với nhu cầu thông tin, được đánh giá bởi người dùng. Chúng tôi không đưa ra giả định cụ thể nào về bản chất khái niệm của tính liên quan; đặc biệt, chúng tôi không giả định tính liên quan là về chủ đề. Tuy nhiên, chúng tôi có đưa ra một số giả định về tình trạng hình thức của biến liên quan, được nêu bên dưới, điều này có thể được coi là ngụ ý một số giả định về bản chất khái niệm của nó.

[1] Khái niệm *topic*, như được sử dụng trong TREC, phần nào giống với *information need*, hoặc ít nhất là một biểu diễn và đặc tả chi tiết và đầy đủ hơn về một nhu cầu thông tin. Việc sử dụng thuật ngữ 'chủ đề' cho mục đích này hơi không may, vì nó dường như ngụ ý một loại tính chất liên quan theo chủ đề. Tuy nhiên, chúng tôi cũng lưu ý rằng việc sử dụng rộng rãi thuật ngữ này sau TREC cũng bao gồm một số ví dụ về các 'chủ đề' không theo chủ đề, ví dụ như các chủ đề trang chủ được sử dụng trong TREC Web track [59].

2.2 Binary Relevance

The assumptions about relevance are as follows:

1. Relevance is assumed to be a property of the document given information need only, assessable without reference to other documents; and
2. The relevance property is assumed to be binary.

Either of these assumptions is at the least arguable. We might easily imagine situations in which one document's relevance can only be perceived by the user in the context of another document, for example. Regarding the binary property, many recent experimental studies have preferred a graded notion of relevance. One might go further and suggest that different documents may be relevant to a need in different ways, not just to different degrees. However, we emphasise that we consider the situation of a single information need (rather than the multiple needs or intents that might be represented by a single text query). If we take *relevant* to mean 'the user would like to be pointed to this document', the binary notion is at least moderately plausible.

2.3 The Probability Ranking Principle

Given that an information retrieval system cannot *know* the values of the relevance property of each document, we assume that the information available to the system is at best probabilistic. That is, the known (to the system) properties of the document and the query may provide probabilistic or statistical evidence as to the relevance of that document to the underlying need. Potentially these properties may be rich and include a variety of different kinds of evidence; the only information assumed to be absent is the actual relevance property itself. Given whatever information is available, the system may make some statistical statement about the possible value of the relevance property.

Given a binary document-by-document relevance property, then this statistical information may be completely encapsulated in a *probability* of relevance. The probability of relevance of a given document to a

2.2 Binary Relevance 337

2.2 Sự liên quan nhị phân

Các giả định về sự liên quan như sau:

1. Mức độ liên quan được cho là một đặc tính của tài liệu dựa trên nhu cầu thông tin duy nhất, có thể đánh giá mà không cần tham khảo các tài liệu khác; và 2. Đặc tính liên quan được giả định là nhị phân.

Mỗi giả định này ít nhất đều có thể tranh luận được. Chúng ta có thể dễ dàng tưởng tượng ra các tình huống mà sự liên quan của một tài liệu chỉ có thể được người dùng nhận thấy trong bối cảnh của một tài liệu khác, ví dụ. Về thuộc tính nhị phân, nhiều nghiên cứu thực nghiệm gần đây đã ưu tiên một khái niệm liên quan theo mức độ. Người ta có thể đi xa hơn và đề xuất rằng các tài liệu khác nhau có thể liên quan đến một nhu cầu theo những cách khác nhau, không chỉ ở các mức độ khác nhau. Tuy nhiên, chúng tôi nhấn mạnh rằng chúng tôi xem xét tình huống của một nhu cầu thông tin duy nhất (thay vì nhiều nhu cầu hoặc mục đích có thể được thể hiện bởi một truy vấn văn bản duy nhất). Nếu chúng ta hiểu liên quan là 'người dùng muốn được hướng đến tài liệu này', thì khái niệm nhị phân ít nhất là tương đối hợp lý.

2.3 Nguyên tắc Xếp hạng theo Xác suất

Vì một hệ thống truy hồi thông tin không thể biết các giá trị của thuộc tính phù hợp của từng tài liệu, chúng ta giả định rằng thông tin có sẵn cho hệ thống nhiều nhất chỉ là xác suất. Tức là, các thuộc tính đã biết (với hệ thống) của tài liệu và truy vấn có thể cung cấp bằng chứng xác suất hoặc thống kê về mức độ phù hợp của tài liệu đó với nhu cầu cơ bản. Các thuộc tính này có thể phong phú và bao gồm nhiều loại bằng chứng khác nhau; thông tin duy nhất được giả định là không có là chính thuộc tính phù hợp thực tế. Với bất kỳ thông tin nào có sẵn, hệ thống có thể đưa ra một phát biểu thống kê nào đó về giá trị có thể c ủa thuộc tính phù hợp.

Với một thuộc tính liên quan tài liệu-nhị phân, thì thông tin thống kê này có thể được bao gói hoàn toàn trong xác suất liên quan. Xác suất liên quan của một tài liệu nhất định đối với một

given query plays a central role in the present theory. We can in fact make a general statement about this:

> If retrieved documents are ordered by decreasing probability of relevance on the data available, then the system's effectiveness is the best that can be obtained for the data.

This is a statement of the *Probability Ranking Principle* (PRP), taken from [52], an abbreviated version of the one in [40]. The PRP can be justified under some further assumptions, for a range of specific measures of effectiveness. It is not, however, completely general; one can also construct counter-examples. But these counter-examples depend on probabilities defined over a population of users. The PRP is safe for the case considered: an individual user. It will be assumed for the remainder of this work.

2.4 Some Notation

In this section, we introduce some of the notation that will be used throughout the survey. The notation assumes a single query q representing a single information need. The first symbol is used to indicate that two functions are equivalent as ranking functions.

rank equivalence: $\propto_q$ e.g. $g() \propto_q h()$

In developing the model, from the probability of relevance of a document to a term-weighting and document-scoring function, we make frequent use of transformations which thus preserve rank order. Such a transformation (in a document-scoring function, say) may be linear or non-linear, but must be strictly monotonic, so that if documents are ranked by the transformed function, they will be in the same rank order as if they had been ranked by the original function.

The property of relevance is represented by a random variable *Rel* with two possible values:

relevance *Rel*: $\text{rel}, \overline{\text{rel}}$ (relevant or not)

truy vấn đã cho đóng vai trò trung tâm trong lý thuyết hiện tại. Thực tế, chúng ta có thể đưa ra một tuyên bố tổng quát về điều này:

> Nếu các tài liệu được truy xuất được sắp xếp theo xác suất liên quan giảm dần dựa trên dữ liệu có sẵn, thì hiệu quả của hệ thống là tốt nhất có thể đạt được cho dữ liệu.

Đây là một tuyên bố về Nguyên tắc Xếp hạng Xác suất (PRP), được trích từ [52], một phiên bản rút gọn của phiên bản trong [40]. PRP có thể được biện minh dưới một số giả định bổ sung, cho một phạm vi các thước đo hiệu quả cụ thể. Tuy nhiên, nó không hoàn toàn tổng quát; người ta cũng có thể xây dựng các ví dụ phản chứng. Nhưng các ví dụ phản chứng này phụ thuộc vào xác suất được định nghĩa trên một tập hợp người dùng. PRP là an toàn cho trường hợp được xem xét: một người dùng cá nhân. Nguyên tắc này sẽ được giả định cho phần còn lại của công trình này.

2.4 Một số ký hiệu

Trong phần này, chúng tôi giới thiệu một số ký hiệu sẽ được sử dụng trong toàn bộ khảo sát. Ký hiệu giả định một truy vấn duy nhất q đại diện cho một nhu cầu thông tin duy nhất. Ký hiệu đầu tiên được dùng để chỉ rằng hai hàm là tương đương như các hàm xếp hạng.

rank equivalence: $\propto_q$ e.g. $g() \propto_q h()$

Trong việc phát triển mô hình, từ xác suất liên quan của một tài liệu đối với một hàm tính trọng số từ và điểm tài liệu, chúng tôi thường xuyên sử dụng các phép biến đổi mà do đó giữ nguyên thứ tự xếp hạng. Một phép biến đổi như vậy (trong một hàm tính điểm tài liệu, chẳng hạn) có thể là tuyến tính hoặc phi tuyến, nhưng phải đúng theo đơn điệu, để nếu các tài liệu được xếp hạng theo hàm biến đổi, chúng sẽ ở cùng thứ tự xếp hạng như khi chúng được xếp hạng theo hàm gốc.

Tính chất liên quan được biểu thị bằng một biến ngẫu nhiên Rel với hai giá trị có thể:

relevance *Rel*: $\text{rel}, \overline{\text{rel}}$ (relevant or not)

As discussed above, we assume that relevance is a binary property of a document (given an information need). We will use the short-hand notation $P(\text{rel}|d,q)$ to denote $P(Rel = \text{rel}|d,q)$.

For documents and queries, we generally assume a bag or set of words model. We have a vocabulary of terms indexed into the set $\mathbf{V}$, each of which may be present or absent (in the set of words model) or may be present with some frequency (bag of words model). In either case the objects (documents or queries) may be represented as vectors over the space defined by the vocabulary. Thus a document is:

$$\text{document:} \quad d := (tf_1, \ldots, tf_{|\mathbf{V}|}),$$

where tf_i normally represents the frequency of term t_i in the document. We will also need to distinguish between the random variable TF_i and its observed value in a document, tf_i. The random variable will usually refer to the term frequencies of a given term in the vocabulary. However, the formulation of the basic model is somewhat more general than this, and can accommodate any discrete variable as a feature (e.g., any discrete property or attribute of the document). Thus we can re-interpret tf as simply representing presence or absence of a term; this is the basis of Section 3.1 below. Continuous variables can also be accommodated by replacing probability mass functions TF_i (of discrete variables) by probability density functions (of continuous variables); although we do not present a formal development of the model with continuous variables, we will use this fact in Section 3.7 to introduce some non-textual continuous features into the model.

A query is represented in two different ways. In the first, it is treated similarly as a vector:

$$\text{query: } q := (qtf_1, \ldots, qtf_{|\mathbf{V}|})$$

Here again the components qtf_i may represent term frequencies in the query, or may represent a binary presence or absence feature.

Throughout this survey we will need to sum or multiply variables of terms present in the query (i.e., with $qtf_i > 0$). For this purpose we define the set of indices:

$$\text{query terms:} \quad \mathbf{q} := \{i \,|\, qtf_i > 0\} \quad \text{(indices of terms in the query)}$$

Như đã thảo luận ở trên, chúng tôi giả định rằng mức độ liên quan là một đặc tính nhị phân của tài liệu (với một nhu cầu thông tin nhất định). Chúng tôi sẽ sử dụng ký hiệu ngắn gọn $P(\text{rel}|d,q)$ để biểu thị $P(\text{Rel} = \text{rel}|d,q)$.

Đối với các tài liệu và truy vấn, chúng ta thường giả định một mô hình tập từ hoặc túi từ. Chúng ta có một tập hợp các thuật ngữ được đánh chỉ mục vào tập V, mỗi thuật ngữ có thể có mặt hoặc không có mặt (trong mô hình tập từ) hoặc có thể xuất hiện với tần suất nào đó (mô hình túi từ). Trong cả hai trường hợp, các đối tượng (tài liệu hoặc truy vấn) có thể được biểu diễn dưới dạng vector trên không gian được xác định bởi từ vựng. Do đó, một tài liệu là:

$$\text{document:} \quad d := (tf_1, \ldots, tf_{|\mathbf{V}|}),$$

nơi mà tf_i thường đại diện cho tần suất của thuật ngữ t_i trong tài liệu. Chúng ta cũng sẽ cần phân biệt giữa biến ngẫu nhiên TF_i và giá trị quan sát được của nó trong một tài liệu, tf_i. Biến ngẫu nhiên thường sẽ ám chỉ tần suất xuất hiện của một thuật ngữ cụ thể trong từ vựng. Tuy nhiên, cách trình bày của mô hình cơ bản có phần tổng quát hơn thế, và có thể chấp nhận bất kỳ biến rời rạc nào làm đặc trưng (ví dụ, bất kỳ thuộc tính hoặc đặc điểm rời rạc nào của tài liệu). Do đó, chúng ta có thể diễn giải lại tf đơn giản là đại diện cho sự hiện diện hay vắng mặt của một thuật ngữ; đây là cơ sở của Mục 3.1 dưới đây. Các biến liên tục cũng có thể được chấp nhận bằng cách thay các hàm khối xác suất TF_i (của các biến rời rạc) bằng các hàm mật độ xác suất (của các biến liên tục); mặc dù chúng tôi không trình bày một phát triển chính thức của mô hình với các biến liên tục, chúng tôi sẽ sử dụng thực tế này trong Mục 3.7 để giới thiệu một số đặc trưng liên tục không phải văn bản vào mô hình.

Aquery được biểu diễn theo hai cách khác nhau. Trong cách thứ nhất, nó được coi tương tự như một vector:

$$\text{query: } q := (qtf_1, \ldots, qtf_{|\mathbf{V}|})$$

Ở đây, các thành phần qtf_i có thể đại diện cho tần số xuất hiện của các thuật ngữ trong truy vấn, hoặc có thể đại diện cho một đặc trưng tồn tại hay không tồn tại nhị phân.

Trong suốt khảo sát này, chúng ta sẽ cần cộng hoặc nhân các biến của các thuật ngữ có trong truy vấn (tức là, với $\text{qtf}_i > 0$). Cho mục đích này, chúng ta định nghĩa tập hợp các chỉ số:

$$\text{query terms:} \quad \mathbf{q} := \{i \,|\, qtf_i > 0\} \quad \text{(indices of terms in the query)}$$

2.4.1 Preview of the Development

The following provides an overview of the development of the basic model; the individual steps are discussed below. The main point to note is that we start with the very general PRP, and end up with an explicit document scoring function, composed of a simple sum of weights for the individual query terms present in the document.

$$P(\mathrm{rel}|d,q) \propto_q \frac{P(\mathrm{rel}|d,q)}{P(\overline{\mathrm{rel}}|d,q)} \tag{2.1}$$

$$= \frac{P(d|\mathrm{rel},q)}{P(d|\overline{\mathrm{rel}},q)} \frac{P(\mathrm{rel}|q)}{P(\overline{\mathrm{rel}}|q)} \tag{2.2}$$

$$\propto_q \frac{P(d|\mathrm{rel},q)}{P(d|\overline{\mathrm{rel}},q)} \tag{2.3}$$

$$\approx \prod_{i \in \mathbf{V}} \frac{P(TF_i = tf_i|\mathrm{rel},q)}{P(TF_i = tf_i|\overline{\mathrm{rel}},q)} \tag{2.4}$$

$$\approx \prod_{i \in \mathbf{q}} \frac{P(TF_i = tf_i|\mathrm{rel})}{P(TF_i = tf_i|\overline{\mathrm{rel}})} \tag{2.5}$$

$$\propto_q \sum_{\mathbf{q}} \log \frac{P(TF_i = tf_i|\mathrm{rel})}{P(TF_i = tf_i|\overline{\mathrm{rel}})} \tag{2.6}$$

$$= \sum_{\mathbf{q}} U_i(tf_i) \tag{2.7}$$

$$= \sum_{\mathbf{q}, tf_i>0} U_i(tf_i) + \sum_{\mathbf{q}, tf_i=0} U_i(0) - \sum_{\mathbf{q}, tf_i>0} U_i(0) + \sum_{\mathbf{q}, tf_i>0} U_i(0) \tag{2.8}$$

$$= \sum_{\mathbf{q}, tf_i>0} (U_i(tf_i) - U_i(0)) + \sum_{\mathbf{q}} U_i(0) \tag{2.9}$$

$$\propto_q \sum_{\mathbf{q}, tf_i>0} (U_i(tf_i) - U_i(0)) \tag{2.10}$$

$$= \sum_{\mathbf{q}, tf_i>0} w_i \tag{2.11}$$

340 *Development of the Basic Model*

2.4.1 Xem trước về Sự Phát triển

Phần sau cung cấp một cái nhìn tổng quan về sự phát triển của mô hình cơ bản; các bước riêng lẻ được thảo luận bên dưới. Điểm chính cần lưu ý là chúng ta bắt đầu với PRP rất tổng quát, và kết thúc với một hàm chấm điểm tài liệu rõ ràng, bao gồm tổng đơn giản của các trọng số cho từng từ truy vấn riêng lẻ có trong tài liệu.

$$P(\mathrm{rel}|d,q) \propto_q \frac{P(\mathrm{rel}|d,q)}{P(\overline{\mathrm{rel}}|d,q)} \tag{2.1}$$

$$= \frac{P(d|\mathrm{rel},q)}{P(d|\overline{\mathrm{rel}},q)} \frac{P(\mathrm{rel}|q)}{P(\overline{\mathrm{rel}}|q)} \tag{2.2}$$

$$\propto_q \frac{P(d|\mathrm{rel},q)}{P(d|\overline{\mathrm{rel}},q)} \tag{2.3}$$

$$\approx \prod_{i \in \mathbf{V}} \frac{P(TF_i = tf_i|\mathrm{rel},q)}{P(TF_i = tf_i|\overline{\mathrm{rel}},q)} \tag{2.4}$$

$$\approx \prod_{i \in \mathbf{q}} \frac{P(TF_i = tf_i|\mathrm{rel})}{P(TF_i = tf_i|\overline{\mathrm{rel}})} \tag{2.5}$$

$$\propto_q \sum_{\mathbf{q}} \log \frac{P(TF_i = tf_i|\mathrm{rel})}{P(TF_i = tf_i|\overline{\mathrm{rel}})} \tag{2.6}$$

$$= \sum_{\mathbf{q}} U_i(tf_i) \tag{2.7}$$

$$= \sum_{\mathbf{q}, tf_i>0} U_i(tf_i) + \sum_{\mathbf{q}, tf_i=0} U_i(0) - \sum_{\mathbf{q}, tf_i>0} U_i(0) + \sum_{\mathbf{q}, tf_i>0} U_i(0) \tag{2.8}$$

$$= \sum_{\mathbf{q}, tf_i>0} (U_i(tf_i) - U_i(0)) + \sum_{\mathbf{q}} U_i(0) \tag{2.9}$$

$$\propto_q \sum_{\mathbf{q}, tf_i>0} (U_i(tf_i) - U_i(0)) \tag{2.10}$$

$$= \sum_{\mathbf{q}, tf_i>0} w_i \tag{2.11}$$

2.4.2 Details

We start with the probability of relevance of a given document and query.

The first three steps are simple algebraic transformations. In Step (2.1), we simply replace the probability by an odds-ratio.[2] In Step (2.2), we perform Bayesian inversions on both numerator and denominator. In Step (2.3), we drop the second component which is independent of the document, and therefore does not affect the ranking of the documents.

In Step (2.4) (term independence assumption), we expand each probability as a product over the terms of the vocabulary. This step depends on an assumption of statistical independence between terms — actually a pair of such assumptions, for the relevant and non-relevant cases, respectively. Note that we are *not* assuming unconditional term independence, but a weaker form, namely *conditional* independence.[3] This is clearly a much more arguable step: in general terms will not be statistically independent in this fashion. The obvious reason for taking this step is to lead us to a simple and tractable (even if approximate) scoring function. However, we may make some further arguments to support this step:

1. Models of this type in other domains, known as Naïve Bayes models, are well known to be remarkably good, simple and robust, despite significant deviations from independence. Experimental evidence in IR provides some support for this general statement.
2. The pair of assumptions is not in general equivalent to a blanket assumption of independence between terms over the whole collection. On the contrary, for a pair of query terms, both statistically correlated with relevance, the pair of assumptions predict a positive association between the two terms over the whole collection. In fact we often observe such a positive association. In effect the model says that this

[2] This transformation is order preserving; the odds-ratio of p is $\frac{p}{1-p}$, and this function is a monotonous increasing function of $p \in [0,1)$.
[3] $P(ab|c) = P(a|c)P(b|c)$.

2.4.2 Chi tiết

Chúng tôi bắt đầu với xác suất liên quan của một tài liệu và truy vấn nhất định.

Ba bước đầu tiên là những phép biến đổi đại số đơn giản. Ở Bước (2.1), chúng ta chỉ đơn giản thay xác suất bằng tỷ lệ cược. Ở Bước (2.2), chúng ta thực hiện đảo ngược Bayesian trên cả tử và mẫu số. Ở Bước (2.3), chúng ta bỏ thành phần thứ hai mà độc lập với tài liệu, và do đó không ảnh hưởng đến thứ hạng của các tài liệu.

Trong Bước (2.4) (giả định độc lập giữa các từ), chúng ta mở rộng mỗi xác suất dưới dạng tích các từ trong từ vựng. Bước này dựa trên giả định về sự độc lập thống kê giữa các từ — thực ra là một cặp giả định như vậy, tương ứng cho các trường hợp có liên quan và không liên quan. Lưu ý rằng chúng ta không giả định sự độc lập tuyệt đối giữa các từ, mà là một hình thức yếu hơn, cụ thể là sự độc lập có điều kiện. Điều này rõ ràng là một bước gây tranh cãi hơn: nói chung các t ừ sẽ không độc lập về mặt thống kê theo cách này. Lý do hiển nhiên để thực hiện bước này là dẫn chúng ta đến một hàm điểm đơn giản và khả thi (ngay cả khi chỉ gần đúng). Tuy nhiên, chúng ta có thể đưa ra một số lập luận bổ sung để ủng hộ bước này:

1. Các mô hình loại này trong các lĩnh vực khác, được biết đến với tên gọi mô hình Naive Bayes, được biết đến là cực kỳ tốt, đơn giản và mạnh mẽ, mặc dù có những sai lệch đáng kể so với tính độc lập. Bằng chứng thực nghiệm trong IR cung cấp một số hỗ trợ cho tuyên bố chung này. 2. Cặp giả định này một cách tổng quát không tương đương với giả định hoàn toà n về tính độc lập giữa các thuật ngữ trong toàn bộ tập hợp. Ngược lại, đối với một cặp thuật ngữ truy vấn, cả hai đều có tương quan thống kê với sự liên quan, cặp giả định này dự đoán một mối liên kết tích cực giữa hai thuật ngữ trong toàn bộ tập hợp. Thực tế chúng ta thường quan sát thấy mối liên kết tích cực như vậy. Thực chất mô hình nói rằng điều này

[2] Sự biến đổi này bảo toàn thứ tự; tỉ số chênh lệch của p là $\frac{p}{1-p}$, và hàm này là một hàm tăng đơn điệu của $p \in [0,1)$. [3] $P(ab|c) = P(a|c)P(b|c)$.

positive association is induced by relevance to the query.[4] This is clearly an over-simplification, but perhaps not such a bad one.

3. Cooper [11] has demonstrated that we can arrive at the same transformation on the basis of a weaker assumption, called *linked dependence*.[5] This is essentially that the degree of statistical association between the terms is the same in the relevant as in the non-relevant subsets. Again, this theoretical result may help to explain the robustness of such a model.

We may represent the independence assumptions by means of a graphical model, as in Figure 2.1. This diagram shows how the term frequencies $(tf_i)_{i \in \mathbf{V}}$ are assumed to be generated as stochastic observations dependant only on the state of the relevance variable Rel (a full explanation of graphical model diagrams is outside the scope of this paper, we refer the reader to [6]).

In step (2.5) (query-terms assumption), we restrict ourselves to the query terms only: in effect, we assume that for any non-query term, the ratio of conditional probabilities is constant and equal to one.[6] This might seem a drastic assumption (that no non-query terms have any association with relevance); however, this is not quite the explanation of the step. We have to consider the question of what information we

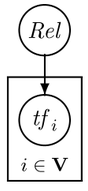


Fig. 2.1 Graphical model indicating basic independence assumptions.

[4] If $P(a|c) > P(a|\overline{c})$ and similarly for b, then it follows that $P(ab) > P(a)P(b)$ even under the conditional independence assumptions made.

[5] $\frac{P(a,b|c)}{P(a,b|\overline{c})} = \frac{P(a|c)}{P(a|\overline{c})} \frac{P(b|c)}{P(b|\overline{c})}$.

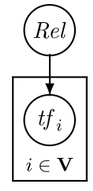
[6] Note that if the ratio is constant, then it must be equal to one; otherwise we would have one of the probability distribution with probabilities always higher than another one, which is impossible since they both need to sum to 1.

mối liên hệ tích cực được tạo ra bởi sự liên quan đến truy vấn.[4]Điều này rõ ràng là một sự đơn giản hóa quá mức, nhưng có lẽ không phải là một điều quá tồi.

3. Cooper [11] đã chứng minh rằng chúng ta có thể đạt được cùng một phép biến đổi dựa trên một giả định yếu hơn, gọi là phụ t huộc liên kết. [5] Điều này về cơ bản có nghĩa là mức độ liên kết thống kê giữa các thuật ngữ là giống nhau trong các tập con liên quan cũng như trong các tập con không liên quan. Một lần nữa, kết quả lý thuyết này có thể giúp giải thích tính vững chắc của một mô hình như vậy.

Chúng ta có thể biểu diễn các giả định về tính độc lập bằng mô hình đồ thị, như trong Hình 2.1. Sơ đồ này cho thấy tần số của từ $(tf_i)_{i \in V}$ được giả định là sinh ra như các quan sát ngẫu nhiên chỉ phụ thuộc vào trạng thái của biến liên quan Rel (một giải thích đầy đủ về các sơ đồ mô hình đồ thị nằm ngoài phạm vi của bài báo này, chúng tôi t ham khảo người đọc đến [6]).

Trong bước (2.5) (giả định các thuật ngữ truy vấn), chúng ta chỉ giới hạn mình vào các thuật ngữ truy vấn: thực chất, chúng ta giả định rằng đối với bất kỳ thuật ngữ không phải truy vấn nào, tỷ lệ xác suất có điều kiện là hằng và bằng một. [6] Điều này có vẻ là một giả định cực đoan (rằng không có thuật ngữ nào ngoài truy vấn có mối quan hệ với tính liên quan); tuy nhiên, đây không hoàn toàn là lời giải thích cho bước này. Chúng ta phải xem xét câu hỏi về thông tin mà chúng ta



Hình 2.1 Mô hình đồ họa chỉ ra các giả định độc lập cơ bản.

[4] Nếu $P(a|c) > P(a|\overline{c})$ và tương tự cho b, thì suy ra rằng $P(ab) > P(a)P(b)$ ngay cả dưới các giả định độc lập có điều kiện đã đưa ra. [5] $\frac{P(a,b|c)}{P(a,b|\overline{c})} = \frac{P(a|c)}{P(a|\overline{c})} \frac{P(b|c)}{P(b|\overline{c})}$. [6] Lưu ý rằng nếu tỷ số là hằng số, thì nó phải bằng một; nếu không chúng ta sẽ có một trong hai phân phối xác suất với các xác suất luôn cao hơn cái còn lại, điều này là không thể vì cả hai đều cần tổng bằng 1.

have on which to base an estimate of the probability of relevance. It is a reasonable prior assumption, and turns out to be a good one, that in general query terms are (positively) correlated with relevance. However, we can make no such assumption about non-query terms (a term relating to a completely different topic could well be *negatively* correlated with relevance). In the absence of any link to the query, the obvious vague prior assumption about a random vocabulary term must be that it is not correlated with relevance to this query. Later we will consider the issue of query expansion, adding new terms to the query, when we have evidence to link a non-query term with relevance to the query.

Again, we can illustrate the assumptions by means of a graphical model, as in Figure 2.2. This diagram shows that in this model the relevance variable only affects terms in the query.

Starting in Step (2.6) we use the following short-hand notation: under the summation operator we will write $\mathbf{q}$ (the starting set of values for i) followed by conditions that i should satisfy. For example: $\sum_{\mathbf{q}}$ should be read as $\sum_{i \in \mathbf{q}}$, and $\sum_{\mathbf{q}, tf_i > 0}$ should be read as $\sum_{\{i \,|\, i \in \mathbf{q}, tf_i > 0\}}$.

In Step (2.6), we make a common, order-preserving transformation, namely we take a log. This allows us to express the product of probabilities as a sum of log probabilities — actually log-odds because of the ratio in the product.

In Step (2.7), we rewrite the previous equation using a function $U_i(x)$:

$$U_i(x) := \log \frac{P(TF_i = x \,|\, \text{rel})}{P(TF_i = x \,|\, \overline{\text{rel}})} \tag{2.12}$$

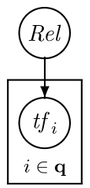


Fig. 2.2 Graphical model for restriction to query terms.

có cơ sở để ước tính xác suất phù hợp. Đây là một giả định tiên nghiệm hợp lý, và hóa ra là một giả định tốt, rằng nói chung các từ truy vấn có mối tương quan (tích cực) với sự phù hợp. Tuy nhiên, chúng ta không thể đưa ra giả định như vậy về các từ không thuộc truy vấn (một từ liên quan đến một chủ đề hoàn toàn khác có thể có mối tương quan tiêu cực với sự phù hợp). Khi không có bất kỳ liên kết nào với truy vấn, giả định tiên nghiệm mơ hồ hiển nhiên về một từ vựng ngẫu nhiên phải là nó không có mối tương quan với sự phù hợp của truy vấn này. Sau này chúng ta sẽ xem xét vấn đề mở rộng truy vấn, thêm các từ mới vào truy vấn, khi chúng ta có bằng chứng liên kết một từ không thuộc truy vấn với sự phù hợp của truy vấn.

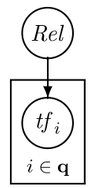
Một lần nữa, chúng ta có thể minh họa các giả định bằng cách sử dụng một mô hình đồ họa, như trong Hình 2.2. Sơ đồ này cho thấy rằng trong mô hình này, biến liên quan chỉ ảnh hưởng đến các thuật ngữ trong truy vấn.

Bắt đầu từ Bước (2.6) chúng ta sử dụng ký hiệu rút gọn sau: dưới toán tử tổng, chúng ta sẽ viết q (tập giá trị khởi đầu cho i) kèm theo các điều kiện mà i phải thỏa mãn. Ví dụ: $\sum$q nên được đọc là $\sum_{i \in \mathbf{q}}$, và $\sum_{\mathbf{q}, tf_i > 0}$ nên được đọc là $\sum_{\{i \,|\, i \in \mathbf{q}, tf_i > 0\}}$.

Trong Bước (2.6), chúng ta thực hiện một phép biến đổi phổ biến, giữ nguyên thứ tự, cụ thể là chúng ta lấy logarit. Điều này cho phép chúng ta biểu diễn tích của các xác suất dưới dạng tổng của các xác suất logarit—thực ra là log-tỷ lệ bởi vì tỷ số trong tích.

Trong Bước (2.7), chúng ta viết lại phương trình trước đó bằng cách sử dụng một hàm $U_i(x)$:

$$U_i(x) := \log \frac{P(TF_i = x \,|\, \text{rel})}{P(TF_i = x \,|\, \overline{\text{rel}})} \tag{2.12}$$



Hình 2.2 Mô hình đồ họa cho việc giới hạn theo các thuật ngữ truy vấn.

Note that this is not the log-odds function. Note also that in Step (2.7) each term frequency tf_i will be applied to a different function $U_i(tf_i)$. This is necessary since the weight of a term does not depend only on its frequency, but also in other factors such as the collection frequency, etc.

The following two steps use an arithmetic trick (sometimes referred to as *removing the zeros*) which eliminates from the equation terms that are not present in the document. This is crucial for the efficient implementation of PRF ranking functions using inverted indices.

In Step (2.8), we do two things. In the first line, the sum over query terms in Step (2.7) has been split into two groups: those terms that are present in the document (first sum) and those that are absent (second sum). In the second line, we subtract and add the same quantity (the sum of zero frequency weights for terms in the document) leaving the result unchanged. The reason for doing this will become clear in the next step.

In Step (2.9), we regroup the sums of Step (2.8). First we note that the first and third sums in Step (2.8) are over the same terms, and can be grouped. This forms the first sum in Step (2.9). Then we note that the second and fourth sums in Step (2.8) span all terms in the query. This forms the second sum in Step (2.9).

In Step (2.10) we drop the last sum since its value is document-independent. We note that by doing so we are left with a single sum over terms present both in the document and in the query. We have removed terms in the query with zero frequency in the document.

In Step (2.11), we again rewrite the equation using the short-hand notation:

$$W_i(x) := U_i(x) - U_i(0) \tag{2.13}$$

$$= \log \frac{P(TF_i = x\,|\,\mathrm{rel})P(TF_i = 0\,|\,\overline{\mathrm{rel}})}{P(TF_i = x\,|\,\overline{\mathrm{rel}})P(TF_i = 0\,|\,\mathrm{rel})} \tag{2.14}$$

$$w_i := W_i(tf_i) \tag{2.15}$$

Equation (2.14) is the formula for the basic weight of a query term in a document. Both U_i and W_i are term-weighting functions which can be precomputed and stored at indexing time. The difference is that in

Lưu ý rằng đây không phải là hàm log-odds. Cũng lưu ý rằng ở Bước (2.7) mỗi tần số từ tf_i sẽ được áp dụng cho một hàm khác $U_i(tf_i)$. Điều này là cần thiết vì trọng số của một từ không chỉ phụ thuộc vào tần số của nó, mà còn vào các yếu tố khác như tần số trong tập hợp, v.v.

Hai bước sau sử dụng một thủ thuật số học (đôi khi được gọi là loại bỏ các số không) mà loại bỏ khỏi phương trình các hạng tử không có trong tài liệu. Điều này rất quan trọng cho việc triển khai hiệu quả các hàm xếp hạng PRF sử dụng chỉ mục đảo ngược.

Trong Bước (2.8), chúng ta làm hai việc. Trong dòng đầu tiên, tổng các thuật ngữ truy vấn trong Bước (2.7) đã được chia thành hai nhó m: các thuật ngữ có mặt trong tài liệu (tổng đầu tiên) và những thuật ngữ không có mặt (tổng thứ hai). Trong dòng thứ hai, chúng ta trừ đi và cộng cùng một đại lượng (tổng trọng số tần số bằng không cho các thuật ngữ trong tài liệu) khiến kết quả không thay đổi. Lý do thực hiện việc này sẽ trở nên rõ ràng ở bước tiếp theo.

Trong Bước (2.9), chúng ta nhóm lại các tổng của Bước (2.8). Trước tiên, chúng ta nhận thấy rằng tổng thứ nhất và thứ ba trong Bước (2.8) là trên cùng các thuật ngữ, và có thể nhóm lại với nhau. Điều này tạo thành tổng thứ nhất trong Bước (2.9). Sau đó, chúng ta nhận thấy rằng tổng thứ hai và thứ tư trong Bước (2.8) bao phủ tất cả các thuật ngữ trong truy vấn. Điều này tạo thành tổng thứ hai trong Bước (2.9).

Trong Bước (2.10) chúng ta loại bỏ tổng cuối cùng vì giá trị của nó không phụ thuộc vào tài liệu. Chúng ta lưu ý rằng bằng cách làm như vậy, chúng ta chỉ còn lại một tổng duy nhất trên các thuật ngữ xuất hiện cả trong tài liệu và trong truy vấn. Chúng ta đã loại bỏ các thuật ngữ trong truy vấn có tần số bằng không trong tài liệu.

Trong Bước (2.11), chúng ta lại viết lại phương trình bằng cách sử dụng ký hiệu ngắn gọn:

$$W_i(x) := U_i(x) - U_i(0) \tag{2.13}$$

$$= \log \frac{P(TF_i = x\,|\,\mathrm{rel})P(TF_i = 0\,|\,\overline{\mathrm{rel}})}{P(TF_i = x\,|\,\overline{\mathrm{rel}})P(TF_i = 0\,|\,\mathrm{rel})} \tag{2.14}$$

$$w_i := W_i(tf_i) \tag{2.15}$$

Phương trình (2.14) là công thức cho trọng số cơ bản của một từ khóa trong một tài liệu. Cả U_i và W_i đều là các hàm trọng số từ khóa có thể được tính trước và lưu trữ tại thời điểm lập chỉ mục. Sự khác biệt là ở việc

order to use the U_i in a document, we would have to sum over all query terms, whether or not they are present in the document. With W_i, we need only to consider the weights w_i of terms present in the document (in effect the rewriting has defined the weight of absent terms as zero). This fits very well with the sparseness of the document-term matrix — we have no need to calculate scores of any document that contains no query terms. Indeed, this is a highly desirable property for a scoring function to be used in an inverted-file-based document retrieval system, since it means that we can easily calculate the score of all documents with non-zero scores by merging the inverted lists of the query terms.

As indicated above, the model is not restricted to terms and term frequencies — any property, attribute or feature of the document, or of the document–query pair, which we reasonably expect to provide some evidence as to relevance, may be included. Below we will consider static features of documents — properties that are not dependent on the query — for inclusion. Any discrete property with a *natural* zero can be dealt with using the W_i form of the weight — if we want to include a property without such a natural zero, we need to revert to the U_i form.

We note also that both forms are simple linear models — the combination of evidence from the different query terms is just by summation. This is not in itself an assumption — it arises naturally from the more basic assumptions of the model.

In the sections which follow, we define various instantiations of this basic sum-of-weights scoring model.

2.5 A Note on Probabilities and Rank Equivalence

One consequence of our reliance on the probability ranking principle is that we are enabled to make the very cavalier transformations discussed above, on the basis that the *only* property we wish to preserve is the rank order of documents. This might be a reasonable assumption for traditional ad hoc retrieval, but does not work for all retrieval situations. In some, for example in adaptive filtering [42], we find it desirable or necessary to arrive at an explicit estimate of the probability of relevance of each considered document. Unfortunately, while

Để sử dụng U_i trong một tài liệu, chúng ta sẽ phải tổng hợp tất cả các từ truy vấn, bất kể chúng có xuất hiện trong tài liệu hay không. Với W_i, chúng ta chỉ cần xem xét các trọng số w_i của các từ xuất hiện trong tài liệu (thực tế việc viết lại này đã xác định trọng số của các từ không có mặt là bằng không). Điều này phù hợp rất tốt với tính thưa thớt của ma trận tài liệu-từ — chúng ta không cần tính điểm của bất kỳ tài liệu nào không chứa từ truy vấn. Thực tế, đây là một đặc điểm rất mong muốn cho một hàm tính điểm được sử dụng trong hệ thống truy xuất tài liệu dựa trên tệp đảo ngược, vì nó có nghĩa là chúng ta có thể dễ dàng tính điểm của tất cả các tài liệu có điểm khác không bằng cách hợp nhất các danh sách đảo ngược của các từ truy vấn.

Như đã chỉ ra ở trên, mô hình không bị giới hạn bởi các thuật ngữ và tần suất thuật ngữ — bất kỳ đặc tính, thuộc tính hoặc tính năng nào của tài liệu, hoặc của cặp tài liệu–truy vấn, mà chúng ta có thể hợp lý kỳ vọng cung cấp một số bằng chứng về sự liên quan, đều có thể được đưa vào. Dưới đây chúng ta sẽ xem xét các đặc điểm tĩnh của tài liệu — các thuộc tính không phụ thuộc vào truy vấn — để đưa vào. Bất kỳ thuộc tính rời rạc nào có điểm gốc tự nhiên có thể được xử lý bằng dạng W_i của trọng số — nếu chúng ta muốn bao gồm một t huộc tính mà không có điểm gốc tự nhiên như vậy, chúng ta cần quay lại sử dụng dạng U_i .

Chúng tôi cũng lưu ý rằng cả hai dạng đều là các mô hình tuyến tính đơn giản — sự kết hợp bằng chứng từ các thuật ngữ truy vấn khác nhau chỉ bằng cách cộng lại. Điều này tự nó không phải là một giả định — nó phát sinh một cách tự nhiên từ các giả định cơ bản hơn của mô hình.

Trong các phần tiếp theo, chúng tôi định nghĩa các cách hiện thực khác nhau của mô hình chấm điểm tổng trọng số cơ bản này.

2.5 Một chú thích về xác suất và sự tương đương thứ hạng

Một hệ quả của việc chúng ta dựa vào nguyên tắc xếp hạng xác suất là chúng ta có thể thực hiện những biến đổi rất bừa bãi đã được thảo luận ở trên, dựa trên cơ sở rằng đặc tính duy nhất mà chúng ta muốn giữ lại là thứ tự xếp hạng của các tài liệu. Điều này có thể là một giả định hợp lý cho truy xuất thông tin theo cách thủ công truyền thống, nhưng không áp dụng cho tất cả các tình huống truy xuất. Trong một số trường hợp, ví dụ như trong lọc thích nghi [42], , chúng ta thấy rằng việc có được một ước lượng rõ ràng về xác suất liên quan của mỗi tài liệu được xem xét là điều mong muốn hoặc cần thiết. Thật không may, trong khi

the above development allows us to serve the ranking purpose well, it is not easily reversible to give us such an explicit estimate. In particular, some of the transformations involved dropping components which would not affect the ranking, but would be required for a good probability estimate. Often, as in the case of the component that we drop at Step (2.3), it would be very difficult to estimate. Thus the above model has to be considerably modified if it is to be used in a situation which requires an explicit probability. This issue is not discussed further in the present survey.

346 *Development of the Basic Model*

Sự phát triển nêu trên cho phép chúng ta thực hiện mục đích xếp hạng một cách tốt, nhưng nó không dễ dàng đảo ngược để cung cấp cho chúng ta một ước lượng rõ ràng như vậy. Cụ thể, một số phép biến đổi liên quan đến việc loại bỏ các thành phần mà không ảnh hưởng đến thứ hạng, nhưng sẽ cần thiết cho một ước lượng xác suất tốt. Thường thì, như trong trường hợp của thành phần mà chúng ta loại bỏ ở Bước (2.3), việc ước lượng sẽ rất khó khăn. Do đó, mô hình trên phải được sửa đổi đáng kể nếu muốn sử dụng trong tình huống yêu cầu một xác suất rõ ràng. Vấn đề này không được thảo luận thêm trong khảo sát hiện tại.

3

Derived Models

The models discussed in this section are all derived from the basic model presented in the previous section. We note again that the symbol TF in the basic weighting formula (2.14) can in general be any discrete property or attribute of the document. We start by interpreting it as a binary variable, indicating the presence or absence only of a query term in a document; in Section 3.4 we return to the more familiar term frequency.

3.1 The Binary Independence Model

Suppose that TF_i is a binary variable, having only the values zero and one. We can think of this, without loss of generality, as presence (one) or absence (zero) of a term: t_i will refer to the event that the term is present in the document. The absence event is simply the complement of the presence event; probability of absence is one minus probability of presence. Now Equation (2.14) reduces to:

$$w_i^{\mathrm{BIM}} = \log \frac{P(t_i|\mathrm{rel})(1 - P(t_i|\overline{\mathrm{rel}}))}{(1 - P(t_i|\mathrm{rel}))P(t_i|\overline{\mathrm{rel}})} \tag{3.1}$$

We now suppose that we do actually have some evidence on which to base estimates of these probabilities. Since they are conditional on

3

Mô hình dẫn xuất

Các mô hình được thảo luận trong phần này đều được rút ra từ mô hình cơ bản đã trình bày trong phần trước. Chúng tôi một lần nữa lưu ý rằng ký hiệu TF trong công thức trọng số cơ bản (2.14) nói chung có thể là bất kỳ đặc tính hoặc thuộc tính rời rạc nào của tài liệu. Chúng tôi bắt đầu bằng cách diễn giải nó như một biến nhị phân, chỉ ra sự có mặt hay vắng mặt của một thuật ngữ truy vấn trong tài liệu; trong Phần 3.4, chúng tôi sẽ quay lại tần suất từ quen thuộc hơn.

3.1 Mô hình Độc lập Nhị phân

Giả sử rằng TF_i là một biến nhị phân, chỉ có giá trị bằng không hoặc một. Chúng ta có thể nghĩ về điều này, mà không làm mất sự tổng quát, như sự hiện diện (một) hoặc vắng mặt (không) của một thuật ngữ: t_i sẽ đề cập đến sự kiện rằng thuật ngữ đó có mặt trong tài liệu. Sự kiện vắng mặt đơn giản là phần bù của sự kiện hiện diện; xác suất vắng mặt bằng một trừ đi xác suất hiện diện. Bây giờ Phương trình (2.14) được rút gọn thành:

$$w_i^{\mathrm{BIM}} = \log \frac{P(t_i|\mathrm{rel})(1 - P(t_i|\overline{\mathrm{rel}}))}{(1 - P(t_i|\mathrm{rel}))P(t_i|\overline{\mathrm{rel}})} \tag{3.1}$$

Bây giờ chúng ta giả sử rằng chúng ta thực sự có một số bằng chứng để là m cơ sở cho các ước lượng về các xác suất này. Vì chúng có điều kiện trên

the relevance property, we are assuming that we have some judgements of relevance. We first imagine, unrealistically, that we have a random sample of the whole collection, which has been completely judged for relevance. We derive an estimator that will also be useful for more realistic cases.

We use the following notation:

N — Size of the judged sample
n_i — Number of documents in the judged sample containing t_i
R — Relevant set size (i.e., number of documents judged relevant)
r_i — Number of judged relevant docs containing t_i

Given this information, we would like to estimate in an appropriate fashion the four probabilities needed for the weights defined in Equation (3.1). The standard maximum likelihood estimate of a probability from trials is a simple ratio, e.g., $P(t_i|\text{rel}) \approx \frac{r_i}{R}$. However, this is not a good estimator to plug into the weighting formula. A very obvious practical reason is that the combination of a ratio of probabilities and a log function may yield (positive or negative) infinities as estimates. In fact there are also good theoretical reasons to modify the simple ratio estimates somewhat, as discussed in [44], to obtain a more robust estimator which introduces a small *pseudo-count* of frequency 0.5. The resulting formula is the well-known Robertson/Sprck Jones weight:

$$w_i^{\text{RSJ}} = \log \frac{(r_i + 0.5)(N - R - n_i + r_i + 0.5)}{(n_i - r_i + 0.5)(R - r_i + 0.5)} \tag{3.2}$$

We next suppose that some documents, probably a small number, have been retrieved and judged – this is the usual relevance feedback scenario. In this case we might reasonably estimate the probability conditioned on (positive) relevance in the same way, from the known relevant documents. Estimation of the probabilities conditioned on non-relevance is more tricky. The obvious way, which is what Equation (3.2) first suggests, would be to use the documents judged to be not relevant. However, we also know that (normally, for any reasonable query and any reasonable collection) the vast majority of documents are not relevant; those we have retrieved and judged are not only probably few in

thuộc tính liên quan, chúng tôi đang giả định rằng chúng tôi có một số đánh giá về mức độ liên quan. Trước tiên, chúng tôi tưởng tượng, một c ách phi thực tế, rằng chúng tôi có một mẫu ngẫu nhiên của toàn bộ tập hợp, vốn đã được đánh giá hoàn toàn về mức độ liên quan. Chúng tôi rút ra một ước lượng cũng sẽ hữu ích cho những trường hợp thực tế hơn.

Chúng tôi sử dụng ký hiệu sau:

N — Kích thước của mẫu được đánh gián_i — Số lượng tài liệu tr ong mẫu được đánh giá chứa $t_i R$ — Kích thước tập hợp liên quan (tức là số tài liệu được đánh giá là liên quan)r_i — Số tài liệu được đánh giá là liên quan chứa t_i

Dựa trên thông tin này, chúng tôi muốn ước lượng một cách phù hợp bốn xác suất cần thiết cho các trọng số được định nghĩa trong Phương trình (3.1). Ước lượng một cách tối đa hợp lý chuẩn của một xác suất từ các thí nghiệm là một tỉ số đơn giản, ví dụ, $P(t_i|\text{rel}) \approx \frac{r_i}{R}$. Tuy nhiên, đây không phải là một bộ ước lượng tốt để đưa vào công thức trọng số. Một lý do thực tiễn rất rõ ràng là sự kết hợp giữa tỉ số của các xác suất và hàm log có thể cho ra giá trị vô cực (dương hoặc âm) làm ước lượng. Thực tế, còn có những lý do lý thuyết tốt để điều chỉnh một chút các ước lượng tỉ số đơn giản này, như đã được thảo luận trong [44]„ nhằm có được một bộ ước lượng bền vững hơn, đưa vào một số đếm giả nhỏ là 0,5. Công thức kết quả là trọng số Robertson/Sprck Jones nổi tiếng:

$$w_i^{\text{RSJ}} = \log \frac{(r_i + 0.5)(N - R - n_i + r_i + 0.5)}{(n_i - r_i + 0.5)(R - r_i + 0.5)} \tag{3.2}$$

Tiếp theo, chúng ta giả sử rằng một số tài liệu, có lẽ là một số lượng nhỏ, đã được truy xuất và đánh giá – đây là kịch bản phản hồi liên quan thông thường. Trong trường hợp này, chúng ta có thể hợp lý ước lượng xác suất có điều kiện dựa trên mức độ liên quan (tích cực) theo cùng một các h, từ các tài liệu đã biết là có liên quan. Việc ước lượng xác suất có điều kiện dựa trên mức độ không liên quan thì khó hơn. Cách rõ ràng, mà Phương trình (3.2) đầu tiên gợi ý, sẽ là sử dụng các tài liệu được đánh giá l à không liên quan. Tuy nhiên, chúng ta cũng biết rằng (thông thường, đối với bất kỳ truy vấn hợp lý nào và bất kỳ bộ sưu tập hợp lý nào) phần lớn các tài liệu đều không liên quan; những tài liệu mà chúng ta đã truy xuất và đánh giá không chỉ có khả năng là ít

number, they are also likely to be a very non-typical set. We can make use of this knowledge to get a better estimate (at the risk of introducing a little bias) by assuming that any document not yet known to be relevant is non-relevant. This is known as the *complement* method. Under this assumption, the RSJ weighting formula defined above still applies, with the following redefinitions of N and n_i.

N — Size of the whole collection
n_i — Number of documents in the collection containing t_i

Experiments suggest that using this complement method gives better estimates than using judged documents only.

Finally, we suppose that we have no relevance information at all (the more usual scenario). In this case, we can only assume that the relevance probability $P(t_i|\text{rel})$ is fixed, but we can continue to use the complement method for the non-relevance probability — now we assume for this estimate that the entire collection is non-relevant. All this can be achieved by setting $R = r_i = 0$ in the RSJ formula (3.2) — this is equivalent to setting $P(t_i|\text{rel}) = 0.5$ (other values can be used [15]).

The resulting formula is a close approximation to classical *idf* (it can be made closer still by a slight modification of the model [47]):

$$w_i^{\text{IDF}} = \log \frac{N - n_i + 0.5}{n_i + 0.5} \tag{3.3}$$

3.2 Relevance Feedback and Query Expansion

The model thus far clearly contains a natural mechanism for relevance feedback — that is, for modifying the query based on relevance information. If we start with no relevance information, then we would weight the terms using the inverse document frequency (IDF) formula. Once the user makes some judgements of relevance, we should clearly reweight the terms according to the RSJ formula. But term reweighting is not in general an effective method for improving search. Additionally, we have to consider expanding the query by adding new terms.

At an early stage in the development of the basic model, rather than considering the entire vocabulary of terms in the estimation of

Về số lượng, chúng cũng có khả năng là một tập hợp rất không điển hình. Chúng ta có thể tận dụng kiến thức này để có được một ước lượng tốt hơn (mặc dù có nguy cơ đưa vào một chút thiên lệch) bằng cách giả sử rằng bất kỳ tài liệu nào chưa được biết là liên quan thì không liên quan. Điều này được gọi là phương pháp bù. Theo giả định này, công thức trọng số RSJ được định nghĩa ở trên vẫn áp dụng, với các định nghĩa lại sau đây của N và n_i.

N — Kích thước của toàn bộ bộ sưu tậpn_i — Số tài liệu trong bộ sưu tập chứa t_i

Các thí nghiệm cho thấy việc sử dụng phương pháp bổ sung này cho kết quả ước lượng tốt hơn so với chỉ sử dụng các tài liệu được đánh giá.

Cuối cùng, chúng ta giả sử rằng chúng ta hoàn toàn không có thông tin về sự liên quan (kịch bản phổ biến hơn). Trong trường hợp này, chúng ta chỉ có thể giả định rằng xác suất liên quan $P(t_i|\text{rel})$ là cố định, nhưng vẫn có thể tiếp tục sử dụng phương pháp bù trừ cho xác suất không liên quan — bây giờ chúng ta giả sử cho một ước tính này rằng toàn bộ tập hợp là không liên quan. Tất cả điều này có thể thực hiện bằng cách thiết lập $R = r_i = 0$ trong công thức RSJ (3.2) — điều này tương đương với việc thiết lập $P(t_i|\text{rel}) = 0.5$ (các giá trị khác có thể được sử dụng [15]).

Công thức thu được là một xấp xỉ gần với idf cổ điển (nó có thể được làm gần hơn nữa bằng một sửa đổi nhỏ của mô hình [47]):

$$w_i^{\text{IDF}} = \log \frac{N - n_i + 0.5}{n_i + 0.5} \tag{3.3}$$

3.2 Phản hồi liên quan và Mở rộng truy vấn

Mô hình cho đến nay rõ ràng chứa một cơ chế tự nhiên cho phản hồi liên quan — tức là, để sửa đổi truy vấn dựa trên thông tin liên quan. Nếu chúng ta bắt đầu mà không có thông tin liên quan, thì chúng ta sẽ đánh trọng số các thuật ngữ bằng công thức tần số ngược tài liệu (IDF). Khi người dùng đưa ra một số đánh giá về mức độ liên quan, chúng ta rõ ràng nên đánh trọng số lại các thuật ngữ theo công thức RSJ. Nhưng việc đánh trọng số lại thuật ngữ nói chung không phải là một phương pháp hiệu quả để cải thiện tìm kiếm. Ngoài ra, chúng ta còn phải xem xét mở rộng truy vấn bằng cách thêm các thuật ngữ mới.

Ở giai đoạn đầu trong việc phát triển mô hình cơ bản, thay vì xem xét toàn bộ từ vựng các thuật ngữ trong việc ước lượng của

probabilities, we restricted ourselves to query terms only. This was not because we assumed that non-query terms were incapable of giving us any useful information, but rather that in the absence of any evidence about either which terms might be useful, or how useful they might be, a reasonable neutral prior assumption was that all non-query terms had zero correlation with relevance.

However, in the relevance feedback scenario discussed above, we do indeed have some evidence for the inclusion of non-query terms. Potentially we can treat any term that occurs in any of the relevant documents as possibly useful. However, it is clear that many such terms will be noise, so we will probably need a conservative rule for adding new terms to the query.

For each candidate term (i.e., non-query term present in a document judged relevant) we can consider how useful it might be if added to the query. One measure of this is simply the RSJ weight as above. However, this will emphasise very rare terms (this is consistent with the IDF idea) — such terms may indeed be good evidence of relevance when they occur, but because they occur in so few documents, they will not have much overall effect on retrieval. As an alternative, we look for a measure of the possible overall effect of adding a term; we refer to this (following [53]) as an *offer weight*.

We could base an offer weight formula on a number of different models. One proposed in [41], to go with the binary independence model, is as follows. We look for terms that will maximally increase the *difference in average score* between relevant and non-relevant items. If we were to add term t_i to the query with weight w_i, then under the binary independence model (or indeed any additive term-weighting system based on term presence/absence only), it would increase the score of any document containing it by w_i. The scores of other documents would not be affected, so the increase in average score could be calculated from the probability of the presence of t_i. Thus the *difference* in average score between relevant and non-relevant documents would be

$$OW_i = (P(t_i|\text{rel}) - P(t_i|\overline{\text{rel}}))w_i \tag{3.4}$$

350 *Derived Models*

về xác suất, chúng tôi chỉ giới hạn bản thân vào các thuật ngữ truy vấn. Điều này không phải bởi vì chúng tôi cho rằng các thuật ngữ không phải truy vấn không thể cung cấp cho chúng tôi bất kỳ thông tin hữu ích nào, mà đúng hơn là trong trường hợp không có bất kỳ bằng chứng nào về việc thuật ngữ nào có thể hữu ích, hoặc chúng hữu ích đến mức nào, một giả định hợp lý trung lập trước là tất cả các thuật ngữ không phải truy vấn đều có mối tương quan bằng 0 với sự liên quan.

Tuy nhiên, trong kịch bản phản hồi liên quan được thảo luận ở trên, chúng ta thực sự có một số bằng chứng cho việc bao gồm các từ không có trong truy vấn. Có khả năng chúng ta có thể coi bất kỳ từ nào xuất hiện trong bất kỳ tài liệu liên quan nào là có thể hữu ích. Tuy nhiên, rõ ràng là nhiều từ như vậy sẽ là nhiễu, vì vậy chúng ta có lẽ cần một quy tắc thận trọng để thêm các từ mới vào truy vấn.

Đối với mỗi thuật ngữ ứng viên (tức là thuật ngữ không có trong truy vấn nhưng xuất hiện trong một tài liệu được đánh giá là liên quan), chúng ta có thể xem xét mức độ hữu ích của nó nếu được thêm vào truy vấn. Một cách đo l ường cho điều này đơn giản là trọng số RSJ như đã nêu ở trên. Tuy nhiên, điều này sẽ nhấn mạnh các thuật ngữ rất hiếm (điều này phù hợp với ý tưởng của IDF) — những thuật ngữ như vậy thực sự có thể là bằng chứng tốt về độ liên quan khi chúng xuất hiện, nhưng vì chúng xuất hiện trong rất ít tài liệu, chúng sẽ không ảnh hưởng nhiều đến việc truy xuất tổng thể. Như một phương án thay thế, chúng ta tìm kiếm một cách đo lường về tác động tổng thể có thể có khi thêm một thuật ngữ; chúng tôi gọi điều này (theo [53]) là trọng số đề xuất.

Chúng ta có thể dựa vào một công thức trọng số đề xuất trên nhiều mô hình khác nhau. Một mô hình được đề xuất trong [41], sử dụng mô hình độc lập nhị phân, được trình bày như sau. Chúng ta tì m các thuật ngữ sẽ làm tăng tối đa sự khác biệt trong điểm trung bình giữa các mục liên quan và không liên quan. Nếu chúng ta thêm thuật ngữ t_i vào truy vấn với trọng số w_i, thì theo mô hình độc lập nhị phân (hoặc thực sự bất kỳ hệ thống trọng số cộng dựa trên sự hiện diện/không hiện diện của thuật ngữ nào), nó sẽ làm tăng điểm của bất kỳ tài liệu nào chứa thuật ngữ đó lên w_i. Điểm số của các tài liệu khác sẽ không bị ảnh hưởng, vì vậy sự tăng điểm trung bình có thể được tính từ xác suất xuất hiện của t_i. Do đó, sự khác biệt trong điểm trung bình giữa các tài liệu liên quan và không liên quan sẽ là

$$OW_i = (P(t_i|\text{rel}) - P(t_i|\overline{\text{rel}}))w_i \tag{3.4}$$

(note that this is *not* the same as w_i itself). Further, an appropriate estimate of this quantity can be derived as follows:

$$\begin{aligned} OW_i^{\text{RSJ}} &\approx P(t_i|\text{rel})w_i \\ &\approx \frac{r_i}{R}w_i \\ &\propto_q r_i\ w_i^{\text{RSJ}} \end{aligned} \tag{3.5}$$

The first step approximates by ignoring the second probability (usually much smaller than the first); the second replaces the probability by the obvious estimate; and the third multiplies by R, which is constant for a given query.

The usual approach is to extract all terms from the relevant documents, rank them in order of offer weight by formula (3.5), and add only the top x terms from this ranked list (x may be of the order of 10).

This approach to query expansion was intended for the binary independence model and RSJ weighting, but has also been used with some success for BM25 (see Section 3.4 below). But it clearly has some limitations. As we add more and more terms to the query, we are likely to introduce synonyms or closely related words (indeed, this is why we do query expansion in the first place). However, in [36, 37] authors argue that this query expansion may worsen the term independence assumption; they propose an extension of the PRF model which attempts to correct this by taking into account some of the semantic structure of the query.

3.3 Blind Feedback

The same principles may be used in what is now known as pseudo-relevance or *blind feedback*. Here we assume that we have no actual relevance judgements, but we run an initial search on an initial version of the query (using only original query terms), take the top-ranked y documents (say 5 or 10), assume them to be relevant, and then follow the above relevance feedback procedures.

3.3 Blind Feedback 351

(lưu ý rằng điều này không giống như w_i tự nó). Hơn nữa, một ước lượng thích hợp của đại lượng này có thể được đưa ra như sau:

$$\begin{aligned} OW_i^{\text{RSJ}} &\approx P(t_i|\text{rel})w_i \\ &\approx \frac{r_i}{R}w_i \\ &\propto_q r_i\ w_i^{\text{RSJ}} \end{aligned} \tag{3.5}$$

Bước đầu tiên xấp xỉ bằng cách bỏ qua xác suất thứ hai (thường nhỏ hơn nhiều so với xác suất đầu tiên); bước thứ hai thay xác suất bằng ước lượng rõ ràng; và bước thứ ba nhân với R, vốn là hằng số cho một truy vấn nhất định.

Cách tiếp cận thông thường là trích xuất tất cả các thuật ngữ từ các tài liệu liên quan, xếp hạng chúng theo trọng số đề xuất bằng công thức (3.5), và chỉ thêm x thuật ngữ hàng đầu từ danh sách đã xếp hạng này (x có thể có thứ tự khoảng 10).

Phương pháp mở rộng truy vấn này được thiết kế cho mô hình độc lập nhị phân và trọng số RSJ, nhưng cũng đã được sử dụng với một số thành công cho BM25 (xem Mục 3.4 bên dưới). Tuy nhiên, rõ ràng nó có một số hạn chế. Khi chúng ta thêm ngày càng nhiều từ vào truy vấn, rất có khả năng chúng ta sẽ đưa vào các từ đồng nghĩa hoặc các từ có liên quan chặt chẽ (thực ra, đây là lý do tại sao chúng ta thực hiện mở rộng truy vấn ngay từ đầu). Tuy nhiên, trong [36, 37] các tác giả lập luận rằng mở rộng truy vấn này có thể làm trầm trọng thêm giả định độc lập giữa các từ; họ đề xuất một phần mở rộng của mô hình PRF nhằm cố gắng sửa điều này bằng cách xem xét một số cấu trúc ngữ nghĩa của truy vấn.

3.3 Phản hồi mù

Các nguyên tắc tương tự có thể được sử dụng trong những gì hiện nay được gọi là phản hồi mù hoặc pseudo-relevance. Ở đây chúng ta giả sử rằng chúng ta không có đánh giá thực sự về độ liên quan, nhưng chúng ta thực hiện một tìm kiếm ban đầu trên phiên bản ban đầu của truy vấn (chỉ sử dụng các từ truy vấn gốc), lấy các tài liệu xếp hạng cao nhất y (ví dụ 5 hoặc 10), giả sử chúng có liên quan, và sau đó làm theo các quy trình phản hồi liên quan nêu trên.

We note, however, the following:

1. Blind feedback is generally known to be capable of improving search results on average, but tends to fail on some queries, particularly on queries that are difficult to start with, where the top-ranked documents from the initial search may be poor.
2. The (true) relevance feedback procedure described above is in some sense correct in terms of the probabilistic model, on the assumption that the relevance judgements are good. In the blind feedback case, we have a set of documents whose relevance is (at best) likely rather than sure. It would be better to take account of the *probability* of relevance of each of these top-ranked documents, rather than simply assuming relevance. Such a method could be devised if we had a calibrated probability of relevance for each of these documents. However, the fact that we do not normally have such a calibrated probability in the present model, as discussed in Section 2.5, makes it more difficult to see how to accomplish this.

3.4 The Eliteness Model and BM25

We now re-introduce term frequencies into our model; this requires a model of how different term frequencies might arise in a document (this model is originally due to Harter [19]). We suppose that for any document-term pair, there is a hidden property which we refer to as *eliteness*. This can be interpreted as a form of aboutness: if the term is elite in the document, in some sense the document is *about* the concept denoted by the term. Now we assume that actual occurrences of the term in the document depend on eliteness, and that there may be an association between eliteness (to the term) and relevance (to the query). But we further assume that these relations are enough to explain the association between term frequency *tf* and relevance to the query — that is, given the two assumed dependencies, *tf* is independent of Rel. As before, we can illustrate the assumptions by means of a graphical model, as in Figure 3.1.

352 *Derived Models*

Tuy nhiên, chúng tôi lưu ý những điều sau:

1. Phản hồi mù thường được biết là có khả năng cải thiện kết quả tìm kiếm trung bình, nhưng có xu hướng thất bại với một số truy vấn, đặc biệt là với những truy vấn khó bắt đầu, nơi các tài liệu được xếp hạng hàng đầu từ tìm kiếm ban đầu có thể kém.

2. Thủ tục phản hồi liên quan (thật sự) được mô tả ở trên về một mặt nào đó là đúng theo mô hình xác suất, với giả định rằng các đánh giá liên quan là tốt. Trong trường hợp phản hồi mù, chúng ta có một tập hợp các tài liệu mà tính liên quan (tốt nhất) chỉ có khả năng thay vì chắc chắn. Sẽ tốt hơn nếu xem xét xác suất liên quan của từng tài liệu đứng đầu này, thay vì chỉ đơn giản giả định liên quan. Một phương pháp như vậy có thể được thiết kế nếu chúng ta có xác suất liên quan đã được hiệu chuẩn cho từng tài liệu này. Tuy nhiên, thực tế là chúng ta thường không có xác suất đã được hiệu chuẩn như vậy trong mô hình hiện tại, như đã thảo luận ở Mục 2.5, làm cho việc nhìn thấy cách thực hiện điều này trở nên khó khăn hơn.

3.4 Mô hình Eliteness và BM25

Chúng tôi bây giờ tái giới thiệu tần suất từ trong mô hình của mình; điều này yêu cầu một mô hình về cách mà các tần suất từ khác nhau có thể xuất hiện trong một tài liệu (mô hình này ban đầu là do Harter [19] đề xuất). Chúng tôi giả sử rằng đối với bất kỳ cặp tài liệu-từ nào, có một thuộc tính ẩn mà chúng tôi gọi là tính ưu tú. Điều này có thể được hiểu như một dạng về nội dung: nếu từ đó là ưu tú trong tài liệu, theo một cách nào đó, tài liệu đó nói về khái niệm được từ đó biểu thị. Bây giờ chúng tôi giả sử rằng sự xuất hiện thực tế của từ trong tài liệu phụ thuộc vào tính ưu tú, và có thể có một mối liên hệ giữa tính ưu tú (đối với từ) và sự liên quan (đối với truy vấn). Nhưng chúng tôi còn gi ả sử rằng những mối quan hệ này đủ để giải thích mối liên hệ giữa tầ n suất từ tf và sự liên quan đối với truy vấn — nghĩa là, dựa trên hai phụ thuộc giả định này, tf là độc lập với Rel. Như trước đây, chúng tôi có thể minh họa các giả định này bằng mô hình đồ họa, như trong Hình 3.1.

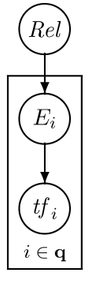


Fig. 3.1 Graphical model of eliteness (E).

We further assume that eliteness itself is binary.

The following development, using Harter's ideas in the context of the PRF, was originally proposed in part in [45] and in full (up to and including BM25) in [46].

3.4.1 The 2-Poisson Model

We introduce some new notation. The eliteness random variable E can take two values:

$$\text{Eliteness E:} \quad \text{elite}, \overline{\text{elite}} \quad \text{(elite, not elite)}$$

We now decompose all the probabilities we want using these two disjoint events, following this pattern:

$$P(\alpha\,|\,\beta) = P(\alpha\,|\,\text{elite})P(\text{elite}\,|\,\beta) + P(\alpha\,|\,\overline{\text{elite}})P(\overline{\text{elite}}\,|\,\beta)$$

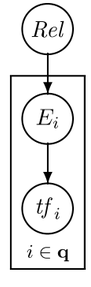
The relationship between eliteness and relevance is denoted thus:

$$p_{i1} := P(E_i = \text{elite}\,|\,\text{rel}); \quad p_{i0} := P(E_i = \text{elite}\,|\,\overline{\text{rel}})$$

The relationship between term frequencies and eliteness is denoted thus:

$$E_{i1}(tf) := P(TF_i = tf\,|\,E_i = \text{elite}); \quad E_{i0}(tf) := P(TF_i = tf\,|\,E_i = \overline{\text{elite}})$$

Now, following the above pattern, we arrive at expressions for all the probabilities we are interested in relating the observed tfs to relevance



Hình 3.1 Mô hình đồ họa của tính ưu tú (E).

Chúng tôi giả sử thêm rằng tính ưu tú tự nó là nhị phân.

Phát triển sau đây, sử dụng các ý tưởng của Harter trong bối cảnh của PRF, ban đầu được đề xuất một phần trong [45] và đầy đủ (bao gồm cả BM25) trong [46].

3.4.1 Mô hình Poisson-2

Chúng tôi giới thiệu một vài ký hiệu mới. Biến ngẫu nhiên eliteness E có thể nhận hai giá trị:

$$\text{Eliteness E:} \quad \text{elite}, \overline{\text{elite}} \quad \text{(elite, not elite)}$$

Chúng ta bây giờ phân tích tất cả các xác suất mà chúng ta muốn sử dụng hai sự kiện không giao nhau này, theo mô hình sau:

$$P(\alpha\,|\,\beta) = P(\alpha\,|\,\text{elite})P(\text{elite}\,|\,\beta) + P(\alpha\,|\,\overline{\text{elite}})P(\overline{\text{elite}}\,|\,\beta)$$

Mối quan hệ giữa tính ưu tú và tính liên quan được biểu thị như sau:

$$p_{i1} := P(E_i = \text{elite}\,|\,\text{rel}); \quad p_{i0} := P(E_i = \text{elite}\,|\,\overline{\text{rel}})$$

Mối quan hệ giữa tần số thuật ngữ và tính ưu tú được ký hiệu như sau:

$$E_{i1}(tf) := P(TF_i = tf\,|\,E_i = \text{elite}); \quad E_{i0}(tf) := P(TF_i = tf\,|\,E_i = \overline{\text{elite}})$$

Bây giờ, theo mô hình trên, chúng ta đi đến các biểu thức cho tất cả các xác suất mà chúng ta quan tâm đến việc liên hệ các tần số từ quan sát được với mức độ liên quan

like the following:

$$P(TF_i = tf \,|\, \text{rel}) = p_{i1}E_{i1}(tf) + (1 - p_{i1})E_{i0}(tf), \quad \text{etc.}$$

This gives us an equation for our term-weights:

$$w_i^{\text{elite}} = \log \frac{(p_1 E_1(tf) + (1 - p_1)E_0(tf))(p_0 E_1(0) + (1 - p_0)E_0(0))}{(p_1 E_1(0) + (1 - p_1)E_0(0))(p_0 E_1(tf) + (1 - p_0)E_0(tf))} \tag{3.6}$$

(for readability, we dropped the i subscript from all the elements in the fraction).

More specifically, we make distributional assumptions about these events. Again following Harter, we assume that the distributions of term frequencies across documents, conditioned on eliteness, are Poisson:

$$E_{ie}(tf) \sim \mathcal{P}(\lambda_{ie}) \quad \text{(Poisson with mean } \lambda_{ie}\text{)}, \tag{3.7}$$

where $e \in \{0,1\}$. In general, we expect $\lambda_{i1} > \lambda_{i0}$. Thus in the entire collection of documents, which is a mixture of elite and non-elite documents, *tf* is distributed as a mixture of two Poisson distributions — so that this model is known as the 2-Poisson model. The consequences of these distributional assumptions are analysed below.

The nature of the 2-Poisson model deserves further discussion. In Harter's original formulation, it was applied to abstracts rather than full-text documents, and indeed it can be said to assume that documents are of fixed length. We can interpret the model as follows. We assume that each document is generated by filling a certain number of word-positions (fixed length) from a vocabulary of words. Furthermore, we assume a simple multinomial distribution over words, so that for each position each word has a fixed (small) probability of being chosen, independent of what other words have been chosen for other positions. Then it follows that the distribution of *tf*s for a given word is binomial, which approximates to a Poisson under these conditions [16, VI.5].

Now the eliteness model can be seen as a simple topical model which causes variation in the unigram distributions. The author is assumed first to choose which topics to cover, i.e., which terms to treat as elite and which not. This defines specific probabilities for the unigram model,

như sau:

$$P(TF_i = tf \,|\, \text{rel}) = p_{i1}E_{i1}(tf) + (1 - p_{i1})E_{i0}(tf), \quad \text{etc.}$$

Điều này cho chúng ta một phương trình cho trọng số thuật ngữ của chúng ta:

$$w_i^{\text{elite}} = \log \frac{(p_1 E_1(tf) + (1 - p_1)E_0(tf))(p_0 E_1(0) + (1 - p_0)E_0(0))}{(p_1 E_1(0) + (1 - p_1)E_0(0))(p_0 E_1(tf) + (1 - p_0)E_0(tf))} \tag{3.6}$$

(để dễ đọc, chúng tôi đã bỏ chỉ số i khỏi tất cả các phần tử trong phân số).

Cụ thể hơn, chúng tôi đưa ra các giả định phân phối về những sự kiện này. Một lần nữa theo Harter, chúng tôi giả định rằng các phân phối tần suất từ ngữ trên các tài liệu, có điều kiện dựa trên tính ưu tú, là phân phối Poisson:

$$E_{ie}(tf) \sim \mathcal{P}(\lambda_{ie}) \quad \text{(Poisson with mean } \lambda_{ie}\text{)}, \tag{3.7}$$

nơi $e \in \{0,1\}$. Nói chung, chúng tôi mong đợi $\lambda_{i1} > \lambda_{i0}$. Do đó, trong toàn bộ tập hợp tài liệu, vốn là sự kết hợp của các tài liệu ưu tú và không ưu tú, tf được phân bố như một hỗn hợp của hai phân phối Poisson — vì vậy mô hình này được biết đến như mô hình 2-Poisson. Những hệ quả của các giả định phân phối này được phân tích bên dưới.

Bản chất của mô hình 2-Poisson đáng được thảo luận thêm. Trong công thức gốc của Harter, nó được áp dụng cho các bản tóm tắt thay vì các tài liệu toàn văn, và thực ra có thể nói rằng mô hình này giả định các tài liệu có độ dài cố định. Chúng ta có thể giải thích mô hình như sau. Chúng ta giả định rằng mỗi tài liệu được tạo ra bằng cách điền một số vị trí từ nhất định (độ dài cố định) từ một từ vựng. Hơn nữa, chúng ta giả định một phân phối đa thức đơn giản trên các từ, sao cho đối với mỗi vị trí, mỗi từ có một xác suất cố định (nhỏ) để được chọn, độc lập với những từ khác đã được chọn cho các vị trí khác. Sau đó, suy ra rằng phân phối tần suất từ (tf) đối với một từ nhất định là phân phối nhị thức, điều này xấp xỉ với phân phối Poisson trong những điều kiện này[16, VI.5].

Bây giờ mô hình tinh túy có thể được xem như một mô hình chủ đề đơn giản gây ra sự biến thiên trong các phân phối đơn ngữ. Giả sử tác giả đầu tiên chọn các chủ đề sẽ đề cập, tức là, chọn các thuật ngữ nào được coi là tinh túy và thuật ngữ nào không. Điều này xác định các xác suất cụ thể cho mô hình đơn ngữ,

and the author then fills the word-positions according to this chosen model.

This generative version of the 2-Poisson model (that is, a model for how documents are generated) ties it very closely with the language models and topical models discussed further in Sections 4.3 and 4.5.

We note the following characteristics of this model:

1. The model of topicality is a very simple one — one word one topic.
2. There is no attempt to normalise the probabilities across the full unigram model for the document.
3. The model depends fairly crucially on the notion that all documents are of the same (fixed) length.

We do not in the present survey attempt to do anything about the first two points — however, they do point forward to the more recent work on language models, discussed briefly below. Concerning the third point, the issue of document-length normalisation is critical to the present model, and is discussed in Section 3.4.5.

3.4.2 Saturation

If we plug the Poisson distributional assumptions into Equation (3.6), we can express the term weight as a function of the two means λ_e and the mixing proportion of elite and non-elite documents in the collection (as well as the observed tf). This is a somewhat messy formula, and furthermore we do not in general know the values of these three parameters, or have any easy way of estimating them. The next step in the development of the model was therefore to investigate the qualitative behaviour of the term-weighting function, under different conditions, in the hope of arriving at a much simpler expression which would capture its dominant behaviour [46].

Clearly its exact behaviour depends on the parameters, but some generalisations are possible. We note in particular that:

1. $w_i^{\text{elite}}(0) = 0$ (this is by design);
2. $w_i^{\text{elite}}(tf)$ increases monotonically with tf;

và sau đó tác giả sẽ điền các vị trí từ theo mô hình đã chọn này.

Phiên bản sinh học của mô hình 2-Poisson này (tức là, một mô hình về cách tài liệu được tạo ra) liên kết nó rất chặt chẽ với các mô hình ngôn ngữ và mô hình chủ đề được thảo luận thêm trong Các Mục 4.3 và 4.5.

Chúng tôi lưu ý các đặc điểm sau của mô hình này:

1. Mô hình về tính chủ đề là một mô hình rất đơn giản — một từ một chủ đề. 2. Không có nỗ lực nào để chuẩn hóa các xác suất trên toàn bộ mô hình đơn từ của tài liệu. 3. Mô hình phụ thuộc khá quan trọng vào khái niệm rằng tất cả các tài liệu đều có cùng độ dài (cố định).

Chúng tôi không cố gắng trong cuộc khảo sát hiện tại để làm bất cứ điều gì về hai điểm đầu tiên — tuy nhiên, chúng hướng tới các công trình gần đây hơn về mô hình ngôn ngữ, được thảo luận ngắn gọn bên dưới. Về điểm thứ ba, vấn đề chuẩn hóa độ dài tài liệu là quan trọng đối với mô hình hiện tại, và được thảo luận trong Mục 3.4.5.

3.4.2 Bão hòa

Nếu chúng ta thay các giả định phân phối Poisson vào Phương trình (3.6), chúng ta có thể biểu diễn trọng số của thuật ngữ như một hàm của hai giá trị trung bình λ_e và tỷ lệ pha trộn của các tài liệu ưu tú và không ưu tú trong bộ sưu tập (cũng như tf quan sát được). Đây là một công thức khá rắc rối, và hơn nữa, chúng ta nói chung không biết các giá trị của ba tham số này, hoặc có bất kỳ cách dễ dàng nào để ước lượng chúng. Bước tiếp theo trong việc phát triển mô hình là do đó nghiên cứu hành vi định tính của hàm trọng số thuật ngữ, dưới các điều kiện khác nhau, với hy vọng tìm được một biểu thức đơn giản hơn nhiều, có thể nắm bắt được hành vi chi phối của nó [46].

Rõ ràng hành vi chính xác của nó phụ thuộc vào các tham số, nhưng một số khái quát là có thể. Chúng tôi lưu ý đặc biệt rằng:

1. $w_i^{\text{elite}}(0) = 0$ (điều này là theo thiết kế); 2. $w_i^{\text{elite}}(tf)$ tăng đơn điệu theo tf;

3. … but asymptotically approaches a maximum value as $tf \to \infty$; and
4. the asymptotic limit being

$$\lim_{tf\to\infty} w_i^{\text{elite}}(tf) = \log \frac{p_1(1-p_0)}{(1-p_1)p_0} \tag{3.8}$$

$$= w_i^{\text{BIM}}. \tag{3.9}$$

This last formulation is the weight that the eliteness feature on its own would have. That is, if eliteness were observable, instead of being hidden, we could treat it like a simple binary attribute and weight it in exactly the same way as we weighted term presence in the binary independence model.

This asymptotic property makes perfect sense. Given (as we have assumed) that the only association between *tf* and relevance is via eliteness, the best information we can hope to get from a term is that the document is indeed elite for that term. In reality our information on this score is probabilistic, and thus the term weight is correspondingly reduced. Although this behaviour of the weighting function has been established only for the 2-Poisson case, it seems likely that *any* reasonable distributional assumptions would exhibit similar characteristics.

We refer to this behaviour as *saturation*. That is, any one term's contribution to the document score cannot exceed a saturation point (the asymptotic limit), however, frequently it occurs in the document. This turns out to be a very valuable property of the BM25 weighting function defined below.

3.4.3 A Special Case

There is one case in which the saturation limit does not apply. If we assume that the eliteness property for each query term coincides with relevance for the query/need, so that $p_{i1} = 1$ and $p_{i0} = 0$, then the limit is infinite, and the weight becomes linear in *tf*. Thus the commonly used term-weighting functions such as the traditional *tf*idf*, linear in *tf*, seem to fit with such a model. However, the non-linear, saturating function of *tf* developed below (also combined with an *idf* component) has frequently been shown to work better than traditional *tf*idf*.

356 *Derived Models*

3. ... nhưng tiệm cận đến một giá trị tối đa khi tf $\to \infty$; và

4. giới hạn tiệm cận là

$$\lim_{tf\to\infty} w_i^{\text{elite}}(tf) = \log \frac{p_1(1-p_0)}{(1-p_1)p_0} \tag{3.8}$$

$$= w_i^{\text{BIM}}. \tag{3.9}$$

Công thức cuối cùng này là trọng số mà đặc điểm tinh hoa tự nó sẽ có. Tức là, nếu tính tinh hoa có thể quan sát được, thay vì bị ẩn, chúng ta có thể xem nó như một thuộc tính nhị phân đơn giản và định trọng số cho nó theo cùng cách mà chúng ta đã định trọng số cho sự xuất hiện của từ trong mô hình độc lập nhị phân.

Tính chất tiệm cận này hoàn toàn hợp lý. Giả sử (như chúng ta đã giả định) rằng mối liên hệ duy nhất giữa tf và mức độ liên quan là thông qua tính ưu tú, thông tin tốt nhất mà chúng ta có thể hy vọng nhận được từ một từ là tài liệu thực sự ưu tú đối với từ đó. Trong thực tế, thông tin của chúng ta về điểm này mang tính xác suất, và do đó trọng số của từ tương ứng bị giảm. Mặc dù hành vi này của hàm trọng số chỉ được thiết lập cho trường hợp 2-Poisson, có vẻ hợp lý khi bất kỳ giả định phân phối nào cũng sẽ thể hiện các đặc điểm tương tự.

Chúng tôi gọi hành vi này là bão hòa. Nghĩa là, đóng góp của bất kỳ thuật ngữ nào vào điểm số của tài liệu không thể vượt quá một điểm bão hòa (giới hạn tiệm cận), bất kể thuật ngữ đó xuất hiện thường xuyên trong tài liệu. Điều này hóa ra là một thuộc tính rất quý giá của hàm trọng số BM25 được định nghĩa dưới đây.

3.4.3 Một Trường Hợp Đặc Biệt

Có một trường hợp mà giới hạn bão hòa không áp dụng. Nếu chúng ta giả sử rằng đặc tính tinh túy cho mỗi thuật ngữ truy vấn trùng khớp với độ liên quan đối với truy vấn/nhu cầu, sao cho $p_{i1} = 1$ và $p_{i0} = 0$, thì giới hạn là vô hạn, và trọng số trở nên tuyến tính theo tf. Do đó, c ác hàm trọng số thuật ngữ được sử dụng phổ biến như tf *idf truyền thống, tuyến tính theo tf, dường như phù hợp với mô hình như vậy. Tuy nhiên, hàm không tuyến tính, bão hòa của tf được phát triển dưới đây (cũng kết hợp với thành phần idf) đã thường xuyên được chứng minh là hoạt động tốt hơn tf *idf truyền thống.

3.4.4 BM25 Precursor

We investigate the shape of the saturation function a little more closely. It is clear that the properties listed above severely limit the possible functions; nevertheless, there remain many possibilities, as illustrated for example in the left-hand graph in Figure 3.2. However, the 2-Poisson model generates much smoother functions, as shown in the right-hand graph. For most realistic combinations of the parameters the curve is convex, as the top two lines; for some combinations it has an initial concavity, as the bottom line.

The next step in the development of BM25 is to approximate this shape. Lacking an appropriate generative corpus model from which to derive a convenient formula, the authors of BM25 decided to fit a simple parametric curve to this shape. The following one-parameter function was chosen:

$$\frac{tf}{k+tf} \quad \text{for some } k>0 \tag{3.10}$$

This function satisfies the properties listed above, and fits well the possible convex curves. We show values of this function for three different values of k in Figure 3.3; the middle line is for $k=1$, the upper line for lower k and the lower line for higher k. Note that because we apply this to all terms, the absolute height does not matter; what matters is the relative increments for different increments in tf. Thus for high k, increments in tf continue to contribute significantly to the score,

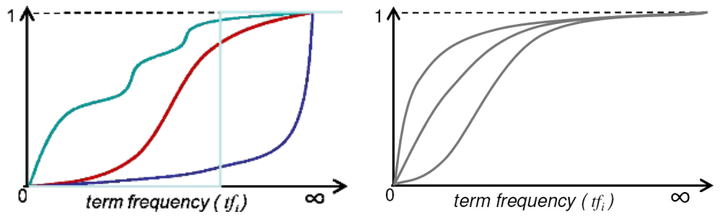


Fig. 3.2 *Left*: some possible saturation functions. *Right*: saturation functions generated by the 2-Poisson model.

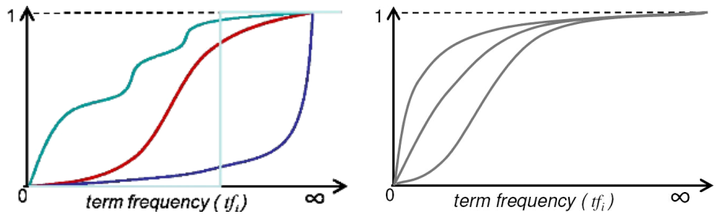
3.4.4 Tiền thân của BM25

Chúng tôi nghiên cứu hình dạng của hàm bão hòa một cách kỹ lưỡng hơn. Rõ ràng là các thuộc tính được liệt kê ở trên giới hạn nghiêm ngặt các hàm khả thi; tuy nhiên, vẫn còn nhiều khả năng, như minh họa trong đồ thị bên trái của Hình 3.2. Tuy nhiên, mô hình 2-Poisson tạo ra các hàm mượt hơn nhiều, như thể hiện trong đồ thị bên phải. Đối với hầu hết các kết hợp tham số thực tế, đường cong là lồi, như hai đường ở trên; đối với một số kết hợp, nó có độ lõm ban đầu, như đường ở dưới.

Bước tiếp theo trong việc phát triển BM25 là xấp xỉ hình dạng này. Do thiếu một mô hình ngữ liệu sinh thích hợp từ đó có thể suy ra một công thức tiện lợi, các tác giả của BM25 đã quyết định phù hợp một đường cong tham số đơn giản với hình dạng này. Hàm một tham số sau đây đã được chọn:

$$\frac{tf}{k+tf} \quad \text{for some } k>0 \tag{3.10}$$

Hàm này thỏa mãn các đặc tính được liệt kê ở trên và phù hợp tốt với các đường cong lồi có thể có. Chúng tôi hiển thị các giá trị của hà m này cho ba giá trị khác nhau của k trong Hình 3.3; đường giữa là cho $k=1$, đường trên là cho k thấp hơn và đường dưới là cho k cao hơn. Lưu ý rằng vì chúng tôi áp dụng điều này cho tất cả các hạng mục, chiều cao tuyệt đối không quan trọng; điều quan trọng là sự tă ng tương đối cho các gia tăng khác nhau trong tf. Do đó, đối với k cao, các gia tăng trong tf tiếp tục đóng góp đáng kể vào điểm số.



Hình 3.2 *Left*: một số hàm bão hòa có thể. *Right*: các hàm bão hòa được sinh bởi mô hình 2-Poisson.

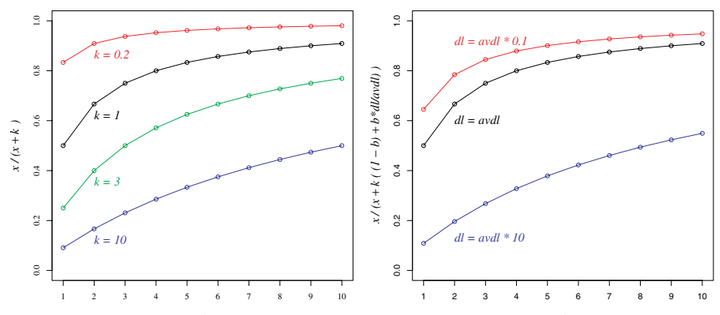


Fig. 3.3 Saturation functions generated by Equation (3.10) with raw frequencies (*left*) and with frequencies normalised using Equation (3.13) (*right*). Stronger saturation is obtained with lower values of k (*left*) and with shorter documents (*right*). For the plot on the right we used $k = 1$ and $b = 0.5$.

whereas for low k, the additional contribution of a newly observed occurrence tails off very rapidly.

We obtain an early version of BM25 by combining the saturation function of Equation (3.10) with an approximation to the asymptotic maximum of Equation (3.9). The latter is obtained by using the old RSJ presence–absence term weight of Equation (3.2):

$$w_i(tf) = \frac{tf}{k + tf}\, w_i^{\text{RSJ}} \tag{3.11}$$

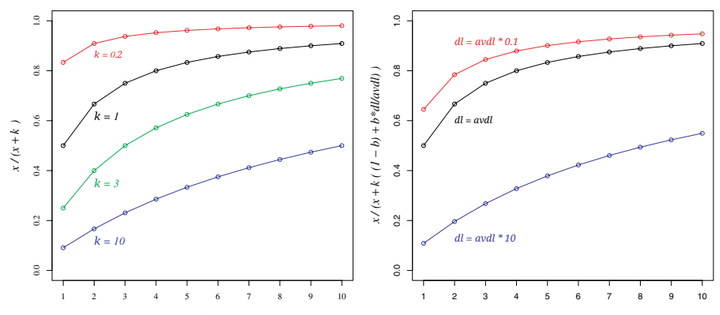
(We will modify this below for the final version of BM25.)

The main thing missing so far from the analysis is the question of document length.

3.4.5 Document Length

The fixed-document-length assumption was made to allow a connection between a simple language model and BM25; we imagined an author filling a fixed number of slots with a fixed unigram model. Now we imagine instead that the author also chooses a document length.

We suppose that there is something like a *standard* length for a document, but that an author may decide to make a document longer



Hình 3.3 Các hàm bão hòa được sinh ra bởi Phương trình (3.10) với tần số thô (*left*) và với tần số được chuẩn hóa bằng Phương trình (3.13) (*right*). Bão hòa mạnh hơn đạt được với giá trị k (*left*) thấp hơn và với các tài liệu ngắn hơn (*right*). Đối với biểu đồ bên phải, chúng tôi đã sử dụng $k = 1$ và $b = 0.5$.

trong khi đối với k thấp, đóng góp bổ sung của một sự kiện mới quan sát được giảm dần rất nhanh.

Chúng tôi thu được một phiên bản sớm của BM25 bằng cách kết hợp hàm bão hòa của Phương trình (3.10) với một xấp xỉ cực đại tiệm cận của Phương trình (3.9). Phương trình sau được thu được bằng cách sử dụng trọng số thuật ngữ hiện diện–vắng mặt RSJ cũ của Phương trình (3.2):

$$w_i(tf) = \frac{tf}{k + tf}\, w_i^{\text{RSJ}} \tag{3.11}$$

(Chúng tôi sẽ sửa đổi điều này bên dưới cho phiên bản cuối cùng của BM25.)

Điều chính còn thiếu cho đến nay trong phân tích là câu hỏi về độ dài của tài liệu.

3.4.5 Độ dài Tài liệu

Giả định về độ dài tài liệu cố định được đưa ra để cho phép kết nối giữa một mô hình ngôn ngữ đơn giản và BM25; chúng tôi tưởng tượng một tác giả điền vào một số chỗ cố định với một mô hình unigram cố định. Bây giờ chúng tôi tưởng tượng thay vào đó rằng tác giả cũng chọn độ dài tài liệu.

Chúng tôi giả sử rằng có điều gì đó giống như độ dài tiêu chuẩn cho một tài liệu, nhưng một tác giả có thể quyết định làm cho tài liệu dài hơn

or shorter; we consider only the longer case. Why might an author so decide? We can postulate two extreme cases:

Verbosity: Some authors are simply more verbose than others, using more words to say the same thing.

Scope: Some authors have more to say: they may write a single document containing or covering more ground. An extreme version would have the author writing two or more documents and concatenating them.

The verbosity hypothesis suggests that we should simply normalise any observed tfs by dividing by document length. The scope hypothesis, on the other hand, at least in its extreme version, suggests the opposite. In a real collection of documents we will observe variations in length, which might be due to either effect, or to a combination. We suppose in general a combination: that each hypothesis represents some partial explanation for the observed variation. This in turn suggests that we should apply some kind of soft normalisation.

We define document length in an obvious way:

$$\text{document length:} \quad dl := \sum_{i \in \mathbf{V}} tf_i$$

and also an average document length for the collection:

$$\text{average doclength:} \quad avdl \quad \text{(average over collection)}$$

The length normalisation component will be defined in relation to the average; this ensures that the definition of document length used is not critical. In practice, we could take (for example) the number of characters in the document, or the number of words before parsing, or even the number of unique terms, and still get very similar results.

The soft length normalisation component is:

$$B := \left((1-b) + b\frac{dl}{avdl}\right), \quad 0 \le b \le 1 \tag{3.12}$$

Thus setting $b = 1$ will perform full document-length normalisation, while $b = 0$ will switch normalisation off. Now we use B to normalise

hoặc ngắn hơn; chúng tôi chỉ xem xét trường hợp dài hơn. Tại sao một tác giả lại có thể quyết định như vậy? Chúng ta có thể đưa ra hai trường hợp cực đoan:

Dài dòng: Một số tác giả đơn giản là dài dòng hơn những người khác, sử dụng nhiều từ hơn để nói cùng một điều. Phạm vi: Một số tác giả có nhiều điều để nói hơn: họ có thể viết một tài liệu duy nhất bao quát nhiều nội dung hơn. Một phiên bản cực đoan sẽ là tác giả viết hai hoặc nhiều tài liệu và ghép chúng lại với nhau.

Giả thuyết dài dòng gợi ý rằng chúng ta nên đơn giản chuẩn hóa bất kỳ t ần suất từ quan sát được nào bằng cách chia cho độ dài của tài liệu. Ngược lại, giả thuyết phạm vi, ít nhất là trong phiên bản cực đoan của nó, lại gợi ý điều ngược lại. Trong một tập hợp tài liệu thực tế, chúng ta sẽ quan sát thấy sự khác biệt về độ dài, điều này có thể do một trong hai hiệu ứng, hoặc do sự kết hợp của cả hai. Chúng ta giả sử nói chung là sự kết hợp: rằng mỗi giả thuyết đại diện cho một số giải thích phần nào cho sự biến đổi quan sát được. Điều này lại gợi ý rằng chúng ta nên áp dụng một loại chuẩn hóa mềm.

Chúng tôi định nghĩa độ dài tài liệu theo một cách rõ ràng:

$$\text{document length:} \quad dl := \sum_{i \in \mathbf{V}} tf_i$$

và cũng là độ dài trung bình của tài liệu cho bộ sưu tập:

$$\text{average doclength:} \quad avdl \quad \text{(average over collection)}$$

Thành phần chuẩn hóa độ dài sẽ được xác định liên quan đến giá trị trung bình; điều này đảm bảo rằng định nghĩa về độ dài tài liệu được sử dụng không quan trọng. Trong thực tế, chúng ta có thể lấy (ví dụ) số lượng ký tự trong tài liệu, hoặc số lượng từ trước khi phân tích cú pháp, hoặc thậm chí số lượng thuật ngữ duy nhất, và vẫn có được kết quả rất giống nhau.

Thành phần chuẩn hóa độ dài mềm là:

$$B := \left((1-b) + b\frac{dl}{avdl}\right), \quad 0 \le b \le 1 \tag{3.12}$$

Vì vậy, thiết lập $b = 1$ sẽ thực hiện chuẩn hóa toàn bộ độ dài tài liệu, trong khi $b = 0$ sẽ tắt chuẩn hóa. Bây giờ chúng ta sử dụng B để chuẩn hóa

tf, before applying the saturation function, as follows:

$$tf' = \frac{tf}{B} \tag{3.13}$$

$$w_i^{\text{BM25}}(tf) = \frac{tf'}{k_1 + tf'}\, w_i^{\text{RSJ}} \tag{3.14}$$

$$= \frac{tf}{k_1\left((1-b) + b\frac{dl}{avdl}\right) + tf}\, w_i^{\text{RSJ}} \tag{3.15}$$

This is the classic BM25 term-weighting and document-scoring function. As with all term-document weights defined in this survey, the full document score is obtained by summing these term-weights over the (original or expanded) set of query terms.

3.5 Uses of BM25

In order to use BM25 as a ranking function for retrieval, we need to choose values for the internal parameters b and k_1, and also instantiate RSJ.

Concerning the RSJ weight (Equation (3.2)), all the previous comments apply. In particular, it can be used with or without relevance information. In the absence of relevance information, it reduces as before to a form of idf. In this case, the BM25 weight looks very much like a traditional $tf{*}idf$ weight — a product of two components, one based on tf and one on idf. However, there is one significant difference. The tf component involves the saturation function discussed, and is therefore somewhat unlike most other tf functions seen in the literature, where common choices are tf itself and $(1 + \log tf)$. The latter has a somewhat similar shape curve, but does not have an asymptotic maximum — it goes to infinity, even if somewhat slower than tf itself.

Concerning the internal parameters, the model provides no guidance on how these should be set. This may be regarded as a limitation of the model. However, it provides an opportunity for optimisation, given some evaluated set of queries and relevance judgements in the traditional retrieval experiment style. A significant number of such experiments have been done, and suggest that in general values such as $0.5 < b < 0.8$ and $1.2 < k_1 < 2$ are reasonably good in many

360 *Derived Models*

tf, trước khi áp dụng hàm bão hòa, như sau:

$$tf' = \frac{tf}{B} \tag{3.13}$$

$$w_i^{\text{BM25}}(tf) = \frac{tf'}{k_1 + tf'}\, w_i^{\text{RSJ}} \tag{3.14}$$

$$= \frac{tf}{k_1\left((1-b) + b\frac{dl}{avdl}\right) + tf}\, w_i^{\text{RSJ}} \tag{3.15}$$

Đây là chức năng điểm tài liệu và trọng số thuật ngữ BM25 cổ điển. Giống như tất cả các trọng số thuật ngữ-tài liệu được định nghĩa trong khảo sát này, điểm tài liệu đầy đủ được tính bằng cách cộng các trọng số thuật ngữ này trên tập các thuật ngữ truy vấn (gốc hoặc mở rộng).

3.5 Các ứng dụng của BM25

Để sử dụng BM25 như một hàm xếp hạng cho truy xuất, chúng ta cần chọn các giá trị cho các tham số nội bộ b và k_1, và cũng cần khởi tạo RSJ.

Về trọng số RSJ (Phương trình (3.2)), tất cả các nhận xét trước đó đều áp dụng. Cụ thể, nó có thể được sử dụng có hoặc không có thông tin liên quan. Trong trường hợp không có thông tin liên quan, nó giả m như trước thành một dạng của idf. Trong trường hợp này, trọng số BM25 trông rất giống với trọng số tf–idf truyền thống — một tích của hai thành phần, một dựa trên tf và một dựa trên idf. Tuy nhiên, có một khác biệt quan trọng. Thành phần tf liên quan đến hàm bão hòa đã được thảo luận, và do đó hơi khác so với hầu hết các hàm tf khác được thấy trong văn liệu, nơi các lựa chọn phổ biến là tf chính nó và (log tf). Hình dạng sau có phần giống, nhưng không có giá trị cực đại tiệm cận — nó tiến tới vô cùng, mặc dù chậm hơn tf chính nó.

Về các tham số nội bộ, mô hình không cung cấp hướng dẫn về cách thiết lập chúng. Điều này có thể được coi là một hạn chế của mô hình. Tuy nhiên, nó cung cấp cơ hội để tối ưu hóa, dựa trên một tập hợp các truy vấn đã được đánh giá và các đánh giá liên quan theo phong cách thí nghiệm truy xuất truyền thống. Một số lượng đáng kể các thí nghiệm như vậy đã được thực hiện, và cho thấy rằng nói c hung các giá trị như $0.5 < b < 0.8$ và $1.2 < k_1 < 2$ là khá tốt trong nhiều

circumstances. However, there is also evidence that optimal values do depend on other factors (such as the type of documents or queries).

3.5.1 Some Variations on BM25

Published versions of BM25 can vary somewhat (the original BM25 [46] was a little more complicated than that of Equation (3.15), for example). Here we indicate some differences that might be encountered in different versions of the function in published sources.

- The original had a component for within-query term frequency qtf, for longer queries where a term might occur multiple times. In its full generality, this had a similar saturation function to that used for tf, but with its own k_3 constant. However, experiments suggested that the saturation effect for qtf was unimportant, leading to a formula which was linear in qtf. In other words, one could simply treat multiple occurrences of a term in the query as different terms.
- The original also had a further correction for document length, to the total document score. This correction was again found to be unimportant.
- A common variant is to add a $(k_1 + 1)$ component to the numerator of the saturation function. This is the same for all terms, and therefore does not affect the ranking produced. The reason for including it was to make the final formula more compatible with the RSJ weight used on its own. If it is included, then a single occurrence of a term would have the same weight in both schemes.
- Some published versions are based on specific values assigned to b and k_1. A common combination would be $b = 0.5$ and $k_1 = 2$. (However, many experiments suggest a somewhat lower value of k_1 and a somewhat higher value of b.)

3.6 Multiple Streams and BM25F

So far, all the arguments in this survey have been based on the idea that the document is a single body of text, unstructured and undifferentiated

tình huống. Tuy nhiên, cũng có bằng chứng cho thấy các giá trị tối ưu phụ thuộc vào các yếu tố khác (chẳng hạn như loại tài liệu hoặc truy vấn).

3.5.1 Một số Biến thể trên BM25

Các phiên bản BM25 được công bố có thể khác nhau đôi chút (BM25 gốc [46] hơi phức tạp hơn so với phương trình (3.15), ví dụ). Ở đây chúng tôi chỉ ra một số khác biệt có thể gặp trong các phiên bản khác nhau của hàm trong các nguồn đã được công bố.

- Bản gốc có một thành phần cho tần số thuật ngữ trong truy vấn qtf, cho các truy vấn dài hơn nơi một thuật ngữ có thể xuất hiện nhiều lần. Theo tính tổng quát đầy đủ của nó, điều này có một hàm bão hòa tương tự như được sử dụng cho tf, nhưng với k_3 hằng số riêng của nó. Tuy nhiên, các thí nghiệm cho thấy hiệu ứng bão hòa đối với qtf không quan trọng, dẫn đến một công t hức tuyến tính theo qtf. Nói cách khác, người ta có thể đơn giản coi nhiều lần xuất hiện của một thuật ngữ trong truy vấn như các thuật ngữ khác nhau.
- Bản gốc cũng có một chỉnh sửa thêm cho độ dài tài liệu, đối với tổng điểm của tài liệu. Chỉnh sửa này một lần nữa được phát hiện là không quan trọng.
- Một biến thể phổ biến là thêm một thành phần ($k_1 + 1$) vào tử số của hàm bão hòa. Điều này giống nhau cho tất cả các hạng mục, vì vậy không ảnh hưởng đến thứ hạng được tạo ra. Lý do bao gồm nó là để làm cho công thức cuối cùng tương thích hơn với trọng số RSJ được sử dụng riêng. Nếu được bao gồm, thì một lần xuất hiện duy nhất của một hạng mục sẽ có cùng trọng số trong cả hai sơ đồ.
- Một số phiên bản đã xuất bản được dựa trên các giá trị cụ thể được gán cho b và k_1. Một sự kết hợp phổ biến sẽ là $b = 0.5$ và $k_1 = 2$. (Tuy nhiên, nhiều thí nghiệm cho thấy giá trị của k_1 hơi thấp hơn và giá trị của b hơi cao hơn.)

3.6 Nhiều luồng và BM25F

Cho đến nay, tất cả các lập luận trong khảo sát này đều dựa trên ý tưởng rằng tài liệu là một khối văn bản duy nhất, không có cấu trúc và không phân biệt.

in any way. However, it is commonplace in search systems to assume at least some minimal structure to documents. In this section we consider documents which are structured into a set of *fields* or *streams*. The assumption is that there is a single flat stream structure, common to all documents. That is, there is a global set of labelled streams, and the text of each document is split between these streams. An obvious example is a title/abstract/body structure such as one might see in scientific papers. In the Web context, with extensive hyperlinks, it is usual to enhance the original texts with the *anchor text* of incoming links.

This is clearly a very minimal kind of structure; one can imagine many document structures that do not fit into this framework. Nevertheless, such minimal structures have proved useful in search. The general idea, not at all confined to the present framework but implemented in many different ways in different systems, is that some streams may be more predictive of relevance than others. In the above examples, a query match on the title might be expected to provide stronger evidence of possible relevance than an equivalent match on the body text. It is now well known in the Web context that matching on anchor text is a very strong signal.

3.6.1 Basic Idea

Given a ranking algorithm or function that can be applied to a piece of undifferentiated text, an obvious practical approach to such a stream structure would be to apply the function separately to each stream, and then combine these in some linear combination (with stream weights) for the final document score. In terms of the eliteness model, this approach may be regarded as assuming a separate eliteness property for each term/stream pair. Thus for a given term, eliteness in title would be assumed to be a different property from eliteness in body. Actually, the assumption would be even stronger: we would have to apply the usual assumptions of independence (given relevance) between these distinct eliteness properties for the same term.

This seems a little unreasonable — a better assumption might be that eliteness is a term/document property, shared across the streams of the document. We would then postulate that the relationship of

bằng bất kỳ cách nào. Tuy nhiên, trong các hệ thống tìm kiếm, việc giả định ít nhất một cấu trúc tối thiểu cho các tài liệu là điều phổ biến. Trong phần này, chúng tôi xem xét các tài liệu được cấu trúc thành một tập hợp các trường hoặc luồng. Giả định là có một cấu trúc luồng phẳng duy nhất, chung cho tất cả các tài liệu. Tức là, có một tập hợp toàn cục các luồng có nhãn, và văn bản của mỗi tài liệu được chia giữa các luồng này. Một ví dụ rõ ràng là cấu trúc tiêu đề/tóm tắt/nội dung chính mà người ta có thể thấy trong các bài báo khoa học. Trong bối cảnh Web, với các liên kết siêu văn bản rộng rãi, thường thì văn bản gốc được bổ sung bằng văn bản neo của các liên kết đến.

Đây rõ ràng là một kiểu cấu trúc rất tối thiểu; người ta có thể tưởng tượng ra nhiều cấu trúc tài liệu không phù hợp với khuôn khổ này. Tuy nhiên, những cấu trúc tối thiểu như vậy đã chứng tỏ hữu ích trong việc tìm kiếm. Ý tưởng chung, không hề bị hạn chế trong khuôn khổ hiện tại nhưng được triển khai một cách khác nhau trong nhiều hệ thống khác nhau, là một số luồng thông tin có thể dự đoán tính liên quan tốt hơn những luồng khác. Trong các ví dụ trên, một kết quả t ruy vấn khớp với tiêu đề có thể được kỳ vọng cung cấp bằng chứng mạnh mẽ hơn về khả năng liên quan so với một kết quả khớp tương đương trên nội dung chính. Hiện nay đã được biết rõ trong bối cảnh Web rằng việc khớp với văn bản neo là một tín hiệu rất mạnh.

3.6.1 Ý tưởng cơ bản

Được cho một thuật toán hoặc hàm xếp hạng có thể được áp dụng cho một đoạn văn bản không phân biệt, một cách tiếp cận thực tiễn rõ ràng với cấu trúc luồng như vậy là áp dụng hàm này riêng biệt cho từng luồng, và sau đó kết hợp chúng trong một số tổ hợp tuyến tính (với trọng số luồng) để có điểm tài liệu cuối cùng. Về mô hình tính ưu tú, cách tiếp cận này có thể được xem như giả định một thuộc tính ưu tú riêng cho từng cặp thuật ngữ/luồng. Do đó, đối với một thuật ngữ nhất định, tính ưu tú trong tiêu đề sẽ được giả định là một thuộc tính khác so với tính ưu tú trong phần nội dung. Thực ra, giả định sẽ còn mạnh mẽ hơn: chúng ta sẽ phải áp dụng các giả định thông thường về độc lập (dựa trên mức độ liên quan) giữa các thuộc tính ưu tú riêng biệt này cho cùng một thuật ngữ.

Điều này có vẻ hơi phi lý — một giả định tốt hơn có thể là tính ưu tú là một thuộc tính/thuộc tính tài liệu, được chia sẻ qua các luồng của tài liệu. Chúng ta sau đó sẽ giả thuyết rằng mối quan hệ của

eliteness to term frequency is stream-specific. In terms of the underlying language model discussed above, we might imagine that the author chooses a length for (say) the title and another for the body. Then, given eliteness (from the author's choice of topics to cover), the unigram probabilities for the language model for filling the term-positions would also be stream-specific. In particular, there would be a much stronger bias to the elite terms when choosing words for the title than for the body (we expect a title to be much denser in topic-specific terms than an average body sentence).

The consequence of this term-document eliteness property is that we should combine evidence across terms and streams in the opposite order to that suggested above: first streams, then terms. That is, for each term, we should accumulate evidence for eliteness across all the streams. The saturation function should be applied at this stage, to the total evidence for each term. Then the final document score should be derived by combination across the terms.

3.6.2 Notation

We have a set of S streams, and we wish to assign relative weights v_s to them. For a given document, each stream has its associated length (the total length of the document would normally be the sum of the stream lengths). Each term in the document may occur in any of the streams, with any frequency; the total across streams of these term–stream frequencies would be the usual term-document frequency. The entire document becomes a vector of vectors.

streams	$s = 1, \ldots, S$	
stream lengths	sl_s	
stream weights	v_s	
document	$(\mathbf{tf}_1, \ldots, \mathbf{tf}_{\lvert\mathbf{V}\rvert})$	vector of vectors
$\mathbf{tf}_i$ vector	$(tf_{1i}, \ldots, tf_{Si})$	

where tf_{si} is the frequency of term i in stream s.

3.6.3 BM25F

The simplest extension of BM25 to weighted streams is to calculate a weighted variant of the total term frequency. This also implies having

Sự tinh túy đối với tần suất từ là đặc thù theo luồng. Về mô hình ngôn ngữ cơ bản đã được thảo luận ở trên, chúng ta có thể tưởng tượng rằng tác giả chọn độ dài cho (ví dụ) tiêu đề và một độ dài khác cho phần nội dung. Sau đó, dựa trên sự tinh túy (từ sự lựa chọn chủ đề mà tác giả muốn trình bày), xác suất unigram cho mô hình ngôn ngữ để điền vào các vị trí từ cũng sẽ đặc thù theo luồng. Cụ thể, sẽ có một xu hướng mạnh hơn đối với các từ tinh túy khi chọn từ cho tiêu đề so với phần nội dung (chúng ta kỳ vọng rằng tiêu đề sẽ đặc hơn về các từ chuyên đề so với một câu bình thường trong phần nội dung).

Hệ quả của thuộc tính tinh túy theo thuật ngữ-tài liệu này là chúng ta nên kết hợp bằng chứng giữa các thuật ngữ và luồng theo t hứ tự ngược lại so với đề xuất ở trên: trước tiên là các luồng, sau đó là các thuật ngữ. Tức là, đối với mỗi thuật ngữ, chúng ta nên tích lũy bằng chứng về tính tinh túy qua tất cả các luồng. Hàm bão hòa nên được áp dụng ở giai đoạn này, cho tổng bằng chứng của mỗi thuật ngữ. Sau đó, điểm tài liệu cuối cùng nên được xác định bằng cách kết hợp giữa các thuật ngữ.

3.6.2 Ký hiệu

Chúng tôi có một tập hợp S luồng, và chúng tôi muốn gán trọng số tương đối v_s cho chúng. Đối với một tài liệu nhất định, mỗi luồng có độ dài liên quan của nó (tổng độ dài của tài liệu thường là tổng của c ác độ dài luồng). Mỗi từ trong tài liệu có thể xuất hiện trong bất kỳ luồng nào, với bất kỳ tần suất nào; tổng tần suất từ–luồng này trên tất cả các luồng sẽ là tần suất một từ trong tài liệu thông thường. Toàn bộ tài liệu trở thành một vector của các vector.

các luồng	$s = 1, \ldots, S$	
độ dài luồng	sl_s	
trọng số luồng	v_s	
tài liệu	$(\mathrm{tf}1, \ldots, \mathrm{tf}\lvert V\rvert)$	vector của các vector
tf_i vector	$(\mathrm{tf}_{1i}, \ldots, \mathrm{tf}_{Si})$	

nơi tf_{si} là tần suất của từ i trong luồng s.

3.6.3 BM25F

Sự mở rộng đơn giản nhất của BM25 sang các luồng có trọng số là tính toán một biến thể có trọng số của tần số thuật ngữ tổng thể. Điều này cũng ngụ ý việc có

a similarly weighted variant of the total document length:

$$\widetilde{tf}_i = \sum_{s=1}^{S} v_s \, tf_{si} \tag{3.16}$$

$$\widetilde{dl} = \sum_{s=1}^{S} v_s \, sl_s \tag{3.17}$$

$$\widetilde{avdl} = \text{average of } \widetilde{dl} \text{ across documents}$$

$$w_i^{\text{simpleBM25F}} = \frac{\widetilde{tf}_i}{k_1 \left((1-b) + b \frac{\widetilde{dl}}{\widetilde{avdl}} \right) + \widetilde{tf}_i} \, w_i^{\text{RSJ}} \tag{3.18}$$

However, we may also want to allow the parameters of BM25 to vary between streams — it may be that the different streams have different characteristics, e.g., in relation to verbosity *v.* scope (as defined in Section 3.4.5). It is in fact possible to re-arrange formula (3.15) so as to include any of the following in the stream-specific part: k_1, b, w_i^{RSJ} or its non-feedback version w_i^{IDF}. We have in particular found it useful to allow b to be stream-specific; we present here the appropriate version of BM25F:

$$\widetilde{tf}_i = \sum_{s=1}^{S} v_s \frac{tf_{si}}{B_s} \tag{3.19}$$

$$B_s = \left((1-b_s) + b_s \frac{sl_s}{avsl_s} \right), \quad 0 \le b_s \le 1 \tag{3.20}$$

$$w_i^{\text{BM25F}} = \frac{\widetilde{tf}_i}{k_1 + \widetilde{tf}_i} \, w_i^{\text{RSJ}} \tag{3.21}$$

This version was used in [62]; the simple version in [50]. As usual, in the absence of relevance feedback information, w_i^{RSJ} should be replaced by w_i^{IDF}. In [50, 62] we computed IDFs on the entire collection disregarding streams. This worked well in practice, but it can lead to degenerate cases (e.g., when a stream is extremely verbose and contains most terms for most documents). The proper definition of IDF in this context requires further research (this is also discussed in [37] where the notion of an *expected idf* is introduced).

một biến thể có trọng số tương tự của tổng chiều dài tài liệu:

$$\widetilde{tf}_i = \sum_{s=1}^{S} v_s \, tf_{si} \tag{3.16}$$

$$\widetilde{dl} = \sum_{s=1}^{S} v_s \, sl_s \tag{3.17}$$

$$\widetilde{avdl} = \text{average of } \widetilde{dl} \text{ across documents}$$

$$w_i^{\text{simpleBM25F}} = \frac{\widetilde{tf}_i}{k_1 \left((1-b) + b \frac{\widetilde{dl}}{\widetilde{avdl}} \right) + \widetilde{tf}_i} \, w_i^{\text{RSJ}} \tag{3.18}$$

Tuy nhiên, chúng ta cũng có thể muốn cho phép các tham số của BM25 thay đổi giữa các luồng — có thể các luồng khác nhau có các đặc điểm khác nhau, ví dụ, liên quan đến mức độ dài dòng so với phạm vi (như được định nghĩa trong Mục 3.4.5). Thực tế có thể sắp xếp lại công t hức (3.15) để bao gồm bất kỳ yếu tố nào sau đây trong phần riêng của t ừng luồng: k_1, b, w_i^{RSJ} hoặc phiên bản không phản hồi của nó w_i^{IDF}. Chúng tôi đặc biệt thấy hữu ích khi cho phép b là riêng của từng luồng; ở đây chúng tôi trình bày phiên bản BM25F phù hợp:

$$\widetilde{tf}_i = \sum_{s=1}^{S} v_s \frac{tf_{si}}{B_s} \tag{3.19}$$

$$B_s = \left((1-b_s) + b_s \frac{sl_s}{avsl_s} \right), \quad 0 \le b_s \le 1 \tag{3.20}$$

$$w_i^{\text{BM25F}} = \frac{\widetilde{tf}_i}{k_1 + \widetilde{tf}_i} \, w_i^{\text{RSJ}} \tag{3.21}$$

Phiên bản này đã được sử dụng trong [62]; phiên bản đơn giản trong [50]. Như thường lệ, trong trường hợp không có thông tin phản hồi li ên quan, w_i^{RSJ} nên được thay bằng w_i^{IDF}. Trong [50, 62] chúng tôi đã tính toán IDF trên toàn bộ tập hợp mà không quan tâm đến các luồng. Điều này hoạt động tốt trong thực tế, nhưng có thể dẫn đến các tr ường hợp thoái hóa (ví dụ, khi một luồng cực kỳ dài dòng và chứa hầu hết các thuật ngữ cho hầu hết các tài liệu). Định nghĩa chính xác của IDF trong bối cảnh này cần được nghiên cứu thêm (điều này cũng được thảo luận trong [37] nơi khái niệm idf dự kiến được giới thiệu).

Table 3.1. BM25F parameters reported in [62] for topic distillation (TD) and name page (NP) search tasks

Parameter	TD'03	NP'03
k_1	27.5	4.9
b_{title}	0.95	0.6
b_{body}	0.7	0.5
b_{anchor}	0.6	0.6
v_{title}	38.4	13.5
v_{body}	1.0	1.0
v_{anchor}	35	11.5

As an illustration, we report in Table 3.1 the BM25Fweights reported in [62] for the 2003 TREC Web Search tasks.

3.6.4 Interpretation of the Simple Version

It is worth mentioning a very transparent interpretation of the simple version — although it does not apply directly to the version with variable b, it may give some insight. If the stream weights v_s are integers, then we can see the simple BM25F formula as an ordinary BM25 function applied to a document in which some of the streams have been replicated. For example, if the streams and weights are $\{v_{\text{title}} = 5, v_{\text{abstract}} = 2, v_{\text{body}} = 1\}$, then formula 3.18 is equivalent to 3.15 applied to a document in which the title has been replicated five times and the abstract twice.

3.7 Non-Textual Relevance Features

In many collections there are other sources of relevance information besides the text. Things like the age of a file, its type or its link in-degree may provide useful information about the relevance of a document. The development of the PRF is quite general and does not make explicit reference to terms or text; it is therefore possible, at least in principle, to take non-textual features into account.

We will make two assumptions here about non-textual features. First we make the usual assumption of feature independence with respect to relevance odds (as discussed in Section 2). Second, we will assume that all non-textual features provide relevance information

Bảng 3.1. Các tham số BM25F được báo cáo trong [62] cho các nhiệm vụ tìm kiếm chiết xuất chủ đề (TD) và trang tên (NP)

Tham số	TD'03	NP'03
k_1	27.5	4.9
b_{title}	0.95	0.6
b_{body}	0.7	0.5
b_{anchor}	0.6	0.6
v_{title}	38.4	13.5
v_{body}	1.0	1.0
v_{anchor}	35	11.5

Như một minh họa, chúng tôi báo cáo trong Bảng 3.1 các trọng số BM25F được báo cáo trong [62] cho các nhiệm vụ TRECWebSearch năm 2003.

3.6.4 Giải thích Phiên bản Đơn giản

Đáng nhắc đến một cách giải thích rất minh bạch của phiên bản đơn giản — mặc dù nó không áp dụng trực tiếp cho phiên bản với biến b, nhưng nó có thể cung cấp một số cái nhìn sâu sắc. Nếu các trọng số luồng v_s là số nguyên, thì chúng ta có thể xem công thức BM25F đơn giản như một hàm BM25 thông thường áp dụng cho một tài liệu trong đó một số luồng đã được nhân bản. Ví dụ, nếu các luồng và trọng số là $\{v_{\text{title}} = 5, v_{\text{abstract}} = 2, v_{\text{body}} = 1\}$, thì công thức 3.18 tương đương với 3.15 áp dụng cho một tài liệu trong đó tiêu đề đã được nhân bản năm lần và tóm tắt hai lần.

3.7 Các tính năng liên quan phi văn bản

Trong nhiều bộ sưu tập, có những nguồn thông tin liên quan khác ngoài văn bản. Những thứ như tuổi của một tập tin, loại của nó hoặc độ liên kết vào của nó có thể cung cấp thông tin hữu ích về mức độ liên quan của một tài liệu. Sự phát triển của PRF là khá tổng quát và không đề cập rõ ràng đến các thuật ngữ hay văn bản; do đó, ít nhất về mặt nguyên tắc, có thể xem xét các đặc điểm phi văn bản.

Chúng tôi sẽ thực hiện hai giả định ở đây về các đặc trưng phi văn bản. Đầu tiên, chúng tôi thực hiện giả định thường gặp về sự độc lập của đặc trưng đối với tỷ lệ liên quan (như đã thảo luận trong Mục 2). Thứ hai, chúng tôi sẽ giả định rằng tất cả các đặc trưng phi văn bản đều cung cấp thông tin về mức độ liên quan.

which is *independent of the query*. With these two assumptions we can integrate non-textual features very easily into the PRF and BM25 scoring frameworks. It is possible in principle to relax these assumptions and derive more sophisticated models of relevance for non-textual features.

Let us call $\mathbf{c} = (tf_1, \ldots, tf_{|\mathbf{V}|})$ the vector of term frequency counts of document d, and let us call $\mathbf{f}$ an extra vector of non-textual features $\mathbf{f} = (f_1, \ldots, f_F)$. We have that $d = (\mathbf{c}, \mathbf{f})$.

Note that the initial PRF development (Equations (2.1–2.4) in Section 2) applies also to this extended version of d. Equation (2.4) makes the assumption of feature independence, which carries over the non-textual features. Therefore the product in Equation 2.4 would include all non-textual features $\mathbf{f}$.

In Equation (2.5), where we drop all the non-query terms in $\mathbf{c}$, none of the terms in $\mathbf{f}$ would be dropped — non-textual features are assumed to be correlated with relevance for all queries. After taking the log in Equation (2.6) we see that the addition of non-textual features simply adds a new term to the sum. Removing the zeros in Equations (2.7–2.9) does not affect this term, so after (2.11) we may write:

$$P(\text{rel}\,|\,d, q) \propto_q \sum_{\mathbf{q}, tf_i > 0} W_i(tf_i) + \sum_{i=1}^{F} \lambda_i V_i(f_i), \tag{3.22}$$

where

$$V_i(f_i) := \log \frac{P(F_i = f_i\,|\,\text{rel})}{P(F_i = f_i\,|\,\overline{\text{rel}})} \tag{3.23}$$

We have artificially added a free parameter λ_i to account for rescalings in the approximation of W_i and V_i.

We note that features f_i may well be multi-valued or continuous, and this implies the need for care in the choice of function $V(f_i)$ (just as we paid attention to finding a good function of tf). This will depend on the nature of each non-textual feature f_i and our prior knowledge about it. Here are some V_i functions that we have used with success in the past for different features:

- Logarithmic: $\log(\lambda_i' + f_i)$

điều này độc lập với truy vấn. Với hai giả định này, chúng ta có thể tích hợp các đặc trưng phi văn bản rất dễ dàng vào các khung chấm điểm PRF và BM25. Về nguyên tắc, có thể nới lỏng các giả định này và tạo ra các mô hình liên quan phức tạp hơn cho các đặc trưng phi văn bản.

Hãy gọi c $=$(tf 1, . . . , tf $|$V$|$) là vector của các tần suất xuất hiện từ của tài liệu d, và hãy gọi f là một vector bổ sung của các đặc trưng phi văn bản f $=(f_1, \ldots, f_F)$. Chúng ta có $d =$(c, f).

Lưu ý rằng phát triển PRF ban đầu (Các phương trình (2.1–2.4) trong Mục 2) cũng áp dụng cho phiên bản mở rộng này của d. Ph ương trình (2.4) đưa ra giả định về tính độc lập của các đặc trưng, điều này cũng áp dụng cho các đặc trưng phi văn bản. Do đó, tích trong Phương trình 2.4 sẽ bao gồm tất cả các đặc trưng phi văn bản f.

Trong Phương trình (2.5), khi chúng ta loại bỏ tất cả các hạng tử không liên quan đến truy vấn trong c, không có hạng tử nào trong f bị loại bỏ — các đặc trưng phi văn bản được giả định có liên quan với mức thích hợp cho tất cả các truy vấn. Sau khi lấy log trong Phương trình (2.6), chúng ta thấy việc thêm các đặc trưng phi văn bản chỉ đơn giản thêm một hạng tử mới vào tổng. Việc loại bỏ các giá trị không trong các Phương trình (2.7–2.9) không ảnh hưởng đến hạng tử này, vì vậy sau (2.11) chúng ta có thể viết:

$$P(\text{rel}\,|\,d, q) \propto_q \sum_{\mathbf{q}, tf_i > 0} W_i(tf_i) + \sum_{i=1}^{F} \lambda_i V_i(f_i), \tag{3.22}$$

ở đâu

$$V_i(f_i) := \log \frac{P(F_i = f_i\,|\,\text{rel})}{P(F_i = f_i\,|\,\overline{\text{rel}})} \tag{3.23}$$

Chúng tôi đã thêm một tham số tự do nhân tạo λ_i để tính đến việc thay đổi tỷ lệ trong việc xấp xỉ W_i và V_i.

Chúng tôi lưu ý rằng các đặc trưng f_i có thể là đa giá trị hoặc liên tục, và điều này ngụ ý sự cần thận trọng trong việc lựa chọn hàm $V(f_i)$ (giống như cách chúng tôi đã chú ý để tìm một hàm tốt của tf). Điều này sẽ phụ thuộc vào bản chất của từng đặc trưng phi văn bản f_i và kiến thức trước đây của chúng tôi về nó. Dưới đây là một số hàm V_i mà chúng tôi đã sử dụng một cách thành công trong quá khứ cho các đặc trưng khác nhau:

- Logarithmic: $\log(\lambda_i' + f_i)$

- Rational: $f_i/(\lambda'_i + f_i)$
- Sigmoid: $[\lambda'_i + \exp(-f_i\,\lambda''_i)]^{-1}$

This development can explain for example why simple scoring functions such as BM25F(q,d)+log$(PageRank(d))$ may work well in practice for Web Search retrieval. This can much improved by adding the scaling parameter λ, and it can be further improved (only slightly) by changing the log into a sigmoid and tuning the two extra parameters λ' and λ'' [12]. In our work we developed more sophisticated ranking functions integrating several forms of non-textual information and using over a dozen parameters [12, 13]. The optimisation of these parameters is discussed in Section 5.

3.8 Positional Information

For the most part the PRF ignores positional information: it cares only about the number of occurrences of a term, but not about their position. There are two important reasons that have held back the PRF from considering positional information: (i) it is extremely hard to develop a sound formal model of relevance which takes into account positional information without exploding the number of parameters, and (ii) position information has been shown to have surprisingly little effect on retrieval accuracy on average. In this section we only give an overview of the existing approaches and discuss the main difficulties. We also propose some intuitions of why position may not be as crucial as it seems at first sight.

Why is it so hard to model relevance with respect to the position of terms in the query and document? Several problems appear. First, we need to define an appropriate universe of events. In the traditional PRF this universe is simply $\mathbb{N}^{|q|}$, all possible term frequency vectors of terms in the query. The most natural way to consider positions would be to characterise all sequences of terms in the query separated by some number of non-query terms. This leads to an excessively high-dimensional space, and one that is very hard to factor it in an appropriate way. In the traditional model the natural unit over which we build (factorise) the required quantities is the occurrence of a term a given number of

- Lý do: $f_i/(\lambda'_i + f_i)$
- Sigmoid: $[\lambda'_i + \exp(-f_i\,\lambda''_i)]^{-1}$

Phát triển này có thể giải thích, ví dụ, tại sao các hàm đánh giá đơn giản như BM25F(q,d)+log$(PageRank(d))$ có thể hoạt động tốt trong t hực tế đối với việc truy xuất thông tin trên Web. Điều này có thể được cải thiện nhiều hơn bằng cách thêm tham số tỷ lệ λ, và có thể được c ải thiện hơn nữa (chỉ một chút) bằng cách đổi log thành sigmoid và điều chỉnh hai tham số bổ sung λ' và λ''[12]. Trong công trình của chúng tôi, chúng tôi phát triển các hàm xếp hạng tinh vi hơn tích hợp nhiều dạng thông tin phi văn bản và sử dụng hơn một chục tham số [12, 13]. Việc tối ưu hóa các tham số này được thảo luận trong Mục 5.

3.8 Thông tin vị trí

Phần lớn, PRF không quan tâm đến thông tin vị trí: nó chỉ quan tâm đến số lần xuất hiện của một thuật ngữ, nhưng không quan tâm đến vị trí của chúng. Có hai lý do quan trọng đã ngăn cản PRF xem xét thông tin vị trí: (i) rất khó để phát triển một mô hình chính thức về mức liên quan một cách vững chắc mà vẫn tính đến thông tin vị trí mà không làm tăng đáng kể số lượng tham số, và (ii) thông tin vị trí đã được chứng minh là có tác động khá ít đến độ chính xác truy xuất trung bình. Trong phần này, chúng tôi chỉ đưa ra tổng quan về các phương pháp hiện có và thảo luận về những khó khăn chính. Chúng tôi cũng đề xuất một vài trực giác về lý do tại sao vị trí có thể không quan trọng như vẻ bề ngoài ban đầu.

Tại sao lại khó đến vậy để mô hình hóa sự liên quan liên quan đến vị trí của các từ trong truy vấn và tài liệu? Một số vấn đề xuất hiện. Đầu tiên, chúng ta cần xác định một vũ trụ sự kiện phù hợp. Trong PRF truyền thống, vũ trụ này đơn giản chỉ là $\mathbb{N}^{|q|}$, tất cả các vectơ tần số từ có thể của các từ trong truy vấn. Cách tự nhiên nhất để xem xét vị trí là mô tả tất cả các chuỗi từ trong truy vấn được phân cách bởi một số từ không thuộc truy vấn. Điều này dẫn đến một không gian có chiều quá cao, và rất khó để phân tích nó một cách thích hợp. Trong mô hình truyền thống, đơn vị tự nhiên mà chúng ta xây dựng (phân tích) các đại lượng cần thiết là sự xuất hiện của một từ với số lượng nhất định

times. What would be the natural unit over which to build (factorise) the probabilities required to model positions adequately?

There have been a number of attempts to deal with these issues and introduce positional information into BM25 (see for example [3, 54, 51] and references therein). The three main approaches used are the following:

1. Indexing phrases as individual terms. This approach is ideal for multi-term tokens (such as *White House*) for which a partial match would in fact be incorrect. Its implementation is extremely simple since one does not need to modify the ranking function in any way (each phrase would have its own *tf* and *idf*). There are three problems however: (i) it does not take into account partial matches; (ii) it does not take into account terms which are close but not exactly adjacent; and (iii) one needs to define the valid phrases [48].
2. Scoring *spans* of text instead of entire documents. This can be done explicitly, with a *passage retrieval* ranking function [3], or implicitly by constructing a ranking function that integrates scores computed over many document spans [51].
3. Deriving *position features* (such as the minimum and maximum length of the document spans containing all the terms in the query) which can then be integrated into the scoring function as non-textual features (as those in Section 3.7) [54].

In our opinion none of these attempts would qualify as a *natural* extension of the PRF, since it is not clear what the assumptions about relevance are. Metzler [32, 33] proposes a novel probabilistic retrieval model which makes clear assumptions about positions and relevance, and could perhaps be integrated within the PRF. The model estimates the probability of relevance of document and query jointly: $P(Q, D \mid Rel)$. This is done by a Markov Random Field (MRF) which can take into account term-positions in a natural way. The MRF can use any appropriately defined potentials: while the original work used LM-derived potentials, BM25-like potentials were used in [31]. However, even when using BM25-like potentials, we cannot call this model an *extension* of

368 *Derived Models*

lần. Đơn vị tự nhiên nào để xây dựng (phân tích nhân tử) các xác suất cần thiết nhằm mô hình hóa các vị trí một cách thích hợp?

Đã có một số nỗ lực để giải quyết những vấn đề này và đưa thông tin vị trí vào BM25 (xem ví dụ [3,54, 51] và các tài liệu tham khảo trong đó). Ba phương pháp chính được sử dụng như sau:

1. Lập chỉ mục các cụm từ như các thuật ngữ riêng lẻ. Cách tiếp cận này lý tưởng cho các token có nhiều từ (chẳng hạn như White House) mà việc khớp một phần thực ra sẽ là sai. Việc triển khai của nó cực kỳ đơn giản vì không cần phải sửa đổi hàm xếp hạng theo bất kỳ cách nào (mỗi cụm từ sẽ có tf và idf riêng). Tuy nhiên, có ba vấn đề: (i) nó không xem xét các khớp một phần; (ii) nó không xem xét các thuật ngữ gần nhau nhưng không hoàn toàn liền kề; và (iii) cần xác định các cụm từ hợp lệ [48]. 2. Đánh giá các đoạn văn bản thay vì toàn bộ tài liệu. Điều này có thể được thực hiện một cách rõ ràng, với một hàm xếp hạng truy xuất đoạn văn bản [3], hoặc một cách ngầm định bằng cách xây dựng một hàm xếp hạng tích hợp các điểm số tính toán trên nhiều đoạn văn bản của tài liệu [51]. 3. Rút ra các đặc trưng vị trí (chẳng hạn như độ dài tối thiểu và tối đa của các đoạn văn bản chứa tất cả các thuật ngữ trong truy vấn) mà sau đó có thể được tích hợp vào hàm đánh giá như các đặc trưng phi văn bản (như những đặc trưng trong

Theo quan điểm của chúng tôi, không có nỗ lực nào trong số này đủ điều kiện như một sự mở rộng tự nhiên của PRF, vì không rõ các giả định về sự liên quan là gì. Metzler [32, 33] đề xuất một mô hình truy xuất xác suất mới, trong đó đưa ra các giả định rõ ràng về vị trí và sự liên quan, và có thể được tích hợp trong PRF. Mô hình này ước lượng xác suất liên quan của tài liệu và truy vấn cùng nhau: $P(Q, D \mid Rel)$. Điều này được thực hiện thông qua Mạng Ngẫu nhiên Markov (MRF) có thể xem xét các vị trí của thuật ngữ một cách tự nhiên. MRF có thể sử dụng bất kỳ tiềm năng nào được xác định phù hợp: trong khi công trình nguyên bản sử dụng các tiề m năng bắt nguồn từ LM, các tiềm năng tương tự BM25 đã được sử dụng trong [31]. Tuy nhiên, ngay cả khi sử dụng các tiềm năng tương tự BM25, chúng tôi cũng không thể gọi mô hình này là một sự mở rộng của

the PRF, since it models a different distribution: $P(D,Q\,|\,Rel)$ instead of the posterior $P(Rel\,|\,D,Q)$.

We end this section with a brief discussion of why position information may not be as important as it may seem at first view. It is sobering to see how hard it has been in the past to effectively use proximity in IR experiments. All the works referenced in this section claim statistically significant improvements over non-positional baselines, but the improvements reported are small. We believe this is specially the case for small collections and high recall situations (typical of academic IR evaluations), since position information is a precision enhancement technique. But even in large collections with high-precision requirements (such as realistic Web Search evaluations) the gains observed are small. Why is this? We do not know of theoretical or empirical studies about this, but we propose here two hypotheses.

First, we believe that natural language, and queries in particular, are quite robust. We would argue that for many queries, a human could determine the relevance of a document to a query even after words in the document and query were scrambled. And for cases that this is not true, it is likely that the user would unconsciously *correct* the query by adding terms to it that disambiguate it. This does not mean that all queries and documents are position-proof, but the fraction that require positions is small. Second, it should be noted that taking into account the structure of a document (e.g., in BM25F) implicitly rewards proximity within important short streams, such as the title.

3.9 Open Source Implementations of BM25 and BM25F

We review here several implementations of BM25 and BM25F available as open source. This list is not exhaustive, there may be other search engines or extensions of them that implement BM25 and BM25F.

As far as we know only the MG4J [9, 34] fully implements BM25F (version 2.2 or later). BM25 is implemented by Lemur, MG4J, Okapi, PF/Tija, Terrier, Wumpus, Xapian and Zettair [22, 27, 34, 35, 39, 56, 57, 60, 61, 63]. All these search engines are quite modular and could in principle be modified to extend BM25 in a number of ways, in particular to implement BM25F. Lucene [29] does not implement BM25

PRF, vì nó mô hình hóa một phân phối khác: $P(D,Q\,|\,Rel)$ thay vì phân phối hậu nghiệm $P(Rel\,|\,D,Q)$.

Chúng tôi kết thúc phần này bằng một cuộc thảo luận ngắn về lý do t ại sao thông tin vị trí có thể không quan trọng như nó có vẻ ban đầu. Thật đáng suy ngẫm khi thấy việc sử dụng hiệu quả thông tin lân cận trong các thí nghiệm IR trong quá khứ khó khăn như thế nào. Tất cả các công trình được tham chiếu trong phần này đều khẳng định cải thiện có ý nghĩa thống kê so với các mốc không vị trí, nhưng các cải thiện được báo cáo là nhỏ. Chúng tôi tin rằng điều này đặc biệt đúng đối với các bộ sưu tập nhỏ và tình huống yêu cầu khả năng truy hồi cao (điển hình trong các đánh gi á IR học thuật), vì thông tin vị trí là một kỹ thuật cải thiện độ chính xác. Nhưng ngay cả trong các bộ sưu tập lớn với các yêu cầu độ chính xác cao (chẳng hạn như các đánh giá Tìm kiếm Web thực tế), các lợi ích quan sát được cũng nhỏ. Tại sao lại như vậy? Chúng tôi không biết các nghiên cứu lý thuyết hay thực nghiệm nào về vấn đề này, nhưng chúng tôi đề xuất ở đây hai giả thuyết.

Trước hết, chúng tôi tin rằng ngôn ngữ tự nhiên, và các truy vấn đặc biệt, khá bền vững. Chúng tôi sẽ lập luận rằng đối với nhiều truy vấn, con người vẫn có thể xác định mức độ liên quan của một tài liệu với truy vấn ngay cả khi các từ trong tài liệu và truy vấn bị xáo trộn. Và trong những trường hợp mà điều này không đúng, có khả năng là người dùng sẽ vô thức sửa truy vấn bằng cách thêm các từ vào đó để làm rõ nghĩa. Điều này không có nghĩa là tất cả các truy vấn và tài liệ u đều chịu được thay đổi vị trí, nhưng tỷ lệ những trường hợp cần vị trí là nhỏ. Thứ hai, cần lưu ý rằng việc tính đến cấu trúc của một tài liệu (ví dụ, trong BM25F) một cách ngầm định sẽ thưởng cho sự gần gũi trong các chuỗi ngắn quan trọng, chẳng hạn như tiêu đề.

3.9 Các Triển Khai Mã Nguồn Mở của BM25 và BM25F

Chúng tôi xem xét ở đây một số triển khai của BM25 và BM25F có sẵn dưới dạng mã nguồn mở. Danh sách này không đầy đủ, có thể có các công cụ tìm kiếm khác hoặc các tiện ích mở rộng của chúng mà triển khai BM25 và BM25F.

Theo như chúng tôi biết, chỉ có MG4J [9, 34] hoàn toàn triển khai BM25F (phiên bản 2.2 trở lên). BM25 được triển khai bởi Lemur, MG4J, Okapi, PF/Tija, Terrier, Wumpus, Xapian và Zettair [22, 27, 34, 35, 39, 56, 57, 60, 61, 63]. Tất cả các công cụ tìm kiếm này đều khá mô-đun và về nguyên tắc có thể được chỉnh sửa để mở rộng BM25 theo một số cách, đặc biệt là để triển khai BM25F. Lucene [29] không triển khai BM25

but there exist a third party Lucene extensions that implement BM25 and BM25F [38]. We inspected the code of all these implementations and we believe they are correct.[1] (inspection was visual: we did not run tests ourselves; in two cases implementation was incorrect and we asked the authors to correct it, which they did). None of the systems above provide support for parameter optimisation, although it should not be difficult to extend them for this.

[1] There are some minor differences in BM25 implementations in these packages at the time of writing this survey. For example, PF/Tijah uses idf= $\log \frac{N+0.5}{n+0.5}$, Terrier does not allow modifying k programmatically and Xapian does not allow modifying any parameters programmatically.

nhưng tồn tại một số tiện ích mở rộng Lucene của bên thứ ba triển khai BM25 và BM25F [38]. Chúng tôi đã kiểm tra mã của tất cả các triển khai này và chúng tôi tin rằng chúng là chính xác. [1] (việc kiểm tra là trực quan: chúng tôi không chạy thử nghiệm tự mình; trong hai trường hợp triển khai không chính xác và chúng tôi đã yêu cầu các tác giả sửa, và họ đã làm). Không có hệ thống nào ở trên hỗ trợ tối ưu hóa tham số, mặc dù việc mở rộng chúng để làm điều này không nên khó khăn.

[1] Có một số khác biệt nhỏ trong các triển khai BM25 trong các gói này vào thời điểm viết khảo sát này. Ví dụ, PF/Tijah sử dụng idf= $\log \frac{N+0.5}{n+0.5}$, Terrier không cho phép chỉnh sửa k theo lập trình và Xapian không cho phép chỉnh sửa bất kỳ tham số nào theo lập trình.

4

Comparison with Other Models

The first probabilistic model for retrieval was proposed by Maron and Kuhns in 1960 [30]. It was similarly based on a notion of probability of relevance; however, there was an interesting discrepancy between the Maron and Kuhns approach and that of Robertson and Spärck Jones fifteen years later. The discrepancy was the subject of research in the early 1980s on a unification of the two. In order to explain both the discrepancy and the attempted unification, we first describe the Maron and Kuhns model.

4.1 Maron and Kuhns

The situation envisaged by Maron and Kuhns was that of a librarian indexing a book (document). The idea was that indexing should anticipate how people make requests in the first place. Ideal indexing should match the requests of just those people who would want to be pointed to this monograph — those people who would find it relevant to their needs. The *system* was assumed to be a system of subject headings, any of which might be assigned by the librarian to the book in question; a *user request* would take the form of a chosen subject heading to

4

So sánh với các mô hình khác

Mô hình xác suất đầu tiên cho việc truy hồi thông tin được Maron và Kuhns đề xuất vào năm 1960 [30]. Nó cũng dựa trên khái niệm về xác suất liên quan; tuy nhiên, có một sự khác biệt thú vị giữa phương pháp của Maron và Kuhns và phương pháp của Robertson và Sp¨arck Jones mười lăm năm sau. Sự khác biệt này là đề tài nghiên cứu vào đầu những năm 1980 về việc thống nhất hai phương pháp này. Để giải thích cả sự khác biệt lẫn nỗ lực thống nhất, trước hết chúng tôi sẽ mô tả mô hình của Maron và Kuhns.

4.1 Maronand Kuhns

Tình huống mà Maron và Kuhns hình dung là của một thủ thư đang lập chỉ mục cho một cuốn sách (tài liệu). Ý tưởng là việc lập chỉ mục nên dự đoán cách mà người ta đưa ra yêu cầu ngay từ đầu. Lập chỉ mục lý tưởng nên phù hợp với những yêu cầu của chính những người muốn được chỉ dẫn đến chuyên khảo này — những người sẽ thấy nó có liên quan đến nhu cầu của họ. Hệ thống được giả định là một hệ thống các đề mục chủ đề, mà bất kỳ đề mục nào trong số đó đều có t hể được thủ thư gán cho cuốn sách đang xét; một yêu cầu của người dùng sẽ có dạng của một đề mục chủ đề được chọn để

look under. Thus the librarian would be invited to estimate, in respect of each candidate subject heading, the probability that a user looking there would find this particular book relevant.

Thus far, the basis for the model looks very like the PRF defined in Section 2. However, to better understand the nature of the probability of relevance as interpreted by Maron and Kuhns, we need to consider the event space in which it is defined. This will give us the basis for a comparison in the following section.

We have (at least in the mind of the librarian) a group of users (with information needs) who look under a particular subject heading. On the other hand, we have a single individual book in front of the librarian. Therefore the event space involved, in which the probability should be defined, is a space of users. If we were to attempt to use feedback to estimate such a probability, we would ideally count users — that is, of all the users who express their queries by means of a particular subject heading, what proportion would like this monograph.

This kind of approach has recently acquired new force, because the big Web Search engines typically see some queries (the so-called 'head' queries) repeated very many times by different users. Click log data looks a little like relevance feedback on individual documents from a population of users with similar queries. However, the relation between this and the PRF discussed in this monograph needs further analysis.

4.2 The Unified Model

We re-visit the original RSJ model, the foundation of the model presented in this survey, in order to define it in similar terms. In this case, we start with a single individual user, who puts a request using certain words. Now we ask the question, what is the probability that any arbitrary document matching one (or a combination) of these words is relevant to the user. Thus the event space here consists of documents, and if we want to use feedback to estimate the probability, we would count documents, as in Section 3.1.

It immediately becomes clear that although both models refer to *probability of relevance*, they define their respective versions of this

xem dưới. Do đó, thủ thư sẽ được mời đánh giá, đối với từng đầu đề chủ đề của ứng viên, xác suất mà một người dùng tìm kiếm ở đó sẽ thấy cuốn sách cụ thể này có liên quan.

Cho đến nay, cơ sở cho mô hình trông rất giống với PRF được định nghĩa trong Mục 2. Tuy nhiên, để hiểu rõ hơn bản chất của xác suất liên quan như được Maron và Kuhns diễn giải, chúng ta cần xem xét không gian sự kiện mà nó được định nghĩa. Điều này sẽ cung cấp cho chúng ta cơ sở để so sánh trong phần tiếp theo.

Chúng ta có (ít nhất trong suy nghĩ của thủ thư) một nhóm người dùng (có nhu cầu thông tin) tìm kiếm theo một đề mục cụ thể. Mặt khác, chúng ta có một cuốn sách cá nhân trước thủ thư. Do đó, không gian sự kiện liên quan, trong đó xác suất nên được định nghĩa, là không gian của người dùng. Nếu chúng ta cố gắng sử dụng phản hồi để ước lượng xác suất như vậy, lý tưởng nhất là chúng ta sẽ đếm người dùng — tức là, trong số tất cả những người dùng biểu thị các truy vấn của họ thông qua một đề mục cụ thể, có bao nhiêu phần trăm sẽ muốn cuốn sách đơn này.

Cách tiếp cận này gần đây đã có thêm sức mạnh mới, vì các công cụ Tìm kiếm Web lớn thường thấy một số truy vấn (các truy vấn gọi là 'đầu') được nhiều người dùng khác nhau lặp lại nhiều lần. Dữ liệu nhật ký nhấp chuột trông hơi giống phản hồi liên quan đến các tài liệu cá nhân từ một tập hợp người dùng có các truy vấn tương tự. Tuy nhiên, mối quan hệ giữa điều này và PRF được thảo luận trong chuyên khảo này cần được phân tích thêm.

4.2 Mô Hình Thống Nhất

Chúng tôi quay lại mô hình RSJ gốc, nền tảng của mô hình được trình bày trong khảo sát này, để định nghĩa nó bằng các thuật ngữ tương tự. Trong trường hợp này, chúng tôi bắt đầu với một người dùng cá nhân, người đưa ra một yêu cầu bằng cách sử dụng một số từ nhất định. Bây giờ chúng ta đặt câu hỏi, xác suất rằng bất kỳ tài liệu nào ngẫu nhiên khớp với một (hoặc kết hợp) những từ này liên quan đến người dùng là bao nhiêu. Do đó, không gian sự kiện ở đây bao gồm các tài liệu, và nếu chúng ta muốn sử dụng phản hồi để ước tính xác suất, chúng ta sẽ đếm các tài liệu, như trong Mục 3.1.

Ngay lập tức trở nên rõ ràng rằng mặc dù cả hai mô hình đều đề cập đến xác suất liên quan, chúng định nghĩa các phiên bản tương ứng của điều này

probability in different event spaces. In fact, the two probabilities of relevance are actually quite distinct.

The unification attempt [43] was based on the following argument. We imagine a matrix of users-with-information-needs against documents (individual users u, individual documents d). Ideally we would like to assign a meaningful probability of relevance to the specific combination of an individual user with an individual document: $P(\text{rel}|u,d)$. However, doing this directly looks difficult — at least if we are looking for direct evidence (feedback). If we show d to u and get a judgement, we no longer need to assign a probability! Indeed, it only makes sense to do so when we have classes of similar events.

Maron and Kuhns start by classifying users together, according to the subject headings they consult. Thus we are dealing with a class U of users, and ask about $P(\text{rel}|U,d)$. On the other hand, Robertson and Sprck Jones classify documents together in classes such as D, and ask about $P(\text{rel}|u,D)$.

The unified model proceeded to define *four* different probabilities of relevance. We might consider starting with $P(\text{rel}|U,D)$, which is a general model needing only feedback from similar users about similar documents (this is referred to as Model 0). If we have feedback about the particular document, we can improve this estimate by considering $P(\text{rel}|U,d)$ (Model 1). On the other hand, if we have feedback from the particular user, we should go for $P(\text{rel}|u,D)$ (Model 2). Finally, if we have both kinds of more specialist evidence simultaneously (Model 3), we might aim for an even better probability. However, its exact relationship to $P(\text{rel}|u,d)$ is not quite obvious, because while it is based on feedback of the above three kinds, it would not actually have feedback on the exact individual pair.

The unified model has been the subject of some more recent work [8], and we are now entering a domain in which many different kinds of feedback may be possible, given the kind of logging of Web searching behaviour that is now the norm. Other authors (for example [14, 17], and later [25] in the context of the language model discussed below) have approached the problem by in effect limiting themselves to Model 0, by considering only *representations* of documents and queries, rather than individual instances.

xác suất trong các không gian sự kiện khác nhau. Thực tế, hai xác suất có liên quan thực sự khá khác biệt.

Nỗ lực thống nhất [43]được dựa trên lập luận sau. Chúng ta hình dung một ma trận người dùng-có-nhu cầu-thông tin đối chiếu với tài liệu (người dùng cá nhân u, tài liệu cá nhân d). Lý tưởng là chúng ta muốn gán một xác suất ý nghĩa về mức độ liên quan cho sự kết hợp c ụ thể giữa một người dùng cá nhân với một tài liệu cá nhân: $P(\text{rel}|u,d)$. Tuy nhiên, thực hiện điều này trực tiếp có vẻ khó — ít nhất là nếu chúng ta đang tìm kiếm bằng chứng trực tiếp (phản hồi). Nếu chúng ta hiển thị d cho u và nhận được đánh giá, chúng ta không còn cần gán xác suất nữa! Thật vậy, chỉ có ý nghĩa khi làm điều đó khi chúng ta có các lớp sự kiện tương tự.

Maron và Kuhns bắt đầu bằng cách phân loại người dùng với nhau, theo các tiêu đề chủ đề mà họ tham khảo. Do đó chúng ta đang xử lý một lớp người dùng, và hỏi về $P(\text{rel}|U,d)$. Mặt khác, Robertson và Sprck Jones phân loại tài liệu với nhau thành các lớp như D, và hỏi về $P(\text{rel}|u,D)$.

Mô hình hợp nhất tiếp tục định nghĩa bốn xác suất liên quan khác nhau. Chúng ta có thể xem xét bắt đầu với $P(\text{rel}|U,D)$, đây là một mô hình tổng quát chỉ cần phản hồi từ những người dùng tương tự về các tài liệu tương tự (điều này được gọi là Mô hình 0). Nếu chúng ta có phản hồi về tài liệu cụ thể, chúng ta có thể cải thiện ước tính này bằng cách xem xét $P(\text{rel}|U,d)$ (Mô hình 1). Mặt khác, nếu chúng ta có phản hồi từ người dùng cụ thể, chúng ta nên chọn $P(\text{rel}|u,D)$ (Mô hình 2). Cuối cùng, nếu chúng ta có cả hai loại bằng chứng chuyên môn đồng thời (Mô hình 3), chúng ta có thể hướng đến một xác suất tốt hơn nữa. Tuy nhiên, mối quan hệ chính xác của nó với $P(\text{rel}|u,d)$ không hoàn toàn rõ ràng, vì mặc dù nó dựa trên phản hồi của ba loại nêu trên, nhưng thực sự nó sẽ không có phản hồi về cặp cá nhân chính xác đó.

Mô hình thống nhất đã là đối tượng của một số nghiên cứu gần đây hơn [8], và giờ đây chúng ta đang đi vào một lĩnh vực mà nhiều loại phản hồi khác nhau có thể khả thi, dựa vào loại ghi nhận hành vi tìm kiếm trên Web mà hiện nay đã trở thành chuẩn mực. Các tác giả khác (ví dụ [14, 17], và sau đó [25] trong bối cảnh mô hình ngôn ngữ được thảo luận dưới đây) đã tiếp cận vấn đề bằng một cách giới hạn bản thân về Mô hình 0, bằng cách chỉ xem xét các đại diện của tài liệu và truy vấn, thay vì các trường hợp riêng lẻ.

However, in the present survey we have restricted ourselves to the RSJ view of the probability of relevance.

4.3 The Simple Language Model

The language model (LM) of IR is a more recent innovation [24, 26, 33], also with a strong probabilistic motivation. We first describe the simple LM, and then some more sophisticated developments.

In the LM, we regard any piece of text (document, query, etc.) as having been generated by a statistical process. Outside of IR, such models have been very successful in various areas, particularly in speech recognition, and the IR application has borrowed from that domain. In this particular view of text, it is regarded as being generated word-by-word in sequence, each word being chosen from a vocabulary. The simplest statistical model, so-called *unigram*, has a fixed probability distribution over the vocabulary, applied to all word-positions (so actually the sequence is not important). n-gram models assume that the choice of the next word depends on the $n-1$ previous words chosen.

The simple LM approach to IR assumes that each document has its own model, and asks this question about each document: what is the probability that the query came from (was generated by) the same language model as the document (there is no separate query model in this approach). This probability is used to rank documents for a query. Thus there is no explicit notion of relevance; the implicit notion is that a document is relevant to a query if the query came from the same language model as the document. This approach also does not distinguish between individual users — a query is understood to be just a text, and each query–document pair is considered as an equivalent individual event. From an individual user point of view, the model implicitly assumes that there is just one relevant document (if this instance of a query was generated by the language model for document 1, it could not also have been generated by the different language model for document 2). However, since the approach does not distinguish individuals, in effect it represents a version of Model 0 (in the terms of the unified model, as discussed above). Different instances of the same query can be generated from different documents; in the (U, D) class, more than

Tuy nhiên, trong khảo sát hiện tại, chúng tôi chỉ giới hạn mình ở quan điểm RSJ về xác suất liên quan.

4.3 Mô Hình Ngôn Ngữ Đơn Giản

Mô hình ngôn ngữ (LM) của IR là một đổi mới gần đây hơn [24, 26, 33], cũng có động cơ xác suất mạnh mẽ. Trước tiên chúng tôi mô tả LM đơn giản, và sau đó một số phát triển tinh vi hơn.

Trong LM, chúng tôi coi bất kỳ đoạn văn bản nào (tài liệu, truy vấn, v.v.) đều được tạo ra bởi một quá trình thống kê. Ngoài IR, các mô hình như vậy đã rất thành công trong nhiều lĩnh vực khác nhau, đặc biệt là trong nhận dạng giọng nói, và ứng dụng IR đã học hỏi từ lĩnh vực đó. Trong quan điểm đặc biệt này về văn bản, văn bản được coi là được tạo ra từng từ một theo trình tự, mỗi từ được chọn từ một từ vựng. Mô hình thống kê đơn giản nhất, gọi là unigram, có một p hân phối xác suất cố định trên từ vựng, áp dụng cho tất cả các vị trí từ (vì vậy trên thực tế trình tự không quan trọng). Mô hình n-gram giả định rằng việc chọn từ tiếp theo phụ thuộc vào $n-1$ từ đã chọn trước đó.

Cách tiếp cận LM đơn giản đối với IR giả định rằng mỗi tài liệu có mô hình riêng của nó, và đặt câu hỏi này về mỗi tài liệu: xác suất mà truy vấn xuất phát từ (được tạo ra bởi) cùng mô hình ngôn ngữ với tài liệu là bao nhiêu (trong cách tiếp cận này không có mô hình truy vấn riêng). Xác suất này được sử dụng để xếp hạng các tài liệu cho một truy vấn. Do đó, không có khái niệm rõ ràng về mức độ liên quan; khái niệm ngầm định là một tài liệu có liên quan đến một truy vấn nếu truy vấn được tạo ra từ cùng mô hình ngôn ngữ với tài liệu. Cách tiếp cận này cũng không phân biệt giữa từng người dùng — một truy vấn được hiểu chỉ là một văn bản, và mỗi cặp truy vấn–tài liệu được xem là một sự kiện cá nhân tương đương. Từ quan điểm của từng người dùng, mô hình ngầm định giả định rằng chỉ có một tài liệu liên quan (nếu phiên bản truy vấn này được tạo ra bởi mô hình ngôn ngữ cho tài liệu 1, nó cũng không thể được tạo ra bởi mô hình ngôn ngữ khác cho tài liệu 2). Tuy nhiên, vì cách tiếp cận

one document can be relevant. But it follows that it makes no sense to consider individual feedback in the context of the simple LM.

In more detail, the document language model is usually built by mixing (*smoothing*) probabilities derived from the document itself with those taken from a general background language model. One purpose of this smoothing is to avoid a zero probability being assigned to any term that does not occur in the document. In general, a rich fund of models and estimation methods has been mined within the general framework of the LM. We further explore only two of these developments in the following sections.

4.4 The Relevance (Language) Model

Some of the limitations of the simple model are addressed in work on a relevance model for the LM framework [26, 33]. Here, by contrast, we assume that the query has (that is, is generated by) its own model, distinct from any particular document model. The initial source for this model is clearly the query itself; however, relevance feedback (from the individual user, for example) can provide additional evidence about it.

With this approach, the document–query matching process becomes much less obvious. Note that both in the simple LM, and in the traditional probabilistic relevance framework (PRF) described in this survey, the process of matching the query to the document is inherent in the model, entirely determined by the model itself. In this new context, no such matching process is defined; it is necessary to choose one from outside the model.

Given that both the document LM and the query (relevance) LM take the form of statistical distributions over a vocabulary, matching becomes a question of matching two statistical distributions. The most common way to do this is to use the Kullback–Leibler (KL) divergence measure. This has good empirical support.

4.5 Topic Models

There is perhaps potential for some kind of bridge between the LM approach and the PRF in work on implicit topic models. Most such

một tài liệu có thể có liên quan. Nhưng điều đó kéo theo rằng không có lý do gì để xem xét phản hồi cá nhân trong bối cảnh của LM đơn giản.

Chi tiết hơn, mô hình ngôn ngữ tài liệu thường được xây dựng bằng cách trộn (làm mượt) các xác suất được suy ra từ chính tài liệu với các xác suất lấy từ một mô hình ngôn ngữ nền chung. Một mục đích của việc làm mượt này là để tránh việc gán xác suất bằng không cho bất kỳ thuật ngữ nào không xuất hiện trong tài liệu. Nói chung, một kho tàng phong phú các mô hình và phương pháp ước lượng đã được khai thác trong khuôn khổ tổng thể của LM. Chúng tôi chỉ đi sâu vào hai trong số các phát triển này trong các phần tiếp theo.

4.4 Mô hình Ngôn ngữ Liên quan

Một số hạn chế của mô hình đơn giản được giải quyết trong công trình về mô hình liên quan cho khuôn khổ LM [26, 33]. Ngược lại, ở đây, chúng tôi giả định rằng truy vấn có (tức là được tạo ra bởi) một mô hình riêng của nó, khác với bất kỳ mô hình tài liệu cụ thể nào. Nguồn ban đầu cho mô hình này rõ ràng là chính truy vấn; tuy nhiên, phản hồi liên quan (ví dụ t ừ người dùng cá nhân) có thể cung cấp bằng chứng bổ sung về nó.

Với cách tiếp cận này, quá trình đối sánh tài liệu–truy vấn trở nên kém rõ ràng hơn nhiều. Lưu ý rằng cả trong LM đơn giản, và trong khuôn khổ xác suất truyền thống về độ liên quan (PRF) được mô tả trong khảo sát này, quá trình đối sánh truy vấn với tài liệu vốn có trong mô hình, hoàn toàn do mô hình tự xác định. Trong bối cảnh mới này, không có quá trình đối sánh nào như vậy được định nghĩa; cần thiết phải chọn một quá trình từ bên ngoài mô hình.

Được biết cả LM của tài liệu và LM của truy vấn (độ liên quan) đều có dạng phân phối thống kê trên một từ vựng, việc so khớp trở thành câu hỏi về việc so khớp hai phân phối thống kê. Cách phổ biến nhất để thực hiện điều này là sử dụng thước đo độ lệch Kullback–Leibler (KL). Điều này có sự ủng hộ thực nghiệm tốt.

4.5 Mô hình chủ đề

Có lẽ có tiềm năng cho một loại cầu nối giữa phương pháp LM và công việc PRFin về các mô hình chủ đề ngầm định. Hầu hết những điều như vậy

work has sought to discover the topics implicit in the statistical structure of the language of documents; examples are Latent Semantic Indexing (LSI) [18], Probabilistic LSI [21] and Latent Dirichlet Allocation [7]. The hidden *eliteness* variables postulated in the probabilistic relevance framework have some similarities (although much simplified by the assumption of one eliteness variable per term). A related approach is the *parsimonious* LM [20], which attempts to model in what ways a particular document or query is distinguished from the general background language. However, we appear to be some distance from a serious unification of the LM and the PRF which is the main subject of this survey.

4.6 Divergence from Randomness

The DFR models [2], like the language models, do not contain "relevance" as a primitive notion. Also like the language models, they concentrate on the statistical distribution of terms in documents. In general, they seek to identify the ways in which term distributions differ from what one might expect on a random basis — evidence of such divergence is taken implicitly as evidence about relevance.

It is possible to derive a variety of term-weighting and document ranking functions within this framework, including a formulation that is approximately the same as BM25.

công trình đã cố gắng khám phá các chủ đề ẩn trong cấu trúc thống kê của ngôn ngữ tài liệu; ví dụ bao gồm Latent Semantic Indexing (LSI) [18], , Probabilistic LSI [21] và Latent Dirichlet Allocation [7]. Các biến tinh tú ẩn được giả định trong khuôn khổ liên quan xác suất có một số điểm tương đồng (mặc dù được đơn giản hóa rất nhiều bởi giả định rằng một biến tinh tú cho mỗi từ). Một cách tiếp cận liên quan là LM tiết kiệm [20], , cố gắng mô hình hóa theo cách nào một tài liệu hoặc truy vấn cụ thể được phân biệt so với ngôn ngữ nền chung. Tuy nhiên, dường như chúng ta còn một khoảng cách khá xa so với việc thống nhất nghiêm túc LM và PRF, là chủ đề chính của bài khảo sát này.

4.6 Sai lệch khỏi Tính Ngẫu nhiên

Các mô hình DFR [2], , giống như các mô hình ngôn ngữ, không chứa " tính liên quan" như một khái niệm cơ bản. Cũng giống như các mô hình ngôn ngữ, chúng tập trung vào phân bố thống kê của các từ trong các tài liệu. Nói chung, chúng tìm cách xác định các cách mà phân bố từ khác với những gì người ta có thể mong đợi một cách ngẫu nhiên—bằng chứng về sự khác biệt này được coi ngầm như là bằng chứng về tính liên quan.

Có thể suy ra nhiều hàm trọng số thuật ngữ và xếp hạng tài liệu khác nhau trong khuôn khổ này, bao gồm một công thức gần giống như BM25.

5

Parameter Optimisation

Like most IR models, the models in the PRF have free parameters that need to be set to appropriate values. The BM25 and BM25F models are known to be quite robust with respect to their parameters, meaning that small changes in the parameter values (or in the collection) do not produce large changes in accuracy or relevance. Nevertheless significant gains in relevance can be obtained by properly optimising the parameters, specially when we deal with a new collection.

Parameter optimisation comes with considerable costs: it will require the human evaluation of many query results, which is expensive, and the optimised parameters will be specific to the collection evaluated and may not work well for other collections. Furthermore, the optimisation procedure can be computationally costly, requiring more computing power that the search engine itself. For these reasons this approach is only appropriate for specific collections which merit the cost needed to optimise the ranking function. Examples of such collections are the WWW, large corporate collections or high-value News or Help sites.

Let us call θ the vector of all free parameters of the ranking model being tuned. In the case of BM25 this vector would have two

5

Tối ưu hóa tham số

Giống như hầu hết các mô hình IR, các mô hình trong PRF có các tham số tự do cần được đặt ở các giá trị thích hợp. Các mô hình BM25 và BM25F được biết đến là khá ổn định đối với các tham số của chúng, có nghĩa là các thay đổi nhỏ trong giá trị tham số (hoặc trong tập hợp dữ liệu) không tạo ra sự thay đổi lớn về độ chính xác hoặc mức độ liên quan. Tuy nhiên, có thể đạt được những cải thiện đáng kể về mức độ liên quan bằng cách t ối ưu hóa các tham số một cách phù hợp, đặc biệt khi chúng ta xử lý một tập hợp dữ liệu mới.

Tối ưu hóa tham số đi kèm với chi phí đáng kể: nó sẽ yêu cầu đánh giá bằng con người đối với nhiều kết quả truy vấn, điều này tốn kém, và các tham số được tối ưu hóa sẽ cụ thể cho bộ sưu tập được đánh giá và có thể không hoạt động tốt cho các bộ sưu tập khác. Hơn nữa, quy trình tối ưu hóa có thể tốn kém về mặt tính toán, đòi hỏi nhiều năng lực tính toán hơn chính công cụ tìm kiếm. Vì những lý do này, phương pháp này chỉ phù hợp cho các bộ sưu tập cụ thể mà đáng giá chi phí cần thiết để tối ưu hóa hàm xếp hạng. Ví dụ về các bộ sưu tập như vậy là WWW, các bộ sưu tập doanh nghiệp lớn hoặc các trang Tin tức hay Hỗ trợ có giá trị cao.

Hãy gọi θ là vectơ của tất cả các tham số tự do của mô hình xếp hạng đang được điều chỉnh. Trong trường hợp của BM25, vectơ này sẽ có hai

components: $\theta = (k_1, b)$. In the case of BM25F it would have more: $\theta = (k_1, b_1, \ldots, b_S, v_1, \ldots, v_S)$. If we include non-textual features then we have even more parameters, the exact number depending on the transformation used for each non-textual feature.

'Tuning' the parameters of the model can be seen as an optimisation problem, where we seek to maximise the relevance of the ranking model with respect to the model parameters θ, for a given set of relevance judgements. More specifically, if we fix the document collection and a set of queries with their associated relevance judgements, then for any parameter setting θ we can compute the performance measure of our choice $M(\theta)$. What is left is to find the parameter setting that maximises $M(\theta)$. This is exactly an n-dimensional optimisation problem with M as the target function being optimised over the space of valid θ values.

Optimising standard IR measures,[1] however, is not easy: they are very expensive to evaluate, they have local maxima and *plateaus*, they are not smooth and they don't have gradients [49]. For these reasons, it is not easy to apply standard optimisation techniques. Even applying simple 0-th order optimisation techniques such as trusted region optimisation is difficult and expensive. In practice we use a number of ad hoc techniques to speed up exhaustive search. We will discuss these in the next subsection.

Another alternative is to change the function being optimised. This approach is specially useful when one is optimising very many features, and is discussed in the last subsection.

5.1 Greedy Optimisation

We discuss here a number of techniques (some heuristics, some implementation tricks) we used in the past to speedup the exhaustive search and find good parameter values.

Caching: Because function evaluations are so expensive, we cache the evaluations. Indeed we may often re-visit a parameter value in our

[1] Such as Average Precision, Precision@k, Mean Reciprocal Rank and Discounted Cumulative Gain.

các thành phần: $\theta = (k_1, b)$. Trong trường hợp của BM25F, nó sẽ có nhiều hơn: $\theta = (k_1, b_1, \ldots, b_S, v1, \ldots, v_S)$. Nếu chúng ta bao gồm các đặc trưng không phải văn bản thì chúng ta sẽ có nhiều tham số hơn nữa, số lượng chính xác tùy thuộc vào phép biến đổi được sử dụng cho từng đặc trưng không phải văn bản.

'Điều chỉnh' các tham số của mô hình có thể được xem như một vấn đề tối ưu hóa, nơi chúng ta tìm cách tối đa hóa mức độ liên quan của mô hình xếp hạng đối với các tham số mô hình θ, cho một tập một tập các đánh giá mức độ liên quan nhất định. Cụ thể hơn, nếu chúng ta cố định tập tài liệu và một tập các truy vấn cùng với các đánh giá mức độ liên quan kèm theo, thì với bất kỳ thiết lập tham số nào θ chúng ta có thể tính toán chỉ số hiệu suất mà chúng ta lựa chọn $M(\theta)$. Điều còn lại là tìm thiết lập tham số tối đa hóa $M(\theta)$. Đây chính xác là một bài toán tối ưu hóa n chiều với M là hàm mục tiêu được tối ưu hóa trên không gian các giá trị hợp lệ θ .

Tối ưu hóa các phép đo IR tiêu chuẩn,[1] tuy nhiên, không hề dễ dàng: chúng rất tốn kém để đánh giá, có các cực đại và bậc thang cục bộ, không mượt mà và không có đạo hàm [49]. Vì những lý do này, việc áp dụng các kỹ thuật tối ưu hóa tiêu chuẩn không dễ dàng. Ngay cả việc áp dụng các kỹ thuật tối ưu hóa bậc 0 đơn giản như tối ưu hóa vùng tin cậy cũng khó và tốn kém. Trong thực tế, chúng tôi sử dụng một số kỹ thuật ad hoc để tăng tốc tìm kiếm toàn diện. Chúng tôi sẽ thảo luận về những điều này trong phần phụ tiếp theo.

Một lựa chọn khác là thay đổi hàm đang được tối ưu hóa. Cách tiếp cận này đặc biệt hữu ích khi người ta tối ưu hóa rất nhiều đặc trưng, và được thảo luận trong phần phụ cuối cùng.

5.1 Tối ưu tham lam

Chúng tôi thảo luận ở đây một số kỹ thuật (một số là thuật toán suy đoán, một số là mẹo triển khai) mà chúng tôi đã sử dụng trong quá khứ để tăng tốc tìm kiếm toàn diện và tìm các giá trị tham số tốt.

Bộ nhớ đệm: Vì việc đánh giá hàm tốn kém rất nhiều, chúng tôi lưu trữ các đánh giá này. Thật vậy, chúng tôi có thể thường xuyên xem lại một giá trị tham số trong

[1] Như Độ Chính Xác Trung Bình, Độ Chính Xác@k, Trung Bình Hạng Độ Lùi Ngược và Lợi Ích Tích Lũy Giảm Giá.

search for the optimum. It would be wasteful to re-evaluate all the queries; instead, we store the resulting relevance in a hash table using the parameter values as the key: $H[\theta] \leftarrow M(\theta)$.

Grid: It is also useful to set a minimum resolution for every parameter, defining a *grid* of allowed parameters values. For example, in most of our experiments we did not allow parameters to change beyond the second decimal. This has negligible affect on the relevance performance and greatly increases the effect of caching and the speed of convergence. Furthermore it makes it easier to report and share parameter values.

5.1.1 Robust Line Search

We first consider methods for optimising over a single parameter. Most parameters being optimised are positive but unbounded above. Therefore we do not know the region of interest of the parameter being optimised, nor do we know the required resolution (the size of the intervals to be tested). For this reason we developed the following search algorithm, which we call Robust Line Search (RLS).

Call l and r the current left and right brackets of the 1−D search space. Split the region in m equal parts of size $(r - l)/m$. Compute the performance on the $m + 1$ region boundaries, and call c the boundary with the highest performance.

The idea is to move towards c by re-centering the search region around c and scaling it appropriately. If $l < c < r$ we need to *zoom in* into c, by scaling down the search region. Since the function being optimised has local maxima we cannot zoom too much, or we may completely lose the global maximum; for this reason we tend to zoom very conservatively. On the other hand, if c equals r or l, it is most likely that the maximum is outside the current search region, and possibly far away. Therefore we increase the size of the search region. We iterate this until l and r are within the some minimum distance, typically below the minimum resolution set. An example optimisation is illustrated in Figure 5.1.

tìm kiếm giá trị tối ưu. Sẽ là lãng phí nếu đánh giá lại tất cả các truy vấn; thay vào đó, chúng tôi lưu trữ độ liên quan kết quả trong một bảng băm sử dụng các giá trị tham số làm khóa: $H[\theta] \leftarrow M(\theta)$.

Lưới: Nó cũng hữu ích khi đặt độ phân giải tối thiểu cho mỗi tham số, định nghĩa một lưới các giá trị tham số được phép. Ví dụ, trong hầu hết các thí nghiệm của chúng tôi, chúng tôi không cho phép các tham số thay đổi vượt quá chữ số thập phân thứ hai. Điều này có ảnh hưởng không đáng kể đến hiệu suất liên quan và tăng đáng kể hiệu quả của bộ nhớ đệm cũng như tốc độ hội tụ. Hơn nữa, điều này giúp dễ dàng báo cáo và chia sẻ các giá trị tham số.

5.1.1 Tìm kiếm tuyến tính mạnh mẽ

Trước tiên, chúng ta xem xét các phương pháp tối ưu hóa trên một tham số duy nhất. Hầu hết các tham số được tối ưu hóa đều là số dương nhưng không có giới hạn trên. Do đó, chúng ta không biết vùng quan tâm của tham số đang được tối ưu hóa, cũng như không biết độ phân giải cần thiết (kích thước của các khoảng cần kiểm tra). Vì lý do này, chúng tôi đã phát triển thuật toán tìm kiếm sau, mà chúng tôi gọi là Tìm kiếm Tuyến tính Mạnh mẽ (Robust Line Search - RLS).

Gọi l và r là dấu ngoặc trái và phải hiện tại của không gian tìm kiếm 1–D. Chia vùng thành m phần bằng nhau kích thước $(r - l)/m$. Tính hiệu suất trên các biên của vùng $m + 1$, và gọi c là biên có hiệu suất cao nhất.

Ý tưởng là tiến về phía c bằng cách tái định tâm vùng tìm kiếm quanh c và điều chỉnh tỷ lệ phù hợp. Nếu $l < c < r$ chúng ta cần phóng to vào c, bằng cách thu nhỏ vùng tìm kiếm. Do hàm được tối ưu hóa có các cực đại cục bộ, chúng ta không thể phóng to quá mức, nếu không có thể mất hoàn toàn cực đại toàn cục; vì lý do này, chúng ta thường phóng to một cách thận trọng. Mặt khác, nếu c bằng r hoặc l, rất có khả năng cực đại nằm ngoài vùng tìm kiếm hiện tại và có thể ở xa. Do đó, chúng ta tăng kích thước vùng tìm kiếm. Chúng ta lặp lại quá trình này cho đến khi l và r nằm trong một khoảng cách tối thiểu, thường dưới độ phân giải tối thiểu đã đặt. Một ví dụ về tối ưu hóa được minh họa trong Hình 5.1.

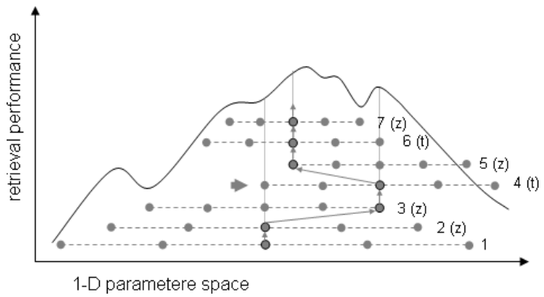


Fig. 5.1 Greedy Optimisation example: robust line search.

5.2 Multidimensional Optimisation

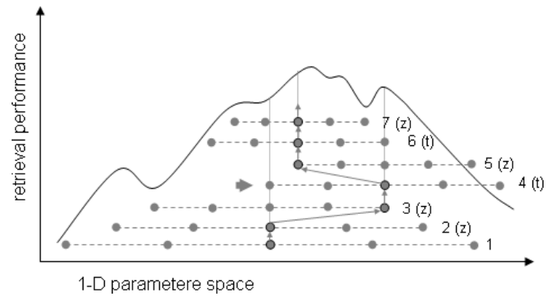
Any 1-D optimisation method can be generalised to n-D in several ways. We have used two methods to do this, both of which worked well in practice.

Greedy Robust Line Search: Imagine that we want to run the RLS method on a 2-D problem, with parameters $\theta = (\theta_1, \theta_2)$. Let's leave θ_2 as a subordinate variable and run RLS on θ_1. Every time that we need to compute the performance $M(\theta)$ at a given point $\theta_1 = z$, we would need to fix the subordinate θ_2 at its optimal value. To find out this value, we can run a local RLS to optimise θ_2 locally while keeping $\theta_1 = z$. Generalising this, every line optimisation with i parameters fires off an optimisation with $i - 1$ subordinate parameters and so on, recursively. Of course this is a greedy approximation to the exhaustive (exponential) exploration of the parameter space, because we are running RLS. However, this approach remains exponentially expensive with respect to n because of its recursive nature, and therefore it is not practicable for large n (e.g., $n > 3$).

Promising Directions: Another way we have used to carry out searches in n dimensions is the following.[2] Choose an initial point for

[2] This method can be seen as a linear version of *trusted region* optimisation methods [4, 5]; it has the advantage of requiring much fewer function evaluations, which are extremely expensive in our case.

380 *Parameter Optimisation*



Hình 5.1 Ví dụ về Tối ưu tham lam: tìm kiếm đường thẳng bền vững.

5.2 Tối ưu hóa đa chiều

Bất kỳ phương pháp tối ưu hóa 1 chiều nào cũng có thể được tổng quát hóa thành n-chiều theo một số cách. Chúng tôi đã sử dụng hai phương pháp để làm điều này, cả hai đều hoạt động tốt trong thực tế.

Tìm kiếm đường thẳng mạnh tham lam: Hãy tưởng tượng rằng chúng ta muốn chạy phương pháp RLS trên một bài toán 2 chiều, với các tham số $\theta = (\theta_1, \theta_2)$. Hãy để θ_2 là một biến phụ thuộc và chạy RLS trên θ_1. Mỗi lần chúng ta cần tính hiệu suất $M(\theta)$ tại một điểm $\theta_1 = z$ nhất định, chúng ta sẽ cần cố định θ_2 phụ thuộc ở giá trị tối ưu của nó. Để tìm giá trị này, chúng ta có thể chạy một RLS cục bộ để tối ưu hóa θ_2 tại chỗ trong khi giữ $\theta_1 = z$. Tổng quát hóa điều này, mỗi tối ưu hóa theo đường thẳng với các tham số i sẽ kích hoạt một tối ưu hóa với các tham số phụ $i - 1$ và cứ tiếp tục như vậy, theo cách đệ quy. Tất nhiên đây là một xấp xỉ tham lam cho việc khám phá toàn diện (theo cấp số mũ) của không gian tham số, bởi vì chúng ta đang chạy RLS. Tuy nhiên, cách tiếp cận này vẫn tốn kém theo cấp số mũ đối với n do tính chất đệ quy của nó, và vì vậy nó không khả thi cho các n lớn (ví dụ, $n > 3$).

Hướng triển vọng: Một cách khác mà chúng tôi đã sử dụng để thực hiện các tìm kiếm trong n chiều là như sau. [2] Chọn một điểm khởi đầu cho

[2]Phương pháp này có thể được xem như một phiên bản tuyến tính của *trusted region* các phương pháp tối ưu hóa [4, 5]; nó có lợi thế là yêu cầu đánh giá hàm số ít hơn nhiều, vốn cực kỳ tốn kém trong trường hợp của chúng tôi.

each parameter (call the resulting the vector θ). Run n 1−D independent searches, to find the optimum value θ'_i of each parameter when all others are kept fixed at θ. Each of these optimal values found defines a *promising directions* in parameter space. Now consider the vector going from θ to $\theta' = (\theta'_1, \ldots, \theta'_n)$. We expect this vector to move through interesting regions of space if there is correlation between features. Therefore we do one more 1−D optimisation along this line. We do this by re-parameterising the system with a new variable that moves all parameters linearly from θ to θ'. Finally we choose the best parameter setting found so far and we re-start the process. An example optimisation is illustrated in Figure 5.2, where we show the first two iterations (noted 1 and 2), each consisting of three line searches (noted a, b and c). The total cost of an iteration is $(n + 1)$ 1−D optimisations. Therefore, it grows only linearly with n, but it may require very many iterations to complete.

K1 Scaling: Note that in general k_1 will depend on the weights assigned to streams in BM25F, even if it is kept as a stream-independent parameter. This is because the stream weights in effect rescale the *tf* values, and k_1 has to be adjusted accordingly. If we have a good k_1^{BM25} value for the regular BM25 function (no streams), we can propose a good initial value of k_1 for BM25F by scaling it according to the change

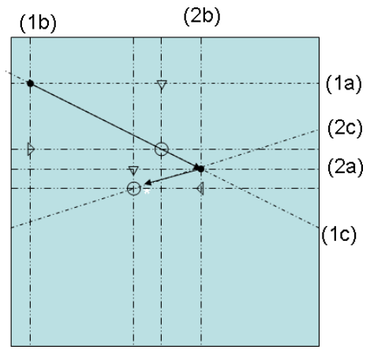
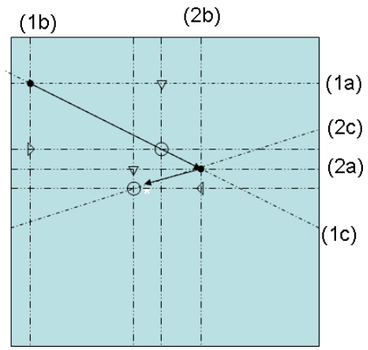


Fig. 5.2 Greedy optimisation example: promising directions.

mỗi tham số (gọi kết quả là vector θ). Thực hiện n 1–D các tìm kiếm độc lập, để tìm giá trị tối ưu θ'_i của mỗi tham số khi tất cả các tham số khác được giữ cố định tại θ. Mỗi giá trị tối ưu được tìm thấy này xác định một hướng đầy hứa hẹn trong không gian tham số. Bây giờ xem xét vector đi từ θ đến $\theta' = (\theta'_1, ..., \theta'_n)$. Chúng ta kỳ vọng vector này sẽ di chuyển qua các vùng không gian thú vị nếu có sự tương quan giữa các đặc trưng. Do đó, chúng ta thực hiện thêm một tối ưu hóa 1–D dọc theo đường này. Chúng tôi làm điều này bằng cách tái tham số hóa hệ thống với một biến mới di chuyển tất cả các tham số một cách tuyến tính từ θ đến θ'. Cuối cùng chúng tôi chọn cài đặt tham số tốt nhất được tìm thấy cho đến nay và chúng tôi bắt đầu lại quá trình. Một ví dụ về tối ưu hóa được minh họa trong Hình 5.2, nơi chúng tôi hiển thị hai lần lặp đầu tiên (được ghi chú 1 và 2), mỗi lần lặp bao gồm ba tìm kiếm theo đường thẳng (được ghi chú a, b và c). Tổng chi phí của một lần lặp là $(n + 1)$ 1–D tối ưu hóa. Do đó, nó chỉ tăng tuyến tính với n, nhưng nó có thể yêu cầu v

K1 Tỷ lệ: Lưu ý rằng nói chung k_1 sẽ phụ thuộc vào các trọng số được gán cho các luồng trong BM25F, ngay cả khi nó được giữ như một tham số độc lập với luồng. Điều này là do các trọng số luồng thực chất làm thay đổi giá trị tf, và k_1 phải được điều chỉnh tương ứng. Nếu chúng ta có một giá trị k_1^{BM25} tốt cho hàm BM25 thông thường (không có luồng), chúng ta có thể đề xuất một giá trị ban đầu tốt của k_1 cho BM25F bằng cách điều chỉnh theo sự thay đổi



Hình 5.2 Ví dụ về tối ưu hóa tham lam: các hướng triển vọng.

in average document length from the unweighted to the weighted form:

$$k_1^{\text{BM25F}} \approx k_1^{\text{BM25}} \frac{\sum_s v_s avsl_s}{\sum_s avsl_s} \tag{5.1}$$

5.2.1 Factoring the Search

A very useful technique for speeding up the search in practice is to factor the search into *batches*, optimising together only the parameters that are known to be strongly dependent. When doing this it is important to choose the initial parameters and the order of the batches judiciously. A typical schedule for BM25F may be:

1. Compute the optimal k_1 and b (ignoring streams). This is equivalent to setting all $v_s = 1$ and all $b_s = b$. (Cost: 1×2D);
2. Optimise stream weights $\{w\}_{s=1..S}$ jointly. We use here the k_1 re-scaling trick in Step (5.1). (Cost: 1×SD); and
3. Optimise k_1 and $\{b\}_{s=1..S}$ independently (Cost: $(S+1)$ ×1D).

This schedule may be repeated until no further increase in performance is obtained. When dealing with non-textual features, the optimisation above is usually interleaved with the optimisation of the non-textual features, which can also be done independently or jointly by batches.

5.3 Gradient Optimisation

A different possibility is to choose a performance function that can be optimised directly by machine learning techniques. This approach was pursued with some success a few years ago [1, 10, 55], and has now become an active area of research (see for example the recent NIPS and SIGIR workshops on this topic [23, 28]). The main idea is to approximate rank-dependant relevance functions such as NDCG by a function with known gradients. Then we can apply the battery of gradient-based optimisation methods. The speed of these methods does not grow exponentially with the number of dimensions optimised, so one can optimise very many parameters simultaneously. Furthermore, if BM25F is being combined with a larger number of other (non-textual)

trong độ dài tài liệu trung bình từ dạng không trọng số sang dạng có trọng số:

$$k_1^{\text{BM25F}} \approx k_1^{\text{BM25}} \frac{\sum_s v_s avsl_s}{\sum_s avsl_s} \tag{5.1}$$

5.2.1 Phân tích yếu tố của tìm kiếm

Một kỹ thuật rất hữu ích để tăng tốc quá trình tìm kiếm trong thực tế là chia tìm kiếm thành các lô, chỉ tối ưu hóa cùng nhau các tham số được biết là phụ thuộc mạnh. Khi thực hiện việc này, điều quan trọng là phải chọn các tham số ban đầu và thứ tự của các lô một cách thận trọng. Một lịch trình điển hình cho BM25F có thể là:

1. Tính toán tối ưu k_1 và b (bỏ qua các luồng). Điều này tương đương với việc đặt tất cả v$_s = 1$ và tất cả $b_s = b$. (Chi phí: $1\times$2D); 2. Tối ưu hóa trọng số luồng $\{w\}_{s=1..S}$ cùng nhau. Ở đây chúng tôi sử dụng mẹo tái chuẩn hóa k_1 trong Bước (5.1). (Chi phí: $1\times S$D); và 3. Tối ưu hóa k_1 và $\{b\}_{s=1..S}$ một cách độc lập (Chi phí: $(S+1)$ $\times$1D).

Lịch trình này có thể được lặp lại cho đến khi không đạt được sự tăng hiệu suất thêm nữa. Khi xử lý các đặc trưng không phải văn bản, tối ưu hóa trên thường được xen kẽ với tối ưu hóa các đặc trưng không phải văn bản, điều này cũng có thể được thực hiện độc lập hoặc cùng nhau theo từng lô.

5.3 Tối ưu hóa Gradient

Một khả năng khác là chọn một hàm hiệu suất có thể được tối ưu trực tiếp bằng các kỹ thuật học máy. Cách tiếp cận này đã được theo đuổi với một số thành công vài năm trước [1, 10, 55], và hiện nay đã trở thành một lĩnh vực nghiên cứu tích cực (xem ví dụ các hội thảo gần đây của NIPS và SIGIR về chủ đề này [23, 28]). Ý tưởng chính là xấp xỉ các hàm độ liên quan phụ thuộc vào thứ hạng như NDCG bằng một hàm có gradient được biết. Sau đó, chúng ta có thể áp dụng hàng loạt các phương pháp tối ưu dựa trên gradient. Tốc độ của các phương pháp này không tăng theo cấp số nhân với số chiều được tối ưu, vì vậy có thể tối ưu rất nhiều tham số cùng lúc. Hơn nữa, nếu BM25F được kết hợp với một số lượng lớn các yếu tố khác (không phải văn bản)

features, methods can be used to optimise jointly all parameters. For example, this is the case in [55] where the overall model is an artificial neural network which takes as input many features, one of them being BM25F. It is out of the scope of this survey to detail gradient-based optimisation methods.

các đặc trưng, các phương pháp có thể được sử dụng để tối ưu hóa đồng thời tất cả các tham số. Ví dụ, đây là trường hợp trong [55] nơi mà mô hình tổng thể là một mạng nơ-ron nhân tạo nhận nhiều đặc trưng làm đầu vào, một trong số đó là BM25F. Việc chi tiết các phương pháp tối ưu hóa dựa trên gradient nằm ngoài phạm vi của khảo sát này.

6

Conclusions

The classical probabilistic relevance framework has provided a series of well-founded scoring formula, as well as some significant insights into different aspects of search. One of the reasons of the success of the PRF, we believe, is the powerful combination of sound theoretical modelling and a pragmatic parameterisation that exploits our prior knowledge in IR. We do not believe that the PRF has reached the end of its useful life. When it is well understood, the PRF model can provide a solid ground on which to analyse new IR problems and derive new solutions.

6

Kết luận

Khung xác suất liên quan cổ điển đã cung cấp một loạt công thức đánh giá có cơ sở vững chắc, cũng như một số hiểu biết quan trọng về các khía cạnh khác nhau của tìm kiếm. Một trong những lý do thành công của PRF, theo chúng tôi, là sự kết hợp mạnh mẽ giữa mô hình lý thuyết vững chắc và việc tham số hóa thực dụng khai thác kiến thức trước của chúng ta trong IR. Chúng tôi không tin rằng PRF đã đến cuối vòng đời hữu ích của nó. Khi nó được hiểu rõ, mô hình PRF có thể cung cấp một nền tảng vững chắc để phân tích các vấn đề IR mới và đưa ra các giải pháp mới.

References

[1] S. Agarwal, C. Cortes, and R. Herbrich, eds., *Proceedings of the NIPS 2005 Workshop on Learning to Rank*, 2005.

[2] G. Amati, C. J. van Rijsbergen, and C. Joost, "Probabilistic models of information retrieval based on measuring the divergence from randomness," *ACM Transactions on Information Systems*, vol. 20, no. 4, pp. 357–389, 2002.

[3] M. M. Beaulieu, M. Gatford, X. Huang, S. E. Robertson, S. Walker, and P. Williams, "Okapi at TREC-5," *The Fifth Text Retrieval Conference (TREC-5). NIST Special Publication* 500-238, pp. 143–165, 1997.

[4] F. V. Berghen, "Trust Region Algorithms," Webpage, http://www.lemurproject.org.

[5] F. V. Berghen, "CONDOR: A constrained, non-linear, derivative-free parallel optimizer for continuous, high computing load, noisy objective functions," PhD thesis, Université Libre de Bruxelles, 2004.

[6] C. Bishop, *Pattern Recognition and Machine Learning (Information Science and Statistics)*. Springer, 2006.

[7] D. M. Blei, A. Y. Ng, and M. I. Jordan, "Latent dirichlet allocation," *Journal of Machine Learning Research*, vol. 3, pp. 993–1022, 2003.

[8] D. Bodoff and S. E. Robertson, "A new unified probabilistic model," *Journal of the American Society for Information Science and Technology*, vol. 55, pp. 471–487, 2004.

[9] P. Boldi and S. Vigna, "MG4J at TREC 2005," in *The Fourteenth Text Retrieval Conference (TREC 2005) Proceedings, NIST Special Publication* 500-266, 2005. http://mg4j.dsi.unimi.it/.

Tài liệu tha m khảo

[1] S. Agarwal, C. Cortes, và R. Herbrich, biên tập., *Proceedings of the NIPS 2005 Workshop on Learning to Rank* 2005 , .[2] G. Amati, C. J. van Rijsbergen, và C. Joost, "Các mô hình xác suất của truy xuất thông tin dựa trên đo độ lệch so với ngẫu nhiên," *ACM Transactions on Information Systems* 20, 4, 357 389, 2002 , tập. số. tr. – .[3] M. M. Beaulieu, M. Gatford, X. Huang, S. E. Robertson, S. Walker, và P. Williams, "Okapi tại TREC- 5, *The Fifth Text Retrieval Conference (TREC-* " - tr. – .[4] *5). NIST Special Publication* 500 238, 143 165, 1997 F. V. Berghen, "Thuật toán vùng tin cậy," Trang web, http://www.lemurproject.org.[5] F. V. Berghen, "CONDOR: Bộ tối ưu song song phi tuyến, không sử dụng đạo hàm, có ràng buộc cho các hàm mục tiêu liên tục, tải tính toán cao, và nhiễu nhiễu," Luận án tiến sĩ, Universit´e Libre de Bruxelles, 2004.[6] C. Bishop, *Pattern Recognition and Machine Learning (Information Science and Statistics)* 2006 . Springer, .[7] D. M. Blei, A. Y. Ng, và M. I. Jordan, "Phân bổ Dirichlet tiềm ẩn," *Journal of Machine Learning Research* 3, 993 1022, 2003 , tập. tr. – .[8] D. Bodoff và S. E. Robertson, "Một mô hình xác suất hợp nhất mới," *Journal of the American Society for Information Science and Technology* 55, , tập. tr. 471– 487, 2004.[9] P. Boldi và S. Vigna, "MG 4 2005, *The Fourteenth Text Retrieval* J tại TREC" tr *Conference (TREC 2005) Proceedings NIST Special Publication* 500 266, 2005 ong , - . http://mg4j.dsi.unimi.it/.

[10] C. Burges, T. Shaked, E. Renshaw, A. Lazier, M. Deeds, N. Hamilton, and G. Hullender, "Learning to rank using gradient descent," in *Proceedings of the International Conference on Machine Learning (ICML)*, vol. 22, p. 89, 2005.

[11] W. Cooper, "Some inconsistencies and misidentified modelling assumptions in probabilistic information retrieval," *ACM Transactions on Information Systems*, vol. 13, pp. 110–111, 1995.

[12] N. Craswell, S. E. Robertson, H. Zaragoza, and M. Taylor, "Relevance weighting for query independent evidence," in *Proceedings of the 28th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval*, pp. 472–479, ACM, 2005.

[13] N. Craswell, H. Zaragoza, and S. E. Robertson, "Microsoft Cambridge at TREC-14: Enterprise track," in *The Fourteenth Text Retrieval Conference (TREC 2005)*, 2005.

[14] F. Crestani, M. Lalmas, C. J. van Rijsbergen, and I. Campbell, ""Is this document relevant? ... probably": A survey of probabilistic models in information retrieval," *ACM Computing Surveys*, vol. 30, no. 4, 1998.

[15] W. B. Croft and D. J. Harper, "Using probabilistic models of document retrieval without relevance information," *Journal of Documentation*, vol. 35, pp. 285–295, 1979.

[16] W. Feller, *An Introduction to Probability Theory and Its Applications*, vol. 1. Wiley, 1968.

[17] N. Fuhr, "Probabilistic Models in Information Retrieval," *The Computer Journal*, vol. 35, no. 3, 1992.

[18] G. W. Furnas, S. Deerwester, S. T. Dumais, T. K. Landauer, R. A. Harshman, L. A. Streeter, and K. E. Lochbaum, "Information retrieval using a singular value decomposition model of latent semantic structure," in *Proceedings of the 11th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval*, pp. 465–480, ACM, 1988.

[19] S. P. Harter, "A probabilistic approach to automatic keyword indexing (parts 1 and 2)," *Journal of the American Society for Information Science*, vol. 26, pp. 197–206 and 280–289, 1975.

[20] D. Hiemstra, S. E. Robertson, and H. Zaragoza, "Parsimonious language models for information retrieval," in *Proceedings of the 27th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval*, pp. 178–185, ACM, 2004.

[21] T. Hofmann, "Probabilistic latent semantic indexing," in *Proceedings of the 22nd Annual International ACM SIGIR Conference on Research and Development in Information Retrieval*, pp. 50–57, ACM, 1999.

[22] Indri. Homepage. http://www. lemurproject.org/indri.

[23] T. Joachims, H. Li, T. Y. Liu, and C. Zhai, "Learning to rank for information retrieval (LR4IR 2007)," *SIGIR Forum*, vol. 41, no. 2, pp. 58–62, 2007.

[24] J. Lafferty and C. Zhai, "Document language models, query models, and risk minimization for information retrieval," in *Proceedings of the 24th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval*, ACM, 2001.

386 References

[10] C. Burges, T. Shaked, E. Renshaw, A. Lazier, M. Deeds, N. Hamilton, và G. Hullender, "Học xếp hạng sử dụng gradient descent," trong *Proceedings of the International Conference on Machine Learning (ICML)* 22, 89, 2005 , tập tr. . [11]

W. Cooper, "Một số sự không nhất quán và giả định mô hình bị xác định sai trong truy xuất thông tin xác suất," *ACM Transactions on Information Systems* 13, 110 111, 1995 , tập tr. – .

[12] N. Craswell, S. E. Robertson, H. Zaragoza, và M. Taylor, "Trọng số phù hợp cho bằng chứng độc lập với truy vấn," trong *Proceedings of the 28th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval* 472 479, 2005 , tr. – ACM, .

[13] N. Craswell, H. Zaragoza, và S. E. Robertson, "Microsoft Cambridge tại TREC-14 *The Fourteenth Text Retrieval Conference* : Đường tr *(TREC 2005)* 2005
track Doanh nghiệp," trong , . [14] F. Crestani, M. Lalmas, C. J. van Rijsbergen, và I. Campbell, ""Tài liệu này có phù hợp không? ... có lẽ": Một khảo sát về các mô hình xác suất trong truy xuất thông tin," *ACM Computing Surveys*, tập 30, số 4, 1998. [15] W. B. Croft và D. J. Harper, "Sử dụng các mô hình xác suất của truy xuất tài liệu mà không có thông tin phù hợp," *Journal of Documentation*, tập 35, tr. 285–295, 1979. [16] W. Feller, *An Introduction to Probability Theory and Its Applications*, tập 1. Wiley, 1968. [17] N. Fuhr, "Các mô hình xác suất trong truy xuất thông tin

[25] J. Lafferty and C. Zhai, "Probabilistic relevance models based on document and query generation," in *Language Modelling for Information Retrieval*, (W. B. Croft and J. Lafferty, eds.), pp. 1–10, Kluwer, 2003.
[26] V. Lavrenko and W. B. Croft, "Relevance based language models," in *Proceedings of the 24th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval*, pp. 120–127, ACM, 2001.
[27] Lemur Toolkit. Homepage. http://www.lemurproject.org.
[28] H. Li, T. Y. Liu, and C. Zhai, "Learning to rank for information retrieval (LR4IR 2008)," *SIGIR Forum*, vol. 42, no. 2, pp. 76–79, 2008.
[29] Lucene. Homepage. http://lucene.apache.org/.
[30] M. E. Maron and J. L. Kuhns, "On relevance, probabilistic indexing and information retrieval," *Journal of the ACM*, vol. 7, no. 3, pp. 216–244, 1960.
[31] D. Metzler, "Automatic feature selection in the Markov random field model for information retrieval," in *Proceedings of the Sixteenth ACM Conference on Information and Knowledge Management*, pp. 253–262, ACM New York, NY, USA, 2007.
[32] D. Metzler and W. B. Croft, "A Markov random field model for term dependencies," in *Proceedings of the 28th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval*, pp. 472–479, ACM, 2005.
[33] D. Metzler, T. Strohman, and B. Croft, *Information Retrieval in Practice*. Pearson Education (US), 2009.
[34] MG4J: Managing gigabytes for java. Homepage. http://mg4j.dsi.unimi.it/.
[35] Okapi-Pack. Homepage. http://www.soi.city.ac.uk/ andym/OKAPI-PACK.
[36] J. R. Pérez-Agüera and H. Zaragoza, "UCM-Y!R at CLEF 2008 Robust and WSD tasks," *CLEF 2008 Workshop*, 2008.
[37] J. R. Pérez-Agüera, H. Zaragoza, and L. Araujo, "Exploiting morphological query structure using genetic optimization," in *NLDB 2008 13th International Conference on Applications of Natural Language to Information Systems*, Lecture Notes in Computer Science (LNCS), Springer Verlag, 2008.
[38] J. Pérez-Iglesias, "BM25 and BM25F Implementation for Lucene," Webpage, http://nlp.uned.es/∼jperezi/Lucene-BM25.
[39] PF-Tijah. Homepage. http://dbappl.cs.utwente.nl/pftijah.
[40] S. E. Robertson, "The probability ranking principle in information retrieval," *Journal of Documentation*, vol. 33, pp. 294–304, 1977.
[41] S. E. Robertson, "On term selection for query expansion," *Journal of Documentation*, vol. 46, pp. 359–364, 1990.
[42] S. E. Robertson, "Threshold setting and performance optimization in adaptive filtering," *Information Retrieval*, vol. 5, pp. 239–256, 2002.
[43] S. E. Robertson, M. E. Maron, and W. S. Cooper, "The unified probabilistic model for IR," in *Proceedings of Research and Development in Information Retrieval*, (G. Salton and H.-J. Schneider, eds.), pp. 108–117, Berlin: Springer-Verlag, 1983.
[44] S. E. Robertson and K. Sparck Jones, "Relevance weighting of search terms," *Journal of the American Society for Information Science*, 1977.

[25] J. Lafferty và C. Zhai, "Mô hình xác suất liên quan dựa trên việc tạo tài liệu và truy vấn," trong *Language Modelling for Information Retrieval*, (W. B. Croft và J. Lafferty, biên tập), tr. 1–10, Kluwer, 2003. [26] V. Lavrenko và W. B. Croft, "Mô hình ngôn ngữ dựa trên liên quan," trong *Proceedings of the 24th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval* 120 127, 2001 , tr. – ACM, .

[27] Bộ công cụ Lemur. Trang chủ. http://www.lemurproject.org. [28] H. Li, T. Y. Liu, và C. Zhai, "Học xếp hạng cho truy xuất thông tin (LR4IR 2008)," *SIGIR Forum*, tập 42, số 2, tr. 76–79, 2008. [29] Lucene. Trang chủ. http://lucene.apache.org/. [30] M. E. Maron và J. L. Kuhns, "Về liên quan, lập chỉ mục xác suất và truy xuất thông tin," *Journal of the ACM*, tập 7, số 3, tr. 216–244, 1960. [31] D. Metzler, "Lựa chọn tính năng tự động trong mô hình trường ngẫu nhiên Markov cho truy xuất thông tin," trong *Proceedings of the Sixteenth ACM Conference on Information and Knowledge Management* 253 262, , tr. – ACM New York, NY, USA, 2007. [32] D. Metzler và W. B. Croft, "Mô hình trường ngẫu nhiên Markov cho sự phụ thuộc thuật ngữ," trong *Proceedings of the 28th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval* 472 479, , tr. – ACM, 2005. [33] D. Metzler, T. Strohman, và B. Croft, *Information Retrieval in Practice*. Pearson Education (Mỹ), 2009. {v18

[45] S. E. Robertson, C. J. van Rijsbergen, and M. F. Porter, "Probabilistic models of indexing and searching," in *Information Retrieval Research (Proceedings of Research and Development in Information Retrieval, Cambridge, 1980)*, (R. N. Oddy, S. E. Robertson, C. J. van Rijsbergen, and P. W. Williams, eds.), pp. 35–56, London: Butterworths, 1981.

[46] S. E. Robertson and S. Walker, "Some Simple Effective Approximations to the 2-Poisson Model for Probabilistic Weighted Retrieval," in *Proceedings of the 17th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval*, pp. 232–241, ACM/Springer, 1994.

[47] S. E. Robertson and S. Walker, "On relevance weights with little relevance information," in *Proceedings of the 20th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval*, pp. 16–24, ACM, 2007.

[48] S. E. Robertson, S. Walker, M. Hancock-Beaulieu, A. Gull, and M. Lau, "Okapi at TREC," in *The First Text Retrieval Conference (TREC-1), NIST Special Publication* 500-207, pp. 21–30, 1992.

[49] S. E. Robertson and H. Zaragoza, "On rank-based effectiveness measures and optimization," *Information Retrieval*, vol. 10, no. 3, pp. 321–339, 2007.

[50] S. E. Robertson, H. Zaragoza, and M. Taylor, "Simple BM25 extension to multiple weighted fields," in *Proceedings of the 2004 ACM CIKM International Conference on Information and Knowledge Management*, pp. 42–49, ACM, 2004.

[51] R. Song, M. J. Taylor, J. R. Wen, H. W. Hon, and Y. Yu, "Viewing term proximity from a different perspective," *Advances in Information Retrieval (ECIR 2008),* Springer LNCS 4956, pp. 346–357, 2008.

[52] K. Sparck Jones, S. Walker, and S. E. Robertson, "A probabilistic model of information retrieval: Development and comparative experiments. Part 1," in *Information Processing and Management*, pp. 779–808, 2000.

[53] K. Sparck Jones, S. Walker, and S. E. Robertson, "A probabilistic model of information retrieval: Development and comparative experiments. Part 2," in *Information Processing and Management*, pp. 809–840, 2000.

[54] T. Tao and C. Zhai, "An exploration of proximity measures in information retrieval," in *Proceedings of the 20th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval*, pp. 295–302, ACM, 2007.

[55] M. Taylor, H. Zaragoza, N. Craswell, S. E. Robertson, and C. Burges, "Optimisation methods for ranking functions with multiple parameters," in *Fifteenth Conference on Information and Knowledge Management (ACM CIKM)*, 2006.

[56] Terrier. Homepage. http://ir.dcs.gla.ac.uk/terrier.

[57] R. van Os D. Hiemstra, H. Rode, and J. Flokstra, "PF/Tijah: Text search in an XML database system," *Proceedings of the 2nd International Workshop on Open Source Information Retrieval (OSIR)*, pp. 12–17, http://dbappl.cs.utwente.nl/pftijah, 2006.

[58] C. J. van Rijsbergen, *Information Retrieval*. Butterworth, 1979.

[59] E. M. Voorhees and D. K. Harman, "Overview of the eighth text retrieval conference (TREC-8)," *The Eighth Text Retrieval Conference (TREC-8), NIST Special Publication* 500-246, pp. 1–24, 2000.

388 References

[45] S. E. Robertson, C. J. van Rijsbergen, và M. F. Porter, "Mô hình xác suất của việc lập chỉ mục và tìm kiếm," trong *Information Retrieval Research (Proceedings of Research and Development in Information Retrieval, Cambridge, 1980)*, (R. N. Oddy, S. E. Robertson, C. J. van Rijsbergen, và P. W. Williams, biên tập), tr. 35–56, London: Butterworths, 1981.

[46] S. E. Robertson và S. Walker, "Một số xấp xỉ đơn giản hiệu quả cho mô hình 2-Poisson cho truy xuất trọng số xác suất," trong *Proceedings of the 17th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval*, 232–241, 1994, tr. – ACM/Springer, .

[47] S. E. Robertson và S. Walker, "Về trọng số liên quan với ít thông tin liên quan," trong *Proceedings of the 20th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval*, 16–24, , tr. – ACM, 2007.

[48] S. E. Robertson, S. Walker, M. Hancock-Beaulieu, A. Gull, và M. Lau, "Okapi tại TREC," trong *The First Text Retrieval Conference (TREC-1) NIST Special*, - tr. – .

[49] *Publication* 500 207, 21 30, 1992 S. E. Robertson và H. Zaragoza, "Về các phép đo hiệu quả dựa trên xếp hạng và tối ưu hóa," *Information Retrieval*, tập 10, số 3, tr. 321–339, 2007.

[50] S. E. Robertson, H. Zaragoza, và M. Taylor, "Mở rộng BM25 đơn giản cho nhiều trường trong số," trong *Proceedings of the 2004 ACM CIKM International Conference on Information and Knowledge Management*, 42–49, 2004, tr. – ACM, .

[51] R. Song, M. J. Taylor, J. R. Wen, H. W. Hon, và Y. Yu, "Xem xét độ gần của thuật ngữ từ một khác

[60] Wumpus. Homepage. http://www.wumpus-search.org/.
[61] Xapian. http://xapian.org.
[62] H. Zaragoza, N. Craswell, M. Taylor, S. Saria, and S. E. Robertson, "Microsoft Cambridge at TREC 2004: Web and HARD track," in *The Thirteenth Text Retrieval Conference (TREC 2004), NIST Special Publication,* 500-261, 2005.
[63] Zettair. Homepage. http://www.seg.rmit.edu.au/zettair.

References 389

[60] Wumpus. Trang chủ. http://www.wumpus-search.org/. [61] Xapian. http://xapian.org. [62] H. Zaragoza, N. Craswell, M.Taylor, S.Saria, và S. E. Robertson, " Microsoft Cambridge tại TREC
2004 *The Thirteenth Text* : Theo dõi *Retrieval Conference (TREC 2004) NIST Special Publication* 500 261, 2005
Web và HARD," trong , , - . [63] Zettair. Trang chủ. http://www.seg.rmit.edu.au/zettair.