Foundations and Trends® trong Truy xuất Thông tin Tập 3, Số 4 (2009) 333–389 c◯ 2009 S. Robertson và H. Zaragoza DOI: 10.1561/1500000019

now
the essence of knowledge

Khung Liên Quan Xác Suất: BM25 và Hơn Thế Nữa

Bởi Stephen Robertson và Hugo Zaragoza

Nội dung

1 Giới thiệu 334

2 Phát triển Mô hình Cơ bản 336

2.1 Nhu cầu và truy vấn thông tin 336 2.2 Độ liên quan nhị phân 337 2.3 Nguyên tắc xếp hạng xác suất 337 2.4 Một số ký hiệu 338 2.5 Ghi chú về xác suất và tương đương xếp hạng 345

3 Mô Hình Phái Sinh **347**

3.1 Mô hình Độc lập Nhị phân 347 3.2 Phản hồi Liên quan và Mở rộng Truy vấn 349 3.3 Phản hồi Mù 351 3.4 Mô hình Ưu tú và BM25 352 3.5 Các ứng dụng của BM25 360

3.6 Nhiều Luồng và BM25F 361
3.7 Tính năng Liên quan Phi văn bản 365
3.8 Thông tin vị trí 367
3.9 Triển khai mã nguồn mở của BM25 và BM25F 369

4 So sánh với các Mô hình Khác **371**

4.1 Maron và Kuhns 371 4.2 Mô hình Thống nhất 372 4.3 Mô hình Ngôn ngữ Đơn giản 374 4.4 Mô hình Liên quan (Ngôn ngữ) 375 4.5 Mô hình Chủ đề 375 4.6 Sai khác so với Ngẫu nhiên 376

5 Tối ưu hóa tham số 377

5.1 Tối ưu tham lam 378 5.2 Tối ưu đa chiều 380 5.3 Tối ưu gradient 382

6 Kết luận 384

Tài liệu tham khảo 385

Foundations and Trends® trong Truy
xuất Thông tin Tập 3, Số 4 (2009) 333–389
c◯ 2009 S. Robertson và H. Zaragoza
DOI: 10.1561/1500000019

now
the essence of knowledge

Khuôn khổ Liên quan Xác suất: BM25 và hơn thế nữa

Stephen Robertson[1] và Hugo Zaragoza[2]

[1] Microsoft Research, 7 J JThomson Avenue, Cambridge CB3 0FB, Vương quốc Anh ser@microsoft.com[2] Yahoo! Research, Av. Diagonal 177, Barcelona 08028, Tây Ban Nha hugoz@yahoo-inc.com

Tóm tắt

Khung Tính Liên Quan Xác Suất (PRF) là một khung chính thức cho việc truy xuất tài liệu, dựa trên các công trình thực hiện vào những năm 1970–1980, dẫn đến sự phát triển của một trong những thuật t oán truy xuất văn bản thành công nhất, BM25. Trong những năm gần đây, nghiên cứu về PRF đã tạo ra các mô hình truy xuất mới có khả năng tính đến siêu dữ liệu của tài liệu (đặc biệt là thông tin cấu trúc và đồ thị liên kết). Một lần nữa, điều này đã dẫn đến một trong những thuật toán tìm kiếm Web và tìm kiếm doanh nghiệp thành công nhất, BM25F. Công trình này trình bày PRF từ góc nhìn khái niệm, mô tả các giả định mô hình xác suất đứng sau khung và các thuật toán xếp hạng khác nhau phát sinh từ việc áp dụng nó: mô hình độc lập nhị phân, các mô hình phản hồi liên quan, BM25 và BM25F. Nó cũng thảo luận về mối quan hệ giữa PRF và các mô hình thống kê khác cho IR, và đề cập đến một số chủ đề liên quan, chẳng hạn như việc sử dụng các đặc trưng phi văn bản, và tối ưu hóa tham số cho các mô hình có tham số tự do.

1

Giới thiệu

Bài đơn khảo này đề cập đến mô hình xác suất kinh điển của việc truy xuất thông tin. Mô hình này đặc trưng bởi việc bao gồm một khái niệm cụ thể về sự liên quan, một biến rõ ràng liên quan đến cặp truy vấn–tài liệu, thường ẩn theo nghĩa không thể quan sát được. Mô hình xoay quanh khái niệm ước lượng xác suất liên quan cho mỗi cặp, và xếp hạng các tài liệu liên quan đến một truy vấn nhất định theo thứ t ự giảm dần của xác suất liên quan. Biểu hiện nổi tiếng nhất của mô hình là hàm tính điểm tài liệu và trọng số từ BM25.

Mô hình đã được phát triển theo các giai đoạn trong khoảng thời gian khoảng 30 năm, với một tiền thân vào năm 1960. Một vài tài liệu tham khảo chính như sau: [30, 44, 46, 50, 52, 53, 58]; các khảo sát khác về một loạt các phương pháp xác suất bao gồm [14, 17]. Một số tài liệu tham khảo chi tiết hơn được đưa ra dưới đây.

Có một số phát triển sau này của các mô hình IR cũng mang tính xác suất nhưng khác biệt đáng kể so với các mô hình được phát triển ở đây — cụ thể và đặc biệt là phương pháp mô hình ngôn ngữ (LM) [24, 26, 33] và các mô hình sai lệch so với ngẫu nhiên (DFR) [2]. Vì lý do này, chúng tôi gọi tập hợp các mô hình được phát triển ở đây là Khung Liên quan Xác suất (PRF), nhấn mạnh

tầm quan trọng của biến liên quan trong việc phát triển các mô hình. Chúng tôi không đề cập đến việc phát triển các mô hình xác suất khác trong khảo sát hiện tại, nhưng một số điểm so sánh đã được thực hiện.

Đây không chủ yếu là một khảo sát thực nghiệm; xuyên suốt, các khẳng định sẽ được đưa ra về các kỹ thuật được cho là hiệu quả. Nói chung, những tuyên bố như vậy dựa trên kết quả thực nghiệm, nhiều thí nghiệm của nhiều người trong một khoảng thời gian dài, mà nói chung sẽ không được trích dẫn đầy đủ. Trọng tâm là phát triển lý thuyết của các phương pháp, logic và các giả định đằng sau các mô hình.

Khảo sát được tổ chức như sau. Trong Phần 2, chúng tôi phát triển mô hình truy xuất tổng quát nhất, bao quát một số hiện thực cụ thể được phát triển trong Phần 3. Trong Phần 4, chúng tôi thảo luận về những điểm giống và khác với các khung truy xuất khác. Cuối cùng, trong Phần 5, chúng tôi cung cấp tổng quan về các kỹ thuật tối ưu hóa mà chúng tôi đã sử dụng để điều chỉnh các tham số khác nhau trong các mô hình và Phần 6 kết luận khảo sát.

2

Phát triển Mô hình Cơ bản

2.1 Nhu cầu thông tin và các truy vấn

Chúng tôi bắt đầu từ khái niệm nhu cầu thông tin. Chúng tôi coi một truy vấn là một đại diện (không nhất thiết phải tốt hoặc đầy đủ) của nhu cầu thông tin của một người dùng cá nhân hoặc có thể là ý định tìm kiếm. Chúng tôi coi tính liên quan là mức độ liên quan của một tài liệu đối với nhu cầu thông tin, được đánh giá bởi người dùng. Chúng tôi không đưa ra giả định cụ thể nào về bản chất khái niệm của tính liên quan; đặc biệt, chúng tôi không giả định tính liên quan là về chủ đề. Tuy nhiên, chúng tôi có đưa ra một số giả định về tình trạng hình thức của biến liên quan, được nêu bên dưới, điều này có thể được coi là ngụ ý một số giả định về bản chất khái niệm của nó.

[1]Khái niệm *topic*, như được sử dụng trong TREC, phần nào giống với *information need*, hoặc ít nhất là một biểu diễn và đặc tả chi tiết và đầy đủ hơn về một nhu cầu thông tin. Việc sử dụng thuật ngữ 'chủ đề' cho mục đích này hơi không may, vì nó dường như ngụ ý một loại tính chất liên quan theo chủ đề. Tuy nhiên, chúng tôi cũng lưu ý rằng việc sử dụng rộng rãi thuật ngữ này sau TREC cũng bao gồm một số ví dụ về các 'chủ đề' không theo chủ đề, ví dụ như các chủ đề trang chủ được sử dụng trong TREC Web track [59].

2.2 Sự liên quan nhị phân

Các giả định về sự liên quan như sau:

> 1. Mức độ liên quan được cho là một đặc tính của tài liệu dựa trên nhu cầu thông tin duy nhất, có thể đánh giá mà không cần tham khảo các tài liệu khác; và 2. Đặc tính liên quan được giả định là nhị phân.

Mỗi giả định này ít nhất đều có thể tranh luận được. Chúng ta có thể dễ dàng tưởng tượng ra các tình huống mà sự liên quan của một tài liệu chỉ có thể được người dùng nhận thấy trong bối cảnh của một tài liệu khác, ví dụ. Về thuộc tính nhị phân, nhiều nghiên cứu thực nghiệm gần đây đã ưu tiên một khái niệm liên quan theo mức độ. Người ta có thể đi xa hơn và đề xuất rằng các tài liệu khác nhau có thể liên quan đến một nhu cầu theo những cách khác nhau, không chỉ ở các mức độ khác nhau. Tuy nhiên, chúng tôi nhấn mạnh rằng chúng tôi xem xét tình huống của một nhu cầu thông tin duy nhất (thay vì nhiều nhu cầu hoặc mục đích có thể được thể hiện bởi một truy vấn văn bản duy nhất). Nếu chúng ta hiểu liên quan là 'người dùng muốn được hướng đến tài liệu này', thì khái niệm nhị phân ít nhất là tương đối hợp lý.

2.3 Nguyên tắc Xếp hạng theo Xác suất

Vì một hệ thống truy hồi thông tin không thể biết các giá trị của thuộc tính phù hợp của từng tài liệu, chúng ta giả định rằng thông tin có sẵn cho hệ thống nhiều nhất chỉ là xác suất. Tức là, các thuộc tính đã biết (với hệ thống) của tài liệu và truy vấn có thể cung cấp bằng chứng xác suất hoặc thống kê về mức độ phù hợp của tài liệu đó với nhu cầu cơ bản. Các thuộc tính này có thể phong phú và bao gồm nhiều loại bằng chứng khác nhau; thông tin duy nhất được giả định là không có là chính thuộc tính phù hợp thực tế. Với bất kỳ thông tin nào có sẵn, hệ thống có thể đưa ra một phát biểu thống kê nào đó về giá trị có thể c ủa thuộc tính phù hợp.

Với một thuộc tính liên quan tài liệu-nhị phân, thì thông tin thống kê này có thể được bao gói hoàn toàn trong xác suất liên quan. Xác suất liên quan của một tài liệu nhất định đối với một

truy vấn đã cho đóng vai trò trung tâm trong lý thuyết hiện tại. Thực tế, chúng ta có thể đưa ra một tuyên bố tổng quát về điều này:

> Nếu các tài liệu được truy xuất được sắp xếp theo xác suất liên quan giảm dần dựa trên dữ liệu có sẵn, thì hiệu quả của hệ thống là tốt nhất có thể đạt được cho dữ liệu.

Đây là một tuyên bố về Nguyên tắc Xếp hạng Xác suất (PRP), được trích từ [52], một phiên bản rút gọn của phiên bản trong [40]. PRP có thể được biện minh dưới một số giả định bổ sung, cho một phạm vi các thước đo hiệu quả cụ thể. Tuy nhiên, nó không hoàn toàn tổng quát; người ta cũng có thể xây dựng các ví dụ phản chứng. Nhưng các ví dụ phản chứng này phụ thuộc vào xác suất được định nghĩa trên một tập hợp người dùng. PRP là an toàn cho trường hợp được xem xét: một người dùng cá nhân. Nguyên tắc này sẽ được giả định cho phần còn lại của công trình này.

2.4 Một số ký hiệu

Trong phần này, chúng tôi giới thiệu một số ký hiệu sẽ được sử dụng trong toàn bộ khảo sát. Ký hiệu giả định một truy vấn duy nhất q đại diện cho một nhu cầu thông tin duy nhất. Ký hiệu đầu tiên được dùng để chỉ rằng hai hàm là tương đương như các hàm xếp hạng.

$$\text{rank equivalence:} \quad \propto_q \quad \text{e.g. } g() \propto_q h()$$

Trong việc phát triển mô hình, từ xác suất liên quan của một tài liệu đối với một hàm tính trọng số từ và điểm tài liệu, chúng tôi thường xuyên sử dụng các phép biến đổi mà do đó giữ nguyên thứ tự xếp hạng. Một phép biến đổi như vậy (trong một hàm tính điểm tài liệu, chẳng hạn) có thể là tuyến tính hoặc phi tuyến, nhưng phải đúng theo đơn điệu, để nếu các tài liệu được xếp hạng theo hàm biến đổi, chúng sẽ ở cùng thứ tự xếp hạng như khi chúng được xếp hạng theo hàm gốc.

Tính chất liên quan được biểu thị bằng một biến ngẫu nhiên Rel với hai giá trị có thể:

$$\text{relevance } \mathit{Rel}: \quad \text{rel}, \overline{\text{rel}} \quad \text{(relevant or not)}$$

Như đã thảo luận ở trên, chúng tôi giả định rằng mức độ liên quan là một đặc tính nhị phân của tài liệu (với một nhu cầu thông tin nhất định). Chúng tôi sẽ sử dụng ký hiệu ngắn gọn $P(\text{rel} \mid d, q)$ để biểu thị $P(\text{Rel} = \text{rel} \mid d, q)$.

Đối với các tài liệu và truy vấn, chúng ta thường giả định một mô hình tập từ hoặc túi từ. Chúng ta có một tập hợp các thuật ngữ được đánh chỉ mục vào tập V, mỗi thuật ngữ có thể có mặt hoặc không có mặt (trong mô hình tập từ) hoặc có thể xuất hiện với tần suất nào đó (mô hình túi từ). Trong cả hai trường hợp, các đối tượng (tài liệu hoặc truy vấn) có thể được biểu diễn dưới dạng vector trên không gian được xác định bởi từ vựng. Do đó, một tài liệu là:

$$\text{document:} \quad d := (tf_1, \ldots, tf_{|\mathbf{V}|}),$$

nơi mà tf_i thường đại diện cho tần suất của thuật ngữ t_i trong tài li ệu. Chúng ta cũng sẽ cần phân biệt giữa biến ngẫu nhiên TF_i và giá trị quan sát được của nó trong một tài liệu, tf_i. Biến ngẫu nhiên thường sẽ ám chỉ tần suất xuất hiện của một thuật ngữ cụ thể trong từ vựng. Tuy nhiên, cách trình bày của mô hình cơ bản có phần tổng quát hơn thế, và có thể chấp nhận bất kỳ biến rời rạc nào làm đặc trưng (ví dụ, bất kỳ thuộc tính hoặc đặc điểm rời rạc nào của tài liệu). Do đó, chúng ta có thể diễn giải lại tf đơn giản là đại diện cho sự hiện diện hay vắng mặt của một thuật ngữ; đây là cơ sở của Mục 3.1 dưới đây. Các biến liên tục cũng có thể được chấp nhận bằng cách thay các hàm khối xác suất TF_i (của các biến rời rạc) bằng các hàm mật độ xác suất (của các biến liên tục); mặc dù chúng tôi không trình bày một phát triển chính thức của mô hình với các biến liên tục, chúng tôi sẽ sử dụng thực tế này trong Mục 3.7 để giới thiệu một số đặc trưng liên tục không phải văn bản vào mô hình.

Aquery được biểu diễn theo hai cách khác nhau. Trong cách thứ nhất, nó được coi tương tự như một vector:

$$\text{query: } q := (qtf_1, \ldots, qtf_{|\mathbf{V}|})$$

Ở đây, các thành phần qtf_i có thể đại diện cho tần số xuất hiện của các thuật ngữ trong truy vấn, hoặc có thể đại diện cho một đặc trưng tồn tại hay không tồn tại nhị phân.

Trong suốt khảo sát này, chúng ta sẽ cần cộng hoặc nhân các biến của các thuật ngữ có trong truy vấn (tức là, với $\text{qtf}_i > 0$). Cho mục đích này, chúng ta định nghĩa tập hợp các chỉ số:

$$\text{query terms:} \quad \mathbf{q} := \{i \mid qtf_i > 0\} \quad \text{(indices of terms in the query)}$$

2.4.1 Xem trước về Sự Phát triển

Phần sau cung cấp một cái nhìn tổng quan về sự phát triển của mô hình cơ bản; các bước riêng lẻ được thảo luận bên dưới. Điểm chính cần lưu ý là chúng ta bắt đầu với PRP rất tổng quát, và kết thúc với một hàm chấm điểm tài liệu rõ ràng, bao gồm tổng đơn giản của các trọng số cho từng từ truy vấn riêng lẻ có trong tài liệu.

$$
\begin{aligned}
P(\mathrm{rel}\,|\,d,q) &\propto_q \frac{P(\mathrm{rel}\,|\,d,q)}{P(\overline{\mathrm{rel}}\,|\,d,q)} && (2.1)\\
&= \frac{P(d\,|\,\mathrm{rel},q)}{P(d\,|\,\overline{\mathrm{rel}},q)}\frac{P(\mathrm{rel}\,|\,q)}{P(\overline{\mathrm{rel}}\,|\,q)} && (2.2)\\
&\propto_q \frac{P(d\,|\,\mathrm{rel},q)}{P(d\,|\,\overline{\mathrm{rel}},q)} && (2.3)\\
&\approx \prod_{i\in\mathbf{V}} \frac{P(TF_i = tf_i\,|\,\mathrm{rel},q)}{P(TF_i = tf_i\,|\,\overline{\mathrm{rel}},q)} && (2.4)\\
&\approx \prod_{i\in\mathbf{q}} \frac{P(TF_i = tf_i\,|\,\mathrm{rel})}{P(TF_i = tf_i\,|\,\overline{\mathrm{rel}})} && (2.5)\\
&\propto_q \sum_{\mathbf{q}} \log \frac{P(TF_i = tf_i\,|\,\mathrm{rel})}{P(TF_i = tf_i\,|\,\overline{\mathrm{rel}})} && (2.6)\\
&= \sum_{\mathbf{q}} U_i(tf_i) && (2.7)\\
&= \sum_{\mathbf{q},tf_i>0} U_i(tf_i) + \sum_{\mathbf{q},tf_i=0} U_i(0)\\
&\quad - \sum_{\mathbf{q},tf_i>0} U_i(0) + \sum_{\mathbf{q},tf_i>0} U_i(0) && (2.8)\\
&= \sum_{\mathbf{q},tf_i>0} (U_i(tf_i) - U_i(0)) + \sum_{\mathbf{q}} U_i(0) && (2.9)\\
&\propto_q \sum_{\mathbf{q},tf_i>0} (U_i(tf_i) - U_i(0)) && (2.10)\\
&= \sum_{\mathbf{q},tf_i>0} w_i && (2.11)
\end{aligned}
$$

2.4.2 Chi tiết

Chúng tôi bắt đầu với xác suất liên quan của một tài liệu và truy vấn nhất định.

Ba bước đầu tiên là những phép biến đổi đại số đơn giản. Ở Bước (2.1), chúng ta chỉ đơn giản thay xác suất bằng tỷ lệ cược. Ở Bước (2.2), chúng ta thực hiện đảo ngược Bayesian trên cả tử và mẫu số. Ở Bước (2.3), chúng ta bỏ thành phần thứ hai mà độc lập với tài liệu, và do đó không ảnh hưởng đến thứ hạng của các tài liệu.

Trong Bước (2.4) (giả định độc lập giữa các từ), chúng ta mở rộng mỗi xác suất dưới dạng tích các từ trong từ vựng. Bước này dựa trên giả định về sự độc lập thống kê giữa các từ — thực ra là một cặp giả định như vậy, tương ứng cho các trường hợp có liên quan và không liên quan. Lưu ý rằng chúng ta không giả định sự độc lập tuyệt đối giữa các từ, mà là một hình thức yếu hơn, cụ thể là sự độc lập có điều kiện. Điều này rõ ràng là một bước gây tranh cãi hơn: nói chung các t ừ sẽ không độc lập về mặt thống kê theo cách này. Lý do hiển nhiên để thực hiện bước này là dẫn chúng ta đến một hàm điểm đơn giản và khả thi (ngay cả khi chỉ gần đúng). Tuy nhiên, chúng ta có thể đưa ra một số lập luận bổ sung để ủng hộ bước này:

> 1. Các mô hình loại này trong các lĩnh vực khác, được biết đến với tên gọi mô hình Naive Bayes, được biết đến là cực kỳ tốt, đơn giản và mạnh mẽ, mặc dù có những sai lệch đáng kể so với tính độc lập. Bằng chứng thực nghiệm trong IR cung cấp một số hỗ trợ cho tuyên bố chung này. 2. Cặp giả định này một cách tổng quát không tương đương với giả định hoàn toà n về tính độc lập giữa các thuật ngữ trong toàn bộ tập hợp. Ngược lại, đối với một cặp thuật ngữ truy vấn, cả hai đều có tương quan thống kê với sự liên quan, cặp giả định này dự đoán một mối liên kết tích cực giữa hai thuật ngữ trong toàn bộ tập hợp. Thực tế chúng ta thường quan sát thấy mối liên kết tích cực như vậy. Thực chất mô hình nói rằng điều này

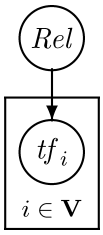
[2] Sự biến đổi này bảo toàn thứ tự; tỉ số chênh lệch của p là $\frac{p}{1-p}$, và hàm này là một hàm tăng đơn điệu của $p \in [0,1)$. [3] $P(ab|c) = P(a|c)P(b|c)$.

mối liên hệ tích cực được tạo ra bởi sự liên quan đến truy vấn.[4]Điều này rõ ràng là một sự đơn giản hóa quá mức, nhưng có lẽ không phải là một điều quá tồi.

3. Cooper [11] đã chứng minh rằng chúng ta có thể đạt được cùng một phép biến đổi dựa trên một giả định yếu hơn, gọi là phụ t huộc liên kết. [5] Điều này về cơ bản có nghĩa là mức độ liên kết thống kê giữa các thuật ngữ là giống nhau trong các tập con liên quan cũng như trong các tập con không liên quan. Một lần nữa, kết quả lý thuyết này có thể giúp giải thích tính vững chắc của một mô hình như vậy.

Chúng ta có thể biểu diễn các giả định về tính độc lập bằng mô hình đồ thị, như trong Hình 2.1. Sơ đồ này cho thấy tần số của từ $(\text{tf}_i)_{i \in \text{V}}$ được giả định là sinh ra như các quan sát ngẫu nhiên chỉ phụ thuộc vào trạng thái của biến liên quan Rel (một giải thích đầy đủ về các sơ đồ mô hình đồ thị nằm ngoài phạm vi của bài báo này, chúng tôi t ham khảo người đọc đến [6]).

Trong bước (2.5) (giả định các thuật ngữ truy vấn), chúng ta chỉ giới hạn mình vào các thuật ngữ truy vấn: thực chất, chúng ta giả định rằng đối với bất kỳ thuật ngữ không phải truy vấn nào, tỷ lệ xác suất có điều kiện là hằng và bằng một. [6] Điều này có vẻ là một giả định cực đoan (rằng không có thuật ngữ nào ngoài truy vấn có mối quan hệ với tính liên quan); tuy nhiên, đây không hoàn toàn là lời giải thích cho bước này. Chúng ta phải xem xét câu hỏi về thông tin mà chúng ta



Hình 2.1 Mô hình đồ họa chỉ ra các giả định độc lập cơ bản.

[4] Nếu $P(a \mid c) > P(a \mid \bar{c})$ và tương tự cho b, thì suy ra rằng $P(ab) > P(a)P(b)$ ngay cả dưới các giả định độc lập có điều kiện đã đưa ra. [5] $P(a,b \mid c)\, P(a,b \mid \bar{c}) = P(a \mid c)\, P(a \mid \bar{c})\, P(b \mid c)\, P(b \mid \bar{c})$. [6] Lưu ý rằng nếu tỷ số là hằng số, thì nó phải bằng một; nếu không chúng ta sẽ có một trong hai phân phối xác suất với các xác suất luôn cao hơn cái còn lại, điều này là không thể vì cả hai đều cần tổng bằng 1.

có cơ sở để ước tính xác suất phù hợp. Đây là một giả định tiên nghiệm hợp lý, và hóa ra là một giả định tốt, rằng nói chung các từ truy vấn có mối tương quan (tích cực) với sự phù hợp. Tuy nhiên, chúng ta không thể đưa ra giả định như vậy về các từ không thuộc truy vấn (một từ liên quan đến một chủ đề hoàn toàn khác có thể có mối tương quan tiêu cực với sự phù hợp). Khi không có bất kỳ liên kết nào với truy vấn, giả định tiên nghiệm mơ hồ hiển nhiên về một từ vựng ngẫu nhiên phải là nó không có mối tương quan với sự phù hợp của truy vấn này. Sau này chúng ta sẽ xem xét vấn đề mở rộng truy vấn, thêm các từ mới vào truy vấn, khi chúng ta có bằng chứng liên kết một từ không thuộc truy vấn với sự phù hợp của truy vấn.

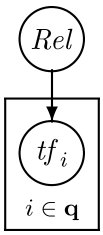
Một lần nữa, chúng ta có thể minh họa các giả định bằng cách sử dụng một mô hình đồ họa, như trong Hình 2.2. Sơ đồ này cho thấy rằng trong mô hình này, biến liên quan chỉ ảnh hưởng đến các thuật ngữ trong truy vấn.

Bắt đầu từ Bước (2.6) chúng ta sử dụng ký hiệu rút gọn sau: dưới toán tử tổng, chúng ta sẽ viết q (tập giá trị khởi đầu cho i) kèm theo các điều kiện mà i phải thỏa mãn. Ví dụ: $\sum$q nên được đọc là $\sum_{i \in}$q, và $\sum$q $_{tf_i>0}$ nên được đọc là $\sum_{\{i \,|\, i \in}$q $_{tf_i>0\}}$.

Trong Bước (2.6), chúng ta thực hiện một phép biến đổi phổ biến, giữ nguyên thứ tự, cụ thể là chúng ta lấy logarit. Điều này cho phép chúng ta biểu diễn tích của các xác suất dưới dạng tổng của các xác suất logarit—thực ra là log-tỷ lệ bởi vì tỷ số trong tích.

Trong Bước (2.7), chúng ta viết lại phương trình trước đó bằng cách sử dụng một hàm $U_i(x)$:

$$U_i(x) := \log \frac{P(TF_i = x \,|\, \text{rel})}{P(TF_i = x \,|\, \overline{\text{rel}})} \tag{2.12}$$



Hình 2.2 Mô hình đồ họa cho việc giới hạn theo các thuật ngữ truy vấn.

Lưu ý rằng đây không phải là hàm log-odds. Cũng lưu ý rằng ở Bước (2.7) mỗi tần số từ tf_i sẽ được áp dụng cho một hàm khác $U_i(\text{tf}_i)$. Điều này là cần thiết vì trọng số của một từ không chỉ phụ thuộc vào tần số của nó, mà còn vào các yếu tố khác như tần số trong tập hợp, v.v.

Hai bước sau sử dụng một thủ thuật số học (đôi khi được gọi là loại bỏ các số không) mà loại bỏ khỏi phương trình các hạng tử không có trong tài liệu. Điều này rất quan trọng cho việc triển khai hiệu quả các hàm xếp hạng PRF sử dụng chỉ mục đảo ngược.

Trong Bước (2.8), chúng ta làm hai việc. Trong dòng đầu tiên, tổng các thuật ngữ truy vấn trong Bước (2.7) đã được chia thành hai nhó m: các thuật ngữ có mặt trong tài liệu (tổng đầu tiên) và những thuật ngữ không có mặt (tổng thứ hai). Trong dòng thứ hai, chúng ta trừ đi và cộng cùng một đại lượng (tổng trọng số tần số bằng không cho các thuật ngữ trong tài liệu) khiến kết quả không thay đổi. Lý do thực hiện việc này sẽ trở nên rõ ràng ở bước tiếp theo.

Trong Bước (2.9), chúng ta nhóm lại các tổng của Bước (2.8). Trước tiên, chúng ta nhận thấy rằng tổng thứ nhất và thứ ba trong Bước (2.8) là trên cùng các thuật ngữ, và có thể nhóm lại với nhau. Điều này tạo thành tổng thứ nhất trong Bước (2.9). Sau đó, chúng ta nhận thấy rằng tổng thứ hai và thứ tư trong Bước (2.8) bao phủ tất cả các thuật ngữ trong truy vấn. Điều này tạo thành tổng thứ hai trong Bước (2.9).

Trong Bước (2.10) chúng ta loại bỏ tổng cuối cùng vì giá trị của nó không phụ thuộc vào tài liệu. Chúng ta lưu ý rằng bằng cách làm như vậy, chúng ta chỉ còn lại một tổng duy nhất trên các thuật ngữ xuất hiện cả trong tài liệu và trong truy vấn. Chúng ta đã loại bỏ các thuật ngữ trong truy vấn có tần số bằng không trong tài liệu.

Trong Bước (2.11), chúng ta lại viết lại phương trình bằng cách sử dụng ký hiệu ngắn gọn:

$$W_i(x) := U_i(x) - U_i(0) \tag{2.13}$$

$$= \log \frac{P(TF_i = x \,|\, \text{rel}) P(TF_i = 0 \,|\, \overline{\text{rel}})}{P(TF_i = x \,|\, \overline{\text{rel}}) P(TF_i = 0 \,|\, \text{rel})} \tag{2.14}$$

$$w_i := W_i(tf_i) \tag{2.15}$$

Phương trình (2.14) là công thức cho trọng số cơ bản của một từ khóa trong một tài liệu. Cả U_i và W_i đều là các hàm trọng số từ khóa có thể được tính trước và lưu trữ tại thời điểm lập chỉ mục. Sự khác biệt là ở việc

Để sử dụng U_i trong một tài liệu, chúng ta sẽ phải tổng hợp tất cả các từ truy vấn, bất kể chúng có xuất hiện trong tài liệu hay không. Với W_i, chúng ta chỉ cần xem xét các trọng số w_i của các từ xuất hiện trong tài liệu (thực tế việc viết lại này đã xác định trọng số của các từ không có mặt là bằng không). Điều này phù hợp rất tốt với tính thưa thớt của ma trận tài liệu-từ — chúng ta không cần tính điểm của bất kỳ tài liệu nào không chứa từ truy vấn. Thực tế, đây là một đặc điểm rất mong muốn cho một hàm tính điểm được sử dụng trong hệ thống truy xuất tài liệu dựa trên tệp đảo ngược, vì nó có nghĩa là chúng ta có thể dễ dàng tính điểm của tất cả các tài liệu có điểm khác không bằng cách hợp nhất các danh sách đảo ngược của các từ truy vấn.

Như đã chỉ ra ở trên, mô hình không bị giới hạn bởi các thuật ngữ và tần suất thuật ngữ — bất kỳ đặc tính, thuộc tính hoặc tính năng nào của tài liệu, hoặc của cặp tài liệu–truy vấn, mà chúng ta có thể hợp lý kỳ vọng cung cấp một số bằng chứng về sự liên quan, đều có thể được đưa vào. Dưới đây chúng ta sẽ xem xét các đặc điểm tĩnh của tài liệu — các thuộc tính không phụ thuộc vào truy vấn — để đưa vào. Bất kỳ thuộc tính rời rạc nào có điểm gốc tự nhiên có thể được xử lý bằng dạng W_i của trọng số — nếu chúng ta muốn bao gồm một t huộc tính mà không có điểm gốc tự nhiên như vậy, chúng ta cần quay lại sử dụng dạng U_i .

Chúng tôi cũng lưu ý rằng cả hai dạng đều là các mô hình tuyến tính đơn giản — sự kết hợp bằng chứng từ các thuật ngữ truy vấn khác nhau chỉ bằng cách cộng lại. Điều này tự nó không phải là một giả định — nó phát sinh một cách tự nhiên từ các giả định cơ bản hơn của mô hình.

Trong các phần tiếp theo, chúng tôi định nghĩa các cách hiện thực khác nhau của mô hình chấm điểm tổng trọng số cơ bản này.

2.5 Một chú thích về xác suất và sự tương đương thứ hạng

Một hệ quả của việc chúng ta dựa vào nguyên tắc xếp hạng xác suất là chúng ta có thể thực hiện những biến đổi rất bừa bãi đã được thảo luận ở trên, dựa trên cơ sở rằng đặc tính duy nhất mà chúng ta muốn giữ lại là thứ tự xếp hạng của các tài liệu. Điều này có thể là một giả định hợp lý cho truy xuất thông tin theo cách thủ công truyền thống, nhưng không áp dụng cho tất cả các tình huống truy xuất. Trong một số trường hợp, ví dụ như trong lọc thích nghi [42], , chúng ta thấy rằng việc có được một ước lượng rõ ràng về xác suất liên quan của mỗi tài liệu được xem xét là điều mong muốn hoặc cần thiết. Thật không may, trong khi

Sự phát triển nêu trên cho phép chúng ta thực hiện mục đích xếp hạng một cách tốt, nhưng nó không dễ dàng đảo ngược để cung cấp cho chúng ta một ước lượng rõ ràng như vậy. Cụ thể, một số phép biến đổi liên quan đến việc loại bỏ các thành phần mà không ảnh hưởng đến thứ hạng, nhưng sẽ cần thiết cho một ước lượng xác suất tốt. Thường thì, như trong trường hợp của thành phần mà chúng ta loại bỏ ở Bước (2.3), việc ước lượng sẽ rất khó khăn. Do đó, mô hình trên phải được sửa đổi đáng kể nếu muốn sử dụng trong tình huống yêu cầu một xác suất rõ ràng. Vấn đề này không được thảo luận thêm trong khảo sát hiện tại.

3

Mô hình dẫn xuất

Các mô hình được thảo luận trong phần này đều được rút ra từ mô hình cơ bản đã trình bày trong phần trước. Chúng tôi một lần nữa lưu ý rằng ký hiệu TF trong công thức trọng số cơ bản (2.14) nói chung có thể là bất kỳ đặc tính hoặc thuộc tính rời rạc nào của tài liệu. Chúng tôi bắt đầu bằng cách diễn giải nó như một biến nhị phân, chỉ ra sự có mặt hay vắng mặt của một thuật ngữ truy vấn trong tài liệu; trong Phần 3.4, chúng tôi sẽ quay lại tần suất từ quen thuộc hơn.

3.1 Mô hình Độc lập Nhị phân

Giả sử rằng TF_i là một biến nhị phân, chỉ có giá trị bằng không hoặc một. Chúng ta có thể nghĩ về điều này, mà không làm mất sự tổng quát, như sự hiện diện (một) hoặc vắng mặt (không) của một thuật ngữ: t_i sẽ đề cập đến sự kiện rằng thuật ngữ đó có mặt trong tài liệu. Sự kiện vắng mặt đơn giản là phần bù của sự kiện hiện diện; xác suất vắng mặt bằng một trừ đi xác suất hiện diện. Bây giờ Phương trình (2.14) được rút gọn thành:

$$w_i^{\mathrm{BIM}} = \log \frac{P(t_i \,|\, \mathrm{rel})(1 - P(t_i \,|\, \overline{\mathrm{rel}}))}{(1 - P(t_i \,|\, \mathrm{rel}))P(t_i \,|\, \overline{\mathrm{rel}})} \tag{3.1}$$

Bây giờ chúng ta giả sử rằng chúng ta thực sự có một số bằng chứng để là m cơ sở cho các ước lượng về các xác suất này. Vì chúng có điều kiện trên

thuộc tính liên quan, chúng tôi đang giả định rằng chúng tôi có một số đánh giá về mức độ liên quan. Trước tiên, chúng tôi tưởng tượng, một c ách phi thực tế, rằng chúng tôi có một mẫu ngẫu nhiên của toàn bộ tập hợp, vốn đã được đánh giá hoàn toàn về mức độ liên quan. Chúng tôi rút ra một ước lượng cũng sẽ hữu ích cho những trường hợp thực tế hơn.

Chúng tôi sử dụng ký hiệu sau:

N — Kích thước của mẫu được đánh gián_i — Số lượng tài liệu tr ong mẫu được đánh giá chứa $t_i R$ — Kích thước tập hợp liên quan (tức là số tài liệu được đánh giá là liên quan)r_i — Số tài liệu được đánh giá là liên quan chứa t_i

Dựa trên thông tin này, chúng tôi muốn ước lượng một cách phù hợp bốn xác suất cần thiết cho các trọng số được định nghĩa trong Phương trình (3.1). Ước lượng một cách tối đa hợp lý chuẩn của một xác suất từ các thí nghiệm là một tỉ số đơn giản, ví dụ, $\underline{P}(t_i|\text{rel}) \approx \frac{r_i}{R}$. Tuy nhiên, đây không phải là một bộ ước lượng tốt để đưa vào công thức trọng số. Một lý do thực tiễn rất rõ ràng là sự kết hợp giữa tỉ số của các xác suất và hàm log có thể cho ra giá trị vô cực (dương hoặc âm) làm ước lượng. Thực tế, còn có những lý do lý thuyết tốt để điều chỉnh một chút các ước lượng tỉ số đơn giản này, như đã được thảo luận trong [44]„ nhằm có được một bộ ước lượng bền vững hơn, đưa vào một số đếm giả nhỏ là 0,5. Công thức kết quả là trọng số Robertson/Sprck Jones nổi tiếng:

$$w_i^{\text{RSJ}} = \log \frac{(r_i + 0.5)(N - R - n_i + r_i + 0.5)}{(n_i - r_i + 0.5)(R - r_i + 0.5)} \tag{3.2}$$

Tiếp theo, chúng ta giả sử rằng một số tài liệu, có lẽ là một số lượng nhỏ, đã được truy xuất và đánh giá – đây là kịch bản phản hồi liên quan thông thường. Trong trường hợp này, chúng ta có thể hợp lý ước lượng xác suất có điều kiện dựa trên mức độ liên quan (tích cực) theo cùng một các h, từ các tài liệu đã biết là có liên quan. Việc ước lượng xác suất có điều kiện dựa trên mức độ không liên quan thì khó hơn. Cách rõ ràng, mà Phương trình (3.2) đầu tiên gợi ý, sẽ là sử dụng các tài liệu được đánh giá l à không liên quan. Tuy nhiên, chúng ta cũng biết rằng (thông thường, đối với bất kỳ truy vấn hợp lý nào và bất kỳ bộ sưu tập hợp lý nào) phần lớn các tài liệu đều không liên quan; những tài liệu mà chúng ta đã truy xuất và đánh giá không chỉ có khả năng là ít

Về số lượng, chúng cũng có khả năng là một tập hợp rất không điển hình. Chúng ta có thể tận dụng kiến thức này để có được một ước lượng tốt hơn (mặc dù có nguy cơ đưa vào một chút thiên lệch) bằng cách giả sử rằng bất kỳ tài liệu nào chưa được biết là liên quan thì không liên quan. Điều này được gọi là phương pháp bù. Theo giả định này, công thức trọng số RSJ được định nghĩa ở trên vẫn áp dụng, với các định nghĩa lại sau đây c ủa N và n_i.

N — Kích thước của toàn bộ bộ sưu tậpn_i — Số tài liệu trong bộ sưu tập chứa t_i

Các thí nghiệm cho thấy việc sử dụng phương pháp bổ sung này cho kết quả ước lượng tốt hơn so với chỉ sử dụng các tài liệu được đánh giá.

Cuối cùng, chúng ta giả sử rằng chúng ta hoàn toàn không có thông ti n về sự liên quan (kịch bản phổ biến hơn). Trong trường hợp này, chúng t a chỉ có thể giả định rằng xác suất liên quan $P(t_i|\text{rel})$ là cố định, nhưng vẫn có thể tiếp tục sử dụng phương pháp bù trừ cho xác suất không liên quan — bây giờ chúng ta giả sử cho một ước tính này rằng toàn bộ tập hợp là không liên quan. Tất cả điều này có thể thực hiện bằng cách thiết lập $R = r_i = 0$ trong công thức RSJ (3.2) — điều này tương đương với việc thiết lập $P(t_i|\text{rel}) = 0.5$ (các giá trị khác có thể được sử dụng [15]).

Công thức thu được là một xấp xỉ gần với idf cổ điển (nó có thể được làm gần hơn nữa bằng một sửa đổi nhỏ của mô hình [47]):

$$w_i^{\text{IDF}} = \log \frac{N - n_i + 0.5}{n_i + 0.5} \tag{3.3}$$

3.2 Phản hồi liên quan và Mở rộng truy vấn

Mô hình cho đến nay rõ ràng chứa một cơ chế tự nhiên cho phản hồi liên quan — tức là, để sửa đổi truy vấn dựa trên thông tin liên quan. Nếu chúng ta bắt đầu mà không có thông tin liên quan, thì chúng ta sẽ đánh trọng số các thuật ngữ bằng công thức tần số ngược tài liệu (IDF). Khi người dùng đưa ra một số đánh giá về mức độ liên quan, chúng ta rõ ràng nên đánh trọng số lại các thuật ngữ theo công thức RSJ. Nhưng việc đánh trọng số lại thuật ngữ nói chung không phải là một phương pháp hiệu quả để cải thiện tìm kiếm. Ngoài ra, chúng ta còn phải xem xét mở rộng truy vấn bằng cách thêm các thuật ngữ mới.

Ở giai đoạn đầu trong việc phát triển mô hình cơ bản, thay vì xe m xét toàn bộ từ vựng các thuật ngữ trong việc ước lượng của

về xác suất, chúng tôi chỉ giới hạn bản thân vào các thuật ngữ truy vấn. Điều này không phải bởi vì chúng tôi cho rằng các thuật ngữ không phải truy vấn không thể cung cấp cho chúng tôi bất kỳ thông tin hữu ích nào, mà đúng hơn là trong trường hợp không có bất kỳ bằng chứng nào về việc thuật ngữ nào có thể hữu ích, hoặc chúng hữu ích đến mức nào, một giả định hợp lý trung lập trước là tất cả các thuật ngữ không phải truy vấn đều có mối tương quan bằng 0 với sự liên quan.

Tuy nhiên, trong kịch bản phản hồi liên quan được thảo luận ở trên, chúng ta thực sự có một số bằng chứng cho việc bao gồm các từ không có trong truy vấn. Có khả năng chúng ta có thể coi bất kỳ từ nào xuất hiện trong bất kỳ tài liệu liên quan nào là có thể hữu ích. Tuy nhiên, rõ ràng là nhiều từ như vậy sẽ là nhiễu, vì vậy chúng ta có lẽ cần một quy tắc thận trọng để thêm các từ mới vào truy vấn.

Đối với mỗi thuật ngữ ứng viên (tức là thuật ngữ không có trong truy vấn nhưng xuất hiện trong một tài liệu được đánh giá là liên quan), chúng ta có thể xem xét mức độ hữu ích của nó nếu được thêm vào truy vấn. Một cách đo l ường cho điều này đơn giản là trọng số RSJ như đã nêu ở trên. Tuy nhiên, điều này sẽ nhấn mạnh các thuật ngữ rất hiếm (điều này phù hợp với ý tưởng của IDF) — những thuật ngữ như vậy thực sự có thể là bằng chứng tốt về độ liên quan khi chúng xuất hiện, nhưng vì chúng xuất hiện trong rất ít tài liệu, chúng sẽ không ảnh hưởng nhiều đến việc truy xuất tổng thể. Như một phương án thay thế, chúng ta tìm kiếm một cách đo lường về tác động tổng thể có thể có khi thêm một thuật ngữ; chúng tôi gọi điều này (theo [53]) là trọng số đề xuất.

Chúng ta có thể dựa vào một công thức trọng số đề xuất trên nhiều mô hình khác nhau. Một mô hình được đề xuất trong [41], sử dụng mô hình độc lập nhị phân, được trình bày như sau. Chúng ta tì m các thuật ngữ sẽ làm tăng tối đa sự khác biệt trong điểm trung bình giữa các mục liên quan và không liên quan. Nếu chúng ta thêm thuật ngữ t_i vào truy vấn với trọng số w_i, thì theo mô hình độc lập nhị phân (hoặc thực sự bất kỳ hệ thống trọng số cộng dựa trên sự hiện diện/không hiện diện của thuật ngữ nào), nó sẽ làm tăng điểm của bất kỳ tài liệu nào chứa thuật ngữ đó lên w_i. Điểm số của các tài liệu khác sẽ không bị ảnh hưởng, vì vậy sự tăng điểm trung bình có thể được tính từ xác suất xuất hiện của t_i. Do đó, sự khác biệt trong điểm trung bình giữa các tài liệu liên quan và không liên quan sẽ là

$$OW_i = (P(t_i|\text{rel}) - P(t_i|\overline{\text{rel}}))w_i \tag{3.4}$$

(lưu ý rằng điều này không giống như w_i tự nó). Hơn nữa, một ước lượng thích hợp của đại lượng này có thể được đưa ra như sau:

$$\begin{aligned} OW_i^{\mathrm{RSJ}} &\approx P(t_i \,|\, \mathrm{rel}) w_i \\ &\approx \frac{r_i}{R} w_i \\ &\propto_q r_i \; w_i^{\mathrm{RSJ}} \end{aligned} \tag{3.5}$$

Bước đầu tiên xấp xỉ bằng cách bỏ qua xác suất thứ hai (thường nhỏ hơn nhiều so với xác suất đầu tiên); bước thứ hai thay xác suất bằng ước lượng rõ ràng; và bước thứ ba nhân với R, vốn là hằng số cho một truy vấn nhất định.

Cách tiếp cận thông thường là trích xuất tất cả các thuật ngữ từ các tài liệu liên quan, xếp hạng chúng theo trọng số đề xuất bằng công thức (3.5), và chỉ thêm x thuật ngữ hàng đầu từ danh sách đã xếp hạng này (x có thể có thứ tự khoảng 10).

Phương pháp mở rộng truy vấn này được thiết kế cho mô hình độc lập nhị phân và trọng số RSJ, nhưng cũng đã được sử dụng với một số thành công cho BM25 (xem Mục 3.4 bên dưới). Tuy nhiên, rõ ràng nó có một số hạn chế. Khi chúng ta thêm ngày càng nhiều từ vào truy vấn, rất có khả năng chúng ta sẽ đưa vào các từ đồng nghĩa hoặc các từ có liên quan chặt chẽ (thực ra, đây là lý do tại sao chúng ta thực hiện mở rộng truy vấn ngay từ đầu). Tuy nhiên, trong [36, 37] các tác giả lập luận rằng mở rộng truy vấn này có thể làm trầm trọng thêm giả định độc lập giữa các từ; họ đề xuất một phần mở rộng của mô hình PRF nhằm cố gắng sửa điều này bằng cách xem xét một số cấu trúc ngữ nghĩa của truy vấn.

3.3 Phản hồi mù

Các nguyên tắc tương tự có thể được sử dụng trong những gì hiện nay được gọi là phản hồi mù hoặc pseudo-relevance. Ở đây chúng ta giả sử rằng chúng ta không có đánh giá thực sự về độ liên quan, nhưng chúng ta thực hiện một tìm kiếm ban đầu trên phiên bản ban đầu của truy vấn (chỉ sử dụng các từ truy vấn gốc), lấy các tài liệu xếp hạng cao nhất y (ví dụ 5 hoặc 10), giả sử chúng có liên quan, và sau đó làm theo các quy trình phản hồi liên quan nêu trên.

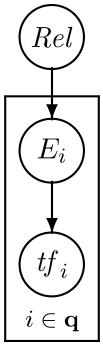
Tuy nhiên, chúng tôi lưu ý những điều sau:

1. Phản hồi mù thường được biết là có khả năng cải thiện kết quả tìm kiếm trung bình, nhưng có xu hướng thất bại với một số truy vấn, đặc biệt là với những truy vấn khó bắt đầu, nơi các tài liệu được xếp hạng hàng đầu từ tìm kiếm ban đầu có thể kém.

2. Thủ tục phản hồi liên quan (thật sự) được mô tả ở trên về một mặt nào đó là đúng theo mô hình xác suất, với giả định rằng các đánh giá liên quan là tốt. Trong trường hợp phản hồi mù, chúng ta có một tập hợp các tài liệu mà tính liên quan (tốt nhất) chỉ có khả năng thay vì chắc chắn. Sẽ tốt hơn nếu xem xét xác suất liên quan của từng tài liệu đứng đầu này, thay vì chỉ đơn giản giả định liên quan. Một phương pháp như vậy có thể được thiết kế nếu chúng ta có xác suất liên quan đã được hiệu chuẩn cho từng tài liệu này. Tuy nhiên, thực tế là chúng ta thường không có xác suất đã được hiệu chuẩn như vậy trong mô hình hiện tại, như đã thảo luận ở Mục 2.5, làm cho việc nhìn thấy cách thực hiện điều này trở nên khó khăn hơn.

3.4 Mô hình Eliteness và BM25

Chúng tôi bây giờ tái giới thiệu tần suất từ trong mô hình của mình; điều này yêu cầu một mô hình về cách mà các tần suất từ khác nhau có thể xuất hiện trong một tài liệu (mô hình này ban đầu là do Harter [19] đề xuất). Chúng tôi giả sử rằng đối với bất kỳ cặp tài liệu-từ nào, có một thuộc tính ẩn mà chúng tôi gọi là tính ưu tú. Điều này có thể được hiểu như một dạng về nội dung: nếu từ đó là ưu tú trong tài liệu, theo một cách nào đó, tài liệu đó nói về khái niệm được từ đó biểu thị. Bây giờ chúng tôi giả sử rằng sự xuất hiện thực tế của từ trong tài liệu phụ thuộc vào tính ưu tú, và có thể có một mối liên hệ giữa tính ưu tú (đối với từ) và sự liên quan (đối với truy vấn). Nhưng chúng tôi còn gi ả sử rằng những mối quan hệ này đủ để giải thích mối liên hệ giữa tầ n suất từ tf và sự liên quan đối với truy vấn — nghĩa là, dựa trên hai phụ thuộc giả định này, tf là độc lập với Rel. Như trước đây, chúng tôi có thể minh họa các giả định này bằng mô hình đồ họa, như trong Hình 3.1.



Hình 3.1 Mô hình đồ họa của tính ưu tú (E).

Chúng tôi giả sử thêm rằng tính ưu tú tự nó là nhị phân.

Phát triển sau đây, sử dụng các ý tưởng của Harter trong bối cảnh của PRF, ban đầu được đề xuất một phần trong [45] và đầy đủ (bao gồm cả BM25) trong [46].

3.4.1 Mô hình Poisson-2

Chúng tôi giới thiệu một vài ký hiệu mới. Biến ngẫu nhiên eliteness E có thể nhận hai giá trị:

$$\text{Eliteness E:} \quad \text{elite}, \overline{\text{elite}} \quad \text{(elite, not elite)}$$

Chúng ta bây giờ phân tích tất cả các xác suất mà chúng ta muốn sử dụng hai sự kiện không giao nhau này, theo mô hình sau:

$$P(\alpha \,|\, \beta) = P(\alpha \,|\, \text{elite}) P(\text{elite} \,|\, \beta) + P(\alpha \,|\, \overline{\text{elite}}) P(\overline{\text{elite}} \,|\, \beta)$$

Mối quan hệ giữa tính ưu tú và tính liên quan được biểu thị như sau:

$$p_{i1} := P(E_i = \text{elite} \,|\, \text{rel}); \quad p_{i0} := P(E_i = \text{elite} \,|\, \overline{\text{rel}})$$

Mối quan hệ giữa tần số thuật ngữ và tính ưu tú được ký hiệu như sau:

$$E_{i1}(tf) := P(TF_i = tf \,|\, E_i = \text{elite}); \quad E_{i0}(tf) := P(TF_i = tf \,|\, E_i = \overline{\text{elite}})$$

Bây giờ, theo mô hình trên, chúng ta đi đến các biểu thức cho tất cả các xác suất mà chúng ta quan tâm đến việc liên hệ các tần số từ quan sát được với mức độ liên quan

như sau:

$$P(TF_i = tf \,|\, \text{rel}) = p_{i1}E_{i1}(tf) + (1 - p_{i1})E_{i0}(tf), \quad \text{etc.}$$

Điều này cho chúng ta một phương trình cho trọng số thuật ngữ của chúng ta:

$$w_i^{\text{elite}} = \log \frac{(p_1 E_1(tf) + (1 - p_1)E_0(tf))(p_0 E_1(0) + (1 - p_0)E_0(0))}{(p_1 E_1(0) + (1 - p_1)E_0(0))(p_0 E_1(tf) + (1 - p_0)E_0(tf))} \tag{3.6}$$

(để dễ đọc, chúng tôi đã bỏ chỉ số i khỏi tất cả các phần tử trong phân số).

Cụ thể hơn, chúng tôi đưa ra các giả định phân phối về những sự kiện này. Một lần nữa theo Harter, chúng tôi giả định rằng các phân phối tần suất từ ngữ trên các tài liệu, có điều kiện dựa trên tính ưu tú, là phân phối Poisson:

$$E_{ie}(tf) \sim \mathcal{P}(\lambda_{ie}) \quad (\text{Poisson with mean } \lambda_{ie}), \tag{3.7}$$

nơi $e \in \{0, 1\}$. Nói chung, chúng tôi mong đợi $\lambda_{i1} > \lambda_{i0}$. Do đó, trong toàn bộ tập hợp tài liệu, vốn là sự kết hợp của các tài liệu ưu tú và không ưu tú, tf được phân bố như một hỗn hợp của hai phân phối Poisson — vì vậy mô hình này được biết đến như mô hình 2-Poisson. Những hệ quả của các giả định phân phối này được phân tích bên dưới.

Bản chất của mô hình 2-Poisson đáng được thảo luận thêm. Trong công thức gốc của Harter, nó được áp dụng cho các bản tóm tắt thay vì các tài liệu toàn văn, và thực ra có thể nói rằng mô hình này giả định các tài liệu có độ dài cố định. Chúng ta có thể giải thích mô hình như sau. Chúng ta giả định rằng mỗi tài liệu được tạo ra bằng cách điền một số vị trí từ nhất định (độ dài cố định) từ một từ vựng. Hơn nữa, chúng ta giả định một phân phối đa thức đơn giản trên các từ, sao cho đối với mỗi vị trí, mỗi từ có một xác suất cố định (nhỏ) để được chọn, độc lập với những từ khác đã được chọn cho các vị trí khác. Sau đó, suy ra rằng phân phối tần suất từ (tf) đối với một từ nhất định là phân phối nhị thức, điều này xấp xỉ với phân phối Poisson trong những điều kiện này[16, VI.5].

Bây giờ mô hình tinh túy có thể được xem như một mô hình chủ đề đơn giản gây ra sự biến thiên trong các phân phối đơn ngữ. Giả sử tác giả đầu tiên chọn các chủ đề sẽ đề cập, tức là, chọn các thuật ngữ nào được coi là tinh túy và thuật ngữ nào không. Điều này xác định các xác suất cụ thể cho mô hình đơn ngữ,

và sau đó tác giả sẽ điền các vị trí từ theo mô hình đã chọn này.

Phiên bản sinh học của mô hình 2-Poisson này (tức là, một mô hình về cách tài liệu được tạo ra) liên kết nó rất chặt chẽ với các mô hình ngôn ngữ và mô hình chủ đề được thảo luận thêm trong Các Mục 4.3 và 4.5.

Chúng tôi lưu ý các đặc điểm sau của mô hình này:

1. Mô hình về tính chủ đề là một mô hình rất đơn giản — một từ một chủ đề. 2. Không có nỗ lực nào để chuẩn hóa các xác suất trên toàn bộ mô hình đơn từ của tài liệu. 3. Mô hình phụ thuộc khá quan trọng vào khái niệm rằng tất cả các tài liệu đều có cùng độ dài (cố định).

Chúng tôi không cố gắng trong cuộc khảo sát hiện tại để làm bất cứ điều gì về hai điểm đầu tiên — tuy nhiên, chúng hướng tới các công trình gần đây hơn về mô hình ngôn ngữ, được thảo luận ngắn gọn bên dưới. Về điểm thứ ba, vấn đề chuẩn hóa độ dài tài liệu là quan trọng đối với mô hình hiện tại, và được thảo luận trong Mục 3.4.5.

3.4.2 Bão hòa

Nếu chúng ta thay các giả định phân phối Poisson vào Phương trình (3.6), chúng ta có thể biểu diễn trọng số của thuật ngữ như một hàm của hai giá trị trung bình λ_e và tỷ lệ pha trộn của các tài liệu ưu tú và không ưu tú trong bộ sưu tập (cũng như tf quan sát được). Đây là một công thức khá rắc rối, và hơn nữa, chúng ta nói chung không biết các giá trị của ba tham số này, hoặc có bất kỳ cách dễ dàng nào để ước lượng chúng. Bước tiếp theo trong việc phát triển mô hình là do đó nghiên cứu hành vi định tính của hàm trọng số thuật ngữ, dưới các điều kiện khác nhau, với hy vọng tìm được một biểu thức đơn giản hơn nhiều, có thể nắm bắt được hành vi chi phối của nó [46].

Rõ ràng hành vi chính xác của nó phụ thuộc vào các tham số, nhưng một số khái quát là có thể. Chúng tôi lưu ý đặc biệt rằng:

1. $w_i^{\text{elite}}(0) = 0$ (điều này là theo thiết kế); 2. $w_i^{\text{elite}}(\text{tf})$ tăng đơn điệu theo tf;

3. ... nhưng tiệm cận đến một giá trị tối đa khi tf $\to \infty$; và

4. giới hạn tiệm cận là

$$\lim_{tf \to \infty} w_i^{\text{elite}}(tf) = \log \frac{p_1(1-p_0)}{(1-p_1)p_0} \tag{3.8}$$

$$= w_i^{\text{BIM}}. \tag{3.9}$$

Công thức cuối cùng này là trọng số mà đặc điểm tinh hoa tự nó sẽ có. Tức là, nếu tính tinh hoa có thể quan sát được, thay vì bị ẩn, chúng ta có thể xem nó như một thuộc tính nhị phân đơn giản và định trọng số cho nó theo cùng cách mà chúng ta đã định trọng số cho sự xuất hiện của từ trong mô hình độc lập nhị phân.

Tính chất tiệm cận này hoàn toàn hợp lý. Giả sử (như chúng ta đã giả định) rằng mối liên hệ duy nhất giữa tf và mức độ liên quan là thông qua tính ưu tú, thông tin tốt nhất mà chúng ta có thể hy vọng nhận được từ một từ là tài liệu thực sự ưu tú đối với từ đó. Trong thực tế, thông tin của chúng ta về điểm này mang tính xác suất, và do đó trọng số của từ tương ứng bị giảm. Mặc dù hành vi này của hàm trọng số chỉ được thiết lập cho trường hợp 2-Poisson, có vẻ hợp lý khi bất kỳ giả định phân phối nào cũng sẽ thể hiện các đặc điểm tương tự.

Chúng tôi gọi hành vi này là bão hòa. Nghĩa là, đóng góp của bất kỳ thuật ngữ nào vào điểm số của tài liệu không thể vượt quá một điểm bão hòa (giới hạn tiệm cận), bất kể thuật ngữ đó xuất hiện thường xuyên trong tài liệu. Điều này hóa ra là một thuộc tính rất quý giá của hàm trọng số BM25 được định nghĩa dưới đây.

3.4.3 Một Trường Hợp Đặc Biệt

Có một trường hợp mà giới hạn bão hòa không áp dụng. Nếu chúng ta giả sử rằng đặc tính tinh túy cho mỗi thuật ngữ truy vấn trùng khớp với độ liên quan đối với truy vấn/nhu cầu, sao cho $p_{i1} = 1$ và $p_{i0} = 0$, thì giới hạn là vô hạn, và trọng số trở nên tuyến tính theo tf. Do đó, c ác hàm trọng số thuật ngữ được sử dụng phổ biến như tf *idf truyền thống, tuyến tính theo tf, dường như phù hợp với mô hình như vậy. Tuy nhiên, hàm không tuyến tính, bão hòa của tf được phát triển dưới đây (cũng kết hợp với thành phần idf) đã thường xuyên được chứng minh là hoạt động tốt hơn tf *idf truyền thống.

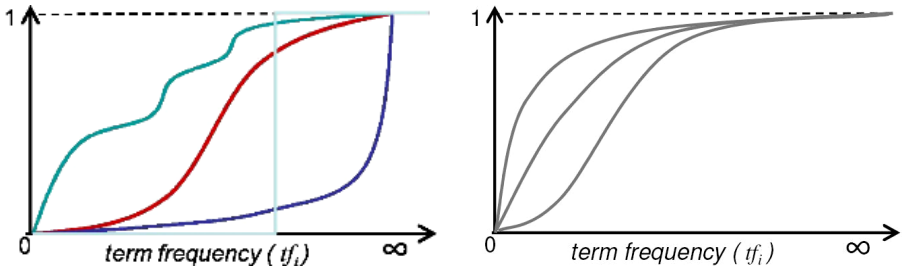
3.4.4 Tiền thân của BM25

Chúng tôi nghiên cứu hình dạng của hàm bão hòa một cách kỹ lưỡng hơn. Rõ ràng là các thuộc tính được liệt kê ở trên giới hạn nghiêm ngặt các hàm khả thi; tuy nhiên, vẫn còn nhiều khả năng, như minh họa trong đồ thị bên trái của Hình 3.2. Tuy nhiên, mô hình 2-Poisson tạo ra các hàm mượt hơn nhiều, như thể hiện trong đồ thị bên phải. Đối với hầu hết các kết hợp tham số thực tế, đường cong là lồi, như hai đường ở trên; đối với một số kết hợp, nó có độ lõm ban đầu, như đường ở dưới.

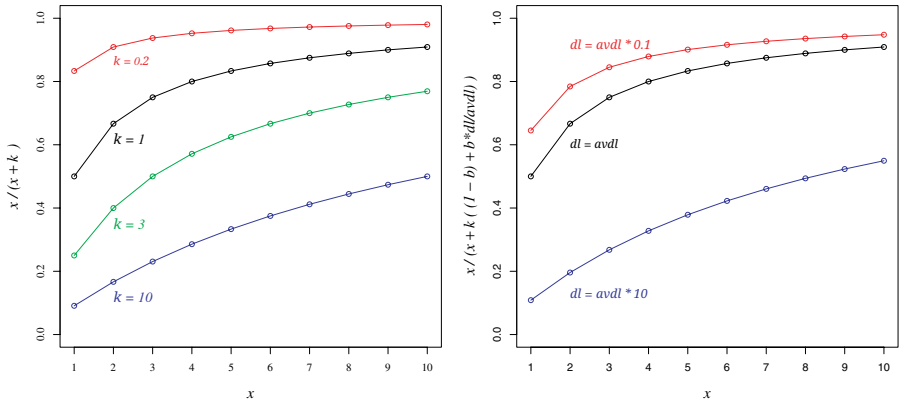
Bước tiếp theo trong việc phát triển BM25 là xấp xỉ hình dạng này. Do thiếu một mô hình ngữ liệu sinh thích hợp từ đó có thể suy ra một công thức tiện lợi, các tác giả của BM25 đã quyết định phù hợp một đường cong tham số đơn giản với hình dạng này. Hàm một tham số sau đây đã được chọn:

$$\frac{tf}{k + tf} \quad \text{for some } k > 0 \tag{3.10}$$

Hàm này thỏa mãn các đặc tính được liệt kê ở trên và phù hợp tốt với các đường cong lồi có thể có. Chúng tôi hiển thị các giá trị của hà m này cho ba giá trị khác nhau của k trong Hình 3.3; đường giữa là cho $k = 1$, đường trên là cho k thấp hơn và đường dưới là cho k cao hơn. Lưu ý rằng vì chúng tôi áp dụng điều này cho tất cả các hạng mục, chiều cao tuyệt đối không quan trọng; điều quan trọng là sự tă ng tương đối cho các gia tăng khác nhau trong tf. Do đó, đối với k cao, các gia tăng trong tf tiếp tục đóng góp đáng kể vào điểm số.



Hình 3.2 *Left*: một số hàm bão hòa có thể. *Right*: các hàm bão hòa được sinh bởi mô hình 2-Poisson.



Hình 3.3 Các hàm bão hòa được sinh ra bởi Phương trình (3.10) với tần số thô (*left*) và với tần số được chuẩn hóa bằng Phương trình (3.13) (*right*). Bão hòa mạnh hơn đạt được với giá trị k (*left*) thấp hơn và với các tài liệu ngắn hơn (*right*). Đối với biểu đồ bên phải, chúng tôi đã sử dụng $k = 1$ và $b = 0.5$.

trong khi đối với k thấp, đóng góp bổ sung của một sự kiện mới quan sát được giảm dần rất nhanh.

Chúng tôi thu được một phiên bản sớm của BM25 bằng cách kết hợp hàm bão hòa của Phương trình (3.10) với một xấp xỉ cực đại tiệm cận của Phương trình (3.9). Phương trình sau được thu được bằng cách sử dụng trọng số thuật ngữ hiện diện–vắng mặt RSJ cũ của Phương trình (3.2):

$$w_i(tf) = \frac{tf}{k + tf}\ w_i^{\text{RSJ}} \tag{3.11}$$

(Chúng tôi sẽ sửa đổi điều này bên dưới cho phiên bản cuối cùng của BM25.)

Điều chính còn thiếu cho đến nay trong phân tích là câu hỏi về độ dài của tài liệu.

3.4.5 Độ dài Tài liệu

Giả định về độ dài tài liệu cố định được đưa ra để cho phép kết nối giữa một mô hình ngôn ngữ đơn giản và BM25; chúng tôi tưởng tượng một tác giả điền vào một số chỗ cố định với một mô hình unigram cố định. Bây giờ chúng tôi tưởng tượng thay vào đó rằng tác giả cũng chọn độ dài tài liệu.

Chúng tôi giả sử rằng có điều gì đó giống như độ dài tiêu chuẩn cho một tài liệu, nhưng một tác giả có thể quyết định làm cho tài liệu dài hơn

hoặc ngắn hơn; chúng tôi chỉ xem xét trường hợp dài hơn. Tại sao một tác giả lại có thể quyết định như vậy? Chúng ta có thể đưa ra hai trường hợp cực đoan:

> Dài dòng: Một số tác giả đơn giản là dài dòng hơn những người khác, sử dụng nhiều từ hơn để nói cùng một điều. Phạm vi: Một số tác giả có nhiều điều để nói hơn: họ có thể viết một tài liệu duy nhất bao quát nhiều nội dung hơn. Một phiên bản cực đoan sẽ là tác giả viết hai hoặc nhiều tài liệu và ghép chúng lại với nhau.

Giả thuyết dài dòng gợi ý rằng chúng ta nên đơn giản chuẩn hóa bất kỳ t ần suất từ quan sát được nào bằng cách chia cho độ dài của tài liệu. Ngược lại, giả thuyết phạm vi, ít nhất là trong phiên bản cực đoan của nó, lại gợi ý điều ngược lại. Trong một tập hợp tài liệu thực tế, chúng ta sẽ quan sát thấy sự khác biệt về độ dài, điều này có thể do một trong hai hiệu ứng, hoặc do sự kết hợp của cả hai. Chúng ta giả sử nói chung là sự kết hợp: rằng mỗi giả thuyết đại diện cho một số giải thích phần nào cho sự biến đổi quan sát được. Điều này lại gợi ý rằng chúng ta nên áp dụng một loại chuẩn hóa mềm.

Chúng tôi định nghĩa độ dài tài liệu theo một cách rõ ràng:

$$\text{document length:} \quad dl := \sum_{i \in \mathbf{V}} tf_i$$

và cũng là độ dài trung bình của tài liệu cho bộ sưu tập:

$$\text{average doclength:} \quad avdl \quad \text{(average over collection)}$$

Thành phần chuẩn hóa độ dài sẽ được xác định liên quan đến giá trị trung bình; điều này đảm bảo rằng định nghĩa về độ dài tài liệu được sử dụng không quan trọng. Trong thực tế, chúng ta có thể lấy (ví dụ) số lượng ký tự trong tài liệu, hoặc số lượng từ trước khi phân tích cú pháp, hoặc thậm chí số lượng thuật ngữ duy nhất, và vẫn có được kết quả rất giống nhau.

Thành phần chuẩn hóa độ dài mềm là:

$$B := \left((1-b) + b\frac{dl}{avdl} \right), \quad 0 \leq b \leq 1 \tag{3.12}$$

Vì vậy, thiết lập $b = 1$ sẽ thực hiện chuẩn hóa toàn bộ độ dài tài liệu, trong khi $b = 0$ sẽ tắt chuẩn hóa. Bây giờ chúng ta sử dụng B để chuẩn hóa

tf, trước khi áp dụng hàm bão hòa, như sau:

$$tf' = \frac{tf}{B} \tag{3.13}$$

$$w_i^{\mathrm{BM25}}(tf) = \frac{tf'}{k_1 + tf'}\, w_i^{\mathrm{RSJ}} \tag{3.14}$$

$$= \frac{tf}{k_1\left((1-b) + b\frac{dl}{avdl}\right) + tf}\, w_i^{\mathrm{RSJ}} \tag{3.15}$$

Đây là chức năng điểm tài liệu và trọng số thuật ngữ BM25 cổ điển. Giống như tất cả các trọng số thuật ngữ-tài liệu được định nghĩa trong khảo sát này, điểm tài liệu đầy đủ được tính bằng cách cộng các trọng số thuật ngữ này trên tập các thuật ngữ truy vấn (gốc hoặc mở rộng).

3.5 Các ứng dụng của BM25

Để sử dụng BM25 như một hàm xếp hạng cho truy xuất, chúng ta cần chọn các giá trị cho các tham số nội bộ b và k_1, và cũng cần khởi tạo RSJ.

Về trọng số RSJ (Phương trình (3.2)), tất cả các nhận xét trước đó đều áp dụng. Cụ thể, nó có thể được sử dụng có hoặc không có thông tin liên quan. Trong trường hợp không có thông tin liên quan, nó giả m như trước thành một dạng của idf. Trong trường hợp này, trọng số BM25 trông rất giống với trọng số tf–idf truyền thống — một tích của hai thành phần, một dựa trên tf và một dựa trên idf. Tuy nhiên, có một khác biệt quan trọng. Thành phần tf liên quan đến hàm bão hòa đã được thảo luận, và do đó hơi khác so với hầu hết các hàm tf khác được thấy trong văn liệu, nơi các lựa chọn phổ biến là tf chính nó và (log tf). Hình dạng sau có phần giống, nhưng không có giá trị cực đại tiệm cận — nó tiến tới vô cùng, mặc dù chậm hơn tf chính nó.

Về các tham số nội bộ, mô hình không cung cấp hướng dẫn về cách thiết lập chúng. Điều này có thể được coi là một hạn chế của mô hình. Tuy nhiên, nó cung cấp cơ hội để tối ưu hóa, dựa trên một tập hợp các truy vấn đã được đánh giá và các đánh giá liên quan theo phong cách thí nghiệm truy xuất truyền thống. Một số lượng đáng kể các thí nghiệm như vậy đã được thực hiện, và cho thấy rằng nói c hung các giá trị như $0.5 < b < 0.8$ và $1.2 < k_1 < 2$ là khá tốt trong nhiều

tình huống. Tuy nhiên, cũng có bằng chứng cho thấy các giá trị tối ưu phụ thuộc vào các yếu tố khác (chẳng hạn như loại tài liệu hoặc truy vấn).

3.5.1 Một số Biến thể trên BM25

Các phiên bản BM25 được công bố có thể khác nhau đôi chút (BM25 gốc [46] hơi phức tạp hơn so với phương trình (3.15), ví dụ). Ở đây chúng tôi chỉ ra một số khác biệt có thể gặp trong các phiên bản khác nhau của hàm trong các nguồn đã được công bố.

- Bản gốc có một thành phần cho tần số thuật ngữ trong truy vấn qtf, cho các truy vấn dài hơn nơi một thuật ngữ có thể xuất hiện nhiều lần. Theo tính tổng quát đầy đủ của nó, điều này có một hàm bão hòa tương tự như được sử dụng cho tf, nhưng với k_3 hằng số riêng của nó. Tuy nhiên, các thí nghiệm cho thấy hiệu ứng bão hòa đối với qtf không quan trọng, dẫn đến một công t hức tuyến tính theo qtf. Nói cách khác, người ta có thể đơn giản coi nhiều lần xuất hiện của một thuật ngữ trong truy vấn như các thuật ngữ khác nhau.

- Bản gốc cũng có một chỉnh sửa thêm cho độ dài tài liệu, đối với tổng điểm của tài liệu. Chỉnh sửa này một lần nữa được phát hiện là không quan trọng.

- Một biến thể phổ biến là thêm một thành phần ($k_1 + 1$) vào tử số của hàm bão hòa. Điều này giống nhau cho tất cả các hạng mục, vì vậy không ảnh hưởng đến thứ hạng được tạo ra. Lý do bao gồm nó là để làm cho công thức cuối cùng tương thích hơn với trọng số RSJ được sử dụng riêng. Nếu được bao gồm, thì một lần xuất hiện duy nhất của một hạng mục sẽ có cùng trọng số trong cả hai sơ đồ.

- Một số phiên bản đã xuất bản được dựa trên các giá trị cụ thể được gán cho b và k_1. Một sự kết hợp phổ biến sẽ là $b = 0.5$ và $k_1 = 2$. (Tuy nhiên, nhiều thí nghiệm cho thấy giá trị của k_1 hơi thấp hơn và giá trị của b hơi cao hơn.)

3.6 Nhiều luồng và BM25F

Cho đến nay, tất cả các lập luận trong khảo sát này đều dựa trên ý tưởng rằng tài liệu là một khối văn bản duy nhất, không có cấu trúc và không phân biệt.

bằng bất kỳ cách nào. Tuy nhiên, trong các hệ thống tìm kiếm, việc giả định ít nhất một cấu trúc tối thiểu cho các tài liệu là điều phổ biến. Trong phần này, chúng tôi xem xét các tài liệu được cấu trúc thành một tập hợp các trường hoặc luồng. Giả định là có một cấu trúc luồng phẳng duy nhất, chung cho tất cả các tài liệu. Tức là, có một tập hợp toàn cục các luồng có nhãn, và văn bản của mỗi tài liệu được chia giữa các luồng này. Một ví dụ rõ ràng là cấu trúc tiêu đề/tóm tắt/nội dung chính mà người ta có thể thấy trong các bài báo khoa học. Trong bối cảnh Web, với các liên kết siêu văn bản rộng rãi, thường thì văn bản gốc được bổ sung bằng văn bản neo của các liên kết đến.

Đây rõ ràng là một kiểu cấu trúc rất tối thiểu; người ta có thể tưởng tượng ra nhiều cấu trúc tài liệu không phù hợp với khuôn khổ này. Tuy nhiên, những cấu trúc tối thiểu như vậy đã chứng tỏ hữu ích trong việc tìm kiếm. Ý tưởng chung, không hề bị hạn chế trong khuôn khổ hiện tại nhưng được triển khai một cách khác nhau trong nhiều hệ thống khác nhau, là một số luồng thông tin có thể dự đoán tính liên quan tốt hơn những luồng khác. Trong các ví dụ trên, một kết quả t ruy vấn khớp với tiêu đề có thể được kỳ vọng cung cấp bằng chứng mạnh mẽ hơn về khả năng liên quan so với một kết quả khớp tương đương trên nội dung chính. Hiện nay đã được biết rõ trong bối cảnh Web rằng việc khớp với văn bản neo là một tín hiệu rất mạnh.

3.6.1 Ý tưởng cơ bản

Được cho một thuật toán hoặc hàm xếp hạng có thể được áp dụng cho một đoạn văn bản không phân biệt, một cách tiếp cận thực tiễn rõ ràng với cấu trúc luồng như vậy là áp dụng hàm này riêng biệt cho từng luồng, và sau đó kết hợp chúng trong một số tổ hợp tuyến tính (với trọng số luồng) để có điểm tài liệu cuối cùng. Về mô hình tính ưu tú, cách tiếp cận này có thể được xem như giả định một thuộc tính ưu tú riêng cho từng cặp thuật ngữ/luồng. Do đó, đối với một thuật ngữ nhất định, tính ưu tú trong tiêu đề sẽ được giả định là một thuộc tính khác so với tính ưu tú trong phần nội dung. Thực ra, giả định sẽ còn mạnh mẽ hơn: chúng ta sẽ phải áp dụng các giả định thông thường về độc lập (dựa trên mức độ liên quan) giữa các thuộc tính ưu tú riêng biệt này cho cùng một thuật ngữ.

Điều này có vẻ hơi phi lý — một giả định tốt hơn có thể là tính ưu tú là một thuộc tính/thuộc tính tài liệu, được chia sẻ qua các luồng của tài liệu. Chúng ta sau đó sẽ giả thuyết rằng mối quan hệ của

Sự tinh túy đối với tần suất từ là đặc thù theo luồng. Về mô hình ngôn ngữ cơ bản đã được thảo luận ở trên, chúng ta có thể tưởng tượng rằng tác giả chọn độ dài cho (ví dụ) tiêu đề và một độ dài khác cho phần nội dung. Sau đó, dựa trên sự tinh túy (từ sự lựa chọn chủ đề mà tác giả muốn trình bày), xác suất unigram cho mô hình ngôn ngữ để điền vào các vị trí từ cũng sẽ đặc thù theo luồng. Cụ thể, sẽ có một xu hướng mạnh hơn đối với các từ tinh túy khi chọn từ cho tiêu đề so với phần nội dung (chúng ta kỳ vọng rằng tiêu đề sẽ đặc hơn về các từ chuyên đề so với một câu bình thường trong phần nội dung).

Hệ quả của thuộc tính tinh túy theo thuật ngữ-tài liệu này là chúng ta nên kết hợp bằng chứng giữa các thuật ngữ và luồng theo t hứ tự ngược lại so với đề xuất ở trên: trước tiên là các luồng, sau đó là các thuật ngữ. Tức là, đối với mỗi thuật ngữ, chúng ta nên tích lũy bằng chứng về tính tinh túy qua tất cả các luồng. Hàm bão hòa nên được áp dụng ở giai đoạn này, cho tổng bằng chứng của mỗi thuật ngữ. Sau đó, điểm tài liệu cuối cùng nên được xác định bằng cách kết hợp giữa các thuật ngữ.

3.6.2 Ký hiệu

Chúng tôi có một tập hợp S luồng, và chúng tôi muốn gán trọng số tương đối v_s cho chúng. Đối với một tài liệu nhất định, mỗi luồng có độ dài liên quan của nó (tổng độ dài của tài liệu thường là tổng của c ác độ dài luồng). Mỗi từ trong tài liệu có thể xuất hiện trong bất kỳ luồng nào, với bất kỳ tần suất nào; tổng tần suất từ–luồng này trên tất cả các luồng sẽ là tần suất một từ trong tài liệu thông thường. Toàn bộ tài liệu trở thành một vector của các vector.

các luồng $s = 1, \ldots, S$ độ dài luồng sl_s trọng số luồng v_s tài liệu $(tf1, \ldots, tf|V|)$ vector của các vector tf_i vector $(tf_{1i}, \ldots, tf_{Si})$

nơi tf_{si} là tần suất của từ i trong luồng s.

3.6.3 BM25F

Sự mở rộng đơn giản nhất của BM25 sang các luồng có trọng số là tính toán một biến thể có trọng số của tần số thuật ngữ tổng thể. Điều này cũng ngụ ý việc có

một biến thể có trọng số tương tự của tổng chiều dài tài liệu:

$$\widetilde{tf}_i = \sum_{s=1}^{S} v_s \, tf_{si} \tag{3.16}$$

$$\widetilde{dl} = \sum_{s=1}^{S} v_s \, sl_s \tag{3.17}$$

$$\widetilde{avdl} = \text{average of } \widetilde{dl} \text{ across documents}$$

$$w_i^{\text{simpleBM25F}} = \frac{\widetilde{tf}_i}{k_1 \left((1-b) + b \frac{\widetilde{dl}}{\widetilde{avdl}} \right) + \widetilde{tf}_i} \, w_i^{\text{RSJ}} \tag{3.18}$$

Tuy nhiên, chúng ta cũng có thể muốn cho phép các tham số của BM25 thay đổi giữa các luồng — có thể các luồng khác nhau có các đặc điểm khác nhau, ví dụ, liên quan đến mức độ dài dòng so với phạm vi (như được định nghĩa trong Mục 3.4.5). Thực tế có thể sắp xếp lại công t hức (3.15) để bao gồm bất kỳ yếu tố nào sau đây trong phần riêng của t ừng luồng: k_1, b, w_i^{RSJ} hoặc phiên bản không phản hồi của nó w_i^{IDF}. Chúng tôi đặc biệt thấy hữu ích khi cho phép b là riêng của từng luồng; ở đây chúng tôi trình bày phiên bản BM25F phù hợp:

$$\widetilde{tf}_i = \sum_{s=1}^{S} v_s \frac{tf_{si}}{B_s} \tag{3.19}$$

$$B_s = \left((1-b_s) + b_s \frac{sl_s}{avsl_s} \right), \quad 0 \le b_s \le 1 \tag{3.20}$$

$$w_i^{\text{BM25F}} = \frac{\widetilde{tf}_i}{k_1 + \widetilde{tf}_i} \, w_i^{\text{RSJ}} \tag{3.21}$$

Phiên bản này đã được sử dụng trong [62]; phiên bản đơn giản trong [50]. Như thường lệ, trong trường hợp không có thông tin phản hồi li ên quan, w_i^{RSJ} nên được thay bằng w_i^{IDF}. Trong [50, 62] chúng tôi đã tính toán IDF trên toàn bộ tập hợp mà không quan tâm đến các luồng. Điều này hoạt động tốt trong thực tế, nhưng có thể dẫn đến các tr ường hợp thoái hóa (ví dụ, khi một luồng cực kỳ dài dòng và chứa hầu hết các thuật ngữ cho hầu hết các tài liệu). Định nghĩa chính xác của IDF trong bối cảnh này cần được nghiên cứu thêm (điều này cũng được thảo luận trong [37] nơi khái niệm idf dự kiến được giới thiệu).

Bảng 3.1. Các tham số BM25F được báo cáo trong [62] cho các nhiệm vụ tìm kiếm chiết xuất chủ đề (TD) và trang tên (NP)

Tham số	TD'03	NP'03
k_1	27.5	4.9
b_{title}	0.95	0.6
b_{body}	0.7	0.5
b_{anchor}	0.6	0.6
v_{title}	38.4	13.5
v_{body}	1.0	1.0
v_{anchor}	35	11.5

Như một minh họa, chúng tôi báo cáo trong Bảng 3.1 các trọng số BM25F được báo cáo trong [62] cho các nhiệm vụ TRECWebSearch năm 2003.

3.6.4 Giải thích Phiên bản Đơn giản

Đáng nhắc đến một cách giải thích rất minh bạch của phiên bản đơn giản — mặc dù nó không áp dụng trực tiếp cho phiên bản với biến b, nhưng nó có thể cung cấp một số cái nhìn sâu sắc. Nếu các trọng số luồng v_s là số nguyên, thì chúng ta có thể xem công thức BM25F đơn giản như một hàm BM25 thông thường áp dụng cho một tài liệu trong đó một số luồng đã được nhân bản. Ví dụ, nếu các luồng và trọng số là $\{$ $\text{v}_{\text{title}} = 5$, $\text{v}_{\text{abstract}} = 2$, $\text{v}_{\text{body}} = 1\}$, thì công thức 3.18 tương đương với 3.15 áp dụng cho một tài liệu trong đó tiêu đề đã được nhân bản năm lần và tóm tắt hai lần.

3.7 Các tính năng liên quan phi văn bản

Trong nhiều bộ sưu tập, có những nguồn thông tin liên quan khác ngoài văn bản. Những thứ như tuổi của một tập tin, loại của nó hoặc độ liên kết vào của nó có thể cung cấp thông tin hữu ích về mức độ liên quan của một tài liệu. Sự phát triển của PRF là khá tổng quát và không đề cập rõ ràng đến các thuật ngữ hay văn bản; do đó, ít nhất về mặt nguyên tắc, có thể xem xét các đặc điểm phi văn bản.

Chúng tôi sẽ thực hiện hai giả định ở đây về các đặc trưng phi văn bản. Đầu tiên, chúng tôi thực hiện giả định thường gặp về sự độc lập của đặc trưng đối với tỷ lệ liên quan (như đã thảo luận trong Mục 2). Thứ hai, chúng tôi sẽ giả định rằng tất cả các đặc trưng phi văn bản đều cung cấp thông tin về mức độ liên quan.

điều này độc lập với truy vấn. Với hai giả định này, chúng ta có thể tích hợp các đặc trưng phi văn bản rất dễ dàng vào các khung chấm điểm PRF và BM25. Về nguyên tắc, có thể nới lỏng các giả định này và tạo ra các mô hình liên quan phức tạp hơn cho các đặc trưng phi văn bản.

Hãy gọi c $=$(tf 1, . . . , tf $|V|$) là vector của các tần suất xuất hiện từ của tài liệu d, và hãy gọi f là một vector bổ sung của các đặc trưng phi văn bản f $=(f_1, \ldots, f_F)$. Chúng ta có $d =$(c, f).

Lưu ý rằng phát triển PRF ban đầu (Các phương trình (2.1–2.4) trong Mục 2) cũng áp dụng cho phiên bản mở rộng này của d. Ph ương trình (2.4) đưa ra giả định về tính độc lập của các đặc trưng, điều này cũng áp dụng cho các đặc trưng phi văn bản. Do đó, tích trong Phương trình 2.4 sẽ bao gồm tất cả các đặc trưng phi văn bản f.

Trong Phương trình (2.5), khi chúng ta loại bỏ tất cả các hạng tử không liên quan đến truy vấn trong c, không có hạng tử nào trong f bị loại bỏ — các đặc trưng phi văn bản được giả định có liên quan với mức thích hợp cho tất cả các truy vấn. Sau khi lấy log trong Phương trình (2.6), chúng ta thấy việc thêm các đặc trưng phi văn bản chỉ đơn giản thêm một hạng tử mới vào tổng. Việc loại bỏ các giá trị không trong các Phương trình (2.7–2.9) không ảnh hưởng đến hạng tử này, vì vậy sau (2.11) chúng ta có thể viết:

$$P(\mathrm{rel}\,|\,d,q) \propto_q \sum_{\mathbf{q}, tf_i>0} W_i(tf_i) + \sum_{i=1}^{F} \lambda_i V_i(f_i), \tag{3.22}$$

ở đâu

$$V_i(f_i) := \log \frac{P(F_i = f_i\,|\,\mathrm{rel})}{P(F_i = f_i\,|\,\overline{\mathrm{rel}})} \tag{3.23}$$

Chúng tôi đã thêm một tham số tự do nhân tạo λ_i để tính đến việc thay đổi tỷ lệ trong việc xấp xỉ W_i và V_i.

Chúng tôi lưu ý rằng các đặc trưng f_i có thể là đa giá trị hoặc liên tục, và điều này ngụ ý sự cần thận trọng trong việc lựa chọn hàm $V(f_i)$ (giống như cách chúng tôi đã chú ý để tìm một hàm tốt của tf). Điều này sẽ phụ thuộc vào bản chất của từng đặc trưng phi văn bản f_i và kiến thức trước đây của chúng tôi về nó. Dưới đây là một số hàm V_i mà chúng tôi đã sử dụng một cách thành công trong quá khứ cho các đặc trưng khác nhau:

- Logarithmic: $\log(\lambda_i' + f_i)$

- Lý do: $f_i/(\lambda'_i + f_i)$
- Sigmoid: $[\lambda'_i + \exp(-f_i\,\lambda''_i)]^{-1}$

Phát triển này có thể giải thích, ví dụ, tại sao các hàm đánh giá đơn giản như BM25F(q,d)+log($PageRank(d)$) có thể hoạt động tốt trong t hực tế đối với việc truy xuất thông tin trên Web. Điều này có thể được cải thiện nhiều hơn bằng cách thêm tham số tỷ lệ λ, và có thể được c ải thiện hơn nữa (chỉ một chút) bằng cách đổi log thành sigmoid và điều chỉnh hai tham số bổ sung λ' và λ''[12]. Trong công trình của chúng tôi, chúng tôi phát triển các hàm xếp hạng tinh vi hơn tích hợp nhiều dạng thông tin phi văn bản và sử dụng hơn một chục tham số [12, 13]. Việc tối ưu hóa các tham số này được thảo luận trong Mục 5.

3.8 Thông tin vị trí

Phần lớn, PRF không quan tâm đến thông tin vị trí: nó chỉ quan tâm đến số lần xuất hiện của một thuật ngữ, nhưng không quan tâm đến vị trí của chúng. Có hai lý do quan trọng đã ngăn cản PRF xem xét thông tin vị trí: (i) rất khó để phát triển một mô hình chính thức về mức liên quan một cách vững chắc mà vẫn tính đến thông tin vị trí mà không làm tăng đáng kể số lượng tham số, và (ii) thông tin vị trí đã được chứng minh là có tác động khá ít đến độ chính xác truy xuất trung bình. Trong phần này, chúng tôi chỉ đưa ra tổng quan về các phương pháp hiện có và thảo luận về những khó khăn chính. Chúng tôi cũng đề xuất một vài trực giác về lý do tại sao vị trí có thể không quan trọng như vẻ bề ngoài ban đầu.

Tại sao lại khó đến vậy để mô hình hóa sự liên quan liên quan đến vị trí của các từ trong truy vấn và tài liệu? Một số vấn đề xuất hiện. Đầu tiên, chúng ta cần xác định một vũ trụ sự kiện phù hợp. Trong PRF truyền thống, vũ trụ này đơn giản chỉ là $\mathbb{N}^{|q|}$, tất cả các vectơ tần số từ có thể của các từ trong truy vấn. Cách tự nhiên nhất để xem xét vị trí là mô tả tất cả các chuỗi từ trong truy vấn được phân cách bởi một số từ không thuộc truy vấn. Điều này dẫn đến một không gian có chiều quá cao, và rất khó để phân tích nó một cách thích hợp. Trong mô hình truyền thống, đơn vị tự nhiên mà chúng ta xây dựng (phân tích) các đại lượng cần thiết là sự xuất hiện của một từ với số lượng nhất định

lần. Đơn vị tự nhiên nào để xây dựng (phân tích nhân tử) các xác suất cần thiết nhằm mô hình hóa các vị trí một cách thích hợp?

Đã có một số nỗ lực để giải quyết những vấn đề này và đưa thông tin vị trí vào BM25 (xem ví dụ [3,54, 51] và các tài liệu tham khảo trong đó). Ba phương pháp chính được sử dụng như sau:

1. Lập chỉ mục các cụm từ như các thuật ngữ riêng lẻ. Cách tiếp cận này lý tưởng cho các token có nhiều từ (chẳng hạn như White House) mà việc khớp một phần thực ra sẽ là sai. Việc triển khai của nó cực kỳ đơn giản vì không cần phải sửa đổi hàm xếp hạng theo bất kỳ cách nào (mỗi cụm từ sẽ có tf và idf riêng). Tuy nhiên, có ba vấn đề: (i) nó không xem xét các khớp một phần; (ii) nó không xem xét các thuật ngữ gần nhau nhưng không hoàn toàn liền kề; và (iii) cần xác định các cụm từ hợp lệ [48]. 2. Đánh giá các đoạn văn bản thay vì toàn bộ tài liệu. Điều này có thể được thực hiện một cách rõ ràng, với một hàm xếp hạng truy xuất đoạn văn bản [3], hoặc một cách ngầm định bằng cách xây dựng một hàm xếp hạng tích hợp các điểm số tính toán trên nhiều đoạn văn bản của tài liệu [51]. 3. Rút ra các đặc trưng vị trí (chẳng hạn như độ dài tối thiểu và tối đa của các đoạn văn bản chứa tất cả các thuật ngữ trong truy vấn) mà sau đó có thể được tích hợp vào hàm đánh giá như các đặc trưng phi văn bản (như những đặc trưng trong

Theo quan điểm của chúng tôi, không có nỗ lực nào trong số này đủ điều kiện như một sự mở rộng tự nhiên của PRF, vì không rõ các giả định về sự liên quan là gì. Metzler [32, 33] đề xuất một mô hình truy xuất xác suất mới, trong đó đưa ra các giả định rõ ràng về vị trí và sự liên quan, và có thể được tích hợp trong PRF. Mô hình này ước lượng xác suất liên quan của tài liệu và truy vấn cùng nhau: $P(Q, D \mid Rel)$. Điều này được thực hiện thông qua Mạng Ngẫu nhiên Markov (MRF) có thể xem xét các vị trí của thuật ngữ một cách tự nhiên. MRF có thể sử dụng bất kỳ tiềm năng nào được xác định phù hợp: trong khi công trình nguyên bản sử dụng các tiề m năng bắt nguồn từ LM, các tiềm năng tương tự BM25 đã được sử dụng trong [31]. Tuy nhiên, ngay cả khi sử dụng các tiềm năng tương tự BM25, chúng tôi cũng không thể gọi mô hình này là một sự mở rộng của

PRF, vì nó mô hình hóa một phân phối khác: $P(D,Q \mid Rel)$ thay vì phân phối hậu nghiệm $P(Rel \mid D,Q)$.

Chúng tôi kết thúc phần này bằng một cuộc thảo luận ngắn về lý do t ại sao thông tin vị trí có thể không quan trọng như nó có vẻ ban đầu. Thật đáng suy ngẫm khi thấy việc sử dụng hiệu quả thông tin lân cận trong các thí nghiệm IR trong quá khứ khó khăn như thế nào. Tất cả các công trình được tham chiếu trong phần này đều khẳng định cải thiện có ý nghĩa thống kê so với các mốc không vị trí, nhưng các cải thiện được báo cáo là nhỏ. Chúng tôi tin rằng điều này đặc biệt đúng đối với các bộ sưu tập nhỏ và tình huống yêu cầu khả năng truy hồi cao (điển hình trong các đánh gi á IR học thuật), vì thông tin vị trí là một kỹ thuật cải thiện độ chính xác. Nhưng ngay cả trong các bộ sưu tập lớn với các yêu cầu độ chính xác cao (chẳng hạn như các đánh giá Tìm kiếm Web thực tế), các lợi ích quan sát được cũng nhỏ. Tại sao lại như vậy? Chúng tôi không biết các nghiên cứu lý thuyết hay thực nghiệm nào về vấn đề này, nhưng chúng tôi đề xuất ở đây hai giả thuyết.

Trước hết, chúng tôi tin rằng ngôn ngữ tự nhiên, và các truy vấn đặc biệt, khá bền vững. Chúng tôi sẽ lập luận rằng đối với nhiều truy vấn, con người vẫn có thể xác định mức độ liên quan của một tài liệu với truy vấn ngay cả khi các từ trong tài liệu và truy vấn bị xáo trộn. Và trong những trường hợp mà điều này không đúng, có khả năng là người dùng sẽ vô thức sửa truy vấn bằng cách thêm các từ vào đó để làm rõ nghĩa. Điều này không có nghĩa là tất cả các truy vấn và tài liệ u đều chịu được thay đổi vị trí, nhưng tỷ lệ những trường hợp cần vị trí là nhỏ. Thứ hai, cần lưu ý rằng việc tính đến cấu trúc của một tài liệu (ví dụ, trong BM25F) một cách ngầm định sẽ thưởng cho sự gần gũi trong các chuỗi ngắn quan trọng, chẳng hạn như tiêu đề.

3.9 Các Triển Khai Mã Nguồn Mở của BM25 và BM25F

Chúng tôi xem xét ở đây một số triển khai của BM25 và BM25F có sẵn dưới dạng mã nguồn mở. Danh sách này không đầy đủ, có thể có các công cụ tìm kiếm khác hoặc các tiện ích mở rộng của chúng mà triển khai BM25 và BM25F.

Theo như chúng tôi biết, chỉ có MG4J [9, 34] hoàn toàn triển khai BM25F (phiên bản 2.2 trở lên). BM25 được triển khai bởi Lemur, MG4J, Okapi, PF/Tija, Terrier, Wumpus, Xapian và Zettair [22, 27, 34, 35, 39, 56, 57, 60, 61, 63]. Tất cả các công cụ tìm kiếm này đều khá mô-đun và về nguyên tắc có thể được chỉnh sửa để mở rộng BM25 theo một số cách, đặc biệt là để triển khai BM25F. Lucene [29] không triển khai BM25

nhưng tồn tại một số tiện ích mở rộng Lucene của bên thứ ba triển khai BM25 và BM25F [38]. Chúng tôi đã kiểm tra mã của tất cả các triển khai này và chúng tôi tin rằng chúng là chính xác. [1] (việc kiểm tra là trực quan: chúng tôi không chạy thử nghiệm tự mình; trong hai trường hợp triển khai không chính xác và chúng tôi đã yêu cầu các tác giả sửa, và họ đã làm). Không có hệ thống nào ở trên hỗ trợ tối ưu hóa tham số, mặc dù việc mở rộng chúng để làm điều này không nên khó khăn.

[1] Có một số khác biệt nhỏ trong các triển khai BM25 trong các gói này vào thời điểm viết khảo sát này. Ví dụ, PF/Tijah sử dụng idf$= \log \frac{N+0.5}{n+0.5}$, Terrier không cho phép chỉnh sửa k theo lập trình và Xapian không cho phép chỉnh sửa bất kỳ tham số nào theo lập trình.

4

So sánh với các mô hình khác

Mô hình xác suất đầu tiên cho việc truy hồi thông tin được Maron và Kuhns đề xuất vào năm 1960 [30]. Nó cũng dựa trên khái niệm về xác suất liên quan; tuy nhiên, có một sự khác biệt thú vị giữa phương pháp của Maron và Kuhns và phương pháp của Robertson và Sp¨arck Jones mười lăm năm sau. Sự khác biệt này là đề tài nghiên cứu vào đầu những năm 1980 về việc thống nhất hai phương pháp này. Để giải thích cả sự khác biệt lẫn nỗ lực thống nhất, trước hết chúng tôi sẽ mô tả mô hình của Maron và Kuhns.

4.1 Maronand Kuhns

Tình huống mà Maron và Kuhns hình dung là của một thủ thư đang lập chỉ mục cho một cuốn sách (tài liệu). Ý tưởng là việc lập chỉ mục nên dự đoán cách mà người ta đưa ra yêu cầu ngay từ đầu. Lập chỉ mục lý tưởng nên phù hợp với những yêu cầu của chính những người muốn được chỉ dẫn đến chuyên khảo này — những người sẽ thấy nó có liên quan đến nhu cầu của họ. Hệ thống được giả định là một hệ thống các đề mục chủ đề, mà bất kỳ đề mục nào trong số đó đều có t hể được thủ thư gán cho cuốn sách đang xét; một yêu cầu của người dùng sẽ có dạng của một đề mục chủ đề được chọn để

xem dưới. Do đó, thủ thư sẽ được mời đánh giá, đối với từng đầu đề chủ đề của ứng viên, xác suất mà một người dùng tìm kiếm ở đó sẽ thấy cuốn sách cụ thể này có liên quan.

Cho đến nay, cơ sở cho mô hình trông rất giống với PRF được đị nh nghĩa trong Mục 2. Tuy nhiên, để hiểu rõ hơn bản chất của xác s uất liên quan như được Maron và Kuhns diễn giải, chúng ta cần xem xét không gian sự kiện mà nó được định nghĩa. Điều này sẽ cung cấp cho chúng ta cơ sở để so sánh trong phần tiếp theo.

Chúng ta có (ít nhất trong suy nghĩ của thủ thư) một nhóm người dù ng (có nhu cầu thông tin) tìm kiếm theo một đề mục cụ thể. Mặt khác, chúng ta có một cuốn sách cá nhân trước thủ thư. Do đó, không gian sự kiện liên quan, trong đó xác suất nên được định nghĩa, là không gian của người dùng. Nếu chúng ta cố gắng sử dụng phản hồi để ước lượng xác suất như vậy, lý tưởng nhất là chúng ta sẽ đếm người dùng — tức là, trong số t ất cả những người dùng biểu thị các truy vấn của họ thông qua một đề mục cụ thể, có bao nhiêu phần trăm sẽ muốn cuốn sách đơn này.

Cách tiếp cận này gần đây đã có thêm sức mạnh mới, vì các công cụ Tìm kiếm Web lớn thường thấy một số truy vấn (các truy vấn gọi là 'đầu') được nhiều người dùng khác nhau lặp lại nhiều lần. Dữ liệu nhật ký nhấp chuột trông hơi giống phản hồi liên quan đến các tài li ệu cá nhân từ một tập hợp người dùng có các truy vấn tương tự. Tuy nhiên, mối quan hệ giữa điều này và PRF được thảo luận trong chuyên khảo này cần được phân tích thêm.

4.2 Mô Hình Thống Nhất

Chúng tôi quay lại mô hình RSJ gốc, nền tảng của mô hình được trình bày trong khảo sát này, để định nghĩa nó bằng các thuật ngữ tương tự. Trong trường hợp này, chúng tôi bắt đầu với một người dùng cá nhân, người đưa ra một yêu cầu bằng cách sử dụng một số từ nhất định. Bây giờ chúng ta đặt câu hỏi, xác suất rằng bất kỳ tài liệu nào ngẫu nhiên khớp với một (hoặc kết hợp) những từ này liên quan đến người dùng là bao nhiêu. Do đó, không gian sự kiện ở đây bao gồm các tài liệu, và nếu chúng ta muốn sử dụng phản hồi để ước tính xác suất, chúng ta sẽ đếm các tài liệu, như trong Mục 3.1.

Ngay lập tức trở nên rõ ràng rằng mặc dù cả hai mô hình đều đề cập đến xác suất liên quan, chúng định nghĩa các phiên bản tương ứng của điều này

xác suất trong các không gian sự kiện khác nhau. Thực tế, hai xác suất có liên quan thực sự khá khác biệt.

Nỗ lực thống nhất [43]được dựa trên lập luận sau. Chúng ta hình dung một ma trận người dùng-có-nhu cầu-thông tin đối chiếu với tài liệu (người dùng cá nhân u, tài liệu cá nhân d). Lý tưởng là chúng ta muốn gán một xác suất ý nghĩa về mức độ liên quan cho sự kết hợp c ụ thể giữa một người dùng cá nhân với một tài liệu cá nhân: $P(\text{rel}|u,d)$. Tuy nhiên, thực hiện điều này trực tiếp có vẻ khó — ít nhất là nếu chúng ta đang tìm kiếm bằng chứng trực tiếp (phản hồi). Nếu chúng ta hiển thị d cho u và nhận được đánh giá, chúng ta không còn cần gán xác suất nữa! Thật vậy, chỉ có ý nghĩa khi làm điều đó khi chúng ta có các lớp sự kiện tương tự.

Maron và Kuhns bắt đầu bằng cách phân loại người dùng với nhau, theo các tiêu đề chủ đề mà họ tham khảo. Do đó chúng ta đang xử lý một lớp người dùng, và hỏi về $P(\text{rel}|U,d)$. Mặt khác, Robertson và Sprck Jones phân loại tài liệu với nhau thành các lớp như D, và hỏi về $P(\text{rel}|u,D)$.

Mô hình hợp nhất tiếp tục định nghĩa bốn xác suất liên quan khác nhau. Chúng ta có thể xem xét bắt đầu với $P(\text{rel}|U,D)$, đây là một mô hình tổng quát chỉ cần phản hồi từ những người dùng tương tự về các tài liệu tương tự (điều này được gọi là Mô hình 0). Nếu chúng ta có phản hồi về tài liệu cụ thể, chúng ta có thể cải thiện ước tính này bằng cách xem xét $P(\text{rel}|U,d)$ (Mô hình 1). Mặt khác, nếu chúng ta có phản hồi từ người dùng cụ thể, chúng ta nên chọn $P(\text{rel}|u,D)$ (Mô hình 2). Cuối cùng, nếu chúng ta có cả hai loại bằng chứng chuyên môn đồng thời (Mô hình 3), chúng ta có thể hướng đến một xác suất tốt hơn nữa. Tuy nhiên, mối quan hệ chính xác của nó với $P(\text{rel}|u,d)$ không hoàn toàn rõ ràng, vì mặc dù nó dựa trên phản hồi của ba loại nêu trên, nhưng thực sự nó sẽ không có phản hồi về cặp cá nhân chính xác đó.

Mô hình thống nhất đã là đối tượng của một số nghiên cứu gần đây hơn [8], và giờ đây chúng ta đang đi vào một lĩnh vực mà nhiều loại phản hồi khác nhau có thể khả thi, dựa vào loại ghi nhận hành vi tìm kiếm trên Web mà hiện nay đã trở thành chuẩn mực. Các tác giả khác (ví dụ [14, 17], và sau đó [25] trong bối cảnh mô hình ngôn ngữ được thảo luận dưới đây) đã tiếp cận vấn đề bằng một cách giới hạn bản thân về Mô hình 0, bằng cách chỉ xem xét các đại diện của tài liệu và truy vấn, thay vì các trường hợp riêng lẻ.

Tuy nhiên, trong khảo sát hiện tại, chúng tôi chỉ giới hạn mình ở quan điểm RSJ về xác suất liên quan.

4.3 Mô Hình Ngôn Ngữ Đơn Giản

Mô hình ngôn ngữ (LM) của IR là một đổi mới gần đây hơn [24, 26, 33], cũng có động cơ xác suất mạnh mẽ. Trước tiên chúng tôi mô tả LM đơn giản, và sau đó một số phát triển tinh vi hơn.

Trong LM, chúng tôi coi bất kỳ đoạn văn bản nào (tài liệu, truy vấn, v.v.) đều được tạo ra bởi một quá trình thống kê. Ngoài IR, các mô hình như vậy đã rất thành công trong nhiều lĩnh vực khác nhau, đặc biệt là trong nhận dạng giọng nói, và ứng dụng IR đã học hỏi từ lĩnh vực đó. Trong quan điểm đặc biệt này về văn bản, văn bản được coi là được tạo ra từng từ một theo trình tự, mỗi từ được chọn từ một từ vựng. Mô hình thống kê đơn giản nhất, gọi là unigram, có một p hân phối xác suất cố định trên từ vựng, áp dụng cho tất cả các vị trí từ (vì vậy trên thực tế trình tự không quan trọng). Mô hình n-gram giả định rằng việc chọn từ tiếp theo phụ thuộc vào $n-1$ từ đã chọn trước đó.

Cách tiếp cận LM đơn giản đối với IR giả định rằng mỗi tài liệu có mô hình riêng của nó, và đặt câu hỏi này về mỗi tài liệu: xác suất mà truy vấn xuất phát từ (được tạo ra bởi) cùng mô hình ngôn ngữ với tài liệu là bao nhiêu (trong cách tiếp cận này không có mô hình truy vấn riêng). Xác suất này được sử dụng để xếp hạng các tài liệu cho một truy vấn. Do đó, không có khái niệm rõ ràng về mức độ liên quan; khái niệm ngầm định là một tài liệu có liên quan đến một truy vấn nếu truy vấn được tạo ra từ cùng mô hình ngôn ngữ với tài liệu. Cách tiếp cận này cũng không phân biệt giữa từng người dùng — một truy vấn được hiểu chỉ là một văn bản, và mỗi cặp truy vấn–tài liệu được xem là một sự kiện cá nhân tương đương. Từ quan điểm của từng người dùng, mô hình ngầm định giả định rằng chỉ có một tài liệu liên quan (nếu phiên bản truy vấn này được tạo ra bởi mô hình ngôn ngữ cho tài liệu 1, nó cũng không thể được tạo ra bởi mô hình ngôn ngữ khác cho tài liệu 2). Tuy nhiên, vì cách tiếp cận

một tài liệu có thể có liên quan. Nhưng điều đó kéo theo rằng không có lý do gì để xem xét phản hồi cá nhân trong bối cảnh của LM đơn giản.

Chi tiết hơn, mô hình ngôn ngữ tài liệu thường được xây dựng bằng cách trộn (làm mượt) các xác suất được suy ra từ chính tài liệu với các xác suất lấy từ một mô hình ngôn ngữ nền chung. Một mục đích của việc làm mượt này là để tránh việc gán xác suất bằng không cho bất kỳ thuật ngữ nào không xuất hiện trong tài liệu. Nói chung, một kho tàng phong phú các mô hình và phương pháp ước lượng đã được khai thác trong khuôn khổ tổng thể của LM. Chúng tôi chỉ đi sâu vào hai trong số các phát triển này trong các phần tiếp theo.

4.4 Mô hình Ngôn ngữ Liên quan

Một số hạn chế của mô hình đơn giản được giải quyết trong công trình về mô hình liên quan cho khuôn khổ LM [26, 33]. Ngược lại, ở đây, chúng tôi giả định rằng truy vấn có (tức là được tạo ra bởi) một mô hình riêng của nó, khác với bất kỳ mô hình tài liệu cụ thể nào. Nguồn ban đầu cho mô hình này rõ ràng là chính truy vấn; tuy nhiên, phản hồi liên quan (ví dụ t ừ người dùng cá nhân) có thể cung cấp bằng chứng bổ sung về nó.

Với cách tiếp cận này, quá trình đối sánh tài liệu–truy vấn trở nên kém rõ ràng hơn nhiều. Lưu ý rằng cả trong LM đơn giản, và trong khuôn khổ xác suất truyền thống về độ liên quan (PRF) được mô tả trong khảo sát này, quá trình đối sánh truy vấn với tài liệu vốn có trong mô hình, hoàn toàn do mô hình tự xác định. Trong bối cảnh mới này, không có quá trình đối sánh nào như vậy được định nghĩa; cần thiết phải chọn một quá trình từ bên ngoài mô hình.

Được biết cả LM của tài liệu và LM của truy vấn (độ liên quan) đều có dạng phân phối thống kê trên một từ vựng, việc so khớp trở thành câu hỏi về việc so khớp hai phân phối thống kê. Cách phổ biến nhất để thực hiện điều này là sử dụng thước đo độ lệch Kullback–Leibler (KL). Điều này có sự ủng hộ thực nghiệm tốt.

4.5 Mô hình chủ đề

Có lẽ có tiềm năng cho một loại cầu nối giữa phương pháp LM và công việc PRFin về các mô hình chủ đề ngầm định. Hầu hết những điều như vậy

công trình đã cố gắng khám phá các chủ đề ẩn trong cấu trúc thống kê của ngôn ngữ tài liệu; ví dụ bao gồm Latent Semantic Indexing (LSI) [18], , Probabilistic LSI [21] và Latent Dirichlet Allocation [7]. Các biến tinh tú ẩn được giả định trong khuôn khổ liên quan xác suất có một số điểm tương đồng (mặc dù được đơn giản hóa rất nhiều bởi giả định rằng một biến tinh tú cho mỗi từ). Một cách tiếp cận liên quan là LM tiết kiệm [20], , cố gắng mô hình hóa theo cách nào một tài liệu hoặc truy vấn cụ thể được phân biệt so với ngôn ngữ nền chung. Tuy nhiên, dường như chúng ta còn một khoảng cách khá xa so với việc thống nhất nghiêm túc LM và PRF, là chủ đề chính của bài khảo sát này.

4.6 Sai lệch khỏi Tính Ngẫu nhiên

Các mô hình DFR [2], , giống như các mô hình ngôn ngữ, không chứa " tính liên quan" như một khái niệm cơ bản. Cũng giống như các mô hình ngôn ngữ, chúng tập trung vào phân bố thống kê của các từ trong các tài liệu. Nói chung, chúng tìm cách xác định các cách mà phân bố từ khác với những gì người ta có thể mong đợi một cách ngẫu nhiên—bằng chứng về sự khác biệt này được coi ngầm như là bằng chứng về tính liên quan.

Có thể suy ra nhiều hàm trọng số thuật ngữ và xếp hạng tài liệu khác nhau trong khuôn khổ này, bao gồm một công thức gần giống như BM25.

5

Tối ưu hóa tham số

Giống như hầu hết các mô hình IR, các mô hình trong PRF có các tham số tự do cần được đặt ở các giá trị thích hợp. Các mô hình BM25 và BM25F được biết đến là khá ổn định đối với các tham số của chúng, có nghĩa là các thay đổi nhỏ trong giá trị tham số (hoặc trong tập hợp dữ liệu) không tạo ra sự thay đổi lớn về độ chính xác hoặc mức độ liên quan. Tuy nhiên, có thể đạt được những cải thiện đáng kể về mức độ liên quan bằng cách t ối ưu hóa các tham số một cách phù hợp, đặc biệt khi chúng ta xử lý một tập hợp dữ liệu mới.

Tối ưu hóa tham số đi kèm với chi phí đáng kể: nó sẽ yêu cầu đánh giá bằng con người đối với nhiều kết quả truy vấn, điều này tốn kém, và các tham số được tối ưu hóa sẽ cụ thể cho bộ sưu tập được đánh giá và có thể không hoạt động tốt cho các bộ sưu tập khác. Hơn nữa, quy trình tối ưu hóa có thể tốn kém về mặt tính toán, đòi hỏi nhiều năng lực tính toán hơn chính công cụ tìm kiếm. Vì những lý do này, phương pháp này chỉ phù hợp cho các bộ sưu tập cụ thể mà đáng giá chi phí cần thiết để tối ưu hóa hàm xếp hạng. Ví dụ về các bộ sưu tập như vậy là WWW, các bộ sưu tập doanh nghiệp lớn hoặc các trang Tin tức hay Hỗ trợ có giá trị cao.

Hãy gọi θ là vectơ của tất cả các tham số tự do của mô hình xếp hạng đang được điều chỉnh. Trong trường hợp của BM25, vectơ này sẽ có hai

các thành phần: $\theta = (k_1, b)$. Trong trường hợp của BM25F, nó sẽ có nhiều hơn: $\theta = (k_1, b_1, \ldots, b_S, \text{v1}, \ldots, \text{v}_S)$. Nếu chúng ta bao gồm các đặc trưng không phải văn bản thì chúng ta sẽ có nhiều tham số hơn nữa, số lượng chính xác tùy thuộc vào phép biến đổi được sử dụng cho từng đặc trưng không phải văn bản.

'Điều chỉnh' các tham số của mô hình có thể được xem như một vấn đề tối ưu hóa, nơi chúng ta tìm cách tối đa hóa mức độ liên quan của mô hình xếp hạng đối với các tham số mô hình θ, cho một tập một tập các đánh giá mức độ liên quan nhất định. Cụ thể hơn, nếu chúng ta cố định tập tài liệu và một tập các truy vấn cùng với các đánh giá mức độ liên quan kèm theo, thì với bất kỳ thiết lập tham số nào θ chúng ta có thể tính toán chỉ số hiệu suất mà chúng ta lựa chọn $M(\theta)$. Điều còn lại là tìm thiết lập tham số tối đa hóa $M(\theta)$. Đây chính xác là một bài toán tối ưu hóa n chiều với M là hàm mục tiêu được tối ưu hóa trên không gian các giá trị hợp lệ θ .

Tối ưu hóa các phép đo IR tiêu chuẩn,[1] tuy nhiên, không hề dễ dàng: chúng rất tốn kém để đánh giá, có các cực đại và bậc thang cục bộ, không mượt mà và không có đạo hàm [49]. Vì những lý do này, việc áp dụng các kỹ thuật tối ưu hóa tiêu chuẩn không dễ dàng. Ngay cả việc áp dụng các kỹ thuật tối ưu hóa bậc 0 đơn giản như tối ưu hóa vùng tin cậy cũng khó và tốn kém. Trong thực tế, chúng tôi sử dụng một số kỹ thuật ad hoc để tăng tốc tìm kiếm toàn diện. Chúng tôi sẽ thảo luận về những điều này trong phần phụ tiếp theo.

Một lựa chọn khác là thay đổi hàm đang được tối ưu hóa. Cách tiếp cận này đặc biệt hữu ích khi người ta tối ưu hóa rất nhiều đặc trưng, và được thảo luận trong phần phụ cuối cùng.

5.1 Tối ưu tham lam

Chúng tôi thảo luận ở đây một số kỹ thuật (một số là thuật toán suy đoán, một số là mẹo triển khai) mà chúng tôi đã sử dụng trong quá khứ để tăng tốc tìm kiếm toàn diện và tìm các giá trị tham số tốt.

Bộ nhớ đệm: Vì việc đánh giá hàm tốn kém rất nhiều, chúng tôi lưu trữ các đánh giá này. Thật vậy, chúng tôi có thể thường xuyên xem lại một giá trị tham số trong

[1] Như Độ Chính Xác Trung Bình, Độ Chính Xác@k, Trung Bình Hạng Độ Lùi Ngược và Lợi Ích Tích Lũy Giảm Giá.

tìm kiếm giá trị tối ưu. Sẽ là lãng phí nếu đánh giá lại tất cả các truy vấn; thay vào đó, chúng tôi lưu trữ độ liên quan kết quả trong một bảng băm sử dụng các giá trị tham số làm khóa: $H[\theta] \leftarrow M(\theta)$.

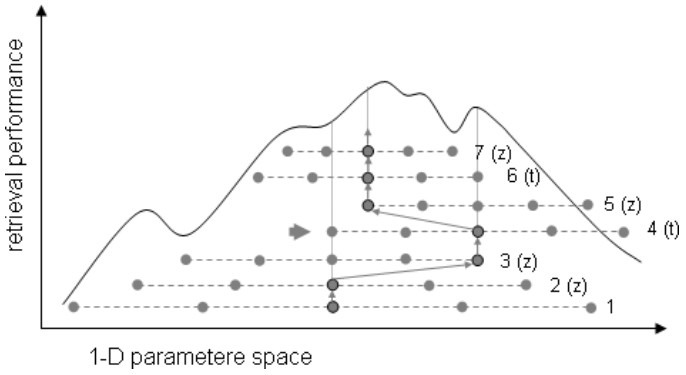
Lưới: Nó cũng hữu ích khi đặt độ phân giải tối thiểu cho mỗi tham số, định nghĩa một lưới các giá trị tham số được phép. Ví dụ, trong hầu hết các thí nghiệm của chúng tôi, chúng tôi không cho phép các tham số thay đổi vượt quá chữ số thập phân thứ hai. Điều này có ảnh hưởng không đáng kể đến hiệu suất liên quan và tăng đáng kể hiệu quả của bộ nhớ đệm cũng như tốc độ hội tụ. Hơn nữa, điều này giúp dễ dàng báo cáo và chia sẻ các giá trị tham số.

5.1.1 Tìm kiếm tuyến tính mạnh mẽ

Trước tiên, chúng ta xem xét các phương pháp tối ưu hóa trên một tham số duy nhất. Hầu hết các tham số được tối ưu hóa đều là số dương nhưng không có giới hạn trên. Do đó, chúng ta không biết vùng quan tâm của tham số đang được tối ưu hóa, cũng như không biết độ phân giải cần thiết (kích thước của các khoảng cần kiểm tra). Vì lý do này, chúng tôi đã phát triển thuật toán tìm kiếm sau, mà chúng tôi gọi là Tìm kiếm Tuyến tính Mạnh mẽ (Robust Line Search - RLS).

Gọi l và r là dấu ngoặc trái và phải hiện tại của không gian tìm kiếm 1–D. Chia vùng thành m phần bằng nhau kích thước $(r - l)/m$. Tính hiệu suất trên các biên của vùng $m + 1$, và gọi c là biên có hiệu suất cao nhất.

Ý tưởng là tiến về phía c bằng cách tái định tâm vùng tìm kiếm quanh c và điều chỉnh tỷ lệ phù hợp. Nếu $l < c < r$ chúng ta cần phóng to vào c, bằng cách thu nhỏ vùng tìm kiếm. Do hàm được tối ưu hóa có các cực đại cục bộ, chúng ta không thể phóng to quá mức, nếu không có thể mất hoàn toàn cực đại toàn cục; vì lý do này, chúng ta thường phóng to một cách thận trọng. Mặt khác, nếu c bằng r hoặc l, rất có khả năng cực đại nằm ngoài vùng tìm kiếm hiện tại và có thể ở xa. Do đó, chúng ta tăng kích thước vùng tìm kiếm. Chúng ta lặp lại quá trình này cho đến khi l và r nằm trong một khoảng cách tối thiểu, thường dưới độ phân giải tối thiểu đã đặt. Một ví dụ về tối ưu hóa được minh họa trong Hình 5.1.



Hình 5.1 Ví dụ về Tối ưu tham lam: tìm kiếm đường thẳng bền vững.

5.2 Tối ưu hóa đa chiều

Bất kỳ phương pháp tối ưu hóa 1 chiều nào cũng có thể được tổng quát hóa thành n-chiều theo một số cách. Chúng tôi đã sử dụng hai phương pháp để làm điều này, cả hai đều hoạt động tốt trong thực tế.

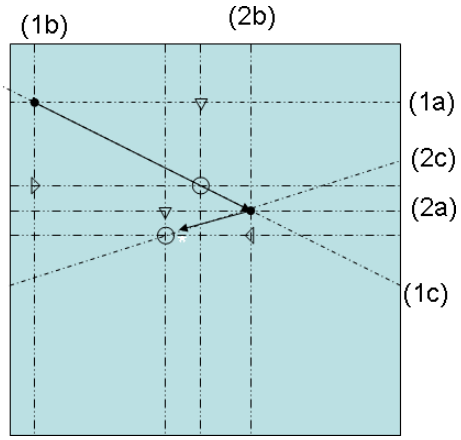
Tìm kiếm đường thẳng mạnh tham lam: Hãy tưởng tượng rằng chúng ta muốn chạy phương pháp RLS trên một bài toán 2 chiều, với các tham số $\theta = (\theta_1, \theta_2)$. Hãy để θ_2 là một biến phụ thuộc và chạy RLS trên θ_1. Mỗi lần chúng ta cần tính hiệu suất $M(\theta)$ tại một điểm $\theta_1 = z$ nhất định, chúng ta sẽ cần cố định θ_2 phụ thuộc ở giá trị tối ưu của nó. Để tìm giá trị này, chúng ta có thể chạy một RLS cục bộ để tối ưu hóa θ_2 tại chỗ trong khi giữ $\theta_1 = z$. Tổng quát hóa điều này, mỗi tối ưu hóa theo đường thẳng với các tham số i sẽ kích hoạt một tối ưu hóa với các tham số phụ $i - 1$ và cứ tiếp tục như vậy, theo cách đệ quy. Tất nhiên đây là một xấp xỉ tham lam cho việc khám phá toàn diện (theo cấp số mũ) của không gian tham số, bởi vì chúng ta đang chạy RLS. Tuy nhiên, cách tiếp cận này vẫn tốn kém theo cấp số mũ đối với n do tính chất đệ quy của nó, và vì vậy nó không khả thi cho các n lớn (ví dụ, $n > 3$).

Hướng triển vọng: Một cách khác mà chúng tôi đã sử dụng để thực hiện các tìm kiếm trong n chiều là như sau. [2] Chọn một điểm khởi đầu cho

[2]Phương pháp này có thể được xem như một phiên bản tuyến tính của *trusted region* các phương pháp tối ưu hóa [4, 5]; nó có lợi thế là yêu cầu đánh giá hàm số ít hơn nhiều, vốn cực kỳ tốn kém trong trường hợp của chúng tôi.

mỗi tham số (gọi kết quả là vector θ). Thực hiện n 1–D các tìm kiếm độc lập, để tìm giá trị tối ưu θ'_i của mỗi tham số khi tất cả các tham số khác được giữ cố định tại θ. Mỗi giá trị tối ưu được tìm thấy này xác định một hướng đầy hứa hẹn trong không gian tham số. Bây giờ xem xét vector đi từ θ đến $\theta' = (\theta'_1, ..., \theta'_n)$. Chúng ta kỳ vọng vector này sẽ di chuyển qua các vùng không gian thú vị nếu có sự tương quan giữa các đặc trưng. Do đó, chúng ta thực hiện thêm một tối ưu hóa 1–D dọc theo đường này. Chúng tôi làm điều này bằng cách tái tham số hóa hệ thống với một biến mới di chuyển tất cả các tham số một cách tuyến tính từ θ đến θ'. Cuối cùng chúng tôi chọn cài đặt tham số tốt nhất được tìm thấy cho đến nay và chúng tôi bắt đầu lại quá trình. Một ví dụ về tối ưu hóa được minh họa trong Hình 5.2, nơi chúng tôi hiển thị hai lần lặp đầu tiên (được ghi chú 1 và 2), mỗi lần lặp bao gồm ba tìm kiếm theo đường thẳng (được ghi chú a, b và c). Tổng chi phí của một lần lặp là $(n + 1)$ 1–D tối ưu hóa. Do đó, nó chỉ tăng tuyến tính với n, nhưng nó có thể yêu cầu v

K1 Tỷ lệ: Lưu ý rằng nói chung k_1 sẽ phụ thuộc vào các trọng số được gán cho các luồng trong BM25F, ngay cả khi nó được giữ như một tham số độc lập với luồng. Điều này là do các trọng số luồng thực chất làm thay đổi giá trị tf, và k_1 phải được điều chỉnh tương ứng. Nếu chúng ta có một giá trị k_1^{BM25} tốt cho hàm BM25 thông thường (không có luồng), chúng ta có thể đề xuất một giá trị ban đầu tốt của k_1 cho BM25F bằng cách điều chỉnh theo sự thay đổi



Hình 5.2 Ví dụ về tối ưu hóa tham lam: các hướng triển vọng.

trong độ dài tài liệu trung bình từ dạng không trọng số sang dạng có trọng số:

$$k_1^{\text{BM25F}} \approx k_1^{\text{BM25}} \frac{\sum_s v_s avsl_s}{\sum_s avsl_s} \tag{5.1}$$

5.2.1 Phân tích yếu tố của tìm kiếm

Một kỹ thuật rất hữu ích để tăng tốc quá trình tìm kiếm trong thực tế là chia tìm kiếm thành các lô, chỉ tối ưu hóa cùng nhau các tham số được biết là phụ thuộc mạnh. Khi thực hiện việc này, điều quan trọng là phải chọn các tham số ban đầu và thứ tự của các lô một cách thận trọng. Một lịch trình điển hình cho BM25F có thể là:

1. Tính toán tối ưu k_1 và b (bỏ qua các luồng). Điều này tương đương với việc đặt tất cả $v_s = 1$ và tất cả $b_s = b$. (Chi phí: $1\times$2D); 2. Tối ưu hóa trọng số luồng $\{w\}_{s=1..S}$ cùng nhau. Ở đây chúng tôi sử dụng mẹo tái chuẩn hóa k_1 trong Bước (5.1). (Chi phí: $1\times S$D); và 3. Tối ưu hóa k_1 và $\{b\}_{s=1..S}$ một cách độc lập (Chi phí: $(S+1)$ $\times$1D).

Lịch trình này có thể được lặp lại cho đến khi không đạt được sự tăng hiệu suất thêm nữa. Khi xử lý các đặc trưng không phải văn bản, tối ưu hóa trên thường được xen kẽ với tối ưu hóa các đặc trưng không phải văn bản, điều này cũng có thể được thực hiện độc lập hoặc cùng nhau theo từng lô.

5.3 Tối ưu hóa Gradient

Một khả năng khác là chọn một hàm hiệu suất có thể được tối ưu trực tiếp bằng các kỹ thuật học máy. Cách tiếp cận này đã được theo đuổi với một số thành công vài năm trước [1, 10, 55], và hiện nay đã trở thành một lĩnh vực nghiên cứu tích cực (xem ví dụ các hội thảo gần đây của NIPS và SIGIR về chủ đề này [23, 28]). Ý tưởng chính là xấp xỉ các hàm độ liên quan phụ thuộc vào thứ hạng như NDCG bằng một hàm có gradient được biết. Sau đó, chúng ta có thể áp dụng hàng loạt các phương pháp tối ưu dựa trên gradient. Tốc độ của các phương pháp này không tăng theo cấp số nhân với số chiều được tối ưu, vì vậy có thể tối ưu rất nhiều tham số cùng lúc. Hơn nữa, nếu BM25F được kết hợp với một số lượng lớn các yếu tố khác (không phải văn bản)

các đặc trưng, các phương pháp có thể được sử dụng để tối ưu hóa đồng thời tất cả các tham số. Ví dụ, đây là trường hợp trong [55] nơi mà mô hình tổng thể là một mạng nơ-ron nhân tạo nhận nhiều đặc trưng làm đầu vào, một trong số đó là BM25F. Việc chi tiết các phương pháp tối ưu hóa dựa trên gradient nằm ngoài phạm vi của khảo sát này.

6

Kết luận

Khung xác suất liên quan cổ điển đã cung cấp một loạt công thức đánh giá có cơ sở vững chắc, cũng như một số hiểu biết quan trọng về các khía cạnh khác nhau của tìm kiếm. Một trong những lý do thành công của PRF, theo chúng tôi, là sự kết hợp mạnh mẽ giữa mô hình lý thuyết vững chắc và việc tham số hóa thực dụng khai thác kiến thức trước của chúng ta trong IR. Chúng tôi không tin rằng PRF đã đến cuối vòng đời hữu ích của nó. Khi nó được hiểu rõ, mô hình PRF có thể cung cấp một nền tảng vững chắc để phân tích các vấn đề IR mới và đưa ra các giải pháp mới.

Tài liệu tha
m khảo

[1] S. Agarwal, C. Cortes, và R. Herbrich, biên tập., *Proceedings of the NIPS 2005 Workshop on Learning to Rank* 2005, . [2] G. Amati, C. J. van Rijsbergen, và C. Joost, "Các mô hình xác suất của truy xuất thông tin dựa trên đo độ lệch so với ngẫu nhiên," *ACM Transactions on Information Systems* 20, 4, 357–389, 2002, tập. số. tr. – . [3] M. M. Beaulieu, M. Gatford, X. Huang, S. E. Robertson, S. Walker, và P. Williams, "Okapi tại TREC-5," *The Fifth Text Retrieval Conference (TREC-5)*. *NIST Special Publication* 500-238, 143–165, 1997 - tr. – . [4] F. V. Berghen, "Thuật toán vùng tin cậy," Trang web, http://www.lemurproject.org. [5] F. V. Berghen, "CONDOR: Bộ tối ưu song song phi tuyến, không sử dụng đạo hàm, có ràng buộc cho các hàm mục tiêu liên tục, tải tính toán cao, và nhiều nhiễu," Luận án tiến sĩ, Université Libre de Bruxelles, 2004. [6] C. Bishop, *Pattern Recognition and Machine Learning (Information Science and Statistics)* 2006, . Springer, . [7] D. M. Blei, A. Y. Ng, và M. I. Jordan, "Phân bổ Dirichlet tiềm ẩn," *Journal of Machine Learning Research* 3, 993–1022, 2003, tập. tr. – . [8] D. Bodoff và S. E. Robertson, "Một mô hình xác suất hợp nhất mới," *Journal of the American Society for Information Science and Technology* 55, , tập. tr. 471–487, 2004. [9] P. Boldi và S. Vigna, "MG4J tại TREC" trong *The Fourteenth Text Retrieval Conference (TREC 2005) Proceedings* 2005, *NIST Special Publication* 500-266, 2005, . http://mg4j.dsi.unimi.it/.

[10] C. Burges, T. Shaked, E. Renshaw, A. Lazier, M. Deeds, N. Hamilton, và G. Hullender, “Học xếp hạng sử dụng gradient descent,” trong *Proceedings of the International Conference on Machine Learning (ICML)* 22, 89, 2005, tập. tr. .

[11] W. Cooper, “Một số sự không nhất quán và giả định mô hình bị xác định sai trong truy xuất thông tin xác suất,” *ACM Transactions on Information Systems* 13, 110 111, 1995, tập. tr. – .

[12] N. Craswell, S. E. Robertson, H. Zaragoza, và M. Taylor, “Trọng số phù hợp cho bằng chứng độc lập với truy vấn,” trong *Proceedings of the 28th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval* 472 479, 2005, tr. – ACM, .

[13] N. Craswell, H. Zaragoza, và S. E. Robertson, “Microsoft Cambridge tại TREC-14 *The Fourteenth Text Retrieval Conference* : Đường tr *(TREC 2005)* 2005
track Doanh nghiệp,” trong , .

[14] F. Crestani, M. Lalmas, C. J. van Rijsbergen, và I. Campbell, ““Tài liệu này có phù hợp không? ... có lẽ”: Một khảo sát về các mô hình xác suất trong truy xuất thông tin,” *ACM Computing Surveys*, tập 30, số 4, 1998.

[15] W. B. Croft và D. J. Harper, “Sử dụng các mô hình xác suất của truy xuất tài liệu mà không có thông tin phù hợp,” *Journal of Documentation*, tập 35, tr. 285–295, 1979.

[16] W. Feller, *An Introduction to Probability Theory and Its Applications*, tập 1. Wiley, 1968.

[17] N. Fuhr, “Các mô hình xác suất trong truy xuất thông tin

[25] J. Lafferty và C. Zhai, "Mô hình xác suất liên quan dựa trên việc tạo tài liệu và truy vấn," trong *Language Modelling for Information Retrieval*, (W. B. Croft và J. Lafferty, biên tập), tr. 1–10, Kluwer, 2003. [26] V. Lavrenko và W. B. Croft, "Mô hình ngôn ngữ dựa trên liên quan," trong *Proceedings of the 24th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval* 120 127, 2001 , tr. – ACM, .

[27] Bộ công cụ Lemur. Trang chủ. http://www.lemurproject.org. [28] H. Li, T. Y. Liu, và C. Zhai, "Học xếp hạng cho truy xuất thông tin (LR4IR 2008)," *SIGIR Forum*, tập 42, số 2, tr. 76–79, 2008. [29] Lucene. Trang chủ. http://lucene.apache.org/. [30] M. E. Maron và J. L. Kuhns, "Về liên quan, lập chỉ mục xác suất và truy xuất thông tin," *Journal of the ACM*, tập 7, số 3, tr. 216–244, 1960. [31] D. Metzler, "Lựa chọn tính năng tự động trong mô hình trường ngẫu nhiên Markov cho truy xuất thông tin," trong *Proceedings of the 31st Annual ACM Conference on Information and Knowledge Management* 253 262, , tr. – ACM

New York, NY, USA, 2007. [32] D. Metzler và W. B. Croft, "Mô hình trường ngẫu nhiên Markov cho sự phụ thuộc thuật ngữ," trong *Proceedings of the 28th International ACM SIGIR Conference on Research and Development in Information Retrieval* 472 479, , tr. – ACM,

2005.[33] D. Metzler, T. Strohman, và B. Croft, *Information Retrieval in Practice*. Pearson Education (Mỹ), 2009. {v18

[45] S. E. Robertson, C. J. van Rijsbergen, và M. F. Porter, “Mô hình xác suất của việc lập chỉ mục và tìm kiếm,” trong *Information Retrieval Research (Proceedings of Research and Development in Information Retrieval, Cambridge, 1980)*, (R. N. Oddy, S. E. Robertson, C. J. van Rijsbergen, và P. W. Williams, biên tập), tr. 35–56, London: Butterworths, 1981. [46] S. E. Robertson và S. Walker, “Một số xấp xỉ đơn giản hiệu quả cho mô hình 2-Poisson cho truy xuất trọng số xác suất,” trong *Proceedings of the 17th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval*, tr. 232–241, 1994, ACM/Springer. [47] S. E. Robertson và S. Walker, “Về trọng số liên quan với ít thông tin liên quan,” trong *Proceedings of the 20th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval*, tr. 16–24, 2007. [48] S. E. Robertson, S. Walker, M. Hancock-Beaulieu, A. Gull, và M. Lau, “Okapi tại TREC,” trong *The First Text Retrieval Conference (TREC-1) NIST Special Publication* 500 207, tr. 21–30, 1992. [49] S. E. Robertson và H. Zaragoza, “Về các phép đo hiệu quả dựa trên xếp hạng và tối ưu hóa,” *Information Retrieval*, tập 10, số 3, tr. 321–339, 2007. [50] S. E. Robertson, H. Zaragoza, và M. Taylor, “Mở rộng BM25 đơn giản cho nhiều trường trọng số,” trong *Proceedings of the 2004 ACM CIKM International Conference on Information and Knowledge Management*, tr. 42–49, 2004, ACM. [51] R. Song, M. J. Taylor, J. R. Wen, H. W. Hon, và Y. Yu, “Xem xét độ gần của thuật ngữ từ một khác

[60] Wumpus. Trang chủ. http://www.wumpus-search.org/. [61] Xapian. http://xapian.org. [62] H. Zaragoza, N. Craswell, M.Taylor, S.Saria, và S. E. Robertson, “ Microsoft Cambridge tại TREC 2004 *The Thirteenth Text* : Theo dõi *Retrieval Conference (TREC 2004) NIST Special Publication* 500 261, 2005 Web và HARD,” trong , , - . [63] Zettair. Trang chủ. http://www.seg.rmit.edu.au/zettair.